

学校代码: 10286
分类号: TP339
密 级: 公开
U D C: 004.8
学 号: 184202



工程硕士学位论文

基于注意力机制与数据增强的行人 重识别方法研究

(学位论文形式: 应用研究)

研究生姓名: 杨苗

导师姓名: 李慧颖 副教授

张 祥 副教授

崔 弘 高 工

申请学位类别 工程硕士 学位授予单位 东南大学

工程领域名称 计算机技术 论文答辩日期 2021 年 6 月 4 日

研 究 方 向 计算机视觉 学位授予日期 2021 年 月 日

答辩委员会主席 徐立臻 评 阅 人 盲审

20 年 月 日

東南大學

工程硕士学位论文

基于注意力机制与数据增强的行人重识别 方法研究

专业名称: 计算机技术

研究生姓名: 杨苗

导师姓名: 李慧颖 副教授

张祥 副教授

崔弘 高工

RESEARCH ON PERSON RE-IDENTIFICATION METHOD BASED ON ATTENTION MECHANISM AND DATA ENHANCEMENT

A Thesis Submitted to

Southeast University

For the Professional Degree of Master of Engineering

BY

YANG Miao

Supervised by

Associate Prof. LI Hui-ying

Associate Prof. ZHANG Xiang

Senior Engineer CUI Hong

Southeast University-Monash University Joint Graduate School

Southeast University

June 2021

摘要

行人重识别技术，作为人脸识别的一项补充技术，在视频监控领域得到了广泛地应用。行人重识别可以根据行人的整体外观、姿态、步态等信息对行人进行认知，实现跨摄像头跨场景下行人的识别与检索。行人重识别目前在公开的数据集上取到了不错的效果，而在现实场景中，由于光照、背景、摄像机的分辨率以及拍摄角度等问题，实际应用的效果远远低于学术场景。主要原因在于模型提取的行人特征的表征力不佳，以及数据样本集的不充足，使得模型鲁棒性较差。

基于以上背景，本文将从模型与数据两方面提升行人重识别的效果，主要研究内容如下：

（1）本文着重设计了一款全新的注意力机制，其中融合非局部注意力和比单一空间注意力与通道注意力更有效的混合注意力的思想，使得在增加有限复杂度的情况下，嵌入该注意力机制模块的行人重识别模型可以更好地识别行人的鉴别性特征，从而有效提升性能。

（2）再利用生成对抗模型，作为数据增强的一种手段，本文提出一套完整的生成式数据增强方案，其中还制作了一种通过结合聚类算法为生成的图像样本自动分配 ID 标签的标注生成方法。

（3）最后通过一系列行人检测、目标跟踪算法，再联合行人重识别与聚类过程，收集一个真实场景下的行人重识别数据集，并将本文提出的注意力模块和数据增强两种方法运用在此真实场景下，通过实验验证二者对于行人重识别任务的实用性。

综上，本文将运用全新的注意力机制与生成式数据增强方法来达到行人重识别模型性能提升的目的，并在真实场景中收集的数据集上加以检验，证实上述方法的有效性。

关键词： 行人重识别，注意力机制，数据增强，聚类，标签生成

Abstract

Person re-identification technology, as a supplementary technology of face recognition, has been widely used in the field of video surveillance. Person re-identification can realize the recognition and retrieval of pedestrians across cameras and across scenes by cognition of pedestrians through their overall appearance, posture, gait and other information. At present, person re-identification has achieved good results on public data sets. However, in the real scene, due to the lighting, background, camera resolution, shooting angle and other problems, the effect of the real application is far lower than that of the academic scene. The main reason is that the model is not strong enough to obtain the representation of pedestrian features, and the sample set of person re-identification data-set is not sufficient, which leads to poor robustness of the model.

Based on the above background, this paper will improve the person re-identification effect from the two aspects of model and data. The main research contents are as follows:

(1) This paper focuses on the design of a new attention mechanism module, which integrates non-local attention and the idea of mixed attention that is more effective than single spatial attention and channel attention. And on the premise of increasing the finite complexity, the person re-identification model embedded by this attention module can better identify the discriminative characteristics of pedestrians, thus effectively improving the performance.

(2) In addition, using the generative adversarial model as a means of data enhancement, this paper proposes a complete set of generative data enhancement scheme, in which an annotation generation method which combines clustering algorithm to automatically assign valid ID tags for the generated image samples is also proposed.

(3) Finally, through a series of pedestrian detection and pedestrian tracking methods, combined with person re-identification and clustering algorithm, to collect person re-identification dataset in a real scene. Then the attention module and data enhancement methods proposed in this paper are applied in the real scene, and the practicability of the two methods for person re-identification task is verified through experiments.

To sum up, this paper will use the new attention mechanism and generative data enhancement method to achieve the purpose of improving the performance of person re-identification model, and verify the effectiveness of the above method on the data-set collected in the real scene.

Keywords: re-identification, attention, data enhancement, clustering, annotation generation

目录

摘 要	I
Abstract	III
插图目录	IX
表格目录	XI
专业术语表	XIII
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外相关研究	2
1.2.1 行人重识别中注意力机制的研究概况	2
1.2.2 行人重识别中数据增强的研究概况	3
1.2.3 行人重识别中聚类算法的研究概况	4
1.2.4 研究现状总结	5
1.3 研究目标与内容	5
1.4 论文结构与安排	6
第二章 相关技术	7
2.1 行人重识别任务流程	7
2.2 注意力机制	8
2.3 生成对抗网络	9
2.4 数据增强	9
2.5 聚类算法	10
2.6 本章小结	12
第三章 基于注意力机制的行人重识别方法	13
3.1 问题描述	13
3.2 注意力机制模块的设计	13
3.2.1 非局部操作	14
3.2.2 混合注意力	15
3.2.3 注意力机制结构设计	16

3.3	行人重识别模型的选取	16
3.3.1	行人重识别基线模型	17
3.3.2	嵌入注意力机制的行人重识别模型	18
3.4	实验评估	18
3.4.1	数据集简介	19
3.4.2	实验评估指标 (CMC/mAP)	19
3.4.3	实验参数设置	21
3.4.4	实验结果及分析	21
3.5	本章小结	23
第四章	基于数据增强的行人重识别方法	25
4.1	问题描述	25
4.2	聚类算法的对比分析	26
4.2.1	聚类算法原理	26
4.2.2	聚类算法评估指标	27
4.3	生成式数据增强方案总体设计	28
4.3.1	生成模型	28
4.3.2	生成样本的标签分配方法	29
4.4	实验评估	29
4.4.1	任务 1: 聚类算法对比实验	30
4.4.2	任务 2: 基于生成式数据增强的行人重识别实验	32
4.5	本章小结	33
第五章	融合注意力机制与数据增强的行人重识别方法	35
5.1	数据集采集	35
5.1.1	行人检测与跟踪	36
5.1.2	样本去重	36
5.1.3	聚类分配样本标签	38
5.2	实验评估	38
5.2.1	实验流程	39
5.2.2	超参数分析	39
5.2.3	实验结果与分析	40
5.3	本章小结	42
第六章	总结与展望	43
6.1	本文总结	43
6.2	未来工作展望	43

致谢	45
参考文献	47
作者简介	51

插图目录

2.1	行人重识别流程图	7
2.2	A Squeeze-and-Excitation block 结构图	8
2.3	CBAM 模块的结构图	9
3.1	$R = 1$ 的高阶注意力模块 (HOA) 结构图	15
3.2	$R = 2$ 的高阶注意力模块 (HOA) 结构图	15
3.3	注意力机制模块设计结构图	16
3.4	行人重识别 pipeline 结构	17
3.5	嵌入注意力机制的行人重识别模型	18
3.6	mAP 计算示例图	20
4.1	Re-ID 模型与 GANs 结合的流程图	28
4.2	DG-Net 模型原理图	29
4.3	聚类算法对比实验流程图	30
4.4	聚类算法对比实验可视化	31
4.5	基于生成式数据增强的行人重识别实验流程图	32
5.1	数据集采集流程图	35
5.2	序列图像集示例图	36
5.3	去重后的行人图像集示例图	37
5.4	FINI 数据集上的总体实验流程图	39
5.5	FINI 数据集上 $Data_{aug}$ 方法的 CDP 聚类参数试验结果对比图	40
5.6	行人重识别任务输出可视化	41

表格目录

2.1	传统聚类算法关键点总结	12
3.1	公开数据集介绍	19
3.2	行人重识别实验 1 评估结果	21
3.3	行人重识别实验 2 评估结果	21
3.4	阶数 R 设置问题实验结果	22
3.5	基于注意力机制的行人重识别最新研究方法对比	22
4.1	聚类算法评估系数表	30
4.2	基于数据增强的行人重识别对比实验评估结果	33
4.3	基于数据增强的行人重识别最新研究方法对比	33
5.1	CDP 聚类多组参数的评估峰值对比结果	39
5.2	FINI 数据集上的实验评估结果	41

专业术语表

Re-ID	行人重识别
Query	查询图像
Gallery	图像集
GANs	生成对抗网络 Generative adversarial networks
NL	非局部 Non-local
HOA	高阶注意力模块 High-Order Attention
BN	Batch Normalization
CMC	累积匹配特性 Cumulative Matching Characteristic
mAP	平均精度 mean Average Precision
$Data_{aug}$	生成式数据增强

第一章 绪论

1.1 研究背景与意义

行人重识别（Person Re-Identification, Re-ID）技术作为现今计算机视觉领域的热门研究方向，主要用于跨摄像头跨场景下行人的识别与检索任务^[1]。该技术可归结于图像检索的一个子问题，同样也是行人智能认知领域的一个重要方向，可与人脸识别技术相结合应用于众多的现实场景中，将人工智能的行人认知水平提高到一个新阶段。

现今的人脸识别技术，是搭建平安城市的重要一环，通过该技术以及结合相关的深度学习算法，城市监控就可以实现视频监控数据的结构化存储，再通过进一步分析挖掘关键有效信息，就可以实现平安城市的事前预防。然而在实际应用场景中，摄像头并非在任何情况下都可以拍摄到清晰的人脸，经常会因口罩、帽子等饰物的遮挡，使得警察和识别系统都无法仅仅通过人脸来进行行人身份的识别。因此，利用全身的整体信息和身体局部细节，或者辅以附加信息例如姿态、步态等，来对行人进行识别、锁定和查找就变得十分必要——即通过将行人的整体特征作为人脸特征之外的重要补充，以此实现对行人的跨摄像头识别。

理论上，在利用人脸识别进行行人识别跟踪的应用场景下，当无法捕获到足够清晰的人脸进行辨别时，可利用 Re-ID 技术，对这些无法捕获清晰人脸的行人利用衣着、发型、姿态等行人信息加以识别，从而实现跨摄像头连续跟踪，增强跟踪数据的连续性。在现实视频监控场景下，众多干扰因素比如光线暗、距离远、摄像头分辨率差异大、拍摄角度偏置等等都使得捕捉人脸这样典型的生物特征的想法变得不切实际，因此在现实场景下进行行人识别与跟踪时 Re-ID 技术更为适用。由此可见，Re-ID 技术区分于人脸识别，是一项可通过行人的衣着、发型、姿态等信息进行行人识别的技术，在视频监控、城市智能安防等领域起着非常重要的作用。

行人重识别技术还与行人检测技术在字面上有一些相似性，但两者本质上相区别。行人检测是简单判定图像中是否存在行人，而 Re-ID 则是要识别出不同摄像机拍摄到的特定行人的所有可能图像。具体而言，即给定行人的一张图像（Query image），再从庞大图像集（Gallery images）中找到属于该行人的一张或多张图像，这就是通过行人整体特征实现的行人图像检索技术。另外，两者的应用领域也有所区别，行人检测主要运用于智能驾驶、辅助驾驶等场景，而 Re-ID 主要应用于刑侦工作、视频监控、智能安防等众多领域。

现阶段由于公共安全的迫切需求，以及高校校园、主题公园、街道等场所监控摄像头数量的不断增加，Re-ID 技术在智能视频监控系统中变得不可或缺^[1]。早期的研究主要集中在手工提取身体结构的特征^[2]，或距离度量学习^[3]。随着深度学习^[4]的推进，

Re-ID 在广泛使用的基线模型上取得了不错的成绩^{[5][6]}。然而，研究导向的场景和实际应用之间仍然有很大的差距。

现下 Re-ID 任务还面临着数据集不充足的问题，用于研究工作的行人重识别公开数据集规模不大，与真实场景中收集的数据存在着较大的差异。在真实场景中，Re-ID 任务通常是在室内外场景中部署的摄像机网络中执行，并处理长时间拍摄的视频。因此，真实的 Re-ID 应用场景必须应对大量的身份、复杂的光照变化和场景变化等挑战。并且，行人重识别任务研究的对象是人的整体特征，包括衣着、体形、发型、姿态等。当深度学习运用于 Re-ID 行人特征提取时，全局特征是首选，但容易忽略掉局部细节信息，比如行人衣服上的明显标志、手包等装饰物，此时就需要研究全局特征与局部特征相结合的方式来进行行人特征提取，注意力机制能够为之提供良好地辅助细节特征提取的方案。

为此，本文着重于研究基于图像的行人重识别任务，结合注意力机制来优化行人特征的提取以提高基线的性能，以及利用生成对抗模型做数据增强，并着力于研究一种基于聚类的标签分配方式来有效扩充数据，其中涉及的聚类算法还可以用于数据集采集阶段，大大地减小数据标注的人工成本，从而从模型与数据两方面提升 Re-ID 的识别效果。

1.2 国内外相关研究

研究前期，对国内外相关技术，包括注意力机制、数据增强、聚类算法，进行了充分的调研，为本文的研究方向提供了重要指引，下面对于相关技术的研究概况展开详细介绍。

1.2.1 行人重识别中注意力机制的研究概况

注意力机制是一种能够使得网络权重分配自动偏向于信息最丰富部分的方法。在计算机视觉领域，研究者们对于注意力机制的研究从 2014 年开始兴起，随后还逐步发展渗透到自然语言处理领域。2017 年，SE-Net^[7] 作为首次提出的一种有效的通道注意力学习机制，取得了良好的效果并一举夺得当年 ILSVRC 比赛的第一名。随后注意力机制迅速发展，在其基础上不断丰富、变化。Woo 等人在 2018 年提出的 CBAM (Convolution block attention module)^[8] 中利用二维卷积计算空间注意力，然后通过与通道注意力相结合的方式构造出新的注意力机制。Roy 等人在 2019 年提出的 scSE^[9]，将 SE 模块变换三种形态并分别整合到 F-CNN 架构中，自适应地校准学习到的特征映射。同年，Cao 等人提出的 GcNet^[10] 网络，通过共享相似的原理集成 SE-Net 与非局部神经网络形成轻量级模块，以此来建模远程依赖关系，形成一个简化的 NL(Non-local) 网络。

聚焦于行人重识别领域，Liu 等人在 2017 年提出了一种端到端比较注意力网络 (CAN)^[11]，该网络模拟人的感知过程，自动学习行人图像具有辨识度的部分（即 soft attention），动态生成行人特征，以此来判断一对行人图像是否属于同一个人。Li 等人^[12] 提出运用空间变换网络 (STN) 来定位潜在区域（即 hard attention），然后将这些区域特征

提取应用于给下游的任务。随之,注意力机制开始正式被应用于行人重识别任务中,并且还出现许多复杂而灵活的变体。2018 年一种新的和谐注意力卷积神经网络 (HA-CNN)^[13] 被提出,其用于软像素注意力和硬区域注意力的联合学习,同时优化特征表示,进一步优化错位图像样本中的特征对齐问题。2019 年 Chen 等人提出的 ABD-Net^[14],在整个网络中无缝地集成了注意力模块和多样性规则化,以学习具有鉴别性的特征。同年高阶注意力机制 (High-Order Attention, HOA) 模块^[15] 被提出,其利用注意力机制对复杂的高阶统计信息进行建模,捕捉行人之间的细微差异,从而产生有区别度的注意力信息。上述方法为本文的注意力模块的设计提供了方向上的指引。

1.2.2 行人重识别中数据增强的研究概况

行人重识别领域中数据增强的方法众多,可以归纳为两大类:图像空间变换与生成式数据增强,其中第一类是较为常规的图像变换,第二类则为本文研究的重点。在行人重识别领域中利用生成对抗网络做数据增强的方法颇为灵活。

生成对抗网络 (generative adversarial networks, GANs) 自 2014 年诞生以来,大量 GANs 的论文在各大顶会期刊中陆续推出。传统的 GANs 模型以服从某种分布的随机噪声数据作为生成器的输入来生成图像样本,再利用判别器判断图像为生成样本还是真实样本^[16],训练过程中生成器与判别器经过不断地迭代更新,直至对抗损失函数到达均衡状态。2017 年, Cycle-GAN^[17] 的提出首次引入循环一致性损失,使得图像之间的风格转换不再依赖于成对的训练数据,将图像风格转换推向了新的高潮。2018 年, Zhong 等人提出 Camera Style Adaptation^[18] 方法来实现跨摄像头的风格迁移,其核心即利用 Cycle-GAN 扩充数据避免过拟合的发生,同时减小不同摄像头的视角、背景等外界因素对于检索任务的干扰。Wei 等人同年提出 PT-GAN^[19],该模型在 Cycle-GAN 框架的基础上,尝试将有标签的数据集风格迁移到无标签的数据集风格上,缩小域差异。Deng 等人提出的 SP-GAN^[20] 也是在 Cycle-GAN 的基础上加以改进,主要思路是提升通过域 A 训练好的模型在域 B 上的检测效果,来减小域之间的差异。2019 年, Zheng 等人提出 DG-Net^[21] 模型,该模型将行人重识别任务与图像数据生成任务统一于一个端到端的联合学习框架,该框架的判别模块和生成模块之间存在一个在线交互循环的过程,使两种任务互相受益,其模型理念是让行人重识别训练时可以更好地利用潜在生成的数据,而不是简单地对生成的数据样本进行训练。无论是图像生成质量还是 Re-ID 识别的准确性上,该方法都带来了一些实质性的改进,是目前行人重识别领域生成图像质量最佳的模型。

使用 GANs 生成样本做数据增强,需要着重进一步考虑如何为生成样本分配适当标签的问题。早在 2017 年, Zheng 等人^[22] 提出一种标签平滑的方法来设置生成样本的标签并投入训练,当时采用 DC-GAN^[16] 模型生成的图像样本的质量并不高,因此能够用该方法为这些生成样本分配统一的标签来正则化网络学习。该方法假设训练数据中存在 N 个类别,本质思想就是让网络将生成样本 ID 标签都设置成一个为 $1/N$ 的概率值,其

思路主要来自于 InceptionNet-v3 中 label smooth 的理念^[23]。2019 年, Huang 等人^[24] 使用 WGAN^[25] 继续这个方向的研究, 延续将伪标签分配给生成样本图像的思想, 利用真实数据分布中生成数据与其可能存在的隶属关系, 为每一个生成样本动态的分配虚拟标签。这些方法证实了利用生成对抗网络的生成样本联合实际样本投入训练时, 只要结合适当的标签分配策略, 就可以有效提高行人重识别模型的判别能力。

1.2.3 行人重识别中聚类算法的研究概况

行人重识别领域的学者对于聚类算法的研究大多在于基于聚类引导的半监督或者无监督算法, 它们通常使用聚类生成的伪标签进行训练, 从而避免了直接进行数据标注的问题。基于聚类引导的半监督算法, 还可以用于解决 Re-ID 任务中的“跨域”问题, 这里的“跨域”指的是跨越不同数据集的场景, 分属于不同数据集的行人样本在背景、外观、光照、分辨率上都会有比较大的差异, 而半监督算法还可以一定程度上缓解利用跨场景的行人图像用于训练时导致的模型效果降低的问题, 使得不同数据集都可以共享投入 Re-ID 模型的训练, 这种方式也有利于解决 Re-ID 任务的数据问题。

早前基于无监督的行人重识别问题的研究进展相对缓慢, 重点主要集中于先利用人工提取行人特征再使用无监督算法进行分类的方法上, 针对的数据集规模也比较小。2017 年, 渐进的无监督学习方法 (progressive unsupervised learning, PUL)^[26] 的提出, 首次把深度学习框架应用到大规模数据集的无监督行人重识别问题上, 其主要训练思路就是用有标签数据首先预训练一个模型; 再将无标签数据输入模型进行推理, 得到伪标签, 并进行 k-Means 聚类 and 样本选择, 从中选出可靠数据加入数据集; 利用更新的数据集再从头训练模型并保存; 继续下一轮迭代, 将无标签数据输入上一轮保存的模型中继续聚类。概括来讲, 其实就是模型结合聚类算法, 使用不断升级的训练数据来迭代训练的过程。PUL 算法是将深度学习框架应用到大规模数据集的无监督行人重识别问题的开山之作, 初次尝试之后, 学术界在这个方向上不断改进。2019 年, Lin 等人提出一种自下而上的聚类方法 (BUC, bottom-up clustering)^[27], 来联合优化卷积神经网络 (CNN) 和单个样本之间的关系, 不使用任何带标签的源数据, 只使用未带标签的目标数据和在 ImageNet 上预先训练好的模型。2020 年 Zeng 等人提出的 HCT^[28] 算法, 对 BUC 算法进行改进, BUC 中比较目标数据集中图像的相似度, 直接采用自下而上的层次聚类方法进行样本合并, 其合并固定数量的集群, 更新伪标签, 再使用生成的伪标签对模型进行微调, 然后重复合并和微调的过程, 直到模型性能不再提高为止。该算法的缺点在于, 合并时只依赖样本之间的相似性, 这使得 hard examples (hard examples 指那些十分相似但不属于同一身份 ID 标签的样本) 难以区分开来, HCT 算法则利用 hard-batch triplet loss 对其进行优化。

这些方法都是行人重识别领域有关聚类算法的研究成果, 其中涉及到的具体聚类算法多为传统的基于划分的 k-means 算法、层次聚类算法, 然而机器学习领域的聚类算法众多, 例如基于密度的 DBSCAN 算法等等。并且在计算机视觉其他研究领域上, 聚类

算法的创新也层出不穷，例如人脸识别中比较经典的 CDP 算法。它是由 Zhan 等人于 2019 年提出的人脸聚类方法，其中仅利用 9% 的有标签的数据与大量无标签的数据，就达到了与完全监督方法不分伯仲的效果。对于这些聚类方法的研究，为本文聚类算法的研究提供了重要思路。

1.2.4 研究现状总结

经过行人重识别领域大量的论文研究与论证分析，发现了以下几点：

(1) **注意力机制模块设计单一**：在注意力机制领域，注意力机制模块更多的是采用通道注意力、空间注意力，或者二者结合的产物，结构单一，因此在注意力机制模块的设计上有较大的上升空间；

(2) **Re-ID 领域适用的聚类研究缺乏**：在聚类算法的研究中，本文着力于行人重识别聚类算法的同时，更多的发现行人重识别领域并未聚焦于聚类算法本身，而是直接运用传统的层次聚类或者 k-means 聚类等算法，尚未研究分析出哪一种聚类算法更加适用于 Re-ID 任务；

(3) **生成样本标签分配方式待更新**：利用生成对抗网络生成图像样本的技术在不断进步，从最初的随机生成、条件生成，发展到利用已有样本共同作用的联合生成方式，使得生成样本的质量有了质的飞跃，因此与之相匹配，行人生成样本的 ID 身份标签的分配方式也亟待进一步更新。

1.3 研究目标与内容

本文的研究目标是为实际场景下的行人重识别任务，设计一个从模型到数据样本层面，均配备完善的行人重识别方案，并通过自建的实际场景下的行人数据集加以检验。

Re-ID 任务符合 zero-shot learning 的设定^[15]，其训练集和测试集中的行人类别 ID 是完全没有交集的，因此 Re-ID 模型需要从可见的训练类别中学习，然后用所学的知识来判别测试集中的未知类别。当然这其中除了行人的全局信息之外，充分捕捉行人的局部细节信息，对于更好地获取行人之间的细粒度差别、得到更具表征力的行人特征，起着非常重要的作用。本文提出的全新的注意力机制模块，融合了非局部（Non-local，简称 NL）操作与混合注意力的思想，能够使得模型更好地利用局部细粒度特征，有效提升模型对于行人鉴别性特征的提取能力。

另外，目前人脸识别任务中人脸数据训练样本集的量级已经达到数百万级别，其中规模最大的 MegaFace2 数据集包含 67.2 万个 ID，共 470 万张人脸图片，而行人重识别中最大的公开数据集只有 4,101 个行人 ID，共 126,441 张行人图像。因此行人重识别任务在数据量上的需求远未得到满足，训练数据的丰富度上有待进一步加强，本文利用生成式数据增强方法为真实数据样本添加更多生成样本。该方法目前的两大难点在于生成图像样本的质量与样本标注的方法，本文采用目前生成样本最佳的 DG-Net 模型来生成

样本，再结合聚类算法，提出一套针对生成样本标注问题的有效解决方案。方案中提及的适用于行人重识别任务的聚类算法，是经过充分的实验研究分析后得出的。

为此本文的研究内容主要包括三个方面：

（1）设计一款针对行人重识别任务的注意力机制模型，以增强基线模型对于区分度高的局部细节特征的提取能力；

（2）提出一套有效的生成式数据增强方案，其中采用 DG-Net 模型生成丰富的样本，并且为之探索出一种适合于 Re-ID 任务的聚类算法，结合该聚类算法设计全新的行人 ID 标签的分配方案；

（3）结合行人检测、跟踪算法，采集实际场景下的行人重识别数据集，以此检验以上方法的性能。

1.4 论文结构与安排

本文阐述了基于注意力机制与数据增强的行人重识别方法研究，到实际数据集上验证分析的过程，总共分为六章，各章节具体内容如下：

第一章，主要介绍本文的研究背景与意义、国内外相关方法的研究概况，以及研究目标与内容，着重对于行人重识别领域的注意力机制、数据增强与聚类算法展开介绍。

第二章，主要对于本文中涉及的相关知识进行介绍，诸如行人重识别的任务流程，注意力机制、生成对抗网络、数据增强与聚类算法。

第三章，描述基于注意力机制的行人重识别方法的研究，设计全新的注意力机制模块，并在公开数据集上进行实验验证与分析。

第四章，设计生成式数据增强的完整流程，其中首先探索行人重识别领域最适用的聚类算法，以及描述结合聚类设计的一套针对 DG-Net 生成模型的新的标签生成方案。

第五章，采集现实场景下行人重识别数据集，检验本文提出的注意力机制与数据增强方法的实用效果。

第六章，主要包括对本文研究工作与成果的总结，以及对未来工作的设想。

第二章 相关技术

本文主要对行人重识别领域中的注意力机制和生成式数据增强加以研究，注意力机制用于辅助行人的特征提取，联合全局性特征来捕获更具表征力的特征信息；生成式数据增强用于产生多样化的图像样本来丰富数据集，结合聚类算法为生成的无标签数据分配行人 ID 标签。本章将首先描述行人重识别任务的具体流程，然后对于论文中涉及的相关概念逐一进行介绍。

2.1 行人重识别任务流程

如图2-1所示，宏观上行人的重识别任务包括行人数据收集（分三步），以及行人重识别（分两步）两个阶段，具体的流程如下：

- （1）从实际应用场景的各个摄像头中，收集原始监控录像的视频集；
- （2）运用行人跟踪、检测算法，将行人图像从原始视频集中截取并裁剪出来；
- （3）为这些裁剪得到的行人图像进行标注，赋予它们正确的行人 ID 标签，确保同一行人的所有图像数据拥有统一且唯一的 ID 标签；
- （4）运用标注的行人数据集进行行人重识别模型的训练，该步骤是行人重识别算法的核心，也是行人重识别任务研究的重点所在；
- （5）向训练完备的行人重识别模型中，输入想要寻找的特定行人图像（Query），模型将从裁剪得到的庞大行人图像集（Gallery）中检索该对象，并按照相似度由高到低的顺序返回前 n （通常取 $n=10$ ）张行人图像作为输出。




图 2-1 行人重识别流程图

2.2 注意力机制

注意力机制可以使得卷积网络提取特征时将更多的资源分配给信息最丰富的、最具有区分性的区域，达到突出重点信息、抑制无关信息的目的，其本质上是通过对相关特征学习权重分布，再施加到原始特征上对其进行重新加权，以进一步提取相关信息。注意力机制大体可以分为两大类，一类为软注意力机制，另一类为硬注意力机制。软注意力是通过神经网络前向传播计算出梯度再后向反馈的过程来学习得到的，因此是可微、连续的确定性注意力，其关注的是空间区域与通道间的信息；而硬注意力是由强化学习的方式得到的，经由一个随机预测、动态变化的学习过程，因此是不可微的，并且其更加专注于图像中的每一个点，也就是从每一个点中都可能延伸出注意力。

软注意力机制是本文的研究重点，本文提出全新的注意力机制模块，可嵌入模型之中提取注意力信息。下面首先介绍一下软注意力机制的几种常见类型：

(1) 通道注意力与空间注意力：通道注意力的典型代表即是 2017 年 Hu 等人提出的 SE-Net (Squeeze-and-Excitation Networks) 架构，其研究网络结构中通道之间的关系，通过引入 Squeeze-and-Excitation blocks 组件，显式建模网络卷积特征的通道之间的相互依赖关系。如图 2-2 所示，将输入 X 映射为特征 U ，其中 $U \in R^{c \times h \times w}$ ，经过 squeeze 操作 F_s 聚集跨越空间 $h \times w$ 维度的特征产生 c 维的通道描述符。该通道描述符本质上是一个通道特征的全局响应，嵌入整合了全局的通道信息，再经由 excitation 操作 F_e 产生最终的每个通道的权重分布，最后将其映射到特征 U 上重新加权得到该注意力机制的输入。而空间注意力与通道注意力最大的区别就在于对特征 U 提取的是空间区域特征，因此会聚集通道维度的 c 维信息得到 $h \times w$ 维度的空间描述符，该过程一般通过空间转换器 (spatial transformer) 来对空间信息作空间变换从而提取出关键信息。




图 2-2 A Squeeze-and-Excitation block 结构图

(2) 空间与通道注意力的结合：两种注意力的结合由 2018 年 Woo 等人提出的 CBAM 注意力机制模块给出了最佳方案，如图 2-3 所示。作者经实验研究发现两种注意力机制模块最佳的方式是顺序放置而非并列，顺序地生成注意力映射可以推断出更精细的注意力输出，并且通道注意力优先略优于空间注意力优先。两种注意力机制的结合相比于任意一种单独的注意力机制，所取得的性能更佳，当然适当的结合策略也同样重要。




图 2-3 CBAM 模块的结构图

2.3 生成对抗网络

生成对抗网络 (Generative Adversarial Networks, GANs), 用于完成图像生成任务, 通过生成器和判别器的最大最小博弈来学习真实的数据集, 从而生成足够拟真的图像, 其在数据增广、图像创作等领域备受青睐。在行人重识别任务中, GANs 可作为一种有效数据增强的手段, 通过生成样本来丰富样本以扩充训练集, 提高模型对于未知样本的泛化能力。

生成对抗网络是近年来深度学习中的一个研究热点, 研究人员为其研发了大量的算法以及多样化的 GANs 变种^[26]。深度学习领域的传奇人物 Yann LeCun 曾说道, “GANs are the most interesting idea in the last 10 years in machine learning”。GANs 中的两个模型: 生成器与判别器, 通常采用两个神经网络来实现的, 并且两者之间存在一种相互竞争的关系, 其背后的对抗性学习的原理具体为: 判别器用于判别样本是真实的样本还是生成的伪样本, 生成器用于生成尽可能真实的样本, 使得判别器无法辨别其真伪。这种对抗关系也使得判别器和生成器得到不断地改进, 构成一个动态的“博弈过程”, 最终达到一种均衡——生成器的生成样本足以“以假乱真”, 以至判别器无法辨识生成器生成的样本的真伪。GANs 的原理可用公式表达为:

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (2.1)$$

其中, x 表示真实图片, z 表示输入 G 网络的噪声, 而 $G(z)$ 表示 G 网络生成的图片, $D(x)$ 表示网络判断图片 x 为真实图片的概率。生成器 G 希望图片越接近真实越好, 即希望 $D(G(z))$ 尽可能大, 这时 $V(D, G)$ 会变小; 而判别器 D 能力越强, $D(x)$ 越大, $D(G(z))$ 越小, 这时 $V(D, G)$ 会变大, 从而两者相互博弈直至达到均衡状态。

2.4 数据增强

数据增强方法具备显著改善深度学习模型的泛化能力的潜力。行人重识别领域中数据增强的方法众多, 可以归为两大类: 图像空间变换与生成式数据增强。行人重识别的训练过程中, 第一类图像空间变换方法例如旋转、翻转、平移、随机擦除等, 均属于较

为常规的操作；而第二类则需运用生成对抗网络作数据增强，是一种可直接大量扩增数据集有效方法，且为本文的研究重点之一。

除此之外，计算机视觉领域中学者们也提出过其他的数据增强的方法，例如简单且与数据无关的 Mixup^[29] 操作通过将数据集中任意两个数据样本按照一定比例进行融合来做数据增强等等。

通常，行人重识别模型训练时，都会使用常规的翻转、随即擦除等方法。其中随机擦除方法通过在行人图像上随机选取一块区域，并用零来填充以擦除掉原先的图像信息，可以一定程度上增强模型对于遮挡、部分缺失等问题的鲁棒性。而生成式数据增强，利用生成对抗网络生成更多的训练数据，本质上不是通过扩张特征空间来引入更多的数据信息，而是在保留住关键信息的前提下利用无关的噪声作扰动，迫使模型学习捕捉在无关信息干扰下的行人特征中不变的关键性因素，从而提取到更具价值的鉴别性行人特征，以此提升模型的识别能力，达到数据增强的目的。

2.5 聚类算法

聚类是众多的数据驱动应用程序领域中的一个基本问题，其目标是根据一些相似性度量，比如欧几里得距离、余弦距离等，将相似度高的数据分配到一个类别中，聚类算法性能的好坏在很大程度上取决于数据表示的质量。传统聚类算法包括基于划分的聚类算法、层次聚类算法、基于密度的聚类算法等。

(1) **基于划分的聚类算法**：将数据集（包含 n 个对象）初始划分为 k 个簇，然后使用迭代控制策略来优化目标函数。控制策略多为基于距离的方法，例如 k -means 算法基于欧式距离计算出簇的中心来代表该簇， k -medoid 算法遍历簇中所有数据点选取误差平方和最小的点作为中心点来代表该簇。初始划分 k 个簇后具体优化的过程为，先根据控制策略计算出簇中新的中心，重新将所有对象分配给“最接近”的簇，不断地迭代计算新的簇心，直至簇心无法更新为止。该方法的缺点在于，需要一些领域知识预先确定初始划分 k 的取值，以及簇的形状必须是凸的，使得该方法的适用范围比较局限，算法原理比较简单，此处不做展开。

(2) **层次聚类算法**：将数据集进行层次分解，分解可用树形图表示，数据集迭代地分割成更小的子集，直至每个子集只包含一个对象。这种层次结构中，每个节点代表一个集群，可以从叶子到根的方法（自下向上）创建，也可以通过每一步合并或者分割集群从根到叶子（自上向下）进行创建。与基于划分的聚类算法相比，分层聚类不需要初始输入 k 值，但是必须定义终止条件以指示何时终止合并或者分割的过程。一般判断合并还是分割的核心是度量两个集群之间的距离，而终止条件即为层次聚类算法的难点所在，比如设立所有集群之间的最小临界距离来作为终止条件时，临界值过小会使得集群分离过度，临界值过大会使得集群分离不充分。

比如，当层次聚类算法采用凝聚聚类的方式时，即每个节点代表一个集群，从叶子到根的方法（自下向上）创建集群。在计算两个聚类簇 s 和 t 之间的距离 $d(s, t)$ 时，采

用 average 的策略, 取 s 和 t 之间所有 pairs 的距离的平均值, 公式如下:

$$d(s, t) = \sum_{i,j} \frac{d(s[i], t[j])}{|s| * |t|} \quad (2.2)$$

其中 $|s|$ 、 $|t|$ 代表聚类簇 s 和 t 中节点的数量, 该式分子计算簇中各个节点之间距离, 再利用两簇中节点数量的乘积来作分母, 取平均后即得到聚类簇 s 和 t 之间的距离度量。该算法的另一个重点是聚类时阈值 λ_{th} 的设定, 作为集群合并的终止条件, 其要求集群内点与点之间的最大距离不可高于该 λ_{th} 值。算法聚类描述如下:

- a. 将图像视为点, 计算点与点之间的欧式距离, 从而产生 Matrix-distance 距离矩阵;
- b. 再根据 Matrix-distance 距离矩阵进行层次聚类, 初始将每个点视作一个集群, 自下向上不断计算集群之间的距离、并合最近的集群, 当集群内最大距离高于 λ_{th} 值时不再合并该集群, 即得到一棵聚类树 Tree-clustering, 直至生成一个完整的聚类森林 Forest-clustering;
- c. 最终根据聚类结果返回各个点 (行人图像) 的层次聚类标签 L_H 。

(3) **基于密度的聚类算法:** 区别于前两种, 该算法的核心是依据样本分布的紧密程度来确定聚类结构, 它可以根据数据的特征进行聚合以发现任意形状的簇, 而基于划分的聚类算法与层次聚类聚类只能发现球状的簇。其典型代表 DBSCAN 算法, 核心思想是对于集群中的每个点, 在给定半径的邻域范围内必须至少包含最小数量的点, 即邻域的密度必须超过某个阈值, 而最终形成的集群形状则由集群中度量点之间距离的函数来决定。

具体而言, DBSCAN 聚类算法的核心在于邻域大小 ϵ 与邻域内最少样本数 Min_{sample} 的设定。若某对象的邻域范围内存在样本的数量高于 Min_{sample} , 则该对象将成为核心对象, 算法聚类描述如下:

- a. 初始化核心对象样本集合 Ω 为空, 遍历数据样本找到所有核心对象并加入核心对象集合 Ω 中;
- b. 在核心对象集合 Ω 中随机选取某一核心对象 O_i , 结合其邻域范围 ϵ 内的所有对象构成一个聚类簇 C_k , 并从核心对象集合 Ω 中删除该核心对象 O_i ;
 - 若该聚类簇 C_k 中存在属于核心对象集合 Ω 的其他核心对象 O_j , 则将核心对象 O_j 的邻域范围 ϵ 中的点均加入将聚类簇 C_k , 并从核心对象集合 Ω 中删除该核心对象 O_j , 重复此操作;
 - 若该聚类簇 C_k 中不存在属于核心对象集合 Ω 的其他核心对象, 则在集合 Ω 的剩余核心对象中继续选择又一核心对象, 重复步骤 (2), 直至核心对象集合 Ω 为空;
- c. 输出所有聚类簇 $C = \{C_1, C_2, \dots, C_k\}$ 。

上述即为传统的聚类算法, 本节对各传统算法的关键点进行了总结, 如表2.1所示。

这些传统聚类算法在大规模数据集上的性能通常不高, 因为它们在相似性度量方面的效率较低, 而且在大规模数据集上通常会面临计算复杂度较高的问题, 比如层次聚类每个合并或者分割时都需要计算多个集群内所有数据点两两之间的距离。为此产

生了针对降维和特征变换的方法，将原始数据映射到新的特征空间。另外，随着深度学习的发展，还诞生了许多基于深度学习的聚类方法，例如深嵌入聚类 (deep embedding clustering, DEC) 等等。

表 2.1 传统聚类算法关键点总结

算法	典型代表	关键点
基于划分的聚类	k-means、k-medoid	预估 k 值
层次聚类	BIRCH	终止条件 (阈值)
基于密度的聚类	DBSCAN	邻域半径、邻域最少样本数

2.6 本章小结

本章描述的均为本文研究涉及到的知识点，其中展开介绍了行人重识别任务的具体流程，并重点讲述了注意力机制的原理和常见三种的注意力机制，生成对抗网络的运行机制，以及行人重识别中的数据增强的方法和机器学习领域中三种传统的聚类算法。

第三章 基于注意力机制的行人重识别方法

本章展开描述基于注意力机制的行人重识别方法，首先 3.1 节对于行人重识别任务中的注意力机制问题展开描述，之后 3.2 节、3.3 节中分别介绍注意力机制模块的设计与该行人重识别任务中模型的选取，3.4 节则对于本章提出的注意力机制模块的有效性进行实验评估。

3.1 问题描述

在计算机视觉领域，卷积神经网络得到广泛运用，尤其是在图像分类任务中。而卷积层的设计主要是用局部受限的感受野来进行特征映射，以及采用权重共享的方式来确保输入的平移不变性。通常，一组卷积核在局部区域融合空间、通道的信息，然后通过一系列带有非线性激活函数的下采样操作的卷积层，最终获得理论上的全局的图像表示^[4]。然而，由于卷积核固有的局部操作特性使得它无法真正地获得图像的全局语境，而对于更好地识别图像中的对象而言，全局语境是必不可少的。注意力机制作为一种可以帮助捕获图像全局信息中最突出部分的方法，可针对性地解决该问题。研究表明，通过将注意力机制整合到骨干网络中，有助于捕获空间相关性的特征，从而增强卷积网络所提取的表征能力^[7]。

实际上，注意力机制在行人重识别任务中也已受到广泛研究，注意力机制可以捕捉到不同的卷积通道、多个特征图、不同层次、不同的身体部位区域，甚至多个图像之间的关系^[24]。在行人重识别任务中，它有助于整合身体局部信息、增强特征对身体错位、不完整和遮挡等问题的鲁棒性。因此，通过引入了注意力机制可以强化特征，加强特征的表征力，以捕捉行人（或某些行人局部身体部位）最具有辨识度的外观特征。由此可见，基于注意力的 Re-ID 模型具备有效提高行人重识别效果的能力。

3.2 注意力机制模块的设计

目前现有的注意力机制模块，多为通道注意力、空间注意力以及二者的结合。通道注意力通过显式地对通道间的相关性建模，自适应地重新校准通道卷积响应，而忽略掉了空间区别性特征的提取^[7]。空间注意力机制^{[13][30]}采用类似人类视觉注意的形式，通过将注意力引导到空间中的某个位置，允许卷积神经网络有选择地处理视野内某个区域的视觉信息，而缺点在于无法处理细粒度的通道相关性特征。继而 CBAM^[8]中提出两种注意力相结合的机制，但提取的信息仍然较为粗略。随后混合高阶注意力网络 MHN^[15]被提出，通过使用高阶注意力机制（High-Order Attention, 简称 HOA）模块，来对注意

力机制中复杂的高阶统计信息进行建模，以捕捉行人之间的细微差异，从而产生有区分度的注意力信息，使得基于注意力机制的 Re-ID 模型的性能得到进一步改善。

同时在目标检测分割任务中，Non-local Neural Networks^[31] 通过引入 NL 操作，对远程依赖关系进行建模的方法取得了不错的效果，NL 操作作为一种有效、简单、通用的组件，可以捕获深度神经网络的远距离依赖关系，并且可作为深度神经网络的基本构件，为后续的拓展研究提供了可能性。

本文研究诞生的注意力机制模块，创造性地将 NL 操作与 Re-ID 中混合注意力机制的思想相结合，二者相互协调构造出一种全新的注意力机制。本节主要对这两种关键技术进行介绍。

3.2.1 非局部操作

非局部操作启发自非局部均值降噪方法^[32]，该方法是一种非局部平均滤波算法，与双线性滤波、中值滤波等利用图像局部信息进行滤波的方法不同，它是利用整幅图像进行去噪，以图像块为单位在图像中寻找相似区域，再对这些区域取平均，较流畅地滤除图像中的高斯噪声。NL 操作吸取该方法的核心思想，在计算某一位置上的响应时，将所有位置对该位置的特征加权和作为该位置的响应值。

捕捉长距离依赖关系是深度神经网络的核心问题，输入图像数据时，卷积网络通常利用堆积卷积层的方法，随着卷积层数不断加深，感受野逐渐变大，从而把原先不相邻的像素点纳入到一个整体进行考虑，使得接收信息分布的广度增大，但靠这种反复堆叠的方式会带来计算效率不断降低、建模以及优化困难等问题。因此 Wang 等人^[31] 提出 NL 操作，其可作为一种简洁高效的构造块（Building block），有效捕捉深度神经网络中的长距离依赖关系。在深度神经网络中，NL 操作的通用公式如下：

$$y_i = \frac{1}{C(x)} \sum_{\forall j} f(x_i, x_j) g(x_j) \quad (3.1)$$

其中 x 、 y 分别代表输入信号（可能为图片、视频等的特征）、输出信号； i 代表输入信号的位置索引， j 表示所有可能位置的索引； f 函数用来计算位置 i 的信号与其他位置 j 的信号之间的关系（比如相似度），函数 g 则是用来计算位置 j 的线性表示； C 函数用来为整体的加权和做平均标准化处理，最后由此得到输入位置 i 的响应值 y 。

NL 操作可以与卷积网络相结合，通过计算任意两个位置之间的交互，来直接捕捉它们的远程依赖关系。NL 组件还具有很高的灵活性，使得构建丰富的层次结构成为可能，便于很好地将局部信息与非局部信息相结合。受此启发，本文通过进一步将 NL 组件与混合注意力机制模块相融合，以此来构造全新的注意力机制，用于捕捉更加具有鉴别性与鲁棒性的行人特征。

3.2.2 混合注意力

Chen 等人在^[15]中将空间注意力和通道注意力定义为粗糙的一阶注意力，而相较而言，混合注意力可以对更丰富的高阶信息量进行统计，进而捕捉到行人之间更加细微的区分性特征。具体来说，混合注意力机制是通过高阶注意力模块（HOA）对注意力机制中的高阶统计信息进行建模来实现的。高阶注意力模块的理论公式如下：

$$a(x) = \sum_{r=1}^R \left\langle w^r, \bigotimes_r x \right\rangle \quad (3.2)$$

式3.2中， $x (x \in R^C)$ 代表特定空间位置中的描述子； $\langle \cdot, \cdot \rangle$ 为内积操作； $\bigotimes_r x$ 则表示 x 的第 r 阶外积，包含 x 的第 r 阶的所有单项式，展开即为 $[x, x^1, \dots, x^r]$ ； w^r 是相应需要学习的权重。当 $r > 1$ 时，该运算的核心是对权重矩阵 w^r 进行张量分解，可以有效防止 r 增大时引入过多的参数，造成过拟合现象。




图 3-1 $R=1$ 的高阶注意力模块（HOA）结构图




图 3-2 $R=2$ 的高阶注意力模块（HOA）结构图

下面利用高阶注意力模块（HOA）结构图，对高阶信息量的建模原理进行讲解。当 HOA 模块 R 设为 1 时仅包含第 1 阶模块，结构如图3-1所示，若其中 $1 \times 1 \text{conv}$ 操作直

接将 χ 降为 1 维，此时的模块即与通道注意力模块相当，也从侧面验证了 HOA 模块是对高阶注意力信息建模，而通道注意力信息仅为一阶注意力；当 HOA 模块 R 设为 2 时，包含第 1 阶模块和第 2 阶模块，其中第 2 阶模块结构如图 3-2 所示，该模块将 w_r 化为 D_r 维的秩为 1 的张量来近似，共包含两大分支，第一大分支与第 1 阶模块的分支结构相同，第二大分支结构则表示张量分解的过程，其中张量分解对应的原理公式如下：

$$w^r = \sum_{d=1}^{D^r} \alpha^{r,d} u_1^{r,d} \otimes \cdots \otimes u_r^{r,d} \quad (3.3)$$

式 3.3 中， u ($u \in R^C$) 代表向量， α 则表示秩为 1 的张量的权重，该操作亦可通过 $1 \times 1 \text{conv}$ 来实现，因此对于高阶注意力信息进行建模时，理论上是复杂的张量分解过程，但此过程的实现并不复杂，为本章注意力模块的设计提供了很好的指引。

3.2.3 注意力机制结构设计

本章注意力机制是基于 NL 操作与高阶注意力模块的思想，注意力机制模块的设计结构如图 3-3 所示，该注意力机制将 HOA 模块与 NL 操作进行了联合创新，注意力模块中虚线框标识出的设计模块分别为模块 f 、模块 g ，它们相对应的正是 NL 操作中的 f 函数与 g 函数的实现部分。设计模块中保留了 f 函数的部分用于获得不同位置之间的依赖关系；而 g 函数部分则嵌入了 HOA blocks，用来提取混合注意力信息以取缔原 NL 模块中简单的线性表示。




图 3-3 注意力机制模块设计结构图

由此可见，该注意力模块既继承了 NL 操作的获取远程依赖关系的优点，同时还利用了 HOA blocks 对高阶信息量进行建模，从而取二者之长达到更好地获取行人鉴别性特征的效果，并且该注意力机制还具备模型无关的特性，可以即插即用。

3.3 行人重识别模型的选取

Re-ID 技术早期的研究主要集中在纯手工方式提取身体特征^[2]与特征的距离度量学习^[3]两大方向上，此时 Re-ID 技术的发展较为受限。之后，随着深度学习技术在 Re-ID

领域的运用，将二者完美融合，产生了许多广泛使用的基线模型，并且在 Re-ID 任务的效果上也有了明显提升。2016 年，Zheng 等人^[5]提出的 ID-discriminative Embedding (IDE) 模型具有十分重要的意义，该模型首次将行人特征提取与度量学习过程联合在一起，其视每一个行人 ID 为不同的类别，使得 Re-ID 的训练任务变成了一个端到端的多分类任务。随后更多经典的基线模型被相继推出，例如 PCB^[6]、Reid-strong model^[33] 等等。

在检验注意力模块的实用效果时，需要嵌入行人重识别模型来进行实验。相较于基于分块或基于其他辅助信息的基线而言，Reid-strong model 是仅利用全局特征便可在 Market-1501 上达到 CMC/mAP 为 94.1%/85.7% 的强大基线模型，在该模型之上嵌入注意力模块，可以更加直接地体现全局特征辅以注意力模块提取的局部特征之后，所达到的模型性能提升的效果。因而，本章将选用当前行人重识别模型中性能优良、结构简单的模型 Reid-strong model，下面对该模型展开简要介绍。

3.3.1 行人重识别基线模型

本文采用简单而又高效的行人重识别模型——Reid-strong model 作为实验的基线模型，模型的 pipeline 结构如图3-4所示：




图 3-4 行人重识别 pipeline 结构

此基线模型，将 $P \times K$ （ P 个类别，每个类别选取 K 张图像）张行人图像作为输入，之后图像经过 Resnet50 骨干网络提取高维行人特征；而后提取出来的特征 tensor 在通过全局平均池化操作后，变成特征矩阵 f ，再经过 Batch Normalization (BN) 层便得到特征矩阵 g ；最后分别利用 f 、 g 特征计算目标函数——Triplet 损失和 ID 损失。

模块的目标函数采用 ID 损失与 Triplet 损失相结合的形式，在行人重识别任务中是一种较为常见的方式。而该模型结构的经典之处就在于额外添加的 BN 层，其将 ID 损失与 Triplet 损失的作用空间区分开来，尽可能地使这两种损失函数不互为干扰。该操作的主要原因在于：

(1) ID 损失作为一种分类损失函数，本质上就是一个交叉熵损失函数，需要一个全连接层来做预测。ID 损失的目的是构造超平面将不同的子空间分隔开，使得每个类别的特征分布于不同的子空间中，此时余弦距离比欧式距离更适合；

(2) Triplet 损失作为一种距离度量函数，目标是为了增强特征空间中类内部的紧密性和类别之间的区分性，这种情况下，使用欧氏距离更合适。

由此可知，两种目标函数的作用空间不同，优化目标也不一致。利用 BN 层可以使得两种损失函数不直接作用于同一特征向量，因而有效避免了一种损失函数减小的同时，另一损失函数发生震荡甚至增长的现象。

3.3.2 嵌入注意力机制的行人重识别模型

本节将介绍本章提出的注意力模块在行人重识别模型中的嵌入方式。将注意力机制模块应用于行人重识别模型的骨干网络中，嵌入该注意力模块后模型的结构如图3-5所示。




图 3-5 嵌入注意力机制的行人重识别模型

本章采用的嵌入方式类似于 NL 注意力机制的嵌入方式，将注意力机制模块分别放置于 ResNet50 骨干网络的 conv 2 层与 conv 3 层之间和 conv 3 层与 conv 4 层之间，并且这两个位置的注意力模块的设置又相互区别。它们的不同点就在于，模块所含的 HOA blocks 的阶数 R 的不同，关于阶数 R 的设置问题将在下一节的实验中另作探讨。

嵌入注意力机制的行人重识别模型，优化了模型对于局部特征的提取，实现全局特征与局部特征的完美结合，从而获得模型整体性能的提升，下一节将通过实验对该模型的性能加以验证。

3.4 实验评估

本文的实验均在 GeForce RTX 2080+256G 内存的服务器上进行实验，配备实验环境如下：

- (1) 通用并行计算架构: CDUA 10.0.130
- (2) 基于 CUDA 的深度学习 GPU 加速库: cuDNN 7.4.2
- (3) 开源的 Python 发行版本: Anaconda3
- (4) Pytorch 深度学习框架: torch==1.2.0+torchvision==0.4.0

3.4.1 数据集简介

本实验在行人重识别领域的两个公开数据集 Market-1501 和 DukeMTMC-ReID 上进行, 本节对于两大数据集的参数进行了总结, 如表3.1所示。

表 3.1 公开数据集介绍

dataset	Identities	Cameras	Images
Market-1501	1501	6	32668
DuckMTMC-reid	1812	8	36441

Market-1501: 该数据集来自于清华大学校园中的 6 台摄像头, 包含 32,668 个带有 1,501 个身份 ID 的带注释的边界框, 并确保每个 ID 标签出现在至少两个摄像机中。其中训练集有 751 个身份 ID 的行人, 共 12,936 张图像; 测试集有 750 个身份 ID 的行人, 共 19,732 张图像。

DukeMTMC-ReID: 该数据集由杜克大学的 8 个摄像头拍摄得到, 包含 36,411 个带有 1,404 个身份 ID 的图像样本, 每个 ID 标签同样至少出现在两个摄像机中, 其中训练集包含 16,522 张图像, 测试集包含 19,889 张图像, 它们拥有的行人身份 ID 数相同, 均为 702 个。

3.4.2 实验评估指标 (CMC/mAP)

行人重识别任务推理阶段的流程如下:

- (1) 给定一个称为 Gallery 的集合 G , 包含 n 张行人图像, 分属于 m 个行人类别。
- (2) 给定一张未知类别的行人图像, 称为 Query, 作为待查询的行人。
- (3) 计算 Query 与集合 G 中每张行人图像的相似度, 并根据相似度由高到低对 G 中图像进行排序, 作为查询结果。

实验中对 Re-ID 效果进行评估时, Query 图像的类别 ID 是已知的, 一般可以采用两大评价指标 Cumulative Matching Characteristic(CMC)、mean Average Precision(mAP) 对查询结果进行评估。

1. 累积匹配特性 CMC

累积匹配特性 (Cumulative Matching Characteristic), 简称 CMC。本节引入返回结果中 top_K 张图像的准确度 Acc_K 的概念进行讲解, K 通常取值为 1、5、10。 Acc_K 的计算

过程如公式3.4所示:

$$Acc_K = \begin{cases} 1 & \text{(前 } K \text{ 个结果中已出现正确 ID 的行人图像)} \\ 0 & \text{(前 } K \text{ 个结果中未出现正确 ID 的行人图像)} \end{cases} \quad (3.4)$$

CMC 曲线的计算方法就是将每次查询的 Acc_K 曲线相加,之后再除以查询的次数,即取查询得到的 Acc_K 曲线的平均值便可得到 CMC 评估指标。

2. 平均精度 mAP

平均精度 (mean Average Precision), 简称 mAP。需要引入准确率 (precision) 和召回率 (recall) 的概念对其进行说明, Precision 是指与 Query 图像同一 ID 标签的行人图像在当前查询结果中的占比; 而 Recall 则是指与 Query 图像同一 ID 标签的行人图像在查询结果中的数量与所有正确图像数量的比值。




图 3-6 mAP 计算示例图

对于连续型变量而言,一般绘制以 recall 为横轴, precision 为纵轴的 P-R 曲线图,然后计算曲线与坐标轴之间的面积的大小,以衡量模型性能的高低。而对于 Re-ID 任务而言,查询结果 $(recall_k, precision_k)$ 是离散型变量,因此面积需要用 $s = \sum_i precision_i \times \Delta recall, i \in k$, 来计算得到。如图3-6所示,为一次查询所得 AP 的计算过程: 输入查询图像之后,得到返回的前 10 张行人图像,其中顺次为 1、3、4、6、10 的返回图像与查询图像为同一行人,即为正确结果,如图分别计算出这 5 张正确返回图像的 Precision 值之后再取平均,便可得到此次检索精度 AP。经过 C 次查询,得到 C 次查询结果后, mAP 可通过公式3.5计算出来。

$$mAP = \frac{\sum_{k=0}^C AP_K}{C} \quad (3.5)$$

3.4.3 实验参数设置

本节实验采用 Pytorch 深度学习框架, 基于 Reid-strong model 的模型架构; ResNet50 骨干网络使用 ImageNet 预训练参数进行初始化, 模型以 $P=16$ 、 $K=4$ 的 batch-size 进行训练, 输入图像大小均调整为 256×128 ; 两个 conv 层之后的 HOA blocks 的阶数 R 分别设置为 $R_1 = 1$ 、 $R_2 = 2$; 初始学习率设置为 0.00035, 并在第 40、80 轮迭代时分别将学习率降低 10%, 共进行 120 轮迭代训练。

3.4.4 实验结果及分析

对比实验: 将注意力模块嵌入 Reid-strong model 时, 为了消除模型中可能存在的干扰项, 首先进行消融实验, 实验 1 在去掉 Reid-strong model 中的 Warm up、随机擦除、标签平滑等训练技巧和去除 BN 层的 baseline 模型上进行, 共设置了 5 组试验, 利用原始 ResNet50 卷积网络, 以及在其中分别嵌入 CBAM、SE、NL 模块, 与嵌入本章的注意力机制模块的模型进行对比; 实验 2 则在 Reid-strong model 上进行实验, 添加上述训练技巧, 然后将原始的 ResNet50 卷积网络, 分别与嵌入 NL、本章注意力机制模块进行对比, 共三组试验, 结果分别如表 3.2、表 3.3 所示。

表 3.2 行人重识别实验 1 评估结果

模型	Market-1501		DukeMTMC-ReID	
	R1	mAP	R1	mAP
Baseline(Resnet50)	86.7	73.1	77.6	62.0
Baseline+CBAM	87.0	73.0	80.1	65.1
Baseline+SE	88.2	74.5	79.2	64.8
Baseline+NL	88.5	74.7	80.7	66.2
Baseline+NL&HOA	89.2	74.8	81.0	66.4

表 3.3 行人重识别实验 2 评估结果

模型	Market-1501		DukeMTMC-ReID	
	R1	mAP	R1	mAP
Model(Resnet50)	94.1	85.7	87.3	76.3
Model+NL	94.5	87.0	88.2	77.4
Model+NL&HOA	95.0	87.2	88.7	77.8

由实验结果可知, 无论是采用 Reid-strong model 的 baseline 模型 (实验 1), 还是添加训练技巧的 Reid-strong model (实验 2) 作为基础行人重识别模型, 嵌入 NL&HOA 注意力

机制模块的效果,均高于其他注意力机制模块,验证了该注意力机制模块的实用性。基于 Reid-strong model 的 baseline 模型的实验中,在 Market-1501、DukeMTMCReID 数据集上分别获得了 Rank1/mAP 评估值为 2.5%/1.7%、3.4%/4.4% 的提升;基于 Reid-strong model 的实验中,获得了 0.9%/1.5%、1.4%/1.5% 的提升。

补充阶数 R 的设置实验: 关于分别置于两个 conv 层之后的 NL&HOA 注意力机制模块中 HOA blocks 的阶数 R 的设置问题,本节做了进一步的实验探究,如表3.4所示,对 Market-1501 数据集上取得的实验结果分析可知,总体上,相较于 $R_1 = 1$ 、 $R_2 = 1$ 的设置, $R_1 = 1$ 、 $R_2 = 2$ 时达到的效果更佳,推测原因可能是建模远程依赖关系时,随着卷积层的深入,卷积感受野逐步增大、特征语境不断丰富,阶数 R_2 相较于 R_1 设置得更大可以捕捉到更多的鉴别性特征。而此后进一步增大阶数,由于引入参数太多,导致实验效果并没有提升反而略微下降,因而 NL&HOA 注意力机制模块中 HOA blocks 的阶数设置为 $R_1 = 1$ 、 $R_2 = 2$ 更为恰当。在 DukeMTMC-ReID 上进行的试验与 Market-1501 上结果相吻合,不多做赘述。

表 3.4 阶数 R 设置问题实验结果

Market-1501				
模型	Reid-strong baseline		Reid-strong model	
	R1	mAP	R1	mAP
NL&HOA (1+1)	88.7	75.9	94.5	87.2
NL&HOA (1+2)	89.2	74.8	95.0	87.2
NL&HOA (2+1)	88.4	75.2	94.6	87.1
NL&HOA (2+3)	87.5	74.5	94.3	87.0

表 3.5 基于注意力机制的行人重识别最新研究方法对比

模型	Market-1501		DukeMTMC-ReID	
	R1	mAP	R1	mAP
Manacs ^[34]	93.1	82.3	84.9	71.8
HA-CNN ^[13]	91.2	75.7	80.5	63.8
MHN-PCB ^[15]	95.1	85.0	89.1	77.2
ABD-Net ^[14]	95.6	88.3	89.0	78.6
SCAL ^[35]	95.8	89.3	89.0	79.6
Model+NL&HOA	95.0	87.2	88.7	77.8

近年研究成果对比: 将实验结果与近年基于注意力机制的最新研究方法进行对比,

结果如表3.5所示，本实验之外的最佳效果已用红色进行标识。这些工作均非采用嵌入注意力机制模块的形式，模型结构相对与本实验模型而言比较复杂。单独对比每一列数据，本模型性能并不是最佳的，但综合对比两大数据集的各项评估指标，仍处于上游的水平。并且本模型胜在复杂度低，注意力模块 NL&HOA 可即插即用。

3.5 本章小结

本章着重对于行人重识别任务中的注意力机制展开研究，结合众多已有的注意力机制模块进行分析与实验验证。通过不断总结前人的经验，最终构造出全新的注意力机制模块，该注意力机制模块融合了经典的 Non-local 操作与具有鲁棒性的混合注意力模块，并且继承了二者对于远程依赖关系建模与捕获行人之间细微差异的优点，同时还具备模型无关的特性。应用于行人重识别的两大公开数据集 Market-1501 和 DukeMTMC-ReID 上时，在现有的可即插即用的注意力机制模块中取得了最佳的实验效果。

第四章 基于数据增强的行人重识别方法

本章提出一套完整的生成式数据增强方案，其中 4.1 节给出行人重识别领域数据增强问题的描述；4.2 节探讨可使用的聚类算法；后续 4.3 节描述数据增强方案的总体设计；最后在 4.4 节通过实验探索出最适用于行人高维特征的聚类算法，并结合该聚类算法实践生成式数据增强方案的整体流程，以证明该方案的实用性。

4.1 问题描述

现实场景中的深度学习对于数据量的需求总是得不到满足，行人重识别数据集样本的收集更是比普通的项目需要花费更大的成本。为了有效地克服标注新训练样本所需成本高昂的问题，学术界提出了许多的解决方案，大体可以分为以下两种：

(1) 使用 GANs 方法来生成新的样本数据；

(2) 使用 Domain adaptation 的方法来转换已有的数据集，使得数据集之间可以共享；

这两种方法都达到了扩增训练数据集的初衷，第一种方案从源头上解决问题，通过“生产”样本数据来直接增添数据^[22]。第二种方案使用数据迁移（migration）的方法缩小“Domain Gap”^[19]来达到扩增训练数据的目的。由于现实场景空间的不同，同等实验设置条件下，在不同数据集上分别进行训练和测试时，行人重识别的性能会出现与在单个数据集上做训练测试时相比，大幅度下降的问题，这会直接导致可用的训练数据无法用于新的应用环境中。因此，第二种方案使用迁移学习变换已有数据集的“风格”，来有效地弥补“Domain Gap”。

GANs 应用于 Re-ID 任务，在具体实现上也有两种方式：

(1) GANs 联合 Re-ID 任务进行训练^[21]：GANs 产生图片供 Re-ID 训练学习行人特征，Re-ID 提取出来的特征又会再传给 GANs 生成模型，提高其生成图片的质量。

(2) 将 GANs 生成图像作为一个辅助任务^[22]：运用 GANs 生成图像样本，为生成样本分配标签后将其用于 Re-ID 模型的训练，作为数据增强的一种手段，帮助提升模型的性能。

本章将利用生成式数据增强的方法达到提升模型判别能力的目的，即采用第二种方式。运用 GANs 生成的高质量样本作数据增强，并研究相应的标签赋予方式来分配标签。相比于第一种方式，该方法无需复杂的联合框架，只需要在行人重识别任务前期作数据处理，而不增加额外的训练负担，因此该方法对于行人重识别模型的训练而言更为灵活、轻便。

本章设计了一套生成式数据增强方案，其中采用目前行人重识别领域生成图像质量最佳的 DG-Net^[21] 模型。该项工作的重心不在于研究样本生成的方法，而是需要研究如

何为这些生成样本分配适当的身份 ID 标签以投入训练。为此，本章将首先探索行人重识别领域适用的聚类算法，然后结合该聚类算法完成生成样本的标签分配方案的设计。

4.2 聚类算法的对比分析

本节研究行人重识别领域最适用的聚类算法，第一章的研究概况和第二章的相关知识中已经对行人重识别中涉及的聚类研究以及传统聚类算法进行了介绍。而传统聚类算法在行人高维特征数据上的性能有待于进一步探究，为此，本节进一步结合同样处理高维数据的人脸识别领域的 CDP^[36] 方法中的聚类算法与传统聚类算法进行对比研究分析，以探索目前最适用于对行人重识别中的高维行人特征进行聚类的算法，供后续为生成样本分配适当的 ID 标签。基于划分的聚类算法由于需要对于聚类类别数——K 值进行的预设，而用于生成样本高维特征的聚类个数并不可先行预知，因此基于划分聚类算法未列入此次分析任务中。

4.2.1 聚类算法原理

本小节主要对于 CDP^[36] 方法中的聚类算法原理展开描述。下面将首先介绍人脸领域中 CDP 算法，再在后续章节中与层次聚类以及基于密度的 DBSCAN 聚类算法一同进行实验对比分析。

对于处理高维数据，CDP 人脸算法¹中的聚类算法提供了有效的思路。CDP 算法是为了解决人脸数据集达到百万级之后再难扩展的问题而提出的，人脸识别经历长期的发展，除了模型的容量不断增大之外更多的依赖于带标签的数据集的飞速增长，但当数据达到一定量级之后就陷入了难以继续扩增的困境，模型每提高一个百分比的准确度，都需要耗费几十万的人工标注成本。此时学者对于数据的标签的可信度方面提出了质疑，提出了这些人工标注的数据中存在多大程度的噪声数据以及是否数据一定要标注后才具有训练价值等问题。

CDP 算法：鉴于以上思考，Zhang 等人^[36]提出一种类似于半监督学习的 Consensus-Driven Propagation (CDP) 方法，目的是能够最大程度地利用这些无标签的人脸数据，得到与利用有标注数据的全监督学习相匹敌的效果。鉴于人脸数据属于开集，未标注的人脸数据与已标注的人脸数据身份上无重叠，因此没有直接的语义信息，不能使用标签预测的方法，只能对通过学习未标注数据内部结构以反映高维面部特征的代表分布的聚类算法加以利用。聚类算法凭借样本的特征描述与样本之间的度量方法即可进行操作，进而为未标注的数据样本生成样本标签。

CDP 中的聚类原理：CDP 中的聚类算法是基于 Affinity graph（其节点为数据样本，边则代表数据样本之间的相似度）。CDP 方法主要包含两个部分，一个是 Committee 模块，另一个则是 Mediator 模块，前者首先利用标注数据进行预训练，再作用于无标记样

¹CDP: <https://github.com/XiaohangZhan/cdp/>

本上产生相似度较高的样本对信息，然后由后者来判断是否同意成功构成样本对，最终形成所有样本对连接组成的新的 graph，即 Consensus-Driven Graph。然后通过在此 graph 上进行连通域搜索与动态剪枝便可得到聚类。

本章从 CDP 算法中探索其聚类方法，即剥离两大模块后，取其聚类算法核心原理，算法具体描述如下：

- (1) 将图像视为顶点，利用 KNN 算法获取每个顶点的 k 个最近邻；
- (2) 将顶点与 k 个最近邻相关联组成边，并将两顶点之间的相似度设置为边的权值，移除低于某一阈值 th 的连接边；
- (3) 连接顶点相连的边构成连通分量 components，并对剩余的边进行迭代，不断扩展连通分量，且每个连通分量的顶点数控制在 max_size 之内；
- (4) 为每个连通分量分配类别标签。

综上所述，本节将采用 CDP 算法中 affinity graph 的方式利用邻居节点的概念构建数据结构，再选择欧式距离作为相似度度量的方法，最后通过简单的连通域搜索快速进行聚类，后文中将该聚类算法统一称为“CDP 聚类算法”。

4.2.2 聚类算法评估指标

对于传统的层次聚类、DBSCAN 聚类算法，以及其他不同特定的视觉领域的聚类算法（比如，人脸识别领域）进行调研评估，由于无法获得生成数据样本的真实标签信息，因此评估的参数选定为轮廓系数 Silhouette Coefficient 和 Calinski-Harabaz Index 系数，下面对于两种评估系数进行简单介绍：

(1) **轮廓系数 Silhouette Coefficient**：由 Peter J. Rousseeuw 在 1986 提出，结合内聚度和分离度两种因素，取值在 -1 到 1 之间，越靠近于 1，聚类效果越好。该评估系数公式原理如下：

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (4.1)$$

其中 $a(i)$ 表示样本 i 与其所在聚类簇中其他样本的平均距离， $b(i)$ 则表示样本 i 与其他聚类簇中样本的平均距离； $\max\{\cdot, \cdot\}$ 运算取两者中的较大值。所得轮廓系数越大，簇内样本之间越紧凑，簇间分离度越大。

(2) **Calinski-Harabaz Index 系数**：该评估指标由分离度与紧密度的比值得到，其中通过计算类中各点与类中心的距离平方和来度量类内的紧密度；通过计算各类中心点与数据集中心点距离平方和来度量数据集的分离度，其公式原理如下：

$$S(k) = \frac{tr(A_k)}{tr(B_k)} \times \frac{m - k}{k - 1} \quad (4.2)$$

其中 m 表示训练样本的数量， k 表示样本中聚类簇的数量， A_k 为簇间的协方差矩阵， B_k 为簇内样本之间的协方差矩阵， $tr(\cdot)$ 取矩阵的迹即可求得距离平方和。CH 值越大代表着类自身越紧密以及类与类之间越分散。

4.3 生成式数据增强方案总体设计

行人重识别任务的生成式数据增强方法中选取当前最佳的生成模型来生成样本，并采用结合聚类算法的标签分配策略赋予样本标签，再将样本投入训练模型训练。训练流程如图4-1所示，具体描述如下：

(1) 利用生成模型生成样本图像；

(2) 将生成样本融入原始数据集，利用在公开数据集上预训练的模型提取新数据集的行人特征，再结合聚类算法为生成样本赋予适当的标签；

(3) 将步骤(2)中得到的标注完成的数据集投入行人重识别模型的训练。

该方案设计中生成数据的标签分配在行人重识别模型训练之前已全部完成，因而作为一种数据增强的方式，为行人重识别数据集进行有效扩展，使得模型可以提取到更多有意义的特征。本节后续将对步骤(1)中的样本生成模型，以及步骤(2)中的标签分配方法的设计展开描述。




图 4-1 Re-ID 模型与 GANs 结合流程图

4.3.1 生成模型

本章采用目前行人重识别领域中生成样本质量最佳的 DG-Net 模型来生成样本数据。DG-Net^[21] 模型是第一个将生成式模型与行人重识别阶段联合为一个整体的模型，其中包含一个生成模块和一个判别模块，两者相互作用。

DG-Net 模型如图4-2所示，具体原理如下：

(1) 生成模块 G 包含一个外观编码器 E_a 和一个结构编码器 E_s ，通过将二者对图像编码生成的外观码和结构码与其他图像的外观码和结构码相交替，便可生成较高质量的合成图像 x_j^i 。

(2) 判别模块 D 与生成模块 G 共享外观编码器，因此就可通过将生成模块 G 的合成图像 x_j^i 在线反馈给外观编码器 E_a ，以改进判别模块 D ，而后编码器的编码质量继而得到改善。




图 4-2 DG-Net 模型原理图

由此可见，DG-Net 的原理就是通过生成式模块与判别式模块的不断交互，使得行人重识别任务性能提升的同时，生成图像的质量也得到有效提高。

4.3.2 生成样本的标签分配方法

本章结合行人重识别领域适用的聚类算法，来设计生成样本的标签分配方法。鉴于 DG-Net 模型生成样本的策略在于将不同行人图像的外观编码与结构编码进行交错融合，得到较高质量的生成图像，为未来高质量图像生成提供了很好的训练思路。针对此类生成模型的风格特点，生成行人图像的特征类别将一定程度上会倾向于提供原始外观编码或者原始结构编码的行人类别。因而，采用 DG-Net 模型训练得到生成样本集（提取行人图像 a 的结构信息与行人图像 b 的外观信息，融合后生成样本数据）后，其生成样本标签的具体分配策略为：

（1）利用由公开数据集预训练的行人重识别模型，提取行人训练集和生成样本集中行人图像的高维 (2048 维) 特征向量；

（2）采用聚类算法，对行人高维特征进行聚类操作：

- 如果聚类的类别与为其提供原始编码的行人 a 或者行人 b 为同一类别，则直接为生成样本赋予相应类别的真实标签；
- 如果聚类的类别与为其提供原始编码的行人 a 和行人 b 均不相同，则作为噪声数据进行标签分配。

由此可见，结合聚类算法的标签分配方法将生成样本置于真实样本的分布中，度量出与其距离最近的真实标签类别，再为其分配 ID 标签。

4.4 实验评估

本节将通过实验找出行人重识别任务适用的聚类算法，应用于下游的生成式数据增强中的标签分配任务，并通过此次实验结果证明该生成式数据增强策略可以实现行人重

识别任务性能的有效提升。实验部分包含两个任务，其中任务一完成聚类算法的对比实验，任务二则完成基于生成式数据增强的行人重识别实验。

4.4.1 任务 1：聚类算法对比实验

此项任务的目的在于探索行人重识别任务适用的聚类算法，实验流程设计如图4-3所示，具体步骤如下：

(1) 采用京东 AI 研究院 2020 年提出的 Fast-reid^[37] 模型 M_f 作为预训练模型，利用所有公开数据集对模型 M_f 进行预训练，得到具备有效行人特征提取能力的 M_f 模型；

(2) DG-Net 模型对数据集 D 进行训练，推理产生该数据集 D 相应的生成样本数据集 D' ，此步骤可以与步骤 (1) 同时进行；

(3) 利用预训练的 M_f 模型，提取数据集 D 与其生成样本集 D' 的高维行人特征 (2018 维)，得到行人特征集 $F_{DD'}$ ；

(4) 利用 CDP 聚类算法、层次聚类算法以及 DBSCAN 聚类算法分别对行人特征集 $F_{DD'}$ 进行聚类，产生的聚类标签集分别为 L_H 、 L_{DB} 、 L_{CDP} ；




图 4-3 聚类算法对比实验流程图

接下来采用轮廓系数 Silhouette Coefficient 和 Calinski-Harabaz Index 系数两种评估指标对聚类算法的聚类效果进行评估，并使用 TSNE^[38] 算法对高维行人特征降维后将聚类结果可视化，以供聚类算法的进一步可视化分析。

表 4.1 聚类算法评估系数表

算法	Silhouette Coefficient		Calinski-Harabaz Index	
	Market-1501	Duke	Market-1501	Duke
CDP 聚类	0.1858	0.0682	7.3719	5.1069
层次聚类	0.1207	-0.0601	4.5750	2.6026
DBSCAN 聚类	0.0959	-0.0691	4.2634	2.2664

1. 聚类算法评估系数对比分析

将行人特征集 $F_{DD'}$ 与聚类标签集数据输入评估算法中，得到两种评估系数在两大公开数据集 Market-1501、DukeMTMC-ReID 上对比结果如表4.1所示。

根据实验结果进行分析可知，在两大公开数据集上，Silhouette Coefficient 值最靠近于 1 以及 Calinski-Harabaz Index 值最大的聚类算法均为 CDP 聚类算法，因此由两大评估系数得出以上三种算法中最适用于行人重识别任务的聚类算法为 CDP 聚类算法。

2. 聚类算法可视化分析

本实验首先利用 Python 第三方 sklearn 库中封装的 TSNE^[38] 算法——最优的数据降维方法，对高维的行人特征集 $F_{DD'}$ 进行降维操作，将其降为二维数据后再将三种聚类结果可视化，结果如图4-4所示，第一行从左到右依次为 Market-1501 数据集上的 CDP 聚类、层次聚类、DBSCAN 聚类的可视化结果，第二行为 DukeMTMC-ReID 数据集上同样次序的可视化结果。




图 4-4 聚类算法对比实验可视化

图中同类相离散、不同类相聚的区域均使用渐变框标识了出来，虽然高维特征降维后的可视化效果会有一定程度的失真，但从图4-4中依然可以看出，第一列 CDP 聚类算法的所得聚类的类内的内聚性和类间的分离度均高于其他两列的聚类效果，该结论与评估系数对比分析时所得的结论相一致。

由以上两种聚类算法的对比实验可知，相较于 DBSCAN 聚类算法和层次聚类算法，CDP 聚类算法更胜一筹。因此，可得如下结论，CDP 聚类即为本章实验得出的三种聚类算法中最适用于行人重识别中高维行人特征的聚类算法，并且后续标签分配策略中将选用 CDP 聚类算法（其中超参数 k 设定为 30， th 设定为 0.6）进行标签分配。

4.4.2 任务 2：基于生成式数据增强的行人重识别实验

本实验结合 CDP 聚类算法，按照 4.3 节提出的标签分配方法完成生成样本的标签分配任务，从而扩展源数据集以达到数据增强的目的，实验流程如图4-5所示，具体步骤如下：

(1) 采用京东 AI 研究院 2020 年提出的 Fast-reid^[37] 模型 M_f 作为预训练模型，利用所有公开数据集对 M_f 模型进行预训练，得到具备有效行人特征提取能力的 M_f 模型；

(2) DG-Net 模型对数据集 D 进行训练，推理产生该数据集 D 相应的生成样本数据集 D' ，此步骤可以与步骤 (1) 同时进行；

(3) 利用预训练的 M_f 模型，提取数据集 D 与其生成样本集 D' 的高维行人特征 (2018 维)，得到行人特征集 $F_{DD'}$ ；

(4) 按照本章提出的标签分配方法，利用 CDP 聚类算法对行人特征集 $F_{DD'}$ 进行聚类，产生的聚类标签集 L_{CDP} ，具体的标签分配分为以下三种情况：

- 当生成样本的聚类标签与提供结构编码的样本 a 的聚类标签相同时，为其赋予提供结构编码的样本的真实 ID 标签 L_{CDP}^a ；

- 当生成样本的聚类标签与提供外观编码的样本 b 的聚类标签相同时，为其赋予提供外观编码的样本的真实 ID 标签 L_{CDP}^b ；

- 否则，为其赋予噪声标签 L_{CDP}^s (行人重识别数据集中静态噪声标签为-1)；

(5) 按照标签将生成样本集融入源数据集，进行行人重识别任务的训练与测试。




图 4-5 基于生成式数据增强的行人重识别实验流程图

本实验前三个步骤与任务一相同，实验同样在 Market-1501 和 DukeMTMC-ReID 两大公开数据集上进行，行人重识别模型分别采用 Reid-strong model 的 baseline 模型以及 Reid-strong model 的两轮实验，参数设置与实验环境均与第三章实验配置相同。将采用生成式数据增强 ($Data_{aug}$) 方式实验结果与未采用生成式数据增强的原始行人重识别任务进行对比，共设置两组对比实验。基于 Reid-strong model 的 baseline 模型和基于 Reid-strong model 的对比实验的评估结果如表4.2所示。

对于实验结果进行分析，在两大数据集上，使用 Reid-strong model 的 baseline 模型时，基于该生成式数据增强方案的行人重识别任务，给原始任务带来了一定幅度的提升，具体在 Market-1501、DukeMTMC-ReID 数据集上分别获得了 Rank-1/mAP 评估值为

1.1%/0.8%、0.9%/0.8% 的提升。而在 Reid-strong model 上进行训练时，训练效果不升反降，造成该结果的原因在于生成样本的质量有待于提升，在模型特征提取能力很强时，模型很容易学习到低质量生成样本中的干扰元素，导致模型对于训练数据产生一定程度的过拟合。

表 4.2 基于数据增强的行人重识别对比实验评估结果

模型	Market-1501		DukeMTMC-ReID	
	R1	mAP	R1	mAP
Baseline(Resnet50)	86.7	73.1	77.6	62.0
Baseline(Resnet50)+ $Data_{aug}$	87.6	73.5	78.4	62.5
Model(Resnet50)	94.1	85.7	87.3	76.3
Model(Resnet50)+ $Data_{aug}$	91.8	80.7	83.7	72.0

近年研究成果对比：生成式数据增强方法的研究自 2017 年后并无更新进展，本章提出的方案作为最新的生成式数据增强方法研究方法，与之前学者的研究进行对比，结果如表4.3所示，本实验的效果在前人的成果上有了较大的提升。事实上，技术的进步也占了一定的比例，基线模型的性能对比从前已经有了较大程度的提升，因而本文提出的是一种结合基于聚类分配样本标签的新方案，着重于方法上的创新，为行人重识别任务带来了性能上的有效提升，表中体现了历年提出的方法在性能上的更新迭代。

表 4.3 基于数据增强的行人重识别最新研究方法对比

模型	Market-1501		DukeMTMC-ReID	
	R1	mAP	R1	mAP
BoW+kissme ^[39]	44.4	20.8	25.1	12.2
LOMO+XQDA ^[40]	-	-	30.8	17.0
Basel. + LSRO ^[22]	83.9	66.1	67.7	47.1
Baseline(Resnet50)+ $Data_{aug}$	87.8	73.9	78.5	62.8

4.5 本章小结

本章提出的生成式数据增强的方案在 4.3 节中给出了总体描述，完整方案实践流程即为任务二中的实验流程，如图4-5所示。本章得出的行人重识别领域适用的聚类算法为 CDP 聚类算法，该算法在实际数据集收集过程中也将发挥重要作用；同时，为无标签生成样本提出的基于 CDP 聚类的标签生成方案，可以为今后类似于 DG-Net 的融合

式对抗生成模型提供了新的标注方法。由本章实验结果证明,该生成式数据增强方案可以有效增强特征表示学习,从而使得行人重识别模型能更好的适应样本的变化,以达到提高模型的泛化能力的目的。但是其一定程度上受到生成样本质量的限制,当生成模型效果更好时,理论上该生成式数据增强方案可以实现更佳的效果。

第五章 融合注意力机制与数据增强的行人重识别方法

本章将综合本文提出的注意力机制模块与数据增强方案,利用真实场景下收集的数据集来检验二者的实用效果。首先在 5.1 节中描述行人重识别数据集的采集过程及涉及的技术要点;随后 5.2 节在该真实场景收集到的数据集上展开行人重识别实验;最后,5.3 节根据实验结果进行总结。

5.1 数据集采集

本章中收集了一个总共包含 1,275 个行人 ID 的数据集,并命名为 FINI,共包含 81,243 张行人图像。该数据集上从某楼道、大厅、走廊等位置的 8 个摄像头中采集得到的真实场景中的行人样本,并为其赋予了 ID 标签。FINI 数据集采集流程如图 5-1 所示:




图 5-1 数据集采集流程图

具体步骤如下:

(1) 分别在上午、中午、下午三个时段进行原始监控视频的截断,获取到原始视频数据;

(2) 通过行人检测算法和行人跟踪算法,捕获视频中行人的序列图像集;

(3) 采用京东 AI 研究院 2020 年提出的 Fast-reid^[37] 模型 M_f 作为预训练模型,利用所有公开数据集共计 18 万张图像对 M_f 模型进行预训练,得到具备有效行人特征提取能力的 M_f 模型。

(4) 按照预先设立的每个 ID 所含样本数的最高阈值 α_{sample} 来控制删除比例,以去除大量高度相似的重复行人样本;

(5) 最后利用预训练的 M_f 模型提取对去重后得到的数据集进行高维特征的提取, 并使用 CDP 聚类算法对该高维行人特征集进行聚类以生成 ID 类别标签。

该数据集中随机选择 638 个行人 ID 用作训练, 共 39,721 张图像; 637 个行人 ID 用作测试, 共 41,271 张图像。可供检验模型在现实场景下的可行性。数据集中的图像样本采用‘行人 ID_摄像头_跟踪 ID_随机数’的命名格式, 与 Market-1501 的命名格式相类似。下面对流程中各个步骤的技术要点进行解析。

5.1.1 行人检测与跟踪

行人检测与跟踪是从原始视频数据中截取行人序列图像集的关键步骤, 本章采用新兴的 Centernet^[41] 算法及 Deep-sort^[42] 算法, 下面对两种算法进行简要介绍。

行人检测: 采用 Centernet 算法进行行人检测, Centernet 算法区别于普通基于边界框 bounding box 的检测算法, 其将所有对象框架建模为一个点, 是一种基于中心点的方法, 并且端到端可微, 运行起来较为简单、高效。

目标跟踪: 利用 Deep-sort 算法进行目标跟踪, 该算法是基于 SORT 算法进行了改进, 作为一种可实时运行的在线跟踪算法, 其通过预训练的关联度量合并了外观信息, 相较于 SORT 算法而言能够完成长时间的有效跟踪。

5.1.2 样本去重

从视频中获取的行人序列图像集中高度相似的行人序列图像数量很大, 需要制定去重策略才能得到真正具有价值的行人图像集合。并且去重操作需要安排在聚类操作之前进行, 原因是行人跟踪检测得到序列样本集中的同一 ID 的图像是包含高相似度重复样本的最小子集, 聚类之后会将属于同一行人的不同序列样本聚集为一类。而不同样本序列通常来自不同摄像头, 因此彼此之间不具备高相似度的重复样本, 此时再进行去重会增添许多不必要的因素。



图 5-2 序列图像集示例图

序列图像集如图5-2所示, 每张行人图像之间的区别很小, 存在大量冗余。本节采用间隔去重的方法, 具体步骤如算法5.1所示。间隔初值 k 设置为 3, 一轮去重结束样本序列数量仍然高于样本数阈值 α_{sample} (设置为 70) 的 1.5 倍, 间隔 k 保持不变; 否则将间隔 k 缩小为 2, 直至低于样本数阈值 α_{sample} 时结束去重操作, 得到部分样本如图5-3所示

的行人图像集，该序列在背景和行人的差异上均高于去重前的序列，具备更好的训练价值。




图 5-3 去重后的行人图像集示例图

算法 5.1 去重算法

Input: *File_Path*: path of files

```

1:  $\alpha_{sample} \leftarrow 70$ 
2: while True do
3:   files  $\leftarrow []$ 
4:   for  $f \in GetFiles(File\_Path)$  do
5:     add  $f$  to files
6:   end for
7:    $num \leftarrow size \leftarrow len(files)$ 
8:   if  $num > \alpha_{sample} * 1.5$  then
9:      $k \leftarrow 3$ 
10:  else if  $num > \alpha_{sample}$  then
11:     $k \leftarrow 2$ 
12:  else
13:    exit
14:  end if
15:   $i \leftarrow 0$ 
16:  while  $i < size$  do
17:    RemoveFiles(files[ $i$ ])
18:     $i \leftarrow i + k$ 
19:     $num \leftarrow num - 1$ 
20:    if  $num \leq \alpha_{sample}$  then
21:      exit
22:    end if
23:  end while
24: end while
25: return

```


5.1.3 聚类分配样本标签

从原始视频中进行行人跟踪检测得到原始数据集，但由于采集过程中每天会收集到不同单摄像头的行人 ID 样本集合，且每个行人 ID 样本集仅包含当天该行人被拍摄到的图像，因此之后需要对这些单摄像头数据样本集进行聚类，来获得跨摄像头的行人数据集。

在收集图像进行聚类的这一步骤中，由于每次跟踪捕获行人的一系列图像过程中，行人的 ID 是随机生成的，因此不同的摄像头即使捕获到同一行人也会分别被赋予不同的 ID 标签；此外行人跟踪收集的数据偶尔还会发生 ID 交换，即多个行人路线交叉后，可能会发生 ID 互换的现象，使得一个行人 ID 的集合中可能出现不同行人的图像样本。数据收集时行人 ID 交换的现象时有发生但占总量的少数，因此该种样本集合可直接去除，以免干扰正常行人特征的提取。综上，对原始数据集做聚类处理的目标是：

- (1) 将同一行人的跨摄像头数据样本进行聚类，并赋予统一的 ID 标签；
- (2) 将包含不同行人的数据集合聚类后统一去除。

本节中对于 Re-ID 聚类方法的研究，是基于训练好的 Re-ID 模型提取特定维度的行人特征。而由于实际应用中要使得不同日期捕获的跨摄像头行人数据聚集到一起，需要克服不同背景、光照、角度等多重因素的影响；并且聚类效果的好坏在一定程度上取决于基线模型提取的行人特征的质量的高低。因此，在聚类之前必须首先利用预训练完备的 Re-ID 模型在同等情况下对于数据集的全部样本进行高维行人特征的提取工作，本文采用京东 AI 研究院 2020 年提出并开源的 Fast-reid^[37] 模型作为预训练模型。随后再运用第四章中得到的适用于行人高维特征的 CDP 聚类算法进行聚类，并标注聚类标签，从而最终得到完整带标签的行人重识别数据集 FINI。

5.2 实验评估

本节的实验在 GeForce RTX 2080+256G 内存的服务器上进行，配备环境如下：

- (1) 通用并行计算架构：CDUA 10.0.130
- (2) 基于 CUDA 的深度学习 GPU 加速库：cuDNN 7.4.2
- (3) 开源的 Python 发行版本：Anaconda3
- (4) Pytorch 深度学习框架：torch==1.2.0+orchvision==0.4.0
- (5) 高维计算工具：nmslib==2.0.6

下面采用本章收集的包含 1,275 个行人 ID 的数据集 FINI，进行基于注意力机制与数据增强方法的联合实验。在行人重识别模型训练之前运用本文提出的生成式数据增强方案扩展数据集，并使用全新的融合了非局部操作与混合注意力的注意力机制模块嵌入基线模型，以此开展实验。

5.2.1 实验流程

本实验仍然采用 CMC、mAP 作为评估指标。实验流程如图5-4所示，具体步骤如下：

- (1) DG-Net 模型对本数据集 D_{FINI} 进行训练，推理产生该数据集相应的生成样本数据集 D'_{FINI} ；
- (2) 采用本文提出的生成式数据增强方式 $Data_{aug}$ 作数据处理，产生融合了数据集 D_{FINI} 与生成样本数据集 D'_{FINI} 的新数据集 D''_{FINI} ；
- (3) 运用数据集 D''_{FINI} ，在嵌入本文提出的注意力机制模块 NL&HOA 的行人重识别模型上展开训练。




图 5-4 FINI 数据集上的总体实验流程图

5.2.2 超参数分析

该实验采用第五章提出的生成式数据增强方案，利用 CDP 聚类算法为生成样本集分配真实 ID 标签，从而融入 FINI 数据集。算法涉及的超参数包含 k 值、 th 值以及 max_size 值， max_size 控制聚类簇所含顶点数量的上限，视具体数据集而定，此处默认设置为 600。本小节就两个关键性参数—— k 值、 th 值的选取，进行分析试验。CDP 聚类算法将图像视为顶点， k 值的选取关乎利用第一步 KNN 算法获取到的最近邻顶点的个数；而 th 参数设定最近邻中可连接成边的最低相似度阈值，在两顶点之间的相似度不低于该阈值的情况下才可最终连接成边。

表 5.1 CDP 聚类多组参数的评估峰值对比结果

参数设置	Silhouette Coefficient	Calinski-Harabaz Index
$k=30$ 、 $th=0.35$	-0.0027	5.2097
$k=60$ 、 $th=0.20$	0.0018	5.8898
$k=80$ 、 $th=0.10$	0.0079	6.1721
$k=100$ 、 $th=0.1$	0.0022	5.8947

本节使用聚类评估指标轮廓系数 Silhouette Coefficient 和 Calinski-Harabaz Index 系数进行评估，经历多次参数试验，其中 k 值分别设置为 30, 40, 60, 80, 100; th 的取值设置在 0 到 1 的区间范围内。经过多次尝试后，得到实验的数据对比结果，如图 5-5 所示。图中展示了 4 组典型数据，每组数据值的最高峰记录在表 5.1 中，根据 Silhouette

Coefficient 值越靠近于 1、Calinski-Harabaz Index 值越大效果越佳的原则，实验最终选取的参数设置为 $k = 80$ ， $th = 0.2$ ，该结果与公开数据集的参数设定相差较大，也表明了 CDP 算法中的超参与数据集关系十分紧密。




图 5-5 FINI 数据集上 $Data_{aug}$ 方法的 CDP 聚类参数试验结果对比图

5.2.3 实验结果与分析

按照上述实验流程，本节采用 Reid-strong model 的 baseline 模型作为基线模型，在真实场景中收集到的 FINI 数据集上进行试验，实验结果如表 5.2 所示：

(1) **定量分析：**由实验结果可知，当注意力机制模块 NL&HOA 和生成式数据增强方法 $Data_{aug}$ 同时应用于行人重识别任务时，相较于注意力机制模块 NL&HOA 与生成式数据增强方法 $Data_{aug}$ 的分开使用，模型对于行人的辨识能力得到了更大程度的提升，分别获得了 Rank-1/mAP 评估值为 8.1%/8.6% 的提升。

(2) **定性分析：**由实验结果分析可知，注意力机制对于行人重识别模型性能的提升高于生成式数据增强方案，该实验结果与公开数据上的实验效果相一致。两种方法本质上都是为了提升模型对于行人有效特征的提取能力，注意力机制可以让模型“注意到”行人整体中区分度高的局部区域，而数据增强则提供更丰富的学习样本帮助模型“熟中

表 5.2 FINI 数据集上的实验评估结果

模型	FINI	
	R1	mAP
Baseline(Resnet50)	73.6	65.8
Baseline+NL&HOA	80.2	70.3
Baseline(Resnet50)+ $Data_{aug}$	75.4	67.1
Baseline+NL&HOA+ $Data_{aug}$	81.7	74.4

生巧”，以捕获更多具有鉴别性的行人特征。因而两者可以相辅相成，共同致力于模型性能的提升。

(3) **输出结果可视化：**对比原始模型与 Baseline+NL&HOA+ $Data_{aug}$ ，将同一行人的正、侧面分别作为 Query 图像，输出结果的前 10 张图像进行可视化，如图5-6所示，即使采用侧面图像的 Baseline+NL&HOA+ $Data_{aug}$ 的跨摄像头行人重识别效果依然高于原始模型对于正面图像的识别效果，证明了本文所提出两种方法给模型带来性能上的有效提升。



图 5-6 行人重识别任务输出可视化

5.3 本章小结

本章运用一系列的行人跟踪检测、样本去重、聚类分配样本标签的流程采集得到真实场景下的行人重识别数据集-FINI，并运用此数据集评估了注意力机制模块 NL&HOA 与生成式数据增强方法 $Data_{aug}$ 的实用性，实验证明本文提出的两种方法在真实场景下也可以有效地提升基线模型的性能，使得模型具备更强的行人重识别能力。

第六章 总结与展望

本章对于基于注意力机制与数据增强的行人重识别方法的研究成果，以及过程遇到的问题与未来进一步的研究工作进行总结与展望。

6.1 本文总结

行人重识别技术作为智能监控与智能安防领域的重要一环，具有很高的研究价值。学术界对于行人重识别的研究，从 2014 年开始兴起，之后长达 7 年的时间里，学者们通过模型、目标函数、训练技巧、数据等多个维度对其不断进行改进。本文则着重从模型和数据两个方面对于基于图像的行人重识别任务展开研究。经过大量论文与实验研究后发现，基线模型的结构在当前已经实现了简易而又高效，在此基础上运用计算机视觉领域新兴的注意力机制可以灵活地进一步改进基线模型的性能。由此本文在前人研究的基础上，创新性地对于非局部操作与混合注意力的思想进行融合，通过将高阶注意力模块 HOA blocks 与 NL 组件相结合，实现既可对远程关系进行建模又可捕捉高阶信息量的注意力机制模块的设计。该注意力模块可即插即用，无论是嵌入单纯的 baseline 模型还是高效能的模型中，均可以一定幅度地提升行人重识别模型的效果。

再者，本文还提出一套生成式数据增强方案，该方案中结合适用于高维特征的 CDP 聚类进行生成样本的自动标签分配任务，进而有效扩展行人重识别数据集，该方案在基线模型上的效果还不错，但是由于受到生成样本质量的限制，过多地将生成样本融入源数据集时，使用高性能的模型进行训练，模型评估效果会有所下降。模型使用生成样本数据时，学习到许多本不属于行人特征的干扰性因素，导致模型过拟合，因此行人重识别效果反而降低了。故而该生成式数据增强方案受限于生成样本的好坏，但在样本缺乏时，仍不失为一种有效的数据增强方法。

本文所提出的注意力机制与数据增强的实用性，在公开数据集和现实场景的数据集上都得到了验证。两者方法也可相辅相成的结合使用，进而使得行人重识别任务从模型和数据两方面得到提升，实现更好的识别效果。

6.2 未来工作展望

注意力机制模块的设计是受到前人工作的启发而完成的，该注意力模型在算法理论上可以进行深入研究，找到数学理论上的依据。从而进一步优化模块的设计，使得模块设计更加轻巧，实现在确保注意力模型效果的同时降低模块的复杂度。

在数据增强方案上，可以将标签分配方案与动态软标签方法相结合，在行人重识别训练过程中使用动态标签分配策略来为生成样本赋予软标签，进而可以减轻该生成式数

据增强方案对于生成样本质量的依赖关系，更好地辅助模型训练效果的提升。

致谢

研究生三年时间飞逝，转眼即将步入社会。感谢三年中老师们的谆谆教导、同学们的同窗相伴，陪我经历人生中蜕变的三年，从一个懵懂的大学生，成为了一名独立自信的青年人。

感谢学校给了我成长的平台，感谢张祥老师、李慧颖老师为我提供了学术路上的指引以及生活上的关怀，让我可以清晰的看到前进的方向，一步一个脚印地成为了现在的我。感谢在南京烽火星空通信发展有限公司长达一年的实习期间，崔老师、王老师以及同事们的照顾与指导，在迷茫时为我指点迷津，让我得到不断前进的动力。

研一期间，参与院研究生会的事务、担任学生办公室助管时，感谢期间周桔老师、孙老师以及办公室各位老师的指导与照顾，让我在平凡的学生工作中看到老师们的辛苦、体会到了学生与老师之间相互理解的重要性。研三回到校园，认识了许多实验室的小伙伴，感谢大家的热情友好、成长相伴，为我研究生生涯画上了最后精彩的一笔。

三年的研究生生活即将结束，感谢三年来学习到的知识，看过的风景，遇见的老师 and 同学，以及不断努力的自己，希望可以以后再见时，我们都成为了更好的自己。

不忘初心，砥砺前行！

参考文献

- [1] Ye, M., Shen, J., Lin, G., et al. Deep Learning for Person Re-identification: A Survey and Outlook[J]. 2020.
- [2] Matsukawa, T., Okabe, T., Suzuki, E., et al. Hierarchical Gaussian Descriptor for Person Re-identification[C]. In: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016.
- [3] Gou, M., Fei, X., Camps, O., et al. Person Re-Identification Using Kernel-Based Metric Learning Methods[C]. In: Computer Vision-ECCV 2014. 2014.
- [4] Krizhevsky, A., Sutskever, I., and Hinton, G. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25:1097–1105.
- [5] Zheng, L., Yang, Y., and Hauptmann, A. G. Person Re-identification: Past, Present and Future[J]. 2016.
- [6] Sun, Y., Zheng, L., Yang, Y., et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and A Strong Convolutional Baseline)[J]. Springer, Cham, 2017.
- [7] Jie, H., Li, S., Gang, S., et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP(99).
- [8] Woo, S., Park, J., Lee, J. Y., et al. CBAM: Convolutional Block Attention Module[J]. European Conference on Computer Vision, 2018.
- [9] Roy, Abhijit, Guha, et al. Recalibrating Fully Convolutional Networks With Spatial and Channel "Squeeze and Excitation" Blocks[J]. IEEE Transactions on Medical Imaging, 2019, 38(2):540–549.
- [10] Cao, Y., Xu, J., Lin, S., et al. GCNet: Non-local Networks Meet Squeeze-Excitation Networks and Beyond[J]. arXiv, 2019.
- [11] Liu, H., Feng, J., Qi, M., et al. End-to-End Comparative Attention Networks for Person Re-Identification[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2017, 26(99):3492–3506.

- [12] Li, D., Chen, X., Zhang, Z., et al. Learning Deep Context-Aware Features over Body and Latent Parts for Person Re-identification[C]. In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017. 2017.
- [13] Li, W., Zhu, X., and Gong, S. Harmonious Attention Network for Person Re-Identification[C]. In: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018.
- [14] Chen, T., Ding, S., Xie, J., et al. ABD-Net: Attentive but Diverse Person Re-Identification[C]. In: arXiv. 2019.
- [15] Chen, B., Deng, W., and Hu, J. Mixed High-Order Attention Network for Person Re-Identification[C]. In: 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019.
- [16] Radford, A., Metz, L., and Chintala, S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks[J]. Computer ence, 2015.
- [17] Zhu, J. Y., Park, T., Isola, P., et al. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks[J]. IEEE, 2017.
- [18] Zhong, Z., Liang, Z., Zheng, Z., et al. Camera Style Adaptation for Person Re-identification[C]. In: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018.
- [19] Wei, L., Zhang, S., Wen, G., et al. Person Transfer GAN to Bridge Domain Gap for Person Re-Identification[C]. In: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018.
- [20] Deng, W., Liang, Z., Kang, G., et al. Image-Image Domain Adaptation with Preserved Self-Similarity and Domain-Dissimilarity for Person Re-identification[J]. 2017.
- [21] Zheng, Z., Yang, X., Yu, Z., et al. Joint Discriminative and Generative Learning for Person Re-Identification[C]. In: 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020.
- [22] Zheng, Z., Liang, Z., and Yi, Y. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro[J]. IEEE Computer Society, 2017.
- [23] Szegedy, C., Vanhoucke, V., Ioffe, S., et al. Rethinking the Inception Architecture for Computer Vision[J]. IEEE, 2016, pages 2818–2826.

- [24] Yan, Huang, Jingsong, et al. Multi-Pseudo Regularized Label for Generated Data in Person Re-Identification[J]. IEEE Transactions on Image Processing, 2019, 28(3):1391–1403.
- [25] Arjovsky, M., Chintala, S., and Bottou, L. Wasserstein GAN[J]. 2017.
- [26] Fan, H., Zheng, L., and Yang, Y. Unsupervised Person Re-identification: Clustering and Fine-tuning[J]. ACM Transactions on Multimedia Computing Communications and Applications, 2017, 14(4).
- [27] Lin, Y., Dong, X., Zheng, L., et al. A bottom-up clustering approach to unsupervised person re-identification[C]. In: Proceedings of the AAAI Conference on Artificial Intelligence. 2019. 8738–8745.
- [28] Zeng, K., Ning, M., Wang, Y., et al. Hierarchical Clustering With Hard-Batch Triplet Loss for Person Re-Identification[C]. In: 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020.
- [29] Zhang, H., Cisse, M., Dauphin, Y. N., et al. mixup: Beyond Empirical Risk Minimization[J]. 2017.
- [30] Li, S., Bak, S., Carr, P., et al. Diversity Regularized Spatiotemporal Attention for Video-based Person Re-identification[C]. In: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018.
- [31] Wang, X., Girshick, R., Gupta, A., et al. Non-local Neural Networks[J]. 2017.
- [32] Buades, A., Coll, B., and Morel, J. M. A non-local algorithm for image denoising[C]. In: 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). 2005. 60–65.
- [33] Luo, H., Jiang, W., Gu, Y., et al. A Strong Baseline and Batch Normalization Neck for Deep Person Re-identification[J]. IEEE Transactions on Multimedia, 2019.
- [34] Cheng, W., Qian, Z., Chang, H., et al. Mancs: A Multi-task Attentional Network with Curriculum Sampling for Person Re-Identification: 15th European Conference, Munich, Germany, September 8-14, 2018, Proceedings, Part IV[C]. In: Computer Vision –ECCV 2018. 2018.
- [35] Chen, G., Lin, C., Ren, L., et al. Self-Critical Attention Learning for Person Re-Identification[C]. In: 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019.

- [36] Zhan, X., Liu, Z., Yan, J., et al. Consensus-Driven Propagation in Massive Unlabeled Data for Face Recognition[C]. In: European Conference on Computer Vision. 2018.
- [37] He, L., Liao, X., Liu, W., et al. FastReID: a Pytorch toolbox for real-world person re-identification[J]. arXiv preprint arXiv:2006.02631, 2020.
- [38] Laurens, Vdm. Accelerating t-SNE using tree-based algorithms[J]. The Journal of Machine Learning Research, 2014, 15(1):3221–3245.
- [39] Zheng, L., Shen, L., Tian, L., et al. Scalable Person Re-identification: A Benchmark[J]. IEEE, 2016.
- [40] Liao, S., Yang, H., Zhu, X., et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C]. In: 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015.
- [41] Zhou, X., Wang, D., and Krhenbühl, P. Objects as points[J]. arXiv preprint arXiv:1904.07850, 2019.
- [42] Wojke, N., Bewley, A., and Paulus, D. Simple Online and Realtime Tracking with a Deep Association Metric[J]. IEEE, 2017, pages 3645–3649.

