

分类号: TP391

密 级: 公开

单位代码: 10422

学 号: 201832647



山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree

(专业学位)

论文题目: 基于深度学习的行人检测与重识别方法及
系统实现

Method and Implementation of Pedestrian Detection and
Re-identification Based on Deep Learning

作者姓名	张 杰
培养单位	信息科学与工程学院
专业学位名称	电子与通信工程
指导教师	孙国霞 副教授
合作导师	刘 琚 教授

2021年 5 月 25 日

目 录

摘 要.....	I
ABSTRACT	III
第 1 章 绪 论	1
1.1 研究背景和意义.....	1
1.2 研究现状.....	1
1.2.1 行人检测研究现状	2
1.2.2 行人重识别研究现状	3
1.3 论文主要工作.....	4
1.4 论文组织架构.....	5
第 2 章 基于卷积神经网络的行人检测与重识别	6
2.1 卷积神经网络理论.....	6
2.1.1 卷积计算层	6
2.1.2 激活层	6
2.1.3 池化层	7
2.1.4 全连接层	7
2.1.5 损失函数	8
2.1.6 优化算法	8
2.2 基于卷积神经网络的行人检测.....	8
2.2.1 基于两阶段的行人检测方法	9
2.2.2 基于单阶段的行人检测方法	9
2.2.3 行人检测评价	10
2.3 基于卷积神经网络的行人重识别.....	11
2.3.1 基于表征学习的行人重识别方法	11
2.3.2 基于度量学习的行人重识别方法	12
2.3.3 行人重识别评价	12
2.4 本章小结.....	14
第 3 章 引入注意力机制的行人检测方法	15
3.1 图像预处理.....	15
3.2 YOLOv3 目标检测算法.....	15
3.2.1 YOLOv3 网络结构	15

3.2.2 边界框的预测	16
3.3 引入注意力机制的 YOLOv3 检测算法	18
3.3.1 注意力机制	18
3.3.2 注意力模块	18
3.3.3 模型剪枝	21
3.4 实验基本设置	22
3.4.1 实验环境	22
3.4.2 实验数据集	22
3.4.3 模型训练设置	24
3.5 实验结果及分析	27
3.6 本章小结	31
第 4 章 融合组合损失的行人重识别方法	32
4.1 行人重识别损失函数	32
4.1.1 交叉熵损失	32
4.1.2 余弦交叉熵损失	33
4.1.3 三元组损失	35
4.1.4 难样本采样三元组损失	36
4.1.5 边界样本挖掘损失	36
4.2 组合损失设计	37
4.2.1 改进的边界样本挖掘损失	37
4.2.2 融合余弦交叉熵的改进边界样本挖掘损失	38
4.3 组合损失网络结构	39
4.4 实验基本设置	40
4.4.1 实验环境	40
4.4.2 实验数据集	40
4.4.3 模型训练设置	41
4.5 实验结果与分析	43
4.6 本章小结	45
第 5 章 行人检测与重识别系统设计与实现	47
5.1 系统需求分析	47
5.2 系统方案设计	48
5.3 系统开发与运行环境	51
5.3.1 硬件设备	51

5.3.2 软件平台 52

5.4 运行结果展示..... 53

5.5 本章小结..... 56

第 6 章 总结与展望 57

6.1 总结..... 57

6.2 展望..... 58

参考文献 59

致 谢..... 66

攻读学位期间发表的学术成果和参加的科研项目 67

CONTENTS

ABSTRACT (in Chinese)I

ABSTRACTIII

Chapter 1 Introduction..... 1

1.1 Research Background and Significance..... 1

1.2 Current Status of the Research..... 1

1.2.1 Current Status of Pedestrian Detection 2

1.2.2 Current Status of Pedestrian Re-identification 3

1.3 The Main Content of the Thesis..... 4

1.4 The Structure of the Thesis 5

Chapter 2 Pedestrian Detection and Re-Identification Based on CNN 6

2.1 Convolutional Neural Networks 6

2.1.1 Convolutional Layer..... 6

2.1.2 Activation Layer 6

2.1.3 Pooling Layer 7

2.1.4 Fully Connected Layer 7

2.1.5 Loss Function 8

2.1.6 Optimization Algorithm 8

2.2 Pedestrian Detection Based on Convolutional Neural Network..... 8

2.2.1 Pedestrian Detection Based on Two-Stage..... 9

2.2.2 Pedestrian Detection Based on One-Stage 9

2.2.3 Evaluation Standard of Pedestrian Detection 10

2.3 Person Re-identification Based on Convolutional Neural Network 11

2.3.1 Person Re-identification Based on Representation Learning 11

2.3.2 Person Re-identification Based on Metric Learning 12

2.3.3 Evaluation Standard of Pedestrian Re-identification 12

2.4 Conclusion 14

Chapter 3 Pedestrian Detection Method with Attention Mechanism 15

3.1 Image Preprocessing 15

3.2 YOLOv3 Object Detection Algorithm 15

3.2.1 YOLOv3 Network Structure 15

3.2.2 Bounding Box Prediction 16

3.3 YOLOv3 Detection Algorithm with Attention Mechanism	18
3.3.1 Attention Mechanism	18
3.3.2 Attention Module.....	18
3.3.3 Model pruning	21
3.4 Experimental Setup	22
3.4.1 Experimental Environment.....	22
3.4.2 Experimental Dataset.....	22
3.4.3 Model Training Setup	24
3.5 Experiment Results and Analysis.....	27
3.6 Conclusion	31
Chapter 4 Person Re-Identification Method with Combined Loss	32
4.1 Loss Function of Person Re-identification	32
4.1.1 Softmax Loss.....	32
4.1.2 Angular Softmax Loss	33
4.1.3 Triplet Loss.....	35
4.1.4 Triplet Loss with Batch Hard Mining.....	36
4.1.5 Margin Sample Mining Loss	36
4.2 Design of Combined Loss.....	37
4.2.1 Improved Margin Sample Mining Loss	37
4.2.2 Improved Margin Sample Mining Loss Combined with Angular Softmax Loss	38
4.3 Network of Combined Loss	39
4.4 Experimental Setup.....	40
4.4.1 Experimental Environment.....	40
4.4.2 Experimental Dataset.....	40
4.4.3 Model Training Setup.....	41
4.5 Experiment Results and Analysis.....	43
4.6 Conclusion	45
Chapter 5 Design and Implementation of Pedestrian Detection and Re- identification System	47
5.1 Analysis of System Demand	47
5.2 Design of System Scheme	48
5.3 System Development and Running Environment.....	51
5.3.1 Hardware Device	51
5.3.2 Software Platform.....	52

5.4 Display of Running Result..... 53

5.5 Conclusion 56

Chapter 6 Conclusions and Future Work..... 57

6.1 Conclusions..... 57

6.2 Future Work 58

References 59

Acknowledgement 66

**Published Academic Achievements and Participated Projects During the
Postgraduate..... 667**

摘 要

随着国家和社会的发展,公共安全问题的预防和排查,人们视频监控系统的的需求越来越迫切。在智能视频监控时代,人工智能已成为加强社会管理、预防犯罪行为的有力工具。在海量的监控视频中,在复杂多变的监控场景下,通过人脸、步态等信息进行智能识别极为困难,因此,行人检测、行人重识别技术引起研究人员的关注。行人检测任务顾名思义就是检测出图像中出现的所有行人,并用矩形框圈画出行人区域。行人重识别技术则是与行人检测技术相结合,实现跨摄像头的检测、识别,在一定程度上弥补了摄像头监控区域固定的局限。因此研究高效可靠的行人检测与行人重识别方法对于智能视频监控系统的构建具有十分重要的意义和价值。在实际的监控场景中,行人检测面临的主要挑战在于环境背景复杂、行人尺寸过小或行人之间存在相互遮挡等。行人重识别面临的主要挑战在于拍摄视角及行人姿态差异导致同一行人拍摄的图片之间存在较大差异。针对以上问题,本论文完成了以下工作:

1. 针对行人检测问题,提出了引入注意力模块 SKNet 的行人检测方法。该方法在通用目标检测算法 YOLOv3 的基础上,针对 YOLOv3 对行人遮挡、小尺度行人易产生漏检的情况,利用注意力机制模块重构原始特征图中不同通道的比重。使得被遮挡通道权重降低,未被遮挡通道权重提高,提升行人遮挡的检测效果;同时使得不同的图像得到具有不同重要性的卷积核,提高 YOLOv3 的多尺度预测效果,从而提高行人遮挡和小尺寸行人的检测效果。此外,针对加入了注意力模块导致模型体积变大参数量变多的问题,通过模型剪枝,使得算法在精确度几乎不变的情况下,检测速度得到提高。

2. 针对行人重识别问题,提出了融合组合损失函数的行人重识别方法。该损失函数整合了基于表征学习损失和基于度量学习损失的优点,将基于度量学习的改进边界样本挖掘损失与基于表征学习的余弦交叉熵损失进行组合。其中,改进边界样本挖掘损失是在基于度量学习的边界样本挖掘损失基础上,新增了一项中心损失。改进后的边界样本挖掘损失压缩了类内距离,使得类内约束更强。此外,为了解决组合损失难以收敛的问题,引入了 BNNeck 网络结构。

3. 基于本论文所提出的行人检测与行人重识别方法，设计了一个系统，实现了算法运行结果的可视化。系统分析了所要搭建的行人检测与重识别系统功能需求，设计了系统的总体架构以及工作原理等，最后基于软件平台 PyQt 搭建了一个具有可视化界面的系统。在设定的场景中，对算法的运行结果进行展示，为在实际应用场景应用提供了验证和接口。

关键词：行人检测；行人重识别；深度学习；注意力机制；边界样本挖掘损失

ABSTRACT

With the development of the country and society, public safety prevention and investigation have made people's demand for intelligent video surveillance systems more urgent. In the era of intelligent video surveillance, artificial intelligence has become a powerful tool to strengthen social management and prevent crime. However, it is extremely difficult to perform intelligent recognition based on human face or gait in massive surveillance videos from complex scenes. Therefore, pedestrian detection and person re-identification technologies have attracted the attention of researchers. The pedestrian detection task, as its name implies, is to detect all pedestrians appearing in the image and draw the pedestrian area with a rectangular frame. Person re-identification technology is combined with pedestrian detection technology to achieve cross-camera detection and recognition, to a certain extent, to make up for the limitation of fixed camera monitoring area. Therefore, research on pedestrian detection and person re-identification technology has vital significance and value for constructing intelligent video surveillance systems. In actual surveillance scenarios, pedestrian detection's main challenges are complex environmental backgrounds, small-sized pedestrians, or mutual occlusion between pedestrians. The main challenge of person re-identification is that the different angles of view and pose lead to significant differences between the images taken even for the same pedestrian or at the same moment. In view of the above problems, the main works of this thesis are as follow:

Aiming at pedestrian detection, a pedestrian detection method with attention module SKNet is proposed. This method is based on the general target detection algorithm YOLOv3. Aiming at the situation where the YOLOv3 algorithm are prone to miss detection on occludes pedestrians and small-scale pedestrians. Through the attention mechanism module to change the weight of the convolution kernel of the original channel in the feature map, the weight of the occluded channel is decreased, and the weight of the unoccluded channel is increased, and improve detection effect of occluded pedestrian. Simultaneously, different images can get different convolution

kernels, which improves the multi-scale prediction effect of YOLOv3, thereby improving the small pedestrian detection effect. In view of the problem that the model volume becomes larger and the number of parameters increases due to the attention module's addition, model pruning enables the algorithm to improve detection speed further. In contrast, the algorithm's accuracy is almost unchanged and meets pedestrians' real-time detection requirements in the monitoring scene.

Aiming at person re-identification, a person re-identification method with combined loss function is proposed. The loss function integrates the advantages of representation learning loss and metric learning loss, and combines the improved boundary sample mining loss based on metric learning and the angular Softmax (A-Softmax) loss based on representation learning. The improved boundary sample mining loss adds a new center loss based on the boundary mining loss. The improved boundary sample mining loss reduces the intra-class distance and makes the intra-class constraint stronger. In addition, in order to solve the problem that the combined loss is difficult to converge, the BNNeck network is introduced.

A system is designed to achieve the visualization of the results of the algorithm based on the pedestrian detection and person re-identification methods proposed in this thesis. The functional requirements of the system to be built are analyzed. The system's overall scheme, including the system design architecture and working principle, is designed, and finally, based on the software platform PyQt, a system with a visual interface was built. In the set scenario, the results of the algorithm are displayed, which provides verification and interface for the application in the actual application scenario.

Keywords: pedestrian detection; pedestrian re-identification; deep learning; attention mechanism; margin sample mining loss

第1章 绪 论

1.1 研究背景和意义

随着社会安全问题的日益突出,随处可见的监控摄像头被安装在学校、商场等活动场所,用以预防和排查公共安全问题。发生安全事件时,传统的监控系统需要花费大量的人力和物力从不同摄像头的监控视频中逐帧地回放查看,以查找嫌疑人的轨迹。在人工智能快速发展的今天,人工智能利用计算机模拟人脑帮助人们从海量的监控数据中获取有用的信息。然而在背景复杂的实际监控场景中,利用人脸、步态等信息进行识别极为困难,因此,行人检测、行人重识别技术引起学者们的关注。

行人检测任务顾名思义就是找出图像或者视频中出现的所有行人并分别用方框进行标记。行人重识别任务则用于解决在不同区域的监控摄像头之间特定行人的匹配问题。即给定一张所要查找的行人图像,判断在其他区域的监控摄像头捕捉到的画面中是否存在该行人。在实际应用场景中往往需要二者结合,行人检测作为行人重识别的预处理部分,负责从监控图像中检测出行人并进行裁剪。行人检测以及重识别技术一定程度上弥补了单个摄像头监控区域固定的局限,可以实现对行人的跨摄像头的检测、识别与跟踪,因此在智能视频监控、突发事件重构、公安侦查等方面具有巨大的应用潜力。目前,行人检测以及重识别技术已经在部分省市公安的监控系统中落地测试,然而由于面对的实际监控环境过于复杂,行人检测以及重识别技术距离被大规模应用仍然存在较大的距离。在实际的监控环境中,行人检测面临的主要挑战在于环境背景复杂、行人尺寸过小或行人之间存在相互遮挡等。行人重识别面临的主要挑战在于拍摄视角及行人姿态差异导致同一行人拍摄的图片之间存在较大差异。针对现有技术的不足,本论文研究高效精准的行人检测方法与行人重识别方法,这对于监控系统的智能化,助力我国强有力地打造平安城市、智慧城市具有重要的意义。

1.2 研究现状

由于真实监控场景下,存在摄像头之间拍摄角度不同^[1,2]、图像分辨率不同^[3,4]、照明条件不一^[5]、行人姿态多变^[6-8]、存在相互遮挡^[9,10]等问题,行人检测与

行人重识别技术仍有许多困难亟待解决,因此研究行人检测与行人重识别具有极大的挑战性与实际意义。

1.2.1 行人检测研究现状

在卷积神经网络出现之前,传统的行人检测方法主要有基于运动检测的方法和基于机器学习的方法。基于运动检测的方法由背景建模算法和分类器两个部分组成,背景建模算法用于提取前景目标,分类器对提取出的目标进行分类,判断目标中是否存在行人。常见的背景建模算法有:高斯混合模型^[11],ViBe 算法^[12],PBAS 算法^[13],样本一致性建模算法^[14]等。背景建模算法的大致思路是在初始的图像帧中学习背景模型,然后通过当前帧与之前提取的帧进行比较,得到运动的目标。背景建模的方法虽然实现简单,检测速度很快,但只能检测到运动状态中的行人,且因为背景建模的方法只利用了像素级别的信息,没有提取出图像中的语义信息,检测过程受光照,阴影等环境因素的影响极大。由于机器学习算法对于环境因素的良好鲁棒性,基于机器学习的行人检测方法开始逐渐涌现。第一个具有里程碑意义的成果是 Navneet Dalal 等人在 2005 年的计算机视觉与模式识别会议 (Computer Vision and Pattern Recognition, CVPR) 中提出的基于梯度直方图 (Histogram of Oriented Gradient, HOG) 和支持向量机 (Support Vector Machine, SVM^[42]) 的行人检测方法^[15]。但由于 SVM 的计算量太大,为了加快检测速度,研究者们用自适应提升算法^[16]代替 SVM 进行分类。之后, P. Dolla'r 等人^[17]提出积分通道特征 (Integral Channel Features, ICF) 用来获取输入图像的不同信息,这一算法达到了实时检测的效果,并且有很高的精度,是当时的巅峰之作。此外为了解决行人遮挡问题, J. Yan 等人^[18]提出使用分块检测的方法,将人体分为头肩、四肢、躯干等部分,分别检测后再把结果组合在一起。

在一些固定的条件下,基于运动检测和机器学习的方法能取得较好的行人检测效率或精确度,但随着各种各样复杂数据集的出现,传统方法在这些数据集上的表现不能同时满足实际应用场景中的精度和帧率要求。

随着卷积神经网络在图像分类领域^[19]广泛应用,研究人员发现卷积神经网络学到的特征具有很强层次的表达能力和很好的鲁棒性,可以更好地解决行人检测问题。2014 年, R-CNN^[20] (Region with CNN) 的横空出世揭开了深度学习应用在目标检测领域的序幕。2016 年, Ross Girshick 的团队在 R-CNN 系列算法中做

出进一步改进,提出了 Faster R-CNN^[21],与 R-CNN 相比,大幅度地提升了检测速度和检测精度。但由于 R-CNN 系列算法的检测速度一直达不到实时性的要求,研究者们将目标检测的关注点转向了检测速度上,因此基于单阶段的目标检测算法层出不穷。与 R-CNN 系列检测模型相比,Redmon 等人提出的 YOLO (You Only Look Once)^[22]模型检测速度大幅提升。Liu 等人提出的 SSD (Single Shot MultiBox Detector)^[23]、Redmon 等人提出的 YOLOv2^[24]和 YOLOv3^[25]等单阶段检测模型,结合 R-CNN 系列模型的一些优点,通过采用特征金字塔、调整网络结构、设计锚框等策略,提高了检测的精度。针对行人小目标检测率低的问题,李慕铠等人^[26]提出将 SENet (Squeeze-and-Excitation Networks)^[27]引入 YOLOv3 中。针对行人检测中遮挡目标漏检率较高的问题,刘丽等人^[28]在网络中引入空间金字塔池化网络。因此研究以 YOLOv3 作为主干网络结构的行人检测方法来解决行人遮挡和小行人检测中出现的漏检率较高的问题,对实时性和准确率都要求比较高的智能视频监控系统非常具有现实意义。

1.2.2 行人重识别研究现状

行人重识别任务可以大致分为两个部分:特征提取和相似度度量。早期的研究工作主要集中在手工提取行人身体特征^[29]或传统的度量学习方法。随着近年来卷积神经网络的不断发展,截止到目前,基于卷积神经网络的行人重识别领域许多杰出的方法层出不穷。以损失函数作为划分标准,可分为基于表征学习和基于度量学习的方法;表征学习将行人重识别等价于分类问题,Zheng 等人^[30]将每个行人看作分类问题的一个类别,Lin 等人^[31]在行人类别的基础上引入行人属性作为分类的依据,增强了网络的泛化能力。度量学习则是通过网络度量不同图片之间的距离,常用的度量学习损失函数有对比损失^[32],三元组损失^[33],四元组损失^[34]。以特征提取方式为划分标准,可分为基于全局特征和基于局部特征,局部特征^[35]的引入则考虑到行人的局部信息,通过将行人图片按区域划分的方式解决行人在不同摄像镜头下姿态多样的问题。以模型输入作为划分标准,可分为基于图像的行人重识别方法和基于视频序列的行人重识别方法^[36-38]。基于视频序列的行人重识别方法更关注视频的运动信息,借助递归循环网络提取出视频的时序特征。而生成对抗网络 (Generative Adversarial Networks, GAN) 的引入^[39,40],通过扩充行人重识别的数据样本,使得行人重识别获得进一步发展。

基于局部特征的行人重识别方法往往需要设计复杂的网络结构来连接多个分支的特征，而基于全局特征的行人重识别方法推理阶段计算快速，因此更适合应用于对帧率要求较高的实际监控场景。因此研究基于全局特征的行人重识别算法，可以在不增加特征提取网络复杂度的基础上，通过改进损失函数来提高准确率，这对于实时性要求较高的监控系统更具有实际意义。

1.3 论文主要工作

本论文主要的研究内容是基于深度学习的行人检测与行人重识别方法以及系统实现。论文的主要工作总结如下：

(1) 在行人检测算法上，提出了引入注意力模块 SKNet 的行人检测方法。针对通用目标检测算法 YOLOv3 应用到行人检测任务时所面临的小尺度行人以及行人遮挡在检测的时候容易产生漏检的问题，对 YOLOv3 网络结构进行优化，在原始网络结构的基础上添加注意力机制模块，通过注意力机制模块改变特征图中原始通道的权重，使得被遮挡通道权重降低，未被遮挡通道权重提高，从而提高被遮挡行人的检测效果。同时在注意力模块中利用不同大小卷积核获得不同的感受视野，提高了 YOLOv3 多尺度行人检测的能力。之后对引入注意力模块的网络进行模型剪枝，在几乎不丧失精度的情况下，进一步提高算法的检测速度，更好地满足实时性的要求。

(2) 在行人重识别任务上，提出了融合组合损失函数的行人重识别方法。通过对比分析各种行人重识别常用的损失函数，基于行人重识别损失极小化类内距离的优化思想，对边界样本挖掘损失函数进行了改进，加入类内损失进一步压缩其类内距离。再将余弦交叉熵损失与改进的边界样本挖掘损失进行组合，使两种损失之间进行互补。在全局特征提取网络的基础上，组合损失函数增强了网络特征提取能力，改善了网络性能，加快了网络训练。

(3) 构建并实现了一个简单的行人检测与重识别系统，在基本监控功能的基础上增加了(1)、(2)提出的行人检测和行人重识别方法。该系统软件平台基于 PyQt 实现，用于对监控画面、行人检测和行人重识别算法的运行结果等信息进行可视化展示。

1.4 论文组织架构

本论文总共分为五章，其结构如下：

第一章将介绍有关行人检测与行人重识别的研究背景、意义以及目前行人检测与行人重识别的研究现状。

第二章介绍了卷积神经网络相关基础，基于卷积神经网络的行人检测方法和评价指标，基于卷积神经网络的行人重识别方法以及常用评价指标。

第三章首先介绍了 YOLOv3 算法，阐述其基本原理。然后针对 YOLOv3 检测算法应用到行人检测任务中，对小尺寸行人和遮挡行人检测效果不佳的缺陷，将针对卷积核的注意力机制模块引入到 YOLOv3 中；通过模型剪枝对引入注意力机制后的算法进行通道修剪，减小模型体积降低参数量；最后在 Caltech^[44]数据集和 Pascal VOC 2007 数据集上进行实验，体现了本章提出的引入注意力机制的行人检测方法的有效性。

第四章首先对比分析了各种行人重识别损失函数的优缺点，然后基于最小化类内距离的思想，在原有的边界样本挖掘损失中新增中心损失约束性，进一步增强类内紧凑性；之后，通过组合余弦交叉熵损失和改进的边界样本挖掘损失实现两种损失的优势互补；最后在行人重识别常用数据集 Market-1501^[60]和 DukeMTMC-reID^[61]上进行实验，体现了本章提出的组合损失函数的有效性。

第五章首先分析搭建的行人检测与重识别系统所要实现的功能，根据功能需求确定系统的总体方案，之后介绍了系统所使用的设备和软件平台，最后基于 PyQt 搭建了一个软件平台实现界面的可视化。

第六章总结了本论文中所提出的行人检测算法与行人重识别算法以及所实现系统的优点与不足，并对未来的研究方向内容做出展望。

第2章 基于卷积神经网络的行人检测与重识别

2.1 卷积神经网络理论

2.1.1 卷积计算层

卷积计算层是 CNN 中最重要的层，通过在 CNN 中不同的位置设计不同大小的卷积核对输入的图片提取图像纹理、边缘信息等特征。假设输入图片的矩阵如式 2-1 中的 A ，卷积核矩阵如式 2-1 中的 K ，

$$A = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{bmatrix} \quad K = \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{bmatrix} \quad (2-1)$$

其中 x_{ij} 表示矩阵 A 中第 i 行第 j 列元素值， w_{ij} 表示矩阵 K 中第 i 行第 j 列元素值。设卷积的步长为 1，输出的结果矩阵为 O ，则卷积的计算过程如式 2-2 所示：

$$O = A * K = \begin{bmatrix} y_{11} & y_{12} \\ y_{21} & y_{22} \end{bmatrix} \quad (2-2)$$

其中矩阵 O 中的元素 $y_{11}, y_{12}, y_{21}, y_{22}$ 计算方式如式 2-3, 2-4, 2-5, 2-6 所示：

$$y_{11} = x_{11} * w_{11} + x_{12} * w_{12} + x_{21} * w_{21} + x_{22} * w_{22} \quad (2-3)$$

$$y_{12} = x_{12} * w_{11} + x_{13} * w_{12} + x_{22} * w_{21} + x_{23} * w_{22} \quad (2-4)$$

$$y_{21} = x_{21} * w_{11} + x_{22} * w_{12} + x_{31} * w_{21} + x_{32} * w_{22} \quad (2-5)$$

$$y_{22} = x_{22} * w_{11} + x_{23} * w_{12} + x_{32} * w_{21} + x_{33} * w_{22} \quad (2-6)$$

2.1.2 激活层

在卷积神经网络中，激活函数用来对特征进行非线性变化。常见的激活函数有 Sigmoid、Softmax、ReLU、Leaky ReLU。

Sigmoid 一般是在网络的最后添加，将输入的变量 z 映射到(0,1)之间，Sigmoid 公式如 2-7 所示：

$$S(z) = \frac{1}{1 + e^{-z}} \quad (2-7)$$

Softmax 和 Sigmoid 一样，一般添加在网络的最后，将多个输入映射到(0,1)之间，公式如 2-8 所示，其中 N 是分类的类别数：

$$S(z_i) = \frac{e^{z_i}}{\sum_{j=1}^N e^{-z_j}} \tag{2-8}$$

ReLU 函数则添加在卷积计算后，用于对输入的特征 z 进行非线性的映射，公式如 2-9 所示：

$$R(z) = \begin{cases} z & z > 0 \\ 0 & z \leq 0 \end{cases} \tag{2-9}$$

由于 ReLU 函数输入小于 0 的部分存在梯度消失的情况，因此 Andrew L. Maas 等人提出改进的 Leaky ReLU，公式如 2-10 所示：

$$R(z) = \begin{cases} z & z > 0 \\ \alpha z & z \leq 0 \end{cases} \tag{2-10}$$

2.1.3 池化层

为了防止卷积神经网络的参数量爆炸，减少特征冗余，使用池化层来减小特征图的大小，降低参数量，同时保留特征的主要信息。通过两个简单的例子：预设池化窗口大小为 2×2 ，池化步长为 2；最大池化的流程：以 2 为步长在提取的特征矩阵上滑动，选取每次滑动过程中窗口内的最大值进行输出。平均池化同理，不过输出的是窗口内的平均值，具体过程如图 2-1 所示：




图 2-1 池化过程示意图

2.1.4 全连接层

全连接层的作用是融合卷积层学习到的各个部分特征。全连接层的连接方式如图 2-2 所示，对于部分卷积神经网络而言，参数主要都来自于全连接层。因此实际的训练过程中，防止参数量过大，通常会采用 dropout 的方法让全连接层上的部分节点休眠（如图中虚线所示）不参与计算来防止过拟合。




图 2-2 全连接层示意图

2.1.5 损失函数

深度学习训练模型的实质就是在损失函数的监督下，不断调整网络的模型参数以拟合训练样本的数据分布，损失函数为网络确定了优化的方向，因此损失函数的设计在网络模型的训练过程中发挥至关重要的作用。根据神经网络优化目标任务的不同，网络所需要的损失函数也不同，常见的损失函数有分类损失，均方误差损失等。

2.1.6 优化算法

常见的优化算法有随机梯度下降算法（Stochastic Gradient Descent, SGD）、自适应矩估计（Adaptive Moment Estimation, Adam）优化算法等。SGD 在训练过程中会使得损失函数不断波动，而且一次以一个训练数据进行梯度下降容易陷入局部最小值，困在鞍点。Adam 算法则通过动态调整参数的学习率，使得参数的变化更加平稳。但是 Adam 可能会不收敛，并且可能会错过全局最优解，因此在实际应用当中根据数据特性、模型特性进行动态调整。

2.2 基于卷积神经网络的行人检测

现有的目标检测分类器根据算法流程的不同主要分为两类：一类是两阶段检测器，即检测过程包含两个阶段，包括 R-CNN、Fast-RCNN^[43]、Faster-RCNN 等。另一类是单阶段检测器，如 YOLO、YOLOv2、SSD 和 YOLOv3 等。行人检测作为目标检测领域的一个重要分支以及应用，因此可以直接采用两阶段或单阶段的检测器作为行人检测的方法。

2.2.1 基于两阶段的行人检测方法

在两阶段的行人检测方法中，第一阶段生成大量的矩形框作为候选区域集。在生成候选区域时，使得图像中的所有行人都至少属于这些区域中的一个。在第二阶段，通过深度卷积神经网络对候选区域的特征向量进行编码，然后依据标签中的类别信息判断该区域内是否存在行人目标，最后通过标签中的坐标对候选区域的坐标进行调整。

R-CNN 是两阶段检测器的先驱。对于网络输入的每张图像，R-CNN 先是通过选择性搜索（Selective Search, SS）^[41]生成大量的矩形框作为潜在行人的候选区域。然后，通过裁剪调整每个候选区域为固定尺寸；接着利用 AlexNet^[19]提取出候选区域图像的特征，并借助 SVM 进行分类判断是否存在行人。最后利用回归函数对候选区域的边框进行调整。R-CNN 的检测效率比起传统算法有了极大的提高，但存在一些缺点：(1) 每一张图片生成的每个候选区域都要经过同一个卷积神经网络，效率太低；(2) 算法中的特征提取、预测类别和目标框边界回归模型是相互独立的，不能实现整个检测框架的端到端优化，难以获得全局最优解，导致模型不易训练。

Fast R-CNN 在 R-CNN 的基础上做出了一些改进。Fast R-CNN 先计算出整张图片的特征图，之后采用感兴趣区域映射的方法分享整幅图像的特征图给不同的候选区域，解决了 R-CNN 中每个候选区域都要经过卷积神经网络的弊端，并且实现行人特征提取、行人分类和行人边框回归的端到端网络训练。

Fast R-CNN 检测效率的瓶颈是候选区域的生成效率。对此，Faster R-CNN 提出使用区域生成网络来代替 Fast R-CNN 的 SS。此外，Faster R-CNN 将区域生成网络、行人特征提取、行人分类任务以及行人边框的回归集成在一个统一的检测框架内，大大提高了两阶段检测器的检测速度。

2.2.2 基于单阶段的行人检测方法

基于两阶段的行人检测方法的定位效果和识别准确率较高，但是检测速度却不够快，因此为了能具有更快的检测速度满足实际应用场景，单阶段检测器应运而生。单阶段检测器，不需要通过候选区域生成这一步骤就直接从输入图像中生成预测框，因此能够更有效率，保证了实时性。

YOLOv1 作为单阶段检测器的开山鼻祖,将检测作为一个回归问题并采取分而治之的思想,它将输入的图像划分成 7×7 的网格,让每个网格以当前网格为中心而独立地预测行人类别标签、置信度分数以及对应的边界框。整个算法流程是一个单阶段的网络,它省略了候选区域生成的步骤,以端到端的方式进行优化。由于 YOLOv1 模型简单,因此在检测效率上是第一个能够满足实时预测的检测器。然而 YOLOv1 存在一些缺点:

- (1) 每个网格只能预测两个行人,使得在行人拥挤的场景下检测变得困难;
- (2) 仅仅使用最后一层的特征图进行预测,达不到多尺度纵横比的检测效果。

为了解决这些问题,YOLOv2 相较于做了如下改进:

(1) 使用卷积层替换 YOLOv1 中的全连接层,采用相当于数据增强的多尺度训练,使模型更具有鲁棒性;

(2) YOLOv2 采用了更强大的深度卷积骨干网络结构,通过对 ImageNet 数据集中分辨率较高的图像进行预训练;

(3) 受到 SSD 中锚框策略的启发,摒弃 YOLOv1 中手动设置锚框的方式并引入锚框,通过 K-means^[45]聚类算法从训练数据中获得更好的锚框先验信息,使得模型更易收敛,同时可以有效提高召回率,减少漏检。

YOLOv3 借鉴了残差神经网络 (Residual Neural Network, ResNet)^[46]中的残差连接方式,相较于 YOLOv2 的主干网络 Darknet-19^[24],构建了更深的主干网络 Darknet-53^[25],并为了降低池化层对网络反向传播带来的负面影响,Darknet-53 中特征图的尺寸变化完全依靠卷积核步长来进行。YOLOv3 结构清晰,实时性好,因此在实际场景中获得了广泛的应用。

2.2.3 行人检测评价

在行人检测任务中,需要综合衡量检测过程的漏检率和误检率,所以一般采用 MR-FPPI (Miss Rate Versus False Positive Per Image) 曲线作为模型优劣的评价指标。

在给出曲线的计算方法之前,先给出几个基本概念。在行人检测中,对于模型预测获得的检测框中的情况一般分为三种: 1) 标签中含有行人,且模型也检测到了行人,则检测结果称为真正例 (True Positive, TP); 2) 标签中含有行人,但模型未检测到行人,则检测结果称为假反例 (False Negative, FN), 即此时产

生了漏检的情况；3) 标签中没有行人，但模型检测出了行人，则检测结果称为假正例 (False Positive, FP)，即此时产生了误检的情况。在行人检测任务中，通过使用行人漏检率 (Miss Rate, MR) 来衡量行人被漏检的比例。每张图片的假正例数 (False Positive Per Image, FPPI) 来衡量误检的情况。在检测的过程中，MR 和 FPPI 通常是一对互斥的指标，当设置的检测阈值越高，检测出的结果则越准确即 FPPI 则越低，同时更容易产生漏检的情况即 MR 则越高。因此，需要通过多次调整检测的阈值，得到多组的 (MR, FPPI)，连接之后得到最终的 MR-FPPI 曲线。

通过观察 MR-FPPI 曲线定性分析，若越靠近坐标原点，则说明行人检测的过程中误检和漏检情况更少，效果更好。此外，用对数平均漏检率 MR^{-2} 作为定量的评价指标。在计算 MR^{-2} 时，一般会在曲线上，均匀地取 9 个 FPPI 值所对应的 MR，并求其对数平均值。 MR^{-2} 的值越小则表明行人检测过程中存在的漏检情况更少。

2.3 基于卷积神经网络的行人重识别

传统行人重识别方法先是通过尺度不变特征变换^[47] (Scale invariant feature transform, SIFT)，然后通过交叉视角的二次判别分析法^[48] (Cross-view Quadratic Discriminant Analysis, XQDA) 或者使用保持直接简单原则的度量^[49] (Keep It Simple and Straightforward Metric Learning, KISSME) 方法来进行相似度的度量。然而，传统方法在复杂的应用场景下提取的特征对输入图像的描述能力有限，行人重识别任务变得异常困难。卷积神经网络学到的特征具有很强语义表达能力和鲁棒性，因此研究基于卷积神经网络的行人重识别方法成为主要研究方向。本节以损失函数为切入点对行人重识别方法进行划分，分别介绍基于表征学习的行人重识别方法和基于度量学习的行人重识别方法。

2.3.1 基于表征学习的行人重识别方法

基于表征学习的方法在训练网络的时候将行人重识别当作是分类任务。作为分类任务时，使用输入图片中的行人 ID 作为训练样本的标签，网络对输入图片的行人 ID 进行分类。分类任务的特征提取网络中的最后一个全连接层计算出输入图片的类别概率，最后利用行人 ID 损失作为网络的损失函数。之后，研究者们发现光靠行人 ID 约束，网络的泛化能力不够强。因此，在训练行人图片中标

注了更多的行人属性（性别、衣着等）作为监督信息，在 ID 损失的基础上增加一项属性损失^[31]，让训练好的网络可以同时预测出行人 ID 和行人属性，增强了网络的泛化能力。

总结来说，表征学习让网络学习输入样本在特征空间上的分界面，其优点在于数据集行人 ID 数量不大的时候训练时间更短，收敛容易，训练出的模型鲁棒性更强。但由于表征学习是将输入图片中的每一个行人当作一个不同的类别，当数据集中行人数量激增的时候，网络最后的全连接层的维度也会相应增多，使得参数量爆炸，并且类别更多分类亦会更加困难。

2.3.2 基于度量学习的行人重识别方法

与 2.3.1 介绍的表征学习不同的是，基于度量学习的行人重识别任务，直接通过网络度量输入行人图片之间的相似度，找出属于同一行人的图片。具体来说，度量学习的一般思路：首先，定义一个特征映射函数 $f(x)$ ，将输入图片从低维度的原始数据域映射到高维的卷积特征域；其次，定义一个度量函数 $D(x, y)$ 来计算前面获得的特征向量之间的距离；最后在损失函数的约束下，同一行人 ID 的不同图片（正样本对）的距离不断减小，不同行人 ID 图片（负样本对）的距离不断增大。此外，每个行人 ID 的训练标注图像很多，同时正、负样本对的严重不平衡增加了训练策略设计的难度。因此在基于度量学习的行人重识别中，选取合适的样本采样策略起到了非常重要的作用。最常用的采样策略是根据行人 ID 抽样，对于每个训练批次，随机选择一定数量的 ID，然后从每个选择的 ID 中抽取几幅图像。

总结来说，度量学习采用的是聚类的思想，在度量学习损失的约束下，正样本对的距离不断拉近，负样本对的距离不断拉远。并且度量学习克服了表征学习需要随着行人 ID 数量变化来调整网络全连接层的缺点。然而，由于采样策略的存在，度量学习相对于表征学习来说收敛比较困难，而且训练的收敛时间也比表征学习长。

2.3.3 行人重识别评价

（1）k 阶匹配率（rank-k）

在行人重识别任务中，rank-k 是最重要的指标，rank-k 表示的是在一次图像检索过程中最靠前的 k 张图中有正确结果的概率。具体表示为：给定一组待查询

图片集和候选行人库，将待查询图片集中的每张图片依次与候选行人库中的图片计算相似度，之后将计算所得的相似度从大到小排序，前 k 个相似度最大的图片中若存在正确匹配的图片，则称为 rank-k 命中。具体 rank-k 公式如式 2-11 所示：

$$\text{rank-k} = \frac{\sum_{i \in \{1, 2, \dots, N\}} S_i}{N} \quad (2-11)$$

其中 N 是待查询图片集中的图片数量，当待查询图片集中的第 i 张图片命中则 $S_i = 1$ ，否则 $S_i = 0$ 。rank-1 表示的是每次查询匹配到的第一张图片刚好命中，是行人重识别任务的根本目标。rank-k 表示前 k 张图片命中，再通过人工筛选找到目标，因此 rank-k also 具有重要的意义。

(2) 平均检测精度 (mean Average Precision, mAP)

rank-k 指标在部分场景下无法反映算法的识别性能，如图 2-3 所示：




图 2-3 rank-k 和 AP 对比

图示中，黄色表示检索结果中成功匹配的图片，蓝色的表示未匹配成功的图片。(a)、(b) 表示的是使用两种算法进行重识别得到的两种情况，这两种情况下 rank-1 和 rank-5 的结果均为 1，此时用 rank-k 则无法区分 (a)、(b) 两种情况下的算法性能优劣，但从排序结果明显可以看出算法 (a) 的性能更优。

查准率是在一次检索过程中，从候选行人库中检索出的图片中成功匹配的比例，查全率是候选行人库中所有应该被匹配的图片被检索出来的比例，mAP 的具体计算方法如式 2-12 所示。

$$\text{mAP} = \frac{\sum_{n=1}^N AP_n}{N} \quad (2-12)$$

其中 N 是待查询图片集中的图片数量, AP 是以查准率为纵坐标, 查全率为横坐标画出的 $P-R$ 曲线下积分得到的面积。由式 2-12 可知, mAP 反映了当待查询图片数量较多时, 行人重识别结果的准确性。

2.4 本章小结

本章先详细介绍了卷积神经网络的常用理论知识, 然后介绍了基于卷积神经网络的行人检测方法, 包括两阶段、单阶段的行人检测方法以及相应的评价指标, 得出在实际监控场景中单阶段的行人检测方法更加合适的结论。最后以损失函数为切入点, 分别介绍了基于表征学习、基于度量学习的行人重识别方法以及行人重识别的评价指标。

第3章 引入注意力机制的行人检测方法

本章将详细介绍基于 YOLOv3 的行人检测方法，分析 YOLOv3 模型应用在行人检测上存在的问题。针对这些问题，提出在 YOLOv3 基础上引入注意力机制的行人检测模型，解决在监控场景下由于行人遮挡或行人尺寸过小导致 YOLOv3 方法在行人检测的过程中造成大量的漏检的问题，引入注意力机制后，将使得行人检测的过程中漏检率更低，识别率更高。同时由于加入了注意力模块导致模型体积变大参数量变多，于是将通过模型剪枝降低参数量，使得算法的检测速度进一步提高，满足实际监控场景下对于实时性的要求。

3.1 图像预处理

图像预处理在图像识别领域起到十分重要的作用，合适的预处理可以有效地提升模型的性能。其中，数据增强是检测算法中不可或缺的一项图像预处理操作。常用的数据增强方法有光度变换和几何变换两种。所谓光度变换，即调整图像的亮度、对比度、色调、饱和度和噪声，使原始图像有更丰富的色彩信息。几何变换，一般有随机缩放、剪切、翻转、旋转还有遮挡等方法。本章中解决的是由于行人遮挡导致的漏检率变高的问题，因此，通过对原始行人图像的部分区域进行随机遮挡，提高模型对于遮挡行人的学习能力，从而减少漏检。

3.2 YOLOv3 目标检测算法

行人检测算法作为目标检测的一个重要分支对实时性的要求较高，在众多的检测算法中，YOLOv3 算法不仅在检测速度方面达到监控场景下实时性的要求，同时算法的检测准确率也有不错的表现，因此本章所研究的行人检测方法在 YOLOv3 算法的基础上加以改进。

3.2.1 YOLOv3 网络结构

如图 3-1 所示，YOLOv3 的网络模型中包括用于特征提取的基础网络结构 Darknet-53 和实现三种不同尺度预测的三条分支 Y1、Y2、Y3。Darknet-53 中主要包括 3 个基础组件：DBL，res unit 还有 resn。

DBL: 如图 3-1 所示由 Conv+Bn+Leaky ReLU 激活函数三者组成。Conv 为卷积层; BN 为批标准化层, 用于将神经网络中的参数进行归一化, 可以加快模型收敛, 避免梯度爆炸或者梯度消失, 使得训练更加稳定; Leaky ReLU 激活函数为网络加入非线性因素, 增强模型的表达能力。

res unit: 其中包含 2 个 DBL, res unit 是一种残差结构, 通过构建这种短路连接使得网络即使构建的很深也依然不会出现梯度弥散或者梯度消失的问题。

resn: 由一个 DBL 和 n 个 res unit 组件构成, 是网络结构中的大组件。Darknet-53 网络依次包括 1 个 DBL, 1 个 res1, 1 个 res2, 2 个 res8, 1 个 res4。其中每个 res 模块前面的 DBL 由于卷积层的步长都为 2, 所以皆起到下采样的作用。




图 3-1 YOLOv3 网络结构图

3.2.2 边界框的预测

对于边界框的预测, YOLOv3 算法的基本思路是: 将输入的图片分成与网络提取的特征图大小相同的网格, 如果图片中某个行人的中心坐标位于哪个网格区域内, 则就由该网格来预测该行人。每个网格会预置 3 种不同宽高比的先验边界框, 最终由三个边界框中和标注的边界框的交并比最大的负责预测该行人。

YOLOv3 中边界框坐标(b_x, b_y, b_w, b_h)的预测方式采用如公式 3-1、3-2、3-3、3-4 所示:

$$b_x = \sigma(t_x) + c_x \tag{3-1}$$

$$b_y = \sigma(t_y) + c_y \tag{3-2}$$

$$b_w = p_w \times e^{t_w} \tag{3-3}$$

$$b_h = p_h \times e^{t_h} \tag{3-4}$$

其中, t_x, t_y, t_w, t_h 是网络的预测输出, σ 为 sigmoid 函数, 用来将 t_x 和 t_y 缩放到 $(0, 1)$ 之间。 c_x 和 c_y 表示在网格中的坐标, 如前所述, 若特征图尺寸为 13×13 , 网格的尺寸也为 13×13 , 那么第 0 行第 2 列的网格坐标 (c_x, c_y) 则为 $(0, 2)$ 。 p_w, p_h 则为边界框在输入图片中的大小。边界框坐标的损失采取的是平方和误差损失函数, 如式 3-5 所示:

$$L_{\text{box}} = \sum_{i=0}^{S^2} \sum_{j=0}^B I_{i,j}^{\text{obj}} (2 - w_i \times h_i) [(x_i - x_i^*)^2 + (y_i - y_i^*)^2 + (w_i - w_i^*)^2 + (h_i - h_i^*)^2] \quad (3-5)$$

其中, S 表示特征图网格的大小, B 表示一个网格内包含的预测边界框数量, $I_{i,j}^{\text{obj}}$ 表示如果在 (i, j) 处的边界框内有目标, 其值为 1, 否则为 0, w, h, x, y 表示标签中边界框的宽高和坐标, 带*号的则表示网络模型所预测边界框的宽高和坐标。

除了预测边界框的坐标信息外, YOLOv3 网络还会为每个生成的边界框预测一个对象得分。对象的得分通过逻辑回归函数得到, 当某个先验边界框和标注边界框的重叠区域大于其他的先验边界框时, 则这个先验边界框的对象得分为 1, 其他边界框的对象得分为 0。YOLOv3 网络只会对一个得分最高的先验边界框进行坐标预测, 而逻辑回归就是为了从众多的先验边界框中找到对象得分最高目标即存在可能性最大的那个。对象得分损失使用二进制交叉熵损失函数, 如式 3-6 所示:

$$L_{\text{obj}} = \sum_{i=0}^{S^2} \sum_{j=0}^B I_{i,j}^{\text{obj}} [C_i^* \log(C_i) + (1 - C_i^*) \log(1 - C_i)] - \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{i,j}^{\text{obj}} [C_i^* \log(C_i) + (1 - C_i^*) \log(1 - C_i)] \quad (3-6)$$

其中, C 表示标签的得分, 带*号表示网络预测的得分, λ_{noobj} 表示不包含目标的得分权重。

除了边界框的坐标信息和对象得分以外, 网络输出还需要预测边界框中对象是否属于行人。类别损失也使用二进制交叉熵损失函数, 如式 3-7 所示:

$$L_{\text{cls}} = \sum_{i=0}^{S^2} I_{i,j}^{\text{obj}} \sum_{c \in \text{class}} p_i^*(c) \log(p_i(c)) + (1 - p_i^*(c)) \log(1 - p_i(c)) \quad (3-7)$$

其中, $p_i^*(c)$ 表示网络预测类别的概率, $p_i(c)$ 表示标签中的真实概率。

因此最终得到 YOLOv3 的损失函数如式 3-8 所示:

$$L = L_{\text{box}} + L_{\text{obj}} + L_{\text{cls}} \quad (3-8)$$

3.3 引入注意力机制的 YOLOv3 检测算法

传统的卷积神经网络如 YOLOv3 一旦训练完成,卷积核参数固定,这对于行人尺度多变的监控画面来说,在行人检测过程中极易产生漏检。针对这些问题,本节提出在 YOLOv3 网络结构的基础上设计添加了针对卷积核的注意力机制模块 SKNet^[50]。通过注意力机制模块改变特征图中原始通道的卷积核权重,使得不同的图像能够得到具有不同重要性的卷积核,提高多尺度预测效果,从而提升小行人的检测效果,降低漏检率;同时使得被遮挡通道权重降低,未被遮挡通道权重提高,从而提高被遮挡行人的检测效果。

3.3.1 注意力机制

2014 年 google mind^[51]团队在图像分类领域引入了注意力机制并获得了巨大的成功,注意力机制因此被研究者们所重视。在计算机视觉领域,注意力机制的原理就是希望网络能够自动学习出图片中需要被关注的区域。比如人眼在看一幅画的时候,不会将注意力平等地分配给画中的所有像素,而是将更多注意力分配给所关注的地方。在本章的行人检测任务当中,则是通过设计对应的注意力模块,使得卷积网络的注意力集中在行人被遮挡和难以检测的小行人部分。

根据注意力所关注的域来划分,注意力机制主要可以分为:空间域、通道域以及混合域注意力机制。空间域的本质是将输入图片的空间信息转换到另一个空间,增强所关注的区域并弱化不相干的背景,使得模型对图片中感兴趣的空间区域能够更加关注。胡杰等人提出的通道域注意力模块 SENet^[27],则是通过特征通道重标定的方式,来自适应地调整不同通道之间的特征响应。之后 Woo 等人提出的卷积块注意模块^[52] (Convolutional Block Attention Module, CBAM),则是一种典型的混合域注意力模块,相比于只关注通道的注意力机制 SENet, CBAM 还增加了空间域的注意力,因此取得了更好的效果。

3.3.2 注意力模块

本节则针对卷积核构建注意力模块 SKNet,针对不同尺度的行人图像动态生成卷积核。SKNet 由分离、融合、选择三个操作组成。

分离操作如图 3-2 所示,对输入的特征图 x 进行多分支卷积操作,其中包括组卷积、批标准化、ReLU 激活函数。其中使用的三个不同的卷积核分别为 3×3 、 5×5 、 7×7 ,多分支卷积之后得到 U_1 , U_2 , U_3 三个特征图。




图 3-2 注意力模块结构图-分离

融合操作如图 3-3 所示，首先聚合多分支卷积得到的 U_1 、 U_2 、 U_3 ，如式 3-9 所示：

$$U = U_1 + U_2 + U_3 \quad (3-9)$$

U 中聚合了多个不同的感受野信息，得到了特征的全局信息。

为了获得每一个通道上的全局信息，接着对 U 进行自适应平均池化，如式 3-10 所示：

$$s_c = f_{sp}(U) = \frac{1}{H * W} \sum_{i=1}^H \sum_{j=1}^W U_c(i, j) \quad (3-10)$$

其中 H 表示特征图的高度， W 表示特征图的宽度， $U_c(i, j)$ 表示特征图的第 c 个通道中位置为 (i, j) 的特征点。经过自适应平均池化， s_c 获得了特征图中的全局信息。

之后对 s_c 做全连接操作，求得每一个通道占的比重大小，获得压缩特征 z ，如式 3-11 所示：

$$z = f_{fc}(s_c) = \delta(B(W * s_c)) \quad (3-11)$$

其中 f_{fc} 表示全连接层函数， δ 是 ReLU 函数， B 表示批标准化处理， W 是一个 $d \times C$ 维的向量。为了验证 W 中第一个特征维度 d 的作用，引入了一个衰减率 r ，如式 3-12 所示：

$$d = \max\left(\frac{C}{r}, L\right) \quad (3-12)$$

其中 C 代表通道数， L 设置为 32。最终获得的压缩特征 z 表示每一个通道占的比重大小。




图 3-3 注意力模块结构图-融合

选择操作如图 3-4 所示，先通过三个线性变换，将融合操作提取的压缩特征 z 变为原来的 C 维，完成了针对通道维度的信息提取，再通过 Softmax 函数进行归一化如式 3-13 所示：

$$a_c = \frac{e^{A_c z}}{e^{A_c z} + e^{B_c z} + e^{C_c z}}, b_c = \frac{e^{B_c z}}{e^{A_c z} + e^{B_c z} + e^{C_c z}}, c_c = \frac{e^{C_c z}}{e^{A_c z} + e^{B_c z} + e^{C_c z}} \quad (3-13)$$

其中 $A, B, C \in \mathbb{R}^{C \times d}$ ， A_c 表示 A 的第 c 行元素， B_c ， C_c 同理。这时候 a_c ， b_c ， c_c 分别代表其通道的重要程度，相当于一个掩码。然后将这三个掩码分别乘以对应的 U_1 、 U_2 、 U_3 ，再相加得到最终信息提炼后的特征图 V ，如式 3-14 所示：

$$V = a_c U_1 + b_c U_2 + c_c U_3 \quad (3-14)$$




图 3-4 注意力模块结构图-选择

最终模块 V 相比于最初的特征图 X 经过了信息的提炼，融合了多个感受野的信息，自动学习到了不同特征通道和不同卷积核的重要程度。

最终引入注意力机制的行人检测算法模型网络结构如图 3-5 所示：




图 3-5 引入注意力机制的网络结构图

3.3.3 模型剪枝

注意力模块的引入会让模型增加不少参数量，因此通过模型剪枝技术减小模型的大小和参数量，降低模型在运行时的内存占用和耗时，使得模型在资源有限的移动设备上部署成为可能。

稀疏化一般可以分为权重、卷积核、通道、层级别这四种不同级别实现。在本节中，引入的是一种通道级稀疏化的剪枝方法。相较而言，通道级稀疏化平衡了灵活性和实现复杂度，使得普适于各种典型的 CNN 网络且易于实现。通道级稀疏化的实现方法是通过对每个通道都引入一个缩放因子 γ ，然后对网络中的参数和缩放因子进行联合训练。对训练得到的缩放因子较小的通道进行修剪，之后再对修剪后的网络进行微调。整体的流程如图 3-6 所示：




图 3-6 模型剪枝流程图

在训练的过程中，模型剪枝的目标函数定义为如式 3-15 所示：

$$L = \sum_{(x,y)} l(f(x,W),y) + \lambda \sum_{\gamma \in \Gamma} g(\gamma) \tag{3-15}$$

其中，第一项为未修剪网络的原始损失函数，第二项为缩放因子的惩罚项，在这里，让函数 $g(\gamma) = |\gamma|$ 即使用 L1 范数来进行稀疏化， λ 则作为平衡因子。

图 3-7 所示为初始网络，图 3-8 为经过通道剪枝后的网络，由图可知模型进行通道剪枝的本质就是删除与该通道相连接的输入输出，让通道缩放因子和每个卷积层联系起来。在训练过程中对这些比例因子进行稀疏化正则化，以自动识别不重要的通道，最终具有比较小的缩放因子的通道则会被修剪。




图 3-7 原始卷积网络




图 3-8 剪枝后的网络

3.4 实验基本设置

3.4.1 实验环境

本章实验所处硬件环境: CPU 为 Intel(R) Xeon(R) Silver 4210 CPU @ 2.20GHz, 内存大小 944G, 显卡为 GeForce RTX 2080Ti, 显存大小 11G。软件环境: 操作系统为 Ubuntu16.04, 深度学习框架为 PyTorch1.7.0。

3.4.2 实验数据集

本章所用的数据来自 The Caltech Pedestrian Dataset^[44]和目标检测领域经典挑战赛 Pascal VOC 在 2007 年公开的数据集, 以下简称 Pascal VOC 2007。The Caltech Pedestrian Dataset 是由加州理工学院所作, 数据集中共包含 250000 帧的图片。对于视频中的每一帧图片, 如图 3-9 所示, 包含有行人的绿色方框表示整个行人的完整范围, 对于被遮挡的行人, 虚线黄色方框表示被遮挡行人的可见区域。





图 3-9 Caltech 数据集示例图像和标注

Caltech 数据集以 seq 和 vbb 的格式对应数据集图片和相应的标注。seq 格式文件是由一系列具有固定大小头的串联图像帧组成的视频文件，vbb 格式则是使用自定义的方式对视频文件进行边框标注。实验过程中，训练集由 70 个 seq 文件组成；测试数据则由 66 个 seq 组成。需要注意的是，在实验中，需要将 seq 文件转换为标准的数据格式图片，再将 vbb 格式生成对应的.xml 标注文件。

由于 Caltech 数据集中的图片为城市道路中的场景，而 Pascal VOC 2007 中的图片场景丰富多彩，因此为了提升模型在不同场景下的泛化能力，采用 Pascal VOC 2007 为辅助数据集。数据集中的数据分为四个大类 vehicle、household、animal、person。由于本论文中的任务是检测行人，因此从数据集中提取包含行人的图片作为正例，随机抽取一些其他类别图片作为负例，在本章实验中共抽选 4510 张图片作为训练集，1127 张图片作为测试集。Pascal VOC 2007 的图片如图 3-13 所示：



(a) 图片大小为 336×500



(b) 图片大小为 500×375


图 3-10 Pascal VOC 2007 示例图片

3.4.3 模型训练设置

(1) 图像预处理

在网络模型开始训练之前,对加载的行人图片进行预处理可以更好地学习行人特征,增强模型的鲁棒性。具体操作如下:1.在 HSV 空间上对图片进行变换,改变原始图片的色调、饱和度、亮度,丰富图片的色彩信息;2.以二分之一的概率对图片进行左右翻转;3.以二分之一的概率对图片进行上下翻转。最后裁剪为固定尺寸的图片,同时根据裁剪的坐标,将原始标签中的坐标进行相应的转换,获得裁剪后的位置坐标。

此外,由 3.2.1 节可知 YOLOv3 网络模型会对输入图片进行下采样 32 倍,因此,要求输入的图片宽高必须是 32 的倍数,而由于 Pascal VOC 2007 数据集中图片尺寸大小不一,所以在进入模型前,图片的宽高要处理到固定的 32 倍整数大小的正方形,这个过程称为仿射变换。如图 3-11 所示,经过仿射变换之后的图片与图 3-10 相比,新增了黑色阴影部分,这部分区域会让网络在训练的过程中产生大量无意义的候选框。因此在 Pascal VOC 2007 数据集训练过程中,采用矩形训练的方法减缓这种现象。矩形训练的思路是通过计算图片的长和宽的较大值缩放到 512 的比值,然后对整张图片按照这个比例进行缩放,最后再对短边进行较少填充,使其满足 32 的倍数。如图 3-12 所示,与图 3-11 相比,经过矩形训练的处理,在满足 YOLOv3 对输入图片大小要求的情况下,图片中的黑色阴影部分明显减少。经过实验证明,由于减少了输入图片的冗余信息,抑制了训练过程中无意义的候选框的生成,最终训练时间能够比不使用矩形训练方法快 1/4。



(a) 图片大小为 512×512



(b) 图片大小为 512×512

图 3-11 仿射变换示例




图 3-12 矩形训练示意图

(2) 模型参数设置

在对基础网络 YOLOv3 网络进行训练时，使用在 ImageNet 上训练效果最好的 darknet53.conv.74 为预训练模型，并使用随机梯度下降（Stochastic Gradient Descent, SGD）和动量梯度下降（Gradient Descent with Momentum, Momentum）相结合的优化算法学习 YOLOv3 各层相关参数，具体设置如表 3.1 所示。

表 3.1 YOLOv3 网络训练设置

参数	设置
训练周期	200
批训练量	16 张
优化算法	SGD+ Momentum
Momentum	0.937
初始学习率	$5e^{-3}$
终止学习率	$5e^{-4}$
预训练采用模型	darknet53.conv.74

在对引入注意力机制的 YOLOv3-SKNet 网络进行训练时，仍然使用在 ImageNet 上训练效果最好的 darknet53.conv.74 为预训练模型，并使用 SGD 和 Momentum 相结合的优化算法学习网络各层相关参数，具体设置如表 3.2 所示。

表 3.2 YOLOv3-SKNet 网络训练设置

参数	设置
训练周期	100
批训练量	32 张
优化算法	SGD+ Momentum
Momentum	0.937
初始学习率	$5e^{-3}$
终止学习率	$2e^{-3}$
缩放因子阈值	0.001
预训练采用模型	darknet53.conv.74

在引入注意力机制的 YOLOv3-SKNet 网络达到理想精度后,使用效果最好的 YOLOv3-SKNet 作为预训练模型再进行稀疏训练,并使用 SGD 和 Momentum 相结合的优化算法学习各层相关参数,具体设置如表 3.3 所示。

表 3.3 模型剪枝的 YOLOV3-SKNet 网络训练设置

参数	设置
训练周期	200
批训练量	32 张
优化算法	SGD+ Momentum
Momentum	0.937
初始学习率	$2e^{-3}$
终止学习率	$5e^{-4}$
预训练采用模型	YOLOv3-SKNet best model

此外为了验证不同注意力机制模块的作用,使用了引入 SENet^[27], CBAM^[64] 模块的注意力机制作为对比实验,实验参数设置均与 YOLOv3-SKnet 相同。

3.5 实验结果及分析

实验阶段，在 Caltech 数据集上选取 7 种具有代表性的行人检测算法进行测试，并以 MR-FPPI 曲线和 MR^{-2} 作为模型优劣的评价指标，结果如图 3-13 所示：




图 3-13 行人检测算法性能比较图

其中使用 Haar 特征的 VJ^[16]和 HOG 特征的 HOG^[15]作为传统的行人检测方法，平均漏检率较高，明显无法在实际应用场景中使用。Deep Cascade^[72]、TA-CNN^[73]、YOLOv3^[25]和 FasterRCNN+ATT^[21]是基于卷积神经网络的深度学习行人检测方法。Deep Cascade 是一种使用深度卷积神经网络分类器的级联结构网络，为了提高检测速度，减少了卷积层的深度，缩小了感受野的大小，平均漏检率 MR^{-2} 为 25%；TA-CNN 通过语义信息协助进行行人检测， MR^{-2} 为 16%。从图 3-13 中可以看出在 FPPI 值较小时，YOLOv3 的漏检率比其他几种深度学习方法更高。由 2.2.3 节可知，FPPI 值较小对应检测阈值设定较高的部分，由于 Caltech 数据集中存在大量的小行人图片，当检测阈值设定较高时，检测到的置信度较低的行人极易被过滤，因此从图 3-13 中可以看出 YOLOv3 对小行人的检测效果不佳。当检测阈值变低之后，YOLOv3 性能明显提高，最终对数平均漏检率 MR^{-2} 为 12%；FasterRCNN+ATT 的方法是两阶段检测器的代表作， MR^{-2} 为 7% 最低。

为了验证本文提出的方法 YOLOv3-SKNet 的有效性，以 YOLOv3 为基准线方法，通过对比多种主流的注意力机制方法，实验结果如图 3-14 所示。




图 3-14 注意力机制效果对比图

从图中可以看出引入通道域注意力机制的 YOLOv3-SENet、引入混合域注意力机制的 YOLOv3-CBAM 以及本文提出的引入 SKNet 的 YOLOv3-SKNet 都可以在一定程度上降低漏检率。其中 YOLOv3-SENet 通过通道注意力机制进行特征重标定，增强了行人被遮挡部分的特征，因此比基准线方法 YOLOv3 平均漏检率 MR^{-2} 降低 0.39%，YOLOv3-CBAM 通过在通道域注意力的基础上增加了空间域注意力，比基准线方法 YOLOv3 平均漏检率 MR^{-2} 降低 0.88%。本章所提出的 YOLOv3-SKNet 方法在通道域注意力的基础上设置了 3 个卷积核来应对不同尺度行人，提高了小行人检测效果，比基准线方法 YOLOv3 平均漏检率 MR^{-2} 降低 1.81%。不同行人检测算法在 Caltech 数据集上的定性分析结果如图 3-15 和图 3-16 所示：



图 3-15 YOLOv3 算法在 Caltech 数据集检测结果示例图



图 3-16 YOLOv3-SKNet 算法在 Caltech 数据集检测结果示例图

由图 3-15 和 3-16 可以看出本章提出的 YOLOv3-SKNet 方法可以明显改进 YOLOv3 算法因行人被干扰背景遮挡或行人尺寸过小导致的漏检问题。

为了验证模型剪枝的有效性，将本章所提出的方法在 Caltech 数据集上训练达到理想精度后再进行稀疏训练和模型剪枝，比较了一下模型剪枝前后的指标，如表 3-4 所示：

表 3-4 剪枝前后模型对比				
	参数量	模型体积	前向时间	Person 类 AP50
YOLOv3	61.5M	246.4MB	25.0ms	92.5%
YOLOv3-SKNet	76.9M	293.7MB	28.0ms	92.9%
YOLOv3-SKNet 剪枝后	11.4M	47.8MB	11.5ms	92.7%

其中 AP50 表示在检测过程中交并比阈值设定为 0.5 时的行人检测准确率。可以看出引入 SKNet 之后行人检测的准确率提高了 0.4%，但是模型的参数量增加了 15.4M 和模型大小增大了 47.3MB，网络的前向时间也增加了 3.0ms。而经过模型剪枝后在行人检测的准确率降低了 0.2%的情况下，模型的参数量和体积大小变为了剪枝前的六分之一，以及前向时间缩小了一半，模型剪枝的效果十分显著。

为了测试本文提出的算法在实际应用场景中的实时性，对本文提出的方法和主流行人检测方法在测试阶段的帧率比较如表 3-5 所示：

表 3-5 YOLOv3-SKNet 与其他方法的帧率对比

方法	GPU/CPU	帧率(帧/秒)	检测效率(秒/帧)
HOG	CPU	0.216	4.630
FasterRCNN+ATT	GPU	12.812	0.078
YOLOv3	GPU	40.000	0.025
YOLOv3-SENet	GPU	37.037	0.027
YOLOv3-CBAM	GPU	38.461	0.026
YOLOv3-SKNet	GPU	35.714	0.028
YOLOv3-SKNet 剪枝后	GPU	90.909	0.011

HOG 方法作为传统算法的代表，在使用 CPU 的情况下，帧率只有 0.216，明显无法达到实时检测的效果。FasterRCNN+ATT 相较于传统方法帧率明显提升，但是距离实时性仍有一定差距。YOLOv3 的帧率能达到 40 帧每秒。YOLOv3-SENet、YOLOv3-CBAM 以及本章提出的 YOLOv3-SKNet，由于引入的注意力模块，增加了部分参数量，因此帧率有所下降。但经过模型剪枝的操作后，帧率比基准方法 YOLOv3 有明显提升，达到了 90 帧每秒的运行速度，进一步满足了实时性的要求。

为了验证本章所提出的方法 YOLOv3-SKNet 在不同场景下的泛化能力，将 YOLOv3-SKNet 与基准方法 YOLOv3 在辅助数据集 Pascal VOC 2007 上训练，以 Person 类 AP50 作为评价标准，结果如表 3-6 所示：

表 3-6 Pascal VOC 2007 检测结果对比表

方法	主干网络	Person 类 AP50
YOLOv3	Darknet-53	82.3
YOLOv3-SENet	Darknet-53-SENet	83.3
YOLOv3-CBAM	Darknet-53-CBAM	83.7
YOLOv3-SKNet(ours)	Darknet-53-SKNet	83.4

由表 3-6 可知本章提出的方法比基准线方法 YOLOv3 在 Pascal VOC 2007 Person 类上的 AP50 要高 1.1%，YOLOv3-SENet 比基准线方法高出 1%，引入 YOLOv3-CBAM 比基准线方法在行人类上的平均精度提升了 1.4%，进一步验证了注意力机制的作用。

3.6 本章小结

本章首先介绍了 YOLOv3 检测算法的网络结构以及检测框的预测原理，分析了 YOLOv3 应用到行人检测时容易出现的问题。针对这些问题，提出在 YOLOv3 的基础上添加了注意力模块 SKNet，并且对添加后的网络结构进行模型剪枝减少参数量。实验阶段，在 Caltech 数据集上选取具有代表性的 7 种行人检测算法进行评价分析，结果表明 YOLOv3 作为基准方法在实时性和有效性上都满足条件，但依然存在不足。为了验证本章提出方法 YOLOv3-SKNet 的有效性，在 YOLOv3 的基础上，对比三种主流的注意力机制方法。实验结果表明，本章提出的 YOLOv3-SKNet 在基准线的基础上 MR^{-2} 提高 1.81%，且经过模型剪枝后的 YOLOv3-SKNet 在几乎不影响精度的情况下模型的参数量和体积大小变为了剪枝前的六分之一，且前向时间缩小了一半。最后为了验证本章提出方法在不同场景下的泛化能力，在辅助数据集 Pascal VOC 2007 上进行实验，结果表明，本章提出的方法比基准线的平均精度有明显提升。

第4章 融合组合损失的行人重识别方法

本章将分析行人重识别领域常用的各种损失函数,并在此基础上进行改进组合,以提高模型的泛化能力和性能。在分析边界样本挖掘损失后,为了进一步提高网络模型的泛化能力,改进边界样本挖掘损失,在原有损失的基础上新增类内约束项,压缩同类特征间距离,使得同类特征的分布更为紧凑。同时考虑到,由于边界样本挖掘损失在每个训练批次中挑选的是最困难的样本,为了让一个训练批次内的所有样本标签信息都利用到,通过引入余弦交叉熵损失辅助参与网络训练。合理利用两种损失,有效提高网络特征提取能力,从而改善网络性能。

4.1 行人重识别损失函数

行人重识别损失有基于表征学习的有交叉熵损失,余弦交叉熵损失等,基于度量学习的有三元组损失、难样本采样三元组损失等,本节将对比不同损失函数的性能优劣。

4.1.1 交叉熵损失

由 2.1.2 节可知,使用神经网络模型解决分类问题时,通常在网络的最后一层设置 n 个输出节点,即网络的输出为 n 维向量, n 为分类任务的目标数。由于输入图片特征经过网络后得到的 n 维向量中每个维度的值 y_i 可以是任意大小的,经过 Softmax 函数如式 4-1 的归一化处理后 y_i' 被归一化为 (0,1) 之间的概率值。

$$y_i' = \text{Softmax}(y_i) = \frac{e^{y_i}}{\sum_{j=1}^n e^{y_j}} \quad (4-1)$$

$$y_i = W_{y_i}^T * x_i + b_{y_i} \quad (4-2)$$

其中 y_i 表示全连接层输出的 n 维向量中的第 i 个元素, y_i 可由式 4-2 所得, W , b 表示全连接层的权重和偏置,最终经过归一化处理所得的 y_i' 在 n 维概率值之和为 1。

将式 4-2 代入式 4-1 再代入交叉熵的公式,最终获得常用的交叉熵损失公式如式 4-3 所示:

$$L = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{W_{y_i}^T x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j^T x_i + b_j}} \quad (4-3)$$

其中, N 表示训练过程中一个批次的样本数, n 表示输出的类别个数, W , b 表示全连接层的权重和偏置, x_i 表示全连接层的输入。

在交叉熵损失的约束下, 行人重识别网络就能分离异类特征, 这符合行人重识别对特征空间维度分布要求。在部分行人重识别任务中, 一些学者^[53]采用交叉熵损失直接对网络进行训练, 并取得了良好的效果。

4.1.2 余弦交叉熵损失

由于交叉熵损失学习到的特征可辨性不足, 嵌入余弦角度的交叉熵损失被提出^[54]。嵌入余弦角度的交叉熵损失通过在 Softmax 函数中嵌入 m 倍的角度约束, 并且对全连接层的权重 W 和偏置 b 添加了 $\|W\|=1$ 和 $b=0$ 的限制, 这样 Softmax 的分类过程仅仅依赖于权重 W 和全连接层的输入 x_i 之间的夹角。并且受嵌入 m 倍的角度约束, 因此可以获得更大的角度裕度, 分类效果更好。具体推导过程如下:

由向量相乘法可知, 公式 4-3 可以改写为如式 4-4 所示

$$L = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\|W_{y_i}\| \|x_i\| \cos(\theta_{y_i,i}) + b_{y_i}}}{\sum_{j=1}^n e^{\|W_j\| \|x_i\| \cos(\theta_{j,i}) + b_j}} \quad (4-4)$$

其中, $\theta_{j,i} \in [0, \pi]$ 是权重 W 和输入 x_i 之间的夹角, 通过归一化 $\|W\|=1$, 将偏置 b 置为零, 得到修正后的交叉熵损失如式 4-5 所示:

$$L_{\text{modified}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\|x_i\| \cos(\theta_{y_i,i})}}{\sum_{j=1}^n e^{\|x_i\| \cos(\theta_{j,i})}} \quad (4-5)$$

由式 4-5 可知, 在二分类问题中, L_{modified} 约束的决策面是 $\cos(\theta_1) = \cos(\theta_2)$, 其中 θ_i 表示权重 W 和输入 x_i 之间的夹角。 L_{modified} 学习到的特征呈现角度分布, 但是可判别性依然不足, 因此通过引入一个整数 m ($m \in N$ 且 $m \geq 2$) 作为角度裕度, 如式 4-6 所示:

$$L_{\text{A-softmax}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\|x_i\| \cos(m\theta_{y_i,i})}}{\sum_{j \neq y_i} e^{\|x_i\| \cos(\theta_{j,i})} + e^{\|x_i\| \cos(m\theta_{y_i,i})}} \quad (4-6)$$

此时类别 1 的决策面为 $\cos(m\theta_1) = \cos(\theta_2)$ ，类别 2 的决策面则为 $\cos(\theta_1) = \cos(m\theta_2)$ ，类别 1 的决策面被压缩成原来的 m 分之一，类别 2 同理。比式 4-5 约束的决策面要求更高，因此网络学习到的决策面分类效果更佳。

由于引入了 m ， $\theta_{y_i,i}$ 的取值限制在 $[0, \pi/m]$ ，为了摆脱 $\theta_{y_i,i}$ 的取值限制，使其在网络中得到优化，并且满足原有的单调性，通过在式 4-6 中引入 $\psi(\theta_{y_i,i})$ 来泛化 $\cos(m\theta_{y_i,i})$ ， $\psi(\theta_{y_i,i})$ 如式 4-7 所示：

$$\psi(\theta_{y_i,i}) = (-1)^k \cos(m\theta_{y_i,i}) - 2k \tag{4-7}$$

其中 $\theta_{y_i,i} \in [\frac{k\pi}{m}, \frac{(k+1)\pi}{m}]$, $k \in [0, m-1]$ 。此时式 4-6 可改写为如式 4-8 所示：

$$L_{A-\text{softmax}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\|x_i\|^* \psi(\theta_{y_i,i})}}{\sum_{j \neq y_i} e^{\|x_i\|^* \cos(\theta_{j,i})} + e^{\|x_i\|^* \psi(\theta_{y_i,i})}} \tag{4-8}$$

在 $L_{A-\text{softmax}}$ 的约束下，网络的分类仅依赖于权重 W 和全连接层的输入 x_i 之间的夹角；且通过添加的参数 m ，模型所学得的特征获得了更大的角度裕度，分类边界更加明显，分类能力更强。在本章的实验中设置 $m=4$ 。

上述推导过程有清晰的几何解释，在 CASIA^[55] 人脸数据集上对这三种损失所约束的特征进行可视化比较，如图 4-1 所示：




图 4-1 三种交叉熵损失对比图^[66]

其中黄色点代表类别 1 的特征，紫色点代表类别 2 的特征。可以看出，通过原始交叉熵损失函数学习到的特征不能简单地通过角度进行分类，而通过修改后的交叉熵损失可以进行分类，但是分类边界较窄。而余弦交叉熵损失约束的特征，分类边界较宽。更进一步地，将特征映射到球面如图 4-2 所示：




图 4-2 三种交叉熵损失映射到球面对比图^[66]

由图 4-2 (b)和(c)可以看出，引入角度裕度 m 后，经过余弦交叉熵损失约束的类别 1 类内角度被压缩至原来的 m 分之一，类别 2 的类内角度同样被压缩，使得类别 1 和类别 2 的分类边界变得非常宽阔，分类变得更加简单。

4.1.3 三元组损失

与基于表征学习的损失不同，基于三元组损失的行人重识别方法在训练的过程中以三张不同的图片 $\{A, A', B\}$ 作为一个三元组。其中 A, A' 属于同一个人的不同图片，称为一对正样本对； A, B 属于不同的人，称为一对负样本对。三元组损失表示为如式 4-9：

$$L_{\text{trip}} = \frac{1}{N} \sum (d_{A,A'} - d_{A,B} + \alpha)_+ \tag{4-9}$$

其中 $d_{A,A'} = \|f_A - f_{A'}\|_2$ ， $d_{A,B} = \|f_A - f_B\|_2$ ， f 表示图片经过网络模型提取出的特征， α 是正负样本对之间的阈值， $(z)_+ = \max(z, 0)$ 。式 4-9 的第一项拉近正样本对的距离，第二项推开负样本对的距离，因此在三元组损失的约束下，属于同一行人的图片进行聚类，达到行人重识别的目的。

由于三元组损失在训练集上对输入图片顺序有很高的要求，因此模型从训练集到测试集上的泛化能力很弱，导致性能较差。因此 Chen 等人提出了四元组损失，如式 4-10 所示，在第二项的约束下，类间距离会大于类内距离，因此模型的输出会具有更大的类间差异和更小的类内差异，具有更好的泛化能力。

$$L_{\text{quad}} = \frac{1}{N} \sum (d_{A,A'} - d_{A,B} + \alpha)_+ + \frac{1}{N} \sum (d_{A,A'} - d_{C,B} + \beta)_+ \tag{4-10}$$

忽视 α 和 β 参数的影响，四元组损失如式 4-11 所示：

$$L_{\text{quad}} = \frac{1}{N} \sum (d_{A,A'} - d_{C,B} + \alpha)_+ \tag{4-11}$$

其中 C 和 A 可以是同一个行人 ID 的图片。由式 4-10 可知，四元组损失的第一项和三元组损失是一样的，让同一张图片的正负样本对相对距离尽可能远。值得一

提的是,四元组损失第二项中的两个距离不共享同一个行人,所以对正负样本间的绝对距离也进行了约束。

4.1.4 难样本采样三元组损失

4.1.3节介绍的度量学习方法在计算度量损失时,随着训练集图片量的增大,将导致三元组四元组图片组合数量急剧上升,而其中的样本对大多都是比较简单的,尤其是负样本对,其数目远大于正样本对。尽管设定了阈值 α 来限制正负样本对的距离,但是大量的简单样本会使得网络难以训练且会使得网络的泛化能力受限。因此,需要从大量的样本中挑选出困难的样本对来训练网络。在每次挑选出的样本集中,找出特征向量距离最大的正样本对和特征向量距离最小的负样本对来训练网络。难样本采样三元组损失如式 4-12 所示:

$$L_{\text{triHard}} = \frac{1}{N} \sum_{A \in \text{batch}} (\max(d_{A,A'}) - \min(d_{A,B}) + \alpha)_+ \quad (4-12)$$

其中 N 是一个批次(batch)中的图片个数, $N=P \times K$, P 表示一个batch中包含 P 个行人, K 表示从每个行人随机挑选 K 张不同的图片。 α 是正样本对和负样本对之间的阈值。通过困难样本采样,简单样本被过滤,加快网络的收敛,提高网络的鲁棒性,明显改进了度量学习方法的性能,是目前广泛采用的一种技术。

4.1.5 边界样本挖掘损失

边界样本挖掘损失(Margin Sample Mining Loss, MSML)^[57]结合了 4.1.3 节中介绍的三元组损失和四元组损失的优点,在考虑正负样本对绝对距离的同时,还采取了难样本采样的策略,MSML 的公式如式 4-13 所示:

$$L_{\text{MSML}} = (\max(d_{A,A'}) - \min(d_{C,B}) + \alpha)_+ \quad (4-13)$$

其中 α 是正样本对和负样本对之间的阈值, A, A', C, B 均是同一批次中的图片, A, A' 是一个批次中距离最大的正样本对, C, B 是一个批次中距离最小的负样本对。总的来说,如图 4-3 所示,MSML 在三元组损失的基础上新增了绝对距离,并且采用了难样本采样思想的度量学习损失。




图 4-3 MSML 演变思想图

4.2 组合损失设计

4.2.1 改进的边界样本挖掘损失

使用边界样本挖掘损失虽然引入了绝对距离，一定程度上增加了样本之间的聚类性能，增强了类内紧凑性，但依然会有少数样本偏离了本类的中心，与其他类别的特征产生重叠，这对行人重识别任务来说是不利的。对于行人重识别任务而言，提升网络泛化能力的关键是尽可能缩小同类特征的距离、增大不同类特征的距离。因此为了更好提升网络泛化能力，在原有的边界样本挖掘损失上新增了中心损失^[58]（Center loss）约束项，弥补了边界样本挖掘损失的不足，使得相同类别的特征类内分布更为紧凑。改进后的边界样本挖掘损失定义如式 4-15 所示：

$$L_{MSML_Center} = (\max(d_{A,A'}) - \min(d_{C,B}) + \alpha)_+ + \beta \frac{1}{2} \sum_{j=1}^N \|f_{I_j} - c_{y_j}\|_2^2 \quad (4-15)$$

其中 N 是一个 batch 中的行人图片个数， α 是区分正样本对和负样本对的阈值， y_j 是这个 batch 内第 j 张图片的标签， c_{y_j} 表示样本 j 所对应的类别的所有样本特征的平均特征， β 是边界样本挖掘损失和中心损失的平衡权重。在本章的实验中，设置 $\alpha=0.3$ ， $\beta=0.0005$ 。

在 MNIST 数据集上分别使用边界样本挖掘损失和改进的边界样本挖掘损失进行训练，将特征进行可视化结果如图 4-4 所示：




图 4-4 两种损失在 MNIST 数据集上特征分布图

图 4-4 中每种颜色的点分别代表一个类别，从特征的分布情况可知，本节所提出的损失在 MSML 的基础上进一步压缩了类内特征距离。

4.2.2 融合余弦交叉熵的改进边界样本挖掘损失

4.1 节中介绍了行人重识别领域中的常用损失函数。基于表征学习的余弦交叉熵损失没有将不同样本对的相似性考虑在内，只是学习到类间分离性而不要求类内紧凑性。4.2.1 节提出的基于度量学习的改进边界样本挖掘损失，增强了特征在欧式空间内的类内紧凑度，但需要对样本对进行困难样本采样挖掘，增加了训练的时间。

本节将 4.1.2 中的余弦交叉熵损失与 4.2.1 节中的改进边界样本挖掘损失进行组合，共同约束卷积神经网络。余弦交叉熵损失具有很好的异类特征分离能力，但其缺点在于类内特征紧凑性不足，类内特征分布较为分散。改进边界样本挖掘损失函数的优点在于类内约束较强，具有很好的类内聚合能力，而缺点在于每个批次的训练中都选择最困难样本参与训练，实际训练过程中网络收敛较困难。组合损失函数则既可以改善余弦交叉熵损失类内特征紧凑性不足的缺点，又能通过余弦交叉熵损失辅助改进边界样本挖掘损失快速收敛；其次，改进边界样本挖掘损失在训练过程中选择难样本训练忽略了某些简单样本，未能完全利用训练集中所有行人图片的标签信息，而余弦交叉熵损失会让所有样本都参与到训练中。综上所述，这两类损失在不同场景中，各有利弊，组合损失函数使得两种损失之间进行互补，提升网络特征提取能力，改善网络性能，加快网络训练。组合损失函数 L 可以定义如式 4-16 所示：

$$L = L_{\text{MSML_Center}} + L_{\text{A-Softmax}} \tag{4-16}$$

4.3 组合损失网络结构

4.2 节中提出了将分类损失和改进边界样本挖掘损失结合的组合损失函数，这种方法可以使模型学习到更具判别性的特征。然而，分类损失优化的是余弦距离，改进的边界样本挖掘损失优化的是欧几里得距离，如果使用这两个损失来同时优化网络，则它们的目标可能不一致。在训练过程中，一种可能的现象是一种损失减少了，而另一种损失正在振荡甚至增加，模型变得难以收敛。

为了克服上述问题，Hao Luo 等人^[59]设计了 BNNeck 的结构，如图 4-5 所示。在基础网络提取特征之后，连接全连接层之前，添加一个批处理归一化（Batch Normalization, BN）层。让 BN 层之前的特征表示为 f_t 。 f_t 经过 BN 层将获取归一化后的特征 f_i 。经过特征提取网络得到的 f_t 是在欧式空间里的，而经过归一化操作后 f_i 的各个维度的值获得平衡，最后近似地在超球面附近呈现高斯分布，这种分布使分类损失更易于收敛。因此，在训练阶段， f_i 直接用于计算边界样本挖掘损失， f_t 则用于计算分类损失。另外，由于 BNNeck 的存在降低了分类损失对 f_t 的约束，导致边界样本挖掘损失和分类损失更易于同时收敛。此外，用于分类的全连接层的偏置全部置零，这样可以保证分类的超平面一定经过原点。因为特征也是关于原点对称分布的。在测试阶段，只选择 f_i 来进行行人重识别任务。因为余弦距离度量的表现比欧几里得距离度量更好。




图 4-5 BNNeck 结构示意图

引入 BNNeck 结构的行人重识别网络结构如图 4-6 所示：




图 4-6 行人重识别网络结构图

在训练集中随机抽样 P 个行人，每个行人抽取 K 张图片组成一个训练批次，使用 ImageNet 上的预训练参数初始化特征提取网络 ResNet50，之后将提取出的特征进行全局平均池化，得到特征 f_t 用来计算改进的边界样本挖掘损失，将特征 f_t 经过 BN 层的处理获取归一化后的特征 f_i ， f_i 则用于计算分类损失。

4.4 实验基本设置

4.4.1 实验环境

本章实验所处硬件环境：CPU 为 Intel(R) Xeon(R) Silver 4210 CPU @ 2.20GHz，内存大小 944G，显卡为 GeForce RTX 2080Ti，显存大小 11G。软件环境：操作系统为 Ubuntu16.04，深度学习框架为 PyTorch1.7.0。

4.4.2 实验数据集

本章所用数据集来自 Market-1501^[60]和 DukeMTMC-reID^[61]。Market-1501 数据集中共包含 1501 个行人，其中标注的行人图像共 32668 张。其中训练集 12936 张图片，测试集 19732 张图片。再从中抽选 3368 张图片作为行人重识别任务的查询图像（query），而剩下的图片作为查询库（gallery）。

如图 4-7 所示，第一行展示的是三个具有不同身份的行人样本图像，外观差距较大。第二行展示的是三个具有不同身份的行人样本图像，但这三个人有着非常相似的外貌。第三行提供了一些干扰图像（左）和垃圾图像（右）的样本，用来增强模型的鲁棒性。




图 4-7 Market-1501 数据集图像样本^[72]

DukeMTMC-reID 数据集共包含 1404 个人的 36411 张图像。其中训练集包含 16522 张训练图像（来自 702 个人）。此外，抽取来自另外 702 个人的 2228 张图像作为查询集，剩下的 17661 张图像作为查询库。如图 4-8 和 4-9 所示为 DukeMTMC-reID 的部分样本示例，其中图 4-8 为数据集中的简单训练样本，图 4-9 为带有行人遮挡的困难训练样本。



图 4-8 DukeMTMC-reID 数据集简单训练样本示例



图 4-9 DukeMTMC-reID 数据集困难训练样本示例

4.4.3 模型训练设置

(1) 数据增强——随机擦除增强（Random Erasing Augmentation, REA）

在行人重识别任务中，摄像头下的行人经常会被其他物体遮挡。为了解决遮挡问题提高模型的泛化能力，在本章的实验中采用 REA 的数据增强方法。对于

一个训练批次中的图片 I ，设定对其进行随机擦除的概率为 P_e ，然后 REA 操作会在大小为 $S=W\times H$ 的图像 I 中随机选择一个大小为 $S_e=W_e\times H_e$ 的矩形框 I_e ，并使用整张图片的平均像素值来替换矩形框内的原本像素值。将擦除比定义为 $r_e=S_e/S$ ，擦除比会在 (r_1,r_2) 之间进行随机初始化。REA 先是随机初始化一个点 $P=(x_e,y_e)$ ，如果 $x_e+W_e\leq W$ 且 $y_e+H_e\leq H$ ，则选中区域 $(x_e,y_e,x_e+W_e,y_e+H_e)$ 为随机擦除的区域，否则重复上述步骤，原始图片和经过随机擦除后的图片对比如图 4-10 所示：



图 4-10 随机擦除增强示例

在本章的实验中，设置相关的超参数分别为 $P_e=0.5$ ， $0.02\leq S_e\leq 0.4$ ， $r_1=0.3$ ， $r_2=3.33$ 。

(2) 学习率优化——预热学习率

普通的训练过程采用的是阶梯下降型学习率，即开始学习率比较大，随后逐渐减小以找到模型的最优点。由于训练初期模型权重是随机初始化的，若采用较大学习率会导致模型震荡，因此使用一种预热策略来进行训练，引导网络获得更好的性能。具体策略是在模型训练初期让学习率进行线性增长，等模型慢慢趋于稳定，再使用预设的学习率进行训练，最终模型的收敛速度将会更快，效果更佳。

在本章当中，采用如式 4-17 所示的训练策略：

$$lr(t)=\begin{cases} 3.5\times 10^{-5}\times t & t\leq 10 \\ 3.5\times 10^{-4} & 10<t\leq 40 \\ 3.5\times 10^{-5} & 40<t\leq 70 \\ 3.5\times 10^{-6} & 70<t\leq epochs \end{cases} \quad (4-17)$$

其中 *epochs* 表示训练的总次数, 在本章实验中 *epochs* 取值为 120。训练的前 10 代中, 学习率缓慢线性增长, 到了第 40 代和 70 代的时候学习率分别衰减为 3.5×10^{-5} 和 3.5×10^{-6} 。

(3) 标签平滑

标签平滑 (Label Smooth, LS) 主要应用于分类任务。在行人重识别任务中分类损失用的是交叉熵损失, 而分类损失使用的监督标签一般都是独热码, 即标签向量中有且仅有 1 个数值为 1, 其他为 0。在使用独热码的情况下, 如果分类准确, 交叉熵损失的结果会是 0。为了缓和标签对于网络的约束, 防止行人重识别模型过拟合训练行人的 ID, 标签平滑对标签做了如式 4-18 的操作:

$$q_i = \begin{cases} 1 - \frac{N-1}{N} \varepsilon & i = y \\ \frac{\varepsilon}{N} & i \neq y \end{cases} \quad (4-18)$$

经过标签平滑后, 使得预测正负样本的输出值差别不那么大, 可以显著改进模型的性能, 提高模型的泛化能力。

4.5 实验结果与分析

将本章提出的行人重识别算法和近三年内性能较好的一系列算法进行比较, 其中包含一部分无监督学习和一部分监督学习的算法如表 4-1 所示。

表 4-1 不同方法在 Market-1501 数据集上的性能表现

	方法	mAP	rank-1	rank-5	rank-10
无监督学习	HHL ^[62]	31.2%	62.4%	78.9%	-
	MAR ^[63]	40.2%	67.6%	81.5%	-
	CR-GAN-TAUDL ^[64]	54.1%	77.9%	89.4%	92.7%
监督学习	SVDNet ^[65]	62.4%	82.5%	92.1%	95.1%
	PABR ^[66]	79.4%	91.4%	96.7%	98.4%
	PCB ^[67]	81.5%	93.9%	97.6%	98.6%
	BFE ^[69]	85.0%	94.5%	98.3%	98.9%
	DGNet ^[70]	86.3%	94.9%	-	-
	AWTL ^[71]	75.7%	89.5%	-	-
	Baseline ^[59]	85.9%	94.5%	98.1%	98.8%
	Ours	87.1%	94.7%	98.3%	99.0%

从表 4-1 中明显可以看出,在有标签的数据集 Market-1501 上,使用无监督学习的方法效果远不如监督学习的方法。此外,将本章所提出的组合损失添加到基准方法上,相比基准方法,本章所提出的组合损失让 mAP 提高了 1.2%,rank-1 提高了 0.2%,验证了本章所提出的组合损失的有效性。将本章提出的方法与表 4-1 中其他监督学习方法进行比较,AWTL 采用自适应加权的三元组损失和新的样本挖掘技术,本章提出的方法比其 mAP 高出 11.4%,rank-1 高出 4.8%;DGNet 将 GAN 和行人重识别统一到一个框架中,本章提出的方法虽然比其 rank-1 低了 0.2%,但是 mAP 依然高了 0.8%;BFE 使用了两个分支进行特征提取,本章提出的方法在只提取全局特征的情况下,mAP 高出 2.1%,rank-1 高出 0.2%。综上所述,本章提出的方法虽然使用结构简单的模型提取全局特征,但在本章所提出的损失函数约束下,在 Market-1501 数据集上表现出了良好的性能。

在 DukeMTMC-reID 数据集上使用和在 Market-1501 数据集上同样的训练参数和方法进行训练。实验结果如表 4-2 所示,

表 4-2 不同方法在 DukeMTMC-reID 数据集上的性能表现

	方法	mAP	rank-1	rank-5	rank-10
无监督学习	HHL ^[62]	31.3%	62.1%	78.7%	-
	MAR ^[63]	40.2%	67.6	81.5%	-
	CR-GAN-TAUDL ^[64]	48.7%	68.8%	80.3%	84.5%
监督学习	SVDNet ^[65]	56.9%	76.8%	86.5%	89.8%
	PABR ^[66]	69.4%	84.3%	92.3%	93.7%
	PCB ^[67]	69.4%	83.5%	-	-
	BFE ^[69]	75.8%	88.7%	-	-
	DGNet ^[70]	74.7%	86.7%	-	-
	AWTL ^[71]	63.4%	79.8%	-	-
	Baseline ^[59]	76.4%	86.4%	94.1%	95.8%
	Ours	77.3%	87.6%	94.6%	96.1%

和在 Market-1501 数据集上效果相似,无监督学习的方法效果远不如监督学习的方法。本章所提出的方法在基准方法的基础上 mAP 提升了 0.9%,rank-1 提升了 1.2%,验证了本章所提出的组合损失函数效果显著。此外,将本章所提出

的方法与表 4-2 中监督学习的方法进行比较,比采用自适应加权的三元组损失和新的样本挖掘技术的 AWTL 在 mAP 上高出 13.9%,rank-1 上高出 7.8%;比 DGNet 在 mAP 上高出 2.6%。rank-1 上高出 0.9%;与采用多分支提出特征的 BFE 相比,虽然 rank-1 下降了 1.1%,但 mAP 提升了 1.5%。综上所述,在 DukeMTMC-reID 上的实验结果进一步地验证了本章所提组合损失函数的有效性。

为了验证模型训练时所设置的各种技巧,在 Market-1501 和 DukeMTMC-reID 数据集上,基于 4.2 节所提出的损失函数和 4.3 节所述的基本网络结构,本节不改变基本训练设置,逐个添加技巧,进行消融实验,结果如表 4-3 所示。

表 4-3 不同训练技巧的的性能表现

训练技巧	Market-1501		DukeMTMC-reID	
	mAP	rank-1	mAP	Rank-1
无训练技巧	80.8%	91.0%	74.1%	82.5%
+预热学习率	82.0%	92.0%	75.4%	83.4%
+随机擦除增强	86.1%	94.6%	76.3%	86.6%
+标签平滑	87.1%	94.7%	77.3%	87.6%

从表中可以看出三种训练技巧都能有效提高性能,其中对于 Market-1501 数据集而言,使用随机擦除增强, mAP 提升了 4.1%, rank-1 提升了 2.6%,比起其它技巧提升了更多的性能。主要原因在于 Market-1501 训练集内的图片,大多都是没有被遮挡的完整行人图片,经过随机擦除模拟遮挡的情况后,模型在测试集中泛化能力增强,效果明显提高。在 DukeMTMC-reID 数据集上,使用随机擦除增强 mAP 提升了 0.9%, rank-1 提升了 3.2%。相对 Market-1501 数据集而言,效果相对降低,主要原因在于 DukeMTMC-reID 训练集中增加了部分的遮挡行人样本,因此训练过程中增强了模型对于遮挡情况的泛化能力。使用预热学习率在 Market-1501 数据集上 mAP 提升 1.2%,rank-1 提升 1%;在 DukeMTMC-reID 上, mAP 提升 1.3%, rank-1 提升 0.9%,在两个数据集上的效果提升表现基本接近,说明预热学习率技巧对于数据集的敏感性不是很强。使用标签平滑在 Market-1501 数据集上 mAP 提升 1%, rank-1 提升 0.1%;在 DukeMTMC-reID 上, mAP 提升 1%, rank-1 提升 1%。

4.6 本章小结

本章首先分析了各种行人重识别损失函数的优缺点,在此基础上改进了边界样本挖掘损失,提升了其类内聚合度。之后,整合基于表征学习损失和基于度量学习损失的优点,将改进的边界样本挖掘损失与余弦交叉熵损失组合。在 Market-1501 和 DukeMTMC-reID 数据集上验证了改进难样本损失与余弦交叉熵组合损失的合理性和有效性。最后,通过消融实验,验证本章所使用的各个训练技巧。

第5章 行人检测与重识别系统设计与实现

在第三章和第四章中分别提出了引入注意力机制的行人检测方法和融合组合损失的行人重识别方法。本章将对前面提出的方法进行封装,首先对设计的系统实际需求进行分析;其次对系统方案和功能框架进行设计分析;然后展示了摄像头,交换机等硬件配置和设计系统所用到的 PyQt 工具包等软件信息;最后基于 PyQt 设计一个包含行人检测与重识别功能的系统,对监控画面、行人检测和行人重识别算法的运行结果等信息进行可视化。

5.1 系统需求分析

本章所实现的系统需要在传统监控系统的基础上,新增行人检测以及行人重识别模块,同时为用户提供简洁的功能性操作界面。此外,为了隐私安全性的考虑,需要对用户分配对应的权限,因此该系统主要有如下功能模块:

(1) 用户登录注册。此模块的功能是便于用户进行账户信息的修改,为用户带来良好的使用体验。

(2) 在线监控画面显示。用户登录之后,可以同时开启多路实时摄像头监控画面,根据不同的光照等外界条件,调节包括增益、亮度、对比度等摄像头的参数。同时为了保证监控画面的灵活性,设计相应按钮分别控制摄像头的暂停、保存等操作。

(3) 行人检测功能。支持对实时的摄像头画面进行行人检测,在摄像头画面中将检测算法所检测到的行人用矩形框进行标记,并标识出检测结果的可行度,同时统计出此时监控画面出的行人个数并加以展示。

(4) 行人重识别功能。系统界面上设置人员查询模块,用户点击行人重识别按钮后,在弹出的窗口中上传需要查询的目标行人图片至本系统,点击提交后系统同预先存储的监控视频中出现的行人进行相似度对比,查询到相似度小于阈值的图片后在用户界面展示结果,同时通过检测结果还可以确定目标人员在摄像头中出现的位置和时间。

(5) 存储功能。存储摄像头读取的完整监控画面,以及经过行人检测后得到的监控画面中的行人图像。

(6) 可扩展性需求。系统的硬件平台应支持扩充摄像头资源，支持多路监控摄像头同时工作，营造更好的行人重识别应用场景，体现行人重识别的价值，因此系统目前配备的计算资源应满足算法计算的同时，也要为将来接入的摄像头所需要的资源进行考虑。

5.2 系统方案设计

由系统需求分析中可知，本章所实现的系统整体方案应如图 5-1 所示。




图 5-1 系统方案示意图

其中表现层由前端人机交互界面组成，包括监控画面的实时显示以及功能控制；数据层作为监控画面显示的信息来源以及结果保存。数据层的访问原理如图 5-2 所示，让网络摄像机通过网线和交换机接入运行主程序的电脑。然后通过局域网配置，将网络摄像机、交换机、运行主程序的电脑三者设置为同一个网段。将设备都置于同一个局域网之后，在主程序中通过 Python 的 OpenCV 库实时读取摄像头的 rtsp 视频流。




图 5-2 数据层访问原理

逻辑层主要由行人检测和行人重识别模块构成,行人检测模块使用第三章所提出的引入注意力机制的行人检测方法。行人重识别模块使用第四章所提出的融合组合损失的行人重识别方法。在系统实际使用过程中,应根据特定场景下的监控画面添加数据对模型进行增量学习,训练出更具有鲁棒性的行人检测和行人重识别算法。由于本文只是实现一个基本模型系统,故本章所实现的系统直接采用在标准数据集上已经训练好的模型。

逻辑层的运行流程如图 5-3 所示,程序在运行后首先映入眼帘的是用户登录界面,在经过账户密码的校验后登录到监控系统中,同时为了保证检测和重识别算法响应速度足够快,在成功登录后程序就会开始加载训练好的行人检测和重识别的模型。监控系统的监控画面通过手动开启,此外行人检测与行人重识别算法默认是不开启的,只有在控制按钮打开时才会调用模型进行计算。其中行人检测模块在独立开启时还包含人流检测的功能,用于检测监控画面中出现行人的位置及行人总体的个数。行人重识别模块的使用依赖检测的结果,因为识别模块的输入以及待查询的候选行人库(gallery)是经过行人检测剪裁好的行人图片。对于摄像头图像的采集,根据摄像头的 IP 及 rtsp 端口使用 Python 的 OpenCV 库读取视频流。在图片输入模型前,会将原始视频帧缩放到合适的大小,并将数组格式转为 Python 可使用的张量类型。进行重识别时,query 文件夹中的图片作为搜索目标,首先要用识别模型处理并生成特征向量,之后每一张图的所有行人检测结果将组成候选行人库 gallery。将 query 的特征与 gallery 中的候选人特征逐一求距离,选择距离最小的一个与阈值比较,若小于阈值,则认为查找到目标,否则,认为目标不存在。




图 5-3 逻辑层运行流程图

此外编写前端界面中，通常用会有一些按钮，点击后触发事件，比如在调用行人检测与行人重识别算法进行计算时，这些操作会耗时，如果不能及时结束，主线程前端界面将会阻塞给用户的感受则是画面出现卡顿，严重的将会导致前端界面出现未响应的状态，因此必须使用多线程来解决这个问题。使用主线程来进行界面的显示，再分别使用一个线程进行检测算法以及重识别算法的计算，在各

个线程之间定义相关的槽函数和发射函数让线程之间进行通信，充分发挥 GPU 的并行计算能力。

5.3 系统开发与运行环境

5.3.1 硬件设备

(1) 海康威视网络摄像机




图 5-4 海康威视网络摄像机外观图

海康威视是领先的安防产品及行业解决方案提供商，其网络摄像机集成了视音频采集、智能编码压缩等多种功能，具有较高的可靠性和较强的稳定性。本章所使用的海康威视网络摄像机主要功能参数如表 5-1 所示。

表 5-1 摄像头主要功能参数

参数名	参数值
型号	DS-IPC-T12-I
传感器类型	1/2.7" CMOS
最大分辨率	200 万
最大图像尺寸	1920 × 1080
调节角度	水平：0°~360°，垂直：0°~75°，旋转：0°~360°
最大红外距离	30 米
镜头光圈	F2.0
主码流帧率分辨率	50 Hz:25 fps(1920 × 1080, 1280 × 960, 1280 × 720)
网络协议	TCP/IP, ICMP, HTTP, HTTPS, FTP, DHCP, DNS, RTP, RTSP, NTP, SMTP, IGMP, QoS, IPv6, UDP, Bonjour

(2) 交换机

系统所使用的交换机的详细配置如表 5-2 所示

表 5-2 交换机主要参数表

参数名	参数值
型号	H3C LS-5130-52S-SI
产品类型	千兆以太网交换机
传输速率	10/100/1000Mbps
背板带宽	256Gbps
包转发率	132Mpps
端口数量	52 个
传输模式	全双工/半双工自适应

5.3.2 软件平台

软件平台主要基于 PyQt 开发可视化界面。Qt 是一个 C++ 的开发类库，主要用于创建 GUI 应用程序。作为 C++ 中的一种常用工具包，Qt 中包含将近 6000 个函数和方法，并且在当前的主流操作系统包括 UNIX、Windows 和 Mac 上都能支持运行，能够很好地实现跨平台编程，具有很强的可移植性。PyQt 是 Qt 库在 Python 语言下的绑定，Pyqt 综合了 Qt 库和 Python 语言的优点。具体来说：

- 1) PyQt 集成了 Qt 的跨平台应用框架和 Python 的跨平台解释语言。
- 2) PyQt 继承了 Qt 所使用的信号与槽通信机制，使用这种机制进行对象之间的通信，更加安全、弱耦合、更易于创建可重用的对象模块。
- 3) PyQt 在 Qt Creator 的基础上新增了 Qt Designer 模块，极大地提升了窗体设计的自由度，而不需要通过修改源码来改变界面窗体效果，极大提高界面设计的效率。

针对 PyQt 的这些优点，非常轻易就能开发设计出界面风格良好，方便易用的系统可视化界面。

5.4 运行结果展示

由于监控画面的内容属于敏感信息，涉及到个人隐私，为了防止不法分子利用本章开发的系统窃取监控画面，威胁他人人身安全，所以在程序运行开始阶段，设置了登录注册模块，模块内包含账号注册和密码提示功能。




图 5-5 系统登录界面

系统登录后的初始化界面如图 5-6 所示，在未手动开启行人检测和行人重识别算法之前，是一个普通的监控系统，包含监控内容的实时播放、监控内容的及时存储等常规功能，界面的左上角包含设备列表，设备控制栏用于手动开启行人检测、行人重识别等智能功能，参数控制栏用于控制画面的部分参数，界面中间的两个主要区域用于播放实时监控画面。




图 5-6 监控系统界面

单击功能控制栏中的行人检测开关按钮后，切换至行人检测模式，便可实现对画面中的行人进行检测。对检测到的行人在画面中使用矩形框标记出行人区域，并在上方标识出检测的可行度，监控画面下方也会根据画面中检测到的人数更新数据，检测结果的可视化如图 5-7 所示，由图可以看出，在左边相对复杂的监控场景下，本论文所提出的方法共检测出了 7 个人，其中有 6 个人是正确的检测结果，1 个存在误检，没有存在漏检的情况；在右边相对简单的监控场景下，本论文所提出的方法十分轻松地检测出了 2 个行人，并且检测的置信度很高。需要说明的是，在展示检测结果时，为了防止侵犯他人的肖像权，在右边检测出的行人脸部手动打码，在实际的行人检测过程中，不存在脸部打码的功能。



图 5-7 行人检测结果可视化

开启行人重识别后，需要手动选取目标，上传需要查找的行人图片至程序所在目录的 query 文件夹下，之后在监控画面 1 和画面 2 保存的候选库中查询是否与 query 相匹配的行人，若有则在画面中会用唯一的矩形框标识出识别结果，完成了跨境头的行人重识别，如图 5-8 所示，由图可以看出，在上传了一张待查找的行人图像后，在两个摄像头的监控区域下都成功查找到了待查询的行人，实现了在实际监控场景下的跨境头的行人重识别。



图 5-8 行人重识别结果可视化

5.5 本章小结

本章通过分析所要搭建的行人检测与重识别系统功能需求,设计了系统的总体方案包括系统设计架构以及工作原理等,然后介绍了系统中所使用的硬件设备和软件平台,最后基于软件平台 PyQt 搭建了一个系统的可视化界面。在设定的场景中,对系统的运行结果进行展示,展示结果表明行人检测与行人重识别结果精度较高,在实际应用场景中具有一定的使用价值。但程序的性能提升还有较大的空间,不管是模型的训练还是模型预测都需要高性能的 GPU 加速,系统对硬件配置要求高,目前本章只是实现了一个原型系统,功能还有待完善。

第6章 总结与展望

6.1 总结

随着国家和社会对安全需求的日益增加,人们对视频监控系统智能识别能力的要求越来越高。行人检测与行人重识别技术作为智能视频监控系统的重要组成部分,具有十分重要的研究意义和价值。在实际的监控场景中,行人检测面临的主要挑战在于环境背景复杂、行人尺寸过小或行人之间存在相互遮挡等。行人重识别面临的主要挑战在于拍摄视角及行人姿态差异导致同一行人拍摄的图片之间存在较大差异。针对目前的行人检测与行人重识别算法所遇到的挑战,完成的主要工作如下:

(1) 行人检测工作方面,提出了引入注意力模块 SKNet 的行人检测方法。该方法在通用目标检测算法 YOLOv3 的基础上,针对 YOLOv3 对行人遮挡、小尺度行人易产生漏检的情况,引入了注意力机制模块 SKNet。通过注意力机制模块改变特征图中原始通道的卷积核权重,使得被遮挡通道权重降低,未被遮挡通道权重提高,提升了行人遮挡的检测效果;同时使得不同的图像能够得到具有不同重要性的卷积核,从而提高小行人的检测效果。在 Caltech 行人检测数据集上的实验结果表明,本论文提出的方法对比基准方法 YOLOv3 平均漏检率降低了 1.81%。针对加入了注意力模块导致模型体积变大参数量变多的问题,通过模型剪枝,使得算法在精确度几乎不变的情况下,检测速度进一步提高。最后为了提高模型的泛化能力,在 Pascal VOC 2007 数据集上训练,实验结果表明,本论文提出的方法在基准方法上平均精度依然有所提升。

(2) 行人重识别方面,提出了一种融合组合损失的行人重识别方法。通过对比分析各行人重识别损失函数性能,然后基于极小化类内距离的优化思想,改进了基于度量学习的边界挖掘损失,在原有损失基础上新增了一项中心损失,改进后的边界样本挖掘损失压缩了类内距离,使得类内约束更强。此外为了整合基于表征学习损失和基于度量学习损失的优点,将基于度量学习的改进边界样本挖掘损失与余弦交叉熵损失进行组合,有效提高了网络特征提取能力,改善了网络性能。最后分别在 Market-1501 行人重识别数据集和 DukeMTMC-reID 行人重识别数据集上进行了对比实验,实验结果表明,本文所提出的方法跟基准方法相比效

果显著,在 Market-1501 数据集上 mAP 提高了 1.2%,rank-1 提高了 0.2%,在 DukeMTMC-reID 数据集上 mAP 提升了 0.9%,rank-1 提升了 1.2%。验证了改进边界样本挖掘损失与组合损失函数的有效性和可行性。

(3) 基于本论文所提出的行人检测与行人重识别方法,设计了一个系统。首先分析所要搭建的行人检测与重识别系统功能需求,设计了系统的总体方案包括系统设计架构以及工作原理等,然后介绍了系统中所使用的硬件设备和软件平台,最后基于软件平台 PyQt 搭建了一个系统的可视化界面。在设定的场景中,对系统的运行结果进行展示,在实际应用场景中具有一定的使用价值。

6.2 展望

本论文分析与探讨了基于卷积神经网络的行人检测与行人重识别算法,在现有算法的基础上取得一定的成果但仍有很多问题亟待解决,下一步的工作可以从如下几个方面进行展开。

(1) 由于遮挡,卷积神经网络只能获取未被遮挡部分的特征,即使通过注意力机制,也无法得到根本的解决,因此可以采取分块的思想,将行人分为多个部分进行分块检测,最后将分块检测的结果综合来判定是否为行人。

(2) 构建基于无锚框的行人检测模型。本论文中使用的行人检测算法是基于预先生成行人锚框的思想,这类方法受遮挡问题影响较大,无锚框的检测算法将检测问题转化为检测行人边界框的关键点对问题,因此检测过程可以很好地解决遮挡问题。

(3) 行人重识别算法往往泛化性能不够,提升模型泛化能力的方法之一是扩充样本训练,现实中获取行人样本较为困难,可通过生成对抗网络产生更多形态姿势各异的行人样本。

(4) 本论文所设计的行人检测与重识别系统只是在常规监控的系统的基础上对算法进行了可视化,性能提升还有较大的空间,而且不管是模型的训练还是模型预测都需要高性能 GPU 加速,系统对硬件配置要求高,系统功能还有待完善。

参考文献

- [1] Karanam S, Li Y, Radke R J. Person re-identification with discriminatively trained viewpoint invariant dictionaries [C]. Proceedings of the 15th IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 4516-4524.
- [2] Bak S, Zaidenberg S, Boulay B, et al. Improving person re-identification by viewpoint Cues [C]. Proceedings of the 11th IEEE International Conference on Advanced Video and Signal-Based Surveillance, Seoul, Korea, 2014: 175-180.
- [3] Xiang L, Zheng W S, Wang X, et al. Multi-scale learning for low-resolution person re-identification [C]. Proceedings of the 15th IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 3765-3773.
- [4] Wang Y, Wang L, You Y, et al. Resource aware person re-identification across multiple resolutions [C]. Proceedings of the Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018: 8042-8051.
- [5] Huang Y K, Fu X Y, Zha Z J, et al. Illumination-invariant person re-identification [C]. Proceedings of the 27th ACM International Conference on Multimedia, Nice, France, 2019: 365-373.
- [6] Cho Y J, Yoon K J. Improving person re-identification via pose-aware multi-shot matching [C]. Proceedings of the 29th IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016: 1354-1362.
- [7] Zhao H, Tian M, Sun S, et al. Spindle Net: Person Re-identification with human body region guided feature decomposition and fusion [C]. Proceedings of the 30th IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017: 907-915.
- [8] Sarfraz M S, Schumann A, Eberle A, et al. A pose-sensitive embedding for person re-identification with expanded cross neighborhood re-ranking [C]. Proceedings of the 31st Meeting of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018: 420-429.
- [9] Huang H, Li D, Zhang Z, et al. Adversarially occluded samples for person re-identification [C]. Proceedings of the 31st Meeting of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018: 5098-5107.
- [10] Hou R, Ma B, Chang H, et al. VRSTC: Occlusion-free video person re-identification [C]. Proceedings of the 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019: 7176-7185.

- [11] Kaew T. An improved adaptive background mixture model for real-time tracking with shadow detection [C]. Proceedings of the Advanced Video Based Surveillance Systems Workshop, London, UK, 2001: 135-144.
- [12] Barnich O, Droogenbroeck M V. ViBe: A universal background subtraction algorithm for video sequences [J]. IEEE Transactions on Image Processing, 2011, 20(6): 1709-1724.
- [13] Hofmann M, Tiefenbacher P, Rigoll G. Background segmentation with feedback: the pixel-based adaptive segmenter [C]. Proceedings of the 2012 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops, Providence, RI, USA, 2012: 38-43.
- [14] Wang H, D Suter. A consensus-based method for tracking: modelling background scenario and foreground appearance [J]. Pattern Recognition, 2007, 40(3): 1091-1105.
- [15] Dalal N, Triggs B. Histograms of oriented gradients for human detection [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, San Diego, CA, USA, 2005: 886-893.
- [16] Jones M, Viola P. Fast multi-view face detection. Mitsubishi Electric Research Laboratories, Technical Report: MERL-2003-96, July 2003.
- [17] Dollár P, Tu Z, Perona P, et al. Integral channel features [C]. Proceedings of the 20th British Machine Vision Conference, London, UK, 2009.
- [18] Yan J, Zhen L, Wen L, et al. The fastest deformable part model for object detection [C]. Proceedings of the 27th IEEE Conference on Computer Vision and Pattern Recognition, Columbus, OH, USA, 2014: 2497-2504.
- [19] Krizhevsky A, Sutskever I, Hinton G. ImageNet classification with deep convolutional neural networks [C]. Proceedings of the 26th Annual Conference on Neural Information Processing Systems, Lake Tahoe, NV, USA, 2012: 1097-1105.
- [20] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]. Proceedings of the 27th IEEE Conference on Computer Vision and Pattern Recognition, Columbus, OH, USA, 2014: 580-587.
- [21] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.
- [22] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection [C]. Proceedings of the 29th IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016: 779-788.

- [23] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector [C]. Proceedings of the 14th European Conference on Computer Vision, Amsterdam, Netherlands, 2016: 21-37.
- [24] Redmon J, Farhadi A. YOLO9000: Better, faster, stronger [C]. Proceedings of the 30th IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017:6517-6525.
- [25] Redmon J, Farhadi A. YOLOv3: An incremental improvement [J]. arXiv preprint arXiv: 1804.02767,2018.
- [26] 李慕锴, 张涛, 崔文楠. 基于 YOLOv3 的红外行人小目标检测技术研究 [J]. 红外技术, 2020, 042(002):176-181.
- [27] Jie H, Li S, Gang S, et al. Squeeze-and-Excitation networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 42(8): 2011-2023.
- [28] 刘丽, 郑洋, 付冬梅. 改进 YOLOv3 网络结构的遮挡行人检测算法 [J]. 模式识别与人工智能, 2020, 2020(6):568-574.
- [29] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features [C]. Proceedings of the 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, San Francisco, CA, USA, 2010: 2360-2367.
- [30] Zheng L, Zhang H H, Sun S Y, et al. Person re-identification in the wild [C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, Hawaii, USA, 2017: 3346-3355.
- [31] Lin Y T, Zheng L, Zheng Z D, Wu Y, Yang Y. Improving person re-identification by attribute and identity learning [J]. Pattern Recognition, 2017, 95: 151-161.
- [32] Varior R R, Haloi M, Wang G. Gated siamese convolutionalneural network architecture for human re-identification [C]. Proceedings of the 2016 European Conference on Computer Vision, Scottsdale, AZ, USA, 2016: 791-808.
- [33] Schroff F, Kalenichenko D, Philbin J. FaceNet: A Unified Embedding for Face Recognition and Clustering [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015: 815-823.
- [34] Chen W H, Chen X T, Zhang J G, et al. Beyond triplet loss: a deep quadruplet network for person re-identification [C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, Hawaii, USA, 2017: 1320-1329.
- [35] Xiao Q, Cao K, Chen H, et al. Cross domain knowledge transfer for person re-identification [J]. arXiv preprint, arXiv: 1611.06026, 2016.

- [36] Liu H, Jie Z, Jayashree K, et al. Video-based person re-identification with accumulative motion context [J]. IEEE transactions on circuits and systems for video technology, 2017, 28(10): 2788–2802.
- [37] McLaughlin N, Martinez del Rincon J, Miller P. Recurrent convolutional network for video-based person re-identification [C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, Nevada, USA, 2016: 1325–1334.
- [38] Zhang W, Ma B P, Liu K, et al. Video-based pedestrian re-identification by adaptive spatio-temporal appearance model [J]. IEEE Transactions on Image Processing, 2017, 26(4): 2042–2054.
- [39] Deng W J, Zheng L, Ye Q X, et al. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification [J]. arXiv preprint arXiv: 1711.07027, 2018.
- [40] Huang Y, Xu J S, Wu Q, et al. Multi-pseudo regularized label for generated data in person re-identification [J]. IEEE Transactions on Image Processing, 2019, 28(3): 1391-1403.
- [41] Uijlings J R, Van D S, Gevers T, et al. Selective search for object recognition [J]. International Journal of Computer Vision, 2013, 104(2): 154-171.
- [42] Platt J C. Fast training of support vector machines using sequential minimal optimization, advances in kernel methods [J]. Advances in Kernel Methods: Support Vector Learning, 1999: 185-208.
- [43] Girshick R. Fast R-CNN [J]. arXiv preprint, arXiv:1504.08083, 2015.
- [44] Dollar P, Wojek C, Schiele B, et al. Pedestrian detection: a benchmark [C]. Proceedings of the 2009 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, Miami, FL, USA 2009:304-311.
- [45] Huang J Z, Ng M K, Rong H, et al. Automated variable weighting in k-means type clustering [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2005, 27(5):657-668.
- [46] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016: 770-778.
- [47] Lowe D G. Object recognition from local scale-invariant features [C]. Proceedings of the Seventh IEEE International Conference on Computer Vision, Kerkyra, Greece, 1999: 1150--1157.

- [48] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015: 2197-2206.
- [49] Köstinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints [C]. Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition, Providence, RI, USA, 2012: 2288-2295.
- [50] Li X, Wang W, Hu X, et al. Selective kernel networks [C]. Proceedings of the 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019: 510-519.
- [51] Mnih V, Heess N, Graves A, et al. Recurrent models of visual attention [C]. Proceedings of the 28th Annual Conference on Neural Information Processing Systems, Montreal, QC, Canada, 2014: 2204-2212.
- [52] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module [C]. Proceedings of the 15th European Conference on Computer Vision, Munich, Germany, 2018: 3-19.
- [53] Lin Y, Zheng L, Zheng Z, et al. Improving person re-identification by attribute and identity learning [J]. Pattern Recognition, 2019, November 2019(95): 151-161.
- [54] Liu W, Wen Y, Yu Z, et al. SphereFace: deep hypersphere embedding for face recognition [C]. Proceedings of the 30th IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017: 6738-6746.
- [55] Dong Y, Zhen L, Liao S, et al. Learning face representation from scratch [J]. arXiv preprint, arXiv:1411.7923, 2014.
- [56] Cheng D, Gong Y H, Zhou S P, Wang J J, Zheng N N. Person re-identification by multi-channel parts-based CNN with improved triplet loss function [C]. Proceedings of the 29th IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA, 2016: 1335-1344.
- [57] Xiao Q, Luo H, Zhang C. Margin sample mining loss: a deep learning based method for person re-identification [J]. arXiv preprint, arXiv:1710.00478, 2017.
- [58] Wen Y, Zhang K, Li Z, et al. A discriminative feature learning approach for deep face recognition [C]. Proceedings of the 21st ACM Conference on Computer and Communications Security, Scottsdale, AZ, USA, 2016: 499-515.
- [59] Hao L. Bags of tricks and a strong baseline for deep person re-identification [C]. Proceedings of the 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, Long Beach, CA, USA, 2019: 1487-1495.

- [60] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: a benchmark [C]. Proceedings of the 15th IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 1116-1124.
- [61] Ristani E, Solera F, Zou R S, et al. Performance measures and a data set for multi-Target, multi-camera tracking [C]. Proceedings of the 14th European Conference on Computer Vision, Amsterdam, Netherlands, 2016: 17-35.
- [62] Zhong Z, Zheng L, Li S, et al. Generalizing a person retrieval model hetero- and Homogeneously [C]. Proceedings of the 15th European Conference on Computer Vision, Munich, Germany, 2018: 176-192.
- [63] Yu H X, Zheng W S, Wu A, et al. Unsupervised person re-identification by soft multilabel learning [C]. Proceedings of the 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019: 2143-2152.
- [64] Chen Y, Zhu X, Gong S. Instance-guided context rendering for cross-domain person re-identification [C]. Proceedings of the 17th IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 2020: 232-242.
- [65] Sun Y, Zheng L, Deng W, et al. SVDNet for pedestrian retrieval [C]. Proceedings of the 16th IEEE International Conference on Computer Vision, Venice, Italy, 2017: 3820-3828.
- [66] Suh Y, Wang J, Tang S, et al. Part-aligned bilinear representations for person re-identification [C]. Proceedings of the 15th European Conference on Computer Vision, Munich, Germany, 2018: 418-437.
- [67] Sun Y, Zheng L, Yang Y, et al. Beyond part models: person retrieval with refined part pooling (and a strong convolutional baseline) [C]. Proceedings of the 15th European Conference on Computer Vision, Munich, Germany, 2018: 501-518.
- [69] Dai Z, Chen M, Zhu S, et al. Batch feature erasing for person re-identification and beyond [J]. arXiv preprint arXiv:1811.07130, 2018.
- [70] Zheng Z, Yang X, Yu Z, et al. Joint discriminative and generative learning for person re-identification [C]. Proceedings of the 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2020: 2133-2142.
- [71] Ergys R, Carlo T. Features for multi-target multi-camera tracking and re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, Utah, USA, 2018:6036–6046.
- [72] Cai Z , Vasconcelos N . Cascade R-CNN: Delving into High Quality Object Detection[C]. Proceedings of the 31st Meeting of the IEEE/CVF Conference on

Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018: 6154-6162.

- [73] Tian Y , Ping L , Wang X , et al. Pedestrian detection aided by deep learning semantic tasks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015: 5079-5087

致 谢

在论文完成之际，谨向三年来所有关心和支持我的老师、同学、朋友以及亲人们表示由衷的感谢。

首先，我要感谢我的导师孙国霞老师，感谢孙老师三年以来的悉心教导与谆谆教诲，孙老师在学习生活中给予我很大帮助与支持。感谢我的导师刘琚教授，刘老师为我提供了良好的学习和生活环境，在实验室的每个日子里，都能感受到在家一般的温暖和谐。其次，刘老师对于学术认真严谨，执着务实让我明白了做科研的正确态度与方法。并且在我找工作的那段时间里，给我提供了鼎力支持，让我找到了相对满意的工作。最后感谢孙老师和刘老师对我论文的指导与修改，督促我按时完成论文。

感谢实验室的师兄姐妹们，感谢同级的张昱、赵雪圻、鲁昱，和你们朝夕相处三年，建立了如家人般的深厚友谊；感谢孔祥茂师兄，在我刚进入实验室时为我提供了无微不至的指导，让我在科研之路上找到一盏明灯；感谢刘晓玺和顾凌晨师姐，你们对科研的严谨态度，为我树立了榜样，对我科研上的指导和帮助，让我受益匪浅；感谢于山山师兄，教会了我很多为人处世的道理；感谢林枫茗、杜若画、姚世聪、王京、于璐跃、李亚锋、王雪静、徐田凤、郭磊、彭志颖、高智超、韩艳阳、江潇、吕林等师兄姐妹们，在 ICMIP 这个大家庭里，大家相互扶持，荣辱与共，祝福你们一帆风顺，前程似锦。

感谢舍友李宸冠在研究生三年的相互包容；感谢蒋明渊同学，和你一起侃大山对于枯燥的科研生活是一份极佳的调味剂；感谢孙国荃同学，在我生活遇到困惑遇到不顺心的时候开导我；感谢魏文辉和宋延新同学，你们宿舍对我来说就是第二个家；感谢远在浙大读博的高晨，在自己科研任务繁重的情况下，依然帮我修改论文。

感谢我的父母二十多年来对我的养育之恩，感谢你们对我的教育和无微不至的照顾，感谢你们对我的支持和鼓励，你们的支持和鼓励能够使我走得更远，家庭永远是我最强有力的后盾，谢谢你们。

最后，衷心感谢各位评审老师在百忙之中抽出宝贵的时间指出本文的缺点和不足，我将虚心接受您的意见，完善本文。

攻读学位期间发表的学术成果和参加的科研项目

申请的发明专利：

1. 刘璐，张杰，江潇，张昱，赵雪圻，鲁昱。一种引入注意力机制的行人检测方法，发明专利，专利申请号：202110276432.5。（学生第一作者）
2. 刘璐，张昱，刘晓玺，赵雪圻，张杰，鲁昱，顾凌晨。一种基于动静态特征融合的视频摘要方法，发明专利，专利申请号：202010815306.8。（学生第四作者）
3. 刘璐，赵雪圻，鲁昱，刘晓玺，张杰，张昱，韩艳阳。一种基于轻量级人脸识别模型的隐私保护方法，发明专利，专利申请号：202010815306.8。（学生第四作者）

参加的科研项目：

1. 图像和视频数据隐私保护项目，企业委托项目，参与。

学位论文评阅及答辩情况表

论文评阅人	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		总体评价
	匿名						优秀
	吴强		副教授	是	山东大学		优秀
答辩委员会成员	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		
	主席	郑海永	教授	是	中国海洋大学		
	委 员	姜威	教授	是	山东大学		
		元辉	教授	是	山东大学		
		吴强	副教授	是	山东大学		
		刘治	教授	是	山东大学		
答辩委员会对论文的 总体评价			良好	答辩秘书	周莹	答辩日期	2021.5.29
备注							