

单位代码：10359

密 级：公开

学 号：2017110966

分类号：TP391

合肥工业大学

Hefei University of Technology

硕士学位论文

MASTER'S DISSERTATION

(学术硕士)

论文题目：面向红外和可见光跨模态的

行人重识别方法研究

专业名称：计算机软件技术与理论

作者姓名：王静

导师姓名：汪荣贵 教授

完成时间：2020 年 05 月

合 肥 工 业 大 学

学历硕士学位论文

面向红外和可见光跨模态的
行人重识别方法研究

作者姓名：_____王静_____

指导教师：_____汪荣贵 教授_____

专业名称：_____计算机软件技术与理论_____

研究方向：_____行人重识别_____

2020 年 05 月

A Dissertation Submitted for the Degree of Master

**Research on Visible-Infrared Cross Modality for
Person Re-Identification Method**

By

Wang Jing

Hefei University of Technology

Hefei, Anhui, P.R.China

May , 2020

合 肥 工 业 大 学

本论文经答辩委员会全体委员审查,确认符合合肥工业大学学历硕士学位论文质量要求。

答辩委员会签名(工作单位、职称、姓名)

主席:

刘明刚

中国科学技术大学 教授

委 员:

方贤勇

安徽大学 教授

郑永年

合肥工业大学 教授

贾伟

合肥工业大学 副教授

赵洋

合肥工业大学 副教授

导 师:

田孝贵

合肥工业大学 教授

致 谢

时光匆匆如流水，转眼间，三年的研究生求学生活即将结束，站在毕业的门槛上，回首往昔，奋斗和辛劳成为丝丝的记忆，甜美与欢笑也都尘埃落定。合肥工业大学以其优良的学习风气、严谨的科研氛围教我求学，以其博大包容的情怀胸襟、浪漫充实的校园生活育我成人。值此毕业论文完成之际，我谨向所有关心、爱护、帮助我的人们表示最诚挚的感谢与最美好的祝愿。

感恩导师汪荣贵，恩师学识似海，虚怀若谷，诲人不倦，不仅授我以文，而且教我做人，虽历时三载，却给以终生受益无穷之道。本研究及学位论文得到恩师的悉心指导，经常询问研究进程，为我指点迷津，助我开拓研究思路，给予我热忱鼓励。在此，谨向我敬爱的导师汪老师表示衷心地感谢。

感谢薛丽霞老师、杨娟老师，感谢她们三年来对我严格的要求、悉心的指导、循循的鼓励和不断的鞭策，教会了我严谨求实的科研思维，治学的方法和解决问题的思维，使我一步一步地成长起来。感谢刘丽华老师、孙进兰老师、罗珣老师在疫情期间不辞辛苦地为毕业学子奔波忙于大大小小的毕业相关事情，非常感谢她们。

感谢师兄师姐们：姚旭晨、陈龙、郑岩、俞鹏飞、李文静、江迪，他们不仅在学术上给我指引，而且在生活上予以帮助，从他们身上我学到很多知识。感谢同窗们：龚毓秀、韩梦雅、叶萌、朱正发、汤明空、邓滔，在项目开发中的互帮互助，在科研工作中交流讨论，在学业生活中关心爱护，三年来朝夕相处的时光，将谱写进我致青春中最美丽的篇章，同窗之间的友谊永远长存。感谢师弟们：李懂、李明熹、刘兵、张珉、尹凯建、马可可、孙旭，在我找工作阶段，给予了很大支持，与你们共度的每一分每一秒我都很快乐。

感谢我的爸爸妈妈，焉得谖草，言树之背，养育之恩，无以回报，你们是我求学路上的坚强后盾，在我面临人生选择的迷茫之际，为我排忧解难，你们对我无私的爱与照顾是我不断前进的动力。

最后，感谢曾经教育和帮助过我的所有老师。衷心地感谢为评阅本论文而付出宝贵时间和辛勤劳动的专家和教授们，谢谢您！

作者：王静
2020 年 05 月

摘要

近年来,基于红外和可见光模态的行人重识别在视频监控、人机互联、智能安保等领域应用广泛,但由于图像间视觉外观具有差异性且红外图像存在着低分辨率等缺陷,使得目前跨模态的行人重识别研究处于起步阶段。通过对跨模态行人重识别问题的深入分析,提出了两种解决方案,分别是特征金子塔随机融合结构与混合损失函数的多模态学习,有效地解决了跨模态行人重识别问题,实验证明了所提算法的有效性。本文的主要研究内容及特色如下:

1. 针对单一尺度特征学习的局限性和多模态特征融合的复杂性,提出了特征金子塔随机融合模型。首先,引入了超分辨重建策略来处理红外图像视觉糊化对网络训练的干扰;然后,融合高层特征的强语义表征能力与低层特征的强几何细节信息表征能力,实现了高分辨强语义特征作为相似性匹配的唯一输入;最后,融合全局学习和局部学习的优势,设计了多层次不同模态特征的随机融合机制。该模型完成了图像多尺度语义学习任务,而且参与运算的参数量不高,有效解决了跨尺度多模态行人的学习问题,实验数据表明所提出的网络识别精度优于现有的方法,而且模型规模小,训练周期短。

2. 针对影响跨模态行人重识别性能的核心因素,即模态内视觉外观差异与模态间异质差距,提出了混合损失函数与分类学习模型。首先,基于奇异矩阵的特性设计了 SVD 层;然后,将交叉熵函数作为基础损失函数,再利用双线性插值算法来显性化差距;最后,利用 RGB-RGB、IR-IR、RGB-IR 三种模态间的偏置来进一步校正网络。实验数据显示,所提出的基于混合损失函数的多模态分类学习有效地修正了模型。

关键词: 深度学习; 跨模态行人重识别; 超分辨重建; 特征金子塔随机融合; 混合损失函数

ABSTRACT

In recent years, visible-infrared modality Person Re-identification (Re-ID) has been widely applied to video surveillance, human-machine interconnection, intelligent security and other fields. However, due to the difference in visual appearance between images and the defects of infrared images such as low resolution, so that the study of cross modality person Re-ID is in the infant stage at present. Through deeply analysis of the cross modality person Re-ID problems, two solutions are proposed, which are feature pyramid random fusion network and multi-modality learning of hybrid loss function. It effectively solves problems of visible-infrared person Re-ID. Extensive experiments demonstrate the effectiveness of our approach. Main researches of our work is as follows:

1. A feature pyramid random fusion structure is proposed for the limitation of single scale feature learning and the complexity of multi-modality feature fusion. Firstly, we introduce a super-resolution reconstruction method to handle training disturbance caused by visual blur from infrared images. Secondly, our work implements high-resolution with multi-semantic information as a single output by mixing strong semantic features at top-level to strong geometric detail features at bottom-level. Finally, integrating the advantages of learning global and local, a random fusion mechanism of convolutional layers from multi-modality and multi-hierarchy is designed. This method completes the task of image multi-scale semantic learning, and the number of parameters involved in the operation is not high, thus effectively solves the problems of cross-scale multi-modality learning of Re-ID. Experimental results testify that the accuracy of our work is better than existing methods, and the model is smaller in size and shorter in training period.

2. The vital factor affecting the performance of cross-domain Re-ID is gaps within intra-modality visual appearance and inter-modality heterogeneity issues. Thus we propose a hybrid loss function of classification learning model. Firstly, the SVD layer is designed based on the characteristic of the singular matrix. Secondly, the cross-entropy is determined as the basic loss function, then a bilinear interpolation skill is used to explicit the gap. Finally, we utilize the bias from the three modalities of RGB-RGB, IR-IR, and RGB-IR to modify the network. The experimental results testify that our algorithm is effectively correcting the model.

KEYWORDS: Deep Learning; Cross-modality Person Re-identification; Super-resolution Reconstruction; Feature Pyramid Random Fusion; Hybrid Loss Function

目录

第一章 绪论	1
1.1 课题来源及意义	1
1.2 研究背景与现状	2
1.3 研究内容与结构安排	3
第二章 跨模态行人重识别的理论	5
2.1 超分辨重建图像的基本理论	5
2.1.1 超分辨重建算法的基础知识	5
2.1.2 基于深度学习的超分辨重建方法	7
2.2 行人重识别的基本理论	9
2.2.1 行人重识别的基础知识	9
2.2.2 传统的行人重识别	10
2.2.3 基于卷积神经网络的行人重识别	11
2.3 评估指标	16
2.3.1 超分辨重建算法的质量评价标准	16
2.3.2 行人重识别的评估标准	17
2.4 数据集	18
2.5 本章小结	19
第三章 特征金字塔随机融合网络的研究	20
3.1 引言	20
3.2 特征提取模型	21
3.3 特征融合模型	25
3.4 实验结果与分析	27
3.4.1 实验设置	27
3.4.2 结果分析	27
3.5 本章小结	32
第四章 基于混合损失函数的多模态分类学习	33
4.1 引言	33
4.2 混合损失函数分析	34
4.2.1 相关损失函数	35
4.2.2 混合损失函数	38
4.3 实验结果与分析	41
4.3.1 实验设置	41

4.3.2 结果分析	42
4.4 本章小结	44
第五章 总结与展望	45
5.1 总结	45
5.2 展望	45
参考文献	47
攻读硕士学位期间的学术活动及成果情况	52

插图清单

图 1.1 一个行人不同的姿态、背景、遮挡物.....	1
图 2.1 研究跨模态行人重识别问题.....	5
图 2.2 图像退化与重建过程	6
图 2.3 FSRCNN 与 SRCNN 对比.....	8
图 2.4 传统行人重识别系统.....	9
图 2.5 卷积神经网络的基本结构.....	11
图 2.6 卷积计算.....	12
图 2.7 最大池化和均值池化过程.....	13
图 2.8 左边为 Sigmoid 函数曲线, 右边是 Sigmoid 导数图	13
图 2.9 左边为 ReLu 函数曲线, 右边是 ReLu 导数图	14
图 2.10 左侧是 LeakyReLu 函数曲线, 右侧是 LeakyReLu 导数图	14
图 2.11 误判行人类别	15
图 2.12 每两列中的图像是同一个人	18
图 3.1 特征金字塔随机融合网络结构示意图.....	21
图 3.2 特征金字塔随机融合网络的流程	21
图 3.3 残差单元.....	22
图 3.4 案例说明, 红色框的图像表示不匹配, 绿色的表示匹配.....	25
图 3.5 构建金字塔简易图	25
图 3.6 特征选取方式	26
图 3.7 特征融合方式.....	26
图 3.8 空心箭头指向候选特征, 蓝色箭头表示参与融合	27
图 3.9 对比最新方法的实验结果曲线	30
图 3.10 训练阶段 mAP 变化趋势 图 3.11 训练阶段 loss 变化趋势.....	31
图 4.1 损失函数在训练阶段的效果.....	33
图 4.2 跨模态行人重识别分类任务的基本流程.....	34
图 4.3 跨模态行人重识别分类任务的模型	35
图 4.4 三元组基本模型	36
图 4.5 三元组损失的缺点	37
图 4.6 难样本采样示意图	37
图 4.7 上采样与上池化的区别.....	39
图 4.8 双线性插值步骤	40
图 4.9 模型中不同模块对比图.....	43

图 4.10 混合损失函数的结构对比图	43
---------------------------	----

表格清单

表 2.1 SRCNN 超分辨结构	7
表 2.2 五种 SR 算法对比	8
表 2.3 SYSU-MM01 与常用 Re-ID 数据集对比	19
表 2.4 SYSU-MM01 数据集内容	19
表 3.1 基础网络结构.....	23
表 3.2 构建特征金字塔	24
表 3.3 分析特征抽取和特征融合方法的实验结果.....	28
表 3.4 在 SYSU-MM01 数据集上对比最新方法	30
表 4.1 选择权重参数值.....	42
表 4.2 模型中不同模块对比	42
表 4.3 混合损失函数的结构对比.....	43

第一章 绪论

1.1 课题来源及意义

在视频监控中,当一个行人被公共场所的某摄像头捕捉到,通过其他摄像机的监控内容去发现该行人下一次出现的地点,这个过程称为行人重识别。行人重识别作为目标检测领域的子问题,在视频监控、人机互联、智能安保等行业应用广泛,特别是社会治安方面,在人口密集城市中锁定犯罪分子具有很大应用前景。当前行人重识别研究挑战主要在于不同摄像头捕获的图像在视觉外观上是明显不同的,导致网络需要同时处理不同光照、背景、遮挡物以及多种行人姿态,如图 1.1 所示。如图 1.1 所示。为了攻克上述问题,很多行人重识别方法被提出,比如消除背景噪声^[1]和补全被遮挡行人图像^[2]以及利用生成特征图生成不同姿态^[3]等。这些方法在可见光(RGB)图像下重识别效果出色,因而被广泛运用到实际生活场景。



图 1.1 一个行人不同的姿态、背景、遮挡物

Fig 1.1 Pose, background and occlusion change of images for the same person

传统可见光的监控摄像头已经不适应于一般场合,道路交通、监狱、机场等大型公共场所是需要 24 小时监控。摄像机捕捉犯罪分子的画频,显然夜晚犯罪分子出现次数大于白天,因而基于红外的行人重识别非常重要。目前很多监控系统 and 智能设备配置了可见光到红外模式自动切换功能^[4],基于可见光模式的行人重识别在 Market1501 数据集^[5]下 rank-1 已经达到了 95%^[6],然而基于红外模式的行人重识别,由于红外(IR)图像低分辨率和低对比度等缺陷,使得目前研究成果很少^[7-9]。

跨模态行人重识别研究,面临着来自 RGB 和 IR 模态内部和 RGB-IR 模态间三方面挑战。模态内的图像存在着视觉外观差异,模态间图像存在着异质差距,比如在分辨率和对比度方面,两种模态的图像是未对齐的,而且 RGB 图像涵盖了三种通道的颜色信息,IR 图像实质是单通道的灰度图,这种不对称的信息分布,会扰乱神经网络特征学习过程,因而,跨模态行人重识别研究重点是减缓三种差异的消极影响。针对上述问题,本文详细分析和深入研究了多种深度学习模型,在此基础上设计跨尺度的特征金字塔模型与基于混合损失的分类模型,以此来解决多模

态行人图像重识别问题,经由公开数据集上的验证效果,是能够发现所提模型优于现有的先进算法。

1.2 研究背景与现状

跨模态检索的对象是不同模态数据,包括可见光图像、红外图像、音频和视频。传统跨模态学习常采用哈希法, zhu^[10]等人提出了缩放索引哈希法,局部自适应哈希法也被提出^[11]。再引入语义信息后,监督学习的哈希法^[12]出现了。最近几年,深度学习被广泛应用在跨模态学习任务,基于玻尔兹曼机的深度学习^[13]在多模态问题的研究上取得了出色的效果。如今,多模态问题的研究在人体识别^[14]和面部识别^[15]以及行人重识别^[16]方面均有成果产生,尤其是跨模态行人重识别^[17-18],它在机场、医院等全天候人流稠密的场所,具有广泛应用前景。

跨模态行人重识别的研究经历了早期郑伟诗^[19]等人基于深度学习网络的探索,再经过 Mogelmose^[20]等人改良,集 RGB、深度和红外图像三种模式于一体,来增强识别的精度,再然后 Nguyen^[21]等人提出了一种行人识别系统,最终在 2017 年第一个针对 RGB-IR 图像的跨模态行人重识别方法被提出^[7],针对 RGB 图像与 IR 图像的通道数不一致的问题,作者取可见光图像中的两个通道做补零操作,增加红外图像两个通道并将通道值取零,这种处理方法被命名为 Zero-Padding,它在融合模态间异质差距方面具备优势。然而,跨模态行人重识别的研究目标不仅仅是平衡异质差距,还包括整合 RGB-RGB 模态内视觉差异与 IR-IR 模态内图像模糊的缺陷。因此,基于生成对抗网络的跨模态融合算法 CmGAN^[8]出现了,它显著提升了跨模态行人重识别领域的实验效果。然而,CmGAN 网络的高参数量使得收敛速度慢,同时对实验设备的性能要求很高,为此端到端的 dual-path 网络^[9]被提出,其结构更为简单,其原理是将不同模态的信号映射到同一特征子空间,用统一的度量标准去计算不同模态间的匹配度,为了融合不同模态的特征,同时提出了 top-ranking 方法。在同一个标准数据集下对比,dual-path 网络的实验效果优于 zero-padding 算法,但明显低于 CmGAN 模型,然而 CmGAN 网络收敛速度比 dual-path 与 zero-padding 慢了一定数量级,而且它们均忽视了红外和可见光不同的成像特点,会造成网络学习的特征量不对称。因此,跨模态行人重识别的目标效果是保证良好识别率的同时有不错收敛性能,为此,本文将拆分跨模态行人重识别的研究问题,具体可细化成跨模态图像的研究与行人重识别的研究。

跨模态图像研究的主要任务是减少图像视觉模糊的负作用,一般是通过提升图像的清晰度来解决,具体的方法有多尺度联合学习框架^[22]和尺度距离函数^[23],来处理损失局部数据的低分辨率图像。此外,也可利用低分辨(LR)图像和高分辨(HR)图像字典对^[24],将 LR 转化成 HR,来增强图像清晰度。本文运用超分辨率重建技术将 LR 图像提升至 HR 状态,在某种程度上能够弥补低分辨率条件下不同类型

的视觉特征损失,有利于降低图像视觉糊化的负影响。

行人重识别主要任务是提取合适特征,确保同一行人不同场合中提取到的特征是相近的,而应让不同人的图像提取到不同特征。早期的特征提取,专注于图像的颜色纹理信息,比如局部特征集成^[25]和形状外观建模^[26]等手工特征。近年来,深度学习方法开始用于行人重识别领域,并与传统方法对比后显示了更优良的效果。Li^[27]等人提出了一种过滤配对网,这是第一个利用深度学习方法处理重识别中特征提取问题。手动标记大量图像很昂贵,使得用于深度学习训练的数据(即真实数据)量不足。为了解决这个问题,生成性对抗网络(GAN)^[28]被用于生成人工样本数据,但是GAN网络的超参数多,时间成本高,不适合少量GPU训练。针对设备性能不高,图像场景下要求较精准的识别时,可采用Resnet^[6],其较小的网络尺寸,使得网络优化更为简单,可实现与GAN网络等同的识别性能,因此,本文将Resnet作为基本特征提取器。

现有的行人重识别技术依赖于单一尺度的外观信息,它过滤掉其他不同尺度隐藏的有用数据。针对上述问题,Liu^[29]等人提出了多尺度三元组神经网络MsTricnn,它通过组合子网络将不同分辨率以及不同尺度的特征融合。Qian^[30]等人提出了多尺度深度模型MuDeep,它实现了MsTricnn不具备的自动加权。Chen^[31]等人提出的深层特征金字塔网络,它抛弃了MuDeep不同尺度匹配不同行人的做法,而是将多尺度特征构造成金字塔,来应对跨尺度学习问题。本文将不同尺度特征融合表征多种语义的思想,运用到卷积层面,就是将Resnet网络中不同卷积层级的特征融合,以此实现图像多种语义信息的单一输出,这种方式融合了高层特征的强语义表征能力与低层特征的强几何细节表达形式,从而形成了高分辨强语义的特征。此外,为了将同一子空间相同标签的行人图像推到一起,将不同身份的行人图像拉开的更远,需要比较图像的特征距离,在跨模态行人重识别中,常见的度量特征间距离的方法,有欧式距离^[7]、SCM^[12]和CRAFT^[32],本文则采用欧式度量法学习区分样本。

1.3 研究内容与结构安排

本文深入研究了跨模态行人重识别的相关理论与关键方法,针对红外和可见光模态重识别存在的三种模态间异质差距的问题,提出了相应的改进方法,采用特征金字塔结构与超分辨重建技术实现改进,再经由实验结果分析,证实了本文方法的有效性。

首先,分析讨论了多种超分辨重建方法在跨模态重识别数据集上的效果。通过超分辨重建增强了图像对比度,提升了分辨率,直接将行人RGB图拉至清晰水平,以此缩小模态内差异,用可见光模态在训练中的优势,去降低红外图像由于视觉糊化效应造成的训练困扰。

其次,利用网络底层和高层分别学习图像的局部和全局的特性,来构建特征金字塔,可实现单模态不同网络层的特征学习。这种多级特征学习方法,集成了全局特征和局部特征学习的优势,既关注了整体表现,又保留了细节特性,设计的特征金字塔产生了高层联合特征,这种跨模态的融合特征在实际训练时减缓了异质差距的负影响,使得网络学习的特征量对称且稳定。然后,通过随机融合机制讨论了不同网络层级特征与模态间的组合关系,得到了随机融合金字塔的优化组合方式,相应地产生了随机融合特征。接下来,将随机融合特征与高层联合特征相互博弈,以实现基于多级多语义判别因子的联合模态和单模态的特征相似性识别。

最后,提出了跨模态混合损失函数,它通过显性化模态的差异并增加其权重,再利用联合模态与单模态间偏置将 RGB-RGB、IR-IR、RGB-IR 三种模态的损失函数融合,有效地修正了网络模型,使得跨模态的重识别学习具有综合性。

论文总共分为五章,具体内容组织结构如下:

第一章为绪论部分。本章首先阐述了行人重识别课题的来源及研究意义,并分成可见光和红外图像两种情况来说明当前重识别存在的缺点,简述了可见光模态识别时的解决方案与研究现状,并且由两种模态结合存在的相应问题提出了本文深度学习的跨模态行人重识别研究内容,最后叙述了文章的内容架构。

第二章为跨模态行人重识别的基本理论。本章首先简要介绍了解决跨模态行人重识别问题所需要的技术以及引入相关技术的原因,并按照技术使用的先后顺序分别概述了超分辨重建技术的基本理论与行人重识别的研究工作,最后讲述了红外和可见光模态的数据集与评估标准。

第三章为特征金字塔随机融合网络的研究。本章首先介绍了特征金字塔网络的产生背景与应用前景以及章节的研究工作和内容安排。其次,通过双分支残差网络初步抽取图像的特征,再将特征组合成金字塔结构,配合上采样技术完成跨模态多个尺度特征的提取。然后,通过随机融合机制,实现多级多语义特征的唯一输出。实验结果表明,本文提出的特征金字塔随机融合网络在红外和可见光条件下具备很好地识别效果与收敛性。

第四章为基于混合损失函数的多模态分类学习。本章首先从多个角度来介绍损失函数的设计,其次说明了跨模态行人重识别分类任务的基本流程与模型,然后对比分析了相关损失函数的优缺点,确定了交叉熵作为基础损失函数,再利用模态内视觉外观差异与模态间异质差距,从而提出了基于红外和可见光的混合损失函数,实验结果证实,提出的混合损失函数与分类学习模型均具有较好地效果。

第五章为总结与展望部分。总结本文研究工作,分析文中方法的创新及特点。针对研究方法中存在的不足进行了展望,探讨了后续课题待研究的方向。

第二章 跨模态行人重识别的理论

跨模态行人重识别问题可通过分别研究跨模态图像与行人重识别两个子问题来解决,如图 2.1 所示。其中,跨模态图像的研究目标是不同光谱图像在传进网络后没有造成过量噪声,本质上是提取不同模态图像的关键互补信息,这种存在互补关系的信息量很容易被冗余噪声干扰,在红外和可见光的行人识别领域中,这类冗余噪声实质是 IR 图像的视觉糊化结果。因此,跨模态图像的研究重心是减少视觉糊化效应的负作用,可以通过超分辨率技术来增加图像的空间分辨率,改善图像质量,还原行人 RGB 图的边缘,用可见光模态在训练中的优势,去降低由于视觉糊化效应造成的训练困扰。行人重识别(Re-ID)的研究目标是在某个摄像机视野中消失的特定行人再在下一个摄像头里识别出,它与常见的目标识别研究类似,本质上都是获取特定目标的身份信息再在数据库中查找出符合的对象。行人重识别课题经历了早期的行人检测再识别,到利用深度学习的行人分类学习模型,再到如今的基于卷积神经网络的重识别,它的识别效果也越来越精确。




图 2.1 研究跨模态行人重识别问题

Fig 2.1 Study of cross modality person Re-ID problems

2.1 超分辨重建图像的基本理论

2.1.1 超分辨重建算法的基础知识

由于数字成像系统等硬件设备的限制以及传输过程中的损耗,使得接收的图像往往会呈现分辨率低与细节模糊以及不符合人眼主观感受的系列问题。为了克服上述问题,最直观的办法是改进硬件设备,但这种方法不符合现有的技术水平,并且受到高昂生产成本的制约。为了克服现有硬件装置的种种限制,人们尝试凭借软件技术来提升图像的空间分辨率,以此改善图像的质量,这样的技术被称之为超分辨率重建算法(Super Resolution, SR)。SR 算法大致分为三个阶段:基于重建的

算法、基于样例学习的算法、基于深度学习的算法。基于重建的 SR 算法一般是将同一场景的多帧图像作为输入，运用多帧图像间信息存在耦合，去重建图像丢失的高频区域，它很显然存在只有利用多帧低分辨率图像才能完成重建的缺陷。为了突破这种限制，样例学习 SR 算法被提出，它利用低分辨率图像 (Low Resolution, LR) 和高分辨率图像 (High Resolution, HR) 对来训练字典，然后查询字典检索到输入图像中每个子块与之对应的高分辨率窗口，最后重组即为高分辨率图像，比较有代表性的算法有流形嵌入法^[33]和锚点近邻回归算法^[34]然而，基于样例学习 SR 算法的重建结果容易受到特征和邻域数量的影响，为了避免人工参与模型设计从而干扰重建效果，人们借鉴了机器视觉中从数据寻找答案的经验学习思想，利用从训练样本中学习到的 LR 与 HR 的映射函数来重建 HR 图像，这种策略被命为基于深度学习的 SR 算法。

深度学习的超分辨率算法运用神经网络自主提取丰富特征，再建模学习 LR 和 HR 图像间的复杂映射关系函数，建模的内容就是人们常说的退化模型，正如下图 2.2 示意，描述了原始高分辨率图像由于运动、散焦等外界不可抗力因素而形成真实低分辨率图的过程。




图 2.2 图像退化与重建过程

Fig 2.2 Process of degradation and reconstruction of image

从图中可以看出超分辨率重建的过程其实就是图像退化模型的逆过程，再根据退化模型的主要 4 个环节，几何形变、外界作用、下采样和噪声，推断出重建过程应包含图像形变、上采样与网络结构设计以及网络学习。一般情况，SR 算法的图像形变方法会与网络模型框架结合使用，并由此分为预先放大、逐级放大、交替放大缩小以及最后放大这四种；SR 算法的上采样是利用反卷积和亚像素卷积对特征做放大操作，它通常出现在输出层的上一层，这样是能够加速网络的收敛；它的网络结构设计，强调的是学习那些更有用的数据来补充图像中缺失的细节，从而提升重建图像的质量，经典的网络算法有 SRCNN^[35]、FSRCNN^[36]、VDSR^[37]、DRCN^[38]以及 EDSR^[39]，并于 2.1.2 节做了详尽说明；它的网络学习策略主要分为基于像素的损失^[40]、基于内容的损失^[41]、基于纹理的损失^[42]，学习策略可以恢复出更加真实的纹理信息，它不再仅限于还原出清晰的边缘，可以使得重建出来的图像整体比较平滑，更符合人的主观视觉感知。

2.1.2 基于深度学习的超分辨重建方法

深度学习的超分辨率重建策略早已成为图像重建的中流砥柱，相较于其他传统算法而言，斩获了较为满意的效果，本节内容将介绍和改进并总结 5 种主流的 SR 算法，并在跨模态行人重识别领域的同一数据集上应用到预处理任务中，经过对比分析重建图像的质量，进而选定本文应采纳的重建方式，以此提升 Re-ID 算法精度。SR 模型原理决定了倘若原图片视觉模糊，经过超分重建后，图像会更糊化。然而跨模态 Re-ID 的公开数据集里红外摄像头捕获的图片很模糊，因此不能作为 SR 网络的输入，只能预处理可见光摄像头下 RGB 图像。

第一个深度卷积网络的超分辨率重建算法是 SRCNN^[35]，其框架十分简洁，只有三个卷积层，经过简单改进后，在标准数据集上运用，具体是将 128*128 大小的 3 通道彩图做水平翻转后，输入模型，然后使用双三次插值将目标放大 2 倍，并取颜色空间 YCrCb 中 Y 通道，接着对 Y 通道做 9*9 卷积以提取特征，此时特征通道数为 64，再经过 1*1 卷积拟合特征的非线性映射，最后反卷积重构出大小 512*512 的特征，详尽结构如表 2.1 所示，网络微调后输出高分辨 256*256 尺寸的行人图。

表 2.1 SRCNN 超分辨结构

Table 2.1 Super-resolution structure of SRCNN

layer	input size	input channel	output size	output channel	structure
preprocessing	128*128	3	256*256	1	bicubic interpolation (2)
conv1	256*256	1	256*256	64	9*9, stride=1
conv2	256*256	64	256*256	32	1*1
conv3	256*256	32	512*512	1	5*5, stride=1, PixelShuffle (2)

相较于 SRCNN，FSRCNN^[36]的网络层度更深了，如下图 2.3 所示，而且 FSRCNN 引入了反卷积层进行特征还原。由反卷积层可以直接将原始 LR 图像传进网络中，它摒弃了 SRCNN 预插值的操作，这能够大幅度降低模型的运算量，因此训练速率加快了。




图 2.3 FSRCNN 与 SRCNN 对比

Fig 2.3 Comparison of FSRCNN-to-SRCNN

VDSR^[37]与 SRCNN 技术的类似之处，均是在预处理阶段对原始 LR 图像做插值处理，以此来获得目标尺度的图像，然后将其输入到网络中进行训练，再利用高低分辨率图像对之间存在的高频残差完成重建过程。VDSR 网络的特点是每轮卷积后采用零填充方法，这样可以避免了逐层卷积造成的特征感受野越来越小的问题，同时引入了残差单元有效防止了梯度爆炸。

DRCN^[38]将递归神经网络结构首次应用在超分辨率重建领域，它通过循环修正，使得输入越来越接近目标图像，再通过引入了跳跃连接机制，来解决循环神经网络存在梯度消失的问题。EDSR^[39]模型通过堆叠网络层来提取更多的特征，为了避免内存耗费过多，它摒除了批规范化层，同时用独立训练的低倍数模型产生的超参数来初始化高倍数结构，目的是为了加快高倍数网络的训练。

上述超分辨重建 SRCNN、FSRCNN、VDSR、DRCN 以及 EDSR 算法均在 Pytorch 框架上训练，在跨模态 Re-ID 的同一标准数据集上对比重建 2 倍和 4 倍的图像质量。根据图像质量评估标准，PSNR 数值越大表明重建结果越趋近原始 HR 图像，由表 2.2 五种 SR 算法重建效果对比，可知本文应采用 SRCNN 技术预处理数据集。

表 2.2 五种 SR 算法对比

Table 2.2 Comparison of five SR methods

SR name	2X/db	4X/db
FSRCNN	28.98	26.14
VDSR	27.12	28.03
DRCN	28.22	28.79
EDSR	24.13	26.61
SRCNN	30.12	29.18

2.2 行人重识别的基本理论

2.2.1 行人重识别的基础知识

行人重识别所要完成的任务就是在一个摄像头拍摄的图片中存在一个人需要识别出该人在其它剩余几个摄像头下出现的画面，因此行人重识别技术又被称为“跨镜追踪”技术。在 2005 年，Zajdel^[43]等人在多相机追踪任务的工作中首次提出“行人重识别”一词，作者运用贝叶斯网络并借用行人颜色、时空变化等特征的相似性将跨摄像头的目标活动轨迹关联起来，探讨了指定行人在某个摄像机视野中消失后再在下一个摄像头监控里辨别出的问题，据此行人重识别课题成为一个独立的研究项目。

早期阶段，受制于低级别的计算机硬件发展水平和小规模的数据集，传统的行人重识别系统主要由行人检测和行人重识别 2 个功能模块组建，正如图 2.4 所示。其中，行人重识别模块专注于手工设计出更具辨别力的视觉特征和设计出合适的距离度量方式，然后再进行特征匹配与排序。然而，传统 Re-ID 鲁棒性差，识别准确率不高，不能较好的应用于复杂多变的真实场景。近些年，随着深度学习工作的发展，深度学习在计算机视觉中很多经典任务上都取得了前所未有的成效，其展现出的优秀性能受到行人重识别学者们的高度欢迎。




图 2.4 传统行人重识别系统

Fig 2.4 Traditional Re-ID System

深度学习方法可以学习多种抽象级的数据特征，它允许计算机凭借简单的基础概念来学习复杂的高级语义，在深度学习的行人重识别课题项目中，最为出彩注目的是卷积神经网络，它拥有卓越的自学习能力，可以挖掘出图像中关键的特征，并具备良好的容错性，允许样本数据存在一定程度的缺损，能够妥善地处理复杂场合下行人识别的问题。基于卷积神经网络 Re-ID 的主要流程如下：从原始监控视频画面中自动提取行人的特征表达，然后对应解决特征的分类和验证问题。其中，分类问题是指利用行人的 ID 或者发色等细节属性作为训练标签来训练模型，验证问题指的是网络判别同时输入的两幅图片是否类属同一个 ID 号。

行人重识别技术在现实场景的各行各业大显身手，在公共安全行业，Re-ID 策

略可以对拍摄到模糊人脸的行人进行跨摄像机的连续追踪定位,有利于警察快速筛选出可疑人员,同时运用我国部署的“天网”,可以在一定时效内将所有监控摄像头的视频传播到控制中心进行分析,可以实现快速精准重拳打击犯罪分子;在智慧交通范畴,Re-ID方法可以完成人车无界互连,产生人、车、路三位一体的全自动闭合集;在人流、物流的统计调控领域,Re-ID技术可以自动化的完成人员的调配、车辆的选送、路线的规划等,能够很大程度地节约时间消耗和物资成本。

2.2.2 传统的行人重识别

传统的行人重识别研究与常见的目标识别工作类似,主要分为两个步骤,特征表达和特征度量,其中特征表达别名特征提取,它是用一个矩阵向量表达图像的全局或局部信息,常用的如颜色、纹理等基础特征,特征度量是指度量多个特征间的相似性,并将置信度高的几个特征视为源自同一个身份ID,常见的早期特征表达方式,本文将介绍以下几种:

1. 梯度方向直方图

梯度方向直方图(HOG)方法由Dalal等人^[44]提出,是用于描绘图像在局部范围的梯度方向和幅值分布,它利用梯度常在图片中各部分的边缘发生突变,来描述局部图像的边界和形状内容,简单来说,它是一种局部性特征。求解图像的梯度直方图特征,首先要把图像分割成一个个小的窗口(cell),然后挨个度量cell的梯度直方图特征,再将所有cell的HOG特征收集组合,并做标准化规范就得到了输出的HOG描述符。那么,求解行人图像HOG特征问题就化解成了度量cell的HOG特征,具体可以凭借计算每个像素点在水平、竖直两个方向上的梯度来获取cell的特征,计算方式如公式(2.1)所示。

$$\begin{cases} G_x(x, y) = I(x + 1, y) - I(x - 1, y) \\ G_y(x, y) = I(x, y + 1) - I(x, y - 1) \end{cases} \quad (2.1)$$

其中, $I(x, y)$ 、 $G_x(x, y)$ 、 $G_y(x, y)$ 表示图像在坐标 (x, y) 处的像素大小和该像素节点在水平和竖直两个方向上测算的梯度值。再通过公式(2.2)计算该点上的梯度大小 $G(x, y)$ 和方向 $\theta(x, y)$ 。

$$\begin{cases} G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \\ \theta(x, y) = \tan^{-1} \frac{G_y(x, y)}{G_x(x, y)} \end{cases} \quad (2.2)$$

HOG特征通过量化图像具体区域的数值和方向,能够有效减少评议和旋转结果的副作用,同时使用标准化策略,能够减轻局部光照变化的负作用,但是缺点也很明显,对图像上的干扰比较敏感,且存在一定的实时性问题。

2. 纹理特征

局部二值LBP^[45]是计算机视觉行业常用的纹理特征算法,它是从图像的结构和统计分析层面解析行人活动图的特征。其计算过程如下:

首先把窗口划分成统一尺寸的 cell 块来进行检测；其次将 cell 块中的每个像素（记成 anchor）与它的 8 邻域点进行对比（即左上、左中、左下，正上，正下等），如果周围像素的值大于 anchor 数值，则记为 1，反之设置为 0，并且以一个固定顺序顺时针或者逆时针记录，这样就得了个八位的二进制编码，它代表的是 0 至 255 间的一个数字，该数字即为 anchor 的 LBP 特征数值，LBP 的编码过程可用公式(2.3)表示：

$$\begin{cases} LBP(\cdot) = \sum_{i=0}^7 S(P_i - P_c) \cdot 2^i \\ S(i) = \begin{cases} 1 & i \geq 0 \\ 0 & else \end{cases} \end{cases} \quad (2.3)$$

其中， P_c 表示 anchor 节点的灰度大小， P_i 表示 8 邻域其它的像素值；在完成 anchor 的 LBP 编码后，需要算出每个划分后子块的直方图，然后做标准化处理；最后，串联所有 cell 的直方图，组成了当前窗口内的一个特征描述矢量。

2.2.3 基于卷积神经网络的行人重识别

不同于传统的行人重识别，深度学习的卷积神经网络 Re-ID 技术依赖大量数据作为学习样本，它不需要手动设计特征，并能够自动提取输入行人图像的特征并分类识别。一个完整的卷积神经网络（CNN）通常包括输入层、输出层以及多个隐藏层。其中，隐藏层又由以下几个部分组成：卷积层、池化层、激活层、全连接层，下图 2.5 展示了经典 CNN 结构。




图 2.5 卷积神经网络的基本结构

Fig 2.5 Basic structure of CNN

1. 卷积层

卷积层是卷积神经网络的核心部件，它用于传进图像或特征图的卷积运算，以得到更高层的特征表达，计算策略是将输入图像的区域和滤波器的权重矢量做点积算术，整幅图像重复进行着相同的点积处理，即可得到图像的特征表达，具体地卷积过程如下图 2.6 示意。

输入图像单通道值					
251	122	125	206	120	161
30	29	55	52	2	162
129	136	40	139	101	80
50	5	141	104	232	209
67	1	4	243	170	33
15	145	10	101	219	62

卷积核		
1	0	1
0	1	0
1	0	1

卷积结果			
574	658	438	588
412	230	569	628
245	660	419	727
217	359	845	646

图 2.6 卷积计算

Fig 2.6 Calculate convolution

本文以 1 通道 6×6 的传入图像为例，卷积核定成 3×3 ，步长记为 1，那么有，原始输入行人图中首轮卷积运算的区域是图 2.9 左边灰色像素域，将其中每个像素值与对应卷积核中的值相乘得到一个结果，填充入图中右边的卷积结果栏列；随后传进图像的灰色覆盖域右移 1 个像素位置；当移动到行末尾时，该区域窗口向下移动一个步长，并从原始输入最左边位置起重复上述计算过程，直至拿到整幅图像的卷积内容。从卷积操作的过程可以看出，卷积过程实质就是一个简单的模板匹配过程，而且这种模板匹配中的模板是可自动学习的，而非人工设计的。通常来说，卷积核大小远要小于输入图像的尺寸，常见的有 1×1 大小的卷积核，其作用是改变特征向量的通道数，从而降低参与运算的参数量，进而减小网络大小和训练时间成本。目前主流卷积核设定是 3×3 ，在实际使用效果中证明了这种小尺寸的卷积核能够提取到更具有代表性的特征表示。

2. 池化层

由于大多数卷积步长都是取 1，并且为了不丢失图像边缘特征而不可能将卷积核尺寸设置过大，当出现输入大图像情况时，为了克服网络过深的问题，池化层应用而生，其作用是缩小特征空间维数。卷积层实现了行人图像的初步特征提取任务，池化层则在卷积结果中，凭借下采样技术提取图片的主要特征，因此池化层也可以视为是降维操作。最大值池化和均值池化是目前常用的 2 种在卷积神经网络中的池化关系函数，如图 2.7 所示，最大值池化是对邻域内的特征点求最大值，平均值池化是对输入区域内所有的像素值取平均。




图 2.7 最大池化和均值池化过程

Fig 2.7 Process of max-pooling and mean-pooling

3. 激活层

深度学习中最重要的是要通过网络学习某种非线性函数映射关系，这种非线性运算由网络中激活函数达成，本质是将卷积结果压缩在一个较小的可控维度空间。为了保障单层神经网络具备凸函数的特性，将原本卷积的线性框架转换成非线性结构，这样更有助于梯度在网络中的反向传播，而且更适应于图像的表达方式，常用的激活函数有 Sigmoid(x)，ReLU(x)，LeakyReLU(x)等。

Sigmoid 的数学表达为下式 2.4，据此本文绘制了函数曲线图和导数图 2.8。

$$S(x) = \frac{1}{1+e^{-x}} \quad (2.4)$$




图 2.8 左边为 Sigmoid 函数曲线，右边是 Sigmoid 导数图

Fig 2.8 Sigmoid function and derivative curve are located on left and right respectively

观测左边图像得知，Sigmoid 函数值域在 0-1 范围内波动，存在取到边界 0 或 1 的可能性，此时右侧对应的梯度无限逼近于 0，这会引起神经网络在用梯度反向传播训练时，发生梯度消失的现象，从而让网络整体的权重参数无法更新，也就无法达成深层网络的训练，因此它一般不作为网络隐藏层的激活函数，而是运用在网络最后一层。

下式 2.5 为 ReLU 表达式，据此而描绘了函数曲线图和导数图 2.9。

$$R(x) = \begin{cases} x & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases} \quad (2.5)$$




图 2.9 左边为 ReLu 函数曲线，右边是 ReLu 导数图

Fig 2.9 ReLu function and derivative curve are located on left and right respectively

由上述图像可知，输入信号小于 0 时，传出结果均是 0，当输入信号出现大于 0 情况，则有输出值等同于传入的数值，此时对应右侧的梯度值是 1，这无疑是解决了 Sigmoid 函数中输入信号极大或极小时梯度接近 0 而产生梯度消失的缺点。值得关注的是，当网络学习率设置的过大，造成输入信号呈现一直为负的情况，这很可能会导致大部分网络神经元进入死区。

LeakyReLU(x)是 ReLu 激活映射函数的改良版，是为了解决 ReLu 函数中零区间带来的权重无法激活更新的缺陷，其数学表达公式为下式 2.6，超参数 α 是极小的常数，通常取[0.01, 0.03]之间的值，本文设定 $\alpha = 0.01$ ，并据此绘制了函数图和导数曲线图 2.10。

$$L(x) = \begin{cases} \alpha x & \text{if } x \geq 0 \\ x & \text{if } x < 0 \end{cases} \quad (2.6)$$




图 2.10 左侧是 LeakyReLU 函数曲线，右侧是 LeakyReLU 导数图

Fig 2.10 LeakyReLU function and derivative curve are located on left and right respectively

对比观察 LeakyReLU 与 ReLu 的梯度图像得知，LeakyRelu 函数修正了输入信号低于零的问题，确保了负半轴所有信息量不被丢失。

4. 全连接层

常规的神经网络具备 2 个全连接层 (Fully-connection layer, FC), 第一个 FC 将提取到的各部分特征展平并按顺序逐次连接到同一个向量空间, 第二个 FC 类似于分类器, 将存在区分度的矢量特征经由线性变换映射至样本标记空间, 这一过程可以看作预测图像属于哪一类。

当神经网络训练的样本分布存在不均匀现象时, 这会导致全连接层中的每个权重向量高度相关, 进而容易产生预测错误分类概率增大的问题, 直接降低了识别精度。此外, 利用欧几里得距离度量样本是基于特征向量中条目互相独立的假设, 也就意味着样本分布不均衡, 必然导致部分特征度量模糊, 特别的是, 相似条目容易出现错分类属的情况, 间接导致排名结果差。例如, CNN 模型训练完成后, 在测试阶段中, 两个不同的行人视频帧, 生成了绿色和黑色的特征矢量, 然后投影到 3 个不同权重向量 $\vec{w}_1$ 、 $\vec{w}_2$ 、 $\vec{w}_3$ 上, 如图 2.11 所示。由于红色 $\vec{w}_1$ 和粉红色 $\vec{w}_2$ 矢量高度相关, 蓝色向量 $\vec{w}_3$ 相对来说几何投影较远, 因此 $\vec{w}_1$ 与 $\vec{w}_2$ 构成一个描述符用来表示绿色的特征, 这就引入了冗余, 使得容易误判绿色行人 ID。




图 2.11 误判行人类别

Fig 2.11 Misjudgment Person's ID

为此, 奇异向量^[46]被引入到 Re-ID 全连接层, 作用是降低特征向量间的耦合度, 去除大部分矢量的冗余, 并且能够加速模型收敛, 同时减小错分类情况的发生, 提升网络预测正确行人的概率。该方法首先将第一个全连接层传出的矩阵 W 进行奇异值分解, 分解形式如公式 2.7 示意。

$$W = XYZ^T \quad (2.7)$$

这里 X 是左秩矩阵, Y 是奇异值矩阵, Z 是右秩矩阵。 W 完成分解后, 然后用 XY 取代原来的 W , 此时, 公式 2.7 更新为下式:

$$W = WZ^T \quad (2.8)$$

显然, 公式 2.8 的结果为一个正交阵, 这意味着第一层 FC 的结果 W 直接变

成了正交阵,然后再将所有的特征矩阵 W 固定住,并继续学习其它网络层的参数,直至网络收敛,最后再取消固定 W 的限制,继续训练模型直至重新收敛为止。

2.3 评估指标

2.3.1 超分辨重建算法的质量评价标准

无论硬件和软件算法如何进步更新,重建后的图像始终与理想中目标图像存在一定差距,这是由于无法完全恢复低分辨率图像损失的所有高频细节内容,因为图像采用的重建算法自身的性能与运行效率会影响重建后图像的效果,因而需要评判图像重建的质量好坏,常见的评价超分辨重建图像质量的方法,主要有主观法和客观法。

主观法是指人眼视觉感受做出的直观评价,又分为绝对评价和相对评价。绝对评价,评价者一般会根据自身经验,从图像边缘是否清晰,纹理是否丰富,细节是否恢复以及图像中噪声是否严重等来进行评价打分。具体是按照规定的平均意见得分(MOS)规则对重建图像评分,根据一定的标准以及视觉感知效果从1分(质量差)到5分(质量好)进行评估,再将所有人的评分累加取算术均值的结果记为MOS。相对评价,顾名思义是对所有参与比较的图像进行从高到低的质量排序。虽然,主观方法更符合实际生产与应用,但主观评价由于主观意识的影响使得结果具备很大的不确定性。评估的效果明显受到观察者状态、经验和水平的影响,同时也没有相关标准来估算视觉感知能力,而且明显在实时图像质量评判行业无法应用。

为了提供实用的图像质量评估,基于图像相关系数的客观质量评价方法应用而生,它将高分辨率图像和原始图像中相关参数作对比,然后使用给定的计算公式定量评价图片。目前主流的超分辨率重建技术都是基于原始高分辨率图像做的退化处理,因而本文采纳了全参考峰值信噪比(PSNR)质量评估法。PSNR取值范围为0-100分贝(db),一般情况它的数值在20到40范围内波动,数值越大代表重建的图像质量越光滑,噪声更低,结果越趋近原始高分辨率行人图。PSNR是根据下面公式2.9计算得到:

$$PSNR = 10\log_{10} \frac{\max_I^2}{MSE} \quad (2.9)$$

式2.9中 $\max_I$ 代表行人图中最大像素值。一般来说,如果图像的单通道宽度为 n ,则 $\max_I$ 取值为 2^n-1 。MSE 是指图像的像素值均方差,定义如式(2.10)所示。

$$MSE = \frac{1}{LW} \sum_{i=0}^{L-1} \sum_{j=0}^{W-1} \|I(i,j) - K(i,j)\|^2 \quad (2.10)$$

这里, I 是真实图像, K 是重建后的超分辨图像, i, j 为像素点位置, L 和 W 分别是图像的长与宽。

2.3.2 行人重识别的评估标准

在行人重识别中,用于查找的图像集合称为 **probe**,用于搜索的图像集合称为 **gallery**。本文采用单次全搜索评估协议^[6],协议主体是:训练阶段,296 个样本全部用于训练;测试阶段,将 RGB 监控样本作为 **gallery set**,IR 摄像机捕获的图像作为 **probe set**,通过计算给定的 **probe** 图像和 **gallery** 图像之间的相似度来进行匹配,其中,**gallery set** 是由 RGB 相机下随机选择一至十个行人图像组成的。面对多镜头的配置条件,度量相似度后,将返回一个列表型的结果图集,该集合是检索图像相似度匹配的降序组合,再用结果图集中最靠前的 n 幅图里出现正确样图的概率来估算行人重识别的准确率,这种度量重识别效果的方式被称之为 **rank- n** ,本文重复实验 10 轮次,取平均值作为传出的 **rank- n** 。按照理论,常见的 **rank-1** 和 **rank-5** 分别表示了结果图集中排在第 1 个和前 5 个的图像中存在和对应检索图像正确匹配的比例,以此类推,**rank-20** 表示返回的图像列表中排在前 20 个图像中符合目标图片的比率,详细地计算过程如下示例:

第一步:给定 3 张不同的图像 P_1 、 P_2 、 P_3 作为 **probe set**,从 100 个 **gallery** 样本中搜索识别;

第二步:对应返回 3 张相似度降序排名的图像列表,分别是 $[P_4, P_2, P_3, P_5, P_6 \dots]$ 、 $[P_1, P_2, P_3, P_4, P_{99} \dots]$ 、 $[P_3, P_1, P_2, P_{10}, P_{22} \dots]$,相似度分数值越靠前说明这两张图像越接近,意味着一个较近的匹配。

第三步:计算 $\text{rank-}n = \frac{\sum_{x=1}^3 \text{前}n\text{个位置的识别结果是否有}P_x}{\text{待查找图像的个数}}$

$$\text{rank} - 1 = \frac{0 + 0 + 1}{3} = 33.33\%$$

$$\text{rank} - 2 = \frac{0 + 1 + 1}{3} = 66.66\%$$

$$\text{rank} - 5 = \frac{0 + 1 + 1}{3} = 66.66\%$$

mAP(mean average precision)也是图像识别问题重要的评估指标,它体现了算法在整个测试集上的平均性能,它由精度 **P** 和平均精度 **AP** 两部分构成。精度 **P** 反应了结果图集 G 中相关对象 x 所占的比率,那么有如下公式的检索精度 $P_X(G)$:

$$P_X(G) = \frac{G}{C_x(G)} \quad (2.11)$$

这里, $C_x(G)$ 表示查询到第 x 个相关项时已经遍历到的行人图像数目。平均精度 **AP** 是结果图集 G 中所有对象的查询相关项的精度数的平均反映,即有下式:

$$AP(G) = \frac{1}{N(G)} \sum_{x=1}^{N(G)} P_X(G) \quad (2.12)$$

其中, $N(G)$ 是一轮检索中所有相关对象的总数,因此总轮次的检索情况的平均精度的均值 **mAP** 则为下式:

$$mAP = \frac{1}{t} \sum_{t \in G} AP(G) \quad (2.13)$$

若所有的相关图像都靠前列，此时有 $mAP=1$ ，若存在所有相关对象均被排斥到后面位置的情况，这意味着图像间愈发的不相似，此时的 mAP 值为零，故有 mAP 值域属于 $[0,1]$ 。

2.4 数据集

红外和可见光两种模式之间存在巨大区别，如图 2.12 所示，第二行中的 RGB 视频帧涵盖了 3 通道的可见光颜色信息，而第三行中的 IR 画面只包含了 1 个通道颜色的数据量，另外，从成像原理层面来看，RGB 和 IR 视频帧的波长范围存在差异，因此 RGB 和 IR 图像实质上是不同类属的异质数据。现有的行人重识别工作中，颜色信息常被作为识别目标人的最重要的线索，但是在跨模态（RGB-IR）重识别问题中，几乎不能利用颜色线索，而且基于 RGB 的行人重识别由于视角变化、姿势和曝光等问题导致类内差异较大，这也会增加研究跨模态 Re-ID 的困难度。为此，Wu^[9]等人收集了一个新的数据集，称为 SYSU Multiple Modality Re-ID (SYSU-MM01)数据集。




图 2.12 每两列中的图像是同一个人

Fig 2.12 The images in every two columns are of the same person

作为跨模态行人重识别课题第一个标准数据集 SYSU-MM01，它与现有的常用 Re-ID 数据集不同，具体如表 2.3 所示。它拥有 491 个人，287628 张 RGB 图和 15792 张 IR 图像，本文对数据集进行了固定拆分，296 人分到训练集，验证集 99 个人和测试集 96 个人。

表 2.3 SYSU-MM01 与常用 Re-ID 数据集对比

Table 2.3 Comparison between SYSU-MM01 with existing Re-ID datasets

Datasets	ID	images	cameras	RGB	IR
CAVIAR [5]	72	610	2	yes	no
CUHK01 [19]	972	1942	2	yes	no
PRID2011 [11]	200	971	2	yes	no
CUHK03 [20]	1467	13164	6	yes	no
Market [53]	1501	32668	6	yes	no
MARS [52]	1261	1191003	6	yes	no
SYSU-MM01	491	287628 / 15792	6	yes	yes

SYSU-MM01 数据集的主体情况如表 2.4 所示, 它由 6 个摄像头来捕捉行人图像, 具体是 4 个 RGB 和 2 个 IR 摄像头, 红外摄像机编码是 3 号和 6 号, 且 3 号摄像头是位于室内无光空间中的 2 号房, 摄像机 6 号搁置在附带背景杂物的室外黑暗通道中, 摄像头 4 号和 5 号作为 RGB 监控, 分别放置在进出门和公园的室外场景。对于每个行人而言, 至少拍摄了 400 张不同姿势和视角的 RGB 画面, 并且至少被两个不同位置和视角的摄像头捕获。

表 2.4 SYSU-MM01 数据集内容

Table 2.4 Overview of SYSU-MM01 dataset

camera	location	(in/out)door	lighting	ID	RGB ID	IR ID
1	room1	indoor	bright	259	400+	---
2	room2	indoor	bright	259	400+	---
3	room2	indoor	dark	486	---	20
4	gate	outdoor	bright	493	20	---
5	garden	outdoor	bright	502	20	---
6	passage	outdoor	dark	299	---	20

2.5 本章小结

本章首先介绍跨模态行人重识别的起源与发展以及存在的两个大问题, 简单说明了解决问题所需要的技术; 其次简叙了超分辨率重建图像技术的起源与发展以及基本原理, 对深度学习的超分辨率重建算法详尽说明, 重点阐述 5 种重建算法, 分别是 SRCNN、FSRCNN、VDSR、DRCN 以及 EDSR, 并于统一标准数据集上评估了它们的性能, 根据图像质量评价规则, 确定本文该使用改进的重建算法 SRCNN; 然后简述行人重识别课题来源、发展趋势与应用, 根据发展趋势可将行人重识别分为传统的和深度学习这两种, 在传统的 Re-ID 工作中, 主要讲述了两种早期的特征表达方式, 梯度方向直方图和局部二值模式, 在深度学习的 Re-ID 研究中, 主要叙述了基于卷积神经网络的图片训练并识别的流程; 再然后概述 SR 算法和 Re-ID 领域常用评价标准; 最后介绍了红外和可见光模态的 Re-ID 数据集 SYSU-MM01。

第三章 特征金字塔随机融合网络的研究

3.1 引言

伴随着卷积神经网络的深入使用，不断地给图像识别带来了一个接一个的突破，人们不停的探索更加深层次的网络模型，期望找到永久的图像识别解决方案，然而，研究结果表明，网络在训练过程中并非层次越深越好，过度的拟合会提高模型的错误概率。在 2015 年微软的 4 名华人学者提出了 Resnet Unit 结构^[47]，并利用该结构成功训练出深达 152 层的神经网络，于当年 ILSVRC 赛季获得冠军。Resnet 网络通过将输入的数据直接输出到输出层的方式保证了信息的完整性，这种端到端的思想，影响了后续很多学者，它把网络学习的重心放到了输入和输出之间，这可以降低优秀模型的设计难度。Resnet 规格化的结构，较小的模型尺寸，使得网络优化更为简单，与此同时也大幅度提升了图像识别的精准度，而且加速了网络的收敛过程，具备良好的跨模型特性，可以直接嵌入到 R-CNN^[48]等网络中，随着 Resnet 的嵌入研究，目标检测算法 Faster-Rcnn^[49]也由此诞生。

在 Resnet 网络中，全连接层的特征维度大小被提前设置了，所以网络的输入图像是固定尺寸的，这就造成了图像分割效果不佳，因为没有学习到充足地细节信息。为此，学者 Lin 等人^[50]注意到，浅层网络能够学习到图像的丰富细节，网络高层能够学习图像的整体表现，故提出了特征金字塔结构。它综合了低层网络的局部特性与高层网络的全局视角，因而被广泛应用在图像分割与图像识别等工作环境中，用于识别任务时，它的每一层网络都可以进行分类预测和边框回归。

随着监控摄像头成本的下降，大范围的安防摄像机被安装，海量的监控视频亟待处理，视频中的行人识别问题被重点关注，基于 Resnet 的重识别只能学习到固定尺度的特征。然而，跨镜追踪特定行人往往需要多方位学习，学习行人的整体特性、局部属性以及重要特点，以减少误判情况的发生。为此，本章借鉴特征金字塔网络的思想，将 Resnet 网络中不同卷积层逐级构造成金字塔结构，如图 3.1 所示，不同尺度的特征进行融合，完成了图像多类语义消息学习的任务。并且采用端到端的设计，用于避免金字塔模型过高参数量的问题，这种方式不仅关注了不同尺度隐藏的有用信息，而且参与运算的参数不高，表征了更具强语义和强几何细节的特征，从而解决了跨尺度多模态行人学习问题。

本章网络处理跨模态行人重识别任务的基本流程如图 3.1-3.2 示意：首先，基于 SRCNN 算法预处理数据集后，对两种模态的图像分别将金字塔结构的思想嵌入到 Resnet 网络中作为特征提取模型，提取到高层联合特征 IR-RGB block；其次，利用随机融合机制作为特征融合模型的基础，以完成端到端的设计，得到了随机融合特征 fusion block；然后将 IR-RGB block 与 fusion block 互相博弈，把相似性排

名最高的作为最终的红外和可见光 Re-ID 特征结果；再使用 ReLu 激活函数，获得一个合适的概率分布，同时应用交叉熵损失函数训练至收敛；最后，用原始的 SYSU-MM01 数据集测试模型。




图 3.1 特征金字塔随机融合网络结构示意图

Fig.3.1 An illustration of the framework for feature pyramid random fusion network




图 3.2 特征金字塔随机融合网络的流程

Fig.3.2 An illustration of the process for feature pyramid random fusion network

3.2 特征提取模型

本章提出的特征金字塔随机融合网络结构，可以从红外场景和可见光场景中

抽取和融合行人特征。前者特征提取模型，抽取了从高级到低级不同层级两种模态的图像特征。后者融合模块，将抽取到的不同层级的特征不区分模态的随机融合。

特征提取模型摒弃了原始金字塔网络不同尺度匹配不同行人的做法，而是将 Resnet 网络中不同卷积层级的特征构造成金字塔，这种深度残差网络与金字塔单元互相嵌入的学习方式，可以表征多种语义的图像特征。

特征提取模型是以 ImageNet 上预训练的 Resnet-50 为基本框架，学习 RGB 模态和 IR 模态下的图像特征，记 r 表示 RGB 模态， i 表示 IR 模态，生成的特征图用 C 标记。标记 Resnet-50 卷积层生成的不同层级特征，第 k 层为 C_k ， $C_k \in C$ ，且不同模态的特征图分别用 C_{r_k} 与 C_{i_k} 表示，即有 $C_k = C_{r_k} \cup C_{i_k}$ 。其中， C_k 是由一定数目的残差单元组成，一个残差单元涵盖两层结构，如下图所示，当输入信号为 x ，传出信号 y 的数学表达如下式 3.1 示意。

$$y = F(x, L_m) + x \quad (3.1)$$

这里的 L_m 表示第 m 层权值，函数 F 的内容如下式(3.2)，其中 φ 是非线性映射函数 ReLu。




图 3.3 残差单元

Fig 3.3 Residual unit

第一个残差单元接收的信号是预处理后的，通过对图像预处理操作，平衡了两种模态间异质差距造成的不对称的特征学习过程。输入的图像尺寸为 288×144 ，它经过 2 步长和 7×7 大小的卷积核，生成 2 维特征图矩阵，其中行分量为 72，列分量为 36，且通道数是 64，每层卷积参数的详尽配置如表 3.1 所示，5 层残差卷积后生成了 2048 通道的特征图 C_5 ， $C_5 = \{C_{i_5}, C_{r_5}\}$ 。 C_5 再经平均池化，形成包含两种模态大小均为 1×1 的特征，并分别用 RGB block 和 IR block 标记。然后，将特征 RGB

block 和 IR block 串联的结果，作为高层联合特征 IR-RGB block。

表 3.1 基础网络结构

Table 3.1 Basic network structure

layer	input size	output size	structure
C ₁	288*144	72*36	7*7,64,stride=2
C ₂	72*36	72*36	3*3 max pool, stride=2, $\begin{bmatrix} 1 * 1,64 \\ 3 * 3,64 \\ 1 * 1,256 \end{bmatrix} * 3$
C ₃	72*36	36*18	$\begin{bmatrix} 1 * 1,128 \\ 3 * 3,128 \\ 1 * 1,512 \end{bmatrix} * 4$
C ₄	36*18	18*9	$\begin{bmatrix} 1 * 1,256 \\ 3 * 3,256 \\ 1 * 1,1024 \end{bmatrix} * 6$
C ₅	18*9	9*5	$\begin{bmatrix} 1 * 1,512 \\ 3 * 3,512 \\ 1 * 1,2048 \end{bmatrix} * 3$
RGB block 和 IR block	9*5	1*1	average pool

特征C₅用 1*1 尺寸的卷积核 ω_1 来降维，生成了通道数为 256 的特征 P_5' ，如图 3.1 所示，其中， P_k' 是特征图 C_k 卷积系列的表达。上采样可让图像拥有高分辨率的特质，本文将双线性插值上采样后的 P_5' 与 1*1 卷积后的特征图 C_4 ，两者按元素相加，之后再用 3*3 的卷积核 ω_2 来避免上采样造成的混叠现象，形成了特征 P_4' ，正如表 3.2 所示。

表 3.2 构建特征金字塔

Table 3.2 Building feature pyramid

layer	C_5	C_4	C_3	C_2
step1	1*1,256, stride=1			
step2		$P_5' \uparrow$	$P_4' \uparrow$	$P_3' \uparrow$
step3		+	+	+
step4		3*3,256, stride=1		
output size	9*5	18*9	36*18	72*36
hidden layer	P_5'	P_4'	P_3'	P_2'
step5	average pool			
output size	1*1	1*1	1*1	1*1
result layer	P_5	P_4	P_3	P_2

第一步：获取特征 C_k 通过 1*1 卷积核 ω_1 的结果。我们注意到 C_1 过大的参数量，因此，只对特征金字塔 $C = \{C_5, C_4, C_3, C_2\}$ 做上述操作， C_1 不参与下面步骤；

第二步：获取特征 P'_{k+1} 上采样的结果；

第三步：将前两步的两个结果进行侧向连接；通过自上而下的路径和横向连接，保障了所有层级的特征都具备丰富语义，而且层级间共享分类器。由于低层特征图忽略了图像的全局特性，高层特征图的细节信息缺乏丰富度，借鉴侧向连接方法的思想，集成了低层网络的丰富细节和高层特征的全局特性，获取了不同尺度特征图的优势。举例来说，图 3.4(a)和(b)属于外观很接近的两个不同行人，对于图 3.4(a)来说，短裤颜色的低级特征可以识别两个人的差异。对于图 3.4(b)而言，在两个人的衣服很相似情况下，低级特征是不能区分两人，但是能够从高级特征计算出的相似性来表明一个人携带包而另一个不携带。在图 3.4(c)匹配对的情况下，同时使用低级和高级特征能够识别出两个图像中存在红色背包，表明在两个图像中行人很可能是相同的。因此，不同层级的视觉特征的组建，是可以实现更稳健的匹配。



图 3.4 案例说明，红色框的图像表示不匹配，绿色的表示匹配

Fig 3.4 Some examples. The image in red box indicates it is unmatched and green for matched.

第四步：经过 1 步长， 3×3 大小卷积核 ω_2 ，生成了通道数均为 256 的特征 P_2' 、 P_3' 、 P_4' ；

第五步：平均池化，以形成 1×1 大小的 2 维特征矩阵 P_k 。上述步骤正如公式 3.3 所示， $\odot$ 代表卷积操作， $2X$ 表示上采样过程。

$$P_k = \text{avg_pool}(\omega_2 \odot (C_k \odot \omega_1 + 2X(P'_{k+1}))) \quad (3.3)$$

其中， $P_k \subseteq (P_{r_k} \cup P_{i_k})$ 。此外，也可以用下面的图例 3.5 简单地表达上述五个流程。若用字母 P 表示上述构建的特征金字塔，那么有 $\{P_{r_2}, P_{r_3}, P_{r_4}, P_{r_5}\} \cup \{P_{i_2}, P_{i_3}, P_{i_4}, P_{i_5}\} = P$ ，再由特征融合模型对 P 进行相应操作，生成随机融合特征 fusion block，接下来，本文将详尽说明特征融合模块。




图 3.5 构建金字塔简易图

Fig 3.5 Simple Graph of building pyramid

3.3 特征融合模型

特征金子塔 P 包含两种模态四种层级的特征图，考虑到网络负载成本，故而从 P 中只抽取一组融合特征 fusion block，作为模型输出。抽取的融合特征直接作用到分类器学习性能，所以需要探讨特征选取和融合方式。

前者特征选取，需要考虑模态和层级间的关系，存在 3 种组合情况，如图 3.6 所示。第一种，抽取来自同一网络层但又为不同模态的特征，比如 (P_{r_5}, P_{i_5}) , (P_{r_4}, P_{i_4}) 组合；第二种，抽取不同尺度同一模态的特征，例如 (P_{r_5}, P_{r_3}) , (P_{i_2}, P_{i_3}) ；第三种，抽取源于不同网络层且是跨模态的特征，如 $(P_{r_4}, P_{i_4}, P_{r_5}, P_{i_5})$ 。

后者特征融合，考虑的是特征间的串联形式，正如图 3.7 所示，也存在 3 种组合情况。此外，在图 3.6-3.8 中，用 r 与 i 分别表示 RGB、IR 模态，特征 P_5, P_4, P_3, P_2 分别用绿色、橙色、蓝色、粉色示意。第一种，特征间彼此横向串联，如 $(P_{r_5}, P_{i_5}, P_{r_4}, P_{i_4})$ ；第二种，特征间彼此纵向串联，比如 $(P_{r_5}, P_{i_5}, P_{r_4}, P_{i_4})^T$ ；第三种，特征间以横向串联和纵向串联混合形式融合，此时特征图的尺度必须被考虑到。

因此，特征间混合串联可细分为以下 3 种情况：组合 1，不同层级特征横向串联时，纵向串联的特征也是不同尺度的；组合 2，当同一层级特征横向串联时，不同层级特征采用纵向串联方式；组合 3，不同层级特征横向串联时，纵向串联的特征维持在同一尺度。




图 3.6 特征选取方式

Fig 3.6 Feature selection




图 3.7 特征融合方式

Fig 3.7 Method of feature fusion

不同的融合技巧产生不同的分类预测效果，不同的模态层级的特征反映了行人不同的特性，通过随机选取融合方式和随机抽取特征，再对比多组实验，可以发现不同尺度隐含的有用信息，有利于找到模态与网络层级间的关联，进而妥善处理了多模态跨尺度学习问题。具体来说，随机设定 m 个特征参与融合，融合的先后

顺序由特征抽取顺序决定,随机从三种融合形式中选择一种作为特征融合方法,其中混合串联是成对出现,即先采用横向串联特征则后面必然采用纵向方法串联特征,反之亦然。如图 3.8 所示,空心箭头指向候选特征,随机从候选特征中抽取 m 个特征,假定 $m=4$,随机抽取到的特征为 P_{r_4} 、 P_{i_4} 、 P_{r_5} 、 P_{i_5} ,按照空心箭头所指的方向为先后顺序,依次进入 fusion,则当 P_{i_4} 进入 fusion 后,会与特征 P_{r_4} 融合,假设采用纵向串联方式,以灰色圆圈所代表的融合方式进行融合,此时灰色模块 fusion 中的特征为 $(P_{r_4}, P_{i_4})^T$,其次 P_{r_5} 进入 fusion, fusion 被更新为 $(P_{r_4}, P_{i_4}, P_{r_5})^T$,最后特征 P_{i_5} 输入到 fusion 中,形成的 fusion block 为 $(P_{r_4}, P_{i_4}, P_{r_5}, P_{i_5})^T$,见图 3.1。




图 3.8 空心箭头指向候选特征,蓝色箭头表示参与融合

Fig 3.8 Hollow arrows point to candidate features, blue arrows indicate to join fusion

3.4 实验结果与分析

3.4.1 实验设置

本章特征金字塔随机融合网络与预处理 SRCNN 模型均在 Pytorch 框架上训练,基于 NVIDIA 1070Ti GPU 实现,均采用随机梯度下降(SGD^[51])进行网络优化。其中, SRCNN 算法的初始学习率设为 0.001,批处理大小定成 32, dropout 置为 0.5,经由 800 次迭代完成网络收敛。然后,将超分辨重建后的数据集中图像随机裁剪到 288*144,再随机水平翻转图像以实现数据增广,之后传入特征金字塔随机融合模型,网络训练完成后,再用原始 SYSU-MM01 数据集测试。特征金字塔随机融合网络的初始学习率设为 0.01,且每 30 次迭代后学习率逐渐降低,迭代次数置为 60,批处理大小置为 32。以下分为两小节,一是分析特征金字塔随机融合网络,二是在统一数据集上与最新的行人重识别方法对比。

3.4.2 结果分析

1. 模型分析

表 3.3 列出部分实验结果, 其中, 列表示特征随机融合方式, 行代表随机抽取不同特征。列 2、3、4 反映了特征间融合方法对实验结果的影响, 行 2、3、4 体现了模态和网络层级对行人重识别精度的影响。同时, 列与列的对比, 有助于发现最佳的特征融合方式; 行间对比, 则能在模态与网络层级间建立某种联系, 这种关联包括模态间组合规律和层级间构建技巧, 它使得特征抽取更加明确。通过对行列的整体分析, 有利于找到一组最适合跨模态行人重识别的特征组合。如表 3.3 所示, 将评估不同特征提取器与融合模式, 其中, T 表示混合串联的组合类型: 组合 1 表示, 不同层级的行列融合; 组合 2 表示, 不同尺度的列融合; 组合 3 表示, 行融合的层级不同。

表 3.3 分析特征抽取和特征融合方法的实验结果

Table 3.3. Analysis of feature extracting and fusion method

Random Feature Pyramid		Horizontal Concatenation			Vertical Concatenation			Hybrid Concatenation			
		rank1	rank5	mAP	rank1	rank5	mAP	T	rank1	rank5	mAP
Different level	$P_{r_5}P_{r_2}$ $P_{r_5}P_{r_2}$	27.79	53.98	30.05	26.37	52.27	29.05	1	27.61	53.23	29.90
								3	27.02	52.26	29.06
	$P_{i_4}P_{i_3}$ $P_{i_4}P_{i_3}$	27.89	53.58	30.10	27.13	51.87	28.96	1	28.18	53.21	30.23
								2	27.40	51.79	29.42
	$P_{r_5}P_{r_3}$	28.42	53.84	29.87	26.31	53.71	29.31	-----			
Same level	$P_{i_3}P_{r_3}$	27.96	53.79	30.15	26.10	52.22	28.64	-----			
	$P_{r_5}P_{r_5}$ $P_{i_5}P_{i_5}$	26.82	51.71	29.06	25.29	50.69	27.32	-----			
Different level	$P_{r_5}P_{r_2}$ $P_{i_5}P_{i_2}$	28.03	54.31	30.28	26.80	53.24	29.62	1	27.18	53.35	29.72
								3	26.83	52.59	29.30
	$P_{r_4}P_{r_3}$ $P_{i_4}P_{i_3}$	28.05	54.48	30.39	26.81	52.83	29.93	1	27.97	53.40	29.84
								2	24.89	50.92	26.79
	$P_{r_5}P_{i_5}$ $P_{i_4}P_{r_4}$ $P_{r_5}P_{i_5}$ $P_{i_2}P_{r_2}$	29.28	55.35	31.43	26.84	53.12	29.65	-----			

第 2 列与第 3 列对比发现, 横向串联明显比纵向串联更具融合优势; 第 2 列和第 4 列对比, 再考虑了混合串联的多种组合情况时, 横向串联也是平均高于混合串联形式, 因此, 不同特征最佳融合方法是横向串联。同时注意到, 在混合串联中组合 1 实验效果大于组合 2, 说明横向融合时应采用不同尺度的特征。对比组合 1 和组合 3, 发现相同层级纵向融合的效果低于不同层级特征的纵向融合效果。因此, 横向与纵向上取不同层级特征是混合串联的最佳形式, 这佐证了设计的低层与高层相结合的多级特征学习方式。本文认为造成这种现象的原因是类内平均相似性会随着融合层级数目的增加而增加, 多级映射后不同层级特征图中相同内容的耦合被增强。

第 2 行与第 4 行对比发现, 包含红外数据的行人重识别中跨模态融合能够提升效果; 除去混合串联情况外, 跨模态的特征融合效果均高于单模态融合; 对比第 3 行与第 4 行, 发现跨模态融合时, 相同层级特征的融合效果低于不同层级, 表明不同层级跨模态融合的泛化能力更大, 合成数据确实能弥合两种模态间差距, 因此, 特征抽取的标准可定为抽取不同模态不同层级的特征。综合特征的抽取标准和最佳融合方式, 我们找到一组最适合跨模态行人重识别的特征集合 $P_{r_5}P_{i_5}P_{i_4}P_{r_4}P_{r_5}P_{i_5}P_{i_2}P_{r_2}$ 。

2. 对比实验

最近几年, Resnet-50 和 SVDnet 常被作为行人重识别的标准对比框架。本章将提出的特征金字塔随机融合网络(FPRnet)基于 SYSU-MM01 数据集与 One-stream、Two-stream、Zero-padding、BCTR、BDTR、CmGAN、Resnet-50 以及 SVDnet 模型进行了比较。其中, BCTR 和 BDTR 是 dual-path 的改进版本, 具体细节见论文^[9]。并从识别精度(见表 3.4 和图 3.9)和收敛速度(见图 3.10-3.11)两方面进行对比, 其中红色字体表示该列中最佳效果。通过将 FPRnet 与 SRCNN 结合, 来提升实验效果, 作为最终训练框架。此外, 将 reRanking 微调策略运用到 FPRnet 上, 作为补充实验。

表 3.4 在 SYSU-MM01 数据集上对比最新方法

Table 3.4 Comparison with state of the art on SYSU-MM01

Methods	Rank-1	Rank-10	Rank-20	mAP
One-stream	12.04	49.68	66.74	13.67
Two-stream	11.65	47.99	65.50	12.85
Zero-padding	14.80	54.12	71.33	15.95
CmGAN	26.97	67.51	80.56	27.80
BCTR	16.12	54.90	71.47	19.15
BDTR	17.01	55.43	71.96	19.66
ResNet-50	19.36	59.89	73.47	23.85
SVDnet	21.75	58.57	73.02	25.61
FPR	29.28	68.43	81.01	31.43
FPR+SRCNN	30.02	69.08	81.19	32.12
FPR+reranking	30.99	67.91	79.76	31.17




图 3.9 对比最新方法的实验结果曲线

Fig 3.9 Comparison of graph with state of the art on SYSU-MM01

实验数据表明本章方法优于上述其他最新的研究成果，特别的是，所提的 FPR 方法 rank-1 和 rank-20 分别高于单流网络 zero-padding 方法 17.24% 和 18.75%，这明显能够减小跟踪行人轨迹错误情况的发生。尽管是以 Resnet-50 为基础网络框架，但实际取得了比深度残差网络更优异的成效，平均精度高 10%左右，这就证明了将浅层网络中的残差层与深层网络中的卷积层互相融合的学习方式的正确性。这种学习方式的实质是金字塔结构思想的变形，它将低层网络的局部特性与高层网络的整体表现合二为一，完成了跨尺度特征的融合，实现了两种模态行人图像的强

语义与强几何细节的特征表达。引入侧目的是，基于对抗网络的 CmGAN 方法也取得了不错的成绩，甚至 rank-10 达到了 67.51%，但是仍低于特征金字塔随机融合算法的识别率，这说明了提出的模型确实学习到了更充足地信息，真实地解决了多模态行人学习问题。同时，FPR+SRCNN 的 mAP 高于 CmGAN 方法 4.32%，显示了在跨模态 Re-ID 研究中加入超分辨重建的优势。

在表 3.4 的最后，使用行人重识别领域流行的微调策略来优化所提的模型，通常而言，reRanking 策略可以将网络整体提升 2%-5%，然而却发现并没有提升特征金字塔随机融合网络性能，甚至在某种程度上拉低识别效果，本文推测度量相似性时出现伪最近邻问题，导致训练过程中保存的模型不是最佳的。




图 3.10 训练阶段 mAP 变化趋势

Fig 3.10 The trend of mAP during training




图 3.11 训练阶段 loss 变化趋势

Fig 3.11 The trend of loss during training

观察图 3.10 得知，大部分网络迭代 30 次左右 mAP 就几乎不再波动，也就意味着大概在 30 轮训练后，模型进入收敛完成阶段，说明了目前行人重识别工作的主流是：小模型，训练周期低，快速训练并应用。针对跨平台移植到硬件设备上有明显优势，具备广阔的商业应用前景。

虽然 CmGAN 算法正确识别行人的概率仅低于 FPRnet、FPR+SRCNN、FPR+reranking，但是它的训练速度极慢，这是因为采用对抗网络生成样本去自动学习，导致模型积压大量参数，由图 3.11 可以看到，网络训练到第 80 轮时，CmGAN 的 loss 变化不大，提出的 FPRnet 却早已收敛。之所以特征金字塔随机融合模型在收敛速度上有了大幅提高，是因为网络深度只有五层，参与运算的参数不高，并且采用了端到端的设计，使得训练过程中部分参数及时释放了，摆脱了对抗网络和金字塔网络的参数量过高的问题。

3.5 本章小结

本章首先介绍了基础网络 Resnet 的产生背景、思想精髓、取得的成效与众多优势以及在多个研究领域的应用,并挑出在图像分割课题项目中的运用效果,由基于残差网络的图像分割存在的问题,引出特征金字塔网络的诞生。简述了特征金字塔模型的优点与基本原理以及应用范围。通过将金字塔结构单元嵌入深度残差网络中,能够有效解决 Resnet 在行人重识别工作中的缺陷,同时可以规避掉金字塔算法存在的问题,这种设计有效解决了跨尺度多模态行人的学习问题,然后详细阐述了该方法的主要流程与设计框架。其基本流程是抽取特征,再融合特征,于文中分成两小节说明,一是特征提取模型,它以 Resnet-50 为基本框架,学习 RGB 和 IR 两种模态的不同卷积特征,接着将各个卷积结果依次构造成金字塔结构,二是特征融合模型,它以随机融合机制完成端到端的框架设计,学习到最终的红外和可见光 Re-ID 特征。并于 SYSU-MM01 数据集上,深度分析了设计的框架,然后从识别精度和收敛速度两方面与最新的行人重识别方法做了对比,实验数据显示,本章提出的网络其识别精度优于现有的算法,而且它模型规模小,训练周期低,这证明了本章所提的算法十分优秀。

第四章 基于混合损失函数的多模态分类学习

4.1 引言

当前红外与可见光的行人重识别算法主要基于深度神经网络而设计，算法的研究一般有两个思路：第一个是 Re-ID 问题的建模方式，第二个是跨模态特征的提取与匹配方式，众多性能优秀的网络模型中这两项工作是相互交叉的。上一章研究探讨了如何提取更加稳健的高分辨强语义特征，在这一章将会研究两种模态的行人重识别深度学习方向的建模问题，其主要内容是讨论研究并总结网络训练中的损失函数。

模型损失的定义是训练阶段输出结果和输入图像之间差异的描述子，通常用损失函数值表达，损失函数的定义是评估模型输出特征值与实际值之间的差异的一种映射关系。损失函数的位置是特征输出层之后，第二个全连接层内部，这也就是全连接层被认为是类似分类器的原因，它将数据集中行人 ID 标签数量对应到输出层，将输出的分类结果作为模型对输入图像预测的 ID 标签概率，这一过程也就是将具有区分度的矢量特征通过线性变换映射到样本真实空间中。损失函数在训练时期的效果如图 4.1 所示，图 4.1(a)是模型训练前的样本距离，(b)表示训练之后度量法测出的样本间距，在(a)图中，无法目测出目标样本 Y 与图像 C、D、E、F、G 哪一个距离更近些，通过网络的特征提取，损失映射函数值不断地更新进行反向传播的学习结果，使得图像 Y 与图像 C 之间的距离缩短了，同时推开了其他干扰图像，正如图(b)所示，实线表示确定了两幅图像来自同一个行人，虚线代表区分了相似或者不同的行人 ID。由损失函数在训练阶段的效果图，可以推断损失函数的本质类似于对样本做聚类操作。




图 4.1 损失函数在训练阶段的效果

Fig 4.1 Effect of loss function during training phase

损失函数的观测，当它的值越来越小，表示模型开始进入收敛阶段，当它的值

出现不减反增的变化,则表明网络肯定存在问题,当其值渐进于 0 时,说明了当前模型完成了数据集上的训练,而且模型的输出结果与训练集的匹配度很高,证明了该网络的性能十分出色,并且拥有一个良好的损失函数,因为能够较好地表达两个特征之间的区别。

4.2 混合损失函数分析

人们在研究对策问题、平衡问题、最优化问题、不动点等问题的性质时,发现它们都与某种特殊的数学矩阵紧密相关,当一个方阵满足非满秩的要求时,该矩阵就是奇异阵,具备对应行列式等于 0 的性质。根据奇异矩阵的特性,经济统计、土地规划、计算机学科均有所应用,特别是计算机研究中的图像类别,有助于定位图像信息中的关键区域,去除不必要的干扰肉眼判别的信号量。

我们观察到 SYSU-MM01 数据集中样本图像分布不均匀,这会造成全连接层的每一个权重向量,都高度相关,而且采用的欧式距离度量法会受到彼此存在耦合关系的矢量的消极作用,这直接影响了行人重识别的效能。为了克服这个问题,为此引入了奇异向量矩阵,并作用于第二层全连接,同时保持第一层全连接中每一个神经元都与上一层所有输出互连的特性,这样处理的目的是降低特征向量间的耦合性,消除多数矩阵的冗余,并将这种做法的两层全连接统一标记为 SVD 层。SVD 层的详细内容是,将第一层全连接产生的特征矢量进行奇异值分解,分解成左奇异矩阵和右奇异矩阵以及一个奇异值向量,然后用左右奇异矩阵的乘积替代原始的特征向量。这样可以减小模型承载的参数量,同时降低由于相似类别投影出现耦合时而造成的误判行人 ID 情况的发生,进而提升了正确预测行人的概率。

本章处理跨模态行人重识别分类任务的基本流程如图 4.2 示意:首先利用上一章的模型提取特征,其次将特征输入进 SVD 层,然后运用激活函数算出反向传播梯度,再用损失函数度量输出值与真实值之间的差距,不停地重复这样的操作,直至网络收敛,最后用数据集 SYSU-MM01 进行测试。




图 4.2 跨模态行人重识别分类任务的基本流程

Fig 4.2 Simple process of cross-modal Re-ID classification task

其中,特征提取模型生成了四种特征 RGB block、IR block、IR-RGB block、

fusion block, IR-RGB block 是 RGB block 和 IR block 串联的结果, fusion block 是特征融合模型的结果。如图 4.3 所示, 高层联合特征 IR-RGB block 和随机融合特征 fusion block 分别输入到 SVD 层, 再将 $\text{leakyRelu}^{[52]}$ 用于联合特征的训练, 被 $\text{Relu}^{[53]}$ 激活的 fusion block 再次输入 SVD 层; 为了加快收敛, 同时与批量归一化 (Batch Normalization, BN) 机制交替使用; 然后, 将 IR-RGB block 与 fusion block 互相博弈, 把相似性排名最高的作为联合模态特征 U; 最后经由分类损失函数传出联合模态的损失 $\text{loss}_{\text{rgb-ir}}$ 。接下来, 将分成两小节详细讨论影响行人识别效果的损失函数, 第一部分介绍相关的损失映射关系, 第二小节提出基于红外和可见光的混合损失函数。




图 4.3 跨模态行人重识别分类任务的模型

Fig 4.3 Model of cross-modal Re-ID classification task

4.2.1 相关损失函数

目前, 行人重识别任务主流使用的损失函数有交叉熵与三元组及其相关变形。三元组损失 (Triplet Loss) 是 Ding 等人^[54]在 2014 年提出的让同类距离更小, 异类距离趋近于更大的一种度量相关特征的方法。三元组损失的内容是每次从已分类的数据集中选择三张图片, 第一张行人图像作为固定项或称锚点 (anchor, a), 是从数据集中的任意选择的一张, 第二张图像是从与 a 同类的图像库中抽取的, 并记为正样本项 (positive, p), 第三张图像是从与 a 不同 ID 类别中采集的, 且标记为负样本 (negative, n), 那么就存在图像 a 与图像 p 组合的正样本对(a,p), 负样本对

(a,n), 根据 Triplet Loss 的设计原理, 则有负样本对的距离大于正样本对这一前提条件, 得到如下公式。

$$distance(a, n) > distance(a, p) + \varepsilon \quad (4.1)$$

这里的 ε 表示匹配对和不匹配对之间的最小边距, 属于可调节的边界值, 目的是改变样本之间的距离。其中, 正负样本对的距离的欧式度量策略分别用式 4.2 与 4.3 表达, U 表示度量方法。

$$distance(a, n) = \|U(a) - U(n)\|_2^2 \quad (4.2)$$

$$distance(a, p) = \|U(a) - U(p)\|_2^2 \quad (4.3)$$

那么, Triplet loss 网络中的损失函数定义如下:

$$Loss_{Triplet} = \max\{\|U(a) - U(p)\|_2^2 + \varepsilon - \|U(a) - U(n)\|_2^2, 0\} \quad (4.4)$$

通过网络模型提取特征, 共享参数的计算每个行人样本的特征空间, 经由上述度量方法估算三个行人特征对网络造成的损失, 并根据损失值调整网络参数, 如图 4.4 所示, 是一个三元组度量的基本模型示意图。因此, 只要有适当的损失函数和输入样本, 该模型可以通过模型训练, 逐步完成扩大类间差与缩小类内差的工作, 就可以得到一个较好的特征提取结果。




图 4.4 三元组基本模型

Fig 4.4 Triplet of basic Model

随着特征融合网络训练的进行, 大部分简单的三元组转换函数很快地学会了正确映射关系, 然而小部分的三元组还没有来得及提供有效信息, 一轮迭代就结束了, 如图 4.5 示意, 这会造成此次迭代对模型的调整幅度较小, 训练可能数轮后停滞不前。




图 4.5 三元组损失的缺点

Fig 4.5 Disadvantage of Triplet Loss

在上边的例子中，倘若发生类内距离大于类间距离的情形，Triplet Loss 会察觉到这种异常的间距关系，由于与正确情况的原理不同，所以网络会在反向传播时期忽略这对关系，从而导致训练具有不稳定性。此外，边界间距 ϵ 的决策数值对算法性能有明显影响，这要求训练阶段的调参能力更强，而且当数据集变大时，网络积累的三组样本量急剧增大。收敛速度慢，难调参，忽略异常样本对，这些种种原因使得出现了相关的改进工作，比如说难采样三元组(Hard Triplets)。Hard Triplets^[55]的计算流程是，首先也是随机选择一个锚点图像 a ，其次从与 a 目标行人一致的图库中找到特征距离最大的图像作为正样本 p ，然后将不同目标 ID 的图库中距 a 最近的图片作为负样本 n ，正如图 4.6 所示。其中，集合 A、B、C 表示行人真实的 ID 编号，空心圆表示某个行人不同拍摄视角的图像。由图得知，难采样的正负行人样本对的边界距离偏大，能够解决 Triplet Loss 网络忽略异常样本对与难调参这两项缺点，它可以显著增强训练效果。但是，频繁地选择难采样三元组样本，可能会使训练时间变得很长，足以限制模型的泛化能力。




图 4.6 难样本采样示意图

Fig 4.6 Diagram of Hard Triplets samples

监控摄像机连续馈送,期望从多个画面中捕获运动行人的情况,需要对同一个身份的图像进行分组任务时,三元组系列的损失函数由于侧重训练集本身而在重识别的聚类过程中表现较差。为此,本章直接考虑在任意图像对中建立映射关系来确定是否为同一行人,可以采用二分类的损失映射函数来解决此类问题,其中,最为经典有效的是交叉熵损失函数,它刻画任意图像对特征矢量之间的差异,基于差异向量来预测 0/1 概率结果。

交叉熵为信息论中的一个概念,它原本是用来估算平均编码长度的。给定相同事件的两个概率分布 p 和 q ,通过 q 来表示 p 的交叉熵定义如下:

$$H(p, q) = -\sum_x p(x) \log q(x) \quad (4.5)$$

为了确保神经网络的输出符合概率分布形式,从而能够运用交叉熵映射函数来描述预测样本与真实标签的距离,还需要将网络的前向传播结果变成概率分布,而 Softmax 回归法可以满足这一要求,假定原始的神经网络输出为 $\hat{y}_i$, i 为当前输出的标签号,经过回归处理后,得到:

$$\text{softmax}(\hat{y}_i) = \frac{e^{\hat{y}_i}}{\sum_{j=1}^n e^{\hat{y}_j}} \quad (4.6)$$

这里, n 是训练集真实标签总数,从交叉熵的公式 4.5 中可以看到 $H(p, q) \neq H(q, p)$,这种非对称的映射是为了表达 q 描述概率分布 p 的困难程度,对应到神经网络中, p 代表的是正确标签, q 表示预测 ID 值,网络学习的目的是预测值为正确答案,也就是尽量让两个数学分布 p 、 q 接近,用数据直观说明是交叉熵的值越小,网络当前的性能越优。以红外和可见光的两个行人样本 (I_n, J_n) 为例,分析采用交叉熵分类器的建模过程, x 为特征层输出,则有下列式概率分布:

$$q(y = i | c_0, c_1, d_0, d_1, x) = \frac{e^{(c_i x + d_i)}}{\sum_{i=0,1} e^{(c_i x + d_i)}} \quad (4.7)$$

若 (I_n, J_n) 属于同一个 ID, y 描述两张图像是否相符,符合则取 1,反之 y 取 0。 c_0, c_1, d_0, d_1 是 y 取 0 或 1 时的对应权重与偏置参数,整合交叉熵的信息论定义公式 4.5,得到神经网络样本的损失值计算形式,如下:

$$\text{Loss}_{\text{交叉熵}}(q, \hat{y}_i, y) = -[y \log q + (1 - y) \log(1 - q)] = -\log \frac{e^{\hat{y}_i}}{\sum_{j=1}^n e^{\hat{y}_j}} \quad (4.8)$$

这里的 y 代表样本真实标签, $\hat{y}_i$ 是预测标签的特征图。通过分析三元组与难采样两类损失函数的不足,对比交叉熵映射特征的优势,提出了本章的基于交叉熵的混合损失函数。

4.2.2 混合损失函数

池化层本质是下采样,它可以完成特征空间维数的降低任务,以确保最终的结果符合目标尺寸。同时下采样策略也减少了原始图像或特征的信息,图像或者特征的质量将无法避免地受到影响。为了补充池化过程中去除的部分信息,尤其是需要

补充高度相关有用的信号，上采样策略被提出了，目的是为了放大图像增加网络训练的信息。上采样作为下采样的逆过程，其基本原理是在原有像素的基础上插入新的元素，与上池化是属于两个不同的概念。上池化是特指下采样工作当中的最大值池化的逆过程，图 4.7 以经过最大值下采样的特征图为案例，展示了上采样与上池化的不同处。




图 4.7 上采样与上池化的区别

Fig 4.7 Difference of unPooling and unSmampling

图 4.7(a)表示上池化的过程，明显的特点是维持最大值的位置数据，其余像素位置补 0，而图(b)，它是将上下文内容直接复制并填充至整幅特征图。上述两种方法的共同之处是没有任何一个像素点是采用过渡值情况，均是简单处理，无需学习参数，但这样可能会引起生成的特征在灰度上间断，尤其是灰度突变部位极大可能发生锯齿现象。因此，一般的上采样策略是有学习参数的，其像素插入的形式有双线性与三线性。双线性插值研究的流程是根据目标像素邻近的四个节点，来测算权值，然后决定插进的像素数值，它的核心原理是在两个方向上逐次做线性插值。那么，新生成的特征图中每个位置都会被计算到一次，下图展示了双线性插值的过程，假定目标节点坐标是 (x,y) ，标记待求位置的像素为 P。




图 4.8 双线性插值步骤

Fig 4.8 Steps of bilinear interpolation

第一步：在 x 方向插值，相邻的两点像素是 (x_1, y_1) 与 (x_2, y_1) ，其数值分别对应 $P_1 = Q_{11}(x_1, y_1)$ 和 $P_2 = Q_{21}(x_2, y_1)$ ，根据线性关系，则有下列 4.9 数学公式。

$$\frac{P - P_1}{x - x_1} = \frac{P_2 - P_1}{x_2 - x_1} \quad (4.9)$$

运算变形，得到下面的公式

$$P_x = \frac{x_2 - x}{x_2 - x_1} P_1 + \frac{x - x_1}{x_2 - x_1} P_2 \quad (4.10)$$

第二步：在 y 方向做插值运算，目标元素相邻的两点是 (x_1, y_2) 与 (x_2, y_2) ，其数值分别对应 $P_3 = Q_{12}(x_1, y_2)$ 和 $P_4 = Q_{22}(x_2, y_2)$ ，根据线性关系，运算得到式 4.11。

$$P_y = \frac{x_2 - x}{x_2 - x_1} P_3 + \frac{x - x_1}{x_2 - x_1} P_4 \quad (4.11)$$

第三步：经由前两步计算的结果，算出 P 点的数值表达式为：

$$P = \frac{y_2 - y}{y_2 - y_1} P_x + \frac{y - y_1}{y_2 - y_1} P_y \quad (4.12)$$

双线性插值技术很大程度地消除了锯齿问题，有学者做了进一步改良，得出三次线性插值算法，它是利用三次多项式逼近理论，但一般是用于 4 维空间，而图像识别隶属于 3 维任务，所以更多时候是采纳双线性插值法。

影响跨模态行人重识别性能的核心因素是模态内视觉外观差异与模态间异质差距，本文认为将这种差距显性化，再增强其权重，作用于网络模型，是能够弥合数据间不同分布引起的差异变化，是可以修正原有模型偏差的。具体是由双线性插值法将 RGB block 和 IR block 的分辨率放大 2 倍后，输入到 SVD 层，再经过交叉熵分类输出两种模态的损失 $loss_{rgb}$ 与 $loss_{ir}$ ，如图 4.3 下方示意，粉色的 RGB 单模态块与紫色 IR 单模态区域。再将 $loss_{rgb}$ ， $loss_{ir}$ 与蓝色的联合模态损失集成，得到

混合损失函数 $loss$ ，如下：

$$loss = \lambda_1 loss_{rgb-ir} + \lambda_2 loss_{rgb} + \lambda_3 loss_{ir} \quad (4.13)$$

其中， λ_1 、 λ_2 和 λ_3 是预定义的权重参数，用于训练时微调网络，提升重识别精度；根据交叉熵数学定义，则有 $loss_{rgb-ir}$ 、 $loss_{rgb}$ 与 $loss_{ir}$ 具体形式如下：

$$loss_{rgb-ir}(U, target_U) = -\log \frac{e^{U[target_U]}}{\sum_{j=0}^M e^{U[j]}} \quad (4.14)$$

$$loss_{rgb}(RGB \ block, target_r) = -\log \frac{e^{RGB \ block[target_r]}}{\sum_{j=0}^M e^{RGB \ block[j]}} \quad (4.15)$$

$$loss_{ir}(IR \ block, target_i) = -\log \frac{e^{IR \ block[target_i]}}{\sum_{j=0}^M e^{IR \ block[j]}} \quad (4.16)$$

其中， $target_U$ 是联合模态特征 U 的真实标签； $target_r$ 是特征 $RGB \ block$ 的真实标签； $target_i$ 是特征 $IR \ block$ 的真实标签； M 是训练集真实标签的数目，其值为 395。

无法忽视的一个问题是联合模态和单模态间也存在着异质差距，造成这种差距的原因是网络模型。通过调整联合模态与单模态间偏置，来进一步修正网络模型。本文将提取到的偏置记作 d ，如公式 4.17 所示，它由联合模态损失与单模态损失算术减法得到这种微小的偏置波动，受 Softmax 回归法的启发，再通过常见的对数函数来放大微小偏置 d 的变化，等价于显性化网络模型训练存在的一些缺失，可以预见的是面对错误分类情况时，这种处理有着很强的调节能力，具体地以对数形式来引导网络学习，见公式 4.18：

$$d = \frac{loss_{rgb} + loss_{ir}}{2} - loss_{rgb-ir} \quad (4.17)$$

$$loss_{cross} = e^{|d|} \quad (4.18)$$

其中， $loss_{cross}$ 表示修正损失。因此公式 4.13 改写成如下式 4.19：

$$loss' = \lambda_1 loss_{rgb-ir} + \lambda_2 loss_{rgb} + \lambda_3 loss_{ir} + loss_{cross} \quad (4.19)$$

交叉熵损失相对于目前重识别中流行的三元组或难采样三元组损失，是属于小复杂度训练。因此，本章采用改进交叉熵的混合损失函数 $loss'$ 训练模型，在收敛性能方面更具优势，接下来将在下一节实验中验证公式 4.19 的效果。

4.3 实验结果与分析

4.3.1 实验设置

本章模型仍然在 Pytorch 框架上训练，基于 NVIDIA 1070Ti GPU 实现，随机梯度下降用于网络优化，初始学习率设为 0.01，每 30 次迭代后学习率逐步调低。迭代次数置为 60，批处理大小置为 32。以下内容分为三小部分，一是定义混合损失函数的权重参数 λ_1 、 λ_2 、 λ_3 取值，二是拆分混合损失函数的数学表达式来分析其成效，三是在数据集 SYSU-MM01 上深度剖析本章的分类学习模型。

4.3.2 结果分析

经过多次实验，确定了合适的权重参数值，具体为 $\lambda_1=1$ 、 $\lambda_2=1$ 、 $\lambda_3=1$ ，部分实验数据如表 4.1 所示。

表 4.1 选择权重参数值

Table 4.1 Selecting value of weight parameter

λ_1	1	1.5	1.2	0.8	1	1	1.5	0.5	0.8	0.4
λ_2	1	1.5	1.2	0.8	0.5	0.3	1.2	0.2	0.15	0.35
λ_3	1	1.5	1.2	0.8	0.5	0.3	1.2	0.3	0.05	0.25
mAP	31.43	28.78	29.97	30.05	26.53	27.46	29.29	30.11	30.14	28.17

在表 4.1 中，列 3 使得所有的权重参数值一致，列 4 保证 λ_2 与 λ_3 的数值相同，列 5 控制所有的权重参数值之和为 1。具体来说，列 3 反映了权重参数值设为大于 1 或小于 1 的情况，然而实验结果并不理想；列 4 控制了一个权重参数值与另外两个权重不同，但数据显示其识别精度仍低于列 2；列 5 是将 $\sum_{i=1}^3 \lambda_i$ 维持在数值 1，然而也未找到期望的实验效果。

网络框架中的组成模块会引起行人重识别性能上的波动。表 4.2 则展示了对性能产生关键作用的结构子块，它是基于混合损失数学表达式，然后移除指定结构，即排除了其他影响因素，我们通过表中具体数据的变化（参考图 4.9）来分析组成混合损失函数的各个部件对于整体网络框架的作用，从侧面阐明网络构建过程。表 4.3 为特定结构块的模块选定提供了数据支撑，它基于网络整体框架 Fig4.3，更改指定模块，形成自身对照（见图 4.10），深层次阐述模型的构建。

表 4.2 模型中不同模块对比

Table 4.2 Different module comparison in frame

Remove out Component	Rank-1	Rank-5	Rank-10	Rank-20	mAP
RGB-domain and IR-domain	24.30	49.61	62.58	75.62	27.51
IR-RGB block	25.40	50.41	63.81	76.81	28.79
fusion block	26.08	51.69	64.09	76.73	28.78
upSample 2X	26.91	52.66	65.85	77.96	29.55




图 4.9 模型中不同模块对比图

Fig 4.9 Graph of different module comparison in frame

表 4.2 展开分析, 当 RGB-RGB 与 IR-IR 结构不采用上采样方法时, 识别精度明显下降。证实了放大模态内差异因子的权重能有效修正网络模型的观点。再移除 RGB-RGB 与 IR-IR 结构后, 实验效果则 rank-1 降低了 4.98%。说明该结构对于整体网络是至关重要的, 仅采用联合模态网络结构对于跨模态数据的利用是不够充分的, 将单模态与联合模态集成能有效利用跨模态的特性。验证模态间偏置的利用对网络模型的正效应, 是通过对联合模态 RGB-IR 结构移除前后效果。研究发现, 网络模型的设计要基于 RGB-RGB 和 IR-IR 以及 RGB-IR 三种模态。

表 4.3 混合损失函数的结构对比

Table 4.3 Component comparison of Mixed loss function

Convert into Component	Rank-1	Rank-5	Rank-10	Rank-20	mAP
Single SVD	26.33	51.76	65.32	78.95	29.35
Double SVD	26.93	53.27	66.74	78.86	29.40
LeakyRelu	26.96	52.74	65.05	77.67	29.42
Relu	26.34	51.96	65.51	78.70	28.94




图 4.10 混合损失函数的结构对比图

Fig 4.10 Graph of component comparison of Mixed loss function

表 4.3 具体来说,研究了奇异矩阵的使用和激活函数的选择,无论是将 fusion block 后接单层 SVD,还是在 IR-RGB block 后连双层 SVD,其效果均下降了。因此,对 fusion block 做双层 SVD 处理以消除不必要的相关性,单层 SVD 则应用在 IR-RGB block 上。此外本文尝试过多种激活函数,不同激活函数产生不同分类效果,通过多组实验得到了网络中表现最优的一组激活函数,分别是基于 Relu 激活的 fusion block 和基于 LeakyRelu 分类的 IR-RGB block,而其他组合的激活函数效果均要低于它,比如说,两者均采用 relu 或者 LeakyRelu 激活,同等条件下,rank-5 效果分别降低了 3.39%和 2.61%,这或许是部分权重无法更新,因此,如图 4.3 所示的模型的设计是合理的。

4.4 本章小结

本章首先简述了行人重识别研究的常规思路,对其中的一个思路损失函数的设计进行了说明。从损失函数的产生、定义、位置、用途、效果与观测以及评估多种角度阐明。其次,概述了奇异矩阵的起源与应用以及优势,基于奇异矩阵的特性而设计了 SVD 层。然后介绍了跨模态行人重识别分类任务的基本流程与模型,并分成两小节来详细说明流程与模型的内容,具体是先介绍相关损失函数的产生与度量特征的流程以及优缺点,确定了交叉熵作为基础损失函数,再简要说明了上采样的起源、原理、发展的方法与特性之后,对双线性插值算法的计算举例来阐述,通过利用模态内视觉外观差异与模态间异质差距,从而提出本章的基于红外和可见光的混合损失函数。通过实验结果,发现本章提出的混合损失函数与分类学习模型均具有较好地效果。

第五章 总结与展望

5.1 总结

近年来,基于红外和可见光模态的行人重识别在视频监控、人机互联、智能安保等领域应用广泛。其中,基于可见光模式的行人重识别需要同时处理不同光照、背景、遮挡物以及多种姿态的行人问题,基于红外模式的行人重识别存在着红外图像低分辨率和低对比度等问题,这些问题使得目前跨模态行人重识别研究成果很少。本文通过对深度学习的跨模态行人重识别方法进行详细分析与研究,在此基础上,提出了两种解决方法,分别是特征金子塔随机融合结构与混合损失函数的多模态学习,并通过实验验证了本文所提算法的有效性。本文的主要研究内容及特色如下:

1. 阐述了解决跨模态行人重识别问题所需要的技术,行人重识别与超分辨重建算法。首先,介绍和评估了 5 类深度学习的超分辨重建算法;其次,由行人重识别的发展趋向,分为传统的和深度学习这 2 种来说明,在传统的行人重识别工作中,主要讲述了早期的两种特征表达方式,在深度学习的行人重识别研究中,主要叙述了基于卷积神经网络的图片训练并识别的流程;最后,概述了相关评价标准与数据集。

2. 针对单一尺度特征学习的局限性和多模态特征融合的复杂性,本文提出了特征金子塔随机融合结构。首先,引入了超分辨重建方法来处理红外图像视觉糊化对网络训练的干扰;其次,通过融合高层特征的强语义表征能力与低层特征的强几何细节信息表征能力,实现了高分辨强语义特征作为相似性匹配的唯一输入;然后,集成全局学习和局部学习的优势,而设计了多层级不同模态特征的随机融合机制。这种方式实现了图像多尺度语义学习任务,而且参与运算的参数量不高,有效解决了跨尺度多模态行人的学习问题,实验数据显示,我们提出的网络识别精度优于现有的方法,而且它模型规模小,训练周期短。

3. 针对影响跨模态行人重识别性能的核心因素,即模态内视觉外观差异与模态间异质差距,提出了混合损失函数与分类学习模型。首先,基于奇异矩阵的特性设计了 SVD 层;然后,将交叉熵函数作为基础损失函数,再利用双线性插值算法来显性化差距;最后,利用 RGB-RGB、IR-IR、RGB-IR 三种模态间的偏置来进一步校正网络。通过实验结果,发现我们提出的基于混合损失函数的多模态分类学习有效地修正了模型。

5.2 展望

本文提出的基于红外和可见光的深度学习的行人重识别方法,经过详细的实

验验证，在跨模态数据集上表现优秀，但是优化过程中存在的问题仍然需要进行改善，有待进一步研究的工作包括以下几个方面：

1. 由于红外图像的视觉糊化严重，使得跨模态的行人重识别干扰信息非常多，通过超分辨重建算法可以提取更多的可见光图像信息，但是仅从预处理数据集角度，明显提取到的信息量有限，未来可以尝试将超分辨重建与网络的特征提取相结合，输出的结果不再是图像形式，而是包含关键信息的特征图。

2. 当前大多数的图像识别都是基于可见光画面，在红外领域，几乎没有一个特别有效的算法能解决红外的低分辨灰度图的性质。超分辨重建技术的应用，具有启发意义，但是红外图像只有一种颜色信息，如果能够通过某种算法填充图像的颜色，再在三通道颜色空间内重建清晰的图像，然后再去除填充的颜色，这样一套流程是否可以解决红外图像的问题。

3. 三元组系列的损失函数，对模型的尺寸和数据集的大小要求很严，当数据集偏大或者模型参数偏多时，包含该系列损失函数的网络性能会受到限制。接下来，如何改进三元组采样方式，网络如何剪枝压缩，训练集怎样从大数据集中挑选，这些问题需要研究探讨。

参考文献

- [1] Tian M, Yi S, Li H, Li S, Zhang X, Shi J, Wang X. Eliminating background-bias for robust person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 5794-5803.
- [2] He L, Liang J, Li H, Sun Z. Deep Spatial Feature Reconstruction for Partial Person Re-identification: Alignment-Free Approach[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7073-7082.
- [3] Ma L, Sun Q, Georgoulis S, Van Gool L, Schiele B, Fritz M. Disentangled Person Image Generation[J]. Computer Vision and Pattern Recognition, 2017: 1712-02621.
- [4] Bahadori S, Iocchi L, Leone G, Nardi D, Scozzafava L. Real-time people localization and tracking through fixed stereo vision [J]. Applied Intelligence, 2005: 1573-7497.
- [5] Dai Z, Chen M, Zhu S, et al. Batch Feature Erasing for Person Re-identification and Beyond[J]. Computing Research Repository, 2018: 1811-07130.
- [6] Zheng L, Shen L, Tian L, Wang S, Wang J, Tian Q. Scalable person re-identification: A benchmark[C]. In Proceedings of the IEEE International Conference on Computer Vision, 2015, 201: 1116–1124.
- [7] Zheng A, Yu W, Gong H, et al. RGB-Infrared Cross-Modality Person Re-identification[C]. IEEE International Conference on Computer Vision, 2017: 2380-7504.
- [8] Dai P, Ji R G, Wang H, et al. Cross-Modality Person Re-Identification with Generative Adversarial Training[C]. Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, 2018: 677-683.
- [9] Mang Y, Zheng W, Lan X Y, et al. Visible Thermal Person Re-Identification via Dual-Constrained Top-Ranking[C]. Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, 2018: 1092-1099.
- [10] Zhu X, Huang Z, Shen H, Zhao X. Linear cross-modal hashing for efficient multimedia search[C]. In: Proceedings of the 21st ACM international conference on Multimedia, 2013: 143-152.
- [11] Zhai D, Chang H, Zhen Y, Liu X, Chen X, Gao, W. Parametric local multimodal hashing for cross-view similarity search[C]. In: Twenty-Third International Joint Conference on Artificial Intelligence, 2013.
- [12] Zhang D, Li W. Large-scale supervised multimodal hashing with semantic correlation maximization[C]. In: Twenty-Eighth AAAI Conference on Artificial Intelligence, 2014.
- [13] Nitish S, Ruslan S. Multimodal learning with deep boltzmann machines[J]. Journal of Machine Learning Research, 2014, 15(1):2949– 2980.

- [14] Dat N, Hyung H, Ki K. Person Recognition System Based on a Combination of Body Images from Visible Light and Thermal Cameras[J]. *Sensors*, 2017, 17(3):605.
- [15] Sarfraz M S, Stiefelhagen R. Deep perceptual mapping for cross-modal face recognition[J]. *International Journal of Computer Vision*, 2017, 122(3): 426-438.
- [16] Xiao T, Li H, Ouyang W, Wang, X. Learning deep feature representations with domain guided dropout for person re-identification[C]. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016:1249-1258.
- [17] Wang F, Zuo W, Lin L, Zhang D, Zhang L. Joint learning of single-image and cross-image representations for person re-identification[C]. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016: 1288-1296.
- [18] Jiang X, Wu F, Li X, Zhao Z, Lu W, Tang S, Zhuang Y. Deep compositional cross-modal learning to rank via local-global alignment[C]. In: *Proceedings of the 23rd ACM international conference on Multimedia*, 2015: 69-78.
- [19] 郑伟诗, 吴岸聪. 非对称行人重识别:跨摄像机持续行人追踪[J]. *Science China Information Sciences*, 2015, 58(58): 100104.
- [20] Mogelmose A, Bahnsen C, Moeslund T, Clapes A, Escalera S. Tri-modal person re-identification with rgb, depth and thermal features[C]. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, 2013: 301-307
- [21] Nguyen D, Hong H, Kim K, et al. Person recognition system based on a combination of body images from visible light and thermal cameras[J]. *Sensors*, 2017, 17(3): 605.
- [22] Li X, Zheng W, Wang X, Xiang T. Multi-scale learning for low-resolution person re-identification[C]. In: *Proceedings of the IEEE International Conference on Computer Vision*, 2015: 3765-3773.
- [23] Wang Z, Hu R, Yu Y, Jiang J, Liang C, Wang J. Scale-Adaptive Low-Resolution Person Re-Identification via Learning a Discriminating Surface[C]. In: *International Joint Conference on Artificial Intelligence (IJCAI)*, 2016: 2669-2675.
- [24] Jing X Y, Zhu X, Wu F. Super-Resolution Person Re-Identification with Semi-Coupled Low-Rank Discriminant Dictionary Learning[J]. *IEEE Transactions on Image Processing*, 2017, 26(3):1363-1378.
- [25] Gray D, Tao H. Viewpoint Invariant Pedestrian Recognition with an Ensemble of Localized Features[C]. In: *European Conference on Computer Vision (ECCV)*, 2008: 262– 275.
- [26] Wang X, Doretto G, Sebastian T, Rittscher J, Tu P. Shape and appearance context modeling[C]. In: *IEEE 11th International Conference on Computer Vision*, 2007: 1–8.
- [27] Li W, Zhao R, Xiao T. Deep ReID: Deep Filter Pairing Neural Network for Person Re-

- identification[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 152-159.
- [28] Huang Y, Xu J, Wu Q, Zheng Z, Zhang Z, Zhang J. Multi-pseudo regularized label for generated data in person re-identification[J]. IEEE Transactions on Image Processing, 2018, 28(3):1391-1403
- [29] Liu J, Zha Z, Tian Q, Liu D, Yao T, Ling Q, Mei T. Multi-scale triplet cnn for person re-identification[C]. In: Proceedings of the 24th ACM international conference on Multimedia, 2016: 192-196.
- [30] Qian X, Fu Y, Jiang Y, Xiang T, Xue X. Multi-scale deep learning architectures for person re-identification[C]. In: Proceedings of the IEEE International Conference on Computer Vision, 2017: 5399-5408.
- [31] Chen Y, Zhu X, Gong S. Person re-identification by deep learning multi-scale representations[C]. In: Proceedings of the IEEE International Conference on Computer Vision, 2017: 2590-2600.
- [32] Chen Y, Zhu X, Zheng W, Lai J. Person re-identification by camera correlation aware feature augmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(2):392-408.
- [33] Chang N H, Yeung D Y, Xiong N. Super-resolution through neighbor embedding[C]// Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition.
- [34] Timofte R, De V, Gool L V. Anchored Neighborhood Regression for Fast Example-Based Super-Resolution[C]// 2013 IEEE International Conference on Computer Vision (ICCV).
- [35] Dong C, Loy C C, He K, et al. Learning a Deep Convolutional Network for Image Super-Resolution[C]// European Conference on Computer Vision. Springer, Cham, 2014.
- [36] Dong C, Loy C C, Tang X. Accelerating the Super-Resolution Convolutional Neural Network[J]. TPAMI, 2016, 38(2):295-307.
- [37] Kim, J, Kwon Lee, J, & Mu Lee, K. Accurate image super-resolution using very deep convolutional networks. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1646-1654.
- [38] Kim J, Lee J K, Lee K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [39] Lim B, Son S, Kim H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW).
- [40] Bruhn A, Weickert J, Schnorr C. Lucas: Combining Local and Global Optic Flow Methods[J].

- International Journal of Computer Vision, 2005, 63(3): 211-231.
- [41] Dosovitskiy A, Brox T. Generating images with perceptual similarity metrics based on deep networks[C]// Proceedings of the Advances on Neural Information Processing Systems, 2016: 2802-2810.
- [42] Gatys L, Ecker A, Bethge M. Image style transfer using convolutional neural networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016.
- [43] Zajdel W, Zivkovic Z, Krose B. Keeping track of humans: Have I seen this person before [J]. 2005: 2081-2086.
- [44] Oreifej O, Mehran R, Shah M. Human identity recognition in aerial images[C]//Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on. IEEE, 2010: 709-716.
- [45] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]//Computer Vision and Pattern Recognition(CVPR), 2012 IEEE Conference on. IEEE, 2012: 2288-2295.
- [46] Sun Y, Zheng L, Deng W, Wang S. Svdnet for pedestrian retrieval[C]. In: Proceedings of the IEEE International Conference on Computer Vision, 2017: 3800-3808.
- [47] He, K, Zhang, X, Ren, S, & Sun, J. Deep residual learning for image recognition[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [48] Girshick R., Donahue J, Darrell T & Malik J. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 580-587.
- [49] S Ren, K He, Girshick R & Sun J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. In IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [50] Lin T Y, Dollár P, Girshick R., He K, Hariharan B & Belongie S. Feature pyramid networks for object detection[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2117-2125.
- [51] Bottou L. Stochastic gradient descent tricks[J]. Neural networks: Tricks of the trade, 2012: 421-436.
- [52] Maas A L, Hannun A Y, Ng A Y. Rectifier nonlinearities improve neural network acoustic models[C]. International Conference on Machine Learning, 2013: 18-3.
- [53] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]. Proceedings of the fourteenth international conference on artificial intelligence and statistics, 2011: 315-323.
- [54] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and

- clustering[C]. Computer Vision and Pattern Recognition(CVPR), 2015: 815-823.
- [55] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. ar Xiv preprint ar Xiv:1703.07737, 2017.

攻读硕士学位期间的学术活动及成果情况

1) 参加的学术交流与科研项目

- (1) 平安城市虚拟卡口关键技术研究及产业化（编号：1301041025），2013-2018，安徽省科技攻关重点项目
- (2) 面向交通及治安安全的视频大数据分析应用与服务系统研发及产业化（编号：W2015JSKF0095），2015-2018，企业委托

2) 发表的学术论文

- (1) 汪荣贵, 王静, 杨娟, 薛丽霞. 基于红外和可见光模态的随机融合特征金子塔行人重识别[J]. 光电工程（校定 178 核心期刊），已录用.
- (2) 陈英, 王静, 段喜龙. 基于改进水平集的肝脏 CT 图像分割方法[J]. 传感器与微系统, 2018(1):44-46.