

分类号	TP391.4	密级	公开
UDC	085211	学位论文编号	D-10617-30852-(2018)-02023

重庆邮电大学硕士学位论文

中文题目	基于卷积神经网络的行人 重识别研究
英文题目	Convolutional Neural Network Based Person Re-identification
学 号	S150231025
姓 名	黄 超
学位类别	工程硕士
学科专业	计算机技术
指导教师	王进 教授
完成日期	2018 年 06 月 12 日

摘要

在现实视频监控场景，摄像头为了能够最大区域的覆盖场所，一般会选择将其安放在比较高的角落，这导致拍摄到的图像画质受到严重影响，任何不确定因素都会导致行人属性的不平衡，从而影响判别方法的性能。此外，行人重识别技术一直是视频监控领域的研究热点，并衍生出许多相关领域的理论研究和方法。然而，作为一种更普遍的行人识别方法，主流行人重识别算法未关注行人局部属性特征的识别，因此面临巨大挑战。行人重识别技术面临的问题可以归纳为以下三个方面：1) 如何解决行人属性不平衡问题以提高行人识别精度；2) 如何改进卷积神经网络结构以学习到更细节行人属性特征；3) 如何更有效设定行人区域分割方式以实现端到端行人重识别模型。针对上述问题，本文的主要研究工作可以分为以下两个方面：

1. 行人重识别技术受摄像头拍摄距离，角度，行人密集度和镜头遮挡等因素影响，这些不确定因素都会导致行人属性不平衡，从而降低行人重识别的识别性能。本文提出一种基于属性敏感卷积神经网络的行人属性分类方法，对图像中的行人属性进行分类，该方法首先调整现有的多属性卷积神经网络结构，使其能够感知更加细节的行人属性。其次利用误差反向传播的方法去更新卷积神经网络中的权重，使网络模型能够对少类属性敏感。解决了行人属性不平衡问题对行人重识别的影响。

2. 为了能够挖掘更加细节的行人属性特征，本文提出一种端到端行人重识别模型，首先利用神经网络自适应学习行人身体部位裁剪参数，再利用裁剪参数对行人关键部位切割，每个关键部位使用属性敏感卷积神经网络提取属性特征，其次用属性敏感卷积神经网络学习行人全局身体属性特征，最后融合全局和局部身体属性特征用以行人重识别。

为了验证本文提出的行人重识别模型有效性，在多个视频监控视频集上进行对比实验。实验表明，本文提出的方法能够很好的处理行人重识别任务。

关键词：行人重识别，行人属性不均衡，卷积神经网络，端到端模型

Abstract

In real-life video surveillance scenes, the camera had been generally choose to place it in a relatively high corner in order to be able to cover the largest area, which results in serious impact on the image quality of the captured image. Any uncertain factors will lead to the imbalance of pedestrian properties, thereby affecting the performance of the discriminant method. ReID technology has already been a hot topic in the field of video surveillance, while many methods and theoretical basis for person identification through video surveillance have been proposed or introduced. However, as a more common person identification method, it is a big challenge since most ReID methods usually fails to recognize the pedestrian parts feature. The problems of ReID technology can be described as the following aspects: 1) Improving pedestrian recognition accuracy by solving the label imbalance problem of pedestrian attribute. 2) Learning more details of the pedestrian attribute by using improved convolutional neural network. 3) Building the end to end ReID model by setting pedestrian parts cropping methods more effectively. To solve these problems, the main research work of this paper can be divided into two aspects:

1. ReID technology is affected by factors such as camera distance, angle, pedestrian density and occlusion rate. The imbalance of pedestrian attributes will affect the recognition performance of ReID, since some uncertainties such as camera shooting distance or angle, pedestrian density and occlusion rate will lead to the imbalance. In this paper, a ReID on label Sensitive Convolutional Neural Network based Pedestrian Attribute Classification is proposed, by adjusting the existing multi label convolutional neural network structure, so that it can perceive more detailed pedestrian attributes, and updating the weight of the convolution neural network by error back propagation method, so that the network model can be sensitive to the weak labels, to reduce the influence of pedestrian label unbalance on ReID.

- 2 An end-to-end ReID model is proposed, by adaptive learning pedestrian body segmentation parameters on neural network and integrating the label sensitive convolutional neural network learning pedestrian attributes, to find more detailed label feature of pedestrian.

To verify the validity of the proposed ReID model, the comparative experiments are carried out on multiple video surveillance video sets. The experiment results show that the proposed method in this paper can handle the task of ReID well.

Keywords: ReID, unbalance of pedestrian attribute, convolutional neural network, end-to-end model

目录

摘要	I
Abstract	III
图录	VII
表录	VII
第 1 章 绪论	1
1.1 行人重识别研究背景和意义	1
1.2 国内外研究现状及发展动态	2
1.3 行人重识别现存问题	5
1.4 本文研究内容	6
1.5 论文结构安排	7
第 2 章 行人重识别概述	9
2.1 卷积神经网络	9
2.1.1 卷积层	9
2.1.2 池化层	10
2.1.3 全连接层	11
2.2 行人属性分类	12
2.2.1 经典分类模型	12
2.2.2 神经网络分类方法	13
2.3 行人重识别技术	13
2.3.1 行人属性特征表达方法	14
2.3.2 相似匹配学习方法	15
2.4 本章小结	16
第 3 章 基于属性敏感卷积神经网络的行人属性分类	17
3.1 属性敏感卷积神经网络模型	17

3.1.1 CReLU2 激活模块.....	18
3.1.2 多尺度网络结构.....	20
3.2 属性敏感损失函数.....	21
3.2.1 属性误差反向传播方法	21
3.2.2 属性不均衡损失函数	22
3.3 实验结果与分析.....	23
3.3.1 实验数据集及评价指标	23
3.3.2 行人属性不均衡度对性能影响.....	26
3.3.3 模型结果与分析.....	27
3.4 本章小结	31
第 4 章 端到端行人重识别模型	33
4.1 端到端模型	33
4.2 基于 STN 网络的行人裁剪模型	35
4.2.1 有效身体部位裁剪规则	36
4.2.2 身体部位特征提取和融合.....	38
4.3 实验结果与分析.....	39
4.3.1 实验数据集及评价指标	39
4.3.2 主流行人重识别方法对比.....	41
4.3.3 基于 STN 身体部位裁剪有效性	44
4.4 本章小结	45
第 5 章 工作总结与展望.....	47
5.1 工作总结	47
5.2 工作展望	48
致谢	49
攻读硕士学位期间从事的科研工作及取得的成果	51
参考文献.....	53

图录

图 2.1 卷积层与池化层结构示意图	10
图 3.1 CReLU2 激活模块结构图	19
图 3.2 多尺度融合网络结构	20
图 3.3 行人属性图例	24
图 3.4 行人属性不均衡率	25
图 3.5 行人属性不均衡度的影响	27
图 3.6 Top-5 准确度行人属性抽选展示	31
图 4.1 端到端行人重识别模型	34
图 4.2 预设定裁剪方法	36

表录

表 3.1 数据采集方式	25
表 3.2 部分属性不均衡率	26
表 3.3 不同模型准确度的对比	28
表 3.4 不同模型召回率上的对比	29
表 3.5 不同模型在 AUC 上的对比	30
表 4.1 Market1501 上实验结果	41
表 4.2 检测模型标注 CUHK03 实验对比	42
表 4.3 人工标注 CUHK03 实验对比	43
表 4.4 MARS 上单例查询实验结果	43
表 4.5 MARS 多例查询实验结果	44
表 4.6 两种行人身体部位裁剪方法结果对比	44

第 1 章 绪论

1.1 行人重识别研究背景和意义

近年来,以信息技术为代表的科技和产业革命正在快速发展,为经济社会的发展注入新生力量,同时互联网的发展也给社会治安基础建设带来许多新的挑战。全国正处于工业信息化向互联网时代转型,常见的社会公众服务更加的便捷亲民,国民幸福指数逐步攀升。众所周知,社会主义的繁荣离不开对社会公众安全的维护,建立健全社会公众安全保护网是迫在眉睫需要解决的难题。得益于科技和产业革命的快速发展,公共场所海量视频监控数据的获取和存储变得越加容易,也越加有效地打击犯罪。这些海量视频影像数据既是公共安全部门侦查破案的重要资源,也是人民生命财产安全的重要保障。传统的视频安全技术多数是采用人工监控的手段来获取对案件有效的信息,为此监控人员需要长时间盯着监控视频捕捉有用信息并进行快速判断,这不仅需要消耗大量的人力物力以及时间,还远达不到快速侦破案件的效率需求。因此,如何高效地从多个无视角重叠的视频摄像头中准确获取有效信息,被视为计算机视觉领域的主导方向,同时在行人重识别、商业传媒咨询与公共场所视频监管、辅助行人监控和行人计数^[1]等领域也面临诸多亟需解决的难题。

行人重识别技术^[2]是在不同视角和时刻拍摄的监控视频影像中准确匹配出特定行人目标。作为视频监控领域新兴技术,行人重识别技术已越来越受到计算机视觉学术界的重视,成为计算机视觉^[3]的热点问题之一。2010-2017 年,已有几百篇题中包含“行人重识别(Person Re-Identification)”关键字的论文在计算机视觉和模式识别领域相关的会议和期刊(包括 ICML、NIPS、CVPR、ECCV、IJCAI、AAAI、ICDM、KDD 等)上发表。文献^[4]关注行人属性类别的不平衡性问题,即行人重识别任务中一个行人的属性通常被赋予多个类别,而且属性之间并非完全独立而是相互关联,所以行人重识别任务,也面临行人属性不均衡的问题,比如数据采集过程受摄像头拍摄距离、角度、行人密集度和镜头遮挡等不确定因素影响,这些不确定因素会导致行人属性不均衡,从而影响行人重识别模型的准确度。文献^[5]将最新的深度学习研究方法运用到行人重识别场景,现在传统的深度学习方法在处理行人重识别问题时往往需要将行人身体部位按照预设定分割方式进行分割,再将分割出来的部分分

别用一个基本深度学习模型提取特征，最后融合在一起进行行人识别。这种预设分割的方式往往会引入误差，例如行人姿态变化可能导致头部区域分割未能包含头部信息。因此，设计一种端到端行人属性自动分割方式是提高整个行人重识别任务准确度的关键，也是当前行人重识别任务面临的一个亟待解决的问题。

深度学习^[6]是近年来机器学习领域的热门方向，卷积神经网络 (Convolutional Neural Network, CNN)^[7]是人工智能领域关键技术。不同于传统神经网络，卷积神经网络结构更加复杂，不仅能够学习线性特征分布，也能学习非线性特征分布。尤其是在视频和图像领域的识别与检测中，卷积神经网络可以省去人为提取特征的过程，只需要设定好学习参数就能在网络训练过程中自动学习模式，并且使得学习到的特征具有更高泛化能力。目前，卷积神经网络已经成功地运用到许多领域，如汽车检测、行人检测、行人计数、行人追踪、图像分割以及图像融合^[8,9]等，近年来针对行人重识别任务的研究渐露头角。本文是基于卷积神经网络的行人重识别研究，提出了一种适用于行人属性不均衡的端到端卷积神经网络行人重识别模型。研究利用深度学习方法处理行人重识别问题提高行人重识别问题的识别准确性和学习效率，为提高行人属性重识别准确度提供一种新的理论和方法，该项研究具有重要的科学意义。

1.2 国内外研究现状及发展动态

行人重识别是行人检测问题的延伸，属于起步比较晚的新兴研究课题，最早的行人重识别相关研究是在 1996 年发表的文章^[10]，距现在也才 21 年的发展历程。在 2006 年，行人重识别的概念第一次在 CVPR 上提出后^[11]，随后相关的研究不断涌现。2007 年，M. E. Monroe 等人^[12]公开发布一种对行人重识别具有研究意义的数据库 VIPeR，标志着越来越多的学者开始关注行人重识别的研究。此外，国际计算机视觉顶级期刊和会议都会对行人重识别问题针对性讨论，其中包括如 2010-2015 年计算机视觉与模式识别会议 (CVPR)、2012 年欧洲计算机视觉会议 (ECCV)、2016 年 IEEE 模式分析与机器智能期刊 (IEEE) 等。尤其是基于深度卷积神经网络方法引起了广泛的关注，深度卷积神经网络方法在各个数据集上也获得很大的提升，可见基于深度卷积神经网络的行人重识别任务已成为计算机视觉的一个热点问题。近年来，行人重识别技术取得长足的发展，绝大部分方法基本可划分为特征描述^[13]和相似匹

配学习^[14]这两大类方法，前者算法模型注重构建更加具有辨识度的属性特征；后者算法模型则更加注重模型本身对图像中行人的相似性量化。

从图像中构建具有强辨别度的行人属性特征便于在多张图像中匹配出相同的行人，同时更有利于根据构建的行人属性计算相似度。相对于传统数值型特征，图像可构建的特征有颜色特征、形状特征、梯度特征、纹理特征、结构特征、区域特征以及关键点^[15,16]等。L. Bazzani 等局部特征相似聚合 (SDALF)^[17]方法是行人属性特征构建方法中最有创新性的一个方法，人体对称性被他们利用到算法模型中，通过对人体对称性的刻画可以很好的解决摄像机拍摄角度对行人属性特征的影响。文中方法根据人体骨架结构将行人分为三个部分：头、上身和下身，为避免头部信息太小丢失太多信息，只针对上身与下身进行左右对称构建颜色直方图特征、颜色区域最大特征和高频结构区域特征，最后融合这三部分特征增强辨识度。D. S. Cheng 等^[18]提出了基于图形结构的 (CPS) 方法，为避免人为引入的误差该文算法更加注重行人骨骼结构自动划分方法，通过模型结构自动划分算法得到图像中行人的头部、上身、腿部和小腿，再构建行人各个部位的颜色特征用以行人识别。L. Bazzani 等人^[19]提出的非对称结构 (AHPE) 算法延续了前人对行人身体部位结构特征的研究，将全局与局部行人身体结构进行融合来提高行人属性特征的辨别度。该算法利用视频拍摄会产生多张画面的特点，将单镜头下行人的多张图像分别构建出行人的 HSV 颜色直方图^[20]作为全局特征；对于其他身体骨架结构同样采集多张图像，再对图像中行人骨架结构提取高频结构特征图构建局部属性。Ma Bingpeng 等提出 eLDFV 方法^[21]，主要是利用费希尔向量和七种区域描述因子来构建图像中行人属性，该文视频的每一帧图像被转化为包含了如灰度梯度和该点均值和方差的七种区域描述因子，最后将构建好的特征再进行编码操作融合成为全局的费希尔向量，再用 PCCA 方法^[22]计算七种区域描述子的相似性。F. Agliardi 等人^[23]提出的聚合七种区域描述因子 (SCEFA) 算法融合了加权颜色直方图^[17]、最大稳定颜色区域^[22]和 Gabor 纹理特征，并融合了图像中像素点特征、部分区域特征和分块特征等信息组合观察。文献^[24]将多种图像中常见的特征信息进行融合并计算特征之间的协方差来增强属性的辨别度。首先会构建人体骨架分区信息的协方差，再计算摄像头中多张画面中行人属性的协方差。文献^[25]首先从图像的颜色和人体骨架结构角度出发构建出基本的属性特征，再将构建好的特征融合到空间直方图和像素分块协方差特征属性中，再进行行人进

行重识别。除此之外, K. H. Han 等人^[26]的 eSDC 方法用无监督区别特征进行行人重识别, 该文提到使用条件相邻分区块搜索的算法构建行人与行人间的稀疏关系。再使用无监督算法训练待识别行人的区别性特征。

此外, 深度学习也被应用于行人重识别的特征提取任务, 利用深度学习自主学习特征之间的关联特征, 增强行人属性特征的表达能力。最经典的特征提取网络结构有 AlexNet^[27]模型, 该模型首先在 ImageNet 数据集^[28]上进行预训练, 以获得较为稳定的网络特征权值, 最后将学习好的网络结构迁移到其他新的网络结构中。网络结构迁移后不需要调整任何卷积神经网络结构参数便可得到高层属性特征, 然后用循环神经网络(RNN)^[29]捕捉序列信息, 然后池化得到序列特征。Xiao Tong 等^[30]对来自各个领域的数据训练出同一个卷积神经网络(CNN), 有些神经元学习各个领域共享的表征, 而其他神经元对特定的某个区域有效, 得到鲁棒的卷积特征描述。

以上简述算法均属于特征描述方法, 前人的研究一般选择欧式空间和巴氏空间距离指标来计算图像中行人之间的匹配度。但由于行人重识别问题场景复杂, 影像资料基本源于多个互相不重叠视角的摄像头, 导致图像中待测试的行人会出现不同程度上的变化, 包括体型变化, 姿势变化, 高矮变化等等。受到复杂因素影响的算法模型就无法使用固定的匹配算法进行度量, 从而影响图像中行人重识别的性能。所以有另一些学者选择使用学习距离因子的方法, 通过距离因子可以获取表征能力较强的特征属性, 实际做法是自动学习各种行人属性特征表达的权重, 并将其按照权重比例融合到一起。Gray 等提出的局部属性特征集成(ELF)方法^[31]将在图像设定长方形区域选取颜色特征^[17]、纹理特征^[20]以及亮度特征融合成为行人重识别的特征, 再 AdaBoost 方法^[32]学习图像特征权重。Du Yuning 等人^[33]提出的局部属性特征随机集成(RECF)方法, 用图片的 RGB、归一化 RGB、HSV、YCbCr、CIE XYZ 和 CIE Lab 等多种常规色彩结构和空间特性组合为强特征, 然后利用 C4.5 算法学习影像集中特定行人匹配函数。B. J. Prosser 等人^[34]提出的 Ensemble-RankSVM 算法先将影像集中图片切割为 6 个等宽的矩形, 在每个矩形区域里构建 8 个色彩层和 21 个图像纹理属性。最后选用 SVM 算法学习这些行人属性特征对的匹配函数。S. Bak 等人^[35]提出协方差矩阵筛选(COSMATI)方法将熵驱动准则与协方差矩阵合并的方法来构建图像特定行人的辨识属性。构建出类似 Sigmoid 函数^[36]分布模型, 利用极大似然函数求取行人匹配函数。最后, 文献^[13]利用贝叶斯推断方法学习行人匹配函数, 好

处是缩短了匹配函数学习时间。学习距离因子的算法训练过程比较复杂，运算效率不高，而特征描述算法就有很好的优势，尤其是解决对运算速度要求较高的监控场景。除此之外，当样本量不够充分的时候，学习距离因子的算法学习不充分，从而不能很好的识别特定行人。特别是在现实场景中，多种复杂的噪声因素都可能会影响到模型的训练，这也对基于学习距离因子的方法研究带来新的挑战。

此外，深度学习的发展同样带来了度量方法的变革。Yi Dong 等人^[37]基于孪生卷积神经网络提出了一种深度度量学习方法，在行人重识别任务中首次取得突出的识别效果。Liu hao 等人^[38]基于领域成分分析和深度置信网络提出一种深度非线性度量学习方法。领域变换分析的作用是通过数据变换使训练数据中每类数据的可识别样本数目最大化。为了扩展领域变换分析中的数据变换，采用深度置信网络来学习非线性特征变换。Li wei 等人^[39]提出了一种深度学习框架来学习滤波器组，该滤波器组旨在对不同视角下的图像因子变换进行自动编码。Ding Shengyong 等人^[40]在损失函数和学习算法上做了改进，提出了一种基于深度神经网络的可扩展距离驱动特征学习框架，同样取得突出的识别性能。

1.3 行人重识别现存问题

行人重识别技术受到许多专家学者以及工程师的关注，无数学者百家争鸣，并在已有的研究基础上逐步推进研究进程。但行人重识别问题仍不可避免地会面临非常多的问题，比如摄像头视角变化，行人姿态变化，光照因素，拍摄距离等，这些不确定因素是会引发很多亟待解决的难题，距离实际应用还有很长的路需要探索。

目前，行人重识别任务仍面临着许多挑战，具体如下：

- a) 行人重识别延续了行人检测的研究，但着重点是在复杂场景下识别出特定行人的监控，均属于从监控视频中匹配出特定的行人。行人的姿态往往是变化的，个体间存在着高矮胖瘦尺度比例的差异，另外行人间的喜好也有很大差异，这些不确定的因素会导致行人属性特征不均衡，从而影响模型的识别性能。
- b) 为了更好的在网络中传输，监控视频影像通常会采用视频压缩的方式，这使得采集到的监控影像到达监控人员端时分辨率较低，会丢失很多行人属性特征的细节。另外已有的卷积神经网络结构只能学习到高层抽象特征，行人身体上的细节属性特征学习效果不佳，进而降低了模型的识别能力。

- c) 目前已有的行人重识别方法会人为的分割行人身体部位，再利用深度卷积神经网络学习每一个身体部位的属性特征。人为的身体部位分割方式会引入许多人为误差，比如分割头部的结果仅为背景图案，网络模型学习这样的行人身体部位信息会大大影响模型的识别能力。

1.4 本文研究内容

行人重识别问题相关研究取得了长足的发展，当前大多数的行人重识别技术都无法在行人模糊、分辨率低的条件下很好的学习行人细节属性。比如，挎包、logo、牛仔裤、墨镜和领带等细节。本文研究主要是要解决以下问题：如何解决行人属性不均衡问题以提高行人识别精度；如何改进卷积神经网络结构以学习到更细节行人属性；以及如何更有效设定行人区域分割方式以实现端到端行人重识别模型。针对行人重识别问题，建立一个行人属性分类模型，提高模型对行人细节属性的学习，同时基于该行人属性分类模型，提出一种端到端的行人重识别模型，为更好的学习行人属性细节增加模型鲁棒性，本文提出一种行人身体部位自适应分割方法，该方法能够通过网络迭代训练学习其分割参数。本文的主要研究内容如下：

1) 提出属性敏感卷积神经网络的行人属性分类

行人属性通常涉及大量的类别属性，通过对公开行人重识别数据库进行统计分析，发现大多数行人由于拍摄角度、拍摄距离、拍摄时间和天气等因素影响，呈现行人属性不均衡的现象，此外监控视频影像经过压缩传输，一些行人属性已经模糊不清或者丢失，这些因素很大程度的影响了行人重识别的性能。因此，本文需要研究一种学习模型，既能够对行人属性不均衡有效地学习，也能够对行人属性模糊和细节特征进行学习。本文提出一种基于属性敏感卷积神经网络的行人属性分类模型，不论是属性不均衡还是属性细节模糊均能有效地学习，并以此来提高行人属性的识别能力。

2) 提出端到端行人重识别模型

基于深度学习的行人重识别方法多采用预设定参数分割行人身体部位，以获得更加细节的行人属性。但由于视频监控受拍摄视角、拍摄距离等等因素，行人的姿态会有所变化，这导致预设定行人身体部位分割参数会出现复杂背景干扰信号，比

如预设定分割头部信息会出现分割画面内只有背景信息而无行人头部信息。因此，为更好的学习行人属性细节增加模型鲁棒性，提出一种行人身体部位自适应分割方法，该方法能够通过网络迭代训练学习其分割参数，只需要输入一张行人样本，就可以不做任何人为操作输出一张另一个监控视频影像中相同行人，达到端到端行人重识别要求。

1.5 论文结构安排

本文共有五个章节，具体组织结构描述如下：

第1章 本章对行人重识别的背景和意义，以及国内外工作进展进行阐述和讨论，其次对机器学习热门研究领域深度学习的研究现状进行了阐述，之后对本文研究的行人重识别现有问题和挑战进行说明，最后简要地概括本文的研究内容与组织结构。

第2章 行人重识别研究综述。本章主要阐述目前为止行人重识别任务的前沿研究理论方法和支撑技术，从中吸取前人研究工作的精华。

第3章 阐述基于属性敏感卷积神经网络的行人属性分类方法的设计方法和论证属性敏感梯度回传的有效性，最后通过实验对结果进行进一步论证；

第4章 阐述端到端行人重识别模型设计原理以及整体框架结构，为验证模型的有效性，在多个实验数据集上进行实验论证；

第5章 系统总结全文工作。

第2章 行人重识别概述

前人研究的行人重识别算法可分为两种类型，基于特征描述的方法^[13]和基于相似匹配学习的方法^[14]，前者注重寻找能够更好地描述行人的特征，后者注重寻找合适的行人图像相似度的度量方法。随着深度学习的广泛运用，大量结合深度学习的行人重识别算法也从这两个角度出发提出新的设计思路和模型。本文主要从卷积神经网络、行人属性分类、行人重识别三个方面进行介绍。

2.1 卷积神经网络

卷积神经网络(CNN)^[7]是模块化的网络结构模型，其模块化特点体现在：一方面，网络层级之间的关联是通过神经元传递，只需要部分神经元便可以进行学习；另一方面是相同层中的神经元结构权重更新方式也相同，其模型学习的最终结果是使用最少的神经元，提高模型学习的效率。Y. LeCun 等人^[41]延续 Fukushima 的成果改进 BP 神经网络法提出卷积神经网络概念(LeNet5)，随着神经网络取得的成功，许多学者延续其工作加以改进，并发现其方法非常适合视觉领域场景。卷积神经网络结构由输入层、卷积层、池化层、全连接层及输出层构成^[7]。卷积层和池化层被交替设置在网络模块中，网络模块中输出层的结果只会与输入层局部关联，并通过迭代自适应关联的权重，从而训练出具有强识别力的网络模型。

2.1.1 卷积层

卷积层是通过许多的一阶线性函数组成，称之为神经元。各层神经元之间通过权值传递的方式进行关联，另外通过卷积核函数将上一层的特征过滤到下一层作为特征。卷积核是一种权值矩阵(如 3x3 或 5x5 矩阵)^[42]。CNN 利用卷积过程构建不同的输出特征，低层卷积层构建如轮廓、边、转角，高层卷积层则构建抽象的表达特征。如图 2.1 以最简标准网络结构为例，其他网络结构只需逐层搭建即可。图中第一层为池化层，第二层为卷积层，第三层为输出层。

由图 2.1 可知，神经元的输出关联到下一层的输入，通过卷积核的权重将神经元和下一层的输入关联在一起^[6]。通过卷积核加权的输出首先会经过 ReLU 函数进




图 2.1 卷积层与池化层结构示意图

行激活，从而得到新的神经元。为了防止模型随着训练迭代而过拟合，前人还在 ReLU 函数后添加了 Dropout 层，其功能是让部分卷积核的权重通过并进入到下一层，其他则丢弃。这样简单的操作不仅可以减少模型训练难度，也可以防止过拟合风险。Xu Chen 的综述^[43]讨论了 CNN 性能的关键因素：模型层数、卷积结果多样及网络架构。该综述在中文字迹数据集上对比了 9 中不同 CNN 网络架构，从每个网络架构的结果进行分析提升模型性能的因素：(1) 添加卷积层数可提高识别率；(2) 提高卷积层输出结果多样性可提高识别率；(3) 增加卷积层个数比增加全连接层更容易提高网络结构的性能。Y. Bengio 等人^[44]也表示卷积网络有很明显于传统算法的优点：(1) 容易反复学习多样的特征；(2) 特征表达更加的细致，从图像中人的线条纹理到像素级别的抽象，都能够很好的学习得到。

2.1.2 池化层

池化层需要与卷积层搭配构建为一个神经组件，池化层从卷积层接收卷积核输出的特征信息，并按照比例改变特征信息的结构。如图 2.1，池化层的输入与卷积层一一对应，且都不做太多计算操作，池化操作的目的是想要减少图像中像素点因卷积操作后造成的依赖联系，降低像素点之间的依赖得到更具区别性特征。池化操作方法与卷积核相似，都是在一个感受区域中计算结果，最后得到更加抽象的属性特征。现在已有的池化操作有极大值、平均值、随机变换^[45]等。Y. L. Boureau 等人^[46]

研究了极大值和平均值池化的机理，从而得出如下结论：(1) 极大值池化一般用来筛选比较稀疏的特征；(2) 不要求感受区域整体的平均值，而是划分子区域计算。

A. Krizhevsky 等人^[47]设计并实现一种可重叠计算的池化操作，在 ImageNet 上 top-1 和 top-5 的错误率下降 0.41% 和 0.33%，相比主流池化操作，该方法能够更好的防止过拟合风险。假设池化操作第 n 个特征上第 l 个神经元的输出为 t_{nl}^{out} ，池化操作可以由式 2.1 表达如下：

$$t_{nl}^{out} = f_{sub} \left(t_{nq}^{in}, t_{n(q+1)}^{in} \right) \quad (2.1)$$

式中： t_{nq}^{in} 指池化层中第 n 个特征信息的第 q 个神经元运算值； $f_{sub}(\bullet)$ 为极大值函数或平均均值函数。与卷积核类似，池化操作使用的矩阵称之为池化核。可以将卷积神经网络中卷积核和池化核等同于休博尔和维瑟尔结构^[48]感受区域的具体实现，卷积层构建图像低层特征信息，等同于休博尔和维瑟尔结构的简单细胞，池化层结构复杂，等同于休博尔和维瑟尔结构的复杂细胞。CNN 中池化^[46]操作输出（神经元个数） $DoMapN$ 为：

$$DoMapN = \left(\frac{oMapN}{DWindow} \right) \quad (2.2)$$

式中，池化核矩阵为 $DWindow$ ，从图 2.1 中可得 $DWindow$ 为 2，池化层操作减少了图像像素点之间的关联关系，通过模型自行挑选的神经元（少量）构建简洁且高效的计算模型。

2.1.3 全连接层

卷积神经网络经过前置低层卷积和池化操作后，最终都会接入一些全连接层。这里的全连接层就同多层感知机一样，输入是上一层操作的输出。全连接层功能^[49]是将前置层输出的结果融合到一起，构建一个具备很高辨识度的特征信息图。如同前置层网络构建方式，全连接层也会在输出结果后添加一层 ReLU 激活函数^[50]。多个全连接层堆叠结构的输出最终到达输出层，就可以利用 SoftMax 模型回归预测分类。不同的任务，对分类函数的选择也有所不同，Gu Jiuxiang 等人^[45]讨论了卷积神经网络结构中输出层常用预测模型的各自特点。卷积神经网络学习与预测过程与 BP 神经网络算法类似，基本采用损失函数的梯度值回传方式更新权重。如果用于训练网

络结构的图像数据集比较小,那么可用于测实验证的数据就少,进而网络模型预测的性能也不够好^[51]。这种状况被称之为过拟合现象,为避免过拟合,仍需要在模型最后加入 Dropout 层来降低过拟合风险,Dropout 层的作用是随机丢弃一部分卷积层输出的结果,通常随机丢弃的概率设为 0.5,即每次有一半的值被丢弃,剩下的继续训练^[51]。每一层神经元的输入和输出因为添加了 Dropout 层函数后具有了一定的随机性,最终训练的结果仍会收敛到一个误差很小的区间。所以卷积神经网络模型具有自适应特征构建的能力和自适应迭代训练的能力,因此卷积神经网络能尽可能多的消除神经元之间的聚合关系,提高网络模型预测性能。

2.2 行人属性分类

行人属性特征属性分类也称为行人属性分类是视频监控系统的关键技术之一,其任务是想要在远距离监控视频中通过对行人属性的识别,从而分辨出行人。同时该技术也广泛运用于行人重识别、商业媒体智能和视觉监控、辅助行人监控、追踪和计数等领域。近年来,尽管行人属性分类技术取得长足的发展,但是在实际场景仍然面临众多挑战,比如摄像头拍摄距离、角度、行人密集度、行人个人喜好和镜头遮挡等,这些不确定因素都会导致行人属性不均衡,从而影响判别方法的性能。

2.2.1 经典分类模型

经典行人属性分类模型是人为的提取特征属性特征,再独立地为每一个属性训练一个分类模型。典型的基分类模型有 SVM^[9]和 KNN^[17],文^[28]有提出使用 AdaBoost 算法来独立训练的分类器模型。这些模型的设计思想相对来说比较简单,仅仅是假设属性之间没有关联性,从而将多类属性问题转化为了 0-1 类别属性问题。这种方法的准确度很难有突破性提高,常常受到属性关联性所制约,所以分类性能仍有空间提升。

有科研工作者进一步挖掘属性之间的关联性并提出了新的基于属性关联的分类算法。Chen Xueyun 等人^[8]利用条件随机场方法研究特征属性间的相互关联关系,该方法利用了 SVM 在独立训练特征属性上的边界来训练分类模型。Deng jia 等人^[28]引入了马尔科夫随机场的方法将相邻图片的语义信息构建为无环图,图中结点代表

马尔科夫隐变量，结点之间的连线表示相似近邻。L. Bourdev 等人^[52]利用 SVM 算法去探索不同特征属性之间的相互关联性。Zhu Jianqing 等人^[53]改进了行人属性特征分类算法，将加权关联信息加入到算法中，这样最终预测评分转化为各个加权关联信息的线性组合，避免了属性不平衡带来的误差，从而使得分类模型更加鲁棒性。

2.2.2 神经网络分类方法

基于 SVM 的方法在训练分类模型时需要人为地提取图像的属性特征。众所周知人为提取图像特征有很大的局限性，无论是在区分度表现能力还是在样本多样性上都稍逊于卷积神经网络自动获取属性特征。因此使用基于特征学习的机器学习方法可能是提升性能的潜在手段。卷积神经网络（CNN）^[6]是目前非常主流的特征学习算法，已经广泛被运用到图像相关的运用中并表现出很好的性能。Gong Shaogang 等人^[2]提出使用卷积神经网络来处理多类属性标注问题。Zhu Jianqing 等人^[53]提出一个多类属性卷积神经网络(MLCNN)来解决行人属性特征属性分类问题，将每一张行人图像进行 15 份连续分割，并将这 15 份分割分别送入到卷积神经网络去学习属性特征。从实验分析，MLCNN 算法的分类性能明显优于上述提到的 SVM 算法。但 MLCNN 模型仍没能充分解决行人属性不平衡问题，仅仅为行人属性按照属性对分类的贡献度来设置权重。这种方法比较固定，随着网络模型的迭代更新，会失去原有的鲁棒性。所以对于行人属性不均衡的问题，仍需要进一步研究卷积神经网络的分类结构。

2.3 行人重识别技术

目前，行人重识别问题的研究主要集中在两个方面：

1. 行人属性特征表达方法：如今图像中行人属性信息的构建已经十分成熟，如何构建出区分性更强的行人属性特征，需要很好地解决图像拍摄过程中受到天气好坏、拍摄距离和拍摄角度等复杂因素影响。
2. 相似匹配学习方法：如何更好的刻画特定行人在图像中的匹配度，需要构建一个更加适应场景的匹配函数。保证特定行人之间匹配度最大，不同行人最小。

2.3.1 行人属性特征表达方法

图像中行人最明显的属性信息是外观,包括服饰色彩、风格和尺寸等,图像中行人外观又常常受到各种环境因素的影响,所以行人属性特征表达模型的瓶颈是如何在复杂场景中对行人属性准确刻画。近年来,科研工作者将行人影像划分为不同子区域,针对不同的子区域构建属性特征。对于构建整张行人影像属性特征的方法,划分子区域的局部属性信息能够很好刻画行人身体结构细节,如头部、上半身、下半身等属性信息。另外,图像中行人属性特征表达还可以按照基于人为构建和基于模型学习构建两种方式区分。

传统方法只能提供常规的视觉属性特征,而语义属性(SA)能够针对性的描述行人具体某个部位的属性特征。例如,“短发男子身着黑色休闲裤”。语义属性对行人的表述更加的准确,而且不必担心受到视频图像采集过程受复杂因素的影响。语义属性带来更具优势的表达,也吸引了许多科研人员的关注。R. Layne 等人^[54]提出 15 种语义属性,对图像中行人的性别、肤色、服装和配饰等因素进行表达。该文将传统图片色彩属性和结构属性用于学习 SVM 模型,再用该模型对 15 种语义属性进行描述,并得到各个语义属性的权值,构建出行人的语义属性特征。Liu Xiangyu 等人^[55]基于 LDA 模型,改进一种基于信息规约的隐含主题模型(ATLTM),ARLTM 先学习特征主成分再对行人语义属性进行提炼。Liu Chengjun 等人^[56]利用无监督学习算法训练少量已知图像属性再自动构建行人语义信息特征。目前,G. Hinton 等^[6]的研究改进现有传统机器视觉领域研究方式,合理利用深度学习方法提高视觉识别能力。对于行人重识别问题,科研人员也开始利用卷积神经网络自主学习特征的优势,快速构建行人属性信息特征。Lei zhen 等人^[57]将图像分割为三个身体部位结构,这三个身体部位结构对应头部、上半身和下半身,每个部位分别训练一个简单的三层卷积网络,最后将这三个网络的结果组合为行人属性特征。Cheng De 等人^[58]改进卷积神经网络的损失函数,将其替换为三元损失函数(TLF)来度量模型识别率。由此可知,深度学习的发展为行人重识别领域提供了新的研究方法和思路。基于学习的特征一般是神经网络的特征,如使用卷积神经网络提取的特征。卷积神经元每一个隐藏层的单元提取图像的局部特征,将其映射成一个平面,特征映射函数采用 sigmoid 函数作为卷积网络的激活函数,使得特征映射具有平移不变性。

2.3.2 相似匹配学习方法

相似匹配学习是度量两个特征之间相似性比较常用的方法，其主要的核心思想是要构建图像中行人的属性特征向量，再借助相似性匹配算法做相应的学习。最常见的相似性匹配算法是基于欧式距离或马氏距离的学习方法。对于马氏距离而言，两个行人属性特征 χ_i 和 χ_j 之间的马氏距离表示为：

$$d_M(\chi_i, \chi_j) = (\chi_i - \chi_j)^T M (\chi_i - \chi_j) \quad (2.3)$$

式中 M 是半正定矩阵，可保证函数的非负性。基于马氏距离相似匹配方法本质是再学习半正定矩阵 M ，保证图像中属于同一行人的距离小，而非同一行人的距离大。K. Q. Weinberger 等人^[59]提出一种最大边界最近邻 (LMNN) 模型，该模型用同属于一类的实例界定间隔比例，再利用合页模型去规约边界的值，这样可以保证不同类别的实例具有大于该边界间隔的距离，从而实现同类别属性的相似性大，不同类别的相似性小。Zheng Weishi 等人^[60]创新提出针对行人重识别相似匹配学习的概率模型，该文对“相同行人属性特征间的相似度大于不同行人属性特征间的相似度”事件建模推断概率，再通过 KL 散度算法计算属性特征时间的相似性，最终得到行人重识别相似性度量函数。M. Kostinger 等^[61]不满足现有的相似性度量函数，提出一种简单直观的相似性度量方法 (KISSME)，该方法首先假设相同类别属性间的相似性与不同类别属性间的相似性分别服从高斯分布，再利用贝叶斯推理模型和似然函数方法，计算高斯分布协方差的差值替代计算马氏距离矩阵。由于 KISSM 方法更加简便不需要迭代计算矩阵结果，所以相比传统方法具有更快的运算速度。除此之外，另一些科研工作者在特征度量学习过程中添加降维操作，在保证属性特征判别性的前提下降低属性特征维度，从而提高运算速度。Liao Shengcai 等人^[62]改进提出交叉二次判别分析算法 (CVQDA)，该算法通过改进传统 LDA 选择具有高判别性的属性特征。具体转换矩阵 ω 求解方式如下：

$$\max_w j(w) = \frac{\omega^T S_b \omega}{\omega^T S_w \omega} \quad (2.4)$$

式中， S_b 和 S_w 为不同类之间的分布矩阵和相同类之间的分布矩阵，分别代表两种类别集合的离散程度。

相似匹配学习方法为行人重识别问题提供了新的思路,并且获得良好识别结果。目前公开影像数据集存在图片数量缺乏和行人正负样本比例不均衡的问题,模型在训练过程中容易发生过拟合,导致模型识别性能下降。除此之外,相似匹配学习方法实质是属性特征在马氏空间中的转换,若仅仅只依赖相似度量方法去匹配特定行人,仍无法避免复杂场景对摄像头的影响。

2.4 本章小结

本章主要对行人重识别相关卷积神经网络、行人属性分类、行人重识别三个方面技术进行介绍。首先介绍了卷积神经网络的基本结构,其次,介绍了行人属性分类相关研究进展。再次,介绍了行人重识别的研究进展,以及结合深度学习方法的成果。最后,介绍了两种行人重识别算法的测评函数,并简要分析了各个指标的特点以及区别。

第3章 基于属性敏感卷积神经网络的行人属性分类

行人重识别问题属于行人检测的延伸，所以行人重识别问题自然也可以通过行人属性分类的方法对行人进行识别。视频监控领域的行人属性，如年龄、头发和穿着等属性，被视为行人识别的辅助特质，这些属性可以用作行人定位、检测、计数以及识别等领域。在现实视频监控场景，摄像头为了能够最大区域的覆盖场所，一般会选择将其安放在比较高的角落，这导致拍摄到的图像画质受到严重影响，任何不确定因素都会导致行人属性的不平衡，从而影响判别方法的性能。此外，由于监控视频受图像画质限制，部分行人细节属性，如墨镜、头发颜色和鞋子类型等属性，存在一定程度的模糊和失真，进而导致行人重识别问题无法突破现有瓶颈。对于现有的卷积神经网络方法，还仅仅是将新的算法模型引入到行人重识别领域中，并未对行人属性不平衡以及行人细节属性深度挖掘。针对现有问题，本文提出一种基于属性敏感卷积神经网络的行人属性分类方法。该方法首先调整现有的多类属性卷积神经网络结构，使其能够感知更加细节的行人属性。其次利用误差反向传播的方法去更新卷积神经网络中的权重，使网络模型能够对少类属性敏感。

3.1 属性敏感卷积神经网络模型

行人属性的图像像素质量存在模糊或者细节层次表现不明显的情况，比如，拍摄角度、距离、光照和行人密集度等因素影响，这些不确定因素都可能导致采集到的图像行人属性表达不利。此外，数据集中行人图片的尺寸较小，例如行人的图像高度在 100-300 pixel，宽度在 50-150 pixel，而且行人图像的像素比例不统一，因此不能直接使用现有预训练模型，需要根据实际需求对模型进行调整和修改，因此，结合实际情况，本文吸取了文^[63]的网络结构改进经验，在现有的行人属性分类模型基础上加深了网络的宽度和深度，具体做法是加入了 InceptionV4 网络结构^[64]，以及多尺度特征融合技术^[63]，学习不同尺度的行人属性特征。本节将从改进属性敏感卷积神经网络模型介绍，主要涉及到本文创新点为 CreLU2 激活模块的设计和多尺度特征融合网络结构的改进。

3.1.1 CReLU2 激活模块

目前在神经网络结构设计过程中,使用频率最高的激活函数是非饱和修正线性单元(ReLU)^[65],当输入的值小于等于零时,线性单元直接输出零,大于零时就将输入的值输出。其公式表达如下:

$$f(x) = \max(0, x) \quad (3.1)$$

由于 ReLU 函数的分段激活特性,可以打破特征参数的依赖关系,得到比较稀疏的属性特征,从而降低模型过拟合的风险。一方面,ReLU 函数的运算公式简单,在一定程度上提高了模型的训练速度,而另一方面,ReLU 函数也能很好的保存有用的属性特征。虽然 ReLU 线性激活单元形式简单,没有其他更多的数学性质,依然能够在工程实践中取得很好的性能,所以该激活单元广泛运用到学术研究和实践中。

总体来说,ReLU 是不饱和函数,它结构形式简单,而且没有如 Sigmoid 和 Tanh^[66]传统激活函数容易梯度弥散的问题。这就有助于在实际应用场景中构建更深层的网络结构,而不用担心属性梯度误差弥散。此外,网络模型梯度误差反向传播时,ReLU 的取值只有 0 或输入值,所以 ReLU 能够更快的学习收敛。对于传统的 S 型激活单元,ReLU 运算和收敛速度都比较快,而且不用担心梯度误差弥散和特征之间的依赖。虽然 ReLU 激活单元具有许多优势,但是其激活的方式仍会很大程度上丢失掉有用的信息,这样就需要迭代更多次训练过程来学习特征。增加模型迭代训练次数可能会带来其他负面的影响,如模型的准确度不稳定,梯度误差弥散和特征过于稀疏。这些负面影响很可能导致模型学习的效果变差。在行人重识别任务中,待训练的数据集是属于低维度和低尺度的行人图片,所以要求模型迭代更新权值的次数不宜太多,否则会因为过拟合问题而降低模型的准确度。行人重识别任务中的卷积神经网络的激活模块要求结构形式简便、收敛速度快,并能保留丰富的行人属性特征和一定的稀疏性。为了网络能够学习到更加细节的特征,本文进一步对卷积神经网络进行改进,设计一种融合正反通道激活模块(CReLU2),并将其融合到多尺度网络结构中。融合正反通道激活模块(CReLU2)具体结构如图 3.1 所示:

该模块可以放在卷积层之后用以激活属性特征图,该模块的输入为上一层卷积




图 3.1 CReLU2 激活模块结构图

层输出的特征图，经过一个 3×3 的卷积操作，将其得到的特征图输出分为两个部分，第一个部分属性特征图正常输出，另一个通过取反属性特征得到新的特征图，再将两个特征图进行融合，得到融合了正反通道的行人属性特征图。为了能够衔接下一步工作行人属性不平衡误差的反向传播，本文选用对负类特征有一定保留的 $\text{PReLU}^{[67]}$ 作为本模块的核心激活函数，并对其进行批量归一化操作，由此就构建出了本文的 CReLU2 激活模块。

本文的 CReLU2 激活模块，不仅在一定层度上增加可学习特征图的多样性，并且能够增强行人图像样本的表达能力。虽然模型中直接学习到表达能力更强的特征图需要额外增加一部分的学习参数，但是这样做可以提高卷积神经网络的鲁棒性，不需要人为地对行人属性特征图进行操作或者设计新的特征提取网络结构而浪费更多的计算资源。此外，由于卷积神经网络的卷积层输出可能会有负值，所以本文采用的是对负数特征值有一定保留的 PReLU 激活算法为核心的激活模块，该模块的特点在于对于负半轴的值有一定的保留，防止在行人图像样本训练过程丢失太多的细节特征，这样做可能会带来过拟合的风险。此外通过控制激活函数的激活阈值参数也可以避免过拟合，同时取得较好的识别效果。整体结构的执行相比未调整过后的卷积神经网络结构（比如，VGG16，GoogleNet）多占用约 5%-7.5% 的 GPU 显存，是一个比较能够接受的消耗水平。

3.1.2 多尺度网络结构

目前已有的卷积神经网络的各层结构输出尺度固定，最终只能获取到高维属性特征。行人数据集是低维度和低尺度的行人图片，利用较大尺寸卷积核学习行人属性特征时，会丢失一些低层行人属性细节。利用较小尺寸的卷积和学习行人属性特征时，目标较大的行人属性学习不够连续。本文利用融合多尺度特征的方式，从网络结构中提取出行人属性的高维特征和低维特征进行融合，融合后的特征具有行人全局和局部信息属性。低维度属性特征表征行人的整体轮廓属性，高维属性特征表征行人的局部细节属性。既可以充分挖掘行人的全局信息和局部信息，又可以增加整个网络结构的宽度，从而降低模型梯度误差弥散的风险。

图 3.2 为本文多尺度融合网络结构，具体多尺度特征融合网络实现的步骤如下：




图 3.2 多尺度融合网络结构

- 将输入的行人图像去均值操作后输入到多尺度融合神经网络中，经过前项属性特征提取网络提取基本的行人属性特征，在经过 CReLU2 激活模块获得具有行人属性细节属性表达能力的双通道融合属性特征图。
- 再将得到的双通道融合属性特征图输入到有三个连续不同卷积核的卷积层，这三个卷积层将接受到的属性特征图 *Pooling* 为 1、1/2 和 1/4 的属性特征图。每个卷积层得到的属性特征图包含了丰富的行人属性特征。此外，重新调整了连

续三个卷积层的卷积尺寸，以更好的解决行人属性低维度和低尺度问题，使之能够保留更多的行人属性特征。

- c) 将得到的三个不同尺度的行人属性特征图进行尺度统一，具体是将 $1/8$ 的特征图进行反卷积上采样到 $1/4$ 的行人属性特征图，另外将 $1/2$ 的行人属性特征图进行池化操作获得 $1/4$ 的行人属性特征。规约到同一个尺寸是为了接下来的特征融合能够有相同的尺寸，避免框架在融合特征的时候报错。
- d) 得到三个统一尺寸的行人属性特征图，通过逐像素相加的方式进行行人属性特征融合，得到一个行人属性表达丰富，判别能力强的行人属性特征图。
- e) 由于融合了多尺度的行人属性特征图，可能导致最终的行人属性特征冗余，降低分类效果和增加计算量，所以本文在之后还添加了 1×1 卷积核的卷积层，对多尺度融合后的行人属性特征图进行适当降维，提高模型对行人属性的识别率。

3.2 属性敏感损失函数

常见的卷积神经网络的损失函数多针对单属性类别或者多属性类别任务而设计，对于多属性类别问题必须根据实际设计合理的损失函数。本文设计一种多属性类别不平衡权重自适应方法。本文方法根据行人属性的不平衡比例自适应更新网络中神经元的权重，即利用误差反向传播对少类属性增加其权值，而多类属性降低其权值。通过每次迭代计算出真实值与预测值的误差来更新属性权重。另外，深度卷积神经网络每一次迭代分为很多的批次分别送样本到网络中，能够很好的避免网络模型陷入局部最优。

3.2.1 属性误差反向传播方法

设样本表示为： $\chi^{(p)} = \{\chi_1^{(p)}, \chi_2^{(p)}, \chi_3^{(p)}, \dots, \chi_n^{(p)}\}$ ，那么第 j 层的输出表示为：

$$\begin{aligned} h_j^p &= h_j(\chi^p) \\ &= \text{normal} \left(\text{PReLU} \left(\left(\sum_{i=1}^N \omega_{ji} \chi_i^{(p)} + b_{j0} \right) \right) \right) \end{aligned} \quad (3.2)$$

式中， ω_{ji} 和 b_{j0} 分别为输入 χ_i 与输出 h_j^p 间的权重和偏差， $\text{PReLU}(\bullet)$ 为带参激活函数， $\text{normal}(\bullet)$ 为 Z-score 标准化函数。第 p 层和第 k 个节点的输出定义为：

$$\mathbb{Z}_k^{(p)} = \text{normal}\left(\text{PReLU}\left(\mathbb{Z}_k^{(p)}\right)\right), k=1, 2, 3, \dots, M \quad (3.3)$$

其中,

$$\mathbb{Z}_k^{(p)} = \sum_{i=1}^N V_{ji} h_i^{(p)} + V_{j0} \quad (3.4)$$

设样本 $\mathcal{X}^{(p)}$ 通过隐藏层得到的输出为: $R^p = \{r_1^{(p)}, r_2^{(p)}, r_3^{(p)}, \dots, r_M^{(p)}\}$

其中,

$$R_k^p = \begin{cases} 1, & \mathcal{X}^{(p)} \in k \\ -\alpha, & \text{else} \end{cases} \quad (3.5)$$

其中, α 为比较小的常数, 一般设定为 0.1 或 0.2, 目的仅为了保留一些负数结果, 从而获得足够的泛化性能, 同时使模型训练更快, 定义误差函数为:

$$E = \sum_{p=1}^P \sum_{j=1}^M \left(R_k^{(p)} - h_j^{(p)} \right)^2 \quad (3.6)$$

定义误差函数后可以通过梯度下降的方法迭代更新权值。

$$\Delta \omega_{ji} = -\eta \frac{\partial E}{\partial \omega_{ji}} = \eta \chi_i^{(p)} \sum_{k=1}^M V_{kj} \frac{\partial E}{\partial \mathbb{Z}_k^{(p)}} \quad (j=1, 2, 3, \dots, H; i=1, 2, 3, \dots, N) \quad (3.7)$$

以上为误差反向传播算法^[68]的过程, 本文对原有的激活函数进行作了调整, 目的是为本文提出的多类属性不平衡权值自适应方法简化计算量, 同时也获得了更加稳定性能。

3.2.2 属性不均衡损失函数

本文考虑的是图像中的多属性分类问题, 即图像有多个特征属性。进过统计发现, 有部分属性的在多种场合下出现的比例均较小, 本文称之为少类属性 C_1 , 而有部分属性出现的比例较高, 称之为多类属性 C_2 。如果仍使用上述误差反向传播方法更新权值会导致少类属性被学习到的概率下降, 最终的预测结果也会出现很强的偏见。为了解决这个问题, 本文在误差反向传播方法基础上提出不平衡多属性自适应方法。不平衡多属性损失函数定义如下:

$$\begin{aligned}
E_{prop} &= -\sum_{i=1}^L \sum_{p \in C_1} \sum_{k=1}^2 \int \frac{r_{ik}^{(p)^{n_i+1}} \left(r_{ik}^{(p)} - Z_{ik}^{(p)} \right)^{n_i}}{2^{n_i-2} \left(1 - Z_{ik}^{(p)^2} \right)} dz_{ik}^{(p)}, (n < m) n \in \{1, 2\} \\
&= -\sum_{i=1}^L \sum_{p \in C_2} \sum_{k=1}^2 \int \frac{r_{ik}^{(p)^{m_i+1}} \left(r_{ik}^{(p)} - Z_{ik}^{(p)} \right)^{m_i}}{2^{m_i-2} \left(1 - Z_{ik}^{(p)^2} \right)} dz_{ik}^{(p)}
\end{aligned} \tag{3.8}$$

式中, $r_{ik}^{(p)}$ 根据公式(3.5)编码, $Z_{ik}^{(p)}$ 为第 i 个属性的预测值, n_i 和 m_i ($n < m$) 是正整数参数, 取值根据属性不平衡度:

$$I = \log \lfloor C_2 / C_1 \rfloor, \quad m = n + I \tag{3.9}$$

这里, 只需要设置参数 n , 实验显示, 在 $n \in \{1, 2\}$ 时使行人属性特征预测取得最优的性能。不平衡多属性损失函数的误差梯度表示如下:

$$\delta_{ik}^{(p)} = -\frac{\partial E_{prop}}{\partial y_k^{(p)}} = \begin{cases} \sum_{i=1}^L r_{ik}^{(p)^{n+1}} \left(r_{ik}^{(p)} - y_{ik}^{(p)} \right)^n / 2^{n-1} & \text{for } k = 1 \\ \sum_{i=1}^L r_{ik}^{(p)^{m+1}} \left(r_{ik}^{(p)} - y_{ik}^{(p)} \right)^m / 2^{m-1} & \text{for } k = 2 \end{cases} \tag{3.10}$$

由于 ($n < m$) , 当 $-\alpha < y_{ik}^{(p)} < 1$, $|\delta_{i1}^{(p)}| \geq |\delta_{i2}^{(p)}|$ 。再利用误差反向传播方法, 卷积网络各层就可以根据误差梯度反向传播 $\delta_{ik}^{(p)}$ 更新。

3.3 实验结果与分析

为了验证本文提出属性敏感卷积神经网络在行人属性分类任务中的有效性。本文采用了 PETA 数据集^[69]进行对比实验。本节主要内容为: 1.介绍实验数据集以及测评函数, 2.实验说明, 行人属性不均衡度对模型性能的影响, 并验证本文方法在处理不均衡行人属性的有效性; 3.实验说明, 本文针对不均衡行人属性分类问题改进的方法有效性。

3.3.1 实验数据集及评价指标

行人重识别技术在商业智能视频和行人视频监控等领域蕴藏着巨大的应用潜力, 行人属性的视觉识别, 如行人性别、年龄和衣着风格, 是计算机视觉研究领域的热门研究话题。在许多的智能视频监控应用场景, 近距离的行人面部和身体区域是不

太容易获取。因此,在远视距场景下进行行人属性特征分类任务时,使用行人面部和近距离身体信息会影响最终性能。在远视距的行人属性识别问题面临两个主要的挑战,1)行人外观视觉多样性,由于行人着装的多样性以及多种不可控制的变量,比如,摄像头视角和解析能力,大量现有的不同行人图像却有许多相同的属性。学习模型去识别此类行人属性特征需要丰富的训练集。2)行人外观随机性,远视距行人属性特征识别是一项异常困难的任务,因为远视距采集到的行人图像存在许多内在视觉随机性和画面质量低的问题。特别地,一个独立的行人图像样本往往只有很少的像素点和小部分是可以真实判别的行人属性特征。通常,图像上的行人身体部位存在被遮挡的情况,这也增加了更好的提取行人属性特征的难度。



图 3.3 行人属性图例

目前现有的数据集在现实世界环境中,不能很好的反应行人属性的多样性。本文采用 PET 数据集进行实验,检验本文的方法在处理行人属性识别问题上的性能优势。PETA 数据集是目前所有已公开的行人属性分类数据集的总和,其样本量达到了 19000 张。文^[69]中作者对 PETA 数据集进行重新标注,其标注信息从之前的 10-20 维属性信息增加到了 64 维。部分具有代表性行人属性的分布如图 3.3 所示,可以看出数据集中有部分行人属性因为受到摄像头拍摄角度、距离、光照和镜头遮挡等不确定因素导致属性不均衡。因此本文的所有实验均基于该数据集进行。PETA 数据集的分辨率大小从 17×39 到 169×365 ,每一张图片由 4 个类别中 61 个二值属性标记。行人二值属性覆盖了详尽的行人属性特征区域,包括行人特征、外观和佩戴的物品等等。PETA 数据集以行人的头部、上身、下身和鞋子将行人属性分为了 4 个类别。该数据集的行人属性中有一半属性比例是平衡的,多类属性与少类属性的比例不会超过 20:1,但是对于另外的部分属性,则存在着严重的数据不平衡问题,表 3.1 和图 3.4 将给出各个数据集整体信息以及行人属性不平衡率。

表 3.1 数据采集方式

数据集	图片数量	拍摄区域	视角	Scene
3DPeS	1012	High	Varying	outdoor
CAVIAR4REID	1220	Ground	Low	Outdoor
CUHK	4563	High	Varying	Outdoor
i-LIDS	477	Medium	High	Indoor
GRID	1275	Varying	Varying	Indoor
Town Center	6967	Medium	Varying	Outdoor
PETA	19000	Varying	Varying	Varying



图 3.4 行人属性不均衡率

本文统一选用准确度、召回率和 $AUC^{[70]}$ 作评价指标，具体表示如下：

$$Precision = \frac{TP}{TP + FP} \quad (3.11)$$

$$Recall = \frac{TP}{TP + FN} \quad (3.12)$$

$$AUC = \frac{\sum_{i \in pc} rank_i - \frac{M(1+M)}{2}}{M \times N} \quad (3.13)$$

式(3.11)和式(3.12)中： TP 为真正正例； FP 为错误正例； FN 为错误负例，(3.13)式中 M 为正样本数， N 为负样本数。在相同参数设置下，分别对比了已有方法受不均

衡行人属性的影响。这三个评价指标都是常见用来评估模型分类性能好坏的指标，其中准确度是预测为正例的数量占整个样本数的比重，召回率是预测为真正例的样本数占被预测为正例样本数的比重，AUC 通过准确度和召回率表征。

3.3.2 行人属性不均衡度对性能影响

为了说明行人属性不均衡对行人属性分类性能的影响，并验证本文改进方法在处理不均衡行人属性分类问题中的有效性。本文挑选了不同不均衡度的行人属性，

表 3.2 部分属性不均衡率

属性名	正例	负例	正负比例
male	10583	8417	1:1
hairShort	12379	6621	2:1
Jeans	5493	13507	1:3
ageLess45	14858	4142	4:1
jacket	15271	3729	4:1
carryOther	17100	1900	9:1
lBGrey	18470	530	34:1
wearGrey	18717	283	66:1
wearShoes	18835	165	114:1

具体如表 3.2 所示，以及用传统方法 (iSVM)^[53] 和基于深度学习方法 (MLCNN)^[53] 与本文方法进行对比实验，实验结果如表 3.3 所示。

由图 3.5 中趋势线可以得到，三种不同的方法在遇到不均衡行人属性时，分类性能随着不均衡度的升高而降低。具体体现在准确度、召回率和 AUC 三个指标上，本文方法预测 footwearShoes 属性 (不均衡比 114:1) 的性能相比于处理 male 属性 (不均衡比 1:1) 的性能分别下降了 21.2%、29.5% 和 14.3%。由图 3.5 可知，对于大多数不均衡行人属性，本文改进的方法 (图中灰色长方形) 在三个指标上的分类结果均优于其他两种方法。

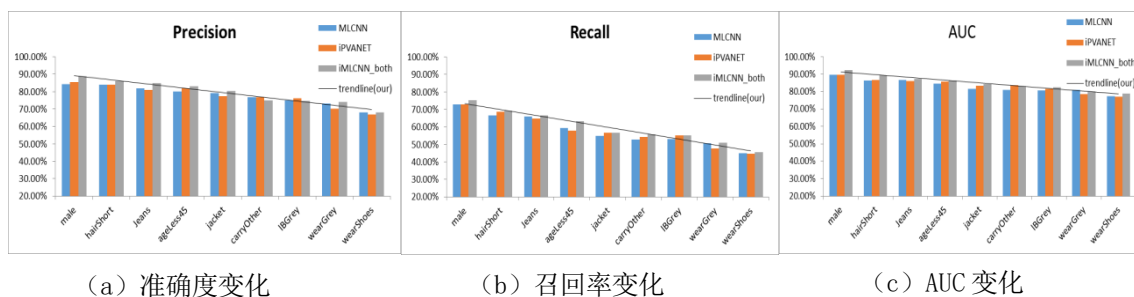


图 3.5 行人属性不均衡度的影响

3.3.3 模型结果与分析

为了说明本文方法能够很好的处理行人属性分类模型受行人属性不均衡影响的问题。用本文的改进方法与多个已有性能优秀的方法进行实验对比。这些方法包括传统人工设计特征表述进行行人属性分类方法，如 iSVM, MRFr2^[62]。以及基于深度学习的方法，如 DeepMAR^[38], MLCNN 和根据行人属性分类场景适应的 iPVANET。在实际运用场景，虽有各种不确定因素会导致行人属性不均衡，但也不能忽视了均衡属性的分类性能。所以本文用完整的 PETA 数据集来验证本文改进方法解决行人属性不均衡问题的有效性，实验结果结果如表 3.3, 表 3.4, 表 3.5 所示。

表 3.3, 表 3.4, 表 3.5 中本文称调整了现有卷积神经网络结构的改进方法为 iMLCNN_CReLU2, 改进属性不均衡损失函数方法为 iMLCNN_Loss, 两个改进方法的结合为 iMLCNN_both。

由表 3.3, 表 3.4, 表 3.5 所示, 本文的改进方法在三个指标上的平均分类性能均优于其他 5 种方法。相比于 MLCNN 方法, 本文的两种改进方法 iMLCNN_CReLU2 和 iMLCNN_Loss 在准确度的平均分类性能分别提高了 0.1% 和 0.95%, 召回率的平均分类性能提高了 1.0% 和 1.93%, AUC 的平均分类性能提高了 0.43% 和 0.53%。本文的两种改进方法是相辅相成的设计, iMLCNN_CReLU2 关注于细节行人属性特征图, 提高模型对小细节属性进行识别, iMLCNN_Loss 关注少类属性在网络中的权重, 使模型能对行人属性敏感。同样相比于 MLCNN, 本文的 MLCNN_both 在准确度上的平均分类性能提高 2.13%, 召回率上提高了 2.38%, AUC 提高了 1.19%。由表 3.3, 表 3.4, 表 3.5 可以看出, 相比于 MLCNN, MRFr2 和 iSVM 等方法, 本文改进的 iMLCNN_CReLU2, iMLCNN_Loss 和 iMLCNN_both 方法在行人属性分类任务

表 3.3 不同模型准确度的对比

Attribute	Precisionrate(%)							
	iSVM[53]	MRFr2[62]	DeepMAR[38]	MLCNN[53]	iPVANET[63]	iMLCNN	CReLU2 iMLCNN	Loss iMLCNN both
accessoryHat	82.31	86.17	89.23	89.32	88.13	90.21	90.33	93.17
accessoryMuffler	88.01	90.45	87.63	91.17	84.35	91.41	91.45	91.31
accessoryNothing	76.83	80.12	80.36	83.31	79.91	84.03	84.25	85.48
carryingBackpack	66.71	67.43	81.07	81.30	80.43	82.34	83.16	83.71
MessengerBag	71.28	75.55	77.36	77.52	77.62	77.89	79.02	79.19
carryingNothing	70.45	71.54	81.21	78.30	80.12	80.21	80.62	81.11
carryOther	64.61	68.11	73.6	76.91	76.83	74.82	75.01	75.11
PlasticBags	74.98	75.53	87.6	88.47	85.41	90.22	91.24	92.28
footwearBlack	62.41	63.6	65.66	71.97	72.01	72.31	73.65	75.17
footwearBrown	70.53	71.22	72.36	90.14	90.26	89.5	89.66	92.13
wearGrey	76.45	77.81	79.6	84.27	70.19	84.28	85.78	86.48
LeatherShoes	78.19	81.71	84.32	83.26	83.41	84.53	85.39	88.11
wearShoes	70.61	73.66	73.62	73.78	74.23	72.03	73.25	73.92
footwearSneakers	67.54	69.32	74.52	78.24	79.11	81.36	83.28	85.99
footwearWhite	60.48	64.68	70.42	75.91	65.17	80.12	83.42	84.42
hairBlack	76.46	77.62	79.44	85.13	80.02	85.07	86.34	89.91
hairBrown	73.14	74.25	80.36	85.58	86.45	85.39	86.58	88.79
hairGrey	68.41	69.69	74.6	91.25	80.13	88.36	88.76	88.80
hairLong	71.52	72.38	84.53	84.12	85.24	84.69	86.38	88.66
hairShort	63.55	65.6	74.91	81.93	79.93	83.26	84.33	86.22
lowerBodyBlack	69.86	70.41	75.63	83.86	83.11	84.02	84.85	85.42
lowerBodyBlue	66.73	68.1	70.36	86.64	80.23	80.15	83.11	83.39
lowerBodyCasual	70.01	71.32	84.91	88.54	87.51	88.43	89.37	90.13
lowerBodyFormal	71.01	71.98	85.22	87.91	83.56	88.39	88.31	88.53
lBGrey	70.13	71.53	74.1	75.12	72.36	76.25	76.21	76.07
Jeans	74.98	76.31	80.02	83.86	84.13	84.72	84.91	85.69
lowerBodyTrouser	74.12	76.57	75.52	77.26	81.66	82.36	83.28	84.11
personalLarger60	87.22	89.02	92.23	93.58	91.22	90.11	92.58	93.07
personalLess30	80.41	83.82	82.91	81.27	82.16	84.05	85.22	85.28
ageLess45	73.65	78.82	79.44	82.50	83.57	83.91	84.05	84.39
personalLess60	73.12	76.41	86.33	89.91	84.33	89.9	89.88	91.42
male	79.73	81.42	84.36	84.34	85.61	86.24	87.34	88.67
upperBodyBlack	65.15	66.21	72.16	85.23	87.12	85.13	86.31	86.66
upperBodyBlue	70.11	71.01	75.42	92.53	80.94	90.18	91.27	93.10
upperBodyBrown	74.58	73.35	77.25	91.25	86.66	90.64	91.54	92.66
upperBodyCasual	70.31	71.32	84.41	87.93	87.15	88.62	89.68	90.36
upperBodyFormal	70.31	70.42	85.12	91.12	89.97	90.18	91.57	93.01
upperBodyGrey	80.13	81.36	83.36	84.39	83.21	83.56	84.83	85.10
jacket	67.17	67.93	79.01	79.17	77.51	79.35	80.09	80.24
LongSleeve	76.5	75.62	77.71	86.42	84.38	85.42	85.65	85.90
upperBodyOther	80.71	80.12	85.63	84.50	82.46	86.02	86.12	86.53
upperBodyRed	79.87	80.32	81.59	93.33	91.62	90.38	89.68	94.71
ShortSleeve	71.31	71.63	80.36	87.09	86.53	83.24	82.19	86.19
upperBodyTshirt	64.33	64.25	83.36	88.59	87.54	87.85	89.18	90.42
upperBodyWhite	68.71	69.55	73.73	87.84	89.55	89.67	89.91	90.93
Average	72.55	74.12	79.61	84.58	82.51	84.68	85.53	86.71

中, 大多数行人属性的分类性能都有所提高, 其中行人属性有着不同程度的不均衡度。对于未能有提高的行人属性, 这些属性本身的可识别区域较大, 仅仅是受行人个人喜好影响变得不均衡。而本文改进方法着重关注于受摄像头客观因素引起的行人属性的不平衡。所以本文改进的方法在处理行人属性不均衡问题中具有一定的适

表 3.4 不同模型召回率上的对比

Attribute	Recall rate(%)FPR=10%							
	iSVM[53]	MRFr2[62]	DeepMAR[38]	MLCNN[53]	iPVANET[63]	iMLCNN	CReLU2 iMLCNN	Loss iMLCNN both
accessoryHat	71.55	72.47	76.28	83.06	85.12	85.25	85.72	86.08
accessoryMuffler	72.43	74.55	77.60	85.42	85.01	85.77	86.81	87.79
accessoryNothing	44.72	46.82	51.88	51.57	51.96	52.03	56.27	58.71
carryingBackpack	45.63	47.31	52.31	53.40	52.66	54.60	56.62	57.22
MessengerBag	47.85	48.91	54.33	54.03	54.50	55.62	87.18	58.77
carryingNothing	50.31	51.36	55.63	54.51	56.61	57.18	57.36	58.11
carryOther	51.33	53.44	53.88	52.87	54.32	54.52	55.22	55.81
PlasticBags	52.05	54.25	62.35	65.23	65.31	66.14	66.39	67.66
footwearBlack	44.18	48.60	50.60	54.42	57.86	57.89	57.91	58.03
footwearBrown	53.48	53.81	60.33	62.71	64.93	63.51	64.25	65.10
wearGrey	45.32	46.66	49.91	50.80	47.53	49.82	50.32	50.89
LeatherShoes	65.47	67.12	68.65	70.43	71.17	70.50	71.25	72.33
wearShoes	40.12	42.11	44.13	44.90	44.69	44.97	45.13	45.66
footwearSneakers	54.78	55.13	61.13	50.04	62.47	62.58	63.28	65.10
footwearWhite	61.20	62.33	59.60	60.27	59.19	63.11	66.72	67.42
hairBlack	68.66	70.63	80.12	81.43	76.72	74.35	75.15	75.16
hairBrown	67.64	70.38	73.61	75.33	72.03	70.36	71.78	71.81
hairGrey	59.28	60.20	63.61	73.19	74.27	74.82	74.92	75.32
hairLong	60.47	65.28	70.61	72.42	73.63	72.34	72.51	72.63
hairShort	62.48	64.12	64.55	66.59	68.78	68.73	68.81	69.21
lowerBodyBlack	48.11	62.02	71.36	68.21	72.03	69.21	59.90	70.01
lowerBodyBlue	53.27	68.60	70.01	74.26	75.26	75.62	76.19	76.39
lowerBodyCasual	46.48	50.18	53.37	54.23	56.11	56.34	57.03	57.24
lowerBodyFormal	62.28	64.23	68.12	70.52	67.71	70.69	70.78	71.91
lBGrey	45.18	51.22	52.28	53.11	55.21	54.39	54.31	55.10
Jeans	50.60	56.28	63.44	65.86	64.77	65.33	66.33	66.43
lowerBodyTrouser	50.62	60.18	55.38	56.19	60.14	61.62	61.78	62.36
personalLarger60	79.71	80.39	81.22	87.71	82.53	85.34	85.54	85.66
personalLess30	50.12	53.66	52.13	53.75	55.64	56.82	56.78	57.31
ageLess45	51.63	56.84	56.84	59.42	57.84	61.36	52.00	63.20
personalLess60	51.74	50.13	55.95	68.22	66.63	69.22	70.05	70.13
male	66.68	65.39	66.72	72.80	72.83	73.10	74.64	75.19
upperBodyBlack	71.20	71.22	73.46	78.58	79.23	78.32	78.51	78.81
upperBodyBlue	71.36	73.61	74.26	76.19	77.43	77.82	78.28	79.42
upperBodyBrown	60.66	65.55	65.88	66.60	68.32	69.35	70.81	71.06
upperBodyCasual	57.76	56.98	57.48	62.14	60.15	63.45	64.52	64.71
upperBodyFormal	59.19	63.85	60.10	70.48	70.51	70.69	70.88	71.58
upperBodyGrey	50.69	52.36	53.36	55.33	55.03	56.98	57.29	61.29
jacket	50.56	51.44	54.11	52.24	56.63	56.48	56.51	56.71
LongSleeve	70.15	71.25	70.55	72.29	72.18	72.39	72.83	73.97
upperBodyOther	68.46	67.53	68.84	69.86	69.63	70.21	71.03	71.25
upperBodyRed	75.60	78.28	76.13	87.77	87.71	84.37	84.81	85.91
ShortSleeve	60.41	61.00	65.22	69.91	68.37	69.87	69.91	70.03
upperBodyTshirt	57.32	58.66	59.45	63.15	64.51	64.62	65.01	65.18
upperBodyWhite	67.22	71.28	70.68	75.25	75.46	74.03	74.11	74.24
Average	57.69	60.39	62.83	65.48	66.01	66.48	67.41	67.86

应性。着重关注于受摄像头客观因素引起的行人属性的不平衡。所以本文改进的方法在处理行人属性不均衡问题中具有一定的适应性。以下图 3.6 是实际分类效果图形抽样展示，图中共选取 6 张不同性别、拍摄角度、光照条件和不同的行人进行展示，为了更好的展示，本文只选取了其中 Top-5 准确度指标进行展示，对于行人身体部位属性一般分为头部、上身、下身以及配饰等部位的明显特征分类，所以选取

表 3.5 不同模型在 AUC 上的对比

Attribute	AUC(%)								
	iSVM[53]	MRFr2[62]	DeepMAR[38]	MLCNN[53]	iPVANET[63]	iMLCNN	CReLU2	iMLCNN	Loss iMLCNN both
accessoryHat	88.62	88.91	91.62	91.15	91.53	91.23	91.79	92.77	
accessoryMuffler	89.22	90.15	91.01	92.42	91.02	92.62	93.32	93.87	
accessoryNothing	77.85	79.62	82.32	84.11	84.69	84.98	85.69	86.15	
carryingBackpack	72.84	80.01	81.05	83.19	82.83	83.57	84.84	84.97	
MessengerBag	73.26	76.24	78.82	81.01	81.24	82.18	83.51	83.59	
carryingNothing	75.62	76.36	80.05	82.15	82.36	82.66	83.33	83.42	
carryOther	70.88	76.58	79.36	80.91	83.64	83.03	83.10	83.23	
PlasticBags	76.25	78.66	82.62	85.01	84.15	85.07	85.68	85.79	
footwearBlack	71.36	73.80	83.10	84.07	84.71	84.75	85.27	85.50	
footwearBrown	73.68	76.28	76.15	83.26	84.86	84.81	84.97	85.19	
wearGrey	78.77	76.22	79.01	80.88	78.62	79.67	80.01	80.10	
LeatherShoes	76.25	78.42	83.25	89.84	89.90	88.02	88.36	88.42	
wearShoes	73.68	74.23	72.00	77.33	77.12	77.61	78.62	78.91	
footwearSneakers	73.14	76.16	80.25	85.19	87.52	87.66	87.91	88.24	
footwearWhite	76.33	78.66	83.11	86.73	84.67	85.28	86.28	87.66	
hairBlack	80.68	81.28	82.50	91.61	88.18	90.16	90.31	90.42	
hairBrown	81.27	83.68	85.36	90.13	89.34	87.96	88.21	88.15	
hairGrey	76.84	79.23	75.22	89.32	89.13	89.42	89.97	90.10	
hairLong	75.38	80.48	81.36	87.55	88.52	89.18	89.63	90.50	
hairShort	78.58	80.65	81.62	86.37	86.73	87.26	88.84	89.32	
lowerBodyBlack	73.68	76.87	79.36	88.66	89.56	89.36	89.15	89.61	
lowerBodyBlue	74.25	76.66	79.05	87.16	87.63	87.87	87.86	88.03	
lowerBodyCasual	74.22	73.85	76.36	86.54	88.15	88.79	88.21	89.17	
lowerBodyFormal	70.31	75.68	77.96	87.93	87.67	87.83	87.19	88.08	
lBGrey	71.85	74.00	72.32	80.77	81.63	82.31	81.36	82.40	
Jeans	78.34	78.09	79.36	86.71	85.95	87.09	87.05	87.19	
lowerBodyTrouser	80.48	81.35	80.31	84.16	85.54	85.48	85.69	86.53	
personalLarger60	84.68	86.22	84.36	90.54	90.49	90.75	91.13	91.13	
personalLess30	83.50	84.35	88.01	88.50	87.69	85.76	86.25	86.91	
ageLess45	76.66	78.85	76.87	84.62	85.73	85.71	85.98	86.24	
personalLess60	73.25	76.89	76.88	85.66	86.12	87.28	88.22	88.66	
male	80.89	83.68	85.36	89.76	89.77	90.25	91.36	92.51	
upperBodyBlack	76.35	78.52	83.12	88.06	89.31	90.31	91.24	91.66	
upperBodyBlue	79.69	80.05	82.25	89.92	90.52	90.82	91.03	91.10	
upperBodyBrown	78.66	81.36	83.36	87.58	88.34	88.92	88.91	89.03	
upperBodyCasual	75.88	76.88	84.36	87.23	89.34	87.39	88.28	88.30	
upperBodyFormal	76.18	77.68	85.16	87.57	87.85	88.68	89.12	89.37	
upperBodyGrey	81.82	82.36	82.36	82.36	83.18	84.24	84.20	84.79	
jacket	76.67	78.00	80.33	81.55	83.26	83.88	83.91	84.33	
LongSleeve	80.62	79.30	81.36	89.91	89.75	89.81	89.80	90.20	
upperBodyOther	81.62	80.40	84.80	87.50	89.03	88.62	88.32	89.05	
upperBodyRed	80.77	83.84	85.62	91.97	90.64	90.62	90.52	91.42	
ShortSleeve	78.84	80.15	81.33	87.12	88.12	84.62	84.69	85.91	
upperBodyTshirt	73.46	75.66	80.25	88.37	88.16	87.08	86.01	87.10	
upperBodyWhite	79.98	81.96	81.36	91.24	92.03	92.22	82.30	92.36	
Average	77.40	79.29	81.37	86.52	86.80	86.95	87.05	87.72	

其中得分最高的五个标签展示足以说明模型的分类效果。通过图中行人分类效果的展示，模型能够对明显的行人属性特征准确识别，包括行人的上衣色彩、款式、头发长短、是否带包、下身色彩和类别等行人属性。同时还可看出，模型能够对行人身上的小目标属性分类，比如模型能够识别四号行人的帽子。当然模型仍有不足之

处，五号行人的属性分类上，`carryOther` 标签分类错误，该行人实际没有携带任何物品，是行人依靠护栏导致模型混淆了目标。故此模型在对行人属性分类任务中能够有较好的分类效果，虽然会受到数据集本身环境的影响，但整体分类性能仍有较高的水平。

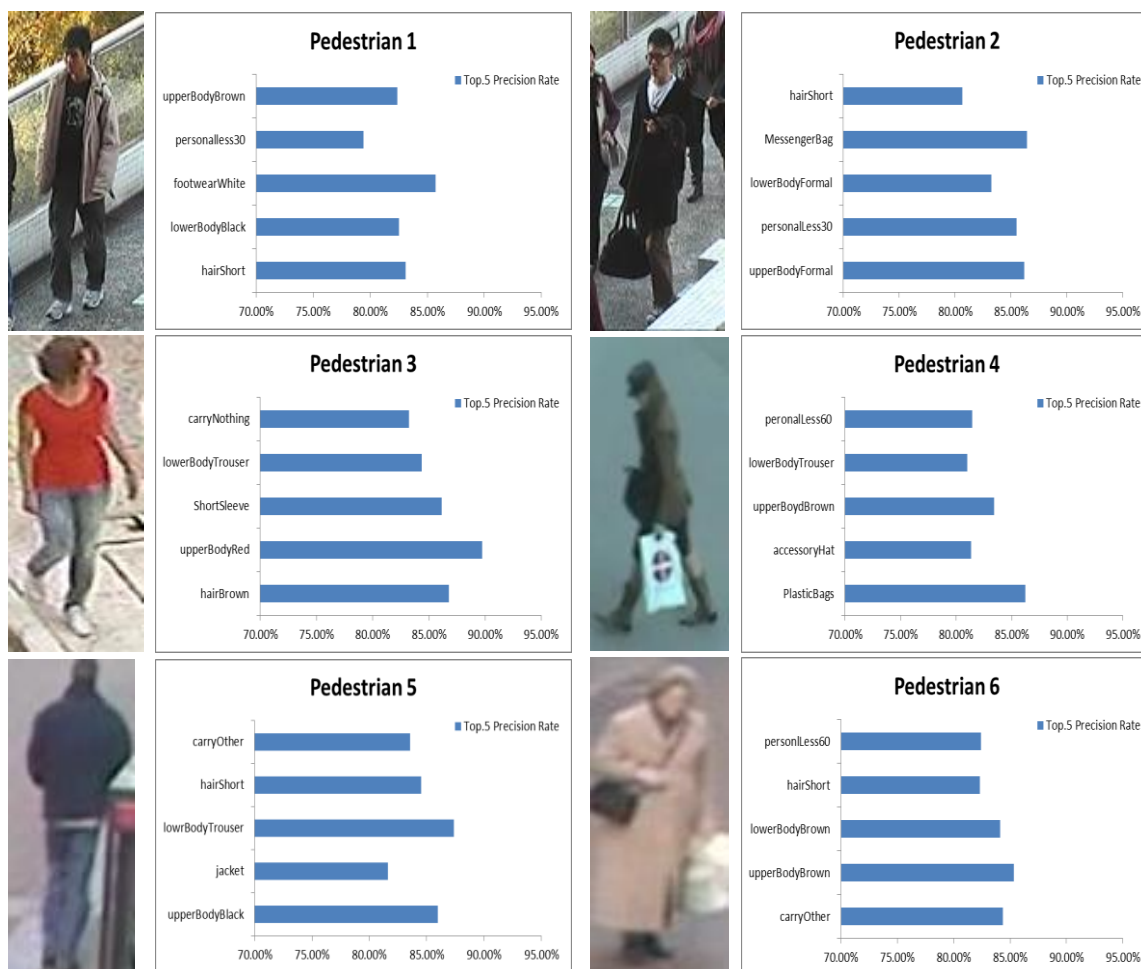


图 3.6 Top-5 准确度行人属性抽选展示

3.4 本章小结

本文主要是解决行人属性分类任务受行人属性不均衡影响导致分类性能不高的问题。首先已有的基于深度学习的行人属性分类方法进行改进，调整网络结构使其能够更加关注细节行人属性特征，提高分类任务的性能；再根据行人属性不均衡性设计属性不均衡损失函数，通过该函数计算得到的误差反向传播到网络中，使得网络对少类属性更加敏感。通过实验表明，本文提出的改进方法在处理行人属性分类问题具有很好的有效性。

第4章 端到端行人重识别模型

本章主要介绍提出的一种端到端行人重识别模型,用以处理行人重识别模型受行人姿态和复杂背景影响的问题。首先,使用本文提出的属性敏感卷积神经网络的基特征提取层去构建行人全局属性特征。由于属性敏感卷积神经网络的特征提取层采用了多尺度特征融合的方法,所以该网络模型可以构建行人身体部位上小目标感知能力强的属性特征图,因此可以解决在复杂场景中行人的特征属性难以学习的问题。此外,相对于传统的行人身体部位裁剪方式,本文提出使用一种基于学习的行人身体部位自动定位裁剪的方法,该方法是一种具有自主学习能力的图像分割网络。本文将其添加到端到端行人重识别模型以构建行人局部属性特征,并随着整体模型的迭代更新训练可裁剪区域,主要解决传统固定区域裁剪方法丢失行人身体部位信息的问题。最后,将行人全身属性特征与局部身体属性特征一起输入到端到端行人重识别模型进行学习,增强模型对行人的识别能力。

4.1 端到端模型

端到端模型可以被视为一种输入图像数据到输出结果的映射关系:

$$f: \mathbb{R}^{i \times j} \rightarrow \mathbb{R}^k \quad (4.1)$$

一个好的关系映射应该具有以下两个特征:

- a) **一致性:** 在行人重识别运用场景中,映射空间中的距离评估指标反映行人相似度,即不同摄像机拍摄的同一个行人的映射空间距离比较近,不同行人的映射空间距离比较远。
- b) **抽象性:** 行人属性特征被封装到卷积神经网络黑盒中,本文的卷积神经网络能够自动提取出行人的全身属性和局部部位属性特征图,最后融合两种有效的特征图用以行人在不同拍摄镜头中的识别。实现输入一张行人图像后不做任何人为操作即可得到相同行人图像输出的效果。

此外,本文还希望设计的模型能够尽可能的自动化并输出想要的结果,所以需要尽可能的减少人工设计特征的过程。最理想的方法就是在一个统一的模型框架中,将卷积神经网络模型看成是一个映射函数,函数经过反复迭代训练得到,得

到只需要输入行人图像资料就可以匹配出相同的行人的踪影。这就是端到端学习的方法：

$$\beta_{func} = \arg \min_{\beta} L(f_{\beta}, I_x) \quad (4.2)$$

其中， f_{β} 是具有能够表达复杂的系统框架结构的映射，本章选用融合了多尺度和行人部位自动裁剪方法的卷积神经网络模型来表示输入图像与输出图像的映射关系。

在机器视觉任务中，比如目标识别和目标检测，视觉语义是个重要的组成成分，视觉语义能够帮助提高模型对目标的识别和检测能力。经典卷积神经网络模型通过对特征图进行层次卷积核池化操作，获取到行人图像中的有效信息。对于行人重识别任务而言，最重要的行人视觉线索是行人视觉属性信息，如衣服颜色和款式。这些行人视觉属性信息的特点是容易因多种因素影响而改变，所以传统经典卷积神经网络对此类行人属性特征进行学习很容易丢失掉重要的信息。为了更好的学习行人多样的视觉属性信息，本文设计了端到端行人重识别模型：




图 4.1 端到端行人重识别模型

本文端到端行人重识别模型如图 4.1 所示，每层的卷积核池化核都根据实际输入图像的尺寸进行过调整，有利于模型在不丢失细节信息的同时学习到更细节的行人属性信息。整个模型可以分为两个主要的部分，第一部分是属性敏感卷积神

神经网络(iMLCNN)，这个部分的结构特点已在第三章详尽的介绍，这里需要用该网络的前项特征提取层帮助构建行人全身属性特征图，优势在于该模块采用了多尺度特征融合的方法，使得获取到的行人全身特征图能够尽可能少的丢失细节特征。第二部分是行人身体部位自适应裁剪模块(iSTN)，这里需要给 iSTN 模块预先设定一个学习初始参数，之后就随着整个端到端行人重识别模块学习更新其参数，不需要再进行额外人为操作。该模块预训练后能够自适应裁剪出行人三个主要部位：头部、上身和下身，三个主要行人身体部位，也是行人属性信息最集中的区域，再分别对每个行人身体部位构建特征，最后将三个部分的特征图进行融合得到一个对行人身体局部特征信息表达能力强的局部特征图。

本文端到端行人重识别框架实现了用户在训练阶段只需要设定 iSTN 网络模块的初始参数，随后就不需要任何过多的人为操作。两部分网络模块在训练阶段和测试阶段可以自动地构建表达能力强的行人属性细节特征图，最后融合两者特征图用以行人重识别。实现用户仅输入一张行人图像，经过网络模型的映射转换，模型输出与输入图像最相似的行人图像。

4.2 基于 STN 网络的行人裁剪模型

由于行人动作姿态变化和检测器自身缺陷，导致行人不能完全处于图像样本中心。比如样本图像中的行人可能存在一些复杂的背景信息或者缺少部分身体信息。在这总情况下，传统预设定裁剪区域的裁剪方式就可能导致错误，所以预设定裁剪区域的方法的鲁棒性较低。为了解决预设定区域带来的裁剪效果不佳的问题，本章将主要介绍本文提出的一种基于 STN 网络的行人裁剪模型。不同于传统的预设定区域裁剪方法，本文提出的方法能够通过学习参数自适应地对行人身体部位进行裁剪。STN 网络最早提出是处理图像转换问题，但针对本文的行人身体部位裁剪，本文在可学习转换参数上添加了三个新的限制条件。通过对新的限制条件的控制就可以实现模型自适应学习裁剪区域，从而自适应地裁剪出合理且有效行人身体部位信息。STN 创造性地在 CNN 结构中装入了一个可学习的仿射变换，目的是增加 CNN 的旋转、平移、缩放、剪裁性。可以减少 CNN 的训练数据量，以及减少做 data argument，让 CNN 自己学会数据的形状变换。

4.2.1 有效身体部位裁剪规则

在行人重识别任务中，行人身体部位蕴藏着非常重要的属性信息。目前，许多工作已经使用预设定裁剪区域方法对行人身体部位进行裁剪。但是由于行人动作姿态变化和检测器自身缺陷，预设定裁剪方法裁剪出来的行人身体部位区域不是最优的像素区域。如图 4.2 所示：



图 4.2 预设定裁剪方法

为了解决预设定区域裁剪方法不能很好进行行人身体部位裁剪的问题，本文整合了 STN 网络作为本文身体部位定位网络。原始的 STN 网络是被提出用来学习图像转换的参数。它具备两个主要的优势：(1) STN 网络结构可以很轻松的整合到目前主流深度学习框架中，(2) STN 网络可以通过学习对指定区域图像的转换、尺度变换、裁剪或者压缩，并且不需要人为提供标注区域。这些特点使得 STN 网络非常适合运用于行人身体部位裁剪问题中。

STN 网络包括两个主要部分，第一部分空间变换神经网络是去学习图像的转换参数，第二部分网格生成器是使用图像插值函数对输入的行人图像进行采样。在行人重识别场景，对 STN 网络改进使用双线性插值核对输入行人图像进行采样。

本文采用四个图像转换参数： $\partial = [s_x, t_x, s_y, y_y]$ ，其中 s_x 和 s_y 是水平和垂直尺度转换参数， t_x 和 y_y 是水平和垂直变换参数。输入行人图像的高度和宽度被

规约到 $[-1,1]$ 。这里仅仅只要学习水平和垂直方向的尺度和变换参数，因为只需要这两个典型的参数标量就足够用于裁剪行人身体部位。将变换操作应用于生成行人身体部位输出的逆过程：

$$\begin{pmatrix} x_i^{in} \\ y_i^{in} \end{pmatrix} = \begin{bmatrix} s_x & 0 & t_x \\ 0 & s_y & t_y \end{bmatrix} \begin{pmatrix} x_i^{out} \\ y_i^{out} \\ 1 \end{pmatrix} \quad (4.3)$$

其中， x_i^{in} 和 y_i^{in} 是输入行人图像的坐标， x_i^{out} 和 y_i^{out} 是输出身体部位坐标， i 是输出身体部位坐标的像素索引。

本文方法中要求 STN 网络只需要学习行人身体三个部位的转换参数，分别为头部、上身和下身。每一个部位都是 STN 网络从行人原始图像中学习得来。使用空间定位网络去学习定位参数 θ ，确定需要裁剪区域。再使用网格生成器去裁剪已经使用转换参数 θ 学习到的行人身体部位，在本文裁剪出的身体部位尺寸为 75×64 。

对于行人身体部位定位网络，很难做到对每个部位学习一组参数。主要存在着三个主要的问题。首先，STN 网络计算出来的身体部位区域很容易向中心聚集，导致身体部位冗余。其次，尺度参数在学习过程中很容易变为负数，导致行人身体部位翻转。最后，裁剪身体部位时可能会逾越出边界，引起网络学习无法收敛。为了解决这些问题，本文提出了三个先验条件去控制转换变量的界限。

第一个条件是为了更好的定位身体部位，本文期望预测出的身体部位区域尽可能的靠近先验中心点。这个期望规则条件表述如下：

$$L_o = \frac{1}{2} \max \left\{ 0, (t_x - c_x)^2 + (t_y - c_y)^2 - \alpha \right\} \quad (4.4)$$

其中， c_x 和 c_y 是每个身体部位的先验中心。 α 是控制预测中心与先验中心变换的阈值。在本文实验中，针对每一个身体部位 $(c_x - c_y)$ 设置为 $(0, 0.6)$ 、 $(0, 0)$ 和 $(0, -0.6)$ ，阈值 α 设置为 0.5 最佳。

第二个是限制预测区域尺寸的取值范围。为保证预测的行人身体部位区域尺寸更加合理，本文将其取值限制为正值。具体表述如下：

$$L_p = \max \{0, \delta - s_x\} + \max \{0, \delta - s_y\} \quad (4.5)$$

其中， δ 是阈值参数，实验中设置为 0.1。

第三个是保证行人身体部位定位网络预测出的身体部位区域在图像内,具体描述如下:

$$L_{in} = \frac{1}{2} \max \left\{ 0, \|s_x \pm t_x\|^2 - \eta \right\} + \frac{1}{2} \max \left\{ 0, \|s_y \pm t_y\|^2 - \eta \right\} \quad (4.6)$$

其中, η 是边界参数, 本文实验中设置 1.0, 保证裁剪区域落在行人图像内部。

4.2.2 身体部位特征提取和融合

特征提取是从原始图像中抽取具有判别性质的信息, 即在相同模式中抽取得到的信息尽可能的相似, 对于不同模式中抽取得到的信息存在较大差异。这样从图片中有针对性的提取属性特征能够帮助模型学习各类之间的差异。特征融合是将多种行人属性特征按照一定的逻辑进行组合, 其核心是利用不同行人属性特征之间的差异性组合得到鲁棒性更强的属性特征, 从而提高模型学习准确度。常见的特征融合方法有特征选择和特征组合两种方式, 特征选择方法会先构建出最初的属性特征集, 再利用常用的特征选择方法 (如, LDA) 选择最具有表征能力的特征集。特征组合的思想是为不同特征分配权重, 将已有的特征集组合为一个全新的特征向量。特征组合常见策略是线性组合和并列组合两种方式, 线性组合是按照线性组合的思想为各个特征分配权重; 并列组合方式是将多个属性特征按层堆叠, 即保持每个属性特征的维度不变组合为新的特征向量。假设 α 和 β 分别行人属性特征向量, 而 δ 是融合结果, 那么特征线性组合方式如式 4.7 所示, 而特征并列组合方式如式 4.8 所示:

$$\delta = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \quad (4.7)$$

$$\delta = \alpha + i \cdot \beta \quad (4.8)$$

假设属性特征 α 是 γ 维, 属性特征 β 是 r 维, 那么线性组合属性特征 δ 的维数为 $(\gamma+r)$ 维; 而并列组合属性特征 δ 的维数依然是 γ 维。虽说并列组合属性特征的维度保持不变, 但是其属性特征的层数加深, 这样组合的行人属性特征将具备更好的区分性, 但会丢失掉部分细节特征, 降低模型对细节属性的学习。

线性组合的方式会将特征集的所有属性特征融合, 导致组合特征向量的维度增高, 这影响卷积神经网络的学习速度。这两种方法属于传统模式识别中常见的特征构建方法, 其特点是需要研究人员参与精心设计出具有判别性的特征。这些特

征提取方法仍然存在一些缺陷,比如经过人为参与设计的特征往往要求很高的专家经验,专家经验决定了模式识别最终的效果。虽然具有专家经验的人设计的特征在特定场景中能够取得较好的成绩,但是更换场景后专家经验特征就无法适应。针对上述问题,可以采用基于卷积神经网络的特征提取方法,即不需要具有专家经验的人参与也可以设计出鲁棒性强的行人属性特征。输入行人原始图像后卷积神经网络的特征提取方法便可以提取出不同层次的特征,包括底层、中层和高层其他特征。

为提取行人全身属性特征和局部属性特征,利用本文属性敏感卷积神经网络(iMLCNN)分别设计出行人全身属性特征提取网络和行人局部部位属性特征提取网络,再将这两个特征提取网络嵌入到端到端行人重识别框架中。本文首先使用iMLCNN网络去提取行人全局属性特征图,将得到的底层、中层和高层属性特征图进行融合得到一个256维的行人全局属性特征图(图4.1, FC_body)。对于局部身体部位属性特征提取,首先,本文利用本章使用的STN网络对行人身体部位进行裁剪。每个部位在经过iMLCNN网络进行特征抽取,获得每一个部位的特征图,然后再将三个部位特征图采用线性插值的方式得到256维的行人局部身体部位特征(图4.1, FC_part*)。这两个特征提取网络中的FC层采用了Dropout方法去防止过拟合。最后,将两个网络提取的行人属性特征进行融合得到一个512维的行人属性特征图。

4.3 实验结果与分析

本节将主要验证本文提出端到端行人重识别方法的有效性,首先介绍实验数据集,其次对比现有的方法与本文提出的端到端模型的性能。

4.3.1 实验数据集及评价指标

本文选用目前最大的行人重识别数据集进行实验,并通过实验说明本文方法的有效性,数据集包括:MarKet1501, CUHK03 和 MARS。为了避免发生过拟合和学习不充分情况,模型训练阶段不直接采用小数据集(如 VIPeR)去训练模型。而是采用从Market1501数据集上预训练好模型,再微调到数据集VIPeR上使用,并且随机交叉行人重识别数据集样本构建一个验证集。

Market1501: 该数据集在清华大学校园中采集, 图像来自 6 个不同的摄像头, 其中有一个摄像头为低像素。作者公开了该数据集所有训练集和测试集, 训练集包含 12936 张图像, 测试集包含 19732 张图像。图像由行人检测器自动检测并切割, 这种方式存在一些检测误差(接近实际使用情况)。训练数据中一共有 751 人, 测试集中有 750 人。所以在训练集中, 平均每类(每个人)有 17.2 张训练数据。

CUHK03: 该数据集是在校园中采集, 图像来自 6 个不同的智能监控视频, 其中该数据集包含了 1360 个行人。每一个行人身份信息是由两个不同不相邻的摄像头采集。共有 13164 张行人图像并且每个行人在每个视角中平均有 4.8 张行人图像。该数据集提供两种行人标注模式, 分别是人为手工标注区域和使用行人检测器进行的标记区域。本文将两种标注方式融合在一起, 共同训练本文模型。本文选用了 1260 个行人进行训练, 余下 100 人用以测试。

MARS: 该数据集是最大的连续行人重识别数据集, 图像来自于多个摄像头采集, 其中包含了 1256 位行人。这些行人包含 1191003 个候选区域和 20478 个踪迹。本文使用 625 个行人做训练, 余下 631 个行人用以测试。

公开数据集相对应有其标准的评价指标, 在本文中选用 mAP 和 $Rank-k$ 来评价模型的性能。 $Rank-k$ 是表示图像匹配结果中识别最准确的 k 个。此外, 平均精度均值 (mAP) 是评价某个召回率下的平均精度, 刻画模型预测的稳定性能。首先需要计算平均精度, 对于一组样本集求取其精度和召回率, 再设定一组阈值召回率向量, 将实际召回率高于阈值召回率的一组样本集分为一组并求取平均精度。其 mAP 和 $Rank-k$ 公式表达如下:

$$mAP(Q) = \frac{1}{|Q|} \sum_{j=1}^{|Q|} \frac{1}{m_j} \sum_{k=1}^{m_j} precision(R_{jk}) \quad (4.9)$$

$$Rank-k = \max_k \left(sort(precision_i) \right) \quad (4.10)$$

式 4.9 中, Q 为召回率大于阈值的所有样本集合, m 为样本集合 Q 的样本个数, R_{jk} 为集合 Q 中样本。由式 4.9 可以看出, 平均精度均值 mAP 评价指标刻画的是某个召回率下准确度的均值, 可以有效的防止模型因样本数量的增加召回率持续升高而精确度减少的影响。实验证明该评价指标具有很好的解释性和稳定性。式 4.10 是计算模型预测结果最靠前的 k 个结果, 通过该指标可以从图片的多个属性综合评价模型的分类性能。

4.3.2 主流行人重识别方法对比

表 4.1 Market1501 上实验结果

Query	Single query		Multiple query	
Evaluation metrics	R1	mAP	R1	mAP
BOW ^[71]	35.18	13.89	42.64	19.47
BOW+HS ^[71]	-	-	47.24	21.88
WARCA ^[72]	44.16	-	-	-
PersonNet ^[73]	38.24	27.55	-	-
S-LSTM ^[74]	-	-	61.6	35.3
SCSP ^[58]	55.7	28.67	-	-
DNS ^[75]	54.47	29.84	73.56	46.03
Gate-SCNN ^[76]	64.78	41.85	77.04	54.45
Our-body	68.25	42.61	78.62	56.90
Our-part	67.12	42.33	79.25	56.53
Our-fusion	69.53	43.24	81.79	60.64

本文实验分别在 Market1501、CUHK03 和 MARS 上进行对比实验：

Market1501: 在该数据集上有许多的主流行人重识别方法可以对比，包括词包 (Bag of Words, BOW)，加权近似秩分量分析 (Weighted Approximate Rank Component Analysis, WARCA)，零空间判别 (Discriminative Null Space, DNS)，多项式特征映射的空间约束相似函数 (Spatially Constrained Similarity function on Polynomial feature map, SCSP)。另外基于深度学习方法，如 PersonNet, Siamese Long Short-Term Memory (S-LSTM)，Gated Siamese Convolutional Neural Network (Gate-SCNN)。具体实验结果展示如表 4.1 所示。

相比于现有的主流全身卷积神经网络，如 Gate-SCNN，这些网络结构能够很好的获取到行人属性特征。在 Rank-1 识别率指标上，本文方法相较于目前最优的模型 (Gate-SCNN) 提高了 4.75%。另外，与自己的全局属性特征相比，本文局部属性特征能够帮助模型提高 0.8%。能够提升的主要原因是使用目标检测模型去采集训练数据集，这样获得的数据集包含很多复杂的背景信息，所以基于身体部位局部信息的方法能够很好的过滤掉背景的影响。

表 4.2 检测模型标注 CUHK03 实验对比

Dataset	CUHK03 detected			
Rank	1	5	10	20
FPNN ^[39]	18.19	50.50	63.32	79.51
IDLA ^[77]	43.14	73.31	83.57	91.25
XQDA ^[62]	43.45	79.50	87.78	92.15
MLAPG ^[78]	52.35	81.55	91.87	97.01
SI-CI ^[79]	54.36	85.23	91.24	95.25
DNS ^[75]	55.63	85.13	94.80	94.12
S-LSTM ^[74]	54.25	81.31	87.31	-
Gate-SCNN ^[76]	55.78	81.89	86.23	-
EDM ^[80]	54.11	83.15	92.89	96.47
Our-part	55.74	83.53	91.97	96.21
Our-full	54.95	83.82	91.58	97.56
Our-fusion	56.99	84.14	92.36	97.83

本文的全局身体属性特征和局部身体属性特征表达是相辅相成的设计，比如，全局身体属性特征表达更多的是关心行人全局的属性信息。局部身体属性特征表达更加关心行人身体部位的属性信息。如头，上身和下身。如表 4.1 所示，相比于全局或局部行人属性特征，两种网络模型提取的行人属性特征融合在 Rank-1 识别率上提升了 4.75%。另外，全局和局部行人属性特征融合模型在 mAP 指标上相比于 Gate-SCNN 网络模型提升约 1.39%。

CUHK03: 在这个数据集上，本文提出的方法与目前主流存在方法进行对比。包括成对滤波神经网络 (FPNN)，增强深度学习框架 (IDLA)，交叉视角二次判别分析 (XQDA)，受限非对称矩阵学习 (MLAPG)，特定样本 SVM (SS)，单一图像与多种图像表达 (SI-CI)，深度度量集成 (EDM)，受区域引导的 Dropout (DGD)，DNS，S-LSTM 和 Gate-SCNN。在这个数据集上，本文分别在用行人检测模型标注的和人为标注的数据集上设计实验。结果如表 4.2 和表 4.3 所示。

相比于度量学习方法，本文提出的全局属性特征与局部属性特征融合的方法在检测模型标注数据上 Rank-1 提升了 0.21%，在人工标注数据上 Rank-1 提升了 0.59%。

表 4.3 人工标注 CUHK03 实验对比

Dataset	CUHK03 labeled			
Rank	1	5	10	20
FPNN ^[39]	21.65	52.43	67.53	81.10
IDLA ^[77]	53.94	85.57	94.25	97.20
XQDA ^[59]	53.43	83.13	93.07	95.35
MLAPG ^[78]	56.87	86.19	94.71	98.43
DGD ^[30]	63.02	90.47	96.23	96.82
DNS ^[75]	63.13	90.05	97.10	98.10
EDM ^[80]	63.08	89.90	96.24	99.84
Our-part	61.41	91.68	96.68	99.02
Our-full	61.88	91.66	96.46	99.18
Our-fusion	63.67	92.13	97.54	99.25

相比于相近工作多类别行人重识别网络 DGD, 本文提出的融合方法在人工标注数据上的 Rank-1 识别率提升了 0.65%。但是本文模型仅在人工标注数据上进行训练, 而 DGD 是使用了两种标注数据集来训练, 因此本文模型能具有有效性。

MARS: 这个数据集是最大的连续行人重识别数据集。在这个数据集上, 本文对比了比较经典的方法, 包括保持简单有效原则下的相似匹配学习算法(XQDA)和 CaffeNet。与之前的实验方法一致, 本文在 MARS 数据集上用单例查询和多例

表 4.4 MARS 上单例查询实验结果

Query	Single query			
Evaluation metrics	1	5	20	mAP
CNN+Eulidean ^[81]	57.73	74.12	86.70	41.37
CNN+KISSME ^[81]	66.13	83.21	87.91	44.66
CNN+XQDA ^[81]	64.87	83.52	88.89	46.60
Our-fusion+Eulidean	67.62	85.29	92.42	52.13
Our-fusion+KISSME	68.89	86.15	92.17	53.30
Our-part+XQDA	66.62	82.07	90.76	53.74
Our-full+XQDA	68.23	83.99	92.17	54.82
Our-fusion+XQDA	71.77	86.57	93.08	56.06

表 4.5 MARS 多例查询实验结果

Query	Multiple query			
Evaluation metrics	1	5	20	mAP
CNN+KISSME+MQ ^[81]	67.47	82.63	87.34	50.31
Our-fusion+Eulidean+MQ	78.28	91.97	95.77	63.43
Our-fusion+KISSME+MQ	79.52	91.23	96.23	64.52
Our-fusion+XQDA+MQ	83.03	93.69	97.63	66.43

查询的方式去评估模型的性能，实验结果如表 4.4 和表 4.5 所示。

CaffeNet 是一种与本文类似的多累表行人重识别网络，本文用全局属性特征模型与之相比较，在 Rank-1 识别率是行提升了 2.93%，mAP 指标上提高了 4.22%。值得注意的是，本文网络模型没有经过任何额外数据的预训练。通常，深度学习网络使用额外数据进行预训练能够获得更好的性能。本文全局属性特征和局部属性特征融合模型能够在 Rank-1 识别率上提升 6.47%，mAP 指标上提升 8.45%。这些结构说明了本文模型在处理行人重识别任务中更具有效性。

4.3.3 基于 STN 身体部位裁剪有效性

本节将使用基于 STN 网络学习裁剪与预设网格区域裁剪进行对比。首先将行人图像使用网格区域进行裁剪，裁剪为三个相互有一定重复的身体部位。将裁剪出的三个身体部位替换到本文 iSTN 网络中进行行人重识别任务实验。实验如表 4.6 所示，与预设区域裁剪方式对比，本文使用的 iSTN 网络结构学习裁剪区域在单例查询中 Rank-1 指标提高了 2.47%，mAP 指标上提升了 1.73%。在多例查询中 Rank-1 指标提高了 0.80%，mAP 指标提升了 1.77%。 这些结果验证了本文方法在处理行人重识别任务提出的可学习区域裁剪方法是有效的。

表 4.6 两种行人身体部位裁剪方法结果对比

Quer	Single		Multiple query	
Evaluation metrics	Rank-1	mAP	Rank-1	mAP
Rigid parts	73.78	51.60	83.32	61.13
iSTN	76.25	53.33	84.12	62.90

4.4 本章小结

本章主要介绍了一种端到端行人重识别模型,该模型结合了上一章属性敏感卷积神经网络(iMLCNN)的优点,利用 iMLCNN 模型先对原始图像进行特征提取。模型主要构建了两种不同的网络去提取全局属性和局部属性特征图,首先利用多尺度网络结构 iMLCNN 得到行人全局属性特征图,其次使用基于 STN 网络结构对行人身体部位进行裁剪,裁剪后的每个部位用 iMLCNN 结构提取其局部属性特征图。最后将两个相辅相成的全局和局部特征图进行融合。整个训练过程不需要过多的人为干预,所以称之为端到端模型。基于 STN 裁剪的网络结构,本文根据实际行人图像资料尺寸大小等实际情况,为了更好获得裁剪区域,使身体部位完整地切割出来,本文设计了三个约束条件,网络通过训练阶段学习约束参数,学习到的合理参数能够保证模型能够对行人身体部位进行合理的切割。实验这表明本文方法在处理行人重识别问题中更具有有效性。

第 5 章 工作总结与展望

本章主要总结全文的研究工作，包括研究的主要创新点，实验论证对比得出的结论。然后指出目前工作不够完善的部分以及后续仍要解决的问题和重点。

5.1 工作总结

本文主要的工作解决行人重识别任务遇到的挑战。行人重识别任务中，由于摄像头拍摄角度、距离和光照等因素，这些不确定因素可能导致采集到的行人图像变得模糊和丢失重要的细节特征。面对这样的问题，本文提出了基于卷积神经网络的行人重识别研究，首先，本文提出了基于属性敏感卷积神经网络的行人属性分类网络结构，这个网络结构能够很好的解决行人因为拍摄角度等不确定因素的影响变得难以识别的问题，提高了行人属性的识别率。其次，本文结合了基于属性敏感神经网络结构的行人属性分类方法，进一步运用到行人重识别任务中，用以解决行人重识别面临的难题，行人重识别除了也会面临如拍摄角度等不确定因素影响，还会受到行人身体部位裁剪好坏影响。所以本文提出使用基于 STN 网络结构的行人身体部位裁剪方式去分割出行人局部身体部位，再对每个部位进行卷积提取特征图。最后再与属性敏感卷积神经网络提取的全局身体属性特征图进行融合，得到一个表达能力更强的特征图。用以行人重识别任务。主要研究是基于行人重识别的图像模糊、丢失信息、属性不平衡问题进行研究。本文主要工作总结如下：

1. 在处理行人属性分类问题中，本文主要针对多属性不平衡问题提出了一种改进的卷积神经网络，与现有的多属性卷积神经网络不同。本文先对卷积神经网络的结构调整，加深网络深度和宽度，增强网络模型对细节目标特征的学习。此外，本文还提出了多属性类别不平衡权重自适应方法，该方法通过误差反向传播的方法修改网络中的权值，使其能够对少类属性样本更加敏感。通过实验表明，新的网络结构更能够学习到行人的细节特征，加入多属性类别不平衡权重自适应方法能够对少类属性样本更加的敏感。

2. 在处理行人重识别任务中，本文首先结合了属性敏感卷积神经网络的特征提取模块，获取到行人全身属性特征图；其次根据 STN 网络的裁剪问题，本文提出了三个限制条件，使得网络能够裁剪出更合理的行人身体部位。行人身体部位分为

三个主要区域，每个区域分别提取特征图。最后，融合行人全身属性特征图和行人局部身体部位特征图，得到具备很强表征能力的行人属性特征图。本文在多个数据集上测试对比了本文方法的有效性。此外还验证了本文基于 STN 行人身体部位裁剪方法的有效性。

5.2 工作展望

本文主要的工作解决行人重识别任务遇到的挑战。行人重识别任务中，由于摄像头拍摄角度、距离和光照等因素，这些不确定因素可能导致采集到的行人图像变得模糊和丢失重要的细节特征。在研究生阶段的行人属性分类研究上进一步结合卷积神经网络提出，基于卷积神经网络的行人重识别方法，本文方法利用卷积神经网络模型提高了行人属性分类的性能，同时结合 STN 网络设计了一个端到端的行人重识别模型，该模型充分利用了 STN 网络的自适应分割行人关键部位的性质，提高了识别准确率。本文行人属性分类方法着重强调对小目标的识别和分类，但对于图形中重叠交叉的目标分类仍存在不足；另外模型的运算效率仍有待提高，模型训练大约需要三天时间，每秒识别大约 8 帧图像；最后，端到端行人重识别模型中的 STN 网络仍具有进一步研究的价值，建议可以从模型的学习效率、模型的结构、以及分割区域设定的泛化能力角度出发去进一步研究。

致谢

论文书写工作接近尾声，在此我向所有曾经帮助我，关心我的老师们、同学们和朋友们表示由衷的感谢。

首先感谢重庆邮电大学计算机学院，自报考其研究生考试时，就开始为我们提供许多的咨询服务，方便大家顺利完成考试。进入到校园，学院办公室的曾书记和各位老师对每一位学生的成长花费了大量的精力。学业和实践中遇到任何困难，他们会倾听你的难处并且鼓励走出困难迎接新的生活。学院良好的管理风范，给我们提供了绝佳的学习环境，在这个大环境中，同学们都相互帮助爱护，老师们互相协作给我们提供了更广阔的平台。让我们能够把工作重心专注于学术研究上。

其次，向我的导师王进老师表示衷心的感谢，起初成功被录用为重庆邮电大学研究生后，王老师就花心思为我们设计入学适应训练，让我们提前了解自己的研究领域，以及领域内的特点研究有哪些！这个阶段必定会遇到许许多多的困难，对于刚入学的新生实在再熟悉不过了。但是有问题找王老师，必定会耐心的给你解答，并且认真引导你让你明白其背后的原理。在我遇到困难时，王老师也是尽可能去帮助我，他不仅传道授业解惑，同时还是人生的一盏明灯。王老师学术态度严谨，做事果断干练，这些优良作风时刻影响着我。让我一改本科时的懒散、不积极的工作态度。庆幸能够有一位这样负责开明的恩师，在求学路上给予我知道，再次感谢。

再次，向同寝三年的室友们道一声感谢，由于实验室工作繁多，可能三年时间彼此并没有过长的相处时间，但是彼此之间心中都怀着深厚的友谊。有空大家一起开心玩耍，释放压力，一起郊游，散心解乏。学术上有不理解，不明白的地方相互请教，相互学习，相互努力，可以说你们不失为一群良师益友。

最后感谢我的父母，父母的辛勤工作换来了我良好的学习环境，他们很多时候给与的是鼓励与支持，每当我抉择人生道路的时候，他们都会帮我分析利弊，并且尊重我的选择，只要是我自己喜欢的事，他们都会支持。不论我走多远的路，你们都待我如初，孩子般呵护。这样有温度的父母才是我心灵的港湾。

每每遇到困难处，就会想起一个笑容。你微笑，笑时犹带岭梅香，试问岭南应不好？却道，此心安处是吾乡。

攻读硕士学位期间从事的科研工作及取得的成果

发表及完成论文：

- [1] 王进, **黄超**, 冉仟元等, 基于AdaBoost集成学习的演化硬件DNA微阵列数据分类[J], 江苏大学学报, 2017,38(1): 86-92
- [2] 王进, **黄超**, 王科等, 基于属性敏感卷积神经网络的行人属性分类[J], 江苏大学学报(自然科学学报), 2017

发明专利：

- [1] 王进, **黄超**, 莫倩雯: 一种基于 Spark 的高维稀疏文本数据聚类方法 (受理: CN201610988558.4)

参考文献

- [1] Tang N C, Lin Yenyu, Weng Mingfang, et al, Cross-camera knowledge transfer for multiview people counting[J], IEEE Trans. Image Process, 2015,24(1): 80-93.
- [2] Gong Shaogang, Cristani M, Loy Chenchang, et al. Person re-identification[M]// Visual Analysis of Behaviour. Springer London, 2011: 301-313.
- [3] Hartley R, Zisserman A. Multiple view geometry in computer vision[M]. Cambridge university press, 2003:128-135.
- [4] Gadeski E, Fard H O, Le Borgne H. GPU deformable part model for object recognition[J]. Journal of Real-Time Image Processing, 2014,13(1):1-13.
- [5] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C]//Computer Vision and Pattern Recognition, Bostons: IEEE, 2015: 3908-3916.
- [6] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [7] Kim P. Convolutional neural network[M]//MATLAB Deep Learning. Apress, Berkeley, CA, 2017: 121-147.
- [8] Chen Xueyun, Xiang Shiming, Liu Chenglin, et al. Vehicle detection in satellite images by hybrid deep convolutional neural networks[J]. IEEE Geoscience & Remote Sensing Letters, 2014, 11(10):1797-1801.
- [9] Benenson R, Omran M, Hosang J, et al. Ten years of pedestrian detection, what have we learned?[J]. 2014, 8926:613-627.
- [10] Dieckmann U, Plankensteiner P, Wagner T. SESAM: A biometric person identification system using sensor fusion[J]. Pattern recognition letters, 1997, 18(9): 827-833.
- [11] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]//Computer Vision and Pattern Recognition, 2006 IEEE Computer Society Conference on, New York: IEEE, 2006, 2: 1528-1535.
- [12] Monroe M E, Tolić N, Jaitly N, et al. VIPER: an advanced software package to support high-throughput LC-MS peptide identification[J]. Bioinformatics, 2007, 23(15): 2021-2023.
- [13] 杜宇宁, 艾海舟. 基于统计推断的行人再识别算法[J]. 电子与信息学报, 2014, 36(7): 1612-1618.

- [14] Bazzani L, Cristani M, Perina A, et al. Multiple-shot person re-identification by chromatic and epitomic analyses[J]. Pattern Recognition Letters, 2012, 33(7): 898-903.
- [15] Yang Yang, Yang Jimei, Yan Junjie, et al. Salient color names for person re-identification[C]//European conference on computer vision, Zurich: Springer, Cham, 2014: 536-551.
- [16] Chow T W S, Rahman M K M. A new image classification technique using tree-structured regional features[J]. Neurocomputing, 2007, 7(4): 1040-1050.
- [17] Bazzani L, Cristani M, Murino V. Symmetry-driven accumulation of local features for human characterization and re-identification[J]. Computer Vision and Image Understanding, 2013, 11(2): 130-144.
- [18] Cheng D S, Cristani M, Stoppa M, et al. Custom Pictorial Structures for Re-identification[C]// British Machine Vision Conference, England: BMVC, 2011: 6-11.
- [19] Bazzani L, Cristani M, Perina A, et al. Multiple-shot person re-identification by chromatic and epitomic analyses[J]. Pattern Recognition Letters, 2012, 33(7): 898-903.
- [20] Cucchiara R, Grana C, Piccardi M, et al. Improving shadow suppression in moving object detection with HSV color information[C]//Intelligent Transportation Systems, 2001. Proceedings. Oakland: IEEE, 2001: 334-339.
- [21] Ma Bingpeng, Su Yu, Jurie F. Local descriptors encoded by fisher vectors for person re-identification[C]//Computer Vision—ECCV 2012, Heidelberg, 2012: 413-422.
- [22] Mignon A, Jurie F. Pcca: A new approach for distance learning from sparse pairwise constraints[C]//Computer Vision and Pattern Recognition (CVPR), Providence: IEEE, 2012: 2666-2672.
- [23] Agliardi F, Crosta G, Zanchi A. Structural constraints on deep-seated slope deformation kinematics[J]. Engineering Geology, 2001, 59(1): 83-102.
- [24] Bak S, Corvee E, Bremond F, et al. Multiple-shot human re-identification by mean riemannian covariance grid[C]//Advanced Video and Signal-Based Surveillance (AVSS), Klagenfurt: IEEE, 2011: 179-184.
- [25] 曾明勇, 吴泽民, 田畅, 等. 基于外观统计特征融合的人体目标再识别[J]. 电子与信息学报, 2014, 36(8): 1844-1851.

- [26] Han K H, Kim J H, Moon H, et al. The *Aspergillus nidulans* *esdC* (early sexual development) gene is necessary for sexual development and is controlled by *veA* and a heterotrimeric G protein[J]. *Fungal Genetics and Biology*, 2008, 45(3): 310-318.
- [27] Ballester P, Araujo R M. On the performance of GoogLeNet and AlexNet applied to sketches[C]// Thirtieth AAAI Conference on Artificial Intelligence, Phoenix: AAAI Press, 2016:1124-1128.
- [28] Deng Jia, Dong Wei, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]// Computer Vision and Pattern Recognition, 2009, Miami: IEEE, 2009: 248-255.
- [29] Socher R, Lin C C, Manning C, et al. Parsing natural scenes and natural language with recursive neural networks[C]// Proceedings of the 28th international conference on machine learning (ICML-11), Bellevue: ICML, 2011:129-136.
- [30] Xiao Tong, Li Hongsheng, Ouyang Wanli, et al. Learning deep feature representations with domain guided dropout for person re-identification[J]. 2016, 5(12):1249-1258.
- [31] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[J]. *Computer Vision—ECCV 2008*, 2008, 32(24): 262-275.
- [32] Räsch G, Onoda T, Müller K R. Soft margins for AdaBoost[J]. *Machine learning*, 2001, 42(3): 287-320.
- [33] Du Yuning, Ai Haizhou, Lao Shihong. Evaluation of color spaces for person re-identification[C]//Pattern Recognition (ICPR), Tsukuba: IEEE, 2012:1371-1374.
- [34] Prosser B J, Zheng W S, Gong S, et al. Person re-identification by support vector ranking[C]// British Machine Vision Conference, Aberystwyth: BMVC, 2010:6-12.
- [35] Băk S, Charpiat G, Corvee E, et al. Learning to match appearances by correlations in a covariance metric space[C]// European Conference on Computer Vision. Springer, Berlin, Heidelberg, 2012: 806-820.
- [36] He Yifan, Ma Yanjun, Genabith J, et al. Bridging SMT and TM with translation recommendation[C]//Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics, Baltimore:CoNll, 2010: 622-630.
- [37] Yi Dong, Lei Zhen, Liao Shengcai, et al. Deep metric learning for person re-identification[C]// Pattern Recognition (ICPR), Opatija: ICPR, 2014: 34-39.

- [38] Liu Hao, Ma Bingpeng, Qin lei, et al. Set-label modeling and deep metric learning on person re-identification[J]. Neurocomputing, 2015: 1283-1292.
- [39] Li Wei, Zhao Rui, Xiao Tong, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Columbus:IEEE,2014:152-159.
- [40] Ding Shengyong, Lin liang, Wang Guangrun, et al. Deep feature learning with relative distance comparison for person re-identification[J]. Pattern Recognition, 2015, 48(10): 2993-3003.
- [41] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [42] Gao Ligang, Chen Paiyu, Yu Shimeng. Demonstration of convolution kernel operation on resistive cross-point array[J]. IEEE Electron Device Letters, 2016, 37(7): 870-873.
- [43] Liu Chunyang, Sun Wangbo, Chao Wenhong, et al. Convolution Neural Network for Relation Extraction[J]. 2013, 3(4):231-242.
- [44] Bengio Y, Courville A, Vincent P. Representation learning: A review and new perspectives[J]. IEEE transactions on pattern analysis and machine intelligence, 2013, 35(8): 1798-1828.
- [45] Gu Jiuxiang, Wang Zhenhua, Kuen J, et al. Recent advances in convolutional neural networks[J]. arXiv preprint arXiv:1512.07108, 2015.
- [46] Boureau Y L, Le Roux N, Bach F, et al. Ask the locals: multi-way local pooling for image recognition[C]//Computer Vision, Barcelona: ICCV, 2011: 2651-2658.
- [47] Li Y, Tao C, Tan Y, et al. Unsupervised Multilayer Feature Learning for Satellite Image Scene Classification[J]. IEEE Geoscience & Remote Sensing Letters, 2016, 13(2):157-161.
- [48] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 3(1): 106-154.
- [49] Dahl G E, Sainath T N, Hinton G E. Improving deep neural networks for LVCSR using rectified linear units and dropout[C]//Acoustics, Speech and Signal Processing (ICASSP), Vancouver: IEEE, 2013: 8609-8613.
- [50] O'Shea K, Nash R. An introduction to convolutional neural networks[J]. arXiv preprint arXiv:1511.08458, 2015.

- [51] Yoo H J. Deep convolution neural networks in computer vision[J]. IEIE Transactions on Smart Processing & Computing, 2015, 4(1): 35-43.
- [52] Bourdev L, Maji S, Malik J. Poselets: a distributed representation for visual recognition[J]. Journal of Vision, 2011, 11(11):891-891.
- [53] Zhu Jianqing, Liao Shengcai, Lei zhen, et al. Multi-label convolutional neural network based pedestrian attributeclassification[J]. Image & Vision Computing, 2016, 58(3):224-229.
- [54] Layne R, Hospedales T M, Gong S. Investigating open-world person re-identification using a drone[C]// European Conference on Computer Vision,Zurich: ECCV,2014:225-240.
- [55] Liu Xiangyu, Sun Xiaobing, Li bin. Top-down program comprehension with multi-layer clustering based on LDA[C]// International Workshop on Evidential Assessment of Software Technologies,England: ACM, 2014:56-59.
- [56] Liu Chengjun. Gabor-based kernel pca with fractional power polynomial models for face recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2004, 26(5):572-81.
- [57] Lei zhen, Yi dong, Li Stan Z. Learning stacked image descriptor for face recognition[J]. IEEE Transactions on Circuits & Systems for Video Technology, 2016, 26(9):1685-1696.
- [58] Cheng De, Gong Yihong, Zhou Sanping, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C]// Computer Vision and Pattern Recognition, Las Vegas: IEEE, 2016:1335-1344.
- [59] Weinberger K Q, Saul L K. Distance metric learning for large margin nearest neighbor classification[J]. Journal of Machine Learning Research, 2009, 10(1):207-244.
- [60] Zheng Weishi, Gong Shaogang, Xiang Tao. Person re-identification by probabilistic relative distance comparison[C]// Computer Vision and Pattern Recognition, Providence: IEEE , 2011:649-656.
- [61] Hirzer M. Large scale metric learning from equivalence constraints[C]//IEEE Conference on Computer Vision and Pattern Recognition,Providence: IEEE,2012:2288-2295.

- [62] Liao Shengcai, Hu Yang, Zhu Xiangyu, et al. Person re-identification by local maximal occurrence representation and metric learning[C]// Computer Vision and Pattern Recognition, Boston :IEEE, 2015:2197-2206.
- [63] Hong S, Roh B, Kim K H, et al. PVANet: lightweight deep neural networks for real-time object detection[J]. arXiv preprint arXiv: 1608.08021, 2016.
- [64] Szegedy C, Ioffe S, Vanhoucke V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning[J]. arXiv preprint arXiv:1602.07261,2016.
- [65] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//International Conference on International Conference on Machine Learning. Omnipress, Boston: 2010:807-814.
- [66] Force T S T. Practice parameters for sigmoid diverticulitis[J]. Diseases of the Colon & Rectum, 2007, 50(3):402-403.
- [67] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Delving deep into rectifiers: surpassing human-level performance on imagenet classification[J]. arXiv preprint arXiv: 1502.01852, 2015.
- [68] Cun Y L, Boser B, Denker J S, et al. Handwritten digit recognition with a back-propagation network[C]// Advances in Neural Information Processing Systems. Morgan Kaufmann Publishers Inc, Denver:1990,:396-404.
- [69] Deng Yubin, Luo Ping, Loy Chenchang, et al. Pedestrian attribute recognition at far distance[C]// International Conference on Multimedia, Brisbane :ACM, 2014:789-792.
- [70] Lobo J M, Jiménez-Valverde A, Real R. AUC: a misleading measure of the performance of predictive distribution models[J]. Global ecology and Biogeography, 2008, 17(2): 145-151.
- [71] Zheng Liang, Shen Liyue, Tian lu, et al. Scalable person re-identification: a benchmark[C]// IEEE International Conference on Computer Vision, Santiago:IEEE Computer Society, 2015:1116-1124.
- [72] Jose C, Fleuret F. Scalable metric learning via weighted approximate rank component analysis[J]. Computer Vision – ECCV 2016, 2016,33(2):875-890.
- [73] Wu Lin, Shen Chunhua, Anton van den Hengel. Personnet: person re-identification with deep convolutional neural networks[J].arXiv preprint arXiv:1601.07255, 2016.

- [74] Varior R R, Bing Shuai, Lu Jiwen, et al. A siamese long short-term memory architecture for human re-identification[C]// European Conference on Computer Vision, Amsterdam :Springer, 2016:135-153.
- [75] Zheng Liang, Bie Zhi, Sun Yifan, et al. MARS: A video venchmark for large-scale person re-identification[C]// European Conference on Computer Vision, Amsterdam: Springer, Cham, 2016:868-884.
- [76] Zhang Li, Xiang Tao, Gong Shaogang. Learning a discriminative null space for person re-identification[C]// Computer Vision and Pattern Recognition, Las Vegas :IEEE, 2016:1239-1248.
- [77] Varior R R, Haloi M, Wang Gang. Gated siamese convolutional neural network architecture for human re-identification[C]// European Conference on Computer Vision, Amsterdam :Springer International Publishing, 2016:791-808.
- [78] Liao Shengcai, Li Stan Z. Efficient psd constrained asymmetric metric learning for person re-identification[C]//International Conference on Computer Vision, Santiago:IEEE, 2015:3685-3693.
- [79] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C]// Computer Vision and Pattern Recognition, Boston:IEEE,2015: 3908-3916.
- [80] Wang Faqiang, Zuo Wangmeng, Lin Liang, et al. Joint learning of single-image and cross-image representations for person re-identification[C]// Computer Vision and Pattern Recognition, Las Vegas: IEEE, 2016:1288-1296.
- [81] Zheng Liang, Bie Zhi, Sun Yifan, et al. MARS: A video venchmark for large-scale person re-identification[C]// European Conference on Computer Vision, Amsterdam: Springer, Cham, 2016:868-884.