

学校代码: 10730

分类号: TP391

密级: 公开

兰州大学
硕士学位论文
(学术学位)

论文题目 (中文)	基于模态对齐与特征融合的 跨模态行人重识别算法研究
论文题目 (外文)	Research on Cross-Modal Person Re-Identification Algorithm Based on Modality Alignment and Feature Fusion
作者姓名	刘东骄
学科专业	计算机科学与技术
研究方向	模式识别
教育类型	学历教育
指导教师	胡希平 教授
合作导师	
论文工作时段	2023 年 10 月 至 2025 年 3 月
论文答辩日期	2025 年 5 月

校址: 甘肃省兰州市城关区天水南路 222 号

基于模态对齐与特征融合的跨模态行人重识别算法研究

中文摘要

行人重识别是一项计算机视觉任务，旨在不同摄像头视角下对同一行人进行匹配。然而，单模态行人重识别主要依赖可见光图像，在光照变化或夜间环境下存在较大的局限性。因此，跨模态行人重识别成为近年来的研究热点，它利用红外和可见光图像进行匹配，以弥补单模态方法在复杂光照条件下的不足。当前跨模态行人重识别任务面临两个核心挑战：一是模态差异，即由于可见光和红外光谱的差异，导致跨模态特征分布不一致，使得直接匹配不同模态的行人图像变得困难；二是行人特征表达的不稳定性，受遮挡、视角变化、行人姿态、低分辨率等因素影响，不同模态下的行人特征可能存在较大差异，导致身份特征难以保持一致性，从而降低跨模态匹配的准确性。针对上述问题，本文提出了针对模态对齐和特征融合问题的跨模态行人重识别方法，旨在减少模态差异、提升跨模态特征对齐能力，并增强模型对行人身份特征的鲁棒性，主要工作内容如下：

(1) 基于视觉提示对齐的跨模态行人重识别：本文引入视觉提示学习机制，通过不同模态提示来引导模型适应不同模态特征。具体而言，设计了视觉提示生成模块和提示融合模块。视觉提示生成模块负责生成不同模态的提示信息，使模型能够识别并适应跨模态特征分布的差异；提示融合模块进一步融合提示信息，促进不同模态特征的共享与对齐，从而提高跨模态匹配的鲁棒性。实验结果表明，该方法在 SYSU-MM01 和 RegDB 数据集上均取得了优于现有方法的性能提升，消融实验验证了两个模块在减少模态差异方面的有效性。同时，可视化分析进一步表明，视觉提示学习能够帮助模型更精准地捕捉跨模态行人的身份特征，从而提高识别的稳定性。

(2) 多尺度特征融合的跨模态行人重识别：为了充分融合不同尺度的行人特征，本文引入多尺度交叉注意力机制，通过不同尺度的特征交互来增强模态对齐能力。此外，本文设计了一种基于鸽群搜索优化的加权特征融合策略，以自适应地调整多尺度特征的融合权重，提高跨模态匹配的精度。同时，为了增强跨模态行人特征的判别能力，引入了模态增强损失，对模态间的特征分布施加约束，从而促使模型更加精准地提取共享的身份特征。实验结果表明，该方法数据集 SYSU-MM01 和 RegDB 数据集的 Rank-1 识别率和 mAP 指标上均显著

优于主流方法，且消融实验进一步验证了各个模块的有效性。

综上所述，本文针对模态对齐和特征融合的问题，提出了两种跨模态行人重识别方法，以解决跨模态行人重识别任务中的模态差异和特征匹配问题。实验结果显示，本文提出的方法在两个主流的跨模态行人重识别数据集上均取得了优异的性能表现，为该领域提供了新的技术思路与方法参考。

关键词：行人重识别，跨模态，多尺度特征融合，模态对齐，可见光和红外特征

Research on Cross-Modal Person Re-Identification

Algorithm Based on Modality Alignment and Feature Fusion

Abstract

Person re-identification (Re-ID) is a computer vision task that aims to match the same individual across images captured from different camera views. However, conventional single-modality Re-ID methods primarily rely on visible light images, which significantly limits their performance under varying illumination conditions, especially in low-light or nighttime environments. To address these limitations, cross-modality person Re-ID (VI Re-ID) has emerged as a research focus in recent years, which seeks to match pedestrians using both visible and infrared images, thus compensating for the shortcomings of single-modality approaches in complex lighting scenarios. Currently, VI Re-ID faces two major challenges. The first is *modality discrepancy*—the inherent differences between visible and infrared spectral distributions lead to inconsistent feature representations across modalities, making cross-modal matching difficult. The second is the instability of person feature representation, which is often affected by factors such as occlusion, pose variations, viewpoint changes, and low resolution. These factors can result in inconsistent identity features across modalities, thereby reducing the accuracy of cross-modality matching. To tackle these challenges, this thesis proposes two cross-modality person re-identification methods focusing on modality alignment and feature fusion, aiming to reduce modality gaps, enhance feature alignment across modalities, and improve the robustness of identity representation. The main contributions are summarized as follows:

(1) Cross-Modality Person Re-ID Based on Visual Prompt Alignment:

This thesis introduces a visual prompt learning mechanism to guide the model in adapting to modality-specific features. Specifically, a visual prompt generation module and a prompt fusion module are designed. The generation module produces modality-aware prompts that help the model recognize and adapt to differences in cross-modal feature distributions, while the fusion module integrates these prompts to facilitate feature alignment and sharing between modalities, thereby improving cross-modality robustness. Experimental results on SYSU-MM01 and RegDB datasets demonstrate

superior performance compared to existing methods. Ablation studies validate the effectiveness of the proposed modules in mitigating modality discrepancy, and visualizations further show that the visual prompt mechanism helps the model focus on consistent identity-related regions across modalities, improving recognition stability.

(2) Cross-Modality Person Re-ID Framework with Multi-Scale Feature Fusion:

To explore discriminative features at multiple scales, this thesis introduces a multi-scale cross-attention mechanism that enhances modality alignment through feature interactions at different spatial resolutions. Additionally, a pigeon-inspired optimization-based weighted fusion strategy is proposed to adaptively adjust the weights of multi-scale features, thereby improving cross-modal matching accuracy. To further enhance the discriminability of cross-modality features, a modality-enhanced loss is introduced to constrain the distribution of modality-specific features, guiding the model to more accurately extract shared identity representations. Experimental results show that the proposed method significantly outperforms existing approaches on both SYSU-MM01 and RegDB datasets in terms of Rank-1 accuracy and mean Average Precision (mAP). Ablation studies further confirm the effectiveness of each component.

In summary, this thesis addresses the key issues of modality alignment and feature fusion in cross-modality person Re-ID by proposing two novel approaches. The experimental results demonstrate that the proposed methods achieve competitive performance on two widely-used datasets, offering new technical insights and methodological references for future research in this field.

Keywords: Person Re-identification, Cross-modal, Multi-scale Feature Fusion
Modality Alignment, Visible and Infrared Features

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	4
1.2.1 单模态行人重识别算法.....	4
1.2.2 跨模态行人重识别算法.....	5
1.2.3 多模态行人重识别算法.....	7
1.3 本文的主要贡献与创新.....	7
1.4 本文的结构安排.....	9
第二章 相关理论基础	11
2.1 行人重识别基本流程.....	11
2.2 Transformer 与 Vision Transformer 概述	13
2.2.1 Transformer 架构	13
2.2.2 Vision Transformer(ViT).....	15
2.3 跨模态行人重识别经典算法	16
2.3.1 CMTR	16
2.3.2 SPOT	18
2.3.3 DFLN-ViT.....	19
2.3.4 PMT.....	20
2.4 优化目标与评估方法.....	21
2.4.1 损失函数.....	21
2.4.2 评价指标.....	22
2.4.3 评价模式.....	23
2.5 本章小结.....	24
第三章 基于视觉提示对齐的跨模态行人重识别	25
3.1 引言.....	25
3.2 视觉提示学习(Visual Prompt Learning)	25
3.3 网络设计.....	26
3.3.1 视觉提示生成模块.....	27
3.3.2 提示互补融合模块.....	29
3.3.3 损失函数.....	30
3.4 实验与结果分析.....	30
3.4.1 数据集.....	30
3.4.2 实验设定	32
3.4.3 与目前方法的对比.....	32

3.4.4 消融实验.....	33
3.5 可视化分析.....	35
3.5.1 检索结果.....	35
3.5.2 t-SNE 可视化分析.....	36
3.5.3 注意力图可视化.....	37
3.6 本章小结.....	38
第四章 基于多尺度特征融合的跨模态行人重识别算法	39
4.1 引言.....	39
4.2 基于多尺度特征融合的跨模态行人重识别算法	39
4.2.1 网络结构设计.....	39
4.2.2 基于多尺度交叉注意力的特征提取	40
4.2.3 加权特征融合.....	42
4.3 损失函数设计.....	44
4.4 实验结果与分析.....	45
4.4.1 实验设置.....	45
4.4.2 与目前方法的对比.....	45
4.4.3 消融实验.....	47
4.5 可视化分析.....	50
4.5.1 检索结果.....	50
4.5.2 特征分布的可视化.....	52
4.6 本章小结.....	53
第五章 总结与展望	54
5.1 本文总结.....	54
5.2 工作展望.....	55
参考文献.....	56

第一章 绪论

1.1 研究背景与意义

在当今社会，围绕日常活动的安全威胁呈上升趋势，这使得在不同网络摄像机中准确识别与跟踪人员变得尤为重要。行人重识别（Person re-identification, ReID），即针对某一相机拍摄的行人图像，在其他相机拍摄的视频或图像中再次识别出同一行人的过程。当出现网络断开或丢失的情况，就需要重新建立跟踪连接，因此在摄像机内部或跨多个摄像机设置一致的标签极为关键。其核心任务是将不同相机或同一相机在不同时段捕捉到的同一行人的图像进行关联，可以说，行人重识别就是在多相机网络环境中赋予某人稳定身份的过程。




图 1-1 不同摄像头下的行人

以大型公共场所为例，如图 1-1 所示，安装了视频监控摄像机网络的购物中心^[2]，两组不同的行人分别出现在咖啡店和电影院入口，行人重识别便是将这两处出现的同一人关联起来的过程。如今，摄像头广泛应用于家庭监控、体育赛事、机场、地铁站、车辆、商店、购物中心等各个领域。然而，任何监控框架的主要目标不只是跟踪和召回，更在于理解场景并确定所需对象的身份。行人重识别可定义为判断特定感兴趣的人是否曾在相机中被观察到，这一问题也被称为人员再识别问题。

行人重识别是计算机视觉领域中一个重要的方向，其任务是跨摄像头视角、图像或跨时间的视频序列中识别出同一人物。在智能安防中，它可以使得监控系统超越摄像头限制，跟踪特定人员，及时发现潜在威胁，提高监控系统的效率和覆盖范围^[3]。在智慧城市建设中，它可以辅助交通管理部门了解行人出行规律，优化交通信号，改善拥堵，为公共服务设施布局提供建议。在视频大数据中，行人重识别能够从海量数据中识别人物，协助分析和做出判断。行人重识别技术在传统基于可见光图像识别时，在照明充足、环境良好的场景下具有一定的准确率^[4]。然而，现实监控场景复杂多变，光照条件参差不齐，夜晚光照条件不足、光照差、强逆光造成关键区域阴影等问题，这些问题都严重影响识别率。不同的行人姿态、摄像头的不同参数也会导致识别的准确率有所上升，亟需新技术来提高识别准确率和适应性^[5]。



图 1-2 不同照明环境下的行人

传统的单模态行人重识别方法，大多都是基于单一类型的数据，即只有可见光图像。在理想的照明条件以及环境良好的场景下，可以根据行人的外观特征，例如衣着服饰，发型等达到一定的识别率。如图 1-2 所示，实际场景中行人重识别会面临各种各样复杂情况，实际的照明条件变化极大，不仅有夜间光照条件下的黑暗无光状态，还有白天光照条件下的强逆光等，这些极端光照条件，导致可见光图像行人特征严重受损，识别率大大降低^[6]；与此同时行人自身姿态也在发生变化，行人行走，奔跑，弯腰等不同姿态，其外观形象也会有较大差异^[34]；不同摄像头拍摄视角的不同，拍摄物体分辨率的不同，都会导致单模态行人重识别面临极大的挑战，无法满足实际场景精准识别的需求^[7]。多模态

行人重识别,是利用多种模态的数据,如可见光、红外、深度、音频、描述等来实现行人重识别的技术。不同模态的数据包含不同的信息,各模态信息又各具互补特性,如可见光数据在识别与定位正常光照条件下的行人特征时,具有纹理、颜色等细节信息;红外数据不受光照条件的制约,能够在黑暗或弱光环境下清晰地给出行人的轮廓和热辐射信息,很好地弥补了可见光数据的不足;深度数据可以提供行人的三维信息,能够更好地对行人姿态、位置进行理解,从而实现对行人更加准确的表征^[8]。多模态行人重识别技术的应用,有利于在恶劣环境下识别出更多的行人,从而提高行人重识别系统的鲁棒性与准确性^[9]。

现有的行人重识别技术主要集中于仅涉及可见光图像的单模态行人重识别,而大多数有关模态的行人重识别技术和常见的公开数据集,往往集中在跨模态的行人重识别上,即可见光-红外模式下的行人重识别。与可见光图像相比,红外图像可以从黑暗中捕捉丰富的信息^[29]。常见的跨模态行人重识别融合可见光、红外的多源数据,突破单一模态局限,在完善理论体系的同时,于公共安全、智能交通等领域展现广阔应用前景,研究意义具有显著多重性。在计算机视觉领域,跨模态行人重识别研究,可以推动模态数据特征提取、融合、模型训练等技术的探索与进步,有利于深入研究复杂的视觉信息处理过程,拓宽计算机视觉领域的研究视野,为解决其他多模态数据处理问题提供思路和方法^[10]。比如目标检测、图像分类等方面,跨模态行人重识别发展出的特征融合和模型训练技术均可得到应用和推广^[11]。

从实际应用情况来看,跨模态行人重识别技术可在安防领域充分发挥其智能化作用,帮助监控系统进行人物识别;刑侦部门可依托跨模态行人重识别技术,充分利用不同相机所采集到的多模态信息,更为快速、准确地锁定犯罪嫌疑人,提升破案效率;在大型活动安保工作中,可实时发现人群中的异常行为和可疑人员,采取措施进行防范,确保活动场所的安全稳定;在智慧社区建设中,可将跨模态行人重识别技术应用于居民身份识别、访客管理等环节,提升社区的安全性、管理效率;在如机场、火车站等交通要道中,应用跨模态行人重识别技术可快速识别出行旅客的身份,提升安检效率,为旅客出行提供更便捷、更安全的服务^[12]。跨模态行人重识别技术发展与应用也必将对安防监控行业产生重大影响,带动相关产业的发展。如硬件设备厂商开发具备多模态数据采集能力的摄像头等;软件开发厂商研发跨模态数据应用软件,提供相关的应用服务。随着跨模态行人重识别技术的日益成熟与应用,必将催生一套涵盖硬件设备生产、软件系统研发、系统集成与应用服务的产业链,为我国经济带来新的增长点^[13]。

1.2 国内外研究现状

1.2.1 单模态行人重识别算法

行人重识别技术是智能视频监控的重要组成部分，旨在对不同摄像机视角下同一行人的图像进行精准识别。早期的单模态行人重识别^[14]大多借助人工设计的特征，如尺度不变特征变换、方向梯度直方图等，这些特征大多是人为经验提取得出，有一定的针对性。单模态中基于可见光的行人重识别较为普遍，主要利用正常光照条件下可见光图像行人的外观信息，如服装纹理、颜色，行人的发型等特征进行识别；对于光照突变、姿势变化、身体遮挡等复杂场景无法识别。但是，仅仅依靠可见光图像及此类手工特征无法达到实际应用中所需的精度^[15]。

可见光-可见光行人重识别（Visible-Visible Re-ID, VV Re-ID）旨在通过一张由可见光摄像头采集的查询图像，从大规模图像集合中识别出目标个体。该任务已被广泛研究，现有方法主要包括基于全局特征提取的方法和基于局部部位特征的方法^[75]。例如，Chen 等人^[76]提出了四元组损失函数，在提升识别性能的同时加速模型收敛，有效增强了类间区分性，并减小类内差异。文章^[77]中提出了一种空间驱动网络，该网络在建模图像之间与图像内部关系的基础上，学习语义丰富且具有高度判别性的特征表示。

从深度学习发展以来，基于卷积神经网络（Convolutional Neural Network, CNN）的单一模态行人重识别算法开始大行其道，例如，AlexNet^[16]就是通过卷积神经网络来提取图像特征，通过卷积神经网络的多层结构和池化功能大大提高了图像特征自动化提取的程度，相较于手工特征而言效果提升显著。VGGNet^[17]实现了卷积网络结构的进一步细化，使用小卷积核来代替大卷积核，在提高特征提取能力的同时大大减少了计算量。GoogleNet^[18]则创新性地引入 Inception 模块，并行处理不同尺度的特征，丰富了特征表达。近几年来，工作重点集中于如何提高网络的结构，使其能够更好地拟合行人特征。例如，ResNet^[30]提出了残差学习模块，残差学习解决了深度网络训练过程中梯度消失的问题，使网络能够更深度地学习特征，在行人重识别任务上取得良好表现^[19]。DenseNet^[31]将网络连接得更紧密，以提高特征在网络中的传播和重复使用率，提高了网络的特征学习能力。注意力机制已应用于单模态行人重识别任务中^[20]。SENet^[32]引入了通道注意力，对每个通道的特征自适应分配权重，在识别过程中着重处理关键特征。CBAM^[21]不仅考虑通道注意力还考虑空间注意力，使所提模型对行人特征的识别性能进一步提高。在设计损失函数时，交叉熵损失函数^[33]是常用的分类损失，这有助于将行人识别为正确的分类。三元组损失^[22]通

通过对构建的三元组(目标样本, 正样本, 负样本)使得目标样本和正样本的样本特征距离更近, 和负样本的样本特征距离更远, 有助于提高特征的判别力。对于损失函数的优化策略也是存在的, 对于损失函数的设计可以采用难样本挖掘策略, 如在线难样本挖掘 OHEM^[23]等, 对难以识别的样本进行重点训练, 以提高对难样本的识别能力。

1.2.2 跨模态行人重识别算法

可见光-红外行人重识别 (Visible-Infrared Re-ID, VI Re-ID) 致力于在两个不同模态 (可见光与红外) 之间实现目标匹配。早期跨模态行人重识别方法^[24]主要基于特征转换, 把来自不同模态的特征投影到同一个空间中。例如, 主成分分析法用于转化不同模态数据之后, 再寻找两个模态之间的映射对应, 但是这类降维方法无法探索不同模态之间更复杂的相互关系。

随着深度学习的兴起, 基于深度神经网络的跨模态行人重识别方法不断涌现, 采用双流网络结构, 分别对不同模态数据进行特征提取, 再通过融合层将特征融合, 如崔洪刚等人^[25]提出的方法, 利用 ResNet50 作为骨干网络对三种模态图像进行特征提取与融合, 结合交叉熵损失与改进的难样本三元组损失对网络进行训练, 在一定程度上提升跨模态行人重识别的准确率。

为了应对模态间的差异问题, 一些研究开始引入生成对抗网络 (Generative Adversarial Nets, GAN), 通过生成器与判别器相互对抗, 模态差距更小的相似模态数据能够在对抗中生成。例如, Cao 等人^{错误:未找到引用源。}将可见光图像转换为红外图像风格, 或者将红外图像转换为可见光图像风格, 利用 GAN 使得网络在相似模态数据上学习, 以跨模态识别作为目标。为克服跨波段识别所面临的挑战, 引入多模态数据已成为关键策略, 前期工作^[73]探讨了融合多模态信息在识别任务中的有效性, 为可见光与红外图像特征的融合方法提供了重要的理论基础和实践启示。同时, 细粒度图像识别与 VI Re-ID 在识别过程中都需要捕捉图像中的精细结构与差异性, 两者在建模目标上具有一定的相似性。Yu 等人^[74]提出了一种分层深度学习框架, 能够有效捕捉图像内部复杂的层次结构特征, 这种分层特征学习机制与可见光与红外模态之间的复杂信息关系具有高度契合性, 为建模跨模态语义对齐关系提供了新的思路。Wu 等人^[78]首次系统定义了 VI Re-ID 任务, 并构建了一个大规模且具有挑战性的数据集。Li 等人^[79]提出了辅助模态学习策略, 通过引入中间模态特征缓解模态差异; Xiang 等人^[80]则设计了 VI 辅助的跨模态匹配机制, 在不同光照条件下捕捉有效的行人特征; 文献^[81]中引入了多种融合机制, 进一步缓解了模态间的特征分布不一致的问题。Sun 等人^[82]提出的模型可有效对模态特征进行对齐, 有助于提升匹配精度。在对模态结构关系建模方面, G2DA^[83]提出几何引导的双重对齐机制, 通过图结构方式优

化多模态节点表示间的匹配问题。DDAG^[84]进一步引入跨模态图结构注意机制,在考虑上下文语义关联的同时提升了模态间特征的一致性。文献^[85]提出了一种自适应性与局部信息融合的新型图像特征构建方法,以应对可见光与红外图像在结构与纹理层面的差异。此外,VI Re-ID 任务中标注数据稀缺也是一项重要挑战。针对这一问题,Zhang 等人^[86]借助半监督学习中的互学习机制,引入了可迁移的自监督学习策略,在标签稀缺的情况下实现了对特征表示的增强,为VI Re-ID 模型的训练提供了新的解决路径。

多尺度特征融合也被广泛应用于跨模态行人重识别任务中,程德强等人^[27]提出基于多粒度融合与跨尺度感知的跨模态行人重识别网络,使用多尺度特征融合注意力机制和多粒度非局部融合框架跨模态融合多尺度图像特征,提出跨尺度特征信息感知策略,降低无关噪声影响,在 SYSU-MM01^[64]和 RegDB^[65]数据集上均取得优于对比方法的结果。其他工作则关注如何提取模态共享特征和模态特定的特征。谭台哲等人^[28]提出跨模态行人重识别网络的训练策略,将频域注意力与模态协同特征优化,提出基于集成频域注意力的双流网络,提取模态共享特征和模态特定特征,对模态特定特征采取模态差异净化的方差聚合损失,在公开数据集上实现提升。

近年来,Transformer^[33]在计算机视觉任务中的成功应用引起了研究者的广泛关注,并引入 VI-ReID 任务,以缓解跨模态特征对齐的挑战。相比传 CNN 方法,基与 Transformer 的方法依靠自注意力机制进行全局特征建模,有助于增强跨模态匹配能力。He 等人^[87]对单模态行人重识别任务中的模型进行了增强,通过引入拼图补丁模块以及辅助信息嵌入,提升了模型对判别性特征的学习能力。为进一步挖掘局部特征,Zhu 等人^[88]在自注意力机制中引入了部件对齐策略,并设计了可学习的部件向量,从而有效加强了局部结构信息的建模能力。例如,CMTR^[50]通过模态嵌入机制优化模态特征对齐,并引入模态感知增强损失提升跨模态判别能力,在多个数据集上均表现优于 CNN 方法。SPOT^[51]则通过建模人体结构和位置信息,结合注意力结构表示和局部特征交互学习模块,提高跨模态匹配的鲁棒性。DFLN-ViT^[52]进一步从空间和通道维度优化跨模态特征表达能力,结合三元组辅助异构中心损失提升模态内外部特征分布的稳定性。此外,PMT^[53]提出逐步模态共享学习策略,引入灰度图像作为辅助模态,以逐步优化跨模态特征对齐,并通过模态共享增强损失和判别中心损失进一步优化特征分布,最终在多个数据集上取得了显著的性能提升。这些研究表明,Transformer 在 VI-ReID 任务中具有较强的应用潜力,有望进一步推动跨模态行人重识别技术的发展,并拓展至更广泛的跨模态视觉任务。

1.2.3 多模态行人重识别算法

多模态行人重识别是对深度图像、红外图像、文本信息等多种模态进行融合后进行识别，以提高识别的准确率。早期的多模态融合^[70]主要是在数据层或特征层将各个模态进行简单拼凑，这种方式不能充分利用各个模态的互补信息。

在特征层次融合部分，研究者提出了多种融合机制。部分基于注意力机制对各个模态特征进行加权融合，强调重要特征。如万磊等人^[70]提出基于双分类器的注意力融合机制，为各个模态自有特征赋予较高的权重，共有特征则赋予较低的权重，得到融合后的多模态特征中判别性自有特征权重较大。设计记忆存储器构建行人多视角特征，并设计自蒸馏无参数动态引导策略，提升模型跨模态推理和多视角推理能力，在公开数据集上取得较好效果。部分研究利用多个不同模态的子模型进行联合训练，然后对多个子模型的输出结果进行联合决策。模型层次融合可采用加权投票、堆叠泛化等方式进行不同模型的优势互补。部分研究还利用多模态数据训练基于 Transformer 类的模型，Transformer 自注意力机制能够对不同模态之间的各种长距离依赖关系进行有效捕捉，从而提高多模态融合的效果。Aditya^[69]等人为了了解决多模态数据中信息不对称的问题，提出了基于生成对抗网络的 I2V-CMGAN 方法，利用生成器将视频网络学习到的特征转换成图像的特征，以此缓解图像和视频特征之间的信息不对称，提高图像到视频的行人重识别率。

在实际应用^[71]中，多模态行人重识别也有着较为广泛的前景，包括在智能安防、智慧城市建设等领域。例如，在智能安防中，对可见光、红外、深度图像等不同模态图像进行融合，可以帮助智能安防的行人进行准确的识别，提升智能安防系统的安全性和可靠性；在智慧城市建设中，基于行人图像和属性描述的语义信息实现多模态行人重识别，能够有效提升城市建设智能化水平。

总之，多模态行人重识别工作取得了许多研究成就，但是由于模态差异大、数据不平衡、缺乏有效的融合策略等原因，多模态行人重识别任务仍然存在着许多不足之处，值得进一步深入研究与探索。

1.3 本文的主要贡献与创新

在前两个小节中，介绍了行人重识别的研究背景与意义，并按照单模态，跨模态，多模态的发展脉络对行人重识别的历史现状进行了梳理。可以发现，跨模态行人重识别所面临的挑战主要是由于可见光摄像头和红外摄像头所拍摄的不同图片，在光照、拍照角度、行人姿态等条件下，造成的不同模态间的差异。因此为了应对以上挑战，本文从两种不同的方法对跨模态行人重识别算法进行

研究。具体来说，主要工作包含以下几点：

在本文的第三章中，围绕基于视觉提示对齐的跨模态行人重识别展开，系统性地探讨了视觉提示学习的概念、网络设计及其实验分析。首先，引入视觉提示学习，通过生成适应不同模态的提示信息，增强模型对模态特定特征的适应性，并提升跨模态特征的对齐能力。在此基础上，提出视觉提示生成模块（VPG）和提示融合模块（MPC），分别用于生成模态感知提示信息和融合提示特征，以促进模态共享信息的提取。实验部分在 SYSU-MM01 和 RegDB 数据集上进行了全面评估，包括模型性能对比、消融实验和可视化分析。实验结果表明，所提出的方法在多个评价指标上均优于现有主流方法，VPG 和 MPC 模块的有效性也得到了消融实验的验证。此外，可视化分析进一步揭示了视觉提示学习如何帮助模型捕捉模态间的隐式对应关系，从而提升跨模态行人重识别的鲁棒性。本研究为跨模态行人重识别任务提供了新的思路，并为后续探索更高效的视觉提示学习方法奠定了理论基础和实践支持。

在本文的第四章中，提出了一种基于多尺度特征融合的跨模态行人重识别方法，针对不同模态间的特征分布差异，利用多尺度交叉注意力机制增强特征对齐能力，并结合基于鸽群搜索优化（DSO）的加权特征融合策略，以提升跨模态匹配的鲁棒性。此外，引入模态感知增强损失（MAE），通过优化特征分布，提高模型在不同模态下的判别能力。在 SYSU-MM01 和 RegDB 数据集上的实验结果表明，所提出方法在 Rank-1 识别率和 mAP 指标上均取得显著提升，超越了现有主流方法。消融实验进一步验证了 CrossViT 结构、加权特征融合及损失函数的有效性，特征可视化分析揭示了模型能够更精准地关注跨模态行人的身份相关区域。本研究为跨模态行人重识别任务提供了新的解决方案，并为后续探索更高效的跨模态特征学习方法奠定了基础。

1.4 本文的结构安排




图 1-3 本文章节安排

本文主要研究基于模态对齐和特征融合的跨模态行人重识别算法，全文共六个章节，如图 1-3 本文章节安排 所示，相关具体内容和章节的安排如下：

第一章：绪论。本章首先介绍了行人重识别的研究背景，阐述其在智能监控、安全防范等领域的重要应用价值，并分析了该领域的发展现状。随后，重点探讨了单模态、跨模态和多模态行人重识别的研究进展，剖析了当前方法的优势与不足，特别是跨模态任务中由于模态差异导致的特征对齐和匹配难题。

第二章：相关理论基础。本章介绍了行人重识别的核心理论，包括基本流程，以及 Vision Transformer（ViT）在该任务中的应用优势。还梳理了跨模态行人重识别的经典算法，比较其优缺点，并探讨了主流损失函数和评价指标。

第三章：基于视觉提示对齐的跨模态行人重识别方法。本章研究基于视觉提示学习的跨模态行人重识别，提出了视觉提示生成模块和提示融合模块，提升模型的跨模态特征提取能力。实验结果验证了模块的有效性，且可视化分析展示了其在提升鲁棒性方面的优势。

第四章：基于多尺度特征融合的跨模态行人重识别方法。利用交叉注意力和加权特征融合策略提升模态对齐能力，结合模态感知增强损失（MAE），使模型能够更有效地挖掘跨模态数据的相似性与差异性。实验在两个数据集上验证了方法的优越性，消融实验与可视化分析进一步证明了各模块的贡献和模型的鲁棒性。

第五章：总结与展望。对本文的研究工作成果进行总结，通过分析本文的研究过程出现的问题和难点，对跨模态行人重识别技术的下一步研究做出展望。

第二章 相关理论基础

行人重识别近年来已成为计算机视觉领域的重要研究方向，为便于理解本文所提出的方法，现对与行人重识别相关的核心概念和基础知识进行简要概述。内容主要包括：首先介绍行人重识别的基本流程及所采用的深度学习理论；随后详细阐述跨模态行人重识别的经典算法和评价指标；最后对本章内容进行总结，为后续研究提供理论支撑。

2.1 行人重识别基本流程




图 2-1 行人重识别流程

如图 2-1 所示，行人重识别（Person Re-Identification, Re-ID）的核心任务是从多个监控摄像头拍摄的海量图像中，准确地匹配和识别出同一目标个体。这一任务在公共安全、犯罪侦查、交通管理等领域具有重要意义，尤其在面对大规模、多视角、不同场景的监控数据时，如何高效准确地找出目标成为关键。为了实现这一目标，通常需要为每个检测到的行人生成独特的身份特征，并通过对在不同摄像头之间进行匹配，将相同身份的个体在各视角下的图像关联起来。匹配结果通常以相似度排序，目标在排序列表中的位置即为排名得分，核心目标则是尽量降低正确匹配的排名位置，从而提高识别精度。

行人重识别任务的主要挑战来自于多摄像头环境下的多视角变化、光照条件不同、遮挡问题、行人姿态多样性、服饰变化以及低分辨率等因素，这些问题都会导致同一行人在不同摄像头拍摄的图像中呈现出较大的视觉差异。因此，如何设计高效且鲁棒的行人特征表示方式，并构建精准的跨摄像头匹配机制，是 Re-ID 任务的核心问题。



图 2-2 行人重识别的挑战

如图 2-2 展示了行人重识别任务面临的常见挑战。其中图（a）分辨率较低的情况下的行人图像。图（b）展示了复杂环境中的遮挡现象，特别是当行人部分被遮挡或其他物体遮挡时，往往造成部分关键特征缺失，导致匹配结果的不准确。图（c）在展示了在不同摄像头，行人姿态和角度的变化，这会降低基于外观特征的辨识能力，增加区分难度。如图（d）所示在不同的光照环境中下，如夜间需要使用红外（IR）和可见光（RGB）摄像头，两个模态之间有显著的视觉差异，直接匹配时经常遇到困难，因此需要运用跨模态学习技术对信息进行对齐和融合。




图 2-3 行人重识别训练和测试流程

行人重识别任务主要分为训练阶段和测试阶段。如图 2-3 所示，训练阶段首先需要准备好经过行人目标检测的数据集（对于视频行人识别任务，需要先进行行人检测，而对于已有检测结果的数据集，则无需重复检测）。随后，利用这些数据对深度学习模型进行训练，核心目标是通过网络提取每个行人的特征。具体来说，通过计算图像特征之间的度量距离，并与真实标签比较得到损失值，再利用优化器（如 SGD、Adam 等）反复更新网络参数，使损失逐步降低，从而学习到更具区分性和鲁棒性的特征表示。测试阶段则是利用训练好的模型，对待检索图像（probe）与图库（gallery）中所有图像的特征进行匹配，通常通过计算相似度或距离进行排序，选取距离最小（或相似度最高）的图像作为最终的匹配结果。这一流程确保了模型在训练阶段能充分优化特征提取能力，在实际应用中实现高效且准确的行人匹配。

2.2 Transformer 与 Vision Transformer 概述


在第 1.2.2 节中, 本文对当前跨模态行人重识别 (VI Re-ID) 的研究现状进行了系统性梳理。随着 Transformer 模型在自然语言处理领域取得突破性进展, 其强大的全局建模能力也逐渐被引入并广泛应用于计算机视觉任务之中。特别是 Vision Transformer (ViT) 的提出, 标志着 Transformer 架构在图像处理任务中的实用性和有效性得到了进一步验证。相较于传统基于卷积神经网络 (CNN) 的方法, Transformer 具备更强的建模长距离依赖关系和捕捉全局上下文信息的能力, 这对于解决跨模态行人重识别中模态差异大、特征对齐困难等关键问题具有重要意义。

鉴于此, 本文以基于 Transformer 架构的跨模态行人重识别算法为研究基础, 旨在通过引入 ViT 相关结构, 提升跨模态特征表示的准确性与鲁棒性。本节将围绕 Transformer 模型的基本架构及其在视觉领域的延伸——Vision Transformer, 展开详细介绍, 为后续方法设计与实现奠定理论基础。

2.2.1 Transformer 架构

在深度学习领域, 卷积神经网络 (CNN) 及其典型代表 ResNet 长期占据图像和视觉任务的主导地位。CNN 通过卷积层和池化层等操作有效提取图像局部特征, 并利用参数共享和局部连接大幅减少模型参数; 例如, ResNet 引入的残差块结构成功缓解了梯度消失和爆炸问题, 使得网络能够训练得更深, 并在图像分类和目标检测等任务中取得优异表现。然而, CNN 的卷积操作本质上是局部的, 虽然堆叠多层可以扩大感受野, 但在建模长距离依赖关系时仍显不足, 且其固定结构对不同尺度和位置的特征提取能力有限。为了解决这些局限性, Transformer 架构应运而生^[33]。最初用于自然语言处理中的序列到序列任务的 Transformer 完全基于注意力机制, 摒弃了传统的循环和卷积操作, 能够更高效地捕捉全局信息和长程依赖关系。

自注意力机制 (Self-Attention) : 标准的 Transformer 结构主要由编码器和解码器组成, 其中自注意力机制是其核心组件之一。如图 2-4 所示, 自注意力机制允许模型在处理输入序列时, 关注序列中不同位置的元素之间的关系, 从而捕捉到长距离依赖信息。计算过程如下:

图 2-4 自注意力机制与多头自注意力机制^[33]

首先，对于输入序列中的每个元素，将其分别映射到三个不同的向量空间，得到 Query（查询）、Key（键）和 Value（值）向量。假设输入序列为 $X = [x_1, x_2, \dots, x_n]$ ，其中 x_i 是第 i 个元素的特征向量。通过线性变换矩阵 W^Q 、 W^K 和 W^V ，可以得到 Query、Key 和 Value 向量：

$$Q = XW^Q \quad (2-1)$$

$$K = XW^K \quad (2-2)$$

$$V = XW^V \quad (2-3)$$

然后，计算 Query 向量与所有 Key 向量之间的相似度得分。通常使用点积运算来计算相似度，即 QK^T 。为了避免点积结果过大，将其除以 $\sqrt{d_k}$ ，其中 d_k 是 Key 向量的维度。得到相似度得分矩阵 S 后，通过 Softmax 函数将其转换为权重矩阵 A ：

$$A = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (2-4)$$

最后，将权重矩阵 A 与 Value 矩阵 V 相乘，得到自注意力机制的输出 Z ：

$$Z = AV \quad (2-5)$$

多头注意力（Multi-Head Attention）是自注意力机制的扩展，它通过使用多个不同的线性变换矩阵，将输入序列映射到多个不同的子空间中，分别计算自注意力，然后将各个子空间的输出拼接起来，并通过另一个线性变换得到最终的输出。多头注意力机制可以让模型在不同的表示子空间中捕捉到更丰富的信息。

位置编码 (Positional Encoding): 由于 Transformer 本质上是一个基于注意力机制的模型, 它对输入序列中的元素进行并行处理, 因此不具备位置信息。为了让模型能够感知到元素在序列中的位置, 需要引入额外的位置编码信息。常见的位置编码方式是正弦 / 余弦编码。对于输入序列中的每个位置 pos 和每个维度 i , 使用以下公式计算位置编码值:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \quad (2-6)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \quad (2-7)$$

其中, d_{model} 是模型的隐藏维度。将位置编码向量与输入序列的特征向量相加, 作为模型的输入。

早期 Transformer 主要应用于自然语言处理 (NLP) 领域, 如机器翻译、文本生成等任务。但随着研究的深入, 人们发现 Transformer 的自注意力机制和强大的长距离依赖建模能力也适用于计算机视觉 (CV) 领域。Vision Transformer (ViT) 是将 Transformer 架构直接应用于图像分类任务的典型代表, 它为计算机视觉领域带来了新的思路和方法。

2.2.2 Vision Transformer (ViT)

Vision Transformer (ViT) ^[35] 在计算机视觉领域获得了广泛的应用, 行人重识别任务也是其重要的应用对象之一。ViT 的最主要创新点是抛弃了传统 CNN 中的卷积操作, 将图像理解为一套图像块序列, 直接采用 Transformer 架构进行处理。




图 2-5 Vision Transformer 网络架构^[35]

Patch Embedding: 如图 2-5 所示, ViT 首先将输入图像划分为固定大小的 patch (如 16×16)。假设输入图像的尺寸为 $H \times W \times C$, 其中 H 和 W 分别是图像的高度和宽度, C 是图像的通道数。将图像划分为 $N = \frac{HW}{P^2}$ 个 patch, 每个 patch 的尺寸为 $P \times P \times C$ 。然后, 将每个 patch 展平为一个一维向量, 并通过一个线性变换层将其映射到固定维度 D 的向量空间, 得到对应的 token。

自注意力机制 (Self-Attention): 在 ViT 中, 自注意力机制用于计算不同 patch 之间的关系, 实现长距离依赖建模。通过自注意力机制, 模型可以捕捉到图像中不同位置的 patch 之间的语义关联, 从而更好地理解图像的全局信息。例如, 在行人重识别任务中, 自注意力机制可以帮助模型关注到行人的不同部位 (如头部、身体、腿部) 之间的关系, 提高对行人特征的表达能力。

分类 token (CLS Token): ViT 在处理分类任务时, 引入了一个特殊的分类 token (CLS Token)。在输入序列的开头添加一个可学习的 CLS Token, 它与其他 patch token 一起输入到 Transformer 编码器中。在经过编码器的处理后, 取 CLS Token 的输出作为整个图像的特征表示, 用于后续的分类任务。


MLP Head: 是 ViT 的最终分类层, 通常由一个或多个全连接层组成。它将 CLS Token 的输出作为输入, 通过非线性激活函数进行变换, 最终输出分类结果。

ViT 适用于行人重识别主要得益于其在处理全局和局部特征上的优势。通过自注意力机制, ViT 能够同时关注图像的整体布局和细微局部信息, 从而有效捕捉行人的姿态、穿着、配饰等关键信息, 有助于提高识别精度。此外, 实际场景中行人的尺度变化及不同模态 (如 RGB 与 IR) 图像的存在, 使得跨模态匹配成为一大挑战。ViT 具有较强的尺度不变性, 其自注意力机制还可以在不同模态之间建立有效关联, 从而提升跨模态匹配的能力。

2.3 跨模态行人重识别经典算法

2.3.1 CMTR

跨模态行人重识别 (VI-ReID) 任务旨在跨越可见光 (RGB) 和红外 (IR) 模态之间的巨大外观差异, 实现同一身份在不同模态下的匹配。然而, 由于两种模态在光谱信息、对比度和纹理细节上的显著不同, 传统的 CNN 方法在跨模态特征对齐方面存在瓶颈, 难以学习到有效的模态不变表示。在这个研究中, 提出了一种基于 Transformer 的跨模态行人重识别方法 CMTR^[50] (Cross-Modality Transformer Re-Identification), 充分利用 Transformer 的全局自注意力机制来挖掘模态信息并提升跨模态匹配能力。


图 2-6 CMTR 网络架构图^[50]

如图 2-6 所示，CMTR 采用 Vision Transformer (ViT) 作为骨干网络，与 CNN 依赖局部感受野不同，ViT 通过自注意力机制实现全局特征建模，使得模型能够同时关注全局和局部细节信息。针对跨模态特征分布的差异，在这个研究中设计了一种模态嵌入机制，在输入图像的 Patch Token 中引入可学习的模态特征，使 Transformer 能够识别 RGB 和 IR 之间的特征分布差异，从而有效缩小模态间的特征鸿沟。此外，为了进一步优化模态对齐，提出了模态感知增强损失 (Modality-Aware Enhancement Loss, MAE)，其中包含模态感知中心损失 (降低同一身份在不同模态下的特征距离) 和模态感知 ID 损失 (扩大不同身份之间的区分度)，从特征分布的角度增强跨模态的判别能力。

此外，在此项研究中，CMTR 的 Transformer 结构能够适应不同尺度的行人目标，并在特征空间中建立更稳定的跨模态关联。在传统 CNN 结构中，由于池化操作的限制，不同模态间的特征对齐通常依赖于额外的网络设计，如双流 CNN 或特征变换模块。而 CMTR 依靠自注意力机制，无需额外的模态变换模块，就能够直接学习模态不变特征，并通过模态嵌入机制有效捕捉 RGB 和 IR 图像中的独特信息。

为了验证 CMTR 的有效性，在这个研究中，在 SYSU-MM01 和 RegDB 公开数据集上进行了实验。结果表明，CMTR 在 Rank-1 识别率和 mAP 指标上均显著超越了现有的 CNN 方法，尤其在跨模态匹配任务中展现了更优越的识别性能。作为首个基于 Transformer 结构的 VI-ReID 方案，CMTR 充分发挥了 Transformer 在长距离依赖建模和全局信息捕捉方面的优势，为跨模态行人重识别提供了一种新思路，并有望推广至其他跨模态视觉任务。


2.3.2 SPOT

图 2-7 SPOT 网络框架^[51]

在跨模态行人重识别（VI-ReID）任务中，由于可见光（RGB）和红外（IR）图像之间的巨大视觉差异，以及姿态变化、遮挡等因素的影响，传统方法主要致力于学习全局共享特征。然而，这些方法通常采用全局表征或均匀划分的局部特征提取方式，对特征错位较为敏感，难以有效对齐跨模态特征分布。在这个研究中，提出了一种结构感知位置网络^[51]，通过利用人体结构和位置信息，学习更具语义可共享性的模态特征，从而提升跨模态匹配的鲁棒性。

如图 2-7 所示，SPOT 主要包括两个核心组件：注意力结构表示和基于 Transformer 的局部交互。通过建模人体结构特征，提取与身份相关的结构信息，并在结构引导下动态选择具有辨识度的外观区域，有效抑制复杂背景噪声的影响。此外，采用 Transformer 结构建模人体各部位之间的上下文和位置信息，通过对局部特征进行交互学习，提升跨模态的判别能力，并增强模型在姿态变化和遮挡情况下的适应性。SPOT 充分挖掘了人体的语义结构信息，在捕获细粒度特征的同时，显著降低了跨模态特征分布的不一致性。在 SYSU-MM01 和 RegDB 数据集上的实验表明，SPOT 在 Rank-1 识别率和 mAP 指标上均超越了当前最先进的方法，尤其在跨模态匹配任务中展现了更强的鲁棒性。该研究为 VI-ReID 任务提供了一种新的方法思路，并有望为其他跨模态视觉任务的研究提供借鉴。

2.3.3 DFLN-ViT


图 2-8 DFLN-ViT 网络框架^[52]

在跨模态行人重识别任务中，由于可见光（RGB）与红外（IR）图像之间的显著视觉差异，现有方法通常依赖卷积神经网络（CNN）提取特征，并通过特征嵌入网络将异构特征投影到同一特征空间。然而，传统方法往往忽略了单个样本内部不同位置和通道之间的潜在关联，导致特征表达能力受限。受 Transformer 在计算机视觉领域成功应用的启发，在这个研究中，提出了一种基于视觉 Transformer 的判别性特征学习网络（DFLN-ViT）^[52]，通过增强跨位置和跨通道的信息交互，有效提升 VI-ReID 任务的特征表达能力。

如图 2-8 所示，DFLN-ViT 主要由三个核心模块组成：空间特征感知模块、通道特征增强模块和三元组辅助异构中心损失。首先，空间特征感知模块采用 Transformer 结构，并结合新的 patch 嵌入策略，捕获不同位置之间的长距离依赖关系，从而增强跨模态特征的空间表达能力。相比传统的 CNN 结构，该模块可以更有效地建模全局位置信息，避免局部感受野的限制。其次，通道特征增强模块关注不同通道特征之间的联系，利用 Transformer 将通道特征序列化并进行信息交互，使得模型能够从全局角度建模长程通道依赖，进而优化跨模态特征的判别能力。此外，针对跨模态特征之间的分布差异三元组辅助异构中心损失在优化过程中同时考虑了跨模态距离和模态内部类别间的相似性，从而促进特征空间的一致性，提高模型的检索性能。

在 SYSU-MM01 和 RegDB 数据集上的实验结果表明，DFLN-ViT 在 Rank-1 识别率和 mAP 指标上均超越了当前主流方法，证明了所提方法的有效性。与传统 CNN 结构相比，该方法通过 Transformer 进一步挖掘了空间和通道维度的潜在关联，从而增强了跨模态特征的判别能力和鲁棒性。这项研究为 VI-ReID 任务提供了一种新的解决方案，同时也为其他跨模态视觉任务的研究提供了新的思路。

2.3.4 PMT

图 2-9 PMT 网络架构^[53]

模态差异是影响行人重识别性能的关键因素之一，尤其是在可见光（RGB）与红外（IR）图像之间，由于成像机制不同，导致数据分布存在巨大差异，给模型的特征提取与匹配带来了极大挑战。在这个研究中，提出了一种新的深度学习框架 Progressive Modality-shared Transformer（PMT）^[53]，通过逐步学习策略有效缓解模态差异，并增强模态共享特征的稳定性，从而提升 VI-ReID 任务的识别性能。

如图 2-9 所示，PMT 主要包含三个关键部分：逐步模态共享学习策略、模态共享增强损失和判别中心损失。首先，考虑到 RGB 与 IR 之间存在较大的模态差异，而灰度图像能够在一定程度上缓解这一差异，PMT 在训练过程中引入灰度图像作为辅助模态，并采用逐步学习策略。具体而言，在第一阶段，模型首先学习灰度图像和红外图像的模态独立特征，以减少干扰信息的影响；在第二阶段，模型再利用 RGB 和 IR 图像进一步优化模态共享特征，从而实现更稳定的跨模态特征对齐。其次，为了进一步提升跨模态特征的可靠性，PMT 设计了模态共享增强损失。该损失函数通过约束模态共享特征的学习过程，使模型能够更多地关注身份相关的信息，避免受模态差异的干扰。

在 SYSU-MM01 和 RegDB 数据集上的实验表明，PMT 在 Rank-1 识别率和 mAP 指标上均取得了显著的性能提升，超过了当前多数主流方法。此外，PMT 还具有良好的泛化能力，不仅适用于 Transformer 架构，在应用于 CNN 结构时同样能够带来显著的性能提升。这项研究证明了逐步模态共享学习策略的有效性，为 VI-ReID 任务提供了一种新的解决思路，并为未来探索更强大的 Transformer 结构以提升特征表达能力提供了参考方向。

2.4 优化目标与评估方法

2.4.1 损失函数

损失函数在行人重识别模型训练过程中发挥着至关重要的作用，用于衡量模型预测结果与真实标签之间差异程度，通过损失函数最小化来修正模型参数，从而让模型能够更好地学习出行人特征的判别性表示。

行人重识别的损失函数主要有交叉熵损失（Cross Entropy Loss）、三元组损失（Triplet Loss）、中心损失（Center Loss）等。

交叉熵损失是一种广泛应用的分类损失函数，对于行人重识别任务，每个行人属于其中一个类别，模型的目的是将输入的行人图像准确分类到其对应的类别中，交叉熵损失为：

$$L_{CE} = - \sum_{i=1}^N \sum_{j=1}^C y_{ij} \log(p_{ij}) \quad (2-8)$$

其中， N 是样本数量， C 是类别数量， y_{ij} 是样本，其中 i 属于类别 j 的真实标签(通常为 0 或 1)， p_{ij} 是模型预测样本 i 属于类别 j 的概率。交叉熵损失促使模型提高正确分类的概率，降低错误分类的概率，从而使模型能够准确地对行人身份进行分类。

三元组损失通过构建三元组(目标样本 a 、正样本 p 、负样本 n)来学习特征的判别性。其核心思想是使目标样本与正样本(属于同一行人)的特征距离尽可能小，同时使目标样本与负样本(属于不同行人)的特征距离尽可能大。三元组损失的计算公式为：

$$L_{Triplet} = \max(\|f(a) - f(p)\|_2^2 - \|f(a) - f(n)\|_2^2 + \alpha, 0) \quad (2-9)$$

$f(\cdot)$ 表示特征提取函数， $\|\cdot\|_2^2$ 是欧氏距离的平方， α 是一个超参数，称为边际(margin)，用于控制正样本与负样本之间的距离差的下限。通过最小化三元组损失，模型能够学习到更具区分性的特征表示，使得同一行人的特征在特征空间中更加聚集，不同行人的特征更加分散。

中心损失是通过对类别中心进行构建，使得每个类别在特征空间中的特征尽可能的靠近其类别中心，即可以提高特征的类内紧凑性，类别中心通过对每个类的所有样本的特征进行取平均值获得。中心损失的计算公式为：

$$L_{Center} = \frac{1}{2} \sum_{i=1}^N \|f(x_i) - c_{y_i}\|_2^2 \quad (2-10)$$

其中， x_i 是样本， y_i 是样本 x_i 的类别标签， c_{y_i} 是类别 y_i 的中心， $f(x_i)$ 是样

本 x_i 的特征表示。

在行人重识别的任务中，交叉熵损失原理简单，在数据丰富且类别平衡时分类性能佳，适用于注重分类准确性场景，但它缺乏对特征距离的度量且易过拟合。三元组损失能直接度量特征距离，提升特征匹配精度，适用于小样本及注重特征匹配的情况，不过其训练难度大且计算效率低。中心损失可增强类内紧凑性，常与其他损失函数互补使用，适合类别内差异较大的任务，然而它存在中心更新不稳定以及对类别数量敏感的问题。因此，将中心损失、交叉熵损失和三元组损失结合使用，可以在提高分类准确性的进一步增强特征的判别性。在实践训练中，为了平衡不同损失函数的作用，通常会采用加权求和的方式组合多个损失函数，如

$$L = \omega_1 L_{CE} + \omega_2 L_{Triplet} + \omega_3 L_{Center} \quad (2-11)$$

其中 $\omega_1, \omega_2, \omega_3$ 是权重系数，通过调整这些系数来优化模型性能。

2.4.2 评价指标

评价指标是衡量行人重识别算法性能的重要依据，常见的评价指标包括准确率（Accuracy）、召回率（Recall）、平均准确率均值（Mean Average Precision, mAP）和累计匹配特性曲线（Cumulative Matching Characteristic, CMC）等。

准确率（Accuracy） 是正确识别的样本数量占总样本数量的比例，计算公式为：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-12)$$

其中，TP 表示真阳性样本数量（即被正确识别为正样本的样本数量），FP 表示假阳性样本数量（即被错误识别为正样本的样本数量），TN 表示真阴性样本数量，FN 表示假阴性样本数量。准确率反映了模型识别结果的正确性，但在行人重识别任务中，由于样本分布不均衡等原因，准确率可能无法全面准确地评估算法性能。

召回率（Recall） 是指正确识别的正样本数量占实际正样本数量的比例，反映了模型对正样本的覆盖程度，即能够正确识别出多少真正的正样本。计算公式为：

$$Recall = \frac{TP}{TP + FN} \quad (2-13)$$

其中，FN 表示假阴性样本数量（即被错误识别为负样本的正样本数量）。

平均准确率均值（Mean Average Precision, mAP） 是指不同召回率下的平

均准确率,对模型在不同阈值下的性能进行综合评价,mAP 的评价过程较为复杂,计算不同召回率下每个查询样本的平均准确率,再将所有查询样本的平均准确率取平均值。mAP 是较为全面的一种评价指标。行人重识别中 mAP 是一个很直观的评价指标,能从整体上衡量算法在数据集上的性能。

累计匹配特性曲线 (Cumulative Matching Characteristic, CMC) 对于 CMC 曲线,其计算涉及到不同排名下的正确匹配概率。假设在一个行人重识别任务中,有 N 个查询样本,对于每个查询样本,我们计算其在不同排名 k 下的正确匹配情况。令 $C(k)$ 表示在排名 k 及之前能够正确匹配到目标行人的查询样本数量,则 Rank - k 准确率的计算公式为:

$$\text{Rank} - k\text{Accuracy} = \frac{C(k)}{N} \quad (2-14)$$

CMC 曲线通常可以反映算法在给定的数据集中,在多大的准确率下运行^[19]。CMC 曲线由多个概率值组成,如 Rank-1 表示排名 1 的图像被目标行人匹配的概率 acc ; Rank- k 表示排名前 k 个图像中,目标行人至少有一个匹配概率。CMC 曲线可以直观地衡量算法在不同检索精度下的性能,便于研究者对算法进行综合分析。

2.4.3 评价模式

在评价模式上,行人重识别中较为常见的有两种评价模式,为封闭集评价和开放集评价^[26]。顾名思义,封闭集评价是指测试集中所有的行人身份在训练集中均有对应的身份,也就是说模型在训练集中的表现是非常好的,在测试集中的表现也是很好的。在封闭集评价中,比较注重模型对已知行人的识别准确率和召回率等。相对来说,封闭集评价较为容易,可以一定程度上衡量模型的基本性能。实际的场景应用中,并不是所有的行人都出现在训练集中,有时可能会出现一个在训练集中未出现的行人,这称为开放集。开放集中测试集的行人身份可以是训练集中未出现的。在开放集评价中,不仅要评估模型对已知行人的识别率,还要评估模型对新行人的拒识率,也就是能够正确地预测出某个行人是否是训练集中未出现过的新行人。

开放集评价一般使用等错误率等指标来评估模型的整体性能,EER 指错误接受率和错误拒绝率相等时的概率,表示模型将实际接受的正确样本和拒绝错误样本之间的平衡。基于注意力机制的行人重识别注意力机制在行人重识别领域的应用十分普遍,其核心在于让算法模型自觉地在进行图片行人重识别的过程中,关注图像中最佳的位置及特征。在基于注意力机制的行人重识别方法中,注意力模块主要包括通道注意力模块和空间注意力模块。

2.5 本章小结

本章围绕行人重识别任务的核心理论进行了系统介绍。首先，阐述了行人重识别的基本流程，包括数据预处理、特征提取、度量学习及检索匹配等关键步骤，为理解后续方法奠定基础。随后，介绍了 Transformer 及 Vision Transformer (ViT) 的基本概念，分析其在计算机视觉任务中的应用优势，并探讨其在行人重识别中的适应性。接着，梳理了跨模态行人重识别的经典算法，分析各自的优缺点及其解决跨模态匹配问题的能力。此外，介绍了行人重识别的优化目标，包括主流损失函数，如三元组损失、中心损失等，并总结了 Rank-1、mAP 等评价指标及其在跨模态任务中的应用。

第三章 基于视觉提示对齐的跨模态行人重识别

3.1 引言

行人重识别技术在公共安全及摄像头监控领域发挥着至关重要的作用。然而，现有的行人重识别方法大多仅聚焦于白天场景下的应用，严重忽视了弱光环境中的复杂情况^[35]。将行人重识别单纯当作单模态问题来处理是不合理的，这种局限性不可避免地导致现有方法在弱光条件下性能欠佳。为有效解决这一问题，跨模态行人重识别研究任务应运而生。在跨模态研究中，基于可见光与红外的行人重识别占据了主导地位。鉴于可见光与红外图像特征差异显著，现有方法虽能在一定程度上缓解模态干扰，却多简单剔除模态特定信息，忽视其潜在价值^[36]。不同行人穿着图案和材质相似的衣服，该因素直接影响红外图像中相应区域的亮度。实际上，不同模态特定信息很可能存在潜在对应关系，比如红外图像更能体现行人服饰的纹理细节，而热成像图因人体温度差异可以呈现出不同的轮廓特征。因此，单纯剔除模态特定信息并不合理，这无法发挥跨模态数据融合优势，限制了行人重识别技术在复杂场景下性能的提升。

因此，本文围绕基于 RGB 图像、红外图像展开行人重识别任务的研究，旨在充分利用模态不变信息与特定于模态的信息，以实现更优的识别效果。然而，特定于模态的信息不可避免地会引发模态间的语义差异，这一差异使得模型在同时适应和处理不同模态输入时面临挑战。与此同时，针对不同模态输入采用单独的模型并非理想选择，因为该方式难以充分挖掘模态不变信息，进而导致模型表征能力不足。过往研究表明^[37]，视觉提示具备保留骨干模型内在基本知识的能力。与此同时，视觉提示能够通过特定于小模态的提示，对模型进行有效调适，助力模型灵活适应不同模态并充分利用特定于模态的信息^[38]。

3.2 视觉提示学习 (Visual Prompt Learning)




图 3-1 传统多模态追踪与基于提示学习的多模态追踪

受自然语言处理领域中中文本提示成功的启发^[40], 视觉提示学习在众多计算机视觉任务中得以广泛应用。例如, VPT^[41]设计出一组可学习向量, 并将其适配到每个编码层的输入序列, 在 24 个下游识别基准测试里, 获得了优于或等同于其他方法的结果。在为视觉 Transformer (ViT) 引入轻量级模块性能表现超越了全量微调模型。Convass^[43]则提议采用卷积旁路, 实现了对已验证 ViT 的提示学习。Zhu 等人^[44]将提示学习融入多模态追踪领域, 充分展示了该方法在多模态任务中的有效性。如图 3-1 所示, 与传统的多模态追踪相比, ViPT 没有进行完全微调, 而是冻结了主干模型, 使用一组特定的可学习提示进行微调, 最大程度地利用大规模预训练的基础模型, 并挖掘下游跟踪的相关性以及多种模态之间的互补性。以上研究表明, 在将原始模型适配其他任务时, 视觉提示学习展现出巨大潜力, 因此将视觉提示学习引入跨模态行人重识别领域的方法。

现有方法通过简单地关注模式不变信息, 同时消除了模式特定的信息, 忽略了特定于模态特定信息的潜在利用, 从而减轻了模式差距的干扰。本文注意到模式特定信息之间可能存在潜在的对应关系, 这也可以有助于重新识别。例如, 可见光图像的服装类型/材料等特征可能会影响热辐射强度, 从而影响红外亮度变化。基于这个想法, 在这项工作中, 本文试图引导模型保存和使用特定于模态的信息。因此, 本文尝试使用特定的提示来针对不同的模态输入, 以探索跨模态行人重识别中视觉提示学习的应用。

3.3 网络设计

为了解决 3.2 中出现的问题, 本文提出了基于视觉提示对齐的跨模态行人重识别模型结构。如图 3-2 所示, 关键部分主要包括视觉提示生成, 多模态提示融合, 以及基于 VPT 的微调模块。本模型首先将 RGB、红外图像分别输入图像的嵌入层, 得到各自的向量表示; 其次利用视觉提示生成模块, 生成对应的提示向量; 之后结合各模态的提示向量融合得到最终的视觉提示向量, 并将其与每一层 Transformer 的编码器相连; 最终通过视觉提示学习的手段, 不改变 ViT 主干参数, 来降低模型训练成本, 提高模型的效率。

主体框架采用基于 ImageNet 预训练的 Vision Transformer(ViT)的方法进行训练, 其中输入图像表示为 $x_M \in R^{C \times H \times W}$, 其中 C 表示通道维度, H 表示图像的高度, W 表示图像的宽度, $M \in \{vi, ir\}$, M 表示图像的模态标识。对于每一个输入图像 x_M , 将其分割成图像序列 $S_M \in R^{L \times C \times b \times b}$, 其中 L 表示图像序列的长度, b 表示图像块的尺寸。将图像序列 S_M 通过嵌入层 $E_m^0 \in R^{L \times D}$, 其中 D 表示嵌入层的维度。引入一组可学习的分类标记 A^0 与嵌入层 E_m^0 串联, 得到 $[A^0, E_m^0]$, 送入




图 3-2 基于视觉提示对齐的跨模态行人重识别模型结构

Transformer 的编码层中，作为第一层的初始输入，其中 $[\cdot]$ 表示串联操作。因此，将 Transformer 的编码层表示为：

$$[A^{i+1}, E_m^{i+1}] = l_i([A^0, E_m^0]) \quad (3-1)$$

其中 A^{i+1} 和 E_m^{i+1} 分别表示为第 i 层的输入标记和输出的嵌入层， $i = 1, 2, \dots, n$ 。

在经过视觉提示生成和融合后，得到跨模态的视觉提示，将其与每个 Transformer 的编码层进行串联，得到：

$$[A^{i+1}, E_m^{i+1}, _] = l_i([A^i, E_m^i, p^i]) \quad (3-3)$$

$$p_i = [p_i^{IR}, p_i^I] \quad (3-3)$$

其中视觉提示 $p_i = [p_i^{IR}, p_i^I]$ ，其跨模态视觉提示 p_i^{IR} 与模态融合后的 p_i^I 分别在 3.3.1 和 3.3.2 中表示， l_i 表示第 i 层 Transformer 的编码层， $i = 1, 2, \dots, n$ ，包括多头自注意力机制（Multi-head Self-Attention, MSA）归一化层（LayerNorm, LN）和前馈神经网络（Feed-Forward Network, FFN），具体内容已在 2.2.1 中进行概述。

3.3.1 视觉提示生成模块

如图 3-3 所示，为了充分获得红外图像与 RGB 图像的对应特征的信息，本文提出了视觉提示生成模块（Visual-Prompt Generation, VPG），模块为初始化和更新提示学习向量提供重要信息。

在通过分别的嵌入层后，得到 RGB 图像与红外图像的向量表示，初始提示标记（prompt token）分别表示为

$$P^{IR} = \{p_i^{vi}, p_i^{ir}\}_{i=1}^N \quad (3-4)$$




图 3-3 视觉提示生成模块

其中 N 表示 Transformer 编码器的层数, $p_i \in R^{j \times D}$, 其中 j 表示各个提示标记的长度, p_i^{vi}, p_i^{ir} 分别表示可见光图像、红外图像的第 i 层的提示标记。在将输入嵌入到每一层编码器之前, 视觉提示生成模块根据输入图像的模态标签以及要输入的图层索引, 从预先构建的模态特定提示库中选择目标模态特异性提示。这一选择过程是基于对模态信息和网络层次的精确判断, 旨在为每个编码器层提供最适合的提示信息。在完成提示选择之后, 所选的模态特异性提示需要经过进一步的处理才能与输入数据进行有效的融合。具体来说, 这些提示会通过一个线性层进行投影操作。线性层投影的目的是对提示进行维度调整和特征变换, 使其能够更好地与输入数据进行匹配和融合。经过投影后的提示向量将与输入数据进行串联操作, 从而将模态特定的信息融入到输入数据中, 为后续的编码器层提供更丰富和更具针对性的特征表示。上述处理过程可以用以下数学公式进行准确描述:

$$p_i^{IR} = \Gamma(P^{IR}, m, i) \quad (3-5)$$

其中 Γ 表示视觉提示生成模块的选择操作, 它根据模态标签 m 和每层的索引 i 从模态提示 P^{IR} 中选择合适的提示。具体选择规则如下:

$$\Gamma(P^{IR}, m, i) = \begin{cases} p_i^{vi}, & \text{if } m = vi \\ p_i^{ir}, & \text{if } m = ir \end{cases} \quad (3-6)$$

其中当模态标签 m 为可见光 (vi) 时, 选择可见光提示 p_i^{vi} ; 当模态标签 m 为红外 (ir) 时, 选择红外提示 p_i^{ir} 。经过选择得到的提示 $\bar{p}_i^{IR}$ 还需要通过一个提示投影线性层 $\varphi(\cdot)$ 进行投影操作, 最终得到用于与输入数据串联的模态特定提示 p_i^{IR} , 其数学表达式为:

$$p_i^{IR} = \varphi(\bar{p}_i^{IR}) \quad (3-7)$$

其中参数 i 的取值范围是 $i = 1, \dots, N$, 表示从第 1 个编码器层到第 N 个编码器层。通过这样的设计和处理流程, 视觉提示生成模块能够有效地利用模态特定提示, 为模型在不同模态数据上的特征学习提供有力的支持, 从而提升模型在多模态任务中的性能表现。

3.3.2 提示互补融合模块

如图 3-4 所示, 提示互补融合模块 (Modality-Prompt Combination, MPC) 包含三部分, 首先将得到的可见光图像提示 p_i^{VI} 和红外图像提示 p_i^{IR} 投影到较低的潜在嵌入; 其次产生跨模态的内部互补表示; 最后投影到原始维度并生成可学习的跨模态视觉提示 p^{IR} 。具体操作如下:

$$U^{vi} = g_1(p_i^{VI}) \quad (3-8)$$

$$c = g_2(p_i^{IR}) \quad (3-9)$$

考虑只有可见光的提示向量具有一定的冗余特征, 并且提示块应具有尽可能少的参数, 因此 $g(\cdot)$ 为 1×1 的卷积。将 p_i^{VI} 和 p_i^{IR} 投影到 1×1 的卷积, 得到 U^{vi} 和 U^{ir} 。基于红外图像模态的融合, 引入 λ 平滑的空间 softmax 函数, 通过空间注意力掩码的 U^{fovea} , 得到提示信息增强的嵌入 U 。




图 3-4 提示互补融合模块

$$U = U^{vi} \odot U^{ir} \quad (3-10)$$

$$U^{fovea} = \left\{ \frac{e^{U^{vi}}}{\sum e^{U^{vi}}} \lambda \right\} \quad (3-11)$$

$$p^{IR} = g_3(U + U^{ir}) \quad (3-12)$$

3.3.3 损失函数

在模型训练中，为了提升跨模态行人重识别的性能，本文采用混合损失函数来优化学习框架，使模型能够充分学习跨模态匹配所需的判别性特征。具体而言，我们在训练的不同阶段引入了不同的损失函数，以实现更加稳定和高效的特征学习。使用交叉熵损失函数 L_{ID} 和三元组损失 L_{TRI} ，损失函数定义如下：

$$L_1 = L_{ID} + L_{TRI} \quad (3-13)$$

交叉熵损失用于增强模型的分类能力，使其能够正确区分不同身份的行人，而三元组损失则通过度量学习的方法，进一步优化同一身份样本之间的相似度，同时拉开不同身份样本的距离，从而提升模型对行人特征的判别能力。为了进一步提取可靠特征，引入 L_{IAEL} 进行优化，整体的损失函数表达为：

$$L_L = \alpha_1 L_1 + \alpha_2 L_{IAEL} \quad (3-14)$$

其中， α_1 和 α_2 为超参数。

3.4 实验与结果分析

3.4.1 数据集




图 3-5 数据集 SYSU-MM01

SYSU-MM01^[64]: 数据集在多模态行人重识别研究领域具有重要地位。如图 3-5 所示, 该数据集涵盖了 491 位行人的图像数据, 共计包含 286,628 张可见光图像以及 15,792 张红外图像, 这些图像均由 4 个可见光摄像机和 2 个红外摄像机所捕获。为便于模型的训练与评估, 数据集被严谨地划分为训练集与测试集两个部分。在训练集当中, 一共纳入了 395 位行人的图像数据, 具体包括 22,258 张可见光图像以及 11,909 张红外图像。这些丰富多样的图像样本, 为模型在训练阶段学习行人在不同模态下的特征模式提供了充足的数据支撑。而测试集则包含了 96 位行人的图像, 其中 3,803 张红外图像被专门挑选出来作为查询图像, 以便在后续的模式测试过程中, 用于检索与之匹配的行人图像。同时, 从可见光图像中随机选取一定数量的图像作为画廊图像, 以此构建测试场景中的待匹配图像库。



图 3-6 数据集 RegDB

REGDB^[65]: 数据集同样是多模态行人重识别研究中常用的重要数据集。如图 3-6 所示该数据集由 412 位行人的图像构成, 其中包含 4,120 张可见光图像以及 4,120 张红外图像, 这些图像均由一台可见光相机和一台红外摄像机捕获。值得注意的是, 每位行人在数据集中均对应应有 10 张可见光图像和 10 张红外图像, 这种相对均衡且标准化的样本采集方式, 为研究模型在相同行人数量、相同图像数量配置下的多模态识别性能提供了便利。与 SYSU-MM01 数据集类似, RegDB 数据集也进行了训练集与测试集的划分。训练集随机选取了 206 位行人的图像, 这些图像作为模型训练的基础数据, 用于引导模型学习行人在可见光和红外两种模态下的特征表达。测试集则包含了剩余 206 位行人的图像, 用于评估模型在未见过的数据上的识别能力。

3.4.2 实验设定

本次实验旨在全面且深入地验证多模态视觉提示对齐的有效性与性能表现。实验环境基于 Pytorch 框架搭建，实验室环境配置为 NVIDIA RTX3090 GPU 的计算平台。在模型架构选择上，采用在 ImageNet^[72]大规模数据集上预先训练的视觉 Transformer^[35]作为骨干网络。训练期间，输入图像被调整大小为 256×128，并运用包括随机裁剪、颜色抖动、随机擦除以及灰度变换在内的数据增强方法对输入图像进行变换。批次设置为 64。采用随机梯度下降（SGD）优化器对模型进行 80 个 epoch 的训练，初始学习率为 1.0×10^{-2} 。学习率将按照余弦衰退方式衰减，其中最小学习率为 1.0×10^{-5} ，动量参数为 0.9，衰减率为 0.1。

3.4.3 与目前方法的对比

为了验证基于视觉提示对齐的跨模态行人重识别的有效性，本小节在 SYSU-MM01 和 RegDB 两个数据集上，对当前主流的跨模态行人重识别方法进行了对比分析。

表 3-1 SYSU-MM01 数据集下的与当前算法的比较

Settings	All Search			Indoor Search		
Method	r=1(%)	r=10(%)	mAP(%)	r=1(%)	r=10(%)	mAP(%)
Zero-Pad ^[45]	14.82	54.12	15.95	20.58	68.38	26.92
cmGAN ^[55]	26.97	67.51	31.49	31.63	77.23	42.19
FMCNet ^[60]	61.68	93.15	57.51	63.41	91.96	68.17
AlignGAN ^[47]	42.40	85.85	40.71	45.90	87.64	54.31
DDAG ^[57]	54.75	90.39	53.02	61.02	94.06	67.98
NFS ^[46]	56.91	91.34	55.45	62.79	96.53	69.79
CM-NAS ^[58]	61.99	92.87	60.02	67.1	97.02	72.95
AGW ^[59]	47.54	84.39	47.65	54.17	91.14	62.97
SPOT ^[51]	65.34	92.73	62.25	69.42	96.22	74.63
OURS	70.64	93.48	64.67	72.26	97.18	75.66

SYSU-MM01 数据集上的评估结果：为了全面验证所提跨模态行人重识别方法的性能表现，本文在多个主流方法上进行了横向对比，相关结果展示于表 3-1 中。由表中结果可知，在全局检索模式（All-Search）下，所提方法的 Rank-1 识别率达到 70.64%，mAP 为 64.67%；在室内检索模式（Indoor-Search）下，Rank-1 识别率和 mAP 分别为 72.26%和 75.66%。整体结果显示，该方法在各项指标上均优于现有主流方案，展现出较强的综合性能。

进一步分析表中数据可以发现，相较于传统的跨模态行人重识别方法，本

文方法在多个关键评价指标上均取得了显著提升。基于视觉提示学习的跨模态行人重识别策略能够有效缓解模态差异问题，增强不同模态数据之间的特征对齐能力，从而提高模型的鲁棒性和识别精度。与此同时，采用多尺度特征融合策略进一步优化了跨模态匹配效果，使得模型在复杂场景下仍能保持较高的检索准确率。

此外，通过对比不同方法的性能指标可以观察到，所提方法在 Rank-1 准确率和 mAP 方面均显著优于其他现有的先进跨模态行人重识别算法，特别是在全搜索模式下，性能优势尤为明显。这表明，本文提出的方法能够更有效地提取跨模态行人身份特征，增强跨模态匹配的鲁棒性，并在跨模态行人重识别任务中达到了目前先进的水平。

表 3-2 RegDB 数据集上与当前算法的比较

Settings	Visible to Infrared			Infrared to Visible		
Method	r=1(%)	r=10(%)	mAP(%)	r=1(%)	r=10(%)	mAP(%)
Zero-Pad ^[45]	17.75	34.21	18.90	16.63	34.68	17.82
cmGAN ^[55]	-	-	-	-	-	-
XIV ^[56]	62.21	83.13	60.18	-	-	-
AlignGAN ^[47]	57.90	-	53.60	56.30	-	53.40
DDAG ^[57]	69.34	86.19	63.46	68.06	85.15	61.80
NFS ^[46]	80.54	91.96	72.10	77.95	90.45	69.79
CM-NAS ^[58]	84.54	95.18	80.32	82.57	94.51	78.31
AGW ^[59]	70.05	86.21	66.37	70.49	87.12	65.90
DFLN-ViT ^[48]	84.29	-	80.79	88.11	-	80.68
SPOT ^[51]	79.37	92.73	72.26	80.35	93.48	72.46
OURS	84.74	96.71	84.15	87.60	97.18	81.07

REGDB 数据集上的评估结果：本文方法与已有的跨模态行人重识别方法进行了对比，相关结果如表 3-2 所示。从表中数据可见，在红外到可见光的映射任务中，所提方法在 Rank-1 准确率和 mAP 方面分别达到了 84.74%和 84.15%；而在可见光到红外的映射任务中，Rank-1 准确率和 mAP 则分别达到 87.60%和 81.07%。DFLN-ViT 取得优异性能的原因可能在于，其结构感知机制能够有效对 RegDB 数据集中相对简单的图像进行人物结构的对齐建模，从而提升了匹配效果。

3.4.4 消融实验

在本章中进行了一系列消融实验来验证视觉提示对齐模块的有效性。首先

将该方法与一般的提示方法进行比较，随后讨论基于视觉提示学习的必要性，所有实验都是在 SYSU-MM01 当中进行的。

为了验证基于视觉提示对齐的跨模态行人重识别算法的有效性。将其分为两个组成部分：视觉提示生成与视觉提示融合，分别进行训练并评估性能。

表 3-3 SYSU-MM01 数据集上的消融实验

方法	模块		All-Search		Indoor-Search	
	VPG	MPC	Rank-1	mAP	Rank-1	mAP
1 (Base)	×	×	40.49	40.93	41.76	49.12
2	✓	×	63.77	60.10	73.28	74.83
3	×	✓	52.98	52.75	62.14	65.75
4 (Full)	✓	✓	70.64	64.35	72.26	75.66

如表 3-3 所示，在 SYSU-MM01 数据集上，本研究通过逐步加入 VPG 模块、MPG 模块，通过对所提出方法进行系统评估，并结合实验结果分析其性能提升趋势，可以看出，相较于基线模型方法 1，添加 VPG 模块后的方法 2 在 Rank-1 和 mAP 方面分别提高了 23.28%和 19.17%，说明 VPG 模块在增强特征表征方面发挥了重要作用。方法 3 采用基线+MPG 作为模型，相较于基线模型，Rank-1 和 mAP 分别提升了 12.49%和 11.82%，表明 VPG 模块对于跨模态对齐具有良好的促进作用。在此基础上，方法 4 同时结合 VPG 和 MPG 两个模块，与单独使用这两个模块的模型相比，进一步带来了 3.44% Rank-1 和 11.60% mAP 的提升，表明二者具有较好的互补性。这一结果验证了视觉提示学习的有效性，它能够进一步优化跨模态行人重识别任务中的模态自适应能力。

表 3-4 RegDB 数据集上的消融实验

方法	模块		Infrared to Visible		Visible to Infrared	
	VPG	MPC	Rank-1	mAP	Rank-1	mAP
1 (Base)	×	×	80.14	80.2	85.05	79.16
2	✓	×	83.64	82.89	86.81	80.27
3	×	✓	82.26	82.43	84.17	80.86
4 (Full)	✓	✓	84.74	84.15	87.60	81.07

为了进一步验证方法的泛化能力，本研究在 RegDB 数据集上进行了相同的消融实验，并得到了类似的趋势。如表 3-4 所示，实验表明 VPG 和 MPG 模块均能独立提升基线模型的性能，证明了它们在跨模态特征学习中的有效性。同时，视觉提示学习的引入进一步增强了模型对不同模态数据的适应能力，使得最终模型在 Rank-1 和 mAP 方面均达到了最佳表现。整体来看，无论在 SYSU-MM01 还是 RegDB 数据集上，本文提出的 VPG 和 MPC 模块都能协同作用，在提高特征判别能力、增强跨模态对齐以及优化整体行人重识别性能方面发挥了重要作用。

3.5 可视化分析

3.5.1 检索结果

为本章从 SYSU-MM01 跨模态行人重识别数据集中选取了若干具有代表性的查询图像样本，并对其检索结果进行了可视化分析，如图 3-7 所示，展示了室内搜索模式下的检索结果。在可视化展示中，每一行的最左侧图像为查询图像，其右侧依次为根据与查询图像的特征相似度排序后的检索结果图像。排序结果中，相似度越高的图像排列越靠前，即最左侧的检索图像与查询图像之间的特征相似度最高。为了更直观地反映检索效果，图中对结果图像进行了颜色标注：绿色边框用于标示识别正确的图像，红色边框则用于标示被错误识别的图像。




图 3-7 检索的可视化结果

从图示结果可以明显看出，在大多数情况下，所提出的方法能够在 Rank-10 范围内返回准确的匹配图像，表现出较强的跨模态检索能力。这说明模型在不同模态之间的特征对齐与判别方面具有良好的性能。然而，仍存在一些特殊情形影响整体表现。例如，在第 5 幅查询图像对应的检索结果中，Rank-10 返回结果中包含了 4 幅来自其他行人的图像，表现出较高的误检率。进一步分析可能发现，这一性能瓶颈主要源于基于 Vision Transformer (ViT) 架构的模型在处理模态差异较大或姿态变化显著的图像时，所提取的特征在判别性上仍有所欠缺，导致误匹配现象的发生。

针对上述问题，未来的工作可从多个方向入手优化模型性能，包括设计更高效特征对齐策略、引入细粒度的结构信息建模机制，以及融合多尺度语义信息，以进一步提升特征的判别力和跨模态适应能力，从而增强整体检索精度和系统鲁棒性。

3.5.2 t-SNE 可视化分析




图 3-8 基于 t-SNE^[54]的可视化

为了直观地分析这一发现，本研究在图 3-8 中展示了基于 t-SNE^[54]的可视化结果，对比了 VPG 模块与 MPC 模块所生成的基于视觉的提示信息。实验中随机采样了 10 名不同行人的 200 张图像，并用不同颜色的点表示不同的行人。从图 3-9 可以看出，VPG 生成的提示信息在同一行人内部具有明显的聚集性，同时不同行人之间存在清晰的边界。并且融合式 MPC 生成的提示信息则分布也呈现出相似的结果。这一结果表明，与融合式 MPC 相比，生成式 VPG 生成的提示信息具有更强的样本感知能力，能够更精细地捕捉个体特征，从而更有效地辅助跨模态行人重识别任务。

3.5.3 注意力图可视化

为了更深入地分析基于视觉提示学习机制所关注的图像特征区域，并验证该机制在建模模态特定信息之间的隐式对应关系方面的有效性，本文对部分典型样本进行了可视化分析。具体如图 3-9 所示，在 SYSU-MM01 数据集上，分别对可见光图像与红外图像进行处理，并提取其经过本模型各阶段处理后的注意力图，进一步展示了视觉提示学习模块对不同模态图像所关注的区域分布。从图中可以观察到，视觉提示学习模块通过引入结构化设计的模态特定提示，显著增强了模型对不同模态特征的适应能力。该模块不仅能够引导模型在图像中关注于更具判别性的区域，还能够有效挖掘可见光与红外图像之间在面部细节、服饰纹理等关键区域上的潜在关联性，进而实现模态间隐式语义的对齐。具体而言，在可见光图像中，注意力主要集中于面部与上半身区域；而在红外图像中，尽管整体纹理信息受限，但模型依然能够对齐到与可见光图像相对应的重要结构区域，这充分体现了所提出方法对跨模态细节关系的建模能力。




图 3-9 Attention map 可视化 (SYSU-MM01)




图 3-10 Attention map 可视化 (RegDB)

此外，图 3-10 展示了在 RegDB 数据集上的可视化案例，同样展现出一致的趋势。无论是从关注区域的重合性，还是从细节层面的聚焦特征来看，视觉提示学习机制均表现出良好的泛化能力和对模态间语义一致性的建模能力。这些可视化结果进一步验证了本文所提方法在跨模态特征对齐任务中的有效性与适用性，也与本研究的设计初衷高度一致，即通过提示机制提升模型对不同模态输入之间语义关系的理解与建模能力，从而提升跨模态行人重识别性能。

3.6 本章小结

本章围绕基于视觉提示对齐的跨模态行人重识别展开研究，详细介绍了视觉提示学习的基本概念、网络设计以及实验分析。首先，本研究引入视觉提示学习，通过生成适应不同模态的提示信息，增强模型对模态特定特征的适应性。随后，在网络设计部分，提出了视觉提示生成模块和提示融合模块，视觉提示生成模块负责生成模态感知的提示信息，而提示融合模块进一步融合提示信息，以促进模态共享特征的提取。实验基于 SYSU-MM01 和 RegDB 数据集展开，主要包括模型性能对比、消融实验以及可视化分析。实验结果表明，所提出的方法在多个评价指标上均超越现有主流方法，且消融实验验证了两个模块的有效性。此外，可视化分析进一步揭示了视觉提示学习如何帮助模型捕捉模态间隐式对应关系，从而提升跨模态行人重识别的鲁棒性。本研究的工作为后续探索更高效的视觉提示学习方法提供了理论支持和实践参考。

第四章 基于多尺度特征融合的跨模态行人重识别算法

4.1 引言

第三章的方法设计了以 ViT 为主干的视觉提示对齐网络，在一定程度上削弱了模态差异的影响，提升了跨模态行人重识别的性能。然而，直接使用可见光图像、红外图像作为视觉提示对模型进行训练，会导致跨模式匹配的判别特征较少。且可见光和红外图像可能具有不同的分辨率，噪声特征和细节特征，在一定程度上影响了模型在模态不变特征条件下的提取能力。为此，本章提出了一种基于多尺度特征融合的跨模态行人重识别算法，以增强模型在不同模态下的判别能力和鲁棒性。该方法在 ViT 主干网络的基础上，引入多尺度特征提取模块 CrossViT^[61]，通过不同感受野的特征表征提升跨模态匹配的效果。同时，设计了一种加权特征融合方法，以减小可见光与红外图像在分辨率、噪声特征和细节层面的差异，从而提高模态不变特征的提取能力。本章将详细介绍所提出的多尺度特征融合方法的设计思路，包括网络结构、特征提取模块、特征融合模块、损失函数优化等，并在两个常见的跨模态行人重识别数据集上进行实验验证，以评估其有效性。

4.2 基于多尺度特征融合的跨模态行人重识别算法

在本小节中，将介绍基于多尺度特征融合的跨模态行人重识别框架。首先，对所构建的模型进行概述，阐述基于 CrossViT 的跨模态的运行机制，对特征提取流程加以说明。其次，描述特征融合机制以及如何借助 CrossViT 实现行人重识别的任务。随后，对模态增强的损失函数进行改进，以进一步减小跨模态差异。

4.2.1 网络结构设计

绝大多数可见光图像与红外图像的行人重识别任务是为了解决模态内和模态间的变化问题而提出的，以满足行人重识别的需求。然而，该任务也面临诸多挑战，例如可见光和红外图像之间的模态差异，以及行人姿态和动作的变化。因此，本文采用一种基于深度学习的网络架构来解决这些问题。




图 4-1 基于 CrossViT 的跨模态行人重识别网络架构

如图 4-1 所示，所提出网络的第一阶段是图像收集，采用了两个标准数据集 SYSU-MM01 和 RegDB 来获取可见光和红外图像。随后，利用 CrossViT 对可见光和红外图像进行特征提取，得到两组特征。接下来，在这两组特征的基础上，进行加权特征融合，从而获得更具辨识度的特征表示。最终，融合后的特征被输入 CrossViT 的解码端，以生成可见光图像并完成行人重识别。此外，本文采用多种评测指标对模型进行全面评估，并与经典方法进行对比实验。实验结果表明，本文提出的方法在跨模态行人重识别任务中显著缓解了模态差异问题，并在多个测评指标上均优于现有方法。

4.2.2 基于多尺度交叉注意力的特征提取

本文提出的网络架构结合了交叉注意力机制和 Vision Transformer，能够有效地利用不同模态的信息，捕捉空间关系，并同时考虑全局和局部上下文。该模型通过多尺度特征提取，不仅能够捕获细粒度细节，还能处理不同成像条件下的外观变化，从而提升行人重识别的鲁棒性。

如 2.2 节的理论知识所示，ViT 是一种基于 Transformer 的神经网络架构，最初用于图像分类任务。将图像划分为多个固定大小的图像块，并将其转换为序列化的 Token 进行处理。在 Transformer 结构中，采用自注意力机制来建模全局依赖关系，并使用多头自注意力和前馈网络对特征进行变换。此外，ViT 还采用了位置编码来保留空间位置信息。在计算过程中，每个 Transformer 编码器包含多头自注意力和前馈神经网络。计算公式如下：

$$I_0 = [I_{CLS} \| I_{Pch}] + I_{PE} \quad (4-1)$$

$$J_P = I_{P-1} + MSA(LN(I_{P-1})) \quad (4-2)$$

$$I_P = J_P + FFN(LN(J_P)) \quad (4-3)$$

其中： I_{CLS} 表示分类 Token，用于最终的分类或特征提取。 I_{Pch} 表示图像块 Token，由图像划分而成。 I_{PE} 是位置嵌入 Token，用于保留图像的空间信息。由于 ViT 仅依赖单尺度的特征提取，在处理不同尺度目标时容易丢失信息。因此，为了提升模型对不同尺寸物体的适应能力，本研究采用多尺度 ViT，并结合交叉注意力机制，使其能够捕获更多不同层次的特征信息。




图 4-2 CrossViT 网络架构

CrossViT^[62]是一种跨模态多尺度特征融合的 Transformer 变体。与标准 ViT 不同，CrossViT 采用双分支结构，并在不同分支之间引入交叉注意力，从而实现更有效的信息交互。如图 4-2 所示，其核心思想是使用大尺度分支和小尺度分支分别提取粗粒度和细粒度特征，并通过交叉注意力机制将二者进行融合。具体计算方式如下：

$$I'^{le} = [Fn^{le}(I_{CLS}^{le} || I_{Pch}^{se})] \quad (4-4)$$

其中， $Fn^{le}(\cdot)$ 为投影函数（Projection Function），用于对齐不同分支的特征维度。随后，交叉注意力机制（Cross-Attention）作用于 I'^{le} 和 I_{CLS}^{le} 之间，其计算公式如下：

$$CA(I'^{le}) = softmax\left(\frac{rm^Q}{\sqrt{\frac{D}{e}}}\right) \cdot I'^{le}V_u \quad (4-5)$$

其中： $r = I_{CLS}^{le}V_r$ 和 $m = I'^{le}V_m$ 代表不同分支的特征向量。 $\frac{D}{e}$ 为嵌入维度， V_r, V_m, V_u 为可学习参数。最终，CrossViT 模型结合归一化层（LN）与残差连接（Residual Connection）来进行特征计算，其公式如下：

$$J_{CLS}^{le} = FN^{le}(I_{CLS}^{le}) + MCA(LN[FN^{le}(I_{CLS}^{le} \| I_{Pch}^{se})]) \quad (4-6)$$

$$Z^{le} = [G^{le}(J_{CLS}^{le} \| I_{Pch}^{se})] \quad (4-7)$$

其中， $G^{le}(\cdot)$ 是用于维度对齐的反投影函数。通过这种机制，CrossViT 能够更有效地提取特征，并在可见光与红外图像之间建立跨模态关联，从而提升行人识别的准确性。

本文利用 CrossViT 进行特征提取。特征提取发生在编码器部分，网络通过输入的可见光图像和红外图像提取两种不同的特征，并在下一小节的步骤中进行融合。这三种特征集的提取方式如下：输入可见光图像 I^{RGB} （白天拍摄的可见光图像），通过编码器提取第一种关键特征 $F(R)$ 。输入红外图像 I^{IR} （夜间拍摄的红外光谱图像），通过 CrossViT 编码器提取第二种特征 $F(I)$ 。这两种特征共同构成最终用于跨模态行人重识别的特征表示，确保模型能够有效应对模态差异，提高匹配准确性。

4.2.3 加权特征融合




图 4-3 加权特征融合与 MAE 损失

本小节介绍基于加权因子的特征融合过程。在训练和测试过程中，对两种特征进行深入分析，以确保模型能够充分学习并提取不同模态下的关键信息。这种分析不仅有助于理解各模态特征在跨模态行人重识别任务中的作用，还能有效提升特征融合的质量，从而增强模型在不同环境下的鲁棒性和识别准确率。但是特征的高维性可能会导致性能下降、处理时间增加以及计算负担加重，因

此所有特征需要进行拼接融合。为此，引入了权重因子，以确保最佳融合效果。特征融合的数学公式如下：

$$F = (wt * F^1) + [(1 - wt) * F^2] \quad (4-8)$$

如果权重选择不当，融合特征的效果难以达到最优。为了解决这一问题，采用鸽群搜索优化策略 DSO^[61] (Dove Search Optimization) 来确定最优权重。其中鸽子被视为搜索群体，进入搜索区域以寻找食物碎屑。DSO 具有较好的局部搜索能力和收敛速度，可以有效捕捉可见光和红外模态中的独特信息，函数表达式为：

$$DO = \operatorname{argmax}[r] \quad (4-9)$$

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2}} \quad (4-10)$$

通过相关系数 r 来衡量特征间的相似度，以此得到基于最优权重的融合特征。在鸽群搜索优化策略算法中，首先设定鸽群数量 D 和最大迭代次数 M ，并在搜索空间内随机初始化所有鸽子的初始位置。在此过程中，饱食度 y_x^m 用于表示鸽子 x 在第 m 次迭代时的状态，取值范围为 $x \in [1, D]$ ，并依据设定的搜索边界进行初始化。随后，计算所有鸽子的适应度，记为 $ft(w_t^m)$ ，其中 $t \in [1, D]$ 表示当前鸽子的索引， w_t^m 代表第 m 轮迭代中鸽子的权重向量。在当前迭代过程中，位于食物碎屑较多区域的鸽子更具优势，因此选择适应度最高的鸽子作为参考，位置更新遵循 $x_t^m = \operatorname{argmax}\{ft(w_t^m)\}$ 。每只鸽子的饱食度的更新公式为：

$$Y_t^m = \beta Y_t^{m-1} + m \left(ft(w_t) - t(w_{x_f}) \right) \quad (4-11)$$

其中 β 为衰减因子。随后，选择当前迭代中饱食度最高的鸽子作为优化目标，即 $x_y^m = \operatorname{argmax}\{Y_t^m\}$ ， $t \in [1, D]$ 。对于位置向量更新，所有鸽子的位置按照

$$w_t^{m+1} = w_t^m + \alpha \chi_t^m (w_{x_y}^m - w_t^m) \quad (4-12)$$

进行调整，其中 α 为学习率，而方向调整系数 χ_t^m 由鸽子的饱食度和距离计算得出。此外，为了克服在高维情况下的搜索精度和收敛速度的限制，本研究对位置更新策略进行了优化，使得在评估适应度值时，采用最优适应度值进行调整，最终更新公式变为 $FP = g_t^{m+1} * BtSn$ ，通过这种方式，新生成的位置用于优化权重，从而提高特征融合的效果。

根据模型结构，编码器首先生成对应特征，然后通过最优权重进行特征融合，最终传递至的 CrossViT 解码层。这一过程分别生成基于 RGB 图像模态特征

表示 $\bar{F}(R)^{wt}$ 和红外图像的模态特征表示 $\bar{F}(I)^{wt}$ 。然而跨模态的行人重识别任务的核心目标是基于红外图像的行人识别。因此，解码层的识别过程可表示为：

$$\begin{aligned} q^I &= p^I \omega^q \\ k^R &= F^R \omega^k \\ v^R &= F^R \omega^v \end{aligned} \quad (4-13)$$

其中， p^I 和 q^I 分别表示红外图像的原型和查询， F^R 表示 RGB 图像的相关特征，其键和值分别由 K_R 和 V_R 赋值。随后，这些特征将通过注意力权重进行优化，使得红外特征 $\bar{F}(I)^{wt}$ 能够获得权重值对应的值，计算过程如下：

$$\bar{F}(I)^{wt} = \text{Attention}(q^I, k^R, v^R) = \text{softmax}\left(\frac{q^I (k^R)^T}{\sqrt{d}}\right) v^R \quad (4-14)$$

最终，完整的可见光和红外图像特征用于行人识别，其建模公式如下：

$$R = F(R) + \bar{F}(I)^{wt} \quad (4-15)$$

$$I = F(I) + \bar{F}(R)^{wt} \quad (4-16)$$

4.3 损失函数设计

为了使不同模态的特征充分融合，整个行人重识别过程进一步引入了模态感知增强损失^[63]（Modality-Aware Enhancement Loss, MAE Loss），以提高模型的识别效率。该损失作用于经过批归一化处理的特征，主要用于测试过程。传统上，模态感知增强损失 L_{MAE} 由身份损失 L_{ID} 和中心损失 L_{Center} 组成，分别用于优化类内特征和分类特征，其计算如下：

$$L_{MAE} = L_{ID} + L_{Center} \quad (4-17)$$

$$L_{ID} = E(-\log p^{(R)}) + E(-\log p^{(I)}) \quad (4-18)$$

$$L_{Center} = E\left[\alpha + d_{c_a, c_p} - d_{c_a, c_n}\right] \quad (4-19)$$

其中， $p(\cdot)$ 表示正确预测的概率， E 表示数学期望。 d_{c_a, c_n} 表示由当前 batch 中的 RGB 特征 R 与 IR 特征 I 计算得到的中心特征。其中， c_a 和 c_p 组成一个正样本对，它们属于同一个人的中心特征，但来自不同模态；而 c_a 和 c_n 组成一个负样本对，它们分别属于不同的行人。

4.4 实验结果与分析

为了验证所提出方法的有效性，依旧采用 3.4.1 所使用的两个数据集 SYSU-MM01^[64]和 RegDB^[65]进行测试。因此，图像表示为 I_e ，其中 $e = 1, 2, \dots, E$ ，变量 E 代表总图像数量。图像包括可见光和红外两种模态，分别用 I_e^R 和 I_e^I 表示。

4.4.1 实验设置

本研究的实验在 NVIDIA P100 GPU 上进行，并基于 PyTorch 框架实现。在数据预处理阶段，将输入图像调整至 256×128 的尺寸，并采用随机裁剪和随机水平翻转进行数据增强。此外，对红外图像额外施加颜色抖动和高斯模糊。训练过程中，批次大小设定为 32，包含 4 个不同样本，每个样本分别采样 4 张可见光和红外图像。优化过程中，采用随机梯度下降优化器，并将动量参数设定为 0.9。整个模型训练 50 轮 epochs，初始学习率设为 0.01，权重衰减参数设定为 $1 \times e^{-4}$ 。由于 SYSU-MM01 和 RegDB 数据集没有提供独立的验证集，本文将训练集划分为训练集和验证集，在此基础上进行实验，以确定最佳的网络结构配置及损失函数参数。随后，使用最优参数对完整训练集进行重新训练，并在原始测试集上进行评估，以验证方法的有效性。

4.4.2 与目前方法的对比

表 4-1 SYSU 数据集上与目前方法的对比

Settings		All Search			Indoor Search		
Method	r=1(%)	r=10(%)	mAP(%)	r=1(%)	r=10(%)	mAP(%)	
Zero-Pad ^[45]	14.80	54.12	15.95	20.58	68.38	26.92	
cmGAN ^[55]	26.97	67.51	31.49	31.63	77.23	42.19	
FMCNet ^[60]	61.68	93.12	57.51	63.41	91.96	68.17	
AlignGAN ^[47]	42.46	85.46	40.76	45.94	87.63	54.36	
DDAG ^[57]	54.75	90.39	53.02	61.02	94.06	67.98	
NFS ^[46]	56.91	91.34	55.45	62.79	96.53	69.79	
CM-NAS ^[58]	61.99	92.87	60.02	67.1	97.02	72.95	
DFLN-ViT ^[52]	59.84	92.49	57.51	62.13	94.83	69.03	
AGW ^[59]	47.56	84.39	47.65	54.17	91.14	62.97	
PMT ^[53]	67.53	95.36	64.98	71.66	98.94	76.52	
CPA ^[66]	58.76	93.17	57.67	61.45	95.07	68.53	
SPOT ^[51]	65.34	92.73	62.25	69.42	96.22	74.63	
OURS	68.35	96.73	65.36	72.43	97.26	78.54	

在 SYSU-MM01 数据集上的实验结果如表 4-1 所示。与当前主流的 CNN-based 方法以及最新的 Transformer-based 方法相比，本研究的方法取得了显著的性能提升。在全局搜索模式下，与 Zero-Pad^[45]相比，本方法在 Rank-1、Rank-10 和 mAP 指标上分别达到了 68.35%、96.73%、65.36%，相较于 Zero-Pad 提高了

53.55%、42.63%和 19.41%。与采用神经架构搜索进行自动特征选择的 NFS^[46]相比, 本方法在 Rank-1、Rank-10 和 mAP 指标上分别达到了 68.35%、96.73%、65.36%, 相较于 NFS 提高了 11.44%、5.39%和 10.51%。DDAG^[57]通过加权部分注意力进行部分级特征聚合, 而本研究的方法进一步采用 Transformer 提取更深入的部分级交互特征, 并结合全局外观特征进行特征表示, 从而超越 DDAG。与此同时, 与 Transformer-based 方法 (DFLN-ViT^[52]、SPOT^[51]、CPA^[66]和 PMT^[53]) 相比, 本方法在全局搜索模式下分别领先 8.51%和 7.85% (Rank-1 和 Rank-10), 3.01%、4%和 3.11% (Rank-1、Rank-10 和 mAP), 9.59%和 7.69% (R1 和 mAP), 以及 0.82%和 0.38% (Rank-1 和 mAP)。

在室内搜索模式下, 本方法在 Rank-1、Rank-10 和 mAP 指标上表现出色。然而, 在 Rank-10 指标上, PMT^[53]取得了最佳结果。其原因可能在于, 在大规模数据集上, Rank-10 更容易包含模糊匹配情况, 使得本模型在某些匹配结果上的置信度低于 PMT^[53]。此外, PMT^[53]通过结合渐进式学习策略与判别损失函数, 在 Rank-10 方面优于本方法。然而, 本研究提出的方法依然表现出高度可比性。综上所述, 这些实验结果充分证明了本方法在缓解模态差距方面的有效性, 并成功挖掘了更可靠的模态共享特征, 从而提升了跨模态行人重识别的性能。

表 4-2 RegDB 数据集上与目前方法的对比

Settings	Visible to Infrared			Infrared to Visible		
Method	r=1(%)	r=10(%)	mAP(%)	r=1(%)	r=10(%)	mAP(%)
Zero-Pad ^[45]	17.75	34.21	18.9	16.63	34.68	17.82
cmGAN ^[55]	-	-	-	-	--	-
XIV ^[56]	62.21	83.13	60.18	-	-	-
AlignGAN ^[47]	57.95	-	53.67	56.32	-	53.45
DDAG ^[57]	69.34	86.19	63.46	68.06	85.15	61.85
NFS ^[46]	80.54	91.96	72.16	77.95	90.45	69.79
MSA ^[67]	84.86	92.75	82.16	-	-	-
DMiR ^[68]	75.79	89.86	69.97	73.93	89.87	68.22
CM-NAS ^[58]	84.54	95.18	80.32	82.57	94.51	78.31
AGW ^[59]	70.05	86.21	66.37	70.49	87.12	65.9
CMT ^[50]	88.78	94.76	88.49	84.55	93.72	83.64
DFLN-ViT ^[48]	92.10	97.97	82.11	91.21	98.20	81.62
PMT ^[53]	84.83	-	76.55	84.16	-	75.13
CPA ^[66]	87.48	96.94	75.59	84.81	96.55	74.93
SPOT ^[51]	79.37	92.73	72.26	80.35	93.48	72.46
OURS	90.54	96.71	84.15	87.65	97.18	82.07

在 RegDB 数据集上的实验结果如表 4-2 所示。此外, 本研究还对可见光到红外评估模式进行了定量对比分析, 并从实验结果中总结了一些有趣的发现。本方法在可见光-红外模式下取得了 90.54% (Rank-1)、96.71% (Rank-10)、

84.15% (mAP) 的优异表现；在红外到可见光模式下，本方法的 Rank-1、Rank-10 和 mAP 指标分别达到 87.65%、97.18% 和 81.07%。在红外-可见光评估模式下，与最佳 CNN-based 方法 MSA^[67] 相比，本研究的方法在 Rank-1、Rank-10、mAP 指标上分别提升了 5.68%、3.96%、1.99%。此外，与 Transformer-based 方法 SPOT^[51] 相比，本方法在 Rank-1、Rank-10 和 mAP 指标上分别领先 11.17%、3.98% 和 11.89%；与 CPA^[66] 相比，在 Rank-1 和 mAP 指标上分别领先 3.06% 和 8.86%。这些实验结果表明，本方法在 RegDB 数据集上显著优于 SPOT^[51] 和 CPA^[66]，进一步验证了本研究方法的有效性和鲁棒性。

值得注意的是，与当前最新的方法 DFLN-ViT^[48] 在 SYSU-MM01 数据集上的表现相比，本研究的方法在 Rank-1 和 mAP 指标上分别超越 8.51% 和 7.85%。然而，在 RegDB 数据集 V-I 评估模式下，本方法在 Rank-10 指标上略微落后 1.02%，但在 mAP 指标上领先 0.45%。这一现象可能源于 DFLN-ViT^[48] 采用了空间特征感知模块，并使用单层 Transformer 进行特征提取。此外，DFLN-ViT^[48] 通过引入基于异构中心的三元组损失进一步提升了性能，使其在 V-I 评估模式下取得了更优的结果。然而，在 I-V 评估模式下，本方法表现出更优的性能。

4.4.3 消融实验

首先验证本章提出的各个模块的有效性，具体来说：（1）基于多尺度交叉注意力机制的特征提取与传统的 Transformer 方法相比，是否有更好的效果。

（2）加权特征融合模块与直接拼接相比是否效果更佳。以此来验证本文提出的多尺度特征融合的跨模态行人重识别算法，促进可见光-红外模态信息交互的有效性，验证该网络能否高效地捕捉可见光与红外图像特征之间的空间依赖关系，从而实现更全面的数据表示。

表 4-3 SYSU-MM01 数据集上的消融实验

方法	模块		All-Search		Indoor-Search	
	(1)	(2)	Rank-1	mAP	Rank-1	mAP
1 (Base)	×	×	40.49	40.93	41.76	49.12
2	✓	×	65.76	62.46	73.65	74.65
3	×	✓	57.26	55.56	67.54	63.46
4 (Full)	✓	✓	68.35	65.36	72.43	78.54

在数据集 SYSU-MM01 上进行的消融实验结果如表 4-3 所示。可以看出，在室内搜索模式下的整体性能都好于全局搜索模式下的性能。同时，多尺度的交叉注意力机制可以确保网络间不同层次的特征表达，从而捕捉更为细粒度的特征和更高级的语义信息。相比直接拼接，通过使用 DSO 算法得到的权重进行特征融合利用模态间的稳定性最小化模态的差异，从而提高模态的对齐效果。如表 4-4 所示，同样在数据集 RegDB 上进行的消融实验结果显示，不管是在可

见光-红外模态下的实验结果，还是红外-可见光模态下的验证，本文提出的方法结合了 CrossVit 和 DSO 算法的优势，使模型有了全面的提升，增强了每种模态的判别性特征，使模型更鲁棒。

表 4-4 RegDB 数据集上的消融实验

方法	模块		Infrared to Visible		Visible to Infrared	
	(1)	(2)	Rank-1	mAP	Rank-1	mAP
1 (Base)	×	×	87.14	80.2	85.05	79.16
2	✓	×	87.54	81.94	84.97	81.28
3	×	✓	85.16	82.67	83.91	80.94
4 (Full)	✓	✓	90.54	84.14	87.65	82.07

为了分别验证本文方法所使用的 CrossViT 的有效性，采用不同的特征提取策略进行实验。统一数据集和搜索模式，数据集 SYSU-MM01 选择单张输入的全局搜索模式，数据集 RegDB 选择可见光-红外模式。评价参数选择累计匹配特征分析、Rank-1、Rank-10 和 mAP。




图 4-4 累计匹配特征（CMC）的对比分析(SYSU-MM01)




图 4-5 累计匹配特征（CMC）的对比分析(RegDB)

如图 4-4 所示, 为了全面评估本文提出的跨模态行人重识别方法的性能, 在 SYSU-MM01 和 RegDB 数据集上, 对不同的分类模型在不同 Rank 下的累计匹配特征进行了对比分析。该实验的主要目标是验证所提出方法在跨模态行人匹配任务中的有效性, 并评估其相较于其他主流模型的优势。

在图 4-5 中, 重点展示了 RegDB 数据集上的实验结果。RegDB 作为一个经典的跨模态行人重识别数据集, 涵盖了红外和可见光图像的匹配任务, 对模型的模态对齐能力和特征提取能力提出了较高的要求。实验结果表明, 当 Rank 取值为 10 时, 本文提出的方法的累积匹配准确率显著优于 LSTM、RNN 和 ResNet 等主流模型。其中, 相较于基于 LSTM 的方法, 本文方法的 Rank-10 识别率提高了 2%; 相较于基于 RNN 的方法, 提升了 20%; 而与基于 ResNet 的方法相比, 则达到了 40% 的显著提升。




图 4-6 平均准确率精度 (mAP) 的对比分析(SYSU-MM01)




图 4-7 平均准确率精度 (mAP) 的对比分析(RegDB)

图 4-6 与图 4-7 分别展示了本文方法在 SYSU-MM01 和 RegDB 数据集上的平均准确率 (mAP) 表现, 并与多个主流分类模型进行了详细对比分析。为了全面评估本文方法在跨模态行人重识别任务中的有效性, 我们在不同特征提取阶段、特征融合策略以及加权特征融合方案下, 对比了不同分类器的性能表现, 旨在深入理解模型的优势与不足, 从而为后续的优化提供方向。

具体而言, 本文所提出的方法在多个方面均展现出了优越的性能。从特征提取角度来看, 本文方法采用了模态感知提示机制, 以适应跨模态行人重识别任务中的模态差异问题。通过模态对齐策略, 模型能够有效减少红外图像与可见光图像之间的特征分布偏差, 使其能够更好地进行匹配。相比于传统的 CNN 或 RNN 结构, 本文方法在提取不同模态的特征时具备更强的泛化能力。在特征融合层面, 本文方法引入了多尺度特征融合策略, 通过跨尺度信息交互增强特征表达能力, 同时采用加权特征融合策略, 使不同模态的特征能够自适应地进行融合, 提高了整体匹配精度。相较于传统特征融合方法, 本文的融合策略能够更精准地捕捉行人身份特征, 从而有效提升跨模态匹配的鲁棒性。

综上所述, 本实验结果充分说明了本文方法在跨模态行人重识别任务中的有效性, 并为未来的模型优化提供了有力的参考方向。为此将进一步改进特征提取与融合策略, 以提升模型在不同场景下的适应能力, 并结合生成式数据增强技术, 以进一步提高跨模态匹配的鲁棒性和泛化性能。

4.5 可视化分析

4.5.1 检索结果

为更直观地呈现实验结果, 本小节对在 SYSU-MM01 与 RegDB 数据集上所获得的跨模态行人重识别检索效果进行了可视化展示, 所示结果基于多尺度特征融合策略所得。图 4-8 展示了在全局搜索模式下, 数据集 SYSU-MM01 上的可视化结果, 第一列为检索的查询的目标图像, 第二至十一列为检索的命中结果, 绿色代表检索正确, 红色代表检索出错。

在全局搜索模式下, 测试集包含共计 3803 张图像, 涉及 96 个行人身份; 而在室内搜索模式下, 由于不包含室外场景, 图像数量相对较少, 共 1120 张图像。实验结果表明, 与 RegDB 数据集相比, SYSU-MM01 数据集在任务复杂性上更高, 不仅体现在数据量更大, 还包括更复杂的采集环境, 如多摄像头视角和室内外场景的变化。因此, 在该数据集上进行跨模态行人重识别时, 整体检索准确率普遍低于在 RegDB 数据集上所取得的结果。尽管如此, 在所提出的基于多尺度特征融合的跨模态行人重识别方法下, 模型在 SYSU-MM01 数据集的

全局搜索模式中依然取得了 74% 的 Rank-1 准确率，明显优于当前主流方法，展现出较强的鲁棒性与泛化能力。同时，在室内搜索模式下，由于环境干扰因素相对较少，模型性能进一步提升，进一步验证了所提方法在不同场景下均具有良好的适应性与检索能力。




图 4-8 SYSU-MM01（全局搜索）的搜索结果




图 4-9 RegDB（可见光-红外）的搜索结果

RegDB 测试集包含 2060 张检索图片，共 206 各 ID，每个 ID 十张图片。图 4-9 展示了在红外-可见光模式下，数据集 RegDB 上的可视化结果。通过图片检索结果可以发现，红外-可见光模式下，检索的成功率高达 92%，而在可见光-红外模式下，准确率几乎高达 100%，几乎没有出现检测失误的结果。

4.5.2 特征分布的可视化




图 4-10 t-SNE 可视化结果 (SYSU-MM01)




图 4-11 t-SNE 可视化结果 (RegDB)

为了与第三章的方法进行对比，本文仍通过 t-SNE^[54]方法将特征映射到一个二维空间进行可视化。不同颜色分别表示属于不同身份的行人图像，本文共选取了 10 个行人 ID 的特征进行可视化展示。图 4-10 展示了在 SYSU-MM01 数据集上使用 t-SNE 进行特征降维后的可视化结果，其中左图对应全局搜索模式，右图对应室内搜索模式。从图中可以看出，相较于第三章的方法，当前所提出的模型在两个模式下的特征分布更为集中，同一 ID 的特征聚合程度更高，表明

所提方法在特征区分性和聚合能力方面具有明显提升。

图 4-11 展示的是在 RegDB 数据集上进行 t-SNE 降维后的可视化结果。左图表示可见光到红外模式下的特征分布，右图则对应红外到可见光模式。在红外到可见光的检索任务中，特征点分布相对更加分散，这一现象可能是由于该方向下的数据存在更高的复杂性和模态差异，使得模型在对特征进行编码时更难以建立一致的表征。而相较之下，可见光到红外模式下的特征聚集性更强，也在一定程度上解释了该模式下 mAP 通常高于红外到可见光模式的现象。

综上所述，实验结果表明，所提出的跨模态行人重识别方法在特征空间中能够更有效地捕捉可见光与红外图像之间的语义关联，并通过学习模态间稳定性特征，有效缩小跨模态表征差异，从而实现更准确的特征对齐和更具判别性的行人表示能力。

4.6 本章小结

本章围绕第三章所涉及的基于 Vision Transformer (ViT) 的跨模态行人重识别方法展开，介绍了模型的架构设计、特征学习策略、模态对齐机制以及优化目标。在跨模态行人重识别任务中，不同模态（如红外和可见光）的特征分布存在较大差异，有效学习共享特征的表示是关键挑战。为此，本章提出了一种基于 CrossViT 的跨模态特征学习框架，利用交叉注意力机制增强特征对齐能力，提高不同模态数据的可比性。所提出模型采用 CrossViT 作为主干网络，通过多尺度交叉注意力的特征提取和基于鸽群搜索优化的加权特征融合策略提升跨模态匹配能力。结合模态增强损失，模型能够充分挖掘跨模态数据的相似性和差异性，提升特征的判别性。

实验部分基于两个常见的跨模态行人重识别数据集进行评测，并与现有方法进行了对比。实验结果表明，所提出方法在 Rank-1 识别率和 mAP 指标取得了显著提升。消融实验分析展示了不同模块的贡献，CrossViT 结构、加权特征融合均对最终性能有积极作用。特征可视化分析表明，模型能够有效关注行人特征的关键区域，增强跨模态识别的鲁棒性。

本章提出的基于多尺度特征融合的跨模态行人重识别方法在提升匹配精度方面取得了良好效果，并通过实验验证了其优越性。研究成果不仅为跨模态行人重识别任务提供了新的解决方案，也为后续研究提供了进一步探索的方向。下一章将对全文研究内容进行总结，并探讨未来可能的研究工作。

第五章 总结与展望

5.1 本文总结

行人重识别是一项基于图像检索的关键任务，其核心目标在于通过计算机视觉技术判断图像或视频序列中是否包含特定目标行人个体。其中，可见光行人重识别作为最为典型的单模态识别场景，近年来在深度学习的发展推动下取得了显著的研究成果。然而，该任务在复杂光照条件下（如夜间或低照度环境）仍存在显著局限性，难以实现稳定的行人匹配性能。为克服单模态方法在实际应用中的局限，跨模态行人重识别逐渐成为研究热点。该任务致力于在不同模态（通常为可见光与红外）之间实现准确的行人匹配，从而满足全天候监控等多场景应用需求。然而，由于可见光与红外图像在成像原理上的差异，会导致显著的模态间特征分布差异。此外，该任务还受到行人遮挡、图像分辨率低、视角变化等因素的共同影响，进一步加剧了跨模态匹配的难度。针对上述挑战，本文围绕提升跨模态行人重识别性能开展了一系列研究工作，主要贡献与具体内容如下：

（1）提出了基于视觉提示对齐的跨模态行人重识别，介绍了视觉提示学习的基本概念、网络设计及实验分析。通过引入视觉提示学习，生成适应不同模态的提示信息，增强模型对模态特征的适应性。设计了视觉提示生成模块和提示融合模块，分别用于生成模态感知提示和融合提示信息以提取共享特征。实验基于 SYSU-MM01 和 RegDB 数据集，结果表明该方法在多个评价指标上优于现有方法，且消融实验验证了两个模块的有效性。可视化分析揭示了视觉提示学习在提升跨模态行人重识别鲁棒性方面的作用。

（2）构建了多尺度特征融合的跨模态行人重识别方法，重点介绍模型架构、特征学习策略、模态对齐机制及优化目标。针对跨模态特征分布差异问题，提出基于 CrossViT 的特征学习框架，通过交叉注意力增强模态对齐，并结合鸽群搜索优化的加权特征融合策略提升匹配能力。此外，引入模态感知增强损失以提高特征判别性。实验在 SYSU-MM01 和 RegDB 数据集上验证了该方法的有效性，在 Rank-1 识别率和 mAP 指标上均优于现有方法。消融实验和可视化分析进一步证明，CrossViT 结构和加权融合策略可提升模型对行人关键特征的关注度，增强跨模态识别鲁棒性。本章研究为跨模态行人重识别提供了新方案，并为后续探索奠定基础。

5.2 工作展望

虽然本文设计的基于视觉提示学习和多尺度特征融合的跨模态行人重识别方法在一定程度上提升了跨模态行人重识别的性能，但是仍需要进一步的探究和完善。

(1) 视觉提示学习的进一步优化。首先，提示生成机制优化，当前的视觉提示生成模块和提示融合模块主要关注模态特定的特征适应性，未来可以探索更动态和自适应的提示生成策略，例如基于注意力机制的自适应提示调整，以更精确地提取跨模态特征。其次，提示信息的显式性增强，现有提示信息仍然较难直观解释，未来可以结合显式特征变换或解释性模型，使提示学习的作用更加透明，同时增强模型的可解释性和鲁棒性。提示学习与预训练模型的结合：可以进一步研究如何将视觉提示学习与大规模预训练模型（如 CLIP、DINO 等）结合，利用预训练模型的强大泛化能力来提升跨模态匹配性能。

(2) 多尺度特征融合的进一步探索。跨模态特征对齐的强化：目前的多尺度特征融合方法主要依赖于 CrossViT 进行模态对齐，但在极端光照变化或模态间存在严重偏差的情况下，特征对齐仍然存在挑战。未来可以考虑引入对比学习或对抗性训练，进一步增强模态不变特征的提取能力。更高效特征融合策略：目前采用鸽群搜索优化进行加权融合，未来可以探索更高效的搜索或优化策略，如基于元学习的动态权重分配方法，以提升特征融合的适应性和计算效率。

(3) 拓展至多模态行人重识别：当前研究聚焦于可见光-红外跨模态行人重识别，未来可以探索包含深度信息、热成像或激光雷达等多模态数据的行人重识别任务，进一步提升模型在复杂环境下的适应性和泛化能力。

综上所述，未来研究可以围绕视觉提示学习的自适应优化、跨模态特征的高效融合、多模态拓展等方向展开，进一步提升跨模态行人重识别的性能和应用价值。本研究为跨模态行人重识别提供了新的思路和方法，也为后续研究提供了有价值的参考。

参考文献

- [1] Song X ,Zhou J ,Jin H , et al.Enhancing cross-modality person re-identification through attention-guided asymmetric feature learning[J].Multimedia Systems,2025,31(2):160-160.
- [2] Mazzon R, Tahir S F, Cavallaro A. Person re-identification in crowd[J]. Pattern Recognition Letters, 2012, 33(14): 1828-1837.
- [3] Ling Y ,Luo Z ,Lin D , et al.Cross-modality average precision optimization for visible thermal person re-identification[J].Pattern Recognition,2025,164111489-111489.
- [4] Lin X, Li J, Ma Z, et al. Learning modal-invariant and temporal-memory for video-based visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 20973-20982.
- [5] Wu J, Jiang J, Qi M, et al. An end-to-end heterogeneous restraint network for RGB-D cross-modal person re-identification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2022, 18(4): 1-22.
- [6] Huang Y, Zha Z J, Fu X, et al. Illumination-invariant person re-identification[C]//Proceedings of the 27th ACM international conference on multimedia. 2019: 365-373.
- [7] Karanam S, Li Y, Radke R J. Person re-identification with discriminatively trained viewpoint invariant dictionaries[C]//Proceedings of the IEEE international conference on computer vision. 2015: 4516-4524.
- [8] Hafner F M, Bhuiyan A, Kooij J F P, et al. RGB-depth cross-modal person re-identification[C]//2019 16th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). IEEE, 2019: 1-8.
- [9] 王凤随,刘芙蓉,陈金刚,等.融合注意力机制的多损失联合跨模态行人重识别方法[J].激光与光电子学进展,2022,59(08):147-156.
- [10] Wang Z, Li C, Zheng A, et al. Interact, embed, and enlarge: Boosting modality-specific representations for multi-modal person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022, 36(3): 2633-2641.
- [11] Maaz M, Rasheed H, Khan S, et al. Class-agnostic object detection with multi-modal transformer[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 512-531..
- [12] Vezzani R, Baltieri D, Cucchiara R. People reidentification in surveillance and forensics: A survey[J]. ACM Computing Surveys (CSUR), 2013, 46(2): 1-37.
- [13] 魏梓钰,杨曦,王楠楠,等.互惠双向生成对抗网络用于跨模态行人重识别[J].西安电子科技大学学报,2021,48(02):205-212.
- [14] 石瑞鑫,智敏,殷雁君.多模态行人重识别研究综述[J/OL].计算机应用研究,1-10.
- [15] Zhang Y ,Teng Z ,Zhang B .Semantic consistency learning for unsupervised multi-modal person re-identification[J].Image and Vision Computing,2025,155105434-105434.
- [16] 崔洪刚,曹钢钢,苏获翔.二值化图像与双流网络在跨模态行人重识别的应用[J].计算机应用与软件,2025,42(02):216-226.
- [17] Zuo X ,Peng J ,Cheng T , et al.Modality-perceptive harmonization network for visible-infrared person re-identification[J].Information Fusion,2025,118102979-102979.
- [18] 程德强,姬广凯,张皓翔,等.基于多粒度融合和跨尺度感知的跨模态行人重识别[J].通信学

- 报,2025,46(01):108-123.
- [19]Hu M ,Zhou Q ,Wang R .Bridging visible and infrared modalities: a dual-level joint align network for person re-identification[J].The Visual Computer,2025,(prepublish):1-16.
- [20]谭台哲,李梦柔,杨卓,等.结合频域注意力和模态协同特征优化的跨模态行人重识别[J/OL].激光与光电子学进展,1-17.
- [21]Joshi A ,Diwakar M .I2V-CMGAN: Generative Adversarial Cross-Modal Network-Based Image-to-Video Person Re-identification[J].Cognitive Computation,2025,17(1):41-41.
- [22]Wu D ,Liu Z ,Chen Z , et al.LRMM: Low rank multi-scale multi-modal fusion for person re-identification based on RGB-NI-TI[J].Expert Systems With Applications,2025,263125716-125716.
- [23]Song W ,Wang X ,Wu W , et al.Channel enhanced cross-modality relation network for visible-infrared person re-identification[J].Applied Intelligence,2024,55(1):4-4.
- [24]Ding Y ,Li J ,Wang H , et al.Attention-enhanced multimodal feature fusion network for clothes-changing person re-identification[J].Complex & Intelligent Systems,2024,11(1):2-2.
- [25]邹子琳,陈莹.域不变多模态多源数据行人重识别协同优化架构[J].控制与决策,2025,40(04):1276-1284.
- [26]Cao C, Ma G, Chen Z, et al. A High-Precision Dynamic Movement Recognition Algorithm Using Multimodal Biological Signals for Human-Machine Interaction[J]. Advanced Intelligent Systems, 2025, 7(3): 2400483.
- [27]何磊,栗风永,秦川.跨通道交互注意力机制驱动的双流网络跨模态行人重识别[J].应用科学学报,2024,42(05):884-892.
- [28]范慧杰,郁航,赵颖畅,等.可见光红外跨模态行人重识别方法综述[J].信息与控制,2025,54(01):50-65.
- [29]Lin X, Li J, Ma Z, et al. Learning modal-invariant and temporal-memory for video-based visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 20973-20982.
- [30]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [31]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [32]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [33]Mao A, Mohri M, Zhong Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//International conference on Machine learning. PMLR, 2023: 23803-23828.
- [34]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [35]Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [36]Liang T, Jin Y, Liu W, et al. Cross-modality transformer with modality mining for visible-infrared person re-identification[J]. IEEE Transactions on Multimedia, 2023, 25: 8432-8444.
- [37]Bahng H, Jahanian A, Sankaranarayanan S, et al. Exploring visual prompts for adapting large-scale models[J]. arXiv preprint arXiv:2203.17274, 2022.

- [38] Lu Y, Liu J, Zhang Y, et al. Prompt distribution learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 5206-5215.
- [39] Jia M, Tang L, Chen B C, et al. Visual prompt tuning[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 709-727.
- [40] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.
- [41] Jia M, Tang L, Chen B C, et al. Visual prompt tuning[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 709-727.
- [42] Chen S, Ge C, Tong Z, et al. Adaptformer: Adapting vision transformers for scalable visual recognition[J]. Advances in Neural Information Processing Systems, 2022, 35: 16664-16678.
- [43] Jie S, Deng Z H, Chen S, et al. Convolutional bypasses are better vision transformer adapters[M]//ECAI 2024. IOS Press, 2024: 202-209.
- [44] Zhu J, Lai S, Chen X, et al. Visual prompt multi-modal tracking[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 9516-9526.
- [45] Wu A, Zheng W S, Yu H X, et al. RGB-infrared cross-modality person re-identification[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5380-5389.
- [46] Chen Y, Wan L, Li Z, et al. Neural feature search for RGB-infrared person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 587-597.
- [47] Wang G, Zhang T, Cheng J, et al. RGB-infrared cross-modality person re-identification via joint pixel and feature alignment[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3623-3632.
- [48] Zhao J, Wang H, Zhou Y, et al. Spatial-channel enhanced transformer for visible-infrared person re-identification[J]. IEEE Transactions on multimedia, 2022, 25: 3668-3680.
- [49] Chen C F R, Fan Q, Panda R. Crossvit: Cross-attention multi-scale vision transformer for image classification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 357-366.
- [50] Jiang K, Zhang T, Liu X, et al. Cross-modality transformer for visible-infrared person re-identification[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 480-496.
- [51] Chen C, Ye M, Qi M, et al. Structure-aware positional transformer for visible-infrared person re-identification[J]. IEEE Transactions on Image Processing, 2022, 31: 2352-2364.
- [52] Zhao J, Wang H, Zhou Y, et al. Spatial-channel enhanced transformer for visible-infrared person re-identification[J]. IEEE Transactions on multimedia, 2022, 25: 3668-3680.
- [53] Lu H, Zou X, Zhang P. Learning progressive modality-shared transformers for effective visible-infrared person re-identification[C]//Proceedings of the AAAI conference on artificial intelligence. 2023, 37(2): 1835-1843.
- [54] Van der Maaten L, Hinton G. Visualizing data using t-SNE[J]. Journal of machine learning research, 2008, 9(11).
- [55] Dai P, Ji R, Wang H, et al. Cross-modality person re-identification with generative adversarial training[C]//IJCAI. 2018, 1(3): 6.
- [56] Li D, Wei X, Hong X, et al. Infrared-visible cross-modal person re-identification with an x

- modality[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(04): 4610-4617.
- [57] Ye M, Shen J, J. Crandall D, et al. Dynamic dual-attentive aggregation learning for visible-infrared person re-identification[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVII 16. Springer International Publishing, 2020: 229-247.
- [58] Fu C, Hu Y, Wu X, et al. CM-NAS: Cross-modality neural architecture search for visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 11823-11832.
- [59] Ye M, Shen J, Lin G, et al. Deep learning for person re-identification: A survey and outlook[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(6): 2872-2893.
- [60] Zhang Q, Lai C, Liu J, et al. Fmcnet: Feature-level modality compensation for visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 7349-7358.
- [61] Su M C, Chen J H, Utami A M, et al. Dove swarm optimization algorithm[J]. IEEE Access, 2022, 10: 46690-46696.
- [62] Chen C F R, Fan Q, Panda R. Crossvit: Cross-attention multi-scale vision transformer for image classification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 357-366.
- [63] Jiang K, Zhang T, Liu X, et al. Cross-modality transformer for visible-infrared person re-identification[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 480-496.
- [64] Wu A, Zheng W S, Yu H X, et al. RGB-infrared cross-modality person re-identification[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5380-5389.
- [65] Nguyen D T, Hong H G, Kim K W, et al. Person recognition system based on a combination of body images from visible light and thermal cameras[J]. Sensors, 2017, 17(3): 605.
- [66] Zhao J, Wang H, Zhou Y, et al. Context-aware and part alignment for visible-infrared person re-identification[J]. Image and Vision Computing, 2023, 138: 104791.
- [67] Miao Z, Liu H, Shi W, et al. Modality-aware Style Adaptation for RGB-Infrared Person Re-Identification[C]//IJCAI. 2021: 916-922.
- [68] Hu W, Liu B, Zeng H, et al. Adversarial decoupling and modality-invariant representation learning for visible-infrared person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(8): 5095-5109.
- [69] Yu H, Cheng X, Cheng K H M, et al. Discovering attention-guided cross-modality correlation for visible-infrared person re-identification[J]. Pattern Recognition, 2024, 155: 110643.
- [70] 万磊,李华锋,张亚飞.多模态特征融合和自蒸馏的红外-可见光行人重识别[J].计算机辅助设计与图形学学报,2024,36(07):1065-1076.
- [71] Wu S, Shan S, Xiao G, et al. Modality blur and batch alignment learning for twin noisy labels-based visible-infrared person re-identification[J]. Engineering Applications of Artificial Intelligence, 2024, 133: 107990.
- [72] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.

- [73] Yu J, Rui Y, Tao D. Click prediction for web image reranking using multimodal sparse coding[J]. IEEE transactions on image processing, 2014, 23(5): 2019-2032.
- [74] Yu J, Tan M, Zhang H, et al. Hierarchical deep click feature prediction for fine-grained image recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 44(2): 563-578.
- [75] Wu L, Wang Y, Shao L, et al. 3-D PersonVLAD: Learning deep global representations for video-based person reidentification[J]. IEEE transactions on neural networks and learning systems, 2019, 30(11): 3347-3359.
- [76] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 403-412.
- [77] Si T, He F, Wu H, et al. Spatial-driven features based on image dependencies for person re-identification[J]. Pattern Recognition, 2022, 124: 108462.
- [78] Wu A, Zheng W S, Yu H X, et al. RGB-infrared cross-modality person re-identification[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5380-5389.
- [79] Li D, Wei X, Hong X, et al. Infrared-visible cross-modal person re-identification with an x modality[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(04): 4610-4617.
- [80] Xiang X, Lv N, Zhai M, et al. Dual-path part-level method for visible-Infrared person re-identification[J]. Neural Processing Letters, 2020, 52: 313-328.
- [81] Gao G, Shao H, Wu F, et al. Learning compact and representative features for cross-modality person re-identification[J]. World Wide Web, 2022, 25(4): 1649-1666.
- [82] Sun J, Li Y, Chen H, et al. Visible-infrared person re-identification model based on feature consistency and modal indistinguishability[J]. Machine Vision and Applications, 2023, 34(1): 14.
- [83] Wan L, Sun Z, Jing Q, et al. G2DA: Geometry-guided dual-alignment learning for RGB-infrared person re-identification[J]. Pattern Recognition, 2023, 135: 109150.
- [84] Ye M, Shen J, J. Crandall D, et al. Dynamic dual-attentive aggregation learning for visible-infrared person re-identification[C]//Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XVII 16. Springer International Publishing, 2020: 229-247.
- [85] Zhang J, Cao Y, Wu Q. Vector of locally and adaptively aggregated descriptors for image feature representation[J]. Pattern Recognition, 2021, 116: 107952.
- [86] Zhang J, Yang J, Yu J, et al. Semisupervised image classification by mutual learning of multiple self-supervised models[J]. International Journal of Intelligent Systems, 2022, 37(5): 3117-3141.
- [87] He S, Luo H, Wang P, et al. Transreid: Transformer-based object re-identification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 15013-15022.
- [88] Zhu K, Guo H, Zhang S, et al. Aaformer: Auto-aligned transformer for person re-identification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023.