

电子科技大学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 基于深度学习的行人重识别方法研究

学科专业 电子与通信工程

学 号 201622050536

作者姓名 吴江

指导教师 张萍 副教授

分类号

密级

UDC 注 1

学 位 论 文

基于深度学习的行人重识别方法研究

(题名和副题名)

吴江

(作者姓名)

指导教师

张萍

副教授

电子科技大学

成都

(姓名、职称、单位名称)

申请学位级别

硕士

学科专业

电子与通信工程

提交论文日期

2019.04

论文答辩日期

2019.05

学位授予单位和日期

电子科技大学

2019 年 06 月

答辩委员会主席

评阅人

注 1: 注明《国际十进分类法 UDC》的类号。

Deep Learning Approach for Pedestrian Re-identification

A Master Thesis Submitted to

University of Electronic Science and Technology of China

Discipline: Master of Engineering

Author: Jiang Wu

Supervisor: Associate Prof. Ping Zhang

School: School of Optoelectronic Science and Engineering

摘 要

行人重识别是计算机视觉中的重要技术，在视频监控、智能视频分析等领域具有广泛的应用前景和研究价值。其中，行人图像来源于不同的监控，对于同一个行人在不同的监控下，由于光照的变化，视角的改变，姿态的不同等，会造成较大差别，甚至在不同的摄像头下，不同的行人可能比同一个行人外貌特征更像，这使得行人重识别是一个很具有挑战性的课题。因此，行人重识别的研究重点是寻找能在跨视角下仍然具有稳定的具有判别性的特征以及度量方式。本文一方面从图像本身入手，通过显著性检测算法将行人图像背景冗余剔除，将人物前景提取出来，为提取特征作准备，另一方面通过构建神经网络来提取鲁棒的具有判别性的特征，进而识别。本文具体工作如下：

（1）针对行人重识别中不同视角下背景冗余问题，设计了一种基于简单线性迭代分割的显著性检测预处理算法。主要用来在特征提取之前，剔除图像背景冗余区域，从而使得在特征提取时获得较鲁棒的特征，提高识别率。

（2）设计了一种基于分块的验证网络模型的行人重识别算法。通过将每对输入行人样本对分成头部，头部和上身，全身三对，分别输入三对孪生网络中，进行训练。这种分块的结构有利于网络对图像局部进行更好的特征提取，再综合三部分识别结果进行综合判断，从而结果更加准确。

（3）在前章提出的验证网络模型的基础上，分析验证网络模型和鉴别网络模型对标签的利用，将每个子网络部分改成一个单独的鉴别网络，从而实现对相似性标签和 ID 标签的充分利用，同时针对在小数据集上识别效果不好的问题，本章利用生成对抗网络可以将数据集风格相互转换的特点，增加原数据集样本数，从而提高识别率。

关键词：视频监控，行人重识别，特征提取，距离度量

ABSTRACT

Pedestrian re-identification is an important technology in computer vision. It has broad application prospects and research value in the fields of video surveillance and intelligent video analysis. Among them, the pedestrian image comes from different monitoring. Under the different monitoring of the same pedestrian, due to the change of illumination, the change of the angle of view, the difference of the posture, etc., it will cause a big difference, even under different cameras, different pedestrians. It may be more like the appearance of the same pedestrian, which makes pedestrian recognition a very challenging topic. Therefore, the research focus of pedestrian recognition is to find discriminative features and metrics that can be stable under cross-view. In this paper, from the image itself, the dominant image background is redundantly eliminated by the saliency detection algorithm. The foreground of the characters is extracted and the features are extracted. On the other hand, with the hot learning of deep learning, the convolutional neural network is widely used for its powerful feature extraction ability. we constructs a neural network to extract robust discriminative features. And then identify. The specific work of this paper is as follows:

(1) Aiming at the background redundancy problem in different perspectives of pedestrian recognition, a saliency detection preprocessing algorithm based on simple linear iterative segmentation is designed. It is mainly used to eliminate the redundant background of the image background before feature extraction, so that the feature extraction can obtain more robust features and improve the recognition rate.

(2) A pedestrian re-identification algorithm based on the block-based verification network model is designed. Each pair of input pedestrian sample pairs is divided into three pairs of head, body and foot, which are input into three pairs of siamese networks for training. This network of block structure facilitates the network to perform better feature extraction on the image part, and then comprehensively judges the results of the three parts of the recognition, so that the result is more accurate.

(3) Based on the verification network model proposed in the previous chapter, the verification and verification network model and the identification of the network model use the tags, and each sub-network part is changed into a separate authentication network, so as to fully utilize the similarity tags and ID tags. At the same time, for the problem of

ABSTRACT

poor recognition on small data sets, this chapter uses the feature of generating a confrontation network to convert the data set styles to each other, and increases the number of samples in the original data set, thereby improving the recognition rate.

Keywords: Video Surveillance, Person Re-identification, Feature extraction, Distance metric

目 录

第一章 绪论	1
1.1 课题研究的相关背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于特征提取的行人重识别	2
1.2.2 基于距离度量的行人重识别	4
1.3 本文研究内容	5
1.4 论文结构安排	5
第二章 本文相关研究工作	7
2.1 显著性检测算法	7
2.1.1 视觉注意机制	7
2.1.2 经典显著性检测模型	8
2.1.3 超像素分割方法	10
2.2 神经网络在行人重识别的应用	12
2.2.1 卷积神经网络	12
2.2.2 验证网络模型	15
2.2.3 鉴别网络模型	17
2.2.4 生成对抗网络	19
2.3 行人重识别数据集与评价指标	23
2.3.1 数据集	23
2.3.2 评价指标	25
2.4 本章小结	26
第三章 基于显著性检测和验证网络的行人重识别	27
3.1 算法思路	27
3.2 显著性检测预处理	28
3.2.1 图像超像素分割	29

3.2.2 对超像素快进行特征提取	30
3.2.3 初始显著性计算	30
3.2.4 建立图模型优化	31
3.3 构建验证网络模型	33
3.4 实验及分析	35
3.4.1 网络训练及参数优化	36
3.4.2 在 Market1501 数据集实验结果与分析	36
3.4.3 在 PRID 数据集实验结果与分析	39
3.4.4 本章算法效率测试实验	41
3.5 本章小结	41
第四章 基于验证鉴别网络的行人重识别	42
4.1 算法思路	42
4.2 验证鉴别网络	43
4.3 网络模型的构建	44
4.4 生成对抗网络优化	45
4.5 实验及分析	47
4.5.1 网络训练及参数优化	47
4.5.2 在 Market1501 数据集实验结果与分析	48
4.5.3 在 PRID 数据集实验结果与分析	50
4.5.4 GAN 网络对行人重识别优化实验	51
4.5.5 实地拍摄视频实验	54
4.5.6 本章算法效率测试实验	55
4.6 本章小结	56
第五章 总结和展望	57
5.1 本文工作总结	57
5.2 工作展望	58
致 谢	59

参考文献	60
攻硕期间取得的研究成果	65

第一章 绪论

1.1 课题研究的相关背景及意义

近年来,无论是文字、语音,还是图像视频等信息越来越多,呈现信息爆炸的姿态,互联网使得信息的获取,传播的范围空前的扩大^[1],实现全球的信息共享和交互,其中图像与视频信息占据很大一部分比重,因此,计算机智能化帮助人类处理、分析所获得图像数据是大势所趋,计算机视觉是一门主要通过模拟人类的视觉,使得计算机能够像人眼一样有效智能的处理大量的数据^[2],从而节省人力。其中行人重识别是计算机视觉的一个重要研究方向。它主要被应用在智能的视频监控系统当中。

21 世纪以来,安全问题一直是许多国家所面临的重大问题,各个国家和地区在安防领域的投资越来越大,呈现逐年上升趋势,视频监控系统可以监视人们在公共场所的行为,对犯罪嫌疑人和犯罪行为可以有效的记录,近年来,无论是英美,还是国内,在火车站,地铁站,机场,还是医院,住宅小区,学校等人群密集聚集地,无不安装大量的监控。而在拍摄的监控视频中,最重要的就是对视频中拍摄的目标进行识别,比如红绿灯识别^[3],车牌号码牌识别^[4],车辆类型识别^[5],人脸识别^[6]等等,而在这些不同的对象中,最主要的还是人的识别,对视频中的行人进行检测、跟踪、识别是计算机视觉的三个重要的研究方向,行人重识别是从多监控追踪^[7]中独立出来的研究方向,在多监控目标追踪研究中,由于目标跨监控,当其出现在一个新的监控下,首先必须对其进行检测,识别,判断其是否属于上一个监控下的目标,再进行追踪。因此对行人进行重识别意义重大。

对于人类来说,要去识别不同位置监控所拍摄到的同一个目标,并不是非常困难,然而,由于光照的变化,视角的改变,姿态的不同等,可能导致在不同的监控下,不同的行人比同一个行人外貌特征更像,因此通过计算机视觉算法去进行识别,难度较大,具体困难包括:

(1) 由于每个摄像头位置不同,角度不同,行人在不同的时间下有不同的姿态,导致采集的行人图像产生不对齐问题。

(2) 由于在不同的位置,不同的角度,导致光照条件不一样,则对于行人而言身体的颜色可能会发生变亮色或者变暗色,给行人图像提取判别性特征造成困难,使得行人匹配难度增加。

(3) 当监控视频位于人群比较多的环境中,人群密集,导致行人之间遮挡比较严重,这使得难以提取到目标的特征。

(4) 由于行人图像位于不同的监控摄像头下, 因此特征分布空间不一样, 导致距离度量困难大。

(5) 有些监控视频的图像分辨率比较低, 这对图像分析造成重大困难。

综上所述, 妥善的解决由于监控系统中各个监控所处的不同的位置所带来的一系列问题, 提出具有鲁棒识别效果的行人重识别算法具有重大意义。

1.2 国内外研究现状

行人重识别起源于多相机追踪, 在早期行人重识别中, 在多相机追踪时, 最重要的一步是, 当目标离开当前监控, 在下一监控出现时, 要将其进行识别, 随后慢慢独立为一个单独的研究方向。1997 年, Huang 和 Russell 等^[8]基于贝叶斯模型根据一个相机下目标的时空特征等来预测其在另外一个相机下的状态, 2005 年, Wojciech Zajdel 和 Zoran 等^[9]在 “Keeping track of humans: Have I seen this person before?” 文章中首次提出术语 “person re-identification”, 并提出定义, 即当一个目标离开视角后, 再次重新回到此视角下, 能够重新识别出目标。2006 年, Gheissari 等^[10]利用基于时空分割算法的前景检测结果进行匹配, 并提出第一个总共包括 44 个人的行人重识别数据集。行人重识别主要任务是, 将 Query sets 中的每个目标都能在 Gallery sets 中找到匹配的目标, 其主要研究过程包括特征提取和距离度量, 因此本文主要从这两个方面分别介绍一些经典的算法。

1.2.1 基于特征提取的行人重识别

基于特征提取的行人重识别目前被研究较多, 这里从传统特征提取和深度特征提取两个角度分别介绍。

在传统特征提取算法中, 最重要的是手工设计对行人的鲁棒的特征表示, 其中, 最普遍使用的特征是颜色特征, 其次是纹理等特征。M. Farenzena 等^[11]首先通过分割算法将行人提取出来, 再以人体为目标, 设计对称轴, 计算权重颜色直方图(WH), 最大稳定颜色区域(MSCR)和低频结构块(PHSP)来提取特征, Gheissari 等^[10]提出了一个基于时空信息的前景分割算法来检测前景目标, 对于每个局部块分别提取边缘直方图和 HS 直方图, Gray 和 Tao^[12]提出将行人分成水平条, 并且对每个水平条提取了 8 个颜色通道(RGB, HSV, YCbCr)和用了 21 个结构滤波提取纹理特征, 后面包括^[13]等方法都是基于分块提取特征的思想, 差别在于使用不同的底层特征, 如 Mignon 等^[14]同样将行人图像分割成多个水平条, 但提取的是 RGB, YUV 和 HSV 颜色和 LBP 纹理特征, 取得比较好的效果。

香港中文大学 Rui Zhao 等^[15]提出无监督的显著性学习方法，文章提出利用块匹配来解决由于监控下不同的场景和不同视角下行人姿态不同导致的不对齐问题，作者通过对图像提取 SIFT 特征和颜色直方图，并进行权重结合，获得比较好的识别效果。中科院的 Liao 等^[16]提出局部最大值表示（Local Maximal Occurrence，LOMO）描述子，先用 max-pool 对图像采样，得到三个尺度的高斯金字塔，然后同样将每个尺度图像进行水平分条，分块，提取颜色和 SILTP 特征，再用局部最大构建新的直方图。清华大学 Zheng^[17]提出对每个小块提取 11 维的 color names 描述子，然后用词包模型构成全局向量，取得较好的效果。

除了直接使用底层颜色纹理特征以外，还可以使用中层表示的基于语义的特征。比如，上衣的款式，裤子的款式，鞋子类型，T 恤的类型，发型等等，伦敦玛丽王后大学 Layne 等^[18]人对将语义特征用于行人重识别中做出了较大的贡献，他提出包括衣服类型、发型、性别等 15 种包括服装和软生物识别的语义特征，再通过支持向量机（Support Vector Machine, SVM）进行分类。

2014 年，深度学习的浪潮涌进行人重识别领域，通过卷积神经网络对行人提取深度特征取得非常好的效果。由于训练样本数量的限制，比如 VIPeR 数据集，每个行人图像来源于两个视角，其每个视角只有一张样本。因此，Yi 等^[19]和 Li 等^[20]都选择使用基于孪生网络的验证网络模型（verification model）进行训练，测试一对输入样本是否属于同一个体，Yi 等^[19]提出，将输入的行人图像分成 3 个有重叠的水平条，然后用训练好的三个 part-CNNs 进行提取特征，再用余弦距离来计算相似度。Li 等^[20]提出加入一个块匹配层，即将两个输入图像的同一个位置的水平条进行匹配，计算相似度。Cheng 等^[21]提出一种多特征融合的算法，即将输入图像分成 4 个部分，对各个部分进行局部特征提取，再结合整幅图像全局特征作为特征向量。Varior 等人^[22]提出将 CNN 与一些门函数相结合，类似于精神上的长期短期记忆（LSTM），其目的是使得网络自适应地关注输入图像对的相似部分。但是由于每个 query 必须与每个 gallery 配对才能通过网络，因此导致计算消耗非常大，效率低。

近年来，CUHK03 和 Market1501 等大尺度数据集被提出，在 CUHK03 数据集中，平均每个个体有 9.6 张训练图片，而在 Market1501 数据集中，平均为 17.2 个，因此通过训练一个更深的鉴别网络模型（identification model）来进行重识别成为可能，清华大学 Zheng 等^[23]直接使用 Market1501，PRW，MARS 等大尺度数据集在预训练的网络进行微调，直接获得较好的效果。Wu 等^[24]在全连接层部分结合传统手工设计的特征，通过将深度学习的特征和手工传统特征结合，提出了一个新的研究方向。香港中文大学的 Xiao 等^[25]训练了一个类似快速基于区域的卷积神经网络

(faster-Region-based Convolution Neural Networks, faster-RCNN) 的模型, 其能自动的从整幅图像中检测并识别出 query 图像, 并且此模型还能够提升检测精度。

蒙特利尔大学的 GoodFellow 提出生成对抗网络 (GANs), GAN 为无监督学习模型提供了强有力的算法框架, 其后在 GAN 网络基础上衍生了许多网络, zheng 等^[23]通过深度卷积生成对抗网络 (Deep Convolution Generative Adversarial Networks, DCGAN) 对数据集训练样本进行训练, 并生成新的训练样本, 通过所提出的对生成样本标签进行平均分配 (label smoothing regularization for outliers, LSRO) 算法, 来增强数据集, 从而提高识别效果。

1.2.2 基于距离度量的行人重识别

由于行人图像来源于不同的视角, 不同光照等使得要构造一个高维度的具有判别性的特征非常困难, 近年来大量文献考虑使用距离度量的方法。经典的距离度量方法有, 欧式距离、巴氏距离、曼哈顿距离等等, 但是这些经典的距离函数均未考虑样本本身特性, 效果不是很理想, 而一系列通过学习样本特性, 学习到一个马氏形式的距离函数成为主流。Liu 等^[26]对距离度量模型进行了一个全面的分析总结, 他们将距离度量模型分成监督的全局度量模型, 监督的局部度量模型, 非监督的距离度量学习模型, 基于支持向量机 (SVM) 的距离度量学习模型等, 而对于行人重识别, 主要还是使用监督的全局距离度量学习模型。而全局距离度量模型的核心思想是, 使得原本属于同一个类别的目标在高维特征空间中相互靠近, 原本不属于同一目标在高维空间中相互远离。一般用马氏距离作为普遍学习的函数。

2002 年, 卡内基梅隆大学 Xing 等^[27]人根据马氏距离的表达形式, 将矩阵 M 作为一个参数, 然后通过学习正负样本对求得参数矩阵 M , 使得模型类内间距比类间间距小。即可以很好的分离出样本对是否相似。2012 年, Kostinger 等^[28]人基于马氏距离提出基于简单而且直接的策略 (Keep it Simple and Straight, KISS) 的距离度量学习算法, 将样本对是否相似转换为一个似然概率测试。该方法不需要繁琐的迭代优化过程, 通过求出训练样本的分布参数即可求得, 但当训练样本数据不足时, 模型参数估计不准确, 效果不是很好。Weinberger 等^[29]提出了大边缘最近邻学习 (large margin nearest neighbor Learning, LMNN) 方法, 该方法为目标近邻对 (匹配对) 建立边界并对进入边界的非目标样本进行惩罚^[30]。Davis 等^[31]人考虑 LMNN 训练时会出现过拟合等问题, 提出信息理论度量学习 (information-theoretic metric learning, ITML) 通过尽量使得学习到原始的距离分布从而有效的缓解了过拟合问题。

2011 年, 中山大学郑伟师等^[32]人等人首次将距离度量学习算法的思想引入到行人重识别问题, 作者通过使用类似 LMNN 算法中的三元组形式的样本对的思想, 提出了概率相对距离比较的距离度量学习算法。但与 LMNN 不同的是, 作者并未使用 LMNN 中所采用的 hinge 误差函数, 而是采用 logistic 误差函数, 因此把最终的目标函数转换成一个凸优化的平滑问题, 而且作者通过对矩阵 M 加入了额外的约束从而有效地避免了过度拟合。2013 年, 为了减少标注样本的需求^[33], 作者在概率相对距离比较算法的基础上, 提出基于 Adaboost 的算法有效的降低了标注样本的成本。东北大学 Fei Xiong 等^[34]人从提高提取的特征的鲁棒性和行人重识别分类器的学习, 提出了一种基于核函数的度量学习的算法, 获得较好的效果。

1.3 本文研究内容

本文主要是研究深度学习在行人重识别上的应用, 主要研究工作如下:

(1) 在行人重识别中, 由于不同视角导致, 行人背景复杂, 从而影响识别, 因此, 本文设计一种基于简单线性迭代聚类(simple linear iterative cluster, SLIC)^[35]的显著性检测的行人重识别预处理算法, 主要用来剔除背景冗余区域, 从而使得在特征提取阶段获得鲁棒的特征, 提高识别率。

(2) 在特征提取部分, 传统手工特征设计算法, 通过针对样本特点, 专门设计一种稳定的特征提取算子, 但其迁移性不好, 且随着样本增多, 识别率显著下降, 近年来, 深度学习被广泛用于特征提取, 通过训练样本, 可以获得鲁棒的特征提取算子, 因此本文设计了一种基于分块验证网络模型的深度学习行人重识别算法, 获得较好的效果。

(3) 分析验证网络模型在样本标签的利用上不足, 从而在第三章提出的验证网络模型的基础上, 通过向验证网络的每个子网络引入分类损失函数, 从而提出一种验证鉴别网络模型, 能够同时利用相似性标签和 ID 标签, 取得较好的效果。

(4) 由于在小数据集上识别效果整体不好, 因此引入生成对抗网络(GAN), 利用 CycleGAN 可以将图像风格相互转换的特点, 可以将现有数据集转换到待测数据集, 增大训练样本, 再进行训练测试, 能有效的提升识别率。

1.4 论文结构安排

本文主要内容围绕行人重识别展开, 梳理了行人重识别的技术来源与发展脉络, 针对行人重识别中背景冗余问题, 设计一种显著性检测算法作为预处理, 提高准确率, 在特征提取部分, 通过改进孪生卷积神经网络进行训练, 从而获得鲁棒的

特征，另外通过研究 GAN 网络，将 GAN 网络运用于行人重识别中，使得提高了算法在原本数据集的精度。本文的具体内容分为以下五个章节：

第一章是绪论，主要介绍了行人重识别的发展相关背景，以及对当今社会的意义，并且分析目前行人重识别主流的研究方向，分别从基于特征提取，与基于距离度量两个角度介绍发展状况，最后总体上介绍本文的主要研究内容。

第二章主要是介绍本论文相关工作，包括显著性检测算法，目前常用的神经网络，各种损失函数，最后还介绍了在行人重识别领域常用的数据集和评价指标。

第三章具体研究行人重识别的预处理过程，提出一种基于 SLIC 的显著性检测与处理算法来规避背景信息对特征提取的干扰，并且分析行人图像的特点，提出基于分块的孪生的卷积神经网络作为特征提取，进而分类识别。

第四章在第三章提出的网络基础上，分析验证网络对行人重识别标签的利用不充分，因此，将网络进行改进，将每个孪生网络的子网络增加鉴别损失，再将验证损失和鉴别损失同时进行训练收敛，从而提高精度；另外针对在小数据集上识别效果不好的问题，研究将 GAN 网络融入行人重识别框架，通过 GAN 的风格迁移，从而提升准确率。

第五章是总结和展望部分，主要是总结论文的主要工作和一些成果，反思研究的一些不足之处，并讨论论文的未来研究方向。

第二章 本文相关研究工作

2.1 显著性检测算法

2.1.1 视觉注意机制

人类长期通过眼睛观察和认识世界万物，眼睛赋予了人类与自然界，与周围的环境相互沟通的能力。长久以来国内外生物学家，心理学家，物理学家等对眼睛能够快速处理外界环境信息的能力非常感兴趣，并形成了一套完整的视觉注意机制理论，即视觉注意机制。下面对其进行简要介绍：

人类的视觉系统最重要的一个任务是将眼睛看到的外界的繁杂的信息进行有效的整理，从而映射到视网膜上，再由大脑中与视觉相关的神经中枢进行处理，将这些繁杂的单独的碎片化的信息整合成连续的看得见的单元，再将这些可见单元组合成完整的图像^[36]，并且图像中，物体和背景有完整的边界，相互隔开。对于人类而言，目光一般仅仅集中在物体上，忽略背景，并且虽然聚焦于物体，但只是关注物体的整体，而非具体某些细节。即当人类视觉系统处理外界复杂信息时，通过视觉相关神经中枢处理完图像后，往往关注的是某些区域，对背景进行忽略。

针对人类视觉注意机制是怎么高效处理外界信息，各国研究人员对其展开了诸多研究，目前，基本上认为人类视觉机制主要有两种方式，自上而下和自下向上。

自上而下的视觉注意机制最主要的特点是，人通过自我意识有选择性的主动的控制视觉系统去寻找目标，对于与目标相关的信息进行处理识别^[36-39]，而不相关的信息自动滤除。这个机制和具体任务非常相关，以目标来驱动，是一种主动行为，通常需要对所寻找的目标有较清晰的了解，如目标的大小，颜色等等。而相对的对于计算机系统而言，则应当是收集所需寻找目标的具体特征，收集大量的类似目标的样本，训练分类器，则可能有效识别出目标。

由于自上而下的机制与具体目标相关性非常高，而不同的目标之间差异性往往很大，对于计算机而言，针对不同的目标需要训练不同的分类器，因此，难以得到较通用的模型。所以目前对自上而下的机制研究较少。

自底向上的视觉注意机制与自上而下的机制最大的不同在于非任务驱使，因此这个机制是由图像本身的信息决定，对于人类而言，即人具体关注图像的哪一个区域，完全由图像本身决定，与主观意识无关，正因为这种机制，使得自底向上视觉注意模型受到更为广泛的研究。自底向上机制本质是将图像中的那些与周围区

域在表现特征上有明显差异的区域显现出来,使得人眼的视觉能更容易看到这些区域,从而视觉系统可以对这些区域着重分析。

目前,在视觉注意模型中,常用的表现特征有颜色,亮度,纹理,形状等,对于一些视频信息,除了考虑图像本身的表现特征以外,还可以利用运动特征,本文这里对这些特征做一些简单介绍:

(1) 颜色特征

人体视觉中通过锥状细胞分辨感知颜色,而颜色特征是图像特征中最基本,也是最重要的特征,除了显著性检测以外,在行人检测,行人重识别等领域均被广泛使用。颜色的表示模型有很多种,目前最常用的是国际照明委员会提出的 RGB 和 CIE Lab 颜色空间模型,其中 RGB 被广泛用于电脑显示器等硬件领域,而 CIE Lab (L 表示亮度, a 值越大表示越偏向红色,越小则表示偏向绿色, b 值越大表示偏黄色, b 值越小表示偏蓝)由于更加复合人类视觉感受,因此在计算机视觉中被使用更多,一般颜色度量使用欧式距离进行度量。

(2) 亮度特征

亮度特征同样是人类视觉系统感知到的最基本的特征,人眼通过杆状细胞^[40]识别亮度特征,其中在 RGB 颜色空间中,通过简单计算可以得到亮度特征。

(3) 纹理特征

纹理特征是一种表示图像表面的颜色,亮度等梯度的变化,反映物体表面的分布规律,常用于图像分类和场景识别。纹理特征具有旋转不变性和良好的抗噪性优点,但对尺度变化较为敏感。常用的纹理特征提取算法有灰度共生矩阵,局部二值表示(LBP)^[41], DCT^[42]变换等。

(4) 形状特征

形状特征表示的是物体的形状,比如是圆形还是方形,其中常用的数学表示有很多,如边缘曲线的斜率等等,形状特征在图像处理和模式识别中同样被广泛使用,具有尺度不变性,并且不受光照等条件影响。

2.1.2 经典显著性检测模型

显著性检测模型种类非常多,其中图论模型,基于全局和局部的区域对比度模型被广泛使用,下面对这两种模型分别简要介绍:

(一) 区域特征对比度模型

1998 年 Itti 等^[37]提出一种基于中央周边机制的视觉注意模型,通过对图像进行不同大小尺度的分解,然后提取各个分解图的底层特征,再用中央-周边机制计算不同尺度的显著性图,最后采用多尺度融合方法得到最终显著性图。

区域特征对比度模型主要的机制是计算图像中各个图像块之间的差异，而这些差异往往更吸引人类关注的焦点，即感兴趣区域，因此可以用来表示该区域的显著性，一般流程图如图 2-1 所示。




图 2-1 基于区域对比度的显著性检测基本流程

其具体过程如下：

(1) 图像分块处理

对图像分块处理一方面是为了降低计算量，另一方面是为了将图像划分成不同的统一整体的区域，使得图像较为连续，目前对图像有两种分块方式：

将图像分成每个大小为 8×8 或者 16×16 小图像块，优点是对每幅图像通用划分，计算效率高，但破坏了图像的整体结构，即图像中同一个物体的边缘被分割成不同的小块，使得后续计算显著性效果不好。

与均匀统一分块不同，目前利用图像的颜色，亮度等底层特征，将图像分块成大小不统一但内部具有一致特征的图像块，这种分块方式保持了图像中物体的轮廓边缘，使得最终的显著性图更符合人眼的感受。

(2) 对不同分割区域特征提取

通过(1)步对图像进行分块之后，需要对每个图像块进行特征提取，一般常用的方法包括：

对图像块内所有像素对应的特征进行累计叠加作为整个图像块的特征；

通过统计的方式表述图像块，如提取图像块的颜色或者灰度直方图；

(3) 计算区域的特征对比度

像前面所述，人眼通常对与周围区域差异较大的区域较为关注，因此通过计算当前图像块与周围图像块的特征对比度能很好的表示当前块的显著性，常用的特征包括颜色、亮度、纹理等，具体计算方法有：

只计算当前图像块和周围一定范围图像块的特征差异；

计算当前图像块与整幅图像所有图像块的差异；

具体计算方式为由（2）中得到的表示图像块特征的值或者向量，与其他图像块进行欧式距离度量。

(4) 不同特征的显著性融合

对于（3）得到的不同特征的特征对比度图，即显著性图，通过加权的方式进行融合，得到最终显著性图。

(二) 概率图模型

概率图模型主要用来表示变量之间概率依赖关系的模型，根据所采用的不同类型的图可以将概率图模型分为贝叶斯网络和马尔可夫随机场。贝叶斯网络主要用的是有向无环图来表示变量之间关系，图的每个节点表示一种条件概率分布或者先验分布，则所有节点分布的乘积构成总的联合分布；马尔可夫随机场采用无向图表示变量之间的关系，其联合概率表示为势函数的乘积。概率图模型在显著性检测中可以用来优化结果。

2006 年 Harel^[42]等人在 Itti 模型的基础上，提出将整幅图像可以作为一个图结构，其中每个像素表示图的节点，像素之间的相似度表示图的边，当两个像素越相似，则边越短，从而构成了图模型。则可以通过图理论进行显著性度量，如 Yang^[44]等人提出基于图模型的流行排序算法，即将图中每个节点结果进行排序，排在前面的被认为是前景图，排在后面的为背景图。此后 Jiang 等^[45]人将贝叶斯网络和马尔可夫链引入显著性检测中，但计算量较大。

2.1.3 超像素分割方法

在区域对比度模型中，图像分割是非常重要的一步，不仅仅是能够降低计算量，同时，分割的结果往往对最终的显著性结果产生较大的影响，以往都是将图像进行均匀分割成 8x8 或 16x16 的小块，但缺点是对图像中的物体的边缘分割的粗糙。因此效果不好，近几年超像素分割技术发展火热，相比传统的均匀分割，超像素分

割通过图像本身的底层特征将图像分割成内部在颜色、亮度等特征上一致的超像素块，而且能有效的保持图像中物体的边缘信息。




图 2-2 超像素分割示意图。(a)原图；(b)超像素分割结果

图 2-2 为超像素分割示意图，左边为原图，右边为超像素分割结果，

超像素分割利用图像的颜色，纹理等底层特征，将人物前景分割出来，并较好的保持了人物轮廓。目前超像素分割算法有很多，其中 Achanta^[35]等人提出的简单线性迭代(simple linear iterative cluster, SLIC)超像素分割方法被广泛使用，和其他相比，SLIC 能完好的将图像中的物体的轮廓保存好，并且运算速度快，因此后续有很多算法在此基础上进行改进。

SLIC 算法主要是利用 k-means 算法对图像进行局部聚类，即首先在图像中均匀撒出超像素种子，再对每个种子的局部范围内进行聚类，图 2-3 为分割示意图。




图 2-3 超像素分割示意图

SLIC 的具体算法流程如下：

(1) 选取种子像素

首先定义初始的种子像素个数，再进行均匀选取，即每在一个边长为 $s = \sqrt{N/K}$ 的正方形区域选取一个种子点，其中 K 为设置的种子个数， N 为图像总像素数。以 S 作为抽样步长，对图像进行抽样，选取初始种子点，为了防止种子点取到图像中物体的边缘位置，导致对边缘分割不好，因此采取以所选取的种子点为中心，在周围 3×3 的邻域内进行种子点更新，计算 3×3 范围内每个像素的

梯度值，由于梯度越大代表越可能处在图像物体上的边缘处，因此取梯度最小的像素作为真正的种子像素，同时给像素进行标号。

(2) 局部像素聚类

当选取完种子像素后，第二步就是对像素聚类，以获得超像素块，这里聚类方法采用的是局部 **k-means** 聚类，原因是对于一副图像而言，一个物体不可能是分割在不同的区域，即一定是连通的，因此不需要进行全局聚类，而且可以减少计算量。则对每个超像素 $2s \times 2s$ 范围内的像素进行聚类，如图 2-3 所示，对每个种子点的 $2s \times 2s$ 像素范围内，计算每个像素与种子点像素的相似程度，将其归类为与其最相似的像素，当整个遍历完所有图像之后，再重新根据每个像素块所包含区域的均值作为新的种子像素，再重新计算相似度，最终达到收敛条件停止。

在计算相似度时，SLIC 采用的是颜色和位置特征，即对于每一个像素可以用一个 5 维向量来表示，如式(2-1)所示。

$$f = [r, g, b, m, n] \quad (2-1)$$

这里 $[r, g, b]$ 表示三维颜色， $[m, n]$ 表示此像素离图像左上角的距离，则像素之间相似性度量公式可以写作为：

$$d_f = \sqrt{(r_i - r_j)^2 + (g_i - g_j)^2 + (b_i - b_j)^2} \quad (2-2)$$

$$d_s = \sqrt{(m_i - m_j)^2 + (n_i - n_j)^2} \quad (2-3)$$

$$d = \sqrt{d_f^2 + \left(\frac{d_s}{s}\right)^2 g^2} \quad (2-4)$$

式(2-2)为颜色距离，式(2-3)为位置距离，式(2-4)为总的距离， g 为权重参数， s 为种子点选取时的采样步长。

(3) 孤立像素点优化

在经过迭代处理之后，图像可能会出现一个孤立的与聚类中心不连通的像素点，对于这些孤立的点，将他们归类为与他们连通且相似度最近的超像素块。

2.2 神经网络在行人重识别的应用

2.2.1 卷积神经网络

卷积神经网络 (Convolution Natural Network, CNN) 属于深度学习中一种重要的网络，其专门被用来处理具有网状结构的数据的神经网络，如图像数据等。20 世

纪 90 年代, Yann Lecun^{[46][47]}提出 LeNet-5 网络, 并用其开发出用于读取银行支票上的手写数字的商业软件, 这是最早用于解决重要商用的神经网络。2010 年, ImageNet 项目组每年都会举办一次大规模视觉识别挑战赛, 比赛主要内容为对物体和场景进行检测和分类, 至今涌现了许多优秀的卷积神经网络, 包括 AlexNet、VGGNet 和 ResNet 等, 下面对这些网络进行简要介绍:




图 2-4 LeNet-5 网络结构图^[46]

如图 2-4 所示, LeNet-5^[46]网络由 Lecun 提出的最早的卷积神经网络模型, 网络总共包括 7 层, C 代表卷积层, S 代表池化层, F 为全连接层。网络的每一个卷积层后都连接一个池化层和 sigmoid 激活函数, 在手写数字字符集上, 准确率达到 98%。




图 2-5 AlexNet 网络结构图^[48]

2012 年, 在 ImageNet 比赛上, Hinton 和其学生 Alex 提出 AlexNet^[48]在实验中准确率达到 57.1%, 获得当年比赛的冠军, 网络包括 8 层结构, 其中 5 个卷积层, 3 个全连接层, 如图 2-5 所示。作者通过使用两块 GPU 进行加速运算, 从而有效的降低了训练时间, 并使用 Relu 作为激活函数, 缓解了由于网络较深带来的梯度消失的问题。作者还通过使用 dropout 和 LRN 层来防止网络过拟合, 增强了网络的通用性。

VGGNet^[49]是由牛津大学和 DeepMind 公司共同研发的卷积神经网络，在 2014 年 ImageNet 比赛中获得第一名，网络依据不同的深度有不同的版本，常用的包括 VGG16 和 VGG19，如图 2-6 所示为 VGG16 的网络结构，卷积层和全连接层加起来一共 16 层，其中卷积核的大小均为 3×3 ，池化层均为大小 2×2 ，步长 2 的最大池化，VGG 相比于 AlexNet 网络更深，并通过多个卷积层，使得网络的感受野更大，并且可以降低参数数量，并且在训练时，通过将样本缩放到不同尺寸，来增加训练样本，从而获得较好的实验结果。




图 2-6 VGG16 网络结构图^[49]

随着网络层数越来越多，实验发现梯度消失问题严重，导致识别效果下降，2015 年，He 等^[50]提出残差网络模型(ResNet 模型)，并成功训练出 152 层的卷积神经网络，识别效果非常好，并且拓展性很强，其中残差网络主要由残差块构成，具体结构如图 2-7 所示。




图 2-7 残差块模型

残差网络引入跨层的思想对于输入 x ，直接把输入传到输出作为初始结果，输出结果为 $H(x) = F(x) + x$ ，当 $F(x) = 0$ 时，那么 $H(x) = x$ ，即为一个恒等映射，恒等映射没有带来误差的上升，但加深了网络层数，有利于提高识别率。于是，通过引入残差块，ResNet 学习目标值和输出的残差值 $F(x) = H(x) - x$ ，而不再去直接学习输出 x 。因此，后面的训练目标就是要将残差结果逼近于 0，使得随着网络加深，准确率不下降。这种残差跳跃式的结构的创新点在于不像以往的神经网络，每一层都向下一层传输，这里直接跨越一层甚至几层输出，有效的缓解了梯度消失的问题，理论上来说残差网络可以无限深，但目前较常用的为 34、50 层等。

如图 2-8 所示，ResNet-50 这里使用 Bottleneck 残差模块，即相比于普通的残差块，这里 Bottleneck 残差模块将原本的 3×3 的卷积核变成两个 1×1 的卷积核，第一个 1×1 主要用来降低通道数，然后 3×3 用来再降通道之后的特征上卷积，第二个 1×1 用来升通道。这样的好处是能够降低参数数量。

层名	conv1	Conv2_x	Conv3_x	Conv4_x	Conv5_x
核子大小	$[7 \times 7, 64]$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
输出尺寸	112×112	56×56	14×14	7×7	1×1

图 2-8 ResNet-50 网络结构图

传统手工提取特征，需要人为的根据样本特性，环境等条件，设计一种鲁棒的特征，这往往是非常困难的，而卷积神经网络通过自动学习样本特性，调整参数，从而学习到鲁棒具有判别性的特征，因此被广泛使用。目前，在行人重识别领域，根据输入样本的数量可以简单的将 CNN 网络分成验证网络模(verification models)和鉴别网络模型(identification models)，下面将分别介绍这两种模型。

2.2.2 验证网络模型

从输入样本数量上，验证网络模型一般输入为一对图像，将一对样本作为输入，输出为 0 或 1，类似二分类或者相似回归问题。网络结构一般使用孪生网络(Siamese network)，即两路共享权值的 CNN 作为特征提取，再进行相似性度量，最后分类识别。

在训练过程中，验证网络模型训练数据为一对样本，标签为 0 或 1，然后，通过训练将样本映射到高维空间，使得对于同一个 ID 的两张输入样本在高维空间中尽可能靠近，而不同 ID 的两张输入样本在高维空间中尽可能远离。最终验证网络模型能够很好的学习到输入样本对的差异，从而判断出输入样本对是否为同一个

ID。在测试阶段，将孪生网络中任意一个子网络作为特征提取器，将目标图像与待识别图像分别输入，从全连接层中获取到鲁棒的特征，标准化，再进行欧式距离度量，从而可以计算出两幅图像的相似度。

验证网络模型损失函数一般使用对比损失函数，对比损失函数能有效的处理验证网络模型中的 *paired data* 的关系。其表达式如下(2-5)所示。

$$L = \frac{1}{2N} \sum_{n=1}^N y d^2 + (1-y) \max(\text{margin} - d, 0)^2 \quad (2-5)$$

其中 $d = \|a_n - b_n\|_2$ ，为两个样本特征的欧氏距离， y 为标签，代表两个样本是否匹配，如果 $y=1$ 表示两个样本属于同一个类别，相互匹配； $y=0$ 则表示样本为不同类别，不相似，*margin* 代表阈值。这种损失函数最初来源于 Yann LeCun^[51]的通过学习不变映射来降维文章，主要思想为通过将样本映射到特征空间中，使得类内相似的样本相互靠近，类间不相似的样本相互远离，从对比损失的表达式中可以看出，当 $y=1$ （即样本相似）时，损失函数为 $\sum y d^2$ ，表示当两个样本为相似样本时，他们的距离越大则损失函数越大，则惩罚也越大，当 $y=0$ （即样本不相似）时，损失函数为 $\sum (1-y) \max(\text{margin} - d, 0)^2$ ，即表示当两个样本不相似时，他们的特征距离越大，则损失就越小，则惩罚也就小，正好符合验证网络模型的需求。函数曲线图如 2-9 所示。




图 2-9 对比损失函数曲线

验证网络模型最早应用可追溯到 1993 年，Bromley 等^[52]人首先将验证网络模型用于签名验证中的深度度量学习。将正确签名与待验证签名图像拼成一对作为输入，通过计算低维特征之间的余弦距离(cosine distance)来输出相似性分数。近来，

研究人员才开始将验证网络模型应用于行人重识别，主要的研究点为图像样本增强和匹配识别。Yi 等^[53]人将行人图像分成三个水平部分，并训练三部分 CNN 来提取特征。两个图像的相似性通过其特征的余弦距离来计算。同样，Cheng 等^[54]人。将卷积图分成四个部分，并将局部特征与全局特征融合从而进行计算。Li 等^[55]人在网络中添加了一块匹配层，它将两个图像不同的水平条纹所提取到的特征分配不同权重。此外，Wu 等^[56]人尝试使用更小的滤波器和更深的网络来提取特征。Varior 等^[57]将 CNN 与一些门函数相结合，类似长短记忆网络^[58]（LSTM），其目的在于自适应地关注输入图像对的相似部分。但它受到计算效率低下的限制，因为查询图像必须与每个图库图像配对才能通过网络。此外，Ding 等^[59]人使用三元组 (triplet) 样本来训练网络，该网络输入为三幅图像，其中两幅来自于同一个 ID，另外一幅为另一个 ID。

2.2.3 鉴别网络模型

鉴别网络模型相比于验证网络模型最直观的不同在于输入图像的数量，如图 2-10 所示。鉴别网络模型输入为一副图像，输出具体为某一类别，即某个 ID(identity)，类似一个多分类任务。网络结构通常为通过 CNN 进行特征提取，再添加 softmax 层进行分类，如一共 751 个 ID 则输出为具体哪个 ID。




图 2-10 验证网络和鉴别网络对比示意图。(a)鉴别网络；(b)验证网络

鉴别网络模型将行人重识别看作一种多分类任务。在训练阶段，先将样本标记为 $\{1, 2, 3 \dots 10 \dots\}$ ，一般网络结构由多个卷积层和池化层交替组成，在最后一层 softmax 层后加上交叉熵(cross-entropy)作为损失函数。表达式为：

$$Loss = - \sum_x p(x) \log q(x) \quad (2-6)$$

其中 $p(x)$ 为样本标签， $q(x)$ 为模型的预估，如果是二分类，表达式可写为：

$$Loss = -[y \log y' + (1 - y) \log (1 - y')] \quad (2-7)$$

其中 y 为样本标签， y' 为网络输出的预测标签，当 $y = 1$ 时

$$Loss = - \log y' \quad (2-8)$$

这时，Loss 与预测输出的关系如图 2-11 所示。




图 2-11 交叉熵损失函数曲线(y=1)

横坐标是预测输出，纵坐标是交叉熵损失函数 Loss。显然，预测输出越接近真实样本标签 1，损失函数 Loss 越小；预测输出越接近 0，Loss 越大。因此，函数的变化趋势完全符合实际需要的情况。

当 $y = 0$ 时：

$$Loss = - \log (1 - y') \quad (2-9)$$

这时，Loss 与预测输出的关系如图 2-12 所示。

同样，预测输出越接近真实样本标签 0，损失函数 Loss 越小；预测函数越接近 1，Loss 越大。函数的变化趋势也完全符合实际需要的情况。并且从图形中我们可以发现，预测输出与 y 差得越多，Loss 的值越大，也就是说对当前模型的“惩罚”越大，而且是非线性增大，是一种类似指数增长的级别。这是由 log 函数本

身的特性所决定的。这样的好处是模型会倾向于让预测输出更接近真实样本标签 y 。训练结束后，则可获得输入图像和样本标签的非线性映射即 $f(i) = y'$ ， i 为输入图像， y' 为识别的样本标签。在测试阶段，将待识别样本输入训练好的网络，从而识别。




图 2-12 交叉熵损失函数曲线($y=0$)

鉴别网络模型由于将行人重识别作为多分类任务，因此每一类别即每个 ID 样本越多则识别效果越好，随着数据集如 CUHK03^[60]和 Market1501^[61]等较大规模数据集的出现，这更加的促进了鉴别网络模型的发展，CUHK03 中平均有 9.6 个训练图像，Market1501 中有 17.2 个图像，这使得训练过程中不容易过度拟合，识别效果提升。Zheng 等^[61]人直接在 Market1501, PRW 和 MARS^[62]数据集上使用传统的微调方法，利用鉴别网络模型获得较好的效果。Wu 等^[63]通过在全连接层将 CNN 深度特征和手工提取特征进行融合以提升效果。此外，香港中文大学的 Xiao 等^[64]人，使用多个数据集联合训练鉴别网络模型，并提出一个新的 Dropout 函数来同时训练这几百个类别。并且 Xiao 等^[65]人还通过模拟 fast-RCNN^[66]分类模型，在对整副图像进行预测候选行人的位置的行人检测任务中，融入识别，从而减少行人检测的错误率。

2.2.4 生成对抗网络

2014 年，蒙特利尔大学的 Ian Goodfellow^[67]和他的同事创造了生成式对抗网络(GAN)。它可以通过学习生成逼真物体的底层数据分布。目前在图像风格转换，超分辨率，素描与彩色图像转换，彩色图像与彩色图像相互转换等领域有广泛使用，GAN 主要原理即为生成器(G)和判别器(D)的相互作用。生成器可以看成是一个神经网络模型，输入为一组随机数 Z ，输出是一个图像。生成网络的目标是生成一个逼

真的物体,使得判别网络没法判断是生成的还是实际存在的。判别器同样可以看作是一个神经网络模型,输入为一副图像,输出一个概率值,用来判断真假,如大于 0.5 判断为真,小于 0.5 判断为假。判别网络的目标是分辨出输入图像是来自真实样本集还是假样本集,即如果输入是真样本(真实世界),网络输出就接近 1,如果输入是假样本(生成器生成),网络输出接近 0,生成器和判别器在不断地进行对抗,最终两个网络达到了一个动态均衡:生成器生成的图像与真实世界的图像非常相似,而判别器没办法识别出图像来自于真实世界还是生成器生成。原理图如 2-13 所示:




图 2-13 生成对抗网络(GAN)原理图

用数学表达 GAN 的目标函数为:

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log(D(x))] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2-10)$$

公式对应着两个优化过程,可以拆成两个部分,优化判别网络 D 部分为:

$$\max_D V(D, G) = E_{x \sim p_{data}(x)} [\log(D(x))] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2-11)$$

优化生成网络 G:

$$\min_G V(D, G) = E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2-12)$$

对于优化判别网络 D, x 为真实样本,因此希望 $D(x)$ 判别为真,即 $D(x)$ 趋近 1,而 z 为隐随机变量, $G(x)$ 为生成的样本,因此希望将生成的样本尽可能判断为假,即 $D(G(z))$ 趋近于 0,从而训练判别模型,即为使得整个 $V(D, G)$ 尽量大。

对于优化生成网络 G,此时和判别网络不同,对于隐随机变量 z , $G(x)$ 为生成的样本,对于生成网络,其核心目的是使得生成的样本判别网络将其识别为真样本,因此这里希望 $D(G(z))$ 尽可能趋近于 1,则整个式子越小越好,即最小化 $V(D, G)$ 。

在 GAN 网络的训练过程中, 由于需要分别训练判别网络和生成网络, 因此目前一般可以采用单独交替迭代训练, 即每一次迭代可以先训练判别网络一次或几次, 再训练生成网络一次。不同的搭配, 结果也不同。

DCGAN^[68]是在 GAN 的基础上的衍生, 其主要的改进是在网络结构上, 到目前为止, DCGAN 的网络结构还是被广泛的使用, DCGAN 极大的提升了 GAN 训练的稳定性以及生成结果质量。




图 2-14 DCGAN 网络结构图^[68]

DCGAN 的生成器网络结构如上图所示, 相较原始的 GAN, DCGAN 几乎完全使用了卷积层代替全链接层, 判别器几乎是和生成器对称的, 从上图中我们可以看到, 整个网络没有池化层和上采样层的存在, 实际上是使用了带步长 (fractional-strided) 的卷积代替了上采样, 以增加训练的稳定性。

DCGAN 相比 GAN 训练稳定的原因主要有:

1. 使用带步长卷积代替上采样层, 使用卷积层代替全连接层。
2. 生成器 G 和判别器 D 中几乎每一层都使用 BN 层, 将特征层的输出归一化到一起, 加速了训练, 提升了训练的稳定性。
3. 在判别器中使用 LeakRelu 激活函数, 而不是 Relu, 目的是缓解梯度消失, 在生成器中激活函数仍然采用 Relu, 但是输出层采用 Tanh。
4. 使用 adam 优化器训练, 其中学习率参数设置为 0.0002。

2017 年, zheng 等^[69]用 DCGAN 对待评价数据集进行训练, 再用生成网络生成样本, 从而增加了训练样本数据, 提高了识别率。如在 Market1501 数据集, 总共包括 12936 帧训练图像, 作者通过 DCGAN 分别生成 12000, 18000, 24000, 30000, 36000 张伪训练样本, 再将这些训练样本和 Market1501 数据集本身训练样本一起输入识别网络中训练, 结果相比于不添加生成训练样本, rank1 分别提升 3.12%, 3.57%, 4.37%, 3.69%, 2.38%。从中可以看出, 通过添加 DCGAN 生成训练样本, 确实能

提高识别率，但不是添加的越多生成图越好，从结果可以看出当添加的生成训练样本为 2 倍原本训练图效果近似达到峰值。




图 2-15 CycleGAN 网络结构示意图

GAN 的另一重要衍生网络为 CycleGAN^[70]，CycleGAN 是一个环形的结构，主要由两个生成器及两个判别器组成，如图 2-15 所示。X 表示 X 域的图像，Y 表示 Y 域的图像。X 域的图像通过生成器 G 生成 Y 域的图像，再通过生成器 F 重构回 X 域输入的原图像；Y 域的图像通过生成器 F 生成 X 域图像，再通过生成器 G 重构回 Y 域输入的原图像。判别器 D_x 和 D_y 起到判别作用，确保图像的风格迁移。

CycleGAN 的训练的损失函数主要包括两大部分，其中一部分是 GAN Loss，如式(2-13)所示。

$$L_{GAN}(G, D_Y, X, Y) = E_{y \sim p_{data}(y)} [\log(D_Y(y))] + E_{x \sim p_{data}(x)} [\log(1 - D_Y(G(x)))] \quad (2-13)$$

但如果仅仅只使用 GAN Loss 可能会导致映射 F 将所有 X 域图像映射到 Y 域的同张图片，使得损失无效，从而没法训练，因此，作者提出另外一部分损失函数：循环一致性损失。如式(2-14)所示。

$$L_{cyc}(G, F) = E_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1] \quad (2-14)$$

循环一致性损失要求，将 X 中的图片转换到 Y 空间后，必须还要可以转换回 X 域，则有效的避免所有的 X 域图转换为 Y 中同一张图，则总的损失函数为式(2-15)所示。

$$L(G, F, D_X, D_Y) = L_{GAN}(G, D_Y, X, Y) + L_{GAN}(F, D_X, Y, X) + \lambda L_{cyc}(G, F) \quad (2-15)$$

2.3 行人重识别数据集与评价指标

2.3.1 数据集

本文使用的数据集主要包括两个大的数据集 Market1501 和 CUHK03，和一个小的数据集 PRID。



图 2-16 Market1501 数据集样本

Market1501 总共包含 32,668 个注释边界框，来自于 1501 个不同的 ID。每个 ID 的图像最多由六个摄像头捕获。根据数据集的设置，训练集包含 12,936 张 751 个 ID 的真实裁剪图像(Ground truth)，测试集总共有 19,732 个裁剪图像，包含 750 个 ID 的 Ground truth 和一些干扰裁剪图像。干扰裁剪图由可形变模型（DPM）对原图进行检测得到，而不是像 Gound truth 通过人工手动真实抠图。对于每个 query 图像，我们的目标是从 19,732 个候选裁剪图像中找到其对应的真实的 Ground truth。

Gallery sets 表示搜索集，即待匹配的图像，搜索集的大小对行人重识别的准确度的影响非常大，由于在现实生活中，对于单一的一张目标图像，可能需要与几万，几十万张进行匹配，因此 Market 数据集除了由 DPM 检测算子检测出的干扰图以

外,还额外提供了 500000 个 bbox,包括背景上的裁剪图以及不属于任何原始 1,501 个 ID 的裁剪图。在测试时可以将 500000 个 bbox 图像添加到 gallery 中,提高识别的难度,图 2-16 为一些样本图。



图 2-17 CUHK03 数据样本图

CUHK03 数据集由香港中文大学研究团队建立,包含在香港中文大学校园收集的 1,467 个 ID 的 14097 个裁剪图像。每个 ID 均通过两个摄像机从不同的视角进行观察,平均每个 ID 具有 4.8 个裁剪图像。作者提供了两种裁剪图像,一种是通过 DPM 检测到的更接近真实场景的裁剪图,另外一种是通过人工扣出的 Ground truth,样本如图 2-17 所示。



图 2-18 PRID 数据样本图

PRID 数据集具有来自摄像机 A 的 385 个轨迹和来自摄像机 B 的 749 个轨迹。其中，在两个摄像机中同时出现的仅仅只有 200 个人。数据集包括 muti_shot 和 single_shot，muti_shot 包括两个镜头所有 ID 的序列，single_shot 包括两个镜头中所有 ID 的序列中随机的一张，但 PRID 数据集一些轨迹没有很好地同步，导致一些人可能在连续帧之间“跳跃”，示意图如图 2-18 所示。

2.3.2 评价指标

目前行人重识别有两个常用的评价指标：累计匹配曲线(Cumulative Match Characteristic,CMC)曲线和平均准确率(mean average precision, mAP)。

CMC 曲线的横坐标为 Rank 值，常用的包括 Rank-1, Rank-5, Rank-10 等，纵坐标为匹配率。在行人重识别测试时，一般包括查询目标集，以及候选图像集，而行人重识别的目标为，针对查询目标集中的每个目标，将其与所有候选图像进行匹配排序，则所有的查询目标的匹配序列构成整个查询的结果，而 Rank-1 表示，在所有的匹配序列中，排在第一位的正确的匹配率，类似的 Rank-5 表示前 5 个排序中有正确目标的匹配率。其中 Rank-1 由于代表算法能不能准确的寻找到目标而被广泛使用，但行人重识别系统往往是辅助人工的系统，即当找到前 5 个或前 10 个匹配对象，再人为进行删选，从而也大大减少人力成本。

mAP 为图像分类，目标匹配，人脸识别等领域广泛使用的评价指标，相比于 Rank-1 表示的，排序结果中正确目标在第一位的匹配率，mAP 综合考虑大部分识别结果，对整个算法性能进行评估。在行人重识别中，针对查询目标集中的每一个目标，均可以根据其准确率和召回率画一条 PR 曲线，而 AP 表示 PR 曲线下方包含的面积，则对于每一个目标可以求得 PR 曲线以及 AP 值，而 mAP 为所有目标的平均 AP 值。AP 的计算公式如式(2-16)所示。

$$AP = (\frac{p_1}{x_1} + \frac{p_2}{x_2} + \dots + \frac{p_n}{x_n}) / n \quad (2-16)$$

其中 p 表示返回的识别结果中第 i 个与目标行人匹配的图像， x_i 表示第 i 个匹配结果在返回集中的排序位置。 n 表示候选集当中所有与目标行人匹配的图像个数。

mAP 如式(2-17)所示，表示所有目标 AP 的平均值，其中 m 表示查询目标集中行人的数量。

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_i \quad (2-17)$$

2.4 本章小结

本章主要介绍论文相关的研究工作，包括图像的显著性检测，单线性迭代聚类分割算法，常用卷积神经网络模型，和基于 CNN 的成对输入的验证网络模型和单个输入的鉴别网络模型，还有最近研究活跃的生成对抗网络，最后介绍了行人重识别常用的经典的数据集和评价指标。

第三章 基于显著性检测和验证网络的行人重识别

3.1 算法思路

行人重识别由于在不同的监控下，视角不同，导致行人间背景复杂，从而对特征提取产生影响，显著性检测是一种分析图像内部各个区域特征，从而将图像前后景分离的算法，其中常用的包括颜色，纹理，空间位置等特征，而在行人重识别中，对于每个行人框图像，行人前景与背景差异较大，因此本章通过引入显著性检测算法，将图像中显著的行人前景分割出来，有利于后续提取出更加鲁棒的行人特征。

在特征提取过程中，传统行人重识别算法，通过分析图像的表观特征，如颜色，纹理等，手工构造跨视角下稳定鲁棒的特征，如 LOMO 算法先将行人分成不同的水平条，再对每个水平条提取直方图作为特征，算法的核心是考虑到同一个人无论是处于什么姿态，其对应水平位置的直方图分布大致相同。当数据集较小时，算法能获得较好的效果，但当数据集上万时，水平直方图表示难以区分出不同的个体，特征差异性不够。卷积神经网络由于其强大的特征提取能力，在诸多计算机视觉领域获得良好的表现，因此本章提出一种分块的基于验证网络模型的卷积神经网络进行特征提取。




图 3-1 本章算法流程图

图 3-1 为本章算法的整体流程图，首先构造正负样本对，再用显著性检测对每个样本进行预处理，提取出人物前景，这里本章采用提出的基于 SLIC 的显著性分割算法，相比于不分块的直接利用图像每个像素特征进行检测，SLIC 通过将图像分成内部特征相似的局部小块，用小块内部所有像素的统计特征代表小块的特征，从而大大提高运算速度，与直接将图像均等分块相比，SLIC 通过利用颜色、纹理等表观特征有效的将图像边缘纹理保存下来，使得前景的检测结果轮廓保存的更好。将每对行人前景提取之后，再将其输入到验证网络模型进行训练，为了充分使用样本，这里我们采取孪生网络结构，每个子网络部分使用在 ImageNet 上预训练的 resNet-50 网络，网络输出一个二维向量，判断是否为同一个样本，并且考虑一些局部区域相比其他更为重要，比如人脸区域是重要的区分行人的区域，但如果将图像分成较多块，一方面训练时间和测试时间增加，另外一方面局部块过多，从而所占比例增加，导致识别效果不好，因此本章采用将输入图像分成人脸，人脸和上半身，人脸和全身三个部分提取，识别效果较好。下面分别对显著性检测预处理与验证网络特征提取分类识别两个部分进行介绍。

3.2 显著性检测预处理

在显著性检测预处理部分主要是剔除冗余背景，而显著性检测常用的模型非常多，由于区域对比度模型相较于其他模型，效果更加稳定，计算量较少，效率高，因此本章提出一种基于简单线性迭代分割的区域特征对比度模型，整个显著性检测算法具体流程图如图 3-2 所示。




图 3-2 显著性检测预处理算法流程图

3.2.1 图像超像素分割

首先结合图像本身的底层特征如颜色、亮度、纹理等信息对图像进行超像素分割。具体步骤如下：

(1) 初始化聚类种子像素

首先，我们定义超像素初始个数 K ，这里我们根据图像大小定为 200，由于输入图像大小为 $N = 480 \times 640$ ，因此，我们选取种子像素的步长 $S = \sqrt{N / K} \approx 39$ ，然后我们以抽样步长进行抽样，抽样后，为了避免种子像素位于图像边缘处，我们以种子像素为中心，计算其 3×3 周围领域内每个像素的梯度，并用最小的像素作为真正的种子像素，同时进行标号。

(2) 进行局部聚类

在第一步选取完种子像素后，我们对每个像素进行局部 **k-means** 聚类，即对每个种子像素的 $2S \times 2S$ 像素范围内，计算每个像素与种子点像素的相似程度，将此像素归类为与之最相似的种子像素，在遍历完所有像素之后，对每个超像素块所包含区域的每个像素统计平均值，计算新的种子像素，再进行聚类，最终达到收敛条件停止。这里在计算相似度时，我们将每一个像素可以表示为一个 6 维向量，如式 (3-1) 所示：

$$C = [l, a, b, t, x, y] \quad (3-1)$$

其中，其中， $[l, a, b]$ 表示 CIEllab 空间中的三维颜色特征， t 为用 LBP 算法提取的纹理特征， $[x, y]$ 为像素在图像所在位置的空间特征。则相似性度量公式为式 (3-2) 和式 (3-3) 所示。

$$d_c = \sqrt{(l_k - l_i)^2 + (a_k - a_i)^2 + (b_k - b_i)^2}$$

$$d_t = \sqrt{(t_k - t_i)^2} \quad (3-2)$$

$$d_s = \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2}$$

$$d = \sqrt{(d_c + d_t)^2 + \left(\frac{d_s}{S}\right)^2 m^2} \quad (3-3)$$

其中， d_c 定义为像素的颜色距离， d_t 代表纹理距离， d_s 代表空间位置距离， d 代表两个像素的相似程度， m 为调整颜色、纹理的特征距离和空间距离的权重参数，这里选取经验参数 0.4， s 为种子点选取时的采样步长。



图 3-3 图像超像素分割结果图。(a)图像原图；(b)分割结果图

(3) 孤立像素优化

在迭代处理之后，将图像上孤立的像素归类为与他们连通且相似度最近的超像素块。图 3-3 为超像素分割结果。

3.2.2 对超像素快进行特征提取

在将图像分割成相互不重叠的超像素块之后，再对每个超像素块进行特征提取。首先，我们将每个超像素块可以记作： $R = \{R_1, R_2, \dots, R_i, \dots, R_N\}$ ，然后这里我们分别对其提取颜色、纹理、和亮度特征。

类似于前面对每个像素提取特征，对于超像素块，我们用块所包含的所有像素的均值作为此超像素块的特征，即同样可以用一个 6 维向量来表示，如式(3-4)所示。

$$R_i = [L, a, b, T, x, y] \quad (3-4)$$

其中 (L, a, b) 为超像素块颜色特征， T 为纹理， (x, y) 为像素坐标。

3.2.3 初始显著性计算

在提取特征之后，我们采用全局对比度的方式计算初始显著性，初始显著性由其与其他超像素块的特征距离与空间权重的乘积表示，计算公式如式(3-5)所示。

$$S_{R_n} = \sum_{m \neq n, (R_m \in R)}^N d(R_m, R_n) \cdot \omega(R_m, R_n) \quad (3-5)$$

其中 $d(R_m, R_n)$ 代表两个超像素块的特征距离, $\omega(R_m, R_n)$ 表示两个超像素块的空间距离权重, 计算公式如式(3-6)所示。

$$\omega(R_m, R_n) = \exp\left(-\frac{d_p(R_m, R_n)}{\sigma}\right) \quad (3-6)$$

其中, $d_p(R_m, R_n)$ 为 m 第块和第 n 块的空间距离, σ 表示空间距离参数, 这里我们取经验值 0.5。

在求超像素块间的特征距离时, 我们使用不同的特征可以得到不同的显著性图, 这里我们使用, 颜色, 纹理特征分别得到两幅特征显著性图, 然后通过加权融合得到初始显著性图, 如式(3-7)所示。

$$S = \sum \omega_F \cdot S_F \quad (3-7)$$

ω_F 为特征融合权重, 这里我们考虑到由于行人基本上位于图像的中心区域, 因此当图像特征图的空间分布紧致性高, 我们则赋予其较大的权重。初始显著性结果如图 3-4 所示。




图 3-4 初始显著性结果图。(a)原图; (b)初始显著性图

3.2.4 建立图模型优化

初始显著性结果由逐个超像素块通过全局特征对比度方式得到, 连续性较差, 因此, 这里我们通过建立图模型, 利用局部相似性对结果优化。具体步骤如下:

(1) 建立图模型

首先我们将每个超像素块可以看作图模型的节点, 像素块之间的相似度可以看作图的边, 则建立图模型。表示为 $G(V, E)$, V 为点集, E 为边集, 图 3-5 为图

模型示意图。其中图 3-5(a)为原图，图 3-5(b)为构建图模型之后的图像，图中红色点表示超像素的中心点，两个红点之间的蓝色线条表示两个超像素块相邻，线条的粗细表示两个相邻块的相似程度。




图 3-5 图模型示意图。(a)原图；(b)图模型

(2) 初始显著性优化

在建立图模型之后，我们得知每个超像素块与其周围相邻像素块的相似度，如果两个超像素块相似度较高，表明其在图像中，属于同一物体的概率比较大，如都属于人体的一部分，或者都属于背景，然后我们根据每个超像素块与其相邻的相似性关系，分别更新每个超像素的初始显著性。

式(3-8)表示当前超像素块与周围邻接像素块的转移概率矢量：

$$p_{v_j, F} = \frac{w_{v_j, F}}{\sum_{v_k \in \Omega_{v_i}} w_{v_k, F}}, F \in \{C, T\} \quad (3-8)$$

其中 w 表示两个超像素的相似程度，根据不同的特征计算不同，这里选用颜色、纹理两种特征，计算公式如(3-9)所示。

$$\begin{aligned} w_C &= \exp\left(-\frac{d_C(R_m, R_n)}{\sigma_1}\right) \\ w_T &= \exp\left(-\frac{d_T(R_m, R_n)}{\sigma_2}\right) \end{aligned} \quad (3-9)$$

d_c 表示两个超像素块颜色距离, σ_1, σ_2 为权重参数, 这里均取经验参数 0.4, 根据相邻块的概率转移矢量, 分别在颜色、纹理两个特征图上进行初始显著性更新, 得到优化结果, 式(3-10)为优化公式以及最终融合公式。

$$S_{v_i, F} = \sum_{v_j \in \Omega_{v_i}} p_{v_j, F} \cdot S_{v_j, F}, F \in \{C, T\}$$

$$S = \sum_{F \in \{C, T\}} S_F + \prod_{F \in \{C, T\}} S_F \quad (3-10)$$

这里融合采用的是将所有优化后的特征显著性图累计叠加再加上所有优化后特征图的累计相乘, 主要目的是保证显著性图的边缘更清晰。图 3-6 展示了优化后显著性结果图和分割结果图。



图 3-6 显著性分割结果图。(a)原图; (b)最终显著性分割模板; (c)分割结果图

3.3 构建验证网络模型

在用显著性检测对图像预处理之后, 将处理之后的样本对输入到验证网络模型中, 验证网络模型是一类以成对输入或者以三元对输入的卷积神经网络, 其中以一对样本输入又被称为孪生网络。早在 1993 年, 孪生网络被提出, 其被用来评估两个签名样本的相似性, 同年, 在指纹验证领域, 孪生网络刷新了当年的识别准确率。与传统神经网络不同, 孪生网络由两个共享相同参数的子网络组成, 每个子网络都是卷积神经网络。2005 年, S. Chopra 等^[51]人将其用到人脸识别领域, 有效的提升人脸识别率。孪生网络的最佳性质是拥有统一而明确的目标函数。在目标函数的指导下, 端到端神经网络可以自动学习朝向目标的最佳度量。网络的最后一层的目标是评估两个子网络的输出的相似性, 常用的包括欧式距离和余弦距离等。本章基于孪生网络提出一种提取行人特征的验证网络模型, 具体网络结构如图 3-7 所示。




图 3-7 本章验证网络的整体结构

考虑在行人识别中，头部信息相比于全身而言最为重要，并且通过局部细节特征和全局特征相结合的方式使得网络能够提取到更加鲁棒的特征，因此这里我们将整个网络采用分块的结构，将输入图像对分成只有头部，头部和上身，全身三个样本对，然后分别由三个独立的孪生网络分别进行训练，这里我们便于描述方便，将所提出孪生网络以 SCNN 表示。




图 3-8 SCNN 网络具体的结构图

我们在训练阶段，分别独立的对三个 SCNN 进行训练，在测试阶段，用每一对 SCNN 网络对目标图像和待查询图像提取特征，计算距离，归一化，再将三个 SCNN 所测得三个部分的距离叠加进行排序识别，SCNN 具体网络模型如图 3-8 所示：

每对输入图像先经过显著性检测进行预处理，再输入网络中，网络整体上是一个孪生网络结构，两个子网络均为 ResNet-50，子网络间共享权重，首先，我们将原本残差网络的最后一层的 FC_1000 去掉，由于输入图像的大小为 256×256 ，因此通过网络后输出 2048 维的特征向量，这里我们定义一个 Square 层对两个输入样本结合，其主要作用为可以反应输入样本之间的差异，公式如式(3-11)所示。

$$f_s = (f_1 - f_2)^2 \quad (3-11)$$

其中 f_1 代表输入样本 1 的特征， f_2 代表输入样本 2 的特征， f_s 为融合特征。在特征融合之后，我们在 Square 层后添加一个核子大小为 $1 \times 1 \times 2048 \times 2$ 的卷积层和 Softmax 层，见式(3-12)，进行二分类，输出一个二维向量为 (q'_1, q'_2) ，表示这两张输入图像属于同一个 ID 的可能性。 $q'_1 + q'_2 = 1$ ，这里损失函数我们使用交叉熵损失函数(cross-entropy loss)，公式如(3-13)所示。

$$q' = \text{softmax}(\theta_s \circ f_s) \quad (3-12)$$

$$Loss = \sum_{i=1}^2 -q_i \log(q'_i) \quad (3-13)$$

这里 f_s 是 Square 层输出的结合特征向量， θ_s 是为卷积层参数， q' 为网络输出的标签， q 为样本真实标签，0 或 1。这里损失函数我们并没有使用验证网络模型中经常使用的对比损失(contrastive loss)，是因为对比损失使得模型在特征空间中，同一个 ID 相互靠近，不同 ID 相互远离，但是为了防止过拟合，导致对每个 ID 数量有一定要求，而在重识别领域中，由于每个 ID 数量有限，因此这里使用交叉熵损失函数。

3.4 实验及分析

本章主要提出一种基于显著性检测和验证网络的行人重识别算法，显著性检测部分作为预处理，剔除冗余背景，SCNN 主要用来特征提取和距离度量分类识别。实验所选用的数据集为 Market1501、PRID，其中 Market1501 属于较大数据集，PRID 相对较小难度较大。训练和测试环境为：CPU：Intel® Core™ i7-6700K、GPU：

NVIDIA GeForce GTX 1080、RAM: 32GB。Windows10 操作系统，软件环境为 MATLAB 平台。基于深度学习的训练和特征提取部分使用 MatConvNet 开源框架。

3.4.1 网络训练及参数优化

在 Market1501 数据集中，我们将原本数据集中提供的 12932 张训练样本作为训练集，首先所有的训练集均通过显著性检测提取出行人前景，然后由于网络部分本文使用的是在 ImageNet 上预训练了的残差网络，因此，首先我们将所有行人前景图的大小调整为 256×256 ，为了使得图像特征更加突出，这里我们先求得所有行人前景的平均图像，再将每个前景图减去平均图像得到真正的训练样本。

然后将所有样本随机配对，分成正负样本对，在训练过程中，由于数据集负样本远远多于正样本，为了避免过拟合，这里我们初始训练时将正负样本比例设置成为 1:1，最后才累计到 1: 4。在多次调整参数训练后，这里我们将 epoch 设置成 75，batch size 设置成 24，学习率 lr 一开始设置成 0.001，在最后慢慢降低为 0.0001，网络参数更新使用的是 mini-Batch 梯度下降法。

在 PRID 数据集进行实验时，由于数据集较小，训练效果不明显，因此我们直接用在 ImageNet 上预训练了的残差网络在 PRID 数据集上进行实验，其中以 cam_a 中的 385 张作为查询目标，以 cam_b 中的 749 张作为匹配目标集进行测试。

3.4.2 在 Market1501 数据集实验结果与分析

在 Market1501 数据集中测试时，我们将数据集中提供的 3368 张 query 集作为查询目标，将 19732 张测试集作为匹配集，实验结果如下，我们分别从主观和客观两个角度进行评估。

(1) 主观评价

本部分选取的方法包括 2015 提出的在手工设计特征中取得较好的识别率的局部最大表示(Local Maximal Occurrence, LOMO)以及 2017 年 Zheng 等^[23]提出的取得较好效果的基于残差网络的鉴别网络模型，从实验中选取部分结果如图 3-9 所示。

从主观上进行识别判断，最左边一列黑色实线框框住的为 Query sets，即所要查询的目标，第二列到第五列为从 Gallery sets 中所查询到的结果，越靠近左边代表算法认为其与目标图越匹配，其中绿色实线框表示正确匹配，红色实线框代表错误匹配，从图 3-9(a)中可以看出，本章算法在所列出的 4 张目标查询图中，Rank 前 3 均为正确匹配，在第 3 张目标查询图的 Rank4 匹配为错误匹配，经过验证，发现是因为 Gallery set 中，仅仅只有 3 张正确匹配图，因此本章算法相对

识别率较高,从图(b)可以看出 LOMO 手工提取算法在第 1, 3, 4 张查询图中均出现错误匹配,由于 LOMO 算法通过手工设计,提取局部分块的特征,再进行距离度量,相比于深度特征,鲁棒性不够,从图 3-9(c)可以看出 Zheng 网络大体上能够对 4 张目标查询图进行正确识别,从目标 1 的 Rank2 和目标 4 的 Rank3 的错误匹配可以看出, zheng 网络将都是穿短裤然后上衣主体颜色一样的个体匹配为同一目标,但对于裤子颜色的不同不能很好的区分,而本章算法,通过分块思想,结合局部和全局特征,通过综合识别,相对识别效果较好。




图 3-9 Market1501 部分结果示意图。(a)本章算法; (b)LOMO 实验结果;
(c)Zheng 实验结果

(2) 客观评价

这里通过对本章算法、LOMO、Zheng, 还有是否添加显著性检测预处理, 以及分块的结构相比不分块进行实验对比, 表 3-1 为实验结果。

在表中, 本章算法 1 为只使用分块网络结构, 本章算法 2 为只使用显著性检测作为预处理, 本章算法 3 为同时使用显著性检测预处理与分块网络, 则算法 1 与算法 3 形成是否使用显著性对照, 算法 3 Rank-1 相比算法 1 高 9.59%, mAP 高 9.77%, 可以得知, 行人图像通过运用显著性检测提取行人目标, 剔除冗余背景预处理有效的提高后续神经网络提取特征的鲁棒性, 有效的提升了识别率; 算法 2 与算法 3 同样形成是否分块对照实验, 其中算法 3 Rank-1 高 5.48%, mAP 高 4.81%, 只针对图像的整体提取的全局特征, 对一些局部较小, 但特征差异较大的区域可能难以表征, 而对图像分块, 使得神经网络能更有效的对当前区域提取具有判别性的

特征,本章考虑到头部信息的独特性以及运行效率,这里采用将图像分成头部,头部和上身,头部和全身三部分,结合图像局部和全局特征,确实能够提取更具有判别性的特征,提高识别精度,但分块过多使得训练的成本大大增加,运行效率变低。

表 3-1 Market1501 数据集关键 Rank 值及 mAP(%)

编号	方法	Rank-1	Rank-5	Rank-10	mAP
1	LOMO	25.42	41.30	48.96	7.02
2	Zheng	61.34	80.94	86.64	62.30
3	本章算法 1	71.23	83.57	91.34	72.36
4	本章算法 2	75.34	86.93	93.41	77.32
5	本章算法 3	80.82	92.34	94.69	82.13

本章算法 3 相比于利用局部最大表示的手工特征设计的 LOMO 和同样基于深度学习 Zheng, 无论是 Rank 值还是 mAP, 可以看出明显效果更好, 主要是因为首先 Market1501 数据集相对比较大, 因此基于 CNN 特征提取的本章算法和 Zheng 通过训练能获得更具有判别性的特征, 而 LOMO 手工特征在数据集较大时效果不明显, 而我们的方法相对于 Zheng, 在预处理阶段, 通过显著性检测有效的剔除背景冗余, 在卷积神经网络部分, 我们提出分块的思想, 从而提取到更具有判别性的特征, 识别效果较好。




图 3-10 三种比对算法 CMC 曲线图

图 3-10 为本章算法和 LOMO 以及 Zheng 的 CMC 曲线图, 图的横坐标为 Rank 值, 纵坐标为匹配率, 曲线越往左上角表明, 在前几个 Rank 中, 就能较好

的识别出目标，即效果更好。从图中可以看出，本章算法明显要好于 LOMO 和 Zheng。

3.4.3 在 PRID 数据集实验结果与分析

这里我们直接在 PRID 数据集上进行测试结果如下，同样从主观和客观两个角度进行评估。

(1) 主观评价

本部分同样选取的是在传统方法中表现很好的 LOMO 和基于鉴别网络的 Zheng，选取部分实验结果，如图 3-11 所示：

图 3-11(a)为 LOMO 结果，算法主要是通过颜色特征进行分块比较，从 4 张查询目标图的前 3 个排名可以看出，基本上能找到正确目标，正确位置分别在 Rank2、Rank1、Rank2、Rank1，取得最好的效果。图 3-11(b)为本章算法结果，在前三个目标查询中，同样能找到正确的目标，分别在 Rank3、Rank1、Rank3，而第四个查询目标，可能由于图片变化差异较大，在前三个 Rank 里不能找到，图 3-11(c)为同样基于 CNN 的 Zheng 算法，在实验结果中可以发现，只有第一和第四个目标能正确查询，分别位于 Rank2、Rank1。虽然识别率不高，但观察实验结果可以发现，算法基本上是把颜色相近的作为查询结果，如第二行，查询结果全部偏黑色，第四行查询结果上身偏蓝色，但仍然鲁棒性不够。




图 3-11 PRID 数据集部分结果图。(a)LOMO；(b)本章算法；(c)Zheng

(2) 客观评价

PRID 数据集与 Makert1501 数据集不同, PRID 数据集主要来自两个摄像机, 摄像机 A 一共包括 385 个 ID, 摄像机 B 包括 749 个 ID, 但是在两个镜头下均出现的 ID 不超过 200 个, 这意味着这里我们以摄像机 A 视角作为目标行人, 在摄像机 B 视角下寻找同一行人时, 大部分行人将干扰查询, 使得识别较为困难, 而且图像的颜色, 亮度, 清晰度等质量不高, 使得整体上识别率均不高。

表 3-2 PRID 数据集关键 Rank 值和 mAP(%)

编号	Method	Rank-1	Rank-5	Rank-10	mAP
1	LOMO	8.05	15.06	18.44	9.83
2	Zheng	2.34	4.42	5.97	3.05
3	本章算法 1	2.13	4.19	5.56	2.84
4	本章算法 2	2.41	5.72	9.54	3.56
5	本章算法 3	2.60	8.31	11.69	4.13

从表 3-2 可以看出, 在 PRID 数据集上, 除了 LOMO 算法, 本章算法 3 取得最好的效果, 其中相比 Zheng, Rank1 高 0.26%, mAP 高 1.08%, 相比于只用分块结构的算法 1, Rank1 高 0.47%, mAP 高 1.29%, 相比于使用显著性检测不使用分块结构的算法 2, Rank1 高 0.19%, mAP 高 0.57%。

从整体上, 基于传统手工设计的 LOMO 算法在 PRID 数据集中表现最好, 而在其他同样基于卷积神经网络的算法中, 本章算法表现最好, 这主要是由于 PRID 数据集较小, 难以训练, 且图像质量相对较差, 从而使得识别率不高。




图 3-12 三种算法在 PRID 数据集 CMC 曲线

图 3-12 为本章算法、LOMO、和 Zheng 在 PRID 数据集上的 CMC 曲线，从图中可以看出，LOMO 曲线最靠近左上角，表现效果最好，本章算法次之，最下面是 Zheng，效果较差。

3.4.4 效率测试实验

表 3-3 不同部分运行时间比较

算法	时间（秒/帧） (256×256)
显著性预处理	0.015s
Resnet 特征提取	0.028s
相似性度量	1.18×10^{-7} s
总体	约 0.043s

本章算法进行了简单的运行效率测试，主要用来计算对于每一张图像，本章算法各个部分大概的运行时间，测试软硬件环境与训练环境相同。测试时分别对各个部分进行测试，结果如表 3-3 式：

从表 3-3 中可知，其中比较耗时的是 Resnet 特征提取部分，这和特征提取网络较为复杂以及计算机硬件有关，后续的研究中会考虑是否可以再调整网络结构以及在实际场景中调整电脑配置来提升效率。

3.5 本章小结

本章介绍了提出的基于显著性检测预处理和验证网络模型的行人重识别算法。显著性检测预处理部分主要利用简单线性迭代分割，使得前景和背景边缘分割更好，再结合颜色，纹理特征构建图模型优化，从而得到更好的显著性前景，在特征提取部分，本章考虑头部信息的重要性提出将每对输入图像分成头部，头部和上半身，全身三块，通过局部特征和全局特征的结合，能更好对行人进行表示，从而取得较好的识别效果。

第四章 基于验证鉴别网络的行人重识别

4.1 算法思路

本文第三章算法通过显著性检测预处理降低背景对识别的干扰，再通过构建的验证网络模型提取特征，取得较好的效果，本章在第三章的基础上进一步分析，由于验证网络训练时，将样本对作为输入，利用的是 $\{0,1\}$ 标签，因此训练时只考虑了样本对之间的相似性，并没有利用样本本身的标签，而鉴别网络模型正好相反，将行人重识别作为一种多分类的任务，利用样本本身标签，而没有考虑样本之间相似性关系，因此本章提出结合验证网络和鉴别网络的优点，提出验证鉴别网络，充分利用标签进行训练。




图 4-1 本章算法流程图

从第三章实验可以发现在 PRID 数据集中测试时，整体识别率不高，分析是由于 ImageNet 数据集与 PRID 数据集相差较大，而 PRID 数据集较小，训练效果不

好导致识别率较低，本章提出引入生成对抗网络（Generative Adversarial Network, GAN），GAN 网络通过学习数据集之间的转换从而桥接数据集，实现数据集 AB 之间的转换，这里，本章分析 GAN 网络在行人重识别中的使用，利用 GAN 网络增强数据集，从而提高识别效果。

图 4-1 为本章算法流程图，总共分成两个部分，上面一部分，从数据集 A 中随机抽取出各种图像对，包括相似样本对和不相似样本对，再将其输入到显著性检测中，通过基于超像素分割的显著性检测算法对图像进行预处理，剔除冗余背景，提取出人物前景，再将其输入验证鉴别网络模型中提取特征，分类识别。下面一部分为使用生成对抗网络桥接数据集 AB，从而增强数据集 A 样本数，提高识别率。首先将数据集 AB 配对，训练，再利用训练后的生成网络，将数据集 B 转换成数据集 A 中，提高数据集 A 样本数，再训练验证鉴别网络从而提高识别率。

4.2 验证鉴别网络

验证网络模型将一对图像作为输入，网络输出为确定输入样本是否属于同一个人。即给定相似性标签 $s \in \{0,1\}$ ，验证网络将输入样本对映射到特征空间中，通过训练，网络迫使同一个人的两个图像在特征空间中相互靠近，如果两个图像属于不同的人，则相互远离。然而，验证网络模型仅仅使用弱的行人重识别标签即 0 或 1 而非具体某个 ID。因此，验证网络模型缺乏对图像对与数据集中的其他图像之间的关系考虑。而鉴别网络模型将行人重识别作为一种多分类识别任务，网络充分利用行人重识别每个 ID 标签，但没有考虑图像样本对之间的关系。如图 4-2 所示为两种模型的样本标签。



图 4-2 两种网络模型样本标签图。(a) 验证网络样本标签；(b) 鉴别网络样本标签

从图 4-2(a)可知，验证标签考虑了样本之间是否相似，即使用 $\{0,1\}$ ，图 4-2(b)展示鉴别网络使用样本具体为哪个人，如 $\{0023,0028\}$ ，因此本章从标签利用的角度提出验证鉴别网络模型。表 4-1 为三者对比。

表 4-1 三种网络对标签利用对比

模型	ID 标签	相似性标签
验证网络模型	0	1
鉴别网络模型	1	0
第四章模型	1	1

4.3 网络模型的构建

本章提出的验证鉴别网络模型基本结构仍然是孪生网络，为了充分利用相似性标签和 ID 标签，我们将第三章原本的验证网络的每个子网络通过增加一个卷积层，和 Softmax 层，将其改为一个鉴别网络，而子网络之间通过 Square 层连接又构成验证网络，则构成验证鉴别网络。




图 4-3 验证鉴别网络模型结构图

图 4-3 为本章网络具体结构图，网络整体框架仍然为一个孪生网络结构，鉴别网络部分：两个子网络这里使用 ResNet-50 卷积神经网络，为了在新数据集上对网络进行微调训练，我们用卷积层替换已经预训练了的 ResNet-50 卷积神经网络模型的 FC_1000 层，再添加一个卷积层（不同的数据集卷积层核子大小不同，如

Market1501 中训练集中 ID 数量为 751。则这里选取卷积核的大小为 $1 \times 1 \times 2048 \times 751$ ，然后我们再在此卷积层后面添加一个 Softmax 层规范化输出。输出大小为 $1 \times 1 \times 751$ 的张量，再通过交叉熵损失函数进行身份预测；验证网络部分：对于通过两个残差网络之后得到 2048 维特征向量，将其连接到 Square 层得到融合特征，大小为 $1 \times 1 \times 2048$ ，由于进行二分类，则在 Square 层后添加一个卷积核大小为 $1 \times 1 \times 2048 \times 2$ 的卷积层，最后再添加 Softmax 层和交叉熵损失函数进行验证网络模型二分类，来判断输入样本对是否属于同一 ID。整个网络包括三个损失函数，即两个鉴别网络损失和一个验证网络损失，然后这里选择权重进行同时训练收敛。

4.4 生成对抗网络优化

针对在一些小数据集上识别效果不好的现象，本节提出利用 CycleGAN 网络对图像风格相互转换的特点，提出将 CycleGAN 用于桥接数据集，进而提高识别结果。即假如有数据集 A 和 B，通过用 CycleGAN 对数据集 A 和数据集 B 进行训练，学习到映射 $B = G(A)$ 和 $A = F(B)$ ，从而可以桥接数据集 A、B。通过训练 $G(A)$ ，再在数据集 B 上进行测试，相比直接在 A 上训练，B 上测试效果更好。




图 4-4 CycleGAN 模型风格转换示意图

图 4-4 为用 CycleGAN 将数据集 A 转换到数据集 B 中示意图，可以明显看出，数据集 B 风格较为锐化，且颜色偏深，而通过 CycleGAN 将 A 转换之后，较为复合 B 数据集风格，从而相当于增加了 B 数据集的样本量。

CycleGAN 网络结构示意图如图 4-5 所示，其中蓝色线条表示生成网络部分，黑色线条表示判别网络部分，整个网络由两个生成网络 A2B 和 B2A，两个判别网络 A 和 B 组成，其中 Market1501 数据集中输入图 A 通过生成网络 A2B 转换成 PRID 数据集中的生成图_B，再通过生成网络 B2A 生成循环图_A，对于 PRID 数据集中的输入图像 B 类似。




图 4-5 CycleGAN 网络结构示意图

CycleGAN 网络中的生成网络如图 4-6 所示，网络可以分成三个部分编码、转换、解码，其中编码部分主要包括三个卷积层，主要目的是将图像进行压缩，将低级特征压缩为高级特征，转换部分这里采用 9 个残差块拼接而成，主要目的是学习，数据集 A 与数据集 B 之间的相互转换映射，将不同部分但是相近的特征进行组合，解码主要包括两个反卷积层和一个卷积层，反卷积层的作用是将，转换后的高维特征解码为低级特征，而卷积层的目的是将输出图像转换到数据集 B 域。

判别网络结构如图 4-7 所示，这里本质是一个二分类鉴别网络，主要包括 4 个卷积层和一个全连接层，将输入图像进行分类，判断图像为自然界真实图像还是生成网络生成的图像。




图 4-6 生成网络结构图




图 4-7 判别网络结构

4.5 实验及分析

本章实验主要测试验证鉴别网络的识别效果，以及生成对抗网络对实验结果的优化。训练和测试环境为：CPU：Intel® Core™ i7-6700K、GPU：NVIDIA GeForce GTX 1080、RAM：32GB。Window-s10 操作系统，软件环境为 MATLAB 平台。基于深度学习的训练和特征提取部分使用 MatConvNet 开源框架进行训练。

4.5.1 网络训练及参数优化

本章对验证鉴别网络模型进行训练时，由于这里我们同时训练三个 Loss，因此我们采用将三个 Loss 加权相加来更新网络参数，其中验证损失和两个鉴别损失权重比为 1:0.5:0.5。在 Market1501 数据集中，我们利用原本数据集提供的 12932 张训练样本作为训练集，在通过显著性检测，提取出目标前景之后，我们将图像

调整为 256×256 ，并减去所有样本的均值图像从而使图像特征突出，有利于训练，在训练过程中，前期以正负样本对 1:1 进行训练，随后逐步增加至 1:4，这里我们将 epoch 设置成 75, batchsize 设为 24，学习率 lr 设为 0.001，最后逐渐降为 0.0001。在 PRID 数据集中，由于样本较少，因此直接用在 ImageNet 上预训练了的残差网络在 PRID 数据集上进行实验。

对生成对抗网络进行训练时，当将大的数据集 Market1501 转换到小数据集 PRID 时，我们从 Market1501 训练数据集中选取 2017 帧图像作为训练数据集 A，从 PRID 数据集中选取 300 帧图像作为训练数据集 B，这里 epoch 设为 200，batch_size 为 1，学习率 lr 取 0.0002。当将大数据集 Market1501 转换到 CUHK03 时，这里，我们从 Market1501 训练数据集中选取 2017 帧图像作为训练数据集 A，从 CUHK03 数据集中选取 990 帧图像作为训练数据集 B，epoch 设为 200，batch_size 为 1，学习率 lr 取 0.0001 进行训练。

4.5.2 在 Market1501 数据集实验结果与分析

本部分主要将 LOMO、Zheng 和第三章提出来的验证网络模型与本章提出来的验证鉴别网络进行对比。这里我们使用的数据集包括一个大尺度的数据集 Market1501 和一个小尺度的数据集 PRID，实验从主观评价和客观评价两个角度进行分析。

(1) 主观评价




图 4-8 在 Market1501 数据集实验结果。(a)本章算法结果；(b)第三章算法结果

图 4-8 为在 Market1501 部分实验结果图, 在图 4-8(a)中, 从第 2 个查询目标的匹配结果可以看出, 对于正面面对镜头的上身白衣, 下半身暗蓝色牛仔褲的目标, Rank1, Rank2 均为正面匹配, Rank3, Rank4 为背部匹配, 均为正确匹配, 而在图 4-8(b)中, 第 2 个目标, 同样 Rank1, Rank2 为正确匹配, 但 Rank3, Rank4 均为错误匹配, 从结果可以看出, 匹配错误的目标同样为白色上衣, 但是黑色裤子, 且背对镜头, 对于其他查询目标两种算法虽然匹配顺序不同, 但均为正确匹配。

表 4-2 在 Market1501 数据集关键 Rank 值及 mAP(%)

编号	方法	Rank-1	Rank-5	Rank-10	mAP
1	LOMO	25.42	41.30	48.96	7.02
2	Zheng	61.34	80.94	86.64	62.30
3	第三章算法	80.82	92.34	94.69	82.13
4	第四章算法	83.91	95.57	97.81	86.83

(2) 客观评价

表 4-2 为在 Market1501 数据集中关键 Rank 值以及 mAP 实验结果, 从表中可以看出, 本章算法相比于第三章算法 Rank-1 高 3.09%, mAP 高 4.7%, 相比于 Zheng, Rank1 高 22.57%, mAP 高 24.53%, 相比于 LOMO, Rank1 高 58.49%, mAP 高 79.81%, 识别效果最好。




图 4-9 四种算法在 Market1501 数据集上 CMC 曲线

图 4-9 为四种算法在 Market1501 上 CMC 曲线, 本章算法、第三章算法, 与 Zheng 整体上都偏向于左上角, LOMO 在最小面, 识别效果相对不好, 而在 3 个基

于卷积神经网络的算法中,本章算法最靠近左上角,识别效果最好,这主要是由于在训练时,本章算法充分利用相似性标签与 ID 标签,同时训练验证损失和鉴别损失,因此网络特征提取效果较好。

4.5.3 在 PRID 数据集实验结果与分析

在 PRID 数据集中,以 cam_a 作为查询目标集,以 cam_b 为测试集,实验评价如下:

(1) 主观评价

图 4-10 为 PRID 数据集上部分实验结果,其中图 4-10(a)为第三章验证网络模型结果,从 4 张查询目标结果可以看出,前三张可以找到正确目标,分别为: Rank2、Rank1、Rank2,第 4 张没有查询到目标,图 4-10(b)为第四章验证鉴别网络模型图,4 张查询目标均能找到正确的匹配,位置分别为: Rank1、Rank1、Rank1、Rank2,相比于第三章结果,首先对于第 1,3 张查询目标,是 Rank1 进行识别,效果更好,第四张由于类似干扰图片较多,颜色和姿态均较为相近,因此在 Rank2 才将其识别,总体上第四章算法识别率更高。




图 4-10 在 PRID 数据集上部分结果。(a)第三章结果; (b)第四章结果

(2) 客观评价

从表 4-3 可以看出,本章算法相比于与基于传统手工特征的 LOMO,以及同样基于卷积神经网络的 Zheng 和第三章算法,识别效果最好,其中相比于 LOMO, Rank1 高 1.75%, mAP 高 1.54%。而第三章算法相比于 LOMO 识别效果要差,说

明本章通过同时训练相似性标签与 ID 标签确实能有效的提高识别效果,但在 PRID 小数据集上,整体识别效果仍然不高。

表 4-3 PRID 数据集关键 Rank 值和 mAP(%)

编号	Method	Rank-1	Rank-5	Rank-10	mAP
1	LOMO	8.05	15.06	18.44	9.83
2	Zheng	2.34	4.42	5.97	3.05
4	第三章算法	2.60	8.31	11.69	4.13
5	本章算法	9.80	15.51	20.49	11.37

图 4-11 为四种算法在 PRID 数据集中测得的 CMC 曲线,越靠近左上角,说明实验结果最好,第三章算法与 Zheng 在最下方,识别效果相对较差,而本章算法相比于 LOMO 更靠近左上角识别率更高,但从纵坐标匹配率可以看出,整体识别效果确实不高。




图 4-11 四种算法在 PRID 数据集 CMC 曲线

4.5.4 GAN 网络对行人重识别优化实验

本部分实验为验证通过 CycleGAN 网络将数据集 A 转换到数据集 B 中,从而提高在数据集 B 的识别率,使用的数据集包括两个大的数据集 Market1501, CUHK03 和一个小的数据集 PRID。实验为了验证 CycleGAN 对行人重识别的影响。从两个角度进行实验,即从将大数据集转换到小数据集,以及从大数据集转换到大数据集。

(1) 从大数据集转换到小数据集

Market1501 数据集总共包括 12936 张训练图像, 而 PRID 数据集一共只有 1124 张, 因此通过将 Market1501 转换到 PRID 数据集中提高识别率, 图 4-12 为 Market1501 转换为 PRID 数据集部分结果。




图 4-12 将 Market1501 数据集风格转移到 PRID 数据集结果图

其中最左列为 PRID 数据集, 风格整体偏蓝色, 后面三大列均为 Market1501 数据集和 Market1501 转换到 PRID 数据集的结果图, 对比 PRID 数据集可以看出, 基本上 Market1501 数据集的风格转换成 PRID 风格。在 PRID 数据集对比实验结果如表 4-5。

表 4-5 通过 CycleGAN 风格迁移之后在 PRID 实验结果(%)

编号	方法 数据集	本章方法		Zheng		LOMO	
		Rank-1	Rank-5	Rank-1	Rank-5	Rank-1	Rank-5
1	PRID	9.80	15.51	2.34	4.42	8.05	15.06
2	Market1501 +PRID	33.51	53.54	26.52	42.56	8.05	15.06

如表 4-5 所示, 在实验 1 中, 本章算法和 Zheng 均在 Market1501 数据集中训练, 再将其在 PRID 数据集中进行测试, 而 LOMO 为传统算法, 直接进行测试, 实验 2 为通过将 Market1501 转换到 PRID 数据集之后, 在转化后的数据集进行测试

练，再对 PRID 进行测试，LOMO 仍然直接进行测试。从表中可以看出，当使用 CycleGAN 进行风格迁移之后，在 PRID 中识别效果显著提高，其中本章方法 Rank1 提高 23.71%，Zhang 算法 Rank1 提高 24.18%。主要是因为通过 CycleGAN 转换数据集后，Market1501 数据集就与 PRID 风格类似，因此在特征空间中差异较小，从而识别效果较好。

(2) 从大数据集转换到大数据集




图 4-13 通过 CycleGAN 将 Market1501 数据集迁移到 CUHK03 数据集部分结果图

CUHK03 数据集为香港中文大学研究团队建立，包含在香港中文大学校园收集的 1,467 个 ID 的 14097 个裁剪图像，同样属于较大数据集，本部分将 Market1501 数据集转换到同样是较大数据集的 CUHK03 中，部分实验结果如图 4-13 所示。

左列为 CUHK03 数据集，右边三大列为 Market1501 数据集以及转换到 CUHK03 数据集的 Market1501 数据集，从整体风格上可以看出转换后风格整体偏锐化，颜色偏暗，比较相似。分别用本章方法、LOMO、Zheng 在 CUHK03 数据集上测试结果如表 4-6 所示。

实验 1 为 Market1501 数据集进行训练，在 CUHK03 进行测试。实验 2 为将 Market1501 数据集转成 CUHK03 之后，再在转换后的 Market1501 上进行训练，在

CUHK03 进行测试。从实验结果可知,当通过 CycleGAN 进行数据集风格转换时,两种基于卷积神经网络的算法识别率均有明显提升,则综合将 Market1501 转 PRID 实验可知,当在实际环境中,无法得到足够的训练样本,可以通过 CycleGAN 进行数据迁移,从而增强网络的在新场景下的鲁棒性。

表 4-6 通过 CycleGAN 风格迁移之后在 CUHK03 实验结果(%)

编号	方法 数据集	本章方法		Zheng		LOMO	
		Rank-1	Rank-5	Rank-1	Rank-5	Rank-1	Rank-5
1	CUHK03	22.5	34.2	18.4	27.1	16.2	31.5
2	Market1501+ CUHK03	37.4	62.1	32.1	54.4	16.2	31.5

4.5.5 实地拍摄视频实验

本部分我们分别在实验室,大厅,大门拍摄了三个场景视频,先对视频进行人工标注,再用本章提出的验证鉴别网络进行识别,图 4-14 为查询目标图像,这里分别用编号 1-4 表示,并且为了便于区分,分别使用红、绿、蓝、黄四种颜色框区分。



图 4-14 实际校园视频查询目标图

图 4-15 为在实际校园场景下的测试结果,其中图 4-15(a)场景为四个人分别离开实验室,由于实验室环境较为复杂,导致图像背景复杂,且存在一些遮挡,这会影响特征提取的准确度,图 4-15(b)场景为两个人从远方的长廊走进监控,实验室里有两个人出来,正好被监控捕获,图 4-15(c)场景为两两从大门走出去,被远方的监控捕获,但整体图像分辨率较低,从图示实验结果可以看出,本章算法可以较好的识别出全部的目标。



图 4-15 校园场景视频测试结果。(a)实验室场景测试结果；(b)大厅实验测试结果；
(c)大门实验测试结果

4.5.6 效率测试实验

本章算法同第三章算法一样进行简单的运行效率测试，测试的环境同训练相同，对整个算法分步测量消耗时间，结果见表 4-4。

从表中可知，相比于第三章算法，本章虽然在网络结构上将每个孪生网络改为一个单独的鉴别网络，但整体上运行时间相差不多，其中同样是在 Resnet 特征提取部分耗时较长，因此同样后续的研究中考虑是否可以再调整网络结构以及在实际场景中调整电脑配置来提升效率。

表 4-4 不同部分运行时间比较

算法	时间（秒/帧） (256×256)
显著性预处理	0.013s
Resnet 特征提取	0.025s
相似性度量	1.27×10^{-7} s
总体	约 0.038s

4.6 本章小结

本章首先在第三章提出的验证网络模型的基础上，分析验证网络模型和鉴别网络模型对行人重识别标签的利用的优缺点，提出验证鉴别网络模型，结合验证损失和鉴别损失同时训练收敛，得到较好的结果，并分析在小数据集上实验效果较差，因此提出通过 CycleGAN 网络桥接数据集，将现有数据集转换到当前待测数据集，训练测试，从而提升识别效果。

第五章 总结和展望

5.1 本文工作总结

21 世纪以来, 安全问题一直是许多国家所面临的重大问题, 各个国家和地区在安防领域的投资越来越大, 呈现逐年上升趋势, 视频监控系统可以监视人们在公共场所的行为, 对犯罪嫌疑人和犯罪行为可以有效的记录, 近年来, 无论是英美, 还是国内, 在火车站, 地铁站, 机场, 还是医院, 住宅小区, 学校等人群密集聚集地, 无不安装大量的监控。而传统通过人工去观看监控对人力物力消耗巨大, 因此智能监控系统的需求越来越多, 计算机视觉是使用计算机等相关设备对生物视觉进行模拟, 其最终研究目标是使得计算机能够像人一样通过视觉系统观察理解世界, 并具有自主适应环境的能力, 其中行人重识别是计算机视觉的一个重要方向, 因此研究意义重大。

本文首先介绍行人重识别的研究背景以及意义, 介绍了目前行人重识别研究中最主要的研究方向是基于特征提取的行人重识别和基于度量的行人重识别, 然后介绍与本论文相关的一些研究工作, 包括显著性检测算法和目前流行的卷积神经网络。之后两章我们介绍我们提出的两个行人重识别算法, 第三章介绍的是基于显著性检测的行人重识别算法, 本章从图像预处理的角度, 通过显著性检测算法将图像样本剔除冗余背景, 从而得到人物前景, 再用卷积神经网络进行特征提取, 网络模型部分, 本文采用的是分块的孪生网络模型, 通过将人物样本分成头, 头和上身, 全身三对进行综合分析, 提高识别率。本文第四章在第三章的基础上, 分析验证网络模型对样本标签的利用不够, 因此将网络改成验证鉴别网络模型, 通过对标签的充分利用从而提高识别, 并且本章考虑, 在小数据集上识别效果不好, 因此本章提出引入 CycleGAN 网络对数据集进行桥接从而可以有效的提高识别效果。

本文的创新点主要包括两个部分:

(1) 针对行人重识别中不同视角下背景冗余问题, 设计一种基于简单线性迭代分割的显著性检测的行人重识别预处理算法, 主要用来剔除背景冗余区域, 从而使得在特征提取阶段获得更鲁棒的特征, 提高识别率。

(2) 设计了一种基于分块的验证鉴别模型的行人重识别算法, 通过将每对输入行人样本对分成头部, 头部和上身, 全身三个部分, 分别输入三对孪生网络中, 进行训练。这种分块结构的网络有利于网络对图像局部进行更好的特征提取, 再综合三部分进行识别, 从而结果更加准确。

5.2 工作展望

行人重识别由于是一个对整个监控系统的各个监控中的行人进行识别，因此，由于监控所在位置的不同，从而拍摄到的行人的姿态，光线等可能差异较大，因此如何避免这些差异，提取较为鲁棒的特征非常重要，就本文而言，本文通过显著性检测避免行人的背景干扰，通过卷积神经网络提取更加鲁棒的特征，并针对一些数据样本较少的数据集，提出使用 GAN 网络对数据集进行增强从而获得较好的结果，但是这些做法还存在一些问题需要进一步研究：

（1）本文通过显著性检测对图像进行预处理，目的是剔除背景，但在一些实际场景中，可能人流较多，因此可能出现行人遮挡问题，导致图像背景复杂，而显著性检测难以将完好的行人轮廓分割出来，从而可能对后续识别效果提升不明显，由于监控系统往往拍摄的动态视频，后续可以研究可以从运动信息入手，研究更为有效的显著性预处理算法，使得图像前景轮廓提取的更好。

（2）本文特征提取部分通过三对孪生网络分别训练样本的三个部分，结合局部和全局特征，目的是为了获得更好的鲁棒特征，从而提升识别效果，但网络模型较为复杂，且需要大量的样本进行训练，使得一方面运行效率不高，另一方面太过依赖训练，后续可以设法简化网络模型，以及考虑弱监督、无监督等模型。

（3）在实际场景中通常行人重识别的识别率与行人检测的结果息息相关，当行人检测效果非常差，如不能完整的框住行人，从而使得识别非常困难，因此下一阶段可以考虑设计行人检测行人识别端到端的设计模型，两部分相互反馈调节，从而提升效果。

致 谢

不知不觉来成都三年了，时间如白驹过隙，转眼间，三年的研究生生活接近尾声了。记得第一次开组会，听学长学姐们讲自己的研究成果报告，心里非常羡慕，对科研产生极大的兴趣；记得第一次看论文，由于知识储备不够，很多看不懂，但还是一句一句认真看到最后；记得第一次自己发表论文的时候，由于时间不够，通宵了一整晚做实验，这一系列的第一次，一串串难忘的回忆，都深刻的刻进了我的生命中，在这里我要向我敬重的老师和同学表达我深深的感谢！

首先我要感谢我的导师张萍副教授，张老师在生活中为人谦和，平易近人，在科研上认真严谨，一丝不苟。从论文的选题、构思到最终撰写，张老师都给了我悉心的指导和热情的帮忙，在张老师的指点下，我发现了很多论文中难以发现的问题，并予以改正，这使得我的毕业论文能够顺利完成，在此，我谨向张老师表示衷心的感谢和深深的敬意。

其次，我还要感谢教研室的熊效李教授和高椿明教授，在我考研之际，是熊老师给了我机会我才能开启我的研究生生涯，敲开学术的大门，感谢高椿明教授，高老师学识渊博，在学术上更是精益求精，他严肃的科学态度，一丝不苟的学术精神值得我终身学习。

感谢教研室的小伙伴夏清、刘静雯、王晓玮、袁雨辰、闫鹏宇、郭正奎及其他师弟师妹们，在科研上给予的诸多帮助与建议，感谢室友聂峰、张大印在学习上的交流，以及生活上的陪伴。

同时，我还要感谢我的女朋友吴比，是她在我研究生三年中一直开导我、鼓励我，陪伴我，使得我能够顺利完成我的论文。

最后，感谢一向默默支持我的家人，他们永远都是我坚强的后盾，他们给予我的爱、理解、关心和支持是我不断前进的动力。

参考文献

- [1] 刘邦凡, 王磊, 李汉卿. 信息爆炸条件下的政治控制[J]. 新闻爱好者, 2009(20):4-5.
- [2] 陈丹. 计算机视觉技术的发展及应用[J]. 电脑知识与技术, 2008, 4(35):2449-2450.
- [3] K. H. Lu, C. M. Wang, S. Y. Chen. Traffic light recognition[J]. Journal of the Chinese institute of engineers, 2008, 31(6): 1069-1075.
- [4] J. A. G. Nijhuis, M. H. Ter Brugge, K. A. Helmholt, et al. Car license plate recognition with neural networks and fuzzy logic[C]. Neural Networks, 1995. Proceedings., IEEE International Conference on. IEEE, 1995, 5: 2232-2236.
- [5] U. Iqbal, S. W. Zamir, M. H. Shahid, et al. Image based vehicle type identification[C]. Information and Emerging Technologies (ICIET), 2010 International Conference on. IEEE, 2010, 1-5.
- [6] M. A. Turk, A. P. Pentland. Face recognition using eigenfaces[C]. IEEE Conference on Computer Vision and Pattern Recognition, 1991, 586-591.
- [7] X. Wang. Intelligent multi-camera video surveillance: A review[J]. Pattern recognition letters, 2013, 34(1): 3-19.
- [8] T. Huang, S. Russell. Object identification in a bayesian context[C]. International Joint Conference on Artificial Intelligence . 1997, 97: 1276-1282.
- [9] W. Zajdel, Z. Zivkovic, B. J. A. Krose . Keeping track of humans: Have I seen this person before?
- [10] N. Gheissari, T. B. Sebastian, R. Hartley. Person reidentification using spatiotemporal appearance[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2006, 1528-1535.
- [11] M. Farenzena, L. Bazzani, A. Perina, et al. Person re-identification by symmetry-driven accumulation of local features[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2010, 2360-2367.
- [12] D. Gray , H. Tao . Viewpoint invariant pedestrian recognition with an ensemble of localized features[J]. Computer Vision–ECCV 2008, 2008, 262-275.
- [13] B. J. Prosser, W. S. Zheng, S. Gong, et al. Person re-identification by support vector ranking[C]. British Machine Vision Conference, 2010, 2(5): 6.
- [14] A. Mignon, F. Jurie. Pcca: A new approach for distance learning from sparse pairwise constraints[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2012, 2666-2672.

- [15] R. Zhao, W. Ouyang, and X. Wang, Unsupervised salience learning for person re-identification[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2013, 3586–3593.
- [16] S. Liao, Y. Hu, X. Zhu, et al. Person re-identification by local maximal occurrence representation and metric learning[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2015, 2197-2206.
- [17] L. Zheng, L. Shen, L. Tian, et al. Scalable person re-identification: A benchmark[C].IEEE Conference on Computer Vision and Pattern Recognition, 2015, 1116-1124.
- [18] R. Layne, T. M. Hospedales, S. Gong, et al. Person Re-identification by Attributes[C].British Machine Vision Conference, 2012, 2(3): 8.
- [19] D. Yi, Z. Lei, S. Liao, S. Z. Li, et al. Deep metric learning for person re-identification. International Conference on Pattern Recognition, 2014, 34–39.
- [20] W. Li, R. Zhao, T. Xiao, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014, 152-159.
- [21] M. M. Cheng, G. X. Zhang, N. J. Mitra. Global contrast based salient region detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, Providence, 2011, 409-416
- [22] R. R. Viorito, M. Haloi, and G. Wang, Gated Siamese convolutional neural network architecture for human re-identification[C], European Conference on Computer Vision. Springer, 2016, 791–808.
- [23] L. Zheng, H. Zhang, S. Sun, et al. Person re-identification in the wild, arXiv preprint arXiv:1604.02531, 2016.
- [24] S. Wu, Y. C. Chen, X. Li, et al. An enhanced deep feature representation for person re-identification[C]. 2016 IEEE Winter Conference on Applications of Computer Vision. IEEE, 2016, 1–8.
- [25] T. Xiao, S. Li, B. Wang, et al. End-to-end deep learning for person search. arXiv preprint arXiv:1604.01850, 2016.
- [26] L. Yang, R. Jin. Distance metric learning: A comprehensive survey[J]. Michigan State University, 2006, 2(2).
- [27] P. Xing, Eric Y. Ng. Andrew, et al. Distance metric learning, with application to clustering with side-information[C]. Neural Information Processing Systems (NIPS), 2002, 505-512.
- [28] M. Kostinger, M. Hirzer, P. Wohlhart, et al. Large scale metric learning from equivalence constraints[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2012.

- [29] K. Q. Weinberger, J. Blitzer, and L. K. Saul. Distance metric learning for large margin nearest neighbor classification[C]. Neural Information Processing Systems (NIPS), 2005, 1473-1480
- [30] L. Yang and R. Jin. Distance metric learning: A comprehensive survey[J]. Michigan State University, 2006,2(78).
- [31] J. V. Davis, B. Kulis, P. Jain, et al. Informationtheoretic metric learning[C]. 24th international conference on Machine learning. ACM, 2007, 209–216
- [32] W. S. Zheng, S. G. Gong, and T. Xiang. Person re-identification by probabilis-tic relative distance comparison[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2011.
- [33] W. S. Zheng, S. G. Gong, and T. Xiang. Reidentification by relative distance com-parison[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(3):653-^668.
- [34] F. Xiong, M. Gou, O. Camps, et al. Person Re-Identification Using Kernel-Based Metric Learning Methods[M]. European Conference on Computer Vision, Springer International Publishing, 2014,1-16.
- [35] R. Achanta, A. Shaji, K. Smith, et al. SLIC superpixels compared to state-of-the-art superpixel methods[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 34(11): 2274-2282
- [36] F. Perazzi, P. Krahenbuhl, Y. Pritch. Saliency filters: Contrast based filtering for salient region detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, Providence, 2012, 733-740
- [37] L. Itti, C. Koch, E. Niebur. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(11), 1254-1259
- [38] D. Gao, N. Vasconcelos. Bottom-up saliency is a discriminate process[C]. IEEE International Conference on Computer Vision, Rio de Janeiro, 2007, 1-6
- [39] D. Gao, V. Mahadevan, N. Vasconcelos. On the plausibility of the discriminate center-surround hypothesis for visual saliency[J]. Journal of vision, 2008, 8(7):13.1-18
- [40] 王威琪, 汪源源, 邵谦明,等. 关于现代超声诊断仪中所采用的一些技术(一)[J]. 生物医学工程学进展, 1993(2):2-5.
- [41] G. Zhang, X. Huang, S. Z. Li, et al. Boosting Local Binary Pattern (LBP)-Based Face Recognition[C]. Chinese Conference on Advances in Biometric Person Authentication, 2004.
- [42] Y Fang, J Wang, M Narwaria, et al. Saliency detection for stereoscopic images[J]. IEEE Transactions on Image Processing, 2014, 23(6): 2625-2636.
- [43] J. Harel, C. Koch, P. Perona. Graph-based visual saliency[J]. Advances in neural information processing systems, 2006, 2(6):545-552

- [44] C. Yang, L. Zheng, et al. Saliency Detection via Graph-Based Manifold Ranking[C]. IEEE Conference on Computer Vision and Pattern Recognition, Portland, 2013, 3166-3173
- [45] B. Jiang, L. Zheng, et al. Saliency Detection via Absorbing Markov Chain[C]. International Conference on Computer Vision, Sydney, 2011, 665-1672
- [46] Y. LeCun, L. Bottou, Y. Bengio, et al. Gradient-based learning applied to document recognition[C]. IEEE, 1998, vol. 86, no. 11, 2278–2324.
- [47] J. S. Denker, D. Henderson, R. E. Howard, et al. Handwritten digit recognition with a back-propagation network[C]. Advances in neural information processing systems, Citeseer, 1990.
- [48] A. Krizhevsky, I. Sutskever, G. Hinton. ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in neural information processing systems, 2012, 25(2).
- [49] K. Simonyan, A. Zisserman. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, 2014.
- [50] K. He, X. Zhang, Ren. S, et al. Deep Residual Learning for Image Recognition[J]. 2015.
- [51] R. Hadsell, S. Chopra, Y. Lecun. Dimensionality Reduction by Learning an Invariant Mapping[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2006.
- [52] J. Bromley, J. W. Bentz, L. Bottou, et al. Signature verification using a siamese time delay neural network[J]. International Journal of Pattern Recognition and Artificial Intelligence, 1993, vol. 7, no. 04, 669–688 .
- [53] D. Yi, Z. Lei, S. Liao, et al. Deep metric learning for person reidentification[C]. International Conference on Pattern Recognition, 2014, 34–39.
- [54] D. Cheng, Y. Gong, S. Zhou, J. Wang, et al. Person reidentification by multi-channel parts-based cnn with improved triplet loss function[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016, 1335–1344.
- [55] W. Li, R. Zhao, T. Xiao, et al. Deepreid: Deep filter pairing neural network for person re-identification. IEEE Conference on Computer Vision and Pattern Recognition, 2014, 152–159.
- [56] L. Wu, C. Shen, and A. V. D. Hengel. Personnet: Person reidentification with deep convolutional neural networks. arXiv preprint arXiv:1601.07255, 2016.
- [57] R. R. Varior, M. Haloi, and G. Wang. Gated siamese convolutional neural network architecture for human re-identification[C]. European Conference on Computer Vision. Springer, 2016, 791–808.
- [58] S. Hochreiter and J. Schmidhuber. Long short-term memory. Neural computation, 1997, vol. 9, no. 8, 1735–1780.

- [59] S. Ding, L. Lin, G. Wang, and H. Chao. Deep feature learning with relative distance comparison for person re-identification. *Pattern Recognition*, 2015, vol. 48, no. 10, 2993–3003.
- [60] W. Li, R. Zhao, T. Xiao, et al. Deepreid: Deep filter pairing neural network for person re-identification. *IEEE Conference on Computer Vision and Pattern Recognition*, 2014, 152–159.
- [61] L. Zheng, Y. Yang, and A. G. Hauptmann. Person re-identification: Past, present and future. *arXiv preprint arXiv:1610.02984*, 2016.
- [62] L. Zheng, Z. Bie, Y. Sun, et al. Mars: A video benchmark for large-scale person re-identification. *European Conference on Computer Vision*. Springer, 2016, 868–884.
- [63] S. Wu, Y. C. Chen, X. Li, et al. An enhanced deep feature representation for person re-identification. *2016 IEEE Winter Conference on Applications of Computer Vision (WACV)*. IEEE, 2016, 1–8.
- [64] T. Xiao, H. Li, W. Ouyang, et al. Learning deep feature representations with domain guided dropout for person re-identification. *IEEE Conference on Computer Vision and Pattern Recognition*, 2016, 1249–1258.
- [65] T. Xiao, S. Li, B. Wang, L. Lin, and X. Wang, “End-to-end deep learning for person search,” *arXiv preprint arXiv:1604.01850*, 2016.
- [66] R. Girshick. Fast R-CNN. *IEEE International Conference on Computer Vision*, 2015, 1440–1448.
- [67] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, et al. Generative adversarial nets[C]. *International Conference on Neural Information Processing Systems*, 2014.
- [68] Y. Yang, Z. Gong, Z. Ping, et al. Unsupervised Representation Learning with Deep Convolutional Neural Network for Remote Sensing Images[J]. 2017.
- [69] Z. Zheng, L. Zheng, Y. Yang. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro[J]. 2017.
- [70] T. Kim, M. Cha, H. Kim, et al. Learning to discover cross-domain relations with generative adversarial networks[C]. *the 34th International Conference on Machine Learning-Volume 70*. JMLR. org, 2017, 1857-1865.

攻硕期间取得的研究成果

- [1] **J Wu**, P Zhang, C Fei, et al. No-reference image sharpness assessment with convolutional sparse representation[C]//2017 14th International Computer Conference on Wavelet Active Media Technology and Information Processing (ICCWAMTIP). IEEE, 2017: 189-192.
- [2] P Zhang, P Yan, **J Wu**, et al. Unsupervised Saliency Detection in 3-D-Video Based on Multiscale Segmentation and Refinement[J]. IEEE Signal Processing Letters, 2018, 25(9): 1384-1388.
- [3] 张萍, **吴江**, 张灵怡, 李俊宏, 费春, 周航, 申奉臻, 杨晓迪. 基于显著性检测和特征融合的行人重识别方法.[P]中国专利, 发明专利, 201810790884.3, 2018.07.18
- [4] 张萍, 王璟璟, 田明, **吴江**, 费春, 夏清, 梁琳梓, 闫鹏宇, 王晓玮. 一种基于卷积神经网络的红外弱小目标检测方法.[P]中国专利, 发明专利, 2017107586794, 2017.08.29