

单位代码: 10293 密 级:

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目: 基于深度学习的行人重识别技术

学	号	<u>1216043029</u>
姓	名	<u>卢丹丹</u>
导	师	<u>周宁宁</u>
专 业 学 位 类 别		<u>工程硕士</u>
类	型	<u>全 日 制</u>
专 业 (领 域)		<u>计算机技术</u>
论 文 提 交 日 期		<u>2019 年 4 月</u>

Pedestrian detection re-identification technology based on deep learning

Thesis Submitted to Nanjing University of Posts and
Telecommunications for the Degree of
Master of Engineering



By

Dandan Lu

Supervisor: Prof. Ningning Zhou

April 2019

摘要

社会的迅猛发展，使得人们对社会公共的安全问题越来越关注。很多大型公共场合都正在逐步大范围多角度的安装监控摄像头，形成监控网络。但面对监控视频的急剧增加所带来的海量数据，怎样使监控视频的分析和使用更加高效和智能化是一个有待解决的问题。

基于行人重识别的智能视频分析方法成为了计算机视觉领域的热点。行人重识别（Person Re-Identification, ReID）技术是判断在不同监控摄像头下出现的行人图像是否属于同一行人的技术。将深度学习应用到行人重识别中已成为当前的研究热点，和人工提取特征的方法相比较，深度卷积神经网络采用自动学习的方法，从数据中得到表征图像的特征，并对图像进行分类，具有实际意义。

论文首先总结了行人重识别常用的算法、特征以及深度学习网络框架，详细分析了深度卷积神经网络的架构，进一步研究了图像分类中被广泛采用的 ResNet 残差网络。

其次，论文仔细分析了训练集扩容所需的学习模型并详细探讨了生成对抗网络，通过生成对抗网络对数据集进行有效扩容。然后，论文选用深度残差网络（ResNet-50）作为实验的基础模型，并在此基础上进行了改进，对行人进行特征提取和分析，有效地提高了特定行人识别率。同时，在 PyTorch 框架下，对改进的深度网络模型进行微调训练，达到最佳识别效果。

最后，论文分析需求并设计和实现了基于深度学习的行人检测重识别系统，通过简单的待查询行人图像的输入，可直观的反馈出行人重识别结果。实验结果表明，本文所改进的方法训练出的模型能够学习到具有较高鲁棒性的特征，有效提高了行人重识别的识别率。

关键词：深度卷积神经网络，行人重识别，PyTorch，生成对抗网络，ResNet-50

Abstract

The rapid development of society has made people pay more and more attention to the safety of public society. Many large public places are gradually installing surveillance cameras on a wide range of angles to form a monitoring network. However, in the face of the massive data brought by the dramatic increase in surveillance video, how to make the analysis and use of surveillance video more efficient and intelligent is a problem to be solved.

The intelligent video analysis method based on pedestrian recognition has become a hot spot in the field of computer vision. The Person Re-Identification (ReID) technology is a technique for judging whether pedestrian images appearing under different surveillance cameras belong to the same pedestrian. Applying deep learning to pedestrian recognition has become a hot research topic. Compared with the method of artificially extracting features, the deep convolutional neural network adopts the automatic learning method to obtain the characteristics of the image from the data and classify the image. , has practical significance.

Firstly, the paper summarizes the algorithms, features and deep learning network framework commonly used in pedestrian recognition. The architecture of deep convolutional neural networks is analyzed in detail, and the ResNet residual network widely used as image classification is further studied.

Secondly, the paper carefully analyzes the learning model needed for the expansion of the training set and discusses in detail the generation of the confrontation network, and effectively expands the data set by generating the confrontation network. Then, the paper selects the deep residual network (ResNet-50) as the basic model of the experiment, and on this basis, it improves the feature extraction and analysis of pedestrians, which effectively improves the recognition rate of specific pedestrians. At the same time, under the framework of PyTorch, the improved deep network model is fine-tuned to achieve the best recognition effect.

Finally, the paper analyzes the requirements and designs and implements the pedestrian recognition re-recognition system based on deep learning. Through the simple input of the pedestrian image to be queried, the pedestrian recognition result can be intuitively feedback. The experimental results show that the model trained by the improved method can learn the features with higher robustness and effectively improve the recognition rate of pedestrian recognition.

Key words: Convolutional neural network, Person Re -Identification, PyTorch, Generative Adversarial Networks ,ResNet-50

目录

专用术语注释表	V
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 行人重识别研究现状	3
1.2.2 深度学习研究现状	4
1.3 论文组织结构	6
第二章 相关技术综述	8
2.1 卷积神经网络	8
2.1.1 人工神经元简介	8
2.1.2 LeNet-5 网络简介	9
2.1.3 ResNet 残差网络	10
2.2 GAN 生成式对抗网络	12
2.2.1 生成对抗网络原理	13
2.2.2 深度卷积生成对抗网络	14
2.3 行人检测和重识别常用特征	15
2.3.1 行人检测常用特征	15
2.3.2 行人重识别常用特征	18
2.4 深度学习框架 PyTorch	19
2.5 本章小结	20
第三章 基于 DCGAN 的行人图像特征提取	21
3.1 训练集扩容	21
3.1.1 DCGNN 介绍	21
3.1.2 数据扩容训练	23
3.2 特征提取	24
3.2.1 卷积层	25
3.2.2 池化层	27
3.2.3 全连接层	28
3.2.4 损失函数和激活函数	28
3.3 本章小结	32
第四章 基于改进 ResNet-50 的行人重识别研究	33
4.1 改进的 ResNet-50 网络	33
4.2 距离度量方法	36
4.3 基于改进 ResNet-50 网络的行人重识别训练与测试	37
4.3.1 训练阶段	37
4.3.2 测试阶段	37
4.4 标准数据集与性能评价标准	38
4.4.1 行人重识别标准数据集	38
4.4.2 性能评价指标	39
4.5 实验结果及分析	40
第五章 行人重识别系统的设计与实现	44
5.1 需求分析	44
5.2 功能分析	44
5.3 系统的设计与实现	45

5.3.1 神经网络训练 46

5.3.2 行人重识别模块与模型评估 47

5.4 本章小结 49

第六章 总结与展望 51

6.1 论文总结 51

6.2 研究展望 52

参考文献 53

附录 1 攻读硕士学位期间撰写的论文 56

附录 2 攻读硕士学位期间参加的科研项目 57

致谢 58

专用术语注释表

缩略词说明:

AI	Artificial Intelligence	人工智能
ANN	Artificial Neural Network	人工神经网络
BP	Back Propagation	后向传播
CNN	Convolutional Neural Networks	卷积神经网络
CPU	Central Processing Unit	中央处理器
CV	Computer Vision	计算机视觉
DCGAN	Deep Convolution Generative Adversarial Networks	深度卷积生成对抗网络
DL	Deep Learning	深度学习
FC	Fully Connected	全连接
GAN	Generative Adversarial Network	生成对抗网络
GPU	Graphics Processing Unit	图像处理器
mAP	mean Average Precision	平均精度均值
ML	Machine Learning	机器学习
ReID	Person Re-identification	行人重识别
ReLU	Rectified Linear Unit	修正线性单元
VGGNet	Visual Geometry Group Network	视觉几何网络模型

第一章 绪论

1.1 研究背景及意义

社会的迅猛发展，使得人们对社会公共的安全问题越来越关注。目前，医院、社区、校园、地铁站、火车站等大型公共场合都在大范围多角度的安装监控摄像头，形成大型分布式监控网络。同时，监控摄像头现已成为保障社会稳定、人身和财产安全的主要依赖。公安部门通过分布式监控网络对有关嫌疑人进行识别和跟踪；交管部门也可以通过监控视频获取实时、海量的路况信息，以方便交通监管；医院安装监控摄像头对病人实行个性化监控；超市将摄像头用于盗窃事件的防范和安全管理；社区也在安装摄像头来保证社区居民的人身和财产安全。对于我们个人来说，视频监控对我们的个人安全和利益也起到了重要的作用。但面对海量增长的监控视频，如何从海量的视频数据中得到有用的信息是个巨大的考验，通过人工的方式对视频内容进行甄别依然是现今社会广为使用的手段，怎样使监控视频的分析和使用更加高效和智能化是一个亟需解决的问题。

随着计算机科学技术的进步，计算机处理性能不断提升，计算机视觉和数字图像处理技术也在不断革新，人们可以利用计算机强大的处理能力和图像处理技术，对监控所产生的海量数据学习分类、智能识别，以提高监控系统的智能化。监控系统的智能化主要体现在对可视化对象（即行人、车型、车牌号等）的准确高效的识别，进一步分析可视化对象以及其行为特征。行人检测技术是利用计算机视觉技术判断图像或者视频序列中是否存在行人并给与精确定位。而对于监控视频中的行人监控和追踪，行人重识别技术就显得更加适用并具有针对性。行人重识别技术是实现无重叠的多摄像头下的行人匹配，即一个行人从一个摄像机下消失后，当其在其它摄像机下再次出现时能够将其与之前摄像机下的该行人重新建立关联，而不是当这个行人再次出现在摄像机下时被当作一个新的行人目标。总的来说就是对不同监控所产生的数据中出现同一行人进行识别的技术。

行人重识别是当前计算机视觉研究的热点，也是一个开放研究课题。随着大规模数据存储技术的不断提高、硬件价格的不断降低以及视频采集技术的不断进步，大量的监控摄像系统得以在众多公共场合得以安装应用。对如此大量的视频数据完成自动化的行人检测和重识别可以有效的提高监控质量和监控效率，对社会稳定和人身财产安全具有重要的意义。其在水机交互、安保、监控以及法庭取证等领域有着广泛的应用前景，因此，对行人重识别的研究具有显著的应用价值。

随着行人重识别关注度的不断提高以及研究工作的不断深入该技术得到了快速发展，但是由于实际环境相对复杂，导致理论与现实有一定的差距。造成该困境的原因主要如下：（1）由于时间和天气的不断变化，监控的环境无法稳定的预测；（2）由于监控摄像头的品质区别，所捕捉到的像素分辨率较低导致对图像进行特征提取难度较大；（3）监控图片中对象较多，相互之间产生不可预测的影响；（4）随着时间推移行人在不同监控图片中的姿态不断变化。如何有效的解决上述问题是提高行人重识别技术的关键，也成为众多学者及公司研究的热点。随着计算机科学技术不断演进，机器学习(Machine Learning, ML) 和深度学习(Deep Learning, DL)的产生对人工智能的发展做出了巨大的贡献。作为人工智能领域的一门重要学科机器学习的理论和应用取得了巨大的进步。深度学习作为机器学习的重要分支，在语音识别和图像分类与识别方面取得了较为优异的成绩，逐渐成为学者研究的热点。另外，随着计算机硬件技术的提升以及硬件成本的下降，计算机得以配置更优的处理器以获得更优的性能，在物理硬件方面促进了机器学习和深度学习的发展。和人工提取特征的方法相比较，深度神经网络采用自动学习的方法，从数据中得到表征图像的特征，并对图像进行分类，具有实际意义。

作为深度学习的一个重要的组成部分，卷积神经网络近年来不断发展，由于其在目标识别上的突出表现，卷积神经网络引起了全球广大科研工作者的关注。早在 20 世纪 60 年代，Hubel 和 Wiesel 在对猫脑皮层中用于局部敏感和方向选择的神经元研究的基础上提出了卷积神经网络（Convolutional Neural Networks, CNN）的概念^[1]，主要是通过独特的网络结构来降低神经网络的复杂度。如今，卷积神经网络已经成为了人工神经网络的一种，在模式分类领域有着优秀的表现，是科学众多领域的研究方向之一。它由卷积层和子抽样层组成。图像中的某个位置对应的编码信息和每个神经元相关联。一个性能较好的神经网络往往由成千上万个神经元组成。神经元作为神经网络的基本单位，每个神经元都有输入和输出，上一个神经元的输出作为本神经元的输入，与输入权值共同作用于本神经元并输出一个结果反馈给与本神经元相关联的下一层神经元，整个神经网络是实现权值共享的。卷积神经网络实质上是一个多层感知机，它的特征提取主要是通过神经网络不断的从数据集中学习并对特征进行表征而来，因此，我们无法直观的看出该网络具体提取了什么样的特征，同时，随着每一轮的迭代训练和反馈，权值被不断的优化以使神经网络的特征提取达到最优效果。采用权值共享的方法不仅降低了特征提取和分类过程中的数据重建次数，同时也很大程度的降低了网络的复杂程度。卷积神经网络依赖于每个神经元都有很少的输入和分层局部连接具有非常强的先验结构的两种假设。卷积神经网络的网络结构接近实际的生物神经网络，作为深度学习架构的一种，在提取图像本质特征方面有其他方法不可比拟的效果。利用深度卷积神经网络对行人视频图像进行特征提取和分析，进行行人重识别的研究不仅具有较高的理论意义而且具

有较强的实用价值。

1.2 国内外研究现状

目前,很多国内外学者在基于深度学习的行人重识别研究方面,付出了大量的心血同时也获得了卓越的研究成果。

1.2.1 行人重识别研究现状

行人重识别研究开始于多目视觉跟踪。行人重识别这个术语在还没正式被提出时是跟多相机追踪紧紧结合在一起的。1997年,Huang和Russel^[2]提出了一个贝叶斯公式来估算根据在其他相机视图中观察到的外观模型来预测一个相机中物体的外观。外观模型包括多个时空特征,如目标的长度、宽度和高度,目标的运行速度和观察时间,目标的颜色。多相机追踪逐渐与“行人重识别”明确结合在一起^[3]。据我们所知,第一部关于多目视觉跟踪的工作提议使用“行人重识别”一词是在2005年提出的,是由Wojciech Zajdel、Zoran Zivkovic和阿姆斯特丹大学的Ben J. A. Krose^[4]在他们的ICRA'05论文题为“追踪人类:我之前有见过这个人吗?”,指同一个人离开视野后重新进入时,能够重新识别出该人。在他们的方法中,使用动态贝叶斯网络作为自轨迹的编码标签和特征之间的概率关系,同时每个人都有一个独特的潜在标签。任何一个后进入视野的人的身份由近似贝叶斯计算的标签分布推理算法验证。

一年后的2006年,Gheissari等人^[5]只采用时空分割算法之后的视觉线索用于前景检测。基于显著边缘直方图的视觉匹配根据关节型行人模型或者hessian仿射兴趣点算子来执行。实验是在数据集上进行的,数据集中共有44人并且视野适中各自交叠,由3台相机拍摄完成。尽管Gheissari等人设计了一个时空分割方法,该方法是基于视频帧的,但是它的匹配过程和特征设计阶段,都没有用到视频信息,因此我们将Gheissari等人所做的事情归类为基于图像的重识别。这项工作标志着行人重识别开始作为一个独立的研究课题出现,不依附于多目视觉跟踪的研究课题。

由于最初用于跟踪视频,图像匹配是大多数的重识别工作关注的重点。2010年,两篇论文^{[6][7]}的发表,提出了通过随机选择帧画面,将图像匹配用于多镜头重识别拍摄,在这两篇论文中,颜色是他们使用的共同特征。对于前景的检测论文采用了分割模型。两篇论文都提出了以计算两个图形边界框之间距离大小来实现距离度量。Bazzani等人,则进一步使用巴氏距离用于颜色和通用缩影功能。它表明行人检测效率使用多帧相比于单帧将会有效提升,而且重识别精度会随着所选帧数增加趋于饱和。2014年,深度学习在图像分类上的成功传播到了

重识别领域^[8]。由于训练样本数量的有限性，Yi 等人^[9]和 Li 等人^[10]都采用孪生神经网络^[11]的方式来判定一对输入图像是否具有相同的身份。不仅参数设置发生变化，主要的区别在于在网络中增加了附加成本函数，该函数使用的更加精细的身体分割方法。在和实验数据集没有发生重叠，所以这两种方法没有直接可比性。虽然它在小数据集集中的表现还不稳定，但是自此以后深度学习方法成为了重识别领域的一个热门选项。

由于绝大多数论文在实验中使用了手工裁剪的框子或者固定的探测器制造的框子，因此很有必要研究一下行人探测器对重识别重要性的影响。2014 年，Xu 等^[12]通过结合检测（共性）和重识别（唯一性）得分来解决这个问题。它表明，在 CAMPUS 数据集上联合考虑检测和重识别相比于单独使用它们会带来更高的行人检索准确率。随着深度学习的不断发展，越来越多的高效学习模型被应用于行人重识别领域，重识别的准确性和识别速率也在不断进步。科研工作者们在研究重识别问题时结合了各个学科的知识和技术，如：机器学习、模式识别等。虽然目前行人重识别取得了一定的成就，但重识别研究离实际应用还有很大一段距离，仍需广大研究人员的不断努力。

1.2.2 深度学习研究现状

深度学习作为人工智能领域的一项重要研究内容，世界各大科技企业纷纷投入大量精力到深度学习的研究和应用中来。BAT 作为中国乃至世界著名的高科技互联网巨头分别在深度学习领域投入了巨大的研发。

作为一家以技术为信仰的高科技公司，早在 2012 年，百度启动人工智能研究计划，成立百度研究院主要从事自然图像 OCR 识别和人脸识别^{[13][14]}，致力于人工智能等相关前沿技术的研究与探索。随后推出了百度 AI 技术平台体系，主要提供语音技术、图像技术和人脸人体识别技术方面的应用。2016 年，百度推出以感知平台、机器学习平台和深度学习平台组成的天智平台。自 2017 年以来，百度全面进入人工智能行业，涉及到出行^[15]、医疗、金融、零售、物流等 15 个行业。目前百度已是国内综合技术储备方面顶级的人工智能公司，极大的推动了人工智能的发展。

阿里巴巴凭借云服务资源、支付和电商优势与人工智能技术展开深度融合，将技术优势逐步面向多领域发展。它目前主要以阿里云为基础，有 EI 金融大脑、EI 工业大脑、ET 城市大脑、智能出行、人脸识别和声纹识别等 6 大板块。

腾讯公司在 AI 方面，也取得了令人瞩目的成绩，公司推出的许多产品，极大的方便了我们的生活。例如许多人生活中都离不开而且受众人群庞大的微信，它的许多功能都是基于深

度学习算法的，我们所熟悉的图像识别功能、语音识别功能等等。

今日头条，作为字节跳动旗下的一款明星新闻产品，秉持着你关心的才是头条，每天向用户推送着用户感兴趣的个性化产品。它之所以如此智能化，是因为今日头条以机器学习为主设计了庞大的推荐系统。由于用户量的庞大和海量的数据，靠人工完成大量的针对用户的个性化推送几乎是不现实的，必须依靠自动化算法来完成这一任务，而深度学习在这一方面的性能是非常强大的，并且与人工推送相比，不仅速度快而且精确度还很高。

国外在深度学习方面的研究也取得了非常大的进展，众所周知，AlphaGo 打败了韩国著名围棋选手李世石，一时引起了轰动，让深度学习名声大噪，美国谷歌公司很早就投入深度学习的研究，布局人工智能行业，谷歌的一些其他的人工智能项目例如谷歌翻译、无人驾驶、虚拟人脑等也都在惠及人们的生活。

在 “Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification” 论文中，微软研究团队指出该论文中提及的深度学习网络已经在 ImageNet 数据集中表现出色，取得了非常卓越的识别效果并具备相当好的泛化能力，他们所搭建的网络模型在一定的场景下的识别错误率已经低于人眼。微软研究团队表示，这是人类历史上第一次机器图像识别首次超过人眼的壮举。

同样，作为信息科技巨头的 Facebook 也在深度学习领域取得巨大的成就，它围绕深度学习采用的了无监督学习的技术，已经具备了自动生成具备特定指定特征的图像数据，可以达到以假乱真的效果，实现了人工智能的又一次飞跃。

近年来，深度学习在飞速发展，也涌现出很多高性能的网络结构，但在目标识别^{[16][17]}和分类中，卷积神经网络具有不可替代的作用。最早有最具代表性的卷积神经网络模型非 LeNet-5 莫属了，LeNet-5^[18]不仅给人们对卷积神经网络的认识提供了便捷而且对卷积神经网络的发展起到了巨大的推动作用。

AlexNet^[19]是 2012 年 ImageNet 竞赛冠军获得者 Hinton 和他的学生 Alex Krizhevsky 设计的，AlexNet 将 LeNet 的思想发扬光大，把 CNN 的基本原理应用到了很深很宽的网络中，使人们对深度卷积神经网络又有了新的认识。通过成功使用 ReLU 作为 CNN 的激活函数，成功解决了 Sigmoid 在网络较深时的梯度弥散问题；通过训练时使用 Dropout 随机忽略一部分神经元，避免了神经网络模型过拟合的问题；利用 GPU 强大的并行计算能力，使用 CUDA 加速深度卷积神经网络的训练，大大加快了训练速度。自此之后，越来越多的优秀神经网络被提出。

2013 年，LeNet-5 的发明者 Lecun 基于 AlexNet 提出了 OverFeat^[20]，提出了学习边框的概念，引起了界内学者的研究热潮。

2014 年,英国牛津大学的 VGG^[21]模型选用了小卷积核,将卷积核全部替换成了 3×3 ,相比于 AlexNet 3×3 的池化核, VGG 全部选用 2×2 的池化核,取得了不俗的成绩。

随着卷积神经网络的深入发展,该网络结构越来越倾向于构建更多的层数,但是伴随着层数的增多往往会导致计算效率降低。

ResNet^[22]则有效的解决了这个问题,使得较多的层数下的网络依然可以保持较好的性能和识别效率。

虽然深度学习算法在计算机视觉领域获得了大量的成就,但是依然有很多问题有待研究,深度学习在下一个阶段的研究任务主要是以下几点:

(1) 无标记的特征学习

目前,数据集要想带入网络模型进行有效的训练,必须先对数据进行标记,但在实际应用中,对数据进行训练之前先进行标记无疑是不现实的,标记需要占据大量的人力物力,而且不利于实时的解决问题。因此,怎样使网络模型设计的更加有利于无标记数据进行训练或者智能化处理标记无疑能成为未来深度学习领域的重点问题。

(2) 训练速度与训练精度之间的关系处理

想要追求训练精度往往会导致训练耗费的时间增多,速度降低,如若想要追求速度也势必要牺牲精度,如何两者兼顾,设计出最大限度满足这两者的模型还是非常值得期待的。

(3) 算法改进

由上述讨论可知,将深度学习单独应用在图像识别方面时具有一定的局限性,每个参数的不确定性都会导致最终识别率的大幅度下降。因此,我们需要对一致的深度学习算法进行改进,或者考虑和其他算法相结合,以降低神经网络在调优过程中的对参数敏感度的要求,同时又能提高神经网络训练的准确度和减少训练的时间,以获得较优的效果。

1.3 论文组织结构

本论文针对行人检测系统进行分析研究,提出了基于深度学习的行人检测重识别技术方案。不仅通过生成对抗网络完成对原始数据集的扩充,同时对深度残差网络基础模型进行了改进,使行人的检测和重识别更加高效和智能化。最后,通过搭建 PyTorch 实验平台,验证了本论文所设计的方案的可行性和高效性。

论文共分为六个章节,详细概述如下:

第一章:对基于深度学习的行人检测重识别技术的研究背景和研究意义进行了探讨和分析,简单介绍了行人重识别和深度学习的国内外研究现状。其次,详细阐述了本论文的组织

结构，方便对后续内容的整体理解。

第二章：首先介绍了卷积神经网络的相关概念和技术特点，其次，研究分析了作为图像分类中被广泛采用的 ResNet 残差网络，分析了网络层中增加了直连通道，并通过残差函数获得恒等映射函数方式。接着，针对生成对抗网络进行了详细的描述和分析，阐述了生成对抗网络的核心原理算法。然后，分析了行人检测和行人重识别中的常用特征。最后，介绍了 PyTorch 框架，为研究提高了可靠的参考依据。

第三章：分析了训练集扩容所需的学习模型，并探讨了数据扩容训练的方式。然后，通过分析卷积神经网络中如何进行特征提取，阐述了特征提取的流程和所需进行的步骤。

第四章：首先，从理论上分析了实验所需的数据集和实验的性能评估标准。其次，通过改进的学习模型进行人重识别训练和测试。最后对实验结果进行分析，通过与传统模型的对比突出了改进的模型对重识别性能进行了提升。

第五章：通过对需求和功能的分析，设计并实现了基于深度学习的行人检测重识别系统。

第六章：对本论文主要取得的研究成果进行了总结，其次，对本课题未来可能的研究方向以及应用领域提出了进一步的思考和分析。

第二章 相关技术综述

在本文所介绍的系统中，对行人进行高效的特征提取以及特征间的距离度量是非常重要的环节，同时我们也要通过生成对抗网络来进行数据集增强，因此，本章将先介绍卷积神经网络相关知识，在了解卷积神经网络的基本组成之后对残差网络中的残差模块以及基本原理有一个更加深入的理解，然后介绍生成对抗网络及深度卷积生成对抗网络，并对行人检测和重识别常用的特征进行系统介绍，最后，我们将会对本实验所选用的平台有一个直观的了解。

2.1 卷积神经网络

2.1.1 人工神经元简介

人工神经网络也被称为神经网络或者类神经网络，是一种类似于大脑神经突触连接结构进行信息处理的数学模型^[23]，对于一个神经网络而言，可以接收多路输入的特征向量经过层层推导得到最后的输出，并通过这些输出解决分类或者回归问题，适用于信号处理、模式识别、机器人视觉、调度排序等组合优化问题。该模型由大量的神经元组成，神经元是构成一个神经网络的最小单元，简单的神经元结构如图 2-1 所示：




图 2-1 单个神经元结构

如图 2-1 所示，多个输入和一个输出组成了单个神经元结构。一个神经元接收多方输入的特征值，然后分别对特征值进行相应的加权求和，以及加上偏置量，最后通过非线性函数变换得到输出结果。神经元的参数为各个输入所对应的权值，所有输入进行加权求和组成了一个最简单的神经元结构。多个简单的神经元之间相互连接就组成了一套完整的神经网络系统。

假设单个神经元有 m 个输入 $(x_1, x_2 \cdots x_m)$ ，同时，每个输入对应的权分别为 $(w_1, w_2 \cdots w_m)$ ， b 表示偏置量， f 表示非线性函数，则得到的输出 z 如式 2.1 所示：

$$z = f(\sum_{i=1}^m x_i w_i + b) \quad (2.1)$$

由于输入的特征包含许多干扰因素，所以我们将低维空间映射到高维空间，将线性不可变的部分变成线性可分即激活函数的方式降低干扰因素。

为了降低无关因素所对应的权值和增大具有差异性特征的权值，我们根据输出结果计算误差，反向修改各个参数，尽量降低甚至排除无关因素或是噪音对识别结果造成的影响。

2.1.2 LeNet-5 网络简介

1998 年，Yan LeCun 教授在其论文 Gradient-based learning applied to document recognition 中首次提出了 LeNet-5 模型概念，并成功将卷积神经网络应用于数字识别问题^[24]。实验结果表明：在 MNIST 数据集基础上，LeNet-5 模型的正确率达到了惊人的 99.2%。LeNet-5 模型总共有 7 层如图 2-2 所示。




图 2-2 LeNet-5 结构图

但由于局限于当时计算机硬件的发展水平，LeNet 的层数被限制，导致对于复杂的图像进行识别时表现不佳。相反，当时的浅层算法例如 SVM，在图像识别方面有着比 LeNet 要好的表现。但是随着数据集的不断扩充和复杂度的不断提高，浅层机器学习算法的参数相比于深度学习较少，其局限性凸显出来，导致了在对复杂图片进行识别时准确率出现快速衰减，其识别率无法达到预期效果。因此浅层算法没有得到大规模的应用和普及，机器学习的发展一再延缓。

随着计算机技术的不断发展，计算机硬件得到了突飞猛进的发展，各种高性能处理器被研发出来，同时硬件的价格大幅下降，为深度学习的研究奠定了良好硬件基础。之前局限于计算机硬件而无法解决的问题，如今都得以解决。计算机硬件的高性能处理器解决了计算的问题，神经网络解决了算法优化的问题，使得网络层数可以进一步的增加。随着卷积神经网络的研究和应用的深入，其在图像识别和语音识别领域取得了优秀的表现，得到了人们广泛的认可。

深度学习的基础即神经网络，典型的深度卷积神经网络（Deep Convolutional Neural Networks, DCNN）的结构一般由输入层、隐藏层和输出层三大层次组成^[25]。在 LeNet-5 结构

如下:

(1) 输入层 (INPUT 层)

输入图像的大小为 32×32 。

(2) 隐藏层 (C1 层、S2 层、C3 层、S4 层、C5 层和 F6 层)

隐藏层主要是卷积层 (C1 层、C3 层) 和池化层 (S2 层、S4 层)。卷积层和池化层主要功能是对输入的图像进行特征提取和整合。由于每次面对识别图像的不确定性, 我们不能对参数进行指定性的初始化, 只能采取随机生成的方式。同样, 卷积核取多大值以及梯度下降算法选择怎样的起始点都是不确定的。要想修改参数, 我们需要用 BP 算法不断进行反向迭代。伴随着迭代次数的不断增加梯度下降算法会逐渐减小, 网络模型慢慢的达到最优化的状态, 这也意味着一个高效的卷积神经网络就此生成了。与此同时, 因为神经网络每次训练的参数都是随机生成而不是指定的, 产生最优网络模型时的迭代次数也不是一个定值, 需要进行大量的实验, 从而确定迭代次数的值使得网络模型性能最优。由于迭代次数是不确定的, 这就给问题的解决带来很多障碍。C5 层和 F6 层都是全连接层, 在样本空间中映射前面池化层和卷积层学习到的特征。

(3) 输出层 (OUTPUT 层)

我们一般认为它是用来感知隐藏层的, 通常被视为隐藏层上的一个感知器, 主要用来识别输出的结果。根据分类方式的不同分为二分类和多分类, 分别对应采用的分类器为 Logistic Regression 和 Softmax Regression 的分类器。

深度卷积神经网络在 2012 年的 ImageNet 大赛中以极高的准确率完成了对其他算法的超越, 一鸣惊人, 取得大赛的桂冠, 又一次成功的吸引了来自全球学者和科技公司的关注。随着 2016 年 ALphaGo 和围棋高手李在石的较量以人工智能的胜利告终, 深度学习在人工智能中已经在以上领域完成了对人类的超越, 正式崛起。全球的高科技互联网公司分别加大投入, 使得卷积神经网络在人工智能领域得到飞速的发展。目前各大科技公司分别推出了 AI 智能平台, 主要提供人脸识别、图像识别、语音识别、语义识别等服务。

2.1.3 ResNet 残差网络

随着对神经网络的深入研究, 深度卷积神经网络的出现和使用为图像分类带来了巨大的突破。其中网络的深度是非常重要的参数, 所以人们在不断的探索更加深层次的网络模型。然而, 更加深层次有效的网络模型并非是多个层次的简单逻辑堆积, 同时由于全连接网络或传统卷积网络在消息传递过程中所产生的信息丢失、损耗以及出现梯度消息/爆炸等现象, 导

致深度卷积神经网络的网络层次无法得到准确和有效的训练。在网络训练过程中并非网络层次越深越好，过度的拟合会提高训练的错误概率，实验结果证明随着网络深度的不断增加，其准确度就会随之达到饱和，然后出现断崖式下降的现象。所以并非所有的系统都同样易于优化。微软研究院的 Kaiming He 等四名华人提出了 ResNet，ResNet 网络^[26]通过将输入的消息直接输出到输出层的方式保证了信息的完整性，同时使得网络学习只关注输入和输出之间的差别从而简化学习的目标和难度，最终上述问题在 ResNet 网络中得到了很大程度的解决，并通过使用 ResNet Unit 成功训练出了 152 层的神经网络，并在 ILSVRC2015 比赛中以在 top5 上的错误率为 3.57%，同时比 VGGNet 更低的参数量，获得了冠军。ResNet 的网络结构在极大的提高了模型准确率的同时也加速了神经网络的训练速度。于传统的网络模型相比 ResNet 网络采用了 shortcut 或者 skip connections 的结构（即通过直连通道的方式将输入直接转接到输出）同时 ResNet 网络具备更加优秀的推广性，甚至可以直接用到 InceptionNet 网络中。

ResNet 提出了 Highway Network 的思想，即在网络层中增加了直连通道^[28]。传统的网络结构是对输入的参数一个非线性变换，而 Highway Network 则允许保留之前网络层输入的一定比例的输出。ResNet 的思想和 Highway Network 的思想也非常类似，允许原始输入信息直接传到后面输出接口，如图 2-3 所示。




图 2-3 ResNet 的残差学习模块

在深度残差网络中，网络层次较多，假设深层网络采用恒等映射的方式，那么深度残差网络就相当于一个浅层网络。因此如何学习恒等映射函数成了准确和快速完成深度网络训练的关键。深度网络难以训练的原因在于直接拟合一个潜在的恒等映射函数 $H(x)=x$ 。因此，将网络设计为 $H(x)=F(x)+x$ 的方式，如图 2-3 所示。然后通过恒等变换将公式变换为一个残差函数 $F(x)=H(x)-x$ ，令 $F(x)=0$ ，则形成了 $H(x)=x$ 的恒等映射函数，通过该方式可以大大降低拟合残差的难度。通过 shortcut 同等映射如式 2.2-2.4 所示：

$$y = F(x, \{W_i\}) + x \quad (2.2)$$

$$F = W_2 \sigma(W_1 x) \quad (2.3)$$

其中， σ 表示非线性函数 ReLU， W_i 表示第 i 层加权值， $F(x)+x$ 表示逐元素相加，相加之前需要通过线性映射保证两个元素具有相同的维度， W_s 为一个线性变换。公式 2.2 可以转换为如式 2.4 所示：

$$y = F(x, \{W_i\}) + W_s x \quad (2.4)$$

正如图 2-3 所示，我们可以看到一个“弯弯的弧线”这个就是所谓的“shortcut connection”这张图也诠释了 ResNet 的真谛，ResNet 模块的使用主要有以下两种方式，如图 2-4 所示：




图 2-4 两种 ResNet 设计

这两种结构分别针对 ResNet34（图 2-4 左图）和 ResNet50/101/152（图 2-4 右图），整个结构被称为一个“building block”。其中右图又称为“bottleneck design”。为了实际计算考虑，作者提出了一种 bottleneck 的结构块来代替常规的 Residual block，它像 Inception 网络那样通过使用 1×1 卷积来巧妙的缩减或扩张 feature map 维度从而使得我们的 3×3 卷积的 filters 数目不受外界即上一层输入的影响，自然它的输出也不会影响下一层的 module。

2.2 GAN 生成式对抗网络

GAN（Generative Adversarial Network）的概念首先由 Ian Goodfellow 提出^[29]，在人工智能领域，GAN 已经成为了一个热门研究方向。GAN 主要包括了两个部分，即生成器 generator 和判别器 discriminator，主要是通过两个网络的相互对抗来达到最好的效果。生成器主要任务是学习真实图像分布，以生成与原图片相似度高的图片，来让判别器通过。判别器则需要对

接受的图片进行真假判断，最终判别器无法识别出生成器生成的图片。在网络对抗的过程中，生成器努力的提高生成的图片和真实图片的相似度，而判别器则努力的识别出图像的真假，这个过程相当于一个两人零和游戏（指参与博弈的各方，在严格竞争下，一方的收益必然意味着另一方的损失，博弈各方的收益和损失相加总和永远为“零”，双方不存在合作的可能）。随着博弈进程的不断推移，博弈双方不断地进行学习、对抗、再学习，最终两个网络完成拟合。通过对于给定图像的预测为真的概率基本接近百分之五十来估测数据样本特征的布局，然后根据特征值进行生成新的图片样本，即生成器生成的图像可以骗过判别器的判断，同时判别器能够准确的识别出生成器生成的对象。目前，GAN 主要应用在图像识别和计算机视觉、语音识别和信息安全等领域并延申到其他重要领域，具有非常广的应用前景。

2.2.1 生成对抗网络原理

GAN 的对抗网络的流程与结构如图 2-5 所示，其中判别器和生成器可以使用任何可微分的函数^[30]，由此，假设微分函数 D 表示判别器和 G 表示生成器，生成器的输入为随机 Z 和判别的结果，如果判别器的输入结果为真实数据 x ，生成器生成的结果为满足服从 P_{data} 分布的样本。如果判别器的输入来自真实数据那么该数据被标注为 1。如果输入的为生成器生成的样本 $G(x)$ 则标注为 0。判别器 D 对输入数据进行二分类判别。而生成器 G 的目标是使自己生成的伪数据 $G(x)$ 通过判别器 D 后得到和真实数据相同的图片。由于判别器和生成器之间的不断对抗，使得判别器和生成器均得到一定程度的提高，最终判别器能够达到无法正确判别数据来源，则可以认为卷积神经网络完成拟合，同时生成器 G 完成了对真实数据的分布的学习^[35]。




图 2-5 GAN 流程图

对抗网络核心算法如下：

首先，假定具有相同的生成器，然后对判别器进行优化，判别器进行非黑即白的判断操作，通过最小化交叉熵的处理过程实现对判别器的优化。 $E(\cdot)$ 代表为计算得到的期望值， x 采

样于真实数据分布 $P_{data}(x)$, z 采样于先验分布 $P_z(z)$ 。生成器为了学习数据 x 的分布, 由先验噪声分布 $P_z(z)$ 构建了一个映射空间 $G(z; \theta_g)$, 对应的判别器映射函数为 $D(x; \theta_d)$, 输出一个标量表示 x 为真实数据的概率。GAN 的目标函数可以描述如式 2.5 所示:

$$\min_G \max_D \{f(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))]\} \quad (2.5)$$

其中, $E_{x \sim P_{data}(x)} [\log D(x)]$ 中, x 表示真实样本, $D(x)$ 表示 x 通过判别网络判断其为真实样本的概率; $E_{z \sim P_z(z)} [\log(1 - D(G(z)))]$ 中, z 表示输入生成样本的噪声, $G(z)$ 表示生成网络由噪声 z 生成的样本, $D(G(z))$ 表示生成样本通过判别网络后, 判断其为真实样本的概率, 生成网络的目的是让生成样本越接近真实样本越好, 即 $D(G(z))$ 越接近 1 越好, 这时 $f(D, G)$ 会变小; 而判别网络的目的是让 $D(x)$ 接近 1, 而 $D(G(z))$ 接近 0, 此时 $f(D, G)$ 会增大。从实际结果看, 相比于其他生成模型, GAN 能产生更好的生成样本。GAN 的优化问题是一个极小—极大化问题。

对于卷积神经网络的学习过程, 需要不断的对判别器进行训练, 使得判别器能够从生成器生成的图片中准确的判别出每一个图片数据是来源于真实数据还是来源于伪数据。直至来源于真实数据或者伪数据分布 $G(z)$ 的准确率为百分之五十。于此同时, 通过 $\log(1 - D(G(z)))$ 来评判生成器是否达到要求。

模型的训练一般采用固定参数法, 即先固定生成器或者判别器, 然后对另外一个进行不断优化使得其准确率达到最优状态, 然后再固定判别器, 从而对生成器进行优化以至其达到最优, 有且仅当 $P_{data} = P_g$ 时达到全局最优解。最终完成生成器和判别器的优化工作。

2.2.2 深度卷积生成对抗网络

深度卷积生成对抗网络 (Deep Convolutional Generative Adversarial Networks, DCGAN) 是在 GAN 基础上的改进^[31], 它利用深度卷积网络进行生成对抗网络的建模, 在图像处理方面, DCGAN 比传统的神经网络更具有优势, 同时通过判别网络提取的图片特征具有普适性, 不管是简单场景的还是复杂场景下图片的识别与分类均能有较好的适应性高于 GAN 的效果。另外, DCGAN 中生成器所生成的图片不仅具有更高的相似度, 同时还可以学习到过滤层。DCGAN 通过融合全卷积神经网络对之前提到的 GAN 网络进行改进, 从而由输入图像生成输出图像。

深度卷积生成对抗网络将卷积神经网络引入到了生成模型和判别模型当中, 使得生成性能有了质的提升, 以至于后来很多工作都在该网络的基础上进行改进。该网络结构主要有以

下特点：1) 删除网络中的全连接层；2) 将批归一化层引入到生成模型和判别模型中；3) 使用相应步长的卷积层来代替卷积网络中的池化层；4) 在判别模型中采用 LeakyReLU 激活函数；5) 在生成模型中采用 ReLU 激活函数。与一般的生成对抗网路相比，深度卷积神经网络拥有更优的性能和更加强大的生命力，而且相比较而言更加容易训练，模型也相对更加稳定，适用的范围也更加多元化。

卷积网络结构被引入生成对抗网络中造就了深度卷积生成对抗网络，DCGAN 结合了 GAN 的优点和卷积层强大的特征提取能力^[32]。与传统 GAN 比较，DCGAN 具有以下优点：

- 1) 将 Four fractionally-strided convolution 应用于生成器模型中，实现图片的生成过程，将随机噪声生成成为图片，在判别器模型中使用带步幅的卷积代替池化层。
- 2) 该网络模型中加入了 Batch Normalization 层，使用了批量归一化方法，除了生成器模型的输出层和相对应的判别器模型的输入层。
- 3) 使用卷积层连接生成器和判别器的输入层和输出层，删除了全连接层。虽然全连接层的删除使得模型变得更加稳定，但是却大大降低了收敛速度。
- 4) Leaky ReLU (Leaky rectified linear unit) 被使用于判别器的所有层，Tanh (双切正切函数) 激活函数被使用于生成器的输出层，ReLU (Rectified linear unit) 则被使用于这些之外的所有层。

2.3 行人检测和重识别常用特征

2.3.1 行人检测常用特征

行人检测是行人重识别的先导，行人重识别的很多研究都是在行人检测基础上探索而来。行人检测的主要工作是通过行人检测算法将行人从整张图片中提取出来，那么特征提取在图像处理过程中就显得尤为关键。怎样找出行人的最有辨识度的特征，对识别出行人来说非常重要。行人检测中最常用的人工设计特征主要包括 HOG 特征、DPM 特征、ACF 特征^[33]。

1. HOG 特征

方向梯度直方图 (Histogram of Oriented Gradient, HOG) 特征是一种在计算机视觉和图像处理中用来进行物体检测的特征描述子。它通过计算和统计图像局部区域的梯度方向直方图来构成特征。在图像识别中，Hog 特征结合 SVM 分类器被广泛使用，被成功应用于行人检测中。在一副图像中，局部目标的表象和形状能够被梯度或边缘的方向密度分布很好的描述，因为梯度主要存在于边缘的地方。由于 HOG 是在图像的局部方格单元上操作，所以它对图像

几何和光学的形变都能保持很好的不变性,这两种形变智慧出现在更大的空间领域上。其次,在粗的空域抽样,精细的方向抽样以及较强的局部光学归一化等条件下,只要行人大体上能够保持直立的姿势,可以容许行人有一些细微的肢体动作,这些细微的动作可以被忽略而不影响检测效果。定义 (x,y) 为图像中的某一个像素点,则有如式 2.6-2.9 所示:

$$G_x(x,y) = H(x+1,y) - H(x-1,y) \quad (2.6)$$

$$G_y(x,y) = H(x,y+1) - H(x,y-1) \quad (2.7)$$

式中 $G_x(x,y)$, $G_y(x,y)$, $H(x,y)$ 分别表示输入图像中像素点 (x,y) 处的水平方向梯度、垂直方向梯度和像素值。像素点 (x,y) 处的梯度幅值和梯度方向分别如式 2.8-2.9 所示:

$$G(x,y) = \sqrt{G_x(x,y)^2 + G_y(x,y)^2} \quad (2.8)$$

$$\alpha(x,y) = \tan^{-1}\left(\frac{G_y(x,y)}{G_x(x,y)}\right) \quad (2.9)$$

具体的特征提取步骤如下所示:

首先将图像分割成 c 个像素单元(cell), 把梯度方向平均划分成 b 个方向(bin), 再将相邻的 L 个 cell 组成一个块(block)。对每一个 cell 里面所有像素点在不同 bin 里的梯度进行直方图统计, 可以得到一个 b 维的特征向量。这样每个 block 中会包含 $L \times b$ 个特征向量。用 block 以一个 cell 为步长对整个图像进行扫描, 最后将所有 block 的特征串联起来就得到了人体的特征。

具体的行人检测步骤如下:

(1) 标准化 gamma 空间和颜色空间

为了减少光照因素的影响, 首先需要将整个图像进行规范化(归一化), 在图像的纹理强度中, 局部的表层曝光贡献的比重较大, 所以这种压缩处理能够有效的降低图像局部的阴影和光照变化。因为颜色信息作用不大, 通常先转化为灰度图。Gamma 压缩公式如式 2.10 所示:

$$I(x,y) = I(x,y)^{\gamma} \quad (2.10)$$

当 $\gamma < 1$ 时, 图像的低灰度区域对比度变高, 高灰度区域对比度降低, 图像整体的灰度值变大。相反, $\gamma > 1$ 时则低灰度区域对比度降低, 高灰度区域对比度变高, 整体的灰度值变小;

(2) 计算图像梯度;

(3) 进行分类识别;




图 2-6 b=9 的 bin 块

我们将图像分成若干个图片像素为 6×6 的“单元格”也被称为 cell。也就是将 cell 的梯度方向 360 度分成 9 个方向块。我们采用积分直方图来计算 HOG 的方式对直方图进行了进一步的改进，是因为 HOG 存在计算速度慢、维度高的缺点。

2. DPM 特征

可变性的组建模型（Deformable Part Model, DPM）是一种检测算法，它区别于其他检测算法的一个重要特征是它是基于组件的，Felzenszwalb 在 2008 年提出了该模型^[34]。DPM 是以 HOG 为基础进一步改进而来的，因为 HOG 比较适用于行人相对静止且站立没有附加多余动作的场景，当物体发生形变时，HOG 就无法使用，于是 DPM 将物体发生运动以及运动所产生的形变纳入检测范围，使用子模型用以检测物体的每个单独部件。因此 DPM 的基本流程是在 HOG 的基础上增加了用以检测物体子部件的子模型。DPM 特征的实质是物体的使用各个部件以及每个部件之间的联系来连接和表示物体每个部件就相当于人的头、躯干和四肢，部件间的联系又相当于血肉而人的头、躯干和四肢都是通过血肉相连却又可以各自有自己独立的动作和形变。DPM 是由一个根滤波器和一组部件滤波器及其可变模型组成的星型结构的部件模型。

响应值得分公式如式 2.11 所示：

$$\text{score}(x_0, y_0, l_0) = R_{0,l_0}(x_0, y_0) + \sum_{i=1}^n D_{i,l_0-\lambda}(2(x_0, y_0) + v_i) + b \quad (2.11)$$

其中， x_0, y_0, l_0 分别为锚点的横坐标、纵坐标、尺度； $R_{0,l_0}(x_0, y_0)$ 为根模型的响应分数；

$D_{i,l_0-\lambda}(2(x_0, y_0) + v_i)$ 为部件模型的响应分数； b 为不同模型组件之间的偏移系数，加上这个偏移量使其与模型进行对齐； $2(x_0, y_0)$ 表示组件模型的像素为原始的 2 倍，所以，锚点为 2； v_i 为锚点和理想检测点之间的偏移系数。

3. ACF 特征

聚合通道特征 (Aggregate Channel Feature, ACF) 是由 Piotr Dollar 提出的^[35], 当原始图像输入经过一些线性或者非线性变化, 将会得到一些底层特征, 我们称这些底层特征为通道。我们将对原始输入图像的针对像素点的基本操作称之为为一阶通道特征, 将对一阶通道特征进行叠加操作之后得到的特征总和称之为高阶通道特征。聚合通道特征的实质就是将各个通道中不同的特征进行叠加, 汇聚成为一个完整的特征。他可以对行人进行高效的表示。




图 2-7 聚合通道特征描述子示意图

如图 2-7 所示: 对于输入图像, 分别计算该图像的 LUV 三个颜色通道的特征, 分别是图 2-7 中的(b)(c)(d), (e)表示它的梯度幅值特征通道, (f)(g)(h)(i)分别是四个梯度方向通道特征。对这些特征进行聚合后得到统一的特征如图 2-7 (j)所示。

2.3.2 行人重识别常用特征

行人重识别技术是实现无重叠的多摄像头下的行人匹配, 即一个行人从一个摄像机下消失后, 当其在其它摄像机下再次出现时能够将其与之前摄像机下的该行人重新建立关联, 而不是当这个行人再次出现在摄像机下时被当作一个新的行人目标。总的来说就是对不同监控所产生的数据中出现同一行人进行识别的技术。对于传统的行人重识别, 我们要先设计出需要提取的特征, 然后对特征进行提取用以进行后续的重识别, 接着对提取的特征进行特定的距离度量, 算出是否为同一特征从而判断是否为同一行人。常用特征主要是颜色特征和 SILTP 特征等。

1. 颜色特征

在行人重识别领域, 衣服等的颜色对于区分视频监控中的行人来说是一个相对来说比较明

显又好辨别的一个特征，也可以说此特征最具辨识度。颜色空间的差异性会影响到颜色特征的描述效果，颜色空间主要有 RGB、HSV、YCbCr 和 Lab 色彩空间等，HSV 颜色空间对光照变化具有一定的不变性，被认为更加符合人类对颜色的感官认知，因此在计算机图像处理中 HSV 被应用的很广。

HSV 颜色空间包括色度（Hue）、饱和度（Saturation）、亮度（Value）三个部分，其中色度是指颜色的种类，用角度度量，取值范围为 $0^\circ \sim 360^\circ$ ，饱和度指色彩的纯度，取值范围为 $0.0 \sim 1.0$ ，亮度表示色彩的明暗，取值范围也是 $0.0 \sim 1.0$ 。常见的彩色图片在计算机中的存储通常是以 RGB 形式存储的，RGB 和 HSV 之间可以互相转化，转换公式如式 2.12-2.16 所示：

$$\max = \max(R, G, B) \quad (2.12)$$

$$\min = \min(R, G, B) \quad (2.13)$$

$$H = \begin{cases} 0^\circ, & \text{if } \max = \min \\ 60^\circ \times \frac{G-B}{\max-\min} + 0^\circ, & \text{if } \max = R \text{ and } G \geq B \\ 60^\circ \times \frac{G-B}{\max-\min} + 360^\circ & \text{if } \max = R \text{ and } G < B \\ 60^\circ \times \frac{B-R}{\max-\min} + 120^\circ, & \text{if } \max = G \\ 60^\circ \times \frac{R-G}{\max-\min} + 240^\circ, & \text{if } \max = B \end{cases} \quad (2.14)$$

$$S = \begin{cases} 0, & \text{if } \max = 0 \\ \frac{\max-\min}{\max} = 1 - \frac{\min}{\max}, & \text{otherwise} \end{cases} \quad (2.15)$$

$$V = \max \quad (2.16)$$

2. SILTP 特征

尺度不变局部三元模式（Scale Invariant Local Ternary Pattern, SILTP）克服了 LBP 对噪声敏感以及 LTP 对光照敏感的缺点，对于行人重识别领域来说，它是一个非常重要的纹理特征，给定任意的像素点位置 (x_c, y_c) ，SILTP 的定义如式 2.17-2.18 所示：

$$SILTP_{N,R}^\tau(x_c, y_c) = \oplus S_\tau(I_c, I_k) \quad (2.17)$$

$$S_\tau(I_c, I_k) = \begin{cases} 01, & \text{if } I_k > (l + \tau)I_c \\ 10, & \text{if } I_k < (l - \tau)I_c \\ 00, & \text{otherwise} \end{cases} \quad (2.18)$$

其中， I_c 表示中心点的灰度值， I_k 表示中心点周围以 R 为半径的邻域像素点， $\oplus$ 表示二进制串的连接运算符， τ 表示比较范围的尺度因子， S_τ 是一个分段函数。

2.4 深度学习框架 PyTorch

2017 年 1 月，Facebook 人工智能研究院（FAIR）团队在 GitHub 上开源了 PyTorch，并迅

速占领 GitHub 热度榜榜首。作为一个 2017 年才发布,具有先进设计理念的框架,PyTorch 的历史可追溯到 2002 年。诞生于纽约大学的 Torch,使用了一种不是很大众的语言 Lua 作为接口。Lua 简洁高效,但由于其过于小众,用的人不是很多,以至于很多人听说要掌握 Torch 必须新学一门语言就望而却步。考虑到 Python 在计算机科学领域的领先地位,以及其生态完整性和接口易用性,几乎任何框架都不可避免地要提供 Python 接口。终于在 2017 年,Torch 的幕后团队推出了 PyTorch。PyTorch 不是简单地封装 Lua,Torch 提供 Python 接口,是对 Tensor 之上的所有模块进行了重构,并新增了最先进地自动求导系统,成为当下最流行的动态图框架。

PyTorch 官网提供了三种安装方式,分别是 conda, pip, source。支持 GPU,但需选择相对应的 CUDA 版本。本论文在 Ubuntu14.04 环境下基于 PyTorch 框架构建模型,因为 PyTorch 具备以下优点:

首先,PyTorch 的设计追求最少的封装,尽量避免重复造轮子。简洁的设计带来的另外一个好处就是代码易于理解。

其次,PyTorch 的灵活性不以速度为代价,在许多测评中,PyTorch 的速度表现胜过 Tensorflow 和 Keras 等框架。同样的算法,使用 PyTorch 实现的算法更有可能快过其他框架实现的。

再次,PyTorch 是所有的框架中面向对象设计的最优雅的一个。Torch 的接口设计以灵活易用而著称,PyTorch 继承了 Torch 的衣钵,符合人们的思维,不需要考虑大多关于框架本身的束缚。

最后,PyTorch 提供了完整的文档,循序渐进的指南,作者亲自维护的论坛供用户交流和求教问题。

2.5 本章小结

本章主要介绍了深度学习中的卷积神经网络的主要特点和应用领域,并选用了两个学习模型进行详细介绍。然后对生成对抗网络进行了详细的描述和分析,阐述了生成对抗网络在图像生成方面的优势,接着介绍了行人重识别领域常用的特征以及行人检测常用的特征。最后,对本论文的实验平台 PyTorch 进行了简单介绍,阐述了该平台的优点和选用理由。

第三章 基于 DCGAN 的行人图像特征提取

在行人重识别研究中，传统的方法一般是通过提取。某些特征（如颜色、姿势等）或者使用单一的滤波器来提取图像中的行人特征，而深度神经网络则是自动从数据中学习特征，因此，本章将讨论行人重识别研究中深度神经网络如何去学习特征和提取特征的。深度学习是通过多层非线性变换对高复杂性数据建立模型来学习数据中的特征，从而实现数据的抽象表示。深度学习也是通过组合大量简单的、非线性的模型将原始数据逐层转变成更高层次更加抽象的表达，从而发现数据中的复杂结构和隐含信息。也就是说，深度学习是通过模型训练从数据中学习特征而不是通过人工的方式提取特征的。所以本文采用深度卷积神经网络来实现特征提取，结合分类器模型建立基于深度学习的行人重识别系统。

3.1 训练集扩容

数据集数量太少导致分类模型的判断能力较弱，而且容易导致过拟合等问题，所以需要增加训练样本，但是实地采集比较麻烦并且爬虫得到的数据冗余又太多，因此，我们可以依靠 GAN 的特点来生成更多的图片来扩容整个数据集。

本小节将重点讨论深度卷积生成对抗网络（Deep Convolution Generative Adversarial Networks, DCGAN），本文将使用 DCGAN 作为数据集扩容也就是数据增强的基础模型进行数据生成训练。相对于原始的 GAN，DCGAN 的一大特点就是使用了卷积层。

3.1.1 DCGNN 介绍

对抗网络是由一个判别模型和生成模型组成。其网络结构大致如图 3-1 所示：




图 3-1 对抗网络结构

G 代表生成模型，D 代表判别模型。我们可以将 G 和 D 的对抗过程比喻成一个假币制作者和银行柜员的博弈过程，假如 D 为银行柜员的角色，那么 D 的功能就类似于不断的学习假币与真币之间的区别来更好的鉴别假币，假如 G 为假币制造者的角色，那么，G 所要做的事就是不断的学习真币的样貌，制造更好更不易被识别的假币来欺骗银行柜员。对基于神经网络的 GAN，其中的大致学习过程如下：

Z 是噪声，也就是 G 的输入，经过 G 之后生成假图像—G(Z)，然后将 G(Z)和 X 作为 D 的输入，最后的 D 的输出表示该数据为真的可能性，该值范围为 0-1 之间。GAN 的大致工作流程如上文所述，其中 DCGAN 是基于卷积的 GAN，其他没什么差别。在 DCGAN 中，G 的网络结构使用的是“de-convolution”层，它是需要进行上采样，D 则使用的是比较普遍的下采样。

DCGAN 的生成网络模型架构如下图 3-2 所示。




图 3-2 DCGAN 的生成网络模型架构

我们可以看到，从开始的 Noise 采样 100 维度，到最后生成了 64×64×3 的图片，经过了“de-convolution”层，实质是 transport convolution 或者 up-sampling convolution(上采样卷积

也就是反卷积)。由于普通卷积网络采用的是下采样卷积，而上采样不常用，下面将通过上采样和下采样的对比更好的区分上采样。下采样示意图如图 3-3 所示。




图 3-3 下采样示意图

在经过 3×3 的卷积核过滤之后， 4×4 的输入信号，产生了 2×2 的特征映射。上采样示意图如图 3-4 所示。




图 3-4 上采样示意图

2×2 的输入信号，经过 3×3 的卷积核过滤，产生了 4×4 的特征映射，维度逐渐由小变大。其实反卷积的本质就是卷积的反向传播，由于反向传播的滤波器矩阵，是前向传播的转置，我们只是将反向传播的过程变成了前向传播来做，就将这种现象称之为反卷积。

3.1.2 数据扩容训练

GAN 生成的数据可以继续用来训练新数据改善训练结果。GAN 从原始数据中学出的是分布。因为原始数据是离散的，不能覆盖所有的变化。导致学分类的 CNN 容易过拟合。而 GAN 生成数据相当于填补了分布中的窟窿的感觉，和直接使用原数据是不同的，下图 3-5 为

原始数据与使用 DCGAN 生成的数据对比图。



图 3-5 (a) 原始数据与 (b) 使用 DCGAN 生成的数据对比图

新的生成数据弥补了数据集量太少导致分类模型的可能导致的判断能力较弱等问题，原始数据与使用 DCGAN 生成的数据将共同组成新的数据集用于行人重识别网络的训练。数据集组成示意图如图 3-6 所示。




图 3-6 数据集组成示意图

3.2 特征提取

在行人重识别研究中，传统的方法一般是通过提取监控视频中的某些特性下的特征或者使用单一的滤波器来提取图像中的行人特征，而神经网络则是自动从数据中学习特征，因此，本章将讨论行人重识别研究中神经网络如何去学习特征和提取特征的。深度学习是通过多层非线性变换对高复杂性数据建立模型来学习数据中的特征，从而实现数据的抽象表示。深度学习也是通过组合大量简单的、非线性的模型将原始数据逐层转变成更高层次更

加抽象的表达，从而发现数据中的复杂结构和隐含信息。深度学习与传统人工算法相区别的是，特征提取的过程是通过模型对数据集进行训练学习得到的，而非通过人工的手段提取特征的。所以本文采用 ResNet-50 来实现特征提取，结合分类器模型建立基于深度学习的行人重识别系统。表 3-1 展示了 ResNet-50 的各层结构，下面将对该网络结构的各个组成部分进行详细探讨。

表 3-1 ResNet-50 各层结构

Layer name	Output size	50_Layer
conv1	112×112	7×7,64,stride 2
pool1	56×56	3×3 max pool,stride 2
conv2_x		$\begin{bmatrix} 1 \times 1 & 64 \\ 3 \times 3 & 64 \\ 1 \times 1 & 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 1 \times 1 & 128 \\ 3 \times 3 & 128 \\ 1 \times 1 & 512 \end{bmatrix} \times 4$
Conv4_x	14×14	$\begin{bmatrix} 1 \times 1 & 256 \\ 3 \times 3 & 256 \\ 1 \times 1 & 1024 \end{bmatrix} \times 6$
Conv5_x	7×7	$\begin{bmatrix} 1 \times 1 & 512 \\ 3 \times 3 & 512 \\ 1 \times 1 & 2048 \end{bmatrix} \times 3$
pool5	1×1	Average pool,fc,softmax

3.2.1 卷积层

卷积层是由若干个卷积单元组成的，通过反向传播算法，每一个卷积单元的传入的参数被一次次优化。通过卷积运算，我们可以提取数据集的重要特征。随着卷积层的层层深入，特征提取将会从一开始的低级特征提取到更加高级更加复杂的特征提取，对于整个卷积神经网络来说，卷积层的重要性不言而喻。卷积层的处理会使节点矩阵变得更深。如图 3-7 所示，图中显示了卷积层神经网络结构中最重要的一部分，这个部分被称之为过滤器（filter）或者内核（kernel）。




图 3-7 卷积层过滤器 (filter) 结构示意图

单位节点矩阵指的是一个长和宽都为 1，但是深度不限的节点矩阵。过滤器可以将当前层神经网络上的一个子节点矩阵转化为下一层神经网络上的一个单位节点矩阵。我们一般都是通过认为指定过滤器所处理的节点矩阵的长和宽，在一个卷积层中，这个节点矩阵的尺寸我们称之为过滤器的尺寸。正如图 3-7 所示，通过左侧小矩阵中的节点计算出右侧单位矩阵中节点的过程称之为过滤器的前向传播过程。为了直观的解释过滤器的前向传播过程，过滤器尺寸一般会选取 3×3 或 5×5 。在下面的篇幅中将给出一个具体的样例。在这个样例中将展示如何通过过滤器将一个 $2 \times 2 \times 3$ 的节点矩阵变化为一个 $1 \times 1 \times 5$ 的单位节点矩阵。一个过滤器的前向传播过程和全连接相似，它总共需要 $2 \times 2 \times 3 \times 5 + 5 = 65$ 个参数，其中最后的 +5 为偏置项参数的个数。假设使用 $w_{x,y,z}^i$ 来表示对于输入单位节点矩阵中的第 i 个节点，过滤器输入节点 (x,y,z) 的权重，使用 b^i 表示第 i 个输出节点对应的偏置项参数，那么单位矩阵中的第 i 个节点的取值 $g(i)$ 如式 3.1 所示：

$$g(i) = f(\sum_{x=1}^2 \sum_{y=1}^2 \sum_{z=1}^3 a_{x,y,z} \times w_{x,y,z}^i + b^i) \quad (3.1)$$

其中 $a_{x,y,z}$ 为过滤器中节点 (x,y,z) 的取值， f 为激活函数。

在卷积神经网络中，过滤器中的参数是共享的，也就是说每一个卷积层都使用相同的参数值。这样做的一个好处就是通过权值共享可以使得图像上的内容不受位置的影响。这样做的另一个好处就是可以缩减网络中的大量参数，简化网络的处理过程加快网络处理速度。图 3-8 给出了使用全 0 填充、步长为 2 的卷积层前向传播的计算流程。




图 3-8 卷积层前向传播过程样例图

如图 3-8 所示标注了过滤器上权重的值和偏置项的值。通过上文的计算公式可以得到每一个格子的具体取值。左上角格子取值的计算方法如式 3.2 所示。

$$\text{ReLU}(0 \times 1 + 0 \times (-1) + 0 \times 0 + 1 \times 2 + 1) = \text{ReLU}(3) = 3 \tag{3.2}$$

卷积层作为神经网络的一个重要组成部分，发挥着重要的作用。在充分了解卷积层的工作原理后，由于本论文的残差学习结构采用瓶颈结构（一个瓶颈结构由三个卷积层组成），如上表 3-1 所示，因此首端和末端采用 1×1 的卷积核用来削减和恢复维度，中间的卷积层采用 3×3 的卷积核。相比于由两层卷积核为 3×3 的卷积层组成的残差学习结构，该结构有效的减少了参数量和计算复杂度，同时也可以增加结构的数量，网络深度得以增加。

3.2.2 池化层

池化层（pooling layer）和卷积层之间是紧密相连的，一般卷积层之后会紧跟一个池化层。池化层的本质是一种形式的降采样，本身并不会改变三维矩阵的深度。池化层可以有效的缩减数据空间的大小，减小参数的运算量。最大池化层（max pooling）和平均池化层（average pooling）是常用的池化操作。最大池化层的基本操作是将输入的图像数据分成若干个矩形区域，将每个矩形区域的最大值进行输出，而平均池化层的基本操作是将输入的图像数据分成若干个矩形区域，将每个矩形区域的均值进行输出。池化层不仅可以加快计算速度而且可以防止过拟合。

与卷积层的过滤器类似，池化层的计算也是像卷积层一样通过移动过滤器来完成的。池化层的常用形式是通过 2×2 的卷积核每次间隔 2 个元素进行移动，框出一个 2×2 的区块，取出区块内的 4 个数取最大值或平均值。池化层的过滤器（卷积核）是需要人工进行设定的，我们需要人工设置过滤器的尺寸、移动的步长和填充方式等。卷积层的过滤器和池化层的过滤

器有相似的移动方式，但是区别在于我们在卷积层选用的过滤器是横跨整个深度的，而池化层所使用的过滤器只影响着一个深度上的节点。




图 3-9 3×3×2 节点矩阵、全 0 填充且步长为 2 的最大池化层前向传播过程示意图

如上表 3-1 所示，本论文所采用得神经网络结构共有两个池化层，分别是 pool1 和 pool5，pool1 选用的是最大池化，pool5 选用的是平均池化。由于一开始的图像像素较大，Pool1 选用的最大池化，可以减小卷积层参数误差所造成的估计均值的偏移，更多的保留纹理信息。经过多轮卷积之后，Pool5 中选用平均池化，可以减小领域大小受限造成的估计值方差增大，更多的保留图像的背景信息。

3.2.3 全连接层

全连接层（fully connected layers，FC）在整个卷积神经网络中起到“分类器”的作用。卷积神经网络结构中，在经历多个卷积层和池化层的作用后，一般会在之后连接一个或一个以上的全连接层。全连接层的主要作用是将学到的“分布式特征表示”映射到样本标记空间。全连接层的神经元与其上一层的所有神经元进行全连接，全连接层在整个卷积神经网络整合最具有区分性的信息，整个网络模型中最后一层的全连接层的输出一般会被输入到 softmax 层对特征进行分类。我们可以将卷积层和池化层看成自动图像特征提取的过程。在特征提取完成之后，仍然需要使用全连接层来完成分类任务。

在经过多轮卷积和池化操作之后，本文所用的模型将连接一个全连接层，目的是将采集到的特征映射到样本标记空间。

3.2.4 损失函数和激活函数

1、损失函数

损失函数（loss function）主要是用来定义神经网络模型的效果以及优化的目标。损失函数是将随机事件或其有关随机变量的取值映射为非负实数以表示该随机事件的“风险”或“损失”的函数。如果你的模型的真实值和预测值越靠近，那么你的损失函数就越小，损失函数描述了你的真实值和预测值不一致的程度。那么如何判断一个输出向量和期望的向量的接近程度，交叉熵（cross entropy）是分类问题中使用比较广的一种损失函数。它描述了两个概率分布之间的距离问题，是常用的评判方法之一。

交叉熵是一个信息论中的概念，它原本是用来估算平均编码长度的。给定两个概率分布 p 和 q ，通过 q 来表示 p 的交叉熵如式 3.3 所示：

$$H(p, q) = -\sum_x p(x) \log q(x) \quad (3.3)$$

交叉熵刻画的是两个概率分布之间的距离，然而神经网络的输出却不一定是一个概率分布。如何将神经网络前向传播得到的结果也变成概率分布，Softmax 回归就是一个非常常用的方法。图 3-10 展示了加上了 Softmax 回归的神经网络结构图




图 3-10 通过 Softmax 层将神经网络输出变成一个概率分布

假设原始的神经网络输出为 $y_1, y_2, \dots, y_n$ ，那么经过 Softmax 回归处理之后的输出如式 3.4 所示：

$$\text{softmax}(y)_i = y'_i = \frac{e^{y_i}}{\sum_{j=1}^n e^{y_j}} \quad (3.4)$$

从以上公式中可以看出，原始神经网络的输出被用作置信度来生成新的输出，而新的输出变成了一个概率分布。这个新的输出所代表的含义为一个样例为不同类别的概率分布是多大。这样就把神经网络的输出也变成了一个概率分布，然后通过交叉熵来计算预测的概率分布和真实答案的概率分布之间的距离。

从交叉熵的公式中可以看到交叉熵函数不是对称的（ $H(p, q) \neq H(q, p)$ ），它刻画的是通过

概率分布 q 来表达概率分布 p 的困难程度。因为正确答案是希望得到的结果，所以当交叉熵作为神经网络的损失函数时， p 代表的是正确答案， q 代表的是预测值。交叉熵刻画的是两个概率分布的距离，也就是说交叉熵值越小，两个概率分布越接近。

本文的损失函数选用的是 Triplet Loss，当我们的样本类别较少时，可以使用交叉熵来训练网络，但是当样本类别较大时，比如判断两个行人是否为同一个人，标签集较大，Triplet Loss 就比较合适，他可以帮助我们学习一种人脸嵌入，使得同一个人的人脸在嵌入空间中尽量接近，不同的人脸在空间中尽量远离。

2、激活函数

激活函数（Activation functions）对于人工神经网络模型去学习、理解非常复杂和非线性的函数来说具有十分重要的作用。它们将非线性特性引入到我们的网络中，如图 3-11，在神经元中，输入的 inputs 通过加权，求和后，还被用作了一个函数，这个函数就是激活函数。引入激活函数是为了增加神经网络模型的非线性。没有激活函数的每层都相当于矩阵相乘。




图 3-11 引入激活函数的模型示意图

如果神经网络没有激活函数，那么无论神经网络有多少层，每一层输出都是上层输入的线性函数，输出始终都是输入的线性组合。这种情况就是最原始的感知机。

正是因为激活函数，神经元被引入了非线性因素使得神经网络可以任意逼近任何非线性函数，这样神经网络就可以应用到很多非线性模型中。常用的激活函数有：ReLU 函数、sigmoid 函数、tanh 函数。

Sigmoid 函数：

Sigmoid 函数（被称为 S 型生长曲线）是一个在生物学中常见的 S 型函数。Sigmoid 函数因其单增以及反函数单增等性质常被用作神经网络的阈值函数，可以将变量映射到 0.1 之间，如式 3.5 所示：

$$f(x) = \frac{1}{1+e^{-x}} \quad (3.5)$$

函数图像如图 3-12 所示:




图 3-12 Sigmoid 函数

Tanh 函数

Tanh 是双曲函数中的一个, Tanh()为双曲正切。在数学中,双曲正切“Tanh”是由基本双曲函数双曲正弦和双曲余弦推导而来,如式 3.6 所示:

$$f(x) = \frac{1-e^{-2x}}{1+e^{-2x}} \quad (3.6)$$

函数图像如图 3-13 所示:




图 3-13 Tanh 函数

ReLU 函数

ReLU 激活函数（The Rectified Linear Unit），用于隐层神经元输出。如式 3.7 所示：

$$f(x)=\max(0,x) \quad (3.7)$$

函数图像如图 3-14 所示：




图 3-14 ReLU 函数

综合分析了以上三种常用的激活函数之后，ReLU 最为常用，也往往具备较好的性能。但是本文将采用 LeakyReLU，它作为 ReLU 的变种，ReLU 是将所有的负值都设为零，而 LeakyReLU 是给所有的负值赋予一个非零斜率。当提取特征时产生较多负值时，由于 ReLU 忽略了负值所携带的特征，直接将负值设为零，对特征提取结果往往会造成一定的影响，而 LeakyReLU 则是对 ReLU 的有效补充，相对而言具有较好的性能。

3.3 本章小结

本章主要介绍了训练集扩容所需的卷积生成对抗网络模型，然后探讨了卷积生成对抗网络进行数据生成的方式。然后，使用卷积生成网络对数据进行扩容训练。接着，对卷积神经网络中进行特征提取的基本组成单元如卷积层、池化层、全连接层等的运行机制和主要特点进行了详细的描述和分析，阐述了特征提取的流程和所需进行的步骤。

第四章 基于改进 ResNet-50 的行人重识别研究

随着对神经网络的深入研究，深度卷积神经网络的出现和使用为图像分类和识别带来了巨大的突破。随后人们不断增加神经网络的深度，试图打造出更加深层次的网络模型，达到最佳的训练效果。实验结果却证明随着网络深度的不断增加，其准确度就会随之达到饱和，然后出现断崖式下降的现象。由于深度残差网络对数据波动更加敏感，尽可能的去准确描述数据，因此在一定程度上解决了深度网络的退化问题。深度残差网络在行人重识别方面也具备着卓越的性能，本章对 ResNet-50 的基础模型进行相应的改进，并结合生成对抗网络所扩充的数据集，对行人重识别这一课题进行了深入的研究。

4.1 改进的 ResNet-50 网络

由于 ResNet-50 网络结构在分类任务中取得了很好的效果，行人检测重识别模型采用该网络结构对输入图片进行特征提取。该小节对 ResNet-50 进行整体性介绍。

深度卷积神经网络已经为图像分类带来了一系列突破。网络深度是至关重要的，在深度重要性的驱使下，人们不断的追求更深层的网络，传统意义上，深度神经网络的层数越深，得到的特征也就越丰富，在分类和识别任务中更加有优势。然而一个问题出现了，学习更好的网络并不像堆更多的层一样简单，传统的卷积网络在训练过程中，它的信息传递或多或少会有些许丢失和损耗，同时会出现“梯度消失/爆炸”现象。导致很深的网络无法训练。随着网络深度的增加，准确度就会饱和，然后就会迅速下降。出乎意料的是，这种退化往往是由过度拟合造成的，并且在适当的深度模型中加入更多的层会导致更高的训练错误。退化表明不是所有的系统都同样易于优化。

ResNet 在一定程度上有效的解决了这个问题，整个网络只需要集中注意力去处理输入、输出差别的那一部分，直接将输入信息从旁路传到输出端，使信息的完整性得到保障，大大改善了网络层数加深所带来的准确度饱和等问题。ResNet 的结构不仅可以大大提升模型的准确度，而且可以使神经网络得到快速训练，模型的准确率也有比较大的提升。ResNet 与其他网络的一个很大的区别在于有很多的旁路将输入直接连接到后面的层，这种结构也被称为 shortcut 或者 skip connections。同时 ResNet 的推广性非常好，甚至可以直接用到 InceptionNet 网络中。

残差模块：




图 4-1 残差模块

残差结构由两层组成，如式 4.1 所示：

$$F = W_2\sigma(W_1x)$$

(4.1)

其中， σ 表示非线性函数 ReLU， W_i 表示第 i 层加权值，经过第 i 个 ReLU 再加上原始输入，表达式如式 4.2 所示：

$$y = F(x,\{W_i\}) + x$$

(4.2)

这样的残差块组合起来一个 ResNet-50 网络，其结构包括 5 个卷积块，其中每个 block 包含有不同个数的残差单元，结构如图 4-2 所示：




图 4-2 ResNet-50 结构图

在图 4-1 中，ReLU 作为较常见的修正线性单元，在残差模块中得到了比较广泛的应用。本文将采用 LeakyReLU，ReLU 是将所有的负值都设为零，而 LeakyReLU 是给所有的负值赋

予一个非零斜率。当提取特征时产生较多负值时，由于 ReLU 忽略了负值所携带的特征，直接将负值设为零，对特征提取结果往往会造成一定的影响，而 LeakyReLU 则是对 ReLU 的有效补充，相对而言具有较好的性能。ReLU 激活函数为 $f(x)=\max(0,x)$ 。而 LeakyReLU 则是其变体 $f(x)=\max(0,x)+\text{negative_slope}\times\min(0,x)$ ，其中 negative_slope 是一个小的非零数，以数学的方式可以表示为如式 4.3 所示：

$$y_i = \begin{cases} x_i & \text{if } x_i \geq 0 \\ \frac{x_i}{a_i} & \text{if } x_i < 0 \end{cases} \quad (4.3)$$

其中， a_i 为 $(1, +\infty)$ 区间内的固定参数。

本文对基础模型的另外一个改进主要是选用 Triplet Loss 损失函数替代原有的损失函数，当我们的样本类别较少时，可以使用交叉熵来训练网络，但是当样本类别较大时，比如判断两个行人是否为同一个人，标签集较大，Triplet Loss 就比较合适，他可以帮助我们学习一种人脸嵌入，使得同一个人的人脸在嵌入空间中尽量接近，不同的人脸在空间中尽量远离。

Triplet Loss 可翻译为三元组损失，其中的三元及其相互间的关系如下图 4-3 所示。三元分别是 Anchor、Negative、Positive，通过 Triplet Loss 的学习使得 Positive 和 Anchor 之间的距离最小，而和 Negative 之间的距离最大，其中 Anchor 为训练数据集中随机选取的一个样本，Positive 和 Anchor 属于同一类的样本，而 Negative 则为和 Anchor 不同类的样本。




图 4-3 三元关系图

Triplet Loss 的目标函数如式 4.4 所示：

$$\sum_i^N \left[\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha \right]_+ \quad (4.4)$$

上式中的 $\|**\|$ 为欧式距离，所以 $\|f(x_i^a) - f(x_i^p)\|_2^2$ 表示的是 Positive 和 Anchor 之间的欧式距离度量， $\|f(x_i^a) - f(x_i^n)\|_2^2$ 表示的是 Negative 和 Anchor 之间的欧式距离度量。 α 是指 x_a 和 x_n 之间的距离和 x_a 和 x_p 之间的距离之间有一个最小的间隔。 $+$ 表示 $[]$ 内的值大于零的时候，取值为损失，小于零的时候，损失为零。

由于行人重识别的数据集中，标签量非常庞大，但是每个标签的图片数据量却很少，要想直接带入深度模型中进行训练，效果会相对较差。而先前像 PersonNet 这样的行人重识别的

深度学习网络往往会进行特殊设计以满足特定行人重识别数据集。这些网络模型与传统的用于分类任务的模型相比往往具有更小的滤波器尺寸并且大多去掉了池化层。这种方法在特定的数据集上是有效的，但是换一个数据集就无法发挥作用了。对于大型的网络模型。我们可以利用预训练的模型。普遍来说，利用 ImageNet 预训练的网络能达到更好的结果，因为它保留了一些好的特征。

4.2 距离度量方法

距离度量方法在行人重识别过程中起到了非常关键的作用，大量数据中判断是否是同一个人需要提取行人的特征进行比对。距离度量方法的优劣直接影响后续的特征比对，如果选用的距离度量方法无法使得不同行人特征间的距离大于同一行人的特征，那么就无法区分出不同的行人，直接影响到重识别的效果。有些具备良好性能的距离度量方法虽然看起来不错，但是添加了很多迭代和优化策略使得方法本身过于复杂，从而影响到发放本身的效率。因此下文列举了一些被广泛使用，简单而又相对性能较好的距离度量算法，并在后续实验中应用。

1、欧式距离（Euclidean Distance）

欧式距离是最容易直观理解的距离度量方法，也是一种常见的度量方式，是点和点之间坐标的均方根。通常情况下人们所说的距离，指的就是欧式距离。二维平面上点 $a(x_1, y_1)$ 和 $b(x_2, y_2)$ 间的欧式距离如式 4.5 所示：

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (4.5)$$

三维空间点 $a(x_1, y_1, z_1)$ 与 $b(x_2, y_2, z_2)$ 间的欧式距离如式 4.6 所示：

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2} \quad (4.6)$$

N 维空间点 $a(x_{11}, x_{12} \cdots x_{1n})$ 与 $b(x_{21}, x_{22} \cdots x_{2n})$ 间的欧式距离（两个 n 维向量）如式 4.7 所示：

$$d_{12} = \sqrt{\sum_{k=1}^n (x_{1k} - x_{2k})^2} \quad (4.7)$$

2、余弦距离

余弦距离，也叫余弦相似度，是用向量空间中两个向量夹角的余弦值作为衡量两个个体间差异的大小的度量。假设对应两个输入的特征输出分别记做 $f_1 = (x_1, x_2, \dots, x_n)$ ， $f_2 = (y_1, y_2, \dots, y_n)$ ，则夹角余弦距离定义为如式 4.8 所示：

$$\cos(x, y) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}} \quad (4.8)$$

3、马氏距离

有 M 个样本向量 $x_1 \sim x_m$ ，协方差矩阵记为 S，均值记为向量 μ ，则其中样本向量 x 到 u 的

马氏距离表示为如式 4.9 所示：

$$D(x)=\sqrt{(x-\mu)^TS^{-1}(x-\mu)} \tag{4.9}$$

其中，向量 x_i 与 X_j 之间的马氏距离定义为如式 4.10 所示：

$$D(x_i,x_j)=\sqrt{(x_i-x_j)^TS^{-1}(x_i-x_j)} \tag{4.10}$$

若协方差矩阵是单位矩阵（各个样本向量之间独立同分布），则公式如式 4.1 所示：

$$D(x_i,x_j)=\sqrt{(x_i-x_j)^T(x_i-x_j)} \tag{4.11}$$

也就是欧式距离了。若协方差矩阵是对角矩阵，公式变成了标准化欧式距离。

4.3 基于改进 ResNet-50 网络的行人重识别训练与测试

4.3.1 训练阶段

本文通过 PyTorch 来训练深度神经网络模型，所使用的 GPU 显存为 4.5G。训练参数如表 4-2 所示。其中“batch size”表示每次迭代网络训练图片的数量；“droprate”表示每次训练随机丢失隐含层的节点数；“epoch”表示使用训练集中的全部样本训练一次；“stride”表示训练步长；“lr”表示学习率；“adaptiveAvgPool2d”是 PyTorch 含有的一种池化层，表示自适应平均池化；表 4-1 为训练参数的设置.

表 4-1 训练参数设置

参数名称	值
batch size	30
droprate	0.5
epoch	70
stride	2
lr	0.05
adaptiveAvgPool2d	(1, 1)

4.3.2 测试阶段

测试行人重识别网络的主要思路是先分别对查询集和候选集特征提取，然后将查询集和候选集的特征进行距离度量，找出距离最小的图像，即默认大概率为同一行人。具体流程如图 4-4 所示：




图 4-4 行人重识别基本流程

根据上文的描述，测试阶段分为两个网络来进行测试。

对于查询集里的图片，只进行特征提取部分和行人重识别部分。载入已训练好的模型，通过简单的前向传播来抽取特征，我们会得到 `feat` 层输出的特征。我们将该特征用来和候选集中检测出的行人特征进行相似性匹配。如图 4-5 所示：




图 4-5 测试网络结构

我们也只对候选集中的图片进行特征提取部分和行人重识别部分，最终得到 `feat` 层所输出的特征。

距离度量：本文采用余弦夹角距离来对查询集（query）和候选集（gallery）中的图片的特征进行距离度量。余弦距离，也称余弦相似度，是用向量空间中两个向量夹角的余弦值作为衡量两个个体间差异的大小的度量。假设对应两个输入的特征输出分别记做 $f_1 = (x_1, x_2, \dots, x_n)$ ， $f_2 = (y_1, y_2, \dots, y_n)$ ，则夹角余弦距离定义为如式 4.12 所示：

$$\cos(x, y) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}} \tag{4.12}$$

4.4 标准数据集与性能评价标准

4.4.1 行人重识别标准数据集

本文用于网络训练的数据集为 Market-1501，Market-1501 数据集是在清华大学校园中采集，夏天拍摄的，在 2015 年构建并公开。它包括由 6 个摄像头（其中 5 个高清摄像头和一个低清摄像头）拍摄到的 1501 个行人，32668 个检测到的行人矩形框。每个行人至少由 2 个摄

摄像头捕获到, 并且在一个摄像头中可能具有多张图像。训练集由 751 人, 包含 12936 张图像, 平均每个人有 17.2 张训练数据; 测试集有 750 人, 包含 19732 张图像, 平均每个人有 26.3 张测试数据。3368 张查询图像的行人检测矩形框是人工绘制的, 而 gallery 中的行人检测矩形框则是使用 DPM 检测器检测得到的。该数据集提供的固定数量的训练集和测试集均可以在 single-shot 或 multi-shot 测试设置下使用。本文的主要工作是 single-shot 的行人再识别, 后续的实验主要是在标准数据集 Market-1501 的基础上进行实验。Market-1501 的具体样例如图 4-6 所示, 样例分为两行, 分别来自不同的摄像机视角, 每一列表示同一个人, 可以看出其光照、视角以及背景的变化。



图 4-6 多监控角度下的数据集 Market-1501 示例

4.4.2 性能评价指标

在行人重识别中, 我们将用于检索的图像组成的集合称为 query, 用于搜索的图像集合称为 gallery。从 query 中选择一个图像作为检索图像 x_i , 在 gallery 中检索出与给定的检索图像 x_i 最相似的图像 x_{result} , 由于受到光照、形变、视角、遮挡以及嘈杂的背景等因素的影响, 使得行人重识别的准确率较低, 返回单张图像难以有很好的准确率, 因此, 本论文中返回结果是一个图像列表, 图像列表按照与检索图像 x_i 的相似度由高到低排序输出 ($x_{result1} > x_{result2} > \dots > x_{resultN}$), 并由此可通过判断搜索结果中最靠前 (置信度最高) 的 n 张图有正确结果的概率来评价行人重识别的准确率, 也就是 rank- n 。

Rank-1 表示返回的图像列表中排在第一位的图像和对应检索图像 x_i 正确匹配的比例。

Rank-5 表示返回的图像列表中排在前 5 个图像中存在和对应检索图像 x_i 正确匹配的比例。**Rank-10** 表示返回的图像列表中排在前 10 个图像中存在和对应检索图像 x_i 正确匹配的比例。例如，我们使用 50 张不同的图像作为检索图像 x_i ，其对应返回的 100 张图像列表中，排在第一位的图像正确匹配的数量是 30，则 **Rank-1** 的值为 60%。由于返回的第一张图像是相似度最高的，所以第一个图像和对应的检索图像 x_i 成功匹配的比例 **Rank-1** 也被作为一个重要的评价标准。

mAP(mean average precision): **mAP** 也是图像检索问题的一个重要评价指标，它反应了算法在整个测试集上的平均性能。对于单个行人图像的查询，定义 **AP** 为如式 4.13 所示：

$$AP = (\frac{tr_1}{loc_1} + \frac{tr_2}{loc_2} + \dots \frac{tr_n}{loc_n})/n \quad (4.13)$$

其中表示返回的结果中第 i 个与查询行人匹配的图像， loc_i 表示第 i 个匹配结果的排序位置， n 表示候选集中所有与查询图像相匹配的图像个数，一般情况下 $n < 20$ 。

mAP 则是表示了测试样本整体的平均准确率如式 4.14 所示：

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_i \quad (4.14)$$

4.5 实验结果及分析

1、训练结果反馈




图 4-7 loss 曲线图

图 4-7 为模型训练过程中的 loss 反馈结果曲线，横坐标表示 epoch（使用训练集中的全

部样本训练一次) 的次数, 纵坐标表示 loss。蓝线表示训练阶段的 loss 曲线, 红线表示验证阶段的 loss 曲线。可以看到, 在初次完成一轮迭代后, 训练阶段的 loss 值为 0.143, 随着迭代次数不断增加, 训练阶段的 loss 值呈指数方式下降, 并最终趋于稳定, 当迭代次数 69 次时 loss 值为 0.2, 主要是由于随着迭代的次数增加, 提取的特征更为丰富。同时, 在完成一轮迭代后验证阶段的 loss 值为 0.098, 随着迭代次数的不断增加, 验证阶段的 loss 值呈现震荡方式下降, 当迭代次数达到 69 次的时候, 验证阶段的 loss 值将为 0.01。同时在迭代的过程中验证阶段的 loss 均值小于训练阶段的 loss 均值, 主要是由于验证阶段所使用的模型是经过本次训练得到的结果模型的泛化能力相对较好。




图 4-8 top1err 曲线图

图 4-8 为模型训练过程中的 top1 反馈结果曲线, 横坐标表示 epoch (使用训练集中的全部样本训练一次) 的次数, 纵坐标表示 top1 的错误率。蓝线表示训练阶段的 top1err 曲线, 红线表示验证阶段的 top1err 曲线。可以看到, 在初次完成一轮迭代后, 训练阶段的 loss 值为 0.85, 随着迭代次数不断增加, 训练阶段的错误率呈指数方式下降, 并最终趋于稳定, 当迭代次数 69 次时错误率为 0.2, 主要是由于随着迭代的次数增加, 提取的特征更为丰富。同时, 在完成一轮迭代后验证阶段的 loss 值为 0.69, 随着迭代次数的不断增加, 验证阶段的错误率呈现震荡方式下降, 当迭代次数达到 69 次的时候, 验证阶段的错误率降为 0.09。同时在迭代的过程中验证阶段的错误率均值小于训练阶段的错误率均值, 主要是由于验证阶段所使用的模型是经过本次训练得到的结果模型的泛化能力相对较好。

2、与原始模型的性能对比

表 4-2 基于 Market-1501 数据集的性能对比

基于 Market-1501 数据集的性能对比		
Model	Rank-1(%)	mAP(%)
ResNet-50	72.54	46.00
改进的 ResNet-50	88.15	70.57

由表 4-2 可知，原始模型 ResNet-50 的返回的图像列表中排在第一位的图像和对应检索图像 x_i 正确匹配的概率为 72.54%，测试样本整体的平均准确率为 46%。改进的 ResNet-50 的返回的图像列表中排在第一位的图像和对应检索图像 x_i 正确匹配的概率为 88.15%，测试样本整体的平均准确率为 70.57%。结果表明，和原始的 ResNet-50 模型相比，改进的 ResNet-50 使得第一位图像的的正确匹配率提高了 21%，整体的平均准确率提高了 53%。本文所改进的模型无论是 mAP 或是 rank-1 的匹配率均得到了大幅度的提升。充分证明了本文方法的有效性。

3、实验结果图示




图 4-9 实验结果

实验结果如图 4-9 所示，标签 query 表示从查询集中随机抽取的样本图像，标签 1-10 表示根据相似度排序匹配的结果。绿色标签的图像代表行人重识别匹配正确，红色标签的图像

代表识别失败。图示结果表明匹配结果具有较高的识别率。同时，导致匹配失败主要原因是和原图像的衣服和外貌具有较高的相似度。

第五章 行人重识别系统的设计与实现

为了更加方便并且直观的显示出重识别效果，找到多个摄像头中的同一个人，本章结合了行人重识别网络的训练和识别结果，设计并实现了行人重识别系统。该系统可以调用已训练的神经网络模型对训练集中的任意行人进行识别，能够得到较好的识别效果，并能够实时评估当前模型的性能指标。

5.1 需求分析

跨监控摄像头的行人重识别，往往都是通过人工肉眼去比对、鉴别的。对于我们个人来说，视频监控对我们的个人安全和利益也起到了重要的作用。但面对海量增长的监控视频，数据量也在越来越大，而我们目前大多还都是通过人工的方式对视频进行监察和比对，但是人工的方式需要消耗大量的人力、物力成本和大量的时间。为了使监控视频的分析和使用更加高效和智能化，本人设计并实现了一个基于深度学习的行人检测重识别系统，以帮助人们更好的对视频中的行人进行监控和跟踪，不仅提高了视频监控效率，也降低了监控和维护成本。

由于视频信息是由一幅幅的图像组成，对一帧帧图像进行识别和处理操作其实就是在处理视频图像。随着大数据时代和视频监控网络的不断扩大和发展，数据量越来越大，传统的人工调用监控查询行人信息的方式不仅浪费大量人力而且查询结果也未必精确，不符合现代社会的需求。借助计算机并结合优秀的计算机算法往往可以使行人的检测和重识别更加高效和智能化，因此，安全高效的行人检测和重识别系统具有很高的应用前景。

在研究目前的状况后，发现该系统需要满足以下几个要求：

(1) 将行人查询集中的行人图像输入到已经训练好的行人重识别模型后能够自动反馈中跨监控视频中的 10 张同一行人的图像，若是查询集给出的图像不是完整的行人或者是同一摄像头下的同一行人，则返回识别错误结果，需重新给出查询图像。

(2) 对于已经训练好的学习模型，可以及时对学习模型进行评估，给出相应的评估结果。

(3) 实时性，在输入测试图像后，能及时反馈识别结果。

5.2 功能分析

行人图像检测功能：能正确识别输入图像为完整的行人图像，未能识别的图像，不予识

别，提示重新选取需识别的图像。

行人重识别功能：正确识别并反馈给出的行人图像在其它监控摄像头下出现过的同一行人图像，若反馈错误结果，则图像的数字标签显示红色。

神经网络训练功能：在设定一定的参数后，能够自动训练神经网络获得最佳的行人重识别模型。

模型评估功能：能及时对已训练模型进行评估，并显示评估结果。

关闭功能：系统运行结束，若要关闭程序，点击关闭，则退出整个系统。

5.3 系统的设计与实现

本系统结合了 5.1 的需求分析，并在 PyTorch 开源框架的基础上使用了 PYTHON 语言实现该系统。该系统可分为两个模块，分别是神经网络训练模块和行人重识别与模型评估模块。




图 5-1 系统运行流程图

系统的运行流程图如上图 5-1 所示，当我们像系统中输入一张查询图片时，系统会调用已训练的神经网络模型进行图片的特征提取，并对候选集进行特征提取，然后将候选集

中的特征与查询图片的特征进行比较, 如果匹配成功, 则输出 10 张与查询集匹配度最高的 10 张图片, 如果识别失败, 则提示该类型图片未经过训练。我们也会对已训练神经网络模型进行模型评估, 并输出评估结果, 最后结束所有流程。

5.3.1 神经网络训练

本模块主要负责神经网络训练, 由于预训练网络往往已经具备了一定的特征学习能力, 我们需要事先选定预训练网络, 并给定数据集。然后将所有参数初始化为零, 在每一轮迭代中, 随机选取部分参数进行训练, 首先进行前向传播获取训练值, 然后将训练值与标签值进行评估, 然后将损失进行优化通过反向传播更新度量, 完成一轮训练。反向传播的优化值将作为新一轮训练的初始参数, 参与新一轮训练, 达到预设训练次数后, 神经网络训练立即结束。神经网络训练具体流程的展示如图 5-2 所示:




图 5-2 神经网络训练流程图

打开网络训练界面需要用户填写一些参数信息, 如图 5-3 所示。首先需要用户输入模型训练所需的数据集, 其次, 由于本次实验需要使用 GPU 进行辅助计算, 需要输入 GPU 的 ID, 然后给训练的模型指定一个名称, 用于标识已训练好的模型。最后, 选取 batchsize, 用于指定每次训练随机选取的数据的数量。在填完所有训练所需参数后, 就可以开始进行训练。




图 5-3 神经网络训练界面

5.3.2 行人重识别模块与模型评估

1.行人重识别模块

本模块主要负责对输入的行人图片在数据集中进行重新识别，并获得匹配度高的图片。该模块首先调用系统 4.3 节已训练完备的学习模型对输入的图片进行特征提取，然后与候选集中图片的特征进行余弦距离匹配比对得到两张图片的相似度，最终得到和该图片中行人匹配度最高的 10 张图片并进行页面展示。该行人重识别模块的具体流程如图 5-4 所示：




图 5-4 行人重识别流程图

本人做了一个简单的 B/S 图形用户界面，可以更加直观的调用项目中的各个接口并显示效果。行人重识别输入框如图 5-5 所示。




图 5-5 行人重识别输入界面

当从查询集中挑选一张图像作为查询图像输入到系统中，系统将会载入已训练完备的模型来抽取每张图片的视觉特征,载入模型的结构,然后载入 weight。查询库中查询图像(query)和候选集(gallery)中的图像都通过已训练完备的模型进行前向传播来抽取特征。当我们抽取了每张图片的特征之后，我们需要用已抽取的特征对查询图像和候选集进行匹配，然后根据距离匹配结构对候选集中的图像进行相似度排序，将得分结果最高的前 10 张图进行系统输出展示。但是并非所有有关行人的图像都可以得到有效识别并输出最终结果图像。如果输入的查询图片不是完整的行人，而只是包含一些人的部件或者同一摄像头下的相同的人，我们不予检索这一类图像。如若出现这一类图像，系统将直接显示识别失败并返回结束查询。行人重识别效果如图 5-6 所示。




图 5-6 行人重识别效果图

2、模型评估

为了能够直观的对该行人重识别系统进行评估，判断该行人重识别系统是否具备高效性

南京邮电大学硕士研究生学位论文 第五章 行人重识别系统的设计与实现

和可行性，该系统设计出了模型评估模块，可对已训练好的模型进行高效的评估，从而判断该模型是否具备可用性，图 5-7 为模型评估模块具体流程的展示。




图 5-7 模型评估模块流程图

调用模型评估模块将会返回一行评估参数，用于评估现有的已训练模型识别效率，方便我们对行人重识别系统性能进行直观的认识。模型评估模块效果图如图 5-8 所示：




图 5-8 模型评估模块效果图

5.4 本章小结

本章首先对系统进行了需求分析，在初步拟定整个系统所需的全部功能后，将前两章研究的方法结合起来，实现一个具有简单图形界面的行人检测重识别系统，并根据所输入的查询

图片从训练模型中自动匹配其他监控摄像头中出现的该行人图片信息。该系统不仅可以识别多个背景下的行人还可以对学习模型进行评估，并输出评估结果。具有较高的实用性。

第六章 总结与展望

6.1 论文总结

现代社会正在迅猛发展，社会公共安全也得到了人们的重点关注。医院、社区、校园、地铁站、火车站等大型公共场合都正在逐步大范围多角度的安装监控摄像头，形成大型分布式监控网络。视频监控对我们的个人安全和利益也起到了重要的作用。但面对海量增长的监控视频，数据量也在越来越大，我们面临着怎样使监控视频的分析和使用更加高效和智能化的问题。

计算机技术在不断革新，计算机的处理能力和计算能力也发生着突飞猛进的变化，计算机视觉和图像处理技术也在迅猛发展，我们可以利用计算机强大的运算能力和图像处理技术，对监控系统进行智能化升级，实时、自动化的监控和处理数据，推动监控系统的智能化进程。本文通过讨论如何更加高效的对视频监控网络中的行人进行重识别从而对监控视频进行有效的监管和分析。近年来随着深度学习的流行和不断发展，其也在行人重识别领域发挥着越来越重要的作用。

本文针对行人检测系统进行分析研究，提出了基于深度学习的行人检测重识别技术方案。不仅通过生成对抗网络完成对原始数据集的扩充，同时对深度残差网络基础模型进行了改进，使行人的检测和重识别更加高效和智能化。本文主要研究工作如下：

（1）总结研究了当前出现的一些行人检测及行人重识别的算法和深度神经网络的结构和原理，并且进行了研究和分析。

（2）选用深度残差网络（ResNet）作为实验的基础模型，并在此基础上进行了改进，对行人进行特征提取和分析，有效地提高了特定行人识别率。

（3）对数据集进行有效的扩容，由于行人数据集看似庞大，然而当细化到特定行人，单个类的样本数偏少。我们通过生成对抗网络对原始数据集进行扩充，与直接使用原始数据集不同，扩容增加了单个标签的样本量，从而更加有利于特征的提取。

（4）设计并实现了基于深度学习的行人检测重识别系统，通过简单的待查询行人图像的输入，可直观的反馈出行人重识别结果。

6.2 研究展望

虽然本文的方法对行人重识别的识别精度提升有所贡献，但是依然无法满足实际场景中复杂的需求，离行人重识别的实际应用依然有很大的差距，行人重识别还有相当大的进步空间。在未来的研究中，有以下几点值得深入研究和探索。

- (1) 本文所使用的方法虽然使识别率有所提高，但是对于低分辨率和部分遮挡的情况下的图片的识别和处理，仍需进一步的努力。
- (2) 训练卷积神经网络的时间较长，对设备的依赖度也很高，未来可以进行更多合理的尝试并提出新的网络模型来解决训练时间较长和降低对设备的依赖度。
- (3) 行人重识别方面的数据集依然很少，因此建立更多丰富而又全面的数据集是非常重要的。

参考文献

- [1] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. Journal of Physiology, 1962, 160(1):106-154.
- [2] Douglas Scott Bush, MariaJesus Cornejo, ChunNong Huang, et al. Ca²⁺-Stimulated Secretion of α -Amylase During Development in Barley Aleurone Protoplasts[J]. Plant Physiology, 1986, 82(2):566-574.
- [3] Wang X. Intelligent multi-camera video surveillance: A review[M]. 2013.
- [4] Zajdel W, Zivkovic Z, Krose B J A. Keeping Track of Humans: Have I Seen This Person Before?[C]. IEEE International Conference on Robotics & Automation. 2006.
- [5] Gheissari N, Sebastian T B, Hartley R. Person Reidentification Using Spatiotemporal Appearance[C]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2006.
- [6] Bazzani L, Cristani M, Perina A, et al. Multiple-Shot Person Re-identification by HPE Signature[C]. International Conference on Pattern Recognition. 2010.
- [7] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C]. Computer Vision & Pattern Recognition. 2010.
- [8] Smirnov E A, Timoshenko D M, Andrianov S N. Comparison of Regularization Methods for ImageNet Classification with Deep Convolutional Neural Networks [J]. Aasri Procedia, 2014, 6(1):89-94.
- [9] Yi D, Lei Z, Liao S, et al. Deep Metric Learning for Person Re-identification[C]. International Conference on Pattern Recognition. 2014.
- [10] Wei L, Rui Z, Tong X, et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C]. Computer Vision & Pattern Recognition. 2014.
- [11] Jane Bromley, Isabelle Guyon, Yann Lecun, et al. Signature Verification using a "Siamese" Time Delay Neural Network[J]. International Journal of Pattern Recognition & Artificial Intelligence, 1993, 7(04):669-688.
- [12] Xu Y, Ma B, Rui H, et al. Person Search in a Scene by Jointly Modeling People Commonness and Person Uniqueness[J]. 2014.
- [13] Schroff F , Kalenichenko D , Philbin J . [IEEE 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Boston, MA, USA (2015.6.7-2015.6.12)] 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - FaceNet: A unified embedding for face recognition and clustering[J]. 2015:815-823.
- [14] Taigman Y , Yang M , Ranzato M , et al. DeepFace: Closing the Gap to Human-Level Performance in Face Verification[C]. Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2014.
- [15] Baek J Y , Chelu I V , Iordache L , et al. Scene Understanding Networks for Autonomous Driving based on Around View Monitoring System[J]. 2018.
- [16] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. 2015.
- [17] Redmon J , Farhadi A . [IEEE 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Honolulu, HI (2017.7.21-2017.7.26)] 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - YOLO9000: Better, Faster, Stronger[J]. 2017:6517-6525.
- [18] Lecun Y L , Bottou L , Bengio Y , et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [19] Ballester P, Araujo R M. On the performance of GoogLeNet and AlexNet applied to sketches[C]. Thirtieth

- Aaai Conference on Artificial Intelligence. 2016.
- [20] Sermanet P, Eigen D, Zhang X, et al. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks[J]. Eprint Arxiv, 2013.
- [21] Simonyan K , Zisserman A . Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, 2014.
- [22] He K , Zhang X , Ren S , et al. Deep Residual Learning for Image Recognition[J]. 2015.
- [23] Yu H X, Wu A, Zheng W S. Cross-view asymmetric metric learning for unsupervised person re-identification[C]. IEEE International Conference on Computer Vision. 2017.
- [24] LECUN, Yann, et al. Gradient-based learning applied to document recognition[C]. Proceedings of the IEEE, 1998, 86.11: 2278-2324.
- [25] Chung D, Tahboub K, Delp E J. A two stream siamese convolutional neural network for person re-identification[C]. The IEEE international conference on computer vision (ICCV). 2017.
- [26] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. IEEE Conference on Computer Vision & Pattern Recognition. 2016.
- [27] Michalski, Ryszard S., Jaime G. Carbonell, and Tom M. Mitchell, eds. Machine learning: An artificial intelligence approach[C]. Springer Science & Business Media, 2013.
- [28] Gheissari N, Sebastian T B, Hartley R. Person Reidentification Using Spatiotemporal Appearance[C]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2006: 1528-1535.
- [29] Dai A, Goodfellow I, Fedus L. MaskGAN: Better Text Generation via Filling in the _[J]. 2018.
- [30] Shen W, Liu R. Learning residual images for face attribute manipulation[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 1225-1233.
- [31] Walk S, Majer N, Schindler K, et al. New features and insights for pedestrian detection[C]. Computer vision and pattern recognition (CVPR), 2010 IEEE conference on. IEEE, 2010: 1030-1037.
- [32] FARENZENA, Michela, et al. Person re-identification by symmetry-driven accumulation of local features[C]. In: 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE, 2010. p. 2360-2367.
- [33] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]. Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on. IEEE, 2001, 1: I-I.
- [34] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 32(9): 1627-1645.
- [35] Dollár P, Rabaud V, Cottrell G, et al. Behavior recognition via sparse spatio-temporal features[C]. 2005 IEEE International Workshop on Visual Surveillance and Performance Evaluation of Tracking and Surveillance. IEEE, 2005: 65-72.
- [36] Yi D, Lei Z, Liao S, et al. Deep metric learning for person re-identification[C]. Pattern Recognition (ICPR), 2014 22nd International Conference on. IEEE, 2014: 34-39.
- [37] Yu C N J, Joachims T. Learning structural SVMs with latent variables[C]. Proceedings of the 26th Annual International Conference on Machine Learning. ACM, 2009: 1169-1176.
- [38] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[J]. arXiv preprint, 2017, 1(6).
- [39] Liu Z, Luo P, Wang X, et al. Deep learning face attributes in the wild[C]. Proceedings of the IEEE International Conference on Computer Vision. 2015: 3730-3738.
- [40] Wojek C , Walk S , Schiele B . Multi-cue onboard pedestrian detection[C]. Computer Vision and Pattern Recognition, 2009.CVPR 2009. IEEE Conference on. IEEE,2009:794-801.
- [41] David Gerónimo, Antonio M. López, Ponsa D , et al. Haar Wavelets and Edge Orientation Histograms for On-Board Pedestrian Detection[C]. Pattern Recognition and Image Analysis, Third Iberian Conference, IbPRIA 2007, Girona, Spain, June 6-8, 2007, Proceedings, Part I. DBLP, 2007.

- [42] 王斌. 基于深度学习的行人检测[D]. 北京交通大学, 2015.
- [43] Ning H, Cao J, Lin S. Scale Space Histogram of Oriented Gradients for Human Detection[C]. International Symposium on Information Science & Engineering. 2008.
- [44] Tuzel O, Porikli F, Meer P. Human detection via classification on riemannian manifolds[C]. Computer Vision and Pattern Recognition, 2007. CVPR'07. IEEE Conference on. IEEE, 2007: 1-8.
- [45] Hermans A, Beyer L, Leibe B. In Defense of the Triplet Loss for Person Re-Identification[J]. 2017.
- [46] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[J]. arXiv preprint arXiv:1701.07717, 2017, 3.
- [47] Wu J, Rehg J M. CENTRIST: A visual descriptor for scene categorization[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 33(8): 1489-1501.
- [48] Ouyang W, Wang X. Joint deep learning for pedestrian detection[C]. Proceedings of the IEEE International Conference on Computer Vision. 2013: 2056-2063.
- [49] Angelova A, Krizhevsky A, Vanhoucke V, et al. Real-Time Pedestrian Detection with Deep Network Cascades[C]. BMVC. 2015, 2: 4.
- [50] Zheng L, Shen L, Tian L, et al. Person re-identification meets image search[J]. arXiv preprint arXiv:1502.02171, 2015.
- [51] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3908-3916.
- [52] 焦旭辉. 基于深度学习的行人再识别技术研究[D]. 2017.
- [53] Xing E P, Jordan M I, Russell S J, et al. Distance metric learning with application to clustering with side-information[C]. Advances in neural information processing systems. 2003: 521-528.
- [54] Zheng Z, Zheng L, Yang Y. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro[J]. 2017.
- [55] 王坤峰, 苟超, 段艳杰, 等. 生成式对抗网络 GAN 的研究进展与展望[J]. 自动化学报, 2017, 43(3): 321-332.
- [56] Ojala T, Pietikainen M, Maenpaa T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns[J]. IEEE Transactions on pattern analysis and machine intelligence, 2002, 24(7): 971-987.
- [57] Hirzer M, Beleznai C, Kostinger M, et al. Dense appearance modeling and efficient learning of camera transitions for person re-identification[C]. Image Processing (ICIP), 2012 19th IEEE International Conference on. IEEE, 2012: 1617-1620.

附录 1 攻读硕士学位期间撰写的论文

(1) Dandan Lu, Ningning Zhou , Guofang Huang. Research on an Improved Visual Background Extraction Algorithm[J]//IEEE 2017 12th International Conference on Intelligent Systems and Knowledge Engineering (ISKE) - Nanjing, China (2017.11.24-2017.11.26)] (收录号: 20182405295846)

附录 2 攻读硕士学位期间参加的科研项目

- (1) 开瑞运软件开发公司：面向服装的人体数据视觉测量系统（2016 外 65）；
- (2) 智能电网保护和运行控制国家重点实验室开放课题，基于深度学习的变电设备图像跟踪、图像识别理论及应用研究（2016No.09）；
- (3) 智能电网保护和运行控制国家重点实验室开放课题：变电站设备状态大数据定性分析与质量测度理论及方法研究（2016No.10）。

致谢

寒来暑往，秋收冬藏，弹指一挥间，又是一年，转眼间，三年的研究生生活即将结束，马上就要背上行囊告别保护了我七年的象牙塔---南京邮电大学。犹记当年，青涩的自己带着无限的期待来到这个一直向往的大学，母校让我的生命里充满了理想和信念。厚德、弘毅、求是、笃行的南京邮电大学校训将成为我一生的座右铭。在这三年的研究生生涯里我收获满满，不仅丰富了自己的知识增长了见识，同时也收获了导师以及同学们的无私关怀和帮助。在此，我想向他们表达我真挚的感谢和祝福。

首先，我要特别的感谢我的导师周宁宁。在研究生阶段课题研究的过程中我遇到了无数的困难和障碍，每每都是您为我拨开迷雾指引前进的方向，让我的课题研究内容日益丰满。您不仅授我知识给我榜样还给我指引前进的方向。谆谆教诲，萦绕耳畔，不敢相忘。谢谢您，谢谢您给了我一双有力的翅膀，让我在未来能过飞的更高、更远。

洪龙教授严谨的治学态度，豁达的人生态度是我们学习的榜样。成卫青教授待人和蔼真诚，以精益求精的工作态度在学术上不断探索。顾磊教授待人诚挚，学识广阔，很多方面都值得我们学习，肖学中教授学术思维敏捷，知识渊博，总能给人及时的点拨。感谢以上四位老师，在我三年的学习生涯中提供的诸多帮助。

其次，我还要感谢我的同门以及师兄师姐师弟师妹们。在生活上大家相互关心，相互帮助，学习上相互学习，相互监督。当课题研究内容出现瓶颈时，他们总能从不同的方面帮我分析，开阔了我的研究思路。正因为有他们，让我的研究生生活丰富而又充满活力。

同时，我还要感谢我的父母以及亲友们，感谢你们对我多年不求回报的付出，是你们对我的学业鼎力相助，当我浮躁时是你们给予我支持和鼓励，正因为有你们作为坚实的后盾，我才能无所畏惧、勇往直前。

最后，我要感谢各位答辩委员会的老师从百忙之中抽出宝贵的时间来审阅我的论文，给我的研究课题提出了宝贵的意见，进一步完善了我的课题内容。