

电子科技大学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

硕士学位论文

MASTER THESIS



论文题目 基于深度学习的行人重识别技术研究 with 实现

学科专业 软件工程

学 号 201621220155

作者姓名 张琴

指导教师 陈佳 副教授

分类号

密级

UDC ^{注1}

学 位 论 文

基于深度学习的行人重识别技术研究 with 实现

(题名和副题名)

张琴

(作者姓名)

指导教师

陈佳

副教授

电子科技大学

成都

(姓名、职称、单位名称)

申请学位级别

硕士

学科专业

软件工程

提交论文日期

2019.03.25

论文答辩日期

2019.05.20

学位授予单位和日期

电子科技大学

2019 年 6 月

答辩委员会主席

评阅人

注 1：注明《国际十进分类法 UDC》的类号。

Research and Implementation of Person Re-Identification Based on Deep Learning

A Master Thesis Submitted to

University of Electronic Science and Technology of China

Discipline: **Software Engineering**

Author: **Qin Zhang**

Supervisor: **Associate Prof. Jia Chen**

School: **School of Information and Software Engineering**

摘 要

由于视频监控系统的普及以及监控视频的数量与日俱增,单纯依靠人力资源在跨摄像头监控视频中找到特定的行人变得越来越困难,而行人重识别技术成为了解决这一难题的有效方法,行人重识别技术指通过将出现在多个不同摄像头下的同一行人进行辨别,判断是否为同一行人。基于上述问题,本论文完成的工作内容主要包含以下几个方面:

1.论文首先提出了一种基于骨骼关键点进行图像分割的算法 ISSE,可以通过使用 OpenPose 工具把图像中的行人骨骼提取出来,然后根据行人身上的 18 个骨骼关键点对行人图像进行分割,分割成互相重复的三部分图像使行人图像特征被更好地提取,解决了由于低分辨率图像导致特征提取效果不佳的问题。

2.改进了原 Resnet50 卷积神经网络的输入层,将原 Resnet50 残差网络的输入层维度由 224×224 改为了 64×64 ,以便改进后的网络输入层能适应分割后的行人图像维度。同时还改进了原 Resnet50 卷积神经网络的残差块,包括卷积残差块以及恒等残差块,解决了由于网络层数增加而导致的网络退化问题。改进了原 Resnet50 卷积神经网络的损失函数,解决了由于参数更新带来的诸多问题,使原残差网络的性能得到了优化。添加了 1×1 以及 3×3 大小的卷积核,以便能减少网络中的参数数目,同时还能使网络中各层提取到的特征效果更好。还在原残差网络 Resnet50 中添加了新的全连接层,并且在增强网络性能的同时,还使网络变得更加灵活。

3.改进后的 Resnet50 卷积神经网络在行人重识别数据集 Market1501 以及 DukeMTMC-reID 数据集上进行了训练与测试,网络训练后的结果表明改进后的卷积神经网络性能更佳,识别的准确率更高,相比于当前比较好的神经网络,也具备一定的可比性,还领先于一些国际上使用的卷积神经网络。

关键词: 卷积神经网络, Resnet50 结构, 行人重识别, 残差网络, 图像分割

ABSTRACT

It is extreme difficult to find specific pedestrians in the surveillance video by relying solely on human resources due to the popularity of video surveillance systems and the increasing number of surveillance videos, person re-identification technology came into being to solve this problem. Person re-identification technology refers to judging whether it is the same pedestrian by distinguishing the same pedestrians appearing under multiple cameras. Based on the above problems, the work that has been done of this thesis mainly includes the following aspects:

1. First of all, a brand new algorithm named ISSE for image segmentation of person re-identification based on skeleton has been proposed , the 18 person skeletons are extracted by exploiting the OpenPose platform, and then the person images will be segmented into three parts according to skeletons extracted above, the three parts are a small amount of overlapped image content between each part, which can effectively enhance the image features so that solve the problem that the performance of extracting features is not good due to the low resolution of image.

2. The input layer of the original Resnet50 convolutional neural network has been improved, and the input layer of the original Resnet50 residual network is changed from 224x224 to 64x64, so that the improved input layer of network can adapt to the dimension of segmented pedestrian image. The residual block of the original Resnet50 convolutional neural network also has been improved, including the convolution residual block and the identity residual block, which solves the problem of network degradation caused by the increase of the network layer. The loss function of the original Resnet50 convolutional neural network has been improved in purpose of solving the problems caused by parameter updating, and the performance of the original residual network has been optimized. The 1x1 and 3x3 convolutional kernels have been added into the original Renet50 residual network, so as to reduce the number of parameters in the network, which also makes the features extracted by each layer in the network much better. A new fully connected layer has been added to the original residual network Resnet50, which makes the network more flexible while enhancing network performance.

3. The optimized convolutional neural network Resnet50 is trained on

Market1501 data set and DukeMTMC-reID data set, the result indicates that the performance and identification accuracy of new network are much better than the original one, the improved neural network is competitive with other neural networks, even with the networks of international level.

Keywords: convolutional neural network, Resnet50 network, person re-identification, residual network, image segmentation

目录

第一章 绪 论.....	1
1.1 论文研究工作的背景与意义.....	1
1.2 论文相关研究现状.....	2
1.3 论文主要的研究内容.....	6
1.4 论文的结构顺序.....	7
第二章 基于行人重识别的基础理论和相关技术.....	9
2.1 行人重识别以及行人检测技术.....	9
2.2 行人重识别技术中存在的问题.....	10
2.2.1 行人重识别的特征表示.....	10
2.2.2 行人重识别的行人外表多样化.....	11
2.2.3 行人重识别的训练数据规模较小.....	11
2.2.4 行人重识别数据归一化的能力.....	12
2.3 行人重识别技术中的研究方向.....	12
2.3.1 行人重识别中的特征提取.....	12
2.3.2 行人重识别中的距离度量.....	14
2.4 卷积神经网络.....	14
2.4.1 神经网络.....	15
2.4.2 卷积神经网络（CNN）理论.....	16
2.4.3 卷积神经网络（CNN）模型.....	17
2.5 本章小结.....	18
第三章 行人重识别图像分割算法 ISSE	19
3.1 基于 OpenPose 的行人重识别骨骼特征提取	19
3.2 行人重识别图像分割算法 ISSE 的总体设计思路	20
3.3 基于行人重识别图像分割算法 ISSE 的实现	23
3.4 行人重识别图像数据归一化设计原则.....	26

3.5 行人重识别图像维度与分割效果的关联性设计.....	27
3.6 本章小结.....	29
第四章 基于行人重识别的卷积神经网络 Resnet50 的改进设计.....	30
4.1 基于行人重识别 Resnet50 网络模型的改进设计.....	30
4.2 基于行人重识别 Resnet50 网络输入层的改进设计.....	31
4.3 基于行人重识别 Resnet50 网络损失函数的改进设计.....	34
4.4 基于行人重识别 Resnet50 网络残差块的改进设计.....	36
4.4.1 恒等残差块的改进设计.....	37
4.4.2 卷积残差块的改进设计.....	40
4.5 行人重识别算法设计.....	43
4.5.1 行人重识别算法总体设计.....	43
4.5.2 行人重识别前向传播流程设计.....	43
4.5.3 行人重识别反向传播流程设计.....	45
4.6 改进后的基于行人重识别 Resnet50 网络主体结构设计.....	46
4.7 基于深度学习的行人重识别系统设计.....	49
4.8 本章小结.....	50
第五章 改进后的行人重识别 Resnet50 模型的实现.....	51
5.1 行人重识别算法的实现.....	51
5.2 行人重识别实验环境配置.....	53
5.3 行人重识别网络训练方式.....	53
5.4 行人重识别网络训练细节.....	54
5.4.1 行人重识别网络学习率.....	54
5.4.2 行人重识别网络参数初始化.....	57
5.4.3 行人重识别网络超参数配置.....	60
5.5 行人重识别实验仿真结果和对比.....	61
5.5.1 行人重识别图片数据库.....	61
5.5.2 行人重识别实验结果评价标准.....	70

5.5.3 行人重识别实验结果.....	74
5.5.4 行人重识别结果对比.....	77
5.6 行人重识别实验仿真结果分析.....	80
5.7 本章小结.....	81
第六章 总结与展望.....	82
6.1 全文总结.....	82
6.2 后续工作展望.....	83
致谢.....	84
参考文献.....	85
攻读硕士学位期间取得的成果.....	91

第一章 绪 论

1.1 论文研究工作的背景与意义

由于社会的快速发展以及人民群众的安全意识不断提高,很多公共场所都被安装了监控摄像头以便能随时监控公共区域的情况来防止意外事件发生,还可以为相关执法部门提供证据,许许多多的摄像头组成了一个诺大的监控网络,让广大人民多了一份安心。通过查看监控视频中的画面可以辅助抓捕犯罪嫌疑人,找回失窃物品,同时也可以让越来越多的人安心出行,不用过于担心人身安全,而对于不法分子起到了威慑作用,对社会文明的进步也起到了促进的作用。

公安部门可以通过使用监控网络系统进行破案,而且可以用最小的人力以及物力完成任务。对于道路交通部门而言,可以通过实时查看道路监控视频记录交通拥堵情况,将信息整理后及时地告知广大即将或者已经出行的司机,司机便可以提前知道哪条行驶路线更适合自己的,也便于交通部门工作人员对交通状况进行监督和管控。当前视频管理中主要靠人力来查看具体的摄像头实时监控,但是随着视频监控网络的逐渐兴起以及海量视频的产生,人工方式的视频分析越来越困难,而且存在许多问题,因为这种方式对于视频监督人员要求特别高,容易使人产生疲倦,其次,海量监控视频必然会造成视频存储空间的不足,需要定时释放视频资源,但在视频清理过程中可能会丢失一些以后需要用到的重要信息。

以往的视频监控系统很难适应现在的需求,因为当前的视频监控网络需要长时间监拍画面,而且现在的监控系统已经趋于智能化,但是由于智能化目标行人匹配技术还没有成熟,所有的工作只能依靠人工来完成,人工的费用巨大,为了减少成本和资源,可以引用云端存储技术以及计算机视觉技术解决上述诸多问题,而行人重识别技术刚好适用上述情况,可以有效地解决相关问题。

近几年一些新的互联网技术不断兴起,比如车牌识别技术等等风靡全球,这些技术都属于计算机视觉技术,之后随着人工智能技术的兴起,计算机视觉技术的研究逐渐和人工智能技术相结合,在社会上产生了许多具有价值的应用,比如在多个监控摄像头下进行识别的行人重识别技术^[1],行人重识别技术主要是指在许多不同摄像头监控下将行人与行人进行匹配的过程,以此来确定某个行人和另外的行人是不是同一个人,行人重识别技术研究出现于 2003 年,于 2016 年在计算机视觉著名的会议^[2]上被提出,并被许多人所熟知。行人重识别数据集 VIPeR^[3]是在 2007 年被相关作者^[3]提出的,行人重识别技术于 2008 年得到了一定的发展,直至今日,行人重识别技术已经被各行各业的人关注,而且越来越多的研究都和

行人重识别技术相关,许多相关的学术论文被发表。由于行人重识别技术是一个涉猎多个学科的联合体,诸如模式识别以及机器学习,因此被各个领域的学者进行研究,不同于生物识别技术,行人重识别技术在提取行人特征过程中可能会面临各类不同的难题,但这些难题也正是研究者在行人重识别技术中研究的方向,以便能更好地推动行人重识别技术的发展。

1.2 论文相关研究现状

行人重识别研究最早出现的时候被理解为一个多摄像机跟踪问题的子项目,而 Viper 数据集在当前的行人重识别技术研究中发挥着巨大的作用。行人重识别技术中主要包含两个重要的内容,第一个内容是监控视频中行人的特征提取,第二个内容指度量学习的方法,由于出现在多个摄像头下的同一行人外表在短时间内不会发生明显变化,监控视频的画质比较低,所以行人的检测主要根据行人的外表,包含穿的衣服以及身高等特征。

行人重识别的特征种类主要分为以下三个:

(1) 基本特征: 上述提到的基本特征主要指包含颜色直方图以及纹理特征等颜色特征,这些特征其实比较常见,如局部特征像尺度不变特征变换^[4]等。在行人重识别任务中,基本特征的使用主要是指将行人图像划分为不同的子图像,也就是图像的子区域,将多个图像子区域的特征分别提取出来,然后将它们合并在一起,就可以组成一个完整的图像信息特征。于此同时,行人重识别问题还被 L.Shen 等学者^[5]看作图像检索的子问题,除了将图像划分为子区域之外,还可以将行人图像划分为六条垂直的区间,将每个区间的图像信息特征提取出来,然后进行图像特征信息的匹配。

(2) 中层语义特征^[6]: 中层语义特征主要包含行人身上穿的衣服等特征,一般在行人重识别实验中不会单纯地使用中层语义特征,因为特征层次还不能完全达到实验的需求,实验中需要基本特征以及高层次的特征,一般采取的措施为在基本特征的基础上再融合中层语义特征,可以获得更多清晰的特征^[7]。

(3) 深层特征: 与基本特征以及语义特征不同的是通过神经网络自动提取的深层特征,在行人重识别任务中,深度卷积神经网络^[8]主要将其视为分类问题,可以使用深度卷积神经网络将行人的特征提取出来,然后计算不同特征之间的相似度,根据行人特征之间的相似度来判断他们是不是同一个行人。联合卷积神经网络^[9]可以更好地完成行人与行人之间的匹配工作。因此深度卷积神经网络的应用使行人重识别技术得到了许多明显的提升,识别率也增加了许多。其中比较著名的 AlexNet 网络^[10]在行人重识别分类任务中取得了令人瞩目的成绩,并被许多

人所了解，AlexNet 网络的识别错误率也特别低，只有百分之十五，相比于当时的其他卷积神经网络，优势非常明显，下图 1-1 就是其网络结构。




图 1-1 AlexNet 模型

图 1-1 的 AlexNet 网络每一层参数的数量都不一样，前面的五层结构为卷积层，主要实现卷积神经网络中的卷积操作，而与前五层不同的是最后三层结构，其主要负责把前五层提取到的行人特征综合起来，实现特征输出前的最后一步操作，因此包含的参数数量也是最多的，其神经元的数量有 650000 个，同时，由于计算机显存的限制，AlexNet 被划分为两个部分，而且它的两部分在两个 GPU 上同时进行训练，所有的卷积层以及全连接层的并行运算使得最后的计算效率提高了许多，因为双 GPU 之间也会通过卷积神经网络的某些层进行信息交流，接着就是网络中的卷积操作以及池化操作，卷积操作中的步长以及卷积核数量主要根据输入图像的维度而定，而池化操作可以使特征映射通道数减少，因此参数也会被减少，一般卷积神经网络最后的卷积操作包含的卷积核大小较小，因为图像维度在逐渐减小。最后就是网络的全连接层，综合前面通过卷积层以及池化层得到的行人信息特征，再进行行人的分类。

在以往的卷积神经网络中一般采用不同的方式进行连接，其中包含随机稀疏连接以及非均匀稀疏矩阵连接，但这两种连接方式关联性不强，而现有的计算机硬件更适合关联性强的数据计算，因此，为了打破网络的对称性以及提高网络的性能，引入了聚类方法^[11]以便加快计算效率，一种被称为 Inception^[12]的新结构被提出。




图 1-2 Inception 网络架构

从图 1-2 所示的网络架构中可以看出，网络中包含了并行的卷积操作，第一部分的卷积操作中一共包含了三个不同卷积核大小的操作，它们分别是 1x1 卷积核大小的卷积操作，3x3 卷积核大小的卷积操作以及 5x5 卷积核大小的卷积操作，分别对应着不同的特征输出。在进行三个不同卷积核大小的卷积操作之前，为了降低图像维度以及参数数量，在原来的模型基础上还分别添加了两个 1x1 卷积核大小的卷积操作以及一个 3x3 大小的最大池化操作，可以使用低成本进行跨通道的特征变换，第二部分直接是一个 1x1 的卷积操作，卷积输出后的结果相关性很大，而且获得的面积特征也大。可以通过两个并行的卷积操作得到输出特征信息后，再通过一个 filter 将两部分特征进行连结，作为下一层的输入。

其中 Network in Network^[13]的设计原理体现在了 GoogleNet 中，以便使卷积神经网络的识别率得到提升，在 GoogleNet 中，包含了许多不同卷积核大小的卷积操作，比如 3x3 卷积核以及 5x5 卷积核大小，在 3x3 以及 5x5 卷积核操作前添加一层 1x1 卷积核大小的卷积操作不仅可以减少参数数量，还可以减少计算量以及提高 GPU 运行的时间效率。

行人重识别中往往通过现有的欧式距离以及余弦距离等较为常用的距离度量公式来计算图像之间的距离以便完成特征配对，而样本的特性可能会被忽略，如果采用固定的方式计算，匹配的准确率会比较低。为了考虑样本的特性以及增加匹配的正确率，马氏距离度量理论^[14]被提出，除此之外还有 LMN（最大边界近邻理论）被相关作者^[15]提出，同时也被很多学者使用，但是该方法有一些弊端，比如产生过拟合的现象。针对这种现象，LMNN-R 算法被提出。为了提高算法的鲁棒性，一种相似性学习算法^[16]被提出，这种算法主要基于内核特征图

来计算特征相似度。

度量矩阵 M 在行人重识别任务中会被经常用到，但是需要经过许多计算才能得到。所以 Hirzer 等人^[17]提出了通过一定程度的减少正约束得到一个和度量矩阵 M 十分接近的矩阵。使用半正定矩阵的思想被 Liao 等人^[18]提出，同时需要给正负样本赋予不同的权重值，然后进行相似度度量。马氏距离的度量方法虽然取得了一定的效果，但方法过于结构化而且较为单一，为了弥补这一不足，作者^[19]提出了成对约束成分分析，在不对数据进行降维的前提下通过特定的函数来处理高维数据，此外，度量学习中还引入了支持向量机^[19]的理念以及用于分类的 SVM 算法^[20]。

行人检测以及行人分类成为了行人重识别研究中比较核心的内容，行人分类主要是指对行人图像进行整体识别以及类别划分，而行人检测主要是指在图像中锁定特定的行人并确定行人的位置信息，由于行人图像分类易受到光照以及遮挡等因素的影响，因此成为了一项国内外具有挑战性的任务。2015 年，著名的研究学者何凯明提出了残差网络 Resnet，残差网络在各类计算机视觉任务中都提高了识别率。如果单纯地增加网络的深度不一定会提高行人的识别率，反而导致网络的性能更差，因此 Resnet 网络设计了链接式的残差学习，通过残差学习使得特征更好地在网络中得到传播。

近年来，人体骨骼关键点检测得到了广泛的应用，比较著名的实时 2D 人体骨骼关键点检测算法由卡内基梅隆大学计算机实验团队于 2016 年提出，主要用于视频中行人的动态骨骼关键点检测，如图 1-3 所示。



图 1-3 人体骨骼关键点实时检测

随后骨骼关键点检测还应用于行为识别，任务跟踪，步态识别等计算机视觉领域，随着深度学习技术的不断发展，基于行人骨骼关键点的检测效果也取得了巨大的进步，如智能视频监控系统，虚拟现实以及病人监护系统。行人重识别研究的开展不仅仅依靠性能更为优越的卷积神经网络，在行人重识别图像处理方面

也取得了一定的进展,比如将图像分割为不同子图像的分割算法。图像分割算法发展的时间比较早,按照其分割的目的可以分为阈值分割,边缘检测分割,主动轮廓模型分割以及语义分割算法等。阈值分割主要依据局部区域进行分割且方式较为传统,计算能力需求小,性能比较稳定,一般应用于主体以及背景区分度较高的图像,而边缘检测分割主要基于图像的边缘像素,通过将边缘区域的像素串联在一起以便构建检测区域,边缘检测主要由串行边缘检测以及并行边缘检测组成,判断边缘区域的方法主要有图像一阶导数的最大值和二阶导数的零点。主动轮廓模型是一种较为实用的图像分割方法,在计算机图像分割任务中包含了几何以及参数主动轮廓模型,Cheng^[21]等人提出了用于分割的传统模型 Snake, Snake 经典参数模型主要通过能量化曲线来确定感兴趣的边缘区域。语义分割算法主要是前述分割算法的优化算法,其包含了各类语义信息,其中比较著名的语义分割算法为 R-CNN,其算法流程如图 1-4 所示。




图 1-4 R-CNN 流程图

如图 1-4 所示, R-CNN 算法流程中首先对输入图片进行选择以便生成不同的区域图像,然后通过卷积神经网络对生成的区域图像进行特征提取,再将提取到的特征信息进行分类,以此来判断具体的行人类别, R-CNN 虽然能对目标进行定位和识别,但是使用了许多图片处理操作,会降低网络最后的识别率。

1.3 论文主要的研究内容

论文主要介绍了深度卷积神经网络在行人重识别领域中的应用,内容可以分为以下几个方面:

首先对目前在行人重识别领域使用的深度卷积神经网络做了相关介绍,还对其发展以及突破进行了阐述,并且结合当前的研究现状做了总结,同时对行人重识别的基础理论知识进行了概括以及梳理。

其次，论文提出了一种基于 18 个行人骨骼关键点的图像分割算法 Image Segmentation of Skeleton Extraction (ISSE)，18 个行人骨骼关键点通过使用 OpenPose 平台提取得到，根据行人骨骼关键点以及对应的行人图像对行人数据集做分割，使图像特征可以被卷积神经网络重复学习。

再者，论文提出了一种改进后的 Resnet50 卷积神经网络模型，该新的卷积神经网络模型可以适应不同的输入数据维度，最低维度可以达到 64x64，在改进后的卷积残差块中添加了新的卷积核，同时除了改进原网络的输入层之外，还改进了原神经网络的残差块以及损失函数。

最后，将改进后的卷积神经网络 Resnet50 在不同的行人重识别数据集上做了实验，并根据得到的实验结果跟其他网络模型的实验结果做了对比，同时还做了详细的分析，并从多个考虑因素对卷积神经网络的优劣进行了评估，使得网络性能的对比更加合理化以及科学化，最后也对改进后的卷积神经网络体系做了归纳与总结。

1.4 论文的结构顺序

论文提出了一种新的行人图像分割算法 ISSE，主要用于神经网络训练之前的行人图像数据分割，同时还设计并实现了改进后的卷积神经网络模型 Resnet50，然后用改进后的卷积神经网络模型提取行人的特征以便完成行人重识别任务，本论文的章节结构顺序主要为：

第一章对论文的研究背景以及研究价值做了详细的介绍，同时还讲述了行人重识别发展过程以及各个不同阶段所提出的观点和技术，最后分析了当前不同卷积神经网络的发展概况，以及做了相关总结。

第二章主要讲解了本论文需要用到的一些理论知识以及相关的技术，首先介绍了行人重识别以及行人检测技术，从整体上把握行人重识别的流程，其次介绍了行人重识别领域中存在的难题，并确定了针对这些难题的研究方向，接着讲解了关于卷积神经网络的相关概念和网络架构，为之后需要改进的神经网络的介绍做了准备。

第三章首先对 OpenPose 工具以及提出的行人图像分割算法 ISSE 做了介绍，主要包含算法的总体设计思路 and 实现方式，以及图像归一化的设计原则，其次还讲解了行人重识别图像维度与分割效果的关联性设计。

第四章主要介绍了基于行人重识别的卷积神经网络 Resnet50 的改进设计，细致地讲解了卷积神经网络模型改进的具体内容并做了详细的阐述，同时还介绍了基于行人重识别算法的设计思路，包括行人重识别前向传播以及反向传播设

计，阐述了本次实验中基于深度学习的行人重识别系统设计思路，以及系统地分析了改进后的残差网络 Resnet50 的性能。

第五章主要介绍了行人重识别技术中改进后 Resnet50 模型的实现，实验过程包括了实验环节的配置，网络训练的方式以及细节部分，然后介绍了改进后的 Resnet50 卷积神经网络模型在不同数据集上的训练结果以及测试结果，并将其实验结果和其他模型的实验结果、时间效率做了比较，同时给出了详尽的分析。

第六章主要概括了本论文的所有研究工作内容，同时也对论文进一步的研究方向进行了细致地阐述，还归纳了论文中的创新点以及讲解了之后可以继续完成的工作。

第二章 基于行人重识别的基础理论和相关技术

2.1 行人重识别以及行人检测技术

行人重识别技术虽然在科学研究中面临诸多问题,但是在现实生活中应用越来越广泛,并且取得了一些重要的成绩,除了安全监控视频中的行人识别外,在跨国跨境追踪方面也被应用。行人重识别技术主要应用在多个交叉的^[20]摄像头情境下,而且被社会上越来越多不同领域的研究者所关注,它已经成为了一项具有科研以及实际应用价值的技术,行人重识别任务通常包括不同摄像头下的行人追踪,以及包含目标行人的离线图像检索。

行人重识别技术主要从大量的图像数据库中匹配出与之对应的图像,整个图像匹配过程基于查询集图像以及候选集图像。匹配的结果和数据集的数量有关,当数据集偏小的时候,需要添加更多的图像样本,以便丰富图像数据库,学习更多特征。行人重识别任务主要包含两个环节,第一个环节为行人图像的收集以及特征的提取,第二个环节为特征的匹配。用于训练的图像数据应达到一定的要求,才能产生具有鲁棒性的特征效果,特征提取旨在为后续的特征匹配做铺垫,通过提取到的特征进行距离计算,然后得到图像之间的相似度,以便进行排序。

行人重识别任务包含不同的类型,比较常见的有以行人图像为基础的行人重识别技术,还有基于视频内容的行人重识别技术,前几年以视频内容为基础的行人重识别技术得到了快速发展,但是由于其数据规模较小,后来便出现了很多行人重识别的数据集,通过深度学习网络模型将行人重识别数据进行训练以及测试,可以得到较高的行人识别精确度。

目前我们使用的是基于视频内容的行人重识别技术,行人的图像数据集主要从视频中一帧一帧的画面截取得到,而行人特征提取的效果是分类任务中取得好结果的关键,因为行人重识别任务主要内容就是特征提取以及特征匹配。整个行人重识别流程主要包含以下几个方面:

- ①给定既定的一张图像作为查询集图片。
- ②学习给定的查询集图片的特征,同时也需要学习候选集中每一张图像的特征。
- ③将查询集中的行人特征向量与候选集中行人的特征向量进行匹配。
- ④根据查询集以及候选集中行人特征向量的匹配结果来确定是否为同一个行人。

行人重识别特征匹配的整个流程可以用下图 2-1 来表示。




图 2-1 特征匹配流程

行人检测技术也得到了快速地发展,而行人检测是行人重识别技术的先序环节,首先通过行人检测技术将行人检测出来,并自动进行标记,然后根据标记的内容进行识别。除此之外,我们熟知的智能驾驶、以及智能监控都属于行人检测技术的范畴,但是行人检测技术也面临很多难题,比如在速度以及性能方面还不能达到一个平衡的状态。

2.2 行人重识别技术中存在的问题

行人重识别技术虽然在不断发展,并且近几年也取得了巨大的进步,但是依旧存在许多挑战以及面临很多问题,接下来会对行人重识别技术遇到的问题分别进行介绍。

2.2.1 行人重识别的特征表示

行人重识别技术中的特征表示方法包含空间结构^[22],颜色特征^[21],纹理特征,或者一些组合特征等组成的基本特征表示,因为这些特征在提取时较为容易,而且会被保存为特定格式的数据,比如以直方图形式或者协方差形式的向量。

行人特征信息的提取成为了行人重识别技术中的关键步骤,理想情况下,卷积神经网络提取的图像特征不会过多的受到光线变化、背景杂物等的影响,目前

对于是否存在能应用于多摄像头视图和所有行人的具有显著性的特征还不明确，因为特征的区分度，可靠性以及可计算性很大程度上取决于观看视角和在给定视图中捕获的行人外观特征。此外，获得对齐的边界框并且准确地将行人从杂乱的背景中分割的难度逐渐上升，具有区分度的特征提取变得愈加困难，行人重识别中遇到的各类问题如图 2-2 所示。




图 2-2 行人重识别中的一些问题

2.2.2 行人重识别的行人外表多样化

行人重识别技术中存在许多需要克服的问题，而行人外表变化的多样性就是其中之一。在行人重识别的任务过程中，首先需要解决行人类间多样性以及类内多样性的问题，类间多样性是指不同行人在同一摄像头下看起来会很相似，类内多样性是指同一个行人在多个摄像头下的外表不一样，所以行人重识别的行人外表多样化也是重识别过程中考虑的一个因素。

2.2.3 行人重识别的训练数据规模较小

行人重识别技术包含的模型不一而足，但是不同的模型都是为了能学习到具有区分度的行人特征，以便进行行人的匹配，因此需要大量的行人数据进行学习，但是目前用于行人重识别模型训练的数据数量较少，而且行人图像的分辨率较低。

2.2.4 行人重识别数据归一化的能力

数据归一化主要指将用于训练的数据进行处理,使其具备稳定性等特性。在传统的训练方式中,对于行人重识别的训练都针对既定的摄像头,因此行人重识别中训练好的数据不能迁移到其他不同的监控摄像头下,训练完成的模型也不能实现一次训练可以多处使用的目的,这将产生数据的不可扩展性问题。

2.3 行人重识别技术中的研究方向

对于行人重识别任务,实现的主要流程包含以下几个步骤:

- ①特征提取
- ②距离度量
- ③分类

查询集行人图像与候选集行人图像间通过距离计算公式比如余弦距离或者欧式距离等实现,根据距离大小确定行人图像间的相似度,然后再将行人进行排序,整个流程示意图如图 2-3 所示。




图 2-3 行人重识别过程

2.3.1 行人重识别中的特征提取

在行人重识别任务实现过程中,行人图片的特性主要靠图片特征来表示,而不同图片的特征决定了最后的识别准确率,所以图片特征的选择非常重要。我们通常会用低层次的特征去寻找监控摄像头下的特定行人,行人的衣着色彩以及纹理特征对于锁定特定行人尤为重要。

行人重识别中的行人特征如 2.2.2 小节所提到的,其主要由三类特征组成,而其中的颜色特征还可以细分为以下几种:

1.HSV 颜色直方图

对颜色直方图中的 SV 值进行判断，当像素的 S 值与 V 值满足关系 (2-1) 时，可以确定该颜色是灰度颜色，SV 值中的字母 V 为图像的亮度，HS 为颜色的饱和度，可以根据 HS 以及 V 的值分布得到颜色直方图。

$$V < \frac{0.0657}{S} + 0.0897 \quad (2-1)$$

2.HSV 相关直方图

颜色相关直方图的理论知识被 S.Kumar 等人^[23]提出，其特征主要综合了颜色的统计分布特性以及颜色对空间的相干特性。

公式 (2-2) 可以用来表示行人图像中不同位置之间的像素点值， $|P_1-P_2|$ 的值代表了距离的大小。

$$|P_1 - P_2| = \max\{|X_1 - X_2|, |Y_1 - Y_2|\} \quad (2-2)$$

第二类是常见的纹理特征，纹理特征主要反应图像的结构组成和局部区域关系，比如行人衣服的纹理特征可以帮助更好地区分行人，图像的纹理特征不会轻易地受到光照变化的影响。

常见的局部二值模式 (LBP)^[24] 特征主要用来表示图像局部像素点和邻近像素点之间的关系，由于光照变化对 LBP 特征的影响较小，因此局部二值模式也经常被用在卷积神经网络对图像特征提取的过程中，局部二值模式值的输出过程如下图所示。




图 2-4 LBP 值输出过程

除此之外，还有梯度方向直方图，梯度也可以理解为二维图像的倒数，不仅可以反应出图像的结构纹理信息，还能表征二维图像的颜色变化情况。

中层次语义特征的提取一般指行人的发型或者衣服的类型，和低层次特征明显不同。

深层次（高级）特征提取使用范围比较广泛，优于前两者特征类型，主要被

使用在行人重识别任务中，一些研究者^[25]建立了深度神经网络结构，通过计算查询集和候选集中图片间的距离来确定图像间的相似度，根据图像间的相似度将行人进行分类。

2.3.2 行人重识别中的距离度量

行人重识别任务中，距离度量往往在特征提取操作之后执行，根据已经提取到的特征向量通过计算公式来计算图像之间的距离，然后将图像之间的距离计算结果进行排序，根据排序结果进行行人之间的匹配。

我们熟知的距离度量方法有两种，它们分别是：

①欧式距离^[27]：欧式距离为行人重识别任务中常见的距离度量方法，比如计算两个点在空间中的距离，一般都是欧式距离来表示。欧式距离也被广泛使用在行人重识别的任务当中，是用来计算图像之间相似度最有效的方法之一。

用来计算距离的欧式距离公式可以表示为：

$$d = \sqrt{\sum_{i=1}^{2048} (x[i] - y[i])^2} \quad (2-3)$$

2048 维空间点 a (x1, x2, ...x2048) 与点 b (y1, y2, ... y2048) 间的欧式距离可以用表达式 (2-3) 来表示。

②夹角余弦距离^[25]：夹角余弦距离主要基于两个向量夹角来计算余弦值，通过得到的余弦值来评定两幅图片的差异大小。多维空间上的夹角余弦距离可由公式 (2-4) 计算得到，其中 x 和 y 分别代表了空间上点的横纵坐标：

$$\cos \theta = \frac{x_1 * y_1 + x_2 * y_2 + \dots + x_n * y_n}{\sqrt{x_1^2 + x_2^2 + \dots + x_n^2} * \sqrt{y_1^2 + y_2^2 + \dots + y_n^2}} \quad (2-4)$$

本论文后续的实验中采用欧式距离来进行图像之间的距离计算。

2.4 卷积神经网络

卷积神经网络在近几年的时间里发展迅速，成为越来越多的研究者使用的人工神经网络，它由前向传播以及反向传播过程组成，属于监督学习的范畴，可以用于数据分析。卷积神经网络中的卷积层以及池化层使网络中的参数减少了很多，而且使网络的学习能力以及模型预测的功能更为强大。卷积神经网络最早用于手写数字识别项目，并取得了很不错的结果，随后该网络模型还应用在其他领域，比如商用支票识别等领域，模型的稳定性和可靠性非常好。同时卷积神经

网络在图像和物体识别方面也有广泛的应用，除此之外，还有自然语言处理^[28]以及推荐系统^[29]。

2.4.1 神经网络

人工神经网络系统由多个相互连结的处理组件组成，这些处理组件通过接收外部响应信号进行信息的反馈，人工神经网络主要基于人类大脑神经元连接的模仿，因为通过建立正确的信号连接可以使人类大脑正常工作，所以人工神经网络的构建也适用这一原则。在计算机图像处理中比较常见的就是卷积神经网络，卷积神经网络包含了不同的神经元节点，这些神经元节点被看作输出函数，同时卷积神经网络中每一层的连接包含了模型的权重参数，浅层神经网络模型如下图所示。




图 2-5 神经网络结构

上述神经网络对应的公式如下：

$$h_{W,b}(x) = f(W^T x) = f\left(\sum_{i=1}^3 W_i x_i + b\right) \quad (2-5)$$

公式 2-5 最右边的函数为激活函数^[30]，神经网络中每个神经元的输出将会被下一个节点用作输入，直到网络中的非线性方程找到了满意的解，同时根据卷积神经网络的误差传播来计算误差值，以便最优化神经网络模型与实际模型的偏差，使卷积神经网络具有更好的鲁棒性。

2.4.2 卷积神经网络（CNN）理论

卷积神经网络目前应用在多个不同的领域，比如图像识别以及处理，语音识别，卷积神经网络被应用在 2014 年的各类大型计算机视觉识别比赛中，并且实现了 6.656% 的极低错误率，卷积神经网络中使用的技术使得卷积神经网络可以有效地提取图像特征，它们分别是：

1. 局部感知野

感知野主要表示视觉神经对光源反馈的范围空间，感知野在卷积神经网络中代表不同的节点用来对图像的感知范围进行描述的元件，感知野的大小代表了卷积神经网络的神经元对图像的感受范围大小，卷积神经网络的神经元首先通过区域块的形式去感知图像的像素，然后将每个区域块的像素信息进行整合，以便构成完整的信息。在这个过程中可以减少权值参数的数量，使得模型变得更加精简，如下图 2-6 所示。




图 2-6 全连接和局部感受野

2. 权值共享

不仅可以使使用上面提及到的局部感受野方式来减少卷积神经网络中的参数，还可以使用权值共享的方法来减少网络中的参数数量，局部感受野虽然在一定程度上可以减少局部网络参数，但是卷积神经网络中的总体参数数量并没有被减少，而在计算机图像中，权值共享中的某一部分统计特性具有可迁移性，可以有效地减少卷积神经网络中的总参数数量。

3. 多卷积核

权值共享中，参数对每个区域提取的特征都是相同的，但是如果使用权值共享的方式来表示图像的特性还远远不够，需要不同的卷积核来生成不同的行人特征图，最后综合所有的特征图对行人进行识别。

4. 池化

在卷积神经网络模型的训练过程中，我们往往会使用不同尺寸的卷积核来提取图像的特征，提取到的特征种类增加的同时，特征的维度也在随之增加，而通过网络池化层（Max Pooling）可以减小特征图维度，以及特征映射通道，而且还可以进行图像的特征压缩，压缩的目的主要是将有效的特征保存下来，Max Pooling 的过程如下图所示。




图 2-7 Max Pooling

2.4.3 卷积神经网络（CNN）模型

下图所示为经典的 LeNet5 卷积神经网络模型，LeNet5 卷积神经网络模型由七层架构组成，而每层架构包含了不同的功能。最开始是卷积神经网络的输入层，如图中手写数字识别图像所示，输入层的输出经过卷积操作后得到了图像的特征图，之后再将特征图进行下采样处理以便降低特征图的维度以及减少网络的权重参数，然后继续重复卷积操作和下采样操作，下采样操作后的输出直接进行全连接，得到最后的特征就可以进行手写数字的分类。




图 2-8 LeNet5 卷积神经网络结构

LeNet5 网络最初主要用于手写数字识别，并取得了很好的效果。在图 2-8 网络结构中输入一张图像经历的过程为：

1.图像首先通过卷积神经网络的输入层被加载进网络中，而卷积神经网络输入层的维度决定了图像维度的大小，所以上述手写数字识别的图像维度为 32×32 。

2. 32×32 维度的图像经过输入层之后便经过网络的第一个卷积层，卷积操作之后的维度降低到 28×28 ，而且特征图的数量为 6，然后再进行输出。

3.将第一个卷积层的 6 个 28×28 维度图像的输出进行下采样操作。

4.将第一个下采样操作之后的特征图输出，再次经过卷积层，卷积操作后的输出为 10×10 维度的特征图。

5.将步骤 4 中卷积操作后的输出再次进行下采样操作，便可以得到 16 个 5×5 维度的特征图，然后进行输出。

6.将步骤 5 中的输出进行全连接操作，最后再进行分类操作，得到模型最后的输出。

2.5 本章小结

第二章首先阐述了行人重识别的基本概念以及关联的技术，然后将行人检测技术与行人重识别技术联系在一起进行分析，行人检测技术将检测到的行人智能化做完标记后再进行重识别过程，接着分析了行人重识别技术中所遇到的挑战，并结合实际情况将这些挑战和研究方向联系起来，以及解释了如何针对性地对相关难点做一些突破。还对卷积神经网络的理论知识以及模型做了介绍，接着阐述了卷积神经网络中各个部分的知识，让读者对论文的核心部分有一个总体的把握，以便能更加具体的了解网络改进的实现原理。本章介绍的相关内容主要是为后续行人图像数据分割以及改进后的卷积神经网络模型实现做铺垫。

第三章 行人重识别图像分割算法 ISSE

3.1 基于 OpenPose 的行人重识别骨骼特征提取

基于 OpenPose 的行人重识别骨骼特征提取为行人重识别图像分割算法 Image Segmentation of Skeleton Extraction (ISSE)设计的前序步骤,因为 ISSE 算法中的图像分割主要基于 OpenPose 平台提取到的行人骨骼关键点特征,根据行人骨骼关键点特征来确定每个区域的坐标以及置信值,从而准确地将行人图像分割成不同的局部图像。

OpenPose 是用 C++开发的开放式资源库,通过使用 OpenCV 库以及 Caffe 框架用于实时的行人骨骼检测平台,OpenPose 平台可以应用在多个领域,比如使用 OpenPose 平台将图片中检测到的行人骨骼关键点连接起来,便可以进行行人姿态预测,其中检测到的行人骨骼关键点有置信分数,来表示相应的准确率,比如可以检测到行人的脖子,耳朵等关键点,OpenPose 检测行人图像骨骼关键点时的速率约为 10 张/秒,可以实时输出行人图像对应的骨骼图像,而行人的骨骼关键点的输出方式包含了两种类型,一种是包含 18 个行人骨骼关键点的输出,还有一种是包含 25 个行人骨骼关键点的输出,在论文的实验中,采用的是 18 个行人骨骼关键点的输出,因为图像分割主要基于 18 个行人骨骼关键点。行人的骨骼关键点检测结果如图 3-1 所示。




图 3-1 行人骨骼关键点检测结果

通过 OpenPose 平台可以将行人的骨骼特征提取出来并用 JSON 格式文件进行保存,每一个行人身上的骨骼关键点用带有 X 值以及 Y 值的坐标表示出来,

结果如图 3-2 所示。

```

{
  "version":1.1,
  "people":[
    {
      "pose_keypoints_2d":[582.349,507.866,0.845918,746.975,631.307,0.587007,...],
      "face_keypoints_2d":[468.725,715.636,0.189116,554.963,652.863,0.665039,...],
      "hand_left_keypoints_2d":[746.975,631.307,0.587007,615.659,617.567,0.377899,...],
      "hand_right_keypoints_2d":[617.581,472.65,0.797508,0,0,0,723.431,462.783,0.88765,...],
      "pose_keypoints_3d":[582.349,507.866,507.866,0.845918,507.866,746.975,631.307,0.587007,...],
      "face_keypoints_3d":[468.725,715.636,715.636,0.189116,715.636,554.963,652.863,0.665039,...],
      "hand_left_keypoints_3d":[746.975,631.307,631.307,0.587007,631.307,615.659,617.567,0.377899,...],
      "hand_right_keypoints_3d":[617.581,472.65,472.65,0.797508,472.65,0,0,0,723.431,462.783,0.88765,...]
    }
  ]
}

```

图 3-2 骨骼关键点的输出形式

根据图 3-2 可知骨骼关键点的输出格式，可以通过解析 JSON 文件将代表行人骨骼特征关键点的坐标值提取出来，然后根据每一张行人图像的特征关键点，把对应的行人图像进行分割，分割后的子图像用于卷积神经网络的训练。

3.2 行人重识别图像分割算法 ISSE 的总体设计思路

行人重识别图像处理在行人重识别任务中非常重要，通常能够决定训练的结果。由于行人重识别中使用的图像数据来源于监控视频画面，所以图像的分辨率比较低，除此之外，图像中的行人还会出现被遮挡的情况，导致图像信息在提取时效果不佳，为了使图像信息特征更加全面，我们可以重复学习图像的局部特征，因为全局特征属于像素级的低层次特征，在进行计算的时候，计算量很大，而且特征维数也很高，不适合混合，重叠以及有遮挡的图像。行人图像的局部特征提取主要从行人图像的细节入手，比如图像的边缘、角、线等等，由于局部特征包含了非常丰富的信息，在行人受到遮挡的情况下并不会因为部分特征的消失而影响其他特征的检测与匹配。

根据局部特征以及全局特征的性质，本实验将提出一种基于行人骨骼特征关键点的图像分割算法 Image Segmentation of Skeleton Extraction (ISSE)，将行人图像数据进行分割。算法的主要思想为：把行人重识别整体图像数据划分为两部分，一部分为行人图像，另一部分为行人图像对应的骨骼图像，行人骨骼图像包含的关键点信息主要通过 JSON 的文件格式进行存储，每个骨骼特征点的信息由 (x, y) 坐标值表示，通过多个图像骨骼特征点的特征值计算图像包含的特征极大值和特征极小值，根据特征极值将对应行人图像分割为不同的局部图像，局部图像中包含了大量的行人信息。

ISSE 算法的流程示意图如下图 3-3 所示。




图 3-3 ISSE 算法流程图

根据图 3-3 中的算法流程示意图可以得到算法的执行步骤，算法执行步骤如下：

步骤 1：首先准备实验需要的行人重识别图像数据，设总的行人重识别图像数据总量为 M 。

步骤 2：将行人重识别图像数据 M 进行数据预处理，数据预处理主要包含了图像维度处理以及数据增广，预处理后的输入图像数据维度统一为 64×128 。

步骤 3：将经过数据预处理后的行人重识别图像数据 M 输入至 OpenPose 平台中，提取行人图像的骨骼特征。

步骤 4：OpenPose 平台的输出结果主要包含了两部分，第一部分是行人图像 M 所对应的骨骼关键点图像，另外一部分是行人图像所对应的包含图像信息的 JSON 文件，将两部分内容进行保存。

步骤 5：将步骤 4 中的输出结果 JSON 文件以及对应的源行人图像作为步骤 6 的输入，通过骨骼图像的坐标值分别标记出对应行人图像的极值坐标点，根据极值坐标点来划分局部图像区域以及计算不同三部分图像间极值差值来确定重叠的内容，最后进行行人图像的分割。

步骤 6: 行人图像分割后的输出结果主要包含了三部分, 分别是行人图像的头部, 躯干以及腿部, 三部分的图像输出维度都是 64×64 。

上述算法步骤 2 中对行人重识别骨骼特征提取的过程可以用图 3-4 表示出来, 图 3-4 中的变量 i 表示执行迭代的次数, M 为数据样本的总数。




图 3-4 骨骼特征提取流程图

上述步骤 6 中的图像分割维度设定主要和行人图像数据总量 M 相关, 因为输入的行人图像数据数量为 M , 如果分割为 3 部分, 则输出的行人局部图像为 $3 \times M$, 如果局部图像维度过大会增加卷积神经网络中训练的参数数量以及对计算性能有了更高的需求。算法步骤 6 中的分割结果如下图 3-5 所示。




图 3-5 行人图像分割示意图

论文中的多个行人重识别数据集都会先通过 ISSE 算法进行图像分割，分割成不同的三部分图像，然后分别输入到改进后的卷积神经网络 Resnet50 中，行人的头部、躯干以及腿部的特征将被卷积神经网络分别提取，最后再将行人的三部分局部特征合并在一起构成全局特征进行输出，做行人分类。如图 3-6 所示。




图 3-6 行人重识别过程

3.3 基于行人重识别图像分割算法 ISSE 的实现

根据论文 3.2 节图像分割算法 ISSE 的设计思路和流程，可以将行人图像的骨骼关键点坐标与源图像进行对应，其简化示意图如下图 3-7 所示。




图 3-7 图像分割简化示意图

根据图 3-7 所示，三个不同颜色的正方形表示行人身上不同的三个部分，橙色的正方形表示行人的头部，蓝色的正方形表示行人的躯干，绿色的正方形表示行人的腿部。三个不同区域之间有相互重叠的部分，重叠的内容主要由骨骼特征点极值运算确定，在图 3-7 中已经用小方框标注出来。重叠内容有利于改进后的卷积神经网络更好地提取图像的特征。

可以通过 OpenPose 平台将行人图像的骨骼关键点特征提取出来，通过 JSON 形式进行存储，因此在对图像进行分割时可以通过极值坐标点来确定行人的位置信息。在图 3-6 的图像分割过程中，第一个橙色的行人框为行人的头部，由坐标 $(0, 0)$ 以及 $(width, y1)$ 来决定，其中 $width$ 为图片的宽， $y1$ 为图像第一个橙色行人框的高，第二个蓝色的行人框为行人的躯干，由坐标 $(0, y)$ 以及 $(width, y3)$ 决定，第三个绿色的行人框主要由坐标 $(0, y2)$ 和 $(width, y4)$ 决定。而第一个橙色的行人框与第二个蓝色的行人框交叉的内容分别用 $(y1-y)$ 和 $(y3-y2)$ 表示。

图像分割算法的部分源代码如下，代码主要描述了输入图像经过 OpenPose 提取特征后获得 JSON 文件，并根据 JSON 文件中的特征值将原始图像的六个关键特征点标记出来，然后根据特征点将图像分割成不同的区域。

```

def readkeypoints(filenamees):
    if filenamees.endswith('.json'):
        fullpath = filenamees
        fp = open(fullpath, 'r')
        images = json.load(fp)
        if len(images['people']) == 0:
            return []
        images_key1 = images['people'][0]
        images_key2 = images_key1['pose_keypoints_2d']

        keypoints = []
        for i in range(0, len(images_key2)):
            if ((i + 1) % 3) == 0:
                continue
            else:
                keypoints.append((images_key2[i])/2)
        bbox = keypoints
        bbox = bbox[1:36:2]
    fp.close()
    coordinates = [max(y1), max(y2), max(y3), min(y1), min(y2), min(y3)]
    print("This is maximal and minimal value", coordinates)
    return coordinates
jsonfile1 = glob.glob("/home/qzhang/openpose/examples/media/skejson/Market1501/query_json/*.json")
images1 = glob.glob("/home/qzhang/openpose/examples/media/data/market1501/query_2times/*.jpg")

blowhole = [bbox1, bbox2, bbox3]
base name = os.path.base name(images1[i])
getname = base name.split('_')[0] + bytes('_') + base name.split('_')[1] + bytes('_') + base
name.split('_')[2] + bytes('_') + \
    base name.split('_')[3]

for j in range(3):
    if (blowhole[j][2] * blowhole[j][3] == 0):
        continue
    if j == 0:
        roi = img1.crop(blowhole[j])
        print(roi)
        # roi.save("F:/keypoints/result/result1/%d_part1.jpg" % i)

roi.save(os.path.join("/home/qzhang/openpose/examples/media/result/Market1501/query/result1/",
    os.path.base name(getname)))

elif j == 1:
    roi = img1.crop(blowhole[j])
    # roi.save("F:/keypoints/result/result2/%d_part2.jpg" % i)

roi.save(os.path.join("/home/qzhang/openpose/examples/media/result/Market1501/query/result2/",
    os.path.base name(getname)))

else:
    roi = img1.crop(blowhole[j])
roi.save(os.path.join("/home/qzhang/openpose/examples/media/result/Market1501/query/result3/",
    os.path.base name(getname)))
print("The number of empty max(y1) or (maxy2) is:", count)

```

3.4 行人重识别图像数据归一化设计原则

在完成行人重识别任务时，我们首先需要对图像数据做预处理，这样能使图像特征更好地被提取，图像预处理分为两个内容，第一个内容为图像标准化处理，第二个内容为图像归一化处理，本实验采用的方法为图像归一化处理。

图像归一化主要分为两类，公式（3-1）表示图像归一化中的最大值以及最小值归一化。

$$\text{norm} = \frac{x_i - \min(x)}{\max(x) - \min(x)} \quad (3-1)$$

如公式（3-1）所示，其中 x_i 表示图像像素点的值， $\min(x)$ ， $\max(x)$ ，分别表示图像像素的最大与最小值。

为了更直观地了解图像归一化地实现原理，将图像数据归一化之前以及归一化之后的数据进行对比，如下图 3-8 所示。

```
[[[ 4 24 19]
   [31 48 44]
   [34 51 48]
   ...,
   [ 0 28 22]
   [ 1 29 23]
   [ 3 31 25]]

 [[12 32 27]
  [30 47 43]
  [32 49 46]
  ...,
   ]]
```

图 3-8 图像归一化之前

根据图 3-8 所示，上图为图像数据归一化之前表示，则图像数据归一化之后的表示为：

```

[[[ 0.01568628  0.09411766  0.07450981]
  [ 0.12156864  0.18823531  0.17254902]
  [ 0.13333334  0.20000002  0.18823531]
  ...,
  [ 0.          0.10980393  0.08627451]
  [ 0.00392157  0.1137255   0.09019608]
  [ 0.01176471  0.12156864  0.09803922]]

[[ 0.04705883  0.1254902   0.10588236]
 [ 0.11764707  0.18431373  0.16862746]
 [ 0.1254902   0.19215688  0.18039216]
  ...,

```

图 3-9 图像归一化之后

根据图 3-8 以及图 3-9 可知，图像进行归一化操作后的结果与原图一致，图像数据的归一化操作并不会改变图像原始的信息特征，而行人图像的归一化操作使改进后的卷积神经网络 Resnet50 在行人图像特征提取方面的效率变得更高。除此之外，很多数据集比如 mnist^[39]数据集也采用归一化的方法后再进行识别实验。

3.5 行人重识别图像维度与分割效果的关联性设计

在行人重识别任务中，不同的行人图像维度通过 OpenPose 平台提取出来的行人骨骼特征点效果也不一样，因为 OpenPose 平台在提取行人骨骼特征点时会根据图像的像素点标记置信区间和置信分数，置信区间的值越小，置信分数越大，而行人图像特征就越明显，置信区间的值越大，置信分数越小，行人图像的特征就越隐晦，为了更加清楚地了解图像维度对行人骨骼特征点提取效果的影响，接下来分别将 64x128 维度的行人图像特征提取结果与 156x364 维度的行人图像特征提取结果做一个对比。

图 3-10 为 64x128 维度的行人图像经过 OpenPose 平台特征提取之后的效果图。




图 3-10 64x128 图像特征效果图

为了和图 3-10 做效果对比，接下来将维度为 156x364 的行人图像特征提取出来，其效果图如下图 3-11 所示。




图 3-11 156x364 图像特征效果图

根据图 3-10 以及图 3-11 所示的特征提取效果图显示，高维度的行人图像提取出来的特征效果会更好，所以在行人重识别数据集中一般会将图像数据统一扩维后再进行行人骨骼特征的提取，根据最后的行人图像分割效果表明，将行人图

像维度扩大为原来的 2 倍后再进行特征提取的效果最佳,所以在行人图像维度与分割效果的关联性设计上应考虑适合骨骼特征提取的图像维度,包括后续的行人图像特征提取也是基于以上设计原则。

3.6 本章小结

本章主要介绍了行人重识别图像分割算法 ISSE 的设计与实现,其中包括了图像分割算法的总体设计思路以及实现过程,图像数据归一化的设计原则还有图像维度与分割效果的关联性设计,主要为后续章节的训练数据获取做准备,因为用于卷积神经网络模型训练的数据是影响卷积神经网络模型学习性能的重要因素,本章的介绍同时也为第五章的实验部分做了铺垫。

第四章 基于行人重识别的卷积神经网络 Resnet50 的改进设计

4.1 基于行人重识别 Resnet50 网络模型的改进设计

根据第二章讲解的卷积神经网络基础理论知识以及关联技术可知,通常来讲深层次的卷积神经网络与浅层次的卷积神经网络在同一数据集上训练的结果不一样,而且深层次网络的实验结果要优于浅层次网络的实验结果,因为网络层次越深,学习到的特征映射就会更加复杂,所以提取出的特征具有更好的区分性。但是在用行人数据集对网络进行训练时,传统网络中的识别率并不会因为网络层数的加深而增加,因为模型的复杂度会随着神经网络层数的增加而提高,而且随机梯度下降的优化会变得更加困难,这就是神经网络在训练时的网络退化问题[31]。

如下图 4-1 所示,左右两部分分别是 20 层以及 56 层的 plain 网络在相同的网络迭代次数下表示的训练错误率和测试错误率对比图,从图中可以直观的看出具有 56 层神经网络的训练和测试阶段错误率明显高于具有 20 层神经网络的训练和测试阶段的错误率,因此不符合上述网络层次越深训练效果越好的理论。




图 4-1 训练以及测试的错误率趋势图

因此包含了残差块学习的卷积神经网络模型被微软亚洲研究院^[22]提出,此模型主要解决深度卷积神经网络模型中由于网络层数的加深导致卷积神经网络出现的退化现象,此模型主要是在浅层次网络的基础上叠加恒等映射。为了得到具备更好性能的卷积神经网络,可以用非线性单元逼近目标函数 $H(x)$,而目标函数 $H(x)$ 由恒等函数 x 和残差函数 $H(x) - x$ 组成,如下图所示。




图 4-2 卷积神经网络的残差模块

根据上图 4-2 所示, `weight layer` 为神经网络的卷积层, `Relu` 为神经网络的激活函数, 则模型输入 $F(x)$ 的值 $W^{[l+1]}a^{[l]}+b^{[l+1]}$ 与 $z^{[l+1]}$ 以及 $W^{[l+1]}a^{[l]}+b^{[l+1]}$ 的值相等, 由于残差块中加入了恒等映射, 则 $F(x)$ 经过线性运算以及再次激活后就能得到输出, 那么有 $g(F(x)+x)=g(W^{[l+1]}g(W^{[l]}x+b^{[l]})+b^{[l+1]}+x)$ 。

虽然使用深度卷积残差网络可以解决网络退化的问题, 但是其本身仍然存在一些不足, 无论是网络设计还是算法的思想都可以进一步优化。因此, 为了提高残差网络的性能, 在具有 50 层的残差网络 Resnet50 中做如下改进:

1. 使用行人骨骼图像分割算法 ISSE 分割输入层的行人图像, 修改了 Resnet50 深度残差网络的输入层维度, 以便能匹配分割后的图像维度并进行网络模型的训练。
2. 除此之外还将原卷积神经网络 Resnet50 的网络残差块, 包括恒等残差块以及卷积残差块做了改进。
3. 将原卷积神经网络 Resnet50 损失函数做了改进, 同时还优化了原残差网络 Resnet50。
4. 改进后的卷积神经网络 Resnet50 以原残差网络 Resnet50 为基础, 将 1×1 和 3×3 的卷积核的参数进行了修改并应用到新的卷积神经网络 Resnet50 中, 以及修改了原 Resnet50 残差网络的全连接层。

4.2 基于行人重识别 Resnet50 网络输入层的改进设计

使用 OpenPose 工具将行人骨骼关键点特征提取出来后, 便可以根据行人的骨骼关键点将行人分割成三个不同的输入, 分别为行人的头部, 躯干, 腿部, 行人图像分割示意图如下图 4-3 所示。




图 4-3 行人图像分割

图像分割后的三部分图像内容分别输入到改进后的 Resnet50 残差网络当中，以便进行行人特征信息的提取。由于原残差网络 Resnet50 的输入层图像维度大小被固定为 224×224 ，经过行人图像分割后的三部分图像维度为 64×64 ，因此不满足残差网络 Resnet50 的输入条件，因此改进后的 Resnet50 的输入层大小为 64×64 ，修改了神经网络 Resnet50 的输入层之后，还需要修改最后一层平均池化层，以便匹配输入维度，同时还需要减少初始化卷积层中 1×1 以及 3×3 卷积核的步长大小，这是因为输入的图像尺寸大小由 224×224 降低至了 64×64 。

输入层的输入图像维度降低至 64×64 后，可以使改进后的卷积神经网络提取到更加丰富以及更加稳定的行人图像特征，行人的三部分 64×64 大小的图像经过三个并行的卷积神经网络 Resnet50 后便能提取到三个并行的特征向量，之后再再将三个特征向量连接在一起进行行人的分类。

将卷积神经网络 Resnet50 的输入层修改后，可以适应分割后的行人图像数据维度，同时还便于图像数据集的训练，还可以使学习到的特征更具有区分性，这些特征主要包含以下几点：

- 1.重复性：行人图像中的不同区域的内容会被重复检测，因为分割后的行人图像之间有互相重叠的部分，因此行人特征会被卷积神经网络重复的学习，所以分割后的行人图像有利于提高卷积神经网络模型的识别效果。

- 2.辨识度：不同的图像检测子可以被区分出来，而且有对应的描述子。

- 3.检测子数量合适：过多的检测子会造成许多无关图像的识别，过少的检测子会造成检测信息的匮乏。

4. 有效性：特征提取的效率比较高。

为了更好的理解改进后的原卷积神经网络 Resnet50 的输入层维度，下面用一种更加直观的方式来说明输入不同行人图像维度后经过卷积操作之后的输出大小，原来卷积神经网络 Resnet50 的输入层维度为 224×224 ，现在假设将一张 224×224 维度的行人图像输入到卷积神经网络 Resnet50 中，那么图像经过第一个卷积操作之后，行人图像的第二个输出特征维度为 112×112 ，行人特征提取的过程如下图 4-4 所示。




图 4-4 卷积操作示意图

那么经过分割后的行人图像一共分为三部分，每部分的维度都为 64×64 ，现在取其中的一部分作为改进后的卷积神经网络 Resnet50 的输入，其他两部分内容一样，由于原卷积神经网络 Resnet50 输入层大小已经改变，则改进后的卷积神经网络 Resnet50 的输入层维度为 64×64 ，假设现在我们将一张行人图像输入到卷积神经网络 Resnet50 中，首先经过第一个卷积操作，卷积操作中的感受野大小 F 为 5×5 ，它的数量 K 等于 1，它的步长 S 等于 2，它的边界填充 P 等于 1，则第一个输出的特征维度为 32×32 ，如图 4-5 所示。此外，行人图像的另外两部分：躯干以及腿部的输出特征维度也是 32×32 ，对比图 4-4，经过第一个卷积操作之后，虽然卷积核以及超参数配置一模一样，但是输入层的图像维度不一致会导致输出特征也不相同。


图 4-5 64×64 维度图像经过一次卷积后的输出

图 4-4 以及图 4-5 中的输出特征大小的计算主要基于公式 (4-1)，(4-2)，(4-3)，公式中的 W_1 和 H_1 分别表示源图像的宽和高， W_2 和 H_2 分别表示经过卷积操作之后输出图像的宽和高， F 表示卷积核尺寸， K 表示卷积核数量， S 表示步长的大小， P 表示填充的大小， D_2 为输出图像的维度：

$$W_2 = \frac{W_1 - F + 2P}{S} + 1 \quad (4-1)$$

$$H_2 = \frac{H_1 - F + 2P}{S} + 1 \quad (4-2)$$

$$D_2 = K \quad (4-3)$$

输入层图像大小为： $W_1 \times H_1 \times D_1$ ， W_1 为输入层图像的宽， H_1 为输入层图像的高， D_1 为输入层图像的维度，与输入层图像大小类似，输出图像大小为 $W_2 \times H_2 \times D_2$ 。

通过将分割后的行人图像输入到改进后的卷积神经网络 Resnet50 中进行特征信息提取的效果会更好，因为图像中重复的内容可以加强神经网络的学习能力。

4.3 基于行人重识别 Resnet50 网络损失函数的改进设计

原有的卷积神经网络 Resnet50 的输出层使用的激活函数为 softmax^[32]，softmax 函数也被称为归一化的指数函数。现在我们假设有一个数组 A ， A_i 为数组 A 的第 i 个元素， j 为激活函数包含的节点数量，根据 softmax 定义，则可以通过公式 (4-4) 将 A_i 的 softmax 值计算出来：

$$A_i = \frac{e^i}{\sum_j e^j} \quad (4-4)$$

根据加权公式介绍可知， $z^{[L]} = W^{[L]}a^{[L-1]} + b^{[L]}$ 是卷积神经网络 L 层，也就是最后一层的加权输入值，那么根据上述等式可知，第 L 层的第 i 个神经元的激活值为：

$$a_i^{[L]} = \frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} \quad (4-5)$$

根据表达式 (4-5) 可知第 L 层的第 i 个神经元的激活值，同时也可以神经网络中最后一层的所有输出神经元上求得分母。而 softmax 激活函数可以规定加权输入值的格式，可以把输入看作幂指数运算得到结果，然后再将这些结果进

行正则化操作。从幂指数运算中可以看出加权输入的增加对应着模型中系数的增加，加权系数的减小对应模型中系数的减小，而且模型中的系数不会小于并且等于零。

可以使用 softmax 损失函数正则化模型中的系数，以便使系数的总和为 1，同时可以得到一个有效的概率分布，可以用公式（4-6）表示出来：

$$P_j = \frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} \quad (4-6)$$

根据表达式（4-6）可以构建新的损失函数 L_{new} ， γ 为损失函数的分位值， $\gamma \in [0,1]$ ，其表达式如（4-7）所示：

$$L_{new} = - \left(1 - \frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} \right)^\gamma \log \frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} = -(1 - P_j)^\gamma \log P_j \quad (4-7)$$

根据前述内容可知误差的表达式如（4-8）所示：

$$\delta_i^{[L]} = \frac{\partial L_{new}}{\partial z_i^{[L]}} = \gamma(1 - P_j)^{\gamma-1} \frac{\partial P_j}{\partial z_i^{[L]}} \log P_j - (1 - P_j)^\gamma \frac{1}{P_j} \frac{\partial P_j}{\partial z_i^{[L]}} \quad (4-8)$$

表达式（4-8）中可以先将 $P_{(j)}$ 关于 $Z_{(i)}$ 的偏导值计算出来， i 与 j 相等时有：

$$\frac{\partial P_j}{\partial z_i^{[L]}} = \frac{\partial}{\partial z_i^{[L]}} \left(\frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} \right) = \frac{e^{z_j^{[L]}} \sum_{k=1}^{n_L} e^{z_k^{[L]}} - e^{z_j^{[L]}} e^{z_i^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}} \sum_{k=1}^{n_L} e^{z_k^{[L]}}} = P_j - P_j^2 \quad (4-9)$$

表达式（4-8）中可以先将 $P_{(j)}$ 关于 $Z_{(i)}$ 的偏导值计算出来， i 与 j 不相等时有：

$$\frac{\partial P_j}{\partial z_i^{[L]}} = \frac{\partial}{\partial z_i^{[L]}} \left(\frac{e^{z_j^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}}} \right) = \frac{-e^{z_j^{[L]}} e^{z_i^{[L]}}}{\sum_{k=1}^{n_L} e^{z_k^{[L]}} \sum_{k=1}^{n_L} e^{z_k^{[L]}}} = -P_j P_i \quad (4-10)$$

将表达式（4-9）和表达式（4-10）分别结合表达式（4-8）可以得到以下公式：

$$\delta_i^{[L]} = \frac{\partial L_{new}}{\partial z_i^{[L]}} = \begin{cases} -(1 - P_j)^\gamma (1 - P_j - \gamma P_j \log P_j), & i = j \\ P_i (1 - P_j)^\gamma (1 - P_j - \gamma P_j \log P_j), & i \neq j \end{cases} \quad (4-11)$$

表达式（4-11）中的 i 的大小为 $1 \ll i \ll n_L$ ， n 为损失函数第 L 层神经元的总个数。根据公式（4-11）便可得到改进后的卷积神经网络 Resnet50 最后一层也就是 L 层的误差 $\delta^{[L]}$ ，根据卷积神经网络中的反向传播算法可以得到倒数第二层

以及倒数第三层甚至第一层的误差，因此可以计算出改进后的 softmax 函数每一层的权重以及偏置梯度，最后得到更新表达式获得更新后的权重和偏置。

改进前后的实验结果如图 4-6 所示，图 4-6 (a) 表示原损失函数的训练结果，图 4-6 (b) 表示改进之后损失函数的训练结果，对比结果显示改进之后的损失函数收敛效果明显优于改进前损失函数的收敛效果。




图 4-6 改进前后的损失函数对比示意图 (a) 改进前损失函数 (b) 改进后损失函数

4.4 基于行人重识别 Resnet50 网络残差块的改进设计

根据前面章节关于残差网络 Resnet50 的介绍可知，多个残差块串联后可以组成残差网络，前一个残差块的输出就变成了后一个残差块的输入，则可以把残差块的输入看作 s ，输出看作 $s^{(l)}$ ， h 为残差网络的目标函数，所以后一个残差块的输入为 $s^{(l)}$ 。则有：

$$s^{(1)} = h(F(s) + s) = h(W^{[l+1]}g(W^{[l]}s + b^{[l]}) + b^{[l+1]} + s) \quad (4-12)$$

上式为残差块的输出 s 的权重、和偏置 b 的函数，可以表示为：

$$F(s, W^{[0]}, b^{[0]}) = W^{[l+1]}g(W^{[l]}s + b^{[l]}) + b^{[l+1]} \quad (4-13)$$

根据公式 (4-12) 和 (4-13) 有下列表达式：

$$s^{(1)} = h(s + F(s, W^{[0]}, b^{[0]})) \quad (4-14)$$

把 $h(\cdot)$ 看作神经网络中的恒等函数，则有如下表达式：

$$s^{(1)} = s + F(s, W^{[0]}, b^{[0]}) \quad (4-15)$$

$$s^{(2)} = s^{(1)} + F(s^{(1)}, W^{[1]}, b^{[1]}) \quad (4-16)$$

根据表达式 (4-15) 以及 (4-16) 可以得到下一个残差块的输入 $s^{(2)}$ ：

$$s^{(2)} = s + F(s, W^{[0]}, b^{[0]}) + F(s^{(1)}, W^{[1]}, b^{[1]}) \quad (4-17)$$

同理可得关于第 n 个残差块的输出 $s^{(n)}$ 可以表示为:

$$s^{(n)} = s + F(s, W^{[0]}, b^{[0]}) + \sum_{i=1}^{n-1} F(s^{(i)}, W^{[i]}, b^{[i]}) \quad (4-18)$$

根据上述表达式, 卷积神经网络中的多层节点特征由函数相加运算所得, 参与计算的有网络初始单元, 网络多层节点参数函数, 前文提到的 plain 网络中的特征可以根据矩阵向量相乘得到, 在反向传播和链式法则中的一条路径主要将信息回传, 而另外一条路径会经过所有带权重的网络层。

4.4.1 恒等残差块的改进设计

恒等残差块为卷积神经残差网络的重要组成部分, 原 Resnet50 卷积神经网络的恒等残差块如下图 4-7 所示:




图 4-7 原恒等残差块

原 Resnet50 卷积神经网络对应的恒等残差块实验参数信息如表 4-1 所示:

表 4-1 原恒等残差块实验参数信息

Main Path							
Input				$W \times H \times D$			
		num	kernel	strid	Padding	Output	Parameters
1	CONV	K	1 x 1	1	0	$W \times H \times K$	$1 \times 1 \times D \times K + K$
2	BN	--	--	--	--	$W \times H \times K$	--
3	ReLU	--	--	--	--	$W \times H \times K$	--
4	CONV	K	3 x 3	1	1	$W \times H \times K$	$3 \times 3 \times K \times K + K$
5	BN	--	--	--	--	$W \times H \times K$	--
6	ReLU	--	--	--	--	$W \times H \times K$	--
7	CONV	K	1 x 1	1	0	$W \times H \times K$	$1 \times 1 \times K \times K + K$
8	BN	--	--	--	--	$W \times H \times K$	--
Total		$(D + 10 \times K + 3) \times K$					

根据 4.4 节中的相关介绍，表达式 (4-14) 以及 (4-15) 中把 $h(\cdot)$ 当作了恒等函数，而本论文中采用的改进方法为将原恒等残差块中末尾的 ReLU^[33] 激活函数放在卷积层前面，因为在训练过程中，ReLU 激活函数可以使特征在进行卷积操作之前具有稀疏性，同时 ReLU 激活函数还可以减少特征间的关联性，通过此改进方法，我们可以得到一种新的恒等残差块，如下图 4-8 所示：



图 4-8 改进后的恒等残差块

根据图 4-8 可知，改进后的恒等残差块中的卷积操作在 ReLU 激活函数后面，同时将改进后的恒等残差块中的卷积核配置信息做了改变，因为参数数量过多会使卷积神经网络得到不准确的训练精度，导致模型最后的预测偏差很大。同时减少了前一个 1x1 卷积核的数量，对于后一个 1x1 卷积核的数量，则不改变，改进后的恒等残差块信息如下表 4-2 所示。

表 4-2 改进后的恒等残差块参数信息

Improved Identity Residual Block							
Main Path							
Input				$W \times H \times D$			
		num	kernel	strid	Padding	Output	Parameters
1	BN	--	--	--	--	$W \times H \times D$	--
2	ReLU	--	--	--	--	$W \times H \times D$	--
3	CONV	$K/4$	1×1	1	0	$W \times H \times K/4$	$D \times K/4 + K/4$
4	BN	--	--	--	--	$W \times H \times K/4$	--
5	ReLU	--	--	--	--	$W \times H \times K/4$	--
6	CONV	$K/4$	3×3	1	1	$W \times H \times K/4$	$(9 \times K/4 + 1) \times K/4$
7	BN	--	--	--	--	$W \times H \times K/4$	--
8	ReLU	--	--	--	--	$W \times H \times K/4$	--
9	CONV	K	1×1	1	0	$W \times H \times K$	$K/4 \times K + K$
Total		$(4 \times D + 13 \times K + 24) \times K/16$					

在表 4-2 中,改进后的恒等残差块是基于旧的恒等残差块实现的,从表中可以看出卷积核大小为 1×1 的卷积操作分别添加在了卷积核大小为 3×3 的操作前后,通过 1×1 的卷积操作可以改变特征映射的尺寸大小或者通道数,但是从上表中可以看出,图像特征的维度并没有改变,但参数的数目发生了变化。

在表 4-2 中,可以使用 BN(Batch Normalization)^[34]方法有效地解决卷积神经网络无法收敛的问题,改进后的恒等残差块第二层为 ReLU 激活函数层,而第三层是 1×1 的卷积层,由于卷积核数量减少到原来的四分之一,所以参数也会减少。

改进后的恒等残差块的第四层的特征映射尺寸大小不会改变,因为它为批处理归一化层,而且结构与前几层结构类似,输出维度也类似。

改进后的恒等残差块的第五层为激活函数层,输出特征维度与上一层一致。

改进后的恒等残差块的第六层的卷积核数量发生了变化,卷积核尺寸为 3×3 ,步长和填充值都为 1。

改进后的恒等残差块第七层至第九层与上述类似。

根据表 4-1 以及 4-2 的数据对比可知,改进后的恒等残差块不仅可以增加卷积神经网络的深度,而且大大减少了参数的数量,所有的参数数量为原来的 $1/4$ 。

4.4.2 卷积残差块的改进设计

除了对行人重识别中的恒等残差块进行改进之外,本文还对卷积残差块进行了改进。在叙述改进后的卷积残差块之前,可以先了解原 Resnet50 的卷积残差块,如图 4-9 所示。




图 4-9 原卷积残差块

卷积残差块不同于恒等残差块,卷积残差块除了包含主路径连接,还包含了 shortcut 连接,改进后的卷积残差块中添加了 1×1 的卷积核,其 stride 为 2, padding 为 0,则输出的特征映射减半,原卷积残差块对应的实验参数信息如表 4-3 所示。

表 4-3 原卷积残差块参数信息

Main Path							
Input				$W \times H \times D$			
		num	kernel	strid	Padding	Output	Parameters
1	CONV	K	1×1	2	0	$W/2 \times H/2 \times K$	$1 \times 1 \times D \times K + K$
2	BN	--	--	--	--	$W/2 \times H/2 \times K$	--
3	ReLU	--	--	--	--	$W/2 \times H/2 \times K$	--
4	CONV	K	3×3	1	1	$W/2 \times H/2 \times K$	$3 \times 3 \times K \times K + K$
5	BN	--	--	--	--	$W/2 \times H/2 \times K$	--
6	ReLU	--	--	--	--	$W/2 \times H/2 \times K$	--
7	CONV	K	1×1	1	0	$W/2 \times H/2 \times K$	$1 \times 1 \times K \times K + K$
8	BN	--	--	--	--	$W/2 \times H/2 \times K$	--
shortcut							
1	CONV	K	1×1	2	0	$W/2 \times H/2 \times K$	$1 \times 1 \times D \times K + K$
2	BN	--	--	--	--	$W/2 \times H/2 \times K$	--
Total		$(2 \times D + 10 \times K + 4) \times K$					

基于原 Resnet50 卷积残差块改进的理念是把激活函数 ReLU 提到卷积操作之前，改进后的卷积残差块架构图如下图 4-10 所示。




图 4-10 改进后的卷积残差块

改进之后的卷积残差块主要分为两部分，一部分是 **main path** 上的操作，还有一部分是 **shortcut** 上的操作，**main path** 上的操作首先是归一化批处理操作，接着实现激活函数操作，然后通过卷积神经网络的卷积层实现卷积操作，其目的是为了将网络中的参数数量减少，由于 **main path** 上卷积核的大小与 **shortcut** 上的卷积核大小不一致，之前的卷积神经网络 Resnet50 是用 1x1 的卷积核来实现减小特征映射尺寸的目的，而现在改进后的卷积神经网络 Resnet50 是用 3x3 的卷积核来减小特征映射尺寸。表 4-4 为改进后的卷积残差块参数信息。

表 4-4 改进后的卷积残差块参数信息

Improved Convolutional Residual Block							
Kernel							
		Number	Type	Stride	Padding	Output	Parameter
1	BN	--	--	--	--	$W \times H \times D$	--
2	ReLU	--	--	--	--	$W \times H \times D$	--
3	CONV	$K/4$	1×1	1	0	$W \times H \times K/4$	$(D+1) \times K/4$
4	BN	--	--	--	--	$W \times H \times K/4$	--
5	ReLU	--	--	--	--	$W \times H \times K/4$	--
6	CONV	$K/4$	3×3	2	1	$W/2 \times H/2 \times K/4$	$13 \times K/16$
7	BN	--	--	--	--	$W/2 \times H/2 \times K/4$	--
8	ReLU	--	--	--	--	$W/2 \times H/2 \times K/4$	--
9	CONV	K	1×1	1	0	$W/2 \times H/2 \times K$	$(K/4+1) \times K$
shortcut							
1	BN	--	--	--	--	$W \times H \times D$	--
2	ReLU	--	--	--	--	$W \times H \times D$	--
3	CONV	K	1×1	2	0	$W/2 \times H/2 \times K$	$D \times K + K$
Total		$(20 \times D + 4 \times K + 49) \times K/16$					

从表 4-4 可以看出卷积残差块的 main path 部分和恒等残差块的 main path 部分大致相同，唯一发生变化的是卷积核的滑动步长，它的值由 1 变为了 2，但是填充值的大小从未改变，因此输出特征的维度将会发生改变，但是 main path 上的参数不会发生改变，因为两部分的卷积核数量是相等的。

在上述改进后的卷积残差块的参数配置中可以看到 main path 上的图像维度缩小了 2 倍，而为了使最后的特征输出结果形式一致，需要在 shortcut^[35]路径中添加一个卷积操作，这样就能和 main path 上的特征输出维度保持一致，由于在

shortcut 路径上增加了新的 1×1 卷积核，所以总体的参数数量也增加了。

4.5 行人重识别算法设计

这一部分主要介绍行人重识别任务中的算法设计思路以及具体的实现过程，而行人重识别任务的本质是深度卷积神经网络，所以算法主要指前向传播和后向传播算法，后续内容首先会介绍算法的相关知识，然后进行设计与实现的阐述。

4.5.1 行人重识别算法总体设计

如图 4-11 所示，同传统神经网络一样，改进的 Resnet50 卷积神经网络的算法流程由前向传播^[40]和反向传播^[41]组成。前向传播主要是指由卷积神经网络的输入层为起点，卷积神经网络的输入层为终点的传播方式，而反向传播以网络的后端输出层为起点，把误差从后往前层层传播，一直传播到网络的起始输入层。




图 4-11 传统的浅层神经网络架构

在算法设计过程中，首先需要准备数据样本标签，由于主要任务是对行人做重识别，因此每个行人都有属于自己的标签，每个标签代表着对应的行人编号。除此之外，改进后的残差网络 Resnet50 在行人重识别数据训练之前，需要设置网络的训练临界值，便于终止网络的训练，训练临界值主要是卷积神经网络模型的误差最小值，当达到最小值时，说明网络的学习效果是最好的，而网络的最大训练次数也是基于临界值，结束点由最大训练次数决定。

4.5.2 行人重识别前向传播流程设计

前向传播流程在前述章节介绍卷积神经网络的时候就已经提及到，包括在使

用深度卷积神经网络对行人图像特征提取的过程中，行人重识别图像首先被输入至深度卷积神经网络的输入层中，然后向前至网络的卷积层进行卷积操作，包括接下来的下采样操作以及全连接操作，直到最后网络的输出，都属于前向传播的内容，具体的流程可以用下图表示出来。




图 4-12 前向传播流程图

前向传播算法具体实现步骤如下：

1. 首先将 Resnet50 预训练模型进行加载，因为 Resnet50 预训练模型包含了权重和参数，加载的目的为进行改进后的卷积神经网络 Resnet50 参数初始化。

2. 根据行人骨骼关键点以及对应的行人图像进行分割后的数据输入到改进后的 Resnet50 卷积神经网络模型中，并经过第一个卷积层 block1 进行卷积操作，然后经过池化层 block1，进行池化操作。

3. 第一个池化层 block1 的输出作为第二个卷积层 block2 的输入，经过再次卷积操作之后，对 block2 进行池化操作。

4. block2 池化层的输出成为了 block3 卷积的输入，然后继续 block3 池化操作。

5. block4 的卷积操作以及池化操作，block5 的卷积操作以及池化操作都和前面的操作一致。

6.block5 池化操作的输出为 block6 卷积层操作的输入,经过卷积操作后便输出。

7.block7 的输入为 block6 的输出,将 block7 输入进行均值化以及归一化、卷积、反池化操作。

8.block6 以及 block7 的输出作为 block 8 计算反卷积的的输入。

9.输入到反卷积层之后进行下采样操作再经过 softmax 层可以实现分类操作。

4.5.3 行人重识别反向传播流程设计

反向传播流程与前向传播流程相对应,我们可以通过反向传播中误差的改变情况以及网络各个层的权重来计算梯度值,然后不断更新网络各层的参数,改进后的卷积神经网络 Resnet50 就会不断的进行训练,反向传播流程的顺序可以细分为以下几个方面:

1.根据 4.2.2 节介绍的前向传播算法可以计算得到网络中的误差,然后根据反向传播算法实现网络由后向前计算网络的误差值,从 bolck8 反卷积层开始计算。

2.依次从 block8 反卷积层到 block7 以及 block 6 卷积层进行卷积操作,按照类似的规则继续进行反向传播,一直传播到网络的输入层然后才结束。

3.网络各层的参数更新操作将在所有的误差传递完成后执行,而参数的更新方向为反向更新,起点为 SoftMax 层,其依次向前更新,一直到网络的输入端结束。反向传播算法流程如下图 4-13 所示。



图 4-13 反向传播流程图

4.6 改进后的基于行人重识别 Resnet50 网络主体结构设计

根据前述章节介绍的卷积神经网络 Resnet50^[36]的改进内容,包括神经网络的输入层,损失函数以及神经网络的残差块,改进后残差网络结构的主体部分如下图所示。




图 4-14 改进后的卷积神经网络主体结构

根据图 4-14 残差网络的结构可知，网络结构从上而下可以分为七个阶段，最开始是输入数据处理，其次结构的中间过程包含了改进后的卷积残差块以及改进后的恒等残差块，最后添加了新的全连接层，改进后的卷积神经网络主体结构中各个部分实验数据信息如表 4-5 所示。

表 4-5 网络残差块详细信息

		INPUT	OUTPUT	PARAMETER
1	CONV	64x64x3	64x64x128	1,792
	BN	64x64x128	64x64x128	—
	ReLU	64x64x128	64x64x128	—
	MAX POOL	64x64x128	32x32x128	—
2	CONV BLOCK	64x64x128	16x16x128	49,408
	ID BLOCK×2	16x16x128	16x16x128	90,496
3	CONV BLOCK	16x16x128	8x8x256	180,736
	ID BLOCK×3	8x8x256	8x8x256	541,824
4	CONV BLOCK	8x8x256	4x4x512	721,920
	ID BLOCK×5	4x4x512	4x4x512	3,608,320
5	CONV BLOCK	4x4x512	2x2x1024	2,885,632
	ID BLOCK×2	2x2x1024	2x2x1024	5,770,240
6	Flatten	1x1x2048	1x1x2048	—
	FC	1x1x2048	1x1x1501	3,074,048
Total		16,924,416		

根据表 4-5 可知，第一部分主要由 3x3 的卷积层，批处理归一化层，ReLU 层和一个 2x2 的池化层组成，3x3 卷积核的滑动步长以及填充的值相等，而池化层的参数之所以设为 2x2，是因为可以降低输出特征的维度。

行人图片预处理操作通常都是在输入到卷积神经网络之前进行，而本实验中行人的重识别图像数据经过分割后的大小为 64x64x3，那么经过第一阶段卷积操作之后的特征映射输出为 64x64x128，根据图 3-13 的参数配置信息可计算得到。

第二部分主要由两个卷积残差块和两个恒等残差块组成，通道数大小一致都是 128，当通过卷积残差块之后，提取到的图像特征大小会缩小 2 倍，而经过网络中的恒等残差块操作之后，网络模型提取到的行人图像特征大小不会改变。

第三部分主要由卷积残差块和恒等残差块组成，如果保留有效的行人特征，可以将特征映射通道的数目设为 256，那么第三部分的输出特征维度不变，而且提取到的特征具有更高的区分度。

第四部分以及第五部分的模块配置信息与第三部分类似，通道数量为上一阶段的两倍，原理与第三部分类似。

最后一个部分主要将第五部分的输入特征映射平铺展开，第五部分的输入特

征映射为 $2 \times 2 \times 1024$ ，因此经过平铺后的输入特征映射为 $1 \times 1 \times 1024$ 。由于在第四章实验中的数据集分为很多类，比如以第一个实验为例，分为 1501 类，所以改进后的网络最终输出个数设为 1501。

改进后的 Resnet50 卷积神经网络主要被用来提取行人图像的特征，由于行人图像被分成了相同大小的三部分，为了保持最后行人特征的完整性，因此三分行人图像会分别输入到改进后的卷积神经网络中，整个流程如图 4-15 所示。




图 4-15 特征提取流程

4.7 基于深度学习的行人重识别系统设计

基于前述章节的理论知识介绍，本节主要提出采用微调^[52]的方法进行改进后的卷积神经网络训练，训练完成后便可以得到最后的神经网络模型，使用模型来提取行人重识别中的行人图像，提取全连接层的特征，通过 Relu 函数将获取到的特征进行稀疏表示，便得到最后的行人图像特征向量，系统结构图如下：




图 4-16 行人重识别系统结构

图 4-16 表示改进后的卷积神经网络部分系统架构图。首先通过 OpenPose^[53] 工具将行人图像的骨骼关键点提取出来，然后基于骨骼关键点进行图像分割，分割成互相重叠的三部分，将行人的三部分图片特征通过之前训练的深度卷积神经网络模型提取出来，最后将行人的三部分特征进行组合，组合成完整的行人特征然后进行分类，最后得到行人重识别的实验结果。

下图 4-17 为图 4-16 对应的网络系统输出架构图。




图 4-17 系统结构输出图

4.8 本章小结

本章详细阐述了改进后的 Resnet50 卷积神经网络，结合目前具有前瞻性的理论思想，确定了以 Resnet50 为大框架的卷积神经网络设计，其中改进了原有 Resnet50 卷积神经网络的输入层，损失函数，以及网络的残差块，并做了详细的介绍，同时在网络中的每一个卷积层之前都添加了 BN 归一化操作，尽量避免梯度消失的问题。与此同时，还介绍了行人重识别算法的设计，包括算法总体设计思路以及前向传播流程和反向传播流程算法设计。

第五章 改进后的行人重识别 Resnet50 模型的实现

本章主要介绍了行人重识别算法实现的具体过程,同时将改进后的网络模型分别在 Market-1501^[37]行人重识别数据集以及 DukeMTMC-reID^[38]行人重识别数据集上进行了实验,并详细描述了实验平台的配置信息,将改进后的卷积神经网络模型的行人重识别实验结果与其他网络模型的实验结果做了对比与分析,然后通过实验分析来突出改进后的 Resnet50 卷积神经网络模型的性能和优势。

5.1 行人重识别算法的实现

根据第 4 章中的行人重识别算法的设计思路,我们可以得到算法的实现方案,可以通过使用 Ubuntu 系统运行编码好的 python 代码,代码主要包含两部分,第一个部分主要是改进后的卷积神经网络 Resnet50 的前向传播算法实现,第二个部分主要是改进后的卷积神经网络 Resnet50 的反向传播算法实现,当开始进行数据训练,数据测试,前向以及反向计算时,参数更新工作时主要由 GPU 完成。本实验系统中, GPU 的运行工作主要基于 cuda8.0,由于硬件性能的不断提升,网络的计算效率通过 GPU 的运行得到了巨大的增加,同时也节省了很多运行时间,让科研工作者可以更加高效地完成相关的工作。

根据改进后的 Resnet50 卷积神经网络以及结合所提出的算法思想,本文实现了视频中行人图像的重识别,具体实现过程如下:

- 1.首先将训练数据集进行图像预处理,把行人图像的骨骼关键点^[42]提取出来。
- 2.根据行人骨骼的关键点以及对应的行人图像可以将图像分割成三部分,然后分别将这三部分图像数据输入到改进后的卷积神经网络 Resnet50 中进行数据的训练。
- 3.在训练过程中,会有一系列权重文件产生,权重文件的保存可以避免训练过程中断后需要从头开始训练的问题。
- 4.当改进后的卷积神经网络 Resnet50 训练达到临界值之后会输出神经网络的权重,即为最后的结果文件,通过使用最终的权重文件可以实现行人重识别检测。
- 5.部分前向传播算法的源代码如图 5-1 所示:

```
def conv_forward(A_prev,W,b,hparameters):
    (m,n_H_prev,n_W_prev,n_C_prev)=A_prev.shape
    (f,f,n_C_prev,n_C)=W.shape
    stride=hparameters['stride']
    pad=hparameters['pad']
    n_H=1+int((n_H_prev-f+2*pad)/stride)
    n_W=1+int((n_W_prev-f+2*pad)/stride)
    Z=np.zeros((m,n_H,n_W,n_C))#init output
    A_prev_pad=zero_pad(A_prev,pad)
    for i in range(m):
        a_prev_pad=A_prev_pad[i]
        for h in range(n_H):
            for w in range(n_W):
                for c in range(n_C):
                    vert_start=h*stride
                    vert_end=vert_start+f
                    horiz_start=w*stride
                    horiz_end=horiz_start+f
                    a_slice_prev=a_prev_pad[vert_start:vert_end,horiz_start:horiz_end,:]
                    Z[i,h,w,c]=np.sum(np.multiply(a_slice_prev,W[:, :, :, c])+b[:, :, :, c])
```

图 5-1 部分前向传播算法代码实现

部分后向传播算法的源代码如下图 5-2 所示，两部分代码是网络训练权重的重要部分，在文章对应的代码里包含了对应的网络架构文件以及所需的起始权重文件，还有改进后的卷积神经网络 Resnet50 设定的临界值，有了临界值卷积神经网络在训练完毕之后就会自动输出模型的权重，同时网络会以固定的格式自动地保存这些权重文件。

```
def backprop(self, x, y):
    nabla_b = [np.zeros(b.shape) for b in self.biases]
    nabla_w = [np.zeros(w.shape) for w in self.weights]
    # feedforward
    activation = x
    activations = [x] # list to store all the activations, layer by layer
    zs = [] # list to store all the z vectors, layer by layer
    for b, w in zip(self.biases, self.weights):
        z = np.dot(w, activation) + b
        zs.append(z)
        activation = sigmoid(z)
        activations.append(activation)

    delta = self.cost_derivative(activations[-1], y) * \
        sigmoid_prime(zs[-1])
    nabla_b[-1] = delta
    nabla_w[-1] = np.dot(delta, activations[-2].transpose())

    for l in xrange(2, self.num_layers):
        z = zs[-l]
        sp = sigmoid_prime(z)
        delta = np.dot(self.weights[-l + 1].transpose(), delta) * sp
        nabla_b[-l] = delta
        nabla_w[-l] = np.dot(delta, activations[-l - 1].transpose())
    return (nabla_b, nabla_w)
```

图 5-2 部分后向传播算法代码实现

5.2 行人重识别实验环境配置

论文中的相关实验主要在意大利帕维亚大学的计算机视觉与多媒体实验室里完成，实验过程中使用的操作系统为 Ubuntu14.04，操作系统的位数为 64 位，使用 python 作为算法实现的编程语言，同时通过使用深度学习框架 Keras^[43]和 Tensorflow 作为改进卷积神经网络 Resnet50 的主要框架，与此同时还使用了 Cuda8.0 进行 GPU 加速操作，由于在深度学习研究领域中对图像数据的处理基本为矩阵运算，因此选择 GPU 来进行矩阵运算将会节省很多时间，而且能在一定程度上提高计算的效率，本次实验中每一类数据集的迭代次数为 50 次，训练总时间约为 10 小时，实验的参数明细如表 5-1 所示。

表 5-1 实验参数信息

Software	Configuration
Operating System	Ubuntu14.04 64 bits
Programming Language	Python
Structure	Keras/Tensorflow

5.3 行人重识别网络训练方式

在行人重识别网络训练方式中，深度卷积神经网络的训练方式主要由主动学习^[45]和在线学习^[44]以及批量学习^[44]组成，网络的具体训练方式根据网络结构还有行人重识别的数据集规模而决定，为了更好地说明网络训练方式对网络最后的训练结果产生的影响，我们将在线学习以及批量学习的优势和劣势进行细致的对比，同时选择比较适合改进后的 Resnet50 残差网络结构的方法来进行网络模型的训练。

第一种为批量学习。我们所了解的机器学习方法包含监督学习^[46]以及非监督学习^[47]，而在监督学习的批量方法中，在训练数据集中所有样本的例子出现后，多层感知器的突触权值将会调整，与此同时，多层感知器的突触权值的调整基于回合到回合的连接。

首先我们需要做的是准备好行人重识别的行人图像样本以及对应的标签，数据准备好以后分批次进行网络的训练，训练过程中可以得到网络的学习平均误差，以此来计算损失函数，批量学习的好处可以概括为以下几点：

1.批量学习可以不受训练图像样本顺序的限制，不会因为样本顺序的因素而对网络造成影响，可以提升网络的性能。

2.在批量学习中可以精确地估计梯度向量,使网络可以快速地收敛。

3.批量学习可以并行化进行样本训练。

第二种就是在线学习,在线学习主要将输入的行人重识别数据图像进行依次学习,而且每次学习的图像数量为1,通过比较网络的输出误差和真实的网络误差值可以得到损失函数,得到损失函数后便可以即时更新网络的参数,而且网络参数的更新速度很快,之后每一个新的数据样本都会受到网络参数更新的影响,所以新的数据样本和网络参数之间的关系很紧密。

在线学习的优点可以总结如下:

1.在线学习中网络的参数更新基于单一图像,因此模型的参数可以在短时间内得到更新,而且模型可以实时地得到更新。

2.在线学习算法的实现过程并不复杂,而且执行难度也不大。

3.在线学习中往往能对大规模数据的分类任务提供最优解。

4.单个样本的随机性能可以有效预防网络参数更新陷入局部极值点,对系统存储容量要求较低。

基于上述批量学习方式以及在线学习方式的比较,批量学习的方式更适合改进后的卷积神经网络 Resnet50 训练,因为批量学习可以随机的选取行人图像数据,没有先后顺序之分,这样还保证了网络训练的客观性以及有效性,所以后续实验将采用批量学习对改进后的卷积神经网络模型 Resnet50 进行训练。

5.4 行人重识别网络训练细节

改进后的 Resnet50 卷积神经网络是一个包含了 50 层的残差网络,而网络训练的参数对于神经网络的收敛至关重要,不合理的参数设置会影响最后的训练结果,使得行人特征的学习效果较差,不同的卷积神经网络在选择参数以及超参数^[48]时考虑的因素也不同,同时超参数的设置也很重要,超参数的选择主要依据网络训练的数据集规模、属性以及卷积神经网络的架构,比如当我们一开始就将参数的值设置的很大,在进行网络训练时,损失函数的值一开始不会减小,相反可能会出现增加的情况,那么我们此时应该根据实际情况适当地减小学习率,学习率会在刚开始的迭代过程中出现下降的情况。此时的学习率就是我们需要的阈值,而一旦超过了这个阈值,网络的收敛效果就会变差。

但在网络的训练过程中,阈值一直在变化,而且网络的权重也在不断地更新。

5.4.1 行人重识别网络学习率

卷积神经网络中学习率^[49]的大小反映了网络参数更新步长的大小,如果学

习率一开始过高，那么步长会很大，虽然到达最优解附近的时间最短，但是权重参数却很可能超过最优解。反之，如果学习率太小，网络会需要更多的时间去优化，所以神经网络的学习率太大或者太小都不适合网络的训练。

为了更加清晰地、直观地了解学习率，可以对比图 5-3 中不同学习率的变化对网络收敛效果的影响情况，一开始如果增大学习速率的值，网络模型的 loss 值会增大，如果一开始减小学习速率的值，但使学习速率的值保持在最佳学习率之上，那么损失函数的值会降低，直至趋于一个平稳的范围不再变化。如果学习率被减小直至最佳学习率，网络模型的损失值在训练的前半环节下降速度变慢了，后半环节会变得相对较低。如果学习率过小，网络模型的损失值下降的很缓慢，没有停止的趋势，因为迭代次数还不够多，当迭代次数够多时，损失值才会下降的更低。

综上，过高或者过低的学习率都不适合。




图 5-3 学习率对模型损失值的影响

根据上述原则，本论文用改进后的 Resnet50 卷积神经网络在不同的数据集上做了多次实验，实验结果显示图 5-4 中的学习速率使得改进后的卷积神经网络 Resnet50 的实验效果最好，图中横坐标为卷积神经网络训练时的迭代次数，纵坐标为对应的学习率。




图 5-4 较优的学习率

图 5-5 为经过优化之后的损失函数改变趋势，而且不同训练次数下的损失函数数值也不一样。




图 5-5 实验中优化后的损失函数值

如图 5-5 所示，图中横坐标为卷积神经网络训练时的迭代次数，纵坐标为对应的 loss 值。深蓝色的曲线为训练数据集上的 loss 值，而浅蓝色的曲线为测试集上的 loss 值。在图 5-4 中，网络最初训练阶段时，学习率设置的值比较大，为 0.1，根据图 5-5 可以看出训练集上的 loss 值在平稳地下降，那么表明这个时候的学习率设置的比较合理，但是随着网络训练的次数增加，loss 值的下降速度开始降低，验证集上的 loss 值变化也比较明显，说明此时的网络不稳定，学习率需要调整，当将学习率降低到 0.01 时，训练集和测试集的 loss 值下降的特别快，说明此时网络的性能非常好，学习速度也快。当训练集的 loss 值即将接近于 0 时，网络的拟合能力最优。继续将学习率降低到 0.001 时，训练集和测试集上的 loss 都很平稳，直至训练结束。

可以观察到改进后的卷积神经网络 Resnet50 的训练精确度为红色的标注，而改进后的卷积神经网络 Resnet50 的测试精确度为紫色的标注，所以改进后的卷积神经网络 Resnet50 的收敛情况要比原来的卷积神经网络 Resnet50 性能好，如图 5-6 所示，图中横坐标为卷积神经网络训练时的迭代次数，纵坐标为对应的准确度。




图 5-6 改进后的卷积神经网络 Resnet50 训练以及测试准确度

根据图 5-6 可知，改进后的卷积神经网络 Resnet50 在训练集以及测试集上的识别准确率有了明显的增加，而且改进后的卷积神经网络模型的总体性能也提升了许多。

5.4.2 行人重识别网络参数初始化

卷积神经网络模型中的参数初始化直接影响网络的训练效果，而且不恰当的激活函数，比如 $\text{sigmoid}^{[50]}$ 甚至会导致网络产生梯度消失的问题，所以正确的网络参数初始化不仅能减少网络收敛的时间，还能提高网络的准确率。

为了更好的了解本次实验网络参数初始化的原理，接下来的内容主要是对网络初始化的方式做详细的分析以及推导。

在参数初始化的实验推导过程中可以将网络中的偏置值设为零，其中 $\text{Var}(W^{(l)})$ 表示卷积神经网络中第一层参数的方差，然后 $z_j^{[l]}$ 可以表示为第 j 个神经元的加权输入值，那么可以得到第 1 层的权重方差 $\text{Var}(z^{[l]})$ ：

$$\text{Var}(z^{[l]}) = \text{Var}(z_j^{[l]}) = \text{Var}\left(\sum_{k=1}^{n_{l-1}} W_{jk}^{[l]} a_k^{[l-1]} + b_j^{[l]}\right) \quad (5-1)$$

根据上式 (5-1) 可知 $W_{jk}^{[l]}$ 为权重参数，由于两个独立变量和的方差等于两个变量方差的和，那么可以得到如下表达式：

$$\text{Var}(z^{[l]}) = \text{Var}\left(\sum_{k=1}^{n_{l-1}} W_{jk}^{[l]} a_k^{[l-1]} + b_j^{[l]}\right) = \sum_{k=1}^{n_{l-1}} \text{Var}(W_{jk}^{[l]} a_k^{[l-1]}) \quad (5-2)$$

如果改进后的卷积神经网络 Resnet50 的权重参数符合 (5-2) 表达式, 则有:

$$\text{Var}(z^{[l]}) = \sum_{k=1}^{n_{l-1}} \text{Var}(W_{jk}^{[l]} a_k^{[l-1]}) = \sum_{k=1}^{n_{l-1}} \text{Var}(W_{jk}^{[l]}) \text{Var}(a_k^{[l-1]}) \quad (5-3)$$

由于公式 (5-3) 中 $W_{j1}^{[l]}, W_{j2}^{[l]} \dots W_{jn_l}^{[l]}$ 与 $W^{[l]}$ 同分布, 则可以将 (5-3) 化简为:

$$\text{Var}(W_{jk}^{[l]}) = \text{Var}(W^{[l]}) \quad (5-4)$$

$a_1^{[l-1]}, a_2^{[l-1]}, \dots, a_{n_{l-1}}^{[l-1]}$ 之间的元素相互独立并且和 $a^{[l-1]}$ 遵循相同的变化原则, 则有:

$$\text{Var}(a_k^{[l-1]}) = \text{Var}(a^{[l-1]}) \quad (5-5)$$

从而有:

$$\text{Var}(z^{[l]}) = \sum_{k=1}^{n_{l-1}} \text{Var}(W^{[l]}) \text{Var}(a^{[l-1]}) = n_{l-1} (W^{[l]}) \text{Var}(a^{[l-1]}) \quad (5-6)$$

根据这种情况可以假设激活函数 $g(\cdot)$ 为恒等函数, 那么 $a^{[l-1]}$ 等于 $z^{[l-1]}$, 则公式可以简化为:

$$\text{Var}(z^{[l]}) = n_{l-1} \text{Var}(a^{[l-1]}) \text{Var}(W^{[l]}) = n_{l-1} \text{Var}(z^{[l-1]}) \text{Var}(W^{[l]}) \quad (5-7)$$

则有:

$$\text{Var}(z^{[l]}) = n_{l-1} \text{Var}(z^{[0]}) \prod_{i=1}^l n_{i-1} \text{Var}(W^{[i]}) \quad (5-8)$$

所以如果我们希望所有加权输入的方差相等, 那么需要保证 $\text{Var}(W^{[l]}) = \frac{1}{n_{l-1}}$, 关于第 L 层则有:

$$\text{Var}(W^{[l]}) = \frac{1}{n_{l-1}} \quad (5-9)$$

在参数初始化过程中, 对于反向传播中的误差在网络各个层级中如果都相

等，L-1 层第 j 个神经元的误差为 $\delta_j^{[l-1]}$ ，那么有：

$$\text{Var}(\delta_j^{[l-1]}) = \text{Var}\left(\delta_j^{[l-1]}\right) = \text{Var}\left(\frac{\partial g_{l-1}(z^{[l-1]})}{\partial z^{[l-1]}} \sum_{k=1}^{n_l} W_{kj}^{[l]} \delta_k^{[l]}\right) \quad (5-10)$$

根据前述内容可知，假设激活函数 $g_{l-1}(\cdot)$ 为恒等函数，则表达式 (5-10) 可以表示为：

$$\text{Var}(\delta_j^{[l-1]}) = \text{Var}\left(\delta_j^{[l-1]} \sum_{k=1}^{n_l} W_{kj}^{[l]} \delta_k^{[l]}\right) = \sum_{k=1}^{n_l} \text{Var}(W_{kj}^{[l]} \delta_k^{[l]}) \quad (5-11)$$

基于表达式 (5-9) 以及表达式 (5-10) 中的权重输出公式，假设权重误差服从独立分布，那么可以得到：

$$\text{Var}(\delta_j^{[l-1]}) = \sum_{k=1}^{n_l} \text{Var}(W_{kj}^{[l]} \delta_k^{[l]}) = \sum_{k=1}^{n_l} \text{Var}(W_{kj}^{[l]} \delta_k^{[l]}) \quad (5-12)$$

同理于公式 (5-4) 以及 (5-5)，则对于 $k=1,2,\dots,n_l$ 有如下表达式：

$$\text{Var}(W_{kj}^{[l]}) = \text{Var}(W^{[l]}) \quad (5-13)$$

$$\text{Var}(\delta_k^{[l]}) = \text{Var}(\delta^{[l]}) \quad (5-14)$$

从而有：

$$\text{Var}(\delta_j^{[l-1]}) = \sum_{k=1}^{n_l} \text{Var}(W_{kj}^{[l]}) \text{Var}(\delta_k^{[l]}) = \sum_{k=1}^{n_l} \text{Var}(W^{[l]}) \text{Var}(\delta^{[l]}) \quad (5-15)$$

那么可以得到递推公式：

$$\text{Var}(\delta_j^{[l-1]}) = \sum_{k=1}^{n_l} \text{Var}(W^{[l]}) \text{Var}(\delta^{[l]}) = n_l \text{Var}(W^{[l]}) \text{Var}(\delta^{[l]}) \quad (5-16)$$

如果运用公式 (5-16) 则有：

$$\text{Var}(\delta_j^{[l-1]}) = n_l \text{Var}(W^{[l]}) n_{l+1} \text{Var}(W^{[l+1]}) \text{Var}(\delta^{[l+1]}) \quad (5-17)$$

如果进行递推操作，递推到第 L 层，那么有：

$$\text{Var}(\delta^{[l]}) = \text{Var}(\delta^{[L]}) \prod_{i=1}^l n_i \text{Var}(W^{[i]}) \quad (5-18)$$

为了保持实验中的反向传播误差不变性，需要满足下列约束条件：

$$\text{Var}(W^{[l]}) = \frac{1}{n_l} \quad (5-19)$$

一般情况下卷积神经网络中的第 L 层和 L 的前一层的网络节点数量不会相等，可以将公式 (5-9) 以及 (5-19) 变形得到 $n_{l-1}\text{Var}W^{[l]} = 1$ 和 $n_l\text{Var}W^{[l]} = 1$ ，则有如下表达式：

$$\text{Var}(W^{[l]}) = \frac{2}{n_{l-1} + n_l} \quad (5-20)$$

如果某区间的最小值和最大值分别为 a 和 b ，而变量服从这个区间的均匀分布，那么变量的方差为 $\frac{(b-a)^2}{12}$ ，只有当 b 的值为 $-a$ ，权重的均值才为零，则有如下表达式：

$$\frac{(b-a)^2}{12} = \frac{(-a-a)^2}{12} = \frac{2}{n_{l-1} + n_l} \quad (5-21)$$

所以参数初始化按照下面的均匀分布 (5-22) 进行：

$$W \sim U\left[-\frac{\sqrt{6}}{\sqrt{n_{l-1}+n_l}}, \frac{\sqrt{6}}{\sqrt{n_{l-1}+n_l}}\right] \quad (5-22)$$

5.4.3 行人重识别网络超参数配置

在改进后的卷积神经网络 Resnet50 中，训练过程中的最大训练次数根据网络的临界值而定，而训练的时候网络的归一化批处理可以有效地避免训练过拟合问题，越小的权重包含的复杂性也就越低，因此网络参数会具有更高的鲁棒性。针对网络训练过拟合的原因，有总结如下：

第一可能是训练次数太多导致模型的复杂度增加，当验证集上的准确率不再增加时可以停止训练，这样可以避免过拟合^[51]的问题。同时在实验中我们无法预测准确率何时会达到饱和状态，可能会让网络反复训练。

第二个原因可能是用于深度卷积神经网络训练的行人数据集数量太小，导致卷积神经网络模型学习到的行人特征过于局限，容易使网络快速达到饱和状态，因此可以采取增加训练数据量的方式来解决这个问题。

在损失函数后面添加一个惩罚项以便于对大的权重进行惩罚，避免网络训练中产生的过拟合问题，以便使卷积神经网络的收敛速度更快，模型得到最佳性能的时间也更短，在改进后的卷积神经网络 Resnet50 训练中 decay 的数值为 0.000001。

同时为了加速网络模型的收敛速度，可以设置超参数动量。网络模型中的参数是根据梯度来决定的，当目前时刻的梯度和历史时刻梯度的方向相同时，动量可以使新的趋势得到加强，如果不同的话，那么当前时刻的梯度趋势会被减弱。如果不设置动量超参数，卷积神经网络模型会花费大量的时间计算最优解，而且网络的收敛速度较慢，因此在卷积神经网络的训练过程中都会根据网络架构以及优化器等具体情况来选择动量超参数的数值，本实验中的超参数设置细节如下图所示。

```
# model configuration
model = Model(
    input=[head_input, torso_input, leg_input],
    output=out)

sgd = SGD(lr=1e-3, decay=1e-6, momentum=0.9, nesterov=True)
model.compile(loss='categorical_crossentropy',
              optimizer=sgd,
              metrics=['accuracy'])

print(model.summary())
```

图 5-7 超参数配置情况

5.5 行人重识别实验仿真结果和对比

改进后的 Resnet50 卷积神经网络在行人重识别公共数据集 Market1501 以及 DukeMTMC-reID 上进行了训练与测试，本节也会对实验结果做详细的分析。

5.5.1 行人重识别图片数据库

本次实验中使用的公共行人重识别数据集一共包含两类，第一类是行人重识别数据集 Market1501，第二类是行人重识别数据集 DukeMTMC-reID。

Market1501 数据集是行人重识别领域以及其他各类相关竞赛的公用数据库，比如 Kaggle 比赛^[54]。其他许多经典或比较前沿的行人重识别算法为了进行网络性能测试，都会在此数据库上进行相关的实验，现在已经被称为公认的行人重识别算法测试库。Market1501 行人重识别数据集中包含了 6 个不同的监控摄像头，其中有 5 个高分辨率的监控摄像头以及一个低分辨率监控摄像头。Market1501 行人重识别数据集包含了属于 1501 个行人实体的 32668 标注框，每一个行人实体最多能出现在 6 个摄像头中，而每一个被标注的行人实体至少出现在两个摄像头中，因此可以实现交叉摄像头间的行人检索，公用的 Market1501 行人重识别数据集包含了以下三个特征属性：

1. Market1501 行人重识别数据集使用了可变型组件模型^[55]，主要用来检测行人的位置，如图 5-8 所示，其包含了三幅图片，中图的像素值明显高于左图的像素值，并且中图的检测准确度也高于左图的准确度，而右图是左图和中图对应的空间模型。




图 5-8 可变型组件模型（DMP）

2. Market1501 行人重识别数据集中除了包含正确的图像边框外，还有一些错误警告的检测结果。

3. 行人重识别公用数据集 Market1501 中的每一个行人实体可能有多张在不同摄像机下拍摄的图像，在交叉摄像头中的图像检索中，对于每一个行人实体包含了多个查询以及返回多个匹配的行人。

Market1501 行人重识别数据集将使用下列准则进行图像的标注，对于每一个检测到并且需要标注的行人框，数据集中将会手动标注一个完完全全包含行人的正确的行人框，然后计算需要标注的行人框与手动标注的正确的行人框之间的重复率，如果重复率大于 50%，则 DMP 标注框被标记为“符合”，如果重复率小于 20%，则 DMP 标注框被标记为“不符合”，否则 DMP 标注框被标记为“毫不相关”，意味着标注的内容对于识别率没有丝毫影响。

如表 5-2 所示，不同行人重识别数据集包含的不同实体以及和识别率相关或者不相关图片的数量，同时还包含了不同数据集的评价标准。

表 5-2 不同数据集包含的信息

Dataset	Market-1501	RAiD [1]	CUHK03 [2]	VIPeR [3]	i-LIDS [4]	CUHK01 [5]	CUHK02 [6]	CAVIAR [7]
identities	1,501	43	1,360	632	119	971	1,816	72
BBoxes	32,668	6,920	13,164	1,264	476	1,942	7,264	610
distractors	2,793	0	0	0	0	0	0	0
cam. per ID	6	4	2	2	2	2	2	2
DPM/hand	DPM	Hand	DPM	hand	hand	hand	hand	hand
Evaluation	mAP	CMC	CMC	CMC	CMC	CMC	CMC	CMC

Market1501 行人重识别数据集一共包含了以下类别的图像数据：

1.训练集：训练集图像中一共包含了 12936 张行人重识别图像，是由六个不同的监控摄像头采集到的图像数据，改进后的卷积神经网络模型 Resnet50 将会在训练集上进行训练。

2.测试集：测试集图像中一共包含了 19732 张行人重识别图像，也是由六个不同的监控摄像头采集到的图像数据。

3.查询集：查询集图像中一共包含了 750 个行人实体，在执行查询操作的过程中，将会为每一个摄像头随机选取一张查询照片，所以每一个行人实体查询的图片最大的数量为 6，在查询集中一共包含了 3368 张行人查询图片。

4.真实查询集：每一张行人图像都包含了正确的标注，对于相关的查询图片会被标注符合或者不相关的标签，不相关的行人图片对查询精确度没有任何影响。

5.真实图像边框集：这一部分行人数据集主要包含了手动画的图像边框，主要用于检测有效的行人图像框。

上面描述的数据集的部分示例图片如下图 5-9 所示。




图 5-9 Market1501 数据集部分示例

图 5-9 示例中行人图片下的数字以及字母组合为每张行人图片的标签。在进行数据准备时，可以通过 OpenPose 工具将随机选取的相关行人的骨骼特征提取出来，如图 5-10 所示。




图 5-10 行人骨骼特征

在 Market1501 行人重识别数据集中，单个行人的骨骼特征提取如下图所示。




图 5-11 行人骨骼特征提取结果

由于 Market1501 数据集中的行人图片维度较小，骨骼特征提取效果不佳，因此在将数据集输入到改进后的卷积神经网络之前，还需要对行人图像进行扩维^[56]，使其骨骼特征能更加容易提取出来。图像扩维流程示意图如图 5-12 所示。




图 5-12 Market1501 数据集扩维示意图

除此之外还有 DukeMTMC-reID 行人重识别数据集，它也被广泛应用在多个竞赛以及神经网络模型的训练以及测试中，它成为了计算机视觉以及深度学习领域比较经典的行人重识别公开数据集。

DukeMTMC-reID 数据集为多目标和多标记行人跟踪数据集，它包含了 7000

多个单摄像机轨迹以及超过 2700 多个独立人物的数据集，DukeMTMC-reID 属于 DukeMTMC 的一部分，它还提供了人工标注的 bounding box^[57]。

我们可以从拍摄的视频中按照每 120 帧采样一张图像的准则得到 36411 张行人图像，包括了出现在两个摄像头及以上的 1404 个行人的图像，有 408 个人，也就是无关的行人照片只出现在一个摄像头下。DukeMTMC-reID 数据集可以分为三部分内容，它们分别是：

1.训练数据集：训练数据集一共包含了 702 个行人实体，其中包含了 16522 张行人图像，这些图像都是通过随机采样得到的。训练数据集的数据分布如下图所示，横坐标为每一个行人类别的图像数量，纵坐标为行人类别的数量。




图 5-13 训练数据集数据分布情况

2.测试数据集：测试数据集包含的行人实体和训练数据集的行人实体数量一致都是 702，但是包含的图片数量不一样，为 17661 张，图像也是通过随机采样^[58]得到的。

3.查询集：查询集的图像数据为测试集中的 702 个行人实体在每个摄像头中随机选择一张图像作为查询，一共包含了 2228 张图像。

DukeMTMC-reID 数据集的示例图片如图 5-14 所示。



图 5-14 DukeMTMC-reID 数据集的示例图片

同理，与 Market1501 数据集类似，DukeMTMC-reID 数据集的行人骨骼通过 OpenPose 工具提取之后的效果图如图 5-15 所示。



图 5-15 骨骼特征提取示例

从以上图 5-14 以及图 5-15 所示，行人重识别中数据集行人姿态的变化以及物体的遮挡，光线强度的变化都会对识别率造成影响，因此需要将图像数据做处理。本实验首先将行人重识别数据集中的 Market1501 骨骼关键点提取出来，然后将其保存为多个 json 文件，如下图 5-16 所示，这些 json 文件中记录了行人骨骼的坐标值。




图 5-16 保存骨骼关键点的 json 文件

根据保存的 json 文件以及原始数据集图像就可以对行人图像进行分割，分割为不同的三部分图像，图像分割后的第一部分结果如图 5-17 所示。




图 5-17 分割后的第一部分图像示例

分割后的第二部分结果如图 5-18 所示，与图 5-17 中的第一部分分割图像相对应。




图 5-18 分割后的第二部分图像示例

分割后的第三部分结果如图 5-19 所示，与图 5-17 以及 5-18 中分割后的图像相对应。




图 5-19 分割后的第三部分图像示例

当对行人重识别图像进行分割后，将这三部分数据分别输入到改进后的 Resnet50 卷积神经网络以便进行图像特征的提取，然后将三部分网络的特征输出进行拼接，最后做多个摄像头下的行人重识别，三个并行的神经网络架构如图 5-20 所示。




图 5-20 三输入的并行神经网络结构

5.5.2 行人重识别实验结果评价标准

实验结果评价标准主要包含 mAP(mean Average Precision) ^[59]，以及 CMC (Cumulative Matching Characteristic) ^[60]曲线，而 mAP 主要由准确率以及召回

率计算得到。

mAP 概念主要在信息检索领域 (information retrieval) [61]用的比较多, 与 mAP 联系紧密的还有准确率以及召回率, 为了更加直观的了解上述概念, 可以用图形将它们之间的联系表示出来, 如下图所示。




图 5-21 准确率和召回率的关系图

如图 5-21 所示, 假如用户向信息检索系统提交了一个行人的查询, 比如 David 是谁? 系统将会返回一系列的结果, 而这些信息都是系统通过用户提交的信息来判断系统内所有与这个查询信息相关的结果。在返回的结果中, 黄色标记的部分为系统返回的结果, 而绿色标记的部分是所有对用户查询有用的结果, 而绿色与黄色相交的地方, 叫做 True Positive(TP), 而黄色剩下的部分为 False Positive(FP), 这些结果对用户的查询没有什么帮助, 但是经过系统判定, 认为对用户有帮助。绿色剩下的部分为 False Negative (FN), 本来是对用户有用的结果, 但是被系统判定为无用。剩余的灰色部分是 True Negative(TN), 对用户的查询实际上没有什么帮助。

1. 准确率 (Precision)

准确率主要是指检索后返回的正确结果的数量占返回的正确结果加上不正确结果的总和的比例, 也就是系统返回给用户的所有结果中有多少是正确的。

2. 召回率 (Recall)

召回率的意思就是用户向系统提交查询后, 在所有的结果中, 系统能够在这些结果中判断出多少是有用的结果, 或者说有多少有用的结果被丢弃了。

mAP 表示平均精度均值, 比如用户在系统上提交了一个查询, 然后计算命中时的平均精度, 最后在所有的查询结果中取平均值。

如图 5-22 所示, 为 mean Average Precision 的一个计算示例。

Mean Average Precision: example




图 5-22 mAP 计算示例

图 5-22 中包含了用户提交的两个查询，首先将查询 1 中的准确率计算出来，然后取平均值，然后将查询 2 的准确率计算出来，取平均值，最后再将查询 1 以及查询 2 的平均准确率再取平均值，最后就能得到平均精度均值。

CMC 曲线是目前比较常用的评价标准，当我们提交一个查找对象后，系统会将候选集中的行人与查找对象一一进行距离的计算，如图 5-23 所示。




图 5-23 查询集与候选集间的距离计算示意图

本实验通过欧式距离将查询集中的行人图像特征与候选集中的行人图像特征距离计算出来，然后根据特征距离的大小进行行人图像间的相似度排序，如果

匹配的行人位置越靠前就说明相似度越高,反之,相似度越低,行人排序的过程如图 5-24 所示。




图 5-24 行人间的距离排序

现假设一共有 N 个行人,则需要进行 N 次查询以及排序,那么可以使用 CMC 曲线将排序的结果表示出来,公式 (5-23) 所示为 CMC 曲线的表示公式。

$$\text{CMC}(R) = \frac{1}{N} \sum_{i=1}^N \begin{cases} 1, & r_i \leq R \\ 0, & r_i > R \end{cases} \quad (5-23)$$

CMC 曲线,也可以用 Rank-k 来表示,主要反应匹配的准确率。行人重识别的数据集一共可以分为两部分,一部分是用于改进后的卷积神经网络 Resnet50 训练的训练集,还有一部分是用于改进后的卷积神经网络 Resnet50 测试的测试集,对于测试集中的图像数据可以分为两部分,一部分是用来检测网络模型性能的查询集,第二部分为对应查询集中行人图像的候选集,主要用来供查询集数据进行行人匹配。行人重识别过程中需要在候选集中找到对应查询集中的每一张行人图像,而最后的结果可以用 CMC 曲线来进行评估。

CMC 曲线意味着查询集中的行人图片在候选集中匹配出相似度最高的前 K 张图片中包含了要查询行人的正确率,而最具代表性的就是 Rank-1。Rank-1 识

别率指表示按照一定的相似度匹配规则进行行人匹配后,首次就能匹配出正确的行人标签数目与总数量之间的比率,比如 Rank-2 识别率意味着有 2 次机会判定是否有正确匹配。

5.5.3 行人重识别实验结果

改进后的卷积神经网络 Resnet50 分别在 Market1501 以及 DukeMTMC-reID 两个经过数据预处理后的行人重识别数据库上进行了训练以及测试,由于行人重识别网络特征层的不同取值会对影响网络的性能,因此实验中测试了不同特征维度下的 Rank-1 以及 mAP 的值。通过对比不同特征维度 d 来确定性能最佳的特征维度,接下来主要以公用行人重识别数据集 Market1501 为测试用例,测试结果表明特征维度在 $d=512$ 时效果最好,因此后续实验都在 $d=512$ 下进行,测试结果如下表 5-3 所示。

表 5-3 多维数下的 Rank-1 (%) 以及 mAP (%) 的值

Dimension	2048	128	256	512	1024
mAP	60.16	65.79	62.44	68.91	67.69
Rank-1	80.66	85.87	82.71	88.49	87.12

1.改进后的卷积神经网络 Resnet50 在 Market1501 数据集上的实验结果如下:

经过图像分割后的 Market1501 数据集训练的精确度达到了 0.986, 如下图 5-25 (a) 所示, 对应的损失函数下降值如图 5-25 (b) 所示。




图 5-25 Market1501 训练结果 (a) 为训练精确度 (b) 为损失函数值

改进后的卷积神经网络模型 Resnet50 在训练过程中设置的超参数有学习率,

它的值为 0.01，同时使用的优化器为随机梯度下降^[62]。在 MATLAB 上测试的 Rank-1 的识别率为 88.49%，在 MATLAB 上测试的 mAP 值为 68.91%。如下图 5-26 所示。




图 5-26 测试的 Rank-1 以及 mAP 的值

2.改进后的卷积神经网络 Resnet50 在 DukeMTMC-reID 行人重识别数据集上的训练精确度达到了约 98%，如下图 5-27（a）所示，数据集所对应的损失函数值如图 5-27（b）所示。




图 5-27 DukeMTMC-reID 数据集的训练结果（a）为训练精确度（b）为损失函数值

改进后的卷积神经网络模型 Resnet50 在训练过程中设置的超参数有学习率，它的值为 0.001，同时使用的优化器为随机梯度下降。在 MATLAB 上测试的 Rank-1 的识别率为 84.6%，在 MATLAB 上测试的 mAP 值为 69.5%。如图 5-28 所示。



图 5-28 DukeMTMC-reID 数据集的 mAP 以及 Rank-1 值

除了上述的实验结果（mAP 值，Rank-1 的值）之外，我们在 MATLAB 中还计算出了图 5-28 对应的 CMC 曲线，如下图 5-29 所示，CMC 曲线的水平轴代表了行人相似度排序的顺序，排序顺序为 Rank-1 到 Rank50，而垂直轴表示行人相似度排序对应的精确度。




图 5-29 数据集 DukeMTMC 的 CMC 曲线

根据图 5-29 所示,本章中介绍的算法在 DukeMTMC-reID 数据集上的 Rank-1 对应的命中率达 84.6%,这也就意味着深度卷积神经网络在行人重识别任务中具有一定的优势,使用深度卷积神经网络可以对行人重识别中的行人图像特征进行自动学习,以便提取到的特征信息更加丰富,包含了低维特征以及高维特征的特征信息成为了提高行人重识别任务中识别率的关键。

5.5.4 行人重识别结果对比

为了更有力地反映改进后网络的性能,论文中用改进后的 Resnet50 卷积神经网络在行人重识别数据集 Market1501 以及 DukeMTMC-reID 上进行了训练以及测试实验,并与近几年使用相同行人重识别数据集的卷积神经网络进行了详细的比较,用来比较的卷积神经网络基本在相关领域的国际会议上发表了论文,通过与不同网络模型的对比来证明新网络模型的性能。

首先要比较的是在 Market1501 数据集上的测试结果,从对比结果中,我们可以看到近几年的计算机视觉高级会议文章在同等条件下的实验结果,通过 mAP 以及 Rank-1 值进行卷积神经网络模型的对比,我们的算法要优于其他多数算法,其结果如表 5-4 所示。

表 5-4 不同模型方法在 Market1501 数据集上 Rank-1 以及 mAP 值的比较

Method	Rank-1(%)	mAP (%)
ResNet-NFST ^[63]	46.5	21.13
TMA4-LOMO ^[64]	47.92	22.31
Hybrid ^[65]	48.15	29.94
SCSP ^[66]	51.90	26.35
PersonNet ^[67]	37.21	18.57
MR B-CNN ^[68]	66.36	41.17
Resnet50-DSK ^[69]	83.58	64.25
Baseline-CamStyle ^[70]	88.12	68.72
DML ^[71]	87.73	68.83
PSE ^[72]	87.7	69.0
Our	88.49	68.91

其次要比较的实验结果是在 DukeMTMC-reID 数据集上的测试结果,从对比结果中可以看到近几年计算机视觉高级会议文章在同等实验下的结果。表 5-5 为不同卷积神经网络在 DukeMTMC-reID 数据集上 Rank-1 值和 mAP 值的对比,对比结果表明我们的算法要优于其他算法。

表 5-5 不同方法在 DukeMTMC-reID 数据集上 Rank-1 以及 mAP 值的比较

Method	Rank-1(%)	mAP (%)
BoW-HS ^[73]	25.13	12.17
LOMO-XQDA ^[74]	30.75	17.04
DPM-RCNN ^[75]	65.22	44.99
GAN ^[76]	67.68	47.13
JDIF ^[77]	68.1	46.82
ResNet ^[78]	68.9	49.3
MLFN ^[79]	81.2	62.8
DuATM ^[80]	81.82	64.58
PCB-RPP ^[81]	83.3	69.2
Inception-Dilation ^[82]	84.4	69.3
Our	84.6	69.5

图 5-30 为在 Market1501 数据集上不同实验方法所对应的 Rank-1 以及 mAP 值的对比图，横坐标为不同的算法名称，纵坐标为对应的精确度，单位为%。




图 5-30 Market1501 数据集上不同实验方法所对应的 Rank-1 以及 mAP 的值

图 5-31 是 DukeMTMC-reID 数据集上不同模型的实验方法所对应的 Rank-1 值以及 mAP 值的比较图，横坐标为不同的算法名称，纵坐标为对应的精确度，单位为%。




图 5-31 DukeMTMC-reID 数据集上不同实验方法所对应的 Rank-1 以及 mAP 的值

除了对上述实验结果做了对比外,本实验还对不同方法在时间效率上的优劣做了对比,图 5-32 为不同模型在 Market1501 数据集上的时间效率对比,横坐标为不同的算法名称,纵坐标为每张图片读取的时间,时间单位为秒。




图 5-32 Market1501 数据集上的时间效率对比

图 5-33 为不同模型在 DukeMTMC-reID 数据集上的时间效率对比,横坐标为不同的算法名称,纵坐标为每张图片读取的时间,时间单位为秒。




图 5-33 DukeMTMC-reID 数据集上的时间效率对比

从图 5-32 以及图 5-33 中的时间效率对比结果显示, 本论文提出的算法在时间效率上优于其他算法。

5.6 行人重识别实验仿真结果分析

根据上一小节的结果对比以及从表 5-4, 5-5 可知, 第一类数据集在 MATLAB 上 Rank-1 的值为 88.49%, mAP 值为 68.91%, 分别和当前其他性能较好的模型做了细致对比, 这些模型包含了 PSE, DML, TMA4-LOMO, 以及 PersonNet, SCSP 等方法, 无论是 Rank-1 的值还是 mAP 的值都领先于大部分的会议论文, 说明改进后的 Resnet50 卷积神经网络优于论文中的卷积神经网络, 而且在 Market1501 行人重识别公共数据集上有了较大提升, 提升的 Rank-1 数值最高达到了 41.99%, 最低为 0.37%, 结果说明改进后的卷积神经网络继承以及保留了原来卷积神经网络的优势, 同时也添加了新的理念和结构, 因此改进后的卷积神经网络 Resnet50 的行人重识别精确度较之前的卷积神经网络识别精确度有了巨大的提升。而且测试的 mAP 值的提升值也在 0.08%至 47.65%之间, 说明在每一个类别的识别中, 都有了明显的优化, 而且在某些图像分辨率较低的行人重识别中, 改进后的网络比之前网络的识别能力有了明显的增加。

改进后的卷积神经网络 Resnet50 不仅在 Market1501 数据集中取得了比较好的结果, 在 DukeMTMC-reID 数据集中也是如此, 在 MATLAB 上测试的 Rank-1 的值为 84.6%, 取得的 mAP 的值为 69.5%, 和近几年的其他方法做了细致的对比, 这些方法已经被很多知名会议收录, 比如 ECCV、ICCV 等, 包含了基本的

ResNet, LOMO+XQDA, BoW-HS 等方法, 不仅测试的 Rank-1 值得到了巨大提升, 而且 mAP 值也得到了提升, 提升的 Rank-1 数值最高的达到了 59.47%, 最低达到了 0.2%, 提升的 mAP 值最高达到了 57.33%, 最低达到了 0.2%, 这从一定程度上反映了改进后的卷积神经网络 Resnet50 的泛化能力, 不仅适用于公共的行人重识别数据集, 而且改进后的卷积神经网络的性能也非常好。在时间效率方面, 改进后的网络模型运行时间远远低于其他模型的运行时间, 与其他网络模型相比, 每一张行人图片读取的时间非常短, 为网络模型在不同数据集上的训练节省了很多时间。

5.7 本章小结

本章首先对使用的算法实现、具体实现流程以及核心思想进行了介绍, 然后介绍了论文实验中需要用到的实验平台和具体的实验环节配置, 以及改进后的卷积神经网络 Resnet50 在不同数据集上的训练方式和训练细节, 列举了最后的实验结果, 同时将实验结果和其他模型的实验结果做了详细的对比, 还对实验结果进行了分析, 并比较了近几年比较前沿的各类算法在同样数据集上的测试结果, 同时也做了细致的分析。总体上从实现原理以及实验数据验证了改进后的卷积神经网络比其他卷积神经网络的性能更好。

第六章 总结与展望

6.1 全文总结

行人重识别已经成为了近几年比较热门的研究课题,在现实生活中与之相关的需求以及应用非常多,由于现代科技的不断进步,特别是计算机硬件得到了巨大的性能提升,这为科学研究提供了特别好的条件。

Resnet50 残差网络是一个性能较好的物体识别模型并于 2015 年被提出,之后许多性能良好的模型被相继提出,卷积神经网络 Resnet50 可以解决由于网络深度增加而带来的梯度消失问题,并且在物体识别率上取得了很大的进步,为推动物体以及行人识别领域的发展做了巨大的贡献,但是 Resnet50 残差网络本身也具有很多不足的地方,比如在多类物体中的识别容易出现混淆的情况,也就是分类错误的问题,当行人图像中出现遮挡以及光照变化时,行人重识别的精确率不是很高。

基于上述背景以及行人重识别领域的多项研究理论,本论文查阅了许多国内外的最新论文,运用卷积神经网络的理论知识,结合多网络并行的理念以及相关技术在卷积神经网络 Resnet50 的基础上做了改进,通过原有网络结构的改变来提升神经网络的性能,从而提升网络在行人重识别上的效率,除此之外还提出了一种新的行人重识别图像分割算法 ISSE,根据行人骨骼关键点将行人图形进行分割,然后将分割后的三部分图像分别输入到改进后的卷积神经网络 Resnet50 模型中进行训练,最后实现行人的分类。本论文中提出的创新点主要涵盖了:

- 1.论文中提出了基于骨骼关键点的行人重识别图像分割算法 ISSE,结合行人的骨骼关键点对行人图像进行分割,分成等维的并且互相重叠的三部分,使改进后的卷积神经网络能提取到辨识度高的特征,以便能提升改进后的卷积神经网络模型 Resnet50 的性能。

- 2.为了匹配输入数据的维度,修改了原 Resnet50 残差网络的输入层大小,使之由 $224 \times 224 \times 3$ 维度变成了 $64 \times 64 \times 3$ 维度,便于进行改进后的卷积神经网络的训练。

- 3.修改了原有 Resnet50 残差网络的损失函数,根据得到的新权重和偏置公式计算新的值,相比于旧的损失函数,新的损失函数的性能更好,也比较灵活,网络收敛的更快。

- 4.在原卷积神经网络 Resnet50 中添加了 1×1 和 3×3 的卷积核,不仅减少了特征映射通道尺寸,还减少了网络中的参数数量。

5.改进了原有的 Resnet50 残差网络中的残差块,包含了恒等残差块以及卷积残差块。实验结果表明,改进后的网络模型卷积残差块以及恒等残差块更适合卷积神经网络对行人图像特征的提取,而且改进后的卷积神经网络模型 Resnet50 的性能优于原卷积神经网络模型 Resnet50 的性能。

最后根据论文中基于深度学习的行人重识别系统设计以及仿真实验,改进后的 Resnet50 残差网络在行人重识别数据集 Market1501 以及 DukeMTMC-reID 上进行了网络模型的训练以及测试, Rank-1 识别率结果分别是 88.49%以及 84.6%,实验表明改进后的卷积神经网络 Resnet50 优于其他网络模型。

6.2 后续工作展望

虽然提出的新图像分割算法 ISSE 取得了比较好的识别效果,以及改进后的 Resnet50 卷积神经网络相比于原神经网络有了巨大的提升,但是还可以进一步优化,因为在行人重识别数据集测试中仍然发现了网络的许多不足,比如相近行人的混淆问题,对最后的识别效果造成了很大的影响。这也是一个需要改进的方向。原有分割后的训练数据的维度为 64x64,其实还可以尝试其他的行人图像维度,比如使用 128x128 的图像维度输入至改进后的卷积神经网络 Resnet50 中,实验结果可能会不一样。同时还可以尝试增加训练数据集的数量,使网络能学习到更好的行人特征信息,或者将改进后的卷积神经网络 Resnet50 在 60000 张行人数据集上从头开始进行网络模型的训练,最后在使用训练完成的模型提取行人图像的特征,将模型保存后做数据集的测试。还可以通过使用生成式对抗网络产生更多的新的数据集用于改进后的卷积神经网络的训练与测试,上述都是可以完成的后续工作。

致谢

在电子科技大学进行硕士研究生学习期间，首先特别感谢我的导师陈佳老师，陈佳老师三年以来对我耐心地教导，并且对我的学习以及生活产生了许多积极的影响。科研上，陈佳老师的不断钻研以及努力的精神给我树立了榜样，让我在做研究时有了十足的动力，同时让我在遇到难题时会耐心地查阅文献资料，最终把难题解决。生活上，陈佳老师十分关心学生的生活境况，平时经常给学生一些无微不至的关怀，亦师亦友，潜移默化地影响着身边的每一个学生，值得我们去学习，同时也要感谢我们实验团队的惠宇老师以及郑莉华老师，感谢他们在科研上给我的建议以及帮助。

其次我要感谢我的父母，感谢他们在生活中给我提供的帮助以及无私奉献，让我勇敢地面对所有的困难。然后还要感谢电子科技大学的各位老师，感谢他们对我的孜孜教诲，以及像辛勤的园丁一般，不辞辛劳地培育了许许多多优秀的学生。我还要感谢实验室所有的小伙伴以及我身边的每一个朋友们，他们在生活以及学习上时时刻刻地帮助我，感谢他们每一次真诚地付出。

最后我要感谢电子科技大学这么优秀的一个平台，让我在这里学习、生活以及成长，让我遇见那么多优秀的人，同时也给我提供了国外修读双硕士学位的机会，在以后的人生中我将会更加努力！

参考文献

- [1] Liang Zheng, Yi Yang, and Alexander G. Hauptmann. 2016. Person re-identification: Past, present and future. arXiv:1610.02984.
- [2] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]. Computer Vision and Pattern Recognition (CVPR), 2006 IEEE Computer Society Conference on. IEEE, 2006, 2:1528-1535.
- [3] Gray D, Brennan S, Tao H. Evaluating appearance models for recognition, reacquisition, and tracking[C]. Proc. IEEE International Workshop on Performance Evaluation for Tracking and Surveillance (PETS). 2007, 3(5).
- [4] Ng, P.C. & Henikoff, S. SIFT: predicting amino acid changes that affect protein function. Nucleic Acids Res. 31, 3812 – 3814 (2003).
- [5] L. Zheng, L. Shen, L. Tian, S. Wang, J. Bu, and Q. Tian. Person re-identification meets image search. arXiv:1502.02171, 2015.
- [6] A. Schumann and R. Stiefelhagen, “Transferring attributes for person re-identification,” in AVSS. IEEE, 2015.
- [7] M. Farenzena, L. Bazzani, A. Perina, V. Murino, and M. Cristani. Person re-identification by symmetry-driven accumulation of local features. In CVPR, 2010.
- [8] E. Ahmed, M. Jones, and T. K. Marks. An improved deep learning architecture for person re-identification. In CVPR, 2015.
- [9] D. Yi, Z. Lei, and S. Z. Li. Deep metric learning for practical person re-identification. ICPR, 2014.
- [10] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
- [11] Çatalyürek Ü V, Aykanat C, Uçar B. On two-dimensional sparse matrix partitioning: Models, methods, and a recipe[J]. SIAM Journal on Scientific Computing, 2010, 32(2): 656-683.
- [12] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Cvpr, 2015.
- [13] Lin, M., Chen, Q., and Yan, S. Network in network. In Proc. ICLR, 2014.
- [14] XING, E., NG, A., JORDAN, M., AND RUSSELL, S. 2003. Distance metric learning, with application to clustering with side-information. In Proceedings of the Conference on Advances in Neural Information Processing Systems (NIPS).
- [15] K.Q. Weinberger and L.K. Saul. Distance metric learning for large margin nearest neighbor

- p classification.
- Journal of Machine Learning Research*
- , 10(Feb):207 – 244, 2009.
- [16] D.-P. Chen, Z.-J. Yuan, G. Hua, N.-N. Zheng, and J.-D. Wang. Similarity learning on an explicit polynomial kernel feature mAP for person re-identification. In *CVPR*, 2015.
- [17] M. Hirzer, P. Roth, M. Kostinger, and H. Bischof. Relaxed ℓ_2 pairwise learned metric for person re-identification. *ECCV*, 2012.
- [18] Liao, S., Li, S.Z.: Efficient psd constrained asymmetric metric learning for person re-identification. In: *Proceedings of the IEEE International Conference on Computer Vision*. pp. 3685 – 3693 (2015)
- [19] A. Mignon and F. Jurie. PCCA: A new approach for distance learning from sparse pairwise constraints. In *Proc. CVPR*, 2012.
- [20] G. Lisanti, S. Karaman, and I. Masi, “Multi-Channel-Kernel Canonical Correlation Analysis for Cross-View Person Re-Identification,” *ACM Transactions on Multimedia*, vol. 13, iss. 2, p. 13:1 – 13:19, 2017.
- [21] Madden, C., Cheng, E.D., Piccardi, M.: Tracking people across disjoint camera views by an illumination-tolerant appearance representation. *Machine Vision and Applications* 18(3-4) (2007)
- [22] Farenzena, M., Bazzani, L., Perina, A., Murino, V., Cristani, M.: Person re-identification by symmetry-driven accumulation of local features. In: *IEEE Conference Computer Vision and Pattern Recognition*, pp. 2360 – 2367 (2010)
- [23] J. Huang, S. Kumar, M. Mitra, W.-J. Zhu, and R. Zabih, Image indexing using color correlogram, in *Proc. of IEEE Conf. on Computer Vision and Pattern Recognition*, 1997.
- [24] Gonzalez, R.C., Woods, R.E., Eddins, S.L. 数字图像处理. 北京: 电子工业出版社, 2006.
- [25] E. Ahmed, M. Jones, and T. K. Marks. An improved deep learning architecture for person Re-ID. In *CVPR*, 2015.
- [26] 彭凯, 汪伟, 杨煜普. 基于余弦距离度量学习的伪 K 近邻文本分类算法[J]. *计算机工程与设计*, 2013, 34(6):2200-2203.
- [27] 蔡建军, 孔令富, 李海涛. 基于欧式距离变换的人体 2D 关节点标定[J]. *计算机仿真*, 2012, 29(7):243-246.
- [28] 吴轲. 基于深度学习的中文自然语言处理[D]. 东南大学, 2014.
- [29] 马文峰, 高凤荣, 王珊. 论数字图书馆个性化信息推荐系统[J]. *现代图书情报技术*, 2003(2):16-18.
- [30] 王雪光, 郭艳兵, 齐占庆. 激活函数对 BP 网络性能的影响及其仿真研究[J]. *自动化技术与应用*, 2002, 21(4):15-17.
- [31] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J].

- 2015:770-778.
- [32] Hinton G E, Salakhutdinov R. Replicated softmax: An undirected topic model[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2009:1607-1614.
- [33] Philipp Petersen and Felix Voigtlaender. Optimal approximation of piecewise smooth functions using deep relu neural networks. arXiv preprint arXiv:1709.05289, 2017.
- [34] Tim Cooijmans, Nicolas Ballas, Cesar Laurent, and Aaron Courville. Recurrent batch normalization. ' arXiv preprint arXiv:1603.09025, 2016.
- [35] J.C. Fernández, C. Hervás, F.J. Martínez, M. Cruz, "Design of Artificial Neural Networks Using a Memetic Pareto Evolutionary Algorithm Using as Objectives Entropy versus Variation Coefficient", Intelligent Systems Design and Applications 2009. ISDA '09. Ninth International Conference on, pp. 408-413, 2009.
- [36] Z. Zhong, B. Fan, K. Ding, H. Li, S. Xiang, and C. Pan, "Efficient multiple feature fusion with hashing for hyperspectral imagery classification: A comparative study," IEEE Trans. Geosci. Remote Sens., vol. 54, no. 8, pp. 4461–4478, Aug. 2016.
- [37] D. Erhan, C. Szegedy, A. Toshev, and D. Anguelov. Scalable object detection using deep neural networks. In CVPR, 2014.
- [38] E. Ristani, F. Solera, R. Zou, R. Cucchiara, and C. Tomasi. Performance measures and a data set for multi-target, multicamera tracking. In ECCV, 2016.
- [39] Mart'in Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, Jerrey Dean, Mahieu Devin, Sanjay Ghemawat, Georey Irving, Michael Isard, and others. 2016. TensorFlow: A system for large-scale machine learning. In Proc. USENIX Symposium on Operating Systems Design and Implementation (OSDI). 264–285.
- [40] Hwang, K., Sung, W.: Fixed-point feedforward deep neural network design using weights+ 1, 0, and- 1. In: Signal Processing Systems (SiPS), 2014 IEEE Workshop on, IEEE (2014) 1–6
- [41] Simard, D., Steinkraus, P. Y. & Platt, J. C. Best practices for convolutional neural networks. In Proc. Document Analysis and Recognition 958–963 (2003).
- [42] Du, Y., Wang, W., Wang, L.: Hierarchical recurrent neural network for skeleton based action recognition. In: CVPR. (2015)
- [43] F. Chollet, et al., Keras: Deep learning library for theano and tensorow, URL:<https://keras.io/k7> (2015) 8.
- [44] J. Duchi and Y. Singer. Efficient online and batch learning using forward backward splitting. Journal of Machine Learning Research, 10:2873–2898, 2009.
- [45] Panitz, T., "Collaborative Versus Cooperative Learning-A Comparison of the Two Concepts

- Which Will Help Us Understand the Underlying Nature of Interactive Learning,”
<http://capecod.net/~tpanitz/tedsarticles/coopdefinition.htm>, accessed 12/2/2003.
- [46] Chen, K., Yang, L.P., Yu, X., Chi, H.S., 1997. A self-generating modular neural network architecture for supervised learning. *Neurocomputing* 16 (1), 33–48.
- [47] A. Radford, L. Metz, and S. Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434, 2015
- [48] K. Duan, S.S. Keerthi, and A.N. Poo. Evaluation of simple performance measures for tuning svm hyperparameters. *Neurocomputing*, To appear, 2002.
- [49] R. A. Jacobs, “Increased Rates of Convergence Through Learning Rate Adaptation,” *Neural Networks*, vol. 1, no. 4, pp. 295-308, 1988.
- [50] A. F. Atiya, Learning on a general network, in *Neural Information Processing Systems*, D. Z. Anderson, ed., American Institute Physics, New York, 1988, pp. 22–30.
- [51] Srivastava, Nitish, Hinton, Geoffrey, Krizhevsky, Alex, Sutskever, Ilya, and Salakhutdinov, Ruslan. Dropout: A simple way to prevent neural networks from overfitting. *J. Mach. Learn. Res.*, 15(1):1929–1958, January 2014.
- [52] Jung, H., Lee, S., Yim, J., Park, S., Kim, J.: Joint fine-tuning in deep neural networks for facial expression recognition. In: *Proceedings of the IEEE International Conference on Computer Vision*. (2015) 2983–2991
- [53] Sen Qiao, Yilin Wang, and Jian Li, “Real-Time Human Gesture Grading Based on OpenPose,” *Image and Signal Processing*, Shanghai, China, 2017, pp 1–6.
- [54] Narayanan, A., Shi, E., & Rubinstein, B. I. P. (2011). Link prediction by de-anonymization: How we won the Kaggle social network challenge. In *The 2011 International Joint Conference on Neural Networks* (pp. 1825—1834). Washington, DC: IEEE Computer Society.
- [55] J. Yan, Z. Lei, L. Wen, and S. Li, “The fastest deformable part model for object detection,” in *IEEE Conference on Computer Vision and Pattern Recognition*, 2014, pp. 2497-2504.
- [56] Haykin S. *Neural Networks: A Comprehensive Foundation*[J]. *Neural Networks A Comprehensive Foundation*, 1994:71-80.
- [57] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11):2278-2324.
- [58] Arora S, Bhaskara A, Ge R, et al. Provable Bounds for Learning Some Deep Representations[J]. 2013:584-592.
- [59] Çatalyürek Ü V, Aykanat C, Uçar B. On two-dimensional sparse matrix partitioning: Models, methods, and a recipe[J]. *SIAM Journal on Scientific Computing*, 2010, 32(2): 656-683.
- [60] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively

- trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 32(9): 1627-1645.
- [61] Hinton G E, Salakhutdinov R. Replicated softmax: An undirected topic model[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2009:1607-1614.
- [62] Ciregan D, Meier U, Schmidhuber J. Multi-column deep neural networks for image classification[C]//Computer vision and pattern recognition (CVPR), 2012 IEEE conference on. IEEE, 2012: 3642-3649.
- [63] Karanam S, Gou M, Wu Z, et al. A Systematic Evaluation and Benchmark for Person Re-Identification: Features, Metrics, and Datasets[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018:1-1.
- [64] Martinel N, Das A, Micheloni C, et al. Temporal Model Adaptation for Person Re-Identification[J]. 2016.
- [65] Wu L, Shen C, Hengel AVD. Deep linear discriminant analysis on fisher networks: A hybrid architecture for person re-identification[J]. Pattern Recognition, 2017, 65(Complete):238-250.
- [66] Chen, Dapeng, et al. "Similarity learning with spatial constraints for person re-identification." 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) 0.
- [67] Wu, Lin, C. Shen, and A. V. D. Hengel. "PersonNet: Person Re-identification with Deep Convolutional Neural Networks." (2016).
- [68] Ustinova, Evgeniya, Y. Ganin, and V. Lempitsky. " [IEEE 2017 14th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS) - Lecce, Italy (2017.8.29-2017.9.1)] 2017 14th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS) - Multi-Region bilinear convolutional neural networks for person re-identification." (2017):1-6.
- [69] He, Lingxiao, et al. "Deep Spatial Feature Reconstruction for Partial Person Re-identification: Alignment-Free Approach." (2018).
- [70] Zhong, Zhun, et al. "CamStyle: A Novel Data Augmentation Method for Person Re-identification." IEEE Transactions on Image Processing (2018):1-1.
- [71] Ying Zhang, Tao Xiang, Timothy M. Hospedales, Huchuan Lu, "Deep Mutual Learning." CVPR. (2018)
- [72] Sarfraz, M. Saquib, et al. "A Pose-Sensitive Embedding for Person Re-Identification with Expanded Cross Neighborhood Re-Ranking." (2017).
- [73] Zheng, Liang, et al. "Scalable Person Re-identification: A Benchmark." 2015 IEEE

- International Conference on Computer Vision (ICCV) IEEE Computer Society, 2015.
- [74] Liao, Shanghai, et al. "Person re-identification by Local Maximal Occurrence representation and metric learning." 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) IEEE, 2015.
- [75] L. Zheng, Y. Yang, and A. G. Hauptmann. Person re-identification: Past, present and future. arXiv:1610.02984, 2016.
- [76] Zheng, Zhedong, L. Zheng, and Y. Yang. "Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro." (2017).
- [77] Xiao, Tong, et al. "Joint Detection and Identification Feature Learning for Person Search." 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) IEEE Computer Society, 2017.
- [78] Zheng, Zhedong, L. Zheng, and Y. Yang. "A Discriminatively Learned CNN Embedding for Person Re-identification." *Acm Transactions on Multimedia Computing Communications & Applications* 14.1(2016).
- [79] Chang, Xiaobin, T. M. Hospedales, and T. Xiang. "Multi-Level Factorisation Net for Person Re-Identification." (2018).
- [80] Si, Jianlou, et al. "Dual Attention Matching Network for Context-Aware Feature Sequence based Person Re-Identification." (2018).
- [81] Yifan Sun, Liang Zheng, Yi Yang, Qi Tian, and Shengjin Wang. 2018. Beyond Part Models: Person Retrieval with Refined Part Pooling. In ECCV. In press.
- [82] Suh, Yumin, et al. "Part-Aligned Bilinear Representations for Person Re-identification." (2018).

攻读硕士学位期间取得的成果

意大利帕维亚大学双硕士学位：

获得意大利帕维亚大学计算机工程系双硕士学位，论文"Part-based Person Re-Identification via Deep Neural Networks" 被意大利帕维亚大学 "Computer vision Tools and Applications" 收录.

科研项目：

[1] 一体化客舱开放式软件体系架构研究（项目编号：H04W1600）

[2] WEBSERVER 优化项目（项目编号：H04W1702）

奖学金：

[1] 电子科技大学研究生学业二等奖学金, 2017

[2] 电子科技大学研究生学业二等奖学金, 2018