

西安电子科技大学

硕士学位论文



基于深度学习的行人重识别研究

作者姓名 孟根强

指导教师姓名、职称 冯大政 教授

申请学位类别 工学硕士

学校代码 10701
分 类 号 TP39

学 号 1602120888
密 级 公开

西安电子科技大学

硕士学位论文

基于深度学习的行人重识别研究

作者姓名：孟根强

一级学科：信息与通信工程

二级学科：信号与信息处理

学位类别：工学硕士

指导教师姓名、职称：冯大政 教授

学 院：电子工程学院

提交日期：2019 年 5 月

Research on Person Re-identification Method Based On Deep Learning

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Signal and Information Processing

By
Meng GenQiang
Supervisor: Feng DaZheng Title: Professor
May 2019

摘要

深度学习在图像识别、自然语言处理、语音识别等领域应用广泛。行人重识别是深度学习技术应用的一个热门方向。行人重识别是指在无重叠监控区域的摄像头网络下进行的行人匹配。行人重识别的图像一般来自不同的摄像头，所以在视角、光照、尺寸等方面的变化可能比较大，如何在不同摄像头的条件差异下仍能准确地识别出目标行人是本论文所面临的重要挑战。目前对于行人重识别研究的主流方向有两种：特征表示和度量学习。本文将特征表示和度量学习通过深度学习结合起来，构建基于深度学习的行人重识别系统，主要的工作和内容归纳如下：

(1)基于深度学习目标检测网络-RetinaNet 进行了目标检测的研究。从检测网络的组成架构上对其进行了详细介绍，选择此网络结构是因其中中心损失函数很好地缓解了检测中正负样本不均衡的问题。本文通过 PASCAL VOC 2012 数据集对检测网络进行了复现，并通过实验仿真验证了所训练的目标检测网络可以在复杂场景中将行人图像检测出来。

(2)基于深度学习分割网络-Unet 进行了图像分割的研究。原始的 Unet 网络由于下采样过程会丢失一些原始图像的信息，进而影响了图像分割的效果。为了缓解这个影响，本文提出将输入从单一尺度变为多尺度，然后将得到的输出送进对应尺寸的网络层进行训练的方法。本文将上述方法和原始的 Unet 对同一个行人数据集进行训练，实验结果表明，本文提出的方法在定量分析和定性分析中都比原始的 Unet 具有更好的性能。

(3)基于孪生网络进行了度量学习算法的研究。由于行人图像的数据集不足，本文采用预训网络来缓解数据不足的问题。原始孪生网络所学习到的映射函数不足以让同类更近异类更远，本文在预训网络所提取特征的基础上，提出了特征组合的方式来丰富后端网络学习的特征。本文通过在行人重识别数据集 Market-1501 进行测试，在此数据集上实现了 Rank1 为 85.65%；另外从单张图片的测试效果看，本文提出的方法实现了让同类的得分更高，异类的得分更低。

(4)基于 Python 的图形界面设计。本文采用的界面语言是 Python，通过其自带的界面设计库 Tkinter 将检测、分割、识别功能结合在一起，形成了一个简易的可交互的行人重识别系统。

关键词：深度学习， 行人重识别， 孪生网络， 迁移学习

ABSTRACT

Deep learning is widely used in image recognition, natural language processing, and speech recognition. Pedestrian re-identification is a hot trend in the applications of deep learning technology. Pedestrian re-identification aims to achieve pedestrian matching in a camera network without overlapping surveillance areas. The pictures used by pedestrian recognition are from different cameras, so there maybe great changes in perspective, illumination, size, etc. How to accurately identify target pedestrians under different camera conditions is an important challenge in this thesis. Currently, there are two mainstream research directions in pedestrian recognition: feature representation and metric learning. This thesis combines feature representation and metric learning through deep learning to construct a pedestrian recognition system based on deep learning. The main work and contents are summarized as follows:

(1)Based on the deep learning network-RetinaNet, the object detection research is carried out. The structure of the detection network is introduced in detail. The reason for choosing this network structure is that its focal loss function can well alleviate the problem of imbalance between positive and negative samples. In this thesis, the detection network is reproduced through the PASCAL VOC 2012 data set, and the experimental simulation results show that the trained target detection network can detect pedestrian images in complex scenes.

(2) Based on the deep learning network-Unet, the image segmentation is studied. The original Unet network will lose some original image information due to the downsampling process, which affects the image segmentation effect. In order to alleviate this effect, this thesis proposes a method of changing the input from a single scale to multi-scale and then sending the output to the corresponding network layer for training. In this thesis, the above method and the original Unet are trained on the same pedestrian data set. The experimental results show that the proposed method has better performance than the original Unet in both quantitative analysis and qualitative analysis.

(3) Based on the siamese network, the metric learning algorithm is studied. Because the dataset of pedestrian images is insufficient, this thesis uses pre-training network to alleviate

the problem of insufficient data. The mapping function learned by the original siamese network is not enough to make the similar ones closer and the different ones farther. Based on the features extracted from the pre-training network, this thesis proposes a feature combination method to enrich the characteristics of back-end network learning. In this thesis, the test is carried out in the pedestrian recognition dataset Market-1501, and the Rank1 is 85.65% on this dataset. In addition, from the results of the single image, the method proposed in this thesis achieves a higher score for the same categories and a lower score for the different categories.

(4) Based on Python's graphical interface design, the interface language used in this thesis is Python. Through its own interface design library Tkinter, the detection, segmentation and recognition functions are combined to form a simple interactive cross-recognition system.

Keywords: deep learning, pedestrian Re-Identification, siamese networks, transfer learning

插图索引

图 1.1	行人重识别任务模型图.....	2
图 2.1	几种 example 示意图	10
图 2.2	残差网络结构示意图.....	11
图 2.3	两种不同的残差模块.....	12
图 2.4	图像特征金字塔.....	13
图 2.5	单特征映射.....	14
图 2.6	层次金字塔特征.....	14
图 2.7	特征金字塔网络示意图.....	15
图 2.8	特征金字塔网络(FPN)横向连接的细节图.....	15
图 2.9	经典 CNN 实现图像分类示意图	16
图 2.10	全卷积网络(FCN)结构示意图	17
图 2.11	检测网络 RetinaNet 结构	19
图 2.12	可扩展标记语言(xml)文件的部分标记内容.....	20
图 2.13	目标和边界框可视化.....	21
图 2.14	文件夹 JPEGImages 中的示例图片	22
图 2.15	文件夹 SegmentationClass 和 SegmentationObject 区别说明图	23
图 2.16	检测网络 RetinaNet 行人图像检测结果	24
图 3.1	分割网络 Unet 结构.....	26
图 3.2	感受野计算示意图.....	29
图 3.3	手写数据集 mnist 中的数字 9.....	30
图 3.4	卷积网络 LeNet-5 第一个卷积层的输出特征图	30
图 3.5	卷积网络 LeNet-5 第二个卷积层的输出特征图	31
图 3.6	原始输入图像.....	32
图 3.7	卷积层特征图.....	32
图 3.8	将 3.7 特征图相加后的结果.....	33
图 3.9	传统多尺度示例.....	34
图 3.10	改进 Unet 示意图.....	34
图 3.11	池化操作示意图.....	35
图 3.12	改进的 Unet 训练所选用的数据集例子	36
图 3.13	交并比运算示意图.....	37
图 3.14	图像分割测试图.....	38

图 3.15	分割结果	38
图 3.16	网络性能对比图	39
图 4.1	人工智能、机器学习以及深度学习关系图	42
图 4.2	谷歌提出的 Inception v3 网络结构	43
图 4.3	一个简化的 Inception 模型	44
图 4.4	简化 Inception 的延伸	44
图 4.5	极端版本的 Inception 结构	45
图 4.6	分离卷积示意图	45
图 4.7	谷歌提出的 Xception 网络结构图	46
图 4.8	孪生网络结构示意图	47
图 4.9	孪生网络运算流程图	48
图 4.10	训练数据集样例	49
图 4.11	原始孪生网络性能指标变化曲线	50
图 4.12	改进后孪生网络性能指标变化曲线	50
图 4.13	原始孪生网络的测试结果	51
图 4.14	改进后网络的测试结果	51
图 4.15	查准率和查全率的计算	52
图 5.1	行人重识别系统流程	55
图 5.2	图形界面设计图	58
图 5.3	执行优先级错误的提示信息	59
图 5.4	行人重识别系统测试图像	59
图 5.5	检测按键 detect 执行后的结果	60
图 5.6	检测后截取出的图像	60
图 5.7	分割按键 segment 执行后的结果	61
图 5.8	识别按键 recognize 执行后的结果	61

表格索引

表 3.1 原始 Unet 和改进 Unet 性能对比表.....	40
表 4.1 改进孪生网络和其他网络及算法实验对比表	53
表 5.1 常用控件介绍	56
表 5.2 标准属性信息	57
表 5.3 几何管理部件	57

符号对照表

符号	符号名称
$\log(\cdot)$	对数函数
$\exp(\cdot)$	指数函数

缩略语对照表

缩略语	英文全称	中文对照
AP	Average Precision	平均准确率
BP	Back Propagation	反向传播
CE	Cross Entropy	交叉熵
CMC	Calculated Matching Characteristic	统计匹配特征
CNN	Convolutional Neural Networks	卷积神经网络
CVPR	Computer Vision and Pattern Recognition	计算机视觉和模式识别
FCN	Full Convolutional Networks	全卷积神经网络
FL	Focal Loss	中心损失
FPN	Feature Pyramid Networks	特征金字塔网络
HSV	Hue Saturation Value	色调饱和度亮度
IoU	Intersection-over-Union	交并比
KISS	Keep It Simple and Straightforward	保持简单和直接
LFDA	Local Fisher Discriminant Analysis	局部费舍判别分析
LOMO	Local Maximal Occurrence	局部最大存在
mAP	mean Average Precision	总体平均准确率
mIoU	mean Intersection-over-Union	平均交并比
NMS	Non-Maximum Suppression	非极大值抑制
PCA	Principal Component Analysis	主成分分析
ReLU	Rectified Linear Unit	线性整流单元
Resnet	Residual Neural Network	残差神经网络
RS-KISS	Regularized Smoothing KISS	正则化的光滑 KISS
SSD	Single Shot MultiBox Detector	单阶段多盒检测
SVM	Support Vector Machine	支持向量机
XQDA	Cross-view Quadratic Discriminant Analysis	跨视角二次判别分析
YOLO	You Only Look Once	只看一次

目录

摘要	I
ABSTRACT	III
插图索引	V
表格索引	VII
符号对照表	IX
缩略语对照表	XI
第一章 绪论	1
1.1 研究背景及研究意义	1
1.2 国内外研究现状	3
1.3 本文的研究内容	6
1.4 论文组织结构	7
第二章 目标检测网络 RetinaNet 介绍	9
2.1 目标检测方法介绍	9
2.2 网络模型 RetinaNet 结构介绍	11
2.2.1 骨架网络 Resnet 介绍	11
2.2.2 特征金字塔网络 FPN 介绍	13
2.2.3 全卷积神经网络 FCN 介绍	16
2.2.4 检测网络 RetinaNet 的中心损失函数	17
2.2.5 检测网络 RetinaNet 总结	19
2.3 训练数据集 PASCAL VOC 2012 介绍	19
2.4 实验仿真分析	23
2.5 本章小结	24
第三章 分割网络	25
3.1 图像分割介绍	25
3.2 分割网络 Unet 的网络	26
3.3 卷积层特征图的可视化	28
3.4 改进的 Unet 网络	33
3.5 实验仿真分析	36
3.6 本章小结	40
第四章 迁移学习和孪生网络	41
4.1 迁移学习的应用场景	41

4.2	迁移学习原理	42
4.3	迁移学习的预训网络 Xception.....	43
4.4	孪生网络的改进	46
4.5	实验仿真分析	49
4.6	本章小结	54
第五章	基于 Tkinter 模块的简易行人重识别系统.....	55
5.1	行人重识别流程介绍	55
5.2	Tkinter 模块的介绍.....	55
5.3	界面展示	58
5.4	本章小结	62
第六章	总结与展望	63
6.1	总结	63
6.2	展望	64
参考文献.....		65
致谢.....		69
作者简介.....		71

第一章 绪论

1.1 研究背景及研究意义

人们对于公共安全的关注日益增强，从乘坐火车前的安检、非小区业主进入小区时的身份登记以及邮寄快递的实名制等方面无不体现了人们对于公共安全的重视。信息技术、集成电路以及加工技术的进步让监控所需设备的成本不断降低，例如：监控摄像头、显示器、计算机等。监控成本的降低让现在的城市监控发生了许多变化。相对于以往的城市监控系统，现在的监控系统分布更广，也呈现出多元化的趋势。根据监控安装的场所，这些监控所起的作用也有些许不同，例如：安装在高速公路上的摄像头主要是为了拍摄所经过的车辆，以便某些车辆主人违反交通规则时可以使之无所遁逃；安装在小区内的摄像头主要是拍摄过往的行人，以便在小区居民发生失窃问题时及时将过往的行人排查一遍，在最短的时间找到可疑人员；安装在医院病房的摄像头主要是为了拍摄病人一天的健康恢复生活，以便可以及时掌握病人的身体状况制定相对应的医疗方针。总之，监控系统对于现代化社会来说是不可缺少的一个重要组成部分。

监控系统虽然可以将各种类型的视频记录下来但是真正要发现这些视频中的潜在价值还是需要人工来提取。针对以前的监控系统，人工查看视频已有很大的不便更何况于现在监控视频的数量比以往增加了不少，所以依靠人力来解决就显得有点不符合时代需求。除了视频数据量大这个原因外，人工监察方式还有以下几个限制因素：第一，监察人员会随着监察时间的推移逐渐产生疲劳感进而会影响监察的质量；第二，不同的监察人员对于同一段视频所获取的信息会有一定的差异，也就是不同的监察人员所关注的信息会有不同；第三，监察人员的经验也就是在监察工作这个岗位上工作时间的长短也很大程度上影响着最后的观察结果，并且这种经验不是可以立马学会的必须经过长期大量的实践才可以完全掌握；第四，现在社会对于人工的费用普遍比较高这也就造成了监察的代价非常昂贵，有可能会超出问题本身的价值。为了适应监控系统的发展，人工查看监控视频的方式应该不能占主导方式，通过发展一套智能的监察系统来实现应对海量视频数据的分析成为了一个亟待解决的问题。为了实现智能的监控系统，我们需要知道监控的对象是什么，这样才可以有针对性的发展相应技术。监控系统主要是应对安全问题，安全问题分为人为和自然现象引发。自然现象引发的安全问题由于其不具有可预知性所以不在本文讨论范围之内。人为引发的问题又分为有意和无意的，无论是有意或者无意都需承担一定的责任，所以本文统一对人为引起的问题进行讨论。

对失踪人员的查找（通过对监控所拍摄的行人图像和失踪人员进行比对）、协助警方进行嫌疑犯的照片比对、保密单位门口的人员识别等方面都需要行人重识别来辅助问题的解决。因其在安全领域的重要应用，本文就行人重识别进行了相关研究。

行人重识别是指在不重叠监控区域的摄像头网络下进行的行人匹配，即如何确认不同位置的摄像头在不同时刻发现的行人目标是否为同一人^[1]。其任务模型如图 1.1 所示：




图1.1 行人重识别任务模型图

图 1.1 中的字母代表了摄像头，数字代表了行人，从摄像头出发的两条射线所围成的区域代表该摄像头的监控区域，数字之间的虚线代表了该行人的行动轨迹。从图 1.1 中我们可以看出，图中显示的四个摄像头模型的监控区域均没有重叠部分，从图中可以看到行人 1 和行人 4、5、6 发生移动并且跨越了没有重叠监控区域的摄像头。我们选择行人 1 来具体描述行人重识别任务。从图中的虚线方向可以知道，行人 1 开始是在摄像头 a 的监控下，然后移动到了摄像头 c 的监控区域下，将行人 1 作为目标，摄像头 c 中拍摄的行人 1、3、4、5 作为候选集，在候选集中成功找到目标行人 1 的过程就是行人重识别。从这个具体的例子可以明确，候选集中的其他行人是对任务的一个干扰；另外同一监控摄像头 a 下的行人 2 也可能对提取行人 1 的图像造成遮挡等影响；监控摄像头和行人 1 之间的相对位置也会对所获取的行人图像产生较大影响。通过上面的分析我们可以知道，行人重识别任务的难点在于监控摄像头和行人之间的相对位置关系、监控摄像头之间的质量差异、行人之间的位置关系、行人的姿态变化以及行人之间服饰的干扰等。除了上面分析到的硬件和人为干扰外，天气的状态、监控的时间（白天或晚上）等也会对行人重识别造成影响。

深度学习是最近几年非常火的一个研究领域,由于其在图像分类领域所表现出的良好性能让大量图像领域的研究人员试着将这一技术应用在自己的研究方向上。深度学习是一种训练人工神经网络的方法,人工神经网络是模拟人类大脑所构建的类神经网络,我们主要用的是其非线性映射的能力。在客观世界中,许多系统的输入与输出之间存在复杂的非线性关系,但是对于这类系统往往很难用传统的数学方法建立其数学模型或者即使能建立数学模型表现也一般不能满足设计者的需要。传统的方法一般建立出的是线性分类器,对于客观世界中的各种非线性系统难以模拟;深度学习是由许多层构成的,每一层都是一个非线性映射,除了输入层和输出层,其他层称为隐含层,这些层之间的关系类似于函数嵌套,这种方式就构成了一个非常复杂的非线性函数,这个函数可以以任意精度逼近任意复杂的非线性映射。这一优良的特性能够让深度学习应用于很多系统的建模,但建出的模型表达是非解析的,输入数据与输出数据的映射规则存储在网络的所有连接中。这些连接中的参数就是其非线性映射的具体表现,这些参数需要大量的数据进行训练更新,类似于需要已知条件求解多元方程。其实深度学习从理论上来讲并不是什么新兴技术,近几年得到快速发展的主要原因是大数据的分布式存储技术和计算机硬件——图形处理器 GPU (Graphics Processing Unit) 和中央处理器 CPU (Central Processing Unit) 的发展。深度学习的快速发展是以 2012 年 Hinton 的学生 Alex 参加 ILSVRC (ImageNet Large Scale Visual Recognition Challenge) 比赛并以卷积神经网络 AlexNet 获得冠军为转折点,在此之前,虽然 BP (Back Propagation) 算法的应用也稍微让深度学习有了一个短暂的高峰但是真正掀起深度学习之风的还是从 2012 年 AlexNet 夺冠开始的。从 2012 年开始,深度学习在计算机视觉的三大研究领域——分类、检测、分割方面都取得了很大进步。深度学习在行人重识别领域也有一定程度的发展,本文是基于深度学习的方法来进行行人重识别算法的研究。

1.2 国内外研究现状

行人重识别属于计算机视觉的一个子问题,这个领域早在 1996 年就被相关学者关注^[2],这时行人重识别只是作为一个学术问题被提出来并没有受到重视。真正将其作为一个正式的研究方向却是在十年之后的 CVPR (Computer Vision and Pattern Recognition) 会议^[3]上,从 2006 年开始关于行人重识别的相关研究就一直有条不紊地进行着。从行人重识别任务的提出到其被作为一个正式的研究方向经过了三个阶段:第一个阶段是从 1996 年开始到 2006 年,这个阶段属于方向未明确时期;第二个阶段是从 2006 年到 2012 年的稳步发展时期;第三个阶段是从 2012 年至今,此阶段属于快速发展时期。前面之所以将 2012 作为阶段点,是因为 2012 年是深度学习崛起的一

年,其在图像识别领域的表现让行人重识别领域的研究人员将其应用在行人重识别任务。行人重识别的主要研究方向有两个:一个是特征表示,另一个是度量学习。

行人重识别研究方向中的特征表示就是通过对所提供的行人图像提取特征来表征行人图像。常用的图像特征有颜色、纹理、形状、边缘等,这些图像特征都有一定的实际意义,可以被人们理解的,也是传统的人工提取特征的重要目标。我国学者 Wang X, Doretto, Sebastian 等^[4]在 2007 年提出了将行人的图像划分为多个区域,在每个区域通过计算共生矩阵来进行描述,将各个区域的特征综合实现对行人图像的整体描述。在 2008 年,Gray D, Tao H 提出了局部特征集成(ensemble of localized features, ELF)算法^[5],该算法将一些简单的特征(例如:颜色通道特征等)通过机器学习算法 AdaBoost(一种迭代算法,将弱分类器组合成强分类器)结合在一起来提高行人重识别的性能。在 2010 年, Farenzena M, Bazzani L, Perina A 等人^[6]提出了局部特征累加对称驱动特征(Symmetry-Driven Accumulation of Local Features, SDALF)。该方法分为四步:第一步,将目标行人从复杂背景中提取出来;第二步,将提取出的行人图像按照外貌特点,将人体分为头部、四肢、躯干三个部分;第三步,将分开的人体分别提取基于 HSV 空间(一种颜色空间)的加权颜色直方图(weighted color histogram, WH)、最大稳定颜色区域(maximally stable color regions, MSR)以及高度结构化图像块(recurrent high-structured patches, RHP)特征;第四步,将这三个特征融合为一个特征作为对行人图像的描述。在 2013 年,范彩霞,朱虹,蔺广逢等^[7]提出类似的多特征目标重识别算法;该算法首先对监控视频所获得的视频进行预处理得到行人图片;然后通过计算行人图像的空间直方图建立目标整体外观表现模型,并使用此模型对具体的行人进行粗识别。在前面粗识别的基础上将人体目标分为 3 个部分,忽略头部信息,分别提取躯干和腿部主色区域的局部色彩和形状特征,并通过 EMD(earth movers distance, 一种距离度量方式,测量两个分布的距离)方法进行目标精识别。在 2013 年, Bazzani L, Cristani M, Murino V^[8]受到 SDALF 的启发,提出了通过人类的视觉线索来表征行人外貌特征的方法;该方法是基于外貌描述子和匹配方法来识别行人,这个描述子将人的特征编码成三个互补的视觉特征:整体的色彩信息,稳定区域的颜色空间分布,具有高熵的并且反复出现的局部特征;通过外貌描述子匹配的方法来实现行人识别。在 2017 年,张耿宁,王家宝,张亚非等^[9]提出了一种基于特征融合的行人重识别算法;该方法首先将行人图像用 Retinex(视网膜 Retina 和大脑皮层 Cortex 的缩写)变换^[10](该变换可以使得处理后的图像包含丰富的颜色信息,并提升阴暗区域的细节效果)进行预处理,然后将颜色特征和纹理特征相结合并通过划分区域的方式获得颜色直方图特征,进而用此特征来描述图像。针对行人重识别这个问题,存在一些独有的特征,比如:行人衣服的颜色、行人的姿态等。因此就有一些将这些独有特征融入深度学习的研究, Matsukawa T, Suzuki E^[11]采用微调的卷积神

经网络特征结合不同属性的标签信息,使用它们作为新的分类损失函数;这个新的损失函数强制让 CNN 来分辨更为特别的行人信息,从而获得更具有区分度的特征。在 2017 年,我国学者 Lin Y, Zheng L, Zheng Z 等人^[12]提出了将行人的属性特征加入行人重识别,在计算损失函数的时候将其和身份识别损失相结合,成为一个多任务学习过程来提高行人重识别算法的性能。针对行人属性获取困难的情况,陈萍,杨鸿波^[13]提出了用深度学习来识别行人属性的方法;这个方法是基于 caffe 框架的深度卷积神经网络,使用行人数据库来训练网络模型,并且允许输入任意大小的图像而不需要进行缩放和裁剪。受到特征层次理论的启发,我国学者 Zhao R, Ouyang W, Wang X^[14]提出了一种新型的学习中等水平特征的方法,设计的中等水平的滤波器对确定某个特定视角模式和分辨目标行人具有良好的效果,并且不随视角的变化而改变。通过该方法可以获得具有区分度和代表性的特征。有一部分学者根据人的空间结构约束来设计相似性函数,Chen D, Yuan Z, Chen B^[15]等人根据行人姿态的变动不是任意的而是随着身体部位(例如:头、躯干、腿)呈现出一定规律的空间分布,分解这些行人姿态的变动,将有助于在空间分布上提高行人的匹配,进而提出了一种新型的相似性函数;这个函数由多个子区域的相似性测量方法组成,通过整合局部相似性和全局相似性的优势,在一定程度上提高了行人重识别在某些行人数据集上的准确率。

行人重识别的主要目的是辨认两张行人图像是否是同一个人,这就与度量学习的主要功能不谋而合,所以将度量学习用到行人重识别上成为了一种自然而然的过程。度量学习的最终目标是通过学习出一个映射矩阵让原图像映射到一个距离空间,在这个距离空间上同类的图像距离变得更短,异类的图像距离变得更长,这样就可以区分是否为相似的图像。距离度量最常用的是欧氏距离,由于欧式距离对尺度比较敏感,当采用此方法时容易得出错误的结论,因此对于距离度量的研究还有很多需要改进的地方。我国学者 Liao S, Hu Y, Zhu N X 等人^[16]提出了局部最大存在(Local Maximal Occurrence, LOMO)和跨视角二次判别分析(Cross-view Quadratic Discriminant Analysis, XQDA)方法。LOMO 方法分析水平方向的局部特征,最大化这个特征以便让这个特征表示能够对视角变换具有稳定性;通过 XQDA 方法对空间进行降维和距离度量。在 2013 年, Pedagadi S, Orwell J, Velastin S 等人^[17]提出了局部 Fisher(在保证局部空间结构的前提下,让同类相聚异类分离的方法)判别分析(Local Fisher Discriminant Analysis, LFDA)。该方法从原始图像颜色空间中提取高维特征,然后分为两个阶段,第一阶段在保证颜色空间冗余度的情况下,采用无监督的主成分分析(Principal Component Analysis, PCA)来进行数据降维;第二阶段采用在训练集上定义的 LFDA 来减少维度。2013 年, Tao D, Jin L, Wang Y 等人^[18]在 KISS(keep it simple and straightforward)度量学习的基础上提出了 RS-KISS(Regularized Smoothing KISS);该方法通过一种有效的方式估计方差矩阵,在这个方差矩阵中,增大被低估

的小特征值并且减小高估的大特征值。通过提供额外的数据，RS-KISS 可以获得更鲁棒的模型。在 2016 年，张耿宁，王家宝，李阳等人^[19]提出了基于核局部 Fisher 判别分析的特征融合方法；该方法首先将传统的核局部 Fisher 判别分析方法的缺点进行了分析，指出其无差别映射从而忽略了不同图像区域的重要性；为此在核局部 Fisher 判别分析的基础上对特征进行区域分组，采用查询自适应得分融合方法来描述图像不同区域的重要性。

除了在特征表示和度量学习有诸多研究外，还有一些研究学者将行人重识别重新定义为排序问题，Prosser B, Zheng W S, Gong S 等人^[20]将支持向量机（Support Vector Machine, SVM）用在行人重识别上，并重新定义了行人重识别问题。

综上所述，行人重识别的主要研究方向是特征表示和度量学习。特征表示方向上，一般采用将传统的图像特征（颜色、纹理以及边缘）结合深度学习来提取相对鲁邦的特征，并且取得了不错的效果。度量学习方向上，主要通过 Fisher 判别分析方法实现类内距离更近类间距离更远，并在此基础上提出局部 Fisher 判别来保留局部的空间结构信息，让效果有所提升。本文通过迁移学习和孪生网络将特征表示和度量学习结合在一起，并针对原始孪生网络学习特征的单一性提出了特征组合方式让其学习到的映射空间更能将同类相聚异类分离。

1.3 本文的研究内容

本文主要通过深度学习对行人重识别的各个环节进行了研究。本文的创新点在于：针对原始图像分割网络 Unet 的信息丢失问题，提出了多尺度的 Unet 网络来缓解；对孪生网络所学特征的单一性，提出了特征组合的方式来丰富学习的特征；将图像的检测、分割以及识别功能整合在一起构成一个简易的行人重识别系统。主要工作如下：

(1)研究了目标检测网络 RetinaNet，对 RetinaNet 的网络结构进行了详细的介绍和分析，并将其应用在行人图像的检测上。本文使用 PASCAL VOC 2012 数据集对检测网络 RetinaNet 进行复现，并通过实验仿真验证了所训练的目标检测网络可以在复杂场景中将行人图像检测出来。将检测到的行人图像截取并保存以便进行接下来的步骤。

(2)改进了经典的分割网络 Unet，让 Unet 网络在检测的基础上进行更加细致的特征提取。原始的 Unet 网络由于下采样过程会丢失一些原始图像的信息，进而影响了图像分割的效果。为了缓解这个影响，本文提出将输入从单一尺度变为多个尺度然后将得到的输出送进对应尺寸的网络层进行训练的方法，通过定性和定量的实验证明了改进网络性能的提升。

(3)提出了一种改进的孪生网络模型，模型在卷积层共享权值。原始孪生网络所学习到的映射空间不足以让同类更近异类更远，本文在预训网络所提取特征的基础上，

提出了特征组合的方式来丰富后端网络学习的特征。主要的改进在于先通过迁移学习获得高维抽象特征然后进行特征运算来丰富后面层学习的特征，从实验仿真中证明了改进网络提高了判别能力。

(4)通过 Python 自带的图形界面库 Tkinter 将检测、分割以及识别功能结合在一起构成一个简易的人机交互的行人重识别系统。

1.4 论文组织结构

本文一共分为六个章节，内容安排如下：

第一章为绪论。首先从行人重识别的研究背景及研究意义的介绍入手，然后对行人重识别的国内外研究现状做了简要的概述，最后总结了本文的主要研究内容。

第二章对目标检测网络模型 RetinaNet 进行了详细地介绍，先是从网络结构出发根据其构成分为三个部分：骨架网络、特征金字塔网络、全卷积神经网络；接着介绍了网络所用到的中心损失函数；然后将复现网络所用到的数据集 PASCAL VOC 2012 进行了简要介绍；最后将复现的模型用于测试图像验证效果。

第三章是分割网络 Unet，首先从网络的结构开始介绍，然后介绍了特征图和感受野之间的关系，并可视化了卷积层学到的特征图；针对原始的 Unet 网络下采样过程会丢失一些原始图像信息的问题，本文提出将输入从单一尺度变为多个尺度并配合其下采样过程同时输入网络的方法，并通过实验仿真验证了改进后网络的效果。

第四章是迁移学习和孪生网络，首先对迁移学习的概念进行系统的介绍，然后对孪生网络的结构进行分析，在此基础上提出特征组合的方式来学习更为丰富的特征，最后通过行人重识别的数据集进行实验仿真。

第五章是基于 Python 中的 Tkinter 模块来进行图形界面的开发。首先介绍 Tkinter 模块各个组成部件的基本功能，然后用其进行界面设计并对其实际效果进行展示。

第六章是总结与展望，总结本文的工作和创新点，对后续研究工作的研究方向和改进方向进行展望。

第二章 目标检测网络 RetinaNet 介绍

2.1 目标检测方法介绍

行人重识别任务的完成首先要获取行人图像,通常摄像头所拍摄的图像是行人在某个场景中,单个行人图像的获取就要求我们从复杂场景中将行人图像准确地提取出来然后才能进行接下来的分析和识别。从复杂场景中将行人图像提取出来的技术就叫做目标检测,所以本文安排从目标检测入手,逐步开展对行人重识别任务的研究。

目标检测在深度学习快速发展的这几年已经取得了很多进展, Zhang S, Wen L, Bian X 等人^[21]的论文中将目前的目标检测方法进行了一个简略的概述。目前的目标检测方法主要是基于深度学习的,其主流方向可以分为两类:一种是双阶段的方法,另一种是单阶段的方法。其中双阶段检测方法的代表是 R-CNN (Regions with Convolutional Neural Networks) 系列算法,主要思路是先通过启发式搜索的方式或者 CNN 网络产生一系列候选框,然后对产生的候选框进行分类和回归。单阶段检测方法的代表是 Yolo (You Only Look Once)^[22]和 SSD (Single Shot MultiBox Detector)^[23]算法,主要思路是均匀地在图片的不同位置进行密集抽样,抽样时可以采用不同尺度和长宽比,然后使用 CNN 提取特征后直接进行分类与回归。

双阶段的目标检测方法优点是准确率高,因为其第一阶段选出的候选框是经过筛选的,正负样本不会特别失衡,送入模型进行训练就相对容易;但是由于双阶段的后续步骤是建立在前一个阶段的基础上所以在图像处理速度上就略微慢于单阶段的目标检测方法,处理速度的相对较慢就是双阶段的目标检测方法的主要缺点。单阶段的目标检测算法的处理速度相对于双阶段目标检测算法的确略胜一筹,但从准确率来看,单阶段就明显处于劣势。对单阶段目标检测算法的性能起决定作用的还是其设计思路,单阶段的目标检测算法的主要思路是对图像进行均匀地密集采样,这种方法训练比较困难的原因在于正样本和负样本(背景)极其不均衡,进而导致分类模型在进行正负样本判决的时候往往倾向于负样本,因此其最终的准确率稍低。

通过上面的分析可以知道,单阶段目标检测准确率偏低的主要原因是由于正负样本不均衡,正负样本不均衡间接影响了检测网络的训练过程。预测框的损失可以分为两类:一类是由正样本引起的,另一类则是由负样本引起的。当预测框和真实框之间的交并比 (Intersection-over-Union, IoU) 大于设置的阈值时,一般会认为这个预测框属于正样本;当交并比小于设置的阈值时,则认为这个预测框属于负样本。一般情况下,输入图像中目标所占的比例都是远远小于背景所占的比例,所以在背景和目标这两类之间,背景也就是负样本占了绝大多数,这就导致了两个问题:

1、负样本占据了绝对的数量优势，所以在计算损失的时候，负样本所引起的损失就会掩盖正样本所产生的损失，不利于训练过程的收敛；

2、负样本的数量虽多，但是在负样本中，大多数不在前景和背景的过渡区域上，也就是说大多数的负样本分类都很容易被称为 **easy negative example**，这类负样本在训练的时候所对应的置信度会很高，对于单个样本来说也就是所产生的损失很小，在反向计算梯度的时候梯度值就会很小，过小的梯度造成这类负样本对于参数的更新作用很有限，所以真正在计算损失起作用的负样本是 **hard negative example**。

双阶段的目标检测方法就很好的缓解了上述的两个问题。对于第一个问题，双阶段的目标检测方法会根据交并比的大小来调整正负样本的比例，这样就解决了负样本过多的情况。对于第二个问题，双阶段的目标检测方法会根据置信度的高低过滤出最有可能是前景的样本，由于过滤的依据是置信度的高低，所以就能把大量背景概率高的 **easy negative example** 给过滤掉，这样就解决了对参数更新贡献很小的 **easy negative example**。上面提到的各种 example 的示意图如 2.1 所示：




图2.1 几种 example 示意图

双阶段方法主要解决的是 **easy example** 的问题。

为了让单阶段的目标检测算法在准确率上能缩小和双阶段目标检测算法的差距，何凯明团队^[22]提出了中心损失函数；该函数很好的在准确率和速度上做了一个平衡，这个损失函数是在 **RetinaNet** 网络中进行实验的，结果表明了可以缓解上面单阶段目标检测算法提到的类别不均衡问题，并且可以在保证速度的同时达到双阶段目标检测方法的准确率。

2.2 网络模型 RetinaNet 结构介绍

RetinaNet 是 2017 年由 Facebook AI 团队提出的一种目标检测网络模型，按照上面对目标检测算法的分类来看，这是一个单阶段的目标检测网络。这个检测网络的主要创新点在于其提出的中心损失函数很好地缓解了目标检测中正负样本不均衡的问题，其次它又将骨架网络——残差网络^[24]（Resnet）和特征金字塔网络^[25]（Feature Pyramid Networks, FPN）以及全卷积网络^[26]（Full Convolutional Networks, FCN）结合在一起来进行网络的训练，通过这两点创新将单阶段目标检测的准确率提高到和双阶段几乎持平的状态。

2.2.1 骨架网络 Resnet 介绍

骨架网络是整个网络的基石，因为从这个网络提取出的图像特征要送到后续的网络结构中进行分析和处理，骨架网络的质量直接决定了整个网络最终的呈现效果。Resnet 是一个实用效果比较好的网络模型，选择这个网络作为骨架网络也一定程度上说明了这个模型的性能。

Resnet 网络的提出是应对随着网络的加深而训练集准确率下降的现象，这不是一种过拟合的现象，因为过拟合现象的表现是在训练集上的准确率会越来越高而测试集的准确率则出现下降。Resnet 网络的全称叫做深度残差网络，它允许网络尽可能加深的同时并不会让已经饱和的网络性能下降，它能做到不让已经饱和的网络性能下降的主要原因在于其网络结构，它的网络结构如图 2.2 所示：




图2.2 残差网络结构示意图

图 2.2 中的 x 表示输入，线性修正单元 ReLU（Rectified Linear Unit）是激活函数，weight layer 代表卷积网络的层结构， $F(x)$ 表示图中两个层结构所构成的映射关系。

从图中我们可以看出 x 从输入到输出有两条通路也就对应了两种映射方式,一种是普通的网络连接方式对应的映射是 $F(x)$;另一种是直接跨过了中间的权重层直接和输出的前一层连接起来,这种映射对应于线性映射(这个线性映射是 $y=x$),所以最后的输出是 $y=F(x)+x$ 。跨层的映射被称为 **identity mapping**,指的是 x 本身;而 **residual mapping** 指的是“差”,也就是 $y-x$,所以残差指的是 $F(x)$ 。为了应对随着网络层数的加深会出现训练集准确率下降的现象,Resnet 提供了两种映射方式,如果网络已经达到了最优,继续加深网络,残差映射将会强制归零,这样的话就只剩下本体映射,从理论上来讲网络一直处于最优的状态。

图 2.2 所展示的残差网络结构图只是讲述了残差结构所有的两种映射关系,但中间方框里面的权重层却是黑匣子式的表示,权重层到底是由多大尺寸的卷积核构成以及卷积核的数量是多少,这些参数我们从图 2.2 中无法得知,缺少这些必要的参数不能指导代码的编写也就是说无法将想法落地实现。所以上面的网络结构图只是大概的表示了一下主要思路,而真正使用的时候需要比上面的隐含表示更为具体的网络结构图,实际编写代码的时候则会有两种残差模块的方式可供选择。图 2.3 展示了两种不同的残差模块:




图2.3 两种不同的残差模块

图 2.3 中方框中的 3×3 或者 1×1 代表卷积核的尺寸而其后面的数字代表卷积核的数量, $64-d$ 或 $256-d$ 中的 d 代表维度。这两种不同的残差模块对应于不同层数的 Resnet 网络,左图的连接方式对应于 Resnet34,右图的连接方式对应于 Resnet50/101/152,一般称整个结构为一个“building block”。其中右图又称为“bottleneck design”,其设计的目的显而易见,就是为了降低参数的数目,第一个 1×1 的卷积把 256 维通道数(channels)降到 64 维,然后在最后通过 1×1 卷积恢复。对于这两种残差模块的选

择，主要是看所使用的网络层数；如果网络层数较多（超过 50 层）一般选用右边的残差模块这样可以减少训练的参数加快训练速度，而层数较少（低于 34 层）时则选用左边的残差模块此时参数本来就不多所以就不用太在意参数对训练速度的影响。另外需要说明的是，Resnet 系列网络层数的计算并不计算激活层和池化层，它们的层数计算是通过卷积层和全连接层计算得到的。

2.2.2 特征金字塔网络 FPN 介绍

特征金字塔网络的发展是一个循序渐进的过程，从传统手工提取特征中所用的图像金字塔开始，逐渐到单层特征映射，随后根据图像金字塔和单层特征映射研究工作的启发，发展出了金字塔特征层次化，综合上面的研究加上深度学习的思想最终形成了特征金字塔网络。

在图像金字塔的基础上构建的图像特征金字塔是应对计算机视觉中多尺度目标检测问题的传统解决思路。对不同尺度的图像采用与其对应大小的图像特征进行预测可以有效地提升多尺度目标检测算法的效果。从特征的表现形式来看，这种方法可以允许模型检测尺度跨度范围较大的图像。图像特征金字塔的示意图如图 2.4 所示：




图2.4 图像特征金字塔

图像特征金字塔主要在人工提取特征中使用，但是随着深度学习的发展 CNN 提取特征成为主流方式，CNN 提取特征的过程是自动的，提取的特征鲁棒性更好。尽管 CNN 有以上的优点，但是在多尺度目标检测任务上还是需要金字塔结构的辅助来进一步提高性能。金字塔结构的优势是其每一层产生的特征在语义信息上都是逐层加强的，这一特性可以让网络学到较为丰富的语义信息；但在具体进行每一层的处理时会有很多限制，层数多不但导致对算力的要求高而且还会增加训练的时间。为了应对 CNN 金字塔结构的耗时耗力问题，需要提出一种和图像金字塔类似的多尺度特征表示方法。从 CNN 计算方式可以知道，其计算的中间结果本身就存在多级特征图，且不同层的特征图尺度就不同，形似金字塔结构，如图 2.5 所示。




图2.5 单特征映射

从图 2.5 可以看出，原始图像经过卷积层后形成了不同尺度的特征图，结构上类似于金字塔，最终预测的时候采用的是顶层的特征图。通过上面的分析可以知道，顶层特征虽然具有丰富的语义信息但是获得这些语义信息的代价是丢失了原始图像中目标的位置信息，这样在进行目标检测的时候可以进行很好的分类但不能进行很好的定位。产生这种结果的原因是对特征图没有充分使用，导致位置信息的丢失。

层次金字塔特征方法弥补了单特征映射特征图使用不充分的问题，其设计思路如图 2.6 所示。




图2.6 层次金字塔特征

从图 2.6 可以看出，除了原始图像外每一层的特征图都参与了结果预测。这些预测结果会进行融合来生成最终的结果，直观上来看确实充分使用了特征图但这种结构有个缺陷是对于小目标的检测效果不好，究其原因在于其没有将更为底层的特征利用起来让较小的目标也可以被检测出来。

为了将层次金字塔没有使用的底层特征利用起来，提出了特征金字塔网络。特征金字塔网络 FPN 的思路是将低分辨率、高语义信息的高层特征和高分辨率、低语义信息的低层特征进行自上而下的侧边连接，使得所有尺度下的特征都有丰富的语义信息。这种结构是在 CNN 网络中完成的，和上面提到的基于图片的金字塔结构不同，而且完全可以替代它。其思路设计图如图 2.7 所示：




图2.7 特征金字塔网络示意图

从图 2.7 可以明显看出，整个结构分为两个部分。图中左边自下而上的过程是 CNN 的前馈计算，原始图像经过卷积层的运算变得越来越小，达到指定尺寸后就结束了自下而上的过程。图中右边的部分是自上而下的过程，通过将具有丰富语义信息的高层特征图进行上采样，然后把自下而上产生的同样大小的特征图和该特征横向连接（lateral connections），通过这种连接方式高层特征得到加强。横向连接不仅让高层特征得到了加强而且还利用了底层特征的位置信息，让小目标也可以被检测出来。横向连接的细节如图 2.8 所示：




图2.8 特征金字塔网络(FPN)横向连接的细节图

图 2.8 向我们展示了横向连接过程中的具体操作过程。从图中可以看出，FPN 横向连接的时候首先把高层特征进行 2 倍上采样，采样方式为最近邻上采样法，将其和对应的特征层通过 1×1 卷积（采用 1×1 的卷积主要是为了让通道数一致以便进行后续的计算）后的特征进行融合，融合的方式是做像素间的加法。在融合之后还会再采用 3×3 的卷积核对每个融合结果进行卷积，目的是消除上采样的混叠效应（aliasing effect）。FPN 算法在利用低层特征高分辨率特性的同时还结合了高层特征的高语义信息，通过融合这些不同层的特征来实现目标检测的目的，并且预测过程是在每个融合后的特征层上单独进行的。

2.2.3 全卷积神经网络 FCN 介绍

全卷积神经网络从其名字就可以知道，该神经网络的主要组成部分应该是卷积层，结构的不同导致其应用领域也与经典卷积神经网络不同。经典卷积神经网络的构成是由卷积层和池化层交替出现数次之后加入若干个全连接层，这些全连接层将卷积层提取的特征图映射成一个固定长度的特征向量。以 AlexNet 为代表的经典卷积神经网络结构适合于图像级的分类和回归任务；不管是分类任务还是回归任务，它们都要求网络最终输出一种数值来描述所输入的图像。下面通过一个分类任务的例子来说明经典卷积神经网络是如何完成目标。在 ImageNet 分类比赛中，需要分类的类别有 1000 类，模型最后输出的向量长度就是 1000，这个向量中的每一位代表所属类别的概率值（此值是通过 softmax 函数归一化的）；将一张猫的图像输入模型中，在得到的长度为 1000 的向量中；如果模型分类正确，会有一个位置的值远远大于其他位置的值，这个位置所对应的图像类别就是猫，其过程如图 2.9 所示：




图2.9 经典 CNN 实现图像分类示意图

全卷积神经网络区别于一般卷积神经网络的功能是其能实现对图像像素级的分类，从而解决了语义级别的图像分割问题。通过上面的例子可以了解到经典的卷积神经网络在解决分类问题时输出一个和任务类别数相同的特征向量，而全卷积神经网络的输出则是和原图像相同大小的图像，该图像会将不同目标以及背景的轮廓以不同的颜色表示出来。由于全卷积神经网络不使用全连接层所以对输入图像的尺寸没有要求，全卷积神经网络经过普通卷积后特征图的尺寸会有所减小，到了最后一个卷积层后，

会有一个反卷积^[27]层（类似于上采样可以使图像越来越大，也被称为分数步长卷积、后向卷积、转置卷积）。该卷积层对最后一个卷积层的特征图进行上采样，使它恢复到输入图像相同的尺寸，从而可以对每个像素都进行预测，同时保留了原始输入图像中的空间信息，最后在上采样的特征图上进行逐像素分类。全连接神经网络的结构示意图如图 2.10 所示：




图2.10 全卷积网络(FCN)结构示意图

从图 2.10 我们可以看出，输入是一张含有猫和狗的图像，输出是和原图像同样尺寸的掩膜。图中有两个箭头，从输入指向输出的箭头上写着 forward 和 inference，说明这个箭头代表的过程是前向传播和推断；从输出指向输入的箭头下面写着 backward 和 learning，说明这箭头代表的过程是反向传播和学习。输出的前一层有一个和原图像同样尺寸但是通道数是 21 的特征图，该特征图上面写着 pixel-wise prediction，这个特征图是通过反卷积得到的，21 是分割图像类别数 20 加上背景 1 得到的。输入图像和反卷积后的特征图之间的层是普通的卷积层。

2.2.4 检测网络 RetinaNet 的中心损失函数

RetinaNet 网络的主要创新之处在于其提出的中心损失函数很大程度上缓解了单阶段目标检测算法中的正负样本极其不平衡的问题，另外结合 FPN 和 FCN 的网络结构进行训练缩小了单目标检测算法和双阶段目标检测算法之间准确率的差距。其提出的中心损失函数是通过改进原有的交叉熵（Cross-entropy, CE）损失函数，从而将其用于处理类别极其不平衡的问题。

首先介绍二分类的交叉熵损失函数：

$$CE(p, y) = \begin{cases} -\log(p) & , y=1 \\ -\log(1-p) & , otherwise \end{cases} \quad (2-1)$$

其中, $y \in \{\pm 1\}$ 表明了真实的类别信息, $p \in [0, 1]$ 是模型对于标签 $y = 1$ 的类的估计概率。为了方便, 我们定义 p_t :

$$p_t = \begin{cases} p & , y = 1 \\ 1 - p & , otherwise \end{cases} \quad (2-2)$$

通过上面的定义公式(2-2)可以转化为:

$$CE(p, y) = CE(p_t) = -\log(p_t) \quad (2-3)$$

解决类别不平衡的常见方法是分别为类别 1 和类别-1 加入权重因子 $\alpha \in [0, 1]$ 、 $1 - \alpha$ 。所以 α -balanced 的 CE 损耗可写为:

$$CE(p_t) = -\alpha_t \log(p_t) \quad (2-4)$$

鉴于以上的改进过程的思想, 可以将交叉熵损失增加一个调节因子 $(1 - p_t)^\gamma$, 其中 $\gamma \geq 0$ 。这样便出现了 Focal Loss, 其定义为:

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t) \quad (2-5)$$

公式(2-5)为理论推导出的结果, 在实际训练中使用的 Focal Loss 形式为:

$$FL(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (2-6)$$

其中的 p_t 是不同类别的分类概率, γ 是一个大于零的值, α_t 是一个在 0 到 1 之间的小数, γ 和 α_t 都是固定值, 不参与训练。

从公式(2-6)可以看出, 无论是背景类还是前景类, p_t 的值越大, 权重 $(1 - p_t)^\gamma$ 的值就会越小。通过权值的约束, 可以让置信度预测较高的样本对损失的贡献降低。调节因子 α_t 是用于调节正样本和负样本之间的比例, 前景类别判断的时候用 α_t , 对应的背景类别的判断就使用 $1 - \alpha_t$ 。 γ 和 α_t 的值是相互影响的, 所以在评估准确率的时候需要将两者结合起来使用, $\gamma = 2$ 和 $\alpha_t = 0.5$ 是论文作者通过实验对比给出的性能比较好的一种组合。

在训练的初始阶段由于正负样本分类的概率基本是一致的, 也就是说 p_t 的值不会很大或很小, 这样中心损失函数就起不到抑制简单样本(容易被检测并分类的样本)

的作用，为了打破这种平衡的状态，训练时对最后一级用于分类的卷积的偏置进行了修改，把它初始化成一个特殊的值 $b = -\log((1-a)/a)$ ， a 的取值是 0.01，这样能在训练的初始阶段提高正样本的分类概率。

2.2.5 检测网络 RetinaNet 总结

本文是从 RetinaNet 网络的组成结构开始介绍的，上面的章节是将骨架网络、FPN、FCN 分开介绍的，对于它们之间的连接关系并没有介绍，图 2.11 给出了其在论文中的实际结构关系：




图2.11 检测网络 RetinaNet 结构

图 2.11 分为四个子图，分别是 a、b、c、d，其中 a 图是骨架网络 ResNet，b 图是 FPN，c 是分类子网络，d 是边界框回归子网络。a 图是自下而上的过程，其主要功能是对原始图像提取特征；b 图是自上而下的过程，其主要作用是充分使用 a 产生的特征图的位置信息以便更好地进行目标定位；c 图是分类子网络，其主要功能是进行目标图像的类别划分并计算分类损失；d 图是边界框的回归子网络，其主要功能是进行框定目标的边界框的参数回归并计算回归损失。网络最后进行反向传播计算的损失是分类和回归损失之和。需要注意的是，在训练过程中，FPN 每一级的所有样本都被用于计算中心损失，将这些样本的损失加到一起用于训练；在测试过程中，FPN 每一级只选择置信度最大的 1000 个预测框进行非极大值抑制（Non-Maximum Suppression, NMS）。

2.3 训练数据集 PASCAL VOC 2012 介绍

PASCAL VOC 2012 数据集来自 PASCAL VOC 举办的图像比赛，其中 PASCAL VOC 的全称是 Pattern Analysis Statical Modeling and Computational Learning Visual Object Classes Challenge。该数据集可以用于图像分类、目标检测、图像分割等任务。

VOC2012 数据集分为 20 类，包括背景为 21 类，其中通过属性或功能又将其分

为四大类，分别如下：

- 1.人；
- 2.动物：鸟，猫，牛，狗，马，羊；
- 3.交通工具：：飞机，自行车，船，公共汽车，小汽车，摩托车，地铁；
- 4.室内用品：瓶子，椅子，餐桌，盆栽植物，沙发，电视/监视器。

该数据集有 5 个文件夹，分别是：Annotations、ImageSets、JPEGImages、SegmentationClass、SegmentationObject。下面我们对这 5 个文件夹的内容一一介绍。

首先从 Annotations 文件夹介绍，该文件夹共含有 17125 个子文件，每一个子文件是可扩展标记语言（eXtensible Markup Language, xml）格式。子文件的个数就是图像的张数，子文件里的标记内容如图 2.12 所示：

```
<?xml version="1.0"?>
- <annotation>
  <folder>VOC2012</folder>
  <filename>2007_000027.jpg</filename>
  - <source>
    <database>The VOC2007 Database</database>
    <annotation>PASCAL VOC2007</annotation>
    <image>flickr</image>
  </source>
  - <size>
    <width>486</width>
    <height>500</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  - <object>
    <name>person</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    - <bndbox>
      <xmin>174</xmin>
      <ymin>101</ymin>
      <xmax>349</xmax>
      <ymax>351</ymax>
    </bndbox>
    - <part>
      <name>head</name>
      - <bndbox>
        <xmin>169</xmin>
        <ymin>104</ymin>
        <xmax>209</xmax>
        <ymax>146</ymax>
      </bndbox>
    </part>
  </object>
</annotation>
```

图2.12 可扩展标记语言(xml)文件的部分标记内容

图 2.12 中的第一行是 `xml version="1.0"`，说明这个 xml 文件是 1.0 版本的；从第二行就开始介绍和 xml 文件对应图片的标记信息了。`folder` 表示该文件所属的文件夹；`filename` 指的是图片的名字；`source` 指明了该图片的来源；`size` 下有 `width`、`height`、`depth`，分别表示图片的宽、高以及通道数；`segmentated` 表示是否可以用于语义分割，0 表示不可以，1 表示可以；`object` 表示要检测的目标，如果有多个检测目标会有多个 `object`；`name` 表示检测目标的类别，该文件对应的图片类别是人；`pose` 表示图片所拍摄的角度，`Unspecified` 代表未说明；`truncated` 表示目标是否被截断，0 表示完整，1 表示截断；`difficult` 表示目标是否难以识别，0 表示容易识别，1 表示识别困难；`bndbox` 的全称是 `bounding box`，表示检测目标在图像中的位置信息；`xmin`、`ymin`、`xmax`、`ymax` 表示的边界框左上角和右下角的横纵坐标；`part` 表示检测目标的肢体部分信息；从 `name` 是 `head` 可以知道该部位是头部。

通过 xml 的信息，我们可以通过可视化的方式将这些目标和边界框的信息表示来，其具体效果如图 2.13 所示：




图2.13 目标和边界框可视化

图 2.13 是根据图 2.12 中的信息所画，其中手和脚的信息由于图片长度原因并没有在图 2.12 显示。从图 2.13 可以看出，目标的确是人，并且准确的将其在图像中的位置用边界框给框了起来，除了目标本身被框了出来，其肢体头、手和脚都被框了出来

来，这些被框出的肢体信息可以用于行人肢体的检测。

ImageSets 文件夹中含有 4 个子文件夹，分别是：Action、Layout、Main、Segmentation。Action 里面存放的是人的动作信息，Layout 里面存放的是人体部位的信息，Main 里面存放的是图像物体识别的信息，总共分为 20 类；Segmentation 里面存放的是可用于分割的图像信息。

JPEGImages 文件夹含有 17125 张图片，该文件夹包括了训练集和验证集的所有图片；从文件夹的名字就可以看出图片的格式是 JPEG（JPEG 和 JPG 通常是指的同一种类型），联合图像专家组 JPEG（Joint Photographic Experts Group）是一种常用的图像格式；图片的命名规则是年份加下划线加编号的方式。图 2.14 给出几张图片的例子：



图2.14 文件夹 JPEGImages 中的示例图片

从图 2.14 可以看出，图片的命名规则符合上面说的命名方式，另外每个图片的尺寸是不一致的，图片人物所包含的场景是复杂多变的，这样的训练集有利于训练出鲁棒性较好的模型。

SegmentationClass 文件夹含有 2913 张图片，每一张图片都对应于 JPEGImages 文件夹中相同名字的图片，图片像素的种类共有 21 种，其中有一类黑色的代表背景，其余 20 类代表 20 类不同的目标。

SegmentationObject 文件夹中的图片数目和 SegmentationClass 文件夹是相同的，其图片编号也是和 SegmentationClass 文件夹是一样的，它们的区别就在于其所分割的对象，一个是针对具体类的，另一个是针对目标的。下面通过图示来具体说明它们之间的区别：





图2.15 文件夹 SegmentationClass 和 SegmentationObject 区别说明图

图 2.15 分为三个子图，分别是 a、b、c，图 a 是从 JPEGImages 文件夹中取出的一张原始图像，图 b 是从 SegmentationClass 文件夹取出的对应原始图像编号的分割图，图 c 是从 SegmentationObject 文件夹取出的对应原始图像编号的分割图。从 b 图可以看出分割的两台电脑是以同一种颜色表示的，图 c 中的两台电脑是以不同的分割颜色表示的；由此说明 SegmentationClass 文件夹所对应的分割任务，只需要将不同类别的物体区分开即可，对同一类别的物体并不加以区分，而 SegmentationObject 文件夹所对应的分割任务是对同一类别的物体也要区分开来。

2.4 实验仿真分析

针对本章介绍的 RetinaNet 检测网络，采用深度学习的 Keras 框架对 RetinaNet 网络进行了复现，采用的设备是两块 NVIDIA TITAN V GPU，每块显存 12G，所用的训练数据集是 PASCAL VOC 2012，由于本论文采用此检测网络目的只是为了将训练或测试图像中的行人图像提取出来即可，并不是改进网络从而与其他检测网络进行对比实验，所以对于目标检测的评价指标并没有做过多分析和实验。本实验的目的是检验所复现的 RetinaNet 检测网络能否检测出复杂场景中的行人，其具体的训练过程以及参数设置可以参考原论文的分析 and 设置。接下来就从实际测试效果上来说明所复现网络的性能。

为了提高实验的可信度，用于测试的行人图像不是从训练数据集 PASCAL VOC 2012 中选择，而是从互联网上随便下载一张行人图像来进行行人检测实验，行人原图像及其检测结果如图 2.16 所示：



(a)原始图像

(b)经过检测网络后的图像

图2.16 检测网络 RetinaNet 行人图像检测结果

图 2.16 中分为两个子图 a 和 b，其中 a 图为测试的原始图像，b 图为经过检测网络后的结果图像。从图 2.16 中可以看出，a 图所展示的图像是三个阿姨买菜回小区的照片；通过所复现的检测网络 RetinaNet 后，所得的结果图像如 b 图所展示的那样，原图中的三个行人都被准确地检测出来；检测出的行人图像的上方有类别加置信度的标识信息，从左至右，三个行人的置信度分别是：0.810、0.828、0.905，从目标的置信度得分来看，所复现的网络在识别上的准确度是符合要求的。从上面的分析可以得出，所复现的检测网络性能基本符合行人重识别的第一阶段行人检测的预期目标。

2.5 本章小结

在本章中，首先对基于深度学习的目标检测方法进行了一个粗略的分类，并对现阶段目标检测所面临的问题进行了详细的分析；接着对 RetinaNet 网络的组成部件——骨干网络 Resnet、FPN、FCN 的网络结构进行了细致的介绍，然后分析了中心损失函数 Focal Loss 以及其参数的作用；接着将落地实现时用到的网络结构进行了介绍；网络模型构建完成后下面就需要使用数据进行模型的训练，所以紧接着介绍了 PASCAL VOC 2012 数据集；最后对复现的网络进行了测试并对结果进行了简略分析。

第三章 分割网络

3.1 图像分割介绍

图像分割是指将一幅图像分解为若干互不交迭区域的集合,是图像处理和计算机视觉的基本问题之一^[28]。从上面的学术定义可以了解,图像分割是分解图像的一种方式。根据图像分割所呈现的结果,我们大致可以推断其用途至少有以下三个方面:首先,图像分割可以应用在医学领域,对生物医学图像进行划分可以帮助医生对发生病变的器官进行分析并进一步确定病变的位置;其次,图像分割可以应用在遥感图像上,高分辨率的遥感图像可以为森林火灾、泥石流、地震等自然灾害的发生进行监测;最后,图像分割可以用于安全领域,通过对模糊监控图像的处理,忽略掉背景等其它干扰信息获得有利于提取目标信息的图像。本文将图像分割作为行人重识别任务的一环,其中就考虑到它在安全领域的用途。本文所要介绍的是基于深度学习的图像分割方法。

图像分割是很早就开始进行研究的问题,只是近年来深度学习的发展又为图像分割提供了一种新的解决思路。基于深度学习的图像分割方法的主要思路是通过卷积神经网络进行语义分割,其具体操作流程分为三步:首先是普通的卷积过程将图像进行下采样然后通过上采样恢复原始图像大小;然后将第一步所获得的特征图进行融合;最后对融合后特征图中的每一个像素进行类别判断。最近基于深度学习的图像分割有了很多发展,上一章提到的 FCN 网络让经典卷积神经网络最后的输出不再是一个特征向量而是一张多维的特征图从而开启了深度学习在图像分割中的应用;Badrinarayanan V, Kendall A, Cipolla R^[29]提出的 SegNet 网络是上采样过程和下采样过程完全对应的一种网络模型;Chen L C, Papandreou G, Kokkinos I 等^[30]提出 DeepLab 网络解决了 FCN 引入噪声的问题,该网络通过空洞卷积来保证输出尺寸不至于太小,进而就不用像 FCN 对原始图像进行 padding 从而产生引入噪声的问题;He K, Gkioxari G, Dollar P 等^[31]提出的 Mask RCNN 网络同时将目标检测和图像分割两个任务结合了起来,并缓解了 Faster RCNN 中的 RoiPooling 效应,该效应产生的原因是此操作会找到原始图像映射在最后输出的特征图上的区域但它找寻过程中有一步化整处理从而丢失了细节信息,而 Mask RCNN 提出的 RoiAlign 采用插值的方法来取代化整处理,进而缓解了 RoiPooling 效应;Liu Z, Li X, Ping L 等^[32]提出的 PSPNet (Pyramid Scene Parsing Network),借鉴了金字塔特征的结构信息,提出了全局金字塔池化来改善效果。上面提到的基于深度学习的图像分割模型都需要大量的标签数据进行训练,但行人图像的分割标签并不容易获得,能够收集的数据比较有限,所以需要一种不需要过多分割数据还能达到分割效果的网络结构,这时就提出了 Unet 网络。

3.2 分割网络 Unet 的网络

Unet 网络结构是 2015 年由 Ronneberger O, Fischer P, Brox T 等^[33]提出来的, 该分割网络是在 FCN 的基础上改进的, 有些研究人员将其用于细胞图像分割证明了此网络结构在数据量很少的情况下依然能够取得不错的分割效果。下面我们就从网络结构上来分析 Unet。Unet 的网络结构如图 3.1 所示:




图3.1 分割网络 Unet 结构

图 3.1 的右下角有一个符号说明, 蓝色向右的箭头代表 3x3 的卷积所用的激活函数是 ReLU, 灰色向右的箭头代表复制和剪切两个操作, 红色向下的箭头代表 2x2 的最大池化过程, 绿色向上的箭头代表扩大尺寸的反卷积操作, 青色向右的箭头代表 1x1 的卷积操作。从图 3.1 中我们可以看出网络结构可以分为两个部分: 左边的下采样过程和右边的上采样过程。网络结构的形状像英文字母 U 所以就叫做 Unet 网络模型。根据网络空间结构的划分我们将分为上采样和下采样两个过程对 Unet 网络进行详细分析。

首先, 对左边的下采样过程进行分析。输入的图像尺寸是 572x572, 通道数为 1, 经过两个卷积过程尺寸变为了 568x568, 通道数变为了 64, 接着通过了最大池化进入下一级; 尺寸缩小了一半, 通道数不变, 接着又通过两个 3x3 的卷积将尺寸缩小通道数增加; 从原始图像经历了 4 次上述操作后, 特征图的尺寸变为了 32x32, 通道数是

512, 最后经过一个 3×3 的卷积后提取到了一个尺寸为 30×30 , 通道数为 1024 的特征图。

上采样过程是自下而上的过程, 开始是一个尺寸为 30×30 , 通道数为 1024 的特征图, 经过 3×3 卷积后, 尺寸减小, 通道数不变, 开始进行上采样过程; 经过 4 个转置卷积将特征图的输出变为了 388×388 , 通道数为 2, 两个通道代表需要分割的图像类别只有 1 类, 另一个代表背景。

中间的连接代表将相同尺寸的特征图进行拼接, 目的是加强特征的使用, 获得低层特征的位置信息。另外需要说明的是, 图 3.1 所提供的 Unet 网络结构是一个特殊例子, 选择此图只是为了说明 Unet 网络结构的特点。

上面介绍了 Unet 的网络结构, 下面将介绍其训练过程中的一些信息。该网络结构一般采用随机梯度下降法作为优化器来训练网络, 我们使用高动量项来决定新一轮优化的步长。能量函数是通过最后特征图交叉熵损失函数以及像素级的软最大来计算的。软最大的公式为:

$$p_k(x) = \frac{\exp(a_k(x))}{\sum_{k'}^K \exp(a_{k'}(x))} \quad (3-1)$$

其中, $a_k(x)$ 表示在特征通道 k 中的像素位置 x 处的激活值, $x \in \Omega$, $\Omega \subset Z^2$, K 是类别的数目, $p_k(x)$ 是最大似然函数。

交叉熵惩罚了每一个位置的偏差, 其公式为:

$$E = \sum_{x \in \Omega} w(x) \log(p_{l(x)}(x)) \quad (3-2)$$

其中, $l: \Omega \rightarrow \{1, \dots, K\}$ 代表的是每个像素的真实标签, $w: \Omega \rightarrow R$ 代表的是权重值, 权重的大小是根据像素在训练中的重要性而分配的, 其计算公式如下所示:

$$w(x) = w_c(x) + w_0 \cdot \exp\left(-\frac{(d_1(x) + d_2(x))^2}{2\sigma^2}\right) \quad (3-3)$$

其中, $w_c: \Omega \rightarrow R$ 代表的是平衡类别频率的权值映射, $d_1: \Omega \rightarrow R$ 代表的是离边界最近的目标的距离, d_2 表示离边界第二近的目标的距离, 论文中将 w_0 设为 10, σ 约等于 5。

权值的初始化是很重要的, 否则会有部分神经元被过分激活, 而另一部分则几乎没有什么贡献。论文中选用的就是标准差为 $\sqrt{2/N}$ 的高斯分布, 其中 N 表示一个神经

元的输入节点个数，例如：对于之前层是一个 $3 \times 3 \times 64$ 的神经元来说， $N = 3 \times 3 \times 64 = 576$ 。

上面从 Unet 网络结构特点和训练过程中的一些参数设置进行了介绍，虽然此网络不需要大量的标注数据进行训练也能取得不错的效果，但其特征提取阶段也就是下采样过程中会丢失掉一部分原始图像的位置信息，这会对最后的分割效果产生一些影响。为了缓解这个问题，下一节从特征图的角度出发来尝试分析其原因。

3.3 卷积层特征图的可视化

卷积神经网络对图像特征的提取过程起关键作用的是卷积层，因此为了更好地指导网络结构的设计，对卷积层特征图的可视化就成为了一个不可避免的问题。在进行卷积层特征图可视化之前，首先需要了解一下感受野这个概念。

感受野，在卷积神经网络中所代表的意思是：决定某一层输出结果中一个元素所对应的输入层的区域大小。上面的定义是从神经网络的角度给出的，如果从数学的角度说，感受野是卷积神经网络中的某一层输出结果的一个元素对应输入层的一个映射。更为具体点就是特征图上的一个点对应原始图像上的区域。为了更好的理解，下面给出感受野的计算公式以及运算示意图。

$$j_{out} = j_{in} * s \quad (3-4)$$

$$r_{out} = r_{in} + (k-1) * j_{in} \quad (3-5)$$

$$n_{out} = \left\lfloor \frac{n_{in} + 2p - k}{s} \right\rfloor + 1 \quad (3-6)$$

$$start_{out} = start_{in} + \left(\frac{k-1}{2} - p \right) * j_{in} \quad (3-7)$$

其中， n 代表特征的数目， r 代表感受野的大小， j 代表两个相邻特征之间的距离， $start$ 代表初始特征的中心坐标， k 代表卷积核的大小， p 代表卷积填充的大小， s 代表卷积滑动的步长，公式(3-6)中的 $\lfloor \rfloor$ 表示的意思是向下取整，下标 in 和 out 代表输入和输出。




图3.2 感受野计算示意图

图 3.2 中有三个子图(a)、(b)、(c)，感受野计算过程是从图(a)到图(c)的。图(a)中的上面指明了这是 *Layer 0* 并将公式(3-4)到(3-7)中的参数分别都给出了， n_0 的值为 5， r_0 的值为 1， j_0 的值为 1， $start_0$ 的值为 0.5 为图中的红色圆点的横纵坐标值，这些参数的物理意义上面有解释在此不再赘述；图(b)中的上面指明了这是 *Conv1*， k_1 的值为 3， p_1 的值为 1， s_1 的值为 2，图中灰色的方框代表了卷积核其尺寸就是 k_1 值为 3，从图中的红色圆点出发有向右和向下两个箭头代表了卷积核的运算方向；根据公式(3-4)至(3-7)可以计算出 n_1 的值为 $1+(5-3+2\times1)/2=3$ ， j_1 的值为 $1\times2=2$ ， r_1 的值为 $1+(3-1)\times1=3$ ， $start_1$ 的值为 $0.5+((3-1)/2-1)\times1=0.5$ ，通过计算我们发现感受野的大小从 *Layer 0* 的 1 变成了 *Layer 1* 的 3，在图(c)中对应的区域就是以红色圆点为中心的白色区域。通过上面的分析可以知道随着网络的加深后面的特征图所对应的感受野会越来越大，学到的信息也就越全面，这样的话学到的特征也就越接近原始图像，更能代表原始图像的信息。

本节通过选择手写数字识别数据集 *mnist* 的图像，在已经训练好的卷积神经网络中，可视化卷积层的特征图来观察这些特征图到底学习到什么特征。此实验中采用以 *Tensroflow* 为后端的 *Keras* 框架作为基本框架，实验目的是为了说明卷积层学到的特征所以就编写了一个比较简单的神经网络 *LeNet-5*^[34]，从代码的编写来看，主要包括 2 个卷积层、2 个最大池化层、3 个全连接层，采用的优化器是随机梯度下降法，损失函数是分类问题常用的交叉熵损失函数。选取了手写数字 9 作为输入图像进行特征的提取和可视化，手写数字 9 如图 3.3 所示：




图3.3 手写数据集 mnist 中的数字 9

从图 3.3 我们可以看出 mnist 数据集中的图像分辨率为较低，是 28x28，所以将图显示出来会有马赛克效应。

首先对 LeNet-5 网络的第一个卷积层进行特征图可视化，由于第一个卷积层的输出通道共有 6 个所以其输出是 6 张特征图，它们的可视化结构如图 3.4 所示：




图3.4 卷积网络 LeNet-5 第一个卷积层的输出特征图

图 3.4 所展示的 6 张特征图，尺寸都是十几个像素，说明经过卷积层后输入图像的尺寸被减小了；另外从图 3.4 中我们可以看出，第一行的第一个图和最后一个图学到的是没有数字区域的特征，中间的两个图有模糊的数字 9 的轮廓特征，第二行的两

个特征图学到的像是数字 9 的边缘特征。从这层的特征图上，我们可以知道浅层卷积所学到的特征还能稍微看出原图像的影子，学到的是人们所能理解的颜色特征，边缘特征，纹理特征等。

LeNet-5 网络的第二个卷积层的输出有 16 个特征图，它们的可视化结构如图 3.5 所示：




图3.5 卷积网络 LeNet-5 第二个卷积层的输出特征图

图 3.5 展示了第二个卷积层输出的 16 张特征图，直观的感受是特征图尺寸变得更小了，至于每一张特征图所要表达的信息，从人类的角度来说几乎是不能够有什么明确的信息，这也就是人类所不理解的抽象特征。虽然不能具体理解每一个特征图所要表达的信息，但是可以确定的是每一个特征图中都有黑色的块和类似原图像数字 9 的颜色块，也就是说，后面卷积层学到的特征是将目标区域和非目标区域的特征进行了融合。

上面只是对手写数字进行了卷积层特征可视化处理，但是并没有对行人的图像进行可视化，而我们最终要将图像分割用于行人重识别所以进行行人图像特征图的可视化是必要的。下面就是对监控所拍下的行人图像进行可视化的结果图。

在进行实验之前将网络卷积层的某些参数进行了修改，因为选择的行人图像的分辨率远远大于刚才用到的手写数字数据集。此实验选择了一个行人图像作为网络的输入图像，图 3.6 为输入的原始图像。



图3.6 原始输入图像

这次为了让所呈现的结果更美观，将第一个卷积层的输出通道改为了 9，所以其输出特征图为 9 个，由于计算机的计数一般是从 0 开始数的所以在图中有关计数的数字都是从零开始的，如图 3.7 所示：




图3.7 卷积层特征图

从图 3.7 可以看出，有些通道的特征由于 ReLU 函数的作用，其值全部都变为了零。图 3.8 展示了将图 3.7 中的特征图相加后的结果。




图3.8 将 3.7 特征图相加后的结果

从图 3.8 几乎已经看不出人的轮廓，已经和原图相差很大了，几乎已经不能够被人类所理解。对比传统人工提取特征的过程，现在特征提取的过程都被深度学习所替代了，人们所需要做的就是处理原始数据，设计神经网络的结构，接着直接送入神经网络训练即可。

由上面两个例子可以看出，数字 9 的原始图像的大小是 28×28 ，行人原始图像的大小是 500×686 的，它们分别送入网络，所学到的特征的丰富程度，从所展示的特征图可以看出，图像分辨率越高学到的图像信息越丰富。前面提到的感受野概念解释了越往后面的网络层学到的特征图的特征越接近原始图像，也就是说如果原始图像的分辨率越高后面层所学得的高级特征感受野越大。根据 FPN 以及特征图的特点，将不同尺度输入图像进行再次融合看是不是可以增加特征的表达能力，进而提出将 Unet 的输入进行多尺度变换送入网络训练。

3.4 改进的 Unet 网络

经过上一节的分析，了解到越是神经网络靠后的卷积层，学习到的特征越是接近全局的特征，那么前面卷积层相对应的就学习到的就是图像的局部特征。这样的话，前面的卷积层就会没有全局观；另外，原始输入图像经过 Unet 网络结构后尺寸会由大到小，以及再恢复的过程，在这个过程中会有一些信息的丢失，因此有可能会对最后进行像素类别划分的时候造成影响。为了让各个阶段的卷积层都能有全局的视角，并缓解原始 Unet 结构中输入图像信息丢失的问题，进而提出了多尺度的 Unet 网络。

这里所提到的多尺度是指深度学习中特征图的不同尺度，而传统图像上的多尺度是指通过某种算子处理来得到的。从它们的基本含义可以知道，深度学习中不同尺度所表现的是不同层特征图的尺度，这些特征图所反映的信息已经相差很大；而传统意义上的多尺度则是对同一个目标采用不同处理方式，以便提取不同的特征信息。上一小节中已经展示了不同层所提取的不同尺度特征图之间的区别，下面我们就以图 3.9 为例来展示传统意义上的一种多尺度概念。




图3.9 传统多尺度示例

图 3.9 是通过改变高斯核的 σ 得到的一组图像，其中高斯核的大小为 5×5 ，最左边的为原始图像，然后依次从左到右其 σ 参数依次为 1.5、3.5。从图 3.9 可以看出，传统的多尺度所表达的意思是通过某种算法对同一张图像进行不同处理的表示。从广义上说，本节提出的多尺度和传统的多尺度都是对原始图像进行操作后使其变为多个尺度，但由于本节实验所选取的深度学习架构 Keras 不支持多输入，所以本节所提到的多尺度是对传统多尺度方法的调整。

其结构示意图如图 3.10 所示：




图3.10 改进 Unet 示意图

从图 3.9 可以看出,该结构总体来看呈英文字母 U 型,输入图像从网络结构中单独提了出来,并分别通过三次采样(这里所指的采样是指提取不同尺度的特征图)送入网络中;其中采样过程中有三条支路,分别从输入图像引出,但其所标注的名字略有差别,主要在于其中参数的不同。

下面介绍具体实现采样过程中的代码以及参数,实现该网络的代码是用深度学习框架 Keras,此框架的编程语言是 Python。采样的代码为 `MaxPooling2D(pool_size=(k, k), strides=None, padding='valid', data_format=None)(Input Image)`,其中 `pool_size` 为池化核的大小参数; `strides` 参数,在默认为 `None` 的情况下和池化核的大小参数取值相同; `padding` 的参数取值有 `valid` 和 `same` 两种, `valid` 代表没有填充, `same` 代表用零填充,当池化核所包含区域超出原始图像时, `valid` 方式会舍弃这次池化,而 `same` 方式会将超出的部分用零填充来完成池化; `data_format` 表示数据输入的格式,在 Keras 中的默认情况是“`channels_last`”,具体形式为 `(samples, rows, cols, channels)`, `samples` 代表 `batchsize` 的大小也就是训练时一次迭代所送入的样本数, `rows` 和 `cols` 代表样本的行和列, `channels` 代表通道数; `Sample1`、`Sample2` 以及 `Sample3` 对应的 `k` 分别为 1、2 和 4。为了更好的解释 `MaxPooling2D`,下面通过池化操作的示意图来说明:




图3.11 池化操作示意图

图 3.10 中,黄色的方格尺寸为 20×20 表示原始图像的大小,红色的方格尺寸为 10×10 表示池化核的大小,其中 4×4 的矩形代表输出结果。池化分为最大池化和平均池化,最大池化的意思是从池化核所选中的区域内选择最大的像素值作为输出,平均池化的意思是将池化核所选中的区域内的所有像素加和求平均。`MaxPooling2D` 中 `MaxPooling` 对应的就是最大池化, `2D` 代表的意思是所应用的对象是二维矩阵。

上面所介绍对原始图像采样的部分是有别与原始 Unet 网络结构的地方。原始的 Unet 网络结构直接将输入图像送入网络并没有采样的过程,该采样的目的是让网络能同时输入多个尺度的图像,然后分别送入 Unet 网络结构的相同尺度层进行训练。通过该步骤就让网络同时学习三种尺度的图像信息,经过 Unet 结构后让它们在最后的一层进行汇合,通过投票的方式来选择每个像素所属的类别。该过程的方式类似于机器学习中集成学习的 Bagging 思想。Bagging 思想是通过对训练集有放回的抽样,

每次都抽取同样大小的数据集进行训练，将这多个数据集所训练出来的模型分别对未知样本进行预测，将这些模型的预测结果通过投票法或者权重法来得到最后的结果，有点集思广益的意思。

网络结构的设计完成了，下面需要根据设计新型的 Unet 网络结构，对网络的性能进行实验仿真来验证所提出的改进是否真的比原始的 Unet 网络的性能要好。

3.5 实验仿真分析

通过对输入进行采样来实现让 Unet 网络结构弥补采样过程中信息损失。本实验所用的深度学习框架依然是 Keras，设备是和检测网络相同的，所选用的数据集是单人图像，下面通过数据集中一个具体的图片来说明所选数据集的信息。



(a) 原始图像



(b) 原始图像所对应的分割标签

图3.12 改进的 Unet 训练所选用的数据集例子

图 3.12 中分为了 a、b 两个子图。从图(a)中我们可以清楚的看出原始图像的人物以及其动作信息；从图(b)中我们可以知晓背景颜色选用的是绿色，人物颜色选用的是青色，另外还能很清楚的看到人物所在的位置以及其所表现的一些动作信息，该图是经过预处理然后再可视化的结果图，原始的分割标签图是全黑的区域没有其他可以通过人眼所能观察的信息。这是本次训练所选用数据集的一些特点，和 PASCAL VOC 2012 数据集中的分割标签数据不同的地方。

在进行实验结果讨论之前，首先介绍一下本实验所采用的图像分割评价标准。图像分割的评价指标有很多，本次实验所采用的评价指标是平均交并比(Mean Intersection-over-Union, mIoU)，提到平均交并比就需要了解交并比，交并比是在目标检测领域常用的评价指标但其也可用于图像分割领域的评价，其运算示意图如图 3.11 所示：




图3.13 交并比运算示意图


从图 3.11 中可以直观的了解，IoU 的计算就是模型所预测的掩膜和实际掩膜的交集除以预测的掩膜和实际掩膜的并集。平均交并比就是计算不同类别的 IoU 的（可加权）平均值，由于本实验是针对行人重识别任务的，所以只关注行人这一类数据，进而在计算平均交并比和交并比就没有差别了。

本实验准备从定性和定量分析上对比改进前后的模型效果，首先进行定性分析，测试图像是从互联网上随机下载的一张人物图像，其原图像如图 3.12 所示：




图3.14 图像分割测试图

将图 3.12 分别输入 Unet 网络和改进的 Unet 网络中，Unet 网络和改进的 Unet 网络所输出的分割图像结果如图 3.13 所示：



(a) 原始Unet分割结果



(b) 改进的Unet分割结果

图3.15 分割结果

图 3.13 分为了 a、b 两个子图，a 图是原始 Unet 网络对测试图像的分割结果，b 图是改进的 Unet 对测试图像的分割结果。从图(a)可以看出人物左手的部分是连在一起的而原图中是稍微有些分开的，图(b)则稍微地体现了原图中分开的部分。从直观感觉来说，应该是图(b)的分割结果好于图(a)的分割结果也就是改进的 Unet 网络的测试结果相比于原始的 Unet 网络效果有所提升。

下面从定量上分析原始 Unet 和改进的 Unet 网络的效果。在训练过程中将它们计算的准确率和损失通过日志的方式记录下来，然后通过可视化的方法将它们放在同一个图中进行观察，其呈现结果如图 3.14 所示：




图3.16 网络性能对比图

图 3.14 中分为 a、b 两个子图，图(a)表示的是准确率变化的曲线，图(b)表示的是损失变化的曲线，并且两个子图中橘色的曲线代表是原始 Unet 的变化曲线，蓝色的曲线是改进的 Unet 的变化曲线。从图(a)中可以看出，蓝色的曲线在前 15 个 epoch 左右是在橘色的曲线下方，所代表的意思是改进的 Unet 此时的准确率低于原始 Unet；从这个 epoch 为分界点，蓝色曲线跑到了橘色曲线的上方，直到训练结束蓝色的曲线一直上方，代表改进的 Unet 的性能从 15 个 epoch 左右后就超过了原始的 Unet 网络。图(b)中的情况和图(a)中类似，也是从 15 个 epoch 左右蓝色的曲线就跑到了橘色曲线下方，代表改进的 Unet 的损失开始小于原始 Unet 网络，也就说明了从这个分界点后改进的 Unet 的性能一直高于原始 Unet 网络。这个准确率的计算是通过类别判断正确与否给出的，由于本实验所使用的是训练数据只有两类，人物和背景。所以进行分类的时候，准确率会比较高，损失会比较小。上面的性能曲线是从 Keras 框架自带的监控评价指标得到的。因为本次实验仿真是针对图像分割问题，所以要用图像分割领域都能认可的评价指标来进行对比，下面选用在图像分割领域常用的性能指标 mIoU 再次进行评估，评估结果如表 3.1 所示：

表3.1 原始 Unet 和改进 Unet 性能对比表

方法	测试样本数	运行时间（秒）	mIoU
原始 Unet	5000	124	0.891
改进后的 Unet	5000	130	0.895

表 3.1 是原始 Unet 网络和改进 Unet 网络的性能对比表，从表中我们可以知道测试样本有 5000 个，另有运行时间和 mIoU 作为测试指标，其中 mIoU 是指平均 IoU，这是在计算多个类别的 IoU 后取平均的结果，由于本实验所关注的类别只有行人一个，所以 mIoU 在数值上和 IoU 是相等的。原始的 Unet 网络的运行时间为 124 秒，改进后的 Unet 网络的运行时间为 130 秒，从运行时间上来看，改进后的网络运行时间稍微慢了 6 秒；另外，原始 Unet 网络的 mIoU 为 0.891，改进后的 Unet 网络 mIoU 为 0.895，从 mIoU 对比可以知道，改进后的 Unet 网络性能有所提升。从上一节的分析可以知道，改进后的 Unet 网络结构更复杂，因此测试运行时间会更长；另外，改进后的 Unet 提取了更多的细节信息，从而让 mIoU 有所提高。

通过实验仿真证明了所改进网络在 mIoU 上的性能提升，因为本次采用的评测指标是 mIoU，所以改进后的网络性能在同一测试集上的表现要优于原始的 Unet 网络。

综上所述，我们从定量上和定性上都验证了改进的 Unet 的网络性能优于原始的 Unet 网络。

3.6 本章小结

在本章，首先介绍了图像分割的相关概念对基于深度学习的图像分割算法进行了简要的介绍，从而引入本章的主角 Unet；接着对 Unet 网络的结构进行了分析，又顺带将原论文中的损失函数、优化器类型、权重更新方式进行了介绍；然后对感受野和卷积层的特征图进行了分析；将原始 Unet 网络进行改进，并给出了其改进后的结构示意图；最后简要介绍了训练的单人数据集并通过实验仿真从定性和定量两个方面对改进的 Unet 和原始的 Unet 进行了性能评估，得出结论改进的 Unet 的网络性能相比于原始的 Unet 有所提高。

第四章 迁移学习和孪生网络

4.1 迁移学习的应用场景

人工神经网络如今的发展十分迅速，针对人工神经网络的研究很早就已经开始了，但是发展迅速却是从这个时代开始的，究其原因有两个：数据的获取比以往方便了许多所以可以收集大量的数据；集成电路技术的发展让计算机的计算性能提高了许多让一些以前不能计算的算法可以进行求解了。任何事物都是有双面性的，要想将一个神经网络模型训练的比较需要大量的数据和算力较高的计算机设备，这就限制了很多研究人员想法的实现或者延长了研究人员想法验证的时间。怎么样能让有条件的研究人员在大型数据集上训练的网络参数共享给其他研究人员呢？让网络参数共享的学习方法——迁移学习就逐渐引起了研究人员的关注，Pan S J , Yang Q 等^[35]对迁移学习做了一些系统的总结和分析。

上面提到了应用迁移学习的主要原因在于数据资源的可获得性和训练任务的成本。当所研究的领域数据资源很好获得的情况下，就没必要应用迁移学习，但如果研究领域可获得的数据极为有限，仅靠这些有限的数据进行训练，所获得的深层网络模型有很大概率上是不稳健的、效果差的，这是因为训练数据少很容易造成过拟合。过拟合的现象是在训练集上的表现好，但是在测试集上的表现差，这是因为深度学习的参数一般是百万数量级的，少量数据几乎不可能将这些参数训练的很合适。另一个原因就是训练成本，即所依赖的计算资源和耗费的训练时间。从头开始训练一个卷积神经网络通常需要很长的时间并且需要强大的 GPU 计算资源，对于想迫切验证自己想法的研究人员而言，这个时间代价他们是不能接受的。

上面提到了迁移学习是应对训练数据不足的情况所提出的一种方法，基于深度学习的行人重识别任务需要一定数量的行人数据来训练网络，由于行人的数据获取不是特别方便，并且牵涉个人隐私问题，使用不当会造成不必要的麻烦，这就导致了有标签的行人数据并不太多，直接采用这为数不多的数据训练深层网络的话就很有可能得不到符合我们要求的网络模型。鉴于这种情况，上面提到的迁移学习就可以应用到行人重识别的问题上。本章第一节介绍了迁移学习的应用场景，为的就是将迁移学习的特点先进行一个简单的概述进而过渡到行人重识别的问题上来；但是迁移学习到底能不能很好地解决行人重识别数据较少的问题，以及其背后所隐含的原理，这些问题关系到迁移学习理论本身的可行性。迁移学习的原理将会在下面的章节中介绍。

4.2 迁移学习原理

迁移学习是运用已存有的知识对不同但相关领域问题进行求解的机器学习方法。用一种通俗的说法解释就是：迁移学习是利用数据、任务或模型之间的相似性，将在旧领域学习过或训练过的模型，应用于新的领域的过程。由于深度学习是机器学习的一个分支，所以机器学习的有些理论可以用于深度学习。图 4.1 给出机器学习、深度学习以及人工智能的关系图：




图4.1 人工智能、机器学习以及深度学习关系图

对于机器学习来说有两个基本的假设：用于进行模型训练和测试的数据应该是独立同分布的；必须有足够多的训练数据才能够学到效果不错的模型。然而实际应用中这两个条件由于各种各样的原因可能并不会同时满足甚至一个都不满足，迁移学习的提出放宽了传统机器学习中的两个基本假设。从迁移学习的定义就可以知道，它本身就是将已有的知识应用于解决相关领域训练样本不多的方法。迁移学习对于机器学习领域来说是一个比较新的概念但是对于人类来说这是一个广泛存在于人类活动中的事实，两个不同的领域共享的因素越多，迁移学习的效果就会越明显，否则就会几乎看不出有效果，甚至产生非预期的效果。

卷积神经网络在具有同等性质输入的任务中具有可迁移性，其根本原因是由卷积神经网络的工作原理所决定的。从上一章的介绍中我们了解到卷积神经网络具有良好的层次结构，通常来说，卷积神经网络都具备卷积-池化-卷积-池化-全连接这样的层次结构，在进行卷积层特征图可视化的过程中，卷积神经网络可以提取各个层次的特征。

本文提到的迁移学习是将经典卷积神经网络在 ImageNet 数据集上进行训练所获得的权值用来作为行人重识别网络的预训权值。ImageNet 数据集是一个图像识别数

数据集所以得到的权值是关于图像分类问题的，从输入的数据上看，都是属于非结构化数据——图像。另外，能将预训的权值应用于行人重识别就是深度学习本身的特点所决定的了。深度学习是一个将数据进行分层表达的过程，然后用高层语义进行分类的模型，模型的底层特征是图像的纹理信息、颜色信息、边缘信息等，这种基本的特征具有一定的不变性这就为迁移学习在深度学习中的应用提供了理论保障。

4.3 迁移学习的预训网络 Xception

本文选用的迁移学习的预训网络是 google 的 Chollet, François 等^[36]提出的 Xception。Xception 网络结构是对 Inception 系列中的 Inception v3 的一种改进，是一种 Extreme Inception，因此得名 Xception。其改进的主要方式是采用深度分离卷积^[37]来替换原来 Inception v3 中的卷积操作。由于 Xception 是从 Inception v3 改进来的，要想了解 Xception 就需要从 Inception v3 开始介绍。

Inception v3 的网络结构如图 4.2 所示：




图4.2 谷歌提出的 Inception v3 网络结构

从图 4.2 中我们可以看到输入进到网络以后分成了四条通路，我们约定从左往右数。第一条通路是通过 1×1 卷积就结束了操作；第二条通路是通过 1×1 卷积后又接了一个 3×3 的卷积然后就结束了操作；第三条通路是先通过平均池化然后接了一个 3×3

的卷积结束了操作；最后一条通路则有些复杂，先是 1×1 的卷积然后连着接了两个 3×3 的卷积。普通的网络结构就是通过一条通路到头，而 Inception v3 中却有许多条通路，其内在原因是：特征的提取和传递可以通过 1×1 卷积， 3×3 卷积， 5×5 卷积（Inception v3 中将 5×5 的卷积换成了两个 3×3 的卷积），池化等，到底哪种才是最好的特征提取方式呢？Inception v3 结构将这个疑问留给网络自己，也就是将一个输入同时输给这几种提取特征方式，然后做特征拼接。这样的话，网络就会自动将比较符合实际任务的特征提取方式赋予更为重要的地位以便对最后的输出结果产生良性的反馈。从 Inception v3 的模型结果可以联想到一个简化的 Inception 模型，其结构如图 4.3 所示：




图4.3 一个简化的 Inception 模型

图 4.3 有从输入开始分了三条通路，每一条通路所进行的操作都是一样的。将图 4.3 的结构进行延伸就得到了图 4.4：




图4.4 简化 Inception 的延伸

从图 4.4 可以知道，输入经过 1×1 的卷积然后接了三个 3×3 的卷积，这三个卷积操作只将前面 1×1 卷积通道的一部分作为输入；这个操作就是将图 4.3 中的 1×1 的卷积操作进行了合并。将图 4.4 中 3×3 卷积的个数和 1×1 卷积后输出的通道数设为相同就得到了图 4.5：




图4.5 极端版本的 Inception 结构

Xception 的创新在于其使用的深度分离卷积，深度分离卷积的示意图如图 4.6 所示：



图4.6 分离卷积示意图

从图 4.6 中可以看出分离卷积是分为两步进行的。假设原来是 3×3 的卷积，那么深度分离卷积就是先用 M 个 3×3 卷积核一对一卷积输入的 M 个特征图，不求和，生成 M 个结果；然后用 N 个 1×1 的卷积核正常卷积前面生成的 M 个结果，求和，最后生成 N 个结果。

深度分离卷积和图 4.5 的过程是很相似的，仔细分析可以发现其不同主要有两点：第一点是操作顺序不一样，在深度分离卷积中是先进行一个通道级的空间卷积，然后是 1×1 的卷积。而在图 4.5 中是先进行 1×1 的卷积，再进行通道级的空间卷积，最后拼接在一起。在图 4.5 中，每个操作后都有一个 ReLU 的非线性激活，通过非线性函数的目的是为了增加网络的表达能力，是神经网络中的常用操作，但是在深度分离卷积中则没有添加激活函数。

通过上面的网络结构演化介绍，终于得到了 Xception 的网络结构图：




图4.7 谷歌提出的 Xception 网络结构图

从图 4.7 中可以看出 Xception 网络结构主要分为三个部分：输入流，中间流，输出流。这三个部分都有 SeparableConv 这个操作，这个操作就是分离卷积。这里的分离卷积指的就是深度分离卷积。另外，每个部分的跨层连接，也就是每个小块的连接方式采用的是残差连接（图中的加号），而不是原 Inception v3 网络结构中的拼接。

4.4 孪生网络的改进

从 1993 年 Bromley J, Bentz J W, BOTTOU 等^[38]提出的论文中就开始将孪生网络结构用于验证支票上的手写签名，即验证支票上的签名与银行预留签名是否一致。孪生网络的研究在 2005 年由 Chopra S, Hadsell R, Lecun Y 等^[39]提出一个新的应用领域就是人脸识别。Yann LeCun 论文中的核心思想是通过孪生网络的训练得到一个映射函数，将输入映射为一个特征向量，用特征向量之间的距离来计算输入之间的差异也就是图像之间的语义距离。

孪生网络中的孪生二字讲的是共用一个主体部分的意思，在网络中具体的意思就是权值共享。和普通的卷积神经网络不同的是，孪生网络的输入有两个。其网络结构示意图如 4.8 所示：




图4.8 孪生网络结构示意图

图 4.8 中的 X_1 和 X_2 表示两个输入，经过同一个卷积神经网络（图中虽然画成了两个不同的通路但实际中就是一条通路只是输入有两个而已）后学到了一个映射函数 $G_w(X)$ ， W 表示模型的参数， W 分别连向两条通路也说明了这两个卷积神经网络是同一个，分别将两个输入映射成 $G_w(X_1)$ 和 $G_w(X_2)$ 两个特征向量，输入映射完成后需要计算特征向量之间的距离，如果采用的是 $L1$ 距离则为 $E_w = \|G_w(X_1) - G_w(X_2)\|$ 。

通过上面基本孪生网络的介绍，了解到学习完映射函数后直接就进行了特征向量的距离运算，采用的距离比较单一，上面提到的只是 $L1$ 距离。经过映射函数得到了一个特征向量，为了让特征向量多样化，也是为了产生更多可以进行度量的距离特征，本文提出在映射函数过后进行了多种距离运算来进行多范围度量特征向量之间的距离，该想法是来自于机器学习中特征工程部分；特征工程是通过对数据的特征先构造再筛选反复几次来选择和目标最为相关的特征，主要是为了学习对最终目标有正反馈的特征。代码的实现是通过 Keras 框架，由于这个框架有画网络流程图的作用，但前提是你要用自己的代码先将你所要构建的网络描述出来再调用框架自带的画图功能即可画出所写网络流程图。

在学到映射函数 $G_w(X)$ 后，映射函数将输入图像映射成特征向量后的网络运算流程图如图 4.9 所示：




图4.9 孪生网络运算流程图

图 4.9 分为了 a、b 两个子图，图(a)是原始孪生网络运算流程图，图(b)是改进后孪生网络运算流程图。从图(a)中可以看出，输入进入网络流程后是按照正常的顺序进行的，流程中的 dropout 操作是随机丢弃一定比例的神经元，是一种防止过拟合的方式。从图(b)中可以看出两个输入进入网络流程后先是通过 *Lambda* 表达式来定义四个计算方式，分别是 *Lambda 1*: $G_w(X_1) \times G_w(X_2)$ ，*Lambda 2*: $G_w(X_1) + G_w(X_2)$ ，*Lambda 3*: $|G_w(X_1) - G_w(X_2)|$ ，*Lambda 4*: $\cos(G_w(X_1) - G_w(X_2))$ 。经过这四种计算方式后通过拼接操作将四个结果向量合成一个特征向量进行接下来的卷积网络层。图(a)中的输入是 input_1 和 input_2 而图(b)中的输入是 input_2 和 input_3，这个不是画图的问题，而是图(b)在进入这个改进孪生网络之前有一个分支网络，也就是迁移学习的模型 Xception 网络。根据 Keras 框架的特点，input_1 已经在 Xception 网络的输入了，所以后面的输入就按阿拉伯数字往后排。经过上面的分析可以知道，图(a)的输入是原始图像进入孪生网络而图(b)的输入则是先通过分支网络映射成特征向量后再进入孪生网络的卷积层。

综上所述，可以总结出对原始孪生网络改进的两点：第一点，输入从原始图像变成了特征向量；第二点，原先的输入经过映射后直接通过一种距离度量方式进行计算

而改进后的网络经过特征组合才输入网络进行度量计算。

为了评估改进后网络的实际效果，下一节将从两个方面来进行对比实验。首先是对比原始孪生网络和改进网络的性能曲线以及对测试图像的实际输出结果；其次将改进的网络在公共数据集上的表现和其他的行人重识别算法在此数据集上的表现进行对比。

4.5 实验仿真分析

为了验证改进孪生网络的效果进行以下实验。本实验采用的深度学习框架是 Keras，之所以选择这个框架主要是因为这个框架简单易学，实现网络比较方便。另外，使用的设备是有两块 NVIDIA GTX Titan X 的服务器，训练的数据集是 Market-1501^[40]，这个数据集是在清华大学校园中采集，夏天拍摄，在 2015 年构建并公开。图 4.10 是随机从数据集中选取的训练样例：



图4.10 训练数据集样例

实验中根据训练集有 12936 张图像，751 个行人，以及 GPU 的显存大小，将 batchsize 设为 32，也就是说每个 batch 中选择了 32 对图像，16 对正样本，16 对负样本，训练了 100 个 epoch。这个训练过程是将行人重识别当成一个二元分类问题，只需要给出输入的图像是否为同一个人的图像即可；但由于这个数据集的标签我们是知道的，所以也可以将这个网络改成一个分类网络，类别就是行人的数量，这样就可以在候选集中进行查询得到和目标图像最相似的图像。首先，我们所训练的是一个二元分类问题也就是只需要执行是否的回答就可以了，训练过程中将得到的准确率数据和

损失数据分布记录下来，并绘制成曲线，得到的训练集和验证集的准确率以及训练集和验证集的损失。它们之间的关系曲线在下面进行展示。




图4.11 原始孪生网络性能指标变化曲线

图 4.11 分为了 a、b 两个子图，图(a)是准确率变化的曲线，图(b)是损失变化的曲线，其中蓝色的表示训练集，橙色的表示验证集。从图(a)中可以看出，当训练到 100 个 epoch 的时候，训练集的准确率达到 65%左右，验证集上的准确率是 57%左右；从图(b)可以看出训练集上的损失不断降低而验证集上的损失却一直在 0.7 左右振荡。上面是原始的孪生网络的性能曲线，改进后的孪生网络性能曲线如图 4.12 所示：




图4.12 改进后孪生网络性能指标变化曲线

图 4.12 分为准确率变化曲线和损失变化曲线。从图(a)可以看出，当训练结束的时候，训练集上的准确率已经到了 90%左右，验证集上的准确率也到了 85%左右；从图(b)可以看出，不管是训练集上的损失还是验证集上的损失都在不断下降，只是验证集上的损失变化起伏比训练集剧烈。

通过图 4.11 和 4.12 的对比可以发现,不论训练集还是验证集,原始的孪生网络在训练结束所达到的准确率是低于改进后的网络;从损失曲线看,在训练结束时,原始的孪生网络损失大于改进后的网络。

上面是从性能曲线的角度对比了原始的孪生网络和改进后的网络,下面从具体的测试图像上来验证改进后网络的效果。首先选取几张行人的图像和原始的孪生网络进行对比实验,结果如图 4.13 和 4.14 所示:




图4.13 原始孪生网络的测试结果

图 4.13 中的图(a)代表不同人物的测试结果,图(b)代表相同人物的测试结果。从图(a)可以看出,不同人物的得分是 0.44,这个分数是一个不算很低的分数,如果阈值稍微变化就有可能让最后的结果出错;从图(b)可以看出相同人物的得分是 0.79。



图4.14 改进后网络的测试结果

从图 4.14 可以看到，对于是不同人物的图像得分非常低，是 0.08；对于是同一个人的图像得分非常高，是 0.99。这也就说明了改进后的模型，让相似的图像之间的距离更近了，不相似的图像的距离更远了，鲁棒性比改进前的模型提高了不少。

综上所述改进后的孪生网络无论是从性能曲线上还是在测试图像上都获得了比原始的孪生网络更好的结果。

上面的实验是针对原始孪生网络的比较，下面我们就使用行人重识别的公共数据集 Market-1501（虽然训练网络时也是采用的此数据集但下面测试用的数据是验证集的部分，这个部分并没有参与训练）来比较改进后的孪生网络，在正式进行实验之前，先介绍后面要用到的评价指标 Rank-n 和 mAP。我们首先介绍一个 Rank-n，Rank-n 是对所查询的图片按照某种度量标准在候选集中选出 n 张与其最近的图片并按照度量结果将其从小到大排序，n 张图片中有正确结果的概率。上面的定义不够直观，下面举个具体的例子来说明 Rank-n 的含义。假设标签是 a1，在 5 个样本中搜索，如果排序结果为 a1、a2、a3、a4、a5 则 Rank-1 是 100%，Rank-2 是 100%，一直到 Rank-5 都是 100%；如果排序结果是 a2、a1、a3、a4、a5 则 Rank-1 是 0%，Rank-2 是 100%，一直到 Rank-5 都是 100%。

在介绍 mAP 之前需要介绍查准率和召回率。本文所说的查准率和查全率是针对行人重识别问题解释的。查准率是所查询人数中正确和目标匹配的人数占所查询的人数的比例；召回率是所查询人数中正确和目标匹配的人数占候选集中所有和目标匹配人数的比例。下面通过一张图来说明查准率和查全率的计算过程：




图4.15 查准率和查全率的计算

图 4.15 中的待查询的图片是 a，背景为蓝色，候选集中共有 5 张和图片 a 相同所以它们的背景也是蓝色，用背景颜色的不同来区分正确匹配的图片 and 错误匹配的图片。图 4.15 中的序号代表和查询图片正确匹配图像所在的位置，查准率和查全率是在正确匹配图片的位置下计算。查准率的分母是所查询图片的个数，分子是正确匹配的；查全率的分母为 5 代表共有 5 张图片和目标匹配，分子是查询到匹配的图片张数。

上面将查准率和查全率给了出来，AP 就可以计算了。上述例子中的平均准确率 AP (average precision) 为 $(1+2/3+3/6+4/9+5/10)/5=0.622$ 。这个 AP 是一个查询例子计算得出，假如有多个需要查询的行人，分别将他们的 AP 算出，相加取平均就得到了 mAP。

下面将本章提出的改进孪生网络和 LOMO^[14]算法、AlexNet identification model^[41,42]网络模型、Bilinear DML^[43]算法、WARCA^[44]度量学习方法、Hist LBP+kLFDA^[45]算法、CRAFT-MFA+LOMO^[46]算法、SOMAnet^[47]网络模型在数据集 Market-1501 的 Rank-1、Rank-5、Rank-10、mAP 上的值进行对比，其对比表格如表 4.1 所示：

表4.1 改进孪生网络和其他网络及算法实验对比表

Method	Rank1(%)	Rank5(%)	Rank10(%)	mAP(%)
LOMO ^[14]	26.07	-	-	7.75
AlexNet identification model ^[41,42]	55.49	76.28	83.55	32.36
Bilinear DML ^[43]	66.36	85.01	90.17	41.17
WARCA metric learning ^[44]	45.16	68.12	76	-
HistLBP+kLFDA ^[45]	46.5	71.1	79.9	-
CRAFT-MFA+LOMO ^[46]	71.8	-	-	45.5
SOMAnet ^[47]	73.87	88.03	92.22	47.89
Our method	85.65	90.23	91.41	60.09

从表 4.1 中可以看出，我们提出的方法在 Rank-1 和 mAP 上都是效果最好的方法，但是在 Rank-10 上略微比 SOMAnet^[45]的效果差一点，总体上说我们提出的孪生网络在公共数据集 Market-1501 上的表现还是不错的。另外我们在 Rank-1 上的准确率和训练过程中在验证集中的准确率几乎是一致的，证明我们所训练的模型没有过拟合。

综上所述，本文所提出的改进版孪生网络在和最近几年的行人重识别算法比较中表现更好。

4.6 本章小结

在本章，首先对迁移学习的应用背景进行了详细介绍，根据其理论保障将迁移学习应用到行人重识别的问题；接着介绍了具体实现代码中所使用的预训网络 Xception，对 Xception 中的创新点分离卷积进行了介绍；然后对原始的孪生网络进行了简单介绍和分析，通过分析发现原孪生网络所学特征的单一性然后根据机器学习中特征工程的启发，本文提出通过特征组合的方式来增加特征的多样性；为了验证所改进孪生网络的性能优劣，通过两个方面的实验对比来说明改进网络的性能，首先是和原始孪生网络的比较，其次是在行人重识别的公共数据集 Market-1501 上对比了其他行人重识别算法；最后得出结论，所改进的孪生网络性能一方面比原始孪生网络有所提升，另外还比最近几年提出的行人重识别算法表现更好。

第五章 基于 Tkinter 模块的简易行人重识别系统

5.1 行人重识别流程介绍

前面的章节介绍了行人检测，分割，识别的相关技术，对于本文所设计的行人重识别系统来说这些都是必不可少的组成环节，图 5.1 就显示了本文设计的行人重识别系统应该包含的环节：




图5.1 行人重识别系统流程

从图 5.1 可以看出，行人图像的获取这是行人重识别系统的开始环节，由于未经他人同意获取他人照片进行实验容易引起不必要的麻烦，因此本文所使用的行人图像并不是从摄像头获取，而是从互联网上下载，这样的话，我们在本章的图形界面化过程中就舍弃了行人图像获取的功能按键；行人图像的检测就使用第二章提到的 RetinaNet 网络结构来实现；行人图像的分割就使用第三章介绍的改进版 Unet 网络结构来实现；行人图像的识别通过第四章改进后的孪生网络进行判断；最后将结果输出到界面上。从流程图来看，检测、分割、识别是有顺序之分的，下面在设计功能按键时会考虑到其顺序。

本章的行人重识别系统流程是根据普通计算机视觉系统的设计思路进行构建的，其中包括了计算机视觉领域的三大问题：检测、分割、识别；严格来说，行人重识别只是涉及了识别问题，将这三个问题都综合到行人重识别任务中是想从系统的角度来重新认识行人重识别，并了解检测以及分割和行人重识别任务之间的联系。通过前面几章的介绍，我们可以了解到行人检测是从场景中将行人图像提取出来这和标准行人重识别数据集制作有关，因为标准数据集的图像都是先通过检测然后进行裁剪最后获得行人图像；行人分割可以忽略背景的干扰只对目标进行分析；行人识别是对预处理过的图像进行识别；检测是行人重识别的基础，分割有提高行人重识别性能的作用。

下面就开始介绍图形界面的设计，首先需要介绍的就是本文所选的图形界面工具。

5.2 Tkinter 模块的介绍

本文选用的图形用户界面(Graphical User Interface, 简称 GUI)实现工具是 Python 的 Tkinter 模块,虽然 Python 的 GUI 库非常多,但我们却选择 Tkinter 作为实现工具,

其主要有三个原因：首先是 Tkinter 的程序编写较为简单；其次是 Tkinter 为 Python 的自带库不需要从互联网上下载安装；最后是从需求的角度出发，我们所要实现的图形界面只是将检测、分割、识别三个主体功能结合在一起，这个界面只是展示和打印结果的作用因此不需要很复杂的 GUI 模块。

Tkinter 模块（“Tk 接口”）是 Python 的标准 Tk GUI 工具包的接口。由于 Python 分为不同的版本所以在实际中要想正确地使用 Tkinter 模块必须明确自己所使用的 Python 版本，从而知道在使用中是用命令 `import Tkinter` 还是 `import tkinter`。为了对 Tkinter 有一个系统的了解，本节从常用控件的功能开始介绍，然后对控件的属性设置进行介绍，最后对窗口的空间布局也就是几何管理进行简要介绍。本文采用的 Tkinter 介绍顺序和普通界面的开发顺序大致类似，普通界面的开发大致分为 5 步：创建按钮，定义按钮名称，定义按钮属性，定义按钮功能，生成布局。首先对按钮进行介绍，在 Tkinter 中称为控件，常用的控件如表 5.1 所示：

表5.1 常用控件介绍

控件	功能及名称描述
Button	按钮控件：在程序中显示按钮
Canvas	画布控件：显示元素如：线条或文本
Checkbutton	多选框控件：用于在程序中提供多项选择框
Entry	输入控件：用于显示简单的文本内容
Frame	框架控件：在屏幕上显示一个矩形区域，多用来作为容器
Label	标签控件：可以显示文本和位图
Listbox	列表框控件：在 Listbox 窗口小部件是用来显示一个字符串列表给用户
Menubutton	菜单按钮控件：显示菜单项
Menu	菜单控件：显示菜单栏，下拉菜单和弹出菜单
Message	消息控件：用来显示多行文本，与 label 比较类似
Radiobutton	单选按钮控件：显示一个单选的按钮状态
Scale	范围控件：显示一个数值刻度，为输出限定范围的数字区间
Scrollbar	滚动条控件：当内容超过可视化区域时使用，如：列表框
Text	文本控件：用于显示多行文
Toplevel	容器控件：用来提供一个单独的对话框，和 Frame 比较类似
Spinbox	输入控件：与 Entry 类似，但是可以指定输入范围值
PanedWindow	窗口布局管理的控件：可以包含一个或者多个子控件
LabelFrame	简单的容器控件：常用与复杂的窗口布局。

从表 5.1 可以了解到常用控件的功能及其名称，这就为后面使用具体功能查找相应控件提供了方便。

下面需要介绍控件的标准属性信息，能够帮助我们更好地使用这些控件。标准属性是属性的一个特殊分支，表示的是所有控件都具有的共同属性，比如大小、颜色、字体等。表 5.2 给出了标准属性的信息。

表5.2 标准属性信息

属性	描述
Dimension	控件大小
Color	控件颜色
Font	控件字体
Anchor	锚点
Relief	控件样式
Bitmap	位图
Cursor	光标

控件的功能和属性都介绍完成后，下面需要解决的问题是将控件放在窗口的什么位置，这就需要介绍几何管理，管理整个区域的控件排列，其部件如表 5.3 所示：

表5.3 几何管理部件

几何方法	描述
pack()	包装
grid()	网格
place()	位置

这三个几何方法决定了所定义的控件在图形界面中的摆放位置。`pack()`方法是里面有个参数是 `side` 可以有四种选择，`left`、`right`、`top`、`bottom`，但是从这几个参数也可以看出 `pack()`方法并不能实现精确定位，所以这种方法的灵活性相比于后两种来说就显得有些逊色；当参数不指定的时候，`pack()`方法会将控件水平或垂直的逐个放在一起。`grid()`方法会把控件的位置当作一个二维表结构来维护，即按照行列的方式排列控件；控件的位置由其所在的行号和列号决定。行号相同而列号不同的几个控件会被彼此上下排列；列号相同而行号不同的几个控件则会被彼此左右排列；另外，使用 `grid()`方法进行布局的过程就是为各个控件指定行号和列号的过程，不需要为每个格子指定大小，这个方法本身就会自动设置一个合适的大小。`place()`方法可以指定具体的位置，其参数有 `x`、`y`、`width`、`height`；`x` 和 `y` 表示放置位置左上角的横纵坐标，`width`

和 height 表示所构成矩形区域的宽和高是 width 和 height。

5.3 界面展示

根据设计目的，最终所要实现的界面应该包括三个功能键分别表示检测、分割、识别，这三个键是有优先级的，必须先经过检测才能进行分割，分割过后最后识别并输出结果。

首先根据优先级顺序将这三个功能键依次排序，主要布局的位置放在窗口的中间，大致设计结构如图 5.2 所示：




图5.2 图形界面设计图

图 5.2 显示了图形界面的设计构图。上面提到过，检测、分割、识别是有优先级顺序的，所以当不小心点了后面的两步应该有提示框弹出来告诉用户应该做什么。当先点了 segment 这个按键时，提示语为 you should do detect first。当点了 recognize 这个按键时，提示语分为三种情况：一种是第一个点的是 recognize 这个按键，这时提示语为 you should do detect first；第二种情况是已经点了 detect 按键，此时的提示语为 you should do segment；第三种情况是首先点的是 segment 这个按键，这样的话就回到了 segment 按键被先按的情况，按照上面说的处理即可。下面给出先点了 segment 按键的例子效果图：




图5.3 执行优先级错误的提示信息

窗口的整体布局和功能按键的优先级问题处理好以后，下面就是要具体将功能键的作用实现了，下面分别对这三个功能键进行了测试。

原始测试图像如图 5.4 所示：



图5.4 行人重识别系统测试图像

图 5.4 是从互联网下载的一张行人图像。当对按键 **detect** 进行测试的时候，结果如图 5.5 所示：




图5.5 检测按键 detect 执行后的结果

从图 5.5 中可以看到，对图 5.4 进行了检测，并且准确地将图中的行人图像用检测框检测了出来，框的上面有一些灰色的字体指明框出来的是 person，后面跟着一个置信度；在按键的右侧有一个结果显示框，上面写着 Detected Finished! 其实 detect 这个按键除了显示在交互界面上的结果外还将所截取的图像分别保存了起来。所以下面进行分割测试的时候是对单个图像进行操作的，需要点两次。

在进行按键 segment 测试之前，先看一下经过 detect 操作以后截取出的行人图像：



图5.6 检测后截取出的图像

从图 5.6 中可以看到，图 5.5 检测框中的图像都分别保存了起来。由于本系统所

做的分割是针对单个行人的图像分割，所以在进行分割按键检测的时候需要扫描检测所截出的图像然后根据图像的数量决定分割按键的次数。

将截取的图像进行按键 `segment` 进行测试，结果如图 5.7 所示：




图5.7 分割按键 `segment` 执行后的结果

图 5.7 显示了两次 `segment` 按键后的操作结果，左图对应于 5.6 图中的左图，右图对应于 5.6 图的右图。从左图可以看出，结果显示对话框中出现的是数字 1，这个代表了是分割了一张图像，而右面的结果显示对话框中出现的是 `Segment Finished!` 表明所有图像已经分割完毕。

当对按键 `recognize` 进行测试的时候，结果如图 5.8 所示：




图5.8 识别按键 `recognize` 执行后的结果

从图 5.8 中可以看到，对于检测出的图像进行识别操作后，在右侧的结果显示对话框中显示的是 Different！其实对于按键 recognize 的输出结果会有两种情况：当输入的两张图像属于同一个人时，输出结果为 Same；当输入的两张图像不是同一个人时，输出结果为 Different。本次测试所选择的两张输入图像，输出结果为 Different 表示不是同一个人；根据实际情况来看，这的确不是同一张图像，所以结果显示正确。

5.4 本章小结

在本章，首先对行人重识别系统进行了整体介绍，并将本文将检测、分割、识别结合在一起的目的进行了讲述；接着对本章图形界面设计所采用的实现工具 Tkinter 进行了介绍，从选择原因到实现所需要的控件、属性信息以及几何管理进行了详细介绍；然后对设计界面的构图进行了介绍，并对 detect、segment 以及 recognize 按键进行了功能测试，结果表明此界面能正确地将这些功能结合在一起并显示出来。

第六章 总结与展望

6.1 总结

深度学习是一种模拟人类大脑工作原理的学习方式,它通过构建深层的非线性网络结构来实现类似人类大脑的决策。集成电路、信息技术等技术的不断发展以及数据获取方式的改变间接推动了深度学习的发展,深度学习的应用也变得广泛起来。行人重识别是计算机视觉下面的一个子问题,行人重识别自从深度学习崛起以来已有不少的研究学者将这个领域和深度学习相结合并取得了很多的研究成果。本文也是基于深度学习的行人重识别研究,但是出发的角度却不同于以往研究行人重识别思路,而是从计算机视觉系统的角度对行人重识别进行了介绍和分析。

本文的创新点在于:针对原始图像分割网络 Unet 的信息丢失问题,提出了多尺度的 Unet 网络来缓解;对孪生网络所学特征的单一性,提出了特征组合的方式来丰富学习的特征;将图像的检测、分割以及识别功能整合在一起构成一个简易的行人重识别系统。论文的主要工作内容如下:

1、本文介绍了基于深度学习的检测网络 RetinaNet,并对其组成结构,损失函数进行了详细介绍,最后通过 PASCAL VOC 2012 数据集对此检测网络进行了复现并在测试图像上验证了训练效果。

2、本文介绍了基于深度学习的分割网络 Unet,首先对其结构特点进行了详细地概括和分析;接着对其训练过程中所从用到的能量函数和权重映射进行了介绍;然后在 mnist 数据集上可视化卷积层特征并介绍感受野的概念提出改进的 Unet 网络结构;最后从定量和定性的仿真实验中验证了改进的 Unet 网络比原始 Unet 网络表现更好。

3、本文介绍了基于迁移学习的孪生网络,首先对迁移学习的原理进行了分析;根据平时的实践经验选择了 Xception 网络作为孪生网络的特征提取层并对其网络结构进行了介绍;接着介绍了原始的孪生网络结构,通过对其分析了解到其所学特征单一性的缺点并提出特征组合的方式来丰富学习的特征;最后通过实验仿真,证明了改进后的孪生网络比原始的孪生网络性能有提升,并且在公共的行人重识别数据集上对比了其他行人重识别算法,结果表明本文提出的孪生网络具有更好的表现。

4、最后进行了图形界面的设计,本文所采用的图形界面实现工具是 Python 自带的 Tkinter 库。首先对 Tkinter 库的控件、标准属性信息以及几何管理进行了介绍;接着将所设计的图形界面示意图进行了展示;最后通过测试证明了所设计的图形界面可以完成检测、分割、识别功能的组合。

6.2 展望

本文对于行人重识别的研究虽然有了一些成果,但是研究工作中有待完善的地方还有很多,接下来还可以从下面几个方面进行展开研究:

1、本文虽然将行人重识别的各个阶段结合在一起做了一个简易的行人重识别系统,但是这个系统并没有真正实现完全的自动化还需要进行人为参与才能实现行人重识别任务各个阶段的功能。

2、实际中应用行人重识别的时候,处理的是动态图像而不是静态图像,如何将算法应用到视频领域是一个很有意义的研究方向。

3、本文所设计的行人重识别系统需要性能较好的显卡支撑,因为检测、分割以及识别是分别训练的,每个功能需要加载不同的模型因此所占用的计算资源较多,如何将模型轻量化则是一个很有价值的努力方向。

参考文献

- [1] Gong S, Cristani M, Yan S, et al. Person re-identification[M]. [S.l.] : Springer, 2014.
- [2] CAI Q, AGGARWAL J K. Tracking human motion using multiple cameras[C]//International Conference on Pattern Recognition. Vienna,Austria,1996: 68–72.
- [3] GHEISSARI N, SEBASTIAN T B, HARTLEY R. Person re-identification using spatiotemporal appearance[C]// IEEE Conference on Computer Vision and Pattern Recognition. New York, USA, 2006: 1528–1535.
- [4] Wang X , Doretto, Sebastian, et al. Shape and Appearance Context Modeling[C]// IEEE International Conference on Computer Vision. IEEE, 2007.
- [5] Gray D, Tao H. Viewpoint Invariant Pedestrian Recognition with an Ensemble of Localized Features[C]// European Conference on Computer Vision-eccv. 2008.
- [6] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C] // Computer Vision and Pattern Recognition(CVPR), 2010 IEEE Conference on. 2010 : 2360 -2367.
- [7] 范彩霞, 朱虹, 蔺广逢, et al. 多特征融合的人体目标再识别[J]. 中国图象图形学报, 2013, 18(6).
- [8] Bazzani L, Cristani M, Murino V. Symmetry-driven accumulation of local features for human characterization and re-identification[J]. Computer Vision and Image Understanding, 2013, 117(2):130-144.
- [9] 张耿宁, 王家宝, 张亚非, et al. 基于特征融合的行人重识别方法[J]. 计算机工程与应用, 2017(12):190-194+245.
- [10] Jobson D J, Rahman Z, Woodell G A . A multiscale retinex for bridging the gap between color images and the human observation of scenes[J]. IEEE Transactions on Image Processing, 1997, 6(7):965-976.
- [11] Matsukawa T, Suzuki E. Person re-identification using CNN features learned from combination of attributes[C]// 2016 23rd International Conference on Pattern Recognition (ICPR). IEEE, 2016.
- [12] Lin Y, Zheng L, Zheng Z, et al. Improving Person Re-identification by Attribute and Identity Learning[J]. The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp(23). 403-412.
- [13] 陈萍, 杨鸿波. 基于深度学习的行人属性识别[J]. 信息通信, 2018, No.184(04):79-81.
- [14] Zhao R, Ouyang W, Wang X. Learning Mid-level Filters for Person Re-identification[C]// 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society,

- 2014.
- [15] Chen D, Yuan Z, Chen B, et al. Similarity learning with spatial constraints for person re-identification[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 0.
- [16] Liao S, Hu Y, Zhu N X, et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2015.
- [17] Pedagadi S, Orwell J, Velastin S, et al. Local Fisher Discriminant Analysis for Pedestrian Re-identification[C]// 2013 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2013.
- [18] Tao D, Jin L, Wang Y, et al. Person Re-Identification by Regularized Smoothing KISS Metric Learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2013, 23(10):1675-1685.
- [19] 张耿宁, 王家宝, 李阳, et al. 基于特征融合与核局部 Fisher 判别分析的行人重识别[J]. 计算机应用, 2016, 36(9):2597-2600.
- [20] Prosser B, Zheng W S, Gong S, et al. [British Machine Vision Association British Machine Vision Conference 2010 - Aberystwyth] Proceedings of the British Machine Vision Conference 2010 - Person Re-Identification by Support Vector Ranking[J]. 2010:21.1-21.11.
- [21] Zhang S , Wen L , Bian X , et al. Single-Shot Refinement Neural Network for Object Detection[C]// 2018 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE.
- [22] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. // 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [23] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]. // 2016 European Conference on Computer Vision.
- [24] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, PP(99):2999-3007.
- [25] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, PP(87):542-550.
- [26] Lin T Y, Dollár, Piotr, Girshick R, et al. Feature Pyramid Networks for Object Detection[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, PP(36):1230-1237.
- [27] Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2014, 39(4):640-651.
- [28] 王爱民, 沈兰荪. 图像分割研究综述[J]. 测控技术, 2000, 19(5):1-6.

- [29] Badrinarayanan V , Kendall A , Cipolla R . SegNet: A Deep Convolutional Encoder-Decoder Architecture for Scene Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017:1-1.
- [30] Chen L C, Papandreou G, Kokkinos I, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016, 40(4):834-848.
- [31] Kaiming H, Georgia G, Piotr D, et al. Mask R-CNN[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018:1-1.
- [32] Liu Z, Li X, Ping L, et al. Semantic Image Segmentation via Deep Parsing Network[C]// IEEE International Conference on Computer Vision. 2016.
- [33] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, PP(39):107-115.
- [34] Lecun Y L, Bottou L, Bengio Y , et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [35] Pan S J, Yang Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge & Data Engineering, 2010, 22(10):1345-1359.
- [36] Chollet, François. Xception: Deep Learning with Depthwise Separable Convolutions[J]. 2016.
- [37] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, PP(12):268-276.
- [38] Bromley J, Bentz J W, BOTTOU, LéON, et al. SIGNATURE VERIFICATION USING A “SIAMESE” TIME DELAY NEURAL NETWORK[J]. International Journal of Pattern Recognition and Artificial Intelligence, 1993, 07(04):669-688.
- [39] Chopra S, Hadsell R, Lecun Y. Learning a similarity metric discriminatively, with application to face verification[C]// IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2005.
- [40] Zheng L, Shen L, Tian L, et al. Scalable Person Re-identification: A Benchmark[C]// 2015 IEEE International Conference on Computer Vision (ICCV). IEEE Computer Society, 2015.
- [41] Zheng L, Bie Z, Sun Y, et al. MARS: A Video Benchmark for Large-Scale Person Re-Identification[M]// Computer Vision – ECCV 2016. Springer International Publishing, 2016.
- [42] Zheng L, Zhang H, Sun S, et al. Person Re-identification in the Wild[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2017.
- [43] Ustinova E, Ganin Y, Lempitsky V. Multiregion Bilinear Convolutional Neural Networks for

- Person Re-Identification[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, PP(63):324-332.
- [44] Jose C , Fleuret F . Scalable Metric Learning via Weighted Approximate Rank Component Analysis[C]// European Conference on Computer Vision. Springer, Cham, 2016.
- [45] Karanam S, Gou M, Wu Z, et al. A Systematic Evaluation and Benchmark for Person Re-Identification: Features, Metrics, and Datasets[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018:1-1.
- [46] Chen Y C, Zhu X, Zheng W S, et al. Person Re-Identification by Camera Correlation Aware Feature Augmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2018, 40(2):392-408.
- [47] Barbosa I B, Cristani M, Caputo B, et al. Looking beyond appearances: Synthetic training data for deep CNNs in re-identification[J]. Computer Vision and Image Understanding, 2017:S1077314217302254.
- [48] Ma B, Su Y, Jurie, Frédéric. Covariance descriptor based on bio-inspired features for person re-identification and face verification[J]. Image and Vision Computing, 2014, 32(6-7):379-390.
- [49] Zheng Z, Zheng L, Yang Y. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, PP(72):94-111.
- [50] 宋婉茹, 赵晴晴, 陈昌红, et al. 行人重识别研究综述[J]. 智能系统学报, 2017, 12(06):770-780.
- [51] Zheng L, Yang Y, Hauptmann A G . Person Re-identification: Past, Present and Future[J]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, PP(33):1244-1252.
- [52] Karanam S, Gou M, Wu Z, et al. A Systematic Evaluation and Benchmark for Person Re-Identification: Features, Metrics, and Datasets[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018:1-1.
- [53] Martinel N, Das A, Micheloni C, et al. Temporal Model Adaptation for Person Re-Identification[C]// European Conference on Computer Vision. Springer, Cham, 2016.
- [54] Wu L, Shen C, Hengel A V D . Deep linear discriminant analysis on fisher networks: A hybrid architecture for person re-identification[J]. Pattern Recognition, 2017, 65(Complete):238-250.

致谢

时间如梭，光阴似箭，在西电的三年研究生学习生活就要结束了，在这三年里我既学到了知识也结识了朋友。感谢家人的支持、朋友的陪伴、老师的指导，让我不断成长，慢慢成熟。岁月慢慢流逝，但感情却愈加深厚，在这里我祝福他们。

首先，我要感谢我的导师冯大政教授。冯大政教授知识渊博、德才兼备、思路开阔，治学严谨。他对本文的论文选题和研究内容做了全面的指导和严格的把关。特别感谢冯大政导师这三年的包容、磨砺和帮助，在冯老师的帮助和指导下使我很快的成长，不断的进步。在这里我也特别感谢本文参考文献中的各位作者，是他们无私贡献，刻苦专研带来了科学的进步。他们的论文为我指点迷津，指明科研的道路，为本文的研究奠定了坚实的基础。

其次，我要感谢实验室全体成员，是他们的对知识的渴望和梦想的追求深深的感染了我。和他们每天在一起生活学习是我的荣幸，他们每个人身上的亮点帮助着我不断认识自己，完善自己。感谢冯祥卫师兄、胡豪爽师兄、田强师兄，是他们在我刚来实验室时给了我很大的帮助，让我很快的适应了这里的生活，积极的进入科研的状态，这为本文的撰写起到的积极的作用。感谢李梦蝶、蒋燕、陶雨停和我一起学习、交流深度学习理论，开阔了我的思路，为本文的其中一个研究点提出了一些不错的建议。

最后，再次感谢家人和朋友的支持和信任，那是我前进的力量之源。无论何时，无论何地，我一定努力奋斗不辜负他们的信任。



西安电子科技大学
XIDIAN UNIVERSITY

地址：西安市太白南路2号

邮编：710071

网址：www.xidian.edu.cn