

分类号	
学校代码	10700
学 号	2180820031

西安理工大学

硕士学位论文

(学术学位)

基于位姿嵌入的多尺度特征行人重识别技术研究

雷浩

学 科 门 类: 工 学

一 级 学 科: 轻工技术与工程

二 级 学 科: _____

指 导 教 师: 郑元林 副教授 廖开阳 讲师

申 请 日 期: 2021 年 06 月

论文题目：基于位姿嵌入的多尺度特征行人重识别技术研究

学科名称：轻工技术与工程

研究生：雷浩

签名：雷浩

指导教师：郑元林 副教授

签名：郑元林

廖开阳 讲师

签名：廖开阳

摘 要

行人重识别技术 (Person re-identification, re-id) 是一种利用计算机视觉技术来准确判断图像或者视频序列中是否存在特定行人的技术, 一般认为这是图像检索的子问题。近年来深度学习的不断发展使得行人重识别技术取得了极大地成功, 该技术也在智能安防和智能监控等领域得到广泛应用。

由于行人容易受到姿态变化、视角改变、复杂背景以及遮挡等方面的影响, 使得行人难以被识别和检索, 目前存在许多亟待解决的问题: (1) 如果通过关注行人图像的显著区域来解决遮挡和复杂背景的影响。(2) 随着行人的运动不断变化, 行人姿态和背景图像也不断发生改变, 如何学习行人的姿态与运动方式的变化, 减少行人匹配中不对齐问题。(3) 特征提取和距离度量无法完全消除不同干扰的影响, 如何提取更加鲁棒的特征并改进行人匹配来消除不同干扰的影响。针对上述问题, 本文对行人重识别方法进行研究, 主要贡献可以概括为以下两个方面:

(1) 为了解决遮挡和复杂背景的干扰问题, 本文提出了一种基于显著性模型的深度特征聚合方法, 首先利用行人图像的特殊性对每幅行人图像进行显著性特征提取, 利用显著性算法提取出图像的显著性人体区域部分去滤除复杂背景部分的干扰。然后使用深度学习的方法学习图像的全局特征, 并对原始图像进行卷积特征提取以此来捕获图像全局信息。最后设计了一种特征加权的方案对提取的特征进行有效特征融合, 利用融合特征来学习。通过这种策略, 每一幅图像信息最丰富的区域得到增强, 从而使得被提取出来的特征更具有鲁棒性。实验结果表明该方法能够根据图像自身特性, 自适应的关注图像行人部分显著性区域, 有效减少复杂背景和遮挡的影响。

(2) 为了解决行人姿态变化带来的不对齐问题, 本文提出了一种基于位姿嵌入的多尺度卷积特征融合模型。首先, 利用随机擦除的图像预处理方法对原始图像进行了预处理,

提高基线网络的性能，同时通过三元组损失函数提高基线网络的泛化能力并提取出能有效捕获全局信息的深度全局特征。然后结合显著性模型和姿态估计模型嵌入位姿学习子网络，通过嵌入的位姿学习子网络学习图像的高阶特征和拓扑信息，提取更加关注局部细节的语义局部特征。最后考虑到不同尺度特征向量之间的互补优势，将深度全局特征和局部语义特征这两个不同层次的特征进行深度聚合加权，并通过重排序策略提高特征的相似性度量。实验结果表明该方法能够自适应的对行人姿态进行学习，并通过局部区域的空间学习和全局区域的信息捕获有效减少行人图像的不对齐问题。

关键词：行人重识别；卷积神经网络；显著性模型；姿态估计

*本研究得到国家自然科学基金（编号：61671376）资助。

**Title: PERSON RE-IDENTIFICATION BASED ON POSE EMBEDDED
MULTI-SCALE FEATURE**

Major: Light Industry Technology and Engineering

Name: Hao LEI

Signature: Hao LEI

Supervisor: Associate Prof. Yuanlin ZHENG

Signature: Yuanlin ZHENG

Lec. Kaiyang LIAO

Signature: Kaiyang LIAO

Abstract

Person re-identification (RE-ID) is a technology that uses computer vision technology to determine whether there is a specific pedestrian in an image or video sequence. It is generally considered as a sub-problem of image retrieval. In recent years, the continuous development of deep learning has made great success of pedestrian re-recognition technology, which has also been widely used in intelligent security and intelligent monitoring and other fields.

Since pedestrians are vulnerable to changes in attitude, changes in perspective, complex background and occlusion, etc., they are difficult to be recognized and retrieved. Currently, there are many problems to be solved : (1) How to solve the impact of occlusion and complex background by focusing on the significant area of pedestrian image. (2) Pedestrian pose and background image constantly change with pedestrian movement. How to reduce the problem of misalignment in pedestrian matching by learning the change of Person pose? (3) Feature extraction and distance measurement cannot completely eliminate the effects of different interferences. How to extract more robust features and improve pedestrian matching to eliminate the effects of different interferences? In view of the above problems, this paper studies the Person re-identification method, and its main contributions can be summarized as the following two aspects:

(1) In order to solve the problem of the interference of sheltering and complex background, this paper proposes a model based on significant characteristics of the depth of the polymerization methods, first using the particularity of the pedestrian image significant characteristics of each pedestrian image are extracted, the significance of using significant algorithm to extract the image body area to filter the background complex part. Then the deep learning method is used to learn the global features of the image, and the original image is extracted by convolution feature to capture the global information of the image. Finally, a feature weighting scheme is designed to

effectively fuse the extracted features and use the fused features to learn. Through this strategy, the most information-rich region of each image is enhanced, so that the extracted features are more robust. The experimental results show that the proposed method can focus on some salient areas of pedestrians adaptively according to the characteristics of the image itself, and effectively reduce the influence of complex background and occlusion.

(2) In order to solve the problem of misalignment caused by the change of attitude estimation, a multi-scale convolution feature fusion model based on pose embedding is proposed in this paper. Firstly, the original image is preprocessed by the random erasure image preprocessing method to improve the performance of the baseline network. At the same time, the triple loss function is used to improve the generalization ability of the baseline network and to extract the deep global features that can effectively capture the global information. Then, the pose learning subnetwork was embedded with the significance model and the attitude estimation model. Through the embedded pose learning subnetwork, the high-order features and topological information of the image were learned, and the semantic local features which paid more attention to the local details were extracted. Finally, considering the complementary advantages among different scale feature vectors, the depth global feature and the local semantic feature were weighted by depth aggregation, and the similarity measurement was improved by reordering strategy. The experimental results show that the proposed method can learn the attitude estimation adaptively, and effectively reduce the misalignment problem of pedestrian image through local spatial learning and global information capture.

Key words: Person Re-identification; Convolutional neural network; Significance model; Pose estimation

* This study was supported by the National Natural Science Foundation of China (No. 61671376).

目 录

1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 基于传统特征研究现状	3
1.2.2 基于深度学习研究现状	4
1.3 论文主要研究内容	5
2 行人重识别研究基础	7
2.1 基于深度学习的行人重识别	7
2.1.1 卷积和池化	7
2.1.2 激活函数	9
2.2 行人重识别数据集	10
2.3 行人重识别算法评价指标	11
2.4 本章小结	12
3 基于显著性模型的深度特征聚合行人重识别方法	13
3.1 基线网络优化与训练策略	13
3.2 基于显著性模型的局部信息增强学习策略	14
3.3 深度特征融合方法	16
3.4 实验结果与分析	17
3.4.1 实施细节	17
3.4.2 在 Market-1501 和 DukeMTMC-reID 的实验	17
3.4.3 在 CUHK03 上的实验	19
3.5 本章小结	19
4 基于位姿嵌入的多尺度卷积特征融合行人重识别方法	21
4.1 Resnet-50 基线网络优化	22
4.1.1 图像预处理策略	22
4.1.2 三元组损失函数优化	24
4.1.3 训练策略	25
4.2 位姿学习嵌入子网络	26
4.2.1 显著性区域子网络	26
4.2.2 姿态学习子网络	27
4.3 多尺度向量特征聚合与重排序策略	28
4.3.1 多尺度向量特征聚合	28
4.3.2 重排序策略	28

4.4 实验结果与分析.....	30
4.5 本章小结.....	33
5 结论与展望.....	35
5.1 结论.....	35
5.2 展望.....	36
致 谢	37
参考文献.....	39
攻读学位期间主要研究成果.....	45

1 绪论

1.1 研究背景与意义

在一个场景中跟踪和监测人类活动和行为特征越来越有用，但由于部署了大量的监控摄像头，这是一项具有挑战性的任务。用于分析和理解海量视频数据流的自动化系统已经成为一种必要。对密集人群中的人群进行可靠的自动化行人重识别和行人跟踪将使系统持续监测和分析不需要人工监督，如图 1-1 所示。随着监控摄像头数量的增加，负责视频监控人员的需要花费大量的时间和精力去监控和分析行人的长期活动和行为表征，导致监控视频工作量的大幅度增加，同时也造成了人工视频监控质量的下降。因此需要对视频数据进行自动分析来提高视频监控的质量。对一个场景或特定地点每时每刻发生的事情有一个全面的了解是很重要的。如果没有用于诸如从一个摄像头到另一个摄像头识别特定行人的身份等任务的技术，人员分析就不能自动执行。



图 1-1 行人监控系统

Fig.1-1 Pedestrian Monitoring System

行人重识别^[1] (Person re-identification, re-id) 也被称为行人再识别，它旨在利用计算机视觉以及其他计算机技术去识别和检索一个图像数据库或者一个视频序列下的特定行人并进行定位和目标跟踪。在实际应用中，一个完整的行人重识别流程主要包含以下几个步骤：首先，将通过行人检测和行人跟踪技术获取的图像数据集或者视频序列输入到行人重识别算法中进行特征提取以提取特定行人的特征。然后将提取到的特定行人特征与原始图像数据集中的图像特征进行特征度量。最后根据特征度量的结果对各行人特征进行相似性排序生成排序列表，依据排序列表选择特征最为相似的图像输出，如图 1-2 所示。而从学术研究的层面考虑，现实生活中一个完整的行人重识别实时监控系統主要分为三大模块，即行人检测模块、行人跟踪模块和行人检索模块。而行人检测模块和行人跟踪模块在计算机视觉领域一般作为独立的学术研究任务，因此行人重识别研究方向的主要侧重点在行人检索模块。




图 1-2 行人重识别基本流程图

Fig.1-2 Basic flow chart of Person re-identification

1.2 国内外研究现状

视觉识别是计算机视觉研究的核心领域之一。它的目的是使机器能够从语义上解释视觉世界。其中包括图像分类、目标检测、语义分割和行人重识别等。视觉识别在自动驾驶汽车、机器人、增强现实和虚拟现实等领域有着广泛的应用。大多数视觉行人重识别系统由两部分组成，即视觉表示和分类模型。在 20 世纪末和 21 世纪初，大多数方法都独立处理这两个部分。传统特征如 SIFT 特征和 HOG 特征经常被用来捕捉图像中物体的外观和形状模式。然后利用已知的语义标签，训练支持向量机等分类模型对这些特征的语义类别进行分类。近年来，出现了一种利用卷积神经网络(CNNs)的主流方法，它将表示和分类模型学习结合成一个单一目标，并进行联合优化。这些架构将图像作为输入，并被训练为整个图像数据集或者单个图像的每个像素产生标签。

在 AlexNet^[2]赢得 ImageNet 分类挑战之后，主流计算机视觉的深度学习崛起开始于 2012 年底。与使用多种传统特征的次优方法相比，AlexNet 的分类错误率降低了约 40%。AlexNet 激发了许多后续的工作，使用卷积神经网络来解决更多的识别任务。除了上述任务外，大多数识别任务使用卷积神经网络作为表征学习的骨干，行人重识别和姿态估计。然而，卷积神经网络通常需要数以万计的标签图像来进行训练，人工标注对于各种识别任务来说是非常昂贵和耗时的。

通过多个摄像机跟踪和检索特定行人不是一项简单的任务，特别是在复杂和拥挤的场景中，频繁的遮挡和行人不断发生的姿态变化都是制约行人重识别的重要因素。行人重识别任务本身就是对视频中出现的各种数据进行建模，这些数据可能包括长期遮挡、不同的场景照明、摄像机属性或不同数量的行人等影响。在大型多摄像机网络中跟踪和检索行人是一个开放性的视觉问题，而行人重识别任务的挑战包括:(1)人数的变化，(2)所有人的持续联系，(3)存在盲点或人的进出，(4)姿势、外观和照明条件的变化。在监控视频中，由于图像尺寸小，难以从单一视角估计人体姿态。由于存在盲点、大量非重叠相机和未知信息，相机之间可能存在时空模糊和不确定性。

为了应对这些问题，当前研究主要通过提取更具有鲁棒性的特征来降低由于行人姿

态改变带来的外观变化造成的影响,行人重识别研究的特征大致可以分为两类:传统特征和深度特征。

1.2.1 基于传统特征研究现状

在行人重识别技术的特征描述中,最常用的特征是颜色特征,M. Farenzena^[3]等人将行人图像的前景与图像的背景进行分离,并为每个图像的行人身体部分计算出一个对称的轴。基于前景的行人身体结构,计算每个图像的行人身体部分的加权颜色直方图、最大稳定颜色区域和递归结构块。Gheissari^[4]等人提出通过计算每一副局部图像区域的边缘直方图和颜色直方图来识别图像前景区域的方法。该实验是在一个仅包含 44 个行人类别的数据库中进行的,虽然它是基于视频序列的,但是在整个算法的提取和特征匹配阶段却没有应用到视频信息,因此将 Gheissari 等人的研究划分为基于图像的行人重识别中。这项工作也标志着行人重识别成为独立研究课题,不再依附于多目标跟踪的课题上。Gray^[5]等人在图像的一个亮度通道上使用了 8 个颜色通道和 21 个纹理过滤器,为了更好地进行特征提取,将图像的纹理划分成为水平条纹。许多后来的研究^[6,7]使用了与 Gray^[5]等人相同的方法。类似的,Mignon^[8]等人通过 RGB、YUV 和 HSV 通道以及 LBP 纹理直方图进行水平条纹划分来得到特征向量。

与早期研究方法相比,近些年传统特征^[9-11]的特点和早年的传统特征的特点相似,在近些年传统特征的研究中,Zhao 等人^[11]首先捕获了 32 维的 LAB 颜色直方图和 128 维的 SIFT 特征描述算子,并对其进行 10×10 像素的密集采样,步长为 5 个像素;利用邻接约束搜索方法,可以从图库中的查询块中找到具有类似维度的水平条纹上,寻找与查询模型块的最优匹配。Das^[12]等人提出在头部、躯干和腿部三个重要局部区域分别绘制 HSV 直方图。Li^[13]等人的也从斑块中提取局部颜色描述符,并通过分层高斯化^[14]将局部颜色描述符聚合以便于获取空间信息。Pedagadi^[15]等人通过 PCA 算法对 HSV 和 YUV 空间进行降维,来得到颜色直方图。Liu^[16]等人对每个行人图像局部块的 HSV 直方图、LBP 直方图和梯度直方图进行提取。为了提高 RGB 值对亮度变化的鲁棒性,Yang^[17]等人提出了一种基于显著全局颜色的背景颜色空间描述符(SCNCD) 它非常适用于对每一个行人图像的整体空间全局颜色进行描述,分析了对应的背景和不同的背景颜色在整体空间上的相互影响。Liao^[18]等人提出了局部最大发生描述符(LOMO)。在图像的每个水平条纹线上进行最大池化操作,并在对数转换前建立一个金字塔模型。Zheng^[19]等人通过词袋(Bag-of-Words, BOW)将提取的每个局部块基线的 11 维颜色描述符^[20]聚合为全局向量。Matsukawa^[21]等人对每个区域进行多重建模高斯分布提取的分层高斯特征,来描述图像的外层颜色和内部纹理。

除使用颜色和纹理等的低级特征,可视为中级描述符的基于属性的特征也被广泛使用。一般认为,属性对于图像翻译来说比低级描述符更健壮。Layne^[22]等人在 VIPeR 数据集上标注与服装和生物特征相关的 15 个二元属性,将底层颜色特征和纹理特征用于属性分类器的训练,然后使用 SDALF^[3]框架对属性特征加权后得到的向量进行积分并与其

他视觉特性融合。Liu^[23]等人改进了线性判别分析(LDA)模型,使用标注属性过滤掉有噪声的线性判别分析(LDA)框架。Liu^[24]等人提出使用无监督学习获得部分具有相同属性的行人特征,再根据这些特征对每个待检测行人进行自适应匹配。Su^[25]等人将不同像机拍摄到的同一行人的二元语义属性嵌入到连续的低秩属性空间中,使得属性向量在匹配时更加准确。Shi^[26]等人建议从目前的数据库中学习一些新的属性特征,包括类别标签、颜色和纹理。这些属性直接迁移到监控视频下的行人重识别中,以提升识别效果。Li^[27]等人收集了一个具有丰富标注属性的大规模数行人据集,以便研究基于属性的行人重识别方法。

1.2.2 基于深度学习研究现状

在 Krizhevsky^[2]等人提出了 AlexNet 卷积神经网络的深度架构以极大的优势在 ILSVRC-2012 比赛中取得胜利之后,基于 CNN 的深度学习模型受到了众多学者们的关注。该模型加入了修正线性激活函数 ReLU,并且为了减少过拟合和欠拟合的情况发生,该模型又加入了数据增强和随机丢失(Dropout)方法,成功的将图像分类的错误率从 26.2%降低到 15.3%。一般来说,在行人重识别中常用的深度学习模型有两种。第一类深度学习模型是图像分类和图像检索等任务中常用的分类模型^[28]。第二种深度模型是使用图像对^[29]或三元组^[30]图像训练卷积神经网络的暹罗模型。目前,在基于深度学习的行人重识别领域中,行人重识别技术遇到的主要问题之一是缺乏训练样本,许多的行人重识别数据集得每一个行人身份仅包含两幅图像。因此,目前基于卷积神经网络的行人重识别模型极大程度上都建立在暹罗模型上。Yi^[31]等人提出对输入图像进行图像预处理,先对其使用水平分割算法在水平方向上对图像进行分割,并获取三个不重叠的水平分割图像,然后将这些水平分割后的图像输入进两个卷积层,再传入全连接层,最后将输出后的图像融合并输出特征向量,再对输出的特征向量进行距离度量来判断图像中行人的相似性。Li^[32]等人提出通过加入小块匹配层,将两幅通过卷积后的图像特征在不同水平条纹上融合,与 ACS^[11]的模型相似。Ahmed^[33]等人改进了暹罗模型,通过交叉输入邻域特征的差异性,来度量输入图像与待匹配图像邻近位置的特征,以此来获得特征之间的差异性。Wu^[34]等人通过采用较小尺寸的卷积核替换大尺寸的卷积核以此来加深网络,称为“PersonNet”。Varior^[35]等人将长短期记忆模块合并到暹罗网络中。长短期记忆模块对图像部分进行序列处理,可以记忆空间连接,提高深层特征的识别能力。Varior^[36]等人提出,在网络模型进行测试的过程中,在模型的卷积层后添加一个门控单元,来更好的对图像模态进行提取。虽然添加门控函数的方法在多个行人重识别基准数据集上都获得了较高的准确率,当时添加门控函数的方法也有相应的缺陷。在网络模型进行训练的过程中,必须将行人重识别基准数据集中的查询集图像和训练图像相匹配,因此在一些较大的基准数据集上这一过程造成了大量的时间损耗。与 Varior^[36]等人类似,Liu^[37]等人提出将注意力机制添加到暹罗网络中,通过自适应的权重变化来提取样本图像的高权重部分;然而这种添加注意力机制的暹罗模型同样会造成大量的时间损耗。这些研究主要使用的是以图像对的方式进行输入,而

Cheng^[38]等人提出了基于学习使得样本之间的类内距离小于类间距离的实现提出了通过三张图像即锚点图像、正样本、负样本输入网络进行训练并计算其三元组损失函数的方法。Su^[39]等提出一个三元组的学习方法，其中包括了使用独立数据集进行属性特征的预测和使用带有行人身份标签的数据集训练的三元组损失。

暹罗模型的一个缺点是它没有充分利用行人重识别的注释。事实上，暹罗模型只需要考虑成对(或三重)标签，确定一个图像对是否属于同一类行人，这是行人重识别中的弱标签。另一个潜在有效的策略是使用分类/识别模式，它充分利用了重新标识标签。Xiao^[40]等人通过联合多个行人重识别基准图像数据集并生成新的联合训练集，使用新生成的联合训练集来对网络模型进行训练和测试，改网络模型加入了 softmax 损失函数，并且结合全连接层与域引导集合的影响评分来共同优化行人重识别模型的性能。这种方法得到的模型无需大量的训练样本即可在大规模行人重识别基准图像数据集上取得不错的性能。然而，识别丢失的信息需要更多的训练样本来实现模型收敛。

上面提到的研究方法大多以端到端的方式进行深度学习，也有一些选择将低级特性作为输入。Wu^[41]等人将每幅图中的 SIFT 特征和颜色直方图特征在内的底层描述符聚合为单个的 Fisher 向量^[42]。将聚合生成的 Fisher 向量输入到设定好的网络模型中，并在此网络模型中加入全连接层，并将线性判别分析(LDA)作为目标函数，由此来得到类内方差低、类间方差高的嵌入。Wu^[43]等通过将全连接层特征和一个低级特征向量连接起来，在 Softmax 之前再接一层全连接层。这些方法都使用传统特征的特性来约束全连接层特性。

1.3 论文主要研究内容

本文主要研究工作和创新如下：

(1) 提出一种基于显著性模型的深度特征聚合行人重识别方法。遮挡和复杂背景是影响行人重识别的重要因素，而传统特征作为低维特征主要从行人外观进行提取，深度卷积特征作为高维特征在进行图像匹配时容易受到复杂背景和遮挡的影响。为了将高维卷积特征向量转变为低维的全局特征向量减少复杂背景对行人重识别的影响，先利用行人图像的特殊性对每幅行人图像进行显著性特征提取，再用显著性算法提取出显著性人体部分去滤除复杂背景部分的干扰。使用深度学习的方法对原始图像进行卷积特征提取，并设计一种特征加权的方案对提取的特征进行有效特征融合。通过这种策略，每一幅图像信息最丰富的区域得到增强，从而使得被提取出来的特征更具有鲁棒性。

(2) 提出一种基于位姿嵌入的多尺度特征加权融合行人重识别方法。在行人重识别领域，现阶段的卷积神经网络架构无法很好的解决行人姿态变化带来的遮挡和复杂背景影响等问题，针对以上问题本文，利用显著性模型和姿态检测的方法学习高阶特征和拓扑信息，提取到更具鲁棒性的特征进行向量度量。首先，利用优化的 Resnet-50 基线网络提取出行人图像的全局特征，然后利用显著性模型和关键点估计模型提取语义局部特征，然后通过将全局特征和局部语义特征这两个不同层次的特征进行深度聚合加权，并通过重排序的方法提高特征的相似性度量。

(3) 提出一种基于 Resnet-50 基线网络优化方法。首先通过随机擦除图像预处理方法,对预训练图像进行随机擦除,强化训练后网络模型的泛化能力;并通过不同的学习策略对网络参数进行微调,最后结合 Softmax 和 Triplet loss 函数将相同身份的行人图像之间的距离(类内距离)拉近,将不同身份的行人图像之间的距离(类间距离)拉远,使得训练的网络模型更具有判别性,进而提高网络的识别准确率。

2 行人重识别研究基础

行人重识别技术作为当前计算机视觉领域的一项热门研究方向，其未来的应用领域非常广泛，潜力巨大。目前行人重识别技术研究已经有了相当扎实的基础，但行人重识别技术目前仍旧面临诸多困难和挑战亟待解决。

2.1 基于深度学习的行人重识别

卷积神经网络（Convolutional Neural Network, CNN）是现阶段广泛应用于计算机视觉领域的常见深度学习网络框架。LeCun^[44,45]等人于上世纪 90 年代初步确立了现代卷积神经网络架构，他们设计了一种多层的人工神经网络，将其命名为 LeNet-5。LeNet-5 和其他许多算法一样可以进行反向传播训练，并能够对手写数字进行分类。然而当时缺乏大规模训练数据，计算机的性能也极大程度上的约束了神经网络的发展，因此 LeNet-5 对于复杂问题的处理效果并不好。在 ILSVRC-2012 比赛中 Krizhevsky^[2]等人提出了 AlexNet 深度卷积网络模型并在图像分类任务中取得的巨大的突破，卷积神经网络就此拉开序幕。AlexNet 网络与 LeNet-5 网络类似，但在层次结构上更加深，同时也应用了非线性激活函数 ReLu^[46]与 Dropout^[47]方法。在 AlexNet 模型取得了巨大的成功后，研究者们又在此基础上提出了众多改善方法，其中最为著名的当属 ZFNet^[48]，VGGNet^[49]，GoogleNet^[50] 和 ResNet^[51]这四种模型。这些模型的主要特点都是通过增加网络深度，使得网络可以利用增加非线性得到目标函数的近似架构，同时可以提取更为鲁棒的特征。卷积神经网络的基本组成成分比较相似，主要包含卷积层、池化层和全连接层。接下来将对卷积神经网络进行深入分析，以便理解对后续行人重识别的研究。

2.1.1 卷积和池化

卷积运算是卷积神经网络中的重要组成部分，执行卷积运算的目的是从输入图像中获得有效的特征。在行人重识别研究中，有许多不同的过滤函数可以用来进行卷积运算，使用这些过滤函数都可以从输入图像中提取不同特征。因此，卷积神经网络也通过卷积运算，并不断学习不同函数应该被赋予的权重来进行特征提取。这些被卷积神经网络提取出来的特征，会通过加权等方式组合在一起来进行特征的距离度量。卷积是指使用卷积核在图像中的对应像素点进行点乘运算，一般来说卷积后图像的维度保持不变，深度随着卷积核的个数增加。通过对图像进行零填充后，卷积运算不改变图像的大小，只改变图像的深度。如图 2.1 所示是一个图像的卷积运算过程。卷积后输出的特征图的大小如公式 2.6 所示：

$$W_2 = \frac{W_1 - F + 2P}{S} + 1 \quad (2-1)$$

经过多次卷积运算可以增加特征图的深度，而对图像尺寸没有太大影响，这种情况下模型的参数较多，运算量和模型复杂度都会成倍增加。因此一般在连续的卷积之后会引入池化层进行池化操作。池化操作通过减少或丢弃一部分对卷积神经网络模型来说影响很小却需要频繁参与运算的参数，来对特征图进行压缩，以达到降低模型复杂度的目的，同时也可以防止过拟合的情况出现。目前最为主流的池化操作主要是平均池化、最大池化和随机池化。平均池化是对特征图中需要进行池化的区域取其平均值，最大池化是计算特征图中池化区域的最大值，随机池化是根据概率矩阵对池化区域进行按照其概率值进行随机选择。如图 2.2 所示是三种不同池化方法的池化过程。




图 2-1 卷积运算过程

Fig.2-1 Convolution operation




图 2-2 池化运算过程

Fig.2-2 pooling operation

2.1.2 激活函数

激活函数（又称激励函数）对于神经网络去学习 and 理解非常复杂的非线性函数具有十分重要的作用。在神经网络中，每一个神经元节点的输出值都会输入到下一个神经元节点，而这个输出值就将作为下一个神经元节点输入值，并不断的传递给下一层。在一个深层神经网络中，激活函数（又称激励函数）会作为上一层神经元节点和下一层神经元节点的之间函数关系。如果不运用激活函数，那么输出值仅仅是一个简单的线性函数的关系。而线性函数的复杂度有限，能够得到的函数映射能力较小。没有激活函数的神经网络只是一个简单的线性回归模型。一般情况下，神经网络需要进行学习并计算线性函数，如果没有激活函数，那么神经网络将无法学习和模拟复杂类型的数据，如图像、音频和视频等。而神经网络模型被设计用来学习和表达任意复杂函数，归结于这一点，需要在神经网络中应用激活函数以便使网络更加强大，增加其学习能力，表示任意复杂函数的映射。在激活函数中，Sigmoid 函数是一种常用的激活函数，它的数学形式如下：

$$f(x) = \frac{1}{1+e^{-x}} \quad (2-2)$$

式中：

x —— 输入数据。

Sigmoid 函数的值在 0 和 1 之间，是一个 S 型生长曲线。在早期因易于理解而被普遍使用。但这样的激活函数不够理想，首先它的输出不是以 0 为中心，导数取值范围在 0 到 0.25 之间，随着网络层数加深会产生梯度消失和改变数据分布的问题，并且较为耗时的运算方式使得收敛速度也比较缓慢。

ReLU(Rectified Linear Units)激活函数是一种分段线性函数，它通过单侧抑制的方法将所有负值变为 0，正值保持不变，使得神经网络中的神经元具有了稀疏激活性。ReLU 函数其实就是一个取最大值函数，注意这并不是全区间可导的，但是可以取次梯度方法（sub-gradient）。ReLU 函数虽然简单，但却是近几年的重要成果，因为它可以很好的解决梯度消失的影响，并且拥有较快的计算速度，其收敛速度也远快于 Sigmoid 函数。ReLU 函数公式表示如下：

$$Relu = \max(0, x) \quad (2-3)$$

式中：

x —— 神经元的输入。

一般在进行过卷积运算后会使用 ReLU 函数，由于 ReLU 函数的特殊性，使得它倒数的负数恒为 0，而正数为 1。当发生梯度爆炸，ReLU 函数会将负数部分变成 0，不激活这些神经元从而解决梯度爆炸问题。因此通过 ReLU 函数可以很好地解决梯度消失和梯度爆炸现象。

2.2 行人重识别数据集

目前,现阶段大多数行人检测算法已经可以自动找出一张图像中的行人目标,并进行自动标注,不再需要人工进行标注了。而行人重识别的任务主要就是对标记过的行人目标进行匹配,搜索最佳待识别目标候选。目前行人重识别研究已经有了许多大规模数据集,例如 Market-1501^[52]、CUHK03^[53]和 DukeMTMC-reID^[54]。这些数据集是通过架设不同数目摄像头对行人图像进行采集,然后通过人工或者自动标注。被采集后的庞大数目图像构成了一个完整的行人重识别数据集,这些图像一部分用于卷积神经网络的训练并提取出图像特征,另一部分用于度量不同特征之间的距离。本文主要使用了三个行人重识别基准数据集,并在这三个公开的大规模行人重识别基准数据集 Market-1501、DukeMTMC-reID 和 CUHK03 上进行对比实验。

三个大规模行人重识别基准数据集 Market-1501、DukeMTMC-reID 和 CUHK03 的详细信息如表 2-1 所示。其中:行人身份代表了行人重识别基准数据库中所包含的行人数量以及对应的行人编号;图像数量代表了行人重识别基准数据库中所包含的图像数量;摄像头格式代表了采集行人重识别基准数据库需要的摄像头个数;评价指标代表了在行人重识别基准数据库中进行不同实验所应用的准确率衡量指标。图 2-3 列举了行人重识别基准数据集 Market-1501、DukeMTMC-reID 和 CUHK03 的示例图像。

表 2-1 行人重识别基准数据集的详细信息

Tab.2-1 Details of Re-id Datasets

行人重识别基准数据集	行人身份	图像数量	摄像头个数	评价指标
Market-1501	1501	32,668	6	CMC/mAP
CUHK03	1467	13,164	2	CMC/mAP
DukeMTMC-reID	1404	36,411	8	CMC/mAP

Market-1501 数据集采集于 2015 年,并在同年公开发布,数据集在清华大学采集,它包含从 6 个摄像头(其中 5 个高清摄像头和 1 个低像素摄像头)收集的 1501 个行人身份的 32668 张带标签的图像。图像检测使用可变形部分模型。数据集被分成两个固定的部分:来自 751 个行人的 12936 幅图像用于训练,来自 750 个行人的 19732 幅图像用于测试。训练集中每个行人平均有 17.2 张测试数据,测试集中每个行人平均有 26.8 张测试数据。在测试中,使用 750 个行人中的 3368 幅查询图像是手工绘制的,这些图像作为查询集来检索数据库中的匹配人物。该数据集提供的 32668 张带标签的图像的训练集和测试集均可以在 single-shot(单阶段回归)和 multi-shot(多阶段回归)测试设置下使用。

CUHK03 数据集在香港中文大学进行采集 MATLAB MAT file 的格式来存储的,它从 10 个摄像头(也叫 5 对摄像机组)进行财经,并以由 1467 个行人身份的 14097 个带标签图像组成。每个身份图像是从两个摄像头捕获的,大约 5 个图像为一个行人身份。有两种方法用于产生裁剪图像,即采用可变形部分模型(DPM)进行人体标注和检测。CUHK03 数

数据集包含两种测试协议：（1）测试协议 1，单阶段回归（single-shot setting），具体地说，即从 CHUK03 数据集中随机抽选包含 100 个行人身份的所有图像组成测试集，并随机抽选 100 个行人身份的所有图像作为验证集，其余未被抽到的 1160 个行人身份的所有图像组成训练集，重复二十次。（2）测试协议 2，将 CHUK03 数据集划分为包含 767 个行人身份的所有图像作为训练集和包含 700 个行人身份的所有图像作为测试集。在测试阶段，随机选择一张图像作为查询图像，除去还在查询列表里的另外一张作为训练集。评估过程使用的是带有人工注释的图像。本文选择的是第二种测试协议，使用标准实验集选择 1367 个身份进行训练，剩下的 100 个身份进行测试。

DukeMTMC-reID 数据集是一个新发布的大规模标记的多目标多摄像机行人重识别数据集。它由 8 台同步摄像机进行同步视频记录，并从视频中每 120 帧进行一次图像采样，总共采集 36411 张图像，一共有 1404 个行人出现在大于两个摄像头下。它有来自 702 个行人身份的 16522 张训练图像，来自其他 702 个行人身份的 2228 张查询图像和 17661 张测试图像，每个行人平均有 23.5 张训练图像。DukeMTMC-reID 数据集一般以 0001_c2_f0046182.jpg 类似方法进行命名，其中 0001 表示每个人的标签编号，c2 表示来自第二个摄像头(camera2)，共有 8 个摄像头，f0046182 表示来自第二个摄像头的第 46182 帧。



图 2-3 行人重识别基准数据集的图像示例

Fig.2-3 Example image from re-id dataset

2.3 行人重识别算法评价指标

行人重识别研究作为一个完整视频监控系统的一个重要环节，也是计算机视觉任务的一个重要研究方向，在行人重识别领域最重要的两个评估标准就是 Rank-N（一般 $N=1,5,10$ ）即第 N 次准确匹配的匹配准确率和平均准确率（mean Average Precision, mAP）。

Rank-N 评价指标指的是在第 N 次搜索结果中排名最靠前（即置信度最高）的 n 张图，有正确结果的概率。然而仅使用 Rank-N 评价指标是远远不够的，因为 Rank-N 评价指标无法完整的体现出算法的准确性，所以一般会使用平均准确率进行补充。平均准确率也是计算机视觉领域中常用来评价图像识别精度的标准。对于行人重识别任务而言，每个类别

都可以根据准确率(precision)和召回率(recall)得出该类别的 PR 曲线(precision, recall), 而 AP 值即为在坐标系中 PR 曲线所包括的面积, 对该 AP 值取平均值运算则可以得到 mAP 值。

正确率是指在检索过程中正确检索图像数量在排序列表中占前 K 个准确的概率, 公式如下所示:

$$P = \frac{n}{N_{loc_k}} \quad (2-4)$$

式中:

n —— 正确检索图像的数量。

N_{loc_k} —— 匹配图像排序列表。

召回率代表在匹配后的初始排序列表的前 K 张图像中正确检索图像占全部匹配图像的比率。公式如下所示:

$$R = \frac{n}{N_{loc_all}} \quad (2-5)$$

式中:

n —— 正确检索图像的数量。

N_{loc_all} —— 候选集中与查询行人相匹配的图像数量。

平均准确率 AP 是指 PR 曲线所包括的面积, 公式如下所示:

$$AP = \int_0^1 P(R) dR \quad (2-6)$$

式中:

$P(R)$ —— 召回率为 R 时的准确率。

mAP 代表每一类平均准确率的平均值, 公式如下所示:

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_i \quad (2-7)$$

式中:

m —— 行人重识别基准数据集中的行人类别数。

2.4 本章小结

本章主要介绍了行人重识别技术研究的理论基础, 研究了传统特征和深度学习在行人重识别领域中的应用, 重点介绍了颜色、纹理和 SIFT 三种传统特征, 并阐明了不同距离度量方法, 并对本文使用的卷积神经网络进行了深入研究, 阐明了卷积神经网络的基本原理和基础知识。最后对本文所使用的三种大规模数据集进行了详细介绍, 并对行人重识别技术研究的基本算法评价指标进行总结。

3 基于显著性模型的深度特征聚合行人重识别方法

非重叠摄像机视图中的行人重新识别有一个难以匹配行人图像的问题，以前的大多数解决方法都试图通过使用卷积神经网络来学习一个人的整体外观，要么是使用一个直接的分类损失，要么是使用一个矩阵学习损失来解决。为了更好地进行局部特征的学习，同样的方法也应用于图像区域，例如使用水平划分或网格划分^[38]。因为一个人的不同视角和姿态之间的匹配带来了内在的挑战，图像的局部重现之间没有隐含的对应关系。这种对应关系可以通过显式地使用全身姿态信息对进行比对，或者通过匹配检测到的身体部位进行局部特征匹配来建立。通过结合人体姿势或者身体部位信息，使用深度特征描述行人，对于行人识别有很大的帮助。

在这项工作中，本文表明一个简单逻辑，即粗略的图像信息(即全局信息)^[55,56]或精细的身体姿态(即局部信息)^[57,58]足以学习一个非常有区别的表示与简单的分类损失。因此本文提出了一个新的架构，以纳入这些线索，并显示其在大规模的具有挑战性的基准数据集中性能提高，超过现有先进的方法。本文演示在标准的 CNN 底层架构中学习和结合视图特定的特征图，可以产生明显更好的行人重识别特征。类似地，作为额外输入通道的局部特征合并有助于增加行人重识别的准确性。

3.1 基线网络优化与训练策略

行人对相机的姿态和方向会极大地影响摄像机所获取的图像的视觉外观。因此，如果图像中只包含行人图像而不包含背景图像对于行人重识别的匹配有很大的促进作用。之前的方法要么仅仅对人体进行姿态检测，依赖于精细的局部信息，要么仅仅研究图像的复杂背景干扰和图像遮挡等影响，依赖于比较粗糙的全局信息。在本节中，本文将研究这两种方法，通过显著性特征提取的方法，找到人体图像部分，并滤除复杂背景部分的干扰。通过这种方法可以同时解决姿态检测和复杂背景的影响，并且将这种方法纳入到相同的 CNN 基线结构和本文的实验中。

作为一个行人的全局信息的精细表征，本文使用 Resnet-50 卷积神经网络作为主网络进行全局特征提取。为了获得这些信息，在图 3.1 中，本文使用现有的 resnet-50 模型对整体图像进行卷积获得卷积特征。深度卷积神经网络作为视觉识别中的图像提取器，需要一个固定大小的输入图像。然而，由于部分行人图像具有任意大小/尺度，因此不可能满足这一要求。事实上，这深度卷积神经网络要求固定长度向量作为输入的全连接层。卷积层以滑动窗口的方式操作，并生成相应大小的空间输出。为了解决对于一个人的图像的任意一个小块，本文放弃了完全连接层来实现只有卷积和池化层保留的完全卷积网络。因此，Resnet-50 网络模型仍然保留空间坐标信息，能够从任意大小的输入中提取空间特征图。所提出的 Resnet-50 网络模型它包含 13 个卷积层和 5 个池化层，最后的池化层生成身份特征

图。

本文用 resnet-50 分类预先训练好的权重初始化本文所有的神经网络。为了训练一个带有视图的模型，本文首先对 Market1501 数据集进行微调。接下来，本文只训练目标行人重识别数据集上的视图单元和最终的个人身份分类层。在这个阶段，视图预测器和视图单元之前的所有层的权重都是固定的。这允许随机初始化视图单元和最终层适应的现有的权重。




图 3-1 基于显著性模型的深度特征聚合行人重识别流程图

Fig. 3-1 Person re-identification flowchart based on Multi-scale feature aggregation of significance models

当训练包含全身姿态信息的嵌入时，resnet-50 的权重与本文输入的大小不匹配。为了使网络适应 17 个通道的输入，本文首先对第一层进行微调，最后对行人 ID 分类层进行随机初始化。一旦这两层适应了网络的其余部分(即观察到收敛)，本文就继续对整个网络进行微调。在最终的特征嵌入中，本文将两种类型的位姿信息合并到一个网络中。本文使用下一节中描述的显著性特征提取模型初始化训练。然后使用卷积特征进行嵌入，并将两种不同的位姿特征进行融合，得到最终的特征输出。

对于本文所有的 CNN 嵌入，本文使用相同的训练方案。输入图像归一化标准变异值为 1。数据增强是通过将图像大小调整为 105% 的宽度和 110% 的高度。训练使用优化器修复参数并使用建议的初始学习率 0.0001 和衰减 0.96 单元。

3.2 基于显著性模型的局部信息增强学习策略

作为一个行人的局部信息的细节表征，本文使用 VGG-16 卷积神经网络作为主网络进行卷积特征提取，得到最终的显著性图像 a。并且在此基础上引入超像素分割方法^[59]获取传统特征，得到最终的显著性图像 b。最后融合显著性图像 a 和显著性图像 b 输出最终

的显著性图像，如图 3-2 所示。

对于行人图像，想要得到它的显著性图，常用的方法包括基于传统的显著物体检测以及基于深度学习的显著物体检测。随着卷积神经网络的发展，基于深度学习的显著物体检测方法得到很大的发展，成为显著物体检测的主流方法，但是，在面对图像的边界细化方面，传统的显著物体检测方法有着很大的优势，因此，我们结合传统特征和深度学习来共同提取行人图像中的显著物体。

首先，如图 3-2 所示，对于输入的图像，我们首先使用超像素分割，将每一幅图像分为若干个超像素块，并初始化聚类中心，形成多个种子点，对于每个搜索到的像素点，分别计算它和该种子点的距离。具体的距离计算公式为：

$$d_c = \sqrt{(lj - li)^2 + (aj - ai)^2 + (bj - bi)^2} \quad (3-1)$$

$$ds = \sqrt{(xj - xi)^2 + (yj - yi)^2} \quad (3-2)$$

$$D' = \sqrt{\left(\frac{dc}{Nc}\right)^2 + \left(\frac{ds}{Ns}\right)^2} \quad (3-3)$$

式中：

dc——超像素点与种子点之间的颜色距离；

ds——超像素点与种子点之间的空间距离；

Ns——类内最大空间距离，定义为 $Ns = S = \text{sqrt}(N / K)$ ；

Nc——最大颜色距离。

不断迭代优化，使得误差在可容忍的范围内。然后将处理后的图像输入到改进的 VGG16 网络中去，通过卷积网络得到基于深度学习的显著图像；使用改进的 VGG-16 网络模块，删除了全连接层和池化层。利用五个卷积模块的最后一个卷积特征作为输入特征。使用特征增强模块将每一层提取到的特征 与其经过两倍的上采样的下一层特征进行融合形成新的特征层。将特征以不同的扩张速率（1、3、5、7）得到四个不同扩张速率，相同维数的特征图，再将这四张特征图融合为一，通过特征融合模块融合，在经过损失函数进行训练，得到显著物体图像。

以及提取出行人图像的颜色、方向和亮度特征图，对特征图进行中央周边差及归一化处理，得到颜色、方向和亮度分量图，对三个分量图进行线性融合，然后对融合后的图像进行边界细化，得到边界细化后的显著图，最后，将两个显著图融合，这样就得到了最终的显著图。

值得一提的是根据上述方法得到的超像素信息图像还需要分别计算每一个超像素点的显著性，通过计算每一个像素点到超像素点的距离作为图像的显著性。因此需要分别对图像的全局、边缘和边缘计算其显著性。在计算图像的全局显著性的过程中，需要计算每一个像素点到超像素点之和。

$$Sa(i) = \sum_{j=1}^n \text{dist}(i, j) \quad (3-4)$$

为了便于显示，对其进行归一化，使得 Sa(i) 取值范围为[0,255]：

$$Sa(i) = \frac{(Sa(i) - \min(Sa)) * 255}{\max(Sa) - \min(Sa)} \quad (3-5)$$

图像的全局显著性就是公式 3-5 得到的 $Sa(i)$ 替换掉计算的超像素点所在位置的灰度值。

计算图像的边缘显著性时，与计算图像全局显著性的方法类似，同样需要计算每一个像素点到超像素点之和，在计算时需要首先判断该点是否位于提前设定好的阈值的边缘点。

$$Sa(i) = \sum_{j=1, j \in Edge}^n dist(i, j) \quad (3-6)$$

在计算图像的局部显著性时，同样与计算图像全局显著性的方法类似。需要在计算每个像素点到超像素点之和时，首先需要判断该点的欧氏距离是否小于提前设定好的某个阈值，若小于设定好的某个阈值，则局部显著性的计算方法如下：

$$Sa(i) = \frac{\sum_{j=1, dist(i,j) \leq R}^n e^{-w * dist(i,j)} * Sa(j)}{\sum_{j=1, dist(i,j) \leq R}^N e^{-w * dist(i,j)}} \quad (3-7)$$




图 3-2 显著性图像提取流程图

Fig. 3-2 Saliency image extraction process

3.3 深度特征融合方法

通过深度架构提取出的特征可能受到行人不同姿势、遮挡以及复杂背景信息的显著变化带来干扰，无法准备定位并且识别行人。而显著性特征可以很大程度上减少复杂背景信息和行人姿态的干扰，在克服行人重识别中的复杂背景信息和行人姿态变化时更加可靠。因此将两种不同特征的信息整合来克服它们的个别缺陷是可行的。

从图像的显著性特征和深度特征这两个维度进行考虑，本文可以分别从这两个维度学习查询图像和参考图像之间的距离。基于深度特征 (DEEP) 和显著性特征 (SOD)，通过

距离度量函数可以获取各个特征优化的距离度量，如公式 3-8 所示：

$$d_k(x_{ik}, x_{jk}) = (x_{ik} - x_{jk})^T W_k \quad (3-8)$$

$$\left((W_k^T \Sigma_I W_k)^{-1} - (W_k^T \Sigma_E W_k)^{-1} \right) W_k^T (x_{ik} - x_{jk}) \quad (3-9)$$

式中：

k —— $DEEP, SOD$ 特征。

为了表达两种不同特征之间的互补性，通过对参数进行加权对深度特征和显著特征进行融合，最终得到的距离排序结果如公式所示：

$$d = \alpha d_{DEEP} + (1 - \alpha) d_{SOD} \quad (3-10)$$

式中：

α ——表示深度特征和显著性特征的权重。



图 3-3 显著性图像输出

Fig. 3-3 Saliency image output

3.4 实验结果与分析

3.4.1 实施细节

该方法是基于 Pytorch 框架和 NVIDIA 2018Ti GPU 实现的。对于网络架构的选择上，本文选用了 Resnet-50 进行图像的预训练，三个数据集中的图像大小调整为 $256 \times 256 \times 3$ ，小批数为 8。提出的架构在每个批次中优化 20,000 迭代，总共 70 个批次。学习率从 0.05 开始，每 40 个批次被 10 除一次，以训练模型达到 70 个 Epoch，序列长度设为 $T=8$ 。

3.4.2 在 Market-1501 和 DukeMTMC-reID 的实验

本节将所提出的方法与现有的先进方法进行比较，并给出结果。在表格中，因为不同模型的侧重和提出的时间不同，导致不同数据集的主流模型是不同的。其中表 3-1 和表 3-

2 为其他不同算法在 Market-1501 和 DukeMTMC-reID 行人重识别基准数据集的 rank-1、rank-5、rank-10 和 mAP 的算法模型评价结果。

从表 3-1 和表 3-2 中可以得出本文在 Market-1501 和 DukeMTMC-reID 行人重识别基准数据集的 rank-1、rank-5、rank-10 和 mAP 的算法模型评价比较中, 本文算法模型的精度高于所比较的其他算法模型。在 Market-1501 数据集中, 本文算法在 rank-1、rank-5、rank-10 和 mAP 分别达到了 90.1%、95.8%、96.9%和 84.5%。rank-1 指标的准确率相比 PAN^[60]模型高出 7.3 个百分点。在 DukeMTMC-reID 数据集中, 本文算法在 rank-1 和 mAP 分别达到了 83.2%和 77.9% , 在 rank-1 指标的准确率上相比 PAN^[60]模型高出 11.6 个百分点。

表 3-1 Market-1501 数据集上不同算法的实验结果对比

Fig.3-1 Comparison of experimental results of different algorithms on Market-1501 dataset

方法	Rank 1	Rank-5	Rank-10	mAP
BOW	44.4	63.9	72.2	12.2
WARCA	68.1	76.0	-	45.2
KLFDA	71.1	79.9	-	46.5
MSCAN	80.3	-	-	57.5
SVDNeT	82.3	92.3	95.2	62.1
PAN	82.8	-	-	63.4
MGCAM	83.8	-	-	74.3
AOS	86.5	-	-	70.4
GLAD	89.9	-	-	65.5
Proposed	90.1	95.8	96.9	84.5

表 3-2 DukeMTMC-reID 数据集上不同算法的实验结果对比

Fig.3-2 Comparison of experimental results of different algorithms on DukeMTMC-reID dataset

方法	Rank 1	mAP
BOW	25.1	12.2
LOMO+XQDA	30.8	17.0
PAN	71.6	51.5
SVDNet	76.7	56.8
AOS	79.2	62.1
PSE	79.8	62.0
MLFN	81.0	62.8
Proposed	83.2	76.9

3.4.3 在 CUHK03 上的实验

本实验采用 CHUK03 测试协议 2，即通过将 CHUK03 数据集划分为包含 767 个行人身份的所有图像作为训练集和包含 700 个行人身份的所有图像作为测试集。在测试阶段，随机选择一张图像作为查询图像，除去还在查询列表里的另外一张作为训练集。评估过程使用的是带有人工注释的图像。通过该方法可以有效避免重复训练和测试。表 3-3 为 CKUK03 行人重识别基准数据集的分类结果。

表 3-3 CUHK03 数据集新分类规则下分类结果

Tab.3-3 classification result on CHUK03 dataset with new classification rules

数据分类	labeled	detected
Train	7368	7365
Gallery	5328	5332
Query	1400	1400

表 3-4 的结果表明，本文提出的算法相比其他模型提出的算法获得了更高的准确率，因此本文所提出的算法对于行人重识别是可行的。本文提出的算法与其他相比，在“Labeled”数据集上，相比 HA-CNN^[61]本文提出的算法 rank1 的值高 14.8 个百分点，mAP 值要高 12.5 个百分点，在“Detected”数据集上，相比 HA-CNN^[61]本文提出的算法 rank1 的值高 15 个百分点，mAP 值要高 14 个百分点，故证明本文提出的算法模型是有效的。

表 3-4 CUHK03 数据集新分类规则下不同算法的实验结果对比

Tab.3-4 Comparison of experimental results of different algorithms on CHUK03 dataset with new classification rules

方法	Labeled		Detected	
	Rank 1	mAP	Rank 1	mAP
LOMO+XQDA	14.8	13.6	12.8	11.5
IDE®	21.9	20.0	21.1	19.0
IDE®	32.0	29.6	31.1	28.2
SVDNet	40.9	37.8	37.2	41.5
HA-CNN	44.4	41.0	41.7	38.6
MLFN	54.7	49.2	52.8	47.8
Proposed	59.2	53.5	56.7	52.6

3.5 本章小结

文章提出了一种基于显著性模型下多尺度特征融合的行人重识别方法，提出了使用显著性模型对图像进行处理，提取出行人图像中人体显著性区域图像，并消除了复杂背景

部分对于行人重识别的干扰。并在此基础上使用深度学习方法进一步提取出全局特征和局部特征，并设计出一种特征加权方案对提取的特征进行有效融合，最大程度上的增强每一幅图像的细节区域。在三个数据集上的广泛的实验结果都表现出良好的性能。

4 基于位姿嵌入的多尺度卷积特征融合行人重识别方法

影响行人重识别精度的一个关键的因素就是行人的错位，这种错位带来的行人身体各部件之间相互遮挡和姿态的不断变化对于行人重识别研究是一个很大的挑战。首先，行人在运动的过程中姿态是不断发生改变的，行人不可避免的会变化各种姿态，而这种姿态变化意味着身体的局部变化在边界框中是不可预测的。例如，行人在运动过程中可能将手放在背后或者头顶上，造成了错位带来的局部遮挡，这对提取的特征具有很大的影响。其次，当行人排列不规则时进行检测对行人重识别研究的准确度会带来影响。在行人重识别领域常用的一个方法是将边界框划分为水平条纹^[32,33]，然而这种方法只能建立在有轻微的垂直偏差下。当垂直偏差失准时，身体和头部的检测可能会与背景进行匹配，导致行人重识别任务的错误识别。因此水平条纹的方法在严重错位时的情况并不理想。在行人不断变化姿态的情况下，背景也在随之不断产生变化，导致背景可能会被卷积神经网络错误的加权从而影响识别精度。因此如何解决行人姿态变化带来的错位和背景变化的影响是提高行人重识别精度的关键。本章从显著性模型出发，通过分离前景与背景，滤除复杂背景的影响下，利用人体关键点估计的方法提取行人的局部特征，并通过随机擦除的方法对基线网络进行图像预处理，加强网络模型的鲁棒性，从而提取到更具鲁棒性的全局特征。最后通过这些不同尺度的特征进行深度加权融合，通过重排序的方法来提高特征之间的相似性度量。

在本章中，利用人体关键点估计的方法提取局部特征，与深度特征互补，提出了一种基于姿态的深度特征加权聚合模型。本章提出的模基于姿态的深度特征加权聚合模型如图所示，本章贡献主要分为以下几个方面：

- 1) 提出将显著性模型与人体关键点估计方法结合，在滤除复杂背景带来的干扰情况下，使用姿态估计器生成对齐良好的行人图像，以便于深度学习网络可以再剧烈的姿态变化下识别同一个行人。
- 2) 通过随机擦除和三元组损失函数的方法提高的基线网络的性能，并通过使用姿态估计提取得到的局部特征与基线网络得到的全局特征进行特征加权聚合，实现了全局优化的目的。
- 3) 在多个已公开的大规模数据集 Market-1501、DukeMTMC-reID 和 CUHK-03 的实验结果表明，本文提出的模型具有较高的准确率。




图 4-1 基于位姿嵌入的多尺度卷积特征融合行人重识别方法流程图

Fig.4-1 Person re-identification flowchart based on Multi-scale convolution feature fusion for position and pose embedding

4.1 Resnet-50 基线网络优化

在行人重识别研究中，由于行人运动的不断变化造成的位姿变化以及行人各身体部位的遮挡和复杂背景因素的干扰下，造成行人部分图像缺失和判断信息错误，从而对算法模型的准确率造成影响。为了解决以上问题带来的影响，本文提出了一种 ResNet-50 网络优化方法，以提高行人重识别的准确度。基线网络本文使用的是 ResNet-50 网络，通过使用图像预处理的方式对行人图像进行随机擦除，并通过结合三元组损失与 Softmax 损失函数的方式优化基线网络模型，得到更加健壮的全局特征。

4.1.1 图像预处理策略

图像预处理技术^[62]在计算机视觉领域的应用十分广泛，在图像分类和图像识别研究中，为了增加训练样本的数量以及样本的多样性，研究者们通常使用图像归一化^[63]加速网络模型的收敛，部分研究也用色彩空间变换和几何空间变换等方法增加训练样本的数量和多样性。色彩空间变换主要是用亮度调整、色彩抖动和对比度增强方法对图像进行处理。几何空间变换主要是用随机裁剪、图像尺寸变化、图像旋转等进行数据增强。通过对原始数据库进行图像增强，可以将原本难以辨别的训练样本转化为有效训练样本。由于深度学习本就是在大规模的训练中建立输入 X 和输出 Y 之间的映射关系，因此图像预处理对于深度学习具有重要的作用。在深度学习中，研究者们通常应用网络模型调整，手工干预和数据增强等方法对已有的原始图像进行增强。

随机擦除增强处理 (Random Erasing Augmentation, REA)^[64]作为一种图像预处理方法，可以很好地进行数据增强。它旨在对不同训练图像进行遮挡，在图像中随机生成一个

矩形区域,该矩形区域的位置和大小都随机产生,并遮挡部分行人图像,将图像遮挡区域的像素值设定为随机值。通过这种方法可以降低过拟合的情况发生,提高网络模型收敛的能力,从而提高深度学习模型的性能。

在网络模型训练中,对于原始训练数据集,假设原始数据集进行随机擦除的概率为 P ,则不被进行擦除的概率为 $1 - P$ 。在随机擦除过程中,以设定好的概率 P 产生矩形区域对图像进行遮挡,这个过程中随机擦除并遮挡的位置和遮挡区域大小都是随机的。

假设图像数据集中的初始图像的大小为:

$$S = W \times H \quad (4-1)$$

式中:

W —— 随机擦除图像的宽度;

H —— 随机擦除图像的高度。

假设进行随机擦除的矩形区域面积大小为 S_e , 并且该面积大小在最小值 S_l 和最大值 S_h 指定的范围内。随机擦除区域的长宽比为 r_e , 那么随机擦除矩形区域的宽度 H_e 和高度 W_e 为:

$$H_e = \sqrt{S_e \times r_e} \quad (4-2)$$

$$W_e = \sqrt{\frac{S_e}{r_e}} \quad (4-3)$$

式中:

S_e —— 随机擦除矩形区域的面积值;

r_e —— 随机擦除矩形区域的高宽比;

H_e —— 随机擦除矩形区域的高;

W_e —— 随机擦除矩形区域的宽。

在初始图像上随机选取一个点 $P = (x_e, y_e)$, 若满足如下公式 4-4 和公式 4-5:

$$x_e + W_e \leq W \quad (4-4)$$

$$y_e + H_e \leq H \quad (4-5)$$

那么初始图像的待擦除矩形区域为 $(x_e, y_e, x_e + W_e, y_e + H_e)$, 利用随机擦除算法生成的待擦除矩形区域, 将待擦除区域中的每一个像素点随机选取 $[0, 255]$ 中的值用以取代原矩形区域。如果随机选择的点 $P = (x_e, y_e)$ 不满足公式 4-4 和公式 4-5 的条件, 则会一直重复上述过程, 在图像中重新选择一个新的点 $P = (x_e, y_e)$, 直到选择了恰当的随机点。最后, 被随机擦除的原始训练样本图像会被输出, 效果如图 4-2 所示。



图 4-2 随机擦除效果图

Fig.4-2 Randomly erase effect diagram

4.1.2 三元组损失函数优化

三元组损失 (Triplet loss) [65] 在计算机视觉领域应用十分广泛, 在行人重识别任务重也是一种重要的手段。使用三元组损失函数训练网络时, 需要输入三张图片作为训练样本, 三张图片包括: 一幅锚点图像, 一幅来自锚点图像同一类别的正样本图像和一幅来自不同类别的负样本图像。在使用三元组损失函数时, 将三张图片作为网络的输入: $x_i = \langle x_i^a, x_i^p, x_i^n \rangle$, 设定 x_i^a 为锚点图像 (Anchor), 在数据集内随机选取样本进行网络模型的训练, 设定 x_i^p 为来自锚点图像同一类别的正样本训练图像, 设定 x_i^n 为一幅来自不同类别的负样本训练图像。卷积神经网络会利用这三张训练样本图像进行网络学习, 利用锚点图像、正样本图像和负样本图像进行权值更新, 卷积神经网络进行三元组损失的学习后, 会拉近锚点图像与正样本图像之间的距离, 也就是类内距离。并且会推远锚点图像与负样本图像之间的距离, 也就是类间距离, 如图 4-3 所示。最终用于计算三元组损失函数的公式为:

$$L_{triplet} = \sum_i^N \left[\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha \right]_+ \quad (4-6)$$

式中:

x_i^a —— 锚点图像;

x_i^p —— 正样本图像;

x_i^n —— 负样本图像;

α —— 类间距离和类内距离之间的最小间隔;

$+$ —— $[\]$ 内恒大于零。

基于公式 4-6 可得, x_i^a (锚点图像) 与 x_i^n (负样本图像) 之间的距离为类间距离, x_i^a (锚点图像) 与 x_i^p (正样本图像) 之间的距离为类内距离。当类间距离和类内距离之和加上 α 的值大于零时才会存在损失值, 而类间距离和类内距离之和加上 α 的值小于或者等于零时, 损失值恒等于零。因此通过三元组损失函数可以将来自同一个类别的图像之间的距离拉近, 将来自不同类别的图像之间的距离推远, 以此来提高网络模型的性能和准确率。

结合了 Softmax 损失函数和三元组损失函数的最终损失函数被表达为:

$$L = \frac{1}{m} (\sum_1^m L_{softmax} + \sum_1^m L_{triplet}) \quad (4-7)$$

式中:

m —— 所使用的损失函数数量。




图 4-3. 三元组损失函数示意图

Fig.4-3 Triplet loss effect diagram

4.1.3 训练策略

本文方法是基于 Pytorch 框架和 2 个 NVIDIA 2018Ti GPU 来训练基线网络 ResNet-50, 训练过程中的 BatchSize (批次) 为 32, 数据集集中的图像大小调整为 $256 \times 256 \times 3$, 每个小批次为 8 个行人身份。训练总共迭代 69 个 Epoch (批次), Lr (学习率) 从 0.01 开始, Dropout (每次训练随机丢失隐含层的节点数) 为 0.5, 步长为 2。并结合 Softmax 损失和三元组损失优化网络结构, 以达到更好的训练效果, 增强网络的泛化能力, 防止过拟合。表 4-1 为训练参数的设置。

表 4-1 训练参数设置

Tab.4-1 Training parameter setting

训练参数	值
Batch Size	32
Dropout	0.5
Epoch	69
Stride	2
Lr	0.01

4.2 位姿学习嵌入子网络

4.2.1 显著性区域子网络

在姿态检测阶段进行姿态构建的过程中,由于本文使用现成的姿态估计器,当行人图像有缺失或者分辨率较低时,可能会发生姿态估计错误和信息丢失等情况,导致进行姿态检测后的图像质量下降。并且进行姿态检测后复杂背景并未去除,复杂背景对行人重识别的检测精度仍然构成影响,因此本文提出使用显著性目标检测模型对图像进行预处理,在避免复杂背景因素的影响的同时,可以更加简单的进行人体姿态估计。显著性目标检测是一种用以识别图像中最为显著的目标的方法,近年来作为计算机视觉中图像预处理的一个步骤收到了广泛关注,如目标重新定位^[66,67]、场景分类^[68]、视觉跟踪^[69,70]、图像检索^[71,72]和语义分割^[73,74]等方法。显著目标检测方法的优点是可以识别图像中最为显著的区域,而在行人重识别领域中的大规模图像数据集几乎是非常显著的行人图像,图像中几乎仅包含行人和复杂背景。因此使用显著性目标检测方法可以很好地对行人图像进行前景与背景的分隔,这是一个很好地图像预处理方法,可以增强图像的人体语义部分,减少甚至去除复杂背景对行人重识别精度带来的干扰。

Zhang^[75]等人提出了一种多尺度特征聚合网络,可以利用多个尺度的卷积特征作为显著线索进行显著性目标检测。本文也使用多尺度特征聚合网络对图像训练样本进行图像预处理,对前景与背景进行分离。具体来说显著目标检测模型主要分为四个部分:多级特征提取,递归显著图预测和边界保持细化。

多级特征提取:由于 VGG-16^[37]模型在图像分类和泛化特效方面的效果理想,因此显著性模型也使用 VGG-16 构建网络结构。给定一个大小为 $W \times H$ 的输入图像,那么输出映射的大小为 $[W/2^5, H/2^5]$,因此基于 VGG-16 构建的网络结构将输出减少了 32 倍的特征映射。为了平衡语义上下文和图像细节,本文去掉了最后一个池化阶段,并扩大了输入图像的大小。这样本文的特征提取网络的输出特征映射相较于输入图像被缩小了 16 倍。

递归显著图预测:集成的特征映射已经包含了各种显著性线索,因此本文可以利用它们来预测显著性映射。本文直接将各个层次的综合特征图反褶积为输入图像的大小,并添加一个新的卷积层来生成预测的显著性图。

边界保持细化:为了进一步进行边界细化分离前景与背景,通过在预测结果中引入短连接来增加边界细化。期望这些底层特征有助于预测物体的边界。此外,这些特征对于输入图像也具有相同的空间分辨率。对于边界细化,首先将核尺寸为 1×1 的卷积层应用于 conv1-2 层,产生边界预测。并将产生的边界预测添加到原始预测中,以获得更好的对齐对象边界。基于边界细化的边界框,应用并学习一个额外的卷积层来产生融合显著性预测作为最终输出。

4.2.2 姿态学习子网络

姿态估计模型是计算机视觉领域一个重要的研究方向。在行人重识别研究中, Su^[76]等人提出了一个基于姿态驱动的行人重识别框架, 可以很好的避免姿态变化带来的干扰, Zheng^[77]等人也提出了基于位姿嵌入的行人重识别模型。本文采用姿态卷积器 (CPM)^[78]的现成模型进行姿态提取, CPM 是一种顺序卷积结构, 它可以检测到 14 个身体关节, 即头部、颈部、左肩和右肩、左肘和右肘、左腕和右腕、左髋和右髋、左膝和右膝以及左踝和右踝, 如图 4 所示。本文提出的姿态估计模型主要分为四个步骤, 包括关节点定位、生成原始零件图像、位姿变换和输出最终身体部位图像。

关节点定位: 根据章节 4.1.1 中输出的人体显著性图像, 将显著性图像作为姿态估计器的输入, 人体姿态估计算法定位人体的 14 个关节。图 1 (c) 显示了人体 14 个关节的示例。根据编号, 这 14 个关节是头、颈、右肩、右肘、右腕、左肩、左肘、左腕、左髋、左膝、左踝、右髋、右膝、右踝。

生成原始零件图像: 然后本文提出了六个矩形来覆盖人体的六个不同部位, 包括头部、上身、两臂和两腿。使用 14 个人体关节进一步定位 6 个子区域 (头部、上身、左臂、右臂、左腿和右腿) 作为人体部位。这些零件通过裁剪、旋转和调整大小到固定的大小和方向来标准化。这些调整大小和旋转的部分组合在一起形成身体部位图像。由于人体 6 个部位的大小不同, 在人体图像中不可避免地会出现黑色区域。

位姿变换: 由于经过调整大小和旋转的部分组合在一起的身体部位图像会出现黑色区域, 因此本文需要对每个身体部位的尺寸进行位姿变换。每个身体部位的尺寸主要是根据本文的观察确定的。例如, 本文观察到手臂的宽度约为 20 像素, 腿部的宽度约为 30 像素。减小这些参数值将导致信息丢失; 增大这些参数可能会带来更多的背景噪声。然而, 只要参数变化很小, 系统性能就保持稳定。其原因是当零件尺寸在较小范围内变化时, 其中包含的鉴别信息变化不大, 因此在给定监控信号的情况下, 网络仍然能够学习鉴别嵌入。

输出最终身体部位图像: 得到最终的身体部位图像后, 将这些图像作为一个全新的数据集, 将其分类为测试集和训练集, 使用新的 ResNet-50 网络进行训练, 注意这里的 ResNet-50 网络与 ResNet-50 基线网络并不贡献权重, 而是单独训练一个新的权重来对局部语义图像进行判断, 提取局部语义特征。




图 4-4 位姿嵌入效果图

Fig.4-4 Pose embedding effect diagram

4.3 多尺度向量特征聚合与重排序策略

4.3.1 多尺度向量特征聚合

通过基线网络提取出的深度全局特征是一个较为鲁棒的特征，可以很好的识别行人，但是无法聚焦于局部信息，忽略了局部信息带来的影响。而通过姿态估计模型提取的局部语义特征更多关注局部细节信息。因此将两种不同尺度的特征通过加权融合得到一个更加具有判别性的融合特征是一个很好的解决办法，可以在关注全局信息的同时更加重视局部语义信息。通过这个方法可以定位人体不同姿态带来的姿态变换和局部遮挡的影响，在显著性模型的帮助下复杂背景的干扰也被降到最低，使得融合特征在克服行人重识别中人体位姿变化时更为可靠。因此本文将两种不同尺度的特征进行融合的方法是有效的。

简而言之，基于从深度全局特征和局部语义特征两个方面考虑，本文融合两个特征之后学习融合特征在测试库和查询库中的距离。基于本文提出的全局特征和局部语义特征，采取特征加权聚合如公式所示

$$d = \alpha f_{DEEP} + (1 - \alpha) f_{SOD} \quad (4-8)$$

式中：

α ——参数 $0 \leq \alpha \leq 1$ 代表深度全局特征和局部语义特征之间不同的权重。

4.3.2 重排序策略

一般来说，行人重识别是可以看作计算机视觉技术中的图像检索问题。给定一个行人测试图像数据集，要在参考图像数据集中以交叉相机模式搜索包含同一个行人的图像数

据集, 搜索参考图像集后会生成一个初始列表排名, 然后通过对初始列表中的图像进行重新排序, 以获得更高的期望图像正确匹配排名。重排序算法的有效性很大程度上依赖于初试排名列表的质量。如果返回的图像排列顺序在搜索的最近邻域内, 那么它很可能是一个正确匹配。然而真实情况可能会偏离理想情况, 因为错误匹配也可能出现在最近邻域中。而重排序算法最大的优点在于它不需要额外的样本对深度网络进行训练就可以获得更高的排名, 适用于所有的初始列表排名结果都能够采用重排序策略进行优化。

基于上述情况, Zhong^[79]等人提出基于 k-倒数编码模型通过对初始排名列表进行重新排序以提高行人重识别精度。具体而言, 首先, 对于一幅给定的行人测试图像 p 和一个给定的图像集 $G = \{g_i | i = 1, 2, \dots, N\}$, 通过加权将 k-倒数最近邻编码为一个特征向量, 来得到 k-倒数特征, 然后利用图像 k-倒数特征计算出两幅图像的杰卡德距离(Jaccard Distance)。最后将原始距离和杰卡德距离进行加权得到最终的距离度量。

首先, 输入行人测试图像 p 用于测试, 并给定一个图像集 $G = \{g_i | i = 1, 2, \dots, N\}$ 用于行人图像参考, 那么可以通过马氏距离来对行人图像 p 和参考数据集 g_i 之间的原始距离进行度量, 度量结果如公式所示

$$d(p, g_i) = (x_p - x_{g_i})^T M (x_p - x_{g_i}) \quad (4-9)$$

式中:

x_p —— 行人测试图像 p 的外观特征;

x_{g_i} —— 参考图像 g_i 的外观特征;

M —— 半正定矩阵。

计算测试图像 P 和参考图像 g_i 的初始距离生成初始排名列表:

$$L(p, G) = \{g_1^0, g_2^0, \dots, g_N^0\} \quad (4-10)$$

将初始排名列表中的前 k 个排名定义为 k 近邻 (k-nearest neighbors, k-nn), 即:

$$N(p, k) = \{g_1^0, g_2^0, \dots, g_k^0\}, |N(p, k)| = k \quad (4-11)$$

k-倒数最近邻(k-reciprocal nearest neighbors, k-rnn), 表示为:

$$R(p, k) = \{g_i | (g_i \in N(p, k)) \wedge p \in N(g_i, k)\}$$

然而, 由于亮度变化、姿态变化、遮挡以及视角变化等影响因素, 最近邻中可能不包含正确匹配样本。为了解决这个问题, 将每一个候选的最近邻集合转化为一个更加鲁棒的集合:

$$R^*(p, k) \leftarrow R(p, k) \cup R(q, \frac{1}{2}k) \quad (4-12)$$

$$s.t. \left| R(p, k) \cap R(q, \frac{1}{2}k) \right| \geq \frac{2}{3} \left| R(q, \frac{1}{2}k) \right|, \forall q \in R(p, k) \quad (4-13)$$

根据检索图像和较近邻之间的原始距离重新分配权重,通过高斯核将样本图像的 k 倒排最近邻集合编码成 N 维向量, 定义为 $v_p = [v_{p,g_1}, v_{p,g_2}, \dots, v_{p,g_N}]$, v_{p,g_i} 表示为:

$$v_{p,g_i} = \begin{cases} e^{-d(p,g_i)} & \text{if } g_i \in R^*(p, k) \\ 0 & \text{otherwise} \end{cases} \quad (4-14)$$

基于近邻被分配较大的权重,远邻被分配较小的权重,计算杰卡德距离需要的交集和并集的候选数可以计算为:

$$|R^*(p, k) \cap R^*(g_i, k)| = \|\min(v_p, v_{g_i})\|_1 \quad (4-15)$$

$$|R^*(p, k) \cup R^*(g_i, k)| = \|\max(v_p, v_{g_i})\|_1 \quad (4-16)$$

交集通过最小操作将两个特征向量对应维度上的最小的那个值作为两者共同包含 g_i 的程度。并集的最大操作就是为了统计两个集合中的匹配候选的总集合。

最终的杰卡德距离表示为:

$$d_j(p, g_i) = 1 - \frac{\sum_{j=1}^N \min(v_{p,g_j}, v_{g_i,g_j})}{\sum_{j=1}^N \max(v_{p,g_j}, v_{g_i,g_j})} \quad (4-17)$$

将原始距离与杰卡德距离联合对初始排序列表进行修正, 则最终的距离定义为:

$$d^*(p, g_i) = (1 - \lambda)d_j(p, g_i) + \lambda d(p, g_i) \quad (4-18)$$

式中:

λ ——加权参数 λ 表示两个距离的权重, 当 $\lambda = 0$ 时只考虑杰卡德距离, 当 $\lambda = 1$ 时只考虑原始距离。

4.4 实验结果与分析

本文实验在三个公开的大规模行人重识别基准数据集上进行训练和测试, 即 Market-1501, CUHK03 和 DukeMTMC-reID 行人重识别基准数据集。本方法在这三个大规模公开数据集上进行训练、查询和测试, 在实验的过程中, 本文遵循行人重识别基准数据集使用原则, 将每个图像数据集分为训练集和测试集。由于本文的实验是在有监督模型的情况下进行的, 因此训练集和测试集的图像都属于同一个大规模公开数据集中的身份信息。在 CHUK03 数据集中, 实验选择 1367 个身份进行训练, 剩下的 100 个身份进行测试。在测试阶段, 随机选择一张图像作为查询图像, 除去还在查询列表里的另外一张作为训练集。评估过程使用的是带有人工注释的图像。通过该方法可以有效避免重复训练和测试。因此, CHUK03 数据集是三个数据集中识别难度最大的数据集。

在对 Resnet-50 网络模型训练的过程中, 由于原始图像数据集, 如 Market-1501 和 CHUK03 数据集中, 样本图像发生遮挡问题的数量不多, 因此如果采用原始图像数据集中

的训练样本对 Resnet-50 网络进行训练，会使得训练后的 Resnet-50 网络缺乏对遮挡问题的处理能力，无法很好地处理图像样本中出现的遮挡问题，网络模型的泛化能力较弱。而泛化能力是卷积神经网络的研究重点，当一个模型过于复杂或者训练样本相较于参数过多时，可能会发生过拟合，卷积神经网络可能对训练样本表现出良好的性能，但对新的样本数据表现出极差的性能。并且遮挡问题也是行人重识别中的核心问题之一，对行人重识别造成极大的影响。为了强化网络模型的泛化能力，提高网络模型的性能，并使网络模型能够很好地处理遮挡问题的出现，可以通过引入随机擦除增广图像预处理方法。在网络模型的训练过程中，随机擦除会在样本图像中随机选择一个矩形区域，并采用随机值来擦除样本数据矩形区域中的像素。在这个过程中生成不同遮挡程度的图像，降低过拟合的风险，强化网络模型的泛化能力，使得网络模型具备处理遮挡情况的能力。可以通过结合随机裁剪、随机水平翻转方法和随机擦除方法这些不同方法并进行结合来对图像训练样本进行处理。在实验过程中，设置需要删除的矩形区域大小占训练样本图像大小的比例区间为 $[0.04, 0.4]$ ，矩形区域最小纵横比为 0.3，随机擦除的概率 $P = 0.5$ ，在不使用其他训练技巧的情况下，在 CHUK03 数据集上的实验结果如图 4-5 所示。




图 4-5 随机擦除的概率对行人重识别的影响

Fig.4-5 Influence of probability of random erasure on recognition of ReID

为了提高网络模型的性能，强化网络模型的泛化能力，使得网络模型更具有鲁棒性，实验使用的不同的优化策略对模型进行优化。其中，基线模型在 Market1501 和 DukeMTMC-reID 上的 Rank-1 值分别达到了 89.7%和 79.2%。在结合随机擦除策略和三元组损失函数对基线网络进行优化后，网络模型在 Market1501 和 DukeMTMC-reID 上的

Rank-1 值分别达到了 91.8%和 82.1%。在使用姿态估计算法对模型进一步优化后,网络模型在 Market1501 和 DukeMTMC-reID 上的 Rank-1 值分别达到了 92.6%和 83.6%。最后,在加入重排序策略后,这些策略最终使得算法模型分别在 Market1501 和 DukeMTMC-reID 上获得 Rank 1 值为 93.5%和 87.7%, mAP 值为 88.7%和 77.3%。

表 4-2 不同优化策略的行人重识别结果

Tab. 4-2 results of different optimization strategies optimizations

优化策略	Market-1501		DukeMTMC-reID	
	Rank-1	mAP	Rank-1	mAP
基线网络	89.7	79.5	79.2	69.8
+三元组损失	90.9	81.2	80.8	70.5
+随机擦除	91.8	82.1	82.1	71.7
+姿态估计	92.6	84.8	83.6	72.9
+重排序	93.5	88.7	86.7	77.3

实验采用 Resnet-50 残差网络作为行人重识别模型的基准网络,在网络训练中,训练样本的图像大小被统一调整为 256×128 ,并通过随机擦除方法进行数据增强,随机擦除的概率 $P = 0.5$,并通过三元组损失函数进一步优化损失函数,使用姿态估计算法使网络模型更具有鲁棒性,最后通过重排序策略提高网络模型的性能。对于查询数据集中的每一副图像,采用相同的评价指标 Rank-N 和 mAP 值对网络模型的性能进行评价。

表 4-3 代表了本文模型在三个大规模行人重识别基准数据集 Market-1501, DukeMTMC-reID 和 CUHK03 上与其他主流方法性能对比的结果。由表 4-3 可以看出本文算法模型在三个行人重识别基准数据集上的精度较高,性能较好。与 IDE^[80]、PAN^[60]、SVDNet^[81]、DaRe^[82]、HA-CNN^[61]、PCB^[83]、PCB+RPP^[83]等主流模型相比,在 Market-1501 数据集上本文提出的算法模型在 Rank-1 的值为 92.6%, Rank-1 的值对比 PCB 模型提高了 2.2%, mAP 值为 84.8%, 对比 PCB 模型高了 12.5%。在 DukeMTMC-reID 数据集上本文所提出的算法模型在 Rank-1 的值为 83.6%, 对比 PCB 算法模型提高了 1.7%, mAP 值为 72.9%, 对比 PCB 模型高了 7.6%。而本文所提出的算法模型在识别难度最大的 CUHK03 数据集上与其他主流模型相比获得了更高的准确率,在 CHUK03-Detected 数据集上本文算法模型 Rank-1 的值为 68.4%, 对比 DaRe 模型提高了 5.1%, mAP 值为 65.1%, 对比 DaRe 模型高了 6.1%,而在 CHUK03-Labeled 数据集上本文算法模型 Rank-1 的值为 70.2%, 对比 DaRe 模型提高了 4.1%, mAP 值为 66.8%, 对比 DaRe 模型高了 5.2%。说明了本文所提出的算法是有效的。并且在使用重排序策略后本文所提出的算法精度又得到了进一步提高,并且在 CHUK03 数据集上的得到了大幅度提高,说明了重排序策略可以有效提高行人重识别的算法精度。

表 4-3 本文模型与其他模型的性能比较

Tab.4-3 Performance comparison of our model with state-of-the-arts model

其他模型比较	Market-1501		CUHK03-Labeled		CUHK03-Detected		DukeMTMC-reID	
	Rank-1	mAP	Rank-1	mAP	Rank-1	mAP	Rank-1	mAP
IDE	72.5	46.0	22.2	21.0	21.3	19.7	67.7	47.1
PAN	82.8	63.4	36.9	35.0	36.3	34.3	71.6	51.5
SVDNet	82.3	62.1	-	-	41.5	37.3	76.7	56.8
DaRe	89.0	76.0	66.1	61.6	63.3	59.0	80.2	64.5
HA-CNN	91.2	75.7	44.4	41.0	41.7	38.6	80.5	63.8
PCB	92.4	77.3	-	-	61.3	54.2	81.9	65.3
PCB+RPP	93.8	81.6	-	-	62.8	56.7	83.3	69.2
Proposed	92.6	84.8	70.2	66.8	68.4	65.1	83.6	72.9
Proposed+rerank	93.5	88.7	78.5	79.3	75.4	77.1	86.7	77.3

4.5 本章小结

本章从姿态估计模型出发，利用姿态估计可以提取人体局部语义信息的特点，提出了一种基于姿态的深度特征加权聚合模型。首先，使用 Resnet-50 卷积神经网络作为本方法的基线网络，通过随机擦除数据增强方法和三元组损失函数提高网络的性能，降低过拟合的同时，增强特征的鲁棒性。其次使用显著性模型去除复杂背景的干扰，这种方法在第三章中被证明是有效的。通过显著性模型输出的显著性图像，使用姿态估计器进行姿态估计，并得到一个全新的身体部位图像，进而得到局部语义特征。最后深度全局特征和局部语义特征进行融合，充分利用了图像的底层信息和高层语义信息，并通过重排序算法得到更高的排名。在 Market-1501, DukeMTMC-reID 和 CUHK03 三个大规模行人重识别基准数据集上的实验结果可以看出本章所提出的方法是有效的，可以显著提高行人重识别的精度。

<此页空白>

5 结论与展望

5.1 结论

目前,人脸识别技术在安防领域已经非常成熟了,但是在很多实际场景中,人脸识别的作用并不明显。因为在很多情况下,摄像头根本无法抓拍到行人清晰的正面照。而行人重识别技术作为人脸识别技术的补充,可以很好地解决实际场景中跨设备、跨场景的问题,所以行人重识别技术在计算机视觉领域的关注度非常高,具有重要的前景和实际意义,一直以来都是计算机视觉领域的重点研究方向。行人重识别是行人智能认知的其中一个研究方向,主要解决跨摄像头场景下行人的识别与检索。行人重识别技术能够根据所拍摄到的行人的外貌、步态和体态等信息达到识别行人的目的,也能够与行人检测技术和行人跟踪技术相结合,广泛应用于智能视频监控、智能安保等领域。同时,行人重识别技术与人脸识别技术相结合可以更好的提高人工智能的认知能力,使其可以应用于更多更丰富的场景中。

在计算机技术的不断发展下,计算机的算力不断提升,本文可以利用现阶段计算机强大的算力优化网络模型,提取出更具有鲁棒性的特征,提高行人重识别技术的识别精度。本文通过对网络模型的进一步研究从而更好地识别和检索行人。随着人脸识别技术在实际场景中遇到的一系列问题,行人重识别技术作为计算机视觉领域的重要课题也发挥着越来越大的作用。

本文针对行人重识别技术难以解决复杂背景、遮挡和姿态变化等不利因素,提出了基于显著性模型中位姿嵌入的多尺度特征融合行人重识别方法。不仅通过图像增强技术完成对基线网络的优化,同时提出了将全局特征和语义特征进行加权融合,得到更加鲁棒的多尺度特征对行人进行检索和识别,提高了行人重识别技术的算法准确度。本文主要研究工作如下:

(1) 提出了一种基于显著性模型的深度特征聚合方法,选择 **Reset-50** 网络作为实验的基线网络,并通过显著性模型提取显著性局部特征,并对深度卷积特征与显著性局部特征进行向量聚合,有效的提高了行人重识别精度。

(2) 提出了一种基于位姿嵌入的多尺度卷积特征融合方法,通过结合显著性模型和姿态估计模型提取到了更加具有判别性的局部语义特征,通过将优化后的深度特征与局部语义特征进行特征加权融合,提高了行人重识别算法的准确度。

(3) 提出了一种基于 **Resnet-50** 基线网络的优化方法,通过随机擦除图像预处理方法,对预训练图像进行随机擦除预处理,强化训练后网络模型的泛化能力;并结合 **softmax** 和 **triplet loss** 函数提高网络的识别准确率,在 **Market-1501**, **DukeMTMC-reID** 和 **CUHK03**

数据集上进行了大量的实验,通过实验分析表明本文提出的算法是有效的,有利于行人重识别技术进行行人的识别与检索。

5.2 展望

随着深度学习的崛起,行人重识别技术也随之突飞猛进,识别精度也不断提升,但是依旧无法应对现实场景中复杂的变化,距离行人重识别技术的实际应用尚有一段距离,其识别精度有待提高。与本文研究内容相结合,行人重识别技术研究还有以下几点值得深度探究:

(1) 行人重识别研究应当使用更加贴合场景的数据集,模拟真实的现实场景提出特征并进行优化。现阶段,行人重识别研究中所使用的数据集都是由人工采集并进行标注,图像中大多数情况只包含行人和少部分背景,并且拍摄得到的图像也较为理想,适合进行行人识别。而现实场景中拍摄的图像往往会有遮挡、低分辨率、位姿偏移和光照等问题出现。因此,建立更加贴合显示场景的数据集是很有必要的,可以根据现实场景捕获的图像进行研究,进一步优化网络得到更具有判别性的特征,使其能够适用于现实场景。

(2) 现阶段行人重识别研究大多聚焦于有监督学习,而有监督学习需要大量的图像样本进行训练,并且图像训练样本需要提前经过标注。而训练样本的采集和标注本就需要大量的人力、财力和物力的支撑,并且训练卷积神经网络的时间较长,对硬件的要求较高,训练结束后容易出现欠拟合和过拟合情况的发生,造成网络模型的性能表现较差。因此,不依赖训练样本,进行半监督甚至无监督学习的方式更加贴合实际使用场景,也是未来行人重识别技术发展的重要趋势。

致 谢

三年时间犹如白驹过隙，只在一瞬却又恰似万年，历历在目。研究生三年时光里，我已记不清有过多少个夜晚在凌晨三点时踏着路灯映射出的影子，踱步走向宿舍。七年前我背上行囊，踏上火车，来到这个距离家乡八百公里的古城——西安。在一个陌生的城市，尽管有时也会思念家乡，尽管有时也想过放下一切，但一颗追逐梦想的心却从未有过动摇。这是一段难熬的路程，这也是一段修炼的历程。弹指一挥间，在西理工求学，转眼已过七年。

在这里，首先我要感谢我的硕士研究生导师——郑元林副教授。感谢就读硕士三年以来郑老师对我的照顾，给予我机会让我加入这个温暖的大家庭。郑老师不仅教育我在学术方面应具备严谨的态度，并且郑老师自己也以身作则，他总是最早达到教研室，永远保持着高涨的热情和敏锐的思维，郑老师这种精神值得我一生去学习。其次，我要感谢我的指导教师廖开阳老师，是他带领我从科研的懵懂走向成熟，每当我遇到不懂的问题时，廖老师总是第一个帮我答疑解惑的人。在两位老师的指导和帮助下我才能顺利完成毕业论文的写作。在此谨向两位老师表示我最诚挚的谢意，祝老师们万事安好！

同时我也要感谢教研室一起努力的师兄师姐和师弟师妹们，有了他们的帮助让我度过了研究生三年最难忘的时光。感谢师兄师姐们帮助我快速进入科研状态，遇到不懂的问题悉心解答，毕业之后依旧保持对我学习和工作上的指导。感谢同级的两位好友和师弟师妹们，让我们一起学习的日子变得更加的丰富多彩，在科研上互相交流，讨论学术，为教研室营造了良好的科研氛围。也希望教研室的同门前程似锦！

我还要感谢张欣同学。从本科到硕士我们在一起走过了七年时光，这七年时光是我人生中最幸福最难忘的时光。你是我追逐梦想的动力，是我对未来美好的憧憬。与你相识，是我人生中最大的幸运。余生有你，三生有幸。

最后，我要感谢我的父母、姑姑和爷爷，是你们为我筑起了最坚固的后盾，也是你们扛起了家庭的重担，让我可以没有后顾之忧的完成我的求学之路。往后的日子里我会尽我所能回报你们，你们的健康是我最大的心愿！

一年好景君须记，最是橙黄橘绿时。寒光中的乍现带来不仅仅是惊艳，更是一颗不断跳动着炙热的心。我拼命的奔跑，只为追上从前的自己。

愿我归来仍是少年。

<此页空白>

参考文献

- [1] Gong S, Xiang T: Person re-identification, Visual Analysis of Behaviour: Springer, 2011: 301-313.
- [2] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [3] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C]. 2010 IEEE computer society conference on computer vision and pattern recognition, 2010: 2360-2367.
- [4] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]. 2006 IEEE computer society conference on computer vision and pattern recognition (CVPR'06), 2006: 1528-1535.
- [5] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[C]. European conference on computer vision, 2008: 262-275.
- [6] Prosser B J, Zheng W-S, Gong S, et al. Person re-identification by support vector ranking[C]. BMVC, 2010: 6.
- [7] Zheng W-S, Gong S, Xiang T. Reidentification by relative distance comparison[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35 (3): 653-668.
- [8] Mignon A, Jurie F. Pcca: A new approach for distance learning from sparse pairwise constraints[C]. 2012 IEEE conference on computer vision and pattern recognition, 2012: 2666-2672.
- [9] Zheng L, Bie Z, Sun Y, et al. Mars: A video benchmark for large-scale person re-identification[C]. European Conference on Computer Vision, 2016: 868-884.
- [10] Zheng W-S, Li X, Xiang T, et al. Partial person re-identification[C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 4678-4686.
- [11] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2013: 3586-3593.
- [12] Das A, Chakraborty A, Roy-Chowdhury A K. Consistent re-identification in a camera network[C]. European conference on computer vision, 2014: 330-345.
- [13] Li Z, Chang S, Liang F, et al. Learning locally-adaptive decision functions for person verification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2013: 3610-3617.
- [14] Zhou X, Cui N, Li Z, et al. Hierarchical gaussianization for image classification[C]. 2009

IEEE 12th International Conference on Computer Vision,2009: 1971-1977.

[15] Pedagadi S, Orwell J, Velastin S, et al. Local fisher discriminant analysis for pedestrian re-identification[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2013: 3318-3325.

[16] Liu X, Song M, Tao D, et al. Semi-supervised coupled dictionary learning for person re-identification[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2014: 3550-3557.

[17] Yang Y, Yang J, Yan J, et al. Salient color names for person re-identification[C].European conference on computer vision,2014: 536-551.

[18] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 2197-2206.

[19] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C].roceedings of the IEEE international conference on computer vision,2015: 1116-1124.

[20] Van De Weijer J, Schmid C, Verbeek J, et al.Learning color names for real-world applications[J].IEEE Transactions on Image Processing,2009, 18 (7): 1512-1523.

[21] Matsukawa T, Okabe T, Suzuki E, et al. Hierarchical gaussian descriptor for person re-identification[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2016: 1363-1372.

[22] Layne R, Hospedales T M, Gong S, et al. Person re-identification by attributes[C]. mvc,2012: 8.

[23] Liu X, Song M, Zhao Q, et al.Attribute-restricted latent topic model for person re-identification[J].attern recognition,2012, 45 (12): 4204-4213.

[24] Liu C, Gong S, Loy C C, et al. Person re-identification: What features are important?[C].uropean Conference on Computer Vision,2012: 391-401.

[25] Su C, Yang F, Zhang S, et al. Multi-task learning with low rank attribute embedding for person re-identification[C].Proceedings of the IEEE international conference on computer vision,2015: 3739-3747.

[26] Shi Z, Hospedales T M, Xiang T. Transferring a semantic representation for person re-identification and search[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2015: 4184-4193.

[27] Li D, Zhang Z, Chen X, et al.A richly annotated dataset for pedestrian attribute recognition[J].rXiv preprint arXiv:1603.07054,2016.

[28] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C].Proceedings of the IEEE conference on computer vision and

pattern recognition,2014: 580-587.

[29] Radenović F, Tolias G, Chum O. CNN image retrieval learns from BoW: Unsupervised fine-tuning with hard examples[C].European conference on computer vision,2016: 3-20.

[30] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 815-823.

[31] Yi D, Lei Z, Liao S, et al. Deep metric learning for person re-identification[C].2014 22nd International Conference on Pattern Recognition,2014: 34-39.

[32] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2014: 152-159.

[33] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 3908-3916.

[34] Wu L, Shen C, Hengel A V D. Personnet: Person re-identification with deep convolutional neural networks[J].arXiv preprint arXiv:1601.07255,2016.

[35] Varior R R, Shuai B, Lu J, et al. A siamese long short-term memory architecture for human re-identification[C].European conference on computer vision,2016: 135-153.

[36] Varior R R, Haloi M, Wang G. Gated siamese convolutional neural network architecture for human re-identification[C].European conference on computer vision,2016: 791-808.

[37] Liu H, Feng J, Qi M, et al. End-to-end comparative attention networks for person re-identification[J].IEEE Transactions on Image Processing,2017, 26 (7): 3492-3506.

[38] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2016: 1335-1344.

[39] Su C, Zhang S, Xing J, et al. Deep attributes driven multi-camera person re-identification[C].European conference on computer vision,2016: 475-491.

[40] Xiao T, Li H, Ouyang W, et al. Learning deep feature representations with domain guided dropout for person re-identification[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2016: 1249-1258.

[41] Wu L, Shen C, Van Den Hengel A. Deep linear discriminant analysis on fisher networks: A hybrid architecture for person re-identification[J].Pattern Recognition,2017, 65: 238-250.

[42] Perronnin F, Sánchez J, Mensink T. Improving the fisher kernel for large-scale image classification[C].European conference on computer vision,2010: 143-156.

[43] Wu S, Chen Y-C, Li X, et al. An enhanced deep feature representation for person re-

- identification[C].2016 IEEE winter conference on applications of computer vision (WACV),2016: 1-8.
- [44] Lecun Y, Bottou L, Bengio Y, et al.Gradient-based learning applied to document recognition[J].Proceedings of the IEEE,1998, 86 (11): 2278-2324.
- [45] Lecun Y, Boser B E, Denker J S, et al. Handwritten digit recognition with a back-propagation network[C].Advances in neural information processing systems,1990: 396-404.
- [46] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C].Icml,2010.
- [47] Hinton G E, Srivastava N, Krizhevsky A, et al.Improving neural networks by preventing co-adaptation of feature detectors[J].arXiv preprint arXiv:1207.0580,2012.
- [48] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C].European conference on computer vision,2014: 818-833.
- [49] Simonyan K, Zisserman A.Very deep convolutional networks for large-scale image recognition[J].arXiv preprint arXiv:1409.1556,2014.
- [50] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 1-9.
- [51] Wang T, Wu D J, Coates A, et al. End-to-end text recognition with convolutional neural networks[C].Proceedings of the 21st international conference on pattern recognition (ICPR2012),2012: 3304-3308.
- [52] Zheng L, Shen L, Tian L, et al. Scalable Person Re-identification: A Benchmark[C].international conference on computer vision,2015: 1116-1124.
- [53] Li W, Zhao R, Xiao T, et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C].computer vision and pattern recognition,2014: 152-159.
- [54] Ristani E, Solera F, Zou R S, et al. Performance Measures and a Data Set for Multi-target, Multi-camera Tracking[C].european conference on computer vision,2016: 17-35.
- [55] 邓轩, 廖开阳, 郑元林, 等.基于深度多视图特征距离学习的行人重识别[J].计算机应用,2019, 39 (8): 2223-2229.
- [56] Choi S, Lee S, Kim Y, et al. Hi-CMD: Hierarchical Cross-Modality Disentanglement for Visible-Infrared Person Re-Identification[C].2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR),2020.
- [57] 刘紫燕, 朱明成, 袁磊, 等.基于非局部关注和多重特征融合的视频行人重识别[J].计算机应用,2020: 0-0.
- [58] Wang G, Yang S, Liu H, et al. High-Order Information Matters: Learning Relation and Topology for Occluded Person Re-Identification[C],2020.
- [59] 廖开阳, 雷浩, 郑元林, 等. 一种基于显著性模型下多尺度特征的行人重识别方法:

CN111709317A[P].2020-09-25.

[60] Zheng Z, Zheng L, Yang Y J a C V, et al. Pedestrian Alignment Network for Large-scale Person Re-identification[J],2017.

[61] Li W, Zhu X, Gong S. Harmonious Attention Network for Person Re-identification[C].2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition,2018: 2285-2294.

[62] Cui X, Goel V, Kingsbury B. Data augmentation for deep convolutional neural network acoustic modeling[C].2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP),2015: 4545-4549.

[63] Rizk H, Shokry A, Youssef M. Effectiveness of data augmentation in cellular-based localization using deep learning[C].2019 IEEE Wireless Communications and Networking Conference (WCNC),2019: 1-6.

[64] Zhong Z, Zheng L, Kang G, et al. Random Erasing Data Augmentation[J],2017.

[65] 廖开阳, 邓轩, 郑元林, 等. 一种基于多尺度卷积特征融合的行人重识别方法: CN111709311A[P].2020-09-25.

[66] Vinyals O, Toshev A, Bengio S, et al. Show and tell: A neural image caption generator[C]. Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 3156-3164.

[67] Brasó G, Leal-Taixé L. Learning a Neural Solver for Multiple Object Tracking[J],2019.

[68] Ren Z, Gao S, Chia L-T, et al. Region-based saliency detection and its application in object recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology,2013, 24 (5): 769-779.

[69] Borji A, Frntrop S, Sihite D N, et al. Adaptive object tracking by learning background context[C].2012 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops,2012: 23-30.

[70] Wang Q, Zhang L, Bertinetto L, et al. Fast Online Object Tracking and Segmentation: A Unifying Approach[C].2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR),2020.

[71] Liao K, Lei H, Zheng Y, et al. IR feature embedded bof indexing method for near-duplicate video retrieval[J]. IEEE Transactions on Circuits and Systems for Video Technology,2018, 29 (12): 3743-3753.

[72] Liu F, Gao C, Sun Y, et al. Infrared and Visible Cross-Modal Image Retrieval through Shared Features[J]. IEEE Transactions on Circuits and Systems for Video Technology,2021.

[73] Donoser M, Urschler M, Hirzer M, et al. Saliency driven total variation segmentation[C]. 2009 IEEE 12th International Conference on Computer Vision,2009: 817-824.

[74] Wang L, Li D, Zhu Y, et al. Dual Super-Resolution Learning for Semantic Segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern

Recognition,2020: 3774-3783.

[75] Zhang P, Wang D, Lu H, et al. Amulet: Aggregating multi-level convolutional features for salient object detection[C].Proceedings of the IEEE International Conference on Computer Vision,2017: 202-211.

[76] Su C, Li J, Zhang S, et al. Pose-driven deep convolutional model for person re-identification[C].Proceedings of the IEEE international conference on computer vision,2017: 3960-3969.

[77] Zheng L, Huang Y, Lu H, et al.Pose-invariant embedding for deep person re-identification[J].IEEE Transactions on Image Processing,2019, 28 (9): 4500-4509.

[78] Wei S-E, Ramakrishna V, Kanade T, et al. Convolutional pose machines[C].Proceedings of the IEEE conference on Computer Vision and Pattern Recognition,2016: 4724-4732.

[79] Zhong Z, Zheng L, Cao D, et al. Re-ranking person re-identification with k-reciprocal encoding[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2017: 1318-1327.

[80] Zheng L, Zhang H, Sun S, et al. Person Re-identification in the Wild[C].computer vision and pattern recognition,2017: 3346-3355.

[81] Sun Y, Zheng L, Deng W, et al. SVDNet for Pedestrian Retrieval[C].international conference on computer vision,2017: 3820-3828.

[82] Wang Y, Wang L, You Y, et al. Resource Aware Person Re-identification Across Multiple Resolutions[C].2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition,2018: 8042-8051.

[83] Sun Y, Zheng L, Yang Y, et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and A Strong Convolutional Baseline)[C].european conference on computer vision,2018: 501-518.

攻读学位期间主要研究成果

期刊论文:

- [1] Liao Kaiyang, **Lei Hao**, Zheng Yuanlin, et al. IR feature embedded bof indexing method for near-duplicate video retrieval[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(12): 3743-3753.
- [2] Deng Xuan, Liao Kaiyang, Zheng Yuanlin, Lin Guangfeng, **Lei Hao**. A deep multi-feature distance metric learning method for pedestrian re-identification[J]. Multimedia Tools and Applications:1-19.
- [3] 邓轩, 廖开阳, 郑元林, 袁晖, **雷浩**, 陈兵. 基于深度多视图特征距离学习的行人重识别[J]. 计算机应用, 2019, 039(008):2223-2229.
- [4] 楼豪杰, 郑元林, 廖开阳, **雷浩**, 李佳.基于孪生 Siamese-YOLOv4 的印刷品缺陷目标检测[J].计算机应用.

申请专利:

- [1] 廖开阳, **雷浩**, 郑元林,等.一种基于图像识别的二维随机码图像识别与提取的方法.公开号: 110348263.
- [2] 廖开阳, **雷浩**, 郑元林,等.一种基于显著性模型下多尺度特征的行人重识别方法.公开号: 111709317.
- [3] 廖开阳, 邓轩, 郑元林, 章明珠, **雷浩**, 刘林山.深度多视图特征距离学习的行人重识别方法.公开号: 109902590A.

申请软件著作权:

- [1] 廖开阳, **雷浩**, 郑元林 等.基于二维随机码的图像识别与提取软件。登记号: 2019SR0849225.
- [2] 廖开阳, 邓轩, 郑元林, **雷浩**.基于深度多视图特征距离学习的行人重识别软件. 登记号: 2019SR0700744.
- [3] 廖开阳, 邓轩, 郑元林, 曹从军, 章明珠, **雷浩**.基于二维随机码的旋转校正软件。登记号: 2019SR0849232.
- [4] 郑元林, 魏双双, 廖开阳, 赵金娟, 王晓彤, **雷浩**.基于频域和空域特征相结合的屏幕内容质量评估软件。登记号: 2019SR0849225.

获奖情况:

- [1] 2019.09 获西安理工大学研究生二等学业奖学金
- [2] 2020.09 获西安理工大学研究生一等学业奖学金
- [3] 2020.01 获西安理工大学“体育积极分子”荣誉称号
- [4] 2020.09 获西安理工大学“互联网+创新创业大赛”校级一等奖
- [5] 2021.01 获西安理工大学“三好学生”荣誉称号
- [6] 2021.04 获西安理工大学“优秀毕业生”