



中国科学院大学

University of Chinese Academy of Sciences

硕士学位论文

监控视频中行人检测与重识别技术研究

作者姓名: 金子丰

指导教师: 卞春江 研究员

中国科学院国家空间科学中心

学位类别: 工程硕士

学科专业: 计算机技术

培养单位: 中国科学院国家空间科学中心

2021 年 6 月



中国科学院大学
University of Chinese Academy of Sciences

硕士学位论文

监控视频中行人检测与重识别技术研究

作者姓名: 金子丰

指导教师: 卞春江 研究员

中国科学院国家空间科学中心

学位类别: 工程硕士

学科专业: 计算机技术

培养单位: 中国科学院国家空间科学中心

2021 年 6 月

Research on Pedestrian Detection and Re-identification
technology in surveillance video

A thesis submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Master of Science in Engineering
in Computer Technology

By

JIN Zifeng

Supervisor: BIAN Chunjiang

National Space Science Center, Chinese Academy of Sciences

June 2021

摘要

随着人们公共安全意识的提升,视频监控设备得到迅速普及,在交通、车站、商场和校园等公共区域的安防工作中发挥着重要作用。行人是安防领域最重要的目标之一,与之相关的行人检测与行人重识别一直是智能监控领域的热点问题,受到了广泛的关注和研究。为了实现监控场景下行人的自动检测和识别,本文分别就监控场景下的行人检测与行人重识别展开研究,主要工作如下:

(1) 为了更好地完成监控视频中行人的检出工作,本文设计了一个轻量型的行人检测模型,将 MobileNetV2 作为行人图像的特征提取网络,相比一般目标检测模型,MobileNetV2 更加轻量化,且保持了较好的目标检测精度;为了使模型更好适应行人尺度变化,将 MobileNetV2 不同层次的特征进行跨深度融合,对融合后的特征进行行人多级检测,增强模型对不同大小和比例行人的检测能力。同时,为了保持模型的轻量化,多级检测分支为基于深度可分离卷积设计的全卷积结构;最后,将模型在行人数据集上进行训练,经测试,模型的平均检测精度达到了 88.53%,对单张图像的平均推理时间为 12.76ms。通过在监控场景对模型的实际检测效果进行测试,结果表明,模型能够完成监控视频中行人的快速、准确检出。

(2) 针对一般的行人重识别方法对行人图像提取一个简单的全局特征,在复杂的行人重识别任务中存在特征表示能力不足的问题,本文提出了一种新的多尺度特征学习算法,结合全局与局部特征学习得到更好的行人表示,提升复杂场景下模型的识别能力;其次,考虑到行人在图像中不对齐时会限制模型性能,对骨干网络不同深度输出的行人特征图,通过特征对齐模块对其执行空间变换,实现行人特征在空间上的矫正和对齐,进一步增强模型的泛化性能;最后,在公开的大型行人重识别数据集上,本文提出的方法取得了优秀的表现,优于当前大多数行人重识别方法。

(3) 将本文设计的轻量级行人检测模型与行人重识别模型进行结合,实现面向应用的行人重识别技术,系统能够对输入的监控视频进行自动、快速的分析,从中寻找给定的目标行人。最后,从多个监控场景采集和制作了新的测试集对系

统进行测试，结果表明，系统能够完成监控视频中指定行人目标的快速检索。

关键词：行人检测，行人重识别，特征融合，行人特征对齐，多尺度特征学习

Abstract

With the improvement of people's awareness of public security, video surveillance equipment has been rapidly popularized, which plays an important role in the security work of public areas such as traffic, stations, shopping malls and campus. Pedestrian are one of the most important object in the security field, and related pedestrian detection and person re-identification are always the popular issues in intelligent surveillance, which have received wide attention and research. In order to realize the automatic detection and recognition of pedestrians in the surveillance scenario, this thesis separately conducts research on pedestrian detection and person re-identification in the surveillance scenario. The main works are as follows:

(1) In order to complete the pedestrian detection in surveillance videos better, this thesis designs a lightweight pedestrian detection model, using MobileNetV2 as the feature extraction network for pedestrian images. Compared with general object detection models, MobileNetV2 is more lightweight and maintains good object detection accuracy. In order to make the model adapt to the change of pedestrian scale well, the features of different levels of MobileNetV2 are integrated across depth, and the concatenated features are used for multi-level pedestrian detection to enhance the detection ability of the model for different sizes and proportions of pedestrians. Meanwhile, for the purpose of maintaining the lightweight of the model, the multi-level detection branches are the fully convolutional structure, which designed by Depthwise Separable Convolutions. Finally , the 88.53% average detection accuracy with 12.76ms inference time of a single image was obtained by training and testing the model on the pedestrian dataset. By testing the detection effect of the model in the real monitoring scene, the results show that the model can complete the fast and accurate detection of pedestrians in the surveillance videos.

(2) The general person re-identification methods extract a simple global feature from the pedestrian image, which leads to the lack of feature representation ability in

the complex person re-identification task. Firstly, This thesis proposes a new multi-scale feature learning algorithm, which combines global and local feature learning to obtain a better representation of person to improve the recognition ability of the model in complex scenarios. Secondly, considering that the misalignment of pedestrians will limit the performance of the model, in order to realize the spatial correction and alignment of human feature, the feature alignment module is used to perform spatial transformation on the feature maps from different depths of the backbone network, and further enhances the generalization performance of the model. Finally, the proposed method achieved excellent performance on the public large-scale person re-identification datasets, which is better than most of the current person re-identification methods.

(3) The lightweight pedestrian detection model was combined with the person re-identification model to realize the application-oriented person re-identification technology. The system can automatically and quickly analyze the surveillance videos to search the given target pedestrian. Finally, the system is tested by using a new test sets collected and made from several monitoring scenes., the results show that the system can complete the fast search of specific target pedestrians in the surveillance videos.

Key Words: Pedestrian detection, Person re-identification, Feature fusion, Pedestrian feature alignment, Multi-scale feature learning.

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	3
1.2.1 行人检测.....	3
1.2.2 行人重识别.....	10
1.3 本文研究内容.....	13
1.4 论文章节安排.....	14
第 2 章 行人检测与行人重识别相关工作	15
2.1 行人检测相关工作.....	15
2.1.1 特征金字塔网络.....	15
2.1.2 YOLOv3 目标检测模型.....	16
2.2 行人重识别相关工作.....	19
2.2.1 PCB 网络	19
2.2.2 空间变换网络.....	21
2.3 本章小结.....	22
第 3 章 基于特征融合的行人检测方法设计与实现	23
3.1 行人检测方法总体设计.....	23
3.2 深度可分离卷积.....	23
3.3 MobileNetV2 目标检测模型	26
3.4 基于特征融合的轻量级行人检测模型.....	28
3.5 实验.....	30
3.5.1 数据集与评价指标.....	30
3.5.2 实验环境与实验设置.....	32
3.5.3 实验结果.....	33
3.5.4 分析与讨论.....	35
3.6 本章小结.....	37

第 4 章 基于多尺度特征学习与特征空间对齐的行人重识别	38
4.1 行人重识别方法总体设计	38
4.2 多尺度特征学习算法	40
4.3 特征对齐模块	42
4.4 损失函数	45
4.5 实验	46
4.5.1 数据集与评价指标	46
4.5.2 实验环境与实验设置	47
4.5.3 实验结果	47
4.5.4 分析与讨论	50
4.6 本章小结	51
第 5 章 结合行人检测的行人重识别技术实现	53
5.1 实现流程	53
5.2 采集测试数据	54
5.3 系统评估	55
5.3.1 评估环境	55
5.3.2 评估指标	55
5.4 测试结果	56
5.5 本章小结	58
第 6 章 总结与展望	59
6.1 总结	59
6.2 展望	60
参考文献	61
致 谢	68
作者简历及攻读学位期间发表的学术论文与研究成果	69

图目录

图 1.1	行人重识别流程	2
图 1.2	Haar 特征模板	4
图 1.3	RCNN 网络结构	6
图 1.4	SPPNet 网络结构	7
图 1.5	Fast RCNN 网络结构	8
图 1.6	YOLO 网络结构	9
图 1.7	SSD 网络结构	9
图 2.1	图像与特征金字塔	15
图 2.2	Darknet53 特征提取网络	16
图 2.3	YOLOv3 网络结构	17
图 2.4	YOLOv3 坐标预测	18
图 2.5	行人空间不对齐示例	19
图 2.6	PCB 网络结构	20
图 2.7	STN 的空间变换效果	21
图 2.8	PAN 网络结构	22
图 3.1	标准卷积	24
图 3.2	深度可分离卷积	25
图 3.3	不同卷积 block 的结构对比	27
图 3.4	轻量级行人检测模型结构	29
图 3.5	学习率变化曲线	32
图 3.6	模型训练收敛曲线	33
图 3.7	不同输入分辨率下模型识别精度	34
图 3.8	在 VOC2007 测试集上行人检测效果	35
图 3.9	实际场景行人检测效果	36
图 3.10	困难场景模型的检测效果	37
图 4.1	行人重识别方法总体设计	39

图 4.2	网络的多分支结构	40
图 4.3	特征对齐模块	42
图 4.4	给定查询图像的前十位检索结果	49
图 4.5	变换前后特征的可视化示例	51
图 5.1	行人重识别系统处理流程	53
图 5.2	监控场景图像示例	54
图 5.3	不同角度和分辨率下行人重识别结果	56
图 5.4	跨场景行人重识别结果	57

表目录

表 3.1	MobileNetV2 网络结构	28
表 3.2	行人检测数据集统计	31
表 3.3	不同模型的行人检测性能对比	34
表 4.1	参数估计网络的结构设计	44
表 4.2	Market1501 数据集实验结果对比 (%)	48
表 4.3	DukeMTMC-reID 数据集实验结果对比 (%)	49
表 4.4	Market1501 上不同分支组合的实验结果 (%)	50
表 5.1	系统在不同视频中的识别结果比较	58

第1章 绪论

1.1 研究背景和意义

近年来,公共安全问题愈发受到重视。为了保障社会的和平稳定与公民的生命财产安全,全国各地开展以“平安城市”、“智慧安防”为目标的视频监控系统的大规模建设,逐渐完善监控设备在大、中、小城市的布局与应用。监控视频能直观、准确地还原现场真实场景,在刑侦、交通、教育、商业等领域发挥着重要作用。另一方面,视频监控设备每天产生大量的监控数据,许多有价值信息没有得到及时利用而被丢弃,此外,传统人工监控模式效率低、代价高,无可避免地会出现误检和漏检等问题,限制视频监控系统更好地发挥作用。行人作为监控场景最重要的目标之一,通常是各类异常事件的主体,自动从海量监控数据中准确、快速地定位到目标人物出现的视频区间,是当前智能监控系统亟需具备的能力。

在单个摄像头下,利用跟踪算法可以对某个目标进行连续跟踪,而当一个目标受到遮挡或短暂消失后又出现在另外一个摄像头视野内时,跨时空的行人身份关联需要依靠行人重识别。行人重识别技术的实现需要解决三个问题:首先,需要利用行人检测算法对监控图像中出现的行人进行定位;其次,对定位到的行人提取判别力强的特征进行表示;最后,使用适当的相似性度量方法进行行人特征间的比对。行人检测是许多计算机视觉技术的基础工作,如行人轨迹预测、行为识别、自动驾驶等,负责将图像中出现的行人进行检出。在实际监控场景下,由于存在遮挡、光照与外观变化、分辨率和姿态差异等各种复杂因素的影响,使行人检测与行人重识别任务富有挑战性,得到了广泛的关注和研究。早期的机器学习方法主要关注于设计更加复杂和表达能力更强的手工特征去表示行人,取得了阶段性的研究成果,为行人检测与行人重识别的发展打下了良好的基础。后来,深度学习的出现将计算机视觉领域的研究工作推向了高潮,在短短几年间取得了重大进展,基于深度学习的多项计算机视觉技术已经被应用到人类社会的各个领域,如人脸识别、人机交互、图像理解等。同样用于身份认证的人脸识别技术,需要人主动配合摄像头采集正面、清晰的人脸图像作为输入,方便进行后续的比

对工作。在监控场景中，由于标准的清晰人脸图像通常无法获取，限制了人脸识别技术在智能监控系统中的应用。实际应用场景下，行人检测和行人身份识别都需要系统自动完成，这使行人重识别技术的落地更加困难。

当前行人检测和行人重识别通常被当作两个独立的任务，针对两个任务陆续出现了一些大型开放数据集。一个标准的数据集通常由训练集和测试集两部分组成，对于行人检测任务，数据集中包含自然场景下拍摄的图像以及图像中行人位置的标注信息，其中，训练集用来训练行人检测模型，测试集用来对模型的检测效果进行测试；对于行人重识别任务，数据集通常由在多相机监控下通过手工裁剪或自动检测器检测得到的行人包围图像，以及对图像标注的行人身份信息组成，模型在训练集得到训练后，在测试集上检验模型能否从图像库中准确找出目标行人的其它图像。在实际监控场景下，行人重识别系统的输入为原始监控视频，而不是人为制作的行人图像框，如图 1.1 所示，一个完整的行人重识别系统需要结合行人检测与行人重识别两个模块，行人检测模块完成行人在每一帧监控图像中的定位，然后将定位到的候选行人图像输入行人重识别模块，与目标行人图像进行匹配，最终获取目标行人在监控视频中出现的信息。




图 1.1 行人重识别流程

Fig 1.1 Process of person re-identification

与学术数据集单一场景不同，实际监控场景下行人重识别系统面临更为严峻的挑战，由于行人重识别部分需要行人检测结果作为输入，所以行人检测模型的检测效果会直接影响行人重识别模型的识别结果，准确的行人检测是识别行人身份的关键前提。虽然更复杂的模型通常具有更好的检测或识别能力，但同时需要

更多的计算资源和时间消耗,一个庞大且高延迟的行人重识别系统无法在监控场景下正常工作,从应用的角度出发,行人重识别系统不仅要保证准确性,还要尽可能地提高实时性和降低硬件要求,因此,设计一个符合应用需求的行人重识别系统是一项富有意义和挑战性的工作。

1.2 国内外研究现状

行人检测与行人重识别的重点在于行人判别性特征的提取,传统方法主要利用图像的颜色、纹理和其它视觉属性构建外观特征,再通过机器学习算法训练分类器对特征进行分类,虽然在一些小规模数据集上能够取得一定的效果,但这种低级外观特征表示能力有限,对数据质量要求较高,在复杂的现实场景下泛化能力不足,因此只能在受限的简单场景下使用。上世纪 90 年代, Hinton 等人^[1]提出了误差反向传播算法,使神经网络能够得到规范的训练和更新,但由于计算能力有限和缺乏大规模的训练数据,神经网络比较容易出现过拟合问题,与传统机器学习方法相比没有明显优势,在当时未得到广泛的关注。随着大规模带标注数据集的出现与高性能并行计算技术的发展,2012 年, Alex Krizhensky 等人提出的 CNN 模型 AlexNet^[2], 在 ImageNet^[3]图像分类挑战赛上取得了优秀的成绩,与当时基于传统机器学习的方法拉开了巨大差距,充分表现了神经网络的强大学习能力。后来,更多性能强大的神经网络模型如 GoogLeNet^[4]、VGG^[5]和 ResNet^[6]等陆续出现,深度学习开始成为计算机视觉研究工作的流行趋势。在此背景下,行人检测与行人重识别也开始从传统机器学习方法向深度学习过渡。本小节将以深度学习的流行为分割点,对行人检测和行人重识别领域研究进程中的一些重要工作做简要介绍。

1.2.1 行人检测

(1) 基于传统手工特征的方法

传统行人检测方法主要有候选区域选择、特征提取和分类三个步骤。在候选区域的选择上,由于目标可能出现在图像的任何位置,并且具有不同的大小和比例,一个常用的方法是使用多个不同尺度的滑动窗口对整个图像进行扫描,这种类似穷举的策略虽然能够尽可能多地找出目标所在的区域,但缺点是对大量的候

选区域的特征计算需要消耗大量时间和计算资源；相反，如果仅应用几个固定的滑动窗口模板对图像进行滑动搜索，检测效果会因此受到影响。

在目标检测工作中，如何提取判别性和鲁棒性强的特征是检测任务中的关键环节。Viola P 等人^[7]采用滑动窗口的方式，提取多尺度 Haar 特征用于人脸检测。如图 1.2 所示，作者使用几种不同的特征提取模板，分别用来提取边缘特征、线性特征、中心特征和对角线特征，每个特征模板由白色和黑色两种矩形构成，所提取的特征被定义为白色矩形内的像素和减去黑色矩形内的像素和。Haar 特征能够很好地反映图像不同方向上物体的轮廓和灰度变化。为了加快特征计算，作者提出了一种积分图算法，在滑动计算 Haar 特征时，事先保存图像上每个点与左上角组成矩阵的像素和，对于任意一个矩形区域，通过一系列加减运算就能快速得到该区域的 Haar 特征值，Viola P 首次实现了无约束场景下的人脸实时检测。




图 1.2 Haar 特征模板

Fig 1.2 Haar feature templates

图像中不同类型目标的纹理和边缘特征具有明显差别，Ojala 等人^[8]提出局部二值模式（Local Binary Patterns, LBP）用于提取图像纹理特征，在以某个像素点为中心的邻域内，将中心点的像素值作为阈值，与周围相邻点的像素值进行比较，当相邻点像素值大于中心点时，该点被标记为 1，反之则被标记为 0，将比较结果按照某一方向进行排列，作为该中心点的 LBP 值，用于反映该中心点周围的纹理信息。LBP 的计算方式使得其对光照变化更加鲁棒，但由于 LBP 只覆盖一个固定尺寸的小区域，无法很好地捕捉多种尺度下的纹理特征。Ojala 在 LBP 的基础上进行改进，提出了圆形 LBP、旋转不变 LBP 与 LBP 等价模式，提升

LBP 特征对尺度和旋转的不变性, 并对原始高维稀疏的 LBP 进行降维, 降低高频噪声的影响, 提升计算速度。后来, Mu Y 等人^[9]提出了一种改进的 LBP 特征描述子, 采用 S-LBP (Semantic Local Binary Pattern, S-LBP) 与 F-LBP (Fourier Local Binary Pattern, F-LBP) 分别对图像提取特征并融合进行行人检测。

Dalal N 等人^[10]提出梯度方向直方图 (histogram of oriented gradient, HOG) 特征用于行人检测, HOG 在图像局部范围内求取梯度, 通过梯度的大小和方向表示该区域的外观和形状特征。在局部区域处理上, 使用在更大图像范围内归一化后的直方图, 这在一定程度上减小光照变化和阴影带来的影响, 对图像几何和光学上的形变具有良好的鲁棒性。为了检测不同大小的目标, HOG 在保持检测窗口大小不变情况下, 对输入图像进行多次缩放, 但较高的特征维度和大量的直方图统计运算使特征计算速度慢, 影响检测实时性, 且 HOG 本身无法很好地应对尺度和旋转变换, 在遮挡情况下检测效果不理想, 基于梯度的性质使其对噪点的存在比较敏感。

对图像提取单一的特征在计算速度方面具有优势, 而融合多种特征能更充分地利用图像中的信息构建更好的特征表示。Wang X 等人^[11]将 HOG 特征与 LBP 特征相融合, 提升行人检测的准确度, 改善了遮挡情况下行人检测的效果。Dollár P 等人^[12]使用融合的多通道特征进行行人检测, 结合局部求和、梯度方向直方图和 Haar 特征作为行人描述, 并且借助积分图算法实现特征的快速计算, 实验证明多种通道特征比单一特征具有更好的检测效果。Felzenszwalb P 等人^[13]提出可变形部件检测 (Deformable Part Model, DPM) 模型, 采用滑动窗口检测方式, 通过构建尺度金字塔在各个尺度进行搜索。为更好地适应物体的形变, DPM 将行人划分为头部、躯干、手、脚、腿等区域, 对每个部分使用独立的部件模型进行分块检测, 融合各部分的总体得分判断检测区域是否为行人, 能很好地应对目标形变和遮挡场景。

(2) 基于深度学习的方法

由于监控图像中的行人是复杂多变的, 依靠手工提取的低级特征很难鲁棒地应对行人的多样性, 而且滑动窗口策略生成候选框是非常冗余和低效的。卷积神经网络的出现很好地解决了这些问题, 与传统的方法相比, CNN 具有更深的网

络结构，更复杂的非线性映射，因此能够学习到更有效的目标特征表示，此外，特征提取和分类端到端地由 CNN 自动完成，无需繁琐的手工设计特征过程。

2014 年，Girshick R 等人^[14]提出的 RCNN 首次将 CNN 用于目标检测领域，其网络结构如图 1.3 所示，与传统目标检测算法使用滑动窗法遍历所有可能的区域判断是否存在目标的方法不同，RCNN 通过启发式搜索(selective search)^[15]的方法选取一系列可能存在物体的候选区域，对待检测目标进行初步的定位，之后将这些候选区域送入 CNN 提取特征，随后，这些特征被送入多个 SVM 二分类器判断所属类别，并通过回归器对候选框位置进行修正。相比传统方法，启发式的搜索显著提升了目标的定位速度；CNN 将候选区域映射到更复杂的高维空间，提取比手工特征更具表示能力的特征；回归器将包含目标的候选框进行位置修正提高检测框的准确度，最终实现目标检测效果的显著提升。在 PASCAL VOC 数据集^[16]上，与经典方法相比平均精度均值（mean average precision, mAP）大幅提升。虽然 RCNN 显著提升了目标检测精度，但 RCNN 对每张图像生成大约两千个候选区域，大量重叠的候选区域被调整到 227×227 ，分别送入 CNN 进行特征提取，导致 RCNN 检测速度过慢。




图 1.3 RCNN 网络结构

Fig 1.3 Structure of RCNN network

为了进一步提升检测速度，He K 等人^[17]提出了空间金字塔网络 SPPNet。在 SPPNet 之前，几乎所有的 CNN 都需要输入固定尺寸的图像，CNN 对输入大小的限制在于全连接层，因为卷积过程实际上是以不同的卷积核在图像上滑动，对输入尺寸无固定要求，而全连接层则是在固定长度的特征向量间进行映射。为了满足 CNN 对输入尺寸的要求，不同大小的图像需要先经过裁剪和缩放到固定的

尺寸再提取特征,这会导致图像在一定程度上的信息丢失和变形。如图 1.5 所示, SPPNet 通过在全连接层之前接入一个空间金字塔池化层, 实现将不同大小的 feature map, 生成固定长度的特征向量, 作为全连接层的输入。与 RCNN 不同的是, SPPNet 只对输入图像提取一次特征得到 feature map, 并在 feature map 上对各候选框对应区域采用金字塔空间池化, 生成固定长度的特征向量来训练检测器, 避免对图像特征的大量重复计算, 因此 SPPNet 在检测速度上有显著提升, 在 VOC2007 上 mAP 也略优于原来的 RCNN。




图 1.4 SPPNet 网络结构

Fig 1.4 Structure of SPPNet network

SPPNet 使 CNN 可以接收任意尺度的输入进行训练,而无需对输入进行裁剪和缩放,显著提高了检测速度,但其训练过程依然是多阶段的,需要分别训练分类器和边框回归器。在 RCNN 和 SPPNet 基础上, Girshick R 等人^[18]提出了 Fast RCNN, 采用多任务损失联合训练目标分类和边框回归, 如图 1.5 所示, 每个提取的特征向量经过两个 FC 层得到两个输出, 一个输出层负责预测 $C+1$ 个类别 (C 个目标, 1 个背景) 概率, 另一个输出层则用来拟合边界框的 4 个位置坐标, 除了区域建议过程, 所有参数都可以在多任务损失中得到优化, 节省了额外的存储开销, 同时提高了检测的精度和速度。




图 1.5 Fast RCNN 网络结构

Fig 1.5 Structure of Fast RCNN network

Fast RCNN 使用多任务损失实现了检测模型的端到端训练，而区域建议生成仍然是其提高模型效率的瓶颈。后来，Ren S 等人^[19]提出了 Faster RCNN 目标检测网络，使用一个额外的区域建议网络（Region Proposal Network, RPN），代替启发式搜索自动完成高质量候选区域的生成，通过与 Faster RCNN 的分类和边框回归网络共享参数，使区域建议过程几乎不需要消耗额外的内存空间。RPN 的提出使 Faster RCNN 成为首个完整的端到端目标检测模型，在 PASCAL VOC 数据集上取得了当时最好的检测精度。

以上工作的相同点是需要事先生成候选区域，然后对候选区域提取特征分别进行分类和回归，属于两阶段的目标检测方法。虽然 Faster RCNN 首次将候选区域建议、特征提取、分类与边界框回归等步骤集成到统一的架构下进行端到端的学习，但需要重复交替地训练 RPN 与目标检测两个网络，导致整个训练过程比较繁琐和耗时。2016 年，Redmon J 等人^[20]提出 YOLO 目标检测模型，在深度目标检测模型中首次移除了区域提议过程，在网络输出的特征张量上同时预测类别概率和边界框坐标，成为深度学习领域第一个单阶段检测器。如图 1.6 所示，YOLO 的特征提取网络由 24 个卷积层和两个全连接层组成，对于每张输入图像提取一次特征，通过最后的全连接层得到 $s \times s \times n$ 的输出张量， s 表示张量的空间分辨率， n 为 $s \times s$ 网格单元（grid cell）中每个 cell 的预测向量长度，包括 C 个类别概率和 B 个边界框坐标，每个边界框具有 4 个位置参数和 1 个置信度参数，因此每个网格单元预测向量长度 $n = B \times 5 + C$ ，网络最终输出的张量大小为




Fig 1.6 Structure of YOLO network




Fig 1.7 Structure of SSD network

级的语义信息和更大的感知野，适合检测大目标；浅层特征感知野小，但包含物体的更多形状和位置信息，适合检测小目标。多尺度检测的设计使 SSD 大大提高了单阶段目标检测器的检测精度，能更好地处理各种大小不同的目标，在多个目标检测数据集上，其表现优于 Faster RCNN 与 YOLO，在检测速度方面，单阶段的 SSD 同样具有明显优势。后来，作为对 YOLO 的改进，Redmon J 等人^[22~23]相继提出了 YOLOv2 与 YOLOv3，在保证实行性的同时，进一步提升了检测精度。

1.2.2 行人重识别

行人重识别最初作为多摄像机下的行人跟踪任务提出，后来被广泛认为是图像检索的子问题，即给定目标行人图像，在大规模的图像库中检索出该目标的其它图像。行人重识别可以实现跨相机的行人身份识别，是智能视频监控领域极具吸引力和挑战性的课题之一。

早期人们主要通过手工提取图像的颜色、纹理和其它外观属性进行行人重识别工作。Gheissari N 等人^[24]采用一种时空分割算法得到时空不变的显著边缘特征，与 HS 直方图、边缘直方图结合表示局部区域进行行人重识别；为了适应行人姿态差异，Farenzena M 等人^[25]将行人身体划分为头、躯干、腿部三个部分，并为每个部分计算一个对称轴，然后提取除了头部以外的各区域的颜色、纹理等多种特征，并根据其与对称中轴的距离对特征进行加权，靠近中轴的部分被分配更高的权重，来应对不同视角下行人的姿态变化；考虑到颜色直方图特征对光照变化比较敏感，Yang Y 等人^[26]提出了一种显著颜色名描述特征（Salient Color Names Color Descriptor, SCNCD），通过预先定义的 16 种颜色在四个不同的颜色空间计算概率向量作为行人特征表示，对光照变化具有更好的鲁棒性。Zhao R 等人^[27]在每个 10×10 的块中以步长为 5 像素的密集采样方式，对每个小区域提取 32 维 LAB 颜色直方图和 128 维 SIFT 描述子得到更好的特征表示。

这些外观特征在面临光照与姿态变化、遮挡等情况时效果下降明显，而且，不同行人可能具有非常相似的外观，手工提取的外观特征面临判别性不足的问题，虽然组合多种类型的手工特征能够在一定程度上增强表示能力，但也使特征的计算过程变得繁琐，距离度量更加耗时，在现实复杂场景下仍然缺乏泛化性。后来，

深度学习的出现为行人重识别技术提供了新的解决方案。

基于深度学习的方法利用 CNN 代替手工来提取行人更复杂、更具判别力的特征，在行人重识别领域，表征学习和度量学习是常见的两种方法。其中，表征学习方法包括分类模型与验证模型，在分类模型^[28]中，假设数据集中包含 K 个行人的 n 张训练图像，对于输入图像 x ，经过分类模型 f 提取特征后计算分类预测向量 $z = [z_1, z_2, \dots, z_K]$ ，则将 x 预测为行人 k 的概率为 $p(k|x) = \frac{e^{z_k}}{\sum_{i=1}^K e^{z_i}}$ ，相应地，对图像 x 的分类损失可表示为：

$$L_{ID}(f, x) = - \sum_{k=1}^K q(k|x) \log p(k|x) \quad \dots (1.1)$$

其中， $q(k|x)$ 为 x 的真实类别标签信息，若 x 的真实类别标签为 y ，则：

$$q(k|x) = \begin{cases} 1 & k = y \\ 0 & others \end{cases} \quad \dots (1.2)$$

相比分类模型，验证模型^[29]将行人重识别看作二分类问题，每次输入成对的图像，两张图像通过共享参数的 CNN 网络提取特征，最后使用一个二输出的全连接层，判别两个图片是否为同一行人。通常，ID 分类损失与验证损失被结合起来训练网络^[30]，用来取得更具判别力的特征表示。与表征学习不同，度量学习方法关注于让网络学习图像之间的相似度上，通过模型提取图像特征后，该特征不用于行人 ID 分类，而是通过距离度量方法（如欧式距离）计算特征之间的距离，以拉近相同行人特征间的距离，推开不同行人特征间的距离为目标，比较常用的度量损失有对比损失（contrastive loss）^[31]、三元组损失（Triplet loss）^[32]，以及在三元组损失基础上的一些改进^[33~34]等。

在特征提取上，对行人图像提取一个全局特征是简单直观的方法，然而，随着行人重识别数据集逐渐变得更大和更复杂，仅使用单一的全局特征在面对大量行人样本时缺乏泛化能力。后来，对行人提取更加复杂和丰富的局部特征变得流行，常用的局部特征学习方法有对图像或特征进行切分，或基于骨架关键点检测定位身体部位等。Varior R 等人^[35]将输入的行人图像进行水平切分，切分后的几个图像块被依次输入长短时记忆网络（Long short term memory network, LSTM）^[36]提取局部特征，然后将所有局部特征融合作为最终行人表示；简单对图像进行切分进行局部特征提取要求图像中人体具有良好的对齐，否则会使不同行人的局

部特征语义差距较大, 导致行人相似性度量结果出错。为了对齐图像中的行人, Zhang X 等人^[37]提出了一种动态对齐网络, 在无需提供额外监督信息的情况下, 通过计算局部区域之间的最短路径实现人体各部分的上下对齐。后来, Zheng Z 等人^[38]利用空间变换网络^[39] (Spatial Transformer Networks, STN), 对网络浅层的特征自动学习空间变换方式, 实现人体特征在空间上的良好对齐; Chu H 等人^[40]使用 STN 将行人检测模型与行人重识别模型进行联合优化, 以端到端的方式训练两个任务, 通过行人重识别网络的分类损失为行人检测网络提供监督信息, 来生成更好的行人包围框。为了使每个局部特征对应人体各部分的确定语义, Zhao H 等人^[41]使用额外的骨架关键点检测模型获取人体的 14 个关键点, 并基于关键点构建人体 7 个局部 ROI 区域, 然后 7 个子区域和原始图像一起输入网络提取特征, 最后级联全局特征和各局部特征得到行人特征表示。Song G 等人^[42]提出基于区域的质量估计网络 (Region-Based Quality Estimation, RQEN), 输入一个人的视频序列, 利用关键点检测器检测人体关键点, 然后将图像划分为上中下三个区域, 质量估计器根据每个区域的姿态信息是否完整为每个区域特征进行评分, 越完整分数越高, 最终多帧图像的各区域特征根据评分进行加权融合得到最终行人特征。虽然能够获得更具语义的部位划分, 但关键点检测模型的检测效果容易受到行人图像质量的影响, 要求图像中人体各关键点能够被检测到, 否则就难以准确定位每个身体部位, 而且无法以端到端学习的方式进行优化, 同时额外的关键点检测工作使整个模型变得更加复杂, 需要占用更多计算资源, 推理过程也更耗时, 不利于实际场景中的应用。后来, Sun Y 等人^[43]利用注意力机制自动感知图像中可见人体区域, 并基于两张图像的共有区域进行特征比对, 缓解遮挡或检测失误导致行人只有部分区域可见的情况下, 行人重识别失败的问题。

最近, Dai Z 等人^[44]提出了 BDB 网络, 对每个小训练批次的特征, 通过随机擦除它们的某个相同区域, 增强局部区域注意力特征的学习, 提升模型的泛化性能。Sun Y 等人^[45]提出基于局部的卷积基线 (Part-based Convolutional Baseline, PCB) 网络, 与在原始图像上进行划分学习局部特征的方法不同, PCB 对骨干网络提取的特征进行水平切分, 将切分后的多个局部特征输入不共享参数的子分支中进行 ID 分类, 并对多个局部特征向量单独计算损失, 指导网络学习丰富的局

部细节信息, PCB 简单有效的网络结构使其成为局部特征学习领域一个流行的基线。后来在 PCB 的基础上, Wang G 等人^[46]通过更复杂的网络结构设计和多损失联合学习获得了更高的识别精度。Fu Y 等人^[47]提出了水平金字塔匹配网络, 将骨干网络提取的行人特征图进行多次不同尺度的水平划分, 并对每个部分使用全局平均池化和全局最大池化两种方法构建丰富的多尺度金字塔特征, 在测试阶段, 连接各尺度的局部特征形成行人最终表示。

1.3 本文研究内容

本文以面向实际应用为背景, 开展监控视频中行人检测与重识别技术研究。当前大多数行人重识别算法基于手工标注或事先检测得到的行人图像框, 实际应用场景中行人重识别系统的输入为监控视频, 因此需要依靠行人检测技术将视频中的行人进行检出。由于实际监控场景面临各种复杂情况的干扰, 因此如何有效地结合行人检测和行人重识别实现行人身份识别是一项具有挑战性的研究工作。

(1) 行人检测部分, 综合考虑行人检测准确性和实时性两个方面, 本文设计了一个轻量级的行人检测模型, 使用 MobileNetV2 作为特征提取网络, 在其基础上进行跨深度的特征融合, 完成行人多级检测, 增强模型对行人尺度变化的泛化性; 为了保持模型的轻量化, 多级检测分支基于深度可分离卷积进行设计, 提升计算效率; 最后, 在行人检测数据集和所采集的监控视频中进行实验, 结果表明, 模型能够在监控场景下完成高效的行人检测工作。

(2) 行人重识别部分, 考虑到一般的行人重识别方法仅对行人提取一个简单的全局特征存在的特征表示能力不足的问题, 本文提出了多尺度特征学习算法, 学习更加丰富的行人特征表示。同时, 针对人体在图像中的空间不对齐导致模型识别精度下降的问题, 本文使用特征对齐模块实现人体特征在空间上的良好对齐, 增强人体特征, 并提升测试期间行人间相似性度量结果的准确性。最后, 在两个常用的大型行人重识别数据集上对所提出的方法进行评估, 并与当前一些代表性的相关工作进行了比较, 实验结果验证了本文方法的有效性。

(3) 结合行人检测完成面向应用的行人重识别技术实现, 将监控视频作为输入, 输出待检索目标在视频中出现的视频区间。为进一步测试性能, 在几个常

见的监控场景拍摄了多段视频并进行标注,制作成新的测试集对整个行人重识别系统进行测试,测试结果表明系统能够自动完成在监控视频中对特定行人目标的检索工作。

1.4 论文章节安排

本文共分为六个章节,每章节的内容安排如下:

(1) 第一章为绪论,首先讲述了结合行人检测的行人重识别技术对现代智能监控系统的重要性,给出了行人检测与行人重识别的问题定义,并分别对国内外行人检测和行人重识别的研究现状进行综述,分析了面向应用场景行人重识别技术实现面临的难点问题,进而引出本文的研究工作。

(2) 第二章介绍了基于深度学习的行人检测与行人重识别的相关工作。

(3) 第三章为本文行人检测部分的实现,首先介绍了深度可分离卷积与轻量级目标检测模型的理论基础,以及本文基于特征融合的轻量级行人检测网络总体设计,然后通过实验对本文方法的有效性进行验证,并对模型在实际监控场景下进行行人检测的可行性进行了分析和讨论。

(4) 第四章为本文行人重识别部分的实现,对本文提出的多尺度特征学习算法进行了详细阐述,介绍了特征对齐模块的理论基础和设计细节,并在大型行人重识别数据集上进行实验,通过与当前一些代表性的工作进行比较,对本文提出方法的有效性进行验证。

(5) 第五章为结合行人检测的行人重识别系统实现,使用在实际场景下拍摄和制作的视频数据对系统进行测试,通过定义的评估指标对系统进行评估,验证系统面临实际监控场景行人身份识别的有效性。

(6) 第六章对全文内容和研究成果进行了概括与总结,分析当前系统存在的不足,对未来行人重识别技术的发展做出展望。

第2章 行人检测与行人重识别相关工作

2.1 行人检测相关工作

2.1.1 特征金字塔网络

之前大多数基于深度学习的目标检测方法只在网络顶层进行检测，无法很好地适应各种目标尺度。为了提取多层次丰富的目标特征，提升模型的泛化能力，Lin T Y 等人^[48]提出了特征金字塔网络（Feature Pyramid Networks, FPN）。




图 2.1 图像与特征金字塔

Fig 2.1 The image and feature pyramid

如图 2.1（a），图像金字塔特征常被用于传统手工设计特征的方法中^[49~50]，提升模型对目标尺度变化的不变性，但对不同尺度的金字塔图像均计算一次特征无法保证效率。CNN 能够提取更高级的语义表示，但大多基于 CNN 的方法只利用网络顶层输出的单个特征（图 2.1（b））进行目标的检测或分类，无法很好地应对目标尺度变化的多样性；随着输入图像在 CNN 中的前向传播，卷积或池化的下采样会自动形成尺度逐渐缩小的特征金字塔（图 2.1（c）），SSD 首次利用金字塔特征进行目标多级检测，改善了模型对不同尺度目标的检测能力。实际上，CNN 不同深度和空间分辨率的特征具有较大的语义信息差距，浅层特征虽然具

有更多细节信息但缺乏表示能力。为了使所有层次的金字塔特征均具有丰富的语义信息，FPN 在 CNN 自底向上的前向计算过程中，对金字塔特征的构建采取一种自顶向下和横向连接结构（图 2.1（d）），将低分辨率、强语义的深层特征与高分辨率但语义较弱的浅层特征进行跨深度融合，使所构建的金字塔特征在各个层次上均具有更强的表示能力，然后再在每个层次上进行多尺度目标检测。基于多尺度特征融合的 FPN 对目标尺度变化具有更强的泛化性，显著提升了目标检测精度。后来，FPN 的思想在目标检测领域被广泛采纳^[51~53]，取得了更优秀的表现。

2.1.2 YOLOv3 目标检测模型

（1）YOLOv3 模型结构

YOLOv3 是 YOLO 的改进版本，同样采用单阶段的目标检测方式，与一般的 CNN 网络相比，YOLOv3 中没有采用全连接层和池化层，仅使用卷积层构建网络，有助于保留更多因空间池化而丢失的细节信息，通过改变卷积步长调整输出尺寸。相比 YOLOv2 使用 Darknet19 作为特征提取网络，YOLOv3 特征提取网络有 53 个卷积层，命名为 Darknet53。Darknet53 结构设计如图 2.2，在 Darknet53 中借鉴了 ResNet 的残差结构，通过跳层（shortcut）连接使网络变得更深，并有效避免深度神经网络难以训练的问题，增强特征提取能力。

	Type	Filters	Size	Output
	Convolutional	32	3 × 3	256 × 256
	Convolutional	64	3 × 3/2	128 × 128
1 x	Convolutional	32	1 × 1	
	Convolutional	64	3 × 3	
	Residual			128 × 128
	Convolutional	128	3 × 3/2	64 × 64
2 x	Convolutional	64	1 × 1	
	Convolutional	128	3 × 3	
	Residual			64 × 64
	Convolutional	256	3 × 3/2	32 × 32
8 x	Convolutional	128	1 × 1	
	Convolutional	256	3 × 3	
	Residual			32 × 32
	Convolutional	512	3 × 3/2	16 × 16
8 x	Convolutional	256	1 × 1	
	Convolutional	512	3 × 3	
	Residual			16 × 16
	Convolutional	1024	3 × 3/2	8 × 8
4 x	Convolutional	512	1 × 1	
	Convolutional	1024	3 × 3	
	Residual			8 × 8
	Avgpool		Global	
	Connected		1000	
	Softmax			

图 2.2 Darknet53 特征提取网络

Fig 2.2 Darknet53 feature extraction network

YOLOv3 中共有 5 次下采样操作，每次下采样使特征图尺寸下降一半，因此 YOLOv3 的输入图像的长和宽需要缩放为 32 的倍数。为了检测不同尺度的目标，YOLOv3 借鉴 FPN 的思想，3 个 YOLO 层通过深层特征与浅层特征融合的方式实现目标的多尺度检测。融合后的特征既保留浅层特征的细节信息，又融合了更深层次特征的语义信息，具有更强的表示能力。图 2.3 展示了完整的 YOLOv3 模型结构。




图 2.3 YOLOv3 网络结构

Fig 2.3 Structure of YOLOv3 network

在 YOLOv3 中，一个卷积（Conv）层、一个 BN 层加一个 Leaky ReLU 激活层构成一个基本组件 DBL/s，s 表示该 DBL 块卷积层的步长，为了表示清晰，当卷积步长为 1 时，用 DBL 表示。两个相连 DBL 的输入与输出相加组成一个残差单元 RES Unit，RES_n 为由 1 个 DBL 和 n 个残差单元堆叠而成的下采样块，每经过一个 RES_n 特征的空间分辨率下降为原来的一半，下采样操作在首个卷积步长为 2 的 DBL（DBL/2）中完成。当输入图像大小为 416×416 时，经过 5 个下采样步骤得到 13×13 大小的特征图，经过 DBL 和 Conv 层进行 bounding box 预测； 13×13 的特征图进行步长为 2 的上采样，并与第四个下采样得到的 26×26 的特征图在通道维度拼接，作为第二个 YOLO 层的输入，得到 26×26 的张量进行预测；第二个 YOLO 层中的 26×26 的特征图与第三个下采样得到的 52×52 的特征图在通道维度拼接作为第三个 YOLO 层的输入，得到 52×52 的特征图进行

预测。在三个 YOLO 层中，输出的特征尺度依次扩大，增强模型对不同尺度目标的检测能力。

(2) YOLOv3 算法原理

图像调整：为了防止图像裁剪和缩放造成图像形变和信息丢失，YOLOv3 先将图像宽和高较长的一边缩放到要求的长度，短的一边按照原始的宽高比进行缩放，不足的地方用固定颜色填充。

先验框(anchor box)生成：为了让网络能够容易地学习更好的预测，YOLOv3 使用 k-means 聚类算法自动生成更好的先验框。例如，在 COCO 数据集上，YOLOv3 通过对训练集中真实的 bounding box 进行聚类得到 9 个 anchor box，然后 9 个 anchor box 被平均分配到三个不同尺度的特征图上，小 anchor box 分配给大的特征图用来检测小目标，大 anchor box 分配给小的特征图用来检测大目标。




图 2.4 YOLOv3 坐标预测

Fig 2.4 The coordinate prediction of YOLOv3

Bounding box 预测：YOLOv3 不直接预测坐标位置，而是对每个 bounding box 预测 4 个坐标偏移量。如图 2.4 所示，其中，黑色虚线框是 anchor box，蓝色矩形框为当前 cell 对该 anchor box 的预测， t_x 与 t_y 预测坐标偏移， t_w 与 t_h 预测尺度偏移， C_x 和 C_y 是 feature map 中当前 grid cell 相对左上角的偏移， P_w 、 P_h 为当前 anchor box 的宽和高。根据预测的四个位置偏移，通过计算得到预测框的位置坐标。 $\sigma(z)$ 为 sigmoid 函数，将该 grid cell 的预测中心限制在该 cell 内。在 YOLOv3 中，每个 grid cell 用来预测三个包围框，对应三个不同尺寸的 anchor

box, 每个 grid cell 向量的长度 $n = 3 \times (4 + 1 + C)$, 其中 4 代表四个位置偏移, 1 代表目标置信度, C 代表预测类别数目。在 COCO 数据集上, 目标类别数目 C 为 80, 当输入大小为 416×416 时, 三个 YOLO 层分别输出 $13 \times 13 \times 255$, $26 \times 26 \times 255$ 和 $52 \times 52 \times 255$ 大小的特征张量。此时, YOLOv3 预测的包围框总数为 $(52 \times 52 + 26 \times 26 + 13 \times 13) \times 3 = 10647$, 通过目标置信度对大量重复无用的框进行过滤, 置信度小于阈值的框将被丢弃, 然后通过非极大值抑制算法筛选同一个目标重复的预测框。

2.2 行人重识别相关工作

2.2.1 PCB 网络

为了解决简单的全局特征面临复杂的监控场景存在的特征判别性不足的问题, 对行人提取更复杂的局部特征成为一个研究热点^[54]。对原始图像进行切块是一种简单直观的方法, 将切分好的块送入 CNN 提取局部特征, 再将多个局部特征进行融合得到最终表示, 虽然能够获取更加丰富的特征表示, 但要求输入图像中的人体具有良好的空间对齐, 如图 2.5 所示, 如果一个行人的头部对应另一个行人的躯干或背景, 将代表不同语义的特征进行比较, 无法得到准确的结果; 基于关键点检测定位身体部位的方法能够获取相对准确的行人部位划分, 在一定程度上消除复杂背景的干扰, 但前提是能稳定提供准确的关键点检测结果, 在监控场景, 人体姿势差异较大, 且容易受到遮挡以及低分辨率影响, 使关键点检测结果变得不可靠, 另外, 额外的关键点检测模型会增加整个模型复杂度。



图 2.5 行人空间不对齐示例

Fig 2.5 The examples of pedestrian spatial misalignment

与上述工作不同, PCB 网络^[45]对 CNN 输出的特征图进行水平切分进行局部特征的学习, 其网络结构如图 2.6 所示。对骨干网络输出的三维特征张量 T , PCB 将其从上到下进行六等分, 经过平均池化得到一个 $6 \times 1 \times c$ 的特征张量, c 表示张量维度, 随后使用 1 个 1×1 卷积层对张量进行降维, 得到六个 $1 \times 1 \times c'$ 的特征向量, c' 为降维后的输出维度, 六个特征向量被输入到六个独立的分支中学习 ID 分类, 每个分支的全连接层之间不共享参数。在 PCB 中, 网络总的损失为六个局部分支的损失之和。相比之前局部特征学习方法, PCB 的结构设计简单而有效, 显著提升了行人重识别的精度。




图 2.6 PCB 网络结构

Fig 2.6 Structure of PCB network

将特征直接划分到六个部分, 难免会将本属于一个部分的特征划分到其它部分, 而同一部分的特征所代表的信息却明显不一致的情况, 作者在 PCB 的基础上, 提出了一种自适应池化方法 (Refined Part Pooling, RPP) 对部分划分的错误进行修正。具体来说, RPP 使用部件分类器去学习特征向量的划分方式。对于张量 T 上的每个特征列向量 $f \in R^{1 \times 1 \times c}$, RPP 预测每个 f 属于部分 P_i 的概率, 其中 $i \in \{1, 2, \dots, 6\}$, 即:

$$S(f \leftrightarrow P_i) = \text{softmax}(W_i^T f) = \frac{\exp(W_i^T f)}{\sum_{j=1}^p \exp(W_j^T f)} \quad \dots (2.1)$$

其中, p 为期望划分的部分个数, 在 PCB 中 $p = 6$, W 为可训练的部件分类器的权重参数。最终, 依概率对 T 的所有特征列向量进行加权得到每个部分最终的特征表示, 代替对 T 直接水平切分和平均池化, 加强同一部分特征信息的一致性。RPP 在一定程度上缓解了直接平均分块引起的划分错误, 得到改进的 PCB+RPP 显著增强了模型对行人的特征提取能力, 提升了局部特征学习的有效性。

2.2.2 空间变换网络

卷积和池化使 CNN 对图像中目标的空间变化具有一定的不变性，但当目标在图像中存在低分辨率、平移、缩放等视觉变化时，CNN 仍缺乏有效的手段增强泛化能力。此外，CNN 本身对输入数据的不变性通常更倾向于网络顶层，如果目标姿态在浅层能够得到适当的矫正，将有助于网络学习到更好的参数。2015 年，谷歌 DeepMind 团队提出了空间变换网络 STN^[39]，STN 可以被嵌入到常规 CNN 网络中，使整个模型具备主动对不同类型的输入执行空间变换的能力。




图 2.7 STN 的空间变换效果

Fig 2.7 Spatial transformation effect of STN

如图 2.7，(a)为作者将 MNIST 手写数字数据集中的图像进行仿射变换和附加干扰后的输入，(b)、(c)为 STN 对输入中的目标数字进行定位和变换的结果，(d)表示 CNN 对得到变换后的手写数字实现了正确的识别，实验结果表明，STN 能够将不良输入图像中的目标调整到预期的、规范的姿势，从而提升 CNN 模型的识别或分类准确性。

后来，Zheng 等人提出 PAN 网络^[55]，利用 STN 实现人体特征在空间上的对齐，提升行人重识别模型的泛化性。如图 2.8，PAN 有两个分支，分别为基本分支和对齐分支，基本分支特征提取网络使用 ResNet-50，按照特征的提取过程将 ResNet-50 划分为 5 个下采样块，对于一个输入图像，基本分支对该图像提取特征并用于身份分类，同时为对齐分支提供空间语义线索，空间变换网络利用基本分支提供的深层语义特征，学习对浅层特征的空间变换参数，并将变换参数应用于浅层特征进行空间变换，变换后的特征作为对齐分支的输入。基本分支和对齐分支在前两个下采样块共享参数，在训练整个模型时，PAN 的损失为两个分支的损失之和。在两个分支的共同学习下，PAN 能够改善图像中背景过多或行人部件

缺失时的行人重识别效果。




图 2.8 PAN 网络结构

Fig 2.8 Structure of PAN network

2.3 本章小结

本章介绍了行人检测与行人重识别的相关工作。行人检测部分,FPN 将 CNN 前向计算过程中的多尺度特征进行跨深度融合,得到更加丰富的特征表示,YOLOv3 使用这种策略改进之前版本对小尺度目标检测能力不足和目标长宽比泛化能力低的问题;行人重识别部分,PCB 网络提出了一种新的局部特征学习方法,只带来少量的参数增加来学习更丰富的行人特征;STN 被用来对图像中的目标姿态进行矫正,增强目标特征并抑制背景,后来,PAN 将 STN 应用于行人重识别,实现人体特征在图像中的对齐,增强模型对行人空间不对齐的泛化能力。在后续章节,本文将从应用角度出发,基于上述工作提出改进方案,实现面向应用的行人重识别技术。

第3章 基于特征融合的行人检测方法设计与实现

行人检测是实现行人重识别的一个重要环节,完成监控图像中行人目标的检出工作,理想的行人检测模型裁剪出图像中包含行人的最小外接矩形,这会大大提升行人重识别模型的准确性。从应用角度出发,系统不仅要具备较高的精度,还要考虑实际处理速度和应用成本。本章实现了一个轻量级的行人检测模型 MobileNetV2-person,显著提升了模型检测速度,并保持了优秀的行人检测精度。

3.1 行人检测方法总体设计

首先,为了达到更快的行人检测速度,给行人重识别部分留出更多时间,使用 MobileNetV2 作为行人检测模型的特征提取网络,代替原 YOLOv3 的 Darknet53,加快对输入图像的特征提取过程;其次,为提升模型的行人检测精度,将 MobileNetV2 的不同层次的特征进行跨深度融合,并将融合后的多尺度特征输入到三个独立的检测层进行多级行人检测,使模型更好地应对图像中行人的大小和宽高比变化;同时,为了保持模型的轻量化,三个检测层基于深度可分离卷积进行设计,使模型能够完成更快的训练和推理过程,更符合实际应用需求;最后,为了只针对行人完成更好地检测,将最后用于输出预测张量的 1×1 卷积层的通道维度进行修改,并从 VOC2007 与 VOC2012 中提取出所有含人的图像及其标注,整理成只含有行人的数据集,对整个网络进行重新训练,使网络针对行人检测任务更好地学习,最终满足实际监控场景下对行人快速、准确检测的需求,为之后的行人重识别工作打下良好基础。

3.2 深度可分离卷积

与其它计算机视觉任务相同,目标检测的精度很大程度上取决于其采用的特征提取网络,研究工作者们在设计更好的特征提取网络上投入了大量的精力,一个总趋势是将网络变得更深和更复杂。最初用于图像分类的 AlexNet 只有 8 层,初步展现了 CNN 在计算机视觉任务上的巨大潜力;后来的 VGG 网络深度扩展

为 16，在 ImageNet 数据集上取得了更好的分类表现；GoogLeNet 采取更宽和更深的网络结构，并提出批归一化方法，使深度神经网络容易训练；为了解决随着网络深度增加，准确率达到饱和后迅速下降的问题，He K 等人提出了 ResNet，通过使用一种新的残差结构使模型加深的同时避免发生退化，ResNet-152 深度达到 152，并在当年赢得了多项计算机视觉比赛的冠军。虽然更复杂的网络通常具有更强的特征提取能力，但同时对硬件设备要求更高，且推理过程通常更加耗时，在人机交互、自动驾驶、行人重识别等领域，检测或识别任务需要在有限计算和存储资源的移动或嵌入式设备上快速完成，小而高效的 CNN 模型对于实际应用场景非常重要。最近，越来越多研究人员开始关注深度神经网络模型的压缩和加速^[56~58]，并尽可能地减少由此带来的模型精度下降。为了满足从监控视频中快速、准确检测行人的需求，本文通过对标准卷积进行分解实现轻量型行人检测模型的设计，同时保证其能够很好地完成实际监控场景下的行人检测任务。




图 3.1 标准卷积

Fig 3.1 Standard convolution

应用深度可分离卷积（Depthwise Separable Convolutions, DSC）实现模型轻量化已被证明是一种有效的方法^[59~61]，在 ImageNet 数据集上，将标准卷积替换为深度可分离卷积的 MobileNet^[59]相比同样配置的标准卷积网络，计算量和参数量仅仅约为其 1/8，而精度仅下降了大约一个百分点。深度可分离卷积将一个标准的卷积过程拆分成通道卷积（Depthwise Convolution, DW）与点卷积（Pointwise Convolution, PW）两个步骤。图 3.1 是一个标准的卷积过程，以 $7 \times 7 \times 4$ 的输入张量为例，设卷积核大小为 3×3 ，则每个 $3 \times 3 \times 4$ 的卷积核同时作用于输入张量的所有通道，当步长为 1 时，得到一个 $5 \times 5 \times 1$ 的输出张量，若输出通道数目为 128，则需要 128 个 $3 \times 3 \times 4$ 的卷积核，若不考虑偏差项，本次卷积过程需要的

参数量为 $3 \times 3 \times 4 \times 128 = 4608$ 。




图 3.2 深度可分离卷积

Fig 3.2 Depthwise Separable Convolutions

图 3.2 展示了深度可分离卷积的计算过程，首先，DW 卷积针对每个输入通道使用一个 $3 \times 3 \times 1$ 的卷积核，同样 $7 \times 7 \times 4$ 的输入张量，卷积步长为 1，DW 卷积得到 $5 \times 5 \times 4$ 的输出张量 Output0。随后，PW 卷积是一个标准的 1×1 卷积， $1 \times 1 \times 4$ 的卷积作用于所有通道，得到一个 $5 \times 5 \times 1$ 的输出张量，128 个 $1 \times 1 \times 4$ 的卷积核得到与标准卷积相同大小的输出特征张量，即 $5 \times 5 \times 128$ 。在深度可分离卷积中，不考虑偏差项，参数量为 $3 \times 3 \times 1 \times 4 + 1 \times 1 \times 4 \times 128 = 548$ ，在输出特征通道数和感受野大小不变的情况下，仅仅约为上述标准卷积的 12%。在计算量上，标准卷积中 128 个 $3 \times 3 \times 4$ 的卷积核以 1 为步长滑动 5×5 个窗口，共产生 $128 \times 3 \times 3 \times 4 \times 5 \times 5 = 115200$ 次乘法运算，而深度可分离卷积在 DW 卷积步骤，4 个 $3 \times 3 \times 1$ 的卷积核滑动 5×5 个位置，共产生 $3 \times 3 \times 1 \times 4 \times 5 \times 5 = 900$ 次乘法运算，在 PW 卷积步骤，128 个 $1 \times 1 \times 4$ 的卷积核滑动 5×5 次，共产生 $128 \times 1 \times 1 \times 4 \times 5 \times 5 = 12800$ 次乘法运算，DW 加 PW 共需要 $900 +$

12800 = 13700次乘法运算，计算成本也仅约为标准卷积的 12%。

在一般情况下，对于 $D_F \times D_F \times M$ 的输入张量，假定卷积步长为 1 且卷积后输出尺寸不变，为 $D_F \times D_F \times N$ ，其中 D_F 表示张量的宽和高， M 和 N 分别为输入和输出通道数，则需要 N 个 $D_K \times D_K \times M$ 的卷积核， D_K 为卷积核尺寸，标准卷积产生的计算量为 $D_K \times D_K \times M \times N \times D_F \times D_F$ ，若将其替换为深度可分离卷积，DW 卷积步骤产生的计算量为 $D_K \times D_K \times M \times D_F \times D_F$ ， 1×1 的 PW 卷积产生的计算量为 $M \times N \times D_F \times D_F$ ，则深度可分离卷积产生的总计算量为：

$$D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F \quad \dots (3.1)$$

深度可分离卷积和标准卷积所需的计算量的比值为：

$$\frac{D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F}{D_K \times D_K \times M \times N \times D_F \times D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad \dots (3.2)$$

通常卷积神经网络的通道数目远大于卷积核尺寸，此时标准卷积所需的计算量约为深度可分离卷积的 D_K^2 倍，CNN 中使用的卷积核尺寸越大，深度可分离卷积对参数和计算量的压缩程度越大，从而实现模型复杂度的降低和模型推理速度的提升。

3.3 MobileNetV2 目标检测模型

MobileNetV2^[60]作为 MobileNet 的改进版本，结合 ResNet 残差结构的思想，在基本的深度可分离卷积结构中使用 shortcut 连接，并且增加了 1 个 PW 卷积层进行输入特征的维度扩张，同时移除了第二个 PW 卷积层之后的非线性激活层。图 3.3 展示了 MobileNet 深度可分离卷积结构、ResNet 基本残差结构与 MobileNetV2 中 Bottleneck Residual Block(BRB)和 Bottleneck Convolution Block (BCB)结构的对比，其中，BCB 与 BRB 的区别在于，BCB 中输入与输出通道不一致，或 BCB 中卷积步长为 2，输入特征经过该 Block 发生空间下采样，因此未采用 shortcut 连接。

在 ResNet 的一个基本残差块中，先将输入通过 1×1 卷积进行降维，随后是 3×3 标准卷积过程提取特征，最后再使用 1×1 卷积将特征变换到输入维度，与原始输入相加得到残差块的输出。而在 MobileNetV2 的 Bottleneck Residual Block 中，因为其使用深度可分离卷积使特征提取过程参数量和计算量大幅减少，再使

用 1×1 卷积对输入进行降维，会使特征含有的信息量与可学习参数变得更少，导




图 3.3 不同卷积 block 的结构对比

Fig 3.3 Structure comparison of different convolution blocks

致所提取特征的丰富性和表示能力降低。在 MobileNetV2 中，先将输入特征通过 1×1 的卷积扩张特征维度，这与一般的残差结构是相反的，然后使用 DW 卷积提取特征，最后再使用一个 1×1 的 PW 卷积对扩张的高维特征进行降维。值得注意的是，与 MobileNet 相比，MobileNetV2 移除了对最后 1×1 卷积输出特征的

ReLU 非线性激活，直接线性映射到输出，这避免了特征损失更多有用信息，增强了特征的表示能力。

MobileNetV2 的整体网络结构如表 3.1 所示，网络主要部分中每一层由一个或多个 bottleneck 组成， t 表示该层每个 bottleneck 中首个 1×1 卷积对输入通道的扩张率， c 表示该层 bottleneck 的输出通道数， n 表示该层 bottleneck 的个数， s 表示该层首个 bottleneck 卷积步长，其余 bottleneck 的步长为 1，若特征在某层发生下采样，则该层首个 bottleneck 中 DW 的步长为 2。

表 3.1 MobileNetV2 网络结构

Table 3.1 Structure of MobileNetV2 network

Input	Operator	t	c	n	s
$224^2 \times 3$	conv2d	-	32	1	2
$112^2 \times 32$	bottleneck	1	16	1	1
$112^2 \times 16$	bottleneck	6	24	2	2
$56^2 \times 24$	bottleneck	6	32	3	2
$28^2 \times 32$	bottleneck	6	64	4	2
$14^2 \times 64$	bottleneck	6	96	3	1
$14^2 \times 96$	bottleneck	6	160	3	2
$7^2 \times 160$	bottleneck	6	320	1	1
$7^2 \times 320$	conv2d 1×1	-	1280	1	1
$7^2 \times 1280$	avgpool 7×7	-	-	1	-
$1 \times 1 \times 1280$	conv2d 1×1	-	k	-	-

在 COCO 数据集目标检测任务上，MobileNetV2 在极少参数和计算量的情况下，取得了具有竞争力的表现，基于 MobileNetV2 与深度可分离卷积的 SSDLite 参数量与计算量比 SSD300 分别减少约 10、40 倍的情况下，mAP 仅下降了 1.1%，检测速度远远超过 SSD300，充分展现了 MobileNetV2 作为轻量级目标检测模型的优势。

3.4 基于特征融合的轻量级行人检测模型

MobileNetV2 在大幅削减模型参数量和复杂度的同时，保持了相对较好的分类和检测准确度，因此，MobileNetV2 比较符合在移动端或嵌入式平台上的部署需求。本文的行人检测模型使用 MobileNetV2 作为特征提取主网络，去掉最后的平均池化和 1×1 卷积，因为目标检测既要求准确定位目标的位置，同时要将目标

识别为正确的类别,更深层特征富含高级语义信息,有助于目标的分类,但缺乏目标位置等细节信息,且对密集小目标检测效果不够好;定位任务则需要捕捉目标的形体、轮廓以及位置等信息,这些低级信息通常更多存在于浅层特征中,而浅层特征往往缺乏表示能力。因此,对于目标检测任务来说,深层特征与浅层特征融合进行多尺度的检测是非常重要的,并在许多工作中被采纳提升模型对多尺度目标的检测能力^[23,48,62],本文参考YOLOv3的多分支检测结构,将MobileNetV2的特征提取过程中不同深度的特征进行融合,在融合后的多尺度特征上进行行人检测,增强模型对行人大小变化的泛化能力。




图 3.4 轻量级行人检测模型结构

Fig 3.4 Structure of lightweight pedestrian detection model

本文的轻量级行人检测模型整体结构如图 3.4, 在每个 Module/s 中 Module 为模块名, s 表示该模块对特征的下采样步长, 为表示清晰, 当 $s=1$ 时该模块直接记为 Module。在图 3.4 中, 除了最后三个用于输出预测张量的 Conv 模块只含有一个 1×1 卷积层外, 其余 Conv 模块为卷积、BN 与 ReLU6 的组合。从结构图中可以看到, 在 MobileNetV2 的特征提取过程中共有 5 次下采样, 除了第一个下采样发生在 Conv/2 模块, 其余四次下采样均发生在 BOT_n 中, n 表示该模块中 bottleneck 的个数。若在某个 BOT_n 中发生了下采样, 则下采样过程在该模块的第一个 BCB 结构的 bottleneck 完成 ($\text{stride}=2$), 其余 bottleneck 为 BRB 结构 ($\text{stride}=1$)。

为了增强模型的多尺度行人检测能力,本文参考 YOLOv3 的多级检测结构,对 MobileNetV2 最后三次下采样得到的三个不同尺度的特征进行了跨深度的融合。与 YOLOv3 的 3 个检测层不同的是,除了最后用于输出的 1×1 卷积外的其它标准卷积,替代为效率更高的深度可分离卷积,减少模型参数量,提升运行速度;在 3 个检测层中,将最后用于预测的 1×1 卷积层的输出通道根据检测类别数目进行修改,因为本文只检测行人一个类别,因此最终输出的特征张量维度为 $(5 + 1) \times 3 = 18$ 。

当网络输入图像大小为 $416 \times 416 \times 3$ 时,经过完整的 MobileNetV2 特征提取网络得到 $13 \times 13 \times 1280$ 的特征张量作为第一个检测层的输入,随后,经过 5 个深度可分离卷积块提取特征得到 $z_0 \in R^{13 \times 13 \times 512}$,再经过一个 1×1 的深度可分离卷积块将特征维度提升到 1024,最后一个 1×1 标准卷积层实现 1024 维度到预测向量维度的映射,作为第一个检测层的输出向量 $f_0 \in R^{13 \times 13 \times 18}$ 。随后, z_0 经过一个深度可分离卷积块降维到 256,并对 256 维的特征进行上采样得到 $z_0^* \in R^{26 \times 26 \times 256}$,与上一个下采样的特征融合输入到第二个检测层,同样经过五个深度可分离卷积块提取特征,得到 $z_1 \in R^{26 \times 26 \times 256}$,再经过一个深度可分离卷积块将维度提升到 512,最后经过一个 1×1 标准卷积得到第二个检测层的输出向量 $f_1 \in R^{26 \times 26 \times 18}$;同样, z_1 经过一个深度可分离卷积块和上采样,再与第三次下采样的特征进行融合,经过五个深度可分离卷积块后,再经过一个深度可分离卷积和一个 1×1 标准卷积得到第三个检测层的输出 $f_2 \in R^{52 \times 52 \times 18}$ 。三个检测层的输出张量具有不同大小的空间分辨率,最小的空间分辨率感知野更大,能够捕获更大范围的上下文信息用来预测大目标,大空间分辨率感知野相对小,但包含更多局部细节,能更好地预测小目标,特征跨深度的融合使得浅层特征在进行目标预测时,可以从深层特征当中获取高级语义信息,弥补浅层特征存在的特征表示能力不足的问题,使在大空间分辨率的输出张量上能够更加准确地预测小目标。

3.5 实验

3.5.1 数据集与评价指标

Pascal VOC 常被用于各项计算机视觉挑战,如语义分割、目标检测、图像分

类等。其中，VOC2007 与 VOC2012 常用于目标检测，并作为多个目标检测模型的基准数据集，用于衡量模型性能。VOC2007 共有 9963 张图像，其中训练集、验证集与测试集分别有 2501、2510 与 4952 张图像。VOC2012 共有 17125 张训练与验证图像。

在 VOC2007 和 VOC2012 中均包括 20 个目标类别，抽取出其中含人的图片及其对应标注，并把它们分别放置在新的文件夹组成行人训练和测试集。在 VOC2007 中，训练集与验证集中包含人的图像有 2095 张，测试集中有 2097 张；VOC2012 训练验证集中含有人的图像有 4374 张。把 VOC2007 训练集中的 2095 张行人图像与 VOC2012 训练集中 4374 张行人图像组成新的行人检测训练集，并将 VOC2007 测试集中的行人图像共 2097 张作为新的测试集对模型进行测试。行人检测数据集的组成如表 3.2。

表 3.2 行人检测数据集统计

Table 3.2 Pedestrian detection dataset statistics

数据集	图像数量	训练集	测试集	类别
VOC2007	9963	5011	4952	20
VOC2012	—	17125	—	20
All	8566	6469	2097	1

目标检测领域常用的评价指标为平均精度（Average Precision, AP），其定义为某个类别在不同召回率阈值下的平均检测精度，平均精度均值 mAP 更常用来衡量模型的综合性能，表示模型对多个类别的平均检测精度的均值。在目标检测领域，交并比（Intersection over Union, IoU）被用来衡量模型检测框的准确性，表示检测框与真实框的重叠程度，当检测框与真实框的 IoU 大于预先设定的阈值时，被认为是成功检出，小于阈值则认为检出失败。例如，AP⁵⁰ 表示在 IoU 阈值为 0.5 时，模型目标检测的平均精度。后来，随着目标检测领域的发展和大规模数据集的出现，研究人员逐渐更加关注目标检测的准确性，并开始更高的 IoU 阈值下对模型进行评估，如 AP⁷⁵ 等。

3.5.2 实验环境与实验设置

本文的实验环境为：ubuntu16.04 操作系统，CPU 型号为 Intel® Core™ i7-6850K @ 3.60GHz × 12，62G 内存，单块型号为 NVIDIA GeForce GTX 1080 Ti 的 GPU，11G 显存。模型实现基于 PyTorch 深度学习框架，编程语言为 python，实验结果中参数量与乘加计算量的统计来自 torchsummaryX。

训练过程中，使用随机水平翻转、随机裁剪和随机仿射变换等方法进行数据增强，使用多尺度训练策略，图像尺度变化范围为 320~608；训练总轮数为 80，训练过程 batchsize 设置为 8，学习率使用 warmup 策略，在前 3 轮从零增加到初始学习率 1e-4，并在之后以余弦方式衰减，余弦衰减公式为：

$$lr = lr_min + \frac{(lr_init - lr_min) \times (1 + \cos(\theta))}{2} \quad \dots (3.3)$$

$$\theta = \pi \times \left(\frac{cur_step - warmup_step}{stepsize - warmup_step} \right) \quad \dots (3.4)$$

其中， lr_min 为设置的最小学习率， lr_init 为初始学习率， $stepsize$ 为训练总迭代次数， $warmup_step$ 为 warmup 的迭代次数， cur_step 为当前迭代次数。




图 3.5 学习率变化曲线

Fig 3.5 Learning rate curve

训练过程中学习率的变化如图 3.5 所示，最终衰减到 1e-6，网络停止训练。实验选择 Adam 作为模型优化器，动量设置为 0.9， l_2 正则化权重衰减系数为 5e-4，IoU 阈值为 0.5。测试阶段图像大小固定使用 544×544 ，使用 AP⁵⁰ 对模型进

行评估。

3.5.3 实验结果

在服务器上对 Mobilenetv2-person 完成训练共需要 3.8 个小时，通过解析训练日志文件可以得到网络训练过程的损失下降曲线，如图 3.6，随着迭代次数的增加，网络整体的损失也在逐渐减少，在迭代大约 64000 次后损失趋于稳定，达到收敛条件，网络停止训练。




图 3.6 模型训练收敛曲线

Fig 3.6 Model training convergence curve

图 3.7 展示了测试阶段 Mobilenetv2-person 在不同输入分辨率下的行人检测精度曲线，随着输入图像分辨率的增加，模型测试精度呈上升趋势，在图像输入为 554×554 后分辨率继续增加模型精度不再增加，因此选择 554×554 作为模型最终输入分辨率。




图 3.7 不同输入分辨率下模型识别精度

Fig 3.7 The recognition accuracy of the model under different input resolutions

本文对三种不同的模型进行实验对比，如表 3.3 所示，YOLOv3 表示在 VOC2007 和 VOC2012 数据集上（20 个类别）训练后模型的行人检测的测试结果，YOLOv3*表示修改最后三个 1×1 卷积层输出通道，只进行单类别检测，并在行人检测数据集进行训练的测试结果，MobileNetV2-person 为本文行人检测模型的测试结果。

表 3.3 不同模型的行人检测性能对比

Table 3.3 Comparison of pedestrian detection performance of different models

Models	Input size	Params	Mult-Adds	AP ⁵⁰	Inference
YOLOv3	544×544	61.62M	55.94G	88.67	22.85ms
YOLOv3*	544×544	61.52M	55.82G	89.61	22.31ms
MobileNetV2-person	544×544	6.74M	6.38G	88.53	12.76ms

可以看到，在只包含行人的数据集进行训练的 YOLOv3*的行人检测精度略优于原来的 YOLOv3 多目标检测模型；同样使用 544×544 的输入尺寸，本文的轻量级行人检测模型 MobileNetV2-person，参数量和计算量仅为原 YOLOv3 模型的 $1/9$ ，且保持了较好的行人检测精度，平均推理速度达到 12.76ms，相比 YOLOv3 原网络有显著提升。

3.5.4 分析与讨论

本小节对本文行人检测模型的检测效果进行可视化分析,主要测试行人检测模型对于不同场景的输入图像能否成功检测行人,以及给出的行人包围框是否准确。

图 3.8 展示了 MobileNetV2-person 在 VOC2007 测试集上的检测结果,可以看到,在不同场景下,图像中的行人均能得到很好的检测,多级检测结构使模型对于行人的尺度变化具有更好的鲁棒性,即使图像中人体姿态发生了很大程度的变化,模型也能得到行人准确的包围框。




图 3.8 在 VOC2007 测试集上行人检测效果

Fig 3.8 Pedestrian detection effect on VOC2007 test set

为了进一步评估模型在实际监控场景下的检测效果,本文从拍摄的监控视频中随机抽取一些图像进行测试,如图 3.9,即使在存在大量的背景干扰,以及距离摄像机远近导致的行人视角和分辨率具有明显差别的情况下,模型依然成功检测出了图像中的行人,在三个不同的场景下均有良好表现。




图 3.9 实际场景行人检测效果

Fig 3.9 Pedestrian detection effect in real scene

图 3.10 展示了模型对从监控视频中抽取的困难场景图像样本的检测结果，左上角为夜晚低照明条件下的监控图像，模型基本能够保持良好的行人检测效果；在右下角图像中行人比较密集的情况下，模型对图像中所有行人均取得了准确的检测结果，即使受到遮挡依然能将未被遮挡的行人部分检出；左下角和右上角的两张图像中，骑自行车或电车的行人姿态发生较大改变，遮挡也更加严重，但模型仍然完整检测出了每个行人，除了右上角中红框内的行人因分辨率过小而错过了检测。




图 3.10 困难场景模型的检测效果

Fig 3.10 Detection effect of the model in difficult scenes

3.6 本章小结

本章详细介绍了本文轻量级行人检测模型 MobileNetV2-person 的设计,在特征提取主网络的选择上,为了实现一个轻量级的行人检测模型,使用 MobileNetV2 作为行人检测模型的特征提取网络,在此基础上,为了进一步削减模型参数量,提升推理速度,结合深度可分离卷积设计了模型的多尺度检测层,使模型既能保持对大目标的检测精度,也能更好地检测图像中的小目标。最终实现的模型参数量与计算量相比一般目标检测模型大幅减少,模型推理速度显著提升,同时保持了行人检测的准确性,通过在监控场景下对模型的检测效果进行测试,表明模型可以很好地应对各种复杂场景,能够满足实际应用的行人检测需求。

第4章 基于多尺度特征学习与特征空间对齐的行人重识别

在上个章节，介绍了本文设计的轻量级行人检测模型，经过测试，本文方法能够满足监控场景下的实时检测需求，在此基础上，本章将继续行人重识别部分的研究工作，首先概括了本文行人重识别方法的总体设计流程，随后对每个部分进行详细介绍，并在开放数据集上对模型进行实验和评估。

4.1 行人重识别方法总体设计

在复杂的行人重识别场景中，对行人图像提取一个简单的全局特征已经无法取得令人满意的识别效果；一般的基于局部特征的工作，简单地把特征划分到多个不同的部分，忽略了人体各部分特征之间的相关性，也可能对特征原有的语义信息造成损害。PCB+RPP 虽然提出了自适应池化模块优化局部特征学习过程，然而，监控视频中行人姿势、分辨率和相机视角等存在明显差异，限制 PCB+RPP 获得更好的识别性能。综上考虑，本文行人重识别方法主要聚焦于行人判别性特征提取和行人特征对齐两个方面，总体设计如图 4.1。

针对一般行人重识别方法中存在的特征表示能力不足的问题，本文提出了一种新的多尺度特征学习算法，与大多数的行人重识别工作相同，本文采用在行人重识别任务上具有更好表现的 ResNet-50 作为特征提取的骨干网络^[63]，在其基础上做了一些相应的修改。首先，取消了 ResNet-50 最后一个以 2 为步长的下采样操作，扩大输出特征图的尺寸，空间分辨率的增加将保留更多行人细节信息，在之前的工作中证明了这一改变能显著提升模型识别能力^[44-46]；其次，去掉了 ResNet-50 最后的全局平均池化层和之后的全连接层，取而代之的是一个多尺度特征池化层，通过不同大小的池化核组合，得到多个尺度的特征张量，作为后续多尺度特征学习模块的输入，模块中的网络采用多分支结构，分支间不共享权重，学习相应区域的特定语义信息；最后，把每个分支用于输出类别预测向量的全连接层根据训练集中的行人 ID 数目进行相应的修改，完成模型在不同数据集上的训练和评估。




图 4.1 行人重识别方法总体设计

Fig 4.1 Overall design of our person re-identification method

考虑到局部特征学习的方法虽然能获取更丰富的行人细节特征,但人体在图像中的不对齐会降低局部特征的有效性,并使行人特征间的相似性度量发生错误^[55,64]。受 STN 与 PAN 启发,本文将所设计的特征对齐模块嵌入到 ResNet-50 的不同深度,对浅层特征自动学习相应的空间变换策略,将人体特征进行对齐,实现消除多余背景、突出人体特征的目的,得到变换后的浅层特征输入 ResNet-50 后续部分继续特征提取过程。在测试阶段,对多尺度特征学习模块中的多个局部特征进行级联,得到最终的行人表示。

4.2 多尺度特征学习算法

在局部特征学习上，对图像切分的方法通常先将多个块输入 CNN 提取局部特征，然后联合多个局部特征进行行人 ID 预测；对特征切分的方法通常先将整个图像经过 CNN 得到一个三维特征张量，然后把张量划分成多个局部特征，每个局部特征被输入到多个独立的子分支进行行人 ID 预测，网络损失为多个局部分支损失之和。两者的关注点都在于使网络更多地关注行人局部细节信息，但它们大都忽略了一个关键因素，即人体各部分特征间是高度相关的，直接将行人划分成多个独立的部分进行学习，丢失了特征间具有的相关性，不利于网络学习到更好的行人表示。例如，行人的背包或躯干本来是一个整体，当被划分到不同部分之后，它们将失去原本所代表的语义信息。为了提升网络对行人特征的提取能力，本文提出了多尺度特征学习算法。




图 4.2 网络的多分支结构

Fig 4.2 Multi- branches structure of the network

如图 4.2，对于一个输入图像 x ，经过 ResNet-50 的四个阶段后得到输出特征张量 $T \in R^{H \times W \times C}$ ， H 和 W 分别为宽和高， C 为通道数目。随后，原始 ResNet-50 在此处的全局平均池化层被替换为一个多尺度特征池化层，以不同大小的卷积核对 T 进行平均池化，得到多个尺度的行人特征张量，之后网络被设计为多分支结构，每个分支接收不同尺度的张量作为输入，对其切分后学习局部特征的 ID 分类。本文将输入图像 x 的大小统一调整为 $324 \times 128 \times 3$ ，由于取消了 ResNet-50 最后

的下采样, 因此 x 经过修改后的 ResNet-50 共发生 4 次下采样, 得到张量 $T \in R^{24 \times 8 \times 2048}$, 沿通道维度的方向, T 含有 $24 \times 8 = 192$ 个特征向量 $T_i \in R^{1 \times 1 \times 2048}$, 其中, $i \in \{1, 2, \dots, 192\}$ 。随后, T 被输入到多尺度特征池化层, 多尺度特征池化层由三种不同大小的卷积核组成, 以相同的步长(均为 8×8)对 T 进行平均池化, 得到三个不同尺度的输出, 网络在此处分为三个独立的分支。其中, 8×8 大小的池化核对张量 T 进行平均池化得到 $z_{P_1} \in R^{3 \times 1 \times 2048}$, 作为局部分支 P_1 的输入; 同样, 经过 16×8 的平均池化得到 $z_{P_2} \in R^{2 \times 1 \times 2048}$, 作为第二个局部分支 P_2 的输入; 第三个池化核大小为 24×8 , 相当于对 T 进行全局平均池化得到 $z_G \in R^{1 \times 1 \times 2048}$, 因此将第三个分支当作全局分支 G 。在两个局部分支, z_{P_1} 与 z_{P_2} 经过一个 1×1 的卷积层将特征维度降低到 512, 再分别经过一个批归一化 (Batch Normalization, BN) 层和一个 ReLU 层, 得到 $f_{P_1} \in R^{3 \times 1 \times 512}$ 与 $f_{P_2} \in R^{2 \times 1 \times 512}$ 。之后, 在垂直方向上分别对 f_{P_1} 与 f_{P_2} 进行水平切分, 得到 $\{f_{P_1}^k \in R^{1 \times 1 \times 512} |_{k=1}^3\}$, $\{f_{P_2}^k \in R^{1 \times 1 \times 512} |_{k=1}^2\}$, 切分后的每个局部特征向量, 经过一个全连接层和 Softmax 层得到行人 ID 预测向量, 对每个预测向量分别计算分类损失, 加强局部特征的判别性学习。

在局部分支 P_1 中, f_{P_1} 被水平切分成三个特征向量, 对应张量 T 上相互独立的三个特征区域。而在局部分支 P_2 中, 对 f_{P_2} 切分得到的两部分特征向量在 T 上具有上下重叠的感知区域。局部分支 P_1 与一般的局部特征学习方法执行相似的划分机制, 其缺点是没有考虑各部分特征之间的相关性, 在 P_2 与全局分支 G 的作用下, 局部特征间的相关性信息重新得到了利用。由于多尺度池化层, 三个分支中的局部特征向量具有不同大小的感知野, 以学习不同粒度水平的人体信息。局部分支 P_1 中用于 ID 预测的特征向量具有最小的感知野, 学习更加精细的局部信息; 在局部分支 P_2 中, 特征向量感知野比 P_1 扩大了一倍, 在更大的局部区域上学习相对粗粒度的行人信息; 在全局分支 G , 特征向量具有全局感知野, 综合行人全部信息学习更富语义的全局特征。

在行人重识别领域, 度量损失与分类损失常被用来联合优化模型, 有助于增强模型的识别性能。在局部分支 P_1 与 P_2 , 仅对每个局部特征向量计算分类损失; 在全局分支 G , 对全局平均池化后的特征 z_G 使用度量损失, 使同类特征间的距离更近, 不同类特征间的距离更远; 对 z_G 经过批归一化后的特征 f_G 应用分类损失, 降低分类损失与度量损失之间的约束, 使两者更容易实现同步收敛。网络的总损

失等于所有分支中的六个分类损失与来自全局分支G中的度量损失之和。在测试阶段，将三个分支中的特征 f_{P_1} 、 f_{P_2} 与 f_G 进行级联，作为最终的行人表示，用于行人间的相似性比对。

4.3 特征对齐模块

行人在图像中不对齐会对识别行人身份造成影响，之前大部分工作通过使用额外的骨架关键点检测模型来定位身体各部位，但在复杂的行人重识别场景，无法保证行人骨架关键点检测结果的可靠性，因此存在部位划分不准确的情况；此外，额外的关键点检测部分会使整个行人重识别模型变得更加复杂，无法满足实际应用需求。STN 首次被提出用来对图像或特征执行空间变换，增强模型对图像中的目标平移、缩放、扭曲等的适应能力。在行人重识别领域，一些工作利用 STN^[39]对图像或特征进行空间上的变换以达到人体或人体特征对齐的目的，伴随着网络的训练过程，STN 将对各种类型的输入学习相应的空间变换策略。受上述工作启发，本文在 ResNet-50 的不同深度应用特征对齐模块，以确保其面对复杂场景下人体特征不对齐情况时能有效地发挥作用。特征对齐模块被插入到 ResNet-50 中，作为一个整体进行端到端训练，无需提供额外的数据集和标注信息，整个模块具备可导性，使其能够参与标准的误差反向传播和参数更新，在整个模型的训练过程中得到学习。




图 4.3 特征对齐模块

Fig 4.3 Feature Alignment Module, FAM

如图 4.3，特征对齐模块主要由参数估计和坐标采样两部分组成。参数估计部分是一个轻量级的 CNN 网络，由卷积层、最大池化层，BN 层，ReLU 激活层和全连接层堆叠而成，将张量 $U \in R^{H \times W \times C}$ 作为输入，输出对该张量预测的空间变换参数 θ ，并根据 θ 构成变换矩阵 A_θ ，坐标采样部分利用 A_θ 对 U 完成空间变换，得到输出张量 $V \in R^{H \times W \times C}$ 。

在本文中，使用仿射变换作为特征对齐模块的空间变换方式，通过参数估计网络得到长度为 6 的空间变换参数 θ ，由 θ 组成的仿射变换矩阵 A_θ 形式为：

$$A_\theta = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \quad \dots (4.1)$$

对于期望输出特征 $V \in R^{H \times W \times C}$ 上的特征点坐标 G ，根据 A_θ 有：

$$\begin{pmatrix} x_i^s \\ y_i^s \end{pmatrix} = f_\theta(G) = A_\theta \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} = \begin{bmatrix} \theta_{11} & \theta_{12} \\ \theta_{21} & \theta_{22} \end{bmatrix} \begin{pmatrix} x_i^t \\ y_i^t \end{pmatrix} + \begin{pmatrix} \theta_{13} \\ \theta_{23} \end{pmatrix} \quad \dots (4.2)$$

其中， (x_i^t, y_i^t) 表示 V 上的一个期望坐标， (x_i^s, y_i^s) 表示 A_θ 对 (x_i^t, y_i^t) 进行变换得到的该点对应在 U 上的源坐标。上式中， $\begin{bmatrix} \theta_{11} & \theta_{12} \\ \theta_{21} & \theta_{22} \end{bmatrix}$ 负责执行输入 U 的旋转和缩放， $\begin{pmatrix} \theta_{13} \\ \theta_{23} \end{pmatrix}$ 负责平移。根据上式， V 上每个期望坐标 (x_i^t, y_i^t) 都能找到在 U 上对应的源坐标 (x_i^s, y_i^s) ，然后将坐标 (x_i^s, y_i^s) 的特征值采样到 (x_i^t, y_i^t) 完成特征的变换过程。由于 (x_i^s, y_i^s) 与 (x_i^t, y_i^t) 分别是 U 和 V 上的离散特征点坐标，通过参数求得的源坐标 (x_i^s, y_i^s) ，不一定刚好属于 U 上的某个特征点，为了保持整个模块的可导性，使用双线性插值执行特征点的采样过程：

$$V_i = \sum_h^H \sum_w^W U_{hw} \max(0, 1 - |x_i^s - h|) \max(0, 1 - |y_i^s - w|) \quad \dots (4.3)$$

其中， V_i 表示期望的输出 V 上坐标 (x_i^t, y_i^t) 处的值，而 U_{hw} 表示输入 U 上坐标 (h, w) 处的值，上式相当于在 U 上对 (x_i^s, y_i^s) 附近的点 (h, w) ，以 (h, w) 到 (x_i^s, y_i^s) 的距离为权重，对 U_{hw} 进行加权采样，距离越近权重越大。当求得 (x_i^s, y_i^s) 刚好位于 U 上 (h, w) 点时，相当于将 U_{hw} 采样到 V_i 。将上式应用于 V 和 U 的所有通道，得到输入张量 U 经过特征对齐模块变换后的结果。

表 4.1 参数估计网络的结构设计

Table 4.1 Structure design of parameter estimation network

FAM_1	FAM_2
Input(batch*256*96*32)	Input(batch*512*48*16)
Conv2d(256,128, kernel_size=1)	Conv2d(512,256, kernel_size=1)
MaxPool2d(2, stride=2)	MaxPool2d(2, stride=2)
ReLU	ReLU
BatchNorm2d(128)	BatchNorm2d(256)
Conv2d(128,128, kernel_size=5)	Conv2d(256,256, kernel_size=3)
MaxPool2d(2, stride=2)	MaxPool2d(2, stride=2)
ReLU	ReLU
BatchNorm2d(128)	BatchNorm2d(256)
Conv2d(128, 256, kernel_size=1)	Conv2d(256,512, kernel_size=2)
MaxPool2d(2, stride=2)	——
ReLU	ReLU
BatchNorm2d(256)	BatchNorm2d(512)
Linear(256*11*3, 260)	Linear(512*10*2, 300)
ReLU	ReLU
Linear(260, 120)	Linear(300, 160)
ReLU	ReLU
Linear(120, 3 * 2)	Linear(160, 3 * 2)
ReLU	ReLU
Output(batch*256*96*32)	Output(batch*512*48*16)

在本文中，两个特征对齐模块分别被嵌入到 ResNet-50 的第一个 stage 和第二个 stage 之后，分别对 stage_1 和 stage_2 输出的特征图 $U_{stage_1} \in R^{n \times 256 \times 96 \times 32}$ 和 $U_{stage_2} \in R^{n \times 512 \times 48 \times 16}$ 学习并执行空间变换，其中， n 表示 batch_size。两个特征对齐模块中参数估计部分的设计细节如表 4.1 所示，首先使用 1×1 卷积先对输入特征张量进行降维，减少特征对齐模块的参数数量，避免陷入过拟合；BN 层稳

定梯度，使模型易于收敛；最后的全连接层将变化长度的特征向量映射到固定长度的变换参数。两个特征对齐模块将不同深度的特征张量作为输入，第一个特征对齐模块利用浅层特征完成行人在图像中的粗略定位，第二个特征对齐模块在更深层次的特征图上完成行人特征更精确的对齐。变换后的特征输入 ResNet-50 后续阶段继续前向计算过程。在测试过程，特征对齐模块的应用能使模型提取到更有效的人体特征，进而提升行人间相似性度量的准确性。

4.4 损失函数

为了增强所学特征的判别能力，本文结合度量损失与分类损失共同指导网络参数的学习。对于一个批次的训练样本 $\{(x_i, y_i), i = 1, \dots, N\}$ ，Softmax 损失形式为：

$$L_{softmax}(f_i, W) = - \sum_{i=1}^N \ln \frac{e^{(W^{y_i})^T f_i}}{\sum_q^Q e^{(W^q)^T f_i}} \quad \dots (4.4)$$

其中， W^q 表示类别 q 分类层的权重参数， Q 表示训练集中行人类别数目， f_i 是网络对 x_i 提取的特征。

在度量学习工作中，Triplet 损失是一种常用的度量损失。对于一个训练批次的 $P \times K$ 张图像，其中 P 表示行人数目， K 表示每个行人的图像数目，Triplet 损失的形式为：

$$L_{triplet} = (d_{a,p} - d_{a,n} + \alpha)_+ \quad \dots (4.5)$$

其中 a 表示该批训练数据中的一个锚点样本 (anchor, a)， p 表示从该批训练数据中随机选择的与 a 身份相同的正样本 (positive, p)， n 表示从该批训练数据中随机选择的与 a 不同身份的负样本(negative, n)， $d_{a,p}$ 与 $d_{a,n}$ 分别表示正样本对与负样本对之间的距离， α 为设置的控制类内与类间距离的阈值超参数。Triplet 损失目标是使同类样本对间的距离小于不同类的样本对，从而让网络能够区分不同身份。由于在 Triplet 损失中，构建三元组的方法为随机抽样，没有关注正、负样本对间的难易程度，可能导致大部分三元组都是易于区分的样本对，使网络没有得到充分的学习。本文使用一种改进的 Triplet 损失，即难样本采样三元组损失(triplet loss with batch hard mining, TriHard 损失)^[73]，在每个训练批次中，TriHard 损失三

元组的构建方法为：对每个锚点样本 a ，找出与 a 相同类被但距离最远（最不相似）的作为正样本 p ，与 a 不同身份但距离最近（最相似）的作为负样本 n ，三个样本构成难样本三元组训练网络。当以欧式距离最为样本间相似性的度量函数时，TriHard 损失函数形式为：

$$L_{TriHard} = - \sum_{i=1}^P \sum_{a=1}^K \left[\alpha + \max_{p=1 \dots K} \|f_a^{(i)} - f_p^{(i)}\|_2 - \min_{\substack{n=1 \dots K \\ j=1 \dots P \\ j \neq i}} \|f_a^{(i)} - f_n^{(i)}\|_2 \right]_+ \quad \dots (4.6)$$

其中， $f_a^{(i)}$ 、 $f_p^{(i)}$ 和 $f_n^{(j)}$ 分别为网络对锚点样本、正样本和负样本所提取的特征。基于难样本采样的 TriHard 损失，可以提高模型的识别性能和对困难样本的泛化能力。

本文中，Softmax 损失应用于每个局部分支中的特征向量，即 $\{f_{P_1}^k |_{k=1}^3\}$ 和 $\{f_{P_2}^k |_{k=1}^2\}$ ，对于全局分支，对全局池化后的特征向量 z_G 使用 TriHard 损失，同时对 z_G 经过批归一化后得到的 f_G 使用 Softmax 损失。网络最终损失为：

$$L = \sum_{k=1}^3 L_{softmax}(f_{P_1}^k, W_{P_1,k}) + \sum_{k=1}^2 L_{softmax}(f_{P_2}^k, W_{P_2,k}) + L_{softmax}(f_G, W_G) + L_{triplet}(z_G) \quad \dots (4.7)$$

其中， $W_{P_1,k}$ 、 $W_{P_2,k}$ 与 W_G 表示三个分支中各分类层的权重参数。

4.5 实验

4.5.1 数据集与评价指标

本文分别在 Market1501^[65]与 DukeMTMC-reID^[66]上进行模型的训练和评估。Market1501 数据集采集于清华大学，使用 6 个不同视角和场景的摄像头进行拍摄，其中有一个低分辨率摄像头。数据集共有 1501 个行人，32668 张图像。其中，751 个行人的 12936 张图像作为训练集，其余 750 个行人作为测试集。DukeMTMC-reID 数据集采集于杜克大学，使用 8 个不同视角和场景的高分辨率摄像机进行拍摄，该数据集的行人框由人工标注得到，共有 1812 个行人，36411 张图像。其中，702 个行人的 16522 张图像作为训练集，其余 702 个行人用作测试集。在测试集中，查询集包含其余 702 个行人的 2228 张图像，图库集共有 17661

张图像,除了与查询集相同行人的不同图像以外,还有 408 个未出现在查询集中的行人图像用于识别干扰项。

本文行人重识别模型的评价指标为 rank-k 和平均精度均值 mAP。rank-k 表示在模型返回的排序列表中,目标行人排在前 k 位的概率;mAP 反映了在排序列表中,目标行人在图库中所有图像都排在前面的程度,综合考虑查准率和查全率,能更全面地衡量算法性能。

4.5.2 实验环境与实验设置

本文实验基于 Ubuntu16.04 操作系统,显卡为 NVIDIA GeForce GTX 1080 Ti, 11G 内存,在 PyTorch 深度学习框架下进行模型实现。使用在 ImageNet 上预训练的 ResNet-50 网络权重初始化骨干网络。在训练过程中,输入图像被调整到 384×128 ,使用随机水平翻转和随机擦除进行数据增强,采用随机抽取的 P 个行人,和对每个行人随机采样的 K 张图片构成一个训练批次,实验中 $P=16$, $K=4$ 。本文选择 Adam 作为模型优化器,动量设置为 0.9,用于 l_2 正则化的权重衰减系数为 $5e-4$ 。TriHard 损失中 α 被设置为 1.2。训练共经过 200 轮,对于主网络,初始学习率为 $5e-5$,在前 20 轮线性增加到 $1e-3$,并在第 60 和第 150 轮分别衰减为 $1e-4$ 和 $1e-5$ 。在训练的开端,特征对齐模块的变换参数 θ_{11} 与 θ_{22} 被初始化为 0.9,其余为 0,这使网络从关注特征图的中心区域开始训练,特征对齐模块的学习率设置为主网络的 0.1,避免模型震荡难以收敛。

4.5.3 实验结果

本文与一些具有代表性的行人重识别方法进行比较,其中 PCB+RPP 将行人特征进行水平划分进行局部特征学习; AANet^[67]和 APR^[68]利用人体属性信息来辅助行人重识别任务; BDB 随机擦除一个批次特征的不同区域,以增强局部区域注意力特征的学习; Spindle^[69]和 GLAD^[70]通过检测骨架关键点定位身体部位指导局部特征的学习。另外,AlignedReID^[71]和 PAN 将行人图像或特征进行对齐来提升行人重识别精度。为了简化实验和直观地分析方法本身的有效性,在本文的所有实验中均使用单帧查询模式,且未使用 re-ranking^[72]技术。

表 4.2 展示了在 Market1501 上的实验结果,本文结果列于最后两行,前一

行为只使用全局分支中的特征向量 f_G （2048 维）的测试结果，后一行为将三个分支特征向量进行级联（4608 维）的测试结果。在仅使用 f_G 进行行人相似性度量时，本文方法的 rank-1 精度和 mAP 分别为 94.82 和 85.66，与其它行人重识别方法相比有明显提升。当级联各分支特征进行测试时，本文方法的 rank-1 精度和 mAP 分别达到了 95.31 和 87.49，优于当前大多数行人重识别方法。与同样基于局部特征学习的 PCB+RPP 和 BDB 相比，本文方法的 rank-1 精度分别提升了 1.51 和 1.11，mAP 分别提升了 5.89 和 3.19；PAN 虽然也采用 STN 缓解人体特征不对齐的问题，但 PAN 将网络划分为主分支与对齐分支两个部分，而不是在训练过程中作为一个整体端到端地学习。与 PAN 相比，本文的方法将特征对齐模块嵌入到骨干网络中，是一个完整的端到端架构，特征对齐模块通过优化网络的学习过程，进而促进多尺度特征学习算法更好地发挥作用。在各项指标上，本文的方法相比 PAN 有显著提升。

表 4.2 Market1501 数据集实验结果对比（%）

Table 4.2 Comparison of experimental results on Market1501

方法	mAP	Rank-1	Rank-5	Rank-10
Spindle	-	76.90	91.50	94.60
PAN	63.35	82.81	93.53	97.06
APR	66.89	87.04	95.10	96.42
GLAD	73.90	89.90	-	-
AlignedReID	79.30	91.80	-	-
PCB+RPP	81.60	93.80	97.50	98.50
AANet	82.45	93.89	-	98.56
BDB	84.30	94.20	-	-
Ours（2048）	85.66	94.82	97.98	98.78
Ours（4608）	87.49	95.31	98.01	99.02

在 DukeMTMC-reID 数据集上的实验结果如表 4.3，与其它工作相比，本文的方法同样取得了优秀的表现，当级联各分支特征进行测试时，rank-1 精度和 mAP 分别达到 87.74 和 77.53。与 PCB+RPP 和 BDB 相比，rank-1 分别提升了

4.44 和 0.94，mAP 分别提升了 8.33 和 5.43。进一步验证了本文方法的有效性。

表 4.3 DukeMTMC-reID 数据集实验结果对比 (%)

Table 4.3 Comparison of experimental results on DukeMTMC-reID

方法	mAP	Rank-1
PAN	51.51	71.59
APR	55.56	73.92
PCB+RPP	69.20	83.30
BDB	72.10	86.80
AANet	72.56	86.42
Ours (2048)	75.93	86.45
Ours (4608)	77.53	87.74

图 4.4 展示了给定查询图像，本文方法对其返回的前十位检索结果，查询图像均取自 Market-1501 查询集，并在 Market-1501 图库集中进行检索。在每一行中，错误的检索结果用红色框框出。




图 4.4 给定查询图像的前十位检索结果

Fig 4.4 Top ten search results of some given query images

从前两行可以看到本文的方法对各种姿势和视角下的行人识别具有强大的鲁棒性，即使给定的是一个人的正面图像，其背后视角的图像也得到了正确识别。

在第一行虽然给定的是一个人不完整的背面图像,本文方法依然能准确地找出其在多相机视角下的正确结果,这得益于多尺度特征学习算法,使网络能提取到更丰富、更具代表性的人体特征。同时,当人体在图像中的位置和分辨率具有较大变化时,也得到了正确的识别,特征对齐模块使模型能够更好地适应这些困难样本。

4.5.4 分析与讨论

为了分析多尺度特征学习算法各分支的作用,本文在 Market1501 数据集上进行不同分支的组合实验,实验结果如表 4.4。其中, G 表示仅使用单一全局分支时的实验结果, $G + P_1$ 与 $G + P_2$ 表示全局分支与每个局部分支分别进行组合的实验结果, $G + P_1 + P_2$ 表示结合三个分支的实验结果,即本文方法的最终结果。

表 4.4 Market1501 上不同分支组合的实验结果 (%)

Table 4.4 Experimental results of different branch combinations on Market1501

分支组合	mAP	Rank-1
G	82.87 (83.86)	93.05 (93.75)
$G + P_1$	84.66 (85.39)	93.81 (94.27)
$G + P_2$	85.18 (86.33)	94.12 (94.69)
$G + P_1 + P_2$	85.89 (87.49)	94.42 (95.31)

在仅使用一个全局分支时,由于没有考虑更多局部细节信息,导致所提取的行人特征缺乏判别性,在四个对比实验中,结果明显低于其它三组实验结果;在第一组实验的基础上,当全局分支与两个局部分支分别进行组合时,实验结果均有提升,局部分支的加入增强了模型的识别能力,其中, $G + P_2$ 的实验结果略优于 $G + P_1$, P_2 分支中局部特征的每个列向量在张量 T 上具有相互重叠的感知区域,在局部特征学习的同时,有助于保留更多特征间的相关性; $G + P_1 + P_2$ 作为本文最终方法,获得了最好的实验结果,相比仅使用单一的全局特征, rank-1 与 mAP 分别增加了 1.37 和 3.02,因为每个分支学习不同粒度水平的人体特征,不同分支学习的特征相互补充,进一步增强模型所提取特征的丰富性和表示能力。另外,表 4 中括号中的内容为在不同分支组合下使用特征对齐模块的实验结果,可以看

到，在多项对比实验中，特征对齐模块的加入对结果有进一步的提升。




图 4.5 变换前后特征的可视化示例

Fig 4.5 The visualization example of features before and after transformation

为了直观分析特征对齐模块在整个模型中的作用，对 ResNet-50 中 stage_2 的输出 $U_{stage_2} \in R^{n \times 512 \times 48 \times 16}$ ，通过可视化得到其经过特征对齐模块执行空间变换前后的特征响应图。如图 4.5 所示，抽取的几张示例图像来自于 Market1501 测试集。可以清楚地看到，在特征对齐模块对行人特征图进行空间变换之前，原来的特征图边缘包含大量无用背景信息，且对这些背景信息具有不同程度的高响应，由于无法很好地过滤掉这部分干扰信息，使网络关注到了人体以外的无关区域。此外，各特征图中人体特征的大小和位置具有明显差异，这对模型的学习和识别是不利的。经过特征对齐模块后，变换后的特征丢弃掉了人体特征以外大量无用的背景干扰信息，使高响应聚焦于人体，从而突出图像中包含人体信息的重要部分而抑制背景；在所有的例子中，人体特征图都得到了不同程度上的平移和缩放，变换后的人体特征更靠近特征图的中心区域，得到良好的对齐，这对网络学习行人的判别性表示是非常重要的。

4.6 本章小结

当前一些行人重识别方法对行人提取一个简单的全局特征，无法应对复杂的

行人重识别场景；局部特征学习的方法有助于学习到丰富的人体局部信息，但将行人生硬地划分成多个部分，对每个部分独立地学习该部分的表示，忽略了人体各部分之间的相关性，而部分划分的错误也会影响行人重识别效果。本文提出的多尺度特征学习算法，在多个尺度的特征上学习不同粒度水平的人体信息，同时保留了各部分特征之间的相关性，增强模型所提取特征的表示能力。实验结果表明，多尺度特征学习算法优于单一的全局特征和一般的局部特征学习方法。特征对齐模块通过将不对齐的人体特征执行相应的空间变换，将其调整到适当的大小和位置，增强模型对图像中人体大小和位置差异的适应能力，进一步提升识别精度。本文的方法在两个大型行人重识别数据集上均取得了优秀的识别结果，在接下来的工作，将从实际应用的角度出发，结合行人检测模型完成行人重识别系统的实现和优化。

第5章 结合行人检测的行人重识别技术实现

本章节将之前得到训练的轻量级行人检测模型与行人重识别模型进行结合，完成监控场景下指定目标行人的定位、跟踪和识别。

5.1 实现流程

完整的行人重识别流程实现如图 5.1 所示，系统支持从网络摄像头读取视频流，或输入监控视频文件进行离线视频分析。




图 5.1 行人重识别系统处理流程

Fig 5.1 The workflow of Person re-identification system

首先，选择待检索目标图片作为检索对象 $query$ ，经过预处理后输入行人重识别模块提取特征并归一化得到 f_{query} ；然后，逐帧读取视频中的监控图像，经过预处理步骤输入行人检测模型进行行人检测，之后将检测出的候选行人图像 $candidates$ 输入行人重识别模块提取特征并归一化得到 $f_{c ds}$ ；最后，计算候选行人特征 $f_{c ds}$ 与目标行人特征 f_{query} 之间的欧式距离：

$$d_{query, c ds} = \|f_{query} - f_{c ds}\|_2 \quad \dots (5.1)$$

根据距离计算结果对候选行人图像进行相似性排序，排序结果越靠前代表与目标行人的相似度越高，并根据预先设定的距离阈值 t 对排在首位的候选图像进行判别，本文中阈值 t 设置为 1，当小于该阈值则认为是目标行人，并将该行人图像在当前帧图像中进行标记，再进行下一帧的检测和识别，否则将直接进入下一帧。系统最终保存包含目标行人的视频区间用于事后分析。

5.2 采集测试数据

为了评估本文方法在实际场景下的识别效果,在三个常见的监控场景(街道、围墙周边、广场等)采集多段监控视频并标注,用来对本文方法进行测试。图 5.2 展示了在各监控场景下截取的示例图像。其中,在广场区域采集了白天和夜晚两个不同时间段的监控视频综合评估算法性能。



图 5.2 监控场景图像示例

Fig 5.2 Examples of monitoring scene images

在测试数据集中共包含 15 个行人在不同场景和视角下的 5 段测试视频,因为行人重识别模型需要固定大小的行人图像作为输入,而行人检测提供的行人图像分辨率差异较大,因此在输入到行人重识别模型提取行人特征之前,行人图像统一被调整为 384×128 。本文用 15 个行人在监控视频中裁剪的图像作为查询集 query,利用本文行人重识别系统判断 query 中每个行人在视频中是否出现,若出现则返回该行人在视频中出现的区间用于模型评估。其中,某个行人可能在一段监控视频中未出现,或者以不同的摄像机视角多次出现,对每段监控视频,算法最终返回 5 个 txt 文件,txt 文件名与视频名相对应,为算法返回的对于该视频的输出结果。txt 文件每一行由目标行人出现的开始和结束时间、区间内的一

张具有代表性的目标图片路径以及命中的行人 id 组成，若该行人多次出现则每次出现都会在新的一行进行记录，不同行人的输出结果按照行人的标注 id 依次记录到该 txt 文件。

5.3 系统评估

5.3.1 评估环境

本文系统评估的软硬件环境为：Ubuntu16.04 操作系统，64G 酷睿 6 核 i7-6850K CPU，单块 11G 英伟达 1080Ti GPU。深度学习框架为 PyTorch 1.1，torchvision 0.3，python 3.6。

5.3.2 评估指标

为了降低系统虚警率，若从第一个识别到目标之后的连续 5 帧内均未再次出现该目标，则认为本次识别为一次错误的识别，不输出到 txt 文件；对于成功识别到的目标行人，将第一次识别到该目标行人的帧作为起点 f_0 ，由于实际场景中存在各种复杂情况，例如光照变化或目标受到遮挡，可能导致行人重识别模型短暂的识别失败，但目标仍存在于当前监控区域，若因某一帧未成功识别到该目标就作为本次识别的终点进行保存，最终可能会产生大量包含该目标行人的视频碎片。因此算法判断若持续 25 帧未再次识别到该目标，则认为目标离开当前监控区域，此时作为本次识别终点 f_1 ，并保存 $f_0 \sim f_1$ 的视频区间作为一段输出。在模型评估时，写入 txt 文件的帧区间为 $f_0 \sim (f_1 - 25)$ 。

本文采用 F1-score 与 IoU 作为评价指标对行人重识别系统进行评估，并将两者加权作为系统最终识别准确率，具体计算步骤如下：首先，对于 query 中每个目标行人，分别统计正确识别结果（TP），错将目标识别为其他人（FN），错将其他人识别为目标（FP），根据统计值计算系统对每个行人识别的精度 P 和召回率 R：

$$P = \frac{TP}{TP + FP} \quad \dots (5.2)$$

$$R = \frac{TP}{TP + FN} \quad \dots (5.3)$$

为每个行人计算 F1-score：

$$F1 = \frac{2 \times P \times R}{P + R} \quad \dots (5.4)$$

其次, 对每个行人的识别结果计算 IoU, 设系统返回的目标视频区间为 T_1 , 目标实际出现的视频区间为 T_2 , 则:

$$IoU = \frac{T_1 \cap T_2}{T_1 \cup T_2} \quad \dots (5.5)$$

设目标行人 k 在视频中总共出现了 M 次 (进入镜头到离开镜头为一次), 对该行人的 F1-score 和 IoU 加权平均得到该行人识别准确率 G_k :

$$G_k = 0.5 \times \frac{\sum_1^M IoU}{M} + 0.5 \times F1_k \quad \dots (5.6)$$

最后, 对 query 中所有 N 个行人的识别准确率求平均得到系统综合准确率 G :

$$G = \frac{1}{N} \sum_{k=1}^N G_k \quad \dots (5.7)$$

5.4 测试结果

通过在测试视频上对行人重识别系统进行测试, 得到系统的综合识别准确率为 63.45%, 对视频单张图像的处理速度能够稳定在 32ms, 能满足监控场景下视频的实时处理需求。



图 5.3 不同角度和分辨率下行人重识别结果

Fig 5.3 The results of person re-identification under different angles and resolutions

图 5.3 展示了系统的实际检测和识别效果, 在行人从远及近的过程中, 行人

分辨率和相机角度处于不断变化,系统均能准确识别出目标;虽然给定的是目标的侧身照,但系统对行人的正面、侧面等多种视角具有很好的适应性。首先,行人检测模型为行人重识别模块提供了准确的行人检测框,其次,本文所设计的行人重识别模型具有强大的行人特征提取能力,对行人图像的各种变化具备良好的鲁棒性,保证了行人身份识别的准确性。

为了观察系统在不同场景下的识别表现,对系统进行了跨场景测试,如图 5.4,系统能够很好地适应监控场景的变化,克服监控图像中复杂的干扰因素,实现跨场景的行人重识别。




图 5.4 跨场景行人重识别结果

Fig 5.4 The results of person re-identification in different scenes

通过对系统在视频测试集上返回的 txt 文件进行解析,结果如表 5.1 所示。在前三个白天场景(001~003),系统能够保持良好的精度和召回率,得到比较高的 F1_score;对于 IoU 的计算,由于在目标行人出现的开头和结尾处,行人身体信息不完整,系统返回的区间基本都位于标注的区间之内;另外,行人中途受到遮挡可能会使系统的跟踪区间断开,但标注区间是连续的,这使 IoU 的计算结果略低;在 004 中傍晚时分的低照明场景,系统也能完成良好的检测和识别,但比白天场景中取得的结果要差;005 为在路灯和摄像机补光情况下拍摄的夜晚场景,此时行人检测模型的检测效果不稳定,即使能够检测到行人,但返回的行人检测

框不够准确；同时，行人重识别模型对低光线行人图像提取特征的有效性降低，因此导致系统的综合识别精度较低；在应对遮挡或低照明度等复杂场景时，系统还有待进一步优化。

表 5.1 系统在不同视频中的识别结果比较

Table 5.1 Comparison of system recognition results in different videos

Video name	Precision	Recall	F1_score	IoU	Total score
001	99.99	79.99	88.88	69.87	79.38
002	92.30	79.99	85.71	73.79	79.75
003	88.88	88.88	88.88	77.98	83.43
004	99.99	66.66	79.99	42.65	61.32
005	28.57	13.33	18.18	13.33	15.75
All	86.27	63.76	73.33	53.57	63.45

5.5 本章小结

本章结合所设计的轻量级行人检测模型与行人重识别模型实现了一个简单的行人重识别系统，输入监控视频，系统能够自动检测和识别视频中的目标行人，对系统整体的测试结果表明，在实际监控视频中，系统对各种场景下的行人检测和行人身份识别具有良好的鲁棒性，基本能够完成在监控视频中搜寻特定目标的功能，但行人重识别系统的功能有待进一步完善，识别的准确性仍需进一步提升。

第6章 总结与展望

6.1 总结

本文围绕智能监控场景下的行人检测和身份识别需求,分别设计了轻量型的行人检测模型和鲁棒的行人重识别模型,主要工作总结如下:

(1) 为了更好地完成监控视频中行人快速、准确的检出工作,本文从面向应用的角度出发,在 MobileNetV2 的基础上,设计了一个轻量型的行人检测模型,考虑到视频中的行人尺度变化较大,为了准确检出不同尺度的行人,本文将 MobileNetV2 不同深度下的多尺度特征图进行融合进行行人的多级检测,为了保证整个模型具有较少的参数量和高的检测速度,将每个检测分支设计成基于深度可分离卷积的全卷积结构,实验结果表明本文模型能够很好地应对不同场景下的行人检测工作。在 VOC2007 数据集上,行人检测平均精度达到 88.53%,在参数量和计算量远低于 YOLOv3 的基础上,保证了对行人的检测精度。

(2) 当前一些行人重识别方法对行人提取一个简单的全局特征,无法应对复杂的行人重识别场景;局部特征学习的方法有助于学习到丰富的人体局部信息,但将行人生硬地划分成多个部分,对每个部分独立地学习该部分的表示,忽略了人体各部分之间的相关性,而部分划分的错误也会影响行人重识别效果。本文提出的多尺度特征学习算法,在多个尺度的特征上学习不同粒度水平的人体信息,同时保留了各部分特征之间的相关性,增强模型所提取特征的表示能力。实验结果表明,多尺度特征学习算法优于单一的全局特征和一般的局部特征学习方法。特征对齐模块通过将不对齐的人体特征执行相应的空间变换,将其调整到适当的大小和位置,增强模型对图像中人体大小和位置差异的适应能力,进一步提升识别精度。本文的方法在两个大型行人重识别数据集上均取得了优秀的识别结果。

(3) 结合行人检测实现了一个行人重识别系统,系统将目标行人图像与监控视频作为输入,行人检测模型负责将视频中的行人检出,行人重识别模型判断检出的行人中是否存在目标行人,最终输出含有目标行人的视频区间。经过实验和测试表明,系统具有一定的有效性和实用性。

6.2 展望

行人重识别技术对现代智能监控系统具有重要意义,在公共安防、智能商业、刑事侦查等领域有广阔的应用前景,本文结合行人检测实现了一个行人重识别系统,但仍存在一些不足有待进一步研究:

(1) 本文首先设计了一个轻量级的行人检测模型,达到了更快的行人检测速度,但在行人检测的准确性方面有待进一步加强。监控场景中,行人视角和姿势上都更加多变,且光照变化、运动模糊、低分辨率等均会影响检测结果,需要大量真实监控场景下的数据对模型进行训练,使模型更好地适应监控场景下的行人变化;

(2) 本文所设计的行人重识别模型具有较强的人体特征提取能力,即使行人发生形变或行人检测提供的包围框不精确,也能通过对人体进行空间变换提升识别精度,但行人重识别本身属于跨场景的视觉任务,对每个应用场景都收集数据重新训练模型非常低效,而直接将模型应用到不同的监控场景,其识别准确性将显著下降,半监督、无监督和迁移学习是一个有价值的研究方向;

(3) 本文系统无法很好地处理行人换装和低照明条件下的行人重识别,当行人外观发生变化时,行人重识别模型难以提取到判别性的行人特征,考虑可以在低光照或红外场景下额外训练步态识别模型,辅助行人重识别工作。另外,当行人受到遮挡时,基于候选行人图像与目标图像的共同可见身体区域进行匹配是非常重要的,骨架关键点检测或姿态识别可以为模型提供身体可见性信息,实现更准确的匹配。

参考文献

- [1] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [2] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [3] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.
- [4] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [5] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [7] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]//Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001. IEEE, 2001, 1: I-I.
- [8] Ojala T, Pietikainen M, Maenpaa T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns[J]. IEEE Transactions on pattern analysis and machine intelligence, 2002, 24(7): 971-987.
- [9] Mu Y, Yan S, Liu Y, et al. Discriminative local binary patterns for human detection in personal album[C]//2008 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2008: 1-8.
- [10] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
- [11] Wang X, Han T X, Yan S. An HOG-LBP human detector with partial occlusion

- p handling[C]//2009 IEEE 12th international conference on computer vision. IEEE, 2009: 32-39.
-
- [12] Dollár P, Tu Z, Perona P, et al. Integral channel features[J]. 2009.
- [13] Felzenszwalb P, McAllester D, Ramanan D. A discriminatively trained, multiscale, deformable part model[C]//2008 IEEE conference on computer vision and pattern recognition. IEEE, 2008: 1-8.
- [14] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [15] Van de Sande K E A, Uijlings J R R, Gevers T, et al. Segmentation as selective search for object recognition[C]//2011 International Conference on Computer Vision. IEEE, 2011: 1879-1886.
- [16] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88(2): 303-338.
- [17] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [18] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [19] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. arXiv preprint arXiv:1506.01497, 2015.
- [20] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [21] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Springer, Cham, 2016: 21-37.
- [22] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
- [23] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

-
- [24] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]//2006 IEEE computer society conference on computer vision and pattern recognition (CVPR'06). IEEE, 2006, 2: 1528-1535.
- [25] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C]//2010 IEEE computer society conference on computer vision and pattern recognition. IEEE, 2010: 2360-2367.
- [26] Yang Y, Yang J, Yan J, et al. Salient color names for person re-identification[C]//European conference on computer vision. Springer, Cham, 2014: 536-551.
- [27] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2013: 3586-3593.
- [28] Zheng L, Yang Y, Hauptmann A G. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [29] Zheng Z, Zheng L, Yang Y. A discriminatively learned cnn embedding for person reidentification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2017, 14(1): 1-20.
- [30] Geng M, Wang Y, Xiang T, et al. Deep transfer learning for person re-identification[J]. arXiv preprint arXiv:1611.05244, 2016.
- [31] Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping[C]//2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). IEEE, 2006, 2: 1735-1742.
- [32] Hoffer E, Ailon N. Deep metric learning using triplet network[C]//International workshop on similarity-based pattern recognition. Springer, Cham, 2015: 84-92.
- [33] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1335-1344.
- [34] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern

- p>recognition. 2017: 403-412.
- [35] VARIOR R R, SHUAI B, LU J, et al. A siamese long short-term memory architecture for human re-identification[C]//European conference on computer vision. Springer, Cham, 2016: 135-153.
- [36] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [37] ZHANG X, LUO H, FAN X, et al. Alignedreid: Surpassing human-level performance in person re-identification[J]. arXiv preprint arXiv:1711.08184, 2017.
- [38] ZHENG Z, ZHENG L, YANG Y. Pedestrian alignment network for large-scale person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(10): 3037-3045.
- [39] JADERBERG M, SIMONYAN K, ZISSERMAN A. Spatial transformer networks[J]. Advances in neural information processing systems, 2015, 28: 2017-2025.
- [40] HAN C, YE J, ZHONG Y, et al. Re-id driven localization refinement for person search[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9814-9823.
- [41] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1077-1085.
- [42] Song G, Leng B, Liu Y, et al. Region-based quality estimation network for large-scale person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).
- [43] Sun Y, Xu Q, Li Y, et al. Perceive where to focus: Learning visibility-aware part-level features for partial person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 393-402.
- [44] Dai Z, Chen M, Gu X, et al. Batch dropblock network for person re-identification and beyond[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 3691-3701.

- [45] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 480-496.
- [46] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]//Proceedings of the 26th ACM international conference on Multimedia. 2018: 274-282.
- [47] Fu Y, Wei Y, Zhou Y, et al. Horizontal pyramid matching for person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 8295-8302.
- [48] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [49] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2009, 32(9): 1627-1645.
- [50] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60(2): 91-110.
- [51] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.
- [52] Ghiasi G, Lin T Y, Le Q V. Nas-fpn: Learning scalable feature pyramid architecture for object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7036-7045.
- [53] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.
- [54] 罗浩, 姜伟, 范星, 等. 基于深度学习的行人重识别研究进展[J]. 自动化学报, 2019, 45(11): 2032-2049.
- [55] Zheng Z, Zheng L, Yang Y. Pedestrian alignment network for large-scale person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018,

29(10): 3037-3045.

- [56] Han S, Mao H, Dally W J. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding[J]. arXiv preprint arXiv:1510.00149, 2015.
- [57] Ullrich K, Meeds E, Welling M. Soft weight-sharing for neural network compression[J]. arXiv preprint arXiv:1702.04008, 2017.
- [58] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. PMLR, 2015: 448-456.
- [59] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [60] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [61] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [62] Cao G, Xie X, Yang W, et al. Feature-fused SSD: Fast detection for small objects[C]//Ninth International Conference on Graphic and Image Processing (ICGIP 2017). International Society for Optics and Photonics, 2018, 10615: 106151E.
- [63] Zheng L, Yang Y, Hauptmann A G. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [64] Luo H, Gu Y, Liao X, et al. Bag of tricks and a strong baseline for deep person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 0-0.
- [65] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1116-1124.
- [66] Ristani E, Solera F, Zou R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]//European conference on computer vision. Springer, Cham, 2016: 17-35.
- [67] Tay C P, Roy S, Yap K H. Aanet: Attribute attention network for person re-

- identifications[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7134-7143.
- [68] Lin Y, Zheng L, Zheng Z, et al. Improving person re-identification by attribute and identity learning[J]. Pattern Recognition, 2019, 95: 151-161.
- [69] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1077-1085.
- [70] Wei L, Zhang S, Yao H, et al. GLAD: Global-local-alignment descriptor for scalable person re-identification[J]. IEEE Transactions on Multimedia, 2018, 21(4): 986-999.
- [71] Zhang X, Luo H, Fan X, et al. Alignedreid: Surpassing human-level performance in person re-identification[J]. arXiv preprint arXiv:1711.08184, 2017.
- [72] Zhong Z, Zheng L, Cao D, et al. Re-ranking person re-identification with k-reciprocal encoding[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1318-1327.
- [73] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.

致 谢

时光荏苒，从我收到中国科学院国家空间科学中心的硕士录取通知，转眼间已过去了将近三年时间，我的研究生生涯也即将步入尾声。在这里，我想对所有给予我帮助和支持的老师、亲人、朋友和同学表达由衷的感谢。

感谢我的导师卞春江老师，在步入校园时为我指明研究方向，在日常工作中督促和指导我，给予我充分的时间和机会去学习和丰富专业知识，让我能够顺利开展和完成我的研究工作；

感谢陈实老师，在我课题的选取与开展的整个阶段为我提供帮助，及时指出我工作中存在的问题，与我商讨解决方案，鼓励和支持我的研究工作，让我能够在课题方向上做得更好；

感谢曹谦老师，在我刚步入实验室时带我熟悉实验室环境，并为我在实验室期间的学习和生活上的需求提供帮助；

感谢我的同学与朋友，学习上，我们共同讨论分享经验；精神上，我们彼此鼓励互相陪伴；生活上，我们一起消遣缓解压力，感谢你们让我的研究生生活更加充实；

感谢我的亲人在背后的默默付出，是你们对我的支持和鼓励，让我始终保持积极乐观的心态面对生活；

感谢各位论文评阅和答辩专家为我提出的宝贵意见，愿各位专家工作顺利，身体健康，万事如意！

