

基于多尺度特征的行人重识别技术研究



重庆大学硕士学位论文

(学术学位)

学生姓名：李渊明

指导教师：黄智勇 副教授

学科门类：工 学

学科名称：信息与通信工程

研究方向：图像处理

答辩委员会主席：冯文江 教授

授位时间：2020 年 6 月

Research of Person Re-identification Based on Multi-Scale Features



A Thesis Submitted to Chongqing University
In Partial Fulfillment of the Requirement for the
Master's Degree of Engineering

By

Li Yuanming

Supervised by Assoc. Prof. Huang Zhiyong

June , 2020

摘 要

随着公共安全需求日益增长,我国在校园、公园与街道等公共场所安装了越来越多监控摄像头,建成了世界上规模最大的视频监控网络。为了对获取的视频信息进行高效、可靠的分析处理,催生了许多智能化信息处理技术。行人重识别是智能化信息处理技术的重要代表之一,旨在解决无重叠视域摄像头下行人匹配问题。由于摄像头所获取的行人图像存在低分辨率、部分遮挡等问题,并且存在视角、姿态、光照变化等情况,因此,针对行人重识别研究一直是属于热点问题。

卷积神经网络可充分挖掘图像信息,提取图像特征,正确刻画行人外貌与身份的关系。本文基于卷积神经网络对如何构建一个高性能的行人重识别系统进行了研究,主要工作如下:

①针对全局特征对于行人描述不充分、忽略细节信息,造成识别性能瓶颈的问题,提出一种多尺度特征提取网络。该网络基于卷积神经网络设计,由一个主干网络和三个分支网络构成,每个分支网络输出不同粒度的特征,通过所有特征共同约束,采用分类损失进行训练,充分挖掘行人图像的可判别信息。

②基于空间注意力机制,设计了特征融合模块,与多尺度特征提取网络相结合,形成多尺度特征融合模型。该模块预测特征的重要性分数,根据分数将各分支网络输出的多个特征加权融合,形成融合特征。测试时,将三个分支的融合特征串联作为行人描述符,用于行人检索。实验表明,此模型具有较好的识别精度,充分说明了此方法的有效性。

③针对多尺度特征融合模型未对嵌入空间中的特征距离做出约束,一定程度上影响检索精度。本文引入深度度量学习对网络进行优化,三个分支网络分别添加独立的三元组损失。训练过程中,将度量损失和分类损失共同作为网络总体损失,以最小化总体损失优化网络参数。

④针对行人图像存在不对齐现象,局部分支特征距离计算时会引入错误距离度量的问题,本文提出一种距离融合方法替换特征融合,形成基于区域有效性与多尺度特征相结合的度量学习模型。该方法以交叉对齐策略构造匹配特征对,并通过特征对相似性加权融合,表示总体距离度量函数。其中,本文提出了区域有效性概念,基于区域有效性可自适应地确定加权融合的权重。实验表明,性能指标比多尺度特征融合模型有进一步的提高,充分说明了改进方向的正确性。

关键词: 行人重识别; 卷积神经网络; 多尺度特征; 区域有效性; 交叉对齐

Abstract

With the increasing demand for public safety, our country has installed more and more surveillance cameras in public places such as campuses, parks and streets, and built the largest video surveillance network in the world. In order to efficiently and reliably analyze the acquired video information, many intelligent information processing technologies have been invented. Person re-identification is one of the important representatives of intelligent information processing technology, which aims to solve the problem of pedestrian matching in cameras with no overlapping views. Pedestrian images acquired by the camera have low resolution, partial occlusion and other problems, as well as viewing angles, postures, lighting changes, etc. Therefore, research on person re-identification has always been a front-burner and difficult issue.

Convolutional neural networks can mine image information sufficiently and extract image features so that it can correctly describe the relationship between pedestrian appearance and identity. This thesis studies how to build a high-performance pedestrian re-identification system based on convolutional neural networks. The main work is as follows:

①Regarding the inadequate description of global features for pedestrians and the neglect of detailed information, it causes the problem of identifying performance bottlenecks, A multi-scale feature extraction network is proposed. The network that is designed based on a convolutional neural network is composed of a backbone network and three branch networks. In this network architecture, each branch network outputs features of different granularities. It is trained with classification loss by the constraints of all output features simultaneously in order to sufficiently mine the discriminable information of pedestrian images.

②A feature fusion module was designed based on the spatial attention mechanism. It is combined with multi-scale feature extraction network to form a multi-scale feature fusion model. This module predicts the importance scores of features, and weights and fuses multiple features output from each branch network according to the scores to generate fusion features. In the test stage, the fusion features of the three branches are connected in series as a pedestrian descriptor for pedestrian retrieval. Experiments show that this model has better identification accuracy than the comparison algorithms, which well-illustrates the effectiveness of this method.

③The multi-scale feature fusion model does not restrict the feature distance in the embedded space, which affects the retrieval accuracy to a certain extent. This thesis introduces deep metric learning to optimize the network through adding independent triplet losses into the three branch networks respectively. In the training process, the multiple triplet losses and classification losses are taken together as the overall network loss to optimize the network parameters by minimizing the overall loss.

④In view of the misalignment of pedestrian images, the problem of incorrect distance measurement is introduced when calculating the distance of local branch features. This thesis proposes a distance fusion method to replace feature fusion and construct a metric learning model based on the combination of regional effectiveness and multi-scale features. In the distance fusion method, a matching feature pair is constructed with a cross-alignment strategy, and then use the similarity weighted fusion method to represent the overall distance metric function. In particular, the concept of regional effectiveness is proposed. The weights of weighted fusion can be adaptively determined using the regional effectiveness. Experiments show that the performance is further improved than the multi-scale feature fusion model, which illustrates the correctness of the improvement direction enough.

Keywords: Person Re-Identification; Convolutional Neural Network; Multi-Scale Features; Regional Effectiveness; Cross-Alignment Strategy

目 录

中文摘要	I
英文摘要	III
1 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 行人表征	3
1.2.2 度量学习	5
1.3 本文研究内容与组织结构	6
1.3.1 本文主要研究内容	6
1.3.2 组织结构	7
2 深度学习与行人重识别基础理论简介	9
2.1 深度学习简介	9
2.2 卷积神经网络简介	9
2.2.1 卷积层	10
2.2.2 池化层	11
2.2.3 全接连层	12
2.2.4 激活函数	13
2.2.5 批归一化层	13
2.3 残差神经网络简介	14
2.4 行人重识别相关知识	17
2.4.1 单帧图像行人重识别任务描述	17
2.4.2 行人重识别与图像分类和检索的关系	17
2.4.3 本文实验所用数据集	18
2.4.4 评价指标	20
2.5 本章小结	22
3 基于多尺度特征融合的行人重识别模型	25
3.1 引言	25
3.2 局部特征获取方法	25
3.3 基于多尺度特征的行人重识别方法	28
3.4 多尺度特征提取网络结构	29
3.4.1 主干网络结构	29

3.4.2 多分支网络结构	30
3.5 特征融合模块	31
3.6 实验与结果分析	33
3.6.1 数据集与实验平台	33
3.6.2 模型训练与测试	33
3.6.3 多尺度特征融合模型性能评估	35
3.6.4 与其他方法对比	36
3.7 本章小结	38
4 基于区域有效性与多尺度特征相结合的度量学习模型	39
4.1 引言	39
4.2 基于多尺度特征的深度度量学习	40
4.2.1 深度度量学习方法	40
4.2.2 三元组框架下的多尺度特征度量学习基本模型	41
4.3 局部分支总体距离计算方法	43
4.3.1 基于 GBVS 算法的图像显著性分析	43
4.3.2 区域有效性与特征对联合有效性计算	45
4.3.3 有效性聚合策略	46
4.3.4 基于交叉对齐匹配策略的局部特征总体距离计算	47
4.4 损失函数层设计	50
4.4.1 困难样本挖掘策略	50
4.4.2 多分支度量损失函数	50
4.4.3 网络总体损失	51
4.5 实验与结果分析	52
4.5.1 数据集与实验平台	52
4.5.2 模型训练与测试	53
4.5.3 基于有效性与多尺度特征的度量学习模型性能评估	53
4.5.4 与其他方法对比	55
4.6 本章小结	57
5 总结与展望	59
5.1 本文主要研究内容总结	59
5.2 未来展望	59
参考文献	61
附 录	67
A. 作者在攻读学位期间取得的科研成果目录	67

B. 作者在攻读学位期间参与的科研项目目录	67
C. 学位论文数据集	67
致 谢	69

1 绪论

1.1 研究背景及意义

随着我国经济社会的不断发展,人民群众对自身财产、生命安全的保护意识逐步增强,导致公共安全需求日益增加。目前,各种智能视频监控系统越来越普及,大量的监控设施被部署到城市的各个角落,如主题公园、大学校园、繁华的商业街等。我国有着世界上最大的视频监控网络,在当前大数据、“互联网+”、人工智能等时代背景下,对获取的视频信息进行高效、可靠的分析处理,已经成为计算机视觉领域研究的焦点问题之一。

在监控视频信息的分析与处理中,对感兴趣的目标进行定位、识别、跟踪等操作,是获取有价值信息的必要条件。目前,对于在监控信息中检索特定的人物对象,如公安民警侦破刑事案件,对犯罪嫌疑人进行锁定和追踪时,需要消耗大量时间和精力去查看海量监控录像,经过长时间分析和比对,才能确定可疑的目标。这种高成本、低效率的人工检索方式不仅浪费人力财力,而且可能耽误时间,导致错失抓捕犯罪嫌疑人的最佳时机。在机器智能时代,通过计算机视觉技术替代人工操作,进行高效、精确的搜寻目标无疑是更佳的选择。行人重识别技术的产生正是为了解决上述问题,当前已被广泛关注,成为一个热门的技术方向。




图 1.1 一个端到端行人重识别系统

Fig.1.1 An end to end person re-identification system

行人重识别(Person Re-Identification)也称行人再识别,可视为图像检索的子问题之一,等效于“以图搜图”业务模型,是利用计算机视觉技术,判断不同监控

设备所获取的视频信息中是否存在特定行人的处理过程^[1]。如图 1.1 所示，给定一个行人的待查询图像，然后在其他设备获取的数据中去检索，判断是否存在相应的行人图像。图 1.1 为一个实际场景落地使用的、端到端的行人重识别系统，它的核心部件包含行人检测（Pedestrian Detection）和行人检索(Person Retrieve)两个主要模块。从学术研究领域来说，研究者们一般将行人检测和行人检索划分为两个相对独立的计算机视觉任务^[2]。狭义的行人重识别是指后面一个模块，本文即针对此进行研究。

假设我们已经通过行人检测获取到了视频监控中的行人图像，在完成检索时，仍然面临很大挑战和诸多问题：①目前，视频监控中高清摄像头难以大规模普及，广泛采用的普通摄像头获取的行人图像通常为低分辨率，且具有不同视角、拍摄场景等。在这种相对糟糕的条件下，导致可精确、高效判断行人身份的人脸识别技术通常处于失效状态。研究人员只有从衣着、配饰、体态等方面入手，在有限的人体外表信息中，采用合适的算法，挖掘可判别的信息。②行人通常是活动的目标，在不同时刻、不同地点，姿态差异巨大。并且，行人在活动过程中，可能出现部分遮挡，将导致行人重识别更加困难。③行人所处场景会具有不同背景、不同光照，对于提取行人可判别信息会有较大干扰，影响行人的匹配精度。如何寻求一种有效的方法，克服上述因素对行人重识别造成的困难，正确刻画行人外貌特征与身份的关系，构建一种高精度的行人重识别系统，是学术界主要研究的问题。



图 1.2 通过行人重识别技术实现跨区域身份信息交接

Fig.1.2 Cross-regional identity information transfer through person re-identification

毋庸置疑，行人重识别技术不仅在学术研究中具有挑战性，而且在工程应用中也具有积极意义。行人重识别技术，一方面为刑事侦查、走失救助等需要大量人工排查的公安案件提供快速的信息筛查手段，使办案人员可以更加迅速、简洁地排查、锁定特定目标人物。另一方面，可以解决当前固定摄像头的视域局限，实现跨区域的行人身份信息交接，如图 1.2 所示。为行人实时跟踪、行人理解等应用，提供基础信息支撑。总的来说，开展该项技术的研究工作，不仅可以建立高智能化的公共安全视频监控系统，保障人们出行安全、维持社会稳定，还可以促进图像处理领域及其他相关学科的共同发展。因此，研究行人重识别技术对生产生活、科学研究都有着广泛的理论及现实意义。

1.2 国内外研究现状

自 2006 年 Gheissan 等人^[3]在计算机视觉和模式识别(CVPR)会议上，明确定义行人重识别问题，使其成为计算机视觉领域一个独立的任务以来，国内外学者对其做了大量的研究，并涌现出丰硕的研究成果。通过对这些成果归纳总结，可以发现：行人重识别算法流程主要由两部分构成，即行人表征与距离度量。一个典型的行人重识别系统如图 1.3 所示。当前，对于行人重识别问题的研究主要也集中在这两个方向上，根据研究重心的不同，我们将现有方法分为两类：侧重于研究行人表征和侧重于研究距离度量。本文将按照这种分类方法，对国内外行人重识别研究的主要成果进行详细介绍。




图 1.3 典型的行人重识别系统

Fig.1.3 Typical person re-identification system

1.2.1 行人表征

行人表征即基于特征对行人进行描述，旨在提取能够应对摄像头及环境变化的可区分特征，以表征行人图像的外观。

在深度学习时代以前，通常以设计特征算子的方式提取图像特征，使用最多的就是颜色特征，而纹理特征用得较少。除直接使用低层颜色和纹理特征外，另外一种好的选择，就是使用低层颜色和纹理特征训练分类器，然后提取特征。

Farenzana 等人^[4]充分考虑了人体结构信息,采用加权颜色直方图 (Weighted Color Histogram, WH)、最大稳定颜色区域 (Maximally Stable Color Regions, MSCR) 以及周期高级结构块 (Recurrent High-Structured Patches, RHSP) 来获取不同的图像特征。Ma 等人^[5]结合生物启发特征 (BIF) 和协方差描述符,提出了一种图像表征。Gary 等人^[6]提出一种集成局部特征的算法 (Ensemble of the Localized Features, ELF)。该方法首先将原始图像分割成若干个矩形条;其次,从每个矩形条中提取颜色与纹理等 10 组不同类型的特征;然后,通过 AdaBoost 机器学习算法构造判别式学习模型,将不同种类的简单特征组合为单一的相似性函数。Yang 等人^[7]提出了一种基于显著颜色名称的颜色描述符 (SCNCD),从不同颜色空间中的颜色名称上获得颜色分布,并将其融合以生成特征描述符。在文献[8]中,提出了一种称为局部最大出现 (LOMO) 的新特征表示,它分析了水平方向上局部特征的具体值,对水平方向上每个特征元素,以取最大值的方式形成鲁棒的表征。该方法对于视角的变化具有很强的鲁棒性。就手工特征而言,根据不同规模的数据集、不同的应用场景,需要设计不同的特征算子,因此,其应用范围较窄、可迁移性较差。

进入深度学习时代,研究人员开始使用网络模型替代传统的特征算子,自动获取图像复杂的特征描述。文献[9]作为深度学习行人重识别的开山之作,提出了滤波器对神经网络 (Filter Pairing Neural Network, FPNN)。该方法通过中间层的滤波器输出区块级别的特征,进行二分类完成行人识别。文献[10]提出了一种身份嵌入 (IDE) 模型,该模型将每个身份视为不同的类别,把行人重识别转化为多分类问题。Wu 等人在文献[11]中将手工特征与卷积神经网络特征相结合,充分研究了手工特征与深度特征的互补作用。文献[12]讨论了行人重识别中的验证模型与分类模型,并提出了一种新的孪生网络 (Siamese Network),将二者结合起来。其网络一次输入一对图像,既预测输入图像的 ID,也判断两张图像是否同类别,充分利用了行人的标注信息,学习出了判别性更强的行人描述符。

以上基于深度学习的方法,提取的深度特征以全局特征为主,即整幅图像提取一个特征。不过,随着数据集规模的不断扩大以及应用场景的复杂化,发现全局特征难以达到性能要求,于是引入局部特征。现在主要的趋势是将全局特征和局部特征相结合,作为行人描述符。Cheng 等人^[13]通过设计了一个多通道部件聚合的深度卷积网络,在三元组框架中整合了全局特征与局部特征。类似的,文献[14]提出了多尺度上下文感知网络 (Multi-Scale Context Aware Network, MSCAN),通过堆叠多尺度卷积,获取身体各个部位之间的局部上下文信息。文献[15]提出了一种双流网络,分别提取全局外观和局部身体部件的特征图,并设计了一个双线性池化层将这两个特征图聚合,以增强行人的表征。Zhao^[16]等人提出 Spindle

Net 网络模型。首先，通过人体关键点定位获取到若干个人体结构感兴趣区域（Region of Interest, ROI）；然后，对 ROI 区域以及全图通过 CNN 网络提取特征；最后，通过一个树状结构竞争融合网络将所有特征进行融合，作为行人描述符。

上述方法，通常需要额外的辅助模型（比如：关键点定位或姿态估计模型）来引导局部特征的提取。由于这些辅助模型对于数据和计算资源的需求较大，为了简化模型、提高运行效率，一些简单而有效的策略被提出。Varior 等^[17]将图像分为若干水平区块，依次送入长短时记忆网络（Long Short Term Memory Networks, LSTM）提取特征，并通过一个融合模块，自适应地聚合了水平区域特征形成行人描述符。该方法使得水平特征间有了上下文信息的传播，充分挖掘了空间信息，增强了区域特征的可分辨性。不过，由于该方法依赖于高精度的行人检测框，如果行人图像因为检测框误差而导致空间位置不对齐，则此模型检索时容易误判。针对于此，文献[18]在同样将图像水平分块的基础上，提出了 RPP(Refined Part Pooling)策略。该方法利用部件内部一致性，对划分区域进行微调，从而解决了不对齐问题。而文献[19]从距离计算的角度入手，该方法基于同一身体部位距离最小的假设，采用最短路径的方式计算局部特征距离，从而达到特征对齐的效果。文献[20]则提出 Spatial Interaction-Aggregation(SIA)模块，该模块对空间特征之间的相互依赖性进行建模，然后聚合身体部位相对应的特征。该方法可根据输入行人的姿态和尺寸，自适应地决定局部特征的接受区域，从而使待匹配的两张图片的身体部位达到语义对齐的效果。

1.2.2 度量学习

度量学习(Metric learning) 旨在学习一种新的相似度计算方式，使得同一行人特征之间相似度大于不同行人特征之间的相似度。

传统度量学习方法多数基于马氏距离函数，将距离函数建模为凸优化问题，以数据驱动的方式，迭代优化求解距离函数的参数^[21]。Zheng 等人^[22]于 2011 年，提出概率相对距离比较（Probabilistic Relative Distance Comparison, PRDC）的度量学习方法，首次将度量学习引入行人重识别。该方法在三元组框架下，设计了一个由不同类样本距离减去同类样本距离组成的目标函数，通过最小化此目标函数，得到距离度量的参数矩阵。Kostinger 等人^[23]基于马氏距离提出了 KISSME 方法。该方法首先假设样本对特征差异服从零均值的高斯分布，通过训练数据集直接估计出高斯分布的参数；然后，分别计算任意两样本属于正样本对与属于负样本对的概率，以二者对数似然比定义样本对的差异程度；最后，将对数似然比转化为马氏距离形式，由对数似然比的统计量得到马氏距离参数矩阵。由于该方法不存在复杂的迭代优化过程，所以效率非常高。MA 等人^[24]提出了多任务距离度量学习(Multi-Task Distance Metric Learning, MTDML)算法，用于行人重识别研

究。该方法将行人重识别定义为一个多任务距离度量学习问题，设计了多个相关联的马氏距离度量，以应对典型摄像机网络中存在的复杂条件。为了避免发生或拟合，这些马氏距离的参数矩阵通过添加基于图的正则化进行联合学习。Chen 等人^[25]提出一种新颖的相似性学习方法用于行人重识别。该方法首先通过一种显式多项式核特征映射，刻画两幅图像间所有区块的相似性信息，形成局部区块软匹配；其次，提出一种混合线性相似函数，用以挖掘局部区块的软匹配模式；最后，基于显式多项式核特征映射与马氏距离之间的联系，对相似性函数引入了负半正定正则化以及参数的稀疏性约束，以避免过拟合。Liao 等人^[26]提出一种基于 PSD (Psd Constrained Asymmetric) 约束的高效非对称度量学习方法。该方法在计算样本对距离时，对正样本对采取半正定约束。并且，对正样本和负样本分别采取不同的加权方式。Yang 等人^[27]提出一种大规模相似性学习算法，将度量学习扩展到了大数据集上。该算法以共性和差异性对图像对的距离进行建模。首先，计算训练数据集中正样本对的协方差矩阵；然后，根据共性和差异性，推导出负样本对的协方差矩阵；最后，以二者之差得到距离参数矩阵。

对于采用深度学习技术的行人重识别系统，其度量学习的研究工作主要集中于改善损失函数，以此来优化特征的嵌入空间 (Embedded Space)。文献[28]采用孪生网络模型，使用余弦相似性计算一对行人相似性，并通过均方误差、指数和二项偏差函数构建了不同的对比损失 (Contrastive loss)。文献[29]提出三元组损失 (Triple loss)，其输入为三个样本数据可以构成一对正样本和一对负样本。三元组损失的基本思想，是使负样本对之间的距离应比正样本对之间的距离大于一个预定的间隔 (Margin)。但其缺乏对正样本对或负样本对绝对距离的考虑。因此，文献[13]在三元组损失函数中加入了正样本绝对距离的约束，使得同类样本空间分布更加紧凑。以及文献[30]在三元组损失的基础上进行改进，提出了四元组损失 (Quadruplet loss)。该方法于三元组基础上，在输入数据中增加了一个负样本，用以进一步增大类间间隔 (Inter-Class Margin)。

1.3 本文研究内容与组织结构

1.3.1 本文主要研究内容

本文针对图像的行人重识别展开研究，在当前主流的行人重识别方法基础上，采用卷积神经网络实现行人图像特征提取，设计了一种基于多尺度特征的行人重识别框架，主要研究工作如下：

①提出一种多尺度特征提取网络 (Multi-Scale Feature Extraction Network, MSFE)。该网络基于卷积神经网络搭建，由一个主干网络和三个分支网络构成。三个分支网络采用不同的池化策略，输出多个不同粒度的特征。训练时，每个特

征均对行人 ID 进行预测产生分类损失，并联合所有分类损失对网络进行优化。测试时，将三个分支输出的特征融合，作为行人的整体描述符。

②本文引入了深度度量学习，对多尺度特征提取网络进行优化，提出基于区域有效性与多尺度特征相结合的度量学习模型（Region Effectiveness and Multi-Scale Feature Model, REMSF）。本文在多尺度特征提取网络的三个分支网络中，均加入独立的三元组损失，使三个分支学习不同的距离度量。同时，为了降低模型对行人检测框的要求、缓解不对齐的问题，提出了基于交叉对齐策略与区域有效性的距离计算方法。该方法替换特征融合模块，既用于训练过程中局部分支三元组损失的计算，也用于测试时图像对距离的度量。

1.3.2 组织结构

本文由 5 个章节组成，具体内容如下所述：

第一章：绪论。首先，介绍了行人重识别的研究背景，分析了其研究的意义与难点。然后，介绍行人重识别课题中一些具有重大意义的研究成果。最后，阐述本文研究内容与组织结构。

第二章：基于深度学习的行人重识别基础理论。首先，介绍了卷积神经网络的结构，详细阐述了本文使用的 ResNet 网络模型。然后，介绍了基于单帧图像的行人重识别任务描述，以及其同图像分类和检索的区别与联系。最后，介绍了本文实验所用的数据集，以及两种国际公开的性能评价指标。

第三章：基于多尺度特征融合的行人重识别模型。本章致力于研究行人特征表达，首先提出了一种多尺度特征提取方法，并基于此设计一种行人重识别整体模型。该模型主要包括多尺度特征提取网络与特征融合模块两部分。然后，详细介绍了这两部分的设计原理、结构以及训练方式。最后，在 Market1501 和 DukeMTMC-reID 两个数据集上进行实验，评估模型性能、分析模型的优势与缺陷。

第四章：基于区域有效性与多尺度特征相结合的行人重识别模型。本章主要针对第三章提出的模型进行改进。首先，分析了分类损失与度量损失的区别和联系，并说明了将度量损失引入模型的可行性。其次，将深度度量学习方法与多尺度特征提取网络相结合搭建模型。然后，介绍了训练与测试过程中样本对距离计算方法，该方法包含基于交叉对齐的特征匹配策略、基于区域有效性的特征对权重计算方法两方面内容。最后，通过实验评估模型的性能。

第五章：总结与展望。对全文工作进行梳理，主要针对提出的两种行人重识别模型进行归纳总结，分析了阶段性成果，指出了不足之处。同时展望未来，针对不足之处提出了一些未来的研究方向和工作计划。

2 深度学习与行人重识别基础理论简介

2.1 深度学习简介

长期以来,如何让机器从原始数据或经验中进行学习,从而实现人工智能,是科学界和工业届最为关注的话题之一。当前,深度学习(Deep Learning, DL)已经在图像识别、目标检测与跟踪、语音识别、文本理解、机器翻译等各个领域广泛应用。由于其性能优异,屡屡在测评结果中超越传统方法并打破记录,目前已达到非常高的关注热度。

深度学习的概念起源于人工神经网络(Artificial Neural Network),它通过多重非线性变换构成的处理层,组合底层特征形成高层特征抽象,是一种端到端的层级特征学习算法。深度学习之所以被称为"深度",是相对支持向量机(Support Vector Machine, SVM)、提升方法(Boosting)、最大熵方法等"浅层学习"方法而言的。采用深度学习方法所创建的模型中,打破了传统神经网络对层数的限制,可根据设计者需要选择网络层数。其中,包含了更多的非线性操作层。浅层学习依靠人工经验抽取样本特征,网络模型学习后,获得的是没有层次结构的单层特征;而深度学习通过对原始信号进行逐层特征变换,将样本在原空间的特征表示变换到新的特征空间,自动地学习得到层次化的特征表示,从而更有利于分类或特征的可视化。深度学习理论相较于“浅层学习”方法更加适合用于大量复杂数据的一个理论基础是:如果一个函数可用 k 层结构以简洁的形式表达,那么用 $k-1$ 层的结构表达则可能需要指数级数量的参数(相对于输入信号),且泛化能力不足。

2.2 卷积神经网络简介

卷积神经网络(Convolution Neural Network, CNN)作为一种特殊的前馈神经网络(Feed-Forward Neural Network),是深度学习中最热门和重要的技术之一^[31]。由于特殊的卷积运算操作及复杂多变的结构,CNN 在处理具有类似网络结构的数据时(特别是图像数据),表现出了强劲的性能^[32]。标准卷积神经网络通常由多个不同类别的网络层堆叠而成,主要包括:卷积层(Convolutional layer)、池化层(Pooling Layer)、全连接层(Fully-connected Layer)以及一些辅助层(比如:批归一化层与 Dropout 层)等。不同类型的网络层有着各自的计算方法,体现出不同的功能,其中,参数通常需要通过训练来优化。图 2.1 为 LeNet 模型^[33]的整体结构,它涵盖了常见的网络层,可视为一种标准卷积神经网络。从图 2.1 中可以看到,该网络模型由 7 个网络层级联而成,分别为卷积层、池化层、卷积层、池化层、全连接层、全连接层以及输出层。在训练过程中,输入数据逐层通

过网络，进行前向传播输出结果，通过该结果可定义损失函数，根据损失函数，采用 BP 算法将梯度反向传播，即可优化网络参数。




图 2.1 卷积神经网络 LeNet 模型示意图

Fig.2.1 Illustration of LeNet model of Convolution Neural Networks

2.2.1 卷积层

卷积层是整个网络的核心部件，通常由若干个形状相同、参数各异的卷积核（Convolution Kernel）组成，其通过卷积操作对输入数据进行特征提取，形成更高层次的抽象。卷积层的输入通常是由多个特征图（Feature Map）构成的张量（Tensor），我们将其记为 $\mathbf{X}$ 。每个卷积核都会与输入张量 $\mathbf{X}$ 进行线性卷积，产生新的特征图。假设第 n 个卷积核对输入张量 $\mathbf{X}$ 进行卷积运算，记卷积核参数为 $\mathbf{W}_n$ ，则计算公式如下所示：

$$A_n = \mathbf{X} * \mathbf{W}_n + b_n \quad (2.1)$$

其中， A_n 表示输出的特征图，对于 A_n 中任意一点 (x, y) 有：

$$A_n(x, y) = \sum_{i=0}^{F_1-1} \sum_{j=0}^{F_2-1} \sum_{d=0}^{D_{n-1}-1} \mathbf{X}(x+i, y+j, d) \mathbf{W}_n(i, j, d) + b_n \quad (2.2)$$

其中， F_1, F_2 分别为卷积核的高、宽， D_{n-1} 为输入张量 $\mathbf{X}$ 的通道数。

一个二维卷积示例如图 2.2 所示。从图 2.2 中可以看出，卷积运算的实质，是将卷积核以滑动窗口的形式，在输入特征图上进行遍历。首先，将卷积核中的参数与输入特征图滑窗内的数据对应点相乘；然后，将结果求和，即可得到运算结果。特别地，卷积核在特征图上每次滑动的像素个数称为步长（Stride），记为 S 。此外，在实际处理图像数据的过程中，为了保留图像边缘的信息，通常会在输入特征图四周进行数据填充（Padding）。卷积层输出特征图的尺寸，由输入特征图尺寸、卷积核大小、步长与填充大小共同决定，计算公式下所示：

$$\begin{cases} H_{out} = \frac{H_{in} - F_1 + 2P_1}{S} + 1 \\ W_{out} = \frac{W_{in} - F_2 + 2P_2}{S} + 1 \end{cases} \quad (2.3)$$




图 2.2 二维卷积示例

Fig.2.2 Example of convolution for two-dimension

其中, H_{in} 、 W_{in} 分别为输入特征图宽和高, H_{out} 、 W_{out} 分别为输出特征图宽和高, F_1 、 F_2 分别为卷积核宽和高, S 为步长, P_1 、 P_2 为高和宽的填充大小。

通过分析卷积运算过程,可以发现,卷积层具有两个非常明显的特点:其一、大小为 $F_1 \times F_2$ 的卷积核与输入进行卷积时,输出神经元仅与输入特征图的一部分进行连接,体现了局部连接性。其二、卷积核在特征图上滑动的过程中,其参数是不变的,这就是 CNN 的权值共享机制。

2.2.2 池化层

池化层 (Pooling Layer) 又称下采样层,其以滑动窗口的方式,对特征图上的局部统计信息进行采样。虽然池化层运算操作与卷积层类似,但其不含有任何参数,属于无参数层。常见的池化操作有平均池化 (Avg Pooling) 和最大池化 (Max Pooling) 两种,其公式分别如 (2.4)、(2.5) 所示:

$$y = \underset{i=1}{\overset{M}{\text{avg}}} \underset{j=1}{\overset{N}{\text{avg}}} X_{i,j} \quad (2.4)$$

$$y = \underset{i=1}{\overset{M}{\max}} \underset{j=1}{\overset{N}{\max}} X_{i,j} \quad (2.5)$$

其中 M , N 分别为块长和块宽, i , j 为坐标。

池化操作,一方面在于对输入特征图进行压缩,保留主要信息的同时减少了其空间大小,降低了模型的计算复杂度。不仅提高模型运行效率,而且减少模型所需参数、降低过拟合的可能。另一方面,由于池化操作对空间位置信息不敏感,因此,局部区域内的响应具有良好的平移和旋转不变性。

2.2.3 全接连层




图 2.3 全连接层示意图

Fig.2.3 Illustration of fully connect layer

全连接层 (Fully Connect Layer) 源于人工神经网络,表示该层的每个神经元与前一层输出的每个神经元进行两两连接。该层通常用于网络的末端,它对输入的特征图进行信息整合,实现向特定嵌入空间映射以及分类的作用。图 2.3 为全连接层的示意图,其计算公式如下所示:

$$y_i = f(\mathbf{W}_i^T \mathbf{x} + b) \quad (2.6)$$

其中, y_i 为第 i 个输出神经元的值, $f(\bullet)$ 表示激活函数, $\mathbf{W}_i$ 为参数矩阵, $\mathbf{x}$ 为输入特征, b 为偏置。

与卷积层相比,由于全连接层不具备权值共享和稀疏连接的特点,因此,其参数量远大于卷积层。早期的 CNN 模型中 (例如: AlexNet^[34], VGG^[35]), 通常

会在网络末端使用多个全连接层，第一层将特征图中的各个特征整合到一个特征向量中，最后一层则实现特征向量的投影分类。该类模型通常表现为：网络末端参数量巨大且臃肿不堪，训练时易出现过拟合现象。后续的一些经典模型（如：ResNet^[36]、DenseNet^[37]）针对此类问题，使用卷积和全局平均池化操作（Global Average Pooling）替换多数全连接层，仅在网络末端使用单个全连接层，实现最后的分类功能。此种设计方法不仅减少了网络末端参数，使网络更加轻盈，而且能够达到不俗的性能。

2.2.4 激活函数

为了使网络能够表达出复杂的映射关系，就必须使网络具有非线性建模的能力。因为 CNN 中的卷积层、池化层与全连接层均是线性映射，所以，在 CNN 模型的设计过程中，会采用适当的激活函数，将卷积层与全连接层的输出结果映射到高维非线性空间，从而，使网络拥有更好的表达和泛化能力。对于 CNN 中使用的激活函数，一般必须满足函数非线性且连续可微、原点处近似线性与具有单调性等条件，才能让梯度顺利地进行反向传播，使网络能够进行训练。在 CNN 的工程实践中，Sigmoid、Tanh 和 ReLU 三个函数常作为神经元的激活函数，其表达式如公式（2.7）、（2.8）、（2.9）所示：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.7)$$

$$\text{Tanh}(x) = \frac{2}{1 + e^{-2x}} - 1 \quad (2.8)$$

$$\text{ReLU}(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0 \end{cases} \quad (2.9)$$

2.2.5 批归一化层

随着网络的深度增加，非线性变换前激活输入值的整体分布，会逐渐向激活函数取值区间的上下两端靠近。由激活函数的导数可知：其上下两端的导数趋近于零，反向传播时，低层网络的梯度将会消失。因此，在训练一个深层卷积神经网络时，我们会发现其收敛越来越慢，难以得到较优解。为此，研究人员提出批归一化（Batch Normalization）^[38]，其通过一定的规范化手段对输入值进行标准化，使其服从均值为 0、方差为 1 的标准正太分布。这样，输入值就会落在激活函数较为敏感的区间，其导数值将会增大，从而增强反向传播信息的流动性。批归一化层属于一种辅助的网络结构，可以灵活地嵌入任意模型的任意阶段。

算法 1: 批归一化算法

输入: 一个 mini-batch, $B = \{x_{1,2,\dots,m}\}$, 需要学习的参数 γ , β

$$\text{计算均值: } \mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i$$

$$\text{计算方差: } \sigma_B^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$\text{归一化: } \hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

$$\text{缩放和移动: } y_i \leftarrow \gamma \hat{x}_i + \beta \equiv BN_{\gamma,\beta}(x_i)$$

输出: 归一化后的响应 $\{y_i = BN_{\gamma,\beta}(x_i)\}$

算法 1 中, 第一步: 计算一个 mini-batch 中样本的均值 μ_B 。第二步: 计算样本方差 σ_B^2 。第三步: 对输入样本 x_i 进行标准化得到 $\hat{x}_i$ 。通过上述三步计算, 输入值 $\hat{x}_i$ 已经形成了均值为 0、方差为 1 的正太分布。但是, 此时输入值 $\hat{x}_i$ 大部分会位于激活函数的线性区间, 减少了数据的非线性变换, 使得网络表达能力下降。因此, Batch Normalization 为了保证数据的非线性变换, 对输入值 $\hat{x}_i$ 使用两个调节参数 γ 和 β 进行了缩放 (Scale) 和移动 (Shift) 操作, 如第四步所示。其中, 参数 γ 和 β 需通过网络学习而得。

从 Batch Normalization 算法中我们可以看到: 该算法不仅将输入值进行标准化, 而且, 还将各输入值的差异缩放到同一范围内。一方面, BN 算法增大了反向传播的梯度, 加快训练速度与提高模型收敛程度。另一方面, 它可以使每层输入值具有相同的分布, 从而使网络各层相对独立, 降低了前层网络在训练时参数更新对后层网络的影响。

2.3 残差神经网络简介

随着深度学习网络的发展, 网络的深度对最终的分类识别结果有较大影响, 深度越深, 其表达能力越强、结果越准确。但是, 当深度神经网络达到一定深度后, 继续增加层数并不能带来性能的进一步提高。而且, 常规的网络堆叠很深时, 网络收敛变得更慢, 效果反而变差。这是因为, 每层信息传递都存在损耗和信息丢失, 随着层数增加很容易出现梯度爆炸和梯度消失的现象。一定程度上是反向传播算法的先天不足所致。设更新参数为 $\omega + \Delta\omega$, 在不考虑学习率情况下有:

$$\Delta\omega = \frac{\partial L}{\partial \omega} \quad (2.10)$$

其中, L 为损失函数。

现假设某一网络具有 N 层参数需要更新, 根据 BP 算法^[39]与链式求导法则, 可得出第 m 层的参数更新信息, 如下所示:

$$\Delta \omega_m = \frac{\partial L}{\partial f_N} \frac{\partial f_N}{\partial f_{N-1}} \dots \frac{\partial f_{m+1}}{\partial f_m} \frac{\partial f_m}{\partial \omega_m} \quad (2.11)$$

其中, f_n 表示第 n 层的输出。当 N 很大, 即层数很深时, 若激活函数的导数小于 1, 则梯度逐层指数衰减, 最终梯度消失。若激活函数的导数大于 1, 则梯度的更新指数增加, 梯度爆炸。由于梯度消失或梯度爆炸, 将导致很深的传统卷积网络无法进行训练。针对这一问题, He 等人^[36]于 2015 提出了 ResNet 网络, 其核心组件为残差学习模块, 如图 2.4 所示。




图 2.4 残差学习模块

Fig2.4 Module of residual learning

残差学习模块中增加了直连通道, 允许网络中信息进行跨层传输, 使得下一层网络可以接受到两种级别的信息, 并能够学习它们的残差。假设残差模块的输入是 x , 输出为 $H(x)$, 残差网络学习的目标就是残差 $F(x) = H(x) - x$, 而不是完整的输出 $H(x)$ 。如: 损失函数在 M 层的梯度为 $\partial L / (\partial x_m)$, 在残差网络中其表达式如下所示:

$$\frac{\partial L}{\partial x_m} = \frac{\partial L}{\partial x_M} \frac{\partial x_M}{\partial x_m} = \frac{\partial L}{\partial x_M} \left(1 + \frac{\partial}{\partial x_M} \sum_{i=m}^{M-1} F(x_i, W_i) \right) \quad (2.12)$$

这种旁路直接连接可视为前后层级的断路机制, 能够无损地传播梯度, 并且, 由于网络只需学习其中的差别, 模型的训练会更加容易。因为常数 1 的存在, 即使残差梯度很小、层数很深时, 也不会导致梯度消失。

残差模块在不额外增加参数和计算开销的同时, 提高了模型的训练速度, 且能较好解决网络层数过深时的退化问题。残差网络由残差模块构建, 实际操作中,

常使用两层和三层的残差学习模块，如图 2.5 所示。三层的残差学习模块主要考虑了计算优化，用 1×1 卷积、 3×3 卷积和 1×1 卷积，替换两个 3×3 的卷积层，减少了计算量、同时保持了精度。

由于残差网络具有上述优势，因此，可以往更深的层数发展。不同数量的残差学习模块可以组成不同层数的残差网络，常用的有 50、101、152 层，其网络配置参考表 2.1。通常，残差网络随层数的增大，训练误差会逐渐减小。其不会像传统结构那样，随着网络层数加深导致的训练误差增大。




图 2.5 两种类型的残差学习模块结构

Fig.2.5 Two types of residual learning module structures

表 2.1 不同层数的 ResNet 网络配置

Table 2.1 ResNet network configuration with different layers

Layer Name	Output size	34-layer	50-layer	101-layer	152-layer
Conv1	112×112	7×7 , 64, Stride=2			
Conv2_x	56×56	3×3 , Max-Pooling, Stride=2			
		$\begin{bmatrix} 3\times 3 & 64 \\ 3\times 3 & 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times 1 & 64 \\ 3\times 3 & 64 \\ 1\times 1 & 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times 1 & 64 \\ 3\times 3 & 64 \\ 1\times 1 & 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times 1 & 64 \\ 3\times 3 & 64 \\ 1\times 1 & 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3\times 3 & 128 \\ 3\times 3 & 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times 1 & 128 \\ 3\times 3 & 128 \\ 1\times 1 & 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times 1 & 128 \\ 3\times 3 & 128 \\ 1\times 1 & 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times 1 & 128 \\ 3\times 3 & 128 \\ 1\times 1 & 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3\times 3 & 256 \\ 3\times 3 & 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times 1 & 256 \\ 3\times 3 & 256 \\ 1\times 1 & 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times 1 & 256 \\ 3\times 3 & 256 \\ 1\times 1 & 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1\times 1 & 256 \\ 3\times 3 & 256 \\ 1\times 1 & 1024 \end{bmatrix} \times 36$

Layer Name	Output size	34-layer	50-layer	101-layer	152-layer
conv5_x	7×7	$\begin{bmatrix} 3 \times 3 & 512 \\ 3 \times 3 & 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1 & 512 \\ 3 \times 3 & 512 \\ 1 \times 1 & 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1 & 512 \\ 3 \times 3 & 512 \\ 1 \times 1 & 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1 & 512 \\ 3 \times 3 & 512 \\ 1 \times 1 & 2048 \end{bmatrix} \times 3$
FC	1×1	Average Pool, 1000-d, FC-Softmax			
FLOPs		3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

2.4 行人重识别相关知识

2.4.1 单帧图像行人重识别任务描述

单帧图像行人重识别任务，是指在测试时使用单一图像在候选库（Gallery Set）中进行行人检索，其中，候选库由 N 个图像组成，表示为 $\{g_i\}_{i=1}^N$ 。给定一个查询图像 q （Probe/Query），其身份由下式确定：

$$i^* = \arg \max_{i \in \{1, 2, \dots, N\}} \text{sim}(q, g_i) \quad (2-13)$$

其中， i^* 表示查询出的探针 q 的身份，我们期望 i^* 的结果与 q 的真实身份一致； $\text{sim}(\dots)$ 是某种形式相似性函数。从公式（2-13）可知，设计一个单帧图像的行人重识别系统，几乎等价于设计两张图像的相似度计算方法。

2.4.2 行人重识别与图像分类和检索的关系

在训练和测试（查询）任务之间的关系上，行人重识别是介于图像分类^[34]和实例检索^[40]之间的，如表 2.2 所示。图像分类是给定一幅测试图像，利用训练好的分类器判定它所属的类别，而分类器是利用带类别标签的训练数据训练出来的。对于图像分类，可为每类提供训练图像，并且测试图像一定属于这些预定义的类别之一，在表 2.2 中表示为测试类别“可见”。对于图像检索，通常不是有特定训练数据集可用，因为待查询图像的内容是未知的，并且检索库通常包含各种类型的对象，难以进行具体的分类。所以，在表 2.2 中表示为“不可用”，测试类别表示为“不可见”。

由于训练类别可用且包括不同的身份信息，因此，行人重识别与图像分类是相似的。同时，由于测试类别不可见，行人重识别与图像检索也是类似的，除了训练和测试图像都是行人，它们与训练身份没有重叠。通常，行人重识别可以将图像分类和图像检索的优势进行互补。一方面，可以将距离度量^[41]或特征嵌入^[42-44]应用于训练类别。另一方面，检索时，采用高效的索引结构^[45]和散列技术^[46]可能有利于在大型图库中进行重识别。综上，有效的学习方法和高效的检索方法都应该引入行人重识别系统，并且作为未来发展的重要方向。

表 2.2 行人重识别任务与分类和检索任务的比较

Table 2.2 Comparison of person re-identification tasks and classification and retrieval tasks			
任务	训练类别	测试类别	优势
图像分类	可用	可见	有辨别力的特征学习
图像检索	不可用	不可见	高效
行人重识别	可用	不可见	both

2.4.3 本文实验所用数据集

在行人重识别算法的建模、训练与测试等阶段，数据集起到了至关重要的作用。为此，有许多针对该任务的公开数据集被研究者们陆续提出，使得研究人员和学者们可以在同一标准下，检验和比较不同模型之间的性能。其中，针对深度学习下的行人重识别问题有三个大型数据集被广泛使用，分别为：CUHK03^[47]、Market1501^[48]、DukeMTMC-reID^[49]。本文将使用这三个数据集，用于所提出模型的训练和测试评估，下面对这三个数据集详细介绍。

① CUHK03 数据集



图 2.6 CUHK03 数据集示意图

Fig.2.6 Illustration of CUHK03 dataset

CUHK03 数据集于 2014 年由香港中文大学创建，如图 5.1 所示，是 CUHK 系列数据集的第三个版本，相较于上两个版本，其采集的行人数量、图像规模和处理难度都在增加。在采集 CUHK03 数据集时，使用了位于香港中文大学校园内 10 个、5 对监控摄像头，对 1467 位行人拍摄了 13164 张图像。对于数据集中的每一位行人，均有两个不重叠摄像头下的照片组。CUHK03 数据集按行人边界框的标注方法，可分为两种类型：一是通过手工标注的边界框，称为 CUHK03-labeled；二是通过可变形部件模型^[50]（Deformable Part Model, DPM）检测器自动标注，

称为 CUHK03-detected。考虑到自动标注更适合实际的行人重识别系统，所以，本文选择 CUHK03-detected 类型的数据集进行实验，评估模型性能。根据其数据集所提的新测试协议^[51]，进行实验时将整体数据集划分为两部分，包含 767 个行人组成的训练集和 700 个行人组成的测试集。对于 700 个行人的测试集，每人随机抽取一张图片组成探针集，其余图片作为候选行人库（Gallery）。

② Market1501 数据集



图 2.7 Market1501 数据集示意图

Fig.2.7 Illustration of Market1501 dataset

为了让行人重识别数据集能更好的反映实际场景，悉尼科技大学的研究人员于 2015 年创建了 Market1501 数据集。Market1501 数据集包含 6 个摄像机视角收集的 32668 张图像，且带有 1501 个行人身份标签，同时，使用 DPM 检测器对行人边界框进行标注。该数据集已被研究人员划分为训练集和测试集，其中：751 个行人组成训练集，其余 750 人组成测试集。训练集中一共有 12936 张图像，平均每个行人 17.2 张。测试集一共有 19732 张图像，其中 16364 张图像构成候选行人库，剩余 3368 张图像构成探针集。该数据集在构成测试集的过程中，保证了查询与候选行人均存在多个摄像头视角下拍摄的图像，从而更加客观地测评模型性能。

③ DukeMTMC-reID 数据集

DukeMTMC-reID 数据集是 DukeMTMC 行人跟踪数据集的子集，专门用于行人重识别算法研究。该数据集包含 8 个摄像头视角收集的 36411 张图像，且有 1812 个行人身份的标签，并使用手工的方式对行人边界框进行标注。训练集包含 702 个行人的 16522 张拍摄图像。另外，来自于一个摄像头下的 408 位行人图像作为干扰项。剩余 702 个行人的 19889 张图像则拆分为探针集与候选行人库，其中，探针集包含 2228 张图像，候选行人库包含 17661 张图像。



图 2.8 DukeMTMC-reID 数据集示意图

Fig.2.8 Illustration of DukeMTMC-reID dataset

这三个大型的行人重识别数据集是在不同场景下采集的，并且具有不同的设置。因此，这三个数据集具有代表性和挑战性，可以准确地测试出行人重识别模型的性能。三个数据集的对比信息，如表 2.3 所示。

表 2.3 数据集对比信息

Table 2.3 Comparison information of three datasets

数据集名称	发布时间	行人个数	摄像机数	图像数量	行人标注方法	图像尺寸
CUHK03	2014 年	1467	10 (5 对)	13164	人工/DPM 检测器	不固定
Market1501	2015 年	1501	6	32217	人工/DPM 检测器	128x64
DukeMTMC	2017 年	1812	8	36441	人工	不固定

2.4.4 评价指标

在一个识别任务中，需要用一些国际通用的指标来衡量算法的优劣，本小节将介绍几个用在本文中的评价指标：

①CMC 曲线与 Rank-k 准确率

CMC 曲线 (Cumulative Match Characteristic, CMC) 是模式识别系统重要的评价指标，可以综合测试出算法的优劣。CMC 曲线依据若干个 top-k 击中概率 (Rank-k 准确率) 绘制而成，其中，top-k 表示第 k 次命中的概率。比如：现使用 m 个测试样本和 n 个注册样本 (候选库) 测试模型性能。首先，依次将 m 个测试样本和 n 个注册样本进行距离计算，得到结果为 $m \times n$ 的距离矩阵；然后，对结果按从大到小排序，得到 m 个排序列表；最后，计算 m 个排序列表中任意位置 k 的击中概率，取 m 个概率值的均值即为模型的 Rank-k 准确率。根据 Rank-k

准确率与 k 的关系，绘制二维曲线即可得到 CMC 曲线。

假设候选库有三个样本，属于三类 (Class n)，每类存在一个测试样本 (Test n)。同时设置了距离函数，距离越小说明相似度越大，则越可能为同一类。现对模型进行测试，计算样本距离矩阵，结果如表 2.4 所示。

表 2.4 测试样本距离矩阵

Table 2.4 Distance matrix of test samples			
	Class 1	Class 2	Class 3
Test 1	0.1	0.2	0.3
Test 2	0.2	0.1	0.2
Test 3	0.2	0.3	0.1

表 2.4 中为较理想状况，每个测试样本与本类的相似度最大。如果存在上述情况（每一类对应的测试样本与其距离最小），则说明此模型 $\text{rank1}=100\%$ ， $\text{rank2}=100\%$ ， $\text{rank3}=100\%$ ，等价于一次命中。一般情况下，Rank-1 小于 1，而 $\lim_{k \rightarrow \infty} \text{Rank} - k$ 的值趋于 1。也就是说，给的机会越多（即查找次数越多），成功率越大。如果一个样本按照匹配程度从大到小排列，最后一项才匹配到正确标签，则说明模型性能不太好，无法成功判别出最佳匹配项。

②mAP (Mean Average Precision)

一般而言，候选库中同一身份的图像数量不止一个，我们希望一个好的行人重识别系统能够将其全部检索出来。此时，需要某个指标来反映检索出的数量，但 Rank- k 准确率并不能满足这种需求。为此，研究人员提出了 mAP (Mean Average Precision) 指标。mAP 表示平均精度均值，它由召回率 (Recall) 与正确率 (Precision) 共同决定，可以更加全面的衡量模型的性能。对于行人重识别任务，正确率 (Precision) 为 K 个排序结果中，身份与 Probe 一致的图像数量占总数的比例，即：

$$P = \frac{k_c}{K} \quad (2.14)$$

其中， k_c 表示身份匹配的图像数量。

召回率即查全率，表示 K 个排序结果中与 Probe 身份相匹配的图像数量，同候选库中所有与 Probe 身份相匹配的图像数量之比，计算公式如下所示。

$$R = \frac{k_c}{k_c + k_f} \quad (2.15)$$

其中， k_f 表示候选库中身份与 Probe 相同但未被检测出来的数量。

假设给定一个 Probe，候选库中与之身份相匹配的图像数量为 N ，使排序结果数量 K 从 1 开始逐渐增大，可计算出 N 个召回率，分别为 $1/N, 2/N, \dots, N/N$ 。用 $R_i = i/N$ 表示任意一个召回率，其中 $i \in [1, N]$ 。对于任意 R_i ，在最小化排序结果数 K 的情况下，可以计算出此召回率下模型最大的正确率，记为 P_i 。则单个 Probe 的平均精度(Average Precision, AP)计算如下所示：

$$AP = \frac{1}{N} \sum_{i=1}^N P_i \quad (2.16)$$

mAP 则表示对所有 Probe 平均精度 (AP) 取均值，可用表 2.5 和图 2.9 来形象的说明 mAP 是如何计算的。




图 2.9 mAP 计算示意图

Fig.2.9 Illustration of calculation for mAP

表 2.5 mAP 计算过程

Table 2.5 Calculation process of mAP

recall	1/5=0.2	2/5=0.4	3/5=0.6	4/5=0.8	5/5=1
Ranking	1	3	6	9	10
Precision	1/1=1	2/3=0.67	3/6=0.5	4/9=0.44	5/10=0.5

首先，根据查询结果得出所有召回率对应的最小 K 值；然后，计算每个 K 值下的 Precision。由表 2.5 可知，这一次查询检索平均精度 (Average Precision) 为： $(1+0.67+0.5+0.44+0.5)/5=0.62$ 。若取多张测试图像进行多次查询检索，可得多次平均精度，将其取平均值，即为 Mean Average Precision。

2.5 本章小结

本章首先介绍了卷积神经网络基础知识，主要阐述了其基本结构及功能。其

次，介绍了残差网络模型，讲解了残差模块的设计思想、原理以及作用。然后，介绍了基于单帧图像的行人重识别任务描述，并说明了其与图像分类和检索的区别与联系。最后，介绍了本文实验将使用的三个公开数据集以及两种性能评价指标。

3 基于多尺度特征融合的行人重识别模型

3.1 引言

在行人重识别问题中,由于摄像头所获取的行人图像具有低分辨率、部分遮挡等特点,且存在视角、姿态、光照变化等情况,相同身份的行人特征通常在视觉上有很大的差异,如何克服类内差异,提取一种具有类内不变性的行人描述符,是一个非常有挑战性的问题。受益于近几年卷积神经网络(Convolutional Neural Network, CNN)技术的飞速发展,大量的研究人员利用 CNN 可以自动挖掘高维数据信息的能力,将其应用于行人重识别中,用以提取特征作为行人描述符。通过训练 CNN 以自动提取特征的方法,我们一般称其为表征学习(Representation Learning)。从表征学习的角度来看,提取的特征按空间结构,可以分为全局特征(Global Feature)和局部特征(Local Feature)。在早期的工作中,如文献[9]使用 CNN 直接从整张图片提取一个全局特征,并用此进行对比查询。虽然,全局特征可以从整体上作为行人的描述符,但是,一方面由于行人图像因背景、姿态、光照变换、部分遮挡会包含过多噪声;另一方面,通常用于 CNN 训练的数据集有限,并且缺乏足够的多样性,全局特征会忽略一些不突出或不常见的细节信息,某些有用的局部信息不会对最终的行人描述符作出贡献。如果直接用其作为行人描述符进行检索,则会导致其单一特征很难适应类内差异,检索性能较差,难以取得较好的识别精度。

为了突破全局特征的局限,研究人员开始从图像中提取人体重要部位的局部信息,该方法已被证实是提高行人身份识别准确性的有效途径^[19,52,53]。通过 CNN 网络共同学习全局信息和局部信息,可以使 CNN 网络关注到更多身份信息。并且将局部信息作为全局信息的补充,共同作为行人的描述符,可使描述符更加鲁棒、更适应类内差异性,使检索精度达到满意的效果。

在本章中,我们提出一种基于 CNN 的多尺度特征提取网络,通过多个粒度下的各个特征共同约束,使网络能够挖掘到更多的判别性信息。并且,进一步探究多尺度下各个特征之间的关系和重要性,对多尺度特征进行融合,形成一个行人的整体描述符,用于测试阶段的行人检索。我们将上述方法(基于多尺度特征融合模型)作为一个整体框架用于行人重识别,在 Market1501, DukeMTMC-reID 两个主流数据集上进行综合实验,取得较高的实验结果和性能。

3.2 局部特征获取方法

局部特征通常需要从行人各个身体部件(Part)或某些局部区域进行特征提

取, 然后再进行融合, 关键在于如何生成行人的各个部件或局部区域。目前, 生成行人部件或局部区域存在两种主流方法, 分别为基于姿态点估计^[54]的方法和基于水平分块^[18]的方法。

① 基于姿态点估计




图 3.1 基于姿态点估计的行人局部区域获取

Fig.3.1 Acquisition of person local region based on pose estimation

基于姿态点估计产生行人局部区域的方法, 如图 3.1 所示。首先, 利用人体姿态点估计模型, 获取到行人图像的多个姿态点; 然后, 将相邻的姿态点相连, 形成人体的骨架信息; 最后, 通过人体骨架信息, 从行人图像中划分出具有语义信息的人体部件区域, 如: 行人头部、上半身和下半身。对行人各个语义部件进行特征提取后, 所获特征可以视为具有真实语义信息的局部特征。该方法最大的特点, 是在行人匹配阶段, 可以使行人的局部特征得到严格语义对齐, 如: 头部与头部进行匹配; 上半身和上半身进行匹配。

② 基于水平分块




图 3.2 基于水平分块的行人局域区域获取

Fig.3.2 Acquisition of person local region based on horizontal partition

基于水平分块的方法，如图 3.2 所示。其不借助行人的姿态点估计等外部信息，直接对行人图像进行水平分割，将原始行人图像自上而下分为多个 Part。对分割出的每个 Part 进行特征提取，得到局部特征。

本文在基于水平分块方法的基础上，提出一种多尺度的行人局部特征提取方法，如图 3.3 所示。我们将行人图像按照不同的分块数，进行一种由粗到精的划分，分别是：不划分、平均划分为 2 块 Part 和平均划分为 4 块 Part。行人图像不划分时，为最粗糙的情况，将其按照垂直方向平均分为 4 个 Part 时，为最精细的情况。对于每种划分方法，我们都采用 CNN 对每块 Part 进行特征提取，并将这三种情况下提取的特征作为特征集合，形成行人的描述符进行匹配。




图 3.3 多尺度特征提取方式

Fig.3.3 Method of multi-scale feature extraction

随着行人图像由粗糙到精细的划分，CNN 将在不同划分尺度下，从不同大小的 Part 中学习精细度不同特征。比如：第一层中，行人图像未进行划分，CNN 将从行人整体图像学习出一个粗糙的特征，即行人全局特征。全局特征代表行人整体的近似描述，这种描述会忽略一些不突出的细节信息；第二层中，将行人分为两个不同的部分，网络将从这两个部分去学习出两个不同的、较为精细的局部特征。由于行人区域被细分，网络从局部去学习特征，因此，将产生对行人局部

的描述，用于挖掘全局特征中所忽略的某些细节。随着分割数量的增加，网络所观察的区域越精细，提取的特征将更加精细，挖掘的局部信息将更丰富。自然而然，我们联合所有由粗到精的特征作为行人描述符时，描述符所包含的信息将更加丰富，也更具有判别力。本文将这些精细度不同的特征，称为多尺度特征。利用多尺度特征构成行人描述符，进行行人匹配时将增加识别的准确率。

这种描述符的设计方式，也非常符合日常生活中我们对行人的观察和识别。当我们去识别一个行人时，如果整体上难以进行分辨，可能就会进一步去观察他局部一些细节信息，比如：行人的发型、所携带的物品以及服饰上是否有特殊的 LOGO 等不同尺度的信息。最终通过细节和整体的信息综合判断，得以完成行人的识别。

3.3 基于多尺度特征的行人重识别方法




图 3.4 基于多尺度特征的行人重识别总体框架

Fig.3.4 Person re-identification overall framework based multi-scale features

根据上一节分析的基于局部特征的行人重识别方法，本文利用卷积神经网络，采用水平分块的局部特征提取策略，设计一套基于多尺度特征的行人重识别方法，整体框架本文称为多尺度特征融合模型 (Multi-Scale Feature Fusion Model, MSFF)，如图 3.4 所示。首先，使用多尺度特征提取网络 (Multi-Scale Feature Extraction Network, MSFE) 获取三种粒度下的特征集合，网络具体细节将在 3.4 节详细介绍；然后，采用特征融合模块将每个尺度下的特征集合，融合为单个特征，本模块于 3.5 节详细介绍；最后，将三种尺度的融合特征串联起来，作为行人描述符用于测试阶段的行人检索。

3.4 多尺度特征提取网络结构

为了实现由粗到精、三层粒度的多尺度特征提取，本节搭建了一个三支的 CNN 网络，如图 3.5 所示。其主要结构，由一个参数共享的主干网络（BackBone Network）加上三个独立的分支网络组成，各个分支与 3.2 节的行人分块方法相对应，进行特定尺度的特征提取。其中：第一个分支可视为全局特征分支，第二、三分支为局部特征分支。为了增强所有尺度下每个 Part 判别性信息的提取，独立地让每个特征预测行人 ID，产生相应的分类损失用于网络训练。




图 3.5 多尺度特征提取网络结构

Fig.3.5 Network structure of multi-scale feature extraction

3.4.1 主干网络结构

主干网络首先对输入的行人图像进行低级别、通用的特征提取，输出行人图像的初级特征图（Feature Map），并将其作为三个多尺度分支网络共同的输入。主干网络在 ResNet50 网络^[8]的基础上进行修改而实现，其结构如表 3.1 所示。具体来说，主干网络使用 ResNet50 网络的前 4 个卷积组合模块，即：去掉原始 ResNet50 网络的 Conv5X 组合模块及其之后的部分。

表 3.1 主干网络结构

Table 3.1 Structure of backbone network

Layer#	Layer	Output Size	Backbone
1	Conv1	384×128	$7 \times 7, 64, \text{stride} = 2$

Layer#	Layer	Output Size	Backbone
			$3 \times 3, \max_pool, stride = 2$
9	Conv2_x	192×64	$\begin{bmatrix} 1 \times 1 & 64 \\ 3 \times 3 & 64 \\ 1 \times 1 & 256 \end{bmatrix} \times 3$
9	Conv3_x	96×32	$\begin{bmatrix} 1 \times 1 & 128 \\ 3 \times 3 & 128 \\ 1 \times 1 & 512 \end{bmatrix} \times 4$
9	Conv4_x	48×16	$\begin{bmatrix} 1 \times 1 & 256 \\ 3 \times 3 & 256 \\ 1 \times 1 & 1046 \end{bmatrix} \times 6$

从网络整体上来看，各个独立的分支共享一个主干网络。一方面，可以利用残差网络的跨层连接特性，在保证有足够深度的网络条件下，提取图像鲁棒特征，同时使得网络易于训练且不会造成性能退化。另一方面，多个分支共同训练，实际是一个多任务的学习过程。因 CNN 的中低层特征不具有较高的语义信息、主要关注图像结构等粗糙的信息，故对于多个任务来说具有通用性。因此，采用共享中、低层参数，将大大减少整个模型的参数和运算量，不仅提高训练和测试的速度，而且还能降低模型过拟合的风险。

3.4.2 多分支网络结构

本文将图像通过主干网络的特征图记为 X ，表示作为多分支输入的共享特征图。每个分支网络独立地对特征图 X 进行特征提取，获得不同尺度和不同数量的特征。

首先，在多尺度分支里，输入的特征图 X 通过各分支独立的 Conv5_x 卷积模块，得到各个分支的特征图 X_N ($N = 1, 2, 3$)，其中，Conv5_x 卷积模块为 ResNet50 网络的第五个阶段。由于对行人图像分块是为了提取更加精细化的局部特征，因此，将两个局部分支（除了第一层的所有分支）中，Conv5_x 卷积模块的卷积步长（Stride）修改为 1，以获得分辨率更高的特征图 X_N ，增强网络挖掘细节信息的能力。

然后，对于各个独立分支中的特征图 X_N ，均通过如下两个步骤，输出最终的特征向量集合，用于行人 ID 预测完成表征学习。

①特征图水平分块与池化：

对于第 N 个分支，将其特征图 X_N 沿垂直方向均匀分为 P 块 ($P = 2^{N-1}$)，得到 P 个水平条纹（Stripe）组成的集合，记为 $S_N = [X_{N1}, X_{N2}, \dots, X_{NP}]$ ($P = 2^{N-1}, N = 1, 2, 3$)。然后对每个水平条纹进行池化操作，将其转化为 P 个向量。

特别地，考虑到多尺度框架中三个分支所提取特征的特点，三个分支采取了不同的池化策略。对于全局特征分支采用平均池化操作，使其输出特征可以感知特征图中每个空间位置的信息，并且将背景上下文考虑在内。其余两个局部特征分支采用最大池化策略，只提取最具判别性的信息，而忽略其他干扰信息。

②特征降维：

由于特征图的通道数为 2048，此时特征向量的维度将达到 2048 维。该维度无论对于分类任务还是检索任务均显得过于庞大，因此，在本章所提模型中，通过一个 1×1 的卷积层将其维度降至 256 维，以利于后续操作。为了便于后续描述，将第 N 分支降维后的特征向量集合记为 $F_N = [\mathbf{f}_N^1, \mathbf{f}_N^2, \dots, \mathbf{f}_N^P]$ 。

最后，每个分支中的所有特征向量，均被送入 P 个独立的分类器预测行人标签，其分类器为线性层加上 Softmax 函数组成，如公式 (3-1) 所示。

$$P(y_i | \mathbf{f}) = \text{softmax}(\mathbf{W}_i^T \mathbf{f}) = \frac{\exp(\mathbf{W}_i^T \mathbf{f})}{\sum_{j=1}^C \exp(\mathbf{W}_j^T \mathbf{f})} \quad (3-1)$$

其中， $P(y_i | \mathbf{f})$ 表示分类器预测特征向量 $\mathbf{f}$ 属于标签为 y_i 的行人的概率， C 表示行人的类别总数。 $\mathbf{W}_j$ ($j=1, 2, \dots, C$) 表示线性层将特征 $\mathbf{f}$ 映射到第 j 类的权重向量。

在训练阶段，每个分类器作为独立的子分类任务，产生分类损失，并通过交叉熵 (Cross Entropy Loss) [55] 可计算其分类损失。如下所示：

$$L(N, j) = -\frac{1}{n} \sum_{i=1}^n \log(P(y_i | \mathbf{f}_N^j)) \quad (3-2)$$

其中， $L(N, j)$ 表示第 N 个分支中第 j 个分类器所产生的损失， y_i 为 $\mathbf{f}_N^j$ 所对应行人的标签， n 为训练时一个训练批次 (Batch) 的大小。

根据公式 (3-2)，可得第 N 个分支的损失 L_N 和多尺度特征提取网络总体损失 L_{total} ，分别为：

$$L_N = \sum_{j=1}^P L(N, j), P = 2^{N-1} \quad (3-3)$$

$$L_{total} = L_1 + L_2 + L_3 \quad (3-4)$$

从网络总体损失中可看到，多尺度特征提取网络一共输出 7 个不同粒度的特征，每个特征均会产生独立的分类损失。

3.5 特征融合模块

由于行人姿态各异、存在遮挡情况，并且含有某些相对突出的部位，导致不同区域的判别性信息存在差异。因此在匹配过程中，从不同区域提取的局部特征不能同等对待，应体现每个局部特征的重要性。如图 3.6 所示，其中 s_i 表示每个

特征的重要性。




图 3.6 行人部件特征的重要性

Fig.3.6 Importance of part feature of person

针对每个区域提取出来的信息具有不同重要性的问题，本节引入了一个权向量 $\mathbf{S}$ ，来度量特征的重要性，同时，希望每个局部特征的重要性都能够在匹配过程中动态地进行计算。文献[56]提出一种特征级别的注意力机制来自适应计算各个特征得分，通过得分，高效地选择出有价值的特征子集。受上述工作的启发，我们对其略微改动，采用弱监督学习的方式来估计每个特征的重要性得分。




图 3.7 特征融合模块

Fig.3.7 Illustration of feature fusion module

特征模块基于空间注意力机制设计，由 2 层卷积网络搭建而成，如图 3.7 所示。局部分支中，Conv_5x 卷积模块输出的特征图 X_N ，经过两次 1×1 的卷积操作转化为 1 个矩阵 A_N ，矩阵中每个元素 $a_{i,j}$ 的值，可视为每个空点间的重要性。然后，将矩阵 A_N 按照水平分块策略，在垂直方向上平均分为 P 块 (P 为对应分支的水平分块数)，并对每块中的所有元素进行求和，得到一个权向量 $\mathbf{W} = [w_1, w_2, \dots, w_P]^T$ ，向量中的每个分量代表每一块区域的重要性。将权向量 $\mathbf{W}$ 按

照公式 (3-5) 进行归一化操作, 转化为表示特征重要性得分的权向量 $\mathbf{S}$, 记为 $\mathbf{S} = [s_1, s_1, \dots, s_p]^T$ 。

$$s_i = \frac{\exp(w_i)}{\sum_{j=1}^p \exp(w_j)} \quad (3-5)$$

对于第 N 个分支其特征集合为 $F_N = [\mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_p]$, 将根据重要性得分进行线性加权融合, 得到最终的融合特征 $\mathbf{f}_{Branch_N}$, 如公式 (3-6) 所示。

$$\mathbf{f}_{Branch_N} = \sum_{i=1}^p s_i \mathbf{f}_i \quad (3-6)$$

在优化特征融合模块的两层卷积层参数集合 θ 时, 仍然采用分类损失进行训练, 其分类损失由融合特征 $\mathbf{f}_{Branch_N}$ 产生, 如公式 (3-7) 所示:

$$L = - \sum_n \log \frac{\exp(W_{y_i}^T \mathbf{f}_{Branch_N})}{\sum_j \exp(W_j^T \mathbf{f}_{Branch_N})} \quad (3-7)$$

其中, W_j 表示将融合特征预测映射为第 j 类的权重向量, y_i 为行人真实标签。

在测试阶段, 每个局部分支输出最终的融合特征 $\mathbf{f}_{Branch_N}$, 将两个局部分支不同尺度的融合特征于全局特征串联起来, 作为行人描述符用于测试阶段的行人检索。

3.6 实验与结果分析

3.6.1 数据集与实验平台

本章将在 Market1501 和 DukeMTMC-reID 两个主流行人重识别数据集上进行实验, 综合评价多尺度特征融合模型的性能。模型部署于 Pytorch 深度学习框架, 在 Ubuntu 操作系统下, 使用 GPU 进行网络训练, 具体实验环境如表 3.2 所示。

表 3.2 实验环境配置

Table 3.2 Configuration of experimental environment

环境项目	配置参数
系统平台	Ubuntu 16.04 LTS, 64 位
编程软件	Python3.6, Pytorch1.0
CPU	Intel® Xeon(R) E5-2649 2.30GHz, 20 核, 32GB 内存
GPU	GeForce GTX1080 Ti, 11GB 内存

3.6.2 模型训练与测试

① 模型训练方法

由于特征融合模块的参数需要通过输入给定特征, 才能进行训练优化, 而多

尺度特征提取网络收敛之前，其输出的特征没有实际意义、不具备有效性，不能作为特征融合模块的输入。因此，整个多尺度特征模型（MSFF）不能进行端到端训练。否则，特征融合模块会因为输入无效特征，向错误方向收敛，从而产生弱模型。基于此，整个模型的训练过程应分为两个阶段：第一个阶段，只训练多尺度特征提取网络，待其收敛后，方可认为提取的行人特征具备有效性。第二阶段，固定多尺度特征提取网络参数，并加入特征融合模块，只训练特征融合模块中两个卷积层的参数。具体训练步骤如下。

第一阶段：

1) 使用在 ImageNet 上预训练模型的参数初始化模型的主干网络，以及各分支的 Conv_5 卷积模块的参数，其他参数使用随机初始化。分支网络参数部分使用 dropout 策略，防止过拟合，其丢弃概率设置为 0.5。

2) 随机选取训练集中的行人图像，构造一个训练批次，批次大小 Batch_Size 设置为 32。将每张图片缩放到 256*128 大小，并采用 0.5 概率的随机水平翻转和随机裁剪，作为数据增广策略。

3) 将所有图像的像素值除以 255，使其缩放到[0,1]区间。然后，对每张图片 RGB 三个通道每个像素点的值减去均值，并除以方差进行标准化。其中，RGB 三个通道的均值和方差，分别为：[0.484, 0.456, 0.406]和[0.229, 0.224, 0.225]。

4) 计算多尺度特征提取网络总体分类损失，采用小批量梯度下降法（Mini-batch Gradient Descent, MBGD）更新网络参数。其中，初始学习率、动量和权重衰减因子分别设置为 0.01、0.9 和 0.0005。

5) 重复 2~4 步骤，直到迭代训练了 80 个 epoch。一个 epoch 表示将训练集中所有图片全部训练完一次。学习率从第 30 个 epoch 开始，每 10 个 epoch 就衰减为原来的一半。

第二阶段：

1) 固定多尺度特征提取网络参数，加入两个局部分支网络的特征融合模块。其中，特征融合模块的参数采用随机初始化。

2) 训练批次构造和数据预处理方式与第一阶段②、③步相同。

3) 按照公式 (3-7)，计算两个特征融合模块的损失，采用小批量梯度下降法（MBGD）更新网络参数。其中，初始学习率、动量和权重衰减因子，分别设置为 0.001、0.9 和 0.0005。

4) 重复 2~3 步骤，直到迭代训练了 20 个 epoch，并且学习率 10 个 epoch 衰减为原来的 0.1。

在第二阶段训练时，使用较小的学习率和较小的迭代次数，主要考虑到融合模块只具有两个卷积层的参数，少量迭代训练即可使其收敛。通过以上两个阶段

的训练,可得到训练完成的多尺度特征融合模型 (MSFF)。

② 模型测试方法

待模型训练完成后,首先,将测试集中的所有图像依次输入多尺度特征融合模型,得到每张图像的描述符向量;然后,计算出每张待查询图像描述符与 Gallery 中所有图像描述符之间的欧式距离;最后,将 Gallery 中所有图像按照距离从小到大排序,即可得出 Rank-k 准确率和 mAP。

3.6.3 多尺度特征融合模型性能评估

本章所提出的多尺度特征融合模型,可以从行人原始图像提取多个粒度下,从粗到精的多个特征。为了验证各个粒度下的特征能使行人信息互补,从而形成健壮的行人描述符,首先研究各个粒度对应的分支独立工作性能和相互组合性能。一共设置了 4 组分离实验与多尺度模型进行对比,探究各个分支的不同作用。其中: Branch1、Branch2、Branch3 表示独立使用单个分支进行实验; Branch (1+2) 表示除去第三分支,仅联合 1、2 分支进行实验。5 组实验的 Rank-k 准确率与 mAP 值,如表 3.3 所示。

表 3.3 不同分支组合在 Market1501 数据集上的性能

Table 3.3 Performance of different branch combinations on Market1501 dataset

分支网络	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP(%)
Branch1	83.8	92.9	94.6	67.7
Branch2	86.2	94.2	95.8	74.1
Branch3	89.3	95.7	97.8	77.1
Branch(1+2)	88.0	94.8	97.3	74.3
MSFF	92.0	96.9	98.2	78.3

从表中数据可以看出:其一、局部分支的性能指标 Rank-k 准确率与 mAP 较全局分支均有较大提升,说明细粒度信息对于行人匹配起到了至关重要的作用。其二、虽然全局分支性能最低,但是,与局部分支进行组合可以提升性能。如: Branch(1+2)的组合相较于 Branch1 全局分支, Rank-1 与 mAP 分别提升 4.2%和 6.6%; 相较于 Branch2 分支, Rank-1 与 mAP 分别提升 1.8%和 0.2%。同时,我们的多尺度特征融合模型 Rank-1 达到了 92%, mAP 达到 78.3%, 远高于任意单个分支。该结果表明,各个分支可以相互补充它们在学习过程中的盲点,通过互相协作可以得到更具判别性的行人描述符。

其次,单独对多尺度特征提取网络进行实验,用以探究特征融合模块的作用。由于多尺度特征提取网络的输出结果为 7 个特征组成的集合,因此在测试时,将

7 个特征串联作为行人描述符，其图像间距离度量仍采用欧式距离。表 3.4 展示了两种方法的对比结果。

表 3.4 特征融合模块的在 Market1501 数据集上的性能

Table 3.4 Performance of feature fusion module on Market1501 dataset

方法	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP(%)
MSFE	91.5	96.3	98.2	78.2
MSFF	92.0	96.9	98.2	78.3

从表中我们发现，单独的多尺度特征提取网络（MSFE）同样具有强劲性能，其 Rank-1 准确率和 mAP 分别达到了 91.5%和 78.2%。在其与特征融合模块级联后，性能指标能进一步提升，Rank-1 准确率与 mAP 分别提升了 0.5%和 0.1%。表明特征融合模块的有效性，同时说明：对于从行人图像多个区域提取的多个局部特征，每个特征对行人相似度有不同的贡献。考虑每个特征的重要性，强化重要特征并弱化不重要特征，可使网络模型达到最佳性能。

3.6.4 与其他方法对比

为了进一步评估多尺度特征融合模型的性能，本节在 Market1501 与 DukeMTMC-reID 这两个大规模数据集上，与常见的主流行人重识别模型进行对比。通过 Rank-1 准确率与 mAP 两个指标进行结果展示，并且所有模型均采用相同的测试协议，其结果如表 3.5 和表 3.6 所示。

表 3.5 MSFF 模型与主流方法在 Market1501 数据集上的性能对比

Table 3.5 Performance comparison of MSFF model with state-of-the-art methods on Market1501

类型	模型	Rank-1 (%)	mAP
①	Bow+Kissme ^[23]	44.4	20.8
①	WARCA ^[57]	45.2	-
①	KLFDA ^[58]	46.5	-
②	PAR ^[59]	81.0	63.4
②	MultiLoss ^[60]	83.9	64.4
②	PDC ^[61]	84.4	63.4
②	PartLoss ^[62]	88.2	69.3
②	MultiScale ^[63]	88.2	69.3
②	GLAD ^[64]	89.9	73.9
②	PCB ^[62]	92.3	77.4

类型	模型	Rank-1 (%)	mAP
③	HDLF[41]	93.3	79.1
③	AlignedReID[19]	91.8	79.1
③	SPReID[65]	92.5	81.3
③	Mancs[66]	93.1	82.3
	MSFF(Ours)	92.0	78.3

表 3.6 MSFF 模型与主流方法在 DukeMTMC-reID 数据集上的性能对比

Table 3.6 Performance comparison of MSFF model with state-of-the-art methods on

DukeMTMC-reID			
类型	模型	Rank-1 (%)	mAP
①	Bow+Kissme ^[23]	25.1	12.2
①	LOMO+XQDA ^[8]	30.8	17.0
②	PAN ^[67]	71.6	51.5
②	MultiScale ^[63]	79.2	60.6
②	PCB ^[18]	81.8	66.1
②	PartLoss ^[62]	84.4	69.3
③	AlignedReID ^[19]	82.1	69.7
③	SPReID ^[65]	84.4	71.0
③	Mancs ^[66]	84.9	71.8
	MSFF(Ours)	83.5	71.1

为了更好地与主流方法对比,在表 3.5 和表 3.6 中,我们将常用的主流方法分成三类,分别为:①传统手工特征提取方法;②采用深度学习,并使用多特征的表征学习方法;③采用深度度量学习的方法。

从两个表中的结果可以看出:

其一、本章所提出的多尺度特征融合模型,性能指标远高于手工特征方法。相较于采用深度学习并使用多特征的表征学习方法,也达到了领先水平。其中,与第二类指标最高的 PCB 方法相比,在 Market1501 数据集上 Rank-1 仅低 0.3%,mAP 比其高 0.9%;在 DukeMTMC-reID 数据集上两个指标均比 PCB 方法高。

其二、本章所提模型与采用深度度量学习的方法相比,性能尚存在差距。与表中性能最高的 Mancs 方法相比,在 Market1501 数据集上 Rank-1 低 1.1%,mAP 低 4%;在 DukeMTMC-reID 数据集上 Rank-1 低 1.4%,mAP 低 0.7%。

其三、通过观察在两个数据集下,AlignedReID、SPReID 方法与本章所提模

型的性能指标发现：在 DukeMTMC-reID 数据集上，本模型的性能比它们高，而在 Market1501 数据集上比它们低。分析两个方法的特点可发现：上述两方法均使用了局部特征对齐策略，使待匹配的一对局部特征具有语义一致性。考虑到 Market1501 数据集的行人边界框是通过 DPM 检测器自动标注，可能存在误差，而 DukeMTMC-reID 数据集的行人边界框是手工标注不存在误差。因此本文推测，检测框标注误差造成行人未对齐，而导致相同区域语义不一致，可能是限制 MSFF 模型性能的一个重要因素。

综上所述，虽然本章提出的多尺度特征融合模型性能指标并未超越所有主流方法，但能达到一个较高的水平，足以证明此模型在行人重识别任务中的有效性。同时，通过分析各种方法的差异与数据集的差异，找到了进一步优化模型的方向，即引入深度度量学习与实现局部特征语义一致性，可进一步挖掘模型的潜力。

3.7 本章小结

本章首先阐述了行人重识别中，联合全局与局部特征进行行人匹配的基本思想，分析了两种不同的局部特征提取方法，并在此基础上提出了多尺度特征提取方法。其次，基于卷积神经网络搭建多尺度特征融合模型，该模型由多尺度特征提取网络和特征融合模块两部分组成。然后，详细介绍了这两部分的网络结构、功能以及设计原理。在多尺度特征提取网络中，通过各个区域独立地进行学习，挖掘不同粒度区域下的判别性信息。在特征融合模块中，为两个局部分支下的每个特征动态分配重要性分数，根据分数可将特征融合，得到最终的行人描述符。最后，本章在 Market1501 数据集上，对多尺度特征融合模型进行分离实验，并在 Market1501 与 DukeMTMC-reID 两个数据集上，与主流方法进行对比，系统地评估了本章所提模型的性能，提出了进一步优化的方向。

4 基于区域有效性与多尺度特征相结合的度量学习模型

4.1 引言

基于深度学习的行人重识别方法，当其特征提取框架固定时，为了训练优化网络参数，可以采取不同的损失函数。根据使用损失函数的不同，构建系统模型的方式可分为两种：①构建一个分类或验证模型，将每个行人视为不同的类别对象，采用 Softmax 交叉熵损失函数或其变种优化网络。该方法的本质是训练出特征嵌入空间，获取特征分布边界，依据边界的划分获得不同类别的样本。然而在测试阶段，测试样本的类别与训练样本并不重合，只能通过样本对之间的距离进行检索。由于分类模型不能约束样本对之间的距离，因此，使用性能强劲的分类模型也可能会出现检索失败。根据分类模型的损失函数可知，分类器在最终的特征嵌入空间中，仅学习了不同类别的临界面划分，而没有考虑类内距离分布，会出现某些样本点的类内距离大于类间距离，如图 4.1 (a) 所示。②构建一个检索模型，直接采用深度度量学习方法（采用三元组损失 (Triplet Loss) 或对比损失 (Contrastive loss) 等函数及其变种函数）优化网络参数。该方法强调样本对之间的距离关系，使每个负样本对距离比每个正样本对距离大于一个预定义的间隔 (Margin)，如图 4.1 (b) 所示。此方法虽然起到聚集同类样本的作用，但忽略了训练样本的整体分布情况，存在构建训练样本对困难、训练结果较为随机的情况。




图 4.1 基于分类和检索模型的行人特征在嵌入空间的分布情况：(a)分类模型样本空间分布；(b)检索模型样本空间分布

Fig.4.1 Distribution of pedestrian features in embedding space based on classification and retrieval model: (a) Sample spatial distribution of Classification model; (b) Sample spatial distribution of retrieval model

上述两种建模方式并非互斥关系，已有一些研究通过大量实验表明：结合两种不同类型的损失函数，可以相互促进网络训练，进一步提升行人重识别性能^[52,68]。后续一些主流的方法，如：文献[19,53,69]均采用混合损失函数的方式搭建模型。本章将在上一章提出的多尺度行人重识别框架的基础上，引入深度度量学习增强分类模型，使其具备分类和检索两种功能，以更适合处理行人重识别问题。同时，为了降低模型对行人检测框的要求、缓解图像不对齐的问题，本章提出了局部特征总体距离计算方法。此方法将替代第三章模型中的特征融合模块，不仅用于训练网络时度量损失的计算，也用于测试时图像对距离的计算。测试时，整体框架如图 4.2 所示。




图 4.2 模型测试框架

Fig.4.2 Framework of testing model

其中，模型的核心部分为局部分支总体距离计算，包含基于交叉对齐的特征匹配策略、基于区域有效性的特征对权重计算方法两方面内容。该距离计算方法将在 4.3 节详细叙述。

4.2 基于多尺度特征的深度度量学习

4.2.1 深度度量学习方法

在深度学习时代之前，传统的度量学习（学习马氏距离函数^[23]或投影矩阵^[26]）

已经被广泛应用于行人重识别。其核心思想是，通过训练样本中提取的特征去学习特定的距离度量函数，如学习公式（4-1）中所示的半正定矩阵 $\mathbf{M}$ 。

$$D_{\mathbf{M}}(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) \quad (4.1)$$

基于该方法的行人重识别系统特征提取和距离度量是两个独立的过程，不能进行端到端学习。而深度度量学习（Deep Metric Learning）与之不同，其核心思想是设计损失函数去引导特征的代表学习，从而达到度量学习的目的，使样本对可采用常规的距离计算方式（如欧式距离、余弦距离等）进行相似度计算。该方法将特征提取和距离度量两个过程合二为一，可实现端到端学习。实现一个深度度量学习，通常需要以下步骤：

首先，定义一个映射 $f_{\theta}(\mathbf{x})$ ，如公式（4.2）所示：

$$f_{\theta}(\mathbf{x}) : \mathbf{R}^F \rightarrow \mathbf{R}^D \quad (4.2)$$

此公式表示：将数据在原始域 $\mathbf{R}^F$ 中的高维稀疏特征 $\mathbf{x}$ ，映射到低维稠密的特征域 $\mathbf{R}^D$ （也称为嵌入空间）中， θ 为此映射函数的参数集合。就行人重识别这个任务而言，此映射的实现方式有很多种，既可使用简单的线性映射^[70,71]，也可使用基于深度神经网络实现的复杂的非线性映射^[19,53,66,69]。

其次，在嵌入空间中定义另外一个映射 $D(\mathbf{x}, \mathbf{y})$ ，表示两个特征之间的距离，如公式（4.3）所示：

$$D(\mathbf{x}, \mathbf{y}) : \mathbf{R}^D \times \mathbf{R}^D \rightarrow \mathbf{R} \quad (4.3)$$

此距离计算公式，虽然是自定义的一种距离度量方式，但通常不会引入任何参数，依据上一步中映射的特征可直接计算出距离。

然后，根据深度度量学习的目标（即：数据集在原始域 $\mathbf{R}^F$ 中语义越相似的两点，映射到特征域 $\mathbf{R}^D$ 后，以 $D(\mathbf{x}, \mathbf{y})$ 作为距离度量，两点间的距离越接近），基于一定的样本采样策略构建训练样本组，并设计相应损失函数，此损失函数是关于样本对距离度量的一个目标函数。

最后，以最小化损失函数的方式，优化映射 $f_{\theta}(\mathbf{x})$ 的参数 θ ，寻找一个最优的映射 $f(\mathbf{x})$ ，实现上述目标。

4.2.2 三元组框架下的多尺度特征度量学习基本模型

为了将上一章所提出的多尺度特征提取网络与深度度量学习方法相结合，从而构建新的行人重识别模型，提升识别性能。本小节按照深度度量学习的主要过程，在三元组框架下，搭建了多尺度特征度量学习基本模型，如图 4.3 所示。

三元组框架，指一种样本组的构成与损失计算方式，在计算每个损失时，均需要输入一个形如 $\{A, P, N\}$ 的三元组，并依据他们之间的距离度量共同确定。其中： A 为从训练集任意选择的一个样本，称为锚点（Anchor）； P 为从训练集选择的与锚点同类的样本，称为正样本（Positive）； N 为从训练集选择的与锚点不

同类的样本，称为负样本（Negative）。




图 4.3 三元组框架下的多尺度特征度量学习基本模型

Fig.4.3 Metric Learning basic model of multi-scale feature under the framework of triplet

该模型使用多尺度特征提取网络来实现特征映射的功能，其映射结果与常规的映射方法不同。依据上一章对多尺度特征提取网络所述，对于任意输入图像 A ，映射结果为一个特征集合 $F_A = [F_{Branch1}^A, F_{Branch2}^A, F_{Branch3}^A]$ 。其中： $F_{Branch1}^A$ 表示网络第一个分支所提取的特征集合，作为全局特征，由 1 个特征向量构成。 $F_{Branch2}^A$ 和 $F_{Branch3}^A$ 分别表示第二、三分支网络所提取的特征集合，均视为局部特征。其中， $F_{Branch2}^A$ 由 2 个特征向量构成， $F_{Branch3}^A$ 由 4 个特征向量构成。

在定义距离度量方法时，根据多尺度特征提取网络的特点，定义多重距离度量函数（即每一分支分别定义一个距离度量函数，以 $d_{Branch1}(x, y)$ ， $d_{Branch2}(x, y)$ ， $d_{Branch3}(x, y)$ 表示）。其中，每个距离度量表示对应分支特征集合的总体距离。比如： $d_{Branch3}(x, y)$ 表示第三分支下，图像 x 的四个特征向量与图像 y 的四个特征向量之间的总体距离。对于全局分支（Branch1 分支），其特征集合 $F_{Branch1}^A$ 为单个特征向量，用 f_{globe}^A 表示。本文直接使用欧式距离定义其距离度量函数。如公式（4.4）所示：


$$d_{Branch1}(A, B) = \|f_{globe}^A - f_{globe}^B\|_2 \quad (4.4)$$

对于局部特征分支 Branch2 和 Branch3，其输出非单一特征向量，无法直接使用欧式距离作为其距离度量函数进行学习，其距离度量由本章 4.3 节所提出的局部分支总体距离计算方法得到。

损失函数层主要包含两方面内容：一是构造三元组的采样策略；二是模型的损失函数。本文将在 4.4 节对其进行详细介绍。

4.3 局部分支总体距离计算方法

因为局部分支的特征集合由多个特征组成，所以在计算其分支总体距离时，需考虑两个方面的问题。一方面，按照什么策略匹配特征，再分别计算出匹配特征对之间的距离。另一方面，每个特征具有不同重要性，其匹配特征对的距离对总体距离的贡献不同。因此，本章提出局部分支总体距离计算方法，主要包含：基于交叉对齐的特征匹配策略和基于有效性的特征对权重计算方法。其整体框架如图 4.4 所示。



4.4 局部分支总体距离计算方法

Fig.4.4 Calculation method of total distance of local branches

整个方法共有三个步骤：首先，通过交叉对齐策略构造匹配特征对，计算所有匹配特征对的相似性；然后，采用对图像进行显著性分析计算每个特征对应区域的区域有效性，并通过聚合方式作为加权融合的权重。最后，将相似性加权融合，得到分支总体距离。

4.3.1 基于 GBVS 算法的图像显著性分析

GBVS 算法是 Harel 等人^[72]在 2006 年提出的一种自下而上的视觉显著性模型，该模型是基于全局对比的算法，在原始图像产生的特征图上，构建无向图模型衡量某个像素点和其邻域的不同，采用马尔科夫方法进行稳态估计，以实现预测人类视觉所感兴趣的区域，具有符合人类视觉注意力机制的特点。该视觉显著性模型的实现流程可分为三个阶段，分别为：特征提取（Extraction）、激活(Activation)

和标准化/联合(Normalization/Combination)。

①第一阶段：对原始图像进行特征提取，产生特征图

首先，通过线性高斯滤波器，对原始图像进行平滑滤波和下采样，形成包括原始图像在内的一个3层高斯金字塔，其每层图像尺度和原始图像的比例分别为[1:1,1:2,1:4]。

然后，对此金字塔中的每一层图像进行三类底层视觉特征提取，分别为亮度特征、颜色通道特征和方向特征。此三类特征提取方法直接、运算复杂度低且不破坏行人图像的空间结构信息，易于后续的显著性分析。具体计算方法如下所示：

1) 亮度特征：输入的行人图像为标准 RGB 图像，本文用 r, g, b 分别表示其红、绿、蓝三个通道的分量，用 I 表示每个像素点的亮度值，则亮度特征为：

$$I = (r + g + b) / 3 \quad (4.5)$$

2) 颜色通道特征： r, g, b 通道可以从亮度中解耦色调，一共可以产生4个宽调谐(Broadly-Tuned)的颜色通道特征，分别用 R, G, B, Y 表示，计算公式如下所示：

$$\begin{cases} R = r - (g + b) / 2 \\ G = g - (r + b) / 2 \\ B = b - (r + g) / 2 \\ Y = (r + g) / 2 - |r - g| / 2 - b \end{cases} \quad (4.6)$$

其中，若 R, G, B, Y 计算出的值为负数，则令其等于0。

3) 方向特征：因为在图像处理领域，Gabor 滤波器常用于提取频域中不同尺度、不同方向上的相关特征。所以，本文将在图像的亮度特征图上，使用 Gabor 滤波器提取局部方向信息，使用 $O(\theta)$ 表示某幅图像的方向特征，其计算公式如下：

$$O(\theta) = I(x, y) * \exp\left(\frac{-x'^2 + \gamma y'^2}{2\sigma^2}\right) \cdot \cos(2\pi \frac{x}{\lambda}) \quad (4.7)$$

$$\begin{cases} x' = x \cos \theta + y \sin \theta \\ y' = -x \sin \theta + y \cos \theta \end{cases} \quad (4.8)$$

其中， $I(x, y)$ 表示图像在点 (x, y) 处的亮度特征， γ 是图像纵横比。公式(4.7)表示图像的亮度特征图与 Gabor 函数进行卷积操作，如果给定角度 θ ，将得到某一确定角度的方向特征，本文选取了4个角度，分别是 $[0^\circ, 45^\circ, 90^\circ, 135^\circ]$ 。

最后，通过第一阶段的特征提取步骤，可以得到3幅亮度特征图、12幅颜色通道特征图和12幅方向特征图。

②第二阶段：形成激活图

首先，设上一阶段得到的任意一张特征图为 M ，定义 M 中 (i, j) 和 (p, q) 两点的差异为 $d((i, j) \parallel (p, q))$ ，计算方法如公式(4.9)所示：

$$d((i, j) \parallel (p, q)) \triangleq \left| \log \frac{M(i, j)}{M(p, q)} \right| \quad (4.9)$$

然后，构造一个有向全连接图 G_M ，以 M 的每个像素点作为其节点，从节点 (i, j) 到节点 (p, q) 作为有向边，边权重定义如下：

$$w_1((i, j) \parallel (p, q)) \triangleq d((i, j) \parallel (p, q)) \cdot F(i - p, j - p) \quad (4.10)$$

$$F(a, b) \triangleq \exp\left(-\frac{a^2 + b^2}{2\sigma^2}\right) \quad (4.11)$$

其中， σ 是一个自由参数，大小通常为图像宽度的十分之一到十五分之一，本文中取 12。将每个节点指向其他节点的边权重做归一化处理后，作为图 G_M 的边权重矩阵。

最后，将 G_M 中的节点作为马尔科夫链的状态，边权重矩阵作为马尔科夫链中的转移概率，从而在 G_M 上定义了一个马尔科夫链。因为此链具有遍历性，所以其平衡分布存在且唯一。当其达到平衡分布时，在初始状态下与周围节点有很大差异的节点，将积累到更高的值，以此状态值作为激活值，得到激活图。

③第三阶段：通过联合方式，将多个激活图融合为显著图

通过前两个阶段，得到一个三层金字塔，共 27 个激活图，每层具有 9 个相同分辨率的激活图。首先，分别对每层的 9 个激活图进行线性相加，得到三个分辨率下的三张显著图；然后，将第二层和第三层的显著图进行双线性插值，缩放到与第一层显著图相同的尺寸；最后，将三幅显著图叠加，作为最终的显著图。

4.3.2 区域有效性与特征对联合有效性计算




图 4.5 区域有效性计算流程：(a)原始分块图像；(b)区域显著图；(c)二值显著图；(d)区域有效性直方图

Fig.4.5 Calculation process of Region effectiveness: (a) Original partitioned image; (b)Regional saliency map; (c) Binary saliency map; (d) Histogram of region effectiveness

根据多尺度特征提取网络的局部特征获取方法可知：每个局部特征与原始图

像的固定区域相对应。以 Branch3 分支为例，所提取的 4 个局部特征向量，分别对应原始图像自上而下（Part1 至 Part4）的四个区域，如图 4.5（a）所示。对于每个 Part，通过上一小节所叙述的 GBVS 显著性算法，可得到每个 Part 的显著图，记为显著图集合 $S = \{s_1, s_2, s_3, s_4\}$ 。其中， s_i 表示第 i 个 Part 的显著图，如图 4.5（b）所示。本文使用灰度图表示其显著图，显著图的灰度值大小代表对应像素点的显著性强弱，反映了行人图像中哪些区域更容易受到人类视觉的关注。

行人局部区域中，显著区域大小代表该区域有效信息量的多少，可视为该区域特征的重要性。本文在此定义区域有效性 E_A^{part-i} ，其表示图像 A 第 i 个 Part 中，显著区域被量化后的数值。区域有效性的计算，有如下两个步骤：

第一步：采用均值二值化方法，将区域显著图转化为二值图像，相应的二值图像集合记为 $B = \{b_1, b_2, b_3, b_4\}$ 。其中：二值图像像素值为 1 的区域，表示为显著区域 R_i^1 ；为 0 的区域，表示为非显著区域 R_i^0 。均值二值化量化公式为：

$$b_i(x, y) = \begin{cases} 1, & s_i(x, y) \geq \text{avg}(s_i) \\ 0, & s_i(x, y) < \text{avg}(s_i) \end{cases} \quad (4.12)$$

$$\text{avg}(s_i) = \frac{1}{n \times m} \sum_{x=1}^n \sum_{y=1}^m s_i(x, y)$$

式中， m 和 n 分别表示显著图的宽和高。

第二步：使用图像 A 第 i 个 Part 的显著区域与总体区域的面积比，表示其区域有效性 E_A^{part-i} ，计算公式如下：

$$E_A^{part-i} = \frac{\text{area}(R_i^1)}{n \times m} \quad (4.13)$$

$$\text{area}(R_i^1) = \sum_{x=1}^n \sum_{y=1}^m b_i(x, y)$$

4.3.3 有效性聚合策略

在局部分支 3 中，计算两个局部特征集合总体距离的过程，如图 4.6 所示。假设两个特征集合中的特征向量，已经按某种策略匹配完成，且计算出各组匹配特征对的相似性。由于各特征的重要性不同，导致每组匹配特征对的相似性对总体相似性的贡献也不同。因此，需要将各组相似性加权融合，才能得到总体相似性。加权融合系数代表每组相似性贡献度的大小，可通过两个特征的区域有效性共同决定。

本文提出一种有效性聚合方式，将两个特征的区域有效性聚合，作为加权融合系数。该系数也称为匹配特征对的联合有效性，计算公式如（4.14）所示：

$$H_{i,j} = \frac{E_A^{part-i} \times E_B^{part-j}}{\alpha + |E_A^{part-i} - E_B^{part-j}|} \quad (4.14)$$

其中， $H_{i,j}$ 表示第 i 个区域和第 j 个区域的联合有效性， α 为控制有效性缩放的参

数。




图 4.6 局部特征集合总体距离计算过程

Fig.4.6 The calculation process of total distance of local feature set

4.3.4 基于交叉对齐匹配策略的局部特征总体距离计算

行人重识别系统的输入图像，通常由行人检测算法自动标注。由于行人检测算法可能存在误差，因此在某些情况下，生成的单个行人包围盒（bounding box）不是包含行人的最小矩形，会导致匹配过程中的图像不对齐，如图 4.7 所示。




图 4.7 检测框误差导致的行人图像不对齐示意图

Fig.4.6 Illustration of pedestrian images are not aligned caused by boundary box error

在行人图像没有对齐的情况下，根据局部分支 Branch 3 中，将行人图像均匀分为 4 个水平区块的方法，两幅待匹配图像同一水平位置的局部区域，会出现语义不一致的情况。在计算局部特征总体距离时，如果对两幅图像自上而下依次匹

配特征，再通过计算每组匹配特征对的相似性得到总体距离，就会产生一些“污点数据”。比如：将图像 A 和图像 B 自上而下依次进行匹配，并计算特征间的相似性，可分别得到 4 个 Part 对应的 4 个相似性，记为 (S_1, S_2, S_3, S_4) 。由于图像 A 和图像 B 的 Part1 区域语义明显不一致（图像 A 的 Part1 代表行人头部区域，图像 B 的 Part1 代表背景），因此，两个特征的相似性 S_1 对于总体距离没有任何意义，即所谓的“污点数据”。若将带有“污点数据”的总体距离，引入到深度度量学习的三元组损失函数中，可能会使网络朝错误方向收敛，导致模型崩溃。

为了避免带有“污点数据”的总体距离度量造成模型学习到错误信息，本文提出交叉对齐策略构造匹配特征对。该方法可以过滤掉错误的距离度量，以降低对行人检测算法精度的要求，即使在单个行人的包围盒（bounding box）出现误差的情况下，行人重识别系统也能做出正确预测。




图 4.8 基于交叉对齐匹配策略计算局部分支总体距离

Fig.4.8 Calculate the overall distance of local branch based on cross-alignment strategy

图 4.8 (a)、(b)、(c)，分别表示了三种不同的特征对匹配方式，两幅图像所匹配的 Part 由带双向箭头的线段连接。图 4.8 (a) 表示自上而下依次匹配，即：图像 A 第 i 个 Part 的特征与图像 B 第 i 个 Part 的特征进行匹配。图 4.8 (b) 和图 4.8 (c) 分别表示向上和向下错开一个 Part 进行匹配，即：表示图像 A 第 i 个 Part 的特征与图像 B 第 $i+1$ 个 Part 的特征进行匹配；图像 A 第 $i+1$ 个 Part 的特征与

图像 B 第 i 个 Part 的特征进行匹配。

定义函数 $\text{Sim}(\mathbf{f}, \mathbf{g})$ ，表示特征 $\mathbf{f}$ 和特征 $\mathbf{g}$ 之间的相似度。根据文献^[73]所述，相似度可与距离相互转化，其计算公式如下所示：

$$\text{Sim}(\mathbf{f}, \mathbf{g}) = \exp\left(-\frac{d(\mathbf{f}, \mathbf{g})}{2\sigma^2}\right) \quad (4.15)$$

其中， $d(\mathbf{f}, \mathbf{g})$ 表示两特征之间的欧式距离，如下所示：

$$d(\mathbf{f}, \mathbf{g}) = \|\mathbf{f} - \mathbf{g}\|_2 \quad (4.16)$$

将三种匹配方式下特征对相似性分别进行加权融合，可得到三种总体相似性，分别记为 S_a 、 S_b 、 S_c ，如下所示：

$$\begin{cases} S_a = \frac{1}{n} \sum_{i=1}^n H_{i,i} \times \text{Sim}(\mathbf{f}_A^i, \mathbf{f}_B^i) \\ S_b = \frac{1}{n-1} \sum_{i=1}^{n-1} H_{i,i+1} \times \text{Sim}(\mathbf{f}_A^i, \mathbf{f}_B^{i+1}) \\ S_c = \frac{1}{n-1} \sum_{i=1}^{n-1} H_{i+1,i} \times \text{Sim}(\mathbf{f}_A^{i+1}, \mathbf{f}_B^i) \end{cases} \quad (4.17)$$

其中， n 为图像分块数， $\mathbf{f}_x^i$ 表示任意图像 X 的第 i 个 Part 的特征。

将公式 (4.17) 引入本文的局部分支中，以 Bracnh3 为例，用 S_a^3 、 S_b^3 、 S_c^3 表示 Branch3 的三种总体相似性，计算公式如下：

$$\begin{cases} S_a^3 = \frac{1}{4} (H_{1,1} \times \text{Sim}(\mathbf{f}_A^1, \mathbf{f}_B^1) + H_{2,2} \times \text{Sim}(\mathbf{f}_A^2, \mathbf{f}_B^2) + H_{3,3} \times \text{Sim}(\mathbf{f}_A^3, \mathbf{f}_B^3) + H_{4,4} \times \text{Sim}(\mathbf{f}_A^4, \mathbf{f}_B^4)) \\ S_b^3 = \frac{1}{3} (H_{1,2} \times \text{Sim}(\mathbf{f}_A^1, \mathbf{f}_B^2) + H_{2,3} \times \text{Sim}(\mathbf{f}_A^2, \mathbf{f}_B^3) + H_{3,4} \times \text{Sim}(\mathbf{f}_A^3, \mathbf{f}_B^4)) \\ S_c^3 = \frac{1}{3} (H_{2,1} \times \text{Sim}(\mathbf{f}_A^2, \mathbf{f}_B^1) + H_{3,2} \times \text{Sim}(\mathbf{f}_A^3, \mathbf{f}_B^2) + H_{4,3} \times \text{Sim}(\mathbf{f}_A^4, \mathbf{f}_B^3)) \end{cases} \quad (4.18)$$

Bracnh2 分支的三个相似性 S_a^2 、 S_b^2 、 S_c^2 同理可得。

由于在各组匹配特征对中，属于相同部位的特征对相似性最大，因此，取三种匹配方式下相似性最大的值，即可作为最终局部特征总体相似性。然后，按照公式 (4.15) 将其转换为局部特征整体距离，作为局部分支下的距离度量函数。计算公式如下：

$$\begin{cases} d_{branch2}(A, B) = -2\sigma^2 \log(\max(S_a^2, S_b^2, S_c^2)) \\ d_{branch3}(A, B) = -2\sigma^2 \log(\max(S_a^3, S_b^3, S_c^3)) \end{cases} \quad (4.19)$$

4.4 损失函数层设计

4.4.1 困难样本挖掘策略

从 4.1 节对行人重识别分类模型的特征空间分布描述中可知：虽然存在某些样本点的类内距离大于类间距离，但对于大多数样本来说，特征空间分布已达到同类样本距离小于非同类样本距离。我们将这些样本分为三类，分别为简单样本、较难样本和困难样本，其中，大多数样本可视为简单样本。如果选择大多数简单样本构成三元组，由于其产生的度量损失值几乎为零、且样本空间数量级巨大，不仅不能优化网络参数、训练出表达能力强的行人重识别网络，而且会浪费大量计算资源。因此，三元组的样本应选择困难样本组成，即采用难样本挖掘（Hard Sample Mining）方式构建三元组。

本模型采用了一种称为 PK 三元组采样^[68]的难样本挖掘方法，此方法已被广泛用于行人重识别。其具体过程如下：首先，从训练集中随机抽取 P 个 ID 的行人，每个行人再随机抽取 K 张图片，组成一个大小为 $P \times K$ 的训练批次，表示为集合 $T = [x_1^1, x_1^2, \dots, x_1^K, \dots, x_P^1, x_P^2, \dots, x_P^K]$ ， x_i^j 表示第 i 个行人的第 j 张图片。然后，对于每一个 x_i^j ，在 T 中按照预定义的距离度量方法，挑选一个距离最远的正样本和一个距离最近的负样本构成一个三元组。构造的任意一个三元组记为 (x_i^j, x_i^k, x_m^n) ，其中 x_i^k 和 x_m^n 如公式（4.20）所示，

$$\begin{aligned} x_i^k &= \arg \max_{k, k \neq j} d(x_i^j, x_i^k) \\ x_m^n &= \arg \min_{m, n, m \neq i} d(x_i^j, x_m^n) \end{aligned} \quad (4.20)$$

此采样方法在一个训练批次里面共构造 $P \times K$ 个这样的三元组，所有三元组将用于计算最终的度量损失。

4.4.2 多分支度量损失函数

对于多尺度特征提取网络的三个分支，根据 4.3 节可知：三个分支各自的距离度量函数分别为 $d_{Branch1}(x, y)$ 、 $d_{Branch2}(x, y)$ 和 $d_{Branch3}(x, y)$ 。将上一小节介绍的采样策略与改进的三元组度量损失相结合，根据每个分支自定义的距离度量函数，分别构建各自的度量损失函数，并形成总体度量损失函数。

根据原始三元组度量损失函数，可以得到基于 PK 三元组采样方法的一个训练批次中，任意一个三元组 (x_i^j, x_i^k, x_m^n) 的损失，记为 $L(x_i^j, x_i^k, x_m^n)$ 。如公式（4.21）所示：

$$L(x_i^j, x_i^k, x_m^n) = \left[d(x_i^j, x_i^k) - d(x_i^j, x_m^n) + \alpha \right]_+ \quad (4.21)$$

式中， α 为正常数作为一个预定义的 Margin； $[\bullet]_+$ 为 Hinge 函数，其内部表达式值小于 0 时，该函数值为 0。否则，函数值为表达式的值。该函数起到截断作用，

避免网络去学习相对距离已经正确的三元组。

对于一个训练批次的度量损失，根据公式 (4.21) 与三元组的采样策略可得：

$$L_{Tri} = \frac{1}{P \times K} \sum_{i=1}^{i=P} \sum_{j=1}^{j=K} L(x_i^j, x_i^k, x_m^n) \quad (4.22)$$

针对多尺度网络的三个分支，依据公式 (4.22) 并带入各自的距离度量函数，分别构造三个分支的度量损失函数，如公式 (4.23) 所示：

$$\begin{cases} L_{Branch1} = \frac{1}{P \times K} \sum_{i=1}^{i=P} \sum_{j=1}^{j=K} [d_{Branch1}(x_i^j, x_i^k) - d_{Branch1}(x_i^j, x_m^n) + \alpha]_+ \\ L_{Branch2} = \frac{1}{P \times K} \sum_{i=1}^{i=P} \sum_{j=1}^{j=K} [d_{Branch2}(x_i^j, x_i^k) - d_{Branch2}(x_i^j, x_m^n) + \alpha]_+ \\ L_{Branch3} = \frac{1}{P \times K} \sum_{i=1}^{i=P} \sum_{j=1}^{j=K} [d_{Branch3}(x_i^j, x_i^k) - d_{Branch3}(x_i^j, x_m^n) + \alpha]_+ \end{cases} \quad (4.23)$$

由公式 (4.23) 可知，在两个局部分支中，本文将基于区域有效性与交叉对齐特征匹配策略的总体距离计算方法引入度量损失中，利用更加有效的距离计算方法，使度量损失的计算更加高效和精确，此方法更有利于网络训练优化。

虽然三个分支各自提取不同的特征，以不同的距离度量函数计算样本距离，但就正样本对而言，三个分支计算出的距离差异应该被最小化。所以，在构建总体度量损失时，除三个分支的度量损失外，还应确保正样本对在三种距离度量计算下的距离差异被最小化。总体度量损失计算如公式 (4.24) 所示：

$$L_{Metric} = L_{Branch1} + L_{Branch2} + L_{Branch3} + diff_{Branch} \quad (4.24)$$

其中， L_{Metric} 表示总体度量损失， $diff_{Branch}$ 表示一个训练批次中，三种距离度量函数计算出的所有困难正样本的距离差异和，计算公式如下所示：

$$diff_{Branch} = \frac{1}{P \times K} \sum_{i=1}^{i=P} \sum_{j=1}^{j=K} \left(\sum_{n=1, m=1}^3 (d_n(x_i^j, x_i^k) - d_m(x_i^j, x_i^k))^2 \right) \quad (4.25)$$

其中， d_n 表示第 n 个分支的距离度量函数。

4.4.3 网络总体损失

整体网络结构的总体损失如图 4.9 所示，采用联合损失对网络参数进行训练优化，该联合损失为网络总体分类损失加上总体度量损失。其中，ID Prediction 为第三章所述的 Softmax 分类损失，由公式 (3.4) 得到，记该损失为 $L_{Softmax}$ 。再由公式 (4.24) 的总体度量损失可得到网络总体损失，如下所示：

$$L_{total} = L_{Softmax} + L_{Metric} \quad (4.26)$$




图 4.9 网络总体损失

Fig 4.9 Loss Function of Network structure

4.5 实验与结果分析

4.5.1 数据集与实验平台

本章提出的基于区域有效性与多尺度特征相结合的度量学习模型 (REMSF), 可视为第三章所提的 MSFF 模型进一步优化, 本节将在 Market1501、DukeMTMC-reID 与 CUHK03 三个较大规模的主流行人重识别数据集上, 对其进行实验、综合评价模型的性能。在 Ubuntu 操作系统下进行实验, 通过 MATLAB 进行图像显著性分析, 网络部署于 Pytorch 深度学习框架, 使用 GPU 进行训练。具体实验环境如表 4.1 所示。

表 4.1 实验环境配置

Table 4.1 Configuration of experimental environment

环境项目	配置详情
系统平台	Ubuntu 16.04 LTS, 64 位
编程软件	MATLAB 2014a, Python3.6, Pytorch1.0
CPU	Intel® Xeon(R) E5-2649 2.30GHz, 20 核, 32GB 内存
GPU	GeForce GTX1080 Ti, 11GB 内存

4.5.2 模型训练与测试

①模型训练方法

与第三章的 MSFF 模型需要进行两阶段训练不同，本章所提模型可直接进行端到端训练，具体训练步骤如下：

1) 使用在 ImageNet 上预训练模型的参数，初始化多尺度特征提取网络中，主干网络及各分支 Conv_5 卷积模块的参数，其余参数使用随机初始化。分支网络参数部分使用 dropout 策略防止过拟合，其丢弃概率设置为 0.5。

2) 将每张图片缩放到 256*128 尺寸，并采用 0.5 概率的随机水平翻转和随机裁剪，作为数据增广策略。

3) 构造一个训练批次，其大小 Batch_Size 设置为 32。具体操作如下：在组成训练批次时，随机选取 8 个 ID 的行人，每个 ID 随机抽样 4 张图片。若某一 ID 行人的图像不足 4 张，则采取预处理中的数据增广策略，使其扩大为 4 张。

4) 对一个训练批次里所有图像进行显著性分析，得到显著图，然后计算每个 Part 的区域有效性。

5) 将所有图像的像素值除以 255，使其缩放到[0,1]区间。然后，对每张图片 RGB 三个通道的每个像素点的值减去均值，并除以方差进行标准化。其中：RGB 三个通道的均值和方差，分别为[0.484, 0.456, 0.406]和[0.229, 0.224, 0.225]。

6) 将步骤⑤处理后的数据输入网络，根据多尺度提取网络输出的特征集合，计算总体分类损失。

7) 使用多尺度提取网络各个分支的特征集合及其区域有效性，计算各分支的总体距离。通过样本距离，确定每张图片对应的困难三元组，并通过所有三元组计算总体度量损失。其中，三元组损失中的 Margin 参数设置为 0.3。

8) 将分类损失与度量损失求和，作为模型总体损失，采用小批量梯度下降法 (Mini-batch Gradient Descent, MBGD) 更新网络参数。其中：初始学习率、动量和权重衰减因子，分别设置为 0.01、0.9 和 0.0005。

9) 重复 2~8 步骤，直到迭代训练 150 个 epoch。其中：学习率从第 60 个 epoch 开始，每 10 个 epoch 就衰减为原来的一半，共衰减 4 次。

②模型测试方法

待模型训练完成后，首先，将测试集中的所有图像依次输入模型，得到每张图像的特征集合与每个特征对应的区域有效性；然后，按照公式(4-4)与公式(4-19)，计算出每一张待查询图像与 Gallery 中所有图像之间的距离；最后，将 Gallery 中所有图像，按照距离从小到大排序，即可得出 Rank-k 准确率和 mAP。

4.5.3 基于有效性与多尺度特征的度量学习模型性能评估

本章模型通过引入度量学习，对多尺度特征融合模型改进。为此，我们提出

了一种距离计算方法，包括基于交叉对齐的特征对匹配策略、基于区域有效性的特征对权重计算方法两部分。本小节将评估这两部分对整体模型的作用，首先评估交叉对齐策略，然后评估区域有效性对模型的影响。

①交叉对齐策略性能验证。

本文使用四组对照实验来验证交叉对齐的作用。第一组：使用第三章的多尺度特征提取网络（MSFE）。在第二至第四组中，均引入深度度量学习，但采用不同的距离计算方法计算样本对距离。第二组：采用自上而下依次匹配策略计算样本对距离（MSFE+ TriHard）。第三组：先采用融合模块将特征融合，再计算样本对距离（MSFF+ TriHard），第四组：使用交叉对齐策略计算样本对距离（MSFE+TriHard+ Align），即本章提出的REMSF模型。其对比结果如表4.2所示。

表 4.2 交叉对齐策略在 Market1501 数据集上验证实验结果

方法	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP(%)
MSFE	91.5	96.3	98.2	78.2
MSFE+TriHard	88.7	96.0	97.2	75.0
MSFF+TriHard	92.4	97.1	97.8	79.0
REMSF	93.0	97.6	99.0	82.1

从表 4.2 中发现：其一、使用自上而下依次匹配计算距离，用于三元组损失进行网络训练，此方法并不能提高模型精度，反而使其性能下降。说明了某些图像存在不对齐，会导致错误的距离度量，从而使网络向错误的方向收敛。其二、采用将局部特征融合之后，再计算三元组损失进行网络训练的方法，虽然可以一定程度上提高 Rank-1 准确率，但对 mAP 没有太大的提升。此结果表明了特征融合模块同样难以处理图像错位问题，不能充分发挥深度度量学习的优势。其三、采用交叉对齐策略取得了最高的性能，其中 Rank-1 提高了 1.5%、mAP 提高 3.9%，说明了该方法可以缓解图像不对齐问题，具有合理性与有效性。同时也表明，引入深度度量学习对分类模型增强时，采用合理的距离计算方法，才能进一步优化网络、提高模型检索性能。

②区域有效性作用验证

本文通过设计了三组对照实验，来研究区域有效性的作用，同时探讨有效性聚合策略的合理性。第一组实验在计算距离时，不加入有效性计算（No-Weight）。第二组实验加入有效性计算，并使用均值方式得到权重（Avg Weight）。第三组实验加入有效性计算，并采用聚合方式得到权重（Aggre Weight），即本章提出的

REMSF 模型。对比结果如表 4.3 所示。

表 4.3 区域有效性在 Market1501 数据集上验证实验结果

方法	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP(%)
No-Weight	92.1	96.9	98.5	79.3
Avg-Weight	92.5	97.1	98.5	81.3
REMSF	93.0	97.6	99.0	82.1

从表 4.3 中可以看出：在计算距离时，通过加入有效性计算，使模型有更好的表现，Rank-k 准确性和 mAP 均有提升。说明在计算局部分支总体距离时，通过有效性计算，可以准确地评估特征的重要程度，使重要的特征对最终距离起到更大的决策作用，从而提高模型的检索精度。同时也表明，在训练网络过程中，使网络关注信息量多的区域，更有利于挖掘判别性信息。此外，为了获得特征对的权重，分别采用聚合方式和均值方法进行有效性计算。相比而言，使用聚合方式取得了更好的实验结果，其中 Rank-1 与 mAP 分别提高了 0.5%与 0.8%。这表明本文采用的有效性聚合方式能合理地体现特征对的重要性。

4.5.4 与其他方法对比

本小节在 Market1501、DukeMTMC-reID 与 CUHK03 这三个大规模数据集上，将本章所提的模型与常见的主流行人重识别模型进行对比。对比的主流方法与第三章所述相同，采用 Rank-1 准确率与 mAP 两个指标展示结果，其结果如表 4.4、4.5 和 4.6 所示。其中，所对比的主流方法同样按照第三章的分类方法，将其分为三类，分别为：①传统手工特征提取方法；②采用深度学习，并使用多特征的表征学习方法；③采用深度度量学习的方法

表 4.4 REMSF 模型与主流方法在 Market1501 数据集上的性能对比

类型	模型	Rank-1 (%)	mAP
①	Bow+Kissme ^[23]	44.4	20.8
①	WARCA ^[57]	45.2	-
①	KLFDA ^[58]	46.5	-
②	PAR ^[59]	81.0	63.4
②	MultiLoss ^[60]	83.9	64.4
②	PDC ^[61]	84.4	63.4

类型	模型	Rank-1 (%)	mAP
②	PartLoss ^[62]	88.2	69.3
②	MultiScale ^[63]	88.9	73.1
②	GLAD ^[64]	89.9	73.9
②	PCB ^[18]	92.3	77.4
③	HDLF ^[41]	93.3	79.1
③	AlignedReID ^[19]	91.8	79.1
③	SPReID ^[65]	92.5	81.3
③	Mancs ^[66]	93.1	82.3
	MSFF(Ours)	92.0	78.3
	REMSF(Ours)	93.0	82.1

表 4.5 REMSF 模型与主流方法在 DukeMTMC-reID 数据集上的性能对比

Table 4.5 Performance comparison of REMSF model with state-of-the-art methods on

DukeMTMC-reID			
类型	模型	Rank-1 (%)	mAP
①	Bow+Kissme ^[23]	25.1	12.2
①	LOMO+XQDA ^[8]	30.8	17.0
②	PAN ^[67]	71.6	51.5
②	MultiScale ^[63]	79.2	60.6
②	PCB ^[18]	81.8	66.1
②	PartLoss ^[62]	84.4	69.3
③	AlignedReID ^[19]	82.1	69.7
③	SPReID ^[65]	84.4	71.0
③	Mancs ^[66]	84.9	71.8
	MSFF(Ours)	83.5	71.1
	REMSF (Ours)	85.3	72.9

表 4.6 MSFF 模型与主流方法在 CUHK03 数据集上的性能对比

Table 4.6 Performance comparison of REMSF model with state-of-the-art methods on CUHK03

类型	模型	Rank-1 (%)	mAP
①	Bow+Kissme ^[23]	6.4	6.4
①	LOMO+XQDA ^[8]	12.8	11.5
②	PAN ^[67]	36.3	34.0

类型	模型	Rank-1 (%)	mAP
②	MultiScale ^[63]	40.7	37.0
②	PCB ^[18]	61.3	54.2
③	AlignedReID ^[19]	61.5	59.7
③	Manacs ^[66]	65.5	60.5
	MSFF(Ours)	61.0	54.5
	REMSF (Ours)	66.8	61.6

从表中数据可发现：①本文所提基于区域有效性与多尺度特征模型，在 DukeMTMC-reID 数据集与 CUHK03 数据集上，性能超越了表中的所有方法；在 Market1501 数据集上，与性能最高的 Manacs 方法也不相上下，其中，Rank-1 低了 0.1%，mAP 低了 0.2%。②本章提出的模型在三个大型数据集上，性能指标均处于领先地位，说明本章对 MSFF 模型优化方向的正确性，以及本章所提模型的有效性。同时也说明了：使用深度度量学习方法训练网络，可以促进同类特征在嵌入空间中形成聚类的效果，有利于提高检索精度。

4.6 本章小结

本章首先分析分类损失和度量损失的特点，以及联合二者用于行人重识别模型的可行性。其次，对多尺度特征提取网络改进，在其每个分支网络中加入独立的三元组损失，使每个分支学习不同的距离度量。然后，介绍了局部分支三元组损失中的距离计算方法。该方法表示分支的总体距离度量，既用于训练网络时损失的计算，也用于测试时图像对距离的计算。最后，本章在 CUHK03、Market1501 与 DukeMTMC-reID 三个数据上进行实验，评估此改进模型的性能。

5 总结与展望

5.1 本文主要研究内容总结

本文针对图像的行人重识别问题,围绕如何提高特征表达能力展开研究,提出一种新的多尺度特征提取网络。同时,提出了一种基于交叉对齐与区域有效性的距离计算方法,引入深度度量学习对网络增强。本文主要研究工作如下:

①提出一种多尺度特征提取网络。该网络由一个主干网络和三个分支网络构成:主干网络使用残差结构,提取可共享的图像低级特征图;三个分支网络分别采用不同的水平池化策略对特征图进行划分,以提取多尺度特征。该网络通过所有特征共同约束,采用分类损失进行训练,充分挖掘行人图像的可判别信息。

②基于空间注意力机制设计了特征融合模块,与多尺度特征提取网络相结合,形成多尺度特征融合模型。该特征融合模块基于分支特征图生成空间位置的重要性分数,对分支网络输出特征分配权重,实现特征线性加权融合,输出值作为行人整体描述符,用于测试阶段的行人检索。实验表明,该模型具有较高的识别准确率,充分说明了本文所提出方法的有效性。

③针对多尺度特征融合提取网络无法对嵌入空间中的特征距离做出约束的问题,本文引入深度度量学习,三个分支分别加入三元组损失学习不同距离度量。训练过程中将度量损失和分类损失作为网络总体损失,从而优化网络参数,使同类样本特征达到聚类效果,并且扩大了非同类样本之间的距离。

④针对三元组损失计算样本对距离时,行人图像不对齐会引入错误距离度量的问题。本文采用了一种距离融合方法替换特征融合,形成基于区域有效性与多尺度特征相结合的度量学习模型。该方法先通过交叉对齐策略构造匹配特征对,然后计算特征对相似性,再对相似性加权融合,得到总体距离度量。此距离融合方法既可降低对行人检测框的要求、缓解不对齐的问题,同时也考虑了每个特征具有不同重要性的问题。实验结果显示,Rank-K 正确率与 mAP 指标相较于多尺度特征融合模型有了进一步的提高,充分说明了改进方向的正确性,以及此模型的优越性。

5.2 未来展望

鉴于行人重识别在学术研究上影响力与实际落地应用的重要性,其研究热度近年来快速增长,开发一个具有鲁棒性、高识别率和实际应用的行人重识别系统,一直是研究人员追求的目标。本文所提出的基于区域性与多尺度特征相结合的行人重识别模型,在一些数据集上取得了不错的性能指标,获得了初步的研究成果,

但本文所提模型依然存在一定不足，有待进一步研究与改进。在未来的研究中，我们可以从下列几个方面做更深入的研究与探讨：

①基于区域性与多尺度特征的行人重识别模型，计算两张图片的相似度时，不仅需要通过对多尺度特征提取网络提取特征向量，还需要通过 GBVS 算法进行显著性分析，就会导致模型时间复杂度过高。未来的工作中，为了能让模型满足实时性的要求，需要优化计算策略，在不降低模型识别性能的前提下，降低时间复杂度。

②在行人图像存在遮挡现象时，本文提出的模型可能会出现误判。在后续的工作中，应该将解决行人图像遮挡问题作为最重要的工作任务，可考虑将部分行人重识别模型、遮挡检测与本文模型相结合，来处理遮挡问题。

③本文提出模型在相同域下进行训练与测试，并未考虑进行跨域实验。考虑到相同域下行人与背景风格较为单一、场景简单，而跨域下场景更加复杂、风格更加多变，更贴近落地应用。因此，下一步将设计一些跨域实验，通过结果深入分析，并进一步优化模型。

参考文献

- [1] Gong S, Cristani M, Yan S, et al. Person re-identification[M].[S.1.]:Springer 2014.
- [2] Zheng L, Yang Y, Hauptmann A G. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [3] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]. 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06), 2006: 1528-1535.
- [4] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C]. 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2010: 2360-2367.
- [5] Ma B, Su Y, Jurie F. Covariance descriptor based on bio-inspired features for person re-identification and face verification[J]. Image and Vision Computing, 2014, 32(6-7): 379-390.
- [6] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[C]. European conference on computer vision, 2008: 262-275.
- [7] Yang Y, Yang J, Yan J, et al. Salient color names for person re-identification[C]. European conference on computer vision, 2014: 536-551.
- [8] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 2197-2206.
- [9] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 152-159.
- [10] Zheng L, Zhang H, Sun S, et al. Person re-identification in the wild[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1367-1376.
- [11] Gou M, Wu Z, Rate-Borrás A, et al. A systematic evaluation and benchmark for person re-identification: Features, metrics, and datasets[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41(3): 523-536.
- [12] Zheng Z, Zheng L, Yang Y. A discriminatively learned cnn embedding for person reidentification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2017, 14(1): 1-20.
- [13] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based cnn

- with improved triplet loss function[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1335-1344.
- [14] Li D, Chen X, Zhang Z, et al. Learning deep context-aware features over body and latent parts for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 384-393.
- [15] Suh Y, Wang J, Tang S, et al. Part-aligned bilinear representations for person re-identification[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 402-419.
- [16] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 1077-1085.
- [17] Varior R R, Shuai B, Lu J, et al. A siamese long short-term memory architecture for human re-identification[C]. European conference on computer vision, 2016: 135-153.
- [18] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 480-496.
- [19] Luo H, Jiang W, Zhang X, et al. AlignedReID++: Dynamically matching local information for person re-identification[J]. Pattern Recognition, 2019, 94: 53-61.
- [20] Hou R, Ma B, Chang H, et al. Interaction-and-aggregation network for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 9317-9326.
- [21] Xing E P, Jordan M I, Russell S J, et al. Distance metric learning with application to clustering with side-information[C]. Advances in neural information processing systems, 2003: 521-528.
- [22] Zheng W-S, Gong S, Xiang T. Person re-identification by probabilistic relative distance comparison[C]. CVPR 2011, 2011: 649-656.
- [23] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]. 2012 IEEE conference on computer vision and pattern recognition, 2012: 2288-2295.
- [24] Ma L, Yang X, Tao D. Person re-identification over camera networks using multi-task distance metric learning[J]. IEEE Transactions on Image Processing, 2014, 23(8): 3656-3670.
- [25] Chen D, Yuan Z, Hua G, et al. Similarity learning on an explicit polynomial kernel feature map for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1565-1573.

- [26] Liao S, Li S Z. Efficient psd constrained asymmetric metric learning for person re-identification[C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 3685-3693.
- [27] Yang Y, Liao S, Lei Z, et al. Large scale similarity learning using similar pairs for person verification[C]. Thirtieth AAAI Conference on Artificial Intelligence, 2016.
- [28] Yi D, Lei Z, Liao S, et al. Deep metric learning for person re-identification[C]. 2014 22nd International Conference on Pattern Recognition, 2014: 34-39.
- [29] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 815-823.
- [30] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 403-412.
- [31] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(06): 1229-1251.
- [32] 黄灿. 图像识别领域中卷积神经网络的应用[J]. 信息记录材料, 2018, 19(05): 39-40.
- [33] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [34] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]. Advances in neural information processing systems, 2012: 1097-1105.
- [35] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [36] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [37] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4700-4708.
- [38] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [39] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [40] Zheng L, Yang Y, Tian Q. SIFT meets CNN: A decade survey of instance retrieval[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(5): 1224-1244.
- [41] Zeng M, Tian C, Wu Z. Person re-identification with hierarchical deep learning feature and

- efficient xqda metric[C]. Proceedings of the 26th ACM international conference on Multimedia, 2018: 1838-1846.
- [42] Luo H, Gu Y, Liao X, et al. Bag of tricks and a strong baseline for deep person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2019.
- [43] Zheng L, Bie Z, Sun Y, et al. Mars: A video benchmark for large-scale person re-identification[C]. European Conference on Computer Vision, 2016: 868-884.
- [44] Fu Y, Wei Y, Zhou Y, et al. Horizontal pyramid matching for person re-identification[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019: 8295-8302.
- [45] Philbin J, Chum O, Isard M, et al. Object retrieval with large vocabularies and fast spatial matching[C]. 2007 IEEE conference on computer vision and pattern recognition, 2007: 1-8.
- [46] Wang J, Zhang T, Sebe N, et al. A survey on learning to hash[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 769-790.
- [47] Satta R. Appearance descriptors for person re-identification: a comprehensive review[J]. arXiv preprint arXiv:1307.5748, 2013.
- [48] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]. Proceedings of the IEEE international conference on computer vision, 2015: 1116-1124.
- [49] Ristani E, Solera F, Zou R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]. European Conference on Computer Vision, 2016: 17-35.
- [50] Felzenszwalb P, Mcallester D, Ramanan D. A discriminatively trained, multiscale, deformable part model[C]. 2008 IEEE Conference on Computer Vision and Pattern Recognition, 2008: 1-8.
- [51] Zhong Z, Zheng L, Cao D, et al. Re-ranking person re-identification with k-reciprocal encoding[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1318-1327.
- [52] Zhang Y, Xiang T, Hospedales T M, et al. Deep mutual learning[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4320-4328.
- [53] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]. Proceedings of the 26th ACM international conference on Multimedia, 2018: 274-282.
- [54] Wei S-E, Ramakrishna V, Kanade T, et al. Convolutional pose machines[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2016: 4724-4732.
- [55] Golik P, Doetsch P, Ney H. Cross-entropy vs. squared error training: a theoretical and experimental comparison[C]. Interspeech, 2013: 1756-1760.

- [56] Noh H, Araujo A, Sim J, et al. Large-scale image retrieval with attentive deep local features[C]. Proceedings of the IEEE international conference on computer vision, 2017: 3456-3465.
- [57] Jose C, Fleuret F. Scalable metric learning via weighted approximate rank component analysis[C]. European conference on computer vision, 2016: 875-890.
- [58] Karanam S, Gou M, Wu Z, et al. A comprehensive evaluation and benchmark for person re-identification: Features, metrics, and datasets[J]. arXiv preprint arXiv:1605.09653, 2016, 2(3): 5.
- [59] Zhao L, Li X, Zhuang Y, et al. Deeply-learned part-aligned representations for person re-identification[C]. Proceedings of the IEEE international conference on computer vision, 2017: 3219-3228.
- [60] Li W, Zhu X, Gong S. Person re-identification by deep joint learning of multi-loss classification[J]. arXiv preprint arXiv:1705.04724, 2017.
- [61] Long M, Zhu H, Wang J, et al. Unsupervised domain adaptation with residual transfer networks[C]. Advances in neural information processing systems, 2016: 136-144.
- [62] Yao H, Zhang S, Hong R, et al. Deep representation learning with part loss for person re-identification[J]. IEEE Transactions on Image Processing, 2019, 28(6): 2860-2871.
- [63] Chen Y, Zhu X, Gong S. Person re-identification by deep learning multi-scale representations[C]. Proceedings of the IEEE International Conference on Computer Vision Workshops, 2017: 2590-2600.
- [64] Wei L, Zhang S, Yao H, et al. GLAD: Global-local-alignment descriptor for scalable person re-identification[J]. IEEE Transactions on Multimedia, 2018, 21(4): 986-999.
- [65] Kalayeh M M, Basaran E, Gökmen M, et al. Human semantic parsing for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 1062-1071.
- [66] Wang C, Zhang Q, Huang C, et al. Mancs: A multi-task attentional network with curriculum sampling for person re-identification[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 365-381.
- [67] Zheng W-S, Gong S, Xiang T. Reidentification by relative distance comparison[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(3): 653-668.
- [68] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [69] Zheng F, Deng C, Sun X, et al. Pyramidal person re-identification via multi-loss dynamic training[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern

- Recognition, 2019: 8514-8522.
- [70] Weinberger K Q, Blitzer J, Saul L K. Distance metric learning for large margin nearest neighbor classification[C]. Advances in neural information processing systems, 2006: 1473-1480.
- [71] Zhang L, Xiang T, Gong S. Learning a discriminative null space for person re-identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1239-1248.
- [72] Harel J, Koch C, Perona P. Graph-based visual saliency[C]. Advances in neural information processing systems, 2007: 545-552.
- [73] Zhao Z, Zhao B, Su F. Person re-identification via integrating patch-based metric learning and local salience learning[J]. Pattern Recognition, 2018, 75: 90-98.

附 录

A. 作者在攻读学位期间取得的科研成果目录:

- [1] 黄智勇, **李渊明**, 吴海华, 虞智. 用于卷积神经网络硬件加速的数据处理方法[P]. 中国专利: CN108805267A. 20181113.
- [2] 黄智勇, 吴海华, **李渊明**, 虞智. 基于 FPGA 的 Tiny-yolo 卷积神经网络硬件加速方法及系统[P]. 中国专利: CN108805274A. 20181113.

B. 作者在攻读学位期间参与的科研项目目录:

- [1] 参与横向科研项目: 基于卷积神经网络的小区门禁人脸识别系统
- [2] 参与横向科研项目: 基于机器视觉的数控机床数据采集与传输系统

C. 学位论文数据集:

关键词		密级		中图分类号	
行人重识别；卷积神经网络；多尺度特征；区域有效性；交叉对齐		公开		TP391	
学位授予单位名称	学位授予单位代码	学位类别		学位级别	
重庆大学	10611	学术学位		硕士	
论文题名		并列题名		论文语种	
基于多尺度特征的行人重识别技术研究		无		中文	
作者姓名	李渊明		学号	20161202021	
培养单位名称			培养单位代码		
重庆大学			10611		
学科专业	研究方向		学制	学位授予年	
信息与通信工程	图像处理		3	2020	
论文提交日期	2020 年 6 月		论文总页数	82	
导师姓名	黄智勇		职称	副教授	
答辩委员会主席			冯文江		
电子版论文提交格式					
文本 (√) 图像 () 视频 () 音频 () 多媒体 () 其他 ()					

致 谢

时光如白驹过隙，弹指一挥间研究生生涯已近尾声，在论文行笔至此，往日的一幕幕景象不由自主地浮现在眼前。回顾自己的研究生生涯，五味杂陈、百感交集，经历很多的人和事，有难以忘怀的，有痛彻心扉的，更优难以割舍的。此时此刻，想说的话有很多，但唯有感激涌上心头。

首先，最需要感谢和最应该感谢的人是我的导师黄智勇副教授，黄老师博学多才、学术严谨、工作认真且非常平易近人，在我研究生的求学路上，给与了莫大的教导、支持、鼓励和关怀。黄老师秉持授人以渔的教育理念，激发我们在学术研究过程中的热情和创造力，引导我们掌握科学、合理和高效的学习研究方法。在学术上，无论是在工程项目和科研论文中，特别是在论文写作过程中的几个关键阶段，黄老师如漆黑夜空中的萤火虫为我点亮前行的方向，一针见血地发现我的问题，无微不至地对我进行谆谆指导，不厌其烦地讲述着他的真知灼见，让我不断觉悟、不断成长。在生活上，黄老师传递我们一种积极、包容和踏实的心态，教导我们正确的为人处世方法，让我们以一种良好的心态去面对未知的生活，以更加从容的态度去迎接更加多姿多彩的未来。吾生有幸遇吾师，定当谨记教诲，勇往直前。

其次，需要感谢实验的师兄、师姐、师弟和师妹们，在求学的路上，有你们的相伴是吾生的一件幸事。大家共同营造和谐、友好的实验室学习氛围，一起学习、生活，一起追逐梦想，一起赶超未来，是一段宝贵的经历和财富。这里，尤其需要感谢虞智师弟，在此论文与工作实验中，需要许多困难和绊脚石，虞智师弟给予了莫大的支持和无私的帮助，感谢虞智师弟与我一起分析问题、解决困难与突破瓶颈，正是在你的帮助下，使我论文不断地完善。祝实验室全体同学们学业有成、事业有成、家庭有成，前程繁华似锦，未来可期。

然后，特别需要感谢我的父母，感谢你们永远支持我这个任性的人，支持我的决定；感谢你们无微不至的关心和照顾，你们一如既往地鼓励我，让慢慢地成熟、蜕变，一步步完成自己的学业。

最后，由衷感谢百忙之中抽出时间对我论文进行评审的专家、教授，感谢你们的宝贵意见使我的研究能更进一步。

李渊明

二〇二〇年四月 于重庆