

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 智能监控视频行人重识别方法研究和系统实现

专业学位类别 工 程 硕 士

学 号 201822011033

作 者 姓 名 李行宇

指 导 教 师 闵锐 研究员

分类号

密级

UDC^{注1}

学 位 论 文

智能监控视频行人重识别方法研究和系统实现

(题名和副题名)

李行宇

(作者姓名)

指导教师

闵锐

研究员

电子科技大学

成 都

(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 工 程 硕 士

工程领域名称 电子与通信工程

提交论文日期 2021.3.31 论文答辩日期 2021.6.2

学位授予单位和日期 电子科技大学 2021 年 6 月

答辩委员会主席

评阅人

Research and System Realization of Pedestrian Re-identification in Intelligent Surveillance Video

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline: **Master of Engineering**

Author: **Xingyu Li**

Supervisor: **Rui Min**

School: **School of Information and Communication**

Engineering

摘 要

随着智能安防设备的不断发展, 智能监控摄像头在公众场所得到了越来越多的应用, 基于监控摄像头的智能视频监控系统研究领域在迅速地成长。行人重识别作为近年来比较火热的研究方向, 在计算机视觉领域和智能视频监控领域都受到了广泛的关注。2012 年以来, 深度学习取得了重大的进展, 在图像检测和分类的各个分支都得到了应用。通过引入深度学习理念, 行人重识别也迎来了新的进展。现有的行人重识别模型, 都是基于对监控视频进行预处理得到的行人图像, 这需要大量的准备工作。针对现实场景, 单独的行人重识别模型并不能满足应用需求, 因此结合行人检测与行人重识别具有很大的研究价值。同时, 目前的行人重识别主要基于行人的整体特征, 局部特征提取有所遗漏, 识别性能受到一定的限制。本文的主要研究工作和贡献如下:

首先, 对行人检测主流框架的实现原理和基本架构进行了研究和性能的测试, 对比。本文对 one-stage 或 two-stage 检测算法进行了研究, 并对其中两个具有代表性的框架 Faster Region Convolutional Neural NetWork(Faster R-CNN)和 Single Shot Detection(SSD)框架进行了更为深入的研究, 测试和比较, 根据测试的结果选择 SSD 检测框架作为智能监控行人重识别系统的视频预处理模块。

其次, 对基于多尺度特征的行人重识别进行了研究。本文针对行人局部特征难以捕捉的问题, 提出了基于多尺度特征的行人重识别研究方法 WholeNet, 通过引入深度可分离卷积对传统卷积层进行改进, 形成新型卷积层, 降低参数数量。在残差网络的瓶颈块基础上引入统一聚合门来进行动态尺度融合, 以及引入新型卷积层, 组成多尺度特征残差块, 通过叠加多尺度残差块构建 WholeNet。随后在主流行人重识别数据集上对 WholeNet 和其他行人重识别方法进行性能的测试与比较, 测试结果证明 WholeNet 方法优于其他方法。

最后, 对智能视频监控行人重识别系统进行了设计与实现。首先对系统进行需求分析, 根据需求对系统的整体架构进行了设计, 随后依据系统的整体架构设计对系统各个模块进行实现。在系统构建完成后, 对系统的准确性和实时性进行了评估, 并且对系统进行了现实场景的验证。结果证明系统实时性和准确性能够满足日常使用要求。

关键词: 行人重识别, 行人检测, 多尺度特征, 视频监控

ABSTRACT

With the continuous development of intelligent security equipment, intelligent surveillance cameras have been more and more applied in public places, and the research field of intelligent video surveillance system based on surveillance cameras is growing rapidly. Pedestrian re-identification, as a hot research field in recent years, has attracted extensive attention in the field of computer vision and intelligent video surveillance. Since 2012, deep learning has made significant progress and has been applied in all branches of image detection and classification. Through the introduction of deep learning concept, pedestrian re-identification also ushered in a new progress. The existing pedestrian re-identification models are all based on the pedestrian image obtained by preprocessing the surveillance video, which requires a lot of preparation work. For the real scene, the single pedestrian re-identification model can not meet the application requirements, so the combination of pedestrian detection and pedestrian re-identification has great research value. At the same time, the current pedestrian re-identification is mainly based on the overall feature of pedestrians, and the local feature extraction has some omissions, so the recognition performance is limited to some extent. The main research work and contributions of this paper are as follows:

Firstly, the implementation principle and basic architecture of the mainstream pedestrian detection framework are studied, and the performance is tested and compared. In this paper, the one-stage and two-stage detection algorithms are studied. In addition, two representative frameworks, Faster Region Convolutional Neural Network (Faster R-CNN) and Single Shot Detection (SSD), are studied, tested and compared in greater depth. According to the test results, the SSD detection framework is selected as the video preprocessing module of the intelligent monitoring pedestrian re-identification system.

Secondly, pedestrian re-identification based on multi-scale features is studied. Aiming at the problem that local pedestrian features are difficult to capture, WholeNet, a research method for pedestrian repeat recognition based on multi-scale features, is proposed in this paper. By introducing deep separable convolution, the traditional convolution layer is improved to form a new convolution layer and the number

of parameters is reduced. On the basis of the bottleneck block of the residual network, a unified aggregation gate is introduced to carry out dynamic scale fusion, and a new convolutional layer is introduced to form a multi-scale characteristic residual block. WholeNet is constructed by superimposing multi-scale residual blocks. Then the performance of WholeNet and other pedestrian re-identification methods is tested and compared on the mainstream pedestrian re-identification dataset. The test results prove that WholeNet is superior to other pedestrian re-identification methods.

Finally, the intelligent video monitoring pedestrian re-identification system is designed and implemented. Firstly, the requirements of the system are analyzed, the overall architecture of the system is designed according to the requirements, and then each module of the system is implemented according to the overall architecture design of the system. After the completion of the system construction, the accuracy and real-time performance of the system were evaluated, and the system was verified in a real scene. The results show that the real-timing and accuracy of the system can meet the requirements of daily use.

Keywords: pedestrian re-identification, pedestrian detection, multi-scale feature, video monitoring

目 录

第一章 绪 论	1
1.1 课题研究的背景与意义	1
1.2 国内外研究现状及发展	2
1.2.1 行人重识别研究现状	2
1.2.2 行人检测研究现状	4
1.3 本论文的结构安排	6
第二章 基于卷积神经网络的行人检测算法研究	8
2.1 引言	8
2.2 卷积神经网络简介	8
2.2.1 卷积神经网络基础结构	9
2.2.2 卷积神经网络特征	10
2.3 two-stage 目标检测	12
2.4 one-stage 目标检测	16
2.5 实验结果及分析	19
2.5.1 数据集介绍	19
2.5.2 实验评价指标	20
2.5.3 检测结果及分析	21
2.6 本章小结	22
第三章 基于多尺度特征的行人重识别方法研究	23
3.1 引言	23
3.2 基于深度特征的行人重识别方法	23
3.3 多尺度特征提取网络 WholeNet	24
3.3.1 卷积层优化	26
3.3.2 多尺度特征残差块	27
3.3.3 统一聚合门	29
3.3.4 WholeNet 网络结构	30
3.4 基于多尺度特征的行人重识别方法评估	31
3.4.1 实验平台	31
3.4.2 实验数据介绍	31
3.4.3 实验评价指标	33

3.4.4 实验与结果分析	34
3.5 本章小结	41
第四章 智能视频监控行人重识别系统设计与实现	42
4.1 引言	42
4.2 系统需求分析	42
4.2.1 系统功能性需求分析	42
4.2.2 系统非功能性需求分析	43
4.3 系统整体架构设计	43
4.4 SSD 行人检测算法的重新训练	44
4.4.1 训练数据集	44
4.4.2 网络训练结果及测试	46
4.5 系统搭建	44
4.5.1 系统界面搭建	47
4.5.2 系统数据库搭建	48
4.5.3 SSD 通用目标检测框架调整	49
4.5.4 读取待检索图片功能实现	49
4.6 系统的功能测试	52
4.7 系统性能评估	53
4.7.1 系统准确性评估	53
4.7.2 系统实时性评估	53
4.8 智能视频监控行人重识别系统现实场景验证	54
4.8.1 验证平台	54
4.8.2 现实场景视频验证	54
4.9 本章小结	59
第五章 总结与展望	60
5.1 全文总结	60
5.2 后续工作展望	61
致 谢	62
参考文献	63
攻读硕士学位期间取得的成果	68

第一章 绪 论

1.1 课题研究的背景与意义

行人重识别(Pedestrian Re-Identification, Re-Id)是指同一个区域内不同位置的摄像头之间的行人匹配问题。行人重识别是图像识别与检测的一个新兴的研究方向,可以广泛应用于刑事侦查,安全保护,监控视频等领域。由于行人是不断移动的,行人图像在不同摄像头之间切换带来的拍摄视角,光照条件改变,行人背景变化等等因素,给行人重识别带来了巨大的挑战,因此行人重识别也成为了图像检测领域的一个研究的热点。一般来讲,行人重识别由图片的特征提取和特征向量的相似度计算两大部分组成。在深度学习广泛应用于行人重识别领域之前,特征提取的研究主要集中在获取鲁棒性强且具有判别性的低级视觉特征,包括颜色特征^[1-6]、纹路特征^[7]、形体特征(方向梯度直方图特征)^[8]和关键点^[9]等。随着深度学习的高速发展,行人重识别也开始引入深度学习这一强有力的工具,从而使识别性能有了明显的提高^[10]。

现有的行人重识别模型,都是基于对拍摄的监控视频进行剪切与标注获取的行人图像,预处理工作量比较大,不适用于现实的应用场景,单独的行人重识别模型也并不能满足应用需求。因此为了解决该问题,可以使用行人检测来进行预处理。行人检测指的是对图片或者视频进行检测,判别其中是否存在行人,如果存在行人,则对行人位置进行标记和定位。该技术拥有广泛的应用前景,可以应用于行人姿态分析,自动驾驶,智慧交通,安防监控,机器人制造等多个领域。同样,行人检测也因为深度学习的广泛应用而蓬勃发展,很多算法因为引入了深度学习的内容,算法效率有了极大的提高,如 R-CNN(Region Convolutional Neural Network)系列^[11], YOLO(You Only Look Once)系列^[12], SSD(Single Shot Detection)^[13]等。行人检测可以对监控视频进行行人图像的提取,并且作为已经拥有许多成熟的解决方案的领域,行人检测可以实现快速,高质量的预处理,因此结合行人检测与行人重识别具有很大的现实意义与研究价值。

除了现实场景应用存在限制之外,现有的行人重识别模型还面临着特征提取的尺度存在遗漏,表达性不够强的问题。目前行人重识别领域关注的特征主要是整体特征和局部特征,整体特征指的是行人作为一个整体而呈现出来的特征,局部特征指的是人脸,肢体躯干等人体局部的特征。目前的行人重识别模型提取的特征尺度组合基本都是固定的,特征尺度不够多样化,无法很好地整合整体特征和局部特征,也无法根据输入的图片去进行调整,所以特征的表达性存在限制。如何实现多

尺度的特征表达以及根据输入的行人图片对特征提取尺度进行动态的整合,从而提高特征的表达性,是个值得深入研究的课题。

1.2 国内外研究现状及发展

1.2.1 行人重识别研究现状

行人重识别是指根据行人身上一些表达力比较强的特征,从同一个监控区域中不同的摄像机视角下找到与某行人身份一致的图像。属于图像识别与检测的一个重要分支。根据是否引入深度学习,卷积神经网络等方法,可以把行人重识别的发展分为2012年前后两个阶段。2012年之前的行人重识别研究方法通常将行人重识别的流程分为两大部分^[14]:特征向量的提取^[15,16]和特征向量的距离度量^[17]。2012年之前研究的特征通常可以分为以下三类:低级、中级、高级特征。

(1) 低级特征。低级特征是指行人图片所拥有的图片纹理,颜色等方面的比较基础的特征。在行人重识别的研究领域中,单的低级特征因为表达能力有限制,所以通常会组合多种低级特征进行重识别。多个低级特征组合起来能有效增加特征的区分度和鲁棒性,同时也能够提升特征的表达能力。这样的组合在背景,光照等条件比较复杂的行人重识别领域中起到了十分关键的作用。

Murino 等^[18]提出一种对称性驱动的局部特征积累方法。该方法有两个步骤:首先截取行人图片,然后从图片中提取三种不同的颜色特征:最稳定的颜色区域和重复度比较高的结构颜色块,加权处理的颜色直方图,并且通过由三种颜色特征组合在一起的融合特征来对行人进行外观颜色上的表达。

纹理特征和颜色特征的组合存在一个问题:缺乏空间信息。针对这个问题,不同的学者给出了不同的解决方案,其中一种比较有代表性的方法是把空间区域信息和颜色,纹理特征进行整合。整合的思路如下:首先将行人图片分解为多个独立,不互相重叠的图像小块,然后对每个独立的小块进行纹理,颜色特征的提取。这种方法能够有效地增加特征中的空间信息。

(2) 中级特征。中级特征是指行人图像中的一部分具有较强区分度,表达能力强的局部特征。身体的不同肢体部位有着不同的视觉特征,因此我们可以通过这些视觉特征来对行人的肢体信息进行特殊的表达。Oyang 等^[19]在行人重识别研究领域引入非监督学习提取的显性区域图像信息,然后根据显性区域的排序结果对显性区域进行权重的二次分配。Cristani 等^[20]根据行人外观的预先设置的特征提取行人图片,在此基础上根据图画结构训练出人体的结构模型,该模型一般是包括11个身体部分。最后,根据从模型上提取出来的颜色直方图对行人进行具有区分度的表达。

(3) 高级特征。通常，我们会通过一些特定的标签来对身边的朋友进行描述，从而加深自己对朋友的印象。所谓的“标签”在行人重识别领域中指的就是高级属性特征。高级特征一般包括身上佩戴的物品，衣物，性别等属性，这些属性具有较强的区分能力。Hospedales 等^[21]在行人重识别中引入高级属性特征，其中包括了性别、发型、衣物款式、性别等属性。除了这些默认的属性，作者还自行标注了 10 多种和低级属性紧密相关的属性。在调用行人重识别方法时，先利用通过手动标记好属性的训练集对支持向量机^[22]进行训练，然后在行人重识别方法中将训练所得的属性判别权重引入。训练集具有很强的鲁棒性，原因是因为训练集来自于不同视角的监控摄像头，样本图片具有多样性。

2012 年之后，深度学习蓬勃发展，诸多深度学习的框架应用到行人重识别中，让行人重识别发生了翻天覆地的变化。在深度学习模型中，行人图片特征的提取和特征向量的距离度量不再是两个独立的环节，而是会将两个环节一起进行联合优化，因此其性能要远高于传统的模型。近年来，行人重识别两个环节的整合方式呈现一种多样化的趋势，其中主流的，影响力比较大的方式有混合式、独立式、端到端式等方法，如下图 1-1，1-2，1-3 所示。

在各种整合方式中，端到端式的整合方案是应用得最为广泛的，而且其整合效果也一直稳居前列。端到端式整合方案的主要思路就是打破行人图片特征提取和特征向量距离度量的界限，把两者联合在一起进行优化，从而获得更好的优化效果。

混合式整合方案则是指在特征提取环节将传统的人工设计特征和深度学习，卷积神经网络进行有机整合，从而获取更具表达性的特征向量。而特征向量距离度量环节，则与传统的行人重识别方案一致。

独立式整合方案在框架上与传统的行人重识别方法并没有明显的差异性，其特点是用卷积神经网络提取的特征来取代传统的人工设计的特征，提高特征的表达性和降低特征优化的难度。特征向量距离度量环节与传统的行人重识别方案没有明显的区别。独立式整合方案的一大优点就是更换特征提取模块方便，可以很容易地对特征提取网络进行替换。

GAN 网络也是常被用于解决行人重识别问题的方法之一。首先，GAN 网络可处理图像补全问题，其次，GAN 网络可辅助生成更多样本，文献^[23]提取数据集中人体的姿态，利用 GAN 网络生成具有其他相机风格与不同姿态的逼真样本来丰富训练集，解决了因缺乏不同姿态的行人训练数据而导致难以匹配的问题。Wei 等^[24]则利用 GAN 来克服复杂场景光照、视角和姿态等变化给行人重识别带来的困难，提出了 PTGAN 方法，从而进行对不同数据集的行人图像进行转换。同时在将背景转为符合要求的数据集风格的情况下依旧能够保持行人身体区域不变，以此来缩

小模型从源数据集到目标数据集的域差距。




图 1-1 混合式整合方法




图 1-2 独立式整合方法




图 1-3 端到端式整合方法

1.2.2 行人检测研究现状

行人检测指的是对图片或者视频进行检测，判别其中是否存在行人，如果存在行人，则对行人位置进行标记和定位。作为一个重要的计算机视觉的研究分支，在过去几十年，众多学者对其进行了深入且全面的研究。该技术拥有广泛的应用前景，可以应用于行人姿态分析，自动驾驶，智慧交通，安防监控，机器人制造等多个领域。在 2012 年之前，行人检测方法主要包含两种类型的方法：基于环境背景进行模型构建和基于机器自我学习两种研究方法。2012 年深度学习兴起之后，基于深度学习的方法开始得到大力的发展。

基于环境背景进行模型构建的算法指的是在背景静止,保持不变的情况下,对运动目标进行截取,并判断其中是否包含行人的算法。背景建模算法属于行人检测中较早使用的经典算法,其中有代表性的算法包括 PBAS 算法^[25],高斯混合模型^[26],样本一致性建模算法^[27],ViBe 算法^[28],基于环境背景进行模型构建的算法的主要思路是学习前面的部分帧图像,经过一定次数的学习迭代之后获得一个能判别背景的模型,然后用当前的帧图像与背景模型进行比对,前后帧图像不一致的,有差异性的区域即为要寻找的运动目标。

基于环境背景进行模型构建的算法具有快速部署,实时性好等优点,但是也存在缺点,如无法识别静止目标,雨雪天气性能差,复杂光照条件下鲁棒性比较差,无法处理重叠目标等等。这些缺点限制了背景建模算法的使用场景。

基于机器自我学习的算法是指让分类器对人工设计的特征进行自我学习,自我迭代,然后使用训练好的分类器对行人进行判别的算法。使用频率较高的人工设计特征包括边缘,色值,纹理等。同时,用于训练的分类器包括支持向量机,Random Forest, AdaBoost 等目标检测常见的算法。行人检测作为一个备受关注的研究方向,出现了许多优秀的算法,其中第一个有代表性的成果是基于梯度向量直方图的支持向量机(Supporting Vector Machine, SVM)算法^[8]。基于梯度向量直方图(Histogram of oriented gradient, HOG)的 SVM 算法由 Dalal 在 2005 的 CVPR 会议上提出,因为引入梯度向量直方图算子,使得行人检测准确率有了明显的提升,但是该方法也存在计算复杂,运行速度慢等不足。为了提高行人检测算法的运行速度,Viola 等借鉴了 VJ^[29]的人脸检测中的分类器结构框架,在行人检测中引入了 AdaBoost 级联分类器,同时对使用的特征进行了调整,把特征表达力一般的 Harr 特征换成 HOG 特征,在保证速度的同时也提升了特征表达能力。图 1-4 对 Cascade 分类器检测流程与结构进行了介绍。通过 AdaBoost 算法学习强分类器,然后将其部署到分类器的每一级中。由于分类器在训练过程中首先选择弱分类器,所以可以采用分类器集成的策略,集成表现优异的小部分弱分类器,通过少量的分类器来实现预期的目标。这种策略具有计算简单,速度快的特点,可以在前期就排除掉大部分冗余的背景图片,剩下的候选图片再由后面的分类器进行检测与判别,使得检测效率有了很大的提高。相比于基于 HOG 算子的 SVM 行人检测方法, Cascade 分类器检测算法在处理速度上提升了 10 倍。




图 1-4 基于级联 Cascade 分类器的检测流程

基于环境背景进行模型构建和基于机器自我学习两种研究方法在实际场景中的应用存在许多限制，实用性有待提高。自从 2012 年深度学习技术取得重大突破之后，许多研究领域开始引入深度学习，卷积神经网络等框架，通过卷积神经网络获取更具区分度的特征。同时，深度学习也在行人检测这一研究方向得到广泛的应用。同时，在通用目标检测领域，出现了许多优秀的通用目标检测框架，如 YOLO 系列、SSD、Feature Pyramid Networks(FPN)、R-CNN 系列等，这些框架可以用于对图片和视频中的行人进行检测，使行人检测的效率得到了很大的提升。

1.3 本论文的结构安排

本文的章节结构安排如下：

第一章：绪论。绪论章节对行人重识别研究领域的工作背景和研究意义进行了比较详细的介绍，同时对行人重识别，行人检测的发展历史，主流方法，研究现状做了比较详细的介绍。

第二章：行人检测算法研究。本章节主要对基于深度学习的行人检测的两种主流检测框架：one-stage 和 two-stage 框架进行了介绍，同时对两种框架中的代表 Faster R-CNN 以及 SSD 检测框架进行了讲解以及性能上的比较。

第三章：多尺度特征行人重识别方法研究。本章节主要对基于多尺度特征的特征提取网络进行了研究，提出了 WholeNet 特征提取网络，对 WholeNet 网络结构，网络组件特点进行了基本原理和基本结构的介绍。最后通过主流的行人重识别数据集上对 WholeNet 网络和其他行人重识别领域的优秀方法进行性能的测试和比较。

第四章：智能视频监控行人重识别系统构建。本章首先从功能性和非功能性这两个角度对系统需求进行了评估，随后根据需求对系统的整体架构进行了设计。然后介绍了 SSD 行人检测算法的重新训练和系统具体模块的搭建，最后对系统的各

个功能模块进行了测试。同时对系统的运行速度进行了评估，以及进行了实际场景的验证。

第五章：全文总结和展望。该章节概括了论文的主要内容，并对后续的工作进行了一系列的计划和展望。

第二章 基于卷积神经网络的行人检测算法研究

2.1 引言

行人检测指的是对图片或者视频进行检测,判别其中是否存在行人,如果存在行人,则对行人位置进行标记和定位。行人检测作为一个研究得比较充分,积淀深厚的领域,具有广泛的应用前景。目前行人检测已经在多个领域得到了应用,如行人姿态分析,自动驾驶,智慧交通,安防监控,机器人制造,安检刑侦等领域,并且在其中发挥了重要的作用。本文主要研究的是基于智能视频监控的行人重识别系统实现,通过行人检测对监控视频进行预处理是该系统的重要组成部分。2012年之后,随着深度学习取得重大突破,开始蓬勃发展之后,目标检测也开始大力应用深度学习的发展成果,识别准确率和识别速度都得到了重大的提升。深度网络在提取高层特征、表述特征能力上有着优异表现,因此需要找到高效的算法框架来发挥其优势。多数具有代表性的检测算法均尝试在多个方面对网络架构进行改进,根据检测步骤上存在的差异,我们可以对框架进行分类,将其分为 **one-stage** 框架和 **two-stage** 框架。**two-stage** 框架的检测流程通常由两个部分组成:先进行选取候选区域的预处理步骤,再对候选区域进行分类定位。**one-stage** 框架是不单独选取候选区域的方法,整个检测流程是一个阶段。行人检测作为目标检测的子方向,这些算法可以直接应用到行人检测中。本章首先简要概括了卷积神经网络的发展历史,讲解了卷积神经网络的基本原理,并详细分析了卷积神经网络的网络架构和结构特点,然后对 **one-stage,two-stage** 通用目标检测框架进行详细的介绍,并对两者进行性能上的测试和比较。

2.2 卷积神经网络简介

卷积神经网络是目前主要的特征提取算法。通过在全连接网络的基础上引入卷积核,池化层等结构,极大地降低了运算复杂度,使网络的运行速度有了很大的改进。除此之外,卷积神经网络还具有平移不变性,即能够在阶层结构不变的前提下对输入的信息进行具有平移不变性的分类,这也是卷积神经网络的一大优良特性。

卷积神经网络这一研究方向从上世纪八十年代开始出现,早期具有代表性的网络有 LeNet-5^[30], Time-delay Network 等等。进入二十一世纪以后,随着计算机设备的发展和 GPU 算力的迅速提高,以及深度学习理论的提出,卷积神经网络重

新焕发了生命力,发展迅猛,并且在 NLP, 计算机视觉领域得到了广泛的应用。自 2012 年的 AlexNet^[31]开始, 基于卷积神经网络的方法多次在 ImageNet 大规模视觉识别竞赛 (ImageNet Large Scale Visual Recognition Challenge, ILSVRC) 上获得优异的成绩, 如 2013 年的 ZFNet^[32]、2014 年的 VGGNet^[33]、GoogLeNet^[34], 2015 年的 ResNet^[35]以及 DenseNet^[36]等。

2.2.1 卷积神经网络基础结构

卷积神经网络由几个功能迥异的模块组合而成, 每个模块都有每个模块特定的功能。通过整合这几个部分, 形成了具有完整功能的卷积神经网络。本论文讨论针对图像分类的卷积神经网络, 如图 2-1 所示。




图 2-1 卷积神经网络结构

(1) 输入层。输入层指的是卷积神经网络的输入源, 一般为图片或视频。在行人检测研究领域, 输入一般指的是以像素矩阵形式出现的图片。同时, 图像形式的不同会影响输入层的深度, 黑白图像因为只有一个通道, 其深度为 1, 彩色图像因为拥有 R,G,B 三个颜色通道, 其深度为 3。

(2) 卷积层。卷积层在卷积神经网络中不可或缺, 起到了滤波器的作用。卷积层一般由一些自适应迭代的卷积核集合而成, 卷积核的深度通常和输入的数据相同, 其大小通常为 1×1 或者 3×3 , 在网络的训练过程中, 卷积核会自动进行学习, 不断地迭代参数, 直到卷积核能够对某些特定类型的视觉特征进行判别。视觉特征形式多样, 如特定的纹理特征, 颜色斑点, 边缘等等。高层网络的卷积核甚至能对某些特定的图案进行响应。同时卷积层在某种程度上相当于神经元的一个输出。神经元存在一个特性: 不会观察输入数据的全部, 只对其中一部分进行观察, 并且同一个空间内的神经元会相互分享参数, 对参数进行更新迭代, 即权值共享。卷积核的权值共享这样的特性, 可以极大程度地减少冗余的参数, 提升网络更新的速度, 同时也可以避免过拟合情况的出现。

(3) 池化层。在卷积神经网络中, 卷积层一般不会连续堆叠, 一般每隔几个

卷积层会插入一个池化层。池化层的作用在于它能够在保留数据特征的同时降低其大小，通过池化层能有效减少冗余的参数，节约算力，提高训练速度。

(4) 全连接层。图 2-1 中，我们可以看到在卷积神经网络的最后有 3 个全连接层。卷积，池化层和全连接层在功能定位上存在差异。卷积，池化层的作用是对输入源进行有效，表达性强的特征提取，全连接层的作用是根据卷积，池化层提取到的特征把输入源划分成不同的类别。全连接层在卷积神经网络中起到了感知器的作用，通过对输入的特征进行汇总以及对特征进行降维，输入特征通常被映射为二维特征。低维特征用于表征与单个样本对应的输出，高维特征用于表征样本批次。

2.2.2 卷积神经网络特征

卷积神经网络的主要特征有接受域，神经元空间排列，权值相互分享等。正是这些特性，让卷积神经网络的特征提取效率远高于全连接神经网络。

(1) 接受域。当输入源是高维度输入源时，为了节约算力，卷积神经网络通常采取部分连接的策略，单个神经元只关注输入数据的小部分区域，这一小部分区域通常被称为神经元的接受域(receptive field)。接受域的尺寸与卷积核的空间尺寸相同。同时接受域在深度上和输入源的深度相等。




图 2-2 接受域展示图

图 2-2 为卷积神经网络的部分网络结构，左边的绿色方块代表输入的数据，假设接受域是 4×4 ，输入源的大小为 $32 \times 32 \times 3$ ，则卷积层中的单个神经元会对应输入源中 $4 \times 4 \times 3$ 区域的权重，包括偏差参数共 49 个权重。同时在深度方向上和输入源的深度相同。一个接受域有 48 个权重，并且这 48 个权重可以自我学习，进行更新迭代。因此，即便是同一个卷积核，它和与它连接的输入源的每一层对应的权重都是不相同的。在这里相当于前面的每一个层对应一个传统意义上的卷积模板，每一层与自己卷积模板做完卷积之后，将各层的卷积结果相互叠加，同时加上偏置，得到最后的结果。单个卷积核只对应单个偏置参数，与输入源层数无关。

(2) 神经元空间排列。卷积神经网络使用的卷积核个数与输出数据的深度相同。卷积核的作用在于从输入数据中寻找具有区分度的图像特征,增加特征表达力。在卷积神经网络中,存在一种名为深度列的结构,即拥有相同的接受域,并且在深度方向上进行排列的神经元集合。

在使用卷积核之前,我们需要设置卷积核的移动步幅。步幅代表着卷积核每次移动的像素距离。步幅通常被设为 1 或者 2。根据实际场景需要可以设置更大的数字。滑动卷积核的意义在于减小输出数据的空间尺寸。

在卷积神经网络中,有时候需要对数据进行处理,从而使输出数据和输入数据在空间尺寸上保持一致。处理这种需求的常用方法称为 0 数值填充(zero padding),即使用数字 0 在输入数据的边界进行填充。通常 0 数值填充的大小为超参数。

假设输入数据的空间尺寸为 $A_1 \times B_1 \times C_1$, 网络处理结果的空间尺寸为 $A_2 \times B_2 \times C_2$ 。则输出数据和网络处理结果的尺寸大小对应关系如公式(2-1), (2-2), (2-3)所示。其中 K 代表卷积核数量, S 代表步长, F 为感受野代表尺寸, P 为 0 数值填充代表数量。

$$A_2 = (A_1 - F + 2P) / S + 1 \quad (2-1)$$

$$B_2 = (B_1 - F + 2P) / S + 1 \quad (2-2)$$

$$C_2 = K \quad (2-3)$$

(3) 权值相互分享。权值相互分享是指每一个卷积核在整个视觉区域是重复的,即所有的卷积核在同时参与某一特定深度的神经元计算是一致的。权值相互分享是有限定条件的,只针对于同一深度的神经元。权重相互分享有两个重要作用:

a. 对图像中一些具有共通性的特征进行提取。图像每个位置的像素可以通过和其他位置的像素相互分享权重来获取到不同位置的相同特征,增加特征表达的鲁棒性。

b. 权重相互分享使所需训练的参数仅为卷积核的参数量。对于局部连接网络,权重参数不相互分享,即在图像不同位置使用不同的卷积核。这种做法的好处是能够增加卷积神经网络的泛化能力,同时极大地降低网络训练的难度。

(4) 池化层。在卷积神经网络中,卷积层一般不会连续堆叠,一般每隔几个卷积层会插入一个池化层。池化层的作用在于它能够在保留数据特征的同时降低其大小,通过池化层能有效减少冗余的参数,节约算力,提高训练速度。常用的池化函数有平均池化函数(Mean Pooling),最大池化函数(Max Pooling),随机池化函数(Random Pooling)。三种采样函数示例如图 2-3 所示。




图 2-3 池化过程示例

2.3 two-stage 目标检测

two-stage 框架的基本思想是定位和分类这两大步骤分开运行，即候选窗口的定位和候选窗口的类别判断分开进行。基于 two-stage 框架思想设计的框架有许多种，其中占主流地位的是 R-CNN 系列通用目标检测框架。R-CNN 系列通用目标检测框架包含两个步骤：首先使用 RPN 网络或者选择性搜索方法产生候选区域，然后基于生成的候选区域进行定位和分类。R-CNN 系算法经过了几年的发展，已经有 R-CNN，Fast R-CNN，Faster R-CNN^[37]框架，三者的总体框架如图 2-4 所示。



图 2-4 R-CNN 系列总体框架

接下来主要介绍 Faster R-CNN 框架。Faster R-CNN 的具体框架图如图 2-5 所示。Faster R-CNN 框架包含 4 个模块：特征提取网络模块、Region of Interest 生成模块、Region of Interest 分类模块、Region of Interest 回归模块。

(1) 特征提取网络模块。特征提取网络模块主要为前文提到的卷积神经网络模块，基本原理和网络结构不再赘述。主要通过该模块从输入的图片中提取出具有区分度的特征，为后续的分类和定位做准备。

(2) Region of Interest 生成模块。Region of Interest 生成指的是在特征图的每

一个点上生成多个备选框 (R-CNN 系框架一般为 9 个), 然后对这些生成的备选框进行目标图片和背景图片的类别划分, 最后通过对备选框的方位进行微小的调整。

(3) Region of Interest 分类模块。Region of Interest 分类模块中起主要作用的是 RPN 网络。RPN 网络的作用是把目标和背景区分开来, 分类的标准是与检索目标区域是否有交集, 同时交集区域占检索目标区域的比例是否超过 10%。与检索目标区域有交集, 同时交集区域占检索目标区域的比例超过 10%, 则为目标, 否则为背景。

(4) Region of Interest 回归模块。Region of Interest 回归模块为 Fast R-CNN 框架。Fast R-CNN 采用了多任务 Loss 层, 把类别判断和位置精调统一用深度网络实现, 不再需要额外存储。具体实现是使用两个不同的全连接层, 第一个全连接层有 $N+1$ 个输出 (N 是类别总数, 1 是背景), 表示各个类别的概率值。第二个全连接层有 $4N$ 个输出, 表示坐标回归值 (tx, ty, tw, th), 这个与 R-CNN 是一样的, 每个类别都预测 4 个位置坐标值。Fast R-CNN 采用了 softmax 分类器, 定位误差采用 smooth L1 而不是 R-CNN 中的 L2。总代价为两者加权和, 如果分类为背景则不考虑定位代价。损失函数如下。 L_{cls} 表示类别的损失值, L_{loc} 表示位置回归的损失值。

$$L_{loc} = \sum_{i=1}^4 g(t_i^u - v_i) \quad (2-4)$$

$$g(x) = \begin{cases} 0.5x^2, & |x| < 1 \\ |x| - 0.5, & \text{otherwise} \end{cases} \quad (2-5)$$

$$L = \begin{cases} L_{cls} + \lambda L_{loc}, & u \text{ 为前景} \\ L_{cls}, & u \text{ 为背景} \end{cases} \quad (2-6)$$




图 2-5 Faster R-CNN 框架结构图

Faster R-CNN 框架的检测流程如下:

(1) 对输入图片进行尺寸大小的调整与裁剪, 然后把处理完成的图片输入特

征提取网络模块中进行特征提取，生成特征图。

(2) 在特征图每一个像素点上取 9 个候选的备选框，备选框具有 3 个不同的尺度和 3 个不同的长宽比。卷积神经网络中有池化层，池化层会调整特征图的空间尺寸，并且池化层的个数和特征图的空间尺寸高度相关。所以在生成备选框后按照特定的比例进行特征图和原始图像的映射。

(3) 将备选框输入到 RPN 网络中，通过 RPN 网络对备选框进行前景，背景的分类，同时通过计算前景先验框与真实目标之间的 bounding box 的偏差值，如 Δx ， Δy ， Δw ， Δh 等数值来进行粗略的定位，然后对备选框进行非极大值抑制。

接着对这些不同大小的备选框进行池化操作，将其映射为特定空间尺寸的特征图，输出 7×7 的特征图。

(4) 将特征图输入分类网络中，再通过 1×1 的卷积层进行类别的划分。

Faster R-CNN 的特点有以下几点：

(1) 提出了 RPN 网络，RPN 的映射过程如下图 2-6 所示。




图 2-6 RPN 映射过程

RPN 的主要思路是对输入源进行充分的卷积。RPN 网络按照功能可以分为回归层和分类层两个部分。回归层主要输出四个值： Δx ， Δy ， Δw ， Δh ，用于对备选框进行位置的调整。而分类层则是给每个锚点输出两个分数值：是真实目标和不是真实目标的分数。

(2) Fast R-CNN 网络和 RPN 网络之间存在特征共享的关系，并且两个网络可以联合训练。

(3) 使用了 ROI Pooling 技术。通过 ROI Pooling 将特征图上面的 Region of Interest 调整为特定空间尺寸的特征图，本文的空间尺寸设定为 7×7 ，为后续的备选框位置调整和分类做准备。ROI Pooling 通常为 Max Pooling。

(4) 使用了非极大抑制(Non-Maximum Suppression, NMS)技术。在 RPN 网络

中,存在锚点重叠的问题。锚点重叠会导致 suggestion 区域重叠的问题。为了避免 suggestion 区域重叠的问题,通常会使用 NMS 方法对 suggestion 区域按照进行排序,并且对排序结果进行多次迭代,根据最后一次迭代的排序表对 suggestion 区域进行选择。我们通常设定一个默认阈值,如果 suggestion 区域的重叠度(Intersection over Union, IoU)大于该阈值,则抛弃该 suggestion 区域。NMS 主要有两种处理方式,分别为 Hard NMS 和 Soft NMS。Hard NMS 的步骤如下:

- a. 根据 suggestion 区域的得分对 suggestion 区域从高到低进行排序;
- b. 取出 suggestion 区域列表(假设有 100 个 suggestion 区域)中第一个 suggestion 区域,计算剩下的所有 suggestion 区域(99 个 suggestion 区域)与该 suggestion 区域的 IoU,将该 suggestion 区域添加到另一个列表中;
- c. 舍弃 IoU 大于 IoU 阈值所对应的 suggestion 区域(认为是检测同一个物体);
- d. 重复 b 和 c 步骤,直至 suggestion 区域列表为空。

Soft NMS 和 Hard NMS 唯一的区别在于,处理 IoU 大于阈值对应的 suggestion 区域的方式,在 Hard NMS 中,直接把 IoU 大于阈值的 suggestion 区域丢弃,如式(2-7)所示。 s_i 代表 suggestion 区域的分数, M 代表目标, b_i 代表 suggestion 区域, N_t 代表 NMS 阈值。

$$s_i = \begin{cases} s_i, & \text{IoU}(M, b_i) < N_t \\ 0, & \text{IoU}(M, b_i) \geq N_t \end{cases} \quad (2-7)$$

而在 Soft NMS 中,处理方式如式(2-8)所示。

$$s_i = \begin{cases} s_i, & \text{IoU}(M, b_i) < N_t \\ s_i(1 - \text{IoU}(M, b_i)), & \text{IoU}(M, b_i) \geq N_t \end{cases} \quad (2-8)$$

相比于式(2-7),式(2-8)是一个跳跃性变化的函数。小于阈值时,分数不变,大于阈值,分数乘上一个小于 1 的系数。对式(2-8)进行改进,则如式(2-9)所示。

$$s_i = s_i e^{-\frac{\text{IoU}(M, b_i)^2}{\sigma}}, \forall b_i \notin D \quad (2-9)$$

对于靠近 M 的 suggestion 区域的分数给予更大的惩罚,即乘上一个很小的系数,对于远离 M 的 suggestion 区域的分值,给予小的惩罚。IoU 为 0,则惩罚为 0。

Faster R-CNN 利用 RPN 简化了候选区域的生成过程,并将其整合到整个测试流程中,使得目标检测的精度有了比较大的提高,同时还极大地提升了目标检测的速度。因此 RPN 网络对 Faster R-CNN 具有重要的意义。

2.4 one-stage 目标检测

one-stage 检测框架是指使用 CNN 卷积作为特征提取，没有 RPN 网络模块，目标分类和位置回归两个步骤同时进行的框架。这些结构上的特点使得 one-stage 检测框架拥有比 two-stage 检测框架更快的检测速度，但也意味着其检测精度要低于 two-stage 检测框架。one-stage 检测框架的思路是采用不同长宽比和尺度，在图片的多层特征图上进行密集的、平均的采样，在采样结果的基础上通过 CNN 提取特征，根据特征同时进行回归和分类两个步骤，即所谓的 one-stage。因此 one-stage 检测框架检测速度较快。但是密集，平均的抽样会存在正负样本的数量差距比较大的问题，导致训练出来的模型准确率不如 two-stage 检测框架，同时训练也比较困难。目前主流的 one-stage 框架包括 YOLO 系列，SSD，DenseDet 等。本文主要讨论 SSD 目标检测框架。SSD 在精度和检测速度上取得了比较好的平衡。SSD(Single Shot MultiBox Detector)算法从诞生至今，开发出来很多 SSD 算法的衍生版本，在目标检测领域中声名赫赫。SSD 算法把 YOLO 系列算法和 Faster R-CNN 算法的优点整合在一起，使得 SSD 算法既有比肩 Faster R-CNN 算法的精度，也有不输于 YOLO 算法的速度。SSD 的整个检测流程采用了端到端的训练方式，检测速度大幅提升。

SSD 检测框架借鉴了 VGG16 的网络结构，并且有自己独特的创新。算法的主要优点如下：

- (1) SSD 检测算法在速度和精度上面取得了很好的平衡，在各个主流的数据集上都表现优异。
- (2) 在结果的预测方面引入了特征金字塔方法，使得预测的准确率有了明显的提高。
- (3) 采用了端到端的训练方式，使得模型能够对低分辨率的图片也能有比较准确的分类结果。

SSD 的网络结构图如图 2-7 所示。




图 2-7 SSD 框架结构图

SSD 框架以在主流数据集上进行预训练的 VGG16 网络作为基本的网络结构。然后对 VGG16 的全连接层进行了调整，把全连接层 FC6, FC7 换成卷积层。FC6 用空间尺寸大小为 3×3 的卷积层进行替换，而 FC7 用空间尺寸大小为 1×1 的卷积层进行替换。同时对池化层 Pool5 进行调整，从步长为 2，空间尺寸为 2×2 调整为步长为 1，空间尺寸为 3×3 。在做了以上调整之后，还在 Conv6 上配套采用了扩展卷积。最后补充了一些卷积层，并且对原有的 FC8 和 Dropout 层进行了删除，还用数据集对网络结构进行了微调。我们在 Conv4_3 层特征图的后面增加了一个 L2 正则层。因为 Conv4_3 层在网络结构的前面，norm 值比较大，因此需要采取这样的措施来避免与后面的检测层差异过于明显。SSD 的特点是采用了多样化尺度的特征图，多样化尺度特征图的优点在于能够捕捉到更具区分度的特征。其设计理念如图 2-8 所示。




图 2-8 SSD 设计理念

SSD 核心设计理念总结为以下三点：

(1) 在检测过程中，使用多个不同空间尺寸的特征图。卷积神经网络有个特点，由于池化层和卷积层的作用，特征图在从前往后传输的过程中空间尺寸会逐渐变小。图 2-9 中可以看到，不同尺寸的特征图都可以用于检测。由于特征图的尺寸多样化，特征表达的区分度会优于单个尺度的特征图。




图 2-9 不同尺度的特征图

(2) 通过卷积提取检测结果。通过卷积提取检测结果的优点是减小卷积核的空间尺寸，使得网络变得更加轻量化，降低训练的复杂度。

(3) 锚点机制的学习。SSD 的备选框学习了 Faster R-CNN 中锚点机制的设计理念，每个锚点上都会设置尺寸多样化的备选框，然后在生成的备选框的基础上去预测 bounding box。生成的备选框的基础上去预测 bounding box 能够实现更快的预测速度。备选框的具体形式如图 2-10 所示，每个锚点都有多个不同尺寸的先验框。图中的行人会采用和他们形状最相似的备选框，然后根据选好的备选框预测 bounding box。




图 2-10 SSD 的先验框

同时，每个备选框都会对应一个边框生成一系列参数，参数主要包括两个部分：边框的位置信息和各个类别的评分。边框的位置信息包含代表边框中心的横坐标 x ，边框中心的纵坐标 y ，边框的宽度 w ，边框的高度 h 等内容。类别评分方面，评分数量等于类别数加 1，因为在 SSD 检测算法中背景也被视为一种类别，同时评分中排序第一的即是背景的评分。如果该评分是所有评分中的最高值的话，说明边框中没有目标，否则该最高值对应的类别就是边框中的目标对应的类别。边框的定位包含四个值 (cx, cy, w, h) ，分别表示边框的中心坐标以及宽高。但是真实预测值其实只是边框相对于备选框的转换值。备选框位置用 $d = (d^{cx}, d^{cy}, d^w, d^h)$ 表示，其对应边框用 $b = (b^{cx}, b^{cy}, b^w, b^h)$ 表示，则边框的预测值 l 则是 b 相对于 d 的转换值。 l 的具体数值如下所示。

$$l^{cx} = (b^{cx} - d^{cx}) / d^w \quad (2-10)$$

$$l^{cy} = (b^{cy} - d^{cy}) / d^h \quad (2-11)$$

$$l^w = \log(b^w / d^w) \quad (2-12)$$

$$l^h = \log(b^h / d^h) \quad (2-13)$$

我们一般把式(2-10)，式(2-11)，式(2-12)，式(2-13)称之为编码。预测时则进行反向操作，即解码，从预测值 l 中得到边界框的真实位置 b 。具体解码过程如下。

$$b^{cx} = d^w l^{cx} + d^{cx} \quad (2-14)$$

$$b^{cy} = d^y l^{cy} + d^{cy} \quad (2-15)$$

$$b^w = d^w \exp(l^w) \quad (2-16)$$

$$b^h = d^h \exp(l^h) \quad (2-17)$$

对于一个大小 $m \times n$ 的特征图，共有 mn 个单元，每个单元设置的备选框的数量为 k ，则每个单元共需要 $(c+4) \times k$ 个预测值，所有的单元共需要 $(c+4) \times k \times m \times n$ 个预测值。由于 SSD 检测框架采用卷积做检测，所以需要 $(c+4) \times k$ 个卷积核完成特征图的检测过程。

2.5 实验结果及分析

本节首先介绍实验所使用的 PASCAL VOC 数据集，然后阐述实验所用性能指标，最后使用数据集对 one-stage 和 two-stage 目标检测框架进行测试和比较。本文的实验平台为搭载了 Intel i5-8300H 和 GTX 1060 的电脑。

2.5.1 数据集介绍

PASCAL VOC 挑战赛(The PASCAL Visual Object Classes)是目标检测领域中公认的使用频率最高的数据集，经常被用于方法的性能测试与验证。

数据集的发展历程如下图所示，相同颜色的代表相同的数据集：




图 2-11 数据集发展历程

目前目标检测常用的是 VOC2007 和 VOC2012 数据集。两个数据集的样本包含四个大类别：运输工具、家具、动物、行人，包括背景总共 20 个小类，如图 2-12 所示。最后给出的预测结果只会输出用黑色粗体标注的类别。




图 2-12 数据集的类别

VOC 数据集的数据量统计如图 2-13 所示。

	train		val		trainval		test		数据集总量	
	Images	Objects	Images	Objects	Images	Objects	Images	Objects	Images	Objects
VOC 2007	2501	6301	2510	6307	5011	12608	4952	12032	9963	24640
VOC 2012	5717	13609	5823	13841	11540	27450	11540	27450	23080	54900
求和	8218	19910	8333	20148	16551	40058	16492	39482	33043	79540

图 2-13 VOC2007 与 2012 数据集及二者的并集数据量对比

2.5.2 实验评价指标

在测试方法性能, 评价方法的优劣时, 实验评价指标起到了非常关键的作用。因此我们要根据实际的需求选出符合要求的评价指标对方法进行评价。本文主要以 mAP(mean Average Precision)来测试方法的性能。mAP 指的是各个类别的 Average Precision 平均值, 而 Average Precision 指的是 PR 曲线与坐标轴所围成的区域的面积。接下来对精确率, 召回率以及 PR 曲线进行介绍。

一般测试样本被分为四类: 真阳性(TP),真阴性(TN),假阳性(FP),假阴性(FN)。具体类别划分和数值计算公式如表 2-1 所示。

表 2-1 评价指标

真实情况	预测为正	预测为反	召回率
正	TP (真正)	FN (假反)	$R = \frac{TP}{TP + FN}$
反	FP (假正)	TN (真反)	
准确率	$P = \frac{TP}{TP + FP}$		

通常我们根据分类器所给出的得分序列 (即预测结果序列) 对样本进行排序, 然后根据该排序把样本按照顺序再次输入到分类器中, 让分类器进行二次学习, 优化排序结果。把每次分类的准确率和召回率用曲线表达出来就会得到 P-R 曲线, 也可以成为 P-R 图, 如图 2-14 所示。mAP 的值为所有类别 AP 值的总和除以类别数。




图 2-14 P-R 曲线图

2.5.3 检测结果及分析

本论文中使用的数据集组合方案有两种：

a. PASCAL VOC2007 trainval+ PASCAL VOC2012 trainval, 即使用 VOC2007 和 VOC2012 的 train+val(16551)上训练, 然后使用 VOC2007 的 test(4952)测试, 用“07+12”表示。

b. PASCAL VOC2007 trainval&test+PASCAL VOC2012 trainval, 即使用 VOC2007 的 train+val+test(9963)和 VOC2012 的 train+val(11540)训练, 然后使用 VOC2012 的 test 测试, 用“07++12”表示。

测试结果如表 2-2 所示。

表 2-2 算法性能比较

目标检测框架	召回率	精确率	VOC07(mAP)	VOC12(mAP)	检测时间
Faster R-CNN	82.73%	64.78%	72.9(07+12)	70.1(07++12)	115.1ms
SSD	79.96%	62.97%	77.1(07+12)	75.2(07++12)	80.01ms

从检测结果可以看出 Faster R-CNN 的召回率、精确率比 SSD 更高, 这是由于 Faster R-CNN 先经过 RPN 生成候选区域, 相当于对目标先进行了粗略的检测, 最后再通过分类回归网络对候选区域再进行更加精确的检测, 使最终的检测结果的准确率高, 但这样会带来更大的计算消耗。而 SSD 直接进行一步检测, 因此检测精度会相对低一些, 但 SSD 拥有比 Faster R-CNN 更快的检测速度, 并且 mAP 更高。因此, SSD 目标检测框架更加适合应用于智能视频行人重识别系统。

2.6 本章小结

本章主要介绍基于卷积神经网络的行人检测方法，首先对卷积神经网络的基本网络结构，网络特征进行了阐述，然后对 two-stage 和 one-stage 目标检测框架的整体架构，各个模块的特征和特点进行了介绍，并分别对 Faster R-CNN 和 SSD 两个框架进行了详细的介绍。最后基于 PASCAL VOC 数据集对 Faster R-CNN, SSD 进行了性能的测试和评价，测试结果表明 SSD 算法更加适用于智能视频行人重识别系统。

第三章 基于多尺度特征的行人重识别方法研究

3.1 引言

行人重识别是指根据行人身上区分度比较强的特征，从同一个监控区域中不同的摄像机视角下找到与某行人身份一致的图像，属于图像识别与检测的一个重要分支。行人重识别面临两大挑战，首先是监控摄像头之间的视角变化引起的同一个行人的视觉特征变化，其次是小范围，局部的特征的差异难以捕捉。为了克服这两个挑战，行人重识别的关键在于提取多尺度的，表达性强的特征。这些特征需要能够覆盖各种尺度。然而，现有的针对多尺度特征学习的行人重识别模型比较少。近年来，行人重识别的方法大多以卷积神经网络作为主要的架构，在其基础上进行改进。然而，大多数 CNN 网络，如 ResNet，最初是为对象类别级的识别任务而设计的，即只能判断该目标属于什么类别，无法对同一类别的物体进行区分，这与重识别中的判断行人身份的任务有很大的不同。对于判断行人身份的任务，多尺度特性能够发挥更为重要的作用。现有的行人重识别方法有部分对多尺度特征进行学习，然而，这些尝试并没有能够动态地对多个尺度的特征进行整合。因此，本节提出多尺度特征网络 WholeNet 提取全尺度的特征。

3.2 基于深度特征的行人重识别方法

行人重识别是指根据行人身上比较独特，具有辨识度的特征，在同一个监控区域中不同的摄像机视角下找到与某行人身份一致的图像，属于图像识别与检测的一个重要研究方向。行人重识别的核心步骤包括特征向量的提取和特征向量的距离度量。其流程图如图 3-1 所示。




图 3-1 行人重识别流程图

特征向量的提取指的是从行人外观中提取出区分度比较高，且具有鲁棒性的

特征,以此作为特征向量距离度量的基础。特征向量距离度量是指通过特定的方法计算两个特征向量的距离,判断两个行人的相似度。根据是否引入深度学习,卷积神经网络等方法,可以将 2012 年作为一个分界线,把行人重识别的发展分为 2012 年前后两个阶段。本文主要讨论 2012 年以后的行人重识别方法。本文采取的行人重识别模型 2012 年之后出现的独立式的行人重识别模型。独立式行人重识别模型的结构图如图 3-2 所示。




图 3-2 独立式行人重识别


独立式行人重识别方法在框架上与传统的行人重识别方法并没有明显的差异性,其特点是用卷积神经网络提取的特征来对传统的人工设计的特征进行取代,让特征的表达能力更强和让特征优化变得更加简单。特征向量距离度量环节与传统的行人重识别方案没有明显的区别。独立式行人重识别方法的一大优点就是更换特征提取模块方便,可以很容易地对特征提取网络进行替换。例如文献^[38]提出一种姿态整合网络,将行人姿态作为特征提取的依据,然后以 KISSME 度量学习方法作为特征向量的距离度量方法。文献^[39]首先利用深度特征学习出一个基于卷积神经网络的嵌入式身份模型,然后以置信加权度量学习方法作为特征向量的距离度量方法,使得重识别准确率得到了有效的提升。本文以独立式行人重识别方法作为主要的研究方法。本文使用 WholeNet 作为特征向量获取的网络结构,余弦相似度作为特征向量的距离度量的方法。

3.3 多尺度特征提取网络 WholeNet

针对特征在尺度上存在的问题,本文提出了 WholeNet。WholeNet 的特点在于能够提取多尺度的特征,使得经过该网络提取的特征具有非常良好的特征表达能力。由图 3-3 我们可以看到,WholeNet 中的单个组件由多个卷积流整合而成,并且每一个卷积流具有不同大小的接受域。同时,WholeNet 中还引入了一个新的指数维度因子,通过该因子来决定每个卷积流关注的特征空间尺寸。指数维度因子在卷积流之间存在线性增加的关系,因此卷积流的特征空间尺寸是不一致的,从而使

捕捉到的特征尺度更加多样化。除此之外，WholeNet 网络中还引入了统一聚合门 (Unified Aggregation Gate, UAG)。空间尺寸各异的特征图通过统一聚合门生成的信道权重动态融合。聚合门是一个在卷积流之间互相分享参数的小型网络，其网络结构中有许多优良的属性。聚合门通过加权算法实现动态尺度融合。因为聚合门的加权算法是可以通过训练更新迭代的，根据输入调整信道权重。WholeNet 通过聚合门能够灵活地学习到多尺度的特征表达。如果我们需要重点学习某个特定尺度的输入图像特征，可以对聚合门进行调整，让其给特定的卷积流或尺度分配一个占主导地位的权重，从而使网络重点关注这个特定的尺度。同时，它也可以选择多个尺度并且对被选择的多个尺度进行混合，从而生成多样化的尺度。WholeNet 单个组件的原理图如图 3-3 所示。

除了通过统一聚合门学习多尺度特征之外，WholeNet 另外一个特点就是轻量级网络。轻量级网络的优势如下：(1)在智能视频监控系统中，拥有数量众多的摄像头，每个摄像头都在不间断地进行监控，产生数据。因此，比较合适的处理方案是在本地对输入的数据进行处理，提取输入源的特征再把特征传送回中央服务器，这样能够有效提高监控系统的数据传输效率。单个摄像头配套的设备算力有限，因此行人重识别特征提取网络的轻量化显得尤为重要。(2)在行人重识别研究领域中，由于数据采集困难，存在着数据集规模有限的问题。采用轻量级网络能够最大程度降低数据集规模有限带来的影响。接下来将进一步对 WholeNet 的特点做详细介绍。



3.3.1 卷积层优化

现有的应用于行人重识别特征提取的卷积神经网络普遍参数规模比较大，训练复杂。为了减少卷积神经网络的参数，降低网络的体积，提高网络的训练速度，本文借鉴了 MobileNet，对传统的卷积结构进行了分解。基本思路就是把一个传统的卷积模块用逐通道和逐点卷积模块进行替代。未分解前的卷积层函数如式(3-1)所示。 $*$ 代表卷积， k 代表卷积核大小， c 代表输入通道宽度， c' 代表输出通道宽度。

$$output = ReLU(w * x) \quad (3-1)$$

卷积层携带的卷积核 w 为：

$$w \in \mathbb{R}^{k \times k \times c \times c'} \quad (3-2)$$

分解后的卷积层函数如下：

$$output = ReLU((v \circ u) * x) \quad (3-3)$$

逐通道卷积核 v 为：

$$v \in \mathbb{R}^{k \times k \times 1 \times c'} \quad (3-4)$$

逐点卷积核 u 为：

$$u \in \mathbb{R}^{1 \times 1 \times c \times c'} \quad (3-5)$$

假设输入一个张量 $x \in \mathbb{R}^{h \times w \times c}$ ，其高度为 h ，宽度为 w ，则其计算量从 $h \cdot w \cdot k^2 \cdot c \cdot c'$ 下降到 $h \cdot w \cdot (k^2 + c) \cdot c'$ ，并且参数数量也从 $k^2 \cdot c \cdot c'$ 下降到 $(k^2 + c) \cdot c'$ 。因此，新的卷积结构更加适合应用于我们的多尺度特征提取网络。经过测试，逐点卷积在上，逐通道卷积在下，能更加有效地进行多尺度特征的学习。在后面的章节中，我们将经过改进的卷积结构称之为 Small3×3 卷积层。新旧卷积层对比图如图 3-4 所示。图 3-4 左边为标准 3×3 卷积层，图 3-4 右边为 Small3×3 卷积层。




图 3-4 卷积层对比图

3.3.2 多尺度特征残差块

ResNet 作为经典的特征提取卷积神经网络，在行人重识别研究中被广泛地使用。而 ResNet 的核心则是其残差块。我们通常把包含几个卷积层的组件称之为一个块。本文用函数 $F(x)$ 来表示单个块的处理结果。假设我们希望把希望实现的函数效果设为函数 $H(x)$ ，直接去学习残差 $H(x) - x$ ，即 $F(x) = H(x) - x$ ，比让函数 $F(x)$ 直接去学习 $H(x)$ 效果更好。所以最终一个块所实现的效果用函数来代表则是 $F(x) = H(x) - x$ 。这样处理之后能带来非常直观的好处：整个优化流程变得更加简便。我们只需要让 $F(x)$ 趋近于 0 就能达到预期效果，并且性能没有收到影响。让 $F(x)$ 通过自我学习迭代趋近于 0 有多种方法，L2 正则则是比较常用的方法。L2 正则方法的公式如下所示。

$$res = \min_w \left[\sum_{i=1}^N (w^T x_i - y_i)^2 + \lambda \|w\|_2^2 \right] \quad (3-6)$$

改进后的组件被称为残差块，图 3-5 中展示了残差块的结构。




图 3-5 残差块结构图

我们可以看到，一个残差块中包含两条路径，一条为残差路径 $F(x)$ ，一条为恒等映射路径 x 。图中的 $\oplus$ 表示逐元素相加，要实现逐元素相加的前提是两者的维度相同。

残差路径主要有 2 种，如图 3-6 所示。图左显示的是传统的残差块结构，传统的残差块包含两个卷积层，卷积层的空间尺寸均为 3×3 。右边的则是瓶颈块 (Bottleneck Block)。和传统的残差块相比，瓶颈块引入了两个瓶颈层，即两个 1×1 的卷积层，先对输入进行降维，最后在恢复输入的维度。引入瓶颈层的好处就是能够使运算量得到大幅度的降低，节约算力。




图 3-6 不同的残差路径

鉴于瓶颈块的优秀性能，WholeNet 中引入了瓶颈块，并把 Small3×3 卷积层应用于瓶颈块中，组成多尺度特征残差块。多尺度特征残差块结构图如图 3-7 所示。




图 3-7 多尺度特征残差块结构图

给定一个输入 x ，则通过全尺度特征残差块之后得到的输出为：

$$y = x + \tilde{x}, \text{ s.t. } \tilde{x} = F(x) \quad (3-7)$$

其中 $F(x)$ 代表经过一个 Small3×3 层处理的结果，一个 Small3×3 层只学习一个特定的尺度特征，本文的尺度设定为 3。图中之所以没有显示 1×1 卷积层，是因

为 1×1 卷积层只起到调整特征向量维数的作用，对特征信息整合环节没有影响。

同时，为了学习多尺度特征，本文改进了残差函数 F ，在残差函数 F 中引入了一个新的维度表示特征尺度，用指数 t 代表。当 F^t 中的 $t > 1$ 时，则代表我们堆叠了 t 个 $\text{Small}3 \times 3$ 层，此时接受域的空间尺寸为 $(2t+1) \times (2t+1)$ 。 $\tilde{x}$ 是表示到 T 个增量尺度的和，其表达式如下：

$$\tilde{x} = \sum_{t=1}^T F^t(x), T \geq 1 \quad (3-8)$$

当 $T = 1$ 时，等式(3-8)退化成等式(3-7)。这种快捷连接方式允许在当前层学习到的较小尺度的特征在下一层中有效地保存，从而使最终的特征能够覆盖整个空间尺度范围。

3.3.3 统一聚合门

前面的章节提到，网络支撑组件由多个具有不同接受域的卷积流组成，每个流都可以提供特定尺度的特征。为了学习多尺度的特征，本文对不同卷积流的输出用动态的方式去进行组合。也就是根据输入的图片，给不同的权重分配不同的尺度。本文通过聚合门来实现动态尺度融合的效果。聚合门是可以进行自我学习的小型卷积神经网络。接下来对聚合门的基本原理进行介绍。

让 x^t 来表示 $F^t(x)$ ，全尺度残差 $\tilde{x}$ 的计算公式如式(3-9)所示。

$$\tilde{x} = \sum_{t=1}^T G(x^t) \odot x^t, \text{s.t. } x^t \triangleq F^t(x) \quad (3-9)$$

$G(x^t)$ 以向量的形式出现，其维数和 x^t 的通道维数相同， $\odot$ 为逐元素乘积。 G 是一个小型卷积网络，由非参数的全局性平均池化层^[40]和多层感知器(MLP)组成。MLP 带有一个 ReLU 激活的隐藏层，然后是 sigmoid 激活函数。为了减少参数开销，我们采用一个衰减比率 r ^[41]来降低 MLP 的隐藏层维数，即首先将特征维度降低到输入的 $1/r$ ，然后经过 ReLU 激活后再通过一个全连接层升回到原来的维度。这样做的好处在于不仅使得网络具有更多的非线性，可以更好地拟合通道间复杂的相关性，而且极大地减少了参数量和计算量。当 $r = 16$ 时整体性能和计算量最为平衡。

本文选择使用信道权重，即聚合门网络 $G(x^t)$ 表示第 t 个卷积流的向量，与使用提供简略的尺度融合的单标量输出函数是不相同的。信道权重的选择意味着尺度更为精细地进行融合，这样使得每个特征通道可以得到更好的调整。另外，根据具体输入的图片，权重会对应地动态调整。这一个特点在行人重识别方法中具有重要的地位，因为实际场景中检测的行人的身份不同于训练网络所使用的训练集中

行人的身份。

单个多尺度特征残差块内的聚合门由所有的卷积流所共享，即每个卷积流对应的聚合门网络模块是相同的，即如图 3-7 虚线框所示。这一共享特性借鉴了卷积神经网络的权值共享的理念，给 WholeNet 带来的优良特性有下面两点：

（1）参数的数量独立于卷积流基数 T ，使得模型的可拓展性有所增强。

（2）在反向传播时有更好的表现。假设使用一个损失函数 L 来监控网络的训练进度，并且该损失函数是可微的并且梯度是可计算的，则有以下公式：

$$\frac{\partial L}{\partial G} = \frac{\partial L}{\partial \tilde{x}} \frac{\partial \tilde{x}}{\partial G} = \frac{\partial L}{\partial \tilde{x}} \left(\sum_{t=1}^T x^t \right) \quad (3-10)$$

式(3-10)中的第二项表明来自所有流的监督信号被聚集在一起来指导 G 的学习。当每个卷积流都有独立的聚合门网络时，这个特性就消失了。

3.3.4 WholeNet 网络结构

WholeNet 由多个多尺度特征残差块叠加而成，因此不需要针对网络的每个阶段专门定制结构。WholeNet 的网络架构如表 3-1 所示。下面用 fusedblock 来表示多尺度特征残差块。

表 3-1 WholeNet 架构

网络阶段	输出	WholeNet 结构
conv1	128×64, 64	7×7 conv, stride 2
	64×32, 64	3×3 average pool, stride 2
conv2	64×256	fusedblock×3
transition	64×32, 256	1×1 conv
	32×16, 256	2×2 max pool, stride 2
conv3	32×16, 384	fusedblock × 2
transition	32×16, 384	1×1 conv
	16×8, 384	2×2 max pool, stride 2
conv4	16×8, 512	fusedblock × 3
conv5	16×8, 512	1×1 conv
gap	1×1, 512	global average pool
fc	1×1, 512	fc

WholeNet 的参数数量只有 220 万，multi-add 运算为约 1000 万次。如果我们用传统卷积模块替代多尺度特征残差块，则无论是参数数量还是 multi-add 运算会增加到原来的三倍，因此可以看出卷积优化的有效性。表 3-1 中的标准 WholeNet

在实践中可以很容易地进行调整,以平衡模型大小、计算成本和性能。在多流设计方面,WholeNet 与 Inception^[42]和 ResNeXt^[43]相似,但在几个方面有重大差异。首先,WholeNet 中的特征流尺寸由指数因子 t 来确定,指数因子 t 在卷积流之间保持一个线性递增的状态。并且所有的特征流由 $\text{Small}3 \times 3$ 层组成,但是每个特征流使用的 $\text{Small}3 \times 3$ 层数量不同,因此其接受域的大小也有所差异。拥有多个尺寸的接受域使得网络的特征尺度提取范围明显增大。而 Inception 网络结构以及网络结构中的池化层,卷积层的混合操作都是手动设置的,和 WholeNet 有比较大的区别。并且 Inception 网络的多流计算共享是为了节约算力。ResNeXt 有多个特征流,但是特征流之间的特征尺度是相同的。其次,WholeNet 使用统一聚合门来进行各个尺度特征的动态整合,融合的操作粒度更加精细,并且参数能针对不同的输入进行相应的调整。而 ResNeXt 和 Inception 网络或者通过连接来融合特征,或者是通过逐元素相加来融合特征。因此,在特征整合方面,WholeNet 和 Inception 网络,ResNeXt 网络是有很大差异的。最后,WholeNet 使用优化过的卷积层,因此整个网络是轻量级的。与 SENet^[44]相比,WholeNet 在概念上有所不同。具体来说,SENet 的目的是通过对单个流的激活值进行调整来重新校准特征通道,而 WholeNet 的目的是有选择性地融合多个不同接受域大小的特征流,以学习多尺度特征。

3.4 基于多尺度特征的行人重识别方法评估

本节通过一些实验,对模型进行全方位,充分的测试和验证,以下是评估的具体内容。

3.4.1 实验平台

本节算法实验硬件设备为台式电脑,Ubuntu16.04 操作系统,CPU 为 i7-9700K@4.90GHZ,128GB 内存,GPU 为 NVIDIA GeForce GTX 1080Ti(12G)。程序代码是在基于 python3.6 的 pyTorch 框架上完成的。

3.4.2 实验数据介绍

本文我们在六个主流的行人重识别数据集上进行了实验:Market1501^[45]、CUHK03^[46]、DukeMTMC-reID (Duke)^[47]、VIPeR^[48]、MSMT17 和 GRID^[49]。除此之外,还在 PA-100K 上对模型的行人属性识别性能进行了评估。以下对这七个数据集进行介绍。

(1) DukeMTMC-reID(Duke)。DukeMTMC-reID 包含来自 8 个摄像机的 1812 个身份的 36411 张图像。训练集使用了 702 个身份的 16522 张图像。测试集包含 702 个身份、2228 个查询图像(probe/query)和 17661 个图库图像(gallery)。Duke 数

数据库图片如图 3-8 所示。

(2) CUHK03。CUHK03 是首个大规模行人重识别数据集，数据来自于五对位于不同区域的摄像头，其中包含 1467 个行人身份。CUHK03 数据库图片如图 3-9 所示。

(3) MSMT17。MSMT17 数据集采集于校园内的视频监控网络，网络包含三个室内的摄像头和十五个室外的摄像头。为了保证数据集的真实性和环境的多样性，工作人员每个月选择四天的监控视频，每天的监控视频包括早晨，中午，下午三个时间段，并且这四天还要保证天气条件不同。因此数据集的视频时长长达 180 小时。该数据集使用 Faster R-CNN 检测框架对原始视频进行预处理，截取出视频中的行人，然后再对预处理生成的图片进行人工标注。数据集中包含 4101 个不同身份的行人。MSMT17 数据库图片如图 3-10 所示。

(4) Market-1501。Market-1501 数据集出现于 2015 年，该数据集中的数据来源于六个摄像头，包含 1501 个不同身份的行人。Market-1501 使用 DPM 检测器对视频进行预处理，检测视频中出现的行人。Market-1501 数据库图片如图 3-11 所示。

(5) VIPeR。该数据集包括 632 个行人。每个行人在两个摄像头中都有出现。行人图片的尺寸设置为 48×128 。VIPeR 数据集的光照条件复杂，视角多样。

(6) GRID。GRID 数据集是在加州大学河滨分校的温斯顿钟楼大厅收集的。它由 2 个室内和 2 个室外摄像机收集。这些摄影机套图中有 43 个行人，共有 6920 张图像。

(7) PA-100K。PA-100K 数据集是最大的行人属性识别数据集，其包含 80000 张训练图片和 10000 张测试图片。每张图片都被标注有 26 种属性，如性别，是否佩戴眼镜，是否背包等等。



图 3-8 DukeMTMC-reID 数据集部分图片



图 3-9 CUHK03 数据集部分图片



图 3-10 MSMT17 数据集部分图片




图 3-11 Market-1501 数据集部分图片

3.4.3 实验评价指标

(1) 累计匹配特征。累计匹配特征(Cumulative Matching Characteristics, CMC)是行人重识别方法性能测试使用频率最高的性能评价指标。该曲线的横坐标为排名,纵坐标为识别准确率。Rank N 表示前 N 个识别结果中包含待检索目标的概率。识别率是 Rank N 数值和检索样本总数的比值。如图 3-12 所示。




图 3-12 CMC 曲线图

(2) 平均精度均值(mean Average Precision)。行人重识别问题中,对于每一个检测图片的匹配结果序列,在候选集中与其匹配正确的图片多数情况下并不能完美地依次排序。比如可能会出现 Rank 1 匹配之后直到 Rank 5 才有下一个正确匹配。因此,仅仅根据 Rank 1 的准确率来评价模型的性能是不够全面的,这种场景 mAP 更加适合作为评价指标。根据单张待检索图片的查询结果图片组合统计身份匹配正确的所有行人图片的排序位置,根据统计结果计算查询准确率。然后根据所有待检索图片的查询准确率计算查询准确率均值。最后根据所有待检索图片的精度均值,计算出 mAP 数值。

(3) F1 分数(F1-score)是分类问题的一个衡量指标。一些多分类问题的机器学习竞赛,常常将 F1-score 作为最终测评的方法。它是精确率和召回率的调和平均数,最大为 1,最小为 0。由第二章可知,一般测试样本被分为四类:真阳性(TP),真阴性(TN),假阳性(FP),假阴性(FN)。F1 分数的计算公式如下:

$$F_1 = \frac{2TP}{2TP + FN + FP} \quad (3-11)$$

3.4.4 实验与结果分析

(1) 网络结构测试。设卷积流基数 T 代表式(3-8)中的卷积流数量,对 T 的数值进行修改,然后在 Market 1501 数据集上测试网络的性能并进行比较。同时,对聚合门结构进行调整,设置统一聚合门与独立聚合门两个对照组,分别在 Market1501 数据集上进行测试。独立聚合门指的是每个卷积流对应的聚合门各不相同。测试结果如表 3-2 所示。

表 3-2 网络结构测试结果

模型类别	R1	mAP
T=1	87.6	68.1
T=2+统一聚合门	93.2	82.8
T=3+统一聚合门	94.3	84.0
T=4+统一聚合门	94.2	83.8
T=3+独立聚合门	93.6	83.2

从测试结果可以看出,随着 T 的增大,网络的检测性能在不断上升,当 $T=3$ 的时候达到最好的检测性能,当 T 继续增大的时候,网络的检测性能开始下降。因此,本文把网络的卷积流基数设置为 3。同时,由测试结果可以看出,采用统一聚合门的网络检测性能优于采用独立聚合门的网络。

(2) 统一聚合门效果可视化。由统一聚合门产生的门控向量决定了特征流聚合的方式，因此我们可以通过可视化门控向量的图像来了解统一聚合门子网络学习的内容。为此，我们连接了最后一个多尺度残差块中三个流的门控向量，对 MSMT17 的测试图像执行 K-means 聚类，并选择最接近集群中心的前 15 个图像。

K-means 聚类算法流程如下所示。输入是样本集 $D = \{x_1, x_2, \dots, x_m\}$ ，聚类的簇数为 k ，最大迭代次数为 N 。输出是簇划分 $C = \{C_1, C_2, \dots, C_k\}$ ：

(1) 从数据集 D 中随机选择 k 个样本作为初始的 k 个质心向量：

$$\{\mu_1, \mu_2, \mu_3, \dots, \mu_k\};$$

(2) 对于 $n=1, 2, \dots, N$ ：

a. 将簇划分 C 初始化为 $C_t = \emptyset, t=1, 2, \dots, k$ ；

b. 对于 $i=1, 2, \dots, m$ ，计算样本 x_i 和各个质心向量 $\mu_j (j=1, 2, \dots, k)$ 的距离 $d_{ij} = \|x_i - \mu_j\|_2^2$ ，将 x_i 标记为最小的 d_{ij} 所对应的类别 λ_i 。此时更新 $C_{\lambda_i} = C_{\lambda_i} \cup \{x_i\}$ ；

c. 对于 $j=1, 2, \dots, k$ ，对 C_j 中所有的样本点重新计算新的质心。质心的计算公式如式(3-12)所示。

$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x \quad (3-12)$$

d. 如果所有的 k 个质心向量都没有发生变化，则转到步骤 c。

(3) 输出簇划分 $C = \{C_1, C_2, \dots, C_k\}$ 。

图 3-13, 3-14, 3-15 显示了 3 个示例集群，在同一个集群内的图像显示的模式是类似的，即全局尺度和局部尺度的外观组合。



图 3-13 背包+卫衣



图 3-14 绿色 T 恤+黑色头发



图 3-15 背包+黄色 T 恤+黑色短裤

(3) 主流数据集测试。在训练过程中，每个不同身份的人都作为一个独立的类。在网络的训练监控方面使用的是标记平滑的交叉熵损失函数。函数公式如下所示。

$$L_1 = -\sum_{i=1}^K p_i \log(q_i) \quad (3-13)$$

$$L_2 = \begin{cases} (1-\varepsilon) \times L_1, & \text{if } (i = y) \\ \varepsilon \times L_1, & \text{if } (i \neq y) \end{cases} \quad (3-14)$$

本文通过对 ImageNet 预先训练的权重进行微调实现了 WholeNet 的训练。batchsize 大小设为 64, 衰减权重值设置为 $5e-4$ 。微调过程中，我们使用 AMSGrad 和初始学习率 0.0015 对网络进行 150 个 epoch 的训练。学习速率每 60 个 epoch 衰减 0.1。在前 10 个 epoch, ImageNet 预训练的基础网络被冻结，只有随机初始化的分类器开放训练。图像被调整为 256×128 。数据增强包括随机翻转和随机擦除。

使用的行人重识别数据集可以根据数据集大小分为两组: Market1501、CUHK03、DukeMTMC-reID (Duke)、MSMT17 为大数据集，VIPeR 和 GRID 为小数据集。分别对大数据集和小数据进行测试。

a. 大数据集测试。本文为了能够更加全面地评价 WholeNet 的性能，将 WholeNet 与几种主流的行人重识别方法在四个大数据集上进行了性能的测试，表 3-3 为测试结果。

实验结果中其余行人重识别领域的主流方法的数据均来自于提出方法的论文，其中部分论文在个别数据集上没做实验，因此用“-”来表示其结果。目前主流的行人重识别模型的 backbone 大部分是 ResNet，因此它们的参数数量远远超过 WholeNet 的 200 万参数数值，显示了 WholeNet 网络结构的优越性。同时，由表 3-3 可以看出，WholeNet 在四个大型数据集上都实现了最优的性能，并且相比于其他的方法在 R1 和 mAP 上有明显的领先优势。说明采用全尺度特征能够有效提升行人重识别的性能。

表 3-3 大数据集的测试结果

方法	方法骨架	Market1501		MSMT17		CUHK03		Duke	
		R1	mAP	R1	mAP	R1	mAP	R1	mAP
Bilinear ^[50]	Inception	91.6	79.4	-	-	-	-	84.3	69.2
PCB ^[51]	ResNet	93.7	81.7	68.1	40.5	63.6	57.4	83.4	69.2
Mancs ^[52]	ResNet	93.0	82.5	-	-	65.6	60.3	84.8	71.5
CAMA ^[53]	ResNet	94.2	84.3	-	-	66.9	64.7	85.9	72.7
IANet ^[54]	ResNet	94.3	83.5	75.2	47.0	-	-	87.3	72.9
WholeNet	WholeNet	94.6	84.2	78.1	53.0	72.9	67.2	89.0	73.2

b.小数据集测试。GRID 数据集和 VlePR 数据集样本数量小,而且背景比较复杂,因此对于行人重识别方法具有很大的挑战性。并且由于两个数据集样本量有限,所以要先让模型在大规模行人重识别数据集上提前进行训练,再进行微小的调整。本文比较了 WholeNet 与六种先进的行人重识别方法的 Rank 1 准确率,实验的结果如表 3-4 所示。

表 3-4 小数据集的测试结果

方法	网络骨架	VIPeR	GRID
MuDeep ^[55]	Inception	42.9	-
DeepAlign ^[56]	Inception	48.5	-
JLML ^[57]	ResNet	50.1	37.4
Spindle ^[58]	Inception	53.6	-
GLAD ^[59]	Inception	54.8	-
HydraPlus-Net ^[60]	Inception	56.7	-
WholeNet	WholeNet	59.0	38.4

由表 3-4 可以看出, WholeNet 在 VIPeR 数据集上的表现优于其他方法。GRID

的测试难度比 VlePR 更大，因为 GRID 的样本数量很少（只有 125 的不同身份的行人）。除此之外，GRID 数据集是在加州大学河滨分校的温斯顿钟楼大厅收集的，数据采集的环境比较复杂，因此对行人重识别方法造成了比较大的考验。总的来说，WholeNet 在这两个小数据集上的强大性能表明了它在无法收集大规模训练数据的现实监控场景中的实用性。

c. Rank N 准确率曲线图。以下是各方法在主流数据集上的 Rank N 曲线图，由图可以看出，随着 N 系数的不断增加，准确率也在不断地上升，但是 WholeNet 方法还是比其他方法有着更高的准确率，验证了其优秀的性能。




图 3-17 Market1501 Rank N 曲线图




图 3-18 Duke Rank N 曲线图




图 3-19 CUHK03 Rank N 曲线图




图 3-20 MSMT17 Rank N 曲线图




图 3-21 ViPR Rank N 曲线图




图 3-22 GRID Rank N 曲线图

由图可以看出,在 N 达到 10 之后,各个主流方法的准确率都达到了比较高的准确率。但是在 N 从 1 到 5 的变化过程中,可以看到 WholeNet 的性能明显优于其他方法,而在行人重识别领域中, N 从 1 到 5 的准确率是比较关键的。因此,说明了 WholeNet 方法的优越性。

(4) 行人属性识别评估。虽然行人属性识别是一个类别识别问题,但它与行人重识别问题高度相关,因为多尺度的特征学习对于行人属性识别也是十分重要的。一些属性如“视角”是全局的,其他的如“戴眼镜”是局部的,识别“年龄”等属性也需要不同尺度的特征。

本文使用 PA-100K 数据集来进行行人属性识别的评估。评估指标方面,本文使用五个评价指标:平均精度(mA),精确率(Acc),准确率(Prec),回归率(Rec)以及 F1 分数(F1)。

为了方便训练网络,使用多标签的类别划分损失函数对训练的过程进行监督。网络用随机梯度下降法从头开始训练,动量为 0.9,初始学习率为 0.065,历时 50 个批次。学习速率在第 30 和 40 个批次时衰减到 0.1。

训练完成后,将 WholeNet 与两个优秀的行人重识别方法进行了比较,以下是对比结果。

表 3-5 行人属性识别结果

方法	PA-100K				
	mA	Acc	Prec	Rec	F1
DeepMar	72.1	70.1	82.4	80.1	80.9
HydraPlusNet	73.8	72.0	82.9	81.7	82.1
WholeNet	74.1	75.8	88.4	82.3	84.9

由测试结果可以看出，WholeNet 在预测属性方面尤其强大。

3.5 本章小结

本章介绍了基于多尺度特征的行人重识别方法 WholeNet,从 WholeNet 轻量化,多尺度特征这两个特点对 WholeNet 的特性与网络结构进行了介绍。同时,在六个行人重识别数据集上对 WholeNet 进行了性能的测试,并且与行人重识别领域目前的主流方法进行了性能上的对比。结果表明基于多尺度特征的 WholeNet 在性能上更具优越性,证明了基于多尺度特征能够有效提高行人重识别的准确率,并且对 WholeNet 进行了网络结构测试,统一聚合门效果可视化等测试,对模型进行了全方位的评估。

第四章 智能视频监控行人重识别系统设计与实现

4.1 引言

随着智能监控系统的普及和发展，行人重识别在现实中的应用场景也在不断地增加，如何把行人重识别落地，使之具有实用性，是目前一个热门的研究领域。目前的行人重识别研究大多数是基于经过预处理的数据集，而不是基于现实监控场景，在实用性这一方向上的探索和研究相对较少，所以其实用性受到了一定的限制。基于前两章的内容，本节致力于实现具有实时性，实用性，且带有 GUI 界面的行人重识别系统。通过整合 SSD 通用目标检测，把 SSD 通用目标检测和行人重识别模块级联在一起，以及使用 PyQt5 来构建系统的界面，使得行人重识别能成功落地于现实场景。

4.2 系统需求分析

4.2.1 系统功能性需求分析

作为一个完善的，功能齐全的实用性行人重识别系统，应该具备以下功能：

（1）行人重识别功能。作为一个智能监控行人重识别系统，这是系统的核心组成部分。通过行人重识别模块，对智能监控系统中拍摄到的行人进行行人重识别，找到符合检索要求的行人。同时，行人重识别模块还要求能有比较高的重识别精度和比较好的实时性，使系统能够在有限的时间内实现高精度的行人重识别功能。

（2）行人检测功能。智能监控行人重识别系统要进入到行人重识别环节，首先要对监控画面进行预处理，对监控画面进行行人检测，把检测到的行人截取并保存。因此行人检测功能是智能监控行人重识别系统必不可少的一部分。同时，我们对行人检测还有高检测精度和高检测速度的要求。因为输入的监控视频可能场景比较复杂，行人比较多，需要行人检测模块能够迅速地识别出行人并且将其保存。

（3）检索图片，查询视频输入功能。系统要给用户提供一个接口，让用户可以输入想要查询的行人。同时也应该给用户提供一个可以输入查询视频的接口，让用户自己选择需要查询的监控视频。除此之外，考虑到有些用户要检索的行人在一个监控视频中，我们还应该提供一个在视频中截取行人作为检索图片的功能。

（4）结果可视化功能。在用户输入要检索的图片之后，我们要将行人重识别结果直观地展示给用户。同时，我们还需要将检索结果在监控视频中的画面给展示

出来, 让用户对检索结果有一个更加清晰的了解。

4.2.2 系统非功能性需求分析

(1) 界面需求。系统应该提供一个简洁美观的用户界面, 界面应该用户友好化, 方便用户使用, 同时各个功能模块区分明确。

(2) 性能需求。智能监控行人重识别系统应该具备实时性, 对输入的图片, 视频数据具有比较高的处理速度。同时, 准确率也是有要求的。

4.3 系统整体架构设计

一个具备实时性, 实用性的行人重识别系统, 大致需要包含以下模块:

(1) 输入接口。给用户提供一个输入的途径, 让用户可以输入自己想要检索的图片以及想要查询的监控视频。

(2) 处理模块。对输入的图片, 视频进行处理。

(3) 用户界面。可以让用户直接使用功能和向用户展示其输入的检索图片和检索结果。

(4) 数据库。保存 SSD 检测在监控视频中检测到的行人的相关信息, 为后续的行人重识别和结果可视化做准备。

基于以上的需求, 智能视频监控行人重识别系统的架构如下: 视频读取检索图片, 检索图片读取, 识别, 结果可视化。用户通过检索图片读取模块可以输入自己想要检索的图片。同时还提供视频截取检索图片, 用户输入视频, 然后在视频中手动截取想要检索的行人作为检索的图片。识别模块则包含 SSD 行人检测, WholeNet 特征提取, 相似性度量三个子模块, 先输入想要查询的监控视频, 然后通过 SSD 行人检测截取视频中的行人, 随后通过 WholeNet 方法对待检索图片, 视频中的行人进行特征提取, 生成 512 维的特征向量, 最后在相似性度量模块中计算其余弦相似度。最后把视频中与检索图片相似度最高的前五张图片作为检索结果进行输出。同时, 为了让用户更加全面地了解检索结果, 点击检索结果图片的时候, 把检索结果所在的那一帧图片也展示出来, 并对其进行加色框注。系统的整体架构图如图 4-1 所示。




图 4-1 系统架构图

4.4 SSD 行人检测算法的重新训练

众所周知，SSD 通用目标检测框架的官方权重是在 PASCAL VOC 数据集下训练的，因此 SSD 通用目标检测框架可以检测 20 种物体，包括行人，汽车，猫，狗等物体。但是在智能视频行人重识别系统中，我们只需要 SSD 通用目标检测框架来检测行人，如果直接使用官方权重来检测的话，检测框架会对除了行人以外的物体也进行检测，这样会浪费算力，极大地增加 SSD 检测框架的工作量，同时会产生很多冗余的结果图片，对后续的行人重识别带来负面影响。因此本文对 SSD 通用检测框架进行行人这一单一类别的重新训练。

4.4.1 训练数据集

本文将 INRIA 数据集的图片和 VOC 数据集中行人的样本图片组成训练数据集，用于训练 SSD 模型。

INRIA 数据集产生于 2005 年，是行人检测领域最为经典的一个数据集。该数据集是作者在行人检测研究工作中积累的行人样本的集合，样本来源多样，包括谷歌，GRAZ-01，作者私人照片等等。INRIA 数据集的结构如图 4-2 所示。

70X134H96	2019/5/18 16:11	文件夹
96X160H96	2019/5/18 16:12	文件夹
Test	2019/5/18 16:13	文件夹
test_64x128_H96	2019/5/18 16:13	文件夹
Train	2019/5/18 16:15	文件夹
train_64x128_H96	2019/5/18 16:15	文件夹

图 4-2 INRIA 数据集结构

INRIA 数据集的图片分为两部分：

- (1) 原始图像。Train 文件夹中为训练用的样本图片，Test 文件夹为测试用的

图片。

(2) 经过尺寸调整的图像。文件夹 `train_64*128_H96` 和 `test_64*128_H96` 中同一个子文件夹的图片拥有着相同的尺寸。

INRIA 数据集部分图片如图 4-3 所示。

PASCAL VOC 数据集是目标检测领域中的经典数据集，被大量用于方法的验证。虽然近期的目标检测或分割模型更倾向于使用 MS COCO 数据集，但是这丝毫不影响 PASCAL VOC 数据集的重要性，毕竟 PASCAL 对于目标检测或分割类型来说属于先驱者的地位。目前使用频率最高的两个 PASCAL VOC 数据集是 PASCAL VOC 2007 与 PASCAL VOC 2012，这两个数据集频频在现在的一些检测或分割类的论文当中出现。本文把数据集中“行人”类别中的样本图片提取出来用于模型训练。PASCAL VOC “行人”类别部分图片如图 4-4 所示。



图 4-3 INRIA 数据集图片



图 4-4 VOC “行人”类别数据集图片

4.4.2 网络训练结果及测试

使用服务器对 SSD 网络进行训练, 硬件设备配置为: Windows10 64 位操作系统, CPU 为 i5-8300H@2.30GHZ, 8GB 内存, GPU 为 NVIDIA GeForce GTX 1060(6G)。本文使用 Adam 优化算法监督网络的训练过程, 衰减权重值设置为 0.0001, 迭代 20000 次。网络训练损失率变化图如图 4-5 所示, 横坐标为训练批次(batches), 纵坐标为平均损失率。




图 4-5 损失曲线图

SSD 网络随着迭代次数的增加, loss 值在逐步减少, 7000 次迭代之前, loss 值下降幅度比较大, 当网络迭代到 18000 批次左右的时候, SSD 网络的损失已经稳定了, 基本稳定至 0.1。

训练完成后, 使用 INRIA 的 Test 文件夹中的图片对训练权重进行批量测试, mAP 值达到了 93%, 检测速度平均为 42.1FPS, 能够满足监控视频行人检测的要求。图 4-6 是 SSD 行人检测的其中一张检测结果图, 可以看出检测性能良好。




图 4-6 重新训练后的 SSD 检测结果图

4.5 系统搭建

4.5.1 系统界面搭建

PyQT5 是通过 Python 语言调用 QT5 的一套实用性 GUI 框架。QT 库是一套最有用的 GUI 库。PyQT5 包含 600 多个类和 6000 个 API。PyQT5 在所有主流操作系统上的均能够正常运行。

PyQT5 主要使用的类包括 QtCore, QtGui, QtWidgets, QtNetwork, QtXml 等等, 通过这些类可以构建简便, 美观的 GUI 界面。

根据上一节的系统整体架构, 我们可以按照架构去构建了一个 GUI 界面, 如图 4-7 所示。GUI 界面分为两大模块: 功能按钮和结果展示窗口。功能按钮有四个: 视频读取待检索图片、检索图片读取、识别、结果可视化。可视化窗口包含待检索图片、检索结果、视频画面展示窗口。点击视频读取待检索图片可以从待检索视频中截取待检索图片, 而点击检索图片读取可以直接读取待检索图片。完成输入待检索图片这一步骤之后, 点击识别按钮, 则会依次启动行人检测, 行人重识别, 结果可视化模块。最后, 检索结果窗口由 5 个 QToolButton 组成, 点击结果可视化按钮, 检索结果窗口会把与待检索图片相似度最高的前五张检索结果图片输出到 5 个 QToolButton 上。同时, 点击检索结果的任意子窗口, 该检索结果所在的那一帧图片将会显示在视频画面展示窗口。



图 4-7 GUI 界面

4.5.2 系统数据库搭建

在智能监控行人重识别系统中，无论是 SSD 行人检测，还是行人重识别，都会产生大量的数据，因此数据库的支撑显得尤为关键。本文选择了 MYSQL 数据库来存储系统运行过程中生成的数据。MYSQL 是使用最广泛的关系型数据库之一。关系数据库的特点是将数据分散存储，根据数据类型和关系将数据存储在不同的数据表中，而不是将所有数据放在一个大仓库内，因此 MYSQL 的可拓展性比较强，而且查询速度很高。MYSQL 数据库使用的语言是数据库中最常使用的 SQL 语言。本文所搭建的行人重识别系统属于一个小型系统，使用 MYSQL 是比较好的选择。

针对智能视频行人重识别系统的情况，在 MYSQL 数据库中建立了两张表，一张表用来记录 SSD 行人检测所检测到的行人的相关信息，包括该行人图片的编号，所在帧图片的编号，在监控视频中出现的时间，行人所在方框的坐标信息等等。另外一张则是记录检索结果对应的行人图片编号。两张表格信息如表 4-1, 4-2 所示。

表 4-1 行人信息表

名称	类型	允许空	含义
personid	varchar(n)	否	行人编号
frameid	varchar(n)	否	检测帧编号
appeartime	varchar(n)	否	行人出现时间
lefttopx	int	是	行人所在框左上角 x 坐标
lefttopy	int	是	行人所在框左上角 y 坐标
rightbottomx	int	是	行人所在框右下角 x 坐标
rightbottomy	int	是	行人所在框右下角 y 坐标

表 4-2 检索结果对照表

名称	类型	允许空	含义
resultid	varchar(n)	否	检索结果编号
personid	varchar(n)	否	对应行人编号

4.5.3 SSD 通用目标检测框架调整

在智能视频行人重识别系统中，对 SSD 通用目标检测框架的调整和整合是一个重要的环节。针对智能视频行人重识别系统的需求，除了重新训练 SSD 网络之外，对 SSD 通用目标检测框架还进行了以下调整：

(1) 隔帧进行行人检测，增加检测率选择窗口。在行人检测过程中，因为一般的监控视频为 24 帧，如果对每帧都进行行人检测，不仅会极大地增大行人检测的工作量，减缓系统运行速度。同时还产生了大量的冗余行人图片，增大了系统的体积和行人重识别的工作量，对行人重识别的识别率提升也没有帮助。因此默认每 24 帧进行一次 SSD 行人检测，这样既能减少冗余的行人图片，又能保证系统的检测效率。不仅如此，系统还提供了检测帧率的设置窗口，可以手动选择 SSD 行人检测的检测帧率。

(2) 检测到行人时保存行人图片和行人相关信息到数据库。当 SSD 行人检测模块进行行人检测时，会把检测到的行人截取出来并保存到 gallery 文件夹，为后续的行人重识别做准备，同时，在检测出行人之后，会把该行人图片的编号，所在帧图片的编号，在监控视频中出现的时间，行人所在方框的坐标信息等等保存到 MYSQL 数据库中，方便后续的信息查询。

(3) 添加查询视频输入接口，让用户选择要输入的查询视频。

4.5.4 读取待检索图片功能实现

读取待检索图片功能有两个实现途径，一是直接读取待检索图片，二是视频读取待检索图片。

(1) 读取待检索图片。直接读取待检索图片使用的是 QFileDialog 模块中的 getOpenFileName 方法，当用户点击检索图片读取按钮时则会调用该方法，弹出的窗口如图 4-8 所示。




图 4-8 检索图片输入窗口

选择了要检索的图片之后，图片会在“待检索图片”窗口里显示，如图 4-9 所示。



图 4-9 “待检索图片”窗口效果

(2) 视频截取待检索图片。在智能视频监控的实际使用场景中，还存在一种情况：用户想直接从视频中截取要检索的行人图像，这种需求在紧急寻人以及罪犯抓捕过程中经常存在。因此智能视频行人重识别系统为了满足这一需求，在系统中加入了视频截取待检索图片这一功能选项。该功能的步骤如下图 4-10 所示。




图 4-10 视频截取待检索图片

首先，点击“视频截取待检索图片”按钮，随后弹出视频选择窗口，选择要输入的视频，选择完视频后被选择视频开始自动播放，通过空格键实现视频的播放与暂停，关闭视频播放窗口之后，当前帧图像被保存到指定文件夹，随后显示帧图像并用鼠标进行检索图片的截取。最后显示截取图片并将其保存到 query 文件夹作为待检索图片。

要实现以上效果，需要将 OpenCV 和 PyQt5 相结合，PyQt5 前面已经作了介绍，这里不再赘述。OpenCV 是一个能在多个主流平台上使用的计算机视觉库。OpenCV 的 API 主要用 C 语言完成，也有少部分 C++，使得 OpenCV 拥有很高的运行效率。除了 C 语言，OpenCV 还向其他多种语言开放接口。OpenCV 中包含多种计算机视觉，图像处理方面的 API。OpenCV 在许多领域得到广泛的应用，如目标检测，目标分割，行人跟踪，行人检测等等。

要实现视频截取待检索图片这一功能，关键在于实现显示帧图像并且截取检索图片这一步。在显示帧图像这一环节涉及到了 OpenCV 和 PyQt5 对象的转换。转换过程如下：

a.在窗体上新建了一个 label 标签，然后载入图片；

b.使用 OpenCV 读取图像；

c.将图像从 BGR 颜色空间转换成 RGB 颜色空间；

d.通过函数 QImage(str, int, int, int, QImage.Format)重新构造一个图像，该图像使用现有内存缓冲区数据，并且格式，高度，宽度和原有图片相同。宽度和高度必须以像素指定。bytesPerLine 指定每行的字节数。QImage 类的表示形式是独立的，提与硬件的图像表示形式无关。并且 QImage 类可以直接访问底层数据，能进行绘画操作；

e.通过 QPixmap.fromImage(QImg)方法将 QImage 对象转换成 QPixmap 对象，在屏幕上展示图像。QPixmap 类的作用是将图像在屏幕上展示出来。

其次是截取图片，截取图片的过程如下：

a.重新实现 QLabel 类，在类中重新实现了鼠标的点击、拖动、释放、以及绘画事件，即 mousePressEvent()，mouseReleaseEvent()，mouseMoveEvent()，paintEvent()；

b.定义鼠标画矩形的逻辑:新建一个矩形是否完成标志 flag，默认是 False，表示未完成。鼠标点击的时候，记录当前鼠标所在位置的坐标，flag 标志置为 True，表示开始画矩形。鼠标拖动的时候，flag 为 True，所以记录当前鼠标所在位置的坐标;鼠标释放的时候，flag 置为 False，表示矩形画完。实现过程中还用到了 QRect，Qpainter，Qscreen 类。

实现结果如图 4-11，4-12 所示。




图 4-11 视频截取待检索图片



图 4-12 待检索图片窗口显示截取结果

可以看到，视频截取检索图片功能顺利运行，功能的效果符合预期。

4.6 系统的功能测试

通过上面的步骤，智能监控行人重识别系统已经完成搭建，接下来需要对系统各个模块进行功能上的测试，确保系统各个模块功能正常。

（1）待检索图片输入功能。测试步骤：

- a. 点击“检索图片读取”按钮，随后弹出窗口，选择要检索的行人图片；
- b. 待检索图片选择完成后，图片正常显示于“待检索图片”窗口。

（2）视频截取检索图片功能。测试步骤：

- a. 点击“视频截取检索图片”按钮，随后监控视频选择窗口出现；
- b. 在窗口选择完视频后，开始播放视频；
- c. 按下 space 键暂停视频，并关掉视频播放窗口；
- d. 窗口弹出，显示视频帧图像，此时用鼠标画方框，截取要检索的行人；
- e. 截取的行人显示于“待检索图片”窗口。

（3）行人重识别功能。测试步骤：

- a. 点击“检索图片读取”按钮，随后弹出窗口，选择要检索的行人图片；
- b. 待检索图片选择完成后，图片正常显示于“待检索图片”窗口；
- c. 点击“识别”按钮；
- d. 点击“结果可视化”按钮，“检索结果”窗口出现和待检索图片相似度最高的前五张图片；
- e. 点击其中一张检索结果图片，“视频展示窗口”展示检索结果所在的那一帧图像，该检索结果被框注。

4.7 系统性能评估

经过对系统的多个方面的功能测试,已经能确保系统顺利运行。一个合格的智能视频监控行人重识别系统,不仅要能够正常运行,其重识别准确率和实时性也要有所保证,因此接下来从系统的准确性和实时性对系统进行评估。

4.7.1 系统准确性评估

行人重识别的系统准确性主要由系统的行人重识别模块 WholeNet 来决定。在第三章中,我们对 WholeNet 的性能进行了测试,在 Market1501、CUHK03、DukeMTMC-reID (Duke)、MSMT17、VIPeR 和 GRID 六个数据集上均取得了优异的成绩。其中在 Market1501 数据集上达到了 94.6% 的 R1 准确率和 84.2% 的 mAP。系统使用的 WholeNet 经过 Market1501 数据集的训练。进行图 4-13 是 WholeNet 针对 Market1501 的四组测试结果,图片最左是待检索图片,右边十张图片是和待检索图片相似度最高的十张图片,从左到右相似度逐渐降低。其中识别正确,则图片上方的数字编号为绿色,识别错误则为红色。由测试结果图可以看出,WholeNet 的重识别准确率比较高,达到预期。




图 4-13 行人重识别结果图

4.7.2 系统实时性评估

系统的实时性主要受 SSD 行人检测和 WholeNet 特征提取的影响。因此在对

系统进行功能测试的时候对算法的运行时间进行了多次统计，得到了以下的数据。

表 4-3 实时性数据统计

输入图片大小	每帧图像 SSD 行人	单张行人图像特征
	检测时间	提取时间
512×512	0.032s	0.002s

默认每一秒进行一次 SSD 行人检测，系统实测 SSD 行人检测的平均 FPS 为 31，即平均每帧图像 SSD 行人检测的时间约为 0.032s。SSD 行人检测模块检测到行人之后会将行人图片截取出来保存到 gallery 文件夹，之后 WholeNet 再对 gallery 文件夹里的行人图片进行特征提取。行人图片大小设置为 64×128 ，单张行人图片的特征提取时间约为 0.002s。从 SSD 行人检测和 WholeNet 特征提取的速度来看，系统的实时性符合日常使用要求。同时，在系统运行过程中还设计到 MYSQL 数据库的数据读取，但是因为本系统在 MYSQL 数据库中存储的数据总量在万级左右，量级比较小，因此 MYSQL 数据库消耗的运行时间基本可以忽略不计。综合而言，智能监控行人重识别系统的实时性达到了要求。

4.8 智能视频监控行人重识别系统现实场景验证

智能视频监控行人重识别系统在测试中表现良好，接下来将系统应用于实际生活场景，通过在生活区域拍摄的视频对系统进行现实场景的验证，对系统的性能以及实用性做进一步的评估。

4.8.1 验证平台

本章算法实验硬件设备为笔记本电脑，Windows10 64 位操作系统，CPU 为 i5-8300H@2.30GHZ，8GB 内存，GPU 为 NVIDIA GeForce GTX 1060(6G)。软件平台使用 PyCharm Community 2019.2，编程语言为 Python。

4.8.2 现实场景视频验证

本章用于验证的视频为两段在客流量比较大的市中心拍摄的视频。视频一是在行人天桥上拍摄，模拟监控摄像头位置的视频，视频每秒 30 帧，时长为 3 分 47 秒。视频 2 为行人道处拍摄的视频，客流量大，且有机机动车辆穿插于行人之中，场景复杂，对行人重识别具有比较大的挑战性。本文通过不同场景，不同人流密度的测试视频对智能视频监控行人重识别系统进行评估。测试视频部分截图如下图 4-

14, 4-15 所示。



图 4-14 测试视频 1 截图



图 4-15 测试视频 2 截图

(1) 直接输入待检索图片。点击“检索图片读取”按钮之后，向行人重识别系统中直接输入检索图片，检索图片如图 4-16 所示。

点击“识别”按钮，则接下来将选择查询视频，选择了待检索视频之后，可以选择检测的帧率，如图 4-17 所示。因为测试视频帧率为 30 帧，为了保持每秒进行一次 SSD 行人检测的效果，我们将检测帧率设置为 30 帧/秒。



图 4-16 检索图片




图 4-17 检测帧率选择

选择完帧率之后，则开始运行行人检测和行人重识别模块，运行结束之后，点击“结果可视化”按钮，显示检测结果图片，点击其中任意一张检索结果图片，则视频画面展示窗口显示该检索结果所在的那一帧完整图像。如图 4-18 所示。




图 4-18 检索完成后系统界面展示

点击了第五个检索结果图片，则视频画面展示窗口显示出了第五个检索结果图片所在的那一帧完整图像，并且该检索结果被黄色方框标注。可以看出，五个检索结果均与检索图片中的行人身份一致，行人重识别效果良好。

接下来我们用场景较为复杂的测试视频 2 来对系统进行评估。检索图片同为

图 4-16, 步骤与上面一致。行人系统运行结果如图 4-19 所示。



图 4-19 检索完成后系统界面展示

由运行结果可以看出, 测试视频 2 的人流密度比较大, 对行人的遮挡比较严重, 对行人重识别系统造成了一定的挑战, 但是前三个检测结果身份仍然能够和检索图片的行人保持一致, 证明了系统在复杂场景下的稳定性。

(2) 视频截取待检索图片

点击“视频截取待检索图片”按钮, 则首先选择视频, 如图 4-20 所示。




图 4-20 视频选择界面

我们选择从测试视频 2 中截取待检索的视频, 并把测试视频 1 作为查询视频。选择了要截取图片的视频之后, 视频开始播放, 点击鼠标右键, 视频暂停。关掉视频窗口之后, 弹出一个展示暂停时该帧画面的窗口, 通过拖动箭头进行检索图片截取, 结果如图 4-21 所示。




图 4-21 检索图片截取展示

截取完成之后，则截取结果出现在待检索图片窗口中。如图 4-22 所示。



图 4-22 截取流程完成后展示图

点击“识别”按钮，则后续过程与(1)一致。结果如图 4-23 所示。




图 4-23 系统完成重识别流程截图

由图 4-23 的结果可以看出，视频截取待检索图片功能运行正常，五个检索结果与待检索图片中的行人身份均一致，达到预期的效果。

4.9 本章小结

本章主要介绍了智能视频监控行人重识别系统设计与实现。本章首先从功能性和非功能性这两个角度对系统需求进行了评估，随后根据需求对系统的整体架构进行了设计。然后介绍了 SSD 行人检测算法的重新训练和系统具体模块的搭建，最后对系统进行了功能测试和性能评估，系统能够正常运行，准确性和实时性也都能够保证。最后进行了实际场景的验证，输入了实际的监控视频，验证了系统的实用性。

第五章 总结与展望

5.1 全文总结

本论文以行人重识别与行人检测结合，实用化行人重识别系统的设计和构建，在行人重识别中引入多尺度特征为重点研究内容。主要的研究内容如下：

首先，本文梳理了行人重识别，行人检测在国内外的研究现状，并简要介绍了深度学习中典型的卷积神经网络的基本理论知识。卷积神经网络因其自动提取多尺度深度特征的特性，在计算机视觉领域被广泛地应用，由此本文详细阐述了卷积神经网络中的深度特征提取方法，卷积神经网络分别通过卷积和池化操作自动提取图像一系列的简单和抽象特征及泛化特征，并将这些特征用于目标检测和识别任务。现有行人重识别模型，都是基于对监控视频进行预处理得到的行人图像，这需要大量的准备工作，不符合现实场景中行人重识别系统对于实时性的要求。因此将行人检测与行人重识别进行结合具有重要的意义。本文对行人检测主流算法：**one-stage,two-stage** 检测算法分别进行了研究，对两类算法中的代表性框架 **Faster R-CNN** 和 **SSD** 框架的运行原理以及结构进行了深入的研究，同时在 **PASCAL VOC** 数据集上对两个检测框架进行了性能的测试与比较，测试结果表明 **SSD** 检测算法更加适合应用于智能视频行人重识别系统。

其次，本文针对行人局部细微特征难以捕捉，特征表达能力存在限制的问题，提出了基于多尺度特征的行人重识别研究方法 **WholeNet**，通过将传统卷积层进行改进，拆分成逐通道卷积和逐点卷积，降低参数数量，从而有效地降低网络训练的复杂度和运行速度，起到网络轻量化的作用。同时在残差网络的瓶颈块基础上引入统一聚合门，通过统一聚合门对卷积流进行动态尺度融合，以及引入改进后的卷积层，组成多尺度特征残差块。随后在主流的大规模和小规模行人重识别数据集上对 **WholeNet** 和其他优秀的行人重识别方法进行性能的测试与比较，测试结果证明，无论是大规模还是小规模数据集，**WholeNet** 方法在性能上均优于其他方法。除此之外，还进行了网络结构测试，聚合门向量效果可视化，行人属性识别评估等测试，从多个方面对 **WholeNet** 方法进行全面的评估。

最后，本文对实用性行人重识别系统进行了构建。目前行人重识别的研究大多数是对理论方法的研究，把行人重识别应用于实际场景，让其发挥作用的尝试还比较少。本文首先对智能视频行人重识别系统的需求进行分析，在得出系统需求的基础上进行了系统架构设计，并对架构中的各个模块进行了实现和功能测试。同时，基于实际需求，对 **SSD** 检测框架进行了重新训练。最后，对系统进行了准确性和

实时性的评估, 以及通过两段不同场景的行人视频对系统进行现实场景的验证。验证结果表明系统的实时性和准确性符合要求, 能应用于现实场景。

5.2 后续工作展望

本文在特征提取和行人重识别系统构建两个方面取得了一定的成果, 但是研究工作仍有可以改进的地方, 以下是几点改进的想法:

(1) 在行人检测算法方面, 本文采用了 SSD 行人检测, SSD 行人检测的检测率还有待提高。可以考虑引入新的行人检测方法, 来提高待检测视频预处理的精度。

(2) 行人重识别系统的整体运行效率还有待提高, 后续可以通过优化系统组件, 从而提高系统的运行效率。

(3) WholeNet 的网络结构还有进一步优化的空间, 在增加 WholeNet 的泛化性方面还有许多工作可做。

致 谢

时光匆匆，三年的研究生时光如白马过隙，即将走向终点。三年，从迷茫走向坚定，从青涩走向成熟。值得庆幸的是初心未改，内心依旧充满着对探索未知的渴望与激情。在这里，首先要感谢的是闵锐老师，作为我的导师，闵老师在这三年里给予了许多指导和帮助，让我学会了如何成为一名合格的研究生，学会了如何开展科研。同时，我从闵老师那里也学会了許多为人处世的道理。衷心感谢闵老师在这三年里的关心与栽培。同时，也要感谢徐政五老师，崔宗勇老师，李晋老师在这三年里给予的帮助与指导，感谢几位老师在我的研究生成长道路上的指引与关心，让我受益颇多。

除了老师们，我还要感谢教研室的十一位同学：申虎，孙佳琪，程添，甄雨寒，张浩，高文文，钟晓语，张昭，曾梧桐，朱明城，王兆彬。感谢他们在这三年里给予的帮助，无论是科研上，还是日常生活上。三年的相处时光，留下了许多美好的记忆和开心的时刻。能和他们相遇，相识，是缘分，也是我的荣幸。

在这里，我也要感谢我的爸爸妈妈和姐姐。感谢他们在背后坚定的支持，让我能够在研究生期间能够专心科研，专心学习。没有他们的牺牲和付出，也不会有现在的我。养育之恩，终身难忘。

三年时间，从人生的低谷走出来，走向新生，走向充满希望的未来，算是完成了对自己的救赎。人很渺小，渺小经常怀疑是不是被宿命论操控。但是生命又很伟大，只要不放弃，一直默默地去努力，终能掌握自己的命运。即将推开新世界的大门的我，憧憬着，恐惧着，渴望着，也希望着。这也正是未知世界的魅力所在，充满着无限的可能，充满着无限的挑战与希望。最后，用《坂上之云》里面一句经典的台词作为这篇致谢的结尾：登高，坡顶自有青天，倘若正有一朵白云闪耀，那就望云爬坡吧。

参考文献

- [1] S. Khamis, C.-H. Kuo, V. K. Singh, et al. Joint Learning for Attribute-Consistent Person Re-Identification[C]. Cham, 2015, 134-146
- [2] M. Koestinger, M. Hirzer, P. Wohlhart, et al. Large Scale Metric Learning from Equivalence Constraints[C]. 2012 IEEE conference on computer vision and pattern recognition, Rhode Island ,2012, 2288-2295
- [3] W. Li and X. Wang. Locally Aligned Feature Transforms across Views[C]. Proceedings of the IEEE conference on computer vision and pattern recognition,Oregon,2013, 3594-3601
- [4] N. Martinel, C. Micheloni and G. L. Foresti. Saliency Weighted Features for Person Re-Identification[C]. European Conference on Computer Vision, Zurich,2014, 191-208
- [5] F. Xiong, M. Gou, O. Camps, et al. Person Re-Identification Using Kernel-Based Metric Learning Methods[C]. European conference on computer vision, Zurich,2014, 1-16
- [6] R. Zhao, W. Ouyang and X. Wang. Person Re-Identification by Saliency Matching[C]. Proceedings of the IEEE international conference on computer vision,Sydney,2013, 2528-2535
- [7] W.-S. Zheng, S. Gong and T. Xiang. Reidentification by Relative Distance Comparison[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(3): 653-668
- [8] N. Dalal and B. Triggs. Histograms of Oriented Gradients for Human Detection[C]. 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05), San Diego,2005, 886-893
- [9] D. G. Lowe. Object Recognition from Local Scale-Invariant Features[C]. Proceedings of the seventh IEEE international conference on computer vision,Corfu,1999, 1150-1157
- [10] L. Zheng, Z. Bie, Y. Sun, et al. Mars: A Video Benchmark for Large-Scale Person Re-Identification[C]. European Conference on Computer Vision,Amsterdam,2016, 868-884
- [11] R. Girshick. Fast R-Cnn[C]. Proceedings of the IEEE international conference on computer vision, Santiago,2015, 1440-1448
- [12] J. Redmon and A. Farhadi. Yolov3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018
- [13] W. Liu, D. Anguelov, D. Erhan, et al. Ssd: Single Shot Multibox Detector[C]. European conference on computer vision,Amsterdam,2016, 21-37

- [14] E.Ahmed, M.Jones and T.K.Marks. An Improved Deep Learning Architecture for Person Re-Identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015, Boston,3908-3916
- [15] Y. Yang, J. Yang, J. Yan, et al. Salient Color Names for Person Re-Identification[C]. European conference on computer vision,Zurich,2014, 536-551
- [16] R. Zhao, W. Ouyang and X. Wang. Learning Mid-Level Filters for Person Re-Identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition,Columbus,2014, 144-151
- [17] Z. Li, S. Chang, F. Liang, et al. Learning Locally-Adaptive Decision Functions for Person Verification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Oregon,2013, 3610-3617
- [18] L. Bazzani, M. Cristani and V. Murino. Symmetry-Driven Accumulation of Local Features for Human Characterization and Re-Identification[J]. Computer Vision and Image Understanding, 2013, 117(2): 130-144
- [19] R. Zhao, W. Oyang and X. Wang. Person Re-Identification by Saliency Learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(2): 356-370
- [20] D. S. Cheng and M. Cristani. Person Re-Identification by Articulated Appearance Matching[J]. Person Re-Identification, 2014: 139-160
- [21] R. Layne, T. M. Hospedales, S. Gong, et al. Person Re-Identification by Attributes[C]. Bmvc, 2012, 8
- [22] M. A. Hearst, S. T. Dumais, E. Osuna, et al. Support Vector Machines[J]. IEEE Intelligent Systems and their applications, 1998, 13(4): 18-28
- [23] J. Liu, B. Ni, Y. Yan, et al. Pose Transferrable Person Re-Identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,Salt Lake City,2018, 4099-4108
- [24] L. Wei, S. Zhang, W. Gao, et al. Person Transfer Gan to Bridge Domain Gap for Person Re-Identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Salt Lake City,2018, 79-88
- [25] M. Hofmann, P. Tiefenbacher and G. Rigoll. Background Segmentation with Feedback: The Pixel-Based Adaptive Segmenter[C]. 2012 IEEE computer society conference on computer vision and pattern recognition workshops, Providence,2012, 38-43
- [26] P. KaewTraKulPong and R. Bowden. An Improved Adaptive Background Mixture Model for Real-Time Tracking with Shadow Detection[J]. Video-Based Surveillance Systems, 2002: 135-144
- [27] H. Wang and D. Suter. A Consensus-Based Method for Tracking: Modelling Background Scenario and Foreground Appearance[J]. Pattern recognition, 2007, 40(3): 1091-1105

- [28] O. Barnich and M. Van Droogenbroeck. Vibe: A Universal Background Subtraction Algorithm for Video Sequences[J]. IEEE Transactions on Image processing, 2010, 20(6): 1709-1724
- [29] M. Jones and P. Viola. Fast Multi-View Face Detection[J]. Mitsubishi Electric Research Lab TR-20003-96, 2003, 3(14): 2
- [30] Y. LeCun and Y. Bengio. Convolutional Networks for Images, Speech, and Time Series[J]. The handbook of brain theory and neural networks, 1995, 3361(10): 1995
- [31] A. Krizhevsky, I. Sutskever and G. E. Hinton. Imagenet Classification with Deep Convolutional Neural Networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105
- [32] M. D. Zeiler and R. Fergus. Visualizing and Understanding Convolutional Networks[C]. European conference on computer vision, Zurich, 2014, 818-833
- [33] K. Simonyan and A. Zisserman. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. arXiv preprint arXiv:1409.1556, 2014
- [34] C. Szegedy, W. Liu, Y. Jia, et al. Going Deeper with Convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Boston, 2015, 1-9
- [35] K. He, X. Zhang, S. Ren, et al. Deep Residual Learning for Image Recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Las Vegas, 2016, 770-778
- [36] G. Huang, Z. Liu, L. Van Der Maaten, et al. Densely Connected Convolutional Networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Honolulu, 2017, 4700-4708
- [37] S. Ren, K. He, R. Girshick, et al. Faster R-Cnn: Towards Real-Time Object Detection with Region Proposal Networks[J]. arXiv preprint arXiv:1506.01497, 2015
- [38] L. Zheng, Y. Huang, H. Lu, et al. Pose-Invariant Embedding for Deep Person Re-Identification[J]. IEEE Transactions on Image processing, 2019, 28(9): 4500-4509
- [39] L. Zheng, H. Zhang, S. Sun, et al. Person Re-Identification in the Wild[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, 2017, 1367-1376
- [40] M. Lin, Q. Chen and S. Yan. Network in Network[J]. arXiv preprint arXiv:1312.4400, 2013
- [41] S. Woo, J. Park, J.-Y. Lee, et al. Cbam: Convolutional Block Attention Module[C]. Proceedings of the European conference on computer vision (ECCV), Munich, 2018, 3-19
- [42] C. Szegedy, V. Vanhoucke, S. Ioffe, et al. Rethinking the Inception Architecture for Computer Vision[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Las Vegas 2016, 2818-2826

- [43] S. Xie, R. Girshick, P. Dollár, et al. Aggregated Residual Transformations for Deep Neural Networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Honolulu,2017, 1492-1500
- [44] J. Hu, L. Shen and G. Sun. Squeeze-and-Excitation Networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Salt Lake City, 2018, 7132-7141
- [45] L. Zheng, L. Shen, L. Tian, et al. Scalable Person Re-Identification: A Benchmark[C]. Proceedings of the IEEE international conference on computer vision, Santiago, 2015, 1116-1124
- [46] W. Li, R. Zhao, T. Xiao, et al. Deepreid: Deep Filter Pairing Neural Network for Person Re-Identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Columbus, 2014, 152-159
- [47] E. Ristani, F. Solera, R. Zou, et al. Performance Measures and a Data Set for Multi-Target, Multi-Camera Tracking[C]. European conference on computer vision, Amsterdam, 2016, 17-35
- [48] D. Gray, S. Brennan and H. Tao. Evaluating Appearance Models for Recognition, Reacquisition, and Tracking[C]. Proc. IEEE international workshop on performance evaluation for tracking and surveillance (PETS), Rio de Janeiro, 2007, 1-7
- [49] C. C. Loy, T. Xiang and S. Gong. Multi-Camera Activity Correlation Analysis[C]. 2009 IEEE Conference on Computer Vision and Pattern Recognition, Miami, 2009, 1988-1995
- [50] Y. Suh, J. Wang, S. Tang, et al. Part-Aligned Bilinear Representations for Person Re-Identification[C]. Proceedings of the European Conference on Computer Vision (ECCV), Munich, 2018, 402-419
- [51] Y. Sun, L. Zheng, Y. Yang, et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and a Strong Convolutional Baseline)[C]. Proceedings of the European conference on computer vision (ECCV), Munich, 2018, 480-496
- [52] C.-P. Tay, S. Roy and K.-H. Yap. Aanet: Attribute Attention Network for Person Re-Identifications[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, 2019, 7134-7143
- [53] W. Yang, H. Huang, Z. Zhang, et al. Towards Rich Feature Discovery with Class Activation Maps Augmentation for Person Re-Identification[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, 2019, 1389-1398
- [54] R. Hou, B. Ma, H. Chang, et al. Interaction-and-Aggregation Network for Person Re-Identification[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, 2019, 9317-9326

- [55] X. Qian, Y. Fu, Y.-G. Jiang, et al. Multi-Scale Deep Learning Architectures for Person Re-Identification[C]. Proceedings of the IEEE International Conference on Computer Vision, Venice, 2017, 5399-5408
- [56] L. Zhao, X. Li, Y. Zhuang, et al. Deeply-Learned Part-Aligned Representations for Person Re-Identification[C]. Proceedings of the IEEE international conference on computer vision, Venice, 2017, 3219-3228
- [57] W. Li, X. Zhu and S. Gong. Person Re-Identification by Deep Joint Learning of Multi-Loss Classification[J]. arXiv preprint arXiv:1705.04724, 2017
- [58] H. Zhao, M. Tian, S. Sun, et al. Spindle Net: Person Re-Identification with Human Body Region Guided Feature Decomposition and Fusion[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Venice, 2017, 1077-1085
- [59] L. Wei, S. Zhang, H. Yao, et al. Glad: Global-Local-Alignment Descriptor for Pedestrian Retrieval[C]. Proceedings of the 25th ACM international conference on Multimedia, Mountain View, 2017, 420-428
- [60] X. Liu, H. Zhao, M. Tian, et al. Hydraplus-Net: Attentive Deep Features for Pedestrian Analysis[C]. Proceedings of the IEEE international conference on computer vision, Venice, 2017, 350-359

攻读硕士学位期间取得的成果