

北京交通大学

硕士学位论文

基于多尺度特征的无监督跨域行人重识别研究

Unsupervised Cross-domain Person Re-identification based on Multi-scale Features

作者： 丁玮玮

导师： 徐保民

北京交通大学

2020 年 6 月

学校代码：10004

密级：公开

北京交通大学

硕士学位论文

基于多尺度特征的无监督跨域行人重识别研究

Unsupervised Cross-domain Person Re-identification based on Multi-scale Features

作者姓名：丁玮玮

学 号：17120355

导师姓名：徐保民

职 称：教授

学位类别：工学

学位级别：硕士

学科专业：计算机科学与技术

研究方向：计算机视觉

北京交通大学

2020 年 6 月

致谢

三年的硕士生涯即将结束，回想三年前第一次迈入校园，站在九教前面对世纪钟的激动心情，一切仿佛历历在目。从研一学期选择研究课题开始，老师们一直竭尽所能的给予我指导与帮助。尤其是我的导师，他始终保持严谨的治学态度，在工作中一丝不苟，正是由于他在百忙之中多次审阅本论文，提出宝贵的修改意见，本文才得以成型。我的导师不仅在学业上给我以精心指导，更让我从他身上学到了很多做人做事的道理，在此向我的导师表示衷心的感谢。

感谢我可爱的舍友们，初来北京，在这个陌生的城市，是她们给予了我家的温暖，给我的研究生生涯带来了许多欢乐。虽然平时相处时一直在嬉戏打闹，但是一旦遇到什么困难，她们始终在我身边陪我并肩作战，让我感觉到没有什么困难是解决不了的。感谢你们的陪伴与支持！

实验室的小伙伴们在我的实验及论文工作中积极提供了很多意见和建议，感谢他们的热情帮助，我为能与你们共处三年的研究生涯深表感激。希望我们都能完成自己的目标，实现自己的理想，祝大家前程似锦。

最后，感谢我的爸爸妈妈姐姐，谢谢你们无私的奉献，让我能无后顾之忧的完成研究生的学业，也很抱歉让你们一直为我操心，以后的日子里我会更加努力，不辜负你们的期望。

摘要

跨域行人重识别是指利用计算机视觉技术进行跨场景的跨摄像机行人检索的技术,在安全领域的海量监控视频的智能分析中有着重要的应用价值,受到学术界和工业界的广泛关注。

实际应用场景下的跨域行人重识别系统需要解决以下三个问题:数据无标签、数据实时获取和模型处理时效性。现有的跨域行人重识别模型主要基于无监督学习解决了数据无标签的问题,但是缺乏对实际场景下模型训练数据输入方式的考虑,使得模型对新到来的数据缺乏学习能力。同时现有模型通过设计复杂网络来换取高性能,网络的复杂性会直接导致模型处理速度的下降,无法满足时效性需求。

针对跨域行人重识别中的数据无标签,模型时效性差问题,从提升预训练模型提取特征的有效性角度出发,设计了基于多尺度特征有效融合的行人重识别模型 EMFF。EMFF 模型基于残差网络构建特征金字塔,提取不同尺度的行人特征,使用一种改进的特征融合方式来融合特征,使得融合特征包含更多判别性信息,从而提升模型的跨域性能。基于 Market-1501 和 DukeMTMC-reID 数据集进行跨域实验,EMFF 模型在不使用目标域数据的前提下,在 CMC Rank-1 指标上,两个数据集上分别达到了 56.7%和 49.8%,在 mAP 指标上,分别达到了 40.3%和 40.4%,相比 ResNet50 基准网络提升了 13.7%和 23.7%。说明该方法能有效提取行人判别性特征,提升模型泛化能力。在 Market-1501 数据集上测试模型的时间性能,每张图片匹配检索时间为 0.0170s,说明该模型复杂度适中,能满足实时性要求。

针对跨域行人重识别中的模型缺乏学习能力问题,基于无监督聚类和增量学习设计了跨域行人重识别模型 ILRe-ID。基于无监督聚类学习为无标签数据添加伪标签,利用伪标签训练模型。为了模拟实际场景下的数据输入方式,将数据集划分为多个不重叠的数据集序列,基于无监督增量学习利用不同数据集依次训练模型,模型基于参数调整方式进行在线更新。该模型在 Market-1501 和 DukeMTMC-reID 的跨域实验中,CMC Rank-1 指标上分别达到了 82.5%和 75.1%,超过目前最优方法 2.5%和 2.1%,mAp 指标上分别达到了 59.1%和 57.2%,分别超过目前最优方法 0.8%和 3.8%。说明该方法通过增量学习方式能够更好的实现目标域上的模型域适应,同时模型具有学习能力,能有效应对监控系统中数据实时获取的场景,更适合实际部署应用。

关键词: 行人重识别; 多尺度特征; 特征融合; 增量学习; 聚类

ABSTRACT

Cross-domain person re-identification (Re-ID) aims at cross-camera pedestrian retrieval under different domain by computer vision technology, which has a promising future in intelligent analysis of massive surveillance videos in security field, and has been widely concerned by academic and industrial community.

There are three issues that should be tackled in real-world Re-ID system, data without label, continuously acquired input data and model's time-efficiency. Existing Re-ID models focus on solving unlabeled data issue with unsupervised learning, without taking input type of continuously acquired data into consideration, which make model lack of learning ability for new-coming data. Simultaneously, existing models are designed complexly to get high performance, which gives rise to models' processing time and violates time-efficiency criterion.

To solve the problem of data without label and poor model's time-efficiency in cross-domain Re-ID, a Re-ID model EMFF based on multi-scale feature fusion is designed from the perspective of improving the effectiveness of feature extracted from pre-trained model. EMFF model builds feature pyramid based on residual network, extracts pedestrian feature of different scales, uses an improved feature fusion method to fuse features, makes fusion feature contains more discriminative information, and improves the model's cross-domain precision. Based on Market-1501 and DukeMTMC-reID datasets, cross-domain experiments were conducted. On the premise of not using the data from target domain, the EMFF model reached 56.7% and 49.8% on two datasets on CMC Rank-1, and 40.3% and 40.4% on mAP criterion respectively, which were 13.7% and 23.7% higher than ResNet50 benchmark network. It shows that the method can effectively extract the discriminative characteristics of pedestrians and improve the generalization ability of the model. The time-efficiency of the model is tested on the Market-1501 dataset, and the retrieval time of each image is 0.0170s, indicating that the model's complexity is moderate and can meet the real-time requirement.

As for the problem of lack of learning ability of cross-domain Re-ID model, ILRe-ID is designed based on unsupervised clustering and incremental learning. Based on unsupervised clustering learning, pseudo labels are added to unlabeled data, and pseudo labels are used to train the pre-trained model. In order to simulate the data input mode in the real scenarios, the datasets were divided into several non-overlapping sequences of

datasets, and the model was trained in sequence using different datasets based on unsupervised incremental learning. The model is updated online based on the method of parameter adjustment. By conducting cross-domain experiments on Market-1501 and DukeMTMC-reID datasets, the model reached 82.5%和 75.1% respectively on CMC Rank-1, and 59.1%和 57.2% respectively on mAP, which increased by 0.8%和 3.8% respectively compared with the existing optimal methods based on unsupervised domain adaptation. It shows that the method can have a better domain adaptation on the target domain through incremental learning, and the model has the ability to learn new data, and can effectively deal with the scene of real-time acquisition of data in the monitoring system, which is more suitable for practical deployment.

KEYWORDS : Person re-identification; Multi-scale Feature; Feature Fusion; Incremental Learning; Clustering Algorithm

目录

摘要	III
ABSTRACT	IV
1 绪论.....	1
1.1 选题背景及研究意义.....	1
1.2 研究现状.....	4
1.3 研究内容与工作.....	6
1.4 本文组织结构.....	8
1.5 总结.....	9
2 行人重识别相关技术概述.....	10
2.1 单域的行人重识别技术.....	10
2.2 跨域的行人重识别技术.....	11
2.3 跨域的行人重识别技术存在的问题.....	13
2.4 行人重识别理论基础.....	14
2.4.1 ResNet 网络结构	14
2.4.2 特征金字塔模型.....	15
2.4.3 增量学习	16
2.4.4 CMC 曲线及 mAP.....	18
2.5 本章小结.....	20
3 基于多尺度特征有效融合的行人重识别模型	21
3.1 引言.....	21
3.2 基于多尺度特征融合的行人重识别传统方法.....	22
3.3 EMFF 模型	23
3.3.1 特征融合模块.....	24
3.3.2 多任务学习模块.....	25
3.3.3 损失函数.....	26
3.4 实验及结果.....	27
3.4.1 数据集及评价标准.....	27
3.4.2 参数选择及实验环境.....	28
3.4.3 实验结果分析	30

3.4.4 时间性能分析.....	32
3.4.5 跨域实验.....	33
3.5 总结.....	36
4 基于无监督增量学习的跨域行人重识别模型	37
4.1 引言.....	37
4.2 ILRE-ID 模型.....	38
4.2.1 无监督聚类学习阶段.....	39
4.2.2 无监督增量学习阶段.....	42
4.3 实验及结果.....	43
4.3.1 数据集及数据预处理.....	43
4.3.2 实验参数设置.....	44
4.3.3 对比实验.....	44
4.3.4 消融实验(Ablation Experiments).....	47
4.4 总结.....	49
5 结论与展望.....	51
5.1 结论.....	51
5.2 展望.....	51
参考文献.....	53
作者简历及攻读硕士/博士学位期间取得的研究成果	58
独创性声明.....	59
学位论文数据集.....	60

1 绪论

在本章节中，首先基于深度网络模型的行人重识别技术研究在安防刑侦领域的重要性，阐述了本文课题的选题背景及研究意义。然后总结了当前行人重识别课题的学术背景及国内外研究现状，总结各种研究方法的优缺点，基于现有研究方法中存在的学术问题提出本文中行人重识别算法的研究思路。然后列举本文的研究内容以及主要工作。最后介绍本文的组织结构。

1.1 选题背景及研究意义

随着全国监控视频系统的部署完善，海量的监控视频数据为安防刑侦工作提供了很好的数据支持。通过分析监控视频，可以帮助刑侦人员锁定犯罪嫌疑人并提供相应犯罪证据。但是由于监控视频数据量的庞大，基于人力的视频分析是非常耗时的，这会影响刑侦人员的办案效率并为犯罪嫌疑人提供充足的潜逃时间。例如国内严峻的儿童拐卖案件，通常犯罪人不会在一个地点长时间停留，如果不能及时定位犯罪嫌疑人并得知其活动路线，抓捕犯罪人和找回儿童将会很困难，最终导致很多家庭失去自己的孩子。借助计算机视觉技术可以帮助解决监控视频中的人物识别和检索工作。目前人脸识别技术已经广泛应用在安全领域，通过人脸摄像头提取行人的脸特征点，形成人脸结构化模型，并与后台人脸数据库对比分析得出行人信息。人脸识别技术需要提供较清晰的人脸图像，目前主要部署在车站、机场、交通要塞等可以直接扫描人脸提取完整人脸信息的场所。但是在监控摄像头中，拍摄的是大范围大角度的场景，通常包含多人的全身照，不同于人脸扫描摄像头，无法获取高清的人脸图像，这也限制了人脸识别技术在安防刑侦领域的应用。所以安防刑侦领域亟需一种可以根据不高清的行人图像来实现行人检测、识别与检索的技术，行人重识别技术课题由此产生。

行人重识别技术(Person Re-identification, Re-ID)^[1]是利用计算机视觉技术进行跨摄像头的行人检索和追踪的技术。如图 1-1 所示，在北京交通大学主校区内有多个无重叠区域的摄像头，如摄像机 A、B、C。行人重识别技术要求对每个摄像机下感兴趣的行人，检索到该行人在其他摄像机下出现的所有图片。即给定摄像机 A 下出现的某个感兴趣行人图像，行人重识别技术需要在摄像机 B、C 下检索出所有该行人的图像。Re-ID 技术作为人脸识别技术的补充，可以更有效的利用监控视频解决实际应用中跨设备、跨场景的行人识别与追踪问题，在安全领域拥有广泛的应用前景，在近几年的计算机视觉研究中受到极高的关注。



图 1-1 行人重识别系统中摄像机部署示意图

Fig. 1-1 The schematic figure of camera deployment in person re-identification

相比人脸识别技术, Re-ID 技术的适用场景更丰富,但是也面临更困难的挑战。人脸识别技术可以根据较清晰的人脸图像提取到人脸特征,不同的人通常具有不同的面部特征,人脸特征可以作为行人识别的重要判别性信息。但是摄像机拍摄的监控范围较广,每一帧图像不可能只包含单个行人,多行人之间会出现遮挡,这为 Re-ID 技术的行人检测步骤带来了很大的困难。在这样复杂的图像中标定的行人检测框(Detection Bounding Boxes),通常存在遮挡、光线问题。跨区域的摄像机具有不一样的背景环境、光线条件、摄像机视角和季节性变化,跨摄像机中出现的行人可能会出现更换服饰、佩戴饰物、改变发型、身材变形等情况。如图 1-2 所示,以上情形更加剧了 Re-ID 研究的难度。



图 1-2 行人重识别影响因素

Fig. 1-2 The challenges of person re-identification

由于存在不同身份行人具有相似的外貌或相同行人由于摄像机视角、季节性

变化导致的外貌差异巨大的情况，行人身体特征的可判别性较低。如何在复杂背景图像中提取到更具鲁邦性和判别性的行人身体特征是 Re-ID 的技术难点。根据应用场景不同，行人重识别技术可以分为两类：单域的行人重识别技术和跨域行人重识别技术。单域行人重识别是通常意义上的跨摄像机 Re-ID，面临的困难主要是行人自主的外貌变化、摄像机导致的行人外貌变化以及背景变化。如何克服以上困难，提取到有效的判别性行人身份特征是单域 Re-ID 的技术难点和研究重点。



图 1-3 行人重识别数据集样本示例 (a) Market-1501 (b) DukeMTMC-reID

Fig. 1-3 The samples of images in Market-1501(a) and DukeMTMC-reID(b) dataset

跨域 Re-ID 是 Re-ID 模型在两个不同场景下的适应问题。如图 1-3 分别列举了两个不同场景下的行人重识别数据集。由图中可以看出，不同数据集的环境不同，不仅存在单域 Re-ID 的跨摄像头问题，还有跨域的风格(季节性风格、背景风格、摄像机视角风格)问题，因此跨域的 Re-ID 技术需要同时解决跨摄像头问题和跨域问题，处理的数据更加复杂，更接近于实际应用场景。实际应用场景中，数据来自跨摄像头的监控视频，属于无标签数据，数据实时的被收集，人工标注显然达不到系统需要的时效性，而基于海量的无标签数据从头训练 Re-ID 模型是非常困难的且无法保证性能。迁移学习的发展为跨域 Re-ID 提供了一个很好的解决方案。通过利用大量的无标签数据对预训练的 Re-ID 模型进行模型微调，可以实现模型到目标域上的迁移。如何保证预训练模型的泛化能力和控制目标域上模型优化方向是跨域 Re-ID 的技术难点和研究重点。

目前一些科技公司正在构建刑侦领域人工智能系统，通过对海量监控视频中人物的检测、识别和追踪，进行行人行为分析，提供智能预警。跨域行人重识别技术的研究将加速系统的落地应用进程。

1.2 研究现状

随着深度学习的发展，越来越多的基于深度神经网络的跨域 Re-ID 模型被提出。如图 1-4 所示，基于深度神经网络的跨域 Re-ID 模型训练分为三个阶段，第一阶段在源域有标签数据集上预训练得到基础 Re-ID 模型，该阶段通常采用监督训练，以获得一个能有效完成行人重识别任务的 Re-ID 模型；第二阶段微调模型直接迁移到目标域无标签数据集上，这一阶段可以测试出预训练模型的泛化能力，如果模型直接迁移到目标域仍能有一定的性能表现，那么这个预训练模型具有较好的泛化能力。到这一阶段，已经完成了跨域的行人重识别，但是为了进一步优化预训练模型在目标域的表现，还需要进行第三阶段的训练。第三阶段是利用目标域数据优化模型，实现模型域适应。这一阶段旨在优化模型以适应目标域场景。




图 1-4 基于深度神经网络的跨域行人重识别示意图

Fig. 1-4 The diagram of cross-domain Re-ID based on deep neural networks

每个阶段中 Re-ID 任务的实现流程如图 1-5 所示。Re-ID 实现流程分为三步：特征提取、相似性度量和行人匹配。首先，分别提取检索行人图像和检索库(Gallery)所有图片的行人特征，然后计算检索行人特征与检索库中每一张图像特征之间的距离(例如欧氏距离、余弦距离)，根据距离进行图像排序，排序越靠前表示相似度越高，返回排序靠前的图像作为该检索行人在别的摄像机下的图像。其中特征提取部分网络一般基于卷积神经网络(Convolutional Neural Networks, CNN)，提取的特征向量用于表示行人特征。在训练阶段，通过设计不同的损失函数，并最小化损失函数值，来使得提取特征更具判别性。测试阶段，将特征提取器提取的特征作为行

人特征与检索库图像特征直接进行行人匹配。




图 1-5 Re-ID 任务实现流程

Fig. 1-5 The pipeline of Re-ID task

跨域 Re-ID 中预训练阶段可以视为一个单域 Re-ID 问题，要实现预训练 Re-ID 模型能有效提取目标域数据集上的行人特征的目标，即需要提升单域 Re-ID 模型的特征提取器性能，并使得预训练 Re-ID 模型具有较强的泛化能力。单域 Re-ID 又被视为分类问题或是验证问题，通过提取行人身体特征进行单域 Re-ID 任务。但是难点在于如何在复杂的图像数据中提取到具有类判别性的行人身体特征并保持模型的泛化能力。早期的单域 Re-ID 方法^[2]通过提取行人图像全局特征进行 Re-ID 任务，由于全局特征比较抽象，损失了很多细节及空间信息，并不能实现较好的 Re-ID 性能。近期，学术界对于 Re-ID 的研究重点放在行人局部特征学习^[7]，提出了很多局部特征的提取方法。相比全局特征，局部特征会关注更多细粒度的特征，比如行人背包、配饰等细节信息，最终融合所有的局部特征形成一个完整的行人表征向量。对于跨摄像头下行人无明显外貌差异的情况，利用局部特征能有效提升模型性能。但在实际场景中，行人发生外貌改变是很常见的现象，属性特征不一定会提升 Re-ID 性能，还可能引入噪声。对于跨摄像机下外貌发生巨大变化的行人，常规提取的行人特征无法将这两张图像识别为同一个人，需要借助一些额外的辅助信息来帮助模型识别。于是有学者提出了基于摄像机拓扑结构的 Re-ID 模型，通过分析摄像机拓扑结构，预测行人在摄像机网络中可能的运动轨迹，从而得到某摄像机拍摄的图像中可能为某一行人的概率，将得到的概率值与特征提取后的概率

值共同进行行人身份识别。实际场景中,摄像机拍摄都会记录摄像机号和图像帧号,这些信息很好获取,而且也能有效的辅助 Re-ID。

跨域 Re-ID 域适应阶段也是提升跨域 Re-ID 模型性能的关键。早期的域适应方法是学习一个域不变性的子空间,通过提取源域和目标域数据在子空间上的域不变性特征进行模型训练,但是子空间学习通常比较困难。有学者利用生成对抗网络在图像生成方面的优势,将有标签数据的背景风格通过生成对抗网络转换为无标签数据的背景风格,再将转换后的有标签数据视为无标签数据领域的数据进行模型训练,实现模型域适应。生成对抗网络转换的图片容易出现失真、变形和模糊等现象,为了得到较真实的转换图片,学者们提出了一系列优化方法。这种方法完全没有利用到无标签数据,有学者认为目标域数据中包含很多域内性质,是目标域上 Re-ID 模型性能表现的重要影响因素,于是提出了基于目标域数据进行模型优化的域适应方法。常见方法是伪标签法,即为无标签数据添加伪标签,然后利用伪标签来训练模型。伪标签法本质是提取了目标域内数据的类内相似性和类间差异性,效果比较稳定。

1.3 研究内容和工作

如下图 1-6 所示,为实际跨域行人重识别系统的流程图。从图中可以看出,实际的跨域行人重识别场景存在以下三个问题:

- (1) 数据无标签;
- (2) 任务处理时效性;
- (3) 输入数据是源源不断收集的跨摄像头视频或图像数据序列。

针对(1)和(2)问题,从改善预训练模型的特征提取器及控制预训练 Re-ID 的模型复杂度两个方向同时改进。现有的模型对于多尺度特征的融合方式^[43]是直接进行相加或拼接,但是不同尺度特征关注图像中的不同区域,有的特征可能会重点关注背景等对 Re-ID 任务来说是噪声的区域,直接不加区分的相加或拼接容易方法噪声对 Re-ID 任务的影响,从而导致模型性能低下。针对不同尺度特征之间的差异性,基于一种优化的特征融合方式进行特征融合,让网络放大不同特征之间的相似性(被所有特征关注的区域可能是具有类判别性的),弱化不同特征之间的差异性(背景与前景人物),从而提升融合特征有效性。网络基于基础的 ResNet50 改进得到,模型复杂度较低,网络处理任务的时间在可接受范围内。

针对(3)问题,从提升模型在目标域上的表征能力及让模型学会学习两个方面进行改进。为了提升模型在目标域上表征能力,基于无监督聚类的伪标签法在基础 Re-ID 模型上训练无标签数据,这使得模型能学习目标域数据分布,从而改进模型

对目标域数据的表征能力。现有跨域 Re-ID 模型是基于给定的完整数据集进行模型训练的，一旦模型接受都新数据，将无法有效识别，除非对新数据重新进行模型训练。为了解决模型无法学习的问题，基于增量学习的方式进一步优化模型，使其能自主学习新数据，并基于模型参数调整保留模型对旧数据的 Re-ID 能力。




图 1-6 实际场景中的跨域行人重识别系统流程图

Fig. 1-6 The flow chart of cross-domain Re-ID system in real-world

本文主要的研究内容有：

- (1) 对现有模型算法进行调研分析，分析各个模型的优缺点。
- (2) 基于行人重识别领域中提出的多尺度特征融合方法，构建一个更适用于跨域场景的强特征提取器。
- (3) 基于无监督聚类算法，利用目标域无标签数据优化特征提取器，使模型学

习到目标域的数据分布知识。

(4) 模拟实际场景下数据收集方式, 利用增量学习方法逐步训练序列数据集, 同时基于模型参数调整方法缓解模型灾难性遗忘问题。

本文的主要工作有:

(1) 改进已有 ResNet50^[32]网络框架, 使得其能够很好的兼容本文提出的多尺度特征有效融合模型方法。去除原模型最后两层, 添加上采样模块, 构造特征金字塔模型。

(2) 构建一个特征提取能力较强的特征提取模型——基于多尺度特征有效融合的行人重识别模型(Effectively Multi-scale Features Fusion Model, 简称为 EMFF 模型)。分析研究现阶段使用深度学习方法进行基于多尺度特征的 Re-ID 模型的优缺点, 综合各个模型网络的优点, 构造一个特征提取能力较好的特征提取模型。

(3) 实验选择不同数据集上的最优参数组合方式, 并验证 EMFF 模型在不同数据集上的 Re-ID 精度。

(4) 进一步实验验证 EMFF 模型在直接跨域场景下的精度, 提出 ICD 损失函数(Inter-class Dissimilarity Loss), 利用无标签目标域数据集结合 ICD 损失函数进行模型优化, 实验验证优化模型精度。

(5) 构建一个基于无监督聚类和增量学习的跨域行人重识别模型(Incremental Learning based Cross-domain Re-ID, 简称为 ILRe-ID), 基于无监督聚类学习利用目标域无标签数据进行模型在目标域上的性能优化, 基于模型参数调整构建目标域上的增量学习, 使模型能及时学习新到来的数据, 同时保留在旧数据上的性能, 缓解模型灾难性遗忘问题。

(6) 大量实验验证基于增量学习的 Re-ID 方法能有效提升跨域行人重识别精度。

1.4 本文组织结构

本文章节内容安排如下:

第一章为绪论部分。首先阐述了本文所选课题的选题背景和研究意义, 并根据国内外研究现状对当前主流的研究方法做了简要阐述并总结现有方法的优缺点。针对现有主流方法的优缺点, 提出本文的研究内容——基于无监督的跨域行人重识别技术研究, 最后介绍了本文主要的研究内容和工作以及本文的组织结构。

第二章为相关理论基础部分。根据模型应用场景的不同, 行人重识别技术研究可以分为基于单域的行人重识别技术研究和基于跨域的行人重识别技术研究, 文献综述章节分别从这两个研究课题详细介绍了前人所做的工作及其所提出模型的

优缺点。同时对本文中所用到的基础网络、深度学习方法以及模型评价标准做了简要的介绍。

第三章为基于多尺度特征有效融合的无监督跨域行人重识别技术研究。本章针对跨域 Re-ID 中预训练 Re-ID 模型的特征提取器比较弱问题,设计一个强特征提取器 EMFF 模型。该模型基于一种有效的特征融合方法进行多尺度特征融合,能提取到更具判别性的特征。大量的实验结果表明,该模型在源域上预训练的结果精度超过现有的多尺度融合模型,证明该特征融合方法的有效性,同时能大幅度提升跨域场景下的识别性能,证明模型泛化能力较强。

第四章为基于增量学习的无监督跨域行人重识别技术研究。本章针对现有模型缺乏学习新数据能力的问题,设计了一个基于无监督聚类和增量学习的跨域 Re-ID 模型 ILRe-ID。ILRe-ID 模型基于预训练的 EMFF 模型进行特征提取,并基于聚类学习和增量学习增加模型的学习能力,同时控制模型参数调整来保留模型的旧知识。大量实验表明,通过持续的迭代学习,该模型在目标域上表现越来越好。

第五章为总结与展望。在本章节中,首先对本文研究内容及研究结果进行总结,然后指出本文研究方法中所存在的问题,最后结合实际场景下行人重识别面临的挑战,提出对跨域行人重识别技术的未来展望。

1.5 总结

在本章节中,首先介绍了本文研究课题的选题背景及意义,分析了跨域行人重识别技术研究的重要性。然后通过对国内外学者提出的大量行人重识别方法进行简要总结,概述目前行人重识别技术的研究现状,通过分析现有模型方法中仍待解决的问题,提出本文的研究课题——基于无监督的跨域行人重识别研究。然后概括了本文针对本课题展开的主要研究及工作内容。最后简要介绍了本文的组织结构。

2 行人重识别相关技术概述

本章节将介绍本课题的相关技术。首先从单域(Single-domain)Re-ID 和跨域(Cross-domain)Re-ID 两个研究课题介绍了一些目前主流的优秀模型方法,并总结现有跨域 Re-ID 方法存在的问题。然后介绍了本文中所提出的模型方法中涉及到的基础知识,对 ResNet50 网络、特征金字塔模型以及增量学习做了简单的介绍,最后介绍了两个常用的行人重识别研究的评估指标 CMC 曲线和 mAP。

2.1 单域的行人重识别技术

单域的行人重识别技术(常见的行人重识别技术)是指对跨摄像机的行人进行检索的技术,其中训练数据与测试数据均来自与一个数据集。根据深度学习方式的不同,又分为有监督的行人重识别和无监督的行人重识别。

监督学习的行人重识别 监督学习的行人重识别是指借助行人真实身份标签训练模型,最后基于模型提取的行人特征进行行人身份分类学习和行人特征间度量学习。近年来,计算机视觉领域采用深度学习方法取得了显著的成效,基于深度学习的研究方法也成为行人重识别领域的主流研究方法。早期基于深度学习的行人重识别方法^[2],类似于图像分类网络,基于卷积神经网络(CNN)对每一张行人图像的全局信息进行特征提取,这样提取的全局特征能学习到行人外观上最显著的特征,优点是对于局部区域的微小干扰有较强的鲁棒性,但是由于缺乏空间信息,噪声区域对于全局特征会造成极大的干扰,所以全局特征无法很好的处理行人重识别中的遮挡、复杂背景、姿态等问题。近期,局部特征学习^[7]成为学者们的研究热点。获取局部特征的方法可以分为以下四种:1)行人图像切片,一般是对行人图像进行水平切片;2)基于关键点定位后的姿态估计;3)结合图像分割分离出前后景,减少背景噪声影响;4)对行人图像划分网格,类似于目标检测,每个网格看成是一个 Anchor。这几种方法前提都是对于目标图像有足够的先验知识存在,而实际场景中,大面积遮挡、姿态大幅度变化、错误的行人检测框等问题都会影响先验知识的完整性,也就无法保证先验知识的准确性。所以局部特征的学习鲁棒性不够高。

无监督学习的行人重识别 目前大部分行人重识别模型还是基于监督学习的,需要使用有标注数据进行模型训练。考虑到实用场景下,数据集往往是没有标签的,手工标注海量数据也是不现实的,因此无监督的行人重识别模型是解决这些问题的关键。传统的无监督行人重识别方法侧重与手工特性,不适合大规模数据集。基

于深度学习的无监督行人重识别方法主要有两类：无监督聚类学习和无监督度量学习。

基于无监督聚类的行人重识别方法，首先基于特征提取器提取无标签数据特征，然后使用聚类算法对无标签数据进行聚类学习，并基于聚类结果给无标签数据打上伪标签，最后利用打上伪标签的数据训练模型。Lin 等人^[15]提出一种自底向上聚类方法(Bottom-up Clustering, BUC)用于无监督行人重识别，整个模型分为三步：第一步利用深度卷积神经网络提取行人特征，第二步利用提取的行人特征在整个无标签数据集上进行聚类合并，第三步依据聚类结果重新训练模型。不断迭代这三个步骤直至行人相似性以及身份差异性达到最大化。

2.2 跨域的行人重识别技术

跨域的行人重识别(Re-ID)是指将一个数据集(源域)上训练的行人重识别模型应用在另一个数据集(目标域)。相比单域 Re-ID，跨域 Re-ID 面临更多挑战，其中最大的挑战是“域漂移”(Domain Shift)问题。由于不同数据集中数据来自不同区域的跨摄像头采集的图像，无交叉的行人、背景、光照、视角等客观因素导致了不同数据集之间分布的巨大差异，称为“域漂移”问题。因此，源域上训练的模型直接迁移到目标域上性能表现差，主要是源域的训练数据对于目标域场景下模型训练没有多少指导意义。

目前跨域 Re-ID 方法都是基于无监督学习或半监督学习。不同于深度学习中的无监督学习，无监督的跨域 Re-ID 是指在目标域上进行无监督学习，但是在源域上进行监督学习。主要原因是实际场景中，跨域 Re-ID 的目标域场景通常具有大量无标签数据(Unlabeled Data)，直接用这些无标签数据从头训练一个 Re-ID 模型比较困难，利用源域上有监督学习得到的预训练模型能基本完成目标域上的 Re-ID 任务，但是由于缺乏目标域数据的知识，模型迁移表现较差，通过让模型学习目标域数据分布，模型能够适应目标域场景，从而提升模型跨域性能。现有的跨域 Re-ID 方法可以分为基于生成对抗网络(Generative Adversarial Networks, GAN)的 Re-ID/无监督域适应(Unsupervised Domain Adaptation, UDA)的 Re-ID^[20]和基于无监督学习的 Re-ID^[29]。

基于 GAN 的跨域 Re-ID 模型是利用生成器将源域的行人图像风格转化目标域场景上的行人图像风格，转换前后行人身份标签不变，用转换后的行人图像结合身份标签进行 Re-ID 模型训练。通过巧妙的风格学习，转换后的行人图像分布在一定程度上可以近似为目标域行人图像分布，从而减少“域漂移”问题。Wei 等人^[21]提出 PTGAN Re-ID 模型，模型特点是尽可能保证行人前景不变实现背景的域迁移。

PTGAN 是基于 CycleGAN^[19]改进的背景风格生成器, 为了保证风格迁移过程中前景人物不会出现模糊或变形等情况, 基于额外的 PSPNet 对行人图像前背景进行分割, 得到行人前景 Mask。通过约束迁移过程中行人前景尽可能保持不变来提升风格迁移效果。Deng 等人^[27]同样基于 CycleGAN 改进得到了适用于 Re-ID 任务的 SPGAN 模型, 不同于 PTGAN 使用额外的分割网络来控制风格迁移的质量, SPGAN 通过 SiaNet 来学习域内的相似性和域间的差异性。SiaNet 是一个 Siamese 网络, 输入为图片对。对于源域, 原图片与准换后图片组成正样本对, 需要学习其中的 Self-Similarity, 即转换后图片要与原图片距离尽可能小。对于目标域, 目标域图片与源域转换的图片组成负样本对, 需要学习其中的 domain-dissimilarity, 即目标域图片与源域转换的图片距离尽可能大。由此, 可以实现平滑的背景风格迁移。以上基于 GAN 的 Re-ID 模型, 只考虑通过图像生成来减小不同域内的 Gap, 而没有考虑目标域的域内变化, 而目标域内的变化是 Re-ID 模型性能的重要影响因素。Zhong 等人^[22]提出异构同质学习(Hetero-Homogeneous Learning, HHL)方法, 在目标域上进行相机风格迁移, 学习到域内的相机不变性(同质), 再通过源域与目标域图像组成的负样本对基于三元组损失函数来学习行人 Embeddings(异构)。域内的生成网络基于 StarGAN^[24]。Zhong 等人^[23]对目标域内的域内变化进行了全面的研究, 提出三种域不变性模型, 分别是样例不变性、相机不变性和领域不变性。样例不变性是指每个行人与自己距离最近, 与别人距离很远, 用于学习无标签数据上明显的相似性。相机不变性同以上方法一样, 基于转换后的图片身份标签不变的假设与样例不变性, 一个行人图像与其相机转换后的图像距离更近。领域不变性是指每个样例与离自己近的样例有相同的身份标签。通过全面学习这三种域不变性特征可以得到一个性能更鲁棒的模型。基于图像生成的 Re-ID 模型是基于 GAN 来模拟目标域数据的分布, 根据模拟数据与原数据之间的身份标签不变的原则, 利用模拟数据及其身份标签进行模型的训练。一定程度上, 模拟数据的数据分布可以代表目标域数据的分布, 但是 GAN 生成的图片比较容易出现变形、扭曲、模糊等现象, 如何控制 GAN 生成的图片质量是该类方法模型性能提升的关键。Huang 等人提出^[25]的 SBSGAN 模型, 利用生成器学习哪些背景像素需要被抑制, 哪些需要被保留来控制背景漂移(Background Shift)问题, 相比基于前后景 Mask 的模型, 可以避免 Mask 网络带来的分割误差。Deng 等人^[27]通过控制生成器生成的图片与原图片需要尽可能相似的原则来控制生成图片的质量, 同时控制生成图片与目标域上图片尽可能不相似的原则来优化模型。基于 GAN 的跨域 Re-ID 模型主要利用 UDA 思想, 通过缩小域之间的差异性来提升模型在目标域上的性能。UDA 方法通常需要满足源域与目标域上数据类别相同的前提条件, 而 Re-ID 不同数据集上的数据类别不同, 数据分布差异较大, 不满足该条件。从实验结果来看, 基于 UDA 的模型性能达不

到 SOTA。

基于无监督学习的 Re-ID 方法是在目标域内对无标签数据进行无监督学习,以实现模型在目标域上的域适应。常用方法包括无监督聚类学习和无监督度量学习方法。基于无监督聚类学习算法的跨域 Re-ID 是从目标域数据的类间差异性和类内相似性来尽可能模拟数据的真实标签,模型性能依赖于聚类准则的选择。无监督度量学习则是通过设计损失函数及采样规则来模拟目标域数据的标签,模型性能依赖于损失函数及距离的选择。这两种方法均利用生成的伪标签来辅助跨域 Re-ID 模型训练。代表模型有 BUC 模型^[15]和模型^[16]。Lv 等人^[29]提出 TFusion 模型,利用目标域的时空属性构建基于贝叶斯的时空模型,基于时空模型推断出不同摄像机下的行人同身份的概率,并将概率值联同排序网络一起优化,随着模型的优化,模型性能表现也越来越好。除了标签信息,目标与数据及上还有很多其他的属性信息,例如摄像机拓扑等,充分利用这些额外信息确实可以帮助提升模型在目标域上的表现。但是需要考虑如何将这些额外信息放入网络中,构建端到端的行人重识别系统。Fu 等人^[30]提出的 SSG 方法同文献^[25]思路一致,即目标域上域内的特性对模型的域适应很重要。SSG 方法基于 DBACAN 聚类算法挖掘无标签样本的潜在相似性,构建多个簇类,通过簇类的伪标签进行“监督学习”。对于目标域样本,利用特征提取器分别提取全身、上身和下身三部分的身体特征,分别进行聚类并打上伪标签。样本与三个伪标签构成一个新的数据集,通过最小化网络损失进行目标域上网络的 Fine-tuning。

考虑到实际场景中数据按时间序列收集,结合增量学习在处理序列数据上的优势,近期有研究将增量学习引入到 Re-ID 模型中,Bhargava 等人^[71]提出一种两阶段循环迭代的有监督增量学习方式,用于缓解跨域 Re-ID 模型在目标域数据上的灾难性遗忘问题。Zhang 等人^[72]将增量学习方法引入到三元组损失函数的 Margin 学习中,提升三元组损失函数的有效性。

2.3 跨域的行人重识别技术存在的问题

通过对现有的跨域 Re-ID 方法的分析,总结跨域 Re-ID 方法存在的问题如下:

(1) 基于 UDA 的跨域 Re-ID 方法通常假设两个域类别是相同或大部分相同,跨域行人重识别场景是不符合这个假设的,因为目标域数据是通过监控摄像头实时采集的数据,通常是很多未知身份的行人,无法估计其数量及类别。所以基于 UDA 的跨域 Re-ID 模型通常性能并不是特别理想。

(2) 基于 GAN 的跨域 Re-ID 方法通过利用有标签数据模拟无标签数据的分布

来减小两个域之间的差异(Gap)，但是该方法性能依赖于图像生成的质量，模拟的数据分布始终不同于真实的数据分布，性能也有待提升。

(3) 基于无监督聚类学习的跨域 Re-ID 模型通过学习无标签数据内部的类内相似性与类间差异性来模拟目标域数据的标签，由于目标域的数据信息对于跨域 Re-ID 性能是非常重要的，这种方法通常可以取得比较稳定的性能。但是模型仍无法解决实际场景中输入数据实时获取的问题，即模型无法处理新类别数据。

2.4 行人重识别理论基础

本章节将对本文中所用到的一些基础网络(ResNet50)、模型(特征金字塔模型)及深度学习方法(增量学习)进行简要的介绍说明，最后简要介绍本文实验中所采用的两种评估标准 CMC 曲线及 mAP。

2.4.1 ResNet 网络结构

ResNet(Residual Neural Network)^[32]是基于 CNN 网络构建的深度残差网络，用于解决深度网络因退化而难以训练的问题。如图 2-1(a)所示，ResNet 网络的核心思想是残差学习，其中 x 表示输入， $F(x)$ 表示残差函数。残差网络通过残差学习，构造了残差模块，通过将输入信息绕道传到输出模块，保护了信息的完整性，同时保证网络性能不会随着网络层数的加深而变差，解决了深度网络的退化问题。ResNet 网络自 2015 年被提出后，在图像分类、目标识别上均取得了非常出色的成绩。如图 2-1(b)、(c)所示，为 ResNet50 中用到的两种残差模块。




图 2-1 ResNet 跨层连接网络结构(a)、两层(b)及三层(c)残差学习模块

Fig. 2-1 The skip connection(a)、two-layer(b) and there-layer(c) residual module in ResNet50

如下图 2-2 所示,为 ResNet50 网络结构图。ResNet50 包含了 1 个独立卷积层、1 个最大池化层、4 个不同的卷积残差模块、1 个平均池化层和 1 个全连接层。ResNet50 可以看成一种端到端的函数映射过程,通过学习经过 ResNet50 处理得到的输出(Output)和给定的数据标签(Label)之间的关系,调整出输入和输出之间最佳的映射过程。其在特征提取过程中,提取的特征信息都是较高维度的信息,并不需要人工选取特定的特征信息,这些信息相对比较抽象,物理含义不是很明确,并不会专门对显式特征进行提取,这是 ResNet50 相比于传统特征提取方法一个很大的不同点。目前,ResNet50 在图片分类、目标检测等视觉领域都取得了出色的成绩,比传统的深度卷积网络模型有更高的精度,而且其残差学习的方式使得网络的可以更深,同时保证信息完整性,更加便于训练,对高维数据的处理有着很强的优势,但是其在网络训练和调参过程中需要大量的训练样本。




图 2-2 ResNet50 网络架构

Fig. 2-2 The architecture of ResNet50 network

2.4.2 特征金字塔模型

特征金字塔模型在计算机视觉领域是一种常用的提取多尺度特征的方法,通常有以下几种方式:(1) 将原图片按比例缩放依次送入网络中,可以检测到不同尺度的目标。但是多次缩放图片是非常耗时的,而且图片缩放会破坏一些原有信息;(2) 仅使用网络的最后一层输出特征进行目标检测,但是最后一层的全局特征缺乏细节信息及空间位置信息;(3) 使用网络中每一层的输出特征分别进行目标检测,但是底层特征图的只是学习到一些特定的属性信息,不具备充足的语义信息。针对以上方法存在的问题,全新的特征金字塔模型^[33]被提出,通过结合第(2)种和第(3)种方法的思想,将不同层次特征经过上采样或是下采样后进行融合,再在每一层的融合特征上分别进行检测,这样的融合特征含有足够的语义信息,同时网络指导可以每一层特征的学习。由此,得到基于 ResNet50 的特征金字塔模型,如下图 2-3 所示。




图 2-3 基于 ResNet50 的特征金字塔模型

Fig. 2-3 The feature pyramid model based on ResNet50

如图 2-3，这种特征金字塔模型的融合模块涉及两个输入和一个输出。两个输入包含来自高层输出特征上采样的结果或是底层输出特征下采样的结果，另一个输入分别是底层输出特征或高层输出特征。一个输出则是根据一定的特征融合方法(相加/拼接)对两个特征进行融合后的特征。使用这种金字塔模型可以保证每一级输出特征具有足够的特征表达能力，并在每个特征分支分别进行学习，通过损失函数来引导每一层特征的学习，使得特征提取更加鲁棒和健壮。

2.4.3 增量学习

随着实际应用场景中的数据获取方式逐渐变为动态的流数据，对模型的更新方式提出了更高的要求。在实际应用系统中，流数据往往是源源不断在线更新的，而一个静态系统无法利用训练好的模型处理新到来的数据。增量学习作为机器学习中的一种动态学习方法，近年来被广泛应用在计算机视觉领域。基于增量学习的模型则能在保留旧知识的同时学习新数据知识。增量学习的动态学习体现在流数据处理上，目前的神经网络学习是针对特定任务给定了完整数据集，然后在给定数据集上训练模型，这种固定类别的模型无法有效处理新类别数据。而增量学习方法是基于增量方式进行模型训练，即数据不是一次性给定，而是在训练过程中不断加入新数据，模型需要能学习到新数据的知识，同时尽可能不忘记训练过的旧数据知识。例如图 2-4 中，多个不同的数据集按序输入网络中进行训练，处理过的数据将不会再访问，最后的模型需要在这几个数据集上都有很好的表现，即学习到多个数据集的知识。




图 2-4 增量学习示意图

Fig. 2-4 The diagram of Incremental Learning

由于数据集不同，最优化目标也不同，网络在不同数据集上训练后的网络权重会发生很大改变，旧数据上训练的网络权重可能会被完全改变，在无法重新访问旧数据的情形下，训练过新数据的网络通常在旧数据上出现很大的性能下降，这种情况被称为灾难性遗忘问题(Catastrophic Forgetting)，如图 2-5 所示。




图 2-5 灾难性遗忘现象示意图

Fig. 2-5 The diagram of Catastrophic Forgetting in Incremental Learning

针对旧数据一旦训练后就无法访问的情况，为了解决增量学习中的灾难性遗忘问题，主要有两种方法：(1) 基于模型参数的方法(Parameter-based)^[37]；(2) 基于知识蒸馏(Distillation-based)的方法^[38]。Parameter-based 的方法是通过控制训练新数据过程中模型参数变化来实现。每次基于原模型训练新数据时，会对原模型中每个参数的重要性进行度量，控制对旧任务比较重要的参数的变化，代表方法有 EWC(Elastic Weight Consolidation)^[37]等算法。Distillation-based 的方法是基于知识蒸馏的实现方法，代表方法有 LWF(Learning without Forgetting)^[38]、iCaRL^[39]等算

法。

对于跨域 Re-ID 场景,由于目标域上数据是无标签的,而基于 Distillation-based 的增量学习方法需要利用数据的标签信息来设计知识蒸馏损失函数,所以基于知识蒸馏的增量学习方法并不适用于跨域 Re-ID 场景。在本文研究中,采用基于模型参数的增量学习方法来缓解 Re-ID 模型面对流数据时的灾难性遗忘问题。通过控制模型训练过程中参数变化来保留 Re-ID 模型对旧数据集的 Re-ID 效果。

2.4.4 CMC 曲线及 mAP

CMC 曲线(Cumulative Matching Characteristic Curve)是分类问题中最常用的评估标准。mAP(Mean Average Precision)是检索问题中最常用的评估指标。行人重识别既是分类问题也是检索问题,所以本文中同时采用 CMC 曲线和 mAP 进行模型评估。

CMC 曲线用于评估模型分类准确性,反映了分类器的性能。在行人重识别中,常用的评价指标为 CMC Rank-1、CMC Rank-5、CMC Rank-10。CMC Rank-n 反映在前 n 个候选结果中,正确命中结果占 n 个结果中的比率。在行人重识别领域中,候选结果来自于行人特征的相似度匹配结果,相似度越高,排名越靠前。

图 2-6 展示了 Re-ID 任务的单组匹配中 CMC Rank-1 至 Rank-5 的匹配结果,1-5 表示匹配结果集,红色表示匹配成功,Rank-1 值为 1。在 Re-ID 任务中,CMC Rank-1 识别率就是将查询图像(Query)的行人特征与检索库(Gallery)中图像进行相似度度量后,具有最高相似度的图像的身份是相同的,CMC Rank-5 则是相似度排名前 5 的图像中,存在与查询图片同身份的图像,同理,CMC Rank-10 识别率就是指相似度排名前 10 的图像中存在与查询图片相同身份的图像。




图 2-6 CMC Rank-n 示意图

Fig. 2-6 The diagram of CMC Rank-n in Re-ID

对于多组匹配结果,则是每组匹配结果的叠加。假设有 N 组匹配结果,第 i 组的匹配结果为 $Rank^i = \{rank_1^i, rank_2^i, \dots, rank_k^i\}$, k 为 CMC Rank- k 取值范围,其中 $rank_k^i$ 取值如下公式 2-1。整组数据的 CMC Rank- k 计算公式如下公式 2-2 所示。

$$rank_k^i = \begin{cases} 1 & \text{排序前}k\text{个样本中包含与}query\text{同ID的样本} \\ 0 & \text{其他} \end{cases} \quad (2-1)$$

$$Rank_k = \frac{1}{N} \sum_{i=1}^N rank_k^i \quad (2-2)$$

下图 2-7 展示了行人重识别中 mAP 指标的计算过程。



图 2-7 行人重识别中 mAP 计算过程

Fig. 2-7 The computational process of mAP in Re-ID

在行人重识别中,对于每一张查询图片(Query),通过计算其与检索集(Gallery)中每个样本的相似度距离,返回相似度排序靠前的前 N 个样本,表示这 N 个样本中行人最有可能与查询图片中人为同一个人。首先计算每个查询图片的 Top- K 返回结果的查询检索精度 AP(Average Precision),计算公式如下公式 2-3 所示,

$$AP^i = \frac{1}{K} \sum_{j=1}^K \frac{p^j + p^{j-1}}{2} (recall^j - recall^{j-1}) \quad (2-3)$$

$$p^j = \frac{\text{前}j\text{个排序结果中与}query\text{同ID的样本数}}{j} \quad (2-4)$$

$$recall^j = \frac{\text{前}j\text{个排序结果中与}query\text{同ID的样本数}}{\text{gallery中与}query\text{同ID的样本数}} \quad (2-5)$$

则 N 张查询图片的 mAP 计算公式如下公式 2-6,

$$mAP = \frac{1}{N} \sum_{i=1}^N AP^i \quad (2-6)$$

从公式可以看出, **mAP** 同时评估了特征信息提取准确性和分类结果准确性两方面。在排序前 Top-K 个样本中, 靠前样本中正确样本越多, **mAP** 计算得分越高。

2.5 本章小结

在本章节中, 分别针对单域 **Re-ID** 和跨域 **Re-ID** 进行了相关技术概述, 阐述了最新的研究进展, 并总结了现有跨域 **Re-ID** 模型方法存在的问题。最后简要介绍了本文研究内容中涉及的深度学习技术及实验评估标准。

3 基于多尺度特征有效融合的行人重识别模型

本章将介绍提出的基于多尺度特征有效融合的行人重识别模型 EMFF。内容主要包含四部分。第一部分引出多尺度特征对于行人重识别模型性能的重要性，并简要阐述现有 Re-ID 模型存在的问题，说明本章模型的改进思路；第二部分详细介绍了现有最优的几种基于多尺度特征的 Re-ID 模型，并总结模型的优缺点。第三部分详细介绍本章提出的模型 EMFF，包括模型各个模块的网络结构设计及数据处理过程，最后总结模型训练的损失函数。第四部分是实验结果展示部分，首先介绍本模型使用的数据集及实验环境，然后展示了模型在数据集上的参数选择实验结果，最后分别展示模型的单域实验结果、时间性能实验结果和跨域实验结果。最后总结本章模型方法，并简要分析实验结果。

3.1 引言

目前基于特征融合的行人重识别模型方法主要有两类：(1) 基于全局特征，水平划分得到部件特征，用各部分特征分别进行度量学习^[7]；(2) 基于金字塔池化形成不同大小感受野的特征，再进行融合(相加或拼接)，用融合特征进行行人 ID 预测学习^[42]。

第一种方法通常能取得很好的性能，因为分块对于遮挡或部分变化问题具有潜在的健壮性。但是这种方法获取的局部特征大多从全局特征划分而来，全局特征本身已经丢失了很多细节特征。特征划分的理想情况是划分得到的每一块都对应一个具体的身体部位，这高度依赖于行人检测框的正确性，但实际场景下，划分结果很可能没有意义。如图 3-1 中展示了一些不理想的划分结果。第二种方法中，利用池化技术生成不同大小感受野的特征图，能使得融合特征包含更加全面的信息，这对行人重识别任务是有利的，但是直接采用特征相加或拼接的方式容易引入噪声，对模型性能产生负作用。因为不同尺度的特征之间可能存在冲突，当这种冲突在网络之间逐级累加时会影响模型性能。

针对现有模型的两大问题，本章提出一个基于多层特征有效融合的行人重识别模型，旨在有效融合不同尺度的特征用于提升行人重识别性能。基于该方法在 Market-1501^[35]和 DukeMTMC-reID 数据集上进行了大量实验，CMC Rank-1 指标分别达到了 96.1%和 89.7%，优于大部分现有模型。在时间性能上，该模型方法网络结构相对简单，比较有优势。在跨域实验中，以 ResNet50 作为基准模型，该模型方法在 Market-1501 和 DukeMTMC-reID 数据集上的 mAP 值分别高出基准模型

11.6%和 21.2%。证明该模型方法特征融合的有效性及其较强泛化能力。



图 3-1 不理想的人体划分结果

Fig. 3-1 Some undesirable examples of body partition

本章的主要贡献可以总结为如下四点：

(1) 提出一种基于多层特征有效融合的行人重识别模型 EMFF，该模型方法能够很好的强化不同尺度特征之间的一致性特征，弱化不同尺度特征中包含的噪声信息对于后续网络训练的影响，达到有效融合特征的目的。

(2) 改进 ResNet50 网络架构，使其能很好的兼容本文提出的多层特征融合的模型方法，去除最后一个残差块后的全局平均池化层（GAP）和全连接层（FC），添加上卷积模块，使得输出特征图变大，构建特征金字塔，提取更加细粒度的特征，从而提升模型性能。

(3) 多任务训练模块，该模块完成两个训练任务：1、基于边界挖掘损失函数^[36]的度量学习；2、基于分类损失的行人 ID 预测。利用可学习的超参数引导网络关注还没有学习好的区域。

(4) 大量的实验证明该特征融合方法能充分利用细节特征，有效提升行人重识别精度，在跨域上 Re-ID 实验中性能大幅度超过基准网络性能。

3.2 基于多尺度特征融合的行人重识别传统方法

针对现有 Re-ID 模型的特征融合问题，近期提出了一些新的方法。Chen 等人^[50]提出一种在多尺度图像上提取特征并共同学习的行人重识别模型方法 DPFL，解决了图像输入进 Re-ID 网络时 Resize 操作带来的显著性特征模糊的问题。这种模型方法在主流数据集上取得了 SOTA 成果。但是同时对不同尺度图像建模会带来时间性能降低和消耗大量内存的问题。Wang 等提出 MGN 模型^[42]，通过不同数量的图像水平切片来提取不同粒度的特征，文中分别在切片数量为 1, 2, 3 时的提

取到一级、二级、三级粒度特征,这三个粒度特征作为独立分支分别进行学习优化,最终不同粒度特征可以整合成一个融合特征。这种模型方法在主流数据集上取得了 SOTA 成果。这种模型根据固定切片数对图像切片,没有考虑切片部分之间的相关性。Fu 等^[43]针对行人遮挡问题提出 HPM 模型,在水平方向上对特征图切片,得到多个特征向量分别进行行人 ID 预测训练。提出平均最大池化策略 (Average and Max Pooling Strategy),减轻平均池化对高判别性区域的弱化问题,将平均池化和最大池化结果相加,从而保留全局和局部信息。模型性能较之之前的模型略有提升。从实验结果来看,平均最大池化策略能提升模型性能,但是直接相加这两种特征会引入冗余特征。Wang 等^[53]提出四阶段神经网络 DaRe,每个阶段对应网络中每层卷积层的输出特征,每个阶段分别基于三元组损失函数进行训练,最后将四阶段的特征通过权重系数进行加权求和。模型相对简单,同等精度下需要的计算量小。Zheng 等^[46]针对错误的行人检测框对行人重识别的影响,提出金字塔模型 PyramidRe-ID 来缓解 Re-ID 模型对检测框的依赖。提出多任务动态学习来学习各分支损失函数的动态权重。该模型方法充分考虑到人体各部件之间关系,性能优于固定切片数的 Re-ID 模型。但是该方法的特征金字塔结构建立在全局特征上,从根本上缺少细节特征。

3.3 EMFF 模型

本章节提出的 EMFF 模型结构如图 3-2 所示。




图 3-2 EMFF 的网络结构图

Fig. 3-2 The network architecture of EMFF

模型主要分为特征提取模块,特征融合模块和多任务学习模块。下面的章节将会详细介绍模型中的每个模块。行人图像经过预处理后作为 EMFF 模型的输入。其中,在 ImageNet 上预训练的 ResNet50 作为特征提取器,提取每个行人图像中的

特征信息。为了方便进行特征融合，对 ResNet50 进行结构调整，去除最后的全局池化层和全连接层，在最后一个残差卷积块(Residual Block)后面添加 3 个上采样模块(由上采样和 1×1 卷积构成)，分别产生对应 ResNet50 第四、三、二个残差卷积块输出特征大小的特征。将每个上采样模块的输出特征与 ResNet50 对应层输出特征送入特征融合模块进行有效融合，形成 4 个特征分支。在每个特征分支中进行基于难样本三元组损失函数^[36]的度量学习和基于交叉熵损失函数的行人 ID 预测学习。测试阶段，将各个分支特征融合后最为提取到的行人特征。

3.3.1 特征融合模块

特征融合模块网络结构如图 3-3。该模块任务分为两步：(1) 减轻特征之间显著性差异；(2) 特征融合。




图 3-3 特征融合模块结构图

Fig. 3-3 The architecture of Feature Fusion Module

特征融合模块接受两个输入，分别来自于高层特征 f_h 和低层特征 f_l 。 f_h 首先经过上采样达到与 f_l 一致的尺寸，在经过一个 1×1 卷积达到与 f_l 一致的通道数。在融合之前，先考虑来自不同层级的特征之间的不一致性。不同卷积层的特征存在显著性差异，假设两个不同层的特征关注重点是冲突的（比如一个强调背景属性，一个强调人物属性，这两个特征对于 Re-ID 分类任务是冲突的），直接相加或拼接这些的特征会干扰训练期间梯度计算，降低融合特征有效性。所以在融合之前先去除特

征之间的显著性差异，提取互补成分，才能得到有效的融合特征。

本文中参考 Hadamard Product 方法来解决特征之间显著性差异问题。Hadamard Product 表示矩阵向量对应位置相乘。将两个不同层级的特征向量分别表示 $f_h = [a_{ij}]_{H \times W}$, $f_l = [b_{ij}]_{H \times W}$ ，则 f_h 和 f_l 之间的 Hadamard Product 计算公式如下：

$$f_{common} = f_h \otimes f_l = [c_{ij}]_{H \times W}, c_{ij} = a_{ij} * b_{ij} \quad (3-1)$$

将提取的特征表示为 f_{common} 。

从公式可以看到两个特征的 Hadamard Product 的结果是对应位置相乘得到的向量。从几何角度出发，特征向量每一个位置元素是由卷积层对原图像进行卷积计算得到，每一个元素不同对应于卷积核的不同，而不同的卷积核对应关注原图像的不同区域。由此经过卷积层提取的特征向量中较大值对应应该层卷积关注的区域。通过 Hadamard Product 计算，两个特征向量值都比较大的位置相乘的结果也会很大，而值差异比较大的位置结果则会很小，这样就提取到不同特征之间的共性部分，同时弱化了两个特征之间显著性差异。

在特征融合步骤中，将 f_{common} 与 f_h 相加，对应如下计算公式：

$$f_{fusion} = f_{common} \oplus f_h \quad (3-2)$$

基于重要的判别性信息应该被多层网络都提取到的假设，FM 模块通过 Hadamard Product 计算后可以强化判别性信息，同时减轻特征之间显著性差异带来的性能损失。

3.3.2 多任务学习模块

多任务学习模块的网络结构如下图 3-4 所示。




图 3-4 多任务学习模块网络结构

Fig. 3-4 The architecture of Multi-task Learning Module

特征融合模块后，多个特征分支单独进行多任务学习。每一个分支中的任务学习过程如下：

首先特征输入全局平均池化层（GAP），对 GAP 的输出特征利用边界挖掘损失函数^[36]进行度量学习，再将经过 BN 层和 FC 层后的特征基于交叉熵损失函数进行行人 ID 预测学习。

每个分支损失函数定义为：

$$L_i = L_{msml} + L_{ID}, i = 1, 2, 3, 4 \quad (3-3)$$

总的损失函数定义为：

$$L_{total} = \sum_i \omega_i L_i, i = 1, 2, 3, 4; \sum_i \omega_i = 1 \quad (3-4)$$

其中 ω_i 是一个可学习超参数，基于上一次迭代中各分支中分类损失大小来更新，目的是重点关注分类效果差的分支。更新规则如下：

$$\omega_i^{t+1} = \omega_i^t * \left(L_{ID,i}^t / \left(\varepsilon + \sum_j L_{ID,j}^t \right) \right) \quad (3-5)$$

在多任务学习模块，通过联合训练 ID 分类任务和相似性度量学习任务来更新网络，在类别学习的同时提升模型泛化能力。为了进一步提升模型性能，设置可学习的超参数 ω 来控制网络学习更具判别性的特征。

3.3.3 损失函数

在训练 EMFF 模型时使用到两个损失函数，包括行人 ID 分类损失和行人相似性度量损失。其中行人 ID 分类损失为交叉熵损失函数，相似度量损失函数如下公式(3-6)，

$$L_{msml} = \left(\max_{a,p} d_{a,p} - \min_{m,n} d_{m,n} + \alpha \right)_+ \quad (3-6)$$

$$d_{a,p} = \|f_a - f_b\|_2 \quad (3-7)$$

其中 a, p, m, n 为 mini-batch 中的图片，a, p 为 mini-batch 中最不像的正样本对，m, n 为 mini-batch 中最相像的负样本对，a, m 可以为正样本也可以为负样本。 $\max_{a,p} d_{a,p}$ 为正样本对距离的上界， $\min_{m,n} d_{m,n}$ 为负样本对距离的下界。 $\|\cdot\|_2$ 表示两个向

量之间的欧氏距离， α 是根据实际需求设定的阈值，其取值将在 3.4.2 中讨论。MSML 损失函数的思想是将正负样本对的边界推开，同时兼顾相对距离和绝对距离来进行度量学习。定义模型训练损失函数表示为 L_{total} ，如公式 3-4。

3.4 实验及结果

3.4.1 数据集及评价标准

本文选择了目前较大的行人重识别数据集 Market-1501，DukeMTMC-reID 对本文方法进行实验。数据集详情如表 3-1 所示。

Market-1501 数据集中总共包含 1501 位行人，包含 32668 张行人图像，由 6 个摄像头(其中 5 个为高分辨率摄像头，1 个为低分辨率摄像头)拍摄得到，每位行人至少有两个摄像机拍摄得到。数据集中每个行人至少由两个摄像头捕获到，同一个摄像头可能具有多张图片。本章中随机采样 751 个行人作为训练集，另外 750 个行人作为测试集。在测试集中，采样每个行人的每个摄像机下的一张图片作为查询集(Query)，摄于图像作为测试集的搜索库(Gallery)，并在搜索库中加入之前的 408 个行人图像作为干扰项。

DukeMTMC-reID 数据集中数据采集自由 8 个同步摄像机记录的新型高清视频数据集，每 120 帧从视频中采样一张图像，一共 36411 张行人图像，有 1401 个人出现在两个以上摄像机下，有 408 人只出现在一个摄像头下。本章中随机采样 702 个行人作为训练集，702 个行人作为测试集。在测试集中，采样每个行人的每个摄像机下的一张图片作为查询集(Query)，剩余图像作为测试集的搜索库(Gallery)，并在搜索库中加入之前的 408 个行人图像作为干扰项。最终，DukeMTMC-reID 数据集中包含 16522 张训练图片(来自 702 位行人)，2228 张查询图像(来自另外的 702 位行人)，17661 张图像的搜索库(Gallery)。

表 3-1 数据集详情

Tab. 3-1 Statistics of two person re-id datasets

数据集	相机数	行人数	行人划分		数据集划分		
			训练	测试	训练	搜索	查询
Market-1501	6	1501	751	750	12936	19732	3368
DukeMTMC	8	1404	702	702	16522	17661	2228

3.4.2 参数选择及实验环境

本文实验开发环境如下表 3-2 所示，所有实验结果均基于此环境实验得到。网络骨干网络采用在 ImageNet 数据集上预训练的 ResNet50 模型，训练阶段，行人图片输入尺寸为 384×128 ，每个训练批量(Batch)中随机采样 8 个 ID 的行人，每个 ID 有 4 张图片。为了了解不同优化算法、margin 值、学习率(Learning Rate)初始值和迭代次数对实验精度的影响，本文分别采用不同的优化算法、margin、学习率初始值及迭代次数进行实验，实验结果如下图 3-5 所示。

表 3-2 实验环境

Tab. 3-2 Experimental environment

配置	参数
操作系统	Ubuntu 16.0.4
内存	15G
CPU	Intel® Xeon® CPU E5-2682 v4 @ 2.50GHZ
GPU	Tesla P4
软件平台	Pytorch0.4.1




图 3-5 Market-1501 上不同参数设置下 Rank-1 精度

Fig.3-5 Rank-1 Results of model with different parameters setting on Market-1501

从图中数据可以看到，基于 ADAM 优化算法的实验精度总体高于基于 SGD 优化算法的实验精度。基于 ADAM 优化算法，学习率初始值设置为 $2e-4$ ，Margin

中设置为 1.2, 迭代次数为 400 时获得较高精度。由此, 模型的采用 ADAM 优化算法进行训练, 动量系数为 0.9。学习率(Learning Rate)初始值设置为 $2e-4$, 分别在第 320 和 360 周期进行学习率衰减, 衰减率系数为 0.1, 总共迭代 400 次。模型权重衰减系数为 $5e-4$ 。每个特征分支独立计算损失函数, 模型的总损失为各分支损失加权和, 其中权重 ω 为可学习超参数, 初始值均为 0.25。在测试阶段, 融合各分支特征作为行人特征表示。

在 Market-1501 和 DukeMTMC 数据集上运用选定的参数进行实验验证。如图 3-6 和图 3-7 分别展示了 EMFF 模型在两个数据集上测试过程中的损失曲线(Loss Curves)与性能曲线图。从损失曲线图中可以看出模型损失初期下降的较快, 整体比较平滑, 没有明显的曲线波动, 在迭代后期, 曲线比较平稳, 说明经过 400 次的迭代, 模型已经收敛。结果表明, 本章实验参数选择合理。




图 3-6 EMFF 模型在 Marke-1501 数据集上的训练过程

Fig. 3-6 The training process of EMFF model on Market-1501 dataset




图 3-7 EMFF 模型在 DukeMTMC-reID 数据集上的训练过程

Fig. 3-7 The training process of EMFF model on DukeMTMC-reID dataset

3.4.3 实验结果分析




图 3-8 模型各层卷积层输出特征图

Fig.3-8 Output feature maps of each convolutional layer in proposed model

为了测试模型的融合特征是否有效, 先将图片输入到模型进行特征图可视化, 并与 ResNet50 模型各层输出的特征图进行对比。如上图 3-8 所示, 基于 EMFF 模型提取的高层特征包含了更多的细节特征, 说明此方法进行的特征融合是有效的。

为了验证本文方法的有效性, 分别在 Market-1501 和 DukeMTMC-reID 数据集上进行大量的实验测试。为了验证特征融合模块和超参数学习对于网络性能的影响, 分别将融合方法和超参数学习加入到基础模型中, 测试结果如下表 3-3。

表 3-3 不同分块模型性能比较

Tab. 3-3 Performance comparison of different part of the model

Models	Market-1501		DukeTMC-reID	
	Rank-1	mAP	Rank-1	mAP
Baseline	92.5	80.8	86.5	70.5
EMFF+ $\oplus$	93.9	84.9	88.5	75.6
EMFF+FM	94.6	86.5	89.2	78.5
EMFF+FM+ ω	96.1	88.8	89.7	80.4

注: $\oplus$ 特征之间直接相加

EMFF 模型的基准网络是基于在 ImageNet 上预训练的 ResNet50 网络。直接使用基准模型在 Market-1501 数据集上 Rank-1 和 mAP 分别达到了 92.5%和 80.8%, 在 DukeMTMC-reID 数据集上 Rank-1 和 mAP 分别达到了 86.5%和 70.5%。在基准网络基础上添加特征金字塔结构, 不同尺度特征之间直接相加的方式训练网络。相比基准网络, 性能在两个数据上都提升了 3%-4%左右, 说明细节特征对于行人重识别任务很重要。在模型中添加特征融合模块后, 性能在两个数据集上也有了相应的提升, 说明将特征直接相加融合虽然会提升模型性能, 但同时不同特征之间的显著性差异也会限制模型性能。最后在加上超参数学习部分, 模型性能也有小幅度上涨, 说明学习的超参数可以引导网络学习更难的特征, 从而提升行人重识别准确率。最终, 通过新的特征融合方法和超参数学习, EMFF 模型 Market-1501 数据集上的 CMC mAP 精度相比 ResNet 基准网络提升了 8%, DukeMYMC-reID 数据集上 mAP 提升了 9.9%。

目前, 有一些优秀的基于多尺度特征融合的行人重识别模型^[42], 本文选取其中表现最好的几种主流方法与本文模型方法进行对比, 对比结果如下表 3-4 所示。

从表中可以看出本文方法性能较其他主流算法都有提升, 相比目前的最优模型 PyramidRe-ID 模型, 在 mAP 性能指标上, DukeMTMC-reID 数据集上涨了 1.4%, Market-1501 数据集上涨了 0.6%; 在 CMC Rank-1 性能指标上, DukeMTMC-reID

数据集上涨了 0.7%，Market-1501 数据集上涨了 0.7%。

表 3-4 本章方法与主流方法性能对比

Tab. 3-4 Performance comparison of proposed model with mainstream models

Methods	Market-1501		DukeTMC-reID	
	Rank-1	mAP	Rank-1	mAP
DPFL	88.9	73.1	79.2	60.6
DPFL*	92.3	80.7	-	-
MGN	95.7	86.9	88.7	78.4
HPM	94.2	82.7	86.6	57.5
DaRe+RR+RE	90.8	85.9	84.4	79.6
PyramidRe-ID	95.7	88.2	89.0	79.0
EMFF(Proposed)	96.1	88.8	89.7	80.4

注：*表示 Multi-shot

3.4.4 时间性能分析

为了测试模型的时间性能，在 Market-1501 数据集的测试集上进行模型测试，并记录所需要花费的时间。评价指标为每张 Query 图片与 Gallery 中所有图像进行匹配需要花费的时间，即 Test-time。Market-1501 数据集中测试集包含 750 位行人，共 19732 张行人图像。与 DaRe 模型^[53]对比，实验结果如下表 3-5 所示。

表 3-5 EMFF 模型在 Market-1501 测试集上的时间性能

Fig. 3-5 Running time of EMFF model on test set of Market-1501 dataset

Model	Time/s	
	Test Time	Per matching(19732)
DaRe	318	0.0161
EMFF(Proposed)	336	0.0170

从上表可以看出，本章模型比 DaRe 模型运行时间稍长，但是精度却有很大的提升。实际场景下，以 0.0170s 的时间从图库中检索一个人是足够满足实时性需求的。

3.4.5 跨域实验


深度网络模型表现好的前提是需要有大量的训练数据。相比人脸识别几十万张图像的数据集，行人重识别常用数据集中仅有几万张的行人图片，在这种数量级的数据集上训练的模型很容易在出现模型在域上过拟合的问题。具体表现是，模型即使在一个数据集上训练和测试的结果都比较好，但是一旦用另外的数据集进行交叉实验，模型表现会很差，也称为模型的泛化能力差。为了进一步验证 EMFF 模型泛化性能，对 EMFF 模型进行跨域测试。方式是采用一个数据集作为模型的训练集，采用另一个不同的数据集作为测试集。以 ResNet50 网络作为基准模型，得到的跨域实验结果如下表 3-6 所示。

表 3-6 跨域测试模型泛化性能


Tab. 3-6 Testing model generalization ability by cross-domain validation

Model	M $\rightarrow$ D		D $\rightarrow$ M	
	Rank-1	mAP	Rank-1	mAP
Baseline	30.5	16.7	54.6	26.6
EMFF(Proposed)	49.8	40.4	56.7	40.3

下图 3-9 中，展示了模型在跨域数据上测试的性能曲线图。



(a)



(b)


图 3-9 EMFF 模型在跨域场景下的测试性能

(a) DukeMTMC→Market-1501 (b) Market-1501→DukeMTMC


Fig.3-7 The cross-domain validation results with EMFF model.

(a) DukeMTMC→Market-1501 (b) Market-1501→DukeMTMC

从图中可以看出 DukeMTMC→Market-1501 的跨域实验性能曲线比较平滑,性能曲线没有明显的下降拐点, Market-1501→DukeMTMC 的跨域实验性能曲线则比较曲折,迭代过程中存在明显的下降拐点,但是模型后期还是呈现上升趋势。这说明不是模型学习能力不够,而是 Market-1501 数据集相比 DukeMTMC-reID 数据集,样本的多样性不够,不足以表示 DukeMTMC-reID 数据集中的复杂场景。图 3-10 中分别列举了 Market-1501→DukeMTMC 实验中较差和较好的匹配结果。从图中可以看出,较差的匹配结果中 Query 图像存在大片区域的遮挡、不同行人具有相似外貌的问题。说明这是导致模型跨域效果差的根源问题,所以导致了性能曲线中的下降拐点。



(a)



(b)

图 3-10 Market-1501→DukeMTMC-reID (a)不好的情况 (b)较好的情况

Fig.3-10 Market-1501→DukeMTMCreID (a) Bad matching (b) Good matching

3.5 总结

在本章节中，提出了基于多尺度特征有效融合的行人重识别模型(EMFF)，这个模型充分利用不同尺度特征的判别性信息，进而提取到更具鲁棒性和判别性的行人特征。与以往基于人体部位特征的特征融合方式不同，网络架构更加简单，相同的精度下时间性能更优。

在本章提出的模型中，首先基于修改后的 ResNet50 网络的各层卷积块输出特征构建特征金字塔，然后将多尺度特征经过特征融合模块输入到多任务学习网络中，利用分类损失和边界挖掘损失函数(边界 margin 为 α 进行模型训练。该方法在特征融合模块强化了特征之间的一致性，弱化了特征显著性差异对后续网络的影响。在多任务学习阶段通过超参数 ω 学习自然的让网络关注还没有学习好的区域，提取判别性信息。在本模型中，有两个重要参数： ω 和 α 。通过大量的实验，对比了各种不同的参数组合方式，最终确定了一组较好的参数。基于此参数组合，在 Market-1501 和 DukeMTMC-reID 数据集上进行模型评估。实验结果表明本章提出的模型精度优于目前基于特征融合的模型精度。尤其在交叉实验中，相比基准网络 ResNet50，在 Market-1501 $\rightarrow$ DukeMTMC-reID 上的 mAP 提升了 23.7%，在 DukeMTMC-reID $\rightarrow$ Market-1501 上的 mAP 提升了 13.9%。

4 基于无监督增量学习的跨域行人重识别模型

本章将介绍提出的基于无监督增量学习的行人重识别模型 ILRe-ID。内容主要包含四部分。第一部分介绍跨域 Re-ID 技术的重要性,并针对实际场景下的跨域 Re-ID 系统面临的挑战提出本章模型。第二部分详细介绍目前跨域 Re-ID 技术的研究现状,并总结各种方法的优缺点。第三部分详细介绍本章提出的 ILRe-ID 模型,包括模型每个模块的训练过程及损失函数。第四部分是 ILRe-ID 模型的实验结果展示,首先介绍数据集与数据预处理,然后进行参数选择,最后展示跨域实验结果并与 SOTA 方法进行对比。最后总结本章模型方法,并简要分析实验结果。

4.1 引言

随着单域 Re-ID 技术的愈发成熟及现实场景对 Re-ID 技术的迫切需求,加速行人重识别技术的应用落地是 Re-ID 课题的首要目的。因此,跨域 Re-ID 课题成为学术界及工业界的研究重点。跨域 Re-ID 同单域 Re-ID 都是处理跨摄像机间的行人检索,但是跨域 Re-ID 涉及到模型在两个不同场景上的应用,更符合现实场景下的 Re-ID 系统需求,是实现 Re-ID 技术落地应用的关键技术。

对于一个实际场景下的 Re-ID 系统,应该具备以下条件:

- (1) 系统接收的数据来自于实时摄像机拍摄的监控图像和视频,无人工标注,数据源源不断的获取;
- (2) 系统模型能实时处理新到来的数据,并在线更新模型;
- (3) 系统模型需要具备时效性,即一个行人图片从输入到分到匹配结果的事件需要再可接受范围内,否则无法满足实用性。

目前还没有 Re-ID 模型能同时满足以上三个条件,所以跨域 Re-ID 的研究需要从以上三个条件同时出发,找到一个能满足所有条件的方法是跨域 Re-ID 的研究重点。现有的 Re-ID 数据集是对监控数据进行人工或技术检测并标注后得到的,但是在现实 Re-ID 系统,实时收集的监控视频是海量数量级的,使用人工标注需要耗费大量的时间和计算力及存储空间,同时不满足(3)条件的时效性。在数据无标签条件下,直接利用无标签数据从头训练一个 Re-ID 模型是困难的。首先缺乏行人身份标签这个强判别性信息,其次对于不断到来的数据序列,无法预知该数据中包含的行人类别数。所以通常的跨域 Re-ID 方法会采用迁移学习思想,先利用标注好的数据集训练一个基础的 Re-ID 模型,称为预训练 Re-ID 模型,该模型会在标注数据集上具有良好的性能表现。然后模型在无标注数据集上进行模型优化,

学习新领域的知识。这是一个两阶段训练过程。从描述可以看出,基于迁移学习的跨域 Re-ID 模型方法性能的关键在于预训练模型在无标注数据集上的泛化能力以及模型在无标注数据集上的优化过程。确定了跨域 Re-ID 方法的基本实现思路后,需要解决跨域 Re-ID 模型的在线学习能力。现有基于深度学习的网络模型是在给定的数据集进行训练,数据类别是固定的,这样固定类别的模型在面对新类别数据时往往表现很差,即缺乏对新类别数据的学习能力。要想提升模型性能,只能综合所有数据,重新训练模型,这同样是个耗时的工作,无法满足(3)条件。还有一种思路是每到来一个新数据就对网络模型进行扩增,使得模型能学习到新数据,模型精度可以保证,但是预想,随着海量监控视频源源不断的输入网络,网络将会越来越臃肿,假设存储空间能满足模型的无限增长,模型的检索时间也会大大增加,同样无法满足(3)条件,况且实际的存储空间是有限的。

所以,一个能应用于实际场景下的跨域 Re-ID 模型需要满足:

- (1) 较低的模型复杂度以保证模型的时效性,
- (2) 同时具有对持续输入的无标签数据序列进行学习的能力。

综合以上分析,能应用于实际场景中的跨域 Re-ID 模型需要实现精度和时效性两者之间的平衡。

针对以上跨域 Re-ID 模型需要满足的两个条件,本章节中基于 EMFF 模型,目标域上结合无监督聚类算法与增量学习方式,提出基于无监督增量学习的行人重识别模型 ILRe-ID。在 Market-1501 和 DukeMTMC-reID 数据集上进行大量跨域实验,其中在 Market-1501 上的跨域 CMC Rank-1 达到了 82.5%,mAP 达到了 59.1%。

本章主要贡献总结如下:

- (1) 提出基于无监督增量学习的跨域行人重识别模型 ILRe-ID。
- (2) 目标域基于无监督聚类方法进行无监督学习,提升模型在目标域性能。
- (3) 基于模型参数调整进行模型的在线更新,逐步实现模型域适应。
- (4) 大量实验证明无监督增量学习方法可以使得模型性能得到持续改进,模型更适用于实际应用场景。

4.2 ILRe-ID 模型

ILRe-ID 模型旨在解决以下问题:给定源域中有标签数据集与目标域无标签数据集,同时目标域上数据通过逐步采集的方式送入模型,希望训练的跨域行人重识别模型能实时学习新到来数据,并在线更新模型,来实现模型域适应。模型结构图如下图 4-1 所示,整个模型分为三个步骤:

- (1) 源域的有标签数据集上进行监督学习,得到一个预训练的 Re-ID 模型

EMFF; 该部分在已经本文第三章进行了详细阐述。

(2) 对于数据序列中的每个数据集, 基于 EMFF 模型提取目标域行人特征, 使用无监督聚类算法为目标域数据添加伪标签, 借助聚类损失函数优化 EMFF 模型;

(3) 基于调整模型参数来指导模型在线更新, 逐步完成新知识学习与旧知识的保留及模型的域适应。

接下来的章节中, 将详细介绍 ILRe-ID 模型中各步骤的具体操作及流程。




图 4-1 ILRe-ID 模型架构图

Fig. 4-1 The architecture diagram of ILRe-ID Model

4.2.1 无监督聚类学习阶段

在无监督聚类学习阶段, 首先利用 EMFF 模型提取行人图像特征, 利用行人特征进行聚类, 然后选择适合的聚类准则进行实验, 对目标域数据生成伪标签, 最后利用生成的伪标签基于设计的损失函数进行模型训练。

在该阶段, 聚类准则的选择和损失函数的设计是关键。本章中通过大量实验验证不同聚类准则对模型的影响, 最后采用最小聚类准则。为了充分提取无标签数据中的类间差异性和类内相似性, 分别利用 Inter-class Repelled Loss 来推开不同类的样本之间的距离, 使用 Intra-class Center Loss 来拉近同类样本之间的距离。如图 4-1(2)中所示, 无监督算法包含三个步骤: 首先, 通过模型的分学习区分不同行人, 实现模型参数更新, 由此学习到不同行人之间显著性差异表示。然后, 基于行人特征相似度排序, 由于同一个人的特征应该相似, 将排序靠前的图像看成是同一个行

人。将同一个人的图像组成为一个聚类,联合 Inter-class Repelled Loss 和 Intra-class Center Loss 进行模型训练。通过上述步骤,同时利用类间差异性与类间相似性进行模型更新,使得模型进一步适应目标域场景。

上述步骤中,涉及到两个重要的聚类损失函数,下面分别进行详细介绍。

(1) 类间差异性损失函数(Inter-class Repelled Loss)

由于目标域数据缺乏标签,首先为每一张图片初始化标签,即 $\{\hat{y}_p = i | 1 \leq i \leq N_{t_k}\}$ 。则每张图片 x 属于第 i 个聚类的概率值表示如下公式 4-1:

$$p(i | x, V) = \frac{\exp(V_i^T v / \tau)}{\sum_{j=1}^C \exp(V_j^T v / \tau)} \quad (4-1)$$

$$v = \Phi(\theta; x) / \|\Phi(\theta; x)\| \quad (4-2)$$

其中 v 是对行人特征 $\Phi(\theta; x)$ 的正则化操作, $\|v\|=1$ 。 C 表示当前聚类数量,初始训练阶段有 $C=|X_T|=N_T$ 。 $V \in \mathbb{R}^{C \times n_\phi}$ 是一个存储了各个聚类的聚类中心特征的查找表,用于减少聚类查找过程中的冗余计算。在前向传播过程中,计算每张图像中行人特征与每个聚类中心特征的余弦距离 $V^T \cdot v_i$ 。反向传播过程中,第 $\hat{y}_i$ 列的更新公式如下 4-3:

$$V_{\hat{y}_p} \leftarrow 2^{-1} \cdot (V_{\hat{y}_p} + v_i) \quad (4-3)$$

即每个聚类中加入新样本时更新聚类中心。由此,基于每张图片属于每类聚类中心的概率值设计损失函数如下公式 4-4:

$$\ell_{repelled} = -\log(p(\hat{y}_p | x_i, V)) \quad (4-4)$$

(2) 类内相似性损失函数(Intra-class Center Loss)

为了在最大化类间差异的同时,最小化类内差异,提出类内中心损失函数如下公式 4-5 所示,其中 m 为训练中 mini-batch 的数量。

$$\ell_{center} = 2^{-1} \sum_{i=1}^m \|v_i - V_{\hat{y}_p}\|_2^2 \quad (4-5)$$

由公式可以看出,该损失函数是希望一个 mini-batch 中的每个样本特征离与该样本最相近的聚类中心特征的欧氏距离越小越好,也就是缩小类内距离。反向传播中, $\mathcal{L}_{center}$ 梯度和 $V_{\hat{y}_i}$ 的更新公式如下式 4-6 和 4-7:

$$\frac{\partial \ell_{center}}{\partial v_i} = v_i - V_{\hat{y}_p} \quad (4-6)$$

$$\Delta V_{\hat{y}_p} = (V_{\hat{y}_p} - v_i) / 2 \quad (4-7)$$

(3) 无监督聚类损失函数

在无监督聚类学习模块的无监督聚类损失函数由以上两个损失的加权和构成。公式如下 4-8:

$$\ell_{unsup} = \ell_{repelled} + \ell_{center} = -\sum_{i=1}^m \log \frac{\exp(V_i^T v / \tau)}{\sum_{j=1}^C \exp(V_j^T v / \tau)} + \frac{\alpha}{2} \sum_{i=1}^m \|v_i - V_{\hat{y}_p}\|_2^2 \quad (4-8)$$

其中 α 为平衡两种损失函数的超参数。

(4) 聚类准则

在无监督聚类学习训练初期,默认设置每张训练图片为一个聚类,随着模型迭代,需要依据相应的聚类合并准则将相似的行人图像进行合并。目前聚类方法中常用的聚类准则主要有以下三种:

- (1) 最大距离准则(Maximum Distance Criterion) 以两个不同聚类中特征间的最大距离作为两个聚类的差异度。
- (2) 平均距离准则(Centroid Distance Criterion) 以两个不同聚类的聚类中心之间的距离作为两个聚类的差异度。
- (3) 最小距离准则(Minimum Distance Criterion) 以两个不同聚类中特征间的最小距离作为两个聚类的差异度。

针对跨域行人重识别场景,(1)准则容易将跨摄像机下外貌差异大的行人图像划分为不同聚类;(2)准则中聚类中心点的特征是该聚类内所有行人图像特征的均值,取均值的过程会影响聚元素的真实概率分布;(3)准则与(1)准则相反,容易将外貌相似的不同行人图像合并为一个聚类。

经过大量实验验证,最小距离准则更符合同一个行人在不同摄像机下应该具有相似特征的假设,容易将同一个行人的图像合并为一个聚类。因此,本章模型中采用最小距离准则作为聚类合并准则,计算公式如下:

$$D_{distance}(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} d(x_i, x_j) = \min_{x_i \in C_i, x_j \in C_j} \|v_{C_i}, v_{C_j}\|_2^2 \quad (4-9)$$

$d(\bullet)$ 用于计算两个聚类中图像特征之间的欧氏距离。

由于最小距离聚类准则对于元素数量较多的聚类有偏向,即如果一个聚类中包含足够多样本,则该聚类更容易吸引其他小数量的聚类点。为此,在聚类准则中加入聚类正则项,尽量控制合并的两个聚类中,样本数量相差不大。最终聚类之间距离计算如下公式 4-10。

$$D_{distance}(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} d(x_i, x_j) + \beta(|C_i| + |C_j|) \quad (4-10)$$

同时在每次聚类合并中控制聚类合并的速度，限制单次合并数量为 m ， $m = N \times \gamma$ ， $\gamma \in (0,1)$ 。

4.2.2 无监督增量学习阶段

目前大多数深度神经网络模型是基于给定的完整数据集及所有类别信息进行训练。而实际跨域行人重识别场景中，数据源源不断从监控摄像头中获取，随着数据的不断增加，训练好的模型无法直接处理新到来的数据。如果每接收到一个新数据就重新训练网络模型，显然代价昂贵，需要消耗大量的存储空间和计算成本，同时也无法满足实际场景下的实时性需求，是不可取的。如果仅使用新数据微调训练好的模型，那么模型权重会发生改变，也就是丧失了对旧数据的识别能力，也称为灾难性遗忘问题(Catastrophic Forgetting)。为了构建一个面向实用场景的 Re-ID 系统，灾难性遗忘问题是增量学习需要解决的重点问题。基于此目的，本章中采取基于模型参数更新的方法，使得源模型能学习新数据上训练的模型知识，同时尽可能保留其在训练过的数据上的 Re-ID 性能。图 4-1(3)中描述了基于参数更新的增量学习过程，该学习过程包含两个步骤：第一步基于无监督聚类学习在新数据集 X_{t_i} 上微调在源域上预训练的分类器模型(记为 $C_{old}(x; \theta_{old})$)，得到一个在新数据集上效果很好的新分类器，记为 $C_{new}(x; \theta_{new})$ ；第二步目标模型与新模型之间的知识传递，优化模型在目标域上模型精度，同时巩固模型在训练过的数据上的精度。

对于两个模型之间的知识传递，现有的知识蒸馏方法，直接采用两个模型对于旧数据的输出 Logits 及相应标签设计知识蒸馏损失函数。在本系统实验环境中，首先旧数据无法获取，即不能重复访问已经训练过的数据，这比较符合实际场景的信息隐私问题导致的数据不能被保存的问题。其次模型基于无监督学习优化得到，没有正确可靠的标签。以上两个问题导致了本章中模型之间的知识传递无法通过设计知识蒸馏损失函数进行，本章中基于 EWC^[37]思想进行跨域 Re-ID 场景下的模型更新，即弹性保留对旧数据有用的模型参数。对于新旧两个分类器，新分类器是基于旧分类器在无标签数据上训练得到的模型，针对新数据有较好的识别性能，而旧分类器则对旧数据有较好的识别性能。解决模型的灾难性遗忘问题关键在于如何提取旧分类器的对旧数据的知识到新分类器中，在缺乏数据标签的条件下，知识的学习与保留通过控制模型参数的变化来完成，参数的损失函数如下公式 4-11 所示。

$$\ell = \ell_{new}(\theta) + \sum_i \frac{\lambda}{2} F_i(\theta_i - \theta_{A,i}^*)^2 \quad (4-11)$$

其中, θ 表示模型的参数, F 函数用于评估每个参数对于旧数据的重要性, F 函数的定义公式如下公式 4-12。参数 λ 用于控制模型在新数据上的学习能力。

$$F = \left[\nabla \log(p(y_n | x_n, \theta_A^*)) \cdot \nabla \log(p(y_n | x_n, \theta_A^*))^T \right] \quad (4-12)$$

从公式可以看出, F 函数是模型参数对损失函数的二阶偏导。通过给定数据集及模型在数据上训练后的模型参数, 首先计算模型分类的先验概率梯度, 再对梯度求内积, 来评估每个参数的重要性程度。 F 值越大表示该参数的重要性越高。

随着数据序列的不断到来, 模型基于公式 4-11 进行模型在线更新, 由公式可以看出, 通过参数 λ 可以在一定程度上保留模型对训练过的数据 Re-ID 能力, 缓解模型灾难性遗忘问题, 同时逐步累积对于目标域场景上数据的识别能力, 增强模型在目标域场景下 Re-ID 性能。

4.3 实验及结果

本章节中, 通过在 Market-1501、DukeMTMC-reID 和 MSMT17 数据集上的大量实验, 证明了本章提出的无监督聚类 and 增量学习的跨域行人重识别方法的有效性。首先介绍实验数据集及数据预处理, 然后介绍本模型的实验参数选择及实验细节, 最后实验对比目前最先进的跨域行人重识别方法与本章方法, 并通过消融对比实验验证模型每个模块的有效性。

4.3.1 数据集及数据预处理

本章基于目前大规模的 Market-1501、DukeMTMC-reID 及 MSMT17 行人重识别数据集展开实验。其中 MSMT17 包含 4101 位行人, 由 15 个摄像头拍摄的 126441 张图像组成。不同于 Market-1501、DukeMTMC-reID 两个数据集中只包含室外的图片, MSMT17 数据集中同时包含室内与室外的图片, 有更加复杂的场景与背景, 涵盖更多的行人数量、摄像头数及行人检测框, 更加贴近于实际摄像机网络, 是目前最大规模的行人重识别数据集。实验过程中, 选择其中一个作为源域数据集, 剩下两个分别作为目标域数据集。

在本章方法中, 目标域数据需要被划分为 N 个数据序列, 持续输入到系统中进行模型更新。为了模拟现实场景下数据流形式, 对目标域数据集进行 N 次随机采样, 形成 N 个不相交的数据集, 每个数据集中包含 150 个不同身份的行人, N 个数据序列包含了目标域中所有的训练数据。

实验基于 CMC 曲线和 mAP 指标进行模型评估。

4.3.2 实验参数设置

本章提出方法中主要包含 5 个重要的参数 α , β , γ , τ , λ 。

无监督聚类学习阶段的 α , β , γ , τ 参数, 其中 α 参数用于平衡聚类的类间距离与类内距离损失对聚类影响, β 参数用于控制合并的聚类大小, γ 参数用于控制聚类合并速度, τ 参数用于控制概率分布的波峰。无监督增量学习阶段的 λ 参数, 用于平衡模型对于新旧知识的学习与保留能力。

无监督聚类学习阶段 在聚类训练中, 批量大小(Batch Size)为 16, 每个行人包含 4 张图片, 学习率(Learning Rate)初始值为 $3e-4$, 7 个迭代后, 以 0.3 衰减率衰减学习率, 14 个迭代后以 0.1 衰减率衰减学习率, Epoch 为 400, 使用动量为 0.9 的随机梯度下降(SGD)优化算法进行模型训练。 α 值设为 0.1, β 值设为 0.005, γ 值设为 0.05, τ 值设为 0.1。

无监督增量学习阶段 设定每个不相交数据集序列中有 150 位行人, λ 值设为 0.25。

后续实验均基于一块 Tesla P4 GPU 的 Ubuntu16.04 服务器进行。

4.3.3 对比实验

本节对比本章提出模型与现有最先进的无监督 Re-ID 模型在跨域行人重识别场景上的模型性能。在三个大规模行人重识别数据集上的实验结果如表 4-1 所示。

表 4-1 本章方法与 SOTA 方法的对比实验结果

Tab. 4-1 The comparison results of proposed model and SOTA models

Methods	Market-1501 $\rightarrow$ DukeMTMC-reID (M $\rightarrow$ D)			
	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
UMDL	18.5	31.4	37.6	7.3
PTGAN	27.4	-	50.7	-
SPGAN(m=2)	41.1	56.6	63.0	22.3
MMFA	45.3	59.8	66.3	24.7
ARN	60.2	73.9	79.5	33.4
ECN	63.3	-	-	40.4
EANet	67.7	-	-	48.0
SSG	73.0	80.6	83.2	53.4
ILRe-ID(Proposed)	75.1	84.6	90.3	57.2

4-1 (续表)

Methods	DukeMTMC-reID $\rightarrow$ Market-1501 (D $\rightarrow$ M)			
	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
UMDL	34.5	52.6	59.6	12.4
PTGAN	38.6	-	66.1	-
SPGAN	51.5	70.1	76.8	22.8
MMFA	56.7	75.0	81.8	27.4
ARN	70.3	80.4	86.3	39.4
ECN	75.1	87.6	91.6	43.0
EANet	78.0	-	-	51.6
SSG	80.0	90.0	92.4	58.3
ILRe-ID(Proposed)	82.5	89.7	93.4	59.1

Methods	DukeMTMC-reID $\rightarrow$ MSMT17 (D $\rightarrow$ MSMT)			
	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
PTGAN	11.8	-	27.4	3.3
ECN	25.3	36.3	42.1	10.2
SSG	32.2	-	51.2	13.3
MMT	50.1	63.9	69.2	23.3
ILRe-ID(Proposed)	46.1	66.7	70.4	23.1

Methods	Market-1501 $\rightarrow$ MSMT17 (M $\rightarrow$ MSMT)			
	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
PTGAN	10.2	-	24.4	2.9
ECN	25.3	36.3	42.1	8.5
SSG	31.6	-	49.6	13.2
MMT	49.2	63.1	68.8	23.3
ILRe-ID(Proposed)	45.5	63.7	67.4	22.1

实验结果表明本章提出方法相比之前方法均有不同程度的性能提升。在 Market-1501 $\rightarrow$ DukeMTMC-reID 和 DukeMTMC-reID $\rightarrow$ Market-1501 实验中,本章方法在 CMC Rank-1 指标上分别达到了 75.1%和 82.5%,超过目前最优方法 2.1%和 2.5%, mAp 指标上分别达到了 57.2%和 59.1%,分别超过目前最优方法 3.8%和 0.8%。在 DukeMTMC-reID $\rightarrow$ MSMT17 实验中,CMC Rank-5 超过目前最好方法 MMT 3.8%,

在 Market-1501 $\rightarrow$ MSMT17 实验中 CMC Rank-5 超过 MMT 方法 0.6%。从表中可以看出, ILRe-ID 模型在 Market-1501 和 DukeMTMC-reID 数据集上性能均超过目前 SOTA 方法, 但是针对其他数据集到 MSMT17 数据集的实验中, 虽然没有取得 SOTA 的结果, 但是相差不大, 可能原因是模型选择参数不适合 MSMT17 数据集, 可以探索更多的参数组合来测试 MSMT17 的跨域性能。下图 4-2 展示了 MSMT17 中行人图像数量分布。




图 4-2 MSMT17 中行人数量分布图

Fig.4-2 The distribution of images for per identity in MSMT17

从图中可以看出 MSMT17 中大部分行人具有 15-30 张图像, 也有部分行人具有 40 张以上的图像, 这会导致有的聚类中包含的行人数量非常多, 这样的聚类簇很容易吸引小的聚类, 从而容易影响聚类效果。因此, 聚类准则的选取对于 MSMT17 上的跨域性能有很重要的影响。

下图 4-3 分别展示了三个数据集上模型训练性能曲线图。从下图中可以看出, 整个增量学习迭代过程中模型整体性能保持持续增长, 没有出现显著的灾难性遗忘现象, 说明基于模型参数调整的方法能有效保持模型对旧数据的识别性能。




图 4-3 四组实验的训练过程图 (a) $M \rightarrow D$ (b) $D \rightarrow M$ (c) $M \rightarrow MSMT$ (d) $D \rightarrow MSMT$

Fig. 4-3 The training process of (a) $M \rightarrow D$ (b) $D \rightarrow M$ (c) $M \rightarrow MSMT$ (d) $D \rightarrow MSMT$

4.3.4 消融实验(Ablation Experiments)

基于 4.3.3 章节的模型最终结果的有效性, 本节具体分析模型中每个模块对整体性能提升的影响。

(1) Intra-class Center Loss(ℓ_{center})

在三个大规模行人重识别数据集上, 对比包含 ℓ_{center} 和不包含 ℓ_{center} 的模型, 结果如下表 4-2、4-3 和 4-4 所示。

表 4-2 D $\rightarrow$ Market-1501 数据集上 Intra-class Center Loss 对模型性能影响Tab. 4-2 The influence of intra-class Center Loss for ILRe-ID model on D $\rightarrow$ Market-1501

Loss	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
$\ell_{repelled}$	77.3	86.5	90.1	48.2
$\ell_{repelled} + \ell_{center}$	80.5	89.7	93.4	53.1

表 4-3 Market-1501 $\rightarrow$ D 数据集上 Intra-class Center Loss 对模型性能影响Tab. 4-3 The influence of intra-class Center Loss for ILRe-ID model on Market-1501 $\rightarrow$ D

Loss	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
$\ell_{repelled}$	72.2	81.7	87.9	54.6
$\ell_{repelled} + \ell_{center}$	75.1	84.6	90.3	57.2

表 4-4 D $\rightarrow$ MSMT17 数据集上 Intra-class Center Loss 对模型性能影响Tab. 4-4 The influence of intra-class Center Loss for ILRe-ID model on D $\rightarrow$ MSMT17

Loss	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
$\ell_{repelled}$	44.5	63.1	68.3	21.2
$\ell_{repelled} + \ell_{center}$	46.1	66.7	70.4	23.1

通过引入 ℓ_{center} 在三个数据集上都取得了相应的性能提升。其中, 包含 ℓ_{center} 的模型在 Market-1501 数据集上 CMC Rank-1 指标上涨了 3.2%, 在 DukeMMC-reID 数据集上 CMC Rank-1 上涨了 2.9%, 在 MSMT17 数据集上 CMC Rank-1 指标上涨了 1.6%。从公式 4-4 可以看出, ℓ_{center} 通过最小化聚类元素与聚类中心的距离, 将聚类中元素尽可能的拉向聚类中心, 即最小化类内距离, 最大化类内相似度。这使得模型的提取特征更加具有类判别性, 从而提升模型在目标域上识别效果。

(2) 聚类准则

在三个数据集上分别测试三种聚类准则对模型性能影响, 如下表 4-5, 4-6, 4-7 所示。

由表 4-5 和表 4-6 中实验结果可以看出, 在 Market-1501 和 DukeMTMC-reID 上使用最小距离准则模型性能相比另两中距离准则会有 3%-4% 的 mAP 性能提升。因为这两个数据集中每位行人的图片数量差异不大, 不容易出现某个聚类中包含大量样本的极端情况。

表 4-5 D → Market-1501 上不同聚类准则对模型性能影响

Tab. 4-5 The influence of different clustering criterion for ILRe-ID on D → Market-1501

Clustering Criterion	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
最大距离准则	71.8	82.1	88.3	46.8
中心距离准则	74.2	84.3	89.1	50.3
最小距离准则	77.9	85.5	90.3	53.9

表 4-6 Market-1501 → D 上不同聚类准则对模型性能影响

Tab. 4-6 The influence of different clustering criterion for ILRe-ID on Market-1501 → D

Clustering Criterion	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
最大距离准则	71.4	79.5	83.3	50.8
中心距离准则	72.2	82.3	87.1	52.3
最小距离准则	75.1	84.6	90.3	55.2

表 4-7 D → MSMT17 上不同聚类准则对模型性能影响

Tab. 4-7 The influence of different clustering criterion for ILRe-ID on D → MSMT17

Clustering Criterion	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)
最大距离准则	47.1	67.1	74.8	26.9
中心距离准则	46.3	66.3	72.1	24.3
最小距离准则	46.1	66.7	70.4	23.1

由表 4-7 中实验结果可以看出, MSMT17 数据集上使用最小距离准则模型性效果最差, 这是由于 MSMT17 数据集中行人数量分布的悬殊造成的, 由图 4-2 可以看出, 存在部分行人的聚类样本数达到 60-100, 使用最小距离准则会对包含大量样本的聚类簇产生倾向, 从而影响 Re-ID 效果。而使用最大距离准则能稍微减轻聚类大小带来的影响, 因此模型性能表现最好。

4.4 总结

在本章节中, 针对实际跨域行人重识别场景数据缺乏标签和模型缺乏学习能力的问题, 设计了一个基于无监督聚类和增量学习的行人重识别模型。通过无监督聚类学习优化预训练模型在目标域数据上的特征提取, 基于聚类损失函数最小化

原则使其更具类判别性。然后通过无监督增量学习基于模型参数更新公式 4-11 更新模型，利用目标域数据序列更新行人重识别模型，逐渐实现目标域的模型域适应。实验表明该模型性能在各个数据集上均有不同的性能提升。该模型是针对实际场景问题设计，从数据序列设计到模型在线更新，都符合实用场景需求，可以更容易的部署到实际应用中。

5 结论与展望

本章内容首先总结本文所提模型及方法，然后总结模型现有问题及实际跨域行人重识别场景面临的挑战，最后给出跨域行人重识别领域的研究展望。

5.1 结论

本文针对实际跨域行人重识别应用场景，提出了两种行人重识别模型。

首先是针对源域数据集场景提出一种新的特征融合模型 EMFF 来解决多尺度特征有效融合的问题。源域数据上的行人重识别过程可以视为单域行人重识别，单域行人重识别模型的训练主要有度量学习和表征学习，这两种方式均使用到模型提取出的行人特征，因此模型性能主要取决于特征提取，模型提取的特征越鲁棒、越具有判别性，则对应模型性能越好。结合网络中多尺度的特征可以提取到更具判别性的行人特征，但是也容易引入噪声。EMFF 基于放大不同尺度特征的一致性，弱化不同尺度特征的冲突性的原则出发，得到特征间的有效融合。在大规模数据集 Market-1501 和 DukeMTMC-reID 上的大量实验结果表明，EMFF 模型的特征融合方法相比其他特征融合方式更加高效，且模型在跨域场景下的直接迁移效果有了非常大的性能增长，说明 EMFF 模型泛化能力也有很大提升。

然后，针对目标域数据集场景设计了一个基于无监督聚类学习和增量学习的行人重识别模型 ILRe-ID。基于 EMFF 模型在跨域场景下直接进行模型迁移的良好表现，将 EMFF 模型作为 ILRe-ID 模型的特征提取器，用于提取行人特征。针对实际目标域数据集的数据无标签问题，基于无监督聚类学习进行伪标签学习，充分利用无标签数据用于特征提取器的优化。聚类损失函数采用 Repelled Loss 来约束尽可能大的类间差异性，同时采用 Center Loss 来约束尽可能大的类内相似性。在此聚类损失函数基础上训练的模型将提取到更具有类判别性的行人特征。最后基于无监督增量学习进行模型域适应，模拟实际场景中数据收集方式，设计 N 个训练集序列，依次训练 N 个分类器，基于模型参数更新公式进行模型在线更新得到最终模型。在 Market-1501、DukeMTMC-reID 和 MSMT17 数据集上进行了充分的实验，结果表明，在增量学习过程中，随着知识的累积，模型在目标域数据集上的性能越来越好，最终模型性能相比目前最先进方法也有了一定的提升。

5.2 展望

本文中无监督学习方法在一定程度上能有效提高跨域行人重识别精度，但是相比目标域上的有监督学习方法，性能仍有很大提升空间。根据现有模型中存在的问题，总结如下：

(1) 多尺度特征

本文中利用全局特征构建金字塔模型，由于行人检测框不够精确，很多行人图片存在遮挡、背景占比大的问题，在这些极端情况下，模型可能会更偏于提取背景或遮挡物区域特征，导致模型提取的融合特征对于行人分类产生负影响。在这些情况下，考虑加入行人特征对齐模块，使得模型关注区域为行人身体，保证模型提取的特征有助于行人重识别任务。

(2) 聚类准则

在本文第四章中关于聚类合并准则实验部分，在 MSMT17 数据集上三种距离准则没有特别突出的性能表现，主要原因在与 MSMT17 数据集中图片比较复杂，非常接近真实场景，存在很多相似外貌的不同行人和跨摄像机下外貌差异巨大的行人，在这种复杂场景下，使用现有的距离准则并不能得到很好的聚类效果，而聚类效果会直接影响模型性能。应该针对具体场景重新探索更合理更高效的合并准则。

(3) 模型在线更新

为了适应实际场景下数据在线收集方式，跨域行人重识别模型需要能够实现模型在线更新，由于目标域数据集缺乏标签信息，无法设计合适的有监督损失函数，而基于模型参数更新的方式对新知识的学习与旧知识的保留都不够友好，存在很多改进空间。考虑针对无监督场景下的模型蒸馏问题进行探索，设计更优的模型蒸馏方案。可以参考目标检测领域无监督知识蒸馏方法。

参考文献

- [1] Zheng L, et al. Person Re-Identification: Past, Present and Future[J].// arXiv preprint, 2016, ArXiv:1610.02984.
- [2] Tao D P, et al. Person Re-Identification by Regularized Smoothing KISS Metric Learning[C].// IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), vol. 23, no. 10, 2013, pp. 1675–1685.
- [3] Xiao T, et al. Learning Deep Feature Representations with Domain Guided Dropout for Person Re-Identification[C].// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 1249–1258.
- [4] Jin H B, et al. Deep Person Re-Identification with Improved Embedding and Efficient Training[C].// 2017 IEEE International Joint Conference on Biometrics (IJCB), 2017, pp. 261–267.
- [5] Zhong Z, et al. Re-Ranking Person Re-Identification with k-Reciprocal Encoding[C].// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 3652–3661.
- [6] Lin Y T, et al. Improving Person Re-Identification by Attribute and Identity Learning[J].// Pattern Recognition, vol. 95, 2019, pp. 151–161.
- [7] Sun Y F, et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and A Strong Convolutional Baseline) [C].// Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 501–518.
- [8] Zhao H, et al. Spindle Net: Person Re-Identification with Human Body Region Guided Feature Decomposition and Fusion[C].// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 907–915.
- [9] Zheng L, et al. Pose-Invariant Embedding for Deep Person Re-Identification[C].// IEEE Transactions on Image Processing (IEEE TIP), vol. 28, no. 9, 2019, pp. 4500–4509.
- [10] Su C, et al. Pose-Driven Deep Convolutional Model for Person Re-Identification[C].// 2017 IEEE International Conference on Computer Vision (ICCV), 2017, pp. 3980–3989.
- [11] Zhao L, et al. Deeply-Learned Part-Aligned Representations for Person Re-Identification[C].// 2017 IEEE International Conference on Computer Vision (ICCV), 2017, pp. 3239–3248.
- [12] Xu J, et al. Attention-Aware Compositional Network for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 2119–2128.
- [13] Quan H, et al. Improving Person Re-Identification via Attribute-Identity Representation and Visual Attention Mechanism[J].// Multimedia Tools and Applications, vol. 79, 2020, pp. 7259–7278.
- [14] Fan H, et al. Unsupervised Person Re-Identification: Clustering and Fine-Tuning[J].// ACM Transactions on Multimedia Computing, Communications, and Applications, vol. 14, no. 4, 2018, p. 83.
- [15] Lin Y, et al. A Bottom-Up Clustering Approach to Unsupervised Person Re-Identification[C].// AAAI 2019 : Thirty-Third AAAI Conference on Artificial Intelligence (AAAI), vol. 33, no. 1,

- 2019, pp. 8738–8745.
- [16] Zhang D, et al. Unsupervised Metric Learning for Person Re-Identification by Image Re-Ranking[J].// International Journal of Computational Science and Engineering, vol. 17, no. 2, 2018, pp. 159–169.
- [17] Li M, et al. Unsupervised Person Re-Identification by Deep Learning Tracklet Association[C].// Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 772–788.
- [18] Yu H, et al. Cross-View Asymmetric Metric Learning for Unsupervised Person Re-Identification[C].// 2017 IEEE International Conference on Computer Vision (ICCV), 2017, pp. 994–1002.
- [19] Zhu J, et al. Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks[C].// 2017 IEEE International Conference on Computer Vision (ICCV), 2017, pp. 2242–2251.
- [20] Zhong Z, et al. Camera Style Adaptation for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 5157–5166.
- [21] Wei L, et al. Person Transfer GAN to Bridge Domain Gap for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 79–88.
- [22] Zhong Z, et al. Generalizing a Person Retrieval Model Hetero- and Homogeneously[C].// Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 176–192.
- [23] Zhong Z, et al. Invariance Matters: Exemplar Memory for Domain Adaptive Person Re-Identification[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 598–607.
- [24] Choi Y, et al. StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 8789–8797.
- [25] Huang Y, et al. SBSGAN: Suppression of Inter-Domain Background Shift for Person Re-Identification[C].// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 9526–9535.
- [26] Qian X, et al. Pose-Normalized Image Generation for Person Re-Identification[C].// Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 661–678.
- [27] Deng W, et al. Image-Image Domain Adaptation with Preserved Self-Similarity and Domain-Dissimilarity for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 994–1003.
- [28] Li Y, et al. Cross-Dataset Person Re-Identification via Unsupervised Pose Disentanglement and Adaptation[C].// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 7918–7928.
- [29] Lv J M, et al. Unsupervised Cross-Dataset Person Re-Identification by Transfer Learning of Spatial-Temporal Patterns[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 7948–7956.
- [30] Fu Y, et al. Self-Similarity Grouping: A Simple Unsupervised Cross Domain Adaptation Approach for Person Re-Identification[C].// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 6111–6120.

- [31] Ge Y, et al. Mutual Mean-Teaching: Pseudo Label Refinery for Unsupervised Domain Adaptation on Person Re-Identification[C].// ICLR 2020 : Eighth International Conference on Learning Representations (ICLR), 2020.
- [32] He K M, et al. Deep Residual Learning for Image Recognition[C].// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.
- [33] Lin T S, et al. Feature Pyramid Networks for Object Detection[C].// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 936–944.
- [34] Deng J, et al. ImageNet: A Large-Scale Hierarchical Image Database[C].// 2009 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2009, pp. 248–255.
- [35] Zheng L, et al. Scalable Person Re-Identification: A Benchmark[C].// 2015 IEEE International Conference on Computer Vision (ICCV), 2015, pp. 1116–1124.
- [36] Xiao Q Q, et al. Margin Sample Mining Loss: A Deep Learning Based Method for Person Re-Identification[J].// arXiv preprint, 2017, ArXiv:1710.00478.
- [37] Kirkpatrick J, et al. Overcoming Catastrophic Forgetting in Neural Networks[J].// Proceedings of the National Academy of Sciences of the United States of America, vol. 114, no. 13, 2017, pp. 3521–3526.
- [38] Li Z Z. “Learning without Forgetting[C].// European Conference on Computer Vision (ECCV), vol. 40, no. 12, 2018, pp. 614–629.
- [39] Rebuffi S, et al. ICaRL: Incremental Classifier and Representation Learning[C].// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), vol. 2017, 2017, pp. 5533–5542.
- [40] Wu Y, et al. Large Scale Incremental Learning[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 374–382.
- [41] Chen H R, et al. Deep Transfer Learning for Person Re-Identification[C].// 2018 IEEE Fourth International Conference on Multimedia Big Data (BigMM), 2018, pp. 1–5.
- [42] Wang G S, et al. Learning Discriminative Features with Multiple Granularities for Person Re-Identification[C].// Proceedings of the 26th ACM International Conference on Multimedia, 2018, pp. 274–282.
- [43] Fu Y, et al. Horizontal Pyramid Matching for Person Re-Identification[C].// AAAI 2019 : Thirty-Third AAAI Conference on Artificial Intelligence (AAAI), vol. 33, no. 1, 2019, pp. 8295–8302.
- [44] Mao C J, et al. Multi-Channel Pyramid Person Matching Network for Person Re-Identification[C].// AAAI 2018: Thirty-Second AAAI Conference on Artificial Intelligence (AAAI), 2018, pp. 7243–7250.
- [45] Mao C J, et al. Pyramid Person Matching Network for Person Re-Identification[C].// Asian Conference on Machine Learning (ACML), 2017, pp. 487–497.
- [46] Zheng F, et al. Pyramidal Person Re-identification via Multi-Loss Dynamic Training[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 8514–8522.
- [47] Zhong W L, et al. “Discriminative Representation Learning for Person Re-Identification via Multi-Loss Training[J].// Journal of Visual Communication and Image Representation, vol. 62, 2019, pp. 267–278.
- [48] Yang Q Z, et al. Patch-Based Discriminative Feature Learning for Unsupervised Person Re-

- Identification[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 3633–3642.
- [49] Sun Y F, et al. Perceive Where to Focus: Learning Visibility-Aware Part-Level Features for Partial Person Re-Identification[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 393–402.
- [50] Chen Y B, et al. Person Re-Identification by Deep Learning Multi-Scale Representations[C].// 2017 IEEE International Conference on Computer Vision Workshops (ICCVW), 2017, pp. 2590–2600.
- [51] Qian X L, et al. Multi-Scale Deep Learning Architectures for Person Re-Identification[C].// 2017 IEEE International Conference on Computer Vision (ICCV), 2017, pp. 5409–5418.
- [52] Li D W, et al. Learning Deep Context-Aware Features over Body and Latent Parts for Person Re-Identification[C].// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 7398–7407.
- [53] Wang Y, et al. Resource Aware Person Re-Identification Across Multiple Resolutions[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 8042–8051.
- [54] Li W, et al. Harmonious Attention Network for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 2285–2294.
- [55] Si J L, et al. Dual Attention Matching Network for Context-Aware Feature Sequence Based Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 5363–5372.
- [56] Quan R J, et al. Auto-ReID: Searching for a Part-Aware ConvNet for Person Re-Identification[C].// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 3749–3758.
- [57] Zhu Y X, et al. Multi-Branch Context-Aware Network for Person Re-Identification[C].// 2019 IEEE International Conference on Multimedia and Expo (ICME), 2019, pp. 712–717.
- [58] Guo Y L, et al. Efficient and Deep Person Re-Identification Using Multi-Level Similarity[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 2335–2344.
- [59] Zeng M Y, et al. Person Re-Identification with Hierarchical Deep Learning Feature and Efficient XQDA Metric[C].// Proceedings of the 26th ACM International Conference on Multimedia (ACM MM), 2018, pp. 1838–1846.
- [60] Chang X B, et al. Multi-Level Factorisation Net for Person Re-Identification[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 2109–2118.
- [61] Luo H, et al. Bag of Tricks and a Strong Baseline for Deep Person Re-Identification[C].// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2019, pp. 0–0.
- [62] Luo H, et al. A Strong Baseline and Batch Normalization Neck for Deep Person Re-Identification[C].// IEEE Transactions on Multimedia (IEEE T MM), 2019, pp. 1–1.
- [63] Huang H J, et al. EANet: Enhancing Alignment for Cross-Domain Person Re-identification[J].// arXiv preprint, 2018, ArXiv:1812.11369.

- [64] Liu H J, et al. Attention: A Big Surprise for Cross-Domain Person Re-identification[J].// arXiv preprint, 2019, ArXiv:1905.12830.
- [65] Zhang X, et al. AlignedReID: Surpassing Human-Level Performance in Person Re-Identification[J].// arXiv preprint, 2017, ArXiv:1711.08184.
- [66] Luo H, et al. AlignedReID++: Dynamically Matching Local Information for Person Re-Identification[J].// Pattern Recognition, vol. 94, 2019, pp. 53–61.
- [67] Jiang B, et al. Person Re-Identification with Patch-Based Local Sparse Matching and Metric Learning[C].// International Conference on Image and Graphics (ICIG), 2019, pp. 143–154.
- [68] Wei L H, et al. “GLAD: Global–Local–Alignment Descriptor for Scalable Person Re-Identification.” IEEE Transactions on Multimedia (IEEE TMM), vol. 21, no. 4, 2019, pp. 986–999.
- [69] Sarfraz M, et al. A Pose-Sensitive Embedding for Person Re-Identification with Expanded Cross Neighborhood Re-Ranking[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 420–429.
- [70] Zhang X Y, et al. Self-Training With Progressive Augmentation for Unsupervised Cross-Domain Person Re-Identification[C].// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 8221–8230.
- [71] Bhargava P. Incremental Learning in Person Re-Identification[J].// arXiv preprint, 2018, ArXiv:1808.06281.
- [72] Zhang Y Y, et al. Learning Incremental Triplet Margin for Person Re-Identification[C].// AAAI 2019 : Thirty-Third AAAI Conference on Artificial Intelligence (AAAI), vol. 33, no. 1, 2019, pp. 9243–9250.

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：丁伟玮

签字日期：2020年6月14日

学位论文数据集

表 1.1: 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
行人重识别	公开			
学位授予单位名称*	学位授予单位代码*		学位类别*	学位级别*
北京交通大学	10004		硕士	硕士学位
论文题名*	并列题名			论文语种*
基于多尺度特征的无监督跨域行人识别研究				中文
作者姓名*	丁玮玮		学号*	17120355
培养单位名称*	培养单位代码*		培养单位地址	邮编
北京交通大学	10004		北京市海淀区西直门外上园村 3 号	100044
学科专业*	研究方向*		学制*	学位授予年*
计算机科学与技术	计算机视觉		3 年	2020 年
论文提交日期*	2020 年 6 月			
导师姓名*	徐保民		职称*	教授
评阅人	答辩委员会主席*		答辩委员会成员	
	孙永奇		熊轲 任爽	
电子版论文提交格式 文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 () 推荐格式: application/msword; application/pdf				
电子版论文出版 (发布) 者		电子版论文出版 (发布) 地		权限声明
论文总页数*	60			
共 33 项, 其中带*为必填数据, 为 21 项。				