



华南理工大学  
South China University of Technology

# 硕士学位论文

基于特征学习的行人重识别研究

---

|        |            |
|--------|------------|
| 作者姓名   | 邱隆庆        |
| 学科专业   | 计算机科学与技术   |
| 指导教师   | 张见威 副教授    |
| 所在学院   | 计算机科学与工程   |
| 论文提交日期 | 2017年4月28日 |

# **Research on Person Re-identification Based on Feature Learning**

A Dissertation Submitted for the Degree of Master

**Candidate: Qiu Longqing**

**Supervisor: Associate Prof. Zhang Jianwei**

South China University of Technology  
Guangzhou, China

分类号：TP391

学校代号：10561

学 号：201420113022

## 华南理工大学硕士学位论文

# 基于特征学习的行人重识别研究

作者姓名：邱隆庆

指导教师姓名、职称：张见威副教授

申请学位级别：硕士

学科专业名称：计算机科学与技术

研究方向：多媒体技术与图形图像处理

论文提交日期：2017年4月28日

论文答辩日期：2017年6月5日

学位授予单位：华南理工大学

学位授予日期： 年 月 日

答辩委员会成员：

主席： 韩国强

委员： 蔡宏民，沃焱，陈琼，张见威



## 摘要

行人重识别是指匹配在无重叠视域的摄像机中出现的同一个行人图像的过程。近年来与行人重识别相关的论文高速增长，该技术已成为智能视频监控系统的重要分支。行人重识目前面临着光照、姿态、视角等变化面临的挑战。目前行人重识别的相关研究有从手工提取特征到自动学习特征，从基于图片的重识别到基于视频的重识别，从封闭重识别到开放重识别的趋势。

行人重识别基本步骤分为特征提取和距离度量两个基本步骤。本文设计了一个用于提取特征的深度网络 FT-FFN (Fine-tuning Feature Fusion Network)。一方面，该网络将 CNN 特征与低层视觉特征借助全连接层融合在一起。在网络训练识别行人属性的过程中，反向传播、更新权值的过程中低层视觉特征会影响 CNN 网络部分的调整，使 CNN 特征朝与低层视觉特征互补的方向变化。另一方面，在借助训练其识别行人属性的微调过程中，网络融合层输出特征的区分能力得到了很大增强，最终使网络输出的融合层特征具有优良的区分能力。此外，FT-FFN 的输出层能产生行人的语义属性，本文讨论语义属性的特征的种类、频率和区别能力，改进了一种中层属性权重的优化方法，并将属性特征与融合层特征结合用于行人重识别。

本文在 PETA 数据集上进行了中层语义属性的实验和测试，在 VIPeR、PRID 450s 和 CUHK01 数据集上进行了行人重识别的实验设计和测试，结果表明 FT-FFN 对中层语义属性的判断较为准确，FT-FFN 产生的融合特征具有良好的区分能力。

**关键词：**行人重识别；特征提取；FT-FFN； 中层属性；

## Abstract

Person re-identification refers to the process of matching the same pedestrian image that appears in cameras without overlapping horizons. In recent years, the paper related to person Re-identification has been growing rapidly. This technology has become an important branch of intelligent video surveillance system. Person re-identification is currently facing challenges such as light, gesture, perspective and other changes. At present, the related research of person re-identification has the tendency of extracting features from manual to automatic learning, from image-based re-identification to video-based re-identification, from closed re-identification to open re-identification.

The basic steps of person Re-identification are divided into two basic steps: feature extraction and metric learning. This paper designs a deep network FT-FFN (Fine-tuning Feature Fusion Network) for extracting features. On one hand, the network fuses CNN features with low-level visual features by means of a fully connected layer. In the process of identifying the pedestrian attribute in the process of network training, the low-level visual feature in the process of back-propagation and updating the weight will affect the adjustment of the CNN network part, so that the CNN feature changes in the direction complementary to the low-level visual feature. On the other hand, in the process of fine-tuning with the identification of pedestrian attributes, the distinguishing ability of network fusion layer output feature is greatly enhanced, and finally the fusion layer feature of network output has excellent distinguishing ability. In addition, the output layer of FT-FFN generates the semantic attributes of pedestrians. In this paper, we discuss the types, frequencies and distinguishing abilities of semantic attributes, improve the optimization method of middle attribute weight, and combine attribute feature with fusion layer in the person re-identification.

In this paper, the experiment and test of the semantic attribute of the middle layer are carried out on the PETA dataset. The experiment design and test of the VIPeR, PRID 450s and CUHK01 datasets are carried out. The results show that the FT-FFN is more accurate in the semantic attribute, FT-FFN fusion feature is discriminative.

**Keywords:** Person Re-identification, Feature extraction, FT-FFN, Middle-level attribute

# 目录

|                             |    |
|-----------------------------|----|
| 摘要.....                     | I  |
| ABSTRACT.....               | II |
| 第一章 绪论 .....                | 1  |
| 1.1 课题研究背景和意义 .....         | 1  |
| 1.1.1 视频监控系统的發展及智能化趋势 ..... | 1  |
| 1.1.2 行人重识别课题的提出和意义 .....   | 2  |
| 1.2 行人重识别的国内外研究现状 .....     | 3  |
| 1.2.1 行人重识别研究简史 .....       | 3  |
| 1.2.2 特征提取 .....            | 4  |
| 1.2.3 度量学习 .....            | 5  |
| 1.2.4 基于深度学习的行人重识别技术 .....  | 5  |
| 1.2.5 基于语义属性的行人重识别技术 .....  | 6  |
| 1.3 面临的问题及挑战 .....          | 6  |
| 1.4 本文的主要工作 .....           | 7  |
| 1.5 本文的章节安排 .....           | 7  |
| 第二章 行人重识别相关技术 .....         | 9  |
| 2.1 特征提取 .....              | 9  |
| 2.1.1 颜色特征 .....            | 9  |
| 2.1.2 纹理特征 .....            | 11 |
| 2.1.3 属性特征 .....            | 12 |
| 2.1.4 几种常用描述子 .....         | 12 |
| 2.2 距离度量学习 .....            | 14 |
| 2.2.1 马氏距离 .....            | 14 |
| 2.2.2 LMNN .....            | 14 |
| 2.2.3 KISSME .....          | 15 |
| 2.2.4 XQDA .....            | 15 |
| 2.3 卷积神经网络 .....            | 16 |
| 2.3.1 卷积层 .....             | 17 |
| 2.3.2 池化层 .....             | 18 |

|       |                           |    |
|-------|---------------------------|----|
| 2.3.3 | 激活函数 .....                | 18 |
| 2.3.4 | 全连接层 .....                | 19 |
| 2.3.5 | Softmax 回归 .....          | 19 |
| 2.3.6 | 反向传播算法 .....              | 21 |
| 2.4   | 本章小结 .....                | 21 |
| 第三章   | 基于深度特征的行人重识别 .....        | 22 |
| 3.1   | 引言 .....                  | 22 |
| 3.2   | FT-FFN 网络的灵感来源 .....      | 22 |
| 3.3   | FT-FFN 的网络结构 .....        | 23 |
| 3.3.1 | 网络概述 .....                | 23 |
| 3.3.2 | ImageNet 部分 .....         | 24 |
| 3.3.3 | 低层视觉特征部分 .....            | 27 |
| 3.3.4 | 融合层 .....                 | 27 |
| 3.4   | 与 FNN 和 FT-CNN 的比较 .....  | 27 |
| 3.5   | FT-FNN 网络的配置和训练 .....     | 28 |
| 3.5.1 | 在 ImageNet 上的预训练 .....    | 28 |
| 3.5.2 | 在 RAP 和 PETA 上的训练策略 ..... | 28 |
| 3.6   | 本章小结 .....                | 29 |
| 第四章   | 基于中层语义属性的行人重识别 .....      | 30 |
| 4.1   | 中层属性种类 .....              | 30 |
| 4.2   | 中层语义属性分析 .....            | 31 |
| 4.3   | 中层语义属性识别 .....            | 33 |
| 4.4   | 中层属性的优化 .....             | 34 |
| 4.5   | 语义属性与低层特征的融合 .....        | 35 |
| 4.6   | 本章小结 .....                | 35 |
| 第五章   | 实验结果与分析 .....             | 36 |
| 5.1   | 数据集及评价方法 .....            | 36 |
| 5.1.1 | PETA 数据集 .....            | 36 |
| 5.1.2 | RAP 数据集 .....             | 37 |
| 5.1.3 | VIPeR .....               | 38 |



|                        |                    |    |
|------------------------|--------------------|----|
| 5.1.4                  | CUHK01.....        | 39 |
| 5.1.5                  | PRID 450S 数据集..... | 39 |
| 5.1.6                  | 评价方法.....          | 40 |
| 5.2                    | 实验结果与分析 .....      | 41 |
| 5.2.1                  | 中层属性识别实验结果.....    | 41 |
| 5.2.2                  | 行人重识别实验结果与分析.....  | 43 |
| 5.3                    | 本章小结 .....         | 48 |
| 总结与展望.....             |                    | 49 |
| 工作总结.....              |                    | 49 |
| 工作展望.....              |                    | 49 |
| 参考文献.....              |                    | 51 |
| 读博士/硕士学位期间取得的研究成果..... |                    | 54 |
| 致谢.....                |                    | 55 |

# 第一章 绪论

## 1.1 课题研究背景和意义

### 1.1.1 视频监控系统的发展及智能化趋势

近二三十年来,视频监控技术走过了数个发展阶段,随着宽带网络的普及,视频监控进入到网络化多媒体监控系统阶段。随着以“平安城市”、“平安校园”为代表的一系列安防项目启动实施,视频监控系统逐渐在公安、城管、交通、商业监控等应用领域普及。在公安领域,视频监控系统应用广泛:对突发事件如打架、抢夺等行为进行记录,用于取证;震慑犯罪分子,有效预防犯罪;提高应急指挥能力;增强群众的安全感。2017年广州市公安局用于“市公安局社会治安视频监控系统建设”项目的预算将近一亿元,将用于开展智能化视频系统改造与智能化应用平台建设等。<sup>[1]</sup> 在商业领域,为避免超市失窃,商超纷纷安装视频监控系统,有些大型超市视频监控路数达到数百上千路。在家用领域百度、小米、360、联想等互联网和电子企业纷纷发布智能摄像头,推出家庭用视频监控产品,主打家庭远程监控功能。视频监控系统也进入到许多家庭和小区以保护房屋财产安全,减少破坏公物行为和入室抢劫这类常见犯罪行为。

根据中国安防产业协会制定的《中国安防行业“十三五”(2016-2020年)发展规划》,安防企业年总收入由2010年的2350亿元增加到2015年的4900亿元左右,增长了一倍以上,年均增长15.8%;安防行业年增加值由2010年的850亿元增加到2015年的1600亿元,年均增长13.5%;到2020年,安防企业总收入达到8000亿元左右,年增长率达到10%以上,实现行业增加值2500亿元。如今摄像探头遍布于大街小巷、机场车站、公共交通工具、商场写字楼,甚至深入到许多家庭中。

当前,视频监控系统目前朝着智能化的方向发展,最新人工智能技术逐步渗透到智能视频监控中去。在公共安全领域,智能人脸识别被用于辅助破案。通过将现场拍摄的图像上传到后台并分析,可实现重点人员事实监控,分析嫌疑人的行动轨迹。智能车牌识别被用于根据车辆和人员布控堵截。通过前端设备采集车辆牌照信息实时与布控信息进行对比,进行自动报警,对嫌疑人行动轨迹进行智能监控,迅速锁定嫌疑人行动路线。在商业领域,除了传统的安全防范,智能摄像头商业化的探索也在进行。如线下传统零售的人流量监控,有助于企业发现视频数据背后的客户活动规律,对于支持未来的业务决策有着积极作用。在家用领域,360智能摄像头提供了监视家中物品移动情况的


功能，若物品有移动则会向手机发送警告

在这个背景下，智能化监控技术与计算机视觉技术快速发展，在许多方面取得了进展。智能视频监控的主要课题是原始的图像和视频中提取包括近于人类的语义理解，按层次由低到高可以分为底层的目标检测，包括目标建模、背景建模、目标跟踪，如人和车辆的多目标检测、夜间目标跟踪等；中层的目标识别，包括目标分类和个体识别，如物体分类、飞行器识别、生物识别等；高层的行为分析，包括姿态识别、行为识别、人体异常动作识别报警、车辆计数与报警等等。

### 1.1.2 行人重识别课题的提出和意义

行人重识别（Person Re-identification），又被译为行人再识别、行人再标志，是指对已经观测到的行人，识别和关联该行人此后在不同摄像机下拍摄到的所有图片的过程。行人重识别是对行人进行多摄像头跟踪的一个前置条件，在行人重识别（Person Re-identification）这个概念提出之前，相关的研究和多目追踪紧紧地联系在一起<sup>[2]</sup>。Wojciech Zajdel 等<sup>[3]</sup>提出了行人重识别这个课题，旨在解决识别一个离开了视野中随后又重新进入的人。Zajdel 把问题分解成两个子问题：局部追踪和全局追踪，在全局追踪中同一个动态贝叶斯网络解决人的重识别问题。

典型的行人重识别系统包括三个阶段：特征提取（Feature Extraction）、度量学习（Metric Learning）和识别分类（Classification），如图 1-1 所示。特征提取将图片从原始像素转变为特征向量的过程；行人重识别中的度量学习一般是在有监督的条件下，学习一个度量两个特征向量相似程度的统计模型。在识别分类阶段，之前在摄像头前出现过、并被检测识别到的行人图片集合称为行人库（Gallery images），而新检测到待识别匹配的行人图片称为待识别图像（probe image）。识别分类阶段的任务，就是对每一待识别图像，逐个比对行人库中的图像，根据度量学习阶段学到模型，逐个计算待识别图像与行人库各行人图像的相似程度，并将结果按由近到远排列。现在行人重识别的研究一般假定待识别图像在行人库中一定存在匹配的图片，这类问题被称为封闭重识别问题（Closed-world Re-identification），若这一假设不成立，即待识别图像可能没有在行人库中出现，这类问题称为开放重识别（Open-world Re-identification）。

图 1-1 行人重识别系统的三个阶段<sup>[4]</sup>

行人重识别技术目前直接应用领域主要是的在线的行人监控和跟踪，和线下的行人检索。将特点人员划定为感兴趣人物后，利用行人重识别技术可以在其出现在其他摄像机视野内时标记出来，得到其实时运动轨迹；也可以在历史视频资料中检索该人物，得到其历史轨迹。此外行人重识别技术还是许多行人目标跟踪、行为分析等课题的基础。

## 1.2 行人重识别的国内外研究现状

### 1.2.1 行人重识别研究简史

(1) 研究开端。对行人重识别课题的研究起始于多摄像头跟踪。在早期行人重识别这一课题没有被正式提出的时期，多摄像头跟踪往往集中在结合了外观模型的多摄像机几何校准。2005 年，Wojciech Zajdel 等<sup>[3]</sup>提出了行人重识别这个课题，尝试解决识别一个离开了视野中随后又重新进入的人。Zajdel 把问题分解成两个子问题：局部追踪和全局追踪，在全局追踪中用一个动态贝叶斯网络解决人的重识别问题。

(2) 行人重识别问题的独立。2006 年 Gheissari 等<sup>[5]</sup>提出一种利用个体的整体外观而非人脸、步态等生物特征来进行重识别的算法，这一工作标志着行人重识别（Person Re-identification）正式成为独立的计算机视觉任务<sup>[2]</sup>。Gheissari 认为行人重识别包含两个方面：一是建立身体部分之间的联系，二是产生不随光照、姿势、衣着变化的签名。文中提出了一个新颖的时空分割算法，该方法对人的衣着外观的变化足够鲁棒。

(3) 从基于图片的重识别到基于视频的重识别。尽管图像取自监控视频，早期的行人重识别的特征设计或匹配算法仅仅对每个任务的单帧图像进行，并没有用到视频信息。2010 年，Bazzani 等<sup>[6]</sup>的直方图累加摘要（Histogram Plus Epitome, HPE）第一次利用到视频信息。HPE 是由多帧图像融合而成的高信息融合而成的签名。HPE 融合了人物外观的全局和局部统计描述，在对 HPE 计算距离时使用了巴氏距离，对低分辨率、遮挡、姿势和光照变化表现良好。这项工作显示对行人使用多帧图像相对于单帧能显著地改善结

果，但随着帧数的增加准确率会逐渐饱和。

(4) 从低层特征到中层属性。2012 年, Ryan Layne 等<sup>[7]</sup>从发现人类在观察监控视频时往往根据人物的衣着、是否背包等特征来筛选匹配行人, 据此将行人的年龄、穿戴等中层语义属性引入到行人重识别课题中。因为中层属性往往具有良好的光照、姿势不变性, 实验结果表现良好。Ryan Layne 等<sup>[7]</sup>的工作提供了行人重识别研究的一个新方向。

(5) 深度学习的引入。随着深度学习在计算机视觉的其他领域获得巨大成功, 2014 年深度学习被引入到行人重识别研究中。Dong Yi 等<sup>[8]</sup>提出了一种利用 Siamese 卷积神经网络的算法用于深度度量学习。Dong Yi 的框架将以往一般分开的特征提取和度量学习统一在了一起, Siamese 卷积神经网络的训练过程完成了颜色、纹理等特征的提取和度量。

### 1.2.2 特征提取

经典的行人重识别过程包括特征提取和度量学习两个基本步骤。特征提取从原始的像素中提取光照、视角不变的描述子, 度量学习旨在合理地度量两个描述子之间的相似程度。

早期的特征提取主要来自低层的颜色、纹理、空间结构等。Farenzena 等<sup>[9]</sup>针对基于外观的重识别, 提出了一种特征提取方法 SDALF (Symmetry-Driven Accumulation of Local Features, 对称驱动局部特征累积)。行人前景首先从背景中分割出来, 再对身体的每一个部分计算对称轴。根据身体配置计算加权颜色直方图 (Weighted color histogram, WH)、最大稳定区域 (Maximally stable color regions, MSCR)、周期高结构图块 (Recurrent high-structured patches, RHSP)。WH 中赋予离对称轴近的像素更高的权重, MSCR 检测稳定的颜色区域并提取颜色、区域、中心等特征, RHSP 则是从高频纹理图块中提取的纹理特征。Ma 等<sup>[10]</sup>提出了一种 gBiCov 描述子, 将原始彩色图片分成 HSV 三个通道后, 分别对每个通道应用不同尺度的 gabor 滤波器, 相邻尺度两两合并至同一 band 中, 相邻 band 分为小图块形成一系列协方差描述子, 在计算同一区域协方差描述子的差值, 插值合并成最终的描述子, 该描述子可以用欧氏距离计算其差值。随着深度相机的流行, Munaro 等<sup>[11]</sup>在 Kinect SDK 的基础上提出了针对深度图像的基于骨架的描述子和另一种基于身体轮廓的点云模型, 开启了 RGB-D 图像重识别先河。

近期, 基于单帧图像、人工设计的描述子依然源自颜色、纹理、空间结构等, 如 Wang 等<sup>[12]</sup>提出的多通道特征融合 (Fusion of multiple channel features, FMCF), 也是从 HSV



颜色空间的不同通道提取低层特征，同时融合空间、纹理信息，并利用重叠策略来消除图像中各小块间的对比。

### 1.2.3 度量学习

对于某些设计良好的描述子，仅使用简单的 L1 范数或 L2 范数（欧氏距离）即可得到良好的结果，如 BioCov 描述子<sup>[10]</sup>，但通常基于学习的度量方法表现更加优良，因为在样本差异存在的情况下高位视觉特征并不能捕获不变因素<sup>[2]</sup>。根据是否有监督可将度量学习方法分为监督学习方法和非监督学习方法；根据学习的范围可以分为全局学习方法和非全局学习方法。行人重识别研究中的度量学习方法通常是有监督全局度量学习。

全局度量学习方法的一般思路是减小类内差，扩大类间差。马氏距离（Mahalanobis distance）及基于马氏距离的度量方法，是最常见的距离度量方法。基于马氏距离的方法，还有 Weinberger 等<sup>[13]</sup>的大间隔近邻（Large Margin Nearest Neighbor, LMNN），M.Kostinger 等<sup>[14]</sup>基于统计推断角度简单而有效的策略来学习等价约束的距离度量，称为从简直接度量（Keep it simple and Straightforward Metric, KISSME）。

### 1.2.4 基于深度学习的行人重识别技术

基于深度学习引入到行人重识别以后，大体有以下两种形式：

（1）将特征提取、度量学习等融合在同一框架中。Dong Yi,等<sup>[8]</sup>受 Siamese 深度神经网络<sup>[15]</sup>启发，提出了深度度量学习（Deep Metric Learning, DML）。DML 将人体分为上中下三部分，对每一对图片的对应部分输入到 Siamese 卷积神经网络中，再综合三部分计算相似性。每个 Siamese 卷积神经网络由一组共享或不共享参数的卷积神经网络组成。DML 直接从图片像素学习相似度量，较人工设计的特征效率更高；DML 学习到的多通道过滤器能够同时获得颜色和纹理信息，较传统的融合方法更加合理。Ding 等<sup>[16]</sup>提出一个距离驱动特征学习框架，利用卷积神经网络自动学习行人的表示。Ding 将一系列三元组输入到网络中，三元组中两个 ID 相同的行人，网络在训练过程中逐步拉近同 ID 行人图片在特征空间的距离，拉远不同 ID 的行人。

（2）深度学习仅用于特征提取，如将卷积神经网络中的某一层输出作为 CNN 特征，再使用传统的度量学习方法计算所提取特征间的距离。Wu 等<sup>[17]</sup>将提出一种新颖的特征提取模型特征融合网络（Feature Fusion Net, FFN），并证明颜色直方图(RGB, HSV, YCbCr, Lab 和 YIQ)是卷积神经网络特征的补充，FFN 正规化了 CNN 流程，使 CNN 专

注于提取互补功能。Matsukawa 等<sup>[18]</sup>利用经行人属性微调后的 AlexNet 网络，将训练好的网络模型作用于行人图像，从第一个全连接层提取 CNN 特征，再运用 Liao 等<sup>[19]</sup>提出的度量学习方法交叉视图二次判别分析（Quadratic Discriminant Analysis, XQDA）。

### 1.2.5 基于语义属性的行人重识别技术

相对于颜色、纹理等低层特征，年龄区间、性别、衣服款式等语义属性可以视为中层的特征。与低层特征相比，中层特征对光照、姿势等图片变化有更好的稳定性。同时中性的语义属性还能应用于根据属性关键词进行检索。

Ryan Layne 等<sup>[7]</sup>最早将中层属性应用于行人重识别中，VIPer 数据集<sup>[20]</sup>中定义了长发、短发、性别、logo 等 15 种二元属性。Layne 使用低层的颜色、纹理特征来训练属性分类器，属性经过加权后在 DALF 的框架下与其他视觉特征融合。Li 等<sup>[21]</sup>利用衣着属性辅助行人重识别：首先提取身体各部分及其局部特征以缓解姿势不对齐的问题，然后通过一个基于潜支持向量机的度量学习方法描述低层身体部分特征、中层衣着属性和高层标签的关系。Li 等<sup>[21]</sup>的工作表明身体部分特征比整个行人框的特征有效，衣着属性能有效提高效果，将衣着属性设置为连续值的效果要好于设置为离散值。Yu 等<sup>[22]</sup>将行人属性检测问题形式化归类再一个弱监督的目标检测框架下。近期 Li 等<sup>[23]</sup>制作了一个包含大量行人属性的数据集。

## 1.3 面临的问题及挑战

（1）摄像头的参数差异。不同厂商生产不同型号、批次甚至同厂商、型号的摄像之间，在视场角、焦距、光圈、畸变、景深、感光面积等参数上都可能存在差异，在自动增益控制、背光补偿、白平衡等机制上存在技术差异，导致即使对同一地点、同一人物在同一环境下所摄制成的图像，也存在分辨率、对比度、景深、失真、投影误差方面的差异。

（2）摄像头安装位置及环境变化。摄像头安装的位置高度、摄像头安装的视角，摄像头安装环境，一天及一年内光照、天气等环境因素的变化，均会影响行人的成像。如中午与黄昏的光照差异，会影响对行人衣服颜色、纹理的判断。

（3）行人的姿态变化。行人除了走路、站立，还有可能会做出下蹲、弯腰等动作，使肢体形态发生较大变化。在一些场景中，行人较为密集，可能相互遮挡。有些行人还会有换衣服、脱帽等使整体外观发生变化的行为。

(4) 监控视频的分辨率普遍较低。无法利用低分辨率行人图像中人体的生物特征如虹膜和人脸对行人进行重识别, 只能利用头部之外的人体外观信息进行识别。而不同行人的体型和衣着服饰有可能相同或相近, 这为行人的重识别带来了挑战。

## 1.4 本文的主要工作

本文在总结分析目前各类研究成果的基础上, 结合了 FFN 和 FT-CNN 两种网络的优点提出了 FT-FFN, 利用从 FT-FFN 网络提取的深度特征及属性特征改进了行人重识别的准确率。本文的主要贡献如下:

(1) 提出了可产生良好 CNN 特征的 FT-FFN 网络。FT-FFN 在结构上保留 FFN 网络的特点, 同时对原始图像提取 CNN 特征和低层视觉特征, 两个特征通过一个全连接层融合, 该层称为融合层。在反向传播、更新权值过程中低层特征会影响 CNN 网络权值, 促使 CNN 网络部分学习到与低层视觉特征互补的特征。在训练上 FT-FFN 吸收了 FT-FFN 网络的成果, 通过训练行人属性而非行人标记, 微调行人属性训练微调的 FT-FFN 产生的 CNN 描述子对行人重识别问题具有优良的区分能力。

(2) 提出的 FT-FFN 网络在行人属性标注方面具有良好的准确性。FT-FFN 网络内包含一个经 ImageNet 预训练的 AlexNet 或 VGG-16, 这类 ImageNet 具有不错的泛化能力, 同时 FT-FFN 还有低层的颜色纹理特征作为补充。FT-FFN 在经行人属性数据集微调后, 在行人属性识别方面表现出了与该领域当前主流方法相当甚至稍好的准确率。

(3) 分析总结了目前常用的中层语义属性, 将 FT-FFN 网络输出的属性特征与 FT-FFN 网络提取的融合特征相结合, 提高了行人重识别的准确性。

## 1.5 本文的章节安排

本文分为六章, 前两章是绪论及主要技术告诉, 第三章到第五章按照算法的流程步骤编排, 最后一章是总结与展望。具体安排如下:

第一章介绍课题研究的背景及实际意义, 概述行人重识别当前的国内外研究现状、流程步骤、面临的问题及挑战, 并介绍本文的工作。

第二章介绍行人重识别课题中具有代表性、应用较为广泛的关键技术, 其中有些方法会在实验与分析中作为对比。

第三章介绍基于 AlexNet 的特征提取方法及中层属性的判定。首先基于 ImageNet 数据集训练网络至收敛, 再用行人属性数据集微调训练好的模型, 同时获得标定好的行人



属性。

第四章探索基于提取好的 CNN 特征与语义属性特征、低层特征的融合，选取合适度量学习方法，应用于目标图像与行人库图像距离的计算。

第五章简述了评价手段，展示了实验结果，并将实验结果与部分文献进行对比，分析评价本文算法。

最后对全文的研究工作进行了总结评价，指出其中创新与不足，并进一步展望未来研究的方向。

## 第二章 行人重识别相关技术

行人重识别与许多类似的模式识别问题一样，一般分为特征提取和距离度量两个步骤。特征提取是将图像从原始像素映射到特征空间的过程，整个映射保留了所需的信息，舍弃不需要或可能造成干扰的信息。距离度量指对特征空间中两个特征相近程度的度量。随着深度学习引入到行人重识别领域，越来越多的研究借助卷积神经网络自动从原始像素中提取特征。

本章概述了行人重识别领域中常用的特征及其提取方法，并介绍若干主流距离度量方法，最后介绍卷积神经网络的基本结构及训练过程。本章中的许多特征提取技术、距离度量方法将在后面的章节中采用。

### 2.1 特征提取

#### 2.1.1 颜色特征

颜色特征是计算机视觉研究者最早关注和应用的特征，也是与人类的视觉最相对应的特征。图像的颜色特征分布不会随着图片中目标的形变、旋转、平移的改变而发生改变。对于分辨率普遍较低的视频监控系统而言，颜色是低层视觉特征中最为重要的特征。

##### 2.1.1.1 颜色空间

颜色空间是用于定量描述不同色彩的模型，又称彩色模型、彩色系统。常见的颜色空间有 RGB、HSV、Lab、YUV、HSI、等。

RGB 颜色空间和 HSV 颜色空间是行人重识别中使用频繁的两个颜色空间。RGB 颜色空间是基于物体发光定义的（RGB 对应光的三原色：Red，Green，Blue），基于颜色的加法混色原理，从黑色不断叠加 Red，Green，Blue 的颜色，最终可以得到白色光，将 R、G、B 三个通道作为笛卡尔坐标系中的 X、Y、Z 轴，就得到了一种对于颜色的空间描述如。HSV 颜色空间更符合人类对颜色的感官认知，对光照变化具有一定的不变性，所以 HSV 颜色空间不但在计算机图像处理中的得到广泛应用，并且很多艺术家也对此有很强烈的偏好。RGB 颜色空间和 HSV 颜色空间如图 2-1 所示。




图 2 -1 RGB 颜色空间和 HSV 颜色空间

RGB 颜色空间和 HSV 颜色空间可以相互转化。设  $(r, g, b)$  分别是一个颜色的红、绿和蓝坐标，它们的值是在 0 到 1 之间的实数。设  $\max$  等价于  $r, g$  和  $b$  中的最大者。设  $\min$  等于这些值中的最小者。要找到在 HSL 空间中的  $(h, s, l)$  值，这里的  $h \in [0, 360)$  角度的色相角，而  $s, l \in [0, 1]$  是饱和度和亮度，计算为：

$$h = \begin{cases} 0, \max = \min \\ 60 \times \frac{g - b}{\max - \min} + 0, \max = r \text{ and } g \geq b \\ 60 \times \frac{g - b}{\max - \min} + 360, \max = r \text{ and } g < b \\ 60 \times \frac{g - b}{\max - \min} + 120, \max = g \\ 60 \times \frac{g - b}{\max - \min} + 240, \max = b \end{cases} \quad (2-1)$$

$$s = \begin{cases} 0, \max = 0 \\ \frac{\max - \min}{\max}, \text{otherwise} \end{cases} \quad (2-2)$$

$$v = \max \quad (2-3)$$

RGB 颜色空间、和 HSV 颜色空间是行人重识别领域使用最为广泛的空间，常常也是最有效的颜色空间<sup>[24]</sup>。有时为了使特征具有光照不变性，会舍弃掉 HSV 颜色空间中的亮度通道，即 V 通道。其余颜色空间也有各自的应用领域，如 YUV 多用在现代彩色电视系统中，CMYK、CMY 两种颜色空间常用语印刷出版。

#### 2.1.1.2 颜色直方图

图像颜色直方图不关心图片中每种色彩所处的空间位置，而是描述不同色彩在整幅

图像中所占的比例，在计算机视觉中常被使用。颜色直方图的计算是把颜色空间划分为若干个小的颜色区域，然后计算落在每个小区间内像素数量，从而可以得到颜色直方图。现有的颜色量化（划分）的方法有许多，比如聚类方法、向量量化、神经网络方法或者均匀量化的方法。

计算颜色直方图需要将颜色空间划分成若干个小的颜色区间，每个小区间成为直方图的一个 bin。这个过程称为颜色量化（color quantization）。然后，通过计算颜色落在每个小区间内的像素数量可以得到颜色直方图。颜色量化有许多方法，例如向量量化、聚类方法或者神经网络方法。最为常用的做法是将颜色空间的各个分量（维度）均匀地进行划分。相比之下，聚类算法则会考虑到图像颜色特征在整个空间中的分布情况，从而避免出现某些 bin 中的像素数量非常稀疏的情况，比量化更为有效。另外，如果图像是 RGB 格式而直方图是 HSV 空间中的，我们可以预先建立从量化的 RGB 空间到量化的 HSV 空间之间的查找表（look-up table），从而加快直方图的计算过程。

## 2.1.2 纹理特征

### 2.1.2.1 方向梯度直方图

方向梯度直方图（Histogram of Oriented Gradients, HOG）是一种用于人体目标检测的描述子，它描述的是图像的局部纹理特征。HOG 计算图片某一区域不同方向上梯度的值得到直方图，用以表示该区域。HOG 生成的一般步骤是：首先，分割图像，将图像分割后基于统计原理的直方图才对该区域具有表达能力；其次，计算每个区块的方向梯度直方图；最后，将每个小图块提取出的特征组成一个以为向量，该向量就是最重的 HOG 特征。

### 2.1.2.2 SIFT 特征

尺度不变特征变换（Scale Invariant Feature Transform, SIFT）通过求解一幅图片中的特征点，以及有关的尺度和朝向的描述子得到特征并进行图像特征点匹配。SIFT 特征不仅具有尺度不变性，还具有一定的角度、图像、拍摄视角的不变性。

SIFT 特征的提取算法包括构建尺度空间、检测 DOG 尺度空间极值点、去除不加特征点、给特征点赋值一个 128 维方向参、关键点描述子生成等。构建尺度空间是一个初始化操哦，其目的是模拟图像数据的多尺度特征。然后在整个 DOG 尺度空间寻找空间极值点去除 DoG 局部曲率非常不对称的像素，确定每幅图中的特征点，为每个特征点

计算一个方向。依照上述方向，利用关键点领域像素的特堵方向分布为每个关键点指定方向参数，从而使算子具备旋转不变性。将坐标轴旋转为关键点的方向，取  $8 \times 8$  的窗口，在  $4 \times 4$  的小块上计算 8 个方向的梯度直方图。在计算关键点周围  $16 \times 16$  中每一个像素的梯度，并降低原理中心像素的权重。这样对每个特征形成 128 维的描述子，将该向量归一化后就进一步去除了光照的影响。

### 2.1.2.3 LBP 特征

LBP (Local Binary Pattern, 局部二值模式) 是一种用来描述图像局部纹理特征的算子；它具有旋转不变性和灰度不变性等显著的优点。

原始的 LBP 描述子的计算步骤为：1) 对图像中所有像素点，以该点为中心，取  $3 \times 3$  的领域窗口；2) 将 8 邻域像素值于中心像素值对比，大于或等于的中心像素标记置 1，否则置 0；3) 将周围 0-1 序列以一定顺序排列，形成一个 8 位无符号的二进制数，转化为证书，该整数即窗口的 LBP 值。

基本的 LBP 算子产生的二进制模式多，不具有旋转不变性。后来 Maenpaa 等人提出了具有旋转不变性的 LBP 算子，其解决思路是不断旋转邻域得到一系列的 LBP 值，取其中最小值作为该邻域的 LBP 值。


### 2.1.3 属性特征

相对于颜色、纹理等低层特征，年龄区间、性别、衣服款式等语义属性可以视为中层的特征，也叫属性特征。与低层特征相比，中层特征对光照、姿势等图片变化有更好的稳定性。同时中层的语义属性还能应用于根据属性关键词进行检索。常用的行人属性包括年龄、性别、上下身的服装款式、颜色、背包、戴帽等等。

### 2.1.4 几种常用描述子

#### 2.1.4.1 gBiCov

gBiCov 特征结合了 BIF 与协方差特征，其提取流程见图 2-2。

图 2-2 gBiCov 特征提取流程图<sup>[10]</sup>

其提取流程如下：

1. 将原始图片分为 HSV 三个通道。
2. 对每个通道，进行不同尺度的 gabor 滤波。
3. 将相邻尺度合为一个 band。
4. 同一 band 内图像取 max，生成 BIF 级图像。
5. BIF 级图像划分为小区域，用协方差描述子表示。
6. 计算相应区域不同协方差描述子之间的差值。
7. 连接差值，形成最终整幅图像的描述子。

#### 2.1.4.2 LOMO

LOMO（Local Maximal Occurrence Feature）描述子是 Liao 等<sup>[25]</sup>，主要包含颜色纹理信息。特征提取前先进行预处理使用 Retinex 算法改善图像色彩。

第一步，先用 10\*10 的图块扫描全图，步长为 5 像素。对应每个图块，提取如下特征：1）HSV，提取 8\*8\*8bin 的直方图；2）SILTP，提取了两个尺度，SILTP0.3 4,3 和

SILTP0.3 4,5, 其中  $N=4$ , 所以是  $3^4 \text{ bin}$

第二步, 将得到的图块 (尺寸为  $8*8*8+(3^4)*2 \text{ bin}$ ) 每一行进行 maximize 操作, 即将 group 变为一个  $8*8*8+(3^4)*2 \text{ bin}$ , 里面每个 bin 放着的都是最大值。对应  $48*128$  的图片, 能 scan 出 24 个 group, 对图片缩放了两次, 得到  $24*64$ 、 $12*32$  图片。三张图片所有的 group 有  $24+11+5$ , 所以一张行人样本能提取  $(8*8*8+(3^4)*2)*(24+11+5) = 26960$  维的数据。

第三步, 对得到的特征进行对数转换, 归一化 HSV 和 SILTP 特征。

## 2.2 距离度量学习

### 2.2.1 马氏距离

马氏距离学习能克服欧氏距离、余弦距离等经典距离函数没有充分利用数据的结构的缺陷, 广泛应用于改善分类结果<sup>[4]</sup>。

马氏距离函数如下:

$$d(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j) \quad (2-4)$$

上式中的  $M$  是一个半正定矩阵, 给定数据后的目标便是估计  $M$ 。

引入  $M$  的因子矩阵  $L$

$$M = L^T L \quad (2-5)$$

则上式可以写为

$$d(x_i - x_j) = \|L(x_i - x_j)\|^2 \quad (2-6)$$

于是可以通过计算因子矩阵  $L$  来代替  $M$ 。

### 2.2.2 LMNN

LMNN 度量学习<sup>[4]</sup>额外利用了数据的局部结构。对于每个实例, 建立了  $k$  近邻共享相同的标记的局部边界。含有不同标记的样本侵入边界会受到惩罚。对一目标对  $(x_i - x_j) \in S$ , 任何满足  $y(x_j) \neq y(x_i)$  当满足下列条件时被视为冒充者

$$\|L(x_i - x_j)\|^2 \leq \|L(x_i - x_i)\|^2 + 1 \quad (2-7)$$

因此当前目标为拉近目标对同时惩罚冒充者, 可通过下列目标函数实现

$$\mathcal{L}(M) = \sum_{j \sim i} d_M(x_i - x_j) + \beta \sum_l (1 - y_{il}) \xi_{il}(M) \quad (2-8)$$

上式中

$$\xi_{ijl}(M) = 1 + d_M(\mathbf{x}_i - \mathbf{x}_j) - d_M(\mathbf{x}_i - \mathbf{x}_l) \quad (2-9)$$

式子中 $\beta$ 用来调整两项之间的相对权重，第一项最小化 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 之间的距离，第二项表征冒充者侵扰程度。对目标函数应用梯度下降法求解  $M$

$$\frac{\partial \mathcal{L}(M)}{\partial M} = \sum_{j \sim i} C_{ij} + \beta \sum_{(i,j,l) \in \mathcal{N}} (C_{ij} - C_{il}) \quad (2-10)$$

### 2.2.3 KISSME

KISSME<sup>[4]</sup>的目标是从统计推断角度简解决度量学习问题。

假设一个样本 $\mathbf{x}$ 和他的类标签 $\mathbf{y}(\mathbf{x})$ 已经给定，根据样本标签是否正确我们可以把数据转换为相似对和不相似对

$$S = \{\mathbf{y}(\mathbf{x}_i) = \mathbf{y}(\mathbf{x}_j)\} \quad (2-11)$$

$$D = \{(\mathbf{x}_i - \mathbf{x}_j) | \mathbf{y}(\mathbf{x}_i) \neq \mathbf{y}(\mathbf{x}_j)\} \quad (2-12)$$

对于假设 $H_0$ :  $(\mathbf{x}_i, \mathbf{x}_j)$ 不相似，假设 $H_1$ :  $(\mathbf{x}_i, \mathbf{x}_j)$ 相似，我们使用似然比检验

$$\delta(\mathbf{x}_i, \mathbf{x}_j) = \log \left( \frac{p(\mathbf{x}_i - \mathbf{x}_j | H_0)}{p(\mathbf{x}_i - \mathbf{x}_j | H_1)} \right) = \log \left( \frac{f(\mathbf{x}_i, \mathbf{x}_j, \theta_0)}{f(\mathbf{x}_i, \mathbf{x}_j, \theta_1)} \right) \quad (2-13)$$

上式中 $\delta$ 为对数似然比， $f(\mathbf{x}_i, \mathbf{x}_j, \theta_n)$ 是在参数 $\theta_n$ 下的概率分布函数。假定服从均值为 0 的正态分布，(2-13)可以写为

$$\delta(\mathbf{x}_i, \mathbf{x}_j) = \log \left( \frac{\frac{1}{\sqrt{2\pi|\Sigma_D}} \exp(-1/2(\mathbf{x}_i - \mathbf{x}_j)^T \Sigma_D^{-1} (\mathbf{x}_i - \mathbf{x}_j))}{\frac{1}{\sqrt{2\pi|\Sigma_S}} \exp(-1/2(\mathbf{x}_i - \mathbf{x}_j)^T \Sigma_S^{-1} (\mathbf{x}_i - \mathbf{x}_j))} \right) \quad (2-14)$$

式中 $\Sigma_D$ 和 $\Sigma_S$ 是  $D$  和  $S$  的协方差矩阵。

对上式取对数并忽略常数项，可以得到

$$\delta(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T (\Sigma_S^{-1} - \Sigma_D^{-1}) (\mathbf{x}_i - \mathbf{x}_j) \quad (2-15)$$

因此，马氏距离矩阵  $M$  可表示为

$$M = (\Sigma_S^{-1} - \Sigma_D^{-1}) \quad (2-16)$$

### 2.2.4 XQDA

XQDA (Cross-view Quadratic Discriminant Analysis, 交叉视图二次判别分析) 是 Liao 等<sup>[25]</sup>给出的一种距离度量方法。给定一个样本差 $\Delta = \mathbf{x}_i - \mathbf{x}_j$ ，当 $\mathbf{y}_i = \mathbf{y}_j$ 时称为内在差异 (intrapersonal variations)，记作 $\Omega_i$ ；当 $\mathbf{y}_i \neq \mathbf{y}_j$ 时称为外在差异 (extrapersonal variations)



$\Omega_E$ 。多类分类问题可以看成是区别类内差和类间差的二分类问题。

在标准正太分布下， $\Delta$ 属于 $\Omega_I$ 或 $\Omega_E$ 的概率如下

$$P(\Delta|\Omega_I) = \frac{1}{(2\pi)^{d/2}|\Sigma_I|^{1/2}} e^{-\frac{1}{2}\Delta^T \Sigma_I^{-1} \Delta} \quad (2-17)$$

$$P(\Delta|\Omega_E) = \frac{1}{(2\pi)^{d/2}|\Sigma_E|^{1/2}} e^{-\frac{1}{2}\Delta^T \Sigma_E^{-1} \Delta} \quad (2-18)$$

式中 $\Sigma_E$ 和 $\Sigma_I$ 是 $\Omega_E$ 和 $\Omega_I$ 的协方差矩阵， $n_I$ 和 $n_E$ 表示两类样本数量。应用贝叶斯法则和对数似然比例检验，判定函数可以简化为

$$f(\Delta) = \Delta(\Sigma_I^{-1} - \Sigma_E^{-1}) \Delta \quad (2-19)$$

$x_i$ 和 $x_j$ 之间的距离函数为

$$d(x_i, x_j) = (x_i - x_j)^T (\Sigma_I^{-1} - \Sigma_E^{-1}) (x_i - x_j) \quad (2-20)$$

因此学习距离函数只需计算协方差矩阵 $\Sigma_E$ 和 $\Sigma_I$ 。

给定一个子空间 $W = (w_1, w_2, \dots, w_n) \in \mathbb{R}^{d \times r}$ ，上式在 $r$ 维子空间可以表示维为


$$d_W(x, z) = (x - z)^T W(\Sigma_I'^{-1} - W(\Sigma_E'^{-1})W^T)(x - z) \quad (2-21)$$

式中 $\Sigma_I'^{-1} = W^T \Sigma_I^{-1} W$ ， $\Sigma_E'^{-1} = W^T \Sigma_E^{-1} W$ 。求解时，对 $\Sigma_I'^{-1} \Sigma_E'$ 进行特征值分解，矩阵 $W$ 由前 $r$ 个最大特征值对应的特征向量构成。

## 2.3 卷积神经网络

人工神经网络是一种模仿动物的中枢神经系统的结构和功能的计算模型，卷积神经网络（Convolutional Neural Network，简称CNN）是其中一类非常适用于图像等二维数据设计的人工网络。Hubel和Wiesel<sup>[26]</sup>对猫视觉皮层的研究发现视觉皮质含有一个复杂的细胞排列，这些细胞些单元作为输入空间的局部滤波器，非常适合利用自然图像中存在的强空间局部相关性。卷积神经网络一般由一个或多个卷积层和顶端的全连接层组成，包括权重关联和池化层（pooling layer）。

卷积神经网络使用一个小卷积核作用在整幅图像上，卷积核在不同区域做卷积时共享参数，较于全连接的方式，这种方式大大减少了权值的数量。因此是最早训练成功、并应用于商用的深度神经网络。Lecun等<sup>[27]</sup>的LeNet5是经典卷积神经网络，见图2-3。

图 2-3 LeCun 提出的经典网络 LeNet5<sup>[15]</sup>

### 2.3.1 卷积层

卷积层的输入为原始图像或前一层产生的特征图，卷积层对其输入进行卷积运算，运算结果送入到激活函数（有时也把激活函数当作一层）生成新的特征图后将其输出。一个卷积层内通常包含若干个卷积核函数，卷积核与原始图片就行卷积运算的过程可以看作提取特征的过程，不同的卷积核提取图片不同的特征。每个卷积核在提取整幅图片各个局部的特征后将其汇总便得到新的特征图。

相对于全连接，卷积层通过局部感受野和权值共享两种机制减少参数个数。一般认为人对外界的认知是从局部到全局的，而图像的空间联系也是局部的像素联系较为紧密，而距离较远的像素相关性则较弱。因而，每个神经元其实没有必要对全局图像进行感知，只需要对局部进行感知，然后在更高层将局部的信息综合起来就得到了全局的信息。权值共享指卷积核在对图像不同局部进行卷积操作时共享同一个卷积核使得在应用于视觉时不受位移影响，同时大大减少网络参数，如图 2-4 所示。




图 2-4 卷积层的局部视野

### 2.3.2 池化层

在没有池化层的情况下，对图像通过卷积网络后所提取特征一般过大。如 96x96 像素的图像，经过 400 个大小为 8X8 的卷积核，将得到 3,168,400 维的卷积特征向量。这对于多数分类器十分不便。因此，为了描述大的图像，常常对不同位置的特征进行聚合统计，如可以计算图像一个区域上的某个特定特征的平均值或最大值。这种聚合的操作就叫做池化(pooling)。池化可以和卷积相结合达到数据降维，去耦合性和冗余性的目的。

池化从滑动窗口作用于图像的区域是否有重叠出发可以划分为一般池化、重叠池化和空间金字塔池化。

### 2.3.3 激活函数

激活函数这一名词来自对大脑工作的研究工作，用于模拟大脑同一时间工作的神经元。对于单个神经元，如图 3-3 所示，其输入为向量

$$\mathbf{x} = (x_1, x_2, x_3, \dots) \quad (2-22)$$

其输出为

$$\mathbf{h}_{w,b} = f(W^T \mathbf{x}) \quad (2-23)$$

其中函数  $f: R \rightarrow R$  被称为激活函数。




图 2-5 单个神经元

另外，Sigmoid 函数如下

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-24)$$

另外，tanh 函数如下

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-25)$$

AlexNet 选用 ReLu (Rectified Linear Units, 修正线性单元) 作为激活函数，其形式

如下

$$f(x) = \max(0, x) \quad (2-26)$$




图 2-6 四种常见的激活函数图像

### 2.3.4 全连接层

全连接层（fully connected layers, FC）中的每个神经元均与上一层的所有神经元连接。全连接层在整个卷积神经网络中起到“分类器”的作用。如果说卷积层、池化层和激活函数层等操作是将原始数据映射到隐层特征空间的话，全连接层则起到将学到的“分布式特征表示”映射到样本标记空间的作用。




图 2-7 全连接层

### 2.3.5 Softmax 回归

Softmax 回归模型是 Logistic 回归模型从二分类到多分类的推广<sup>[28]</sup>，多分类即类标签  $y$  可取两个以上的值。

假设有由  $m$  个样本组成的样本  $\{(x_1, y_1), \dots, (x_m, y_m)\}$ , 其中  $x_i \in \mathbf{R}^{n+1}$  为第  $i$  项样本的特征, 对于二分类的 Logistic 回归模型, 其类标记  $y_m \in \{0, 1\}$ , 假设函数为:

$$h_\theta = \frac{1}{1 + e^{-\theta^T x}} \quad (2-27)$$

通过优化代价函数训练模型参数  $\theta$

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m y_i \log h_\theta(x_i) + (1 - y_i) \log(1 - h_\theta(x_i)) \right] \quad (2-28)$$

在多分类的 Softmax 回归模型中, 对于训练集  $\{(x_1, y_1), \dots, (x_m, y_m)\}$ , 有  $y \in \{1, 2, \dots, k\}$ , 即类标签可以取  $k$  个不同的值。假设函数如下

$$h_\theta(x_i) = \begin{bmatrix} p(y_i = 1 | x_i; \theta) \\ p(y_i = 2 | x_i; \theta) \\ \vdots \\ p(y_i = k | x_i; \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x_i}} \begin{bmatrix} e^{\theta_1^T x_i} \\ e^{\theta_2^T x_i} \\ \vdots \\ e^{\theta_k^T x_i} \end{bmatrix} \quad (2-29)$$

其中  $\theta_1, \theta_2, \dots, \theta_k \in \mathbf{R}^{n+1}$  是模型的参数,  $\frac{1}{\sum_{j=1}^k e^{\theta_j^T x_i}}$  这一项对概率分布进行了归一化。

为方便用  $\theta$  表示所有的参数:

$$\theta = \begin{pmatrix} \theta_1^T \\ \theta_1 \\ \vdots \\ \theta_1^T \end{pmatrix} \quad (2-30)$$

Softmax 回归模型的代价函数为

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k l(y_i = j) \log \frac{e^{\theta_j^T x_i}}{\sum_{l=1}^k e^{\theta_l^T x_i}} \right] + \frac{\lambda}{2} \sum_{i=1}^k \sum_{j=0}^n \theta_{ij}^2 \quad (2-31)$$

式(2-31)中  $l(\cdot)$  为指示函数, 当其中语句为真时取值为 1, 但其中语句为假时取值为 0。式(2-31)中第二项为权重衰减项, 可防止产生过大的参数值, 避免过拟合。对  $J(\theta)$  求导得到如下梯度公式

$$\nabla_{\theta_j} J(\theta) = -\frac{1}{m} \sum_{i=1}^m [x_i (l(y_i = j) - p(y_i = j | x_i; \theta))] + \lambda \theta_j \quad (2-32)$$

得到梯度公式后可结合梯度下降法等来最小化  $J(\theta)$ 。以梯度下降法为例, 每次迭代进行如下更新

$$\theta_j := \theta_j - \alpha \nabla_{\theta_j} J(\theta), j = 1, \dots, k \quad (2-33)$$

### 2.3.6 反向传播算法

反向传播（Back Propagation）算法是用来训练人工神经网络的最常见方法，该算法通过激励传播、权重更新两个环境反复迭代，调整网络参数，直至网络的输出与目标输出的差值小于一定值。

对于包含  $m$  个样例的训练集  $\{(x_1, y_1), \dots, (x_m, y_m)\}$ ，使用批量梯度下降法求解，定义网络的整体代价函数为

$$J(W, b) = \left[ \frac{1}{m} \sum_{i=1}^m \|h_{W,b}(x_i) - y_i\|^2 \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} (W_{ji}^l)^2 \quad (2-34)$$

式(2-34)中第一项为均方差项，用于衡量网络输出与目标输出的差距，第二项是正则化项或权重衰减项，该项是为了减小权重的幅度，防止过拟合。 $\lambda$ 用于控制两项之间的相对权重。

为求解网络，首先赋予所有参数  $W_{ji}^l$  和  $b_i^l$  一个较小、接近于 0 的初值。梯度下降法中每一次迭代地更新公式如下

$$W_{ji}^l = W_{ji}^l - \alpha \frac{\partial J(W, b)}{\partial W_{ji}^l} \quad (2-35)$$

$$b_i^l = b_i^l - \alpha \frac{\partial J(W, b)}{\partial b_i^l} \quad (2-36)$$

式(2-36)中  $\alpha$  为学习率，影响每次权值更新的步长。

反向传播算法的思想如下：给定样例  $(x, y)$ ，先将样本输入网络，计算网络中所有的激活值，计算网络输出值与目标输出值之差。对于输出层  $l$  的每个节点，计算每个节点对最终残差产生的影响

## 2.4 本章小结

本章总结了颜色、纹理、属性等常见特征的提取方法，介绍了两个本文常见的描述子推导马氏距离及其衍生的 LMNN、KISSME、XQDA 等度量学习方法。最后介绍了卷积神经网络的组成结构及求解的一般过程。

## 第三章 基于深度特征的行人重识别

### 3.1 引言

特征提取是特征工程的重要问题。特征提取是从原始数据出发构造新特征的过程，一般数据转化到特征空间以后，舍弃了某些对识别无关或造成干扰的信息，保留相关的信息，如对于行人重识别，理想的描述子应该对光照、行人姿势变化、视角变化等不敏感，而保留颜色、纹理、空间结构等信息。早期特征的构造由专家借助相关领域知识，在对数据的分析、判断和思考下，抽取、组合各类特征得到。随着各行各业累积数据的爆发式增长，原有的人工特征方法难以满足日益增长的需求。此外手工设计的特征往往使用领域较窄，在其目标领域表现良好，迁移到其他领域往往效果会大打折扣。

深度学习的流行正在改变这一现状，Hinton 等<sup>[29]</sup>于 2006 年对深度神经网络引入了预训练这一步骤，通过逐层的训练，使整个网络具有较好的初值，避免因随机梯度下降法在深层网络上的梯度弥散现象，从而学习得到的特征对数据有更本质的刻画，。随后深度学习逐渐流行起来，在语音识别领域、视觉对象识别等领域带来了突破<sup>[30]</sup>。

引入卷积神经网络的行人重识别大体可以分为两类：一类将行人图片对或三元组送入卷积神经网络中，令卷积网络学习判断两幅图像是否为同一人，如 Ding 等<sup>[16]</sup>将行人图片分为若干三元组，三元组包含一对匹配行人和一对不匹配行人将三元组送入网络，令 CNN 学习相对距离比较；另一类将 CNN 作为特征提取的手段，将 CNN 的某一层输出导出作为 CNN 特征，融合其他的低层特征，使用经典的距离度量方法计算相对距离，如<sup>[17,18,31]</sup>。前者由于行人图片对数目较少，且常常面临正负例不平衡的问题，因此目前行人重识别领域更多倾向与将 CNN 作为特征提取的手段，并通过各类手段调整 CNN 所学特征。本文循着第二类的方向，设计了 FT-FFN 网络，用于 CNN 特征的提取。

本文基于近期的研究成果，设计了一个深度网络，命名为 FT-FFN（Fine-Tuning Feature Fusion Net）。FT-FFN 既可以将其中融合层的输出作为 CNN 特征，结合现有的度量学习方法衡量实现行人重识别，也可以在输出层得到行人的语义属性特征用于行人辅助重识别。本章侧重于 CNN 特征的提取，与行人语义属性有关的讨论见第四章。

### 3.2 FT-FFN 网络的灵感来源

FT-FFN 的灵感来自 Matsukawa 等<sup>[18]</sup>的 FT-CNN 和 Wu 等<sup>[17]</sup>的 FFN（Fusion Feature Net），如图 3-1 所示。Wu 等<sup>[17]</sup>将 ELF16 特征与一个经典的五层 CNN 网络接到同一个



连接层，在一个包含 1501 个行人的 38195 幅图片训练，使 CNN 学习到与低层 ELF16 特征互补的特征。将 FC7 层输出作为 CNN 特征，取得了较好的效果。Matsukawa 等<sup>[18]</sup>将训练好 AlexNet 网络应用于行人属性识别，发现经属性训练微调后 FC6 层输出 CNN 特征，在融合 LOMO 等特征后具有良好的效果。




图 3 -1 FFN<sup>[16]</sup>和 FT-CNN<sup>[17]</sup>网络简图

### 3.3 FT-FFN 的网络结构

#### 3.3.1 网络概述

本文提出的 FT-FNN 网络的整体结构如图 3-2 所示。FT-FNN 网络的结构由 ImageNet 部分、ELF 部分、融合层等关键部分组成，ImageNet 部分用于提取图片的 CNN 特征，ELF 部分用于提取图片的低层视觉特征（颜色、纹理等），低层特征通过融合层与 CNN 特征融合，送入到最后的全连接层，用于联合判断行人的多个中层属性。下面对 FT-FNN 的主要部分做详细介绍。






图 3-2 本文提出的 FT-FFN（Fine-tuning Feature Fusion Net）网络框架图

### 3.3.2 ImageNet 部分


图 3-2 的上半部分通过一个 CNN 网络提取 CNN 特征。本文使用 Alex 和 VGG 两种 ImageNet 来提取特征。ImageNet 是美国斯坦福的计算机科学家，模拟人类的识别系统建立的，是目前世界上图像识别领域最大的识别物体数据库。许多研究<sup>[32-34]</sup>表明，经过海量训练集预训练的网络，其高层的输出可以作为一个现成的描述子。在 ImageNet 图像分类数据集上训练出来的 CNN 特征，在其他识别人任务中也表现出极高的性能<sup>[32-34]</sup>。ImageNet 竞赛每年开展，AlexNet、VGG、GoogLeNet、ResNet 是历年表现最优异四个网络模型。其参数对比如表 3-1 所示。

表 3-1 四种 ImageNet 网络对比

| 模型名      | AlexNet <sup>[35]</sup> | VGG <sup>[36]</sup> | GoogLeNet <sup>[37]</sup> | ResNet <sup>[38]</sup> |
|----------|-------------------------|---------------------|---------------------------|------------------------|
| 提出年份     | 2012                    | 2014                | 2014                      | 2015                   |
| 层数       | 8                       | 19                  | 22                        | 152                    |
| Top-5 错误 | 16.4%                   | 7.3%                | 6.7%                      | 3.57%                  |

| 模型名    | AlexNet <sup>[35]</sup> | VGG <sup>[36]</sup> | GoogLeNet <sup>[37]</sup> | ResNet <sup>[38]</sup> |
|--------|-------------------------|---------------------|---------------------------|------------------------|
| 卷积层数   | 5                       | 16                  | 21                        | 151                    |
| 卷积核大小  | 11,5,3                  | 3                   | 7,1,3,5                   | 7,1,3,5                |
| 全连接层数  | 3                       | 3                   | 1                         | 1                      |
| 全连接层大小 | 4096,4096,1000          | 4096,4096,1000      | 1000                      | 1000                   |

考虑到网络层数过多带来的时间开销,本文将选择 AlexNet 和 VGG 用于 FT-FFN 网络中的 CNN 特征提取。AlexNet 和 VGG 的网络结构图如图 3-3、图 3-4 所示。AlexNet 由 5 个卷积层和三个全连接层组成, AlexNet 的训练相比传统的 CNN, 不同之处在于采用了数据增强、Dropout 防止过拟合, 此外还采用了 ReLU 激活函数。VGG 是在 Alex-net 的基础上, 增加网络层数, 并第一个卷积层使用更小的 filter 尺寸和间隔 (3\*3) 发展而来。与 AlexNet 不同, VGG 在 multi-scale 上和整个图片训练和测试图片。

图 3-3 Alex 网络结构<sup>[39]</sup>




图 3-4 VGG-16 网络简图

### 3.3.3 低层视觉特征部分

图 3-1 的下半部分, 提供手工设计的低层视觉特征。ELF 是 Gray 等<sup>[20]</sup>于 2008 年提出的描述子, 后来经过 Zheng 等<sup>[40, 41]</sup>的改良。ELF 包括 RGB、HSV、LAB、等颜色通道的分条直方图。除颜色信息之外, 还有 8 个 Gabor 过滤器、13 个 Schmid 过滤器所产生的纹理信息信息。本文参照 Wu 等<sup>[17]</sup>的做法, 增加了若干颜色通道和 LBP 纹理特征, 扩充后共有 16 维的颜色直方图, 因此称为 ELF16。

### 3.3.4 融合层

图 3-1 的右半部分, 从 ImageNet 第一个全连接层输出的 CNN 特征与低层视觉特征通过输入到同一个 4096 维的全连接层融合。Wu 等<sup>[17]</sup>的工作证明, 由于低层视觉特征在反向传播过程中会对 CNN 的影响, 使 CNN 网络提取到与低层视觉特征互补的特征, 从而使两者融合后的特征具有更高的区别能力。低层视觉特征在进入全连接层前先通过一个 4096 维的缓冲层, 缓冲层是两种差异巨大特征之前的桥梁保证 FFN 的收敛<sup>[17]</sup>。

融合层的输出同时含有 ImageNet 网络提取的深度特征, 以及低层的 ELF 特征, 因此本文将这一层的特征导出作为 FT-FFN 网络提取到的 CNN 特征。

## 3.4 与 FNN 和 FT-CNN 的比较

本文的 FT-FFN 网络保留了 FFN 输入低层视觉特征的结构, 但是在以下方面与 FT-FFN 不同: 1) 训练目标不同 FT-FFN 用来识别行人属性, 其最后一层是节点数与属性数量一致的全连接层, 而 FNN 用来识别行人的标签; 2) FNN 使用了作者自己设计的卷积网络, FT-FNN 使用标准的 AlexNet。FFN 使用的数据集种每个行人的标签仅有几十到数百张, 而如果进行中层属性的训练, 每张行人图片都可以作为所有属性的样本。因此, 训练行人属性能够获取的样本数要远远多余行人的标签, 而大量的样本是深度网络取得成功的关键。AlexNet 在 2012 年 ImageNet 的图片分类竞赛中获得当年的冠军, 被广泛使用, 其训练好的模型参数获取比较容易, 此外 AlexNet 在 FT-CNN 中展现较高的准确率, 因此 FT-FFN 选用了 AlexNet 为 FT-FFN 中提取深度特征部分的网络。

相较于 FT-CNN, 本文引入了 FFN 中低层视觉特征 ELF。FFN 引入的 ELF 特征, 使得 FFN 中的 CNN 部分在反向传播的过程中学习到与 ELF 高度互补的特征, 提高了融合层输出的深度特征的表达能力。考虑属性中仍有“上身红色”这类与颜色高度相关的特征, 加入包含颜色直方图的 ELF 有可能改进这部分属性识别的准确性。FT-CNN 没

有用到最终输出的中层语义属性信心，本文在第四章将中层属性与深度特征融合起来。

### 3.5 FT-FNN 网络的配置和训练

#### 3.5.1 在 ImageNet 上的预训练

ImageNet 网络的图像分类与行人重识别相差巨大，直接使用 ImageNet 网络提取的 CNN 特征用于行人重识别在 ImageNet 的工作中证明十分不理想<sup>[18]</sup>。因此当将模型跨领域迁移到其他识别任务中时，通常需要经过微调。用迁移到领域的数据微调原有模型，在许多研究中使准确率有显著提高<sup>[42, 43]</sup>。

本文使用行人属性识别数据集对 ImageNet 进行微调，使其产生适用于判别行人图像相似程度的数据集。原因主要有：行人属性如性别、年龄等可用于检索、区别行人图像，与行人重识别判断两个行人图片的相似程度具有很大的相关性，如同时具有长发、白色上衣、蓝色裤子等属性的两个行人，在外观上也必然十分相似；行人属性识别数据集同样来自街头、机场等公共场所的监控，甚至直接由行人重识别数据集组成，二者的图片比较相近；近年来行人属性识别出现了许多大规模的数据集，如 RIP 数据集<sup>[44]</sup>，为微调提供了充分的条件；最后行人属性信息本身也是一种重要的特征，网络的识别结果可以作为属性特征，作为 CNN 特征和低层视觉特征的补充。

本文的方法在 Caffe 框架<sup>[45]</sup>下实现，Caffe 提供了训练完毕的 AlexNet 模型，本文在这个模型之上添加另一个数据层用于输入低层 ELF 特征，构成本文设计的 FT-FFN 网络结构。

#### 3.5.2 在 RAP 和 PETA 上的训练策略

RAP<sup>[44]</sup>和 PETA<sup>[46]</sup>是两个行人属性识别数据集，其介绍和样图请参考第五章。本文使用 RAP 和 PETA 两个数据集对 FT-FFN 网络就进行微调训练。

数据增强是训练深度网络的常见技术。数据增强可以丰富训练图像，扩增训练样本，防止过拟合提高模型的泛化能力。数据增强的常用手段有旋转平移、剪切、改变图像色差等手段。本文采用了水平翻转、剪裁等手段进行数据扩展。由于大多数属性分布并不平衡，于是本文在进行数据增强时，适当增大了部分低频属性样本的扩增幅度，以减弱样本不平衡带来的影响。同时，FT-FNN 采用了加权损失函数

$$Loss = -\frac{1}{N} \sum_{i=1}^N \sum_{l=1}^L \omega_l (y_{il} \log(1 - p_{il}) + (1 - y_{il}) \log(1 - p_{il})) \quad (3-1)$$

$$w_l = \exp(-\frac{p_l}{\sigma^2}) \quad (3-2)$$

3-1 式中的 $w_l$ 为第 $l$ 个属性的权重，本文中该权重的设置如 3-2 式所示 $p_{il}$ 为该属性正例所占的比例。

FT-FNN 使用批量随机梯度下降法求解，每批次输入 25 张图片。学习率初始设置为 $\alpha=2e^{-5}$ ，每一万次学习率衰减到原来十分之一。

### 3.6 本章小结

本章介绍了 FT-FFN 网络的灵感来源、设计思想、网络结构集训练策略。FT-FFN 在结构上与 FFN 类似，由 CNN 部分和 ELF 两部分组成。可以通过低层属性特征影响 CNN 特征的提取，使学得的 CNN 特征具有高度互补性。

## 第四章 基于中层语义属性的行人重识别

语义属性是指性别、服装款式、戴帽背包等具有语言意义、可被人类理解的属性。实际上，人类专家在监控视频中搜索感兴趣人物时，也常常根据该人物“穿了一件红色T恤”、“戴了一顶帽子”、“背一个黑色商务背包”、“拎着行李箱”等比较显著地特征，快速地排除一系列无关人员，缩小检索范围，将注意力集中在拥有同样属性、外观类似的小范围人群中。

本章将分类总结常用的中层属性，分析不同属性的区分能力等特征，随后进一步探索中层属性在行人重识别中的应用。

### 4.1 中层属性种类

中层语义属性的划分存在许多不同的方案。Ryan 等<sup>[47]</sup>人综合可计算性和区别能力选择了 21 个二元属性，Deng 等<sup>[46]</sup>人综合许多公开的行人数据集，制作的 PETA（PEdesTrian Attribute）数据集定义了 61 中二元属性和 4 种多远属性，Zhang 等人<sup>[44]</sup>制作的 RAP（Richly Annotated Pedestrian）数据集，囊括 72 种细粒度属性。

综合不同的属性划分方案，常用的中层语义属性按其描述内容可以划分为以下几类：

（1）个人特征。个人特征指人的性别（男、女或未知），年龄区间（小于 15 岁、15 至 35 岁、35-60 岁、60 岁以上）、种族（黑人、白人）、体型的高矮胖瘦（偏瘦、标准、微胖）、发型（长发、短发、光头）等。

（2）衣着穿戴。衣着穿戴可按从上到下的顺序，分为头部、上身、下身、脚四个部分。头部的特征有戴帽、戴眼镜、围巾、头巾等。上身的特征有衬衣、毛衣、马甲、T恤、棉服、卫衣、长袖、短袖、西服、夹克等衣着款式信息，上衣颜色黑、颜色白、颜色红、颜色灰等色彩属性，还有 LOGO、格子等标志信息。身的特点与上身类似，有长裤、长裙、短裤、短裙、牛仔裤等款式信息，也有下衣黑、下衣白、下衣棕等色彩属性的部分有长筒靴、皮鞋等鞋袜的种类信息，也有白、灰、红、绿等色彩属性

（3）附属物品。附属物品指人携带的箱包等，常见的附属物品有单肩包、双肩包、手提包、行李箱、塑料袋、购物车等。

（4）行为特征。行人正在进行的打电话、交谈、聚集、抱东西、推东西、拉拽东西、夹带东西等特征。

图 4-1 展示了不同种类属性的若干样例。



图 4-1 行人属性示例（图片来自 RAP 数据集<sup>[44]</sup>）

## 4.2 中层语义属性分析

虽然上节列举的众多属性都被归类于中层属性，但内部还是存在一定层次。如行人的性别、年龄等与低层的颜色、纹理等低层视觉特征关联较弱，而上下身的衣着颜色属性则与低层颜色特征紧密相关。不同属性之间稳定程度存在差别，人的性别、年龄最为稳定，短期一般不会发生变化，衣着款式、颜色在不同摄像头移动的短时间内不发生变化的假设大多时间也能成立，但是购物车、拎包、戴帽等则有可能发生变化，如因天气热把帽子摘下，将箱包交给同伴。许多属性具有一定的主观性。如一件介于黑色和灰色之间的裤子，其属性应当为下身灰还是下身黑，Layne 等<sup>[47]</sup>记录了两个标注者的结果，发现许多属性的标注都产生了分歧，21 个属性中有 4 个不一致率超过 10%，主要集中在黑头发、黑下身等与颜色关联较强的属性。

属性的频率对于其在行人重识别中的作用有着重要影响。例如某种属性如绿色裤子在人群中的比例较小，假设能准确判断行人的各类属性，对于具有绿色裤子的待匹配图片（probe image），这一属性能排除大部分非绿色裤子的候选人，这种情况之下穿绿色裤子这一属性对该 probe 图片十分有效。但是，对于不穿绿色裤子的大多数 probe 图片来说，利用是否穿绿色裤子这一属性能排除的行人库图片（gallery images）图片十分稀少，对于这类占多数的 probe 图片来说，穿绿色裤子这一属性几乎没有帮助。总体上，属性频率过低或过高，属性的有效性都会较低。属性的效用可以用互信息衡量<sup>[47]</sup>，理论上效用最高的是频率为 0.5 的属性，即刚好能大致过滤掉 gallery 中一半候选人的属性。

属性的频率除了对属性效用的影响，还可能对属性预测的准确性产生影响。属性频率过低属性，其正样本相对于负样本过于稀少，属性过高的影响则是负样本相对于正样本频率过低，两种情况都会导致正负样本极度不平衡，而正负样本不平衡会给分类器



训练带来极大地挑战，影响属性识别的准确性。

对 RAP 和 PETA 两个数据集的属性频率进行统计，结果如图 4-2、图 4-3 所示。可以看到两个数据集中不同属性的频率相差很大。PETA 数据集存在大量频率低的属性，实际上 PETA 数据集最初标记了 65 个二元属性，但是口罩（accessoryFaceMask）、下身标志（lowerBodyLogo）、披肩（accessoryShawl）、下身细条纹（lowerBodyThickStripes）四个属性过少而被剔除，剩下的属性中也存在许多样本偏低的情况，如绿色头发。因此，在 PETA 上的研究工作往往剔除 PETA 中一部分频率较低的属性。RAP 数据集的频率分布较 PETA 数据集稍好，较少出现极端偏低的属性。因此本文在进行属性识别训练时，通过加权损失函数和数据扩展两个手段削弱属性不平衡给训练结果带来的影响，并剔除了 PETA 数据集种样本过少的属性。




图 4-2 PETA 数据集属性频率直方图




图 4-3 RAP 数据集属性频率直方图

### 4.3 中层语义属性识别

本文的语义属性检测方法即第三章中提到的 FT-FNN 网络预测语义属性，FT-FNN 是 FFN 与 FT-CNN 网络的结合，将 FT-CNN 中训练行人属性的方法运用于改进的 FFN 网络中，FT-CNN 网络的输出即为语义属性向量。该方法的细节已在第三章中具体介绍，本节不再赘述。这里对本文方法和目前行人属性识别领域的两种领先方法 ACN<sup>[48]</sup>和 DeepMAR<sup>[23]</sup>做一个比较。




图 4-4 本文网络 FT-FNN 与 ACN、DeepMAR 的比较

如图 4-4 所示，第一行为本文提出的 FT-FNN 网络结构概要图，第二行为 Sudowe 等<sup>[48]</sup>提出的 ACN。我们提出 FT-FNN 将手工提取 ELF 特征和原始图片输入到网络中，原始图片输入到 ImageNet 部分，具体包括 AlexNet 或 VGG-16。ACN 网络和 DeepMAR 网络均基于 CaffeNet，并且同时训练多个属性。ACN 网络将图片输入到经 ImageNet 数据集预训练的 CaffeNet，在 CaffeNet 的最后对每个属性添加一个 loss 层，ACN 选用的 loss 函数为 KLloss 函数。ACN 还提供了一个可选的隐藏层，在 FC8 层前加一个隐藏层能提高实验结果。DeepMAR 中，行人图片同样经过经预训练的 CaffeNet，再通过一个全连接层。与 ACN 不同的是，DeepMAR 较细致考虑到了属性不平衡的问题，DeepMAR 给出的解决方案包括：1) 在数据增强阶段，对频率较低的属性，令其样本扩展更多的数

量；2) 调整了 loss 函数，加入了一个权重项，一使得少数类判别错误的损失大于多数类判别错误的损失。本文提出的 FT-FNN 同样使用了加权 loss 函数和加大低频数据增强的幅度两个手段降低训练数据不平衡对于实验结果的影响。三种网络都同时预测所有属性，而不是单独训练每个属性，原因在于属性之间存在相关关系，例如一个性别为女的行人通常更有肯能具有长发、拎包等属性。

综上，本文 FT-FNN 方法与 ACN 或 DeepMAR 的共同之处在于：1) 均基于泛化能力强、且经过 ImageNet 海量数据集预训练的深度网络；2) 同时学习多个属性，而非每个属性单独训练；3) 从 loss 函数和数据增强两个方面入手降低属性频率不平衡的影响。不同之处在于：1) 本文提出 FT-FNN 的基于 AlexNet 或 VGG-16，而 ACN 和 DeepMAR 均基于 CaffeNet；2) 本文 FT-FNN 中还加入了手工提取的低层视觉特征。考虑到中层属性中含有大量与颜色相关的属性，我们认为新加入的低层特征能对改善这一部分属性的识别准确率有一定帮助。

#### 4.4 中层属性的优化

现在我们考虑仅用属性向量衡量两个行人之间的相似程度。

记  $I_p, I_g$  为一对图片， $p$  表示待识别图像 (probe)， $g$  为行人库 (gallery) 图像集合。 $x_p, x_g$  为两图片对应的属性向量， $d(I_p, I_g)$  为  $I_p, I_g$  之间的距离。比较简单直接的方法是统计两个属相向量取值不同的属性的个数，即  $x_p, x_g$  差值的 L1 范数

$$d(I_p, I_g) = |x_p - x_g| \quad (4-1)$$

或者计算  $x_p, x_g$  之间的欧氏距离

$$d(I_p, I_g) = \|x_p - x_g\| \quad (4-2)$$

这类方式同等对待向量中的每一维，即所有属性对距离函数所起的作用相等。结合前面的讨论，可以看出这种方式明显不合理。其一，不同属性的区分能力不同；其二，不同属性的预测准确率不同。针对之这点，Ryan 等<sup>[47]</sup>给不同属性赋予了不同的权重：

$$d_w(I_p, I_g) = w^T |x_p - x_g| \quad (4-3)$$

上式中向量  $w$  表示各属性权重

Ryan 等<sup>[47]</sup>设计了如下目标函数

$$ER = \frac{1}{|P|} \sum_{p \in P} \sum_{g \in G} L_w(D_{pp}, D_{pg}) + \lambda \|w - w_0\| \quad (4-4)$$

$D_{pp}$ 表示与  $G$  中匹配图像的距离,  $D_{pg}$ 表示  $p \in P$ 与其不匹配图像  $g$  之间的距离。 $L_w$ 为损失函数。 $w_0$ 为正则偏置项,  $\lambda$ 为调整经验风险正则项之间权重的系数。定义的损失函数 $L_w$ 如下

$$L_w = \frac{1}{1 + e^{d_{pg} - d_{pp}}} \quad (4-5)$$

在初始时令各属性权重相等, 可采用牛顿法或共轭梯度法求解目标函数最小值, 求得较优的 $w$ 。

## 4.5 语义属性与低层特征的融合

对于语义属性向量和低层特征的融合, 本文采用对属性与低层特征 (Low-level feature) 之间按照各自度量方法分别求距离, 再加权求和得到:

$$d_{w^L, w^A}(I_p, I_g) = \sum_{l \in LL} w_l^L d_l^L(L_1(I_p), L_l 1(I_p)) + d_{w^A}^A(A(I_p), A(I_g)) \quad (4-6)$$

上式中  $LL$  为低层特征集合,  $I_p, I_g$ 为待匹配图像与行人库图像,  $w^L, w^A$ 分别为属性的权重和低层特征的权重。 $w^L$ 可参照上节中 $w^A$ 的求得。

## 4.6 本章小结

本章介绍了常见的中层语义属性, 以及中层语义属性具有主观性, 频率分布往往很不平衡; 介绍了本文使用 FT-FFN 预测行人属性的方法。最后介绍了行人属性的优化、与 CNN 特征的融合。

## 第五章 实验结果与分析

### 5.1 数据集及评价方法

本文使用了 PETA 和 RAP 两个行人属性数据集上微调了 FT-FNN 网络，并在 PETA 数据集上检验了本文方法对于中层属性识别的准确率。为了与 FNN 及 FT-CNN 对比，本文在 VIPeR、CUHK01、PRID 450S 上进行了行人重识别实验。下面分别介绍这几个数据集。

#### 5.1.1 PETA 数据集

PETA (PEdesTrian Attribute) 数据集<sup>[46]</sup>由 19000 张图片组成，8705 个行人，分辨率从 17\*39 到 169\*365 不等。每个行人标注了 61 个二元属性和 4 个多类属性，见表 5-1。

表 5-1 PETA 数据集的 61 个二元属性

| 类别   | 属性                                                                                                                                                                                                                                                                                     |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 性别年龄 | personalFemale, personalMale, personalLarger60, personalLess15, Age16-30, Age31-45, Age46-60                                                                                                                                                                                           |
| 穿戴   | accessoryHairBand, accessoryHat, accessoryHeadphone, accessoryKerchief<br>accessoryMuffler, accessoryNothing, accessorySunglasses                                                                                                                                                      |
| 携带物品 | carryingBabyBuggy, carryingBackpack, carryingFolder, carryingLuggageCase,<br>carryingMessengerBag, carryingNothing, carryingOther, carryingPlasticBags,<br>carryingShoppingTro, carryingSuitcase, carryingUmbrella                                                                     |
| 发型   | hairBald, hairLong, hairShort                                                                                                                                                                                                                                                          |
| 上身   | upperBodyCasual, upperBodyFormal, upperBodyJacket, upperBodyLogo,<br>upperBodyLongSleeve, upperBodyNoSleeve, upperBodyOther, upperBodyPlaid,<br>upperBodyShortSleeve, upperBodySuit, upperBodySweater, upperBodyThickStripes,<br>upperBodyThinStripes, upperBodyTshirt, upperBodyVNeck |
| 下身   | lowerBodyCapri, lowerBodyCasual, lowerBodyFormal, lowerBodyHotPants,<br>lowerBodyJeans, lowerBodyLongSkirt, lowerBodyPlaid, lowerBodyShorts,<br>lowerBodyShortSkirt, lowerBodySuits, lowerBodyThinStripes, lowerBodyTrousers                                                           |
| 脚    | footwearBoots, footwearLeatherShoes, footwearSandals, footwearShoes,<br>footwearSneaker, footwearStocking                                                                                                                                                                              |

PETA 数据集的图片采集于 VIPeR、PRID 等 10 个常用的数据集，其比例及样图见图 5-1。

图 5-1 PETA 数据集的构成<sup>[46]</sup>

### 5.1.2 RAP 数据集

RAP (Richly Annotated Pedestrian) 数据集<sup>[44]</sup>是一个用于现实场景中行人属性标注的数据集，它包含 41582 个行人的包括衣着、性别、年龄在内的 92 种属性标记。RAP 数据集属性标注示例见图 5-2，所囊括的 92 种属性见表 5-2。

图 5-2 RAP 属性<sup>[44]</sup>标注示例



表 5-2 RAP 属性集的全部 92 个属性

| 类别    | 属性                                                                                                                                             |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------|
| 性别年龄  | 性别, 年龄 16, 年龄 30, 年龄 45, 角色制服, 体型微胖, 体型标准, 体型偏瘦, 角色顾客, 角色制服                                                                                    |
| 头部    | 发型光头, 发型长发, 头肩黑色头发, 头肩戴帽, 头肩眼镜, 头肩围巾                                                                                                           |
| 衣服款式  | 上衣衬衣, 上衣毛衣, 上衣马甲, 上衣 T 恤, 上衣棉服, 上衣夹克, 上衣西服, 上衣卫衣, 上衣短袖, 下衣长裤, 下衣裙子, 下衣短裙, 下衣连衣裙, 下衣牛仔, 下衣包腿裤                                                   |
| 鞋     | 鞋子类型皮鞋, 鞋子类型运动鞋, 鞋子类型靴子, 鞋子类型布鞋, 鞋子类型休闲鞋                                                                                                       |
| 附属物   | 附属物双肩包, 附属物单肩包, 附属物手提包, 附属物箱子, 附属物塑料袋, 附, 物纸袋, 附属物车, 附属物其他                                                                                     |
| 朝向与遮挡 | 正面, 背面, 面向左侧, 面向右侧, 左侧遮挡, 右侧遮挡, 上部遮挡, 下部遮挡, 遮挡类型环境物, 遮挡类型附属物, 遮挡类型目标, 遮挡类型其他                                                                   |
| 衣服颜色  | 上衣颜色黑, 上衣颜色白, 上衣颜色灰, 上衣颜色红, 上衣颜色绿, 上衣颜色蓝, 上衣颜色黄, 上衣颜色棕, 上衣颜色紫, 上衣颜色粉, 上衣颜色橙, 上衣颜色混色, 下衣颜色黑, 下衣颜色白, 下衣颜色灰, 下衣颜色红, 下衣颜色绿, 下, 衣颜色蓝, 下衣颜色黄, 下衣颜色混色 |

### 5.1.3 VIPeR

VIPeR 数据集由 Gay 等<sup>[20]</sup>收集制作, 是行人重识别中采用最多的数据集。该数据集由不同摄像机拍摄的 632 个行人的 1264 张照片组成, 所有照片的分辨率均为 48\*128。行人的两张照片常常存在光照、姿势、视角、背景等多个方面的变化, 给重识别工作带来了很大的挑战。VIPeR 数据集的图片示例见图 5-3。

图 5-3 VIPeR 数据<sup>[20]</sup>集示例

### 5.1.4 CUHK01

CUHK01 数据集<sup>[49]</sup>包含 971 个行人, 每个行人 4 张不同照片, 共 3884 张行人图片。照片由两个无重叠视域的摄像机拍摄而成, 每个相机对每个行人拍摄两张, 拍摄在校园环境下进行。不同摄像头的照片表现出了较大差异, 其中由摄像头参数造成的原因, 也有因视角、光照、背景、姿势变化等因素造成的。摄像头 B 主要包括行人的正面或背面而 Camera A 视角则多有变化。CUHK01 数据集图片示例见图 5-4。

图 5-4 CUHK01 数据集<sup>[49]</sup>图片示例

### 5.1.5 PRID 450S 数据集

PRID 450S 数据<sup>[50]</sup>是 PRID 2011 数据集中挑选了 450 对行人图片形成的。所有照片



由两个静态、固定、无重叠视域的摄像头拍摄而成，两个摄像头的光照条件有一定差异。每个行人有两张图片，分别由这两个摄像头摄制而成，行人图像从监控视频中剪切出来，图片的分辨率不统一，图像高度在 100 到 150 像素。拍摄地点位于室外的马路上，有较多的人携带背包、公文包等。图片大多从行人的侧面拍摄，成像基本清晰。PRID 450S 数据集的图片示例见图 5-5。




图 5-5 PRID 450s 数据<sup>[50]</sup>集示例

### 5.1.6 评价方法

在行人重识别领域，一般通过比较同一数据集上 Rand-1、Rand-5、Rank-10 等几个特殊 Rank 的上的准确率来衡量不同的重识别方法。Rank-k 表示将行人库中所有图像按照与待匹配图像的相似程度从近到远排列后，正确匹配的图片位于前 k 位。例如 Rank-1 表示正确匹配图片出现在第一位，Rank-5 表示出现在前五位。将各 Rank 作为横轴，Rank-k 下正确图片出现在前 k 位的概率作为纵轴，在坐标系中绘制出来的曲线就是 CMC 曲线。一般来说，Rank-1 准确率越高，CMC 曲线左半边越高，重识别的效果就越好。最理想的情况是所有正确匹配的图片都出现在第一位，此时 Rank-1 准确率为 100%，CMC 曲线为通过 (0, 1) 的水平线。

## 5.2 实验结果与分析

### 5.2.1 中层属性识别实验结果

本文方法与文献方法在 PETA 数据集上的对比如表 5-1 所示。其中第一列为各中层属性的名称，第二列为各属性正例在数据集中所在的比例，第三列 MRFr2 为 Deng 等<sup>[51]</sup>提出的方法，第四、五列 DeepSAR、DeepSAR 为 Li 等<sup>[23]</sup>提出的方法，第六列为本文方法。三至六列的数值为准确率，定义如下

$$\text{准确率} = \frac{\text{正确分类的正例} + \text{正确分类的负例}}{\text{总样本数}} \quad (5-1)$$

PETA 数据集存在许多频率较低、样本不足的属性，这里舍去了部分属性，仅保留文献<sup>[23]</sup>列出的 35 种属性。

基于 AlexNet 的 FT-FFN 在 PETA 数据集上的部分属性准确率见表 5-3。对比 FT-FFN 与 DeepMAR 的识别准确率，FT-FFN 对属性的判断平均要优于 DeepMAR，仅在部分属性低于 DeepMAR。对比 DeepMAR、FT-FFN 与 DeepSAR，可以发现多属性联合学习的平均效果要优于各属性单独训练的 DeepSAR 网络，但是 V-Neck、Logo 等属性例外，原因可能有 1) V-Neck、Logo 与其他属性的关联不强，联合训练属性时收到了其他属性的干扰，造成其准确率较低；2) V-Neck、Logo 都属于频率极低的属性，在加权 loss 函数中被矫正过正。

表 5-3 FT-FFN 在 PETA 数据集上的部分属性准确率（100%）

| Attribute     | Ratio | MRFr <sup>[51]</sup> | DeepSAR <sup>[23]</sup> | DeepMAR <sup>[23]</sup> | FT-FFN |
|---------------|-------|----------------------|-------------------------|-------------------------|--------|
| Age16-30      | 0.497 | 86.8                 | 82.9                    | 85.8                    | 87.3   |
| Age31-45      | 0.329 | 83.1                 | 79.4                    | 81.8                    | 83.0   |
| Age46-60      | 0.102 | 80.1                 | 83.3                    | 86.3                    | 87.6   |
| AgeAbove61    | 0.062 | 93.8                 | 92.0                    | 94.8                    | 95.0   |
| Backpack      | 0.197 | 70.5                 | 78.8                    | 82.6                    | 83.7   |
| CarryingOther | 0.199 | 73.0                 | 73.0                    | 77.3                    | 78.3   |
| Casual lower  | 0.861 | 78.2                 | 81.6                    | 84.9                    | 84.7   |
| Casual upper  | 0.853 | 78.1                 | 81.1                    | 84.4                    | 84.6   |
| Formal lower  | 0.138 | 79.0                 | 81.9                    | 85.2                    | 86.1   |
| Formal upper  | 0.134 | 78.7                 | 81.6                    | 85.1                    | 84.2   |
| Hat           | 0.102 | 90.4                 | 89.2                    | 91.8                    | 93.6   |
| Jacket        | 0.069 | 72.2                 | 77.5                    | 79.2                    | 80.0   |
| Jeans         | 0.306 | 81.0                 | 80.2                    | 85.7                    | 87.9   |
| Leather shoes | 0.296 | 87.2                 | 84.2                    | 87.3                    | 88.1   |
| Logo          | 0.04  | 52.7                 | 76.1                    | 68.4                    | 70.0   |
| Long hair     | 0.238 | 80.1                 | 83.2                    | 88.9                    | 88.9   |
| Male          | 0.549 | 86.5                 | 85.1                    | 89.9                    | 91.3   |
| MessengerBag  | 0.296 | 78.3                 | 77.4                    | 82.0                    | 83.7   |
| Muffler       | 0.084 | 93.7                 | 94.4                    | 96.1                    | 96.8   |
| No accessory  | 0.749 | 82.7                 | 81.5                    | 85.8                    | 85.9   |
| No caryying   | 0.276 | 76.5                 | 78.8                    | 83.1                    | 84.7   |
| Plaid         | 0.027 | 65.2                 | 84.9                    | 81.1                    | 81.9   |
| Plastic bag   | 0.077 | 81.3                 | 82.9                    | 87.0                    | 87.7   |
| Sandals       | 0.020 | 52.2                 | 81.3                    | 67.3                    | 68.3   |
| Shoes         | 0.363 | 78.4                 | 75.8                    | 80.0                    | 80.8   |
| Shorts        | 0.035 | 65.2                 | 81.9                    | 80.4                    | 80.5   |
| ShortSleeve   | 0.142 | 75.8                 | 84.6                    | 87.5                    | 88.9   |
| Skirt         | 0.046 | 69.6                 | 83.2                    | 82.2                    | 82.2   |
| Sneaker       | 0.216 | 75.0                 | 77.3                    | 78.7                    | 80.3   |
| Stripes       | 0.017 | 51.9                 | 72.8                    | 66.5                    | 67.4   |
| Sunglasses    | 0.029 | 53.5                 | 79.1                    | 69.9                    | 69.2   |
| Trousers      | 0.515 | 82.2                 | 78.4                    | 84.3                    | 83.9   |
| Tshirt        | 0.084 | 71.4                 | 80.0                    | 83.0                    | 86.1   |
| UpperOther    | 0.456 | 87.3                 | 83.4                    | 86.1                    | 88.4   |
| V-Neck        | 0.012 | 53.3                 | 75.4                    | 69.8                    | 70.3   |

## 5.2.2 行人重识别实验结果与分析

### 5.2.2.1 VIPeR 数据集实验结果

本文方法在 VIPeR 数据集的结果如表 5-1 所示, 本文八种方法的 CMC 曲线见图 5-5, 表格各列、曲线横纵坐标的含义见 5.1.6 节。表 5-4 中的 FT-FFN 是本文的网络结构, FT-FFN(AlexNet)+XQDA 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法; FT-FFN(VGG)+XQDA 表示以 VGG 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法; FT-FFN(AlexNet)+XQDA+Attrib 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法, 所得到的距离再与属性特征加权相加作为最终度量。FT-FFN(AlexNet)+LOMO+XQDA 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, 将融合特征与 LOMO 特征连接, 再以 XQDA 距离度量方法。

在 VIPeR 数据集上, 与文献中的四种方法相比, FT-FFN 提取的融合特征在再结合 LOMO 特征后, 使用 XQDA 作为距离度量方法, 其表现均明显优于 FNN 方法, 也稍好于 FT-CNN 方法, 说明 FT-FFN 将二者融合能起到改善识别率的效果。对比 FT-FFN(AlexNet)+XQDA 与 FT-FFN(VGG)+XQDA、FT-FFN(AlexNet)+LOMO+XQDA 与 FT-FFN(VGG)+LOMO+XQDA, 可以看出基于 VGG 的方法要略好与基于 AlexNet 的方法, 原因可能是 VGG 较 AlexNet 网络根深, 且 VGG 网络本身在 ImageNet 图片分类数据的 top-5 错误率指标均由于 Alex, 经过 RAP 数据集较大量的数据调整后, VGG 的优势有机会发挥出来。对比添加中层属性的方法与未添加中层属性的方法, 添加了 a 中层属性后性能均有 1%到 3%的性能提升, 说明中层属性对识别率的提升有帮助。

表 5-4 VIPeR 数据集上的结果

| 方法                                          | Rank=1      | Rank=5      | Rank=10     | Rank=20     |
|---------------------------------------------|-------------|-------------|-------------|-------------|
| FT-FFN(AlexNet)+XQDA                        | 43.1        | 72.6        | 83.4        | 91.2        |
| FT-FFN(VGG) + XQDA                          | 44.3        | 73.7        | 84.3        | 92.0        |
| FT-FFN(AlexNet)+XQDA+Attrib                 | 44.8        | 74.8        | 84.5        | 92.2        |
| FT-FFN(VGG)+XQDA+Attrib                     | 46.1        | 75.2        | 85.5        | 92.0        |
| CNN(AlexNet)+XQDA                           | 22.3        | 46.7        | 60.1        | 74.5        |
| CNN(VGG)+XQDA                               | 24.3        | 48.1        | 61.4        | 75.3        |
| FT-FFN(AlexNet) + LOMO+XQDA                 | 51.1        | 79.2        | 89.2        | 94.8        |
| FT-FFN(VGG) + LOMO+XQDA                     | 51.9        | 79.5        | 89.3        | 95.1        |
| FT-FFN(AlexNet) + LOMO+XQDA+Attrib          | 52.0        | 80.0        | <b>89.8</b> | 95.0        |
| FT-FFN(VGG) + LOMO+XQDA+Attrib              | <b>52.7</b> | <b>80.5</b> | 89.5        | 95.1        |
| FT-CNN (Comb.+Multi) + XQDA <sup>[18]</sup> | 42.5        | 72.0        | 83.0        | 92.0        |
| FFN+LOMO+Mirror KMFA <sup>[17]</sup>        | 51.1        | 81.0        | 91.4        | <b>96.9</b> |
| FFN+LOMO+XQDA <sup>[17]</sup>               | 47.8        | 76.7        | 86.7        | 93.6        |
| Improved Deep <sup>[52]</sup>               | 34.8        | 63.6        | 75.6        | 84.5        |




图 5-6 VIPeR 数据集上本文方法的 CMC 曲线比较

## 5.2.2.2 CUHK01 数据集

CUHK01 数据集上的结果见表 5-5, CMC 曲线图见 5-7, 表格各列、曲线横纵坐标的含义见 5.1.6 节。表 5-5 中的 FT-FFN 是本文的网络结构, FT-FFN(AlexNet)+XQDA 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法; FT-FFN(VGG)+XQDA 表示以 VGG 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法; FT-FFN(AlexNet)+XQDA+Attrib 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法, 所得到的距离再与属性特征加权相加作为最终度量。FT-FFN(AlexNet)+LOMO+XQDA 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, 将融合特征与 LOMO 特征连接, 再以 XQDA 距离度量方法。

表 5-5 CUHK01 上的结果

| 方法                                        | R=1  | R=5  | R=10 | R=20 |
|-------------------------------------------|------|------|------|------|
| FT-FFN(AlexNet)+XQDA                      | 48.8 | 73.8 | 81.2 | 89.0 |
| FT-FFN(VGG)+XQDA                          | 49.4 | 74.2 | 81.3 | 89.1 |
| FT-FFN(AlexNet)+XQDA+Attrib               | 51.0 | 74.2 | 82.4 | 90.1 |
| FT-FFN(VGG)+XQDA+Attrib                   | 52.8 | 75.5 | 83.4 | 91.0 |
| CNN(AlexNet)+XQDA                         | 32.4 | 56.2 | 64.2 | 76.0 |
| CNN(VGG)+XQDA                             | 31.2 | 54.3 | 63.9 | 75.8 |
| FT-FFN(AlexNet)+LOMO+XQDA                 | 60.7 | 78.2 | 83.6 | 90.5 |
| FT-FFN(VGG)+LOMO+XQDA                     | 62.1 | 79.6 | 84.4 | 91.0 |
| FT-FFN(AlexNet)+LOMO+XQDA+Attrib          | 61.1 | 78.6 | 83.6 | 90.2 |
| FT-FFN(VGG)+LOMO+XQDA+Attrib              | 63.6 | 80.2 | 85.2 | 91.6 |
| FT-CNN (Comb.+Multi)+XQDA <sup>[18]</sup> | 46.8 | 71.8 | 80.5 | 88.2 |
| FFN+LOMO+Mirror KMFA <sup>[17]</sup>      | 55.5 | 78.4 | 83.7 | 92.6 |
| FFN+LOMO+XQDA <sup>[17]</sup>             | 59.8 | 81.6 | 87.9 | 93.6 |
| Improved Deep <sup>[52]</sup>             | 47.5 | 72.1 | 80.5 | 88.5 |




图 5-7 CUHK01 数据集上不同方法的 CMC 曲线比较

在 CUHK01 数据集上，与文献中的四种方法相比，FT-FFN 提取的融合特征在再结合 LOMO 特征后，使用 XQDA 作为距离度量方法，其表现均明显优于 FNN 方法，也稍好于 FT-CNN 方法，说明 FT-FFN 将二者融合能起到改善识别率的效果。对比 FT-FFN(AlexNet)+XQDA 与 FT-FFN(VGG) + XQDA、FT-FFN(AlexNet) + LOMO+XQDA 与 FT-FFN(VGG) + LOMO+XQDA，可以看出基于 VGG 的方法要略好与基于 AlexNet 的方法，原因可能是 VGG 较 AlexNet 网络根深，且 VGG 网络本身在 ImageNet 图片分类数据的 top-5 错误率指标均由于 Alex，经过 RAP 数据集较大量的数据调整后，VGG 的优势有机会发挥出来。对比添加中层属性的方法与未添加中层属性的方法，添加了 a 中层属性后性能均有 1%到 2%的性能提升，说明中层属性对识别率的提升有帮助。

### 5.2.2.3 PRID450S 数据集

本文方法在 PRID450S 数据集的结果如表 5-6 所示，本文八种方法的 CMC 曲线见图 5-8，表格各列、曲线横纵坐标的含义见 5.1.6 节。表 5-4 中的 FT-FFN 是本文的网络结构，FT-FFN(AlexNet) +XQDA 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络，XQDA 作为 FT-FFN 所提取的融合特征距离度量方法；FT-FFN(VGG)+XQDA 表示以 VGG 作为 FT-FFN 中的 CNN 特征提取网络，XQDA 作为 FT-FFN 所提取的融合特征距离度

量方法; FT-FFN(AlexNet)+XQDA+Attrib 表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, XQDA 作为 FT-FFN 所提取的融合特征距离度量方法, 所得到的距离再与属性特征加权相加作为最终度量。FT-FFN(AlexNet)+LOMO+XQDA 表示表示以 AlexNet 作为 FT-FFN 中的 CNN 特征提取网络, 将融合特征与 LOMO 特征连接, 再以 XQDA 距离度量方法。

表 5-6 PRID450S 上的结果

| 方法                                        | Rank=1 | Rank=5 | Rank=10 | Rank=20 |
|-------------------------------------------|--------|--------|---------|---------|
| FT-FFN(AlexNet)+XQDA                      | 59.2   | 84.5   | 91.0    | 95.2    |
| FT-FFN(VGG)+XQDA                          | 60.4   | 84.8   | 91.2    | 95.5    |
| FT-FFN(AlexNet)+XQDA+Attrib               | 62.3   | 87.3   | 92.4    | 96.0    |
| FT-FFN(VGG)+XQDA+Attrib                   | 65.5   | 88.6   | 93.0    | 97.2    |
| CNN(AlexNet)+XQDA                         | 39.9   | 65.3   | 67.3    | 86.5    |
| CNN(VGG)+XQDA                             | 40.0   | 64.9   | 67.2    | 86.3    |
| FT-FFN(AlexNet)+LOMO+XQDA                 | 70.2   | 89.9   | 94.7    | 97.8    |
| FT-FFN(VGG)+LOMO+XQDA                     | 71.3   | 90.0   | 94.2    | 97.2    |
| FT-FFN(AlexNet)+LOMO+XQDA+Attrib          | 72.4   | 91.0   | 95.0    | 97.6    |
| FT-FFN(VGG)+LOMO+XQDA+Attrib              | 72.6   | 90.8   | 94.8    | 97.5    |
| FT-CNN (Comb.+Multi)+XQDA <sup>[18]</sup> | 58.2   | 83.5   | 90.0    | 94.3    |
| FFN+LOMO+Mirror KMFA <sup>[17]</sup>      | 66.0   | 86.8   | 92.8    | 97.0    |
| FFN+LOMO+XQDA <sup>[17]</sup>             | 68.8   | 88.6   | 93.5    | 97.2    |
| Improved Deep <sup>[52]</sup>             | 34.8   | 63.7   | 76.2    | 81.9    |

在 5.2.2.3PRID450S 上, 与文献中的四种方法相比, FT-FFN 提取的融合特征在再结合 LOMO 特征后, 使用 XQDA 作为距离度量方法, 其表现均明显优于 FNN 方法, 也稍好于 FT-CNN 方法, 说明 FT-FFN 将二者融合能起到改善识别率的效果。对比 FT-FFN(AlexNet)+XQDA 与 FT-FFN(VGG)+XQDA、FT-FFN(AlexNet)+LOMO+XQDA 与 FT-FFN(VGG)+LOMO+XQDA, 可以看出基于 VGG 的方法要略好与基于 AlexNet 的方法, 原因可能是 VGG 较 AlexNet 网络根深, 且 VGG 网络本身在 ImageNet 图片分类数据的 top-5 错误率指标均由于 Alex, 经过 RAP 数据集较大量的数据调整后, VGG 的优势有机会发挥出来。对比添加中层属性的方法与未添加中层属性的方法, 添加了 a 中层属性后性能均有 1%到 2%的性能提升, 说明中层属性对识别率的提升有帮助。






图 5-8 PRID450S 上 CUHK01 数据集上不同方法的 CMC 曲线比较

### 5.3 本章小结

本章介绍了实验所用到的 PETA、RAP 两个中层语义属性数据集, VIPeR、CUHK01、PRID 450 两个中层属性数据集。在 PETA 数据集上的属性识别实验表明 FT-FNN 在属性识别方面的准确性达到了 ACN、DeepDSM 等当前主流属性识别方法, 并在部分属性的准确率上超越了 DeepDSM。在 VIPeR、CUHK01、PRID 数据集上, FT-FFN 提取的融合特征表现出了优良的准确率, FT-FFN+LOMO+XQDA+Attrib 的组合在多个数据集表现效果都为最佳, 充分说明了本文算法的有效性。

## 总结与展望

### 工作总结

行人重识别是指对已经观测到的行人，识别和关联该行人此后在不同摄像机下拍摄到的所有图片的过程。行人重识别技术是智能视频监控领域重要的研究分支，是进一步进行多摄像头追踪、行人行为分析等的基础。本文梳理了行人重识别技术研究的发展简史，介绍了特征描述、距离度量两个方面的若干关键技术，总结了几年来行人重识别技术上的进展和趋势，着重介绍了若干描述子和距离度量方法。在总结分析目前各类研究成果的基础上，结合了 FFN 和 FT-CNN 两种网络的优点提出了 FT-FFN，利用从 FT-FFN 网络提取的深度特征及属性特征改进了行人重识别的准确率。本文的主要贡献如下：

(1) 提出了可产生良好 CNN 特征的 FT-FFN 网络。FT-FFN 在结构上保留 FFN 网络的特点，同时对原始图像提取 CNN 特征和低层视觉特征，两个特征通过一个全连接层融合，该层称为融合层。在反向传播、更新权值过程中低层特征会影响 CNN 网络权值，促使 CNN 网络部分学习到与低层视觉特征互补的特征。在训练上 FT-FFN 吸收了 FT-FFN 网络的成果，通过训练行人属性而非行人标记，微调行人属性训练微调的 FT-FFN 产生的 CNN 描述子对行人重识别问题具有优良的区分能力。

(2) 提出的 FT-FFN 网络在行人属性标注方面具有良好的准确性。FT-FFN 网络内包含一个经 ImageNet 预训练的 AlexNet 或 VGG-16，这类 ImageNet 具有不错的泛化能力，同时 FT-FFN 还有低层的颜色纹理特征作为补充。FT-FFN 在经行人属性数据集微调后，在行人属性识别方面表现出了与该领域当前主流方法相当甚至稍好的准确率。

(3) 分析总结了目前常用的中层语义属性，将 FT-FFN 网络输出的属性特征与 FT-FFN 网络提取的融合特征相结合，并证明中层语义属性能在一定程度上提高行人重识别的准确率。

### 工作展望

行人重识别相关的期刊、会议今年来快速上涨，行人重识别逐渐成为计算机视觉领域中一个热门研究课题。深度学习自 2014 年第一次引入到行人重识别领域以来，现在已在行人重识别的研究中占据了重要地位。越来越多的工作是基深度网络学习到的 CNN 特征。尽管本文的方法表现出一定的优势，但仍然待完善之处。以下几处还需要进一步探讨和完善：

1) 本文在中层属性的识别中采用多属性联合识别的方式,这种方式对属性识别的准确率平均高于每个属性逐个训练的方式,但是其中有个别属性反常。其原因还需要进一步的探讨:是由于这些属性频率在训练样本中偏低还是在训练过程中受到其他属性的干扰?。

2) FT-FNN 框架中的低层视觉特征提取部分、CNN 特征提取部分可以替换为其他种类的手工特征或是其他结构的网络。可以进一步尝试使用 LOMO 等手工特征替换 ELFCaffeNet 替换 AlexNet 等,寻找最优的组合。

3) 本文的中层属性和低层特征的融合方式是在距离度量时对二者分别计算距离,然后加权相加。这种方式虽然具有一般性,中层属性和低层特征实际相互独立,这一点需要进一步寻找更佳的融合方案。

## 参考文献

- [1] 新华网. 广州政府部门“晒”预算 投一亿搞视频监控  
[EB/OL].[http://news.xinhuanet.com/politics/2017-02/14/c\\_1120466745\\_2.htm](http://news.xinhuanet.com/politics/2017-02/14/c_1120466745_2.htm). 2017/2017-02-14.
- [2] Zheng L, Yang Y, Hauptmann A G. Person Re-identification: Past, Present and Future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [3] Zajdel W, Zivkovic Z, Krose B J A. Keeping Track of Humans: Have I Seen This Person Before?[C]. IEEE International Conference on Robotics and Automation. IEEE, 2005:2081-2086.
- [4] Gong S, Cristani M, Yan S, et al. Person Re-Identification[M]. Springer London, 2014: 301-313.
- [5] Gheissari N, Sebastian T B, Hartley R. Person Reidentification Using Spatiotemporal Appearance[C]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2006:1528-1535..
- [6] Bazzani L, Cristani M, Perina A, et al. Multiple-Shot Person Re-identification by HPE Signature[C]. International Conference on Pattern Recognition. IEEE Computer Society, 2010:1413-1416.
- [7] Layne R, Hospedales T M, Gong S. Person Re-identification by Attributes[C]. British Machine Vision Conference. 2012
- [8] Yi D, Lei Z, Liao S, et al. Deep Metric Learning for Person Re-identification[C]. International Conference on Pattern Recognition. IEEE, 2014:34-39.
- [9] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C]. Computer Vision and Pattern Recognition. IEEE, 2010:2360-2367.
- [10] Ma B, Su Y, Jurie F. Covariance descriptor based on bio-inspired features for person re-identification and face verification[J]. Image & Vision Computing, 2014, 32(6 - 7):379-390.
- [11] Munaro M, Fossati A, Basso A, et al. One-Shot Person Re-identification with a Consumer Depth Camera[M] Person Re-Identification. 2014:161-181..
- [12] Wang X, Zhao C, Miao D, et al. Fusion of multiple channel features for person re-identification[J]. Neurocomputing. 2016, 213: 125-136.
- [13] Weinberger K Q, Blitzer J, Saul L K. Distance Metric Learning for Large Margin Nearest Neighbor Classification[C].NIPS. 2005.207-244
- [14] Hirzer M. Large scale metric learning from equivalence constraints[C].Computer Vision and Pattern Recognition. 2012.2288-2295
- [15] Bromley J, Bentz J W, Bottou L, et al. Signature Verification Using A “SIAMESE” TIME DELAY NEURAL NETWORK[J]. International Journal of Pattern Recognition & Artificial Intelligence. 1993, 7(04): 669-688.
- [16] Ding S, Lin L, Wang G, et al. Deep Feature Learning with Relative Distance Comparison for Person Re-identification[J]. Pattern Recognition. 2015, 48(10): 2993-3003.
- [17] Wu S, Chen Y C, Li X, et al. An enhanced Deep Feature Representation for Person Re-identification[C].Applications of Computer Vision. 2016.1-8
- [18] Matsukawa T, Suzuki E. Person Re-Identification Using CNN Features Learned from Combination of

- Attributes[C]. International Conference on Pattern Recognition .2016:2430- 2434
- [19] Liao S, Hu Y, Zhu X, et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C].IEEE Conference on Computer Vision and Pattern Recognition. 2015.2197-2206
- [20] Gray D, Tao H. Viewpoint Invariant Pedestrian Recognition with an Ensemble of Localized Features[C]// Computer Vision - ECCV 2008, European Conference on Computer Vision, Marseille, France, October 12-18, 2008, Proceedings. DBLP, 2008:262-275..
- [21] Li A, Liu L, Wang K, et al. Clothing Attributes Assisted Person Reidentification[J]. IEEE Transactions on Circuits & Systems for Video Technology. 2015, 25(5): 869-878.
- [22] Yu K, Leng B, Zhang Z, et al. Weakly-supervised Learning of Mid-level Features for Pedestrian Attribute Recognition and Localization[J]. arXiv preprint arXiv:1611.05603, 2016.
- [23] Li D, Chen X, Huang K. Multi-attribute learning for pedestrian attribute recognition in surveillance scenarios[C].Pattern Recognition (ACPR), 2015 3rd IAPR Asian Conference on. IEEE, 2015: 111-115.
- [24] 丘宇辉. 基于度量学习和稀疏表示的行人重识别技术研究[D]. 华南理工大学, 2015.
- [25] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 2197-2206.
- [26] Hubel D H, Wiesel T N. Receptive fields and functional architecture of monkey striate cortex[J]. Journal of Physiology. 1968, 195(1): 215-243.
- [27] Haykin S, Kosko B. GradientBased Learning Applied to Document Recognition[D]. Wiley-IEEE Press, 2009.
- [28] Andrew Ng J N C Y. 2013/2013-04-07.[http://ufldl.stanford.edu/wiki/index.php/Softmax\\_Regression](http://ufldl.stanford.edu/wiki/index.php/Softmax_Regression)
- [29] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation. 2006, 18(7): 1527-1554.
- [30] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. Nature. 2015, 521(7553): 436-444.
- [31] Xiao T, Li H, Ouyang W, et al. Learning deep feature representations with domain guided dropout for person re-identification[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 1249-1258..
- [32] Azizpour H, Razavian A, Sullivan J, et al. Factors of Transferability for a Generic ConvNet Representation.[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence. 2015, 38(9): 1790-1802.
- [33] Sharif Razavian A, Azizpour H, Sullivan J, et al. CNN features off-the-shelf: an astounding baseline for recognition[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2014: 806-813.
- [34] Donahue J, Jia Y, Vinyals O, et al. DeCAF: A Deep Convolutional Activation Feature for Generic Visual Recognition[J]. Computer Science. 2013, 50(1): 815-830.
- [35] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C].Advances in neural information processing systems. 2012: 1097-1105.
- [36] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J].

- arXiv preprint arXiv:1409.1556, 2014.
- [37] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 1-9..
- [38] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C].Computer Vision and Pattern Recognition. 2016.770-778
- [39] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C].International Conference on Neural Information Processing Systems. 2012.1097-1105
- [40] Zheng W S, Gong S, Xiang T. Person re-identification by probabilistic relative distance comparison[C].The IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2011, Colorado Springs, Co, Usa, 20-25 June. 2011.649-656
- [41] Zheng W S, Gong S, Xiang T. Reidentification by Relative Distance Comparison[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence. 2013, 35(3): 653.
- [42] Oquab M, Bottou L, Laptev I, et al. Learning and Transferring Mid-level Image Representations Using Convolutional Neural Networks[C].Computer Vision and Pattern Recognition. 2014.1717-1724
- [43] Chatfield K, Simonyan K, Vedaldi A, et al. Return of the Devil in the Details: Delving Deep into Convolutional Nets[J]. Computer Science. 2014.
- [44] Li D, Zhang Z, Chen X, et al. A richly annotated dataset for pedestrian attribute recognition[J]. arXiv preprint arXiv:1603.07054, 2016.
- [45] Jia, Yangqing, Shelhamer, et al. Caffe: Convolutional Architecture for Fast Feature Embedding[J]. Eprint Arxiv. 2014: 675-678.
- [46] Deng Y, Luo P, Chen C L, et al. Pedestrian Attribute Recognition At Far Distance[C].the ACM International Conference. 2014.789-792
- [47] Layne R, Hospedales T M, Gong S. Attributes-Based Re-identification[M]. Springer London, 2014: 93-117.
- [48] Sudowe P, Spitzer H, Leibe B. Person Attribute Recognition with a Jointly-Trained Holistic CNN Model[C].IEEE International Conference on Computer Vision Workshop. 2015.329-337
- [49] Li W, Zhao R, Wang X. Human reidentification with transferred metric learning[C].Asian Conference on Computer Vision. 2012.31-44
- [50] Roth P M, Hirzer M, Köstinger M, et al. Mahalanobis Distance Learning for Person Re-identification[J]. 2014: 247-267.
- [51] Deng Y, Luo P, Chen C L, et al. Learning to Recognize Pedestrian Attribute[J]. Computer Science. 2015.
- [52] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C].Computer Vision and Pattern Recognition. 2015.3908-3916

## 读博士/硕士学位期间取得的研究成果

一、已发表（包括已接受待发表）的论文，以及已投稿、或已成文打算投稿、或拟成文投稿的论文

情况（只填写与学位论文内容相关的部分）：

| 序号 | 作者（全体作者，按顺序排列） | 题 目 | 发表或投稿刊物名称、级别 | 发表的卷期、年月、页码 | 相当于学位论文的哪一部分（章、节） | 被索引收录情况 |
|----|----------------|-----|--------------|-------------|-------------------|---------|
|    |                |     |              |             |                   |         |
|    |                |     |              |             |                   |         |
|    |                |     |              |             |                   |         |
|    |                |     |              |             |                   |         |
|    |                |     |              |             |                   |         |

注：在“发表的卷期、年月、页码”栏：

1 如果论文已发表，请填写发表的卷期、年月、页码；

2 如果论文已被接受，填写将要发表的卷期、年月；

3 以上都不是，请据实填写“已投稿”，“拟投稿”。

不够请另加页。

二、与学位内容相关的其它成果（包括专利、著作、获奖项目等）

1、发明专利（已受理），一种用于视频监控场景中行人重识别的方法，张见威，邱隆庆，林文钊，201710403300.8

## 致谢

在华南理工大学的求学生涯已近尾声，回首过往的近三年时间，是我人生中学识、能力等各方面都有成长和提升的三年。这三年里，我当初从对图像视频、计算机视觉一知所知，到现在对自己的研究领域有了较为全面的了解，同时伴随着学术、工程等多方面等多方面能力的成长。值此论文完成之际，再次向一直以来给予关心与帮助的导师同学和家人表示由衷的感谢。

首先感谢我的导师张见威副教授。在学术方面，张老师治学严谨，学识渊博，对待工作认真负责，是我们学习的榜样；在生活方面，张老师为人随和，对我们的学习生活方面都给予了母亲般的关心和关怀，使我们感到温暖。本文从开题、写稿到反复修改润色、最后成文，都离不开张老师的指导和帮助。您在学术上的建议、指导和教诲，在生活中的关心、包容，都将成为我受用终身的宝贵财富和美好回忆。

同时感谢实验室的同学们，感谢你们陪我度过的美好时光。感谢丘宇辉、朱林、胡振鹏、何小臻师兄等师兄们的在学习、工作方面的建议和帮助。感谢与我一同进入的周子健、林文钊、刘红成、陈海潮等同学们，感谢你们一路陪伴和共同成长。感谢温春霞、赵菁、钟佳琪、何君婷、吴炫奇、林思浩等师弟师妹们，他们给实验室带来许多活力与朝气。

另外还要感谢我们父母和家人们，感谢他们在背后默默地付出，感谢女友这三四年来的陪伴与支持，有了你们的支持和支撑，使得我能没有后顾之忧，顺利完成学业。最后，向在百忙之中抽出时间批评审阅本文的专家、教授致以谢意。



#### IV - 2 答辩委员会对论文的评定意见

邱隆庆同学的硕士论文“基于特征学习的行人重识别研究”有较好的理论意义和应用价值。

论文参照了较多的相关文献资料，提出了一种行人重识算法。主要地，设计了一个用于提取特征的深度网络 FT-FFN (Fine-tuning Feature Fusion Network)，将 CNN 特征与底层视觉特征融合在一起，同时借助训练识别行人属性的微调，提高融合层输出特征的区分能力。在 PETA 数据集上进行了中层语义属性的实验和测试，通过实验测试，表明 FT-FFN 对中层语义属性的判断较为准确，取得了较好的实验效果。

作者对文献的调研、数据的收集较充分，论文资料丰富，论点正确，结论合理，实验数据真实可信。反映作者具有较强的理论基础、较好的科研和工程能力。

论文结构清晰，图文表达规范，达到硕士学位论文水平。答辩过程讲述较清楚，回答问题基本正确。经答辩委员会无记名投票，同意该同学通过硕士论文答辩，同意授予硕士学位。

论文答辩日期：2017 年 6 月 5 日


答辩委员会委员共 5 人，到会委员 5 人

表决票数：优秀 (0) 票；良好 (5) 票；及格 (0) 票；不及格 (0) 票

表决结果 (打“√”)：优秀 ( )；良好 (√)；及格 ( )；不及格 ( )

决议：同意授予硕士学位 (√) 不同意授予硕士学位 ( )

答辩  
委员  
会成  
员签  
名

 (主席)

