



工程硕士专业学位论文

基于特征融合的行人重识别方法研究  
Person Re-identification Based on Feature  
Fusion

作 者：谭玉莹  
导 师：张国鹏 教授

中国矿业大学

二〇二〇年六月

中图分类号 TP183

学校代码 10290

UDC 004

密 级 公开

**中国矿业大学**  
**硕士学位论文**

**基于特征融合的行人重识别方法研究**  
**Person Re-identification Based on Feature Fusion**

作 者 谭玉莹

导 师 张国鹏

申请学位 工程硕士专业学位

培养单位 计算机科学与技术学院

学科专业 软件工程

研究方向 计算机视觉

答辩委员会主席 曹天杰

评 阅 人 盲评

二〇二〇年六月

## 致谢

时光荏苒，研究生两年转瞬即逝。拿到录取通知书的雀跃还近在眼前，如今已迎来了对毕业的期盼。值此之际，向研究生阶段给予我莫大帮助的老师、同学和家人表达感谢。

首先要感谢我的导师张国鹏教授，张老师的努力与严谨深刻地影响了我。犹记得每天晚上回宿舍时老师的车还停在学院楼下，撰写开题报告时老师帮我逐字逐句地推敲，张老师对待学术的热忱、对待文字的严谨、对待学生的负责无不令我钦佩与敬仰，感谢老师为实验室营造了良好的学习环境和积极的学习氛围。还要感谢的是同课题组的周世斌老师，感谢周老师对论文选题和论文修改的指导，以及求职方向和就业单位的建议。论文修改过程中，周老师反复审阅，精心点拨，使我得以顺利完成论文。为师，点拨迷津，让人醍醐灌顶；为长，关怀备至，让人感念至深。衷心祝愿两位老师生活幸福美满，科研再攀高峰。

其次，要感谢我的实验室同学、舍友以及我的朋友们。感谢师兄师姐两年来的照顾和指导，感谢同门在我不能返校期间对答辩事宜的协助，谢谢你们让实验室变得像家一样温暖；感谢舍友两年来在生活中的关照，一路走来从你们身上学到了许多；感谢因打乒乓球结缘的朋友们，有的陪伴我走过了求职的道路，有的在论文修改中给予了莫大的帮助，非常幸运在研究生阶段结识到你们。

最后，感谢我的父母和奋战在抗疫前线的英雄们。感谢父母在我求学过程中的支持，父母的爱使我勇敢且坚定。感谢疫情期间坚守一线的医务工作者和行政人员，是你们的奉献守护了后方的我们。

## 摘要

行人重识别问题是一个跨摄像机的行人检索问题,即给定一个需要查找的行人,识别该行人是否出现在另一个摄像机的监控记录中。在保障公共安全的实际需求下,随着公园、街道等场所监控摄像机数量的不断增加,行人重识别技术在智能监控系统中的应用势在必行。然而,由于不同摄像机拍摄的图像在背景、光照、姿态和分辨率等方面存在很大差异,行人的特征提取面临着巨大的挑战。此外,行人图像中普遍存在的遮挡问题也增加了行人重识别的难度。因此,提取鲁棒的特征描述子并设计合适的判别方法就成为了解决行人重识别问题的关键。近年来,深度学习的方法不断应用于行人重识别领域中并取得了良好的效果,极大地推动了行人重识别技术的进步。现有的大量深度学习方法都属于有监督学习的方法,需要对大规模已标记的数据集进行学习。而现有的行人重识别数据集规模较小,难以模拟现实场景,大规模的数据标注又需要耗费大量的人力资源。因此,为了降低数据标注的成本,提高行人重识别方法在实际场景中的可用性和可扩展性,基于无监督的行人重识别方法也成为了这一领域的一大研究方向。针对上述问题,本文进行了以下研究:

1) 提出了一种基于图像-空间特征融合的有监督行人重识别方法。首先,根据图像特征提取空间特征,定位图像中的行人,然后通过融合图像特征和空间特征,让模型更多地关注图像中的前景行人而非杂乱背景,解决了背景杂乱的问题。其次,将融合后的特征水平均分为若干个局部特征,分别对每个局部特征进行行人身份的判别,解决了行人遮挡问题。接下来,利用局部特征训练分类损失,利用全局特征训练三元组损失,最终提出了一个由分类损失和三元组损失加权组成的目标函数。该方法可以训练出更具判别性的特征,有效提高了行人检索的效果。

2) 提出了一种基于局部特征融合的无监督行人重识别方法。针对无监督下的度量学习问题,提出了一种新的基于无监督的三元组损失。对每个训练样本,通过图像的剪裁、亮度调节等随机变换生成难正样本,通过提出的难负样本挖掘算法挖掘难负样本。该损失不受限于网络结构和研究领域,是一个适用于无监督学习的度量学习方法。同时,该损失应用在融合局部特征的网络结构中,该网络利用局部特征的优化挖掘了图像中的细粒度信息,有效提高了无监督场景下行人重识别的性能,解决了手动标记数据成本高的问题,提高了行人重识别方法在实际场景中的应用能力。

该论文有图 16 幅,表 21 个,参考文献 78 篇。

**关键词:** 行人重识别; 特征融合; 无监督学习; 三元组损失; 局部特征

# Abstract

Person Re-identification (Re-ID) is a cross-camera pedestrian retrieval problem. It is a kind of technology that determines whether there is a specific pedestrian in the surveillance record of another camera. With the actual demand for ensuring public safety and the increasing number of surveillance cameras in parks, streets and other places, it is necessary to apply Person Re-ID technology in the intelligent surveillance system. However, since the images captured by different cameras are really different in background, lighting, posture, and resolution, the task of Person re-identification is facing great challenges. In addition, the common occlusion problem in pedestrian images also increases the difficulty of pedestrian retrieval. Therefore, the keys to solve these problems of Person Re-ID are to extract robust feature representation and design appropriate discriminant methods. In recent years, deep learning methods have been widely used in Person Re-ID and achieved good results, which has greatly promoted the progress of Person Re-ID technology. A large number of existing deep learning methods are supervised learning methods, which need large-scale labeled datasets. However, the existing datasets of Person Re-ID are small in scale, which makes it difficult to simulate the real scene. Moreover, large amounts of data annotation require a lot of human resources. Therefore, in order to reduce the cost of data annotation and improve the usability and scalability of Person Re-ID in the actual scene, the research of unsupervised Person Re-ID is also a major direction of Person Re-identification research in the future. In response to the above issues, the following researches have been carried out in this paper:

1) A supervised Person Re-identification method based on image-space feature fusion is proposed. Firstly, spatial features are extracted from the image features to locate the pedestrians in the image. Then, by fusing image features and spatial features, the model pays more attention to the foreground pedestrians in the image rather than the cluttered background. Secondly, the fused features are divided into several local features horizontally, and each of them is discriminated separately to solve the pedestrian occlusion problem. Next, the local features are used to train the classification loss, and the global features are used to train the triplet loss. Finally, an objective function composed of the classification loss and the triplet loss is proposed. This method can extract more discriminative features and effectively improves the performance of pedestrian retrieval.

2) An unsupervised Person Re-identification method based on local feature fusion is proposed. In order to solve the problem of unsupervised metric learning, a new unsupervised triple loss is proposed. For each training sample, a hard positive is generated by random transformation such as image cropping or brightness adjustment, and a hard negative is mined by the proposed hard negative mining algorithm. The loss is not limited to network structures or the fields of research, it is a metric learning method suitable for unsupervised learning. At the same time, the loss is applied to a network structure that fuses local features. This network uses the optimization of local features to mine fine-grained information in images, which effectively improves the performance of Person Re-ID in unsupervised scenarios. The method reduces the high cost of manual data labeling, and improves the practicability of person re-identification method in the actual scene.

The paper has 16 pictures, 21 tables, and 78 references.

**Keywords:** Person Re-identification; Feature Fusion; Unsupervised Learning; Triplet Loss; Local Features

# 目 录

|                                      |           |
|--------------------------------------|-----------|
| 摘 要.....                             | I         |
| 目 录.....                             | IV        |
| 图清单.....                             | VIII      |
| 表清单.....                             | IX        |
| 变量注释表 .....                          | XI        |
| <b>1 绪论.....</b>                     | <b>1</b>  |
| 1.1 研究背景及意义.....                     | 1         |
| 1.2 国内外研究现状.....                     | 2         |
| 1.3 本文主要工作.....                      | 4         |
| 1.4 论文组织结构.....                      | 5         |
| <b>2 相关工作 .....</b>                  | <b>7</b>  |
| 2.1 有监督的行人重识别.....                   | 7         |
| 2.2 无监督的行人重识别.....                   | 9         |
| 2.3 残差网络.....                        | 10        |
| 2.4 数据集和评价指标.....                    | 13        |
| 2.5 本章小结.....                        | 17        |
| <b>3 基于图像-空间特征融合的有监督行人重识别方法.....</b> | <b>18</b> |
| 3.1 方法概述.....                        | 18        |
| 3.2 基于图像-空间特征融合的网络模型 .....           | 19        |
| 3.3 实验结果及分析.....                     | 24        |
| 3.4 本章小结.....                        | 28        |
| <b>4 基于局部特征融合的无监督行人重识别方法 .....</b>   | <b>30</b> |
| 4.1 方法概述.....                        | 30        |
| 4.2 基于无监督的三元组损失函数.....               | 31        |
| 4.3 基于局部特征融合的网络模型.....               | 34        |
| 4.4 实验结果及分析.....                     | 37        |
| 4.5 本章小结.....                        | 40        |
| <b>5 总结与展望 .....</b>                 | <b>41</b> |
| 5.1 总结.....                          | 41        |
| 5.2 未来工作的展望.....                     | 41        |

|                 |    |
|-----------------|----|
| 参考文献 .....      | 43 |
| 作者简介 .....      | 50 |
| 学位论文原创性声明 ..... | 51 |
| 学位论文数据集 .....   | 52 |



# Contents

|                                                                                      |             |
|--------------------------------------------------------------------------------------|-------------|
| <b>Abstract .....</b>                                                                | <b>II</b>   |
| <b>Contents .....</b>                                                                | <b>VI</b>   |
| <b>List of Figures.....</b>                                                          | <b>VIII</b> |
| <b>List of Tables.....</b>                                                           | <b>IX</b>   |
| <b>List of Variables.....</b>                                                        | <b>XI</b>   |
| <b>1 Introduction.....</b>                                                           | <b>1</b>    |
| 1.1 Background and Significance .....                                                | 1           |
| 1.2 Research Status at Home and Abroad .....                                         | 2           |
| 1.3 Major Works of Thesis.....                                                       | 4           |
| 1.4 Organization.....                                                                | 5           |
| <b>2 Related Work.....</b>                                                           | <b>7</b>    |
| 2.1 Supervised Person Re-identification.....                                         | 7           |
| 2.2 Unsupervised Person Re-identification.....                                       | 9           |
| 2.3 Residual Network.....                                                            | 10          |
| 2.4 Datasets and Evaluation Metrics.....                                             | 13          |
| 2.5 Summary .....                                                                    | 17          |
| <b>3 Supervised Person Re-identification Based on Image-Space Feature Fusion ...</b> | <b>18</b>   |
| 3.1 Method Overview .....                                                            | 18          |
| 3.2 Network Based on Image-Space Feature Fusion .....                                | 19          |
| 3.3 Experimental Results and Analysis.....                                           | 24          |
| 3.4 Summary .....                                                                    | 28          |
| <b>4 Unsupervised Person Re-identification Based on Local Feature Fusion .....</b>   | <b>30</b>   |
| 4.1 Method Overview .....                                                            | 30          |
| 4.2 Unsupervised Triplet Loss .....                                                  | 31          |
| 4.3 Network Based on Local Feature Fusion.....                                       | 34          |
| 4.4 Experimental Results and Analysis.....                                           | 37          |
| 4.5 Summary .....                                                                    | 40          |
| <b>5 Summary and Future Work.....</b>                                                | <b>41</b>   |
| 5.1 Conclusion .....                                                                 | 41          |

|                                               |           |
|-----------------------------------------------|-----------|
| 5.2 Prospects for Future Work .....           | 41        |
| <b>References.....</b>                        | <b>43</b> |
| <b>Author's Resume.....</b>                   | <b>50</b> |
| <b>Declaration of Thesis Originality.....</b> | <b>51</b> |
| <b>Thesis Data Collection .....</b>           | <b>52</b> |

# 图清单

| 图序号        | 图名称                                    | 页码 |
|------------|----------------------------------------|----|
| 图 1-1      | 行人检索结果                                 | 2  |
| Figure 1-1 | Pedestrian search results              | 2  |
| 图 1-2      | 行人重识别系统                                | 3  |
| Figure 1-2 | Person Re-identification system        | 3  |
| 图 2-1      | 深度网络的退化问题                              | 10 |
| Figure 2-1 | Degradation problem in deep networks   | 10 |
| 图 2-2      | 残差学习                                   | 11 |
| Figure 2-2 | Residual learning                      | 11 |
| 图 2-3      | 两种构建块                                  | 13 |
| Figure 2-3 | Two kinds of building blocks           | 13 |
| 图 2-4      | 数据集行人图片示例                              | 13 |
| Figure 2-4 | Person images in datasets              | 13 |
| 图 2-5      | 累积匹配特征曲线                               | 15 |
| Figure 2-5 | Cumulative match characteristics curve | 15 |
| 图 3-1      | 基于图像-空间特征融合的行人重识别网络示意图                 | 19 |
| Figure 3-1 | An illustration of the ISFNet          | 19 |
| 图 3-2      | 特征融合                                   | 20 |
| Figure 3-2 | Feature fusion                         | 20 |
| 图 3-3      | 特征融合模块添加位置                             | 21 |
| Figure 3-3 | Location of feature fusion module      | 21 |
| 图 3-4      | 行人遮挡问题                                 | 22 |
| Figure 3-4 | Pedestrian occlusion problem           | 22 |
| 图 3-5      | 身份预测器                                  | 22 |
| Figure 3-5 | ID predictor                           | 22 |
| 图 4-1      | 三元组损失                                  | 31 |
| Figure 4-1 | Triplet Loss                           | 31 |
| 图 4-2      | 基于局部特征融合的行人重识别网络示意图                    | 34 |
| Figure 4-2 | An illustration of the LFNet           | 34 |
| 图 4-3      | 局部特征提取                                 | 35 |
| Figure 4-3 | Extraction of local features           | 35 |
| 图 4-4      | 局部特征优化                                 | 36 |
| Figure 4-4 | Optimization of local features         | 36 |

## 表清单

| 表序号        | 表名称                                                              | 页码 |
|------------|------------------------------------------------------------------|----|
| 表 2-1      | Resnet 体系结构                                                      | 12 |
| Table 2-1  | Architectures of Resnet                                          | 12 |
| 表 2-2      | 查询结果排序                                                           | 15 |
| Table 2-2  | Sort of query results                                            | 15 |
| 表 2-3      | 准确率和召回率的计算                                                       | 16 |
| Table 2-3  | The calculation of accuracy and recall                           | 16 |
| 表 3-1      | Market1501 数据集上人工特征方法的性能比较(%)                                    | 25 |
| Table 3-1  | Performance (%) Comparison on Market-1501 (Handcrafted Feature)  | 25 |
| 表 3-2      | DukeMTMC 数据集上人工特征方法的性能比较(%)                                      | 25 |
| Table 3-2  | Performance (%) comparison on DukeMTMC (Handcrafted Feature)     | 25 |
| 表 3-3      | Market1501 数据集上全局特征方法的性能比较(%)                                    | 25 |
| Table 3-3  | Performance (%) comparison on Market-1501 (Global Feature)       | 25 |
| 表 3-4      | DukeMTMC 数据集上全局特征方法的性能比较(%)                                      | 26 |
| Table 3-4  | Performance (%) comparison on DukeMTMC (Global Feature)          | 26 |
| 表 3-5      | Market1501 数据集上局部特征方法的性能比较(%)                                    | 26 |
| Table 3-5  | Performance (%) comparison on Market-1501 (Local Feature)        | 26 |
| 表 3-6      | DukeMTMC 数据集上局部特征方法的性能比较(%)                                      | 26 |
| Table 3-6  | Performance (%) comparison on DukeMTMC (Local Feature)           | 26 |
| 表 3-7      | Market1501 数据集上注意力机制方法的性能比较(%)                                   | 27 |
| Table 3-7  | Performance (%) comparison on Market-1501 (Attention Mechanisms) | 27 |
| 表 3-8      | DukeMTMC 数据集上注意力机制方法的性能比较(%)                                     | 27 |
| Table 3-8  | Performance (%) comparison on DukeMTMC (Attention Mechanisms)    | 27 |
| 表 3-9      | MSMT17 数据集上的性能比较(%)                                              | 27 |
| Table 3-9  | Performance (%) comparison on MSMT17                             | 27 |
| 表 3-10     | Market1501 数据集上的消融实验 (ISFNet)                                    | 28 |
| Table 3-10 | Ablation Study on Market-1501 (ISFNet)                           | 28 |
| 表 3-11     | 不同损失的权重分析                                                        | 28 |
| Table 3-11 | Analysis on the weight of different losses                       | 28 |
| 表 4-1      | Market1501 数据集上人工方法的性能比较(%)                                      | 38 |
| Table 4-1  | Performance (%) comparison on Market-1501 (Handcrafted Methods)  | 38 |
| 表 4-2      | DukeMTMC 数据集上人工方法的性能比较(%)                                        | 38 |
| Table 4-2  | Performance (%) comparison on DukeMTMC (Handcrafted Methods)     | 38 |
| 表 4-3      | Market1501 数据集上聚类方法的性能比较(%)                                      | 39 |
| Table 4-3  | Performance (%) comparison on Market-1501 (Clustering)           | 39 |
| 表 4-4      | DukeMTMC 数据集上聚类方法的性能比较(%)                                        | 39 |
| Table 4-4  | Performance (%) comparison on DukeMTMC (Clustering)              | 39 |
| 表 4-5      | Market1501 数据集上无监督域自适应方法的性能比较(%)                                 | 39 |

|           |                                                 |    |
|-----------|-------------------------------------------------|----|
| Table 4-5 | Performance (%) comparison on Market-1501 (UDA) | 39 |
| 表 4-6     | DukeMTMC 数据集上无监督域自适应方法的性能比较(%)                  | 39 |
| Table 4-6 | Performance (%) comparison on DukeMTMC (UDA)    | 39 |
| 表 4-7     | Market1501 数据集上的消融实验 (LFNet)                    | 40 |
| Table 4-7 | Ablation Study on Market-1501 (LFNet)           | 40 |

## 变量注释表

|                      |                           |
|----------------------|---------------------------|
| $\mathbf{F}$         | 图像特征                      |
| $\mathbf{F}_{avg}$   | 图像平均池化特征                  |
| $\mathbf{F}_{max}$   | 图像最大池化特征                  |
| $\mathbf{F}_s$       | 空间特征                      |
| $\mathbf{F}'_m$      | 第 $m$ 个局部特征               |
| $m$                  | 局部特征分支数目                  |
| $P$                  | 抽样行人数                     |
| $K$                  | 每个行人抽样的图像张数               |
| $N$                  | 小批量样本数                    |
| $C$                  | 行人总数                      |
| $\lambda_1$          | 分类损失权重系数                  |
| $\lambda_2$          | 三元组损失权重系数                 |
| $\mathbf{x}_i$       | 锚点样本 (Anchor)             |
| $\mathbf{x}_i^+$     | 正样本                       |
| $\mathbf{x}_i^-$     | 负样本                       |
| $\mathbf{R}_i^{N-1}$ | $\mathbf{x}_i$ 的相似度正序列表   |
| $\mathbf{x}_j$       | $\mathbf{R}_i^{N-1}$ 中的样本 |
| $\mathbf{R}_j^{N-1}$ | $\mathbf{x}_j$ 的相似度正序列表   |
| $\theta$             | 仿射变换矩阵                    |

# 1 绪论

## 1 Introduction

### 1.1 研究背景及意义 (Background and Significance)

随着城市基础设施的逐步完善，人们对生活质量的要求不断提高，大量人口流向城市，中国城镇化进入高速增长期。2019 年，我国规模城市总数量居世界首位，城镇人口数量占比高达 60%。然而，由于现阶段城市规划发展不够合理，城市综合承载能力有限，快速的人口膨胀也给城市带来了极大的人口压力，进而引起了交通拥堵、环境污染、公共安全受威胁等一系列问题。其中，由于公众安防意识的逐渐增强，公共安全问题近几年越来越受到人们的重视，催生出平安城市、智慧城市等政策，促进了我国安防产业的快速发展。2018 年，中国安防市场行业总产值达到 7183 亿元，全年市场增长率为 15.86%<sup>[1]</sup>。

在安防行业中，随着科技地不断进步，监控摄像机的生产成本逐渐降低。为了更好地维护社会治安，保障人民生命财产安全，视频监控系统逐渐得到普及，在城市的路口、机场、商场、医院等场所均有所应用。通过视频监控系统，相关部门可以获取突发性异常事件的视频、音频等数据，及时地监视或回访，第一时间进行有效的指挥和警力部署。但是，视频监控系统的广泛应用在带来便利的同时，也产生了大量的监控数据。这些监控数据有效信息密度低，数小时的视频数据中，关键信息可能仅占几秒钟，人工处理难以保证准确性和实时性。因此，凭借人工处理数量庞大的监控数据，效率低下且需要耗费大量的人力资源。为了提高视频监控系统的智能化和自动化水平，行人重识别 (Person Re-identification, ReID) 技术<sup>[2]</sup>应运而生。

行人重识别也称行人再识别，旨在跨摄像机检索行人，是判断图像或视频序列中是否存在特定行人的技术。如图 1-1 所示，给定一张待查询图像，行人重识别方法可以检索出该行人在其他摄像头下的图像（蓝色框表示检索成功，红色框表示检索失败）。该技术可以作为人脸识别技术的重要补充，对无法获取清晰人脸图像的行人进行跨摄像头连续跟踪，增强数据的时空连续性<sup>[3]</sup>。由于其在安保和监控中的重要作用，行人重识别一直受到学术界和工业界的广泛关注。然而，不同于人脸识别，行人重识别技术距离应用到现实场景还有一定的差距。首先，现有图像本身质量较差。由于国内还没有大规模安装高清摄像机且行人和摄像机的距离通常较远，摄像机记录下来的行人图像普遍不清晰。其次，摄像机视角的不同、行人姿势的变化、光照条件的不同、行人存在遮挡等问题也极大地影响了行人的识别。此外，现有的行人重识别数据集规模相对较小，不足以模拟现实场景，而大规模数据的标注需要耗费大量的人力资源，这增加了该技术应用到现实

场景的难度。




图 1-1 行人检索结果

Figure 1-1 Pedestrian search results

针对上述问题，深度学习被引入到行人重识别方法的研究中，并取得了重大的进展。通过端到端的自主学习，深度学习在行人重识别工作中取得了良好的效果。然而，现有的大多数行人重识别方法基于有监督学习，需要大量已标记数据集，这限制了它在实际应用场景中的可用性和可扩展性。为了解决这一问题，近期一些相关工作把注意力放在了无监督学习上，通过改进人工特征和聚类算法来提高行人重识别方法的可扩展性。最新的基于无监督学习的行人重识别方法利用迁移学习从已标记数据集中获取信息。但是，由于不同数据集之间的图像差别很大，这些方法在迁移学习时仍然表现不佳。如何在无监督学习的基础上有效提高行人重识别性能，是未来行人重识别方法研究的一大方向。

综上所述，对于提升城市公共安全、构建智慧城市，行人重识别技术有着不容忽视的市场应用前景。但是，不同于人脸识别和目标检测等其他计算机视觉技术，由于现有数据集的匮乏，行人重识别技术的落地仍然具有较高的难度和复杂性。因此，行人重识别技术未来仍将是计算机视觉领域中一个既具实用价值又充满挑战性的研究课题，具有极高的研究价值。

## 1.2 国内外研究现状（Research Status at Home and Abroad）

行人重识别技术最早起源于多目标跟踪，后来逐渐发展为一个较为独立的研究领域。2005 年，Zajdel 等人<sup>[4]</sup>首次在多目标跨摄像头跟踪的工作中提出“行人重识别”术语。2006 年，行人重识别任务首次和跨摄像头跟踪任务分开，开始作为独立的研究领域<sup>[5]</sup>。2014 年以后，随着深度学习在图像分类任务上的广泛应用<sup>[6]</sup>，行人重识别的研究数量剧增，在重要会议和期刊上出现了大量学术论文。



行人重识别分为特征提取和度量学习两个阶段，如图 1-2 所示<sup>[7]</sup>。传统的行人重识别研究将特征提取和度量学习独立开来，针对某一模块进行优化。而基于深度学习的行人重识别则将特征提取和度量学习视为一个整体，协同优化两大模块。下面分别介绍传统的行人重识别方法和基于深度学习的行人重识别方法。




图 1-2 行人重识别系统

Figure 1-2 Person Re-identification system

### 1.2.1 传统的行人重识别方法

在深度学习方法主导行人重识别领域之前，人工提取特征的方式是特征提取的主要方法，常见特征包括颜色特征、纹理特征、形状特征和关键点等。例如，Gray 和 Tao<sup>[8]</sup>将行人图像分成若干水平条纹，提取了颜色和纹理特征。Gheissari 等人<sup>[5]</sup>将行人图像划分为若干三角形，提取了局部特征。Cheng 等人<sup>[9]</sup>根据图像结构将行人分解为若干语义部分，利用了语义信息。同样地，Dalal 等人<sup>[10]</sup>应用 HSV (Hue, Saturation, Value) 直方图在头部、躯干和腿部捕获空间信息。LOMO (Local Maximal Occurrence)<sup>[11]</sup>是目前综合性能较好的人工特征，它是廖胜才等人 2015 年在 CVPR 上提出的，弱化了光照、视角和分辨率的影响，同时兼顾了特征提取的效率和行人重识别准确率，超过了同年大部分基于深度学习的方法。

在度量学习 (Metric Learning) 方法上，2002 年，Xing 等人<sup>[12]</sup>首次提出了以马氏距离为基础的度量学习算法，成就了度量学习的经典开山之作。在行人重识别领域，Weinberger 等人提出了大间隔最近邻居 (Large Margin Nearest Neighbor, LMNN)<sup>[13]</sup>算法，该算法首次使用三元约束，使异类样本的距离大于同类样本的距离。2012 年，Koestinger 等人提出了保持简单和直接的度量学习 (Keep It Simple and Straightforward Metric Learning, KISSME)<sup>[14]</sup>算法，通过计算样本对属于相似样本对和不相似样本对的概率的比值来表示两个样本间的距离，摒弃了繁琐的迭代优化过程，提高了计算速度。三年后，廖胜才等人又提出了交叉视图二次判别分析 (Cross-view Quadratic Discriminant Analysis, XQDA)<sup>[11]</sup>算法，该算法是对 KISSME 算法在多场景下的推广，联合学习样本对应的低维子空间和距离度量函数，保留了行人的判别性信息。

### 1.2.2 基于深度学习的行人重识别方法

在数据量较大的情况下,传统的人工特征描述能力有限,使用传统的度量学习方法求解也非常困难,因此行人重识别技术很难适应具有庞大数据量的现实场景。为了解决上述问题,深度学习的方法在行人重识别研究上得到了广泛的应用。深度学习端到端的特性,直接将输入映射为相应的输出,协同优化特征提取和度量学习两个模块,极大地简化了行人重识别方法的研究。目前,基于深度学习的行人重识别方法在性能上已经远远超过传统的人工方法,大量相关研究工作也基于深度学习展开。

深度学习方法下的行人特征主要通过卷积神经网络(Convolutional Neural Network, CNN)<sup>[15]</sup>提取。2014年, Li 等人提出了一种新颖的滤波器配对神经网络(Filter Pairing Neural Network, FPNN)<sup>[16]</sup>,以行人的两张图像为输入,通过FPNN得到联合输出,一定程度上解决了图像中行人不对齐、光照变化、行人被遮挡等问题。同年, Yi 等人<sup>[17]</sup>首次使用孪生网络(Siamese Network)<sup>[18]</sup>研究行人重识别问题,该方法将行人图像分为水平的三个部分,分别进行卷积和池化操作,并将处理后的特征融合为最终特征。该方法可以在统一的框架中同时学习颜色特征、纹理特征和特征度量。次年, Ahmed 等人<sup>[19]</sup>对 FPNN 进行了改进,加入了跨输入邻域差值(Cross-Input Neighborhood Differences)层和图像块差异累加(Patch Summary Features)层,使网络能够更有效地比较特征,减少视角和姿态变化的干扰。此后,随着深度学习的蓬勃发展,基于特征提取的行人重识别研究也迎来了热潮。

深度学习的发展同样带来了度量方法的变革。度量学习旨在将行人特征映射到嵌入空间(Embedding Space)中,使同一行人的图像特征间的距离更近,不同行人的图像特征间的距离更远。2016年, Cheng 等人提出了行人重识别领域中最常用的度量学习方法:三元组损失(Triplet Loss)<sup>[20]</sup>,即给定锚点样本(Anchor)、正样本(Positive)和负样本(Negative),三元组损失会强制正样本与锚点样本间的距离小于负样本与锚点样本间的距离。为了提高普通三元组损失的效果, Hermans 等人提出了难样本挖掘(Hard Sample Mining)的三元组损失<sup>[21]</sup>,不再以随机方式挑选正负样本,而是挑选一个训练批次中与固定图片特征距离较大的正样本和与特征距离较小的负样本。此外, Chen 等人<sup>[22]</sup>还提出了一个四元组损失函数,其中每个四元组包含一个锚点样本,一个正样本和两个难负样本,优化四元组关系会能保持较小的类内差异和较大的类间差异。

### 1.3 本文主要工作(Major Works of Thesis)

由于摄像机视角和分辨率的不同、光照变化、行人姿态变化、行人遮挡等问

题的存在，行人特征的提取和判别面临着巨大的挑战。同时，现有的行人重识别数据集规模难以模拟现实场景，而大规模的数据标注需要耗费大量的人力资源。针对上述问题，本文分别提出了基于特征融合的有监督和无监督方法，具体贡献如下：

1) 提出了一种基于图像-空间特征融合的有监督行人重识别方法。首先，根据卷积处理的行人图像特征提取空间特征，学习图像中的行人位置，再通过图像特征和空间特征的融合解决了背景杂乱的问题。接下来，将融合后的特征水平平均分为若干个局部特征，分别对每个局部特征进行行人身份的判别。最后，提出了由分类损失和三元组损失加权融合的损失函数，利用局部特征训练分类损失，利用全局特征训练三元组损失。既有效改善了行人遮挡问题，又避免了视角过于局限造成的干扰。

2) 提出了一种基于局部特征融合而无监督行人重识别方法。在提取特征时，将卷积处理后的行人特征分为三个局部特征：头部特征、上肢特征和下肢特征，然后通过空间采样器对局部特征进行优化，屏蔽了局部特征中的背景信息。最终，融合优化的局部特征作为行人的特征描述子，挖掘了行人图像中的细粒度信息。在度量学习方面，提出了一种基于无监督学习的三元组损失，通过图像的剪裁、亮度调节等随机变换生成难正样本，通过提出的难负样本挖掘算法挖掘同一训练批次中的难负样本，解决了现有无监督聚类方法依赖于网络结构的问题。

## 1.4 论文组织结构 (Organization)

本文共划分为五个章节，各章节内容组织如下：

第1章：绪论。本章首先阐述了行人重识别技术的研究背景和意义，从有监督学习和无监督学习两个方面回顾了行人重识别领域在国内外的研究现状，并针对现有行人重识别方法存在的不足提出了本文的主要工作，最后对论文的组织结构进行了说明。

第2章：相关工作。本章首先回顾了现有的行人重识别方法，并简要介绍了本文提出方法与现有方法的不同。此外，为了便于理解后文提出的行人重识别方法，本章还简要介绍了残差网络的结构和思想。最终介绍了行人重识别领域常用的数据集和评价指标。

第3章：基于图像-空间特征融合的有监督行人重识别方法。本章首先介绍了融合图像-空间特征的行人重识别网络结构，其中详细阐述了特征融合方法、身份预测器构成以及多损失融合方法。然后对实验的设置和实验结果进行了说明和分析。

第4章：基于局部特征融合而无监督行人重识别方法。本章首先根据有监督学习下的三元组损失，对提出的基于无监督学习的三元组损失进行了说明。接下

来,从局部特征提取、局部特征优化、特征融合三个模块介绍了基于局部特征融合的网络模型。最终对实验的设置和实验结果进行了说明和分析。

第 5 章:总结与展望。本章对全文进行了一个简要概括,总结了本文的研究成果和主要贡献,并提出了一些不足之处,对未来的研究方向进行了规划和展望。

## 2 相关工作

## 2 Related Work

### 2.1 有监督的行人重识别 (Supervised Person Re-identification)

目前大部分的行人重识别研究都采用有监督学习的方法。通过设计或改进卷积神经网络,基于监督学习的行人重识别方法可以利用图像的标签信息训练网络从而得到一个最优模型。现有相关工作大部分基于深度学习展开,而基于深度学习的有监督方法可以大致分为五类:基于全局特征的方法,基于局部特征的方法,基于注意力机制的方法、基于生成对抗网络(Generative Adversarial Networks, GAN)<sup>[23]</sup>的方法以及基于视频序列的方法,具体内容如下:

1) 基于全局特征的方法。全局特征表征学习是为每个行人的整张图像提取一个特征向量,早期将深度学习方法应用到行人重识别领域时,全局特征是首要选择。为了提取全局特征中的细粒度线索,Wu 等人<sup>[24]</sup>提出了 PersonNet,使用小型卷积滤波器捕获行人图像中的细粒度线索。Wang 等人<sup>[25]</sup>提出了一种由单图像表征(Single-image Representation, SIR)和交叉图像表征(Cross-image Representation, CIR)组成的联合学习框架,利用特定的子网络对三元组损失进行训练。郑良等人<sup>[26]</sup>提出了一种身份识别嵌入(ID-discriminative Embedding, IDE)模型,通过把每个身份作为一个不同的类,将行人重识别问题看作一个多类分类问题。

2) 基于局部特征的方法。局部特征是从图像的局部区域中提取的特征,包括角点、线和特别属性的区域等。基于局部特征的行人重识别方法包括语义分区和水平分区两种局部分区方式。

语义分区指依据语义上有意义的身体部位分区,例如头部、四肢、躯干等,从而提供一致的身体部位特征。Li 等人提出了一种改进的特殊卷积神经网络 Spindle Net<sup>[27]</sup>,利用人体的 14 个关键点信息提取 7 个区域特征(Region of Interest, ROI),再将这些区域特征与行人的全局特征在不同尺度下联结,得到最终的特征表示。Zhao 等人<sup>[28]</sup>提出了一种基于姿势驱动的深卷积(Pose-driven Deep Convolutional, PDC)模型,利用身体部位的信息进行学习,解决了姿势变化问题。相似地,注意力感知合成网络(Attention-Aware Compositional Network, AACN)<sup>[29]</sup>开发了一种姿势引导的局部注意力模块(Pose-guided Part Attention, PPA),屏蔽了不需要的背景特征,以及一种注意感知特征组合模块(Attention-aware Feature Composition, AFC),对局部特征进行聚合。

基于水平分区的方法使用均匀分区来获得水平部分,该方法比较灵活,不需要额外的姿势信息,但也因此对混乱的背景较为敏感。对于没有姿态估计的水平区域特征,Varior 等人<sup>[30]</sup>引入了长短期记忆网络(Long Short-Term Memory, LSTM)来自适应地聚合水平区域特征,利用上下文信息对图像区域进行顺序处理,提高局部特征的可判别性。郑良等人提出了 PCB 网络<sup>[31]</sup>,将图像水平分为六个部分并针对每个局部特征进行分类。在此基础上,作者还提出了一种精炼的部分池化(RPP)方法,将每个局部特征中的异常值重新分配到它们最接近的局部特征中,达到增强内部一致性的效果。

3) 基于注意力机制的方法。注意力机制可以帮助网络关注更关键的信息。例如,为了学习背景无关的行人特征,Song 等人<sup>[32]</sup>提出了一种基于分割轮廓图的对比注意模型(Mask-guided Contrastive Attention Model, MGCAM),将二值化的行人分割轮廓图作为附加输入,与彩色图像结合成新的四通道输入。HA-CNN<sup>[33]</sup>结合软注意力方法和硬注意力方法,除了获得硬注意力区域外,还依赖于通道注意力和空间注意力,是对先前的硬注意力的补充。Liu 等人<sup>[34]</sup>设计了一种新的基于结果匹配的特征软校正方案,提出了一种对比注意力网络(Comparative Attention Network, CAN),这种新的软注意模型可以在比较部分图像后,有选择地聚焦于图像中行人的部分。

4) 基于生成对抗网络的方法。基于生成对抗网络的方法可以通过风格转换、图像增强等操作增加训练数据的变化。Zhu 等人提出的 CycleGAN<sup>[35]</sup>将图像从源域转换到目标域,实现了图像的风格转移、目标变形、季节转移、照片增强等。PTGAN(Person Transfer GAN)<sup>[36]</sup>使用前景分割网络,在保证行人前景不变的前提下将背景转换成期望的数据集风格。Qian 等人<sup>[37]</sup>提出的姿态归一化生成对抗网络(Pose-normalization GAN, PNGAN)用于生成身份一致、姿态可控的姿态归一化图像,实现了行人姿态的迁移从而解决了行人姿态的偏差。

5) 基于视频序列的方法。视频序列不仅包含单帧图像的信息,还包含视频序列的运动信息。一种典型的基于视频序列的网络模型是累计运动背景网络(Accumulative Motion Context Network, AMOC)<sup>[38]</sup>,该网络利用原始图像序列和光流序列,提取一个融合了内容信息和运动信息的特征。此类研究的另一个代表方法是 DFPG(Deep Feature Guided Pooling)<sup>[39]</sup>,它先使用网络提取每一帧的特征,再通过平均池化得到序列的平均特征。Zhou 等人<sup>[40]</sup>还提出了一种时间注意力模型,用于自动选择给定视频中最具判别性的帧,并将上下文信息与空间模型相结合。

与郑良等人提出的方法不同,本文提出的基于特征融合的有监督方法没有采用精炼的部分池化(RPP)方法,而是在 PCB 水平分区的基础上,添加了特征

融合模块和多损失融合模块。特征融合模块融合了空间特征和图像特征，弱化了背景信息，解决了 PCB 网络中水平分区对混乱背景敏感的问题。多损失融合模块利用局部特征训练分类损失，利用全局特征训练三元组损失，并将两个损失的加权和作为最终的损失函数。在采用局部特征判别行人的同时，利用全局特征从整体上辨别不同的行人，从整体和局部两方面联合训练网络的判别能力。

## 2.2 无监督的行人重识别 (Unsupervised Person Re-identification)

监督学习方法依赖于大量已标记的训练数据，而手动标记数据需要耗费大量的人力资源，这限制了监督学习方法的可扩展性和实用性。而基于无监督学习的行人重识别方法不需要已标注的行人数据集，因此具有极大的研究意义。现有的无监督方法可以大致分为基于人工特征的方法，基于聚类的方法以及基于无监督域自适应 (Unsupervised Domain Adaptation, UDA)<sup>[41]</sup>的方法，具体内容如下。

1) 基于人工特征的方法。尽管人工制定的外观特征可以直接应用于行人重识别方法，但由于设计视图不变的特征非常具有挑战性，因此性能通常较差。Peng 等人<sup>[42]</sup>基于字典学习方法，将每张行人图像都映射到一个共享空间中，得到这个行人的特征，再进行重识别。

2) 基于聚类的方法。Fan 等人<sup>[43]</sup>提出了一种渐进式无监督学习 (Progressive Unsupervised Learning, PUL) 方法，在行人聚类 and 卷积神经网络的部分卷积层之间迭代，改进了在不相关标记数据集上训练的初始化模型。Yu 等人<sup>[44]</sup>提出了一种基于非对称 K 均值聚类的无监督不对称距离度量学习方法，以实现视图不变性。

3) 基于无监督域自适应的方法。得益于深度学习的发展，近期一些工作试图解决基于深度学习的无监督域自适应问题。Deng 等人<sup>[45]</sup>通过提出的相似性保留生成对抗网络 (Similarity Preserving Generative Adversarial Network, SPGAN) 将图像从源域转换为目标域，转换后的图像以有监督的方式训练行人重识别模型。Zhong 等人<sup>[46]</sup>引入异质学习 (Hetero-Homogeneous Learning, HHL) 方法，通过同时实现相机不变性和域连通性来提高行人重识别模型在目标数据集上的泛化能力。

与基于无监督域自适应的行人重识别方法相比，本文提出的方法从目标域的局部特征出发，屏蔽了目标域中行人图像的背景信息，挖掘了行人本身的细粒度信息。此外，本文提出了一种基于无监督的三元组损失，该损失是对传统三元组损失的改进，是一个适用于无监督领域的通用损失函数，可以单独应用到其他网络结构中。

## 2.3 残差网络 (Residual Network)

上述大量的行人重识别方法均以残差网络作为骨干网络 (Backbone) 进行改良, 本文所提出的网络模型也基于残差网络展开。因此, 为了更好地介绍下文提出的方法, 本节对残差网络的原理和结构进行简要说明。

由于深度学习方法端到端的简洁特性以及在高层视觉任务中取得的良好性能, 深度学习被广泛应用于行人重识别任务中。深度神经网络以端到端的多层次的方式提取了低、中、高层次的特征, 网络的深度越高, 堆叠的层数越多, 特征的级别就越高。而高层次的特征通常包含更高级的语义信息, 因此研究人员会倾向于使用更深层的网络结构。

然而, 随着网络深度的增加, 训练会变得更加困难。因为在基于梯度下降法的深度网络的训练过程中, 误差信号的多层传播容易产生梯度消失或梯度爆炸现象。为了解决这个问题, 研究人员提出了一些特殊的权重初始化方法和批规范化方法, 这些方法帮助网络能够正常的训练。但是, 如图 2-1 所示, 随着网络深度的继续增加, 数据的训练误差和测试误差没有降低反而升高了。这并不是由过拟合引起的, 而是在适当深度的网络模型上添加了更多层网络导致的, 这就是网络的退化现象。




图 2-1 深度网络的退化问题

Figure 2-1 Degradation problem in deep networks

针对这一问题, 微软研究院的何恺明等四名华人提出了一种残差网络 (Residual Neural Network, ResNet) <sup>[47]</sup>, 通过训练目标的转换, 缓解了深度神经网络中增加深度时带来的退化问题。

### 2.3.1 深度残差学习

当网络直接进行简单的堆叠时, 网络层数会迅速增多, 而网络内部的特征在其中某一层已经达到了最佳状态, 此时剩下的层就不应该对特征再做出任何改变。残差网络的核心就是提出这样一个恒等快捷连接 (Identity Shortcut Connection) 的结构, 跳过一个层或多层, 直接输出所输入的特征。

在前向传播中, 恒等快捷连接仅执行身份映射, 其输出被添加到堆叠层的输



出中。这种连接方式既不会增加额外的参数，也不会增加计算复杂性，并且实现了一开始的目的：当浅层的输出已经达到最佳状态时，深层网络后面的层能够实现恒等映射（Identity Mapping）的作用。具体来说，在残差学习中，将一个浅层网络的输出复制加给深层网络的输出，当网络特征达到最优化时，更深层恒等映射的任务就从原来堆叠的层中释放到新建的恒等映射关系中，而原来层中的任务会趋向于自动学习成 0。

如图 2-2 所示，假如把  $H(\mathbf{x})$  看作是几个堆叠层（不一定是整个网络）的底层输出， $\mathbf{x}$  表示这些层中第一层的输入。在传统网络中，网络的输入是  $\mathbf{x}$ ，网络的输出就是  $H(\mathbf{x}) = F(\mathbf{x})$ ，网络的训练目标是  $F(\mathbf{x})$  本身。而在残差网络中，网络的输入是  $\mathbf{x}$ ，网络的输出是  $H(\mathbf{x}) = F(\mathbf{x}) + \mathbf{x}$ ，网络的训练目标是  $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$ ，由此得名残差网络。在残差网络中，当浅层的  $\mathbf{x}$  代表的特征已经足够成熟，任何对于特征  $\mathbf{x}$  的改变都会让损失变大，则  $F(\mathbf{x})$  会趋向于自动学习成 0，而  $\mathbf{x}$  则从恒等映射的路径继续传递。训练目标选择  $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$  而不是  $H(\mathbf{x}) = F(\mathbf{x}) + \mathbf{x}$  是因为两种形式表达的效果相同，但是优化的难度却并不相同。当特征达到最佳状态时， $H(\mathbf{x})$  仍需要拟合到一个确切的数值，而  $F(\mathbf{x})$  仅需要拟合为 0，因此  $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$  的优化会比  $H(\mathbf{x}) = F(\mathbf{x}) + \mathbf{x}$  简单的多。




图 2-2 残差学习

Figure 2-2 Residual learning

从另一个角度看，在反向传播中，残差模块会明显减小堆叠层参数的值，使网络参数对反向传导的损失值更敏感地响应。虽然没有从根本上解决回传损失小的问题，但是却通过让参数减小相对增加了回传损失的效果。例如，假设网络的输入  $\mathbf{x} = 10$ ，网络的底层输出  $H(\mathbf{x}) = \mathbf{W} \cdot \mathbf{x} = 11$ ，标签的真实值为 12，反向传播的损失为 1。传统网络中  $F(\mathbf{x}) = H(\mathbf{x}) = 11$ ，参数从 1.1 到 1.2；而残差网络中  $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x} = 1$ ，参数从 0.1 到 0.2，可以看出残差网络中输出的变化对

权重的调整作用更大，所以效果更好。同时，恒等映射的支路的存在也为反向传播过程中梯度的传导提供了更简便的路径，仅仅经过一个 ReLU 就可以把梯度传达给上一个模块。

因此，残差学习通过改变信息前向和后向传播的方式，很好地解决了退化问题，并在很大程度上促进了网络的优化。在不给网络增加额外参数和计算量的前提下，大大增加了网络模型的训练速度，提高了训练效果。此外，整个网络仍然可以通过随机梯度下降法（Stochastic Gradient Descent, SGD）反向传播进行端到端训练，并且可以使用通用库（如 Pytorch）轻松实现。

### 2.3.2 残差网络结构

残差网络中不同网络是以网络层数命名的，表 2-1 罗列了 5 种深度的残差网络，由左到右分别是 18 层、34 层、50 层、101 层和 152 层。每种网络又分成 5 部分，分别是：conv1，conv2\_x，conv3\_x，conv4\_x，conv5\_x。其中，第一部分是一个 7×7 的卷积层，第二部分包括池化层和堆叠的残差模块，第三至第四部分则仅由堆叠的残差模块组成。

表 2-1 Resnet 体系结构

Table 2-1 Architectures of Resnet

| layer   | Resnet-18                                                                   | Resnet-34                                                                   | Resnet-50                                                                                       | Resnet-101                                                                                       | Resnet-152                                                                                       |
|---------|-----------------------------------------------------------------------------|-----------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| conv1   | 7×7, 64, 步长 2                                                               |                                                                             |                                                                                                 |                                                                                                  |                                                                                                  |
|         | 3×3 最大池化, 步长 2                                                              |                                                                             |                                                                                                 |                                                                                                  |                                                                                                  |
| conv2_x | $\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$   | $\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$   | $\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$    | $\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$     | $\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$     |
| conv3_x | $\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$ | $\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$  | $\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$   | $\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$   |
| conv4_x | $\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$ | $\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$ | $\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$ | $\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$ |
| conv5_x | $\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$ | $\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$ | $\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$  | $\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$  |
|         | 平均池化, 全连接层, softmax 层                                                       |                                                                             |                                                                                                 |                                                                                                  |                                                                                                  |

在残差网络中残差模块分为两种，一种是以两个 3×3 的卷积层串接在一起的 basic 型残差模块，见图 2-3（a），另外一种是由 1×1、3×3、1×1 的 3 个卷积层串接在一起的 bottleneck 型残差模块，见图 2-3（b）。Resnet-18 和 Resnet-34 使用 basic 型残差模块，因为此时网络较浅，不太需要考虑模型的效率，而当网络加深到 50、101、152 层时则引入 bottleneck 型残差模块，方便模型的存储和计算。

具体来说，basic 型残差模块叠加两个 64 通道的 3×3 卷积，输入输出均为 64 通道，可直接相加。bottleneck 型残差模块叠加了三个卷积层，第一个 1×1 的卷

积将 256 维通道降到 64 维通道, 最后一个  $1 \times 1$  卷积将 64 维通道恢复为 256 维通道。这种结构在保证模型精度的情况下, 降低了网络模型的参数量, 进而缩小了整个模型训练所需的时间。




图 2-3 两种构建块

Figure 2-3 Two kinds of building blocks

## 2.4 数据集和评价指标 (Datasets and Evaluation Metrics)

### 2.4.1 数据集

深度学习的发展离不开大规模的数据集, 卷积神经网络的优化同样需要使用大量训练数据。行人重识别方法从传统的人工提取特征到如今利用深度学习自动提取特征, 其间离不开相关数据集的发展。行人重识别领域发展至今也产生了大量数据集, 本文在三个常用数据集上进行实验, 分别是 Market-1501<sup>[48]</sup>、DukeMTMC-reID<sup>[49]</sup>和 MSMT17<sup>[36]</sup>, 行人图片如图 2-4 所示。



图 2-4 数据集行人图片示例

Figure 2-4 Person images in datasets

从图中可以看出, 行人重识别数据集由从监控视频帧中检测到的单个行人的

图片组成。数据集中的行人边界框可由人工绘制、可变形局部模型（Deformable Parts Model, DPM）<sup>[50]</sup>检测或 Faster R-CNN<sup>[51]</sup>检测得到。对检测出的图片人工标注后，行人重识别数据集被划分为训练集和测试集，其中测试集又分为查询集（Query）和图库集（Gallery）。在测试过程中，从查询集中选择待查图片，在图库集中查询与它具有相同身份的行人图片。

Market1501 数据集是在清华大学校园中采集的，总共使用了 6 个摄像机，其中包括 5 个高清摄像机和 1 个低清摄像机。在 Market1501 数据集中，训练集包含 751 个行人的 12936 张图像，测试集包含其他 750 人的图像，具体分为查询集的 3368 张图像和图库集的 19732 张图像。查询集中的行人边界框是人工绘制得到的，而图库集中的行人边界框则是由 DPM 检测器检测得到的。

DukeMTMC-reID 数据集是 DukeMTMC 数据集的行人重识别子集，它的边界框是由人工绘制的。该数据集包含由 8 个摄像机拍摄的 1812 个行人的 36411 张图像，其中只有 1404 个行人出现在两个以上的摄像机下，其他 408 个行人被视为干扰项。训练集包含 702 个行人的 16522 张图像，而测试集包含 702 个行人的 2228 张查询图像和 17661 张图库图像。此外，该数据集还提供了行人属性（性别、长短袖、是否背包等）的标注。

MSMT17 数据集是目前为止规模最大的图像数据集，它采用了 12 个室外摄像机和 3 个室内摄像机，在校园里对一个月内不同天气的 4 天进行采集。该数据集每天收集上午、中午、下午三个不同光照程度下的视频，并利用 Faster RCNN 进行行人检测。在 MSMT17 数据集中，训练集包含 1041 个行人的 32621 张图片，测试集包括 3060 个行人的 11659 张查询图片和 82161 张图库图片。

## 2.4.2 评价指标

在评估行人重识别方法的性能时，累积匹配特征（Cumulative Match Characteristics, CMC）曲线<sup>[52]</sup>和平均准确度均值（mean Average Precision, mAP）<sup>[48]</sup>是两种广泛使用的评价指标。

### 1) 累积匹配特征曲线

CMC 曲线是模式识别系统（人脸、指纹、虹膜识别系统等）的重要评价指标，在生物特征识别系统中能够综合评价出算法的好坏。如图 2-5 所示，该曲线的横坐标为 Rank，纵坐标为识别率。

在行人重识别任务中，CMC 曲线的具体含义为：在图库集中检索查询集中的行人图像，前 k 个检索结果中包含正确匹配结果的比例。例如，在行人重识别查询集中有三个待查询图像，标签分别为 m1、m2、m3，将其依次与图库集中的行人图像比对后，将返回结果按相似度从高到低排序（sort1-10），如表 2-2 所示。




图 2-5 累积匹配特征曲线

Figure 2-5 Cumulative match characteristics curve

表 2-2 查询结果排序

Table 2-2 Sort of query results

| 标签        | sort1     | sort2     | sort3     | sort4 | sort5 | sort6 | sort7 | sort8 | sort9 | sort10 |
|-----------|-----------|-----------|-----------|-------|-------|-------|-------|-------|-------|--------|
| <b>m1</b> | <b>m1</b> | m2        | m3        | m4    | m5    | m6    | m7    | m8    | m9    | m10    |
| <b>m2</b> | m1        | <b>m2</b> | m3        | m4    | m5    | m6    | m7    | m8    | m9    | m10    |
| <b>m3</b> | m1        | m2        | <b>m3</b> | m4    | m5    | m6    | m7    | m8    | m9    | m10    |

在单张行人图像查询时，rank-k 表示识别结果中最靠前（最相似）的 k 张图像中是否存在与查询图像身份相同的图像。例如，当待查询图像的标签为 m1 时，rank-1 的正确率为 100%，rank-2 和 rank-3 的正确率也为 100%。当待查询图像的标签为 m2 时，rank-1 的正确率为 0%、rank-2 的正确率为 100%、rank-3 的正确率也为 100%。当待查询图像的标签为 m3 时，rank-1 的正确率为 0%、rank-2 的正确率也为 0%、rank-3 的正确率为 100%。

而当待识别的行人图像有很多时，CMC 曲线就是计算 top-k 的命中概率，即查询集所有图像的前 k 个匹配中，正确匹配的 rank-k 数目占总的查询图像数的比例。根据表中识别结果，累计匹配特征的计算结果如公式（2-1）所示。

$$\begin{aligned}
 \text{top} - 1 &= (1 + 0 + 0) / 3 = 33.33\% \\
 \text{top} - 2 &= (1 + 1 + 0) / 3 = 66.66\% \\
 \text{top} - 3 &= (1 + 1 + 1) / 3 = 100\%
 \end{aligned}
 \tag{2-1}$$

在本文中，选择累计匹配特征 top-1、top-5、top-10 作为评价指标，这也是行人重识别领域目前最常用的三个指标。其中，top-1 表示按照相似度排序后，最匹配行人图像刚好与查询图像身份相同的概率，即该指标为真正的识别能力。然而，当 k 值很小但大于 1 时，由于可以通过人眼辅助识别来查找目标行人，因此也具有很大的现实意义。例如，top-5 指标反映了前 5 个匹配行人图像中存在与查询图像身份相同的概率，top-10 指标反映前 10 个匹配行人图像中与查询图像身份相同的概率。因此，top-k 的值越高，说明相似度排序后，正确识别行人的概率越高，分类器的性能越好。

## 2) 平均准确率均值

准确率均值 (Average Precision, AP) 衡量的是模型在单个类别上的好坏, 平均准确率均值 (mean Average Precision, mAP) 衡量的是模型在所有类别上的好坏。在行人重识别任务中, AP 是检索一个行人图像时的准确率, 而 mAP 是检索查询库中所有行人图像时的准确率。

在介绍平均准确率均值之前, 首先要了解两个概念——准确率 (Precision) 和召回率 (Recall)。准确率是所有检索样本中检索出的正确样本的比率, 召回率是所有正确样本中检索出的正确样本的比率。为了方便说明, 定义四个变量  $TP$ 、 $TN$ 、 $FP$ 、 $FN$ 。 $TP$  (True Positive) 表示预测为真、实际也为真的行人图像数量,  $TN$  (True Negative) 表示预测为假、实际也为假的行人图像数量,  $FP$  (False Positive) 表示预测为真、实际却为假的行人图像数量。 $FN$  (False Negative) 表示预测为假、实际却为真的行人图像数量。

如公式 (2-2) 所示, 准确率=查询返回的正确个数/查询返回的总个数, 即正确被识别的行人图像 ( $TP$ ) 占有所有实际被检测行人图像 ( $TP+FP$ ) 的比例。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2-2)$$

如公式 (2-3) 所示, 召回率=查询返回的正确个数/该查询对象在被检测样本中的总个数, 即正确被识别的行人图像 ( $TP$ ) 占有所有应该被识别的行人图像 ( $TP+FN$ ) 的比例。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2-3)$$

以表 2-4 为例, 从查询集中选择一张行人图像, 在与图库集中图像进行比对后, 将返回的查询结果按相似度降序排序。其中 Image1、Image3、Image6、Image9、Image10 是与查询图像具有相同身份的图像。

表 2-3 准确率和召回率的计算

Table 2-3 The calculation of accuracy and recall

| 返回图            | 标签 | 准确率      | 召回率     |
|----------------|----|----------|---------|
| <b>Image1</b>  | Y  | 1/1=1    | 1/5=0.2 |
| Image2         | N  | -        | -       |
| <b>Image3</b>  | Y  | 2/3=0.67 | 2/5=0.4 |
| Image4         | N  | -        | -       |
| Image5         | N  | -        | -       |
| <b>Image6</b>  | Y  | 3/6=0.5  | 3/5=0.6 |
| Image7         | N  | -        | -       |
| Image8         | N  | -        | -       |
| <b>Image9</b>  | Y  | 4/9=0.44 | 4/5=0.8 |
| <b>Image10</b> | Y  | 5/10=0.5 | 5/5=1   |

由表可知，当检索的行人图像个数为 1 时，平均准确率表示图库集中正确被识别的行人图像占图库集中所有图像的比例  $AP=(1+0.67+0.5+0.44+0.5)/5=0.62$ 。因此，当行人重识别任务需要检索  $n$  个行人时，识别准确率取所有人的平均准确率的均值  $mAP=(AP_1+AP_2+\cdots+AP_n)/n$ 。

## 2.5 本章小结 (Summary)

本章首先从有监督和无监督两个方面简要介绍了现有行人重识别方法的进展，以及本文提出的方法与现有方法的不同。其次，由于本文提出的方法以残差网络作为骨干网络，为了更好地说明下文所提出的网络结构，本章还介绍了残差网络的原理与结构。接下来，本章介绍了行人重识别领域的基础知识，包括 Market1501、DukeMTMC-reID、MSMT17 数据集的概况和划分方法，以及两个常用的评价指标：累计特征匹配 CMC 和平均准确度均值 mAP。

### 3 基于图像-空间特征融合的有监督行人重识别方法

## 3 Supervised Person Re-identification Based on Image-Space Feature Fusion

### 3.1 方法概述 (Method Overview)

图像特征包括全局特征 (Global Features) 和局部特征 (Local Features)。全局特征描述图像的整体属性, 包括颜色特征、纹理特征和形状特征等。局部特征则描述图像局部区域中的属性, 包括边缘、角点、线和特别属性的区域等。因此, 全局特征和局部特征具有较好的互补性。

在行人重识别领域中, 大量方法基于残差网络改进, 因为残差网络可以解决退化问题, 挖掘更抽象的高层特征。同样, 本文提出的方法也基于残差网络进行改进。残差网络提取的图像特征是全局特征, 无法区分前景的行人信息和背景信息, 这会导致杂乱背景的干扰。为了解决这一问题, 本章根据图像特征提取空间特征, 学习行人的空间位置。与图像特征不同, 空间特征旨在描述图像特征内的空间关系, 关注的重点是行人在图像中的位置。因此, 本章融合了空间特征和图像特征, 对图像特征进行约束增强处理, 使融合后的特征更多地强调行人信息而弱化背景信息, 从而解决行人重识别图像中背景杂乱的问题。

但是除了背景干扰, 当行人受到遮挡等影响时, 特征仍可能包含了遮挡物的干扰信息。在实际场景中, 行人部分身体被遮挡是十分常见的现象。例如, 行人可能被其他行人遮挡, 或被车辆、交通标志、垃圾桶等障碍物遮挡。不同于全局特征, 局部特征通常选取一些能够稳定出现、具有良好判别性的点。于是, 当目标没有被完全遮挡时, 一些局部特征仍然稳定地存在以表示目标, 便于下一步的分析。因此, 本章将在行人重识别任务中充分利用行人的局部特征进行判别, 从而减小遮挡问题带来的影响。

然而, 采用局部特征进行判别虽然一定程度上缓解了行人的遮挡问题, 但只利用行人的局部特征却容易对网络训练造成误导。例如, 不同行人可能穿着相似的上衣, 在现有摄像机分辨率低的现状下, 网络更难对此类相似的局部特征进行判别, 进而造成过拟合。基于此, 本章提出了一种基于图像-空间特征融合的行人重识别网络 (Person Re-identification Network Based on Image-Space Feature Fusion, ISFNet), 通过空间特征和图像特征的融合解决行人图像背景杂乱的问题, 通过局部特征的身份预测解决行人遮挡问题。最后, 采用局部特征判别行人的同时, 利用全局特征从整体上辨别不同的行人, 从整体和局部两方面联合训练网络的判别能力。



### 3.2 基于图像-空间特征融合的网络模型 (Network Based on Image-Space Feature Fusion)

行人重识别属于细粒度图像识别的范畴,着眼于在整张图像中提取有用的细粒度信息,因此学习有效的局部特征对于行人重识别任务十分必要。在行人重识别问题中,我们更希望忽略图像中的背景信息而聚焦前景的行人,以屏蔽更多的干扰信息。此外,在实际场景中,行人重识别还面临着光照变换、视觉遮挡等问题,尤其是行人在行走过程中,被车辆和城市基础设施遮挡的情况十分常见。因此,本章提出了一种基于图像-空间特征融合的行人重识别网络 (Person Re-identification Network Based on Image-Space Feature Fusion, ISFNet),在融合图像特征和空间特征的基础上提取局部特征,有效解决了背景杂乱和行人遮挡的问题。同时,该网络采用分类损失和三元组损失加权组成的损失函数,通过局部特征训练分类损失,通过全局特征训练三元组损失,从整体和细节两个方面对行人进行识别。ISFNet 的网络结构如图 3-1 所示。




图 3-1 基于图像-空间特征融合的行人重识别网络示意图

Figure 3-1 An illustration of the ISFNet

首先, ISFNet 融合了行人的图像特征和空间特征,强调了行人信息而抑制了背景信息的流动。本章使用残差网络 Resnet-50 获取图像特征,并在此基础上通过进一步细粒度特征的提取,获取了空间特征,该特征定位了行人在图像中的位置。通过空间特征和图像特征的融合, ISFNet 得到了弱化背景信息的图像特征,即该特征的关注点在前景的行人而非背景上。

接下来, ISFNet 将强调了行人信息的特征水平均分为  $m$  个局部特征。对于每个局部特征,分别使用  $1 \times 1$  卷积减小特征的维数。每个降维后的局部特征又分别输入到身份预测器中,以训练分类损失。同时, ISFNet 将  $m$  个局部特征直接相连得到全局特征,以训练三元组损失。最后,将分类损失与三元组损失组合得

到最终的损失函数，利用全局特征和局部特征联合训练网络。

在训练期间，每个身份预测器都预测输入局部特征的身份，以减小遮挡问题对行人识别的影响。在测试过程中，直接将局部特征连接起来的全局特征作为输入图像的最终描述符。

以下详细介绍了特征融合模块、身份预测器结构和多损失融合方法。

### 3.2.1 特征融合

在构建网络模型时，网络层数越多，提取特征包含的信息就越丰富。因此，为了提取更有效的特征向量，同时更好地解决网络的退化问题、提高网络性能，本章选择残差网络 Resnet-50 作为 ISFNet 的骨干网络（Backbone）。通过残差网络得到的特征图记为  $F$ ，该特征图包含行人图像的全部信息。

然而，在行人重识别任务中，行人图像从监控视频中以四边形的方框截取。因此，除了行人本身，图像中还包含了大量无用的背景信息。这些信息会对行人的识别造成干扰，因此模型希望更多地关注前景的行人而非杂乱的背景。

在深度学习中，网络提取到的信息以同等重要性向后流动，而如果知道某些重要信息的空间位置，网络就能根据空间信息强调有效信息、抑制某些无效信息的流动。基于此，本节提出了一个融合空间特征和图像特征的网络模块，以关注行人特征并弱化背景特征，其结构如图 3-2 所示。




图 3-2 特征融合

Figure 3-2 Feature fusion

空间特征利用特征内的空间关系，关注的重点是信息部分的位置。在行人图像中，行人区域和背景区域对行人重识别任务的贡献是不同的，只有图像前景的行人区域才是网络应该关注的重点。在行人重识别任务中，空间特征的本质就是定位行人并获取权重。下面对空间特征的提取进行详细的介绍。

在卷积神经网络中，卷积层对图像的局部接受域进行卷积得到图像的邻域特征，池化层再将小邻域内的特征点整合得到新的特征。因此，池化不仅可以降低特征的维度，还能够提取更好的、具有更强烈语义信息的特征。池化方法分为两种：平均池化和最大池化。平均池化取局部接受域中的平均值，最大池化取局部

接受域中的最大值。因此，当图像中的每个部分都有意义时应该使用平均池化，当存在无用信息时应当使用最大池化。

在行人重识别任务中，行人图像包含了杂乱的背景信息，这些信息会对行人的识别造成干扰。因此，为了弱化背景信息，应当采用最大池化的方法。然而，残差网络 Resnet-50 的深度较大，最终提取的特征包含的语义信息较多，采用最大池化可能会丢失重要信息。为了解决这个问题，ISFNet 将平均池化提取的特征  $F_{avg}$  和最大池化提取的特征  $F_{max}$  进行融合，既突出了图像前景的行人特征，又保证了信息的完整性。

接下来，根据融合后的平均池化特征和最大池化特征，ISFNet 应用卷积操作来生成空间特征  $F_s$ ，其中编码了要强调或抑制的位置。其中，卷积核的大小设置为  $7 \times 7$ ，填充宽度为 3。对于经过卷积处理的特征，使用 Sigmoid 函数将特征中的值映射到  $(0, 1)$  之间，表示特征各部分的权重。

最后，ISFNet 通过逐元素相乘的方法融合了空间特征和图像特征。空间特征定位了行人的位置，提取了图像特征中各部分的权重。通过与图像特征的融合，相对强调了行人部分的信息而弱化了背景部分的信息，解决了行人图像背景杂乱的问题。特征融合的计算如公式 (3-1) 所示。

$$\begin{aligned} F' &= \text{Sigmoid}(\text{Conv}([F_{avg}; F_{max}])) \\ &= F_s \otimes F \end{aligned} \quad (3-1)$$

其中  $\otimes$  表示逐元素乘法。如图 3-3 所示，该模块位于残差网络堆叠的残差模块后，最终的平均池化前。




图 3-3 特征融合模块添加位置

Figure 3-3 Location of feature fusion module

### 3.2.2 身份预测器

图像特征和空间特征的融合在一定程度上解决了行人图像背景杂乱的问题，提高了特征的表达能力。然而，行人重识别中还面临着严重的遮挡问题，如图 3-4 所示。为了解决这一问题，ISFNet 将特征水平均分为  $m$  个局部特征进行判别，这一思路得益于郑良等人提出的 PCB 网络<sup>[31]</sup>。与 PCB 网络不同的是，ISFNet 在残差网络中添加了特征融合模块，弱化了行人的背景信息，并且采用了多特征融合的方法，联合训练网络模型。



图 3-4 行人遮挡问题

Figure 3-4 Pedestrian occlusion problem

每个局部特征都分别输入到身份预测器中，以训练分类损失，每个身份预测器都由一个全连接层（Fully Connected Layer, FC）和一个 Softmax 层实现。在行人重识别问题中，假设共有  $C$  个行人，即身份预测器的目标为  $C$  个类别，其网络结构如图 3-5 所示。




图 3-5 身份预测器

Figure 3-5 ID predictor

如上图所示，全连接层的输入是特征向量  $x$ ，该特征向量由全连接层前面的多个卷积层和池化层处理得到。全连接层将转置的权重矩阵  $W$  与输入的特征向量  $x$  相乘再加上偏置  $b$ ，得到最终的输出结果  $z = W^T x + b$ 。

$z$  向量是一个  $C$  维的列向量，通过 Softmax 层后的输出也是  $C$  维的列向量，向量中的每个值表示输入特征属于每个行人的概率。换句话说，向量中的第一个值就是当前图片属于第一个行人的概率，向量中的第  $i$  个值就是当前图片属于第  $i$  个行人的概率。输出的概率向量的每个值的大小范围为 0 到 1 且所有值的总和为 1。Softmax 层的计算如公式 (3-2) 所示。

$$\text{softmax}(z) = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)}, \quad i = 1, \dots, C \quad (3-2)$$

综上所述，通过身份预测器，ISFNet 可以预测输入特征向量属于第几个行人。分类器的计算方式如公式 (3-3) 所示。

$$\hat{y} = \text{softmax}(z) = \text{softmax}(W^T x + b) \quad (3-3)$$

其中,  $x$  为全连接层的输入,  $W$  为全连接层的权重矩阵,  $b$  为偏置项。 $\hat{y}$  为 Softmax 层输出的概率向量, 向量中的每个值表示输入特征属于每个行人的概率。概率向量中值最大的数的索引作为输入图像的预测标签。

### 3.2.3 多损失融合

在完成了模型结构的构建后, ISFNet 需要通过对损失函数的优化进行学习。损失函数的数值反应了预测值与实际结果的偏离程度。根据 ISFNet 中局部特征及全局特征的不同语义, 本章对局部特征和全局特征分别预测, 然后对损失函数加权融合, 最终联合训练网络模型。

对于全局特征, ISFNet 采用三元组损失进行训练。在训练数据集不够大的情况下, 三元组损失具有比对比损失和分类损失更好的泛化能力。三元组损失的目标旨在缩小类内差距, 扩大类间差距。在行人重识别问题中, 三元组损失的应用会缩小相同身份之间的特征距离, 增大不同身份之间的特征距离。

传统的三元组采用随机采样的方法, 采样出的三元组对网络来说容易识别, 因此不利于网络模型的训练。为了更好地训练网络, ISFNet 采用在线硬样本挖掘方法 (Online Hard Example Mining, OHEM) [21], 在一个小批量样本中采样所有的样本对。对于每一个训练批次, 随机抽样  $P$  个行人, 每个行人随机选取  $K$  张不同的图像, 即一个批次含有  $N = P \times K$  张图像。对于该批次中的每一张图像  $x_i$ , 在生成三元组来计算损失时选择该批次中最不相似的正样本  $x_i^+$  和最相似的负样本  $x_i^-$ , 其方法如公式 (3-4) 所示。

$$Loss_{tri} = \frac{1}{N} \sum_{i=1}^N [\|f(x_i) - f(x_i^+)\|_2^2 - \|f(x_i) - f(x_i^-)\|_2^2 + \alpha] \quad (3-4)$$

对于局部特征, ISFNet 引入交叉熵损失 (Cross Entropy Loss) 作为分类损失进行训练。交叉熵损失又叫做负对数似然, 它的函数表达式如公式 (3-5) 所示。

$$Cross\ Entropy\ Loss = -(y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)) \quad (3-5)$$

该函数使用对真实值类别的实际预测概率的对数相乘来计算损失, 在优化的过程中会偏向惩罚置信度高但是错误的预测值, 从而逐步减小损失。

通过身份预测器, 网络得到了一个输入图像属于第几个行人的概率向量, 并通过向量中最大值的索引得到预测标签。于是, 分类损失的计算如公式 (3-6) 所示。其中,  $N$  是批量样本数,  $m$  是局部特征分支数,  $y$  是预测标签。

$$Loss_{cls} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^m \log \left( \frac{e^{z_y}}{\sum_{j=1}^C e^{z_j}} \right) \quad (3-6)$$

最后,为了更好的融合局部特征与全局特征,本章提出了一个融合分类损失与三元组损失的目标函数  $Loss_{total}$ , 其公式如式(3-7)所示。其中,  $\lambda_1$  和  $\lambda_2$  分别是分类损失与三元组损失的权重系数。

$$Loss_{total} = \lambda_1 Loss_{cls} + \lambda_2 Loss_{tri} \quad (3-7)$$

### 3.3 实验结果及分析 (Experimental Results and Analysis)

为了验证本章提出的深度行人重识别网络结构 ISFNet 的有效性,本章在三个常用的行人重识别数据集 Market-1501、DukeMTMC-reID 和 MSMT17 上进行了实验,并采用累计匹配特征 (Cumulative Match Characteristics, CMC) 曲线和平均准确率均值 (Mean Average Precision, mAP) 进行评估。本章详细说明了实验设置,并将 ISFNet 与现有的方法进行对比和分析。具体内容如下。

#### 3.3.1 实验设置

在实验中,ISFNet 使用 ImageNet 预训练的参数初始化 Resnet-50,并去掉最后一个全连接层。在 Resnet-50 的最后一个残差块中将卷积层的步长设置为 1 而不是原来的 2。特征图划分为  $m=6$  个水平部分,每个分支的输出特征的维度为 256 维。在训练过程中,使用三种数据增强方法,包括随机裁剪、水平翻转和随机擦除。每个批次的训练随机选取  $P=24$  个行人,每个行人选取  $K=4$  张图像,每个输入图像的大小调整为  $384 \times 128$ 。三元组的边距 margin 和标签平滑正则化率分别设置为 0.3 和 0.1。分类损失和三元组损失的权重系数  $\lambda_1$  和  $\lambda_2$  分别设置为 3 和 1。优化算法使用动量梯度下降法,动量 momentum 设置为 0.9。初始学习率设置为 0.1,每 40 个 epoch 按 10% 的速率衰减。通过 60 个 epoch 在数据集上训练模型,在测试过程中将同一张图像的局部特征串联在一起。所有实验均在两张 Nvidia GTX 1080Ti 显卡上进行。以上参数设置适用于本章实验中的所有数据集。

#### 3.3.2 实验结果及分析

##### 1) 对比实验

本节将提出的方法 ISFNet 与现有方法进行了比较。比较的方法分为四类:基于人工特征的方法、基于全局特征的方法、基于局部特征的方法以及基于注意力机制的方法。实验结果表明,本章提出的方法在三个数据集上都优于比较的方法。

首先, 将本章所提出的方法与传统的人工提取特征的方法进行比较, Market-1501 数据集上的比较结果详见表 3-1, DukeMTMC-reID 数据集上的比较结果见表 3-2。实验结果显示, ISFNet 在两个数据集上都明显优于传统的方法。这是因为人工提取的特征大多基于启发式设计, 不能较好的挖掘不同的数据集中的判别性信息。

表 3-1 Market1501 数据集上人工特征方法的性能比较 (%)

Table 3-1 Performance (%) comparison on Market-1501 (Handcrafted Feature)

| 方法              | top-1       | top-5       | top-10      | mAP         |
|-----------------|-------------|-------------|-------------|-------------|
| Bow+kissme [48] | 44.4        | 63.9        | 72.2        | 20.8        |
| WARCA [53]      | 45.2        | 68.1        | 76.0        | -           |
| KLFDA [54]      | 46.5        | 71.1        | 79.9        | -           |
| <b>ISFNet</b>   | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |

表 3-2 DukeMTMC 数据集上人工特征方法的性能比较 (%)

Table 3-2 Performance (%) comparison on DukeMTMC (Handcrafted Feature)

| 方法              | top-1       | top-5       | top-10      | mAP         |
|-----------------|-------------|-------------|-------------|-------------|
| Bow+kissme [48] | 25.1        | -           | -           | 12.2        |
| LOMO+XQDA [55]  | 30.8        | -           | -           | 17.0        |
| <b>ISFNet</b>   | <b>85.5</b> | <b>93.3</b> | <b>94.7</b> | <b>71.9</b> |

其次, 将本章所提出的方法与基于全局特征的方法进行比较, Market-1501 数据集上的比较结果详见表 3-3, DukeMTMC-reID 数据集上的比较结果见表 3-4。全局特征直接学习整个图像的表征, 而不受局部图像的约束。在面临遮挡这类常见问题时, 全局特征会由于其他物体的干扰而错误判别行人的身份。因此, 当行人背景杂乱或出现严重的遮挡时, 学习局部特征通常会挖掘更具判别性的身体部位信息来获得更好的性能。实验结果显示, 本章提出的利用局部特征判别的方法更利于模型解决遮挡问题。

表 3-3 Market1501 数据集上全局特征方法的性能比较 (%)

Table 3-3 Performance (%) comparison on Market-1501 (Global Feature)

| 方法                | top-1       | top-5       | top-10      | mAP         |
|-------------------|-------------|-------------|-------------|-------------|
| SOMAnet [56]      | 73.9        | -           | -           | 47.9        |
| SVDNet [57]       | 82.3        | 92.3        | 95.2        | 62.1        |
| PAN [58]          | 82.8        | -           | -           | 63.4        |
| Transfer [59]     | 83.7        | -           | -           | 65.5        |
| Triplet Loss [21] | 84.9        | 94.2        | -           | 69.1        |
| DML [60]          | 87.7        | -           | -           | 68.8        |
| <b>ISFNet</b>     | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |



表 3-4 DukeMTMC 数据集上全局特征方法的性能比较 (%)

Table 3-4 Performance (%) comparison on DukeMTMC (Global Feature)

| 方法            | top-1       | top-5       | top-10      | mAP         |
|---------------|-------------|-------------|-------------|-------------|
| GAN [49]      | 46.5        | 71.1        | 79.9        | -           |
| PAN [58]      | 73.9        | -           | -           | 47.9        |
| SVDNet [57]   | 76.7        | 86.4        | 89.9        | 56.8        |
| <b>ISFNet</b> | <b>85.5</b> | <b>93.3</b> | <b>94.7</b> | <b>71.9</b> |

然后, 将本文所提出的方法与基于局部特征的方法进行比较, Market-1501 数据集上的比较结果详见表 3-6, DukeMTMC-reID 数据集上的比较结果见表 3-7。基于局部特征的方法分为基于语义信息和基于水平分区。基于语义信息的特征提取方法通常需要一个额外的姿势检测器, 然而行人重识别数据集与姿态估计数据集的差距较大, 容易产生噪声干扰, 因此该方法无法取得较好的性能。而基于水平分区的方法使用均匀分区来获得水平部分, 该方法比较灵活, 不需要额外的姿势信息, 但对混乱的背景较为敏感。本章提出的方法首先融合了空间特征和图像特征, 弱化了背景信息, 然后将图像分为若干个尺寸一致的水平横条作为局部特征。实验表明, 本章提出的方法取得了较好的效果。

表 3-5 Market1501 数据集上局部特征方法的性能比较 (%)

Table 3-5 Performance (%) comparison on Market-1501 (Local Feature)

| 方法               | top-1       | top-5       | top-10      | mAP         |
|------------------|-------------|-------------|-------------|-------------|
| MultiRegion [61] | 66.4        | 85.0        | 90.2        | 41.2        |
| HydraPlus [62]   | 76.9        | 91.3        | 94.5        | -           |
| PAR [28]         | 81.0        | 92.0        | 94.7        | 63.4        |
| MultiLoss [63]   | 83.9        | -           | -           | 64.4        |
| PDC [64]         | 84.4        | 92.7        | 94.9        | 63.4        |
| PartLoss [65]    | 88.2        | -           | -           | 69.3        |
| MultiScale [66]  | 88.9        | -           | -           | 73.1        |
| GLAD [67]        | 89.9        | -           | -           | 73.9        |
| PCB + RPP [31]   | 93.8        | 97.5        | 98.5        | 81.6        |
| <b>ISFNet</b>    | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |

表 3-6 DukeMTMC 数据集上局部特征方法的性能比较 (%)

Table 3-6 Performance (%) comparison on DukeMTMC (Local Feature)

| 方法              | top-1       | top-5       | top-10      | mAP         |
|-----------------|-------------|-------------|-------------|-------------|
| MultiScale [66] | 79.2        | -           | -           | 60.6        |
| PCB + RPP [31]  | 83.3        | -           | -           | 69.2        |
| <b>ISFNet</b>   | <b>85.5</b> | <b>93.3</b> | <b>94.7</b> | <b>71.9</b> |

最后, 将本文所提出的方法与基于注意力机制的方法进行比较, Market-1501 数据集上的比较结果详见表 3-7, DukeMTMC-reID 数据集上的比较结果见表 3-8。注意力机制能够帮助模型学习更具判别性的特征, 因为注意力机制可以捕获不同卷积通道、多个特征图、不同身体部位甚至多个图像之间的关系。现有的基于注



注意力机制的方法大多针对全局特征采用注意力机制,在提取行人特征时有效屏蔽了背景信息。在本章提出的方法中,图像特征和空间特征的融合也起到了同样的效果,突出了行人特征,弱化了背景特征。与之相比,本章的方法还提取了图像的局部特征,解决了行人遮挡的问题。

表 3-7 Market1501 数据集上注意力机制方法的性能比较(%)

Table 3-7 Performance (%) comparison on Market-1501 (Attention Mechanisms)

| 方法            | top-1       | top-5       | top-10      | mAP         |
|---------------|-------------|-------------|-------------|-------------|
| CAN [34]      | 60.3        | -           | -           | 35.9        |
| DLPAR [28]    | 81.0        | 92.0        | 94.7        | 63.4        |
| PDCNN [64]    | 84.1        | -           | -           | 63.4        |
| IDEAL [68]    | 86.7        | -           | -           | 67.5        |
| MGCAM [32]    | 83.8        | -           | -           | 74.3        |
| AACN [29]     | 85.9        | -           | -           | 66.9        |
| DuATM [69]    | 91.4        | 97.1        | -           | 76.6        |
| HA-CNN [33]   | 91.2        | -           | -           | 75.7        |
| <b>ISFNet</b> | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |

表 3-8 DukeMTMC 数据集上注意力机制方法的性能比较(%)

Table 3-8 Performance (%) comparison on DukeMTMC (Attention Mechanisms)

| 方法            | top-1       | top-5       | top-10      | mAP         |
|---------------|-------------|-------------|-------------|-------------|
| AACN [29]     | 76.8        | -           | -           | 59.3        |
| DuATM [69]    | 81.8        | 90.2        | -           | 64.6        |
| HA-CNN [33]   | 80.5        | -           | -           | 63.8        |
| <b>ISFNet</b> | <b>85.5</b> | <b>93.3</b> | <b>94.7</b> | <b>71.9</b> |

此外,本章还在 MSMT17 数据集上进行了实验。MSMT17 数据集是目前最大的行人重识别数据集,更接近于真实的场景。现有的在该数据集上进行评估的方法非常少,因此不再区分方法所属的类别进行比较,其比较结果见表 3-9。

表 3-9 MSMT17 数据集上的性能比较(%)

Table 3-9 Performance (%) comparison on MSMT17

| 方法             | top-1       | top-5       | top-10      | mAP         |
|----------------|-------------|-------------|-------------|-------------|
| GoogleNet [70] | 47.6        | 65.0        | 71.8        | 23.0        |
| PDC [64]       | 58.0        | 73.6        | 79.4        | 29.7        |
| GLAD [67]      | 61.4        | 76.8        | 81.6        | 34.0        |
| PCB + RPP [31] | 68.2        | 81.2        | 85.5        | 40.4        |
| <b>ISFNet</b>  | <b>69.4</b> | <b>82.1</b> | <b>86.2</b> | <b>41.5</b> |

## 2) 消融实验

为了验证特征融合模块和多损失融合模块的有效性,本节在 Market1501 数据集上进行了消融实验(Ablation Study),结果如表 3-10 所示。本节选用 PCB 网络作为基准模型(Baseline),并在此基础上分别添加了特征融合(Feature Fusion, FF)模块和多损失融合(Multi-Loss Fusion, MLF)模块,最终同时添加两种模块,

即本章提出的 ISFNet 模型。

实验结果显示：仅添加特征融合（FF）模块 mAP 提升了 2.3%，CMC top-1 提升了 1.2%；仅添加多损失融合（MLF）模块 mAP 提升了 4.1%，CMC top-1 提升了 1.9%；同时添加特征融合（FF）模块和多损失融合（MLF）模块（即本章提出的 ISFNet 模型）带来了显著的性能提升，mAP 提升了 6.0%，CMC top-1 提升了 2.3%，这表明两种模块并不冲突，组合使用对模型起到了更好的效果。

表 3-10 Market1501 数据集上的消融实验（ISFNet）

Table 3-10 Ablation Study on Market-1501（ISFNet）

| 方法                 | top-1       | top-5       | top-10      | mAP         |
|--------------------|-------------|-------------|-------------|-------------|
| PCB [31]           | 92.3        | 97.2        | 98.2        | 77.4        |
| PCB+ FF            | 93.5        | 96.8        | 97.9        | 79.7        |
| PCB+ MLF           | 94.2        | 97.6        | 98.8        | 81.5        |
| PCB+FF+MLF（ISFNet） | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |

### 3) 参数敏感性实验

ISFNet 的损失函数由分类损失和三元组损失加权组成，其中分类损失的权重为  $\lambda_1$ ，三元组损失的权重为  $\lambda_2$ 。在实验中，本文最终设置  $\lambda_1$  的值为 3， $\lambda_2$  的值为 1，交叉验证结果如表 3-11 所示。其中  $\lambda_1 = 0$ 、 $\lambda_2 = 1$  时表示 ISFNet 仅选择三元组损失作为最终的损失函数，即不利用局部特征进行判别； $\lambda_1 = 1$ 、 $\lambda_2 = 0$  时表示 ISFNet 仅选择分类损失作为最终的损失函数，即添加了特征融合模块的 PCB 网络。实验结果显示，分类损失为 ISFNet 提供了更有效的指导，三元组损失在一定程度上修正了局部特征对网络训练的误导，网络在  $\lambda_1 = 3$ 、 $\lambda_2 = 1$  时取得最佳性能。

表 3-11 不同损失的权重分析

Table 3-11 Analysis on the weight of different losses

| $\lambda_1$ | $\lambda_2$ | top-1       | top-5       | top-10      | mAP         |
|-------------|-------------|-------------|-------------|-------------|-------------|
| 0           | 1           | 85.6        | 93.3        | 95.6        | 72.2        |
| 1           | 0           | 93.5        | 96.8        | 97.9        | 79.7        |
| 1           | 1           | 94.0        | 97.6        | 98.6        | 82.9        |
| 2           | 1           | 94.2        | 97.8        | 99.0        | 83.1        |
| <b>3</b>    | <b>1</b>    | <b>94.6</b> | <b>98.1</b> | <b>99.0</b> | <b>83.4</b> |
| 4           | 1           | 94.1        | 97.9        | 98.9        | 83.0        |
| 1           | 2           | 93.7        | 97.7        | 98.1        | 80.8        |
| 2           | 2           | 93.9        | 97.7        | 98.3        | 82.0        |
| 3           | 2           | 94.1        | 97.9        | 98.7        | 82.3        |
| 4           | 2           | 94.2        | 98.0        | 98.9        | 82.6        |

## 3.4 本章小结（Summary）

本章提出了一种基于图像-空间特征融合的有监督行人重识别方法。首先，

本章分析了行人重识别中存在的挑战,并对应地提出解决办法,最终提出了基于特征融合的行人重识别网络结构。随后,本章详细介绍了该网络结构的组成部分。本章提出的方法应用残差网络 Resnet-50 作为骨干网络,提取图像特征。然后根据行人图像特征提取空间特征,学习图像中的行人位置,并通过图像特征和空间特征的融合解决了背景杂乱的问题。接下来,提出了由分类损失和三元组损失加权融合的损失函数,通过局部特征训练分类损失,通过全局特征训练三元组损失。既利用局部特征有效改善了行人遮挡问题,又利用全局特征避免了视角过于局限造成的干扰。最后,本章详细介绍了实验的参数设置,并将提出方法与四类现有方法分别对比和分析。结果显示,本章提出的方法有效提高了行人重识别的准确率。此外,本章还进行了消融实验和参数敏感性实验,分别证明了本章提出方法的有效性和参数设置的合理性。

## 4 基于局部特征融合的无监督行人重识别方法

### 4 Unsupervised Person Re-identification Based on Local Feature Fusion

#### 4.1 方法概述 (Method Overview)

监督学习方法依赖于大量已标记的训练数据,而标记数据需要耗费大量的人力资源,且现有数据集规模远小于现实场景的数据规模,这限制了监督学习方法的可扩展性和实用性。因此,基于无监督学习的行人重识别方法具有极大的研究价值。

行人重识别方法在有监督学习方面已经取得了较大的进展,因为已标记数据集可以为神经网络的训练提供标签,这帮助损失函数更精准地计算预测值与真实值的差距,从而优化网络模型。然而,在无监督场景下,行人标签是缺失的,这增加了网络训练的难度。现有的基于无监督学习的行人重识别方法虽然也引起了研究人员的关注,但是与基于监督学习的方法相比,性能仍然不尽人意。

在基于无监督行人重识别方法的研究中,基于聚类的方法主要通过网络结构来实现聚类的目的,在此类方法中,网络针对行人的全局特征进行聚类,这限制了网络对细粒度信息的挖掘。为了解决这个问题,本章提出了一种基于局部特征融合的行人重识别网络 (Person Re-identification Network Based on Local Feature Fusion, LFNet)。首先,将全局特征分为三个局部分支:头部特征、上肢特征和下肢特征,再通过局部特征的优化屏蔽图像的背景信息,挖掘前景行人的细粒度信息。最终融合优化的局部特征来生成干扰更少更有效的行人特征描述符。

同时,为了保证网络的聚类属性,本章提出了一种基于无监督学习的三元组损失 (Unsupervised Triplet Loss, UTL)。不同于分类损失在目标很大时严重增加网络参数,也不同于验证损失只能缓慢地判断成对图片的相似度,三元组损失自带聚类属性,可以简单直接地进行端到端的训练。根据有监督场景下批量难样本挖掘的三元组的思想,UTL 通过随机变换生成固定样本 (Anchor) 的难正样本 (Hard Positive),通过本章提出的难负样本挖掘算法生成图像的难负样本 (Hard Negative),有效地更新了网络权重,解决了随机采样导致的收敛缓慢的问题。此外,该损失不局限于本章提出的 LFNet 或行人重识别领域,是一个适用于无监督学习的通用损失。

## 4.2 基于无监督的三元组损失函数 (Unsupervised Triplet Loss)

监督学习按照样本的标签进行学习,与监督学习不同,无监督学习则按照样本间的差异来进行学习。在无监督学习中,模型学习的样本没有标签。因此,无监督学习的目标就是挖掘这些无标签样本中存在的内在特性或规律,其代表就是聚类。

三元组损失具有聚类属性,它期望在嵌入空间中拉近同一身份的图像并推开不同身份的图像。因此,为了给 LFNet 提供有效的指导,本节提出了一种基于无监督学习的三元组损失 (Unsupervised Triplet Loss, UTL),以在未标记的数据集上学习更多具有判别性的特征。

### 4.2.1 传统的三元组损失

三元组损失最早来自于谷歌的 FaceNet<sup>[71]</sup>,它的思想非常简单:相同身份之间的特征距离要尽可能小,而不同身份之间的特征距离要尽可能大。在 FaceNet 中,三元组损失优化了嵌入空间 (Embedding Space),嵌入空间中不同图像间距离的长度代表了图像的相似度。在行人重识别任务中,三元组损失的学习就是使同一行人的图像间的距离比不同行人的图像间的距离更小。




图 4-1 三元组损失

Figure 4-1 Triplet Loss

如图 4-1 所示,模型将图像  $\mathbf{x}$  嵌入  $d$  维度的欧几里得空间中  $f(\mathbf{x}) \in \mathbb{R}^d$ 。在该向量空间内,三元组损失想要保证一个特定行人的锚点图像  $\mathbf{x}_i$  (Anchor) 比其他任何人的图像  $\mathbf{x}_i^-$  (Negative) 更接近同一个人的所有其他图像  $\mathbf{x}_i^+$  (Positive)。因此,在所有的三元组样本对上,正样本对间的距离加上边距 (Margin) 要小于负样本对间的距离,如公式 (4-1) 所示。

$$\|f(\mathbf{x}_i) - f(\mathbf{x}_i^+)\|_2^2 + \alpha < \|f(\mathbf{x}_i) - f(\mathbf{x}_i^-)\|_2^2, \forall (f(\mathbf{x}_i), f(\mathbf{x}_i^+), f(\mathbf{x}_i^-)) \in \mathcal{T} \quad (4-1)$$

其中,  $\alpha$  是强制在正负对之间的边距,可以控制正负样本的距离。 $\mathcal{T}$  是训练集中所有可能的  $N$  个三元组的集合。通过转换,它的损失函数就变为公式 (4-2) 所示。

$$L = \sum_i^N [\|f(x_i) - f(x_i^+)\|_2^2 - \|f(x_i) - f(x_i^-)\|_2^2 + \alpha] \quad (4-2)$$

如果严格按照公式(4-1)中的约束条件,可能会生成许多容易满足条件的三元组。这些三元组是从训练集中随机挑选组成的,因此可能包含很像的正样本对和很不像的负样本对,即简单的样本组合。然而,一直学习简单的样本会限制网络的泛化能力。为了更好的训练网络,三元组损失需要选择对网络来说更“难”识别的样本对,这些难以识别的“难三元组”将有助于改善模型。

如何选择三元组对于模型的训练非常重要,“难三元组”指的是比较难判断的样本,具体表现在最不相似的正样本对和最相似的负样本对。即锚点样本(Anchor)与正样本之间的距离较大,与负样本之间的距离较小。这意味着,在给定样本 $x_i$ 的情况下,该损失希望选择一个最不相似的正样本 $x_i^+$ (难正样本)以及最相似的负样本 $x_i^-$ (难负样本),这能够增加网络模型识别的难度,从而更有效地训练网络。

在整个训练集中选择最不相似的正样本 $x_i^+$ 和最相似的负样本 $x_i^-$ 是不可行的,需要耗费大量的时间与计算,因为产生的三元组集合 $\mathcal{T}$ (穷举所有的图像三元组)是非常庞大的。此外,通过这种方式选出的“难”样本很可能是错误标记或是不良成像的图像,这反而会影响正常的训练过程。

为了解决这个问题,作者没有在整个数据集中选择最不相似的正样本和最相似的负样本,而是在一个小批次中采样所有的样本对。例如,对于每一个训练批次随机抽样 $P$ 个行人,每个行人随机选取 $K$ 张不同的图像,即一个批次含有 $P \times K$ 张图像。随后,对于该批次中的每一张图像 $x_i$ ,在生成三元组来计算损失时选择该批次中最难的正样本和负样本。

综上所述,三元组损失允许网络在输入图像和期望的嵌入空间之间进行端到端的学习,直接针对最终任务去优化网络,简化了度量学习的步骤。在行人重识别任务中,该损失可以通过计算嵌入空间的欧氏距离来简单地聚类行人。然而,在使用三元组来学习时需要挖掘一些难以训练的样本对,即更相似的负样本对和不相似的正样本对。这是使用三元组损失的一个必要步骤,因为缺少难负样本挖掘会导致训练的停滞不前,而选择过难的难负样本又会导致训练变得不稳定从而难以收敛。因此,挖掘适当的三元组对于网络的优化至关重要。

#### 4.2.2 基于无监督的三元组损失

为了解决传统三元组随机采样生成简单样本对而限制网络泛化能力的问题,一种批量难样本挖掘的改进版三元组损失被提出,旨在挖掘更相似的负样本对和不相似的正样本对。同样地,为了能在无监督场景下更好地应用三元组损失,提

高网络的性能，本节提出了无监督场景下难样本的挖掘方法。

1) 难正样本挖掘。当从包含大量图像和身份的数据集中随机抽取少量图像时，在小批量样本中的图像具有相同身份的概率非常低，因此不能被动选择而应该主动为每个样本生成难正样本。显而易见的是，最不会出错的选择是直接将原始图片作为正样本，然而，这种正样本对于网络模型来说过于容易学习，因此很难提高网络模型的判断能力。

由于现有的行人重识别数据面临着遮挡、角度、姿态、色差等问题，对应地，UTL 也定义了一系列随机变换来生成难正样本，这些变换包括图像的裁剪、缩放、翻转以及图像的亮度、对比度、饱和度变化。于是，在每一个训练批次中，UTL 随机为每个图像生成一个替代图像，以形成正样本对。通过这种转换，每一个图像样本  $\mathbf{x}_i$  生成了一个难正样本  $\mathbf{x}_i^+$ 。

2) 难负样本挖掘。当从包含大量图像和身份的数据集中随机抽取少量图像时，虽然在小批量样本中图像具有相同身份的概率非常低，但这也并非不可能。此外，难负样本挖掘的目标是寻找与锚点图像 (Anchor) 较为相似的图像，因此即使小批量样本中每个样本的身份都不相同，UTL 还是希望选择一个与锚点图像 (Anchor) 更相似的样本来组成难负样本对。这需要一种算法来确定具有更高置信度的难负样本。

为了提高样本挖掘的效率和三元组的质量，UTL 没有在整个数据集中选择最不相似的正样本和最相似的负样本，而是在一个小批次中采样所有的样本对。已知在一个小批量训练样本中，如果存在同一个行人的两张图像，那么这两张图像在嵌入空间中很可能是距离彼此最近的。反之，如果两张图像在嵌入空间中的距离较远，那么它们很可能属于不同的行人。基于这个推论，本节提出了一个在小批量训练样本中挖掘难负样本的算法。

---

#### 算法 1: 无监督难负样本挖掘算法

---

```

1: 输入: 锚点样本  $\mathbf{x}_i$ , 小批量训练样本  $\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^N$ 
2: 输出: 难负样本  $\mathbf{x}_i^-$ 
3:   for 同批次其他样本  $\mathbf{x}_j (j \neq i)$  in  $\mathbf{X}$ 
4:     计算  $\mathbf{x}_i$  与  $\mathbf{x}_j (j \neq i)$  的欧氏距离
5:   将距离排序得到样本  $\mathbf{x}_i$  的相似度正序列列表  $\mathbf{R}_i^{N-1} = \{\mathbf{x}_j\}_{j=1}^{N-1}$ 
6:   for  $\mathbf{x}_j$  in  $\mathbf{R}_i^{N-1}$ :
7:     计算  $\mathbf{x}_j$  的相似度正序列列表  $\mathbf{R}_j^{N-1} = \{\mathbf{x}_k\}_{k=1}^{N-1}$ 
8:     if  $\mathbf{x}_i$  不是  $\mathbf{x}_j$  的最近邻 (即  $\mathbf{x}_i \neq \mathbf{R}_j^{N-1}[0]$ )
9:        $\mathbf{x}_i^- \leftarrow \mathbf{x}_j$ 
10:    break

```

---

在每一个小批次训练中,利用欧氏距离度量两个样本间的相似度,产生每个样本 $\mathbf{x}_i$ 的相似度排序结果。假设每一批训练样本 $X = \{\mathbf{x}_i\}_{i=1}^N$ 的个数为 $N$ ,则样本 $\mathbf{x}_i$ 的相似度排序列表表示为 $\mathbf{R}_i^{N-1}$ 。接下来,按顺序遍历该排序列表,并依次为列表 $\mathbf{R}_i^{N-1}$ 中的每个样本 $\mathbf{x}_j$ 计算属于它的排序列表 $\mathbf{R}_j^{N-1}$ 。

在 $\mathbf{x}_j$ 的相似度排序列表 $\mathbf{R}_j^{N-1}$ 中,如果 $\mathbf{x}_i$ 不是 $\mathbf{x}_j$ 的最近邻,则认为 $\mathbf{x}_j$ 很可能是 $\mathbf{x}_i$ 的负样本。相反,如果 $\mathbf{x}_i$ 是 $\mathbf{x}_j$ 的最近邻,则更倾向于认为它们属于同一个行人,因此将继续遍历 $\mathbf{x}_i$ 的相似度排序列表 $\mathbf{R}_i^{N-1}$ ,直到找到其中符合条件的样本。通过这一算法取得的样本对 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 在理论上具有相似的外观和不同的身份,能更有效地学习具有判别性的特征。为了更好地区分,将符合上述条件的难负样本 $\mathbf{x}_j$ 表示为 $\mathbf{x}_i^-$ 。

随机变换针对图像检索常见问题通过多种变换方式生成了难正样本,难负样本挖掘算法以简单而合理的原理无监督地挖掘了难负样本,这对无监督条件下挖掘潜在标签信息具有重要意义。基于无监督三元组损失如公式(4-3)所示。

$$UTL = \sum_i^N [\|f(x_i) - f(x_i^+)\|_2^2 - \|f(x_i) - f(x_i^-)\|_2^2 + \alpha]_+ \quad (4-3)$$

### 4.3 基于局部特征融合的网络模型 (Network Based on Local Feature Fusion)

为了挖掘行人图像中的细粒度信息,屏蔽行人的背景信息,本章提出了一种基于局部特征融合的行人重识别网络(Person Re-identification Network Based on Local Feature Fusion, LFNet),其网络结构如图4-2所示。LFNet共分为四个部分:局部特征提取、局部特征优化、特征融合以及度量学习。




图 4-2 基于局部特征融合的行人重识别网络示意图

Figure 4-2 An illustration of the LFNet



首先，本章选用残差网络 Resnet-50 作为骨干网络（Backbone）来提取网络的全局特征。其次，根据行人身体的结构将全局特征水平切分为三个局部特征，分别表示头部特征、上肢特征、下肢特征。

接下来，采用空间变换器对局部特征进行优化。空间变换器能够根据自身特征主动地对特征图进行空间变换，从而得到不含其他干扰信息的图像。通过优化，局部特征屏蔽了杂乱的背景信息，包含了更多的行人信息。

最终，将优化过的局部特征融合为一个行人的完整特征，并采用 4.2 节提出的基于无监督的三元组损失 UTL 作为度量学习方法。其中，针对行人重识别任务，生成难正样本的随机变换参考了深度学习中常见的图像数据增强处理，具体包括裁剪、左右翻转、轻度旋转（随机旋转不超过 10 度）、对比度、饱和度和亮度调整<sup>[72]</sup>。

以下详细介绍了局部特征提取、局部特征优化和特征融合三大模块。

### 4.3.1 局部特征提取

在第三章中，局部特征的提取是为了行人身份的判别，从而解决遮挡问题。因此，局部特征的划分更加细粒度，适应不同遮挡程度的行人图像。而在本章中，行人局部特征的提取则是为了挖掘具有语义信息的特征，从而优化生成最终的行人特征描述子。因此，本章的特征提取将从语义上进行划分。简而言之，上一章的局部特征提取以判别行人目标，本章的局部特征提取以描述行人目标，不同的目标决定了特征提取的不同方法。

在本章中，对于残差网络 Resnet-50 卷积后的行人特征，LFNet 将其分割为三个部分。如图 4-3 所示，由于行人重识别数据集中的图像仅包含一个对象类别（即人）的实例，并且这些实例大多是直立的，在提取行人局部特征时，本章直接从物理层面上将图像进行水平切分。




图 4-3 局部特征提取

Figure 4-3 Extraction of local features

由于摄像机通常高于行人，在视角上行人的下肢的长度被相对缩短。根据人体比例，本节将行人图像水平分为高度比为 1:2:3 的三个部分，分别对应行人的头

部，上肢和下肢<sup>[73]</sup>。图 4-3 中可以看出，无论行人的状态在直立行走、骑行还是上下楼，该分割方法都能够较好地提取行人的头部、上肢和下肢特征。

### 4.3.2 局部特征优化

从图 4-2 中可以看出，对于每个局部分支，局部特征中仍含有大量的背景信息。考虑到行人重识别图像中背景杂乱的问题，本章在每个局部分支中加入空间变换器（Spatial Transformer, ST）<sup>[74]</sup>对局部特征进行优化，把目标对象纠正到局部特征的正中央，放大，占满整个空间。此外，空间变换器可以通过标准的反向传播进行训练，因此可以直接整合进卷积网络中进行端到端的训练。




图 4-4 局部特征优化

Figure 4-4 Optimization of local features

如图 4-4 所示，空间变换器由三个模块组成：本地化网络（Localisation Net）、网格生成器（Grid Generator）和采样器（Sampler），它们的功能分别是参数预测、坐标映射和像素采集。简单来说，本地网络学习仿射变换矩阵 $\theta$ ，网格生成器根据仿射变换矩阵得到输出图和输入图之间的位置映射关系。采样器根据映射关系计算输出图中每个像素点的值。每个模块具体阐述如下。

本地网络是一个小型的卷积神经网络。它的输入是局部特征，输出是该特征对应的仿射变换矩阵 $\theta$ 。在线性代数中，矩阵运算可以实现图像的平移、旋转或是缩放。在仿射变换中，仿射变换矩阵 $\theta$ 则映射了输入特征和输出特征之间的坐标关系。

网格生成器根据输出特征的坐标点和仿射变换矩阵 $\theta$ 计算出输入特征中的坐标点。输出特征的大小预先定义，因此可以直接得到输出特征的所有坐标点，且仿射变换矩阵 $\theta$ 已由本地网络生成，所以网格生成器的运算是以输出特征的所有坐标点为自变量，以仿射变换矩阵 $\theta$ 为参数进行矩阵运算，得到输入局部特征的坐标点。

采样器根据网格生成器得到的坐标和输入特征（因为像素值要从输入特征中取）来填充输出特征。由于网格生成器计算出了输出特征中每个点对应的输入特

征坐标,在采样阶段就可以直接根据对应的输入特征的坐标点的像素值来对输出特征进行填充,而无需再经过矩阵运算。对于填充方法,本章选用双线性插值,考虑近邻四个坐标点的位置。

综上所述,局部特征的优化不仅能选中特征中的重要信息,还可以将这些区域转换成规范的预期姿态,进而屏蔽杂乱背景的干扰。此外,空间变换器的计算速度非常快,不会减缓训练速度,在使用时不会造成过多的时间开销。

### 4.3.3 特征融合

特征融合常用的方法分别是直接拼接(Concatenation)、逐元素相乘(Element-wise Product)和逐元素相加(Element-wise Sum)。在上一章中,针对空间特征和图像特征的融合,本文采用了逐元素相乘的融合方法。因为空间特征定位了图像中的行人,获取了图像特征中每个值的权重,利用逐元素相乘的融合方法能够突出行人特征并弱化背景特征。

而在本章中,不同的局部特征分别表示了不同的身体部位,这些特征语义上不重叠也没有特别的映射关系。因此,本章采用拼接的融合方法,将优化过的局部特征融合为一个行人的完整特征。局部特征的融合既屏蔽了图像中的背景信息,挖掘了行人的细粒度信息,又综合了整体信息,大大提高了特征的描述能力和可判别性。

## 4.4 实验结果及分析(Experimental Results and Analysis)

考虑到现有的无监督行人重识别方法多基于 Market-1501 和 DukeMTMC-reID 数据集,为了验证本章所提出的方法的有效性,本章同样在这两个数据集上进行实验。采取的评价指标与上一章相同,分别是累计匹配特征(Cumulative Match Characteristics, CMC)曲线和平均准确率均值(Mean Average Precision, mAP)。本节详细说明了实验设置,并将 LFNNet 与现有的方法进行对比和分析。具体内容如下。

### 4.4.1 实验设置

本章首先在源数据集 MSMT17 上训练模型,再将模型参数应用到 Market1501 和 DukeMTMC-reID 数据集训练的初始化中,在训练期间不再使用 MSMT17。LFNNet 选择残差网络 Resnet-50 作为骨干网络,在 ImageNet 数据集上进行预训练,并去掉最后一个全连接层,将最后一个残差块的步长设置为 1。对于无监督的三元组损失 UTL,为每个图像生成一个难正样本,边距 margin 设为 2。在未标记数据集的训练过程中,图像从训练数据集中随机抽取并调整大小为  $384 \times 128$ 。每个批次的训练样本数  $N$  设置为 48。LFNNet 使用动量梯度下降法作为优化算法,动量 momentum 设置为 0.9,初始学习率设置为 0.0001,学习率下

降的乘数因子  $\gamma$  设置为 0.1, 调整学习率的步长设置为 40。通过 60 个 epoch 在未标记数据集上训练模型。在不同数据集上进行的所有实验均遵循上述相同的设置。

## 4.4.2 实验结果及分析

### 1) 对比实验

本节将提出的方法 LFNet 与人工提取特征的方法以及针对行人重识别的最新的无监督学习方法进行了比较。可以看出, 本章提出的方法在两个数据集上都明显优于比较的方法。其中, DukeMTMC-reID 数据集上的性能远高于 Market-1501 数据集上的性能, 这是由于它与 MSMT17 数据集的场景更接近。

首先, 将本章所提出的方法与基于人工特征的方法进行比较, Market-1501 数据集上的比较结果详见表 4-1, DukeMTMC-reID 数据集上的比较结果见表 4-2。人工提取的特征无需任何训练过程即可直接应用于测试数据集, 但是很明显, 这些方法都无法取得良好的性能。当本章的模型与基于人工特征的模型进行比较时, 性能差距最为显著。其主要原因是这些早期的工作大多基于启发式设计, 因此无法学习到最具判别性的特征。

表 4-1 Market1501 数据集上人工方法的性能比较 (%)

Table 4-1 Performance (%) comparison on Market-1501 (Handcrafted Methods)

| 方法           | top-1       | top-5       | top-10      | mAP         |
|--------------|-------------|-------------|-------------|-------------|
| LOMO [11]    | 27.2        | 41.6        | 49.1        | 8.0         |
| BOW [48]     | 35.8        | 52.4        | 60.3        | 14.8        |
| UMDL [42]    | 34.5        | 52.6        | 59.6        | 12.4        |
| <b>LFNet</b> | <b>64.9</b> | <b>79.5</b> | <b>85.3</b> | <b>36.7</b> |

表 4-2 DukeMTMC 数据集上人工方法的性能比较 (%)

Table 4-2 Performance (%) comparison on DukeMTMC (Handcrafted Methods)

| 方法           | top-1       | top-5       | top-10      | mAP         |
|--------------|-------------|-------------|-------------|-------------|
| LOMO[11]     | 12.3        | 21.3        | 26.6        | 4.8         |
| BOW [48]     | 17.1        | 28.8        | 34.9        | 8.3         |
| UMDL [42]    | 18.5        | 31.4        | 37.6        | 7.3         |
| <b>LFNet</b> | <b>66.7</b> | <b>79.8</b> | <b>84.2</b> | <b>47.6</b> |

其次, 将本章所提出的方法与基于聚类的方法进行比较, Market-1501 数据集上的比较结果详见表 4-3, DukeMTMC-reID 数据集上的比较结果见表 4-4。现有的基于聚类的方法往往将聚类的思想融会在网络结构中。这种聚类的方法紧密依赖于包含聚类属性的网络结构, 而非具有聚类属性的度量方法, 这就造成了现有方法的局限性, 因为我们很难将其应用到其他网络中。在本章提出的方法中, 基于无监督学习的三元组损失是一个独立的可移植的损失函数, 它可以单独应用到其他网络结构中。

表 4-3 Market1501 数据集上聚类方法的性能比较 (%)

Table 4-3 Performance (%) comparison on Market-1501 (Clustering)

| 方法           | top-1       | top-5       | top-10      | mAP         |
|--------------|-------------|-------------|-------------|-------------|
| PUL [43]     | 45.5        | 60.7        | 66.7        | 20.5        |
| CAMEL [75]   | 54.5        | -           | -           | 26.3        |
| DECAMEL [44] | 60.2        | 76.0        | 81.1        | 32.4        |
| <b>LFNet</b> | <b>64.9</b> | <b>79.5</b> | <b>85.3</b> | <b>36.7</b> |

表 4-4 DukeMTMC 数据集上聚类方法的性能比较 (%)

Table 4-4 Performance (%) comparison on DukeMTMC (Clustering)

| 方法           | top-1       | top-5       | top-10      | mAP         |
|--------------|-------------|-------------|-------------|-------------|
| PUL [43]     | 30.0        | 43.4        | 48.5        | 16.4        |
| <b>LFNet</b> | <b>66.7</b> | <b>79.8</b> | <b>84.2</b> | <b>47.6</b> |

最后，将本章所提出的方法与无监督域自适应的（Unsupervised Domain Adaptation, UDA）方法进行比较，Market-1501 数据集上的比较结果详见表 4-5，DukeMTMC-reID 数据集上的比较结果见表 4-6。与基于无监督域自适应的行人重识别模型相比，本章提出的方法具有更好的性能。一个关键的原因在于这些模型更多地关注源域中的判别性特征，而忽略了未标记的目标域中的特征提取。与之相反，本章提出的方法利用优化的局部特征进行融合，更好的挖掘了目标域中的细粒度信息。此外，TJ-AIDL 方法还需要额外的属性标签，这限制了它的可扩展性。

表 4-5 Market1501 数据集上无监督域自适应方法的性能比较 (%)

Table 4-5 Performance (%) comparison on Market-1501 (UDA)

| 方法             | top-1       | top-5       | top-10      | mAP         |
|----------------|-------------|-------------|-------------|-------------|
| PTGAN [36]     | 38.6        | -           | 66.1        | -           |
| ATNet [77]     | 55.7        | 73.2        | 79.4        | 25.6        |
| SPGAN+LMP [45] | 57.7        | 75.8        | 82.4        | 26.7        |
| TJ-AIDL [76]   | 58.2        | 74.8        | 81.1        | 26.5        |
| SBGAN [78]     | 58.3        | -           | -           | 27.3        |
| HHL [46]       | 62.2        | 78.8        | 84.0        | 31.4        |
| <b>LFNet</b>   | <b>64.9</b> | <b>79.5</b> | <b>85.3</b> | <b>36.7</b> |

表 4-6 DukeMTMC 数据集上无监督域自适应方法的性能比较 (%)

Table 4-6 Performance (%) comparison on DukeMTMC (UDA)

| 方法             | top-1       | top-5       | top-10      | mAP         |
|----------------|-------------|-------------|-------------|-------------|
| PTGAN [36]     | 27.4        | -           | 50.7        | -           |
| TJ-AIDL [76]   | 44.3        | 59.6        | 65.0        | 23.0        |
| ATNet [77]     | 45.1        | 59.5        | 64.2        | 24.9        |
| SPGAN+LMP [45] | 46.4        | 62.3        | 68.0        | 26.2        |
| HHL [46]       | 46.9        | 61.0        | 66.7        | 27.2        |
| SBGAN [78]     | 53.5        | -           | -           | 30.8        |
| <b>LFNet</b>   | <b>66.7</b> | <b>79.8</b> | <b>84.2</b> | <b>47.6</b> |

## 2) 消融实验

为了验证本章提出方法的有效性,本节分别将全局特征和融合后的局部特征作为最终描述子,实验结果如表 4-7 所示。本节将 Resnet-50 作为基准模型 (Baseline),度量方法选用本章提出的基于无监督的三元组损失 UTL。在这种情况下,实验的唯一变量即为特征描述子,Resnet-50 提取的是全局特征,而 LFNet 提取的是优化后的融合特征。实验结果显示,融合优化后的局部特征有效提高了无监督下行人重识别的性能,mAP 提升了 13.6%,CMC top-1 提升了 18.2%。

表 4-7 Market1501 数据集上的消融实验 (LFNet)

Table 4-7 Ablation Study on Market-1501 (LFNet)

| 方法            | 特征属性          | top-1       | top-5       | top-10      | mAP         |
|---------------|---------------|-------------|-------------|-------------|-------------|
| Resnet-50+UTL | 全局特征          | 46.7        | 61.9        | 68.1        | 23.1        |
| <b>LFNet</b>  | <b>局部特征融合</b> | <b>64.9</b> | <b>79.5</b> | <b>85.3</b> | <b>36.7</b> |

## 4.5 本章小结 (Summary)

本章提出了一种基于无监督学习的三元组损失以及一种基于局部特征融合的无监督行人重识别方法。首先,本章介绍了有监督场景下的三元组损失以及批量难样本三元组挖掘的思想。接下来介绍了提出的基于无监督学习的三元组损失,该损失通过图像的剪裁、亮度调节等随机变换来生成难正样本,通过提出的难负样本挖掘算法来挖掘同一训练批次中的难负样本。该损失不受限于网络结构 and 研究领域,是一种适用于无监督学习的度量学习方法。其次,本章提出了一种基于局部特征融合的无监督行人重识别方法,通过融合优化后的局部特征挖掘行人图像的细粒度信息,并屏蔽图像的背景信息,度量学习方法采用提出的基于无监督学习的三元组损失。最后,本章详细介绍了实验设置,并将提出的方法与其他方法进行了对比和分析,还通过消融实验验证了提出方法的有效性。实验结果表明本章提出的方法具有较好的性能,能够相对准确、鲁棒地完成行人重识别任务。

## 5 总结与展望

## 5 Summary and Future Work

### 5.1 总结 (Conclusion)

行人重识别是判断图像或视频序列中是否存在特定行人的技术。由于其在安保和监控中的重要应用,行人重识别一直受到学术界和工业界的广泛关注。然而,由于摄像机视角和分辨率的不同、光照变化、行人姿态变化、行人遮挡等问题的存在,行人重识别技术面临着巨大的挑战。近年来,深度学习的方法不断应用于行人重识别领域中并取得了良好的效果,极大地推动了行人重识别技术的进步。现有的基于深度学习的行人重识别方法大多是有监督学习的方法,需要大量已标注的数据。而现有的行人重识别数据集规模较小,难以模拟现实场景,大规模的数据标注又需要耗费大量的人力资源,这限制了监督学习方法的可扩展性和实用性。针对上述问题,本文分别提出了基于特征融合的有监督和无监督方法,具体贡献如下:

1) 本文提出的基于图像-空间特征融合的有监督行人重识别方法,通过空间特征和图像特征的融合解决了背景杂乱问题,通过局部特征判别解决了行人遮挡问题。最终利用局部特征训练分类损失,利用全局特征训练三元组损失,通过多损失融合从整体和局部两个方面对行人进行识别,在三个常用数据集上都取得了良好的性能,有效提高了行人重识别的准确率。

2) 本文提出的基于局部特征融合的非监督行人重识别方法,将行人图像分为三个部分,并采用空间转换器优化每个部分的特征,最终通过融合优化后的头部特征、上肢特征和下肢特征挖掘了行人图像中的细粒度信息。同时,本文提出了一种基于非监督学习的三元组损失,解决了现有聚类方法对于网络结构的依赖问题。该方法在两个常用数据集上均取得了较好的性能,提高了行人重识别方法在实际场景中的应用能力。

### 5.2 未来工作的展望 (Prospects for Future Work)

行人重识别方法作为一个具有实际应用需求的研究领域,在未来的工作中还有很多值得思考和改进的地方:

1) 非监督场景下行人遮挡问题的解决。目前有监督的行人重识别方法已经取得了较好的表现,而非监督方向的研究虽然有了一定进展,但相比有监督的方法仍然差距很大。本文在第四章中提出的方法虽然一定程度上屏蔽了背景信息,但对于遮挡问题还没有解决。在有监督学习中遮挡问题可以通过局部特征的判别来解决,这依赖于图像的标签信息。而在非监督学习中数据没有标签的情况下,

盲目使用局部特征进行判别反而会错误的引导网络。因此，无监督场景下行人遮挡问题的解决还有很大的研究空间。

2) 行人检测与行人识别相结合。现有的行人重识别数据集都是通过对采集到的监控视频进行裁剪和标注而得到的单独的行人图像，这需要大量的前期准备工作。而在实际的应用场景中，从视频帧中提取出单独的行人图像再进行行人重识别会降低智能监控系统检索行人的效率。因此，单一的行人重识别模型难以满足实际应用需求，将行人检测与行人重识别相结合具有重要的现实意义和研究价值。

3) 动态目标跟踪。本文的行人重识别方法还是基于静态图片做查询，而目标追踪方法可以动态的跟踪目标对象。因此，将行人重识别方法与目标追踪相结合，就可以实现行人的跨摄像头动态跟踪，这在实际生活中有更大的应用可能。在结合了目标跟踪方法以后，该技术的难点在于寻找行人出现的下一个摄像机。这需要对摄像机的位置和角度进行汇总和分析，对相机信息的采集与处理提出了更高的要求。



## 参考文献

- [1] 丁兆威. 2018 年中国安防行业十大新闻[J]. 中国公共安全, 2019, 426(6):39-42
- [2] Zheng L, Yang Y, Hauptmann A G. Person Re-identification: Past, Present and Future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [3] 李夏凤. 基于深度学习的跨镜追踪技术浅析 [J]. 中国安全防范技术与应用, 2019(01):19-22.
- [4] Zajdel W, Zivkovic Z, Krose B J A. Keeping track of humans: Have I seen this person before?[C]//Proceedings of the 2005 IEEE International Conference on Robotics and Automation. Barcelona: IEEE, 2005: 2081-2086.
- [5] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]//2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). New York: IEEE, 2006, 2: 1528-1535.
- [6] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems. Lake Tahoe: Curran Associates, 2012: 1097-1105.
- [7] 罗浩, 姜伟, 范星, 张思朋. 基于深度学习的行人重识别研究进展 [J]. 自动化学报, 2019, 45(11):2032-2049.
- [8] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[C]//European Conference on Computer Vision. Berlin: Springer, 2008: 262-275.
- [9] Cheng D S, Cristani M, Stoppa M, et al. Custom pictorial structures for re-identification[C]//British Machine Vision Conference (BMVC). Dundee Scotland: British Machine Vision Association, 2011, 1(2): 6.
- [10] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). San Diego: IEEE, 2005, 1: 886-893.
- [11] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 2197-2206.
- [12] Xing E P, Ng A Y, Jordan M I, et al. Distance metric learning, with application to clustering with side-information[C]//International Conference on Neural Information Processing Systems. Vancouver: MIT Press, 2002: 521-528.
- [13] Weinberger K Q, Saul L K. Distance metric learning for large margin nearest neighbor classification[J]. Journal of Machine Learning Research, 2009, 10(1): 207-244.
- [14] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence

- constraints[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. Providence: IEEE, 2012: 2288-2295.
- [15] 周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2017,40(06):1229-1251.
- [16] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Columbus: IEEE, 2014: 152-159.
- [17] Yi D, Lei Z, Liao S, et al. Deep metric learning for person re-identification[C]//2014 22nd International Conference on Pattern Recognition. Stockholm: IEEE, 2014: 34-39.
- [18] Bromley J, Guyon I, LeCun Y, et al. Signature verification using a " siamese" time delay neural network[C]//Advances in Neural Information Processing Systems. Denver: Curran Associates, 1994: 737-744.
- [19] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 3908-3916.
- [20] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based CNN with improved triplet loss function[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 1335-1344.
- [21] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [22] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Hawaii: IEEE, 2017: 403-412.
- [23] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems. Montreal: Curran Associates, 2014: 2672-2680.
- [24] Wu L, Shen C, Hengel A. Personnet: Person re-identification with deep convolutional neural networks[J]. arXiv preprint arXiv:1601.07255, 2016.
- [25] Wang F, Zuo W, Lin L, et al. Joint learning of single-image and cross-image representations for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 1288-1296.
- [26] Zheng L, Zhang H, Sun S, et al. Person re-identification in the wild[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Hawaii: IEEE, 2017: 1367-1376.
- [27] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]//Proceedings of the IEEE Conference on

- Computer Vision and Pattern Recognition. Hawaii: IEEE, 2017: 1077-1085.
- [28] Zhao L, Li X, Zhuang Y, et al. Deeply-learned part-aligned representations for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 3219-3228.
- [29] Xu J, Zhao R, Zhu F, et al. Attention-aware compositional network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 2119-2128.
- [30] Varior R R, Shuai B, Lu J, et al. A Siamese long short-term memory architecture for human re-identification[C]//European Conference on Computer Vision. Cham: Springer, 2016: 135-153.
- [31] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich: Springer, 2018: 480-496.
- [32] Song C, Huang Y, Ouyang W, et al. Mask-guided contrastive attention model for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 1179-1188.
- [33] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 2285-2294.
- [34] Liu H, Feng J, Qi M, et al. End-to-end comparative attention networks for person re-identification[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3492-3506.
- [35] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE International Conference on Computer Vision. Hawaii: IEEE, 2017: 2223-2232.
- [36] Wei L, Zhang S, Gao W, et al. Person transfer GAN to bridge domain gap for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 79-88.
- [37] Qian X, Fu Y, Xiang T, et al. Pose-normalized image generation for person re-identification[C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich: Springer, 2018: 650-667.
- [38] Liu H, Jie Z, Jayashree K, et al. Video-based person re-identification with accumulative motion context[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 28(10): 2788-2802.
- [39] Li Y, Zhuo L, Li J, et al. Video-based person re-identification by deep feature guided

- pooing[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. Hawaii: IEEE, 2017: 39-46.
- [40] Zhou Z, Huang Y, Wang W, et al. See the forest for the trees: Joint spatial and temporal recurrent neural networks for video-based person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Hawaii: IEEE, 2017: 4747-4756.
- [41] Long M, Zhu H, Wang J, et al. Unsupervised domain adaptation with residual transfer networks[C]//Advances in Neural Information Processing Systems. Barcelona: Curran Associates, 2016: 136-144.
- [42] Peng P, Xiang T, Wang Y, et al. Unsupervised cross-dataset transfer learning for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 1306-1315.
- [43] Fan H, Zheng L, Yan C, et al. Unsupervised person re-identification: Clustering and fine-tuning[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2018, 14(4): 83.
- [44] Yu H X, Wu A, Zheng W S. Unsupervised person re-identification by deep asymmetric metric embedding[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018.
- [45] Deng W, Zheng L, Ye Q, et al. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 994-1003.
- [46] Zhong Z, Zheng L, Li S, et al. Generalizing a person retrieval model hetero-and homogeneously[C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich: Springer, 2018: 172-188.
- [47] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 770-778.
- [48] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]//Proceedings of the IEEE International Conference on Computer Vision. Santiago: IEEE, 2015: 1116-1124.
- [49] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[C]//Proceedings of the IEEE International Conference on Computer Vision. Hawaii: IEEE, 2017: 3754-3762.
- [50] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence,

2009, 32(9): 1627-1645.

- [51] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[C]// Advances in Neural Information Processing Systems. Montreal: Curran Associates, 2015: 91-99.
- [52] Wang X, Doretto G, Sebastian T, et al. Shape and appearance context modeling[C]//2007 IEEE 11th International Conference on Computer Vision. Venice: IEEE, 2007: 1-8.
- [53] Jose C, Fleuret F. Scalable metric learning via weighted approximate rank component analysis[C]//European Conference on Computer Vision. Cham: Springer, 2016: 875-890.
- [54] Karanam S, Gou M, Wu Z, et al. A comprehensive evaluation and benchmark for person re-identification: Features, metrics, and datasets[J]. arXiv preprint arXiv:1605.09653, 2016, 2(3): 5.
- [55] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 2197-2206.
- [56] Barbosa I B, Cristani M, Caputo B, et al. Looking beyond appearances: Synthetic training data for deep cnns in re-identification[J]. Computer Vision and Image Understanding, 2018, 167: 50-62.
- [57] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[C]//Proceedings of the IEEE International Conference on Computer Vision. Hawaii: IEEE, 2017: 3800-3808.
- [58] Zheng Z, Zheng L, Yang Y. Pedestrian alignment network for large-scale person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(10): 3037-3045.
- [59] Geng M, Wang Y, Xiang T, et al. Deep transfer learning for person re-identification[J]. arXiv preprint arXiv:1611.05244, 2016.
- [60] Zhang Y, Xiang T, Hospedales T M, et al. Deep mutual learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 4320-4328.
- [61] Ustinova E, Ganin Y, Lempitsky V. Multi-region bilinear convolutional neural networks for person re-identification[C]//2017 14th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). Lecce: IEEE, 2017: 1-6.
- [62] Liu X, Zhao H, Tian M, et al. Hydraplus-net: Attentive deep features for pedestrian analysis[C]//Proceedings of the IEEE International Conference on Computer Vision. Hawaii: IEEE, 2017: 350-359.
- [63] Li W, Zhu X, Gong S. Person re-identification by deep joint learning of multi-loss

- classification[J]. arXiv preprint arXiv:1705.04724, 2017.
- [64] Su C, Li J, Zhang S, et al. Pose-driven deep convolutional model for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. Hawaii: IEEE, 2017: 3960-3969.
- [65] Yao H, Zhang S, Hong R, et al. Deep representation learning with part loss for person re-identification[J]. IEEE Transactions on Image Processing, 2019, 28(6): 2860-2871.
- [66] Chen Y, Zhu X, Gong S. Person re-identification by deep learning multi-scale representations[C]//Proceedings of the IEEE International Conference on Computer Vision Workshops. Hawaii: IEEE, 2017: 2590-2600.
- [67] Wei L, Zhang S, Yao H, et al. GLAD: Global-local-alignment descriptor for pedestrian retrieval[C]//Proceedings of the 25th ACM International Conference on Multimedia. Mountain View: Association for Computing Machinery, 2017: 420-428.
- [68] Lan X, Wang H, Gong S, et al. Deep reinforcement learning attention selection for person re-identification[J]. arXiv preprint arXiv:1707.02785, 2017.
- [69] Si J, Zhang H, Li C G, et al. Dual attention matching network for context-aware feature sequence based person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 5363-5372.
- [70] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 1-9.
- [71] Schroff F, Kalenichenko D, Philbin J. FaceNet: A unified embedding for face recognition and clustering[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 815-823.
- [72] Shorten C, Khoshgoftaar T M. A survey on image data augmentation for deep learning[J]. Journal of Big Data, 2019, 6(1): 60.
- [73] Bogin B, Varela-Silva M I. Leg length, body proportion, and health: a review with a note on beauty[J]. International Journal of Environmental Research and Public Health, 2010, 7(3): 1047-1075.
- [74] Jaderberg M, Simonyan K, Zisserman A. Spatial transformer networks[C]//Advances in Neural Information Processing Systems. Montreal: Curran Associates, 2015: 2017-2025.
- [75] Yu H X, Wu A, Zheng W S. Cross-view asymmetric metric learning for unsupervised person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 994-1002.
- [76] Wang J, Zhu X, Gong S, et al. Transferable joint attribute-identity deep learning for unsupervised person re-identification[C]//Proceedings of the IEEE Conference on Computer

Vision and Pattern Recognition. 2018: 2275-2284.

- [77] Liu J, Zha Z J, Chen D, et al. Adaptive transfer network for cross-domain person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 7202-7211.
- [78] Huang Y, Wu Q, Xu J S, et al. SBSGAN: Suppression of inter-domain background shift for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. Seoul: IEEE, 2019: 9527-9536.





## 学位论文原创性声明

本人郑重声明：所呈交的学位论文《基于特征融合的行人重识别方法研究》，是本人在导师指导下，在中国矿业大学攻读学位期间进行的研究工作所取得的成果。据我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

年 月 日

# 学位论文数据集

|                                                |              |                                                  |                   |      |
|------------------------------------------------|--------------|--------------------------------------------------|-------------------|------|
| 关键词*                                           | 密级*          | 中图分类号*                                           | UDC               | 论文资助 |
| 行人重识别；特征融合；无监督学习；三元组损失；局部特征                    | 公开           | TP183                                            | 004               | 无    |
| 学位授予单位名称*                                      | 学位授予单位代码*    | 学位类别*                                            | 学位级别*             |      |
| 中国矿业大学                                         | 10290        | 工程硕士专业学位                                         | 硕士                |      |
| 论文题名*                                          |              | 并列题名*                                            | 论文语种*             |      |
| 基于特征融合的行人重识别方法研究                               |              | Person Re-identification Based on Feature Fusion | 中文                |      |
| 作者姓名*                                          | 谭玉莹          | 学号*                                              | TS18170096P21     |      |
| 培养单位名称*                                        | 培养单位代码*      | 培养单位地址                                           | 邮编                |      |
| 中国矿业大学                                         | 10290        | 江苏省徐州市                                           | 221116            |      |
| 学科专业*                                          | 研究方向*        | 学制*                                              | 学位授予年*            |      |
| 软件工程                                           | 计算机视觉        | 2 年                                              | 2020              |      |
| 论文提交日期*                                        |              | 2020 年 6 月                                       |                   |      |
| 导师姓名*                                          | 张国鹏          | 职称*                                              | 教授                |      |
| 评阅人                                            |              | 答辩委员会主席*                                         | 答辩委员会成员           |      |
| 盲评                                             |              | 曹天杰                                              | 张磊、王珂、陈朋朋、丁怀舟、韩丽霞 |      |
| 电子版论文提交格式 文本（√） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） |              |                                                  |                   |      |
| 推荐格式：application/msword; application/pdf       |              |                                                  |                   |      |
| 电子版论文出版（发布）者                                   | 电子版论文出版（发布）地 |                                                  | 权限声明              |      |
|                                                |              |                                                  |                   |      |
| 论文总页数*                                         |              | 52                                               |                   |      |
| 注：共 33 项，其中带*为必填数据，共 22 项。                     |              |                                                  |                   |      |