

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 基于监控场景的行人重识别方法的研究与应用

专业学位类别 工 程 硕 士

学 号 201522060717

作 者 姓 名 杨新雨

指 导 教 师 刘 明 教授

分类号_____密级_____

UDC ^{注1} _____

学 位 论 文

基于监控场景的行人重识别方法的研究与应用

(题名和副题名)

杨新雨

(作者姓名)

指导教师

刘 明

教 授

电子科技大学

成 都

(姓名、职称、单位名称)

申请学位级别 **硕士** 专业学位类别 **工 程 硕 士**

工程领域名称 **计算机技术**

提交论文日期 **2018.3.23** 论文答辩日期 **2018.5.18**

学位授予单位和日期 **电子科技大学** **2018 年 6 月**

答辩委员会主席_____

评阅人_____

注 1：注明《国际十进分类法 UDC》的类号。

Research and Design of Person Re-Identification Method for Surveillance Scenarios

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline: **Master of Engineering**

Author: **Yang Xinyu**

Supervisor: **Prof.Liu Ming**

School: **School of Computer Science & Engineering**

摘 要

随着社会经济的高速发展，人们对人身安全与财产安全的要求日渐提高。安防系统得到了人们的重视，随之而来的便是监控设备的普及。监控设备数目的大量增加使得监控视频的数据量变得日益庞大，仅仅依靠传统的人工处理监控数据的方式已经远远不能满足需要，因此智能视频监控技术迅速成为一个研究热点，将计算机视觉与监控技术相结合的智能监控系统成为一个重要的研究应用方向，其中行人重识别由于其重要研究的意义与广泛的应用场景得到了人们的重视。

近年来，随着大规模的数据集的诞生以及能够充分利用这样的数据集的深度学习系统的出现，基于深度学习的目标检测与跟踪算法取得了较好的成果。但在跨多摄像头视野的情景下，对特定目标进行检索识别的效果依然有待提升。行人重识别主要关注于判断给定的两个行人图像是否属于同一行人，其中给定的行人图像是已经从场景中人工标注裁取好的。目前多数学者依旧将目标检测与行人重识别作为计算机视觉领域中互相独立的问题，将两者结合应用的方法尚未普及，所以在监控场景图像中识别特定行人可以分为两步来做，即行人检测过程与行人重识别过程。

本文在研究常用目标检测算法和行人重识别算法的基础上，提出一种基于监控场景的端到端的行人重识别方法。本文将此问题作为一个序列模型处理，利用行人检测指引行人重识别的思想，将循环神经网络与注意力机制结合来进行目标行人检索识别，能够减少单次循环时所需要处理的计算量；然后使用 ResNet 网络提取图像特征，将提取好的目标行人的特征信息加入长短期记忆网络，用于指引注意力模型的在监控场景图像中的关注区域，最后结合多次从场景图像中观察所得到的信息，推论出场景图像中与目标行人最相似的目标，进行特征距离计算与排序。本文加强了行人检测与行人重识别之间的联系，减少了模型之间的误差。由于减少了与目标行人进行重识别匹配的候选行人的数量，所以本文算法能以更小的计算量完成行人重识别任务。本文还通过将多种行人检测方法 with 行人重识别方法结合来研究行人检测效果对行人重识别的影响。在多个行人重识别数据集上的测试实验，证明了本文算法的有效性。

关键词：行人重识别，目标检测，注意力机制，循环神经网络

ABSTRACT

With the rapid development of economy, people have higher and higher demands for safety of property and body. Thus, surveillance system has drawn many researchers' attentions. With the popularization of surveillance cameras, the data from surveillance cameras becomes enormous gradually. The traditional way of processing surveillance data by manpower is impracticable. So, intelligent video surveillance that focus on how to combine computer vision and surveillance system becomes a hot topic rapidly. Among this, person re-identification draws more and more people's attentions due to its wide range of application scenarios and research significance.

Recently, with the appearance of many large-scale datasets and deep learning systems that could efficiently use them, object detection and tracking has made significant progress. However, in a scenario that people wants to find a specific target person from multiple cameras' view, the performance is still limited. Most researchers still consider object detection and person re-identification as two independent tasks in computer vision, the study of how to combine them is few. Nowadays, the task of searching a target person from cross-camera view is normally divided into two independent tasks, i.e, person detection and person re-identification.

This thesis introduces an end-to-end method that uses attention model and Recurrent neural network to identify the person of interest. This thesis considers this problem as sequence modeling and let the detection process guide the identification process and combines RNN with attention mechanism. We first use ResNet to extract features of the target person, then add them to a ConvLSTM to help it choose the next focus region, combines all the observation at last to infer person who are most likely to be the target person. This method could reduce the number of images from surveillance video that need to be processed for person re-identification and performs the identification task with less computation cost and time. This thesis also compares different combinations of detection methods and re-identification methods. The method proposed above is proved to be valid by testing on several datasets.

Key words: Person Re-identification, Object Detection, Attention Mechanism,
Recurrent Neural Network

目 录

第一章 绪 论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 目标检测	3
1.2.2 行人重识别	4
1.3 本文的研究内容	6
1.4 论文组织结构	7
第二章 相关理论与技术介绍	8
2.1 目标检测介绍	8
2.1.1 滑动窗口检测	10
2.1.2. R-CNN(Region with Convolutional Neural Network Feature).....	11
2.1.3 空间金字塔池化	12
2.1.4 Fast R-CNN	14
2.1.5 Faster R-CNN	15
2.1.6 实时检测算法	15
2.2 行人重识别简介	17
2.2.1 行人的特征表示	17
2.2.2 距离度量	18
2.3 端到端的行人重识别系统	20
2.4 本章小结	21
第三章 基于监控场景的行人重识别算法的设计	22
3.1 算法框架描述	23
3.2 初始记忆单元	26
3.3 基于多次观察的行人检测	26
3.3.1 梯度消失问题	27
3.3.2 加入目标特征的 LSTM	29
3.4 注意力机制	33
3.4.1 Hard Attention 与 Soft Attention.....	34
3.4.2 glimpse	35
3.4.3 循环注意力模型	36

3.5 训练策略	39
3.6 特征提取	40
3.7 算法的效率分析	42
3.8 本章小结	43
第四章 数据集及评测方法	44
4.1 数据集介绍	44
4.1.1 CUHK-SYSU 数据集	44
4.1.2 PRW 数据集	45
4.2 评价指标	48
4.3 实验设计	48
4.4 本章小结	49
第五章 实验数据分析	50
5.1 实验环境	50
5.2 观察次数的影响	51
5.3 算法性能比较	51
5.3.1 检测器与识别器结合的性能	51
5.3.2 在 CUHK-SYSU 数据集上的性能	56
5.3.3 在 PRW 数据集上的性能	59
5.3.4 运行时间对比	61
5.4 本章小结	61
第六章 总结与展望	62
6.1 本文总结	62
6.2 存在的问题与不足	62
6.3 未来工作展望	63
致 谢	64
参考文献	65

第一章 绪论

1.1 研究背景及意义

经济水平的快速提高、科技的高速发展使得人民生活水平质量得到不断的提高，同时也提高了群众对人身安全与财产安全保障的要求。在此情况下，监控设备得到了广泛的普及。安防监控系统被广泛应用到各个领域，它监视着人们在公共场所的行为。早在 1997 年，美国国防高级研究项目署便成立了视觉监控项目 VSAM(Visual Surveillance and Monitoring)^[1]。许多学者也投入到了对智能监控系统的研究当中，如 Northwestern University 的 IVPL 实验室，他们从数字视频流中提取出有用的信息并应用到远程监控系统中；中央佛罗里达大学的计算机视觉实验室做了大量关于智能监控的研究，其研发出的 KNIGHT^[2]系统已经成功应用于当地警察局的电子监控系统。据报道，在 2013 年的统计数据中，我国已建成世界上最大的视频监控网，监控摄像头超过 2000 万个，投资数额超过 3200 亿元^[3]。视频监控的建设与应用，在打击犯罪和维护社会稳定方面已经取得了不可替代的地位。

视觉是人类获取外界信息最重要的方式之一，而监控设备则是安防系统的视觉，如何有效利用和处理监控设备获取的信息对安防系统有着至关重要的意义。社会经济的高速发展、硬件设备价格的降低导致监控设备的普及，监控视频数据的规模变得空前巨大，远远超出一般人的处理能力。仅仅由人力来处理如此大的信息量显然是不合理的。例如在轰动全国的周克华系列案中，为了尽快锁定犯罪嫌疑人活动轨迹，警方调动了大量警力人员，对上万个视频图像一一进行排查甄别，耗时 24 小时后，才找到了犯罪嫌疑人的活动踪迹^[4]。仅仅依靠人工排查的方法来处理如此大规模的信息，不仅耗时耗力，而且效率低下，更容易错过破案黄金时期。因此，如何对监控视频数据加以分析处理得到了越来越广泛的关注，也成为计算机视觉的一个重要的应用方向。其中针对特定嫌疑目标尤其是人的监控视频检索成为视频侦查工作中的一项重要研究课题。

一般来说，一个可行的视频监控的行人重识别系统可以被分为三个部分：行人检测、行人追踪与行人查询。通常把前面两个问题作为相对独立的计算机视觉问题。行人重识别主要研究第三个部分即行人查询，旨在从一系列的行人图片中匹配到目标行人，其中最大的难点在于当同一个目标人物在复杂的外观变换下如何正确匹配。它在视频监控方面有许多应用，如嫌疑人追踪^[5]、多摄像头行人追踪^[6]、行人活动分析^[7]等。在稳定的环境中，使用人脸等生物特征来进行行人识别的理论与技术已经发展得较为成熟^[8,9,10,11,12]。但在实际应用场景中，由于人物姿态的

复杂变换、摄像头的视角不同、光照问题、分辨率问题、监控背景环境的复杂，其获取的行人图像往往质量较低，因此依靠人脸特征来解决行人重识别问题是困难且不可靠的。图 1-1 展示了行人在不同摄像头下的图像。



图 1-1 同一行人在不同镜头下的图像

由上述背景可知，行人重识别在监控安防领域有着重要的研究应用价值。然而目前行人重识别的研究是基于裁剪好的行人图像进行匹配，在监控场景中，行人图像区域通常只占据监控画面的很小一部分，因此不能直接将现有的行人重识别方法应用于监控场景。基于深度学习在目标检测和行人重识别领域的良好发展，本文研究了将两者进行结合应用于监控场景的方法，形成端到端的行人重识别方法，更具有实用性和研究前景。

1.2 国内外研究现状

虽然在许多应用场景中需要同时使用目标检测与行人重识别算法，例如机场的行人监控、无人超市监控等，但到目前为止，目标检测与行人重识别通常被作为计算机视觉的两个独立问题来研究。如前文所述，一个可实际运用的智能视频监控系統通常可以被分为三个模块：行人检测、行人追踪与行人重识别，其中行人检测被视为目标检测的一个子问题。下面介绍目标检测以及行人重识别的发展与研究现状。

1.2.1 目标检测

目标检测任务可以被概略定义为从静态图片中检测出是什么物体、在什么位置。它衍生于目标识别任务但却比目标识别任务更加复杂，传统的目标识别任务旨在判断图像中是否存在特定种类的物体。目标检测对于人类而言，不过是一项非常简单的任务。通过对图片中不同颜色区域的辨别很容易找出各个物体的位置并区分它们的类别。然而对于计算机而言，它面对的图像是一个像素矩阵，很难直接从图像矩阵中理解、获取出抽象物体的概念，例如检测出图中是否存在小猫。而复杂的背景环境或者多个物体混杂在一起等情况使目标检测任务变得更加困难。目标检测的相关研究工作一直是计算机视觉领域的研究热点。2005 年，由 Everingham 等人发起的 PASCAL Visual Object Classes Challenge 引起了许多计算机视觉研究人员的兴趣，这项挑战主要解决基于静态图片的目标检测、分类以及分割问题。到 2012 年，PASCAL 数据库已经增长到包含 11530 张图片，其中有 24750 个目标带有标注。Viola^[13]提出了基于 Haar-like 特征与 AdaBosst 算法框架的目标检测算法，该算法首先利用 Haar-like 特征分类，然后使用滑动窗口方法来准确定位，可以比较好地解决人脸检测问题。N.Dalal 与 B.Triggs^[14]提出使用图像局部梯度方向直方图（Histogram of Oriented Gradient,HOG）作为特征的行人检测算法，并构建了 INRIA Person dataset。自然界的许多物体具有运动能力，在其运动过程中通常会发生形态变化，针对物体的形态变化问题，Felzenszwalb^[15]提出了 DPM(Deformable Part Model)算法，该算法是目标检测中最为经典的算法之一，在 PASCAL 竞赛中展现出优异的效果，DPM 的本质是弹簧形变模型。Malisiewicz^[16]提出一种简单高效的集成学习算法，获得了良好的泛化性能。在图像分类方面，Krizhevsky^[17]利用深度卷积神经网络获得了大幅的准确率提高，在其思想与方法的影响下，目标检测的最高准确率的也得到了提升。R-CNN 使用候选区域方式(region proposal)来代替传统的滑动窗口检测方式，通过去除掉图像中明显没有检测目标的区域，大大地减少了检测范围，提高了检测的效率。

与图像分类不同，目标检测需要将图片中的物体定位。其中一种定位思想就是将其视为回归问题。然而，Szegedy 的研究^[19]表明，在实际应用中这种方法的效果并不理想。另一种替代的方法是建立一个滑动窗口检测器。这种方式已经在卷积神经网络（Convolutional neural network, CNN）中被应用超过了 20 年。尤其是在针对有特定限制的目标中，例如脸^[20,21]和行人^[22]。Ross Girshick 等人采用滑动窗口方式并使用一个五层卷积网络，通过使用 Caffe^[23]从每一个候选区域（region proposal）中提取 4096 维的特征向量来进行检测。根据 Krizhevsky 的描述^[24]，Caffe 实现了 CNN。继 2014 年的 R-CNN 之后，后续推出了 Fast R-CNN^[25]，Fast R-CNN

融合了 R-CNN 和 SPP-NET^[26]的优点,在同样使用最大规模网络的情况下, Fast R-CNN 与 R-CNN 相比,训练时间从 84 小时减少为 9.5 小时,测试时间从 47 秒减少为 0.32 秒。

Joseph Redmon 等人发布了 YOLO^[27],一种目标检测的新方式。之前的目标检测方法是通过训练分类器来执行检测,而 YOLO 将目标检测作为一个回归问题。每一步通过神经网络从全图中预测边界和分类概率。因为整个检测流程在同一个网络之中,所以在检测执行可以被直接优化为端对端的。YOLO 大幅提高了检测的速度。

Wei Liu^[28]等人提出一种新的检测方法 SSD(Single shot MultiBox Detector)。将检测过程整合在一个深度神经网络中。SSD 结合了 Faster R-CNN 与 YOLO 的优点。相比于 YOLO, SSD 能够取得更高的精度,即使是在输入图像较小的情况下,例如对于 PASCAL VOC 2007 中大小为 300×300 的图像,SSD 也取得了 72.1%的 mAP,并且速度能够达到 58fps。

1.2.2 行人重识别

行人重识别即利用计算机视觉技术判断图像或者视频序列中是否存在特定行人的技术。广泛被认为是一个图像检索的一个子问题:给定一个监控行人图像,检索跨设备下的该行人图像。在一般的重识别系统中,给定一个检索目标,系统则会计算出其与检索库中的各个样本的相似度,给出排名最高的数个检索结果。在监控视频的场景中,由于光照、相机角度和机器分辨率等方面的原因,通常无法得到高质量的人脸图片。当人脸识别无法得到很好的效果的时候,行人重识别就展现出它重要的意义。行人重识别在学术界已经有多年的研究发展,但直到最近几年深度学习的兴盛,才取得了巨大的突破。下图展示了行人重识别研究的发展历史:




图 1-2 行人重识别研究的发展

行人重识别研究源自对跨多摄像头追踪问题的研究，起初并没有被作为一个独立的课题被提出研究，而是作为跨摄像头追踪问题的衍生问题。1997 年，Huang 和 Russell 提出一种贝叶斯公式，用于评估出现在监控视野中的行人是在另一个监控图像中出现过的同一个行人的概率。行人重识别这一概念是在 2005 年，由来自 Amsterdam 大学的 Wojciech Zajdel, Zoran Zivkovic 和 Ben J. A 正式提出。在他们 2005 年的论文“Keeping track of humans: Have I seen this person before?”中，Zajdel 等人提出“当一个人离开当前视野并在其后又重新出现时重新识别他”的重识别概念^[29]。2006 年，Gheissari^[30]等人利用人的整体外表特征来替代人脸等生物特征来进行重识别，并在通过三个独立摄像头采集到的包含 44 个行人的数据集上得到验证。自此，行人重识别被视为一个与多摄像头追踪相独立的计算机视觉问题。2010 年，L.Bazzani 等人的研究中，通过随机选取视频帧来处理视频中的多帧图像。M.Farenzena 也做了相似的研究。这两篇文章都使用颜色这一常见的视觉特征来作为重识别的重要依据，他们的研究表明对每一个人使用多帧图像处理相比只使用单帧图像处理，准确率有着较大的提升。在 2014 年，深度学习取得的巨大成果被应用到了行人重识别领域，Yi 等人与 Li 等人都通过使用 Siamese 神经网络来判别一对输入图像是否属于同一个人。选取 siamese 模型的原因是每个检测对象的训练样本是有限的。Yi 等人还提出了一种损失函数，能够更好地分辨人体的部位。自此深度学习方法在行人重识别领域开始盛行。虽然大多数的重识别研究中使用的都是已经人工标注好的边框或是由特定检测器标注好的边框，但研究行人检测对行人重识别准确率的影响显然是具有重要意义的。同样是在 2014 年，Xu 组合了多种检测算法与重识别算法来评估其效率，通过在 CAMPUS 数据集上的进行对比，证明了将检测模块与重识别组合在一起比将它们独立使用有着更高的行人检索准确率。

行人重识别问题中的行人图像来自于多个不同的监控摄像头，所以有着以下特点：

1. 在复杂的监控环境中，由于获取图像的质量低、拍摄角度问题、光照条件恶劣等原因，通常无法获取高质量的人的脸部生物信息，所以一般利用人的外表特征来进行识别。
2. 在多个不同的摄像头中，因为环境的变化以及行人的姿势的不同，同一个人物在不同图片中，通常外貌特征会产生一定程度的变化。
3. 在由不同摄像头获取的图片中，由于行人姿态以及环境的变化，不同行人的图片可能比同一行人的图片看起来更为相似。

目前，行人重识别领域的研究工作主要集中在以下两个方面：

- 研究行人对象的特征表示方法，即寻找能够不受外界环境变化的影响而有效地区分不同行人的特征表达方式。
- 研究距离度量学习方法，希望找到一个具有分辨行人能力的距离度量函数，通过该函数能够使得同一个行人的图像之间的特征距离小于不同行人图像之间的特征距离。

在基于特征表示的方法中，常用的视觉特征有颜色直方图、纹理特征和局部特征等等。其中最为常用的特征就是颜色，纹理则不那么被常使用。但是这些特征描述子并不稳定，容易受到环境的影响而产生变化。例如光照可能导致颜色的变化，姿势与视角的变化可能导致纹理描述的变化。目前大多数的方法是将整张的图像划分为多个区域来形成更有效的特征表示模型。2002 年，Xing^[31]提出基于马氏距离的距离测度学习，2007 年，Davis^[32]提出基于信息论理论的距离测度学习方法。到目前为止，虽然行人重识别问题已经得到了学者的重视和大力发展，但行人重识别的问题依然没有得到很好的解决，现阶段的重识别准确率依然比较低，离实际应用仍有一定的性能差距。

1.3 本文的研究内容

当前的行人重识别研究大多基于已经裁剪好的行人图像，主要研究如何将识别目标与候选集当中的行人图像进行匹配。而在监控视频的应用场景中，行人在监控图像中通常只占据一小部分。因此，在监控视频中进行检索识别特定的目标行人任务可以被分为两个过程：首先利用行人检测技术从监控图像中裁剪出行人所在区域，然后将获取到的候选行人目标送入重识别网络进行匹配。本文工作与研究内容为：

1. 提出一种检索行人重识别方法，把从监控视频场景中识别特定目标行人任务当作一个序列模型问题，利用循环神经网络将原来的两级的先进行行人检测再进行行人重识别的流程变为一个更为统一的检测重识别流程，即端到端的行人重识别方法。
2. 通过引入目标行人的特征信息，使得基于注意力模型的检测方法由原来的对与行人相似的区域增加注意力变为对与特定目标行人相似的区域增加注意力，从而使得整个检测过程更具有目的性。
3. 通过使用注意力模型来处理图像，结合引入的目标行人信息，减少了整个行人重识别网络的处理次数，从而减少了整个流程所消耗的时间。

1.4 论文组织结构

第一章为绪论，首先介绍视频监控安防系统的重要性与将其智能化的重要意义，阐述了其两个重要模块即目标检测与行人重识别在国内外的研究现状，然后介绍了本文的研究内容。

第二章介绍了相关理论与技术，包括目标检测的常用理论技术以及它们的优势及局限，概略介绍了行人重识别的研究要点。

第三章是基于监控场景的行人重识别方法的设计，是本文的主要研究内容。本章介绍了基于监控场景的行人重识别方法的详细设计，并针对算法框架中的每一个组成部分进行介绍。

第四章对进行算法验证的数据集进行介绍，并给出了实验的设计思想。

第五章是实验数据分析。对在各个数据集上算法的性能结果进行分析，并与一些其它现有的方法进行对比。

第六章是论文的总结与展望部分。该部分对基于监控场景的行人重识别算法作出概括与分析。指出算法上的缺点与不足，并分析了算法改进的方向。

第二章 相关理论与技术介绍

视频监控系统需要同时利用目标检测技术与行人重识别技术。本章将简略介绍经典与常用的目标检测技术与行人重识别技术。虽然在许多应用场景中需要同时使用目标检测技术与行人重识别技术，但到目前为止，大多数研究人员还是把行人检测与行人重识别作为两个相对独立的任务处理，行人检测注重从完整的场景图像中标注出行人，而行人重识别注重于将已经从完整的场景图像中提取出的行人图像与目标行人进行匹配。

2.1 目标检测介绍

目前，深度学习网络在图像分类上的表现已经比人类更优秀，但人类通过视觉观察世界时所完成的远远不止分辨物体这一项简单任务，例如，我们同样也能找出在视野中出现物体的精确位置以及辨别出现在视野中的所有物体，这些问题都比简单的图像分类问题更加复杂与困难。目标检测是计算机视觉领域中一个新兴的应用方向。相比之前的发展阶段，目标检测的效果在最近几年取得了巨大的提升。为了更好地阐述目标检测任务，我们首先利用图 2-1 将与分类任务(Classification)、定位任务(Localization)与检测任务(Detection)做比较。




图 2-1 不同任务对比。(a) 图片分类；(b) 定位任务；(c) 目标检测

图片分类任务使用算法遍历整张图片，判断其中的对象是什么类别，可以判断多类物体；定位问题判断物体在图片中的具体位置，一般来说只判断某一类物体在图片中所处的位置；检测任务相当于分类任务与定位任务的结合，它既需要判断图中有哪些物体，还需要找到它们的精确位置，并且图片中可以出现多个甚至多类物体。从分类问题到定位问题再到检测问题，可以说是从简单到困难。例如，给出图 2-1(a)，判断图片 2-1(a)是否是猫，这是一个图片分类问题；给出图 2-1(b)，

找出图中猫所在的准确位置是一个定位问题；给出图 2-1(c)，找出图中所有的目标物体及它们分别所在的位置则是目标检测问题。

目标检测问题研究如何从给定的图片中精确地找到物体所处的位置，并判断物体的类别。它与目标分类的问题区别主要在于它不仅需要判断物体的类别，还需要找到物体在图片中的精确位置，并且图片中可能有多个物体需要处理。由此带来两个主要问题。首先，需要处理大量的候选区域，因为这些区域只提供了物体的大体位置，通过对大量的候选区域使用高质量的分类器来判断其中是否存在目标物体；其次则是需要重新定位来确定它们的精确位置。图 2-2 展示了自 2014 年以来出现的关键的目标检测算法。




图 2-2 2014 年以来的目标检测方法

目前，目标检测的评估标准主要是 mAP(mean average precision)。在检测多个类别的物体时，其中 precision 与 recall 的含义如公式 (2-1) 所示：

$$\text{precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$\text{recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}} \quad (2-1)$$

precision 表示在全部识别出的图片中的正确识别率，而 recall 表示被正确识别出的数量占实际总数量的比例。评估一个分类器的性能可以观察 precision 与 recall 的变化情况。一个好的分类器能在识别阈值变化时，能够在 recall 增长的同时保持 precision 在一个很高的水平，而性能较差的分类器可能会损失很多的 precision 值才能得到 recall 的提高。目标检测的每一个类别都可以按照其 recall 与 precision 绘制一条曲线，较好的分类器在其 precision-recall 曲线下的面积应当是较大的。Average Precision(AP)就是该曲线下的面积，而 mAP 就是多个类别 AP 的平均值。图 2-3 给出上述目标检测算法间的性能对比：




图 2-3 当前主流目标检测算法的性能比较

2.1.1 滑动窗口检测

在介绍上述算法之前，首先介绍滑动窗口检测算法。滑动窗口是目标检测的经典算法之一，它的思想可以概述为：给定一张图片，首先选取一个特定大小的窗口，然后将窗口中的信息内容传递给卷积网络进行预测；随后移动窗口，将下一个窗口位置的图像传递给卷积网络进行处理；依次重复，直到窗口滑过图像的每一个角落，如图 2-4 所示：




图 2-4 滑动窗口检测

接着可以使用更大的窗口进行同样的处理，根据卷积网络对输入图像的大小要求调整窗口的大小。滑动窗口检测算法有一个明显的缺点，即计算成本高。可以看到，在窗口滑动的过程中，图片中会剪切出过多的区域图片并依次作为输入提交给卷积网络处理，如果选用的窗口滑动的步长较大或截取框很大，虽然可以减少卷积网络的窗口数量，但同时也会影响检测的性能。

2.1.1.2. R-CNN(Region with Convolutional Neural Network Feature)

候选区域(Region proposal)在计算机视觉领域是一个非常有影响力的概念，在上文所述的滑动窗口检测算法中，需要把剪切出的所有窗口都交给训练好的分类器进行处理，判断其中是否有目标物体，如车辆、行人等等。滑动窗口算法有一个比较明显的缺点：对于许多明显不存在任何目标对象的区域，依然需要经过整个算法处理流程，这显然是对计算资源的浪费。Ross Girshick 等人提出了 R-CNN, Fast R-CNN, Faster R-CNN 等算法，都是基于 Region proposal 这一方法，Fast R-CNN 主要是针对 R-CNN 获取的大量 region proposals 中，总是有大量的重叠部分来进行改进；而 Faster R-CNN 主要是针对 Fast R-CNN 的检测流程中获取候选区域的过程进行优化，从而减少了流程的计算量，获得了大幅的速度提升。基于 Region proposal 方法的流程通常是：首先尝试选出一些候选区域，然后对每个候选框的位置做一些调整使得定位更加精确，最后对这些区域使用训练好的高质量的目标分类器，所以不再对每个窗口位置都运用检测算法，而只是选择一部分窗口来运行卷积网络分类器。基于 Region proposal 的方法相对来说拥有比较好的精准度，但也存在计算量过大等缺点。

在 2010 到 2012 年间，目标检测领域的研究发展变得缓慢，以往的方法的检测效果达到瓶颈，此后，Ross Girshick 提出了 R-CNN，将 CNN 方法应用到目标检测这一问题上，它在 ILSVRC2013 数据集上的检测性能超出当时最前沿的算法 OverFeat 接近 50%，成为目标检测研究发展历史上的一个重要里程碑。R-CNN 与传统的物体检测的流程相似，依然是先找出候选目标物体，然后逐个提取特征。选取候选区域的方法是运行图像分割算法^[21]，通过选取与周边环境有较明显区别的色块从而获取出候选区域，这个流程称为 Selective Search。通过对多个尺寸的窗口使用选择性搜索，使用纹理、颜色或者强度将相邻像素归类，从而完成识别的目的。在获取这些候选区域后，R-CNN 首先判定这些区域中的物体是否为目标，即进行分类，在确定了候选区域中的物体是目标物体后，通过运行线性回归以生成更精确的边界坐标，从而适应目标的真实尺寸。R-CNN 的处理方式与滑动窗口算法相比，大幅地减少了需要处理的窗口数量。R-CNN 的处理流程如图 2-5 所示：





图 2-5 R-CNN 检测流程

与传统的目标检测流程相比,R-CNN使用了 CNN 卷积网络替代传统的 HOG, LBP, DPM 等算法来计算提取图像特征。在 VOC 2012 数据集上, R-CNN 取得了 53.3%的 mAP, 将之前的 mAP 最高值提升了超过 30%。R-CNN 在目标检测发展历史上是一个非常重要的算法, 虽然 R-CNN 具有里程碑式的意义, 但 R-CNN 也存在几个比较明显的问题:

1. 需要预先提取多个候选区域对应的图像, 存储这些区域图像将会消耗大量的磁盘空间;
2. 传统 CNN 的输入图像必须是固定尺寸的, 所以需要对输入进行尺寸调整, 而进行归一化处理(crop/wrap)会使图像中的物体产生截断或拉伸, 导致 CNN 中的信息丢失;
3. 每一个候选区域都需要在 CNN 网络中进行计算, 而上千个候选区域中有大量的重复区域, 这些重复的特征提取计算导致处理性能严重降低, 也是对计算资源的浪费;
4. 目标检测速度较慢, 使用 VGG16 神经网络检测一张图片平均花费 47 秒。

2.1.3 空间金字塔池化

SPP-Net(Spatial Pyramid Pooling Net)在 CNNs 的基础上做了性能优化。如上文所述, CNN 方法有一个严重的问题在于: R-CNN 需要固定大小的图像输入, 这既限制了图片的分辨率也限制了图片的大小。SPP-Net 针对不同尺寸的输入可以得到相同维度的输出。由于输入尺寸的可变性, SPP 可以提取不同尺度的特征。当需要对任意大小的图片进行处理时, 常用的做法是将输入图像大小改变到固定的尺寸也就是对其做归一化处理(cropping^[35],wrapping^[37])。然而裁剪区域(cropped region)可能没有包含完整的物体, 而 warped 区域可能会产生异常的拉伸、扭曲、变形导致图片中信息的丢失。如图 2-6 所示:

图 2-6 将图像归一化处理^[35]。(a)crop;(b)wrap

为什么卷积神经网络需要固定大小的图像输入？一个卷积神经网络主要由两个部分组成：卷积层与在其之后的全连接层。卷积层并不需要固定的图像大小，可以生成任意大小的特征图。但是，全连接层必须接受预先所定义的固定大小的输入。因此，固定输入大小的限制仅仅来源于全连接层。**SPP-Net** 通过采用空间金字塔池化方法去除了图像的归一化过程，从而解决了图像变形导致的信息丢失以及存储问题；为了适应不同分辨率的图像，**SPP-Net** 定义了一种可伸缩的池化层，无论输入的分辨率是多少，都能被划分为 $m \times n$ 个部分，所以它的输出大小是固定的。**SPP** 放在所有卷积层之后，有效解决了卷积层的重复计算问题。传统 CNN 处理结构与 **SPP-Net** 的结构对比如图 2-7 所示：




图 2-7 SPP-Net 与传统 CNN 结构对比。(a) 传统 CNN 结构；(b) SPP-NET 结构

SPP-Net 在 **R-CNN** 的基础上做了实质性的优化改进，但仍然存在一些问题。**R-CNN** 的训练过程是隔离，即 **Region Proposal**、计算 CNN 特征、分类回归、边界回归是相互独立训练的，并且存在大量的中间结果需要转存，无法整体训练参数。**SPP-Net** 的训练过程同样也是隔离的，所以它存在同样的问题并且在整个检测过程中，提取候选区消耗的时间依然很长。

2.1.4 Fast R-CNN

由 Ross Girshick 提出的 Fast R-CNN^[25], 在之前 R-CNN 与 SPP-Net 的基础上, 增加了一些改进来加快训练和测试的速度并且提高了检测的准确率。在 VGG16 卷积神经网络上, Fast R-CNN 的训练速度是 R-CNN 的 9 倍并且有着更高的 mAP。与 SPP-Net 相比, Fast R-CNN 训练 VGG16 卷积神经网络的速度是它的 3 倍, 同时也更加准确。R-CNN 之所以速度慢, 主要原因是因为它存在大量的重复计算。SPP-Net 通过共享计算, 在 R-CNN 的基础上得到了性能的提升。SPP-Net 对输入图片计算一个特征图并在之后的计算过程中共享这个特征图来进行计算。SPP-Net 的验证阶段比 R-CNN 快 10 到 100 倍, 训练时间也减少了 3 倍以上。SPP-Net 同样也有着显著的缺点, 与 R-CNN 相同, 它的训练是一个多级的过程。Fast R-CNN 将分类任务与边框回归统一到了同一个框架之内, 用 selective search 方法从原始图片中提取 2000 个候选区域(Region of Interest, ROI), 对整张图片进行卷积计算, 得到卷积特征图, 然后利用 ROI pooling layer 从卷积特征图中提取每一个候选区域的特征向量, 通过全连接层后, 特征向量进入两个输出层, 一个进行分类(Fast R-CNN 用 softmax 代替了之前 SVM 分类器), 另一个进行边框回归。Fast R-CNN 的结构如图 2-8 所示:




图 2-8 Fast R-CNN 的架构

Fast R-CNN 有着以下优点:

1. 比 R-CNN、SPP-Net 更高的检测质量;
2. 提出了简化版的 ROI 池化层, 改善了整体网络的训练问题;
3. 训练变为单级(single-stage)的, 使用多任务 loss 层;
4. 由于训练过程可以对所有层进行更新, 除了速度提升外, 也更节省空间。

尽管得到了性能的提升，但 Fast R-CNN 仍然没有解决 selective search 进行候选区域选择的时候计算速度慢、耗时过长的的问题。

2.1.5 Faster R-CNN

针对 Fast R-CNN 进行候选区域选择速度慢的问题，Faster R-CNN^[36]使用了利用卷积神经网络来代替传统的分割算法进行候选区域的选择。之前用于提取候选区域的 Selective Search 方法，提取一副图像大概需要 2 秒的时间，远远不能满足实际要求。但候选区域提取不一定要在原图上做，如果能在特征图上进行候选区域提取，那么低分辨率的特征图将带来更少的计算量。Faster R-CNN 通过使用 RPN 网络将候选区域的提取过程整合到卷积神经网络当中，得到了较大的性能提升。简单来说，Faster R-CNN = RPN + Fast R-CNN。公式 (2-2) 为 Faster R-CNN 的损失函数：

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_{i=1}^n L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_{i=1}^n p_i^* L_{reg}(t_i, t_i^*) \quad (2-2)$$

其中 $L_{cls}(p_i, p_i^*) = -p_i^* \log(p_i)$ ， p_i 是第 i 个 anchor^[36]是一个物体的概率。图 2-9 展示了 Faster R-CNN 的结构：




图 2-9 Faster R-CNN 的结构

2.1.6 实时检测算法

尽管 Faster R-CNN 取得了显著的性能提升，平均每秒能处理 7 帧图像，但仍不能满足实时应用的需求。Joseph Redmon 等人提出一种全新的目标检测方式，将目标检测作为一个回归问题处理，而不再需要消耗大量时间的候选框提取过程，从而极大地提升了目标检测的速度，每秒钟可处理 45 帧图像，基本达到了实时应

用的要求。YOLO 意为“You Only Look Once”，即你只需要查看一次。不同于之前的 R-CNN、Fast R-CNN 和 Faster R-CNN，它将预测边框及物体类别的可能性放在一个神经网络对整张图片的一次处理中，即输入图像经过一次推断处理，就能得到图像中所有物体的位置及其所属类别与相应的置信概率。图 2-10 对比了 YOLO 与 R-CNN、Fast R-CNN、Faster R-CNN 的结构。




图 2-10 网络结构对比。(a)R-CNN；(b)Fast R-CNN；(c)Faster R-CNN；(d)YOLO

YOLO 将输入图片划分为 $S \times S$ 个网格，如果一个物体的中心落在网格内，则此网格负责检测此物体。每一个网格需要预测 B 个边界框及其置信概率，置信概率应当与预测边界和 ground truth 的交并比(Intersection over Union, IoU)值相同。然后根据阈值去除可能性比较低的目标窗口，最后使用非最大值抑制^[27]去除冗余窗口，只保留一个最终结果。YOLO 网络结构由 24 个卷积层和两个全连接层组成。网络入口为 448×448 ，网络的输出结果为一个 $S \times S \times (B \times 5 + C)$ 的张量，其中 S 为划分网格数， B 为每个网格负责目标个数， C 为类别个数。对于每一个目标，需要得出它的相对坐标 (x, y) ，相对整个图片所占的长宽比例 w 及 h ，以及置信概率，所以对每个目标需要得出五个预测参数。

YOLO 的优缺点都是明显的。优势是由于舍弃了 Region Proposal 阶段，计算速度得到了显著提高；缺点是对小物体及邻近物体的检测效果较差。

SSD^[28](Single Shot MultiBox Detector)结合 Faster R-CNN 的 anchor^[39]机制和 YOLO 的回归思想进行目标检测，与 YOLO 相比，SSD 的定位精度和分类准确率都有了大幅度的提高。SSD 与 YOLO 的的架构如图 2-11 所示：




图 2-11 SSD 与 YOLO 的结构对比。(a)SSD 的结构；(b)YOLO 的结构

2.2 行人重识别简介

行人重识别问题可以表述为：在两个不同区域的摄像头 a 与摄像头 b，利用摄像头 a 中的行人图像作为查询条件，在摄像头 b 所记录的候选图像中找出与之匹配的行人的图像。其中影响行人重识别效果的两个关键因素为：行人的特征表示与距离度量。

2.2.1 行人的特征表示

如何识别一个行人？通常人们首先想到的方法就是通过人脸，然而由于监控视频的图像质量问题与监控环境的复杂性，人脸信息在此场景下变得不可靠，不能作为行人的有效特征表示。人们希望能够将用一种特征向量来表示行人图像，用来区分不同的行人，且在外界环境的变化下也能保持较好的稳定性。

最直观的特征就是行人图像的外观。颜色特征是图像的基本特征之一，且不受时空变化的影响，对图像的大小、旋转、移动等变化不敏感，是在行人重识别中应用最为广泛的特征^[37]。颜色特征通常在颜色空间模型中提取，常见的颜色空间模型有 LAB 颜色空间、RGB 颜色空间、HSV 颜色空间等。

LAB 颜色空间是由 CIE(国际光线标准组织)所定义的颜色模型，理论上可以用来表示人眼所能感知的所有颜色。其中 L 表示亮度，颜色分量 A 表示从绿色到红色的变化，颜色分量 B 表示从蓝色到黄色的变化。RGB 颜色空间是基色颜色空间。绝大多数颜色都可以通过不同强度与比例的这三种颜色合成，HSV 颜色空间^[38]更符合人类对颜色的感知，其中 H 表示色调，指颜色的种类，用角度来衡量，取值范围是 0 到 360 度；S 表示饱和度；V 表示亮度。RGB 与 HSV 可以相互转换，如公式 (2-3) 所示：

$$\begin{aligned}
 H &= \begin{cases} 0^\circ, & \text{if } \max = \min \\ 60^\circ \times \frac{G-B}{\max-\min} + 0^\circ, & \text{if } \max = R \text{ and } G \geq B \\ 60^\circ \times \frac{G-B}{\max-\min} + 360^\circ, & \text{if } \max = R \text{ and } G < B \\ 60^\circ \times \frac{B-R}{\max-\min} + 120^\circ, & \text{if } \max = G \\ 60^\circ \times \frac{R-G}{\max-\min} + 240^\circ, & \text{if } \max = B \end{cases} \\
 S &= \begin{cases} 0, & \text{if } \max = 0 \\ 1 - \frac{\min}{\max}, & \text{otherwise} \end{cases} \\
 V &= \max
 \end{aligned} \tag{2-3}$$

其中 $\max = \max(R, G, B)$ ， $\min = \min(R, G, B)$ 。

相比颜色特征，纹理特征的使用较少一些。纹理特征是对行人图像中的细节描述。图像的纹理反应了像素之间的规律，因此提取纹理特征对于图像分类等任务也具有重要的意义。通过将颜色特征与纹理特征相结合，能够形成对行人外观的概括描述。

2.2.2 距离度量

如果一个函数对同一个行人图像间的特征向量计算得到的距离较小，而对不同行人图像之间的特征向量得到的距离值较大，那么它就可以作为区分行人的一个距离函数。距离函数的目的就是为了根据行人特征的相似度对行人进行匹配。

经典的距离函数如欧氏距离、夹角余弦距离也常被用于处理行人图像的相似性。欧式距离是最简单的距离度量函数，假设两个输入图像经过特征提取后得到两个特征向量 $f_1=(x_1, x_2, \dots, x_n)$, $f_2=(y_1, y_2, \dots, y_n)$ ，则它们间的欧式距离定义如公式 (2-4) 所示：

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2-4)$$

同样假设两个特征向量为 $f_1=(x_1, x_2, \dots, x_n)$, $f_2=(y_1, y_2, \dots, y_n)$ ，则其余弦距离的定义如公式 (2-5) 所示：

$$d = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}} \quad (2-5)$$

2012 年，Xing^[31]首次提出马氏距离形式的距离测度学习。它是在特征空间上使用线性尺度和旋转的方法对欧氏距离的一种扩展，如公式 (2-6) 所示：

$$d(x_i, x_j) = (x_i, x_j)^T M (x_i, x_j) \quad (2-6)$$

其中， x_i, x_j 是 n 维空间的两点， M 是半正定矩阵，通过样本学习参数。上述方程的求解可以被认为是一个凸优化问题。

交叉视角的二次判别分析法使用高斯模型来拟合样本特征的差值分布，它定义了两个概率密度函数，如公式 (2-7)，公式 (2-8) 所示：

$$P(\Delta | \Omega_I) = \frac{1}{(2\pi)^{d/2} |\Sigma_I|^{1/2}} e^{-\frac{1}{2} \Delta^T \Sigma_I^{-1} \Delta} \quad (2-7)$$

$$P(\Delta | \Omega_E) = \frac{1}{(2\pi)^{d/2} |\Sigma_E|^{1/2}} e^{-\frac{1}{2} \Delta^T \Sigma_E^{-1} \Delta} \quad (2-8)$$

其中 $\Delta = (x_i - x_j)$ ， Σ_I 和 Σ_E 分别表示类内与类间样本差值分布的协方差矩阵。结合公式 (2-7) 与公式 (2-8) 可以得到距离度量函数，如公式 (2-9) 所示：

$$f(\Delta) = \Delta^T (\Sigma_I^{-1} - \Sigma_E^{-1}) \Delta \quad (2-9)$$

所以 x_i 与 x_j 的距离可以由公式 (2-10) 表示：

$$d(x_i, x_j) = (x_i - x_j)^T (\Sigma_I^{-1} - \Sigma_E^{-1}) (x_i - x_j) \quad (2-10)$$

在人工设计的重识别系统当中，选取一个好的距离度量对于行人重识别的准确率是十分重要的。现阶段对于距离度量学习的研究已经越来越多。

2.3 端到端的行人重识别系统

如前文所述，目前的研究大都将检测任务与识别任务作为计算机视觉中相互独立的两个研究问题。但是在许多应用场景中，例如视频监控、机场中人流监控、用于自动驾驶的行为分析等应用场景中，将行人检测与行人识别任务相结合能发挥重要的作用。

在监控视频中识别检索特定目标任务也可以通过检测任务与重识别任务的结合来完成，首先通过检测算法提取出图像中出现的所有行人作为重识别任务的候选行人集，然后利用重识别网络根据检索目标特征来进行匹配。这样的端到端检测识别系统的流程可以由图 2-12 来表示：




图 2-12 行人检测与行人重识别结合^[48]

这样的端到端检测识别系统的流程首先从原始的视频图像帧开始处理，通过行人检测器来创建候选行人集合；在给定一个特定的检索目标行人后，计算候选行人与目标行人的特征距离，然后根据与检索目标的相似度大小对候选集中的行人进行排序。

虽然目前大部分相关研究仍然将目标检测问题与行人重识别问题作为两个相互独立的任务来研究处理，但已经有学者开始意识到将这两者结合的重要意义。Zheng 等人通过将使用不同方法的检测器与识别器结合起来研究行人检测效果对行人重识别的影响。Xiao^[39]等人注意到，现有的行人重识别方法主要研究如何将识别对象与已经从环境中裁剪出的候选行人图像进行匹配。然而现实场景中的图像中，并不会已经有标注好的行人边框，所以需要从整个场景中去检索识别目标行人，而不是从已经从环境图像中截取好的行人图像进行匹配。Xiao 提出一种新的行人检索框架，将行人检测与行人重识别放在一个统一的卷积神经网络当中处理。其算法框架如图 2-13 所示：




图 2-13 端到端的行人检测与识别框架

当输入一张图像时，首先通过 CNN 来将原始图像转化为卷积特征图，然后根据获得的卷积特征图使用候选行人网络来预测候选行人的边框位置，通过 ROI 池化层后送入重识别网络进行匹配。他们提出一种新的损失函数 OIM(Online Instance Matching)^[39]来训练网络。此外，他们还收集并标注了一个大规模的行人图像数据集用于行人重识别任务。

2.4 本章小结

通过将目标检测与行人重识别相结合能够构成一个基本的监控识别系统。本章分别介绍了目前常用的目标检测相关的算法与行人重识别问题中的两个主要研究问题，最后介绍了端到端行人重识别系统的结构。

第三章 基于监控场景的行人重识别算法的设计

目前的行人重识别算法主要研究如何将目标行人图像与已经从完整的场景图像中裁剪并提取出的候选行人图像进行匹配。然而在实际应用场景中，候选行人图像通常是没有被单独从场景图像中分离出来的，因此需要从完整的监控场景图片中识别目标人物。由于使用行人检测不可避免地会出现漏检、误检等情况，所以将行人检测模型与行人重识别模型直接串联结合来进行重识别的准确率并不高。图 3-1 展示了目前行人重识别研究与实际监控场景的行人重识别应用间的区别。



图 3-1 行人重识别的区别。(a) 行人重识别；(b) 面向监控场景的行人重识别

如前文所述，虽然行人检测与行人重识别在许多应用场景中是紧密结合在一起的任务，但目前人们通常将行人检测与行人重识别作为两个独立的任务与课题来研究。为了在监控场景中识别出特定的目标行人，一种自然的一种做法是：先从图片中检测出所有候选行人，然后逐一与检索目标做匹配，最后选出与其相符

合的目标，图 3-2 展示了这样的方法的流程：




图 3-2 行人检测与行人重识别结合

这样的方法显然是可行的，Xiao^[39]提出一种新的深度学习框架，将行人检测与行人重识别放入一个统一的卷积神经网络当中，并提出一种新的函数 OIM 来训练网络模型。Xiao 的方法加强了整个系统的内聚性，但这样的方法没有改变检索识别过程分为两级的本质，并且在行人检测阶段没有充分利用已有的查询对象的信息，即目标行人的特征信息，需要在全图范围内寻找所有的目标然后进行重识别的匹配。本文提出一种新的方法，使用基于注意力机制的行人检索识别方法，提取目标行人的特征作为初始记忆信息传递给行人检索识别网络，来引导在监控图像中寻找目标行人的过程。与之前的先进行行人检测再进行行人重识别的方法相比，本文将检测与识别流程进行了更加紧密地结合。通过引入记忆信息来使得检测流程更具有目的性并减少了进行重识别计算的次数，由此减少了整个流程计算量。

3.1 算法框架描述

传统的目标检测算法通常对整个图片的视觉信息不加选择地全部进行处理，而人类自身每时每刻接受到的视觉信息量是庞大的，我们不会也不可能将所有信息都进行仔细地分析与处理，正如我们在观赏一幅画作时，虽然我们能够观察到整幅画作，但通常我们的注意力在某一个时间段是集中在画作的一小部分上的，即我们对整个画面信息的关注度、注意力的大小是不均衡的。基于这种思想，本文通过使用注意力机制^[40]来进行行人检索识别，能够有重点地从整张图片中选取感兴趣的部分进行处理。同传统的方法相比，本文的方法能减少整个检测识别流程中计算量。

本文将目标行人的重识别问题视为一个序列模型问题，通过将注意力模型与循环神经网络结合并使用一个包含目标行人信息的记忆单元来处理。假设我们只

能通过一个观察代理来观察图片，而观察代理在每一个时间点只能观察到图片的一部分区域。在输入需要检索识别的目标行人后，首先提取出其特征作为对目标的初始记忆信息，利用初始记忆来帮助注意力网络选择下一个观察区域，通过多次观察获取的信息结合，最终得到的即为搜索结果。正如在阅读文章时一样，我们根据之前阅读到的文字信息来理解当前读到的文字，而不是将信息独立分割来看待，即人的思考是具有连续性的。我们将这整个目标识别处理流程也视为一个连续的过程，而循环神经网络是当前被广泛用于处理序列问题的网络结构，所以本文使用 LSTM^[41] 网络结构来进行行人检索识别。

本节介绍算法的总体框架，整个检索识别流程由两个关键模块组成：记忆单元和行人检索识别网络。通过残差网络 ResNet-50 Part1 提取目标行人的特征作为记忆信息，将它传递给行人检索识别网络。本文的行人检索识别网络由使用注意力模型的循环神经网络构成，在循环过程的每一步，都只能观察全图的一部分区域。通过记忆信息来引导行人检索识别网络在全图中的观察区域。此算法将传统的两步流程即先进行行人检测再进行匹配识别的过程转化为一个简单的搜索识别过程，减少了进行重识别特征距离计算与排序的次数，从而减少了计算量与处理时间。算法的框架结构及如图 3-3 所示：




图 3-3 基于监控场景的行人重识别算法的框架

图 3-3 展示了整个检索识别算法的流程，输入一个检索识别目标后，首先通过残差网络 ResNet-50 Part1 进行特征提取，得到目标行人的特征表达 Q 并传递给使用注意力模型的检索识别网络当中，本文的检索识别网络是基于使用长短期记忆单元的循环神经网络构建的。检索识别网络只能通过一个观察范围有限的观察代理来观察图像，其中 I_i 表示第 i 步的观察位置坐标，需要进行检索的监控场景图像

与当前的观察坐标 l_i 共同构成了循环中第 i 步的观察区域，当前观察区域同样经过残差网络 ResNet-50 part1 提取特征，并传递给长短期记忆单元，长短期记忆单元结合历史状态 h_{i-1} 来生成下一个状态 h_i 。 h_i 通过一个 f_l 定位功能函数来决定下一次的观察坐标 l_{i+1} ，在经过固定的循环次数后，得到最终的特征向量 h_N ， h_N 与检索目标特征 Q 经过残差网络 Res50 part2 进行特征提取后传递给重识别网络进行余弦特征距离计算和排序，图 3-4 展示了整个算法的流程：




图 3-4 本文算法的流程图

3.2 初始记忆单元

在基于监控场景的行人重识别问题中, 给定一个需要识别的目标行人, 可以首先利用行人检测从监控场景图像中检测得到所有的候选行人图像, 然后将候选图像送入重识别网络进行特征距离计算与排序。

在这样的分为两级的识别流程当中, 需要被识别的目标行人的特征在行人检测阶段没有被充分利用, 只在重识别阶段与候选目标作比较时才会被使用。所以从监控场景图像中检测出的所有行人都会作为候选行人参与特征距离计算与排序。如果能利用需要被检索目标的特征来引导检测过程, 在检测阶段就找到图像中与目标行人特征相近的目标, 就能减少进行行人重识别流程的次数。本文首先提取出检索识别目标的特征, 我们可以将其称为初始记忆, 将初始记忆送入检索识别网络, 利用初始记忆来引导观察代理的下一个需要关注的区域。为了实现这样的流程, 我们设计了初始记忆单元, 利用残差网络 Resnet-50 提取目标行人的特征表达。并在循环神经网络的每一步观察过程中, 都将此特征表达传递给 LSTM 单元, 用于帮助检索识别网络选择下一个需要观察的区域。在本章 3.3.2 小节中的公式 (3-7) 描述了这样的结构定义。

本文的基于监控场景的行人重识别方法的核心网络之一是使用 LSTM 单元的循环神经网络, 另一个核心网络则是残差神经网络 ResNet-50, 用于提取行人图像特征。ResNet-50 被分为两个部分。前面的数层作为第一个部分用于提取用于行人检测的特征, 后面的高层网络作为第二部分用于提取行人重识别所需要的特征。

3.3 基于多次观察的行人检测

为了将目标行人的特征信息加入到检测过程中, 本文假定只能通过一个观察代理来观察监控图像, 并且在每一个时间节点只能观察图像的部分区域, 通过多次对图像中的不同区域的观察并结合每次观察获取的信息来寻找识别目标, 在不同时间点观察获取的局部信息形成了一个序列, 因此本文将从一幅给定全图中搜寻识别特定目标行人的问题视为一个序列模型问题。循环神经网络是一种常用的处理序列模型的网络结构。

人类思考过程是连续的, 正如在阅读这段文字时, 对每一个文字的理解都基于之前的文字信息。但在传统的神经网络模型中, 不同层之间的结点是全连接的, 层内的结点是无连接的, 即传统的神经网络假设元素之间是相互独立的, 输入和输出也是相互独立的, 所以不能很好地处理这类问题, 这是它的一个重大缺陷。循环神经网络引入了“记忆”的概念, 在一定程度上解决了这个问题。图 3-5 展示了一个简单的循环神经网络的结构:




图 3-5 循环神经网络结构

我们可以用了另一种更直观的方式来描述它，如下图所示：




图 3-6 循环神经网络结构的循环模式

图 3-6 中的将 x_i 映射到 h_i 的方式是相同的，也就是重复的处理单元，因此将它称为循环神经网络。

3.3.1 梯度消失问题

循环神经网络令人欣喜的原因在于，看起来它们能够结合历史信息来处理当前的任务。但它有一个明显的问题，正如人的大脑一样，循环神经网络参数矩阵的可存储的信息或者说计算机内存的大小是有限的，所以循环神经网络并不能捕捉和保留所有的信息。在许多情况下，这样的循环神经网络是不稳定的，它存在一个问题使得它不能得到有效地训练，通常把它称为梯度消失问题 (Vanishing gradient problem)。如公式 (3-1) 所示：

$$\frac{\partial E}{\partial \theta} = \sum_{t=1}^s \frac{\partial E_t}{\partial \theta} \quad (3-1)$$

其中 E 表示损失函数，我们想要在循环过程中的每一步都获取比较小的损失值从而得到一个良好的训练模型。当我们利用链式法则对其求导后我们可以得到公式 (3-2)：

$$\begin{aligned} \frac{\partial E_t}{\partial \theta} &= \sum_{k=1}^t \frac{\partial E_t}{\partial y_t} \frac{\partial y_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial \theta} \\ \frac{\partial h_t}{\partial h_k} &= \prod_{i=k+1}^t \frac{\partial h_i}{\partial h_{i-1}} = \prod_{i=k+1}^t \theta^T \text{diag}[\phi'(h_{i-1})] \end{aligned} \quad (3-2)$$

梯度消失问题出现在求解公式 (3-2) 的 $\frac{\partial h_t}{\partial h_{i-1}}$ 部分，由公式 (3-3) 我们可以理解这个问题：

$$\begin{aligned} \left\| \frac{\partial h_t}{\partial h_{i-1}} \right\| &\leq \left\| \theta^T \right\| \left\| \text{diag}[\phi'(h_{i-1})] \right\| \leq \gamma_\theta \gamma_\phi \\ \left\| \frac{\partial h_t}{\partial h_k} \right\| &\leq (\gamma_\theta \gamma_\phi)^{t-k} \end{aligned} \quad (3-3)$$

其中 $\phi'(h_{i-1})$ 不大于某一个确定的值的，在此我们将它设为 γ_ϕ 。同理， θ^T 不大于 γ_θ 。因此，通过将公式 (3-3) 与公式 (3-1)、公式 (3-2) 结合，可以得到公式 (3-4)：

$$\left\| \frac{\partial h_t}{\partial h_k} \right\| \leq (\gamma_\theta \gamma_\phi)^{t-k} \quad (3-4)$$

由于 $\gamma_\theta \gamma_\phi$ 是一个常数，当网络的层数较深时，如果 $\gamma_\theta \gamma_\phi$ 大于 1，那么 $\left\| \frac{\partial h_t}{\partial h_k} \right\|$ 可能会变得很大，称为梯度爆炸问题；如果 $\gamma_\theta \gamma_\phi$ 小于 1，那么 $\left\| \frac{\partial h_t}{\partial h_k} \right\|$ 将会趋近于 0，称为梯度消失问题。这意味着在第 k 步的信息都对第 t 步的输出没有产生影响，历史的信息没有得到有效利用。所以在网络层数很深的情况下，循环神经网络不能很好地学习如何利用历史信息。

如果我们将第 t 步中的输入量定义为 g_t ，输出量定义为 h_t 。 c 表示细胞状态(cell state)，如公式 (3-5) 所示：

$$\begin{aligned}
 c_t &= \Theta c_{t-1} + \Theta_g g_t \\
 h_t &= \text{Tanh}(c_t)
 \end{aligned}
 \quad (3-5)$$

解决梯度消失问题的一种尝试方案是将 θ 函数变为常数 1，简单地将过去的信息堆积累加，但这显然不是一个很好的记忆模式。一个好的记忆模式应当能够决定何时读取信息、何时删除遗忘信息、何时能重置记忆。长短期记忆网络 (LSTM) 正是使用这种记忆模式来解决长期依赖所产生的梯度消失和梯度爆炸问题。

3.3.2 加入目标特征的 LSTM

对于基于监控场景的行人重识别任务，我们在此将它视为一个序列模型问题。序列模型的特点是每一步的输出不仅依赖于当前的输入，还依赖于其他步的信息。在传统的神经网络模型中，数据流向是从输入层到隐含层最终到达输出层。层与层直接为全连接，而位于同一层的结点是无连接的。这种网络结构在处理上述序列问题时显得无力。循环神经网络常被用来处理序列相关的问题，在循环神经网络当中，一个结点当前的输出与此前的输出也是有联系的。然而由于传统的循环神经网络对信息的控制方式问题，在网络层数很深和存在长期依赖的情况下，历史信息可能不能得到有效的利用。

为了解决梯度消失与梯度爆炸问题，Sepp Hochreiter 和 Schmidhuber 在传统循环神经网络的基础上改进形成了一种新的循环神经网络：长短期记忆网络 (Long Short-Term Memory, LSTM)。LSTM 是一种时间递归神经网络，目前已经有了语言翻译、图像分析、图像识别、语音识别、合成音乐等多种应用。

LSTM 网络实质上是一种特殊的循环神经网络，能够处理当网络层数较深时所出现的梯度消失问题，LSTM 既能够记忆信息，也能够遗忘、重置信息。所有的循环神经网络结构中都存在着一个链式的重复模块，在普通的循环神经网络当中，这些重复的模块可能只有一个非常简单的结构，例如一个 $\tanh$ 层。如图 3-7 所示：




图 3-7 标准 RNN 中的重复模块结构

长短期记忆神经网络同样拥有循环神经网络的链式结构，但它的内部重复模块更加复杂。长短期记忆单元的核心思想在于细胞状态的改变，一个长短期记忆单元中存在一个或多个细胞核，用来描述它的当前状态。细胞状态存在于整个链式结构当中，并且通常只参与一些简单的线性交互计算。因此数据信息容易在细胞状态中得以保存。长短期记忆网络能够通过门^[41]来控制细胞状态，实现向其添加数据信息、更新数据信息或移除数据信息。长短期记忆网络重复单元的结构如图 3-8 所示：




图 3-8 LSTM 中的重复模块

门能够控制时序数据信息的在网络中的流动，LSTM 有三种类型的门用于控制细胞状态，分别是遗忘门(forget gate)、输入门(input gate)和输出门(output gate)。它们通常由一个 sigmoid 神经网络层和一个 pointwise 乘法运算器组成。sigmoid 层的输出范围在 0 到 1 之间，反映了信息可以通过的程度，0 值表示任何信息都不应该通过而 1 则表示所有的信息都可以通过。遗忘门获取上一步的状态 h_{t-1} 和输入 x_t 的值，通过函数为细胞状态 c_{t-1} 中的每一个值输出一个 0 到 1 之间的数值，1 表示完全保留，0 表示完全舍弃。同理，输入门和输出门也根据 h_{t-1} 与 x_t 的值给出 0 到 1 之间的值，输入门决定是否需要更新状态值，然后通过一个 tanh 层产生新的状态量 c_t ；输出门则决定哪些值最终会被输出到下一层。公式 (3-6) 给出了这些过程的定义：

$$\begin{aligned}
i_t &= \sigma(w_{xi}x_t + w_{hi}h_{t-1} + b_i) \\
f_t &= \sigma(w_{xf}x_t + w_{hf}h_{t-1} + b_f) \\
O_t &= \sigma(w_{xo}x_t + w_{ho}h_{t-1} + b_o) \\
g_t &= \tanh(w_{xc}x_t + w_{hc}h_{t-1} + b_c) \\
c_t &= f_t \odot c_{t-1} + i_t \odot g_t \\
h_t &= o_t \odot \tanh(c_t)
\end{aligned} \tag{3-6}$$

其中 $\odot$ 表示 Hadamard 积, i_t 表示输入门, f_t 表示遗忘门, O_t 表示输出门, c_t 表示细胞状态, h_t 表示隐藏状态。以上是传统的长短期记忆单元的结构, 这种传统的 LSTM 一般使用全连接来作为不同状态之间的转换, 所以可以称之为 FC-LSTM, 它能够较好地处理时序数据, 但是在处理空间数据时, 由于空间数据有着很强的局部特征, 而 FC-LSTM 不能很好地刻画这些局部特征, 所以会造成空间信息的丢失, 因此, 本文不能直接使用 FC-LSTM。

为了更有效地利用目标行人的信息, 本文将目标行人的特征作为一个独立的输入信息加入到修改过的 ConvLSTM^[42]单元当中, ConvLSTM 是一个专门针对时空序列所设计的处理结构。传统的 LSTM 的主要缺陷是将输入编码到内部状态与状态转换时使用的是全连接, 没有考虑到对空间信息的处理。ConvLSTM 用卷积来做不同状态之间的转换, 能更好的地使用空间位置信息。图 3-9 展示了两者的对比:




图 3-9 LSTM 状态转换。(a)传统 LSTM; (b)ConvLSTM

ConvLSTM 能够更有效地保留时空信息。ConvLSTM 的内部结构如图 3-10 所示:




图 3-10 ConvLSTM 的内部结构

本文在 ConvLSTM 的基础上额外地增加了的目标行人的特征信息，更改之后的 ConvLSTM 单元的定义如公式（3-7）所示：

$$\begin{aligned}
 i_t &= \sigma(W_{xi} * X_t + W_{hi} * h_{t-1} + W_{qi} * q + b_i) \\
 f_t &= \sigma(W_{xf} * X_t + W_{hf} * h_{t-1} + W_{qf} * q + b_f) \\
 O_t &= \sigma(W_{xo} * X_t + W_{ho} * h_{t-1} + W_{qo} * q + b_o) \\
 g_t &= \tanh(W_{xc} * X_t + W_{hc} * h_{t-1} + W_{qc} * q + b_c) \\
 c_t &= f_t \odot c_{t-1} + i_t \odot g_t \\
 h_t &= o_t \odot \tanh(c_t)
 \end{aligned} \tag{3-7}$$

其中*表示卷积，q 表示待检索识别目标行人的特征信息，可以看出在传统 LSTM 单元的基础上，本文算法在输入门、遗忘门、输出门与输入信息中都加入了通过 Resnet-50 part1 提取后的目标行人特征信息，用于指引 ConvLSTM 的内部状态朝着向与目标行人相关的区域改变，并抛弃与目标行人无关的信息。注意到目标行人的特征信息 q 与循环步骤 t 的处理流程是无关的，即目标行人的特征信息在整个检索重识别过程中是一个全局不变的值。 W_{xi} 、 W_{hi} 是二维的卷积核， X_t 是当前观察区域的特征图，与传统的长短期记忆单元不同，ConvLSTM 中的 i_t ， f_t ， O_t ， h_t ， c_t 都是三维的张量，后面的两个维度是行和列的空间信息。在本文的重识别方法当中，通过在观察过程中加入了目标行人的特征信息，使得整个检索重识别过程具有更强的目的性。

3.4 注意力机制




图 3-11 视觉注意机制示例

如图 3-11 所示，人们在观察上面两幅图时会自然地将注意力集中到第一幅图像中的黑色圆环与第二幅图中的矩形上。人类在观察图像时的注意力并不是均匀分布的，人们通常不会在一个时刻尝试处理所有的场景信息，而是优先将注意力着重放在图像的显著区域，即与周边环境有着较大差异的区域。通过将不同区域的信息结合起来分析来建立一个内部的场景表示，从而决定接下来的注意力区域。通常我们感兴趣的对象在图像中只占据较小的区域，例如我们从 512×512 的图像中寻找一只小猫，最终它所处区域大小只占据 64×64 个像素点，但计算机仍然需要处理整个图像。如果我们将计算机处理图像的过程模拟为人感知图像的过程，将能大大地减少需要处理的区域，也就大大地减少了计算量与处理时间。

人类有两种处理视觉信息的方式，分别是自下而上的数据驱动处理方式与自上而下的任务驱动处理方式。目前大多的视觉注意模型都是基于自下而上的视觉注意模型即数据驱动的视觉注意模型。自下而上的数据驱动模型通常使用图像的底层视觉特征，例如颜色、亮度、方向，来生成图像的多维特征显著图。图 3-12 展示了数据驱动的视觉注意模型的处理流程：




图 3-12 数据驱动的视觉注意模型应用流程

虽然目前数据驱动的视觉注意正被广泛使用，但直接将其应用于目标检测时，由于环境自身的底层视觉特征的干扰，可能取得的效果并不尽人意。因此自上而下的任务驱动视觉模型在目前更为有效。任务驱动型的视觉注意模型，是带有先验知识的模型，更具有针对性，任务驱动的视觉注意力模型预先建立视觉期望，将期望目标从原始图像中分离出来，从而完成对图像中感兴趣区域的提取。任务驱动模型一般在场景先验信息、任务需求、物体特征这三个方面来实现对不同目标的注意。例如在一个复杂场景中寻找汽车，而汽车都拥有四个轮胎，因此在模型中加入轮胎的特征后，就可以使模型在搜索流程中较快地排除其他干扰信息，提升搜索目标的效率。本文的处理方式与任务驱动型的视觉注意模型相似，在检测识别任务中加入了目标行人的特征信息类似于生成了视觉期望。图 3-13 展示了任务驱动的视觉注意流程：




图 3-13 任务驱动的视觉注意处理流程

3.4.1 Hard Attention 与 Soft Attention

注意力机制可以被分为 Soft Attention 和 Hard Attention 两类。Hard Attention 是一个随机的过程。Hard Attention 根据概率分布从特征图中提取一些特征。由于专注区域是由随机取样完成的，所以它是一个随机的过程。与之相对的，Soft Attention 是一个确定的过程，Soft Attention 将图片的 attention map 与通过卷积神经网络得到的 feature map 做乘积并融合，使得当前专注的区域的特征的突显性远远高过其他不相关特征。Soft Attention 的构建基于显著图，主要对底层图像特征进行处理。Soft Attention 是参数化的，因此是可导的，可以将梯度通过反向传播给之前的网络。而 Hard Attention 则是不可导的，通常可使用增强学习来训练模型。Soft Attention 与 Hard Attention 的效果对比如图 3-14 所示：

图 3-14 Soft Attention(第一行)与 Hard Attention(第二行)^[47]

本文中的基于监控场景的行人重识别算法是一个观察区域随机的方法，因此属于 Hard Attention。


3.4.2 glimpse

Geoffrey.Hinton 与 Hugo.Larochelle 提出了“glimpse”的概念，用来指代对图像的某一次局部观察并进行视网膜转化后所得到的状态。观察代理不能观察到整个环境，只能通过一个类似人类视网膜的观测器来观察图像，即观察代理的高分辨率像素部分只能覆盖整个图像的一小部分，所以观察代理必须决定一系列的观察位置并且将每一个位置所获取到的信息与其对应的位置整合起来。其中涉及两项主要的计算问题：

1. 如何将位置信息与从视网膜输入中提出的特征结合来推理观察到的物体外形？
2. 在已知当前位置与历史位置后，怎样选取下一个观察区域来获得最优的目标识别效果？

给定一个图像训练集和一些标签对(I^t , I^l),通过给定的图像 I^t 来预测 I^l （比如分类标签, $I^l \in \{1, 2, \dots, C\}$ ）的值。常见的机器学习方法通常会从整个图像 I^t 中提取特征值然后通过这些特征值来直接预测 I^l 。为了阐明 glimpse 的作用，对从图像 I^t 中获取信息的方式加上一些限制。

将观察方式限制为只能依次通过注视 $[(i_1, j_1), \dots, (i_K, j_K)]$ 这 K 个位置来获取图像 I 中的信息。给定一个位置 (i_k, j_k) ，表示图像中的 $I(i_k, j_k)$ 像素点，通过一个视网膜变换^[44]将此像素周围的信息提取出来。这种转换仅仅将 $I(i_k, j_k)$ 附近的信息以高分辨率提取；而在视网膜的外围，通过取落在图像中小六边形中像素点的平均值来获取低分辨率的数据信息，这些六边形呈螺旋状排列，并且大小随着与 (i_k, j_k) 中心的距离增加而增大。所有的高分辨率信息与低分辨率信息都通过 $r(I, (i_k, j_k))$ 被整合在一个向量当中。Geoffrey. Hinton 给出了这种转化的示意图，如图 3-15 所示：


图 3-15 视网膜转变示例图^[44]

我们需要构建一个模型，能够根据一系列的 $\text{glimpses}(x_1, \dots, x_k)$ 来判别图像的分类 l 。Hermann Von Helmholtz 在很早之前就阐述了其可行性：人们可以通过一个远远小于整个形状大小的小孔的多次观察，来“看清”整个形状。他称之为“anorthoscopic perception”。每次 glimpse 得到的物体外观信息不能只是简单的叠加在一起，而是需要将观察到的物体局部的外观特征与它的相对位置相结合才能提供整体外观的有效信息。通常处理这种信息结合的方法对“是什么”(what)与“在哪儿”(where)这两个信息做乘积操作。


3.4.3 循环注意力模型

我们可以将识别目标行人问题视为一个带有特定任务的与视觉环境交互的观察代理的一系列决策过程。在每一个时间点，观察代理只能通过一个有观察范围限制的感知器(sensor)来观察环境，也就是说它永远不能完整地观察到整体的环境。观察代理可以从一个较小的区域提取信息，并且能够决定如何控制它的感知范围，比如改变观察区域的位置。观察代理也能通过执行一些动作来影响环境的真实状态。由于观察代理在一个时间点只能观察到环境的某些部分，所以它需要学习将不同时间点获取到信息整合来决定执行何种动作和决定下一个时间点的观察位置。每一步决策后，观察代理都会收到一个奖励值，它的目标就是如何获取最大的奖励值。

可以利用循环神经网络构造上述的注意力模型，给定观察的图像 x_t 与坐标位置 l_{t-1} ，利用一个传感器(glimpse sensor)提取图像在此处的特征表达。如图 3-16 所示：

图 3-16 glimpse sensor 示意图^[43]


在获取到输入图像 x_t 、观察位置 l_{t-1} 及其视觉特征 $\rho(x_t, l_{t-1})$ 之后，glimpse 网络通过使用一个 linear layer 将观察位置与视觉特征信息结合在一起，形成一个统一维度的信息 g_t ，即通过 glimpse 网络提取了图像的纹理和位置信息，如图 3-17 所示：

图 3-17 glimpse network 示意图^[43]

上述过程也可以由公式 (3-8) 表示：

$$g_t = G_{image}(x_t | W_{image}) \odot G_{loc}(l_t | W_{loc}) \quad (3-8)$$

接下来循环网络将 g_t 作为输入信息并与上一步的网络内部状态 h_{t-1} 结合来生成新的网络内部状态 h_t 。紧接着 location 网络 $f_l(., \theta_l)$ 和 action 网络 $f_a(., \theta_a)$ 根据系统当前的内部状态 h_t 来分别生成下一个观测位置 l_t 以及相应的行动 a_t (例如识别、分类等)。图 3-18 展示了上文所述的循环网络结构：

图 3-18 注意力模型的结构^[43]

由于在每个时间点观察代理都只能观察到全图的一部分，所以观察代理还需要将不同时间点获得的信息整合来决定下一步如何进行观察以及需要作出的举动。在循环的每一个步中，观察代理都会收到一个奖励信号。观察代理的任务是获取最大的奖励值。将上述模型应用到行人目标识别任务当中。那么 **action** 则是对目标行人的识别判断，奖励信号则反映了判断是否正确。

在每一个时间节点，观察代理处理由 **glimpse sensor** 获取的 **sensor** 数据，并与之前获取的信息结合来决定下一个时间节点的观察区域。在此我们将整个流程梳理一遍。在循环流程中的每一个节点 t ，观察代理都会收到图像的部分观察信息 x_t ，观察代理只能通过一个有带宽限制的 **sensor** 来从 x_t 中获取信息而不能总览全图。**sensor** 从图像 x_t 的 l_{t-1} 位置周围提取出区域图像信息。它将处于 l_{t-1} 位置附近的区域以高分辨率编码，相对地将距离 l_{t-1} 位置较远的区域以低分辨率编码。由此组成一个维度远远小于原图 x 的向量，将其称为 **glimpse**^[44]。**glimpse sensor** 包含于 **glimpse** 网络当中，用于生成 **glimpse** 特征向量 $g_t = f_g(x_t, l_{t-1}; \theta_g)$ 。观察代理维持一个内部状态来融合从历史观察中所获得的信息；它包含了观察代理对环境的感知信息并用于帮助决定下一个时间节点的观察区域及如何行动。本文的内部状态由循环神经网络的隐藏单元 h_t 组成并由一个核心网络随着时间变化对其进行更新，**glimpse** 特征向量 g_t 是此核心网络的外部输出，如公式 (3-9) 所示：

$$h_t = f_h(h_{t-1}, g_t; \theta_h); \quad (3-9)$$

在每一个时间节点，观察代理都需要执行两个行为：根据 sensor 控制器 l_t 决定如何部署 sensor 并根据 a_t 决定如何与环境交互。在第 t 个时间点，根据 location 网络 $f_l(h_t; \theta_l)$ 选取下一个观测区域即 $l_t \sim p(\cdot | f_l(h_t; \theta_l))$ 。相似地， a_t 由另一个网络 $a_t \sim p(\cdot | f_a(h_t; \theta_a))$ 决定。

在每次执行动作之后，观察代理都会收到一个新的视觉观察信息 x_{t+1} 和一个奖励信号 r_{t+1} 。观测代理需要得到最大的奖励值： $R = \sum_{t=1}^T r_t$ 。而在序列处理问题中，奖励值通常具有延迟回报的特点。在目标识别任务中，如果目标在 T 步之后被正确识别，那么 $r_T = 1$ ，否则 $r_T = 0$ 。

上述过程可以被看为部分可观察马卡罗夫决策过程即 POMDP(Partially Observable Markov Decision Process)的一个特例。整个环境的实际状态是不可知的，因此观察代理需要通过参数 θ 学习一种策略 $\pi(l_t, a_t | s_{1:t}; \theta)$ 来将利用历史信息决定当前时间的行动策略。

3.5 训练策略

观察代理的参数由 glimpse 网络的参数、核心网络($h_t = f_h(h_{t-1}, g_t; \theta_h)$)的参数以及 action 网络的参数 $\theta = \{\theta_g, \theta_h, \theta_a\}$ 构成。通过学习参数来使得观察代理在与环境交互时能获得最大的奖励值。当观察代理能够与外界环境交互时，例如在视频游戏中，观察代理引入一个基于交互序列 $s_{1:N}$ 的分布。通过最大化此分布的奖励来学习参数： $J(\theta) = E_p(s_{1:T}; \theta)[\sum_{t=1}^T r_t] = E_p(s_{1:T}; \theta)[R]$ 。由于 J 中包含一系列可以影响环境的高维序列的期望值，所以最大化 J 是比较困难的。可以将问题视为一个部分可观察的马卡罗夫决策过程，Williams^[45] 给出一个样本近似的方法来逼近其梯度，如公式 (3-10) 所示：

$$\begin{aligned} \nabla_{\theta} J &= \sum_{t=1}^T E_p(s_{1:T}; \theta) [\nabla_{\theta} \log \pi(u_t | s_{1:t}; \theta) R] \\ &\approx \frac{1}{M} \sum_{i=1}^M \sum_{t=1}^T \nabla_{\theta} \log \pi(u_t^i | s_{1:t}^i; \theta) R^i \end{aligned} \quad (3-10)$$

上面的学习策略被称为增强策略。观察代理通过当前的策略来获取交互序列 $s_{1:T}$ 的采样随后改变代理的参数 θ ，使得选中会获得高的累积奖励值行动的概率增加，而获取低奖励行动的概率减小。

公式 (3-10) 提供了梯度的无偏估计，但它具有较高的方差。因此通常使用公式 (3-11) 来进行梯度估计：

$$\nabla_{\theta} J \approx \frac{1}{M} \sum_{i=1}^M \sum_{t=1}^T \nabla_{\theta} \log \pi(u_t^i | s_{1:t}^i; \theta) (R_t^i - b_t)$$

$$R_t^i = \sum_{t'=1}^T r_{t'}^i \quad (3-11)$$

其中 R_t^i 是在执行动作 u_t^i 后得到的累积奖励值, b_t 是取决于 $s_{1:t}^i$ 而不取决于 u_t^i 本身的基准值。公式 (3-11) 能取得与公式 (3-10) 相同的期望, 但却有更小的方差值。依据 Sutton^[46] 的论述, 通常使用 $b_t = E_{\pi}[R_t]$, 这种基准值形式在增强学习中通常被称为值函数或效用函数(value function)。这样的方式能够增加后续能取得高累积奖励值的行动的概率, 相对应地减少获取累积奖励值较少的行动的概率。在本文中使用此类基准值并通过减少 R_t^i 与 b_t 之间的平方误差来训练模型。

在某些情景当中, 我们知道哪些行动才是正确的。例如一个目标检测任务, 其观察代理在最终的步骤的行动必须输出物体的预测标签。在训练集图像中, 物体标签是已知的, 通过学习优化策略后, 观察代理能够在观察序列的末尾输出训练图像的正确标签。这种方式也是监督学习的一种, 上述的目标检测任务可以通过最大化预测训练图像的正确标签的条件概率来完成, 即最大化 $\log \pi(a_T^* | s_{1:T}; \theta)$, 其中 a_T^* 对应从观察序列 $s_{1:T}$ 获得图像的真实标签。

在基于监控场景的行人重识别方法中, 由于我们观测的环境是静态的图像帧, 所以仅需要在观察状态的最后一层将 h_N 状态传递给 identification 网络进行识别匹配。通过使用上述增强学习策略, 即通过在最后的 identificationNet 输出的识别结果的正确与否来反馈相应的奖励值, 从而训练整个检索识别网络。

3.6 特征提取

目前有许多的深度神经网络均能很好地提取图像特征, 例如 AlexNet, VGG-16 和 ResNet。Zheng^[37] 在 Market-1501 数据集上对比了这些网络模型的性能, 如表 3-1 所示:

表 3-1 各网络模型在 Market-1501 上的性能对比^[37]

Model	Identification		Verification	
	rank-1(%)	mAP(%)	rank-1(%)	mAP(%)
AlexNet	56.03	32.38	41.24	22.47
VGG-16	64.34	40.77	42.99	24.29
ResNet-50	72.54	46.00	60.12	40.54

根据表 3-1 的性能对比结果, 可以看出 ResNet 的总体性能优于其他网络模型。基于表 3-1 的性能对比结果, 本文选取 ResNet 作为 base network。

ResNet 全称为 Residual Network, 即残差网络。它也是一种深度卷积神经网络, 在 2015 年的 ILSVRC 比赛上取得第一名。深度卷积神经网络在图像等分类问题上已经取得了巨大的进展与成果。研究^[50]表明网络的深度对网络的效果起着至关重要的效果, 由此提出一个重要的问题: 简单地叠加网络层能否使网络学习能力提升。在本文 3.3.1 小节中提到的梯度消失和梯度爆炸问题已经说明了, 传统的网络结构在网络深度加深到一定程度时, 性能不会再明显提升, 甚至出现下降。残差网络通过残差学习^[51]的方式解决了长期依赖的梯度消失与梯度爆炸问题, 使得在深度学习网络层数较深时, 学习能力也能得到比较有效的提高。表 3-2 展示了常用的残差网络结构:

表 3-2 常用 ResNet 的网络结构

Layer name	Output size	18-layer	34-layer	50-layer	101-layer	152-layer
Conv1	112×112	7×7, 64, stride 2				
Conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{pmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{pmatrix} \times 2$	$\begin{pmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{pmatrix} \times 3$
Conv3_x	28×28	$\begin{pmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{pmatrix} \times 2$	$\begin{pmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{pmatrix} \times 4$	$\begin{pmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{pmatrix} \times 4$	$\begin{pmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{pmatrix} \times 4$	$\begin{pmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{pmatrix} \times 8$
Conv4_x	14×14	$\begin{pmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{pmatrix} \times 2$	$\begin{pmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{pmatrix} \times 6$	$\begin{pmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{pmatrix} \times 6$	$\begin{pmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{pmatrix} \times 23$	$\begin{pmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{pmatrix} \times 36$
Conv5_x	7×7	$\begin{pmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{pmatrix} \times 2$	$\begin{pmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{pmatrix} \times 3$	$\begin{pmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{pmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPS		1.8×10 ⁹	3.6×10 ⁹	3.8×10 ⁹	7.6×10 ⁹	11.3×10 ⁹

目前比较常用结构的是 ResNet-50 与 ResNet-101。表 3-3 给出了不同层数的 ResNet 在 ImageNet 数据集上的分类错误率。

表 3-3 在 ImageNet 上的分类错误率

Model	top-1 error(%)	top-5 error(%)
ResNet-34	28.54	10.02
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

可以看出模型的分类错误率随着网络的加深而下降,但层数的增加也会使得网络更加难以收敛。由表 3-3 可以看出 ResNet-50 的错误率较低,并且层数深度尚可,因此本文选用在 ImageNet 上预训练的 ResNet-50 来进行特征提取,使用 conv1 到 conv4_3 作为 ResNet-50 part1 用于提取检测阶段的特征,使用 conv4_4 到 conv5_3 作为 ResNet-50 part2 提取行人重识别的特征。

3.7 算法的效率分析

与直接将行人检测器与行人重识别进行串联来使用的方法相比,本文算法可以有效减少整个流程的计算量。

由于行人重识别需要将检索目标与候选行人集合中的图像做特征提取、特征距离计算、排序等计算,所以当候选集较大时,重识别的消耗时间也是较长的。在传统的直接串联目标检测器与行人重识别网络的方法中,由于没有利用目标行人的信息,因此检测器在监控视频图像中检测出的所有行人都将参与行人重识别流程,所以整个流程的计算量比较大。在现实世界中,一个行人在一个时间之会出现于一个位置,所以在一幅监控画面中,目标行人最多出现一次。本文的方法利用了检索目标行人的特征来指引行人检测的过程,在一幅监控图像中只推论一个与目标行人最相似的候选行人来进行行人重识别,因此减少了参与行人重识别过程的行人数量,从而减少了整个流程的计算量与所需的时间。




图 3-19 候选行人数量。(a)检测直接结合重识别的候选数量；(b)本文方法的候选数量

例如在一个监控场景图像数量为 n 的重识别任务中, 假设平均每张图像中包含的行人个数为 m 。如上图 3-19 所示: 分为两级的识别检测方法, 首先检测出每个监控场景图像的中出现的行人, 然后作为行人重识别的比较对象, 与目标行人进行特征距离计算与排序。则进行检测后需要与 $m*n$ 个候选行人做特征距离计算与排序; 而本文的方法在每张监控图像中只推论一个候选行人, 即进行检测后只需要与 n 个候选行人做特征距离计算与排序, 在检测时间消耗差距不大的情况下, 让整个检索识别目标行人流程的时间减少了。

3.8 本章小结

本章给出了基于监控场景的行人重识别方法的详细设计思想, 首先介绍了算法的总体结构与识别流程, 接下来分别介绍算法的组成部分。通过将问题视为一个序列模型问题, 从而引出使用循环神经网络的解决方案, 再由循环神经网络在网络层数较深的情况下存在的梯度消失与梯度爆炸问题引出使用长短期记忆网络的解决方案; 随后论述了通过使用记忆单元与注意力模型来减少在监控图像中推论出的候选行人数量的方法, 减少了重识别网络计算的次数, 从而减少了整个流程的计算量。最后给出了算法的训练策略, 并分析了算法的效率。

第四章 数据集及评测方法

4.1 数据集介绍

目前行人重识别任务已经有不少的可用的评测数据集，但大多不符合监控视频的应用场景，例如 VIPeR、CUHK03 数据集，只提供已经剪切裁取好的行人边框图像而没有提供完整的监控场景图像，而 Caltech、Inria 等数据集则没有对行人的 ID 标识。本文采用提供完整的视频图像的 CUHK-SYSU、PRW 数据集来进行训练。

4.1.1 CUHK-SYSU 数据集

Xiao 等人收集并标注了一个大规模的行人检索数据集^[39]，即 CUHK-SYSU 数据集，其中包含多样化的场景。他们通过摄像设备拍摄了大量学校周围的环境画面，为了使视角、光照、背景环境更加丰富，他们又从包含行人的电影场景当中收集了大量的快照。图 4-1 展示了 CUHK-SYSU 的一组检索识别图像示例。




图 4-1 CUHK-SYSU 数据集图像示例

CUHK-SYSU 数据集总共包含 18184 张图像，经标注后得到 96142 个已标注的行人边框，将出现在不同图像中的同一行人进行统计后，共得到 8432 个标注过的不同行人，每一个行人在不同的图片中出现了两次以上。表 4-1 展示了 CUHK-SYSU 数据集的统计数据。

表 4-1 CUHK-SYSU 数据集统计情况

数据来源/分割	图像数量	行人数量	行人个体数
街边拍摄	2490	75845	6057
电影/电视	5694	20298	2375
训练集	11206	55272	5,532
测试集	6978	40871	2900
总计	18184	96143	8432

数据集中没有标注只出现部分身体和非正常行走姿态的行人，如坐着或蹲着的人。同样，由于行人重识别算法主要根据其衣着及体型等来进行匹配，所以在不同场景中更换了衣着外观的人也没有被标注。此外，对于高度小于 50 个像素的行人也没有进行标注，因为即使是人为对这样大小的行人图像进行识别也是很困难的。图 4-2 展示了已标注和未标注行人的高度分布。




图 4-2 CUHK-SYSU 中行人高度分布。(a) 已标注行人高度分布；(b) 未标注行人高度分布

4.1.2 PRW 数据集

为了模拟目标人物在当前监控视野消失一小段时间后，随后在邻近的监控设备视野中出现时将其定位的应用场景，Zheng 等人收集了 PRW 数据集。PRW 数据集是 Market-1501 数据集的扩展，并给出了完整的视频图像。视频数据在清华大学中收集，总时长 10 个小时。使用 6 个摄像头来进行数据收集，其中五个为 1080×1920 的 HD 高清摄像头，另一个为 576×720 的标清摄像头。对于每一个摄像头采集的视频数据，每隔 25 帧会进行一次标注。首先由人工标记出现在视频图像中的行人的边框，对于出现在 PRW 数据集中的每一个行人，如果他在 Market-1501 数据集

中存在，则赋予他一个 ID 来进行标识。由于所有的行人都被标注了边框，当不能确定行人的 ID 时，为这样的行人 ID 赋值-2。此类不能明确 ID 的行人边框在检测器中依然可以被使用来进行训练与验证，而重识别的训练与验证过程不使用此类边框。图 4-3 展示了 PRW 的标注样例：




图 4-3 PRW 数据集的标识界面

图 4-4 展示了 PRW 数据集的检测边框效果：

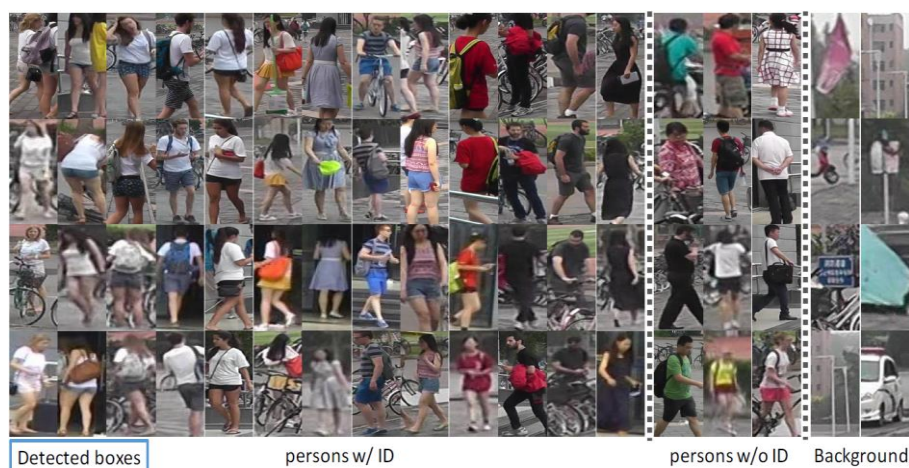


图 4-4 PRW 数据集检测框示例

其中 persons w/ ID 区域中，每一列包含同一个行人在不同视野下的 4 个检测边框；person w/o ID 展示了 PRW 数据集中出现但没有 ID 的行人；Background 这一列展示了检测器的错误检测结果。图中所使用的检测器为 DPM+R-CNN。

PRW 总计人工标注了 11816 个视频帧，共计检测得到 43110 个行人边框。其中 34304 个被赋予一个值为 1 到 932 的 ID，余下的被赋予的 ID 值为-2。目前的大多数行人重识别数据集都没有给出完整的视频图像，相对其他行人重识别数据集，PRW 不仅给出了完整的视频图像，并且数据规模也更加庞大，有利于充分训练。表 4-2 展示了 PRW 与传统的行人重识别数据集的对比：

表 4-2 PRW 数据集与其他重识别数据集对比

数据集	视频图像数量	ID 数量	标识框数量	摄像头数量
PRW	11816	932	34304	6
CAMPUS	214	74	1519	3
EPFL	80	30	294	4
Market-1501	0	1501	25259	6
RAiD	0	43	6920	4
VIPeR	0	632	1264	2
i-LIDS	0	119	476	2
CUHK03	0	1360	13164	2

下图给出 PRW 数据中行人高度与长宽比的分布：




图 4-5 行人高度与长宽比。(a) 行人高度分布；(b) 长宽比例(长/宽)

PRW 被分为包含 5704 帧图像与 482 个可识别行人的训练集和包含 6112 帧图像与 450 个可识别行人的测试集。数据集划分情况由表 4-3 展示：

表 4-3 PRW 数据集划分

数据集	训练集	验证集	测试集
视频帧数量	5134	570	6112
ID 数量	482	482	450
行人总数	16243	1802	25062
有 ID 行人数量	13416	1491	19127
无 ID 行人数量	2827	314	5935

4.2 评价指标

目前行人重识别有两个常用的评价指标：CMC Rank-k 与 mAP。

CMC Rank-k 和 mAP 都是图像检索问题中最常用的评价指标，行人重识别问题与图像检索问题类似。我们可以将目标行人的图像视为检索条件，行人重识别任务就是要在所有候选图像集中找到与目标行人最为相似的行人图像。使用累积匹配曲线来进行性能评估，Rank-k 准确率表示在候选集中得到的与目标行人相似度最高的 k 张图片中包含有目标行人的概率。其中常被使用的有 Rank-1、Rank-5、Rank-10 与 Rank-20。Rank-5、Rank-10 与 Rank-20 在返回重识别结果后还需要人眼的辅助来进一步判断，由于需要人为进行判别的图像数量大大减少，可以将其视为强力的辅助系统，所以也具有一定的实际应用意义。Rank-1 能够反映算法自动识别的准确性，是实现自动化识别的评价标准，所以本文使用 Rank-1 作为评价标准之一。

mAP (mean average precision) 是图像分类、图片检索等任务的常用评价标准，它能够较好地反映算法在整个测试集上的平均性能。由于在候选集中与目标行人匹配的图像通常不止一张，所以仅仅使用 Rank-1 评价指标不能完全反映算法的准确性，应当将所有的识别结果都计入评价范围当中。对于行人重识别任务，每一个类别即待识别的目标行人，都可以根据其召回率(recall)和查准率(precision)来绘制一条 P-R 曲线，AP 的含义是该 P-R 曲线下的面积，mAP 则是多个类别的 AP 的平均值。对于单个目标行人的识别，公式 (4-1) 定义 AP 的计算方式：

$$AP = \left(\frac{tr_1}{loc_1} + \frac{tr_2}{loc_2} + \dots + \frac{tr_n}{loc_n} \right) / n \quad (4-1)$$

其中 tr_i 表示返回的识别结果中第 i 个与目标行人匹配的图像， loc_i 表示第 i 个匹配结果在返回集中的排序位置。N 表示候选集中所有与目标行人匹配的图像个数。mAP 是多类目标行人的 AP 平均值，如公式 (4-2) 所示，其中 m 表示数据集中目标行人的 id 数量：

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_i \quad (4-2)$$

4.3 实验设计

由于整个网络的循环次数即观察图像的次数是可变的，首先设置不同循环次数的情况下，观察算法准确率的变化，推论观察次数对算法准确率的影响。然后使用不同的检测方法与行人重识别方法进行组合，研究检测器与识别器直接结合的准确率。接着在上文所述数据集上进行算法识别效果的验证，并与传统的检测

重识别方法进行性能对比。候选集的大小决定了与目标行人进行特征距离计算的次数，通过对比在不同的候选集大小条件下算法识别准确率的变化，来研究候选集大小对算法检测识别性能的影响。最后在 CUHK-SYSU 数据集上与传统方法进行识别速度的对比。

4.4 本章小结

本章介绍了进行算法测评实验的数据集，给出算法的评价标准，并给出了具体的实验目的与思想。

第五章 实验数据分析

本章对基于监控场景的行人重识别算法进行验证，首先将传统的行人检测与重识别方法结合来研究行人检测效果对重识别效果的影响，随后将本文算法在 CUHK-SYSU 和 PRW 数据集上进行测试验证，并与传统算法进行对比。图 5-1 展示了本文算法的识别示例图：




图 5-1 本文算法的识别示例图

5.1 实验环境

本文实验使用的主要软件环境如表 5-1 所示，硬件环境如表 5-2 所示：

表 5-1 本文实验的软件环境

操作系统	Ubuntu16.04
深度学习框架	Caffe
并行计算框架	CUDA8.0
加速库	cudnn5.1

表 5-2 本文实验的硬件环境

CPU	Intel Xeon E5-2620
内存	128 GB
GPU	NVIDIA GeForce GTX TITAN X

5.2 观察次数的影响

在本文的行人重识别方法的循环神经网络搜索目标行人的过程中，我们可以设置总的循环次数，即观察代理对图像总的观察次数。显然，观察次数越多，从监控场景图像中获取的信息就越丰富、越详细，准确率也应当有相应的提高；相对地，观察次数的增加也会增加整个流程的计算量与时间。为了研究观察次数对检测效率的影响，将观察次数从 5 逐步增加到 14 并比较它们的 Rank-1 识别准确率，结果如图 5-2 所示：




图 5-2 观察次数对识别效率的影响

由上图可以看出，当观察次数逐步地从 5 增加到 8 时，检测识别的准确率得到了比较明显的提升，而在观察次数从 8 增加到 14 的这一阶段，检测效率并没有得到显著的改善，观察次数越多，整个流程的计算量也越大。基于图 5-2 的实验结果，可以看出选择循环次数为 8 时，可以得到准确率与计算量间一个比较合理的平衡。

5.3 算法性能比较

本节在 CUHK-SYSU 及 PRW 数据集上验证基于监控场景的行人重识别算法的性能表现，并与其它传统的检测和重识别算法模型进行性能比较。

5.3.1 检测器与识别器结合的性能

在监控视频中检索识别特定的目标行人需要同时使用到行人检测与行人重识别技术，一种自然的做法就是将当前已有的行人检测器与重识别器结合来形成一个检索识别系统。本节研究检测器与识别器之间的影响。目前的行人检测方法通

常使用“候选区域+CNN”的方式，在此选用 Deformable Part Model(DPM)^[52]、Aggregated Channel Feature(ACF)^[53]和 Locally Decorrelated Channel Features^[54]来作为检测器用于生成候选区域。在行人重识别方面，分别使用 BoW^[55]，LOMO^[56]与 IDE recognizer^[48]方法来进行结合。

DPM、ACF 与 LDCF 都是优秀的目标检测算法。DPM 是一种基于可变形组件的检测算法，采用了传统的滑动窗口检测方式，通过构建尺度金字塔在不同的尺寸下进行搜索，它的本质是弹簧形变模型，能够比较好地适应物体运动所产生的形变问题。

ACF 即聚合通道特征，也就是将多个不同的特征叠加在一起，形成一个统一的特征，文献[53]通过实验发现将 LUV 颜色、梯度幅值通道与梯度方向通道组合所形成的特征用于检测能取得良好的检测效果，这三种特征成为目前聚合通道特征的标准配置，除了检测效果良好之外，该算法检测速度也很快。

LDCF 算法是对 ACF 算法的改进，通过提取更加高效线性无关的通道特征，进一步提高了检测的效果。

我们首先比较各检测方法在 PRW 数据集上的召回率。将使用 DPM、ACF 与 LDCF 的 CNN 在 PRW 数据集上训练后，在测试集上的统计得到召回率如图 5-3 所示：




图 5-3 召回率对比(IoU>0.5)

目前的目标检测算法通常将成功检测的标准设为 $\text{IoU} > 0.5$ ，其中 IoU (Intersection over Union)表示检测方法提出的候选框与原图中人为标记的行人框的重合程度。图 5-3 中的数据是在设定 $\text{IoU} > 0.5$ 的阈值标准下得到的，当我们设定检测正确的条件为 $\text{IoU} > 0.7$ 时，检测方法的召回率对比如图 5-4 所示：




图 5-4 召回率对比(IoU>0.7)

对比图 5-3 与图 5-4 可以看出, 当标准条件从 $\text{IoU}>0.5$ 变为 $\text{IoU}>0.7$ 时, 检测器的召回率有着明显的下降。其中 DPM 在 $\text{IoU}>0.5$ 的标准下表现较为劣势, 但在 $\text{IoU}>0.7$ 的标准下有着最好的检测性能。接下来使用这三种检测方法来生成候选区域, 并与重识别方法串联来研究检测效率对重识别准确度的影响, 在此采用三种常用行人重识别方法: BoW、IDE 与 LOMO。BoW 也被称为词袋模型, 起先被用于文档信息检索。在图像表示中, 同样可以将图像视为一个文档, 它由许多“视觉词汇”组成, 对于同一类型的不同图像, 它们必然存在一些共同的特征, 这些特征构成了此类目标的视觉词汇。图 5-5 与图 5-6 展示了各检测方法与 BoW 结合的平均精确度均值(mAP)与 Rank-1 识别率:




图 5-5 各检测方法与 BoW 结合的 mAP 对比




图 5-6 各检测方法与 BoW 结合的 Rank-1 识别率对比

文献[48]提出了 IDE 模型，用于在开阔环境中的行人重识别。IDE 是专为行人检测与行人重识别相结合的所提出的模型，通过使用在 ImageNet 上预训练过的模型并在数据集上进行参数微调，增强了对行人检测器所产生的背景误检情况的辨别能力。图 5-7 与图 5-8 分别展示了各检测方法与 IDE 结合的平均精确度均值与 Rank-1 识别率：




图 5-7 各检测方法与 IDE 结合的 mAP 对比




图 5-8 各检测方法与 IDE 结合的 Rank-1 识别率对比

文献[56]提出了使用 LOMO (Local Maximal Occurrence representation) 特征表达的方法来进行行人重识别, LOMO 能够有效地减少光照和视角变换对行人重识别性能造成的影响。图 5-9 与 5-10 展示了各检测方法与 LOMO 结合的平均精确度均值与 Rank-1 识别率:




图 5-9 各检测方法与 LOMO 结合的 mAP 对比




图 5-10 各检测方法与 LOMO 结合的 Rank-1 识别率对比

通过观察上面各图中的数据可以看出，当每张图片中由检测算法法提出的候选区域过少时，识别的准确率较低，这很可能是需要识别的目标行人在检测过程中没有被正确检测到，从而导致整个检测重识别过程的准确率降低；然而，当检测方法生成的候选区域过多时，重识别的准确率也发生了下降，这可能是由于检测器的产生了更多的干扰信息。生成更多的候选区域也将会使得计算量变大、消耗的时间变长。

在使用不同的检测方法来提出候选行人时，可以看出使用 DPM 作为检测器的组合整体表现出的准确率最高，LDCF 次之，而 ACF 排在最后。这与它们在 $\text{IoU}>0.7$ 标准下表现出的检测性能一致。而在 $\text{IoU}>0.5$ 的标准下，DPM 的检测效果最差。这说明检测方法对行人的定位会对后续的重识别准确率产生较大影响，所以将行人检测与行人重识别结合时应该使用 $\text{IoU}>0.7$ 的标准而不是目标检测中常用 $\text{IoU}>0.5$ 标准。

5.3.2 在 CUHK-SYSU 数据集上的性能

本节将基于监控场景的行人重识别方法与传统的行人检测结合行人重识别的方法进行对比。CCF^[57]将 filtered channel feature 与卷积神经网络组合，形成新的结构即 CCF (convolutional channel feature)。相比传统的 channel feature，CCF 学习到的特征表达更加丰富，在视觉处理任务中具有更好的泛化性能；人眼可以通过观察某些小型的显著区域来区分行人，但在传统的重识别方法中，这些显著表示信息没有被充分利用，在计算行人的相似度时常常被忽略，Zhao 等人提出一种无监督的显著性学习即 DSIFT^[58]，通过寻找图像中能用于分辨行人的显著性区域来

改善行人重识别的性能。 $KISSME^{[59]}$ 是行人重识别领域中一种经典的度量学习方法,通过学习一种马氏距离形式的度量函数来判断输入的图像是否匹配;虽然目前深度学习已经成为重识别特征提取的趋势,但一些出色手工设计特征也取得了很好的识别效果,LOMO就是其中之一,它首先通过使用Retinex算法对图像进行增强,随后再使用HSV颜色直方图来提取特征并采用XQDA方法来进行度量学习,较好地解决了光照和视角变换对行人重识别准确率所产生的影响。表5-3与图5-11、图5-12展示了本文算法与上述算法在CUHK-SYSU数据集上的行人重识别性能对比:

表 5-3 在 CUHK-SYSU 数据集上的性能对比

Method	mAP(%)	Rank-1(%)
CCF+DSIFT+KISSME	13.3	13.7
CCF+DSIFT+ Euclidean	11.3	11.7
CCF+Bow+Cosine	26.7	29.5
CCF+LOMO+XQDA	41.1	46.6
CCF+IDNet	51.1	57.2
ACF+DSIFT+KISSME	32.3	38.1
ACF+DSIFT+ Euclidean	21.7	25.9
ACF+BoW+Cosine	42.3	48.2
ACF+LOMO+XQDA	55.3	63.3
ACF+IDNet	56.7	63.2
R-CNN+DSIFT+Euclidean	34.4	39.6
R-CNN+DSIFT+KISSME	47.6	53.4
R-CNN+Bow+Cosine	56.9	62.3
R-CNN+LOMO+XQDA	68.9	74.1
R-CNN+IDNet	68.6	74.8
OIM	75.3	78.5
本文算法	70.4	74.6

图 5-11 展示了表 5-3 中识别性能较高的几种方法的平均精确度均值对比:




图 5-11 在 CUHK-SYSU 数据集上的 mAP 对比

图 5-12 对比了表 5-3 中 Rank-1 识别率较高的几种方法：




图 5-12 在 CUHK-SYSU 数据集上的 Rank-1 识别率对比

根据表 5-3 与图 5-11、图 5-12 的对比可以看出，本文算法的识别效果优于大多数的现有算法。

候选集的大小(gallery size)也会对算法的性能产生影响。表 5-3 与图 5-11、图 5-12 中的数据是在候选集大小为 100 的条件下统计的，接下来通过设置将候选集大小分别设为 50、100、500、1000、2000 与 4000 张。通过观察在不同候选集大小条件下算法准确率的变化来研究候选集大小对识别准确率的影响。结果如下图所示：




图 5-13 不同候选集大小下本文算法性能对比

由图 5-13 可以看出，算法匹配的准确率随着候选集大小的增大而逐渐下降，这是由于与目标行人相似的图像增多，增加了干扰信息。

5.3.3 在 PRW 数据集上的性能

表 5-4 与图 5-14、图 5-15 展示了本文算法在 PRW 数据集上与其他传统算法的性能对比。

表 5-4 在 PRW 数据集上算法的性能比较

Method	mAP(%)	Rank-1(%)
DPM+LOMO+XQDA	13.3	34.5
DPM+IDE _{det}	20.2	47.3
DPM+IDE _{det} +CWS	20.5	48.3
ACF+LOMO+XQDA	10.5	30.5
ACF+IDE _{det}	17.4	43.2
ACF+IDE _{det} +CWS	17.7	45.6
LDCF+LOMO+XQDA	11.2	31.2
LDCF+IDE _{det}	18.4	44.8
LDCF+IDE _{det} +CWS	18.5	45.2
OIM	25.4	52.1
本文算法	21.6	49.3




图 5-14 在 PRW 数据集上的 mAP 对比




图 5-15 在 PRW 数据集上的 Rank-1 识别率对比

其中 DPM、ACF 与 LDCF 检测器使用 AlexNet 作为 base network。虽然上文中曾提到的 VGGNet 与 ResNet 也能作为 base network，并且有更多的参数与更深的网络层数，但文献[48]中的实验表明，DPM、ACF 在 AlexNet 网络上与其他重识别器结合能取得更好的识别效果。

通过表 5-4 与图 5-14、图 5-15 中的数据可以看出，本文算法在 PRW 数据集上的识别准确率优于大多数识别方法，mAP 与 Rank-1 准确率相比 OIM 分别要低 3.8% 与 2.8%。总体来看，与在 CUHK-SYSU 数据集上的准确率表现一致。各算法在 PRW 数据集上的准确率都低于在 CUHK-SYSU 数据集上的准确率。这是由于 PRW 数据集的图像质量相对于 CUHK-SYSU 来说比较差。本文算法在 CUHK-SYSU 数据集与 PRW 数据集上的准确度上稍逊于 OIM，但本文的方法减少了整个流程的计算量，

以牺牲了少量识别准确率的方式换取了更快的重识别速度。

5.3.4 运行时间对比

本文算法通过在行人重识别的流程中引入目标行人的特征信息，减少了参与特征距离计算与排序过程的候选行人图像数量，因此减少了整个流程的计算量与运行时间。表 5-5 展示了在 CUHK-SYSU 数据集上直接将行人检测与行人重识别结合的方法即 OIM 的运行时间与本文方法的运行时间的对比。

表 5-5 在 CUHK-SYSU 数据集上的运行时间

候选监控图像数量	OIM	本文算法
100	192.7s	173.6s

通过在多个大小为 100 的候选测试集上进行检索识别任务，可以看出本文算法相对于将行人检测与行人重识别直接串联的方法，在处理时间上有着大约 10% 的提升。CUHK-SYSU 数据集中的每张图像大约包含 4 到 5 个行人，由本文 3.7 章节的分析可知，行人重识别是一个 1: N 的搜索匹配过程，N 表示候选集中的行人数量。OIM 一类的方法在监控图像中包含的行人越多时，产生的候选集中的行人越多；而本文算法产生候选行人与图像中包含的行人数量无关，每一帧图像只产生一个候选行人，因此每张图像中包含的行人越多，相对其他算法提升的速度就越大。当然，随着每张图像中包含的行人数量增多，干扰因素随之增多，也会出现检测准确率的小幅降低。

5.4 本章小结

本章首先将多种检测算法与行人重识别算法组合，通过比较在不同 IoU 阈值条件下的各检测器的召回率并将它们与不同的重识别方法结合来推论检测器对识别准确率的影响；然后将基于监控场景的行人重识别算法在 CUHK-SYSU 与 PRW 数据集上进行验证并进行性能对比，验证了算法的有效性；通过在 CUHK-SYSU 与 PRW 数据集上的实验对比的结果，显示了本文算法的检索识别效果优于大多数现有的方法；通过在 CUHK-SYSU 数据集中设置不同的候选集大小执行行人重识别任务，可以看出随着候选集的增大，算法的识别准确率逐渐下降；通过与文献[39]中的方法进行运行时间比较，证明了与传统方法相比，本文方法可以降低整个识别流程的时间。总体来看，验证了本文算法的有效性，实验对比结果显示本文算法的识别准确率优于大多数现有的算法，并且提高了识别过程的效率。

第六章 总结与展望

6.1 本文总结

本文以解决实际监控场景中的行人重识别问题为主线，首先分析一个可实际运用的面向监控场景的行人重识别系统所需要的主要理论技术，即行人检测与行人重识别。虽然将两者结合在许多场景有着重要的应用意义，但在目前，研究人员大多将行人检测与行人重识别作为计算机视觉领域中两个相互独立地问题来处理，将两者结合的研究应用仍然很少。

当前的行人重识别主要研究解决目标行人图像与候选行人图像之间的匹配问题，即当前的行人重识别算法默认候选图像是已经从整个图像中截取好的行人图像，在实际监控场景中，这个条件显然是不成立的。通常我们所需要寻找的目标在监控视频图像中只占据很小的一部分画面。为了解决这个问题，使得监控系统可以从包含行人的监控场景图像中进行行人重识别，本文设计了一种基于注意力模型的行人重识别方法。

本文的主要工作如下：

1. 将监控场景中的行人重识别问题作为一个序列模型问题，利用循环神经网络将原来的两级的先进行行人检测再进行行人重识别的流程变为一个统一的检测识别流程，设计了针对监控视频场景下的端对端的行人重识别方法。
2. 在两级识别过程中，即先进行行人检测再进行行人重识别，检索目标的信息只在行人重识别的匹配阶段被利用。本文通过引入一个初始记忆单元，与行人检测搜索网络相结合来寻找目标行人。相比先进行行人检测再进行重识别的流程，本文的方法在检索过程中更具有目的性。
3. 利用注意力模型与初始记忆单元结合，引导搜索网络的搜索区域，减少了行人重识别的候选行人数量，由此减少了计算量。
4. 在多个数据集上进行算法实验，并与其他常见的检测识别算法对比，分析算法的性能。

6.2 存在的问题与不足

本文设计的基于监控场景的行人重识别算法的思想为：通过一个观察代理来观察图片，观察代理每次只能观察图片中的一部分区域，通过将多次观察获取的

信息结合来检索识别目标。当候选监控图像增多时，本文方法的识别准确率有一定程度的下降。并且虽然相比直接串联行人检测模型与行人重识别模型的方法，速度有着一定的提升，但识别速度依然有着较大的提升空间。

6.3 未来工作展望

目前监控设备已经得到大范围普及，仅仅使用传统的人工方式处理由监控设备产生的巨大数据量显得力不从心，将智能处理方式引入安防监控系统的需求越来越强烈。在监控视频中检索识别特定目标人物可以分为两个步骤来做，即行人检测流程与行人重识别流程。将行人检测与行人重识别流程结合来为智能监控系统服务是一种自然的思想，同时将两种技术整合在同一个框架中是未来的发展方向。本文利用注意力模型与循环神经网络将行人检测与行人重识别流程结合，减少了整个检测流程的计算量。目前的行人重识别的研究依旧处于快速发展期，应当进一步研究如何提升重识别的准确率并加快识别的速度。

致 谢

不知不觉已耗尽了在学校的七年光景，回顾我的研究生生涯，有充实的理论基础学习，有令人兴奋的技术实践，也有过对未来的生活的迷茫。总的来说，无论是理论知识、技术能力还是人生阅历都有了不小的增长。随着硕士论文的完成，我的研究生生涯也即将告终。在此，我衷心地感谢陪伴我的每一个人。

首先感谢我的父母、爷爷奶奶，无论何时何地你们都是我最坚强的后盾。每当我意志消沉、踟蹰不前时。你们总能为我点亮明灯，驱散阴霾。你们永远是我前进的源动力。

感谢我的导师刘明教授，刘明老师渊博的学识、开阔的视野与严谨的态度使我在学习和生活中都受益匪浅。感谢龚海刚老师和刘念伯老师在论文撰写过程中给予我的批评与建议。

感谢戴锡笠师兄，从踏进教研室的第一步开始，就感受到戴师兄的热情关怀，使我在学习上能更进一步。在撰写硕士毕业论文时，戴师兄也为我解决了不少难题。

感谢我的室友谢鹏程，在我的生活与学习方面给予我许多帮助。感谢教研室的同伴们，与你们一起共度的时光总是快乐而短暂的。

感谢学校，给我一个良好的学习与生活环境，与我共度七年青春。

最后感谢自己，有过迷茫，但永不放弃。不忘初心，方得始终。

参考文献

- [1] R.T Collins, A.J Lipton, T. Kanade, et al. A system for video surveillance and monitoring[R].Technical Report CMU-RI-TR-00-12,CMU, 2000.
- [2] O Javed, M Shah. Tracking and object classification for automated surveillance[C]. The seventh European Conference on Computer Vision, Copenhagen, May 2002:439-443.
- [3] 徐瑞哲, 我国视频监控网世界最大[N]. 解放日报, 2013 年 12 月 15 日.
- [4] 成 岚 . 南 京 持 枪 劫 匪 逃 窜 视 频 公 布 [EB/OL].
http://news.xinhuanet.com/photo/2012-01/09/c_122555027.htm.
- [5] Wang X. Intelligent multi-camera video surveillance: A review[J]. Pattern Recognition Letters, 2013, 34(1):3-19.
- [6] Shouu-I Yu, Yi Yang, Alexander Hauptmann. Harry Potter's Marauder's Map: Localizing and Tracking Multiple Persons-of-Interest by Nonnegative Discretization[C]. IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2013:3714-3720.
- [7] Chen C L, Xiang T, Gong S. Multi-camera activity correlation analysis[C]. Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE Conference on. IEEE, 2009:1988-1995.
- [8] W. Hill, L. Stead, M. Rosenstein, et al. Recommending and evaluating choices in a virtual community of use[C]. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems, Denver, Colorado, USA, 1995, 194-201.
- [9] A.K Jain, A. Ross, and S. Prabhakar. An introduction to biometric recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology(TCSVT), 14(1):4-20, Jan 2004.
- [10] Pentland A, Moghaddam B, Starner T. View-based and modular eigenspaces for face recognition[C]. CiteSeer, 1994:84-91.
- [11] Turk M A, Pentland A P. Face recognition using eigenfaces[C] Computer Vision and Pattern Recognition, 1991. Proceedings CVPR '91. IEEE Computer Society Conference on. IEEE, 2002:586-591.
- [12] W. Zhao, R Chellappa, P. J. Phillips, and A. Rosenfeld. Face recognition: A literature survey[J]. ACM Computing Surveys, 35(4):399-458, 2003.
- [13] A. Pentland, B. Moghaddam, T. Starner. View-based and modular eigenspaces for face recognition[J]. Proc Cvpr, 1994:84-91.

- [14] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C] Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on. IEEE, 2005, 1: 886-893
- [15] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2010, 32(9): 1627-1645.
- [16] Malisiewicz T, Gupta A, Efros A A. Ensemble of exemplar-svms for object detection and beyond[C] Computer Vision (ICCV), 2011 IEEE International Conference on. IEEE, 2011: 89-96.
- [17] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C] Advances in neural information processing systems. 2012: 1097-1105.
- [18] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[J]. arXiv preprint arXiv:1311.2524, 2013.
- [19] C. Szegedy, A. Toshev, and D. Erhan. Deep neural networks for object detection. In NIPS, 2013.
- [20] H. A. Rowley, S. Baluja, and T. Kanade. Neural networkbased face detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1998, 20(1):23-38.
- [21] Vaillant R, Monrocq C, Cun Y L. Original approach for the localisation of objects in images[J]. Vision, Image and Signal Processing, IEE Proceedings -, 1994, 141(4):245 - 250.
- [22] Sermanet P, Kavukcuoglu K, Chintala S, et al. Pedestrian Detection with Unsupervised Multi-stage Feature Learning[C]. IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2013:3626-3633.
- [23] Jia, Yangqing, Shelhamer, et al. Caffe: Convolutional Architecture for Fast Feature Embedding[J]. 2014:675-678.
- [24] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]. International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
- [25] R Girshick.Fast R-CNN.MicroSoft Research, 2015.
- [26] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Trans Pattern Anal Mach Intell, 2014, 37(9):1904-1916.
- [27] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Computer Vision and Pattern Recognition. IEEE, 2016:779-788.

- [28] Wei Liu, Dragomir Anguelov, Dumitru Erhan. SSD:Single Shot MultiBox Detector[J]. Computer Vision and Pattern Recognition, 2015:21-37.
- [29] Zajdel W, Zivkovic Z, Krose B J A. Keeping Track of Humans: Have I Seen This Person Before?[C]. IEEE International Conference on Robotics and Automation. IEEE, 2006:2081-2086.
- [30] Gheissari N, Sebastian T B, Hartley R. Person Reidentification Using Spatiotemporal Appearance[C].Computer Vision and Pattern Recognition, 2006 IEEE Computer Society Conference on. IEEE, 2006:1528-1535.
- [31] Eric P. Xing, Andrew Y, Ng, Michael I. Jordan, and Stuart Russell. Distance metric learning, with application to clustering with side-information[C].In Neural Information Processing System(NIPS), pages 505-512, 2002.
- [32] Jason V. Davis, Brian Kulis, Prateek Jain, Suvrit Sra, and Inderjit S. Dhillon. Information-theoretic metric learning[C]. In International Conference on Machine Learning, 2007.
- [33] A. Krizhevsky, I. Sutskever, and G. Hinton. Imagenet classification with deep convolutional neural networks. In NIPS, 2012.
- [34] J. Donahue, Y. Jia, O. Vinyals, J. Hoffman, N. Zhang, E. Tzeng, and T. Darrell. Decaf: A deep convolutional activation feature for generic visual recognition. arXiv:1310.1531, 2013.
- [35] K. He, X. Zhang, S. Ren, and J. Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition. In ECCV, 2014.
- [36] Ren. S, He. K, Girshick. R, Sun. J. Faster R-CNN: Towards real-time object detection with region proposal networks. In NIPS, 2015.
- [37] Liang Zheng, Yi Yang, and Alexander G. Hauptmann. Person Re-identification: Past, Present and Future[C]. CVPR, 2015. 2-3.
- [38] H. Yoo, H. Park, D. Jang. Expert System for color image retrieval[J]. Expert Systems with Application, 28(2):347-357, 2005.
- [39] Xiao T, Li S, Wang B, et al. Joint Detection and Identification Feature Learning for Person Search[J]. 2016.
- [40] Wang F, Jiang M, Qian C, et al. Residual Attention Network for Image Classification[J]. 2017:6450-6458.
- [41] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 2013, 9(8):1735-1780.

- [42] Shi X, Chen Z, Wang H, et al. Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting[J]. 2015, 9199:802-810.
- [43] Mnih V, Heess N, Graves A, et al. Recurrent models of visual attention[J]. 2014, 3:2204-2212.
- [44] Larochelle H, Hinton G. Learning to combine foveal glimpses with a third-order Boltzmann machine[C]. International Conference on Neural Information Processing Systems. Curran Associates Inc. 2010:1243-1251.
- [45] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4):229-256.
- [46] Sutton R S. Policy Gradient Methods for Reinforcement Learning with Function Approximation[J]. Submitted to Advances in Neural Information Processing Systems, 2000, 12:1057-1063.
- [47] Xu K, Ba J, Kiros R, et al. Show, Attend and Tell: Neural Image Caption Generation with Visual Attention[J]. Computer Science, 2015:2048-2057.
- [48] Zheng L, Zhang H, Sun S, et al. Person Re-identification in the Wild[J]. 2016:3346-3355.
- [49] Chen D, Yuan Z, Chen B, et al. Similarity Learning with Spatial Constraints for Person Re-identification[C] Computer Vision and Pattern Recognition. IEEE, 2016:1268-1277.
- [50] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C] IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2015:1-9.
- [51] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. 2015:770-778.
- [52] Felzenszwalb P F, Girshick R B, Mcallester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2014, 47(2):6-7.
- [53] Dollár P, Appel R, Belongie S, et al. Fast Feature Pyramids for Object Detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2014, 36(8):1532-1545.
- [54] Nam W, Dollár P, Han J H. Local decorrelation for improved pedestrian detection[C]. NIPS. 2014:1-9.
- [55] Zheng L, Shen L, Tian L, et al. Scalable Person Re-identification: A Benchmark[C].IEEE International Conference on Computer Vision. IEEE Computer Society, 2015:1116-1124.
- [56] Liao S, Hu Y, Zhu X, et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C]. Computer Vision and Pattern Recognition. IEEE, 2015:2197-2206.
- [57] B. Yang, J. Yan, Z. Lei, and S. Z. Li. Convolutional channel features[C].IEEE ICCV,2015, 82–90.

- [58] Zhao R, Ouyang W, Wang X. Unsupervised Saliency Learning for Person Re-identification[C]. Computer Vision and Pattern Recognition. IEEE, 2013:3586-3593.
- [59] Köstinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]. IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2012:2288-2295.