

论文精读：具有Mamba聚合和协同提示的多模态对象重新识别

1. 研究背景

1.1 目标再识别 (ReID)

1.2 单模态 ReID 的问题

1.3 多模态对象再识别 (Multi-modal Object ReID)

2. 作者的方案 —— MambaPro 框架

① PFA (并行前馈适配器)

② SRP (协同残差提示)

③ MA (Mamba 聚合)

3. 实验结果

4. 用一句大白话总结

5. 论文的四大贡献

1. 新框架 MambaPro

2. SRP (协同残差提示)

3. MA (Mamba 聚合)

6. 整体路线

6.1 左侧：三种模态 & token 组成

6.2 中间蓝块 (a)：PFA 并行前馈适配器

6.3 左侧黄块 (b)：Synergistic Prompt (协同提示, SRP 的第1部分)

6.4 中下橙块 (c)：Residual Prompt (残差提示, SRP 的第2部分)

7. 实验设置

7.1 数据集

7.2 评估协议

7.3 训练配置

8. 多模态 Person ReID (RGBNT201 数据集)

9. 多模态 Vehicle ReID (RGBNT100 / MSVR310 数据集)

9.1 单模态方法

9.2 多模态方法

9.3 我们的 MambaPro

10. 消融研究分析 (RGBNT201 数据集)

11. 可视化特征分布

12. 结论

1. 研究背景

1.1 目标再识别 (ReID)

就是用监控摄像头拍的图片，去确认某个物体（比如人、车）是不是同一个。

特点是：摄像头位置不一样、视角不一样，没有重叠视野。

1.2 单模态 ReID 的问题

单模态指的是只用一种图像类型（一般是普通彩色RGB图像）。

问题是：

- 光照变化（白天/晚上）会影响识别
- 阴影干扰
- 图片分辨率低（远距离拍摄）

在这些极端条件下，模型容易提取到**错误或无用的特征**，导致识别失败。

1.3 多模态对象再识别 (Multi-modal Object ReID)

就是用多种类型的图片信息（例如彩色图像RGB、夜视图像NIR、热成像图像Thermal等）来识别是不是同一个物体（比如同一个人、同一辆车）。

为什么要多模态？因为不同模态有**互补信息**：

- 彩色图像白天很好用，但晚上可能看不清。
- 热成像晚上好用，但细节不够清晰。

所以多模态结合能更稳定地识别对象。

- **问题**

现在有一些很强的“大模型”，比如 CLIP，它本来是为了文字和图片匹配训练的（单模态或跨模

态)，在传统单模态 ReID 中表现很好。

但直接用在多模态 ReID 上，效果不一定好，因为：

- a. 它没专门学过不同模态之间的细节融合。
- b. 多模态信息的交互需要更细致的特征提取方法。

2. 作者的方案 —— MambaPro 框架

作者提出了一个新方法，叫 **MambaPro**，它有三大关键设计：他们提出了 **MambaPro** 框架，把 CLIP 和 Mamba 模型结合起来，同时降低计算量和保持特征融合效果。

① PFA（并行前馈适配器）

- 把 CLIP 模型“改造”一下，让它能处理多模态输入。
- 就像给 CLIP 加了一个“转接口”，让它不仅能看彩色图像，还能理解热成像、红外等信息，并且能把这些信息对齐到同一个特征空间。

② SRP（协同残差提示）

- 这个东西是为了让不同模态的特征更好地“合作学习”。
- 可以理解成：模型在处理不同模态的特征时，会额外加上一些“提示信息”，让它知道哪些特征应该一起考虑。
- 这样能让多模态的融合更顺畅，而不是各自为政。

③ MA（Mamba 聚合）

- **Mamba** 是一个对长序列建模很高效的模型结构（类似 Transformer，但更轻、更快）。
- 在这里用 Mamba 来**建模不同模态之间的交互**，就像把不同模态的特征当作一个“长序列”，用 Mamba 去提取它们之间的关系。
- 优点：
 - a. 比 Transformer 计算量更小（低复杂度）。
 - b. 特征提取更稳健，不容易受噪声影响。

3. 实验结果

- 作者在三个公开的多模态 ReID 数据集上验证了效果：
 - RGBNT201
 - RGBNT100
 - MSVR310
- 结果显示，MambaPro **效果更好**（准确率提升） + **计算量更小**（更适合实际应用）

4. 用一句大白话总结

这篇论文的意思是：

他们把一个很强的**预训练大模型 CLIP** 改造成能处理**多模态图片（彩色+红外+热成像等）**，再用一种新的融合方法（SRP 提示 + Mamba 聚合）让这些模态的信息能更好地配合起来，最终在多个数据集上比以前的方法更准、更快。

5. 论文的四大贡献

1. 新框架 MambaPro

- 第一次把 CLIP 搬到多模态对象 ReID 任务里用。
- 加上 Mamba 聚合 和 协同快速微调（相当于让不同模态快速“磨合”）。
- 目标：多模态 ReID 又快又好。

2. SRP（协同残差提示）

- 用来指导多模态特征的**联合学习**。
- 让不同模态之间更好地交流知识（知识转移）。
- 还能减少**参数量**和**计算量（FLOPs）**，节省算力。


3. MA（Mamba 聚合）

- 把不同模态的互补信息充分融合（既融合单个模态内部的信息，也融合不同模态之间的信息）。

- 算法复杂度是线性，所以速度快、算力要求低。
- 实验验证
- 在三个公开的多模态 ReID 数据集上做了大量实验。
- 结果：比现有方法更准、更高效。

6. 整体路线

RGB / NIR / TIR 三种模态 → 进 冻结的 CLIP 图像编码器（只训练轻量外接模块）
 → 在编码器里插 并行前馈适配器 PFA 做低成本适配
 → 用 SRP 协同残差提示让三模态“互通有无、逐层细化”
 → 把三条序列拼成长序列交给 Mamba 聚合 MA 做高效跨模态建模
 → 得到融合特征，接 分类/度量学习头 训练（CE + Triplet）。



6.1 左侧：三种模态 & token 组成

NIR / RGB / TIR 输入 先做 Patch Embedding（把图像切块变 token）。

每条序列都含：

[cls] token（全局摘要用）

patch tokens（每个图像块的特征）

prompt tokens（提示向量，指导模型“关注什么”）

雪花标识的是 冻结（Frozen）的 CLIP 层；粉色的是 可训练 的新模块/向量。

6.2 中间蓝块 (a): PFA 并行前馈适配器

目的：把 CLIP 的能力“温和地”迁移到多模态 ReID，而不破坏原有信息流。

- 每个 Transformer Layer 里原本有：LN $\rightarrow$ MHSA $\rightarrow$ LN $\rightarrow$ FFN（前馈网络）。
- PFA 做法：在 FFN 并行接一条小 FFN 支路（Linear—GELU—Linear），然后把主 FFN 输出与 PFA 输出相加后再往下走。
- 对比“串联插适配器”的做法，这种并行不会打断 CLIP 的主干语义流，保留原特征同时少量参数完成任务适配，尤其多模态场景下更稳。

6.3 左侧黄块 (b): Synergistic Prompt（协同提示，SRP 的第1部分）

目的：三种模态先“对齐共识”，共享一份“融合提示”。

- 每个模态各自有一组 prompt tokens（小方块）。
- 图里带 A 的圆表示：把三模态的 prompt 做 平均/聚合 得到“融合提示”。
- 这份融合提示再被回灌到每个模态（图中“Transfer Block”），等于告诉三条分支：“我们共同要关注这些关键信息”。
- 效果：跨模态知识转移、减少噪声差异，且仅靠少量可训练向量完成。

6.4 中下橙块 (c): Residual Prompt（残差提示，SRP 的第2部分）

目的：提示不是一次性注入，而是逐层细化、动态更新（层级聚合）。

- 在后续层里，每个模态的 prompt 会经过一个小网络产生增量（残差），新提示 = 旧提示 + 增量（图中“ $\oplus$ ”）。
- 这让提示在浅层关注形状/边缘，在深层逐步强化身份相关细节，同时保持对原有特征的残差保真，不把有用信息“洗掉”。

PFA 让 CLIP 低成本“转行”，SRP 让三模态先达成共识再逐层细化，MA 以线性复杂度做长序列跨模态交互——最终在不涨太多算力的前提下，学到更稳更可分的多模态 ReID 表征。

7.实验设置

7.1 数据集

- **RGBNT201** (Zheng et al., 2021)
 - 多模态 人 ReID 数据集
 - 包含 RGB、NIR (近红外)、TIR (热红外) 三种模态
- **RGBNT100** (Li et al., 2020)
 - 大规模多模态 车辆 ReID 数据集
 - 挑战因素: 异常照明、眩光、遮挡等
- **MSVR310** (Zheng et al., 2022)
 - 小规模多模态 车辆 ReID 数据集
 - 挑战因素: 视觉复杂度更高 (如密集场景、严重遮挡)

7.2 评估协议

指标:

- 平均精度 (mAP)
 - 累积匹配特征 (CMC)
- 测试 Rank-K ($K = 1, 5, 10$)

复杂度分析:

- GPU 内存占用
- 可训练参数量
- FLOPs (每次前向计算的浮点运算量)

7.3 训练配置

- **小批量大小:**
 - 小规模数据集 (RGBNT201 / MSVR310) :
 - batch = 64
 - 每个 ID 采样 4 张图像
 - 每批 16 个 ID
 - 大规模数据集 (RGBNT100) :
 - batch = 128
 - 每个 ID 采样 16 张图像
- **损失权重:**
 - $\lambda_1 = 0.25$
 - $\lambda_2 = 1.0$
- **优化器:**
 - Adam, 初始学习率 = 3.5×10^{-4}
 - 采用预热 + 余弦衰减策略
- **训练轮数:**
 - RGBNT201 / MSVR310 $\rightarrow$ 60 epochs
 - RGBNT100 $\rightarrow$ 30 epochs

8. 多模态 Person ReID (RGBNT201 数据集)

- **单模态方法** (只用一种图像类型) 表现较差, 例如:
 - PCB (经典方法) mAP 仅 **32.8%**
- **多模态方法** (融合多种图像模态) 性能明显更好:
 - 基于 CNN 的:
 - IEEE (Wang et al., 2022) mAP = **49.5%**
 - LRMM (Wu et al., 2025) mAP = **52.3%**
 - 基于 Transformer 的:
 - TOP-ReID (Wang et al., 2023) mAP = **72.3%**
- **我们的 MambaPro:**
 - mAP = **78.9%** (比 TOP-ReID 高 6.6%)
 - Rank-1 = **83.4%** (比 TOP-ReID 高 6.8%)

结论: 我们的方法在 Person ReID 上显著领先, 说明 MambaPro 对多模态特征的融合能力更强。

9. 多模态 Vehicle ReID (RGBNT100 / MSVR310 数据集)

9.1 单模态方法

- 有时 CNN 还能赢过部分 Transformer (例如 BoT (Luo et al., 2019)) , 但总体仍弱于多模态融合。

9.2 多模态方法

- LRMM (Wu et al., 2025) RGBNT100 $\rightarrow$ mAP = **78.6%**
- EDITOR (Zhang et al., 2024) RGBNT100 $\rightarrow$ mAP = **82.1%**

9.3 我们的 MambaPro

- RGBNT100 $\rightarrow$ mAP = **83.9%** (比 EDITOR 高 1.8%)
- MSVR310 (小规模复杂数据集) $\rightarrow$ mAP = **47.0%** (比 EDITOR 高 8.0%)

结论: MambaPro 在大规模和小规模车辆 ReID 数据集上都取得了领先, 尤其在更困难的小规模场景中优势更明显。

10. 消融研究分析 (RGBNT201 数据集)

1. 关键组件的影响 (表 3)

模型	主要变化	mAP 变化	结论
A → B	冻结 CLIP (L) → 全微调 CLIP (F)	↑ 显著提升	微调是必要的, 解锁预训练知识潜力
B → C	加入 PFA (并行前馈适配器)	↑ 3.8% mAP	PFA 能高效提升特征转化能力
B → D	加入 SRP (协同残差提示)	↑, 且参数/FLOPs 增加极少	SRP 在低成本下带来性能提升
C + D → E	结合 PFA + SRP	↑ 更高	组件互补, 进一步提高性能
E → F	加入 MA (Mamba 聚合)	↑ 达到最佳 mAP = 78.9%	高效建模多模态长序列是关键
F ↔ G	比较全微调 vs 冻结主干	mAP 相近 (78.9 vs 78.7)	方法鲁棒, 适配不同微调策略

结论: PFA、SRP、MA 都是有效且互补的模块, 最终组合带来最大性能提升。

2. 不同提示机制的效果 (表 4 & 图 4)

提示机制	描述	mAP 结论
IP (独立提示)	各模态独立提示, 无信息交互	基线
SP (协同提示)	模态间提示交互	↑ 优于 IP, 协同融合有效
SRP-Separation	残差提示, 但来源于分离模态	↑ 进一步提升
SRP-Fusion	残差提示, 来源于融合模态	最佳性能

结论: 提示机制中, 残差结构 (SRP) 显著优于普通协同提示 (SP), 且融合版本优于分离版本。

3. 不同适配器的效果 (表 5)

适配器	性能特点	mAP 对比
LoRA	无非线性变换, 学习能力弱	较低
BNA (瓶颈适配器)	适中性能	基线
PFA (本方法)	并行结构, 保持原信息流, 适应多模态	↑ 4.7% mAP 优于 BNA

结论: PFA 在多模态 ReID 任务中显著优于常用适配器。

4. 不同聚合方法的效果 (表 6)


聚合方法	特性	mAP	
Sum / Concat	简单融合	较差	
Transformer 聚合	基于注意力, 性能提升	中等	
Intra-MA / Inter-MA	基于 Mamba, 分别建模模态内与模态间序列	高	
最终 MA	综合 Intra+Inter	最佳性能	

结论: Mamba 聚合在捕获多模态长序列依赖方面比 Transformer 更有效。

11.可视化特征分布

表五：与不同适配器的比较。BNA表示瓶颈适配器。LoRA-r (x) 表示等级为x的LoRA，我们将x设置为64，256和384进行比较。

图6：MA前后不同模态的余弦相似性分布的对齐可视化。



你这张图很直观地展示了 MA 前后跨模态特征的相似性变化：

- (a) R 和 N：MA 之前（蓝色）分布集中在接近 0 的低相似度区间，表示两个模态特征几乎不对齐；MA 之后（绿色）分布整体右移，峰值接近 0.5~0.6，相似性显著提升。
- (b) R 和 T：MA 之前同样集中在低相似度区域；MA 之后峰值向右移动到 0.4~0.5，分布范围变宽，模态对齐效果明显改善。

可以在论文中这样总结：

图 6 展示了 MA 前后不同模态间特征余弦相似性的分布变化。可以看到，MA 之前各模态间相似性主要集中在低值区域，表明特征分布存在明显偏移。引入 MA 后，相似性分布整体右移并显著集中，证明 MA 有效地对齐了多模态特征空间，从而提升跨模态信息融合的质量与稳定性。

12. 结论

本文提出了 **MambaPro** 一种高效的多模态对象 ReID 特征学习框架。

我们设计了 **并行前馈适配器（PFA）**，将预训练 CLIP 的知识高效迁移至 ReID 任务，并引入 **协同剩余提示（SRP）** 以增强多模态特征交互与知识传递。此外，我们提出了 **Mamba 聚合（MA）**，以线性复杂度建模长序列并充分融合跨模态互补信息，在保持低计算开销的同时超越了基于注意力的现有方法。在 RGBNT201、RGBNT100 和 MSVR310 三个多模态对象 ReID 基准上的大量实验表明，MambaPro 在 mAP 与 Rank-1 上均显著优于最新方法，验证了其在多模态特征学习中的有效性与泛化潜力。

