

学校代码: 10004

密级: 公 开

北京交通大学

BEIJING JIAOTONG UNIVERSITY

硕士专业学位论文

基于部位匹配与注意力模型的
行人重识别算法研究

作者姓名 李 芮

工程领域 计算机技术

指导教师 滕 竹 副教授

培养院系 计算机与信息技术学院

二零一九年五月

北京交通大学

硕士专业学位论文

基于部位匹配与注意力模型的行人重识别算法研究

Research on Person Re-identification Algorithm by Part Matching and
Attention Models

作者：李芮

导师：滕竹

北京交通大学

2019 年 5 月

学校代码: 10004

密级: 公开

北京交通大学

硕士专业学位论文

基于部位匹配与注意力模型的行人重识别算法研究

Research on Person Re-identification Algorithm by Part Matching and
Attention Models

作者姓名: 李芮

学 号: 17125208

导师姓名: 滕竹

职 称: 副教授

工程硕士专业领域: 计算机技术

学位级别: 硕士

北京交通大学

2019 年 5 月

致谢

时光如白驹过隙，转眼间两年的研究生生涯即将结束，短短两年时间让我学习到很多，从学术科研到为人处世，逐渐变得成熟，也结识了很多良师益友。谨在此以简短的文字向在硕士期间关心、帮助和支持我的老师与同学表示诚挚的感谢。

首先要感谢的是我的导师滕竹老师，滕老师在生活中待人和善，平易近人，在学术上态度严谨，严格要求我们。在实验室的两年科研学习中，滕老师不但为我指引学习的方向，及时帮我改正错误，同时也亲力亲为地带领我参加科研项目。在研究生的两年学习生活中，滕老师帮助我建立起正确的科研和工作态度，开阔了我在学术方面的眼界。在此，由衷地感谢滕老师对我的帮助和指导。同时也要感谢实验室的张宝鹏老师，在学习和生活上也给与我很大的帮助。

此外，实验室的李玉琳，李妍，田佳杰，王耀瑄等同学，李佳坤师弟，王晶粦、晏明莉和段雅妮师妹等积极同我讨论学术科研问题，对我的科研工作和论文撰写提出了宝贵的意见，在此特别感谢你们的陪伴，感恩与你们在一起的点点滴滴。同时也要感谢我的室友刘俊杰和李珊同学，感谢你们在生活中给与我的关怀和帮助。

同时也要感谢学校的培养和教育，为我们的学习和生活提供了良好的环境和条件，教会我很多可以应用于社会和工作中的知识和经验。感谢在本文相关研究中所参考论文的作者，你们的研究成果增加了我的知识储备，让我能够顺利做好科研工作。

最后，要感谢父母对我二十多年的养育之恩，是你们的关怀、支持与鼓励让我走到现在，是你们给与奋斗的动力，谢谢你们的爱，我将继续努力，报答你们的养育之恩。

在论文即将完成之际，心里五味杂陈，有激动也有不舍，在这里再一次感谢研究生生活里遇到的每一位老师和同学，同时也要感谢百忙之中抽出时间参与论文审批与答辩的老师。在未来的人生道路上，我将砥砺前行，努力奋进。

摘要

在计算机视觉中,行人重识别是一个具有挑战性的任务,因为其涉及到行人外观、行人姿态、背景光线以及相机视域等方面的变化。因此,如何提取具有可分辨性的特征进行行人匹配是当前行人重识别需要重点关注的问题。同时随着深度学习的快速发展,卷积神经网络的优势为行人重识别问题的解决提供了很好的技术基础,通过网络模型自动提取的行人特征可以有效地提高行人重识别的效率和准确率。本文基于深度学习方法对行人重识别进行了模型及算法的研究,针对两个不同的关注点提出了两个模型,具体内容如下:

针对传统的行人重识别方法直接提取全局特征,难以获得较好的行人区分度的问题,本文提出一种基于注意力机制的多任务优化学习算法模型。该模型由一个含有注意力机制的孪生网络构成,通过一个新的多任务损失函数进行参数调整。注意力机制通过强调有用的通道特征抑制作用较小的特征来提高网络的辨别能力;多任务损失函数的目的是在特征空间中缩小同一个体的距离,同时增大不同个体之间的距离。通过在 Market1501 和 CUHK03 数据集上与其他传统和深度学习算法的比较,进一步证明了本模型在行人重识别任务上的有效性。

针对全局特征无法反映行人部位的细节,难以有效提高行人重识别准确率的情况,提出了一种多特征融合的行人表达方法。该方法不依赖于额外的骨架关键点或者姿态估计模型,通过一个特征划分模型生成全局特征和部位特征,并保持不同图片行人部位的内容一致性;同时构建一个自适应评分网络对部位特征的重要性进行评估,将全局特征和部位特征进行融合作为最终的行人特征。该方法在 Market1501, CUHK03 和 DukeMTMC-reID 三个广泛使用的数据集上进行对比实验,结果证明该方法优于现有的大多数行人重识别算法。

关键词: 行人重识别;深度学习;注意力机制;全局特征;部位特征

ABSTRACT

In computer vision area, person re-identification is a challenging task as it involves large variations in human appearances, human poses, background illuminations, camera views, etc. Therefore, how to extract the distinguishable features for pedestrian matching is indispensable and critical for the person re-identification task. And with the rapid development of deep learning, the advantages of convolutional neural network provide a good technical basis for solving the person re-identification. The pedestrian feature automatically extracted by the network model can effectively improve the efficiency and accuracy of person re-identification. In this paper, based on the deep learning method, two models viewed from two different perspectives for person re-identification are studied. The details are as follows:

To solve the problem that the traditional person re-identification method directly extracts the global features and it is difficult to obtain a better pedestrian discrimination, this paper proposes a novel deep Siamese person re-ID network equipped with an attention mechanism, constrained by a multi-loss function. The attention mechanism enhances the discriminability of the network by emphasizing effective features and suppressing the less useful ones. The purpose of the multi-loss function is to diminish distances of identical persons and at the same time expand distances between dissimilar persons in the learned feature space. Extensive comparative evaluations demonstrate that the proposed method significantly outperforms a number of state-of-the-art approaches, including both conventional and deep network based ones, on the challenging Market1501 and CUHK03 data sets.

To solve the problem that the global features could not reflect the details of pedestrians, it is difficult to effectively improve the accuracy of pedestrian recognition, a multi-feature fusion method is proposed. This method does not rely on additional skeleton key points or attitude estimation models. It generates global features and part features through a feature division model and maintains the content consistency of the parts across different images. At the same time, an adaptive scoring network is constructed to unite person parts, and the pedestrian descriptor is extracted by a combination of the global feature and the united parts. Extensive experiments are conducted on three widely used benchmarks including Market1501, CUHK03 and DukeMTMC-reID, and results demonstrate that the proposed model achieves a significant performance against a number of state-of-the-arts.

KEYWORDS: Person re-identification; Deep learning; Attention mechanism; Global feature; Part feature.

目录

摘要	III
ABSTRACT	IV
1 引言	1
1.1 研究背景	1
1.2 研究目的与意义	2
1.3 本文研究内容	3
1.4 本文组织结构	4
2 国内外研究现状	6
2.1 基于传统方法的行人重识别算法	8
2.2 基于深度学习的行人重识别算法	9
2.3 本章小结	11
3 基于注意力机制的多任务优化学习模型	13
3.1 注意力机制模型	13
3.2 卷积神经网络	14
3.2.1 残差网络	15
3.2.2 孪生网络	19
3.3 模型设计	21
3.3.1 基于注意力的多任务网络模型	21
3.3.2 分类任务学习	23
3.3.3 验证任务学习	24
3.4 实验结果及分析	25
3.4.1 数据准备	25
3.4.2 实验衡量指标	26
3.4.3 模型训练和测试	26
3.4.4 实验结果及分析	28
3.5 本章小结	32
4 基于多特征融合的行人重识别网络模型	33
4.1 部位特征提取方法	33
4.2 空间变换网络	35

4.3 多特征融合网络模型 39

 4.3.1 全局与部位特征提取方法 40

 4.3.2 特征融合方法 42

4.4 实验结果及分析 44

 4.4.1 数据准备及实验衡量指标 44

 4.4.2 模型训练和测试 45

 4.4.3 实验结果及分析 46

4.5 本章小结 51

5 总结与展望 52

 5.1 工作总结 52

 5.2 工作展望 53

参考文献 54

作者简历及攻读硕士学位期间取得的研究成果 58

独创性声明 59

学位论文数据集 60

1 引言

1.1 研究背景

在信息飞速发展的当今时代,随着电子多媒体设备的普及和发展,大量需要处理的数据信息涌现出来,大数据与人工智能领域也随之迅速崛起,如何对海量数据进行处理和分析成为当前学术界与工业界共同致力的研究方向。

在人类的感知系统中,视觉信息大约占所获取的全部信息的 80%~85%,随着人工智能的兴起,计算机视觉成为一个极为重要的研究领域,一直以来备受学者们的关注。与国民日常生活密切相关的智能安防、无人超市、智能商业等得到广泛应用,在这些场景中,人类作为主体,分析其行为举止成为重点内容。然而由于摄像头获取的图像信息内容庞大,依靠人工做分析工作量繁重且费时费力,因此如何让机器对获取的大量行人图像进行处理,获取个体的信息并分析其行为举止成为研究的重点。

在面对街道、校园、超市等复杂多变的场景时,摄像头获取的图像分辨率较低,图像中的行人可能存在遮挡现象,而且不同的图像中行人之间可能存在视角和姿势变化,光照变化等问题,行人重识别的主要任务便是处理这些复杂场景中拍摄到的行人图像,给出一张来自某个摄像头的行人图像,在其他摄像头中找出与该图像属于同一个行人的图像。

相比于目标分类、目标检测任务来说,行人重识别^[1]属于计算机视觉中一个较新的研究方向,2006 年才将其作为一个独立的任务进行研究,传统的机器学习方法主要将研究重点集中在特征描述和距离度量两个方面,使用颜色直方图、方向梯度直方图(Histogram of Oriented Gradient, HOG)特征^[1]设计行人特征表示模型,手工设计特征的方法比较繁琐,而且需要大量的经验,效果较差。近几年深度学习的出现以及高性能机器的支撑将人工智能的发展推向了一个新阶段,越来越多的学者也开始使用深度学习进行行人重识别的研究,Zheng Z 等人^[3]使用卷积神经网络搭建模型自动提取行人表征,比传统方法性能得到很大的提升,Haiyu Zhao 等人^[4]使用姿态估计模型、骨架关键点等对行人进行部位特征的提取,2017 年 ICCV 上 Zheng Z 等人^[5]首次提出将 GAN 应用到行人重识别进行数据增强,这些深度学习方法采用端到端的方式学习提取行人特征,效率快,准确度高。然而由于图像反映的场景比较复杂,行人轮廓比较模糊,因此行人重识别仍然具有很大的发展空间,如何借助深度学习寻找一个合适的模型解决行人重识别问题仍是当前计算

机视觉领域的一个热点研究问题。

1.2 研究目的与意义

随着互联网时代的快速发展，智能安防、智能商业等人工智能领域迅速兴起，提取视频中获取的人类图像，对行人交互行为进行信息处理和分析成为智能视频领域关注的重点。在视频监控领域中，涉及到计算机视觉的三层任务：底层任务、中间层任务以及高层任务，如图 1-1 所示。在这三层任务中，行人重识别作为连接其他任务的桥梁，起着至关重要的作用。




图 1-1 视频监控领域三层任务

Figure 1-1 Three-layer Task in the Video Surveillance Field

对行人进行分析时，涉及到行人检测、数据关联、跨摄像头行人目标跟踪以及最终的动作识别任务等，在整个过程中，行人重识别是行人检测的后续操作，其作为跨摄像头行人目标跟踪中数据关联的重要解决方案，能够有效解决由于非刚性目标运动的不确定性导致的关联准确率低的问题。动作识别属于视频监控领域三层任务中的高层任务，是多目标跟踪之后需要解决的一个难题，对最终的行人分析结果起着决定性作用。对比行人重识别和动作识别，二者的数据集极为相似，均是从摄像头中获取的背景复杂、行人模糊的图像，从两个任务特征提取方式相似的角度出发，如果在行人重识别中能够获取到具有鲁棒性和泛化性的行人

特征,则可以将同样的模型应用到动作识别中,进而提高动作识别的准确率。因此本文对视频监控领域中获取的行人图像进行分析,得到行人重识别模型,其可以与跨摄像头多目标跟踪、动作识别等任务相结合,对公共安全和刑侦等有着非常重要的现实意义。

行人重识别是指在非重叠的相机视域下,找出所有视频序列中属于同一个体的所有图像。由于行人图像分辨率低,拍摄到的行人视角不同、姿态不同、存在遮挡,不同图像光线变化等问题的存在,给行人重识别任务的研究带来了巨大的挑战。首先,由于拍摄到的行人比较模糊,面部特征无法获取,因此无法利用人脸识别等技术解决行人重识别问题,而面部之外的行人外观信息可能存在体型、服饰极其相似的情况,这给行人重识别的准确度带来了极大的挑战。其次,由于行人图像来自于多个不同的摄像头,所以可能存在属于同一个体的图像外型差距较大,而不同个体的图像外形相似的情况。此外,拍摄的光线不同,拍摄场景复杂多变,行人流量大,遮挡等问题的出现都加剧了行人重识别任务的挑战,因此,目前行人重识别的研究直接应用到实际场景中仍然具有一定的难度。

在视频监控领域中,由于行人图像自身存在的一些难点问题,传统的机器学习模型处理行人重识别存在工作量大,准确率较低的问题,而深度学习的应用使得行人重识别的准确率大幅度提高。因此,本文提出了基于深度学习的行人重识别方法和模型,旨在使用端到端的卷积神经网络模型提取具有鲁棒性的行人特征表示方法,提高行人重识别的准确率。

1.3 本文研究内容

本文通过对传统机器学习和深度学习算法进行学习和实践,并在对现有的行人重识别算法进行研究的基础上,分析行人重识别任务本身存在的问题以及现有模型存在的缺点,针对这些问题和缺点,基于卷积神经网络构建两种行人重识别模型,论文主要工作及创新点如下:

(1) 提出一种基于注意力机制的多任务优化学习算法。该算法主要提取行人含有注意力的全局特征,同时使用多任务损失函数调整特征空间中不同行人特征之间的距离。该模型创新点如下:

- 传统的行人重识别方法直接提取全局特征,无法反映出图像特征中的侧重点,进而难以获得较好的行人区分度的问题,故本文提出了基于注意力机制的学习算法。基于注意力机制的行人重识别模型以提取有效的行人特征作为主要任务,通过在网络中加入注意力机制强调有用的特征而抑制作用较小的特征。与传统的基于深度学习的行人重识别方法相比较,本文

的算法创新性地将行人图像特征使用注意力机制进行权重估计，并将权重赋给网络提取的全局特征，从而提高行人准确率。

- 为了提高模型的泛化能力，提出一个新的多任务损失函数进行模型的训练。该多任务损失函数由分类损失函数和验证损失函数两部分构成，作用在同时输入两张不同行人图像的结构相同、参数共享的孪生网络中，在对每个行人个体分类的同时判断输入的两张图像是否属于同一个体，并且进一步考虑到在特征空间中拉近特征与其所对应的类中心的距离。

(2) 提出一种多特征融合的行人表达方法，该方法不依赖于额外的骨架关键点或者姿态估计模型，自动生成全局特征和部位特征并保持不同图片行人部位的内容一致性，同时构建一个自适应评分网络对部位特征的重要性进行评估。该模型创新点如下：

- 由于行人图像中每个人的位置不同，导致同一水平位置下获取的行人部位存在偏差，因此提出一个特征变换网络对提取到的行人底层特征进行对齐，然后进行深层特征的提取和水平划分获得部位特征。与传统的方法相比，该方法不依赖于额外的模型，训练成本小，直接通过一个特征变换网络自动对行人位置进行对齐，进而保持不同图片的内容一致性。
- 对于不同的行人图像，划分的各个部位重要程度不同。本文提出一个自适应评分网络对提取到的各个部位特征进行重要性评估，并将计算得到的权值赋予部位特征，最后将带有权值的部位特征与全局特征进行融合作为最终的行人特征。

(3) 针对提出基于注意力机制的多任务优化学习和多特征融合的行人表达方法。论文以 Market1501^[6]，DukeMTMC-reID^[5,7]和 CUHK03^[8]作为行人重识别的实验数据集，从 CMC、mAP 评估指标和各个组件性能方面进行对比实验验证模型的有效性。

1.4 本文组织结构

论文共由五章组成，各部分内容如下：

第一章：引言，本章主要介绍论文主题的研究背景与目的意义，分析行人重识别在视频监控领域的重要性以及存在的问题，从而引出本文的研究内容，并介绍主要创新点与工作。

第二章：国内外研究现状及相关工作，本章对行人重识别的国内外相关技术进行介绍，同时对这些技术方法进行研究和分析，总结了目前行人重识别算法的研究工作及存在的问题。

第三章：基于注意力机制的多任务优化学习模型，首先介绍了注意力机制及其在深度学习中的应用，并针对行人重识别任务提出了本文的基于注意力机制的行人全局特征，同时提出了新的网络架构，使用分类任务和验证任务对模型进行优化。本章通过实验和现有的相关技术方法进行了对比，分别在相同数据集下完成行人重识别任务以验证本文的基于注意力机制的多任务优化学习模型的有效性。

第四章：基于全局和部位的行人特征描述，本章主要介绍一种新的行人特征表达方法，首先介绍了现有技术中提取部位特征的方法以及空间变换网络的应用，通过分析现有方法存在的一些问题，提出一种分别提取全局特征与部位特征并进行融合的行人特征描述方法。通过实验对比，验证了本文行人特征描述方法的有效性并给出最终检测结果。

第五章：总结与展望。总结本文在行人重识别分析，算法和模型的构建以及实验过程中所做的工作与成果，并对未来行人重识别任务需要解决的问题以及更广阔的应用场景等进行展望。

2 国内外研究现状

随着视频监控、智能安全等领域的发展，行人重识别任务在计算机视觉中越来越受关注。行人重识别的目的是从图像数据库中找出所有与给定图像属于同一关注行人个体的图像，而图像库中的图像由应用在不同位置的摄像头所获取，而这些摄像头不存在重叠视域，如图 2-1 中摄像头 a 和摄像头 b 所示。行人重识别可以视为一个检索问题，将给定图像与数据库中的所有图像逐一对比，进行相似度排名后返回一个候选集，其中在候选集中排名越靠前表示与给定图像的相似度越大。




图 2-1 摄像头位置分布

Figure 2-1 Camera Position Distribution

行人重识别选取一张图像作为查询图像（query），所有待匹配的 N 张图像组成候选图像数据库（gallery），提取到的特征表示为 $\{g_i\}_{i=1}^N$ 。给定一张查询图像 q ，其所属的行人个体号可通过公式（2-1）获得：

$$i^* = \arg \max_{i \in 1, 2, \dots, N} \text{sim}(q, g_i) \tag{2-1}$$

其中， i^* 是查询图像 q 所属的行人个体号， $\text{sim}(\cdot)$ 是相似度度量函数

如图 2-2 所示，是行人重识别的检索结果，每行代表一个行人的查找结果，左侧为待查的行人图像（query），右侧为从候选集中选出来的与 query 最为相似的五张图像，其中蓝色框表示正确匹配的图像，红色表示匹配错误的图像。

相对于目标分类、目标检测而言，行人重识别是一个比较新的方向，其研究起始于二十世纪九十年代中期，2006 年才作为一个独立的任务^[9]进行研究。如图 2-3 所示，由于图像分辨率低，拍摄视角变化，光线变化，行人部位存在遮挡等不

同的内部和外部因素的影响^[10]，使得行人重识别成为计算机视觉领域最具挑战性的任务之一。因为行人重识别数据集的图像中存在大量行人背影和侧面，而且像素较低，因此无法使用相对成熟的人脸识别技术进行行人重识别任务；数据集中存在很多外形相似，衣着颜色相似的人，这种情况下易将其看成同一个体，另一方面由于不同摄像头拍摄的图像光线不同，因此只靠颜色直方图提取特征准确率较低。2014 年深度学习被广泛应用之前，行人重识别的研究主要集中在特征描述和距离度量两方面，通过手工的方法设计行人特征，过程繁琐且准确率低；2014 年之后，越来越多的学者开始使用深度学习进行行人重识别，效率和准确率有了很大的提升。下面将从传统方法和深度学习两种类型对目前的国内外行人重识别研究现状进行介绍和分析。




图 2-2 行人检索结果

Figure 2-2 Pedestrian Search Results



图 2-3 行人重识别数据集

Figure 2-3 Person Re-identification Data Set

2.1 基于传统方法的行人重识别算法

从公式 2-1 可以看出行人重识别任务由特征表示和距离度量两部分组成。

基于特征表示的方法重点在于设计鲁棒可靠的行人特征表示模型，使其能够区分不同的行人个体，在不受分辨率、视角和光线变化影响的同时能够较好地消除遮挡带来的困难。传统方法中使用最多的是颜色特征，而纹理特征使用相对较少。在颜色特征中，如颜色直方图赋予对称轴附近的像素更高的权重，得到多个颜色直方图。最大稳定极值区域（Maximally Stable Extremal Regions, MSCR）检测稳定的颜色区域并提取颜色、区域和矩形等特征。循环高结构化块（Loop High Structured Patch, RHSP）是一种纹理特征，用于提取循环出现的纹理特征。这些都是早期行人重识别中使用到的特征表示方法，近年来研究的手工设计特征的方法如 LOMO^[11]、SCNCD^[12]均是基于低级的颜色特征进行设计的。除此之外，还有一种被视为中级特征的基于属性的特征表示方法，即使用颜色和纹理特征训练属性分类器，然后提取中级特征。

由于摄像机分辨率不同，拍摄视角和尺度不同，拍摄的场景光照不同，行人的服饰和姿态存在变化以及行人部位存在遮挡等原因，导致使用传统的欧氏距离、巴氏距离等标准的距离度量方式来衡量行人相似度不能获得很好的重识别效果，因此，很多研究者将关注点放在度量学习的方法上。通过度量学习可以获得一个新的距离度量空间，在这个度量空间中，不同图像间的同一行人的特征距离小于不同行人的特征距离。2002 年，E. P. Xing 等人^[13]提出以马氏距离为基础的度量学习算法，通过学习距离尺度变换使得属于同一个体的行人图像之间的特征距离减小，而属于不同个体的行人图像特征距离增大。该算法根据提供的样本类别标签分成两类，一类为由相同标签的样本组成的正样本对，一类为不同标签组成的负

样本对, 将该两类数据作为约束训练得到一个马氏矩阵进行度量学习, 该算法开创了行人重识别中距离度量学习的先河。到目前为止, 在行人重识别研究中有一些基于传统方法的被广泛用于图像特征比较的度量学习算法, 如 LMNN 算法^[14]、LDML 算法^[15]、PRDC 算法^[16]、KISSME 算法^[17]、XQDA 算法^[11]等。

传统的特征表示和距离度量方法能够在一定程度上反映行人的关键特征, 对行人重识别问题的解决提供了有力支撑, 为后期基于深度学习的算法奠定了基础。但由于传统的方法手工设计特征, 过程比较繁琐而且需要具备一定的先验知识, 工作量比较大, 导致行人重识别效率较低。而且, 传统的方法主要考虑底层特征, 未考虑到与图像相关的语义内容, 即使底层特征相似, 但是图像中处于行走状态和站立状态的人可能属于两个不同的个体, 因此传统方法的准确率并不是很高。随着深度学习的发展, 研究者开始采用基于深度学习的方法进行行人重识别任务, 使用卷积神经网络自动提取行人的底层和高层特征, 准确率相比于传统方法有了很大的提升。

2.2 基于深度学习的行人重识别算法

2014 年以前, 行人重识别任务主要基于传统的方法进行, 然而随着时代的快速发展对行人重识别准确率有了更高的要求。2014 年随着深度学习的广泛应用, 研究者们开始尝试通过深度学习的方式进行行人重识别任务, 主要集中在特征表示、度量学习和数据增强这三个方面。

基于深度学习的特征表示方法已经成为行人重识别中最常用的方法, 这得益于卷积神经网络 (Convolutional neural network, CNN) 的快速发展。研究者们将行人重识别看作分类任务或者验证任务。分类任务旨在将行人的 ID 作为训练标签, 从而使训练得到的模型可以判断出行人图像所属的 ID。验证任务是指同时输入两张图像, 通过训练好的网络模型判断其是否属于同一个行人。卷积神经网络可以根据任务需要自动从行人图像中提取出表征特征用于后续的行人特征距离比较。Mengyue Geng 等人^[18]将行人重识别同时看作是分类任务和验证任务, 训练阶段输入若干对图像, 分类子网络对图像所属 ID 进行预测, 并根据分类误差损失调整网络参数; 验证子网络对提取到的两张图像的特征进行融合, 判断其是否属于同一个 ID。在测试阶段输入一张图像, 训练好的网络模型自动提取出该图像的特征用于行人重识别任务。Yutian Lin 等人^[19]额外标注了图像中行人的性别、头发、衣着等属性标签, 增加了模型的泛化性能。

近几年, 由于全局特征的研究遇到瓶颈, 越来越多的人开始研究行人的局部特征, 并通过实验证明了局部特征的有效性。Rahul Rama Varior 等人^[20]将行人图

像水平划分为若干份, 然后按顺序送入长短时记忆网络中提取局部特征。Liang Zheng 等人^[21]为了解决图像未对齐情况下水平划分失效的问题, 使用姿态估计模型估计出 14 个人体的关键点, 通过仿射变换使相同的关键点对齐。Haiyu Zhao 等人^[4]使用训练好的骨架关键点获取 7 个感兴趣区域, 这 7 个区域与原始图像共同输送到同一个网络中提取特征, 在不同尺度上进行特征联结得到最终的行人重识别特征。这些方法利用额外的姿态估计模型或者骨架关键点进行行人部位特征的提取, 以解决图像行人部位缺失, 背景杂乱等问题给部位特征提取带来的干扰, 但这种方法也存在一些问题, 首先训练一个达到实用程度的姿态估计模型或者骨架关键点需要标注大量的训练数据; 其次, 姿态估计和行人重识别两个不同任务上的数据集之间存在语义偏差, 会在一定程度上降低行人重识别任务的准确率。如何解决上述问题是现在研究者在行人重识别任务上重点关注的内容。

除了特征提取以外, 度量学习作为一种广泛应用于图像检索领域的方法, 在行人重识别中也得到了广泛地关注。与传统的方法相似, 基于深度学习的度量学习方法旨在通过学习网络模型, 使提取到的同一行人的不同图像特征相似度大于不同行人的不同图像。常用的度量学习损失方法有对比损失 (Contrastive loss)^[22]、三元组损失 (Triplet loss)^[23-25]、四元组损失 (Quadruplet loss)^[26]、难样本采样三元组损失 (Triplet hard loss with batch hard mining, TriHard loss)^[27]、边界挖掘损失 (Margin sample mining loss, MSML)^[28]。Xiao Q 等人^[28]对这几种常见的度量学习损失方法进行分析, 并在尽可能公平的实验条件下进行性能比较, 实验结果如表 2-1 所示。

数据集数据量少, 模型训练难度大是使用深度学习进行行人重识别任务时的一个难点问题。2017 年, Zheng Z 等人^[5]在 ICCV 上首次提出使用对抗生成网络增加数据量以提高行人重识别准确率。论文使用对抗生成网络生成行人图像, 并提出标签平滑的方法对生成图像赋标签。生成的图像作为训练数据加入到训练集中, 可以有效避免过拟合现象的产生。来自同一课题组的 Zhong Z 等人^[29]在生成行人图像数据的同时考虑到不同摄像头之间存在的偏差, 使用生成对抗网络将一个摄像头的图像迁移到另一个摄像头上。Wei L 等人^[30]考虑到数据集之间存在的偏差, 提出一种使用对抗生成网络将一个数据集的图像迁移到另一个数据集上, 提高了跨数据集行人重识别的准确率。

目前, 基于深度学习的行人重识别算法仍然存在一些问题, 传统 CNN 网络直接提取全局特征进行比较的方法, 没有反映出图像特征中的侧重注意点; 大多数模型主要使用某种单一的损失函数 (交叉熵、对比损失、三元组损失函数) 进行训练, 考虑角度不全面; 模型依赖于额外的骨架关键点或者姿态估计模型提取行人局部特征的方法, 需要收集足够多的数据训练模型等。本文基于对国内外研究

现状的分析，综合考虑目前仍存在的问题，提出两种从特征提取和损失函数角度进行研究的行人重识别模型，以提高其准确率。针对前两个问题，本文提出一种基于注意力机制的多任务优化学习模型，通过注意力机制反映图像中对重识别任务其主要作用的特征，并使用多任务损失函数对模型进行参数调整；针对第三个问题，提出一种基于多特征融合的行人重识别网络模型，该模型不依赖于额外的骨架关键点或姿态估计模型，通过一个特征变换网络对图像中的行人进行对齐操作，并使用水平切分方式获得行人部位特征，将部位特征与全局特征进行融合作为行人特征进行重识别任务。两种模型通过实验验证了其在行人重识别任务上的有效性。

表 2-1 度量学习损失方法性能比较

Table 2-1 Performance Comparison of Metric Learning Loss Methods

网络 模型	方法	Market1501			CUHK03		
		mAP	r=1	r=5	mAP	r=1	r=5
ResNet50	Cls	41.3	65.8	83.5	51.2	72.6	81.8
	Tri	54.8	75.9	89.6	73.0	92.0	96.0
	Quad	61.1	80.0	91.8	79.1	95.3	97.9
	TriHand	68.0	83.8	93.1	79.5	95.0	98.0
	MSML	69.6	85.2	93.7	84.0	96.7	98.2
Inception -v2	Cls	40.7	66.3	84.1	50.5	68.8	77.4
	Tri	57.9	78.3	91.8	76.9	93.7	97.2
	Quad	66.2	83.9	93.6	81.9	96.1	98.3
	TriHand	73.2	86.8	95.4	85.5	97.2	98.7
	MSML	73.4	87.7	95.2	86.3	97.5	98.7
Rsenet50 -X	Cls	46.5	70.8	87.0	57.2	77.7	85.6
	Tri	69.2	86.2	94.7	82.0	96.3	98.4
	Quad	64.8	83.3	93.8	80.7	94.9	97.9
	TriHand	71.6	86.9	94.7	82.8	96.1	98.1
	MSML	76.7	88.9	95.6	87.5	97.7	98.9

2.3 本章小结

本文主要讨论和分析了行人重识别的发展历程，对当前国内外对于行人重识别任务的研究现状进行技术研究分析，并结合本文所用的相关技术做了介绍。行人重识别相关技术主要分为两类：第一类是基于传统方法颜色直方图、HOG 特征

等进行行人特征的提取以及使用马氏距离等度量方式衡量图像之间的差异度；第二类是基于深度学习中的卷积神经网络自动提取行人特征以及设计对比损失、三元组损失等度量学习方式训练网络模型。相比于传统方法手工设计特征的繁琐，基于深度学习的方法可以让网络自动地学习提取有利于进行重识别任务的行人特征，更加省时省力，而且深度学习的方法准确率更高，对行人重识别有重要意义。

随着深度学习的发展和其所具有的优势，使用深度学习进行行人重识别已成为大势所趋。因此，本文将基于深度学习卷积神经网络结构，在训练过程中结合注意力机制提取行人特征，并使用多任务损失函数调整网络参数。本文还提出一种新的行人特征表示方法，使用仿射变换和水平划分获得部位特征，并根据每个部位特征的重要程度赋予权重，最后将部位特征与全局特征进行融合作为行人特征，以此提高行人重识别的准确度。

3 基于注意力机制的多任务优化学习模型

行人重识别是计算机视觉领域中最具挑战性的任务之一，其涉及行人外观，动作姿态，背景光照等因素的影响。由于摄像头的长距离部署以及后期图像的裁剪等操作，导致行人重识别数据集图像分辨率较低。本章提出一种新的注意力机制孪生网络用于行人重识别，使用多任务损失函数进行训练。注意力机制网络通过强调有用的特征和抑制作用不大的特征来提高网络的辨别能力。通过使用多任务损失函数可以拉近相同个体在特征空间的距离，扩大不同个体之间的距离。最后，通过实验证明该模型在行人重识别任务上的有效性。

3.1 注意力机制模型




图 3-1 注意力机制举例

Figure 3-1 An Example of Attention Mechanism

随着深度学习的兴起和发展，注意力模型在各个领域被广泛使用，由最初的自然语言处理，到计算机视觉、语音识别等领域，都能看到注意力模型的身影。注意力模型借鉴于人类视觉的选择性注意力机制，人类通过快速扫描整个图像，获取需要重点关注的目标区域，对这区域投入更多的注意力，以获取更多目标的细节信息，而抑制其他一些无用的信息。如图 3-1 所示，我们在对一张图像中的动物进行分类时，会更加关注具有识别度的特定区域，如蓝色区域中狗的耳朵，然后移动到红色区域中的另一只耳朵、眼睛、鼻子等，最后对整张图像的信息进行推断，判断该动物为一只狗，但是像穿的毛衣、披的毯子这些信息对解析狗的特

征信息帮助不大,无法只根据这些信息判断图像中的动物是狗。

神经网络在进行计算机视觉任务时,需要通过大量的数据训练一个网络模型,比如一个神经网络如果见过大量的手写数字的图像,那么该网络便可以识别出一张新图像中含有的手写数字。但是这种情况下训练的神经网络对图像中的所有特征等价处理,虽然能够学习到图像的特征进行分类,但与人类的视觉注意力机制不同,在神经网络里对所有的特征“一视同仁”,不会过多关注某一个区域。对于人类来说,我们的注意力往往集中在这张图像的某一个区域,而其他区域的信息会被弱化,因此计算机视觉中提出注意力机制,旨在让网络模型自主学会注意力,能够关注重点信息而抑制无关信息,从而降低无关信息对视觉任务的影响。

最早期的注意力机制研究是从大脑成像机制的角度进行分析,采用一种 winner-take-all^[31]的机制来研究如何对注意力进行建模。随着深度学习的发展,越来越多的人开始将研究重点放在深度学习与视觉注意力机制结合上,主要思想是生成掩码表示注意力机制,即通过学习训练,让网络学习一层新的权重,将图像数据中关键的特征标识出来。这种思想形成两种不同类型的注意力机制:软注意力和强注意力。软注意力更加关注特征的区域^[32]或者通道^[33],该注意力是可微的,因此可以通过神经网络学习生成。强注意力^[3]关注于图像上的每一个点,是一个随机的预测过程,认为每个点都可能延伸出注意力。强注意力是一个不可微的注意力,往往需要借助于增强学习来实现。

本章提出一个基于注意力机制的多任务优化学习模型用于进行行人重识别任务,在基础网络中加入软注意力机制,让网络自主地学习通道域上的注意力机制。从基本的信号变换的角度理解,在信号系统分析中任何一个信号都可以作为正弦波的线性组合,经过时频变换(一般使用傅里叶变换,也是卷积变换)之后,时域上连续的正弦波信号就可以用一个频率信号数值代替。在卷积神经网络中,每一张图像由(R, G, B)三通道表示,每个通道经过不同的卷积核后会生成新的信号。每个通道的特征其实就相当于图像在不同卷积核上的分量,而这些分量对于关键信息的贡献度大小不同,通过注意力机制给每个通道上的信号增加一个权重用来表示该通道与关键信息的相关度,权重越大,表示相关度越高。

3.2 卷积神经网络

2006年, Hinton 提出深度学习概念,基本思想是通过构建多层的网络模型对输入目标进行表示,获得目标额高层次特征作为数据的抽象语义信息,以获得具有鲁棒性的目标特征。随着大规模数据的出现以及计算机硬件的飞速发展,尤其是 GPU 的出现,使得深度学习飞速发展。卷积神经网络是深度学习中一种典型的

网络结构，其包括三个关键的操作：局部感受野、权值共享和池化层，通过这三个操作有效地减少了网络中的参数个数，缓解模型过拟合的问题。随着卷积神经网络的受关注度逐渐增高，不断涌现出新的网络结构，从最简单的 LeNet5 到 AlexNet、VGG 网络，再到现在关注度极高的残差网络 ResNet，网络在层数上变得越来越“深”，其性能也越来越高。本文将采用卷积神经网络中的残差网络 ResNet 作为基础网络，搭建一个孪生网络结构进行行人重识别任务，本节会对所用到的网络模型进行说明，同时对孪生网络这一深度学习结构进行介绍。

3.2.1 残差网络

深度学习一个显著特点就是“深”，通过较深层次的网络可以在图像识别、语音识别等任务中实现非常高的准确率。一般情况下，深层网络比浅层网络效果好，如果需要进一步提高模型的准确率，可以将网络层级设计得深一些。但是在实验中，如图 3-2 与 3-3 所示，红色和黄色曲线分别表示 56 层的网络和 20 层的网络在 CIFAR-10 数据集上训练和测试的准确率，发现当网络层级增加到一定数目时，训练和测试精度会迅速下降。这是因为神经网络在反向传播时要不断地传播梯度，随着网络层数的加深，在传播过程中可能会导致梯度逐渐消失，导致无法对前面网络层的参数进行调整。




图 3-2 训练错误率

Figure 3-2 Training Error




图 3-3 测试错误率

Figure 3-3 Test Error

为了在加深网络层数的情况下解决梯度消失问题，提升模型的准确度，何恺明等人^[36]提出残差网络模型 ResNet。通过这种残差网络结构，可以使网络层的深度增加，并且分类结果达到很高的准确率。其基本模块结构如图 3-4 所示，该结构参考高速网络（Highway Network）的跨层连接思想，将带有权值的残差项改用恒等映射代替。




图 3-4 残差网络基本模块结构图

Figure 3-4 Structure of the Basic Module of the ResNet




图 3-5 神经元计算

Figure 3-5 Neuron Calculation

假定残差网络基本模块的输入是 x ，通过“shortcut connections（捷径连接）”的方式，直接把输入 x 传到输出作为初始结果，输出结果为 $H(x)=F(x)+x$ ，当 $F(x)=0$ 时，那么 $H(x)=x$ ，即上面所提到的恒等映射。于是，ResNet 网络模型将学习目标改变目标值 $H(x)$ 和 x 的差值，也就是所谓的残差 $F(x) := H(x)-x$ ，因此，后面的训练目标就是要将残差结果逼近于 0，使到随着网络加深，准确率不下降。

如图 3-5 所示，假设该层只有权重 w ，没有偏差项 b 和激活函数，当随机初始化的权重接近 0 时，经过卷积计算后输出为[1.2 1.2]，比输入值[4 2]更接近于[0 0]。而且，使用 ReLU 层可以将负数激活为 0，从而过滤掉负数的线性变化。因此，残差网络中通过学习 $F(x)=0$ 更新冗余层的参数要比学习 $H(x) = x$ 速度快。通过学习 $F(x)=0$ 让网络恒等映射上一层的输入，使含有冗余层的网络效果与没有冗余层的网络效果相同，很大程度上解决了网络的退化问题。

由于参数初始化值一般接近于 0，当网络层数很“深”时，训练过程中很容易导致浅层网络的参数因为梯度消失而无法更新，如公式（3-1）为网络中的损失函数，公式（3-2）为对某个神经元节点求偏导。当网络足够深时，偏导求解结果如公式（3-3）所示，每一项求解偏导的值都很小，在连乘的情况下求得的结果非常小，相当于原地踏步。在残差网络中，通过添加残差快，偏导计算结果如公式（3-4），有效解决了神经元节点参数梯度消失的问题。

$$Loss = F(X_L, W_L, b_L)$$

(3-1)

$$\frac{\partial Loss}{\partial X_L} = \frac{\partial F(X_L, W_L, b_L)}{\partial X_L}$$

(3-2)

$$\frac{\partial Loss}{\partial X_1} = \frac{\partial F_N(X_{LN}, W_{LN}, b_{LN})}{\partial X_L} * \dots * \frac{\partial F_2(X_{L2}, W_{L2}, b_{L2})}{\partial X_1}$$

(3-3)

$$\frac{\partial X_L}{\partial X_I} = \frac{\partial X_I + F(X_I, W_I, b_I)}{\partial X_I} = 1 + \frac{\partial F(X_L, W_L, b_L)}{\partial X_L}$$

(3-4)

表 3-1 ResNet50 结构

Table 3-1 Structure of ResNet50

layer name	output size	ResNet50
conv1	112×112	7×7, 64, stride 2
		3×3 max pool, stride 2
conv2_x	56×56	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$
conv4_x	14×14	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 6$
conv5_x	7×7	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$
-	1x1	Average pool, 1000-d fc, softmax

这种残差跳跃式的结构，使某一网络层的输出可以直接跨过几层作为后面某一层的输入，而不再像传统神经网络第 n-1 层的输出只能传输给第 n 层，其意义在于将多层网络进行叠加，使得整个学习模型的错误率降低。这样卷积神经网络的层数可以超越之前的约束，达到几百层甚至几千层，为高级语义特征提取和分类提供了可行性。残差网络的提出在深度学习中占据了极为重要的地位，其允许逐层深入地表征更多的模型；使得前馈/反向传播算法能够顺利进行，极大程度上使优化深层模型的操作变得简单；捷径连接不产生额外的参数，不会增加计算复杂度，整个网络仍为端到端的训练方式，为提高计算机视觉任务的准确率带来希望。因此，本文以 ResNet50 作为基础网络，其结构如表 3-1 所示，由 conv1、conv2_x、

conv3_x、conv4_x 和 conv5_x 五部分构成，对于一张输入图像，首先进行一个 $7 \times 7 \times 64$ 的卷积，然后经过 $3+4+6+3=16$ 个模块，每个模块有 3 个卷积层，所以共有 $16 \times 3=48$ 层，最后为一个全连接层 fc 用于分类，因此 ResNet50 共有 $1+48+1=50$ 层网络。本文在 ResNet50 基础网络上添加注意力机制模块，实验验证该方法在行人重识别任务上的有效性。

3.2.2 孪生网络

孪生网络（Siamese Network）于 2005 年由 Yann Lecun 提出^[34]，是一种相似性度量方法，可用于目标类别较多，但每个类别下样本数量较少的识别、分类等任务。传统的基于深度学习的分类方法需要知道每个样本的类别标签，当类别数比较多，但是每个类别下的样本数量较少时，这些分类方法效果就会大幅度下降。而孪生网络的特点就是不需要样本的类别标签，只需要提供其是否属于同一个目标即可。




图 3-6 孪生网络结构图

Figure 3-6 Structure of Siamese Network

孪生网络输入两张图像，主要思想是通过一个函数将输入图像映射到特征空间中，在特征空间中使用欧氏距离等距离度量方式进行相似度的计算。在训练阶段，通过最小化相同类别的样本损失函数值，最大化不同样本类别的损失函数值调整整个网络模型的参数，其结构如图 3-6 所示， X_1 、 X_2 为两张输入图像， $G_w(X)$ 为卷积神经网络的映射函数，其中两个卷积神经网络参数共享。图像在输入到卷积神经网络之后，通过前向传播获得对应的特征向量，两张图像的特征向量进行相似度计算之后输送到损失函数当中，根据损失函数值进行梯度反向传播，进而

实现对整个网络中参数的调整。孪生网络的应用场景较为广泛^[35]，可用于目标分类、目标检测、图像块匹配、目标跟踪等多项计算机视觉任务中，而且已有实验验证其对于不同任务的有效性。




图 3-7 行人重识别网络结构图

Figure 3-7 Person Re-identification Network Structure

在行人重识别任务中，通常使用孪生网络进行验证任务，即通过网络模型判断两张图像是否属于同一个行人个体，其实质上是一个二分类网络。图 3-7 为论文 [22] 中使用孪生网络构建的行人重识别模型结构图，输入一对图像 I_1 和 I_2 ，每对图像对应一个标签 y ， $y=1$ 表示两张图像为同一个行人（正样本对），反之则表示不属于同一个行人（负样本对）。图中 MG 表示一种特征融合方法，首先将两张输入图像的特征进行汇总，然后进行相似性度量并使用高斯函数进行激活，最后将经过 MG 处理之前的特征与处理后的特征进行相加，做 L_2 标准化处理。通过孪生网络对特征进行提取后计算其欧氏距离，如公式（3-5）所示，然后使用对比损失函数进行网络参数的调整，公式如（3-6）所示，其中 $(c)_+$ 表示 $\max(c,0)$ ， α 参数是根据实际情况给定的阈值。在训练过程中，当网络输入一对正样本， $d_{(I_a, I_b)}$ 会逐渐变小，即相同 ID 的行人图像逐渐在特征空间形成聚类。反之，当网络输入一对负样本时， $d_{(I_a, I_b)}$ 会逐渐变大直到超过设定的 α 。通过最小化 L_c ，可以使正样本对之间的距离逐渐变小，负样本对之间的距离逐渐变大，从而调整整个网络模型的参数以进行行人重识别任务。

$$d_{I_1, I_2} = \|f_{I_1} - f_{I_2}\|_2$$

(3-5)

$$L_c = yd_{I_a, I_b}^2 + (1 - y)(\alpha - d_{I_a, I_b})_+^2 \tag{3-6}$$

在本章的基于注意力机制的多任务优化学习模型中，使用孪生网络结构，每个网络分支由 ResNet50 残差网络和注意力模块构成，两个网络分支结构相同且参数共享。与目前现有的使用孪生网络进行行人重识别的多数方法不同，本文提出的模型使用分类任务和验证任务共同学习调整网络参数，其中的分类任务由交叉熵损失函数构成，验证任务由交叉熵损失函数和新提出的距离损失函数构成，并通过实验验证该模型在行人重识别任务上的有效性。

3.3 模型设计

3.3.1 基于注意力的多任务网络模型




图 3-8 基于注意力机制的多任务优化学习模型

Figure 3-8 Deep Attention Network with Multi-Loss

基于注意力机制的多任务优化学习模型是一个结合分类任务与验证任务的孪生网络，该网络模型具有两个参数共享的分支，每个分支接收一张输入图像。如图 3-8 所示，分别由 A 、 B 表示的两张输入图像构成的正样本对（两张图像属于同一行人个体）或负样本对（两张图像属于不同的行人个体）输送到两个分支网络，即注意力机制网络中用于提取行人特征 f_1 和 f_2 。提取到的两张图像的特征 f_1 和 f_2 （2048 维的向量）分别用于进行分类任务和验证任务，分类任务用于预测两张图像的 ID，验证任务用于计算两张图像的相似度。本模型在分类任务中使用交叉熵损失函数进行网络参数的调整，在验证任务中提出一个新的损失函数，并将交叉

熵损失函数与新提出的损失函数结合，在拉近特征空间中正样本对距离的同时拉大负样本对之间的距离，提高模型在行人重识别中准确度。




图 3-9 注意力机制网络

Figure 3-9 Deep Attention Network

在深度学习中，随着网络深度的增加，残差网络已经表现出很好的性能。本文使用 ResNet50^[36]作为基础网络，将通道注意力机制与其融合形成注意力机制网络。如图 3-9 所示，孪生网络中的一个注意力机制网络由五个阶段和一个全连接层构成。第一阶段的 Conv 模块直接采用 ResNet50 中的网络结构，由一个卷积层和一个最大池化层构成。第二阶段至第五阶段以相同的方法在 ResNet50 的基础上添加注意力模块，主要过程为将 ResNet50 中每个 Conv 模块和 ID 模块的输出作为注意力模块的输入，随后将注意力模块的输入与输出进行通道元素相乘的操作，将结果作为下一模块的输入。




图 3-10 注意力模块

Figure 3-10 Attention Module

如图 3-10 所示，本文使用一个含有 5 层的轻量级网络构成注意力模块。为了解决注意力机制网络中的过拟合问题，进一步增加网络的稀疏性，本文在第二阶段和第三阶段使用 Relu 层作为注意力模块的最后一层，第四阶段和第五阶段使用 softmax 代替注意力模块中最后一层的 Relu 层。注意力模块的输入为一个 3 维的张量 X ， w 、 h 和 c 分别表示 X 的宽、高和通道数，该模块的输出为一个大小为 $1 \times 1 \times c$ 的权重 Z 。

在注意力模块中，首先通过一个全局均值池化层执行下采样操作以生成一个对整张图像具有表现力的局部描述符。如公式 (3-7) 所示，下采样操作将分布在空间中的特征信息融合到通道中，以产生通道的统计信息。

$$S_c = \frac{1}{w \times h} \sum_{i=1}^w \sum_{j=1}^h X_c(i, j) \tag{3-7}$$

为了充分利用在下采样中得到的融合后的信息，并在此基础上捕捉通道的依赖关系，本文在下采样之后进行第二步上采样工作，如公式 (3-8) 所示，其中 W_1 、 W_2 表示两个卷积层的参数，分别为大小 $(c/r) \times c$ 和 $c \times (c/r)$ 的张量， r 是超参数，通过实验发现将其设置为 16 时效果最佳，故在本文设置为 16。

$$Z = \text{relu}(W_2 \times \text{relu}(W_1 S)) \tag{3-8}$$

如图 3-10 所示，经过下采样和上采样之后得到的张量 Z 与注意力模块的输入 F 进行张量相乘，得到的基于注意力机制的特征用于后续操作。两个注意力网络的输出一方面经过一个池化层、dropout 层、全连接层和 softmax 层用于分类任务。另一方面，使用本文提出的距离计算层计算所提取到的两张图像特征之间的距离，然后将计算结果输入到一个全连接层和 softmax 层中用于验证任务。

基于注意力机制的多任务优化学习模型是一个含有多模块的孪生网络，该网络通过注意力机制学习到有价值的行人特征，并且通过多任务学习可以显著提高行人重识别的准确性。

3.3.2 分类任务学习

如 3.3.1 中描述，基于注意力机制的多任务优化学习模型有两个分支，每次需要输入一对样本对模型进行训练。在行人重识别中，标签由数据集中行人的 ID 信息构成。这些 ID 信息一方面可以用来对输入的行人进行分类，另一方面可以确定两张输入图像是否属于同一个行人，即 ID 是否相同。

分类任务用于对输入的行人图像进行分类,即判断其行人 ID。本文在训练模型时同时给出两张图像和其所对应的 ID 信息作为图像标签,通过注意力网络提取到每张图像的行人特征之后,使用交叉熵损失函数调整优化模型参数,如公式(3-9)所示,其中 n 表示数据集中包含的行人个体数, y_i 表示真值,如果 i 是目标个体的 ID,则 $y_i=1$,否则 $y_i=0$ 。 y'_i 表示通过网络模型预测得到的结果。

$$L_{ide} = \sum_{i=1}^n -y_i \log(y'_i) \quad (3-9)$$

3.3.3 验证任务学习

在行人重识别中,验证任务可以看作是一个二分类任务。虽然交叉熵损失函数在验证任务中已经表现出很好的性能^[3],但是它并没有对正负样本对之间的距离进行约束。这可能导致在学习到的特征空间中属于同一个体的行人图像形成一个平均类内距离较大的聚类,而不同个体之间的距离不够远。在这种情况下,很容易导致测试的准确率降低。因此,本文在验证任务中提出一种新的损失函数,即距离损失函数,在交叉熵损失函数的基础上增加该损失函数以约束图像对之间的距离。验证任务损失函数如公式(3-10)所示,公式的第一项交叉熵损失函数用于表述分类的错误程度,第二项距离损失函数描绘了样本和其对应的类中心之间的距离,起到聚集相同个体而分离不同个体的作用,其梯度求解公式如公式(3-11)所示。

$$\begin{aligned} L_{ver} &= \lambda_1 L_{cross} + \lambda_2 L_{dis} \\ &= \lambda_1 \left(\sum_{j=1}^2 -p_j \log(p'_j) \right) + \lambda_2 \sum_{j=1}^2 (p_j \|x - c_j\|_2^2) \end{aligned} \quad (3-10)$$

公式(3-10)中 λ_1 , λ_2 是交叉熵损失和距离损失函数的权重系数, j 为验证任务的类别, $j=1$ 表示图片对属于不同个体, $j=0$ 表示图像对属于同一个体。 p_j 为输入的真值(如果输入的两张图像为同一个体,则 $p_1=0$, $p_2=1$;否则, $p_1=1$, $p_2=0$)。 p'_j 表示通过网络模型预测得到的结果。 x 是距离计算层的输出结果,大小为 $1 \times 1 \times 2048$ 。 c_j 是一个自适应变量,表示相同个体或不同个体对应的特征中心,其更新方式如公式(3-12)所示, m 表示批处理大小,当 $p_j=1$ 时, $\delta(p_j=1)=1$,否则 $\delta(p_j=1)=0$ 。

$$\frac{\partial L_{dis}}{\partial x} = \sum_{j=1}^2 p_j (x - c_j) \quad (3-11)$$

$$\Delta c_j = \frac{\sum_{k=1}^m \delta(p_j = 1) \cdot (c_j - x_k)}{1 + \sum_{k=1}^m \delta(p_j = 1)} \quad (3-12)$$

3.4 实验结果及分析

3.4.1 数据准备

本文实验中，主要使用了两个数据集 CUHK03^[8]和 Market1501^[6]，具体数据及组成见表 3-2。对于 CUHK03 数据集，我们采用 T. Xiao 等人^[16]使用的数据划分策略，Market1501 中的训练和测试图像通过 L. Zheng 等人^[6]提出的方法进行划分。对于所有的数据集，训练和测试的图像中不存在重叠的个体。两个数据集的概况如下：

(1) CUHK03：该数据集是第一个用于深度学习的规模较大的行人重识别数据集，采集于香港中文大学校园。数据集中包含来自 5 对摄像头下的 1467 个行人的 14096 张图像，其中每个行人只出现在两个摄像头视域下。该数据集提供两种类型的标签，手工标注的行人候选框和通过 DPM^[37]自动检测得到的行人候选框。

(2) Market1501：该数据集采集于清华大学校园，2015 年构建并公开。数据集中包含来自 6 个摄像头的 19732 张候选集图像和 12936 张训练图像。平均每个行人有 3.6 张从各个角度捕获到的图像，这些图像被分成两种类型，即手工标注的行人候选框和通过 DPM^[37]自动检测得到的行人候选框。与 CUHK03 数据集不同，Market1501 数据集中直接提供数据集和测试集，不需要使用者自己划分。

对于所有数据集图像，在输入网络模型进行训练之前需要进行预处理操作。首先将图像大小调整为 224×224，然后对图像进行标准化处理，将每张图像减去所有训练图像的均值。将所有图像进行随机排序，任意组成由同一/不同个体组成的正/负样本对。由于正样本较少，为了防止训练时出现过拟合现象，本文采用一种负样本和正样本比例初始化为 1:1，每一次迭代比例乘以 1.01 的策略逐渐递增，以减少预测偏差。

表 3-2 数据集介绍

Table 3-2 Introduction of Datasets

数据集	CUHK03	Market1501
行人个数	1467	1501
摄像头个数	2	6
图像总数	14097	32643
训练 ID 个数	1367	750
测试 ID 个数	100	751
检索图像数	100	3368
候选集图像数	100	19732

3.4.2 实验衡量指标

本文采用积累匹配特性（CMC）曲线和平均精度的均值（mAP）作为评估行人重识别准确度的方式。在行人重识别中，检索图像需要和候选集中的行人图像进行距离比较，将候选集中的图像按照距离的远近由小到大进行排序，要查找的行人排序越靠前，则算法的效果越好。假设总共有 N 个行人，即共进行 N 次查询和排序，每次查询中目标行人的排序结果用 $r=(r_1,r_2,...,r_n)$ 表示，那么 CMC 曲线计算方法如公式（3-13）所示：

$$CMC(R)=\frac{1}{N}\sum_{i=1}^N\begin{cases}1 & r_i\leq R\\0 & r_i>R\end{cases}$$

(3-13)

L. Zheng 等人^[6]首次提出在行人重识别中使用 mAP 作为评估标准，在 CMC 曲线的基础上使用 mAP 可以更全面地比较算法的优缺点。目前，越来越多的学者开始结合 CMC 曲线和 mAP 作为行人重识别的评估标准，如 S-LSTM^[20]、G-SCNN^[22] 和 BOW^[6]等。

3.4.3 模型训练和测试

本文在训练过程中将最大迭代次数设为 80，批处理大小为 48。在实验中，使用在 Imagenet 上与训练之后的 ResNet50 网络作为基准网络，注意力模块中各层的

参数使用均值为 0，标准差为 0.01 的高斯分布进行初始化，使用 SGD 进行网络参数的更新。根据验证任务中交叉熵损失和距离损失计算结果值，将公式 (3-4) 中的参数 λ_1 和 λ_2 分别设置为 1 和 0.001。 λ_2 的数量级远远小于 λ_1 是因为 L_{dis} 要比 L_{cross} 大很多。模型的整个训练过程主要分为以下两个步骤：

- (1) 在前 20 次迭代过程中将注意力机制网络的学习率设为 0.1，后 60 次迭代学习率设为 0.01。使用公式 (3-9) 和公式 (3-10) 中的 L_{cross} 作为多任务学习中的损失函数进行模型参数优化。使用训练好的模型对 1000 个正负样本对进行测试，取其平均值作为公式 (3-10) 中 c_j 的初始值；
- (2) 前 20 次和后 60 次迭代的学习率分别改为 0.01 和 0.001。使用 (3-9) 和公式 (3-10) 对模型重新进行训练得到最终的模型，训练情况如图 3-11 所示。




图 3-11 训练过程图

Figure 3-11 Training Process Diagram

第一步训练过程为第二步使用 c_j 提供良好的初始值， c_j 是一个自适应变量，在

第二步中随着网络参数的变化其值也会不断变化，如公式（3-12）所示。如果去掉第一步过程随机初始化 c_j ，在初始化分布理想的效果下模型可能会达到和两步训练类似的效果。但如果初始化不理想，训练可能需要更多的迭代次数甚至导致模型不收敛。因此，本文使用两步训练的方式获取最终的行人重识别模型。

在测试阶段，因为基于注意力机制的多任务优化学习模型中两个分支参数共享，因此我们只使用一个分支进行特征提取。给定一张 224×224 大小的行人图像，通过网络的前向传播得到一个 2048 维的行人描述符。本文在测试时首先将候选集中的所有行人图像预处理为 224×224 大小，依次输入到网络模型中得到所有图像的 2048 维的行人描述符并进行线下保存。在评估阶段，给定一张测试图像，输入到网络模型中在线获取其行人描述符。将该测试图像的行人描述符与候选集中所有行人描述符进行欧式距离计算，按照计算结果从小到大进行排序获得最终结果。

3.4.4 实验结果及分析

表 3-3 CUHK03 实验评估 (Single-shot 设置)

Table 3-3 CUHK03 evaluation (Single-shot Setting)

方法	Rank1	Rank5	Rank10	mAP
KISSME ^[17]	11.7	33.3	48.0	-
XQDA ^[11]	46.3	78.9	88.6	-
DNS ^[38]	54.7	80.1	88.3	-
Deep Reid ^[39]	19.9	49.3	64.7	-
Siamese network ^[3]	83.4	97.1	98.7	86.4
Ours	85.5	97.6	98.8	88.0

CUHK03 数据集提供两种类型的标签，手工标注的行人候选框和通过 DPM 自动检测得到的行人候选框。为了更接近真实情况，本文使用自动检测得到的行人候选框评估模型效果，并且采用 single-shot（候选集中仅仅为每个行人目标提供一张图像用于检索）和 multi-shot（候选集中为每个行人目标提供多张图像用于检索）两种设置。在 single-shot 中随机选取来自 100 个行人的 100 张图像作为候选集，multi-shot 中将来自于其他摄像头的所有图像作为候选集。在 single-shot 设置下对本文提出的模型进行评估，并与现有的五种模型进行性能对比，结果如表 3-3 所示。从表中可以看出，本文模型在 CUHK03 数据集上达到了最好的性能，比排名第二、结构相似的孪生网络^[3]在 Rank1、Rank5、Rank10 和 mAP 四个指标上高了 2.1%，

0.5%，0.1%，1.6%。本文还对 multi-shot 设置下模型的效果进行了评估，结果如表 3-4 所示。虽然我们的模型低于最优的孪生网络模型^[3]0.1%在 Rank1 指标中，但是在 Rank5、Rank10 和 mAP 中达到 96.9%、98.9%、86.2%，均高于表中的其他模型，尤其是 Rank5 高于孪生网络 1.2%。

表 3-4 CUHK03 实验结果评估 (Multi-shot 设置)

Table 3-4 CUHK03 evaluation (Multi-shot Setting)

方法	Rank1	Rank5	Rank10	mAP
GOG ^[40]	65.5	88.4	93.7	-
DCNN+ ^[41]	44.9	76.0	83.5	-
S-LSTM ^[20]	57.3	80.1	88.3	46.3
G-SCNN ^[22]	68.1	88.1	94.6	58.8
JLML ^[42]	80.6	96.6	98.7	-
Siamese network ^[3]	88.3	95.7	97.8	85.0
Ours	88.2	96.9	98.9	86.2

本文在 Market1501 数据集上对模型进行进一步的评估，结果如表 3-5 所示。我们的网络模型表现出优于大多数方法的良好性能，就 Rank1 而言，比排名第二的 JLML^[42]在 single-query 中高 4.4%（89.5% vs. 85.1%），在 multi-query 中高 0.6%（90.3% vs. 89.7%）；而对于 mAP，比排名第二的 JLML^[42]在 single-query 中高 6.6%（72.1% vs. 65.5%），在 multi-query 中高 1.6%（76.1% vs. 74.5%）。同样，我们的模型在 CUHK03 数据集上性能也比 JLML 高很多，如表 3-4 所示，Rank1 比 JLML 高 7.6%，这些结果证明本文提出的模型在行人重识别任务中具有明显的优势。

除了在 CUHK03、Market1501 两个数据集上进行评估外，本文基于 Market1501 数据集进一步评估了各个组件对模型的影响。表 3-6 为有无注意力模块，是否使用多损失函数时模型的性能。其中（a）模型表示未使用注意力机制，验证任务中只使用交叉熵损失函数进行优化学习；（b）为使用注意力机制，但是验证任务只使用交叉熵损失函数训练得到的模型；（c）为未使用注意力机制，验证任务中使用交叉熵损失函数和距离损失函数联合训练得到的模型；（d）为既使用注意力机制，又使用交叉熵损失函数和距离损失函数联合训练得到的模型。从模型（c）、（d）中可以看出注意力模块对行人图像的匹配有显著影响，Rank1 可以提高 4.1%（single-shot）和 2.5%（multi-shot），mAP 可以提高 8.2%（single-shot）和 3.7%

(multi-shot), 通过实验说明了基于通道的注意力特征表示的重要性。此外, 本文通过对比不同的实验设置评估多任务损失函数中距离损失函数的重要性, 如表 3-6 所示, 实验结果表明本文中的多任务损失函数在有无注意力机制的情况下均可以提高行人的辨别能力。例如, 在同样都使用注意力模块的前提下, 使用距离损失函数的模型 Rank1 准确率提高了 3.8%(89.5% vs. 85.7%, single-shot)和 4.2%(90.3% vs. 86.1%, multi-shot), mAP 提高了 7.1%(72.1% vs. 65.0%, single-shot) 和 5.3%(76.1% vs. 70.8%, multi-shot)。实验结果证明多损失函数在联合学习的优化中起着至关重要的作用。

表 3-5 Market1501 实验评估

Table 3-5 Market1501 Evaluation

方法	Single-query		Multi-query	
	Rank1	mAP	Rank1	mAP
BOW ^[6]	34.4	14.1	42.6	19.5
XQDA ^[11]	43.8	22.2	54.1	28.4
SCS ^[43]	51.9	26.3	-	-
DNS ^[38]	61.0	35.6	71.6	46.0
CRAFT ^[44]	68.7	42.3	77.0	50.3
CAN ^[24]	60.3	35.9	72.1	47.9
G-SCNN ^[22]	65.9	39.6	76.0	48.5
MSCAN ^[45]	80.3	57.5	86.8	66.7
Siamese network ^[3]	79.5	59.9	85.8	70.3
JLML ^[42]	85.1	65.5	89.7	74.5
Ours	89.5	72.1	90.3	76.1

图 3-12 为在 (a) (b) (c) (d) 模型下行人图像的特征分布图。我们随机挑选 200 对测试样本, 所选取的特征来自于网络模型最后一个全连接层的输出结果, 大小为 $1 \times 1 \times 2$ 。其中绿色的点表示负样本对的特征, 红色点表示正样本对的特征, 从图 3-4 中可以观察到, 注意力机制和距离损失函数在特征空间中可以有效地拉近同一个体的距离而扩大不同个体的距离。

表 3-6 模型组件评估实验

Table 3-6 Components of Model Evaluation

模型	有无注意力	是否使用多损	Single-shot		Multi-shot	
	模块	失函数	Rank1	mAP	Rank1	mAP
(a)	无	否	79.5	59.9	85.5	70.3
(b)	有	否	85.7	65.0	86.1	70.8
(c)	无	是	85.4	63.9	87.8	72.4
(d)	有	是	89.5	72.1	90.3	76.1




图 3-12 行人特征分布图

Figure 3-12 Distribution of Pedestrian Feature

3.5 本章小结

本章首先介绍了注意力机制模型在计算机视觉中的应用，接着对卷积神经网络中的残差网络和孪生网络进行分析和总结。在模型设计阶段，详细介绍了由残差网络和注意力机制相结合构成的孪生网络模型，并对该模型的多任务优化学习方式进行了介绍，本章提出的基于注意力机制的多任务优化学习模型，通过注意力机制强调对行人重识别任务有用的通道特征而抑制作用不大的通道特征，同时使用提出的任务损失函数对网络模型参数进行优化。

在实验阶段，设计多组对比实验，结合目前现有的行人重识别方法，在CUHK03和Market1501两个标准数据集上进行统一测试，得出相应的评估指标结果，并通过对比得出本章网络模型相比于其他模型的有效性，本章还对模型的各个模块的重要性进行实验验证，通过实验数据说明注意力机制和多任务损失函数在行人重识别任务中具有重要作用。

4 基于多特征融合的行人重识别网络模型

随着深度学习的发展,越来越多的研究人员将卷积神经网络用于行人重识别任务,准确率比传统方法有很大的提升。在行人重识别中,学习有效的特征表示方法是至关重要的,然而早期使用深度学习提取全局特征的方法研究已经遇到瓶颈,它们的准确率低于使用部位特征进行研究的方法^[4,20,21,46]。本章提出一个多特征融合网络模型,该模型对行人特征表示方法进行优化,通过卷积神经网络自动地划分和整合行人特征而不依赖于额外的骨架关键点或者姿态估计模型,强调不同图像部位特征的内容一致性,同时学习同一张图像中各个部位不同的贡献程度。该网络包含一个特征划分模型(Feature Division Model, FDM)和一个自适应评分网络(Adaptive Scoring Network, ASN),通过特征划分网络获取全局和部位特征,并且保持不同图像同一水平位置下的内容一致性。自适应评分网络估计同一张图像中每个行人部位的重要程度,并将其赋予部位特征。本章通过设计对比实验验证该模型在行人重识别上的有效性。

4.1 部位特征提取方法

早期的行人重识别研究主要关注点在提取全局特征上,即使用整张图像得到一个特征向量进行行人图像的匹配。但随着研究的不断深入,学者们逐渐发现全局特征已经达到研究瓶颈,于是越来越多的人开始重视行人的局部特征,主要提取方法包括图像切块、利用骨架关键点定位以及姿态矫正等等。

图片切块是行人重识别中最早使用的局部特征提取方式^[20]。图片被水平分为若干份,因为水平方向划分更符合我们对人体识别的直观感受,所以行人重识别领域很少用到垂直方向切割。这种直接切块的方式缺点在于对图像对齐的要求比较高,如果两张图像水平方向没有对齐,如图 4-1 所示,那么很可能出现头和上身对比的现象,造成模型判断错误。为了解决图像没有对齐情况下水平划分导致模型准确率低的问题,一些论文使用预训练的人体姿态和骨架关键点模型的先验知识进行部位特征提取。例如, C.Su^[46]等人在提出的网络结构中更加注重人体部位信息,以减轻姿势变化引起的误差,从全局和部位特征中学习具有鲁棒性的行人特征。H. Zhao 等人^[4]利用人体的关键点来提取感兴趣的区域,然后融合全局特征和多尺度局部特征作为最终的行人描述符。论文^[47]提出了一种全局-局部对齐特征描述子(GLAD 模型: Global-Local-Alignment Descriptor)来解决行人姿态变化的问题,如图 4-2 所示,该模型根据提取的人体关键点把输入图像分为头部、上

身和下身三个部分，然后将整张图像和三个局部图像一起输入到一个参数共享 CNN 网络中，最后提取的特征融合了全局和局部的特征。在训练时，四张输入图像各自计算对应的损失，而不是将其融合成一个特征计算总损失值。这些方法依赖于额外的骨架关键点或姿势估计模型来解决图像没有对齐、部位缺失和背景杂乱等问题，这意味着需要大量标记的数据训练得到一个达到实用程度的姿态估计模型或骨架关键点，而且姿态估计模型数据集和行人重识别数据集之间存在语义划分层次的偏差，容易导致部位划分不准确。



图 4-1 图像未对齐情况下水平切分示例

Figure 4-1 Example of Horizontal Partition of Images without Alignment

为了解决依赖额外模型进行部位划分带来的问题，一些论文提出不借助于其它模型或者身体部位标签而进行部位特征提取的方法^[48,49]。H. Yao 等人^[48]设计一个部位损失网络（Part Loss Networks，PL-Net），通过部位损失函数使网络更加关注于关键部位并自动检测行人的身体部位。Y. Sun 等人^[49]提出一种自适应池化的方法重新分配各个经过均匀划分的身体部位。这些方法均受注意力机制的启发，通过设计不同的网络学习各个身体部位的掩码。与这些方法不同，本章使用一个特征变换网络对提取到的底层特征进行仿射变换，之后输入到网络中提取行人的深度特征并进行水平均匀划分获取部位特征。对得到的部位特征使用自适应评分网络估计各个部位的重要程度，最后将带有权重的部位特征与局部特征进行融合作为行人的特征进行匹配。




图 4-2 GLAD 模型

Figure 4-2 GLAD Model

4.2 空间变换网络

使用卷积神经网络进行分类时，通常需要考虑输入样本的空间不变性以提高分类的准确度。这些空间不变性的本质就是图像处理的经典方法，如图 4-3 所示，以行人作为目标，神经网络中的空间不变性即对目标进行缩放、平移、旋转等操作后，模型仍然可以对目标正确分类。空间变换网络^[32]的提出使网络模型在不需要标定关键点的情况下就可以对数据实现各种仿射变换（平移、缩放、旋转等几何变换）。空间变换网络的输入既可以是原始图像，也可以是卷积神经网络中某一层的特征图，其作用是将图像或者特征图进行空间变换，使其变成理想图像后放到网络中进行目标分类。

空间变换网络主要结构如图 4-4 所示，输入为 U ，输出为 V 。定位网络的输入是 U ，输出为参数 θ ，用于映射 U 和 V 之间的坐标关系。网络生成器的作用是根据变化参数 θ ，计算出 V 中每个坐标点在 U 中所对应的位置坐标；采样器根据网络生成器得到的 U 中的坐标对 V 进行填充，因为通过计算得到的 U 的坐标点可能是小数，因此需要双线性插值等方法来填充。空间变换网络的执行过程如图 4-5 所示，首先需要根据目标坐标和定位网络得到的参数，确定源坐标的位置，然后根据源坐标的位置提供源像素，通过插值操作将其对应复制到目标的回归网格中。




图 4-3 空间变换示意图

Figure 4-3 Schematic Diagram of Spatial Transformation




图 4-4 空间变换网络结构图

Figure 4-4 Structure of the Spatial Transformation Network




图 4-5 空间变换网络执行过程

Figure 4-5 Spatial Transformation Network Execution Process

空间变换网络既可以作为网络模型中的第一层，即输入为原始图像，也可以添加到网络模型中间的任意一个卷积层或者池化层的前面和后面。此外，也可将多个空间变换网络插入到网络模型中，图 4-6 为将多个空间变换网络插入到手写字体的网络模型中，该模型包含 3 个卷积层。STN1 为网络模型的第一层，直接作用于输入图像，STN2a 和 STN2b 作用于第一个卷积层，对其得到的特征进行空间变换，STN3 作用于第二个卷积层，对更深层的特征进行空间变换。空间变换网络不仅可以对全局特征进行变换，还可以自动提取局部特征并进行空间变换，如图 4-7 为实现两个手写数字相加的网络，在网络的第一层添加两个空间变换网络 STN1 和 STN2，这两个网络直接用于提取输入图像不同区域的两个局部特征并进行空间变换，将变换后的特征输入到后续网络中计算数字相加的结果。

空间变换网络具有模块化、可区分性和动态性三个属性。可以将空间变换网络插入到现有的任何网络中，且需要调整的幅度较小；空间变换网络支持整个现有网络端到端的训练，可使用反向传播算法；与池化层针对所有样本进行相同操作的过程不同，空间变换网络针对每个输入样本的特征映射执行动态的空间变换。由于空间变换网络的这些特点，其在分类和识别等计算机视觉任务中得到了广泛的关注，可有效地解决现实场景中图像中目标发生旋转、扭曲等情况时分类准确率较低的问题，从而实现在不同场景下对目标物体的分析。在行人重识别任务中，由于数据集图像来自于摄像头，拍摄的行人属于非刚性运动目标，因此行人图像经常存在背景嘈杂和行人部位缺失等问题，本章基于空间变换网络，提出一个特征变换模块，将其应用到整个网络框架中实现对不同图像中行人的对齐操作，进

而提高行人部位划分时的准确率。




图 4-6 手写字体网络模型

Figure 4-6 Hand-written Font Network Model




图 4-7 数字相加网络模型

Figure 4-7 Digital Addition Network Model

4.3 多特征融合网络模型




图 4-8 多特征融合网络模型

Figure 4-8 Multi-feature Fusion Network

针对行人重识别任务，目前常见的特征提取方法包括全局特征提取、部位特征提取和全局特征与部位特征融合。对于这三种方法，部位特征比全局特征更加注重细节信息，准确率更高；特征融合的方法同时兼顾全局特征和部位特征，考虑角度全面，行人特征更加鲁棒，辨别能力强。因此，本文提出一种对全局特征和部位特征进行融合的网络模型，与其它方法相比，本模型在考虑不同图像之间内容一致性的同时，对同一张图像中行人各个部位的重要性进行评估。图 4-8 为多特征融合网络模型的结构图，由特征划分模型（Feature Division Model，FDM）和自适应评分网络（Adaptive Scoring Network，ASN）两部分构成。前者包括底层特征提取模块，特征变换模块（Feature Transformation Network，FTN），深层特征提取模块和水平均匀划分模块（Horizontal Uniform Partition，HUP）四部分，将输入图像分割成具有内容一致性 4 个部位特征，同时提取行人的全局特征。后者对 4 个部位特征的重要性进行学习，并将权重赋给对应的部位特征。最终的行人描述符由带有权重的部位特征和全局特征融合而成。

在多特征融合网络模型中，将行人重识别作为一个分类任务，并且在训练时给定行人标签（即 ID 信息），使用交叉熵损失函数对其进行优化，如公式（4-1）

所示， n 表示数据集中行人个体数， y'_i 表示通过网络模型预测得到结果， y_i 为真值，如果 i 是目标个体的 ID，则 $y_i = 1$ ，否则 $y_i = 0$ 。

$$L_{loss} = \sum_{i=1}^n -y_i \log(y'_i)$$

(4-1)




图 4-9 模块效果可视化

Figure 4-9 Visualization of Each Module

图 4-9 对 FTN、HUP、ASN 模块的作用进行了可视化举例说明，每一行表示一个行人个体，通过图 4-9 可以观察到，即使输入图像在外观、姿态、相机视角、背景杂乱情况等方面存在差异，每个部位特征仍可以较好地保存下来。

4.3.1 全局与部位特征提取方法

如何在不依赖于额外的骨架关键点或姿态估计模型的前提下，提取有效的行人部位特征是一个难点问题。为了解决该问题，本文在多特征融合网络模型中设计一个特征划分模型 FDM，接下来本节将对该模型进行详细介绍。

FDM 由底层特征提取模块，特征变换模块 FTN，深层特征提取模块和水平均匀划分模块 HUP 四个模块构成，如图 4-10 所示。整个模型的基准网络是在 ImageNet^[50]上进行预训练后的 ResNet50 网络，将其最后一个全连接层去掉。ResNet50 包含五个模块，本文将前两个模块作为底层特征提取模块用于后续特征变换操作，后三个模块作为深层特征提取模块，提取的特征作为水平均匀划分模块的输入进行全局特征和部位特征的提取。




图 4-10 特征划分模型结构

Figure 4-10 Structure of Feature Division Model

特征划分模型中的特征变换网络（FTN）用于进行行人特征的仿射变换。如图 4-10 红色虚线框区域所示。给定一张大小为 $384\times192\times3$ 的行人图像，FTN 的输入为底层特征提取模块的输出，即经过 ResNet50 前两个模块之后得到的特征映射，大小为 $96\times48\times256$ 。FTN 是一个轻量级的网络，包括五个卷积模块，一个最大池化层和两个全连接层。通过 FTN 网络将输入转换为一个 6 维的变换参数 P_θ ，用于生成网格和进行线性采样，特征变换过程如公式（4-2）所示，其中 (x^s, y^s) 是底层特征提取模块（即图 4-6 中的 ResNet1、2）的输出所对应的坐标点， (x', y') 是经过 FTN 变换之后的特征所对应的坐标点。参数 $\theta_{11}, \theta_{12}, \theta_{21}, \theta_{22}$ 表示特征的缩放和旋转情况， θ_{13}, θ_{23} 反映特征的平移情况。

$$\begin{pmatrix} x^s \\ y^s \end{pmatrix} = P_\theta \begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} \tag{4-2}$$

FTN 的输出结果前向传播进入深层特征提取模块（即图 4-10 中的 ResNet1、ResNet2 和 ResNet3），得到一个大小为 $24 \times 12 \times 2048$ 的特征映射。然后将该特征映射传送到两个分支中，一个分支对其进行均值池化操作得到一个长度为 1×2048 的向量作为全局特征；另一个分支为水平均匀划分模块 HUP，该模块将特征映射水平均匀划分为 4 部分，对每一部分进行均值池化操作，获得 4 个大小为 1×2048 的部位特征。

4.3.2 特征融合方法



图 4-11 身体部位重要性举例

Figure 4-11 Examples of the Importance of Body Parts

在行人重识别中，判别不同的行人图像所属 ID 时各个部位的特征重要性存在差异。如图 4-11 所示，红色部分是区分两个不同行人的关键信息，蓝色部分是这些关键信息所在的水平位置。行人 1 与行人 2（行人 3 与行人 4）在穿戴上极为相似，但是从一些特定部位可以很容易地分辨出这两个行人，如发型、背包等信息。因此，在一张行人图像中，各个部位特征的重要性可能差异很大，在判断行人 1 和行人 2 所属的行人图像时，应该重点关注头发和鞋子所在的部位，而对于行人 3 和行人 4 来说，背包和裤子的重要性更大。




图 4-12 自适应评分网络结构

Figure 4-12 Structure of Adaptive Scoring Network

通过分析发现，在行人重识别中，对于不同的行人来说，他们的局部特征（发型、眼镜、衣服、背包等）的重要程度各不相同，本文提出一个自适应评分网络 ASN 以获得一个更优化的特征表示方法，其结构如图 4-12 所示。红色虚线框区域包含 4 个卷积层和 4 个 ReLU 层用来估计每个部位特征的重要性，它的输入是通过特征划分模型得到的 4 个部位特征，输出为各个部位特征所对应的权重 W ，大小为 4×1 ，计算过程如公式 (4-3) 所示， F_{part-i} 表示第 i 的部位的特征张量， $f_{w-i, b-i}$ 为第 i 个卷积操作，4 个卷积操作之间不共享参数，ReLU 表示 ReLU 层的操作。将学习到的权重与对应的部位特征相乘，然后与全局特征进行融合作为最终的行人描述符进行行人重识别任务，特征融合方式如公式 (4-4) 所示。 F_{part} 与 F_{global} 表示部位和全局特征， $\odot$ 表示权重 W 和 $F_{part}(4 \times 512)$ 的行向量之间元素相乘的操作。

$$W = \text{ReLU}(f_{w-i, b-i}(F_{part-i})) \tag{4-3}$$

$$F_{feature} = [W \odot F_{part}, F_{global}] \tag{4-4}$$

通过训练整个模型得到全局特征和局部特征，为了得到更加鲁棒、辨别能力强的描述符，这两种特征在多行人识别的统一框架进行融合。本模型通过底层特征提取模块、特征变换模块和深层特征提取模块提取全局特征，获得一个 2048 维的特征向量。同样，通过水平均匀划分模块和全连接层可以获得 4 个 512 维的部位特征向量。最后将全局特征和部位特征进行串联融合作为该行人的特征。

4.4 实验结果及分析

4.4.1 数据准备及实验衡量指标

表 4-1 数据集介绍

Table 4-1 Introduction of Datasets

数据集	CUHK03	Market1501	DukeMTMC-reID
行人个数	1467	1501	1404
摄像头个数	2	6	8
图像总数	14097	32643	36411
训练 ID 个数	767	750	702
测试 ID 个数	700	751	702
检索图像数	2100	3368	2228
候选集图像数	6028	19732	17661

在本章的实验中，主要使用了 CUHK03^[8]、Market1501^[6]和 DukeMTMC-reID^[5,7]，具体数据及组成见表 4-1。对于 Market1501 数据集，本章采用与 3.4 章中相同的数据划分方法。对于 CUHK03 数据集，本章采用一种新的更具挑战的数据划分策略^[51]，该策略将数据集分为包含 767 个行人的训练集和包含 700 个行人的测试集。DukeMTMC-reID 数据集中包含来自 8 个摄像头的 1404 个行人，共有 36411 张行人图像，该数据集的所有行人候选框均通过手工标注获得，本章采用 Z. Zheng 等人^[5]采用的策略对数据集进行划分和评估。

对于所有数据集图像，在输入网络模型进行训练之前需要进行预处理操作。首先将图像大小调整为 384×192，然后对图像进行标准化处理，将每张图像减去所有训练图像的均值。

在本章的实验中，采用与 3.4.2 相同的实验衡量指标对多特征融合网络模型进行评估。

4.4.2 模型训练和测试

多特征融合网络模型使用在 ImageNet 进行预训练后的 ResNet50 作为基础网络。训练时，基础网络中的各个网络层参数的学习率设为 0.01，而 FTN 模块和 ASN 模块中各网络层的学习率设为 0.1，每隔 30 次迭代学习率乘以 0.1。FTN 模块和 ASN 模块中网络层的参数使用均值为 0，标准差为 0.01 的高斯分布进行初始化。实验将训练的最大迭代次数设为 60，批处理大小为 32，采用小批量随机梯度下降的方法进行参数的更新，图 4-13 为本模型的训练过程图。




图 4-13 训练过程图

Figure 4-13 Training Process Diagram

在测试阶段，给定一张 384×192 的行人图像，通过多特征融合网络模型的前向传播获得 1 个 2048 维的全局特征和 4 个 512 维的部位特征，对全局特征和部位特征进行融合获得最终的行人描述符。在测试的评估阶段，将所有候选集图像依次输入网络模型中获取行人描述符并进行线下保存。给定一张测试图像，线上提取其行人描述符。将该测试图像的行人描述符与候选集中所有行人描述符进行欧式距离计算，按照计算结果从小到大进行排序获得最终结果。

4.4.3 实验结果及分析

表 4-2 CUHK03 实验评估(手工标注标签)

Table 4-2 CUHK03 Evaluation (Manually Labelled)

方法	Rank1	mAP
BoW+XQDA ^[6]	7.93	7.29
LOMO+XQDA ^[11]	14.8	13.6
ResNet+XQDA ^[51]	32.0	29.6
ResNet+XQDA+re-rank ^[51]	38.1	40.3
PAN ^[52]	36.9	35.0
PAN+re-rank ^[52]	43.9	45.8
HA-CNN ^[53]	44.4	41.0
Ours	57.7	57.3

表 4-3 CUHK03 实验评估(自动检测标签)

Table 4-3 CUHK03 Evaluation (Auto-Detected)

方法	Rank1	mAP
BoW+XQDA ^[6]	6.36	6.39
LOMO+XQDA ^[11]	12.8	11.5
ResNet+XQDA ^[51]	31.1	28.2
ResNet+XQDA+re-rank ^[51]	34.7	37.4
PAN ^[52]	36.3	34.0
MultiScale ^[54]	40.7	37.0
SVDnet ^[55]	41.5	37.3
HA-CNN ^[53]	41.7	38.6
PAN+re-rank ^[52]	41.9	43.8
Ours	55.6	52.9

CUHK03 数据集提供两种类型的标签,手工标注的行人候选框和通过 DPM 自动检测得到的行人候选框。本文分别在这两种标注类型中对多特征融合网络模型进行评估,实验采用一种新的数据划分策略^[51],将数据集分为包含 767 个行人的训练集和包含 700 个行人的测试集,手工标注和自动检测两种情况下的实验结果分别如表 4-2、4-3 所示。通过实验观察到多特征融合网络模型在两种不同的标签

下都达到最佳的准确度，优于表格中传统的算法和基于深度学习的算法，进一步证明了模型的鲁棒性。本模型在人工标注的标签上，Rank1 和 Map 比排名第二的 HA-CNN 算法高 13.3%，11.5%，在自动检测的标签上，比 PAN+re-rank 高 13.7%，9.1%。而且，多特征融合模型相比于其它算法在参数大小上更加轻量，易于部署和训练。

表 4-4 Market1501 实验评估
Table 4-4 Market1501 Evaluation

方法	Rank1	Rank5	Rank10	mAP
LOMO+XQDA ^[11]	43.79	-	-	22.22
BoW+Kissme ^[6]	44.42	63.90	72.18	20.76
WARCA ^[56]	45.16	68.12	76.00	-
KLFDA ^[57]	46.50	71.10	79.90	-
TMA ^[58]	47.92	-	-	22.31
LDNS ^[38]	55.43	-	-	29.87
HVIL ^[59]	78.00	-	-	-
PersonNet ^[60]	37.21	-	-	26.35
DGDropout ^[61]	59.53	-	-	31.94
Gate S-CNN ^[22]	65.88	-	-	39.55
LSTM S-CNN ^[20]	61.60	-	-	35.50
PIE ^[21]	79.33	90.76	94.41	55.95
Spindle ^[4]	76.90	91.50	94.60	-
PAR ^[62]	81.00	92.00	94.70	63.40
SVDnet ^[55]	82.30	92.30	95.20	62.10
PAN ^[52]	82.80	-	-	63.40
PDC ^[46]	84.40	92.70	94.90	63.40
JLML ^[42]	85.10	-	-	65.50
IDE+Camera+RE ^[29]	89.49	-	-	71.55
GLAD ^[47]	89.90	-	-	73.90
HA-CNN ^[53]	91.20	-	-	75.70
PCB ^[49]	92.30	97.20	98.20	77.40
Ours	92.99	98.06	98.72	78.62

本章在 Market1501 数据集上对模型进行评估,并与现有的 22 种方法进行比较,这 22 种方法分为两类:传统的行人重识别方法和基于深度学习的行人重识别方法,结果如表 4-4 所示。我们的网络模型表现出优于现有方法的良好性能,在 single-query 的设置下,模型在 Rank1、Rank5、Rank10 和 mAP 四项指标上达到 92.99%, 98.06%, 98.72%和 78.62%,比排名第二的 PCB 模型^[49]分别高 0.69%, 0.86%, 0.52% 和 1.22%。这是因为本章提出的多特征融合网络模型充分考虑在背景杂乱和行人身体部位缺失的情况下提取的部位特征的内容一致性,并且考虑到各个部位特征的重要程度。

表 4-5 DukeMTMC-reID 实验评估
Table 4-5 DukeMTMC-reID Evaluation

方法	Rank1	mAP
BoW+Kissme ^[6]	25.1	12.2
LOMO+XQDA ^[11]	30.8	17.0
ResNet50 ^[36]	65.2	45.0
ResNet50+LSRO ^[5]	67.7	47.1
APR ^[19]	70.7	51.9
JLML ^[42]	73.3	56.4
SVDnet-caffeNet ^[55]	76.6	45.8
SVDnet-ResNet50 ^[55]	76.7	56.8
IDE+Camera+RE ^[29]	78.3	57.6
HA-CNN ^[53]	80.5	63.8
PCB ^[49]	81.7	66.1
Ours	83.4	68.5

多特征融合网络模型进一步在 DukeMTMC-reID 数据集上进行评估,并与 11 种现有方法进行比较,包括传统的手工方法 BoW+Kissme^[6],LOMO+XQDA^[11]和深度学习方法 ResNet50^[36], ResNet50+LSRO^[5], APR^[19], JLML^[42], SVDnet-caffeNet^[55], SVDnet-ResNet50^[55], IDE+Camera+RE^[29], HA-CNN^[53]和 PCB^[49],如表 4-5 所示,本章提出的模型在 Rank1 和 mAP 两个指标上比排名第二的 PCB 模型高 1.7%和 2.4%。

除了在 CUHK03、Market1501、DukeMTMC-reID 三个数据集上进行评估外,本文基于 Market1501 数据集进一步评估了各个组件对模型的影响。图 4-14 为 FDM 模型重要性评估实验,可以观察到该模块对提高行人重识别性能具有很大的影响,

使用 FDM 模块可将 Rank1、Rank5、Rank10 和 mAP 四个指标在基础网络的基础上分别提高 5%、2%、1.5%、5.5%左右。在 FDM 模型中，我们提出 FTN 和 HUP 两个模块用于进行特征变化和部位划分，本文进一步对这两个模块进行实验性能评估，通过实验发现这两个模块的使用均可以提高整个模型在行人重识别中的准确率。此外，本章还针对行人部位的不同数目进行实验比较，如图 4-15 所示，不同颜色的折线表示不同的行人部位数。当行人部位的数目为 1 时，其相当于行人图像的全局特征，随着部位数目的增加准确率逐渐增高，4 个行人部位时准确率最高，当部位数目继续增加时准确率开始下降，因此从训练成本和性能的角度出发，本模型最终选取 4 个行人部位。




图 4-14 FDM 模型评估实验

Figure 4-14 FDM Model Evaluation




图 4-15 不同行人部位数目对比实验

Figure 4-15 Impacts of the Number of Parts Evaluation

表 4-6 模型与其他方法结合实验评估

Table 4-6 Evaluation on the Proposed Model with Other Methods

方法	Rank1	Rank5	Rank10	mAP
Ours（FDM+ASN）	92.99	98.06	98.72	78.62
Ours+GAN ^[29]	93.85	98.02	98.86	79.11
Ours+re-rank ^[51]	94.11	97.62	97.92	89.16

多特征融合模型是一个轻量级模型，并且具有训练简单和部署快速的优势，因此该模型可以在增加少量训练负担的情况下与其他方法进行结合。如表 4-8，通过实验验证将模型与预处理方法或者后处理方法进行结合，将进一步提升行人重识别的性能。在预处理方法中，本文使用 CycleGan^[29]模型生成具有其他摄像头风格的行人图像进行数据增强，新数据直接从原始图像中借用标签信息，将新样本与原始样本共同作为训练集进行模型训练。在后处理方法中，首先对通过模型获取的查询图像和候选集图像的特征进行欧氏距离计算，根据计算结果排序，然后按照重排序策略^[51]对结果进行重新调整。该策略使用 k-倒数编码方法并将欧氏距离与 Jaccard 距离进行组合作为最终的距离结果。如果候选集中的一张图像与查询

图像的 k 倒数最近邻类似, 则该候选集图像极有可能与查询图像属于同一个个体。从表 4-6 中可以观察到将模型与预处理方法结合后, 虽然 Rank5 略有下降, 但是 Rank1、Rank10 和 mAP 提高了 0.86%, 0.14%, 0.49%。在进行重排序之后, 尽管 Rank5 和 Rank10 下降了 0.44% 和 0.8%, 但是 Rank1 和 mAP 两个评估指标有较大的提高, 分别为 1.12% 和 10.54%。这是因为重排序方法使得相似图像的排序更加靠前, 而对于外观差距很大的图像, 则将其排序重新往后调整。

4.5 本章小结

本章首先介绍了涉及到的行人部位特征提取方法, 并对其各类方法的优缺点进行了介绍与分析, 接着对空间变换网络方法做了相关介绍。在模型设计阶段, 由于第三章提出的基于注意力机制的多任务优化学习模型只考虑到全局特征, 准确率的提升达到瓶颈, 因此本章提出的多特征融合网络模型同时提取全局特征和部位特征, 在部位特征提取之前使用特征变换网络对图像进行对齐, 一定程度上解决了行人图像背景杂乱和行人部位缺失导致部位特征内容不一致的问题, 并且参考注意力机制的使用在模型中估计部位特征中各部分的重要性, 在深度学习框架中进行模型训练。

在实验阶段, 设计多组对比实验, 结合目前现有的行人重识别方法, 在 CUHK03、Market1501 和 DukeMTMC-reID 三个标准数据集上进行统一测试, 得出相应的评估指标, 并经过对比得出本章多特征融合网络模型的有效性。同时对模型的各个模块的重要性和参数改变情况下准确率的变化进行实验验证。此外, 本章还将多特征融合模型与预处理方法 Gan 和后处理方法 re-rank 等进行结合, 通过实验发现本模型与其他方法的结合在训练负担增加较少的情况下可以有效地提高行人重识别准确率。通过以上实验结果的比对, 得出本章的多特征融合模型可以有效地提高行人重识别的准确率, 而且模型训练简单, 可以与其他方法直接结合使用。

5 总结与展望

随着人工智能的快速发展,智能视频监控、智能安保等计算机视觉领域已经成为与人类发展密切相关的内容,行人重识别作为其中的一项任务,起着至关重要的作用,它的性能直接影响着智能监控、智能安保的结果;另一方面,随着海量数据的涌现,深度学习成为解决人工智能中大数据的有效手段。因此,将深度学习应用在行人重识别中是本文研究的主要内容。

5.1 工作总结

本文深入讨论了行人重识别的研究现状与相关技术,并将传统的行人重识别方法与基于深度学习方法在特征提取方式和距离度量上进行了对比,分析了深度学习在处理行人重识别任务时的优势所在,并对现有的行人重识别方法存在的一些问题进行相关分析。在模型训练上,介绍了常用的参数更新方法,并采用随机梯度下降法对算法模型进行优化,论证了模型的有效性。现将本文的主要研究工作进行总结如下:

(1) 从行人重识别全局特征的提取入手,设计了一个基于注意力机制的孪生网络结构,每个网络分支以 ResNet50 作为基础网络,在其中加入注意力模块,重点强调对行人重识别有用的通道特征而抑制作用不大的通道特征,从而实现更精确的行人匹配。

(2) 在基于注意力机制的孪生网络的损失函数部分,提出了一个多任务优化学习方法。将行人重识别任务作为分类任务和验证任务联合优化学习网络参数。在分类任务中使用交叉熵损失函数进行参数调整,验证任务中对两张图像的特征进行欧氏距离计算,将计算结果输入到损失函数中。本文提出一个新的损失函数——距离损失函数,将其与交叉熵损失函数结合,共同调整网络参数。

(3) 提出一个多特征融合网络模型,将全局特征与部位特征进行融合作为行人的特征表示。在对部位特征进行划分之前,使用一个特征变换网络对提取到的底层行人特征进行对齐,使划分后的部位特征能够保持内容一致性。同时提出一个自适应评分网络,对各个部位特征的重要性进行权重估计,将带有权重的部位特征与全局特征进行融合作为行人的最终特征,用于进行行人匹配。

(4) 在实验上,充分利用现有的 CUHK03、Market1501 和 DukeMTMC-reID 三个标准数据集,分别在基于注意力机制的多任务优化学习模型和多特征融合网络模型上进行训练和测试,与现有方法在多个衡量指标上进行比对,同时对两个

模型的各个组件进行实验比较,得出模型在行人重识别任务上的有效性。

5.2 工作展望

尽管本文的基于注意力机制的多任务优化学习模型和多特征融合网络模型在行人重识别上有不错的性能,但还存在许多不足之处,这里提出几点可以进一步完善优化的地方:

(1) 本文提出两个关注点不同的网络模型进行行人重识别任务,未来考虑将两个模型进行融合,在多特征融合网络中加入注意力机制,使其进一步关注更加有用的行人特征,同时对网络优化方法进行改进,使其提取的特征更有利于进行行人匹配,提高行人重识别准确率。

(2) 行人重识别数据集由摄像头拍摄得到,图像存在分辨率低、模糊不清、行人被遮挡等问题,给提高准确率带来很大的挑战,未来考虑从图像超分辨率重构的角度出发,在提取行人图像特征之前使用稀疏编码、贝叶斯、金字塔、卷积神经网络等方法对行人图像进行重构操作,提高图像分辨率以便获得更多的行人信息用于后续重识别工作。对于图像中的遮挡问题,通过生成式对抗模型尝试恢复遮挡,并且通过生成式对抗模型进行数据增强。

(3) 有监督的深度学习在行人重识别任务上已经可以达到较高的准确率,但是模型训练期间需要大量标注 ID 信息的训练数据。不同数据集合之间风格差异较大,若是用一个数据集训练,在另一个数据集上进行测试,由于提取的特征子空间不同,导致准确率会大幅度下降。下一步将考虑使用迁移学习对图像风格转换,通过生成式对抗模型等改变原数据集风格,使用半监督方式对网络模型训练,进一步提升网络框架的性能。

参考文献

- [1] 张化祥, 刘丽. 行人重识别研究综述 [J]. 山东师范大学学报 (自然科学版), 2018, 33(04):379-387.
- [2] Juengling K, Bodensteiner C, Arens M. Person re-identification in multi-camera networks[C]// CVPR 2011 WORKSHOPS, 2011:55-61.
- [3] Zheng Z, Zheng L, Yang Y. A Discriminatively Learned CNN Embedding for Person Re-identification [J]. Acm Transactions on Multimedia Computing Communications & Applications, 2016, 14(1).
- [4] Zhao H, Tian M, Sun S, et al. Spindle Net: Person Re-identification with Human Body Region Guided Feature Decomposition and Fusion[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017:907-915.
- [5] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[C]//2017 IEEE International Conference on Computer Vision (ICCV), 2017:3774-3782.
- [6] Zheng L, Shen L, Tian L, et al. Scalable Person Re-identification: A Benchmark[C]// 2015 IEEE International Conference on Computer Vision (ICCV), 2015:1116-1124.
- [7] Ristani E, Solera F, Zou R, Cucchiara R., Tomasi C. Performance Measures and a Data Set for Multi-target, Multi-camera Tracking[EB/OL]. <https://arxiv.org/abs/1609.01775>, 2016.
- [8] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition, 2014:152-159.
- [9] GHEISSARI N, SEBASTIAN T B, HARTLEY R. Person re-identification using spatiotemporal appearance[C]//2006 IEEE Conference on Computer Vision and Pattern Recognition, 2006: 1528-1535.
- [10] 宋婉茹, 赵晴晴, 陈昌红, 干宗良, 刘峰. 行人重识别研究综述 [J]. 智能系统学报, 2017, 12(06):770-780.
- [11] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition, 2015:2197-206.
- [12] Yang Y, Yang J, Yan J, et al. Salient Color Names for Person Re-identification[C]// 2014 European Conference on Computer Vision (ECCV), 2014:536-551.
- [13] Xing E P, Jordan M I, Russell S J, et al. Distance metric learning with application to clustering with side-information[C]//Advances in neural information processing systems, 2003:521-528.
- [14] Weinberger K Q, Saul L K. Distance Metric Learning for Large Margin Nearest Neighbor Classification [J]. Journal of Machine Learning Research, 2009, 10(1):207-244.
- [15] Guillaumin M, Verbeek J, Schmid C. Is that you? Metric learning approaches for face identification[C]//2009 IEEE International Conference on Computer Vision. IEEE Computer Society, 2009:498-505.
- [16] Xiao T, Li H, Ouyang W, et al. Learning Deep Feature Representations with Domain Guided

- Dropout for Person Re-identification[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016:1249-1258.
- [17] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012:2288-2295.
- [18] Geng M, Wang Y, Xiang T, et al. Deep transfer learning for person re-identification [EB/OL]. <https://arxiv.org/abs/1611.05244>, 2016.
- [19] Lin Y, Zheng L, Zheng Z, et al. Improving person re-identification by attribute and identity learning [EB/OL]. <https://arxiv.org/abs/1703.07220>, 2017.
- [20] Varior R R, Shuai B, Lu J, et al. A siamese long short- term memory architecture for human re-identification[C]//2016 European Conference on Computer Vision, 2016:135-153.
- [21] Zheng L, Huang Y, Lu H, et al. Pose invariant embedding for deep person re-identification [EB/OL]. <https://arxiv.org/abs/1701.07732>, 2017.
- [22] Varior R R, Haloi M, Wang G. Gated siamese convolutional neural network architecture for human re-identification[C]//2016 European Conference on Computer Vision, 2016, pp.791-808.
- [23] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C].2015 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015, pp.815-823.
- [24] Liu H, Feng J, Qi M, et al. End-to-End Comparative Attention Networks for Person Re-identification [J]. IEEE Transactions on Image Processing, vol. 26, no. 7, pp. 3492-3506, July 2017.
- [25] Cheng D, Gong Y, Zhou S, et al. Nanning Zheng. Person re-identification by multichannel parts-based cnn with improved triplet loss function[C]//2016 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016:1335-1344.
- [26] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification [EB/OL]. <https://arxiv.org/abs/1704.01719>, 2017.
- [27] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification [EB/OL]. <https://arxiv.org/abs/1703.07737>, 2017.
- [28] Xiao Q, Luo H, Zhang C. Margin Sample Mining Loss: A Deep Learning Based Method for Person Re-identification [EB/OL]. <https://arxiv.org/abs/1710.00478>, 2017.
- [29] Zhong Z, Zheng L, Zheng Z, et al. Camera Style Adaptation for Person Re-identification [EB/OL]. <https://arxiv.org/abs/1711.10295>, 2017.
- [30] Wei L, Zhang S, Gao W, et al. Person Transfer GAN to Bridge Domain Gap for Person Re-Identification [EB/OL]. <https://arxiv.org/abs/1711.08565>, 2017.
- [31] Itti L, Koch C. Computational modelling of visual attention [J]. Nature Reviews Neuroscience, 2001, 2(3):194-203.
- [32] Jaderberg M, Simonyan K, Zisserman A. Spatial transformer networks[C]//Advances in neural information processing systems, 2015:2017-2025.
- [33] Hu J, Shen L, Albanie S, et al. Squeeze-and-excitation networks [EB/OL]. <https://arxiv.org/abs/1709.01507>, 2017.
- [34] Chopra S, Hadsell R, LeCun Y. Learning a similarity metric discriminatively, with application to face verification[C]// 2005 IEEE Conference on Computer Vision and Pattern Recognition,

2005:539-546.

[35] 沈雁, 王环, 戴瑜兴. 基于改进深度孪生网络的分类器及其应用[J]. 计算机工程与应用, 2018, v.54; No.905 (10):24-30.

[36] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016:770-778.

[37] Felzenszwalb P F, Mcallester D A, Ramanan D. A discriminatively trained, multi-scale, deformable part model[C]//2008 IEEE Conference on Computer Vision and Pattern Recognition, 2008:1-8.

[38] Zhang L, Xiang T, Gong S. Learning a discriminative null space for person re-identification [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016:1239-1248.

[39] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014:152-159.

[40] Matsukawa T, Okabe T, Suzuki E, et al. Hierarchical gaussian descriptor for person re-identification[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016:1363-1372.

[41] Ahmed E, Jones M, Marks T. An improved deep learning architecture for person re-identification[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015:3908-3916.

[42] Li W, Zhu X, Gong S. Person re-identification by deep joint learning of multi-loss classification[C]//IJCAI International Joint Conference on Artificial Intelligence, 2017:2194-2200.

[43] Chen D, Yuan Z, Chen B, et al. Similarity learning with spatial constraints for person re-identification[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016:1268-1277.

[44] Chen Y C, Zhu X, Zheng W S, et al. Person re-identification by camera correlation aware feature augmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 40, no. 2, pp. 392-408, 1 Feb. 2018.

[45] Li D, Chen X, Zhang Z, et al. Learning deep context-aware features over body and latent parts for person re-identification[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017:7398-7407.

[46] Su C, Li J, Zhang S, et al. Pose-driven deep convolutional model for person re-identification [C]//2017 IEEE International Conference on Computer Vision (ICCV), 2017:3980-3989.

[47] Wei L, Zhang S, Yao H, et al. Glad: Global-local-alignment descriptor for pedestrian retrieval[C]//MM 2017 Proceedings of the 2017 ACM Multimedia Conference, 2017:420-428.

[48] Yao H, Zhang S, Zhang Y, et al. Deep representation learning with part loss for person re-identification [J]. IEEE Transactions on Image Processing, vol. 28, no. 6, pp. 2860-2871, June 2019.

[49] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline) [EB/OL]. <https://arxiv.org/abs/1711.09349>, 2017.

[50] Deng J, Dong W, Socher R, et al. Imagenet: a large-scale hierarchical image database[C]// 2009 IEEE Conference on Computer Vision and Pattern Recognition, 2009:248-255.

[51] Zhong Z, Zheng L, Cao D, et al. Re-ranking person re-identification with k-reciprocal

- encoding[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017:3652-3661.
- [52] Zheng Z, Zheng L, Yang Y. Pedestrian Alignment Network for Large-scale Person Re-identification[EB/OL]. <https://arxiv.org/abs/1707.00408>, 2017.
- [53] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification [C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:2285-2294.
- [54] Chen Y, Zhu X, Gong S, et al. Person Re-Identification by Deep Learning Multi-Scale Representations[C]//2017 IEEE International Conference on Computer Vision Workshops (ICCVW), 2017:2590-2600.
- [55] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[C]//2017 IEEE International Conference on Computer Vision (ICCV), 2017:3820-3828.
- [56] Jose C, Fleuret F. Scalable metric learning via weighted approximate rank component analysis [EB/OL]. <https://arxiv.org/abs/1603.00370>, 2016.
- [57] Karanam S, Gou M, Wu Z. A systematic evaluation and benchmark for person re-identification: Features, metrics, and datasets [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 41, no. 3, pp. 523-536, 1 March 2019.
- [58] Martinel N, Das A, Micheloni C, et al. Temporal model adaptation for person re-identification [EB/OL]. <https://arxiv.org/abs/1607.07216>, 2016.
- [59] Wang H, Gong S, Zhu X, et al. Human-in-the-loop person re-identification [EB/OL]. <https://arxiv.org/abs/1612.01345>, 2016.
- [60] Wu L, Shen C, Hengel A V D. Hengel. Personnet: Person re-identification with deep convolutional neural networks [EB/OL]. <https://arxiv.org/abs/1601.07255>, 2016.
- [61] Xiao T, Li H, Ouyang W, et al. learning deep feature representations with domain guided dropout for person re-identification[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016:1249-1258.
- [62] Zhao L, Li X, Zhuang Y, et al. Deeply-learned part-aligned representations for person re-identification[C]//2017 IEEE International Conference on Computer Vision (ICCV), 2017:3239-3248.
- [63] Oreifej O, Mehran R, Shah M. Human identity recognition in aerial images[C]//2010 IEEE Conference on Computer Vision and Pattern Recognition, 2010:709-716.
- [64] Jüngerling K, Bodensteiner C, Arens M. Person re-identification in multi-camera networks[C]//2011 IEEE Computer Vision and Pattern Recognition Workshops, 2011:55-61.
- [65] 种衍杰, 方琰, 沙涛. 基于特征融合网络的行人重识别 [J]. 计算机系统应用, 2019, 28(01):127-133.
- [66] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification [C]//2013 IEEE Conference on Computer Vision and Pattern Recognition, 2013:3586-3593.
- [67] Matsukawa T, Suzuki E. Person re-identification using cnn features learned from combination of attributes[C]//Pattern Recognition (ICPR), 2016:2428-2433.
- [68] Zhao B, Wu X, Feng J, et al. Diversified visual attention networks for fine-grained object classification [J]. IEEE Transactions on Multimedia, vol. 19, no. 6, pp. 1245-1256, June 2017.

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：李芮

签字日期：2019年5月28日

学位论文数据集

表 1.1: 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
行人重识别；深度学习；注意力机制；全局特征；部位特征	公开			
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	工程硕士专业学位	硕士
论文题名*		并列题名*		论文语种*
基于部位匹配与注意力模型的行人重识别算法研究		无		中文
作者姓名*	李芮		学号*	17125208
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
工程领域*		研究方向*	学制*	学位授予年*
计算机技术		计算机视觉	2	2019 年
论文提交日期*	2019 年 5 月 30 日			
导师姓名*	滕竹		职称*	副教授
评阅人	答辩委员会主席*		答辩委员会成员	
	丁丁		林春雨、黎琳	
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	68			
共 33 项，其中带*为必填数据，为 21 项。				