

2017 届研究生硕士学位论文

分 类 号:

学校代码: 10269

密 级:

学 号: 51141201049



華東師範大學

East China Normal University

# 硕士学位论文

MASTER'S DISSERTATION

论文题目: 基于卷积神经网络的行人重识别算法

院 系: 计算机科学与软件工程学院

专 业: 计算机科学与技术

研 究 方 向: 计算机视觉

指 导 教 师: 续晋华 副教授

学位申请人: 刘娜

2017 年 4 月

2017 届研究生硕士学位论文

分类号: \_\_\_\_\_

学校代码: 10269

密 级: \_\_\_\_\_

学 号: 51141201049



# 華東師範大學

**East China Normal University**

**硕士学位论文**

**MASTER'S DISSERTATION**

## 论文题目: 基于卷积神经网络的行人 重识别算法

院 系: 计算机科学与技术系

专 业: 计算机科学与技术

研究方向: 计算机视觉

指导教师: 续晋华 副教授

学位申请人: 刘娜

2017 年 4 月

Thesis of Master's degree on 2017

School Code: 10269

NO.: 51141201049

# EAST CHINA NORMAL UNIVERSITY

## Person re-identification based on Convolutional Neural Networks

Department: Computer Science and Technology

Major: Computer Science and Technology

Research Area: Computer Vision

Advisor: A.Prof.Jinhua Xu

Mater Candidate: Na Liu

Fulfilled in April, 2017



刘娜硕士学位论文答辩委员会成员名单

| 姓名 | 职称  | 单位                   | 备注 |
|----|-----|----------------------|----|
| 吕岳 | 教授  | 计算机科学与软件工程学院计算机科学技术系 | 主席 |
| 兰曼 | 副教授 | 计算机科学与软件工程学院计算机科学技术系 |    |
| 文颖 | 副教授 | 计算机科学与软件工程学院计算机科学技术系 |    |

## 摘要

随着监控摄像头在各领域的大量应用,传统的人工监控方法无法应对由此产生的海量监控视频。行人重识别是指在多台摄像机监控下进行行人匹配,即给定一个行人目标,在多台不同位置的摄像机不同时刻拍摄的视频中找到该目标。行人重识别(person re-identification)技术是智能视频分析、视频监控、人机交互等诸多领域的核心技术,已经成为计算机视觉领域的研究热点。但是因为光照、视角、姿势、遮挡和分辨率等因素的影响,使得行人重识别技术存在很大的挑战性。行人重识别通常主要包含两个步骤,首先设计有效的描述行人的特征,然后通过度量学习算法进行相似性度量。传统的行人重识别方法依靠人工设计的特征,但由于同一个行人在不同图像中可能有很大差异,而不同的行人又可能看起来很相像,使得这些手工特征很难应用到复杂的现实环境中。深度学习目前已经成功地应用在计算机视觉的很多领域,如手写字符识别、目标检测、图像分类、人脸识别等,在行人重识别领域也有一定的研究。

本文采用深度学习方法对行人重识别进行研究,主要研究内容包括:

1、基于卷积神经网络中的分类模型的行人重识别研究。不同于常用的相似性度量中的对比损失和三重损失函数,我们用 SoftMax 损失训练网络。首先对 ImageNet 数据库上预训练好的 AlexNet 用行人数据库进行微调(Fine-Tuning),用该网络提取行人特征,并采用目前效果较好的度量学习方法进行识别。其次设计了一个行人分类专用的卷积神经网络,用于提取行人特征,然后用度量学习算法进行行人重识别。

2、提出了一种改进的 Siamese 结构的基于深度卷积神经网络的行人重识别模型。训练时结合了分类和相似性度量,从而增大类间距离,缩小类内距离,提取出行人的有效特征,然后再进一步用度量学习算法进行相似度量。

本文在三个公开的行人重识别数据集上进行实验,采用累积匹配特征(Cumulative Matching Characteristic, CMC)曲线对实验结果进行验证,与其他行人重识别算法进行对比试验,我们的模型优于大部分现有模型。

**关键词:** 行人重识别, 卷积神经网络, 深度学习, 度量学习, 相似度量

## ABSTRACT

Due to the rapid development of video surveillance, the massive video data has brought great challenges to the traditional artificial video analysis methods. Person re-identification (Re-ID) is to identify the same person's images coming from non-overlapping camera views. Images for re-identification are mainly captured by different cameras. Person re-identification has drawn intensive attention in the computer vision for a decade. It is a critical task in video analysis, surveillance, human-machine interaction and so on. However, it is still an unsolved problem due to the dramatic variations caused by illumination, view point, pose, occlusion and resolution. There are two main components in person re-identification, feature extraction and metric learning. The traditional person re-identification methods rely on the hand-crafted pedestrian features. However, since the same pedestrian may be very different in different images, and different pedestrians may look very similar, it is difficult to apply these manual features to the complicated real environment. Convolutional neural networks (CNNs) have achieved great success in many computer vision tasks, including image classification, object detection and face recognition. They are also applied to person re-identification. But the problem is still far away to be solved.

In this paper, CNNs are applied to the study of Person re-identification. The research contents include:

- 1、Person re-identification based on Classification model. Different from the commonly used contrastive loss and triplet loss for similarity measure, we train a CNN using SoftMax loss for person classification. Firstly, by fine-tuning the pre-trained AlexNet using Pedestrian dataset, it is used for feature extraction, replacing the hand-crafted features in traditional methods. Secondly, Design a specific CNN for person classification. Then extract convolutional features using the CNN for person Re-identification.

2、Design a model with improved Siamese structure for person re-identification based on CNNs. We design a CNN architecture and a loss function composed of SoftMax loss and contrastive loss for feature extraction, and then use metric learning algorithms for re-identification. Experiment results on two public datasets demonstrate the effectiveness of our model. The Rank1 index on VIPeR database and iLIDS dataset are 41.8%, and 54.3% respectively, outperforming most of existing models.

**KEY WORD:** person re-identification, convolutional neural networks, deep learning, metric learning, similarity match



# 目 录

|                                               |    |
|-----------------------------------------------|----|
| 第 1 章 绪 论.....                                | 1  |
| 1.1 研究背景及意义.....                              | 1  |
| 1.2 国内外研究现状.....                              | 2  |
| 1.2.1 特征提取.....                               | 2  |
| 1.2.2 度量学习.....                               | 4  |
| 1.3 本文研究内容.....                               | 5  |
| 1.4 论文组织结构.....                               | 5  |
| 第 2 章 本文相关的研究工作 .....                         | 7  |
| 2.1 卷积神经网络在行人重识别的应用.....                      | 7  |
| 2.1.1 Single image representation (SIR) ..... | 7  |
| 2.1.2 Cross image representation (CIR) .....  | 9  |
| 2.2 距离度量.....                                 | 11 |
| 2.2.1 传统的度量学习算法.....                          | 11 |
| 2.2.2 基于深度学习的度量学习算法.....                      | 13 |
| 2.3 公共数据库概述.....                              | 14 |
| 2.3.1 VIPeR 数据集.....                          | 14 |
| 2.3.2 iLIDS 数据集.....                          | 15 |
| 2.3.3 CUHK01 数据集 .....                        | 15 |
| 2.4 评估方案.....                                 | 16 |
| 2.5 本章小结.....                                 | 16 |
| 第 3 章 基于卷积神经网络的行人特征提取 .....                   | 17 |
| 3.1 基于 AlexNet 的行人特征提取.....                   | 18 |
| 3.1.1 AlexNet 的网络结构 .....                     | 18 |
| 3.1.2 AlexNet 的微调 .....                       | 22 |

|                                       |    |
|---------------------------------------|----|
| 3.1.3 实验分析.....                       | 24 |
| 3.1.4 小结.....                         | 25 |
| 3.2 行人专用的简单卷积神经网络模型.....              | 26 |
| 3.2.1 实验参数设置.....                     | 27 |
| 3.2.2 实验结果分析.....                     | 27 |
| 3.3 本章工作总结.....                       | 28 |
| 第 4 章 改进的孪生神经网络设计 .....               | 29 |
| 4.1 Siamese 网络 .....                  | 29 |
| 4.1.1 经典 Siamese 网络结构 .....           | 29 |
| 4.1.2 改进的 Siamese 网络结构 .....          | 31 |
| 4.1.3 卷积神经网络结构.....                   | 32 |
| 4.1.4 对比损失函数 (Contrastive loss) ..... | 33 |
| 4.1.5 改进的 Siamese 网络训练过程 .....        | 34 |
| 4.1.6 Caffe 下的网络模型训练.....             | 36 |
| 4.2 度量学习方法.....                       | 36 |
| 4.3 实验结果分析.....                       | 38 |
| 4.4 本章工作总结.....                       | 40 |
| 第 5 章 总结与展望 .....                     | 41 |
| 5.1 论文总结.....                         | 41 |
| 5.2 后续工作展望.....                       | 41 |
| 附录.....                               | 43 |
| 参考文献.....                             | 44 |
| 致谢.....                               | 51 |

## 第1章 绪 论

### 1.1 研究背景及意义

由于摄像机成本下降以及数据存储技术的不断提升,越来越多的道路、机场、火车站等行人密集的公共场合安装了大量的监控摄像头,形成了大型的分布式摄像网络。随着这种摄像网络的形成,相关部门可以及时监控各种公共安全事件的发生。当前人们对视频监控系统的应用还处于低级阶段,主要通过人工监控的方法寻找有效信息。由于分布式摄像网络的发展十分迅速,往往需要耗费大量的人力在海量视频中寻找到需要的信息,而且即使花费了很大的代价,也不能保证能准确的找到有效信息。因此,能够同时处理多个监控视频并准确的寻找出有效信息的视频分析算法就变得非常重要和有研究价值,成为了计算机视觉领域的研究重点。行人重识别算法正是为了解决这一问题。

行人重识别 (person re-identification)<sup>[1]</sup>是指在没有视角重叠的多台摄像机监控下对行人目标进行相似度匹配的过程,即给定一个行人目标,在多台不同位置的摄像机不同时刻拍摄的视频中找到该目标。随着监控摄像头在各领域的大量应用,行人重识别技术得到了广泛的关注,有着重要的研究价值。由于摄像头受到光照强弱、拍摄视角、行人姿态变化等因素的影响,使得即使是一台摄像机拍摄的同一个行人目标在不同时间也会有不小的变化,行人重识别技术依然面临着很大的挑战。

行人重识别主要有两个关键部分:首先,特征提取,即提取目标行人和候选行人的特征。然后,度量学习 (metric learning),即计算目标行人和候选行人的特征相似度,判断候选行人是否为要找的目标。其中,特征描述是距离度量的基础。传统的行人重识别算法需要人工提取行人特征,再选择一个度量学习的方法来进行相似度度量。由于监控系统的分辨率一般相对较低,因此无法直接得到人脸等有辨识度的特征。由于光照、视角等影响,同一个行人在不同摄像机中可能

有很大差异，而不同的行人又可能看起来很相像，使得这些手工特征很难应用到复杂的现实环境中。

深度学习是这几年来机器学习领域的热门方向，卷积神经网络<sup>[2]</sup> (Convolutional Neural Network, CNN)，是深度学习领域一种非常有代表性的模型。相对于传统的神经网络，卷积神经网络的识别效果有了很大的提升。卷积神经网络在处理图像时，不需要进行复杂的预处理操作，不需要手工设计特征，能在网络训练的过程中自动学习特征，泛化能力明显比传统方法要好很多。目前已经成功地应用在计算机视觉的很多领域，如手写字符识别、目标检测、图像分类、人脸识别等，在行人重识别领域也有一定的研究。本文的研究基于卷积神经网络在行人重识别领域的应用，提出了一种适用于行人重识别的深度学习模型。

## 1.2 国内外研究现状

最早关于行人重识别的研究是作为多摄像机跟踪问题的子项目提出的，在2006年，Gheissari<sup>[3]</sup>等人在计算机视觉国际顶级会议 CVPR 上第一次正式提出行人重识别概念这一概念。行人重识别领域第一个公开的数据库是 Gray 等人在2007年建立的 VIPeR<sup>[4]</sup>数据库，该数据库直到今天依然是非常具有挑战性的。行人重识别主要分为两个部分，行人特征的提取和以及对已有特征进行度量学习。因此，相关的研究也主要集中在这两个方面。下面我们将从这两方面介绍行人重识别领域的一些经典算法。

### 1.2.1 特征提取

在对行人的特征描述时，最理想的状态是得到的特征具有很强的区分效果，并且相对来说比较稳定。在深度学习出现之前，研究者通常使用人工设计的特征对行人目标进行描述。主要使用的特征有颜色特征（HSV，LAB 等颜色直方图）、形状特征（HOG）、纹理特征（LBP，Gabor）等。

在研究中发现，在监控视频中对行人特征进行描述时，最具有区分性的特征是颜色，因此很多研究者常常使用颜色直方图来描述目标行人。Gheissari<sup>[3]</sup>等人

提出一种时空分割方法来对行人图像进行分割,对每一个稳定的区域提取 H-S 直方图和边缘直方图作为行人的特征。Gray 和 Tao 等人提出了 ELF<sup>[5]</sup>算法,该算法将一副行人图像水平的划分成头、躯干和腿部三部分,使用了 8 个颜色通道 (RGB,HS 和 YCbCr) 以及 21 个亮度纹理通道,把这些局部特征串联为最终的特征。Bazzani 等人提出的局部特征累加对称驱动特征 (Symmetry-Driven Accumulation of Local Features, SDALF)<sup>[6]</sup>方法首先将人的前景从图像背景中分割出来,根据行人的对称性将人的前景划分为不同的图像块 (patch),并提取每个块的加权颜色直方图、最稳定色域和纹理信息对行人进行描述,通过累加的方法使得得到的特征更具有鲁棒性。B. Ma 等人提出的 LDFV (Local Descriptors encoded by Fisher Vectors)<sup>[7]</sup>算法构建了一种 BiCov 描述子表述行人目标。

Liao<sup>[8]</sup>等人提出了局部最大出现特征 (Local Maximal Occurrence Feature, LOMO),首先使用多尺度 Retinex 算法对图像进行预处理,然后将所有的图像分为 10\*10 的图像块,每个块提取 HSV 颜色直方图特征和 SILTP (Scale Invariant Local Ternary Pattern) 直方图,对每一行所有图像块进行最大池化并建立一个三尺度的金字塔模型。

Zhao<sup>[9]</sup>等人的系列文章中,将所有的图像分为 10\*10 的图像块,每个块在 32 维的 LAB 颜色空间和 128 维的 SIFT 特征,采用邻接约束搜索,找出最相似的图像。Li<sup>[10]</sup>等人从图像块中提取局部颜色描述符,并使用分层高斯模型将这些特征整合起来。Pedagadi<sup>[11]</sup>等人从 HSV 和 YUV 色彩空间提取颜色直方图,然后使用 PCA 降维。

除了直接使用色彩信息和纹理特性,还可以使用基于属性的特征对行人进行描述。Layne<sup>[12]</sup>等人在 VIPeR 数据库上采用服饰、发型等 15 种属性描述行人,然后使用马氏距离衡量两个样本间的相似性。Liu<sup>[13]</sup>等人使用带标签的属性去除了 LDA 模型 (latent Dirichlet allocation) 中的噪音,获得了改进的 LDA 模型来描述行人特征。Liu C<sup>[14]</sup>等人用将人体水平的分为 6 部分,并通过无监督学习给每个部分的特征分配不同的权重,得到更加显著的行人特征。

有关行人重识别的特征的详细介绍可参见综述文章<sup>[15, 16]</sup>。

### 1.2.2 度量学习

上面介绍了很多行人图像特征提取方法,因为高维视觉特性通常无法捕获样本的不变因素,因此在传统的行人重识别算法中,一个好的距离度量学习是其成功的关键。距离度量学习的目的是能够准确的度量图片间的相似性。对于一个好的度量学习方法,两个样本如果彼此相似,它们之间的距离应该越小越好;如果不相似,则它们之间的距离越大越好。

近几年,度量学习算法的发展很快,很多学者在传统的度量学习方法的基础上提出了更具有辨别性的算法。

早期最常用的度量学习算法是欧氏距离 (Euclidean distance),但是欧氏距离往往忽略了图像之间的本质信息,使得匹配结果较差。而马氏距离 (Mahalanobis distance) 是行人重识别领域最常用的一种度量学习算法,与欧氏距离不同,它利用数据的结构信息能更有效的度量图片之间的相似性,因此很多具有代表性的度量学习的算法都是在马氏距离的基础上提出的。比如本文用到的 KISSME<sup>[17]</sup> 算法; Weinberger 等人提出的最大边界邻近算法<sup>[18]</sup> (LMNN),但该方法容易产生过拟合现象,因此 Davis<sup>[19]</sup>等人在 LMNN 的基础上提出了信息理论度量学习 (ITML) 算法。ITML 算法能很好的满足给定的相似度约束,并保证学习得到的度量与最初的距离函数相近。

由于度量矩阵  $M$  往往需要大量的计算才能得到, Hirzer<sup>[20]</sup>等人提出通过适度的放宽正约束来获得一个足够接近度量矩阵  $M$  的矩阵。Chen<sup>[21]</sup>等人在马氏距离的基础上,增加了一个双线性相似的约束。Liao<sup>[22]</sup>等人提出使用一个半正定矩阵,并给正样本和负样本加上不同的权重进行相似度度量。

除了使用马氏距离进行度量学习,有些学者研究了基于判别子空间的度量学习算法。在其中,最具有代表性的是 Mignon<sup>[23]</sup>等人提出的成对约束成分分析 (PCCA),能够直接学习一个线性映射函数处理高维的数据,而不需要对数据进行降维处理。还有的学者利用线性判别分析 (FDA) 的思想,通过一个线性判别式区分正样本和负样本,如 Pedagadi 等人提出的局部线性判别分析<sup>[11]</sup> (LFDA); Xiong 等人又引入了核的概念,提出了核局部线性判别分析<sup>[24]</sup> (kLFDA),该方

法具有很好的识别效果。

除了上述的两种以外，有些学者将支持向量机（SVM）这一概念引入了度量学习中。Prosser<sup>[25]</sup>等人通过学习了一组用于排序的弱 RankSVMs，将其组合形成了一个很好的相似度排序算法。Liu<sup>[26]</sup>等人使用了一个结构化的 SVM 模型，在决策层比较不同的颜色特征进行度量学习。

有关度量学习算法的详细介绍可参见综述文章<sup>[15, 16]</sup>

### 1.3 本文研究内容

本文主要使用卷积神经网络对行人重识别方法进行了研究。主要工作如下：

①研究了经典网络模型 AlexNet 在行人重识别上的应用。使用行人重识别数据库的训练样本对 AlexNet 模型进行微调训练，并使用训练得到的模型对数据库中的测试样本进行特征提取。最后使用有效的度量学习方法对行人特征进行相似性度量。

②设计了一种结构简单的行人专用的卷积神经网络，用行人重识别数据库对该网络进行训练，然后用它提取行人特征。

③提出了一种改进的 Siamese 结构的模型，模型采用权值共享的卷积神经网络。我们在传统的孪生网络中增加了一个全连接层和 SoftMax 层，然后在损失函数中结合了 SoftMax 损失函数和对比损失函数（Contrastive loss）。

本文分别在两个公共数据库上做了广泛的实验，同时与目前已有的算法进行了比较。实验结果展示了模型的有效性。

### 1.4 论文组织结构

本文包含五个章节，内容安排如下：

第一章为绪论。首先介绍了行人重识别的背景和研究价值，然后对国内外的经典行人重识别算法进行了简单的描述，总结了本文的主要研究内容。

第二章介绍了本文的相关工作，包括深度学习在行人重识别领域的应用，常用的度量学习方法，本文用到的行人重识别数据库，以及算法的评估方案。

第三章介绍了基于卷积神经网络的行人特征提取方法。首先，在 Caffe 学习框架下，使用微调的方法对现有的 AlexNet 模型进行训练。使用微调训练获得的模型进行特征提取，度量学习算法相结合进行相似性度量。其次，设计了一个专用于行人的结构更为简单的卷积神经网络，用训练得到的模型进行特征提取。

第四章提出的一种改进的卷积神经网络模型，本章采用改进的 Siamese 网络，设计了更适用于行人重识别的卷积神经网络模型，损失函数结合了分类模型的 SoftMax 损失和匹配模型的对比损失，在训练样本有限的情况下也取得了很好的识别效果。

第五章总结了全文的工作和创新点，并对后续的研究工作进行规划和展望。



## 第2章 本文相关的研究工作

### 2.1 卷积神经网络在行人重识别的应用

在计算机视觉领域，深度学习近年来得到了广泛深入的应用，目前已成功运用于图像分类、目标检测、人脸识别和姿态估计等领域。基于深度学习的行人重识别模型可以分为两类，一类是利用卷积神经网络进行特征提取，然后用度量学习算法进行识别。另一类是采用 Siamese 或者 triplet 结构，将特征提取和度量学习结合在一起训练。

从特征描述的角度来说，现有的基于深度学习的行人重识别模型可以分为两类：一类是对单一图像的特征描述（single-image representation, SIR），另一类是对两张图像的特征描述（cross-image representation, CIR）。我们将从这两方面对现有的深度学习算法进行简要的介绍。

#### 2.1.1 Single image representation (SIR)

SIR，是用 CNN 方法得到每幅行人图像的特征，然后使用度量学习判断两幅行人图像是否相似。常用的卷积神经网络结构有 Siamese network 和 Triplet network 两种。

Siamese network 通常由两个共享权重的对称的子网络构成，在最后一层计算两个子网络输出特征的相似度。常用的相似度计算方法有 L1 范式、L2 范式和 cosine。在<sup>[27]</sup>中，作者提出了一个典型的 Siamese 卷积神经网络（SCNN）。SCNN 将两张输入图像水平的划分成三个重叠的部分，分别经过两个卷积层和一个全连接层，获得将两张图片的特征向量，在最后一层相互融合并使用余弦距离计算两个特征向量的相似度。SCNN 结构框图如图 2.1 所示。它直接将图片的特征学习和度量学习放在一个卷积神经网络中得到两幅图片的相似度。




图 2.1 SCNN 网络结构<sup>[27]</sup>

Triplet network 由三个子网络构成，分别输入三张图像，把一张图像作为候选图像，剩下的两张图像，一张与候选图像为同一行人，作为正样本，另一张为不同行人，作为负样本。一个 Triplet network 的结构框图通常如图 2.2 所示。通过 Triplet 损失函数使得正样本的距离尽可能的近，负样本的距离尽可能的远。通常使用一个 triplet 损失函数实现这个过程。对于一组三元输入样本  $\{p_i, p_i^+, p_i^-\}$ ，triplet 损失函数定义如下<sup>[28]</sup>：

$$J=\sum_i \max \left(0, \eta+\left\|f\left(p_i\right)-f\left(p_i^{+}\right)\right\|^2-\left\|f\left(p_i\right)-f\left(p_i^{-}\right)\right\|^2\right)+\|W\|^2 \tag{2.1}$$

其中， $p_i$ 和 $p_i^{+}$ 是一对正样本， $p_i$ 和 $p_i^{-}$ 是一对负样本， $f\left(p_i\right)$ 是图片 $p_i$ 的特征， $\eta$ 表示正样本间的距离与负样本间的距离的最小的间隔， $\|W\|$ 是一个惩罚项。




图 2.2 Triplet 网络结构<sup>[28]</sup>

Ding<sup>[29]</sup>等人是最早将 triplet network 用于行人重识别领域的，以三张图片作为输入，经过一个结构简单的卷积神经网络，使用式（2.1）中的损失函数进行

相似度学习，最后使用欧氏距离进行相似度度量。

Cheng<sup>[30]</sup>等人在 Ding 的基础上设计了一个多通道的 triplet 网络，传统的 triplet 网络将整张图片作为一个三元组的输入，而 Cheng 等人除了输入整张图片以外，在经过第一个卷积层后，将每张图片水平地划分为 4 个身体部分，分别通过一个网络通道，并在 FC 层将 5 个通道的特征整合成一个整体，进行后续的相似度学习。除了改进了网络结构之外，Cheng 等人在 triplet 损失函数中加入了一个阈值  $\tau$ ，令正样本间的距离小于  $\tau$ ，进一步缩小了正样本间的距离。

<sup>[29, 30]</sup>在网络的学习中，都使用欧氏距离对行人特征进行相似度度量。但是由卷积神经网络学习到的行人特征往往比较复杂，无法很好地使用欧氏距离对得到的特征进行度量。因此，在<sup>[31]</sup>中，Wang 等人用马氏距离替代了<sup>[29]</sup>中使用的欧氏距离，使学习到的特征更具有判别性。Zhang 等人<sup>[32]</sup>融合了深度哈希算法，使用加权的汉明距离（hamming distance）描述一对图像间的距离。在实际实验中，Zhang 等人使用了类似于 tanh 函数的操作保证学习到的空间类似于汉明空间。

在上述的卷积神经网络中，都是把特征描述和距离度量相结合。实际上，在行人重识别领域，很多学者只是将卷积神经网络用于特征描述，在训练网络模型时将其视为一个多分类问题。Wang<sup>[33]</sup>等人将多个行人重识别数据库合成一个大型的综合数据集以分类为目标进行卷积神经网络的训练，对每一个数据库的数据进行前向传播，得到属于不同数据库的样本的影响因子，再使用这些影响因子进行模型的训练。Wu 等人<sup>[34]</sup>则是将卷积神经网络学习到的特征与人工提取的颜色特征在全连接层相融合送到 SoftMax 分类器中，对融合后的特征进行分类学习。这种多分类网络模型的弊端是只有在大量训练样本的情况下得到的模型才具有较强的识别效果，若训练样本不够会导致模型无法学习到有效的识别特征。

### 2.1.2 Cross image representation (CIR)

CIR 通常将行人重识别看成传统的二分类问题。

Ahmed<sup>[35]</sup>等提出了一种新的卷积网络结构，设计了一个新的卷积层来计算两张图片间邻域差异，捕捉两个输入图像之间的中间层特征的局部关系，将这层输

出的加权和送给全连接层，然后再送入 SoftMax 层进行二分类。该结构能够在分析特征的同时并利用图像特征学习到相应的图像相似性函数。Li<sup>[36]</sup>等人提出了一种六层的 FPNN (filter pairing neural network) 神经网络，使用一个卷积层用来模拟光照变化，添加了一个图像块匹配层可以有效的处理监控视频中出现的行人姿态变化、光照变化、遮挡等引起行人外观差距的问题，显著的提高了识别率。Lai<sup>[37]</sup>等人提出了一个统一的深度排名和特征描述相结合的框架，能够直接对输入图像进行相似度排序。将一个标记的数据放入排名集合 (ranking units) 中，每次简单的将两张图片水平的拼接在一起输入网络中，正确的匹配排名应该靠前，通过每次迭代最小化正样本排名的加和惩罚。

CIR 方法相对于 SIR 方法能更好的描述两幅输入图像间的关系，但需要将一幅测试图像 (probe image) 与候选库 (gallery set) 中的每幅图像配对抽取特征，时间复杂度相对较高。而 SIR 则只需对 gallery 中的每幅图像抽取一次特征，因此可以提前抽取并存储，然后与测试图像做相似性比较即可。在<sup>[38]</sup>中，作者将两种方法相结合，提出了一种新的卷积神经网络。该网络有三个子网络，一个共享的子网络，一个 SIR 子网络和一个 CIR 子网络，网络结构如图 2.3 所示。在训练时作者根据二元组和三元组的不同约束，得到了 Siamese 和 triplet 两种损失函数。




图 2.3 SIR 和 CIR 的联合训练网络<sup>[38]</sup>

## 2.2 距离度量

### 2.2.1 传统的度量学习算法

我们在对不同样本间的相似性进行度量时，通常是采用样本间的“距离”（distance）来进行计算。距离度量学习的目的是对图像间的相似性进行一个准确的测度，主要思路是让正样本之间的距离尽量的小，而负样本之间的距离尽量的大。大多数现存的度量学习方法只是使用线性变换将行人特征映射到一个新的特征空间。但是行人图片通常是处于一个非线性的流行空间，因此，线性方法无法准确的描述行人图片间的距离。为了解决这一问题，通常采用核计算方法将线性度量处理为非线性度量。传统的线性距离度量方法有：

- 1) 欧氏距离，也可以称为 L2 距离，就是两点在欧氏空间的距离。有两个  $n$  维向量  $x_i$  和  $x_j$ ，在欧氏空间的距离定义如下：

$$d(x_i, x_j) = \sqrt{(x_i - x_j)^T (x_i - x_j)} \quad (2.2)$$

- 2) 马氏距离，假设有两个向量  $x_i$  和  $x_j$ ，它们之间的马氏距离为：

$$d_M(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j) \quad (2.3)$$

其中， $M$  是测度矩阵并且是一个半正定矩阵，但由于测度矩阵  $M$  很难直接得到，因此一般是通过求解系数矩阵来间接获得  $M$ ，因此一般是通过求解系数矩阵  $L$  来间接获得  $M$ ，其中， $M = L^T L$ 。则马氏距离变为：

$$d_M(x_i, x_j) = d_L(x_i, x_j) = (x_i - x_j)^T L^T L (x_i - x_j) = \|L(x_i - x_j)\|^2 \quad (2.4)$$

可以通过求解系数矩阵  $L$  来实现样本间的度量。另外，当中的  $L$  为单位矩阵，此时，公式变为求解欧氏距离。

- 3) 余弦距离，将几何学中夹角余弦这一概念引入距离度量学习中，其中夹角的余弦取值为  $[-1, 1]$ ，通过两个特征向量间的余弦表示它们的相似度。两个特征向量的相似度越高，它们的余弦值越大，当两个向量方向完全重合时其余弦取最大值。对于两个向量  $x_i$  和  $x_j$ ，它们之间的余弦距离为：

$$d_{\cos}(x_i, x_j) = \frac{x_i^T x_j}{\sqrt{x_i^T x_i} \sqrt{x_j^T x_j}} \quad (2.5)$$

在行人重识别领域,通常采用欧氏距离,马氏距离,联合贝叶斯距离<sup>[39]</sup>和 LADF<sup>[10]</sup>四种度量进行度量学习。除此之外,近几年提出的 LFDA、kLFDA、KISSME 等度量学习算法也具有很好的识别效果。除此之外,近几年提出的 LFDA、kLFDA、KISSME 等度量学习算法也具有很好的识别效果。这里介绍一下后面用到的 kLFDA 算法。

局部费舍尔判别方法(local Fisher discriminant analysis, LFDA)<sup>[11]</sup>是一种基于局部保持投影(LPP)<sup>[40]</sup>和费舍尔线性判别(FDA)<sup>[41]</sup>。相结合的降维分类算法,使不同类别的样本在投影空间具有更好的分离性。而 kLFDA 则在 LFDA 的基础上引入了核方法,改善了小型数据库由于降维而导致特征失去鉴别性。

假设高维空间中一个训练样本集  $X = (x_1, x_2, \dots, x_n)$ ,  $X$  包含  $C = (l_1, l_2, \dots, l_c)$  个类别,每个类别有  $n_i$  个样本。将训练样本投影到低维空间,表示为<sup>[11]</sup>:

$$z_i = P^T x_i \quad (2.6)$$

其中,  $P \in^{n \times m}$  ( $1 \leq m \leq n$ ) 为待求的转换矩阵,  $m$  为投影后的维数。根据 LFDA, 局部内类散度矩阵  $S^w$  和局部类间散度矩阵  $S^b$  表示为:

$$S^w = \sum_{i,j=1}^n \mathbf{A}_{i,j}^w (x_i - x_j)(x_i - x_j)^T \quad (2.7)$$

$$S^b = \sum_{i,j=1}^n \mathbf{A}_{i,j}^b (x_i - x_j)(x_i - x_j)^T \quad (2.8)$$

其中,  $\mathbf{A}_{i,j}^w$  和  $\mathbf{A}_{i,j}^b$  为加权系数矩阵,  $\mathbf{A}_{i,j}^w$  和  $\mathbf{A}_{i,j}^b$  的定义如下:

$$\mathbf{A}_{i,j}^w = \begin{cases} \frac{\mathbf{A}_{i,j}}{n_c}, l_i = l_j = c \\ 0, l_i \neq l_j \end{cases} \quad (2.9)$$

$$\mathbf{A}_{i,j}^b = \begin{cases} \mathbf{A}_{i,j} \left( \frac{1}{n} - \frac{1}{n_c} \right), l_i = l_j = c \\ \frac{1}{n}, l_i \neq l_j \end{cases} \quad (2.10)$$

其中,  $l_i$  和  $l_j$  分别为第  $i$  个和第  $j$  个图像的类标签;  $n_c$  为第  $c$  类样本数,  $n$  是训练样本数;  $\mathbf{A}$  为近似矩阵(Affinity matrix)。转化矩阵可以定义如下:

$$P_{lda} = \arg \max_P (P^T S^w P)^{-1} P^T S^b P \quad (2.11)$$

kLFDA 在 LFDA 的基础上通过一个核函数  $\phi$  将 LFDA 推广到非线性空间,

内类散度矩阵  $\tilde{S}^w$  和类间散度矩阵  $\tilde{S}^b$  表示为:

$$\tilde{S}^w = \frac{1}{2} \phi(X)^T S^w \phi(X)$$

(2.12)

$$\tilde{S}^b = \frac{1}{2} \phi(X)^T S^b \phi(X)$$

(2.13)

投影矩阵  $Q$  作用于核空间的特征向量  $P = Q\phi^T(X)$ , 则 kLFDA 的问题转换为求解:

$$Q = \arg \max_Q (QKS^wKQ)^{-1} QKS^bKQ$$

(2.14)

其中,  $K = \phi(X)^T \phi(X)$ 。这样, kLFDA 仅对一个  $n \times n$  的矩阵特征求解, 降低了原有算法的复杂度。在本文的实验中, kLFDA 采用线性核。

2.2.2 基于深度学习的度量学习算法

由于深度学习的兴起, 很多学者开始研究基于深度学习的度量学习算法。Tan<sup>[42]</sup>等人提出了判别深度度量学习模型 (Discriminative Deep Metric Learning, DDML) 用于人脸识别。该算法通过学习一个深度神经网络, 使用该网络的两个子分支获得成对图片的特征向量, 送入一个损失函数中判断两张图片是否相似, 该算法的网络结构如图 2.4。




图 2.4 DDML 模型<sup>[42]</sup>



## 2.3 公共数据库概述

在进行行人重识别训练时，需要有预处理过的行人图像作为训练图像和测试图像。本文为了方便实验进行，采用已经存在的公共数据集进行行人重识别对比试验。本文用到的行人重识别数据集有以下几个：

### 2.3.1 VIPeR 数据集

VIPeR<sup>[5]</sup>（View Invariant Pedestrian Recognition）是加利福尼亚大学的 Gray 等人采集完成的，是目前最具有挑战性的行人重识别数据库。数据集共有 632 个行人图像，每个行人有两张在不同摄像机下的不同角度的图像，一共有 1024 张图像。数据集包含了不同拍摄视角下的行人图像，存在着姿势、光照等变化，且大多数图片存在较大的视角转换。VIPeR 数据集将每幅图像统一处理成 128\*48 的大小，便于特征的提取。下图为 VIPeR 数据集中部分图像样本，其中同一列代表不同摄像机下的同一行人目标。实验中，我们随机选取 316 个行人的图像进行网络模型的训练。



图 2.5 VIPeR 数据集示例



2.3.2 iLIDS 数据集

iLIDS<sup>[43]</sup> (the Imagery Library for Intelligent Detection System), 是在机场的候机厅中采集的。该数据集包含 119 个行人, 共 476 张图像, 每个行人包含 2 到 8 张不同的图像。该数据集由于在行人众多的候机大厅进行拍摄, 因此该数据集存在比较严重的遮挡问题。另外, 由于候机大厅不同区域的光照强度和拍摄角度不同, 导致大部分图像存在光照和视角等问题。

iLIDS 数据集中图像的尺寸大小不一样, 为了方便后续的实验, 我们把图像尺寸统一设置为 128\*48 大小。实验中, 我们随机选取 69 对相关行人图像进行网络模型的训练。

2.3.3 CUHK01 数据集

CUHK01<sup>[44]</sup>数据集是由香港中文大学研究团队建立的, 该数据集包含 971 个不同行人在两台摄像机下的共 3884 张图像。平均每个行人有 4 张图像, 其中两张是由摄像机 A 捕获的行人的正面和背面图像, 另外两张是由摄像机 B 捕获的行人的侧面图像, 如图 2.6 所示。每个行人在同一摄像机下拍摄的两张图像只存在姿态上的少许变化, 在不同摄像机下拍摄的图像在姿态、视角、光照上都有比较明显的变化。



图 2.6 CUHK01 数据集示例

CUHK01 数据集中图像的尺寸大小不一样, 为了方便后续的实验, 我们把图

像尺寸统一设置为 128\*48 大小。实验中，我们随机选取 486 对相关行人图像进行网络模型的训练。

## 2.4 评估方案

行人重识别算法可以看作是一个相似度排序的问题，因此一般使用累积匹配特征（Cumulative Matching Characteristic, CMC）<sup>[24]</sup>曲线对实验结果进行评估。设有一个存在  $n$  张行人图片的候选库（gallery set） $G = \{g_1, g_2, \dots, g_n\}$  和待测试库（probe set） $P = \{p_1, p_2, \dots, p_m\}$ ， $m$  表示待测试库的大小。对于一幅待测试图像将其与候选库中的每幅图像的距离进行相似度排序。也就是说，给定一个待查询的行人目标，在候选库（gallery set）的很多行人中找到该目标，CMC 值表示在前  $N$  个结果中找到该目标的概率。其中第一匹配率（rank-1）表示在候选库中，最匹配的行人正好是目标行人的概率。同理，rank- $k$  表示在候选库中，目标行人出现的概率正好在与目标相似的前  $k$  张图片中的概率。在行人重识别中，常常使用 rank-1 到 rank-30 的概率作为衡量算法的指标。侯选库的行人数量越多，能准确找到目标行人的概率越低，rank-1 的值也越低。Rank-1 指标是 CMC 曲线中最重要的指标，rank-1 指标越大，则代表算法的识别效果越好。

本文首先随机选取数据集中一半行人的样本训练卷积神经网络模型，再用另一半行人样本进行测试，并按相似度进行排序，最后得到相似度排序的结果。本文在每一次测试中均进行 10 次实验，然后计算 10 次的平均值作为最后的结果。

## 2.5 本章小结

在本章中，介绍了深度学习在行人重识别领域的应用，包括特征描述和度量学习两部分的基本研究内容和当前存在的相关方法，并对本文用到的三个行人重识别数据库进行了简单的描述。最后，本章介绍了在行人重识别中常用的性能评估方法 CMC 值。

### 第3章 基于卷积神经网络的行人特征提取

行人重识别研究中用到的图像往往是在不可控的条件下采集的，由于光照、摄像角度、行人姿态、遮挡和分辨率等因素的影响，传统的方法通常是使用人工设计的方法对视频中行人的某一种特性（如颜色）的特征进行提取，或者提取多种特性融合的特征对行人进行描述。由于同一个行人在不同图像中可能有很大差异，而不同的行人又可能看起来很相像，使得这些人工设计的特征很难应用到复杂的现实环境中。而深度学习则可以自动从数据中学习特征，目前已经在计算机视觉的很多领域取得了不错的成绩，如手写字体识别、目标检测、目标分类、人脸识别等。因此本章采用卷积神经网络模型学习行人特征。

卷积神经网络的产生受到神经生物学的启发，其计算方式和哺乳动物的视觉系统有极大的相似性，是一种端对端的识别方法。在处理图像时，不需要进行复杂的预处理操作，能够从数据中自动学习特征。卷积神经网络是一种由多个卷积层和全连接层构成的神经网络，在训练的过程中结合局部感受野、权值共享和池化三个方法实现网络的优化。局部感受野使得在卷积层的学习过程中，每一层的神经元只与上一层的部分神经元连接，大大减少了参数的个数，加速了网络的训练；权值共享是指位于同一感受野的神经元权值相同，进一步减少了训练参数；池化可以降低特征图的尺寸，从而减小网络的计算量，并且增加物体平移、缩放等操作的鲁棒性。2012年，Alex等人提出的AlexNet在ImageNet挑战赛上取得了很好的分类效果，后续研究者的研究<sup>[45, 46]</sup>表明，用ImageNet训练好的CNN可以提取出有效的特征直接用在不同的任务中，如场景分类、目标检测、细粒度(fine grained)识别、属性检测(Attribute detection)、图像检索等。

本章旨在将卷积神经网络用于行人特征的提取。首先使用在ImageNet上预训练好的AlexNet进行特征提取。然后，设计了一种结构更为简单的卷积神经网络结构，将训练得到的模型用于行人特征提取。

3.1 基于 AlexNet 的行人特征提取

AlexNet 是在 2012 年 ImageNet<sup>[47]</sup>分类赛上 Krizhevsky<sup>[48]</sup>提出的图像分类模型，该网络模型有超过 6000 万个参数，在当年取得了比赛的第一名，分类效果远远领先于第二名。ImageNet 数据库的训练集有 1000 个分类，每类大约有 1000 张图片，AlexNet 就是在这个数据库上训练得到的。由于训练样本类别足够多，训练样本容量也很大，在<sup>[45, 46]</sup>中，作者将 AlexNet 用于目标分类、目标检测等不同的领域均取得了不错的效果，说明 AlexNet 可以提取出输入图像的有效特征。本章将 AlexNet 用于行人重识别领域，探究其在行人重识别领域是否也依然具有很好的效果。

3.1.1 AlexNet 的网络结构

AlexNet 网络模型一共有五个卷积层，三个池化层，三个全连接层以及一个 SoftMax 层。AlexNet 模型的网络结构图如 3.1 所示：




图 3.1 Alexnet 网络模型

3.1.1.1 卷积层

在卷积层，特征图（feature map）的每一个神经元只与前一层的特征图局部相连，因此卷积层相对于全连接层，可以大大减少参数的个数。一个卷积层使用多个卷积核与上一层的输出进行卷积操作，得到多个特征图。同一个特征图的中神经元权值共享。不同的特征图的神经元权值不同，得以区分不同的特征。在网络模型的训练中会对权值进行优化。该层的相关计算公式如式 3.1 所示：

$$x_j^l = f \left( \sum_{i \in M_j} x_i^{l-1} * k_{ij}^l + b_j^l \right) \tag{3.1}$$

其中， $M_j$ 表示选择的输入特征图的集合， $x_j^l$ 表示第 $l$ 层中第 $j$ 个特征图， $x_i^{l-1}$ 表示第 $l-1$ 层中第 $i$ 个特征图， $k_{ij}^l$ 表示第 $l$ 层中第 $j$ 个特征图和第 $l-1$ 层中第 $i$ 个特征图之间连接的滤波器，函数 $f(\cdot)$ 为激活函数， $b_j^l$ 为偏置。

3.1.1.2 池化层

池化层是对上一层的每一个特征图进行采样操作，上一层的特征图经过池化(pooling)后个数不变，尺寸减小。池化层通常跟在卷积层之后，能进一步减少网络的数据，降低网络的计算量，并且增加物体平移、缩放等操作的鲁棒性。在对池化窗口进行取值的过程中，我们可以将池化操作分为最大池化(max pooling)和平均池化两种。最大池化是指对于一个池化窗口，我们选取其中数值最大的一个特征向量作为该窗口的输出。而平均池化则是计算池化窗口区域的平均值作为该池化窗口的输出。本文在训练卷积神经网络均采用最大池化方法。假设一个池化窗口的大小为 size，池化操作的过程中，相邻的两个池化窗口的位移为步长(stride)。如果 size=stride，即在进行池化操作时每一个池化窗口都不重叠；如果 size>stride，即进行池化窗口时，邻近的池化窗口之间会有一定的重叠。在<sup>[49]</sup>中，作者又提出了一种新的空间金字塔池化操作，在这种操作下，网络的输入不要求是固定尺寸的图片。任意尺寸的图像经过该池化层操作可以转化成相同的维度进行后续的学习，因此不必事先对训练样本的尺寸进行统一，避免了由于图片尺寸的变化和图片截取导致训练样本失真变形。

3.1.1.3 修正线性单元 (ReLU 层)

激活函数(active function)是神经网络领域的概念，能提高神经网络的表达能力。在神经网络中，常用的激活函数有 ReLU 函数，Sigmoid 函数和 Tanh 函数三种，通常是非线性的。由于 Sigmoid 函数和 Tanh 函数会随着网络的迭代过程达到饱和状态，出现梯度消失(vanishing gradient)，造成信息丢失，而使用 ReLU

激活函数则没有这个弊端。在本文卷积神经网络模型的训练过程中,均采用 ReLU 作为激活函数。假设一个神经元的输入为  $x$ , ReLU 函数定义如下:

$$f(x) = \max(0, x) \quad (3.2)$$

由上式可以知道,当神经元的输入是一个正值,在通过 ReLU 函数后,输出等于输入;当神经元的输入是一个负值时,输出为 0。

ReLU 能使输出具有一定的稀疏性,这一特点能减少参数间相互依赖的关系,防止过拟合现象的产生。此外由于 Sigmoid 等函数计算量大,使得网络收敛速度较慢。实验证明,在相同的网络结构下,使用 ReLU 函数的网络的收敛速度比 tanh 函数快 7 倍左右。

#### 3.1.1.4 局部响应归一化

局部响应归一化是对一个局部的输入区域进行归一化处理,与 ReLU 函数一样,能加速网络的学习。用  $a_{x,y}^i$  表示点  $(x,y)$  处在某一层使用核计算得到的神经元激活度,然后应用非线性的局部响应归一化,产生该神经元的归一化活性  $b_{x,y}^i$  由下式给出:

$$b_{x,y}^i = a_{x,y}^i / \left( k + \alpha \sum_{j=\max(0, i-n/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2 \right)^\beta \quad (3.3)$$

其中  $\sum_{j=\max(0, i-n/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2$  表示有  $n$  个位于相同空间位置且彼此相邻的核,该层一

共有  $N$  个核。核映射的顺序在训练开始时就已经确定了。常数  $k$ ,  $n$ ,  $\alpha$  和  $\beta$  是超参数,通过验证集来确定。在 AlexNet 中采用  $k=2$ ,  $n=5$ ,  $\alpha=10^{-4}$ ,  $\beta=0.75$ 。

#### 3.1.1.5 全连接层

卷积神经网络中的全连接层实际上就是传统的人工神经网络 (Artificial Neural Networks, ANNs)。与卷积层不同,全连接层的每一个神经元与上一层的所有神经元连接。一个神经网络中的每一层都有大量的神经元,通过这些神经元组合,就得到了一个结构复杂的神经网络。对于一个有三个输入值的神经元,

它对输入信息的处理过程如图 3.2 所示：




图 3.2 单个神经元<sup>[50]</sup>

图 3.2 表示一个神经元此时有三个输入值（ $x_1$ 、 $x_2$ ， $x_3$ ），这三个输入值在通过该神经元后的输出为：

$$h_{w,b}(x)=f\left(W^Tx\right)=f\left(\sum_{i=1}^nW_ix_i+b\right) \tag{3.4}$$

其中， $x_i$ 是一个输入向量， $W_i$  为每个输入在该神经元中的权重， $b$  为偏置，函数  $f(\cdot)$  称为激活函数。

3.1.1.6 SoftMax 层

SoftMax 损失函数是一种常用的多分类损失函数。假设一个  $k$  类的多分类问题，有  $m$  个样本，对于训练集 $\left\{\left(x^1,y^1\right),\ldots,\left(x^m,y^m\right)\right\}$ ，其中，样本  $x^i$  的特征为  $f\left(x^i\right)$ ， $y^{(i)}=\left\{1,2,\ldots,k\right\}$  是样本标签。对于一个待测试的输入  $x^i$ ， $x^i$  属于每一个类别  $j$  的概率为  $P\left(y=j|x\right),\left(j=1,\ldots,k\right)$ ，这样每个样本就形成了一个  $k$  维的输出，根据概率最大值进行类别判断，假设函数  $h_{\theta}(x)$  可以表示为：

$$h_{\theta}\left(x^i\right)=\begin{bmatrix}P\left(y^{(i)}=1|x^{(i)},\theta\right)\\P\left(y^{(i)}=2|x^{(i)},\theta\right)\\...\\P\left(y^{(i)}=k|x^{(i)},\theta\right)\end{bmatrix}=\frac{1}{\sum_{j=1}^ke^{\theta_j^Tf\left(x^{(i)}\right)}}\begin{bmatrix}e^{\theta_1^Tf\left(x^{(i)}\right)}\\e^{\theta_2^Tf\left(x^{(i)}\right)}\\...\\e^{\theta_k^Tf\left(x^{(i)}\right)}\end{bmatrix} \tag{3.5}$$

其中， $\theta_1,\theta_1,\ldots,\theta_1\in\Re^{n+1}$  是 FC8 的连接参数， $1/\sum_{j=1}^ke^{\theta_j^Tf\left(x^{(i)}\right)}$  是一个归一化处理方法,使得每一个样本在经过 SoftMax 层后输出的概率向量之和为 1。SoftMax 损失函数定义如下：

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T f(x^{(i)})}}{\sum_{j=1}^k e^{\theta_j^T f(x^{(i)})}} \right] \quad (3.6)$$

其中  $1\{y^{(i)} = j\}$  表示如果  $y^{(i)} = j$ , 则为 1, 否则为 0。损失函数越小意味着分类的结果越准确。

### 3.1.1.7 Dropout 技术

在训练网络模型时, 如果训练样本过少, 则会出现过拟合现象。Dropout<sup>[51]</sup>技术的提出是为了缓解在网络训练的过程中出现过拟合。过拟合 (over fitting) 是指训练得到的模型对于训练数据能有很好的拟合, 但对于测试数据, 不能很好的拟合数据。Dropout 是指在网络的训练过程中, 进行权值更新时, 随机的让某些隐含单元的权重不工作, 每次只使用部分的隐含单元进行权值的更新。

运用 dropout 技术训练网络模型, 在每次训练的过程中都随机的去除一些隐含单元, 相当于训练了很多只有部分隐含单元的神经网络, 每一个这样的网络都能得到一个分类结果, 有些分类结果是正确的, 有些是错误的。随着迭代的过程, 最终大部分网络都能给出正确的分类结果, 错误的分类结果只占少部分, 则能让网络最终的输出更为准确。

### 3.1.2 AlexNet 的微调

本节的实验基于两个公开的行人重识别数据库 VIPeR 和 CUHK01, 首先使用了在 ImageNet 上预训练好的卷积神经网络模型 AlexNet, 然后使用 Caffe<sup>[52]</sup> 框架, 分别用这两个数据库对 AlexNet 进行微调。最后使用微调得到的模型对两个数据库的测试图像进行特征提取, 选取一个有效的度量方法进行相似度度量。

由于训练深层的卷积神经网络需要大量的数据样本才能得到良好的卷积神经网络模型, 因此本章采用微调的目的是为了解决训练样本有限的情况下模型训练的问题。微调时, AlexNet 的卷积层和第一个全连接层的参数都不作改变, 在训练模型的过程中会继承这些参数, 减少了模型的训练时间。本章改变了后两个



全连接层的神经元个数，将 fc7 层的神经元个数从 4096 变为 1024，这是由于行人的特征描述子相对较小，fc7 的维数过高会导致后续进行度量学习时计算任务加重。而 fc8 层则分别设为两个数据库的行人类别 312 和 486。通过改变全连接层的参数，减少网络模型的训练参数，降低模型训练的时间复杂度。在模型的训练过程中，会对这两层的权重进行初始化后重新训练得到新的权重参数。

下面，我们将介绍 AlexNet 微调时的参数设置。

在训练的过程中，网络继承了 AlexNet 的卷积层和第一个全连接层的权重参数。因此我们在训练网络的过程中，由于需要学习的网络参数减少，因此初始学习速率不能设置太大，本章将其设置为 0.001。由于 GPU 技术的高速发展，在相同的条件下，使用 GPU 技术训练网络要比使用 CPU 训练网络时间要少很多。因此本章使用 GPU 对进行网络模型的训练。在微调的过程中，还需要设置一些参数，具体参数如表 3.1 所示：

| 表 3.1 微调训练时网络模型参数设置 |        |
|---------------------|--------|
| 参数变量                | 参数值    |
| 初始学习率               | 0.001  |
| 优化方法                | SGD    |
| gamma               | 0.1    |
| 步率                  | 20000  |
| 显示值                 | 20     |
| 最大迭代次数              | 100000 |
| momentum            | 0.9    |
| weight_decay        | 0.0005 |
| 映射                  | 10000  |
| solver_mode         | GPU    |

上表中各项的意义是，微调时的初始学习率设置为 0.001，每经过 20000 次迭代，学习率变为初始学习率 \* gamma，网络训练的过程中使用 SGD 算法进行参数优化。每 20 次迭代，网络的训练会在屏幕上显示一次；每 10000 次，会生成一个网络模型并保存；整个网络的训练过程需要迭代 100000 次。momentum 表示上一次更新的权重，思路来源与牛顿第二定律，可以使 SGD 优化算法更加快速稳定。weight\_decay 是设置的权重衰减项，可以防止过拟合。

### 3.1.3 实验分析

本节选取 VIPeR 和 CUHK01 两个存在视角变化的公开数据集进行实验。我们首先直接使用在 ImageNet 数据集上预训练好的模型进行特征提取,然后对该模型分别在 VIPeR 和 CUHK01 数据集上进行微调得到新的模型,提取该模型 FC7 层的输出作为行人的特征向量,将这些特征用 kLFDA 算法进行度量学习,最后采用标准的累积匹配特征 (Cumulative Matching Characteristic, CMC) 曲线进行评估。

在训练网络之前,由于 AlexNet 网络模型的卷积核设置较大,因此我们将两个数据集中的图像样本尺寸适度扩大使其适用于 AlexNet。在训练 VIPeR 数据集的卷积神经网络模型时,随机选取 316 个行人共 632 张图像作为训练集,剩下的图像作为测试集。同理,在 CUHK01 数据集上随机选取 486 个行人作为训练集进行模型的训练。

在进行评估的时候,采用了<sup>[24]</sup>中提供的工具,在 Viper 数据集的测试集中随机选取 200 个行人,共 400 个图像。实验时将相机 A 中的图像作为待测试库 (probe set),相机 B 中的图像作为候选库 (gallery set)。将一幅测试图像与候选库中的每幅图像的距离进行相似度排序。为了获得稳定的结果,实验一共进行 10 次测试,最后计算 CMC 值的平均值作为最终结果。CUHK01 数据集上的操作与 VIPeR 数据集类似。

本章首先在 VIPeR 数据集上进行实验。为了比较微调的效果,我们直接使用 AlexNet 提取特征,rank-1 最好的结果是 18.9%,使用微调训练得到的模型提取特征,rank-1 指标提升到 28.3%。在表 3.2 中,我们比较了本章算法与其他基于人工特征的行人重识别算法。可以看出,即使只是简单的使用预训练好的 AlexNet 模型提取行人特征,识别效果也优于部分经典的人工特征的行人重识别算法。而使用行人重识别数据库对 Alexnet 模型进行微调后,识别效果有了较大的提升。

表 3.2 Viper 数据集上与人工特征算法的比较 (%)

| Rank                  | 1     | 10    | 20    |
|-----------------------|-------|-------|-------|
| Alexnet (fine-tuning) | 28.3  | 56.4  | 66.7  |
| Alexnet               | 18.9  | 60.5  | 75.9  |
| SDALF [6]             | 19.87 | 49.37 | 65.73 |
| ELF[5]                | 12    | 44    | 61    |
| PS[53]                | 21.85 | 57.2  | 71.17 |
| ICT[54]               | 14.41 | 59.65 | 78.32 |
| RPDC[55]              | 15.66 | 53.86 | 70.09 |
| eSDC[9]               | 26.7  | 62.4  | 76.4  |
| SCNN[27]              | 28.2  | 73.4  | 86.4  |
| eBiCov[56]            | 20.7  | 56.2  | 68.0  |

从 VIPeR 数据库的结果上看，微调过的模型有更好的识别效果，因此在 CUHK01 数据库上，我们只分析使用微调模型得到的特征，表 3.3 分析了本章算法在 CUHK01 上与其它行人重识别算法的比较。

表 3.3 CUHK01 数据集上与其他主流算法的比较 (%)

| Rank                  | 1     | 10    | 20    |
|-----------------------|-------|-------|-------|
| Alexnet (fine-tuning) | 38.0  | 65.8  | 74.6  |
| SDALF[6]              | 9.9   | 30.3  | 41.0  |
| ITML[57]              | 15.98 | 45.60 | 59.81 |
| Mid-level[58]         | 34.30 | 64.96 | 73.94 |
| eSDC[9]               | 19.67 | 40.28 | 50.57 |
| SalMatch[59]          | 28.45 | 55.67 | 68.89 |

3.1.4 小结

深度学习已经成为计算机视觉领域新的研究热点。由于卷积神经网络具有特征学习能力，因此比传统方法更适合于工程领域的实际应用。本章利用卷积神经网络自动特征学习的特点，避免了复杂的人工特征提取过程，与一个有效的距离度量方法相结合，完成整个行人重识别。由于训练样本的数据有限，本章使用 AlexNet 进行微调。在 Caffe 架构下使用 GPU 平台能较快的得到用行人重识别数据库训练的模型。使用该模型提取行人特征，使用 kLFDA 度量学习方法对所得到的特征进行相似度度量，通过在 VIPeR 和 CUHK01 两个数据库上进行实验，rank-1 指标分别达到了 28.3%和 38.0%，实验结果优于传统的人工提取的特征，

验证了卷积神经网络模型在行人重识别领域的可行性。

本节的研究基于经典的 AlexNet 模型，将卷积神经网络作为一种特征提取的方法。在下一节，我们将在提出一种结构更为简单的网络结构，更深入地研究卷积神经网络在行人重识别领域的应用。

3.2 行人专用的简单卷积神经网络模型

由于行人重识别的图片样本尺寸较小，若直接使用 AlexNet 网络，需要对行人图像进行放大导致图像失真。且由于行人重识别数据库样本都相对较少，一般只有几千张图片，网络结构过于复杂会导致收敛过慢，甚至会导致过拟合（over-fitting）现象，无法学习到有效的网络模型。因此我们采用了一个更简单的网络结构，由三个卷积层和两个全连接层构成，由于在上一章我们微调训练了一个多分类的卷积神经网络得到了较好的识别效果，在本章我们依然使用 SoftMax 损失函数，将行人重识别看作是一个分类问题。本章使用的卷积神经网络结构如图 3.3 所示：




图 3.3 卷积神经网络结构

我们只设置了三个卷积层，将卷积核统一设置为 5\*5 的大小，卷积层的卷积核尺寸变小，以及卷积层数的减小，使得网络参数大大减少，更适用于行人重识别数据库。前两个 pooling 层使用了 3\*3 的核，步长为 2，最后一个 pooling 层使用了 8\*5 的核，使得最后一层的 feature map 分别对应行人从头到脚的四个部分。同时，该网络结构只有两个全连接层，第一个全连接层的神经元个数设置为 1024 维，相对于 AlexNet 降低了全连接层的维度，第二个全连接层的神经元个数设置为训练样本的类别数，送入 SoftMax 损失函数进行分类训练。在该网络中，我们

使用 FC6 层的输出作为行人样本的特征向量。

在 Viper 数据集中随机选取 316 个行人共 632 张图像作为训练集，因此 FC7 的神经元个数为 316，这样网络大约有 66 万个参数，远少于 AlexNet 的 6000 万个。

3.2.1 实验参数设置

在进行训练的过程中由于行人重识别数据库的样本较少，因此学习速率的选择十分重要。本章在开始时选择与上一章微调训练时的参数 0.001 作为初始学习率，发现在训练的过程中损失值变为 87.3356，说明在 SoftMax 损失函数中计算得到的概率出现了 0 值。由于初始学习率设置过大，导致某次迭代后的输出值出现了 float 溢出的现象，此时应该适当的减小初始学习率。

但我们在减小初始学习率变为 0.0001 后，由于学习率过小，导致训练过程中网络收敛过慢。在经过几次试验后，我们将初始学习率设置为 0.0005，保证在网络训练的过程中迭代能顺利进行。本章训练过程的具体参数如表 3.4 所示：

| 表 3.4 训练时网络模型参数设置 |        |
|-------------------|--------|
| 参数变量              | 参数值    |
| 初始学习率             | 0.0005 |
| 优化方案              | SGD    |
| gamma             | 0.1    |
| 步率                | 50000  |
| 显示值               | 100    |
| 最大迭代次数            | 200000 |
| momentum          | 0.9    |
| weight_decay      | 0.0004 |
| 映射                | 10000  |
| solver_mode       | GPU    |

3.2.2 实验结果分析

使用本节训练得到的模型进行特征提取，将特征用于相似度度量时，实验结果并不理想，在 VIPeR 数据集上的 rank-1 指标只有 8.9%，远远低于直接使用

AlexNet 提取特征 rank-1 指标 18.9%。

本节在前一节的研究基础上提出了一个结构更为简单的卷积神经网络,使其能够更加的适用于行人重识别库。

但是通过实验我们发现该网络结构的识别效果并不理想。由于 AlexNet 是在 1000 个类别上千万张图片上训练的网络模型,而本章的数据样本只有 316 类的 632 张图片,而分类模型需要大量的数据样本才能得到有效的网络模型。即使在实验时为了加大样本数据,我们对每张图片进行了水平翻转扩大数据量,但分类效果依然十分不理想,模型无法学习到有效的行人特征。

要使得分类网络模型能够学习到有效的行人特征,需要在一个大型的行人数据库上进行模型的训练,以解决训练样本容量过小的问题。另外,本节的网络只有三个卷积层,两个全连接层,模型结构太过简单,不足以学习到行人的有效特征。

### 3.3 本章工作总结

本章将卷积神经网络作为一种行人特征提取的方法。目前在行人重识别领域,大多数学者不再只是将卷积神经网络作为一种特征提取的方法,提出了很多新的卷积神经网络结构,识别效果得到了很大的提升。且由于训练样本数量过少,本章的卷积神经网络结构难以学习到有效的特征。因此在下一章,我们重新设计了一个卷积神经网络结构,使其能在图像样本容量很小的时候依然能够得到较明显的识别效果。

## 第4章 改进的孪生神经网络设计

基于深度学习的行人重识别模型可以分为两类,一类是利用卷积神经网络进行特征提取,然后用度量学习算法进行识别,即分类模型。另一类是将特征提取和度量学习联合在一起训练,从而提取出有利于相似度量度的特征,即匹配模型。第三章我们采用第一类模型,将卷积神经网络用作行人特征提取,再与度量学习相结合。但是由于训练样本数量过少,分类模型只有使用预训练好的模型在微调的情况下才能取得较好的效果。分类模型可以充分的利用行人的类别标签,但需要大量的数据样本进行模型的训练;而匹配模型对数据样本的数量没有过多的要求,但是没有充分的利用到行人的类别标签。因此本章将这两种模型相结合,设计了一种能在训练样本有限的情况下进行行人重识别的网络模型。

本章在训练时采用孪生神经网络(Siamese network)结合了特征学习和相似性度量,测试时用训练好的网络抽取特征,然后再用度量学习算法进行行人重识别。本章采用改进的 Siamese 结构的模型。我们在传统的孪生网络中增加了一个全连接层和 SoftMax 层,然后在损失函数中结合了 SoftMax 损失函数和对比损失函数(Contrastive loss)。SoftMax 损失函数作为一种有效的分类损失函数,能够很好地区分不同的类别,但对类内的样本并没有太多约束。对比损失函数则能进一步缩小类内距离,扩大类间距离。通过两个损失函数联合训练,可以学习到更具判别力的特征。

### 4.1 Siamese 网络

#### 4.1.1 经典 Siamese 网络结构

Siamese 网络是用于处理验证类问题的一种网络。算法的原理是利用卷积神经网络提取图像的特征,然后利用两个图像样本的特征进行相似度量度。Siamese 网络如图 4.1 所示,有两个分支分别输入图片  $x_1$  和  $x_2$ , 经过一个完整的卷积神经

网络得到两个图像的输 出特征向量  $f(x_1)$  和  $f(x_2)$ ，然后构造两个特征向量的距离度量方法，作为两张图像的相似度计算函数。需要注意的是，虽然在图 4.1 的 Siamese 网络中有两个分支，但这两个分支实际上是同一个卷积神经网络，共享一套权重。




图 4.1 Siamese 网络结构

如图 4.1 所示，Siamese 网络的作用是判断两张图片是否相似，输入是一对（pari-wise）样本。因此训练样本的正样本是一对拥有同一标签的图片，负样本是标签不同的一对图片。其中的卷积神经网络可以看作是一个特征提取器，然后在网络的最后一层定义了用于度量相似度的损失函数。我们的目的是要构建一个损失函数满足：对两张同类别的图片，样本间距离应该尽量小；对两张不同类别的图片，样本间距离应该尽量大。假设两个图片的特征向量间的距离记作  $d_{i,j}$ （可用欧氏距离、余弦距离等度量方式衡量，这里假设使用欧氏距离进行相似度度量），Siamese 网络的损失函数定义如下：

$$L=\frac{1}{2}y_{i,j}d_{i,j}^2+\frac{1}{2}(1-y_{i,j})\max\{0,m-d_{i,j}\}^2 \tag{4.1}$$

其中， $y_{i,j}$  为表示两个样本是否相似的标签， $m$  是一个阈值。 $y_{i,j}=0$  表示两个样本不是同一类别， $y_{i,j}=1$  表示两个样本属于同一类别。当两个样本相似（ $y_{i,j}=1$ ）时，损失函数变为两个特征的距离平方，则距离越近损失值越小；当两个样本不相似（ $y_{i,j}=0$ ）时，损失函数变为  $\max\{0,m-d_{i,j}\}^2$ ，当距离小于  $m$  时，就会获得一个  $m-d_{i,j}$  的惩罚项，当距离大于  $m$  时，就没有惩罚项。两个样本间的距离越大，惩罚越小。



传统的 Siamese 网络结构的缺点是只使用了辨识两张图片是否为同一类别的标签，不能完全的利用行人重识别的行人图片标签。因此，我们在传统的 Siamese 网络的基础上提出了一种改进的 Siamese 网络结构，既能充利用行人图片标签，也考虑到了图片成对标签。

4.1.2 改进的 Siamese 网络结构

本章采用改进的 Siamese 网络结构进行特征和度量学习的联合训练，如图 4.2 所示。该网络结构的创新点在于在学习特征的时候，不仅考虑样本类间的距离，还考虑分类的准确率。从下图可以看出，我们传统的 Siamese 网络的基础上对网络结构进行了改进，增加了一个全连接层 FC8 和 SoftMax 层，将不同类别的样本进一步分开。在训练传统的 Siamese 网络时只需要给出两幅输入图像是同类还是不同类，损失函数一般用对比损失函数。在我们改进的网络中，还需要给出两幅输入图像的类别标签，用作学习样本的类别。在损失函数里结合了 SoftMax 和 Contrastive 两种损失函数，这样可以更有效地将不同的类别分开。




图 4.2 改进的 Siamese 网络结构

在改进的 Siamese 网络中，有两种标签，一种是类别标签（identity），用给定标签的行人重识别数据，进行分类训练，将不同类别的样本分开，拥有非常强的身份关联性和类间差异，本章使用 Caffe 架构中的 SoftMax 损失函数实现样本

的分类，其输入来源于全连接层 FC8；另一种是验证标签（verification），也就是行人对的验证，要求输入的数据成对存在，每一对图像数据有一个验证标签，标识行人样本是否属于同一个类别。如果是同一个标签，则要求这对图像数据的特征更接近，如果是不同的标签，则要求它们的特征尽可能的远。本章使用 Caffe 中的对比损失函数实现这一功能，其输入来源于全连接层 FC7。

其中，FC8 层的神经元个数与样本类别一致，其输出表示输入的样本属于每一个类别的概率大小。

4.1.3 卷积神经网络结构

我们设计了一个由五个卷积层（convolutional layer），三个池化层（pooling layer），以及两个全连接层构成的适用于行人的卷积神经网络。如图 4.3 所示。




图 4.3 卷积神经网络结构

在一个卷积神经网络中，网络的结构越复杂，学习到的特征也越多，在第三章，Alexnet 的网络结构取得了不错的分类效果，因此本章在 Alexnet 的基础对网络结构进行了改进。由于行人的输入样本尺寸较小，在卷积层，我们参照 VGG<sup>[60]</sup> 的设定，将卷积核设置为 3\*3 的大小。五个卷积层特征图（feature map）个数分别为：64,128,256,512,512。

卷积神经网络结构有 3 个池化层，均采用最大池化（max pooling），分别位于第一、第二和第五个卷积层之后。前两个 pooling 层的核大小设置为 2\*2，步长为 2，最后一个 pooling 层使用了 8\*5 的核，使得最后一层的 feature map 分别对应行人从头到脚的四个部分。有两个全连接层，为了便于后续特征的计算，我们其中第一（FC6）、第二个全连接层（FC7）的 feature map 个数从原来的 4096 维分别设置为 1024 和 512。

#### 4.1.4 对比损失函数 (Contrastive loss)

我们在传统的孪生网络中增加了一个全连接层和 SoftMax 层，然后在损失函数中结合了 SoftMax 损失函数和对比损失函数 (Contrastive loss)。通过两个损失函数联合训练，可以学习到更具判别力的特征。在本章中，使用 Siamese 网络进行学习的目的是得到特征向量，并不是为了使识别率最大化。

对比损失函数主要用于 Siamese 网络中，其表达式如下：

$$Ver = \frac{1}{2N} \sum_{i,j} y_{i,j} d_{i,j}^2 + (1 - y_{i,j}) \max(m - d_{i,j}, 0)^2 \quad (4.2)$$

其中， $d_{i,j} = \|f(x^{(i)}) - f(x^{(j)})\|_2$  代表两个样本特征  $f(x^{(i)})$  和  $f(x^{(j)})$  的欧氏距离， $y_{i,j}$  表示样本  $i$  和样本  $j$  是否匹配， $y_{i,j}=1$  表示两个样本属于同一类， $y_{i,j}=0$  则代表两个样本属于不同类。 $m$  为设置的阈值，表示我们期望的不同类别的特征之间的距离，通常设置为 1。

Lecun<sup>[61]</sup>最初是将 Contrastive loss 用于特征降维，在降维后的特征空间中，原本相似的样本依然相似，不相似的样本依然不相似。通过表达式可以知道，当样本相似时 ( $y_{i,j}=1$ )，损失函数只剩下  $\sum d_{i,j}^2$ ，损失函数可以看作是两个样本间的欧氏距离，若此时两个样本的欧氏距离依然较大，则需要最小化它们之间的距离，减小损失；而当样本不相似时 ( $y_{i,j}=0$ )，此时损失函数只剩下  $\sum \max(m - d_{i,j}, 0)^2$ 。当两个样本特征之间的距离大于  $m$  时，说明网络已经能够很好的区分这两个特征了，此时损失函数变为 0；当两个样本特征之间的距离小于  $m$  时，损失函数变为  $\sum (m - d_{i,j})^2$ ，表示这两个样本还需要更好的区分。当两个样本不同时，需要增大它们间的距离，提出  $m$  的目的在于使类间距离大于这个阈值。在训练中，网络通过这样一个过程实现扩大类间距离，缩小类内距离的目的。图 4.4 展现了 Contrastive loss 的损失函数值和样本的特征向量的欧氏距离之间的关系，其中红色线表示的是相似样本的损失值，蓝色线表示不相似样本的损失值。




图 4.4 损失函数值和样本的特征向量的欧氏距离之间的关系<sup>[61]</sup>

4.1.5 改进的 Siamese 网络训练过程

结合上述对改进的 Siamese 网络模型的介绍，我们对网络的训练过程进行详细描述：

行人类别是通过  $n$  维的 SoftMax 层来预测，输出是一个  $n$  维的概率分布，通过 SoftMax 损失函数来训练：

$$L_{Iden}(fc8,t,\theta_{id},\theta_{cnn})=-\frac{1}{N}\log P_i \tag{4.3}$$

其中， $fc8(x,\theta_{id})$  是通过 FC8 层提取的特征向量， $t$  是目标的身份类别， $\theta_{id}$  是 FC8 层的参数，由输入样本时的标签决定， $P_i$  是预测概率分布， $\theta_{cnn}$  是待训练的卷积神经网络参数。

行人对比损失是基于 L2 范数的验证函数：

$$L_{Ver}(f_i,f_j,y_{i,j},\theta_{cnn})=\begin{cases} \frac{1}{2N}\sum_{i,j}\|f_i-f_j\|_2^2,y_{i,j}=1 \\ \max\left(m-\|f_i-f_j\|_2,0\right)^2,y_{i,j}=0 \end{cases} \tag{4.4}$$

改进的 Siamese 网络在 FC7 层进行特征提取  $f(x,\theta_{cnn})$ ， $x$  是输入的样本。当  $y_{i,j}=1$  时，说明两张样本属于同一类别，我们需要最小化两个特征向量的欧氏距离，当  $y_{i,j}=0$  时，说明两个样本属于不同的类别，尽可能的让两个向量之间的欧氏距离大于阈值  $m$ 。

在本章的整个网络训练的过程中，网络的损失函数为上面两个损失函数的加

权和:

$$L = L_{Iden}(fc8, t, \theta_{id}, \theta_{cnn}) + \lambda L_{Ver}(f_i, f_j, y_{i,j}, \theta_{cnn})$$

(4.5)

参数  $\theta_{id}$  和  $\theta_{cnn}$  通过随机梯度下降法在网络的迭代过程中进行更新,  $m$  一般设置为 1。

表 4.1 Siamese 算法流程

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 输入: 一系列带有标签的训练集 $\mathcal{X} = \{(x_i, l_i)\}$ , 其中 $x_i$ 输入图像, $l_i$ 为样本标签, 初始化参数 $\theta_{id}$ 和 $\theta_{cnn}$ , 超参数 $\lambda$ , 初始学习率 $\eta(t)$ , $t \leftarrow 0$                                                                                                                                                                                                                                                                                                                                                   |
| 当 loss 值不收敛时,                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| 令 $t \leftarrow t + 1$ , 从训练集 $\mathcal{X}$ 中选取两个训练样本 $(x_i, l_i)$ 和 $(x_j, l_j)$                                                                                                                                                                                                                                                                                                                                                                                                                                        |
| $f_i = f(x_i, \theta_{cnn})$ , $f_j = f(x_j, \theta_{cnn})$ ,                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| $\frac{\partial L}{\partial \theta_{id}} = \frac{\partial L_{Iden}}{\partial \theta_{id}} = \sum_i \frac{\partial L_{Iden}}{\partial fc8_i} \cdot \frac{\partial fc8_i}{\partial \theta_{id}}$                                                                                                                                                                                                                                                                                                                           |
| $\frac{\partial L}{\partial \theta_{cnn}} = \frac{\partial L_{Iden}}{\partial \theta_{cnn}} + \lambda \frac{\partial L_{Ver}}{\partial \theta_{cnn}}$                                                                                                                                                                                                                                                                                                                                                                    |
| $\frac{\partial L_{Iden}}{\partial \theta_{cnn}} = \sum_i \frac{\partial L_{Iden}}{\partial f_i} \cdot \frac{\partial f_i}{\partial \theta_{cnn}}$                                                                                                                                                                                                                                                                                                                                                                       |
| $\frac{\partial L_{Ver}}{\partial \theta_{cnn}} = \sum_{i,j} \left( \frac{\partial f_i}{\partial \theta_{cnn}} - \frac{\partial f_j}{\partial \theta_{cnn}} \right) (f_i - f_j)$                                                                                                                                                                                                                                                                                                                                         |
| $\frac{\partial f_i}{\partial \theta_{cnn}} = \begin{pmatrix} \frac{\partial f_{i,1}}{\partial \theta_{cnn,1}} & \frac{\partial f_{i,2}}{\partial \theta_{cnn,1}} & \dots & \frac{\partial f_{i,512}}{\partial \theta_{cnn,1}} \\ & & \dots & \\ \frac{\partial f_{i,1}}{\partial \theta_{cnn,N}} & \frac{\partial f_{i,2}}{\partial \theta_{cnn,N}} & \dots & \frac{\partial f_{i,512}}{\partial \theta_{cnn,N}} \end{pmatrix}$ , $\frac{\partial f_i}{\partial \theta_{cnn}}$ 是一个 $N \times 512$ 的矩阵, $N$ 为 CNN 的参数个数。 |
| 更新 $\theta_{id} = \theta_{id} - \eta(t) \cdot \theta_{id}$ , $\theta_{cnn} = \theta_{cnn} - \eta(t) \cdot \theta_{cnn}$ 。                                                                                                                                                                                                                                                                                                                                                                                                |
| 结束一次迭代。                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |

4.1.6 Caffe 下的网络模型训练

本章重新训练了一个神经网络模型，在训练的过程中，由于数据样本较少，因此初始学习率不能设置过大，学习率太大会导致网络的输出溢出 float，通过实验验证，最终将学习率设置为 0.001，既能保证网络快速收敛也不会发生溢出。训练过程中使用 GPU 技术训练网络。本章的网络训练时使用的训练参数如下表所示：

| 表 4.2 训练时网络模型参数设置 |        |
|-------------------|--------|
| 参数变量              | 参数值    |
| 初始学习率             | 0.001  |
| 优化方法              | SGD    |
| gamma             | 0.1    |
| 步率                | 100000 |
| 显示值               | 200    |
| 最大迭代次数            | 400000 |
| momentum          | 0.9    |
| weight_decay      | 0.0005 |
| 映射                | 10000  |
| solver_mode       | GPU    |

4.2 度量学习方法

本章在训练卷积神经网络的过程中已经加入了度量学习。在以往的工作中，如果将特征学习和度量学习联合训练的话，一般只采用简单的欧式距离进行相似度比较。因此我们首先将得到的特征用欧式距离进行 CMC 评估，在 VIPeR 数据集上的 Rank-1 指标达到了 23.5%。但在后续的实验中我们发现即使是联合训练得到的特征，测试时如果进一步采用度量学习方法进行相似度度量，性能仍会有较大提高。在对多种度量学习方法进行比较后，本章选取 KISSME 算法对本章得到的卷积神经网络特征进行相似度评估。

KISSME 算法是由 Kostinger<sup>[17]</sup>等人从统计学角度提出的度量学习方法。对

于两个行人 $(i, j)$ ，它们之间的相似度可以表示如下：

$$S(i, j) = \log \left( \frac{P_0(i, j)}{P_1(i, j)} \right) \quad (4.6)$$

其中， $P_0(i, j)$  表示两个行人为不同目标的概率， $P_1(i, j)$  表示两个行人为同一目标的概率。函数的值越小，表示两个行人为同一行人的概率也越大。

设行人 $i$ 的特征向量是 $x_i$ ，行人 $j$ 的特征向量是 $x_j$ ，则上式从原始空间映射到特征空间表示如下：

$$S(x_i, x_j) = \log \left( \frac{f_0(x_i, x_j)}{f_1(x_i, x_j)} \right) \quad (4.7)$$

在 KISSME 算法中， $f_0(x_i, x_j)$  和  $f_1(x_i, x_j)$  在特征空间中服从正态分布，均值为 0，协方差矩阵为  $\Sigma_{y_{ij}=0}$  和  $\Sigma_{y_{ij}=1}$ ， $y_{ij}=0$  表示不同行人， $y_{ij}=1$  表示相同行人。

$f_0(x_i, x_j)$  和  $f_1(x_i, x_j)$  的正态分布公式如下<sup>[17]</sup>：

$$P_0(x_i, x_j) = \frac{1}{\sqrt{2\pi} |\Sigma_{y_{ij}=0}|} e^{-\frac{1}{2}(x_i, x_j)^T \Sigma_{y_{ij}=0}^{-1} (x_i, x_j)} \quad (4.8)$$

$$P_1(x_i, x_j) = \frac{1}{\sqrt{2\pi} |\Sigma_{y_{ij}=1}|} e^{-\frac{1}{2}(x_i, x_j)^T \Sigma_{y_{ij}=1}^{-1} (x_i, x_j)} \quad (4.9)$$

其中，

$$\Sigma_{y_{ij}=0} = \sum_{y_{ij}=0} (x_i - x_j)(x_i - x_j)^T \quad (4.10)$$

$$\Sigma_{y_{ij}=1} = \sum_{y_{ij}=1} (x_i - x_j)(x_i - x_j)^T \quad (4.11)$$

将 (4.8) 和 (4.9) 代入 (4.7)，转化为求：

$$S(x_i, x_j) = \log \left( \frac{1}{\sqrt{2\pi} |\Sigma_{y_{ij}=1}|} \right) - \log \left( \frac{1}{\sqrt{2\pi} |\Sigma_{y_{ij}=0}|} \right) + \frac{1}{2}(x_i - x_j)^T \Sigma_{y_{ij}=1}^{-1} (x_i - x_j) - \frac{1}{2}(x_i - x_j)^T \Sigma_{y_{ij}=0}^{-1} (x_i - x_j) \quad (4.12)$$

由于相似度函数  $S(x_i, x_j)$  中的常数不会对相似度度量的结果产生任何影响, 因此我们忽略上式中的常数项系数, 将公式进一步简化得到:

$$\begin{aligned} S(x_i, x_j) &= (x_i - x_j)^T \Sigma_{y_{ij}=1}^{-1} (x_i - x_j) - (x_i - x_j)^T \Sigma_{y_{ij}=0}^{-1} (x_i - x_j) \\ &= (x_i - x_j)^T (\Sigma_{y_{ij}=1}^{-1} - \Sigma_{y_{ij}=0}^{-1}) (x_i - x_j) \end{aligned} \quad (4.13)$$

最后, 作者得到了能反映对数似然比检验的马氏距离度量:

$$d_M^2(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j) \quad (4.14)$$

其中  $M = \Sigma_{y_{ij}=1}^{-1} - \Sigma_{y_{ij}=0}^{-1}$ 。Kostinger 等人提出的 KISSME 算法思路是首先直接在原始特征空间中通过测度学习算法学习到测度矩阵, 然后求得矩阵所对应的相似度函数。

### 4.3 实验结果分析

本章选取 VIPeR 和 iLIDS 两个存在视角变化的公开数据集进行实验。

在训练网络之前, 我们将两个数据集中的图像样本统一为  $128 \times 48$  的大小。在训练 VIPeR 数据集的卷积神经网络模型时, 我们在数据集中随机 316 个行人共 632 张图像作为训练集进行网络的训练, 剩下的一半行人作为测试集进行后续的度量学习。同时由于 Siamese 网络需要输入一对图像, 因此我们将每个行人的两个图像样本生成一个正样本对, 并随机从剩下的行人样本中抽取 10 个样本生成 10 个负样本对, 进行网络的训练。同理, 在 iLIDS 数据集上随机选取 69 个行人作为训练集进行模型的训练。

在进行评估的时候, 采用了<sup>[24]</sup>中提供的工具, 在 VIPeR 数据集的测试集测试集中随机选取 200 个行人, 共 400 个图像。实验时将相机 A 中的图像作为待测试库 (probe set), 相机 B 中的图像作为候选库 (gallery set)。将一幅测试图像与候选库中的每幅图像的距离进行相似度排序。使用 CMC 方法对度量结果进行评估, 实验一共进行 10 次测试, 计算平均值作为最终结果。

由于在训练卷积神经网络的过程中已经加入了度量学习, 因此我们首先将得到的特征用欧式距离进行 CMC 评估, 在 VIPeR 数据集上的 Rank-1 指标达到了



23.5%。然后我们对联合训练得到的特征使用 KISSME 方法进行评估，实验结果得到了很大的提升， Rank -1 指标提升到了 41.8%。

在 VIPeR 数据集上与<sup>[24]</sup> 中自带的 HistLBP 特征同样使用 KISSME 比较如图 4.5。HistLBP 的 Rank -1 指标是 23%，远低于我们的 CNN 特征 41.8%。这个结果说明用同样的度量方法我们提取的 CNN 特征比人工特征 HistLBP 有很大的优势。




图 4.5 Viper 数据集上 CNN 和 HistLBP 算子使用 KISSME 的 CMC 曲线

我们将在 VIPeR 数据集上的实验结果与其他主流算法做了比较，如表 4.3 所示。可以看得出，我们的模型在 Rank -1 指标上优于大多数算法。在<sup>[34]</sup>中，作者将卷积神经网络得到特征和手工提取的颜色特征相结合，共同送入一个 SoftMax 分类器中进行训练，取得了最好的结果 51.06%。

表 4.3 Viper 数据集上与其他主流算法的比较 (%)

| Rank                                  | 1      | 5      | 10     | 20    |
|---------------------------------------|--------|--------|--------|-------|
| Our Model                             | 41.8   | 65.9   | 74.7   | 82.5  |
| HistLBP+KISSME <sup>[24]</sup>        | 23.9   | 53.6   | 68.5   | 82.4  |
| Deep feature learning <sup>[29]</sup> | 40.5   | 60.8   | 70.4   | 78.3  |
| FNN+CNN <sup>[34]</sup>               | 51.06  | 81.01  | 91.39  | 96.90 |
| LOMO+XQDA <sup>[8]</sup>              | 40     | 67.4   | 80.51  | 91.08 |
| LADF <sup>[10]</sup>                  | 29.34  | 61.04  | 75.98  | 88.10 |
| kBiCov <sup>[62]</sup>                | 31.11  | -      | 70.71  | 82.45 |
| 文献 <sup>[63]</sup>                    | 35. 1  | 64. 9  | 77. 1  | 88. 7 |
| ELF <sup>[5]</sup>                    | 12     | -      | 44     | 61    |
| 文献 <sup>[64]</sup>                    | 29. 93 | 52. 58 | 64. 72 | 77. 6 |

另外，我们也在 iLIDS 数据集上与其他主流算法做了比较，结果如表 4.4 所示。我们的 Rank -1 指标 54.3% 优于人工特征<sup>[24, 62, 63]</sup>，也优于深度特征 DARI<sup>[31]</sup>和基于 Triplet 网络的深度特征<sup>[29]</sup>。

表 4.4 iLIDS 数据集上与其他主流算法的比较 (%)

| Rank                                  | 1     | 5     | 10    | 20    |
|---------------------------------------|-------|-------|-------|-------|
| Our Model                             | 54.3  | 73.7  | 82    | 90.1  |
| HistLBP+KISSME <sup>[24]</sup>        | 29.4  | 54.9  | 68.8  | 82.1  |
| Deep feature learning <sup>[29]</sup> | 52.1  | 68.2  | 78.0  | 88.8  |
| kBiCov <sup>[62]</sup>                | 39.17 | 68.19 | 82.10 | 89.53 |
| DARI <sup>[31]</sup>                  | 42.8  | -     | -     | -     |
| 文献 <sup>[63]</sup>                    | 42. 8 | 68. 8 | 79. 2 | 93. 9 |

4.4 本章工作总结

本章对卷积神经网络在行人重识别领域进行了深入的研究。本章提出了一个基于卷积神经网络的行人重识别模型。我们设计了一个适用于行人的卷积神经网络，作为孪生网络的子网络，并在孪生网络中增加了分类层，从而提取出有判别力的行人特征。对深度特征进一步通过度量学习，进行行人相似性度量。在实验中文本的算法达到了很好的识别效果，优于大多数现有模型。

## 第5章 总结与展望

### 5.1 论文总结

行人重识别是计算机视觉领域一项很重要的课题,是智能视频监控系统的核心技术。随着深度学习在计算机视觉中的广泛应用,学者们将深度学习应用到行人重识别中,在近几年取得了不错的识别效果。本文是基于深度学习中的卷积神经网络在行人重识别中的应用研究。

本文的前两章简单的介绍了行人重识别的研究背景和意义,行人重识别领域的传统的基于手工的算法以及近几年出现的基于卷积神经网络的算法,并简要介绍了行人重识别领域常用的公开数据库。

本文研究了针对行人重识别问题的深度学习模型。主要创新点包括:

①将卷积神经网络用于行人特征提取,因为行人数据库样本较少,我们将 ImageNet 训练好的 AlexNet 进行微调训练,得到新的网络模型来提取行人特征,最后采用 kLFDA 距离度量算法对得到的特征进行相似度度量。实验证明 AlexNet 可以有效地用于行人重识别,其性能优于目前的基于人工特征的算法。

②提出了一种改进的 Siamese 结构,设计了行人专用的卷积神经网络。我们在损失函数中结合了 SoftMax 损失和对比损失。该模型在行人重识别数据库上取得了很好的识别效果。

③将匹配模型与度量学习结合。在匹配模型 (Siamese, Triplet) 中一般只采用欧式距离作为相似性度量。我们发现用匹配模型进行特征提取后,再与距离度量算法结合,识别效果会有大幅提升。

### 5.2 后续工作展望

本文的研究虽然有一些结果,但是对于整个行人重识别领域而言,还有很多

研究需要进行，从实际应用的角度，接下来我们的工作将主要从以下几点展开：

1、本文只在 VIPeR 和 iLIDS 两个小型数据集上对改进 Siamese 网络进行了实验。在文献<sup>[45, 46]</sup>中提到，使用在大规模数据集上训练的模型具有很好的泛化能力，可以应用于不同的数据集进行特征提取，避免了每个数据集训练网络带来的耗时过多和过拟合的缺点。但如今，行人重识别领域尚且没有一个拥有大量行人样本的数据库。在下一步，我们将寻找或者建立一个大型的行人重识别数据库，并在该数据库上进行网络的训练。

2、目前的研究是建立在图像的基础上进行的，但是在实际生活中，应该是从监控视频中展开行人重识别的研究的。因此，下一步我们将尝试建立基于视频的三维卷积神经网络模型，将输入由图像改为视频流。

## 附录

攻读硕士学位期间取得的科研成果：

[1] 图像检索管理操作系统 V1.0，登记号 2017SR076683（软件著作权）

## 参考文献

- [1]Gong S, Cristani M, Yan S, et al. Person Re-Identification[M]. Springer London, 2014.
- [2]Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998,86(11):2278-2324.
- [3]Gheissari N, Sebastian T B, Hartley R. Person Reidentification Using Spatiotemporal Appearance: IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2006[C].
- [4]Gray D, Brennan S, Tao H. Evaluating appearance models for recognition, reacquisition, and tracking[J]. 2007.
- [5]Gray D, Tao H. Viewpoint Invariant Pedestrian Recognition with an Ensemble of Localized Features: European Conference on Computer Vision (ECCV), European, Marseille, France, 2008[C].
- [6]Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features: Computer Vision and Pattern Recognition (CVPR), IEEE, San Francisco, USA, 2010[C]. IEEE.
- [7]Ma B, Su Y, Jurie F. Local Descriptors Encoded by Fisher Vectors for Person Re-identification: International Conference on Computer Vision, 2012[C].
- [8]Liao S, Hu Y, Zhu X, et al. Person re-identification by Local Maximal Occurrence representation and metric learning: Computer Vision and Pattern Recognition(CVPR), IEEE, Boston, MA, USA, 2015[C]. IEEE.
- [9]Zhao R, Ouyang W, Wang X. Unsupervised Saliency Learning for Person Re-identification: Computer Vision and Pattern Recognition (CVPR), IEEE, Portland, Oregon, USA, 2013[C]. IEEE.
- [10]Li Z, Chang S, Liang F, et al. Learning Locally-Adaptive Decision Functions for

- Person Verification: Computer Vision and Pattern Recognition(CVPR), IEEE, Portland, Oregon, 2013[C]. IEEE.
- [11]Pedagadi S, Orwell J, Velastin S, et al. Local Fisher Discriminant Analysis for Pedestrian Re-identification: Computer Vision and Pattern Recognition(CVPR), IEEE, Providence, Rhode Island, 2013[C]. IEEE.
- [12]Layne R, Hospedales T M, Gong S. Person Re-identification by Attributes: BMVC, 2012[C].
- [13]Liu X, Song M, Zhao Q, et al. Attribute-restricted latent topic model for person re-identification[J]. Pattern Recognition, 2012,45(12):4204-4213.
- [14]Liu C, Gong S, Loy C C, et al. Person re-identification: what features are important? International Conference on Computer Vision, 2012[C].
- [15]Karanam S, Gou M, Wu Z, et al. A Comprehensive Evaluation and Benchmark for Person Re-Identification: Features, Metrics, and Datasets: Computer Vision and Pattern Recognition(CVPR), IEEE, Honolulu, Hawaii, USA, 2016[C]. IEEE.
- [16]Zheng L, Yang Y, Hauptmann A G. Person Re-identification: Past, Present and Future[J]. 2016.
- [17]Köstinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints: Computer Vision and Pattern Recognition(CVPR), IEEE, Providence, Rhode Island, 2012[C]. IEEE.
- [18]Weinberger K Q, Saul L K. Distance Metric Learning for Large Margin Nearest Neighbor Classification[J]. Journal of Machine Learning Research, 2009,10(1):207-244.
- [19]Davis J V, Kulis B, Jain P, et al. Information-theoretic metric learning: Machine Learning, Proceedings of the Twenty-Fourth International Conference, 2007[C].
- [20]Hirzer M, Roth P M, Stinger M, et al. Relaxed pairwise learned metric for person re-identification: European Conference on Computer Vision, 2012[C].
- [21]Chen D, Yuan Z, Hua G, et al. Similarity learning on an explicit polynomial

- kernel feature map for person re-identification: Conference on Computer Vision and Pattern Recognition, 2015[C].
- [22]Liao S, Li S Z. Efficient PSD Constrained Asymmetric Metric Learning for Person Re-Identification: IEEE International Conference on Computer Vision, 2015[C].
- [23]Jurie F, Mignon A. PCCA: A new approach for distance learning from sparse pairwise constraints: Computer Vision and Pattern Recognition, 2012[C].
- [24]Gou M, Xiong F, Camps O, et al. Person Re-Identification Using Kernel-Based Metric Learning Methods: European Conference on Computer Vision(ECCV), European, Zurich, Switzerland, 2014[C].
- [25]Engel C, Baumgartner P, Holzmann M, et al. Person Re-Identification by Support Vector Ranking.: British Machine Vision Conference, BMVC 2010, Aberystwyth, UK, August 31 - September 3, 2010. Proceedings, 2010[C].
- [26]Liu X, Wang H, Wu Y, et al. An Ensemble Color Model for Human Re-identification: Applications of Computer Vision, 2015[C].
- [27]Yi D, Lei Z, Liao S, et al. Deep Metric Learning for Person Re-identification: International Conference on Pattern Recognition(ICPR), Stockholm, Sweden, 2014[C].
- [28]Wang J, Song Y, Leung T, et al. Learning Fine-Grained Image Similarity with Deep Ranking: IEEE Conference on Computer Vision and Pattern Recognition, 2014[C].
- [29]Ding S, Lin L, Wang G, et al. Deep feature learning with relative distance comparison for person re-identification[J]. Pattern Recognition, 2015,48(10):2993-3003.
- [30]Cheng D. Person Re-Identification by Multi-Channel Parts-Based CNN With Improved Triplet Loss Function: Computer Vision and Pattern Recognition (CVPR), Nevada, USA, 2016[C]. IEEE.



- [31]Wang G, Lin L, Ding S, et al. DARI: Distance metric And Representation Integration for Person Verification[J]. 2016.
- [32]Zhang R, Lin L, Zhang R, et al. Bit-Scalable Deep Hashing With Regularized Similarity Learning for Image Retrieval and Person Re-Identification.[J]. Image Processing IEEE Transactions on, 2015,24(12):4766.
- [33]Xiao T, Li H, Ouyang W, et al. Learning Deep Feature Representations with Domain Guided Dropout for Person Re-identification[J]. 2016.
- [34]Wu S, Chen Y C, Li X, et al. An enhanced deep feature representation for person re-identification: Winter Conference on Applications of Computer Vision (WACV) , IEEE, Lake Placid, NY, USA, 2016[C]. IEEE.
- [35]Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification: Computer Vision and Pattern Recognition (CVPR) , IEEE, Columbus, OH, USA, 2015[C]. IEEE.
- [36]Li W, Zhao R, Xiao T, et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification: IEEE Conference on Computer Vision and Pattern Recognition, 2014[C].
- [37]Chen S Z, Guo C C, Lai J. Deep Ranking for Person Re-identification via Joint Representation Learning[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2016,25(5):2353-2367.
- [38]Wang F, Zuo W, Lin L, et al. Joint Learning of Single-Image and Cross-Image Representations for Person Re-identification: IEEE Conference on Computer Vision and Pattern Recognition, 2016[C].
- [39]Chen D, Cao X, Wang L, et al. Bayesian face revisited: a joint formulation: European Conference on Computer Vision (ECCV), European, Florence, Italy, 2012[C].
- [40]He X, Niyogi P. Locality Preserving Projections (LPP)[J]. Advances in Neural Information Processing Systems, 2002,16(1):186-197.

- [41]Fisher R. A. The Use of Multiple Measurements in Taxonomic Problems[J].  
Annals of Human Genetics, 1936,7(2):179-188.
- [42]Hu J, Lu J, Tan Y P. Discriminative Deep Metric Learning for Face Verification  
in the Wild: Computer Vision and Pattern Recognition (CVPR) , IEEE,  
Columbus, OH, USA, 2014[C]. IEEE.
- [43]Zheng W S, Gong S, Xiang T. Associating Groups of People: British Machine  
Vision Conference, BMVC 2009, London, UK, September 7-10, 2009.  
Proceedings, 2009[C].
- [44]Li W, Zhao R, Wang X. Human reidentification with transferred metric learning:  
Asian Conference on Computer Vision, 2012[C].
- [45]Donahue J, Jia Y, Vinyals O, et al. DeCAF: A Deep Convolutional Activation  
Feature for Generic Visual Recognition: Advances in Neural Information  
Processing Systems (NIPS) , Lake Tahoe, USA, 2012[C]. NIPS.
- [46]Razavian A S, Azizpour H, Sullivan J, et al. CNN Features Off-the-Shelf: An  
Astounding Baseline for Recognition: Computer Vision and Pattern  
Recognition(CVPR), IEEE, Columbus, USA, 2014[C]. IEEE.
- [47]Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image  
database: Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE  
Conference on, 2009[C].
- [48]Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep  
convolutional neural networks: International Conference on Neural Information  
Processing Systems, 2012[C].
- [49]He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional  
Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis &  
Machine Intelligence, 2014,37(9):1904-1916.
- [50]UFLDL. Neural Networks[EB/OL].  
[http://deeplearning.stanford.edu/wiki/index.php/Neural\\_Networks](http://deeplearning.stanford.edu/wiki/index.php/Neural_Networks).

- [51]Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. Computer Science, 2012,3(4):212-223.
- [52]Jia, Yangqing, Shelhamer, et al. Caffe: Convolutional Architecture for Fast Feature Embedding[J]. Eprint Arxiv, 2014:675-678.
- [53]Dong S C, Cristani M, Stoppa M, et al. Custom Pictorial Structures for Re-identification: British Machine Vision Conference, 2011[C].
- [54]Avraham T, Gurvich I, Lindenbaum M, et al. Learning implicit transfer for person re-identification: International Conference on Computer Vision, 2012[C].
- [55]Zheng W S, Gong S, Xiang T. Person re-identification by probabilistic relative distance comparison: Computer Vision and Pattern Recognition, 2011[C].
- [56]Ma B, Su Y, Jurie F. BiCov: a novel image representation for person re-identification and face verification, 2012[C].
- [57]Ilyas A, Scuturici M, Miguet S. Inter-camera color calibration for object re-identification and tracking: Soft Computing and Pattern Recognition, 2010[C].
- [58]Zhao R, Ouyang W, Wang X. Learning Mid-level Filters for Person Re-identification: Computer Vision and Pattern Recognition, 2014[C].
- [59]Zhao R, Ouyang W, Wang X. Person Re-identification by Saliency Matching: IEEE International Conference on Computer Vision, 2013[C].
- [60]Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, 2014.
- [61]Hadsell R, Chopra S, Lecun Y. Dimensionality Reduction by Learning an Invariant Mapping: Computer Vision and Pattern Recognition (CVPR), IEEE, New York, USA, 2006[C]. IEEE.
- [62]Ma B, Su Y, Jurie F. Covariance descriptor based on bio-inspired features for person re-identification and face verification ☆[J]. Image & Vision Computing, 2014,32(6-7):379-390.

- [63]张耿宁, 王家宝, 李阳, 等. 基于特征融合与核局部Fisher判别分析的行人重识别[J]. 计算机应用, 2016,36(9):2597-2600.
- [64]陈莹, 霍中花. 多方向显著性权值学习的行人再识别[J]. 中国图象图形学报, 2015,20(12):1674-1683.

## 致谢

时间如流水，在华东师范大学的三年研究生即将结束，在这三年里，我学到了很多知识。感谢家人的支持，导师的指导，朋友的陪伴，让我顺利的渡过了三年的研究生生涯。

首先，我要感谢我的导师。她的指导深入到学习的每个细节中，对我的论文选题和研究内容进行了全面的指导。在最开始的选题过程中，导师给了我很多建议；在实验的过程中，与导师的讨论推进本文的实验的进行，给了我许多实验的思路；在最后论文写作的过程中，会指出论文写作中的各种不足，帮助我不断完善论文细节。

其次，我要感谢实验室的同学们。与他们渡过了三年时光，他们对知识的渴望和梦想的追求深深的感染了我。在我实验、写论文的过程中给我提供了很多帮助，在与他们的讨论中开阔了我的思路。

最后，我要感谢我家人朋友的支持和陪伴，他们是我不断学习和进步的力量之源。