

西安电子科技大学

硕士学位论文



基于深度学习的行人重识别技术研究

作者姓名_____李强_____

学校导师姓名、职称_____田玉敏 教授_____

企业导师姓名、职称_____郭向英 研究员_____

申请学位类别_____工程硕士_____

学校代码 10701
分 类 号 TN39

学 号 1603121750
密 级 公开

西安电子科技大学

硕士学位论文

基于深度学习的行人重识别技术研究

作者姓名：李强

领 域：计算机技术

学位类别：工程硕士

学校导师姓名、职称：田玉敏 教授

企业导师姓名、职称：郭向英 研究员

学 院：计算机科学与技术学院

提交日期：2019 年 6 月

Research on Person Re-identification Technology Based on Deep Learning

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Computer Technology

By

Li Qiang

Supervisor: Yumin Tian Title: Professor

Supervisor: Xiangying Guo Title: Researcher

June 2019

摘要

随着当今时代的发展,社会安全问题越来越受到公众的重视。城市智能监控作为防治公共犯罪的重要手段,在公共场所秩序管理、大型案件侦破以及嫌疑人追踪等方面的作用日益凸显。作为智能安全领域的主要研究方向之一,行人重识别(Person Re-identification)是一种利用计算机视觉算法在给定的图像集或视频序列中查找特定行人的技术。然而由于实际应用场景较为复杂,导致难以提取行人具有辨别力的有效特征,这给行人重识别任务带来了极大挑战。此外,传统检索方法无法满足海量视频数据任务需求的问题也逐渐浮现,因此如何准确且快速地定位目标行人成为亟待解决的问题。

深度学习算法可以自适应地学习图像的有效特征,避免了人工设计和选择特征的弊端,并且可以适应大数据时代的数据量需求。因此,本文使用基于深度学习的方法,从以下几个方面对行人重识别技术进行研究。

(1) 针对大部分相关数据集中行人图像数量不足的问题,本文提出了一种基于生成式对抗网络的数据增强模型 PersonGAN。该模型以 CycleGAN 为基础,并对网络进行相应改进,以适应行人重识别任务的需求。同时,本文设计了一种恒等映射损失(identity mapping loss)约束网络模型,从而可生成不同摄像头风格的行人图像。PersonGAN 不仅可以有效地扩充数据集,而且能够生成一些识别难度更大的样本,给训练提供新的动量,使模型具有更强的鲁棒性和更广泛的适用性。

(2) 针对难以提取行人具有辨别力特征的问题,本文提出了一种鲁棒联合学习网络(Robust Joint Learning Networks, RJLN)。RJLN 是基于表征学习的网络模型,首先通过基础网络提取行人的低级特征,然后使用改进的全局分支网络和改进的局部分支网络分别提取目标行人的全局特征和局部特征,以适应提取不同粒度特征的需求,提高模型的学习能力,从而使模型的识别准确率和鲁棒性得到显著提升。最后,融合两个分支网络的损失函数,作为 RJLN 的总体损失函数。

(3) 针对局部特征的提取问题,本文提出了一种结构简洁、性能优良的强化局部基础网络(Strong Part-base Networks, SP_Net)。与利用骨架关键点定位、姿态估计等局部特征提取方法不同,该模型直接以特征图水平分割后的条纹作为网络输入,之后通过全局平均池化从水平条纹中学习细粒度特征。为了提升模型的识别准确率和鲁棒性,本文在 SP_Net 中添加核尺寸为 1×1 的卷积层进行降维,并通过随机失活层和批正则化层来防止过拟合。

通过在 Market-1501、DukeMTMC-reID、CUHK03 等数据集上进行实验,本文对模型性能的提升进行了验证。实验结果证明,改进后的算法在三个数据集上的 rank-k

准确率和 mAP 均有明显提高，与目前基于深度学习的行人重识别其他算法相比也具有一定的优越性。

关 键 词：行人重识别， 深度学习， 数据增强， 生成式对抗网络， 联合学习

ABSTRACT

With the development of the current times, more and more public have paid attention to the social security. As a significant means of preventing and controlling public crimes, urban intelligent monitoring is playing an increasingly prominent role in public place management, large-scale case detection and suspect tracking. As one of the main research directions in the field of intelligent security, Person re-identification is a technology that using computer vision algorithms to find specific pedestrians in a given image set or video sequence. However, due to the complexity of the practical application scenario, it is difficult to extract the effective features of pedestrians with discrimination, which brings great challenges to the task of person re-identification. In addition, the problem that the traditional retrieval method can not meet the task requirements of massive video data is gradually emerging. As a result, how to locate the target pedestrian accurately and quickly becomes an urgent problem to be solved.

The deep learning methods can adaptively learn the effective features of the image, so avoiding the disadvantages of manual design and selection of features, and can adapt to the data volume requirements of the big data times. Therefore, this thesis uses the method based on deep learning to study the person re-identification technology from the following aspects:

First, for the problem that the images in most pedestrian datasets is insufficient, this thesis proposes a data augmentation model named PersonGAN which based on the generative adversarial networks. The model is based on CycleGAN and the network is modified to adopt to the needs of pedestrian recognition tasks. At the same time, this thesis designs an identity mapping loss to constraint network model, so as to generate pedestrian images with different camera styles. PersonGAN can not only effectively expand the dataset, but also can generate some samples that are more difficult to identify, so that providing a new momentum for training, and making the model more robust and widely applicable. :

Second, in view of the problem that it is difficult to extract the discriminative features of pedestrians, this thesis proposes a Robust Joint Learning Networks (RJLN). RJLN is a network model based on representation learning. Firstly, the low-level features of

pedestrians are extracted through the basic network. Then the improved global branch network and the improved local branch network are used to extract the global features and local features of the target pedestrians respectively, so as to adapt to extract different granularity features and enhance the learning ability of the model, so that the identification accuracy and robustness of the model are significantly improved. Finally, the loss function of the two branch networks is merged as the overall loss function of RJLN.

Third, aiming at the extraction of local features, a Strong Part-base Networks(SP_Net) with simple structure and excellent performance is proposed in this thesis. Different from the local feature extraction methods such as skeleton key point location and pose estimation, The model directly uses the horizontally partition stripes of the person feature map as the network input, and then learns the fine-grained features from the horizontal stripes through the global average pooling. In order to improve the identification accuracy and robustness of the model, a convolutional layer with a kernel size of 1×1 is added to the SP_Net for reducing the dimension, and the over-fitting is prevented by the dropout layer and the batch normalize layer.

Through experiments on Market-1501, DukeMTMC-reID, CUHK03 and other datasets, this thesis verifies the improvement of the model. The experimental results show that the improved methods has significantly higher rank-k accuracy and mAP on the three data sets, and outperforms existing deep learning methods.

Keywords: Person Re-identification, Deep Learning, Data Augmentation, Generative Adversarial Networks, Joint Learning

插图索引

图 1.1	行人图像中的难样本展示.....	1
图 1.2	本文研究内容结构图.....	6
图 2.1	多层前馈网络结构示意图.....	10
图 2.2	卷积过程示意图.....	14
图 2.3	均值池化和最大池化过程示意图.....	15
图 2.4	ReLU 及其改进版本示意图.....	16
图 2.5	全连接层示意图.....	17
图 2.6	行人重识别流程示意图.....	18
图 2.7	CMC 曲线示意图.....	19
图 2.8	P-R 曲线示意图.....	20
图 3.1	GAN 网络示意图.....	23
图 3.2	配对图像与非配对图像对比图.....	25
图 3.3	CycleGAN 示意图.....	25
图 3.4	PersonGAN 模型结构示意图.....	26
图 3.5	残差块示意图.....	27
图 3.6	PersonGAN 生成网络结构示意图.....	28
图 3.7	PersonGAN 判别网络结构示意图.....	30
图 3.8	Market-1501 数据集摄像头风格转换结果图.....	34
图 3.9	DukeMTMC-reID 数据集摄像头风格转换结果图.....	35
图 3.10	CUHK03 数据集摄像头风格转换结果图.....	36
图 3.11	重建图像对比图.....	37
图 3.12	不同 GAN 模型生成图像对比图.....	38
图 4.1	RJLN 算法框架示意图.....	41
图 4.2	SP_Net 框架示意图.....	44
图 4.3	标签为-1 的不完整行人示例图.....	46
图 4.4	随机擦除示意图.....	47
图 4.5	行人重识别的可视化结果图.....	51
图 4.6	不同分块数与 rank-1 准确率坐标图.....	52
图 4.7	不同分块数与 mAP 坐标图.....	52
图 4.8	局部损失函数权重与 rank-1 准确率坐标图.....	54
图 4.9	局部损失函数权重与 mAP 坐标图.....	54

表格索引

表 3.1	PersonGAN 生成网络相关参数.....	29
表 3.2	PersonGAN 判别网络相关参数.....	31
表 3.3	PersonGAN 实验配置.....	33
表 3.4	PersonGAN 实验参数设置.....	33
表 3.5	添加恒等映射损失前后 SSIM 对比.....	38
表 4.1	不同数据增强方法在 Market-1501 数据集的实验对比.....	48
表 4.2	不同数据增强方法在 DukeMTMC-reID 数据集的实验对比.....	48
表 4.3	不同数据增强方法在 CUHK03 数据集的实验对比.....	48
表 4.4	不同分支网络在 Market-1501 数据集上的实验对比.....	49
表 4.5	不同分支网络在 DukeMTMC-reID 数据集上的实验对比.....	49
表 4.6	不同分支网络在 CUHK03 数据集上的实验对比.....	49
表 4.7	RJLN 与不同模型在 Market-1501 数据集上的实验对比.....	55
表 4.8	RJLN 与不同模型在 DukeMTMC-reID 数据集上的实验对比.....	55
表 4.9	RJLN 与不同模型在 CUHK03 数据集上的实验对比.....	56

符号对照表

符号	符号名称
m	多层神经网络中输入神经元数量
m	多层神经网络中输入神经元数量
q	多层神经网络中隐层神经元数量
n	多层神经网络中输出神经元数量
v_{ik}	多层神经网络中输入层神经元与隐层神经元之间的权值
ω_{kj}	多层神经网络中隐层神经元与输出层神经元之间的权值
a_k	多层神经网络中隐层神经元接收到的输入
β_j	多层神经网络中输出层神经元接收到的输入
θ_k	多层神经网络中隐层神经元的阈值
γ_j	多层神经网络中输出层神经元的阈值
f	多层神经网络中隐层和输出层的激活函数
$\hat{y}_t$	多层神经网络输出
$f(\bullet)$	多层神经网络中隐层和输出层的激活函数
$g(\bullet)$	残差网络激活函数
$F(x)$	残差网络中定义的残差函数
$\ \cdot \ _1$	L ₁ 范式
$\ \cdot \ _2$	L ₂ 范式
G_{AB}	PersonGAN 中满足数据域映射: A→B 的生成器
G_{BA}	PersonGAN 中满足数据域映射: B→A 的生成器
D_A	PersonGAN 中判断 A 域上图像真假性的判别器
D_B	PersonGAN 中判断 B 域上图像真假性的判别器
L_{cyc}	PersonGAN 循环一致性损失
$L_{identify}$	PersonGAN 中恒等映射损失
L_{total}^P	PersonGAN 总体损失
N	RJLN 中特征向量的维度
$class$	RJLN 中行人类别标签
C	RJLN 中行人类别种类
W_{global}	RJLN 全局损失对应的权重

W_{local}	RJLN 局部损失对应的权重
L_{global}	RJLN 全局损失
L_{local}	RJLN 局部损失
L_{total}	RJLN 总体损失
M	SP_Net 中分块数目
$P(i)$	行人属于类别 i 的概率
W	SP_Net 中局部分类器的可训练矩阵

缩略语对照表

缩略语	英文全称	中文对照
BN	Batch Normalize	批正则化
BP	error BackPropagation	误差逆传播
CMC	Cumulative Match Characteristic	累计匹配特征
CNN	Convolutional Neural Networks	卷积神经网络
CycleGAN	Cycle-Consistent Adversarial Networks	循环一致性对抗网络
DL	Deep Learning	深度学习
GAN	Generative Adversarial Networks	生成式对抗网路
GAP	Global Average Pooling	全局平均池化
GLAD	Global-Local-Alignment Descriptor	全局-局部对齐描述子
LSTM	Long Short Term Memory Networks	长短时记忆网络
ML	Machine Learning	机器学习
MSGD	Mini-batch Stochastic Gradient Descent	小批量随机梯度下降
ResNet	Residual Neural Networks	残差网络
RJLN	Robust Joint Learning Networks	鲁棒联合学习网络
ROI	Region of Interest	感兴趣区域
SP_Net	Strong Part-base Networks	强化局部基础网络
SSIM	Structural Similarity	结构相似性

目录

摘要.....	I
ABSTRACT.....	III
表格索引.....	VII
符号对照表.....	IX
缩略语对照表.....	XI
第一章 绪论.....	1
1.1 研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于表征学习的行人重识别.....	3
1.2.2 基于度量学习的行人重识别.....	4
1.2.3 基于生成式对抗网络的数据增强.....	4
1.3 本文研究内容.....	5
1.4 本文组织结构.....	6
第二章 深度学习及行人重识别概述.....	9
2.1 深度学习.....	9
2.1.1 深度学习概述.....	9
2.1.2 深度学习核心算法.....	10
2.2 卷积神经网络.....	12
2.2.1 卷积神经网络概述.....	12
2.2.2 卷积神经网络基础部件.....	13
2.3 行人重识别.....	17
2.3.1 问题表述.....	17
2.3.2 评价标准.....	18
2.3.3 相关数据集.....	20
2.4 本章小结.....	22
第三章 基于生成式对抗网络的数据增强算法.....	23
3.1 生成式对抗网络.....	23
3.1.1 生成式对抗网络概述.....	23
3.1.2 生成式对抗网络算法流程.....	24
3.2 PersonGAN.....	24
3.2.1 PersonGAN 网络结构.....	24

3.2.2 PersonGAN 损失函数.....	31
3.3 实验结果与分析.....	33
3.3.1 实验配置与参数.....	33
3.3.2 PersonGAN 实验效果验证.....	34
3.3.3 恒等映射损失实验效果验证.....	36
3.3.4 与其他方法对比.....	38
3.4 本章小结.....	39
第四章 基于联合学习的行人重识别模型.....	41
4.1 联合学习算法框架 RJLN.....	41
4.1.1 全局分支网络结构设计.....	42
4.1.2 局部分支网络结构设计.....	43
4.1.3 全局分支网络与局部分支网络的融合.....	43
4.2 局部特征提取网络 SP_Net.....	44
4.2.1 SP_Net 结构设计.....	44
4.2.2 SP_Net 参数设计.....	45
4.3 实验结果与分析.....	45
4.3.1 实验配置与参数.....	45
4.3.2 不同数据增强方法对比.....	46
4.3.3 RJLN 识别准确率提升验证.....	49
4.3.4 RJLN 鲁棒性提升验证.....	50
4.3.5 不同分块数对网络的影响.....	51
4.3.6 网络权重的影响.....	53
4.3.7 与其他方法对比.....	54
4.4 本章小结.....	56
第五章 总结与展望.....	57
5.1 工作总结.....	57
5.2 未来展望.....	58
参考文献.....	59
致谢.....	65
作者简介.....	67

第一章 绪论

1.1 研究意义

随着社会的进步和发展，人们对于公共安全问题的关注与日俱增，但是在公共场所中出现暴力事件和违法行为的情况却屡见不鲜，这给社会带来了极大的潜在危害。近年来，得益于监控网络和图像采集技术地不断完善和发展，越来越多的摄像头被布置在大型商场、地铁站等公共场所，这些摄像头所采集到的视频及图像数据也在打击违法犯罪、维护公共安全乃至国防安全等诸多领域发挥着重要作用。但是，由于实际应用环境复杂，且摄像头数量众多，所获取到的数据量也十分巨大，如何准确且快速地从检索出所需要的行人信息并进行追踪，是目前亟需解决的问题。其中，行人重识别技术作为主要的研究方法之一，也越来越引起研究者的重视。

行人重识别（Person re-identification）也被称为行人再识别，是一种利用计算机视觉算法在图像或视频序列中查找特定行人的技术，即给定一个目标行人，跨设备检索该行人图像，因此通常也被认为是图像检索的一个子问题^{[1][2]}。利用该技术可以在跨设备的图像、视频中检索出特定行人目标，并能够弥补当前固定摄像头下的视角局限，在与行人检测或跟踪技术相结合后常应用于智能安保、智能视频监控、智能检索等领域。



图 1.1 行人图像中的难样本展示

但在实际场景中,由于不同摄像头拍摄的角度、光照条件和行人姿态都不尽相同,即使是同一个行人,在不同摄像头下的图片也会呈现很大差异,如图 1.1 中 (a)~(c) 所示。此外,由于视频设备性能的局限性和背景环境的复杂性,摄像头采集到的行人图像中包含一些难以识别的样本,如图 1.1 中 (d)~(h) 所示。其中包括行人比例过小、行人不完整、光线过暗、像素值过低、发生遮挡等情况,这使得细节特征(如人的面部)在重识别任务中起到的作用有限。上述客观条件的限制,给行人重识别技术的研究带来了一定程度的困难和挑战。

在行人重识别研究的早期阶段,受制于计算机硬件发展水平较低和数据集规模较小,传统的行人重识别算法复杂度较低,计算过程也较为简单。同时,早期的行人重识别研究主要集中于如何手工设计更具辨别力的视觉特征和如何学习更好的相似性度量,算法的识别准确率不高,鲁棒性较差,不能较好的应用于复杂多变的实际场景。随着硬件技术的发展和大数据时代的到来,深度学习逐渐被人们关注,其表现出的优秀性能深受研究者们欢迎。

作为机器学习(Machine Learning, ML)的重要分支之一,深度学习(Deep Learning, DL)的概念早在 19 世纪 80 年代就被提出^[3]。在 2006 年时, Hinton 正式将深度学习引入人工神经网络^[4],从而引领了一场新的科技革命。深度学习方法由多个层组成,以学习具有多个抽象层次的数据特征,它允许计算机通过相对简单的基础概念来学习复杂的高级概念。例如人工神经网络层,就具有许多隐藏层,以适用于非线性变换,将低维特征映射为高维特征,从而解决有监督或无监督的特征学习、表示、分类等问题。复杂的深度神经网络拥有出色的自学习能力,能够挖掘出图像中最关键、最具辨别力的特征,将其应用于行人重识别将有很大的优势。此外,深度学习算法具有良好的容错性,允许样本数据存在一定程度的缺损,并支持并行处理,从而能够良好地解决复杂情况下的图像处理和识别问题。

综上所述,对于实际应用场景复杂多变的行人重识别问题,采用深度学习算法进行研究将是最好的选择。将深度学习算法应用于行人重识别技术研究当中,既可以突破目前行人重识别问题的研究瓶颈,丰富行人重识别的理论研究;同时又可以为行人重识别应用于实际生活、推动智能城市的发展奠定坚实的基础。

1.2 国内外研究现状

相对于行人检测来说,行人重识别的研究还处于初期阶段。最早可追溯到 1996 年,行人重识别问题^[5]就引起了相关研究者的关注。2006 年的 CVPR 会议上,行人重识别问题被正式提出^[6],之后就迅速引起了学者们的研究兴趣。2007 年,第一个行人重识别的专用数据库 VIPeR^[7]被正式公布,该数据集的诞生标志着不同的行人重识

别算法间有了可比较的统一平台，从而可以确定它们的优劣程度。此后，行人重识别的研究越来越受到专家学者们的重视，相关的专著也不断涌现^[8]。2014年后，国内外诸多学者开始尝试将深度学习引入行人重识别研究，给该领域注入了新的活力，尤其是基于深度神经网络的方法引起了广泛的关注；2016年至今，行人重识别的研究迎来了爆发式的增长，相关数据集不断地被扩充，在各个数据集上的实验结果也获得明显的提升，每年在 CVPR、ICCV、ECCV 等顶级会议也会出现大量相关论文，已然成为计算机视觉领域最炙手可热的问题之一。

目前，行人重识别主要分为两个步骤：（1）行人有效特征的提取；（2）行人特征的距离度量，其具体过程将在 2.3.1 节中具体阐述，这里不再赘述。因此，国内外研究的基于深度学习的行人重识别问的方法主要也有两种，一种是基于特征表示的方法，主要是找到一组具有视觉区分的描述符；另一种是基于度量学习的方法，主要是学习一种合适的距离尺度函数。

1.2.1 基于表征学习的行人重识别

基于特征表示方法是一种很常用的行人重识别方法^{[9][10][11][12]}，具体可分为基于全局特征表示和基于局部特征表示两大类。在行人重识别研究的前期阶段，因为基于全局特征的方法逻辑简单且运算量小，所以更受研究者的青睐。该方法主要将整幅行人图像视作研究对象，在经过特征提取后，使用行人的全局特征来完成检索任务。但是由于全局特征具有局限性，很多细节信息无法被学习到，导致行人重识别的准确率不高。而基于局部特征表示的方法可以学习到行人的细粒度特征，因此算法的识别准确率有了很大的提升，并且鲁棒性更好。于是，许多学者开始把目光放在基于局部特征的行人重识别上，而如何有效提取局部特征成为主要的关注点。

针对局部特征的提取问题，Varior 等^[13]提出可以使用图像切块的方式对图像进行处理。虽然在图像处理领域，常见的切块方式有垂直分割和水平分割两种，但因为人体结构的特殊性，在行人重识别领域一般只采用水平分割，这也更符合大众的直观感受。在 Varior 等设计的网络模型中，首先将输入的两幅行人图像水平等分为若干图像块；然后，将分割好的若干图像块依次送到一个长短时记忆网络（Long Short Term Memory Networks, LSTM）中去提取各自的局部特征；最后，再将提取到的局部特征融合为一个全局特征去进行比对。虽然这种方法在一定程度上提高了行人重识别的准确率，但是缺点也很明显：如果进行比较的行人图像没有对齐，则很可能发生行人匹配部位不一致的现象，从而使模型判断出错。

为了解决行人图像在未对齐时可能出现较大误差的问题，Zheng 等^[14]提出可以使用姿态估计和仿射变换先将行人对齐，然后再进行重识别。在该网络中，Zheng 等首先使用已经训练好的姿态估计模型对行人图像进行预处理，获得 14 个骨架关键点；

然后,根据得到的关键点,通过仿射变换来调整相应的部分,从而实现行人对齐,并通过获得的关键点将行人划分为若干区域;最后,通过不同尺度的姿态框获取不同人体区域的局部特征。

与之类似,2017年提出的 Spindle Net^[15]也使用了 14 个骨架关键点来提取人体的局部特征。但是和 Zheng 等提出的方法不同,Spindle Net 没有进行行人对齐,而是直接通过骨架关键点来定位出 7 个人体的感兴趣区域 (Region of Interest, ROI),分别为头部、上身、下身和四肢;然后,研究人员将这些 ROI 区域送入参数共享的网络中去提取行人的局部特征,并与全局特征结合后来判定行人的类别。

除此之外,Wei 等^[16]也提出使用全局-局部对齐描述子 (Global-Local-Alignment Descriptor, GLAD) 先将行人图像对齐,然后进行水平分割,划分为头部、上身和下身三个部分,最后利用全局平均池化 (Global Average Pooling, GAP) 来提取各部分的局部特征。

1.2.2 基于度量学习的行人重识别

度量学习 (Metric learning) 是广泛用于图像检索领域的一种方法。与表征学习旨在找到最具辨别力的特征不同,度量学习的主要任务是通过训练好的网络模型计算出两张图像的相似度。具体到行人重识别问题上,研究者们希望同一行人不同图像间的相似度尽可能大,不同行人图像间的相似度尽可能小。在早期基于深度学习的图像检索研究中,孪生神经网络是最常用的模型之一。2014 年,Li 等人^[17]首次将该模型引入到行人重识别领域中,取得了突破性的进展。孪生神经网络将一对行人图像作为输入,之后分别对图像进行特征提取,然后通过特征间的相似性度量,得到两张行人图像是否属于同一个行人的概率。显然,这种网络结构将行人重识别问题简化为一个二分类问题,因此也受到了广泛的关注。之后,Ahmed^[18]和 Arulkumar^[19]等人分别对 Li 的工作进行了改进和拓展,并使度量学习逐渐成为行人重识别的主要研究方向之一。尤其是近些年来,研究者们针对相似度计算进行了大量改进以提高模型的识别准确率,目前常用的度量学习损失方法有对比损失 (Contrastive loss)^[20]、三元组损失 (Triplet loss)^{[21][22][23]}、四元组损失 (Quadruplet loss)^[24]、难样本采样三元组损失 (TriHard loss)^[25]和边界挖掘损失 (MSML)^[26]。

1.2.3 基于生成式对抗网络的数据增强

生成式对抗网络^[27] (Generative Adversarial Networks, GAN) 是一种基于博弈思想的深度学习模型,其主要作用就是用来生成目标数据。自 2014 年被提出后,该技术立刻引起了研究者们极大的兴趣。但是由于 GAN 不需要预先建模,在训练过程中缺少一定的约束,所以初期的 GAN 模型性能欠佳。近些年来,随着 GAN 的进一步

发展,在图像增强和图像生成方面有了更大的应用前景,根据实际需求,研究者们先后从网络结构^{[28][29][30]}、损失函数^{[31][32][33][34][35]}等方面提出诸多改进模型,这些模型对图像处理算法的研究都具有里程碑意义。

由于行人数据集中的某些目标类存在样本过少的问题,这将导致该目标行人的识别准确率下降,所以如何获得更多的训练样本成为一个亟需解决问题。因此,有学者试图将 GAN 应用在行人重识别上来解决这一问题^{[36][37][38][39]}。通过 GAN 生成不同摄像头风格(如拍摄角度、背景环境)的行人图像,可有效对数据集进行扩充,并平滑不同摄像头、不同数据集之间的差距,这些为行人重识别研究提供给了新的思路。

1.3 本文研究内容

本文主要基于深度学习对行人重识别技术展开研究。实际情况下,摄像头捕捉到的行人图片或多或少都存在行人面部不清晰、摄像头角度有差异、行人姿态变化较大等问题,这些将导致难以准确高效地对目标行人进行重识别。针对上述问题,本文主要完成了以下几个方面的工作:

(1) 设计了数据增强模型 PersonGAN

目前已有的数据集普遍存在数据量不够充足的问题,这极大程度上掣肘了行人重识别技术的发展。针对该问题,本文根据不同摄像头下行人图片数量一般并不一致的特点,对传统 GAN 模型的结构和损失函数作了相应改进,得到可生成不同摄像头风格行人图像的模型——PersonGAN,并使用现有数据集进行了训练和测试。PersonGAN 模型生成的图片,不仅可以模拟现实中摄像头捕捉到的行人图像,而且能够生成识别难度较大的困难样本,给模型的训练提供动量,从而跳出局部极小值点,避免训练的过拟合。从而达到数据增强的作用,提高模型的鲁棒性和泛用性。

(2) 设计了基于联合学习的深度网络模型 RJLN

卷积神经网络可以自动提取视觉特征,这是进行行人重识别的必要条件,针对行人重识别中特征向量难以提取且鲁棒性较差的问题,本文比较并分析目前主流的卷积神经网络结构后,挑选并设计出最适合行人重识别的网络模型作为基础网络。其次,本文通过联合学习,同时将行人的局部特征和全局特征纳入模型的学习范围,来增强模型提取行人最具辨别力特征的能力,从而达到提高模型识别准确率和鲁棒性的目的。

(3) 设计了有效学习行人局部特征的网络模型 SP_Net

虽然目前已有不少学者开始着手基于局部特征的行人重识别研究,但是相关工作普遍需要额外的网络模型对行人图像进行预处理,这无疑会给网络带来多余的开销。针对该问题,本文提出一种结构简单、识别准确率高的局部网络模型 SP_Net 去学习

行人局部特征。该模型直接以特征图水平分割后的条纹作为网络输入，然后使用优化后的网络结构对得到的每一个水平条纹进行局部特征的提取，从而获取细粒度的行人特征，增强模型对行人类别的辨别力。

综上所述，本文的研究内容结构如图 1.2 所示。首先输入真实图像集，通过 PersonGAN 模型对行人图像进行摄像头风格转换，得到生成图像集；其次，将生成图像集与真实图像集合并，进行数据扩充后得到一个新的增强数据集；最后，将增强数据集作为行人重识别模型 RJLN（该模型包含 SP_Net）的训练集，进行特征提取的相关实验。




图 1.2 本文研究内容结构图

1.4 本文组织结构

本论文共包括五个章节，各章节的基本内容概述如下：

第一章：绪论。在本章中，首先阐明了行人重识别问题的具体概念；其次，简要介绍了本课题的研究背景与研究意义；然后，分析并总结了行人重识别领域的国内外研究现状；最后，对本文的主要研究内容和组织结构进行了概述。

第二章：深度学习及行人重识别基础概述。首先，对深度学习的概念进行了简要概述，并对核心算法进行了分析。其次，详细阐明了深度学习代表算法卷积神经网络的概念，并分析了其网络层；最后，就行人重识别领域的相关理论知识、评价标准和常用数据集等进行了介绍。

第三章：基于生成式对抗网络的数据增强。首先对生成式对抗网络进行了概述，并分析了其网络结构和实现过程。其次，针对行人重识别问题的特点，提出了一种改进的生成式对抗网络模型——PersonGAN，并对其网络结构和损失函数进行了分析。最后，通过实验验证 PersonGAN 生成行人图像的效果。

第四章：基于联合学习的行人重识别模型。如何提取更鲁棒、更具辨别力的行人特征是行人重识别领域的重点研究方向之一。本文在第四章中提出了一种基于联合学习的行人重识别模型 RJLN，该模型同时学习行人图像的局部特征和全局特征并进行

融合，从而使行人重识别的准确率和鲁棒性都得到了显著提升。此外，针对行人局部特征的提取，本文提出 SP_Net 模型，在几乎不增加网络额外开销的情况下完成对图像局部特征的有效学习。本章中首先对基于联合学习的网络模型进行结构设计和参数分析，然后通过充足的实验论证了该模型对行人重识别性能提升的有效性。

第五章：总结与展望。本章中首先对已完成的工作进行了总结和分析，并对存在的一些问题进行了归纳；其次，对本课题未来需要改进的工作进行了展望。

第二章 深度学习及行人重识别概述

近些年来,深度学习的快速发展给许多研究课题注入了新的活力,尤其在计算机视觉领域,深度学习为很多传统问题的解决提供了新的思路。在研究者将其引入到行人重识别任务后,基于深度学习的模型迅速展现了优于传统机器学习方法的性能,并逐渐成为该领域的主要研究方向。

本章中,首先对深度学习的概念和核心算法进行简单介绍;然后,对计算机视觉领域常用的卷积神经网络进行了概述,并分析了其基础组成和作用;在此基础上,进一步介绍了基于深度学习的行人重识别的相关概念、评价标准和常用数据集。

2.1 深度学习

2.1.1 深度学习概述

深度学习是机器学习的一个重要子领域,通过计算机来模拟人类学习的过程是传统机器学习的研究核心。通常来说,使用机器学习算法解决回归、分类等问题时,必须先对数据进行预处理,并进行特征提取和特征选择。由此可见,对于机器学习算法来说,特征的学习具有至关重要的作用。但是在传统的机器学习中,特征的提取与选择都需要人工完成,这不仅需要消耗大量的人力物力,而且算法的学习效果未必能达到期望。

而人工神经网络作为模拟生物神经网络的一种简单模型^[4],可以有效地解决传统机器学习遇到的问题。人工神经网络具有一定的自学习能力,可以自主地学习特征,从而避免了人工设计特征或人工选择特征的难点。理论上来说,参数越多的人工神经网络模型复杂度就越高,能完成的学习任务复杂度也就越高。但在训练过程中,如果神经网络的结构过于复杂,则会导致网络冗余、难以收敛,且容易过拟合,因此难以进行实际应用。而随着硬件技术的发展和大数据的普及,网络的训练效率得到了提升,模型过拟合的问题也得到了缓解。因此,深度学习开始受到人们的关注。

通常认为,深度学习是由 Hinton 等人于 2006 年首次明确提出的^[3],具体是指在传统的人工神经网络中增加多个隐层,然后通过非线性操作,解决分类、识别等机器学习问题。前文中曾提到,隐层增多后,神经元的连接权值、阈值等参数也会增多,从而使整个神经网络模型的容量更大、复杂度更高。因此,深度神经网络在训练过程中可能会出现学习能力不足的问题,即参数更新过慢甚至无法更新,导致欠拟合。为了解决该问题,在深度神经网络的训练过程中首先使用无监督方法对各网络层的参数逐层进行初始化,给其赋一个较好的初值;然后再使用有监督方法对整个

网络的训练参数进行微调, 加快其收敛速度, 这也是与传统神经网络最大的不同。在此之后, 许多深度学习的训练技巧也被提出, 如参数批正则化 (Batch Normalize, BN)、随机失活 (dropout) 等训练方法, 这些方法都较好的缓解了网络结构复杂时会出现过拟合等问题。

在 2014 年, 生成式对抗网络的诞生为研究者们打开了新的思路。近几年, 随着该研究重心逐渐转向无监督学习, 生成式对抗网络逐渐成为复杂情况下无监督学习最具潜力的算法之一, 引领了深度学习的又一波浪潮。本文将在第三章中对生成式对抗网络进行详细介绍, 这里不再赘述。

2.1.2 深度学习核心算法

与传统神经网络的核心算法相同, 深度神经网络训练时采用的也是误差逆传播算法 (error BackPropagation, BP) 算法, 它包括两个部分: 1. 信息的前向传播过程; 2. 误差梯度的反向传播过程。




图 2.1 多层前馈网络结构示意图

前向传播过程较为简单, 这里主要分析反向传播时各参数的更新过程。为了便于讨论, 本文在图 2.1 给出一个拥有 m 个输入神经元、 q 个隐层神经元和 n 个输出神经元的多层神经网络结构。其中, v_{ik} 表示输入层第 i 个神经元与隐层第 k 个神经元之间的权值, ω_{kj} 表示隐层第 k 个神经元与输出层第 j 个神经元之间的权值。

记隐层和输出层的激活函数为 $f(\cdot)$ 。对任意训练例 (x_i, y_i) , 假定神经网络的输出为 $\hat{y}_i = (\hat{y}'_1, \hat{y}'_2, \dots, \hat{y}'_n)$, 即:

$$\hat{y}_t = f(\beta_j - \gamma_j) \quad (2-1)$$

其中, $\beta_j = \sum_{k=1}^q \omega_{kj} b_k$ 为输出层神经元对应的输入, γ_j 为输出层神经元对应的阈值。

则可得神经网络的均方误差为:

$$E_t = \frac{1}{2} \sum_{j=1}^n (\hat{y}_j^t - y_j^t)^2 \quad (2-2)$$

根据梯度下降的优化思想, 从负梯度方向对参数进行调整, 以求得最优解。对于式 (2-2) 的误差 E_k , 若给定学习率 η , 有

$$\Delta \omega_{kj} = -\eta \frac{\partial E_t}{\partial \omega_{kj}} \quad (2-3)$$

根据链式法则, 可得:

$$\frac{\partial E_t}{\partial \omega_{kj}} = \frac{\partial E_t}{\partial \hat{y}_j^t} \cdot \frac{\partial \hat{y}_j^t}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial \omega_{kj}} \quad (2-4)$$

根据 β_j 的定义, 显然有:

$$\frac{\partial \beta_j}{\partial \omega_{kj}} = b_k \quad (2-5)$$

而常用的激活函数有如下性质:

$$f'(x) = f(x)(1 - f(x)) \quad (2-6)$$

根据式 (2-1) 和式 (2-2), 可得:

$$\begin{aligned} g_j &= -\frac{\partial E_t}{\partial \hat{y}_j^t} \cdot \frac{\partial \hat{y}_j^t}{\partial \beta_j} \\ &= -(\hat{y}_j^t - y_j^t) f'(\beta_j - \gamma_j) \\ &= \hat{y}_j^t (1 - \hat{y}_j^t) (y_j^t - \hat{y}_j^t) \end{aligned} \quad (2-7)$$

将式 (2-5) 和式 (2-7) 代入式 (2-4), 再代入式 (2-3) 可得 BP 算法中关于输出层与隐层之间权值 ω_{kj} 的更新公式为:

$$\Delta \omega_{kj} = \eta g_j b_k \quad (2-8)$$

同理可得：

$$\begin{aligned} e_k &= -\frac{\partial E_t}{\partial b_k} \cdot \frac{\partial b_k}{\partial \alpha_k} \\ &= -\sum_{j=1}^n \frac{\partial E_t}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial b_k} f'(\alpha_k - \theta_k) \\ &= \sum_{j=1}^n \omega_{kj} g_j f'(\alpha_k - \theta_k) \\ &= b_k (1 - b_k) \sum_{j=1}^n \omega_{kj} g_j \end{aligned} \quad (2-9)$$

其中， $\alpha_k = \sum_{i=1}^m v_{ik} x_i$ 为隐层神经元对应的输入， θ_k 为隐层神经元对应的阈值。

从而可得输出层阈值更新公式为：

$$\Delta \gamma_j = -\eta g_j \quad (2-10)$$

输入层与隐层之间权值 v_{jk} 的更新公式为：

$$\Delta v_{jk} = \eta e_k x_i \quad (2-11)$$

隐层阈值更新公式为：

$$\Delta \theta_k = -\eta e_k \quad (2-12)$$

上述公式中，学习率 $\eta \in (0,1)$ ，它决定了每一轮迭代中更新步长的大小，在实际训练过程中，需要做精细的调节。

2.2 卷积神经网络

卷积神经网络（Convolutional Neural Networks, CNN）是指包含卷积计算且具有深度结构的前馈神经网络，它是深度学习最具代表性的算法之一。下面将对卷积神经网络的基本概念、基础部件和主要特点等分别进行介绍。

2.2.1 卷积神经网络概述

20 世纪 60 年代，在研究猫的大脑视觉皮层结构时，Hubel 和 Wiesel 等人^[40]提出

了神经细胞感受野的概念，即大脑皮层的每一个视觉神经元在处理视觉信号时，并不是对整个区域做处理，而是只处理一个局部区域的视觉信息。在此基础之上，研究者还进一步发现，生物大脑的分层处理机制可以有效地降低反馈神经网络的复杂性，从而提升信息处理的效率。根据这些发现，Hubel 和 Wiesel 等人提出了卷积神经网络的具体概念，也为后来该领域的发展提供了重要的生物学理论基础。受此启发，K.Fukushima 等人^[41]在 1980 年实现了第一个卷积神经网络——神经感知机，并在该模型中首次提出了池化等具有创造性的概念，完善了卷积神经网络的理论框架。随后，更多的研究者们对该网络进行了改进，在 1990 年，lecun 等在研究手写字体识别相关问题时提出了 LeNet 网络^[42]，该网络首次将梯度下降算法^[43]应用到神经网络训练过程中，并在 MINIST 数据集中取得了上佳的表现。

此后，卷积神经网络历经数十年发展，取得了诸多重大的突破。尤其在 2012 年的图像识别大赛 ILSVRC 中，Alex Krizhevsky 提出的基于卷积神经网络的 AlexNet^[44] 以其优异的表现夺得桂冠，并展现出了明显优于 SVM 等传统机器学习模型的实力。此后，卷积神经网络迎来了一个快速发展的时期，每年都有不同结构的卷积神经网络模型被提出，特别是 ResNet、DenseNet 等模型，在图像识别任务中的表现甚至超过了人类。

现在，卷积神经网络已经成为众多研究者们关注的热点之一。因为不需要对数据进行复杂的预处理，并具有权值共享和稀疏连接的特点，可以极大程度上降低网络的复杂性和参数冗余度，所以在许多研究领域都日益受到研究者的青睐。

2.2.2 卷积神经网络基础部件


一个完整的卷积神经网络是由输入层、输出层以及多个隐层组成的。其中隐层主要由以下几个部分组成：1.卷积层（Convolutional layer）；2.池化层（Pooling layer）；3.激活层（Activation Layer）；4.全连接层（Fully-connection layer）。下面将对隐层的四个主要组成构件分别进行介绍。

1. 卷积层


卷积层是卷积神经网络的最核心部分，主要负责卷积计算，从而进行特征的提取。一般来说，卷积层由若干个可学习的卷积核（kernel）组成，它们具有一定的感受野，用以学习不同的特征。在网络训练过程中，每一个卷积核都会在输入图像上按照特定的步长（stride）移动，然后与对应的像素点进行卷积计算，具体过程如图 2.2 所示，其中（a）为卷积核滑动过程，（b）为卷积计算过程。然后在实际操作中会加上一个偏置（bias）后再作为输出，若以二维图像作为输入，则：

$$output = \sum_{i=1}^m \sum_{j=1}^n I_{i,j} * K_{i,j} + b \quad (2-13)$$

其中 I 表示输入图像, K 表示卷积核, i, j 表示此时像素点的位置, m, n 分别表示输入图像的长和宽, b 表示偏置, $*$ 表示卷积操作。



(a) 卷积核滑动过程



(b) 卷积计算过程

图 2.2 卷积过程示意图

除了步长和卷积核大小等参数,卷积操作中还有一个重要的参数,就是补零尺寸(padding)。因为当卷积核在不断移动进行卷积操作时,有时未必能将图像边缘的数据恰处理好,从而造成数据丢失。该参数的作用就是在输入图像的外围按指定尺寸补0,从而可以使卷积核在移动到图像边缘位置时依然可以正常进行卷积操作,避免发生数据丢失。通常来说,卷积层的输出特征图尺寸是由输入特征图尺寸、卷积核尺寸、步长和补零尺寸共同决定的,其计算公式如下:

$$size_{out} = \left\lfloor \frac{(size_{in} - size_k + 2 \times padding)}{stride} \right\rfloor + 1 \quad (2-14)$$

其中 $size_{in}$ 和 $size_{out}$ 分别表示图像输入和输出特征图的尺寸, $size_k$ 表示卷积核的尺寸, $padding$ 表示补零尺寸, $stride$ 表示步长, $\lfloor \bullet \rfloor$ 表示向下取整操作。

与传统的人工设计特征相比,卷积层具有局部感知、稀疏连接和权值共享等特点。每个卷积核都可以学习到不同的参数,从而用来提取图像的不同特征,并且很大程度上减少了相邻网络层之间连接参数的数目,极大地提高了算法的运行效率。

2. 池化层

池化层通常紧接在卷积层后面,用来对特征进行下采样(down-sampling),降低提取特征的维度。一般来说,经过卷积层提取的图像特征维度较多,因此会带来巨大的计算量,且容易导致过拟合的现象。所以需要在每一个卷积层后面加上一个池化层,作用就是进行非线性的下采样,从而减少特征维数,降低网络参数的冗余度,防止发生过拟合。




图 2.3 均值池化和最大池化过程示意图

目前,卷积神经网络中常用的池化方式主要有两种:均值池化和最大池化。均值池化是计算指定区域内图像块中所有像素的平均值,然后用该均值来表示该区域的输出值,更多地保留了图像的背景信息;最大池化在指定区域内查找该部分的最大像素值,然后用该最大值表示该区域的输出值,更多的保留了图像的纹理信息。池化的操作与卷积类似,也是通过滑动窗口实现的,每次滑动后都会通过计算得到一个新的值并作为输出。两种方式的池化过程如图 2.3 所示。此外,池化也是有步长(stride)、补零尺寸(padding)、核大小等参数,其输出的大小也可以通过式(2-14)得到。

3. 激活层

激活层主要作用是实现非线性映射,而在深度神经网络中,这是通过激活函数来完成的。对于激活层而言,输入特征是低维的,经过激活函数进行非线性变换后,输入特征将被映射到更高维的空间,从而提升网络的描述能力。一般来说,网络中常见的激活函数有 sigmoid、tanh、ReLU 等几种,公式分别如下:

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-15)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-16)$$

$$\text{ReLU} = \max(0, x) \quad (2-17)$$

因为 sigmoid 和 tanh 会出现“软饱和”的现象，即当数据不断增多时，梯度会趋近为 0，导致网络权值无法更新，进而发生网络梯度弥散。而 ReLU 不会发生“软饱和”的情况，能够极大地加快训练时的收敛速度，从而成为目前最常用的激活函数。但是当输入值为负时，ReLU 也会发生无法更新权重的现象。为了改善此情况，许多 ReLU 的改进版本也被不断提出来，如 Leaky-ReLU、ELU 等。改进版本的 ReLU 在输入值小于 0 的时候，也有一定的输出，从而使输入为负时，网络权重依然可以得到更新，几者的对比图 2.4 所示。




图 2.4 ReLU 及其改进版本示意图

4. 全连接层

全连接层的概念来源于人工神经网络。与多层感知器类似，全连接层中的每个神经元都与其前面一层的所有神经元进行全连接，其网络结构如图 2.5 所示。在整个卷积神经网络中，全连接层主要起到了一个“分类器”的作用，以完成特征映射和后续的分类工作。




图 2.5 全连接层示意图

显然，与卷积层相比，全连接层不具备稀疏连接和权值共享等特点，这将导致训练过程中参数数量太多，网络计算量太大。因此，随着深度学习的不断成熟与发展，越来越多的网络模型只使用一层全连接层来完成特征的映射，如残差网络（ResNet）、密集连接卷积网络（DenseNet）等。全连接层的一般计算公式如下：

$$y = f(W^T x + b) \quad (2-18)$$

上式中 W^T 表示权值矩阵， x 表示输入值， y 表示输出值， b 表示输出层的偏置， $f(\cdot)$ 表示激活函数。

2.3 行人重识别

2.3.1 问题表述

行人重识别，是指利用计算机视觉算法，在特定的图像或视频序列中查找目标行人的技术。在本文中，主要研究的是基于深度学习的行人重识别问题，即给定一个待查询行人图像（query），加载基于卷积神经网络的深度模型，从候选图像集（gallery）中检索到最可能属于同一个行人的图像。

行人重识别任务在本质上也被广泛认为是一个图像检索的子问题，因为在测试集中的行人均不与训练集中的行人个体重复，这一点非常符合检索问题的特点。但是由于其训练过程中，行人的标签是可用的，这一点又与分类任务很相似。根据这个特点，

本文在训练过程中将行人重识别视为分类任务，在测试过程中再将其视为检索问题，从而降低问题的复杂度，并可以得到更具辨别力的模型。其具体流程如图 2.6 所示。




图 2.6 行人重识别流程示意图

由图 2.6 可知，做行人重识别相关研究时，需要分两步来做：（1）在训练过程中，通过计算行人分类的误差损失，不断对模型参数进行微调，最终得到识别准确率高、鲁棒性好的特征提取网络。（2）在测试过程中，首先加载训练得到的特征提取网络分别对待查询图像和候选图像集中的样本进行特征提取；其次，对于提取到的特征进行按照一定的基准进行距离度量；最后，按度量距离大小对结果进行排序，并显示检索结果。

需要注意的是，在测试过程中，如果待查询图像只有一张，则为单查询样本（single-query）测试；如果待查询样本由一个行人的多张图像组成，则为多查询样本（multi-query）测试。通常来说，多样本查询时的识别准确率要高于单样本查询。

2.3.2 评价标准

在行人重识别任务中，通常需要通过一定的指标去评判一个算法的优劣，常用的

评价标准有 rank-k, CMC, mAP 等。

1. rank-k 准确率和 CMC

rank-k 准确率是指在检索结果中, 置信度最高的 k 张图片中有正确结果的概率。具体到行人重识别问题, 就是指在查找某一行人的检索结果中, 排名靠前的 k 张行人图像中有指定目标行人的图像的概率。一般来说, rank-k 准确率是反映行人重识别模型性能最重要也是最直观的指标, 其中最常用的就是 rank-1、rank-5、rank-10 准确率。一般来说, 比较两个行人重识别模型时, rank-k 准确率越高的模型, 其检索能力越强, 模型性能也越佳。

此外, 累计匹配特征 (Cumulative Match Characteristic, CMC) 曲线也是行人重识别重要的评价标准之一。如图 2.7 所示, 该曲线的横坐标是 rank-k 准确率中 k 对应的值, 纵坐标是 rank-k 准确率对应的值, 它可以更直观地表现出模型的优劣情况。一般来说, CMC 曲线中, 曲线整体越高, 则模型性能越好。




图 2.7 CMC 曲线示意图

2. mAP

rank-k 与 CMC 曲线可以反映出模型检索行人时的查准率 (Precision, 也被称为精确率), 但是并没有考虑到查全率 (Recall, 也被称为召回率)。在行人重识别问题中, 查全率表示置信度最高的 k 个行人图像中, 正确匹配的行人数目所占的比例, 具体定义如下:

$$P = \frac{k_t}{k} \quad (2-19)$$

其中, k_t 为正确匹配的数目。

而查全率表示置信度最高的 k 个行人图像中, 正确匹配的行人数目占候选图像集中所有属于该行人图像数目的比例, 具体定义如下:

$$R = \frac{k_t}{k_a} \quad (2-20)$$

其中 k_a 表示在候选图像集中所有与待查询图像属于同一行人的图片数。

若以查全率为横坐标、查准率为纵坐标，为当 k 发生变化时，把相应的 P 与 R 的值作一条曲线，就可以得到“P-R 曲线”，显示该曲线的图称为“P-R”图，如图 2.8 所示。通过计算某一个查询样本“P-R 曲线”与坐标轴围成的图形面积，即可得到该样本的 AP 值，所有查询样本 AP 的均值就被称为 mAP。mAP 可以综合考量模型对数据集中所有行人类别的学习能力。




图 2.8 P-R 曲线示意图

2.3.3 相关数据集

通常，基于深度学习的行人重识别任务需要大量的图片数据进行训练，因此数据集的优劣程度会对训练的结果造成较大的影响。本文在这里介绍几种常用的行人重识别数据集，并进行简单的分析。

1. VIPeR^[5]

VIPeR 是 Grey 等人在行人重识别研究早期阶段提出的一个小型行人重识别数据库。该数据集包括了 2 个不同摄像头采集到的 632 个行人的图像，每个视角下仅包含每个行人的一张图片。同时，它很好地包含了不同视角下行人姿态和背景环境的变化，并且每张图片被标准化为统一的 128×48 的分辨率，以便于特征的提取。这也是第一个真正意义上的行人重识别公开数据集，在本领域早期的研究中，被研究者们广泛使用来评价传统模型的性能，极大程度上推动了行人重识别领域的发展。但是由于拍摄条件的限制，该数据集在图像数量及分辨率上均无法很好地满足深度学习模型对于训练数据的需求，所以当深度模型兴起后，已经逐渐淡出了人们的视野，仅被个别工作用来检验模型在小样本条件下的泛化能力。

2. CUHK03^[45]

随着行人重识别技术的不断发展,为了满足该领域的深度学习模型对图片数量和图像质量的需求,香港中文大学在 2014 年提出了 CUHK03 数据集。该数据集的图像来自于香港大学内 5 对不同的摄像头,并且每对摄像头会分别采集每个行人在两个视角下的图片。此外, CUHK03 包含两个子数据集: detected 和 labeled,子数据集里面包含的行人种类完全相同,区别在于里面的行人检测矩形框分别是 DPM 算法自动检测得到和人工标记得到的。其中自动检测的行人数据集包含一些检测误差,也更接近于真实情况;而人工标记的行人数据集则更加精确。该数据集总共包含 1467 个行人的 14097 张图片,平均每个行人在每个视角下有 4.8 张训练数据。相较于之前的数据集, CUHK03 基本解决了行人重识别的深度学习模型受制于数据集的问题。在 CUHK03 出现后,越来越多的相关工作得以进行,行人重识别的许多成果也在顶级期刊和会议上逐渐出现。

3. Market-1501^[46]

Market-1501 数据集是在清华大学校园中采集的,并在 2015 年完成构建并公开。Market-1501 数据集在设计上相较于 CUHK03 数据集又做了进一步的改善,使之更加符合行人重识别系统在实际场景中的应用。该数据集的图像来自于 6 个不同的高清摄像头,总共包含 1501 个行人的 32668 个图像,其中的行人检测矩形框是 DPM 算法自动检测到的。与 CUHK03 数据集类似,每个行人都至少出现在 2 个摄像头中,并且在一个摄像头中可能包含该行人的多张图像。训练集包含 751 个行人和对应的 12936 张图像,平均每个人有 17.2 张训练数据;测试集有 750 人对应的 19732 张图像,平均每个人有 26.3 张测试数据。待查询图像有 3368 张,其中的行人检测矩形框是人工绘制的;而候选图像集中有 16364 张图像,其中的行人检测矩形框是使用 DPM 检测算法检测得到的。

4. DukeMTMC-reID^[47]

DukeMTMC-reID 是在杜克大学内采集得到的数据集。原始数据集包含了 85 分钟的高分辨率视频,来自于 8 个不同摄像头,并提供人工标注完成的行人检测框。然后对视频中每 120 帧采样一张图像,得到了 36411 张图像。其中一共有 1,404 个人出现在大于两个摄像头下,有 408 个人只出现在一个摄像头下。据此,研究者随机采样了 702 个人作为训练集,702 个人作为测试集。在测试集中,作者采样了每个行人的每个摄像头下的一张照片作为待查询图像。剩下的图像加入测试集作为候选图像集,并且将之前的 408 人作为干扰项,也加到候选图像集中。经过上述处理后,训练集包含 16522 张行人图像,测试集包含 17661 张行人图像。训练数据中一共有 702 人,平均每个人有 23.5 张训练数据,而测试集中包含另外的 702 人。该数据集是 ICCV2017 会议之前最大的行人重识别数据集,也是目前最主要的行人重识别数据

集之一，并且提供了行人属性（性别/长短袖/是否背包等）的标注。

2.4本章小结

在本章中，首先对深度学习进行了介绍，对其概念和核心算法进行了简述。然后，在此基础上又对深度学习的代表算法之一，也是本文中主要使用的网络结构——卷积神经网络进行了详细说明，分别介绍了卷积层、池化层、激活层和全连接层的具体构造及作用。最后，本章对行人重识别问题进行了详细表述，并对行人重识别领域目前的主流算法、评价标注及相关行人数据集详细进行了介绍。

第三章 基于生成式对抗网络的数据增强算法

前文分析中提到,数据集对于行人重识别算法具有至关重要的作用。如果数据集中图片数量过少,可能会造成模型过拟合,这也是早期行人重识别遇到的瓶颈之一。但是由于现实环境中诸多条件的限制,通常难以获得足够规模的行人数据集来进行训练。因此,如何合理进行数据增强,以提高行人重识别模型的鲁棒性成为目前的研究热点之一。

本章中主要提出了一种基于生成式对抗网络的数据增强算法 PersonGAN。首先,详细介绍了 PersonGAN 模型的网络结构;其次,简要分析了该模型中使用的损失函数;最后,在多个数据集上展示了该模型生成图像的效果,并与主流方法进行了对比。

3.1 生成式对抗网络

3.1.1 生成式对抗网络概述

作为专门用于估计生成模型的新算法,生成式对抗网络于 2014 年横空出世。在出现之后,其新颖的网络框架和博弈思想很快引起了相关学者们的广泛关注。

GAN 的基本思想起源于博弈论中的纳什均衡,其关键就是让生成器 G 和判别器 D 这两个模型互相博弈,从而寻找二者之间的一个纳什均衡点。以计算机视觉中的图像生成任务为例,生成器 G 的作用是从输入数据中不断学习真实数据的概率分布,进而生成可以以假乱真的图片。判别器 D 的作用是正确判断一张图片是真实图片还是生成器 G 生成的虚假图片。判别器 D 的存在可以使生成器 G 在没有大量先验知识和分布经验的情况下也能够通过不断学习去生成逼近真实值的数据。GAN 的具体实现流程如图 3.1 所示。




图 3.1 GAN 网络示意图

3.1.2 生成式对抗网络算法流程

GAN 的实现方法就是让生成器 G 和判别器 D 这两个模型不断地学习和竞争, 生成器 G 根据判别 D 的识别结果不断改进自身, 直到判别器 D 不能判断输入图像是真实图片还是生成的图片, 此时整个系统达到一个纳什均衡。

如图 3.1 所示, 假设输入的随机噪声为 z , $G(z)$ 表示生成器对噪声进行处理后的输出。模型 G 首先会将该随机噪声 z 转换成与真实数据相同的数据类型, 然后与真实数据一同送入判别器 D 。对于任意的输入 x , $D(x)$ 会输出一个 0~1 之间的概率值, 用来表示该输入为真实值的可能性大小, 从而判断该输入图像是生成图像还是真实图像。若用 P_{data} 表示真实数据的分布, P_z 表示生成数据的分布, 则整个 GAN 的损失函数为:

$$\min_G \max_D E_{x \sim P_{data}} [\log D(x)] + E_{z \sim P_z} [\log(1 - D(G(z)))] \quad (3-1)$$

其中, $E_{x \sim P_{data}} [\log D(x)]$ 为判别器的判别损失, 表示判别器判断某张图片为真实图片或生成图片时造成的误差损失。 $E_{z \sim P_z} [\log(1 - D(G(z)))]$ 为生成器的生成损失, 表示生成图片与真实图片之间的误差损失。

在训练判别器 D 的过程中, 如果 $D(x)$ 的值越趋近 1, $D(G(z))$ 的值越趋近 0, 表明判别器 D 的识别能力越强; 在训练生成器 G 的过程中, 如果 $D(x)$ 的值越接近 0, $D(G(z))$ 越趋近 1, 表明生成器 G 生成的图片效果越好。因此, GAN 的整体优化过程可表示为分别对判别器 D 和生成器 G 进行交互迭代:

- (1) 先固定生成器 G 不变, 优化判别器 D ;
- (2) 经过一段时间后, 再固定判别器 D 不变, 优化生成器 G ;
- (3) 不断循环上述过程, 直至整个系统达到一个均衡, 损失函数开始收敛。

3.2 PersonGAN

3.2.1 PersonGAN 网络结构

传统的 GAN 只是单向的, 即可以实现图像从一种风格向另一种风格的转换 (例如, 将模糊图像转换为清晰图像)。但是在训练过程中可能会出现模型崩溃 (model collapse) 的现象, 即对所有的输入图像, GAN 生成的图像类别单一, 只认为满足某一分布的图像为真, 其他均为假, 使优化过程无法开展。为了解决这个问题, 研究者们先后提出 pix2pix GAN^[48]、CGAN^[26] 等改进模型。这些 GAN 模型训练时可以通过网络层间的传递性来优化结构化的数据, 因此生成图像的效果明显更佳。但是这些模

型都要求两个数据集中图片的是一一配对（paired）的，配对（paired）图片与不配对图片（unpaired）的区别如图 3.2 所示。一般来说就行人重识别任务而言，不同数据集中或不同摄像头下的行人图片是不一致的，成对的训练数据难以获得，因此传统的 GAN 模型显然不完全适用于行人重识别任务。





图 3.2 配对图像与非配对图像对比图^[33]

不同于传统的 GAN 模型，循环一致性对抗网络（Cycle-Consistent Adversarial Networks, CycleGAN）^[33]最大的创新点就是使用了环形结构，从而使训练所使用的数据集中可以有不对（unpaired）的图像，其基本思想如图 3.3 所示。



(a) CycleGAN 结构简图

(b) X 域循环一致性损失

(c) Y 域循环一致性损失

图 3.3 CycleGAN 示意图

CycleGAN 的整体结构包含两个生成器和两个判别器。两个生成器主要用来实现图 3.3 (a) 中的两个映射函数，分别为 F_1 ：将 X 域的图片转换为 Y 域的图片； F_2 ：将 Y 域的图片转换为 X 域的图片。两个判别器 D_X 和 D_Y 分别用来计算映射函数 F_1 生成图片时的误差损失和映射函数 F_2 生成图片时的误差损失。

此外，为了避免模型崩溃现象的发生，CycleGAN 提出可以利用循环一致性损失监督训练，从而提升生成图片的质量。如图 3.3 中的 (b) 所示，当原图像从 X 域映射到 Y 域，再由 Y 域映射回 X 域时生成的图像被称为重建图像。显然，重建图像应

该与原图像尽可能相似，而原图像与重建图像之间的误差损失，就被定义为循环一致性损失。与之类似，（c）表示的是以 Y 域图像作为输入的情况。二者一起构成了整个网络的循环一致性损失，即在模型中加入了 $F_l(F_2(x)) \approx x$ ，以及 $F_2(F_l(y)) \approx y$ 的约束，这样就可以保证对于每张图像都会被转换为另一种风格的对应图像，而不会只生成单一图像。




图 3.4 PersonGAN 模型结构示意图

基于此，本文提出一种以 CycleGAN 作为基础网络的 PersonGAN 模型，对传统的 GAN 进行相应的改进，使其适用于行人重识别任务。PersonGAN 模型与 CycleGAN 的网络结构相似，本质上是由两个互为镜像的单向 GAN 组成的一个环形网络，其模型结构示意图如图 3.4 所示。A 域与 B 域分别表示两个不同风格的数据集，具体到行人重识别问题，即表示不同摄像头采集到的行人图像。两个单向 GAN 共享两个生成器：A2B 和 B2A，A2B 根据 A 摄像头风格的行人图像生成 B 摄像头风格的行人图像，B2A 根据 B 摄像头风格的行人图像生成 A 摄像头风格的行人图像。两个单向 GAN 还各拥有一个判别器，分别为判别器 A 和判别器 B，用来判断当前输入的图片是真实图像还是生成图像。此外，为了计算生成图像与对应的真实图像的重建损失，每个单向 GAN 中还各自有一个损失函数来进行约束（一般可采用 L1 损失或 L2 损失），二者共同组成 CycleGAN 中的循环一致性损失。下面将详细介绍 PersonGAN 模型中

生成网络和判别网络的具体结构。

1. 生成网络

本文中，生成网络采用了基于残差网络（Residual Neural Networks, ResNet）^[49]的模型，而残差块（residual block）是构成的残差网络的基础部件。下面将简单介绍一下残差网络和残差块的主要概念和工作原理。

根据以往的经验，如果神经网络的深度越深，那么网络越能提取到有辨别力的特征，模型的准确度也就越高。因此，以 VGG 为代表的深度神经网络开始不断增加网络层以取得更好的效果。但是，研究者们发现，随着网络层加深到一定程度，其特征提取的效果和模型的识别准确率趋于饱和，甚至反而不如一些浅层网络，该现象也被称为“网络退化”。“网络退化”现象的发生说明深度网络当网络层级达到一定值之后，会变得难以训练，这主要是因为当网络层数过深时，神经网络的梯度在反向传播过程中会逐渐下降直至消失，从而导致网络丧失学习能力。因此，并不能通过简单地增加网络层数来取得好的优化效果。

在这种困境下，残差网络的提出很好地解决了网络退化的问题。残差网络主要通过在网络中增加跳跃连接（shortcut connection）来实现网络优化，即跳过一层或多层网络，将信息传递到网络中的更深层。包含一个跳跃连接的若干层网络被称为一个残差块，残差块的具体结构如图 3.5 所示。




图 3.5 残差块示意图

在图 3.5 所示的残差块中，Weight Layer 表示输入层与输出层间含可训练参数的网络层， x 表示网络的输入，而 $F(x)$ 表示残差块经过两个 Weight Layer 后的输出。若用 W_1 、 W_2 分别表示两个 Weight Layer 的权值， $g(\cdot)$ 表示网络层中的激活函数 ReLU，忽略网络层中的偏置（bias），则

$$F(x) = W_2 g(W_1 x) \quad (3-2)$$

而第 2 个激活函数 ReLU 的输入为 $F(x) + x$ ，残差块最终的输出值为：

$$output = g(F(x) + x) \quad (3-3)$$

对于一个如上所示的 2 层网络，假设经过两个 Weight Layer 后的理想输出为 $H(x)$ 。当没有右侧的跳跃连接时，则残差块相当于是一个传统的 2 层网络（其中网络层可以是卷积层，也可以是全连接层）。此时，如果要拟合常见的恒等映射，则神经网络要学习的目标是 $H(x) = x$ ，也就是让输入 x 趋近于输出 $H(x)$ ；而对于残差块来说，通过跳跃连接，使得 $H(x) = F(x) + x$ ，因此只需将 $F(x) = H(x) - x$ 优化，让其趋近于 0 即可。在这里，研究者们定义 $F(x)$ 为残差函数，这也是残差网络名字的由来。在深度神经网络中，优化的复杂度越低，越能避免网络发生退化，而显然，当 x 很小时，让 $F(x) = 0$ 的优化难度远小于让 $H(x) = x$ 的优化难度。

而前文中提到，残差网络就是由多个残差块组成的深度神经网络。这种跳跃式的网络传输结构，打破了以往的神经网络中本层的输出只能给下一层作为输入的传统，使某一层的输出可以直接跨过几层作为后面某一层的输入，从而为解决深度神经网络中可能发生的“网络退化”问题提供了新的思路。在本文中，生成网络就是选用了基于多尺度深度残差网络的结构，其网络结构如图 3.6 所示。




图 3.6 PersonGAN 生成网络结构示意图

首先，用 1 个卷积层中去对行人图像进行特征提取，并用 2 个步长（stride）为 2，但卷积核大小不同的卷积神经网络代替传统的池化层进行下采样（down-sampling），将高维特征映射为低维特征。经过多个不同尺度的卷积神经网络后，就可以得到目标

行人图像的特征向量，记为 v 。

其次，将特征向量 v 送入由 9 个残差块组成的残差网络中，通过组合行人图像间的不相似特征，将行人图像在 A 域的特征向量 v 转换为 B 域上的特征向量 v' 。其中，每一个残差块都是由两个卷积层组成的人工神经网络，并且在除输出层外的每一个残差块后都接着一个批正则化层（Batch Normalize Layer）和一个 ReLU 激活函数，以达到在转换时尽可能保持原始图像特征不变的目的。这是因为传统的神经网络仅在输入层对数据进行正则化操作，而随着训练的进行可能会发生梯度消失导致训练速度下降的情况，此时误差无法得到修正。而批正则化层可以在隐层上对每一批（batch）数据都进行正则化操作，所以极大程度避免了梯度消失和过拟合现象的发生。

最后，利用和下采样层相同数目的转置卷积神经网络（Transposed Convolution Neural Networks）来实现反卷积，进行上采样（up-sampling）操作，每个转置卷积层的步长（stride）均为 2，卷积核大小与步幅卷积层核大小对应，从而完成将特征向量 v' 映射为低级特征的工作，再通过一个卷积层将得到的低级特征转换为最终的生成图片。上述网络的具体参数如表 3.1 所示。

表 3.1 PersonGAN 生成网络相关参数

网络类型	输入维度	核尺寸	步长	输出维度
卷积层	3	7×7	1	64
下采样卷积层 1	64	5×5	2	128
下采样卷积层 2	128	3×3	2	256
残差块 1	256	3×3	1	256
残差块 2	256	3×3	1	256
残差块 3	256	3×3	1	256
残差块 4	256	3×3	1	256
残差块 5	256	3×3	1	256
残差块 6	256	3×3	1	256
残差块 7	256	3×3	1	256
残差块 8	256	3×3	1	256
残差块 9	256	3×3	1	256
转置卷积层 1	256	3×3	2	128
转置卷积层 2	128	5×5	2	64
卷积层	64	7×7	1	3

2. 判别网络

一般来说, 当使用 L1 损失或 L2 损失对 GAN 中的生成器进行约束时, 生成图像容易出现模糊。但是对于图像的低频部分, L1 损失函数等已经可以很好的对其进行约束, 所以并不需要一个判别器对整张图像进行额外的修正。因此, 仅对图像的高频部分进行模拟, 就可以提高整个网络识别率。而对于模拟高频结构, 研究者的关注点在于模拟图片中局部图像块的结构。因此, 本文不直接将一张完整图像作为判别器的输入, 而是取图像上的局部区域作为输入。

判别网络主要由多个卷积层组成, 目的用来实现一个二分类, 判断图片是真实图片还是生成图片, 因此其结构相对来说较为简单, 如图 3.7 所示。




图 3.7 PersonGAN 判别网络结构示意图

首先, 对于每一张行人图像, 先在图片上取多个 $N \times N$ 大小的局部区域, 称为补丁 (patch), 需要注意的是, 这里 N 是远小于图片大小的。然后用 3 个不同尺寸的卷积层对这些补丁进行特征提取, 获得该行人图像每个补丁的特征向量 μ 。

其次, 用一个一维输出的卷积层替代全连接层对特征向量 μ 进行操作, 获得该补丁是真实图片还是生成图片的一个概率值 p , 然后对每个补丁部分的概率值取均值, 获得整张行人图片是真实图片还是生成图片的概率值 $\hat{p}$ 。

最后, 网络将获得的概率均值 $\hat{p}$ 送入一个 Sigmoid 激活函数层, 完成该图像是真实图片还是生成图片的判断。上述网络的相关参数如表 3.2 所示。

这种方法不仅可以避免判别器的一个极端输出, 而且在进行图像处理时, 一个补丁的所需要训练的参数远少于一张完整图像, 可以提高网络的收敛速度。

表 3.2 PersonGAN 判别网络相关参数

网络类型	输入维度	核尺寸	步长	输出维度
卷积层 1	3	4×4	2	64
卷积层 2	64	4×4	2	128
卷积层 3	128	4×4	2	256
映射卷积层	256	4×4	1	1
Sigmoid 激活层	1	-	-	1

3.2.2 PersonGAN 损失函数

PersonGAN 是对 CycleGAN 模型的一个改进，以便更加适用于行人重识别问题，其损失函数主要由两个部分组成：分别为基于 CycleGAN 的损失函数和保证颜色等细节特征具有一致性的恒等映射损失（identity mapping loss）。

1. 基于 CycleGAN 的损失

前文曾提到，不同于传统的单向 GAN，CycleGAN 拥有两个判别器和生成器。因此，CycleGAN 的损失函数中有两个单独的 GAN 损失函数，分别用来计算两个 GAN 中的映射损失以及生成图像和真实图片的判别损失。此外，两个单向 GAN 还各自需要一个重建损失进行约束，表示某域的图片经过转换与恢复之后与其对应的真实图片之间的误差损失。两个重建损失在一起构成了一个完整的循环一致性损失（Cycle Consistency Loss）。

值得一提的是，受到 Liu W^[50]等人的启发，为了能够避免训练震荡，使网络更稳定，本文使用了均方误差损失（Mean-square error Loss）去替代传统 GAN 中的对数损失（Logarithmic Loss）。

综上所述，一个完整的 CycleGAN 共由两个生成器和两个判别器组成，总共需要训练四个损失函数，具体如下：

从 A 摄像头到 B 摄像头方向的 GAN 损失函数为：

$$L_{GAN}(G_{AB}, D_B, A, B) = E_{b \sim P_{data}(b)} [(D_B(b) - 1)^2] + E_{a \sim P_{data}(a)} [D_B(G_{AB}(a))^2] \quad (3-4)$$

从 B 摄像头到 A 摄像头方向的 GAN 损失函数为：

$$L_{GAN}(G_{BA}, D_A, B, A) = E_{a \sim P_{data}(a)} [(D_A(a) - 1)^2] + E_{b \sim P_{data}(b)} [D_A(G_{BA}(b))^2] \quad (3-5)$$

A 摄像头下的重建图像与真实图像的误差损失为：

$$L_A = E_{a \sim P_{data}(a)} [\|G_{BA}(G_{AB}(a)) - a\|_2] \quad (3-6)$$

B 摄像头下的重建图像与真实图像的误差损失为:

$$L_B = E_{b \sim P_{data}(b)} [\|G_{AB}(G_{BA}(b)) - b\|_2] \quad (3-7)$$

由式 (3-6), 式 (3-7) 可得, CycleGAN 部分中的循环一致性损失为:

$$L_{cyc}(G_{AB}, G_{BA}) = E_{a \sim P_{data}(a)} [\|G_{BA}(G_{AB}(a)) - a\|_2] + E_{b \sim P_{data}(b)} [\|G_{AB}(G_{BA}(b)) - b\|_2] \quad (3-8)$$

因此, CycleGAN 部分的总损失如下式:

$$L(G_{AB}, G_{BA}, D_A, D_B) = L_{GAN}(G_{AB}, D_B, A, B) + L_{GAN}(G_{BA}, D_A, B, A) + L_{cyc}(G_{AB}, G_{BA}) \quad (3-9)$$

在上述式 (3-4) 到式 (3-9) 中:

A : 表示数据域 A , 即 A 摄像头下的图片集合。

B : 表示数据域 B , 即 B 摄像头下的图片集合。

G_{AB} : 表示将 A 摄像头风格图像转换为 B 摄像头风格图像的生成器, 即以 A 摄像头下的行人图片为输入, 生成 B 摄像头下行人的虚假图片。

G_{BA} : 表示将 B 摄像头风格图片转换为 A 摄像头风格图片的生成器, 即以 B 摄像头下的行人图片为输入, 生成 A 摄像头下行人的虚假图片。

D_A : 表示用来计算 A 域上虚假图片与真实图片的误差损失的判别器。

D_B : 表示用来计算 B 域上虚假图片与真实图片的误差损失的判别器。

L_{cyc} : 表示两个 GAN 中真实图片与其对应的重建图片误差损失之和, 即循环一致性损失。

2. 恒等映射损失 (identity mapping loss)

一般来说, GAN 主要实现不同图像风格间的转换, 但在实际过程中, 有可能遇到如下情况: 对于从 A 风格到 B 风格的映射 G_{AB} , 可能输入图像 b 本身就是 B 风格的图像, 此时生成器更应该输出 B 风格的图像, 即 $G_{AB}(b) = b$; 同理, 对于映射 G_{BA} , 应当有: $G_{BA}(a) = a$ 。基于此, 本文在 PersonGAN 中增加了一个恒等映射损失, 使用 L1-loss 对行人图片转换进行像素级的约束, 来保证输入图像和输出图像在颜色等方面的一致性, 同时增强模型对于不同输入的鲁棒性, 具体公式如下:

$$L_{identity}(G_{AB}, G_{BA}) = E_{a \sim P_{data}(a)} [\|G_{BA}(a) - a\|_1] + E_{b \sim P_{data}(b)} [\|G_{AB}(b) - b\|_1] \quad (3-10)$$

其中, a 、 b 表示真实行人图片, $G_{BA}(a)$ 、 $G_{AB}(b)$ 表示对应的生成图片。

加入恒等映射损失后, 给整个 PersonGAN 模型, 尤其是生成器部分增加了约束项, 因此 PersonGAN 模型进行行人风格转换的能力得到了进一步提升, 恒等映射的实验效果将在 3.3.2 节中具体阐述。由式 (3-9) 和式 (3-10) 可得, PersonGAN 的总损失函数为:

$$L^p_{total} = L(G_{AB}, G_{BA}, D_A, D_B) + L_{identify}(G_{AB}, G_{BA}) \quad (3-11)$$

3.3 实验结果与分析

3.3.1 实验配置与参数

以往研究者的实验结果表明, 实验环境和参数的不同对于深度学习的实验效果具有显著的影响, 因此, 本小节将简要介绍一下本章实验的相关配置和实验的相关参数。

(1) 本章实验中所使用的软件及硬件环境如表 3.3 所示。

表 3.3 PersonGAN 实验配置

软硬件环境	相关配置
操作系统	Ubuntu 16.04
实验平台	Pytorch 深度学习框架
中央处理器	Inter(R) Xeon(R) CPU E5-2609
显卡	NVIDIA GTX 1080
内存	8GB
显存	8GB

(2) 本章中训练模型时参数设置如表 3.4 所示。

表 3.4 PersonGAN 实验参数设置

参数名称	参数数值
输入图像尺寸	256×256
迭代次数 epoch	200
动量因子	0.9
权重衰减系数	5×10^{-4}
初始学习率	0.0001

3.3.2 PersonGAN 实验效果验证

本小节主要使用 PersonGAN 模型进行了摄像头风格转换的实验，并对 PersonGAN 模型生成图像的效果进行了验证。

在实验中，首先对数据集进行预处理，将行人图像数据按摄像头进行分组。假设数据集中有 m 个摄像头采集的数据，则一共形成 m 个分组。

其次，将这 m 组数据被视为 m 个数据域，对每两个数据域都需用 PersonGAN 进行一个风格转换，因此总共需要进行风格转换的次数 n 为 $m(m-1)/2$ 。

最后，每张行人可以生成对应的 $m-1$ 个虚假行人图像，对生成图片也按摄像头进行分类，并与真实图片进行对比，验证模型性能。



(a) 3 号摄像头风格转换结果



(b) 4 号摄像头风格转换结果



(c) 6 号摄像头风格转换结果

图 3.8 Market-1501 数据集摄像头风格转换结果图

图 3.8 是 PersonGAN 在数据集 Market1501 上进行实验的结果。因为数据集中的摄像头数量较多，所以从六个摄像头中随机挑选出三组（3、4、6 号摄像头），进行风格转换后的行人图像展示。其中，（a）为 3 号摄像头风格转换结果，（b）为 4 号摄像头风格转换结果，（c）为 6 号摄像头风格转换结果。



图 3.9 DukeMTMC-reID 数据集摄像头风格转换结果图

图 3.9 是 PersonGAN 在数据集 DukeMTMC-reID 上进行实验的结果。因为数据集中的摄像头数量较多，所以从八个摄像头中随机挑选出四组（1、3、5、7 号摄像头），进行风格转换后的行人图像展示。其中，（a）为 1 号摄像头风格转换结果，（b）为 3 号摄像头风格转换结果，（c）为 5 号摄像头风格转换结果，（d）为 7 号摄像头风

格转换结果。




图 3.10 CUHK03 数据集摄像头风格转换结果图

图 3.10 是在数据集 CUHK03 上的实验结果,因为该数据集中的摄像头数量较少,只有两个,所以全部进行了展示。其中, (a) 为 1 号摄像头风格转换结果, (b) 为 2 号摄像头风格转换结果

在图 3.8、图 3.9 和图 3.10 中,虚线左边表示数据集中真实行人图像及对应的摄像头编号,虚线右边表示生成的不同摄像头风格的行人图像及对应的摄像头编号。

从实验结果中可以看出, PersonGAN 可以生成同一行人在不同摄像头下的图像,并对光照、背景等进行了改变。同时,生成的图像尽可能地保持了行人的姿态、颜色等具有辨别力的特征不变,从而实现了不同摄像头间的风格转换。

但是,实验结果也表明,在使用 PersonGAN 进行摄像头风格转换时,会出现一些噪声,如图像模糊和行人缺损等。这是由于真实数据集中本身就存在遮挡和检测行人不精确的样本,这些难样本作为输入时,很容易产生噪声数据;再加上使用 PersonGAN 进行风格转换时,难免会发生学习不到真实图像细节特征的现象,从而导致生成图像时出现噪声。

3.3.3 恒等映射损失实验效果验证

前文中提到, PersonGAN 模型中增加了恒等映射损失来对生成图片进行一个约束,从而保持输入图像与输出图像的颜色等细节特征具有一致性,以增强模型的鲁棒性和泛用性。本小节主要对恒等映射损失的约束性进行了验证。

本小节中,首先对未添加恒等映射损失的 PersonGAN 模型进行实验,得到行人的重建图像;其次,保持网络参数不变,在 PersonGAN 中加入恒等映射损失后再次进行实验,得到受恒等映射损失约束的行人重建图像,并将两次实验的结果与真实图片进行对比,如图 3.11 所示。



图 3.11 重建图像对比图

图 3.11 中 (a) 为行人的真实图像, (b) 为加入恒等映射损失前的重建图像, (c) 为加入恒等映射损失后的重建图像。

从图 3.11 的实验结果可以直观地看出, 添加恒等映射损失前的重建图像在颜色等细节方面与真实图像有些许差异; 添加恒等映射损失后的重建图像则与真实图像基本保持一致。为了进一步比较添加前后重建图像的差异, 本小节引入结构相似性 (Structural Similarity, SSIM) 来对图像的相似度进行评价。SSIM $\in [0, 1]$, 它是最常见的图像质量评价方法之一, 其值越接近 1, 表明两张图片越相似。SSIM 的对比结果如表 3.5 所示。

表 3.5 添加恒等映射损失前后 SSIM 对比

行人编号 \ 模型	添加恒等映射损失前的 PersonGAN	添加恒等映射损失后的 PersonGAN
I	0.9517	0.9804
II	0.9473	0.9736
III	0.9635	0.9869
IV	0.9665	0.9886

表 3.5 的实验结果表明, PersonGAN 模型添加恒等映射损失后, 其重建图像的 SSIM 明显较高, 从而验证了本章提出的恒等映射对于网络的约束是有效的。

3.3.4 与其他方法对比

本小节主要与目前主流的 DCGAN^[28]行人生成模型进行对比。实验结果如图 3.12 所示。



图 3.12 不同 GAN 模型生成图像对比图

从图 3.12 可以看出, DCGAN 模型生成的行人图像具有缺损、模糊、形变过大等问题, 导致难以直观地辨别出行人类别。与 DCGAN 模型相比, PersonGAN 模型生成的行人图像明显具有更好的效果, 基本保证了行人基本特征不变, 且没有缺损、形变过大等极端现象出现。

上述结果表明, DCGAN 模型并没有给生成器添加约束项, 同时也没有考虑网络层间的约束性, 因此生成的图像会包含更多噪音, 导致行人图像产生较大的形变、缺损和模糊, 显然这是难以作为好的样本进行模型训练的。而 PersonGAN 模型在传统

网络的基础上,充分考虑了原图像与重建图像间的损失以及恒等映射损失,因此生成的行人图像更加接近真实图像,可以作为有效样本加入数据集,进行数据增强。

3.4本章小结

本章中,首先从基本概念、网络结构和算法流程等方面介绍了生成式对抗网络的相关知识。其次,针对行人重识别领域的具体问题,设计了一种改进的 PersonGAN 模型。该模型以 CycleGAN 为基础,并根据行人重识别任务的特点对损失函数进行相应的调整,从而使模型的生成性能更好。最后,通过实验对 PersonGAN 的图像生成效果进行了展示,并与其他方法的对比,对 PersonGAN 模型图像生成效果的提升进行了论证。

第四章 基于联合学习的行人重识别模型

通过前文中的分析可知,不同摄像头的视角、光照条件和捕捉到的行人姿态都不尽相同,即使是同一个行人,在不同摄像头下的图片也会存在很大差异,这给检索行人的任务造成了不少困难。因此,如何建立一个特征提取模型,使其可以学习更具辨别力的行人特征,一直是行人重识别领域的努力方向之一。

在本章中,主要提出了一种鲁棒的联合学习网络(Robust Joint Learning Networks, RJLN)模型以解决特征提取问题。首先,本章对 RJLN 模型的具体组成结构和某些重要参数进行了分析和讨论,其次,在多个数据集上对模型的提升效果和参数的有效性进行验证,并与其它方法进行了对比分析。

4.1 联合学习算法框架 RJLN

基于深度学习的行人重识别方法中,所用到的特征主要分为全局特征和局部特征两类。全局特征一般可以由深度神经网络在行人图片上自适应学习得到,其虽然能够从整体上对行人的可辨别信息进行一定的描述,但是由于结构简单,并缺乏对行人细粒度信息的描述,因此难以区分相似行人之间的差异,从而导致欠拟合。而局部特征一般需要一定的约束去训练得到,其能够学习并表示目标行人的细粒度信息,因此更具有辨别力,但是由于网络结构复杂,有时候会陷入局部极小值点,导致过拟合。因此,本文提出了一种可同时学习行人全局特征和局部特征的网络模型 RJLN,以获得更好的识别准确率并提高模型的鲁棒性, RJLN 的算法框架如图 4.1 所示。




图 4.1 RJLN 算法框架示意图

如图 4.1 所示, 在输入一张行人图片后, 首先使用简化的卷积神经网络作为基础网络对低级特征进行提取, 得到初始特征图 (feature map)。根据现有主流深度神经网络的表现, 本文主要采用 ResNet50 作为提取行人特征的基础网络, 但是将均值池化层、全连接层及之后的网络层全部去除以减少网络中的冗余参数。

其次, 再将提取到的低级特征分为两支, 分别送入全局分支和局部分支进行处理。在全局分支网络和局部分支网络中, 分别对低级特征进行更进一步的特征提取, 并各自进行分类误差损失函数的计算, 得到全局损失和局部损失。

最后, 给得到全局损失和局部损失赋予不同的权值并进行融合, 从而得到整个网络最终的损失函数。

4.1.1 全局分支网络结构设计

如图 4.1 所示, 全局分支网络主要负责从一整张行人图片中学习最具辨别力的全局特征。

首先, 使用一个全局平均池化层 (Global Average Pooling Layer) 替代 ResNet50 中去除的均值池化层和全连接层来对初始特征进行映射, 即将低维特征映射为一个 2048 维的特征向量。

然后, 将全局平均池化层输出的特征送入到全局网络优化层中来获得更好的特征向量。全局网络优化层主要由线性层 (Liner Layer)、批正则化层 (Batch Normalize Layer)、随机失活层 (Dropout Layer) 等组成。线性层首先进行降维操作, 将前一层输出的 2048 维特征降为 512 维特征, 然后送入批正则化层和随机失活层进行网络的正则化操作。前文中提到, 批正则化层可以在隐层上对每一层网络的输入进行归一化处理, 而随机失活层则可以在训练过程中随机选择隐层中部分节点将其权重置为 0, 两者都可以有效避免过拟合的现象发生。接着, 用一个 Leaky ReLU 激活函数实现非线性映射。

最后, 全局网络优化层输出的 512 维特征会被送入到一个分类器中进行分类, 并计算损失函数。本文选择了一个线性层和 softmax 函数的组合来作为全局分类器, 去预测行人属于某一类别 (ID) 的概率。在训练过程中, 本文选用交叉熵损失 (Cross-Entropy loss) 函数来计算全局分支网络的损失, 具体如下:

$$\text{loss}(x, \text{class}) = -\log \left(\frac{e^{x[\text{class}]}}{\sum_{j=1}^N e^{x[j]}} \right) = -x[\text{class}] + \log \left(\sum_{j=1}^N e^{x[j]} \right) \quad (4-1)$$

其中, $x \in \mathbb{R}^N$ 表示特征向量, N 表示特征向量 x 的维度, $class \in [0, C]$ 表示行人所属的类别, C 表示类别总数。

4.1.2 局部分支网络结构设计

如图 4.1 所示, 局部分支网络主要负责从被分割好的行人特征块中学习最具辨别力的局部特征。

首先, 局部分支网络对初始特征图进行一个均匀的水平分割, 将其分为 M 个水平条纹 (stripe)。

其次, 被分割后的水平条纹会被送入到本文提出的一个专门用来处理局部特征的模型——强化局部基础网络 (Strong Part-base Networks, SP_Net) 中去进行细粒度的特征提取, SP_Net 的网络结构与传统的简单网络一样清晰简洁, 且提取局部特征的效果出色, 其具体细节会在 4.2 节中详细介绍。

最后, 通过计算可得到每个水平条纹对应的局部损失, 在将 M 个水平条纹的局部损失进行融合后, 就可以得到局部网络分支的总损失, 即整张行人图片的局部损失。在这里, 局部损失函数采用的也是式 (4-1) 中的交叉熵损失。

4.1.3 全局分支网络与局部分支网络的融合

局部分支和全局分支是在权值共享的基础网络上学习低级特征的, 而且在提取局部特征和全局特征后, 两个分支网络之间又存在一定的相互约束, 这种共享基础网络权值且相互约束的思想就是联合学习。

在得到局部分支网络和全局分支网络各自的损失后, 需要将二者进行融合, 以得到整个网络的总体损失函数。本文认为, 局部特征和全局特征在行人类别的预测过程中起到的作用是不同的。因此, 在构建总损失函数的过程中, 需要给予二者不同的权重。

得益于采用了相同的损失函数去计算局部分支和全局分支的误差损失, 本文可以用如下公式融合二者的损失:

$$\begin{cases} W_{global} + W_{local} = 1 \\ L_{total} = W_{global} \times L_{global} + W_{local} \times L_{local} \end{cases} \quad (4-2)$$

W_{global} 和 W_{local} 分别表示全局损失和局部损失的权重, 并且相加和为 1。 L_{global} 和 L_{local} 分别表示全局损失和局部损失, L_{total} 表示 RJLN 模型的总体损失。显然, 权重对于联合学习以及确定最终行人所属类别有着极重要的意义, 本文将在 4.3.6 节中对如何选取

合适的权重进行详细讨论。

4.2 局部特征提取网络 SP_Net

局部特征提取网络 SP_Net 主要对行人特征被均匀划分后的水平条纹进行细粒度的局部特征提取，是整个框架的核心部分，本节将对其网络结构进行描述并对其中的重要参数进行分析和讨论。

4.2.1 SP_Net 结构设计

本文针对传统的网络进行了一定修改，得到了可以有效提取行人细粒度特征的 SP_Net，其基本结构如图 4.2 所示。




图 4.2 SP_Net 框架示意图

SP_Net 以行人特征图分割后的 M 个水平条纹作为网络的输入，对于每一个水平条纹，SP_Net 首先使用全局平均池化层将其进行下采样，得到 M 个列向量（column vector） p_i ($i=1,2,3\cdots M$)，向量维度为 2048 维。然后使用一个随机失活层进行网络的正则化操作，虽然该网络层没有参数，但是研究者们证明在高维的网络层上进行随机失活可以有效避免模型过拟合，并可显著提高模型的识别准确率。

然后，SP_Net 使用一个核尺寸为 1×1 的卷积层对列向量 p 进行降维操作，根据以往的大量实验，本文将特征维度降到 256 维，得到列向量 q 。在进行降维后，与全局分支网络类似，SP_Net 也有局部网络优化层，其中包含一个批正则化层和一个随机失活层来进行网络正则化，并用 Leaky ReLU 激活函数完成非线性映射。

最后，每一个列向量 q 被送入到局部分类器中去预测输入水平条纹所属的行人类别。和全局网络分类器一样，局部网络分类器也由线性层和的 softmax 函数组合得到，如式 (4-3) 所示：

$$P(i) = \frac{\exp(W_i^T q)}{\sum_{j=1}^{class} \exp(W_j^T q)} \quad (4-3)$$

其中, $class$ 表示类别, $P(i)$ 表示列向量 q 属于类别 i 的概率, W 表示局部分类器可训练的权值矩阵。

4.2.2 SP_Net 参数设计

通过对 SP_Net 网络结构的分析可知, 细粒度级别的特征对提高模型识别准确率有显著效果。而一些关键参数, 如输入图片的大小 (即 $[H; W]$)、初始特征图大小 (即 $[X; Y]$) 以及进行均匀分割时分块的数目 (即 M) 等对 SP_Net 的性能也有很大影响。显然, 在给定输入图像大小 $[H; W]$ 后, $[X; Y]$ 是由基于 CNN 的基础网络中的空间下采样率决定的, 而一些深度目标检测模型的实验结果, 例如 SSD^[51]、R-FCN^[52] 等, 都表明降低网络中的下采样率可以增加特征的粒度。本文中也采用了类似的思想, 通过删除基础网络中的最后一个下采样层降低了空间下采样率, 增加了特征图的大小。实验结果证明, 这种方法仅仅增加了很少的计算时间成本, 但是对于行人重识别的识别准确率提升明显。

通过实验, SP_Net 中的最优参数设置为:

- 输入图像尺寸调整为 384×192 , 其中 384 是输入尺寸的高度, 192 是输入尺寸的宽度, 高宽比为 2: 1。
- 特征图的空间大小设置为 24×12 , 其中 24 是特征图的高度, 12 是特征图的宽度。
- 特征图被均匀划分的数目为 5。特别地, 本文在 4.3.4 节中对水平条纹划分数目 M 进行了实验分析和讨论。

4.3 实验结果与分析

4.3.1 实验配置与参数

本章采用的实验配置与第三章中相同, 使用的基础网络模型为已经预训练好的 ResNet50, 本章实验中使用的数据集主要为 Market-1501, 部分实验用到了 DukeMTMC-reID 数据集和 CUHK03 数据集时会单独说明。

本章中训练时涉及到的参数设置如下: 输入图像尺寸为 384×192 ; 优化算法为小批量随机梯度下降法 (Mini-batch Stochastic Gradient Descent, MSGD)^[53]; 训练迭代 (epoch) 次数为 60; 训练的批尺寸 (batchsize) 为 24; 初始学习率为 0.1, 每 40 次迭代下降 0.01; 动量为 0.9, 权重衰减系数为 5×10^{-4} 。

如图 4.3 所示, 在测试集中, 因为某些行人图片仅包含行人部分躯干, 难以作为

完整的样本进行特征提取，也很难确定其分类结果正确与否。所以在进行测试之前，首先需要对这些图像进行预处理，将其标签设置为-1，表示这些行人图像为负样本，不参与模型的测试过程。



图 4.3 标签为-1 的不完整行人示例图

4.3.2 不同数据增强方法对比

数据增强（Data Augmentation）是深度学习常见的数据预处理方法，其可以提高模型的泛化能力和鲁棒性，本文中主要用来两种方法进行数据增强操作，分别为第三章提出的 PersonGAN 数据增强和随机擦除（random erasing）^[54]。

随机擦除指的是按照一定概率随机确定是否对一张被选择的图像进行处理；确定进行处理后，以一定的面积比范围和高宽比限制，并在不超过图像宽和高的范围内随机选择一块矩形区域，给该区域中所有的像素点随机赋一个 $[0, 255]$ 范围内的值，其具体算法流程如下。

首先，给定随机擦除的概率，设为 p 。对于输入的行人图片 I ，若其不需要进行随机擦除，则不处理，否则计算其面积：

$$S = W \times H \quad (4-4)$$

其中， W 是行人图片的宽度， H 是行人图片的高度。

其次，在给定的面积比范围 (s_l, s_h) 和高宽比范围 (r_l, r_2) 中随机选择得到面积比 s_m 和宽高比 r_e ，则进行擦除操作的矩形面积 S_e 为：

$$S_e = S \times s_m, S_m \in (S_l, S_h) \quad (4-5)$$

根据宽高比 r_e 可得选定进行擦除操作的矩形区域的高度和宽度如下：

$$H_e = \sqrt{S_e \times r_e} \quad (4-6)$$

$$W_e = \sqrt{\frac{S_e}{r_e}} \quad (4-7)$$

最后，在行人图片中随机选择一个像素点 $Pix(x_e, y_e)$ ，若满足条件：

$$\begin{cases} W_e + x_e \leq W, \\ H_e + y_e \leq H \end{cases} \quad (4-8)$$

则将 $(x_e, W_e + x_e, H_e + y_e)$ 作为选定的矩形区域，并对矩形区域内每个像素点分配 $[0, 255]$ 范围内的值。否则，重复上述步骤，直到符合式 (4-8) 的条件为止。其中， x_e 为像素点 Pix 的横坐标， y_e 为像素点 Pix 的纵坐标。经过随机擦除预处理后的图像效果如图 4.4 所示。




图 4.4 随机擦除示意图

PersonGAN 主要是对数据集进行扩充，同时引入一定的噪声，为模型学习提供动量，提高模型的泛化能力；随机擦除是对行人图像进行预处理，模拟遮挡、姿态变化等情况，提高模型的鲁棒性。

本小节将对不同数据增强方法的效果进行验证。实验时，仅改变数据增强的方法，训练时使用的网络框架和参数设置完全相同，均为预训练好的 RJLN 模型及相应的最佳参数。其在 Market-1501、DukeMTMC-reID 和 CUHK03 三个数据集上的对比结果分别如表 4.1，表 4.2 和表 4.3 所示。

表 4.1 不同数据增强方法在 Marker-1501 数据集的实验对比

数据增强方法	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
\	86.1	91.4	93.1	75.3
RE	92.5	96.9	98.2	80.5
PG	90.7	95.6	97.5	77.3
RE+PG	93.7	98.0	98.6	81.9

表 4.2 不同数据增强方法在 DukeMTMC-reID 数据集的实验对比

数据增强方法	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
\	77.5	86.3	90.6	65.2
RE	83.7	92.5	96.2	71.5
PG	81.3	90.5	94.4	68.8
RE+PG	85.5	94.5	97.9	73.1

表 4.3 不同数据增强方法在 CUHK03 数据集的实验对比

数据增强方法	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
\	56.5	74.8	83.4	50.6
RE	63.0	80.1	89.1	58.2
PG	65.5	80.2	90.3	60.6
RE+PG	66.9	84.8	90.6	61.3

表 4.1、表 4.2 和表 4.3 中，“\”表示没有进行数据增强，RE 表示使用随机擦除方法进行数据增强，PG 表示使用 PersonGAN 进行数据增强。从表 4.1 至表 4.3 的结果可以看出：

(1) 使用随机擦除和 PersonGAN 两种数据增强方式均有助于提高模型的识别准确率，且二者结合使用，提升效果要优于单独使用某一种数据增强方式。

(2) 在 Market-1501 数据集和 DukeMTMC-reID 数据集上，使用 PersonGAN 进行数据增强时的 rank-1、rank-5、rank-10 准确率和 mAP 均低于使用随机擦除进行数据增强时的 rank-1、rank-5、rank-10 准确率和 mAP；但是在 CUHK03 数据集上进行数据增强时，其结果刚好相反。

实验结果表明，在行人图片数量较多的数据集上，使用随机擦除进行数据增强效果较好，而在行人图片数量较少的数据集上，使用 PersonGAN 进行数据增强的效果较好。通过第三章中的实验分析可以得知，这是因为利用 PersonGAN 进行样本生成时，难免会生成噪声图像，当使用包含这些图像样本的数据集进行实验时，虽然可以解决

数据量不足导致的过拟合问题，但是会给整个实验引入额外的噪声。当摄像头数目较少，数据集中图片数目不充足时，生成图像的噪声虽然也会造成干扰，但是由于数据集得到了扩充，其数据增强的效果占主导地位，因此提升效果仍然明显；当相机摄像头数目较多，数据集中行人图片数量充足时，生成的图片噪声影响较大，其弊端也就更加明显，因此效果较差。而二者结合时，随机擦除的效果可以在一定程度上抑制 PersonGAN 噪声带来的干扰，因此模型的效果识别准确率更高。

4.3.3 RJLN 识别准确率提升验证

在 RJLN 框架中，本文提出将全局特征和局部特征同时纳入考虑以提高识别准确率，因此分别设计了全局分支网络和局部分支网络。其中，全局分支网络用来提取行人的全局特征，从整体上对行人进行描述；局部分支网络用来提取行人的局部特征，从细粒度层面对行人进行描述。两者从不同层面对行人具有辨别力的特征进行学习，并相互约束，从而达到提升识别准确率的目的。

本小节中，主要通过实验去验证两个分支网络的不同作用。首先去除局部分支，验证全局分支的检索性能；其次，保留局部分支，去除全局分支验证其检索性能；最后，将二者融合，验证完整网络模型的检索性能。本节比较了三者在三个数据集上的 rank-1、rank-5、rank-10 准确率及 mAP 值，实验结果如表 4.4、表 4.5 和表 4.6 所示。

表 4.4 不同分支网络在 Market-1501 数据集上的实验对比

分支网络	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
local	88.3	95.6	97.5	76.3
global	87.1	94.8	96.1	70.3
RJLN	93.7	98.0	98.6	81.9

表 4.5 不同分支网络在 DukeMTMC-reID 数据集上的实验对比

分支网络	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
local	80.3	91.5	95.2	69.4
global	78.9	90.6	94.0	62.5
RJLN	85.5	94.5	97.9	73.1

表 4.6 不同分支网络在 CUHK03 数据集上的实验对比

分支网络	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
local	60.7	79.4	86.5	55.4
global	59.1	78.0	85.1	50.5
RJLN	66.9	84.8	90.6	61.3

表 4.4、表 4.5、表 4.6 中, local 表示仅使用局部分支网络, global 表示仅使用全局分支网络, RJLN 表示本文提出的同时使用全局和局部特征的联合学习网络。从表 4.4、表 4.5 和表 4.6 的结果可以看出:

(1) 与全局分支网络相比, 局部分支网络的识别准确率明显更优, 其 rank-1、rank-5、rank-10 准确率等略高于全局分支网络, 其 mAP 值明显高于全局分支网络。

(2) 虽然全局分支网络的性能略逊于局部分支网络, 但是与局部分支网络结合之后的构成的 RJLN, 在 rank-1、mAP 等方面明显优于仅单独使用一个分支网络时的模型。

上述实验结果表明, 相较于全局特征, 局部特征能够关注到行人更具辨别力的细粒度特征, 因此局部分支网络在行人检索能力上比全局分支网络有了明显提升, 这也充分验证了局部特征用于行人重识别的有效性。而全局分支网络与局部分支网络融合后, 对于整体网络的性能有了明显提升, 这说明局部特征和全局特征具有一定的互补作用, 从而验证了本文提出的联合学习模型 RJLN 对于提高行人重识别的准确率是有效的。

4.3.4 RJLN 鲁棒性提升验证

因为行人的躯干包含了衣服颜色、姿态特征等人体大部分信息, 所以全局特征主要关注行人的躯干部分, 而忽略了行人的一些细节信息, 因此是粗粒度特征; 而局部特征主要关注分块后的行人特征, 可以学习到行人的细节信息, 因此是细粒度特征。基于联合学习的模型 RJLN 可以同时学习这两种特征, 所以在识别准确率和鲁棒性等性能上具有显著优势。

识别准确率的提升在上一小节中已经得到验证, 本小节中, 主要对模型的鲁棒性进行验证。在实验中, 首先给定一个可视为难样本的待查询行人图像(视角为背面); 其次, 加载本文中提出的网络模型, 在候选图像集上检索该行人并列出判定为相同行人的 10 个图像, 并按相似度大小进行排序; 最后, 对检索结果进行验证: 如果检索到的行人与待查询图像中的行人身份(id)相同, 则用绿色标记标记其序号; 如果检索到的行人与待查询图像中的行人身份(id)不同, 则用红色标记标记。为了更好地进行说明, 本文对行人重识别的结果进行了可视化处理结果, 其结果如图 4.5 所示。



(a) 仅包含全局分支网络的模型对应的检索结果



图 4.5 行人重识别的可视化结果图

图 4.5 中，(a) 为仅有全局分支网络的模型的检索结果，(b) 为仅有局部分支网络的模型的检索结果，(c) 为 RJLN 模型的检索结果。从实验结果中可以看出，随机给定行人图像后，当仅考虑全局特征或局部特征时，其检索结果都出现了一定偏差；而 RJLN 的检索结果均正确，没有出现错误检索行人的情况。

上述实验结果表明，全局特征和局部特征在描述行人时都具有一定的局限性，因此仅学习全局特征或局部特征的模型提取到的行人特征鲁棒性均欠佳；而 RJLN 模型因为同时学习了全局和局部两种特征，所以获得的行人特征具有更好的鲁棒性，其检索结果明显优于前两种方法。

4.3.5 不同分块数对网络的影响

在前文中的网络结构介绍中曾提到，在局部分支网络中，首先要对行人的特征图进行划分，再将划分后的水平条纹送入 SP_Net 进行局部特征提取。显然，分块的数目不同，对于 SP_Net 的结果也有不同影响，进而会影响整个模型的性能。

本小节中，主要在数据集 Market-1501 上对不同分块数带来的影响进行了探究和分析，并寻找最佳分块数。实验中，从 $M=1$ 开始，逐步增加 M 的大小，并计算其对应的 rank-1 准确率和 mAP，直到 $M=7$ 为止。得到的实验结果如图 4.6、图 4.7 所示。需要注意的是，当 $M=1$ 时，分块数目为 1，此时并不对特征图进行划分操作，网络学习到的就是全局特征。

在图 4.6、图 4.7 中，横坐标均表示局部分支网络中分块的数目，纵坐标分别表示 rank-1 准确率和 mAP。从图 4.6、4.7 的结果中可以看出：




图 4.6 不同分块数与 rank-1 准确率坐标图




图 4.7 不同分块数与 mAP 坐标图

(1) 开始时, 随着分块数 M 的增加, rank-1 准确率和 mAP 也是在不断上升的, 且趋势明显, 并在 $M=5$ 时达到极值。

(2) 当 M 的值超过 5 后, 随着分块数的增加, rank-1 准确率和 mAP 反而开始不断下降, 且趋势明显。

上述实验结果表明, 当分块数刚开始增加时, 模型的性能会不断提升, 这是因为 $M > 1$ 时, 训练过程中开始把行人的局部特征纳入考虑, 网络学习到了行人的细粒度特征, 所以模型的识别准确率有所提升。但是, 随着 M 不断增加, 分块后局部区域的大小不断缩减, 每一块行人局部区域所包含的信息量也在不断减少, 所以提取到的

特征向量逐渐不能与行人类别建立起良好的映射。此外，随着分块数目的不断增多，网络的参数也大大增加，这也给网络模型的优化带来了极大的困难。因此，当 M 的值超过 5 后，模型的性能开始下降。

4.3.6 网络权重的影响

前文中提到，在计算网络总损失函数时，由于局部特征和全局特征的对于行人的描述能力不同，因此不能简单地将全局损失和局部损失进行直接融合，而是应该根据全局特征和局部特征在最终确定行人所属类别时所起到的作用，赋予二者不同的权重，从而使联合学习的网络能够获得最佳性能。本小节中，主要通过实验探究并验证网络权重的最佳取值，所使用的数据集为 Market-1501。

在实验中，首先将局部损失权重和全局损失权重分别设置为可训练变量 W_1 、 W_2 并赋予初值；其次，将 W_1 、 W_2 和网络中其他参数一同训练并根据实验结果不断优化；最后，通过多次迭代， W_1 、 W_2 的值逐渐趋于稳定，即可得到网络模型的最佳权重。根据实验得出，局部损失的最佳权重 W_{local} 为 0.2995，全局损失的最佳权重 W_{global} 为 0.7005，此时，模型的 rank-1 准确率达到 93.7%，mAP 达到 81.9%。为了验证最佳网络权重的有效性，本文以 0.1 为间隔，把局部损失权重从 0 到 1 进行划分，并分别进行实验，然后就不同权重对行人重识别结果的影响进行了探究和分析。要注意的是，当局部权重设置为 0 时，代表仅考虑全局损失；当局部权重设置为 1 时，代表仅考虑局部损失。实验结果如图 4.8、图 4.9 所示。

在图 4.8、图 4.9 中，横坐标均表示局部损失函数的权重，纵坐标分别表示 rank-1 准确率和 mAP。从图 4.8、图 4.9 的实验结果可以看出：

(1) 当仅考虑全局或局部特征时，无论联合学习模型的权值是否为最佳取值，其 rank-1 准确率和 mAP 与基于联合学习的模型相比都有明显差距，这也进一步验证了 4.3.3 节的实验结论。

(2) 当局部损失函数的权重为 0.3 时，模型的 rank-1 准确率，mAP 均达到最大值，分别为 93.6%，81.9%，与取最佳权重 0.2995 时的实验结果基本持平。当局部损失取值范围在 $[0, 0.3)$ 时，随着局部损失权重的增加，rank-1 准确率和 mAP 也在不断增加，但这种性能的提升并不是一直持续的，在 $(0.3, 1]$ 范围内，随着局部损失权重的增加，模型的性能开始下降。

上述实验结果说明，网络中训练得到的局部损失最佳权重是有效的。当权重越趋近于最佳取值时，模型的性能越好，权重过低或过高，模型的性能都会下降，这表明局部特征和全局特征在同时用来描述行人时存在一个平衡点，二者相互制约。此外，局部损失和全局损失的权重并不相同，这验证了局部特征和全局特征对于行人的描述作用存在差异，也证明了本文提出给予二者不同损失的方法是正确且必要的。




图 4.8 局部损失函数权重与 rank-1 准确率坐标图




图 4.9 局部损失函数权重与 mAP 坐标图

4.3.7 与其他方法对比

为了验证本文提出的基于联合学习的行人重识别模型 RJLN 的性能，本小节在 Market-1501、DukeMTMC-reID、CUHK03 三个数据集上将 RJLN 模型与目前常见的行人重识别模型进行对比。所有的结果都是在单查询样本 (single-query) 和没有进行重排序 (re-ranking) 情况下得到的。在 Market-1501 数据集上，主要比较了 rank-1、rank-5、rank-10 准确率和 mAP，在 DukeMTMC-reID 和 CUHK03 数据集上，主要比较了 rank-1 准确率和 mAP。实验结果如表 4.7、表 4.8 和表 4.9 所示。

表 4.7 RJLN 与不同模型在 Market-1501 数据集上的实验对比

模型	rank-1(%)	rank-5(%)	rank-10(%)	mAP(%)
BoW+kissme ^[45]	44.4	63.9	72.2	20.8
WARCA ^[55]	45.2	68.1	76.0	-
KLFDA ^[56]	46.5	71.1	79.9	-
SOMAnet ^[57]	73.9	-	-	47.9
SVDNet ^[58]	82.3	92.3	95.2	62.1
PAN ^[59]	82.8	-	-	63.4
Transfer ^[60]	83.7	-	-	65.5
Triplet Loss ^[23]	84.9	94.2	-	69.1
DML ^[61]	87.7	-	-	68.8
MultiRegion ^[62]	66.4	85.0	90.2	41.2
HydraPlus ^[63]	76.9	91.3	94.5	-
PAR ^[64]	81.0	92.0	94.7	63.4
MultiLoss ^[65]	83.9	-	-	64.4
PDC ^[66]	84.4	92.7	94.9	63.4
PartLoss ^[67]	88.2	-	-	69.3
MultiScale ^[68]	88.9	-	-	73.1
GLAD ^[14]	89.9	-	-	73.9
PCB ^[69]	92.3	-	-	77.4
RJLN	93.7	98.0	98.6	81.9

表 4.8 RJLN 与不同模型在 DukeMTMC-reID 数据集上的实验对比

模型	rank-1 (%)	mAP (%)
BoW+kissme ^[45]	25.1	12.2
LOMO+XQDA ^[70]	30.8	17.0
PAN ^[59]	71.6	51.5
TriNet+RE ^[53]	73.0	56.6
SVDNet ^[58]	76.7	56.8
MultiScale ^[69]	79.2	60.6
SVDNet+RE ^[53]	79.3	62.4
PCB ^[69]	81.8	66.1
PartLoss ^[67]	84.4	69.3
RJLN	85.5	73.1

表 4.9 RJLN 与不同模型在 CUHK03 数据集上的实验对比

模型	rank-1 (%)	mAP (%)
BoW+kissme ^[45]	6.4	6.4
LOMO+XQDA ^[70]	12.8	11.5
PAN ^[59]	36.3	34.0
TriNet+RE ^[53]	55.5	50.7
SVDNet ^[58]	41.5	37.3
MultiScale ^[69]	40.7	37.0
SVDNet+RE ^[53]	48.7	43.5
PCB ^[69]	61.3	54.2
RJLN	66.9	61.3

表 4.7 中，用作对比的方法被分为 3 组：1.基于手工特征的方法；2.基于全局特征的深度学习方法；3.基于局部特征的深度学习方法。从表 4.7、表 4.8 和表 4.9 的实验结果可以看出，在 Market-1501、DukeMTMC-reID 和 CUHK03 三个数据集上，本文中提出的 RJLN 模型都具有一定的优越性。与早期的基于手工特征方法相比，RJLN 模型在性能上有着巨大的提升，与目前主流的基于深度学习的方法相比，RJLN 模型也具有小幅的领先。实验结果证明了 RJLN 模型在行人重识别任务中的有效性。

4.4 本章小结

本章首先分析了行人重识别课题中特征提取的难点，并在此基础上，提出了一种基于联合学习的行人重识别模型 RJLN。其次，对 RJLN 模型的全局分支网络、局部分支网络以及二者的融合做了详细介绍。再次，对本文提出的局部特征提取网络 SP_Net 模型进行了详细介绍，在分析了其网络结构后，对网络的重要参数进行了讨论。最后，本文通过实验对 RJLN 模型中各模块的作用及重要参数进行了验证，并与其他行人重识别方法做了全面的对比，验证了本文提出的模型在识别准确率和鲁棒性上都具有一定的优越性。

第五章 总结与展望

5.1 工作总结

预防公共犯罪问题、维护公共安全一直是备受关注的社会话题之一，而城市视频监控系统作为维护治安的重要手段，其技术更新显得尤为必要。随着视频监控技术的发展和监控数据的日益增加，在给定目标行人后，如何迅速在多摄像头获得的视频或图片集中获取目标，并进行追踪，成为亟待解决的问题。显然，低效的人工检索方法在人力和时间成本上花销太大；而受制于不同摄像头下背景不同、行人姿态不同、光照条件不同等因素，传统的行人重识别方法在识别性能上又难以达到要求。因此，本文针对行人重识别问题展开研究，并通过深度学习方法来获得可以对行人精确检索的模型，主要研究成果如下：

（1）目前大部分行人数据集都存在图像数量不足的问题。针对此问题，本文提出了一种基于生成式对抗网络的改进模型 **PersonGAN**。与传统 GAN 模型不同，**PersonGAN** 模型通过循环一致性损失和本文提出的恒等映射损失对网络进行了约束，从而更好地模拟生成不同摄像头风格的行人图片。实验证明，**PersonGAN** 不仅可以有效对数据集进行扩充，而且生成的某些图片具有一定的噪声，可以增强模型的鲁棒性和泛用性。

（2）行人图像易受到背景环境变化、摄像头角度变化、行人姿态变化等干扰，因此难以提取具有辨别力的特征。针对此问题，本文提出了一种基于联合学习的行人重识别模型 **RJLN**。该模型是基于表征学习的网络模型，先通过基础网络提取行人的低级特征，然后分为全局网络和局部网络两个分支，同时提取目标行人的全局特征和局部特征，以提高模型的学习能力，使模型的识别准确率和鲁棒性均得到较大提升。

（3）传统的局部特征提取网络，通常需要在额外的数据集和网络上进行预训练，不仅结构复杂，且迁移效果欠佳。针对此问题，本文提出了一种结构简洁、效果优良的局部特征提取网络 **SP_Net**。与以往的利用关键点定位、姿态估计等方法不同，**SP_Net** 模型不需要一个额外的网络进行预处理，而是直接以行人特征图水平分割后的条纹作为网络输入，并使用本文提出的改进结构对划分后的水平条纹进行细粒度特征的提取。

综上，本文从优化网络结构和数据增强两个方面对行人重识别问题进行了探究，并且就二者对行人重识别模型性能的提升效果进行了分析和验证。

5.2 未来展望

近些年来，行人重识别的研究如火如荼，许多专家学者都投身于获得更鲁棒、识别准确率更高的模型中。本文的研究虽然取得了一定的成果，但是仍然存在诸多不足。因此，本文认为可以从以下几个方面做进一步的探究：

(1) 将本文提出的 PersonGAN 模型应用到不同数据集上，以平滑不同数据集之间的差异。与不同摄像头之间的行人图像存在差异类似，不同数据集之间也有着巨大的差异，因此在一个数据集上表现良好的模型不能直接应用于另一个数据集上。虽然也有相关学者进行迁移学习的研究，但是网络结构复杂且迁移效果欠佳。而本文提出的 PersonGAN 模型已经被证明是可以进行摄像头风格的转换，所以，以后的研究可以尝试对数据集进行风格的转换，并与迁移学习结合，从而提升模型的泛用性。

(2) 现有的行人重识别模型都是基于有监督训练的，但实际生活中，获取到的行人目标通常是没有强监督信息（如标签）的。针对此问题，可以将以后的工作重心放在基于无监督的行人重识别上。对于摄像头获取到的行人图像，首先根据行人图像的时空属性（如行人某时刻在摄像头 A 下出现，则此时刻一定不可能出现在其他摄像头下），对行人的活动轨迹进行预测，从而对某摄像头下行人是否可能出现进行辅助判断。然后结合 RJLN 模型提取到的行人特征，对该行人图像类别进行综合判断。

总而言之，行人重识别目前的发展仍然有很大的探索空间，如何结合实际，设计并实现一个识别准确率高、泛用性和鲁棒性强的行人重识别模型，仍然是今后研究的重点方向。

参考文献

- [1] 宋婉茹, 赵晴晴, 陈昌红,等. 行人重识别研究综述[J]. 智能系统学报, 2017, 12(06):770-780.
- [2] 陈首兵, 王洪元, 金翠,等. 基于孪生网络和重排序的行人重识别[J]. 计算机应用, 2018, 38(11):3161-3166.
- [3] Lecun Y , Bengio Y , Hinton G . Deep learning.[J]. Nature, 2015, 521(7553):436.
- [4] 朱大奇. 人工神经网络研究现状及其展望[J]. 江南大学学报, 2004, 3(1):103-110.
- [5] Flickr CAI Q, AGGARWAL J K. Tracking human motion using multiple cameras [C]International Conference on Pattern Recognition. Vienna, Austria, 1996.
- [6] GHEISSARI N, SEBASTIAN T B, HARTLEY R. Person re-identification using spatiotemporal appearance[C]IEEE Conference on Computer Vision and Pattern Recognition. New York, USA, 2006.
- [7] GRAY D, BRENNAN S, TAO H. Evaluating appearance models for recognition, reacquisition, and tracking[J]. International journal of computer vision, 2007, 89(2): 56–68.
- [8] Gong S, Cristani M, Yan S, et al. Person Re-Identification[J]. Advances in Computer Vision & Pattern Recognition, 2014, 42(7):301-313.
- [9] Mengyue Geng, Yaowei Wang, Tao Xiang, et al. Deep transfer learning for person reidentification[J]. arXiv preprint arXiv:1611.05244, 2016.
- [10] Yutian Lin, Liang Zheng, Zhedong Zheng, et al. Improving person re-identification by attribute and identity learning[J]. arXiv preprint arXiv:1703.07220, 2017.
- [11] Liang Zheng, Yi Yang, Alexander G Hauptmann. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [12] Matsukawa T , Suzuki E . Person re-identification using CNN features learned from combination of attributes[C] 2016 23rd International Conference on Pattern Recognition (ICPR). IEEE, 2016.
- [13] Rahul Rama Varior, Bing Shuai, Jiwen Lu, et al. A siamese long short-term memory architecture for human re-identification[C]European Conference on Computer Vision. Springer, 2016:135–153.
- [14] Zhao H , Tian M , Sun S , et al. Spindle Net: Person Re-identification with Human Body Region Guided Feature Decomposition and Fusion[C] 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2017.
- [15] Liang Zheng, Yujia Huang, Huchuan Lu, Yi Yang. Pose invariant embedding for deep person reidentification[J]. arXiv preprint arXiv:1701.07732, 2017.
- [16] Longhui Wei, Shiliang Zhang, Hantao Yao, Wen Gao, Qi Tian. GLAD: Global-Local-Alignment

- Descriptor for Pedestrian Retrieval[J]. arXiv preprint arXiv:1709.04329, 2017.
- [17] Li W , Zhao R , Xiao T , et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C] 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2014.
- [18] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C] Computer Vision & Pattern Recognition. 2015.
- [19] Subramaniam A, Chatterjee M, Mittal A. Deep neural networks with inexact matching for person re-identification[C] Advances in Neural Information Processing Systems.2016.
- [20] Rahul Rama Varior, Bing Shuai, Jiwen Lu, Dong Xu, Gang Wang. A siamese long short-term memory architecture for human re-identification[C]European Conference on Computer Vision. Springer, 2016.
- [21] Florian Schroff, Dmitry Kalenichenko, James Philbin. Facenet: A unified embedding for face recognition and clustering[C]Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.2015.
- [22] Liu H , Feng J , Qi M , et al. End-to-End Comparative Attention Networks for Person Re-identification[J]. IEEE Transactions on Image Processing, 2017:1-1.
- [23] De Cheng, Yihong Gong, Sanping Zhou, Jinjun Wang, Nanning Zheng. Person re-identification by multichannel parts-based cnn with improved triplet loss function[C]Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016.
- [24] Weihua Chen, Xiaotang Chen, Jianguo Zhang, Kaiqi Huang. Beyond triplet loss: a deep quadruplet network for person re-identification[J]. arXiv preprint arXiv:1704.01719, 2017.
- [25] Alexander Hermans, Lucas Beyer, Bastian Leibe. In defense of the triplet loss for person reidentification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [26] Xiao Q, Luo H, Zhang C. Margin Sample Mining Loss: A Deep Learning Based Method for Person Re-identification[J]. arXiv preprint arXiv:1710.00478, 2017.
- [27] Goodfellow I J , Pouget-Abadie J , Mirza M , et al. Generative Adversarial Nets[C]International Conference on Neural Information Processing Systems. MIT Press, 2014.
- [28] Mirza M, Osindero S. Conditional Generative Adversarial Nets[J]. Computer Science, 2014:2672-2680.
- [29] Denton E , Chintala S , Szlam A , et al. Deep Generative Image Models using a Laplacian Pyramid of Adversarial Networks[J]. arXiv preprint arXiv:1506.05751, 2015.
- [30] Radford A , Metz L , Chintala S . Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks[J].Computer Science, 2015.
- [31] Im D J , Kim C D , Jiang H , et al. Generating images with recurrent adversarial networks[J].

- arXiv preprint arXiv:1602.05110, 2016.
- [32] Larsen A B L , Sønderby, Søren Kaae, et al. Autoencoding beyond pixels using a learned similarity metric[J].arXiv preprint arXiv:1512.09300, 2015.
- [33] Chen X , Duan Y , Houthoof R , et al. InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets[J].arXiv preprint arXiv:1606.03657, 2016.
- [34] Arjovsky M , Bottou, Léon. Towards Principled Methods for Training Generative Adversarial Networks[J]. Stat, 2017.
- [35] Zhu J Y , Park T , Isola P , et al. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks[J].arXiv preprint arXiv:1703.10593, 2017.
- [36] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[J].arXiv preprint arXiv:1701.07717, 2017.
- [37] Zhong Z , Zheng L , Zheng Z , et al. Camera Style Adaptation for Person Re-identification[J]. arXiv preprint arXiv:1711.10295, 2017.
- [38] Deng W , Zheng L , Ye Q , et al. Image-Image Domain Adaptation with Preserved Self-Similarity and Domain-Dissimilarity for Person Re-identification[J].arXiv preprint arXiv:1711.07027, 2017.
- [39] Wei L , Zhang S , Gao W , et al. Person Transfer GAN to Bridge Domain Gap for Person Re-Identification[J].arXiv preprint arXiv:1711.08565, 2017.
- [40] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex.[J]. Journal of Physiology, 1962, 160(1): 106-154.
- [41] Fukushima K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position[J]. Biological Cybernetics, 1980, 36(4):193-202.
- [42] Cun Y L, Boser B, Denker J S, et al. Handwritten digit recognition with a back-propagation network[J]. Advances in Neural Information Processing Systems, 1990, 2(2):396--404.
- [43] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(3):533-536.
- [44] Krizhevsky A , Sutskever I , Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[C]Advances in neural information processing systems.2012.
- [45] Zheng L , Shen L , Tian L , et al. Scalable Person Re-identification: A Benchmark[C] 2015 IEEE International Conference on Computer Vision (ICCV). IEEE Computer Society, 2015.
- [46] Li W , Zhao R , Xiao T , et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C] 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2014.
- [47] Ristani E , Solera F , Zou R S , et al. Performance Measures and a Data Set for Multi-Target,

- Multi-Camera Tracking[J].arXiv preprint arXiv:1609.01775, 2016.
- [48] Isola P , Zhu J Y , Zhou T , et al. Image-to-Image Translation with Conditional Adversarial Networks[J].arXiv preprint arXiv:1611.07004, 2016.
- [49] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J].arXiv preprint arXiv:1512.03385, 2015.
- [50] Mao X , Li Q , Xie H , et al. Least Squares Generative Adversarial Networks[J].arXiv preprint arXiv:1611.04076, 2016.
- [51] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C] European Conference on Computer Vision. 2016.
- [52] Dai J , Li Y , He K , et al. R-FCN: Object Detection via Region-based Fully Convolutional Networks[J].arXiv preprint arXiv:1605.06409, 2016.
- [53] Qi Q, Rong J, Yi J, et al. Efficient distance metric learning by adaptive sampling and mini-batch stochastic gradient descent (SGD)[J]. Machine Learning, 2013, 99(3):353-372.
- [54] Zhong Z, Zheng L, Kang G, et al. Random Erasing Data Augmentation[J].arXiv preprint arXiv:1708.04896, 2017.
- [55] Jose C , Fleuret F . Scalable Metric Learning via Weighted Approximate Rank Component Analysis[J].arXiv preprint arXiv:1603.00370, 2016.
- [56] S. Karanam, M. Gou, Z. Wu, et al. A comprehensive evaluation and benchmark for person re-identification: Features, metrics, and data sets[J]. arXiv preprint arXiv: 1605.09653, 2016.
- [57] Barbosa I B , Cristani M , Caputo B , et al. Looking beyond appearances: Synthetic training data for deep CNNs in re-identification[J]. Computer Vision and Image Understanding, 2017:S1077314217302254.
- [58] Sun Y , Zheng L , Deng W , et al. SVDNet for Pedestrian Retrieval[J]. arXiv preprint arXiv:1703.05693, 2017.
- [59] Zheng W S , Gong S , Xiang T . Reidentification by Relative Distance Comparison[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(3):653-668.
- [60] Geng M , Wang Y , Xiang T , et al. Deep Transfer Learning for Person Re-identification[J]. arXiv preprint arXiv: 1611.05244, 2016.
- [61] Zhang Y, Xiang T, Hospedales T M, et al. Deep Mutual Learning[J].arXiv preprint arXiv:1705.00384, 2017.
- [62] Ustinova E , Ganin Y , Lempitsky V . Multiregion Bilinear Convolutional Neural Networks for Person Re-Identification[J].arXiv preprint arXiv:1512.05300, 2015.
- [63] Zhihui Li, Feiping Nie, Xiaojun Chang, et al. Beyond Trace Ratio: Weighted Harmonic Mean of Trace Ratios for Multiclass Discriminant Analysis[J]. IEEE Transactions on Knowledge\

- s&\sdata Engineering, 2017, PP(99):1-1.
- [64] Zhao L , Li X , Wang J , et al. Deeply-Learned Part-Aligned Representations for Person Re-Identification[J].arXiv preprint arXiv:1707.07256, 2017.
- [65] Li W , Zhu X , Gong S . Person Re-Identification by Deep Joint Learning of Multi-Loss Classification[J].arXiv preprint arXiv:1705.04724, 2017.
- [66] Long M , Zhu H , Wang J , et al. Unsupervised Domain Adaptation with Residual Transfer Networks[J].arXiv preprint arXiv:1602.04433, 2016.
- [67] Yao H , Zhang S , Zhang Y , et al. Deep Representation Learning with Part Loss for Person Re-Identification[J]. IEEE Transactions on Image Processing, 2017.
- [68] Chen Y , Zhu X , Gong S , et al. Person Re-Identification by Deep Learning Multi-Scale Representations[C] 2017 IEEE International Conference on Computer Vision Workshop (ICCVW). IEEE, 2017.
- [69] Sun Y, Liang Z, Yi Y, et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and A Strong Convolutional Baseline)[J].arXiv preprint arXiv:1711.09349, 2018.
- [70] Liao S , Hu Y , Zhu X , et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C] 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2015.

致谢

时光匆匆，三年的研究生学习生活即将拉下序幕，就要挥手对母校说再见了。轻闭上双眼，三年生活如同一幅幅画卷展现在我的脑海，有苦有甜，有哭有笑，经历了很多，成长了很多，也收获了很多。在硕士论文即将完成之际，感谢西安电子科技大学对我的教育和培养，欣喜之余也特地向一直照顾和指导我的老师、家人、同学和朋友们致以最真诚的谢意。

首先，我要衷心的感谢我研究生阶段的导师田玉敏教授，本论文是在田老师的悉心指导下完成的。感谢这三年田老师对我的照顾、指导与帮助。从选择专业课、学习理论知识、摸索科研工作，到论文的选题、实验中遇到的困难、写作指导以及日常生活中的问题等等很多方面，田老师都给予我耐心的帮助、细心的指导并提出宝贵的意见。我在学习、科研中取得的每一个进步都离不开田老师的指导，在论文方面，田老师认真安排我的研究工作，分析我遇到的难题，给予我极大地帮助。田老师认真负责的工作作风，细致严谨的科研态度，宽厚温柔的待人处事都深深地影响着我，一直激励我勇往直前。三年的研究生生涯，田老师对我亦师亦友，让我收获满满，再次送上我最诚挚的谢意。

其次，我要向一直关心我、帮助我、陪伴我的同学朋友们致以最诚挚的感谢。感谢陈娟、石毅杰、彭晨晖、魏永恒、张中才等给与我的帮助，在学习上的指点和日常生活中的关心；感谢实验室的同学们，三年的朝夕相伴和共同成长，研究生的生活有了你们的参与更加丰富多彩；感谢我舍友们在生活上的关心和学习上的帮助，以及在我低落时给与我的包容和鼓励。

再次，我要好好感谢我的父母，他们是一路陪伴我长大的亲人，是我的精神支柱，感谢他们在这段时间里对我的关爱和呵护。感谢父母给了我一个温暖而幸福的家，让我健康快乐的长大；感谢他们磨炼我坚强的意志，让我遇到困难迎难而上、从不轻易放弃；感谢他们对我学业的鼓励与信任，让我始终奔着自己的目标一路前行。

最后，向审阅此文的各位专家和教授致以崇高的敬意和真诚的谢意，谢谢你们百忙之中评阅本论文，希望能够得到各位宝贵的意见与建议。



西安电子科技大学
XIDIAN UNIVERSITY

地址：西安市太白南路2号

邮编：710071

网址：www.xidian.edu.cn