

中国科学技术大学

University of Science and Technology of China

硕士学位论文



论文题目 面向单模态和跨模态场景的无监督行人

重识别方法研究

作者姓名 刘章平

学科专业 网络空间安全

导师姓名 刘斌 副教授

完成时间 二〇二四年五月

中国科学技术大学

硕士学位论文



面向单模态和跨模态场景的无监督行人 重识别方法研究

作者姓名： 刘章平

学科专业： 网络空间安全

导师姓名： 刘斌 副教授

完成时间： 二〇二四年五月二十四日

University of Science and Technology of China
A dissertation for master's degree



Unsupervised Person Re-identification Methods for Single and Cross Modality Scenarios

Author: Liu Zhangping

Speciality: Cyberspace Security

Supervisor: Associate Prof. Liu Bin

Finished time: May 24, 2024

摘要

随着智能视频监控在公共安全领域的需求不断增加,行人重识别已成为计算机视觉领域的一个重要研究方向。然而现有的行人重识别方法大多是标记数据驱动的有监督方法,而身份标注过程耗费的高昂成本阻碍了行人重识别方法的实际应用。因此,无监督行人重识别成为了一个具有实用性和挑战性的课题,根据光照场景和模态差异,又分为面向可见光场景的无监督单模态行人重识别研究,以及面向可见光和红外场景的无监督跨模态行人重识别研究。

当前无监督单模态行人重识别方法采用样本平等优先级的训练方法,忽略了模型对不同噪声程度伪标签的容错能力;此外,当前的无监督跨模态行人重识别方法不论是建立跨模态配对关系还是进行跨模态特征学习,都局限于图像特征层面,忽略了噪声标签对图像特征辨别性的影响,也没有充分利用行人身份的语义信息来缩小两种图像模态间的鸿沟。针对以上问题,本文做出了如下工作:

(1) 针对无监督单模态行人重识别,本文提出了基于双重不确定性引导的课程学习方法。为了抑制噪声标签对模型训练前期的影响,本文利用类簇内样本间的特征亲和力度来估计样本标签的可靠度,然后让模型遵循标签可靠度由高到低的课程学习顺序进行训练。为了能进一步抑制噪声标签,本文提出了双重不确定建模方法来全面地建模样本标签的不确定性,并转化为样本权重来减少高不确定性标签对损失函数的贡献。此外,为了兼顾行人的局部特征线索,本文提出了一种局部细粒度语义感知的全局特征改善方法,进一步增强了模型的识别能力。最后本文在三个单模态主流数据集上进行了大量的对比实验和消融实验,验证了本文所提方法的有效性。

(2) 针对无监督跨模态行人重识别,本文提出了基于视觉语言模型的知识蒸馏方法。为了获得包含行人身份语义信息的数据,本文提出使用多模态大模型来生成可见光和红外图像对应的行人文本描述,并引入图文预训练模型 CLIP 在该图文对数据上进行基于特征蒸馏方法的微调,使其适配到行人重识别这种细粒度检索任务。为了缓解仅依赖图像特征相似度产生的匹配噪声,本文将 CLIP 模型输出的语义信息更丰富的特征作为外部知识注入到跨模态匹配过程中。为了利用文本语义信息来辅助两种图像模态的对齐,本文提出了文本语义增强的模态内表征学习以及对比关系蒸馏的跨模态表征学习。最后本文在两个跨模态主流数据集上进行了大量的对比实验和消融实验,验证了本文所提方法的有效性。

关键词: 无监督; 单模态; 跨模态; 课程学习; 知识蒸馏

ABSTRACT

With the increasing demand for intelligent video surveillance in the field of public safety, Person Re-identification has become an important research task in computer vision. However, most existing Person Re-identification methods are supervised methods driven by labeled data, and the high cost of identity labeling process hinders the practical application of Person Re-identification methods. Therefore, unsupervised Person Re-identification methods have become a challenging but practical topic, which can be further divided into unsupervised single modality Person Re-identification research for visible scenarios and unsupervised cross modality Person Re-identification research for visible and infrared scenarios.

The current unsupervised single modality Person Re-identification methods adopt a training method with equal priority of samples, ignoring the model's noise tolerance ability for pseudo labels with different levels of noise; In addition, current unsupervised cross modality Person Re-identification methods, whether establishing cross modality pairing relationships or conducting cross modality feature learning, are limited to the image feature level, ignoring the impact of noise labels on image feature discrimination, and failing to fully utilize the semantic information of person identity to narrow the gap between the two image modalities. In response to the above issues, this thesis has made the following contributions:

(1) A dual-uncertainty guided curriculum learning approach is proposed for unsupervised single modality Person Re-identification. In order to suppress the influence of noisy labels on the early stage of model training, this thesis estimates the reliability of sample labels by using the feature affinity between samples within the cluster, and then trains the model in the order of label reliability from high to low. In order to further suppress noisy labels, this thesis proposes a dual uncertainty modeling method to comprehensively model the uncertainty of sample labels and convert it into sample weights to reduce the contribution of high uncertainty labels to the loss function. Finally, in order to balance the local feature clues of persons, this thesis proposes a global feature improvement method based on local fine-grained semantic perception, which further enhances the recognition ability of the model. Extensive experiments are conducted on three mainstream datasets for single modality, including comparative experiments and ablation experiments, and the experiments validate the effectiveness of our methods.

(2) A knowledge distillation method based on visual language model is proposed

for unsupervised cross modality Person Re-identification. In order to obtain data containing semantic information of person identity, We propose to use the off-the-shelf multi-modal large model to generate persons' pseudo text descriptions corresponding to visible and infrared images, then we introduce a feature distillation approach to fine-tune CLIP based on the pseudo text dataset, making it suitable for ReID task. In order to alleviate the matching noise caused by relying solely on image feature similarity, we inject richer semantic information contained in CLIP model as external knowledge into the cross modality matching process. In order to exploit text semantic information to facilitate modality alignment, we propose textual-semantics enhancement for intra-modality representation learning and contrastive relational-distillation for cross-modality representation learning.

Key Words: Unsupervised; Single Modality; Cross Modality; Curriculum Learning; Knowledge Distillation

目 录

第 1 章 绪论.....	1
1.1 研究背景与研究意义.....	1
1.2 国内外相关研究现状.....	3
1.2.1 单模态行人重识别.....	4
1.2.2 跨模态行人重识别.....	5
1.2.3 无监督行人重识别.....	6
1.3 本文研究内容.....	8
1.3.1 基于双重不确定性引导课程学习的无监督单模态行人重识别	8
1.3.2 基于视觉语言模型知识蒸馏的无监督跨模态行人重识别	9
1.4 论文组织结构.....	9
第 2 章 相关理论基础与知识	11
2.1 神经网络基础知识.....	11
2.1.1 卷积神经网络结构与性质.....	12
2.1.2 常见深度神经网络模型.....	15
2.2 行人重识别任务概述.....	17
2.3 基于聚类微调的无监督单模态行人重识别方法	19
2.3.1 聚类算法.....	20
2.3.2 训练方法.....	21
2.4 基于特征相似度匹配的无监督跨模态行人重识别方法	23
2.4.1 第一阶段:模态内表征学习	24
2.4.2 第二阶段:跨模态表征学习	25
2.5 行人重识别数据集和评价指标	27
2.5.1 数据集.....	27
2.5.2 评价指标.....	29
2.6 本章小结.....	31
第 3 章 基于双重不确定性引导的课程学习的无监督单模态行人重识别	32
3.1 引言.....	32
3.2 课程学习训练方法.....	33
3.2.1 基于邻居特征亲和力的伪标签可靠度评估模块	33
3.2.2 基于标签可靠度的课程学习训练方法	34
3.3 双重不确定性建模方法.....	35
3.3.1 基于教师-学生的原型预测一致性	35

3.3.2 基于蒙特卡洛 Dropout 的自聚合概率熵	36
3.3.3 标签不确定性感知的损失函数	37
3.4 局部语义感知的全局特征改善	38
3.5 实验与分析	38
3.5.1 实验设置	38
3.5.2 实验结果分析	39
3.6 本章小结	45
第 4 章 基于视觉语言模型知识蒸馏的无监督跨模态行人重识别	47
4.1 引言	47
4.2 基于特征蒸馏的 CLIP 微调方法	49
4.2.1 伪图文对数据的生成与制作	50
4.2.2 基于特征蒸馏的微调	51
4.3 一阶段: 文本语义增强的红外-可见光模态内表征学习	52
4.4 二阶段: 基于对比关系蒸馏的红外-可见光跨模态表征学习	53
4.4.1 基于混合原型分类器的跨模态匹配方法	53
4.4.2 基于关系蒸馏的跨模态对齐	55
4.5 实验与分析	56
4.5.1 实验设置	56
4.5.2 实验结果分析	57
4.6 本章小结	63
第 5 章 总结与展望	64
5.1 本文总结	64
5.2 研究展望	65
参考文献	66

插图清单

图 1.1	行人重识别应用场景	1
图 1.2	行人重识别技术示意图	2
图 1.3	行人重识别研究分类	3
图 1.4	单模态行人重识别常用损失函数	5
图 1.5	跨模态行人重识别原理	6
图 2.1	卷积层运算原理	12
图 2.2	池化层原理	13
图 2.3	常见激活函数	14
图 2.4	常用 ResNet 网络结构	15
图 2.5	ResNet 残差模块原理	15
16figure.caption.25		
图 2.7	行人重识别任务的五个环节	18
图 2.8	无监督单模态行人重识别的主流训练方法	19
图 2.9	无监督行人重识别三种常见的聚类方法	20
图 2.10	SPCL: 基于类簇可靠度的自步学习策略	22
图 2.11	MMT: 基于教师-学生思想的模型结构	22
图 2.12	无监督跨模态行人重识别主流的两阶段训练方法	24
图 2.13	Market1501 可见光单模态数据集	28
图 2.14	DukeMTMC 可见光单模态数据集	28
图 2.15	MSMT17 可见光单模态数据集	29
图 2.16	SYSU-MM01 可见光-红外跨模态数据集	29
图 2.17	Rank-k、召回率和 mAP 的计算演示	30
图 3.1	本章提出的无监督单模态行人重识别算法总览图	33
图 3.2	基于邻居特征亲和力的伪标签可靠度评估模块	33
图 3.3	本章提出的课程学习训练方法	35
图 3.4	参数值对性能影响分析	40
图 3.5	基线模型的 t-SNE 特征分布可视化	41
图 3.6	SPCL 和本文模型的 t-SNE 特征分布可视化	41
图 3.7	Grad-CAM 热力图	43
图 3.8	检索结果可视化	44

图 4.1	同一身份行人可见光和红外图像分别对应的文本	47
图 4.2	本章提出的无监督跨模态行人重识别算法总览图	48
49figure.caption.51		
图 4.4	基于视觉语言大模型 zero-shot 推理生成的行人文本	50
图 4.5	基于特征蒸馏的 VI-CLIP 微调	51
图 4.6	基于混合原型分类器的跨模态匹配方法	54
图 4.7	CLIP 微调时的特征蒸馏残差支路系数 β	60
图 4.8	损失函数权重 λ 和 γ 分析	60
图 4.9	t-SNE 特征分布可视化	62

表格清单


表 2.1	几种常见激活函数	13
表 2.2	无监督单模态行人重识别的两个子方向	19
表 3.1	所提模块的消融性结果	39
表 3.2	与主流无监督单模态方法在 Duke 和 Market 数据集上的对比实验 ...	45
表 3.3	与主流无监督单模态方法在 MSMT 数据集上的对比实验	45
表 4.1	所提模块的消融性结果	58
表 4.2	不同 CLIP 增量微调方法对第一阶段模型的性能影响	58
表 4.3	第二阶段模型采用不同跨模态匹配算法对性能的影响	59
表 4.4	第二阶段模型采用不同关系蒸馏方法对性能的影响	59
表 4.5	与主流无监督跨模态方法在 SYSU 数据集上的对比实验	63
表 4.6	与主流无监督跨模态方法在 RegDB 数据集上的对比实验	63

第1章 绪 论


1.1 研究背景与研究意义

随着近些年人们自身防范意识和公共安全意识的不断增强，越来越多的摄像头已经被用于机场、社区、街道、学校等公共空间。随着技术的不断发展，视频监控系统作为城市安全的捍卫者越来越发挥着举足轻重的作用。自2004年以来，我国先后开展了城市报警与监控系统建设、平安城市建设、天网工程等工作，这些重大项目建设速度的持续加快及社会整体安防意识的提升，不断织密社会治安防控网，大大提升了人民群众的安全感和幸福感。根据新闻报道，欧美发达国家近年的安防视频监控市场持续保持了较快增长，与此同时，在国家关于构建立体化社会治安防控体系的号召下，我国各级政府也在积极推进以视频监控系统为重要组成部分的多个安全防范项目。

2016年8月，国家发改委和公安部等相关部门，联合发布了《关于印发加强公共安全视频监控建设联网应用工作方案的通知》，标志着“雪亮工程”的正式启动，它成为了继“平安城市”与“天网工程”之后，又一维护民众安全的重大举措。为此，公安部积极推进各项科技创新，力求构建一个全域覆盖、全程可控且安全可靠的公共安全视频监控体系，以全力保障人民安全。



(a) 智慧零售



(b) 智能寻人

图 1.1 行人重识别应用场景

视频监控系统作为保障城市安全重大工程的关键组成部分，其重要性不言而喻。在视频监控系统中，我们时常需要从海量的监控录像中锁定特定目标，如行人、车辆等。对于行人搜索而言，人脸识别技术无疑是一项高效且精准的工具。然而当遇到光照不足、视频分辨率低下或拍摄角度不佳等不利条件时，人脸识别技术的效果往往大打折扣，因此不再能满足日益提升的安防需求。此时，利用行人的全身信息来对特定行人进行锁定和查找就显得尤为重要。随着人工智能技术蓬勃发展，行人重识别技术作为一种以行人整体体态、着装等外观信息为基础进行精准搜索的解决方案^[1]，正日益凸显其重要性。该技术不仅广泛应用于公共安防领域，更成为公安部门在视频案件分析过程中提升案件侦破效率和准确性

的一项关键工具。

行人重识别是一种前沿的智能监控技术，其核心在于运用计算机视觉算法实现对跨设备行人图像或视频的精准匹配。简言之，该技术能在给定一个行人查询图像的条件下在不同监控设备的图像库中准确检索出相同的行人。这一过程的实现如图1.2所示，首先依赖于行人检测算法从监控视频中筛选出对应的行人图像库，从而将视频级的搜索问题转化为图像间的匹配问题。随后，通过深度学习技术提取查询图像（query）与候选图像库（gallery）中所有行人图像的特征，并通过对比这些特征的距离，精确检索出目标行人图像。鉴于行人重识别在智能安防、视频监控等领域的广阔应用前景，它已成为计算机视觉领域的研究热点，吸引着众多学者和从业者的关注与探索。




图 1.2 行人重识别技术示意图

然而，当前基于深度学习的行人重识别方法大多是标记数据驱动的有监督方法，而标注数据时会产生大量的人力和财力成本，这阻碍了行人重识别技术投入到实际应用中。近年来，无监督行人重新识别方法 (Unsupervised Person Re-identification, Unsupervised ReID) 因其在利用海量无标注数据方面的巨大潜力而引起了研究人员越来越多的关注，另一方面，在实际监控场景中大量监控视频片段是可以轻易获取的，而对视频进行逐帧处理和行人身份标注将耗费巨大，因此无监督行人重识别方法不论是对学术研究还是实际使用都有很重要的价值。具体来说，无监督行人重识别任务可以分为无监督单模态行人重识别和无监督跨模态行人重识别，前者探索的是基于白天可见光模态这一光照场景，在不提供行人身份标记信息条件下设计行人重识别算法以完成行人检索任务。而后者探索的是更具挑战性的任务，即在白天可见光模态和夜间红外模态这两种都不提供行人身份标记的复杂光照条件下，如何设计性能优良的行人重识别算法，来完成可见光模态和红外模态的跨模态行人互搜任务。可以看到，无监督行人重识别充分探索了无标记数据的分布特点以学习具有辨识性的行人特征，相比于有监督行人重识别方法具有更出色的通用性和可迁移性，因此对于促进行人重识别方法在真实场景落地应用具有重要意义。

1.2 国内外相关研究现状

行人重新识别任务起源于多目标视觉跟踪技术，其发展可以分为两个不同的阶段。2014 年之前，行人重新识别主要依靠传统的手工设计功能^[2-3]。2006 年，Gheissari 等人^[4]使用颜色和显著边缘直方图来完成行人重新识别任务，这是第一次正式提出“行人重新识别”的概念。自 2014 年卷积神经网络首次用于行人重识别领域^[5-6]起，深度学习方法^[7]就成为了行人重识别任务的主流选择，并极大地促进了该领域的发展。行人重识别这一概念自提出至今已有十多年，许多独特的方法思路不断涌现，这一研究课题因其实用性而成为了一个热门研究方向，学者们根据实际应用场景的不同需求，展开了不同细分方向的研究，具体划分方法如图1.3所示。




图 1.3 行人重识别研究分类

在行人重识别的众多研究方向中，从应用场景来看，单模态行人重识别是一项面向白天可见光场景的行人搜索任务，也是学术界最早开始研究的课题。随着视频安防监控需求的日益增长以及科技的不断进步，红外模式摄像头的大规模应用已经显著弥补了可见光摄像头无法全天候使用的缺陷，在此背景下，学者们针对昼夜光照条件变化提出的面向可见光红外场景的跨模态行人重识别任务开始受到关注。因此从**实用性和普及性**角度来看，单模态和跨模态行人重识别是最贴合实际应用场景的两项基础研究。然而，随着平安城市等诸多保障城市安全的重大工程得到深入推进，行人重识别研究在如何**提高数据使用效率**方面也面临了一定的制约。一方面，在实际使用过程中，利用人工标注好的小规模行人数据集来训练行人重识别模型，其识别准确率难以满足复杂场景的需求，另一方面，尽管国内视频监控系统的规模日益庞大并且这些监控设备中的海量视频片段容

易获取,但逐帧进行视频分析和处理来获取人工标注数据是不可取的,这同时也不利于行人重识别模型的大规模普及。因此无监督行人重识别方法因其在利用海量无标注数据方面的潜力开始成为研究热点。

本节首先简要介绍目前国内外主流的行人重识别研究方法,同时为了兼顾应用场景实用性、数据使用高效性以及与本文研究方向的关联性,本文将着重介绍单模态行人重识别、跨模态行人重识别和无监督行人重识别这三个方向,以期本文为后续的研究内容提供直接有效的参考。

1.2.1 单模态行人重识别

传统的单模态行人重识别技术旨在对白天可见光这一模态的视频监控中跨摄像头图像集合建立身份关联^[8],其经常被视为细粒度图像检索的问题。单模态行人重识别研究的核心其实就是使模型学习更具有判别力的行人特征表示,即**表征学习** (Representation Learning)。目前主流的方法可以粗略分为两大类。第一类方法侧重于设计高效的度量学习损失函数。行人身份损失函数将每个身份视为一个特定的分类 ID,因此训练过程被建模成图像分类问题,典型的网络被称为 IDE 网络^[9],作为该领域重要的基准方法被广泛应用在目前的各种研究方法里^[10]。验证损失函数^[6]和对比损失函数^[11-12]用来优化图片两两之间的关系,一般用于训练孪生网络 (siamese network)。孪生网络需要每次输入两张图片,图片会经过一个共享的卷积网络得到两个特征向量将融合起来预测图片是否属于同一个行人。还有部分工作基于多任务学习策略,联合分类损失和验证损失去学习具有判别力的特征^[13-15],更好地提升了模型效果。此外,部分工作利用难样本挖掘策略的三元组损失函数^[16-19] (triplet loss) 来减小类内差异,增大类间差异。上述提到的单模态行人重识别常见损失函数如图1.4所示。第二类方法重点探究利用局部线索来强化特征的判别力,PCB 方法^[20]采用了水平切分的方法获得多个局部的行人图像区域,并针对多个局部区域采用多个分类器学习,在很多论文中有所应用^[21-23]。此外姿态估计^[24]和语义解析^[25]等利用人体姿态关键信息或数据集属性信息来提取局部关键特征的方法也比较有效。

单模态行人重识别研究为后续行人重识别领域的发展提供了许多启发性方法,尤其是其基于各种度量学习损失函数来促进模型学习更有判别力的特征表示的表征学习思想 (Representation Learning),影响了许多后续相关工作。然而随着应用需求和部署场景的不断扩大,只考虑白天可见光这一种光照条件的单模态行人重识别具有一定的局限性。此外,单模态行人重识别严重依赖于图像数据的标签来进行有监督学习 (Supervised Learning),而在现实场景中耗费高昂的人力成本来给行人图像进行身份标注几乎是不可行的。




图 1.4 单模态行人重识别常用损失函数

1.2.2 跨模态行人重识别

跨模态行人重识别技术旨在研究白天行人图像和夜间红外行人图像的相互搜索问题，它在一定程度上弥补了传统单模态行人重识别技术在场景应用上的局限性，其原理如图1.5所示。当前研究的核心在于为如何为每种身份的行人图像提取出与模态无关且具有良好判别力的特征表示，从而显著缩小跨模态语义鸿沟，以实现更精细化的细粒度检索，因此跨模态行人重识别的本质仍然是表征学习（Representation Learning）。现有的跨模态行人重识别研究方法集中于在特征空间或者图像空间显式对齐不同的模态。Ye 等人^[26]利用跨模态度量学习和对抗性学习等方式将不同模态的特征嵌入到一个子空间来消除模态鸿沟。Wang 和 Zheng 等人^[27-28]利用循环生成对抗网络（Cycle-GAN）进行图像翻译，对红外图像和可见光图像在图像层面直接消除跨模态差异。Zhao 等人^[29]提出一致性学习模块来提取衣服颜色无关特征，并通过身份感知的模态自适应模块对齐身份级别跨模态特征分布。Fang 等人^[30]提出了一种端到端的语义对齐和关联推断框架，探索了语义对齐特征学习和关联推断方法在跨模态行人重识别任务的联合应用。Yu 等人^[31]提出了一种跨模态学习器和模态内学习器来生成辅助模态，然后通过一种基于模态身份中心的身份对齐损失函数和一种模态对齐损失函数来消除两种模态的鸿沟。Wu 等人^[32]设计了一种目标感知的协调对齐范式，在对齐跨模态样本时允许根据被对齐的目标图像进行自适应注意力调整，从而自主挖掘局部细节。

以上有监督跨模态技术都取得了很好的效果，得益于人工标注数据，这些方法能够依据准确无误的跨模态配对标签进行模态对齐，但对标注数据的强依赖




图 1.5 跨模态行人重识别原理

导致这些有监督跨模态行人重识别方法在真实场景中作用有限。同时这些有监督跨模态行人重识别方法仅专注于图像层面的跨模态对齐，没有探索如何借助更具象的行人身份语义信息来辅助红外模态和可见光模态之间的对齐。

1.2.3 无监督行人重识别

无监督行人重识别算法解决的是一个更具有挑战性的问题，即在无标注数据场景如何利用海量原生图像数据设计合理的深度学习算法来完成行人重识别，这对于推动行人检索在现实场景落地和应用是具有重要意义的。无监督行人重识别研究方法主要可以分为无监督单模态和跨模态行人重识别，其中二者均存在模态内的噪声标签问题，而后者则还存在另一更困难的挑战，即白天可见光和夜间红外两种场景的跨模态匹配标签是未知的。

无监督单模态行人重识别研究方法中，DGM 动态图匹配方法^[33]将标签估计公式化为二分图匹配问题。全局相机网络约束^[34]被提出用于一致性匹配。Fan 等人^[35]提出了一种基于特征聚类 and 模型微调交替进行的无监督方法，这也是现在无监督单模态行人重识别的主流基线方法。Zeng 等人^[36]在分层聚类框架中利用样本之间的关系。Wu 等人^[37]将相机内挖掘和相机间关联应用于图关联学习框架。Yu 等人^[38]在参考特征集中挖掘有利于判别的软标签信息，并将软多标签学习思想运用于无监督行人重识别。另一方面，也有部分工作通过设计合理的对噪声鲁棒的损失函数^[39]或者样本加权方法^[40]来直接抑制标签噪声对网络训练的影响。Zou 等人^[41]使用不一致的类簇代理特征和多实例代理特征来维护一个

类簇,构建了基于类簇的对比损失来减少类内差异,同时通过在多实例代理中进行全局难负样本挖掘构建实例对比损失,以此降低类间相似性。Chen 等人^[42]提出了一种基于特征记忆存储模块 (Memory Bank) 的非参数方式,旨在从实例样本的自对比学习以及概率蒸馏两个维度,全面而高效地利用所有聚类与非聚类实例的自监督信号。

尽管以上的无监督单模态方法已经取得了不错的效果,但这些方法都采用了无优先级的样本学习顺序,这显然忽视了模型对于不同噪声程度的样本标签的不同容忍度,从而导致模型可能在训练早期就由于记忆效应而学习到了噪声标签的错误模式,影响了行人重识别的检索性能。此外以上方法采用的噪声标签建模方法往往比较单一^[43-45],而单一识别方法很有可能会疏漏部分噪声标签。

无监督跨模态行人重识别研究是近两年被关注的一个新兴研究课题。相比于有监督跨模态和无监督单模态行人重识别研究,无监督跨模态行人重识别研究更具挑战性。因为在这一研究课题中,可见光和红外模态的行人图像数据不仅分别无法提供行人标签,而且要求模态间的配对标签也是不可知的,现有的方法一般致力于解决跨模态配对标签问题,往往基于两图像模态的特征相似度来挖掘可靠的跨模态匹配对^[46-48]。Liang 等人^[46]提出了 H2H 算法,是第一个研究无监督跨模态行人重识别的工作,该研究中尝试使用两阶段学习框架,即聚类获得伪标签和跨模态实例选择两阶段。Yang 等人^[47]提出了 ADCA 方法,将研究重心放在了如何挖掘可靠的跨模态样本对中,通过相似度度量的方法挖掘潜在的跨模态样本对,并基于挖掘的两种模态间的身份匹配关系,引入双路的跨模态对比学习来帮助模型学到模态无关信息。Wu 等人^[48]提出了一种渐进式的二分图匹配方法 PGM,来逐步建立红外类簇和可见光类簇之间的跨模态联系,并基于这种跨模态配对关系进行跨模态表征学习。Wang 等人^[49]提出了名为 OTLA 的方法,将可见光红外类簇的配对问题建模成最优化传输问题,从而将可见光样本标签分配给红外样本。

尽管以上的无监督跨模态行人重识别方法从挖掘跨模态匹配对的角度出发提供了很好的研究视角,但都是基于图像特征相似度进行离线挖掘的,这两个主要缺陷:一方面网络输出的图像特征质量已经受到了噪声标签的影响,因此辨别性差,同时可见光图像和红外图像间存在天然差异,以上两个因素导致仅依赖于图像特征相似度可能无法挖掘到足够置信的匹配对。另一方面,当前方法均忽略了如何利用行人的语义来辅助红外可见光模态的对齐,具体来说相同身份的不同模态行人尽管图像外观差异大但其文本语义应该是一致的,如何获取这种文本语义并基于文本语义在特征空间来增强可见光和红外图像的跨模态交互,在当前的无监督跨模态行人重识别方法中均未得到有效探索。

1.3 本文研究内容

虽然上述无监督行人重识别方法已经取得了良好的效果,但这些研究方案仍然存在不足。一方面,当前无监督单模态行人重识别方法对于如何更全面地建模样本伪标签的不确定性,以及如何基于标签的不确定性来合理分配样本的训练优先级,没有深入探索。另一方面,当前无监督跨模态行人重识别方法都只是在图像特征层面来建立跨模态配对关系和进行跨模态表征学习的,不但忽视了噪声标签对图像特征辨别性的影响,也忽视了如何借助行人身份的语义差异与共性来缩小两种图像模态间的鸿沟。针对以上问题,本文分别提出了一种基于双重不确定性引导的课程学习的无监督单模态行人重识别方法和一种基于视觉语言模型知识蒸馏的无监督跨模态行人重识别。本文的主要研究内容如下:

1.3.1 基于双重不确定性引导课程学习的无监督单模态行人重识别

目前大多数无监督单模态行人重识别方法一般采用先聚类获得行人伪标签再利用伪标签监督神经网络训练的策略,一方面这些方法往往采取无优先级的训练方法,忽略了网络对不同程度伪标签噪声的容错能力,而导致神经网络可能在训练前期就由于记忆效应而过拟合在噪声标签的错误模式上。另一方面,尽管部分方法通过损失函数大小、标签时空一致性等手段来识别噪声标签,然而这些建模方式往往比较单一因此很容易疏漏不同特点的噪声标签。此外,大多数无监督单模态行人重识别方法在训练阶段仅关注行人的全局特征而忽视了局部细节差异,这使得模型的辨别能力受限,进一步地也不利于产生更有判别性的特征并基于此来获取更高质量的聚类伪标签。

本文提出一个新颖的基于双重不确定性引导的课程学习方法,利用类簇内样本间的特征亲和力度来估计样本标签的可靠度,然后让模型遵循课程学习范式的训练顺序先学习标签可靠度最高的行人样本再逐渐学习标签可靠度低的样本,使得模型在课程学习前期专注于可靠标签的学习而不易受到噪声标签错误模式的影响,在课程学习中后期可靠度低的样本通过重新聚类也将获得质量更高的伪标签,从而在训练的不同阶段均能充分抑制噪声标签对模型性能的损害。此外,本文提出了基于教师-学生模型的预测一致性和基于蒙特卡洛 Dropout 的模型自聚合概率熵两种方法来全面地建模样本标签的不确定性,并转化为样本权重来减少高不确定性样本对损失函数的贡献,这保证了模型能够充分抑制不同程度噪声标签而选择性地从行人样本中学习置信的知识。同时,本文从兼顾行人的全局特征和局部细节出发,设计了一种局部细粒度语义感知的全局特征改善方法,将局部语义从通道维度和空间维度通过注意力机制来改善行人全局特征表示向量,以提高模型对不同行人局部细节差异的关注能力。

1.3.2 基于视觉语言模型知识蒸馏的无监督跨模态行人重识别

目前无监督跨模态行人重识别方法一般先在可见光和红外两种模态数据上分别聚类而产生独立伪标签集合, 由于行人身份标签集合不共享无法建立跨模态联系, 因此现有方法一般直接基于两种模态图像特征之间相似度构造匹配对来进行跨模态表征学习。然而噪声标签对模型特征辨别性的影响以及可见光-红外图像天然的差异, 导致这种仅靠图像相似度来挖掘匹配对的方式可能不够置信。此外当前方法不论是匹配对挖掘还是模型训练, 均忽视了不同行人身份的语义差别和相同行人身份的语义共性, 更具体而言目前没有方法探索如何利用行人的文本语义来辅助红外和可见光模态的对齐。

本文研究发现, 将行人图像和指令输入到多模态大模型 (Language Large Model, LLM) 其输出的行人文本描述包含十分重要的语义信息, 具体来说尽管同一个行人的红外模态和可见光模态数据在图像层面相似度小, 但对应的两种文本描述具有高度的语义一致性, 而不同行人的文本表述具有截然不同的语义。这一观察表明行人的文本语义包含模态无关的判别性线索。

为了能让上述文本语义用于缓解红外-可见光图像之间的跨模态匹配噪声以及辅助两模态之间的特征对齐, 本文首先基于多模态大模型来生成可见光图像和红外图像对应的文本描述数据, 然后引入图文预训练模型 CLIP (Contrastive Language Image Pretraining) 并在收集的图文对数据集上进行基于特征蒸馏方法的微调, 使其适配到行人重识别这种细粒度检索任务。一方面, 为了在跨模态匹配时缓解仅依赖于红外和可见光图像特征相似度产生的匹配噪声问题, 我们将 CLIP 模型输出的语义信息更丰富的文本特征和辨别能力更强的视觉特征作为外部知识, 与原始的 ReID 模型的视觉特征一起经过处理得到混合原型分类器, 完成更准确的红外可见光跨模态匹配。另一方面, 为了在模型训练时利用文本语义信息辅助红外-可见光模态的相互对齐, 我们利用 CLIP 中的图文对齐知识, 在无监督跨模态 ReID 模型训练的第一阶段进行文本语义增强的模态内表征学习, 在第二阶段进行基于关系蒸馏的跨模态表征学习, 这两阶段保证红外和可见光图像都能够与语义一致的文本特征对齐, 从而间接促进两模态图像的相互对齐。

1.4 论文组织结构

本文的整体结构共分为五个章节, 具体内容安排如下:

第1章, 绪论, 本章节主要介绍行人重识别的研究背景与意义, 以及行人重识别子方向的国内外研究现状, 并在最后列出了本论文的组织结构。

第2章, 无监督行人重识别理论基础与知识, 本章节首先介绍了卷积神经网络的基础理论, 行人重识别任务概述, 然后重点阐述了无监督单模态和跨模态行

人重识别两个任务的主流方法理论和优缺点。最后,本章节还详细介绍了无监督单模态和跨模态行人重识别任务常用的数据集和评价指标。

第3章,基于双重不确定性引导课程学习的无监督单模态行人重识别,本章节首先分析现有基于聚类微调的无监督单模态行人重识别方法所存在的局限性,阐述了本文的改进方案和模块设计细节。最后介绍相关的实验结果和分析。

第4章,基于视觉语言模型知识蒸馏的无监督跨模态行人重识别,本章节首先分析现有基于特征相似度匹配的无监督跨模态行人重识别方法所存在的局限性,阐述了本文的改进方案和模块设计细节。最后介绍相关的实验结果和分析。

第5章,总结和展望,对本文在无监督单模态和跨模态行人重识别领域的研究内容和成果进行总结,并在此基础上对可改进的工作进行展望。

第2章 相关理论基础与知识

本章节将首先对神经网络的基础知识进行介绍,然后重点对对行人重识别任务进行梳理概述。为了更好地理解本文所提出的无监督行人重识别算法,本章节将详细介绍两类无监督场景下的主流行人重识别方法理论,包括基于聚类微调的无监督单模态行人重识别方法与基于特征相似度匹配的无监督跨模态行人重识别方法,并分别分析它们的基本构建思路。最后,本章节对于无监督的单模态和跨模态行人重识别任务中主流数据集和评价指标进行介绍,为后续章节的实验设计与分析提供了基础。

2.1 神经网络基础知识

近年来,以卷积神经网络(CNN)和循环神经网络(RNN)等结构为主要代表的人工智能技术飞速发展,推动了许多领域的变革,作为深度学习领域最具代表性的方法,已经落地并应用在诸多领域,深刻改变了我们的生活。其中RNN是一种适用于处理序列数据的神经网络模型,如文本、语音等。RNN的内部网络结构主要由循环神经元和遗忘门构成。循环神经元负责记忆序列中的先前信息,并将其应用于当前的处理。遗忘门则负责在每个时刻决定保留哪些信息,摒弃哪些信息。而CNN则是一种特别适合处理图像、视频等二维数据的神经网络模型,因此对于行人重识别这种主要以图像为数据载体的研究,CNN是一种十分适合用于提取行人特征的神经网络结构。1986年Hinton等人发明了BP误差反向传播算法,为后来神经网络的发展奠定了基础,1998年LeCun正式提出LeNet-5^[50],该网络采用了标准的卷积神经网络(CNN)结构,被视为现代深度卷积神经网络的起源。其采用了卷积和池化等模块,并选择双曲正切激活函数和极大似然估计损失函数,同时使用BP算法进行训练,该网络在手写数字识别上获得成功。2012年的ImageNet图像识别大赛中AlexNet^[51]取得了遥遥领先的成绩,其与之前网络相比参数规模变大有更深的结构,同时引入了全新的激活函数ReLU和dropout机制,再次掀起了深度学习浪潮的。来自牛津大学的团队采用小卷积堆叠的方式搭建了更深层的VGG网络^[52],感受野进一步减小,而网络则达到了19层,证明了更深的网络能够更好地提取特征。谷歌团队在2014年提出一种名为GoogleNet的深度神经网络^[53],网络中包含Inception机制同时最后的全连接层被平均池化层替代,对图像的多尺度处理机制进一步提升了模型优越的性能。2015年何恺明团队提出ResNet^[54]系列网络,深层网络难以训练的问题通过首次提出的残差结构来解决,网络层数达到了历史最高,在ILSVRC分类任

务比赛以 3.57% 的 Top-5 错误率赢得了桂冠。之后 DenseNet 网络^[55]的提出，特征复用的思想加快了网络中信息流的传递，进一步提高了性能。

2.1.1 卷积神经网络结构与性质

1. 结构

CNN 一般由卷积层、激活函数层、池化层以及批量归一化层等结构组成。下面对一些基本结构进行介绍。

(1) 卷积层 (Convolution Layer)

卷积层是卷积神经网络的最重要成分，产生了网络中的大部分计算量。卷积核起着滤波器的作用，同时这些滤波器能够通过自己的感受野计算前一层的图像或其他数据，通过不断学习来更新自身参数，而使卷积层不断学习更新参数的特征往往是某些类型的视觉特征，当卷积层看到这些特征输入就会如神经元细胞达到自身阈值被激活。卷积运算的目的是提取输入的不同特征。




图 2.1 卷积层运算原理

感受野指的是卷积核与输入数据连接的局部区域，感受野的大小实际就是卷积核的各维度大小。在宽高维度上，感受野是局部的，而在深度方向上，感受野的深度与输入数据深度必须相同。卷积核的权值共享机制能够有效的控制参数的数量，该机制是基于减少网络参数的目的：一个卷积核当它的感受野移动到不同的输入位置时，使用相同权值并不影响对输入特征的理解。因此在在一个卷积核中，每一个感受野采用的都是相同的权值。如图2.1显示的是一个 3x3 大小的卷积核对一张 5x5 大小的图像进行卷积运算的流程。

(2) 池化层 (Pooling Layer)

池化层通过保留主要的特征减少了参数数量，具体计算过程和卷积运算基本相同，都是通过以一定步长的滑窗处理每次落在窗口区域的数据。一般在接连若干卷积层之后设置少数池化层，起着数据压缩和特征图维度降维的作用，除此以外还能提高模型的泛化能力。如图2.2所示。




图 2.2 池化层原理

(3) 激活函数层 (Activation Layer)

一般在输入数据卷积运算后，激活函数进一步对特征张量进行处理，有助于神经网络获取输入数据的非线性特征。根据梯度下降的原理，激活函数要求能够可导，因为网络需要更新参数就需要不断通过求导来传递梯度值。常用的激活函数如表2.1所示。

表 2.1 几种常见激活函数

激活函数	表达式	性质	图像
Sigmoid	$f(x) = \frac{1}{1 + e^x}$	软饱和性	2.3 (a)
tanh	$f(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}}$	软饱和性	2.3 (b)
ReLU	$f(x) = \begin{cases} 0 & \text{if } x < 0, \\ x & \text{if } x \geq 0. \end{cases}$	硬饱和性	2.3 (c)
Leaky ReLU	$f(x) = \begin{cases} \alpha x + 1 & \text{if } x < 0, \\ x & \text{if } x \geq 0. \end{cases}$	中等饱和性	2.3 (d)

Sigmoid 和 tanh 具有软饱和性，即 $\lim_{x \rightarrow +\infty} f(x) = 0$ ，在梯度反向传播参数更新的过程中，一旦更新到某层参数该层的输入特征值落在导数值趋近于 0 的区间，由梯度求导的链式法则，当梯度继续会向底层传递时梯度值会出现累乘效应，引发梯度衰减甚至消失现象。ReLU 具有硬饱和性，观察其函数曲线可以推导，当特征值落在负值区域，导数值为 0，所以仅仅减少了特征值大于 0 时的梯度衰减消失现象，随着网络继续学习参数，一旦输入特征落在小于 0 区域，影响网络的收敛性，这就是硬饱和性。常用的四种激活函数如图2.3所示。

(4) 全连接层 (Fully Connected Layer)

经过多个卷积或池化层，接近网络最深层时会设置全连接层，作为 CNN 的特征“提纯器”，它能够接收经过卷积层和池化层计算后的特征，并计算得到特




图 2.3 常见激活函数

征在 N 个类别上的得分值，并把此作为判断类别归属的重要依据，简言之就是把学习到的特征映射到标签空间。在实际计算时，我们常常可以把 FC 层当作多个 1×1 的卷积核来方便运算。

(5) 归一化层 (Batch Normalization)

归一化层 (BN 层) 的作用是批量数据标准化，一般位置是在激励函数层之前。具体实现方法是对即将进入激活层函数的数据求取数据均值和方差，之后对数据进行标准化。卷积神经网络通常利用 BN 层解决梯度消失和梯度爆炸的现象。

2. 性质

参数共享：参数共享是指当输入图像进入 CNN 时，在滑动窗口操作过程中同一个卷积核的感受野处理图像不同区域时会使用完全相同的权重参数，这种高效简洁的计算大大减少了网络中参数个数以及训练时对存储空间的要求。

平移不变特性：平移不变特性是指输入不管如何平移，卷积神经网络产生相同的输出。由于卷积神经网络的参数共享机制使得目标出现在图像的任意位置，都能被网络检测到并输出同样的响应；而池化函数同样对特征位置不敏感，当输入做出适当平移，输出并不会发生变化。卷积和池化处理使得神经网络具备了这一优良性质。

2.1.2 常见深度神经网络模型

1. 深度残差网络

深度残差神经网络 (Residual Network, ResNet) 于 2015 年被首次提出^[54], ResNet 相比于以往的网络最大的突破在于首次提出了跨层连接的残差结构, 有效地缓解了网络层数加深时的模型退化现象。ResNet 系列网络如图2.4所示。

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2.x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3.x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4.x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5.x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

图 2.4 常用 ResNet 网络结构

ResNet 网络模型由两种主要的残差映射模块: 投影映射模块和恒等映射模块 (Identity Mapping) 组成, 其中投影映射是在恒等映射模块基础上改进, 是为了解决残差结构中输入和经过网络的输出相加时尺寸不匹配问题而产生的。事实表明, 越深的网络模型能够带来更好的分类效果, 但是单纯通过增加网络深度来获得的模型收益也随之而来暴露出梯度爆炸或消失的负面作用, 这一问题在 ResNet 中通过一个包含恒等映射的残差模块得以克服, ResNet 残差模块如图2.5所示:




图 2.5 ResNet 残差模块原理

我们通过求导梯度方法来分析一下 ResNet 奏效的原因。当需要对第 l 层卷

积层参数进行梯度更新时，我们需要做如下梯度求导工作：

$$\frac{\partial Loss}{\partial x_l} = \frac{\partial Loss}{\partial x_L} \cdot \frac{\partial x_L}{\partial x_l} = \frac{\partial}{\partial x_L} \cdot (1 + \prod_{i=l}^{L-1} F(x_i, W_i)), \quad (2.1)$$

公式2.1中，括号中的1指的是短路机制，梯度成分 $\frac{\partial Loss}{\partial x_L}$ 通过短路机制可以无损地传播，而另外一项梯度 $\prod_{i=l}^{L-1} F(x_i, W_i)$ 则是经过正常带有卷积层的梯度。当网络层数比较深时导致出现梯度衰减现象即 $\prod_{i=l}^{L-1} F(x_i, W_i) = 0$ ，有1的存在深层的梯度可以至少保证不会传递值为0的梯度到浅层，模型退化的问题被很好的解决，有利于稳定的训练，也扩展了训练更深层网络的可能性。也正是由于ResNet的上述优点，ResNet被主流的行人重识别方法广泛采用，在后续章节中我们也将基于ResNet骨干网络开展实验。

2. Transformer 模型

Transformer 模型^[56]是一种基于自注意力机制的深度学习模型，在自然语言处理(NLP)领域有着广泛的应用。该模型由编码器(Encoder)和解码器(Decoder)两大部分构成，旨在通过自注意力机制捕捉输入序列中不同位置间的相互关系，实现对序列数据的处理。具体来说，Transformer模型的每一层均包含两个核心子层：一是多头自注意力层(Multi-head Self-Attention Layer)，二是前馈神经网络层(Feed-Forward Neural Network Layer)。在自注意力层中，模型通过计算注意力权重，使得输入序列中的每个位置都能与其他位置进行交互，从而有效捕获序列中的关键上下文信息。这种注意力机制特别擅长处理长距离依赖性问题，能够显著提高模型的性能。




图 2.6 Vision Transformer 结构示意图^①

在编码器部分，输入序列会依次经过多个编码器层的处理。每个编码器层都会根据前一层的输出生成新的特征表示，逐步提炼和抽象输入序列的信息。而在

^①图源自 <https://arxiv.org/pdf/2010.11929>

解码器部分，除了自注意力层和前馈神经网络层外，还引入了一个编码器-解码器注意力层（Encoder-Decoder Attention Layer）。这一层允许解码器在生成输出序列时，能够关注到编码器的输出，从而实现对源序列和目标序列之间关系的建模。通过这种方式，Transformer 模型能够更有效地完成序列到序列的转换任务。在 NLP 任务中，Transformer 模型已经取得了显著的成果，成为了机器翻译、文本生成等众多任务的基准模型，其优势在于能够处理长距离依赖性、并行计算效率高以及模型性能优越，为自然语言处理领域的研究和应用提供了有力的支持。

在 2020 年 Google 团队首次将 Transformer 应用在计算机视觉领域，提出了 Vision Transformer (ViT) 模型^[57]，如图 2.6。Vision Transformer 模型在进行图像处理时，将图像切分成多个小块（patch），不同 patch 将经过线性层处理得到一组序列特征，作为 Vision Transformer 模型的输入。这些输入序列通过自注意力层，其中每个输入首先通过一个线性变换，然后被分割成三个子向量：查询（query）、键（key）和值（value）。这些子向量随后被用于计算不同输入之间的相似性，并通过一个归一化过程生成注意力权重。这些权重被用来加权输入的值向量，从而生成模型输出的新表示。ViT 模型简单且效果好，因此这一里程碑式著作也启发了后续大量的相关研究^[58-62]。

2.2 行人重识别任务概述

行人重识别任务 (Person re-identification, ReID) 的目的是根据一个待查询行人 (query) 从一个包含大量行人图像的候选集 (gallery) 找到与待查询行人相匹配的行人图像，这属于图像检索领域的子问题。如图 2.7 所示，一个完整的行人重识别任务包括视频数据收集、行人检测、数据标注、模型训练和行人检索五个环节，如图 2.7 所示。

视频数据收集：采集分布在不同场所与环境的监控摄像头所拍摄的视频，是获取原始数据的主要途径之一。一般要求监控摄像头的是非重叠分布的，保证拍摄视频中出现的行人背景光照等因素具备多样化特点。

行人检测：利用目标检测算法对原始视频数据进行处理获得行人检测框，并进行人工裁剪得到行人图像。

数据标注：基于处理后的行人图像，再逐张图像进行身份标注和相机标注。因此最终的行人图像数据集中任意身份的行人，往往存在多张出现在不同摄像头下的行人图像，与真实监控或刑侦场景中目标行人出现的场景变化剧烈这一特点相符合。

模型训练：模型训练的基本流程是以带身份标签的行人图像数据集作为输入训练数据，通过深度学习方法进行训练，得到一个辨别能力强的 ReID 模型。

如何利用深度学习方法训练一个辨别性能好的 ReID 模型也是当前行人重识别领域的主要研究内容。

行人检索：行人重识别任务的测试集包括行人查询集 (query set) 和行人候选集 (gallery set)，模型测试过程一般先将查询行人和候选集行人分别输入到 ReID 模型得到查询行人特征和候选集行人特征，通过计算查询行人和候选集行人特征之间的相似度并按照相似度高到低的顺序返回行人检索列表。衡量 ReID 模型检索性能好坏的一个直观方法，就是统计返回的行人检索列表中包含的与待查询行人相同身份的正确匹配行人比例。




图 2.7 行人重识别任务的五个环节

由以上五个环节的描述可以看出，数据标注环节是行人重识别任务中“劳动密集型”环节，需要投入巨大的人力和时间开销，而对于日益增长的智能安防需求，这显然是不够合理的。相比于投入昂贵的数据标注成本，海量无标注的监控视频数据更易获得，无需行人标签信息作为模型训练监督信号，研究人员可以将更多的时间投入到针对复杂开放环境的算法优化中，因此无监督行人重识别方法研究对于提高海量监控视频数据使用效率具有重要现实意义。除此以外，传统的行人重识别技术主要考虑白天这一单模态场景下行人图像的检索问题，重点研究如何提取具有判别力的鲁棒特征。然而随着应用需求和场景的不断扩大，单模态行人重识别技术已经不能满足该场景的需求，旨在研究白天行人图像和夜间红外行人图像相互搜索问题的跨模态行人重识别技术对于解决长时间跨度的行人追踪有十分重要的意义。

综合上述分析，结合实际场景的光照条件差异和数据标注瓶颈，更契合实际应用需求的无监督单模态和无监督跨模态行人重识别方法研究受到广泛关注。在接下来的两小节中，我们将针对目前学术界的无监督单模态和无监督跨模态行人重识别方法理论进行详细介绍。

2.3 基于聚类微调的无监督单模态行人重识别方法

无监督单模态行人重识别致力于在白天可见光单一模态利用无监督方法进行模型训练并应用到行人检索任务，其最大的特点是在模型训练阶段样本是无标签信息的，因此这一研究课题对于减少昂贵的人工标注成本以及利用海量监控视频中的无标签行人数据具有十分宝贵的现实研究价值。

无监督单模态行人重识别方法分为无监督领域自适应行人重识别方法和纯无监督行人重识别方法，这两种方法的异同点如表2.2中所示，二者的差别仅在于源域预训练模型的差异。值得注意的是，在无监督域自适应行人重识别的研究中，与深度学习其他领域的域自适应研究相比，一个显著的区别在于源域和目标域中行人身份的类别并不共享，即完全不相交，这使得传统的域自适应方法难以直接应用。因此不论是无监督域自适应还是纯无监督行人重识别，都主要采用本节即将详细阐述的基于聚类微调的主流无监督训练方法。本小节将介绍该方法的构建思路。

表 2.2 无监督单模态行人重识别的两个子方向

无监督单模态方法	主流方法	模态	源域		目标域	
			数据	标签	数据	标签
无监督领域自适应行人重识别	聚类 + 微调 交替进行	可见光	✓	✓	✓	✗
纯无监督行人重识别			✗	✗	✓	✗




图 2.8 无监督单模态行人重识别的主流训练方法

如图2.8所示，基于聚类微调的无监督单模态行人重识别方法一般包含如下两个步骤：(1) 利用公开预训练模型提取可见光模态下的无标注行人图像特征，然后基于特征向量先执行聚类算法得到伪标签；(2) 利用行人伪标签作为监督信息来训练行人重识别模型。其中聚类和微调这两步是交替进行多次直至模型收敛，这么做的好处是多次聚类可以及时移除错误标签，而随着训练进行伪标签质量也越来越高，有利于监督最新状态模型进行训练。由于聚类算法的不准确，获得的伪标签存在大量的错误即噪声标签问题（如图2.8右下角的“类簇分布”区域），

而噪声标签作为网络训练的监督信号将起着误导作用，直接损害行人重识别模型性能，因此当前的无监督单模态行人重识别方法主要研究如何减少噪声标签的负面影响。从抑制噪声标签这一角度出发，当前的许多研究方法从以上两个步骤切入尝试缓解噪声标签问题，即选择不同聚类算法和改进训练方法。

2.3.1 聚类算法

聚类算法的好坏决定了生成的图像伪标签质量高低，而伪标签作为模型训练的监督信息，直接决定了模型是否能学习到具有良好判别性的行人特征表示。在无监督单模态 ReID 的相关工作中，具有代表性的聚类方法主要有自底向上的聚类算法 (BUC)^[63]，基于 K 均值的聚类算法 (Kmeans)^[64] 以及基于密度的聚类算法 (DBSCAN)^[65]。

自底向上聚类方法：自底向上聚类方法 (bottom-up clustering, BUC) 充分考虑了 ReID 任务的两个核心要素：不同身份行人样本的多样性以及同一身份行人间的相似性。算法伊始，将每个行人视为独立的一类，旨在最大化各类别的多样性。随后，通过合并相似的类别，逐步提升各类的相似性。在聚类过程中，算法引入了一个多样性正则项，用以平衡各类簇的数据量，最终在多样性与相似性之间取得理想的平衡状态，如图2.9(a)所示。

基于 K 均值的聚类算法：Kmeans 是一种基于特征点间距离的聚类方法。其核心流程如下：首先，随机选取 K 个行人样本作为初始聚类中心。接着，将剩余样本分配给距离其最近的聚类中心所对应的类簇，形成 K 个临时类簇。随后，根据当前临时类簇重新计算每个新类簇的中心，并重复上述步骤直至类簇中心不再变化。Kmeans 算法简洁易行，但需预先设定类簇数量 K，这在处理未知身份类别数量的数据时显得不够灵活。此外，该算法对初始聚类中心的选择较为敏感，其原理如图2.9(b)所示。




图 2.9 无监督行人重识别三种常见的聚类方法

基于密度的聚类算法：DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 如今被主流的无监督行人重识别方法广泛采用，是一种基于

密度的聚类算法。DBSCAN 通过计算行人样本周围的密度，将数据集划分为多个类簇，确保每个类簇内部密度较高而类簇间密度较低。其基本思想为：对于每个样本，若其周围样本数量超过设定阈值，则将其视为核心点，并将周围样本归入同一类簇；若周围样本数量不足，则将其视为噪声点。随后，以核心点为中心，在一定半径内寻找并归入同类样本，重复此过程直至所有样本均被分配至类簇。DBSCAN 无需预设类簇数量，能自动识别噪声点，且对初始聚类中心不敏感，因此成为无监督行人重识别中的主流聚类算法，如图2.9(c)所示。

2.3.2 训练方法

无监督单模态 ReID 的基线方法如图2.8所示，基于聚类算法产生的伪标签作为网络的监督信息，而交叉熵损失函数和三元组损失函数被用于模型训练，分别表示成公式2.2和2.3。

$$L_{id} = -\frac{1}{B} \sum_{i=1}^B \log p(y_i | x_i), \quad (2.2)$$

$$L_{triplet} = -\frac{1}{B} \sum_{i=1}^B \max\{\|f(x_i) - f(x_i^{pos})\|^2 - \|f(x_i) - f(x_i^{neg})\|^2 + \alpha, 0\}, \quad (2.3)$$

其中公式2.2中 B 表示训练批量大小 batch size, y_i 表示聚类算法给样本 x_i 分配的伪标签, $p(y_i | x_i)$ 表示网络分类器将样本 x_i 的标签预测为 y_i 的概率。交叉熵损失函数的作用是将行人特征从向量空间映射到标签空间。公式2.3中 $f(x_i)$ 表示 x_i 的特征向量, $f(x_i^{pos})$ 和 $f(x_i^{neg})$ 分别表示在当前训练 batch 内与查询样本 x_i 的伪标签相同和不同的正样本和负样本特征, $\|\cdot\|^2$ 表示欧氏距离的平方。 α 是距离阈值, 当负样本对的特征距离 $\|f(x_i) - f(x_i^{neg})\|^2$ 比正样本对的特征距离 $\|f(x_i) - f(x_i^{pos})\|^2$ 小于阈值 α , $L_{triplet}$ 将持续优化网络直至二者之差超出阈值 α (此时 $L_{triplet} = 0$)。因此训练时通过优化三元组损失函数 $L_{triplet}$, 可以迫使特征空间中伪标签相同的行人特征之间距离足够近, 而伪标签不同的行人特征之间距离足够远, 以保证模型学习到具有足够辨别能力的特征。

然而上述损失函数通常会放大伪标签的负面影响, 导致模型性能受到受损。我们将现有研究工作对训练方法的改进归纳为训练策略, 网络结构和样本置信度估计三种。

SPCL^[66]提出了一种自步的对比学习训练策略 (Self-paced Contrastive Learning), 提出了根据类簇的类内紧密性和类间独立性来估计每个类簇的可靠度, 每次模型只专注训练可靠类簇而放弃不可靠类簇用于对比学习, 通过这种模型自行辨认可靠类簇的自我调节方式来减少噪声标签影响从而提高表征学习的质量, 如图2.10所示。尽管 SPCL 较早意识到合适的学习策略对带噪声的表征学习具有积极作用, 但每次训练时只保留可靠类簇的做法忽视了不可靠类簇中仍然包含

假负样本的问题，此外这种衡量类簇伪标签可靠性方法有着“一刀切”的弊端，即被纳入为可靠类簇的所有样本在训练优先级上是完全相同的，忽视了样本个体的伪标签可靠度差异。后续章节中我们将针对上述的 SPCL 存在的问题提出我们的解决方案。




图 2.10 SPCL: 基于类簇可靠度的自步学习策略

前面提到基线方法将聚类伪标签当作网络训练的监督信息，本质上是把伪标签通过常规 one-hot 编码成一种硬标签，这种含噪声的监督很容易误导模型训练过程。因此基于聚类微调的无监督单模态 ReID 领域近年来也有引入软标签来缓解噪声标签的工作，比较有代表性的是教师-学生网络模型^[44,67-68]。教师-学生网络模型的具体做法是：教师模型是基于学生模型历史权重的滑动平均操作获得的，因此具备更可靠的预测能力，将教师模型的输出预测向量当作是学生模型训练的软标签，从而缓解硬标签的噪声影响。




图 2.11 MMT: 基于教师-学生思想的模型结构

基于样本伪标签置信度估计来重新安排样本权重也是一种缓解噪声标签的改良版训练方法。现有相关工作主要采用损失函数大小^[43]、不同时刻的聚类一致性^[45]以及不同增强图像的聚类一致性^[40]来估计样本伪标签的置信程度,并给样本加权。尽管上述工作对于抑制噪声标签提供了合理的方法论,但由于往往采用单一的置信度衡量手段因此容易遗漏噪声标签,后续章节中我们将分析这些方法所存在的问题,并提出我们的解决方案。

2.4 基于特征相似度匹配的无监督跨模态行人重识别方法

无监督跨模态行人重识别方法旨在白天可见光场景和夜间红外场景完成行人相互搜索任务,需要在不提供可见光模态和红外模态的行人身份标签信息条件下完成模型训练。无监督跨模态行人重识别相比于无监督单模态行人重识别是一个挑战性更大的行人检索任务,主要存在以下两个制约因素:

缺失行人身份标签的模态数量更多:无监督单模态仅需要研究白天可见光这一单模态场景的无监督方法,而无监督跨模态则关注在白天可见光和夜间红外两种模态场景同时不提供行人身份标签的条件下提取具有辨别力的行人特征。

模态间的行人匹配标签无从获取:在有监督跨模态场景,得益于同一身份行人已知的可见光模态和红外模态的配对标签信息,通过模态无关的度量学习方法可以直接促进同一身份行人在不同模态的特征表达趋于一致。然而在无监督模态场景,这种模态间配对信息不可知,限制了模型直接基于精准匹配关系的多模态表征学习。

因此,无监督跨模态行人重识别方法需要同时克服两种模态场景下模态内样本标签和模态间配对标签不可知的难题。针对第一个问题,现有的研究工作往往采取分别在可见光模态内和红外模态内进行独立的无监督单模态表征学习的方法,通过训练模型分别在两个模态内学习到较好的行人辨别能力从而为下一步模态匹配打好基础。针对第二个问题,现有方法往往将模态间配对问题建模成二分图匹配问题,将跨模态图像间的特征不相似度转化为节点间匹配的代价,利用此代价矩阵来求解跨模态二分图匹配问题,然后基于计算得到的分属两个模态的样本配对关系进行跨模态特征对齐。解决以上两个子问题的方法也被归纳为无监督跨模态行人重识别方法的**两阶段训练框架**,如图2.12所示。

如图2.12所示,红色虚线表示聚类算法运行的数据流,黑色实线表示输入图像在网络中前向传播被处理成特征的数据流。双箭头线表示根据特征匹配算法计算的跨模态匹配伪标签,其中绿色和红色双箭头线分别表示正确和错误的匹配关系,红色实线表示基于这种伪匹配标签的跨模态对比学习。接下来我们将重点介绍无监督跨模态的两阶段训练方法:




图 2.12 无监督跨模态行人重识别主流的两阶段训练方法

2.4.1 第一阶段：模态内表征学习

在这一阶段，可见光模态和红外模态的行人图像都没有身份标签，若同时进行两种模态的无监督学习可能会加大噪声标签的错误累积效应，因此一般采用“分而治之”的策略，即基于两种模态数据分别进行独立的模态内表征学习，目的是保证 ReID 模型在单一模态内能够达到较理想的行人辨别能力，从而为模型后续的跨模态行人相互检索能力打下基础。如图 2.12 (a) 显示的是第一阶段的模态内表征学习过程。

对于骨干网络，一般采用基于 ResNet50 的 AGW 网络^[1]，该网络由双路模态独立的特征提取模块和一路模态共享的特征提取模块组成。其中模态独立的特征提取模块主要目的是分别为可见光模态和红外模态分别提取具有独立模态特性的特征，减少模态信息损失。而模态共享的特征提取模块目的是为了通过将两种模态特征映射到同一个特征子空间，从而一定程度上消除不同模态特征的风格差异，这种结构有利于强化模型的跨模态特征对齐能力。

对于损失函数，一般采用基于特征记忆存储模块的对比学习损失函数。由于 ReID 模型旨在为不同身份行人学习到具有辨别力的特征表示，这意味着每个身份下的行人特征在特征子空间应该彼此紧凑，与其他不同身份行人特征在特征空间是分散的，而促成这种与行人身份紧密相关的特征表示学习的首要前提是准确的行人身份标签。在无监督行人重识别任务中，两种模态均存在的噪声标签会导致使用身份伪标签计算交叉熵损失函数会放大噪声的负面影响，因此模态内的表征学习一般采用基于特征向量的对比学习损失函数来减少模型对噪声标签的敏感性以及提高特征向量的辨别性。受启发于 MoCo^[69]、SimCLR^[70]和 BYOL^[71]等视觉无监督预训练工作，在无标签或标签不可靠的情况下，实现更大的训练批量 batch 来进行查询样本特征 (query feature) 与正负样本特征 (positive/negative feature) 间的对比学习是有助于模型学习到更好的特征表示的。因此我们采用一个特征记忆存储模块 (feature memory bank) 结构用于存储当前时刻以前的所有样

本特征，通过使当前训练批量 batch 内的样本与特征记忆存储模块中的正负样本特征进行对比学习，达到优化模型表征学习的目标。特征记忆存储模块的特征更新公式2.4和基于记忆存储模块的对比学习公式3.6如下：

$$M[i] = \alpha M[i] + (1 - \alpha)f(x_i), \quad (2.4)$$

$$L_{contrast} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(M[pos]^T \cdot f(x_i))}{\sum_{k=1}^{|M|} \exp(M[k]^T \cdot f(x_i))}, \quad (2.5)$$

其中 $f(x_i)$ 表示当前训练批量 batch 内的行人样本 x_i 的特征， $M[i]$ 表示 x_i 存储在记忆存储模块 (Feature Memory Bank) 中的历史特征，更新时基于滑动平均的思想利用 α 来控制更新速率的快慢。 $M[pos]$ 表示以 batch 内样本 x_i 作为查询样本 (query)，在特征记忆存储模块中找到的与 query 伪标签相同的正样本特征，通过约束公式3.6可以促进分子项即查询特征与正样本特征相似度 $M[pos]^T \cdot f(x_i)$ 尽可能大，而使分母项即查询特征与负样本特征相似度 $M[k]^T \cdot f(x_i)$ 尽可能小，从而促使正负样本行人的特征向量在空间具有区分性。通过分别在可见光模态和红外模态内执行独立的聚类算法以及对比学习两个步骤，就可以获得一个在两种光照场景分别具有良好模态内辨别能力的行人重识别模型。

2.4.2 第二阶段：跨模态表征学习

基于第一阶段已经具备模态内识别能力的 ReID 模型，第二阶段目的是在此基础上专注跨模态识别能力的提升。现有方法往往通过样本特征之间的相似度来建立跨模态的匹配关系，如图2.12 (b) 所示，代表性的匹配算法有阈值法^[47]和二分图法^[48,72]等。

阈值法背后的思想是：任意可见光样本 x_m 和红外样本 x_n 之间特征相似度大于一定阈值 δ 时，可以认为这是一对潜在的跨模态匹配对，即二者是属于同一身份行人的不同模态图像，而当它们所在的可见光类簇 C_m 和红外类簇 C_n 间包含的这种潜在跨模态匹配对数量越多时，则代表这两个不同模态类簇很有可能是同一身份行人的图像集合。具体实现方式如2.6：

$$R = \{(y_m^v, y_n^i) | \text{sim}(x_m^v, x_n^i) \geq \delta, x_m^v \in C_m^v, x_n^i \in C_n^i\}, \quad (2.6)$$

其中 $\text{sim}(\cdot, \cdot)$ 表示特征相似度函数， R 统计的是两个跨模态类簇间的所有潜在匹配对。通过找到潜在匹配对数量 $|R|$ 最大的两个跨模态类簇，即可近似认为二者是配对的。

此外，二分图法将任意两个跨模态类簇间的匹配代价转换为类簇特征的不

相似度, 通过求解使得匹配代价最小, 从而找到最优的跨模态匹配方案:

$$\min_{Q^r} \langle Q^r, -\log(P^r) \rangle + \frac{1}{\lambda} KL(Q^r || \alpha \beta^T),$$

$$s.t. \begin{cases} Q^r \mathbf{1} = \alpha, \alpha = \mathbf{1} \cdot \frac{1}{N_r}, \\ (Q^r)^T \mathbf{1} = \beta, \beta = \mathbf{1} \cdot \frac{1}{N_p^v}, \end{cases} \quad (2.7)$$

其中 N_p^v 表示聚类后可见光图像的伪标签数量 (即类簇数量), $Q^r \in \mathbb{R}^{N_r \times N_p^v}$ 表示从可见光伪标签空间到红外伪标签空间的最优传输方案, $P^r \in \mathbb{R}^{N_r \times N_p^v}$ 表示的是红外模态特征输入到可见光模态分类器时的输出预测概率分布, $\langle \cdot, \cdot \rangle$ 表示两个向量的 Frobenius 点积, $KL(\cdot || \cdot)$ 表示 KL 散度函数, $\mathbf{1}$ 表示全 1 向量。 $\alpha \in \mathbb{R}^{N_r \times 1}$ 和 $\beta \in \mathbb{R}^{N_p^v \times 1}$ 表示一张行人红外图像被分配给可见光标签且 $N_r \times 1$ 张红外图像应该被均匀分成 N_p^v 个类别。因此我们可以清楚看到这里的伪标签传输问题也是预测概率分布和平滑标签分布的权衡。

如图2.12 (b) 所示, 在执行跨模态匹配算法后我们获得了跨模态的身份匹配伪标签, 由于这种匹配伪标签同样是包含噪声的, 因此基于这种跨模态匹配关系进行跨模态表征学习时我们需要考虑缓解不准确的噪声匹配标签的影响。具体来说, 同一个类簇下的所有样本特征的中心特征可以理解成是一个类簇的鲁棒特征表示, 相较于单一样本特征作为特征对齐的目标会有效减少模型对匹配伪标签噪声的敏感性, 训练过程中如果将当前训练批次 batch 内的特征与记忆存储模块中的跨模态匹配类簇中心特征在特征空间进行拉近, 就可以促进更可靠的跨模态对比学习。

$$C_k^v = \frac{1}{|S_k^v|} \sum_{f(x_m^v) \in S_k^v} f(x_m^v), \quad (2.8)$$

$$C_k^i = \frac{1}{|S_k^i|} \sum_{f(x_n^i) \in S_k^i} f(x_n^i), \quad (2.9)$$

其中 v 和 i 分别表示可见光模态 (visible) 和红外模态 (infrared), $f(x_m^v)$ 和 $f(x_n^i)$ 分别表示第 m 张可见光模态的行人图像特征和第 n 张红外模态的行人图像特征, S_k^v 表示可见光模态聚类后的第 k 个伪标签类簇下的样本集合。因此经过公式4.7和4.8我们便能分别为可见光模态和红外模态构建中心特征的记忆存储模块 (Center Feature Memory Bank)。接下来我们将介绍基于两种模态中心特征记忆存储模块的跨模态对比学习:

$$L_{contrast}^{v \rightarrow i} = -\frac{1}{B} \sum_{m=1}^B \log \frac{\exp((C_{pos}^i)^T \cdot f(x_m^v))}{\sum_{k=1}^{|C^i|} \exp((C^i)^T \cdot f(x_m^v))}, \quad (2.10)$$

$$L_{contrast}^{i \rightarrow v} = -\frac{1}{B} \sum_{n=1}^B \log \frac{\exp((C_{pos}^v)^T \cdot f(x_n^i))}{\sum_{k=1}^{|C^v|} \exp((C^v)^T \cdot f(x_n^i))}, \quad (2.11)$$

其中 B 表示训练批次大小 batch, $f(x_m^v)$ 和 $f(x_n^i)$ 分别表示 batch 内第 m 张可见光模态的行人图像特征和第 n 张红外模态的行人图像特征。 C^i 表示红外模态的中心特征记忆存储模块, 则 C_{pos}^i 表示以 $f(x_m^v)$ 作为查询样本 (query) 时在 C^i 中找到的与查询样本属于跨模态匹配对关系的“同类”中心特征, 因此公式2.10表示: 以可见光模态样本特征作为查询 (query), 以红外模态类簇中心特征作为候选集 (gallery), 进行跨模态表征学习时的损失函数。

以上基于特征相似度匹配的无监督跨模态行人重识别两阶段方法已经被广泛采用为该领域的基线方法, 然而这种方法不论是跨模态匹配还是一阶段和二阶段的训练其背后思想都是基于图像特征的相似度: 匹配时依赖两种模态图像特征相似度来建立匹配关系, 训练时致力于使匹配的跨模态图像特征尽可能相似。这种仅专注于图像的机制使得匹配时的配对噪声会持续影响到训练时的跨模态表征学习, 在没有外部知识的注入时模型陷入了“基于输出的图像特征产生伪标签, 然后基于伪标签来学习更好的图像特征”这种噪声标签导致的恶性循环中, 即模型无法跳出自身的认知偏差 (confirmation bias)。此外基线方法忽略了行人图像的语义共性和差异, 具体来说相同身份的不同模态行人尽管图像外观差异大但其文本语义应该是一致的, 然而关于如何获取行人语义以及如何使用行人语义来增强可见光-红外图像的联系, 均未得到当前主流方法的有效探索。后续章节我们将进一步分析当前基线方法的不足并提出我们的解决方案。

2.5 行人重识别数据集和评价指标

2.5.1 数据集

本小节将主要介绍实验中使用的公开数据集。在本文无监督单模态行人重识别实验中, 共采用了3个公开的行人重识别数据集进行测评, 在本文无监督跨模态行人重识别实验中, 共采用了2个公开的行人重识别数据集进行测评, 且均选用了学术界公认的评价指标测评本文所提无监督行人重识别算法。

1. 单模态行人重识别数据集

Market1501: Market1501 数据集^[73]采集于清华大学校园内的一个校园超市前并利用 DPM 检测器来获得行人边界框。该数据集的训练集和测试集分别包含 751 个和 750 个行人身份, 总计 32668 张行人图像。如图2.13显示了 Market1501 数据集中 4 个不同身份的行人图像。

DukeMTMC-ReID: DukeMTMC-ReID 数据集^[17]的行人图像是从杜克大学校园内的 8 个具有非重叠视角的摄像机拍摄的 DukeMTMC 视频数据集中裁剪获得, 并参考了 Market1501 数据集的标注形式。如图2.14显示的是该数据集中 4 个不同身份的行人图像。



图 2.13 Market1501 可见光单模态数据集



图 2.14 DukeMTMC 可见光单模态数据集

MSMT17: MSMT17 数据集^[74]由 15 个具有非重叠视角的摄像机在不同时刻捕获到的 4101 个行人身份图像组成，总共包括 126441 张图像，Faster R-CNN 检测器被用于从视频帧中检测提取得到这些行人图像。如图2.15展示了随机抽取的 4 个身份行人图像。

2. 跨模态行人重识别数据集

SYSU-MM01: SYSU-MM01 数据集^[75]由中山大学团队提出，训练集包含 296 个身份的 22,258 张 RGB 图像和 11,909 张 IR 图像，分别由 4 个 RGB 相机和 2 个红外相机拍摄得到，测试集包括 96 个行人身份。如图2.16显示的是该数据集中 4 个不同身份的行人图像，其中包含可见光和红外两种模态图像。

RegDB: RegDB 数据集^[76]中的每个行人均有 10 张红外图像和 10 张 RGB 图像。在 412 个行人身份中有 156 个行人是从正面拍摄，剩下 256 个人从背面拍摄。



图 2.15 MSMT17 可见光单模态数据集



图 2.16 SYSU-MM01 可见光-红外跨模态数据集

2.5.2 评价指标

1. CMC 曲线

CMC 曲线表示返回检索结果的的前 k 张图中包含至少一张检索目标图像的概率。如果候选库中有 n_q 个检索目标, n_{r1} 表示检索结果排在第一位的目标个数。则 CMC-Rank1 的值为:

$$\text{CMC-Rank1} = \frac{n_q}{n_{r1}} \tag{2.12}$$

2. 精确度 (Precision) 和召回率 (Recall)

精确度表示检索的精度, 召回率表示查找的全面性。精确度又称为查准率, 即正确检索的概率。记检索时被预测为正样本的总量为 SUM, 正确检索的正样

本数量为 ACC，则检索的精确度为：

$$\text{Precision} = \frac{\text{ACC}}{\text{SUM}} \quad (2.13)$$

召回率又称为查全率，表示的是全部正确的结果中有多少被检索出来。假设正样本的总数目为 S，正确检索的正样本数量为 ACC，则召回率是：

$$\text{Recall} = \frac{\text{ACC}}{S} \quad (2.14)$$

事实上二者常常矛盾，因此常常绘制 Precision-Recall 曲线分析。

3. mAP(Mean Average Precision, 平均准确率)

mAP 是一种可以用于弥补精确度和召回率，能够客观衡量算法整体性能的指标。一般我们希望召回率和精确度都高，也就是 Precision-Recall 曲线和坐标轴围成的面积越大越好，这一面积值则是 mAP 的值：

$$\text{mAP} = \frac{1}{n_q} \sum_{j=1} n_q \frac{1}{m_j} \sum_{k=1}^{m_j} \text{precision}(R_{jk}), \quad (2.15)$$

其中 m_j 表示的是检索目标 q 对应的匹配目标的数目， $\text{precision}(R_{jk})$ 表示匹配出的目标 k 在正确匹配的所有目标中的位置与其所在的所有匹配结果中的位置之比。当候选集中存在多个目标时，采用 mAP 衡量算法性能更符合实际应用的需求，因此 mAP 也是行人重识别任务的常用评价指标。




图 2.17 Rank-k、召回率和 mAP 的计算演示

图2.17列举了两个检索目标行人时 Rank-k、召回率和 mAP 性能指标的具体计算流程。

2.6 本章小结

本章节主要介绍了相关理论基础与知识，首先介绍了卷积神经网络的基础知识，然后重点介绍了行人重识别任务的定义，并详细阐述了基于聚类微调的无监督单模态行人重识别方法和基于特征相似度匹配的无监督跨模态行人重识别方法这两种主流方法的的基本原理与步骤，以及它们存在的不足。接着，介绍了无监督单模态和跨模态行人重识别任务中需要使用到的主流数据集以及性能指标。在接下来的章节中，本文将分别针对当前基于聚类微调与基于特征相似度匹配的方法的局限性，介绍所提出的一种双重不确定性引导课程学习的无监督单模态行人重识别算法与一种基于视觉语言模型知识蒸馏的无监督跨行人重识别算法，并进行一系列实验来验证有效性。

第3章 基于双重不确定性引导的课程学习的无监督单模态行人重识别

本章将介绍提出的基于双重不确定性引导的课程学习的无监督单模态行人重识别方法。首先，在引言部分介绍当前方法的不足和我们所提方法的出发点。然后我们从课程学习训练策略、双重不确定性建模方法以及局部语义感知的全局特征改善模块三个方面来详细介绍我们的算法整体框架和模块设计细节。最后我们通过大量实验来验证所提方法的有效性。

3.1 引言

目前学术界大多数无监督单模态行人重识别研究一般采用2.3中所述的基于聚类微调的方法，这类方法的优势在于能够为无标注数据快速获取伪标签以完成行人重识别模型的训练，但也存在不容忽视的噪声标签问题，这将误导行人重识别模型从图像数据中学习错误的模式，进而导致次优的判别性能。一方面，当前流行的无监督单模态行人重识别方法往往采取无样本优先级的训练方法，这些方法通常没有关注行人图像样本的学习先后顺序，忽略了神经网络对不同程度伪标签噪声的容错能力，导致行人重识别模型可能在训练前期就由于记忆效应而过拟合在噪声标签的错误模式上，造成模型训练后期性能提升受到阻碍。另一方面，尽管部分方法从损失函数大小，标签时空一致性等方面去识别噪声标签并抑制其影响，但这些方法往往采用单一的噪声标签建模方法，可能会疏漏不同特点的噪声标签。此外，当前大多数方法仅专注于行人的全局特征向量，这不但忽视了不同身份行人样本的局部差异，导致在聚类阶段产生了许多外观大体相似实则身份不同的噪声标签，而且也使模型在微调阶段无法学习到更细粒度的行人特征表示。

从抑制噪声伪标签对模型训练的负面效应这一角度出发，本章提出了基于双重不确定性引导的课程学习方法，首先我们改进了无监督行人重识别模型的无优先级训练方法，使模型遵循由易至难的课程学习顺序从样本中逐步接收可靠的标签知识，然后提出了一种双重不确定性的噪声标签建模方法来尽可能多角度发现噪声伪标签，并将标签不确定性以样本加权形式融入到损失函数以抑制噪声对网络训练的影响，以上两步充分缓解了噪声标签对模型性能的负面效应。从兼顾行人的全局特征和局部细节出发，本章进一步设计了局部细粒度语义感知的全局特征改善方法，将局部语义从通道维度和空间维度通过注意力机制注入到全局特征图中，以促进更细粒度的表征学习从而提高特征聚类的伪标签

质量。本章提出的无监督单模态行人重识别算法框架如图3.1所示, 主要包括基于邻居特征亲和力的伪标签可靠度评估模块、基于课程学习的训练方法模块、基于伪标签不确定性估计的噪声抑制模块和局部语义感知的全局特征改善模块。




图 3.1 本章提出的无监督单模态行人重识别算法总览图

3.2 课程学习训练方法

3.2.1 基于邻居特征亲和力的伪标签可靠度评估模块

现有无监督单模态方法主要瓶颈在于：聚类算法将全局外观相似的行人样本划分到一个身份类簇中而导致了标签噪声，给行人重识别模型训练带来影响。经过对多个行人类簇进行统计我们发现，同一类簇下的行人虽然整体外观比较相似，但其局部存在不同程度的差异，而现有研究采用的对行人全局特征层次的聚类操作显然忽视了这种样本间的局部差异。因此我们从分析任意样本与其同一类簇内邻居样本的全局特征和局部特征的亲和力（Feature Affinity）出发，来评估该样本的标签可靠度：




图 3.2 基于邻居特征亲和力的伪标签可靠度评估模块

如图3.2所示, 首先我们改进现有的全局特征提取方法, 特征提取网络 $F(\theta)$

对输入的行人图像 x 进行处理得到全局三维特征图 f_g 的像素高这一维度进行水平切分, 得到若干个新的局部特征支路 $\{f_1, f_2, \dots, f_p\}$:

对于任一样本 x_i , 我们根据其与同一类簇内其他邻居样本的全局水平和局部水平的特征相似度来评估该样本的标签可靠度 R_i :

$$R_i = \sum_{j=1}^{n-1} (\lambda \cdot s(f_g^i, f_g^j) + (1 - \lambda) \cdot \frac{\sum_{p=1}^P s(f_p^i, f_p^j)}{P}), \quad (3.1)$$

其中 $s(\cdot, \cdot)$ 表示向量相似度计算函数, P 表示经过水平划分得到的局部特征图数量, P 越大表示我们关注样本间更细粒度的特征差异。 λ 作为可调节参数控制全局和局部特征相似度对估计标签可靠度的贡献。 n 表示当前类簇中的行人样本数量。更高的可靠度 R_i 表明行人样本 x_i 与其类簇内邻居们有更大的亲和力, 即样本 x_i 更有可能具备一个正确分配的干净标签。如图3.2所示的某个类簇中, 白色衣服男性作为该类簇的标签正确样本, 与类簇内的其他样本在特征空间有更高的特征亲和力, 表明白色衣服男性样本与该类簇的其他样本存在高度的标签一致性, 因此间接反映了该样本标签的高置信度 (亦即低噪声程度)。反之白衣黑裙女性样本由于其头部女性特征和下半身黑裙特征在特征空间与邻居样本的特征亲和力弱, 表明该样本标签的低置信度 (亦即高噪声程度)。

3.2.2 基于标签可靠度的课程学习训练方法

课程学习^[77]这一概念首次由计算机图灵奖得主 Bengio 的科研团队提出, 指的是让深度学习模型模仿人类由易到难学习知识这一范式来吸收样本的知识, 不同于之前广泛应用于有监督学习领域的课程学习相关工作, 我们首次将这一思想运用到无监督行人重识别领域, 如图3.3所示。具体来说, 对于一个包含 n 个行人样本的类簇, 我们通过公式3.1计算每一个图像样本的伪标签可靠度 $\{R_1, R_2, \dots, R_n\}$, 然后基于此执行 Kmeans 算法 ($k=3$), 将每个类簇分离为高伪标签可靠度子集 D_1 、中等伪标签可靠度子集 D_2 和低伪标签可靠度子集 D_3 。在这种情况下, 伪标签可靠度更高的子集 (例如 D_1) 具有更小的类内方差所以更有可能包含该类簇标签下的真正实例 (如图3.3 (c) 所示), 因此应赋予这些高置信度样本训练高优先级, 让模型首先接受可靠的知识, 使得模型在训练早期不易受到噪声标签错误模式的影响。对于伪标签可靠度更低的中低置信度样本子集 (例如 D_2 和 D_3), 其中蕴含了相对较难的样本知识, 有助于帮助模型提高泛化性, 我们灵活运用了2.3章节所述的无监督基线方法中的“聚类-微调-聚类-微调”的交替训练机制, 使模型在前期规避中低置信度样本, 随着交替训练机制的进行, 在训练中后期, 中低置信度样本分配的错误标签也会由于重新聚类而及时移除错误知识进而提高这部分样本的标签干净程度, 此时的模型处在对易样本

知识学习饱和而对难样本知识匮乏的阶段，因此将已经重新聚类且标签干净程度有所提升的中低置信度样本送入模型，将提升模型判别能力的上限。




图 3.3 本章提出的课程学习训练方法

基于上述分析，我们将整个训练流程划分为三个课程学习阶段，即 $\{D_1\}$ 上的课程一， $\{D_1, D_2\}$ 上的课程二和 $\{D_1, D_2, D_3\}$ 上的课程三，以此来分配适合模型的由易到难，由高置信到低置信的样本学习次序 (课程学习顺序)，保证模型既能从行人图像数据中循序渐近接收置信的知识，也能缓解模型对噪声标签的记忆效应，提高无监督单模态场景中行人重识别模型的鲁棒性和可靠性。

3.3 双重不确定性建模方法

基于标签可靠度分配的课程学习训练方法从优化训练流程的角度来抑制噪声标签对网络性能的负面影响，为了进一步抑制噪声标签对模型训练的影响，本研究提出了双重不确定建模方法，如图3.1所示 DUM (dual uncertainty module) 模块。通过合理建模样本标签的不确定性，我们自适应地调整不同样本对损失函数的贡献，进而调整不同样本对行人重识别模型的参数更新的梯度贡献，确保模型的判别能力提升主要源自于低噪声样本。本研究提出了基于教师-学生的原型预测一致性和基于蒙特卡洛 Dropout 的自聚合概率熵两种不确定建模方法。

3.3.1 基于教师-学生的原型预测一致性

首先基于教师-学生的原型预测一致性受启发于半监督学习和带噪声标签学习等领域的相关研究，这些研究表明在多专家场景标签的可靠度往往可以通过不同专家模型对标签的预测分歧程度来反映。基于此，我们采用了教师-学生模型的骨干网络用于训练，这样能够带来两个明显的好处。i) 训练时只有学生模型的参数是通过梯度反传更新，而教师模型的参数通过学生模型的参数滑动平均

机制来更新, 大大减少训练成本。ii) 教师和学生模型对所有样本产生的两个模型视角下的预测一致性可以用于衡量标签可靠度。此外, 一些相关领域的研究表明原型特征往往在表征类簇级别的特点属性方面具有鲁棒性, 因此本研究并没有直接利用教师-学生最后一层全连接层输出的概率分布向量来计算一致性, 而是分别借助教师学生模型输出的同类簇的所有样本特征, 分别产生类簇级别的中心特征嵌入作为类簇原型特征。这些类簇级别的原型将作为非参数化的原型分类器, 通过与实例级别样本的特征相似度计算, 间接计算任意样本基于原型分类器的概率, 这种经过鲁棒的原型分类器计算的预测一致性, 对发现样本级别的噪声是有指导意义的。以上流程可以形式化表示为: 对于来自学生模型的特征向量 $f(x_i) \in \mathbb{R}^{2048}$, 我们计算其基于原型特征 $\{C_1, C_2, \dots, C_c\}$ 的预测概率:

$$p(y_k|x_i) = \frac{\exp(f(C_k)^T f(x_i)/\tau)}{\sum_{k=1}^C \exp(f(C_k)^T f(x_i)/\tau)}, \quad (3.2)$$

其中, C_k 表示基于学生模型输出特征计算的第 k 个类簇的特征原型, τ 表示控制概率分布平滑程度的温度系数。同样, 我们也使用教师模型获得了概率 $\tilde{p}(y_k|x_i)$ 。基于以上分别来自教师模型和学生模型的概率向量, 分别简写成 $\tilde{p}(x_i^k)$ 和 $p(x_i^k)$, 然后我们使用 Kullback-Leibler divergence 散度函数 $D_{KL}(\cdot||\cdot)$ 来衡量教师模型-学生模型对于预测样本 x_i 的概率分布的不一致性水平:

$$d_i = D_{KL}(\tilde{p}(x_i)||p(x_i)) = \sum_{k=1}^C \tilde{p}(x_i^k) \log\left(\frac{\tilde{p}(x_i^k)}{p(x_i^k)}\right). \quad (3.3)$$

当 d_i 越大, 表明教师模型和学生模型对样本 x_i 的预测分歧越大, 即衡量的样本 x_i 的伪标签不确定性值越大, 说明样本 x_i 的标签是噪声标签的可能性越大。

3.3.2 基于蒙特卡洛 Dropout 的自聚合概率熵

基于蒙特卡洛 Dropout 的自聚合概率熵方法旨在弥补第一种不确定建模方法的这种缺陷: 由于教师模型的权重是通过对学生模型这种机制导致学生-教师模型导致两网络之间的同质性, 这意味着它们可能在许多输入上产生相似的预测, 进而导致无法尽可能多地过滤不同类型的错误标签。因此, 我们引入 Monte-Carlo Dropout^[78], 对于任意样本 x_i 我们计算其流经教师模型的 T 次随机前向传递的平均预测熵, 即 $e_i = -\sum_{c=1}^C P_i^c \log P_i^c$, 其中 P_i^c 表示概率分布向量 P_i 中第 c 个类别对应的概率值, 而 $P_i = \frac{1}{T} \sum_{t=1}^T p_t$ 表示 x_i 在教师模型随机 Dropout 情况下 T 次前向传播的聚合概率分布以计算概率熵来实现更稳健的不确定性测量。在这种情况下, 较小的 e_i 反映了样本 x_i 对模型的随机扰动具有鲁棒性, 因此其标签更可能具备高置信度。

3.3.3 标签不确定性感知的损失函数

我们将样本权重融合进损失函数,以抑制具有更高不确定性的样本。任意样本 x_i 的权重由两方面的标签不确定性决定,定义为 $\omega_i = \delta \cdot \exp(-d_i) + (1 - \delta) \cdot \exp(-e_i)$, 其中 δ 用于权衡两种标签不确定性对样本权重估计的贡献。而融合了样本权重的损失函数可以表示为以下形式: 对于一个由 B 个样本组成的训练批次,我们直接将每个样本的权重 w_i 融合进身份损失函数 L_{id} 中:

$$L_{id} = -\frac{1}{B} \sum_{i=1}^B w_i \log p(y_i | x_i). \quad (3.4)$$

此外,由于三元组损失函数和对比学习损失函数均以 < 查询样本, 正/负样本 > 这种样本对的特征距离为约束目标,为了使这两种损失函数也能感知到样本对的不确定性,我们采用查询样本 x_i 权重和它的正负样本 x_k 权重的平均值 $w_{i,k} = 0.5 \cdot (w_i + w_k)$ 作为该样本对的整体权重。因此融合了样本对权重的软三元组损失函数 $L_{triplet}$ 和对比学习损失函数 $L_{contrast}$ 分别可以表示为:

$$L_{triplet} = -\frac{1}{B} \sum_{i=1}^B \log \frac{w_{i,pos} \exp(f(x_{i,pos})^T f(x_i))}{w_{i,neg} \exp(f(x_{i,neg})^T f(x_i))}, \quad (3.5)$$

$$L_{contrast} = -\frac{1}{B} \sum_{i=1}^B \log \frac{w_{i,pos} \exp(M[pos]^T f(x_i))}{\sum_{k=1}^{|M|} w_{i,k} \exp(M[k]^T f(x_i))}, \quad (3.6)$$

其中 $L_{contrast}$ 表示我们受一些无监督研究工作^[66,69-70]的启发引入的基于特征记忆存储模块(Memory Bank)的对比学习损失,通过增大查询样本(query)进行表征学习时的负样本采样数量从而提高模型的辨识能力, $|M|$ 表示特征记忆存储库包含的训练样本历史特征的数量, pos 和 neg 表示与查询样本 x_i 伪标签相同/不同的正/负样本标识。

我们训练模型的最终损失函数可以表示为以上不确定性感知损失函数的加权和:

$$L_{target} = L_{id} + \lambda_{tri} L_{triplet} + \lambda_{ct} L_{contrast}, \quad (3.7)$$

其中 λ_{tri} 和 λ_{ct} 表示损失函数的权重。通过优化以上损失函数,我们能够针对伪标签噪声程度不同的样本进行自适应地权重调整,以抑制标签不确定性高的样本对损失函数的贡献,进而调整不同样本对行人重识别模型的参数更新的梯度贡献,确保模型的判别能力提升主要源自于标签不确定性低(标签噪声程度低)的样本。

3.4 局部语义感知的全局特征改善

聚类算法之所以会产生噪声标签是因为利用行人的全局特征而忽略了很多行人的局部细节来进行聚类得到伪标签。因此除了利用不确定性引导的课程学习来充分抑制噪声标签,我们也使得模型专注于更细粒度的表征学习,如图3.1所示 PRM (Part refinement module) 模块。具体来说我们从特征层面挖掘更细粒度的局部细节,通过不同维度的注意力机制来改善行人的全局特征表示,这将直接有利于模型学习到更强大的判别能力而输出更具有判别能力的特征表示,间接有利于提高基于特征聚类得到的伪标签质量。在本研究中我们从特征的通道维度和空间维度为行人的全局特征表示注入丰富的局部语义信息。

首先我们将局部语义信息沿着通道维度改善行人全局特征:

$$\begin{aligned} F^R &= \sigma(\mathcal{A}^p \otimes F^p) \otimes \Phi \\ &= \sigma(\sigma(\text{MLP}(F^p)) \otimes F^p) \otimes \Phi, \end{aligned} \quad (3.8)$$

其中 $\otimes$ 表示矩阵哈达玛积操作, σ 表示 sigmoid 函数, $\Phi \in \mathbb{R}^{C \times H \times W}$ 表示行人图像的全局特征图, $F^p \in \mathbb{R}^{1 \times C}$ 表示水平切分 Φ 后的第 p 个局部特征图在经过平均池化后的特征向量。MLP 表示多层感知机网络 (multi-layer perception), 我们利用 MLP 在通道维度的缩放操作来产生局部语义感知的注意力图, 我们设置的 MLP 具体结构为: FC:2048 $\rightarrow$ 2048, FC:2048 $\rightarrow$ 512, FC:512 $\rightarrow$ 2048。在上述公式中 $F^R \in \mathbb{R}^{C \times H \times W}$ 就是我们将局部语义沿着通道维度改善过的全局特征图。

接着我们将局部语义信息沿着通道维度对行人全局特征进一步改善:

$$S_{i,j}^p = \frac{\exp(\Phi_{i,j} \cdot F^p)}{\sum_{i,j} \exp(\Phi_{i,j} \cdot F^p)}, \quad (3.9)$$

由上式我们得到一个沿着空间维度的掩码注意力矩阵 $S^p \in \mathbb{R}^{H \times W}$, 用于自适应地调整行人全局特征图每个位置像素值 $\Phi_{i,j}$ 的重要程度, 该注意力矩阵将与上述我们得到的全局特征图 F^R 进行哈达玛积。最后经过平均池化操作 φ 我们得到最终改善的全局特征向量 $f^R \in \mathbb{R}^{1 \times C}$:

$$f^R = \varphi\left(\sum_{i,j} S_{i,j}^p \cdot F_{i,j}^R\right). \quad (3.10)$$

3.5 实验与分析

3.5.1 实验设置

本章实验中, 使用 TITAN XP 作为 GPU。训练模型时整体网络的学习率设置为 0.00035, 选用 Adam 优化器。对于输入图像, 我们统一调整至 256 像素高 $\times$ 128 像素宽的大小, 且采用随机擦除和翻转等常见数据增强手段, 同时我们采

样 16 个伪标签的 64 张行人图像组成一个训练批次。我们采用 DBSCAN 作为特征聚类算法来获得行人样本的伪标签。其他的超参数分别设置为 $T = 10$, $P = 2$, $\tau = 0.1$, $\lambda = 0.5$, $\delta = 0.6$, $\lambda_{tri} = 1.0$ 以及 $\lambda_{cl} = 0.5$ 。

我们在三个主流的单模态行人重识别数据集上评估我们的模型性能, 分别是 Market-1501^[73], DukeMTMC-reID^[17] 和 MSMT17^[74]。如 2.5.2 小节中介绍, 我们采用了 mAP (mean average precision) 和 CMC Rank-1/5/10(R1/R5/R10) 准确率用于评估行人重识别模型的性能。

3.5.2 实验结果分析

1. 消融性实验分析

(1) 各模块有效性

在本部分研究内容的实验中, 我们先设计实验验证了课程学习训练范式的重要性以及我们提出的两种不确定性建模方法的有效性。之后, 我们在国际主流的数据集上做实验验证了我们提出的基于局部语义感知的全局特征改善模块的有效性。从实验结果中可以看出, 我们设计的课程学习训练范式、两种不确定性建模方法和基于局部语义感知的全局特征改善模块都带来了性能上的提升, 验证了这些模块的有效性。

表 3.1 所提模块的消融性结果

基线模型	对比学习	教师-学生结构	课程学习训练方法	双重不确定性估计	局部语义感知特征改善	Duke→Market		Market→Duke	
						mAP	R1	mAP	R1
ResNet50						69.3	89.1	62.1	76.6
ResNet50	✓	✓				77.4	90.6	66.5	80.5
ResNet50	✓	✓	✓			79.8	91.9	69.4	82.2
ResNet50	✓	✓	✓	✓		82.1	93.0	71.5	84.4
ResNet50	✓	✓	✓		✓	80.8	92.5	70.0	82.3
ResNet50	✓	✓	✓	✓	✓	84.0	93.9	72.7	84.9

如表 3.1 所示, 当我们采用以 ResNet50 为骨干网络的无监督基线模型^[35], 基线模型在两个无监督数据集 Duke→Market 和 Market→Duke 上分别取得了 69.3% 和 62.1% 的准确率。我们在此基础上受一些无监督研究工作^[66,69-70]的启发引入了特征记忆存储库的对比学习方法来提高无监督表征学习的负样本采样数量, 同时我们也跟随 MMT 等方法^[44,67]引入了教师-学生结构的模型来实现更高质量的特征提取与聚类, 这两个模块的引入有效提高了基线模型的无监督性能, 在 Duke→Market 和 Market→Duke 上分别达到了 77.4% 和 66.5% 的 mAP 性能。

当我们进一步提出课程学习训练方法, mAP 精度可以在 Duke→Market 和 Market→Duke 上分别取得 2.4% 和 2.9% 的性能提升, 这说明课程学习思想通过分配合理的样本学习顺序对于减少 ReID 模型对噪声标签的记忆效应确实是有帮助的。之后我们进一步提出使用两种不确定估计方法来建模样本标签的不确定性, 可以看到通过这种方法自适应调整样本对损失函数计算的贡献进一步抑制

了噪声标签,在 Duke→Market 无监督数据集上取得了 82.1% 的 mAP 精度。除此以外,我们提出将局部语义融合至全局特征图的方法也进一步带来了收益,这说明促进更细粒度的行人表征学习对于提高模型判别能力是有帮助的。最后当我们把以上提出的所有方法集成到一个整体的无监督学习框架,相对于基线模型在 Duke→Market 和 Market→Duke 数据集上分别取得了 14.7% 和 10.6% 的 mAP 精度提升,达到了 84.0% 和 72.7% 的 mAP 性能,验证了所提出方法的有效性。

(2) 超参数分析

如图3.4所示,我们分析了两个主要参数对模型性能的影响,分别是标签可靠度评估模块中(见章节3.2.1)的 λ 和水平切分的局部特征数量 P (见章节3.2.1和3.4)。 λ 作为可调节参数控制样本与邻居的全局和局部特征相似度对




图 3.4 参数值对性能影响分析

估计标签可靠度的贡献,当 λ 越大表示全局特征相似度比重越大, $\lambda = 0$ 表示只考虑全局特征,我们可以发现 $\lambda = 0.5$ 即全局和局部特征相似度具有相同贡献时,模型性能达到峰值。 P 表示水平切分的局部特征数量, $P = 2$ 即将行人图像均分为上半身和下半身时效果最好,当 P 越来越大时意味着均分得越密集,即我们将更加细粒度的局部语义融合到全局特征向量,但这也会导致切分的局部区域辨识度更小(例如仅行人衣服的其中一块小区域是不具备合理语义信息的),因此造成特征融合时的噪声。

(3) 可视化实验

本节设计了可视化实验来比较不同模型的效果，从而进一步验证本文方法的有效性。首先，我们选取了模型训练完毕输出的随机 20 个行人身份的特征，通过 t-SNE 图^[79]比较几个模型学习到的这 20 个身份下行人特征的空间分布，如图3.5和3.5所示，不同颜色圆圈代表不同身份的行人，其中我们进行了两组类簇分析，第一组是虚线圆圈包围的 ID-1 行人和 ID-2 行人，第二组是虚线圆圈包围的 ID-3、ID-4 和 ID-5 行人。




图 3.5 基线模型的 t-SNE 特征分布可视化




图 3.6 SPCL 和本文模型的 t-SNE 特征分布可视化

首先我们对第一组 ID-1 和 ID-2 行人进行分析，由图3.5我们可以看到，基线模型（Baseline）输出的 ID-1 和 ID-2 行人的特征在特征空间是距离很相近的，这

反映基线模型学习到的两个身份下行人的特征是不够有辨别力的。由图3.6 (a) 可以看到 SPCL 模型通过引入自步对比学习的训练策略对 ID-1 和 ID-2 行人这两个不同类簇特征进行了一定程度区分。图3.6 (b) 显示本文的模型特质分布, 本文通过额外的支路将局部特征以注意力机制融合至全局特征中, 促使模型进行更细粒度的表征学习, 因此对 ID-1 和 ID-2 行人在特征空间进行了更有效的区分。

然后我们对第二组 ID-3、ID-4 和 ID5 行人进行分析, 我们可以看到, 在基线模型对应的3.5特征分布图中, ID-3、ID-4 和 ID5 行人的特征在特征空间同样很接近, 同时每一个 ID 下的行人样本彼此比较分散, 这说明基线模型不论是在类间分离性和类内紧凑性两方面都表现不够好。图3.6(a) 显示的 SPCL 模型输出的三个 ID 下的行人样本彼此间出现了混合情况, 增大了辨认难度, 这一现象就是在聚类阶段导致噪声标签的根源, 即不同身份行人由于特征分布过于相似而被聚类算法错误地聚类到同一个类簇中。图3.6(b) 显示本文模型输出的 ID-3、ID-4 和 ID5 行人特征在空间得以分散开, 是因为我们的课程学习策略相比于 SPCL 模型不仅仅只专注可靠类簇的自步学习策略, 通过对相同类簇下行人进行标签可靠性估计, 使模型优先学习那些与邻居样本综合相似度高即标签更可靠的样本, 从而模型对类簇内的干净标签和噪声标签进行了有效区分, 避免模型出现对噪声拟合导致学习的特征不够有辨别力的问题。

为了从深度神经网络可解释性角度来验证所提方法的有效性, 本节还使用了类激活热力图方法 (Grad-CAM^[80]) 比较了我们的模型 (Ours) 与基线模型 (Baseline) 的性能优劣。热力图响应越高的区域表示该区域对模型最终决策的贡献越大, 即表示模型预测结果和不同区域的相关性大小。如图3.7所示, 我们依次分析了基线模型和我们的模型在四个不同身份行人图像上的激活图, 从图中可以看出我们的模型学习到的行人特征十分均衡地关注到了行人的上中下区域, 而基线模型容易忽略某些重要区域线索, 例如在3.7(c) 中, 基线模型只关注到了该行人的头部特征, 而我们的模型在决策时兼顾学习到了头部、肩膀和腿部区域的特征重要性。在3.7(d) 中, 基线模型重点关注了行人的上半身躯干特征, 而我们的模型同时学习到了该行人的手臂和下半身特征。这是由于我们的模型通过将局部特征和全局特征在通道维度和空间维度的亲和力大小转换为两个维度上的注意力系数, 从而以注意力机制将局部语义融合到全局特征图中, 有效提高了全局特征语义和粒度的丰富性, 强化了模型在优化特征时对各个子区域特征的关注度。

最后我们随机选取 Market1501 测试集中的部分查询图像 (query), 可视化几种不同方法在候选图像集合 (gallery) 中的检索结果, 如图3.8所示, 绿色框图像代表检索出的图像与查询图像的行人身份相同, 即检索正确, 红色表示检索错误。可以看到我们的方法在不同查询图像作为模型输入时得到的前十位检索行人是




图 3.7 Grad-CAM 热力图

错误率最低的，优于 SPCL^[66]和 UNRN^[44]。一方面这是由于我们的模型采用了课程学习的训练策略，相比于 SPCL 仅关注可靠类簇的自步学习训练策略，我们使前期标签可靠性低的样本在模型训练后期得以重新聚类分配更高质量的伪标签，从而保证模型充分学习了大多数样本中的知识因此具备更鲁棒的辨别能力。另一方面，我们对噪声标签采用了两种不确定性建模方法，相比于 UNRN 的单一不确定性建模方法，我们的方法采用了基于特征原型的预测不一致性和基于 Monte Carlo 的概率熵，因此能够更准确地抑制噪声标签对训练损失函数的贡献。总体来说，我们的方法在训练策略和噪声估计等方面弥补了 SPCL 和 UNRN 两种方法存在的不足，从而实现了更好的行人重识别效果。




图 3.8 检索结果可视化

2. 与主流方法的对比

我们比较了我们提出的无监督单模态行人重识别方案与当前主流方法的对比实验，相应结果如表3.2和3.3所示，其中 SPCL 的部分结果是我们根据其官方代码库复现的结果。表格中粗体字表示该方法在当前数据集上性能最优，下划线表示表示该方法在当前数据集上性能达到次优。我们设计的基于不确定性引

表 3.2 与主流无监督单模态方法在 Duke 和 Market 数据集上的对比实验

方法	来源	Duke→Market				Market→Duke			
		mAP	R1	R5	R10	mAP	R1	R5	R10
MMT ^[67]	ICLR'2020	71.2	87.7	94.9	96.9	65.1	78.0	88.8	92.5
NRMT ^[81]	ECCV'2020	71.7	87.8	94.6	96.5	62.2	77.8	86.9	89.5
SPCL ^[66]	NIPS'2020	77.5	89.7	96.1	97.6	68.8	82.9	90.1	92.5
MEB-Net ^[82]	ECCV'2020	76.0	89.9	96.0	97.5	66.1	79.6	88.3	92.2
Dual-Refinement ^[83]	TIP'2021	78.0	90.9	96.4	97.7	67.7	82.1	90.1	92.5
UNRN ^[44]	AAAI'2021	78.1	91.9	96.1	97.8	69.1	82.0	90.7	93.5
GLT ^[84]	CVPR'2021	79.5	92.2	96.5	97.8	69.2	82.0	90.2	92.8
P2LR ^[85]	AAAI'2022	81.0	92.6	97.4	98.3	70.8	82.6	90.8	93.7
IDM ^[86]	ICCV'2021	82.8	93.2	97.5	98.1	70.5	83.6	91.5	93.7
RESL ^[40]	AAAI'2022	83.1	93.2	96.8	98.0	<u>72.3</u>	83.9	91.7	93.6
MCRN ^[87]	AAAI'2022	<u>83.8</u>	<u>93.8</u>	<u>97.5</u>	<u>98.5</u>	71.5	<u>84.5</u>	<u>91.7</u>	<u>93.8</u>
Ours	-	84.0	93.9	97.5	98.6	72.7	84.9	92.0	93.9

导的课程学习和局部语义感知的全局特征改善方法和当前的主流方法对比, 在 Duke→Market、Market→Duke 以及 Market→MSMT 三个跨数据集无监督任务上的测试结果上是取得了最好结果, 同时在第四个跨数据集 Duke→MSMT 无监督任务上也是具有可比性的。这验证了我们方法的有效性, 也凸显了我们设计的方法的优越泛化性能。

表 3.3 与主流无监督单模态方法在 MSMT 数据集上的对比实验

方法	发表	Market→MSMT				Duke→MSMT			
		mAP	R1	R5	R10	mAP	R1	R5	R10
MMT ^[67]	ICLR'2020	22.9	49.2	63.1	68.8	23.5	50.1	63.9	69.8
Dual-Refinement ^[83]	TIP'2021	25.1	53.3	66.1	71.5	26.9	55.0	68.4	73.2
UNRN ^[44]	AAAI'2021	25.3	52.4	64.7	69.7	26.2	54.9	67.3	70.6
GLT ^[84]	CVPR'2021	26.5	56.6	67.5	72.0	27.7	59.5	70.1	74.2
P2LR ^[85]	AAAI'2022	29.0	58.8	71.2	76.0	29.9	60.9	73.1	77.9
IDM ^[86]	ICCV'2021	33.5	61.3	73.9	78.4	<u>35.4</u>	63.6	75.5	80.2
MCRN ^[87]	AAAI'2022	32.8	64.4	<u>75.1</u>	79.2	35.7	67.5	77.9	81.6
RESL ^[40]	AAAI'2022	<u>33.6</u>	<u>64.8</u>	74.6	<u>79.6</u>	34.2	65.2	74.6	80.1
Ours	-	33.9	65.0	74.8	79.7	34.6	<u>66.5</u>	<u>76.8</u>	<u>81.0</u>

3.6 本章小结

针对目前大多数基于聚类微调的无监督单模态行人重识别方法的两个主要问题: 采用无样本优先级的训练方法而忽视了不同程度噪声标签样本对模型训练影响, 以及采用单一的噪声标签建模方法而疏漏了不同特点的噪声标签, 本章节从合理的课程学习训练策略和完善的三重不确定性建模方法两方面来克服上

述两个问题。同时为了解决当前方法忽视局部细粒度特征而导致的模型辨别力受限这一问题，本章节提出了局部语义感知的特征改善方法以将丰富的局部语义信息融合到行人的全局特征向量中，进一步提高了表征学习的质量。在实验阶段我们在公开数据集上针对各模块的消融实验和与前沿方法的比较实验验证了所提方法的有效性。最后我们也通过 t-SNE 可视化手段验证了我们的课程学习训练策略和不确定性建模方法对抑制噪声标签的积极作用，通过 Grad-CAM 热力图验证了经过局部语义改善的行人特征能更全面关注到行人的局部区域判别线索。

第4章 基于视觉语言模型知识蒸馏的无监督跨模态行人重识别

本章将介绍提出的基于视觉语言模型知识蒸馏的无监督跨模态行人重识别方法。首先，在引言部分介绍当前方法的不足和我们所提方法的出发点。然后我们从基于特征蒸馏的 CLIP 微调方法、文本语义增强的红外-可见光模态内表征学习以及基于 CLIP 对比关系蒸馏的红外-可见光跨模态表征学习，这三个方面来详细介绍我们的算法整体框架和模块设计细节。最后我们通过大量实验来验证所提方法的有效性。

4.1 引言

目前，大部分无监督跨模态行人重识别研究主要集中在对可将光图像和红外图像这两种模态行人图像互搜的方法研究，相比于无监督单模态行人重识别，更困难的瓶颈主要在于：如何建立模态间图像配对关系以及如何基于配对关系进行更好的跨模态表征学习。当前主要方法一般采用2.4章节所述的模态内表征学习和跨模态表征学习解耦的两阶段训练方法。具体来说，这些方法在一阶段通过分别对两种模态图像特征聚类，来获得两套模态独立的伪标签以监督网络的训练，在二阶段通过将配对问题建模成二分图匹配问题，将跨模态图像间的特征不相似度转化为节点间匹配的代价，基于此代价矩阵来求解跨模态二分图匹配问题，之后基于这种配对关系进行红外(可见光)图像到可见光(红外)图像的跨模态特征对齐。总体来看已有方法在解决上述瓶颈问题时蕴含的思想都是在图




图 4.1 同一身份行人可见光和红外图像分别对应的文本

像特征层面来建立跨模态配对关系和进行跨模态表征学习，这种做法存在两点不足：1) 过度依赖于图像特征进行相似度计算来挖掘红外-可见光跨模态匹配对，

然而这种特征向量是由经过噪声标签训练的网络产生的, 因此特征向量的辨别性受了影响, 此外红外和可见光图像天然相差较大的特征相似性可能会无法找准置信的匹配对; 2) 行人图像的语义差异与共性被忽视, 不同身份的行人应该具有独特的语义属性, 而同一身份的行人不论模态差异应具有一致的语义, 因此行人的语义属性相比于行人图像特征更能抽离出行人的身份特点并有助于促进模型学习更有辨别力的特征, 然而如何获取这种行人语义以及如何借助行人语义促进红外和可见光图像的间的跨模态表征学习, 仍未得到有效探索。

当下以大语言模型 (LLM, Large Language Model) 为代表的前沿方法^[88-91] 开启了人工智能新篇章, LLM 的理解能力在自然语言处理、计算机视觉以及搜索推荐等算法领域都已经得到了充分验证。在我们的行人重识别相关实验中, 我们发现基于行人图像和精心设计的提示 prompt, 输入到已有多模态 LLM(例如 InstrutBLIP^[91]、LLAVA^[90] 等) 来对不同行人图像产生的文本描述包含十分重要的语义信息, 具体来说尽管同一个行人的红外/可见光数据在图像层面相似度小, 但对应的红外/可见光文本描述是高度一致的, 两种模态下的文本描述均能捕捉到行人的服装风格 (除颜色外) 以及形体步态之类的结构信息, 如图4.1。这表明,




图 4.2 本章提出的无监督跨模态行人重识别算法总览图

借助不同模态下的行人描述文本, 可以缓解配对过程中的不对齐问题。我们首先引入大规模图文预训练模型 CLIP, 在我们收集的红外-可见光-描述文本数据集上进行基于特征蒸馏方法的微调, 使其兼顾原 CLIP 中的泛化知识和行人重识别的任务特定知识, 从而更好地适配到行人重识别这种细粒度识别问题上, 我们称之为 VI-CLIP。为了在跨模态匹配时缓解仅依赖于红外和可见光图像特征相似度产生的匹配噪声问题, 我们将 VI-CLIP 模型输出的语义信息更丰富的文本特征

和辨别能力更强的视觉特征作为外部知识,与原始的 ReID 模型的视觉特征一起经过处理得到混合原型分类器,完成更准确的跨模态匹配过程。为了在模型训练时利用文本语义信息辅助红外-可见光模态的相互对齐,我们利用 VI-CLIP 中的图文对齐知识,在无监督跨模态 ReID 模型训练的第一阶段进行文本语义增强的模态内表征学习,在第二阶段进行基于关系蒸馏的跨模态表征学习,这两阶段保证红外和可见光图像都能够与语义一致的文本特征对齐,从而间接促进红外和可见光图像的相互对齐,值得注意的是,不论是 LLM 还是 CLIP,都只是在训练中发挥辅助红外可见光对齐的作用,在测试时是不需要的,这保证了推理和部署的灵活性。

4.2 基于特征蒸馏的 CLIP 微调方法

基于图4.1中的观察,同一身份行人的可见光图像和红外图像对应的文本描述具有较高的语义一致性,这启发我们将可见光和红外图像分别与相同语义的文本进行对齐,间接促进可见光和红外图像在表征层面的靠近,进而提高 ReID 模型的跨模态识别能力。因此一个自然的想法是:借助语义高度对齐的文本特征来产生行人身份级别的文本原型特征,使该文本原型特征扮演中间模态连接器的作用,在模型训练过程中我们促进红外和可见光图像特征分别与文本原型特征对齐,来间接促进红外和可见光图像特征相互对齐。

近两年,图文对比预训练模型 CLIP (Contrastive Language Image Pretraining) 作为一个通用的跨模态大模型,通过在 4 亿图文对数据集上进行预训练从而获得了强大的跨模态表征能力,已经在多个下游跨模态任务中展现出了强大的跨模态语义理解能力,其训练原理如图4.3所示。在基于文本搜图的行人搜索任务




图 4.3 图文对比预训练模型 CLIP^①

^①图源自 <https://arxiv.org/abs/2103.00020>

(Text-based person search) 中, CLIP 也是一个被广泛采用的基线模型。然而学术界目前还没有将 CLIP 模型应用于红外可见光 ReID 任务中, 这其中的原因可能如下: i) 基于文本搜图的行人搜索任务中, 有精细化标注的行人文本描述, 而文本标注信息对于无监督红外可见光场景的行人重识别任务是不可获取的。ii) 红外可见光行人重识别的直接任务是红外条件和可见光条件下的行人互搜, 而 CLIP 作为图文对齐模型, 其如何辅助红外/可见光这两种图像模态对齐, 暂时没有可直接借鉴的方法。接下来我们将介绍将 CLIP 模型适配到可见光红外跨模态 ReID 任务的具体实现方法。

4.2.1 伪图文对数据的生成与制作

得益于 VLLM (Vision Language Large Model) 强大的多模态理解和生成能力, 我们能够利用已有的视觉语言大模型对行人图像的理解来生成一段描述文本, 从而一定程度填补上述红外可见光图像无文本描述的空白, 这种文本描述在描述同一个身份的红外模态和可见光模态行人图像时具有语义一致的特点, 因此将作为模态连接器为辅助红外可见光图像对齐打下基础。具体来说, 我们将可见光/红外行人图像和 prompt 提示文本作为 LLaMA-Adapter^[88] 的输入, 通过视觉语言大模型的 zero-shot 推理能力来获取行人图像的文本描述。具体流程如图4.4所示:




图 4.4 基于视觉语言大模型 zero-shot 推理生成的行人文本

可以看到, 尽管可见光和红外图像在外观上差异比较大, 但是其文本描述仍然具有高度一致的结构信息。如图粗体字部分所示, VLLM 捕捉到了两种模态图像行人的性别/体型/发型/上半身穿衣风格 (shirt/muscular/pants/short hair), 这充分说明了文本描述其中包含了丰富的模态无关的行人结构信息。另一方面, 文本描述也保留了模态特异的行人外观信息: 例如 red/black/white 等颜色相关的词。这说明尽管无法获得人工标注的行人文本描述, 但基于已有大模型的推理能力我们仍然能够获得包含丰富信息的伪文本信息。

4.2.2 基于特征蒸馏的微调

基于已经获取的红外行人文本描述和可见光行人文本描述,我们期望利用 CLIP 模型的图文对齐能力,辅助红外/可见光这两种图像模态对齐。然而,原始 CLIP 具备的是粗粒度分类识别能力,只擅长捕捉类别不同的目标物体的差异(例如猫/狗/汽车/飞机等),为了让 CLIP 更好契合行人重识别这种细粒度检索任务,我们提出对 CLIP 在手工收集的小型可见光-红外-文本行人重识别数据集上进行增量微调。

为了保证 CLIP 模型在我们收集的图文 ReID 数据集上微调时既能获得对行人的细粒度识别能力,也能保留原模型中丰富的泛化性知识,受视频理解等相关工作^[92-94]的启发,我们在微调时采用一种基于残差结构的特征蒸馏方法^[93]将原 CLIP 知识迁移到我们的 VI-CLIP 上,如图4.5所示。




图 4.5 基于特征蒸馏的 VI-CLIP 微调

在特征蒸馏支路,我们以冻结的 CLIP 模型作为教师模型,以我们要微调的 VI-CLIP 作为学生模型。基于特征蒸馏有两种常见的方法,一种是将学生模型特征与教师模型特征直接进行特征对齐,无需进行特征投影。然而,这种强监督要求学生模型的特征保持与教师模型特征完全相同,这限制了学生模型特征学习红外可见光跨模态 ReID 的识别能力。另一种方法是应用一个投影层网络,将微调模型的特征从学生空间映射到教师空间,这种弱监督放宽了对学生模型特征的约束,以便更好地拟合 ReID 数据,但同时也限制了其泛化能力。因此考虑到上述两个学习目标,我们需要在两种方法之间找到一个折中方案。

受到 ResNet 残差结构的启发,该特征蒸馏方法设计了一个残差网络用于蒸馏时平衡两个学习目标^[93]。这种设计背后的直觉是允许微调后的特征有效地接受冻结的原始 CLIP 的监督,同时也保持对行人特征的有效学习能力。如图4.5所示,本文应用一个改进的残差网络,通过 MLP (multi-layer perception) 投影层网络和恒等映射来转换学生模型特征,从而与教师模型对齐,其中采用的损失函数

如下所示:

$$ResBlk(FT(text_i)) = FT(text_i) + \beta \cdot MLP(FT(text_i)) \quad (4.1)$$

$$L_{distill}^{text} = -\frac{1}{B} \sum_{i=1}^B ||FT^*(text_i) - ResBlk(FT(text_i))||_2^2, \quad (4.2)$$

$$L_{distill}^{image} = -\frac{1}{B} \sum_{i=1}^B ||FI^*(image_i) - ResBlk(FI(image_i))||_2^2, \quad (4.3)$$

其中 B 表示一个训练批次的大小, $image_i$ 和 $text_i$ 表示该训练批次中第 i 张图像和第 i 个文本, FT^* 和 FI^* 分别表示冻结的原始 CLIP 的文本和视觉编码器, FT 和 FI 则表示我们需要微调的 VI-CLIP 的文本和视觉编码器, $ResBlk$ 表示残差模块。

在对比学习支路, 我们遵循原始 CLIP 的训练方法, 在可见光图像-可见光对应文本以及红外图像-红外对应文本上进行对比学习任务, 采用损失函数如下所示:

$$L_{image \rightarrow text} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(FT(text_i)^T \cdot FI(image_i))}{\sum_{k \neq i} \exp(FT(text_k)^T \cdot FI(image_i))}, \quad (4.4)$$

$$L_{text \rightarrow image} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(FI(image_i)^T \cdot FT(text_i))}{\sum_{k \neq i} \exp(FI(image_k)^T \cdot FT(text_i))}. \quad (4.5)$$

因此, 基于特征蒸馏方法的 CLIP 微调损失函数可以表示成:

$$L_{fine-tune} = L_{distill}^{text} + L_{distill}^{image} + L_{text \rightarrow image} + L_{image \rightarrow text}. \quad (4.6)$$

4.3 一阶段: 文本语义增强的红外-可见光模态内表征学习

基于图4.1中的观察, 我们期望通过语义一致的文本信息来增强原来红外-可见光模态的表征学习。在本章我们遵循无监督跨模态行人重识别的两阶段训练方法 (如2.4节中所述), 并将文本信息分别嵌入到两阶段以增强红外和可见光的对齐关系。

第一阶段进行的是模态内表征学习, 即红外模态和可见光模态数据在这一阶段进行无关联的独立的模型训练。要使得文本信息能发挥增强模态对齐的作用, 我们应该在第一阶段使图像特征空间和文本特征空间建立联系。我们以可见光模态为例。首先, 对于可见光数据的模态内表征学习, 我们分别基于可见光图像中心特征和可见光文本中心特征, 来初始化两个记忆存储库进行对比学习, 这两个记忆存储库分别由聚类后同一个可见光类簇伪标签下的所有图像和文本的

中心特征进行初始化:

$$C_k^v = \frac{1}{|S_k^v|} \sum_{f(x_m^v) \in S_k^v} f(x_m^v), \quad (4.7)$$

$$C_k^{vt} = \frac{1}{|S_k^v|} \sum_{f(x_m^v) \in S_k^v} FT(x_m^{vt}), \quad (4.8)$$

其中 C_k^v 和 C_k^{vt} 分别表示可见光模态 (visible) 的第 k 个类簇的图像中心特征和文本中心特征, $f(x_m^v)$ 和 $f(x_m^{vt})$ 分别表示第 m 张可见光模态的行人图像特征和文本特征, 其中文本特征是利用我们前面微调过的 VI-CLIP 的文本编码器 FT 提取得到, S_k^v 表示第 k 个伪标签类簇下的样本集合。在训练过程中我们将当前训练批次内 (batch) 的可见光图像特征与记忆存储模块中的同类簇的图像中心特征和文本中心特征分别进行拉近:

$$L_{contrast}^v = -\frac{1}{B} \sum_{m=1}^B \log \frac{\exp((C_{pos}^v)^T \cdot f(x_m^v))}{\sum_{k=1}^{|C^v|} \exp((C^v)^T \cdot f(x_m^v))}, \quad (4.9)$$

$$L_{contrast}^{vt} = -\frac{1}{B} \sum_{m=1}^B \log \frac{\exp((C_{pos}^{vt})^T \cdot f(x_m^v))}{\sum_{k=1}^{|C^{vt}|} \exp((C^{vt})^T \cdot f(x_m^v))}, \quad (4.10)$$

其中 $f(x_m^v)$ 表示当前训练批次 batch 内第 m 张可见光模态的行人图像特征。 C^v 和 C^{vt} 分别表示红外模态的图像中心特征和文本中心特征的记忆存储库, 则 C_{pos}^v 和 C_{pos}^{vt} 表示与查询样本 $f(x_m^v)$ 伪标签相同的同类簇图像中心特征和文本中心特征。因此第一阶段针对可见光模态训练的损失函数可以表示成:

$$L^v = L_{contrast}^v + \lambda L_{contrast}^{vt}, \quad (4.11)$$

同理我们为红外模态训练计算的损失函数 L^i 。值得注意的是, $L_{contrast}^v$ 是章节2.4.1所述基线方法中的损失函数, 其目的是为了可见光图像特征与同类簇或不同类簇的图像中心特征接近或远离, 我们在此基础上额外提出的 $L_{contrast}^{vt}$ 则是通过施加图像与不同文本特征中心的距离约束从而使图像特征语义化, λ 权重系数控制了这种文本语义引导的强弱。因此, 第一阶段模型训练的损失函数可以表示为:

$$L_{overall} = L_{contrast}^v + L_{contrast}^i + \lambda(L_{contrast}^{vt} + L_{contrast}^{it}). \quad (4.12)$$

4.4 二阶段: 基于对比关系蒸馏的红外-可见光跨模态表征学习

4.4.1 基于混合原型分类器的跨模态匹配方法

如2.4.2所述, 在无监督跨模态 ReID 的第二阶段, 以往工作往往通过阈值法和二分图法来建立红外特征和可见光特征的跨模态联系, 其本质思想都是基于

两种模态图像的特征相似度,这背后有两个缺点:首先,由于两种模态图像的天然外观差异,这种特征相似度在表示跨模态图像相似性时可能会不够准确,并且这种匹配过程忽视了行人身份的语义差异与共性。此外,由于噪声标签的影响,经过第一阶段训练的模型输出的特征表示向量的辨别性是受了影响的,基于这种特征向量来计算相似度显然也是不够合理的。因此,我们提出将多种混合知识注入到跨模态匹配的决策中,实现了一种如图4.6所示的基于混合原型分类器的跨模态匹配方法。




图 4.6 基于混合原型分类器的跨模态匹配方法

以往的跨模态匹配方法往往仅基于行人的全局视觉特征进行相似度计算,这不但忽略了图像的一些细粒度差异,也忽略了由于噪声标签导致特征质量受到影响。为了弥补这种跨模态匹配方法的两方面缺陷,我们提出分别将 ReID 模型输出的多个局部视觉特征和 CLIP 模型输出的视觉/文本特征同时纳入到跨模态匹配框架中。具体来说,每一个类簇下的单个行人样本通过 ReID 模型推理获得其全局行人特征、局部行人特征,和 CLIP 模型输出的视觉特征和文本特征,而对于该类簇下的所有样本获得的这些不同类型特征将分别通过特征平均操作得到对应支路的原型特征 (prototype feature)。以 CLIP 文本支路为例,设红外模态 (infrared) 和可见光模态 (visible) 分别用 i 和 v 表示,两种模态下的数据经过聚类分别得到 K_1 和 K_2 个类簇, D_{clip} 表示 CLIP 输出的特征维度,则我们可以分别为红外模态和可见光模态获得第 k 个类簇的文本特征原型 $C_k^{vt} \in \mathbb{R}^{1 \times D_{clip}}$ 和 $C_k^{it} \in \mathbb{R}^{1 \times D_{clip}}$:

$$C_k^{vt} = \frac{1}{|S_k^v|} \sum_{FT(x_m^v) \in S_k^v} FT(x_m^v), \quad (4.13)$$

$$C_k^{it} = \frac{1}{|S_k^i|} \sum_{FT(x_n^i) \in S_k^i} FT(x_n^i), \quad (4.14)$$

则红外模态所有类簇的文本特征原型向量经过拼接可以得到 $C^{it} \in \mathbb{R}^{K_1 \times D_{clip}}$ 这样的类簇文本原型拼接向量,同理我们也可以为可见光模态支路计算类簇文本

原型拼接向量 $C^{vt} \in \mathbb{R}^{K^2 \times D_{clip}}$ 。接下来以红外模态的类簇文本原型拼接向量 C^i 作为分类器，我们将可见光的文本原型拼接向量 C^v 与其做点乘，便可以计算每一个可见光类簇分配给红外类簇的概率分布 $Prob_{text} \in \mathbb{R}^{K^1 \times K^2}$ ：

$$Prob_{text} = Softmax(\frac{C^{it}}{\|C^{it}\|_2} \times (\frac{C^{vt}}{\|C^{vt}\|_2})^T / \tau), \quad (4.15)$$

其中 $Prob_{text} \in \mathbb{R}^{K^1 \times K^2}$ 矩阵的第 m 行第 n 列元素含义表示第 n 个可见光类簇与第 m 个红外类簇相匹配的概率大小。同理，对于其他支路我们也以不同类簇原型为分类器计算得到不同视角下的匹配概率分布，如图4.6所示。我们通过投票机制^[95]聚合各个原型分类器的输出概率从而获得最终的概率分布矩阵 $Prob_{vote}$ ：

$$\begin{aligned} Prob_{vote} &= \sum_j \alpha_j \cdot Prob_j, \\ s.t. \sum_j \alpha_j &= 1, \end{aligned} \quad (4.16)$$

其中 α_j 表示第 j 个原型分类器的概率分布 $Prob_j$ 在投票时的权重系数，而 $Prob_{vote} \in \mathbb{R}^{K^1 \times K^2}$ 概率分布矩阵的第 m 行第 n 列元素含义表示第 n 个红外类簇与第 m 个可见光类簇相匹配的概率大小，随后我们通过 $\arg \max$ 操作，找到与第 m 个可见光类簇匹配概率最大的第 n 个红外类簇，记为跨模态匹配身份类簇，因此我们组成一对跨模态匹配类簇 $\langle m, n \rangle$ ，而该匹配关系将直接用于接下来的跨模态表征学习。

这种基于混合原型的投票方法，能集成来自每种原型特征分类器视角下的概率分布（包括 CLIP 模型输出的语义信息更丰富的文本特征和辨识能力更强的图像特征），减少由单一 ReID 模型的全局图像特征计算跨模态匹配概率的误差，也是本文提出的跨模态匹配方法与以往基于特征相似度匹配的最大优势。

4.4.2 基于关系蒸馏的跨模态对齐

由于无监督跨模态行人重识别旨在训练一个适用于两种图像模态互搜场景的具备高判别性能的行人重识别模型，因此其核心仍在于这两种图像模态的相互辨识能力。经过第一阶段两种图像模态与各自模态对应文本间的距离约束，我们在两种模态内实现了独立的图像特征语义化。为了能够进一步促进红外图像和可见光图像的相互对齐，我们在第二阶段使两种图像模态分别与对方的文本原型特征进行对齐。具体来说，我们冻结已经微调好的 VI-CLIP，将其中的可见光图像-红外图像-文本原型的对齐知识，通过关系蒸馏方法^[96-98]迁移到 ReID 模型的可见光和红外图像的双流网络中。

第一阶段中我们通过将图像特征与记忆存储模块的文本中心特征进行对比学习从而实现了图像特征语义化，因此在第二阶段的一个自然想法是将图像特

征与另一图像模态对应的文本特征记忆存储模块对齐来实现跨模态交互。然而这种方法可能存在一个直接的歧义性学习问题：例如假设我们将可见光图像同时与红外模态的图像记忆存储库和文本记忆存储库进行对齐，会导致模型无法判别图像特征与文本特征的重要性，即“学偏了”。因此我们采用了一种更柔和的对齐方式，即基于对比关系的知识蒸馏。假设当前训练 batch 内有一张可见光图像 $f(x_m^v)$ ，我们利用公式4.16从特征记忆存储库中找到其配对的红外类簇，将该红外类簇的图像中心特征记为 C_{pos}^i ，配对红外类簇的文本中心特征记为 C_{pos}^{it} ，配对红外类簇的图像特征与所有红外类簇文本中心特征的相似度关系 (Relation) 则可以表示为：

$$R^{i \rightarrow it} = \text{Softmax}\left(\frac{C_{pos}^i}{\|C_{pos}^i\|_2} \times \left(\frac{C^{it}}{\|C^{it}\|_2}\right)^T\right). \quad (4.17)$$

进一步地，我们计算可见光图像 $f(x_m^v)$ 和红外类簇文本特征的相似度关系：

$$R^{v \rightarrow it} = \text{Softmax}\left(\frac{f(x_m^v)}{\|f(x_m^v)\|_2} \times \left(\frac{C^{it}}{\|C^{it}\|_2}\right)^T\right). \quad (4.18)$$

我们可以看到，公式4.17和4.18计算的是一个跨模态匹配对 $\langle f(x_m^v), C_{pos}^i \rangle$ 中的两元素分别与一致的比较对象 C^{it} 计算得到的两个关系向量 $R^{i \rightarrow it}$ 和 $R^{v \rightarrow it}$ ，而 C^{it} 作为一个描述不同行人身份语义的文本向量集合，如果限制 $R^{i \rightarrow it}$ 和 $R^{v \rightarrow it}$ 两关系向量的分布尽可能一致，就等效于在特征空间促进可见光-红外跨模态配对 $\langle f(x_m^v), C_{pos}^i \rangle$ 他们的语义分布彼此接近，这与我们图4.2中的观察和动机相契合。因此我们通过 Kullback-Leibler Divergence 散度函数 $D_{KL}(\cdot||\cdot)$ 限制这两个关系向量的分布一致性：

$$L_{distill}^v = \frac{1}{B} \sum_{m=1}^B D_{KL}(R_m^{v \rightarrow it} || R_m^{i \rightarrow it}). \quad (4.19)$$

同理，我们也为红外模态计算关系蒸馏损失函数 $L_{distill}^i$ ，因此第二阶段模型训练的损失函数不仅包括2.4.2章节所述的基线模型的跨模态对比学习损失函数 $L_{contrast}^{v \rightarrow i}$ 和 $L_{contrast}^{i \rightarrow v}$ ，也包括我们提出的两个基于 CLIP 文本特征的关系蒸馏损失函数，我们用 γ 控制蒸馏损失函数的权重：

$$\begin{aligned} L_{overall} &= L_{contrast} + \gamma L_{distill} \\ &= L_{contrast}^{v \rightarrow i} + L_{contrast}^{i \rightarrow v} + \gamma(L_{distill}^v + L_{distill}^i), \end{aligned} \quad (4.20)$$

4.5 实验与分析

4.5.1 实验设置

本章实验中，使用的 GPU 是 NVIDIA A100 GPU，采用的深度学习框架是 Pytorch 2.0。

训练 ReID 模型时,我们选用的优化器是 Adam 优化器,整体网络的学习率设置为 0.00035。对于输入的行人图像,我们统一缩放至高度 288 像素宽度 144 像素的大小,且进行随机裁剪,翻转和擦除等数据增强方法,同时我们采样 16 个伪标签下的 64 张行人图像组成一个训练批次。我们采用基于密度的聚类算法 DBSCAN 作为特征聚类算法来获得行人样本的伪标签。我们采用的投影层结构为:FC(2048 $\rightarrow$ 1024),ReLU,FC(1024 $\rightarrow$ 1024)。整个 ReID 模型共训练了 80 轮,其中第一阶段 50 轮,第二阶段 30 轮。

训练 CLIP 模型时,我们选用的是"CLIP-RN50"版本模型,即图像编码器采用的是 ResNet50 而非 ViT 类模型,这充分减少了训练开销。训练采用了 AdamW 优化器,为了保证 CLIP 经过任务特定的微调后能避免破坏模型原有的丰富泛化知识,我们整体网络采用较小的学习率即 $5e-6$,且每一个 batch 内采样 256 个伪标签下的 1024 张行人图像,其中图像分辨率和行人文本 tokens 长度均和原始 CLIP 保持一致,分别是 224×224 和 77。值得注意的是,我们的 CLIP 模型只微调 5 轮就取得了不错的效果,说明以较小的额外计算开销获得 CLIP 输出的文本特征表示作为红外和可见光模态的一致对齐目标,是可取的。

无监督跨模态行人重识别尽管在训练时是标签不可见的,但是在测试时的目标与有监督跨模态行人重识别不变,仍然是可见光搜红外图像和红外图像搜可见光图像。因此我们采用的评估指标仍然 mAP 和 Rank@K。我们在主流的跨模态数据集 SYSU-MM01 和 RegDB 进行了实验。

4.5.2 实验结果分析

1. 消融性实验分析

(1) 各模块有效性

本部分研究内容的消融实验如表4.1所示,我们先设计实验验证了在第一阶段引入文本语义增强的图文对比学习的效果,验证了视觉特征语义化的可行性。为了使 CLIP 提供的文本语义更符合 ReID 任务,我们进行了基于特征蒸馏方法的 CLIP 微调,通过提高文本特征的质量而进一步带来了性能提升。在第二阶段的匹配环节中,我们的消融实验首先验证了提出的跨模态匹配方法的有效性,说明外部知识注入能够改善仅依赖于 ReID 模型图像特征的匹配噪声。接着我们在第二阶段的训练环节,进一步验证了 CLIP 图文对齐知识进行关系蒸馏的有效性。

(2) 不同 CLIP 增量微调方法对一阶段模型性能影响

如表4.2中所示,我们在 SYSU 数据集上验证了不同的 CLIP 微调方法对一阶段模型性能的影响。该表格体现的是:在我们收集的可见光-红外图像-行人文本描述的图文数据集上经过不同微调方法训练得到的 CLIP,其输出的文本特征参与一阶段图文对比学习时的性能差异。可以看到即便是我们完全冻结 CLIP 权

表 4.1 所提模块的消融性结果

基线模型	DCL 对比学习	图文对比 学习	基于蒸馏的 CLIP 微调	跨模态 匹配	CLIP 对比 关系蒸馏	All Search		Indoor Search	
						R1	mAP	R1	mAP
ResNet50	✓					43.22	42.10	48.27	55.47
ResNet50	✓	✓				45.25	45.01	50.53	58.81
ResNet50	✓	✓	✓			47.88	46.12	53.17	61.35
ResNet50	✓		✓	✓		55.43	52.44	59.12	64.39
ResNet50	✓	✓	✓	✓		58.96	55.19	62.29	67.81
ResNet50	✓		✓	✓	✓	57.15	54.01	60.35	67.24
ResNet50	✓	✓	✓	✓	✓	59.62	56.15	62.78	68.68

表 4.2 不同 CLIP 增量微调方法对第一阶段模型的性能影响

微调方法	All Search		Indoor Search	
	R1	mAP	R1	mAP
一阶段基线模型	43.22	42.10	48.27	55.47
完全冻结	45.25	45.01	50.51	58.68
全量微调	43.96	42.80	49.13	56.21
CLIP-Adapter ^[99]	46.19	45.75	51.55	58.93
Prompt Tuning ^[100]	45.92	45.21	51.10	58.74
特征蒸馏	47.88	46.12	53.17	61.35

重不训练，也能对基线模型产生 2.91% 的 mAP 收益，验证了将红外图像特征和可见光图像特征进行语义增强的有效性。我们也尝试了全量微调 CLIP 但提升十分有效，仅有 0.7% 的 mAP 提升，这可能是因为：首先是收集的含 3 万对图文对的 CLIP 微调数据集体量，相对于包含 4 亿对图文对 CLIP 预训练数据集非常小，直接微调可能会完全浪费原 CLIP 中的泛化知识；同时我们的文本数据并非真实人工标注的而是由大模型推理生成的，其中包含的很大噪声会导致文本质量不够高，直接微调学习到的 ReID 任务特定知识也是欠佳的。然后我们也比较了两种参数高效的微调方法（Parameter-efficient Fine-tuning）的性能差异，我们发现 CLIP-Adapter^[99]和 Prompt Tuning^[100]方法均能带来超过冻结 CLIP 的性能提升，说明了只微调 CLIP 一部分参数而保留其中大部分泛化知识是有助于提升下游任务性能的。最后我们进行了基于残差结构的特征蒸馏微调实验，通过兼顾泛化性和任务特定性，这种微调方法达到了最优，在 All Search 和 In Search 两个实验设置上对基线模型的 mAP 提升分别达到了 4.02% 和 5.88%。

(3) 不同跨模态匹配和关系蒸馏方法对二阶段模型性能影响

如表4.3所示，我们比较了不同的跨模态匹配方法对二阶段模型性能影响。其中二阶段基线模型只采用 Rc-ID 模型输出红外模态和可见光模态的行人特征来计算跨模态相似度，并取两个跨模态类簇相似度最大值来当作一个跨模态匹配对，这种匹配关系将随后用于二阶段模型的跨模态表征学习。我们可以观察到当我们用 CLIP 输出的图像特征相似度来替换 ReID 特征相似度，能够对 All Search 设置带来 1.25% 的 mAP 性能提升。此外，当我们只考虑 CLIP 文本特征相似度时，

是对匹配准确性有损害的。而当我们把不同来源模型的特征进行集成，通过投票机制来选择跨模态匹配对时，这种基于混合原型特征相似度的匹配方法达到了最优性能，相对基线模型的匹配方法带来了 2.26% 的性能提升。

表 4.3 第二阶段模型采用不同跨模态匹配算法对性能的影响

匹配方法	All Search		Indoor Search	
	R1	mAP	R1	mAP
二阶段基线模型 (基于 ReID 图像特征相似度)	52.92	50.18	55.31	61.77
基于 CLIP 图像特征相似度	53.82	51.43	57.69	63.18
基于 CLIP 文本特征相似度	50.32	48.16	51.44	58.53
基于混合原型特征相似度	55.43	52.44	59.12	64.39

如表4.4所示，我们进一步比较了不同关系蒸馏方法对模型性能的影响。其中 batch 内和 memory 内的关系蒸馏存在两点差异：i) 范围不同，关系蒸馏损失函数作用的范围分别是训练批次 batch 内和记忆存储模块 memory bank 内；ii) 比较目标不同，以可见光样本为例，对于 memory 内的关系蒸馏其比较对象是存储在 memory 结构中的红外配对类簇，通过约束 $\langle \text{可见光样本}, \text{红外配对类簇} \rangle$ 这一对跨模态匹配元素与相同文本特征集合的相似度分布趋于一致，从而间接促进可见光和红外的对齐。而 batch 内的关系蒸馏则只能将 batch 内可见光样本的 ReID 特征与 CLIP 特征进行关系蒸馏，不涉及跨红外模态的操作，这是因为可见光模态和红外模态独立聚类导致标签集合没有交集，经过数据采样的一个 batch 内无法保证相互匹配的跨模态样本同时出现，因此借助 batch 无法完成跨模态交互。可以看到我们提出的 memory 内关系蒸馏对二阶段基线模型的 mAP 提升达到了 3.83%，验证了关系蒸馏方法将视觉语言模型知识迁移到 ReID 模型的有效性。

表 4.4 第二阶段模型采用不同关系蒸馏方法对性能的影响

蒸馏方法	All Search		Indoor Search	
	R1	mAP	R1	mAP
二阶段基线模型	52.92	50.18	55.31	61.77
batch 内关系蒸馏	54.88	53.26	58.49	65.22
memory 内关系蒸馏	57.15	54.01	60.35	67.24

(4) 超参数分析

如图4.7和4.8所示，我们分析了三个主要参数对模型性能的影响，分别是基于特征蒸馏的 CLIP 微调方法中的残差模块参数 β 、图文对比学习损失函数的权重 λ 和 CLIP 对比关系蒸馏损失函数的权重 γ 。

β 是 CLIP 微调方法中残差结构的 MLP 支路权重系数，控制了 MLP 支路在和特征流恒等映射进行相加时的权重大小（见公式4.1），由于 MLP 支路和恒等映射支路分别负责学习 ReID 特定任务的知识 and 原 CLIP 中的泛化知识，因此 β

越大表示对模型在特征蒸馏过程中学到的 ReID 特定任务知识越强,但也会因此阻碍一部分泛化知识的迁移学习。在图4.7反映的是经过不同 β 训练后的 CLIP 其输出的文本特征参与图文对比学习时的性能差异,我们发现 $\beta=0.2$ 时即达到了最好的效果,这说明原始的预训练 CLIP 多模态理解能力已经足够强大因此在微调时模型只需要学习到少量任务特定的参数就能达到不错的效果。 $\beta=0$ 时表示特征蒸馏过程中限制 VI-CLIP 模型 (学生模型) 与原 CLIP 模型 (教师模型) 在特征空间严格对齐,可以看到只学习原 CLIP 的泛化知识是不利于将其应用在我们下游的无监督跨模态行人重识别任务的。






图 4.7 CLIP 微调时的特征蒸馏残差支路系数 β

λ 作为损失函数权重控制了一阶段 ReID 模型训练时图文对比学习损失函数对总体损失函数的贡献 (见公式4.12), 当 λ 越大表示训练 batch 内图像样本与文本特征记忆存储库的对齐力度越强。我们在图4.8(a)中可以观察到, $\lambda=0$ 表示模



(a) 图文对比学习损失函数权重 λ



(b) 关系蒸馏损失函数权重 γ

图 4.8 损失函数权重 λ 和 γ 分析

型没有图文对比学习损失函数参与训练,即退化成一阶段基线模型,而 $\lambda=0.4$ 时对一阶段 ReID 模型的增益最大,此时 mAP 准确率超出了基线模型 4.02% 的绝对值大小。由于一阶段模型图像样本与图像特征记忆存储模块中的对比学习损失函数 $L_{contrast}^v$ 和 $L_{contrast}^i$ 权重默认为 1,当图文对比学习损失函数权重与之相同贡献即 $\lambda=1$ 时,图像特征语义化的学习目标就会损害原本的红外模态和可见光模态内的无监督表征学习,因此在图4.8(a)中我们观察到 $\lambda=1$ 时性能甚至低于基线模型。基于上述实验我们可以得出结论:引入文本特征作为语义辅助信息是能够增强红外-可见光跨模态表征学习的,但损失函数权重过大时让其占据模型训练的主导地位是会损害模型性能的。

γ 控制了二阶段模型训练时基于 CLIP 的关系蒸馏损失函数权重(见公式4.20),相较于图文对比损失函数只是独立增强模态内视觉特征语义的思想,我们提出的关系蒸馏损失函数则是通过与跨模态文本特征原型的对齐来辅助增强红外-可见光模态的对齐,因此二者均扮演辅助角色,在训练时权重 λ 同样不宜过大。在图4.8(b)中可以观察到,当 $\gamma=0.6$ 时,关系蒸馏方法对二阶段的模型增益最大,相较于二阶段基线模型的 mAP 准确率达到 3.83% 的提升收益。

(5) 可视化实验

本节设计了可视化实验来比较不同模型的效果,从而进一步验证本文方法的有效性,如图4.9所示。首先,我们选取了模型训练完毕输出的随机 10 个行人身份的特征,通过 t-SNE 图比较不同模型学习到的行人特征的空间分布。这 10 个行人都包含可见光模态和红外模态的两种图像,我们的期望是,同一身份行人不论是何种模态都能在特征空间尽可能相近,而不同身份行人的图像在特征空间尽可能分散。如图4.9所示,形状为圆表示可见光图像,菱形表示红外图像,10 种不同颜色表示 10 个不同身份的行人,我们分别比较了“初始化模型”、“基线模型”、“基线模型 + 文本语义增强”以及“基线模型 + 文本语义增强 + 对比关系蒸馏”这四个模型的 t-SNE 特征散点图分布。

我们可以看到图4.9(a)中初始模型输出的 10 个身份行人特征难以辨别,只有极少数相同身份下的行人样本在特征空间是接近的,例如深红色身份下的行人样本其红外模态图像(红色圆形)是聚集在一起的,然而距离其可见光模态图像(红色菱形)在特征空间相隔较远,这说明初始模型几乎不具备跨模态识别能力。图4.9(b)反映的是基线模型输出的特征分布,基线模型由于在一阶段和二阶段分别进行了模态内表征学习和跨模态表征学习,因此相同颜色身份行人的不同模态数据在特征空间被拉近(例如紫色和土黄色等),红外模态和可见光模态之间的鸿沟在一定程度上得以弥补,然而部分身份行人仍然存在较大的跨模态差异,例如大圆圈包围的三组身份行人(蓝色,青色,靛色),这三个行人身份下的两种模态数据之间的特征差异通过连接两个圆圈之间的线段长度来反映,因




图 4.9 t-SNE 特征分布可视化

此我们可以观察到尽管基线模型一定程度上具备了跨模态识别能力但仍然表现不够优异。图4.9(c)反映了我们在基线模型基础上给第一阶段提出的文本语义增强方法，该方法将红外模态和可见光模态分别与模态内的文本原型特征对齐从而实现视觉特征语义化，由于相同身份下两模态的行人文本描述其语义属性具有一致性，因此在特征空间相当于间接促进了两种语义化的视觉特征彼此拉近，我们可以看到青色和靛色身份的各自跨模态特征鸿沟的进一步缩小。图4.9(d)反映了进一步增加了对比关系蒸馏的效果，关系蒸馏直接找到具有匹配关系的可见光样本和红外类簇，分别计算他们与相同文本特征向量的两个相似度分布，并促进这种语义分布趋于一致，从而实现跨模态的对齐，因此可以看到关系蒸馏方法使得蓝色、青色和靛色身份的行人其跨模态图像在特征空间的有更好的类内紧凑性。

2. 与主流方法的对比

我们比较了我们提出的无监督跨模态行人重识别方案与当前主流方法的对比实验，相应结果如表4.5和4.6所示，表格中粗体字表示该方法在当前数据集上

表 4.5 与主流无监督跨模态方法在 SYSU 数据集上的对比实验

方法	来源	All Search					Indoor Search				
		R1	R10	R20	mAP	mINP	R1	R10	R20	mAP	mINP
H2H ^[46]	TIP'2021	30.15	65.92	77.32	29.40	-	-	-	-	-	-
OTLA ^[49]	ECCV'2022	29.98	71.79	83.85	27.13	-	29.80	-	-	31.8	-
ADCA ^[47]	MM'2022	45.51	85.29	93.16	42.73	28.29	50.60	89.66	96.15	59.11	55.17
PGM ^[48]	CVPR'2023	57.27	92.48	97.23	51.78	34.96	56.23	90.19	95.39	62.74	58.13
Ours	-	59.62	<u>91.86</u>	<u>96.82</u>	56.15	41.33	62.78	96.98	97.70	68.68	64.52

表 4.6 与主流无监督跨模态方法在 RegDB 数据集上的对比实验

方法	来源	Visible to Thermal		Thermal to Visible	
		R1	mAP	R1	mAP
H2H ^[46]	TIP'2021	23.81	13.87	-	-
OTLA ^[49]	ECCV'2022	32.90	29.70	32.10	28.60
ADCA ^[47]	MM'2022	67.20	64.05	68.48	68.81
PGM ^[48]	CVPR'2023	69.48	65.41	69.85	65.17
Ours	-	71.53	68.71	72.49	67.71

性能最优，下划线表示表示该方法上性能达到次优。我们设计的基于视觉语言模型知识蒸馏的方法和当前的主流方法对比，在 SYSU 和 RegDB 两个无监督跨模态数据集上的表现取得了很好的性能优势，这验证了我们引入文本语义方法的有效性，通过分别在一阶段进行文本语义增强的对比学习以及在二阶段进行对比关系的知识蒸馏，更好地促进了红外模态和可见光模态的相互对齐，从而实现了更好的跨模态识别性能。

4.6 本章小结

本章着眼于当前基于特征相似度匹配的无监督跨模态行人重识别方法存在的两个主要问题，即过度依赖于图像特征进行相似度计算来挖掘红外-可见光跨模态匹配对，以及忽视了利用不同行人图像的语义共性和差异来辅助两种图像模态的对齐。针对第一个问题，本章节提出基于混合原型特征的匹配方法来缓解跨模态匹配时的噪声问题从而提高匹配质量。针对第二个问题，本章节提出利用大语言模型 LLM 来生产包含行人丰富语义信息的文本描述，并在第一阶段进行文本语义增强的红外-可见光模态内表征学习，在第二阶段进行基于 CLIP 对比关系蒸馏的红外-可见光跨模态表征学习，充分借助行人文本语义促进两种图像模态的对齐。在实验阶段我们在公开数据集上进行了大量实验，包括各模块的消融实验和与前沿方法的比较实验，最后我们通过 t-SNE 可视化验证了提出的文本语义增强和对比关系蒸馏方法的有效性。

第5章 总结与展望

5.1 本文总结

随着人工智能技术的飞速发展,行人重识别技术因其在智能安防和视频分析等方面的应用前景而受到了广泛关注。现有的行人重识别方法大多是标记数据驱动的有监督方法,而身份标注过程耗费的高昂成本阻碍了行人重识别方法的实际应用,在这种背景下,无监督行人重识别方法成为了该领域的研究热点,本文主要面向无监督单模态和无监督跨模态的行人重识别展开了研究。

本文研究发现,当前方法仍然存在一些缺陷。一方面,当前的无监督单模态行人重识别方法忽略了样本训练顺序和模型对不同噪声程度伪标签的容错能力。此外这些方法采用的噪声标签建模方案过于单一导致可能会疏漏部分噪声标签,且对行人局部特征的忽视导致模型的识别性能受限。另一方面,当前的无监督跨模态行人重识别方法不论是建立跨模态配对关系还是进行跨模态表征学习,都受限于图像特征层面,不但忽视了噪声标签对图像特征辨别性的影响,也忽视了如何借助行人身份的语义信息来缩小两种图像模态间的鸿沟。本文针对无监督单模态和跨模态行人重识别,主要工作如下:

(1) 针对无监督单模态行人重识别:本文提出基于双重不确定性引导的课程学习方法,利用类簇内样本间的特征亲和力度来估计样本标签的可靠度,然后让模型遵循课程学习范式进行训练。此外,本文针对样本标签提出了两种不确定性建模方式,并转化为样本权重来减少高不确定性样本对损失函数的贡献。以上两种方法保证了模型能够充分抑制不同程度噪声标签而选择性地从行人样本中学习置信的知识。同时,本文从兼顾行人的全局特征和局部细节出发,设计了一种局部细粒度语义感知的全局特征改善方法,进一步提高了模型的识别能力。

(2) 针对无监督跨模态行人重识别:本文提出了基于视觉语言模型的知识蒸馏方法。本文首先使用多模态大模型来生成可见光图像和红外图像对应的文本描述数据,然后引入图文预训练模型 CLIP 并在收集的图文对数据集上进行基于特征蒸馏方法的微调,使其适配到行人重识别这种细粒度检索任务。一方面,我们将 CLIP 模型输出的语义信息更丰富的特征作为外部知识,与原始的 ReID 模型的视觉特征一起作为混合原型分类器,建立更准确的跨模态联系以缓解匹配噪声问题。另一方面,我们利用 CLIP 中的图文对齐知识,分别进行文本语义增强的模态内表征学习,以及基于关系蒸馏的跨模态表征学习,充分利用文本语义信息来辅助两种图像模态的对齐。

5.2 研究展望

无监督行人重识别对于维护公共安全的重要性不言而喻,随着新时代我们面临更多复杂严峻的安防挑战,未来无监督行人重识别研究如何结合更前沿的深度学习技术,仍然是一个值得进一步深入探索的问题,本文设计的无监督单模态和跨模态行人重识别方法也还有值得继续研究的地方:

(1) **提高基础模型的识别能力:** 当今行人重识别研究绝大多数仅专注于 ResNet50 以及相关变体模型,这些模型具有小而精的高性价比特点。然而对于行人身体被遮挡或图像不够清晰等复杂场景,这类小模型对局部细节的关注能力以及对不同区域之间联系的建模能力也许就会稍逊一筹,这不利好十分依赖特征辨别性的行人重识别方法。本文研究从一定程度上探索了局部特征对聚类噪声和表征学习的积极作用,但基础模型的识别能力才是决定无监督识别方法性能上限的一个重要因素。如何将 Vision Transformer 及衍生的一系列视觉基础模型直接应用到本领域研究,或者通过知识蒸馏等方式来赋予小模型更好的识别能力,以推进无监督行人重识别研究,应该是未来一个值得探索的方向。

(2) **面向更复杂的无监督全天候场景:** 当前的无监督跨模态行人重识别方法探索了白天可见光和夜间换衣两种场景的行人检索问题,对于实际刑侦场景具有十分宝贵的现实价值。然而当我们将检索时间跨度从一天延伸到若干天,这种长时追踪条件下存在行人可能主动更换衣服的复杂情形,对模型算法和技术人员都是一个不小的挑战。如何利用海量无身份标注的监控数据,训练一个能够同时应对白天可见光和夜间红外跨模态检索场景,以及长时追踪行人主动更换衣服这种换衣检索场景的全天候无监督行人重识别模型,对于提高侦查效率以及维护公共安全有着更重大的意义。

(2) **处理图像文本的统一多模态模型:** 基于文本的行人重识别是一类仅依赖于输入文本描述来搜索目标行人的方法研究,可以解决当目标行人相关的图像数量稀少甚至遗失时的检索难题,因此基于图像或文本的行人重识别两个任务是互补的。然而当前很少有研究能将图像和文本纳入到一个能够统一处理多模态数据的行人重识别模型中,本研究探索了如何利用行人文本这一模态来更好地引导可见光图像和红外图像的对齐,但文本模态在本研究中是起着辅助增强的作用。未来的行人重识别模型应该具备处理多模态数据以及对齐多模态特征的能力,以便于满足实际刑侦场景中整合多来源多形式检索证据的迫切需求。

参考文献

- [1] YE M, SHEN J, LIN G, et al. Deep learning for person re-identification: A survey and outlook [J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(6): 2872-2893.
- [2] CHENG D S, CRISTANI M, STOPPA M, et al. Custom pictorial structures for re-identification.[C]//Bmvc: Vol. 1. Citeseer, 2011: 6.
- [3] BAZZANI L, CRISTANI M, PERINA A, et al. Multiple-shot person re-identification by chromatic and epitomic analyses[J]. Pattern Recognition Letters, 2012, 33(7): 898-903.
- [4] GHEISSARI N, SEBASTIAN T B, HARTLEY R. Person reidentification using spatiotemporal appearance[C]//2006 IEEE computer society conference on computer vision and pattern recognition (CVPR'06): Vol. 2. IEEE, 2006: 1528-1535.
- [5] YI D, LEI Z, LIAO S, et al. Deep metric learning for person re-identification[C]//2014 22nd international conference on pattern recognition. IEEE, 2014: 34-39.
- [6] LI W, ZHAO R, XIAO T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 152-159.
- [7] GU J, WANG Z, KUEN J, et al. Recent advances in convolutional neural networks[J]. Pattern recognition, 2018, 77: 354-377.
- [8] ZHENG L, YANG Y, HAUPTMANN A G. Person re-identification: Past, present and future [A]. 2016. arXiv: 1610.02984.
- [9] ZHENG L, ZHANG H, SUN S, et al. Person re-identification in the wild[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1367-1376.
- [10] TIAN M, YI S, LI H, et al. Eliminating background-bias for robust person re-identification [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 5794-5803.
- [11] VARIOR R R, SHUAI B, LU J, et al. A siamese long short-term memory architecture for human re-identification[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part VII 14. Springer, 2016: 135-153.
- [12] DENG W, ZHENG L, YE Q, et al. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 994-1003.
- [13] WU L, WANG Y, GAO J, et al. Where-and-when to look: Deep siamese attention networks for video-based person re-identification[J]. IEEE Transactions on Multimedia, 2018, 21(6):

1412-1424.

- [14] ZHENG Z, ZHENG L, YANG Y. A discriminatively learned cnn embedding for person reidentification[J]. ACM transactions on multimedia computing, communications, and applications (TOMM), 2017, 14(1): 1-20.
- [15] CHENG D, GONG Y, ZHOU S, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1335-1344.
- [16] HERMANS A, BEYER L, LEIBE B. In defense of the triplet loss for person re-identification [A]. 2017. arXiv: 1703.07737.
- [17] RISTANI E, SOLERA F, ZOU R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]//European conference on computer vision. Springer, 2016: 17-35.
- [18] VARIOR R R, HALOI M, WANG G. Gated siamese convolutional neural network architecture for human re-identification[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14. Springer, 2016: 791-808.
- [19] CHEN W, CHEN X, ZHANG J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 403-412.
- [20] SUN Y, ZHENG L, YANG Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 480-496.
- [21] SUN X, ZHENG L. Dissecting person re-identification from the viewpoint of viewpoint[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 608-617.
- [22] ZHONG Z, ZHENG L, LUO Z, et al. Invariance matters: Exemplar memory for domain adaptive person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 598-607.
- [23] SONG J, YANG Y, SONG Y Z, et al. Generalizable person re-identification by domain-invariant mapping network[C]//Proceedings of the IEEE/CVF conference on Computer Vision and Pattern Recognition. 2019: 719-728.
- [24] SU C, LI J, ZHANG S, et al. Pose-driven deep convolutional model for person re-identification[C]//Proceedings of the IEEE international conference on computer vision. 2017: 3960-3969.
- [25] SUH Y, WANG J, TANG S, et al. Part-aligned bilinear representations for person re-identification[C]//Proceedings of the European conference on computer vision (ECCV).

- 2018: 402-419.
- [26] YE M, WANG Z, LAN X, et al. Visible thermal person re-identification via dual-constrained top-ranking.[C]//IJCAI: Vol. 1. 2018: 2.
- [27] WANG G, ZHANG T, CHENG J, et al. Rgb-infrared cross-modality person re-identification via joint pixel and feature alignment[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 3623-3632.
- [28] WANG Z, WANG Z, ZHENG Y, et al. Learning to reduce dual-level discrepancy for infrared-visible person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 618-626.
- [29] ZHAO Z, LIU B, CHU Q, et al. Joint color-irrelevant consistency learning and identity-aware modality adaptation for visible-infrared cross modality person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 3520-3528.
- [30] FANG X, YANG Y, FU Y. Visible-infrared person re-identification via semantic alignment and affinity inference[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 11270-11279.
- [31] YU H, CHENG X, PENG W, et al. Modality unifying network for visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 11185-11195.
- [32] WU J, LIU H, SU Y, et al. Learning concordant attention via target-aware alignment for visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 11122-11131.
- [33] YE M, LI J, MA A J, et al. Dynamic graph co-matching for unsupervised video-based person re-identification[J]. IEEE Transactions on Image Processing, 2019, 28(6): 2976-2990.
- [34] WANG X, PANDA R, LIU M, et al. Exploiting global camera network constraints for unsupervised video person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 31(10): 4020-4030.
- [35] FAN H, ZHENG L, YAN C, et al. Unsupervised person re-identification: Clustering and fine-tuning[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2018, 14(4): 1-18.
- [36] ZENG K, NING M, WANG Y, et al. Hierarchical clustering with hard-batch triplet loss for person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 13657-13665.
- [37] WU J, YANG Y, LIU H, et al. Unsupervised graph association for person re-identification [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 8321-8330.

- [38] YU H X, ZHENG W S, WU A, et al. Unsupervised person re-identification by soft multi-label learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2148-2157.
- [39] YANG F, ZHONG Z, LUO Z, et al. Joint noise-tolerant learning and meta camera shift adaptation for unsupervised person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 4855-4864.
- [40] LI Z, SHI Y, LING H, et al. Reliability exploration with self-ensemble learning for domain adaptive person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 36. 2022: 1527-1535.
- [41] ZOU C, CHEN Z, CUI Z, et al. Discrepant and multi-instance proxies for unsupervised person re-identification[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 11058-11068.
- [42] CHENG D, ZHOU J, WANG N, et al. Hybrid dynamic contrast and probability distillation for unsupervised person re-id[J]. IEEE Transactions on Image Processing, 2022, 31: 3334-3346.
- [43] YANG F, LI K, ZHONG Z, et al. Asymmetric co-teaching for unsupervised cross-domain person re-identification[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 34. 2020: 12597-12604.
- [44] ZHENG K, LAN C, ZENG W, et al. Exploiting sample uncertainty for domain adaptive person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 3538-3546.
- [45] ZHANG X, GE Y, QIAO Y, et al. Refining pseudo labels with clustering consensus over generations for unsupervised object re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 3436-3445.
- [46] LIANG W, WANG G, LAI J, et al. Homogeneous-to-heterogeneous: Unsupervised learning for rgb-infrared person re-identification[J]. IEEE Transactions on Image Processing, 2021, 30: 6392-6407.
- [47] YANG B, YE M, CHEN J, et al. Augmented dual-contrastive aggregation learning for unsupervised visible-infrared person re-identification[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 2843-2851.
- [48] WU Z, YE M. Unsupervised visible-infrared person re-identification via progressive graph matching and alternate learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 9548-9558.
- [49] WANG J, ZHANG Z, CHEN M, et al. Optimal transport for label-efficient visible-infrared person re-identification[C]//European Conference on Computer Vision. Springer, 2022: 93-109.

- [50] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[C/OL]//Vol. 86. 1998: 2278-2324. DOI: 10.1109/5.726791.
- [51] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [52] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[A]. 2014. arXiv: 1409.1556.
- [53] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [54] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [55] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [56] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [57] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[A]. 2020. arXiv: 2010.11929.
- [58] OQUAB M, DARCET T, MOUTAKANNI T, et al. Dinov2: Learning robust visual features without supervision[A]. 2023. arXiv: 2304.07193.
- [59] CARON M, TOUVRON H, MISRA I, et al. Emerging properties in self-supervised vision transformers[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 9650-9660.
- [60] XIE Z, LIN Y, YAO Z, et al. Self-supervised learning with swin transformers[A]. 2021. arXiv: 2105.04553.
- [61] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.
- [62] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [63] LIN Y, DONG X, ZHENG L, et al. A bottom-up clustering approach to unsupervised person re-identification[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 33. 2019: 8738-8745.
- [64] MACQUEEN J, et al. Some methods for classification and analysis of multivariate observa-

- tions[C]//Proceedings of the fifth Berkeley symposium on mathematical statistics and probability: Vol. 1. Oakland, CA, USA, 1967: 281-297.
- [65] ESTER M, KRIEGEL H P, SANDER J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//kdd: Vol. 96. 1996: 226-231.
- [66] GE Y, ZHU F, CHEN D, et al. Self-paced contrastive learning with hybrid memory for domain adaptive object re-id[J]. Advances in Neural Information Processing Systems, 2020, 33: 11309-11321.
- [67] GE Y, CHEN D, LI H. Mutual mean-teaching: Pseudo label refinery for unsupervised domain adaptation on person re-identification[A]. 2020.
- [68] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[J]. Advances in neural information processing systems, 2017, 30.
- [69] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9729-9738.
- [70] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. PMLR, 2020: 1597-1607.
- [71] GRILL J B, STRUB F, ALTCHÉ F, et al. Bootstrap your own latent-a new approach to self-supervised learning[J]. Advances in neural information processing systems, 2020, 33: 21271-21284.
- [72] CHENG D, HUANG X, WANG N, et al. Unsupervised visible-infrared person reid by collaborative learning with neighbor-guided label refinement[C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 7085-7093.
- [73] ZHENG L, SHEN L, TIAN L, et al. Scalable person re-identification: A benchmark[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1116-1124.
- [74] WEI L, ZHANG S, GAO W, et al. Person transfer gan to bridge domain gap for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 79-88.
- [75] WU A, ZHENG W S, GONG S, et al. Rgb-ir person re-identification by cross-modality similarity preservation[J]. International journal of computer vision, 2020, 128: 1765-1785.
- [76] NGUYEN D T, HONG H G, KIM K W, et al. Person recognition system based on a combination of body images from visible light and thermal cameras[J]. Sensors, 2017, 17(3): 605.
- [77] BENGIO Y, LOURADO J, COLLOBERT R, et al. Curriculum learning[C]//Proceedings

- of the 26th annual international conference on machine learning. ICML, 2009: 41-48.
- [78] GAL Y, GHAHRAMANI Z. Dropout as a bayesian approximation: Representing model uncertainty in deep learning[C]//international conference on machine learning. PMLR, 2016: 1050-1059.
- [79] HINTON G E, ROWEIS S. Stochastic neighbor embedding[J]. Advances in neural information processing systems, 2002, 15: 11323-11336.
- [80] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 618-626.
- [81] ZHAO F, LIAO S, XIE G S, et al. Unsupervised domain adaptation with noise resistible mutual-training for person re-identification[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16. Springer, 2020: 526-544.
- [82] ZHAI Y, YE Q, LU S, et al. Multiple expert brainstorming for domain adaptive person re-identification[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part VII 16. Springer, 2020: 594-611.
- [83] DAI Y, LIU J, BAI Y, et al. Dual-refinement: Joint label and feature refinement for unsupervised domain adaptive person re-identification[J]. IEEE Transactions on Image Processing, 2021, 30: 7815-7829.
- [84] ZHENG K, LIU W, HE L, et al. Group-aware label transfer for domain adaptive person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 5310-5319.
- [85] HAN J, LI Y L, WANG S. Delving into probabilistic uncertainty for unsupervised domain adaptive person re-identification[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 36. 2022: 790-798.
- [86] DAI Y, LIU J, SUN Y, et al. Idm: An intermediate domain module for domain adaptive person re-id[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 11864-11874.
- [87] WU Y, HUANG T, YAO H, et al. Multi-centroid representation network for domain adaptive person re-id[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 36. 2022: 790-798.
- [88] ZHANG R, HAN J, ZHOU A, et al. Llama-adapter: Efficient fine-tuning of language models with zero-init attention[A]. 2023. arXiv: 2303.16199.
- [89] LI J, LI D, SAVARESE S, et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models[C]//International conference on machine

- learning. PMLR, 2023: 19730-19742.
- [90] LIU H, LI C, WU Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2024, 36.
- [91] DAI W, LI J, LI D, et al. Instructblip: Towards general-purpose vision-language models with instruction tuning[A]. 2023. arXiv: 2305.06500.
- [92] PAN J, LIN Z, ZHU X, et al. St-adapter: Parameter-efficient image-to-video transfer learning [C]//Vol. 35. 2022: 26462-26477.
- [93] HUANG X, ZHOU H, YAO K, et al. Froster: Frozen clip is a strong teacher for open-vocabulary action recognition[C]//2024.
- [94] WANG M, XING J, LIU Y. Actionclip: A new paradigm for video action recognition[C]//2021.
- [95] DAI Y, LI X, LIU J, et al. Generalizable person re-identification with relevance-aware mixture of experts[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 16145-16154.
- [96] MANSOURIAN A M, JALALI A, AHMADI R, et al. Attention-guided feature distillation for semantic segmentation[A]. 2024. arXiv: 2403.05451.
- [97] LI J, AZIZOV D, YANG L, et al. Contrastive continual learning with importance sampling and prototype-instance relation distillation[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 38. 2024: 13554-13562.
- [98] WANG L, YOON K J. Knowledge distillation and student-teacher learning for visual intelligence: A review and new outlooks[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(6): 3048-3068.
- [99] GAO P, GENG S, ZHANG R, et al. Clip-adapter: Better vision-language models with feature adapters[J]. International Journal of Computer Vision, 2024, 132(2): 581-595.
- [100] ZHOU K, YANG J, LOY C C, et al. Learning to prompt for vision-language models[J]. International Journal of Computer Vision, 2022, 130(9): 2337-2348.