

中图分类号: TP391
学科分类号: 520.6040

论文编号: 193131336
密 级:

天津理工大学研究生学位论文

基于多尺度特征和深度多分支网络 的行人重识别研究

(申请硕士学位)

专业学位类别: 工程硕士

专业(领域): 计算机技术

研究方向: 行人重识别

作者姓名: 李铭浩

校内指导教师: 温显斌 教授

企业指导教师: 李胜利 高工

2022 年 2 月

**Thesis Submitted to Tianjin University of Technology
for the Master's Degree**

**Research on person
re-identification based on
multi-scale features and deep
multi-branch network**

By
Minghao Li

Supervisor
Xianbin Wen

Feb.2022

摘要

随着深度学习技术的快速突破以及人们对智能安防技术的迫切需求，行人重识别的研究工作获得了显著的发展。但在实际的拍摄场景中，因为姿势、角度、照明条件等改变，以及行人背景信息的冗杂和遮挡等问题的出现，限制了行人重识别技术的进一步突破，仍需开展深入的研究。目前，构造新型的深度学习模型，以提取出高鲁棒性和高鉴别力的行人特征表示，仍是解决各类行人重识别问题的关键研究方向。

本文将通过多尺度特征学习、多粒度学习等方法，通过提出全新的网络模型和对特征提取分支进行调整，来获得更为全面、更具有判别能力的特性，从而提升行人重识别的准确度和鲁棒性。本文的重要工作和创新成果包括：

（1）提出了基于多特征融合的多尺度注意力网络用于行人重识别任务。该方法引入了卷积注意力模块，使得网络更加聚焦在有利于识别的关键特征上，增强了网络的学习能力。其次，将通道注意力模块与池化融合策略（GAP+GMP）有机融合来得到高判别力与鲁棒性的特征描述，进而提升了行人重识别的精度。

（2）提出了基于多尺度特征学习的双流行人重识别网络。与上面提到的工作有所不同，本方法考虑的是如何提取更广泛的多尺度特征来强化特征表示。在该方法中，多尺度特征的学习结构建立在双流网络上，大大拓宽了特征的采样范围，并实现了对不同粒度的全局特征与局部特征的有效融合，从而使网络获取到更具有辨识性能的特征，提高了行人重识别的准确度。

第一种算法偏向于使用注意力机制来关注不同尺度上的行人关键特征，第二种算法则侧重于利用双流多分支结构扩大特征的采样范围。

关键词：行人重识别，深度学习，多尺度特征学习，双流网络

Abstract

With the rapid breakthrough of deep learning technology and people's urgent demand for intelligent security technology, the research work of person re-identification has achieved remarkable development. However, in the actual shooting scene, because of the change of posture, angle, lighting conditions, and the emergence of the redundant of pedestrian background information and occlusion problem, further breakthroughs in person re-identification technology are restricted, and further research is still needed. At present, the construction of new deep learning models to extract high robustness and high discrimination pedestrian feature representation is still a key research direction to solve various person re-identification problems.

In this paper, through multi-scale feature learning, multi-granularity learning and other methods, new network model is proposed and the feature extraction branch is adjusted to obtain more comprehensive and discriminant features, so as to improve the accuracy and robustness of person re-identification. The important work and innovation achievements of this paper include:

(1) A multi-scale attention network based on multi-feature fusion is proposed for person re-identification task. The convolutional attention module is introduced in this method, which makes the network focus more on the key features conducive to re-identification and increases the learning ability of the network. Secondly, the channel attention module is organically integrated with the pooling fusion strategy (GAP+GMP) to obtain the feature description with high discrimination and robustness, thus improving the accuracy of person re-identification.

(2) A two-stream person re-identification network based on multi-scale feature learning is proposed. Different from the work mentioned above, this method considers how to extract a wider range of multi-scale features to enhance feature representation. In this method, the learning structure of multi-scale feature learning is built on the structure of the two-stream network, which greatly expands the sampling range of features, and realizes the effective fusion of global features and local features with different granularity, so that the network can obtain more discernible features and improve the accuracy of person re-identification.

The first algorithm tends to use attention mechanism to focus on key pedestrian features at different scales, while the second algorithm focuses on using two-stream

multi-branch structure to expand the sampling range of multi-scale features.

Key words: Person re-identification, Deep learning, Multi-scale feature learning, Two-stream network

目 录

第一章 绪论	- 1 -
1.1 研究背景及意义	- 1 -
1.2 国内外研究现状	- 2 -
1.2.1 特征表达	- 2 -
1.2.2 度量学习	- 4 -
1.3 本文研究内容	- 5 -
1.4 论文组织结构	- 6 -
第二章 基于深度学习的行人重识别相关理论概述	- 8 -
2.1 卷积神经网络	- 8 -
2.1.1 卷积神经网络概述	- 8 -
2.1.2 卷积神经网络的结构	- 9 -
2.1.3 深度残差网络	- 11 -
2.1.4 激活函数	- 13 -
2.2 标准数据集	- 14 -
2.2.1 Market-1501 数据集	- 14 -
2.2.2 DukeMTMC-reID 数据集	- 15 -
2.2.3 CUHK03 数据集	- 15 -
2.3 评价指标	- 16 -
2.3.1 累积匹配曲线	- 16 -
2.3.2 平均均值精度	- 16 -
2.4 本章小结	- 17 -
第三章 基于多特征融合的多尺度注意力行人重识别网络	- 18 -
3.1 引言	- 18 -
3.2 基于多特征融合的多尺度注意力网络模型	- 20 -
3.2.1 整体架构设计	- 20 -
3.2.2 特征后处理模块	- 21 -
3.2.3 损失函数	- 24 -
3.3 实验结果及分析	- 25 -
3.3.1 实验设置	- 25 -

3.3.2 与 SOTA 方法比较.....	- 26 -
3.3.3 消融实验.....	- 28 -
3.4 本章小结.....	- 30 -
第四章 基于多尺度特征学习的双流行人重识别网络.....	- 31 -
4.1 引言.....	- 31 -
4.2 基于多尺度特征学习的双流网络模型.....	- 32 -
4.2.1 多尺度特征学习结构.....	- 32 -
4.2.2 整体结构设计.....	- 33 -
4.2.3 损失函数.....	- 35 -
4.3 实验结果及分析.....	- 37 -
4.3.1 实验设置.....	- 37 -
4.3.2 与 SOTA 方法比较.....	- 38 -
4.3.3 消融实验.....	- 40 -
4.3.4 在 CUHK03 上与 MSAN 网络的对比实验.....	- 43 -
4.4 本章小结.....	- 44 -
第五章 总结与展望.....	- 45 -
5.1 工作总结.....	- 45 -
5.2 工作展望.....	- 45 -
参考文献.....	- 47 -
在学期间取得的科研成果和科研情况说明.....	- 51 -
致 谢.....	- 52 -

第一章 绪论

1.1 研究背景及意义

近年来,随着智慧城市的建设和互联网的不断发展,音频、文字、视频等信息日益增多。面对这样的海量数据,如何更好地利用这些信息辅助人类的生产与生活是一个亟待解决的问题。传统人工处理信息的方式成本高昂且效率低下,借助计算机智能来帮助人类处理和分析这些海量信息是大势所趋。计算机视觉是计算机智能的一个关键方面,旨在模拟人类视觉来更高效更智能地分类与管理大量的数据,通过计算机视觉技术自动分析各类图形和视频数据,已经成为了一项有效的方法。

行人重识别(Person re-identification, ReID)是计算机视觉领域的一个重点课题,其目标是确定感兴趣的行人是否出现在非重叠视域的其他摄像头之下^[1]。行人重识别技术主要利用行人全身的身体特征来实现对行人身份的识别,能够成为人脸识别在无效情况下的一个补充技术来提高整体的识别率,同时由于行人重识别技术能够实现跨镜头之间的持续追踪,所以这样能够极大的增强数据的时空连续性。行人重识别可以在智能安防、人机交互、商场导购等领域发挥很大的应用价值。例如,在智能安防领域,通过行人重识别技术可以自动对海量视频监控信息进行有效分析,从而发现可疑犯罪对象,协助公安机关破案,对打击违法犯罪,维护社会治安有重要意义。在智能商业领域,行人重识别技术可对商场顾客的轨迹进行分析,记录行人的路径信息和在不同货架前的停留时间,进而判断出顾客的兴趣所在,为商场工作人员提供决策支持,提高商场经营收入。研究行人重识别技术有着重大的理论意义和实用性。随着该领域相关技术的不断突破,行人重识别整体的水平已经到达了新的阶段。然而,行人重识别任务受到实际拍摄场景各种问题的影响,这些问题大致分为内在原因和外在影响。内在原因指行人本身的主观能动性造成的行人姿态变化和穿戴变化,会产生外观差异性等问题。外在影响是指因拍摄的客观条件变化而出现的各种问题,如行人被遮挡、光照条件差、图像不清晰或非完整拍摄等问题。面对这些问题,需要引入新方法设计出性能更加优异的算法,以便于加快落地,造福社会。

近年来,由于深度学习技术的成熟运用,更多的学者们开始运用深度学习方法对行人重识领域进行新的探索,通过提供基于某种目的的新方法来提高模

型的泛化性能。无论如何，提取更加鲁棒的高辨识度行人特征依旧是研究者的努力方向。

1.2 国内外研究现状

由于深度学习技术的迅速发展，学者们也开始将深度学习技术引入到行人重识别的各种算法当中。相对于传统方法中复杂繁琐的特征设计，采用深度学习方法的模型经过大量数据样本的迭代训练，可以自适应地获取判别能力较强的行人特性，能够更好地反映出数据集的特点。本文重点研究的是基于图像的有监督行人重识别。

图 1.2 展现的是基于深度学习的行人重识别过程，先指定一个待检索的图像 Probe，在第一步 Probe 会进入到用作特征提取的神经网络中，接着再进行特征嵌入，使得特征张量转换为特征向量，特征向量将用于预测行人身份。在模型训练结束后，将 Probe 与 Gallery 中图像的特征进行相似度匹配并得出排序结果。




图 1.2 基于深度学习的行人重识别流程图

使用深度学习技术的行人重识别方法通常分为两类：第一类是以特征表达（Feature Representation）为基准的方法，另一类则是以度量学习（Metric Learning）为基准的行人重识别方法。下面，将对特征表达法和度量学习法分别加以说明。

1.2.1 特征表达

在深度学习技术应用到行人重识别任务后，早期在方法层面基本上都是基于全局特征而设计的算法。全局特征能表示一整幅图像的整体特性，主要包含

色彩和形状等总体特征，但不宜用于图形混叠或者有遮挡的情形，可以对行人进行快速识别，代表较为完整的行人特征信息。全局特征的提取过程就是把一个行人图像输入到卷积神经网络（Convolutional Neural Network, CNN）中得到全局特征，为了获得更好的实验效果，一般采用在 ImageNet^[2]预训练好的卷积神经网络。Sun 等人设计了 SVDNet^[3]，SVDNet 的网络后端的全连接层前添加了一个 Eigenlayer，Eigenlayer 专门用于对参数进行奇异值分解，通过对特征向量进行正交化来减少特征相关性，提升了网络基于欧氏距离的行人重识别性能。Zheng 等人提出了一个名为 PAN^[4]的网络，PAN 利用人体姿态估计模型进行人体关键点的估计，然后借助仿射变换法对行人进行对齐，以此获得更好的识别性能。

基于全局特征学习的方法^{[5]-[7]}确实能够达到一些良好效果，不过仍然存在着一些严重问题，比如拍摄角度的不一致、光照强度的不同、物体遮挡和行人外观的相似性问题，而这些问题也往往会影响行人重识精度的提高。因此，单纯依靠全局特征是不充分、不全面的。局部特征包含行人部分区域的细节线索，基于局部的方法大体可分为三种，有水平切片方式、融合注意力机制的方式及辅助信息的方式，方法示例如图 1.3 所示。




图 1.3 基于局部特征的方法示例

水平切片法是把图片或特征张量切分成许多水平条，然后在每一个特征条块中挖掘局部特征。Sun 等人在文献中提出了著名的 PCB^[8]模型，如图 1.4 所示，PCB 模型的基本思路就是把一张行人图像输入到卷积神经网络之中，对网络末端输出的特征张量按水平方向均分为 6 份，然后再对各份条块分别进行局部特征学习，每一个条块分别对应一个交叉熵损失函数来监督局部特征学习。在检测阶段，所有的局部特征块拼接在一起作为最终的鉴别特征。




图 1.4 PCB 网络模型

基于注意力机制的方法^{[9]-[12]}可以使网络聚焦于关键的行人特征区域，抑制非重要特征信息。这类方法的具体表现就是定位特征图中高度活跃的特征区域来获得 ROI（Regions of Interest）特征。Li 等人还提出了 HA-CNN^[10]模型，HA-CNN 模型同时利用了软注意力和硬注意力两种注意力机制，并对特征表示进行了优化，主要用于处理图像的校准问题。Kalayeh 等人提出了名为 SPReID^[12]的模型，提取了 5 个代表不同人体部位的置信图，然后利用其进行人体语义解析。这类行人重识别方法利用各种注意力机制来增强网络对物体遮挡、姿态变化以及图像质量不佳等问题的鲁棒程度，降低其产生的影响。

基于辅助信息的方法，其核心思想主要是通过使用行人姿态信息、身体特征点等辅助信息，处理行人的遮挡和不对齐问题。Wei 等人^[13]利用人体姿态识别技术，首先通过网络迭代训练来定位人体关键点，然后将人体划分为头部、上肢、下肢三个部分，然后从全局图像和三个部件中进行全局与局部特征学习。Wang 等人提出了一种双流网络 st-ReID^[14]，能够使用时空信息以克服外观歧义。基于辅助信息的方法虽然可以解决某一方面的问题，但是由于采用了外部模块，这些外部信息的获取方法本身就存在的误差反而会限制重识别性能的提高，并且网络结构本身也较为复杂。

1.2.2 度量学习

度量学习也是行人重识别的一种主要方式，这 and 传统表征学习方法中采用分类和验证的方法有所不同，因为度量学习的主要目的是达到特征距离优化的效果，具体是使相同 ID 的不同图片之间的相似程度大于不同 ID 的不同图片之间的相似程度。在度量学习方法中，常见的损失函数包括对比损失（Contrastive Loss）^[15]、三元组损失（Triplet Loss）^[7, 17, 18]、四元组损失（Quadruplet Loss）^[19]。

对比损失会使得类内样本间产生聚类效果，因此类间样本之间的距离也会更远，实质上是为了优化特征距离。Hoffer 等人研究出了三元组网络 Triplet Network^[18]，该网络的输入样本采用原始图像 Anchor（a）以及对应的正样本（p）

和负样本 (n) 的组合, 训练模型应使得正样本之间的距离加上某个阈值仍然小于负样本之间的距离。Hermans 等人还给出了批难样本损失函数 (Batch Hard Triplet Loss)^[17], 使用该策略的网络会从每一个 batch 中选择 P 个不同 ID 的行人, 从每个 ID 的行人中随机选取 K 张不同的照片。难样本选取策略的独到之处就是每个 batch 中的每一张图片 a , 都选取出最难的正样本 p 和最难的负样本 n , 构成难样本三元组, 然后求出损失函数, 其本质思想就是在这种极端情况下进行特征空间优化。四元组损失也是度量学习的一类方法, 在样本选取上比三元组损失多了一张负样本图片, 本质上也是拉近相同 ID 图像间的距离, 推开非同 ID 图像之间的距离, 优化了四个类别的特征距离。

1.3 本文研究内容

本文研究的问题是如何降低在行人被遮挡、视角不一致、姿态变化等条件下的图像问题所带来的影响。主要的研究内容是在多尺度特征学习的基础上, 基于特定目的, 提出能够获得更强辨识度与更高鲁棒性特征的深度多分支网络, 从而有效提升模型性能。本文主要的研究成果包括基于多特征融合的多尺度注意力行人重识别网络和基于多尺度特征学习的双流行人重识别网络两项。

(1) 基于多特征融合的多尺度注意力网络

仅提取粗粒度的全局特征会导致网络忽略掉一些重要的行人细节, 这样会使得网络容易被图像问题所干扰, 为了缓解图像变化所带来的影响, 本文提出了一种基于多特征融合的多尺度注意力网络 MSAN。该网络可以对网络不同深度的特征进行采样, 并结合了全局与局部特征, 引入注意力机制使网络聚焦于不同尺度特征图的关键信息, 从而增强对人体关键部位的学习, 进一步缓解图像变化带来的干扰, 最终融合各分支采样的不同特征对行人进行预测。

(2) 基于多尺度特征学习的双流行人重识别网络

为了对行人特征进行充分提取, 本文提出了一种基于多尺度特征学习的双流网络 DFMS。DFMS 的两个子网都拥有多个针对不同类型的特征提取分支, 采用这样的双子网多分支架构进一步增大了特征的采样范围。每个子网络都面向三种不同尺度空间上的全局级特征, 但二者面向的局部特征的粒度不同, 这样使得 DFMS 可以获得不同尺度的全局特征与局部细节特征, 提取更全面的粗粒度与细粒度特征线索来弥补判别特征的缺失, 强化了模型的特征表达能力, 进而减轻图像问题带来的影响, 提高模型的精度。

1.4 论文组织结构

本文研究了不同的行人重识别算法，尤其是多尺度特征学习和多分支网络相关的方法，对各类模型展开了广泛的剖析和深入研究。本文所要解决的重点问题是如何减少由于图像问题所带来的影响，根本目的是为了获取到更有效的、鉴别能力更强的行人特征，以便提高模型的泛化性能。根据文章研究内容，本文共包含 5 个章节。论文的组织结构如图 1.5 所示。

论文章节结构及主题内容如下：

第一章是绪论，重点是对行人重识别作出了整体性阐述。首先阐述了行人重识别的研究背景以及意义，然后剖析了目前国内外行人重识别的研究现状和一些主流的行人重识别方法。

第二章的内容主要是讲述了基于深度学习的行人重识别的相关理论基础。本章首先对卷积神经网络的概念、构造机理做了阐述，接着对深度残差网络和卷积神经网络中最常见的几种激活函数分别进行了说明，在结尾阶段还简单总结了行人重识别中一些常见的数据集，以及主要的评估指标。

第三章是在论文中给出的第一个主要研究内容，基于多特征融合的多尺度注意力行人重识别网络。从解决全局特征易受图像问题的影响出发，考虑通过对多尺度学习、局部特征学习、卷积注意力机制等进行联合使用，进而创造了一种新的设计思路。最后利用实验来对方法的有效性与先进性加以检验。

第四章是本文的第二个主要研究内容，基于多尺度特征学习的双流行人重识别网络。首先以缓解图像问题所产生的不良影响为出发点，基于多尺度特征学习设计了一种双流多分支网络结构，并提供了多元化特征信息以强化行人特征表示，最后利用大量的实验对提出的方法进行检验和评估。

第五章主要对全文内容做了总结并对未来的工作进行了展望。




图 1.5 论文组织结构

第二章 基于深度学习的行人重识别相关理论概述

近年来, 由于深度学习技术的迅速发展, 基于深度学习的行人重识技术也做出了一定的成就, 在很大程度上替代了设计复杂的传统手工特征方式。想要设计出更好的行人重识别模型, 就需要对基于深度学习的行人重识别技术做出更深入的理解。由于本章将分为三部分展开阐述, 在本文第一个部分中重点阐述了卷积神经网络的基本原理以及架构, 然后对行人重识别中使用的深度残差网络 ResNet^[20]进行了阐述。本章第二部分介绍了 ReID 中常用的数据集, 并对其进行了简要分析。在第三个部分中, 主要说明了评判行人重识别算法性能的两个主要技术指标。

2.1 卷积神经网络

2.1.1 卷积神经网络概述

人工神经网络 (Artificial Neural Network, ANN) 又叫作神经网络, 由众多的神经元相互连接而成, 呈现高度的非线性特点, 因此可以进行复杂的逻辑运算和非线性关系的实现。神经网络通过调节节点之间的连接关联, 来模仿人的记忆, 主要网络层包括隐藏层、输入层和输出层。图 2.1 展示了神经网络的网络结构。




图 2.1 人工神经网络结构图

卷积神经网络是具有卷积结构的深度神经网络, 能够根据特定的模式对大

量复杂数据进行特征提取，并具有良好的数据泛化能力，是目前在图像处理领域特征提取的最佳方法，主要运用在目标检测、物体识别、图像分割、动作识别等技术领域，在这些领域的效果远远超过了传统人工方法。

2.1.2 卷积神经网络的结构

卷积神经网络主要由全连接层（Fully connected layer, FC）、卷积层（Convolutional layer）、池化层（Pooling layer）组合而成。在完成图像分类工作时，CNN 提供的特征空间将使用全连接层来进行划分。其中卷积和池化的引入大幅度减少了模型的参数。对 CNN 的训练实际上就是通过训练样本迭代地调整网络的权重。目前主流的卷积神经网络都是由简单的 CNN 改进而成。下面分别对卷积神经网络的三个构成部分分别加以说明。

（1）卷积层

卷积层的目的是对所有输入数据信息做卷积运算。在一个卷积层中，往往含有大量的滤波器，也称卷积核，在网络的训练过程中，卷积核将学习到合理的权值，卷积核的大小决定了其感知区域。卷积计算过程是使卷积核以特定步长在输入矩阵上由左至右，从上到下地逐步移动并完成点积计算，结果累加以获得代表图像属性的特征图。这样，可以通过卷积核不断地获取输入数据从局部的特征到总体的特征，从而进行图像识别等功能。最后将输出结果通过激活函数进行激活操作。




图 2.2 卷积过程演示

图 2.2 展示了卷积运算的过程，图中绿色部分代表卷积核，卷积核移动步长设置为 1，自左向右，自上而下的顺序每次移动一个单元格。输入图像大小为 4×4 ，卷积核大小为 2×2 。如图 2.2 (a) 所示，第一次卷积运算结果为 $0 \times 1 +$

$0 \times 1 + 1 \times 0 + 1 \times 0 = 0$ 。如果所采用的激活函数是 ReLU 激活函数，根据其表达式 $f(x) = \max(0, x)$ 得出特征图上第一个点的值为 $f(0) = 0$ 。然后，如图 2.2 (b) 所示，卷积核右移一格，重复上述运算过程，同理可以得到输入图像经过卷积操作之后的特征图。

在 CNN 各层中，网络所提取特征的层次根据卷积网络深度的逐渐加深而增加。目前主流的卷积神经网络通常是深层网络，会包含大量的卷积层，每一层卷积的结果都将送入至下一个模块。更深层次的特征往往更易于提取图像的有效信息。

(2) 池化层

池化方法是一种下采样方法，而由于特征图的数量过大不利于更高层次特征的获得，因此池化方法的主要就是通过减小特征图的特征空间，从而降低了网络参数量和计算量，提升了模型的泛化能力。

最常见的特征池化方法有最大池化 (Max Pooling) 方法和平均池化 (Average Pooling) 方法，前者对特定范围内特征点进行取最大值操作，后者对则是取平均数的操作。假设把窗口尺寸设定为 2×2 ，把步长设置为 1，两种池化操作的计算方式如图 2.3 所示。




图 2.3 最大值池化与平均池化的计算方式

(3) 全连接层

全连接层可以连接所有的分布式特征，在卷积神经网络中通常作为分类器来应用，最终全连接层的输出值被传送给 softmax 层进行分类。但由于全连接层的参数冗余现象，对全连接层的宽度和深度的扩展将会导致网络的参数量大幅度提升，现在的一些神经网络考虑用其他方法来替代全连接层，图 2.4 为全连接层示意图。




图 2.4 全连接层示意图

全连接层如公式 (2.1) 所示:

$$\text{output}(x) = f(W^T x + b) \quad (2.1)$$

这里, $f(\cdot)$ 代表的是激活函数, x 为输入向量, b 是偏置项, W^T 是权重矩阵。

2.1.3 深度残差网络

作为一种颇具吸引力的深度学习结构, 卷积神经网络的发展有着从简到繁再由繁到简的过程。研究者们提出的每一种卷积神经网络模型都有所创新, 本文选用深度残差网络系列中的 ResNet50 作为骨干网络, 下面对深度残差网络进行简要介绍。

在卷积神经网络中, 提高深度网络的层数将有助于获得更具辨别力的特征。随着网络深度的逐步增加, 在训练中的梯度消失问题的发生也愈发频繁。为了解决这个问题, He 等人于 2015 年提出了一种深度残差网络 ResNet。ResNet 运用了残差的思想, 把靠前的若干层的某一层的数据直接跳过多层传递到后面层中, 输入信息也能够从任意低层中直接传递至后面的高层, 使信息前向传递的比较流畅, 在一定程度上能够克制网络退化问题。所以, 设计 ResNet 目的实质就是通过这种“捷径连接”方式一定程度上解决因网络层数加深导致学习模型的精度不升反降的问题。在 ResNet 网络中, 并不使用常规的残差模块 (Residual block), 而是替换为 Bottleneck 模块, 其模块结构图 2.5 所示。




图 2.5 Bottleneck 模块结构图

Bottleneck 的本质思想就是利用多个小卷积核替代一个大卷积核，从而减少参数量，特征降维后可以被更有效地提取。其中，两个 1×1 卷积核分别用于降低和提升特征维度。Bottleneck 使得在输入与输出之间建立了快速连接，从而可使信号在网络系统前后层次之间快速传输，有效避免了深层网络的梯度消失和梯度爆炸问题。深度残差网络的出现给各种计算机视觉任务带来了极大的性能提升。

表 2.1 ResNet50 网络结构

层名称	输出尺寸	构成部分
Conv1	112×112	7×7, 64, stride=2
		3×3 max pool, stride=2
Conv2_x	56×56	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
Conv3_x	28×28	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$
Conv4_x	14×14	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$
Conv5_x	7×7	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax

ResNet50 是行人重识别中最常见的骨干网，主要由若干个残差块所构成，共包括了五十组卷积操作，其网络结构如表 2.1 所示。ResNet50 有 4 个名字分别为 Conv2_x、Conv3_x、Conv4_x、Conv5_x 的卷积层，分别由 3、4、6、3 个 Bottleneck 模块组成。ResNet50 末端的平均池化层用于降低特征图尺寸，全连接层则用于分类，接着 softmax 函数实现输出离散化。

2.1.4 激活函数

数据的分布绝大多数是非线性的，但是对于卷积神经网络的计算通常是线性的，激活函数是神经网络中非线性的来源，可以使神经网络能够表达任意的非线性映射。本节将选择几种常见的激活函数进行介绍。

(1) Sigmoid 激活函数的公式如下所示：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.2)$$

Sigmoid 函数是一个非线性激活函数，有单调递增与连续可导的函数特征，用于隐藏层神经元输出，可以将任意值转换到[0, 1]之间。不过 sigmoid 函数也存在着问题，当函数取值趋近于 0 和 1 时产生了饱和现象，在反向传播中易造成梯度消失，致使网络在训练阶段达到过拟合状态。而且 sigmoid 函数是一种指数函数，计算复杂度较高。

(2) ReLU 激活函数的公式如下所示：

$$f(x) = \begin{cases} 0, & x \leq 0 \\ x, & x > 0 \end{cases} \quad (2.3)$$

在 ReLU 激活函数当中，如果自变量大于 0，则其函数输出结果就是自变量本身，如果自变量小于等于 0，函数值则始终为 0。ReLU 激活函数具有单侧抑制性，使得神经网络中的神经元也具备了稀疏激活的特性，从而促进了网络的训练，可以更好地拟合训练数据。因为 ReLU 不像 sigmoid 函数一样有饱和区，很好地缓解了梯度消失的问题。ReLU 函数的设计也存在不足之处，ReLU 函数在 0 点附近不可微，所以通常在 0 点上只可以求得右导数，另外 ReLU 激活函数在反向传播过程中会让一些神经元的导数永远是 0，致使这部分神经元成为假死状态，会发生梯度消失现象，从而导致网络对应权值无法更新。

(3) Leaky ReLU 激活函数

$$f(x) = \begin{cases} \lambda x, & x \leq 0 \\ x, & x > 0 \end{cases} \quad (2.4)$$

Leaky ReLU 的计算如公式 (2.4) 所示。ReLU 是将所有的负值都映射为 0, 但 Leaky ReLU 的自变量为负时, 其输出函数值并不等于 0, 而是保持轻微的倾斜, 其中斜率为 λ , 有效避免了神经元假死的问题。值得注意的是 Leaky ReLU 为确定的标量, 是不可学习的。

2.2 标准数据集

在行人重识别领域中存在着大量数据集, 如 CUHK01^[23]、CUHK02^[24]、Market-1501^[25]、DukeMTMC-reID^[26]、CUHK03^[5]、PRID2011^[27]、VIPeR^[28]、MARS^[29] 等数据集。接下来, 将描述本文中实验采用的 Market-1501、DukeMTMC-reID 和 CUHK03 这三种标准数据集。

2.2.1 Market-1501 数据集

Market-1501 数据集在 2015 年构建并公开发表, 图像质量较高, Market-1501 数据集的部分图像如图 2.6 所示。它包含了由 6 个非重叠摄像头 (包含 5 个高清摄像头和 1 个低清摄像头) 抓拍到的 1501 个行人 (1501 个不同行人的 ID), 共计 32668 张图像。




图 2.6 Market-1501 数据集中的部分图像

每个行人都至少可以由两台摄像头拍摄到, 而且在一个摄像机中还可以拍

摄有多个图像。训练集有 751 个 ID 的行人，包含 12,936 张图像，平均每个 ID 有 17.2 张训练数据；而测试集有 750 个 ID 的行人，包含 19,732 张图像，构成了 Gallery 图像库。检索库共由 3368 幅查询图像组成，对应 750 个 ID 的行人。

2.2.2 DukeMTMC-reID 数据集

DukeMTMC-reID 数据集是 2017 年发布的一个大型行人重识别图片数据集，由 8 个同步摄像机记录。其中的部分图像如图 2.7 所示。DukeMTMC-reID 的训练集共 16522 张图片，这些图片来自 702 个类的行人，检索图像集共 2228 张图片，来自 702 个类的行人。此外还有 17661 张行人图片组成了图像库 Gallery。




图 2.7 DukeMTMC-reID 数据集中的部分图像

2.2.3 CUHK03 数据集

CUHK03 采自香港中文大学，由 5 对摄像头收集而成，在 CUHK03 数据集中的部分图像如图 2.8 所展示。CUHK03 共包含 14097 个样本，样本的 ID 数为 1467。CUHK03 包括了 Labeled 和 Detected 两种子数据集，Labeled 数据集中主要是由行人检测器标记而产生的，包括 7367 张训练样本、1400 张检索图像和 5328 张 Gallery 的图像。而 Detected 则是由人类手动标记而成，包含 7365 张训练图像、1400 张检索样本和 5332 张 Gallery 图像库中的图像。



图 2.8 CUHK03 数据集中的部分图像

2.3 评价指标

在行人重识别中，为了评价行人重识别算法的性能，一般用累积匹配曲线（Cumulated Match Curve, CMC）和平均均值精度（Mean Average Precision, mAP）。下文将对这两个技术指标分别进行说明。

2.3.1 累积匹配曲线

CMC 曲线是评价 ReID 网络分类特性的常用评价技术指标，ReID 模型的好坏可以通过 CMC 曲线来评价，CMC 曲线的具体含义是指：在 gallery 图像库中去检索与 probe 是同一 ID 的行人的图片，将识别结果相似性降序排列，前 k 个检索结果中就成功检索出目标行人图像的比率。 $\text{rank-}n$ 值具体指 $\text{rank-}n$ 的数目占总的 query 样本数的比例。其中， $\text{rank-}1$ 指标代表特征相似度最匹配的图像就与 probe 图像是同一 ID 的概率，代表模型实际的识别能力。此外，在 n 大于 1 时可以采用人工辅助识别来搜索目标，也有着很大的实际意义。

2.3.2 平均均值精度

平均均值精度（Mean Average Precision, mAP）是将多分类任务中的平均精度（Average Precision, AP）相加求和之后再求取平均。设一次查询中目标 p

有 N 个结果，其中与 p 是相同 ID 的结果有 $S(p)$ 个， $f_i(p)$ 则表示 N 个结果中与 p 同一 ID 的第 i 个结果的查准率。则 $f_i(p) = i/T_i(p)$ ， $T_i(p)$ 代表在检索到第 i 个结果时对应的所有图像的数量。如上所述，AP 可以表示为：

$$AP(p) = \frac{1}{S(p)} \sum_{i=1}^{S(p)} f_i(p) \quad (2.5)$$

假设总共进行了 M 次查询，则 mAP 的计算公式为：

$$mAP = \frac{1}{M} \sum_{m=1}^M AP_m(p) \quad (2.6)$$

2.4 本章小结

在本章中，首先介绍了在基于深度学习的行人重识别研究中的一些基础知识理论与概念，其中包括卷积神经网络的相关概念、网络结构与激活函数。由于深度残差网络 ResNet 在行人重识别算法中作为最常用的骨干网，在本章对其进行了单独的介绍。接下来介绍了在本文的实验阶段使用的三个标准数据集，分别为 Market-1501、DukeMTMC-reID 和 CUHK03。最后对衡量网络模型性能的两个重要的评价指标 CMC 和 mAP 进行了简要概括。

第三章 基于多特征融合的多尺度注意力行人重识别网络

由于真实拍摄场景的复杂性以及行人自身的灵活性，致使行人姿态变化、光照差异过大、行人被遮挡等问题的发生。普通的卷积神经网络从图像中提取的全局特征往往会忽略掉一些重要的细节信息，致使网络得不到足够的判别信息从而影响识别效果。为了解决这些问题，本章提出了一种基于多特征融合的多尺度注意力网络（Multi-Scale Attention Network Based on Multi-Feature Fusion for Person Re-Identification），简称为 MSAN。该网络能够采样不同卷积深度下的行人特征，并结合全局与局部特征得到高辨识度的特征嵌入，进而通过融合所采样的特征准确的预测行人身份。本章工作的核心思想在于使用注意力机制使网络更加聚焦于不同尺度上的关键特征信息，从而增强对人体关键部位的学习，缓解图像变化带来的干扰，提升重识别效果。

3.1 引言

行人重识别属于图像检索的范畴，其目标是匹配由多个非重叠视域的摄像机在不同视角拍摄的行人图片。行人重识别研究存在诸多困难，比如受摄像头成像质量的限制，以及摄像头与行人距离过远，造成摄像头所拍摄到的行人图像分辨率差。行人的主观能动性造成的姿势变化，将造成摄像头抓拍到的行人图像出现人体姿态各异的情况。实际拍摄场景中的客观环境存在易变性，会造成光照强度不一致、行人被物体遮挡以及行人背景杂波等问题的出现，致使行人重识别效果的提高受到了严重限制。面对这些棘手的问题，需要新型的行人重识别网络去学习更具鉴别性和鲁棒性的特征。早期行人重识别领域的研究重点，大多是在全局特征^{[5]~[7]}方面，全局特征学习的目的是获取行人最重要的外观信息和姿态信息，忽略掉了人体特定部位周围的局部细节，容易受到行人姿态变化、遮挡问题和拍摄角度不一致的影响，不足以准确地表达复杂场景中的行人身份信息。

因此，行人重识别领域的研究者逐渐开始研究基于局部特征的方法^[8, 30, 31]。基于局部特征的一种常用方法是将人体区域划分为若干特定尺寸的水平条，所有提取到的特征条块被融合在一起作为最终的特征描述符。在文献^[13]中，把整个行人图像分成了头部、上半身和下半身三个部分，然后将这三部分的局部图像输入到 CNN 中并进行参数共享。这种方法的主要缺点在于网络中的人体骨骼

关键点模型需要预先训练,这无疑增加了训练的难度。Sun 等人采用多粒度分割模型 PCB,将骨干网输出的行人图像的全局特征图垂直分割为 6 块,分割后的每个特征块使用分类损失函数监督训练。在检测阶段中,将 6 个局部特征块拼接在一起作为最终的鉴别特征。然而,由于行人的姿态变化和不对齐现象,基于局部分割的方法将受到限制。后来出现了一种较好的 HPM 方法^[31],其主要思想是结合全局和局部特征信息来解决姿态变化和错位问题。全局和局部线索的结合可以进一步提高模型的泛化能力,对行人姿态变化、拍摄视角不一致和行人局部遮挡等情况具有较强的鲁棒性。然而,这些方法大多只使用 CNN 最后一层输出的高级特征图,忽略了低卷积深度的特征图中包含的有用语义信息。浅层特征中包含的这些语义信息可以作为一种有效的细粒度的辅助信息,以缓解行人图像的各种问题带来的影响。为了能够同时利用网络中多个卷积层输出的多尺度特征信息,文献^[32]提出了一种能够融合浅层特征和高层特征信息的深度识别模型,它采用 9 个子网络来学习网络的多级判别特征。该方法最大的缺点是网络层数过多,导致参数冗余,影响模型精度。因此,将高阶特征的局部和全局特征线索与低阶细节特征相结合是一种有效的方法。另外,许多方法没有考虑注意力机制的影响,注意力的引入可以使得网络选择性地聚焦于图像中的行人部分,非重要的区域信息将在一定程度上被抑制,从而进一步提高特征的鉴别性和鲁棒性,达到抗干扰的效果。

为了弥补上述方法的不足,获得更多的鉴别性特征信息,本章提出了一种端到端模型,即基于多特征融合的多尺度注意力行人重识别网络,简称 MSAN。MSAN 能够有效利用网络中不同深度的多尺度特征,包括浅层细粒度特征和深层特征的全局与局部特征线索,对行人的特征描述更加丰富。全局特征象征着行人的整体属性,但是这种整体性的特征缺少了可以作为辅助特征信息的细粒度特征,局部特征能够很好地解决图像变化造成的关键信息缺失问题,浅层特征中的语义线索则可以作为全局细粒度特征。将上述特征进行有效融合能够显著提高最终行人描述符的表征能力。此外,本章提出的 MSAN 网络利用卷积注意力模块 CBAM^[33]中的空间注意力模块和通道注意力模块,将其合理运用到 MSAN 之中,使得网络更加聚焦于关键的鉴别性特征,增强了网络的学习能力。为了进一步优化网络的性能,本章重点研究了如何有效地处理不同尺度空间上的特征图,设计了一种简单有效的特征处理模块,将此命名为基于通道注意力的池化特征融合模块(the Pooling Features Fusion Module based on Channel Attention),简称 PFCA。PFCA 模块将通道注意力模块与池化融合策略(GAP+GMP)有效地结合起来,PFCA 模块由通道注意力模块、最大值池化和平均池化特征融合模块、ReLU 激活函数和降维模块组成,PFCA 模块中的通道

注意力模块实现了对网络多尺度特征的通道注意力处理功能。实际上,封装在 PFCA 模块中的通道注意力模块与独立的空间注意力模块共同构成了 MSAN 网络的注意力机制部分。

3.2 基于多特征融合的多尺度注意力网络模型

在本小节中,重点介绍并分析了 MSAN 的基本网络结构及其核心模块。首先对基于多特征融合的多尺度注意力网络 MSAN 进行整体性介绍,并阐述了其设计思路。然后,再对特征处理模块 PFCA 进行分析,并对 PFCA 模块中的子模块也进行了介绍。最后,结合网络模型解释 MSAN 使用的损失函数及其最终计算公式。

3.2.1 整体架构设计

本章所设计的 MSAN 网络能够有效利用不同深度阶段的多尺度特征信息,并同时融合了全局与局部特征线索。如图 3.1 所示,MSAN 是一个深层的多分支网络,共包含了四个分支,从上至下依次对其编号为分支 1 到分支 4。分支 1 是浅层特征学习分支,分支 2 与分支 3 则是局部特征学习分支,处于最下方的分支 4 则是全局特征学习分支。全局特征学习分支是主干分支,目标是提取行人的整体性特征,而局部特征学习分支的目标则是提取分割后的局部特征块中含有的细粒度的局部行人信息,而浅层特征学习分支则可以充分利用浅层特征所包含的语义信息。




图 3.1 基于多特征融合的多尺度注意力网络模型

MSAN 采用了已在 ImageNet 上预训练过的深度残差网络 ResNet50 来作为骨干网。ResNet50 模型共包括了 5 个卷积阶段,第一个卷积阶段的主要操作为 {conv,bn,relu,maxpool}, conv 表示卷积操作, bn 代表批归一化处理, relu 表示

relu 激活函数, maxpool 表示最大池化, 其他四个深度残差块分别称为 layer1、layer2、layer3、layer4。因为在 ResNet50 中, 最后两个卷积层 layer3 和 layer4 的特征图包含有更丰富的语义信息, 而 layer1 与 layer2 输出的特征图感受野过小, 并且含有了过多的背景信息, 属于还没有进行过充分处理的特征信息, 这将对最终的有效识别产生负面影响, 所以在 MSAN 中对有效多尺度特征的提取以 layer3 和 layer4 输出的特征图为基础, 所有的分支都来自于 layer3 或 layer4。另外, 在 ResNet50 的末端移除了最后一个平均池化层和完全连接层, 这使得网络可以获得一个更大尺寸的特征图, 从而提取更多的特征信息。将一组尺寸为 [3,384,128] 的数据输入到 ResNet50 中, 在 ResNet50 中的 layer4 层会输出尺寸为 [2048,18,9] 的深层特征图, layer3 层则输出特征尺寸为 [1024,18,9] 的浅层特征图 T'。MSAN 的浅层特征学习分支使用 layer3 输出的特征图 T', 其他分支则使用 layer4 输出的深层特征图 T。局部特征的提取是将 layer4 输出的特征图 T 水平切分成两片, 分别从两个特征块中挖掘行人的局部特征线索。

在 MSAN 中, 除了浅层特征学习分支中单独设置了一个 Bottleneck 模块外, 其他所有分支的基本结构都相同, 只是具体参数设置不同, 且每一个分支后面均设定了 PFCA 模型, 作为多尺度特征的处理单元。特征张量进入各分支中首先会经过特征处理模块 PFCA 的增强处理, 依次经过通道注意力加权、池化融合操作、特征降维, 最后用于分类学习。其中浅层特征分支中的 Bottleneck 用于降低浅层特征的通道维数, 减少参数量, 提高特征的判别力, 因此浅层特征学习分支可以从中更有效地提取细粒度的语义信息。

3.2.2 特征后处理模块

(1) 空间注意力模块

本章引入的空间注意力模块可以在空间维度上赋予图像的行人部分较高的权重, 突出其重要性, 对非重要特征区域则赋予较低的权重, 抑制其重要性。ResNet50 的 layer3 输出的特征图 T' 是未经充分提取的特性, 感受野较小, 是一种细粒度特征。空间注意力模块只对 layer4 输出的特征图 T 进行注意力加权处理。




图 3.2 空间注意力模块

在 MSAN 中所采用的空间注意力模型的基本构造如图 3.2 所示，其思路主要是用特征空间的空间关系得到空间注意力权重图。空间注意力主要关注于位置信息，能够突显出一些关键的位置上的特征信息，下面我们详细讲述该空间注意力的计算过程。假设特征图 T 的大小为 $[C \times H \times W]$ ，首先分别对 T 进行通道维度上的平均池化和最大池化把特征图 T 的通道数压缩为 1，获得两个大小都为 $[H \times W \times 1]$ 的特征描述子，然后将二者在通道维度上进行拼接，得到一个大小为 $[H \times W \times 2]$ 的特征描述子 M 。然后使用一个卷积核大小为 7×7 的卷积层对特征描述子 M 进行卷积操作，再通过 sigmoid 函数处理，最终得到尺寸为 $[H \times W \times 1]$ 权重图 M_s ，即为空间注意力权重图。然后，权重图 M_s 和原始特征图 T 相乘后，得出了经空间注意力加权处理后的新特征图。空间注意力的计算公式如下：

$$\begin{aligned} M_s(T) &= \sigma(f^{7 \times 7}([AvgPool(T); MaxPool(T)])) \\ &= \sigma(f^{7 \times 7}([T_{avg}^s; T_{max}^s])) \end{aligned} \quad (3.1)$$

其中， σ 为 sigmoid 运算， 7×7 为卷积核的大小。

(2) 基于通道注意力的池化特征融合模块

在本章所提出的基于通道注意力的池化特征融合模块作为一个有效的特征处理单元，可以从流入各特征提取分支的特征张量中提取到尽可能多的鉴别性特征，从而增强各分支的特征提取能力。其构造如图 3.3 所示，PFCA 模块由以下三个部分构成：通道注意力模块、最大值池化与平均池化特征融合模块、降维模块。PFCA 模块作为基本的特征处理单元，应用于 MSAN 的各个分支中。当特征图进入到各个分支时，都要经过该分支中 PFCA 模块的处理。通道注意力模块首先对其进行通道加权处理，然后池化特征融合模块再对通道注意力处理后的特征图分别进行 Max Pooling 和 Average Pooling，并利用逐元素相加运算对池化后的两个特征图进行了有效融合。最后，由降维模块对输出特征向量进

行通道降维。




图 3.3 PFCA 模块结构图

PFCA 模块中的通道注意力模块结构如图 3.4 所示。




图 3.4 通道注意力模块结构图

特征图被通道注意力模块进行通道加权操作，实际上是重新分配给不同通道赋以不同的权重，使得网络可以专注于特征图中不同通道中的显著特征信息并抑制非显著性特征，以便更充分地利用特征信息。具体来说，特征图 F 从 ResNet50 的第 3 层或第 4 层输出，其大小设为 $[C, H, W]$ 。首先，通过把 F 分别输入到最大池化层和平均池化层来聚合特征图的空间信息，即可得到两个不同的空间上下文描述符 F_1 和 F_2 ，接着 F_1 和 F_2 进入到共享网络 MLP 中，MLP 所产生的特征向量逐元素相加以有效融合，最后再通过 sigmoid 激活产生通道注意力向量 M_c 。通道注意力的计算公式如下所示：

$$\begin{aligned}
 M_c(F) &= \sigma \left(MLP(AvgPool(F)) + MLP(MaxPool(F)) \right) \\
 &= \sigma \left(W_1 \left(W_0(F_{avg}^c) \right) + W_1 \left(W_0(F_{max}^c) \right) \right)
 \end{aligned} \quad (3.2)$$

其中， σ 是 sigmoid 函数。 W_0 和 W_1 都是 MLP 的权重，被两个输入特征共享。

(3) 最大值池化和平均池化特征融合模块

全局平均池化和全局最大池化在行人重识别技术中被广泛使用。目前的行

人重识别方法大多只关注一种池化方法，没有综合利用二者的优势，会丢失特征图中的一些有用的信息。平均池化会保留图像的背景信息，强化特征图与行人身份之间的关联，而最大值池化则能够保留图像中的显著性特征。本章工作中，为了充分发挥两种池化方法的优势，通过逐元素相加的方式对两种池化层输出特征向量加以有效融合。融合后的特征向量既包含了更多的行人的背景信息，也保留了图像中的大量的纹理信息，从而增强了用以预测行人身份的特征信息。

(4) 降维模块

降维模块是 PFCA 模块的子模块，由全连接层、批归一化层 (BN)^[34]和 Leaky ReLU 激活函数依次组成。降维模块将输入的特征向量的通道维数统一降至 512 维然后进行最终分类。

3.2.3 损失函数

MSAN 仅使用分类损失函数用来监督训练模型。分类损失指的是 softmax loss，即交叉熵损失函数，用来衡量真实概率分布与预测概率分布间的相似程度。MSAN 的每个分支提取的特征向量被输入进分类器以产生预测特征向量，最后利用 softmax 损失函数预测输入图像中的行人 ID。

(1) 交叉熵损失函数

对于真实分布 $p(x)$ 和模型训练之后的预测分布 $q(x)$ ，交叉熵损失函数能够衡量 $p(x)$ 和 $q(x)$ 之间的相似性，公式计算如公式 (3.3) 所示。

$$F(p, q) = - \sum_{i=1}^n p(x_i) \log(q(x_i)) \quad (3.3)$$

真实分布 $p(x)$ 即为训练时的样本标签，其值为 1。根据 softmax 分类的预测分布 $q(x)$ 的计算如公式 (3.4) 所示。

$$q(x) = \frac{\exp(W_{y_i} x_i)}{\sum_j^n \exp(W_j x_i)} \quad (3.4)$$

Softmax 输出的结果是基于多个类别的概率值， j 表示类别数， W 表示权值矩阵， x 为特征向量。通过公式 (3.3) 和公式 (3.4)，可以得到 softmax 交叉熵损失函数 L_{id} 的表达式，表达式如公式 (3.5) 所示。

$$L_{id} = -\frac{1}{N_{batch}} \sum_i^{N_{batch}} \log \frac{\exp(W_{y_i} x_i)}{\sum_j^n \exp(W_j x_i)} \quad (3.5)$$

其中 N_{batch} 代表在训练阶段中一个 batch 中的样本数量。

(2) 最终损失函数表达式

MSAN 在训练阶段采用单一的交叉熵损失函数。从图 3.1 中可以看到，整个网络模型用了 4 个 softmax 损失函数。所以，完整的损失函数可以表示为：

$$L_{total} = \sum_{s=1}^4 L_{id}^s \quad (3.6)$$

3.3 实验结果及分析

本节首先介绍了 MSAN 网络的训练阶段的实验设置，然后将 MSAN 与多个 SOTA 方法展开实验对比。最后，通过进行大量的消融实验来验证 MSAN 网络各类分支和特征处理模块的有效性。本章实验基于 DukeMTMC-reID、Market-1501 以及 CUHK03 三个标准数据集。

3.3.1 实验设置

为了增强实验效果，本章使用了一些常见的数据增强方法来从数据样本中获得更多的有用信息。具体来说，所有的图像在进入骨干网 ResNet50 之前尺寸会被调整为 288×144 ，然后图像样本会经过随机裁剪和水平翻转进一步处理。

在训练策略方面，为使模型可以进行充分的训练，MSAN 网络共被训练了 220 个 epoch。实验中 batch size 设定为 32，则在一个 batch 中共有 32 幅图片，其中有 8 个不同的行人 ID，而每个 ID 则对应 4 张行人图片。在训练阶段中，采用了随机梯度下降 (SGD) 优化器，将动量值设置为 0.9，动量衰减系数为 0.0005。在学习率方面使用了 warm up 训练技巧，学习率初始值为 $3e-4$ ，在前 10 个 epoch，学习率从 $3e-4$ 逐渐增加到 $3e-2$ 。在 10 到 60 个 epoch 之间，学习率保持为 $3e-2$ 。在 60 到 130 个 epoch 之间，学习率则维持为 $3e-3$ 。在 130 个 epoch 过后，学习率维持在 $3e-4$ 直至训练完毕。本章使用的训练框架是 PyTorch，所用的显卡型号为 NVIDIA GTX 2080Ti。每个实验在不同的数据集上，都保持着同一设置。

3.3.2 与 SOTA 方法比较

本章实验是基于 Market-1501、DukeMTMC-reID 和 CUHK03 进行的，所有实验均是基于单目标查询的设定，且在网络中没有应用 re-ranking^[35] 技巧。MSAN (ours) 代表了本章中所提出的网络模型，下面将与 SOTA 方法进行对比并予以简要分析。

(1) 在 Market-1501 上的对比结果

表 3.1 Market-1501 数据集上与 state-of-the-art 方法的对比结果

Method	Rank-1(%)	Rank-5(%)	Rank-10(%)	mAP(%)	References
ACRN ^[36]	83.6	-	-	62.6	CVPR2017
MGCAM ^[37]	83.6	-	-	74.3	CVPR2018
DPFL ^[38]	88.9	-	-	76	ICCV2017
MLFN ^[16]	90.0	-	-	74.3	CVPR2018
KPM ^[39]	90.1	96.7	97.9	75.3	CVPR2018
Mancs ^[40]	93.1	-	-	82.3	ECCV2018
PCB+RPP ^[8]	93.8	97.5	98.5	81.6	ECCV2018
AANet ^[41]	93.9	-	98.5	83.4	CVPR2019
SCPN ^[42]	94.1	97.7	-	81.8	ACCV2018
HPM ^[31]	94.2	97.5	98.5	82.7	AAAI 2019
HONet ^[43]	94.2	-	-	84.9	CVPR2020
OSNet ^[44]	94.8	-	-	84.9	ICCV2019
MSAN(ours)	96.1	98.4	99.1	88.6	

如表 3.1 所示，本文提出的方法在 rank-1 和 mAP 两个指标上获得了最高的实验结果。与同样采用局部特征学习的 PCB+RPP 方法相比，在 Market-1501 上，MSAN 的 rank-1 和 mAP 精度分别提高了 2.3% 和 7.0%。HPM 同样也是基于充分利用行人的不同局部空间信息以提升网络性能，与之相比，MSAN 在 Rank-1、Rank-5 和 Rank-10 上分别提高了 1.9%、0.9% 和 0.6%，在 mAP 上提高了 5.9%。产生这样差距的主要原因是 HPM 网络没有有效利用多尺度特征，也没有运用注意力机制进行关键特征的聚焦。

(2) 在 DukeMTMC-reID 上的对比结果

在 DukeMTMC-reID 数据集上与 state-of-the-art 方法的对比实验结果如表 3.2 所示。在实验数据表中可以发现，MSAN 网络在 Rank-1 和 mAP 两个指标上分

别取得了 89.7%和 79.5%的实验精度,超过了表中其他方法。其中,深度多分支网络 MGN 也是充分利用了全局特征与局部特征,但其模型复杂度较高,MSAN 在 Rank-1 和 mAP 上较 MGN 增加了 1.0%和 1.1%,且 MSAN 的网络结构相对也较为简单,再次表明了其先进性。

表 3.2 DukeMTMC-reID 数据集上与 state-of-the-art 方法的对比结果

Method	Rank-1(%)	mAP(%)	References
AACN ^[9]	76.84	59.25	CVPR2018
DPFL ^[38]	79.2	60.6	ICCV2017
MLFN ^[16]	81.0	62.8	CVPR2018
PCB ^[8]	83.3	69.2	ECCV2018
GP-reid ^[45]	85.2	72.8	ICGIP2017
AANet-50 ^[41]	86.4	72.6	CVPR2019
HPM ^[31]	86.6	74.3	AAAI2019
DG-Net ^[46]	86.6	74.8	CVPR2019
HONet ^[43]	86.9	75.6	CVPR2020
BFENet ^[47]	88.7	75.8	-
MGN ^[30]	88.7	78.4	ACM2018
MSAN(ours)	89.7	79.5	

(3) 在 CUHK03 上的对比结果

表 3.3 CUHK03 数据集上与 state-of-the-art 方法的对比结果

Method	Detected		References
	Rank-1(%)	mAP(%)	
DPFL ^[38]	40.7	37.0	ICCV2017
SVDNet ^[3]	41.5	37.3	ICCV2017
HA-CNN ^[10]	41.7	38.6	CVPR2018
MLFN ^[16]	52.8	47.8	CVPR2018
PCB ^[8]	63.7	57.5	ECCV2018
Mancs ^[40]	65.5	60.5	ECCV2018
HPM ^[31]	63.9	57.5	AAAI2019
MSAN(ours)	72.2	68.6	

CUHK03 是三个数据集中最具挑战性的数据集，其图像质量较低并且图像标签错误率较高。如表 3.3 所示，在 CUHK03 的 Detected 子数据集下，MSAN 在 Rank-1 和 mAP 上达到了 72.2%和 68.6%的精度。与 HPM 相比，MSAN 在 Rank-1 和 mAP 上高出 8.3%和 11.1%。与 Mancs 相比，在 Rank-1 和 mAP 上高出了 6.7%和 8.1%。

综上所述，在 Market-1501、DukeMTMC-reID 和 CUHK03 三个标准数据集上相比其他 SOTA 方法而言，MSAN 的实际的实验结果均有了一定的提高，尤其是在最具挑战性的 CUHK03 数据集上。通过上述对比实验验证了 MSAN 的有效性与先进性。

3.3.3 消融实验

为了进一步验证 MSAN 中的特征提取分支与特征处理模块的有效性，我们在 Market-1501 和 DukeMTMC-reID 两个数据集进行了大量的消融实验。在本节中，将从分支消融实验和模块消融实验两个方面展开实验与分析。

(1) 对 MSAN 各分支的消融实验

表 3.4 MSAN 网络各特征提取分支的消融实验

Method	Market-1501		DukeMTMC-reID	
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
MSAN(w/o global branch)	95.6	87.8	89.4	78.5
MSAN(w/o local branch)	95.7	87.1	88.0	76.4
MSAN(w/o shallow feature branch)	95.0	86.3	88.4	76.8
MSAN(ours)	96.1	88.6	89.7	79.5

如表 3.4 所示，具有完整结构的 MSAN 网络为 MSAN (ours)。w/o 代表无，在 MSAN 网络上分别移除了浅层特征学习分支、局部特征学习分支和全局特征学习分支后，将这些变体分别命名为 MSAN (w/o global branch)、MSAN (w/o local branch) 和 MSAN (w/o shallow feature branch)。在 Market-1501 数据集上，与这三个结构不完整的网络相比，MSAN (ours) 在 mAP 指标上分别超出 0.8%、1.5%、2.3%，在 DukeMTMC-reID 上分别超出 1.0%、3.1%、2.7%。这意味着每一类特征学习分支的设计都有助于提高模型的性能，可以通过整合所有分支来进一步提高模型的整体性能。

(2) 对 MSAN 各类型模块的消融实验

表 3.5 MSAN 中各类型模块的消融实验

Method	Market-1501		DukeMTMC-reID	
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
MSAN(only GAP)	94.7	87.4	88.7	77.6
MSAN(only GMP)	95.2	87.3	88.6	77.4
MSAN(w/o reduction)	95.6	86.3	88.9	77.6
MSAN(w/o channel-attention)	95.8	88.0	89.8	79.2
MSAN(w/o spatial-attention)	95.7	88.4	89.8	79.5
MSAN(channel attention+GAP)	95.1	88.2	76.6	59.2
MSAN(channel attention+GMP)	95.6	88.3	89.3	79.1
MSAN(w/o Bottleneck)	96.1	88.2	89.6	78.8
MSAN(ours)	96.1	88.6	89.7	79.5

如表 3.5 所示, 本节实验分别去掉了 MSAN 的各种模块并记录了去掉各类型模块后的模型的性能, 用来验证 MSAN 中设置的各类模块的有效性。在 PFCA 模块中去掉通道注意力模块且只保留了单一的池化方式, 称之为 MSAN (only GMP) 和 MSAN (only GAP)。将 PFCA 模块中的通道注意力模块从 MSAN 中移除, 命名为 MSAN (w/o channel-attention)。将移除空间注意力模块后的 MSAN 命名为 MSAN (w/o spatial-attention)。在 PFCA 模块中只利用单一的池化方式而不采用池化融合, 分别称为 MSAN (channel attention+GAP) 和 MSAN (channelattention+GMP)。然后, 将 MSAN 浅层特征学习分支中设置的 BottleNeck 模块去掉后, 称为 MSAN (w/o Bottleneck)。MSAN (w/o reduction) 表示在降维模块中去掉了全连接层, 等同于不对特征向量进行降维处理。通过实验发现, 使用单一的池化方法代替 PFCA 模块中的池化特征融合模块会降低模型的整体性能, 在 DukeMTMC-reID 数据集上 MSAN (ours) 比 MSAN (channel attention+GMP) 和 MSAN (channel attention+GAP) 在 Rank-1 上分别提高了 0.4% 和 13.1%, 在 mAP 上分别提高了 0.4% 和 20.3%, 这验证了在 PFCA 模块中通道注意力与池化特征融合模块的组合使用是有效的。通过进一步观察发现, 在 Market-1501 数据集上, 从 PFCA 模块中分别移除了通道注意力模块和降维模块的网络 MSAN (w/o channel-attention) 和 MSAN (w/o reduction), 与 MSAN (ours) 相比 rank-1 分别降低了 0.3% 和 0.5%, mAP 则分别降低了 0.6% 和 2.3%, 这进一步验证了 PFCA 模块设计的合理性和有效性。综上所述, 从 MSAN 中移除任何类型的模块则只能获得有限的性能, 这意味着 MSAN 的每个模块都可以有效地提高模型的最终性能, 而各个模块的组合使用将使模型的性能

能达到最大化。

3.4 本章小结

本文提出了一种基于多特征融合的多尺度注意力行人重识别网络，该网络可以有效的提取不同网络深度的多尺度特征，并结合全局和局部特征得到高鉴别性和鲁棒性的特征嵌入，形成用于预测行人身份的特征描述子。本章主要介绍了网络的多尺度特征学习结构和多尺度注意力机制。前者利用网络的多个分支去学习不同层次的语义信息，以获得具有鲁棒性和鉴别性的特征信息。后者是指在网络的不同位置使用空间注意力模块和 PFCA 模块，使网络更加关注重要的行人区域。通过大量的实验验证，采用这种网络架构可有效提高模型对图像变化的抗干扰能力，进而提升了行人重识别性能。

第四章 基于多尺度特征学习的双流行人重识别网络

在上一章的工作中，通过融合卷积注意力模块构建了一种多尺度注意力网络，可更加聚焦于不同深度的关键行人特征线索并进行提取，经过有效融合得到具有较强辨识性与鲁棒性的最终特征。目前，基于多尺度特征学习的相关方法还是一类潜在的、更有判别力的特征描述方式。本章将在上一章工作的部分基础上对多尺度特征学习方法作进一步研究，将研究重心放在提取更大范围上的有效多尺度特征上，完善特征学习的多样性，提高模型的精度。基于此，得出本章的所有分析和讨论。

4.1 引言

得益于深度学习技术的发展，基于深度学习的行人重识别研究工作已获得了极大的推进。但是由于拍摄场景复杂化，出现了姿态变化、行人被遮挡、分辨率低等问题，致使一些缺乏鲁棒性的网络提取不到足够的判别特征，进而导致重识别效果不佳，这是行人重识别领域一直以来的难题。

基于多尺度特征的方法^[11, 35, 44]在计算机视觉领域中被广泛应用，将多尺度特征学习技术融入到行人重识别任务中，同样也能够达到不俗的成效。多尺度特征学习能对不同尺度空间上的行人语义特征进行提取，进而提升特征的表达能力。多粒度特征学习在一定程度上可以改善特征细节不足的问题，类似于文献^[30]所提出的MGN模型，这类特征金字塔方法构建了大量的特征提取分支来尽可能多的获取行人的全局与局部特征信息，利用全局特征和局部细节特征相结合、相补充的方式来提取更多的有效性特征信息，对行人进行了多粒度描述。并且，MGN利用分类损失函数、三元组损失函数共同优化网络，构建多任务学习，取得了不俗的效果。从全局特征信息到局部特征信息，不同阶段不同粒度的特征能够表示不同程度的视觉信息，通过扩展多分支网络对不同尺度空间与不同粒度的特征进行有效提取，已经成为一个重要的研究方向。

提取更高辨识度的行人特征是增强模型在姿态变化、行人不对齐、遮挡等状况下特征表达能力的必经之路。从多个语义层次学习视觉不变特征，融合不同尺度、不同粒度的判别信息完善特征学习，挖掘更加全面丰富的行人信息，则是提高特征辨识度的一个很好的思路。基于此目的，本章提出了一种基于多

尺度特征学习的双流行人重识别网络（Double-flow person re-identification network based on multi-scale feature learning），简称 DFMS。DFMS 网络是一个端到端的双子网多分支的深层网络，通过提取更多尺度空间上的全局与局部特征来捕获更为全面、丰富的行人判别性信息，结合不同尺度的特征线索对行人特征做更为完整的描述，从而在一定程度上解决判别信息缺失的问题，进而降低图像问题带来的不良影响。DFMS 的每个子网都是深度多分支网络，不仅可以对三个不同尺度空间上的全局特征进行有效学习，从宏观角度对行人显著的全局线索进行把握，而且我们引导第二个子网络去学习更加精细的行人局部特征描述，将其作为全局特征的重要补充，以此构成的差异化特征提取使得各子网络在特征提取方面互为补充、增强。所有分支所提取的特征将在最终阶段融合为一个包含丰富信息的特征描述子，用于行人的特征匹配。

4.2 基于多尺度特征学习的双流网络模型

在本小节中，首先对 DFMS 所采用的多尺度特征学习结构进行介绍，主要是阐述了子网络各特征提取分支的设计思路。然后介绍了 DFMS 的整体网络结构，并对网络中的特征处理细节进行了详细描述。接着，对分支中的特征后处理模块进行了说明。最后部分则介绍了本章网络使用的三元组损失函数，并结合模型分析了网络最终的损失函数及其计算公式。

4.2.1 多尺度特征学习结构

仅利用单一尺度的特征图提取出的特征是不全面的，易受复杂场景下各类图像问题的影响。在 DFMS 中，多尺度特征学习的实现依赖于各类特征提取分支，实际上就是不同分支提取出不同尺度的特征线索的过程，不同尺度的特征能表示不同的信息。DFMS 的两个子网络均以深度残差网络 ResNet50 作为骨干网络，并将 ResNet50 最后的平均池化层和全连接层去掉，这样可以得到更大尺寸的特征图来提取更多的特征信息。DFMS 以 ResNet50 中的 layer3 和 layer4 两层末端所输出的特征图作为基准，有效的缓解仅利用高层特征造成的空间几何特征细节的缺乏问题。我们在每个子网络中设计了四种旨在学习不同尺度的特征信息的特征提取分支。其中，layer4 特征对语义信息表征能力最强，第一、二类分支即为针对 layer4 这一深度层的两个不同尺寸特征图的全局特征提取分支。第三类分支是局部特征提取分支，由于在两个子网络中局部特征条块分割数目不同，所以局部分支的数量也各不相同。第四类是浅层特征提取分支，用于提取 layer3 末端输出的浅层特征图中的潜在的语义信息，包含有效的域不变的判

别特征，浅层特征是一种细粒度的全局特征，实际上浅层特征提取分支面向的也是全局级的特征。DFMS 网络中的每类分支都是基于不同的提取目的进行设计的，每条分支都可以提取不同尺度或不同种类的行人特征线索，这样的双子网多分支结构扩大了特征的采样范围，使模型在逐步迭代训练的过程中，每个分支能够更多地关注其负责的行人特征区域，提高了所提取特征的全面程度。

4.2.2 整体结构设计

为了从不同尺度上提取到更丰富的行人特征，我们将 DFMS 构建为双流多分支网络，即在整体网络结构中设置两个独立的子网络，分别称为 subnet1 和 subnet2，二者不共享参数，所面向的局部特征粒度不同，每个子网都可以独立完成鉴别性特征的提取。DFMS 的每个分支上都设置了 Bottleneck 层与池化融合模块，作为特征处理单元来提高模型的最终性能。在 subnet1 和 subnet2 中，浅层特征提取分支用于提取 layer3 输出的浅层特征，将其作为全局特征信息的细粒度补充。layer4 特征图包含较为完整的行人信息，作为主要的特征源，针对不同特征尺寸的两条全局特征提取分支分别对其进行特征提取。其中，在第二条全局特征提取分支上会将 layer4 特征图先进行均值池化操作，得到一个高度为原来二分之一的特征图，这样采用相同结构的两条全局特征提取分支对池化前后的两个不同特征尺寸的特征图实现全局级别的有效特征提取，实现了对同一深度不同尺度空间下的全局特征的学习，使得网络可以学习到更多的粗粒度特征线索。值得注意的是，两个子网络对于局部特征的提取有所不同，在 subnet1 中使用了水平切片法，把 layer4 输出的全局特征图均等地分成了两块，两条局部特征提取分支则分别从这两个特征块中提取到行人的局部特征，独立地学习局部特征表示。为了使网络能够提取到更加精细的行人局部区域特征，在 subnet2 中则将 layer4 输出的特征图均等分割为三份，并在 subnet2 中设置三条局部特征提取分支分别对三个特征条块进行更细粒度的局部线索挖掘。在局部特征的分割方面，随着分割出的特征条块数量的增加，局部特征更加集中于在每个特征条块中包含的更精细的判别信息。DFMS 采用这样的多尺度特征学习架构可以充分利用不同尺度的不同特征，获得更为完整的局部与全局特征线索，当输入的图像受到模糊或光照和姿态等影响时，利用这些丰富的多尺度信息进行综合判别，增强所提取特征的鉴别性和鲁棒性，以更好地识别正确的行人。

DFMS 的网络结构如图 4.1 所示，行人图像作为训练样本输入到子网络 subnet1 和 subnet2 中分别提取行人特征。来自 layer4 的特征图 T_2 进入第一条全局特征提取分支并随后分流给第二条全局特征提取分支。来自 layer3 的特征图 T_1 进入浅层特征提取分支用于浅层全局级特征嵌入。在 subnet1 中，特征图 T_2 被分

割为两条均等的特征张量块后分别进入两条局部特征分支。在 subnet2 中, 特征图 T_2 则被分割成三份均等特征张量块, 然后分别进入 subnet2 的三条局部特征提取分支。在 DFMS 网络中的每条分支中提取到的特征最终都在分支末端计算出分类损失作为独立的监督信号。




图 4.1 基于多尺度特征学习的双流网络结构示意图

具体来说, 首先输入一个尺寸为 $[N, C, H, W]$ 的特征张量, N 代表 batchsize, C 代表通道数量, H 表示高度, W 表示宽度。此特征张量在输入到每个子网的骨干网 ResNet50 中后, 依次经过 layer1、layer2、layer3、layer4 的特征处理和提取, 我们可以从中得到 4 组尺寸不同的特征图。我们选择由 layer3 和 layer4 分别输出的尺寸为 $[N, C_1, H_1, W_1]$ 的特征图 T_1 以及尺寸为 $[N, C_2, H_2, W_2]$ 的特征图 T_2 进行进一步的特征提取。浅层特征提取分支提取来自 layer3 的浅层特征图 T_1 的细粒度全局信息。两条全局特征提取分支针对 layer4 的特征图的全局特征信息进行有效提取, 但后者提取的是经过平均池化层下采样后的尺寸为 $[N, C_2, H_2/2, W_2]$ 的特征图中的特征线索。同时, 局部特征提取分支也以 layer4 输出的特征图 T_2 为基准, 在 subnet1 中按垂直方向将其均等分割为两个尺寸为 $[N, C_2, H_2/2, W_2]$ 的特征块, 在 subnet2 中则是分割为三个尺寸为 $[N, C_2, H_2/3, W_2]$ 的特征块, 各子网络中对应的局部分支将分别提取每一个特征块中的局部细节信息。

在子网络的每条特征提取分支中, 特征张量都首先使用 Bottleneck 模块进行特征降维处理, 减少特征参数量从而减少网络计算量。然后, 将特征图输入至池化融合模块进行特征增强处理, 池化融合模块的主要特点是使用了全局平均

池化 (GAP) 和全局最大池化 (GMP) 各自的优点, 具体是将两个池化后的特征向量进行逐元素相加, 形成融合后的特征图。以 subnet1 为例, 输入到浅层特征提取分支中的特征图首先进入池化融合模块, 经过 GAP+GMP 融合为一个 1024 维的特征向量 F_1 , 输入到两条全局特征提取分支的两个特征张量经过池化融合模块后, 得到两个 2048 维的全局特征向量 F_2 和 F_3 , 输入到两条局部特征提取分支中进行池化融合模块后, 则分别得到 2048 维的局部特征向量 P_1 和 P_2 。然后再对这些特征向量进行通道降维, 降维层是由 1×1 卷积层, 以及 batch normalization 层和 Leaky ReLU 激活函数构成。其中, 特征向量 F_1 会降维成一个 256 维的特征向量 f_1 , F_2, F_3, P_1, P_2 会降维成 512 维特征向量 f_2, f_3, p_1, p_2 。与 f_1, f_2, f_3 相对应, 在 subnet2 中经降维处理过后的三个全局特征向量为 s_1, s_2, s_3 , 三个局部特征向量则称为 k_1, k_2, k_3 。DFMS 是由两个子网络构成的, 所以最后将会得到 2 个 256 维的特征向量和 9 个 512 维的特征向量。subnet1 和 subnet2 所有分支的共计 11 个特征向量在通道维度融合为一个 5120 维的特征向量, 然后将其降维至 512 维, 即特征向量 x_1 。同时 f_1, f_2, s_1, s_2 在通道维度融合为 1536 维的特征向量, 然后降维处理为一个 512 维的特征向量 x_2 用于计算批难样本三元组损失, 在最终阶段我们利用包括 $\{f_1, f_2, f_3, p_1, p_2, s_1, s_2, s_3, k_1, k_2, k_3, x_1\}$ 在内的共计 12 个特征向量用于 softmax 损失的计算, 相当于计算分类损失。同时利用包括 $\{f_1, f_2, f_3, s_1, s_2, s_3, x_2\}$ 在内的共计 7 个特征向量用于计算批难样本三元组损失。

在训练阶段, 本章所设计的 DFMS 网络会通过 12 个 softmax 损失函数和 7 个批难样本三元组损失函数进行联合优化。在推理阶段, DFMS 的所有分支提取到的共计 12 个特征向量会在通道维度上合并为一个用于预测行人身份的特征描述子。

4.2.3 损失函数

本章的 DFMS 网络所运用的损失函数与第三章中提出的 MSAN 网络有所不同, 为了提取到具有辨识力的特征, DFMS 采用了 softmax 损失函数和批难样本三元组损失函数联合训练的方法来优化模型。DFMS 中的分支比 MSAN 网络更多, 意味着 DFMS 使用了更多数量的损失函数进行端到端的监督训练。在第三章中详细介绍了 softmax 交叉熵损失函数的概念、参数分析以及计算公式, 所以在本章对基础三元组损失函数和难样本三元组损失函数以及最终损失函数分别进行介绍。

(1) 基础三元组损失函数

三元组损失函数是一种度量损失函数, 主要作用在特征空间中的样本分布。三元组损失函数中的三元分别指 Anchor、Positive 和 Negative, 在训练集上首先

随机选择一个样本 **Anchor**，再为该样本随机选择一个同类的正样本 **Positive**，最后随机选择一个异类的负样本，命名为 **Negative**。三元组损失函数将会使 **anchor** 和 **positive** 之间的距离愈来愈小，而 **anchor** 和 **negative** 的间距也将会愈来愈大，进而达到同类相聚，异类拉远的效果，其示意图如图 4.2 所示。




图 4.2 三元组损失函数示意图

Anchor, **Positive**, **Negative** 分别记作 a 、 p 、 n ，在训练阶段，首先把三元组样本输入到特征提取网络中来分别取各样本特征，然后计算损失，损失计算如公式 (4.1) 所示：

$$L_{triplet} = \frac{1}{N} \sum_{\substack{a,p,n \\ y_a=y_p \neq y_n}} [m + d_{a,p} - d_{a,n}]_+ \\ d_{i,j} = D(f_{\theta}(x_i), f_{\theta}(x_j)) \quad (4.1)$$

其中， $f_{\theta}(x)$ 表示网络提取出的图像特征， $D(\cdot, \cdot)$ 则代表两个样本特征之间的欧式距离， m 则为一个阈值。在训练阶段，三元组损失函数的函数值在训练过程中持续变小，惩罚了同类样本之间的特征间距与不同类样本之间距离的差值，使得该距差值大于阈值 m ，使相同标签的图像特征能够在特征空间上聚集，而不同标签的的图像特征间距被拉远，从而实现了优化样本特征距离的目的。但是随机的选取方法仍然会有相当几率选取了初始特征间距过近的同类数据样本 p ，以及初始特征距离过远的异类样本 n ，这种简单的三元组形式会导致特征空间得不到有效的优化。

(2) 难样本三元组损失函数

难样本三元组损失引入了困难样本采样策略，其主要目的是为了改良网络的收敛效果。具体而言，每个 **batch** 会挑选出 K 类样本，每一类样本中再选取 N 幅图片。其特殊之处在于对于一个锚定样本来说，一般都会挑选出一个与其相

似度最低的正样本和一个相似度最大的负样本构成三元组。最终难样本三元组损失的计算如公式（4.2）所示：

$$L_{BHTri} = \frac{1}{PK} \sum_{i=1}^{PK} \left[m + \max D(f_{\theta}(x_i^a), f_{\theta}(x_i^p)) - \min D(f_{\theta}(x_i^a), f_{\theta}(x_i^x)) \right]_+ \quad (4.2)$$

公式（4.2）中， $\max$ 代表在一个 batch 中最大的正样本距离， $\min$ 则代表在一个 batch 中最小的负样本距离。难样本三元组损失函数强化了网络对于某些复杂的难样本特征的表征能力，有助于提高训练网络的分类能力，增加学习算法的计算效率，有利于网络学习到更好的特征表示。

（3）最终损失函数表达式

本章所提出的 DFMS 网络在训练阶段采用的是交叉熵损失函数和难样本三元组损失函数相结合的多任务学习策略。整个网络模型使用了 12 个 softmax 损失函数和 7 个批难样本三元组损失函数。因此，最终完整的损失函数公式可以表示为：

$$L_{total} = \sum_{s=1}^{12} L_{id}^s + \alpha \sum_{t=1}^7 L_{BH}^t \quad (4.3)$$

4.3 实验结果及分析

本节将从实验角度来分析验证本章所提出的 DFMS 网络。首先对网络训练时采用的实验设置加以说明。紧接着，将 DFMS 和多个 SOTA 方法的实验结果进行对比。最后，对 DFMS 的子网、分支、模块、损失函数等方面进行消融实验以显示方法的合理有效性，并在本节末尾将 DFMS 与第三章提出的 MSAN 网络在实验角度进行对比，并依此分析二者的特点与不同点。本章中的所有实验都是在 Market-1501、DukeMTMC-reID 和 CUHK03 进行的。

4.3.1 实验设置

在 DFMS 的网络训练阶段，所有的样本的图像尺寸将会调整为 384×128 像素，并进行水平翻转操作来增加数据集的样本量。在推理阶段，只将图像尺寸变成 384×128 像素，不实现水平翻转。

为了提高网络的训练速度，骨干网 ResNet50 是经过 ImageNet 数据集预训练

过的。DFMS 网络整体上有 11 个分支，浅层特征提取分支的特征经过降维处理后得到 256 维的特征向量，全局与局部特征提取分支的则为 512 维的特征向量。DFMS 中的一个 batch 包含 64 张行人图像，batch 的大小由 $P \times K$ 决定， P 代表了一个 batch 中行人图像的 ID 数， K 则代表了每个 ID 的行人对应的样本数量。本节实验中设置 $P = 16$ 且 $K = 4$ 。

在训练阶段，引入了 Adam 作为优化器，其动量值为 0.9，参数衰减值为 $5e-4$ 。损失函数则由 triplet loss 和 softmax loss 共同构成，超参数 α 的取值是 1， m 的取值为 0。整个模型一共训练了 700 个 epoch，而且在训练时引入了 warm-up 训练策略。在开始的 50 个 epoch 内，学习率 LR 从 $1e-4$ 增加到了 $1e-3$ ，在 50 到 200 个 epoch 间的学习率则保持为 $1e-3$ 。200 到 500 个 epoch 间学习率会降至 $1e-4$ ，最后学习率则维持在 $1e-5$ 直至 700 个 epoch。本章节的所有实验都统一在 NVIDIA RTX 2080Ti GPUs 上进行，基于 PyTorch 平台完成，对不同的数据集实验参数保持一致，都使用了 single-query 的设定。为了公平的实验对比，所有实验均未使用 re-ranking 技术。

4.3.2 与 SOTA 方法比较

(1) 在 Market-1501 上的测试结果

在 Market-1501 数据集上，本章所设计的 DFMS 网络与其他 SOTA 方法的对比结果如表 4.1 所示。通过实验数据可以发现，DFMS 在 Rank-1 和 mAP 上得到了 95.9%和 88.1%的实验精度，超过了其他方法。相对于 SCPNet、HPM 和 OSNet，DFMS 在 rank-1 和 mAP 上分别超过其+1.8%/+6.3%、+1.7%/+5.4%和 +1.1%/+3.2%。即使与近期顶级会议上提出的先进方法 CDNet 相比，本章提出的 DFMS 依然超过其+0.8%/+2.1%，这很好地证明了 DFMS 的先进性。本章所提出的方法与上述 SOTA 方法相比，在 Rank-1 和 mAP 两个主要重识别指标上，均取得了最好的效果。

表 4.1 与 state-of-the-art 方法的对比结果

Method	Market-1501		DukeMTMC-reID		References
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)	
DaRe ^[48]	89.0	76.0	80.2	64.5	CVPR2018
MLFN ^[16]	90.0	74.3	81.0	62.8	CVPR2018
KPM ^[39]	90.1	75.3	80.3	63.2	CVPR2018
PSE ^[35]	90.3	84.0	85.2	79.8	CVPR2018
PCB ^[8]	92.2	81.2	81.9	72.8	ECCV2018

Manacs ^[40]	93.1	82.3	84.9	71.8	ECCV2018
DeepCRF ^[49]	93.5	81.6	84.9	69.5	CVPR2018
PCB+RPP ^[8]	93.8	81.6	83.3	69.2	ECCV2018
SCPNet ^[42]	94.1	81.8	84.8	68.5	ACCV2018
HPM ^[31]	94.2	82.7	86.6	74.3	AAAI2019
OSNet ^[44]	94.8	84.9	88.6	73.5	ICCV2019
DG-Net ^[46]	94.8	86.0	86.6	74.8	CVPR2019
MMGA ^[11]	95.0	87.2	89.5	78.1	CVPR2019
MGN ^[30]	95.7	86.9	88.7	78.4	ACM2018
HONet ^[43]	94.2	84.9	86.9	75.6	CVPR2020
CDNet ^[50]	95.1	86.0	88.6	76.8	CVPR2021
DFMS	95.9	88.1	89.6	78.5	

(2) 在 DukeMTMC-reID 上的测试结果

表 4.1 中介绍了本章所提出的网络模型 DFMS 在 DukeMTMC-reID 数据集上的实验结果及 state-of-the-art 方法的结果。DFMS 在 Rank-1 和 mAP 上取得了 89.6%和 78.5%的精度，相比于 Manacs 和 HPM，在 Rank-1 和 mAP 分别提高了 +4.7%/+6.7%和+3.0%/+4.2%，验证了 DFMS 网络的有效性与先进性。

(3) 在 CUHK03 上的测试结果

表 4.2 CUHK03 数据集上与 state-of-the-art 方法的对比结果

Method	CUHK03-Detected		CUHK03-Labeled		References
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)	
DPFL ^[38]	40.7	37.0	43.0	40.5	ICCV2018
SVDNet ^[3]	41.5	37.3	-	-	ICCV2017
HA-CNN ^[10]	41.7	38.6	44.4	41.0	CVPR2018
PCB+RPP ^[8]	63.7	57.5	-	-	ECCV2018
HPM ^[31]	63.9	57.5	-	-	AAAI2019
Manacs ^[40]	69.0	63.9	65.5	60.5	ECCV2018
MGN ^[30]	66.8	66.0	68.0	67.4	ACM2018
MSCAN ^[51]	67.9	-	74.2	-	CVPR2017
OSNet ^[44]	72.3	67.8	-	-	ICCV2019
DFMS(Ours)	78.9	76.4	81.1	78.4	

表 4.2 中介绍了本章提出的 DFMS 网络在 CUHK03 中的 Detected 和 Labeled 两个数据集上的实验结果。在 Detected 数据集上, 本章的方法在 Rank-1 和 mAP 上超过了 OSNet 和 MGN +6.6%/+8.6%和+12.1%/+10.4%。在 Labeled 数据集上, MGN 的实验精度是最高的, 而 DFMS 在 Rank-1 和 mAP 上比 MGN 方法提升了 +13.1%/+11.0%的精度, 再一次验证了本章方法的先进性。

4.3.3 消融实验

本节的主要目的是在 DFMS 的子网络、特征提取分支、特征后处理模块、多任务学习等方面来检验 DFMS 网络的有效性 & 设计合理性, 而 DFMS 的具体的消融实验将在 Market-1501 数据集和 DukeMTMC-reID 数据集上展开。

(1) DFMS 与子网络对比实验

DFMS 采用双流网络结构, 表 4.3 中展示了两个子网络与 DFMS 网络的对比实验。在 Market-1501 数据集上, 本章提出的 DFMS 网络在 Rank-1 和 mAP 两个指标上比 subnet1 提高了 0.8%和 1.6%, 比 subnet2 提高了 1.1%和 1.8%。在 DukeMTMC-reID 数据集上, DFMS 比 subnet1 提高了 0.7%和 1.9%, 比 subnet2 提高了 1.0%和 2.1%。由此可见, 使用双流网络结构的 DFMS 的网络性能优于子网络 subnet1 和 subnet2, 这是因为 DFMS 采用的双子网结构能够扩大特征采样范围, 设计了更多的分支来提取更多的有效特征以强化特征表示, 并且 DFMS 的两个子网具有差异化的特征提取能力, 可捕获不同粒度的局部特征, 二者的组合使用有效提高了模型的泛化能力。

表 4.3 DFMS 与子网络对比实验

Method	Market-1501		DukeMTMC-reID	
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
Subnet1	95.1	86.5	88.9	76.5
Subnet2	94.8	86.3	88.6	76.3
DFMS	95.9	88.1	89.6	78.4

(2) 对不同网络深度特征的对比实验

DFMS 网络对不同深度的特征图进行了有效多尺度特征的提取, 为了进一步验证 DFMS 利用 layer3 和 layer4 特征是合理有效的, 本节对 ResNet50 不同深度特征的有效性进行了实验分析。

表 4.4 Market-1501 上对不同网络深度特征的对比实验

Method	Layer1	Layer2	Layer3	Layer4	Rank-1(%)	mAP(%)
subnet1	√	√	√	√	91.9	79.0
		√	√	√	94.6	84.9
			√	√	95.1	86.5
				√	94.9	85.0
subnet2	√	√	√	√	91.3	78.5
		√	√	√	94.2	84.2
			√	√	94.8	86.3
				√	94.4	84.3
DFMS				√	95.4	86.9
			√	√	95.9	88.1

如表 4.4 所示，在子网络 subnet1、subnet2 及 DFMS 中同时使用来自 layer3 与 layer4 的特征图会取得最佳效果。对比提取不同 layer 层特征的实验结果可以发现，如果网络提取 layer1 和 layer2 的低层次特征，重识别精度反而有所下降。这是因为在 layer1 和 layer2 这样的低深度层中，网络的注意力集中于背景区域，包含了过多的背景信息，属于不可直接利用的非有效特征，从而在特征融合时影响了特征对行人的表达能力。与之相比，layer4 输出的特征图具有更高的抽象和语义表达能力，使得网络可以聚焦于目标区域以提取最丰富的行人特征信息。但是，仅利用 layer4 的深层特征而忽略掉 layer3 特征图所包含的行人细粒度信息，则会限制网络性能的进一步提升。综上所述，在 DFMS 网络中同时利用 layer3 和 layer4 的特征图是最佳策略。

（3）不同特征提取分支的有效性实验

表 4.5 对不同特征提取分支的有效性实验

Method	Market-1501		DukeMTMC-reID	
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
DFMS(no part)	95.1	87.8	88.8	77.3
DFMS(no layer3)	95.4	86.9	88.2	76.1
DFMS(no Global-1)	95.5	87.5	88.9	77.2
DFMS(no Global-2)	95.7	87.7	89.1	77.3
DFMS(Stripe-3-3)	94.8	85.8	88.4	75.9
DFMS(Stripe-2-2)	95.7	87.8	89.3	77.8

DFMS(Stripe-2-4)	95.4	85.8	88.8	76.7
DFMS(Stripe-2-6)	95.2	85.7	89.5	78.2
DFMS	95.9	88.1	89.6	78.4

表 4.5 展示了对不同特征提取分支的有效性实验。在实验中, 首先将 DFMS 中的局部特征分支、浅层特征分支、第一条全局特征分支、第二条全局特征分支逐一去除, 分别对应表 4.5 中的 DFMS (no part)、DFMS (no layer3)、DFMS (no Global-1) 和 DFMS (no Global-2)。在 Market-1501 上, 结构完整的 DFMS 网络在 Rank-1 和 mAP 上超过 DFMS (no Global-1) +0.4%/+0.6%, 在 DukeMTMC-reID 上超过 DFMS (no Global-1) 与 DFMS (no Global-2) +0.7%/+1.2%和+0.5%/+1.1%, 验证了在 DFMS 网络中提取同一深度的不同尺寸的全局特征这一方法是有效的。此外, 在 Market-1501 上, DFMS 在 Rank-1 和 mAP 上超过 DFMS (no part) +0.8%/+0.3%, 在 DukeMTMC-reID 上超过 +0.8%/+1.1%, 验证了在 DFMS 中采用局部特征学习的有效性。将 DFMS 的各类分支进行组合使用将达到最佳识别效果, 充分验证了 DFMS 网络的各特征提取分支设计的合理性与有效性。

如表 4.5 所示, 本节对不同的局部条块数量也进行了对比实验。Stripe-X-Y 表示在子网络 subnet1 中将 layer4 所输出的特征图分割为 X 等份, 并依此设置 X 个局部特征分支, 在 subnet2 中则分割为 Y 等份, 并依此设置了 Y 个局部特征分支。根据实验结果可以得出, 当 X=2 而 Y=3 时, 网络会达到最佳效果。当 subnet1 和 subnet2 的局部条块数分别为 2 和 3 时, 局部分割粒度呈现递进式变化, 引导 DFMS 网络捕获由粗粒度到细粒度的局部特征信息, 避免了因分割粒度差别过大而导致严重的特征不对齐问题。

(4) 多任务学习有效性实验

表 4.6 多任务学习有效性实验

Method	softmax	Triplet	Market-1501		DukeMTMC-reID	
	Loss	Loss	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
Subnet1	√		94.3	83.2	87.7	72.5
Subnet1	√	√	95.1	86.5	88.9	76.5
Subnet2	√		94.2	84.4	87.5	72.4
Subnet2	√	√	94.8	86.3	88.6	76.3
DFMS	√		95.4	86.1	88.6	74.5
DFMS	√	√	95.9	88.1	89.6	78.4

为获得良好的重识别效果，DFMS 网络选择了分类任务与度量学习相结合的方法实现多任务联合学习，使用了 softmax loss 和 triplet loss 这两种损失函数共同训练模型。在 Market-1501 和 DukeMTMC-reID 上，进行的多任务学习有效性实验将检验每一类损失函数及其组合使用的有效性。

如表 4.6 所示，在 Market-1501 上，使用两种损失函数联合训练下的 DFMS 比仅用 softmax loss 训练的 DFMS 在 Rank-1 和 mAP 两个指标上提升了 +0.5%/+2.0%，在 DukeMTMC-reID 数据集上 Rank-1 和 mAP 分别提升了 +1.0%/+3.9%。经实验验证，DFMS 中使用 softmax loss 联合 triplet loss 的多任务学习策略提高了网络的识别效果。

（5）GAP 与 GMP 池化融合模块有效性实验

本小节将基于 DFMS 网络，分别对 GAP、GMP、GAP+GMP 这三个池化处理方法进行对比实验，以检验池化方法与融合模块的有效性，实验结果如表 4.7 所示。池化融合模块的具体操作是对经过 GAP 和 GMP 处理后的两个特征图进行相加操作来充分利用两种池化方法的优势。表 4.7 中实验结果证明，GAP 和 GMP 两种池化方式结合使用才能取得最好的重识别效果。

表 4.7 池化融合模块对比实验

GMP	GAP	Rank-1(%)	mAP(%)
	√	95.2	87.5
√		95.5	87.7
√	√	95.9	88.1

4.3.4 在 CUHK03 上与 MSAN 网络的对比实验

表 4.8 在 CUHK03 上与 MSAN 网络的对比实验

Method	CUHK03-Detected		CUHK03-Labeled	
	Rank-1(%)	mAP(%)	Rank-1(%)	mAP(%)
MSAN	72.2	68.6	73.8	71.9
DFMS	78.9	76.4	81.1	78.4

CUHK03 数据集存在清晰度较差、图像标签的较高错标率等问题，是一种较难识别的数据集，更接近于真实拍摄场景，在该数据集上将二者进行实验对比，则具有更强的说服力。如表 4.8 中所示，在 CUHK03-Detected 上，与 MSAN

相比, DFMS 网络在 Rank-1 和 mAP 上分别提高了 6.7%与 7.8%。在 CUHK03-Labeled 上, 分别提高了 7.3%与 6.5%。可以看出, 在 CUHK03 数据集上, DFMS 的重识别性能明显优于 MSAN。

MSAN 网络属于单流网络, 其核心思想是在网络中融合注意力模块促进模型自主学习关键区域。具体而言, MSAN 使用卷积注意力机制迫使网络聚焦于多个尺度上的关键特征区域, 强化了网络对行人关键特征的特征表达能力。DFMS 则采用双流网络架构, 不引入注意力机制进行辅助, 两个子网络分别独立提取多尺度的全局特征以及不同粒度的局部显著性特征, 各子网络本身就是独立的深度多分支网络, 这样的设计扩大了网络的特征采样范围, 使得网络可以在更多尺度空间上挖掘不同的行人信息。DFMS 的子网络所面向的局部特征的粒度不同, 可以捕获更多的区域级特征, 因此提取到的局部特征也更为精细。这样的设计使得 DFMS 对行人的特征表达更为完整、丰富。MSAN 网络只采用了分类损失函数来训练网络, DFMS 则采用了多任务学习法来优化训练模型, 对行人的特征描述更具有辨识力。但 DFMS 的网络结构更为复杂, 模型参数量也更大。

4.4 本章小结

本章提出了一种基于多尺度特征学习的双流行人重识别网络 DFMS。在 DFMS 的每个子网络中, 合理地设计了针对不同类型特征的提取分支, 各子网络所提取的特征包含了粗粒度、细粒度的全局特征与局部细节特征, 最后融合为辨识度较强的行人特征描述符, 增强对行人特征的表达能力。DFMS 各个分支提取的不同尺度空间上丰富的辨识信息, 提升了特征提取的全面程度, 进而减轻行人图像中存在的干扰性问题带来的影响, 提高了模型的精度。本章在整体网络结构、多尺度特征学习、多分支特征提取、多任务学习等方面对 DFMS 网络进行了详细的阐述和分析。通过在三个标准数据集上展开的大量实验验证了本章方法的设计是合理有效的。

第五章 总结与展望

5.1 工作总结

本文针对基于多尺度特征和深度多分支网络的行人重识别方法展开研究，以提取多尺度的行人鉴别性特征为出发点，提出了具有更强泛化能力的深度多分支网络模型。主要取得了以下两个研究成果：

（1）面对例如姿态变化、行人遮挡、视角变化等情形下形成的图像问题，卷积神经网络对行人图像提取的单一的全局特征具有特征判别信息不足的缺陷，易受图像问题的影响，忽略了可以作为有效特征信息的局部特征、浅层细粒度特征以及注意力机制的作用。本文提出了一种基于多特征融合的多尺度注意力行人重识别网络 MSAN。在 MSAN 中，通过设计多种类型的特征提取分支实现对全局特征、局部特征、浅层特征的提取，弥补全局特征判别力不足的缺陷。不仅如此，MSAN 通过引入卷积注意力模块使得网络更加聚焦于关键的行人特征，并基于通道注意力设计了 PFCA 模块，实现多尺度注意力处理功能，进一步提高了网络的性能。实验结果显示，MSAN 可以提取出具有更强判别力与鲁棒性的特征，从而取得了优异的行人重识别效果。

（2）在真实的行人重识别场景中，姿态变化、行人不对齐、图像模糊等情况时常发生，一直是行人重识别领域中的难题，想要缓解这些影响就要考虑如何提高网络所提取特征的判别力和鲁棒性。基于此目的，本文提出了一个端到端的基于多尺度特征学习的双流行人重识别网络 DFMS，通过联合使用两个独立的深度多分支网络，强化了模型的特征表达能力。具体来说，DFMS 通过子网络的多个分支对不同尺度上的全局特征与不同粒度的区域信息进行充分学习，子网络之间的差异性具体表现为各面向的局部特征的粒度不同。此外，DFMS 通过联合分类损失和度量学习损失构成多任务学习，从而增强模型的收敛能力。在检测阶段，将两个子网络提取出的特征进行有效融合形成最终的判别特征。最后通过在公开的大型行人重识别数据集上与近几年 SOTA 方法的对比实验来检验模型的有效性与先进性。

5.2 工作展望

本文对行人重识别的研究虽然有了一定进展，但是研究工作中还有许多待

完善之处，下一步的研究工作将从以下几点展开：

（1）局部特征与全局特征之间的深度融合。大量的 SOTA 方法已经证实，将全局特征与局部特征相结合，是提升行人重识别准确度的最有效手段。但是现有的办法只能是单纯地把两种特征进行简单合并。因此，如果考虑在特征融合阶段采取一种动态权重算法，根据不同分支求出的损失函数值动态调节特征融合的权重，改变最终特征向量中的特征信息分布，提高重要特征比重，弱化非重要特征比重，这可能会进一步提升行人重识别精度。

（2）浅层特征的有效利用。在本文提出网络模型中，只关注于提取骨干网 ResNet50 的 layer3 和 layer4 的特征图，并未考虑对更浅层次的特征图中包含的潜在有用信息进行有效提取。虽然这些特征感受野较小，包含较多的干扰性背景信息，属于未被充分处理的特征，但是其中依然存在潜在的有效细粒度语义信息。所以，应对浅层特征进行特征预处理，使之成为有效特征再进行提取，这是一个有潜力的研究方向。

（3）降低模型复杂度。DFMS 网络使用双流网络架构，伴随大量的特征提取分支的设计，且算法的时间和空间复杂度较高，需要引入新的方法改良特征提取分支、减少分支数量，从而提升模型的效率，这是需要改进的方向。

参考文献

- [1] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]. 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). IEEE, 2006, 2: 1528-1535.
- [2] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2009: 248-255.
- [3] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[C]. Proceedings of the IEEE International Conference on Computer Vision. 2017: 3800-3808.
- [4] Zheng Z, Zheng L, Yang Y. Pedestrian alignment network for large-scale person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(10): 3037-3045.
- [5] Wei L , Rui Z , Tong X , et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern recognition. 2014: 152-159.
- [6] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C]. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2015.
- [7] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based CNN with improved triplet loss function[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 1335-1344.
- [8] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]. Proceedings of the European Conference on Computer Vision (ECCV). 2018: 480-496.
- [9] Xu J, Zhao R, Zhu F, et al. Attention-aware compositional network for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2119-2128.
- [10] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2285-2294.
- [11] Cai H, Wang Z, Cheng J. Multi-scale body-part mask guided attention for person re-identification[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 0-0.
- [12] Kalayeh M M, Basaran E, Gökmen M, et al. Human semantic parsing for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1062-1071.

- [13] Wei L , Zhang S , Yao H , et al. GLAD: Global–Local-Alignment Descriptor for Scalable Person Re-Identification[J]. IEEE Transactions on Multimedia, 2019, 21(4):986-999.
- [14] Wang G, Lai J, Huang P, et al. Spatial-temporal person re-identification[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 8933-8940.
- [15] Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping[C]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). 2006, 2: 1735-1742.
- [16] Chang X, Hospedales T M, Xiang T. Multi-level factorisation net for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2109-2118.
- [17] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017
- [18] Hoffer E, Ailon N. Deep metric learning using triplet network[C]. International Workshop on Similarity-based Pattern Recognition. 2015: 84-92.
- [19] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 403-412.
- [20] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [21] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 160(1): 106-154.
- [22] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [23] Li W, Zhao R, Wang X. Human reidentification with transferred metric learning[C]. Asian Conference on Computer Vision. 2012: 31-44.
- [24] Li W, Wang X. Locally aligned feature transforms across views[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 3594-3601.
- [25] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]. Proceedings of the IEEE International Conference on Computer Vision. 2015: 1116-1124.
- [26] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[C]. Proceedings of the IEEE International Conference on Computer Vision. 2017: 3754-3762.
- [27] Hirzer M, Beleznaï C, Roth P M, et al. Person re-identification by descriptive and discriminative classification[C]. Scandinavian Conference on Image Analysis. 2011: 91-102.

- [28] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[C]. European Conference on Computer Vision. 2008: 262-275.
- [29] Zheng L, Bie Z, Sun Y, et al. Mars: A video benchmark for large-scale person re-identification[C]. European Conference on Computer Vision. Springer, Cham, 2016: 868-884.
- [30] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]. Proceedings of the 26th ACM International Conference on Multimedia. 2018: 274-282.
- [31] Fu Y, Wei Y, Zhou Y, et al. Horizontal pyramid matching for person re-identification[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 8295-8302.
- [32] Zhang J, Jiang F. Multi-level supervised network for person re-identification[C]. Proceedings of the IEEE Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 2072-2076.
- [33] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European Conference on Computer Vision (ECCV). 2018: 3-19.
- [34] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]. International Conference on Machine Learning. PMLR, 2015: 448-456.
- [35] Sarfraz M S, Schumann A, Eberle A, et al. A pose-sensitive embedding for person re-identification with expanded cross neighborhood re-ranking[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 420-429.
- [36] Schumann A, Stiefelhagen R. Person re-identification by deep learning attribute-complementary information[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2017: 20-28.
- [37] Song C, Yan H, Ouyang W, et al. Mask-Guided Contrastive Attention Model for Person Re-identification[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [38] Chen Y, Zhu X, Gong S, et al. Person Re-identification by Deep Learning Multi-scale Representations[C]. 2017 IEEE International Conference on Computer Vision Workshops (ICCVW). IEEE, 2017.
- [39] Shen Y, Xiao T, Li H, et al. End-to-end deep kronecker-product matching for person re-identification[C]. Proceedings of the IEEE Conference on Computer vision and Pattern Recognition. 2018: 6886-6895.
- [40] Wang C, Zhang Q, Huang C, et al. Mancs: A multi-task attentional network with curriculum sampling for person re-identification[C]. Proceedings of the European Conference on Computer Vision (ECCV). 2018: 365-381.
- [41] Tay C P, Roy S, Yap K H. Aanet: Attribute attention network for person re-identifications[C]. Proceedings of the IEEE/CVF Conference on Computer

- Vision and Pattern Recognition. 2019: 7134-7143.
- [42] Fan X, Luo H, Zhang X, et al. Scpnnet: Spatial-channel parallelism network for joint holistic and partial person re-identification[C]. Asian Conference on Computer Vision. 2018: 19-34.
- [43] Wang G, Yang S, Liu H, et al. High-order information matters: Learning relation and topology for occluded person re-identification[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 6449-6458.
- [44] Zhou K, Yang Y, Cavallaro A, et al. Omni-scale feature learning for person re-identification[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 3702-3712.
- [45] Xiong F, Xiao Y, Cao Z, et al. Good practices on building effective CNN baseline model for person re-identification[C]. Tenth International Conference on Graphics and Image Processing (ICGIP 2019). 2019, 11069: 110690I.
- [46] Zheng Z, Yang X, Yu Z, et al. Joint Discriminative and Generative Learning for Person Re-Identification[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020.
- [47] Dai Z, Chen M, Zhu S, et al. Batch feature erasing for person re-identification and beyond[J]. arXiv preprint arXiv:1811.07130, 2018, 1(2): 3.
- [48] Wang Y, Wang L, You Y, et al. Resource Aware Person Re-identification across Multiple Resolutions[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [49] Chen D, Xu D, Li H, et al. Group consistent similarity learning via deep crf for person re-identification[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8649-8658.
- [50] Li H, Wu G, Zheng W S. Combined Depth Space based Architecture Search For Person Re-identification[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 6729-6738.
- [51] Li D, Chen X, Zhang Z, et al. Learning deep context-aware features over body and latent parts for person re-identification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 384-393.

在学期间取得的科研成果和科研情况说明

取得的科研成果：

[1] Multi-Scale Attention Network Based on Multi-Feature Fusion for Person Re-Identification[C]. 2021 International Joint Conference on Neural Networks (IJCNN). IEEE, 2021: 1-8.

参与的科研项目：

[1] 多粒度视觉监控数据智能解析方法研究（18ZXZNGX00150），天津市新一代人工智能科技重大专项项目；

[2] 基于压缩感知的大尺度 SAR 图像三维重建及其算法研究（61472278），国家自然科学基金面上项目；

[3] 天津市研究生科研创新项目（2019YJSS049）。

致 谢

时光似箭，日月如梭，转眼间已在天津理工大学度过了两年多的难忘时光，这段时间将会对我的人生产生重要的作用，让我学会了如何独立思考，如何深度分析问题并找出解决办法，也让我对于许多事物的洞察力有了一定的提高，更重要的是使我养成了更为严谨的思维习惯。回首过去的研究生生活，至今仍历历在目，有万般留恋与不舍。此刻，我想对所有给予过我帮助的老师、同学以及学长学姐们表示由衷的感谢，是你们让我的研究生生涯变得更加多彩。

首先，我要对我的指导老师温显斌教授表示特别感谢。研究生期间，温老师为我们提供了优质的软硬件设备与科研平台，积极关心着我们的学习与生活，在温老师的带领下，实验室的学术气氛一直非常好，为我们树立了非常好的榜样，是我们读研期间的指路明灯。

同时，也感谢实验室的同学们与其他老师们。在我的学习与科研中，他们用自己的时间与精力，为我排忧解难，给予我灵感。特别是袁立明老师，对我悉心教导，在困难时指导我前进的方向。无论是学术论文的发表还是毕业论文的写作，都离不开他们的帮助与鼓励。

最后，感谢我的家人们对我的关怀与支持。父母的养育之恩大于天，使我铭记于心，我将用我的实际行动来报答他们，为祖国的建设奉献出自己的力量。