

中文图书分类号：TP391

UDC：004

学 校 代 码：10005



硕 士 学 位 论 文

MASTERAL DISSERTATION

论 文 题 目：基于人体语义分割与多尺度特征学习的行人重识别研究

论 文 作 者：黄笳惊

学 科：计算机科学与技术

指 导 教 师：刘波 副教授

论文 提交 日期：2021 年 5 月

UDC: 004

学校代码: 10005

中文图书分类号: TP 391

学 号: S201861170

北京工业大学工学硕士学位论文

题 目: 基于人体语义分割与多尺度特征学习的行人重识别研究

英文题目: PERSON RE-ID BASED ON HUMAN SEMANTIC SEGMENTATION AND
MULTI-SCALE FEATURE LEARNING

论 文 作 者: 黄笏惊

学 科 专 业: 计算机科学与技术

研 究 方 向: 计算机应用

申 请 学 位: 工学硕士

指 导 教 师: 刘波 副教授

所 在 单 位: 信息学部计算机学院

答 辩 日 期: 2021 年 5 月

授 予 学 位 单 位: 北京工业大学

摘要

行人重识别是利用计算机视觉技术判断图像或者视频序列中是否存在特定行人的技术，被广泛认为是一个图像检索的子问题。旨在弥补固定位置的摄像头的视觉局限，并可与行人检测技术相结合，广泛应用于智能视频监控、智能安保等领域。由于不同摄像设备之间的差异，同时行人兼具刚性和柔性的特性，外观易受穿着、尺度、遮挡、姿态和视角等影响，使得行人重识别成为计算机视觉领域中一个既具有研究价值同时又极具挑战性的热门课题。

为了进行行人重识别的有效研究，研究人员一般比较注重行人特征的提取和损失的设计。在提取特征方面，研究人员通常采用水平图像切块划分的方法让模型学习行人局部特征信息，但由于空间上存在人体和背景区域比例失衡的情况，局部特征匹配将会存在误差，从而降低行人重识别的精度；此外，语义分割也适用于行人重识别，使网络学习到行人整体的特征，但忽略了行人的局部特征，从而降低了行人重识别的精度。基于上述问题，本文从网络结构和损失函数两个方面进行研究，主要工作包括以下三个部分：

（1）全局和局部特征相结合。针对现有的网络仅学习到行人整体的特征而忽略了行人的局部特征的问题，本文将多尺度水平切块划分法与行人全局和划分的局部特征相结合，使得网络模型能够适应人体姿态变化、遮挡和背景杂波等情况，学习到行人完整且具有价值的信息。

（2）引入人体语义分割模型。针对两张需要匹配的图片，如果相同的空间位置对应的内容语义不同，则行人重识别技术的鲁棒性和有效性会受到制约。针对这一问题，本文在 COCO Densepose 数据集上训练人体语义分割模型，该模型用来生成三个行人重识别公开数据集中人体部位伪标签。同时，网络中设计新的多尺度分割模块预测人体部位标签，通过共享多尺度特征提高了行人重识别技术的算法精度。

（3）采用端到端的多任务学习策略。该策略同时考虑三个损失作为子任务：基于多尺度全局和局部水平切块特征的交叉熵损失、基于多尺度全局特征的三元组损失和多尺度人体部位语义分割损失，从而提高了行人检索的准确性。

本文在三个公开数据集上进行了实验，实验结果表明了所提出的网络模型在行人重识别任务中拥有较高的精度，并且该模型具有较好的鲁棒性和泛化性。

关键词：行人重识别；语义分割；多尺度卷积神经网络；模式识别；有监督学习

Abstract

Person re-identification is a technology that uses computer vision technology to determine whether there is a specific pedestrian in the image or video sequence, and it is widely considered as a sub problem of image retrieval. It aims to make up for the visual limitations of cameras in fixed position, and can be combined with pedestrian detection technology, widely used in intelligent video surveillance, intelligent security and other fields. Due to the differences between camera devices, and characteristics of pedestrians with rigidity and flexibility, the appearance of pedestrians is easily affected by clothing, scale, occlusion, posture and perspective, which makes person re-identification become a hot topic in the field of computer vision with both research value and great challenge.

In order to carry out effective research on person re-identification, researchers generally pay more attention to pedestrian feature extraction and loss design. In the aspect of feature extraction, researchers usually use the method of horizontal image stripes to let the model learn pedestrian local feature information. However, due to the imbalance of human body and background area in space, there will be errors in local feature matching, which will reduce the accuracy of person re-identification; In addition, semantic segmentation is also suitable for person re-identification, which makes the network learn the overall features of pedestrians, but ignores the local features of pedestrians, thus reducing the accuracy of person re-identification. In this paper, from the network structure and loss function, the main work includes the following three parts:

(1) Combining global and local features. Aiming at the problem that the existing networks only learn the global feature of pedestrians but ignore local features, the multi-scale horizontal stripes method is combined with the global and local features of pedestrian, so that the network can adapt to the changes of human posture, occlusion and background clutter, and learn complete and valuable information about pedestrians.

(2) Introducing human body semantic segmentation model. For two images to be matched, if the semantics of the content corresponding to the same spatial position are different, the robustness and effectiveness of person re-identification technology

will be restricted. To solve this problem, a human semantic segmentation model is trained on COCO Densepose dataset. The model is used to generate pseudo labels of human parts in three public person re-identification datasets. At the same time, a new multi-scale segmentation module is designed in the network to predict the labels of human parts, which improves the presicions of person re-identification algorithms by sharing multi-scale features.

(3) The end-to-end multi task learning strategy. In this strategy, three losses are considered as sub tasks: cross-entropy loss based on multi-scale global and local horizontal stripe features, triplet loss based on multi-scale global features and multi-scale human part semantic segmentation loss, which improves the accuracies of person re-identification algoritms.

Experimental results on three public datasets show that the proposed network model has achieved high accuracy in person re-identification task with excellent robustness and generalization.

Keywords: person re-identification; semantic segmentation; multi-scale convolutional neural network; pattern recognition; supervised learning

目 录

摘 要.....	I
Abstract.....	III
第 1 章 绪论.....	1
1.1 研究意义.....	1
1.2 国内外研究现状.....	3
1.2.1 基于全局或局部特征学习的方法.....	3
1.2.2 非基于全局或局部特征学习的方法.....	4
1.3 本文主要内容.....	5
1.4 本文主要组织结构.....	5
1.5 本章小结.....	6
第 2 章 相关技术.....	7
2.1 行人重识别的研究模式.....	7
2.1.1 行人重识别数据集结构.....	7
2.1.2 行人重识别基本流程.....	7
2.2 行人重识别网络搭建和损失函数设计.....	8
2.2.1 行人特征提取与分类.....	8
2.2.2 多尺度特征融合和三元组损失.....	9
2.3 预训练卷积神经网络.....	12
2.3.1 ResNet 分类网络.....	12
2.3.2 Inception 语义分割网络.....	13
2.4 数据增广.....	13
2.4.1 随机擦除.....	13
2.4.2 基于人体部位的语义分割.....	14
2.4.3 GAN 实现数据增广.....	16
2.5 评价指标.....	18
2.5.1 平均精度均值 mAP.....	18

2.5.2	累计匹配特性曲线 CMC.....	19
2.6	本章小结.....	20
第 3 章	基于人体语义分割与多尺度特征的行人重识别模型.....	21
3.1	总体模型框架.....	21
3.2	多尺度特征提取模块.....	23
3.3	基于多尺度全局和局部水平切块特征的交叉熵损失.....	24
3.4	基于多尺度全局特征的三元组损失.....	25
3.5	多尺度人体部位语义分割模块.....	26
3.6	多任务损失训练和测试.....	28
3.7	本章小结.....	29
第 4 章	实验结果与分析.....	31
4.1	数据集.....	31
4.1.1	Market-1501.....	32
4.1.2	DukeMTMC-reID.....	32
4.1.3	CUHK03.....	32
4.2	实验细节.....	33
4.3	评价函数.....	34
4.4	行人重识别算法性能比较.....	34
4.4.1	各模型在 Market-1501 数据集上的性能比较.....	34
4.4.2	各模型在 DukeMTMC-reID 数据集的性能比较	38
4.4.3	各模型在 CUHK03 数据集上的性能比较.....	39
4.4.4	总结	41
4.5	消融研究.....	41
4.6	本章小结.....	43
结 论		45
参 考 文 献		47
攻读硕士期间的主要研究成果		51
致谢		53

第1章 绪论

1.1 研究意义

作为近几年兴起的新兴技术,“行人重识别”(Person Re-identification)^[13, 9, 22, 28, 30, 37]被广泛利用在目标检测和目标跟踪等领域。“行人”即被识别的目标,“识别”则是通过计算机视觉相关技术对行人进行定位以及对行人属性进行判别。“重识别”则是针对跨域跨摄像头情境下的不同行人进行定位和属性判别。行人重识别的具体流程为:某个摄像机第一次记录某个行人身份特征并将其存储至库中,之后其他的摄像机重新识别该行人,并将识别到的行人特征与库中已经存储的行人信息进行匹配,如果匹配为同一个行人身份,则说明完成行人的重识别任务。通过这样的方法,行人就可以在不同的摄像机下,避免识别跟踪丢失的情况。因此,行人重识别技术是行人检测和行人跟踪研究中十分强有力的工具。



图 1-1 行人重识别应用领域

Fig. 1-1 Person re-identification applications

随着计算机技术和人工智能技术的快速发展,传统方法和深度学习在计算机视觉、自然语言处理和语音识别等方面取得了非常大的进展^[1]。其中,人脸识别技术在计算机视觉方面占有很大的市场和地位,目前许多的企业和公司把这样的技术应用在安保和员工管理上。然而,在很多实际场景中,摄像头根本无法抓拍到行人清晰的正面照,并且由于天气变化、夜间光线不足和视线遮挡等问题,人

人脸识别技术无法对人脸信息进行较好的处理,甚至出现误检和漏检的情况。在人脸识别技术不能完全发挥作用的情况下,行人重识别技术就被作为一种辅助技术甚至是决定性技术用于行人识别或重识别的场景之中,如智能安防、智能商业、人机交互和相册聚类等。

近年来,能够自动学习鲁棒性特征的深度学习方法逐渐被广泛使用。该方法包括搭建相应的卷积神经网络模型和设计合理的损失函数,以便于行人身份类别的分类和匹配。首先,使用预训练网络模型提取行人的深层次特征,其意义是在后续添加的分支网络模块中损失函数收敛地更快,行人重识别的精确度也更高。第二,特征学习的内容和方式也会对行人匹配的结果产生影响:基于表征学习的方法是一类常用的行人重识别方法,该方法一般基于分割网络设计新框架^[11, 39]。然而仅靠行人的 ID 信息是不足以学习出一个泛化能力足够强的模型,因此该方法需要额外标注行人的性别、头发和衣着等属性,通过引入这些属性标签,模型不仅准确地预测行人的 ID,还可以预测出行人各项的属性^[2, 38, 40],提高了模型的泛化能力。;基于度量学习的方法既可以在图片层级进行相似度计算,还可以在特征层级进行相似度计算。在行人重识别问题上,具体为同一 ID 行人的相似度大于不同 ID 行人的相似度,使得特征学习更具有针对性;基于局部特征学习的方法是在基于全局特征的方法遇到了瓶颈时被提出,该方法包括图像切块、人体关键点检测^[12]和姿态估计或姿态驱动^[23]等。图像切块的方法一般把图像对齐后,水平切分为若干块,在划分区域的时候注意对齐避免错误信息匹配^[29];基于视频序列的方法是通过比较视频帧间差异,利用光流法或者运动补偿来解决视频中存在的行人遮挡等问题,尤其是在多个摄像头下遮挡和不全的情况更加明显,需要通过前后帧的变化来进行行人姿态的预测和判断;基于生成对抗网络(GAN)的方法可以运用到无监督任务或者跨数据集跨场景任务中,对补充数据样本,提高模型泛化性有着极为关键的作用。

本课题旨在利用深度学习方法的卷积神经网络 CNN 提取行人特征,并结合目标检测、语义分割、生成对抗网络以及风格转换等技术加强全局和局部特征学习,结合多尺度思想^[4]对特征数据进行相似性度量,匹配相似度高的行人图像来进行行人再识别。对于减轻人工作业的负担,提高识别效率和准确度具有重要意义,在刑侦和安保方面也具有很大的应用价值。

1.2 国内外研究现状

1.2.1 基于全局或局部特征学习的方法

1.2.1.1 人体关键点检测和姿态估计

随着行人姿态估计^[41]的迅速发展,越来越多的研究者关注人体关键点预测,并将其作为行人重识别的辅助方法。Li 等人^[23]提出了一种基于姿态驱动的深度卷积模型,该模型不仅匹配了全局和局部人体局部的特征,还利用了人体部位的线索解决摄像机部署产生的复杂视点变化和姿态变化导致的误差问题。2017 年,Wei 等人^[7]提出了全局局部对齐描述符(GLAD),其包括局部特征提取模块和描述符的学习方法,并将其作为行人重识别的有效索引和检索框架。在论文[32]中,Arne 等人提出了一种有效的方法,该方法包括融合精细和粗糙的姿态信息来学习判别性嵌入(discriminative embedding),以提高模型的检索性能。此外,Zhao 等人^[6]基于注意力模型提出了一种新的行人特征对齐表示方法,该方法仅需进行特征的相似度计算,无需行人的身体监督信息。然而,由于检测时下半身、手、头等部位的关键区域不稳定,因此基于人体姿态和骨架关键点定位的方法在识别过程中会产生较大的误差,这些错误的关键点定位必然会导致错误的特征学习,降低行人重识别的精度。

1.2.1.2 水平图像切块

在没有人体关键点定位方法的情况下,Yao 等人^[24]使用局部区域损失(Part Loss)自动检测人体局部区域,并分别计算每个区域的分类损失。2017 年,Sun 等人^[14]提出了 PCB 框架,在没有引入任何额外数据的情况下,利用大小相同的水平图像切块划分策略进行局部表示。在论文[27]中,Li 等人设计了一种新的 CNN 结构,用于在相同的行人重识别标记信息下同时学习局部和全局鉴别特征。与全局特征学习和局部特征学习的结合类似,云从科技的 Wang 等人提出多粒度网络(MGN)^[18],该网络包含一个全局特征分支和两个局部特征分支,但这种单纯的水平划分方式对于复杂场景和遮挡问题仍然是无效的。虽然考虑了全局信息和较少的区域划分来降低空间错位导致的误差,但是行人样本中仍存在一些没有占据整个空间的检测结果。如果边界框捕捉到具有较多背景或被遮挡的人物图像,那么该模型学习到的局部特征将会受到空间错位的影响,导致行人局部特征匹配误差增大。

1.2.1.3 空间对齐

为了避免这种极端的空间错位,2019 年 Sun 等人^[5]提出局部可见性感知模型(VPM),其通过自监督来感知区域的可见性,从而提取区域级特征。在论文[36]中,腾讯优图的 Zheng 等人提出了一个新的由粗到细的金字塔模型,该模型融合了行人的局部和全局信息,并考虑了信息之间的逐步过渡过程。在此过程中,将主干网络提取的原始特征图分为 6 个子特征图,然后将这些子地图逐层成对拼接成大特征图,直到大特征图的大小与原始特征图的大小相同。此外,作者还设计了一种动态训练方案,该方案可以无缝地统一两个损失,并提取适当的共享信息,以满足检测框高精确度的需求。可以说,空间对齐的方式不仅使得多尺度网络提取的特征更加合理,在度量计算时还可以降低匹配误差。

1.2.1.4 语义分割对齐

在语义分割对齐的研究中,微软亚洲研究院 Zhang 等人^[35]提出了一种密集语义对齐的行人再识别框架,该框架具有两个流网络,其中包括用于特征学习的主完整图像流(MF-stream)和密集语义对齐引导流(DSAG-stream)。之后, Kalayeh 等人^[11]提出了 SPReID 框架用于行人重识别任务,该框架采用了具有像素级的精度和构建任意轮廓能力的 Inception-V3^[8]作为人类语义分析模型的主干架构。因此,通过语义信息在高层次层面降低行人局部特征匹配误差是十分有效的。

1.2.2 非基于全局或局部特征学习的方法

除了以上多种多样的特征提取方法,结合传统方法以及在改善训练策略方面也存在着一些很好的文献研究。例如,由于训练和测试性能之间存在较大的差距,Huang 等人引入了一些遮挡样本^[26]来增加训练数据的多样性。通过这些额外的样本,该模型能够发现行人信息上新的判别性线索,并从提取的特征中学习不变性。SVDNet^[25]论文中利用奇异向量分解(SVD)优化深度特征表示学习过程,迭代集成 CNN 训练中的正交约束。在论文[31]中,Chen 等人在训练过程中,行人图像被用来统一 CRF 中的局部和全局相似性之间的关系,在测试阶段,多尺度的局部相似性则被组合在一起作为模型的预测相似性。为了学习用于多视点匹配的行人特征一致性表示,Zheng 等人^[34]提出一个新的孪生网络框架。由于注意力一致性与来自同一个人的公共区域相关联,因此作者提出一种孪生框架来学习样本数据中行人一致的关注区域特征,并相应地产生不变性特征表示进而提高行人匹配的精确度。因此,结合全局和局部特征并学习一致性或约束以及优化训练策略也可以提升模型性能。

综上所述,通过对国内外大量文献的分析,基于深度学习的行人重识别方法

需要考虑诸多方面的因素。度量学习和表征学习已经有了很大的进展,将其与目标检测和分割领域等技术相结合更能提升行人重识别模型的性能。多尺度的考虑行人信息,将多任务机制与多种数据增广方法进行结合,并进行端到端的架构设计,提高模型识别的效率,减少繁杂的步骤,这样的方法在实际应用中也是值得期待的。根据以上分析,本课题结合多尺度特征融合并引入多种数据增广方法提升模型泛化性,通过对行人全局和局部特征相结合进行度量学习,解决行人多摄像头下重新识别问题。

1.3 本文主要内容

本文针对行人重识别任务和相关问题,设计了基于全局和局部特征度量学习,多尺度特征融合的网络模型。此外,使用诸如目标检测、语义分割等计算机视觉研究领域的方法强化网络提取和学习特征的能力。并在多种数据增广方法的辅助下,对数据集场景和样本进行丰富和替换,提高所提出的网络模型的泛化能力,使之能够在实际场景中发挥作用。

主要内容如下:

(1) 全局和局部特征相结合。针对现有的网络仅学习到行人整体的特征而忽略了行人的局部特征的问题,本文将多尺度水平切块划分法与行人全局和划分的局部特征相结合,使得网络模型能够适应人体姿态变化、遮挡和背景杂波等情况,学习到行人完整且具有价值的信息。

(2) 引入人体语义分割模型。针对两张即将匹配的图片,相同的空间位置对应的内容的语义不同,从而制约了行人重识别技术的鲁棒性和有效性的问题,本文在 COCO Densepose 数据集上训练人体语义分割模型,该模型用来生成三个行人重识别公开数据集中人体部位伪标签。同时,网络中设计新的多尺度分割模块预测人体部位标签,通过共享多尺度特征提高了行人重识别技术的算法精度。

(3) 采用端到端的多任务学习策略。该策略同时考虑三个损失作为子任务:基于多尺度全局和局部水平切块特征的交叉熵损失、基于多尺度全局特征的三元组损失和多尺度人体部位语义分割损失,从而提高了行人检索的准确性。

本文在三个公开数据集上进行了实验,实验结果表明了所提出的网络模型在行人重识别任务中拥有较高的精度,并且该模型具有较好的鲁棒性和泛化性。

1.4 本文主要组织结构

本文针对现有行人重识别算法遇到的问题,基于人体语义分割与多尺度特征学习进行行人重识别研究。本文共分为六章,各章节安排如下:

第一章:绪论。本章介绍了行人重识别的研究背景和研究现状,并说明了该

课题的研究意义。随后针对行人重识别任务存在的关键问题进行分析，提出本文的解决方案。

第二章：行人重识别任务相关技术介绍。主要围绕行人重识别的多任务网络搭建和损失函数设计的问题，介绍了利用预训练模型提取行人特征并进行分类的方法；介绍了多尺度特征融合以及度量学习进行特征相似性比较；针对数据增广问题，介绍了多尺度区域分割以及随机擦除等关键技术。

第三章：基于人体语义分割与多尺度特征学习的行人重识别模型的设计框架。首先，介绍多尺度特征提取模块，对行人特征的多样性进行分析，利用全局和局部特征学习的方法进行相似性度量学习。采取水平切块的方法进行局部特征划分，并使用三元组损失进行正负样本划分，且划分程度正比于特征尺度。通过以上方式，设计一种多尺度特征提取网络。其次，介绍多尺度语义分割模块，由于仅仅使用多尺度特征提取不能解决空间错位下的特征匹配问题，因此研究利用在 COCO 数据集上训练人体语义分割模型，来对三个公开数据集进行人体部位伪标签预测，并利用标签进行多尺度语义分割，进而影响多尺度特征提取模块。最后，介绍基于多任务学习网络，将多尺度特征学习和人体语义分割的内容相结合，提出一种新的网络框架，既可以用于做行人重识别任务也可以完成语义分割任务。将二者相结合并设计总损失函数进行训练可提升整体网络的性能。

第四章：实验结果与分析。本章利用行人重识别常用的评价指标在三个公开数据集上进行了实验，并列举其他模型的效果进行比较。此外，消融研究用于比较各个模块以及训练参数不同时的实验效果。实验表明，本文研究的网络框架和算法在 Market-1501、DukeMTMC-reID 和 CUHK03 三个公开数据集上取得了优异的性能。

1.5 本章小结

本章主从课题的研究方向和研究背景出发，详细介绍了现如今行人重识别技术的发展状况和主要的方法技术。由此，本文提出使用全局和局部特征联合学习的方式，并结合多尺度思想，利用不同尺度下的行人信息进行学习和判别。此外，本文还从数据增广方面说明了行人重识别任务可以利用的其他思想和方法。最后，在第四小节，主要说明了本文的主要研究内容以及各个章节的安排，为之后的行文进行规划。

第2章 相关技术

2.1 行人重识别的研究模式

2.1.1 行人重识别数据集结构

行人重识别任务中，数据集通常是通过人工标注或者检测算法得到的行人图片。数据集分为：训练集、Query 集和 Gallery 集，其中训练集中的人物身份与 Query 集和 Gallery 集中的人物身份不重复。如图 2-1 所示，在行人重识别任务中，首先在训练集上进行模型的训练，训练完毕后对 Query 与 Gallery 中的图片提取特征计算相似度，对于每个 Query 集中的各个行人，都需要在 Gallery 中找出前 N 个对应标签的相似的图片。




图 2-1 行人重识别数据集结构

Fig. 2-1 The structure of person re-identification datasets

由此可见，Query 集相当于某个摄像机拍摄的行人图片集，而 Gallery 集则是待检测的行人图片集。通过这样的数据集结构，研究者就可以设计相应的算法来验证行人重识别的性能，进而完成行人重识别任务。

2.1.2 行人重识别基本流程

行人重识别系统从细节来说，包括以下几个部分：特征提取 (Feature

Extraction)、度量学习(Metric Learning)以及图像检索(Matching)。特征提取的主要目的是学习能够应对在不同摄像头下行人变化的特征;度量学习是将学习到的特征映射到新的空间,使相同的人更近不同的人更远;图像检索则是根据图片特征之间的距离进行排序,返回检索结果。




图 2-2 行人重识别基本流程

Fig. 2-2 The basic flow of person re-identification

通过以上基本流程,研究者就可以利用训练好的模型对行人进行被跨摄像头地跟踪和监测,进而达到行人重识别的目的。

2.2 行人重识别网络搭建和损失函数设计

在行人重识别任务中,网络搭建主要分为特征提取、特征池化、特征降维和最后的分类工作,损失函数则是对行人标签的分类损失。但是,由于行人图像十分复杂,相似的行人在识别和匹配时具有较大的挑战性,因此一般的网络并不能仅仅通过以上方式对行人信息有更加丰富和细致的学习,因此设计网络和损失就成为了行人重识别任务中至关重要的因素。模型学到的特征越复杂,损失函数设计的越得当,整体的网络的性能就会越好。接下来着重介绍行人重识别中,网络搭建和损失函数设计的主要内容。

2.2.1 行人特征提取与分类

在行人重识别任务中,首先对行人数据集图片进行裁剪和翻转以及归一化等数据预处理操作,再将其输入到预训练模型中,目的是为了使得预训练模型提取的特征具有较好的数据分布且具有多样的细节信息。

之后，行人图片样本经过诸如 ResNet-50 或 InceptionV3 等主干网络提取全局深度特征。使用迁移学习的预训练网络和未经过训练的网络在效果上存在较大差异，其原因前者经过了模型参数的优化步骤，而后者未经过模型参数优化，因此迁移学习的网络精确度更高。此外，预训练网络在提取了行人的深度特征后，由于原始主干网络的分类类别和本身的任务并不相同，并且分类的标签也并不一致，研究者不能直接使用原始主干网络的分类器进行分类。因为 ResNet 等网络的预训练模型都是在 ImageNet 数据集上进行训练和分类任务，所以网络中原始设计的分类器一般不作为行人重识别任务中的分类器，研究者需要移除主干网络原始的分类器，使用新的分类网络框架进行替代。

除此之外，在进行分类任务之前，网络提取到的深度特征还需要进行新的编码和筛选工作，一般需要设计多个池化层、特征映射层以及特征降维层去进行这些操作。最终，由这些网络层提取出来的特征，会被送入至全连接分类层进行样本的分类操作。




图 2-3 行人重识别基本流程

Fig. 2-3 Basic process of person re-identification

如图 2-3 所示，使用 ResNet-50 作为预训练模型训练提取行人的全局特征，之后将特征进行池化降维和分类操作，输出的结果和行人标签一起进行损失计算来完成行人重识别的训练任务。

由此，本文展示了一个基本的行人重识别训练流程，其可以解决比较简单的行人重识别工作，但是对于模型识别的准确度而言，仍旧存在不足，整体的训练流程还有可改进和提升的空间。接下来继续介绍如何将行人的特征进行多样化和分类处理。

2.2.2 多尺度特征融合和三元组损失

大部分的行人重识别任务利用单一尺度的全局特征，来进行特征筛选池化降维操作，并最终进行分类任务。那么，行人重识别的效果在很大程度上都依赖于网络输入的行人特征信息。如果行人特征能够存在更多层级的划分和更为丰富的

细节保存度，行人重识别性能也会得到显著的提升。而多尺度思想，正是在不同尺度和不同信息粒度的情况下，让网络学习到行人特征中更多复杂且隐藏的信息。




图 2-4 多尺度特征融合网络

Fig. 2-4 Multi-scale feature fusion network

在行人重识别任务中，多尺度思想被用来作为行人特征多尺度特征判别的依据，即行人特征存在多个尺度的特征图与之对应。然而，这些尺度的特征图包含的信息是不同的，那么对这些不同尺度的特征图分别进行池化降维等数据筛选提炼的操作后，就可以使得网络在分类学习阶段，从不同层级来挖掘行人更多的特征信息，进而提高网络的鲁棒性和泛化性。

具体地，对来自诸如 ResNet 等主干网络提取的全局特征进行多尺度判别，目的是保留不同尺度的行人特征信息，进而可以对全局特征进行水平切块划分法得到多个局部特征。因此，为了学习不同尺度下的行人特征，应该各自设计一个分支来处理每个尺度下的参数学习和池化降维以及分类器判别等操作。此外，每

个分支的全局特征还可以采用度量学习的方式,在特征层面进行正负样本的编码学习,即相同行人图片的编码应该是相似的,而不同行人的图片编码应该是不相似的。这里,度量学习方面可以选择三元组损失进行图像特征编码间的距离相似度计算。

如图 2-4 所示,展示了多尺度特征融合和三元组损失的相关流程。行人图像经过主干网络后生成不同尺度下的全局特征图,每个全局特征图都有一个对应的分支学习该尺度下的全局特征信息,最后通过拼接(Concatenate)操作将这些在不同尺度下的全局特征向量进行融合,进行三元组损失的计算。

在人脸识别任务和行人重识别任务中,三元组损失^[42]已经成为十分常见的损失函数。在网络模型设计时,一般利用经过池化和降维后的特征进行三元组损失的判定,而三元组损失中的距离是人为定义的距离(如欧式距离或余弦距离),这些距离用于度量不同行人样本间的编码差异。计算三元组损失需要三张输入图片,分别命名为固定图片(Anchor)a,正样本图片(Positive)p 和负样本图片(Negative)n。图片 a 和图片 p 为一对正样本对,图片 a 和图片 n 为一对负样本对。三元组损失定义如下:

$$L_{\text{triplet}} = \max(d_{ap} - d_{an} + \text{margin}, 0) \quad (2-1)$$

其中, d 表示样本之间的特征距离, margin 是设定的阈值。




图 2-5 行人重识别中的三元组损失

Fig. 2-5 Triplet loss in person re-identification

如图 2-5 所示,三元组损失可以拉近正样本对之间的距离,推开负样本对之间的距离,最后使得相同 ID 的行人图片在特征空间里形成聚类,达到行人重识别的目的。对于每一张图片 a,本文选择一个最难的正样本和一个最难的负样本,即与 a 最不相似的正样本和与 a 最相似的负样本组成一个三元组。

值得注意的是,多尺度特征学习网络需要构建复杂的结构,包含的网络参数比单尺度特征学习网络的要更加庞大,因此在设计分支网络的时候应该注意梯度爆炸或消失的问题,否则在训练过程中会出现标签分类损失上升不收敛的情况。所以,深度学习网络结构不是越复杂性能越优异,而是需要对网络结构进行精心

的设计，在减少花费成本的同时，又能得到较好的重识别效果。

2.3 预训练卷积神经网络

在分类任务中，为了减少网络训练的成本和时间消耗，一般采用迁移学习的方式进行图像的特征提取。迁移学习的具体表现形式就是利用预训练网络来提取特征，然后设计相应的分类器对相关的问题进行模型的训练和测试。在行人重识别任务中，研究者通常采用预训练模型作为行人特征提取的关键工具，并将其作为卷积神经网络的主干部分。下面几节介绍行人重识别任务中几种常用的预训练分类网络框架。

2.3.1 ResNet 分类网络

2015 年何凯明团队提出了 ResNet^[3]分类网络，用于解决深度网络中存在的梯度弥散和梯度爆炸的问题。针对之前诸如 VGG 网络等深度网络的层数不断增加而导致的分类性能下降的困境，ResNet 分类网络中所采用的残差学习机制可以使得这一问题得到大幅度的缓解。

深度网络学习的实质是学习到输入与输出之间的映射关系，而 ResNet 则是学习输入与输出间存在的差异。此外，学习到的差异是按块的形式进行组合的，而不是针对于每个单一的某个层，因此 ResNet 中存在多个这样的残差映射保证块之间的残差传递。

如图 2-6 所示，残差块的构成如下：




图 2-6 残差结构

Fig. 2-6 Residual Structure

其中，残差学习的思想为：输入 x ，输出为 $F(x) + x$ ，而 $F(x) = H(x) - x$ 。

简而言之，残差学习的原理就是学习输入与输出之间的残差，如果输入为 x ，则直接通过训练得到的输出是 $H(x)$ ，那么残差学习的输出则是 $H(x) - x$ 。

残差网中的恒等映射(Identity mapping)是 ResNet 中存在于输入与输出的一

个特征传递通道,用于输入与输出在相同通道下进行残差学习。这样的恒等映射由跳跃连接(Skip Connection)完成,即输入跳过若干个神经层到达输出进行残差运算。这样就能保证图像特征在网络传递时减少丢失几率,同时也提高了特征间的相关性。

现如今,ResNet 是行人重识别任务中最常见的主干网络模型,原因是不仅可以处理深度网络训练问题,而且 ResNet 模型参数量相较于 VGG 网络更少,并且识别精度也更高。因此,本文也是用 ResNet 中的 ResNet-50 作为主干网络进行行人特征的提取。

2.3.2 Inception 语义分割网络

Inception 网络可以解决深度网络中存在的梯度弥散和梯度消失的问题,与残差学习不同的是,Inception 网络采用的是引入稀疏特性。现如今研究者主要采用 InceptionV3^[8]网络进行行人重识别的研究。

为了学习特征的稀疏性,Inception 网络中设计不同种类的卷积核来提取不同尺度的特征,并将这些特征进行拼接(concatenate)来学习非线性属性。对于网络深度较深的情况,模型中存在降维层以减少参数计算量。尽管如此,Inception 相较于 ResNet 还是存在模型参数量大的问题,因此并没有广泛地应用于行人重识别的工作。

值得一提的是,现如今的 Inception 网络已经与 ResNet 网络相结合得到了新的网络,构成 Inception-ResNet 系列,性能得到了进一步提升,可用于行人重识别任务。

2.4 数据增广

尽管深度学习网络相较于一般的传统算法可以提取到更为深层和复杂的特征,但是仍旧存在一些不可避免的问题,即存在网络提取到的特征本身不够丰富或者特征区别不明显的情况,从而导致行人重识别的结果产生较大的误差甚至发生严重的错误。因此,除了需要搭建可以提取复杂特征的深度学习网络,研究者还需要一些数据增广手段,帮助模型学习到更丰富且更具有判别性的特征。接下来,本文将介绍几种在行人重识别任务中常用的数据增广手段。

2.4.1 随机擦除

随机擦除(Random Erasing)^[17]作为一种强有力的数据增广方式,可以有效的模拟出行人被遮挡或行人背景发生变化等场景。其原理如下:给定一个随机擦除的因子 r_e ,则擦除区域的长为 $H_e = \sqrt{S_e \times r_e}$,宽为 $W_e = \sqrt{\frac{S_e}{r_e}}$,则在满足擦除区

域始终在原始图像区域内的情况下，随机擦除的区域为：

$$I_e = (x_e, y_e, x_e + W_e, y_e + H_e) \quad (2-2)$$

其中 x_e 和 y_e 是原始图像区域内随机选取的点的横坐标和纵坐标。示意图如图 2-7 所示。



图 2-7 原始图像和随机擦除后的图像

Fig. 2-7 The original image and images after random erasing

在大部分的行人重识别任务中，模型训练阶段的随机擦除因子 r_e 一般设置为 0.5，即存在一半的概率对图像区域进行随机擦除。此外，随机擦除这种数据预处理方式可以增加数据集中不存在的遮挡场景作为训练样本，因此模型对行人重识别的场景的适应性也得到了进一步的提高。

值得注意的是，随机擦除虽然可以增加更多复杂的场景，但如果擦除区域和划分的局部特征区域位置相似甚至覆盖，则有可能存在空间上的局部特征匹配误差，反而会降低行人重识别的精度。因此，设计较好的随机擦除因子，以及设计合理的局部特征划分方案，才能更好地进行行人重识别任务。

2.4.2 基于人体部位的语义分割

在行人重识别任务中，语义分割方法可作为辅助手段帮助进行行人重识别工作^[11,35]。由于行人躯干的划分大体相同，因此语义分割方法虽然可以对行人部位进行分割和标记，但是却不能有效地处理行人的姿态风格和衣服纹理等信息。但是在加强网络对行人部位区域的关注度方面，语义分割却是非常强力的一种工具。

大部分的行人重识别技术仅仅基于图像特征提取层面进行度量学习研究，却没有考虑在此基础上加入语义信息。研究者如果想利用人体的语义信息，就必须拥有人体各个部位的分割标签样本。但是三个公开的行人重识别数据集中并不存在这样的部位标签，那么研究者就需要自己手动标定这些人体部位。标记人体部位的分割标签，则需要一个行人关键区域分割模型来对行人样本进行区域标定。

近几年，行人检测和部位分割技术也得到了快速发展。本文可以利用这些领域里的效果较好的模型对人体部位进行区域标定，生成部位伪标签。例如，我们

可以在 COCO DensePose 数据集^[12]上训练一个较好的人体关键区域分割模型，并用其预测行人重识别数据集中样本各部分标签，这样就可以引导特征提取网络更好地关注人体部分，同时也较好地解决行人特征空间匹配错误的问题，避免在模型训练和效果测试中出现较大的误差。原始论文效果如图 2-8 所示。



图 2-8 COCO DensePose 数据集上的人体部位语义分割结果

Fig. 2-8 Human part semantic segmentation results on COCO DensePose dataset

可以看到模型对图片中多个行人的部位都进行了区域分割，因此本文利用该模型来对行人重识别数据集中每个行人样本做同样的部位区域分割操作。当每个行人样本的部位区域的分割标签图像生成完毕之后，将其保存为新的数据集，利用这三个新的人体部位分割数据集辅助完成行人重识别的工作。如图 2-9 所示，利用在 COCO DensePose 数据集上训练好的模型预测 Market-1501 数据集^[16]中行人样本的部位区域伪标签。

通过这样的方法拥有了每个行人样本的部位语义信息。利用这些信息，设计一个具有语义分割功能的网络模块进行特征学习，再进行行人重识别任务。




图 2-9 Market1501 数据集样本及其对应的人体部位伪标签

Fig. 2-9 Samples of Market1501 dataset and their corresponding human part pseudo labels

2.4.3 GAN 实现数据增广

GAN(生成对抗网络)^[47]是近几年兴起的深度学习技术，主要用于无监督学习。GAN 不仅可以生成伪造的图像，也可以进行数据增广以及风格迁移等。对于行人重识别数据而言，GAN 的作用最主要的是风格迁移，也可以用来扩充行人重识别数据集样本。

GAN 主要由生成器 G 和判别器 D 构成，生成器用于生成以假乱真的图像，判别器用于判断生成器生成图像的真假，即生成的图像判定为假，二者进行对抗，最终双方分别在生成假图和判别图片方面都有较为优异的性能。

使用 GAN (生成对抗网络)对行人重识别数据集进行风格迁移和样本扩充可以使设计的模型学习到更多的特征表示。此外，由于通过 GAN 生成了更多变化的场景，行人重识别模型的泛化能力也会得到显著提升。对于不同数据集的采样风格，可以将其迁移至另一个数据集，使得原来的数据集额外添加不同风格的训练和测试样本。而这样的风格迁移方式在行人重识别任务中被广泛使用，如图 2-10 所示，本文利用 SPGAN^[46]对 Market1501 数据集的样本图片进行到 Duke 数据集的风格迁移。



图 2-10 利用 SPGAN 对 Market1501 数据集进行到 Duke 数据集的风格迁移

Fig. 2-10 Using SPGAN to migrate style of Duke dataset to Market1501 dataset




图 2-11 利用 StarGAN 对 Market1501 数据集生成不同摄像机下相同行人姿态图像

Fig. 2-11 Using StarGAN to generate the same pedestrian pose images under different cameras on Market1501 dataset

除了利用 GAN 进行数据集的风格迁移来提高模型识别各种不同场景的能力, 无监督或半监督模型还可以在相同数据集中, 学习 GAN 生成的不同摄像机下的相同行人姿态的样本图片。通过这种方法, 网络在进行无监督学习时, 就会考虑到相机视点偏差和光照分布不同等干扰情况, 进而可以使得网络模型对行人多视点多个姿态变得更加适应, 模型对更多的复杂场景更具有判别力。如图 2-11 所示, 利用了 StarGAN^[45] 这样的一个用于人脸风格变换网络来改变行人所处的摄像机拍摄环境。

因此, 对于行人重识别任务, 采用 GAN 去处理各种不存在的场景是十分有效的, 尤其是对于半监督或无监督而言, 这样的方法就显得更加强有力。当然, 也可以将生成对抗的思想融入到重识别的流程中去, 构建一个端到端的架构, 例如 CVPR2019 的 DG-Net^[44], 就是一个成功的端到端架构。开发团队通过该网络在 Market1501 数据上生成了一个大型公开的数据集 DG-Market^[44], 其包含了 128,307 图像的数据集, 如图 2-12 所示。




图 2-12 DG-Market 数据集

Fig. 2-12 DG-Market dataset

2.5 评价指标

行人重识别任务是图像检索的子任务，因此评价指标与图像检索和分类任务类似，核心的评价指标有两个：**mAP** 和 **CMC**。通过这两个评价指标，可以对行人重识别算法的性能优劣做出判断，从而找出存在的问题以便之后的优化工作。

2.5.1 平均精度均值 mAP

mAP(mean Average Precision)，平均精度均值，反应检索的人在数据库中所有正确的图片排在排序列表前面的程度，能更加全面的衡量行人重识别算法的性能。在行人重识别任务中，行人标签的数量十分庞大，需要从大量的行人图片样本中进行分类再匹配，因此行人重识别属于多标签的图像分类任务。而多标签图像分类任务中常用的指标为 **mAP**，因此行人重识别的常用的指标就是 **mAP**。由于行人重识别并不是单一图像的分类任务，所以 **AP** 即平均精确率这个指标不能被用来作为行人重识别任务的评价指标，取而代之的是 **mAP** 作为行人重识别任务的评价指标。

AP 的计算方式由两个元素构成，第一是准确率(**Precision**)，第二是对应标签类别的图像样本数。准确率和召回率一般是二分类任务中常用的评判标准，假设数据集包含预测的目标以及混淆的目标，并且数据集样本存在正样本和负样本两种划分，那么模型预测标签正确的正样本数量定义为 **TP**，模型预测标签错误的正样本数为 **FP**，模型预测标签正确的负样本数为 **TN**，模型预测标签错误的负样本数为 **FN**。准确率(**Precision**)和召回率(**Recall**)的公式分别为：

$$\text{precision} = \frac{TP}{TP+FP} \quad (2-3)$$

$$\text{recall} = \frac{TP}{TP+FN} \quad (2-4)$$

其中，针对原有样本，召回率表示样本中的正样本被预测正确的数量；针对预测结果，精确率表示预测为正样本的样本中是真正正样本的数量。因此，AP 为：

$$AP = \frac{\sum \text{precision}_c}{\text{images}_c} \quad (2-5)$$

在多分类任务中，mAP 是将每个标签类别的平均精度 AP(Average Precision) 求和之后再取平均，由于行人重识别任务中需要对每个行人标签进行预测和识别，因此需要对所有行人类别计算 mAP。其中，mAP 的计算公式如下：

$$mAP = \frac{\sum_{k=0}^C AP_k}{C} \quad (2-6)$$

其中， C 表示行人类别的总数，公式 2-6 中的分子为每个行人类别的 AP 值。



图 2-13 mAP 指标样例

Fig. 2-13 The example of mAP

如图 2-13 所示，被检索的行人在 Query 集中，假设该行人从 gallery 中检索出 4 张图片，并且检索的位置分别为 1、3、6、7，则 AP 为 $(\frac{1}{1} + \frac{2}{3} + \frac{3}{6} + \frac{4}{7})/4 = 0.685$ 。若通过计算得到的 AP 值较大时，该行人的检索结果则相对靠前。对所有 query 集中行人计算得到的 AP 值取平均值则得到 mAP。因此，通过计算 mAP 来衡量模型预测行人类别是十分有效的。

2.5.2 累计匹配特性曲线 CMC

CMC, Cumulative Matching Characteristics, 即累计匹配特性曲线，是行人重识别问题中的经典评价指标。在行人重识别任务中，CMC 指标用来得到排名前 K 中模型预测标签为正确的占比。在进行 CMC 指标计算时，先比较候选集中行人的特征距离并从小到大排序，然后查看要查找的行人在排名前 K 中的占比，占比越大则说明行人重识别的效果越好。假设数据集中存在 N 种行人标签，每次查询目标的排序结果为 $r = (r_1, r_2, \dots, r_N)$ ，那么 CMC 公式可如下表示：

$$\text{CMC}(K) = \frac{1}{N} \sum_{i=1}^N \begin{cases} 1, & r_i \leq K \\ 0, & r_i > K \end{cases} \quad (2-7)$$

r 则代表排名前 K ，如果排名在前 K 名，加 1，否则，加 0。累加 N 次，最后再除以 N 就得到了目标行人在排名前 K 中所占的比例。

对于行人重识别任务来说, CMC 一般选择 rank-1, rank-5 和 rank-10 进行计算, 而常用的则是 rank-1 指标, 即首位命中率。如果模型预测结果在 rank-1, rank-5 和 rank-10 上的都有较大的数值, 则说明模型可以在数据量较大的行人标签样本筛选出正确的目标标签样本。因此, CMC 和 mAP 可以作为行人重识别的评价标准。

2.6 本章小结

本章主要介绍了行人重识别中的相关技术。首先介绍了行人重识别中主要的提取特征的方法, 即利用预训练卷积神经网络来提取行人特征, 并介绍了常用的预训练网络模型。其次, 本文介绍了行人重识别任务中两个重要的评价指标: mAP 和 CMC。通过这两个指标对各个行人重识别模型进行比较, 研究者可以直观地得到模型间性能差异, 进而在当前技术发展的基础上继续完善或者提出新模型。此外, 本文继续深入阐述在行人重识别任务中, 行人特征多尺度判别和度量学习的使用方式, 即将常规的行人重识别方法与多尺度思想进行结合的方法, 并且还详细介绍了度量学习中常用的三元组损失。最后, 本文又对行人重识别中数据增广的方法进行了说明, 例如最常用的随机擦除技术, 较为常用的人体部位语义分割技术和无监督或半监督学习中应用较为广泛的 GAN 造图技术。在下一章, 本文将对在行人重识别任务中所采用的研究方法加以详细说明和阐述。

第3章 基于人体语义分割与多尺度特征的行人重识别模型

本章研究利用人体部位语义分割以及多尺度特征学习设计一个多任务联合的行人重识别模型 MDRS。其中,人体部位语义分割旨在进行行人全局特征空间的对齐和区域关注度的任务,而多尺度特征学习将主干网络提取的特征进行多尺度划分,并根据划分的尺度进行对应数量的水平切块划分,得到的全局特征进行相似性度量学习,局部特征进行对应区域的特征匹配。本章提出的方法可以有效地结合多尺度特征学习和人体区域语义分割来进行行人重识别任务,具有十分优异的性能。

3.1 总体模型框架

现如今,行人重识别任务的主要流程是利用深度神经网络进行行人特征提取再进行特征相似度比较和分类。在特征提取时一些误差和错误的匹配信息有可能会被作为特征学习的依据,最终降低整体模型的性能。如果在特征提取时减轻错误信息的匹配和传递,让网络更多地注意到行人的特征而非类似背景等的冗余区域,则可以很大程度上提高行人重识别的性能。因此,可以利用其他领域的方法与行人重识别进行相结合来完成行人重识别任务,例如目标检测、语义分割和风格转换等,这样的模型设计方式就属于多任务特征学习的方式。

研究表明,多任务学习策略通过在任务间适当地共享特征信息,取得了较好的效果,这同样有助于行人重识别任务的开展和实施。为了实现行人重识别的多任务特征学习,本文设计的框架将考虑三个相关损失对应三个相关任务,它们分别是:多尺度标签损失用于行人全局和局部特征分类;多尺度三元组损失用于行人全局特征相似性度量;多尺度人体区域分割损失用于行人全局特征的区域关注和特征对齐。本文的总体模型框架如图 3-1 所示。




图 3-1 多任务网络设计思路

Fig. 3-1 The design idea of multi-task network

首先, 将行人图像经过数据预处理操作后输入主干网络, 利用多尺度特征提取模块得到多尺度特征图。之后, 每个尺度的特征图(图 3-2 中所表示的 P_1 、 P_2 、 P_3)将被分割成若干个水平图像切块。每个水平图像切块和三个不同尺度的全局特征经过池化和降维操作后, 各自都由 256 维向量表示, 并将这些向量中作为输入进入分类器, 得到的输出与行人标签相比较来最小化标签损失(任务 1)。在训练阶段, 每个行人图像的标签被设置为该输入图像所属行人的标签。在任务 2 中, 所有尺度分支中的全局特征向量将拼接在一起作为一个新的特征向量来进行三元组损失的计算。此外, 针对行人各部位的语义分割任务设计多尺度分割模块, 将其与多尺度全局特征相结合, 以最优化多尺度分割损失(任务 3)为目标来辅助进行行人重识别工作, 其中人体部位的伪标签通过 COCO-Densepose 数据集上训练的模型获得。本文模型的框架具体组成如图 3-2 所示。




图 3-2 MDRS 框架图

Fig. 3-2 The architecture of MDRS

3.2 多尺度特征提取模块

行人重识别的识别步骤是在 gallery 库中找到与 query 库中标签一致的行人图片。由于识别时比较特征间的相似度，因此整体网络框架中主干网络的特征提取能力在很大程度上决定了行人重识别任务的最终效果。

本文采用 ResNet-50 作为特征提取的主干网络，并修改了 ResNet-50 的最后几层的结构，即在 Conv5 上对每个尺度各自使用不同步长的卷积层、批标准化层和激活层来获得不同尺度的特征图，其中 $S = \{s_1, s_2, \dots, s_Q\}$ 是步长集合， Q 是尺度个数。在本文中，设置 $s_1 = Q, s_2 = Q - 1, \dots, s_Q = 1$ ，即意味着卷积层步长越大特征提取网络获得的特征图尺度越小。

一方面，这些特征图作为行人的全局特征被输入到不同尺度的分支中，即输入到分支 P_1 到 P_Q 中，用于池化和降维操作。对于步长为 s_1 的分支 P_1 ，行人的全局特征可以直接得到，无须进行水平图像切块划分局部特征。而从 P_2 分支到 P_Q 分支，本文框架将每个全局特征图分割成若干个水平特征切块，其中水平特征切块的数量随着全局特征图的大小的增大而增加，以保证特征切块划分时，每个水平特征切块所代表的局部特征拥有较为丰富的细节。另一方面，除了针对行人特征的多尺度判别，这些由多尺度特征提取模块提取的全局特征图还将会输入到多尺度分割模块中，用于进行人体部位的标签预测。整个网络框架中，只有通过多尺度特征提取模块进行行人的全局和局部特征学习，才能很好地完成人体区域语义分割和行人重识别任务。

3.3 基于多尺度全局和局部水平切块特征的交叉熵损失

行人特征的分类和匹配任务，通常与其他传统的分类匹配任务一致。在深度学习中，利用神经网络中的分类器得到预测的特征分数，之后在训练过程中，这些预测的特征分数与样本标签经过网络不断的迭代，特征分数会不断地靠近样本标签，最终可以得到很好的分类网络来测试其他图像样本。而在行人重识别任务中，行人特征需要通过池化和降维等操作才能进行标签预测，那么如果行人特征除了全局特征还包括若干个局部特征，则标签损失需要针对提取的全局和局部特征进行合理地设计。

本文所提出的网络框架中，全局特征的水平切块数量随着全局特征图的尺度呈正相关，目的是可以在划分多块局部特征时保留行人信息中更多的细节。经过池化和降维之后，每个尺度下的全局特征以及对应尺度下的每个水平特征切块分别由单独的 256 维向量表示。




图 3-3 多尺度全局和局部水平切块特征划分框架

Fig. 3-3 The framework of multi-scale global and local horizontal stripes

如图 3-3 所示，分支 P_1 的全局特征图没有进行水平切块处理，因此只包含一个特征块。在 P_2 分支中，全局特征图额外分割成两个水平特征切块，该水平切块特征表示行人的局部特征，再对其分别进行池化和降维操作，生成 3 个 256 维特征向量。这里，将每个特征向量称为切块特征向量。在分支 P_3 中，行人全局特征则是被分成三个水平特征切块，以相同的处理方式就得到了 4 个 256 维的切块特征向量。最后，将所有特征向量送入至各自对应的分类器中预测行人标签分数，以进行行人重识别任务。

本文利用交叉熵(cross-entropy)损失作为标签损失来对整体的网络框架进行优化。在一个批次 N 幅图像中，基于多尺度全局和局部水平切块特征的交叉熵损失公式如下：

$$L^{id} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^P \log(p(y_i | I_{ij})) \quad (3-1)$$

其中 $p(y_i | I_{ij})$ 是 I_{ij} (第 i 个行人图像的第 j 个 256 维切块特征向量) 具有行人标签 y_i 的概率。预测的标签概率由在切块特征向量上进行分类处理的 softmax 层计算。

此外,本文框架中对于相同行人样本得到的所有切块特征都采用相同的行人标签进行标签损失的计算。通过标签损失将行人在特征级别进行分类和匹配,对行人信息进行多尺度特征学习可以有效地实行人重识别工作。

3.4 基于多尺度全局特征的三元组损失

利用三元组划分数据集样本的思想在行人重识别数据样本上进行聚类 and 分离操作。在行人重识别任务中,相同行人标签的 query 查询图像与 gallery 行人库图像在特征级别上应该是彼此接近的,而不同行人标签的图像则应该在特征级别上是互相远离的,这样就可以将行人图像在特征层面上聚集分块,使得网络在训练阶段可以更好地学习相同行人不同姿态的图像信息,并且对于不同行人特征则更具有判别力。

如果是在一个批次里进行深度神经网络训练,则计算三元组损失前需要确定采样器中采样的行人标签和对应标签的图片数量,这样就可以利用矩阵运算快速的得到多个样本对距离,以便进行正样本对拉近和负样本对推远的操作。在样本对距离的选择上,可以选择欧氏距离或者余弦距离,而本文采用欧氏距离作为特征相似度计算的基准,其原因是欧氏距离计算效率更高,同时也在计算时也不丢失较多的行人特征信息。此外,由于行人图片在目标检测时可能存在不完整或者遮挡以及背景比例失衡等因素,局部特征不可单独作为三元组损失的样本对进行比较,否则会在三元组损失计算时对整体网络迭代回归产生较大的误差,影响整体网络的性能。

在本文中,不同尺度的全局特征图拼接在一起组成一个新的特征向量,并利用这个组成后的特征向量来计算三元组损失。一个三元组称为 (I_a, I_p, I_n) ,其中 (I_a, I_p) 代表具有相同行人身份的正样本对, (I_a, I_n) 则代表具有不同行人身份的负样本对。由此,本文提出基于多尺度全局特征的三元组损失,公式如下:

$$L^{triplet} = \frac{1}{N_{triplet}} \sum_{(I_a, I_p, I_n)} \left[d(h(I_a), h(I_p)) - d(h(I_a), h(I_n)) + \alpha \right]_+ \quad (2-2)$$

其中 α 是平衡行人正样本对距离和行人负样本对距离的 margin 超参数(特征距离阈值), $N_{triplet}$ 是三元组样本个数, $d(x, y) = \|x - y\|_2^2$ 代表的是欧氏距离,其中 $h(I)$ 代表每个尺度的全局特征拼接在一起构成的新特征 I ,此外, $[z]_+ = \max(z, 0)$ 代表 hinge 铰链损失。

通过计算三元组损失,本文的模型可以将行人信息在特征级别进行聚类操作。由于拼接的全局特征拥有不同的尺度,因此模型可在不同信息粒度上有效地实行人重识别工作。

3.5 多尺度人体部位语义分割模块

现如今，大多数的行人重识别算法主要分为两种：第一种，使用水平图像切块对行人图像进行划分^[14,18,24,27,36]，划分得到的特征就是行人的局部特征，并利用这些局部特征进行标签损失的计算；第二种，在主流的语义分割网络的基础上加以修改^[11,34]，使得模型对行人特征尤其是人体的各个部位进行分割，通过这样的方法来对行人进行重识别的任务。这两种方法在行人重识别算法中都十分有效，对行人重识别的任务也都有着极大的帮助。然而，如果将二者结合到一起，并形成端到端的架构来同时产生作用，就意味着网络的深度和参数数量大幅度增加，因此，训练这样较为庞大的模型并使其性能优异，目前仍存在着挑战。

为了将多尺度行人特征与行人部位语义信息相结合，本文设计了一个多尺度分割模块来预测人体 K 个部位的像素级标签。多尺度分割模块由两个子模块组成：一个多尺度的上采样器子模块 (Upsampler) 和最后的分割子模块 (Segmentation)，其整体网络设计结构如图 3-2 所示。由于主干网络提取的多尺度全局特征图尺寸较小，为了进行像素级的损失计算，这些全局特征图 $\{F_1, F_2, \dots, F_Q\}$ 需要经过若干次上采样，目的是使其与行人部位伪标签样本拥有一致图像尺寸。因此，本文采用若干个卷积核大小为 3×3 的转置卷积层 (Deconv layer) 来实现上采样。




图 3-4 多尺度人体部位语义分割模块示意图

Fig. 3-4 The architecture of multi-scale human part semantic segmentation module

在多尺度人体部位语义分割模块中，每个转置卷积层用于将全局特征图的大小增加一倍，但是特征图的通道的数量减少一半，所以尺度较小的图则需要更多的上采样操作，即需要更多的转置卷积层来逐步扩大特征图的尺寸。上采样结束

之后的全局特征大小保持不变, 仅仅采用若干个卷积核大小为 1×1 的卷积层来调整特征的通道数, 使之与行人部位伪标签包含的区域个数相等。在图 3-4 中, 上采样模块也被划分为多个分支进行上采样处理, 每个尺度的分支都各自由一组转置卷积层组成, 数量反比于输入的全局特征图大小; 分割子模块包含每个尺度分支各自的 BatchNorm 层(BN)、ReLU 激活层、卷积核大小为 1×1 的卷积层。最后, 通过逐像素的 softmax 计算得到行人图像的多尺度伪标签预测值 $\{ML_1, ML_2, \dots, ML_Q\}$ 。

在本文提出的网络框架中, 多尺度人体部位语义分割模块将强制多尺度特征提取模块学习有助于行人部位分割的判别特征。因此, 一方面多尺度特征提取模块主要学习到的特征将集中在人体部位, 而不是毫无关系的背景杂波等特征, 另一方面也有利于标签损失和三元组损失的计算。通过这样的网络设计, 行人部位语义分割就可以辅助特征提取阶段来进行行人重识别任务。




图 3-5 人体部位标签和多尺度标签预测示意图

Fig. 3-5 Examples of body part labels and multi-scale label predictions

为了获得更好的性能, K (行人伪标签的种类数)应该设置足够大, 这样就可以包括分割标签中小尺寸的语义部位区域, 例如尺寸较小的头部和足部。具体地, 本文主要对 8 个人体部位($K = 8$)进行了伪标签的预测, 即{背景、头部、躯干、上臂、下臂、大腿、小腿、脚}, 如图 3-5(a)所示。在图 3-5(b)中, 多尺度标签预测图像 $\{ML_1, ML_2, \dots, ML_Q\}$ 是从多尺度特征图 $\{F_1, F_2, \dots, F_Q\}$ 通过若干次转置卷积和逐像素分类得到的。从左到右看, 多尺度全局特征图的标签预测图像按照全局特征图的尺寸大小顺序进行展示。针对相同标签的行人图像样本而言, 不同尺度上的多尺度标签预测图像的语义分割结果是相似的, 否则就说明多尺度语义分割模块在设计上存在较大问题, 需要进一步改进。此外, 还可以从图中看到, 随着全局特征图尺寸的增加, 红色区域更加突出和精细, 各个颜色部分的轮廓也更加鲜明。例如, ML_1 中的头部标签预测图像不如 ML_2 中的准确, 其中周围的背景也被预测为头部标签。然而, ML_3 中的这种错误分割的现象得到了很大程度的缓解, 可以看到随着全局特征图尺度的增大, 语义分割得到的结果越好, 因为越大的特征图包含的信息也越多。因此, 在人体部分分割中使用多尺度特征是有效的。

为了增加行人样本场景的随机性, 本文在进行多尺度行人部位语义分割之前, 对原始图像和行人部位伪标签图像进行随机擦除^[17], 由于随机擦除会改变数据集的原本像素分布和编码形式, 因此行人伪标签数据同样需要在对应的位置进行等比例的随机擦除, 保证数据映射的一致性, 因此对于多尺度特征提取模块和多尺度分割模块都会增加特征学习和判别的多样性。所以, 这是一种有效的数据增广方案。此外, 擦除率 r_e 是随机生成的, 则选择随机擦除的矩形区域对于每张行人图片都不完全一致, 这也在很大程度上提高了整体网络结构的鲁棒性和泛化性。

多尺度人体部位语义分割损失公式如下:

$$L^{ms} = \frac{1}{Q} \sum_{i=1}^N \sum_{q=1}^Q L_{i,q}^{ms} \quad (3-3)$$

其中 Q 是多尺度的尺度个数, N 是一个 batch 的大小, $L_{i,q}^{ms}$ 是逐像素的交叉熵 (cross-entropy) 损失, 最后所求的是所有分割损失的平均值 L^{ms} 。

通过多尺度人体部位语义分割损失, 将行人特征在不同尺度进行上采样比较行人各部位的语义分割信息, 有助于加强行人全局特征中行人特征的关注度和敏感度, 减弱类似背景或遮挡等干扰因素的影响。由于提取的全局特征拥有不同的尺度, 因此多尺度分割网络在不同信息粒度上有效地实施行人部位语义分割的任务, 进而辅助行人重识别工作。

3.6 多任务损失训练和测试

多任务网络近年来称为了主流, 类似孪生网络和多分支网络等都是多任务网络的主要体现, 尽管优良的多任务网络可以解决诸多的问题, 但是其参数量庞大

和较高的网络深度也使得研究者不得不考虑其他快速而有效的方法。因此,对于多任务网络,设计端到端的架构将十分具有挑战。

对于多任务网络,每个子任务一般对应一个损失函数来进行子网的训练,因此每个损失函数对于整体的网络训练非常重要,如果其中的某一个损失函数设计不当,则可能导致整体网络训练的失常和发散。一般地,整体网络的总损失函数等于其各个任务的所对应的损失函数之和,且每个任务的损失函数前拥有超参数,超参数决定子任务占总体任务的权重。如果在损失函数设计时设计出一组合理的超参数,则可以让整体网络快速收敛并具有较高的性能。对于行人重识别任务来说,最常见的损失是标签损失,因此一般的行人重识别网络都是单任务。而如果设计多任务网络,则需要在合适的位置添加子网或者子模块来完成新功能,并保持原有网络功能,在此基础上添加新的任务或者损失函数。

本文考虑了多尺度标签损失、多尺度三元组损失和多尺度分割损失之间的相互作用,并通过探索它们之间的潜在相关性来提高行人重识别的性能。总损失函数公式为:

$$L = \lambda_1 L^{id} + \lambda_2 L^{triplet} + \lambda_3 L^{ms} \quad (3-4)$$

其中, λ_1 、 λ_2 和 λ_3 是分别是基于多尺度全局和局部水平切块特征的交叉熵损失、基于多尺度全局特征的三元组损失和多尺度人体部位语义分割损失的权重,通过本文模型的交叉验证,将三者分别设置为1、2和1。

在这三种损失函数中,基于多尺度全局和局部水平切块特征的交叉熵损失最为重要,因为该损失针对于不用尺度的全局特征和局部特征的信息匹配和判别,所以它决定了行人重识别模型的准确性,而另外两种损失的作用都是进一步提高模型识别的精度,并且多尺度人体部位语义分割损失比基于多尺度全局特征的三元组损失对模型的最终性能影响更大。多任务损失中每个损失的作用将在实验的消融研究中得到比较和证明(见第4.5节)。

在测试阶段,所有尺度256维的水平切块特征向量拼接成一个大的切块特征向量,并以query数据集和gallery数据集这两者拼接得到的水平切块特征向量之间的余弦距离作为相似性度量分数进行排序。

通过多任务网络损失函数的设计和训练超参数的设置,我们就可以端到端地让各个子模块共同完成行人重识别任务。对于参数量较大的网络模型,则需要注意batch大小的设置以及优化器参数的设置,以便缩短训练时间,提高效率。

3.7 本章小结

本章主要介绍了基于人体语义分割与多尺度特征的行人重识别模型的网络搭建和损失函数设计。相比于其他的行人重识别方法,本章所提及的多任务和端

到端结构在一般的行人重识别网络上性能更加优异,并且设计的多尺度分割模块跨领域地将行人重识别任务和语义分割进行了结合,并取得了很好的效果。然而,该方法还存在一定的局限性,例如多尺度特征提取的设计忽视了局部特征间的相关性以及行人预测伪标签的准确性低导致的错误分割问题。在未来的工作中,将尝试使用更为复杂的特征提取的方法(例如行人特征金字塔结构)来提高特征间的相关性,以及训练更加准确的伪标签预测模型对行人重识别数据集重新标签标定工作。下一章着重介绍具体的行人重识别的实验实施细节和效果比对等内容,并且对网络结构中的子模块以及尺度选择等变量进行消融研究,得到模型本身的各个组成部分的效果比较。

第4章 实验结果与分析

4.1 数据集

在行人重识别数据集中，同一个行人标签的图像由多个摄像机拍摄得到，由于采集摄像机的视角和位置均不相同，因此采集的行人样本不仅在姿态上不同，其对应的背景环境、光照强度、以及行人部位采集的完整度也都不相同。对于摄像机采集的行人图像，在采集之后还需要进行人工筛选或者模型检测筛选等步骤，选择得到合适的行人图片作为数据集中的样本。除此之外，行人图像还需要进行行人标签的标定工作，一般同一个行人标签对应多个摄像机下的不同采集图像，通过这样的方式，研究者或监控者就可以从这些摄像机下拍摄到的某个行人找到另一个摄像机下拍摄的相同的行人。



图 4-1 行人重识别三大公开数据集

Fig. 4-1 Three public datasets of person re-identification

因此,对于深度学习网络,行人特征的提取效果在很大程度上受数据集样本分布的影响。现如今,为了验证算法和模型在行人重识别任务中效果,研究者可利用 Market-1501^[16]、DukeMTMC-reID 和 CUHK03 这三个公开数据集进行行人重识别工作。三个公开数据集如图 4-1 所示,红色部分为 Market1501 数据集,蓝色部分为 Duke 数据集,黄色部分为 CUHK03 数据集。本文将按章小节分别对这三个数据集进行介绍。

4.1.1 Market-1501

Market-1501 数据集^[16]包含 32688 张 1501 个不同行人身份的图像,这些图像由 DPM (Deformable Part Model)^[15]行人检测器检测得到,其中包括了一些行人与背景没有较好对齐的检测框。数据集采集时使用六个不同位置视角的摄像头,其中包括 5 个高分辨率摄像头和一个低分辨率摄像头。此外,在该数据集的标准评估协议中,750 个行人标签用于训练,总共 12936 张图像以及 2793 个干扰样本,其余 751 个行人标签分别用于测试 gallery 数据集的 19734 张和 query 数据集中的 3368 张图像。

4.1.2 DukeMTMC-reID

DukeMTMC-reID 数据集^[21]由从 DukeMTMC 跟踪数据集^[20]中提取出的行人图像组成。在这个数据集中,每个行人样本图像是从 8 台高分辨率相机上拍摄得到的,其中包含 1404 个身份,并且还带有人工标注的标签。该数据集使用与 Market-1501 相同的协议^[21],并且将 702 个行人标签对应的 16522 个图像作为训练集。除此之外,测试集包含 19889 张图像,由 2228 张 query 数据集图像和 17661 张 gallery 数据集图像组成,其中 gallery 数据集中包含其他 702 个行人标签和额外的 408 个干扰标签(总共 1110 个标签)的行人图像。

4.1.3 CUHK03

按照新的训练/测试协议^[19],CUHK03 数据集^[10]中有 767 个训练行人标签和 700 个测试行人标签。此外,该数据集包含两个版本的行人检测框:一个是人工标记的,另一个由行人检测器检测得到。人工标记的子数据集包括 1400 个 query 数据集图像,并且在 gallery 数据集中有 5328 个图像用于测试以及 7368 个图像用于训练。而利用行人检测器检测得到的子数据集中包含 7365 个训练行人图像,1400 个 query 数据集图像和 5332 个用于测试 gallery 数据集图像。

在行人重识别数据集中,行人和背景面积比例正常(行人占较大空间比例,背景占较小空间比例)的数据样本占绝大多数,然而当检测框检测的图像没有对齐而导致的行人与背景占比失衡的情况存在时,行人重识别模型会在很大程度上

产生错误的识别结果。因此, 尽管这样的数据占总样本数据较小, 却可用作难例样本进行模型效果的判定。对于遮挡的行人图像, 同样会存在模型识别产生误差的情况, 这些都是实际场景中常见的应用问题, 因此模型同样需要对这样的数据集样本进行相应的算法设计和模型框架的搭建任务。

4.2 实验细节

对于行人重识别任务来说, 研究者需要通过对训练过程的各项分配细节进行参数设置和数据采样的设计, 才能完成行人重识别的模型训练和测试工作。期间, 研究者主要需要注意的是数据预处理、损失函数超参数设置、优化器参数设置、训练周期设置、学习率调度器的训练周期设置以及 batch 大小的设置等因素, 这些因素将直接导致整个模型训练过程的收敛情况以及最终模型的重识别效果。对于类似三元组损失这样的非随机采样方式, 研究者还需要设计相应的优化器来构造三元组结构, 以便完成三元组损失的计算。因此, 设置恰当的训练参数可以有效地保证整体网络的优良性能。

在本文中, 输入网络前的所有行人图像的分辨率在数据预处理阶段都调整为 384×128 。在主干网络的参数初始化阶段, 本文对 ImageNet 上预训练的 ResNet-50 模型参数进行初始化, 并将其作为主干网络的参数用于行人特征提取。在训练阶段, 行人样本图像和相应的人体部位分割标签图像进行随机水平翻转和随机擦除^[17]操作, 这样做可以提高行人重识别场景的多样性。此外, 多尺度网络的全局特征的尺度数量 Q 的数目设置为 3, 这样模型训练优化阶段就可以利用三个尺度的全局特征进行标签损失、三元组损失和多尺度分割损失的计算。在损失函数中, 三元组损失的 margin 值设置为 0.3, 并且为了构造三元组样本, 本文构造了一组 N 个样本的小批量图像, 并在每次训练迭代的过程中随机选择 P 个行人标签和每个标签对应的 I 个图像作为采样器采样的 N 个样本图像。这里本文设置 $P = 8$, $I = 4$, 因此 $N = P * I = 32$ 。对于训练阶段优化器的选择, 本文采用 Adam 优化器作为模型迭代收敛的策略, 其中 Adam 优化器的 beta 因子设置为 0.9, epsilon 因子设置为 $1e-8$, 权重衰减因子设置为 $5e-4$ 。除此之外, 整体网络训练的初始学习率 learning rate 设置为 $2e-4$, 并且分别经过 360 和 420 个训练周期后逐渐下降为 $2e-5$ 和 $2e-6$ 。总体而言, 整体的模型网络框架将在一块单一的 NVIDIA GTX 1080Ti GPU 上训练 440 个周期。

通过以上的参数设置, 本文提出的网络框架就可以在训练迭代收敛完成后以优异的性能完成行人重识别任务。具体的实验数据将在 4.4 节进行详细介绍。

4.3 评价函数

在模型重识别性能评估阶段, 本文采用 *Rank-1*、*Rank-5* 和 *Rank-10* 的累积匹配特征曲线(CMC)和平均精度均值(mAP)这两种评价函数, 把本文模型算法与其他具有竞争力的行人重识别算法进行性能比较。此外, 本文中所有的实验都是在 single query 设置的前提下, 采用 Market-1501、DukeMTMC-reID 和 CUHK03 这三个公开数据集来实施进行的。为了公平起见, 本文列出的模型重识别结果没有使用 re-ranking^[19]算法来进行提升。


4.4 行人重识别算法性能比较

在表 1、表 2 和表 3 中, 本文列出了本文提出的算法与最近提出的几种最新算法在三个公共数据集 Market-1501、DukeMTMC-reID 和 CUHK03 上的性能比较。接下来分别按照数据集的顺序进行说明。


4.4.1 各模型在 Market-1501 数据集上的性能比较

为了验证实验结果的真实可靠, 本文将 MDRS 在 Market1501 数据集上的识别率变化趋势进行记录, 如图 4-2 所示, 随着训练 Iteration 的不断增加, 本文提出的模型在 Market1501 数据集上各损失逐渐迭代至收敛。从图 4-2(a)中可以看出, 8 个水平切块特征对应的交叉熵损失在训练前期的变化程度互不相同, 这也体现出网络模型在学习行人特征时针对各个特征的适应性有所不同。图 4-2(b)中的基于多尺度全局特征的三元组损失是三个多尺度全局特征拼接之后计算的, 因此当该损失逐渐下降至稳定值时, 模型对每个尺度全局特征的学习程度也达到了最优。图 4-3(c)展示的是多尺度人体部位语义分割损失, 从该图可以看到学习率经历了一次明显的下调, 这样做有利于训练更为快速地达到收敛。当该损失处于稳定时, 模型针对人体部位语义分割的效果也达到了较高的水平。


因此, 当以上三种损失在多任务网络中逐渐迭代至收敛时, 本文提出的 MDRS 模型就可以在较高的性能下完成行人重识别任务。此外, 从图 4-3 中可以看到, 本文提出的 MDRS 模型在训练收敛后的两种识别率的评价指标 Rank-1 和 mAP 都达到了较高的数值, 没有出现准确度较低或者逐渐下降没有准确度的情况, 因此也可以说明本文将人体语义分割与多尺度特征学习相结合的思想是十分有效的。



(a) 基于多尺度全局和局部水平切块特征的交叉熵损失



(b) 基于多尺度全局特征的三元组损失



(c) 多尺度人体部位语义分割损失

图 4-2 MDRS 模型在 Market-1501 数据集上的各损失变化趋势

Fig. 4-2 Losses trend of MDRS on Market-1501 dataset




图 4-3 MDRS 模型在 Market-1501 数据集上的识别率变化趋势

Fig. 4-3 Identification rate trend of MDRS on Market-1501 dataset

如表 4-1 所示, 本文提出的 MDRS 在 *Rank-1*(95.8%)上取得了最好的结果, 并且在 *mAP* 指标上与 DSA-reID 并列第二(87.6%)。PCB+triplet 模型是在 PCB(part-based convolutional baseline)的基础上加了额外的三元组损失进行训练的。VPM 是一种可见性感知模型, 它通过自监督学习来感知区域的可见性, 属于水平区域划分的模型之一。两种方法的 *mAP* 指标分别为 83.0%和 80.8%。MGN 多粒度网络模型在仅考虑局部信息的基础上, 还考虑了全局和局部信息相结合的特征学习方式。在 *mAP* 指标上, 本文提出的模型算法比 MGN 的性能提高了 0.7%。SPReID 并不属于局部特征区域划分的算法, 该模型则考虑了人体部位的语义分析, 其性能也不如本文提出的 MDRS (83.4%比 87.6%)。这些结果表明, 人体部位区域分割和多尺度特征提取相结合提高了行人重识别的性能。因此, 可以说明本文提出的网络框架模型在 Market-1501 数据集具有十分优异的性能。

表 4-1 现有模型在 Market-1501 数据集上的性能比较

Tab. 4-1 Performance comparison of existing models on Market-1501 dataset

Method	<i>mAP</i>	<i>Rank-1</i>	<i>Rank-5</i>	<i>Rank-10</i>
MDRS	87.6	95.8	98.4	99.1
DSA-reID ^[35]	87.6	95.7	-	-
MGN ^[18]	86.9	95.7	-	-
PCB+triplet ^[5]	83.0	93.4	97.8	98.4
CASN(PCB) ^[34]	82.8	94.4	-	-
PCB+RPP ^[14]	81.6	93.8	97.5	98.5
VPM ^[5]	80.8	93.0	97.8	98.8
PCB ^[14]	77.4	92.3	97.2	98.2
GLAD ^[7]	73.9	89.9	-	-
MultiScale ^[4]	73.1	88.9	-	-
PartLoss ^[24]	69.3	88.2	-	-
PDC ^[23]	63.4	84.4	-	-
MultiLoss ^[27]	64.4	83.9	-	-
PAR ^[6]	63.4	81.0	92.0	94.7
HydraPlus ^[2]	-	76.9	91.3	94.5
MultiRegion ^[37]	41.2	66.4	85.0	90.2
SPReID ^[11]	83.4	93.7	97.6	98.4
AOS ^[26]	70.4	86.5	-	-
Triplet Loss ^[42]	69.1	84.9	94.2	-
Transfer ^[33]	65.5	83.7	-	-
PAN ^[29]	63.4	82.8	-	-
SVDNet ^[25]	62.1	82.3	92.3	95.2

如图 4-4 所示, 本文展示了若干个在 top-10 上 MDRS 模型检索 gallery 图像的样例。由图可知, 排名靠前的 gallery 图像与 query 图像具有相同的行人身份标签。然而, 模型在预测时仍旧存在一些错误的行人标签分类情况, 错误分类的主要原因是行人服装图案花纹材质等方面相似度较高, 错误样例中还展示了模型预测行人标签时忽视行人背包的现象。总体而言, 本文提出的 MDRS 网络模型在 Market-1501 数据集上具有优良的性能和较高的鲁棒性。




图 4-4 本文提出的 MDRS 模型在 Market-1501 数据集上的重识别样例

Fig. 4-4 Re-ID examples of MDRS on Market-1501 dataset

4.4.2 各模型在 DukeMTMC-reID 数据集的性能比较

如图 4-5 所示, 本文提出的 MDRS 模型的评价指标 Rank-1 和 mAP 在训练收敛后都达到了较高的数值, 分别为 89.4%和 79.4%。如表 4-2 所示, 在具有挑战性的 DukeMTMC-reID 数据集上, 本文提出的 MDRS 方法在 Rank-1 和 mAP 评价函数上比金字塔模型 Pyramid 的精度分别高出 0.4%和 0.4%。此外, MDRS 在评价函数 mAP 和 Rank-1 上的效果也分别超过 PCB+triplet 模型, 分别高出了 6.2%和 5.3%。CASN(PCB)是近几年提出的一种新颖的注意力驱动的孪生网络特征学习架构, 该模型建立在 PCB 框架之上, 联合了区域注意力一致性, 但是该模型的性能也比 MDRS 的性能要差(在 mAP 评价函数上 CASN(PCB)是 73.7%, 而 MDRS 是 79.4%)。到目前为止, 还没有针对行人重识别数据集的有专门标定的人体密集语义部位标签, DSA-reID 模型同样利用了 COCO DensePose 数据集上训练的 DensePose 模型预测行人部位伪标签。然而, 它的 mAP 比 MDRS 低 5.1%。除此之外, 在所有性能优异的模型算法中, MDRS 在该数据集上的 Rank-5 和 Rank-10 指标都是最高的。由此, 可以说明本文提出的网络框架模型在 DukeMTMC-reID 数据集具有十分优异的性能。




图 4-5 MDRS 模型在 DukeMTMC-reID 数据集上的识别率变化趋势

Fig. 4-5 Identification rate trend of MDRS on DukeMTMC-reID dataset

表 4-2 现有模型在 DukeMTMC-reID 数据集上的性能比较

Tab. 4-2 Performance comparison of existing models on DukeMTMC-reID dataset

Method	<i>mAP</i>	<i>Rank-1</i>	<i>Rank-5</i>	<i>Rank-10</i>
MDRS	79.4	89.4	95.1	96.8
Pyramid ^[36]	79.0	89.0	94.7	96.3
MGN ^[18]	78.4	88.7	-	-
CASN(PCB) ^[34]	73.7	87.7	-	-
DSA-reID ^[35]	74.3	86.2	-	-
SPReID ^[11]	73.3	86.0	93.0	94.5
PCB+triplet ^[5]	73.2	84.1	92.4	94.5
VPM ^[5]	72.6	83.6	91.7	94.2
PCB+RPP ^[14]	69.2	83.3	-	-
PSE+ECN ^[32]	75.7	84.5	-	-
DNN-CRF ^[31]	69.5	84.9	-	-
GP-reid ^[28]	72.8	85.2	-	-
AOS ^[26]	62.1	79.2	-	-

4.4.3 各模型在 CUHK03 数据集上的性能比较

如图 4-6 和图 4-7 所示, 本文提出的 MDRS 模型在 CUHK03 Detected 数据集和 CUHK03 Labelled 数据集上的两种识别率评价指标达到较高的数值。如表 4-3 所示, 在论文[19]中对于该数据集的新协议下, 本文的 MDRS 同样具有十分优异的性能, 并且比其他模型的行人重识别效果要更精确。对于手工标定的数据集(labelled setting)而言, 本文提出的模型在 *Rank-1* 和 *mAP* 上至少高出了 5.3%和

8.4%，而对检测器检测的数据集(detected setting)而言，本文提出的模型在 *Rank-1* 和 *mAP* 上至少高出了 7.2%/9.8%。并且，在 CUHK03 这个数据集上，本文提出的 MDRS 在行人重识别任务的性能上也较为接近金字塔模型 Pyramid 的性能。此外，在人工标定和检测器检测的数据集上，本文提出的模型在评价函数 *mAP* 上分别比 DSA-reID 模型分别高了 1.2%和 1.1%。由此可见，本文提出的网络框架模型在 CUHK03 数据集上具有较高的精确度。




图 4-6 MDRS 模型在 CUHK03 Detected 数据集上的识别率变化趋势

Fig. 4-6 Identification rate trend of MDRS on CUHK03 Detected dataset




图 4-7 MDRS 模型在 CUHK03 Labelled 数据集上的识别率变化趋势

Fig. 4-7 Identification rate trend of MDRS on CUHK03 Labelled dataset

表 4-3 现有模型在 CUHK03 数据集上的性能比较

Tab. 4-3 Performance comparison of existing models on CUHK03 dataset

Method	Labelled				Detected			
	<i>mAP</i>	<i>Rank-1</i>	<i>Rank-5</i>	<i>Rank-10</i>	<i>mAP</i>	<i>Rank-1</i>	<i>Rank-5</i>	<i>Rank-10</i>
MDRS	76.4	79.0	91.1	94.6	74.2	78.7	90.5	94.1
DSA-reID ^[35]	75.2	78.9	-	-	73.1	78.2	-	-
CASN(PCB) ^[34]	68.0	73.7	-	-	64.4	71.5	-	-
MGN ^[18]	67.4	68.0	-	-	66.0	68.0	-	-
PCB+RPP ^[14]	-	-	-	-	57.5	63.7	-	-
MLFN ^[30]	49.2	54.7	-	-	47.8	52.8	-	-
AOS ^[26]	-	-	-	-	43.3	47.1	-	-
SVDNet ^[25]	37.8	40.9	-	-	37.3	41.5	-	-
PAN ^[29]	35.0	36.9	-	-	34.0	36.3	-	-
IDE ^[13]	21.0	22.2	-	-	19.7	21.3	-	-

4.4.4 总结

上述三个数据集的实验结果表明,本文提出的多尺度特征学习、水平切块特征划分和人体部位区域语义分割相结合的 MDRS 方法具有良好的行人重识别性能。此外,本文所提出的模型与现有模型的复杂度比较如表 4-5 所示。可以看出,由于多尺度特征提取模块和多尺度区域分割模块的加入,MDRS 网络搭建资源需求高于其他方法,但是精确度也有了大幅度的提升,可以说是达到了提高行人重识别精确度的目的。

因此,本文提出的将多尺度特征学习与语义分割进行结合的思想是非常可行和有效的,并且本文这样的多分支网络除了可以进行重识别任务之外也同样可以用来做语义分割任务,那么这样端到端的多任务网络框架在将可以结合其他方法继续提升行人重识别任务的性能。

4.5 消融研究

除了本文提出的网络框架模型在三个公开数据集上与其他 the state-of-art 的模型算法的比较结果,为了更近一步地展示提出模型算法框架的有效性,本文还开展了对本模型内部构成元素(多尺度特征思想、标签损失、三元组损失和多尺度分割损失)的消融研究,旨在阐释每个模块或思想对整体算法精确度的影响。由此,本文可以更加详细地展示所提出的网络模型和算法框架随着模型内部模块等元素的增加或缺失,在最终训练收敛之后,整体网络模型在行人重识别任务中的精确度变化,以便分析和展示模型在行人匹配工作任务中存在的一些错误,有助于之后的工作。

因此,为了进一步验证本文提出的 MDRS 网络框架中每个构成元素的有效

性，我们在 single query 的模式下对 Market-1501 数据集进行了若干的消融研究。为了公平比较，本文中展示每个比较结果只有一个构成元素改变，而其他的构成元素保留默认设置。

表 4-4 消融研究

Tab. 4-4 Ablation study

Model	mAP	Rank-1	Rank-5	Rank-10
Baseline	72.4	88.1	96.0	97.3
Baseline+Triplet	74.9	89.7	96.3	97.8
Baseline+MS	76.9	90.8	97.1	98.2
Baseline+Triplet+MS	78.3	90.8	97.0	98.4
MD-1	79.2	92.7	97.2	98.4
MD-1+Triplet	84.3	94.4	98.1	98.9
MDRS-1(MD-1+Triplet+MS)	86.0	95.0	98.2	99.0
MD-2	79.5	92.8	97.4	98.3
MD-2+Triplet	86.1	95.0	98.1	98.9
MDRS-2(MD-2+Triplet+MS)	87.6	95.8	98.4	99.1

首先讨论各个消融元素的具体设置情况。在表 4-4 中，本文展示了 MDRS 模型在不同构成元素设置下的评估结果。“Triplet”代表三元组损失，“MS”代表多尺度分割损失，由于 ResNet-50 是多尺度特征提取模块的主干网络，因此本文将作为行人重识别模型中的 Baseline 模型。如果将三元组损失“Triplet”也添加到行人重识别任务中，那么就将这样的构成元素组合表示为“Baseline+Triplet”，“Baseline+MS”同理代表将多尺度分割损失“MS”添加到行人重识别任务中。此外，我们使用“MD-n”和“MDRS-n”这两组构成元素设置分别对模型进行训练。其中，“MD-n”表示多尺度特征学习，即除了 ResNet-50 提取的原始全局特征图外，还有额外的 n 个不同尺度的全局特征图，并且这些特征图都会有各自的水平切块划分得到对应的局部特征。例如，“MD-1”表示由步长 $\text{stride} = \{2,1\}$ 卷积层形成的两个尺度的全局特征图，这两个特征图包括了一个原始的全局特征图和一个额外尺度的全局特征图，同理“MD-2”表示由卷积层步长为 $\text{stride} = \{3,2,1\}$ 形成的三个尺度的全局特征图，即一个原始的全局特征图和额外的两个尺度的全局特征图。“MDRS-n”与“MD-n”都会生成 n 个额外的全局特征图，且二者具有相同的卷积步长设置，因此二者生成的全局特征图信息保持一致，区别是“MDRS-n”除了进行多尺度特征提取的标签损失计算，还进行三元组损失计算和多尺度区域分割损失的计算，因此也可以表示为“MD-n+Triplet+MS”。此外，以上提及的所有设置，在数据预处理阶段都对行人原始图像和语义分割伪标签图像进行了随机擦除的数据增广操作。因此，本文的消融研究主要针对模型多个尺度下的标签损失、三元组损失和分割损失之间的研究。接下来主要阐述消融研究中的各个模型构成元素对行人重识别任务的性能对比影响。

如表 4-4 所示,“Baseline+Triplet”设置采用三元组损失计算作为行人重识别任务的辅助工作,该模型的性能比“Baseline+MS”设置的性能要差(74.9%比 76.9%)。然而,“Baseline+Triplet+MS”设置不仅考虑了原始 Baseline 模型的标签损失,还添加了三元组损失和多尺度分割损失,因此在 *Rank-1* 和 *mAP* 评价函数的效果上优于“Baseline+Triplet”设置,分别高出了 1.1%和 4.4%。以上的这些实验结果十分清楚地表明,本文设计的多尺度区域分割模块能够十分有效地提高行人重识别的算法性能,该模块在原始的全局特征上比三元组损失更具有重要的作用。当引入额外尺度的全局特征时,“MD-1+Triplet”设置比“Baseline+Triplet”设置在 *Rank-1* 和 *mAP* 精确度上分别高出了 4.7%和 9.4%。“MD-2+Triplet”设置比“MD-1+Triplet”设置多了一个尺度的全局特征图,其在 *Rank-1* 和 *mAP* 精度上比后者高出 0.6%和 1.8%。此外,我们还可以从表 4-4 中看到,“MDRS-2”设置使用更多的尺度进行行人的全局特征提取,在 *Rank-1* 和 *mAP* 精度上比“MDRS-1”设置分别高出 0.8%和 1.6%。这些结果表明,本文提出的模型能够通过多尺度全局和局部特征学习和多尺度人体部位语义分割方法进一步提高行人重识别任务的精度。总体而言,本文通过联合多尺度判别特征学习和多尺度人体语义分割,设计了一个端到端的行人重识别网络架构,并且在三个公开数据集上取得了良好的性能。

表 4-5 与现有模型复杂度比较

Tab. 4-5 Comparison of complexity with some existing models

Model	Number of parameters	GPU(s)	Batch Size	Training Time	Epochs
PCB ^[14]	24.033M	two NVIDIA TITAN XP GPUs	64	50 minutes	60
PGFA ^[43]	25.082M	-	32	-	60
MLFN ^[30]	32.473M	A K80 GPU	256	-	307
MGN ^[18]	68.808M	two NVIDIA TITAN XP GPUs	64	2 hours	80
MDRS	113.637M	a single NVIDIA GTX 1080Ti GPU	32	12 hours	440

4.6 本章小结

本章主要阐述和展示了本文提出的网络架构模型在实验环节上的效果。首先,本文的模型在三个数据集上的效果十分优异,可以和其他的 the state-of-the-art 的模型性能相媲美,其次也展示出了模型在行人重识别任务中存在的不足和需要改进的地方。此外,我们还通过消融研究展示了本文模型内部组成结构的增加和缺失对整体网络性能的影响,揭示了多尺度特征学习与人体语义分割相结合的可行性和重要性。由于是端到端的架构,模型设置的参数量和训练资源都比其他的较为单一的网络要多,但是处理多任务的效果却要更佳,因此也体现了本文模型

在多任务训练时的不易性和行人匹配时的准确性。在未来的工作中，将局部可见性感知的思想融入到模型算法当中，并且将其应用到我们的分割和分类任务当中以进一步提高模型的性能。

结 论

基于近几年深度学习的快速发展和各个计算机视觉领域的逐步兴起,人脸识别技术在低分辨率识别的情况下存在识别精度较低的情况,因此需要其他的辅助或者备用方法来完成行人信息的匹配工作。在众多方法中,行人重识别技术就足以充当这样的一个角色来完成这项工作。对于行人信息,其穿着风格和姿态以及人体的各个部位都可以作为行人重识别技术的关键信息完成匹配任务。因此,通过各种手段来研究行人重识别技术并用于实际生活十分必要。

基于以上的研究目的,本文针对现有的行人重识别技术存在的问题,将多尺度特征融合,全局和局部信息学习以及多种数据样本增广相结合来构建一个高鲁棒性高泛化性的行人重识别分类网络。在研究阶段,针对端到端的网络架构,多任务网络搭建、损失函数设计和多尺度信息利用的方式都进行了多次实验和测试,最终得到了高鲁棒性高泛化性且性能优异的模型,并为将来工作中引入局部可见先感知思想打下基础。

本文具体的研究内容介绍如下:

(1)多任务网络搭建和损失函数设计。对于多任务网络,其核心是将所考虑的特征学习任务应用于一个整体网络之上,但是网络的复杂程度也使得网络参数的优化具有更大的难度。网络结构设计不当或者损失函数的设计无法诠释学习到的特征,都会使得训练中出现过拟合和梯度爆炸或消失的不利情况。那么,设计一个性能优异且功能复杂的多任务网络,是本文主要研究的内容之一。

(2)行人多尺度信息的利用和处理方式。对于深度学习网络,特征图的尺度一定程度上决定了学习到的特征是否具有代表性。此外,诸如语义分割和 GAN 造图等得到的新数据样本也需要进行对应的多尺度采样操作,以对应每个尺度特征来计算损失,不同尺度的增广样本所含有的信息也不同,因此合理利用多尺度的行人信息并加以综合考虑,是本文主要研究的内容之一。

(3)多种数据增广方法的使用。在行人重识别样本获取方面,数据集样本并没有涵盖实际场景,这给模型训练带来很大的挑战,因此利用多种数据增广的方法进行风格迁移或语义分割非常必要。此外,额外的数据采样和增广方法会使得整体的网络架构复杂庞大,训练开销和时间成本也进一步扩大。因此,本文除了需要提取行人特征信息之外,行人的语义信息,风格信息和注意力信息的使用也是本文主要研究的内容之一。

本文提出的基于人体语义分割与多尺度特征的行人重识别模型，创新点如下：

1. 本文针对现有的行人重识别任务，本文在三个行人重识别公开数据集上，训练人体部位语义分割模型，该模型用来预测数据集中人体部位伪标签，并利用这些标签辅助进行行人重识别工作。通过引入人体部位语义分割，并结合多尺度特征学习思想，整体的行人重识别模型的性能得到了较大的提升。

2. 本文利用全局和局部特征表示学习行人特征，并且使用度量学习方进行特征间距离计算，进一步提高行人重识别的精度。此外，设计了一种多尺度网络来学习不同尺度下的全局和局部行人特征，提升特征信息多样性。通过这样的特征划分和学习方式，行人信息在尺度和多样性上都得到了较大的扩展和丰富，对行人重识别任务十分有效。

3. 本文最后将人体语义分割与多尺度特征学习相结合，使模型既可以做行人重识别任务也可以完成语义分割任务。并在多种数据增广方法的辅助下，对数据集场景和样本进行丰富和替换，提高所提出的网络模型的泛化能力。综合实验表明，该方法在 Market-1501、DukeMTMC-reID 和 CUHK03 三个公开数据集上取得了优异的性能。

对于下一步研究，本文做如下的展望：

(1) 本文接下来的工作可能考虑利用图神经网络解决行人重识别阶段的遮挡问题。首先，可利用人体关键点检测模型得到关键点区域的置信分数，计算局部特征间的差异并利用图神经网络进行学习。之后，每个局部特征都作为图神经网络中的一个节点，利用矩阵运算得到融合后的两两特征间差异信息，进行图匹配运算，还原遮挡部分，提高重识别精度。此外，还可以结合多尺度特征，提高重识别精度。在今后的工作中，会尝试以上的方法提升模型重识别的性能。

(2) 可能考虑利用 GAN 造图解决无监督的行人重识别任务。首先利用 StarGAN 生成不同摄像机下相同姿态的行人图片，以扩充行人重识别数据样本，用于无标签的训练。之后，进行有监督地模型训练，再无监督地对 GAN 扩充的数据样本进行 K 邻近以及其他聚类方法的计算。最后，同样结合多尺度特征学习，提高重识别精度。在今后的工作中，将上述方法融入到现有的算法框架中，使模型在行人重识别任务更为实际和真实的场景具有更高的识别精度。

综上所述，本文工作尽管完成了对行人重识别任务的性能提升，但是仍然存在进步的空间。今后将继续完善行人重识别算法中的不足之处，提升模型的效果，为实际行人监控和重识别系统的研究者和使用者提供更好的帮助。

参 考 文 献

- [1] Y. Lecun, Y. Bengio, G. Hinton. Deep learning[J]. Nature, 2015, 521(7553): 436.
- [2] X. Liu, H. Zhao, M. Tian, L. Sheng and J. Shao, S. Yi and J. Yan, and X. Wang. Hydraplus-net: Attentive Deep Features for Pedestrian Analysis[C]// 2017 IEEE International Conference on Computer Vision (ICCV). IEEE, 2017.
- [3] K. He, X. Zhang, S. Ren, and J. Sun. Deep Residual Learning for Image Recognition[C]//European Conference on Computer Vision, 2016.
- [4] Y. Chen, Xiatian Zhu, and Shaogang Gong. Person Re-identification by Deep Learning Multi-Scale Representations[C]// 2017 IEEE International Conference on Computer Vision Workshops (ICCVW). IEEE, 2017.
- [5] Y. Sun, Xu Q, Li Y., et al. Perceive Where to Focus: Learning Visibility-aware Part-level Features for Partial Person Re-identification[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019.
- [6] Zhao L, Xi L, Zhuang Y, et al. Deeply-Learned Part-Aligned Representations for Person Re-identification[C]// 2017 IEEE International Conference on Computer Vision (ICCV). IEEE, 2017.
- [7] Wei L, Zhang S, Yao H, et al. GLAD: Global-Local-Alignment Descriptor for Pedestrian Retrieval[C]. ACM, 2017.
- [8] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna. Rethinking the Inception Architecture for Computer Vision[C]// 2016 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2016.
- [9] E. Ristani and C. Tomasi. Features for Multi-Target Multi-Camera Tracking and Re-identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [10] W. Li, R. Zhao, T. Xiao, X. Wang. Deepreid: deep Filter Pairing Neural Network for Person Re-identification[C]// 2014 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2014.
- [11] M. M. Kalayeh, E. Basaran, M. Gokmen, et al. Human Semantic Parsing for Person Re-identification[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
- [12] Güler, Rza Alp, N. Neverova, I. Kokkinos. DensePose: Dense Human Pose Estimation In The Wild[C]// IEEE. IEEE, 2018.
- [13] L. Zheng, Y. Yang, Hauptmann A G. Person Re-identification: Past, Present and Future[J]. arXiv preprint arXiv: 1610.02984, 2016.
- [14] Y. Sun, L. Zheng, Y. Yang, et al. Beyond Part Models: Person Retrieval with Refined Part

- Pooling (and A Strong Convolutional Baseline)[C]// Springer, Cham. European Conference on Computer Vision (ECCV), 2017.
- [15] P. F. Felzenszwal, D. A. Mcallester, D. Ramana. A discriminatively trained, multiscale, deformable part model[C]// 2008 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2008.
- [16] L. Zheng, L. Shen, et al. Scalable Person Re-identification: A Benchmark[C]// 2015 IEEE International Conference on Computer Vision (ICCV). IEEE, 2015.
- [17] Z. Zhong, L. Zheng, G. Kang, et al. Random Erasing Data Augmentation[C]// Proceedings of the AAAI Conference on Artificial Intelligence. AAAI, 2017, 34(7).
- [18] G. Wang, Y. Yuan, X. Chen, et al. Learning Discriminative Features with Multiple Granularities for Person Re-Identification[C]// 2018 ACM Multimedia Conference. ACM, 2018.
- [19] Z. Zhong, Z. Liang, D. Cao, et al. Re-ranking Person Re-identification with k-reciprocal Encoding[C]// 2017 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2017.
- [20] E. Ristani, F. Solera, R. S. Zouet al. Performance Measures and a Data Set for Multi-Target, Multi-Camera Tracking[C]// European Conference on Computer Vision. Springer, Cham, 2016.
- [21] Z. Zheng, Z. Liang, Y. Yi. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro[C]// 2017 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2017.
- [22] W. Li, X. Zhu, S. Gong. Harmonious Attention Network for Person Re-identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
- [23] C. Su, J. Li, S. Zhang, J. Xing, Wen Gao, and Qi Tian. Pose-Driven Deep Convolutional Model for Person Re-identification[C]// 2017 IEEE International Conference on Computer Vision (ICCV). IEEE, 2017.
- [24] H. Yao, S. Zhang, Y. Zhang, et al. Deep Representation Learning with Part Loss for Person Re-Identification[J]. IEEE Transactions on Image Processing, 2019, 29(6): 2860-2871.
- [25] Y. Sun, L. Zheng, W. Deng, et al. SVDNet for Pedestrian Retrieval[C]// 2017 IEEE International Conference on Computer Vision (ICCV). IEEE Computer Society, 2017.
- [26] H. Huang, D. Li, Z. Zhang, et al. Adversarially Occluded Samples for Person Re-identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [27] W. Li, X. Zhu, S. Gong. Person Re-Identification by Deep Joint Learning of Multi-Loss Classification[C]// Twenty-Sixth International Joint Conference on Artificial Intelligence. IJCAI, 2017.
- [28] F. Xiong, Y. Xiao, Z. Cao, et al. Good Practices on Building Effective CNN Baseline Model for Person Re-identification[C]// 2018 International Conference on Graphics and Image

- Processing. ICGIP, 2018.
- [29] Z. Zheng, L. Zheng, Y. Yang. Pedestrian Alignment Network for Large-scale Person Re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(10): 3037-3045.
- [30] X. Chang, T.M. Hospedales, T. Xiang. Multi-Level Factorisation Net for Person Re-Identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [31] D. Chen, X. Dan, H.Li, et al. Group Consistent Similarity Learning via Deep CRF for Person Re-identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [32] M. S. Sarfraz, A. Schumann, A. Eberle, et al. A Pose-Sensitive Embedding for Person Re-identification with Expanded Cross Neighborhood Re-ranking[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
- [33] M. Geng, Y. Wang, T. Xiang, and Y. Tian. Deep Transfer Learning for Person Re-identification[C]// IEEE Fourth International Conference on Multimedia Big Data. BigMM, 2018:1-5.
- [34] M. Zheng, S. Karanam, Z. Wu, et al. Re-Identification With Consistent Attentive Siamese Networks[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019.
- [35] Z. Zhang, C. Lan, W. Zeng, et al. Densely Semantically Aligned Person Re-Identification[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019.
- [36] F. Zheng, C. Deng, X. Sun, et al. Pyramidal Person Re-IDentification via Multi-Loss Dynamic Training[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019.
- [37] E. Ustinova, Y. Ganin, V. Lempitsky. Multiregion Bilinear Convolutional Neural Networks for Person Re-Identification[C]// 2017 IEEE Conference on Advanced Signal and Video Based Surveillance. AVSS, 2017.
- [38] A. Schumann, R. Stiefelhagen. Person Re-identification by Deep Learning Attribute-Complementary Information[C]// IEEE Computer Society. IEEE Computer Society, 2017:1435-1443.
- [39] X. Chen, R. Mottaghi, X. Liu, et al. Detect What You Can: Detecting and Representing Objects using Holistic Models and Body Parts[C]// 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2014.
- [40] Y. Lin, L. Zheng, Z. Zheng, et al. Improving Person Re-identification by Attribute and Identity Learning[C]// 2017 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017.
- [41] Z. Cao, T. Simon, Wei S E, et al. Realtime Multi-Person 2D Pose Estimation using Part

- Affinity Fields[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017.
- [42] A. Hermans, L. Beyer, B. Leibe. In Defense of the Triplet Loss for Person Re-Identification[C]// 2017 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2017.
- [43] Miao J, Wu Y, Liu P, et al. Pose-Guided Feature Alignment for Occluded Person Re-Identification[C]// 2019 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2019.
- [44] Zheng Z, Yang X, Yu Z, et al. Joint Discriminative and Generative Learning for Person Re-Identification[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020.
- [45] Choi Y, Choi M, Kim M, et al. StarGAN: Unified Generative Adversarial Networks for Multi-domain Image-to-Image Translation[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018.
- [46] Deng W, Zheng L, Ye Q, et al. Image-Image Domain Adaptation with Preserved Self-Similarity and Domain-Dissimilarity for Person Re-identification[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
- [47] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Nets[M]. Neural Information Processing Systems. NIPS, 2014.

攻读硕士期间的主要研究成果

1. Huang Jialiang, Liu Bo, Fu Lihua. Joint multi-scale discrimination and region segmentation for person re-ID[J]. Pattern Recognition Letters, 2020, 138.(SCI JCR Q2, 已见刊, 入藏号-WOS: 000579804900073)
2. Fu Lihua, Zhao Yu, Sun Xiaowei, Huang Jialiang, et al. Video object segmentation based on motion-aware ROI prediction and adaptive reference updating[J]. Expert Systems with Applications, 2020, 167(4):114153.
3. Fu, L. and Sun, X. and Zhao, Y. and Li, Z. and Huang, J. and Wang, L. Video super-resolution reconstruction method based on deep Back projection and motion feature fusion[J]. Multimedia Tools and Applications, 2021(11).

致谢

从 18 岁第一次走进工大的校门，就被工大的每一个事物深深吸引。在这里，工大陪伴着我度过了 7 年的光阴。在这年里我收获颇多，感慨颇多，同时也成长了许多。在这里，我要感恩陪伴我的每一个人。

首先，在这里我要感谢我的导师刘波老师。我还记得第一次来到刘波老师的实验室，每位师兄师姐都在忙着自己的课题或者是研读与自己领域有关的论文，实验室学习气氛浓厚，也使得我产生了更多的学习动力。刘波老师非常关心每一位同学的学习情况和生活情况，每次组会都会认真听每个报告的同学的演讲并做出相应的指导。在我写论文期间，刘波也会对我产生的问题进行一一解答，例如文章的行文结构，文章的内容划分，公式撰写和图表绘制等等，真的是非常用心。在论文的修改阶段仍旧给我十分正确的修改意见，让我注意审稿人的每一个修改项目，最终论文发表在 SCI 期刊上，我十分激动万分高兴，也很感激刘波老师对我的帮助和鼓励。同时在生活中，刘老师也给我们每个同学无微不至的关心和爱护。经常会给我们分享自己年轻的时候学习经历，也时常勉励我们要努力科研，不要荒废了研究生这几年的时光，对自己的将来负责。感谢刘老师对我的悉心指导与鼓励，不仅教我如何进行学术研究，同时也教我做人处事的道理，让我明白这个世界每个人都有自己的义务和责任，都要为自己的未来做好打算，付诸行动。

感谢实验室的同学梁祎、杜宾、包文强和孙雄飞对我平时学习上的帮助和科研问题的助力，感谢研究生阶段里对我的照顾和关心。感谢实验室学弟学妹董玲梅、李剑、张翔宇、郝婧煜和沈梦雅，感谢你们平时对我的帮助，你们在实验室认真学习的态度和朴实无华的为人时刻影响着我，对我受益匪浅。感谢师兄王铎和张开创，也感谢师姐韩雨莹、薛圆圆和郭灵灵，感谢平时生活中对我的帮助和支持。

感谢我的女朋友兼学妹董玲梅，感谢你在研究生的时光里陪伴着我。感谢你平时对我的关心和爱护，感谢你总是带给我阳光和欢乐。每次陪你去玩、逛街、看电影，我都觉得十分轻松和惬意，我也愿意陪着你帮助你做任何的事情。感谢你在平时的学习生活中对我的支持和鼓励，让我可以安心学习和科研。感谢疫情期间对我的支持和鼓励，让我相信我们的爱情经得起时间的考验。我会一直陪在你的身边，彼此照顾，互相成长，共同进步。

感谢我的父母，在大学和研究生期间一直支持我，让我和其他人一样可以读书和学习。感谢你们平时的付出和对我的照顾。

感谢我的母校工大给我提供了舒适的学习和生活环境。从操场到食堂，从羽毛球馆到中蓝公寓，这里的每一个事物我都会在心里铭记，感谢它们在 7 年里陪

伴着我度过风风雨雨，希望今后可以和每一位工大学子相聚于此，畅谈这里发生的每一件难忘的事。

最后，致敬在这次疫情里每一位坚持付出顽强拼搏的人们。愿这个世界永远美好，永远那么阳光灿烂。