

分类号: _____

单位代码: _____ 10300

密 级: _____

学 号: _____ 202212490753

南京信息工程大学

硕士学位论文



论文题目: _____ 基于多尺度特征融合的换衣
行人重识别方法研究 _____

申请人姓名: _____ 周洁琼

指导教师: _____ 张国庆教授

类别名称: _____ 电子信息

领域名称: _____ 计算机技术

培养学院: _____ 计算机学院、网络空间安全学院

提交时间: _____ 2025 年 6 月 11 日

二〇二五年六月

目 录

第一章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统行人重识别方法.....	3
1.2.2 换衣行人重识别方法.....	5
1.3 主要研究内容.....	6
1.4 本文的组织结构.....	8
第二章 相关基础理论和知识	9
2.1 深度学习相关知识.....	9
2.1.1 Transformer.....	9
2.1.2 对比语言图像预训练.....	10
2.2 行人重识别常用损失函数	12
2.2.1 交叉熵损失.....	12
2.2.2 三元组损失.....	12
2.2.3 难样本三元组损失.....	13
2.2.4 中心损失.....	13
2.3 换衣行人重识别数据集.....	14
2.3.1 PRCC 数据集	14
2.3.2 LTCC 数据集.....	14
2.3.3 VC-Clothes 数据集.....	15
2.3.4 Celeb-reID 数据集.....	15
2.3.5 Celeb-reID-light 数据集.....	15
2.3.6 NKUP 数据集.....	15
2.4 行人重识别评价指标.....	16
第三章 基于自适应感知注意力与金字塔聚合的换衣行人重识别方法	18
3.1 引言.....	18
3.2 整体框架结构.....	19
3.2.1 多层动态集中模块.....	20
3.2.2 局部金字塔聚合模块.....	21
3.2.3 损失函数设计.....	22
3.3 实验结果与分析.....	23
3.3.1 实现细节与参数设置.....	23
3.3.2 VC-Clothes-W&R 数据集.....	24

3.3.3 与先进方法的比较.....	26
3.3.4 消融实验.....	30
3.4 本章小结.....	34
第四章 基于图文预训练大模型与多模态特征融合的换衣行人重识别方法.....	35
4.1 引言.....	35
4.2 整体框架结构.....	36
4.2.1 姿态感知身份特征增强模块.....	37
4.2.2 全局-局部协同注意力模块.....	39
4.2.3 跨层级交互增强模块.....	40
4.2.4 损失函数优化.....	42
4.3 实验结果与分析.....	43
4.3.1 与先进方法的比较.....	43
4.3.2 消融实验.....	46
4.4 本章小结.....	49
第五章 总结与展望.....	50
5.1 总结.....	50
5.2 研究展望.....	51
参考文献.....	53

摘要

行人重识别（Person Re-identification, Re-ID）作为智能视频监控系统的核心技术，在跨摄像头目标检索与追踪领域具有重要的应用前景。近年来，随着深度学习技术的快速发展，当前行人重识别研究在应对部分遮挡、光照变化和低分辨率等挑战方面已取得显著成果。然而，现有方法仍存在明显局限：当前研究主要聚焦于短期监控场景，对长期跨时段识别任务缺乏系统性研究，此外，现有算法过度依赖服装表观特征进行身份匹配，导致在长期监控场景中因服装更换或相似而引发的误匹配问题日益凸显，针对上述问题，本文聚焦换衣行人重识别这一前沿方向，提出了以下两种方法：

（1）针对换衣场景下因行人服装变化而引起的身份特征混淆问题，本文提出一种自适应感知注意力与金字塔聚合的 Transformer 网络，旨在通过捕获和整合多尺度视觉信息提升跨服装识别性能。首先，提出多层动态集中模块，通过实时评估每一层特征的重要性自适应调整特征提取策略，降低相关层之间的信息冗余程度。其次，提出局部金字塔聚合模块，结合快速傅立叶变换（FFT）与自注意力机制实现频域多尺度特征提取，同时降低计算复杂度。最后，构建包含多种气象条件模拟的换衣数据集，为模型的训练和评估提供了更真实的环境。实验结果表明，该方法能有效缓解服装变化带来的特征干扰，显著提升跨服装场景的识别准确率。

（2）针对图文预训练模型（CLIP）在换衣场景中对服装特征过度敏感的问题，本文提出基于 CLIP 的多模态特征融合框架增强模型对非服装特征的感知能力。首先，提出姿态感知身份特征增强模块，通过应用排名损失最小化行人外观和姿态特征差异，强化模型对人体固有特征信息的捕捉能力。其次，设计全局-局部协同注意力模块，利用交叉注意机制建立关键局部区域与全局语义的关联映射，提升跨尺度特征表达的语义一致性。此外，提出跨层级交互增强模块，通过构建跨层级特征交互机制，实现图像编码器多层次视觉特征的分组聚合，增强模型对视觉上下文信息的理解能力。实验结果表明，本文所提方法能有效缓解 CLIP 模型对服装特征的依赖性，显著提升了模型在服装变化场景下的鲁棒性。

关键词：换衣行人重识别，跨模态，特征融合，自适应

Abstract

Person Re-identification (Re-ID), as the core technology of intelligent video surveillance systems, has important application prospects in the field of cross-camera target retrieval and tracking. In recent years, with the rapid development of deep learning technology, current research on person re-identification has achieved remarkable results in dealing with challenges such as partial occlusion, illumination changes, and low resolution. However, existing methods still have obvious limitations: current research mainly focuses on short-term monitoring scenarios, and lacks systematic research on long-term cross-period recognition tasks. In addition, existing algorithms over-rely on clothing appearance features for identity matching, resulting in increasingly prominent mismatching problems caused by clothing changes or similarities in long-term monitoring scenarios. To address the above problems, this paper focuses on the cutting-edge direction of clothing-changing person re-identification and proposes the following two methods:

(1) To address the problem of identity feature confusion caused by pedestrian clothing changes in clothing-changing scenarios, this paper proposes a Transformer network with adaptive perceptual attention and pyramid aggregation, aiming to improve cross-clothing recognition performance by capturing and integrating multi-scale visual information. First, a multi-layer dynamic concentration module is proposed to adaptively adjust the feature extraction strategy by evaluating the importance of each layer of features in real time, thereby reducing the information redundancy between related layers. Secondly, a local pyramid aggregation module is proposed, which combines the fast Fourier transform (FFT) and self-attention mechanism to achieve multi-scale feature extraction in the frequency domain while reducing the computational complexity. Finally, a clothing-changing dataset containing simulations of various meteorological conditions is constructed to provide a more realistic environment for model training and evaluation. Experimental results show that this method can effectively alleviate the feature interference caused by clothing changes and significantly improve the recognition accuracy of cross-clothing scenarios.

(2) Aiming at the problem that the image-text pre-training model (CLIP) is overly sensitive to clothing features in clothing-changing scenarios, this paper proposes a multimodal feature fusion framework based on CLIP to enhance the model's perception of non-clothing features. First, a posture-aware identity feature enhancement module is proposed. By applying a ranking loss to minimize the difference between pedestrian appearance and posture features, the model's ability to capture the inherent feature information of the human body is enhanced. Secondly, a

global-local collaborative attention module is designed. The cross-attention mechanism is used to establish an association mapping between key local regions and global semantics, thereby improving the semantic consistency of cross-scale feature expression. In addition, a cross-level interactive enhancement module is proposed. By constructing a cross-level feature interaction mechanism, the multi-level visual features of the image encoder are grouped and aggregated, thereby enhancing the model's ability to understand visual context information. Experimental results show that the method proposed in this paper can effectively alleviate the dependence of the CLIP model on clothing features. The robustness of the model in clothing change scenarios is significantly improved.

Keywords: Clothing-changing Person Re-identification, cross-modality, feature fusion, adaptation

第一章 绪论

1.1 研究背景和意义

随着社会信息化程度持续提升，计算机视觉技术的应用进入新阶段，特别是在像公共安全、智能交通和犯罪防控等领域^{[1][2]}，监控系统所发挥的作用愈发凸显，可从图 1-1 看出，城市作为表现最复杂、最密集特性的生活空间，伴随人口不断增长和社会活动的繁荣景象，安全问题也随之日趋明显。为维护公共安全进而提升社会治理水平，公安部门把行人行为实时监控分析作为城市管理关键组成部分，然而传统视频监控主要依赖人工巡查以及录像回放手段，尤其是面对大量数据的时候，人工检查显得力不副心，更无法满足现代社会在监控系统实时性和精确性方面的既定需求，怎样采用高效手段进行行人行为分析与追踪，尤其是行人身份的校定与匹配，已成为监控系统面对的一个核心挑战。



图 1-1 监控系统的应用场景示例

行人重识别（Person Re-identification, Re-ID）作为一种创新的计算机视觉任务，正是为应对这种挑战而提出。它借助多样化的行人特征提取算法，从监控视频归档的行人图像或视频序列中提取深层次的身份特征，目的是解决在不同摄像头或监控视角下匹配同一行人身份的难题。行人重识别在诸多方面呈现广泛的应用范畴：它在多个监控摄像头之中识别且跟踪嫌疑人的移动路径，大幅提升公共安全部门的调查效能与犯罪预防水平，在智能交通系统实际运作的体系里，它可在行人流量监控、交通行为分析方面发挥作用，支持交通调度决策运转；在零售经营范畴，行人重识别可开展顾客行为分析、安全监控与盗窃防控相关工作，增强商场的安全守护力度；在机场、车

站等公共交通集散点，它能辅助安保人员在大规模人群中迅速识别出可疑人员，增高安检速率，减小安全风险系数；在紧急响应及灾难防控里起到关键效用，行人重识别技术凭借快速识别受伤或急需援助人员，可有效实现救援资源科学配置和应急措施有序执行。

近年来，随着深度学习技术不断拓展以及行人数据集不断地涌现^{[3][4]}，行人重识别领域引起了越来越多学者的关注，而且涌现出大量卓越且有针对性的研究成果，这些研究着重聚焦物体遮挡、光线变化、图像分辨率差异、视角变化等挑战，不断带动该领域的技术优化。

需要留意的是，多数行人重识别研究方法把行人着装当作主要辨别特征，以应对物体遮挡、视角变化等形成的挑战，这往往是基于行人短期内不会替换衣服的一种假定，如图 1-2 所示，在实际的情况里面，服装更换或许鉴于气温的局部变化、场合的局部变动等因素而出现，尤其是在犯罪追踪等应用操作阶段内，嫌疑人常借由换衣逃避识别，不同行人穿类似衣装的情形较为多见，这让传统的短期 Re-ID 方法在应对现实场景的复杂局面时显得难以招架。



图 1-2 (a) 传统行人重识别



图 1-2 (b) 换衣行人重识别

1.2 国内外研究现状

行人重识别研究在发展路径上经历了从手工特征时期到深度学习时期显著变迁，早期研究主要依赖于手工设计的特征（如颜色直方图、纹理特征等）开展工作，这些方法虽然在特定场景下表现出一定的有效性，但由于特征表达能力有限，泛化能力较弱，难以应对复杂多变的实际场景。伴随深度学习的兴起，依靠卷积神经网络（Convolutional Neural Networks, CNN）的方法渐渐成为主流标杆，运用端到端的学

习策略，模型可自动筛选更具判别性的特征，极大增强行人识别性能。然而传统深度学习过于依赖服装特征作为身份判别依据，此在实际应用里有明显局限性，尤其是在换衣场景下表现不佳。因此针对换衣场景的行人重识别研究开始崭露头角，成为领域内极具价值的研究方向。本节将介绍行人重识别的研究进展，囊括基于手工特征的途径、基于深度学习的途径以及针对换衣场景的行人重识别方法。

1.2.1 传统行人重识别方法

多摄像头跟踪任务是行人重识别研究的起源，此研究的主要目标是运用外观模型和时空线索在多个摄像头间关联同一行人身份。2005 年，Zajdel 等人^[5]首度提出“行人重识别”概念，采用动态贝叶斯网络，把时空特征跟视觉线索结合起来识别那些离开视野后重新进入的个体。2006 年，Gheissari 等人^[6]设计出一种基于视觉线索的方法，采用空间时间分割算法进行前景检测，且利用颜色与显著边缘直方图实施视觉匹配，这项工作表明行人重识别从多摄像头跟踪中分离为独立体系，成为一个独立的计算机视觉范畴。

行人重识别早期研究阶段，技术主要针对从图像中提取手工设计的特征进行，并采用这些特征进行行人身份匹配，常见的特征涉及颜色直方图、局部二进制模式（LBP）、以及梯度直方图（HOG）。颜色直方图借助统计图像中各颜色通道的分布描述行人整体颜色信息，对在不同光照情形下识别颜色相近的行人起到辅助作用。局部二进制模式则主要用于提取图像的纹理特征，它依靠对每个像素周围局部区域作二值化处理，捕捉区域的灰度变化，以此在视觉上捕捉到行人服装及外观上的细微不同，尤其对于姿势和服装变化敏感性较高。梯度直方图计算图像中各区域的梯度方向与强度，采集边缘信息，帮助识别行人轮廓结构，在行人形状的区分上作用重大，基于这些手工特征的研究也逐渐涌现。2010 年，Bazzani 等人^[7]将同一行人的一组帧压缩为一个具有高度信息量的直方图加缩影（Histogram Plus Epitome, HPE），HPE 通过直方图表示捕捉行人整体的色彩信息，同时利用典型模式估计提取重复出现的局部区域，从而在全局和局部层面提供对行人外观的全面描述。2011 年，zhang 等人^[8]提出了基于 Gabor 和局部二值模式（LBP）的区域协方差描述符的方法，首先通过行人图像预处理提取颜色特征及 Gabor、LBP 纹理特征，进而构建多特征融合框架，将不同区域的色彩空间信息和纹理响应映射到协方差矩阵空间，形成具有几何结构的区域协方差描述符，并在此基础上采用黎曼流形距离度量替代传统欧氏距离，通过计算协方差矩阵间的测

地线距离构建相似度判别模型，以克服特征空间非线性分布带来的匹配难题。尽管基于手工特征的行人重识别方法实现简单且对小样本数据具有较好的适应性，但在复杂场景中，这些方法的局限性逐渐显现，特别是在应对光照变化、遮挡和姿态变化等挑战时，表现较为薄弱。

随着深度学习的快速发展，行人重识别在算法性能和应用场景上均取得了显著突破。2014年，Li 等人^[9]提出的 DeepReID 首次将卷积神经网络引入行人重识别任务，通过端到端的深度排序框架进行训练，并采用排序损失函数实现度量学习，有效地优化了行人图像对的相似性度量。2015年，Zheng 等人^[4]以清华校园作为真实场景，收集并公布了一个大规模行人数据集 Market-1501，为后续研究基于深度学习的行人重识别方法奠定了重要的实验基础。该数据集包含 1501 个行人身份，3 万多张图像，覆盖多个摄像头视角，成为行人重识别领域的标志性数据集之一。2016年，Hermans 等人^[10]提出基于 Triplet Loss 的度量学习方法，通过构建锚点-正样本-负样本三元组，迫使网络学习类内紧凑性和类间可分性，成为后续研究的基准框架。

为应对行人姿态变化与局部特征错位问题，2017 年之后，研究重点转向局部特征建模与注意力机制。例如，Sun 等人^[11]提出了一种基于部分卷积基线（PCB）和精炼部分池化（RPP）的方法，PCB 采用均匀分区策略，通过修改 ResNet50 主干网络，移除全局平均池化层，将卷积特征图划分为多个水平条带，每个条带独立提取部分特征并训练分类器，最终拼接各部分特征形成全局描述符。RPP 进一步优化均匀分区的不足，引入部分分类器动态计算每个列向量与各部分的相似度，通过弱监督学习调整分区的空间对齐，将异常值重新分配到最相似的部分，从而增强部分内部一致性。2018年，Wang 等人^[12]提出多粒度网络（MGN），通过并行分支提取全局、中粒度和局部特征，并设计动态匹配策略融合多尺度信息，有效解决了遮挡与局部信息缺失问题。与此同时，注意力机制被广泛用于特征选择，如 Chen 等人^[13]提出的 SAN（Spatial Attention Network）通过空间注意力图动态加权特征图响应，强化显著区域（如头部、背包）的语义表达。

针对跨域泛化与标注成本难题，2020 年后研究呈现两大趋势：一是基于 Transformer 的全局建模方法，如 He 等人^[14]提出的 TransReID 首次将 Vision Transformer 引入行人重识别，通过自注意力机制捕捉长距离依赖关系，在遮挡场景下表现出色；二是无监督与跨域自适应方法，如 Dai 等人^[15]提出的 SpCL 框架（Self-paced Contrastive

Learning) 通过动态聚类生成伪标签, 结合对比学习实现无监督特征蒸馏, 显著缩小了跨域性能差距。

在损失函数设计层面, 研究经历了从单一度量学习转向多任务协同优化的演变。早期工作依赖验证损失 (Verification Loss), 主要通过二元分类判断样本对是否属于同一身份, 但难以应对类内差异与类间相似性交织的复杂场景。2017 年, Hermans 等人^[10]引入 Triplet Loss, 通过锚点-正样本-负样本三元组优化特征空间, 强制类内距离小于类间距离, 但其对样本挖掘策略敏感且收敛不稳定。2020 年后, 损失函数设计转向自适应梯度平衡与联合优化: Sun 等人^[16]提出 Circle Loss 通过动态调整正负样本权重, 缓解梯度不平衡问题; Zhang 等人^[17]进一步提出联合 ID Loss (交叉熵身份分类损失) 与 Triplet Loss 的混合监督框架, 利用身份标签的强监督信号增强特征判别性。当前的研究强调多损失协同 (如结合度量学习、属性预测、姿态对齐等辅助任务), 并通过课程学习策略动态调整优化目标, 以应对遮挡、跨域泛化等挑战。

1.2.2 换衣行人重识别方法

现有的行人重识别方法大多把服装作为主要的视觉分辨特征, 一般默认行人在不同时间、不同摄像头的监控时段中穿着相同服装, 而在真实状况所包含的情形里, 行人有几率替换衣物、佩戴不同的配饰, 或者身着类似却不完全相同的衣物, 这些因素同样极大地影响了传统方法的鲁棒性。

当前, 针对换衣场景的研究方法主要分为两类: 一种普遍途径是对与服装无关的生物特征进行挖掘, 采用身体轮廓、步态模式、姿态、面部等提取身份相关特征。中山大学 Hong^[18]等学者提出细粒度形状外观相互学习框架 (FSAM), 利用将细粒度体型知识迁移到外观流中, 补充外观特征中的非服装信息。然而该方法依赖形状特征的表现明显, 在遮挡或姿态不完整呈现的状态下可能受影响。南京信息工程大学 Zhang 等人^[19]提出的多生物识别统一网络 (MBUNet) 通过自适应图卷积掌握人体关键点关联, 结合涉及头、颈、肩的生物特征, 减弱服装变化对识别环节的干扰。即便该方法在提取生物特征时表现出较强灵活性, 但由于视角变化对身体关键点提取的影响, 可能会导致在不同角度下的表现达不到预期效果。类似地, 中国科学技术大学 Jin 等人^[20]借助步态信息补充静态外观, 开发图像与步态双流框架 (GI-ReID), 进而设计出步态序列预测 (GSP) 模块丰富步态信息。尽管步态能有效弥补静态外观缺陷, 不过依赖完整步态序列, 动态场景实施阶段可能受遮挡或快速运动妨害, 导致识别性能下降。

浙江大学的 Wang 等人^[21]研究出连续表面对应学习（CSCL）方法，通过建立二维图像平面与规范化三维人体表面之间的连续对应关系，获得逐像素的表面嵌入。基于这些既定的表面嵌入，作者进一步甄选出细粒度形状特征，并通过跨模态融合模块把它与全局 RGB 特征进行融合，于是极大增强了模型对人体形状的整体理解。

基于生物模态辅助的手段能够减轻对服装的依赖并在一定程度上提升换衣行人重识别性能，但由于视角和姿态出现波动，单一生物特征难以提供足够的鲁棒性。另一类方法凭借生成对抗网络、语义感知模型或服装擦除策略实现外观和结构信息的分离，把结构信息看成与服装无关的身份特征。例如，SAVS^[22]借助语义分割与注意力模块增强人体特征表达，屏蔽服装区域，专注提取与身份相关的视觉语义特征，进而促进识别精度增长。不过该方法对精确分割依赖处于较高的量级，受遮挡或图像质量差影响较大。北京大学的 Shu 等人^[23]提出了语义引导的像素采样方法，采用交换行人图像中的服装像素的做法来分离身份与服装特征。虽然这个途径能有效分离特征，但像素交换大概率会生成不自然的样本，损害模型适应真实世界多元变化的能力。悉尼科技大学的 Zheng 等人^[24]开发出一个联合学习框架，通过把每个图像的外观和形状特征分开，并在身份内部和身份之间进行交换，借此实现数据合理增强。然而源于精确监督信号匮乏，特征解耦过程采用隐式的进行模式，这使得模型提取与服装无关特征期间，依旧或许会受服装信息的负面干扰。上述采用服装信息和结构信息解耦的方法在一定程度上降低了服装变化对身份判别的干扰，然而现有的解耦架构多着眼于全局特征分离，未对不同粒度的服装无关特征（例如局部生物特征、步态时序特征）的互补关联性进行系统发掘，造成身份表征的信息完备性欠缺。除此之外，模型对解耦特征的空间感知能力存在局限，在遮挡、光照突变等场景下不易维持稳定的特征解耦效果，最终导致身份判别过程仍然过度依赖表层外观特征。

1.3 主要研究内容

在跨摄像头追踪场景中，当监控时间间隔延长时，目标个体可能因服饰更换产生显著的视觉特征差异，这种动态衣着条件显著增加了行人重识别任务的复杂度。传统算法通常以衣着特征作为关键识别依据，然而这种强关联性特征依赖机制在面对服装变化时，其识别性能会出现明显退化。因此，针对换衣场景的特点，本文致力于挖掘与服装无关的身份特征，主要内容如下：




图 1-3 本文主要研究内容

(1) 提出了一种基于自适应感知注意力与金字塔聚合的换衣行人重识别方法，旨在有效应对服饰干扰并增强身份特征的鲁棒性。针对换衣场景下信息利用率不足的问题，本方法设计了多层动态集中模块，通过动态分析并赋予各层级特征不同的重要性权重，自适应地融合多层视觉特征，有效降低相邻层级间的计算冗余。与此同时，为在保持全局感知能力的同时精准捕捉关键局部信息，提出局部金字塔聚合模块，创新性地将快速傅立叶变换（FFT）与自注意机制相结合，在频域中实现了多尺度特征提取，同时降低自注意机制在处理高维数据时的计算复杂度。此外，为更真实地模拟换衣场景中的自然环境变化，本方法构建了一个包含多种气象条件的综合行人数据集，为模型训练和性能评估提供了更加多样化的环境样本。在多个公开换衣行人重识别数据集上的实验结果充分验证了本方法的优越性能。

(2) 提出了一种基于图文预训练大模型与多模态特征融合的换衣行人重识别方法，着力增强模型对非服装特征的感知能力。本方法首先设计了姿态感知身份特征增强模块，从而有效强化模型对身份固有信息的感知能力，并通过应用排名损失最小化特征空间中同一行人外观和姿势的差异，以削弱了服装信息的干扰。为进一步提升关键信息的全局识别能力，设计了全局-局部协同注意力模块，通过交叉注意机制融合头部和全局特征，实现了对身份关键信息的有效捕捉与增强。此外，鉴于现有基于图文预训

练模型的方法对于浅层和中层视觉特征的利用存在不足，本方法设计了跨层级交互增强模块，该模块对图像编码器的多层特征实施分组与整合策略，从而提升了模型对于视觉特征的上下文感知能力。多个主流换衣数据集上的综合实验结果充分证明了本方法的良好性能。

1.4 本文的组织结构

本文共由五章组成，各章节内容的核心安排如下：

第一章首先介绍了行人重识别的研究背景及应用前景，而后按照传统方法和换衣场景的方法回顾行人重识别的历史发展，归纳了本文聚焦研究重点及结构设定。

第二章剖析相关理论知识，着重介绍深度学习的相关算法以及本文研究所涉及的相关模型。此外，还介绍了本文所采用的相关换衣行人数据集和实验的评价指标，为后续章节的研究夯实基础。

第三章介绍了基于自适应感知注意力与金字塔聚合的换衣行人重识别方法，对网络的两个模块和提出的具有多种大气条件的行人数据集进行了详细的描述，针对对应模块进行了消融实验，并且与目前先进方法进行了实验对比。

第四章介绍了基于图文预训练大模型与多模态特征融合的换衣行人重识别方法，对提出的姿态感知身份特征增强模块、全局-局部协同注意力模块以及跨层级交互增强模块作了详细描述，对提出的方法进行了消融实验，并与目前的先进方法做了对比实验，结果证明了本方法的有效性。

第五节为总结与展望，包含对本文工作的总结，以及对未来换衣场景的行人重识别可研究性的展望。

第二章 相关基础理论和知识

2.1 深度学习相关知识

2.1.1 Transformer

Transformer 模型最初由 Vaswani 等人^[25]在 2017 年提出，该模型的核心创新在于摒弃了传统循环神经网络（RNN）的序列处理方式，转而完全依赖自注意力机制（Self-Attention）捕捉序列内元素的全局依赖关系。该机制通过计算输入元素间的相关性权重（Attention Score）动态聚合全局信息，使得 Transformer 在处理长距离依赖时表现出色。模型主要把编码器（Encoder）和解码器（Decoder）堆叠后组合而成，其中编码器的设计对后续视觉任务影响深远。每个编码器层包含两个核心模块——多头自注意力机制（Multi-Head Attention）与前馈神经网络（Feed-Forward Network），并通过残差连接（Residual Connection）与层归一化（Layer Normalization）优化训练过程。架构不仅显著提升了自然语言处理（NLP）任务的性能，还为计算机视觉（CV）领域带来了新的突破。

2020 年，Dosovitskiy 等人^[26]提出 Vision Transformer（ViT），首次将 Transformer 架构引入计算机视觉任务。ViT 对输入图像进行分割，得到固定大小的图像块（Image Patches，如 16×16 像素），再将它们线性映射为序列后直接输入 Transformer 编码器。通过引入可学习的位置编码（Positional Embedding），ViT 克服了 Transformer 本身对输入顺序不敏感的缺陷，成功捕捉图像的空间结构信息。与传统的卷积神经网络（CNN）相比，ViT 的优势在于其呈现出的全局感知能力与并行计算效率，自注意力机制使模型能够直接建模图像块间的长程依赖，而无需依赖堆叠卷积层的感受野扩张。此外，ViT 的可扩展性赋予其增加 Transformer 层数或隐藏层维度的能力，灵活提升模型性能。

随着 ViT 在通用视觉任务中的成功，研究者开始探索其在行人重识别任务中的应用价值。例如，He 等人^[14]提出的 TransReID 是首个将 ViT 引入 ReID 任务的成果，提出的拼图补丁模块（JPM）通过移位和补丁混洗操作重新排列补丁嵌入，从而生成具有更高辨别能力和更多样化覆盖范围的鲁棒特征；同时引入侧信息嵌入，通过插入可学习的嵌入来整合非视觉线索，以减轻对相机变化的特征偏差，这也是第一项采用纯

Transformer 进行 ReID 研究的工作。此外，ViT 在行人重识别中的另一个重要优势是高效的并行计算能力。传统 CNN 方法需要通过堆叠多个卷积层逐步增大感受野大小，而 ViT 依靠多头自注意力机制直接建模图像块之间的长程依赖，显著减少了计算复杂度。这种特性使得 ViT 在处理大规模数据集时更加高效，尤其是在预训练任务中，ViT 可以凭借大量图像数据学习到丰富的视觉特征，进一步提升行人重识别的性能。未来，随着轻量化 ViT 设计、多模态预训练框架的进一步发展，其在实际监控系统中的实用性与泛化能力预计会持续提升。

然而，ViT 在行人重识别中的应用也面临一些挑战。首先，ViT 模型在训练以及推理过程中对计算资源要求较高，尤其是在处理大量图像数据时，需要较强的 GPU 计算能力。此外，ViT 模型的参数量较大，可能导致模型的复杂度和内存占用增加。因此在实际应用中，怎样对 ViT 模型加以优化以契合换衣行人重识别的特定需求，是一个值得探索的方向。

2.1.2 对比语言图像预训练

对比语言-图像预训练^[27]（Contrastive Language-Image Pre-training，简称 CLIP）作为多模态表征学习的里程碑式突破，通过构建统一的视觉-语言语义空间，为计算机视觉领域带来了范式革新。该模型采用对比学习策略在大规模自然语言监督下进行预训练，核心创新点在于建立了图像编码器与文本编码器的联合嵌入空间。具体而言，CLIP 通过最大化配对图像-文本对的余弦相似度，同时最小化非配对样本的相似度，实现了跨模态语义对齐。这种训练范式使得模型能够突破传统监督学习的局限性，在零样本迁移学习（Zero-shot Transfer Learning）中展现出卓越性能。

从理论架构层面分析，CLIP 的成功可归因于三个关键设计：首先，其采用的双塔式编码器结构（Dual-Encoder Architecture）实现了模态间的高效交互，其中视觉编码器通常基于 Vision Transformer（ViT）或 ResNet 架构，而文本编码器则采用 Transformer 模型；其次，通过大规模弱监督训练策略，模型能够捕捉细粒度的语义关联；最后，基于提示工程（Prompt Engineering）的标签语义扩展技术，有效缓解了视觉概念与文本描述之间的语义鸿沟。这种创新架构使得 CLIP 在处理开放世界视觉任务时，不仅能准确识别预定义类别，更能理解训练数据中未曾出现的概念，展现出强大的语义泛化能力。

在计算机视觉领域，CLIP 的零样本推理能力已在多个前沿方向得到验证。在细粒

度分类（FGVC）任务中，Jiang 等人^[28]提出了基于 CLIP 的多模态提示框架（MP-FGVC），旨在通过跨模态协同推理解决 FGVC 中的子类别区分难题。具体来说，模型通过分别引入子类别敏感视觉提示（SsVP）和差异感知文本提示（DaTP），从视觉和语言角度强调子类别差异，并设计视觉语言融合模块（VLFM）实现跨模态协同推理。此外，为 MP-FGVC 量身定制了两阶段优化策略，以充分利用预先训练的 CLIP 模型并加快 FGVC 的有效适应。异常检测方面，Zuo 等人^[29]提出的高效三维小样本异常检测方法（CLIP3D-AD），通过在正常图像上合成异常样本，实现了 3D 异常分类与分割。CLIP3D-AD 通过图像和文本适配器微调 CLIP 特征，采用粗到细的解码器融合多层视觉表示，并设计多视图融合模块增强视觉与语言的相关性，在 MVTec-3D AD 数据集上表现出竞争力的分类和分割性能。在语义分割领域，Chen 等人^[30]提出了一种基于 CLIP 模型进行零样本语义分割的方法（ZeroSeg），通过将 CLIP 学习到的视觉概念提炼为片段标记，ZeroSeg 克服了 CLIP 仅在图像级别训练的局限性，从而实现了对局部区域的精确分割。利用这些片段标记，ZeroSeg 在多个分割基准上实现优异的性能，进一步提升了零样本分割任务的效果。

近年来，CLIP 模型在行人重识别（ReID）领域掀起了一股研究热潮。与传统 ReID 方法主要依赖视觉外观特征不同，CLIP 的引入为融合语义先验知识提供了一种全新的范式。例如，Yu 等人^[31]提出了一种基于 CLIP 驱动的语义发现网络（CSDN），通过引入高级语义信息，解决可见红外人像重识别（VIREID）任务中的跨模态身份匹配问题。CSDN 主要包括模态特定的提示学习器、语义信息集成模块以及高级语义嵌入机制，充分利用 CLIP 提取的高级语义信息，通过设计双模态可学习文本标记捕捉可见光与红外图像的模态私有语义，并整合双模态文本特征，建立跨模态的视觉-语义关联，从而提升视觉表示的模态不变性。此外，在遮挡场景中，He 等人^[32]提出了一种多粒度对比一致性对齐框架，通过粒度内与粒度间的视觉-文本表示，进行遮挡视觉特征与查询文本之间的语义对齐。

近期，CLIP 模型也开始探索针对服装变化场景的适用性，但这种尝试仍面临着诸多挑战：由于 CLIP 在训练过程中更倾向于关注显著且易于描述的视觉属性，这使得模型在服装变化场景下可能过度依赖于服装特征，而忽略了与个体身份密切相关的内在信息，例如头部特征和行人姿态等。为进一步提升 CLIP 模型在换衣场景中的表现，未来研究需要深入探讨如何平衡服装特征与个体身份特征的提取，尤其关注在复杂场景下增强模型对个体身份信息的敏感性。

2.2 行人重识别常用损失函数

行人重识别作为跨摄像头追踪的核心技术，其本质是通过特征空间映射实现行人身份的精准判别。在这一展开过程中，损失函数借助参数优化机制激励模型学习具有强判别性的特征表示，直接影响着系统的识别性能。本部分着重对行人重识别任务的四大核心损失函数进行介绍，交叉熵损失（Cross-Entropy Loss）、三元组损失（Triplet Loss）、中心损失（Center Loss）和难样本挖掘三元组损失（Hard Example Mining Triplet Loss），下面结合数学表达式详细阐释各损失函数的设计原理与作用机制。

2.2.1 交叉熵损失

交叉熵损失（Cross-Entropy Loss）是分类任务中最常用的损失函数之一，在行人重识别中通常用于身份分类。其核心思想是通过最小化预测概率分布与真实标签分布之间的差异实现模型参数的合理优化。假设有 N 个行人样本，每个样本对应唯一的身份标签 $y_i \in \{1, 2, \dots, C\}$ （其中 C 为总身份分类数）模型输出的预测概率分布为 p_i ，交叉熵损失可以表示为：

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N y_i \log(p_i). \quad (2-1)$$

交叉熵损失凭借优化分类任务，促使模型能够正确预测行人的身份，由此间接地学习到具有判别性的特征。在行人重识别任务中，交叉熵损失通常与卷积神经网络结合使用。模型首先通过 CNN 提取行人图像的特征，然后将这些特征输入到全连接层中，最终通过 Softmax 函数输出每个类别的概率分布。交叉熵损失采用最小化预测分布与真实标签分布之间差异的做法，鼓励模型学习到能够区分不同身份的特征。

然而，交叉熵损失同样存在一定局限。它主要关注分类任务，忽视了特征空间中的度量学习。在行人重识别任务中，度量学习对于优化行人之间的相似性和差异性具有重要作用。因此，交叉熵损失通常与其他损失函数结合使用，以进一步提升模型的区分能力和识别性能。

2.2.2 三元组损失

三元组损失（Triplet loss）是行人重识别中广泛使用的一种度量学习损失函数，旨在通过拉近正样本对的距离、推远负样本对的距离来优化特征空间。它的核心思想是：

假设有 N 个行人样本，给定一个锚点样本 X_i^a 、一个正样本 X_i^p （与锚点属于同一行人）和一个负样本 X_i^n （与锚点属于不同行人），损失函数可以表示为：

$$L_{\text{Triplet}} = \sum_{i=1}^N \max(d(x_i^a, x_i^p) - d(x_i^a, x_i^n) + \alpha, 0), \quad (2-2)$$

其中， $d(\cdot, \cdot)$ 表示特征之间的距离； α 为预先给定的边界值，用于把控正负样本对之间的距离差异。三元组损失凭借优化特征空间中的距离度量，驱动同一行人的特征聚合，同时推动不同行人的特征分离，进而有力提升跨摄像头行人重识别水平。其优势在于能够直接学习判别性特征表示，但在实际应用中，样本选择对其效果的影响至为关键。随机采样有概率使模型收敛迟缓或陷入局部最优境地，因此一般运用难样本挖掘策略，借助筛选高信息量的样本对，增强模型的判别能力，从而进一步提升识别效果。

2.2.3 难样本三元组损失

难样本挖掘三元组损失（Hard Example Mining Triplet Loss）通过动态选择最具挑战性的样本对优化特征空间，切实提升了传统三元组损失的行人重识别性能。相较于随机采样，其核心策略聚焦于双重对抗性选择：强制模型学习同类样本中距离最远的正样本（跨摄像头/姿态差异大）以增强类内泛化能力，同时锁定外观高度相似的异类负样本以突破特征混淆边界。损失函数可以表示为：

$$L_{\text{HardTriplet}} = \sum_{i=1}^N \max(\max_{p \in P} d(x_i^a, x_i^p) - \min_{n \in N} d(x_i^a, x_i^n) + \alpha, 0), \quad (2-3)$$

其中， $d(\cdot, \cdot)$ 表示特征之间的距离； α 表示预设的边界值； P 和 N 分别表示锚样本 α 对应的正负样本集合； $\max_{p \in P} d(x_i^a, x_i^p)$ 和 $\min_{n \in N} d(x_i^a, x_i^n)$ 分别表示最难正样本和最难负样本的选择。采用这种方式，难样本挖掘三元组损失可更高效地优化特征空间，使模型在处理具有挑战性的样本时表现更佳。

然而，难样本挖掘的一个潜在问题是它可能会引入噪声样本，由此引发模型过拟合，因此在实际应用中，往往要对难样本挖掘策略进行适当调整，比如结合半难样本挖掘（Semi Hard Mining）或动态调整边界值 α 。

2.2.4 中心损失

中心损失（Center loss）是一种辅助损失函数，通常与交叉熵损失联合优化，以进

一步提升特征的判别能力。其核心思想是为每个类别定义一个特征中心 C_{y_i} ，并通过最小化样本特征与对应类别中心之间的距离，使同一类别的特征分布更紧凑，从而提升模型的区分能力。具体而言，中心损失的数学表达如下：

$$L_{center} = \frac{1}{2N} \sum_{i=1}^N \|f(x_i) - C_{y_i}\|_2^2. \quad (2-4)$$

其中， $f(x_i)$ 表示样本 x_i 的特征； C_{y_i} 是类别 y_i 在特征空间的中心； $\|\cdot\|_2$ 表示欧氏距离，用来衡量样本特征与类别中心的距离。

中心损失的主要优势在于能够有效减少类内特征的离散，使得同类样本在特征空间中更紧密聚合，从而提高模型的泛化能力和对相似类别的区分能力。然而，由于它需要为每个类别维护一个特征中心，这在类别数量较多时会导致计算复杂度增加。因此，在实际应用中，中心损失通常与交叉熵损失结合使用，以在分类任务和特征优化之间获得平衡。

2.3 换衣行人重识别数据集

2.3.1 PRCC 数据集

PRCC^[33]数据集是针对中等服装变化场景构建的行人重识别基准数据集，包含 221 个身份共 33,698 张图像，通过 3 个摄像头视角采集，其中摄像头 A、B 拍摄同一服装但不同场景（不同房间），摄像头 C 捕获跨日期间隔的服装变化（如 T 恤、短裤替换原服装），涵盖光照、遮挡、姿态及视角变化。该数据集每个身份平均包含约 152 张图像（各视角约 50 张），通过跨视角服装差异模拟现实场景中非剧烈但显著的服装调整需求。

2.3.2 LTCC 数据集

LTCC^[34]数据集是针对长期跨服装行人重识别任务构建的大规模基准数据集，包含 152 个身份共 17,138 张图像，采集自 12 个摄像头视角，覆盖两个月内 478 套不同服装的穿着记录。该数据集通过精细化人工标注，为每张图像同时标注人物身份和服装标签，并划分为衣物更换子集（91 人，14,756 张图像，平均每人套服装）和衣物一致子集（61 人，2,382 张图像），特别模拟现实场景中人物频繁更换服装（如上衣更换率高于下装和鞋子）、携带物品变化及发型调整等挑战，同时包含光照、视角、姿态变化

以及相似服装干扰，填补了长期跨跨服装 ReID 研究的数据空白，为刑侦追踪等实际应用提供重要支持。

2.3.3 VC-Clothes 数据集

VC-Clothes^[35]数据集是基于 GTA5 游戏引擎构建的虚拟行人重识别数据集，通过高精度渲染生成包含多场景（1 个室内、3 个室外）、多视角（4 个固定摄像头）的合成图像，聚焦跨服装身份识别挑战。该数据集通过配置虚拟角色服装（每人 1-3 套）、动态光照（跨场景及时段调整）及固定行走路径，模拟真实环境中的行人外观变化，其中 Cam2、Cam3 强制统一服装以增强跨衣饰识别难度，Cam1、Cam4 保留服装差异性。数据集强调生物特征（体型、发型、性别等）而非服装的识别，涵盖同人异装、异人同装、遮挡、姿态及复杂光照等干扰，为换衣 ReID 及生物特征学习提供可控实验环境，弥补真实数据隐私与标注成本限制。

2.3.4 Celeb-reID 数据集

Celeb-reID^[36]是采集 590 位名人的 10,842 张街拍图像构建而成的名人街拍数据集，通过丰富的人物服装变化（平均每人约 18 张图像）为模型训练与测试提供充足样本。然而，其数据特性存在双重局限性：一方面，街拍场景背景复杂且图像分辨率显著高于安防监控设备，导致训练模型在自域测试（self-testing）中表现优异，但在跨域测试（cross-testing）时因域差异（如低分辨率、结构化背景）泛化能力下降；另一方面，名人着装风格与普通人群的差异性可能削弱模型在刑侦等实际场景的应用效果，突显合成数据与真实监控数据的语义鸿沟挑战。

2.3.5 Celeb-reID-light 数据集

Celeb-reID-light^[37]是 Celeb-ReID 数据集的轻量化版本，专为验证跨服装行人重识别方法鲁棒性而设计。该数据集从过滤后的候选图像中筛选构建，包含 590 个身份共 10,842 张图像，划分为训练集与测试集，其中测试集严格限定同一身份穿不同服装，设置 887 张查询图和 934 张候选图。相较于原数据集，其通过强制每身份服装不重复的设定，在缩小规模的同时强化跨服装识别挑战。

2.3.6 NKUP 数据集

NKUP^[38]数据集包含 107 个身份共 9,738 张图像，于 2019 年 9 月至 12 月跨四季采

集自 15 个室内外场景，覆盖视角、光照、分辨率、姿态、背景等多维度变化，尤其强调服装多样性与季节变迁的复合挑战。作为当前多样性最丰富的换衣 ReID 数据集，NKUP 通过非受限环境数据采集（如第四季度跨场景拍摄）模拟真实世界中行人换装、跨季外观变化等复杂干扰，突破传统数据集对服装一致性的强假设限制。

2.4 行人重识别评价指标

行人重识别作为跨摄像头追踪行人的核心技术，其评价指标需要综合衡量算法在复杂场景下的检索精度和排序能力。其中，均值平均精度（mean Average Precision, mAP）和首位命中率（Rank-1 Accuracy, Rank-1）被广泛视为核心评价指标，两者分别从全局排序质量和单样本匹配能力两个维度刻画算法性能。

mAP 的核心思想在于量化模型对所有正样本的检索效果，其计算过程融合了精确率（Precision）与召回率（Recall）的动态平衡关系。对于单个查询图像，假设数据集中存在 M 个与其身份相同的行人图像，当模型返回的检索结果中前 N 个结果包含 K 个正样本时，精确率定义为 $P = \frac{K}{N}$ ，召回率定义为 $R = \frac{K}{M}$ 。随着检索结果的逐步展开，精确率与召回率会形成一条非单调曲线，而平均精度（Average Precision, AP）则通过积分计算该曲线下的面积，数学上可表示为：

$$AP = \int_0^1 P(R) dR. \quad (2-5)$$

然而，实际应用中检索结果是离散的，因此 AP 通常采用插值法近似计算。具体而言，每当检索到一个正样本时，记录当前召回率下的最大精确率，并对所有召回率点进行插值平滑。例如，若正样本出现在检索结果的第 $\{1, 3, 5, 7, 10\}$ 位，则需依次计算每个正样本位置的精确率，取其插值后的最大值作为局部精度贡献，最终对所有正样本位置的精度贡献取平均得到 AP。mAP 则是所有查询样本的 AP 值的算术平均，其公式为：

$$mAP = \frac{1}{Q} \sum_{q=1}^Q AP_q, \quad (2-6)$$

其中 Q 为查询总数， AP_q 表示第 q 个查询的 AP 值。这一过程严格反映了模型对正样本的排序敏感度：若正样本集中分布在检索结果前列，则 AP 值趋近于 1；反之，若正样本分散在靠后位置，AP 显著降低。

相较于 mAP 的全局视角，Rank-1 识别率则聚焦于模型在最优匹配场景下的极限性能。其定义为：在模型返回的检索结果中，排名第一的样本与查询图像属于同一身份的比例。数学上，对于包含 Q 个查询的数据集，若其中 $Q_{correct}$ 个查询的 Top-1 结果正确，则 Rank-1 计算为：

$$Rank-1 = \frac{Q_{correct}}{Q}. \quad (2-7)$$

这一指标直接反映了模型在理想情况下（即用户仅关注第一条结果）的实用价值。然而，Rank-1 的局限性在于其仅考虑首位结果的正确性，忽略了后续正样本的排序信息。例如，若某查询的前 10 个结果中包含 5 个正样本但均未排在首位，则其 Rank-1 贡献为 0，尽管模型实际具备较高的召回能力。因此，Rank-1 常与 Rank-5、Rank-10 等指标结合使用，共同刻画模型在不同检索深度下的表现。

mAP 与 Rank-1 的互补性体现了行人重识别任务的多维需求。一方面，mAP 通过加权平均所有正样本的排序质量，能够识别模型在长尾分布下的稳定性，例如当部分行人因遮挡或姿态变化导致多数正样本排名靠后时，mAP 会显著下降，而 Rank-1 可能仍保持较高值。另一方面，Rank-1 揭示了模型在特征区分度上的极限能力，尤其在安防等对实时性要求极高的场景中，首条结果的准确性直接影响用户体验。综上，mAP 与 Rank-1 分别从宏观统计和微观匹配两个层面定义了行人重识别系统的评价标准。二者共同构成了行人重识别性能评估的基石，为模型设计、损失函数选择及后处理策略提供了不可替代的指导意义。

第三章 基于自适应感知注意力与金字塔聚合的换衣行人重识别方法

3.1 引言

换衣行人重识别任务的目标是提取不受衣物变化影响的身份信息。现有的主流方法主要关注与服装无关的特征，如身体轮廓、姿态关键点和步态信息等。例如，Yang 等人提出了一种适应行人轮廓变化的网络，但该方法容易受到照明和遮挡等环境因素影响，且可能忽视面部等关键细节。另一类方法则通过分离身份和服装特征进行优化，如基于 GAN 和语义引导的服装擦除网络^{[22][23]}，但这类方法通常伴随较高的计算负担和对数据精度的高度依赖。

近期，Vision Transformer^[26]（ViT）凭借其多头自注意机制有效地捕获图像内的相互依赖关系，在各类计算机视觉任务中展现出卓越的性能。然而，Transformer 架构的一个常见限制是倾向于利用特定层的输出进行表示，因此往往会忽略嵌入在其他层中的其他有价值信息。图 3-1 展示了 ViT 模型前三层和后三层的注意力图可视化，可以观察到，不同层的注意力焦点存在明显差异。此外，虽然现有方法往往通过姿势估计等策略提高对行人局部关键信息的感知能力，然而如何实现局部细节与全局语义信息的有效协同仍然是当前研究中面临的一个重要挑战。




图 3-1 ViT 的前三层（第一行）和后三层（第二行）的注意力图

为了缓解这些局限，本方法提出了一种基于 Transformer 的自适应感知注意力与金字塔聚合网络（A³PFN）。首先设计了一个多层动态集中模块（MLDC），通过加权融合 ViT 各层特征并实时调整每层的重要性，从而整合各层特征并减少层间冗余。随后，考虑到 ViT 模型的每一层特征的焦点聚集在图像的不同方面，提出了一个局部金字塔

聚合模块（LPAM）来提取多尺度特征，以保持对全局感知和关键局部信息的注意力。该模块创新性地将快速傅立叶变换（FFT）集成到自注意力机制中，以有效识别频域中细微的行人差异（例如步态和服装纹理），从而提高计算效率和准确性。最后，由于现有的 Re-ID 数据集没有考虑天气的影响，提出了 VC-Clothes-W&R 数据集，通过引入风雨元素来填补气象变化这一空白。新数据集和多个换衣数据集的大量实验清楚地证实了本方法的优越性。

3.2 整体框架结构

如图 3-2 所示，A³PFN 的整体框架主要由两个关键模块组成：1）多层动态集中模块：针对换衣场景中特征提取的关键挑战，通过实时评估各层特征的重要性权重，实现特征提取策略的动态调整。这种自适应机制不仅提高了模型在复杂换衣环境中的信息利用效率，还有效减少了相关层之间的计算冗余。2）局部金字塔聚合模块：提出了局部金字塔聚合模块（LPAM）来提取多尺度特征，旨在保持全局感知能力并关注关键局部信息。在这个模块中，本方法将快速傅立叶变换（FFT）与自注意力机制相结合，以更有效地在频域中识别和分析行人步态和其他结构细节，并降低自注意力机制中处理高维数据的计算复杂度。




图 3-2 A³PFN 框架图

3.2.1 多层动态集中模块

在图像处理领域，Transformer 架构以其层级化的特征构建机制而著称，能够从最基础的边缘和纹理检测，逐步提炼至复杂的语义场景理解。这种层次化的特征表达形成了一个从局部细节到全局语义的连贯视觉认知。然而，当前主流的行人重识别方法往往过度依赖 Transformer 的最高层特征作为身份辨别的唯一依据，这种做法不可避免地忽略了基础层和中间层中蕴含的丰富细节信息，从而限制了模型的辨别能力。为弥补这一不足，本方法提出了多层动态集中模块（MLDC）。MLDC 通过动态地评估各个层次特征的重要性，并聚合不同层次中的关键信息，从而实现各层优势互补，以获得更具鲁棒性且富有细节的特征表示。

权重计算：为了有效地进行多层特征融合，多层动态集中模块为每一层分配一个权重系数 $w_i (i \in 1, 2, \dots, 12)$ ，用于实时评估各层特征的重要性，从而减少相关层的相似性冗余， w_i 的具体计算过程如下：

$$w_i = \frac{\exp(f_i - \alpha \sum_{j=1, j \neq i}^L \langle F_i, F_j \rangle)}{\sum_{k=1}^L \exp(f_k - \alpha \sum_{m=1, m \neq k}^L \langle F_k, F_m \rangle)}, \quad (3-1)$$

其中， $F_i \in R^{N \times D}$ 表示第 i 层的输出， N 表示图像块的数量， D 表示每个 token 的特征维数， $\langle \cdot, \cdot \rangle$ 为内积，衡量不同层之间的特征相关性， α 为正则化系数，用于缩放正交性约束的影响，减少层间特征重叠， f_i 为一维标量，表示各层输出特征 F_i 的重要性， f_i 的具体计算公式为：

$$f_i = \frac{1}{h} \sum_{t=1}^h \text{mean}(A_{it}), \quad (3-2)$$

h 表示每层注意力头的数量， $\text{mean}(\cdot)$ 表示所有元素的均值， $A_{it} \in R^{N \times N}$ 表示第 i 层中第 t 个头的注意力得分矩阵， A_{it} 按照如下的公式计算：

$$A_{it} = \text{softmax}\left(\frac{Q_{it} K_{it}^T}{\sqrt{d_t}}\right). \quad (3-3)$$

接下来，按照权重融合多层特征表示，获得特征 F_{fusion} ：

$$F_{\text{fusion}} = \sum_{i=1}^L w_i F_i. \quad (3-4)$$

3.2.2 局部金字塔聚合模块

尽管多层动态集中模块在融合多层特征以实现全面表示方面取得了一定成效，但其全局融合方法在处理多尺度信息时仍存在一定局限性，可能导致关键的细粒度特征在整合过程中被稀释或丢失。为解决这一挑战，本研究进一步提出了局部金字塔聚合模块（LPAM）。

如图 3-2 所示，LPAM 采用层级化的金字塔结构设计，从 Transformer 编码器中选取四个具有互补性的层次输出特征 F_1, F_2, F_3, F_4 。这种层级选择策略使模块能够以由粗到细的渐进方式捕获并融合多尺度视觉信息。与传统的全局特征融合不同，LPAM 通过层叠式的特征融合机制，保留了各个尺度下的判别性细节，同时建立了不同尺度特征之间的内在联系。




图 3-3 FFT 自注意力示意图，旨在从频域角度识别行人的详细信息。

具体来说，在该模块的局部特征聚合机制（LFA）中，首先对特征 F_{l_1} 和 F_{l_2} 进行 1×1 卷积和层归一化处理，并通过 ReLU 激活函数实现特征的非线性增强。此外，该机制中引入结合了快速傅立叶变换（FFT）的自注意力机制，从频域角度进一步提取并增强行人的关键信息，如图 3-3 所示。最后，将卷积处理后的 F_{l_1} 和 F_{l_2} 连接起来，并输入到卷积块中实现特征融合。特征融合的公式如下：

$$F_{mid_{l_1}} = \rho(\text{concat}(\rho(F_{l_1}), \rho(F_{l_2}))), \quad (3-5)$$

其中 $\rho(\cdot)$ 表示卷积块， $\text{concat}(\cdot, \cdot)$ 表示拼接操作。后续的融合步骤与此类似，详细过程见图 3-2 所示的局部金字塔聚合模块（LPAM）框架图。

下面具体介绍一下局部金字塔聚合模块中结合了快速傅立叶变换的自注意力机制。

快速傅立叶变换^[39]（FFT）是一种计算离散傅立叶变换的有效算法，其计算复杂度从 $O(N^2)$ 显著降低到 $O(N\log N)$ ，这使得它成为信号频域分析中至关重要的部分。在 LPAM 模块的自注意力中输入特征矩阵 $X \in \mathbb{R}^{N \times D}$ ，其中 N 表示图像块（token）的数量， D 为每个 token 的特征维度。随后，对 X 执行不同的线性，得到查询（Q）、键（K）和值（V）矩阵，并进一步将它们划分为多个注意力头。为了提高 FFT 的计算效率，该模块适当地将 Q 和 K 矩阵填充到最接近的 2 的整数幂，获得填充后的矩阵 Q_{padded} 和 K_{padded} 。接着，应用 FFT 计算 Q_{padded} 和 K_{padded} 在频域上的相关性，获得增强的频域注意力特征。具体的输出计算公式如下：

$$Attn = \text{Softmax}(F^{-1}(F(Q_{padded}) \odot F(K_{padded})))[:, :, :, Q.size(-1)], \quad (3-6)$$

其中， $F(\cdot)$ 和 $F^{-1}(\cdot)$ 分别表示 FFT 和逆 FFT（IFFT）， $\odot$ 为点积运算， $[:, :, :, Q.size(-1)]$ 表示在最后一个维度上进行切片操作，从而移除填充的部分。Softmax 函数旨在对结果进行归一化，从而产生注意权重 $Attn$ ，最后通过加权计算和残差连接得到注意加权的输出。

3.2.3 损失函数设计

在行人重识别任务中，ID 损失依赖标签分类，可能忽略细粒度特征差异。以同一行人从不同视角为例，尽管能被正确分类，但其特征仍可能未充分对齐；另一方面，三元组损失通过优化特征距离来提升判别能力，却对噪声十分敏感，尤其在难样本采样不当的情况下易导致训练不稳定。因此，本方法融合两种损失的优势，既兼顾语义判别性又强化度量学习能力，从而提升模型的整体表现。

身份损失（ID 损失）采用传统的交叉熵损失函数，具体公式如下：

$$L_{ID} = -\sum_j^C y_j \log(p_j), \quad (3-7)$$

其中， C 表示类别数， y_j 是真实标签的独热编码， p_j 是模型预测样本属于第 j 个类别的概率。

在三元组损失的应用中，本方法采用了半硬样本挖掘策略，以缓解硬样本挖掘中因噪声样本导致的过拟合问题。通过在训练阶段选取预测错误但置信度较低的样本，可扩大模型对样本集的覆盖范围，并降低噪声样本的干扰。半硬样本的指标函数如下：

$$I_{semi-hard}(x_l^a, x_l^p, x_l^n) = \begin{cases} 1, d(ap) + m < d(an) < d(ap) + M \\ 0, otherwise \end{cases}. \quad (3-8)$$

上式中 $d(ap)$ 表示锚样本 x_l^a 与正样本 x_l^p 之间的距离, $d(an)$ 表示锚样本与负样本 x_l^n 之间的距离。 m 表示锚样本与正样本之间的最小距离差, 用于避免模型只关注相似样本之间的细微差异, M 表示锚样本与负样本之间的最大距离, 以防止选取过于简单的负样本, 从而保证模型学习到具备判别力的特征。基于此, 半硬样本挖掘的三元组损失定义如下:

$$L_{tri} = -\sum_l^N I_{semi-hard}(x_l^a, x_l^p, x_l^n) (\|f(x_l^a) - f(x_l^p)\|_2^2 - \|f(x_l^a) - f(x_l^n)\|_2^2 + m)_+, \quad (3-9)$$

上式中, $f(\cdot)$ 表示特征提取算子, 用于将输入图像映射到嵌入空间。 $\|\cdot\|_2^2$ 表示 L2 范数的平方, $(\cdot)_+$ 表示铰链损失函数, 仅当括号中的值为正数时计算损失, 否则损失为 0。因此, 模型的综合损失函数可定义为:

$$L = \sum_q^T t_q (L_{ID_q} + L_{tri_q}) (q=1, \dots, 4), \quad (3-10)$$

其中, $T=4$ 表示本方法中模型输出特征的总数, t_q 表示第 q 个输出特征的权重。尽管为每个损失分量指定固定权重简单易行, 但这种方法难以保证模型性能的最优化。本方法引入了损失函数权重的自适应调整机制, 在训练初期为各输出特征分配相同的权重, 并在后续训练过程中, 通过反向传播动态优化损失权重, 从而实现模型整体性能的进一步提升。

3.3 实验结果与分析

3.3.1 实现细节与参数设置

数据集: 为了客观地评估本方法提出的模型性能, 本章在多个公开的换衣行人数据集上展开对比实验, 包括 PRCC^[33]、LTCC^[34]、VC-Clothes^[35]、Celeb-reID^[36]、Celeb-reID-light^[37]、NKUP^[38], 具体数据集的基本信息如表 3-1 所示。此外, 本章还基于 VC-Clothes 数据集构建了一个针对风雨天气条件的增强数据集 VC-Clothes-W&R, 以进一步验证和提升本方法在复杂环境与背景变换下的稳定性与泛化性能。

评估指标: 为了客观地验证本方法在不同场景下的性能, 本章在实验过程中采用

了三种测试场景评估 Rank-1 (R-1) 和 mAP 指标的准确率: (1) 混合场景 (Standard), 包括服装变化与服装一致的情况; (2) 服装变化场景 (Cloth-changing), 仅包括服装变化的样本; (3) 服装一致场景 (Same clothes), 仅使用服装一致样本。下文对比实验中使用的简称“sil”、“ga”、“dg”、“pose”和“bs”分别代表行人语义分割、步态、数据生成、人体姿势和型信息。

表 3-1 实验中使用的长期行人数据集, 其中“SC”和“CC”分别表示相同服装和服装变化两种模式。

数据集	来源	相机数	数据类型	天气背景
PRCC	采集	3	SC/CC	-
LTCC	采集	12	SC/CC	-
VC-Clothes	合成	4	SC/CC	-
Celeb-reID	采集	较多	CC	-
Celeb-reID-light	采集	较多	CC	-
NKUP	采集	15	CC	-
VC-Clothes-W&R	合成	4	SC/CC	风&雨

实验细节: 本方法使用 Vision Transformer^[26] (ViT-Base) 为基线网络进行实验, 该模型由 12 个 Transformer 编码层组成, 每层的嵌入维度为 768, 能够有效地处理尺寸为 16×16 像素的图像块。为满足模型对输入图像尺寸的要求, 本章统一将所有图像调整为 256×128 像素。此外, 为进一步提升模型在真实视觉环境中的泛化能力, 实验过程中采用了随机水平翻转和随机擦除两种数据增强策略, 每种策略以 0.5 的概率独立应用。在训练阶段, 本方法采用每批次包含 4 个实例的 softmax 采样策略来增强模型的泛化能力, 并使用 8 个数据加载线程并行处理, 以提升训练过程的数据加载效率。模型在训练过程中通过随机梯度下降 (SGD) 算法进行优化, 总轮次为 120 个 epoch, 初始学习率设置为 0.008。为了优化学习率调整过程, 本方法采用线性预热技术并将学习率衰减因子设置为 $1e-4$ 。此外, 为及时评估模型性能的变化, 每隔 10 个 epoch 使用批大小为 64 的图像数据进行一次性能评估, 以动态监控模型训练效果, 确保实验结果的稳定性与有效性。

3.3.2 VC-Clothes-W&R 数据集

VC-Clothes 作为一个合成数据集, 能够提供更可控的实验环境, 使其他影响因素 (如光照条件和遮挡) 在不同场景下保持相对一致。相比之下, 真实世界中收集的图像数据集往往具有自然环境的复杂性, 存在诸多不可控变量, 如波动的光照条件、不

可预测的障碍物导致的不同程度的遮挡等。这些因素可能会掩盖天气对识别任务的具体影响，使得分离测试所需的变量变得具有挑战性。因此，为了增强图像背景的多样性并提高模型的鲁棒性，本章基于 VC-Clothes 数据集构建了涵盖风雨天气条件的增强数据集（VC-Clothes-W&R）。数据集中的部分图像展示如图 3-4 所示，天气背景的构建过程如下所述：



图 3-4 来自 VC-Clothes-W&R 数据集的图片实例。

考虑到降水程度的复杂性和图像亮度的变化，本方法采用改进的大气散射模型^[40]来生成图像的雨天和刮风场景。具体而言，假设原始图像中某像素点为 $J(x, y)$ ，加入风雨场景后的对应像素 $I(x, y)$ 可通过以下公式计算：

$$I(x, y) = L[J(x, y)t(x, y) + R(x, y)(1 - t(x, y))M(x, y)], \quad (3-11)$$

公式中， $L[\cdot]$ 反映亮度系数； $R(x, y)$ 表示空间坐标 (x, y) 上雨滴的辐射亮度； $M(x, y)$ 为模糊核，用于模拟雨滴引起的视觉扭曲的宽度和扩散特性； $t(x, y)$ 表示每个点处的介质透射比，它量化了由于该位置处存在雨滴而产生的光强度，具体公式如下：

$$t(x, y) = e^{-\beta d(x, y)s(x, y)\cos(\theta)}, \quad (3-12)$$

其中， β 为介质雨水的衰减系数， $d(x, y)$ 表示点 (x, y) 处介质的深度， $s(x, y)$ 表示 (x, y) 处雨水的密度， θ 为雨滴的入射角度；该公式有效刻画了风雨天气下雨滴对于光线传播的局部透射影响。

接下来，为了真实地表现雨滴对成像传感器的散射效应，本方法利用模糊核函数 $M(x, y)$ 模拟雨滴对成像传感器及其有效半径的散射效应，定量描述不同大小雨滴引起的光学扩散特性。核函数具体定义如下：

$$M(x, y) = \frac{1}{2} e^{-\frac{x^2+y^2}{2k^2}}, \quad (3-13)$$

上式中， k 表示雨滴散射效应的尺度参数，通过调整 k 可以模拟不同大小的雨滴在传感器上造成的散射分布，从而更准确地反映雨滴对图像质量的影响。

整个模型不仅模拟了雨滴方向、雨滴大小等，还充分考虑了降雨条件下整体和局部的光照波动，从而构建出更为真实且多样化的降雨场景，进一步提升可数据集的多样性。

3.3.3 与先进方法的比较

在 **VC-Clothes** 数据集上的实验结果：如表 3-2 所示，本章在 VC-Clothes 数据集上将提出的 A³PFN 与七种基于换衣的方法和三种短期方法进行了评估。

表 3-2 A³PFN 和目前先进方法在 VC-Clothes 数据集上的性能比较

方法名/出版处	模态	Cloth-changing		Same clothes	
		R-1	mAP	R-1	mAP
基于短期场景的方法					
PCB(ECCV18) ^[11]	RGB	62.0	62.2	-	-
ISP(ECCV20) ^[44]	RGB+sil	72.0	72.1	94.5	94.7
DG-Net(CVPR19) ^[24]	RGB+dg	76.8	68.4	94.1	93.8
基于换衣场景的方法					
FSAM(CVPR21) ^[18]	RGB+bs	78.6	78.9	94.7	94.8
MBUNet(TIP22) ^[19]	RGB+pose	82.3	68.2	95.7	94.3
CAL(CVPR22) ^[45]	RGB	81.4	81.7	<u>95.1</u>	<u>95.3</u>
ACID(TIP23) ^[41]	RGB	<u>84.3</u>	74.2	<u>95.1</u>	94.7
AFL(TMM23) ^[43]	RGB	82.5	<u>83.0</u>	-	-
DCR-ReID(TCSVT23) ^[42]	RGB+bs	83.7	82.6	94.6	94.5
MGP(TMM23) ^[46]	RGB+dg	81.8	81.7	94.7	94.9
本方法	RGB	89.3	83.1	96.6	95.6

可以注意到，本方法在服装变化和相同服装设置中都取得了最佳效果。相比 FSAM^[18]将细粒度的体形知识从形状转移到外观流以增强与衣服无关的特征，本方法在服装变化设置下分别将 R-1 和 mAP 提高了 10.6%和 4.2%，这表明信息的质量对 FSAM 的性能有很大影响。与使用逐步竞争策略积累身份线索的 ACID^[41]相比，本方法有效结合细粒度局部信息与全局特征建模优势，在服装变化场景下，R-1 和 mAP 分别

提升了 4.9%和 8.9%，验证了本方法在大规模数据环境中稳健提取身份信息的能力。DCR-ReID^[42]在人体部件重构的基础上，提出了部件重构解耦（CRD）模块来分离服装相关和不相关的特征，但在图像质量较低或有遮挡时难以有效发挥作用；其深度组装配耦（DAD）模块虽然增强了特征区分度，但较高的计算量要求限制了其在资源受限环境下的应用。MBUNet^[19]通过利用与服装不相关的生物线索（如头部、颈部和肩部）减少了服装变化的干扰，但这些生物特征可能由于遮挡或相机间角度变化而大大降低其有效性。此外，次优方法 AFL^[43]虽然取得了不错的效果，但关联因子的构建需要考虑不同身份的差异性和相似性，大大增加了模型的复杂度。对比 AFL，本方法不仅在服装变化场景下 R-1 提升了 6.7%，mAP 提升了 0.1%，而且有效降低了实验设置成本，由此表明本方法在高准确率和低计算量及模型复杂度之间取得了良好的平衡。

在 Celeb-reID 和 Celeb-reID-light 上的实验结果：为进一步验证本方法的有效性，本章将其与多个短期方法以及换衣场景的研究成果在 Celeb-reID 和 Celeb-reID-light 数据集上进行了对比分析，结果如表 3-3 所示。

表 3-3 本方法和目前先进方法在 Celeb-reID 和 Celeb-reID-light 数据集上的性能比较。

方法名/出版处	模态	Celeb-reID		Celeb-reID-light	
		R-1	mAP	R-1	mAP
基于短期场景的方法					
MGN(ACMMM18) ^[12]	RGB	49.0	10.0	13.9	21.5
PCB(ECCV18) ^[11]	RGB	37.1	8.2	9.0	16.7
DG-Net(CVPR19) ^[24]	RGB+dg	50.1	10.6	23.5	12.6
基于换衣场景的方法					
RCSAN(ICCV21) ^[47]	RGB	55.6	11.9	29.3	16.7
AFD-Net(IJCAI21) ^[48]	RGB+GAN	52.1	10.6	22.2	11.3
MBUNet(TIP22) ^[19]	RGB+pose	55.3	12.1	<u>33.9</u>	21.3
SAFR(TIP22) ^[49]	RGB+GAN	<u>56.0</u>	14.2	29.5	16.7
DCR-ReID(TCSVT23) ^[42]	RGB+bs	60.8	<u>15.7</u>	33.5	<u>22.0</u>
MGP(TMM23) ^[46]	RGB+bs	60.5	16.1	32.8	21.5
SAVS(TNNLS23) ^[22]	RGB+sil	65.9	21.3	-	-
本方法	RGB	<u>61.4</u>	<u>16.9</u>	40.6	24.2

结果表明，本方法在 Celeb-reID-light 上超越了所有比较方法。相对于 AFD-Net^[48]和 SARF^[49]，本方法的 R-1 准确率分别提高了 18.4%和 11.1%，mAP 分别提高了 12.9%

和 7.5%。由于 AFD-Net 和 SARF 的共同点在于它们通过生成对抗图像来解耦信息，并通过额外的人体解析模型来分离服装区域，这增加了计算开销。相比之下，本方法不需要加入额外的生物分支，而且充分利用了 ViT 不同层之间的信息差异，在提高模型准确率的同时，有效地减少了额外的计算负担。

从表 3-3 可以看出，本方法在 Celeb-reID 数据集上取得了第二高的性能，而 SAVS^[22]获得了最佳结果。具体来说，本方法的 R-1 和 mAP 分别比 SAVS 低 4.5%和 4.4%。这一差距主要源于 SAVS 采用了视觉掩蔽模块以屏蔽服装信息，并在人体语义注意模块中对视觉特征图进行加权，以充分利用人体语义信息。这种结合服装掩蔽与生物识别的策略展现出较强的适应性，为未来在该领域的进一步研究提供了新的思路。

在 NKUP 数据集上的实验结果：表 3-4 展示了本方法与短期 Re-ID 方法及换衣 Re-ID 方法在 NKUP 数据集上的比较。从结果可以看出，本方法在该数据集上明显优于所有短期方法，并取得了最佳性能。对比的三种换衣方法均利用语义分割或身体形状作为辅助线索，以提取与服装无关的身份特征。然而，这些方法未能充分利用行人的局部结构信息，限制了识别能力的进一步提升。相较于第二优方法 SAVS^[22]，本方法在 R-1 和 mAP 指标上分别提升了 0.4%和 0.5%。这一结果进一步表明，通过有效聚合不同尺度的特征，本方法显著增强了人体部位的区分能力，提升了模型的整体表现。

表 3-4 本方法和目前先进方法在 NKUP 数据集上的性能比较。

方法名/出版处	模态	R-1	mAP
基于短期场景的方法			
PCB(ECCV18) ^[11]	RGB	49.0	10.0
MGN(ACMMM18) ^[12]	RGB	37.1	8.2
基于换衣场景的方法			
MVSE(ACMMM21) ^[50]	RGB+sil	23.8	17.9
UCAD(IJCAI22) ^[51]	RGB+bs	25.0	16.9
MBUNet(TIP22) ^[19]	RGB+pose	24.5	17.7
DCR-ReID(TCSVT23) ^[42]	RGB+bs	24.7	18.3
MGP(TMM23) ^[46]	RGB+dg	25.1	18.0
SAVS(TNNLS23) ^[22]	RGB+sil	<u>25.3</u>	<u>18.6</u>
本方法	RGB	25.7	19.1

在 VC-Clothes-W&R 上的实验结果：为了进一步验证本方法的泛化能力，在 VC-Clothes-W&R 上进行了对比实验。据现有研究所知，该数据集是第一个添加天气背景

的换衣数据集。表 3-5 展示了本方法与短期和换衣方法在该数据集上的比较结果，表明本方法取得了最佳性能。与取得第二佳性能的 ACID[41]相比，本方法在服装变化设置中分别将 R-1 和 mAP 提高了 3.6%和 5.2%。由于 ACID 通过全局、通道和像素级特征提取逐渐积累 ID 线索，这可能导致大规模数据处理中的特征冗余和推理速度缓慢。相比之下，本方法采用多层动态集中模块来聚合每层的特征并最小化相关层之间的计算重叠，从而有效提升了风雨场景下的鲁棒性。

表 3-5 本方法和目前先进方法在 VC-Clothes-W&R 数据集上的性能比较。

方法名/出版处	模态	Cloth-changing		Same clothes	
		R-1	mAP	R-1	mAP
基于短期场景的方法					
ISP(ECCV20) ^[44]	RGB+sil	72.0	72.1	94.5	94.7
DG-Net(CVPR19) ^[24]	RGB+dg	76.8	68.4	94.1	93.8
基于换衣场景的方法					
MBUNet(TIP22) ^[19]	RGB+pose	78.1	70.6	90.9	91.1
AFL(TMM23) ^[43]	RGB	78.9	70.2	91.6	91.3
ACID(TIP23) ^[41]	RGB	<u>80.5</u>	71.3	91.1	90.8
DCR-ReID(TCSVT23) ^[42]	RGB+bs	80.1	72.0	91.9	91.4
MGP(TMM23) ^[46]	RGB+dg	77.5	<u>72.3</u>	<u>92.4</u>	<u>92.1</u>
本方法	RGB	84.1	76.5	93.1	92.7

在 PRCC 和 LTCC 上的实验结果：本章在 PRCC 和 LTCC 数据集上与最先进的方进行了比较，结果如表 3-6 所示。在服装变化设置中，与第次优方法 MBUNet^[19]相比，我们的方法在 PRCC 和 LTCC 数据集上的 R-1 提高了 1.5%和 0.6%，mAP 提高了 3.4%和 2.7%。与其他方法相比，RCSAN^[47]侧重于服装状态感知，但在动态场景变化下表现不佳；FASM^[18]增强了体形和外观特征，但在数据稀疏或变化剧烈时效果有限；GIReID^[20]依赖于单幅图像的步态信息，但当步态细微或模糊时其准确率会降低；MBUNet 专注于提取与服装无关的生物特征，但在遮挡严重时会失败。我们的模型通过融合 Transformer 各层的动态信息、加强对关键局部信息的捕捉，有效提升了多变服装条件下的识别准确率和鲁棒性。在相同服装设定下，AIM^[52]取得了最佳效果。它是一种基于因果关系的自动干预模型，通过双分支模型模拟因果干预，在不破坏语义完整性的情况下，逐步将服装偏见与纠缠的 ID 服装表征分离。与本方法相比，AIM 在

PRCC 和 LTCC 上的 Rank-1 分别高 0.2%和 4.2%，mAP 分别高 1.8%和 4.4%。在未来工作中，考虑借鉴 AIM 的因果推理方法来增强模型更有效地区分身份和服装变化的能力。

表 3-6 本方法和目前先进方法在 PRCC 和 LTCC 数据集上的性能比较。

方法名/出版处	模态	PRCC				LTCC			
		Cloth-changing		Same clothes		Cloth-changing		Same clothes	
		R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
基于短期场景的方法									
PCB(ECCV18) ^[11]	RGB	22.9	-	86.9	-	23.5	10.0	61.8	27.5
ISP(ECCV20) ^[44]	RGB+sil	33.6	-	92.8	-	27.8	11.9	66.3	29.6
MGN(ACMMM18) ^[12]	RGB	53.5	53.3	98.2	98.4	25.0	12.6	68.4	34.6
基于换衣场景的方法									
RCSAN(ICCV21) ^[47]	RGB	50.2	48.6	100	97.2	-	-	-	-
GI-ReID(CVPR22) ^[20]	RGB+ga	37.6	82.3	79.0	-	28.1	13.2	<u>73.6</u>	<u>36.1</u>
FSAM(CVPR21) ^[18]	RGB+bs	54.5	-	98.8	-	38.5	16.2	-	-
MBUNet(TIP22) ^[19]	RGB+pose	<u>67.6</u>	<u>65.3</u>	100	<u>99.6</u>	<u>39.5</u>	14.7	67.1	34.4
AIM(CVPR23) ^[52]	RGB	54.7	55.0	100	99.9	38.3	17.0	76.1	39.1
本方法	RGB	69.1	68.7	<u>99.8</u>	98.1	40.1	17.4	71.9	34.7

3.3.4 消融实验

框架各模块的有效性：为了验证各模块的有效性，本章在 Celeb-reID、NKUP、Celeb-reID-light、VC-Clothes 等数据集上进行了实验，实验结果如表 3-7 所示。

从表 3-7 中可知，引入 MLDC 模块后，所有数据集的性能都有所提升，尤其是在 Celeb-reID-light 上，R-1 和 mAP 的准确率分别提升了 4.3%和 1.4%。这说明 MLDC 模块通过动态融合 Transformer 的多层信息，有效提升了模型对服装变化的适应性。单独加入提出的 LPAM 时，baseline 在大部分数据集上的性能得到进一步提升，特别是在 NKUP 和 Celeb-reID-light 上的 R-1 分别提升了 1.8%和 3.6%，凸显了局部金字塔聚合模块在提取多尺度特征、捕捉局部信息的关键作用。

当 MLDC 与 LPAM 同时使用时，模型在所有数据集上的性能都有明显提升，特别是在 Celeb-reID-light 上，R-1 和 mAP 的准确率分别提升了 7.0%和 3.6%。这些结果表明，同时使用多层信息融合和多尺度信息可以进一步抵抗服装变化带来的干扰。接下

来, 为了进一步验证所提出的 FFT 自注意力机制的优越性, 本章对比了结合 FFT 的注意力机制和普通注意力机制在 LPAM 模块局部特征聚合上的性能。

表 3-7 在 Celeb-reID、NKUP、VC-Clothes、VC-Clothes-W&R 和 Celeb-reID-light 数据集中对本方法框架中的组件进行消融实验。

变量	Celeb-reID		NKUP		VC-Clothes		Celeb-reID		VC-Clothes-W&R	
	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
基线	57.3	15.6	21.5	15.5	83.7	80.6	29.1	20.3	80.3	74.4
+MLDC	59.1	16.3	22.5	16.9	85.3	81.9	33.4	21.7	81.9	75.2
+LPAM	60.2	15.9	23.3	17.7	84.8	80.3	32.7	21.2	81.5	74.9
+MLDC+LPAM	<u>60.9</u>	<u>16.8</u>	<u>24.2</u>	<u>18.3</u>	<u>87.1</u>	<u>82.3</u>	<u>36.1</u>	<u>23.9</u>	<u>83.1</u>	<u>75.8</u>
+MLDC+LPAM (FFT)	61.4	16.9	25.7	19.1	89.2	83.1	40.6	24.2	84.1	76.5

从表 3-7 中还可以看出, 引入 FFT 之后, 模型在所有数据集上的性能都有了进一步的提升, 特别是在 VC-Clothes-W&R 数据集上, R-1 和 mAP 分别提升了 1.0% 和 0.7%。这充分说明了 FFT 通过将数据转换到频域, 可以帮助模型更有效地在频域上处理和识别结构细节。这些结果充分验证了框架中各个组件的有效性和重要性。为了直观地展示各个模块的有效性, 将 Celeb-reID 数据集上的实验结果进行了可视化, 如图 3-5 所示。




图 3-5 在 Celeb-reID 数据集上对基线和本方法各模块及组合进行可视化。绿色框突出显示正确结果, 红色框突出显示错误结果。

可以看出,单独使用模块 MLDC 和 LPAM 的匹配结果优于基线模型。当这两个模块结合使用时,其在 R-1 至 R-10 的匹配率有显著的提升。特别是在引入 FFT 自注意力之后,模型的准确率得到了进一步的提升,这与本方法的消融实验结果完全一致。

特征分布的可视化: 为了进一步证实各模块的有效性,本方法采用 t-SNE^[53]可视化模型在不同组件中提取的特征分布,如图 3-6 所示。图中圆圈表示从 Celeb-reID 数据集的训练集中随机选择的图像特征,不同颜色表示不同的身份。




图 3-6 Celeb-Rid-Light 数据集上特征分布的视觉分析。

具体而言,图 3-6 (a) 显示了基线模型 ViT 提取特征的分布。可以看出,特征点相对分散,身份聚集程度较低,这反映了行人换衣行为对 ViT 模型有效识别的挑战很大。图 3-6 (b) 显示了引入 MLDC 模块后的特征分布,MLDC 通过对 Transformer 的多层特征进行加权融合,显著增强了对身份信息的捕捉,从而使类之间的界限更加明显。图 3-6 (c) 显示了在基线模型中引入 LPAM 模块后的特征分布。该模块通过聚焦关键局部信息、提取多尺度特征,显著提升了模型对局部细节的捕捉和感知能力,特征分布相较于基线更加聚集。图 3-6 (d) 为同时融合 MLDC 与 LPAM 模块后的特征分布,其中特征点聚集效果更佳,说明这两个模块的结合不仅保持了全局感知能力,还显著提升了细节的识别与处理能力,展现出优越的综合性能。图 3-6 (e) 在 (d) 的基础上结合了傅立叶变换 (FFT),即本章提出的完整方法 A^3PFN ,其特征聚集效果最为突出,充分说明了 FFT 在帮助模型更有效地处理和识别频域结构细节方面的潜力。由此可以看出各模块展现出的优越性能。

LPAM 模块中关于 Transformer 层的选择: 本方法的基线 ViT-Base^[26]模型包含 12 个 Transformer 层。由于 Transformer 的较低层主要关注边缘、颜色和纹理等细节特征;中间层逐渐转向图像的局部结构;较高层进一步关注图像的全局语义理解。为了使 LPAM 模块获得全面的特征集成,本方法根据经验选择了第 3、6、9 和 12 层作为输入。为了证明选择这些层数的有效性,在 Celeb-reID、NKUP 和 VC-Clothes (跨服装) 数据集上进行了部分实验。结果如表 3-8 所示,可以看到所选择的 3、6、9 和 12 层在这三

个数据集上都取得了最佳性能。这种组合涵盖了从初级到高级的各个特征阶段，为 LPAM 模块提供了全面的特征集成，并强调了在特征融合中考虑局部到全局信息的重要性。

表 3-8 不同 Transformer 层选择上的消融结果比较。

选择的层	Celeb-reID		NKUP		VC-Clothes	
	R-1	mAP	R-1	mAP	R-1	mAP
1、2、3、4	57.1	15.1	23.1	17.1	87.1	81.2
5、6、7、8	59.3	16.0	24.4	17.9	87.7	81.6
9、10、11、12	58.4	15.7	24.1	17.2	87.3	81.7
2、4、6、8	<u>60.2</u>	<u>16.6</u>	<u>25.2</u>	18.8	88.4	82.9
3、6、9、12	61.4	16.9	25.7	19.1	89.2	83.1

自适应权重对损失函数的有效性：本方法采用 ViT-Base^[26]作为基线模型，该模型包含 12 个 Transformer 层。根据 Transformer 架构的特性，不同层次捕获的图像信息各有侧重：低层主要提取边缘、颜色和纹理等细节特征，中间层逐步捕获局部结构信息，而高层则专注于整体语义理解。基于这一特性，为使 LPAM 模块能够实现更全面有效的特征集成，本方法经过分析后选取了第 3、6、9 和 12 层的特征作为输入，形成了一个覆盖低级至高级信息的特征金字塔。为验证这一层选择策略的有效性，在 Celeb-reID、NKUP 和 VC-Clothes（跨服装）三个具有代表性的数据集上进行了对比实验。如表 3-8 所示，所选取的 3、6、9 和 12 层组合在所有测试数据集中均取得了最佳性能。这一结果充分证明，该层组合成功地捕获了从局部细节到全局语义的多层次特征信息，不仅为 LPAM 模块提供了更为全面的特征支持，也验证了在行人重识别任务中，融合多层次特征信息的重要性。

表 3-9 手动加权和自适应加权的消融研究。

权重分配				NKUP		
t_1	t_2	t_3	t_4	R-1	R-5	mAP
0.25	0.25	0.25	0.25	21.5	31.2	17.5
0.7	0.1	0.1	0.1	22.7	33.3	18.3
0.1	0.7	0.1	0.1	<u>24.4</u>	34.3	18.1
0.1	0.1	0.7	0.1	23.9	33.1	17.9
0.1	0.1	0.1	0.7	23.3	<u>33.5</u>	<u>18.5</u>
本方法 (自适应权重)				25.7	35.1	19.1

3.4 本章小结

本章提出了一种基于自适应感知注意力与金字塔聚合的换衣行人重识别方法，设计多层动态集中模块实时评估不同层次特征的重要性，有效减少计算冗余并提高准确率。此外，所提出的局部金字塔聚合模块优化了多尺度特征的提取过程，在保持全局感知能力的同时关注关键的局部信息。本方法还将快速傅立叶变换与自注意力机制相结合，旨在增强对行人细节的识别能力。最后，为了削弱复杂环境对识别问题的影响，在现有数据集中添加了风雨场景，以提高模型的适用性。尽管本章的研究在换衣行人重识别任务中取得了良好的进展，但在现实环境中仍然存在一些局限性：频繁的遮挡和复杂的光照条件可能会阻碍行人身份特征的准确提取。此外，模型在极端天气环境下的表现也有待提高。因此，未来研究将更深入地融合遮挡、弱光等环境因素，测试更加多样化的气候条件，并探索改进策略以增强模型在各种复杂的现实场景中的适应性和鲁棒性。

第四章 基于图文预训练大模型与多模态特征融合的换衣行人重识别方法

4.1 引言

尽管上一份工作通过动态特征选择与频域融合策略有效缓解了换衣场景的多尺度特征退化问题，但该方法作为纯视觉建模范式仍受限于服装特征的语义干扰，无法充分挖掘多模态信息的互补优势。为此，本章基于图文预训练大模型提出多模态特征融合的方法，结合姿态感知与全局-局部交互机制，突破单模态的认知局限，从而有效减轻服装变化对行人身份特征表达的干扰影响。

近年来，基于对比语言-图像预训练（CLIP）^[27]的研究由于其出色的零样本学习能力，吸引了广泛关注，并在多个计算机视觉领域如物体分类、异常检测和语义分割等取得了显著进展^{[54][55][56]}。在行人重识别任务中，CLIP 通过分析图像与文本描述之间复杂的语义关系，增强了模型捕捉行人身份特征的能力，从而提升了识别的精度和鲁棒性。例如，Yan 等人^[57]提出了一个 CLIP 驱动的框架 CFine，旨在利用 CLIP 强大的多模态知识挖掘精细且具有区分性的细节，实现有效的全局对齐。此外，为了处理因遮挡导致的外观细节部分丢失，Cui 等人^[58]提出了一种基于提示引导的特征解耦方法（ProFD），通过文本提示激活并利用预训练模型中丰富的知识，生成稳健的局部特征。




图 4-1 图像-文本行人重识别的示例。

尽管 CLIP 模型在多模态学习中表现出色，但在直接应用于换衣场景的行人重识别任务时，仍面临一些不容忽视的挑战。本章采用 CLIP-ReID^[59]作为骨干网络，在换衣行人数据集 CelebReID^[36]上进行实验。实验的视觉结果如图 4-1 所示，尽管 CLIP 能够生成与行人衣物相关的文本提示，其跨模态能力加强了视觉内容与文本描述之间的联系。

然而，模型在处理因衣物变化而导致的身份信息干扰方面存在明显不足。这一局限性主要源于 CLIP 的预训练机制倾向于强调视觉元素的显著特征，如衣物，而忽略了与个人身份密切相关的更微妙的特征，如面部特征或身体姿势，这些对身份识别至关重要。

为了克服上述挑战，本方法提出了一种基于 CLIP 的多模态特征融合网络（CMFF），该方法结合了图像、文本和生物（如头部、姿势）信息，以增强模型的鲁棒性。首先，提出姿态感知身份特征增强模块（PIE），利用姿态估计模型 HRNet^[60]来捕捉行人的详细姿态信息。通过将姿态信息与从 CLIP 获得的全局视觉特征结合，增强了模型感知行人身份固有特征的能力。为了最大限度减少衣物变化对识别精度的影响，在该模块中使用排名损失函数对模型进行微调，从而有效地缩小姿势和外观特征之间的语义距离。此外，考虑到头部区域比其他身体部位包含更丰富的身份信息，提出了全局-局部协同注意力模块（GLHA）来促进全局特征与头部特征之间的交互，旨在从全局角度指导并增强对头部信息的关注，并且根据全局信息增强头部特征的上下文。最后，为了增强图像编码器各层特征之间的信息流动，设计了跨层级交互增强模块（CIEM），通过对多个层的特征进行精细分组和融合，从而优化整体特征的语义丰富度和可分辨性。

4.2 整体框架结构

多模态特征融合框架采用 CLIP-ReID 作为骨干网络，通过一组预训练的可学习文本标签增强缺失的文本信息。整个方法主要包含两个阶段，如图 4-2 所示。在初始训练阶段，本方法利用与每个身份相关的可学习文本标签，以处理模糊的文本描述并确保这些描述在身份级别上的唯一性。具体来说，文本描述 $T(\cdot)$ 格式为“ $[X]_1[X]_2\dots[X]_M$ 的照片”，其中每个 $[X]_m$ ($m \in \{1, 2, \dots, M\}$) 是一个可学习的文本标签， M 表示文本标签的总数。在此阶段，通过图像到文本对比损失 L_{i2t} 和文本到图像对比损失 L_{t2i} 来优化模型，旨在强化跨模态表示的一致性：

$$L_{i2t} = -\log\left(\frac{\exp(s(V_i, T_i))}{\sum_{a=1}^B \exp(s(V_i, T_a))}\right), \quad (4-1)$$

和

$$L_{t2i} = -\log\left(\frac{\exp(s(V_i, T_i))}{\sum_{a=1}^B \exp(s(V_a, T_i))}\right). \quad (4-2)$$

$s(\cdot, \cdot)$ 用于计算图像嵌入 V_i 和文本嵌入 T_i 在跨模态空间中的相似度。此外，它还用于比较 V_i 与同一批次中其他文本嵌入 T_q 的相似度。

第二阶段中，首先将姿态信息与从 CLIP 提取的全局视觉特征融合，从而增强模型对行人固有身份信息的感知能力接下来，提出了一种全局-局部协同注意力模块（GLHA），该模块能够利用全局信息突出头部区域特征，并在上下文语境中进一步强化对头部细节的表达。最后，本方法提出跨层级交互增强模块（CIEM），通过对图像编码器的多层特征进行精细化的分组与融合，以提升模型的上下文感知能力，并丰富特征表达的语义层次性。




图 4-2 基于 CLIP 的多模态特征融合网络

4.2.1 姿态感知身份特征增强模块

行人姿态在体现人体关键结构信息方面发挥着至关重要的作用，这些结构特征在衣物变化、光照条件及视角变化下仍能保持相对不变。通过将姿态信息与全局视觉特征融合，旨在减轻衣物变化对全局视觉表征造成的干扰，从而提高模型在行人外观发生显著变化时的稳定性和鲁棒性。具体来说，对于给定的行人图像 x_i ，本方法首先采用姿态估计模型 HRNet 来定位 K 个身体关键点的坐标，并根据这些坐标生成对应的关键点热图 $H_k (k = \{1, 2, \dots, K\})$ ：

$$H_k(x, y) = \exp\left(-\frac{(x - x_k)^2 + (y - y_k)^2}{2\sigma^2}\right), \quad (4-3)$$

其中， (x, y) 表示热图中某点的空间坐标， σ 表示高斯核的标准差，用来控制分布的扩展， (x_k, y_k) 为第 k 个关键点在图像中的位置。接下来，将所有 K 个单独的热图聚合成

一个组合姿态热图 H_m ：

$$H_m = \sum_{k=1}^K H_k. \quad (4-4)$$

在上述公式中， $H_m \in R^{W \times H}$ ， W 和 H 分别表示热图的宽度和高度。为了更有效的融合局部姿态信息与全局视觉特征融合，先将全局图像特征 f_g 扩展至与姿态热图 H_m 的空间相匹配的维度，然后通过逐元素相乘的方式，将扩展后的全局特征与姿态热图相融合，最终得到兼具姿态信息的增强特征表 f_p ：

$$f_p = H_m \odot \text{Expand}(f_g, W, H), \quad (4-5)$$

其中， $\odot$ 表示逐元素相乘， $\text{Expand}(\cdot, W, H)$ 用于将特征的维度重塑为 $W \times H$ 。

此外，受到^[61]中基于轮廓草图与 RGB 图像的对比损失启发，该模块引入了排名损失，旨在通过最小化外观特征与姿态特征之间的距离来减少外观特征对衣物信息的依赖。这种设计有效增强了模型对行人身份核心信息的关注能力，从而提高了跨服装行人重识别的准确性，具体计算过程如图 4-3 所示。




图 4-3 排名损失的可视化，其中相同颜色的边界代表同一 ID。

由于一个批次中包含了 N 张图像及其对应的 N 个姿态热图，同一身份的 RGB 特征与姿态特征（正样本对）之间的距离应当小于不同身份的 RGB 特征与姿态特征（负样本对）之间的距离。此外，为进一步强化模型对行人身份固有特征的关注，并减少外观变化的干扰，还需要增大不同身份之间姿态特征的距离。为此，本方法将排名损失

细化为类间排名损失 L_{cross} 和类内排名损失 L_{intra} ，以更精细地调控特征间和模态间的相似性约束：

$$L_{cross} = \frac{1}{N} \sum_{i=1}^N \max(0, \delta_1 + \|f_{g,i}^a - f_{p,j}^+\|_2 - \|f_{g,i}^a - f_{p,t}^-\|_2), \quad (4-6)$$

$$L_{intra} = \frac{1}{N} \sum_{i=1}^N \max(0, \delta_2 + \|f_{g,i}^a - f_{p,j}^+\|_2 - \|f_{g,i}^a - f_{p,t}^-\|_2). \quad (4-7)$$

其中， $\|\cdot\|_2$ 表示欧几里得距离， δ_1 和 δ_2 表示预设的间隔阈值，旨在确保正样本特征与锚点的距离显著小于负样本与锚点之间的距离。接下来，通过将上述的类间排名损失 L_{cross} 和类内排名损失 L_{intra} 集成到统一的排名损失函数中，并引入权重系数 λ_1 和 λ_2 来调整它们在总损失中的贡献比，从而优化模型性能。具体损失函数如下：

$$L_{rank} = \lambda_1 L_{cross} + \lambda_2 L_{intra}. \quad (4-8)$$

4.2.2 全局-局部协同注意力模块

由于头部区域通常包含比身体其他部位更为关键和丰富的身份识别信息，本方法提出了一种全局-局部协同注意力模块（GLHA），通过有效融合局部关键信息，更好的强化模型对局部关键特征的感知能力。体而言，对于给定的行人图像 x_i ，首先应用 HRNet 模型准确定位人头和肩部的关键点；随后，基于这些定位结果，采用 Mask R-CNN 图像分割算法从整个图像中精确提取头部和颈部区域。接下来，将完整的行人图像及其对应的头部图像分别输入到图像编码器中进行特征提取。考虑到全局图像与局部头部图像之间的维度差异，本方法分别对两者进行自适应池化操作，从而获得全局特征 f_g 和头部特征 f_h 。全局-局部协同注意力机制如图 4-4 所示：




图 4-4 全局-局部协同注意力机制

首先对 f_g 和 f_h 进行不同的线性变换，将它们分别映射为查询（ Q ）、键（ K ）和值（ V ）的形式。与传统的自注意力机制不同，本方法以全局特征的查询向量关注头部特征的键和值向量，反之也以头部特征的查询向量关注全局特征的键和值，从而实现全局与局部特征之间的双向交互：

$$A_{g-h} = \text{softmax}\left(\frac{Q_g K_h^T}{\sqrt{d}}\right) \odot V_h, \quad (4-9)$$

$$A_{h-g} = \text{softmax}\left(\frac{Q_h K_g^T}{\sqrt{d}}\right) \odot V_g. \quad (4-10)$$

接下来，通过特征拼接操作 $\text{concat}(\cdot, \cdot)$ 将上述两个交互加权特征组合在一起，形成最终的全局局部融合特征 F_{g-h} 。详细表达式如下：

$$F_{g-h} = \text{concat}(A_{g-h} f_g, A_{h-g} f_h). \quad (4-11)$$

通过这种方式，本方法可以有效地捕捉头部特征与整体图像之间的上下文交互关系，进一步提高模型对行人身份特征表达的稳定性。

4.2.3 跨层级交互增强模块

考虑到基于 Vision Transformer 的图像编码器仅利用高层信息作为图像特征来识别行人，忽略了低层特征中的语义信息，本章提出了跨层级交互增强模块（CIEM），通过对图像编码器的多层特征实施分组与整合策略，旨在提升模型在多尺度特征上的上下文感知能力，详细架构如图 4-5 所示。




图 4-5 跨层级交互增强模块的框架图

具体而言，本方法首先从图像编码器的每一层中提取相应的输出特征，并将 $X^{(l)} \in R^{N \times D}$ 表示为第 l 层的输出特征，其中 $l \in \{1, 2, \dots, 12\}$ ， N 和 D 分别表示序列长度和特征维度。在将这些特征输入到注意力模块之前，本方法对每一层的输出特征进行层归一化操作：

$$\hat{X}^{(l)} = \frac{X^{(l)} - \mu^{(l)}}{\varphi + \sigma^{(l)}}, \quad (4-12)$$

在这个公式中， φ 为防止分母为零的平滑常数， $\mu^{(l)}$ 和 $\sigma^{(l)}$ 分别表示 $X^{(l)}$ 的均值和标准差，计算方式如下：

$$\mu^{(l)} = \frac{1}{D} \sum_{d=1}^D X_{:,d}^{(l)}, \quad (4-13)$$

$$\sigma^{(l)} = \sqrt{\frac{1}{D} \sum_{d=1}^D (X_{:,d}^{(l)} - \mu^{(l)})^2}. \quad (4-14)$$

随后，将经过归一化处理的特征分别映射到对应节点，并根据 Transformer 的层次将节点分为三组 ($t=3$)。接着，基于节点特征结构建立节点之间的关系。边权 e_t^{ij} 由节点之间的相似度决定，反映了第 t 组中节点 i 与节点 j 之间的相对重要性， e_t^{ij} 的计算公式如下：

$$e_t^{ij} = \frac{\exp(\text{sim}(\hat{X}_t^{(i)}, \hat{X}_t^{(j)}))}{\sum_{k \in N_i} \exp(\text{sim}(\hat{X}_t^{(i)}, \hat{X}_t^{(q)}))}, \quad (4-15)$$

其中， $\text{sim}(\cdot, \cdot)$ 表示节点之间的余弦相似度， N_i 表示节点 i 的邻居集合。为了进一步量化节点间特征的影响关系，本方法定义了节点间的注意力系数 α_t^{ij} ，用于在节点特征更新过程中衡量相邻节点 $\hat{X}_t^{(i)}$ 对 $\hat{X}_t^{(j)}$ 的影响：

$$\alpha_t^{ij} = \frac{e_t^{ij} \exp(\text{ReLU}(a^T [W_t^i \parallel W_t^j]))}{\sum_{q \in N_i} e_t^{iq} \exp(\text{ReLU}(a^T [W_t^i \parallel W_t^q]))}. \quad (4-16)$$

上式中， W 是可学习的线性变换矩阵， a 是用于计算注意力的可学习向量，符号 $\parallel$ 表示向量的连拼接操作， $\text{ReLU}(\cdot)$ 为非线性激活函数。基于上述计算后的注意力系数，节点特征更新如下：

$$h_t^i = \text{ReLU}(\sum_{q \in N_i} \alpha_t^{iq} \hat{X}_t^{(i)}). \quad (4-17)$$

随后，对每个分组的节点特征进行最大池化操作并将它们聚合，得到各组最终的特征表示 h_t ：

$$h_t = \text{maxpooling}(h_t^1, h_t^2, h_t^3, h_t^4), t \in \{1, 2, 3\}. \quad (4-18)$$

最后，本方法将每组的特征进行拼接，形成跨层级交互增强模块的整体特征表示 F_{graph} 。

基于上述的设计，该模块旨在充分利用图像编码器不同层次的语义信息，在复杂场景中提高模型的鲁棒性。

4.2.4 损失函数优化

自适应特征融合：为了最大化不同分支的信息利用并优化最终特征表示，本方法对三支的输出特征进行自适应融合操作，通过全连接层初始化每个分支的权重，并使用 softmax 函数对其进行归一化。根据这些生成的权重，对三个特征向量进行加权聚合，并在反向传播过程中自适应调整权重：

$$F_{\text{fused}} = w_{\text{pose}} f_p + w_{g-h} F_{g-h} + w_{\text{graph}} F_{\text{graph}}. \quad (4-19)$$

模型优化：在第一阶段，使用图像到文本对比损失 L_{i2t} 和文本到图像对比损失 L_{t2i} 来减少图像和文本描述之间的跨模态差异。总损失函数表达式如下：

$$L_{\text{stage1}} = L_{i2t} + L_{t2i}. \quad (4-20)$$

在第二阶段，首先在姿态感知身份特征增强模块中应用排名损失 L_{rank} ，最小化外观特征与姿态特征之间的差异。此外，本方法采用身份损失 L_{ID} 和三元组损失 L_{tri} ，进一步优化模型：

$$L_{\text{ID}} = -\sum_{i=1}^C y_i \log(p_i), \quad (4-21)$$

$$L_{\text{tri}} = \frac{1}{N} \sum_{i=1}^N \max(0, m + d_{\text{ap}} - d_{\text{an}}). \quad (4-22)$$

其中， C 表示类别数， y_i 是实际标签的独热编码， p_i 是对应类别的预测概率。 N 表示同一批次中的样本数， d_{ap} 表示锚点样本与正样本之间的距离， d_{an} 表示锚点样本与负

样本之间的距离。

为了充分发挥 CLIP 预训练大模型的潜力，本方法用到了图像到文本的交叉熵损失，确保图像特征与对应的文本描述密切对应，同时与其他不相关身份的文本特征保持距离：

$$L_{i2tce(i)} = - \sum_{k=1}^N \log \left(\frac{e^{s(V_i, T_{y_k})}}{\sum_{y_a=1}^N e^{s(V_i, T_{y_a})}} \right). \quad (4-23)$$

其中， V 表示在第二阶段融合后的整体视觉特征， $s(\cdot, \cdot)$ 用于计算相似度分数。因此，第二阶段的整体损失函数表示为：

$$L_{stage2} = L_{rank} + L_{ID} + L_{tri} + L_{i2tce}. \quad (4-24)$$

4.3 实验结果与分析

数据集：为了评估本章提出的 CMFF 方法的有效性，在 VC-Clothes^[35]、CelebreID^[36]、Celeb-reID-light^[37] 和 NKUP^[38] 四个公开可用的换衣行人数据集上进行了实验。

实验细节：本方法采用 CLIP ReID 框架中的 ViT-B-16 处理输入图像，首先将输入图像大小调整为 256×128 以适应网络输入要求。为了提升模型的泛化能力，采用了一系列数据增强技术，包括随机水平翻转、随机擦除、边缘填充等。数据加载时采用结合 softmax 与三元组损失的混合采样器，每个批次处理 4 个实例，使用 8 个工作线程并行处理数据。本研究的训练过程分两个阶段进行优化，第一阶段采用 Adam 优化器，批量大小为 128，基础学习率为 3.5×10^{-4} ，训练周期设为 60。第二阶段将训练周期延长至 120，批量大小保持不变。基础学习率降低为 0.5×10^{-5} ，迭代次数设置为 10，权重衰减和偏置权重衰减均配置为 0.1×10^{-3} 。

4.3.1 与先进方法的比较

在 VC-Clothes 上的实验结果：本方法在 VC-Clothes 数据集上的对比实验采用以下两种设置：1) General：图库集既包含服装变化的样本，也包含服装相同的样本；2) Cloth-changing：图库集仅包含服装变化的样本。

如表 4-1 所示，本方法在两种设置中均取得了最高的性能。与排名第二的方法 DSIFLF^[62] 相比，本方法在衣服变化场景中将 Rank-1 (R-1) 和 mAP 提高了 0.5% 和

0.2%，在一般场景中将 mAP 提高了 1.3%。在对比方法中，GLH^[63]利用多分支架构来捕获全局和局部身份信息，并通过对生成的伪标签进行聚类以进行跨图像比较来训练局部身体部位。然而，这种依赖于自动生成的伪标签的策略可能会因标签质量不一致而引入错误，从而影响模型的准确性和鲁棒性。FSAM^[18]通过在两个流分支之间迁移细粒度的体形知识来增强与服装无关的特征。DSIFLF 使用人体解析模型擦除服装部分，抑制服装纹理在身份特征空间中引起的波动，并通过生成对抗性干扰因素解耦网络来减少判别学习过程中对干扰因素的依赖。GI-ReID^[20]将步态识别作为辅助任务，利用独特的步态信息引导模型学习与服装无关的特征。虽然这些方法通过单一的生物模态信息提高了特征提取的准确性，但它们也显著依赖于数据的质量和一致性，这限制了它们在新环境或变化条件下的泛化能力。相比之下，本方法结合了姿态估计和全局特征，充分利用了头部的身份识别信息，大大增强了模型捕捉固有身份信息的能力。

表 4-1 本方法和目前先进方法在 VC-Clothes 数据集上的性能比较。

方法名/出版处	辅助信息	General		Cloth-changing	
		R-1	mAP	R-1	mAP
基于短期场景的方法					
PCB(ECCV18) ^[11]	-	87.7	74.6	62.0	62.2
DG-Net(CVPR19) ^[24]	-	-	-	76.8	68.4
ISP(ECCV20) ^[44]	语义解析	-	-	72.0	72.1
基于换衣场景的方法					
FSAM(CVPR21) ^[19]	语义解析+姿态	94.7	94.8	78.6	78.9
CAL(CVPR22) ^[45]	服装 ID	92.9	87.2	81.4	81.7
GI-ReID(CVPR22) ^[20]	语义解析+步态	-	-	<u>64.5</u>	58.7
ACID(TIP23) ^[41]	-	95.1	94.7	<u>84.3</u>	74.2
IMS-GEP(TMM23) ^[46]	-	-	-	81.8	81.7
MSD-Net(ICMR24) ^[64]	语义解析	94.1	93.9	84.1	83.4
GLH(Neurcom.24) ^[63]	-	94.2	90.2	86.4	86.1
A ³ PFN	-	92.8	92.3	89.3	83.1
DSIFLF(ACMMM24) ^[62]	语义解析	96.8	<u>93.6</u>	94.3	<u>90.2</u>
baseline	文本描述	95.7	93.4	92.3	88.5
本方法	文本描述+姿态	<u>96.3</u>	94.5	94.8	90.4

Celeb-reID 和 Celeb-reID-light 上的实验结果：本方法在 Celeb-reID 和 Celeb-reID-light 数据集上与最先进的方法进行了对比实验，详细结果见表 4-2。

可以看到，本方法在这两个数据集上都超越了所有的对比方法。MADE^[68]通过属性检测模型提取个人属性描述，并掩盖了服装和颜色信息。但当服装属性与其他身体特征紧密结合时，仅掩盖服装属性不足以完全消除所有与服装相关的信息。AFD-Net^[48]和 SAFR^[49]使用生成对抗网络来分离与身份相关和不相关的特征。其中，AFD-Net 的解耦和重构依赖于复杂的自监督，增加了训练难度，效率较低。虽然 SAFR 从随机样本中学习到了解耦的特征，但是输入样本的质量和多样性限制了其泛化能力。3DInvarReID^[67]创新性地利用 3D 身体模型来分离身份和非身份特征，但极端的姿势变化和服装多样性可能会降低其分离的准确性和效率。相比之下，本方法采用多分支架构从头部和姿势中提取关键身份线索，同时利用图注意机制来聚合多尺度特征，从而显著提高模型在复杂场景下的性能。

表 4-2 本方法与目前先进方法在 Celeb-reID 和 Celeb-reID-light 数据集上的性能比较。

方法名/出版处	辅助信息	Celeb-reID		Celeb-reID-light	
		R-1	mAP	R-1	mAP
基于短期场景的方法					
MGN(ACMMM18) ^[12]	-	49.0	10.0	13.9	21.5
DG-Net(CVPR19) ^[24]	-	50.1	10.6	23.5	12.6
基于换衣场景的方法					
AFD-Net(IJCAI21) ^[48]	-	52.1	10.6	22.2	11.3
MBUNet(TIP22) ^[19]	姿态	55.3	12.1	33.9	21.3
MCSC(TIP24) ^[65]	-	57.8	13.0	29.2	16.2
SAFR(TIP22) ^[49]	-	56.0	14.2	29.5	16.7
FIRe2(TIP24) ^[66]	-	64.0	18.2	-	-
SAVS(TNNLS23) ^[22]	语义解析	65.9	21.3	-	-
A ³ PFN	-	61.4	16.9	40.6	24.2
3DInvarReID(ICCV23) ^[67]	3D 身体模型	65.5	18.4	42.2	25.7
GLH(Neurcom.24) ^[63]	-	<u>69.0</u>	23.6	-	-
MADE(arxiv24) ^[68]	文本描述	-	-	<u>69.6</u>	<u>52.1</u>
baseline	文本描述	67.8	<u>28.1</u>	67.4	46.9
本方法	文本描述+姿态	69.7	30.2	71.3	52.3

NKUP 数据集上的实验结果：本章在 NKUP 数据集上与现有方法进行了对比实验，结果如表 4-3 所示。在该实验中，本方法获得了第二高的性能，rank-1 和 mAP 分别比 IGCL^[69]低 0.9%和 8.5%。主要原因是 NKUP 数据集的图像是在黑暗环境下采集的，图像清晰度较低。IGCL 引入服装注意激活图来掩盖与衣服外观相关的线索，并通过图像拼接技术丰富同一身份下不同姿势的表达，可以有效提取独立于背景的人体语义信息，并适应行人的姿势变化。这些策略使 IGCL 在处理低清晰度图像方面显示出强大的优势。

表 4-3 本方法和目前先进方法在 NKUP 数据集上的性能比较。

方法名/出版处	辅助信息	R-1	mAP
基于短期场景的方法			
PCB(ECCV18) ^[11]	-	18.7	14.1
MGN(ACMMM18) ^[12]	-	20.6	16.1
基于换衣场景的方法			
MVSE(ACMMM21) ^[50]	语义解析	23.8	17.9
SAVS(TNNLS23) ^[22]	语义解析	25.3	18.6
UCAD(IJCAI22) ^[51]	-	25.0	16.9
A ³ PFN	-	25.7	19.1
IGCL(TPAMI23) ^[69]	语义解析	28.8	28.0
Baseline	文本描述	25.3	18.6
本方法	文本描述+姿态	<u>27.9</u>	<u>19.5</u>

4.3.2 消融实验

图结构分组的有效性：为了分析跨层级交互增强模块中特征分组数量对模型性能的影响，本章对此进行了消融实验，并设置不同的分组数 $n = \{1, 2, 3, 4, 6\}$ 。




图 4-6 四个换衣行人数据集上不同组数的实验结果。




图 4-7 换衣行人数据集上关于模块有效性的折线图

如图 4-6 显示，随着组数的变化，模型的性能波动明显。特别当 $n=1$ 时，无论数据集的性质如何，模型的 mAP 始终是最底的；而当 $n=3$ 时，它在所有数据集上的表现都是最优的。另外，组数过低或过高都会导致性能下降。主要原因是当特征只分成一组时，依赖于单一融合输出的模型可能会过度压缩信息，导致边缘和纹理等关键的细粒度特征的丢失，而这些特征对于识别复杂场景中的微小差异至关重要。显然，适度增加组数（例如 $n=3$ ）可以有效保留和利用不同尺度的特征，通过各组内特征的互补性来平衡信息的多样性和完整性，从而优化模型性能。但是过多的组数（例如 $n=4$ 或 6 ）会导致特征过于分散，导致每组信息量不足，不利于有效的学习和识别，从而降低整体性能。因此，选择合适的组数对提高模型精度和适应性极其关键。

表 4-4 各模块的消融实验，“CC”表示换衣设定。

变量	VC-Clothes (CC)		NKUP		Celeb-reID	
	R-1	mAP	R-1	mAP	R-1	mAP
baseline	92.3	88.5	25.3	18.6	67.8	28.1
+PIE	92.5	88.9	25.7	19.1	67.5	28.7
+GLHA	92.8	89.3	26.4	19.2	68.1	29.2
+CIEM	93.1	<u>89.9</u>	26.1	18.9	68.3	29.5
+PIE+GLHA	<u>93.5</u>	89.6	<u>27.3</u>	<u>19.2</u>	<u>69.5</u>	<u>29.7</u>
+PIE+GLHA+CIEM	94.5	90.4	27.9	19.5	69.7	30.2

每个模块的有效性：通过在 VC-Clothes，NKUP 和 Celeb-reID 三个换衣数据集上的实验来评估 CMFF 框架中各个分支的贡献。本方法将以 Vision Transformer 作为骨干网络的 CLIP ReID 设定为 baseline，并在此 baseline 上融合姿态感知身份特征增强模块（PIE）、全局局部混合注意模块（GLHA）和跨层级交互增强模块（CIEM），以及这些模块的不同组合，探究它们对性能的具体影响。表 4-4 列出了全部结果，其累积匹配

特征（CMC）曲线如图 4-7 所示。

首先可以发现，单个模块的引入在三个数据集上都实现了相对于基线模型准确率的提升，具体而言，PIE 模块对 mAP 的提升分别为 0.4%、0.5%和 0.2%；GLHA 模块的提升分别为 0.8%、0.6%和 0.5%；CIEM 模块的提升分别为 1.4%、0.3%和 1.4%。其次，PIE 和 GLHA 作为生物特征学习分支，分别侧重于提取行人姿态和头部信息，二者组合在三个数据集上分别较 baseline 模型实现了 1.3%、2.0%和 2.7%的 Rank1 提升，证明了两个模块的互补性以及提取判别性特征的有效性。在此基础上引入 CIEM 模块，Rank-1 准确率进一步提升 1.3%、0.6%和 1.4%，验证了增强多尺度上下文感知的效果。

本章还在 Celeb-reID 数据集上对各个分支及组合进行了可视化，如图 4-9 所示。可以看出，PIE、GLHA 和 CIEM 模块单独表现均优于 baseline 模型，其中 PIE 与 GLHA 组合显著提升了 Ranks 1-10 的匹配率。特别是在引入 CIEM 模块之后，模型精度进一步提高，这与消融实验的结果是一致的。




图 4-8 Celeb-reid 数据集上的检索结果可视化

4.4 本章小结

本章提出了一种多模态特征融合方法（CMFF）来应对换衣行人重识别的挑战。首先，设计了姿势感知身份增强模块（PIE），将姿势估计与全局特征分析相结合，以增强模型对基本身份特征的辨别能力，并通过排名损失缩小外观和姿势驱动特征之间的差距。接下来，引入了一个全局-局部协同注意力模块（GLHA），通过头部分支融合和交叉注意在全局范围内突出关键头部信息。最后，采用跨层级交互增强模块（CIEM）来更新和集成图像编码器的多层特征，以增强多尺度特征的上下文感知能力。在几个主流的换衣行人数据集上进行的大量实验证明了本章提出的 CMFF 的卓越性能。考虑到在弱光条件下拍摄的行人的 RGB 图像通常质量较差，考虑在未来结合红外模态来解决换衣场景中的行人识别问题，并提高模型在弱光条件下的性能和准确性。

第五章 总结与展望

5.1 总结

在智能监控技术快速发展的背景下，公共安全场景对行人身份精准感知的需求日益迫切。作为智能安防体系的核心技术之一，行人重识别通过跨摄像头目标关联能力，在案件侦查、走失人员追踪等场景中发挥着不可替代的作用。然而，换衣场景下行人服饰的动态变化导致身份关联特征模糊化，传统方法难以有效应对复杂环境下的特征漂移问题，这一技术瓶颈严重制约了智能监控系统在真实场景中的应用效能。

在第一章中，本文阐述了换衣行人重识别的研究背景及其在智能安防、智慧城市等领域的重要意义，系统梳理了国内外研究现状以及现有方法的局限性。第二章重点介绍了深度学习基础理论如 Transformer 架构和对比语言图像预训练模型，并归纳了主流换衣行人重识别数据集与评价指标。第三章针对换衣场景下身份特征易受服装干扰的问题，提出基于 Transformer 的自适应感知注意与金字塔聚合网络，通过多尺度特征整合提升复杂场景的识别鲁棒性。第四章针对 CLIP 模型在换衣场景中的特征适应性问题，构建了多模态特征融合框架，以增强模型对非服装特征的感知能力。

本文工作的创新之处归纳如下：

(1) 针对换衣场景下身份特征易受服装干扰的问题，提出了一种基于 Transformer 的自适应感知注意力与金字塔聚合网络。首先，设计了多层动态集中模块，通过实时评估多层特征的重要性动态调整各层特征的权重，有效降低冗余计算并提升信息利用效率。其次，构建局部金字塔聚合模块，将快速傅立叶变换与自注意机制相结合，在频域中实现多尺度特征建模，从而降低计算复杂度。此外，创新性地构建了模拟不同天气条件的换衣行人数据集，通过引入风雨等环境变量增强数据的多样性，为模型训练与评估提供了更贴近真实场景的基准。

(2) 针对 CLIP 模型的文本编码器对服装特征过度敏感的问题，提出了一种多模态特征融合框架。首先，设计姿态感知身份增强模块，通过排名损失函数约束外观与姿势特征的差异度，强化模型对身份固有特征的表征能力。其次，设计了全局-局部协同注意力模块，通过交叉注意力机制建立头部关键区域与全局语义的映射关系，提升跨尺度特征的语义一致性。此外，提出多层级交互增强模块，通过构建跨层级特征交互机制实现视觉特征的分组聚合，有效增强了图像编码器对特征的上下文感知能力。

该方法突破了传统 CLIP 模型对服装特征的过度依赖，显著提升了动态服装变化的适应性。

5.2 研究展望

尽管本文研究的基于多尺度特征融合的换衣行人重识别方法取得了不错的性能，但换衣场景中仍有急需解决的关键问题。面对最近提出的视觉大模型以及相关领域的发展趋势，我们需要考虑与这些大模型之间的问题，并将其纳入今后的工作展望中。具体而言，今后工作的研究方向主要包括以下两个方面：

（1）换衣行人重识别在动态开放环境下的泛化能力仍是有待突破的技术瓶颈。尽管当前方法在静态场景数据集上表现优异，但真实环境中的复杂变量（如突变光照、极端天气、随机遮挡）会严重干扰模型对身份本质特征的提取能力。这一问题的核心在于，现有模型难以区分环境噪声与身份标识特征之间的耦合关系。例如，同一行人换装后在强逆光与夜间红外成像下的轮廓差异可能因环境噪声放大，导致模型误判为不同个体。为突破这一局限，未来研究需构建环境自适应的动态学习框架：首先，基于元学习范式设计跨模态特征映射网络，融合可见光、红外、雷达等多源数据，通过时序环境状态感知实现特征空间的动态校准；其次，设计环境因子解耦策略，将光照强度、气象条件等干扰项建模为可分离隐变量，利用对比学习策略在特征空间实现身份表征的纯化；同时，在训练阶段嵌入对抗扰动生成器，模拟暴雨折射、雾霾散射等极端环境噪声，迫使模型学习更具判别力的鲁棒特征。

（2）现有方法对行人重识别的特征挖掘仍停留在外观与步态等显性层面，而人体隐含生物特征（如骨骼关节运动模式、微表情习惯、肢体比例拓扑关系）的深度利用尚未突破。这类特征虽具有服饰不可变性的天然优势，却因两大核心矛盾难以直接建模：1）精细标注骨骼运动轨迹需耗费极高成本；2）生物特征数据涉及隐私保护红线。为此，可以考虑构建“自监督对比学习+因果推理”的双驱框架：首先，基于无标注视频流设计时空对比学习任务，通过跨帧运动模式匹配自动捕捉隐式生物标识，利用时序连贯性约束减少标注依赖；其次，构建时序因果图模型，分析关节角度变化与步态特征间的关联性，提取个体特有的运动模式特征，并建立多任务学习框架，使动作序列预测与身份特征形成互补约束，从而在保护隐私的前提下实现隐含生物特征的有效建模。进一步，可整合图神经网络与三维重建技术，从多视角视频中提取行人生物力学特征，分析骨骼运动模式与身体结构的独特性。这种方法能够捕捉到传统方法难以获

取的细粒度生物特征，如关节协同运动模式、身体各部位的运动相关性等。在此基础上，构建“服饰-姿态-身份”关系模型，通过因果分析识别并减弱服饰变化对身份识别的干扰，同时强化稳定生物特征在识别过程中的权重，从而在跨场景、跨时间、跨服饰等复杂条件下提高行人重识别的稳健性与准确率。

参考文献

- [1] 汪琦,雪心远,闵卫东.跨域联合学习与共享子空间度量的车辆重识别[J].中国图象图形学报, 2024, 29(05):1364-1380.
- [2] 姜定, 叶茫. 面向跨模态文本到图像行人重识别的 Transformer 网络[J]. 中国图象图形学报, 2023, 28(5): 1384-1395.
- [3] Wang G, Wang G, Zhang X, et al. Weakly Supervised Person Re-ID: Differentiable Graphical Learning and A New Benchmark[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(5): 2142-2156.
- [4] Zheng L, Shen L, Tian L, et al. Scalable Person Re-Identification: A benchmark[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 1116-1124.
- [5] Zaidel W, Zivkovic Z, Krose B J. Keeping Track of Humans: Have I Seen This Person Before?[C]//Proceedings of the IEEE International Conference on Robotics and Automation, 2005: 2081-2086.
- [6] Gheissari N, Sebastian T B, Hartley R, et al. Person Reidentification Using Spatiotemporal Appearance[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2006, 2: 1528-1535.
- [7] Bazzani L, Cristani M, Perina A, et al. Multiple-shot Person Re-identification by Hpe Signature[C]//Proceedings of the IEEE International Conference on Pattern Recognition, 2010: 1413-1416.
- [8] Zhang Y, Li S. Gabor-LBP Based Region Covariance Descriptor for Person Re-identification[C]//Proceedings of the IEEE International Conference on Image and Graphics, 2011: 368-371.
- [9] Li W, Zhao R, Xiao T, et al. Deepreid: Deep Filter Pairing Neural Network for Person Re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 152-159.
- [10] Hermans A, Beyer L, Leibe B. In Defense of the Triplet Loss for Person Re-identification[J]. ArXiv preprint arXiv:1703.07737, 2017.
- [11] Sun Y, Zheng L, Yang Y, et al. Beyond Part Models: Person Retrieval with Refined Part Pooling (and a Strong Convolutional Baseline)[C]//Proceedings of the European Conference on Computer Vision, 2018: 480-496.

- [12] Wang G, Yuan Y, Chen X, et al. Learning Discriminative Features with Multiple Granularities for Person Re-identification[C]//Proceedings of the 26th ACM International Conference on Multimedia. 2018: 274-282.
- [13] Chen T, Ding S, Xie J, et al. Abd-net: Attentive but Diverse Person Re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 8351-8361.
- [14] He S, Luo H, Wang P, et al. Transreid: Transformer-based Object Re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. 2021: 15013-15022.
- [15] Dai Y, Liu J, Sun Y, et al. Idm: An Intermediate Domain Module for Domain Adaptive Person Re-id[C]//Proceedings of the IEEE International Conference on Computer Vision. 2021: 11864-11874.
- [16] Sun Y, Cheng C, Zhang Y, et al. Circle loss: A unified Perspective of Pair Similarity Optimization[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 6398-6407.
- [17] Zhang X, Luo H, Fan X, et al. Alignedreid: Surpassing Human-level Performance in Person Re-identification[J]. ArXiv preprint arXiv:1711.08184, 2017.
- [18] Hong P, Wu T, Wu A, et al. Fine-grained Shape-appearance Mutual Learning for Cloth-changing Person Re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 10513-10522.
- [19] Zhang G, Liu J, Chen Y, et al. Multi-biometric Unified Network for Cloth-changing Person Re-identification[J]. IEEE Transactions on Image Processing, 2023, 32: 4555-4566.
- [20] Jin X, He T, Zheng K, et al. Cloth-changing Person Re-identification from a Single Image with Gait Prediction and Regularization[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2022: 14278-14287.
- [21] Wang Y, Yu H, Yan Y, et al. Exploring Shape Embedding for Cloth-changing Person Re-identification via 2d-3d correspondences[C]//Proceedings of the 31st ACM International Conference on Multimedia, 2023: 7121-7130.
- [22] Gao Z, Wei H, Guan W, et al. A Semantic-aware Attention and Visual Shielding Network for Cloth-changing Person Re-identification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023.
- [23] Shu X, Li G, Wang X, et al. Semantic-guided Pixel Sampling for Cloth-changing Person Re-identification[J]. IEEE Signal Processing Letters, 2021, 28: 1365-1369.

- [24] Zheng Z, Yang X, Yu Z, et al. Joint Discriminative and Generative Learning for Person Re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 2138-2147.
- [25] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [26] Dosovitskiy A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. ArXiv preprint arXiv: 2010.11929, 2020.
- [27] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the International Conference on Machine Learning, 2021: 8748-8763.
- [28] Jiang X, Tang H, Gao J, et al. Delving into Multimodal Prompting for Fine-grained Visual Classification[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(3): 2570-2578.
- [29] Zuo Z, Dong J, Wu Y, et al. CLIP3D-AD: Extending CLIP for 3D Few-Shot Anomaly Detection with Multi-View Images Generation[J]. ArXiv preprint arXiv: 2406.18941, 2024.
- [30] Chen J, Zhu D, Qian G, et al. Exploring Open-vocabulary Semantic Segmentation from Clip Vision Encoder Distillation Only[C]//Proceedings of the IEEE International Conference on Computer Vision, 2023: 699-710.
- [31] Yu X, Dong N, Zhu L, et al. Clip-driven Semantic Discovery Network for Visible-infrared Person Re-identification[J]. IEEE Transactions on Multimedia, 2025.
- [32] He S, Chen W, Wang K, et al. Region Generation and Assessment Network for Occluded Person Re-identification[J]. IEEE Transactions on Information Forensics and Security, 2023, 19: 120-132.
- [33] Yang Q, Wu A, Zheng W S. Person Re-identification by Contour Sketch under Moderate Clothing change[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 43(6): 2029-2046.
- [34] Qian X, Wang W, Zhang L, et al. Long-term Cloth-changing Person Re-identification[C]//Proceedings of the Asian Conference on Computer Vision, 2020.
- [35] Wan F, Wu Y, Qian X, et al. When Person Re-identification Meets Changing Clothes[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2020: 830-831.
- [36] Huang Y, Xu J, Wu Q, et al. Beyond Scalar Neuron: Adopting Vector-neuron Capsules for Long-term Person Re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(10): 3459-3471.

- [37] Huang Y, Wu Q, Xu J, et al. Celebrities-reid: A Benchmark for Clothes Variation in Long-term Person Re-identification[C]// Proceedings of the IEEE International Joint Conference on Neural Networks, 2019: 1-8.
- [38] Wang K, Ma Z, Chen S, et al. A Benchmark for Clothes Variation in Person Re-identification[J]. International Journal of Intelligent Systems, 2020, 35(12): 1881-1898.
- [39] Brigham E O, Morrow R. The fast Fourier transform[J]. IEEE Spectrum, 1967, 4(12): 63-70.
- [40] Bruneton E, Neyret F. Precomputed atmospheric scattering[C]//Proceedings of the Computer Graphics Forum, 2008, 27(4): 1079-1086.
- [41] Yang Z, Zhong X, Zhong Z, et al. Win-win by Competition: Auxiliary-free Cloth-changing Person Re-identification[J]. IEEE Transactions on Image Processing, 2023, 32: 2985-2999.
- [42] Cui Z, Zhou J, Peng Y, et al. Dcr-reid: Deep Component Reconstruction for Cloth-changing Person Re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(8): 4415-4428.
- [43] Liu Y, Ge H, Wang Z, et al. Clothes-changing Person Re-identification via Universal Framework with Association and Forgetting Learning[J]. IEEE Transactions on Multimedia, 2023, 26: 4294-4307.
- [44] Zhu K, Guo H, Liu Z, et al. Identity-guided Human Semantic Parsing for Person Re-identification[C]//Proceedings of the European Conference on Computer Vision, 2020: 346-363.
- [45] Gu X, Chang H, Ma B, et al. Clothes-changing Person Re-identification with Rgb Modality Only[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2022: 1060-1069.
- [46] Zhao Z, Liu B, Lu Y, et al. Joint Identity-aware Mixstyle and Graph-enhanced Prototype for Clothes-changing Person Re-identification[J]. IEEE Transactions on Multimedia, 2023, 26: 3457-3468.
- [47] Huang Y, Wu Q, Xu J S, et al. Clothing Status Awareness for Long-term Person Re-identification[C]// Proceedings of the IEEE International Conference on Computer Vision, 2021: 11895-11904.
- [48] Xu W, Liu H, Shi W, et al. Adversarial Feature Disentanglement for Long-Term Person Re-identification[C]//Proceedings of the International Joint Conference on Artificial Intelligence, 2021: 1201-1207.
- [49] Yang S, Kang B, Lee Y. Sampling Agnostic Feature Representation for Long-term Person Re-identification[J]. IEEE Transactions on Image Processing, 2022, 31: 6412-6423.
- [50] Gao Z, Wei H, Guan W, et al. Multigranular Visual-semantic Embedding for Cloth-changing Person Re-

- identification[C]//Proceedings of the 30th ACM International Conference on Multimedia, 2022: 3703-3711.
- [51] Yan Y, Yu H, Li S, et al. Weakening the Influence of Clothing: Universal Clothing Attribute Disentanglement for Person Re-Identification[C]//Proceedings of the International Joint Conference on Artificial Intelligence, 2022: 1523-1529.
- [52] Yang Z, Lin M, Zhong X, et al. Good is bad: Causality Inspired Cloth-debiasing for Cloth-changing Person Re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2023: 1472-1481.
- [53] Buja A, Swayne D F, Littman M L, et al. Data Visualization with Multidimensional Scaling[J]. Journal of computational and graphical statistics, 2008, 17(2): 444-472.
- [54] Jiang X, Tang H, Gao J, et al. Delving into Multimodal Prompting for Fine-grained Visual Classification[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(3): 2570-2578.
- [55] Zuo Z, Dong J, Wu Y, et al. CLIP3D-AD: Extending CLIP for 3D Few-Shot Anomaly Detection with Multi-View Images Generation[J]. ArXiv preprint arXiv:2406.18941, 2024.
- [56] Chen J, Zhu D, Qian G, et al. Exploring Open-vocabulary Semantic Segmentation from Clip Vision Encoder Distillation Only[C]//Proceedings of the IEEE International Conference on Computer Vision, 2023: 699-710.
- [57] Yan S, Dong N, Zhang L, et al. Clip-driven Fine-grained Text-image Person Re-identification[J]. IEEE Transactions on Image Processing, 2023, 32: 6032-6046.
- [58] Cui C, Huang S, Song W, et al. ProFD: Prompt-Guided Feature Disentangling for Occluded Person Re-Identification[C]//Proceedings of the 32nd ACM International Conference on Multimedia, 2024: 1583-1592.
- [59] Li S, Sun L, Li Q. Clip-reid: Exploiting Vision-language Model for Image Re-identification without Concrete Text Labels[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(1): 1405-1413.
- [60] Sun K, Xiao B, Liu D, et al. Deep High-resolution Representation Learning for Human Pose Estimation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 5693-5703.
- [61] Zheng J, Hu X, Xiang T, et al. Dual-path Model for Person Re-identification under Cloth Changing[C]//

- Proceedings of the IEEE International Conference on Machine Learning and Cybernetics, 2020: 291-297.
- [62] Li Y, Cheng D, Fang C, et al. Disentangling Identity Features from Interference Factors for Cloth-Changing Person Re-identification[C]//Proceedings of the 32nd ACM International Conference on Multimedia, 2024: 2252-2261.
- [63] Thanh D T, Lee Y, Kang B. Enhancing Long-term Person Re-identification using Global, Local Body Part, and Head Streams[J]. Neurocomputing, 2024, 580: 127480.
- [64] Ding Y, Wang A, Zhang L. Multidimensional Semantic Disentanglement network for clothes-changing person re-identification[C]//Proceedings of the International Conference on Multimedia Retrieval, 2024: 1025-1033.
- [65] Huang Y, Wu Q, Zhang Z, et al. Meta Clothing Status Calibration for Long-term Person Re-identification[J]. IEEE Transactions on Image Processing, 2024.
- [66] Wang Q, Qian X, Li B, et al. Exploring Fine-grained Representation and Recomposition for Cloth-changing Person Re-identification[J]. IEEE Transactions on Information Forensics and Security, 2024.
- [67] Liu F, Kim M, Gu Z A, et al. Learning Clothing and Pose Invariant 3d Shape Representation for Long-term Person Re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2023: 19617-19626.
- [68] Peng C, Wang B, Liu D, et al. Masked Attribute Description Embedding for Cloth-Changing Person Re-identification[J]. IEEE Transactions on Multimedia, 2024.
- [69] Gao Z, Wei S, Guan W, et al. Identity-guided Collaborative Learning for Cloth-changing Person Reidentification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 46(5): 2819-2837.