

東北大學



NORTHEASTERN
UNIVERSITY

硕士学位论文

THESIS FOR MASTER'S DEGREE

论文题目 基于多尺度注意力特征的行人重识别跨域方法研究

作者 许芳斌

学号 1900908

学院(部) 信息科学与工程学院

专业 控制科学与工程

指导教师 陈东岳 教授

二〇二一年六月

分类号_____ 密级 _____

UDC _____

学 位 论 文

基于多尺度注意力特征的行人重识别跨域方法研究

作 者 姓 名： 许芳斌

作 者 学 号： 1900908

指 导 教 师： 陈东岳 教授

东北大学信息科学与工程学院

申请学位级别： 硕士

学科专业名称： 控制科学与工程

论文提交日期： 2021 年 6 月 论文答辩日期： 2021 年 6 月

学位授予日期： 2021 年 7 月 答辩委员会主席： 薛定宇

评 阅 人： 薛定宇、丛杨

东 北 大 学

2021 年 6 月

A Thesis in Control Science and Engineering

**Research on Cross-domain Person Re-
identification Based on Multi-scale Attention
Features**

By Xu Fangbin

Supervisor: Professor Chen Dongyue

Northeastern University

June 2021

摘 要

随着城市化进程的加快推进与人工智能技术的飞速发展,智慧城市治理已经成为一项具有重要现实意义的研究领域。目前,监控摄像头遍布城市的每一个角落,利用人工智能技术分析和理解监控视频,从而为城市治理决策提供依据与知识也因此成为智慧城市领域的一个重要研究方向,而行人重识别正是该方向下的一个热点研究课题。

行人重识别是指利用计算机视觉与机器学习技术在不同摄像头的视频中找到来自于同一个行人的图像的任务。目前大多数行人重识别算法以深度学习为主要手段,在标准的有监督行人重识别问题上具有较高的成熟度。相比之下,训练场景与应用场景存在明显差异的跨域行人重识别问题更加接近于真实的应用需求,因而也具有更大的技术挑战。本文面向实际监控场景下的跨域行人重识别任务需求,具体针对行人目标的尺度差异性、背景对目标的干扰以及目标域缺少行人 ID 标签等挑战,研究一种基于多尺度注意力特征的跨域行人重识别模型,具体内容如下:

1) 针对行人目标在不同摄像头下存在的尺度差异,设计了一种基于多尺度注意力特征的行人重识别模型。该模型将高分辨率特征提取框架与全尺度特征提取模块相结合,并构建了相应的动态注意力聚合模块,通过标签平滑交叉熵损失函数和难样本挖掘三元组损失函数的优化,实现了端到端的高分辨率全尺度有监督行人重识别网络 HROSNet 的设计与训练。实验证明该模型提取的多尺度特征对于行人目标尺度差异和背景干扰有更好的鲁棒性,可以为跨域行人重识别任务提供骨干网络架构与源域预训练模型。

2) 针对目标域无标签的跨域行人重识别问题,提出了一种基于自步对比学习的跨域行人重识别方法。该方法采用基于聚类伪标签的自适应跨域基准框架,以本文提出的 HROSNet 为特征提取网络,将自步对比学习方法引入跨域重识别框架,结合混合记忆库与统一对比损失函数,在随机初始化参数的网络上,同时利用有标签的源域数据和无标签的目标域数据,实现重识别模型的域适应学习。实验结果证明该方法能够在 HROSNet 的特征优势基础上进一步提升跨域检索准确率,其性能基本达到了目前跨域行人重识别的先进水平。

3) 基于上述工作,结合本文依托项目对行人重识别系统实际部署的任务需求,在实际室内场景中搭建了一套行人重识别软硬件平台,并在自建数据集和真实应用场景上对本文提出的跨域行人重识别模型的性能进行了测试。测试结果证明了本文模型在实际应用中仍然具有比较良好的性能。

综上所述,上述工作在特征学习方面提出了基于多尺度注意力特征的HROSNet 网络提升了特征表达的鲁棒性;在跨域策略方面提出了基于自步对比学习的跨域行人重识别方法;搭建了相应的软硬件实验系统对模型进行了测试与实践;实验结果和实用效果均证实了本文方法的先进性和实用性。

关键词: 行人重识别, 多尺度特征, 注意力机制, 域适应学习, 自步对比学习

Abstract

With the increasing process of urbanization and soaring development of artificial intelligence, smart city governance has become a practically meaningful research field. As surveillance cameras can be found from every corner of the city, there comes as no surprise that the analysis and understanding of surveillance videos using AI technology, which can provide reference and knowledge for administering smart cities, has turned into an important research area, within which Person Re-Identification (ReID) is a hot topic.

Person ReID refers to the task of retrieving the same person images from multiple camera views using computer vision and machine learning technology. Currently, most ReID algorithms take the advantage of deep learning, and standard supervised ReID problems have shown maturity to some extent. In contrast, cross-domain ReID, whose training and application scenarios are closer to the real application requirements, implies greater technical challenges. This thesis aims at the application demand of cross-domain ReID in real surveillance situations. Focusing on the problem of varying pedestrian scale, background disturbance, as well as the lack of person ID labels in the target domain, a cross-domain person ReID model based on multi-scale attention feature is studied. The concrete research details are as follows:

- 1) For the problem of varying pedestrian scale under different cameras, a multi-scale attention feature based ReID model is designed. It combines the high-resolution feature extraction architecture and omni-scale feature extraction modules, and incorporates dynamic attention aggregation modules. Optimized by the joint learning of label smoothing cross entropy loss and hard batch triplet loss, an end-to-end supervised HROSNet (High-Resolution Omni-Scale Network) is designed and trained. Experiments show that the multi-scale features extracted by the model are more robust to pedestrian scale variation and background disturbance, thus a backbone network and the weights pretrained from the source domain are provided for the cross-domain person ReID task.
- 2) As for the problem of unsupervised cross-domain learning, a self-paced contrastive

learning method is introduced. Based on the clustering-based pseudo-label self-adapting baseline framework and the features extracted by HROSNet, which is proposed by this thesis, we introduce self-paced learning method into the cross-domain ReID framework. Combined with mixed memory bank and unified contrastive loss function, we leverage both labeled source domain data and unlabeled target domain data simultaneously to train a network from scratch, thus realizing domain adaptation learning. The experiment results prove that this method is capable of further improving cross-domain retrieving accuracy on account of the superiority of the features extracted by HROSNet, which achieves state-of-the-art (SOTA) performance in cross-domain person ReID.

- 3) Based on the work above, we establish an indoor software and hardware platform in consideration of the deployment demand of the ReID system required by the supporting project. We also test the performance of our proposed cross-domain person ReID model on the self-built dataset and in real application scenarios. The testing results prove that our model maintains good performance in practical application.

To sum up, in this thesis, a multi-scale attention feature based HROSNet is proposed from the perspective of feature learning, which improves the robustness of feature expression. In addition, a cross-domain person ReID method based on self-paced contrastive learning is proposed in terms of cross-domain strategy. Last but not least, a software and hardware system is established for practical testing. Experimental and practical application results both prove the progressiveness and practicability of the proposed methods.

Key words: person re-identification; multi-scale feature; attention mechanism; domain adaptation; self-paced contrastive learning

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 行人重识别问题的难点.....	2
1.3 国内外研究现状.....	3
1.3.1 行人重识别特征提取.....	3
1.3.2 行人重识别跨域策略.....	5
1.4 研究内容.....	7
1.5 论文章节安排.....	8
第 2 章 相关知识概述	11
2.1 行人重识别相关知识.....	11
2.1.1 数据集.....	11
2.1.2 性能指标.....	12
2.2 行人重识别特征提取相关知识	13
2.2.1 多尺度特征提取概述.....	13
2.2.2 注意力机制概述.....	14
2.3 行人重识别跨域相关知识	16
2.3.1 对比学习概述.....	16
2.3.2 自步学习概述.....	17
2.4 本章小结.....	18
第 3 章 基于多尺度注意力深度网络的特征提取方法	19
3.1 引言	19
3.2 多尺度注意力深度网络结构设计	20
3.2.1 多分辨率并行架构.....	20
3.2.2 多分辨率特征融合机制.....	21
3.2.3 全尺度特征提取模块.....	22
3.2.4 全尺度特征注意力聚合机制.....	25
3.3 损失函数设计.....	27
3.3.1 标签平滑交叉熵损失函数.....	27
3.3.2 难样本挖掘三元组损失函数.....	28
3.4 实验分析.....	29
3.4.1 实验设置.....	30
3.4.2 模型参数设置.....	31
3.4.3 消融实验.....	34
3.4.4 与当前主流方法的对比.....	36

3.5 本章小结.....	38
第4章 基于聚类伪标签与自步学习的自适应跨域行人重识别方法	39
4.1 引言.....	39
4.2 自适应跨域基准策略.....	40
4.3 基于聚类的伪标签生成.....	42
4.4 基于自步对比学习的跨域策略	45
4.4.1 混合记忆库.....	46
4.4.2 统一对比损失函数设计.....	47
4.4.3 基于聚类可靠性准则的自步样本选取策略	48
4.5 实验分析.....	51
4.5.1 实验设置.....	51
4.5.2 聚类方法测试与分析.....	51
4.5.3 消融实验.....	53
4.5.4 与当前主流方法的对比.....	55
4.6 本章小结.....	57
第5章 行人重识别系统设计与实现	59
5.1 引言.....	59
5.2 行人重识别系统流程.....	59
5.3 系统需求分析.....	60
5.3.1 系统功能性需求分析.....	60
5.3.2 系统非功能性需求分析.....	61
5.4 系统开发与运行环境.....	61
5.4.1 硬件平台.....	61
5.4.2 软件平台.....	63
5.5 系统框架设计.....	65
5.5.1 硬件平台搭建设计.....	65
5.5.2 软件框架搭建设计.....	66
5.6 系统模块实现.....	67
5.6.1 视频解码模块实现.....	67
5.6.2 算法模块实现.....	68
5.6.3 视频推流模块实现.....	70
5.6.4 行人数据库实现.....	71
5.6.5 后端服务响应模块实现.....	72
5.6.6 客户端界面实现.....	73
5.7 自建测试数据集.....	75
5.8 系统功能测试评估.....	77
5.8.1 行人检测与跟踪性能评估.....	77
5.8.2 行人重识别性能评估	78

5.9 本章小结.....80

第 6 章 结论与展望81

6.1 结论.....81

6.2 展望.....82

参考文献.....83

第1章 绪 论

1.1 研究背景及意义

随着全球城市化进程的持续推进,世界各地的城市规模都不断扩大,随之而来的是诸多不稳定、不可预见的因素,造成种种管理问题。重大突发事件呈现高发态势,危害程度不断增加,给城市公共安全治理带来了极大考验。在一系列推动城市健康有序发展的构想中,“智慧城市”成为许多人眼中的答案,也因此成为人们广泛热议的话题。早在“十三五”期间,国家就已将建设新型智慧城市纳入规划,成为一项重要的国家战略^[1],并推进了天网工程、平安城市、雪亮工程、智安社区等一系列建设^[2];而在后疫情时代,全世界已经普遍认识到以智慧城市为代表的治安防控与管理体系在人类应对重大危机时的决定性作用。在智慧城市的构建中,视频监控建设发挥了主力军的作用。在过去的十几年中,我国是监控摄像头数量增长最快的国家。据估计,中国 2021 年监控摄像头数量将超过 5 亿个。视频监控系统不仅可以部署在机场、车站、广场等人流密集的场所,也可以部署在政府机关、电站、会议中心等重要单位。利用部署的摄像头,可以实时监控行人在公共场所的活动、检测并识别潜在的危险分子、提供风险预警、预防恐怖暴力,从而维护社会治安稳定、保护人民生命财产安全。目前,监控摄像头已经遍布城市的每个角落,由此产生的庞大视频数据,靠人工值守研判显然是不可能的。现实场景的安防应用催生出了巨大的数据处理需求,尤其是利用智能技术,实现对行人为主体的分析。监控视频中的行人分析技术主要包括行人检测与跟踪、行人识别、行人动作识别、行人重识别等等。其中,行人检测负责检测出视频数据中的行人信息;行人跟踪负责记录行人在单个摄像头下的运动轨迹;行人识别指将识别出某个行人的具体身份;行人动作识别指识别出行人正在进行的动作;而行人重识别技术则主要是解决跨摄像头场景下行人的识别和检索问题。

行人重识别(Person Re-Identification, Person Re-ID),又称行人再识别、跨镜追踪,简称 ReID,是近年来针对智慧城市安防而提出的一项新型监控技术。该技术能够根据行人的穿着、体态、发型等信息识别出不同摄像头下的行人,可作为人脸识别技术的重要补充,适用于更多新的应用场景。在安防应用场景中,监控摄像头由于安装高度、角度的原因,往往难以抓拍到行人正脸,只能拍到行人头顶、后脑勺或者侧脸的概率更大一些;其次,即便拍到人脸,但由于拍摄距离较远、光照

条件不足,大多无法抓拍到行人清晰的正脸照,这就极大地限制了人脸识别技术在实际监控场景中的应用。而利用行人重识别技术,在无法获得清晰人脸图片的前提下,依旧可以实现对行人跨摄像头的连续跟踪,从而增强行人数据的时空连续性。结合人脸识别技术和行人重识别技术各自的特点及优势,以少量人脸卡口加大量普通监控探头的混合部署方式,既可锁定嫌疑人身份,又能重现嫌疑人轨迹,这种综合型技战法可以对城市进行大范围的监控覆盖,具有极强的实战价值,对视频监控安防行业具有颠覆性意义。而在商业应用中,可以根据行人的外观,实时动态跟踪用户在商场或超市内的行踪轨迹、收集“人”与“场”之间的关系数据,以此分析用户的购物行为,以便优化用户体验。此外,行人重识别技术还可以应用在公共场所走失人员的查找、人员比对、人流统计等场景中。综上所述,行人重识别技术在安防、商业、交通等各个领域中的应用将有助于提升经济效益、社会效益。行人重识别技术的研究,将有助于推动以人为主体的行为分析技术的发展、有助于提升计算机视觉算法对相似物体的辨别能力,具有重要的学术价值和理论研究价值。

1.2 行人重识别问题的难点

行人重识别问题的研究起始于多摄像机跟踪。Zajdel 等^[3]率先提出了明确的行人重识别问题定义,即“识别一个离开之后又重新进入摄像头视野的行人”。经过近 20 年的发展,行人重识别领域研究已经较为深入。然而在实际应用中,行人重识别还面临着一系列挑战尚待解决:

- (1) **数据集规模与标注问题:** 有监督行人重识别数据集要求将多个摄像头中的同一个行人标注出来,标注成本十分高昂,因此行人重识别的公开数据集规模都十分有限。目前常用的数据集平均每个行人的图片数量只有 10~30 张,和 ImageNet^[4]每一类约 1000 张图片的规模相距甚远,因而从某种意义上说,行人重识别又可以视作一个颇具难度的小样本细粒度分类任务。
- (2) **特征鲁棒性问题:** 监控摄像头中,根据拍摄距离的远近,行人尺度会发生明显的变化,而行人身上具有辨识性的区域大小也不尽相同,这就要求模型提取的特征能够应对上述多尺度的情形;而在行人图片中,不可避免地含有背景区域,若不加选择地利用来自全图的特征会引入背景干扰,不利于行人的检索,这就要求模型具有一定的特征筛选机制。综上所述,行人重识别特征需要对尺度和背景干扰具有鲁棒性。
- (3) **跨域学习问题:** 在行人重识别任务中,由于通常无法事先知晓实际应用的具体

场景或具体行人,因此训练与应用数据的域分布模式通常会有明显的不同。这一差异往往导致在训练集上表现良好的模型,在实际应用中出现大幅度的性能下降,从而严重制约了行人重识别的落地应用。为了研究这一问题,跨域行人重识别将数据划分为源域和目标域,其中,源域是有标签的,而目标域是无标签的。跨域行人重识别通常基于在源域上经过有监督充分训练的模型,在目标域上进行无监督域适应训练,从而提升模型在目标域上的性能。

1.3 国内外研究现状

行人重识别从问题的定义和实际应用的需求来看,研究重点集中在特征提取和跨域策略两个方面。本节将从这两个方面对行人重识别研究现状进行阐述。

1.3.1 行人重识别特征提取

行人重识别特征提取算法可以分为两类,一类是基于人工设计的传统特征提取方法,另一类是基于深度学习的特征提取方法。

1) 传统人工特征提取方法

传统的人工特征重识别模型针对特征的提取主要思路是设计人工特征。最初,人们利用的是 RGB、YUV 以及 HSV 等底层颜色特征,但由于判别能力较低,不能很好的实现复杂的行人重识别任务。此后,人们开始尝试引入 HOG (Histogram of Oriented Gradient)^[5]、GoG (Gaussian of Gaussian)^[6]、SIFT (Scale Invariant Feature Transform)^[7]、LOMO (Local Maximal Occurrence)^[8]等中高层语义特征和描述子。这些特征和描述子具备较高的判别能力,在行人重识别任务中发挥了重要的作用。此外,除了纹理和颜色的特征,有学者期望借助行人的属性特征,如性别、衣着、外貌等进行行人重识别的检索,研究表明,行人属性特征在行人重识别任务很复杂时相对于其他的人工特征更具鲁棒性。

2) 基于深度学习的特征提取方法

随着深度学习的发展,利用卷积神经网络(Convolutional Neural Networks, CNN)提取特征迅速成为行人重识别领域的主流方法,得益于其强大的表征能力,这一类方法的性能相对于传统人工特征提取方法而言有了显著提升。基于深度学习的行人重识别特征提取方法主要可以分为以下几类:基于单尺度的特征提取方法、基于多尺度的特征提取方法以及基于注意力机制的特征提取方法。

基于单尺度的特征提取方法存在两种结构,一种是利用单个特征提取网络,结

合分类损失、度量损失在嵌入空间 (embedding space) 中学习行人表征, 典型的例子是 Zheng 等^[9]提出的 IDE 基准模型, 它利用 ResNet^[10]提取行人特征, 成为许多后续工作的基础; 另一种是利用孪生网络 (siamese network) 结构和对比验证损失, 同时输入一对行人图片, 判断其是否是同一个行人, 典型的例子如文献[11]、文献[12]等。

多尺度信息在计算机视觉领域具有重要的意义。近年来, 一些工作基于多尺度特征提取方法, 提升行人重识别网络的表征能力。Chen 等^[13]基于图像金字塔提出一种深度金字塔特征学习 (Deep Pyramid Feature Learning, DPFL) 方法, 通过具有相同结构的多个分支提取输入大小不同的同一行人图片特征, 并通过一个融合分支将它们整合。Wang 等^[14]提出多粒度网络 (Multiple Granularity Network, MGN) 架构, 将 ResNet-50 中 res_conv4_1 残差块之后的部分划分为三个独立分支, 每个分支切分成不同数量的分块, 分块越多, 其提取特征的尺度越精细。结合全局和多粒度局部特征, 可以让学习到的行人表征更加鲁棒。Zheng 等^[15]提出一种由粗略到精细的金字塔模型, 首先将骨干网络提取到的特征度切分成许多分块, 并逐步合并, 在不同空间尺度上捕捉具有鉴别能力的信息。Zhou 等^[16-17]基于 Inception^[18]、ResNeXt^[19]等网络模块化多分支的设计思路, 提出了全尺寸网络 (Omni-Scale Network, OSNet), 各个分支通过不同数量的卷积堆叠, 形成不同大小的感受野, 并用一个通道聚合模块将其融合; 作者还利用神经架构搜索 (Neural Architecture Search, NAS) 技术, 找到了最佳的全尺寸模块组合; 此外, OSNet 采用了轻量化设计, 利用深度可分离卷积替代普通卷积, 模型参数量较传统 ResNet 等网络大大减小。

注意力机制是近年来深度学习领域广泛研究的热点问题。注意力机制期望关注输入中对解决任务具有高价值信息的部分, 抑制其他无用的信息, 从而提高信息处理效率、提升特征的表征能力。许多学者将注意力机制应用在行人重识别工作上, 其中一种方式是基于行人形态或姿态的先验知识, 将行人进行局部划分, 分别关注各个部分的特征。Variora 等^[20]将行人图片水平切分成 6 等分, 分别提取特征, 并基于孪生 LSTM 网络进行对比学习。Sun 等^[21-22]提出基于分块的卷积基准 (Part-based Convolutional Baseline, PCB) 模型, 将特征图均等划分成 6 块, 每块分别进行预测, 然后将结果叠加作为最终的输出; 此外, 作者还提出了分块改善池化 (Refined Part Pooling, RPP) 方法提升行人分块的精细程度。基于图片分块的方法需要行人对齐, 否则提取到的特征语义存在不一致性。基于姿态估计的方法通过提

取行人骨骼关键点进行局部特征对齐,方法有 AACN^[23]、Spindle Net^[24]、GLAD^[25]等。上述方法可视为使用了硬注意力,着重对局部特征选择建模;而另一种应用注意力机制的方式是利用软注意力来进行全局的特征关系建模。Li 等^[26]提出协调注意力卷积网络(Harmonious Attention CNN, HA-CNN)联合利用硬区域注意力和软像素注意力学习特征。Hou 等^[27]利用不同尺度的空间注意力来挖掘不同位置表现的相似性。Zhang 等^[28]提出全局关系注意力(Relation-aware Global Attention, RGA)网络,从空间和通道两个注意力维度挖掘全局相关信息。

综上所述,传统人工特征提取方法发展较早,效果一般;而基于深度学习的特征提取方式能够提取更为鲁棒的行人特征。从研究发展趋势来看,未来特征提取方式将继续朝着多尺度信息的提取与融合、局部与全局信息的关联与交互发展。而随着行人重识别落地应用的需求不断增加,越来越多的工作中将会考虑模型参数量与计算复杂度的问题,基于轻量化网络、知识蒸馏的行人重识别特征提取网络将会得到发展。

1.3.2 行人重识别跨域策略

行人重识别技术落地应用的一个巨大挑战来自于跨域问题。由于实际应用时,算法需要处理采集自不同时刻、不同地点摄像头的行人数据,它们的视角、背景、光照条件等与训练集常常存在巨大的差异,即存在“域漂移”(Domain Shift)问题,因而造成在训练集上训练好的模型在另一个场景中的性能表现十分差。目前,完全利用无标签数据训练行人重识别模型还不够成熟,因此人们通常综合利用源域和目标域缓解跨域的问题。

行人重识别域适应算法旨在通过迁移学习(Transfer Learning)等方式,让在源域(Source Domain)上训练好的模型经过调整后,能够在目标域(Target Domain)上同样表现良好。由于在实际应用场景中,可以方便地获取大量无标签的行人图片,因此人们通常采用无监督或者弱监督的方式来实现这一过程。行人重识别域适应算法大致可以分为两大类,一类是基于生成对抗网络(Generative Adversarial Network, GAN)的域转换的方法,另一类是基于伪标签的无监督域适应(Unsupervised Domain Adaptation, UDA)方法。

1) 基于生成对抗网络的域转换法

基于域转换的方法通常包含两个步骤:1)训练 GAN 模型,将源域图像转换成目标域图像的风格,或者反之将目标域图像转换成源域图像的风格,通常保持转

换前后的行人标签不变；2) 利用风格变换后的图像进行有监督训练。由于该模型是利用目标域风格图片训练的，所以能够在目标域上取得不错的性能。Wei 等^[29]基于 Cycle-GAN^[30]的结构，结合 PSPNet^[31]生成的行人掩模，提出了 PTGAN 模型，在考虑行人标签不变约束的前提下，实现行人背景的转换；Deng 等^[32]基于同域内同一行人标签的一致性和不同域间行人标签的不一致性提出 SPGAN 方法，同样利用改进后的 Cycle-GAN 生成风格迁移图片。然而，Cycle-GAN 在风格变换时需要对每一对相机进行建模和训练，这样会大大增加训练成本。对此，Zhong 等^[33]提出异构同质学习 (Hetero-Homogeneous Learning, HHL) 方法，该方法基于 StarGAN^[34]，通过单个模型对多个摄像头风格转换建模，利用来自同一个域不同摄像头的同质图片学习相机不变行人特征，利用来自不同域的异构图片学习域间连通性；而 Chen 等^[35]则提出了一种基于个体的背景渲染的 CR-GAN 方法，该方法能将单个目标域行人转换至多张目标域背景图上，从而大大增加训练图片数量。此外，Huang 等^[36]提出 SBSGAN 方法，通过抑制图片背景漂移来最小化域间漂移；Li 等^[37]提出的 PDA-Net 考虑对行人姿态进行单独分解，通过对姿态维度、视觉维度分别生成对抗建模，最终得到与姿态无关且具有域不变性的特征向量。Zhai 等^[38]同样基于 StarGAN 提出 AD-Cluster 方法，在保证伪标签不变的前提下最大化目标域样本的多样性，以此提升行人特征的辨识力。

2) 基于伪标签的无监督域适应法

基于伪标签的方法也通常包含两个步骤：1) 通过聚类、图片相似性刻画等方式生成目标域数据伪标签；2) 利用生成的伪标签展开训练。一些工作侧重挖掘目标域行人间的相似性和差异性，如 Zhong 等^[39]提出的 ECN 方法，基于样本不变性、相机不变性、邻域不变性三个假设设计了损失函数。Fu 等^[40]提出的自相似归组 (Self-Similarity Grouping, SSG) 方法基于分块的思想，将行人分成全身、上半身、下半身三个部分，分别进行伪标签聚类和学习；此外，作者还引入了簇引导的半监督学习方法，可以在不花太多精力标注的前提下进一步提升算法精度。一些方法尝试挖掘源域和目标域之间的关系，如 Lin 等^[41]利用中层语义特征对齐源域和目标域；Zou 等^[42]将源域和目标域编码到同一个表征空间、不同的结构空间中，以此达到表征关联性和类别解耦性的统一。基于伪标签的方法容易受伪标签噪声的影响，尤其是在训练初期，伪标签噪声较大的情况下，模型训练容易崩溃，因此，一些工作将研究重点放在如何减轻标签噪声的影响上。Zhang 等^[43]提出一个渐进增强式自训练 (Self-Training with Progressive Augmentation, PAST) 框架，将训练划

分为保守阶段 (conservative stage) 和提升阶段 (promoting stage), 两个阶段交替进行。其中保守阶段使用基于聚类和基于排序的两种三元组损失进行监督, 在训练早期可以防止由于伪标签噪声导致的模型崩溃; 提升阶段引入了交叉熵分类损失, 可以防止仅仅使用三元组损失而陷入局部最优。Ge 等^[44]提出相互平均教学 (Mutual Mean-Teaching, MMT) 框架进行伪标签优化, 核心思想是在离线生成的硬伪标签的基础上, 利用更为鲁棒的软标签对伪标签进行在线优化, 做法是同时训练两个结构相同、权重不同的网络, 各自的输出作为对方的软伪标签, 在协同训练下达到相互监督的效果; 为了避免对网络自身的输出误差形成过拟合, 两个网络都利用各自的平均模型生成监督信号, 从而提供更为可信和稳定的软标签。和 MMT 类似, Zhai 等^[45]基于集成学习、相互学习的思想设计了多专家头脑风暴 (Multiple Expert Brainstorming, MEB) 方法, 同时训练多个网络, 并设计了一种正则化方法, 根据单个网络输出的伪标签聚散程度来调节各个网络在相互学习时的权重。和 MMT 的不同点在于, MEB 中的多个网络结构是互不相同的。此外, Ge 等^[46]提出了一种基于自步对比学习 (Self-paced Contrastive Learning, SpCL) 的方法, 利用可靠性准则筛选出可靠的聚类簇, 从而提升伪标签质量。还有一些工作认为同一个行人在不同相机下出现的时间间隔遵从一定的规律, 因而尝试利用行人图片的相机编号和拍摄时间信息来提升伪标签的可靠性。Lv 等^[47]提出的 TFusion 方法综合利用时空信息构建了时空贝叶斯融合模型, 并结合排序学习生成更可靠的伪标签, 以此训练性能更佳的视觉分类器; Li 等^[48]同样利用行人图片的相机编号和拍摄时间信息, 提出联合视觉相似性与时间一致性 (Joint Visual and Temporal Consistency, JVTC) 方法, 当两张图片的视觉特征足够相似、时间一致性足够时, 才打上同样的伪标签。

目前基于伪标签的无监督域适应法通常性能更好, 但前提是域间差异不能过大, 否则会因为无法生成高质量的伪标签而难以训练; 而基于域转换的方法在单独使用时, 性能往往不如伪标签法, 但是在领域差异非常大的情况, 可以充分利用源域数据, 缩小域间差异。综上所述, 两种方法可以互为补充, 未来很可能出现综合考虑两种方法设计的行人重识别域适应算法。

1.4 研究内容

本文研究课题为基于多尺度注意力特征的行人重识别跨域方法研究, 具体研究内容如下:

1) 基于多尺度注意力深度网络的特征提取方法

针对行人目标在摄像头下存在的尺度差异和背景干扰,设计一种基于多尺度注意力特征的深度行人重识别网络,利用有监督学习方式,在源域上进行训练,从而为跨域行人重识别任务提供高效的网络架构和预训练模型。

2) 基于聚类伪标签自步学习的行人重识别跨域策略

针对目标域无标签的跨域行人重识别问题,基于聚类伪标签的自适应跨域基准框架和多尺度注意力特征,结合应用自步对比学习方法、混合记忆库与统一对比损失函数等方法,探究行人重识别跨域最优策略,实现重识别模型的域适应学习。

1.5 论文章节安排

本文的总体思路是从行人重识别的两个关键问题出发:有监督特征提取问题与无监督跨场景域适应问题。这两个问题是行人重识别领域研究的关键难点。针对每个问题,本文分别考虑设计相应的算法。针对特征提取问题,本文提出使用多尺度注意力特征提取方法提取鲁棒的行人特征;针对跨场景问题,本文基于多尺度注意力行人特征,进行了无监督域适应方法的探究。最后,本文还将上述研究的方法应用到实际系统中,为行人重识别的落地部署应用提供了一套完整的解决方案。本文具体的论文章节安排如下:

第1章 绪论。本章首先阐述本课题研究的背景和意义,以及行人重识别问题研究的难点;随后介绍本文的研究内容,即行人重识别特征提取方法和域适应方法,并分别从这两个方面对国内外相关研究进行阐述;最后对本文的章节安排进行介绍。

第2章 相关知识概述。本章属于基础知识介绍。首先介绍行人重识别任务相关的知识,包括常用的开源数据集和评价标准;接着对本文在设计行人重识别特征提取算法时涉及的多尺度特征提取方法和注意力机制进行分别概述;最后对本文跨域方法研究中涉及的对比学习和自步学习相关基础知识进行概述。

第3章 基于多尺度注意力深度网络的特征提取方法。为了提取更加鲁棒的行人重识别特征,本章基于高分辨率特征提取架构和全尺度特征提取方法,结合注意力机制,设计了高分辨率全尺度特征提取网络 HROSNet,训练中使用标签平滑交叉熵损失函数和难样本挖掘三元组损失函数进行监督。实验表明 HROSNet 在性能和参数量之间达到了平衡。

第4章 基于聚类伪标签与自步学习的自适应跨域行人重识别方法。面向多尺

度注意力特征提取网络 HROSNet, 本章进行了行人重识别跨域学习方法的探究。首先基于自适应跨域基准策略对聚类方法进行探究, 其次将自步对比学习跨域策略应用到 HROSNet 上, 从自步可靠性准则、离群样本、目标域实例特征存储、特征库更新、源域数据的使用等方面进行了一系列探究。

第5章 行人重识别系统设计与实现。本章属于实践部分。首先在实际场景中搭建了软硬件平台, 实现了一个完整的行人重识别系统; 然后将本文提出的 HROSNet 在实际场景中进行了测试和应用。

第6章 结论与展望。本章对本文进行的研究和实践工作进行总结, 对研究结果进行了概述, 同时对工作中存在的不足进行探讨, 提出了对未来工作的展望与建议。

第2章 相关知识概述

本文将分别对行人重识别的特征提取方法和跨域学习方法展开研究。本章内容将会就行人重识别任务的相关知识以及本文方法涉及的基础知识进行介绍，其中行人重识别知识将会介绍常用的数据集和性能评价指标；特征提取方法将会介绍多尺度特征提取和注意力机制相关概述；跨域学习将会介绍对比学习和自步学习相关概念。

2.1 行人重识别相关知识

2.1.1 数据集

随着行人重识别任务研究的发展，现有的相关研究大都基于深度学习方法在大规模行人重识别数据集上开展。本文将基于目前在行人重识别领域广泛使用的 Market1501^[49]、DukeMTMC-reID^[50-51]和 MSMT17^[29]三个大规模行人数据集展开实验。本节将首先对这几个数据集展开介绍。其详细统计信息如表 2.1 所示：

表 2.1 行人重识别数据集
Table 2.1 Person re-identification datasets

数据集	行人 身份数	图片数	摄像头 数量	检测器	场景
Market1501	1501	32668	6	DPM, 手动	室外
DukeMTMC-reID	1812	36411	8	DPM, 手动	室外
MSMT17	4101	126441	15	Faster-RCNN	室内, 室外

Market1501 数据集采集自清华大学校园中的 6 个摄像头，其中 5 个高清摄像头的分辨率为 1280×1080 ，还有一个分辨率为 720×576 的标清摄像头。这些摄像头存在重叠的拍摄区域，从而保证每个行人至少出现在两个摄像头中。数据集中的行人框由可变形局部模型（Deformable Part Model, DPM）^[52]检测算法自动生成，并通过人工标注验证其生成质量。数据集共有 1501 个行人 ID、32668 张图片，随机划分成训练集和测试集。其中训练集有 751 人、12936 张图片，平均每个行人有 17.2 张训练图片；测试集包括 750 人、19732 张图片，其中 3368 张作为行人查询库（query），其余的图片作为行人搜索库（gallery）。

DukeMTMC-reID 数据集是在杜克大学采集的, 是 DukeMTMC 数据集的一个子集, 共由八个摄像头拍摄完成。该数据集中的行人检测框同样是通过 DPM 算法自动生成的。数据集中有 1404 个行人至少出现在两个摄像头下, 随机采样其中的 702 人共 16522 张图片作为训练集, 另 702 人共 17661 张图片作为测试集。在测试集中, 从每个行人出现的每个摄像头下抽取一张图片形成行人查询库, 剩余的作为行人搜索库。除此之外, 还有 408 人只出现在一个摄像头中, 他们作为干扰项也加入到行人搜索库中。

MSMT17 数据集包含 15 个不同的摄像头拍摄的图片。和之前的数据集不同, 它不再使用 DPM 算法, 而是用检测性能更强的 Faster-RCNN^[53]算法生成行人检测框。该数据集拥有 126441 张行人图片, 共 4101 个不同的行人。数据集的拍摄地点包含了室内、室外多种场景, 采集时间涵盖了早晨、中午、下午多个时间段以模拟实际监控场景下不同时刻光照的变化。和 Market1501、DukeMTMC-reID 等数据集相比, 该数据集在图片数量、行人数量、场景丰富度等方面都有了明显提升, 因此更贴近真实情况, 难度显著增加。

2.1.2 性能指标

行人重识别可以看作是一种图像检索任务, 为了评估算法性能, 本研究中采用的性能指标是累积匹配特征 (Cumulative Matching Characteristic, CMC)^[54]和平均均值准确率 (mean Average Precision, mAP)。

CMC, 亦称 CMC Rank-N, 表示每次检索查询的目标行人在不同数量的候选列表中出现的概率, 例如 CMC Rank-1 表示每次检索第一个结果与查询图像成功匹配的概率。在算法性能比较时, 通常查看 CMC Rank-1、CMC Rank-5、CMC Rank-10 的准确率。计算 CMC Rank-N 的公式如式 2.1 和 2.2 所示:

$$\text{ACC}_k = \begin{cases} 1, & \text{前}k\text{个结果有正确查询结果} \\ 0, & \text{前}k\text{个结果无正确查询结果} \end{cases} \quad (2.1)$$

$$\text{Rank}(n) = \frac{\sum_{x_{\text{probe}} \in X_{\text{query}}} \text{ACC}_n(x_{\text{probe}})}{N_q} \quad (2.2)$$

其中, x_{probe} 指当前进行检索的行人图片, X_{query} 是查询集, N_q 是查询集的大小。将 $\text{Rank}(n)$, $n = N^+$ 各个点连成曲线即为 CMC 曲线。

由于 CMC 评价只计算第一个匹配项, 因此当行人在搜索库中存在多个真实匹

配时,无法很好地反映算法的召回能力。为此,Zheng 等^[49]引入了平均均值准确率的评估指标,将多个检索任务的均值精度(Average Precision, AP)求和再取平均,得到平均均值准确率 mAP,能够更好地反映行人重识别模型对行人视角、姿态等变化的鲁棒性,其计算式如式 2.3 和 2.4 所示:

$$AP = \frac{\sum_{i=1}^{N_{q_gt}} \frac{i}{g_i}}{N_{q_gt}} \quad (2.3)$$

$$mAP = \frac{\sum_{x_{probe} \in X_{query}} AP(x_{probe})}{N_q} \quad (2.4)$$

其中, x_{probe} 、 X_{query} 含义与式 2.2 相同, g_i 表示 probe 检索结果第 i 个正确匹配的索引值, N_{q_gt} 代表 probe 在检索集中正确匹配的真实数目。

2.2 行人重识别特征提取相关知识

特征提取与表达是行人重识别的核心研究问题之一,相关方法研究也层出不穷。考虑到本文主要从多尺度和注意力模块两个角度对现有的重识别特征网络进行改进,因此在提出具体的改进算法之前,首先对与这两种改进相关的已有方法和思想进行简单介绍。

2.2.1 多尺度特征提取概述

多尺度可以理解为从不同粒度对信号进行的采样。许多传统的计算机视觉算法中已经融入了多尺度的特征提取方式,如 DPM、SIFT、V-J 检测器^[55-56]等。深度学习中,常见的多尺度特征提取方式有多尺度输入、多尺度特征融合、多尺度并行特征分支等。

多尺度输入利用如图 2.1(a)所示的图像金字塔作为网络输入,即输入不同分辨率的图像,分别进行特征提取,然后将其结果进行融合,典型例子是多任务级联卷积神经网络(Multi-Task cascaded Convolutional Neural Network, MTCNN)^[57]。

多尺度并行结构通过若干分支提取感受野大小不同的特征,典型的例子是图 2.1(b)所示的 Inception 基本模块,包含四条并行的分支结构,分别是 1×1 卷积分支、 3×3 卷积分支、 5×5 卷积分支和 3×3 最大池化分支,最后将四个分支进行拼接融合。并行的多尺度特征分支也可以通过如图 2.1(c)所示的空洞卷积(dilated convolution)来实现,比如图像分割网络 DeepLabv3^[58]、目标检测网络 TridentNet^[59]

等。

多尺度特征融合也是目标检测、语义分割中常用的一种多尺度特征提取与预测方式，典型的例子是如图 2.1(d)所示的特征金字塔网络 (Feature Pyramid Network, FPN) [60]，它将经上采样的高层特征与相邻的低层特征融合成新的输出特征层，每一层分别进行预测，不同大小的特征图适合不同尺度物体的预测。

本文将基于多尺度特征融合的网络架构，利用多尺度并行特征分支模块构建一个适用于行人重识别任务的多尺度特征提取网络。




图 2.1 多尺度特征提取示意图
Fig. 2.1 Illustration of multi-scale feature extraction

2.2.2 注意力机制概述

注意力机制是深度学习里面的一个非常重要且有效的技巧，其基本的思想是使得模型能够忽略无关信息而关注重点信息，从而提升特征的表征能力。Bahdanau 等[61]最早在自然语言处理 (Natural Language Processing, NLP) 中提出了注意力机制，并在机器翻译任务上取得了重大突破；随后，Xu 等[62]将注意力机制引入计算

机视觉当中。

注意力机制可以分为软注意力、硬注意力和自注意力三类^[63]。其中，如图 2.2(a) 所示，硬注意力强调是否需要关注某个元素，输出的热图取值为 0 和 1，通过定位显著的区域来获得特征。硬注意力机制的缺点是无法直接进行反向传播优化。如图 2.2(b) 所示，软注意力关注每个元素应该赋予的重要性权重，通常可将训练层插入模型主体中，输出取值在 0~1 之间的热图作为掩模以掩盖卷积特征图，从而突出显示"有用的信息"的区域。自注意力也称内部注意力，如图 2.3 所示，自注意力挖掘同一个序列或者同一张图片不同元素之间的相对关系，提供了一种捕捉全局上下文信息的高效建模方式。




图 2.2 软注意力与硬注意力示意图
Fig. 2.2 Illustration of soft and hard attention



图 2.3 自注意力示意图
Fig. 2.3 Illustration of self-attention

在计算机视觉中，自注意力机制一般又可分为空间注意力（spatial-wise attention）和通道注意力（channel-wise attention）。典型的空間注意力机制包括 Non-local Network^[64]、动态卷积（dynamic convolution）^[65]等；典型的通道自注意力案例包括 SENet^[66]、SKNet^[67]等。此外还有一些方法联合使用空间和通道自注意力，

例如 CBAM^[68]、BAM^[69]等。

自注意力机制擅长捕捉数据或特征的内部相关性，能够减少对外部信息的依赖。本文将在多尺度特征融合中使用自注意力机制提升多尺度特征性能。

2.3 行人重识别跨域相关知识

在第一章介绍的多种跨域策略中，基于伪标签的自适应跨域策略的综合性能相对较好。然而此方法采用的伪标签在迭代循环之初，存在较大的标签噪声，可靠性较差。因此在此类策略中适当加入对标签可靠性依赖较低的损失函数将会有助于提高此类方法的收敛精度和稳定性。本文遵循这一思路，尝试将对比学习和自步学习进行融合，并将其引入到自适应跨域策略框架中。因此，在后面章节介绍本文提出的新算法之前，首先对对比学习和自步学习的思想与方法进行简单的介绍。

2.3.1 对比学习概述

对比学习 (Contrastive Learning, CL) 是表征学习 (Representation Learning) 中常用的一种学习范式。表征学习指将原始数据输入进行参数化映射，从而得到能够表征抽象概念，提升下游任务性能的特征向量或者特征张量的过程^[70]。其基本思想是，通过对比不同样本，来学到适用于某个任务的有效表征模式。这里，用于对比的可以是“相似”的正样本对，也可以是“不相似”的负样本对。和有监督学习不同，对比学习不需要对每个样本进行标注，而是需要定义相对于某个输入样本 $\mathbf{x}$ 的正样本分布 $\mathbf{x}^+ \sim p^+(\cdot | \mathbf{x})$ 与负样本分布 $\mathbf{x}^- \sim p^-(\cdot | \mathbf{x})$ ，从而能够采样出正负样本用于训练。对比学习的目标即让正样本的表征在嵌入空间中的距离尽可能拉近、负样本的表征在嵌入空间中的距离尽可能拉远。

设有映射函数 f ，将样本 $\mathbf{x}$ 编码成其表征 $f(\mathbf{x})$ ，对比学习的核心是使得 f 满足：

$$s(f(\mathbf{x}), f(\mathbf{x}^+)) \gg s(f(\mathbf{x}), f(\mathbf{x}^-)) \quad (2.5)$$

其中， $\mathbf{x}^+$ 、 $\mathbf{x}^-$ 分别表示与样本 $\mathbf{x}$ 相似和不相似的样本， $s(\cdot, \cdot)$ 是一个度量样本间相似性的函数，相似性越高，值越大，一般可以使用向量内积。对比学习损失函数通常可以构建成 softmax 的形式，如式 2.6 所示：

$$\mathcal{L}_N = -\mathbb{E}_{\mathbf{x}} \left[\log \frac{\exp(f(\mathbf{x})^T f(\mathbf{x}^+))}{\exp(f(\mathbf{x})^T f(\mathbf{x}^+)) + \sum_{j=1}^{N-1} \exp(f(\mathbf{x})^T f(\mathbf{x}_j))} \right] \quad (2.6)$$

其中，分母项包含一个正样本、 $N-1$ 个负样本。

近年来,对比学习在自监督领域得到了广泛应用,并取得了令人鼓舞的进展。例如 Oord 等^[71]提出对比预测编码 (Contrastive Predictive Coding, CPC)、Hinton 等^[72]提出的 SimCLR 框架; He 等^[73-74]提出的 MoCo 框架等。

对比学习在嵌入空间中最小化正样本对距离、最大化负样本对距离的优化目标与行人重识别的任务要求十分吻合,然而,直接将自监督对比学习方式应用到行人重识别跨域任务中往往效果不佳^[46],原因是它们通常将单个样本视作独立的类,使用数据增强产生的样本个体作为正样本,这样会破坏同一个行人重识别任务中重要的类内类间关系。因此对于行人重识别这样的检索任务,需要设计更适合的对比学习方法。

2.3.2 自步学习概述

机器学习算法在应用到实际问题中时,通常需要解决非凸优化问题。常用的机器学习算法有 EM 算法、CCCP 算法等。然而这些算法容易陷入局部极小点,难以最小化训练误差和泛化误差。为了缓解这个难题, Bengio 等^[75]提出课程学习 (Curriculum Learning, CL) 的概念,通过模拟人的认知机理,通过将任务分解为一系列子任务,让模型首先学习简单的、普适性的知识结构,然后逐渐增加难度,过渡到学习更复杂、更专业化的知识。自步学习 (Self-Paced Learning, SPL) 的概念最早由 Kumar^[76]等提出。和课程学习类似,其核心思想也同样是模拟人类学习过程,让训练过程遵循“从易到难”的范式。二者的区别在于,课程学习需要基于先验知识,指定样本不同的学习顺序或者学习特性^[77];而自步学习算法能够自适应地优先学习简单、可靠的样本,然后逐步过渡到对困难样本的挖掘和学习。

自步学习的数学模型构建方式如下。假设当前有训练集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 包含 n 个样本对,其中 $\mathbf{x}_i$ 代表一个样本实例, y_i 对应每个样本的标签。若用 $g(\mathbf{x}_i, \mathbf{w})$ 表示预测值,其中 $\mathbf{w}$ 是决策函数 g 的模型参数; $L(y_i, g(\mathbf{x}_i, \mathbf{w}))$ 表示损失函数,计算真实标签 y_i 和预测值的损失值,那么自步学习模型可以表示为式 2.7:

$$\min_{\mathbf{w}, \mathbf{v} \in [0,1]^n} \mathbf{E}(\mathbf{w}, \mathbf{v}, \lambda) = \sum_{i=1}^n \left(v_i L(y_i, g(\mathbf{x}_i, \mathbf{w})) + f(v_i, \lambda) \right) \quad (2.7)$$

其中 $\mathbf{v} = [v_1, \dots, v_n]^T$ 是隐变量, λ 是控制自步学习步伐的参数, $f(v, \lambda)$ 代表自步正则化项。在迭代优化训练的过程中,可以通过改变 λ ,来决定当前哪些样本应当纳入学习中。

基于伪标签聚类行人重识别域适应方法的性能十分依赖于伪标签的质量,而

利用从易到难的自步学习方式,将可能有助于提升伪标签的质量,从而提高跨域性能。

2.4 本章小结

本章节属于基础知识介绍,首先介绍了行人重识别任务相关的基础知识,包括 Market1501、DukeMTMC-reID、MSMT17 三个常用的数据集和 CMC、mAP 两个评价标准;然后介绍了本文第 3 章中与特征提取相关的知识,包括计算机视觉中多尺度特征提取方法和注意力机制的概述;最后介绍了本文第 4 章中面向多尺度特征跨域行人重识别域适应方法所涉及的对比学习和自步学习的概念。

第3章 基于多尺度注意力深度网络的特征提取方法

3.1 引言

行人重识别问题的核心是特征的学习，而多尺度问题则是行人重识别特征学习中普遍存在的一个基本问题。由于目标人物的表观特征随着其在场景中的位置与距离的变化会表现出明显的差异，传统的单一尺度特征很难为不同观测距离下的同一个行人对象建立起具有良好相似性与可区分性的描述，因此必须引入多尺度特征。

图 3.1 是分别从 Market1501、DukeMTMC-reID 两个公开数据集以及自建数据集中选取的三组行人图片。从图中可以看出，在公开的行人重识别数据集或实际应用中，由于行人检测器不够准确或者人工框定时对行人边界定义模糊产生的误差，导致算法输入图片中的行人普遍存在占据图片比例不尽相同，即尺度不统一的问题。因此倘若使用单一尺度的特征提取器，将会致使最终得到的特征存在匹配偏差。针对这个问题，本章提出了一种多尺度行人重识别特征提取方法，并利用注意力机制进行特征融合，加强特征的表征能力，从而提高行人重识别性能。



图 3.1 行人重识别数据多尺度问题

Fig. 3.1 Illustration of multi-scale issues in person re-identification data

当前行人重识别深度学习网络的主干网络设计模式通常基于单分支的主干网络进行，例如 ResNet、VGGNet^[78]、DenseNet^[79]等，其典型的特点是将特征提取网络分成若干阶段，每个阶段中串联若干卷积提取模块；随着网络阶段加深，特征分辨率不断降低、特征维数不断增加、特征语义抽象程度不断增加。

深度特征提取到的高阶语义信息对于行人姿态角度、相机色调、物体遮挡等影响因素具有一定的鲁棒性，但由于经过多次下采样，特征图分辨率降低，导致丢失了大量的几何空间信息；而浅层特征虽然拥有较大的分辨率，保留了较多的空间特征，但由于卷积层数较浅，特征抽象能力不足，不能直接用于行人重识别任务。因

此如何充分利用浅层和高层的特征，是提升行人重识别模型的一个思路。Yu 等^[80]研究了将不同深度特征融合对行人重识别性能的影响，结果发现，将浅层特征与高层特征简单地叠加融合或者拼接反而对结果不利。因此，对于行人重识别任务，我们需要设计既能保留空间信息、又具有足够丰富语义的网络架构。

本章将基于 2.2 节中介绍的行人重识别特征提取相关知识，结合多尺度网络提取架构，提出端到端的高分辨率全尺度行人重识别网络 HROSNet (High Resolution Omni-Scale Network)，分别从多个分辨率分支和单分辨率多感受野分支提取多尺度特征，并利用视觉注意力机制将多尺度特征聚合。该方法可以有效应对行人尺度差异带来的问题，并使网络专注于行人区域，有效缓解背景因素干扰。

3.2 多尺度注意力深度网络结构设计

Wang 等^[81]提出的高分辨率网络 (High-Resolution Network, HRNet) 能够很好地满足 3.1 节论述的网络架构设计要求。如图 3.2 所示，HRNet 架构和 ResNet、VGGNet、DenseNet 等网络类似，同样包含多个阶段；不同之处在于，HRNet 的每个阶段由若干分辨率不同的并行分支组成，分支数量随着阶段的增加而增长。HRNet 通过并行多个分辨率的分支，加上不断进行不同分支之间的信息交互，可以达到同时提取强语义信息和精准位置信息的目的。




图 3.2 高分辨率网络架构图
Fig. 3.2 Architecture of High-Resolution Network

本节将基于上图所示的 HRNet 高分辨率网络架构构建思路，针对行人重识别任务，设计一个能够高效提取多尺度行人特征的深度网络。

3.2.1 多分辨率并行架构

原始的 HRNet 共有四个阶段，而本文为了缩减参数量，基于 HRNet 架构思想，设计了如图 3.2 所示的三阶段架构，其中第一个阶段只有一个主干通路，而后两个阶段分别包含 2、3 个并行分支，每条分支由若干高分辨率模块 (High-Resolution

Module) 组成; 每条分支的特征分辨率都保持其上一个阶段对应分支的特征分辨率大小, 每个阶段的第一条分支始终维持初始的分辨率; 每个阶段最后一条分支经过下采样形成下一个阶段的新分支。设 B_{sr} 是第 s 个阶段的第 r 条分支, 那么第 r 条分支的特征图分辨率为第一条分支的 $1/2^{r-1}$, 图 3.2 中的架构分支展开可用图 3.3 表示:




图 3.3 多分辨率特征并行架构示意图

Fig. 3.3 Illustration of multi-resolution feature parallel architecture

3.2.2 多分辨率特征融合机制




图 3.4 多分辨率特征融合示意图

Fig. 3.4 Illustration of multi-resolution feature fusion

各个分支提取的多分辨率特征的相互融合是使得不同分辨率特征信息之间相互沟通的关键。如图 3.4, 以三个分支的融合为例, 设待融合特征图集合为 $\{R_p^i, p = 1, 2, 3\}$, 其中 p 是输入分支的编号, 而融合后的特征图集合为 $\{R_q^o, q = 1, 2, 3\}$, q 是输出分支的编号, 融合过程可以表示为式 3.1:

$$R_q^o = f_{1,q}(R_1^i) + f_{2,q}(R_2^i) + f_{3,q}(R_3^i) = \sum_{p=1}^3 f_{pq}(R_p^i) \quad (3.1)$$

其中变换函数 $f_{pq}(\cdot)$ 的具体形式与输入输出的分支编号有关。若 $p = q$, $f_{pq}(\cdot)$ 为恒

等映射，即 $f_{pq}(\mathbf{R}) = \mathbf{R}$ ；若 $p < q$ ， $f_{pq}(\cdot)$ 利用 $q - p$ 个步长为 2 的 3×3 卷积，对输入特征图 $\mathbf{R}$ 下采样 $q - p$ 倍；若 $p > q$ ， $f_{pq}(\cdot)$ 先通过 1×1 卷积匹配不同分支间的特征，然后通过插值上采样匹配特征图大小。

3.2.1 节中所述的特征分支并行架构最终可以得到三个维度、大小都不相同的特征图，无法直接应用于行人重识别任务，还需要将其融合成一个特征向量用于检索。对此，本文设计了一种迭代式的表征融合方式。如图 3.5 所示，首先先对三个输出分支的特征图进行升维操作，然后按照分辨率从大到小的顺序迭代地进行下采样，同时从上到下逐级融合相加，最后用 1×1 卷积升维，并利用全局池化操作得到特征向量。




图 3.5 多分辨率特征分支迭代式融合表征示意图

Fig. 3.5 Illustration of iterative multi-resolution branch feature fusion

3.2.3 全尺度特征提取模块

虽然多分辨率特征并行架构可以从多个分辨率的特征图提取特征，但对于单个分辨率来说，使用单一尺度的卷积容易忽略该分辨率下的一些不同尺度的视觉信息特征。为了进一步提升单分辨率特征的表征能力，本文引入全尺度特征模块（Omni-Scale Block, OSBlock）作为 HRNet 各个分支的基本组成单元，设计了高分辨率全尺度网络（High-Resolution Omni-Scale Network, HROSNet）。每个分辨率的每条分支由若干个全尺度特征模块串联组成。全尺度特征提取示意图如图 3.6 所示。

由图 3.6 可以看出，全尺度特征模块采用了多尺度分支的设计，即输入特征图送入四个感受野大小不同的分支中，图中 R 表示该分支在输入特征图上感受野的大小。不同感受野可以通过堆叠不同数量的卷积层实现，为此，引入感受野幂指数

$t \in N^+$ ，当 $t > 1$ 时，堆叠 t 个 3×3 卷积，可以得到感受野大小为 $(2t + 1) \times (2t + 1)$ 的特征分支。若设输入特征图为 $\mathbf{x}$ ，堆叠 t 个 3×3 卷积的操作表示为 $F^t(\cdot)$ ，那么将多个分支求和得到的特征图 $\tilde{\mathbf{x}}$ 的计算过程可以表示为式 3.2：

$$\tilde{\mathbf{x}} = \sum_{t=1}^T F^t(\mathbf{x}), \quad T \geq 1$$

(3.2)




图 3.6 全尺度特征提取示意图

Fig. 3.6 Illustration of omni-scale feature extraction

基于图 3.6 所示的多分支全尺度特征提取方式，本文设计了全尺度特征提取模块，其基本组成模块使用了残差结构设计，而其中堆叠的卷积则采用深度可分离卷积实现。

1) 残差结构

如图 3.7 所示，为了缓解由于网络层数较深造成的梯度消失、难以训练的问题，全尺度特征模块中引入了残差（Residual）结构设计。ResNet 的残差结构中包含快捷连接（shortcut connections）和特征提取分支两条支路，而 HROSNet 中，由于包含了多尺度分支，因此特征提取分支实际是多支路的。因此 OSBlock 的输出可表示为式 3.3：

$$\mathbf{y} = \mathbf{x} + \tilde{\mathbf{x}}$$

(3.3)

其中 $\mathbf{x}$ 表示输入特征图， $\tilde{\mathbf{x}}$ 表示经过多个分支处理并融合后的特征图。




图 3.7 全尺度特征提取模块残差结构图
Fig. 3.7 Residual Structure of Omni-Scale Block

2) 深度可分离卷积

为了减小参数量，全尺度特征模块中堆叠的卷积都通过深度可分离卷积（Depthwise Separable Convolutions）实现。Guo 等^[82]研究证明了深度可分离卷积可以近似等效普通卷积。设有卷积层参数 $W \in \mathbb{R}^{c_o \times c_i \times k_h \times k_w}$ ，其中 c_i 和 c_o 分别是输入和输出特征图的通道数， k_h 和 k_w 分别是卷积核的高和宽，则对于一个输入块 $x_p \in \mathbb{R}^{c_i \times k_h \times k_w}$ ，普通卷积运算可表示为式 3.4：

$$y = W * x_p \tag{3.4}$$

其中， $*$ 代表普通卷积运算。式 3.4 的计算复杂度为 $O(c_o \times c_i \times k_h \times k_w)$ ；而对于一张大小为 $H \times W$ 的特征图，其计算复杂度为 $O(H \times W \times c_o \times c_i \times k_h \times k_w)$ 。

深度可分离卷积将一个完整的卷积分解为两步进行，分别是深度卷积（DepthWise convolution, DW）和逐点卷积（PointWise convolution, PW）。其中，深度卷积只对一张 2 维的特征图做卷积，侧重于对空间关系进行建模；而逐点卷积则通过 1×1 的卷积跨特征通道建模。

图 3.8 对比展示了普通卷积和深度可分离卷积的计算过程，而如图 3.8(b)和(c)所示，根据深度卷积和逐点卷积先后顺序的不同，深度可分离卷积有两种实现形式。

根据文献[16]和[17]，本文采用先做逐点卷积、后做深度卷积的形式。设逐点卷积权重参数为 $P \in \mathbb{R}^{c_o \times c_i \times 1 \times 1}$ ，深度卷积权重参数为 $D \in \mathbb{R}^{c_o \times 1 \times k_h \times k_w}$ ，则对于一

个输入块 $\mathbf{x}_p \in \mathbb{R}^{c_i \times k_h \times k_w}$ ，深度可分离卷积可以表示为式 3.5：

$$\mathbf{y}' = (\mathbf{D} \circ \mathbf{P}) * \mathbf{x}_p \quad (3.5)$$

其中 $\circ$ 指 1×1 逐点卷积运算。式 3.5 的计算复杂度为 $O(H \times W \times c_o \times (c_i + k_h \times k_w))$ 。由于 c_i 的数值通常较大，可能的取值包括 128、256、512 等，因此深度可分离卷积的计算量显然要远远小于普通卷积。




图 3.8 普通卷积与深度可分离卷积示意图

Fig. 3.8 Illustration of regular convolutions and depthwise separable convolutions

3.2.4 全尺度特征注意力聚合机制

全尺度特征提取模块中的每一条分支可以提取单一尺度的特征，接下来需要将它们有效地聚合，形成全尺度特征图。如图 3.7 所示，全尺度特征模块中的聚合门（Aggregation Gate, AG）采取了一种统一的动态注意力聚合策略，即利用一个参数共享的模块，根据输入的图像，自动计算出聚合权重，作用在不同分支的输出上，如式 3.6 所示：

$$\tilde{\mathbf{x}} = \sum_{t=1}^T G(\mathbf{x}^t) \odot \mathbf{x}^t, \text{ s.t. } \mathbf{x}^t \triangleq F^t(\mathbf{x}) \quad (3.6)$$

其中， G 代表聚合门， $G(\mathbf{x}^t)$ 是一个长度和各分支通道数相同的权重向量， $\mathbf{x}^t$ 是全尺度特征提取模块各个分支的输出， $\odot$ 是哈达玛积（Hadamard Product）。聚合门 G 的实际上对来自不同分支的特征图做了通道注意力。统一聚合门有两个优点：

(1) 聚合门使得网络的参数量独立于特征分支的数量，这样在模型设计时便于控制参数伸缩性；

(2) 统一的网络结构在反向传播时具有良好的特性，其求导过程变得更加容易。设网络由可微损失函数 ℓ 监督，即 $\partial \ell / \partial \tilde{\mathbf{x}}$ 可以计算，那么关于 G 的梯度可以通过式 3.7 的推导计算得到：

$$\frac{\partial \ell}{\partial G} = \frac{\partial \ell}{\partial \tilde{x}} \frac{\partial \tilde{x}}{\partial G} = \frac{\partial \ell}{\partial \tilde{x}} \left(\sum_{t=1}^T x^t \right) \quad (3.7)$$

其中 T 是全尺度特征提取模块的分支数量。显然，式 3.7 的第二个乘积项仅仅是各分支求和，计算十分方便。

聚合门 G 具体通过多层感知器（Multi-Layer Perceptron, MLP）结构实现。首先对输入特征图使用全局平均池化，得到全局特征向量作为感知器的输入层。中间隐层使用 ReLU 作为激活函数，输出层采用 Sigmoid 激活函数。为了缩减全连接参数量，参照文献[66]、[68]将隐层维度的缩约系数设为 16，即隐层的通道数是输入特征通道数的1/16，最后输出层又将输出恢复成和输入一致，用于特征加权聚合。因此聚合门 G 可以用式 3.8 描述：

$$G(x^t) = \sigma(g(x^t)) = \sigma(W_2 \delta(W_1(g(x^t)))) \quad (3.8)$$

其中 σ 表示 Sigmoid 激活函数， δ 表示 ReLU 激活函数， W_1 和 W_2 是两个全连接层的权重，其中 $W_1 \in \mathbb{R}^{C/r \times C}$ ， $W_2 \in \mathbb{R}^{C \times C/r}$ ， r 是缩约系数， g 代表全局平均池化操作。

然而，对输入特征进行全局平均池化容易丢失其中的显著特征，也不利于对不同空间位置之间的特征关系进行建模。因此本文又引入局部语义分支 $\mathcal{L}(x^t)$ ，与全局语义分支 $g(x^t)$ 相比， $\mathcal{L}(x^t)$ 不对输入使用全局平均池化操作，而是始终保持与输入特征图相同的大小。局部语义分支的计算过程如式 3.9 所示：

$$\mathcal{L}(x^t) = \mathcal{B}(\text{PWConv}_2(\delta(\mathcal{B}(\text{PWConv}_1(x^t))))) \quad (3.9)$$

其中， $\mathcal{B}$ 代表批归一化操作； PWConv_1 和 PWConv_2 是两个逐点卷积操作，其中 PWConv_1 的维度是 $C/r \times C \times 1 \times 1$ ， PWConv_2 的维度是 $C \times C/r \times 1 \times 1$ 。其余字母的含义和全局语义分支相同。最终通过广播加法得到特征通道加权聚合向量，如式 3.10 所示：

$$G(x^t) = \sigma(g(x^t) \oplus \mathcal{L}(x^t)) \quad (3.10)$$

最终设计的通道注意力聚合门的结构如图 3.9 所示：




图 3.9 通道注意力聚合门结构图

Fig. 3.9 Structure of channel attention aggregation gate

3.3 损失函数设计

本章设计的高分辨率全尺度特征提取网络采用多任务学习的方式训练，本节对所使用的标签平滑交叉熵损失函数和难样本挖掘三元组损失函数展开介绍。其中，前者能够有效地缓解分类任务训练中的过拟合问题，而后者可以挖掘行人的类内关系和类间关系，从而提升行人重识别性能。

3.3.1 标签平滑交叉熵损失函数

交叉熵（Cross Entropy, CE）损失函数是分类任务中常用的一种损失函数。设共有 N 个样本，第 i 个样本的真实标签为 y ， p_i 是模型第 i 个样本，则交叉熵损失函数可由式 3.11 计算：

$$L_{CE} = \sum_{i=1}^N -q_i \log(p_i) \begin{cases} q_i = 0, y \neq i \\ q_i = 1, y = i \end{cases} \tag{3.11}$$

行人重识别本质上是一个检索问题，但是在有监督行人重识别训练时，通常将其视作在训练集上进行分类学习的任务；而在测试推理阶段，才利用网络提取到的特征向量进行相似度匹配计算。此外，由于行人重识别的训练集和测试集没有重合的行人，又可以看作一种特殊的零次学习（Zero-Shot Learning, ZSL）任务，因此防止网络在训练阶段对训练集产生过拟合显得尤为重要。

Szegedy 等提出标签平滑 (Label Smoothing, LS) [83] 技术来防止分类任务过拟合。其核心思想是调整交叉熵中的系数 q_i ，如式 3.12 所示：

$$q_i = \begin{cases} 1 - \frac{N-1}{N} \varepsilon, & \text{if } i = y \\ \frac{\varepsilon}{N}, & \text{其他} \end{cases} \tag{3.12}$$

其中 ε 是一个小常数，通常设为0.1，其作用是软化交叉熵函数，降低模型对训练集结果的置信程度，从而减轻训练阶段过拟合的现象。

本章实验中交叉熵损失均采用带标签平滑的交叉熵损失函数。如图 3.10，AvgPool 前的特征图对应图 3.5 中最后升维得到的特征，随后经过全局平均池化 (Global Average Pooling, GAP) 得到特征向量，然后经过批归一化 (Batch Normalization, BN) 和全连接 (Fully Connection, FC) 操作，式 3.12 中的 q_i 对应全连接层的输出。




图 3.10 HROSNet 输出层结构
Fig. 3.10 Output layers structure of HROSNet

3.3.2 难样本挖掘三元组损失函数

在实际场景中，由于拍摄角度、光照条件、姿态变换等因素，同一个行人在不同摄像头下或者不同时间拍摄到的图片可能有较为明显的差异；而不同行人由于衣着等原因，可能表观特征较为相近，这样的现象给行人重识别算法带来了巨大的挑战。因此在行人重识别问题中，如何有效地挖掘行人的类内关系和类间关系是提升算法性能的关键。

三元组损失函数是一种度量损失函数，最早应用在人脸识别当中，其原理是尽可能拉近同一个 ID 不同样本之间的特征空间距离、拉远不同 ID 之间的特征空间距离。这也非常契合行人重识别的问题特性。

设有锚点样本 x_i^a 、正样本 x_i^p 和负样本 x_i^n 构成一个三元组，其中正样本与锚点

样本类别相同，负样本与锚点样本类别不同。训练集中所有三元组集合为：

$$\forall (x_i^a, x_i^p, x_i^n) \in \mathcal{T} \quad (3.13)$$

设模型提取的特征向量为 $f(x) \in \mathbb{R}^d$ ，则三元组损失期望满足式 3.14 的关系：

$$D(f_\theta(x_i^a), f_\theta(x_i^p)) + m < D(f_\theta(x_i^a), f_\theta(x_i^n)) \quad (3.14)$$

其中 m 是正负样本对特征距离差异的边界值 (margin)， D 表示距离函数，通常可以使用欧氏距离，此时，上式即为：

$$\|f(x_i^a) - f(x_i^p)\|_2^2 + m < \|f(x_i^a) - f(x_i^n)\|_2^2 \quad (3.15)$$

三元组损失函数可以表示为式 3.16 所示：

$$L_{tri}(\theta; X) = \sum_{i=1}^P \sum_{a=1}^K [m + D(f_\theta(x_i^a), f_\theta(x_i^p)) - D(f_\theta(x_i^a), f_\theta(x_i^n))] \quad (3.16)$$

其中 P 是每个训练批次中随机采样的行人 ID 数量， K 是每个行人 ID 随机采样的样本数，因此一个批次共有 $P \times K$ 张图片。

虽然从理论上分析，三元组损失能够保证拉近特征空间距离正样本之间的距离、拉远负样本之间的距离，然而，由于三元组的选取导致数据分布并不一定均匀，从而导致训练过程不够稳定，造成收敛缓慢，甚至不收敛。

Hermans 等^[84]研究了在行人重识别任务中使用不同三元组策略的训练效果，结果发现，使用难样本挖掘三元组损失函数效果最好，其计算式如式 3.17 所示：

$$L_{BHtri}(\theta; X) = \sum_{i=1}^P \sum_{a=1}^K [m + \overbrace{\max_{p=1 \dots K} D(f_\theta(x_i^a), f_\theta(x_i^p))}^{\text{最难正样本}} - \underbrace{\min_{\substack{j=1 \dots P \\ n=1 \dots K \\ j \neq i}} D(f_\theta(x_i^a), f_\theta(x_i^n))}_{\text{最难负样本}}]_+ \quad (3.17)$$

本章实验中三元组损失函数均采用难样本挖掘三元组损失函数，其输入是图 3.10 中经过全局平均池化得到的特征。

3.4 实验分析

本节将使用前文介绍的 Market1501、DukeMTMC-reID、MSMT17 三个数据集展开实验和分析。首先介绍本文设计的高分辨率全尺度特征提取模型参数的设置：

其次设计了一些参数优化实验对本文模型中的超参数进行优化设定；再次，考虑到本章工作的主要创新点在于提出了全尺度注意力特征网络的结构，设计了专门的消融实验以验证全尺度注意力架构对于特征提取性能的作用，证明本章创新性工作的有效性；最后与主流方法进行对比，以证明本章提出的 HROSNet 作为基础骨架网络在源域数据上的性能，以判断是否适合作为跨域重识别模型的源域预训练网络。

3.4.1 实验设置

实验中采取行人重识别常用的数据预处理过程。首先将所有行人图片尺寸都调整至 256×128 ；然后进行数据增强，包括边缘像素填充、随机水平翻转、随机擦除；最后将像素值调整到区间 $[0,1]$ ，并在 R、G、B 三个通道上分别减去 0.485、0.456、0.406，并分别除以 0.229、0.224、0.255，做归一化处理。

模型参数优化采用随机梯度下降 (Stochastic Gradient Descent, SGD) 算法，使用 Nesterov 动量^[85]，动量值为 0.9。学习率初始值设为 0.065，并采取预热训练的策略，即训练前 2000 个 mini-batch 的时候，学习率从 0.0065 线性增加至 0.065；接着采取阶梯式下降的学习率衰减策略，即在第 150、225、300 个迭代周期时，将学习率衰减 0.1 倍；训练最大迭代次数为 350。整个网络参数的权重衰减值为 $5e-4$ 。

实验基于 PyTorch^[86]框架和 FastReID^[87]行人重识别工具库编程实现，训练时使用一块 NVIDIA RTX 2080TI。由于本文重新设计了网络结构，因此没有在 ImageNet 上预训练网络的过程，整个模型从随机初始化开始直接在行人重识别数据集上训练。其中，全连接层权重初始化采用 Xavier 方法^[88]，卷积层权重初始化采用 Kaiming 方法^[89]。

由于使用了三元组损失函数，因此输入数据的随机采样策略需要围绕行人 ID 进行设计。默认数据随机采样行人 ID 数 P 和 K 分别设为 16 和 4，即每个 mini-batch 中共有 64 张图片。网络的总损失函数计算如式 3.18 所示：

$$L = L_{LSCE} + \alpha L_{BHtri} \quad (3.18)$$

其中 α 是损失函数组合系数。完整的模型训练流程如表 3.1 所示：

表 3.1 模型训练流程

Table 3.1 Model training procedure

算法 3.1 多尺度注意力特征提取网络训练流程	
输入：当前迭代次数 <i>i</i> 、最大迭代次数 I_{max} 、每个批采样的行人 ID 数 <i>P</i> 、每个行人 ID 采样数 <i>K</i> 、数据集 <i>T</i> 、模型 <i>M</i>	
输出：最佳模型 <i>M</i> *	
1:	for <i>i</i> from 1 to I_{max} do:
2:	随机从 <i>T</i> 中采样 <i>P</i> 个行人 ID，每个 ID 随机采样 <i>K</i> 个样本，组成大小为 $B = P \times K$ 的 mini-batch;
3:	输入固定尺寸 256×128，数据增强;
4:	mini-batch 送入模型 <i>M</i> ，前向传播，分别计算 L_{LSCE} 、 L_{BHtri} ;
5:	计算总损失 $L = L_{LSCE} + \alpha L_{BHtri}$;
6:	SGD 更新模型 <i>M</i> ，得到 <i>M</i> *
7:	end for.

3.4.2 模型参数设置

本节将使用 Market1501 数据集对 HROSNet 的深度、输出特征向量的维度、损失函数组合系数 α 、mini-batch 中行人 ID 数量等参数进行探究。

1) HROSNet 深度

为了找到最佳的高分辨率全尺度网络结构以及模型参数数量的组合，本文设计了三种深度不同的网络，按照网络阶段数量的不同，分别将它们称作 HROS-2s、HROS-3s 和 HROS-4s。其中，三种网络的第一阶段结构都是相同的，采用与 ResNet 中相同的 Bottleneck 设计，特征通道数为 64；而从第二阶段开始，每个阶段新增一条分支，每个分支由若干高分辨率模块组成，每个高分辨率模块又由 2 个全尺度特征提取模块串联构成。每个阶段详细的特征通道数和高分辨率模块的数量如表 3.2 所示，其中#channel 表示每个阶段中特征图的特征通道数，#module 表示高分辨率模块的数量。

表 3.2 高分辨率全尺度网络参数设置

Table 3.2 Parameter settings of HROSNet

网络名称	HROS-2s		HROS-3s		HROS-4s	
	#channel	#module	#channel	#module	#channel	#module
stage1	64	1	64	1	64	1

表 3.2（续） 高分辨率全尺度网络参数设置

Table 3.2 Parameter settings of HROSNet

网络名称	HROS-2s		HROS-3s		HROS-4s	
	#channel	#module	#channel	#module	#channel	#module
stage2	64,128	2	64,128	2	64,72	1
stage3	-	-	64,128,256	4	64,72,144	4
stage4	-	-	-	-	64,72,144,256	3
参数量	708.4K		5.7M		16.0M	

默认输出特征维度设为 512。三种不同深度配置的实验结果如表 3.3 所示：

表 3.3 HROSNet 深度实验结果

Table 3.3 Experiment results on the depth of HROSNet

网络名称	R1	mAP
HROS-2s	87.5	72.4
HROS-3s	94.7	85.7
HROS-4s	93.3	82.8

从表中可以看出，当阶段数为 2 时，虽然网络参数量极小，但网络显然深度不足，无法提取足够强大的行人语义表征；当阶段数为 3 时，网络的性能与参数量达到了最佳平衡；而当阶段数为 4 时，虽然参数量几乎是 HROS-3s 的三倍，但网络性能反而出现了下降，由此可以分析为模型对任务产生了过拟合。因此在接下来的实验中，都默认使用 HROS-3s 的配置。

2) 输出特征向量维度

现有的行人重识别特征提取网络大多基于 ResNet 模型，通常输出特征维度设为 2048；而 OSNet 输出特征维度是 512。由此可见，对于不同的网络结构，可能存在最适合的输出特征维度。本文将输出维度设为 512、1024、2048 进行实验探究，其结果如表 3.4 所示：

表 3.4 HROSNet 输出特征向量维度实验结果

Table 3.4 Experiment results on the output feature dimension of HROSNet

输出特征向量维度	R1	mAP
512	94.7	85.7
1024	93.6	84.2
2048	93.7	84.6

从表中可以看出，当输出特征向量维度为 512 时，取得了最佳效果；而当输出为 1024 或 2048 维时，性能均出现下降。因此，HROSNet 实验的输出特征维度均设为 512。

3) 损失函数组合系数 α

在训练 HROSNet 时同时使用了交叉熵和三元组损失函数，其中，前者用于引导网络完成分类任务，而后者是一种度量损失，二者的监督任务不同。为了取得最佳的多任务学习结果，对式 3.19 中组合系数 α 的取值进行实验探究，其结果如表 3.5 所示：

表 3.5 损失函数组合系数 α 实验结果
Table 3.5 Experiment results on the combination coefficient of loss function

α	R1	mAP
0	93.5	82.9
1	94.7	85.7
2	94.1	84.5
3	93.8	83.8

从表中可以看出，当 $\alpha = 0$ ，即只使用交叉熵函数时，效果最差；而当 $\alpha = 1$ 时，Rank1 和 mAP 都取得了最佳效果，这说明使用三元组损失函数可以有效地提升行人重识别算法性能，尤其是 mAP 从 82.9%增长到 85.7%；当 α 的数值继续增加时，效果呈递减趋势。通过实验可以得出结论，三元组损失的权重系数不宜过大。本文后续的实验都令 $\alpha = 1$ 。

4) mini-batch 中行人 ID 数量

在利用难样本三元组损失训练时，mini-batch 中行人 ID 采样的数量对于结果有一定影响。为了获得最佳的 mini-batch 中行人 ID 数量 P 与每个行人图片数 K ，本文针对不同组合进行了探究，其结果如表 3.6 所示：

表 3.6 mini-batch 中行人 ID 数量实验结果
Table 3.6 Experiment results on the person ID numbers in a mini-batch

P	K	R1	mAP
16	4	94.7	85.7
8	8	93.1	82.2
4	16	87.6	70.0

从表中可以看出，当批大小为 64 时，当行人 ID 数 P 为 16 时，效果最好；当

$P = 8$ 时，效果略有下降；而当 P 减小为4时，性能出现大幅下降。

图3.11展示了Market1501训练集上单个行人ID拥有的图片数量统计直方图，横坐标是单个行人ID图片数量，纵坐标是统计频数。从图中可以看出，大多数图片的数量集中在5~30张之间。在mini-batch采样时，如果同一行人未采足 K 张图片，则随机复制该行人图片补足。由于训练集中的同一行人存在较为相似的图片，因此可能造成正样本的距离接近0，从而导致类内间距难以监督优化。因此当批大小一定时，每个行人图片数 K 不宜过大。本章剩余实验中，保持 $P = 16$ 、 $K = 4$ 。




图 3.11 Market1501 训练集单个行人 ID 图片数直方图

Fig. 3.11 Histogram of per person ID picture numbers in Market1501 training set

3.4.3 消融实验

本节将在 Market1501、DukeMTMC、MSMT17 三个数据集上对 3.2 节中阐述的多尺度结构的使用、全尺度特征提取模块的使用、注意力机制的使用进行消融实验，以验证本章设计的有效性。其中，多尺度结构对比的基准是基于单尺度 ResNet50 网络提取特征的 BagTricks 方法^[90-91]；全尺度特征提取模块对比的基准是使用 HRNet-18 前三个阶段组成的多尺度网络，本文将其称作 HRNet-18-3s。消融实验结果如表 3.7 所示。

从实验结果可以看出，在加入多尺度结构之后，HRNet-18-3s 只用三个阶段，性能与包含四个阶段 BagTricks 相比，mAP 在三个数据集上都获得了约 3% 的提升，而 Rank1 在 Market1501 上提升了 0.7%，在 DukeMTMC 上提升了 2.5%，在 MSMT17 上提升超过 4%，这表明，多尺度的网络结构性能优于一般的单尺度网络。

在全尺度特征提取模块和注意力机制的使用方面，未加入注意力机制时，

HROSNet 与基准模型 HRNet-18-3s 相比，Rank1 和 mAP 都分别提高了 1%左右，这表明，加入全尺度特征提取模块的 HROSNet 的多尺度结构设计优于原始的 HRNet-18-3s。而在加入了注意力机制后，HROSNet 的性能又得到了进一步提升。

表 3.7 多尺度注意力特征提取消融实验
Table 3.7 Ablation study on multi-scale attention feature extraction

网络名称	Market1501		DukeMTMC		MSMT17	
	R1	mAP	R1	mAP	R1	mAP
BagTricks	92.6	81.6	84.5	72.7	69.5	44.9
HRNet-18-3s	93.3	84.0	87.0	75.3	73.6	47.5
HROSNet w/o attention	94.4	85.3	87.9	76.5	74.5	48.3
HROSNet w/ attention	94.7	85.7	88.7	76.9	75.8	49.2

为了进一步理解多尺度注意力特征提取对行人重识别任务的提升，利用 Grad-CAM^[92]技术对基于单尺度的 BagTricks 方法和 HROSNet 的输出特征热图进行了可视化，如图 3.12 所示：




图 3.12 BagTricks 与 HROSNet 输出特征热图可视化对比

Fig. 3.12 Visualization comparison of output feature heatmap between BagTricks and HROSNet

从热图中可以看出，BagTricks 在行人各部位的响应强度较为平均，这表明其

无法有效地提取行人显著信息；BagTricks 在一些背景区域也拥有较高的响应，这表明其不能很好地关注行人本身，在提取行人特征时容易受到背景噪声的干扰。相比之下，HROSNet 在不同尺度的行人输入时，其响应热区集中在行人身上的具有显著特点的区域，例如挎包、手提篮、花裙等，且背景区域几乎无响应，这表明 HROSNet 在多个尺度下具有良好的行人显著特征表征性，且对于嘈杂背景具有良好的鲁棒性。这进一步印证了本文多尺度和注意力设计的有效性。

3.4.4 与当前主流方法的对比

HROSNet 与当前主流方法在 Market1501、DukeMTMC、MSMT17 三个数据集上取得了具有竞争力的结果，对比结果如表 3.8 所示。

表 3.8 HROSNet 与当前主流方法对比
Table 3.8 Performance comparison between HROSNet and SOTA methods

方法	出处	参数量 (M)	Market1501		DukeMTMC		MSMT17	
			R1	mAP	R1	mAP	R1	mAP
ImageNet 预训练								
DPFL ^[13]	ICCVW17	>6.8	89.4	72.6	79.2	60.6	-	-
GLAD ^[25]	ACMMM17	>6.8	89.9	73.9	-	-	61.4	34.0
PCB ^[21-22]	ECCV18	27.2	93.8	81.6	83.3	69.2	68.2	40.4
IANet ^[27]	CVPR19	>23.5	94.4	83.1	87.1	73.4	75.5	46.8
BagTricks ^[90-91]	CVPRW19	23.5	94.5	85.9	86.4	76.4	-	-
Auto-ReID ^[94]	ICCV19	13.1	94.5	85.1	-	-	78.2	52.5
OSNet ^[16-17]	ICCV19	2.2	94.8	86.7	88.7	76.6	79.1	55.1
随机初始化训练								
MobileNetV2 ^[95]	CVPR18	2.2	87.0	69.5	75.2	55.8	50.9	27.0
HA-CNN ^[26]	CVPR18	4.5	91.2	75.7	80.5	63.8	-	-
Auto-ReID ^[94]	ICCV19	13.1	90.7	74.6	-	-	-	-
BagTricks* ^[90-91]	CVPRW19	23.5	92.6	81.6	84.5	72.7	69.5	44.9
OSNet ^[16-17]	ICCV19	2.2	93.6	81.0	84.7	68.6	71.0	43.3
HRNet-18* ^[81]	PAMI20	19.2	94.2	85.5	89.2	77.4	76.7	52.5
Lite-HRNet-30* ^[96]	CVPR21	16.4	91.2	77.9	83.1	68.8	65.7	36.6
HROSNet	本文	6.5	94.6	85.7	88.7	76.9	75.8	49.2

表 3.8 中，加粗的数据代表最优结果，斜体的数据代表次优结果，打上*号的表示由本研究工作复现的实验结果，其余结果来自原始论文。由于本章设计的 HROSNet 没有预训练模型，所有实验均从随机初始化开始进行，因此我们首先对比从随机初始化开始训练的网络。从结果可以看出，HROSNet 的性能大幅超过了轻量化网络 MobileNetV2、HA-CNN 和 OSNet，同时也超过了 BagTricks、Lite-HRNet-30 等参数量比较大的网络；而和 HRNet-18 相比，HROSNet 用三个阶段、约三分之一的参数量在三个数据集上超过或达到了类似的性能。以上结果证明了 HROSNet 在从随机初始化开始的网络中拥有优异的性能。图 3.13 展示了 HROSNet 与其他从随机初始化开始的网络方法的对比气泡图，其中，横坐标表示 Rank1、纵坐标表示 mAP、气泡的大小表示网络模型的参数量。从图中能够看出，HROSNet 在 Rank1、mAP 性能优异的同时，还拥有较小的参数量，在性能和参数量二者之间达到了平衡。




图 3.13 Market1501 上 HROSNet 与主流方法对比气泡图
Fig. 3.13 Bubble diagram of HROSNet and SOTA on Market1501

在和基于 ImageNet 网络预训练的模型进行对比时，HROSNet 的性能也超过了一些具有更大参数量的网络，包括基于多尺度特征提取方法的 DPFL、基于注意力机制的 GLAD、PCB 和 IANet 等，这表明 HROSNet 在于预训练模型方法比较中也

处于较高水平。值得注意的是, HROSNet 性能优于从初始化开始训练的 Auto-ReID 和 OSNet, 但在与二者基于 ImageNet 预训练的版本进行对比时, HROSnet 在三个数据集上的性能并不总是最好的, 这也说明了预训练和迁移学习在深度学习中的重要性。

3.5 本章小结

本章首先阐述了行人重识别应用中存在的行人尺度和背景干扰等问题; 接着针对这些问题, 设计了基于多尺度特征提取方法和注意力机制的 HROSNet 网络, 以及对应的损失函数。在实验阶段, 首先对实验中一些超参数进行了介绍; 然后进行对比实验以确定了最优的模型参数设置; 接着针对多尺度结构、全尺度特征提取、注意力机制等设计进行了消融实验, 以验证每一部分设计的有效性; 最后将 HROSNet 与当前主流方法进行比较, 对比发现 HROSNet 在性能和参数量规模上达到了良好的平衡, 这为跨域自适应学习方法提供了一种高效的网络结构。

第4章 基于聚类伪标签与自步学习的自适应跨域行人重识别方法

跨域行人重识别方法

4.1 引言

域差异问题是机器学习领域一个典型性问题。由于行人重识别在训练中无法事先预知测试时的具体行人，因此，行人重识别不但可以视为一个细粒度检索问题，在测试时又可以看作零样本学习问题，因此，域差异问题在行人重识别领域中的体现尤为明显。

图 4.1 列出了来自三个不同数据集的行人图片示例。从图上可以明显看出，这些图片无论在光照、分辨率、拍摄角度、行人衣着、图片背景等方面都有显著的差异。这直接导致了在一个数据集场景中训练的模型，直接应用在新的场景中使用时，性能指标会出现断崖式的下降。这极大阻碍了行人重识别在实际生活中的应用。



图 4.1 数据集域差异示例^[29]

Fig. 4.1 Illustration of dataset domain gaps

通过大规模带标注的数据集训练是解决上述问题的一种可能途径。然而，行人重识别数据集的标注需要耗费大量的人力，所以当前广泛使用的行人重识别数据集规模还相对较小，利用深度网络训练的模型容易在这些数据集上过拟合。表 4.1 对比了当前常用的行人重识别数据集与 ImageNet2012 的训练集规模，其结果可以

看出，和图像分类任务常用的 ImageNet2012 相比，行人重识别数据集的训练集无论在图片总数量、还是在平均每一类的图片数量上都相差甚远，这就极大限制了基于某一个数据集训练的模型的泛化能力；然而另一方面，利用较为成熟的行人检测跟踪算法大规模采集无标签的行人数据是可能的，因此利用目标域场景下采集的无标注行人数据对源域场景下的预训练重识别模型进行跨域学习具有巨大的研究价值和实用价值。

表 4.1 行人重识别数据集与 ImageNet2012 训练集规模对比
Table 4.1 Comparison on training set scales between person ReID datasets and ImageNet2012

数据集	Market1501	DukeMTMC	MSMT17	ImageNet2012
图片总数	12936	16522	32621	1281167
类别数	751	702	1041	1000
平均每类图片数	17.2	23.5	31.3	1281.2

近年来，基于无监督的行人重识别跨域算法得到了较为广泛的关注，主要研究途径分为两种：（1）利用 GAN 网络对不同数据域的分布进行学习，并期望缩小源域和目标域之间的域偏移；（2）利用聚类等方式，生成目标域伪标签，接着迭代地进行自监督训练和伪标签生成的过程，直至模型收敛。二者最大的区别在于，前者训练通常是非端到端的过程，这样极大地增加了行人重识别的任务复杂程度；而后者可以进行端到端的训练。

本章将主要采样基于聚类的伪标签策略，在第 3 章介绍的多尺度注意力特征提取方法基础上，对行人重识别跨域学习方法开展具体研究。

4.2 自适应跨域基准策略

自适应训练是解决跨域问题的一种常用方式。如图 4.2，在行人重识别跨域问题中通常使用的一种基准策略是，首先在有标签源域 $\mathcal{D}_s$ 上利用有监督算法预训练一个初始模型 M_0 ；然后在无标签目标域 $\mathcal{D}_t$ 上提取所有样本的特征，并利用这些特征进行聚类，得到伪标签；接着利用伪标签数据集进行自监督训练，并更新模型。特征提取-聚类-自监督训练-更新模型的过程不断地迭代进行，直至模型收敛。值得注意的是，在生成伪标签数据集时，我们忽略离群的样本点，即离群样本不参与自适应训练；而在每次得到伪标签以后，由于每次迭代时伪标签的数量和语义都会发生变化，因此在每次聚类生成伪标签之后，都要重新初始化网络分类输出层的权值。跨域自适应基准策略训练流程见表 4.2：

表 4.2 自适应跨域基准训练流程

Table 4.2 Self-adaptation cross-domain baseline training procedure

算法 4.1 自适应跨域基准训练算法	
输入：当前迭代次数 i 、最大迭代次数 I_{max} 、每个批采样的行人 ID 数 P 、每个行人 ID 采样数 K 、目标域数据集 $\mathcal{D}_t$ 、源域预训练的初始模型 M_0	
输出：最佳模型 M^*	
1:	for i from 1 to I_{max} do:
2:	提取目标域所有样本特征;
3:	基于样本特征聚类, 忽略离群样本, 生成伪标签数据集;
4:	初始化模型分类输出层权重;
5:	随机从 T 中采样 P 个行人 ID, 每个 ID 随机采样 K 个样本, 组成大小为 $B = P \times K$ 的 mini-batch;
6:	输入固定尺寸 256×128 , 数据增强;
7:	mini-batch 送入模型 M , 前向传播, 计算损失值;
8:	更新模型 M , 得到 M^* ;
9:	end for.




图 4.2 自适应跨域基准策略示意图

Fig. 4.2 Illustration of self-adaptation cross-domain baseline training strategy

4.3 基于聚类的伪标签生成

在自适应跨域策略的每个迭代循环的开始，都需要利用当前最佳模型对目标域数据集 $\mathcal{D}_t$ 提取特征，然后利用聚类算法生成伪标签。常用的聚类算法可以分为四类：划分法（partitioning approach）、层次法（hierarchical approach）、基于密度的方法（density-based approach）和基于模型的方法（model-based approach）。

本文将选择基于密度的聚类方法来对数据集产生伪标签，原因是在行人重识别任务中，无法事先预知到目标域上行人的真实编号数量，因此例如 K-means 等需要指定聚类簇个数的方法就显得不适用了。常见的基于密度的聚类方法有 DBSCAN (Density-Based Spatial Clustering of Applications with Noise)^[97]、HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)^[98]等。

1) DBSCAN

DBSCAN 算法是一种比较有代表性的基于密度的聚类算法，它能够将足够高密度的区域划分成簇，并能在具有噪声的数据空间中发现任意形状的簇。其核心思想是从某个核心点出发，不断向密度可达的区域扩张，从而得到一个包含核心点和边界点的最大化区域，区域中任意两点密度相连。

给定包含 n 个对象的样本集 $\mathbf{X} = \{o_i | i = 1, 2, \dots, n\}$ 、半径 ξ 、最小聚类密度 $minPts$ ，DBSCAN 算法流程如表 4.3 所示：

表 4.3 DBSCAN 算法流程
Table 4.3 DBSCAN algorithm procedure

算法 4.2 DBSCAN 算法流程
输入：样本集 $\mathbf{X}$ 、半径 ξ 、最小聚类密度 $minPts$
输出：聚类结果
1: 将 n 个对象的状态都标记为 0, $i = 1$;
2: 从 $\mathbf{X}$ 中随机选取一个状态为 0 的对象 p ，将其状态更改为 1;
3: 若对象 p 的密度不小于 $minPts$ ，则创建一个新的簇 C_i ，并把 p 加入到此簇中；令集合 $N = neighbor(p, \xi)$ ，对于 N 中的每个对象 q ，做如下操作：
4: 若 q 的状态为 0，改为 1；若 q 是核心点，将其所有 ξ -邻居加入集合 N ；
5: 若 q 不属于已有的任何一个簇 $C_j, 1 \leq j \leq i$ ，将 q 放入 C_i ；
6: 若对象 p 的密度小于 $minPts$ ，标记 p 的状态为 3；
7: 若所有对象的状态都为 1，则输出所有簇，不属于任何簇的对象为离群点，停止算法； 否则，令 $i = i + 1$ ，转第 2 步。

DBSCAN 算法通常使用距离度量来刻画对象的相似性。常用的距离度量方式有：

a) 曼哈顿距离 (manhattan distance):

$$\sum_{i=1}^n |x_i - y_i| \quad (4.1)$$

b) 欧式距离 (euclidean distance):

$$\sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (4.2)$$

c) 闵可夫斯基距离 (minkowski distance):

$$\sqrt[p]{\sum_{i=1}^n (x_i - y_i)^p} \quad (4.3)$$

d) 切比雪夫距离 (chebyshev distance):

$$\max |x_i - y_i|, i = 1, 2, \dots, n \quad (4.4)$$

e) 马氏距离 (mahalanobis distance):

$$\sqrt{(x - y)^T S^{-1} (x - y)} \quad (4.5)$$

其中, S^{-1} 为样本协方差矩阵的逆矩阵。当样本呈独立同分布时, 马氏距离和欧式距离是等价的。由于多尺度特征提取网络的高维输出特征空间并不是规则的, 因此使用欧式距离度量是较好的选择。

虽然 DBSCAN 算法不需要指定簇的个数, 但它对 ξ 、 $minPts$ 等参数比较敏感, 对于高维数据, 采用距离度量时聚类效果一般。

2) HDBSCAN

HDBSCAN 是对 DBSCAN 的一种改进算法, 它将 DBSCAN 转换为分层聚类算法, 其最大的优势在于不用人工选择 ξ 、 $minPts$ 等参数, 因而可以处理密度不同的聚类问题。

HDBSCAN 中定义了一种新的距离度量方式, 称为相互可达距离 (mutual reachability distance)。设有样本集 $\mathbf{X}$, 其中两个样本 x_p 和 x_q 之间的相互可达距离定义如式 4.6 所示:

$$d_{mreach}(x_p, x_q) = \max\{d_{core}(x_p), d_{core}(x_q), d(x_p, x_q)\} \quad (4.6)$$

其中 $d_{core}(\cdot)$ 指核心距离 (core distance), 表示样本 x_p 到其 $minPts$ 个最近邻 (包括 x_p) 所需要的距离。核心距离越大, 表示密度越低; 反之, 核心距离越小, 表示密度越高。相互可达距离对可以拉远密度较低的点之间的距离, 而密度较大的点之间距离影响不大, 因此其作用是生成更易于聚类的样本空间。

将所有样本作为顶点、相互可达距离作为边, 可以形成相互可达图 (mutual reachability graph) G_{mpts} 。显然相互可达图是一个完全图 (complete graph)。设 $G_{mpts, \varepsilon} \subseteq G_{mpts}$ 是 G_{mpts} 去除所有大于 ε 的边得到的子图, 那么这些子图中顶点数量大于等于 $minPts$ 的就是聚类簇, 其余的就是噪点。

为了让提取的簇更加稳定, 首先定义 λ 是距离的倒数, 即:

$$\lambda = \frac{1}{d_{mreach}(x_p, x_q)} \quad (4.7)$$

对于树中的某个节点定义两个量: λ_{birth} 、 λ_{death} , 其中 λ_{birth} 表示分裂产生当前节点时距离的倒数, λ_{death} 表示当前节点被分裂成两个节点时距离的倒数。因此, 若用 λ_p 表示簇 C_i 下各节点 p 从 C_i 分离出去时距离的倒数, 则可以定义如式 4.8 的稳定度指标:

$$S(C_i) = \sum_{p \in C_i} (\lambda_p - \lambda_{birth}) \quad (4.8)$$

在提取簇的时候, 将依据稳定度指标来决定节点对于聚类簇的归属。

在聚类过程中, HDBSCAN 首先计算样本集 X 中所有样本的核心距离, 并基于双向可达距离变换样本的度量空间; 然后计算双向可达图最小生成树 (Minimum Spanning Tree, MST); 接着对变换后的空间进行单链路 (single-linkage) 聚类。HDBSCAN 主要算法流程见表 4.4 所示:

表 4.4 HDBSCAN 算法流程
Table 4.4 HDBSCAN algorithm procedure

算法 4.3 HDBSCAN 算法流程	
输入:	样本集 X 、最小簇大小 $minCluster$
输出:	聚类结果
1:	计算样本集 X 中所有样本的核心距离;
2:	计算样本集 X 中所有样本的相互可达距离, 并形成相互可达图 G_{mpts} ;

表 4.4（续） HDBSCAN 算法流程
 Table 4.4 HDBSCAN algorithm procedure

算法 4.3 HDBSCAN 算法流程
3: 计算 $G_{m_{pts}}$ 的最小生成树 MST;
4: 聚类树压缩, 自上而下遍历聚类树:
5: 若左右子节点有一个样本数 $<minCluster$, 直接删除该节点, 另一个子节点保留父节点聚类标签;
6: 若左右子节点的样本数均 $<minCluster$, 删除两个子节点;
7: 若左右子节点的样本数均 $\geq minCluster$, 保持原聚类树不变;
8: 提取簇:
9: 初始化簇, 将压缩聚类树的每个叶子节点都设为某个簇;
10: 自下而上遍历整棵压缩聚类树:
11: 若当前节点稳定度小于两个子节点的稳定度总和, 则该节点的稳定度设为其子节点稳定度之和; 否则当前节点定为某个簇。

跨域自适应基准策略中所使用的损失函数与第 3 章有监督训练方式类似, 同样也是使用标签平滑交叉熵损失函数与三元组损失函数; 不同的是, 这里损失函数所使用的标签是聚类后得到的伪标签。

4.4 基于自步对比学习的跨域策略

在行人重识别域适应学习过程中, 通常基于一个在源域上预训练过的模型开始在目标域上的域适应训练。这种做法存在一定的局限性。一方面, 由于源域和目标域往往存在较大的域差异, 因此基于源域训练模型提取的初始特征做的聚类结果往往具有很大的噪声, 这给无监督的域适应训练带来了极大的挑战; 另一方面, 这种做法抛弃了宝贵的源域真实标签, 损失了大量潜在可以利用的训练监督信息。针对这个问题, 本文将自步对比学习引入到自适应跨域行人重识别框架中, 通过在域适应训练中同时利用源域和目标域样本, 最大化地利用监督信息。

在自适应跨域基准策略中, 目标域训练时所使用的数据仅仅是属于某个簇的伪标签样本, 而未聚成簇的离群样本则直接丢弃了。这种方式有助于提升自监督训练时标签的可靠性, 但也忽略了大量可用的信息, 尤其是在训练早期, 往往存在大量的聚类离群值, 若简单地将它们丢弃, 那么训练样本将大幅减少, 可能导致模型训练不够稳定, 甚至难以收敛。因此, 我们希望能在训练过程中, 在不影响伪标签

质量的前提下，将离群的样本也包含进来。

本节将详细介绍自步对比学习跨域策略来应对上述的若干问题。

4.4.1 混合记忆库

自步对比学习跨域策略中，为了充分利用源域数据，因此在针对目标域适应性训练的过程中，同时加入源域的样本进行训练。在跨域自适应基准策略中，由于每次聚类产生的伪标签结果不一致，因此在每次聚类后需要重新初始化分类输出层的权值。然而，这样的做法使得网络训练不具有连续性，容易造成训练效果不佳。

为了提升训练过程的连续性，本文使用混合记忆库来存储训练过程中得到的特征。所谓“混合”，即记忆库中同时存储来自源域和目标域的特征，且记忆库中同时包含类中心特征（源域）和样本个体特征（目标域）。混合记忆库中的特征产生与更新过程示意图如图 4.3 所示：




图 4.3 混合记忆库示意图

Fig. 4.3 Illustration of hybrid memory bank

在训练第一次迭代伊始，利用初始模型 M_0 提取源域和目标域所有训练集样本的特征用于初始化混合记忆库。其中，源域的样本数据以类别为单位进行存储，这样可以节省计算空间，且效果更好；目标域的样本数据以实例为单位进行存储，这样可以使得目标域样本即便在聚类簇、离群值不断变化的情况下，仍然能够在混合记忆中找到对应的特征进行连续更新。而除了第一次迭代，接下来任一迭代都基于上一次迭代更新后的混合记忆库特征进行训练。

设源域类中心特征集合为 $\{\mathbf{w}\} = \{\mathbf{w}_k | k = 1, 2, \dots, n^s\}$ 、目标域特征集合为 $\{\mathbf{v}\} =$

$\{v_k | k = 1, 2, \dots, n^t\}$ 、目标域聚类簇中心特征集合为 $\{c\} = \{c_k | k = 1, 2, \dots, n_c^t\}$ 、目标域离群样本特征集合为 $\{u\} = \{u_k | k = 1, 2, \dots, n_o^t\}$ ，目标域样本数为 n^t 。注意， $n^t \neq n_c^t + n_o^t$ 。其中， c_k 的计算如式 4.9 所示：

$$c_k = \frac{1}{|J_k|} \sum_{v_i \in J_k} v_i \quad (4.9)$$

其中， J_k 表示第 k 个聚类簇中所有的样本特征， $|\cdot|$ 表示集合中样本的个数。

源域和目标域记忆库采用不同的动量更新（momentum update）算法，以适应其不同的特性。其中，源域记忆库的更新方式如式 4.10 所示：

$$w_k \leftarrow m^s w_k + (1 - m^s) \cdot \frac{1}{|B_k|} \sum_{f_i^s \in B_k} f_i^s \quad (4.10)$$

其中， B_k 表示当前 mini-batch 中属于源域中第 k 类的行人特征集合； $m^s \in [0, 1]$ 是更新源域特征中心的动量系数，根据相关研究，其值一般设为 0.2； f_i^s 指从源域样本提取到的特征。

由于目标域聚类簇样本 X_c^t 和离群样本 X_o^t 在训练不同迭代阶段一直在变化，因此不能与源域采用同样的动量更新方式。目标域记忆库的更新方式如式 4.11 所示：

$$v_i \leftarrow m^t v_i + (1 - m^t) f_i^t \quad (4.11)$$

其中 $m^t \in [0, 1]$ 是更新目标域的动量系数，一般也设为 0.2。

4.4.2 统一对比损失函数设计

在同时基于源域和目标域进行跨域训练时，设行人特征为 $f = f_\theta(x)$, $x \in X^s \cup X_c^t \cup X_o^t$ ，可以定义如式 4.12 的统一对比损失函数：

$$L_f = -\log \frac{\exp(\langle f, z^+ \rangle / \tau)}{\sum_{k=1}^{n^s} \exp(\langle f, w_k \rangle / \tau) + \sum_{k=1}^{n_c^t} \exp(\langle f, c_k \rangle / \tau) + \sum_{k=1}^{n_o^t} \exp(\langle f, v_k \rangle / \tau)} \quad (4.12)$$

其中 z^+ 表示类别原型（class prototype），其具体表示和 f 相关。若 f 是源域特征，则 z^+ 是 f 所在那一类的特征中心，即 $z^+ = w_k$ ；若 f 是目标域第 k 个簇中样本的特征，则 z^+ 是 f 所在那个簇的特征中心，即 $z^+ = c_k$ ；若 f 是目标域的离群样本特征，则 $z^+ = v_k$ 。 τ 是温度系数， $\langle \cdot, \cdot \rangle$ 表示向量内积， n^s 是源域样本类别数目， n_c^t 是目标域聚类簇数目， n_o^t 是目标域离群样本数目。

从式 4.12 中可以看出，统一对比损失函数同时考虑了三种不同的类别原型，

这样既考虑了不同类别之间的关系,又兼顾了一定的类内关系,这样的设计适用于行人重识别这样的检索任务。此外,混合记忆库与统一对比损失函数的结合,和分类层与交叉熵损失函数的组合在工作机理上具有相似性,可以认为是一种非参数化的分类器。

而在基于源域预训练的模型进行域适应训练时,行人特征为 $\mathbf{f} = \mathbf{f}_\theta(\mathbf{x}), \mathbf{x} \in \mathbf{X}_c^t \cup \mathbf{X}_o^t$,此时统一对比损失函数和式 4.12 相比,删去了源域样本对应的项,如式 4.13 所示:

$$L_f = -\log \frac{\exp(\langle \mathbf{f}, \mathbf{z}^+ \rangle / \tau)}{\sum_{k=1}^{n_c^t} \exp(\langle \mathbf{f}, \mathbf{c}_k \rangle / \tau) + \sum_{k=1}^{n_o^t} \exp(\langle \mathbf{f}, \mathbf{v}_k \rangle / \tau)} \quad (4.13)$$

4.4.3 基于聚类可靠性准则的自步样本选取策略

伪标签使用策略是基于伪标签聚类行人重识别跨域训练方法的核心。利用 DBSCAN 等聚类算法可以很容易的将目标域行人特征划分成簇 $\mathbf{X}_c^t$ 或者离群值 $\mathbf{X}_o^t$ 。然而,在伪标签聚类的过程中,无法保证聚类结果的准确性,即聚类之后,同一个簇中可能包含不同的行人。倘若将包含大量错误伪标签的数据样本投入训练,那么无疑会影响网络训练的准确性和效率。因此,我们需要一种机制来尽可能减少错误伪标签的影响。

自步学习对训练样本由简入难进行选择的思想提供了一种途径。在每个迭代循环伊始重新聚类完成后,可以利用自步可靠性准则保留可靠性较高的聚类簇,其余的均视作离群样本,以此提升伪标签的质量。

可靠的聚类簇应当距离其他簇或者样本足够远的距离;同时聚类簇内部的样本间距离也应当足够小。然而,由于潜在空间样本密度的不一致性,我们不能简单地用类中心、离群样本之间的间距来直接衡量聚类独立性(cluster independence),同样也不能简单地利用距离来直接衡量聚类簇内样本的聚类紧凑性(cluster compactness)。

在聚类的时候,调整聚类算法的超参数可能获得不同的聚类簇结果,倘若放宽聚类标准,那么聚类簇的数量可能减少,每个簇中包含更多的样本;而如果收紧聚类标准,那么聚类簇的数量可能会增加,每个簇中包含更少的样本。通过对比放宽或者收缩聚类标准前后聚类簇结果间的差异,我们可以发现样本间的相对关联程度,从而判定聚类簇的可靠性。

1) 聚类独立性准则

如图 4.4 所示，倘若放宽聚类标准，那么独立性较好的聚类簇将保持原有的结构；而独立性较差的聚类簇可能相互合并，或者与离群点成为一个簇。




图 4.4 聚类独立性示意图

Fig. 4.4 Illustration of cluster independence

设与特征 f_i^t 在同一个聚类簇中的样本为 $\mathcal{J}(f_i^t)$ ，我们可以利用交并比 (Intersection-over-Union, IOU) 来衡量样本 f_i^t 所在聚类簇的聚类独立性 $\mathcal{R}_{\text{indep}}(f_i^t)$ ，如式 4.14 所示：

$$\mathcal{R}_{\text{indep}}(f_i^t) = \frac{|\mathcal{J}(f_i^t) \cap \mathcal{J}_{\text{loose}}(f_i^t)|}{|\mathcal{J}(f_i^t) \cup \mathcal{J}_{\text{loose}}(f_i^t)|} \in [0, 1] \quad (4.14)$$

$\mathcal{R}_{\text{indep}}(f_i^t)$ 越大，那么特征 f_i^t 所在的聚类簇独立性越强；反之，聚类独立性越弱。

2) 聚类紧凑性准则

如图 4.5 所示，倘若收紧聚类标准，那么紧凑性较好的聚类簇将保持原有的结构；而紧凑性较差的聚类簇可能有样本脱离聚类簇，成为离群点或者新的簇。

与聚类独立性准则一样，我们同样可以用交并比来衡量样本 f_i^t 所在聚类簇的聚类紧凑性 $\mathcal{R}_{\text{comp}}(f_i^t)$ ，如式 4.15 所示：

$$\mathcal{R}_{\text{comp}}(f_i^t) = \frac{|\mathcal{J}(f_i^t) \cap \mathcal{J}_{\text{tight}}(f_i^t)|}{|\mathcal{J}(f_i^t) \cup \mathcal{J}_{\text{tight}}(f_i^t)|} \in [0, 1] \quad (4.15)$$

$\mathcal{R}_{\text{comp}}(f_i^t)$ 越大，那么特征 f_i^t 所在的聚类簇紧凑性越强；反之，聚类紧凑性越弱。

设 $\alpha, \beta \in [0,1]$ 分别是聚类独立性和聚类紧凑性阈值。在构建伪标签数据集时，我们只保留 $\mathcal{R}_{\text{indep}} > \alpha$ 且 $\mathcal{R}_{\text{comp}}(f_i^t) > \beta$ 的聚类簇，其他样本点都视作离群值。




图 4.5 聚类紧凑性示意图
Fig. 4.5 Illustration of cluster compactness

3) 基于聚类可靠性准则的自步学习策略

综上，自步对比学习跨域训练算法流程可以总结如表 4.5 所示：

表 4.5 自步对比学习跨域训练算法流程

Table 4.5 Self-paced contrastive learning corss-domain training algorithm procedure

算法 4.3 自步对比学习跨域训练算法流程	
输入：当前迭代次数 i 、最大迭代次数 I_{max} 、每个批采样的伪标签数 P 、每个伪标签采样数 K 、源域数据集 $\mathcal{D}_s$ 、目标域数据集 $\mathcal{D}_t$ 、源域预训练的初始模型 M_0	
输出：最佳模型 M^*	
for i from 1 to I_{max} do:	
1:	if $i == 0$:
2:	提取 $\mathcal{D}_s$ 、 $\mathcal{D}_t$ 所有训练集样本图片特征，初始化特征记忆库；
3:	目标域样本聚类，根据可靠性评价标准筛选可靠聚类，形成伪标签数据集 $\mathcal{D}_t^*$ ；
4:	随机从 $\mathcal{D}_t^*$ 中采样 P 个伪标签，每个伪标签随机采样 K 个样本，组成大小为 $B = P \times K$ 的 mini-batch；
5:	输入固定尺寸 256×128，数据增强；
6:	mini-batch 送入模型 M ，前向传播，计算损失值；
7:	反向传播，更新模型 M ，得到 M^* ，动量更新特征记忆库；
end for.	

4.5 实验分析

本节将使用前文介绍的 Market1501、DukeMTMC-reID 两个数据集展开实验和分析。首先通过实验对自适应跨域基准策略中不同特征聚类方式进行探究，然后进行消融实验，验证本章设计的有效性，最后与主流方法进行对比。

4.5.1 实验设置

数据预处理过程与第3章有监督一致。在参数优化方面，当域适应训练基于源域预训练的模型、不使用源域数据时，使用 Adam^[99] 算法优化模型参数，初始学习率设为 $3.5e-4$ ，迭代 50 个循环，每个循环中随机从伪标签数据集中抽取 400 个 mini-batch，采用阶梯式学习率衰减策略，在第 15、25、35、45 个迭代周期时，将学习率衰减 0.1 倍；而当域适应训练过程中同时利用源域和目标域的数据时，由于此时没有预训练模型，因此需要增加训练迭代次数，模型参数优化采用随机梯度下降算法，使用 Nesterov 动量，动量值为 0.9，学习率初始值设为 0.065，迭代 150 个循环，同样采用阶梯式学习率衰减策略，在第 60、100、120 个迭代周期时，将学习率衰减 0.1 倍。整个网络参数的权重衰减值为 $5e-4$ 。

实验同样基于 PyTorch 框架编程实现，HDBSCAN 基于 McInnes 等^[99-101]的工作实现。当域适应训练基于源域预训练的模型、不使用源域数据时，使用一张 NVIDIA RTX 2080TI，批处理大小设为 64；而当域适应训练过程中同时利用源域和目标域的数据时，使用两张 NVIDIA RTX 2080TI，每张显卡的批处理大小设为 32，总批处理大小保持为 64。

4.5.2 聚类方法测试与分析

本节通过 DukeMTMC→Market1501 和 Market1501→DukeMTMC 两组域适应训练，利用自适应跨域基准策略进行聚类方法探究。*minPts* 设置为 4，即聚类簇最小需要包含 4 个样本；而当 *minPts* 设为更大的数值时，在伪标签训练伊始无法找到足够的聚类簇，训练无法进行。聚类方法探究实验结果如表 4.6 所示。

通过实验可以发现，使用 HDBSCAN 与 DBSCAN 相比，Rank1 和 mAP 分别在 DukeMTMC→Market1501（以下用 D→M 表示）上提升了约 9%、13%，在 Market1501→DukeMTMC（以下用 M→D 表示）上分别提升了 22.8%、19.9%，这表明，HDBSCAN 可以大幅提升行人重识别的性能。

表 4.6 聚类方法实验
 Table 4.6 Experiments on clustering algorithms

聚类方法	DukeMTMC→Market1501		Market1501→DukeMTMC	
	R1	mAP	R1	mAP
DBSCAN	72.8	40.5	41.1	24.1
HDBSCAN	80.3	52.2	63.9	44.0

图 4.6 展示了在 D→M 训练中聚类簇数量变化过程，其中，横坐标表示训练迭代次数，纵坐标表示聚类簇的数量，蓝色线、绿色线分别代表 DBSCAN 和 HDBSCAN 的聚类簇数量变化，红色虚线是 Market1501 训练集中真实的行人 ID 数量，即 751。从图中可以看出，HDBSCAN 的聚类簇数量非常贴近真实行人 ID 数量，而 DBSCAN 的聚类簇数量远远超过真实的行人 ID 数，对比表明，使用 HDBSCAN 可能取得更优的聚类结果，这很可能是其性能提升的重要原因。




图 4.6 DukeMTMC→Market1501 训练中聚类簇数量变化
 Fig. 4.6 Dynamically changing cluster numbers during training on DukeMTMC→Market1501

图 4.7 展示了在 D→M 训练中离群样本数量变化过程，同样，横坐标表示训练迭代次数，纵坐标表示离群样本的数量，蓝色线、绿色线分别代表 DBSCAN 和 HDBSCAN 的离群样本数量变化，注意，由于训练中离群样本的数量变化较大，因此纵坐标使用对数坐标。从图中可以观察到，HDBSCAN 的离群样本数量总体上看

要小于 DBSCAN,这说明在 HDBSCAN 在训练中可以使用更多可靠的伪标签样本,这在一定程度上提升了训练样本的多样性,也是提升性能的另一个可能原因。




图 4.7 DukeMTMC→Market1501 训练中离群样本数量变化
 Fig. 4.7 Dynamically changing outlier numbers during training on DukeMTMC→Market1501

虽然图 4.7 中离群样本数量总体呈下降的趋势,但是当模型收敛时,仍然有较多数量的离群点存在,这表明在训练过程中,还有许多样本没有参与监督优化的过程,这对于行人重识别这样数据本就较为匮乏的任务来说十分不利,因此,设计让离群样本也加入训练的策略十分必要。

4.5.3 消融实验

本节通过 DukeMTMC→Market1501 和 Market1501→DukeMTMC 两组域适应训练为例进行消融实验。跨域训练中涉及的消融变量设置如表 4.7 所示:

表 4.7 跨域训练算法消融实验设置
 Table 4.7 Settings for ablation study on cross-domain adaptation training algorithms

跨域方法	memory	reliable	outliers	tgt_instance	no refresh	src_data
直接跨域						
基准策略						
v1	√					

表 4.7（续） 跨域训练算法消融实验设置

Table 4.7 Settings for ablation study on cross-domain adaptation training algorithms

跨域方法	memory	reliable	outliers	tgt_instance	no refresh	src_data
v2	✓	✓				
v3	✓	✓	✓			
v4	✓	✓		✓		
v5	✓	✓	✓	✓		
v6	✓	✓	✓	✓	✓	
v7	✓	✓	✓	✓	✓	✓

表 4.7 中，直接跨域是指将在源域上训练的模型直接应用在目标域上测试性能；基准策略对应 4.2 节阐述的自适应跨域基准策略；v1~v7 均使用了混合记忆库来存储特征；“reliable”选中代表使用自步可靠性准则筛选出可靠的聚类簇；“outliers”选中代表在域适应训练中将离群样本纳入训练，否则忽略离群样本；“tgt_instance”选中代表目标域样本所对应的记忆库存储的是样本实例的特征，否则是伪标签聚类簇中心特征；“no refresh”选中代表只在第一次迭代时初始化记忆库特征，否则每个迭代开始前重新基于最新的模型提取特征初始化记忆库；“src_data”选中代表将源域数据纳入域适应训练中，即此时不使用预训练的模型，而是直接从随机初始化开始训练模型，否则基于源域预训练的模型在目标域上进行域适应训练。除了 v7 的训练是从随机初始化开始，其余方法都使用第 3 章中的方法在源域预训练的模型，其源域指标见 3.4.4 节。消融实验结果如表 4.8 所示：

表 4.8 跨域训练算法消融实验

Table 4.8 Ablation study on cross-domain adaptation training algorithms

跨域方法	DukeMTMC→Market1501		Market1501→DukeMTMC	
	R1	mAP	R1	mAP
直接跨域	49.8	22.4	24.5	13.7
基准	80.3	52.2	63.9	44.0
v1	84.9	65.4	77.8	61.9
v2	88.5	71.5	80.1	63.7
v3	89.3	75.8	80.5	66.1
v4	81.3	60.8	73.4	54.1
v5	83.8	64.9	74.1	56.1

表 4.8（续） 跨域训练算法消融实验

Table 4.8 Ablation study on cross-domain adaptation training algorithms

跨域方法	DukeMTMC→Market1501		Market1501→DukeMTMC	
	R1	mAP	R1	mAP
v6	89.6	76.6	81.3	66.0
v7	90.1	77.6	83.5	69.3

从表格中可以看出，当使用基于源域预训练的模型直接在目标域上测试时，性能出现大幅下降。其中，在 D→M 时，Rank1 从 88.7%下降到 49.8%，下降了 38.9%；mAP 从 76.9%下降到 22.4%，下降了 54.5%。类似地，Rank1 和 mAP 在 M→D 时分别下降了 70.2%、72%，因此无法在目标域上无法直接使用源域预训练的模型，需要进行域适应训练。基准方法已经能够将 Rank1 和 mAP 在目标域上的指标大幅提升，但是和有监督方法相比还是相差甚远。v1 方法实验结果表明，基于混合记忆库和统一对比损失函数的效果大幅优于基准策略。v2 在 v1 方法基础上，Rank1 可以获得 3%~4%的提升，mAP 在 D→M 可以获得 6%的提升，在 M→D 也提升了 1.8%，这表明利用自步可靠性准则选取伪标签可以有效地提升无监督域适应的性能。而 v3 在 v2 方法的基础上，性能进一步得到提升，尤其是 mAP，在 D→M 和 M→D 时分别提升了 4.3%和 2.4%，这表明将离群样本加入训练，并配合统一对比损失函数，可以提供有效的监督信号，进一步提升性能。然而，观察 v4、v5、v6 的实验结果，可以发现，当混合记忆库中存储目标域实例特征而不是聚类中心特征、且每个迭代开始前重新初始化记忆库时，性能反而出现了较大幅度的下降；而若不重新初始化记忆库，其结果又优于 v3，推测分析是，每次迭代重新初始化目标域实例特征时容易导致训练过程中优化的连续性被破坏，从而影响算法优化收敛。v6 和 v7 方法的对比实验结果表明，在域适应训练中加入源域数据，从随机初始化开始训练 HROSNet 可以获得更好的效果。

4.5.4 与当前主流方法的对比

基于第 3 章设计的 HROSNet，利用自步对比学习跨域策略，与当前主流无监督跨域行人重识别方法在 D→M 和 M→D 两个任务上相比取得了最优的结果，对比结果如表 4.9 所示：

表 4.9 本文方法与当前主流方法对比

Table 4.9 Performance comparison between our method and SOTA methods

方法	出处	DukeMTMC→Market1501		Market1501→DukeMTMC	
		R1	mAP	R1	mAP
PUL ^[102]	TOMM18	45.5	20.5	30.0	16.4
TJ-AIDL ^[103]	CVPR18	58.2	26.5	44.3	23.0
SPGAN ^[32]	CVPR18	51.5	22.8	41.1	22.3
HHL ^[33]	ECCV18	62.2	31.4	46.9	27.2
ARN ^[104]	CVPRW18	70.3	39.4	60.2	33.4
ECN ^[39]	CVPR19	75.1	43.0	63.3	40.4
PDA-Net ^[37]	ICCV19	75.2	47.6	63.2	45.1
CR-GAN ^[35]	ICCV19	77.7	54.0	68.9	48.6
PCB-PAST ^[43]	ICCV19	78.4	54.6	72.4	54.3
SSG ^[40]	ICCV19	80.0	58.3	73.0	53.4
ECN++ ^[105]	TPAMI20	84.1	63.8	74.0	54.4
MMCL ^[106]	CVPR20	84.4	60.4	72.4	51.4
SNR ^[107]	CVPR20	82.8	61.7	76.3	58.1
AD-Cluster ^[38]	CVPR20	86.7	68.3	72.6	54.1
MMT ^[44]	ICLR20	89.5	73.8	76.3	62.3
SpCL ^[46]	NIPS20	90.3	76.7	82.9	68.8
本文方法		90.1	77.6	83.5	69.3

从表中可以看出,本文方法性能大幅超越了基于域转换的 SPGAN、HHL、PDA-Net、CR-GAN 等方法;而在和基于伪标签的方法对比时,本文方法也超越了大多数方法。值得注意的是,基于伪标签策略的 SpCL 方法也同样采用了与本文类似的方法,一个不同点是本文在统一对比损失函数上又加入了三元组损失函数进一步提升伪标签的类内性能;另一个不同点在于,SpCL 基于在 ImageNet 上预训练的 ResNet50 开始训练,而本文基于随机初始化的 HROSNet 训练,在 D→M 上 Rank1 只比 SpCL 低了 0.2%,而 mAP 则超过了 0.9%;在 M→D 上,Rank1 和 mAP 分别提升了 0.6%、0.5%,综合来看,本文方法略优于 SpCL。

4.6 本章小结

本章基于第3章设计的 HROSNet, 针对行人重识别跨域学习问题进行了探究。首先从数据集图片域差异、数据集规模等角度阐述了行人重识别跨域学习的必要性; 然后介绍了行人重识别中广泛使用的自适应跨域基准策略; 接着详细介绍自步对比学习跨域策略, 包括混合记忆库模型、统一对比损失函数、自步可靠性准则等。在实验部分, 首先介绍了跨域实验中的超参数设置; 然后对自适应跨域基准策略中的聚类方法进行了探究; 接着针对4.4节所述的自步对比学习跨域策略, 从自步可靠性准则、离群样本、目标域实例特征存储、特征库更新、源域数据的使用等方面展开进行消融实验, 以确定最优的自步对比学习策略; 最后将本文方法与当前主流方法进行对比, 验证了本文方法的优越性。

第5章 行人重识别系统设计与实现

5.1 引言

前文已经详细介绍了面向跨域的多尺度注意力行人重识别特征提取算法以及跨域学习方法。本章从项目研究需求出发，将上述方法部署到实际场景中，首先介绍行人重识别系统的流程，然后对系统进行实际需求分析，接着对系统整体架构设计展开介绍，并详细阐述系统开发与运行的软硬件环境，最后对系统功能和性能进行测试评估。

5.2 行人重识别系统流程




图 5.1 行人重识别系统检索流程

Fig. 5.1 Retrieval procedure of person re-identification system

如图 5.1，完整的行人重识别系统流程可大致分为四个阶段：

- (1) 场景数据采集：从分布在场景各处的监控摄像头视频流采集原始数据。原始数据的质量受相机分辨率、光照变化等因素的影响；
- (2) 行人检测框生成：为采集到的原始视频数据中的行人标注上检测框，并裁剪出行人图片。由于视频数据量往往规模巨大，因此这个步骤难以完全通过人工完成。通常情况下，该过程可以由行人检测或跟踪算法辅助人工筛选加以完成；
- (3) 行人重识别模型训练：行人重识别算法训练通常会采用特征学习、度量学习等方式。若数据集带标签，则利用有监督算法进行训练；但实际场景中，对所有行人数据进行标注的成本十分高昂，因此可以采用域适应训练的方式，首先在带行人标签标注的数据集上预训练一个行人重识别模型，然后利用无监督域适应算法，基于源域预训练的模型，在无标签的目标域行人数据上进行训练，提升模型在具体场景中的性能；
- (4) 行人检索：即模型训练完成后的推理测试阶段。给定一个待检索的目标行人图片，分别提取该目标图片和行人图像集中所有图片的特征，并进行相似度比对，

按照相似度分数对行人图像集进行排序。

5.3 系统需求分析

5.3.1 系统功能性需求分析

系统功能性需求(Functional Requirement, FR)指系统必须提供的功能及服务。本系统面向视频监控场景安防需求设计,让用户能够实时监控多个场景,并基于行人重识别算法,提供跨场景的行人检索分析功能。具体来说,系统需要具备如下功能:

1) 多路监控视频流实时显示功能

视频显示是视频监控系统最基础的功能。而在实际监控场景中,通常需要同时查看多路实时的摄像头画面,并且提供画面切换的功能,当用户发现异常时,能够及时点击某一路画面单独放大,以更好地观察现场情况,从而预防重大事件发生。

2) 行人检测跟踪功能

在系统实时显示多路监控画面的同时,系统还应当自动检测出画面中出现的所有行人,将检测到的行人结果显示在实时画面上;同时,利用跟踪算法自动为画面中的行人编上序号。检测和跟踪的结果保存在数据库中,为行人重识别算法提供基础的行人数据。

3) 行人重识别功能

该功能是系统的核心。当用户需要使用该功能时,首先从本地上传,或者从监控画面中截取待检索行人图片,接着系统利用行人重识别算法提取该行人的特征,并与行人数据库中的所有行人进行相似度匹配,系统返回若干张相似度最高的结果显示在界面上;同时,通过检索过程返回行人图片所对应的拍摄时间、拍摄地点,可以还原出目标行人在完整监控场景中的行踪轨迹,方便用户做进一步分析。

4) 行人重识别功能

行人数据库用于辅助实现行人重识别功能。在系统实时运行的过程中,需要将行人图片以及抓拍时的信息存入数据库,例如抓拍的时间、抓拍摄像头、行人自动编号等,以便行人重识别检索排序后,返回该行人相关的信息,展示给用户。此外,行人重识别特征提取后得到的高维特征向量同样需要存储在数据库中,供相似度计算时调用。

5.3.2 系统非功能性需求分析

系统的非功能性需求（Non-Functional Requirements, NFR）是系统为了满足用户需求必须具有且除功能需求以外的特性。系统的非功能性需求制约着系统设计，也是系统实际运行时的重要评价准则。行人重识别系统的非功能性需求主要包括：

1) 界面需求

系统界面应当简洁明了，功能按钮、菜单设计等应当清楚划分，让用户能够在经过简单培训，甚至不经培训的情形下快速上手使用。

2) 实时性需求

视频监控要求系统对视频流数据处理达到实时性，而行人检索则要求系统具有较快的响应速度。系统数据库中存储着大量的行人抓拍信息，其中既包括拍摄时间、地点等文本形式的信息，也包括高维特征向量的数值信息，此外还包括行人图片等多媒体信息。

3) 安全性需求

行人监控数据具有隐私性，因此系统需要设置权限等级，保证数据库的访问操作由特定用户进行，而关键数据在存储和传输时需要加密，防止数据被窥视或者篡改，以保证数据安全。

4) 可扩充性需求

行人重识别系统中，涉及到的算法包括对行人的检测、跟踪、重识别特征提取等。随着深度学习理论、计算机视觉算法的飞速发展，更精确、更鲁棒、更高效的算法将不断涌现。为了支撑算法的迭代升级，系统各算法功能模块在接口设计上要采用对象化的设计思想，尽可能降低各功能模块的耦合性；同时应统一算法调用接口，实现算法模型的即插即用。此外，系统功能模块也应考虑可能的摄像头数量扩展需求。

5.4 系统开发与运行环境

5.4.1 硬件平台

本系统硬件平台包含监控摄像头、交换机、网络视频录像机、服务器等设备，本节对上述设备的型号和功能进行介绍。

1) 监控摄像头

系统采用海康威视 DS-2CD3346WD-I 半球型监控摄像头采集实时的监控视频

流，其有效像素值为 400 万，最大分辨率达到 2K，可以拍摄到清晰的监控场景画面。此外，该型摄像头支持 PoE 供电，只需要网线即可同时供电和传输视频。详细的配置如表 5.1 所示：

表 5.1 监控摄像头参数表
Table 5.1 Technical parameter sheet for surveillance cameras

参数名	参数值
传感器类型	1/2.7 英寸 CMOS
最大分辨率	2560x1440
镜头焦距	6mm
有效像素	400 万
宽动态	120dB
最大帧率	25fps
视频编码	H.264、H.265
电源功率	5.5W MAX

2) 交换机

系统采用海康威视 DS-3E0318P-E/M 型交换机，最大输出功率 135W，拥有 16 个百兆 PoE 电口，其中 8 个端口支持最远 250 米远距离传输，可以满足本系统监控摄像头部署的需要。详细配置如表 5.2 所示：

表 5.2 交换机参数表
Table 5.2 Technical parameter sheet for network switch

参数名	参数值
端口	16 个百兆 PoE 电口、1 个千兆电口、1 个千兆光电复用口
处理类型	存储转发
交换容量	7.2Gbps
内部缓存	2.75M
MAC 地址表大小	4K
包转发率	5.36Mpps

3) 网络视频录像机

系统采用海康威视 DS-7832N-K2 型网络视频录像机（Network Video Recorder, NVR），该型 NVR 最大支持 32 路视频输入、16 路视频同步回放，接入带宽达到 160Mbps，最大支持 4K 视频输入，另外还配备了 4T 硬盘，可以满足系统监控视

频存储和回放的需求。详细配置如表 5.3 所示：

表 5.3 NVR 参数表	
Table 5.3 Technical parameter sheet for NVR	
参数名	参数值
视频输入	32 路
接入带宽	160Mbps
视频输出	1 路 HDMI 输出，1 路 VGA 输出
视频分辨率	3840x2160
网络协议	NTP、PPPoE、DHCP
录像回放	同步回放 16 路
录像分辨率	8MP/5MP/4MP/3MP/1080p/UXGA/720p/VGA/4CIF/2CIF/CIF/QCIF

4) 服务器

系统配置了高性能计算服务器用于深度学习模型的推理，其配置如表 5.4 所示：

表 5.4 服务器参数表	
Table 5.4 Technical parameter sheet for server	
参数名	参数值
CPU	Intel® Xeon® E5-2640v4 10 核，主频 3.4G
内存	128G DDR4
操作系统	Ubuntu18.04
GPU	NVIDIA RTX 2080TI 11G

5.4.2 软件平台

为了实现行人重识别系统，本系统在硬件平台的基础之上，基于多款软件平台，编写了一套实时的后端视频流处理、数据库存储程序和前端客户端界面程序，本节将对本系统中采用的软件平台进行介绍。

1) Qt

Qt 是一套完整的跨平台软件开发框架，通过 Qt 可以实现一套代码在所有操作系统、平台和屏幕类型上完成部署，包括台式机、嵌入式系统、可穿戴设备、移动设备等等。在本系统实现的过程中，利用 Qt 实现了客户端软件界面的绘制、与后端服务器通信等功能。利用 QSS 样式，可以统一管理软件界面的样式，提升界面

的美观性和整洁度。

2) Flask

Flask 是一个 Python 编写的轻量级 Web 开发框架,底层基于 Werkzeug 和 Jinja2 实现^[108]。Flask 具有良好的可扩展性,可以通过多种数据库插件存储数据,方便开发者选取;Flask 还内置了开发服务器和调试器,调试方便。本系统利用 Flask 在后端搭建服务,用于响应客户端发送的请求。

3) Kafka

Kafka 最初由 LinkedIn 公司采用 Scala 语言开发,是一个分布式、分区的、多副本、多订阅者、基于 ZooKeeper 协调的分布式消息系统,现已被捐献给 Apache 基金会^[109]。目前,Kafka 已经发展成一个分布式流式处理平台,具有高吞吐、可持久化、可水平扩展、支持流数据处理等多种特性。在本系统中,利用 Kafka 的发布-订阅机制实现了流数据存储系统,用于缓存经算法处理并渲染上处理结果的视频帧,以供后端系统将其推成视频流,最终展示在前端客户端界面上。

4) FFmpeg

FFmpeg 是一套开源的多媒体处理开发框架,其功能十分强大,可以对几乎任意的音视频流实现编码、解码、转码、混流、解复用、推拉流等操作;同时,FFmpeg 可以在多种平台下编译,具有良好的可移植性。本系统后端基于 FFmpeg 将处理完的视频帧推成视频流,供客户端拉取;同时客户端也基于 FFmpeg 拉流,将监控视频展示在界面上。

5) MySQL

MySQL 是最早由瑞典 MySQLAB 公司开发的关系型数据库管理系统,目前属于 Oracle 公司。关系型数据库可以将数据保存在不同的表中,而不是将所有数据放在一个的存储空间内,这样就可以同时提升查询速度和存储灵活性。本系统利用 MySQL 存储抓拍行人图片相关信息。

6) HDF5

HDF5 (Hierarchical Data Format) 是由伊利诺伊大学厄巴纳-香槟分校开发的一种跨平台的数据存储文件,可以用于存储如图像这样的高维数据。HDF5 文件一般以.h5 或者.hdf5 作为后缀名,可以利用 Python、C++函数库读写内容。本系统利用 HDF5 格式存储高维行人重识别向量。

7) TensorRT

TensorRT 是由英伟达 (NVIDIA) 公司开发的一套用于高性能深度学习推理的

SDK, 可以为深度学习提供低延迟、高吞吐率的模型推理加速。对于利用 Caffe^[110]、TensorFlow^[111]、PyTorch 等框架训练好的深度学习模型, 可以直接通过 TensorRT 提供的解析器转换, 或者经过开放式神经网络交换工具 ONNX (Open Neural Network Exchange) 转换后再交给 TensorRT 解析优化。TensorRT 针对 GPU 进行层与张量融合、CUDA 内核自动调整、动态张量显存、多流执行等优化操作, 以最大化模型的推理速度和吞吐。

8) DeepStream

DeepStream 是英伟达公司基于开源多媒体框架 GStreamer 开发的一套 SDK, 用于大规模创建和部署基于 AI 的音视频分析应用程序。DeepStream 以插件的形式与 Gstreamer 原生组件相结合, 为基于深度学习的音视频应用部署提供了完整的解决方案, 其最大的优点是从音视频流的拉取、算法处理、结果帧推流都保持在 GPU 上进行, 减少内存与显存间的数据传输耗时, 从而加速音视频流处理算法的部署性能。

5.5 系统框架设计

系统采用前后端分离架构, 即客户端-服务器架构。其中前端负责交互与展示, 后端实现数据与业务的处理。这种结构在技术上比较成熟, 它充分利用客户端和服务端两端硬件, 将任务分配到客户端和服务端两端, 可以降低系统通讯开销, 具有交互性强、网络通信量低、响应速度快的特点, 利于处理大量数据。而在开发的过程中, 前端开发无需关注后端的实现, 后端开发也无需关心前端的实现, 两者开发可以独立同时进行, 不用担心前后端技术不兼容的问题, 这样分工明确, 有利于提高开发效率。

5.5.1 硬件平台搭建设计

系统硬件平台基于 5.4.1 节介绍的硬件进行搭建, 如图 5.2 所示。由图可以看出, 接入交换机对网络监控摄像头 PoE 供电, NVR 也和交换机相连, 可以对监控视频数据进行长时间存储, 客户机可从 NVR 中查看视频回放。推理服务器获取从 NVR 获取实时的视频流之后, 进行视频帧解码、算法处理、数据存储等操作, 处理结果推送至客户机展示。




图 5.2 系统硬件连接拓扑图

Fig. 5.2 Topological graph of system hardware connections

基于 5.4.1 节所述的硬件平台，以及上述连接拓扑，在室内走廊场景架设了一个包含 14 路摄像头的监控平台，其布局如图 5.3 所示。




图 5.3 监控摄像头布局示意图

Fig. 5.3 Illustration of surveillance camera layout

5.5.2 软件框架搭建设计

系统软件框架基于 5.4.2 节介绍的软件进行搭建，其设计如图 5.4 所示。本系统软件负责实现面向实时视频流的算法处理、数据存储查询、实时结果展示等功能。首先利用 DeepStream 对拉取实时视频流，并解码成为视频帧以供行人检测和跟踪算法处理，得到算法处理结果。其中，检测与跟踪算法输出的结果可视化渲染到原场景帧，并存入 Kafka 对应的 Topic 中缓存，之后用从 Topic 中按时间顺序读取多帧，并使用 GStreamer 将其推成流，供前端 Qt 界面使用 FFmpeg 拉取展示；而截

取的行人图片则交给行人重识别算法提取行人特征向量，行人检测输出、行人图片、特征向量均存入数据库中以供检索；Flask 服务负责响应前端 Qt 界面与数据库的交互检索操作。




图 5.4 软件框架图

Fig. 5.4 Frame diagram of softwares

5.6 系统模块实现

5.6.1 视频解码模块实现

视频解码是系统获取视频流之后的首要任务。视频解码包含软解码、硬解码两种方式。其中软解码指使用 CPU 进行解码，其特点是实现原理简单，开发方便，但处理效率偏低，CPU 负载重；硬解码指使用非 CPU 外设进行解码，例如 GPU、DSP、FPGA、ASIC 芯片等，其特点是性能高、效率高。由于本系统需要同时处理多路实时视频流，为了减轻系统负载，采用硬解码方式。视频解码模块基于 Gstreamer 和 DeepStream 插件开发实现，其模块结构如图 5.5 所示。

由图 5.5 可知，视频解码模块主要包含三个基本组件，其中蓝色的是 Gstreamer 容器 uridecodebin 和 queue，绿色的是 DeepStream 插件 Gst-nvstreammux。组件 uridecodebin 内部实现了多种媒体的解码过程，可以自适应地对使用统一资源定位符 (URL) 定位的音视频资源进行解码，包括基于 rtsp、rtmp 协议的网络视频输入、

或者本地的视频文件输入等。插件 `Gst-nvstreammux` 将多路解码后的视频帧混成一个 `batch`，便于深度学习算法批量处理。此外，`Gst-nvstreammux` 还可以对视频帧尺寸进行调整、多路视频帧同步等操作。组件 `queue` 起到队列缓冲的作用，同时，`queue` 还会创建一个新的线程，从而解耦视频解码和后续算法处理任务，提高系统性能。




图 5.5 视频解码模块结构图
Fig. 5.5 Video decode module structure

5.6.2 算法模块实现

本系统中的算法模块包括行人检测、行人跟踪、行人重识别等，软件框架图 5.4 中已经展示了它们在完整视频流处理中所处的位置。算法模块实现的过程主要包括两个步骤，第一步是模型的训练、导出和转换，第二步是模型推理功能实现。

1) 模型的训练、导出和转换




图 5.6 模型转换流程
Fig. 5.6 Model conversion procedure

图 5.6 展示了模型训练、导出与转换的流程。首先基于 `PyTorch` 框架编写模型结构、训练逻辑，并完成训练；然后使用 `PyTorch` 提供的 `torch.onnx` API，将 `PyTorch` 模型导出成为 `ONNX` 模型格式，`ONNX` 是一个用于表示深度学习模型的标准，可

使模型在不同框架之间进行转换；最后，使用 TensorRT 提供的 ONNX parser API，根据系统配置环境，将 ONNX 解析转换为 TensorRT engine，转换成功后，TensorRT runtime 可以直接调用 TensorRT engine，并执行推理过程。

本文行人检测算法基于转换成 TensorRT engine 的 YOLOv4^[111]模型实现，跟踪算法基于 DeepStream 插件 Gst-nvtracker 实现，行人重识别算法的实现过程则是将第 3 章阐述的 HROSNet 转换成 TensorRT engine。

2) 模型推理功能实现

模型推理功能基于 DeepStream 实现，组件连接结构如图 5.7 所示：




图 5.7 算法模型推理

Fig. 5.7 Algorithm model inference

行人检测算法基于 Gst-nvinfer 实现。Gst-nvinfer 是 DeepStream 中专门用于模型推理的插件，能够调用转换生成的 TensorRT engine 文件进行推理。行人检测作为初级检测器（primary detector），接收混成 batch 的解码视频帧以及 batch 元数据 NvDsBatchMeta，输出的元数据类型为 NvDsObjectMeta。

行人跟踪基于 Gst-nvtracker 实现。Gst-nvtracker 则是 DeepStream 中专门用于目标跟踪的插件，可以接收来自上游的图片帧，并将其转换成跟踪算法所需的图片格式。DeepStream 已经实现了基于 IOU（Intersection-Over-Union）、KLT（Kanade-Lucas-Tomasi）、NvDCF（NVIDIA-adapted Discriminative Correlation Filter）三种目标跟踪算法，其各自的特点和适用场景对比如表 5.5 所示。

由于视频监控场景中背景较为复杂，且行人之间容易存在重叠，因此选用 NvDCF 作为行人跟踪的方法，其使用方式是调用编译好的 libnlds_nvdcf.so 库。

行人重识别同样基于 Gst-nvinfer 实现，和行人检测不同的是，行人重识别的输入不是场景帧，而是基于行人检测结果裁剪得到行人图片，因此称作次级特征提取器（secondary feature extractor），而由于行人重识别输出的是高维特征向量，因此输出的 NvDsObjectMeta 中需要加上 NvDsInferTensorMeta 类型的元数据。

表 5.5 Gst-nvtracker 跟踪方法对比
Table 5.5 Gst-nvtracker tracking method comparison

跟踪方法	GPU 负载	CPU 负载	优点	缺点	适用场景
IOU	无	非常低	轻量级	容易受重叠、遮挡干扰	目标无重叠
KLT	无	高	简单场景效果好	CPU 占用率高，容易受表观变化干扰，低速目标难以跟踪	目标与背景差异大、简单场景
NvDCF	中等	低	对部分遮挡、表观变化鲁棒	比 IOU 和 KLT 慢，占用 GPU 资源	多目标、带部分遮挡的复杂场景

行人检测和行人重识别 Gst-nvinfer 插件一些关键的参数配置如表 5.6 所示：

表 5.6 Gst-nvinfer 关键属性配置
Table 5.6 Gst-nvinfer key property settings

属性	行人检测	行人重识别
gie-unique-id	1	2
operate-on-gie-id	-	1
network-type	0: Detector	100: Custom
output-tensor-meta	0=False	1=True
process-mode	1=Primary Mode	2=Secondary Mode

5.6.3 视频推流模块实现




图 5.8 视频推流模块

Fig. 5.8 Video streaming module

推流模块负责将渲染上行人检测跟踪结果的场景帧推成视频流，供客户端界面拉取展示。由于视频数据编码需要消耗较多的计算资源和计算时间，因此本模块

中采用 Kafka 作为缓冲队列，减轻视频解码与算法模块的压力，提升系统稳定性。推流模块实现方式如图 5.8 所示。

由图可知，在 Kafka Broker 中建立一个名为“Video”的 Topic，并划分 14 个 partition。生产者（Producer）是算法模块，每路视频帧渲染上算法结果后都存入其对应的 partition 中，Kafka partition 能够保证图片帧是有序的。消费者（Consumer）Gstreamer RTSP Server 从 partition 中按时间顺序读取视频帧，并将其推成 RTSP 视频流，供前端客户端拉取。

5.6.4 行人数据库实现

行人重识别系统需要构建行人数据库来保存行人相关的信息，以使用户检索查询。本系统中，需要保存的行人信息分成两类，一类是文本信息，主要围绕抓拍到的行人图片进行，包括抓拍到该行人的摄像头编号、该摄像头下行人的编号、行人在图片帧中的位置、抓拍时间戳，以及保存行人图片的路径等；另一类是特征信息，即行人重识别算法提取的高维行人特征。

第一类信息使用 MySQL 数据库进行存储。构建如表 5.7 所示的行人数据库信息表，实际系统运行时存储的数据示例如图 5.9 所示：

表 5.7 行人数据表
Table 5.7 Information table of pedestrians

字段名称	类型	含义
id	int	主键
camID	int	摄像头编号
personID	int	摄像头下行人编号
startX	int	行人起始位置 X
startY	int	行人起始位置 Y
endX	int	行人结束位置 X
endY	int	行人结束位置 Y
time	double	时间戳
imgPath	varchar(30)	行人图片存储路径

id	camID	personID	startX	startY	endX	endY	time	imgPath
1	0	4	427	263	638	651	1603767825 00_4_2021_05_10_11_03_45.jpg	
2	0	5	866	317	1134	913	1603767825 00_5_2021_05_10_11_03_45.jpg	
3	3	5	493	523	1006	1557	1603767825 03_5_2021_05_10_11_03_47.jpg	
4	9	5	461	713	1215	1844	1603767829 09_5_2021_05_10_11_03_49.jpg	
5	2	5	395	688	934	1630	1603767830 02_5_2021_05_10_11_03_50.jpg	
6	12	8	670	692	1183	1615	1603767830 12_8_2021_05_10_11_03_50.jpg	

图 5.9 行人数据库

Fig. 5.9 Algorithm model inference

第二类信息使用 HDF5 存储。行人数据表的主键 id 与特征矩阵的索引值相关联，即 id 为*i*的行人，其特征向量在特征矩阵第*i*行的位置。这样在行人重识别检索返回特征相似度排序后，可以利用排序索引值到行人数据表中找到对应的行人信息，并最终返回给用户。行人数据表和特征矩阵的对应关系如图 5.10 所示：




图 5.10 行人数据表与特征矩阵对应关系

Fig. 5.10 Correlation between pedestrian information table and feature matrix

5.6.5 后端服务响应模块实现

后端服务响应模块基于 Flask 编程实现。Flask 的服务请求遵循 RESTful API 方式设计。REST（Representational State Transfer）是一种针对网络应用的设计开发架构风格，可以降低系统开发的复杂性、提高系统的可伸缩性。RESTFUL 接口围绕网络资源及其动作展开，资源可以是文本、图片等形式。

本系统后端服务的作用是响应前端 Qt 界面发起的行人重识别请求，后端需要根据请求进行行人重识别的操作，包括特征提取、相似度计算、排序等过程，然后将结果返回给前端展示。本系统将该请求过程抽象为 HTTP 的 GET 方法，实现后，请求调用形式如：[server_ip]:<port>/[method_route]，其中，[server_ip]是服务器的 ip 地址，<port>是 Flask 服务的端口号，[method_route]是设计的方法路由。后端设计的方法路由如表 5.8 所示：

表 5.8 RESTful 方法路由
Table 5.8 RESTful method routes

方法路由	方法	返回内容
reid_query	GET, POST	JSON 格式的检索结果
flask_img	GET	.jpg 格式的二进制流

如图 5.11，后端服务响应请求过程如下：reid_query 将待检索行人图片传给后端、或直接使用后端的图片，服务程序完成重识别操作后，将最相似的若干个行人的信息，包括行人编号、摄像头编号、图片路径等信息以 JSON 字符串的形式返回给前端；前端接受到重识别结果后，再发起 flask_img 请求，后端按照图片路径将图片返回给前端，最终显示在界面上。




图 5.11 后端服务响应
Fig. 5.11 Backend serve response

5.6.6 客户端界面实现

本系统客户端界面利用 Qt 实现。首先利用 Qt Designer 绘制界面，然后编写 C++程序完成各组件逻辑的实现，最后利用 qmake 编译生成可执行文件。

1) 行人检测跟踪界面

行人检测跟踪界面主要用于展示实时的监控视频画面。客户端利用 FFmpeg 拉取经算法处理、且渲染上结果的实时视频流，拉取的 RTSP 视频流格式为 rtsp://[server_ip]:<port>/gs，其中，[server_ip]是服务器的 ip 地址，<port>是 GStreamer 推流服务的端口号，每一路处理完成的视频流单独推成一路 RTSP 流。

图 5.12 展示了系统运行时行人检测跟踪界面的实际效果。其中，左侧上方是设备列表，使用 QtreeWidget 实现，显示当前系统中包含可以调用的视频流来源名称；下方是窗口信息，使用 QTableWidgetItem 实现，可以记录主窗口的播放日志；右侧是播放主窗口，可以看到当监控画面中出现行人时，系统会在画面上实时显示行人的检测框、行人 ID 等信息。




图 5.12 行人检测跟踪界面运行效果图

Fig. 5.12 UI demonstration of pedestrian detection and tracking

2) 行人重识别界面

行人重识别界面为用户提供了行人重识别检索的交互逻辑，其运行实际效果如图 5.13 所示：



图 5.13 行人重识别界面运行效果图

Fig. 5.13 UI demonstration of person ReID

左侧上方的设备列表与行人检测与跟踪界面相应的区域一致，右侧的视频流

来源可以是算法实时处理的结果帧，也可以是来自 NVR 的回放视频。左侧中部有“播放”、“暂停”、“检索”、“清空”四个 QPushButton 组件，其中“播放”和“暂停”负责控制视频画面的刷新，当画面暂停时，用户可在画面上手动绘制行人框选中待检索的行人，然后点击“检索”按钮，触发对应的信号槽完成检索过程；“清空”按钮可以清空检索内容，初始化界面。此外，左侧面板还可以通过 QSpinBox 组件修改检索返回数。界面下方展示行人重识别的检索结果，使用 QListWidget 实现，每个检索结果封装成行人检索信息显示控件 reiddisplaywidget 控件进行展示。该控件的设计如图 5.14 所示：




图 5.14 行人检索信息显示控件设计图

Fig. 5.14 The design of pedestrian retrieval information display widget

5.7 自建测试数据集

为了测试行人重识别在系统中的性能，我们利用上述软硬件平台在实际场景中采集了原始视频数据。我们使用 YOLOv4 检测行人，并人工筛选建立了一个行人数据集，自建数据集的统计信息如表 5.9 所示：

表 5.9 自建行人数据集
Table 5.9 Self-built pedestrian dataset

行人身份数	图片数	摄像头数量	检测器	场景
71	13967	14	YOLOv4	室内

为了进行行人重识别任务，我们需要对行人数据集进行训练集、查询集和行人搜索库的划分。首先，随机挑选 35 个行人编号作为训练集；剩余的 36 个行人编号中，我们从每个编号每个摄像头拍摄的图片中随机选取一张放入查询集中，其余图片放入行人搜索库中。划分完成的数据集统计信息如表 5.10 所示：

表 5.10 自建行人数据集划分信息
Table 5.10 Division result of self-built pedestrian dataset

划分	行人身份数	图片数
训练集	35	6747
查询集	36	503
行人搜索库	36	6717

自建数据集行人示例图片如图 5.15 所示：



图 5.15 自建数据集行人示例图片
Fig. 5.15 Sample images of self-built pedestrian dataset

从图 5.15 中可以看出，自建数据集与公开数据集类似，具有拍摄视角多样、光照条件多样、行人姿态多变、行人尺度不一等特点，且存在行人部分遮挡、重叠的情形。而如图 5.16 所示，自建数据集与公开数据集的一个不同之处在于，平均每个行人的图片数量达到了 196.7 张，远远超过了现有的公开行人重识别数据集，这样在很大程度上提升了查全检索行人的难度。因此自建数据集虽然总体规模小于公开数据集，但对于行人重识别算法仍然存在一定挑战性。




图 5.16 自建数据集与公开行人重识别数据集行人平均图片数对比

Fig. 5.16 Comparison of average person images between self-built and public datasets

5.8 系统功能测试评估

5.8.1 行人检测与跟踪性能评估

行人重识别系统的实时运行效率在很大程度上取决于行人检测与跟踪的运行速度。我们基于单张 RTX2080TI 显卡,输入 YOLOv4 的图片帧大小设为 320×512,测试不同数量的实时视频流的处理速度,如表 5.11 所示:

表 5.11 实时视频流处理速率测试

Table 5.11 Speed test on real-time video streams

视频流数量	实时帧率	显存占用	内存占用
4	24.8fps	1929M	3183M
6	22.3fps	2288M	4281M
10	19.0fps	2916M	6330M
14	15.6fps	3186M	7062M

测试时,将网络摄像头的帧率设置为 25fps,每一帧均进行处理。而从表中可以看出,当视频流数量为 4 时,实时帧率达到了 24.8 帧,说明此时系统处理速率几乎与视频原始帧率一致;随着视频流数量的增加,实时帧率出现了一定下降,显存和内存的占用出现了上升。综合考虑实时性、系统资源利用率和算法性能,在系

统运行时,可对视频流进行跳帧处理,以满足系统响应速度的需求。由于条件受限,本系统只测试了至多 14 路实时监控视频流,而若有更多摄像头加入,按照本系统硬件的配置,由于使用单个 NVR 接入视频流数量的限制,可以满足 32 路视频流的处理需求;更多而添加多个 NVR 后,预估能够满足更多路视频流的实时处理需求。

5.8.2 行人重识别性能评估

我们首先基于 HROSNet 网络,直接在自建数据集的训练集上训练,并在测试集上测试算法的准确性,训练配置依照 3.4 节所述进行设置。实验结果如表 5.12 所示:

表 5.12 自建数据集有监督训练结果
Table 5.12 Supervised traning result on self-built dataset training set

数据集	自建数据集	
结果	R1	mAP
	94.4	69.6

从训练结果看出,虽然 HROSNet 在自建数据集上 Rank1 指标为 94.4%,达到了较高的结果,但是 mAP 指标只有 69.6%,这也与我们在 5.7 节中对数据集难度的预估相吻合。

由于自建数据集规模较小,因此我们探究 HROSNet 在从规模较大的公开行人重识别数据集到自建数据集的跨域性能。我们将第 3 章中在 Market1501、DukeMTMC、MSMT17 三个公开行人重识别数据集上训练的 HROSNet 模型直接跨到自建数据集上测试性能,测试结果如表 5.13 所示:

表 5.13 自建数据集直接跨域性能测试
Table 5.13 Cross-domain performance test on self-built dataset

源域	Market1501		DukeMTMC		MSMT17	
结果	R1	mAP	R1	mAP	R1	mAP
	70.9	39.9	83.1	46.2	93.8	71.6

从测试结果中可以看出,直接跨域性能随着源域数据集规模和复杂程度的扩大而增长,其中在 MSMT17 上预训练的模型直接跨域效果在 Rank1 指标上只比直接在自建数据集上训练时低了 0.6%,而 mAP 指标则高了 2%,因此综合来看,性能甚至更好了。

为了测试无监督跨域算法的效果，我们以 MSMT17 为例，利用第 4 章所述的自步学习方法进行域适应训练，其结果如表 5.14 所示。从结果可以看出，虽然第 4 章方法在公开大型数据集上达到了良好的性能，但是在自建的小型数据集上的结果和有监督方式相比还是存在较大的差距。

表 5.14 自建数据集跨域性能测试

Table 5.14 Cross-domain performance test on self-built dataset

训练方法	MSMT17→自建训练集	
	R1	mAP
结果	59.8	39.4

为了充分利用源域数据，我们将 Market1501、DukeMTMC-reID、MSMT17 三个公开行人重识别数据集的所有数据合并成一个大型的数据集，因此源域的数据统计如表 5.15 所示：

表 5.15 源域数据统计

Table 5.15 Statistics for source domain data

数据集	Market1501	DukeMTMC	MSMT17	合并数据集
图片总数	32668	36411	126441	195520
类别数	1501	1812	4101	7414

训练参数配置与 3.4.1 节讲述的基本一致，区别是为了缩短训练时间，批处理大小扩大到 256，使用 4 张 NVIDIA RTX 2080TI 完成训练。将训练好的模型直接在自建数据集上测试，结果如表 5.16 所示：

表 5.16 合并数据集→自建数据集跨域性能测试

Table 5.16 Cross-domain performance test on combined dataset→self-built dataset

训练方法	合并数据集→自建训练集	
	R1	mAP
结果	98.6	86.8

与表 5.12 的测试结果相比，基于合并数据集训练模型的直接跨域效果有了显著提升，尤其是 mAP，与分开训练跨域最优的 MSMT17→自建训练集相比提升了 15.2%。综上，基于合并数据集训练的 HROSNet 在自建数据集上表现出了良好的性能。

5.9 本章小结

本章主要阐述了行人重识别系统的设计与实现过程。首先介绍了行人重识别系统的工作流程；然后对系统的功能性需求和非功能性需求展开分析；接着介绍系统开发和运行中使用到的软硬件环境平台，以及系统软硬件整体设计；之后逐模块地阐述系统的实现过程；最后介绍自建数据集，并进行了系统的功能测试与评估，结果显示，系统能够满足实时性与准确性的要求。

第6章 结论与展望

6.1 结论

本文针对行人重识别领域研究的两个关键难点问题分别提出了相应的算法。第一章和第二章分别介绍了行人重识别的任务背景和任务相关的基础知识，第三章设计了多尺度注意力特征提取网络进行了有监督行人重识别实验，第四章在第三章基础之上进行了无监督域适应行人重识别方法的探究，第五章将本文研究成果应用于实际行人重识别系统，并进行了实际测试。本文成果主要体现在以下三个部分：

(1) 针对行人重识别任务中不同摄像头下存在的行人尺度差异问题和背景干扰问题，本文基于高分辨率特征提取架构和全尺度特征提取模块设计了高分辨率全尺度特征提取网络 (High-Resolution Omni-Scale Network, HROSNet)，从多个尺度提取行人特征；同时，在全尺度特征提取模块聚合结构中加入通道注意力机制，为同一分辨率不同尺度的特征分配权重，进一步提升特征的鲁棒性。实验结果表明 HROSNet 在算法性能与模型参数量之间达到了平衡。

(2) 针对目标域无标签的跨域行人重识别问题，本文基于聚类伪标签的自适应跨域框架和 HROSNet 探究了面向行人重识别无监督域适应学习方法，提出了一种基于自步对比学习的跨域行人重识别方法，结合混合记忆库与统一对比损失函数，在随机初始化参数的网络上，同时利用有标签的源域数据和无标签的目标域数据，实现重识别模型的域适应学习。实验结果表明，该方法能够在 HROSNet 的特征优势基础上进一步提升跨域识别准确率，其性能基本达到了目前跨域行人重识别的先进水平。

(3) 针对行人重识别系统实际部署的问题，本文基于实际室内场景设计搭建了一套行人重识别软硬件系统，实现了多路实时视频流的拉取、行人检测与跟踪、场景帧算法结果渲染、行人重识别等功能，并基于系统采集构建了一个小型的数据集进行系统功能测试。测试结果表明，本文设计的系统可以达到实时性和准确性的要求。

6.2 展望

虽然本文对行人重识别任务的探索研究取得了一定的成果, 在于当前主流算法对比中具有一定优越性, 但由于时间的限制, 本文研究中还存在一些不足之处, 这也促使我们对未来进一步的研究有了新的思考。

(1) HROSNet 模型虽然在性能上超越了许多同样从随机初始化开始训练的模型, 但和一些基于 ImageNet 预训练的模型相比, 其性能仍然具有一定差距, 因此, 研究无需预训练就能在具体任务中达到先进性能的网络模型是值得未来发展的方向。

(2) 本文无监督域适应方法虽然在与主流行人重识别跨域方法相对比中表现良好, 但与有监督训练方式相比, 性能还是存在一定差距, 尤其是在 mAP 上, 这表明现有的无监督域适应方法对于检索任务还存在一定局限性, 因此下一阶段的工作重点会集中于针对检索任务无监督域适应监督信号的设计上, 通过挖掘类内或类间的关系改进域适应行人重识别的性能。

(3) 针对行人重识别系统实际部署的问题, 虽然本文实现了在具体场景中的部署测试, 但规模还相对有限。在实际应用中, 一方面, 由于监控网络的规模将远远超过现有系统, 因此有必要在设计时考虑使用弹性伸缩架构、高可用系统, 以满足系统扩容和稳定性的需求; 另一方面, 由于行人数据涉及到隐私的问题, 因此数据传输和存储的安全性也应当考虑。未来系统将朝着这两个方面进行改进。

参考文献

- [1] 张中辉. 新型智慧城市建设痛点及解决方案[J]. 中国公共安全, 2020(Z2): 71-73.
- [2] 裴欣欣. AI 赋能视频监控 开启各行业深度应用[J]. 中国安防, 2020(10): 84-86.
- [3] Zajdel W, Zivkovic Z, Krose BJ. Keeping track of humans: Have I seen this person before?[C]//Proceedings of the IEEE International Conference on Robotics and Automation, 2005: 2081-2086.
- [4] Jia D, Wei D, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2009: 248-255.
- [5] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2005: 886-893.
- [6] Matsukawa T, Okabe T, Suzuki E, et al. Hierarchical gaussian descriptor for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1363-1372.
- [7] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2013: 3586-3593.
- [8] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 2197-2206.
- [9] Zheng L, Zhang H, Sun S, et al. Person re-identification in the wild[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1367-1376.
- [10] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [11] Zheng Z D, Zheng L, Yang Y. A discriminatively learned cnn embedding for person reidentification[J]. ACM Transactions on Multimedia Computing, Communications,

- and Applications (TOMM), 2018, 14(1):1-20.
- [12]Guo Y, Cheung NM. Efficient and deep person re-identification using multi-level similarity[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2335-2344.
- [13]Chen Y, Zhu X, Gong S. Person re-identification by deep learning multi-scale representations[C]//Proceedings of the IEEE International Conference on Computer Vision Workshops, 2017: 2590-2600.
- [14]Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]//Proceedings of the 26th ACM international conference on Multimedia, 2018: 274-282.
- [15]Zheng F, Deng C, Sun X, et al. Pyramidal person re-identification via multi-loss dynamic training[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 8514-8522.
- [16]Zhou K, Yang Y, Cavallaro A, et al. Omni-scale feature learning for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 3702-3712.
- [17]Zhou K, Yang Y, Cavallaro A, et al. Learning generalisable omni-scale representations for person re-identification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI), 2021.
- [18]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.
- [19]Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1492-1500.
- [20]Varior RR, Shuai B, Lu J, et al. A siamese long short-term memory architecture for human re-identification[C]//Proceedings of the European Conference on Computer Vision, 2016, 135-153.
- [21]Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European Conference on Computer Vision, 2018: 480-496.
- [22]Sun Y, Zheng L, Li Y, et al. Learning part-based convolutional features for person re-

- identification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI), 2019: 902-917.
- [23] Xu J, Zhao R, Zhu F, et al. Attention-aware compositional network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2119-2128.
- [24] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1077-1085.
- [25] Wei L, Zhang S, Yao H, et al. Glad: Global-local-alignment descriptor for pedestrian retrieval[C]//Proceedings of the 25th ACM international conference on Multimedia 2017: 420-428.
- [26] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification. [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2285-2294.
- [27] Hou R, Ma B, Chang H, et al. Interaction-and-aggregation network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 9317-9326.
- [28] Zhang Z, Lan C, Zeng W, et al. Relation-aware global attention for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 3186-3195.
- [29] Wei L, Zhang S, Gao W, et al. Person transfer gan to bridge domain gap for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 79-88.
- [30] Zhu J, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 2223-2232.
- [31] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2881-2890.
- [32] Deng W, Zheng L, Ye Q, et al. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 994-1003.

- [33]Zhong Z, Zheng L, Li S, et al. Generalizing a person retrieval model hetero-and homogeneously[C]//Proceedings of the European Conference on Computer Vision, 2018: 172-188.
- [34]Choi Y, Choi M, Kim M, et al. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8789-8797.
- [35]Chen Y, Zhu X, Gong S. Instance-guided context rendering for cross-domain person re-identification [C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 232-242.
- [36]Huang Y, Wu Q, Xu J, et al. SBSGAN: Suppression of inter-domain background shift for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 9527-9536.
- [37]Li YJ, Lin CS, Lin YB, et al. Cross-dataset person re-identification via unsupervised pose disentanglement and adaptation[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 7919-7929.
- [38]Zhai Y, Lu S, Ye Q, et al. Ad-cluster: Augmented discriminative clustering for domain adaptive person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 9021-9030.
- [39]Zhong Z, Zheng L, Luo Z, et al. Invariance matters: Exemplar memory for domain adaptive person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 598-607.
- [40]Fu Y, Wei Y, Wang G, et al. Self-similarity grouping: A simple unsupervised cross domain adaptation approach for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 6112-6121.
- [41]Lin S, Li H, Li CT, et al. Multi-task mid-level feature alignment network for unsupervised cross-dataset person re-identification[C]//Proceedings of the 29th British Machine Vision Conference, 2018.
- [42]Zou Y, Yang X, Yu Z, et al. Joint disentangling and adaptation for cross-domain person re-identification[C]//Proceedings of the European Conference on Computer Vision, 2020: 87-104.
- [43]Zhang X, Cao J, Shen C, et al. Self-training with progressive augmentation for

- unsupervised cross-domain person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 8222–8231.
- [44]Ge Y, Chen D, Li H. Mutual mean-teaching: Pseudo label refinery for unsupervised domain adaptation on person re-identification[C]//International Conference on Learning Representations, 2020: 1–15.
- [45]Zhai Y, Ye Q, Lu S, et al. Multiple expert brainstorming for domain adaptive person re-identification[C]//Proceedings of the European Conference on Computer Vision, 2020: 594-611.
- [46]Ge Y, Zhu F, Chen D, et al. Self-paced contrastive learning with hybrid memory for domain adaptive object Re-ID[C]//Advances in Neural Information Processing Systems (NeurIPS), 2020: 11309--11321.
- [47]Lv J, Chen W, Li Q, et al. Unsupervised cross-dataset person re-identification by transfer learning of spatial-temporal patterns[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7948-7956.
- [48]Li J, Zhang S. Joint visual and temporal consistency for unsupervised domain adaptive person re-identification[C]//Proceedings of the European Conference on Computer Vision, 2020: 483-499.
- [49]Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1116-1124.
- [50]Ristani E, Solera F, Zou R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]//Proceedings of the European Conference on Computer Vision, 2016: 17-35.
- [51]Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 3754-3762.
- [52]Felzenszwalb P, Girshick R, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI). 2009, 32(9): 1627-1645.
- [53]Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and

- Machine Intelligence (PAMI). 2016, 39(6): 1137-1149.
- [54] Wang X, Doretto G, Sebastian T, et al. Shape and appearance context modeling [C]//Proceedings of the IEEE International Conference on Computer Vision, 2007: 1-8.
- [55] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2001.
- [56] Viola P, Jones M. Robust real-time object detection[J]. International Journal of Computer Vision (IJCV). 2001, 13(4): 34-47.
- [57] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE Signal Processing Letters. 2016, 23(10): 1499-1503.
- [58] Chen LC, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation[J]. arXiv preprint arXiv:1706.05587, 2017.
- [59] Li Y, Chen Y, Wang N, et al. Scale-aware trident networks for object detection [C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 6054-6063.
- [60] Lin TY, Dollár P, Girshick R, et al. Feature pyramid networks for object detection [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2117-2125.
- [61] Bahdanau D, Cho KH, Bengio Y. Neural machine translation by jointly learning to align and translate[C]//International Conference on Learning Representations, 2015.
- [62] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]//International Conference on Machine Learning, 2015: 2048-2057.
- [63] De S, Colombini EL. ATTENTION, PLEASE! A survey of neural attention models in deep learning[J]. arXiv preprint arXiv:2103.16775, 2021.
- [64] Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7794-7803.
- [65] Wu F, Fan A, Baevski A, et al. Pay less attention with lightweight and dynamic convolutions[J]. arXiv preprint arXiv:1901.10430. 2019.

- [66]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.
- [67]Li X, Wang W, Hu X, et al. Selective kernel networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 510-519.
- [68]Woo S, Park J, Lee JY, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision, 2018: 3-19.
- [69]Park J, Woo S, Lee JY, et al. Bam: Bottleneck attention module[J]. arXiv preprint arXiv:1807.06514. 2018.
- [70]Le-Khac PH, Healy G, Smeaton AF. Contrastive representation learning: A framework and review[J]. IEEE Access, 2020, (8): 193907-193934.
- [71]Oord AV, Li Y, Vinyals O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748, 2018.
- [72]Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//International Conference on Machine Learning, 2020: 1597-1607.
- [73]He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 9729-9738.
- [74]Chen X, Fan H, Girshick R, et al. Improved baselines with momentum contrastive learning[J]. arXiv preprint arXiv:2003.04297, 2020.
- [75]Bengio Y, Louradour J, Collobert R, et al. Curriculum learning[C]//Proceedings of the 26th annual international conference on machine learning, 2009: 41-48.
- [76]Kumar MP, Packer B, Koller D. Self-paced learning for latent variable models[C]//Proceedings of the 23rd International Conference on Neural Information Processing Systems, 2010, (1):1189-1197.
- [77]汪业成. 基于自步学习的兴趣点(POI)推荐技术研究[D]. 2020.
- [78]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//International Conference on Learning Representations, 2015.
- [79]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern

- Recognition, 2017: 4700-4708.
- [80] Yu Q, Chang X, Song YZ, et al. The devil is in the middle: Exploiting mid-level representations for cross-domain instance matching[J]. arXiv preprint arXiv:1711.08106, 2017.
- [81] Wang J, Sun K, Cheng T, et al. Deep high-resolution representation learning for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI), 2020.
- [82] Guo J, Li Y, Lin W, et al. Network decoupling: From regular to depthwise separable convolutions[J]. arXiv preprint arXiv:1808.05517, 2018.
- [83] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.
- [84] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [85] Sutskever I, Martens J, Dahl G, et al. On the importance of initialization and momentum in deep learning[C]//International Conference on Machine Learning, 2013: 1139-1147.
- [86] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library[J]. arXiv preprint arXiv:1912.01703, 2019.
- [87] He L, Liao X, Liu W, et al. FastReID: A Pytorch toolbox for real-world person re-identification[J]. arXiv preprint arXiv:2006.02631, 2020.
- [88] Glorot X, Bengio Y. Understanding the difficulty of training deep feedforward neural networks[C]//Proceedings of the 13th International Conference on Artificial Intelligence and Statistics, 2010: 249-256.
- [89] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 1026-1034.
- [90] Luo H, Gu Y, Liao X, et al. Bag of tricks and a strong baseline for deep person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2019.
- [91] Luo H, Jiang W, Gu Y, et al. A strong baseline and batch normalization neck for deep

- person re-identification[J]. IEEE Transactions on Multimedia, 2019, 22(10): 2597-2609.
- [92] Selvaraju R, Cogswell M, Das A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 618-626.
- [93] Zheng Z, Yang X, Yu Z, et al. Joint discriminative and generative learning for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 2138-2147.
- [94] Quan R, Dong X, Wu Y, et al. Auto-reid: Searching for a part-aware convnet for person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 3750-3759.
- [95] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4510-4520.
- [96] Yu C, Xiao B, Gao C, et al. Lite-HRNet: A lightweight high-resolution network[J]. arXiv preprint arXiv:2104.06403, 2021.
- [97] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining, 1996: 226-231.
- [98] Campello RJ, Moulavi D, Sander J. Density-based clustering based on hierarchical density estimates[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining, 2013: 160-172.
- [99] Kingma DP, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [100] McInnes L, Healy J, Astels S. HDBSCAN: Hierarchical density based clustering[J]. Journal of Open Source Software. 2017, 2(11): 205.
- [101] McInnes L, Healy J. Accelerated hierarchical density based clustering[C]//IEEE International Conference on Data Mining Workshops (ICDMW), 2017: 33-42.
- [102] Fan H, Zheng L, Yan C, et al. Unsupervised person re-identification: Clustering and fine-tuning[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2018, 14(4): 1-8.

- [103] Wang J, Zhu X, Gong S, et al. Transferable joint attribute-identity deep learning for unsupervised person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2275-2284.
- [104] Li YJ, Yang FE, Liu YC, et al. Adaptation and re-identification network: An unsupervised deep transfer learning approach to person re-identification [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2018: 172-178.
- [105] Zhong Z, Zheng L, Luo Z, et al. Learning to adapt invariance in memory for person re-identification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2020.
- [106] Wang D, Zhang S. Unsupervised person re-identification via multi-label classification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 10981-10990.
- [107] Jin X, Lan C, Zeng W, et al. Style normalization and restitution for generalizable person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 3143-3152.
- [108] 刘长龙. Python 高效开发实战: Django、Tornado、Flask、Twisted[M]. 电子工业出版社: 北京, 2016: 268-270.
- [109] 朱忠华. 深入理解 Kafka: 核心设计与实践原理[M]. 电子工业出版社: 北京, 2019: 1-7.
- [110] Jia Y, Shelhamer E, Donahue J, et al. Caffe: Convolutional architecture for fast feature embedding[C]//Proceedings of the 22nd ACM international conference on Multimedia, 2014: 675-678.
- [111] Abadi M, Agarwal A, Barham P, et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems[J]. arXiv preprint arXiv:1603.04467, 2016.
- [112] Bochkovskiy A, Wang CY, Liao HY. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.