

中国科学技术大学

University of Science and Technology of China

硕士学位论文



论文题目 行人重识别中的多尺度特征和

重排序框架研究

作者姓名 袁明月

学科专业 信息与通信工程

导师姓名 尹东 副教授

完成时间 二〇一九年五月

中国科学技术大学

硕士学位论文



行人重识别中的多尺度特征和 重排序框架研究

作者姓名：袁明月

学科专业：信息与通信工程

导师姓名：尹东副教授

完成时间：二〇一九年五月

University of Science and Technology of China
A dissertation for master's degree



Study on Multi-scale Feature and Re-ranking Framework for Person Re-identification

Author: Mingyue Yuan

Speciality: Information and Communication Engineering

Supervisors: Associate Prof. Dong Yin

Finished time: May, 2019

摘 要

近年来,随着人工智能技术的不断发展,越来越多的技术被考虑到如何应用到实际场景中,为人类生活提供更多高效、智能的协助。行人重识别这一计算机视觉领域的重要研究课题也随着城市监控系统的不断的完善,被期望可以用来对多摄像头网络下的同一身份的行人进行检索匹配,以达到可以对行人的轨迹进行描述和对特定行人进行检索的目的。因此,该研究问题在商业和安防都有极高的应用价值。

由于实际场景环境复杂,光照条件、镜头视角变化大,场景下存在行人拥挤的遮挡的现象,这给行人重识别任务带来了巨大挑战。就此为了提高在实际场景下行人重识别技术的准确率,论文做了以下工作:

1. 设计了一种融合了行人多尺度特征的卷积神经网络,兼顾到人体全局特征和局部特征,为行人重识别任务提取更有辨别力的特征。此外整个网络结合标签平滑的交叉熵损失和难样本采样的三元组损失进行训练学习,在多损失函数的监督下,综合得到一个端到端的行人重识别的特征提取网络。实验证明标签平滑机制在交叉熵损失的使用,减少了模型过拟合,对准确率的提高有积极作用;难样本采样的三元组损失与网络的配合使用也使网络对行人特征识别的辨别能力得到了提升;该网络的全局特征与局部特征具备一定的互补性,融合后,网络的性能得到了提升。

2. 设计了一种基于图像池的重排序框架,利用目标人的多张图像特征作为检索,可以使目标人的特征更为丰富全面,从而提高重识别的准确性。为了降低相邻视频帧图像之间的冗余度,该框架首先以最优化查询图像特征的多样性和可靠性为准则,从多图像中选取固定张数的图片命名为该目标人的图像池。其次,为了进一步提高行人重识别检索结果的准确率,该框架将图像池中每张图像检索的结果进行聚合,对多个初始排序列表中的图像进行打分,置信度越高的图像分数越低。然后按照该分数对初始排序列表进行升序重排序,最终得到一个新的检索结果的排序列表。实验证明行人重识别网络通过该框架可以进一步提高识别准确率。

关键词: 行人重识别, 卷积神经网络, 多尺度特征, 图像池, 重排序框架

ABSTRACT

Recently, with the development of artificial intelligence technology, increase number of technologies are considered to be applied to assist human life in reality. Person re-identification, an important research branch in the computer vision, is expected to be used to search and match pedestrians with the same identity in the multi-camera network. This research can help human to describe the trajectory of pedestrians and retrieve specific pedestrians in surveillance video system. Therefore, person re-identification has high application value in business and security.

Due to the complexity of the real environment, the great change of illumination condition and lens perspective, crowded and occlusion, person re-identification has great challenge in practical application. In order to improve the performance of it, the following work has been done in this paper:

1. This paper proposes a convolutional neural network that takes into account the global and local features of human body. network combines multi-scale features to provide discriminative features for re-identification tasks. In addition, the whole network was trained with the supervision of multi-loss, which are cross-entropy loss of label smoothing and the triple loss of hard sample sampling. Experiments show that the use of label smoothing in cross-entropy loss can reduce over-fitting of model, then has a positive effect on the accuracy. The use of the triple loss of hard sample sampling improves the recognition ability of the network. In the end, the global and local features of the network are complementary to each other. The performance of the network is boost after fusion those multi-scale features.

2. This paper proposes a re-ranking framework with Image Pool, which uses multiple image features of the target person as retrieval. It can make the features of the target person richer and more comprehensive, then improve the accuracy. In order to reduce the redundancy between adjacent video frames, the framework firstly takes the diversity and reliability of query image into consider, and chooses a fixed number of images from multiple images to name the target person's Image Pool. Secondly, in order to further improve the accuracy, framework computes initial ranking lists of every samples in Image Pool, and proposes a 'Multiple-Image joint re-ranking algorithm' to aggregate initial ranking lists. Framework calculates the rank score of partial elements of initial ranking lists. In the end, final ranking list is obtained by ascending order of the rank score. Experiments show that this re-ranking network can further improve the

ABSTRACT

accuracy.

Key Words: Person Re-identification; Convolutional Neural Network; Multi-scale Features; Image Pool; Re-ranking framework

目 录

摘 要 I

ABSTRACT.....II

第 1 章 绪论3

 1.1 研究背景及意义3

 1.2 国内外研究现状4

 1.2.1 行人特征提取4

 1.2.2 重排序方法5

 1.3 本文主要工作和章节安排6

第 2 章 相关基础理论和知识8

 2.1 卷积神经网络8

 2.1.1 卷积神经网络基础结构9

 2.1.2 深度残差网络13

 2.2 行人重识别14

 2.2.1 行人重识别概述14

 2.2.2 评价指标15

 2.2.3 数据集16

第 3 章 行人重识别中的多尺度特征研究18

 3.1 引言18

 3.2 相关工作18

 3.2.1 特征研究18

 3.2.2 损失函数21

 3.3 损失函数设计22

 3.3.1 基本思想22

 3.3.2 交叉熵损失函数22

 3.3.3 标签平滑的交叉熵损失函数23

 3.3.4 三元组损失函数24

3.3.5 难样本采样三元组损失	25
3.3.6 损失函数实验参数与配置	26
3.3.7 实验结果与分析	26
3.4 多尺度网络结构设计	27
3.4.1 基本思想	27
3.4.2 网络结构设计	28
3.4.3 实验配置与参数	31
3.4.4 实验结果与分析	31
3.5 本章小结	33
第 4 章 行人重识别中的重排序框架研究	34
4.1 引言	34
4.2 相关工作	34
4.2.1 基于多图的行人重识别	34
4.2.2 重排序方法	35
4.3 图像池的选择	36
4.4 基于图像池的度量距离	38
4.5 基于图像池的重排序框架	39
4.6 实验配置与参数	44
4.7 实验结果与分析	45
4.7.1 图像池参数分析实验	45
4.7.2 图像池选取判别准则分析实验	47
4.7.3 与其他算法结果对比	48
4.8 本章小结	50
第 5 章 总结与展望	51
5.1 本文总结	51
5.2 研究展望	52
参考文献	53
致谢	58
在读期间发表的学术论文与取得的其他研究成果	59

第1章 绪论

1.1 研究背景及意义

当今，随着科技的发展，“天网”监控系统不断完善，数以万计的监控设备被安装到街道、银行、学校、商场等地方，通过网络的管理与调度，在城市内形成了大规模的视频监控系统。这些视频监控图像信息构成了巨大的基础数据库数据，为平安城市治安防控体系的建设，打下了丰富的图像数据基础。该系统本身对于防范、控制危害公共场所的行为是一项关键的安全措施，同时也是安全防控，武装警备的重要力量。监控设备每天都会产生海量的监控视频数据，因此，如果能实现系统内所有摄像头对可疑目标人的实时自动跟踪，可以大大解放人力资源。同时，整个监控摄像头系统内的自动跟踪较人眼跟踪更为高效准确，因此该技术的确是预防公共场所犯罪、追踪犯罪嫌疑人的科技利器。

而实现在整个系统中跨摄像头对目标人自动跟踪的技术关键就是行人重识别（person re-identification）。行人重识别旨在解决非重叠视角域中，多摄像头网络下的行人匹配问题，即判断不同位置的摄像头在不同的时刻拍摄到的行人目标是否为同一人。但是由于真实的监控视频画面十分复杂，实际场景下的行人重识别研究存在以下几点挑战。

第一个挑战是设计良好的外观特征，使算法可以做到在不同视角下的不同监控中重新识别出同一个身份的行人。而一个好的外观特征应该对视角和照明的变化具有鲁棒性，并且在遮挡和检测器定位有误差的情况下也能具有良好的性能。在这方面上，已经有大量的文献对此进行研究。近年来，最为成功的方法是一些基于有监督学习的卷积神经网络方法。通过设计合适的网络结构与使用合适的损失函数最终可以获得具有判别力的外观特征。

第二个挑战是行人之间具有很大的相似性，需要进一步增大不同身份标签样本图像之间的距离，同时使相同身份样本图像之间的距离尽量的小。对于这个研究目标，早期的一些度量学习的工作对此进行了研究。之后，随着深度学习的发展，深度度量学习方法被更多的使用。通过各种度量学习损失，如对比损失，三元组损失，以端到端的方式帮助神经网络学习样本之间的距离空间。此外，在实际应用中，重排序方法可以通过挖掘图片之间的关系，进一步提高检索结果的准确性。

因此，可以看出，行人重识别是一个具有很大实际应用价值同时也存在很大挑战的研究课题。研究行人重识别技术并提高实际场景下识别的准确率对公共安全和刑侦具有重要的现实意义。

1.2 国内外研究现状

2006年,行人重识别的概念第一次在 CVPR 上提出后^[1],相关的研究不断涌现。2007年 Gray 提出对于行人重识别研究非常重要的数据库 VIPeR^[2]。此后越来越多的学者加入行人重识别的研究。近年来,每年在国际顶级的会议以及顶级期刊上关于行人重识别的工作在稳步增加。2012年,第一个行人重识别研讨会在 ECCV 会议上召开;2014年后,深度学习被应用到行人重识别领域;2016年,行人重识别方向的研究迎来井喷式的增长,在各大计算机视觉的会议中出现了几十篇相关论文,尤其是基于深度神经网络的方法引起了广泛的关注;同时,相关数据集在不断地扩充,在各个数据集上的结果也获得很大的提升。到目前为止,行人重识别问题已成为计算机视觉的一个热点问题,针对该方法不断革新,研究在各大公开数据集上取得了不错的进展。

近年来,国内的对行人重识别研究也非常重视,技术研究走在世界前沿。国内主要的研究机构有清华大学,北京大学,复旦大学,中山大学,香港中文大学,华中科技大学,西安交通大学,中科院等;顶级会议的接受论文量稳步提升。其中中山大学的郑伟诗组对行人重识别的研究贡献较为突出,该组对特征提取、度量学习以及基于视频的行人重识别技术都做出了非常卓越的贡献。由于方法的不断革新,行人重识别的研究在各大数据集上都取得了不错的进展

行人重识别最开始是在基于图片的情况下进行,基本方法是通过匹配两幅裁剪后的行人图像来对不同相机中人物进行识别。随后,由于视频相较于图像拥有更多信息,并且基于视频的研究更符合视频监控环境下的现实情况,从2010年后,很多学者开始对基于视频的行人重识别进行研究^[3,4,5]。基于视频的行人重识别研究使用人物视频帧序列作为查询图像,其传统的方法是从图像序列中提取出姿态信息。McLaughlin 等人^[6]在2016年首度将深度学习方法应用到基于视频的行人重识别上。长期短期记忆(LSTM)网络^[7]也在研究中以循环的方式,聚合逐帧人物特征对识别准确率有进一步的提高。基于视频的方法有效地提高了行人重识别的准确性,但在研究中^[8]发现,随着所选帧数的增加,重识别的精度将会饱和。此外,基于视频的方法的研究目前仍然存在一定局限性,行人重识别的最终目的是实现跨多摄像头对目标人进行跟踪^[9],而现有的基于视频的行人重识别研究只涉及到两个摄像头^[10]。

1.2.1 行人特征提取

行人特征的研究重点在于设计鲁棒性强的行人图像特征表达,即模型提取的行人特征能够很好的区分不同的行人,同时特征能够不会很大程度的受光照和视角变化的影响。在传统的特征提取方法中,基本的做法是将图像划分成多个区域,

对每个区域提取多种不同的底层视觉特征,然后对底层特征进行组合,得到鲁棒性更好的特征表示形式。这种传统的特征工程中,最常用的特征方式是颜色特征,这是因为大部分情况下,行人的衣着,整体外观的颜色结构简单,用颜色对行人进行表示,是一种非常有效的特征。该特征通常采用 RGB、HSV 的直方图形式。此外,还有研究把 RGB 空间的图像转化成 HSL 和 YCbCr 的颜色空间的图像,观察在对数颜色空间中像素值的分布情况。在特性研究中发现,颜色特征在不同光照和角度下,行人的特征的确具有一定的不变性,是一种较为有效的特征^[11]。除了颜色特征外,还有一些手工特征被广泛使用。如形状特征、局部特征和纹理特征。形状特征常常使用方向梯度直方图^[12] (histogram of oriented gradients, HOG),局部特征的代表有局部不变特征-尺度不变特征变换 (scale-invariant feature transform), SIFT^[13], SURF^[14]和 Covariance 描述子 ELF (ensemble of localized features)。纹理特征则包括 Haar-like Representation^[15]、局部二值模式 (LBP)^[16]、Gabor 滤波器^[17]、共生矩阵^[18]等。

近年来,随着研究的深入和技术的发展,由于底层的视觉特征并不能很好的满足行人特征的复杂性,因此使用深度学习方法提取特征的技术逐渐被应用到行人重识别中来。最早的研究中,研究者把在 ImageNet 数据集上预训练的基于 AlexNet 结构的神经网络模型拿来,然后用行人重识别的数据集对模型进行微调。在微调过程中,不修改卷积层的权重,训练后两个全连接层,得到行人特征提取的深度学习网络模型。此后,由于残差网络 (ResNet) 在图像分类任务中的卓越表现,一些研究采用残差网络对图像进行特征提取。从 IDE (ID-discriminative Embedding) 的研究开始^[10],行人重识别的深度学习网络通常采用 ResNet-50 作为行人重识别系统性能水平的准线。在此基础上,越来越多的研究开始细化对深度学习方法的研究,提高网络模型对人体细节的注意力。一些研究^[19,20,21]将完整人体通过人体关键点估计的方法分为固定的几个部分,然后进行特征提取得到一些具有不同语义的局部特征信息,对人体全局特征进行补充,提高网络对行人图片细节的关注度和判别力。此外,旷视采用水平切条的方式并对切条的局部特征对齐的策略^[22]提高了特征的网络对局部特征的判别能力,大大提高了行人重识别在公开数据集上识别的准确率。

1.2.2 重排序方法

重排序方法的研究通常计算相似度的可靠性来进一步提高查询准确率。该方法是通过初始度量学习产生的相似度排序列表和相关图像来提高相似度排序列表的可靠性。在目标检索任务中,重排序方法已被应用来提高排序列表的准确性^[23]。在已有的研究中,k 最近邻方法被用来探索图像间的相似关系来实现重排序

目的^[24]。被排序的每个图像的新分数根据其在原有排序列表中的位置来计算。Chum 等人^[25]提出的平均查询扩展法,通过平均 top-k 返回结果中的向量来获得新的查询向量,用该新的查询向量对图库集图像进行重新匹配。总的来说,重排序方法都通过修改初始排序列表的方式,提高了检索结果的准确率。

1.3 本文主要工作和章节安排

本文的研究内容主要为行人重识别中多尺度特征和重排序框架的研究。研究从两个方面开展:(1)对于行人重识别中的多尺度特征研究,论文在一些现有的神经网络基础上进行研究,改进并提出鲁棒性更好的卷积神经网络,可同时表达行人图像的全局特征和局部特征。在行人重识别的实际应用场景中,可以使不同行人的特征尽量不受光照和视角变化的影响,以此来提高行人重识别检索结果的准确率。(2)对于行人重识别中重排序框架的研究,论文设计了一个基于图像池的重排序框架,充分利用多摄像头监控系统中丰富的数据信息,通过利用同一身份人的图像池中的多张图像的初始检索的排序列表的信息,对该目标人与图库集图像之间的距离进行重新评估排序,利用多张图像的检索结果生成重排序列表,进一步提高行人重识别任务的准确性。

针对行人重识别中多尺度特征研究,在行人重识别的任务中,由于不同视角下的姿态、光照等环境因素的变化,数据分布,特征的外观在镜头之间有很大的变化,给行人身份的匹配造成了一定的困难。而行人图片具有结构性单一且明确的特点,这是由于行人通常在站立或者行走的状态。而行人之间的差异比较细微,主要体现在高矮,胖瘦,衣着,携带物品等细粒度信息。因此论文设计了一种融合了行人多尺度特征的网络,可以兼顾到人体全局特征和局部特征,为行人重识别任务提取到更有辨别力的特征。此外整个网络结合标签平滑的交叉熵损失和难样本采样的三元组损失进行训练学习,在多损失函数的监督下,综合得到一个端到端的行人重识别的特征提取网络。

针对行人重识别中重排序框架研究,由于行人重识别任务往往是通过监控视频进行的,因此存在大量的关于身份人的图像可以利用。因此论文设计了基于图像池的重排序框架,利用目标人的多张图像特征作为检索,可以使目标人的特征更为丰富全面,从而可以提高重识别的准确性。由于视频序列中的相邻帧图像具有很大的相似性。因此直接使用连续的视频帧时,图像之间的冗余度高。因此该框架首先以最优化查询图像的多样性和可靠性为准则从每个目标人的连续视频帧或多图图集中选取固定张数的图片,命名为该目标人的图像池。其次,为了实现提高行人重识别检索结果准确性的目标,该框架将每张图片检索的结果进行聚合,聚合过程中将多张图片检索结果的排序列表中的每张图像进行打分,置信度

越高的图片分数越低。然后按照该分数对初始排序列表进行升序重排序,最终得到一个新的检索结果的排序列表,完成对初始排序列表的重排序。

本文的安排如下所述:

第1章,绪论。本章由本文的研究背景及意义引出了行人重识别中多尺度特征研究的必要性以及重排序框架在实际场景中对行人重识别任务的有效性。此外本章还概况介绍了行人特征提取和重排序方法目前在国内外的研究现状。最后本章介绍了本文的主要工作和章节安排。

第2章,相关基础理论和知识。本章首先介绍了卷积神经网络基础结构的理论知识,以及论文用到的基础网络框架——深度残差网络的原理。然后对行人重识别进行概述介绍,对行人重识别任务常用的评价指标进行详细的理论说明。最后对论文用到的行人重识别公开数据集和本文提出的 ITSD 数据集进行介绍。

第3章,行人重识别中的多尺度特征研究。本章对行人重识别的多尺度特征网络中用到的损失函数和网络结构本身分别进行了详细的说明。论文对作用于同特征空间分布的损失函数,以及其改进的版本进行了理论说明和实验对比。最后为论文提出的网络结构选取了合适的损失函数进行使用。论文在多尺度的网络结构的设计和实验中,通过实验结果证明了该多尺度特征融合的网络结构的有效性。

第4章,行人重识别中的重排序框架研究。本章首先介绍了结合多个图像和重排序方法进行行人重识别任务的优势。然后分别介绍了在基于图像池的重排序框架中图像池的选取准则,和该重排序框架通过图像池的图像的初始排序列表计算得到重排序列表的过程。最后实验结果证明了该基于图像池的重排序框架的有效性。

第5章,总结和展望。本章对本文所有的研究工作进行总结和分析,概括介绍了本文的创新点以及多尺度的特征提取网络和重排序框架的有效性和先进性。最后,本章分析了论文使用的方法的不足之处,并对未来工作进行展望。

第 2 章 相关基础理论和知识

2.1 卷积神经网络

在计算机视觉领域，通常要面临一个挑战，就是数据的输入可能会非常大，这是由于图像尺寸造成的。要处理这么庞大的输入数据，如果采用传统的全连接网络，难以获得足够多的参数来防止神经网络发生过拟合。此外，要处理包含 30 亿参数的神经网络，巨大的内存需求也很不实际。因此对于计算机视觉而言，卷积操作是不可或缺的组成部分。

卷积神经网络（Convolutional Neural Network，CNN）一般是由多层组成的网络结构，许多个二维平面，也就是卷积核构成了每层的基本单位，每个卷积核又是由多个不同的权值参数组成的。CNN 卷积操作的示意图如图 2.1 所示。




图 2.1 CNN 卷积操作示意图

卷积神经元每个隐层的单元被用来提取上一层图像的局部特征，然后映射成一个平面。特征映射函数多依靠 Relu 函数作为其激活的函数。Relu 函数在使用中可以使得特征映射保持着位移不变化，使特征具有一定鲁棒性。在卷积计算中，每个神经元与前一层的局部感受野相连。同一平面的神经元权值进行共享。此外，通常也会将一些池化层放在卷积层之后，对输入进行降采样，减少模型的参数量。常用的池化操作是对每个滤波器的输出求平均值或最大值。总的来说，CNN 通过局部感受野、共享权值和降采样的方式保证图像特征对位移、缩放、扭曲具有一定的鲁棒性。

卷积神经网络原本的意义便是以输入、输出的方式进行映射。因此，对输入和输出的关系能够产生强大的表达能力，可以不通过输入与输出之间的具体的数

学表达式就能完成。卷积神经网络仅需要通过已知标签和数据对其进行训练，就可直接得到输入与输出之间的映射。输入向量和理想输出向量所组成的向量对构成了卷积网络的样本集。在训练开始前，神经网络的每一个权值参数都是由各种随机数字完成最初的赋值，确保网络权值训练时不会进入梯度饱和的状态。参数采用各种数值对网络初始状态进行调整的作用是为了使网络正常运作。

2.1.1 卷积神经网络基础结构

对卷积神经网络而言，无论是简单还是复杂，通常都由以下的基础部件组合而成。它们是卷积层、池化层、归一化层、全连接层、激活函数和损失函数。

1. 卷积层

卷积层（Convolutional layer）作为 CNN 的至关重要的组成部分，卷积层依靠卷积核（kernel）来完成特征的计算和提取。每一个卷积层一般由多个卷积核组成，它的数量通常被称为三维卷积的深度（depth）。而对于每一个卷积核，它的本质则是一个拥有特定权重参数的滑动窗口，可以把它看成是一种图像滤波器。在具体的计算中，卷积核在输入图像上按照一定的步长（stride）进行滑动，滑动到每个位置时，计算该位置的输入图像与卷积核参数的卷积作为输出。在真实的计算中，得到卷积输出后，还会加上一个偏置（bias），才得到最后的输出。以二维卷积为例，其计算过程如公式（2.1）所示：

$$\text{output} = \sum_{i=1}^m \sum_{j=1}^n I_{i,j} \times K_{i,j} + b \quad (2.1)$$

其中 I 是图像输入， K 是卷积核和参数操作， m ， n 是卷积核长宽的尺寸， i ， j 是当前像素的坐标， b 为偏置。

此外，卷积层还有一个重要的基本操作就是补全尺寸（padding）。如果用—个 3×3 的过滤器卷积—个 6×6 的图像，最后会得到—个 4×4 的输出，也就是—个 4×4 矩阵。那是因为 3×3 过滤器在 6×6 矩阵中，只可能有 4×4 种可能的位置。可通过数学公式： $(n - f + 1) \times (n - f + 1)$ 计算而来。而这样操作会造成两个缺点，第一个缺点是每次卷积操作，图像尺寸都会缩小，可能几次卷积操作后，图像的尺寸就会变得很小，甚至会缩小到只有 1×1 的大小。而在实际运用中不希望图像在每次识别时，边缘或其他特征时都缩小。第二个缺点是，角落边缘的像素只被—个输出计算使用，这是由于它位于该 3×3 的区域的边缘。而在中间的像素点，

会与许多 3×3 的区域重叠。所以那些在角落或者边缘区域的像素点在输出中被计算的次数较少，这意味着很多图像的边缘位置信息被丢失。

为了解决这些问题，减少信息的丢失，做法就是在卷积操作之前填充这幅图像。比如对于之前所说的 6×6 的图像，沿着图像边缘再填充一层像素，此时 6×6 的图像就被填充成了一个 8×8 的图像。然后再使用 3×3 的过滤器对这个 8×8 的图像卷积，此时输出图像的尺寸仍然是 6×6 。因此可以得到了一个尺寸和原始图像一样大小的特征图（feature map）。一般的操作中，使用 0 作为填充值，用 p 来表示填充数量，在这个例子中，因为在周围都填充了一个像素点，则 $p = 1$ 。输出尺寸就变成了 $(n + 2p - f + 1) \times (n + 2p - f + 1)$ ，所以就变成了 $(6 + 2 \times 1 - 3 + 1) \times (6 + 2 \times 1 - 3 + 1) = 6 \times 6$ ，和输入的图像一样大。通过 padding 的操作，缩小尺寸丢失信息，同时角落或图像边缘的信息发挥的作用较小的缺点就被减小了。

因此卷积神经网络输出的完整的计算公式由输入尺寸，卷积核尺寸，补全尺寸以及步长共同计算得出，它的具体计算公式如公式（2.2）所示：

$$o = \left\lfloor \frac{(n+2p-f)}{s} + 1 \right\rfloor \quad (2.2)$$

公式里， o 和 n 代表输入输出的大小， f 是正方形卷积核的边长， p 是补全尺寸的数值， s 是步长长度。此外，为了保证求值结果为整数，使用 $\lfloor \cdot \rfloor$ 的操作进行舍值取整。

通过数据对卷积神经网络进行着不断的迭代训练，各个卷积核在其培训的过程中产生不一样的权重值。因为参数的不同，这些卷积核在图像的提取出独特的特征。大量的卷积层的连接组合形成完整的神经网络，每一个卷积层的输入都是由上一个卷积层非线性处理的输出而得到。通过这样的方式进行一层又一层的特征处理，因此不同深度的卷积层在卷积神经网络里分别承担了不同的视觉处理能力，对图像的浅层信息和深层信息分别进行处理。

一些可视化的研究已表明，已知在卷积神经网络的中低层中，图像的边缘和纹理等相关的底层特征主要由底层卷积操作完成筛选。随着神经网络层数的加深，特征图开始逐渐具有复杂的语义。中层的卷积层可以对图像中的一些局部特征具有感知力，而卷积神经网络的深层的卷积层具有表达整个物体的能力。

2. 池化层

除了卷积层，卷积神经网络也经常使用池化层（Pooling layer）来缩减模型的

体积大小,增幅计算速率。在此基础上,还能增强所提取特征的鲁棒性。区别于卷积层的操作,池化层是一个无参层,它只对输入的特征图直接进行计算,而本身没有参数权重需要学习。池化层同样通过滑动窗口进行实现。卷积层输出大小的公式同样适用于池化层。根据不同的池化计算方法,池化一般分为最大池化(Max pooling),和平均池化(Mean pooling)这两种。最大池化操作较为常用,因为其在实际应用中效果比较好。它的功能是将任何一个象限内提取到最为强烈的特征保留在最大化池化的输出中。因此最大化运算的实际作用可以直观理解为,如果在过滤器在某一范围内进行特征提取,那么对该范围内特征值保留最大值。如果最大池化操作后没有提取到这个特征,可能是因为该过滤器视野范围内中不存在这个特征,那么其提取的最大值仍然是一个比较小的值。

使用池化层在卷积神经网络中具有重要意义。首先,通过降采样的操作,在保留特征图的主要信息同时减小了输入特征图的尺寸,池化层可以缩减网络参数的数量,增幅训练模型的速率,有效减少网络参数,起到了一定的防止过拟合的作用,增强了泛化性能。由于池化可使象限内的全部值集中为一个单值,因此特征图响应值的敏感程度被削弱,网络局部范围内有效的产生平移、旋转的不变性。

3. 激活函数

激活函数又可以称为非线性映射函数,是深度卷积神经网络中不可缺少的重要组件。深度网络的计算过程里,神经网络中一层叠一层的隐藏层一定要进行非线性形的激活计算。这是因为如果不进行该操作的话,无论神经网络有多少层一直只是在做线性计算,这与一个单层神经网络的效果是等价的,神经网络的深度没有意义。因此,如果不引入非线性映射函数的话,神经网络将不能依靠网络的深度的叠加提取更复杂的特征。

因此,深度网络模型强大的表示能力大部分是由激活函数的非线性操作带来的。常用的激活函数有 sigmoid, tanh, Relu 等。

sigmoid 的表达式如(2.3)所示:

$$\sigma(z) = \frac{1}{1+e^{-z}} \quad (2.3)$$

tanh 的表达式如 (2.4) 所示:

$$\tanh = \frac{e^{-z} - e^{-z}}{e^{-z} + e^{-z}} \quad (2.4)$$

Relu 的表达式如 (2.5) 所示:

$$a = \max(0, z) \quad (2.5)$$

通过表达式可知, tanh 函数是 sigmoid 的向下平移和伸缩后的结果。对它进行了变形后, 穿过了 (0,0) 点, 并且值域介于 -1 和 +1 之间。在实际研究实验中发现, 用 tanh 激活函数在实际应用中效果往往要比 sigmoid 函数好。对公式进行原理分析可以得知, tanh 函数的输出值的范围为 (-1, 1), 因此它的均值可取到 0 的附近。因此在训练神经网络的时候, 使用 tanh 函数可得到更为中心化的网络模型, 这点比均值为 0.5 的 sigmoid 函数要好。

sigmoid 函数和 tanh 函数的共同的缺点是, 在函数值 z 特别大或者特别小的情况下, 导数的梯度或者函数的斜率会变得特别小, 最后就会接近于 0, 导致降低梯度下降的速度很慢, 无法有效的更新, 导致网络无法收敛。

而 Relu 函数只要函数是正值的情况下, 导数恒等于 1, 这解决了 sigmoid 和 tanh 在饱和状态下梯度弥散的问题。当函数为负值时, 梯度为 0, 神经元此时不会训练, 网络产生所谓的稀疏性。此外, 使用 Relu 激活函数的神经网络通常会比使用 sigmoid 或者 tanh 激活函数学习的更快。

4. 归一化层

对于一个模型来说, 归一化输入特征可以加快学习过程。计算平均值, 从训练集中减去平均值, 计算方差, 接着根据方差归一化整个数据集, 有利于训练的优化和收敛。归一化层的操作是先把把输入的 z 值标准化, 化为含平均值 0 和标准单位方差的分布, 因此 z 的每一个分量都含有平均值 0 和方差 1。如公式 (2.6) 所示:

$$z_{norm}^{(i)} = \frac{z^{(i)} - \mu}{\sqrt{\sigma^2 + \epsilon}} \quad (2.6)$$

其中 μ 是输入的平均值, σ^2 是方差, ϵ 是一个小数, 防止分母为 0。

然后 Batch 归一化层将 $z^{[1]}$ 值进行 Batch 归一化, 简称 BN, 此过程将由 $\beta^{[1]}$ 和 $\gamma^{[1]}$ 两参数控制, 这一操作将会得到新的的规范化的 $z^{[1]}$ 值 $\hat{z}^{[1]}$, 使它得到其想要的分布。然后将归一化后的数据再输入到激活函数中。也就是说 Batch 归一化

是发生在 z 的计算和计算激活函数之间。表达式如公式 (2.7) 所示, γ 和 β 是模型学习的参数。

$$\hat{z}^{(i)} = \gamma z_{norm}^{(i)} + \beta \quad (2.7)$$

Batch 归一化减少了输入值改变的问题, 它使输入值变得更稳定, 神经网络的后面的层就有了稳定的基础, 鲁棒性更好。即使输入分布改变了一些, 对网络整体的影响也会更少。它做的是当前层保持学习, 当改变时, 迫使后层适应的程度减小, 减弱了前层参数的作用与后层参数的作用之间的联系, 使得网络每层都可以自己学习, 稍稍独立于其它层, 有助于加速整个网络的学习。因此, 归一化层本身可以有效增快网络的收敛速度, 还能起到调控网络过度拟合的状况。在目前设计中, 常将归一化层加入在卷积层或全连接层后。

2.1.2 深度残差网络

由于神经网络的深度对识别任务的效果有很大的影响。特征的层次可以通过堆叠层数(深度)来丰富。但是随着网络深度的增加, 准确度变得饱和然后迅速退化, 这就是退化问题。在这种情况下, 可以使用残差网络框架(ResNet)来解决退化问题。ResNet 的原理是让图层适合残差映射, 而不是让每个堆叠的图层直接适合所需的底层映射。残差块(Residual Block)是通过在一个普通的前向网络中加入一个快捷连接通道, 在输出位置直接加上未经该块卷积神经网络块处理的输入得到的网络结构。

在进行非常深的网络训练过程时, 残差块的使用比直接堆叠卷积网络具有更易收敛的特征。普通的深度网络不容易实现参数优化和自适应, 网络结构的加加深, 反而会使得模型的正确率降低。残差神经网络因为存在快捷连接通道, 网络数据间的传输阻碍变小, 同时也对因为模型过深, 梯度消失造成的欠拟合的现象进行修正。残差块的图示如图 2.2 所示, 公式如公式 (2.8) 所示。




图 2.2 残差块

$$y = F(x) + x \tag{2.8}$$

在公式 (2.8) 中， x 和 $F(x) + x$ 分别表示残差块的输入和输出向量；函数 $F(x)$ 表示残差映射。原始的映射被改写为 $F(x) + x$ 。 $F(x) + x$ 的公式通过具有“捷径”的前馈神经网络来实现。快捷连接就是那些跳过一个或多个图层的连接。在这种情况下，快捷连接只需执行识别 (identity) 映射，将其输出添加到堆叠层的输出。

2.2 行人重识别

2.2.1 行人重识别概述

随着深度学习的发展，深度网络的特征学习已成为解决行人重新识别任务的常见方法。深度学习的特征提取方法与现代手工制作方法相比，为行人重识别任务实现了更高的性能。目前的研究中，通常采用 ResNet-50 的基础网络框架作为行人重识别系统性能的基线。在基线之上，为了进一步改善深度学习的行人重识别性能，研究主要关注对局部特征的增强作用，一些研究将局部进行对齐匹配，以提高度量学习性能。一些研究根据人体结构信息确定不同区域，按区域的方法去定位身体部位，然后通过空间增强局部特征的注意力。此外还有的研究采用粗切条的方式对人体局部特征进行划分和表达。总的来说，行人重识别的研究，为了实习提高模型识别准确率的目标，虽然采取的方式多种多样，但达成的共识就是如何去结合局部特征的信息，使网络的性能更好。

2.2.2 评价指标

在行人重识别任务中,通常使用两个评估指标来评估行人重识别方法的性能。第一个是累积匹配特征(CMC)。CMC曲线的横坐标为Rank-k的值,纵坐标的值表示在前k个Rank中匹配的结果有正确标签的概率。CMC曲线通常使用其曲势和Rank-1的值,直观地表示模型的好坏。将多个模型的CMC曲线对比观察时,曲线整体位置越高,则表面模型性能越优越。

该评价指标将行人重识别作为排名问题进行考虑。对排名的累积匹配准确度进行报告,通常参考排名1的准确度也就是Rank-1。Rank-1值的含义是在查询结果排序列表第一位处,整个数据集查询图像的标签和该查询结果的标签相同的概率。Rank-1是反映行人重识别模型性能最为关键且直观指标。在对模型之间优劣性进行比较时,Rank-1是优先考虑的评价指标,Rank-1的值越高通常说明模型越好。

另一个评价指标是平均精度(mAP)。该评价指标将行人重识别视为对象检索问题。mAP同时考虑到模型的召回率(recall)和精确率(precision),对模型可以进行更综合地评价。定义一个查询图片的检索正确率为匹配排名前k的样例中,正确匹配图片数量占的比例,如公式(2.9)所示。

$$P = \frac{k_c}{k} \quad (2.9)$$

其中 k_c 就是在前k中正确匹配身份的数量。

而该查询样本的召回率是匹配结果排名前k中,正确匹配到身份的图像数目占总所有属于该身份行人图像总数的比例,如公式(2.10)所示:

$$R = \frac{k_c}{k_{all}} \quad (2.10)$$

其中 k_{all} 就是某身份行人图像的总数,对被检索的图像集中不同身份的人来说,都是一个已知的定值。

将相对应的P值和R值画一条曲线,就得到了PR图。而某一个查询样例图片的AP值就是该PR图下围成的面积,mAP就是所有查询图片AP值的均值。

对于基于图像的数据集,图像池的结果被视为主图像的结果。对于图像序列数据集,图像池的结果被视为整个序列的结果。

2.2.3 数据集

行人重识别任务用于评价的的数据集通常有 Market-1501，DukeMTMC-reID，PRID 2011，iLIDS-VID 以及 CUHK03 等。它们的基本信息如下表所示。

表 2.1 常用行人重识别数据集信息

数据集	提出时间	身份数	图片数	摄像头数	评价指标	图片尺寸
iLIDS-VID	2009	119	476	2	CMC	各种尺寸
PRID 2011	2011	200	1134	2	CMC	128×64
CUHK03	2014	1467	13164	2	CMC	各种尺寸
Market-1501	2015	1501	32668	6	CMC/mAP	128×64
DukeMTMC-reID	2017	1812	36441	8	CMC/mAP	各种尺寸

由于现有的数据集通常每个身份人的图像只涉及到两个镜头，很难模拟真实的多个摄像头的监视数据。为了更好地评估论文提出的框架在现实环境中的有效性，收集建立了新的室内火车站数据集（ITSD）。

1. PRID 2011 数据集

PRID 2011 数据集包含 200 个身份人的 400 个图像序列。从两个彼此相邻的摄像机视角收集图像。每个图像序列拥有由 5 到 675 个图像帧组成的可变长度序列。根据评估协议，序列对的总池被随机分成两个相同大小的子集，一个用于训练，另一个用于测试。在测试阶段，来自第一台摄像机的序列用作查询组，而来自另一台摄像机的序列被当作图库集。

2. iLIDS-VID 数据集

iLIDS-VID 人物序列数据集从两个非重叠视图的摄像机收集而来的。它由 300 个随机抽样人物的 600 个图像序列组成。每个身份人的两个摄像机视图中都有一组图像序列。每个图像序列具有由 23 到 192 个可变长度图像帧组成。iLIDS-VID 的评估协议遵循 PRID 2011 数据集的设置。

3. Market-1501 数据集

Market-1501 是目前最常使用的基于图像的准线数据集。它包含 32668 个标记的行人包围框，其中包含了从 6 个不同视角摄像头捕捉的 1501 个身份人的图片。Market-1501 数据集分为两部分：12936 个图像，有 751 个用于训练的行人身份，以及 19732 个图像具有 750 个用于测试的行人身份。在测试环境中，使用具有 750 个身份的 3368 个图像作为查询组来识别测试集上的正确身份。

4. ITSD 数据集

由于当前可用的数据集太过单一且背景环境简单,这些公开数据集很难代表现实世界的监控数据。为了评估现实世界中行人重识别的有效性,论文提出了一个小型室内火车站数据集(ITSD)。数据集的来源来自火车站的真实监控视频。因此,ITSD 数据集具有复杂的背景和真实的监视视图。在人工监督下,使用均值漂移跟踪方法收集每个标识的样本,并使用 DPM 确定行人边界包围框。采集的图像的大小为 64×128 。ITSD 数据集包含 5607 张图像,从 8 个不同的视点捕获 443 个身份,其中 50 个身份由至少 3 个不相交的摄像头捕获。ITSD 的边界框经过人工的调整筛选更加紧凑。此外,ITSD 数据集具有更复杂的场景和视角。完全符合真实的监控环境。

从实验的目的出发,数据集分为两部分:3833 个图像,其中有 343 个身份用于训练,以及 1774 个图像具有的 100 个身份用于测试。正是由于 ITSD 提供丰富的摄像机视图和真实环境的数据。论文可以充分评估行人重识别框架性能的优劣。

第3章 行人重识别中的多尺度特征研究

3.1 引言

通过上文的分析,已知在行人重识别的任务中,由于不同视角下环境、光照等原因给行人重识别任务带来很大的难度和挑战。因此行人重识别任务的研究重点首先着重放在对鲁棒性特征这一难题的研究上。

现有的一些端到端的主流卷积神经网络框架可以在不同数据集上自适应地学习数据集并提取图像的特征,完成不同的计算机视觉任务。但是直接将主流的卷积神经网络框架用来解决行人重识别问题,识别的准确度和精度还远远没有达到实际应用的需求。原因主要在于,这些主流的神经网络结构如 VGG, ResNet 等更多是针对识别任务进行设计的,然后在 ImageNet 数据集进行训练和测评。而 ImageNet 数据集是一个广泛用于识别任务的数据集,它拥有多个物种的类别,同时相同类别标签的物种差异也比较明显。而行人重识别数据集与其不同的是,行人图像的结构明确且单一,行人之间的差异比较细微,主要体现在高矮,胖瘦,衣着,携带物品等细粒度的信息。此外,由于复杂的实际环境存在形变、遮挡等更为复杂的情况,这给网络学习有辨别力的特征带来了更大的难度。所以在这种情况下,现有的主流的卷积神经网络框架难以给行人重识别这类细粒度检索任务更高精确度的表现。由于这样的网络结构不满足实际应用的要求,因此本文将对行人图像特点进行进一步的研究,通过已有的研究思考,设计可以提取到更精确鲁棒的细粒度特征的网络结构。

在本章中,论文对多尺度特征进行研究,并将多尺度进行融合,使网络模型可以兼顾到人体全局和局部特征,为行人重识别任务提取更有鲁棒性的特征。此外整个网络结合交叉熵损失和三元组损失进行训练学习,在多损失函数的监督下,综合得到一个端到端的行人重识别的特征提取网络。

3.2 相关工作

3.2.1 特征研究

在深度学习的行人重识别研究里,目前特征被划分为两种:全局特征和局部特征。在一些比较早期和局部监督指导的研究工作里直接使用全局特征对行人的

外观进行描述。在这类整体的端到端的深度神经网络中,通常采用在 ImageNet 上预训练的模型参数,然后使用相应的行人重识别的数据集进行微调。这样做的原因,一方面也是因为目前行人重识别的数据集规模较小,需要在大的数据集上进行图像基础特征学习,在较小的数据集上才可以达到较好的识别效果。但这种全局特征虽然便于训练,能整体的对行人的外观进行表达,但仍存在缺点:缺乏细粒度信息。这导致模型对相似外观的难样本区分度差。而独立的局部特征可以将注意力放在更有辨别力的局部细节上,可以更好的反应行人之间微小的差异。因此在行人重识别的特征研究中,应该对全局特征和局部特征做出一个好的平衡。

在一些早期的融合局部特征行人重识别的研究的研究思路主要有两个方向:

(1) 在网络中使用额外的关键部位定位的信息,在网络训练过程中加强对局部特征的学习。在不同研究中,引用额外的关键部位信息的方法也有所不同。如通过结合人体属性的方法^[26], Yutian 等人将衣服颜色,是否有背包,性别等 27 个属性特征损失与行人身份损失结合,共同训练。对训练后的网络模型进行可视化后,可以看到该模型的确加强了对局部特征的关注度。在一些研究中,先在其他数据集中训练可以检查人体关键点的模型^[19, 20, 21],然后在行人重识别中使用该模型对图片中行人进行关键点估计,对人体局部进行定位,以这种方式引入和增强人体的局部信息。该方法对行人重识别的准确率的提升也有帮助,但该方法存在的问题是,由于关键点是通过模型检测到,而非标注得到的。关键点定位存在很大的误差,提供局部关键点信息的同时也引入了很多误差噪声,这也会对模型带来很大的负面影响。此外,还有使用人体部位分割的方式^[27]引用局部信息的研究,该方法的问题同样在于该分割信息是通过模型检测到的,会引入误差噪声。

(2) 通过区域划分,使网络自适应学习到局部特征的表达。旷视采用水平切条的方式并对切条的局部特征对齐的策略^[22]提高了特征的网络对局部特征的判别能力,识别准确率得到大大的提升,这也说明了这种局部特征引入方式的有效性。在 PCB^[28]的研究中,采用水平粗切条的方式提取局部特征,与全局特征共同作用得到行人特征。该工作将识别率提高到一定准线,也证明了全局特征和局部特征的互补性。此后,越来越多的研究使用水平切条的方式提取局部特征,如 MGN^[29], HPM^[30]等。但如何将水平切条的局部特征与全局特征进行结合,如何搭配使用损失函数仍是一个需要研究的问题。

这两种方法都有各自的优缺点。在使用额外定位信息的网络中，需要使用额外的部位标注。如果是使用人工标注的方法，代价非常昂贵。如果使用在其他训练集上训练的模型对行人重识别的数据集直接进行估计时，则会导致引入定位误差的问题，这样会使训练数据存在误差。而使用自适应学习的局部特征的网络框架会给计算带来很大的负担，参数量大，模型效率低，以及定位不准确会引入误差，造成行人重识别的精度下降^[31]。

目前已有的行人重识别数据集中的行人数据通常是从监控视频或者相机视频中获取，行人的包围框是通过手工或是检测器的方法获取并对行人进行裁剪和单独的保存来构成数据集。这样的行人图像数据集具有一些共有的特点：

- (1) 每张图片上只有一个行人。
- (2) 行人主体处于图片中心，且占据整张图片的大部分面积。
- (3) 行人图片结构性单一且明确。这是由于行人通常在站立或者行走的状态，人体自上至下依次结构一定是头，躯干，腿。不同部位在图像的位置较为固定^[32]。如图 3.1 所示，图中从 Market-1501 数据集中随机挑选了一些行人图像，对行人图像从上到下均分成四条，从图上很容易可以观察到的现象是，对行人图像进行切条，其不同条内的人体部位大体一致。




图 3.1 行人结构性示意图

使用水平切条的方式依据人体自身的结构对行人进行粗粒度的局部特征提取。这种划分方式的好处就是可以减小网络的参数规模。该网络结构不必单独进行工作，可以作为全局特征网络的部分分支，使用不同的网络分支去学习不同的局部人体，最终能够获得对行人不同的局部特征更有判别力的模型。在测评阶段，

将这些特征和全局特征结合起来，可提高网络整体的特征判别力^[33]。

这种粗放化划分一定程度的解决了姿势或遮挡变化会影响局部表示可靠性的问题，比采用额外信息定位的方法带入更少的噪声误差。通过网络的训练自动对局部特征进行学习，自适应的训练得到更有辨别力的局部特征。

3.2.2 损失函数

损失函数 (loss function) 是在神经网络学习中被用来计算网络输出标签 $f(x)$ 和真实标签 Y 差异程度的函数。使用 $L(y, f(x))$ 表示该非负实值的数学函数。损失函数的值越小，预测出的标签和真实标签就越一致，可以判断该模型的特征能力越好。作为经验风险函数和结构风险函数的重要理论依据，损失函数的公式由经验风险项和正则项这两部分共同组成。经验风险用来衡量模型预测的准确性。如果模型过度依赖少数几个参数，就会导致模型过拟合。因此为了在一定程度上减小这些参数的值，使它接近于 0，就能很好的拟合。因此，在最小化代价时也需要将这个惩罚纳入考虑中，并最终导致选择较小的参数值，就是惩罚项的作用。

结构风险函数公式表示如公式 (3.1)：

$$\theta^* = \operatorname{argmin} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i; \theta_i)) + \lambda \phi(\theta) \quad (3.1)$$

公式中，前一项均值函数表示的是经验风险函数， L 表示损失函数，后一项是正则化项或者叫惩罚项，可以使用 L1 正则化项、L2 正则化项或是其他的正则函数。 λ 是正则化项的系数。为模型选择合适的参数，求解最优解的目标是最小化结构风险。针对不同的计算机视觉任务，目标函数具体使用的公式也有所不同。它们根据不同的任务进行设计，如交叉熵损失函数，中心损失函数，三元组损失函数等^[34]。而在行人重识别的深度学习应用中，损失函数被用作嵌入学习的监督工具。在深度行人重识别系统的训练阶段，最常见的损失函数是分类损失和度量损失。交叉熵损失几乎是分类损失函数的唯一选择，对各种多类的分类任务都具有很强的鲁棒性。交叉熵损失可以单独使用或与其他损失结合，共同用于嵌入行人重识别网络的学习。对于在行人重识别网络嵌入学习中使用的度量损失，存在具有不同排名度量的更多变体。对比度损失通常用于 Siamese 网络，它的重点是最大化类间对之间的距离，并最小化类内对之间的距离。三元组损失用来加

强内部距离和外部距离之间的边界。基于三元组损失提出了许多变体来解决度量学习中的学习或性能问题。在论文模型中，将采用交叉熵和三元组损失的联合学习设置。

3.3 损失函数设计

3.3.1 基本思想

损失函数在神经网络的训练中重起到非常关键的作用。在行人重识别的网络模型训练时，如何使用损失函数，使用什么损失函数，都对最后学习到的模型参数是否具有辨别力的特征，以及不同类之间特征的距离都起到至关重要的作用。损失函数是深度学习中度量学习的核心组成部分，通过设计不同的损失函数可以提高网络对难样本的辨别能力。此外，使用合适的损失函数还可以使同标签的图片距离尽量的小，使不同标签的图片的距离尽量远的。由于不同的损失函数有着不同的特点，起到强调特征不同特性的作用，因此根据具体的网络架构搭配使用不同的损失函数，可以训练出性能更好的网络。在本节中，对不同的损失函数进行研究讨论，并在数据集上衡量其在行人重识别任务的表现，并提出多损失函数融合网络学习方法。

3.3.2 交叉熵损失函数

交叉熵损失函数（Cross-entropy loss 或 Softmax loss）是一种广泛使用于分类任务的损失函数。通常，在分类网络的最后，接上一个用于分类的全连接层，然后通过训练，计算输出该输入图像在各标签下的置信度。由于置信度的尺度不一，以及为了是不同置信度的输出结果更为明显，交叉熵损失函数使用 Softmax 函数进行进一步计算，Softmax 公式如公式（3.2）所示，Softmax 的输出成为最后各类标签的概率依据。

$$p_i = \frac{e^{w_i^T x + b_i}}{\sum_j e^{w_j^T x + b_j}} \quad (3.2)$$

公式里，用 i 代表每个类别 ID 的标签 z ；使用 w_i 代表神经网络层中该神经元与对应第 i 个输出之间的参数权重；使用 b 表示每个神经元的偏置参数； x 是输入的特征图的值；而输出 p_i 表示这个输入图像对应的第 i 类的概率值的大小。每类 p_i

概率值的取值范围区间为 $(0, 1)$, p_i 所有类的概率值的总和为 1。在分别求出所有类别的概率值后, 对 p_i 分别使用 Softmax 函数, 如公式 (3.3) 所示, 求出其 Softmax 损失函数值。

$$L_{softmax} = -\frac{1}{N} \sum_i \log(p_{y_i}) \quad (3.3)$$

其中, i 表示类别标签的序号。 y_i 表示第 i 号样本图片的标签。 N 总样本图片的数目。通常, 行人重识别研究将仅使用 ResNet-50 网络结构和交叉熵损失函数组合作为准线, 在 Market-1501 数据集上目前已经取得了较高的识别准确率。但这是远远不够的, 仅仅由交叉熵损失函数训练得到的参数模型缺乏对细粒度特征的判别力。此外, 在机制上缺乏对样本特征空间分布的显式约束, 它无法做到使不同类别之间的距离拉开, 也无法进一步缩小类间距离, 从而造成模型对难样本的辨别力较差。因此不能满足检索任务的需求。已有研究表明, 交叉熵损失函数训练出来网络参数模型在结果上倾向产生“辐射状”的样本分布。不同标签的样本在特征空间中距离近, 没有较大的间隔。类间样本混杂, 存在冗余且边界模糊的现象。这将使得模型的辨别力不够, 对难样本更难正确处理。因此仅用交叉熵损失函数处理行人重识别任务是不够的。

3.3.3 标签平滑的交叉熵损失函数

使用交叉熵函数来计算损失值时, 网络模型的训练目标是最小化预测概率和标签真实概率的交叉熵, 以得到最优的预测概率的参数。在该训练的过程中, 为了达到最好的拟合效果, 也就是使损失函数值最小, 网络学习方向具有由正确标签和错误标签差值大的方向进行转移的特点。但是当训练数据不充足, 无法全面的表达所有的样本特征时, 交叉熵损失函数会导致网络模型参数过拟合。

标签平滑 Label Smoothing Regularization (LSR)^[35]的提出就是为了解决上述问题。最早是在 Inception v2 中提出的, 是一种有效的正则化的策略。LSR 通过软化传统的单一标签分发类型的标签, 在输出 y 中添加噪声对模型进行约束, 使网络在训练计算损失值过程中能够有效抑制过拟合现象。LSR 可以看作是减少真实样本标签的类别在计算损失函数时的权重的方法, 最终起到抑制过拟合的作用。

LSR 将真实概率分布——如公式 (3.4) 所示改变为公式 (3.5) 的分布。

$$P_i = \begin{cases} 1 & , if (i == y) \\ 0 & , if (i \neq y) \end{cases} \quad (3.4)$$

$$P_i = \begin{cases} (1 - \varepsilon) & , if (i == y) \\ \frac{\varepsilon}{K-1} & , if (i \neq y) \end{cases} \quad (3.5)$$

更新后的分布相当于对真实的数据分布中加入了噪声。一般来说,为了方便计算,该噪声为均匀分布。与之对应的是,标签平滑的交叉熵损失函数变为如公式(3.6)所示的形式:

$$L_{LSR} = \begin{cases} (1 - \varepsilon) * L_{softmax} & , if (i == y) \\ \varepsilon * L_{softmax} & , if (i \neq y) \end{cases} \quad (3.6)$$

该损失函数分别以不同的权重对预测标签与标注的标签之间的差距,预测标签与先验分布的差距进行惩罚,以此来抑制过拟合现象。

3.3.4 三元组损失函数

目前在计算视觉的图像检索这一课题的研究中,广泛进行使用和研究的就是三元组损失函数(Triplet loss)。检索这一任务与分类任务的区别之处在于,在进行检索任务的损失函数设计时,通常考虑的重点是如何拉开类间的距离,而不是像分类任务一样考虑如何更加准确的进行类别分类。所以该类损失函数的作用重点是用来改变特征空间的分布,才能使不同类之间的距离尽可能的大。在检索任务中,最为基础的就是三元组损失函数。该函数通过正负样本的作用,将对样本之间的距离强调作用在损失函数中,使得网络可以通过该损失函数可以自动的学习到一个新的特征空间。在该空间中,样本的分布具有类内距离小,类间距离大的特点。

在使用三元组损失函数时,网络的使用三张图片作为输入 $x_i = \langle x_i^a, x_i^p, x_i^n \rangle$,其中 x_i^a 是锚点样本(anchor), x_i^p 和锚点样本是同标签样本(positive), x_i^n 和锚点样本是不同标签样本(negative)。在特征提取时,它们共享同样的网络结构,提取特征后进行损失计算的公式如公式(3.7)、(3.8)所示:

$$L_{triplet} = \frac{1}{N} \sum_{y_a=y_p \neq y_n} a.p.n [m + d_{a,p} - d_{a,n}]_+ \quad (3.7)$$

$$d_{i,j} = D((x_i), f_{\theta}(x_j)) \quad (3.8)$$

在公式中, θ 表示整个网络总的参数, $f_{\theta}(x)$ 表示输入 x 通过网络进行的特征提取操作, $D(\cdot)$ 是样本之间度量距离的计算, 一般使用欧式距离。 m 表示样本之间的间距应取的最小值, 也就是阈值。整个三元组网络取的总正负样本的对数为 N 对。

从公式中我们可以看出, 三元组损失的作用是作用于正样本对和负样本对之间的距离累积值, 当累积值大于一定该阈值时, 将没有损失值, 小于阈值时才有损失。通过这种损失函数的计算方式, 网络模型可以将不同标签的行人图像之间的距离拉的更开。与交叉熵损失函数训练得到的辐射状分布情况不同。三元组的训练结果表明, 其样本分布状态呈簇状分布, 同类样本分布集中, 不同类的样本簇之间又明显间隔。该结果很好显示了三元组损失函数的作用, 也使训练得到的参数模型对难样本和细节信息更具有辨别力。

3.3.5 难样本采样三元组损失

虽然三元组损失已经有了明显的优点, 但不能忽视的是当应用三元组损失时, 训练选取图片的采样策略也非常重要。原始的三元组损失存在训练效率低, 收敛慢的缺点。因此在三元组损失的基础上, 一种改良版的三元组损失被提出, 其主要思想是通过所谓的 PK 采样方法进行在线难样本的三元组采样。该方法随机采样 P 个身份, 然后对每个身份随机抽取 K 个图像, 形成一个大小为 $P \times K$ 的小批量样本集 (mini-batch)。对于一个小批量内的训练样本, 难样本采样三元组损失只挑选其中最为困难的三元组组合参与 loss 的计算。该采样过程也被称为在线硬实例挖掘 (OHEM)。难样本采样三元组损失函数的表达式如公式 (3.9) 所示:

$$L_{hardtriplet} = \frac{1}{PK} \sum_{i=1}^{PK} [m + \max D^+(f_{\theta}(x_i^a), f_{\theta}(x_i^p)) - \min D^-(f_{\theta}(x_i^a), f_{\theta}(x_i^n))]_+ \quad (3.9)$$

公式分别使用 $\max D^+(\cdot)$ 、 $\min D^-(\cdot)$ 来表示分别在一个批次中挑选正样本间差异最大的对, 和在一个批次中挑选负样本间差异最小的对。其他符合的解释参考公式 (3.7)、(3.8)。

总的来说, 公式 (3.9) 在每一个批次中都使用了正样本差异最大, 负样本差异最小的样本对, 也就是该批次中最难的样本对参与损失函数值的计算, 也就是说对当前模型最难的样本, 这种策略体现了难样本挖掘的思想。与传统的三元组

损失函数相比,能够关注到数据集中一些更难分辨的样本,因此难样本采样的策略可以加快网络的收敛速度,提高了网络的训练效率,使网络可以收敛到更优解。

3.3.6 损失函数实验参数与配置

在上一节中,论文介绍了基础的分类和检索的损失函数,以及它们的改进版本。因此本章将对在整个网络模型框架中的损失函数环境进行研究和讨论。本节直接使用 ResNet-50 网络作为网络结构的准线,分别与不同的损失函数组合,进行对比实验,以量化不同损失函数对模型性能的影响结果。该对比实验在数据集 Market-1501 上进行。

对于交叉熵损失和标签平滑的交叉熵损失这两个分类损失,论文使用网络模型对图像提出特征向量,将输出的特征向量送入全局的平均池化层将特征降维至 2048 维,然后依次通过全连接层,RELU 层和 BN 层,将特征映射到输出分类的标签上。如数据集 Market-1501,训练集的行人身份一共有 751 个,则最后的全连接层的输出映射对应为 751 维。

对于三元组损失和难样本采样三元组损失这两个检索损失函数的使用,行人在通过 ResNet-50 的特征提取后,经过一个全局的平均池化层将特征降维至 2048 维,直接与损失函数进行搭配使用,进行训练。

本章实验的环境配置为:计算机为 Ubuntu16.04 系统,2 块 GTX 1080Ti 显卡,CPU 处理器 i7-6700,Pytorch 深度学习平台;输入图像大小为 384×128 ;使用 SGD 作为优化器,动量为 0.9,权重衰减系数为 5×10^{-4} ;学习率为 0.01;模型训练总迭代次数为 60 代;学习率的衰减系数为 0.1,在 40 代进行衰减,学习率变为 0.001;训练使用的批尺寸 batchsize 为 32。本章实验使用在 ImageNet 上预训练的 ResNet-50 模型进行 fine-tune,所使用的数据集为 Market-1501,实验结果在该公开数据上进行对比和展示。

3.3.7 实验结果与分析

在实验中,采用的损失函数的具体设置如下所示:

(1) 交叉熵损失和标签平滑的交叉熵损失:这两种损失函数非常相似,在

实验中，标签平滑的交叉熵损失仅对标签加入了常数分布的噪声。

(2) 三元组损失：一个批次中对 300 对标签的样本三元组进行随机选择样本，阈值的参数设置： $m=1.2$ 。

(3) 难样本采样三元组损失：在一个批次中，对 $P=16, K=4$ 的样本组进行均匀选择样本，阈值的参数设置： $m=1.2$ 。

在 Market-1501 上不同损失函数的实验结果如表 3.1 所示。

表 3.1 不同损失函数对比实验

损失函数	Rank-1	mAP
交叉熵损失	85.3	68.5
标签平滑的交叉熵损失	86.0	69.9
三元组损失	86.5	70
难样本采样三元组损失	87.7	73.1

从表 3.1 的结果中可以看出：

(1) 同为分类损失函数，标签平滑的交叉熵损失较交叉熵损失的性能有所提升，说明它的标签平滑机制在行人重识别任务中确实发挥了作用，能够减少模型过拟合，通过这样的方式比可以一定程度的提高识别精度。

(2) 与实验的结果中对三元组损失和交叉熵损失进行对比，检索损失的整体表现都优于分类损失的表现。这说明在行人重识别任务中，检索损失的确可以学习到令样本的分布类内距离小，类间距离大的特征，网络对行人特征识别的辨别能力得到了提升。

(3) 对比难样本采样三元组损失和三元组损失的结果发现，加入难样本后，三元组损失的效果得到了一定的提升。这一点验证了前面的理论分析。难样本采样的三元组损失使模型的辨别力更好。

3.4 多尺度网络结构设计

3.4.1 基本思想

从上文对行人重识别的介绍讨论中我们知道，将具有判别力的局部特征加入到全局特征中，可以提高网络模型重识别的能力。因此在本小节中，本文根据行人图像的结构特点，提出了将多尺度特征进行结合的网络结构，来帮助网络学习到更有判别力的行人的图像特征。最后以端到端网络的方式对行人图像进行特征

提取。

在网络的设计中，首先以多尺度水平切条的方式对特征图进行划分。在网络的后面，将每个切条局部分别进行全局平均池化和全局最大池化，然后将这两种池化结果进行拼接；最后网络将不同尺度水平切条的特征与全局特征拼接，得到最终的特征。用该特征进行行人重识别。论文希望以这种多尺度粗切条的方式，提高模型对人体局部特征的判别能力。

3.4.2 网络结构设计

根据在 3.2.1 小节中对行人特征的研究与分析，论文采用水平切条的粗划分局部特征提取的方式，引入松散的人体局部特征信息。将行人的局部特征和全局特征共同考虑，设计网络结构，以提高网络对行人细节特征的辨别能力。本文采用如图 3.2 所示的多尺度网络结构。




图 3.2 多尺度网络结构图

由于网络的主要的目的是通过端到端的方式在网络内部对行人局部特征和全局特征进行抽取，以此得到行人图像不同尺度的特征，所以本文将设计的网络结构叫做多尺度的网络结构。此外网络还将不同切条数目的局部特征进行融合。

在该网络结构中,对应全局特征和局部特征这不同尺度的特征提取,网络也相对应分为两大分支:局部和全局分支。进一步的说,在局部的分支中,网络分别采取切条数目为4和切条数目为6的方式对网络进行划分,最后再将特征提取的结果进行拼接,用以提取行人不同区域的局部特征;而全局分支则直接采用 ResNet-50 的网络对整张行人的图像输入特征提取,得到全局分支的输出向量。最终,论文将这两个分支分别提取的特征进行最后的拼接,形成最终的特征向量,然后使用该向量进行行人重识别的检索。

为了进一步更为详细的介绍本文设计网络结构,本文将整体的网络框架分为前端网络,局部分支,全局分支,以及损失函数这几个部分分别对该多尺度特征提取网络进行介绍。

1. 前端网络

首先要说明的是,对于本文设计的该网络框架,为了减少网络的参数量,降低网络的冗余,使该网络的训练收敛速度更快,该网络的全局分支部分和局部分支部分共用一个前端网络进行基本的特征提取。在这一部分的网络结构中,论文继续沿用 ResNet-50 的作为基本网络。在此基础上进行一些小的更改,将在 ImageNet 预训练的 ResNet-50 网络模型首先只使用 conv5_1 之前的网络作为前端网络,加载其预训练的网络参数。获得更大尺寸的基础行人图像特征,在 conv5_1 之后,该网络分别输出到局部和全局分支中去。

2. 全局分支

在该分支获得前端网络输出的特征图后,由于全局分支不需要过大的图像尺寸,因此首先会先送入 stride 为 2 的 conv5 残差块。然后网络使用多种损失函数进行监督学习。从 conv5 输出的特征图会再次被送入两个不同的分支。一个以分类损失函数为优化目标,因此在 max pooling, 512 维的全连接层, BN 层和 Relu 层后,最后连接一个维度为行人 ID 数的全连接层。该分支使用标签平滑的交叉熵损失进行训练;另一个分支在 512 维的 1×1 卷积层, BN 层、Relu 层、max pooling 层后输出 512 维的特征向量,与难样本采样的三元组损失训练完成检索任务。

3. 局部分支

由于局部特征分支中需要将输入的特征划分为多个的子区域,然后接上指定

的损失函数完成各自的训练。为了保证各个子区域拥有充分的信息，局部分支因此使用更大尺寸的行人图像特征图。与全局分支不同的是，conv5 去掉了原来 ResNet-50 中的降采样操作，该模块的步长变小至 1，以此扩大输出特征的尺寸，使其拥有更多的信息量。

局部分支同样采用多种损失函数对网络进行训练。从 conv5 模块中出来的特征会被分为两支，分别与检索损失和分类损失进行连接。其中的检索分支与全局分支的操作相似，256 维的 1×1 卷积层后，经过 BN 层、Relu 层、max pooling 层，输出 256 维的特征向量，以难样本采样的三元组损失监督组合。在分类支线，从前端网络出来的特征图分别在水平方向上均匀地切为 4 条和 6 条。每条通过 max pooling 层、256 维 1×1 卷积层、BN 层以及 Relu 层，最后输入到标签平滑的交叉熵损失中进行训练。由于人体局部特征不同，不同切条之间网络结构相同但参数不共享。

4. 损失函数

整个网络结构的局部分支和全局分支在上文种已经进行了介绍，每个分支又由两个不同的小分支组成，在分支中搭配不同的损失函数对网络完成训练。在每个小分支中，都有各自不同的损失函数进行监督和训练，最后的损失函数值是将所有分支的损失值相加得到。

更详细的说，对全局分支，它的损失函数由分类损失中的标签平滑的交叉熵损失和检索损失中的难样本采样三元组损失共同组成，如公式 (3.10) 所示：

$$L_{global} = L_{LSR} + L_{hardtriplet} \quad (3.10)$$

公式中 L_{global} 是全局支线的损失值， L_{LSR} 是分类支线使用的基于标签平滑的交叉熵的损失值， $L_{hardtriplet}$ 表示其中检索分支中的基于难样本采样三元组损失值。

同理，局部支线也由分类分支和检索分支共同构成。由于切条的缘故，局部支线存在多个平行分支，每一个块都有各自的损失函数连接训练。因此局部支线的完全的损失函数公式如公式 (3.11) 所示：

$$L_{local} = \sum_{k=1}^N L_{LSR}^k + L_{hardtriplet} \quad (3.11)$$

公式中 L_{local} 是局部支线的损失值， L_{LSR}^k 是分类支线中第 k 个切条块的基于

标签平滑的交叉熵损失值， $L_{hardtriplet}$ 是检索分支的基于难样本采样三元组损失函数值。如公式 (3.12) 所示，整体网络的损失值 L_{total} 由全局和局部损失值的总和构成。

$$L_{total} = L_{global} + L_{local} \tag{3.12}$$

3.4.3 实验配置与参数

本章中实验采用的基础配置与上节一致，因此不再赘述。基础模型仍采用有预训练参数的 ResNet-50 模型，测评在 Market-1501 公开数据集上进行。

3.4.4 实验结果与分析

在前文的网络结构介绍中，局部特征图是由水平横向切条得到，切条后的特征图继续送入神经网络中进行特征提取，最后每条分别接入损失函数进行计算。而这样切条的问题在于，在实际应用中不知道到切条数目多少是最合适的，切条过粗可能无法充分使网络关注到局部特征，而切条过细则可能使每条特征图中有效的信息过小，导致训练无法拟合收敛。因此在本节出，本文对切条的数目进行实验，寻找最优的切条组合数目。本节的实验首先只使用局部的切条分支，不使用全局分支进行实验，对比不同切条数目对准确率的影响，实验结果如表 3.2 所示。

表 3.2 不同切条数目对比实验

分割条数 p	Rank-1	mAP
1	85.2	68.3
2	89.0	71.9
4	91.9	76.1
6	92.2	77.4
8	91.5	76.0
12	91.0	74.4

观察实验结果中 Rank-1 的准确率，当切条数目从 1 开始增加时，准确率呈现先增加后减少的趋势。这个实验结果与理论推论相符合，当对特征图切条过少时，局部特征的效果不显著，与全局特征比较相似。当切割的范围逐渐缩小时，与全局特征的差异逐渐明显，局部特征的优势得到表达，准确率得到提高。但是

当分割数目超过 6 后，因为切条过细的缘故，每个特征图条内的信息过少，无法进行很好的语义特征提取，造成了准确率下降。因此，通过表 3.2 可知，在目前行人重识别的数据集上，切条数为 6 时，模型的性能达到最佳状态。

完成对切条数目的探究后，下面则对不同的网络分支进行实验探究。对全局特征和局部特征如何组合可以得到最好的性能进行实验讨论。理论上来说，全局特征和局部特征对图片的关注重点不同，具有一定的相互补充的作用，如果结合得当，是可以进一步提高网络识别的准确率的。因此在实验中，首先分别对局部分支当切条数为 6 时，结合不同的损失函数进行实验，然后对全局分支也结合不同损失函数进行实验，最后将全局分支分别和切条为 6 的局部分支结合，以及和切条为 4、6 的局部分支共同结合进行实验。实验效果如表 3.3 所示。

表 3.3 网络中不同分支的实验结果

分支网络	Rank-1	mAP
Global LSR	86.0	69.9
Global LSR + hardtriplet	90.0	74.3
Local6 LSR	92.2	77.4
Local6 LSR + hardtriplet	92.8	79.2
Global + Local6	94.4	84.5
Global + Local6 + Local4	95.0	88.1

在表 3.3 中，Global 代表全局分支；Local 代表局部分支，后面的数字代表具体切条的数目；LSR 表示该分支使用标签平滑的交叉熵损失函数；hardtriplet 表示该分支使用难样本采样的三元组损失。从实验结果可以得到以下分析：

(1) 对比局部分支和全局分支的实验结果，局部分支的表现更好，这说明，局部特征比全局特征的确对行人细节的判别力更好，所以单独使用时，准确率会高于全局分支。

(2) 对于损失函数而言，观察全局分支和局部分支的实验结果可以发现，一起使用难样本采样的三元组损失和标签平滑的交叉熵损失函数对学习有判别力的特征更有帮助。

(3) 虽然全局分支的识别准确率不如局部分支，但是实验发现，当将两个部分的特征进行融合之后，识别准确率可以进一步提高，这种实验现象可以说明全局和局部特征的确有相互补充的作用。

最后实验证明全局分支和切条分别为 4、6 的局部分支进行融合时，Rank-1

准确率为 95.0、mAP 为 88.1，达到最好的识别结果。该多尺度特征融合的网络结构的确能够提取更有判别力的特征，识别准确率更高。

论文将把多尺度特征融合的网络框架的实验结果与其他算法结果的对比放在表 4.5、4.6 进行集中展示与对比分析，在此不进行赘述。

3.5 本章小结

本章中对如何得到更好的行人重识别的多尺度特征进行研究。首先对网络使用的损失函数进行讨论和实验。实验结果证明，在训练行人重识别特征提取网络时，使用改进的标签平滑的交叉熵损失函数和难样本采样的三元组损失函数的效果更好。

然后，论文将行人的全局特征和局部特征进行多尺度融合，讨论并验证了多尺度特征的有效性。多尺度特征结合标签平滑的交叉熵损失函数和难样本采样的三元组损失函数进行训练学习，在 Market-1501 上取得了 Rank-1 准确率为 95.0、mAP 为 88.1 的结果。实验同时也验证了全局特征和局部特征的互补性。

第4章 行人重识别中的重排序框架研究

4.1 引言

在现实场景中,行人重识别任务往往是通过监控视频进行的,因此存在大量的关于身份人的图像可以利用。在基于多个图像的重识别的研究中,检索使用多张目标人的视频帧的图像而不是单个图像。这样做的意义在于,提供目标人的多张图像特征作为检索,可以使目标人的特征更为丰富全面,从而可以提高重识别的准确性。因此基于多个图像的重识别方法更适合于实际场景的任务。目前,现有研究与现实应用之间仍存在很大差距。例如,基于多个图像的重识别的主流方法是通过计算所有图片的平均特征向量作为该行人的特征,该方式使得多个图像的特征的多样性没有得到充分表达。因此论文考虑为每张检索的图片都进行特征提取并分别独立进行检索任务,而不是对多个图像特征取平均值,用这种方式来充分挖掘查询图像的信息。

此外,基于多个图像的重识别还存在一个问题:视频序列中的相邻帧图像具有很大的相似性。因此当直接使用连续的视频帧时,图像之间的冗余度,也就是重复性很高。这造成很多不必要的计算开销,影响了检索任务的速度。因此,在论文考虑在使用多个图像分别进行查询之前,要对多张图像的视频帧进行评价,选择出更有代表性的图片作为查询图片,最后才对其查询结果进行聚合。

为了解决以上问题,本章节提出将基于多个图像的重识别方法和重排序方法结合起来进行行人重识别任务的方法:基于图像池的重排序框架。首先,该框架以最优化查询图像特征的多样性和可靠性为准则从每个目标人的连续视频帧或多图图集中选取固定张数的图片,命名为该目标人的图像池。其次,为了实现提高行人重识别检索结果准确性的目标,该框架将每张图片检索的结果进行聚合,聚合过程中将多张图片检索结果的排序列表中的每张图像进行打分,置信度越高的图片分数越低。然后按照该分数对初始排序列表进行升序重排序,最终得到一个新的检索结果的排序列表。

4.2 相关工作

4.2.1 基于多图的行人重识别

传统的基于多个图像的重识别方法从图像序列中提取信息,这些方法随着时间收集同一个身份人多张图的兴趣点描述符^[36],以及在多个帧上训练得到特征分类器^[37]。此外,基于多图的行人重识别还用到了基于监督学习的方法,例如学习保持低维度流形的距离^[38],或学习序列外观之间的映射^[39]。此外,还有一些基于多个图像的重识别方法使用了建模视频的方法。例如使用条件随机场(CRF)来确保视频序列中的类似图像接收相同的标签^[40]。还有一些作品从目标人的视频序列中选择了关键帧来减少多个图像作为查询时图像之间的冗余。例如,cong等人的研究^[41]选择了10个关键帧,然后以块稀疏恢复^[42]的方式构造特征字典D来建模高维视觉特征。

McLaughlin等人在2016年首次将深度学习应用于解决基于多个图像的重识别问题。该研究使用长短期记忆(LSTM)网络以循环方式聚合人物特征。通过该研究可以看到,以LSTM网络聚合特征的方式虽然可以有效地提高精度,但随着多图像的数量增加,重识别的精度将趋于饱和,不再随着图像数量的增加继续上升。此外,该方法还存在的问题是时间复杂度太高,无法满足实际应用中实时的要求。

行人重识别这项任务,根据训练和测试类之间的关系进行考虑可以发现,该任务介于图像分类和实例检索之间。因此,可以考虑将在分类任务^[43]和检索任务^[44]中取得有效成果的工作迁移到行人重识别任务中来。例如,在分类任务中,AL-LUPI^[45]使用了多样性和不确定性测量对多张图像的集合进行评价,使用该准则来确保所选样本具有代表性。因此,本文将参考AL-LUPI并提出图像池代表图像选择的准则。

4.2.2 重排序方法

重排序是可以通过初始排序列表和相关图像获得检索结果准确度更高的方法。k-reciprocal encoding利用k近邻方法探索相似关系来实现重排序。排序列表中每个图像的新分数是通过其在排序列表中的位置计算得到的,然后以该分数作为重排序的依据。为了利用负样本,Arandjelovic等人还通过使用线性SVM开发查询扩展,使用到决策边界的距离来修改初始排序列表进行重排序。Common-Near-Neighbor^[46]方法则组合每对样本的相对信息和直接信息以获得重排序的结

果。而基于判别式上下文信息分析的重排序方法^[47]从不同的特征表示中获得初始排序列表，然后采用 Stuart 排名聚合的方法来组合成互补的排序列表。总的来说，行人重识别的重排序方法是一个非常值得研究的方向。它可以以较小的计算成本作为代价，大大的提高行人重识别检索结果的准确性。

4.3 图像池的选择

在多镜头的监控中，系统可以获得同一行人许多来自不同镜头的很多图像。论文认为同一目标人丰富的图像可以提供该行人更多更全面的特征，从而可以提高行人重识别的准确率。因此为了存储每个行人的多张图像样本，论文定义图像集合——图像池（Image Pool）来储存从监控视频中收集提取的目标人图像。每个目标人的图像池定义为 $\Omega_{ID} = \{q_i | i = 1, 2, \dots, M\}$ ，其中ID是该目标人的标签， q_i 表示图像池中的第*i*个像。 图像池的示例如图 4.1 所示。

图像池							
镜头 1	镜头 2	镜头 3	镜头 4	镜头 5	镜头 6	镜头 7	镜头 8
I (n ₁ , 1)	I (n ₂ , 4)	I (n ₃ , 7)	I (n ₄ , 10)	I (n ₅ , 13)	I (n ₆ , 16)	I (n ₇ , 19)	I (n ₈ , 22)
I (n ₁ , 2)	I (n ₂ , 5)	I (n ₃ , 8)	I (n ₄ , 11)	I (n ₅ , 14)	I (n ₆ , 17)	I (n ₇ , 20)	I (n ₈ , 23)
I (n ₁ , 3)	I (n ₂ , 6)	I (n ₃ , 9)	I (n ₄ , 12)	I (n ₅ , 15)	I (n ₆ , 18)	I (n ₇ , 21)	I (n ₈ , 24)

图 4.1 目标人的图像池的示例图

目标人的图像池被定义好后，下一步的任务则是获得图像池的图像，以及对图像池中参与检索的图像进行选择。在实际应用中，图像获取可以通过行人检测

和自动跟踪的系统来完成初始化^[48]，由于本文的研究重点是行人重识别，所以这里将不对图像获取收集进行更多的讨论，而将研究关注的重点放在如何选择图像池上，以使图像池的图像更具有代表性。

当使用基于多图像的数据集对论文提出的框架进行测评时，实验时只需要根据最大化多样性的准则对每个图像序列直接进行选择。当使用基于图像的数据集进行测评时，首先会将每个单张的查询图像视为图像池的主图像，然后通过访问标签的方式，按照最大化多样性的标准选择图像组成图像池。

在选择图像池图像时，除了考虑要使图像池中样本的多样性尽可能大之外，还需要考虑使图像池中样本的不确定性尽可能小。换句话说，图像池中不仅希望有某行人更多的不同的图像，使得图像池拥有的行人的特征图像尽可能的全面；图像池还希望引入的图像的查询结果是可信度高的，而不是一些拥有复杂背景和噪声的图像。因此，受 AL-LUPI 的启发，结合最大化多样性和查询结果的可靠性，论文提出了图像池选取的判别准则如下。

其中公式 (4.1) 用来计算不确定性度量，不确定性越小则查询结果的可靠性越高。 $P_i(i = 1, 2, \dots, M)$ 用来表示原图像池 $\{q_i | i = 1, 2, \dots, M\}$ 中每张图像的不确定性度量。在公式 (4.1) 中，首先计算图像 q_i 与图像池的每一个其它图像之间的欧式距离，并按递增顺序对它们进行排序。然后取排序结果中与该图像之间最小的欧式距离值，记为 $E(q_i, q_{top1})$ 。和第二小的欧式距离值，记为 $E(q_i, q_{top2})$ 。将它们之间的差值作为分母。此外为了避免分母为 0 的可能，在分母中加入一个无限接近零的常数 ε 。公式代表的意义是， $E(q_i, q_{top1})$ 和 $E(q_i, q_{top2})$ 越接近，则查询的结果稳定性越好，该查询图像的可靠性越高。在公式中其分母越小， P_i 值就越大。因此，大的 P_i 表示该图像不确定性小，其查询结果可靠性也就越高。

公式 (4.2) 用来计算图像 q_i 与图像池的每一个其它图像之间的欧式距离的均值。

公式 (4.3) 用来计算图像 q_i 与图像池的每一个其它图像之间的欧式距离的方差。某种程度上，方差可以用来描述样本的分布。所以论文使用方差来表达图像 q_i 和整个图像池样本之间多样化的关系。方差越大，则代表该图像与图像池整体的差异越大。

$$P_i = \frac{1}{|E(q_i, q_{top1}) - E(q_i, q_{top2})| + \varepsilon} \quad (4.1)$$

$$\bar{E}_i = \frac{1}{M} \sum_{n=1}^M E(q_i, q_n) \quad (4.2)$$

$$s^2_i = \frac{1}{M} \sum_{n=1}^M [E(q_i, q_n) - \bar{E}_i]^2 \quad (4.3)$$

$$\lambda_i = \frac{P_i}{s^2_i} \quad (4.4)$$

最终综合考虑图像的不确定性和多样性提出图像池选取的判别值 λ_i ，如公式(4.4)所示。在图像池图像选取过程中，计算每一个候选图像的 λ_i 并按照降序进行排序。图像池需要几张图像就按 λ_i 的排序从候选图像中选取前几张。

4.4 基于图像池的度量距离

在本节中，论文将对基于图像池的度量距离进行介绍。欧式距离只能计算一张图像到另一张图像的距离，而基于图像池的度量距离则用于描述整个图像池与某单张图像之间的欧式距离。图库集 G 表示为 $G = \{g_j | j = 1, 2, \dots, N\}$ ，其中 N 是图库集中图像的总数。 g_j 是图库集中的第 j 个图像。

公式(4.5)中用 $f(g_j, q_i)$ 描述查询图像 q_i 和图库集中的图像 g_j 之间的相似性。

$$f(g_j, q_i) = \begin{cases} \frac{1}{E(g_j, q_i)} & E(g_j, q_i) \leq T \\ 0 & E(g_j, q_i) > T \end{cases} \quad (4.5)$$

在公式(4.5)中， $E(g_j, q_i)$ 是单张查询图像 q_i 和图库图像 g_j 之间的欧式距离。如果该值大于阈值 T ，则认为这两个图像非常不相似，不可能为同一身份人的图像，并且将相似性度量 $f(g_j, q_i)$ 的值设为0。如果该数量小于等于阈值 T ，则简单地将相似性度量 $f(g_j, q_i)$ 的值等于其欧式距离的倒数。该阈值函数的意义在于，在计算过程中，某些图像之间的欧式距离值过大，这些图像显然不是需要找到的目标人的图像。因此论文在公式中设置阈值 T 以减少计算量。

在此基础上，本文定义每张图库集中的图像到某一身份人的图像池之间的欧式距离为 $S(g_j, \Omega_{ID})$ ，其计算公式如公式(4.6)所示。

$$S(g_j, \Omega_{ID}) = E(g_j, q_{main}) - \sum_{i=1}^M \left[W_i \cdot \frac{\eta f(g_j, q_i)}{\sum_{i=1}^M f(g_j, q_i)} \cdot E(g_j, q_{main}) \right] \quad (4.6)$$

公式中， q_{main} 是每个图像池的主查询图像，在不同的测评环境中主查询图像

的定义不同。在基于单张图像的数据测评集上,主查询图像就是当前测评的查询图像,然后通过访问标签,按照4.2小节中图像池选取的判别准则选择图像组成图像池。在基于多图像的数据集上进行测评时,主查询图像则是按照4.2小节中图像池选取的判别准则直接选取图像集合中 λ_i 值最大的图像,图像池的其它图像被称为辅助查询图像。

此外,公式中 $E(g_j, q_{main})$ 是主查询图像和图库集图像 g_j 之间欧式距离。 η 是用来决定辅助查询图像在计算中重要性的尺度因子。 $W_i (i = 1, 2, \dots, M - 1)$ 是每个辅助查询图像的权重。通过以上的公式可以计算所有辅助查询图像检索的结果对主查询图像检索结果的影响。然后,通过主查询图像到图库集图像 g_j 的欧式距离减去辅助查询图像对主查询图像检索结果的总影响,最终得到 $S(g_j, \Omega_{ID})$,它表示的就是图库集图像 g_j 和图像池之间的相似性。

基于图像池的度量距离算法给出了一种单个图像到一组图像之间距离的计算方法。然而,该方法仍然有需要改进的地方:

在基于图像池的度量距离中,除了超参数 W_i 之外,需要进行大量的实验和训练进行调整,很难对公式中的一些参数设置非常合适的值,如阈值 T 和缩放因子 η 。

为了得到 $S(g_j, \Omega_{ID})$,论文计算了每个图库集图像和每个图像池图像对之间的欧式距离。假设图库集的大小为 N ,其计算的时间复杂度为 $O(N^2)$,这在实际计算中是非常耗时且效率低下的。因此,论文采取的解决办法是先计算得到原始的排序列表,然后只取列表中排名靠前的图像,计算基于图像池的度量距离并对原始列表进行重排序,以此来大大减少计算量。

4.5 基于图像池的重排序框架

为了进一步优化基于图像池的度量距离算法,减少时间开销和计算复杂度,论文以基于图像池的距离算法作为理论依据,提出基于图像池的重排序框架。论文仍延续基于图像池距离中主查询图像的概念,计算主查询图像 q_{main} 与图库集 $g_j (j = 1, 2, \dots, N)$ 中所有图像之间的距离,将距离从小到大排列得到初始的主查询图像的排序列表 $R(G, q_{main}) = \{g_1^{main}, g_2^{main}, g_3^{main}, \dots, g_N^{main}\}$ 。同理,依次计算

得到图像池中其他图像（辅助查询图像）的排序列表 $R_k(G, q_i) = \{g_1^i, g_2^i, g_3^i, \dots, g_k^i\} (i = main, 1, 2, \dots, M - 1)$ 。将排序列表中的前 k 位图像取出进行重排序，其中，主查询图像的排序列表取前 k_1 个图像进行重排，辅助查询图像的排序列表取前 k_2 个图像进行重排。

与 4.4 节一致，对于基于单张图像的数据集，每个查询的图像将轮流被视为图像池的主查询图像。对于基于多图像序列的数据集，使用 PRID 2011 数据集中的评估协议进行评估。基于图像池的重排序框架得到的结果可以代表整个序列的检索结果。

基于图像池的重排序算法的流程图如图 4.2、图 4.3 所示。其中图 4.2 算法(a) 对主查询图像与图像池中其他辅助查询图像的排序列表中被检索到的图像进行匹配，被检索到的图像在排序列表出现的次数越多，其 $Rank(g_i^1)$ 的值就越小，在重排列表中的排名就越靠前。图 4.3 算法 (b) 对生成的新列表 $\{Rank(g_i^1) | i = 1, 2 \dots k_1\}$ 进行冒泡排序， $Rank(g_i^1)$ 的值小的图像在重排列表中的排名越靠前，最后得到最终重排序列表。算法应用于实际情况的说明如图 4.4 所示，为了简单说明，图像池中的图像仅取三张。




图 4.2 基于图像池的重排序算法 (a)




图 4.3 基于图像池的重排序算法 (b)

在基于图像池的重排序算法中， $Rank(\cdot)$ 用于记录在主查询图像中的每张被检索到的图像的排序分数，该值使用其主查询图像的排序列表中的初始排序次序进行初始化。 $Times(\cdot)$ 用于记录该被检索到的图像在辅助查询图像的排序列表中被查询到的次数， $Times(\cdot)$ 用 0 进行初始化。每次在辅助查询图像的排序列表中被查询到时， $Rank(\cdot)$ 的值的都增加 $k1 * M - Times(g_i^{main})$ 的值。 $Rank(\cdot)$ 的计算准则表明，检索结果图像的排序分数不仅与其初始的排序位置有关，还与其在辅助查询图像的排序列表中被查询到的次数有关。图像在给定长度的排序列表中被检索的次数越多，它的排序分数就越低，最终经过算法 (b) 的冒泡排序后，它的排名位置就越靠前。




图 4.4 基于图像池的重排序算法的实际应用说明图

在图 4.4 中，ranking list 是指图像池中的查询图像与图库集计算相似度最大的前 k 位的排序列表。在该应用中，主查询图像的 k_1 值取 10，辅助查询图像的 k_2 值取 5。图中，相同彩色框的图像是同一张图。从说明图中我们可以看到，红框框住的图像在图像池中所有查询图片的排序列表中都出现了，而绿色，蓝色，黄色分别在主查询图像的排序列表和其中一个辅助查询图像的排序列表中出现，图像在各个排序列表中出现的次数越多，出现的位置越靠前，其排名分数就越低。按照排名分数对主查询图像的初始排序列表进行重新排序，将红框的图像序列提到最前，其他颜色盒子按照其在主查询图片中的次序依次提到列表的前面，最终得到了重排序列表。该图就是对基于图像池的重排序算法的流程进行一个直观の説明，帮助对该算法有更好的理解。

在有了基于图像池的重排序算法以后，可以画出完整的基于图像池的重排序框架，如图 4.5 所示。在图中，给定一个图库集（有 N 个图像）和一个包含某个身份人的最大化多样性的 M 个图像的图像池。通过卷积神经网络对每张图提取特征向量。然后计算每对查询图像和图库图像的距离。初始排序列表是按欧式距离升序获得。重排列表由基于图像池的重排序算法计算获得的。




图 4.5 基于图像池的重排序框架

4.6 实验配置与参数

本章实验的环境配置为：计算机为 Ubuntu16.04 系统，2 块 GTX 1080Ti 显卡，CPU 处理器 i7-6700，Pytorch 深度学习平台；输入图像大小为 256×128 ；使用 SGD 作为优化器，动量为 0.9，权重衰减系数为 5×10^{-4} ；学习率为 0.01；模型训练总迭代次数为 60 代；学习率的衰减系数为 0.1，在 40 代进行衰减，学习率变为 0.001；训练使用的批尺寸 batchsize 为 32。

为了更直观的验证基于图像池的重排序框架的有效性，本节实验中在 ImageNet 上预训练的 ResNet-50 模型的基础上进行训练，从 ResNet-50 输出的 2048 维向量作为最终的向量特征；以 ResNet-50 和交叉熵损失函数训练的网络模型作为准线，进行图像池参数分析实验和图像池选取判别准则分析实验。而与其他算法结果的对比实验则结合上文中探索的多尺度网络模型和重排序框架与其他前沿算法的分数进行对比，以显示基于图像池的重排序框架的有效性。

实验在四个数据集上进行验证。两个基于多图像序列的数据集：PRID 2011 和 iLIDS-VID 数据集。一个基于单张图像的数据集 Market-1501，和本论文收集建立的室内火车站数据集（ITSD）。在基于单张图像的数据集上，评价采用累积

匹配特征 (CMC) 和平均精度 (mAP) 两个评估指标, 在基于多图像序列的数据集上, 评价仅采用 CMC 评估指标, 评估协议遵循 PRID 2011 数据集中的设置。

4.7 实验结果与分析

4.7.1 图像池参数分析实验

4.7.1.1 图像池中的图像数量 M 的分析

M 是图像池中的图像数量, 该参数决定要参与重排序的排序列表的个数。在参与重排序的排序列表中, 有一个主查询图像的初始排序列表, 取该初始排序列表的前 k_1 个查询结果参与重排序; 此外, 还有 $M-1$ 个辅助查询图像的初始排序列表, 取该初始排序列表的前 k_2 个查询结果参与重排序。为了研究 M 对基于图像池的重排序框架性能的影响, 我们简单地将 k_1 和 k_2 都设为固定值 10, 在 Market-1501 数据集上进行实验, 探究不同 M 值对准确率的影响, 实验结果在表 4.1 中显示。

表 4.1 图像池中的图像数量 M 对基于图像池的重排序框架性能的影响

M 数量	Rank-1	mAP
1	73.28	47.87
2	81.77	52.27
3	85.15	51.62
4	86.05	51.60
5	85.84	50.95

M 等于 1 时相当于没有使用论文的重排序框架, 可以将它的实验结果看成准线。在当 M 大于 1 时, 表 4.1 中的实验结果可以看出, 重排序框架对 Rank-1 和 mAP 都有显著的提高。当 M 小于 3 时, Rank-1、mAP 随着 M 的增加而增加, 当 M 大于 3 时, mAP 开始减小。当 M 等于 4 时, Rank-1 获得 13.22% 的提升, mAP 获得 3.73% 的提升。通过查看 Market-1501 的测试集发现, 该测试集包含 750 个身份的 3,368 个图像, 其中 27 个身份具有少于 3 个查询图像, 115 个身份具有少于 4 个查询图像, 98 个身份具有最多 6 个查询图像。查询图像过少, 导致当 M 增加时, 查询图像的不足会影响到 M 增大对性能提高的作用。因此, 在

查询图像集规模较小时，M 取 3 或 4 时性能最佳。同时考虑到系统计算速度的时间开销，在以下基于单张图像的数据集上实验时，M 采用的值为 3。

4. 7. 1. 2 查询图像的排序列表长度 k1, k2 的分析

由于图像池的查询图像的排序列表长度的值对重识别的准确率有很大影响。我们将主查询图像的排序列表长度设为参数 k1，其他查询图像的排序列表长度设为参数 k2。论文在图像池中图片数目为 3 的基础下，在 Market-1501 数据集上进行实验，探究不同 k1, k2 的值对准确率的影响，实验结果在表 4.2、表 4.3 中显示。

表 4.2 主查询图像的 k1 参数对基于图像池的重排序框架性能的影响

参数	Rank-1	mAP
k1=6,k2=6	82.24	50.69
k1=10,k2=6	85.72	52.07
k1=20,k2=6	88.90	52.66
k1=30,k2=6	89.85	53.53
k1=40,k2=6	90.56	57.79
k1=50,k2=6	90.88	58.80
k1=60,k2=6	91.09	59.45
k1=70,k2=6	91.75	59.31
k1=80,k2=6	91.48	60.59
k1=90,k2=6	91.45	61.00
k1=100,k2=6	91.54	61.33

表 4.3 辅助查询图像的 k2 参数对基于图像池的重排序框架性能的影响

参数	Rank-1	mAP
k1=70,k2=20	87.25	58.84
k1=70,k2=15	87.68	59.62
k1=70,k2=10	89.40	60.20
k1=70,k2=9	89.90	60.26

k1=70,k2=8	90.44	60.29
k1=70,k2=7	90.97	60.29
k1=70,k2=6	91.39	60.12
k1=70,k2=5	92.04	59.93
k1=70,k2=4	93.11	69.67
k1=70,k2=3	93.91	59.03
k1=70,k2=2	94.80	57.60
k1=70,k2=1	94.51	54.73

表 4.2 显示，当 k_1 从 6 增加到 100 时，当 k_1 为 70 时，Rank-1 精度达到最大值。此时，Rank-1 精度提高了 18.74%，mAP 提高了 13.46%。对实验结果进行分析，可以得到推论，当 k_1 超过 70 时，也就是 k_1 值过大时，性能开始下降的原因是大的 k_1 值可能会导致将更多的错误匹配的次序赋予小的排序分数，导致其被重排序到较前的位置，造成了性能的下降。

表 4.3 显示，当 k_2 从 20 减少到 1 时，当 k_2 为 2 时，Rank-1 精度达到最大值。此时，准确度提高了 21.52%，mAP 提高了 12.42%。对实验结果进行分析，当 k_2 超过 2 时性能开始下降的原因是大的 k_2 辅助查询图像的排序列表对参与重拍的图像质量要求更为严格，大的 k_2 值对性能的损害大于对性能的增益，因此 k_2 取较小的值可以保证引入少量的图像参与重排序计算，减少可能的错误匹配对性能造成的损害。

4. 7. 2 图像池选取判别准则分析实验

在这一部分中，论文将在 ITSD 数据集上进行实验，对图像池选取判别准则的有效性进行评估。实验的参数设置依据上节的图像池的参数分析实验得出的结论，将 M 设置为 3， $k_1=70$ ， $k_2=2$ 。在实验中，图像池的图像以三种不同的方式选取：随机选择、基于“稀疏恢复”的方法^[37]、和本文提出的图像池选取判别准则。在表 4.4 和图 4.6 中显示了不同方式选取图像池样本的 CMC（%）曲线的性能。

在表 4.4 中，将所有探测图像的平均特征的查询结果视为准线。(a) 是使用随机选择辅助图像的方法。(b) 是通过“稀疏恢复”方法选择辅助图像的方法。(c) 是通过本文提出的图像池选取判别准则来选择辅助图像。

表 4.4 不同选取图像池图像规则对基于图像池的重排序框架性能的影响

方法	Rank-1	rank-5	Rank-10	rank-20	mAP
准线	38.68	59.46	66.83	75.02	42.22
(a)	44.19	61.79	64.00	73.19	46.75
(b)	56.87	70.76	75.25	82.76	57.11
(c)	58.53	78.17	81.44	85.00	64.50




图 4.6 不同选取图像池图像规则在 ITSD 数据集上测评的 CMC 曲线图

表 4.4 和图 4.6 显示，当使用本文提出的图像池选取判别准则来选择辅助图像时，CMC(%)和 mAP 的性能是最好的：rank-1 准确度较准线增加了 19.85%，mAP 增加了 22.28%。此外，(c) 和 (a) 的结果对比表明，使用本文的准则选择辅助图像比随机选择图像可以大大提高查询图像的质量，使其具有很高的可靠性和多样性。(c) 和 (b) 的结果对比表明我们的方法优于“稀疏恢复”方法。

4. 7. 3 与其他算法结果对比

在本节中，论文在 Market-1501 数据集和两个基于视频的数据集 PRID-2011、iLIDS-VID 与现有行人重识别最新的研究的结果进行比较，结果在表 4.5、表 4.6 中显示。为了保证公平的比较，论文框架实验中使用的训练和测试评估准则和分割协议采用通用的协议规定。

在 Market-1501 数据集的对比实验中，分别采用 ResNet-50 和交叉熵损失函数训练的网络模型和第三章提出的多尺度融合网络（Multi-scale network）训练的网络模型分别与本文提出的基于图像池的重排序框架（MJR）和 k-reciprocal re-

ranking 重排序方法分别组合进行实验，然后与其他最新的研究结果进行比较。在实验中，M 设定为 3，k1 设定为 70，k2 设定为 2。对比结果如表 4.5 所示。

表 4.5 在 Market-1501 数据集上与现有算法的对比结果

方法	Rank-1	mAP
Bow+Kissme ^[49]	44.42	20.76
PIE ^[46]	79.33	55.95
SVDNet ^[50]	80.5	55.9
TinNet ^[51]	84.92	69.14
GLAD ^[52]	87.9	71.0
CamStyle ^[53]	88.12	68.72
HA-CNN ^[54]	93.8	82.8
ResNet-50+Softmax loss	86.0	69.9
ResNet-50+Softmax loss+Re-ranking	90.11	80.5
ResNet-50+Softmax loss+MJR	94.8	79.52
Multi-scale network	85.78	69.11
Multi-scale network+Re-ranking	95.0	88.1
Multi-scale network+MJR	96.57	85.30

表 4.5 中结果显示，使用本文提出的基于图像池的重排序框架可以使不同的准线模型：ResNet-50 和交叉熵损失函数训练的网络模型和多尺度融合网络训练的网络模型的 rank -1 和 mAP 都有大幅的提升。当模型是通过 ResNet-50 和 Softmax loss 训练得到时，对比没有使用本文提出的重排序框架，使用该框架使 rank -1 准确度获得了 8.8% 的提高，mAP 增加 9.62%。当模型是通过多尺度融合网络训练得到时，rank -1 准确度获得了 11.77% 的增加和 16.19% 的 mAP 提升。并达到论文在该框架下实现的最佳结果：96.57%rank -1 准确度和 85.30% mAP。该实验结果证明了论文提出的多尺度融合网络的先进性和重排序框架的有效性。与无监督重排序方法 k-reciprocal re-ranking 相比，我们的方法取得了更好的结果，这证明了基于图像池的重排序方法比无监督的重排序方法在有多图可以利用的情况下，将获得更多性能的提升。

在 PRID-2011、iLID-VID 数据集的对比实验中，采用多尺度融合网络（Multi-scale network）训练的网络模型和基于图像池的重排序框架组合进行实验，与其他最新的研究结果进行比较。在实验中，M 设定为 3，k1 设定为 70，k2 设定为

2. 对比结果如表 4.6 所示。

表 4.6 在 PRID-2011、iLID-VID 数据集上与现有基于视频的算法的对比结果

方法	PRID-2011 Rank-1	iLIDS-VID Rank-1
VR ^[55]	42	35
AFDA ^[56]	43	38
STA ^[1]	64	44
RFA ^[7]	64	49
RNN-CNN ^[6]	70	58
ASTPN ^[57]	77	62
Multi-scale network+MJR	81	66

从表 4.6 的结果可以看出，论文的重排序框架在 PRID-2011 和 iLIDS-VID 数据集上实现了比其他方法更高的性能。Rank-1 的值在 PRID-2011 和 iLIDS-VID 数据集的提升分别为 3.2%和 1.7%，该结果证明了多尺度融合网络和重排序框架的组合在基于视频的数据集上也有好的表现。

4.8 本章小结

本章首先对基于多图像的行人重识别工作的意义进行说明，在此基础上提出基于图像池的重排序框架。在重排序框架的研究中，首先介绍了图像池的选取准则，依照论文提出的不确定性最小以及多样性最大化的准则选择图像池中的图片。在实验中，通过与其他方法的对比，也验证了论文提出的方法的有效性。当图像池的图片确定后，本章定义了单张图像到图像池的距离，在此基础上提出了基于图像池的重排序框架。对每一个目标人，通过利用其图像池图像的初始检索的排序列表信息，对该目标人与图库集图像之间的距离进行重新评估，最后生成重排序列表。论文通过与不使用该框架的结果和其他算法的结果进行比较，共同验证了该框架的有效性。

第5章 总结与展望

5.1 本文总结

近年来,随着人工智能技术的发展,越来越多的技术被考虑到实际应用到实际场景,对人类生活提供更多高效、智能的帮助。行人重识别任务从提出到今天,也一直拥有这样的目标。希望通过不断的研究创新和技术发展,将不同摄像头下行人检索,匹配这样的任务做好。在研究中发现,由于存在实际场景的复杂背景,人类姿态的多样性,拥挤环境的遮挡问题,以及镜头之间视角和照明的变化等等,这给行人重识别任务带来很大的挑战。行人重识别至今仍是一个非常困难的任务,较人脸识别而言,监控场景下的行人特征很难进行较为精确的特征对齐,因此在特征之间的匹配存在很大的难度。对于这样的问题,设计出能提取更有鲁棒性特征的深度学习网络成为研究关注的重点。本文的主要工作为以下两点:

(1) 根据行人图片结构性单一且明确、行人之间的局部细节差异细微的特点,论文设计了一种融合了行人多尺度特征的网络。该网络可以兼顾到人体全局特征和局部特征,为行人重识别任务提取到更有辨别力的特征。此外,由于损失函数作为嵌入学习的监督工具,损失函数的使用也对特征的辨别力有很大影响。因此本文结合标签平滑的交叉熵损失和难样本采样的三元组损失对论文设计的多尺度特征网络进行训练学习,在多损失函数的监督下,综合得到一个端到端的多尺度特征提取网络。该网络模型可以提取具有辨别力的特征,提高行人重识别的准确率。

(2) 此外考虑到在实际监控视频环境中,存在大量的关于身份人的图像可以利用,当网络模型的特征能力到达瓶颈时,希望对所有可利用的数据进行更为充分的使用,以继续提高行人重识别的准确率。因此,本文提出了基于图像池的重排序框架。通过利用同一身份人的图像池中的多张图像的初始检索的排序列表的信息,对该目标人与图库集图像之间的距离进行重新评估,然后生成重排序列表。该重排序框架在牺牲一定实际计算时间的基础上,进一步提高了行人重识别检索结果的准确性。

5.2 研究展望

本文针对行人重识别研究课题中的不同尺度的行人特征和重排序框架都开展了讨论,进行了较为深入的研究。在现有研究基础上,使用粗切条的方式对行人的全局特征和局部特征进行了结合。但是这种无监督的粗切条的方式有时候会将相同部位分割开,使每一条的局部特征块无法具有特定有意义的语义。此外,每条局部特征之间有冗余重复,局部特征不明确。因此,未来对于行人重识别的特征研究,会关注如何把姿态和关键点的信息更好的嵌入到网络结构中,帮助网络学习到更准确映射的局部特征。

行人重识别算法模型的一大应用是多目标跟踪,因此本文提出的基于图像池的重排序网络框架在实际应用中的确可以切实有效的提高行人重识别的准确率。但是该框架没有太多考虑到计算速度的问题。而在实际应用对算法模型的实时性是有很高要求的,因此未来可以对该框架的计算速度进行进一步优化。此外,由于深度学习的不断发展,可以考虑将多图聚合的操作直接通过网络进行,集成成一个端到端的网络。

参考文献

- [1] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C]//2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). IEEE, 2006, 2: 1528-1535.
- [2] Gray D, Brennan S, Tao H. Evaluating appearance models for recognition, reacquisition, and tracking[C]//Proc. IEEE International Workshop on Performance Evaluation for Tracking and Surveillance (PETS). Citeseer, 2007, 3(5): 1-7.
- [3] Shen X, Lin Z, Brandt J, et al. Object retrieval and localization with spatially-constrained similarity measure and k-nn re-ranking[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2012: 3013-3020.
- [4] 杜久伦. 多视图行人重识别算法研究与数据采集[D].山东大学,2017.
- [5] 彭志勇. 智能视频监控系统中的行人重识别方法研究[D].山东大学,2016.
- [6] McLaughlin N, Martinez del Rincon J, Miller P. Recurrent convolutional network for video-based person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1325-1334.
- [7] Yan Y, Ni B, Song Z, et al. Person re-identification via recurrent feature aggregation[C]//European Conference on Computer Vision. Springer, Cham, 2016: 701-716.
- [8] Zajdel W, Zivkovic Z, Krose B J A. Keeping track of humans: Have I seen this person before?[C]//Proceedings of the 2005 IEEE International Conference on Robotics and Automation. IEEE, 2005: 2081-2086.
- [9] Bazzani L, Cristani M, Perina A, et al. Multiple-shot person re-identification by hpe signature[C]//Pattern Recognition (ICPR), 2010 20th International Conference on. IEEE, 2010: 1413-1416.
- [10] Zheng L, Yang Y, Hauptmann A G. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [11] 徐阳. 基于卷积神经网络的行人重识别算法研究[D].华东师范大学,2018.
- [12] Oreifej O, Mehran R, Shah M. Human identity recognition in aerial images[C]//Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on. IEEE, 2010: 709-716.
- [13] Jüngling K, Bodensteiner C, Arens M. Person re-identification in multi-camera networks[C]//Computer vision and pattern recognition workshops (CVPRW), 2011 IEEE computer society conference on. IEEE, 2011: 55-61.

- [14] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification[C]//Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on. IEEE, 2013: 3586-3593.
- [15] Corvee E, Bremond F, Thonnat M. Person re-identification using haar-based and dcd-based signature[C]//Advanced Video and Signal Based Surveillance (AVSS), 2010 Seventh IEEE International Conference on. IEEE, 2010: 1-8.
- [16] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]//Computer Vision and Pattern Recognition (CVPR), 2012 IEEE Conference on. IEEE, 2012: 2288-2295.
- [17] Prosser B J, Zheng W S, Gong S, et al. Person re-identification by support vector ranking[C]//BMVC. 2010, 2(5): 6.
- [18] Schwartz W R, Davis L S. Learning discriminative appearance-based models using partial least squares[C]//Computer Graphics and Image Processing (SIBGRAPI), 2009 XXII Brazilian Symposium on. IEEE, 2009: 322-329.
- [19] 姚乐炜. 基于深度学习的行人重识别算法研究[D].哈尔滨工业大学,2018.
- [20] H. Zhao, M. Tian, S. Sun, J. Shao, J. Yan, S. Yi, X. Wang, and X. Tang. Spindle net: Person re-identification with human body region guided feature decomposition and fusion.In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1077–1085, 2017.
- [21] C. Su, J. Li, S. Zhang, J. Xing, W. Gao, and Q. Tian. Posed driven deep convolutional model for person re-identification. In Proceedings of the IEEE International Conference on Computer Vision, pages 3980–3989, 2017.
- [22] Zhang X, Luo H, Fan X, et al. Alignedreid: Surpassing human-level performance in person re-identification[J]. arXiv preprint arXiv:1711.08184, 2017.
- [23] 陈首兵,王洪元,金翠,张玮.基于孪生网络和重排序的行人重识别[J].计算机应用,2018,38(11):3161-3166.
- [24] 王亦民. 面向监控视频的行人重识别技术研究[D].武汉大学,2014.
- [25] Chum O, Philbin J, Sivic J, et al. Total recall: Automatic query expansion with a generative feature model for object retrieval[C]//Computer Vision, 2007. ICCV 2007. IEEE 11th International Conference on. IEEE, 2007: 1-8.
- [26] Lin Y, Zheng L, Zheng Z, et al. Improving person re-identification by attribute and identity learning[J]. arXiv preprint arXiv:1703.07220, 2017.
- [27] Kalayeh M M, Basaran E, Gökmen M, et al. Human semantic parsing for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and

- Pattern Recognition. 2018: 1062-1071.
- [28] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 480-496.
- [29] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]//2018 ACM Multimedia Conference on Multimedia Conference. ACM, 2018: 274-282.
- [30] Fu Y, Wei Y, Zhou Y, et al. Horizontal pyramid matching for person re-identification[J]. arXiv preprint arXiv:1804.05275, 2018.
- [31] 杨新雨. 基于监控场景的行人重识别方法的研究与应用[D].电子科技大学,2018.
- [32] 温春霞. 基于卷积神经网络与朝向姿态信息的行人重识别[D].华南理工大学,2018.
- [33] 刘楷怡. 行人重识别中的特征表达和度量学习的研究[D].华南理工大学,2018.
- [34] 王嫣然,罗宇豪,尹东.一种监控视频人脸图像超分辨技术[J].光学学报,2017,37(03):112-119.
- [35] Pereyra G, Tucker G, Chorowski J, et al. Regularizing neural networks by penalizing confident output distributions[J]. arXiv preprint arXiv:1701.06548, 2017.
- [36] Hamdoun O, Moutarde F, Stanciulescu B, et al. Person re-identification in multi-camera system by signature based on interest point descriptors collected on short video sequences[C]//2008 Second ACM/IEEE International Conference on Distributed Smart Cameras. IEEE, 2008: 1-6.
- [37] Nakajima C, Pontil M, Heisele B, et al. Full-body person recognition system[J]. Pattern recognition, 2003, 36(9): 1997-2006.
- [38] Cong D N T, Achard C, Khoudour L, et al. Video sequences association for people re-identification across multiple non-overlapping cameras[C]//International Conference on Image Analysis and Processing. Springer, Berlin, Heidelberg, 2009: 179-189.
- [39] Li W, Wang X. Locally aligned feature transforms across views[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 3594-3601.
- [40] Karaman S, Bagdanov A D. Identity inference: generalizing person re-identification scenarios[C]//European Conference on Computer Vision. Springer,

- Berlin, Heidelberg, 2012: 443-452.
- [41] Cong D N T, Khoudour L, Achard C, et al. People re-identification by spectral classification of silhouettes[J]. *Signal Processing*, 2010, 90(8): 2362-2374.
- [42] Karanam S, Li Y, Radke R J. Person re-identification with block sparse recovery[J]. *Image and Vision Computing*, 2017, 60: 75-90.
- [43] Li W, Niu L, Xu D. Exploiting privileged information from web data for image categorization[C]//*European Conference on Computer Vision*. Springer, Cham, 2014: 437-452.
- [44] Wu Y, Kozintsev I, Bouguet J Y, et al. Sampling strategies for active learning in personal photo retrieval[C]//*2006 IEEE International Conference on Multimedia and Expo*. IEEE, 2006: 529-532.
- [45] Yan Y, Nie F, Li W, et al. Image classification by cross-media active learning with privileged information[J]. *IEEE Transactions on Multimedia*, 2016, 18(12): 2494-2502.
- [46] Zheng Z, Zheng L, Yang Y. A discriminatively learned cnn embedding for person reidentification[J]. *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)*, 2018, 14(1): 13.
- [47] Garcia J, Martinel N, Gardel A, et al. Discriminant context information analysis for post-ranking person re-identification[J]. *IEEE Transactions on Image Processing*, 2017, 26(4): 1650-1665.
- [48] R. Vezzani, D. Baltieri and R. Cucchiara, People reidentification in surveillance and forensics: a survey, *ACM Comput. Surveys (CSUR)* 46 (2), 2013, 29.
- [49] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]//*Proceedings of the IEEE International Conference on Computer Vision*. 2015: 1116-1124.
- [50] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[C]//*Proceedings of the IEEE International Conference on Computer Vision*. 2017: 3800-3808.
- [51] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. *arXiv preprint arXiv:1703.07737*, 2017.
- [52] Wei L, Zhang S, Yao H, et al. Glad: Global-local-alignment descriptor for pedestrian retrieval[C]//*Proceedings of the 25th ACM international conference on Multimedia*. ACM, 2017: 420-428.
- [53] Zhong Z, Zheng L, Zheng Z, et al. Camera style adaptation for person re-

- identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 5157-5166.
- [54] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2285-2294.
- [55] Wang T, Gong S, et al. Person re-identification by video ranking[C]//European Conference on Computer Vision. Springer, Cham, 2014: 688-703.
- [56] Li Y, Wu Z, Karanam S, et al. Multi-Shot Human Re-Identification Using Adaptive Fisher Discriminant Analysis[C]//BMVC. 2015, 1: 2.
- [57] Xu S, Cheng Y, Gu K, et al. Jointly attentive spatial-temporal pooling networks for video-based person re-identification[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 4733-4742.

致谢

在科大三年的学习即将结束，回顾这三年的学习和生活感触很深。科大为我提供了非常好的科研和生活环境，周围的同学也都十分认真、努力、有理想、有抱负，这都给我带来了很大的积极影响。在这里的学习经历，让我对理论和实际应用都有了更深的认识，也大大提高了我的各方面的能力。更重要的是，在这里，我找到了我喜欢的研究方向，并且愿意为之努力，并且能从刻苦钻研的过程中获得乐趣和成就感。这种乐趣让我感到充实，并且有自我价值的实现骄傲。这是以前没有体验过的，所以首先我想感谢科大带给我的这么棒的学习体验，它让我对自己的能力和价值都进行了探索 and 发现。我想，这也是大学之所以为大学的迷人之处。

同样非常重要的一点是，在这里我要衷心感谢我的导师尹东老师。尹东老师具有很大的亲和力和人格魅力。他对学生循循善诱，在学术的思想方面高瞻远瞩，注重学生整体性的培养。他在我的学习过程中对我有耐心，有信心，尊重我们每个人的个性与个人发展，同时为实验室营造了非常棒的工作学习氛围，使同学之间不仅是共同学习进步的好伙伴，也是生活中的好朋友。在实验室学习工作的三年，尹老师为我的学术学习提供了很多指导。在他的带领下，我也在实际的项目中锻炼了动手实践、解决问题的能力。

其次我要感谢实验室的同学。在研究生期间，实验室的同学是我在学校里关系最亲近的人。他们不仅是我平时的好朋友，还是科研中的好伙伴。一个人的学习是无法涉及覆盖更多的研究领域和更开阔的思想的。正是因为有他们的存在，我们可以互相讨论，促进与学习。他们都是非常优秀的人，我也在他们身上学习了很多，非常荣幸曾与他们一同学习科研过。离开学校后，我们仍会是很好的朋友。

最后，我要感谢我的父母对我成长过程中所有决定的支持和对我的爱和付出。

在读期间发表的学术论文与取得的其他研究成果

已发表论文:

1. Yuan M, Yin D, Ding J, et al. A Multi-image Joint Re-ranking framework with updateable Image Pool for Person Re-identification[J]. Journal of Visual Communication and Image Representation, 2019. Volume 59, February 2019, Pages 527-536

在读期间参与的科研项目:

1. 安徽省重点研究和开发计划项目“公交智能化安全系统在智慧城市中的工程化应用”，主要成员。