

硕士学位论文

基于深度学习的行人重识别算法研究

**RESEARCH ON PERSON
RE-IDENTIFICATION BASED ON DEEP
LEARNING METHODS**

姚乐炜

哈尔滨工业大学

2018 年 6 月

国内图书分类号: TP391.4
国际图书分类号: 004.8

学校代码: 10213
密级: 公开

工程硕士学位论文

基于深度学习的行人重识别算法研究

硕 士 研 究 生: 姚乐炜

导 师: 姚鸿勋教授

申 请 学 位: 工程硕士

学 科: 计算机技术

所 在 单 位: 计算机科学与技术学院

答 辩 日 期: 2018 年 6 月

授予学位单位: 哈尔滨工业大学

Classified Index: TP391.4

U.D.C: 004.8

Dissertation for the Master's Degree in Engineering

RESEARCH ON PERSON RE-IDENTIFICATION BASED ON DEEP LEARNING METHODS

Candidate:	Yao Lewei
Supervisor:	Prof. Yao Hongxun
Academic Degree Applied for:	Master of Engineering
Specialty:	Computer Technology
Affiliation:	School of Computer Science and Technology
Date of Defence:	June, 2018
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

随着社会的发展,城市的公共安全逐渐受到公众的关注。监控视频作为目前公众安全管理的重要手段之一,在城市秩序管理、遗失人物查询以及案件侦破中均扮演着极为重要的角色。在这些过程中,目标人物的定位与追踪往往是重要的前提条件。而随着视频数据的爆炸式增长,使用人工的方式来查找和定位目标行人的成本将越来越高,并且低效的人工监察方式很容易导致错过案件侦破的关键时机,造成人民生命财产的重大损失。所以使用机器来准确、高效地定位行人成为了一种迫切的需求。

行人重识别 (Person Re-identification) 是指在非重叠视域的多摄像头网络中进行的行人匹配,本文就该问题的深度学习方法展开研究,并将研究重点聚焦在其中最关键的两个问题:特征提取与度量学习。针对度量学习问题,本文探究了不同损失函数及多任务学习策略在行人重识别问题上的表现;而对于特征提取,本文着重于行人特征提取的网络结构设计。具体而言,本文完成了以下工作:

(1) 在度量学习方法的研究中,提出了结合分类与检索模型的多任务学习策略。首先就不同类型的损失函数展开探究,从理论上验证各个损失函数的可行性;其次,提出可融合多种损失函数训练的多任务学习网络,在此网络基础上,探究不同种类损失函数的组合性能。最后通过在行人重识别数据集上的实验来并挑选出最优的损失函数组合,并在之后将此设计融入至本文所提出的特征提取网络中。

(2) 在对特征提取方法的研究中,根据行人图像的高度结构性,提出了具有针对性的多分支局部特征提取网络结构,并将其与全局特征提取网络相融合,成为一个多尺度特征融合网络;此后,进一步分析了行人重识别问题中存在的行人图像误对齐问题以及其可能对网络带来的影响,在此基础上,提出了一种使用空间变换网络来解决该问题的方案。

(3) 将空间变换网络、特征提取网络以及多任务学习融入到一个模型中,完成了整体网络的端到端的设计,使得整个网络的所有部分能够同时进行优化求解及参数更新;在行人重识别公共数据集 Market1501 上验证了我们设计的各个模块以及整个网络的有效性,并对所有实验结果进行了分析。

关键词: 行人重识别; 深度学习; 多任务学习; 多尺度特征网络; 空间变换网络

Abstract

With the quick development of contemporary society, public security problems have received increasingly attention from masses. As one of the most important means for public safety management, surveillance video plays a significant role in the processes of city order management, missing person searching, and the cases' detection. In these processes, the positioning and tracking of target people is often an important prerequisite. On the other hand, with the explosive growth of video data, the cost of using manual methods to find and locate target pedestrians will become increasingly higher, and inefficient manual monitoring methods will have the risk of missing key information for detection, thus endangering people's lives and property. Therefore, using machines to accurately and efficiently locate target pedestrians has become an urgent need.

Person re-identification refers to pedestrian matching in multi-camera networks in non-overlapping views. In this paper, we research on this task and focus on the two most critical issues of it: feature extraction and metric learning. For metric learning, we explore the performances of several loss function and propose a multi-task learning strategy for network training. And for feature extraction, this paper focuses on the design of network structures for persons' local feature extraction. Specifically, this paper mainly completes the following works:

(1) In the study of metric learning methods, a multi-task learning strategy that combines classification model and retrieval model is explored. First, we explore different types of loss functions and verify theoretical feasibility of each of them; Secondly, we propose a multi-task learning network that can be applied for training using multiple loss functions. Based on this network, we further explore the combined performance of different kinds of loss functions. Finally, through the experiments on the person re-identification datasets, the optimal loss function's combination is selected, and then this design is further integrated into the feature extraction network proposed in this paper.

(2) In the research of feature extraction methods, a multi-branch local feature extraction network structure is proposed according to the highly structured feature of pedestrian images, and it is merged with the global feature extraction branch to form a multi-scale

fusion network. After that, the misalignment problem in person re-identification task, along with its potential impact on our model is analyzed. Based on this, a solution using the space transformer networks to solve this problem is proposed.

(3) We integrate the spatial transformation network, the feature extraction network and multi-task learning strategy into one model, completing the end-to-end design of the entire network so that all parts of the model can simultaneously perform optimization and parameter updating. We verify the effectiveness of each module as well as the entire network on the public dataset Market1501, and further analyze all experimental results.

Keywords: Person re-identification, deep learning, multi-task learning, multi-scale feature network, spatial transformer network

目 录

摘 要	I
ABSTRACT	II
第 1 章 绪论	1
1.1 课题研究背景及意义	1
1.1.1 课题研究背景	1
1.1.2 课题研究意义	2
1.2 相关工作的研究概况	2
1.2.1 人工特征方法研究概况	3
1.2.2 深度学习方法研究概况	5
1.3 行人重识别问题研究难点分析	8
1.4 本文研究内容及组织结构	10
第 2 章 深度学习及行人重识别基础	12
2.1 引言	12
2.2 卷积神经网络	12
2.2.1 卷积神经网络简介	12
2.2.2 卷积神经网络基础构件	13
2.2.3 卷积神经网络特点	19
2.3 行人重识别基础	21
2.3.1 问题表述	21
2.3.2 行人重识别任务与分类和检索任务的关系	23
2.3.3 评价指标	23
2.3.4 常用数据集	25
2.4 本章小结	27
第 3 章 面向度量学习的多任务学习策略	28
3.1 引言	28
3.2 多损失函数设计	29
3.2.1 交叉熵损失函数	29
3.2.2 A-softmax 及 AM-softmax 损失函数	30

3.2.3 三元组损失函数	33
3.2.4 基于 KN 困难采样的三元组损失	34
3.2.5 多任务学习	35
3.3 网络结构设计	36
3.4 实验结果及分析	37
3.4.1 实验配置与参数	37
3.4.2 网络基础结构挑选	37
3.4.3 单损失函数性能测试	38
3.4.4 组合损失函数性能测试	39
3.5 本章小结	40
第 4 章 面向特征提取的多尺度融合网络结构设计	41
4.1 引言	41
4.2 多尺度融合特征及网络结构设计	41
4.2.1 思路来源	41
4.2.2 多尺度融合网络结构设计	44
4.3 行人图像对齐及网络结构设计	46
4.3.1 思路来源	46
4.3.2 空间变换网络	48
4.3.3 总体网络结构设计	51
4.4 实验结果及分析	52
4.4.1 实验配置与参数	52
4.4.2 不同分支数目对局部分支的影响	52
4.4.3 MSN 网络各模块性能探究	53
4.4.4 STN 网络的作用	55
4.4.5 与其他方法的对比	56
4.5 本章小结	56
结 论	58
参考文献	59
攻读硕士学位期间发表的论文及其他成果	65
哈尔滨工业大学学位论文原创性声明和使用权限	66
致 谢	67

第 1 章 绪论

1.1 课题研究背景及意义

1.1.1 课题研究背景

随着社会的发展，人们对公共安全问题的关注日益增加，但是在公共场所出现不文明行为或者暴力事件的情况却仍屡见不鲜。得益于图像采集技术及通信网络的发展，越来越多的监控摄像头被布置到公共场所中。这些摄像头采集的视频及图像数据成为了公共安全管理及犯罪侦破的重要手段，在公安部门对目标行人进行识别跟踪，或是执法部门对嫌疑人的行为进行调查取证时都发挥着重要的作用。目标人物的识别与定位是这些工作的必要前提条件，也是这一过程中最为关键的一环，但在实际操作中，却存在以下几点问题：

1) 由于拍摄角度及分辨率等因素的限制，使得这些摄像头在监控的过程中往往很难捕获到清晰的行人脸部特征，这就使得相关人员在调用监控录像时，必须通过身体形态或是衣着装饰等粗粒度的外貌特征来完成对目标人物的识别，这给目标人物的定位带来了一定的难度。

2) 考虑到成本的因素，为了使用较少的摄像头覆盖较广的监控范围，监控网络中的摄像头在布置时一般会彼此间相隔一段距离，使得监控网络出现一些视域盲区与监控断点，导致监察人员在查看监控时，出现视角切换困难、切换后跟踪丢失等问题。当目标人物在一个摄像头监控视域内消失时，如何在庞大的监控网络中快速再次定位出该人物的位置是一个问题。

3) 最为关键的一点，目前大多数监控系统仍处于人工监察的状态，但随着监控网络的不断扩大，使用人工的方式在海量的监控视频找到特定行人的成本将变得越来越高，不仅容易出错，而且费时费力，严重影响了监控系统的时效性。而在案件侦破或是城市的安全防护中，时间往往是最为宝贵的资源，低效的人工检索很有可能会导致错过案件侦破的最佳时机，造成人民生命财产的重大损失。所以使用机器智能来代替低效的人工劳动成为了一种迫切的需求。

因此，针对传统人工方法中的这些不足，人们开始思考能否使用机器智能来准确、高效地完成行人匹配以及定位的任务。在需求出现之后，也有越来越多的研究者投入到这一问题的研究中来，行人重识别 (Person Re-identification) 的课题也

由此展开。本文就基于深度学习方法的行人重识别算法展开探索与研究，希望在已有方法的基础上，做出一定的改进与创新，提出性能更优行人重识别算法。

1.1.2 课题研究意义

行人重识别 (Person Re-identification) 是指在非重叠视域的多摄像头网络中进行的行人匹配^[1]，也就是当一个行人的图像在某一时刻被某一个摄像头捕获后，根据该图像检索在其他摄像头中是否也有该行人的踪迹，所以行人重识别问题也被称为非重叠视域摄像头网络中的行人检索问题。该任务的示意图如图 1-1所示。




图 1-1 行人重识别任务示意图

行人重识别课题研究的意义主要体现在提高视频监控的自动化程度，从而解决快速增长的监控数据与低效的人工检索之间的矛盾。随着研究人员对行人重识别问题研究的深入，越来越多优秀的重识别算法将被应用到现实的监控系统中，辅助或是代替监察人员执行监察工作，这不仅大大提高了目前整个监察系统的工作效率，节省了人工成本开支，而且在案件侦破、失踪人口搜寻以及城市安全管理等工作中都扮演着非常重要的角色。在倡导智能城市发展的今天，行人重识别系统的研究为城市安全的自动化管理提供了一条切实可行的方案，具备极高的社会价值。

1.2 相关工作的研究概况

对行人重识别的研究最早可以追溯到 1996 年，当时已经有学者开始关注多摄像头情况下的行人追踪问题^[2]。2006 年，行人重识别这一概念首次在顶级计算机视觉国际会议 CVPR 中被提出^[3]。2007 年，Gray 等人公布了第一个针对行人重识别任务的公开数据集 VIPeR^[4]，这让研究者们提出的不同的算法之间有了可比较的基准。此后，行人重识别这一任务便引起了计算机视觉领域的广泛关注，每年都

有优秀的工作涌现。特别是在近几年中, 计算机视觉领域关于行人重识别的研究有了爆发式的增长, 在计算机视觉的国际顶级会议 (ICCV, CVPR, ECCV, NIPS, AAAI) 中及期刊 (TPAMI, TIP, IJCV) 中, 相关的工作均在逐年增加。

随着研究的深入及方法的更新, 研究者们提出的模型在各个数据集上的性能表现取得了质的飞跃。总体来说, 行人重识别的模型主要经历两个阶段: 基于人工特征的重识别模型以及基于深度学习的重识别模型。在研究行人重识别问题的早期阶段, 由于深度学习技术尚未成熟, 所以对行人特征的研究仍停留在人工特征阶段, 研究者们更多地关注于如何通过对问题的认识以及先验知识来设计出对视角变化鲁棒的行人特征, 以及通过特征在空间中分布的研究来设计出良好的度量学习算法。而在深度学习技术的兴起之后, 越来越多的研究者开始将深度模型引入到行人重识别任务中, 相较于基于人工设计特征的模型, 基于深度学习的方法在行人匹配的成功率上有了极大的提升。不过即使是在深度学习相对成熟的今天, 仍有一些很好的基于传统模型的工作出现在顶级国际会议中。上述两个阶段中都有非常出彩的工作涌现, 下文中将对两个阶段中的一些突出性工作进行分别阐述。

1.2.1 人工特征方法研究概况

在行人重识别课题研究的早期, 大量工作中采用的仍是基于人工特征的算法。正如前文所述, 基于人工特征的识别系统一般由两大部分组成, 即人工特征设计与度量学习。一般而言, 在这个阶段, 特征设计与度量学习在整个行人重识别系统中是两个分开的、彼此独立的过程, 在研究时, 研究者们会针对这两个过程进行分别分析与建模。在下文中, 我们针对这两个过程的研究概况分别进行阐述。

1.2.1.1 人工特征设计

由于在不同视角和光照条件下, 行人的外貌会发生较大的变化, 所以能否找到一种能够适应光照、视角变化的表达力较强的特征是解决行人重识别问题的一个关键。

在早期的工作中, 研究者使用一些传统图像处理任务中的低层视觉特征来解决行人重识别问题, 例如颜色直方图特征、纹理特征以及一些图像局部特征描述子等。在 2010 年, M. Farenzena 等人^[5]提出 SDALF 特征 (Symmetry-Driven Accumulation of Local Features)。他们首先将行人从背景中提取出来, 并根据行人的外貌特点, 将人体分成了头部、躯干和下肢等几个部分, 然后对不同的人体部分, 提取了基于 HSV 空间的加权颜色直方图 (weighted color histogram, WH)、最大稳定颜色区域 (maximally stable color regions, MSR) 以及高度结构化图像块 (recurrent high-

structured patches) 等特征, 最后将这三个特征融合为一个特征作为对行人的描述; 在 [6] 中, Gray 和 Tao 等人提取了 8 维的颜色特征 (RGB, HS 以及 YCbCr) 以及 21 维的纹理特征 (Schmid、Gabor 等) 来表示行人图像; 类似地, Mignon 等人^[7] 将行人图像分为数个等高的条形区域, 并对每个条形提取了 RGB, YUV 以及 HSV 色彩空间下的颜色特征, 以及 LBP 纹理特征, 最终将不同条形的特征串联成为一个整体的特征来进行行人匹配。

但随着研究的深入, 研究者们发现单纯地使用低层视觉特征并不能很好地解决行人重识别问题, 因为低层的视觉特征往往不具备很好的判别力, 所以人们开始探究如何设计具有判别力的中高层语义特征。Zhao 等人^[8] 首先提出了使用具有代表性的图像块 (patch) 的表示行人, 他们首先将行人图像分割为一系列相互重叠的图像小块, 并对每个图像提取了 32 维的 LAB 色彩特征以及 128 维 SIFT 特征, 然后通过 KNN 和 One-class SVM 挑选出了每个行人图像中的具有代表性的图像块, 用以作为该行人的特征表示; 在他们之后的工作中, [9] 在上述工作的基础上, 进一步设计了显著区域的图像匹配方法; 而 [10] 中设计了一种中层滤波器, 用以提取图像具有判别力的部分。Yang 等人^[11] 提出了一种称为色彩名称 (salient color names based color descriptor, SCNCD) 的全局特征, 他们认为衣物的颜色是判别行人的有效手段之一, 所以他们提出了 16 种具有判别力的基础颜色, 然后基于这些基础颜色对行人的不同区域提取相应的颜色直方图来作为行人的表示; 而后, 为了寻求更加有效的行人表示, 2015 年的 CVPR 中, Liao 等人^[12] 提出了 LOMO(local maximal occurrence) 特征, 他们首先将行人图像划分为等大的图像块, 对每个图像块提取了颜色直方图以及 SILTP^[13] 直方图, 然后对于在同一水平位置上的图像块的每一维特征进行了 max pooling 从而得到 LOMO 描述子, 该特征具有良好的光照及角度不变性, 在当时获得了几乎能与同期深度学习方法相媲美的实验结果。由于 LOMO 具有计算方便、表达能力强等优点, 故而后也被陆续应用于 [14,15] 等其他一些工作中; 而后, T. Matsukawa 等人^[16] 使用高斯分布对图像局部区域进行建模, 提出了 GOG(Gaussian Of Gaussian) 描述子, 在实验中取得了很好的效果。

除了采用基于颜色及纹理特征外, 还有另一些工作^[17-22] 更加关注于行人的属性特征, 即通过分类器将行人的衣物穿着、性别外貌等高层的语义特征划分成不同的类别, 来作为行人的属性, 然后依据这些属性来完成行人的识别任务。一般而言, 当视角发生变化时, 这些属性特征相较于低层特征更具有鲁棒性。

1.2.1.2 度量学习

在上文中提到, 行人重识别任务中的一大难点就是经常出现样本的类内距离大于类间距离的情况, 所以有很多研究者提出了使用度量学习的方法来解决这个问题。度量学习是通过优化求解得到一个新的相似度的度量方式, 使得同类样本的相似度高于异类样本。在度量学习中最常用的度量方式为马氏距离:

$$d(x_i, x_j) = (x_i - x_j)^T \mathbf{M} (x_i - x_j) \quad (1-1)$$

其中 $\mathbf{M}$ 是一个半正定矩阵 x_i 和 x_j 表示特征向量。根据 [23] 通过将式1-1可以转化成凸优化问题进行求解, 当使用不同限定条件与目标函数时, 我们可以得到不同的 $\mathbf{M}$ 。

在式1-1的基础上, 出现了一系列关于度量学习的工作。Weinberger 等人^[24]提出了一种最大间距最近邻学习 (Large Margin Nearest Neighbor, LMNN) 的方法, 主要思想是在目标函数中加入了对于类内距离过大而类间距离过小的惩罚, 从而拉近同类样本的距离, 并推远异类样本指间的距离。而后, 为了解决 LMNN 容易过拟合的问题, Davis 等人^[25]提出了信息理论度量学习方法 (Information-theoretic Metric Learning, ITML), 该方法通过在一些约束下最小化两个高斯分布间的 KL 距离, 将度量学习转化为一个特别的 Bregman 问题。

近些年中, 一些专门针对行人重识别任务的度量学习的工作被陆续提出。M. Kostinger 等人^[26]提出了一种称为 KISS Metric Learning(KISSME)的方法, 其假设两个样本之间的特征差异满足均值为零的高斯分布, 将目标函数转化成对数似然比的形式, 可以根据样本直接求得映射矩阵 $\mathbf{M}$, 从而避免了其他度量学习工作中复杂的优化过程, 大大提高了学习速度; Liao 等人^[12]提出了一种名为 XQDA(Crossview Quadratic Discriminant Analysis)的度量学习方法, 将 KISSME 与 PCA 相结合, 将度量学习与数据降维中子空间的学习融合到一个优化过程中, 获得了较好的效果; 此外, Chen 等人^[27]用图像块特征 (patch descriptor) 来描述图像, 并在马氏距离中加入了双线性相似度, 用来衡量图像对之间的距离; Yang 等人^[28]同样结合了马氏距离与双线性相似度, 并且考虑了图像对的相似性及相异性, 指出了不相似图像对的协方差矩阵在一定程度上可以由相似图像对的协方差矩阵计算得到, 使得该度量学习方法能够更好地适应大规模的行人重识别问题。

1.2.2 深度学习研究方法研究概况

近年来, 深度学习技术在各类的计算机视觉任务中均表现出了相当卓越性

能，因此很多研究者开始将深度学习模型引入到行人重识别问题中来。深度学习模型相较于传统基于人工特征的模型具备其独特的优势，它可以通过梯度下降算法来自适应地获得表达能力较强的特征，从而避免了传统模型中繁杂的特征设计过程；并且相较于基于规则的手工特征，深度特征往往更能反映数据集的特点。在行人重识别任务中，与手工特征模型不同，深度模型往往会将特征提取与度量学习两个过程融入到一个网络中，形成一个端到端的可训练的系统，这就相当于将原本的分步求优问题转化成了联合求优，不仅简化了系统，而且能够带来性能的提升。

早期的行人重识别深度模型中，使用最为广泛的是一种称为孪生网络 (Siamese Network) 的网络结构，这种网络结构将行人重识别问题视作一个二分类问题，使用二元图像对作为网络的输入，输出图像对属于（或不属于）同一个人的概率，该网络的示意图如图1-2所示。2014 年，Li 等人^[29] 率先使用这种网络结构来处理行人重识别任务，他们在孪生网络中加入一个图像块匹配层 (Patch matching layer)，用于匹配两张图像间不同的图像块，并使用点乘的方式来计算特征图之间的相似度。但在这方面更具知名度的是另一份在 2015 年 CVPR 中的工作，Ahmed 等人^[30] 改进了 Li 等人的工作，在孪生网络中加入了一种相似度计算层，通过计算相邻局部区域的差值来生成两个特征之间的相似度特征图，再通过这个相似度特征图来进一步计算输入图像对之间的相似度。类似的工作也出现在 2016 年的 NIPS 中，Arulkumar 等人^[31] 设计了一种标准化相关层 (Normalized Correlation Layer)，使用标准化相关这一指标来衡量两个特征图的相似度。




图 1-2 Siamese 网络结构示意图

在之后的研究中,除了相似度层的设计外,研究者们也致力于在其他方向上改善神经网络的性能。与基于手工特征的模型类似,这些工作分一般致力于两个方向:改善网络的结构以提高特征提取能力以及改善损失函数来使网络学习到一个更好的特征度量空间。

在对于度量学习的研究中,Cheng 等人^[32]将改善了传统的三元组损失,在其中加入了对同类样本分类更为紧促的约束,从而使网络能够学习到更好特征映射方式,并且他们将行人图像分成等大的相互重叠的几个部分输入网络,增加网络对人体局部特征的学习能力;Chen 等人^[33]将多任务学习的策略引入到行人重识别任务中,采用了三元组的输入形式,网络将排序任务 (ranking task) 与分类任务 (classification task) 结合起来,最终的损失函数由三元组损失 (triplet loss) 与 softmax 损失共同组成,用来提高网络的学习性能;在此后的 2017 年 CVPR 上,他们又提出了一种崭新的损失函数:四元组 (quadruplet loss)^[34],采用四元组的形式作为输入,用以进一步获得更大的类间间隔 (inter-class margin);为了解决三元组损失函数训练收敛速度慢,收敛效果不佳的问题,[35–37]等工作研究了当使用三元组损失时,输入网络的困难样本选择策略;[38]则结合了四元组与困难样本挖掘的思想,提出了一种更具有判别力的困难样本选择策略。

在对行人特征的研究中,Wu 等人^[39]受到 VGG-Net 的启发,提出了 PersonNet 网络,该网络在设计中使用了更小的卷积核并加深的网络的深度,提高了网络的性能;Varior 等人^[40]受到 LSTM 的启发,在每一个卷积核后加入了门函数,从而使网络能够学习到一些更具有判别力的模式;在 2017 年的 ICCV 中,为了解决在匹配过程中行人关键部位无法对齐的问题,Zhao 等人^[41]创新性地将显著度机制融入到网络的设计中,使用多个显著度分支来自适应地关注到不同行人的相同部位;同样为了解决行人部位对齐的问题,2017CVPR 中,Zhao 等人^[42]提出了一种叫做 SpindleNet 的行人重识别网络,他们首先通过人体姿态估计 (Pose estimation) 的预训练模型得到了人体的 14 个关键点,并使用这 14 个关键点来获取 7 个人体的局部感兴趣区域 (Region of interest, ROI),然后用一个多分支网络对这些局部区域进行特征分别提取并融合,从而形成一个完整的行人特征来进行行人匹配;类似的,在 [43] 中,利用人体关键点将行人分为头、上身、下身三个部分,然后用一个多分支网络进行特征的分别提取和融合,不同的是,在 GLAD 中每一条均有一个损失函数作为监督信号来引导网络的训练。此外,还有一些研究者另辟蹊径,使用 GAN 来生成不同视角下的行人图像来帮助网络更好地获取行人特征,如在

2017ICCV 中, Zheng 等人^[44]提出了使用 GAN 来生成额外行人数据进行训练的思想, 并给每一个生成的数据贴上相应的“软标签”, 在一定程度上提高了一般模型的性能; 而在 [45] 中, 作者设计了一种行人图像生成网络, 可以根据不同的姿态, 生成不同视角下的行人图像, 在此基础上, 作者将每一个行人图像都按指定的 8 种姿态生成其所对应的 8 个不同视角下的图像, 并将这 8 个视角下的图像特征与原图的特征融合成为一个特征来表示行人, 从而消除了视角对行人重识别的影响。

1.3 行人重识别问题研究难点分析

经过数年的研究与发展, 学术界对行人重识别问题的研究已经达到了一个新的高度, 但即使每年在该领域有很多优秀的工作涌现, 行人重识别问题却还是没有从真正意义上被完全地解决, 这是由于行人重识别问题存在着一些固有的技术难点, 分析如下:



图 1-3 困难样本展示

1) 行人姿态的多变性: 由于行人是非刚性的目标, 所以在不同时刻拍摄的同行人可能在形态上存在着很大的差异性, 这导致即使是同一个体, 也可能因为形态的差异, 变得难以识别。如图1-3(a)所示, 同一个行人在一个视角下处于行走状态, 而在另一个视角下处于骑行状态, 这种姿势的差异给行人的识别造成了困难。

2) 行人视角差异: 当拍摄视角发生变化时, 行人的外貌特征可能发生较大的变化, 并且有些时候, 用于判断行人个体的一些关键外貌特征可能由于视角的原因变得不可见, 这就会在一定程度上影响行人的识别率, 这一点的样例如图1-3(b)

所示。

3) 不同行人间的相似性: 不同的行人个体可能在衣着、体型上存在着相似性, 甚至在有些时候, 不同行人比相同行人长得更加相像, 这一点极大地增加了行人个体识别的难度。在图1-3(c) 中, 我们可以看到这两个行人在衣着和外观上非常相似, 且两个视角拍摄的均为背部, 导致他们变得很难区分。

4) 外部因素干扰: 在实际情况下, 监控环境往往是不可控的, 所以在一些外部因素的影响下, 行人图像可能会产生较大的变化。这些外部因素主要包括: 光照变化、遮挡、拍摄距离、图像分辨率等。这些例子被展示在图1-3的 (d-f) 中。

我们在 Market1501 数据集中挑选了以上各种情况的图片示例, 展示在图1-3中。以上各点体现了行人图像的高度复杂性, 也就使得很多情况下相同行人不同视角下的外貌差异甚至比不同行人之间的更大, 反映到特征空间中, 即可能会出现类内间距大于类间间距的情况, 如图 1-4所示。这一点为行人重识别任务带来巨大的挑战。为了解决上述问题, 研究者在行人重识别领域的各个工作主要聚焦于以下两个主要任务:



图 1-4 类内间距大于类间间距示意

1) 探究合理有效的行人特征。一般而言, 研究者在行人重识别任务中设计的特征需要满足以下两个特点: 一是具备视角变化情况下的鲁棒性。就是说当行人视角出现变化时, 所提取的行人特征应该具有一定的不变性, 同时该特征也应该对光照、遮挡等外部因素具有一定的鲁棒性, 这样才能保证不同视角下的相同行人能够相互匹配; 二是具备不同个体之间的辨识性, 不同行人个体的特征应当具备其独特性, 且提取的不同行人的特征之间应当具备一定的差异, 从而才能有效地减少误配率。

2) 寻找一个良好的特征度量方式。即找到一个好的特征投影空间, 在将原特征通过一定的运算投影到该空间后, 能够满足个体间类内 (同类) 间距较小而类间

(异类) 间距较大的关系。针对这一类问题的研究一般也被称为度量学习。

1.4 本文研究内容及组织结构

在本文中，我们将对基于深度学习方法的行人重识别算法展开研究。正如上文所述，行人重识别领域的研究主要关注两个问题：其一是特征提取，即探究对视角变化鲁棒的行人特征；其二是度量学习，即探究较优的特征度量空间，使得相同行人之间的距离能够较近。所以，本文的研究工作也将针对这两点进行展开。本文的主要研究内容包括：




图 1-5 本文章节结构图

1) 探究不同的度量学习方式对行人重识别任务的影响。在深度学习模型中，度量学习算法主要体现在损失函数的设计中。所以在本文中，我们会探究不同损失函数对行人重识别任务的影响，并且进一步探究他们的组合性能，从而得到一个性能最优的损失组合。第三章中对这一点进行了详细介绍。

2) 探究对行人重识别问题行之有效的特征设计，以及相应的网络模型结构。

具体来说，我们将会探究如何在目前已有的主流深度模型的基础上，加入针对行人图像特点的网络模块，使得网络能够提取到更具有判别力的行人特征。这个工作主要展现在第四章中。

本文的论文组织结构如下：

在第一章中，我们主要阐述行人重识别问题的研究背景及意义，并对近年来该领域的国内外研究状况及相关的优秀工作进行简单的分类、概述及分析，然后进一步分析该任务的主要研究难点以及我们将要探究的内容。

在第二章中，我们主要介绍深度学习技术中主流模型——卷积神经网络的基础理论知识，以及行人重识别领域相关的理论知识及技术细节。

在第三章中，我们将介绍几种不同损失函数的原理及实现方式，并分别探究他们在行人重识别任务中的性能；此外，在本章中我们，还会设计多任务学习的网络结构，探究不同损失函数的组合策略对行人重识别任务的影响，并得到最优的组合策略。

在第四章中，我们将主要探究如何改善网络结构来得到更具判别力的行人特征。在本章中，我们将会根据行人图像的数据特点，提出一种用于提取行人多尺度融合特征的网络结构；并在此基础上，进一步该探究结构所存在的问题，提出了用于解决行人误对齐问题的空间变换网络；最终我们将这两个网络与多任务学习策略一起融入到一个网络的设计中，并将在实验中验证该网络的性能。

本文各章节之间的结构示意图如图1-5所示。

第 2 章 深度学习及行人重识别基础

2.1 引言

近年来, 由于深度学习模型在众多计算机视觉任务中取得了令人瞩目的成绩, 故也被研究者们逐渐引入到行人重识别这一项任务中来。经过近几年的发展, 深度学习模型在各大行人重识别的公开数据集上均表现出了很好的性能, 并且逐渐取代了基于人工特征的方法, 成为这一领域的主流方法之一。本章将首先从目前计算机视觉领域深度学习技术的主流模型——卷积神经网络入手, 详细介绍其基本构造以及相关理论基础; 在此基础上, 进一步介绍目前基于深度学习技术的行人重识别模型的一般框架以及相关技术细节。

2.2 卷积神经网络

2.2.1 卷积神经网络简介

卷积神经网络 (Convolutional Neural Networks, CNN) 是研究者在生物大脑视觉认知机制的启发下提出的一种机器学习模型。在 19 世纪 60 年代, Hubel 和 Wiesel 等人^[46]在研究猫的大脑视觉皮层系统时发现动物大脑皮层的每一个视觉神经元在处理视觉信号时, 只会处理一个局部区域的视觉信息, 由此, 他们提出了神经细胞的感受野 (receptive field) 的概念; 此外, 他们还进一步发现了生物大脑在处理视觉信息时的分层处理机制, 这为后来 CNN 的发展提供了重要的生物学理论基础。1982 年, 日本学者 Kunihiko Fukushima 在此基础上, 将感受野和分层处理的思想融入到视觉模型的构造中, 提出了神经感知机 (Neocognitron) 模型^[47], 这是第一个基于神经元之间的局部连接性和层次结构组织的人工神经网络, 并且在其中首次提出卷积、池化、非线性映射等操作, 所以该模型也被视作 CNN 的前身。此后, Lecun 等人^[48]在 1990 年研究手写数字体识别问题时, 借鉴神经感知机的思路, 设计出了著名的 LeNet 网络, 并且创造性地将梯度下降算法^[49]应用到网络的训练中, 该网络在手写数据集 MNIST 中取得了相当好的表现。第一个真正意义上的卷积神经网络便由此诞生了。

在此之后, 卷积神经网络经过了数十年的发展, 取得了一系列重大的突破。在此过程中, 一个非常重要的里程碑就是在 2012 年全球性的图像分类竞赛 ILSVRC(ImageNet Large Scale Visual Recognition Competition) 上, Alex Krizhevsky 率

领其团队使用他们提出的网络 AlexNet^[50] 一举夺冠，该网络在当时的 ILSVRC2012 测试集中达到了惊人的 16.4% top-5 分类错误率，力压前一年基于 SVM 的冠军模型将近 10%，使得卷积神经网络一时名声大噪。此后，越来越多计算机视觉领域的学者开始关注深度学习技术，卷积神经网络也迎来了其发展的高峰期。在最近的短短几年中，每年都不断有不同结构的 CNN 模型被提出，并且它们在 ILSVRC 中的准确率不断攀升 (如图2-1所示)。到 2015 年时，Kaiming He 及其团队提出的 152 层的残差网络 Resnet152^[51] 在 ILSVRC2015 的测试集中将 top-5 分类准确率降到了 3.57%。至此，卷积神经网络在物体识别任务中的表现已经超越了人类的视觉系统。此外，研究者们发现卷积神经网络的能力不仅仅限于物体识别这一任务，在其他的视觉任务 (如目标检测、语义分割、动作检测、立体图像匹配等) 均表现出了非常良好的性能。在接下来的小节中，我们将详细介绍卷积神经网络的基础结构及相关概念。




图 2-1 历年 ILSVRC 模型 top-5 错误率图

2.2.2 卷积神经网络基础构件

一般而言，传统的卷积神经网络包括以下基础构件：卷积层 (Convolutional layer)、池化层 (Pooling layer)、全连接层 (Fully connected layer)、激活函数 (Activation function) 以及归一化层 (Normalization layer)。

(1) 卷积层

卷积层 (Convolutional layer) 是卷积神经网络的核心部件，用于特征的提取与计算。一般而言，一个卷积层由多个卷积核 (kernel) 构成，而每一个卷积核实际上

是一个带有参数的滑动窗口，其功能类似于图像滤波器。实际操作时，每一个卷积核在输入图像上以一定的步长 (stride) 进行滑动，每滑动一次，计算该位置原图像与卷积核参数的卷积作为输出，示意图如图2-2所示。在实际中，在得到卷积输出后，往往还需要加上一个偏置 (bias)，以二维卷积为例，其计算过程如下：

$$output = \sum_{i=1}^m \sum_{j=1}^n I_{i,j} \times K_{i,j} + b \quad (2-1)$$

其中 I 为输入图像， K 为卷积核， m, n 分别为卷积核的长和宽， i, j 为坐标， b 为偏置。




图 2-2 卷积层计算过程示意图

除步长 (stride) 以及卷积核大小 (size) 外，卷积核还有另一个参数，称为补全尺寸 (padding)。该参数的含义为在输入图像的外围补上指定圈数“零”元素 (zero padding)，这些“零”元素在当卷积核移动到输入图像边缘时发挥作用，可以使得卷积核只与边缘的部分元素进行卷积，这种操作可以用来保持输出图像的尺寸与输入图像一致。一般而言，卷积层的输出大小由输入图像大小、卷积核大小，步长以及补全尺寸同时决定，其计算公式如下：

$$size_{out} = \left\lfloor \frac{(size_{in} - ksize + 2 \times padding)}{stride} \right\rfloor + 1 \quad (2-2)$$

其中 $size_{out}$ 和 $size_{in}$ 分别为输出及输入图像尺寸， $ksize$ 为卷积核尺寸， $padding$ 为补全尺寸， $\lfloor \cdot \rfloor$ 表示向下取整操作。

与传统的人工设计特征不同，卷积神经网络通过训练，每个卷积核都可以学习到不同的参数，从而用来提取图像不同的特征。一个神经网络一般由多层卷积层组成，前一层的输出通过一定的处理后形成后一层的输入，由此来完成对图像特征的逐层抽取，所以不同位置的卷积层承担了不同的视觉处理功能。文章 [52]

提出了一种反卷积的方法来可视化神经网络不同卷积层的学习结果，图2-3展示了 AlexNet 网络中不同卷积层所扮演的角色。可以看到，通过学习，网络中低层的卷积主要表达的是边缘、纹理等低层的视觉特征，而随着层数的加深，后层卷积所表达的特征开始逐渐向高层的语义特征过渡，中层的卷积层能够呈现出物体的某些局部特征，而后层的卷积层则具备了表达整个物体的能力。




图 2-3 卷积神经网络学习结果可视化

研究表明，在人类视觉系统中同样存在着类似的分层处理机制^[53,54]。人类的视觉皮层由 V1 至 V5 五个不同的区域组成，如图2-4所示，不同的视觉皮层承担不

同的视觉处理任务，如初级视皮层 (V1) 负责处理方向运动、空间频率、视差和颜色等简单的视觉信息，而纹外皮层 (V2-V5) 则负责对 V1 区产生的信号进行进一步的加工处理，形成更为复杂的几何、颜色及运动信息。所以说，卷积神经网络这种由浅至深、逐层处理的结构设计具备的较强的生物学理论基础。




图 2-4 人类大脑视觉皮层示意图

(2) 池化层

池化层 (Pooling layer) 也称为下采样层 (Down-sampling layer) 是卷积神经网络的重要组成部分之一。与卷积层不同，池化层是一个无参层，也就是说它只对输入做计算而本身没有参数。但池化操作却与卷积操作类似，也是通过滑动窗口实现的，每滑动至一个位置，就将该位置输入图像在滑动窗口内部的元素通过一定的计算得到一个新的输出值。池化操作也有步长 (stride)、补全尺寸 (padding) 等参数，它的输出尺寸同样可由式2-2进行计算。此外，根据操作的不同，池化可分最大池化 (Max pooling), 平均池化 (Mean pooling), 随机池化 (Stochastic pooling) 等，图2-5为不同操作的示意图。以二维的最大池化为例，计算公式如下：

$$output = \max_{i=1}^m \max_{j=1}^n I_{i,j} \quad (2-3)$$

池化操作的意义在于：(1) 在保留输入特征图 (Feature map) 主要信息的情况下，通过降采样缩小输入特征的尺寸，减少后续网络的参数，提高模型的效率；(2) 由于能够减少网络的参数，所以池化操作也能够一定程度上提高模型的泛化能力，有效地防止过拟合；(3) 由于池化操作会将一个窗口内的所有值整合成一个值输出，这个过程仅对输入特征图的响应值大小敏感，而对于响应所在的位置并不敏感，所以池化操作能够为 CNN 提供局部区域内的特征不变性 (如平移、旋转不变性等)。

(3) 全连接层




图 2-5 三种不同的池化操作示意图

在卷积神经网络中，输入单元与输出单元的每个神经元均有连接的层称之为全连接层 (Fully connected layer)。全连接层的设计源自于传统的人工神经网络，在卷积神经网络中，它一般位于网络的末端，承担特征映射及分类的功能。一个完整的全连接层示意图如图2-6所示。全连接层的公式表达如下：

$$output(x) = f(W^T x + b) \quad (2-4)$$

其中 W^T 表示权重矩阵； x 为输入向量； b 为偏置向量； $f(\cdot)$ 表示激活函数。




图 2-6 全连接层示意图

由于全连接层的完全连接机制，它并不具备稀疏连接、共享参数等特点，因此全连接层会极大地增加网络的参数。在早期的卷积神经网络 (如 VGG 等) 中，采用了大量的全连接结构，导致网络非常臃肿，而随着深度学习理论的发展，后期的模型 (如 resnet, densenet) 中，一般都只采用一层全连接层来完成特征的映射，在缩减网络参数的同时，也能够达到很好的性能。

(4) 激活函数

非线性激活函数是网络能够对非线性模式建模的基础，在卷积神经网络中，由于卷积与池化均是线性操作，没有非线性激活函数的情况下，网络即使层数再多，也只能表达线性映射，表达能力十分有限。而非线性激活函数能够将网络的输出通过非线性的方式映射到更高维的空间，从而增加网络的表达能力，所以一般来说，在 CNN 中，卷积层及全连接层的输出端都会加上一个激活函数。常用的激活函数有 sigmoid、tanh、ReLU 等，它们的公式表达如下：

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-5)$$

$$\text{tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-6)$$

$$\text{ReLU}(x) = \max(0, x) \quad (2-7)$$

其中 ReLU 是目前大多数卷积神经网络构架中所采用的主流激活函数，这是因为相较于 sigmoid 和 tanh，ReLU 不存在“软饱和”的机制，所以即使响应较大，也不会出现梯度等于 0 的情况，从而能够有效地避免网络梯度弥散 (vanishing gradient problem) 的问题，此外，ReLU 还能够极大地加快网络的收敛速度。但 ReLU 也存在着一些不足：当输入为负时，输出的梯度为 0，这将可能导致有网络内部的一些神经元在很长的时间内无法更新参数，即神经元的“静默”。为了改善这一点，后续又有一些 ReLU 的变种被陆续提出，如 Leaky-ReLU、P-ReLU 及 R-ReLU 等，它们在 ReLU 负输入部分也加上了一定的输出，所以可是使得即使输入为负的情况下，神经元依旧可以得到更新。

(5) 批归一化层

批归一化层 (Batch Normalization layer, BN)^[55] 是卷积神经网络发展历程中极为重要的一个设计，在目前的各种卷积神经网络中均被广泛使用。由于卷积神经网络在训练时，整个网络的参数是一同更新的，这就导致每次更新后，网络中某个

节点由于前层参数的变化，其输出分布发生了改变，所以它后面的层必须通过再次改变参数来适应这种变化，这个问题导致网络训练的效率变得很慢，而且必须精心挑选训练参数，才能够使网络收敛到一个较好的点。BN 层将网络每层的输出进行归一化操作，使得每个节点的输出在整个迭代过程中均满足同一分布，就可以有效地解决这一问

$$\hat{x}^{(k)} = \frac{x^{(k)} - E(x^{(k)})}{\sqrt{\text{VAR}(x^{(k)})}} \quad (2-8)$$

其中， k 表示 batch； $x^{(k)}$ 为 BN 层输入； $\hat{x}^{(k)}$ 为归一化后的输出； $E(x^{(k)})$ 为 $x^{(k)}$ 的期望； $\text{VAR}(x^{(k)})$ 的方差。

BN 层能够很大程度上提升网络的收敛速度，并且能够有效地防止网络的过拟合问题。所以现在在卷积神经网络的设计中，往往都会将其加入到卷积层或是全连接层后。

2.2.3 卷积神经网络特点

卷积神经网络是在传统人工神经网络 (多层感知机模型) 的基础上发展而来的，被用以专门解决计算机视觉任务。我们都知道，图像在计算机中是以像素值的方式存储的，图像的像素点个数就相当于网络的输入层的节点数目，这个数目往往是非常巨大的，例如一张 224×224 大小的具有 RGB 三通道的图像就拥有 150528 个像素点，若使用传统的人工神经网络进行建模，那么整个网络的参数数目将无法想象，如此庞大的模型不仅难以训练，而且容易产生过拟合，影响模型的泛化能力。卷积神经网络的设计有效地避免了这些问题，大大减少了网络参数，这得益于它具有以下两个特点：

(1) 局部感知：

在前文中提到，Hubel-Wiesel 实验发现，动物大脑的每一个视觉神经元在处理视觉信号时只会处理局部的视觉信息，然后将通过逐层处理，将局部信息融合成为全局印象，并由此提出了感受野 (Receptive field) 的概念。在卷积神经网络的设计中，很大程度上借鉴了这一点。相较于传统人工神经网络中的全连接结构，卷积神经网络采取了一种稀疏连接的结构，通过卷积核这一设计，使得网络中隐含层的每一个神经元仅与上一层的局部区域内的个别神经元相连，如图2-7所示。这一设计在大幅减少了网络参数的同时，依旧能够保证卷积神经网络对视觉图像的建模能力，因为它非常好地利用了自然图像的空间联系的局部性：每一个像素点仅和与其相距较近的其他像素点具备较强的关联性，而和那些相距较远的像素关

联性很弱。因此，这种稀疏连接和局部感知的设计具有合理性。




图 2-7 稀疏连接示意图

与动物的视觉系统类似，卷积神经网络也具有感受野的概念，它是指网络某层输出的特征图上的一个像素点在原始输入图像上所对应的区域。在局部连接的设计中，网络中某一层输出的一个像素值其实包含了上一层输出中的某一局部区域的信息，而下一层的一个值又对应了本层的一个局部区域。所以随着网络层数的加深，特征图上的一个像素点在原图中所对应的区域会逐渐加大，也能囊括越来越多的信息。卷积神经网络内部每一层的感受野可以通过迭代的方式进行计算，公式如下：

$$RF_{i+1} = \begin{cases} ksize_1, & \text{if } i = 1, \\ ((RF_i - 1) \times stride) + ksize_i, & \text{else} \end{cases} \quad (2-9)$$

其中， RF_i 表示网络第 i 层的感受野大小， $ksize_i$ 表示第 i 层卷积核大小。即网络第一层的感受野大小等于第一层的卷积核大小，而接下来每层的感受野可由上一层的感受野及该层的卷积核大小计算得到。

(2) 权值共享

权值共享是卷积神经网络设计中的另一大特点。在介绍卷积层时，我们提到，卷积操作是通过将一个卷积核在输入图像 (或特征图像) 上滑动来完成的，即一个卷积核的参数会作用于整个输入图像，这就是所谓的权值共享。权值共享的设计

也具备一定的先验假设,即对于自然图像而言,局部区域的统计特征具有重复性,在某一个位置所出现过的特征在其他位置也可能出现,如相似的图像边缘、纹理等,所以可以采用相同的卷积核来进行对整张图像进行相似特征的抽取是可行的。但是由于一个卷积核仅能提取一种类型的特征,为了弥补这一点不足,卷积神经网络中的每一个卷积层一般都包含了很多个卷积核,用以抽取不同类型的特征,来完成特征间的互补。其次,通过权值共享,可以保证网络结构与参数个数和输入图像的大小的无关性,即无论输入图像的尺寸是多少,卷积层的参数个数都不会改变。

权值共享可以极大地减少网络的参数个数。例如对于一张 100×100 的单通道输入图像,同样提取 128 维的特征,使用全连接设计则需要 1.28×10^6 个参数,但若我们使用 128 个 3×3 的卷积核,那么最终的网络参数则会降为 1152 个。权值个数降为原本的千分之一。

2.3 行人重识别基础

上一小节中,我们介绍了神经网络的基础构件及特点,在本小节中,我们将主要介绍行人重识别任务的相关理论及技术细节。

2.3.1 问题表述

在第一章中我们提到,行人重识别问题其实就是非重叠视域下的行人检索问题,所以它具备和一般检索问题相同的形式。在测试时,给定一个包含 m 张待查询行人图像的查询库 (probe set) $P = \{p_1, p_2, \dots, p_m\}$, 以及一个包含 n 张行人图片的候选库 (gallery set) $G = \{g_1, g_2, \dots, g_n\}$, 我们希望对于待查询图像库中的每一张待查询行人图像 (query/probe), 找到其在候选库中所对应的图像 (可以是一张, 也可以是多张)。一般而言, 行人重识别算法的框架由特征提取与特征匹配两大部分组成, 如图2-8所示。在基于深度学习的行人重识别方法中, 特征抽取由网络完成, 提取完成后, 我们分别计算待查询图像与每一张候选图像之间的距离, 并找到距离最小的那一张图像作为查询图像的匹配:

$$I^*(q) = \arg \min_{i \in 1, 2, \dots, N} d(q, g_i) \quad (2-10)$$

其中, $I^*(q)$ 表示查询图像 q 的匹配对象, g_i 表示第 i 个候选图像, $d(\cdot, \cdot)$ 表示距离度量函数。

在行人重识别问题中最为常用的距离度量函数一般有以下几种:




图 2-8 行人重识别任务的一般流程框架

1) 欧式距离，也称 L2 距离，表征两个向量在欧式空间中的距离，公式表述如下：

$$d(x_i, x_j) = \sqrt{(x_i - x_j)^T (x_i - x_j)} \quad (2-11)$$

2) 马式距离：一般用于度量学习算法中的距离表述，公式表述如下：

$$d_M(x_i, x_j) = (x_i - x_j)^T \mathbf{M} (x_i - x_j) \quad (2-12)$$

其中 $\mathbf{M}$ 为半正定矩阵，所以其又可以被分解为 $\mathbf{M} = L^T L$ 的形式，所以式2-12在形式上也等于：

$$d_M(x_i, x_j) = \|L(x_i - x_j)\|^2 \quad (2-13)$$

所以马式距离相当于通过矩阵 L 将特征映射到另一空间后的欧氏距离。

3) 余弦距离：衡量两个向量在欧式空间中的夹角大小，余弦距离仅关注向量在空间中的方向相似度，而忽略了向量本身的长度。公式表述如下：

$$d_{cos}(x_i, x_j) = \frac{x_i^T x_j}{\|x_i\| \|x_j\|} \quad (2-14)$$

2.3.2 行人重识别任务与分类和检索任务的关系

行人重识别任务在本质上属于检索任务，但是由于任务的特殊性，使得其与传统检索任务又有一些不同。更加具体地说，行人重识别任务的特点介于图像分类任务与图像检索任务之间，它们之间的比较关系如表 2-1 所示。

表 2-1 行人重识别任务与分类和检索任务的比较

任务	训练样本类别标签	测试样本类别
分类	可用	仅限于训练类别
检索	不可用	不仅限于训练类别
行人重识别	可用	不仅限于训练类别

在行人重识别任务中，训练集中的行人个体标签是可用的，在这一点上与分类任务十分相似；但是在测试过程中，查询及候选库中的行人均不出现在训练集中，也就是说测试样本的类别在训练过程中不曾出现过，在这一点上，行人重识别又与检索任务相似。根据行人重识别任务的这一特点，我们可以将分类模型与检索模型的优势相互融合：分类模型具备强监督标签，更加擅长学习具有判别力的特征；检索模型更加注重对于特征在空间中的分布的学习，能够使得类内间距更小，而类间间距更大，并且更讲究效率。

2.3.3 评价指标

在一个行人重识别任务中，评价一个算法的优劣，往往会使用以下几个指标：

(1) 第一匹配率 (rank-1):

第一匹配率 (rank-1) 表示的是对于查询库中查询图像，其在侯选库中的匹配图像恰好与其属于同一行人的概率，即：

$$rank1 = \frac{\sum_{i \in 1, 2, \dots, m} s_i}{m} \quad (2-15)$$

其中 m 为查询库的总图片数， s_i 表示对于第 i 张查询图像，是否匹配成功，若成功则 $s_i = 1$ ，反之 $s_i = 0$ 。

第一匹配率是反映重识别模型性能最为直观也是最为关键的指标。一般而言，在行人重识别任务中，当我们需要评价两个模型之间优劣性时，会首先比较这一指标，rank-1 越高的模型往往性能越好。

(2) 第 k 匹配率 (rank-k) 和 CMC 曲线:

第 k 匹配率 (rank-k) 表示的是查询图像正确匹配出现在与之最相似的前 k 张

图片中的概率。常用的指标除了 rank-1 之外，还有 rank-5，rank-10 以及 rank-20 等。rank-1 体现的是模型对于最易匹配对象的检索能力，而 rank-k 指标则在一定程度上能够反映模型对所有匹配对象的检索能力，所以其能够更加综合地衡量模型的检索性能。

rank-k 除了使用表格的形式体现外，另一种常用的表现方式是使用累计匹配特征 (Cumulative Matching Characteristic, CMC) 曲线进行展示。CMC 曲线的纵坐标为 rank-k 值，横坐标为 k，曲线上的每个点表示在不超过 k 个结果中找到正确匹配的概率。CMC 曲线的起点 (即 rank-1) 与走势能够非常好地反映一个模型的优劣，当两个模型的 CMC 曲线进行比较时，曲线整体越高，则模型性能越好。

(3)mAP

在早期的行人重识别公开数据集中，行人图像数量较少，数据集结构也较为简单。一般来说，这些数据集中查询库中不同个体的行人图像仅有一张，且对于每一张查询图像，在候选库中也有且仅有一张正确的行人图像与之匹配。所以对于这些早期的数据集，top-k 以及 CMC 曲线已经足够描述一个模型的性能。但是随着行人重识别领域的发展，数据集不断更新迭代，很多复杂的数据集被相继提出，如 Market1501，MARS 等。在这些数据集中，每张查询图像在候选库中均有多张与之相匹配的正确图像，此时，仅仅使用 top-k 和 CMC 曲线等指标将不再能够满足模型评价的需求，这是因为这些指标没有对模型的召回率 (recall) 进行衡量，一个简单的示意图如图2-9所示。在这个例子中，三个查询样本的 CMC 均为 1，但是他们检索效果其实并不相同，因为第二个样本相较于第三个样本，它的正确匹配的置信度更高 (排名更前)，所以我们应该认为第二个样本的匹配效果更好。




图 2-9 使用 mAP 和 CMC 的区别示意

而 mAP(mean Average Precision) 这一指标则同时考虑了召回率 (recall) 与正确率 (precision)，能够更加综合且客观地评价模型的性能。在行人重识别任务中，我们将一个查询样本的检索正确率 (precision) 定义为匹配排名前 k 的图像中，正确

匹配数目所占的比例，即：

$$P = \frac{k_c}{k} \quad (2-16)$$

其中 k_c 为匹配正确的图像数目。

而该查询样本的检索召回率 (recall) 定义为其匹配排名前 k 的图像中，正确匹配的图像数目占候选库中所有属于该行人图像数目的比例，即：

$$R = \frac{k_c}{k_{all}} \quad (2-17)$$

其中 k_{all} 表示在候选库中与查询图像属于同一行人的图像数目，为一个定值。

当我们取定不同的 k 时， P 和 R 均会发生相应的变动。逐渐增加 k ，将相应的 P 和 R 值画作一条曲线，我们称之为“PR 图”。从而我们可以计算某一个查询样本“PR 图”下的面积，称之为 AP 值，所有查询样本 AP 值的均值则称为 mAP。

2.3.4 常用数据集

在行人重识别发展的不同阶段，有许多针对该任务的公开数据集被研究者们陆续提出，用来检验和比较不同模型之间的性能。在此我们将着重介绍其中几个相对重要的数据集。

VIPeR^[4] 是由 Gray 等人在 2007 年提出的一个专门针对行人重识别任务的数据集。该数据集包括了 2 个不同视角下的 632 个行人的图像，每个视角下仅包含每位行人的一张图片。同时，它很好地包含了不同视角下行人姿态、光照的变化，并且每张图片被标准化为统一的 128×48 尺寸，便于特征的提取。VIPeR 可以说是第一个真正意义上的行人重识别公开数据集，在本领域早期的研究中，被研究者们广泛使用来评价传统模型的性能，极大程度上推动了行人重识别领域的发展。但是由于拍摄条件的限制，该数据集在图像数量及清晰度上均无法很好地满足深度学习模型对于训练数据的需求，所以当深度模型兴起后，VIPeR 不再成为检验深度模型的主要数据集，仅被个别工作用来检验模型在小样本条件下的泛化能力。

为了满足一些复杂模型对高质量的数据集的需求，香港中文大学分别于 2012 及 2014 年提出了 CUHK01^[56] 及 CUHK03^[29] 两个数据集。其中 CUHK01 包含了 971 个行人在两个视角下的图片，每个视角下每位行人的图像数为两张，每张图像的大小为 160×60 ；CUHK03 包含了 1360 个行人的 13164 张图像，使用 5 个不同的摄像机对进行拍摄，每一对摄像头拍摄两个不同视角的行人图像，平均每位行人在每个视角下有 4.8 张图像。该数据集采用了手工标注和 DPM 检测两种方式来



图 2-10 行人重识别数据集示例图

定位视频中的行人图像。相较于在此之前其他的数据集，CUHK 在图像质量和数量上都做了较大的改善，基本解决了先前由于数据集限制而无法很好地完全训练深度模型的问题。在 CUHK 数据集出现后，基于深度学习方法行人重识别模型也逐渐迎来了春天，越来越多相关的工作在国际的顶级会议和期刊中涌现。

表 2-2 行人重识别数据集基本信息

数据集	提出时间	行人数	图片数	摄像头数目	标签方式	评价指标
VIPeR	2007	632	1264	2	手工	CMC
iLIDS	2009	119	476	2	手工	CMC
GRID	2011	250	1275	8	手工	CMC
PRID2011	2011	200	1134	2	手工	CMC
CUHK01	2012	971	3884	2	手工	CMC
CUHK03	2014	1467	13164	2(5 对)	手工/DPM	CMC
Market-1501	2015	1501	32668	6	DPM	CMC/mAP
MARS	2016	1261	1191003	6	DPM+GMMCP	CMC/mAP
DukeMTMC-reID	2017	1812	36441	8	手工	CMC/mAP
MSMT17	2018	4101	126441	15	Faster RCNN	CMC/mAP

在此之后，悉尼科技大学的研究人员在 2015 年提出了 Market1501^[57] 数据集。Market1501 数据集在设计上相较于 CUHK 数据集又做了进一步的改善，使之更加符合行人重识别系统在现实情况中的应用。它包含 1501 个行人在 6 个不同视角下的 32368 张图像，每位行人在每个视角下平均拥有 3.6 张图像。整个数据集

被划分为两个部分，其中训练集包含了 751 个行人的 12936 张图像，剩下 750 个行人的 19732 张图像作为测试集，包括 3368 张查询图像以及 16364 张候选图像。Market1501 数据集在测试集的设计中，查询与候选的每一位行人均包含了多个视角下的图像，这使得该数据集能够更加综合、客观地反映模型的性能。并且在 [57] 中首次将 mAP 这一指标引入行人重识别任务，用以衡量多视角匹配的性能，该指标也广泛应用于之后的各大数据集中。

图2-10中展示了上述几个数据集的一些样例。在领域的整个发展过程中，还有很多其他知名的数据集被提出，表2-2展示了这些数据集的基本信息。

2.4 本章小结

在本章中，我们首先详细介绍了卷积神经网络基础理论知识，其中分别介绍了常用的卷积层、池化层、全连接层、激活函数以及批归一化层等常用的网络基础构件及神经网络的基本特点。在此基础上，我们介绍了神经网络在处理行人重识别任务时的一般框架，并且分析了该任务的特点。最后我们介绍了行人重识别任务中常用的评价指标以及数据集。在本章中介绍的内容将在后续章节中使用。

第3章 面向度量学习的多任务学习策略

度量损失函数在基于深度学习的行人重识别模型中扮演着至关重要的角色，是度量学习方法的核心组成部分。损失函数的设计直接决定了模型能否学习到的一个好的特征映射方式，从而影响模型的检索性能。此外，不同的损失函数具有其各自不同的特点，有的损失函数之间存在着较好的互补性，当它们协同工作时，会表现出更好的性能。在本章中，我们就将探究不同度量损失函数在行人重识别任务中的表现，以及基于损失函数融合的多任务学习策略。

3.1 引言

在前文(2.3.2小节)的分析中，我们提到，行人重识别任务具有其自身的特殊性，它同时具备了分类任务与检索任务的一些特点，这使得我们可以选择使用分类模型或检索模型来对这个问题进行建模。分类模型和检索模型具备它们各自不同的特点：(1) 对于分类模型而言，由于具备强监督信息，所以其更加擅长学习具有判别力的特征。但分类模型本质上考虑的是样本在特征空间中的分布与分类边界之间的关系，而没有考虑样本点之间的相互联系，所以在分类成功时，却存在着检索失败的可能，如图3-1(a)所示。此外，当训练集中未曾出现的类别，分类模型将显得束手无策；(2) 检索模型则不同，其更加注重样本点之间的相对分布情况以及它们之间的距离度量方式，在建模时，往往会显式地加入样本之间的空间约束，要求同类样本的聚类更加紧促且不同类的样本簇在空间上具备一定的间隔，从而满足检索的需求，如图3-1(b)；但同样，检索模型也有其不足之处，由于它使用的是一种较弱的监督信息(样本是否属于同一类)，所以当其在考虑一组图像的空间约束时，往往会忽略这组图像与数据集中其他图像的关联，这可能会导致模型丧失部分对数据集整体建模的能力。

所以从以上分析可以看出，分类模型与检索模型各有其的优劣，并且存在着互补性。而对于行人重识别任务而言，一方面，我们希望能够得到具有判别力的行人特征以适应不同视角下行人姿态的变化；另一方面，由于在测试时，所使用的查询与候选行人均未出现在训练集中，且在行人图像中普遍存在着类内距大于内间距的情况，所以我们又希望网络能够关注到样本之间的联系，从而自适应地学习到一个良好的度量方式。基于以上考虑，我们认为多任务学习的策略能够更加




图 3-1 分类与检索样本分布示意

有效地解决行人重识别问题，即让模型同时处理分类与检索两个任务，以促使网络学习到具有判别力的行人特征的同时，也能够学习到一个良好的度量方式。

在深度学习模型中，分类模型与检索模型由于建模目标不同，往往使用不同的损失函数，而在特征提取部分的网络却十分类似。所以在本章中，我们将主要探究不同损失函数及其组合在行人重识别任务中的性能，而非用于网络中的特征提取部分。首先我们对几类不同的分类及检索损失函数进行介绍，然后介绍我们所使用的特征提取网络，最后，我们会探究在该网络中不同损失函数融合策略及其效果，以完成多任务学习的目标。

3.2 多损失函数设计

3.2.1 交叉熵损失函数

交叉熵损失函数 (Cross-entropy loss 或 Softmax loss) 是分类模型中最常用的损失函数。一般来说，在分类网络中完成特征的提取后，会经过一个分类的全连接层，得到样本属于各类的置信度，然后再用 Softmax 层来对置信度进行归一化，输出样本属于各类的概率，即：

$$p_i = \frac{e^{\mathbf{W}_i^T \mathbf{x} + b_i}}{\sum_j e^{\mathbf{W}_j^T \mathbf{x} + b_j}} \quad (3-1)$$

其中， i 表示类别标号； $\mathbf{W}_i$ 和 b_i 表示分类器的全连接层中特征与第 i 个输出之间的权重与偏置； $\mathbf{x}$ 表示图像特征； p_i 表示样本属于的第 i 类的概率。

由式3-1得到样本属于各类的概率后，便可计算 softmax loss：

$$L_{softmax} = -\frac{1}{N} \sum_i \log(p_{y_i}) \quad (3-2)$$

其中, i 表示样本编号; y_i 表示第 i 号样本的标签; N 表示样本总数。

在后文的实验中 (表3-1), 我们发现, 仅仅使用 resnet50 和 softmax loss 的组合, 在 Market1501 数据集上就可以得到较好的结果。但即使如此, 我们认为对于行人重识别任务而言, softmax loss 在设计上存在其缺陷: 其在机制上缺乏对样本特征在空间中分布的显式约束, 它既不能保证样本的类内距离足够小, 也不能保证样本的类间距离足够大, 所以并不能满足检索任务的需求。

事实上, softmax loss 在结果上会倾向于产生“辐射状”的样本分布^[58]。我们在 MNIST 数据集上, 对 softmax loss 进行了实验, 并将最终特征的分布可视化出来, 如图3-2所示。可以看到不同类的样本在空间中距离较近, 甚至出现了类间样本混杂的情况, 这种情况对检索任务是非常不利的。所以在损失函数的机制中加入对样本空间分布的约束是必须的。




图 3-2 Softmax loss 在 MNIST 上训练后得到的样本特征空间分布

3.2.2 A-softmax 及 AM-softmax 损失函数

A-softmax loss^[59] 在 AM-softmax loss^[60] 是 softmax loss 的改进版本, 它们在 softmax 的基础上加入了样本分布间距 (margin) 的机制, 在训练中强迫不同类样本间的间距更大, 而同类样本的样本聚类更加紧密。A-softmax loss 和 AM-softmax loss 最早出现在人脸验证 (Face Verification) 的工作中, 而由于人脸验证与行人重识别任务有诸多相似之处, 所以我们将这两个损失函数引入到行人重识别任务中,

并验证其效果。

(1) A-softmax loss

A-softmax loss 的思路是将一般网络中最后一个全连接层 (即分类器) 的权重向量与样本的特征向量的点积过程视作向量间的投影, 在去除偏置 b 的影响后, 普通 softmax loss 可以改写成:

$$L_{softmax} = -\frac{1}{N} \sum_i \log \left(\frac{e^{\|W_{y_i}\| \|x_i\| \cos(\theta_{y_i,i})}}{\sum_j e^{\|W_j\| \|x_i\| \cos(\theta_{j,i})}} \right) \quad (3-3)$$

其中, i 表示样本编号; y_i 表示第 i 号样本的标签; $\theta_{j,i}$ 表示特征向量 x_i 与第 j 类分类权重向量 W_j 之间的夹角, 当其较小时, 说明 x_i 与 W_j 的在方向上更加接近。

对于普通的 softmax loss, 通过要求 $W_1^T x > W_2^T x$ (即 $\|W_1\| \|x\| \cos(\theta_1) > \|W_2\| \|x\| \cos(\theta_2)$) 来使样本偏向于第一类的置信度更高, 从而达到将样本分为第一类的目的。但我们可以通过加入更加严苛的约束, 来进一步提升样本偏向于第一类的置信度。假如我们要求: $\|W_1\| \|x\| \cos(m\theta_1) > \|W_2\| \|x\| \cos(\theta_2)$, 那么在这种情况下, 特征向量 x 与第一类分类权重向量 W_1 之间的夹角必须比原来更小, 才可以达到原本的分类约束条件, 即当分类向量固定时, 属于同一类的样本会比原本更加紧促, 而不同类的样本中间则会出现一定的间隔, 如图3-3所示。这样, 便在 softmax loss 中, 加入了基于角度 margin 机制。为了使这种角度的 margin 更加明显, 并且简化计算, A-softmax loss 还将每类权重向量 W_i 进行了归一化处理, 这样一来, 原本的 softmax loss 便可以改写成为:

$$L_{Asoftmax} = -\frac{1}{N} \sum_i \log \left(\frac{e^{\|x_i\| \cos(m\theta_{y_i,i})}}{e^{\|x_i\| \cos(m\theta_{y_i,i})} + \sum_{j \neq y_i} e^{\|x_i\| \cos(\theta_{j,i})}} \right) \quad (3-4)$$

其中, m 即为间隔, 用来控制同类样本的紧促程度以及不同类样本间的间隔。 m 越大则同类样本越紧促, 且不同类样本间的间隔越大。其他符号含义与3-1中相同。




图 3-3 A-softmax 与 softmax 的对比

此外,为了解决当 $m\theta_{y_i,i}$ 大于 π 时, $\cos(m\theta_{y_i,i})$ 出现不单调的情况, A-softmax 中还加入了一个单调函数 $\psi(\theta)$ 来代替 $\cos(\theta)$:

$$\psi(\theta) = (-1)^k \cos(m\theta) - 2k, \quad \theta \in \left[\frac{k\pi}{m}, \frac{(k+1)\pi}{m}\right] \quad (3-5)$$

其中, k 为整数且 $k \in [0, m-1]$ 。

从而, 式3-4等于:

$$L_{Asoftmax} = -\frac{1}{N} \sum_i \log \left(\frac{e^{\|x_i\| \psi(\theta_{y_i,i})}}{e^{\|x_i\| \phi(\theta_{y_i,i})} + \sum_{j \neq y_i} e^{\|x_i\| \cos(\theta_{j,i})}} \right) \quad (3-6)$$

同样,为了直观地展示 A-softmax 的效果,我们同样在 MNSIT 数据集上对其进行了实验,并将训练得到的特征分布展示在图3-4 b)中,并将其与最基本的 softmax 进行了对比。可以看到,相较于原本的 softmax, A-softmax 训练得到的样本聚类更加紧促,不同类的样本之间出现了明显的夹角间隔,这对于检索任务是十分有利的。

(2)AM-softmax loss

AM-softmax loss 是在 A-softmax 的基础上改进而来的。在 A-softmax 中,引入了一种类似于夹角间隔的的机制,从而使样本能够更加鲜明的被分开。但是我们可以看到,在 A-softmax 中,引入了 $\cos(\theta)$ 和 $\psi(\theta)$ 这种非线性的函数,这不仅使得网络的计算效率下降,而且不易求导,在具体实施时会有一定的难度。

基于以上考虑,AM-softmax 在延续了 A-softmax 思想的基础上,对其进行了一定的改善,使其具有更加简单的形式,从而便于实施。具体来说,AM-softmax 的形式如下:

$$L_{AMsoftmax} = -\frac{1}{N} \sum_i \log \left(\frac{e^{s \cdot W_{y_i}^T x_i - m}}{e^{s \cdot W_{y_i}^T x_i - m} + \sum_{j \neq y_i} e^{s W_j^T x_i}} \right) \quad (3-7)$$

其中 m 为间隔,用来控制样本的类内类间分布, s 为缩放因子,用来控制网络的收敛速度。其他符号含义与式3-4中相同。

与 A-softmax 相比,AM-softmax 将 $\|W\| \|x\| \cos(m\theta)$ 的形式直接改为了 $W^T x - m$, 这相当于只需要在原本 softmax 的基础上,在样本对应标签的那一类的输出置信度上直接减去 m 即可,操作起来非常方便,而且也很好地体现了 margin 的思想:样本在本类上的置信度必须足够高,使得其减去 m 后,仍然能够成为置信度最高的那一个。这样同样能够达到样本类内分布更加紧促的目的。AM-softmax 的 demo 实验被展示在图3-4 c)中,可以看到,虽然 AM-softmax 简化了操作,但与 A-softmax

达到了几乎相同的训练效果。




图 3-4 分类损失函数在 MNIST 上的训练结果示意

3.2.3 三元组损失函数

三元组损失函数 (Triplet loss)^[61] 是检索任务中最常用的损失函数之一。与之前介绍的几种分类损失函数不同，检索任务的损失函数考虑的是样本与样本之间的关系，它们直接作用于样本的特征分布，而非分类置信度。例如三元组损失函数就将对样本分布的约束显式地加入函数的设计中，使得网络在训练的过程中，能够自适应地使样本映射到一个同类间距较小，异类间距较大的特征空间中。

具体来说：使用三元组损失的网络一般会使用一个三元输入网络，该网络的前端的特征提取部分采用参数共享的结构。在训练时，每次挑选一个三元组 $x_i = \langle x_i^a, x_i^p, x_i^n \rangle$ 作为输入，其中 x_i^a 称为锚点样本， x_i^p 是 x_i^a 的同类样本， x_i^n 是 x_i^a 的异类样本，在使用网络分别进行提取特征后，进行损失计算，具体表示如下：

$$L_{triplet} = \frac{1}{N} \sum_{\substack{a,p,n \\ y_a=y_p \neq y_n}} [m + d_{a,p} - d_{a,n}]_+ \quad (3-8)$$

$$d_{i,j} = D(f_\theta(x_i), f_\theta(x_j)) \quad (3-9)$$

其中， θ 为网络参数； $f_\theta(x)$ 表示由网络计算得到的样本特征； $D(\cdot, \cdot)$ 表示距离度量函数； m 为间距差阈值； x 表示样本； N 表示输入网络的三元组总数。

三元组损失的直观含义就是当同类样本的特征间距与异类间距的差小于某一阈值时，即产生损失，从而迫使网络在学习的过程中自适应地学习到一种具有判别力的样本特征映射方式。

我们将 triplet loss 在 MNIST 上的训练效果展示在图3-5 a)中，可以看到与 softmax loss 得到的“辐射状”分布不同，triplet loss 得到的样本分布呈现出“簇团”状的形态，属于同一类的样本聚类到了一个簇中，并且不同类的样本簇之间有明显的间隙，很好地体现了 triplet loss 的效果。这种同类样本近，异类样本远的分布能够有效地提升检索的成功率。

3.2.4 基于 KN 困难采样的三元组损失

基于 KN 困难采样的三元组损失 (KN-triplet loss)^[37] 是一种改良版的 triplet loss。事实上，triplet loss 在训练时存在着一些不可避免的问题，如训练效率低下、收敛效果不理想等。而 KN-triplet loss 在 triplet loss 的基础上，加入了一种困难样本采样机制，使得其在训练的过程中，能够关注到一些更加困难的三元组样本，从而提高网络的收敛效果；此外它还能够充分利用到一个 batch 内的信息，从而也提高了网络的训练效率。

KN-triplet loss 采用了一种 KN sample 的采样策略，并在 loss 项的设计中，加入了困难样本的挖掘策略。具体而言，在 KN-triplet loss 中，将原本的随机三元组采样改为了使用每次挑选 K 类样本，每类样本选取 N 张图来组成一个 batch 的采样方式。并且，对于一个 batch 内的训练样本，KN-triplet loss 只挑选其中最为困难的三元组组合参与 loss 的计算：

$$L_{KNtriplet} = \frac{1}{PK} \sum_{i=1}^{PK} \left[m + \max_{+} D(f_{\theta}(x_i^a), f_{\theta}(x_i^p)) - \min_{-} D(f_{\theta}(x_i^a), f_{\theta}(x_i^n)) \right]_{+} \quad (3-10)$$

其中, $\max_{+}(\cdot)$ 和 $\min_{-}(\cdot)$ 分别表示在一个 batch 中挑选所有正样本中的最大值, 和挑选所有负样本中的最小值。其他符号含义与3-8中相同。

通过式3-10我们可以看到, KN-triplet loss 在每一个 batch 中, 都会挑选最困难的正样本 (距离最大) 和负样本 (距离最小) 参与 loss 的计算, 这体现了困难样本挖掘的思想。在实验中证明, 与传统的 triplet loss 相比, 这样的操作可以大大加快网络的收敛速度, 并且能够有效地使网络避免训练瓶颈, 从而收敛到更优解。

图3-5 b)展示了 KN-triplet loss 训练效果, 可以看到相较于 triplet loss, KN-triplet loss 得到的样本分布呈现出的聚类簇更加紧促, 而且簇与簇之间的间距更大




图 3-5 检索损失函数在 MNIST 上的训练结果示意

3.2.5 多任务学习

多任务学习 (Multi-task learning) 就是要求网络同时完成多种不同类型的任务, 与之对应的, 就是采用多种不同的损失函数对网络进行同时训练。在这一过程中, 不同的损失函数各自发挥作用, 对网络产生更强的约束, 一些损失函数虽然针对不同的任务, 但是他们最终对样本特征在空间分布的约束是相似的, 所以具备互补性。合理地利用这种互补性能够有效地提高网络提取特征的能力, 从而改善网络的性能。

在这里，我们提出多任务学习的行人重识别策略，将使用网络来共同完成分类任务与检索任务。在本章的实验中，我们将探索上述分类损失与检索损失函数的不同组合策略以及它们在行人重识别任务中的表现。

3.3 网络结构设计

在上一小节中，我们介绍了多种分类及检索的损失函数以及多任务学习的模型训练策略。在本小节，我们将介绍我们在多任务学习中所使用的网络结构。由于在本章中，我们更加关注模型的度量学习部分，即不同损失函数对模型性能的影响，而非模型的特征提取，所以我们在介绍模型结构时，将略化对特征提取网络的介绍。为了使网络能够同时使用分类损失以及检索损失进行训练，我们在网络中分别设计了一条分类分支以及一条检索分支，并将网络前端抽取的特征分为两支分别输入这两个部分，具体而言，我们的网络结构如图3-6所示。




图 3-6 多任务学习的网络结构

从上图可以看到，行人图像进入网络后，会先经过特征提取网络，然后分为两支，分别进入分类分支与检索分支：

(1) 对于分类分支而言，行人特征会先经过一个 Max pooling 层进行特征的降维，然后经过一个 512 维的全连接层进行特征映射，在该全连接层之后，我们还设置了一个 Leaky-ReLU 以及一个 BN 层，最后特征会再经过一个 dropout 层，输入到分类损失函数中进行训练。

(2) 对检索分支而言，行人特征会先经过一个 512 维 1×1 的卷积进行特征再抽取，之后再经过一个 Leaky-ReLU 以及一个 Max pooling 进行特征的降维，得到一个 512 维的特征；然后我们会在此处进行在线的三元组采样，抽取指定的三元

组特征输入到损失函数中进行训练。

网络总体的损失函数由两个分支的损失函数共同组成：

$$L_{total} = L_{cls} + L_{ret} \quad (3-11)$$

其中 L_{cls} 和 L_{ret} 分别表示分类分支和检索分支损失函数。

3.4 实验结果及分析

3.4.1 实验配置与参数

本章实验所使用的软件及硬件条件为：i7-6700K CPU，GTX 1080Ti 显卡，Ubuntu16.04 操作系统，Pytorch 深度学习框架。

本章中涉及到的模型训练参数如下：输入图像尺寸 384×128 ；使用 SGD 算法进行模型优化求解，动量 momentum 设为 0.9，权重衰减系数为 5×10^{-4} ；模型训练初始学习率为 0.01，总共迭代 60 个 epoch，在第 40 个 epoch 出进行学习率衰减，衰减率为 0.1；训练所使用的 batchsize 为 48。

本章实验中所使用的数据集为 Market1501，相关的对比实验及最终的实验效果均使用该数据集上的结果进行展示。

3.4.2 网络基础结构挑选

我们将在本小节中首先进行最简单的基础性实验，来挑选3.3节中我们提出的多任务学习网络的特征提取部分的网络结构。我们挑选了几个最为常用的深度学习模型：AlexNet,VGG-16,Inception 以及 Resnet50 进行实验。为了验证各模型在对于行人特征的提取能力，我们在不改动任何网络结构(除了最后一个分类全连接层改成相应的 751 类)的情况下，直接使用 softmax 损失在 Market1501 数据集上进行训练。实验的结果如表3-1所示。

表 3-1 基础网络性能测试

分支网络	rank1 准确率 (%)	mAP(%)
AlexNet	56.0	32.4
VGG-16	68.2	48.1
Inception	69.7	49.9
Resnet50	76.9	54.9

从上表中我们可以看出，几个网络中，AlexNet 网络的表现最差，VGG-16 和 Inception 网络取得了相似的性能，而 Resnet50 的性能远高于其他几个网络。并且

与 VGG-16 和 Inception 网络相比, Resnet50 在模型参数上也要小得多。所以在本章及之后的实验中, 我们将使用 Resnet50 作为网络特征提取模块。

3.4.3 单损失函数性能测试

在上一小节实验的基础上, 我们将使用 resnet50 最后一个 average pooling 层之前的网络作为网络特征提取模块, 并使用我们在3.3节中提出的网络进行各个损失函数的性能测试。

对于分类损失函数, 我们将仅使用网络中的分类分支, 去除检索分支; 而对于检索损失函数, 我们将仅使用检索分支。此外, 各损失函数所涉及的训练参数如下:

(1)A-softmax 和 AM-softmax: 由于这两种损失函数非常相似, 但 AM-softmax 的实施较 A-softmax 来说更为简单, 并且其在人脸验证任务中取得了更好的性能, 所以在本小节的实验中, 我们仅对 AM-softmax 进行实验。对于该损失函数, 我们所采用的参数为: $m = 0.25, s = 12$ 。

(2)triplet: 在一个 batch 中, 我们采样的三元组对数为 300 对, 采样方式采用随机采样, margin 参数设置为 $m = 1.2$ 。

(3)KN-triplet: 在使用 KN-triplet 损失时, batch 的采样方式选用 $P = 12, K = 4$ 的均匀采样, margin 参数设置为 $m = 1.2$ 。

在训练时, 我们对输入行人做了随机水平翻转的数据扩增; 同样的, 在测试中, 对于输入的一张行人图像, 我们选用该张图像的特征以及其水平翻转后图像的特征的和来作为最终特征进行行人表示。

我们采用上述设置, 在 Market1501 数据集上进行了实验, 实验结果如表3-2所示。

表 3-2 单损失函数训练实验结果

分支网络	rank1 准确率 (%)	mAP(%)
softmax	83.3	65.8
AM-softmax	84.2	67.9
triplet	57.0	34.4
KN-triplet	85.1	68.6

从表3-2的结果中我们可以看出:

(1) 同为分类损失函数, AM-softmax 较 softmax 的性能有所提升, 说明它的

margin 机制在行人重识别任务中确实发挥了作用，能够使类与类之间的距离拉远，从而提高检索成功率。

(2) 对比检索损失 triplet 和分类损失 softmax，我们发现尽管 triplet 在设计中加入了对样本类内类间距离的约束，但是其性能却远不如 softmax，这与我们的预期很不符合。我们认为造成这一现象的原因可能是：1) triplet loss 在训练时，仅仅使用了一个三元组内部 2 个样本对的信息，导致其无法充分利用一个 batch 内所有样本的信息，所以训练效果较差；2) 与 softmax loss 不同，triplet loss 的训练过程结果极大程度上依赖于三元组采样的质量，而在样本复杂的行人重识别数据集中，使用随机采样的采样方式采集到高质量的三元组的十分困难，从而导致 triplet loss 在训练中非常容易陷入瓶颈，无法进一步提升性能。因此我们认为样本的 hard mining 在 triplet loss 训练过程中是非常重要的。确保每次采集高质量三元组来进行训练，可以提高 triplet loss 的训练效果。

(3) 对比 KN-triplet 和 triplet 的结果，我们发现，加入 hard mining 后，KN-triplet 的效果得到了大幅度的提升。这一点验证了我们之前的分析。并且，仅使用单损失函数的情况下，KN-triplet 取得了最好的结果，进一步验证了它的有效性。

3.4.4 组合损失函数性能测试

在本小节中，我们将进一步验证多任务学习策略的有效性。我们采用的多任务学习策略为：分类任务加检索任务共同训练，所以我们将测试不同分类损失函数及检索损失函数的组合性能。

在实验中，我们采用的网络结构为3.3节中提出的多任务学习网络。使用多损失函数联合训练时，各损失函数的训练及测试配置与上一小节中一致。实验结果如表3-3所示。

表 3-3 多任务学习实验结果

分支网络	rank1 准确率 (%)	mAP(%)
softmax+triplet	75.2	51.1
softmax+KN-triplet	89.6	72.4
AM-softmax+triplet	68.2	42.1
AM-softmax+KN-triplet	87.1	70.9

分析实验结果，我们可以发现：

(1) 在采用多损失函数融合训练后，融合 triplet 后的 softmax 和 AM-softmax 性

能均有所下降，这是由于单损失函数情况下 triplet 的性能较差，从而影响了分类损失的收敛。而在融合了 KN-triplet 后，softmax 和 AM-softmax 的结果均高于单损失函数的结果，说明良好的检索损失与分类损失之间存在着一定的互补性，这也验证了我们多任务学习策略的有效性。

(2) 比较 softmax loss 与 AM-softmax loss 的实验结果，我们可以发现虽然在单损失函数的情况下，AM-softmax 要优于 softmax，但是当与检索 loss 进行组合时，softmax 获得了更大的提升，与 KN-triplet loss 进行联合训练的结果均超过了 AM-softmax，这说明 softmax 与两类 triplet 的协调性与互补性更高。

在以上实验结果中，softmax+KN-triplet 的组合取得了最好的效果，rank1 准确率达到 89.6%，相较于原始的 softmax 提升了将近 6%。因此，我们将这一组组合视为最优的损失组合，并将其融入下一章的特征网络设计中。

3.5 本章小结

在本章中，我们首先分析了行人重识别任务的特点以及它与传统的分类任务及检索任务之间的关系，在此基础上提出了多任务协同学习的策略。然后，我们阐述了四种不同分类及检索损失函数 (softmax、AM-softmax、triplet 及 KN-triplet) 的原理进行了阐述，并且通过在 MNIST 上的 demo 实验展示了各个损失函数的训练效果。之后，我们提出了我们所使用的多任务学习网络。在实验阶段，我们首先验证了各个损失函数在 Market1501 数据上单独的性能，并根据实验结果分析了他们的优劣，然后使用我们之前提出的多任务学习网络验证了不同损失函数的组合策略。

第4章 面向特征提取的多尺度融合网络结构设计

4.1 引言

在前文的分析中我们提到,不同视角下的行人图像由于姿态、光照等因素的变化,会产生较大的差异,从而对检索造成一定的难度,所以如何得到对于视角鲁棒的行人特征是行人重识别领域一直以来所探究的问题之一。虽然目前的深度学习模型能够根据数据集的特点自适应地获取目标的主要特征,但是直接将传统的特征提取网络用以解决行人重识别任务,往往不能获得令人满意的效果。这是由于目前主流的深度学习网络结构(VGG,resnet等)更多是基于Imagenet数据集的识别任务所设计的,Imagenet数据集包含的图像种类多,且不同类之间的形态差异较大,而对于行人图像而言,结构相对单一,人与人之间的差异更多地体现在衣着、装扮这种细粒度的信息上,且因为遮挡、形态变化等因素的存在,进一步加大了网络学习的难度,所以直接使用这些主流的网络结构来处理行人重识别这一类细粒度的检索任务存在着较大的难度。这就要求我们进一步深入探究行人图像的特点,将行人图像的先验知识融入到网络的设计中,设计出更具有任务针对性的网络模块及结构,来协助网络的学习。

在本章中,我们提出了一种根据行人重识别数据集的特点所设计的网络结构,来帮助网络学习到更具有判别力的行人多尺度融合特征。此外,我们进一步探究了此方法存在缺点及不足,并由此提出了相应的行人图像对齐方法及其网络结构。我们将以上两个网络融合成为一个端到端的网络来进行行人特征的提取,取得了不错的效果。

4.2 多尺度融合特征及网络结构设计

4.2.1 思路来源

基于深度学习的行人重识别方法中所使用的特征可以被分为两类,即全局特征和局部特征。在很多工作中,如[34,39,62]等,均直接使用全局特征来进行对行人的描述,这类方法一般直接使用在Imagenet上预训练的模型在行人重识别的数据集上进行微调。然而,全局特征虽然能够从整体上较好地描述行人的外貌,但却缺乏细粒度信息,无法很好地区分相似个体之间的差异。而局部特征相较于全局特征而言能够更好地反映行人的局部差异,所以更具备判别力。因此我们认为,

在行人重识别任务中，对于局部特征的挖掘是非常必要的。

在以往的行人重识别工作中，已经存在着一些挖掘局部特征的方法，例如 [43, 63,64] 等，它们的示意图如图4-1所示，这些工作的思路一般基于两点：(1) 使用人体 pose 的信息对行人的不同部位进行划分；(2) 在网络中额外的 part 定位模块使网络自适应地寻找到行人的不同部位。但其实都存在一些不足，其中第一种方案需要使用额外的 pose 预训练模型或是 pose 标注，第二种方案则会极大地增加网络的参数，降低模型的效率，且会存在定位不准确的情况。在本文中，我们会使用一种更加简单且仍然有效的方法进行行人局部特征的提取。




图 4-1 基于局部特征的方法展示图

对于目前大多数行人重识别数据集而言，行人图像往往来源于视频片段，研究者们一般会通过手工或是检测器的方式来定位出视频中的行人，然后将行人图片单独裁剪出来，形成数据集中的行人图像。当我们对这些行人图像进行观察与分析时可以发现，它们往往具有以下特点：(1) 一张图像中有且仅有一个行人；(2) 行人位于图像的中央，且占据了整张图像的绝大部分区域；(3) 大多数行人图像具有

高度的结构性，即行人某一部位在图片中的位置相对而言较为固定。例如图 4-2 所示，在 Market1501 数据集中，我们随机挑选了一些行人图像，采用均分操作将行人图像分为高度相等的四个条形部分，可以发现，每个行人相同部分对应的身体部位基本相同。




图 4-2 行人图像结构性示意图

所以，我们可以这种机械的划分方式来近似等效地代替定位行人不同 part 的过程，这将大大减少网络设计中的工作量。此外，我们也可以将这一结构信息融入到网络的设计中，将网络分为若干个不同的分支，每一个分支用以处理行人的不同区域。这样便可以强迫网络的每个分支去学习到更具有判别力的行人局部特征。在检索时，我们可以将这些局部特征结合起来，从而提高网络整体的检索性能。

这种基于行人高度结构性的条形划分方式在形式上与图像处理中常用的切块特征提取有些类似，但是从设计思路上来看，却有很大的不同。普通的图像切块提取特征方法在对每一个切块图像提取特征后，往往需要通过后处理算法挑选出其中一些具有代表性的图像块来作为图像的整体表示，这种方式具有以下缺点：(1) 在机制上无法保证各图像块的语义性，均匀切分会大概率导致在语义上属于同一部分的图像区域被划分到不同的图像块中，这样就破坏了该局部区域本身所具有的语义特征；(2) 丢失了各图像块之间的空间结构信息，破坏了图像块与图像块之间的空间关联性，导致分块的局部特征对图像的代表能力下降。而基于行人高度结构性的条形划分则一方面可以保证每一个条形区域都具备高度的语义性，另一方面也保留了条形与条形之间在空间上的结构关系，所以用这种局部区域特征来对

行人进行表示是一种切实可行的方案。

另一方面,这种设计非常符合我们的日常生活经验。在日常生活中,当我们需
要识别一个人时,往往不需要得到这一个人所有的外观信息,而是只需要通过其
中部分的外观信息进行便可以完成判断。所以我网络中的每一个分支实际上充当
了这种局部信息的观察者与判断者。当每一个分支在仅需要观察部分信息即可判
断成功的情况下,那么将所有分支的信息结合起来进行判断,自然能够得到更加
优秀的效果。

4.2.2 多尺度融合网络结构设计

根据上一小节中对行人图像特点的分析,我们在主流深度学习模型的基础上
进行了一定的改进,将行人图像的结构化特点融入到其中,增强了网络提取局部
特征的能力。经过改进后的网络结构如图4-3所示。




图 4-3 MSN 网络结构示意图

由于网络的主要特点是在网络内部同时抽取了行人不同尺度两个特征,即局
部特征及全局特,所以我们将以上的网络结构称为多尺度的网络结构 (Multi-Scale
Network, MSN)。在这个网络结构中,主要包含了两个分支:局部分支及全局分支。
其中,局部分支的设计体现了之前对行人图像结构的分析,用以提取行人不同区
域的局部特征;而全局分支则沿用了第三章中的设计,用来提取行人的全局特征。
最终,我们将局部分支与全局分支所提取的特征融合成为一个整体的特征,进行
行人的检索。

下面从前缀网络,全局分支、局部分支以及损失函数这几个方面来详细介绍
网络的组成:

1) 前缀网络:

为了节省网络的参数,提高训练的效率,对于网络的全局分支与局部分支,我们采用了同一个前缀网络来进行前端特征的提取。对于这一部分,我们沿用了 resnet50 网络结构,并且去掉了其中最后的 conv5 卷积模块、Average pooling 层以及用于分类的全连接层,保留了 conv5_1 之前的网络来作为这一部分的网络结构。前缀网络的输出分为两支,一支输入到全局分支中,一支输入到局部分支中。

2) 全局分支:

在全局分支中,我们采用了和第三节中类似的网络结构。前端网络提取的特征输入到全局分支之后,首先会经过一个 stride 为 2 的 conv5 残差模块。其后,我们采用了多任务学习的策略来对全局分支进行处理。具体来说,从 conv5 得到的输出会被分为不同的两支,其中一支经过一个 max pooling 层后,连接一个 512 个神经单元的全连接层进行特征的降维,然后再经过一个 BN 层,和一个 leaky ReLU 层后,输入到 softmax loss 中进行训练,这个分支主要用来完成分类任务;另一个分支连接一个 512 维的 1×1 卷积进行特征降维,然后同样经过 BN 层和 leaky ReLU 层之后再经过一个 max pooling 层,得到一个 256 维的特征,输入到 KN-triplet loss 中进行训练,用来完成检索任务。

3) 局部分支:

对于局部分支,与全局分支不同的是,它会首先会经过一个 stride 为 1 的 conv5 残差模块。这是因为局部特征分支中需要将输入的特征划分为多个的子区域进行单独地训练,而我们希望每一个子区域都能够包含足够的信息,因此,在这里我们去掉了原来 resnet50 中 conv5 模块的降采样操作,将这个模块的 stride 调为 1,以增加输出特征的尺寸,让其包含更多的信息。在局部分支中,我们同样采用了多任务学习的策略来对网络进行训练。从 conv5 模块中出来的特征会被分为两支,其中的检索分支与全局分支中的类似,在经过一个经过 256 维的 1×1 卷积以及相应的 BN 和 leaky ReLU 层,再经过 max pooling,最后输入到 KN-triplet loss 中进行训练;而对于另一个分类分支,我们首先将从 conv5 中出来的特征图从水平方向上均匀地切为若干个条形部分,然后每一部分都会经过一个与检索分支相同的 max pooling 层、256 维 1×1 卷积、BN 层以及 leaky ReLU 层,最后输入到 softmax loss 中进行训练。在这里,考虑到行人的每个区域享有不同的特征特点,所以我们并没有采用共享参数的设计,而是对于每一个分支,均采用不同的网络参数进行训练。

4) 损失函数:

从以上的介绍可以看出，整个网络结构上由局部分支和全局分支两大分支构成，并且由于采用了多任务的学习策略，每个分支又由两个不同的小分支组成。对于每一个小分支，都有损失函数来监督网络的训练，最终网络整体的损失函数由这些小分支的损失函数来共同组成。

具体来说，对于全局分支而言，其损失函数由分类损失的 softmax loss 和检索损失的 KN-triplet 共同组成，即：

$$L_{global} = L_{g_softmax} + L_{g_KNtriplet} \quad (4-1)$$

其中 L_{global} 表示全局分支的损失函数， $L_{g_softmax}$ 表示其中分类分支的损失函数， $L_{g_KNtriplet}$ 表示其中检索分支的损失函数。

同样的，对于局部分支，也由这两项组成，不过局部分支中的分类分支又由多个不同的平行分支构成，每一个平行部分均有单独的监督信号来监督网络的训练，所以它总体的损失函数如下：

$$L_{local} = \sum_{k=1}^N L_{l_softmax}^k + L_{l_KNtriplet} \quad (4-2)$$

其中 L_{local} 表示局部分支的损失函数， $L_{l_softmax}^k$ 表示其中第 k 个平行分支的损失函数， $L_{l_KNtriplet}$ 表示其中检索分支的损失函数。网络整体的损失函数则由全局分支与局部分支来共同组成：

$$L_{msn} = L_{global} + L_{local} \quad (4-3)$$

4.3 行人图像对齐及网络结构设计

4.3.1 思路来源

在上一小节中思路分析中，我们介绍了一种使用简单机械划分的方式来近似代替人体部位定位的方法，这个方法的思路主要来源于行人图像的强结构信息，它包含了一个非常重要的假设，即：对于大多数的行人图像而言，行人目标在图像中的分布是相对固定的，不同行人图像的相同区域往往对应了相同的人体部位。但是，当我们进一步观察行人重识别的数据集时，可以发现，这个假设有些时候并不成立。这是因为，对于 Market1501、MARS 之类规模较大的行人重识别数据集来说，在数据集制作的过程中使用人工的方式从视频中定位出行人目标的成本是非常大的，所以研究者们往往会使用目标检测模型来自动地定位出行人的位置。但是由于拍摄距离、角度、时刻的不同，行人目标在视频中所呈现的姿态和大小会

有较大的差异，再加上复杂背景的影响，会给检测算法带来一定的难度，所以有些时候，检测器并不能完美地定位出行人的位置，使检测框正好包含视频中的行人目标。因此，在这些检测器给出部分图像中，行人目标会出现在不同的区域，使得它们不满足我们之前给出的假设。我们在 Market1501 数据集中挑选了部分这样的图片，展示在图4-4中。



图 4-4 行人图像误对齐示意图

从这些图片中我们可以看到，部分行人在不同视角下的图像具有很大的差异：其中一些视角中，这些行人占据了图片的大部分区域，但是在另一些视角中，他们则位于图片的一些局部区域内。这就造成了行人重识别任务中另一个问题——行人的误对齐问题 (Misalignment problem)。

误对齐问题会给行人重识别模型造成一定的影响。一方面，行人误对齐所带来的图像分布差异性进一步增加了数据的复杂程度，所以在特征提取方面，要求网络除了具备较强的特征抽取能力之外，还需要其能够自适应地定位到行人区域，这给网络的训练造成了一定的难度；另一方面，它也给网络的特征映射过程带来了很大的难度，当我们度量行人的相似度时，我们希望所使用的特征每一个维度所对应的隐含的语义信息是一致的，但是当误对齐问题出现时，网络很难自适应地学习到一个有效的特征映射方式，来满足这一点。

除此之外，更为重要的一点是，误对齐问题破坏了行人图像的高度结构性，导致我们之前提出的假设在一些情况下并不成立，我们由此设计的网络结构也会因此失去其意义。具体来说，我们之前网络中所提出的局部分支中的每一个平行分支实际上都是一个行人判别器，我们希望它们仅通过行人图像的局部区域信息就能完成行人个体的判别。但是从图4-4中我们可以看到，若按照我们之前的划分方法对图像进行多条形切割，那么所得到的某些条形可能完全属于背景图像，不包含任何的行人信息，所以网络中一些平行分支在处理部分行人图像时，实际上是使用背景信息来判别行人个体，这相当于在网络的训练中加入了很多噪声样本，从而影响网络的训练。同时，在测试时，也可能因为这个原因导致网络对行人的误

判，从而降低整体的检测率。

因此，我们考虑将行人对齐的方案加入到我们的网络设计中。在网络的前端首先加入一个能够完成行人对齐功能的子网络，使其能够输出对齐后的行人图像，然后再将对齐的图像输入到我们的 MSN 网络中，使其能够进一步发挥它的功能。

4.3.2 空间变换网络

4.3.2.1 思路阐述

在上一小节的分析中，我们阐述了行人重识别中的误对齐问题，以及其对网络产生的影响。在本小节中，我们将介绍如何通过神经网络来解决这一问题。

在之前的一些行人重识别工作中，也提到了关于行人误对齐问题的解决方案。如 [43] 中，使用预训练的 Deeper Cut 网络^[65] 来对行人的 pose 关键点进行检测，然后利用这些关键点来定位出行人的不同部位，再使用一个多分支网络对这些不同部位进行分别训练，每个分支负责相同部位的识别，从而在一定程度上解决了误对齐问题；[41] 则将显著度 (attention) 机制加入到网络的设计中，在网络的后端加入了几个 attention 分支，每个 attention 分支通过一个 1×1 卷积来获取原特征图的 soft attention mask，通过端到端的训练，使得网络中的每一个 attention 分支能够自适应关注到不同行人的某一相同部位，从而完成对行人的对齐。

而在本文中，我们将采用一种更加简单的方式来完成行人图像的对齐工作。通过对图4-4的观察，我们发现，在这些行人定位较差的图像中，行人目标虽然大小不一且位于图像的不同区域，但是依然保留了非常强人体结构性。就是说当我们行人图像抠出并 resize 成目标尺寸，则新图像依然能够保证之前我们所提出的假设，图4-5展示了这一过程。所以我们如果能够通过一次行人目标的再定位来完成背景的滤除，将这些定位较差的图像转化成与定位较好的图像类似的、由行人占据大部分区域的图像，就可以完成行人的对齐工作。



图 4-5 行人对齐思路展示

而这里的难点在于，如何将这一定位与 **resize** 的过程融入到网络的设计中，使之能够与我们之前的 **MSN** 网络相结合，形成一种端到端的网络结构设计，并且能够一同训练。所幸的是，空间变换网络 (**Spatial Transformer Networks, STN**) 为我们提供了这一问题的实现方案。在接下来的小节中，我们将对这个网络结构及其实现方式进行详细的阐述。

4.3.2.2 网络结构

空间变换网络 (**Spatial Transformer Networks, STN**)^[66] 是 Google 的 Deepmind 团队在 2015 年的 CVPR 中提出的一种网络结构，它能够实现图像 (或特征图) 在网络内部的几何变换，并且通过一定的设计，使这种几何变换成为一个可导的过程，从而支持网络端到端的训练。

具体来说，空间变换网络由三大模块组成：定位网络 (**localisation network**)，网格生成器 (**grid generator**) 以及采样器 (**sampler**)，其结构如图4-6所示。




图 4-6 空间变换网络结构示意图

网络的工作方式如下：

当输入图像 $U \in \mathbb{R}^{W \times H \times C}$ 进入网络后，其首先会经过一个定位网络，该网络负责计算空间变换所需要的参数 θ ；然后经过网格生成器，它的主要功能是根据参数 θ 生成输出图像 $V \in \mathbb{R}^{W' \times H' \times C}$ 与输入图像 U 之间的像素点对应关系 T_θ ；最后经过一个采样器，它主要负责根据之前得到的对应关系 T_θ 从输入图像 U 中采样，形成输出图像 V 。

其中，定位网络就是用于输出参数 θ 的卷积神经网络，它由一些卷积神经网络的基础构建组成，这一部分我们已经在第二章进行了详细阐述，这里不再赘述。在接下来的小节中，我们将详细阐述网格生成器和采样器的工作原理及其实现方式。

4.3.2.3 网络生成器及仿射变换

理论上，空间变换网络可以实现任何形式的空间变换，这主要取决于定位网络所产生的参数以及网络生成器所使用的网格映射方式。这里将主要介绍在我们工作中所使用的变换方式——仿射变换。

仿射变换是数字图像处理中常用的一种图像几何变换方式，它可以实现图像的平移 (Translation)、旋转 (Rotation)、缩放 (Scale)、翻转 (Flip)、剪切 (Shear) 以及裁剪 (Crop) 等操作。具体来说它通过一个仿射变换矩阵，来完成二维坐标下目标图到原图点对点的线性映射。在空间变换网络中，该过程的公式可表述为：

$$\begin{pmatrix} x_i^s \\ y_i^s \end{pmatrix} = T_\theta(G_i) = A_\theta \begin{pmatrix} x_i^t \\ y_i^t \end{pmatrix} = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} \quad (4-4)$$

其中， (x_i^t, y_i^t) 为目标空间中的网格坐标； (x_i^s, y_i^s) 为原空间中的网格坐标； T_θ 表示网络生成器所使用的坐标点映射方式； G_i 表示输出图像的网格， $G_i = (x_i^t, y_i^t)$ ； A_θ 为仿射变换矩阵； $\theta_{11}, \theta_{12}, \dots, \theta_{23}$ 为仿射变换参数，其中 θ_{11}, θ_{22} 用来控制目标的缩放， θ_{21}, θ_{12} 用来控制目标的旋转， θ_{13}, θ_{23} 用来控制目标的平移。

对我们而言，仿射变换中最为重要的功能是它能够实现图像的裁剪，因此，我们可以用它来自适应地寻找行人图像中的行人区域，并将该部分裁选出来，形成一张新的行人图像。

4.3.2.4 采样器及双线性采样

实际上，空间变换网络在获得参数 A_θ 后，网络生成器就可以根据输出图像的坐标定位到其在原图的位置。但是这里存在一个问题：输出图像的坐标点 (x_i^t, y_i^t) 在经过式4-4运算后，得到的原图坐标点 (x_i^s, y_i^s) 不一定为整数，这样就无法直接使用原图的像素点进行迁移。网络中的采样器就是主要用来解决这一问题。

在 [66] 中，作者给出了采样的一般形式：

$$V_i^c = \sum_n^H \sum_m^W U_{nm}^c k(x_i^s - m; \Phi_x) k(y_i^s - n; \Phi_y) \quad \forall i \in [1 \dots H'W'], \forall c \in [1 \dots C] \quad (4-5)$$

其中 $k(\cdot)$ 表示采样核函数； Φ_x 和 Φ_y 表示核函数在 x 和 y 方向上所使用的参数； U_{nm}^c 表示输入图像上 (n, m, c) 处的像素值； V_i^c 表示在输出图像第 c 个通道 (channel) 上第 i 个像素点的像素值，即 (x_i^t, y_i^t) 处的像素值； W, H 分别表示出入图像的尺寸。

式4-5中的采样核函数 $k(\cdot)$ 可以采用任何可导的形式，其中最为常用的就是双

线性采样。当 $k(\cdot)$ 为双线性采样核函数时，式4-5可以被改写成为：

$$V_i^c = \sum_n^H \sum_m^W U_{nm}^c \max(0, 1 - |x_i^s - m|) \max(0, 1 - |y_i^s - n|) \quad \forall i \in [1 \dots H'W'], \forall c \in [1 \dots C] \quad (4-6)$$

式4-6具备可导性，它关于原图 U 和生成图坐标 x_i^s, y_i^s 的 p 偏导数为：

$$\frac{\partial V_i^c}{\partial U_{nm}^c} = \sum_n^H \sum_m^W \max(0, 1 - |x_i^s - m|) \max(0, 1 - |y_i^s - n|) \quad (4-7)$$

$$\frac{\partial V_i^c}{\partial x_i^s} = \sum_n^H \sum_m^W \max(0, 1 - |y_i^s - n|) \begin{cases} 0 & \text{if } |x_i^s - m| \geq 1 \\ 1 & \text{if } m \geq x_i^s \\ -1 & \text{if } m < x_i^s \end{cases} \quad (4-8)$$

$$\frac{\partial V_i^c}{\partial y_i^s} = \sum_n^H \sum_m^W \max(0, 1 - |x_i^s - m|) \begin{cases} 0 & \text{if } |y_i^s - n| \geq 1 \\ 1 & \text{if } n \geq y_i^s \\ -1 & \text{if } n < y_i^s \end{cases} \quad (4-9)$$

因此，整个空间变换网络可以被用作端到端的训练。

4.3.3 总体网络结构设计

在上一小节中，我们介绍了空间变换网络的基础结构及其实现过程，现在我们将其应用到行人重识别任务中，使用它来完成行人的对齐工作。我们将 STN 与上一节中的 MSN 网络融合起来，形成了一个整体的网络，网络结构如图4-7：




图 4-7 总体网络结构

该网络的前端由 STN 组成。在 STN 的设计中，我们使用了一个 Resnet34 来作

为它的定位网络，并去除了最后一个分类全连接层，将其改为一个 128 维的全连接层以及一个 6 维的全连接层，用以仿射变换所需要的参数。之后，我们利用该参数对输入的行人图像进行了仿射变换，然后将变换后的图像输入到 MSN 中，进行训练。所以在我们设计的网络中，STN 与 MSN 是一个端到端的系统，可以一同训练。

此外，在实验中我们发现，仅仅使用 MSN 的监督信号来对 STN 进行训练会出现行人定位不准确、仿射变换效果不佳等问题，为了能够让 STN 网络能够更加准确地定位行人，我们在 STN 的设计中还加入了行人分类的监督信号，在输出特征后接出一个 512 维的全连接层，使用该层后的特征对行人进行分类。网络最终的损失函数由 STN 与 MSN 网络的损失共同组成：

$$L_{all} = L_{msn} + L_{stn} \quad (4-10)$$

4.4 实验结果及分析

在本小节中，我们将用实验结果来验证前文中提出的网络结构的有效性。首先我们将从局部分支的设计入手，探究将行人图像分成不同条数时，网络的性能；然后我们将分别对全局分支和局部分支以及它们融合后的性能进行测试，以两条分支在网络中所起的作用；最后，我们将探究 STN 网络的作用，以说明融入 STN 模块后网络性能带来的提升。

4.4.1 实验配置与参数

本章中采用的配置与参数与第三章中的相同。使用的基础模型为在 Imagenet 上预训练的 Resnet50 模型，使用的数据集仍然为 Market1501。

4.4.2 不同分支数目对局部分支的影响

在前文的网络结构介绍中，我们将局部分支的输入分为了多个条形区域，然后由设计了多分支的网络对每一个条形区域进行训练。但是，这里具体的条形数目是不确定的，这取决于数据集的特点。所以为了探究最优的网络结构设计，我们首先对局部分支内的分支数目进行了探究。

由于在我们设计的 MSN 网络中，仅局部分支的分类分支包含了这种多条形的网络结构，为了简化实验过程，我们仅适用这一部分探究不同行人图像分割的局部区域数目对网络性能的影响。我们分别对分割条数 $p = 1, 2, 4, 6, 8, 12$ 的情况进行了实验，实验结果如表4-1所示。

表 4-1 分割局部区域数目对网络的影响

分割局部区域数目 p	rank1 准确率 (%)	mAP(%)
1	83.9	67.5
2	87.5	71.1
4	90.9	74.5
6	91.4	76.8
8	90.5	74.2
12	88.9	72.4

从上述结果中我们可以看出，当分割的区域数目上升时，模型的检索 rank1 准确率先上升后下降，这种趋势具有其合理性：当分割数较少时，模型所获取的行人特征接近全局特征，全局特征是一种粗粒度的行人描述，能够很好地找到具有判别力的局部区域，导致模型性能下降；在分割数逐渐上升时，每一个局部区域所包含的行人信息将逐渐变少，在分割数达到一定量后，每个局部区域所包含的行人信息将不足以判别一个行人个体，导致网络非常容易出现过拟合的问题，所以整体性能有所下降。

表4-1的实验结果显示，在分支数 $p = 6$ 时模型的检索准确率将达到最高，所以在后续的实验中，我们将其作为模型的默认设置，进行其他的实验。

4.4.3 MSN 网络各模块性能探究

在 MSN 网络的设计中，我们为了充分利用行人各种尺度特征的优点，所以在网络中同时加入了全局分支与局部分支，其中全局分支提取行人的全局特征，用来对行人的整体外貌进行描述；局部分支提取局部特征，用来描述行人具有判别力的局部区域。两者在理论上分工不同，且具备互补性。在本小节中，我们就将使用实验来分别验证网络两条分支的性能，以及它们的互补性。

在实验中，我们首先去掉了网络的全局分支，并对局部分支的分类及检索两个分支的效果进行了验证；然后使用相同的方法来验证全局分支的性能；最后将两者进行融合，用完整的模型进行实验。实验效果如表4-2所示。

表 4-2 网络中不同分支的实验结果

分支网络	rank1 准确率 (%)	mAP(%)
global_cls	83.3	65.8
global_cls+ret	89.1	72.4
local_cls	91.4	76.8
local_cls+ret	91.8	78.8
global_all+local_all	92.5	81.7

其中, *local* 表示局部分支, *global* 表示全局分支, *cls* 表示各分支中的分类子分支, *ret* 表示搜索子分支。从表4-2的结果可以看出:

(1) 相较于全局分支, 局部分支能够较大幅度地提升对行人检索的成功率, 说明局部特征相较于全局特征更能够关注到行人具有判别力的区域, 这非常好地验证了局部特征的有效性。

(2) 我们可以发现无论对于全局分支还是对于局部分支, 加入检索损失函数 *KN-triplet loss* 后, 网络的性能均有提升, 此外, 在网络训练的过程中, 我们发现加入 *KN-triplet loss* 能够帮助网络更快地收敛, 这很好地验证了我们在第三章中所提出的多任务学习的思想。

(3) 尽管全局分支的性能较局部分支而言较差, 但当将其与局部分支进行融合后, 网络整体的性能得到了提升, 这说明行人的全局特征与局部特征具备一定的互补性, 验证了多尺度特征融合的有效性。

上述实验结果表明, 我们根据行人图像结构特点设计的局部分支具备其合理性, 此外, 我们采用的这种“全局 + 局部”的多尺度特征融合网络结构能够进一步提升网络的性能。

此外, 我们对不同分支的实时性进行了实验, 分别测试了各分支在训练及测试阶段提取特征时每秒所能处理的图像数目。实验结果展示在表4-3中。

表 4-3 网络中不同分支的实验结果

分支网络	训练图片处理速度 (<i>pics/s</i>)	测试图片处理速度 (<i>pics/s</i>)
<i>global_cls</i>	4.20	73.55
<i>global_cls+ret</i>	3.92	72.52
<i>local_cls</i>	3.39	64.08
<i>local_cls+ret</i>	3.17	62.78
<i>global_all+local_all</i>	2.7	50.97

从上述实验结果可以看出, 在训练阶段, 由于需要进行复杂的 *loss* 计算, 所以网络对图像处理的速度并不快; 而在测试阶段, 网络每秒能够处理的帧数大幅度上升, 约为训练阶段的 20 倍左右。对于测试阶段而言, 局部分支由于需要同时处理多个局部切片的信息, 所以在速度上略低于全局分支; 对于局部与全局分支而言, 加入多任务学习策略基本不影响网络的速度; 当融合局部分支与全局分支后, 网络的速度有所下降, 相较于最简单的全局分支而言, 速度越降为其 0.7 倍, 但是其每秒依然能够处理近 51 帧的行人图像, 能够很好地满足实时性的要求。

4.4.4 STN 网络的作用

前几个小节的实验结果验证了我们设计的 MSN 网络所取得的效果，但是在我们的网络的设计中，还有一个非常关键的组成成分：用于行人图像对齐的 STN 网络，在本小节中，我们将验证 STN 网络的性能。

在实验中，我们采用了 Resnet32 来作为 STN 网络中的定位网络，另外在网络开始训练中，我们将 STN 的用于输出参数的最后一层全连接层的权重置零，并且将 6 个神经单元的偏置置为 (1,0,0,0,1,0)，即使得 STN 网络的输出初始化为：

$$\theta = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \quad (4-11)$$

这样做的目的是将由 STN 网络采样的图片初始化为原图，以原图为起点来进行迭代训练，能够保证后端 MSN 网络的训练效果，并且能够使网络更快收敛。

我们分别在仅有分类损失的网络以及我们所提出的 MSN 网络前端加入了 STN 网络，来验证它的效果。实验结果如表4-4所示。

表 4-4 STN 网络的实验结果

分支网络	rank1 准确率 (%)	mAP(%)
softmax	83.3	65.8
softmax+STN	84.5	67.3
MSN	92.5	81.7
MSN+STN	92.9	82.6

从表4-4的结果中可以看出，无论对于较为简单的全局特征分类网络还是我们的多分支 MSN 网络，加入 STN 后，网络的性能均能够得到提升。而且值得一提的是，由于我们的网络本身就能够得到较高的性能，但是在加入 STN 后取得了与分类网络类似的提升，这说明 STN 所带来的行人对齐效果与我们网络的协同性更高。

此外，我们对 STN 网络得到的图像进行了可视化处理，结果如图4-8所示。我们对其中具有代表性的输出结果使用绿框进行了标注，可以看到，这些只占据图像部分区域的误对齐行人图像在经过处理后，基本切除了背景部分，从而完成了与其他行人图像的对齐，该变换结果基本达到了我们的预期效果，验证了 STN 网络的有效性。



图 4-8 STN 网络图像变换可视化

4.4.5 与其他方法的对比

我们使用我们的方法与 2017 年来计算机视觉领域各大定会中其他的行人重识别模型进行了比较, 比较的结果被展示在表 4-5 中。可以看到, 我们的模型在效

表 4-5 与其他工作的结果对比

模型	rank1 准确率 (%)	mAP(%)
Spindle(CVPR2017) ^[42]	76.9	-
Part-Aligned(ICCV2017) ^[41]	81.0	63.4
SVDNet(ICCV2017) ^[1]	82.3	62.1
PDC(ICCV2017) ^[63]	84.1	63.4
JLML(IJCAI2017) ^[67]	85.1	65.5
GLAD(MM2017) ^[43]	89.9	73.9
DeepPerson(arXiv2017) ^[68]	92.3	79.6
AlignedReID(arXiv2017) ^[69]	92.6	82.3
ours(MSN+STN)	92.9	82.6

果上超越了 2017 年顶会中的绝大部分工作, 相较于较早期的 2017 年 CVPR 中的 Spindle Net, 我们的模型在 rank1 准确率上得到了 15% 的巨幅提升; 而相较于较晚的 AlignedReID 方法, 在 rank1 上也有约 0.3% 的小幅领先。这验证了我们的模型在行人重识别任务中的有效性。

4.5 本章小结

在本章中, 我们首先对行人数据集中的图像特点进行了分析, 认为行人图像

具备高度的结构性，在此基础上，我们提出了具有针对性的多分支网络结构 **MSN**，用来提取行人图像的局部特征，并详细介绍了网络各个分支的结构；之后，我们进一步分析了上述模型存在的问题，阐述了行人图像的误对齐情况对模型的影响，并提出使用空间变换网络来解决行人误对齐的问题；最后，我们将空间变换网络与之前的特征提取网络 **MSN** 相互融合，形成一个端到端的系统。在实验阶段，我们首先对 **MSN** 中各模块的性能进行了验证；然后我们验证了加入 **STN** 后对网络性能的影响，并且展示了由网络所学习到的对齐行人图像。

结 论

公共安全问题一直以来都是一个备受关注的话题，城市视频监控作为违法犯罪行为的重要取证手段，在案件侦破中起到了至关重要的作用，目标人物的识别与追踪则是这一过程的必要前提。近年来，监控摄像头的日益普及带来了监控数据的爆炸式增长，使得低效的人工监察方法所带来的成本日益增加，并有可能因此错过案件侦破的关键信息。所以使用机器快速准确地定位目标行人在近年来成为一种迫切的需求。本文就行人重识别问题展开研究，并通过深度学习算法的设计来完成行人的准确、快速检索。

相较于传统的检索任务，行人重识别具有类内差异更大而类间差异更小的特点，针对这一困难，本文就该任务中最为主要的两个的问题展开探究，即度量学习以及特征提取。在度量学习上，本文着重探究了不同损失函数及多任务学习策略在行人重识别任务上的表现；而在特征提取上，本文着重探究了针对行人特征的多尺度融合网络结构设计。主要研究工作总结如下：

在对度量学习方法的研究中：(1) 在分析传统分类及检索模型的优劣性的基础上，根据行人重识别任务的特点，提出了使用网络进行分类与检索任务协同学习的多任务学习策略；(2) 完成了对目前已有的各类分类及检索损失函数的理论层面的探究，并着重分析了其可被用于解决行人重识别任务的可行性；(3) 使用本文所提出的多任务学习的网络结构对各损失函数的组合性能进行了进一步探究，通过在 Market1501 数据集上的实验效果完成了对损失组合性能的验证工作，得到了最优的损失组合项，为后续特征网络结构的设计打下基础。

在对特征提取方法的研究中：(1) 分析了局部特征在行人重识别任务中的优势，并由此提出了加入局部特征提取的网络设计策略；(2) 根据行人图像的高度结构性的特点，提出了相应的多尺度融合特征提取网络 MSN，该网络结构具有能够同时提取行人局部特征及全局特征的特点；(3) 分析了行人重识别任务中可能存在的误对齐问题，并提出了相应的解决方案——空间变换网络；(4) 将 MSN 与 STN 网络相融合，完成了网络端到端的设计；(5) 通过在 Market1501 上的实验验证了所设计的网络的在准确率上的优势。

综上，在本文中，我们完成了行人重识别问题两大关键问题的探究，并且将两者融入到一个模型的设计中，完成了综合的、一体化的行人重识别系统设计。

参考文献

- [1] Gong S, Cristani M, Yan S, et al. Person re-identification[M]. [S.l.] : Springer, 2014.
- [2] Cai Q, Aggarwal J K. Tracking human motion using multiple cameras[C] // Pattern Recognition, 1996., Proceedings of the 13th International Conference on : Vol 3. 1996 : 68 – 72.
- [3] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance[C] // Computer Vision and Pattern Recognition, 2006 IEEE Computer Society Conference on : Vol 2. 2006 : 1528 – 1535.
- [4] Gray D, Brennan S, Tao H. Evaluating appearance models for recognition, reacquisition, and tracking[C] // Proc. IEEE International Workshop on Performance Evaluation for Tracking and Surveillance (PETS) : Vol 3. 2007 : 1 – 7.
- [5] Farenzena M, Bazzani L, Perina A, et al. Person re-identification by symmetry-driven accumulation of local features[C] // Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on. 2010 : 2360 – 2367.
- [6] Gray D, Tao H. Viewpoint invariant pedestrian recognition with an ensemble of localized features[C] // European conference on computer vision. 2008 : 262 – 275.
- [7] Mignon A, Jurie F. Pcca: A new approach for distance learning from sparse pairwise constraints[C] // Computer Vision and Pattern Recognition (CVPR), 2012 IEEE Conference on. 2012 : 2666 – 2672.
- [8] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification[C] // Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on. 2013 : 3586 – 3593.
- [9] Zhao R, Ouyang W, Wang X. Person re-identification by salience matching[C] // Computer Vision (ICCV), 2013 IEEE International Conference on. 2013 : 2528 – 2535.
- [10] Zhao R, Ouyang W, Wang X. Learning mid-level filters for person re-identification[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014 : 144 – 151.

- [11] Yang Y, Yang J, Yan J, et al. Salient color names for person re-identification[C] //European conference on computer vision. 2014 : 536–551.
- [12] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015 : 2197–2206.
- [13] Liao S, Zhao G, Kellokumpu V, et al. Modeling pixel process with scale invariant local patterns for background subtraction in complex scenes[C] //Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on. 2010 : 1301–1306.
- [14] Zhang L, Xiang T, Gong S. Learning a discriminative null space for person re-identification[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 1239–1248.
- [15] Zhang Y, Li B, Lu H, et al. Sample-specific svm learning for person re-identification[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 1278–1287.
- [16] Matsukawa T, Okabe T, Suzuki E, et al. Hierarchical gaussian descriptor for person re-identification[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 1363–1372.
- [17] Layne R, Hospedales T M, Gong S, et al. Person re-identification by attributes.[C] //Bmvc : Vol 2. 2012 : 8.
- [18] Liu X, Song M, Zhao Q, et al. Attribute-restricted latent topic model for person re-identification[J]. Pattern recognition, 2012, 45(12) : 4204–4213.
- [19] Liu C, Gong S, Loy C C, et al. Person re-identification: What features are important?[C] //European Conference on Computer Vision. 2012 : 391–401.
- [20] Su C, Yang F, Zhang S, et al. Multi-task learning with low rank attribute embedding for multi-camera person re-identification[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 40(5) : 1167–1181.
- [21] Shi Z, Hospedales T M, Xiang T. Transferring a semantic representation for person re-identification and search[C] //Computer Vision and Pattern Recognition (CVPR), 2015 IEEE Conference on. 2015 : 4184–4193.
- [22] Li D, Zhang Z, Chen X, et al. A richly annotated dataset for pedestrian attribute recognition[J]. arXiv preprint arXiv:1603.07054, 2016.

- [23] Xing E P, Jordan M I, Russell S J, et al. Distance metric learning with application to clustering with side-information[C] // Advances in neural information processing systems. 2003 : 521 – 528.
- [24] Weinberger K Q, Saul L K. Distance metric learning for large margin nearest neighbor classification[J]. Journal of Machine Learning Research, 2009, 10(Feb) : 207 – 244.
- [25] Davis J V, Kulis B, Jain P, et al. Information-theoretic metric learning[C] // Proceedings of the 24th international conference on Machine learning. 2007 : 209 – 216.
- [26] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C] // Computer Vision and Pattern Recognition (CVPR), 2012 IEEE Conference on. 2012 : 2288 – 2295.
- [27] Chen D, Yuan Z, Hua G, et al. Similarity learning on an explicit polynomial kernel feature map for person re-identification[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015 : 1565 – 1573.
- [28] Yang Y, Liao S, Lei Z, et al. Large Scale Similarity Learning Using Similar Pairs for Person Verification.[C] // AAAI. 2016 : 3655 – 3661.
- [29] Li W, Zhao R, Xiao T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014 : 152 – 159.
- [30] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015 : 3908 – 3916.
- [31] Subramaniam A, Chatterjee M, Mittal A. Deep neural networks with inexact matching for person re-identification[C] // Advances in Neural Information Processing Systems. 2016 : 2667 – 2675.
- [32] Cheng D, Gong Y, Zhou S, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 1335 – 1344.
- [33] Chen W, Chen X, Zhang J, et al. A Multi-Task Deep Network for Person Re-Identification.[C] // AAAI: Vol 1. 2017 : 3.

- [34] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C] // Proc. CVPR : Vol 2. 2017.
- [35] Zheng L, Bie Z, Sun Y, et al. Mars: A video benchmark for large-scale person re-identification[C] // European Conference on Computer Vision. 2016 : 868 – 884.
- [36] Zheng L, Zhang H, Sun S, et al. Person re-identification in the wild[J]. arXiv preprint, 2017.
- [37] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [38] Xiao Q, Luo H, Zhang C. Margin Sample Mining Loss: A Deep Learning Based Method for Person Re-identification[J]. arXiv preprint arXiv:1710.00478, 2017.
- [39] Wu L, Shen C, Hengel A v d. Personnet: Person re-identification with deep convolutional neural networks[J]. arXiv preprint arXiv:1601.07255, 2016.
- [40] Varior R R, Haloi M, Wang G. Gated siamese convolutional neural network architecture for human re-identification[C] // European Conference on Computer Vision. 2016 : 791 – 808.
- [41] Zhao L, Li X, Zhuang Y, et al. Deeply-learned part-aligned representations for person re-identification[C] // in Proc. IEEE Int. Conf. Comput. Vis.(ICCV). 2017.
- [42] Zhao H, Tian M, Sun S, et al. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017 : 1077 – 1085.
- [43] Wei L, Zhang S, Yao H, et al. Glad: Global-local-alignment descriptor for pedestrian retrieval[C] // Proceedings of the 2017 ACM on Multimedia Conference. 2017 : 420 – 428.
- [44] Zheng Z, Zheng L, Yang Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[J]. arXiv preprint arXiv:1701.07717, 2017, 3.
- [45] Qian X, Fu Y, Wang W, et al. Pose-Normalized Image Generation for Person Re-identification[J]. arXiv preprint arXiv:1712.02225, 2017.
- [46] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 160(1): 106 – 154.

- [47] Fukushima K, Miyake S. Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition[G] // Competition and cooperation in neural nets. [S.l.] : Springer, 1982 : 267 – 285.
- [48] LeCun Y, Boser B E, Denker J S, et al. Handwritten digit recognition with a back-propagation network[C] // Advances in neural information processing systems. 1990 : 396 – 404.
- [49] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088) : 533.
- [50] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C] // Advances in neural information processing systems. 2012 : 1097 – 1105.
- [51] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2016 : 770 – 778.
- [52] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C] // European conference on computer vision. 2014 : 818 – 833.
- [53] Ishai A, Ungerleider L G, Martin A, et al. Distributed representation of objects in the human ventral visual pathway[J]. Proceedings of the National Academy of Sciences, 1999, 96(16) : 9379 – 9384.
- [54] Ungerleider L G, Haxby J V. ‘What’ and ‘where’ in the human brain[J]. Current opinion in neurobiology, 1994, 4(2) : 157 – 165.
- [55] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [56] Li W, Zhao R, Wang X. Human reidentification with transferred metric learning[C] // Asian Conference on Computer Vision. 2012 : 31 – 44.
- [57] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C] // Proceedings of the IEEE International Conference on Computer Vision. 2015 : 1116 – 1124.
- [58] Wang F, Xiang X, Cheng J, et al. NormFace: L_2 Hypersphere Embedding for Face Verification[J]. arXiv preprint arXiv:1704.06369, 2017.

- [59] Liu W, Wen Y, Yu Z, et al. Sphereface: Deep hypersphere embedding for face recognition[C] // The IEEE Conference on Computer Vision and Pattern Recognition (CVPR) : Vol 1. 2017.
- [60] Wang F, Liu W, Liu H, et al. Additive Margin Softmax for Face Verification[J]. arXiv preprint arXiv:1801.05599, 2018.
- [61] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2015 : 815 – 823.
- [62] Zheng Z, Zheng L, Yang Y. A Discriminatively Learned CNN Embedding for Person Reidentification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2017, 14(1) : 13.
- [63] Su C, Li J, Zhang S, et al. Pose-driven Deep Convolutional Model for Person Re-identification[C] // 2017 IEEE International Conference on Computer Vision (ICCV). 2017 : 3980 – 3989.
- [64] Yao H, Zhang S, Zhang Y, et al. Deep representation learning with part loss for person re-identification[J]. arXiv preprint arXiv:1707.00798, 2017.
- [65] Insafutdinov E, Pishchulin L, Andres B, et al. Deepcut: A deeper, stronger, and faster multi-person pose estimation model[C] // European Conference on Computer Vision. 2016 : 34 – 50.
- [66] Jaderberg M, Simonyan K, Zisserman A, et al. Spatial transformer networks[C] // Advances in neural information processing systems. 2015 : 2017 – 2025.
- [67] Li W, Zhu X, Gong S. Person re-identification by deep joint learning of multi-loss classification[J]. arXiv preprint arXiv:1705.04724, 2017.
- [68] Bai X, Yang M, Huang T, et al. Deep-Person: Learning Discriminative Deep Features for Person Re-Identification[J]. arXiv preprint arXiv:1711.10658, 2017.
- [69] Zhang X, Luo H, Fan X, et al. Alignedreid: Surpassing human-level performance in person re-identification[J]. arXiv preprint arXiv:1711.08184, 2017.

攻读硕士学位期间发表的论文及其他成果

致 谢

时光荏苒，在哈工大两年的硕士生涯转瞬间就要接近尾声，这两年哈工大生活让我成长了很多，在这里，我要对我在这里遇到的每一位同学和老师表示衷心的感谢。

首先，我要感谢我的导师姚鸿勋教授。刚进入实验室时，我还是一个从外系转来的学生，在专业知识、科研方法上均有很大的不足，您是我科研道路上的引路人，带我一步步走上科研的这条道路。两年来，您渊博的科研知识和严谨的治学态度无时无刻不在影响着我。我要感谢您一直以来对我的严格要求，在我懈怠时为我敲响警钟，让我明确道路，砥砺前行；我要感谢您在这两年里对我孜孜不倦的教导与鼓励，在我遇到困惑时为我指明方向，在我科研的道路上为我解答疑惑；我也要感谢您对我的包容，在我犯错时您总是能为我明确指出错误，但又不会严厉地批评。在这两年里，我经常很晚还能在实验室看到您的身影，您对科研勤奋的态度让我由衷地敬佩。尽管我即将离开工大，但是您为树立的榜样我会铭记于心，在未来的人生道路上，时时刻刻激励自己。

然后，我要感谢实验室的老师，感谢赵德斌老师、刘岩老师、姜峰老师、刘绍辉老师，为实验室日常生活中给我带来的帮助。也感谢你们严谨的教学态度，让我从你们的课程中学到了很多宝贵的理论知识。另外，我想要特别感谢我们实验室的孙晓帅老师，您在实验室的日常交流和组会中，总是和蔼可亲给我提出的科研工作上的宝贵建议，此外，作为您的邻座，我能够深深感受到您日常工作中严谨勤奋的工作态度，这也深深影响这我，让我懂得督促自己努力学习。

另外，我还要感谢实验室和我朝夕相处的师兄师姐学弟学妹们，感谢姜小磊、张严浩、于伟、卢修生、姜雪松、庞程、王栋、韩婷婷、王雅思、郑影、谢文龙、李浩然、侯雨欣、刘帝麟、夏雨、刘亚田、熊振仑、张军磊、林闯。你们在平常组会的讨论中给我提出了很多宝贵的意见和建议，也是因为你们的存在，让我觉得在实验室的日子非常温暖和有趣。

我要单独感谢与我同届的几位同学，周尚辰、唐文博、金声、隋海波、武兴隆。感谢你们在这两年来对我的帮助和鼓励。你们是我这两年来最好的朋友和伙伴，和你们在一起深夜攀谈、探讨科研问题、参加数据竞赛以及出行游玩的时光，是我这两年来最为宝贵的回忆。而如今，你们也将步入人生新的台阶，在这里衷心的祝福你们前程似锦！

最后，我要感谢我的父母和家人，是你们在背后默默无闻的支持与鼓励让我有勇气坚持我的求学之路。当在我的人生道路上遇到挫折时，你们是我最为坚实的后盾。也感谢你们二十多年来对我不求回报的养育之恩，教导我做人做事的道理，这些宝贵的财富将伴随我一生。