

江南大学

硕 士 学 位 论 文

题 目: 融合局部特征的深度学习行人重识别方法研究

英文并列题目: Research on Person Re-identification
with Local Features Fusion Based on Deep Learning

研 究 生: 陈 璠

专 业: 控制科学与工程

研 究 方 向: 模式识别与智能系统

导 师: 彭 力 教授

指导小组成员: 彭 力 教授

学位授予日期: 2021 年 12 月

答辩委员会主席: 黄 敏

江 南 大 学

地址: 无锡市蠡湖大道 1800 号

二〇二一 年 十二 月

摘 要

行人重识别技术是智能安防、目标追踪等领域的重要基础，是构建平安智慧城市的重要一环。由于监控摄像头部署位置的差异，使行人图像存在姿态差异化、光线照度易变化、拍摄角度多样化等情况，导致行人识别可用信息较少，从而难以满足行人重识别对于准确度高要求。因此，如何高效地定位并组织图像的局部特征信息，提高现有的行人重识别网络的准确度具有很高的研究价值。近些年来，基于特征空间分割的 PCB (Part-based Convolutional Baseline) 结构网络由于对图像遮挡或姿态变化的良好的鲁棒性获得了较大的关注。然而，该类算法在行人重识别任务中准确性偏低，因此具有较大的提升空间。本文基于该类算法从不同方面进行了改进，主要研究内容如下：

(1) 针对基于局部特征的行人重识别方法在提取行人特征时因信息缺失导致鲁棒性和判别力不足的问题，提出了一种多层级重叠条纹特征融合的行人重识别方法。首先，设计了重叠条纹特征提取模块，弥补了提取行人局部特征时缺失的关键信息。其次，采取分层特征融合的方式，将深度网络的浅层特征与深层特征相结合，使网络模型更有效地区分细节信息。然后，设计了组归一化模块，消除了不同损失函数在优化方向上存在的差异，进而促使网络模型提取到更恰当的共享特征，使网络模型学习到更多难例样本的有效信息。最后，在 Market-1501 和 DukeMTMC-reID 这两个数据集上进行了实验验证，结果表明所提算法可以充分利用行人的特征信息，并提高识别的准确度。

(2) 针对采用多分支结构的行人重识别模型在提取行人特征时缺乏异构特征的问题，提出了一种异构分支关联特征融合的行人重识别方法。首先，将 OSNet 与注意力机制相结合作为主干共享卷积网络，扩大了不同通道的权重差距，提高了网络模型学习显著性和区分性更强的特征的能力。其次，构建了条纹特征关联模块，在弥补缺失信息的同时加强了行人身体各部位的联系。然后，设计了异构特征提取模块，增加了模型学习差异特征所需的结构多样性，并通过使用单一 ID 损失函数，提高了模型的分类预测能力。最后，所提算法在 Market-1501 和 DukeMTMC-reID 数据集上进行了实验验证，结果表明所提算法可以有效地减少无关特征的干扰，提升对行人特征的判别力。

(3) 针对采用空间分区的行人重识别模型在提取行人特征时易忽略纵向语义信息的问题，提出了一种融合多分区特征的行人重识别方法。首先，构建了高激活擦除模块，剔除最受网络关注的区域，提高了网络模型对低关注度区域中高判别力特征的学习能力。其次，设计了金字塔空间分区模块，综合不同尺度的多粒度局部特征，在充分学习行人局部信息的同时保证行人特征的完整性。然后，设计了信道分区模块，与金字塔空间分区模块互补，突出了语义概念的重要性，进而提高模型学习小区域丰富语义信息的能力。最后，所提算法在 Market-1501、DukeMTMC-reID 和 CUHK03 数据集上进行了实验验证，结果表明所提算法可以关注到行人更精细的特征，能有效减小模型的误检率。

关键词：行人重识别；卷积神经网络；特征融合；重叠条纹特征；条纹特征关联；异构特征；信道信息

Abstract

Person re-identification (Person Re-ID) technology is an important foundation for intelligent security and target tracking, and plays a significant role in safe and smart city. Due to the differences in the deployment positions of surveillance cameras, some problems in pedestrian images such as different pedestrian posture, variation of illumination and diverse shooting angles are presented. These difficulties result in that less person information are available, which make Person Re-ID still a very challenging task. Therefore, how to design an algorithm that captures and organizes the local features of images efficiently, and improve the accuracy of Person Re-ID network, has important research value. Recently, due to the strong robustness for Image occlusion and posture change, the PCB (Part-based Convolutional Baseline) network has drawn considerable attention. However, the accuracy of the algorithm in Person Re-ID task is still low, which means it has a lot of room for improvement. This paper improves this algorithm from different aspects, and the main research contents are as follows.

(1) Most of the local features based Person Re-ID methods met the problem of the lack of robustness and discriminability due to the distortion of information in the procedure of extraction of pedestrian features. A novel Re-ID algorithm based on multi-level feature fusion with overlapping stripes is proposed. Firstly, the features with overlapping stripes are extracted to compensate the loss of information. Secondly, the hierarchical feature fusion strategy is adopted, which integrates the deep and shallow features of the target, to make the network model distinguish the detailed information more effectively. In addition, group normalization modules are designed to reduce the optimization differences within various loss functions for obtaining appropriate shared features. Finally, the experimental results on the Market-1501 and DukeMTMC-reID datasets show that the proposed algorithm can make full use of the person features, and improve the accuracy.

(2) Most of the multi-branch network based Person Re-ID methods met the problem of the lack of the heterogeneous features in the procedure of extraction of pedestrian features. A novel Re-ID algorithm based on heterogeneous branch correlative features fusion is proposed. Firstly, the attention-based OSNet is designed as the backbone sharing network, which increases the weight gap of different channels and extracts more significant and distinguished key features. Secondly, the stripe features correlation module is developed, which compensates the loss of information while enhances the relatedness of the parts of the body. In addition, the heterogeneous features extraction module is designed to increase the structural diversity of the model for learning difference features. The single ID prediction loss is proposed to improve the classification and prediction ability of the model. Finally, the experimental results on the Market-1501 and DukeMTMC-reID datasets show that the proposed algorithm can effectively reduce the interference of irrelevant features, and improve the discriminative ability of features.

(3) Most of the spatial partition based Person Re-ID methods met the problem of the lack of the longitudinal semantic information in the procedure of extraction of pedestrian features. A novel Re-ID algorithm based on multi-partition features fusion is introduced. Firstly, the highly active drop module is proposed, which create a mask to cover the most activated regions.

The learning ability of the model for the features with high discrimination in activated regions is improved. Secondly, the pyramid spatial partition module is designed to integrate the local features of different granularity, which helps to learn the person local features efficiently while keep the completeness. In addition, the channel partition module is developed and complementary with pyramid spatial partition module, which highlights the importance of semantic concepts and improves the learning ability for the features with a wealth of semantic information in local regions. Finally, the proposed algorithm is experimentally verified on the Market-1501 and DukeMTMC-reID datasets, and the results show that the algorithm could extract the more detailed features, and reduce the false matching rate efficiently.

Keywords: Person re-identification; Convolutional neural network; Feature fusion; Feature with overlapping stripes; Stripe feature correlation; Heterogeneous features; Channel information

目 录

摘 要	I
Abstract	II
第一章 绪论	1
1.1 课题研究背景及意义	1
1.2 国内外研究现状	2
1.3 行人重识别面临的挑战	4
1.4 论文的研究内容及结构安排	6
第二章 基于特征空间分割的行人重识别相关理论	9
2.1 行人重识别定义与实例	9
2.2 行人重识别基准	9
2.2.1 卷积神经网络	10
2.2.2 基准网络结构	13
2.2.3 常用网络约束	14
2.3 基于特征空间分割的行人重识别算法流程	14
2.3.1 行人重识别流程	15
2.3.2 训练细节	15
2.4 行人重识别常用数据集及评估指标	18
2.4.1 评价指标	18
2.4.2 数据集介绍	20
2.5 本章小结	21
第三章 多层次重叠条纹特征融合的行人重识别	23
3.1 引言	23
3.2 模型设计	24
3.2.1 特征空间分割特性分析	24
3.2.2 网络架构	25
3.2.3 重叠条纹特征提取模块	26
3.2.4 多损失函数优化	28
3.2.5 组归一化模块	29
3.3 实验结果及分析	30
3.3.1 数据集与评估指标	30
3.3.2 实验配置及参数	31
3.3.3 实验分析	31
3.3.4 不同基准网络下的方法比较	33
3.3.5 与现有方法的比较	35
3.4 本章小结	37
第四章 异构分支关联特征融合的行人重识别	39

4.1 引言	39
4.2 模型设计	39
4.2.1 网络总体结构	39
4.2.2 条纹特征关联模块	40
4.2.3 异构特征提取模块	42
4.2.4 注意力模块	43
4.2.5 损失函数	46
4.3 实验结果与分析	47
4.3.1 实验参数设置	48
4.3.2 实验分析	48
4.3.3 关联特征提取模块的有效性	50
4.3.4 检索排序图	51
4.3.5 与现有方法的比较	53
4.4 本章小结	53
第五章 融合多分区特征的行人重识别	55
5.1 引言	55
5.2 融合多分区特征的行人重识别	55
5.2.1 空间分区与信道分区特性分析	55
5.2.2 多分区特征提取模块	56
5.2.3 网络结构与约束	59
5.3 实验结果及分析	61
5.3.1 实验参数设置	61
5.3.2 实验分析	61
5.3.3 方法对比	64
5.4 本章小结	65
第六章 主要结论与展望	67
6.1 主要结论	67
6.2 展望	68
致谢	69
参考文献	70
附录: 作者在攻读硕士学位期间发表的论文	75

第一章 绪论

1.1 课题研究背景及意义

5G 时代下物联网和监控视频的快速发展，为“智慧互联城市”和“平安和谐城市”的建设提供了强有力的技术支撑。为了加强城市安全建设，各级政府部门积极地采取措施，已在我国建成世界上最大的视频监控网，其中共享互联互通的监控设备已经高达数十万部。安全监管部门需要对城市中人流密集场所如地铁站、中央街道和医院等重点区域进行严密监控，并自主分析 24 小时内产生的海量视频数据，从中挖掘有用且关键的信息，从而及时地预警和处理异常情况。

随着图像和视频等多媒体信息的日益激增，以往仅依靠人工对比的目标跨区域监察和追踪的弊端日渐凸显：一是投入的人力成本高且易出错。当目标行人在一个摄像头的覆盖范围内消失后，那么他的行进轨迹也随之消失，难以预测该行人会再次出现在哪个摄像头视野中，查看并分析庞杂的视频数据需要耗费巨大的人力资源和时间成本，容易引起身体和精神的双重疲劳，导致错失线索或判断失误。二是事后查看已录制存档的视频图像数据，这些未经提纯的信息不能在异常情况发生时立刻预警到相关部门，不能发挥视频监控的“主观能动性”。三是时间周期长且时效性低下。耗费时长越长，人工比对查找的效率越低，易错过侦破的最佳时机。因此，如何实现智能视频监控，充分利用机器视觉技术对爆炸式的多媒体数据进行自主分析理解和处理显得尤为重要。最终计算机在无人工参与时，对目标行人识别和跟踪并预判其行为，即时地为工作人员提供有用信息并降低容错率，以满足公共安全领域即时决策的需求。行人重识别技术只需要对所采集的目标行人样本进行身体外观特征的分析从而识别其身份，在实际应用方面对于犯罪嫌疑人行踪检索、智能零售领域中的消费者轨迹追踪等均有积极意义，对于保障人民生命财产安全、稳定社会治安极为重要。行人重识别任务现已成为一项兼具研究价值与挑战性的研究课题。




图 1-1 行人重识别目标示意图

行人重识别作为目前机器视觉领域的重要研究课题之一，旨在将不同物理位置、不同摄像头捕获的同一个行人的图像进行关联，实现跨摄像头跨场景下的行人识别与检索，用以填补人脸识别和接力跟踪技术的空白，进而连续跟踪无法获取清晰面部特征的行人，从而保证数据的时空连续性^[1]。如图 1-1 所示，视频监控网中被安装在不同地理位置的两个或多个监控摄像机持续地拍摄视频，从中选择一个摄像机下某个指定的行人图像，与其余任意摄像机下捕获的图像进行比对，进而查找出该目标行人。具体描述为：假设监控摄像机 1 下身份为 ID1 的行人为目标行人，那么行人重识别要做到：当该行人出现在视频监控网的其他监控摄像头下时（如监控摄像机 2 捕获到身份为 ID1 的行人图像），能够被成功辨识到其身份为 ID1。但是从图 1-1 中可以看到，(1) 不同监控摄像头所部署的周边环境差异较大、拍摄角度不一致、摄像机距离行人远近不同以及拍摄时间不统一，会导致行人图像中相同行人的外观差异明显，如行人图像照度不一、行人姿态的多样化以及行人在图像中的占比不一等；(2) 不同摄像机自身参数属性的差异无法保证采集到足够多的视觉信息，如行人图像具有不同的分辨率、图像中行人的脸部轮廓模糊，甚至没有明显的行人脸部特征等；(3) 现实生活中的监控场景复杂多变，如人流量大、特定场合下行人着装造型相似等，行人重识别任务因此而难度大增。

1.2 国内外研究现状

行人重识别技术起源于 2005 年的跨摄像头多目标跟踪课题^[2]，发展自 2006 年的 CVPR 会议，是智能监控系统的关键技术之一。当时 Gheissari 等人提出了时空特征分割的行人重识别方法^[3]，此后行人重识别便脱离于跟踪领域而“自立门户”，在对人类视觉机理的研究模拟和漫长的研究探索中更是呈现出了多样化的发展。




图 1-2 行人重识别技术流程图

行人重识别技术有两大组成部分——图像特征提取和特征相似性度量，如图 1-2 所示。传统方法主要通过人工设计局部特征对图像中的行人进行特征提取，再将其融合构成全局特征。研究者从人体结构特点出发，将行人图像分区处理，提取各部分纹理、形状和颜色等底层视觉特征^[4-6]，并进一步挖掘行人的着装属性等中层语义信息^[7-8]作为补充，组成行人特征。在获取行人特征以后，通过欧氏距离度量、KISSME (Keep It Simple and Straightforward Metric)^[9]、ITML (Information-theoretic metric learning)、LMNN (the Large Margin Nearest Neighbor Learning) 等方法学习图像间的相似性。但传统的特征设计方法极耗费精力且难适应复杂场景，传统的度量学习方法面对巨额数据时难以求解。

近年来，深度学习方法在机器视觉众多任务中表现优异，行人重识别任务的精度也在被该方法不断刷新。与前述传统方法不同的是，深度学习方法可以通过构建具有非线性特征的多层模型，提取具有高度鉴别性的图像特征，学习更准确的相似度量。由于卷积神经网络模型可以自动学习到复杂高维的行人特征，此时仅需使用最简单的欧式距

离就可以进行特征间的相似性度量。因此,现阶段的行人重识别方法主要集中在网络结构的改进和输入数据的改善,从而获取表现更优的特征提取器,大致可分为以下研究方向:

(1) 匹配局部区域。深度学习行人重识别方法早期主要集中于全局特征^[10-12],即直接对输入的整幅图像提取特征,优点在于计算速度快^[13]。后来研究发现提取全局特征的方法忽略了图像的空间特征信息,并且极易受遮挡、姿态变化等影响,导致匹配失败。各类匹配局部区域的方法因此被提出,常用的研究思路有水平切条^[14-21](特征空间分割)、在正方形邻域内做匹配^[22]、引入人体部位(头、胳膊、腿等)检测部件^[23-26]以及注意力机制^[27-28]等等。PCB 模型将卷积网络输出的全局特征图水平分割为均等的 6 个条纹区域以提取行人的抽象部件特征,经过多次卷积后的局部特征具有良好的高级语义特征,然后分别经过不同的全连接层进行预测,该模型只需学习抽象部件之间的上下文关系,简单高效^[14]。在此基础上,多粒度模型 MGN (Mutiple Granularity Network, MGN) 被提出,首先通过将特征图划分成多个条纹特征图,并且改变不同分支的条纹数量来获得多粒度局部特征表示,然后将全局特征与局部特征整合到一起,再使用三元组损失函数^[29]优化全局特征向量,使用交叉熵损失函数约束局部特征向量。与仅采用局部特征的 PCB 模型相比, MGN 模型的识别精度有很大的提升^[15]。金字塔模型在全局和局部特征的基础上,思考了两种特征间的渐变关系,通过特征融合的方式,促使模型提取到具有较强上下文联系的特征^[16]。Zhang 等将动态规划方法融入分割部件的匹配中,计算所有局部特征间的距离并加和作为行人最终的相似度,不需要额外的监督信息即可实现自上而下的行人对齐^[19]。Sun 等将输入图像分割成上中下 3 个区域,使模型在训练时对每个局部区域的可见性进行打分。分值低代表该区域特征对于行人匹配是无效的,因此设置为不可见部件。通过减少不可见区域参与后续计算的权重,有效克服遮挡问题^[20]。Fu 等将行人图像分割为上中下 3 组,在组内聚类并分配伪标签,构建了一个子数据集细调网络,通过分割后的局部特征能够挖掘出所需的自然相似特征,有效解决跨域偏差问题^[21]。匹配局部区域的方法通过改进网络模型以挖掘行人的关键信息,如身体部位和姿态点等,从而鼓励模型忽视无关特征,学习人体局部关键区域^[30]。

(2) 设计损失函数。深度学习行人重识别任务在相似性度量阶段虽然仅使用欧氏距离,但损失函数的设计可参考距离度量方法,设计出的损失为度量损失。通过应用度量损失的方法去约束网络,帮助网络直接地关注到行人特征之间具有何种相似性和差异性,以使网络表现出更强的鲁棒性。具体描述为在行人重识别问题中,不同行人的图像相似度须远大于同一行人的不同图像相似度,因此在实际的训练过程中需要损失函数约束网络以学习由图像到特征空间的一种映射,使不同行人图像间距离明显大于相同行人图像间的特征距离。该领域应用度最高的度量损失函数有三元组损失(Triplet Loss)^[29]、对比损失(Contrastive Loss)^[31]和四元组损失(Quadruplet Loss)^[32]等等。

(3) 利用 GAN 造图。庞大的图像样本是深度学习所必须的,而现阶段的行人重识别数据集数量非常有限,且各数据集间都存在一定的背景、照度等的差异,因此行人重识别模型在训练集上容易过拟合。从数据的角度来说,传统的数据增广方式对其性能的提

升已经起不到比较好的作用了,而对抗生成(Generative Adversarial Net, GAN)网络逼真的图像生成效果,使其成为了研究者们不可忽视的一种选择。Feng 等人设计了一个跨模态的 GAN 网络,首先通过生成器构建了数据集,接着利用循环 GAN 网络降低其中的模态差异,并通过特征融合的方式增强前层网络的输出,最后进行图像相似性度量,得到最终的检索结果^[33]。Qiu 等人设计提出了联合时空模型的 GAN 网络,包括识别模型和筛选低匹配样本的时空模型两部分,二者融合完成整个识别过程^[34]。

(4) 改善输入数据。大多数计算机视觉任务都假设算法的输入数据是完整的,或有足够的信息可以被正确识别^[35-36],但对于从监控视频中获取的单帧图像,由于数据处理过程存在缺陷(如不完善的检测器^[37]、存在姿态方差等),输入数据并不总是满足这个假设。例如,地铁站、机场或超市内的目标行人可能会被售票门、行李和收银台或其他人或物遮挡。对此,研究者们提出了一个直接的想法:让深度网络自行矫正输入数据。通过一个二维变换的学习,帮助网络去对齐行人各部位,再用该网络去进行下一步的识别工作。Zheng 等人提出将行人对齐与行人重识别相结合,使高层网络通过仿射变换学习参数,然后将学习到的参数更新到仿射网络中,最后使低层网络的特征通过仿射网络达到行人对齐的效果^[38]。深度空间重构 DSR 在深度学习框架中通过稀疏重构直接匹配两个任意大小的特征映射,以加速匹配过程^[39]。Luo 等人使用了 STN^[41]处理输入,STN 模块利用部分和整体图像的高级特征,预测二维仿射变换的参数,然后从整体图像中采样一个仿射图像去匹配部分图像^[40]。类似地,He 等人提出部分与部分对应学习的策略,在没有任何额外的部分级监督的情况下学习图像补丁之间的对应关系:首先对原始图像随机裁剪,取任意部分作为输入,然后经过 GLRec 模块生成一组仿射转换系数,并获得具有适当比例和布局的校正部分图像,之后 CRLoc 模块根据给定的部分输入图像在参考图像中定位相应的区域,最后计算相应的部分区域之间的部分输入与参考图像的相似性^[42]。改善输入数据本质上是希望网络模型更易关注并挖掘到有鉴别能力的特征,简化后续的识别过程,同时避免了额外标注信息的引入。

(5) 基于视频序列的方法。单帧图像下的行人重识别,由于其数据量相对较小,在小型服务器上跑图耗时可观,因此仍是现阶段的研究主流。但相对图像而言,视频序列中的额外运动信息、帧与帧之间的额外信息,都使基于视频的方法能够提取更多的具鉴别性和鲁棒性的特征,这使得基于视频的方法更有希望处理人为遮挡和模糊造成的挑战。对于视频序列下的行人重识别,许多努力都致力于对时间线索和视频帧进行建模。Chung 等人将光流信息输入模型以学习时间特征^[43]。Song 等人设计不同的分支来预测视频帧的质量分数^[44]。Liu 等人设计了一个细化的循环单元,使用运动信息和外观表示来抑制噪声^[45]。Liu 等人利用视频和无线移动定位信号,设计了一个循环上下文传播模块,促使无线定位信息与视觉信息进行充分的融合和持续的传播,并依据视觉轨迹和无线定位轨迹的重合来判断视频和无线信号是否属于同一个人。无线信号的引入可以弥补对遮挡、模糊、姿势变化、服装变化等因素敏感的视觉数据的缺陷^[46]。

1.3 行人重识别面临的挑战

目前行人重识别理论和方法日益完善,越来越强大的重识别算法被提出,尤其是行

人重识别任务所达的基线性能已逐渐逼近甚至超越人类水平。但我们所处的实际环境复杂,这一研究中依然有一些问题亟待解决。现阶段行人重识别研究主要有以下4个挑战:

(1) 行人姿态不对齐导致的特征定位和匹配错误问题:当行人自身姿态多样、摄像头的视角和拍摄时机不一等情况出现时,行人图像的外观表征也会发生不规则的变化,此时面临的挑战主要包括两个方面:一是行人姿态不同和行人在图像中占比不一,在嵌入空间中行人身体局部特征的分布会发生明显变化,从而出现特征不对齐问题;二是不含遮挡物的半身图和全身图之间的匹配容易出现错误。针对第一种情况,有不少研究者提出使用分割信息或人体骨骼姿态点来解决,但缺点在于,该方法需要一个额外的姿态点模型来提供人体语义部件的先验信息,并且需要在额外的数据集上进行训练,增加了训练代价。另外,行人重识别任务对姿态点模型的精度要求很高,否则不仅无法正确地对齐行人特征,还会造成大量错误的匹配。针对第二种情况,目前已有的工作极少,但是实际系统中半身图却是广泛存在的。因此如何在不耗费多余代价的前提下进行行人局部特征的自动对齐以及实现半身图和全身图的高效匹配,是行人重识别任务中一个非常值得研究的问题。

(2) 基准网络的特征筛选利用非最优导致的重识别准确度不高问题:目前相关的行人重识别研究工作均是在基准网络的基础上进行的,通过对基准网络的加工和改进来满足实际应用的需求。但这会导致所提方法具有很大的时空复杂度,而实用性却大打折扣。基于卷积神经网络的行人重识别模型的网络结构仍有很大优化空间,网络深度的不断增加使网络能够提取到更加精细的特征,但可能存在对特征的筛选利用非最优的问题,从而导致基准网络的重识别准确度不高。如果基准网络达到很高的精度,且兼容速度与性能,那么一个新方法的有效性也更加能够被大家所认可。因此如何设计高精度的基准网络是目前该技术的一大重点。

(3) 图像前景(行人)的视觉信息不足:不同的光照条件使得行人影像的表征呈现不同。如果监控摄像机在充足的光照条件下,那么此时的图像具有很高的细节质量。即使行人出现在不同的摄像头中,图像的差异也会很小而易识别。但光照不足会导致样本图像中的多个区域外观颜色亮度很低,从而对分类器造成干扰。无关物体对行人的遮挡使得行人不是全部可视的,甚至其中最具有代表性的外观特征也被掩盖。不同摄像机的自身参数属性的差异以及与行人间距的变化会使捕获的行人轮廓模糊、图像具有不同的分辨率等。不同摄像机的拍摄视角和抓取时间不统一,使得同一行人在不同图像中占比不一,其中行人占比很小的图像便会增加重识别的难度。因此如何从较少的有用信息量中辨识出目标行人是行人重识别当前阶段的难点之一。

(4) 行人检测框不精确导致的行人特征在图像中占比不一问题:视频监控网中摄像机采集的行人图像和视频的数量非常庞大,人工标注行人的成本巨大,因此常利用行人检测算法自动检测并提取画面中的行人区域。然而在自动检测并提取行人区域时,行人检测框具有一定的不精确性。如图1-3所示,第一幅图是一个正确行人检测得到的行人区域,而第二幅图中的检测框过大,包含了大量的背景干扰信息,而第三幅图像中的检测框则太小,遗漏了一部分行人区域,丢失了相应区域的特征。因此,行人检测框的不

精确也对行人重识别任务的准确率造成了影响。



图 1-3 行人检测框不精确示例

本文对算法的改进工作在上述(1)(3)(4)点均有体现并有所克服,针对第(2)点本文将在 3.3.4 节中通过实验进行对比总结。

1.4 论文的研究内容及结构安排

由上文对行人重识别的介绍可知,行人重识别是一项跨地域跨镜头重新识别相同行人的技术,通过对它的研究,能够填补人脸识别技术和接力跟踪技术的空白。作为一项可应用于多领域的技术,行人重识别技术得到了研究者的广泛关注,且行人重识别模型的识别性能得到了极大地提高。对融合局部特征的研究已成为热门,不同的局部特征着眼于不同的判别信息。采取适当的方法提取并融合更加细腻丰富的局部特征,能够提高特征的判别力。因此论文就融合局部特征的深度学习行人重识别方法进行了研究与分析,以获得更高的检索准确率。在前人研究的基础上,通过对局部特征提取模型的改进、骨架网络的改进、不同分区特征融合、注意力机制、多分支结构等策略的应用,进一步提升了采用局部特征的行人重识模型的识别准确率,并且在该领域公开的常用数据集上验证了所提方法的有效性。论文共分为六个章节,内容安排如下:

第一章绪论。首先简要说明了行人重识别的研究背景与意义,突出了行人重识别技术的实用价值。然后概括了该技术的研究现状,详细梳理了该领域的研究类别以及各类中的典型算法。再说明了在实际应用中该技术所面临的技术难点和挑战。最后论述了论文的主要研究内容和总体结构框架。

第二章行人重识别相关工作。首先阐述了行人重识别的定义并给出了一个实例,接着详细研究了行人重识别基准,包括卷积网络的概念和组成部分、常用的基准网络和约束损失,然后具体实现了基于特征空间分割的 PCB 模型的行人重识别流程,并给出了本文所做基准工作的结果,最后介绍了行人重识别领域内应用最广泛的 3 个数据集,以及算法的性能评估指标和计算方法。

第三章多层次重叠条纹特征融合的行人重识别。针对目前行人重识别算法在提取行人局部特征时存在的信息缺失的问题,在深度学习框架下提出多层次重叠条纹特征融合的行人重识别方法,以保证行人关键信息的高提取率和利用率。两个数据集的有效性实验证明,该网络能够提取到更多的局部特征信息,并保证很低的信息丢失率,重识别准

确度优于现有方法。

第四章异构分支关联特征融合的行人重识别。由于多分支结构的网络模型在提取行人特征时缺乏异构特征，为了增加行人特征的多样性并加强行人局部特征间的联系，论文提出异构分支关联特征融合的行人重识别方法。在公开数据集上的实验结果表明，关联条纹特征提取模块能有效优化区域局部特征，能够更关注到行人较小的局部区域。与现有方法比较，能够更好地应对行人姿态的变化、部分物体的遮挡和较明显的照度变化。

第五章融合多分区特征的行人重识别。由于空间分区行人重识别方法会忽略纵向高级信息，论文引入了信道分区方式，提出融合多分区特征的多分支行人重识别网络，使不同的分支负责学习行人不同区域的不同特征。在 3 个公开数据集的结果表明，信道分区与空间分区的特征互补，在帮助网络在学习身体部位特征的同时，更强调了语义概念层面的重要性。

第六章主要结论与展望。总结本论文对行人重识别课题的研究工作，分析其中存在的不足与局限性，并进一步提出未来研究工作的展望。

第二章 基于特征空间分割的行人重识别相关理论

2.1 行人重识别定义与实例

行人重识别任务通常可以做如下定义。给出规定的两组图像数据——行人图像库 gallery 和测试的行人图像 probes。其中行人图像库 gallery 包含 M 个行人的 N 张图像且有 $M \leq N$ 。即每个行人应该相应的有一张图像或多张不同图像。probes 包含每个行人的一张图像 query。该任务的目标是对于任意一张测试图像 query，在 gallery 中找出所有与该 query 身份相同的行人图像，即具有相同的身份 ID 的图像，并且将该行人的所有图像在检索结果中排序在最前面。

图 2-1 展示了一个行人重识别实例。行人图像库 gallery 是对智能监控中的每一帧视频进行行人检测后采集得到，gallery 中图像数量巨大。行人重识别要做到在 gallery 库中找到特定 query 对应的同身份行人，从而确定其位置和行进轨迹，属于跨镜头的行人检索。如果多个摄像头的视野覆盖范围有重叠，那么在行人重识别时，由于行人所处场景的光照条件和背景等相近，只需考虑摄像视角的变化，因此检索难度较小。而如果没有视野重叠，不仅是背景和摄像头的视角、距离，几乎所有外在条件均会发生很大变化，行人重识别任务的难度也会因此大大增加。




图 2-1 行人重识别实例

2.2 行人重识别基准

本课题任务在检索阶段须要根据图像之间的相似性高低依次进行排序。相似性常用欧氏距离或余弦距离计算得出，代表了特征向量在某种度量方式下的差异。深度学习行人重识别任务中，行人图像的特征向量通过卷积神经网络提取得到。




图 2-2 行人重识别 IDE 网络结构

深度学习环境下出现了众多表现杰出的网络结构，其中被广泛应用且有效的基准网络为嵌入行人样本图像的身份 ID 标签的 IDE 网络 (ID Embedding, IDE)^[47]，图 2-2 为 IDE 网络结构。首先选取一定数量的行人图像构成一个批次，然后将其输入骨架基准网络，再经过池化层和全连接层，从而获取行人的深度特征表示。在训练初始阶段，所获取的目标特征的判别力较弱，但伴随训练的加深，网络的损失会逐渐减小，进而优化骨架网络的参数，从而获取判别力渐强的行人特征。其中骨架基准网络和损失函数的选取尤为重要，骨架网络的特征提取能力越强，且损失函数对网络的约束能力越强，后续识别的效果越好。

2.2.1 卷积神经网络

卷积神经网络 CNN (Convolutional Neural Network, CNN) 由 Yann LeCun 教授设计并公开，它具有很深的网络结构，是使用图像卷积计算进行表征学习的一种前馈式网络结构，即模型的输出没有连接回输入的反馈线，因此信息进入输入层，经过中间层的映射变换，最后到达输出层便完成计算。CNN 的提出不仅将研究者们从繁琐的人工特征设计的工作中解放出来，而且带给计算机视觉领域前所未有的变化。卷积神经网络所具备的权值共享和局部链接特性，保留了它多层感知机的本质，既保证了恰当的模型复杂度，又减少了参数数量，同时减小了模型过拟合现象的发生率。早期的卷积网络主要以“卷积层-池化层”的组合形式反复地交替堆叠而成，如图 2-3 所示的网络示例结构，卷积神经网络摒弃了传统方法中的数据恢复操作，可以直接对整幅图像提取高级语义信息，具有传统方法无法取代的天然优势。随着计算机视觉各领域任务精度需求的提高，卷积神经网络的结构也在不断完善，下面分别从卷积层、激活层、池化层和全连接层入手介绍卷积神经网络的常用基本组成结构。




图 2-3 卷积神经网络样例图

(1) 卷积层

作为卷积神经网络的核心成分，内含一系列特定尺寸的卷积核。选择适当尺寸的卷积核，滑动扫描输入特征图，以完成特征的学习计算和提取，并生成一个新的包含精炼信息的特征图。卷积核通常不是单独存在的。若干数量的卷积核包含于每一个独立的卷积层，它们相互独立地从图像中提取差异特征信息。以二维卷积为例，其计算过程为

$$x_j^l = f \left(\sum_{M_j} x_j^{l-1} * k_{ij}^l + b_j^l \right), \quad (2.1)$$

式中 x_j^l 是第 l 层卷积层的输出特征图， x_j^{l-1} 为第 $l-1$ 层卷积层的输出特征图， b_j^l 是第 l 层卷积层的偏置大小， M_j 为输入特征图序列中的第 j 个特征图， $k_{i,j}^l$ 是第 l 层卷积层的第 i 个卷积核。

卷积核以特定步长和大小在原图像的对应位置上滑动，生成图像的大小由滑动步长决定，参与卷积运算的像素范围与卷积核大小相同。图 2-4 展示了一个二维卷积示例。3×3 的卷积核由图 2-4 的左上角出发，以步长为 1 的速度从左向右平滑移动。输出值为卷积核与输入对应位置元素的乘积的加和，重复上述计算过程，每移动一步就要做一次卷积运算，直至卷积核被移动到输入特征图的最右下角，方才结束卷积计算。实际应用时会给卷积输出加上一个偏置值。




图 2-4 二维卷积计算过程样例示意图

(2) 激活层

由上图 2-4 可以看出卷积操作是一个线性函数，而实际场景下的数据信息基本都是非线性的，如果神经网络只是单纯的卷积层堆叠，那么层数再多也毫无意义，因其始终只是表达了一种线性组合关系，几乎没有逼近能力。为此引入了具有不同非线性属性的函数为网络模型提供激励，使其可以逼近任意函数，将输出结果限制在有限的范围内，如此可获得表达能力将更加强大的深层神经网络。我们常称具有这般作用的非线性函数为激活函数 (Activation Function)。该领域应用度较高的有 Sigmoid 函数、Tanh 函数以及 ReLU 函数。

计算机视觉领域中早期的研究主要使用 Sigmoid 和 Tanh 函数，因二者输出有界，易作为下一层网络的输入数据。其中 $\text{Sigmoid}(x) \in (0,1)$ 形式简单且易求导，但在反向调整权重参数时，因 Sigmoid 函数不是以零为中心的且易饱和而梯度值均小于零，输入

$x > 0$ 会使前层网络的权重值几乎没有更新，研究者们称之为“梯度弥散”现象。该现象会极大地影响网络模型的性能。而 Tanh 函数虽然以零为中心但仍旧不能消除梯度弥散现象。激活函数 ReLU 出现后被研究者广泛使用，因其线性非饱和的形式可以有效降低梯度弥散出现的概率，且在结合随机梯度 (SGD) 优化模型参数时速度相对更快。

(3) 池化层

为了最大程度地保留住尺寸为 $H \times W$ 的输入图像的特征，在对其进行卷积操作时通常选择步长为 1，不考虑通道数，在卷积运算后输出尺寸为 $(H-2) \times (W-2)$ 的特征图。因此对于尺寸很大的输入图像，要想得到适于后续任务的特征图大小，就需要网络模型具有更深的层，但是层数越多网络越难以训练，由此池化层 (Pooling Layer) “应运而生”。池化也可称为降采样，作用有二：(1) 池化操作保留了特征图中关键信息，摒弃了无用冗余信息，同时引入了空间不变性，使模型更具鲁棒性、更利于识别与分类；(2) 局部降采样特征图，以减小原特征图的维度和分辨率，降低计算量、所需的运算显存和模型过拟合的概率。

图 2-5 为池化运算样例，同卷积运算类似，池化函数通过使用特定大小的过滤器窗口在特征图上进行移动，不同之处在于过滤器窗口不会互相重叠。最大值池化输出为即对像素领域内特征像素点所取的最大值，平均值池化输出为对像素邻域内特征像素点所取平均值。




图 2-5 池化运算样例图

(4) 全连接层

行人重识别任务也是一项多分类任务，为了更好地完成此任务，通常会在卷积神经网络的最后一层加入全连接层。与前述网络各层将输入数据映射至隐层嵌入空间不同，它先是充分融合前层网络所学特征，然后将其映射到一个样本标记空间，这个空间是线性可分的。

全连接层如图 2-6 (a) 所示，神经元之间的密集链接确保了下层网络的每个神经元都可以接收到上层传出的信息，但会导致整个网络模型参数量大大增加。因此在实际任务中全连接层仅在 CNN 网络的最后一层或几层有所应用，以实现后续的分类工作。此外为了降低相邻层之间不同神经元的依赖性，如图 2-6 (b) 所示，通常在全连接的层之间应用的 Dropout 正则化方法，在网络训练过程中，Dropout 会随机阻断正向传播途中神经元的信号接收与传递，这相当于每次都是不同的网络模型在学习同一组输入数据，

可以获得泛化能力强的模型，并且能够有效降低过拟合现象的发生率。




图 2-6 全连接层示意图

2.2.2 基准网络结构

计算机视觉的各大领域中，CNN 网络作为骨架网络以提取强有力的特征已被证明先进性。深度学习行人重识别任务中常用的骨架基准网络有很多，如 VGGNet、深度残差网络(Residual Neural Network, ResNet)^[48]、全尺度网络(Omni-Scale Network, OSNet)^[49]、DenseNet 等等。下面简要介绍本文使用的骨架基准网络——ResNet。

相比于浅层网络模型而言，越深层的网络模型所提取的目标特征的表达能力越强。网络模型的卷积层越多，不同的卷积核越能从图像中提取出更细腻、语义特征表达能力更强的信息，因此研究者常常通过增加网络模型的深度以求取性能的大幅提升。但实际上，训练中的卷积神经网络模型在反向传播的过程中，会通过链式求导法则求取每一个卷积层的权重参数的梯度值。更多的网络层数会更易令梯度值在向前层网络传播的途中越变越小甚至为 0，如此一来，比较靠前的网络层参数将不能得到更新，模型会因此而性能大幅降低。针对这一困扰，何凯明等人于 2015 年在 ILSVRC 2015 比赛中创新性地提出 ResNet 网络^[48]，在一定程度上消除了因网络深度增加导致的梯度弥散现象。




图 2-7 ResNet 的主要思想和基本结构单元

ResNet 创新在残差学习模块的构建和设计思想。如图 2-7 所示，通过加入一个跨越

链接,保证了网络每个残差块的输出都可以跳过一个及以上网络层,直达下一个残差块的末端。它不仅很好地避免了深层神经网络在训练时的梯度弥散问题,而且在堆叠若干个该学习模块后,深度残差网络计算量小且不会出现先前的退化问题,更进一步提高了网络特征的表达能力。

2.2.3 常用网络约束

如第一章 1.2 节所述,常用于约束行人重识别网络的损失函数有二——分类损失函数和距离损失函数。在同时考虑效率和精度时,通常使用二者相结合的方式对网络进行训练。分类损失函数负责加快网络收敛的速度,距离损失函数负责在训练过程中引入距离度量的思想,可以有效减少模型过拟合的问题。

分类损失是基于交叉熵 softmax 的身份损失。仅使用分类损失的网络即为 2.1.3 节中的 IDE 网络,也被叫做分类网络。分类网络视行人的身份 ID 为类别,在网络训练阶段预测出每张图像的所属类别,此时网络是在学习特征空间中样本类别的分界面。通常是在提取到的图像全局特征后添加一个全连接层,然后通过交叉熵 softmax 的激活,输出身份 ID 的预测向量。现有一训练集共 N_{train} 张图片, K 个行人,经过全连接层后的输出则为 K 类 $z = [z_1, z_2, \dots, z_K]$, 则约束身份的分类损失定义为

$$L_{id}(z, l_{id}) = - \sum_{i=1}^K \log \left(\frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \right) \cdot x_{id}, \quad (2.2)$$

其中 $x_{id} = \begin{cases} 1, l_{id} = k \\ 0, l_{id} \neq k \end{cases}$ 表示当前预测的身份类别 k 是否和标签值 l_{id} 一致。分类损失在数据量

小时易收敛且训练时长短,但是数据量大时,行人的身份 ID 也增多了,在经过网络的全连接层后参数量变的巨大,将导致模型训练耗时长且收敛困难。但由于现阶段行人重识别数据集的规模尚可,因此很多方法仍然使用分类损失函数约束网络。

距离损失是基于度量学习思想,可以被加入到 IDE 网络中与分类损失共同约束网络。与分类损失不同的是,距离损失是在特征空间中将样本聚类,同时不需要全连接层,因此更易适应不同的数据集,不受身份 ID 数量的限制。常用的训练网络的距离损失是三元组损失函数

$$L_{triplet} = \sum_i^N \left(\|f(x_i^a) - f(x_i^p)\| - \|f(x_i^a) - f(x_i^n)\| \right), \quad (2.3)$$

其中 x 表示输入图像; x^a 为固定参考图像; x^p 为正样本,即与 x^a 相同身份 ID 的另一图像; x^n 为负样本,即与 x^a 不同身份 ID 的图像; i 为三元组的索引数; N 为数据集中三元组的组数; $\|\cdot\|$ 为欧氏距离; $f(\cdot)$ 为网络提取到的行人特征。

2.3 基于特征空间分割的行人重识别算法流程

2018 年, Sun 等人提出的基于深度残差网络的 PCB 模型由于其空间分区方法可以有效应对姿态变化和遮挡,并且可以在大规模数据集上端到端训练,引起了研究者的广泛关注。此后,很多研究者在该 PCB 结构基础上进行了大量的改进。因此 PCB 结构模

型可以说是当前基于特征空间分割的行人重识别的开山之作。

2.3.1 行人重识别流程

PCB 结构模型将行人重识别视作部分级特征的相似性匹配问题，在行人检索过程中使用部分级特征会给行人表征提供细粒度信息。PCB 算法提出了一种部位级匹配策略来衡量查询图像 x 和候选图像 y 之间的相似度，当表示同一个行人的身体部位的两个图像块被输入网络时，那么相似度的值就应该很大，反之则得出很小的相似度值。而深度残差网络结构正适用于这类相似性学习的任务。此外，深度残差网络接受任意大小的输入，这使得我们可以调整输入图像的大小以满足实际行人的高度比，从而匹配计算每个部位的相似度。PCB 模型中特征提取子网络为修改后的 ResNet-50，相比于原始的 ResNet-50，改进的特征提取子网络删除了 GAP 层及之后的空间降采样操作。

图 2-8 展示了 PCB 模型的整体框架和重识别流程。PCB 模型会将查询图像 x 和候选图像 y 输入进同一个特征提取子网络以获取它们的特征，然后通过欧式或余弦距离函数计算出二者各个部位的相似程度，相似度最大的候选图像即为正确检索匹配结果。总体的检索匹配过程可以表示为

$$f(x_i, y_i) = \|\varphi(x_i) - \varphi(y_i)\|, \quad (2.4)$$

其中 x_i 和 y_i 分别表示查询图像和候选图像的身体部位 i ， $\varphi(*)$ 表示骨架网络的特征映射，在 PCB 算法中表示修改后的 ResNet-50 对输入图像提取的特征， $\|*\|$ 表示特征相似度的计算。




图 2-8 PCB 算法的行人重识别流程

PCB 模型在进行行人重识别时，首先将输入数据调整为 $384 \times 128 \times 3$ 大小，经特征提取子网络得到 $24 \times 8 \times 2048$ 的整体特征图 M 。然后将 M 在 H 方向均等分割为 6 份大小为 $4 \times 8 \times 2048$ 的部位特征图，并经过全局平均池化得到 6 个特征向量 m 。再使用 1×1 的卷积操作降维得到 6 个比 m 低维的向量 n 。最后，计算两幅图像相应部位 n 的特征相似度，如果相似度很高则表示被比较的部位是同一个人的，反之则不是。为了保证每一个部位都能够被正确定位，PCB 使用了部位内部的上下文信息一致性，将 6 个部位对应的空间分布进行软权值分配。

2.3.2 训练细节

PCB 模型在训练时使用 6 个不同的分类器，以保证行人的每个部位区域都被很好地

学习。这些分类器由 FC 和 Softmax 函数构成且不共享权重，可表示为

$$L_{id} = \text{soft max} \left(W_i^T f \right) = \frac{\exp(W_i^T f)}{\sum_{j=1}^{\rho} \exp(W_j^T f)}, \quad (2.5)$$

其中 ρ 为分割的身体部位的数目，PCB 模型中设置为 $\rho=6$ ， W 为训练所得的分类器的权重矩阵。

本文复现该 PCB 模型并在此基础上应用度量损失函数，并将其作为本文后续比较的基准，在实验结果和对比结果中均有体现。2.2.3 节公式 (2.3) 表示样本间距满足“同类足够近，异类足够远”即可，但它未考虑同异类的相对关系，这样在网络训练过程中会出现“同类密集，异类无限分散”的情况，从而使网络收敛困难。理论上讲，只要同类间距在一定范围内相对小于异类间距，网络的分类层就可以找到它们的类别边界。因此，通过预定义边距控制裕量 α ，调整异类图像间特征向量的接近程度。三元组损失函数进一步表示为

$$L_{\text{triplet}} = \sum_i^N \left[\left\| f(x_i^a) - f(x_i^p) \right\| - \left\| f(x_i^a) - f(x_i^n) \right\| + \alpha \right]_+, \quad (2.6)$$

其中 $\alpha > 0$ ， $[*]_+$ 表示 $\max(*, 0)$ 。

在选择三元组图像时会生成大量的成对样本，这是高度冗余的，包括许多无信息的样本。随机抽样训练会被这些冗余样本淹没，大大降低模型的能力，也降低了收敛速度。因此对数据集中的样本图像如何采样决定了公式 (2.6) 的实际效果如何。相对正样本来说，数据集中的负样本在多数情况下很好与之区分，所以在网络的训练阶段常有损失为 0 的现象，因为异类间差距足够大，此时使用三元组损失无疑是一种资源的浪费。对此研究者提出了难例挖掘 (Hard Sampling) 的采样方式，选择参考图像、与参考图像最不像的同类样本、与参考图像最像的异类样本作为三元组，则公式 (2.6) 改进为

$$L_{\text{triplet hard}} = \sum_i^N \left[\left\| f(x_i^a) - f(x_i^p) \right\|_{\max} - \left\| f(x_i^a) - f(x_i^n) \right\|_{\min} + \alpha \right]_+, \quad (2.7)$$

其中 N 为一个批次中的图像数量， x^a 为参考图像， x^p 为与 x^a 同类别的正样本， x^n 为与 x^a 不同类别的负样本， $\|*\|_{\max}$ 表示取与参考图像最不像的正样本， $\|*\|_{\min}$ 表示取与参考图像最像的负样本。只要最不像的同类样本间距在一定范围 α 内相对小于最像的异类样本间距，网络就可以判定行人的所属类别。

综上，本文通过在线的方式来挖掘难例样本组，模型在训练时采用的损失函数为

$$L = L_{id} + L_{\text{triplet hard}}. \quad (2.8)$$

本文复现上述 IDE 和 PCB 模型，实验进行于 Market-1501 和 DukeMTMC-reID 数据集，实验所用的骨架网络为修改后的 ResNet-50 并经过了权重初始化，输入行人图像的分辨率大小调整为 256×128 。在训练的过程中，成批次地向网络中输入数据， $P \times K$ 张图像/批次，即随机地在训练集中抽取 P 个行人身份 ID，每个 ID 随机抽取 K 张图像。骨架网络为修改后的 ResNet-50 并经过了权重初始化，使用 He 方法^[48]对新增的全连接层进行待训练参数的初始化。在训练过程中，批次设置为 64， $P=4$ ， $K=16$ ，采用随机梯度

下降法 SGD 对每个批次进行参数的优化和更新。

表 2-1 和表 2-2 为本节算法模型在两个数据集上的识别准确度和其与其他方法比较的结果。“-”表示数据信息未公开。其中包括传统的特征提取方法下的算法结果、使用卷积神经网络提取深度特征的算法结果和本节实现的一个基准(baseline),从各项指标数据可见,深度方法远超传统方法。本节实现的基准(baseline)虽然与最优秀的算法有一定的差距,但是作为本文后续方法的对比,是一个相对基础且公平的基准。其中可以看到 PCB*的精度要明显高于 baseline,这是因为 baseline 只是用了全局特征,而 PCB*使用的是局部特征,更加精细且包含了更多的关键点信息,进一步证明了使用局部特征的方向正确性。

表 2-1 Market-1501 上与其他算法的比较

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
BoW+kissme	39.6	-	-	17.7
KLFDA	46.5	71.1	79.9	-
SVDnet	82.3	92.3	95.2	62.1
TripletLoss	84.9	94.2	-	69.1
Aligned	91.8	97.1	-	79.3
PCB	93.8	97.5	98.5	81.6
Our baseline	86.8	94.4	97.9	69.6
PCB*	88.5	95.2	98.3	69.9

表 2-2 DukeMTMC-reID 上与其他算法的比较

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
BoW+kissme	25.1	-	-	12.2
SVDnet	76.7	86.4	89.9	56.8
PCB	83.3	90.5	92.5	69.2
Our baseline	72.6	90.2	94.5	54.9
PCB*	80.3	93.0	97.9	64.3

不同的训练方案对识别准确度是有一定影响的,下面主要围绕损失函数不同、切割条纹数量不同 2 个方面,讨论其对算法性能的影响。

(1) 损失函数的选择。网络训练过程中,损失函数的约束作用很重要。实验包括三个:仅分类损失约束的 IDE 模型、仅三元组损失约束的 triplet 模型、二者共同约束的 IDE+triplet 模型。如表格 2-3 所示,其中列举了每个实验所使用的的损失函数和他们在数据集上的测试结果,由表 2-3 可以看到,单独使用一个损失函数训练的模型精度较低,但是将二者组合可以得到更优的网络模型。

(2) 切割的条纹数量。条纹数量 ρ 决定了零件特征的粒度,如表格 2-4 所示,当 $\rho=1$ 时,网络学习到的特征是全局的,随着 ρ 的增加,识别准确度会有所提高。但是也可以

看到识别精度并不随着 ρ 的增加一直提高,这是由于细分的越多,有些条纹会因为错位遮挡等而不包含行人特征,反而会降低模型的识别准确度。实验发现 $\rho=6$ 模型表现最佳,因此本文均使用 6 个条纹提取行人的局部特征。

表 2-3 在不同损失函数约束下的网络模型性能比较

所用数据集		Market-1501		DukeMTMC-reID	
模型	损失函数	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
baseline	IDE	74.5	42.6	68.5	51.4
	IDE+triplet	81.3	58.9	68.2	50.1
	triplet(难例挖掘)	84.7	68.7	72.0	53.6
	IDE+triplet(难例挖掘)	86.8	69.6	72.6	54.9
PCB*	IDE	76.7	43.5	68.2	51.6
	IDE+triplet	82.5	59.4	68.4	51.6
	triplet(难例挖掘)	86.4	68.9	79.5	55.7
	IDE+triplet(难例挖掘)	88.5	69.9	80.3	64.3

表 2-4 在不同的切割条纹数量下的网络模型性能比较

所用数据集		Market-1501		DukeMTMC-reID	
模型	条纹数量	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
PCB*	1	86.8	69.6	72.6	54.9
	2	87.2	69.8	74.5	55.3
	4	87.9	69.9	77.8	57.6
	6	88.5	69.9	80.3	64.3
	8	88.1	69.4	79.3	63.1
	10	87.5	69.2	77.5	5.5

2.4 行人重识别常用数据集及评估指标

计算机视觉的迅速发展带来的不仅有优秀算法的脱颖而出,而且有大规模的高质量数据集的提出。新型的数据集越来越满足实际需求,通过将算法进行相应的性能评估以保证算法的可应用性。其中广泛使用的有 Market-1501 数据集^[50]、DukeMTMC-reID 数据集^[51]和 CUHK03 数据集^[52] 3 个,本课题也使用这三个数据集对所提算法进行性能的测试。下面将列举所用评价指标的计算方法和这三个数据集的背景。

2.4.1 评价指标

行人重识别要求算法具有高准确度和强鲁棒性。准确度表现为检索匹配结果和测试图像是否来自于同一行人。鲁棒性表示模型的泛化能力,如果一个在数据集上训练好的模型,当被应用在不同背景和光照条件的场景下时,仍然能保持较高的检索准确度,则表示这个模型是具有强鲁棒性的。由于数据集的获取、制作和标注均需要耗费大量的人

力物力且难度大，并且实际应用和训练时使用数据的行人身份几乎是不可能重叠的，所以强鲁棒性是大家最终关注的。因此一个算法的鲁棒性要看其在测试集上的检索准确度表现，测试集和训练集的数据分布应该不同。

衡量行人重识别准确度的指标包括：

(1) 累计匹配曲线 (Cumulative Match Characteristic curve, CMC 曲线)，是检索准确度的图形表示，一般用 Rank-K 数值表格形式代替，单位为%。为了得到 CMC 曲线，要先根据相似程度对每次查询的结果进行排序，再引入查到率

$$r(k) = \begin{cases} 0, ID(query) \notin \{ID(1, \dots, k)\} \\ 1, ID(query) \in \{ID(1, \dots, k)\} \end{cases}, \quad (2.9)$$

其中 $ID(*)$ 表示测试样本图像 query 对应的身份 ID。 $r(k)$ 反映了在返回的 k 个检索结果中是否有和测试样本身份相同的 gallery 图像，有则为 1，没有则为 0。具体地说，如果返回的检索排序结果中，在第 i 个位置第一次出现与 query 一样身份的检索图，那么在 $k=i$ 之前，均有 $r(k)=0$ ，在 $k=i$ 时， $r(k)$ 则由 0 突变为 1。将所有检索结果的查到率加和即可获得 CMC 曲线

$$CMC(k) = \sum_{j=1}^{B_q} r_j(k), \quad (2.10)$$

其中 B_q 代表测试图像 query 的数量。CMC 曲线以图形的形式描述了 k 个检索结果中标行人被正确锁定的概率，其中返回的结果数目 k 的取值作为横坐标，行人被成功匹配的概率为纵坐标，该概率值越大，则识别性能越好。训练时间越长，网络接收的样本图像数目和可学习的判别特征也随之增加，则目标被成功匹配的概率也必然上升，因此在整个网络的训练过程中 CMC 曲线呈现持续上升的趋势。

CMC 曲线常用 Rank-K 表格代替，以数值的形式展现算法准确度的差异，需要对每个 query 的检索结果取平均值。通常选择 Rank-1、Rank-5 和 Rank-10 处的累计匹配率。由于在公式 (2.10) 中 r 取很小的数值时，可采用人工辅助的方式查找正确的检索目标。因此首位匹配度 Rank-1 最能直观地反映模型的性能，Rank-1 值越大表示网络模型的识别效果越好。Rank-K 更多关注的是排序结果中的正确率，而不是排列次序的先后。假设返回的 2 个结果为 TTTFFTF 和 FFTTTFTF，其中 T 为正确匹配，F 为错误匹配，则二者的 Rank-5 都是 60%，但是第一个排序中被正确匹配的结果位置相对靠前，因此检索匹配效果更好，是本课题更期待的重识别结果。

(2) 平均准确度 (Mean Average Precision, mAP)，以%为单位。分三步计算：

i 计算精确度 P：对于一张测试图像 query，从 gallery 中返回了排好序的 n 个检索结果，其中有 s 个结果与 query 具有相同的 ID，则精确度 $P(n) = s/n$ 。

ii 计算平均精度 AP 为

$$AP = \frac{1}{N_q} \sum_{i=1}^{N_q} P(i)z_{id}, \quad (2.11)$$

$$z_{id} = \begin{cases} 0, ID(gallery_i) \neq ID(query) \\ 1, ID(gallery_i) = ID(query) \end{cases}, \quad (2.12)$$

其中 N_r 表示 gallery 中与 query 相同身份的图片数, N_g 表示 gallery 中的图片数, $ID(*)$ 表示样本图像的身份 ID。

iii 平均均值精度 mAP: 所有检索结果的平均精度 AP 的均值

$$mAP = \frac{1}{N_q} \sum_{i=0}^{N_q} AP_i, \quad (2.13)$$

其中 N_q 表示测试图像 query 的数量。显然, 检索结果中与 query 相同身份的人排在越靠前的位置则 mAP 指标越高。

AP 代表一次检索的准确度, 属于查准程度。mAP 代表多次检索的平均准确度, 属于查全程度。所以 mAP 更加关注检索匹配结果的次序排列, 更能反映重识别模型的总体性能好坏, 更加适合作为评估算法检索匹配的指标。要全面评估行人重识别算法的有效性, 必须同时关注 CMC 和 mAP。在实际应用中, 存在使用多张 query 测试图像进行一次检索的情况, 此时由于被检索图像的信息更丰富, 所获检索匹配结果将更好。本文使用单张 query 测试图像做一次检索, 以便对比其他算法。

2.4.2 数据集介绍

深度学习对数据的需求量巨大, 行人重识别数据集也因此更加规模化。一般获取自监控视频, 并通过手工和行人检测算法进行标注, 包括任意背景任意角度拍摄的行人图像。本文所涉及的数据集有以下三个, 其基本信息如表格 2-5 所示, 它们均是该领域的公开数据集。图 2-9 列举了数据集中的一些示范图像, 每一列代表来自不同摄像机的同一个人的图像。

表 2-5 行人重识别数据集汇总

数据集	Market-1501	DukeMTMC-reID	CUHK03
公开时间	2015	2017	2014
行人身份数	1501	1404	1467
行人图像数	32668	34183	14097
摄像头个数	6	8	10
检测方式	DPM 算法	手工	DPM 算法+手工
拍摄场景	室外	室外	室内



图 2-9 行人数据集中不同摄像头下同身份行人图像

(1) Market-1501 数据集。该数据集涵盖了 32668 张图像 1501 个行人，其中 751 人的 12936 张图像打包为训练集，剩余 750 人的 19732 张图像打包为测试集^[50]。所有图像由六个视角不一的摄像头拍摄获取，且均采用 DPM 算法自动检测和切割所得，清晰度较高且颜色真实，更加接近实用场景，是 Person Re-ID 理想的数据集。

(2) DukeMTMC-reID 数据集。该数据集涵盖了 34183 张图像 1404 个行人，其中 702 人的 16522 张图像打包为训练集，剩余 702 人的 17661 张图像打包为测试集^[51]。所有图像由八个视角不一的高清摄像头拍摄获取，且均采用人工标注，是 Person Re-ID 很具挑战性的数据集。

(3) CUHK03 数据集。该数据集涵盖了 14097 张图像 1467 个行人，可根据相关协议自行划分训练测试集^[52]。所有图像由十个视角不一的摄像头拍摄获取，且采用人工标注和 DPM 自动检测两种方式。

2.5 本章小结

本章主要讨论了行人重识别课题相关的预备理论，首先阐述了行人重识别的定义并给出了一个实例，接着详细研究了行人重识别基准，包括卷积网络、行人重识别常用的基准网络和约束损失，然后具体实现了基于特征空间分割的 PCB 模型的行人重识别流程，并将其作为本文后续方法的对比基准，最后列举了本文所使用的三个行人重识别数据集和训练、测试集的划分，以及算法的性能评估指标和计算方法。

第三章 多层次重叠条纹特征融合的行人重识别

3.1 引言

为了测量两个行人图像之间的相似性，需要为数据集中的每个样本构建一个外观表征。构建表征最直观的方法是从边界框直接提取全局特征图。由于监控摄像头部署位置的差异，使行人图像存在分辨率不一致、姿态差异化、光线照度变化、拍摄角度多样化等情况，从而导致行人可用信息较少等问题，因此从图像整体提取的全局特征易受无关因素的干扰，关键的局部特征（携带的物体和身体部位，例如脸和手）不能总是被观察到，导致模型的识别精度不高。DaRe-Net 模型以不同分辨率提取网络每一阶段输出的全局特征^[1]，通过级联的方式进行特征融合。这种融合多层特征的方式，提高了仅依赖全局特征的重识别模型对难例样本的识别准确率，但是得到的高层特征的相似性对分类结果影响很大，而低层特征在区分细节等方面起到的作用对结果的影响极小。

为了提高模型性能，匹配局部特征的方法被提出。改进网络模型以挖掘行人的关键信息，如身体部位和姿态点等，从而鼓励模型忽视无关特征，学习人体局部关键区域。最典型的就是基于特征空间分割的方法（PCB 模型），其中行人特征图被切割为若干局部显著性区域。以此来保证模型对不同局部区域相似性和差异性地进行充分学习。PCB 方法能简单有效地利用局部特征进行分类，但是如图 3-1 所示，由于行人姿态变化和尺寸差异，会出现行人结构无法对齐的现象，并且单一地对 6 个区域进行预测，未使用相邻块之间存在的关联特征，可能导致具有判别性的信息丢失。




图 3-1 图像切块引起的无法对齐问题

针对上述未解决的问题，本章提出多层次重叠条纹特征融合的行人重识别算法。基于 RseNet-50 的主体框架，将网络不同阶段输出的多分辨率特征进行水平均等分割，再

提取重叠条纹特征，以综合利用位于各个相邻块间的重要信息；联合三种损失函数网络模型进行监督训练，以学习到鲁棒性更强的行人特征；设计组归一化模块以消除不同损失函数在优化方向上存在的差异。

3.2 模型设计

在本节中，主要分为 5 个部分介绍多层次重叠条纹特征融合的行人重识别网络，首先分析特征空间分割后行人特征的显著特性并引出网络的设计思想；然后给出本章网络的整体架构；最后分别研究总体模型中的重叠条纹特征提取模块、组归一化模块的结构以及在网络中的应用。

3.2.1 特征空间分割特性分析

由于视角变化、部分遮挡和错位在真实世界的行人重识别任务中很常见，如图 3-1 所示。用局部特征补充全局特征可以在一定程度上解决这些问题，并建立更好的人物表征，进一步提高神经网络对行人外观细小差异的区分能力。图 3-2 是采用 Grad-Cam^[53]画出的行人特征热度图，颜色越亮表示网络对该区域特征的关注度越高。子图(a)和(d)为网络提取到的行人全局特征，子图(b)和(e)为将行人图像在空间坐标上进行横向二分区后得到的局部特征，子图(c)和(f)为将行人图像在空间坐标上进行横向四分区后得到的局部特征。从图中可以看到，神经网络在提取行人的全局特征时，仅着重关注某一个显著区域。而将行人在空间坐标上进行横向分区以后，网络可以关注到每个局部区域的重要信息，从而获得更丰富的特征表征。将这些局部信息整合到一起，可以形成更加丰富的特定行人的信息。例如，图 3-2(a) 的全局特征图，网络对行人的上半身的衣袖关注度更高，几乎没有对下半身的关注。但是对于横向分区后的子图(b)，网络既关注到了上半身也关注到了下半身，且将在上半身的注意力从衣袖转移到了背包和鲜艳的衣服颜色上，这样可表征该行人的特征便更加丰富，更有利于网络对行人的识别。

在分区后，表征行人的关键特征有所增加，但仍然面临一个问题，即每个区域的特征无法很好地衔接，甚至丢失了一部分关键的特征信息。如图 3-2(f) 中，分别提取到行人的头部和背包的信息，但是肩膀处的关联信息丢失，这就可能导致网络在识别该行人时出现失误，因此在设计网络时应该将这部分信息重新考虑进去。本章通过设计一个重叠条纹特征提取模块，挖掘行人局部关键信息的同时弥补丢失的关联信息，使得关联局部特征更加有利于进行行人重识别。




图 3-2 特征空间分割特性分析

3.2.2 网络架构

模型的总体结构沿用了 PCB 的骨架结构, 同时为充分利用位于各个相邻块间的重要信息, 本章所提模型结构如图 3-3 所示, 包括多分辨率的骨架网络、重叠条纹特征提取模块、组归一化 (GN) 模块和全连接 (FC) 层, 图中 D 表示特征向量的维数。骨架网络选用的是 ResNet-50 (Residual Network with 50 Parameter Layers), 由 4 个卷积块 $Conv_i$ 组成, 其中 $i=1,2,3,4$, 该网络结构具有更深的层, 能够提取行人更多的外观和语义特征, 并且能够保证较高的特征提取效率。本章对该骨架网络进行了修改: (1) 为获得尺寸恰当的行人特征图, 删除 ResNet-50 的全局平均池化层 (GAP) 及其后的所有层; (2) 为方便分块操作并且有利于提取行人局部信息, 设定第四个卷积块 $Conv_4$ 中的 $Conv_{4_1}$ 的步长为 2, 此时特征图的尺寸扩大 2 倍。骨架网络输出的特征图 T 经过重叠条纹特征提取模块后, 共获得 11 个条纹特征向量 $g_j (j=2,3,4)$ 。

训练阶段, 串联 11 个条纹特征向量 $g_j (j=2,3,4)$ 为特征描述符 G , 并同时使用中心损失函数和三元组损失函数对 G 进行监督优化; 为了克服过拟合问题并提高模型的性能, 将特征向量 $g_j (j=2,3,4)$ 分别送入组归一化模块 (GN 层) 得到特征向量 $h_j (j=2,3,4)$; 将 h_2 、 h_3 和 h_4 分别送入不共享权重的 FC 层, 然后通过交叉熵损失函数根据行人的身份标签对 FC 输出的向量进行监督优化。测试阶段, 仅使用特征描述符 G 来进行相似性判断, 即把 GN 层之前的 11 个 512D 的向量融合成一个新的向量, 通过欧氏距离度量方法, 查询图像使用新向量与图库中图像进行相似度匹配。具体为, 网络模型接收查询图像和候选图像并输出各自的局部特征, 然后将各自的局部特征串联得到两个新特征, 再通过欧式距离函数计算出这两个新特征的相似程度, 最后按照相似度从大到小进行排序。




图 3-3 网络结构图

3.2.3 重叠条纹特征提取模块

由于行人数据集中存在大量的难样本,相比于使用单一的全局特征,采用更加精细的局部特征可以减少行人数据集复杂化的影响,而且这些关键的局部特征更具有代表性、判别力更强,是区分不同行人的重要判据。目前常用特征空间分割、骨骼关键点的匹配定位、嵌入注意力机制等方法提取行人的局部特征。基于特征空间分割的模型因其对图像遮挡或姿态变化的鲁棒性较强,在许多计算机视觉任务中均显示出了优越的性能,这也影响了行人重识别的发展方向。PCB 模型是最公认的基于特征空间分割的方法之一,其性能超过了大多数深度学习模型。但是,目前的 PCB 模型也存在一些缺点:(1) PCB 模型只考虑分割的特征,完全忽略了整体特征在整个网络中的作用;(2) PCB 模型的有效性取决于边界框的准确性,忽略了真实场景中不完全的图像监测和模型的边界框。本章方法采用多层多粒度操作来减少模型在精确边界框上的依赖。




图 3-4 与 PCB 模型比较

本章模型与 PCB 结构相似但有区别,如图 3-4 所示,PCB 根据人体的结构特征,将网络最后一层输出的特征图进行水平分割,但是由于分割后会出现行人结构特征无法对齐以及丢失局部关键特征信息的情况,因此设计提出图 3-4 (b) 所示的重叠条纹特征提取模块,对相邻条纹特征进行叠加操作,以弥补丢失的关联信息。该模块针对网络最后两层 $Conv_3$ 和 $Conv_4$ 的特征进行操作。局部条纹特征的数量对匹配准确度有一定的影响,数量少时,条纹特征中行人身体区域过大,网络不能更具有针对性地提取行人图像的空间特征信息;数量大时,切割操作会使表征相同空间信息的特征分布在不同区域,生成不完整的空间特征,不利于模型学习显著性特征。本章取条纹数为 6,条纹特征中的空间信息相对均衡,且在 2.3.2 节中也得到了证实。

如图 3-3 所示,重叠条纹特征提取模块首先接收来自多分辨率的骨架网络提取的特征图,将最后两个卷积块 $Conv_3$ 和 $Conv_4$ 的输出 (tensor T_3 和 T_4) 分别在竖直方向上水平分割为均等的 6 块 ($s=6$),通过使用重叠步长将相邻块成对地组合,并将全局平均池化


(GAP) 作用在重叠部件上, 从而共获得 $2 \times (s-1) = 10$ 个重叠条纹特征向量 (每个卷积块的输出对应获得 5 个条纹特征)。为了使卷积计算更快更高效, 使用 1×1 的卷积核将这 10 个特征向量分别进行降维操作得到特征向量 g_3 和 g_4 。 T_j 到 $g_j (j=3,4)$ 的计算过程为

$$g_{m,n} = \frac{1}{2}(T_{m,n} + T_{m,n+1}), \quad (3.1)$$

其中 $m=3,4$, $n=1,2,3,4,5$ 。

此外, 本章模型增加了行人的整体特征, 将第二个卷积块 $Conv_2$ 得到的全局特征 (tensor T_2) 直接通过全局平均值池化和降维操作得到特征向量 g_2 。最终共得到 11 个条纹特征向量。这些特征向量中包含多个多尺度的局部特征和全局特征, T_3 和 T_4 包含了足够丰富的语义信息, T_2 提供的低层全局特征能够有效区分细节信息, 对分类结果产生积极的影响。

如图 3-5(a) 和(b) 所示, 同一行人的两张图像经过水平分割后, 最后一个分块将空地 (遮挡物) 和小腿对齐, 如果直接进行分类预测将会匹配失败; 但是经过该模块后, 对应的分块中均包含小腿特征, 在进行分类预测时能够很大程度上减小特征不对称所导致的度量差异。行人的大部分特征在经过该模块后, 又得到了二次的加强利用。因此, 该模块能够充分利用到块间的重要信息从而有效减少行人结构无法对齐所带来的影响。



(a) 目标行人尺寸不一致



(b) 目标行人部分被遮挡

图 3-5 重叠条纹特征提取模块示例

3.2.4 多损失函数优化

采用随机梯度下降法 SGD 实现组合损失函数的最小化, 训练过程中每种损失函数根据被赋予的权重值优化不同的特征向量, 随着迭代和反向传播次数的增加, 最终达到损失和的最小。SGD 算法是从样本中随机抽出一组, 训练后参数按梯度反向传播更新一次, 然后再抽取一组, 再更新一次, 在训练完所有的样本就可以获得一个损失值最小的模型。

行人重识别最终要判定出行人的所属类别, 并使行人样本在其所属的样本空间中分布紧密, 使网络能明显区分不同的样本空间, 因此同时使用了分类损失函数和三元组损失函数, 这可以满足模型对效率和精度的要求。其中三元组损失函数是一种样本聚类手段, 将正负图像样本对分别映射到特征空间, 通过最小化三元组损失函数可以缩短正对间距并拉大负对间距, 使同类间距在一定范围内相对小于异类间距, 从而保证同类的紧密性以及不同类的分离性, 进而使网络的分类层更准确地找到它们的类别边界。但是由于三元组损失函数只考虑到了 d_p 和 d_n 之间的差值而忽略了二者的绝对值, 因此三元组损失对于同类别间的距离约束较弱。为减小这类影响, 引入中心损失函数, 也应用于特征描述符 G , 从而使特征空间中的特征分布更加紧凑, 加强类内样本分布的紧密性。在训练过程中, 中心损失可以不断地优化网络, 直至学到各类别深度特征对应的中心向量, 同时最小化同类别中其余特征与类别中心的间距, 达到紧凑同类别分布的目的。

联合多种损失函数, 能够帮助网络模型学习到鲁棒性更强的行人特征。在训练阶段, 组合三种不同的损失函数, 包括三元组损失(Triplet Loss)^[54], 中心损失(Center Loss)^[55]和交叉熵损失(Cross-entropy Loss)。本章采用最小化组合损失函数的方式约束并优化网络。首先将三元组损失应用于特征描述符 G , 三元组损失函数为

$$\begin{cases} L_{\text{triplet}} = \sum_{i=1}^P \sum_{a=1}^K [\alpha + d_p - d_n]_+, \\ d_p = \max_{p=1 \dots K} \|G_a^i - G_p^i\|_2, \\ d_n = \min_{\substack{j=1 \dots K \\ n=1 \dots K \\ i \neq j}} \|G_a^i - G_n^j\|_2, \end{cases} \quad (3.2)$$

其中 P 是批次中的身份数量, K 是批次中相同身份的图像数量, α 是损失余量, 本章 $\alpha = 0.3$, G_a 为固定样本对应的特征向量, G_p 为与固定样本为同一身份的正样本对应的特征向量, G_n 为与固定样本不同身份的负样本对应的特征向量, d_p 为 G_a 与 G_p 间距离, d_n 为 G_a 与 G_n 间距离, $\|\cdot\|_2$ 表示欧氏距离的计算。中心损失函数的公式为

$$L_{\text{center}} = \frac{1}{2} \sum_{i=1}^m \|G^i - c_{y_i}\|_2^2, \quad (3.3)$$

其中 m 是批处理大小, y_j 是一个批次中第 j 张图片标签, c_{y_i} 是第 y_i 个类别的特征中心向量。然后对局部特征向量 h_j 的每个条纹特征向量计算交叉熵损失以实现最终的分类, 交叉熵的本质是使样本在正确类别上的评分最大。交叉熵损失函数为

$$L_{cross} = -\sum_{i=1}^m \ln \frac{e^{W_{y_{ik}}^T h_{ik}^i + b_{y_{ik}}}}{\sum_{c=1}^C e^{W_{ck}^T h_{ik}^i + b_c}}, \quad (3.4)$$

其中 m 是批次大小, C 是训练集中的类别数, x_{ik} 为批次中第 i 张图片的第 k 个局部向量, y_{ik} 为 x_{ik} 对应的标签, W 是 x_{ik} 对应的最后内积层的权重向量, b 是偏差。所有交叉熵损失的平均值即为总的交叉熵损失

$$L'_{cross} = \left(\frac{1}{2 * (s-1)} + 1 \right) \sum_{j=3}^4 \sum_{l=1}^{s-1} L_{cross}^{j,l}. \quad (3.5)$$

总损失值由公式(3.2)、(3.3)和(3.5)的加权总和计算得出, 其中三元组损失和交叉熵损失保持相同的优先级。总损失函数为

$$L = L_{triplet} + \beta L_{center} + L'_{cross}, \quad (3.6)$$

其中 β 是中心损失所占权重, 本章取 $\beta=0.001$ 。

3.2.5 组归一化模块

本章采用多种损失函数对模型进行监督优化, 提高了网络模型对特征的学习能力, 但是当交叉熵损失函数和三元组损失函数共同作用时, 二者采用不同的计算方式, 优化目标出现差异, 会导致特征数据的分布异常。如图 3-6 所示, 以三分类为例, 交叉熵损失函数经改进后使用余弦距离进行度量, 通过构造超球面的方式, 嵌入特征空间被分成了 3 个不同的子空间, 3 种类别中的每个特征都被映射为超球面上的点, 这样每个类别的特征会被分配到不同的子空间。三元组损失函数则采用欧氏距离进行度量。当这两种损失函数对网络中的同一个特征向量进行监督时, 二者优化方向的差异可能使得训练过程中一个损失减小, 而另一个损失震荡发散, 最终导致整个训练过程中损失的收敛难度变大。




图 3-6 不同损失监督下样本分布二维可视化图

在深度学习领域, 混用不同的网络约束易使图像数据中出现奇异样本数据, 从而造成训练时间过长以及损失无法收敛的问题。这是由于不同的约束采用了不同的评价方法, 具有不同的量纲。为消除上述影响, 需要对数据进行归一化^[56]。最初, 网络结构基本只包括一个或者两个隐藏层, 仅对输入数据进行归一化。随着网络结构的深度不断提高,

Ioffe 等人将 BatchNorm 算法应用到了中间层^[57]，只需计算整个输入或者随机选取的小批次的均值和方差，提取的矩就会显示出不含预测信息的数据集中数据分布的偏差，移除该偏差能够很大程度改善网络模型的优化和泛化能力。最近提出的归一化方法将每个训练实例的特征视为一个分布，并分别对每个样本进行归一化^[58]。

为了解决图 3-6 显示的问题，提出了组归一化层结构 (GN 层)。如图 3-7 所示，图中 GN 层之前的特征向量记为 f_t ，GN 层之后的特征向量记为 f_i 。在训练阶段， f_t 用于计算三元组损失和中心损失， f_i 用于计算交叉熵损失。组归一化可以使得向量 f_t 中分布异常的特征趋于平稳，使其在超球面更接近于高斯分布，不仅保证了同类别特征的分布更加紧密，而且提高了交叉熵损失的收敛速度。GN 表示为

$$\begin{cases} \hat{x}_i = \frac{1}{\sigma_i} (x_i - \mu_i), \\ \mu_i = \frac{1}{m} \sum_{k \in S_i} x_k, \\ \sigma_i = \sqrt{\frac{1}{m} \sum_{k \in S_i} (x_k - \mu_i)^2 + \varepsilon}, \\ S_i = \left\{ k \mid k_N = i_N, \left\lfloor \frac{k_C}{C/G} \right\rfloor = \left\lfloor \frac{i_C}{C/G} \right\rfloor \right\}, \end{cases} \quad (3.7)$$

其中 x_i 为网络某层计算出的特征， i 为索引 $i = (i_N, i_C, i_H, i_W)$ ， S_i 是计算平均值 μ_i 和方差 σ_i 的像素集合，该集合大小为 m 。 G 是分组数目， C/G 为每组的通道数，

$\left\lfloor \frac{k_C}{C/G} \right\rfloor = \left\lfloor \frac{i_C}{C/G} \right\rfloor$ 表示索引 i 和 k 在同一组同道中。




图 3-7 组归一化模块

3.3 实验结果及分析

3.3.1 数据集与评估指标

本章在 2.4.2 节提及的 Market-1501 和 DukeMTMC-reID 两个大规模数据集上进行实验，评估指标采用 mAP 值和 CMC 曲线。在实验结果中以 Rank-K 表格的数值形式表

示 CMC, $K=1,5,10$ 。此外,所有的实验结果和对比结果均使用第二章 2.1.1 节提到的单张 query 检索配置。

3.3.2 实验配置及参数

本章使用的深度学习框架 Pytorch-1.0.1, 操作系统 Ubuntu16.04, 显卡内存为 8G 的 NVIDIA GTX 1070 GPU, CUDA 版本 10.1。

实验所用的骨架网络为修改后的 ResNet-50 并经过了权重初始化, 输入行人图像的分辨率大小调整为 256×128 。由于神经网络对数据的需求量大, 在训练中加入数据增强是一种广泛采用的技术, 不仅可以扩大数据集, 还能提高模型的泛化能力; 另一方面, 聚合多个增强样本的预测结果可以进一步提高模型性能。因此本章提取原始输入图像及其水平翻转变体的嵌入特征, 其尺寸为 $24 \times 12 \times 2048$ 。该特征图在经过条纹特征提取模块和组归一化之后将输出 10 个 512 维的特征向量。

在训练过程中, 采用随机梯度下降法 SGD 对每一个 batchsize 进行参数的优化和更新, 动量为 0.9, 权重衰减系数为 0.0005, 经实验验证 batchsize 大小最终设置为 64。使用 warmup 策略对学习率进行预热以激活网络, 初始学习率为 0.0003, 为了保持损失的稳定下降, 分别在 40 代和 70 代两个阶段分别设置学习率衰减点, 衰减系数为 0.1, 呈指数形式衰减, 模型总共训练 120 代。对组归一化层输出的每一个特征向量采用单独分类方式, 然后将各损失加和作为模型的总损失。推理阶段, 融合组归一化层之后的 11 个特征向量为新向量, 测试图像与候选图像均使用新特征向量计算欧氏距离并排序。整个实验过程中不使用能够显著改进 mAP 的重新排序算法。

3.3.3 实验分析

本小节将对每个模块进行消融实验验证与分析, 并通过消融实验选取出最优的模块组合。分别有多损失函数优化、不同分块和不同批尺寸对模型的影响。

(1) 多损失函数优化

为了测试多损失联合训练和组归一化模块的有效性, 本章分别在 Market-1501 和 DukeMTMC-reID 数据集上进行了消融实验, 结果分别如表 3-1 和表 3-2 所示, 其中基准模型 baseline 对应的是仅使用交叉熵损失函数训练的全局特征模型。

对于 Market-1501 数据集, 对比两种损失联合优化的模型, 三种损失联合优化的模型的 Rank-1 精度值有 1.2 个百分点的提升, mAP 精度值有 2.3 个百分点的提升。三种损失联合优化的模型在加入组归一化 (GN) 模块后, 模型的 Rank-1 精度有了 2.0 个百分点的提升, mAP 精度值提高了 1.2 个百分点。本章所提模型相对基准模型 baseline 在 Rank-1 精度值有了 5.2 个百分点的提升, 在 mAP 精度值上有了 9.1 个百分点的提升。

对于 DukeMTMC-reID 数据集, 对比两种损失联合优化的模型, 三种损失联合优化的模型 Rank-1 精度提高 0.8 个百分点, mAP 精度提高了 0.4 个百分点。三种损失联合优化的模型在加入组归一化 (GN) 模块后, 模型的 Rank-1 精度有 1.3 个百分点的提升, mAP 精度有 1.1 个百分点的提升。本章所提模型相对基准模型 baseline 在 Rank-1 精度有 3.1 个百分点的提升, 在 mAP 精度上有 6.8 个百分点的提升。

表 3-1 Market-1501 上不同策略的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	89.3	94.8	98.2	74.5
cross-e+triplet	91.3	95.6	98.5	80.1
cross-e+triplet+center	92.5	96.1	98.6	82.4
cross-e+triplet+GN	93.2	96.6	98.8	82.9
cross-e+triplet+center+GN	94.5	97.2	99.1	83.6

表 3-2 DukeMTMC-reID 上不同策略的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	80.6	84.7	89.0	65.2
cross-e+triplet	81.6	85.6	89.8	70.5
cross-e+triplet+center	82.4	87.3	91.1	70.9
cross-e+triplet+GN	82.9	87.5	91.3	71.4
cross-e+triplet+center+GN	83.7	88.9	92.4	72.0

从实验数据可以看到,使用了中心损失函数的行人重识别模型的识别精确度有很大提升,这表明中心损失函数能够有效地约束同类别样本间的距离。由于不同到的损失函数采用了不同的评价方法,其对特征的优化目标自然也不同。网络在不同损失函数的约束下,提取到的特征判别信息也将有所区别,因此合理地组合不同的损失函数获得了行人特征中更多的信息。组归一化在保证特征的分布规律的前提下,对分布异常的特征进行了约束,对于多损失联合优化的模型有很大助益。总的来说,三种损失联合训练可以使模型学习到鲁棒性更强的特征,组归一化模块对于减弱损失函数间的优化冲突效果明显。

(2) 不同分块的模型对比

本章根据人体结构对骨架网络输出的行人特征图进行了分块操作,经过实验验证,将行人特征图均分为 6 块 ($s=6$) 为最佳。如表 3-3 所示,其中 baseline 对应的是仅使用交叉熵损失训练的全局特征模型。从表中数据可以看出,采用切块提取局部特征的方法比仅使用全局特征的方法在 Rank-1 精度和 mAP 上都有明显的提高,且随着重叠条纹数 ($s-1$) 的增加,模型精度也有所提升。这是由于局部特征包含的是行人身体局部区域的关键特征,而全局特征可能仅包含行人全身的一个最显著特征,因此局部特征的组合相比于全局特征包含了行人更多的具有区分性的特征,有更强的辨别能力。但是在 $s=7$ 或 8 时,精度不升反降,是因为随着分割区域的增加,行人特征的错位分布会更加明显,从而导致越小尺寸的条纹特征越易受到该区域异常值的影响,最终降低模型的总体识别效果。

(3) 不同批尺寸的模型对比

三元组损失中,批尺寸 $\text{batchsize}=P \times K$,有研究表明随着批尺寸的增加,模型精度也

不断提高。因为大的 `batchsize` 有助于三元组损失更好地挖掘“难样本对”以约束不同类别之间的距离^[59]，但是该规律并不适用于本章所提算法。如表 3-4 所示，随着 `batchsize` 的增加，模型精度的提升并不明显，这是因为加入了组归一化 (GN) 模块，GN 计算的是通道方向上每组数据的均值和方差，与批尺寸 `batchsize` 无关，所以模型精度基本不会因为 `batchsize` 的变化而受影响。因此，即使 `batchsize` 受限，本章所提算法也能够保证模型的精度。

表 3-3 Market-1501 上不同分块的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	89.3	94.8	98.2	74.5
s=4	90.2	94.9	97.8	75.6
s=5	92.4	95.4	98.0	77.5
s=6	94.5	97.2	99.1	83.6
s=7	93.0	96.8	98.4	81.8
s=8	92.5	95.4	98.1	81.2

表 3-4 DukeMTMC-reID 上不同批尺寸实验结果

batchsize	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
20	84.4	88.3	92.3	72.9
40	84.4	88.7	92.2	72.9
60	84.8	88.9	92.4	73.0
80	84.6	88.8	92.4	72.9
100	Out of memory			

3.3.4 不同基准网络下的方法比较

第一章第 1.3 节中提到，如果基准网络达到很高的精度，且兼容速度与性能，那么一个新方法的有效性也更加能够被大家所认可。为了验证这一想法，本节提出基于 OSNet 骨架网络的多层级重叠条纹特征融合的行人重识别方法，并在两个数据集上进行实验验证。

轻量级全尺度网络 OSNet (Omni-Scale Network) 解决了全尺度特征学习问题，通过学习图像中同质尺度和异质尺度特征，并将其进行任意地组合构成全尺度特征，使网络模型能够更优地提取目标特征^[49]。其中同质尺度特征为网络模型对全局图像的整体把握和理解，异质尺度特征为网络模型对图像中中小目标的局部特征的捕获和学习。

OSNet 的基本单元如图 3-8 (d) 所示，通过堆叠不同数量的 Lite3×3 结构，学习不同尺度的单尺度特征，再通过共享权重的统一聚合门 AG 组合这些单尺度特征为全尺度特征，并将输入部分恒等映射至输出，保证了前层网络学习到的相对小的尺度特征能够有效地保留至下一层，从而使整个网络模型所学的特征能够覆盖到整个空间尺度范围。其

中 Lite3×3 结构如图 3-8(b)，将子图(a)中的标准 3×3 卷积替换为点卷积 Conv1×1 和深度卷积 DW Conv3×3 的组合，通过这种卷积的分解操作，网络可以将其对空间相关性和通道相关性的学习分解开，从而更有效地进行全尺度的特征学习；Lite3×3 结构的数量 t 决定了所学单尺度特征的尺度大小 $(2t+1) \times (2t+1)$ ，例如子图(c)输出的特征尺度为 3×3；子图(d)中每个分支学习不同单尺度特征，再由可学习的统一聚合门动态地组合这些特征，为每个尺度赋予不同的权重，这样可以产生更细粒度的融合，可以对每个特性通道进行调优，是一种自适应的特征尺度融合策略。OSNet 是为行人重识别任务专门设计的可伸缩性强、计算成本小且性能更好的基准深度卷积网络。




图 3-8 OSNet 的全尺度残差块示意图

本节实验除了所采用的的骨架网络不同，其余设置均与 3.3.2 节保持一致并进行了定量定性的分析。实验结果如表格 3-5 所示，以 OSNet 作为骨架网络的模型在评价指标 Rank-1 和 mAP 上优于以 ResNet-50 为骨架网络的模型。为了更直观地感受基准网络对所提方法的影响，图 3-9 展示了不同骨架网络下模型的检索排序图，给出了前 5 个检索

结果,结果显示以 OSNet 为骨架网络的模型所得正确匹配结果优于以 ResNet-50 为骨架网络的模型。从第一个行人的检索结果看,两个网络的误检结果和检索对象都身穿白色 T 恤黑色短裤,但以 OSNet 为基准的网络能关注到更加精细的特征,即行人 T 恤上胸前的黑色图案,在该特征的辅助下网络的识别准确度有所提高。这表明 OSNet 主干提取的全尺度特征包含的判别信息要多于 ResNet-50 提取的特征,也进一步说明基准网络性能越高,在采用相同方法进行行人重识别时,模型的识别准确度越高,模型表现越好。因此论文后续的研究会选择以 OSNet 为主干网络提取行人特征。

表 3-5 在不同基准网络下的评价指标比较

模型所用的骨架网络	Market-1501		DukeMTMC-reID	
	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
ResNet-50	94.5	83.6	84.8	73.3
OSNet	95.1	86.4	88.9	78.6

骨架网络	query	1	2	3	4	5
ResNet-50						
OSNet						
ResNet-50						
OSNet						

图 3-9 不同基准网络下模型的检索排序图

3.3.5 与现有方法的比较

为了验证本章算法 (ResNet-50 为骨架网络) 的先进性,将其与现阶段表现较突出的 7 种行人重识别算法对比,各类算法的 Rank-1 精度和 mAP 如表 3-6 所示,所有结果中金字塔模型^[64]表现最好,但是该算法包含了 21 个不同尺度的局部特征分支,模型较复杂,训练过程占用较多的资源,使得计算效率较低。除此模型外,所提算法的识别准确度优于其他对比方法(用下划线标出),其中 PCB*表示本文复现的 PCB 模型,在第二章有所提及。对于 Market-1501 数据集,本章方法得到的 Rank-1 精度和 mAP 分别为 94.5%和 83.6%。在对结果应用重排序算法 Re-ranking 后,Rank-1 精度和 mAP 各自有 0.8/7.8 个百分点的提升。对于 DukeMTMC-reID 数据集,本章所提方法得到的 Rank-1 精度和 mAP 分别为 84.8%和 73.3%。在对结果应用重排序算法 Re-ranking 后,Rank-1 和 mAP 精度值有 3.6/5.3 个百分点的提升。图 3-10 给出了本章所提方法在 Market-1501

测试集上的部分行人的前 10 个检索匹配结果排序图。从匹配结果中可以看到，行人姿势差异大的情况比较明显，且排序图像内光照明度不同，但行人也都被正确识别出来，说明本章网络可以较好地应对图像较明显的照度和行人姿态的变化；对于图中第二行，行人头部缺失的图像被正确识别，虽然排序比较靠后，但也在一定程度上表明该网络可以应对遮挡情况。第三行的结果中有错误检索，但观察到错误结果中行人手提白色包包，与检索图像一致，表示网络对白色包包这个局部特征关注度更大。因此该方法具有较强的鲁棒性和判别力，模型能够较好地应对行人姿态的变化、部分物体的遮挡和较明显的照度变化。

表 3-6 在 2 个数据集上与主流算法的比较

模型	Market-1501		DukeMTMC-reID	
	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
DaRe-Net[11]	89.0	76.0	80.2	64.5
HA-CNN[60]	91.2	75.7	80.5	63.8
GLAD[61]	89.9	73.9	-	-
PSE[62]	87.7	69.0	79.8	62.0
AWTL[63]	89.5	75.7	79.8	63.4
Pyramid[64]	95.7	88.2	89.0	79.0
PCB+RPP[14]	93.8	81.6	83.3	69.2
Our baseline	86.8	69.6	72.6	54.9
PCB*	88.5	69.9	80.3	64.3
本章算法 (OSNet)	95.1	86.4	<u>88.9</u>	<u>78.6</u>
本章算法 (ResNet-50)	94.5	83.6	84.8	73.3
本章算法 (ResNet-50) + Re-ranking	<u>95.2</u>	<u>91.4</u>	88.4	<u>78.6</u>



图 3-10 本章模型在 Market-1501 数据集上部分测试结果

3.4 本章小结

本章为解决现有的行人重识别方法在提取行人局部特征时存在的信息缺失的问题，提出了一种多层次重叠条纹特征融合的行人重识别算法。使用重叠条纹特征提取模块，弥补了在提取行人局部特征时丢失的信息；加入组归一化模块，减弱了不同损失函数在优化监督时的冲突影响；结合低层的全局特征，使网络模型能够有效区分细节信息。本章方法在两个公开数据集的实验结果表明该算法能够有效提高行人重识别的准确度。

实验过程中，对整幅图像提取局部特征时会受到复杂背景的影响以及前景遮挡的干扰。在今后的研究过程中，将考虑通过网络模型分离出图像中行人的可见部分，并用该部分进行检索，进一步提升模型的行人重识别能力。

第四章 异构分支关联特征融合的行人重识别

4.1 引言

上一章模型采用空间分区的方法，在空间尺度上将行人特征图切割为若干局部显著性区域，鼓励模型去学习不同区域的特征差异性，并强制每个区域满足独立的 ID 预测损失。这种做法能够简单直观地细化特征，加强特征的鲁棒性。另外，上一章模型直接把全部的局部特征串联以得到行人的结构化特征。这虽然能在一定程度上解决姿态多样等问题，但没有顾及局部区域之间的内在联系，可能降低具有相似属性的不同行人在对应部位的区分度。

空间分区策略下的单分支网络在性能达到瓶颈时，有研究者通过构建具有多个分支的网络模型提高空间分区模型的重识别效果，例如全局特征分支和局部特征分支。Yao 等人提出的零件损失网络 PL-Net 通过引入零件损失自动检测人体部位，并计算每个零件的分类损失，以影响全局分支的特征表达^[65]。Wang 等人设计了一种整合全局特征和局部特征的多粒度模型 MGN (Multiple Granularity Network)，包括一个全局分支和两个局部分支，MGN 通过将特征图划分成多个条纹特征图，并且改变不同分支的条纹数量来获得多粒度局部特征表示^[15]。在研究过程中发现，对于采用多个分支的模型，全局特征主要关注背景信息，而局部特征可融合人体关键特征。但其缺点在于每个分支均使用同构特征，即这些特征均复制自全局分支的高层，使模型缺乏结构多样的差异特征。

针对上述问题，本章采用多分支的网络结构，并考虑空间分区后局部特征之间的关系以及差异性特征缺失的问题，提出了异构分支关联特征融合的行人重识别算法。本章网络模型包括一个提取行人外观特征的骨架网络和 3 个分支子网络。骨架网络为 OSNet 与注意力机制的结合，以学习到具有更强显著性和区分性的行人关键特征。将分支网络输出的行人特征进行水平均等分割，再提取关联条纹特征，从而全面利用位于条纹间的综合信息；设计异构特征提取模块，以增加模型学习差异特征所需的结构多样性；最后融合每个分支的输出特征为行人最终的特征表示，对行人最终的特征表示计算欧氏距离得到相似度和识别结果。

4.2 模型设计

在本节中，主要分为 5 个部分设计异构分支关联特征融合的行人重识别网络，首先给出文章网络的总体结构，再分别详细地推导网络的几个集成部分，包括注意力模块、条纹特征关联模块、异构特征提取模块和损失函数。

4.2.1 网络总体结构

图 4-1 为本章所提的模型结构，包括 3 个网络分支，分别为全局分支 (v1)、条纹特征关联分支 (v2) 和异构特征提取分支 (v3)，图中 D 表示特征向量的维数。骨架网络采用 OSNet，包括 5 个卷积块 $Conv_i (i=1,2,3,4,5)$ 。OSNet 是支持全尺度特征学习的轻量级网络，保证较高的特征提取效率，并且能够有效地捕获不同感受野范围下的尺度特征。

为了学习图像中更值得关注的关键信息，在 OSNet 的 $Conv_2$ 和 $Conv_3$ 层分别添加空间注意力模块(Spatial Attention Module, SAM) 和通道注意力模块(Channel Attention Module, CAM)。骨架网络的输出特征图被复制为 3 份作为 3 个分支子网络的输入。




图 4-1 本章网络架构

(1) 全局分支。由 OSNet 的 $Conv_5$ 组成，且仅使用全局最大池化 GMP (Global Max Pooling)，GMP 可以促使网络识别相对较弱的显著特征，以保证全局分支与其他分支之间的功能多样性。全局分支获得 1 个 512D 的特征向量 g_1 。

(2) 条纹特征关联分支。通过条纹特征关联模块将不同的条纹特征进行关联计算，以加强条纹间信息的相关性，进而最优地学习并整合局部特征信息。条纹特征关联分支最终获得 1 个 2048D 的特征向量 g_2 。

(3) 异构特征提取分支。将 OSNet 的 $Conv_5$ 替换为网络 ResNet-50 的 $Conv_2$ 、 $Conv_3$ 和 $Conv_4$ ，以学习更具结构多样性的特征。共享卷积网络输出的特征图经过全局分支，获得 1 个 512D 的特征向量 g_1 ；经过条纹特征关联分支和平均池化 AP (Average Pooling)，获得 8 个 256D 的关联特征向量 $f_i (i=1,2,\dots,8)$ ，再串联为特征向量 g_2 ；经过异构特征提取分支和降维操作，获得 1 个 512D 的特征向量 g_3 。

训练阶段，对 3 个特征向量 $g_j (j=1,2,3)$ 分别使用 ID 预测损失函数、中心损失函数和三元组损失函数进行监督优化。测试阶段，将特征向量 $g_j (j=1,2,3)$ 串联为特征描述符 G ，并使用特征描述符 G 进行相似性判断。

4.2.2 条纹特征关联模块

局部特征的使用降低了数据集中行人样本复杂化的影响，且这些关键的局部特征更

具代表性、更有助于网络模型区分不同的行人。

本章提出的算法根据人体的结构特征，按照 PCB 结构将分支网络 v2 输出的特征图进行水平均等分割，由于分割后的条纹相互独立，且每个条纹仅包含自身的信息，当每个条纹不与其他条纹进行通信时，如果直接将这局部特征单独用于行人检索，会混淆具有相似属性的不同行人在相应部位的区分度。因此设计提出条纹特征关联模块，该模块考虑了行人身体各个部位与其他部位之间的关系，使每个条纹特征都包含了对应部位本身和其他部位的综合信息，更具鉴别力。如图 4-1 所示，条纹特征关联模块接收来自所在网络分支提取的特征图，将最后一个卷积块 Conv_5 的输出特征图在竖直方向上水平分割为均等的 8 块，通过条纹间的关联计算依次将每个条纹与其他条纹进行通信，从而获得 8 个关联条纹特征向量，并将平均值池化 AP (Average Pooling) 作用在所得的关联条纹特征上。

条纹特征关联模块计算过程示例如图 4-2 所示，首先选中其中一个条纹特征向量 $f_i (i=1,2,\dots,8)$ ，尺寸为 $1 \times 1 \times C$ ，将平均值池化 AP 作用于其余 7 个条纹特征向量 $f_j (j \neq i)$ ，以获取向量 $g_l (l=j)$ 为其余部件的综合信息；然后将 1×1 的卷积层用于向量 f_i 和 g_l ，以减小通道数至 c ，并产生尺寸为 $1 \times 1 \times c$ 的向量 $\bar{f}_i$ 和 $\bar{g}_l$ 。条纹特征关联模块连接特征 $\bar{f}_i$ 和 $\bar{g}_l$ ，并且为每个 f_i 输出一个关联特征向量 $q_i (i=1,2,\dots,8)$ 。此时每个特征 $q_i (i=1,2,\dots,8)$ 均包含了行人的全部信息。关联计算过程表示为

$$g_l = \frac{1}{7} \sum_{j \neq i} f_j, \quad (4.1)$$

$$q_i = \bar{f}_i + B_p \left(C_a \left(\bar{f}_i, \bar{g}_l \right) \right) = c_{1 \times 1} f_i + B_p \left(C_a (c_{1 \times 1} f_i, c_{1 \times 1} g_l) \right), \quad (4.2)$$

式中 $i=1,2,\dots,8$ 且 $j \neq i, l \neq i$ 。 $c_{1 \times 1}$ 为 1×1 的卷积。 B_p 是一个子网络，包括一个 1×1 的卷积层、BN 层和 ReLU 层； C_a 表示特征的串联。 $B_p \left(C_a \left(\bar{f}_i, \bar{g}_l \right) \right)$ 能够使局部的条纹特征 $\bar{f}_i$ 对遮挡与几何变化更具辨别性和鲁棒性。特征关联模块通过线性方式计算特征 q_i ，计算成本低的同时保持了特征表示的紧凑性。




图 4-2 条纹特征关联模块


4.2.3 异构特征提取模块

结合全局特征和局部特征的多分支行人重识别网络能够同时关注行人的轮廓信息和细节信息，但目前很多网络的不同分支使用的均是同构特征，是从骨架网络的输出复制的，不具备多样性，导致整体模型特征单一，缺乏结构多样的差异特征，加大了识别的难度。因此增加异构特征提取分支，以关注其它分支未能注意的特征，从而增强网络学习差异特征的能力，同时使其更具有判别力。具体做法是采用与骨架网络不同结构的网络继续提取分支特征，本节采用的是 ResNet-50 网络的一部分。具体为：异构特征提取分支将 OSNet 的 $Conv_5$ 替换为 ResNet-50 的 $Conv_{2,3,4}$ 。其中 ResNet-50 的每个残差卷积块 block 均由不同数量的卷积层与恒等跳跃连接的残差块构成，如图 4-3 (a)，每个残差块均由 3 个卷积层 ($1\times 1, 3\times 3, 1\times 1$) 堆叠而成，其中两个 1×1 的卷积调整维数， 3×3 的卷积对图像进行降采，设置其中的卷积参数，以保证其输出特征图与输入具有相同的尺寸，方便后续的线性操作，保证网络深层的梯度值能够有效地传递至网络浅层，以避免深度网络的退化和梯度弥散问题。对于输入张量 $X \in R^{H*W*C}$ ，经残差块后对应的输出 Y 为


$$\begin{aligned}
 Y &= F^{res}(X, W^{res}) \\
 &= W_3^{res} \bullet \delta(W_2^{res} \bullet \delta(W_1^{res} \bullet X)) \\
 &= W_3^{res} \bullet \left\{ \sum \frac{1}{1+e^{-z}} (x-i+0.5) \left(W_2^{res} \bullet \left[\sum \frac{1}{1+e^{-z}} (x-i+0.5) (W_1^{res} \bullet X) \right] \right) \right\} \quad (4.3) \\
 &= W_3^{res} \bullet \left\{ \max(0, x + N(0,1)) \left(W_2^{res} \bullet \left[\max(0, x + N(0,1)) (W_1^{res} \bullet X) \right] \right) \right\},
 \end{aligned}$$

式中 F^{res} 表示残差函数， W_1^{res} 、 W_2^{res} 、 W_3^{res} 分别表示 1×1 、 3×3 、 1×1 卷积层的权重， $\bullet$ 表示卷积操作。

异构特征提取分支 v3 的特征提取过程如图 4-3 (b)所示，v3 分支接收来自骨架网络 OSNet 输出的特征图，并将其送入 ResNet-50 网络的 $Conv_{2,3,4}$ 层，再经过全局平均值池化 GAP 和全局最大值池化 GMP 得到一个 2048D 的特征向量。为了提高计算效率，使用 1×1 的卷积将得到的 2048D 的特征向量降维至 512D。对于输入张量 $X \in R^{H*W*C}$ ，经



(a) 不同卷积数量的残差块



(b) 异构特征提取分支

图 4-3 异构特征提取模块

v3 后对应的输出 F_o 为

$$\begin{cases} Y_{R1} = F_{res1}(X, W_{res1}), \\ Y_{R2} = F_{res2}(Y_{R1}, W_{res2}), \\ Y_{Ro} = F_{res3}(Y_{R2}, W_{res3}), \end{cases} \quad (4.4)$$

$$\begin{aligned} F_o &= C_{1*1}(G_m(Y_{Ro}) + G_a(Y_{Ro})) \\ &= C_{1*1}\left(\max_{x=1, y=1}^{w, h}(Y_{Ro}(x, y)) + \frac{1}{w \times h} \sum_{x=1}^w \sum_{y=1}^h Y_{Ro}(x, y)\right), \end{aligned} \quad (4.5)$$

式中 F_{res1} 、 F_{res2} 和 F_{res3} 分别为 ResNet-50 中 $Conv_{2,3,4}$ 层的网络表示； W_{res1} 、 W_{res2} 和 W_{res3} 分别为每层网络对应的权重； Y_{R1} 、 Y_{R2} 和 Y_{R3} 分别为 ResNet-50 中 $Conv_{2,3,4}$ 层的输出； G_m 表示全局最大池化 GMP； G_a 表示全局平均池化 GAP； C_{1*1} 表示一个降维子网络，包括一个 1×1 的卷积层、BN 层和 ReLU 层。


4.2.4 注意力模块

而由于行人重识别技术被应用于监控摄像头，通常真实的场景和使用的数据集是由模糊嘈杂的图像组成，现有的方法大多无法从图像中掌握深层的显著特征。为了建立一个更强的描述符来对抗这种退化，需要无噪声和独特的特征学习。骨架基准网络的特征提取能力越强，重识别模型的性能会越好。借鉴这一思想，本节在骨架网络中引入了注


注意力模块，以学习图像特征中一致的空间相关性和通道相关性，进而增强整体模型的特征提取能力。

在深度学习领域，注意力机制的使用普遍且广泛^[66-68]，类似于人类视觉习惯性地注视图像中某块能辅助判断的区域。而在深度学习行人重识别任务中，输入图像的某些区域可能比其他区域对目标任务更有用处。注意力机制鼓励模型自适应地关注与目标相关的输入的某些区域，帮助卷积神经网络 CNN (Convolutional Neural Networks, CNN) 将关注的重点放在输入的重要细节信息并抑制无用信息，使网络在保留主要信息的同时还可以关注到次要信息，进而从次要信息中寻找对特征图影响较大的部分，以此增强模型对局部区域中判别特征的关注度，进而使 CNN 对信息进行快速筛选，并总结高价值信息，提高信息处理与提取的效率和准确度。

卷积网络中低层网络提取到的更多是图像中的细节特征，高层网络提取的是全局的语义信息。由于低层特征图对高层特征图的生成至关重要，后者依赖于前者，因此只有低层网络的卷积核提取到行人更多的边缘特征，高层网络才能将该行人进行最佳的抽象映射。因此为了使模型发现图像中更具区别性的特征（颜色或纹理），而忽略与任务无关的其他特征（背景），本章在骨架网络 OSNet 中加入空间注意力模块 SAM (Spatial Attention Module, SAM) 和通道注意力模块 CAM (Channel Attention Module, CAM)。SAM 主要关注的是“在哪里”是有助于识别的特性。由于深度网络在提取特征过程中扩展了特征图的信道维度，CAM 可以找出从“哪些”通道能提取更有效的特征。



(a) SAM 模块的工作原理




(b) SAM 模块的流程示意

图 4-4 空间注意力模块 SAM


(1) 空间注意力模块 SAM

图 4-4 (a)为 SAM 的工作原理，先对骨架网络的输出特征图 T 进行局部建模，获得一个将显著信息的贡献数值化的注意力图 (Attention Map, AM)，再融合 AM 与 T 获取局部加权的特征。即 SAM 可以突出卷积网络的有效部分并抑制像素级背景杂波的干扰，

在空间域中捕获并聚合语义相关的像素点。如图 4-4 (b)所示, 本节使用 1×1 的卷积核, 将输入图像的通道数由 c 减少至 c/r , 以降低计算复杂度。但是单独使用 SAM 的模型会过度集中于图像前景, 而忽视低相关特征, 因此加入通道注意力模块 CAM。



(a) CAM 模块的工作原理



(b) CAM 模块的流程示意

图 4-5 通道注意力模块 CAM

(2) 通道注意力模块 CAM

卷积网络的输入图像通常为 R、G、B 三通道的形式, 在经过众多卷积核后产生更多的特征通道, 其中每一个通道都表示参与计算的卷积核所占有的不同分量, 因此每个通道对输出特征图的权重贡献各不相同。通道注意力图可以通过特征中的通道间关系生成, 如图 4-5 (a)所示, CAM 模块旨在压缩每个通道的权重为一个特征向量, 并组合具有相同语义信息的通道, 最后融合原始特征, 鼓励模型学习关键通道的特征^[30]。如图 4-5 (b)所示, CAM 模块普遍采用通道压缩-权重激活-重整权重 SER (Squeeze-Excitation-Reweight, SER) 结构。首先压缩每个通道的特征至一个 1×1 的二维矩阵, 在式 (4.6) 中将每个通道中的特征值加和后取平均, 获得通道中全局响应的二维矩阵表征形式

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j), \quad (4.6)$$

式中 z_c 、 u_c 分别为输入特征 u 和输出特征 z 的第 c 个通道。

然后根据式 (4.7), 对经过两次全连接层的特征的非线性响应进行激活强化, 获得激励后的通道注意力图。最后根据式 (4.8) 将通道注意力图与原始特征相融合, 以重新分配各个通道所占的权重。

$$s = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1 z)), \quad (4.7)$$

$$\tilde{x}_c = F_{scale}(u_c, s) = s_c u_c, \quad (4.8)$$

式中 δ 和 σ 分别为激活函数 ReLU 和 Sigmoid, W_1 和 W_2 为两层全连接层的权重矩阵。

4.2.5 损失函数

在全局和局部特征上联合多种损失函数训练本章模型有助于构建区分度更高、更稳健的行人外观表示。在训练阶段,组合三种不同的损失函数,包括 ID 预测损失 (Softmax Loss)、三元组损失 (Triplet Loss)^[54]以及中心损失 (Center Loss)^[55]。将组合后的损失应用于特征描述符 G , 本章采用最小化组合损失函数的方式约束并优化网络。组合后的总损失为

$$\begin{aligned}
 L &= L_{s-id} + \alpha L_{center} + \beta L_{triplet} \\
 &= -\frac{1}{N_s} \sum_{i=1}^{N_s} \log \left(\frac{\exp \left((W^{y_i})^T g_i + b_{y_i} \right)}{\sum_j \exp \left((W^j)^T g_j + b_j \right)} \right) + \alpha \frac{1}{2} \sum_{i=1}^{N_s} \|G^i - c_{y_i}\|_2^2 \\
 &\quad + \beta \sum_{i=1}^P \sum_{a=1}^K \left[\delta + \max_{p=1 \dots K} \|G_a^i - G_p^i\|_2 - \min_{\substack{j=1 \dots K \\ n=1 \dots K \\ i \neq j}} \|G_a^i - G_n^j\|_2 \right],
 \end{aligned} \tag{4.9}$$

式中 L_{s-id} 为单一 ID 损失, α 、 β 分别是中心损失和三元组损失所占的权重。 N_s 为一个批次中到的样本数目, P 是批次中的身份数量, K 是批次中相同身份的图像数量, δ 是损失余量, G_a 为固定样本对应的特征向量, G_p 为与固定样本为同一身份的正样本对应的特征向量, G_n 为与固定样本不同身份的负样本对应的特征向量, d_p 为 G_a 与 G_p 间的距离, d_n 为 G_a 与 G_n 间的距离, $\|\cdot\|_2$ 表示欧氏距离的计算, c_{y_i} 是第 y_i 个类别的特征的中心向量。

局部特征由于是从小部分区域提取出来的, 因此对错位和视角变化比较敏感, 三元组损失很难从具有大面积相似局部特征的难例样本对中正确匹配。例如, 当两个人穿着相似的黄色短袖时, 如果只关注上本身, 三元组损失函数很难正确区分, 会误认为二者是同一个人。因此本章仅将三元组损失用于约束全局特征。而 ID 预测损失有助于定位小部分区域中特定特征, 这使其更适合局部特征, 因此本章将 ID 预测损失用于约束局部特征。

在基于特征空间分割的行人重识别研究中, 大多数方法采用多重 ID 损失函数对行人身份进行预测。如图 4-6 所示, 输入的行人图像通过骨架网络进行特征提取得到张量 T , 在特征空间中 T 被均等划分为 n 条水平条纹, 再经过平均值池化和降维等操作生成 n 个特征向量 $g_i (i=1, \dots, n)$, 最后使用 n 个分类器以产生 n 个 ID 预测损失值。整体模型的损失值为这 n 个 ID 预测损失值的加和。多重 ID 损失函数 L_{m-id} 为

$$L_{m-id} = \sum_{p=1}^n L_{id}^p, \tag{4.10}$$

$$L_{id}^p = -\frac{1}{N_s} \sum_{i=1}^{N_s} \log \left(\frac{\exp \left((W_p^{y_i})^T g_p^i + b_{y_i} \right)}{\sum_j \exp \left((W_p^j)^T g_p^j + b_j \right)} \right), \tag{4.11}$$

式中 L_{id}^p 为第 p 个分类器产生的 ID 预测损失值, N_s 为样本数目, W_p 为特征向量 g_p 对应分类器的权重矩阵, W_p^j 和 $W_p^{y_i}$ 为权重矩阵 W_p 的第 j 列和第 y_i 列。




图 4-6 单一 ID 损失与多重 ID 损失

通过多重 ID 损失函数来监督每个条纹特征向量, 模型可以将局部区域的特征学习到最优以区分不同的行人。然而如图 4-6 所示, 许多条纹特征可能无法捕捉到不同行人的具有明显区分性的信息, 因此降低对行人整体的预测准确率。例如图 4-6 中将行人四等分, 由于两人都穿有黄色 T 恤和黑色短裤, 图中黄色和黑色在局部区域中更显著, 使得所提取的局部特征具有很高的相似性, 此时网络模型会认为这两张图像中对应的部分特征属于同一个行人, 这样就会增大两个行人总体相似度, 被网络认为是同一个行人的概率增大, 从而导致行人检索匹配错误。

为了更高效地利用模型学习到的局部显著性区域的判别特征, 本章将 n 个条纹特征向量串联成一个列向量 g 用于产生单一的 ID 预测损失值。单一 ID 预测损失函数 L_{s-id} 为

$$g = [g_1^T, g_2^T, \dots, g_n^T]^T, \quad (4.12)$$

$$L_{s-id} = -\frac{1}{N_s} \sum_{i=1}^{N_s} \log \left(\frac{\exp \left((W^{y_i})^T g_i + b_{y_i} \right)}{\sum_j \exp \left((W^j)^T g^j + b_j \right)} \right), \quad (4.13)$$

其中 W 是特征向量 g 对应分类器的权重矩阵, W^j 和 W^{y_i} 是权重矩阵 W 的第 j 列和第 y_i 列, N_s 为样本数目。

由于向量 g 包含输入图像中行人的完整信息, 使用单一 ID 损失函数可以驱动 g 学习并整合局部显著性区域中足够多的判别信息。

4.3 实验结果与分析

本小节采用的深度学习框架、操作系统、显卡内存、编程语言和实验数据集均与第三章相同。所有的对比结果均使用第二章 2.1.1 节提到的单张 query 检索配置。4.3.1 节介绍了实验参数的选择与设置; 4.3.2 节通过消融实验详细体现了最优的模块组合的选

择过程；4.3.3 节对关联特征提取模块输出的特征向量进行了可视化；4.3.4 节分别展示了本章网络模型和 OSNet 网络模型在测试集上的检索排序图并进行了对比；4.3.5 节为本章网络在 Market-1501 和 DukeMTMC-reID 两个数据集上的测试结果，与其他优秀算法在评估指标方面进行了对比。

4.3.1 实验参数设置

实验所用的骨架网络为结合注意力机制的 OSNet 并经过了权重初始化，输入的行人图像分辨率大小调整为 256×128 ，并应用了数据增强。输入图像经过骨架网络得到的特征图的大小为 $16 \times 8 \times 384$ 。该特征图在经过三个分支网络之后将输出三个不同维数的特征向量。

在训练过程中，本章实验使用 Adam 优化器^[69]。对每一个 batchsize 进行参数的优化和更新，batchsize 大小设置为 64，基础学习速率初始化为 $3.5e-5$ 。使用 warmup 策略对学习率进行预热以激活网络，初始学习率为 0.0003。为了保持损失的稳定下降，分别在第 60 代和 90 代两个阶段之后分别设置学习率衰减点，衰减系数为 0.1，呈指数形式衰减，模型总共训练 150 代。对三个分支输出的每一个特征向量采用单独分类方式，然后将各损失加和作为模型的总损失。在验证阶段，将输入图像经过三个网络分支后得到的三个特征向量进行串联，获得一个长度为 3072 的新特征向量。通过欧氏距离度量方法，查询图像与候选图像集中每张图像均使用新特征向量一一地进行欧式距离的计算，然后按照距离由大到小进行排列。

4.3.2 实验分析

本小节将对每个模块进行实验验证与分析，并通过消融实验选取出最优的模块组合。分别有多分支联合学习实验、注意力机制的影响和不同种类 ID 损失函数下的实验。

(1) 多分支联合学习实验结果

为了测试多分支联合学习的有效性，本章分别在 Market-1501 数据集和 DukeMTMC-reID 数据集上进行了实验验证，结果分别如表 4-1 和表 4-2 所示。

对于 Market-1501 数据集，对比两分支联合学习的模型，三支联合学习模型的 Rank-1 精度值分别提高 2.3 个百分点和 1.1 个百分点，mAP 值分别提高了 1.2 个百分点和 1.8 个百分点。其中两分支 (v1+v2) 联合学习的模型在加入异构特征提取模块 v3 后，模型的 Rank-1 精度值提高了 2.3 个百分点，mAP 值提高了 1.8 个百分点。本章所提三支模型相对全局单分支模型在 Rank-1 精度值上提升了 3.3 个百分点，在 mAP 值上提升了 3.6 个百分点。

对于 DukeMTMC-reID 数据集，对比两分支联合学习的模型，三支联合学习模型的 Rank-1 精度分别有 1.9 和 1.8 个百分点的提升，mAP 精度分别有 2.9 和 2.1 个百分点的提升。其中两分支(v1+v2) 联合学习的模型在加入异构特征提取模块 v3 后，模型的 Rank-1 精度有 1.9 个百分点的提升，mAP 精度有 2.9 个百分点的提升。本章所提三支联合学习模型相对全局单分支模型在 Rank-1 精度上有 3.2 个百分点的提升，在 mAP 值上有 4.7 个百分点的提升。

表 4-1 Market-1501 上不同策略的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
v1	93.4	95.4	98.5	85.9
v1+v2	94.4	96.5	98.7	87.7
v1 +v3	95.6	97.4	99.0	88.9
v1+v2+v3	96.7	98.6	99.5	89.5

表 4-2 DukeMTMC-reID 上不同策略的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
v1	88.5	94.6	96.3	76.9
v1+v2	89.8	95.1	96.7	78.7
v1 +v3	89.9	95.1	96.5	79.5
v1+v2+v3	91.7	95.8	96.9	81.6

从实验数据可以看出,单一的全局特征分支识别精度较低,将局部特征进行关联计算,识别精度相对于仅使用全局特征时有较大的提升。行人重识别模型加入异构特征后,增加了模型的特征多样性,识别精度提升显著。实验结果表明,多分支联合学习可以使模型学习到鲁棒性更强的特征,异构特征提取模块对于提取更加多样化的差异特征效果明显。

(2) 注意力机制的影响

本章将主流的注意力模块添加到共享卷积网络中,以使模型更专注于显著性较强的特征,表现为对一个区域内的重要信息进行重复抓取,通过对比发现两个比较对象间具有何种程度的相似性和差异性,从而识别出最匹配的目标。实验结果如表 4-3 和表 4-4 所示。从表中数据可以得出,注意力模块对模型性能的改善做出了贡献,对比未使用注意力模块的模型,骨架网络中嵌入注意力机制的模型在 Market-1501 数据集下 Rank-1 精度有 0.6 个百分点的提升, mAP 精度有 0.5 个百分点的提升。在 DukeMTMC-reID 数据集下 Rank-1 精度有 0.7 个百分点的提升, mAP 精度有 0.3 个百分点的提升。

表 4-3 Market-1501 上注意力机制的影响

注意力模块	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
无	96.1	98.2	99.3	89.0
有	96.7	98.6	99.5	89.5

表 4-4 DukeMTMC-reID 上注意力机制的影响

注意力模块	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
无	91.0	95.5	96.4	81.3
有	91.7	95.8	96.9	81.6

(3) 不同种类 ID 损失函数下的实验结果

与 PCB 及其变体采用多重 ID 损失不同的是,本章通过将多个关联条纹特征向量串联为一个新的特征向量,并用单一 ID 损失函数进行监督优化。利用多重 ID 损失可以获得与条纹特征数量一致的 ID 损失数量,这样做的好处是每个条纹特征向量根据数据集中的行人身份标签学习每个特定局部区域的特征,但缺点是某些条纹特征向量不具备区分性,因此不能进行正确有效的身份预测,从而导致匹配失败。为了验证单一 ID 损失函数的有效性,本章分别在 Market-1501 数据集和 DukeMTMC-reID 数据集上进行了实验验证,实验结果分别如表 4-5 和表 4-6 所示。

以 Market-1501 数据集下三支联合学习模型为例,如表 4-5 所示,单一 ID 损失下的模型相比于多重 ID 损失下的模型在 Rank-1 精度值上有 1.9 个百分点的提升,在 mAP 值上有 3.6 个百分点的提升。同理在 DukeMTMC-reID 数据集下,如表 4-6 所示,单一 ID 损失下的模型相比于多重 ID 损失下的模型在 Rank-1 精度上有 1.8 个百分点的提升,在 mAP 精度上有 3.8 个百分点的提升。实验结果表明,单一 ID 损失函数能够帮助模型学习并整合局部区域的关键特征,强化了行人重识别模型的判别力,在本章所提模型中的表现更好。

表 4-5 Market-1501 上不同损失的实验结果

Method	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
多重 ID 损失	94.8	97.6	98.8	85.9
单一 ID 损失	96.7	98.6	99.5	89.5

表 4-6 DukeMTMC-reID 上不同损失的实验结果

Method	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
多重 ID 损失	89.9	93.6	95.2	77.8
单一 ID 损失	91.7	95.8	96.9	81.6

4.3.3 关联特征提取模块的有效性

不同数据集上特征关联计算前后的重识别结果如表 4-7 和表 4-8 所示,本节实验包含两部分:(1)剔除异构分支 v3,余下一个全局分支和一个局部分支;(2)所有分支均保留,从而检验本章条纹特征关联模块的有效性。由表中数据可见,关联计算后的网络模型识别性能更好,从侧面表现出经过关联特征提取模块后的特征包含行人更多的信息,更有助于行人重识别任务。

通过对基础网络输出的特征图进行不同的操作,模型从特征图中获得的信息也各不相同。全局特征包含的显著特征单一,网络只对行人图像中的某一小区域感兴趣。局部特征与全局特征相比具有一定程度的多样性,包含特征相对丰富,而关联计算后网络能够综合学习行人的身体特征,有助于创建更好的特征表示,使所学的激活特征更分散在行人的身上,从而所得特征更能代表特定的行人。因此将局部特征进行关联计算不仅增加了行人显著特征的利用率,而且加强了局部与局部、局部与整体之间的联系。实验结

果表明条纹特征关联模块能够学习并整合不同的局部特征，使整体模型得到更丰富的行人特征，从而在处理行人重识别任务时具有一定的优势。

表 4-7 Market-1501 上关联计算前后的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
v1+v2 (前)	93.7	95.8	98.3	87.1
v1+v2 (后)	94.4	96.5	98.7	87.7
v1+v2+v3 (前)	96.0	98.3	99.0	89.3
v1+v2+v3 (后)	96.7	98.6	99.5	89.5

表 4-8 DukeMTMC-reID 上关联计算前后的实验结果

模型	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
v1+v2 (前)	89.2	95.0	96.6	78.2
v1+v2 (后)	89.8	95.1	96.7	78.7
v1+v2+v3 (前)	91.5	95.4	96.4	81.3
v1+v2+v3 (后)	91.7	95.8	96.9	81.6

4.3.4 检索排序图

图 4-7 展示了本章网络模型和 OSNet 网络模型在 Market-1501 测试集上的部分行人的前 10 个匹配结果排序图。从图中可以看出，本章网络模型在行人图像完整和较多无关特征干扰时的表现均优于 OSNet 模型。从排序结果看，两个网络模型的错误匹配和测试对象 query 很相似，但本章网络关注到了更精细的局部特征。例如排序结果(c)中，匹配到的错误对象与 query 所处背景环境杂乱且相似，都穿着紫色 T 恤和灰黑色裤子，显然两个网络都能很好地识别行人外观颜色信息。但是 OSNet 网络匹配到的错误检索结果头部未戴有白色帽子，本章网络则捕捉到了白色帽子这一局部特征，进一步说明本章模型对局部小区域的关注度很高。综合所有匹配结果来看，在行人姿态发生明显变化、光线照度明显变暗和行人所处背景杂乱时，本章模型比 OSNet 模型更能准确识别行人身份，表明本章模型所提取的特征具有较强的鲁棒性和判别力。



图 4-7 本章模型在 Market-1501 数据集上部分测试结果

表 4-9 与主流算法的性能比较

Method	Market-1501		Duke-MTMCReID	
	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
SONA[70]	95.6	88.6	89.2	78.0
Auto-ReID[71]	94.5	85.1	88.5	75.1
CAMA[72]	94.7	84.5	85.8	72.9
MGN[15]	95.7	86.9	88.7	78.4
Pyramid[64]	92.8	82.1	-	-
Bag Of Tricks[73]	94.5	85.9	86.4	76.4
MHN[74]	95.1	85.9	89.1	77.2
OSNet[49]	94.8	84.9	88.6	73.5
IAN[75]	94.4	83.1	87.1	73.4
本章算法	96.7	89.5	91.7	81.6

4.3.5 与现有方法的比较

将本章算法与现阶段表现较突出的 8 种行人重识别算法进行对比以验证其有效性。包括金字塔模型 Pyramid^[64]、二阶注意力机制 SONA^{[68][70]}、搜索零件感知 Auto-ReID^[71]、类激活图增强 CAMA^[72]、多粒度网络 MGN^[15]、技巧包 Bag Of Tricks^[73]、混合高阶注意力 MHN^[74]、全尺度网络 OSNet^[49]和交互与聚集网络 IAN^[75]。由表 4-9，本章所提方法在两个公开数据集上展示了较好的特征映射性能。在 Market-1501 数据集上得到的 Rank-1 和 mAP 精度值为 96.7%和 89.5%。在 DukeMTMC-reID 数据集上得到的 Rank-1 和 mAP 精度值为 91.7%和 81.6%，显著优于其他方法。结果表明，本章构建的模型不仅继承了 OSNet 的轻量级特性，而且显著提升了重识别的精度。

4.4 本章小结

本章提出了异构分支关联特征融合的行人重识别算法。使用条纹特征关联模块，综合了位于条纹间的关联信息；加入异构特征提取分支，增加了网络模型学习差异特征所需的结构多样性；结合注意力机制对特征进行增强，拉大了不同通道与空间位置特征的重要性差距，帮助网络突出强调更重要的特征，使网络模型学习显著性和区分性更强的行人关键特征；采用单一 ID 损失函数对条纹特征关联模块进行监督，避免特征的错误学习，并提高预测的可靠性。本章方法在两个公开数据集的实验结果表明该算法能够有效提高行人重识别的准确度。

实验过程中，全局分支对整幅图像提取特征时会受到复杂背景的影响以及前景遮挡的干扰。在今后的研究过程中，将考虑结合人体骨骼姿态图以进一步提升模型的行人重识别能力。

第五章 融合多分区特征的行人重识别

5.1 引言

上一章结合局部和全局特征的行人重识别方法性能良好，在一定程度上克服了全局特征单一、关键部位信息缺失和行人局部特征错位的问题，从而获得了更具鲁棒性的行人外观表征。其中局部特征的提取主要采取空间分区策略，这种横向划分行人身体部位的方式可以提取行人外观上呈现矩形的区域，如衣服胸前位置的贴图，但单一的分区方式所得的特征分布图也单一，且往往会忽略背包肩带这类纵向的特征。这类纵向的特征信息在嵌入空间中表现为信道方向的信息。近年来，研究者对信道 (Channel) 信息的操作给各种视觉任务带来了重大进展，如组归一化和通道注意力等。在 ResNeXt 中研究发现，大量的信道组可以在不增加计算复杂度的情况下，可以显著提高图像分类任务的准确性^[77]。同样，组归一化方法通过将信道划分为几个组，并在每个信道组内计算归一化的均值和方差^[58]，最终表现优于批归一化。这些研究证实了划分信道组在各种视觉任务中是有效的，因此本章研究了信道分区在行人重识别任务中的可应用性，并将其与空间分区等不同分区方式相结合，获得语义信息更丰富的特征分布图，从而提高模型的识别准确度。

5.2 融合多分区特征的行人重识别

在本节中，主要分为 3 个部分研究融合多分区特征的行人重识别网络，首先分析空间分区与信道分区的特性和二者的差别，然后对此设计提出了多分区特征提取模块，最后梳理本章模型的总体结构和所用网络约束。

5.2.1 空间分区与信道分区特性分析

网络获取自主干网络的行人特征图具有三维维度，即高度 H 、宽度 W 和信道 C 。高度 H 和宽度 W 都对应于图像的空间坐标，因此沿着高度和宽度维度进行的局部特征的提取方式称为空间分区。而信道 C 是独立于空间坐标的，因此沿着信道维度进行的划分称为信道分区。图 5-1 展示了提取局部特征的两种分区方式，第三章和第四章所使用的方法即为图 5-1 中右上侧的空间分区方式。




图 5-1 空间分区与信道分区示意图

为了直观地表现网络对两种分区方式所得特征的关注方式和关注程度，本节使用 Grad-CAM^[53]生成了对应的热力图，如图 5-2 所示，其中子图(a)为仅采用分类损失训练的网络模型所提取的行人全局特征，子图(b)和(c)为采用图 5-1 的空间分区方式所得的行人上身和下身的特征热力图，子图(d)和(e)为采用图 5-1 的信道分区方式所得的行人两组通道对应的特征热力图，可见每种分区方式所得对应的特征分布具有明显的区别。

由于子图(a)的行人全局特征，网络更加关注行人上半身，特别是背带右侧的区域，而其他区域包括左臂和整个下半身被完全忽略。当以这种方式进行网络的训练时，模型只考虑行人上半身衣服上有区别的区域特征，而忽略其他区域的特征。因此，模型在这些区域上易过拟合，不易区分难例样本，从而难以对行人进行正确的分类。对该行人采用图 5-1 所示的空间和信道二分区方式，并在所得的每个分区特征上应用不同的分类器(类似于图 2-8)，通过训练保证每个分类器在对应的局部区域内表现最优，从而获得鉴别性更强的局部特征，相应的特征分布如图 5-2(b)-(e)所示。与子图(a)相比，经过空间二分区得到的特征热力图(b)突出显示了行人上半身的多个区域，(c)则突出显示了行人下半身区域，每个分区都有足够的特征被提取，比全局特征(a)包含的信息更加丰富细腻。经过信道二分区得到的(d)突出的是行人穿着的 T 恤和裤子这类外观特征，(e)突出显示了行人身上的背包带和鞋子等细节，这些突出部分更多是网络对不同语义概念的描述，表明信道分区下的网络模型学习到的是一组高级语义功能，它能够将不同信道组的高级特征相关联，从而进行更加精细的特征匹配与整合。

由于信道分区的激活区域不同于空间分区的激活区域，可以推断采用两种分区方式提取的局部特征在联合训练时是互补的。该推断在实验中被证实。因此本章在全局特征的基础上，提出融合多分区特征的行人重识别方法，同时采用空间分区和信道分区方式提取行人局部特征，利用二者的互补特性，获得语义信息更加丰富的行人特征，从而提升行人重识别模型的性能。




图 5-2 不同分区方式所得特征分布图示意

5.2.2 多分区特征提取模块

多分区特征提取模块包括高激活擦除模块、金字塔空间分区模块和信道分区模块。

(1) 高激活擦除模块。就全局特征而言，现有模型的全局分支仅采用图例 5-2(a) 和图例 5-3(b) 所示的全局特征，但是易忽略其余大面积可用行人特征。此外，数据集中的行人图像，用于匹配两个人的区分性区域不一定是可见可用的，这就要求模型保持高性能，不仅仅依赖于可区分性强的区域。换句话说，好的模型必须具备在区分性较差的区域依然能辨别出该行人的能力。因此本章在原有的全局分支中增加了一个擦除分支与

其形成互补，全局分支仍关注高区分度区域，擦除分支则关注余下的低区分度区域，并从中学习相对高鉴别性的特征，两个子分支互相补充，使行人的全局表征更加丰富具体。受文献[78]和[79]的启发，模拟上述情景，如图 5-3 所示，在全局分支上应用高激活擦除模块，删除全局特征中被高度关注的区域获得子图(b)，训练网络从剩余区域中学习相对具有高区分度的特征，如子图(c)。



图 5-3 高激活擦除示例

对于一个训练批次中的 N 张图像，首先为每幅图像定义信息最丰富、激活程度最高的条纹区域。 branch1 输出 N 个尺寸为 $c \times h \times w$ 的特征图 F ，其中 c 、 h 和 w 分别表示图像的信道、高度和宽度，按照文献[80]中的定义将特征 F 转化为激活图 A

$$A = \sum_{i=1}^c |F_i|, \quad (5.1)$$

其中 F_i 表示 $h \times w$ 的张量。然后在 A 的基础上将每个条纹区域的相关性 r_j 定义为第 j 行上像素值的平均值

$$r_j = \frac{\sum_{k=1}^w A_{j,k}}{w}, \quad (5.2)$$

最后剔除 r_j 值最大的行，通过创建一个与 F 大小相同的二进制掩模图 TDM ，并将 F 和 TDM 进行点积操作，如图 5-3(b) 以剔除激活最高的条纹区域。

$$\text{TDM}_{i,j,k} = \begin{cases} 0, & \text{if } r_j \in \text{the largest values} \\ 1, & \text{otherwise} \end{cases}, \quad (5.3)$$

$$r_j = \frac{\sum_{i=1}^c \sum_{k=1}^w |F_{i,j,k}|}{w}, \quad (5.4)$$

其中 $1 \leq i \leq c$ ， $1 \leq k \leq w$ 。 r_j 定义中的 $|*|$ 函数表示特征图 F 中像素值大于零的区域，即图 5-3 子图(a)中颜色最亮的红色区域为激活程度最高的区域，这些区域包含了更具有辨别性的信息，通过删除它们鼓励网络学习并区分可用信息较少的样本（即图 5-3 子图(b)的剩余区域），从而增强其对区分性较低区域的学习和鉴别能力。图 5-3 子图(c)即为删除高激活区域后，网络对低激活区域所学的特征。

(2) 信道分区模块。对于信道分支的输入特征张量 $F \in R(C * H * W)$ ，在信道 C 方向进行二分，以获得信道方向上的两个区域特征组 M_C

$$M_C = F_{1,2} \in R(C/2, H, W). \quad (5.5)$$

(3) 金字塔空间分区模块。与 PCB 模型只考虑分割的特征，完全忽略了整体特征在网络中的作用不同，对于输入的特征张量 $F \in R(C * H * W)$ ，本章通过设置划分级别 k 来获得不同粒度的局部特征，构建了一个金字塔结构，从而使提取到的特征更加细腻全面。如图 5-4 左侧，顶层只包含一个全局特征；最底层有 k 个条纹特征；中间层按照公式 (5.6) 根据所设级别数 p 对特征图进行切分重组，从而获得不同数量的条纹特征组 M_p 。

$$M_p = F_{1 \sim p} \in R\left(C, \left(\left((K-1)*H/n+1\right): \left((k-1)*H/n+l*H/n\right)\right), W\right), \quad (5.6)$$

$$F_{1 \sim k} \in R(C * (H/k) * W), \quad (5.7)$$

其中 $l=1,2,\dots,p$ ， $n=1,2,\dots,k$ ， p, k 为设置的划分级别数； $F_{1 \sim k}$ 为金字塔最底层的 k 个条纹特征表示。

将局部条纹特征组 M_p 送到多池特征提取器，以获得最终的特征表示向量 F_o

$$F_o = C_{1 \times 1} \left\{ C_c \left(\frac{1}{W \times H} \sum_{x=1}^W \sum_{y=1}^H (M_p(x, y)), \max_{x=1, y=1}^{W, H} (M_p(x, y)) \right) \right\}, \quad (5.8)$$

其中 $C_c(*)$ 表示对 $*$ 进行拼接操作， $C_{1 \times 1}(*)$ 表示 1×1 卷积降维操作。




图 5-4 金字塔空间分区分支结构

对于条纹特征组 M_p ，平均池化 AP 可以更好地聚合特征中的高级语义信息，最大池化 MP 可以保留特征映射中响应性最快的部分。因此，该特征提取器使用了两种不同的池化方法，保证了特征信息的完整性，并突出了特征的判别部分。如图 5-4 所示，对获得的不同数量的局部特征采用最大池化 MP 和平均池化 AP，得到了相应的两个特征映射并将其拼接，由于拼接操作增加了向量的维数，因此引入了一个 1×1 的卷积层减少其维数并得到向量 F_o ，从而提高提取器的运算效率。紧接着在 BN 层和 ReLU 激活函数之

后,再通过一个全连接层 FC 变为 512 维的向量 $g_{spatial}$,再使用该特征向量来计算多相似性损失。最后通过 BN 层和 FC 层获得最终的分类特征向量 $\hat{g}_{spatial}$,并用于计算分类损失。在测试阶段,本章使用 BN 层的输出作为测试向量。

5.2.3 网络结构与约束

(1) 网络整体结构

本章模型所用骨架网络与第四章保持一致,模型结构如图 5-5 所示,包括三个分支,分别为全局与擦除分支 (branch1)、信道分区分支 (branch2) 和空间分区分支 (branch3),图中 D 表示特征向量的维数,骨架网络仍选用轻量的 OSNet,与第四章不同的是,本章主干共享网络使用截断的 OSNet,即从初始层到第三个卷积块的第一层 Conv3_0,在 Conv3_1 层之后的所有层都被复制,形成三个独立的分支,使所得特征图中保留图像行人更多的高级特征。主干共享网络输出的特征图被复制为三份作为三个分支子网络的输入,分别得到特征图 T_1 、 T_2 、 T_3 ,它们的尺寸均为 $24 \times 8 \times 512$ 。




图 5-5 本章网络模型结构

(a) 全局与擦除分支。该分支包含了两个全局表征:首先,在张量 T_1 上应用平均池化 AP 聚合信息,得到 512 维向量 g 。然后将张量 T_1 作为高激活擦除模块的输入,移除 T_1 中被高度激活的区域,再应用最大池化 MP,得到另一个 512 维向量 g_{drop} 。特征向量 g 和 g_{drop} 互相补充,使行人的全局表征更加丰富具体,从而增加了特征表示的鲁棒性。

(b) 信道分区分支。输入特征张量 T_2 经平均池化 AP 后简化为一个 512 维的特征向量,然后被划分为两个 256 维的向量。为了方便推理阶段的计算,保证该分支特征向量与其它分支维度一致,用 1×1 的卷积扩展该向量的特征维度,得到两个 512 维向量 c_1 和 c_2 ,其中 1×1 卷积块在两个信道子分支之间共享参数。

(c) 空间分区分支。本章将输入的特征张量 T_3 按照第三、四章的方法进行空间分区，但不同的是，本章通过设置划分级别，在每个划分级别上得到不同粒度的局部特征。所得特征结构类似金字塔，顶层只包含一个全局特征，中间层根据所设级别数对特征图 T_3 进行切分重组，获得不同尺度不同数量的条纹特征，底层包含的条纹特征数量最多、尺度最小。最后该分支所有特征经多池特征提取器获得一个 512 维向量 $g_{spatial}$ 。

对所得的 5 个分支向量使用 BNNeck 结构^[73]，每个 BNNeck 块由批归一化和一个全连接层组成，目的是同时优化度量排序空间和身份标识空间中的两个不同嵌入特征。训练分类器为 5 个全连接层，最终特征向量上分别有 5 个交叉熵损失和 2 个多相似性损失。

(2) 损失函数

2.2.2 节提到的三元组距离损失，通过难例挖掘可以较大程度地抑制样本冗余，提高其表现力。它更多考虑正样本对之间的相对相似性，通过设置裕量参数增加正样本对的相似性，减小负样本对的相似性。然而负样本对具有更大的相似性意味着很难从不同的类别中区分两个样本。换句话说，如果能从难以分辨的负样本对中学习最相似的区域并加以区分，那么网络也将更容易辨识正样本对，因此学习具有更大相似性的负对样本对的鉴别特征更有意义。多相似性损失(Multiple Similarities Loss, MS Loss)将三元组损失中的采样问题转换为成对加权，并在局部数据分布中测量多个样本相关性，然后联合挖掘样本对的自相似性和相对相似性，再对不同的相似性赋予不同的权重，进而加权迭代样本对，从中收集鉴别信息^[81]，是更优的损失函数选择。

本章采用 ID 预测损失和多相似性损失的组合约束网络。同第三章，由于两个损失函数的优化目标不一致，因此将 BNNeck 之前获得的嵌入特征用于优化排序损失，即多相似性损失；将 BNNeck 之后获得的嵌入特征用于身份损失的优化，即 ID 预测损失；BNNeck 结构中批归一化之后全连接层之前获得的嵌入特征可以在两个不同的度量空间之间找到平衡，因此被用于推理阶段。本章将从图 5-5 所示的网络中获得的嵌入特征进行如下分组

$$\Upsilon = \left\{ \hat{g}, \hat{g}_{drop}, \hat{c}_1, \hat{c}_2, \hat{g}_{spatial} \right\}, \quad (5.9)$$

$$\Theta = \left\{ g, g_{drop}, g_{spatial} \right\}, \quad (5.10)$$

其中 $\hat{*}$ 表示 BNNeck 之后的特征向量，对应至图 5-2 有： $\hat{g}$ 、 $\hat{g}_{drop}$ 为全局与擦除分支输出的特征向量， $\hat{c}_1$ 、 $\hat{c}_2$ 为信道分区分支输出的特征向量， $\hat{g}_{spatial}$ 为空间分区分支输出的特征向量。将不同的损失函数用于上述两个特征向量组，分别计算 BNNeck 之前的全局嵌入特征 Θ 的多相似性损失 L_{MS} 和 BNNeck 之后的所有嵌入特征 Υ 上的 ID 预测损失 L_{ID} 。

$$L_{MS}(f(X), y) = \sum_{r \in \Upsilon} L_{MS}(r, y), \quad (5.11)$$

$$L_{ID}(f(X), y) = \sum_{\theta \in \Theta} L_{ID}(\theta, y), \quad (5.12)$$

$$L = \alpha L_{MS} + \beta L_{ID}. \quad (5.13)$$

其中 $f(X)$ 表示网络对于输入图像 X 的输出特征; L 为总损失函数, α 、 β 为两个损失所占的权重。本章对 ID 预测损失函数使用了标签平滑正则化技术, 通过在 ID 预测损失的计算过程中增加均匀的噪声分布, 降低了行人身份标签的存在性, 从而提高整体模型的泛化能力。

5.3 实验结果及分析

本章所用的深度学习框架为 Pytorch-1.0.1, 实验平台的操作系统为 Ubuntu16.04, 编程语言版本为 Python3.6。硬件所用的显卡内存为 11G 的 4 块 2080T GPU, CUDA 版本为 10.1, CUDNN 版本为 7.0。所有的实验结果和对比结果均使用第二章 2.1.1 节提到的单张 query 检索配置。

5.3.1 实验参数设置

实验所用的骨架网络为截断式的 OSNet 并经过了权重初始化, 输入行人图像的空间分辨率大小调整为 384×128 , 并将图像大小调整到 105% 的宽度和高度, 然后经过随机裁剪、擦除和归一化策略进行数据增强。使用随机擦除, 从而产生具有更高方差的训练数据并提高模型的泛化能力。输入图像经过主干共享网络得到特征图的大小为 $24 \times 8 \times 512$, 该特征图经过三个分支子网络后输出 5 个相同维数的特征向量。本章使用预热余弦退火作为学习速率策略, 学习速率首先在前 10 代从 $6 \cdot 10^{-5}$ 线性增长至 $6 \cdot 10^{-4}$, 再在剩余的训练时期应用余弦衰减至 $6 \cdot 10^{-7}$ 。因此总的学习速率 $learningrate(t)$ 为

$$learningrate(t) = \begin{cases} 6 \cdot 10^{-4} \cdot \frac{t}{10}, & \text{if } t \leq 10 \\ 6 \cdot 10^{-4} \cdot \frac{1}{2} \left(1 + \cos \left(\pi \frac{t-10}{T-10} \right) \right), & \text{if } 10 \leq t \leq T \end{cases}. \quad (5.14)$$

在训练过程中, 本章实验使用 Adam 优化器^[69]对每一个批次 batchsize 进行参数的优化和更新, 参数选择 $\varepsilon=1e-8$ 、 $\beta_1=0.9$ 、 $\beta_2=0.999$ 。批大小设置为 64 (一批次有 8 个身份, 每个身份有 8 张图像)。模型在 Market-1501 和 DukeMTMC-reID 数据集训练 140 代, 在 CUHK03 数据集训练 180 代。对三个分支输出的每一个特征向量采用独立的分类方式, 然后将各损失加和作为模型的总损失, 为了平衡损失, 选择各损失的权重参数为 $\alpha = \beta = 0.5$ 。在验证阶段, 查询图像和图库图像的分辨率分别重新调整至 384×128 像素并归一化, 利用余弦距离计算特征相似度。评估标准是 CMC 曲线的 Rank-K 表格形式和 mAP, 且不计算与查询图像具有相同身份 ID 和相同相机 ID 的结果。

5.3.2 实验分析

本小节将对每个模块进行实验验证与分析, 并通过消融实验选取出最优的模块组合。分别有不同分支特征的消融实验、学习率和擦除模块对模型性能的影响。

(1) 不同分支特征的消融实验

当将不同的分支引入神经网络体系结构时, 参数量会有所增加, 但是由于不同分支

提取到分布不同的特征,因此性能也会得到提升。表 5-1 至 5-3 为本章网络在不同数据集上对不同分支进行组合得到的性能实验结果。从表中数据可以看出,当其他两个分支不作用时,单个分支的识别准确率相差不大,表现相似;而三个分支相结合的模型表现最佳。由于本章模型每个分支提取的特征类型固定,如全局分支提取全局特征,信道分区分支提取信道方向特征,空间分区分支提取的是行人身体局部特征,因此表格中的数据也说明,模型的性能与所用行人特征类型有关,在一定程度内,融合特征类型越多,网络所提取的行人特征语义信息越丰富,模型的重识别性能越好。图 5-6 列举了两个数据集上的评价指标曲线图,随着样本数量的增多,总体呈现上升趋势。

(a) 擦除模块的影响。以表 5-1 为例,表格中数据的第一二行, **baseline** 为不加擦除模块的全局分支,显然加了擦除模块以后 **Rank-1/mAP** 精度值提高了 1.6/3.1 个百分点。这说明擦除模块在剔除了高鉴别性区域后,网络仍然可以从其余区域学习到判别力强的特征,该特征与原有全局特征的互相补充,使行人的整体特征更加丰富具体,从而提高了网络所学特征的区分能力。

(b) 信道分区的影响。**DukeMTMC-reID** 和 **CUHK03** 两个数据集的结果中,信道分区单分支的表现效果最差,但与其它分支相结合识别准确度大幅提升。在一定程度上说明了信道分区学习到的语义概念层的特征对于区分行人是有帮助的。单独使用全局特征,网络也学习了语义层的信息,但相对信道分区来说,针对性不强,全局特征更多的是表现一幅图像里行人穿了什么颜色的衣服等外观信息,而信道信息则更具体为身上的背带这类细节性的特征。显然细节特征的作用更大。信道分支单独作用时,网络可能只关注到背带的细节,在图片中行人没有背带时即认为身份不对应,归类为不同样本,但这就忽视了行人的整体信息,因此空间分区所得的身体部位特征和全局分支特征都是不可缺少的一部分。

表 5-1 Market-1501 上不同分支特征的消融实验结果

分支 branch	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	93.6	95.8	97.9	85.9
branch1	95.2	97.4	99.0	89.0
branch2	95.5	97.5	99.1	88.4
branch3	95.6	97.5	99.1	89.9
branch1+branch2	96.1	98.4	99.1	90.9
branch1+branch3	95.9	98.3	99.0	89.8
branch2+branch3	96.0	98.5	99.2	91.0
branch1+branch2+branch3	96.3	98.6	99.5	91.2




图 5-6 数据集上评价指标的增长趋势图

表 5-2 DukeMTMC-reID 上不同分支特征的消融实验结果

分支 branch	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	88.2	93.4	95.6	76.8
branch1	89.9	95.2	97.0	81.1
branch2	85.5	91.3	94.5	78.8
branch3	89.4	94.5	96.5	80.9
branch1+branch2	91.6	96.0	97.2	81.7
branch1+branch3	91.3	95.5	96.7	81.4
branch2+branch3	91.5	95.8	97.1	81.5
branch1+branch2+branch3	91.9	96.0	97.3	82.1

表 5-3 CUHK03 上不同分支特征的消融实验结果

分支 branch	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)	mAP (%)
baseline	79.3	83.6	91.0	75.9
branch1	81.3	85.6	92.3	77.4
branch2	74.9	83.3	89.7	71.1
branch3	80.9	85.1	91.4	77.7
branch1+branch2	83.6	88.2	93.8	80.2
branch1+branch3	82.5	86.6	92.3	80.1
branch2+branch3	84.0	89.3	95.0	82.1
branch1+branch2+branch3	85.2	89.9	95.3	83.5

(2) 不同基准网络下的实验结果

表 5-4 为分别以 ResNet-50 和 OSNet 为基准网络，并分别在不同数据集上的实验结果，且设置了一系列的训练技巧。其中 WCA 表示使用余弦退火预热学习率，MS 为使用多相似性损失，DB 为使用高激活擦除模块，空白处表示不设置任何训练技巧。结果表明，以 ResNet-50 为骨架的模型在所有模型中性能最弱，通过所有训练技巧的设置，才实现了与 OSNet 不使用技巧的模型的类似性能。

表 5-4 不同基准网络下的性能比较

基准网络	训练技巧			Market-1501		CUHK03	
	WCA	MS	DB	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
ResNet-50				95.5	88.2	71.8	70.6
ResNet-50	√	√	√	96.0	90.5	81.5	79.6
OSNet				95.9	90.1	78.4	75.3
OSNet	√			96.1	91.0	83.8	81.3
OSNet	√		√	96.2	91.2	83.6	80.9
OSNet		√	√	95.9	90.5	79.3	77.1
OSNet	√	√		96.0	91.1	84.7	81.0
OSNet	√	√	√	96.3	91.2	85.2	83.5

5.3.3 方法对比

表格 5-5 为本章算法在 Market-1501 和 DukeMTMV-reID 数据集上与其他方法比较性能结果的比较，加粗字体为最高准确度。可见本章模型在全局特征基础上，同时采用空间分区和信道分区方式提取局部特征，利用特征类型之间的互补特性，可以获得更加丰富细腻的行人表征，从而显著提高模型的表现力。对比方法中相似的是 SCR 网络模型^[82]，但是 SCR 没有在全局分支中剔除高激活区域，且空间分区分支中只考虑局

部未考虑局部与整体的关系，因此本章方法识别准确率稍高。此外，SCR 的每个分支均有空间分区和信道分区后的特征，这在精度的比较上会影响判断，到底起作用的是哪种分区方式、哪种类型的特征。而本章将所得不同类型的特征单分支化，可以更好地从数据判断其作用是否明晰。结果在 Market-1501 数据集表现出的 Rank-1 和 mAP 为 96.3%和 91.2%。在 DukeMTMC-reID 数据集上表现的 Rank-1 和 mAP 为 91.9%和 82.1%，优于其他对比方法，其中 mAP 值的提升非常明显，表明本章模型在处理行人重识别任务时是具有一定优势的。

表 5-5 与主流算法的性能比较

Method	Market-1501		Duke-MTMCreID	
	Rank-1 (%)	mAP (%)	Rank-1 (%)	mAP (%)
Bag Of Tricks[73]	94.5	85.9	86.4	76.4
OSNet[49]	94.8	84.9	88.6	73.5
BDB[79]	95.3	86.7	89.0	76.0
AWTL[63]	89.5	75.7	79.8	63.4
MGN[15]	95.7	86.9	88.7	78.4
PCB+RPP[14]	93.8	81.6	83.3	69.2
Pyramid[64]	92.8	82.1	-	-
SCR[82]	95.7	89.0	91.1	81.4
PLR-OSNet[83]	95.6	88.9	91.6	81.2
MHN[74]	95.1	85.9	89.1	77.2
Compact Re-ID[84]	96.2	89.7	89.8	80.3
本章算法	96.3	91.2	91.9	82.1

5.4 本章小结

本章在已有的空间分区基础上，引入了信道分区，提出了一个融合多分区特征的多分支行人重识别网络。使用了轻量级的 OSNet 作为骨干网络提取目标特征，虽然分支数增加了总体的参数复杂度，但是主干网络和适当的训练技巧相结合可以保持总体模型仍然在一个较低的复杂度。网络模型的不同分支负责学习捕捉行人不同区域的不同特征。全局分支中加入擦除模块，剔除区分性最强的区域，帮助网络从区分度低的区域学习判别性强的特征；信道分区与空间分区互补，帮助网络在学习身体部位特征的同时，更强调了语义概念层面的重要性，进一步提升了识别准确度。将所提算法分别在公开数据集上进行了有效性实验验证。结果表明该算法能够完成预期目标，有效地提高了行人重识别的准确度。

第六章 主要结论与展望

6.1 主要结论

行人重识别技术作为计算机视觉任务的基础问题，目前在智能安防、目标跟踪等诸多领域都发挥了越来越重要的作用。由于行人重识别任务对于行人特征的判别力有着极高的要求，而图像数据包含的行人识别可用信息较少，因此，如何高效地定位并组织图像行人的局部特征信息，提高现有的行人重识别算法的准确度依然是一个应用价值极高的课题。

本文的研究主要是通过有效地提取行人局部特征并加以融合利用来对锁定的目标进行识别。在 PCB 结构模型的基础上，一方面继承其对图像遮挡等具有较强鲁棒性的优势，另一方面针对其特征判别力不足的缺陷，从局部特征提取模型的改进、骨架网络的改进、不同分区特征融合、注意力机制、多分支结构等多个方面进行改进。本文主要完成了以下各项工作：

(1) 针对局部特征提取不当时的信息缺失导致特征鲁棒性和判别力不足的问题，首先分析了网络对行人的全局和局部特征的关注特点，讨论了各自对识别准确度的影响，并据此设计了重叠条纹特征提取模块，使其弥补提取行人局部特征时缺失的关键信息；其次，更深层的网络可以充分利用不同层的丰富信息，因此，本文采取了分层特征融合的方式，加强网络模型对细节信息的区分能力；最后，本文设计了组归一化模块，消除了不同损失函数在优化方向上存在的差异，网络模型学习到更多难例样本的有效信息，从而提升网络模型对行人特征的鉴别能力。

(2) 针对采用多分支结构的行人重识别模型在提取行人特征时缺乏异构特征的问题，本文提出了异构分支关联特征融合的行人重识别方法。首先将注意力机制融入主干共享卷积网络，扩大了不同信道的权重差距，促使网络模型更关注那些显著性和区分性更强的区域；接着，设计了条纹特征关联模块，从而加强行人身体各部位的联系；最后，从特征多样性入手，设计了异构特征提取模块，增加了模型学习差异特征所需的结构多样性，并通过使用单一 ID 损失函数，减少了模型的错误匹配。

(3) 针对采用空间分区的行人重识别模型在提取行人特征时忽略纵向高级信息的问题，本文提出了融合多分区特征的行人重识别方法。首先，分析了在采用不同分区方式提取行人的局部特征时，特征分布表现出来的差异，并据此设计了多分区特征融合模块，促使网络学习更丰富的判别信息。接着，构建了高激活擦除模块，剔除最受网络关注的区域，提高了网络模型对低关注度区域中的高判别力特征的学习。最后，设计了金字塔空间分区模块和信道分区模块，二者形成互补，既使网络充分学习了行人的局部信息，又突出了语义表达的重要性，进而提高了模型学习小区域丰富语义信息的能力。

(4) 本文通过组合所提各模块并设计不同策略下的对比实验，并在三个数据集上进行了实验验证，获得了重识别效果最佳的网络模型。将最佳模型与目前主流的重识别算法模型进行了比较，实验结果表明，本文网络模型提取的特征具有较强的鲁棒性和判别力，能够有效地减少无关特征的干扰。融合局部特征的深度学习行人重识别方法能够有

效地减少错误的检索匹配，并显著提高识别精度。

6.2 展望

本文虽然通过改进局部特征提取方式、融合不同分区特征、嵌入注意力机制等手段提升了行人重识别的检索准确度，但是仍存在一些局限和不足，后续的研究可以从以下几个方面入手：

(1) 设计不同权重的特征映射函数。对于第三章分层特征融合的方式，如果网络低层特征语义化程度低，在高层特征鲁棒性不足时直接融合该特征可能引起模型性能的下降，因此计划在未来的工作中，设计一个特征映射函数，利用不同层的卷积特征图的互补性来获得更好的模型性能。

(2) 分离行人可见部位区域。对整幅图像提取特征时会受到遮挡物的干扰，因此计划在未来的工作中，将图像中行人的可见部分分离出来并用于检索，进一步提升行人重识别性能。

(3) 兼顾计算速度与识别准确度。第五章的多分支体系结构允许网络关注各个分支中人物的不同特征，虽然分支通常会增加模型的可用性性能，但是它会带来更高的计算成本，计划在未来的工作中开发更加轻量级的基准网络，减少模型计算量，提高检索效率。

致谢

时光荏苒，一晃三年的硕士生活已至尾声，回想自己的学习生活，感触颇深。有初入江大的兴奋雀跃，有结识好友的志同道合，有因学术研究而产生的彷徨忧虑，有文章小有进展的欣喜。三年中收获颇多，有专业知识的积累，有良师益友的教导，有同窗的搀扶鼓励。

感谢导师彭力教授对我学术研究道路上的鼓励和引领以及生活情绪上的劝导。学术研究方面，彭老师教导大家要时刻保有认真严谨的态度，并且以身作则地为我们示范，常常组织小会议，带领大家探讨相关领域的发展近况和未来的发展方向，同时鼓励我们大胆创新，有想法就要付诸行动。而我在开始接触陌生选题时的担忧也渐渐地转变为对学术的热爱。生活方面，当情绪出现问题时，彭老师会耐心地询问并聆听我的困扰，然后给出指导性的建议，对我助益良多。另外，彭老师也非常关心我们的身体素质，时常会组织一些团体活动，如郊游、排球等，让大家在快乐学习的同时也能积极地对待身边的一切。

感谢同窗好友的鼓励搀扶，大家的每一次鼓励都使我愈发奋进。感谢师兄在我方向迷茫时给的建议和指导；感谢同级的伙伴们，大家共同在科研项目上探讨交流，闲暇时又不忘互相鼓励。团队中的师弟师妹们每天也乐趣多多，为实验室增添了不少欢乐的氛围。感谢 403 小屋各位的陪伴，家一般的温暖为三点一线的科研生活增色良多。

感谢家人和男朋友对我的支持和鼓励，每当我情绪上出现波动，他们总是会第一时间察觉到，并对我给予关心和爱护，让我倍感温暖。

最后，衷心地感谢各位论文评审老师和答辩老师的认真和奉献。

参考文献

- [1] 尹萍, 赵亚丽. 视频监控中的行人再识别技术综述[J]. 警察技术, 2018, 166(01): 65-68.
- [2] Zajdel W, Zivkovic Z, Krose B J. Keeping track of humans: have I seen this person before? [C]. Proceedings of the IEEE International Conference on Robotics and Automation, 2005: 2081-2086.
- [3] Gheissari N, Sebastian T B, Hartley R. Person reidentification using spatiotemporal appearance [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2006: 1528-1535.
- [4] Bazzani L, Cristani M, Murino V. Symmetry-driven accumulation of local features for human characterization and re-identification [J]. Computer Vision and Image Understanding, 2013, 117(02): 130-144.
- [5] Zhao R, Ouyang W, Wang X. Unsupervised salience learning for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2013: 3586-3593.
- [6] Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 2197-2206.
- [7] Yang Y, Ramanan D. Articulated pose estimation with flexible mixtures-of-parts [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2011: 1385-1392.
- [8] Li A, Liu L, Yan S. Person re-identification by attribute-assisted clothes appearance [M]. Advances in Computer Vision and Pattern Recognition, 2014: 119-138.
- [9] Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2012: 2288-2295.
- [10] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval [C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 3800-3808.
- [11] Wang Y, Wang L, You Y, et al. Resource aware person re-identification across multiple resolutions [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2018: 8042-8051.
- [12] Xiao T, Li H S, Wang X G, et al. Learning deep feature representations with domain guided dropout for person re-identification [C]. Proceedings of the IEEE International Conference on Computer Vision, 2016: 1249-1258.
- [13] Luo H, Jiang W, Fan X, et al. A survey on deep learning based person re-identification [J]. Acta Automatica Sinica, 2019, 45(11): 2032-2049.
- [14] Sun Y, Zheng L, Yang Y, et al. Beyond part models: person retrieval with refined part pooling (and a strong convolutional baseline)[C]. Proceedings of the European Conference on Computer Vision, 2018: 501-518.
- [15] Wang G S, Yuan Y F, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification [C]. Proceedings of the ACM International Conference on Multimedia, 2018: 274-282.
- [16] Zheng F, Deng C, Sun X, et al. Pyramidal person re-identification via multi-loss dynamic training [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 8514-8522.
- [17] 郑爱华, 曾小强, 江波, 等. 基于局部异质协同双路网络的跨模态行人重识别[J]. 模式识别与人工智能, 2020, 33(10): 867-878.
- [18] 匡澄, 陈莹. 基于多粒度特征融合网络的行人重识别[J]. 电子学报, 2021, 49(08): 1541-1550.

- [19] Wang G S, Yuan Y F, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification [C]. Proceedings of the ACM International Conference on Multimedia, 2018: 274-282.
- [20] Sun Y F, Xu Y, Zhang C, et al. Perceive where to focus: learning visibility-aware part-level features for partial person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019. 393-402.
- [21] Fu Y, Wei Y C, Zhou Y Q, et al. Self-similarity grouping: a simple unsupervised cross domain adaptation approach for person re-identification [C]. Proceedings of the IEEE International Conference on Computer Vision, 2019. 6112-6121.
- [22] Ahmed E, Jones M, Marks T K. An improved deep learning architecture for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3908-3916.
- [23] Zhao H Y, Tian M Q, Sun S Y, et al. Spindle net: person re-identification with human body region guided feature decomposition and fusion [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 907-915.
- [24] Zheng L, Huang Y J, Lu H C, et al. Pose invariant embedding for deep person re-identification [J]. IEEE Transactions on Image Processing, 2017, 28(09): 4500-4509.
- [25] Wu Z, Li Y, Radke R J. Viewpoint invariant human re-identification in camera networks using pose priors and subject-discriminative features [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(05): 1095-1108.
- [26] Liang Z, Huang Y, Lu H, et al. Pose-invariant embedding for deep person re-identification [J]. IEEE Transactions on Image Processing, 2019, 28(09): 4500-4509.
- [27] Xu J, Zhao R, Zhu F, et al. Attention-aware compositional network for person re-identification [C]. Proceedings of The IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2119-2128.
- [28] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification [C]. Proceedings of The IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2285-2294.
- [29] Cheng D, Gong Y H, Zhou S P, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016. 1335-1344.
- [30] 姚足, 龚勋, 陈锐, 等. 面向行人重识别的局部特征研究进展、挑战与展望[J]. 自动化学报, 2020, 5(05): 1-19.
- [31] Wang Z, Peng C, Zhang N, et al. Fully convolutional siamese networks based change detection for optical aerial images with focal contrastive loss [J]. Neurocomputing, 2021, 457(11): 155-167.
- [32] Chen W, Chen X, Zhang J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 403-412.
- [33] 冯敏, 张智成, 吕进, 等. 基于生成对抗网络的跨模态行人重识别研究[J]. 现代信息科技, 2020, 4(04): 107-109.
- [34] 邱耀儒, 孙为军, 黄永慧, 等. 基于生成对抗网络联合时空模型的行人重识别方法[J]. 计算机应用, 2020, 40(09): 2493-2498.
- [35] Alejandro N, Yang K Y, Deng J. Stacked hourglass networks for human pose estimation [J]. European Conference on Computer Vision, 2016(08): 483-499.
- [36] Christian S, Vincent V, Sergey I, et al. Rethinking the inception architecture for computer vision [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.
- [37] Ren S Q, He K M, Ross G, et al. Faster r-cnn: towards real-time object detection with region proposal networks [J]. IEEE transactions on Pattern Analysis and Machine Intelligence, 2016, 39(06): 1137-1149.
- [38] Zheng Z, Zheng L, Yang Y. Pedestrian alignment network for large-scale person re-identification [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(10): 3037-3045.

- [39] He L, Liang J, Li H, et al. Deep spatial feature reconstruction for partial person re-identification: alignment-free approach [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7073-7082.
- [40] Luo H, Jiang W, Fan X, et al. Stnreid: deep convolutional networks with pairwise spatial transformer networks for partial person re-identification [J]. IEEE Transactions on Multimedia, 2020, 22(11): 2905-2913.
- [41] Jaderberg M, Simonyan K, Zisserman A. Spatial transformer networks [J]. Advances in Neural Information Processing Systems, 2015, 28: 2017-2025.
- [42] He T, Shen X, Huang J, et al. Partial person re-identification with part-part correspondence learning [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2021: 9105-9115.
- [43] Chung D, Tahboub K, Delp E J. A two stream siamese convolutional neural network for person re-identification [C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 1983-1991.
- [44] Song G, Leng B, Liu Y, et al. Region-based quality estimation network for large-scale person re-identification [J]. Artificial Intelligence, 2018, 32(01):365-378.
- [45] Liu Y, Yuan Z, Zhou W, et al. Spatial and temporal mutual promotion for video-based person re-identification [J]. Artificial Intelligence, 2019, 33(01): 8786-8793.
- [46] Liu Y, Zhou W, Xi M, et al. Vision meets wireless positioning: effective person re-identification with recurrent context propagation [C]. Proceedings of the ACM International Conference on Multimedia, 2020: 1103-1111.
- [47] 罗浩, 姜伟, 范星, 等. 基于深度学习的行人重识别研究进展[J]. 自动化学报. 2019, 45(11): 2032-2049.
- [48] He K M, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [49] Zhou K, Yang Y, Cavallaro A, et al. Omni-scale feature learning for person re-identification [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3702-3712.
- [50] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: a benchmark [C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 1116-1124.
- [51] Ristani E, Solera F, Zou R S, et al. Performance measures and a data set for multi-target, multi-camera tracking [J]. Computer Vision, 2016, 9914: 17-35.
- [52] Li W, Zhao R, Xiao T, et al. Deepreid: deep filter pairing neural network for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 152-159.
- [53] Selvaraju R R, Cogswell M, Das A, et al. Grad-cam: visual explanations from deep networks via gradient-based localization [C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 618-626.
- [54] 王兴柱, 王儒敬. 三元组在非监督行人再识别中的应用[J]. 仪表技术, 2018, 356(12): 19-21.
- [55] Wen Y D, Zhang K P, Li Z F, et al. A discriminative feature learning approach for deep face recognition [C]. Proceedings of the European Conference on Computer Vision, 2016: 499-515.
- [56] Zhang J. Data sphering: some properties and applications [J]. Annals of the Institute of Statistical Mathematics, 1998, 50(02): 223-240.
- [57] Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift [J]. International Conference on Machine Learning, 2015(03): 448-456.
- [58] Wu Y X, He K M. Group normalization [J]. International Journal of Computer Vision, 2020, 128(03): 742-755.
- [59] 徐龙壮, 朱凤增, 彭力. 多任务金字塔重叠匹配的行人重识别方法[J]. 计算机工程, 2021, 47(01): 239-245.
- [60] Li W, Zhu X, Gong S, et al. Harmonious attention network for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2285-2294.

- [61] Wei L H, Zhang S L, Yao H T, et al. Glad: global-local-alignment descriptor for pedestrian retrieval [C]. Proceedings of the ACM International Conference on Multimedia, 2017: 420-428.
- [62] Sarfraz M S, Schumann A, Eberle A, et al. A pose-sensitive embedding for person re-identification with expanded cross neighborhood re-ranking [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 420-429.
- [63] Ergys R, Carlo T. Features for multi-target multi-camera tracking and re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6036-6046.
- [64] Zheng F, Deng C, Sun X, et al. Pyramidal person re-identification via multi-loss dynamic training [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 8514-8522.
- [65] Yao H, Zhang S, Zhang Y, et al. Deep representation learning with part loss for person re-identification [J]. IEEE Transactions on Image Processing, 2019, 28(06): 2860-2871.
- [66] Song C F, Huang Y, Ouyang W L, et al. Mask-guided contrastive attention model for person re-identification [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 1179-1188.
- [67] Chen T, Ding S, Xie J, et al. Abd-net: attentive but diverse person re-identification [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 8351-8361.
- [68] 王粉花, 赵波, 黄超, 等. 基于多尺度和注意力融合学习的行人重识别[J]. 电子与信息学报, 2020, 42(12): 222-229.
- [69] Kingma D P, Ba J. Adam: a method for stochastic optimization [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 805-813.
- [70] Xia B N, Gong Y, Zhang Y, et al. Second-order non-local attention networks for person re-identification [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3760-3769.
- [71] Quan R, Dong X, Wu Y, et al. Auto-reid: searching for a part-aware convnet for person re-identification [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3750-3759.
- [72] Yang W, Huang H, Zhang Z, et al. Towards rich feature discovery with class activation maps augmentation for person re-identification [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 1389-1398.
- [73] He T, Zhang Z, Zhang H, et al. Bag of tricks for image classification with convolutional neural networks [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 558-567.
- [74] Chen B, Deng W, Hu J. Mixed high-order attention network for person re-identification [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 371-381.
- [75] Hou R, Ma B, Chang H, et al. Interaction-and-aggregation network for person re-identification [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 9317-9326.
- [76] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks [J]. Communications of the ACM, 2017, 60(06): 84-90.
- [77] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1492-1500.
- [78] Quispe R, Pedrini H. Top-db-net: top dropblock for activation enhancement in person re-identification [C]. Proceedings of the International Conference on Pattern Recognition, 2021: 2980-2987.
- [79] Dai Z, Chen M, Gu X, et al. Batch dropblock network for person re-identification and beyond [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3691-3701.
- [80] Zagoruyko S, Komodakis N. Paying more attention to attention: improving the performance of convolutional neural networks via attention transfer [C]. Proceedings of the International Conference on Learning Representations, 2017: 2480-2489.

-
- [81] Wang X, Han X, Huang W, et al. Multi-similarity loss with general pair weighting for deep metric learning [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 5022-5030.
- [82] Chen H, Lagadec B, Bremond F. Learning discriminative and generalizable representations by spatial-channel partition for person re-identification [C]. Proceedings of the IEEE/CVF Conference on Applications of Computer Vision, 2020: 2483-2492.
- [83] Xie B, Wu X, Zhang S, et al. Learning diverse features with part-level resolution for person re-identification [C]. Proceedings of the International Conference on Pattern Recognition and Computer Vision, 2020: 216-228.
- [84] Lawen H, Ben-Cohen A, Protter M, et al. Compact network training for person re-id [C]. Proceedings of the International Conference on Multimedia Retrieval, 2020: 164-171.

附录: 作者在攻读硕士学位期间发表的论文

- [1] 陈璠, 彭力. 多层次重叠条纹特征融合的行人重识别[J]. 计算机科学与探索, 2021, 15(09): 1753-1761.
- [2] 陈璠, 彭力. 异构分支关联特征融合的行人重识别[J]. 计算机科学与探索. doi: 10.3778/j.issn.1673-9418.2103082